

Modelarea piețelor financiare

Capitolul 1: Fapte stilizate și randamente



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Randamente imprevizibile, volatilitate previzibilă

Ce trebuie să poți face

- calculezi și agregi randamente simple și logaritmice
- măsori cozile cu momente, cuantile și estimatorul Hill
- distingi lipsa corelației de independență
- alegi teste a căror distribuție de referință rămîne validă
- estimezi volatilitatea din deschidere, maxim, minim și închidere
- verifici o ipoteză propusă de un asistent de inteligență artificială (AI)

Definiție

- Un **fapt stilizat** este o regularitate statistică calitativă a **randamentelor**
  - observată pe multe active, piețe și perioade Cont (2001)
- Rămîne o ipoteză Ratliff-Crain, Van Oort, Koehler & Tivnan (2025)
  - testată din nou pe fiecare piață și frecvență
- Ideea centrală: randamentele sînt slab autocorelate liniar
  - dar **mărimea** lor este în mare măsură predictibilă

- Faptele stilizate sînt proprietățile pe care orice model al randamentelor trebuie să le reproducă
  - modelul i.i.d. (independente și identic distribuite) cu distribuție Normală nu reproduce majoritatea lor
  - demonstrațiile și detaliile tehnice sînt în Anexa de la final

Cum parcurgem capitolul: traseul de bază și studiul aprofundat

Traseul de bază (prima lectură)

- Prețuri și randamente: simplu vs logaritmic, anualizare, CAGR
- Distribuție și cozi: JB, măsuri bazate pe cuantile, estimatorul Hill și tabelul lui
- Dependență: Faptele 1 și 6, benzi ACF robuste, mixtura de Normale
- Persistență: Faptul 8, tabelul $\hat{d}$, ce inferență rămîne validă
- Parkinson și Yang–Zhang; Sharpe, Sortino, Calmar, drawdown
- Implicații pentru modelare; concluzii

Studiu aprofundat (a doua lectură)

- Condițiile de momente din metoda delta; formulele Whittle local și log-periodogramă
- Rupturi structurale și efectul Taylor
- Garman–Klass și Rogers–Satchell
- Studiul de caz (11 slide-uri) și bucla de descoperire cu AI
- Anexa: demonstrații, estimări pe cele două cozi, SE Sharpe dincolo de Normală

- Exerciții rezolvate: Seminarul 1, A1 (randamente), A4 (mixturi), A8 (estimatori din range)

Cinci piețe cu reguli de cotare și calendare diferite

Serie	Tip de preț	Tip, monedă	Calendar	Eșantion	T
S&P 500	închidere zilnică (plus deschidere, maxim, minim)	indice de preț, USD	zilele de tranzacționare din SUA	1990–2026	9 245
BET-TR	închidere zilnică	randament total, RON	zilele de tranzacționare ale Bursei de Valori București (BVB)	sept. 2014 – 2026	2 992
Bitcoin	închidere zilnică	preț, USD	în fiecare zi, 24/7	sept. 2014 – 2026	4 384
EUR/RON	cursul de referință al Băncii Naționale a României (BNR)	lei pe euro, managed float	zilele lucrătoare din România	iul. 2005 – 2026	5 352
Aur	închidere zilnică	spot, USD pe uncie	doar zilele lucrătoare	1990–2026	9 559

- Prețuri de închidere zilnice, pînă la 18 septembrie 2026
  - BET-TR: indicele BET al BVB, cu dividendele reinvestite (total return)
  - randamente logaritmice zilnice, fiecare serie pe propriul calendar
  - T: numărul de randamente zilnice ale seriei

Cînd distorsionează cotațiile randamentele măsurate?

- **Managed float** (flotare controlată): regim în care cursul se formează pe piață, cu intervenții ale băncii centrale
  - folosim cursul de referință BNR în locul cotațiilor interbancare EUR/RON
  - în mai mulți ani, cotațiile interbancare au o autocorelație de lag 1 între $-0{,}4$ și $-0{,}7$, generată de erori de cotare
- Prețul de deschidere al S&P 500 coincide adesea cu închiderea precedentă (stale open)
  - înainte de 2008 fenomenul era sistematic: circa 96% din zile în 1996–2005, încă 16% în 2007
  - de aceea, estimatorii volatilității bazați pe range (amplitudinea zilnică) folosesc doar datele din 2008 încoace
  - ulterior, stale open-urile sînt sporadice (3,5% din zile în 2008–2026), dar se concentrează în 2012–2013 (pînă la 26%); acești ani rămîn în eșantion, iar comparația cu SPY arată efectul lor

Randament simplu sau logaritmic: ce se adună în timp și ce se adună între active

	Randament simplu R_t	**Randament logaritmic r_t**
Definiție	$(P_t + D_t)/P_{t-\mathbf{1}} - \mathbf{1}$	$\ln(\mathbf{1} + R_t) = \ln P_t - \ln P_{t-\mathbf{1}}$ (fără dividend)
Pe k perioade	$\prod_{j=\mathbf{0}}^{k-\mathbf{1}}(1 + R_{t-j}) - \mathbf{1}$	$\sum_{j=\mathbf{0}}^{k-\mathbf{1}} r_{t-j}$: aditiv în **timp**
Agregare între active	$R_{p,t} = \sum_i w_i R_{i,t}$: exactă	doar aproximativă
Domeniu	$R_t \geq -100\%$	$(-\infty, +\infty)$
Utilizare tipică	portofolii, raportarea randamentelor	dinamica unui activ, teorema limită centrală (CLT)

- Randamentul simplu este variația relativă a valorii investiției
- Randamentul logaritmic este variația logaritmului prețului
- Notațiile
  - P_t: prețul de închidere al zilei t
  - D_t: dividendul plătit în intervalul $(t-1, t]$
  - k: numărul de perioade agregate
  - indicele $j = 0, \ldots, k-1$ parcurge aceste perioade
  - $R_{i,t}$: randamentul simplu al activului i
  - w_i: ponderea lui în valoarea portofoliului, cu $\sum_i w_i = 1$
  - $R_{p,t}$: randamentul portofoliului
- Cînd activul plătește dividende, folosiți serii de randament total sau serii ajustate (BET-TR)

De ce randamentul logaritmic este mereu sub cel simplu

- Randamentul logaritmic este întotdeauna mai mic decît randamentul simplu: $r = \ln(1 + R) < R$ pentru orice $R \neq 0$
  - motivul: $\ln(1 + x) < x$ pentru orice $x > -1$, $x \neq 0$, deoarece funcția logaritm este concavă
- Diferența este neglijabilă pentru variații mici și importantă pentru scăderi mari:
  - $R = +1\%$ dă $r = 0{,}995\%$
  - $R = -50\%$ dă $r = -69{,}3\%$
- Agregarea în timp: randamentul logaritmic pe k zile este suma celor k randamente logaritmice zilnice
  - randamentul simplu pe k zile cere produsul factorilor de creștere $1 + R_{t-j}$
- Exemplu: prețul trece de la 100 la 110, apoi la 99 (Seminarul 1, A1)
  - randamentele simple $+10\%$ și -10% au suma 0, dar valoarea scade cu 1%: $1{,}1 \times 0{,}9 = 0{,}99$
  - randamentele logaritmice $9{,}53\%$ și $-10{,}54\%$ au suma $-1{,}01\% = \ln 0{,}99$
- Manuale: Campbell, Lo & MacKinlay (1997), cap. 1; Franke, Härdle & Hafner (2019)

De la zi la an: cînd este corectă regula $\sqrt{A}$

- Anualizarea transformă media și volatilitatea zilnice în valori pe un an
- Notațiile
  - A: numărul de perioade de randament dintr-un an
  - 252 pentru acțiuni și EUR/RON (zile de tranzacționare), 365 pentru cripto (tranzacționate în fiecare zi), $\approx$ 260 pentru aur (cotațiile efective din zilele lucrătoare)
  - $\bar{r} = \frac{1}{T}\sum_{t=1}^{T} r_t$: media randamentelor logaritmice zilnice
  - $\hat{\sigma}$: abaterea standard de selecție a randamentelor zilnice
- $\mu_{\text{an}} = A\,\bar{r}$: media anuală a randamentelor **logaritmice** (rata de creștere logaritmică)
  - presupune doar o medie constantă
  - raportul Sharpe folosește mai tîrziu media anuală a randamentelor **simple**, $A\bar{R}$, care este mai mare
- $\sigma_{\text{an}} = \sqrt{A}\,\hat{\sigma}$: volatilitatea anuală
  - exactă doar pentru randamente necorelate serial, cu variață constantă
  - atunci variațele zilnice se adună, iar varianța anuală este $A\,\hat{\sigma}^2$
  - cu autocorelație, factorul $\sqrt{A}$ nu mai este corect
  - EUR/RON, cu autocorelația de lag 1 de 0,17: după corecție, volatilitatea anualizată crește de la 4,4% la 5,3% (▸ Anexă; Seminarul 1, A7 obține această valoare, folosiți-o ca verificare)

CAGR și volatility drag: de ce media aritmetică supraestimează creșterea

- **CAGR** (Compound Annual Growth Rate): randamentul anual constant care duce prețul de la P_0 la P_T

$$\text{CAGR} = (P_T/P_0)^{1/Y} - 1$$

  - P_0, P_T: prețul la începutul și la sfîrșitul eșantionului
  - Y: numărul de ani
  - CAGR este media geometrică anuală a factorilor de creștere

- Logaritmul factorului geometric de creștere $\approx \mu_{\text{aritm}} - \sigma^2/2$, citită pe **scară logaritmică**:

$$\ln(1 + \text{CAGR}) = \tfrac{1}{Y} \ln(P_T/P_0) \approx \mu_{\text{aritm}} - \sigma^2/2$$

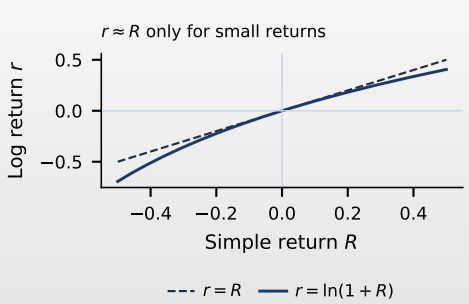
  - μ_{aritm}: media aritmetică anuală a randamentelor simple; σ^2: varianța lor anuală
  - $\ln(1 + \text{CAGR})$: rata de creștere compusă continuu, adică media anuală a randamentelor logaritmice $A\bar{r}$
  - **volatility drag**: diferența dintre media aritmetică și cea geometrică; pe scară logaritmică este $\approx \sigma^2/2$ și crește cu pătratul volatilității

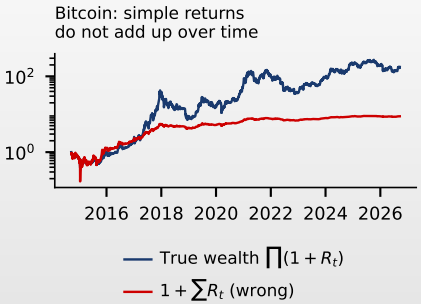
Volatility drag în cifre: S&P 500 și Bitcoin

	μ_{aritm}	σ	$\sigma^2/2$	$\ln(1+\text{CAGR})$	CAGR
S&P 500 1990–2026 ($A = 252$)	9,95%	17,97%	1,62 pp	8,33%	8,69%
Bitcoin 2014–2026 ($A = 365$)	65,2%	66,6%	22,2 pp	43,1%	53,9%

- Drag-ul pe scară logaritmică, $\mu_{\text{aritm}} - \ln(1+\text{CAGR})$: $9{,}95 - 8{,}33 = 1{,}62$ pp și $65{,}2 - 43{,}1 = 22{,}1$ pp, adică $\sigma^2/2$
- Drag-ul măsurat față de CAGR, $\mu_{\text{aritm}} - \text{CAGR}$: 1,26 pp pentru S&P 500 și 11 pp (puncte procentuale) pentru Bitcoin
  - mai mic, deoarece $\text{CAGR} = e^{\ln(1+\text{CAGR})} - 1$ este peste logaritmul său: $e^{0{,}431} - 1 = 53{,}9\%$
  - cînd o valoare este numită „drag", precizați care dintre cele două diferențe este
- S&P 500: $\hat{\sigma} = 1{,}133\%$ pe zi, 18,0% pe an (randamente logaritmice); indice de preț, fără dividende
- **Verificare**: aurul are CAGR 6,7% și $\sigma = 16{,}3\%$. Estimați μ_{aritm}
  - răspuns: $\ln 1{,}067 + 0{,}163^2/2 = 6{,}5\% + 1{,}3\% \approx 7{,}8\%$; comparați cu Sharpe $0{,}48 \times 16{,}3\% \approx 7{,}8\%$ (tabelul din anexă)

Randamente simple și logaritmice în practică

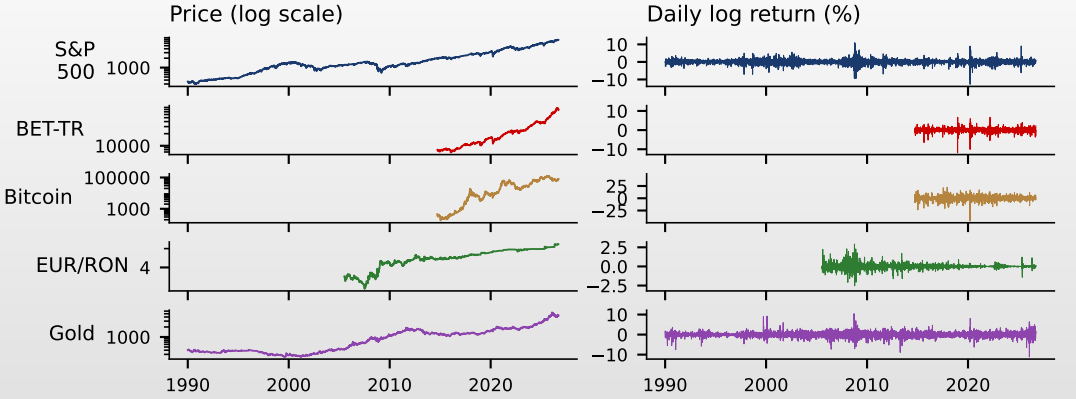




- Stînga: $r \approx R$ doar pentru variații mici
- Dreapta: Bitcoin 2014–2026 a multiplicat valoarea investiției de 176,9 ori, adică $\sum_t r_t = \ln 176{,}9 = 5{,}18$
  - suma randamentelor logaritmice zilnice este $\ln(P_T/P_0)$, logaritmul multiplicatorului
  - adunarea randamentelor simple zilnice dă $1 + \sum_t R_t = 8{,}83$, de 20 de ori mai puțin decît multiplicatorul real

MFM_ch1_returns

Cinci piețe: prețuri și randamente logaritmice zilnice



Prețurile au tendință, randamentele oscilează în jurul unei medii mici

- **Stînga:** prețuri pe scală logaritmică: serii cu tendință, nestaționare
- **Dreapta:** randamentele logaritmice zilnice
  - fluctuează în jurul unei medii mici
  - perioadele calme alternează cu cele agitate
  - valorile extreme apar grupat (2008, martie 2020)
- EUR/RON variază cu peste 1% doar în 1,4% din zile
- Bitcoin, 12 martie 2020: randament logaritmic $-46{,}5\%$
  - prețul se înmulțește cu e^{r_t}, deci scade cu $1 - e^{-0{,}465} = 37{,}2\%$

MFM_ch1_returns

Asimetria și kurtosisul: forma distribuției după standardizare

- Asimetria și kurtosisul descriu forma distribuției, după eliminarea mediei și a scalei

$$z_t = \frac{r_t - \bar{r}}{\hat{\sigma}}, \qquad \hat{S} = \frac{1}{T}\sum_{t=1}^{T} z_t^3, \qquad \hat{K} = \frac{1}{T}\sum_{t=1}^{T} z_t^4$$

  - z_t: randamentul standardizat, cu media 0 și abaterea standard 1
  - $\hat{S}$: asimetria de selecție
  - $\hat{S} < 0$: coada stîngă este mai lungă, pierderile mari domină
  - $\hat{K}$: kurtosisul de selecție
  - $\hat{K} > 3$: mai multă masă în centru și în cozi decît la distribuția Normală
  - S și K fără $\hat{}$: valorile din populație
  - notația $\hat{}$ indică o valoare estimată
- Distribuția Normală: $S = 0$, $K = 3$, excesul de kurtosis $K - 3 = 0$

Cît de precis estimăm media, asimetria și kurtosisul

- **Eroarea standard** (SE): abaterea standard a unui estimator de la un eșantion la altul
- Media: $\mathrm{SE}(\bar{r}) = \sigma/\sqrt{T}$, cu σ abaterea standard a randamentelor zilnice, estimată prin $\hat{\sigma}$
  - intervalul de încredere de 95%: $\bar{r} \pm 1{,}96\,\mathrm{SE}(\bar{r})$
  - mediile zilnice sînt de 13 pînă la 40 de ori mai mici decît $\hat{\sigma}$
  - deci, **raportat la mărimea sa**, media este momentul estimat cu cea mai mică precizie
  - S&P 500: $\bar{r} = 0{,}033\% \pm 0{,}023\%$ pe zi (95%), $T = 9\,245$; $\mathrm{SE}/|\bar{r}| = 0{,}0118/0{,}033 \approx 0{,}36$
  - momentele superioare au altă problemă: SE poate să nici nu existe (secțiunea despre cozi)
- Pentru date i.i.d. din distribuția Normală: $\sqrt{T}\,\hat{S} \to N(0,6)$ și $\sqrt{T}(\hat{K}-3) \to N(0,24)$
  - $\to$: convergența în distribuție cînd $T \to \infty$
  - $N(0,v)$: distribuția Normală cu media 0 și varianța v
  - deci $\mathrm{SE}(\hat{S}) \approx \sqrt{6/T}$ și $\mathrm{SE}(\hat{K}) \approx \sqrt{24/T}$
  - pentru S&P 500, cele două erori standard sînt 0,025 și 0,051

Metoda delta și momentele care trebuie să existe

- **Metoda delta** dă eroarea standard a unei funcții de un estimator

$$\sqrt{T}(\hat{\theta} - \theta) \to N(0, v) \implies \sqrt{T}\left(g(\hat{\theta}) - g(\theta)\right) \to N(0, g'(\theta)^2 v)$$

  - θ: un parametru, de exemplu un moment
  - $\hat{\theta}$: estimatorul lui
  - v: varianța asimptotică a lui $\hat{\theta}$
  - g: o funcție derivabilă, de exemplu raportul de momente care definește $\hat{S}$
  - g': derivata ei
  - ideea: dezvoltarea Taylor de ordinul întîi $g(\hat{\theta}) \approx g(\theta) + g'(\theta)(\hat{\theta} - \theta)$
- Pentru date i.i.d. cu orice distribuție, metoda delta dă o distribuție limită Normală
  - pentru $\hat{S}$ doar dacă $\mathbb{E}r^6 < \infty$, pentru $\hat{K}$ doar dacă $\mathbb{E}r^8 < \infty$
  - $\mathbb{E}$: media (valoarea așteptată)
  - $\mathbb{E}r^6 < \infty$: momentul de ordinul 6 este finit
  - varianța lui $\hat{S}$ conține momentul de ordinul 6, iar cea a lui $\hat{K}$ momentul de ordinul 8
  - existența acestor momente se verifică empiric în secțiunea despre cozi

Noțiunile de care au nevoie testele: ARCH, volatility clustering, tail index

- **ARCH** (heteroscedasticitate condiționată autoregresivă): varianța de azi depinde de randamentele trecute
- **Volatility clustering** (gruparea volatilității): zilele cu variații mari tind să fie urmate de zile cu variații mari
- **Tail index-ul** α măsoară cît de repede scade probabilitatea valorilor extreme

$$P(|r_t| > x) \approx c\, x^{-\alpha} \quad \text{pentru } x \text{ mare}$$

  - x: un prag pozitiv
  - $c > 0$: o constantă de scală
  - un α mic înseamnă o coadă groasă: probabilitatea scade lent cînd x crește
  - deci $\mathbb{E}|r_t|^p < \infty$ doar pentru $p < \alpha$, unde p este ordinul momentului
  - estimările din acest capitol dau $\alpha \approx 3$

Trei teste clasice: normalitate, autocorelație, efecte ARCH

- **JB** (Jarque–Bera): $JB = T\left[\hat{S}^2/6 + (\hat{K}-3)^2/24\right]$
  - distanța asimetriei și a kurtosisului față de valorile distribuției Normale
- **LB** (Ljung–Box): $Q(m) = T(T+2)\sum_{k=1}^{m} \hat{\rho}_k^2/(T-k)$
  - o sumă ponderată a primelor m autocorelații la pătrat
  - $\hat{\rho}_k$: autocorelația de selecție la lagul k, adică între r_t și r_{t-k}
  - aici se folosesc $m = 10$ laguri
- **ARCH-LM**: TR^2 din regresia lui $\hat{\varepsilon}_t^2$ pe $\hat{\varepsilon}_{t-1}^2, \ldots, \hat{\varepsilon}_{t-q}^2$
  - LM: testul multiplicatorului Lagrange
  - $\hat{\varepsilon}_t = r_t - \bar{r}$: reziduurile
  - aici se folosesc $q = 5$ laguri; T numără observațiile regresiei auxiliare, după pierderea acestor laguri
  - R^2: proporția din variația lui $\hat{\varepsilon}_t^2$ explicată de pătratele reziduurilor trecute
- Citirea: toate trei statisticile sînt ≥ 0, iar valorile mari resping ipoteza nulă H_0
  - distribuțiile de referință: χ_2^2, χ_m^2, χ_q^2
  - χ_n^2: distribuția hi-pătrat cu n grade de libertate
  - valori critice la 5%: $\chi_2^2 = 5{,}99$, $\chi_5^2 = 11{,}1$, $\chi_{10}^2 = 18{,}3$

Ce presupune fiecare test și unde cedează pe randamente

Test	Statistică	H_0	Limita χ^2 presupune	Problema pentru randamente
JB, Jarque & Bera (1980)	$T\left[\frac{\hat{S}^2}{6} + \frac{(\hat{K}-3)^2}{24}\right]$	i.i.d., distribuția Normală	chiar H_0 (toate momentele există)	o respingere nu arată ce parte a ipotezei este încălcată
LB, Ljung & Box (1978)	$T(T+2)\sum_{k=1}^{m} \frac{\hat{\rho}_k^2}{T-k}$	$\rho_1 = \cdots = \rho_m = 0$	i.i.d., nu doar absența corelației	volatility clustering: H_0 respinsă prea des
ARCH-LM, Engle (1982)	TR^2, $\hat{\varepsilon}_t^2$ pe q laguri	i.i.d., fără efecte ARCH	sub H_0 i.i.d.: $\mathbb{E}r^4 < \infty$ ($\alpha > 4$)	$\alpha \approx 3 < 4$: valori critice nesigure

- Două condiții de momente pentru ARCH-LM, în două situații diferite
  - sub ipoteza nulă i.i.d.: limita χ^2_q cere o varianță finită a lui r_t^2, adică $\mathbb{E}r^4 < \infty$
  - sub dependență de tip GARCH: ACF de selecție a lui r_t^2, pe care se bazează statistica, folosește limita Normală standard sub condiția de moment $\mathbb{E}r^8 < \infty$ ($\alpha > 8$) Davis & Mikosch (1998); vezi ce inferență rămîne validă
- Problema nu este aplicarea mecanică a testelor
  - ci validitatea distribuției lor de referință pentru randamente

Exemplu rezolvat: JB pentru S&P 500

- Statistica $JB = T\left[\hat{S}^2/6 + (\hat{K}-3)^2/24\right]$, definită la testele clasice
- Valoarea critică χ^2_2 la 5%: 5,99
- S&P 500, 1990–2026: $T = 9\,245$, $\hat{S} = -0{,}364$, $\hat{K} - 3 = 10{,}88$
  - termenul de asimetrie $\hat{S}^2/6 = 0{,}132/6 = 0{,}022$
  - termenul de kurtosis $10{,}88^2/24 = 118{,}4/24 = 4{,}93$
  - $JB = 9\,245 \times (0{,}022 + 4{,}93) \approx 45\,800$, față de valoarea critică 5,99
- Aproape întreaga valoare a statisticii provine din termenul de kurtosis
  - abaterea de la normalitate provine din cozi, nu din asimetrie

Ce arată, și ce nu arată, o respingere JB

- Sub ipoteza nulă toate momentele există
  - deci p-value-ul este valid pentru ipoteza nulă **comună** „i.i.d. și distribuție Normală”
  - în prezența cozilor groase, JB crește odată cu T
  - acesta este un efect al puterii testului, nu un p-value greșit
- O respingere nu arată ce parte a ipotezei este încălcată
  - poate fi încălcată distribuția marginală sau ipoteza de independență
  - teste pentru distribuția marginală cu variante HAC (robuste la heteroscedasticitate și autocorelație): Anexă

Alternativa robustă: asimetrie și kurtosis bazate pe cuantile

- Două măsuri bazate pe cuantile Kim & White (2004), care nu presupun existența momentelor
  - q_p: cuantila de ordin p a randamentelor, valoarea sub care se află o proporție p din zile
  - $q_{0,5}$: mediana
- **Asimetria Hinkley** compară lungimile celor două cozi față de mediană

$$\frac{q_{0,95} + q_{0,05} - 2q_{0,5}}{q_{0,95} - q_{0,05}}$$

  - numărătorul este $(q_{0,95} - q_{0,5}) - (q_{0,5} - q_{0,05})$: coada dreaptă minus coada stîngă
  - ia valori în $[-1, 1]$
  - o valoare negativă indică o coadă stîngă mai lungă
- **Excesul de kurtosis Crow–Siddiqui**, notat K_{CS}, compară lățimea cozilor cu lățimea centrului

$$K_{CS} = \frac{q_{0,975} - q_{0,025}}{q_{0,75} - q_{0,25}} - 2{,}91$$

  - 2,91: valoarea raportului pentru distribuția Normală
  - o valoare pozitivă indică cozi mai groase
  - ambele măsuri sînt 0 pentru distribuția Normală

Intervale de încredere prin bootstrap pe blocuri mobile

- Intervalele de încredere (CI) de 95% se obțin prin **bootstrap pe blocuri mobile**
  - se reeșantionează blocuri de 20 de zile consecutive (1 000 de reeșantionări)
  - măsura se recalculează pe fiecare serie reeșantionată
  - blocurile păstrează dependența din interiorul lor
- Procedura este validă pentru randamente staționare, slab dependente, cu densitate pozitivă în aceste cuantile
- Un CI care nu conține 0 indică o abatere semnificativă de la distribuția Normală

Cozile groase se confirmă și fără momente

	Asimetrie (momente)	Hinkley [CI 95%]	Exces kurt.	Exces Crow–Siddiqui [CI 95%]
S&P 500	−0,36	−0,064 [−0,092; −0,041]	10,9	1,54 [1,29; 1,79]
BET-TR	−1,40	−0,036 [−0,085; 0,025]	17,8	1,06 [0,73; 1,43]
Bitcoin	−0,70	−0,018 [−0,069; 0,032]	12,0	2,25 [1,88; 2,64]
EUR/RON	0,73	0,041 [−0,022; 0,093]	15,1	4,87 [3,74; 6,13]
Aur	−0,23	0,004 [−0,025; 0,030]	9,3	1,47 [1,29; 1,73]

- Excesul de kurtosis bazat pe cuantile (Crow–Siddiqui) este pozitiv pe toate cele cinci piețe
  - niciun CI nu conține 0
- Asimetria negativă bazată pe cuantile este semnificativă doar pentru S&P 500
  - asimetria bazată pe momente a BET-TR (−1,40) provine din cîteva zile extreme (19 decembrie 2018)

MFM_ch1_inference

Statistici descriptive: cinci piețe

	S&P 500	BET-TR	Bitcoin	EUR/RON	Aur
Observații	9 245	2 992	4 384	5 352	9 559
Medie (% pe zi)	0,033	0,077	0,118	0,007	0,025
Abatere standard (% pe zi)	1,13	0,98	3,49	0,28	1,01
Volatilitate anualizată (%)	18,0	15,5	66,6	4,4	16,3
Asimetrie	−0,36	−1,40	−0,70	0,73	−0,23
Exces de kurtosis	10,9	17,8	12,0	15,1	9,3
Randament log min / max (%)	−12,8 / 11,0	−11,9 / 6,7	−46,5 / 22,5	−2,5 / 2,9	−11,1 / 10,4
Jarque–Bera	45 805	40 433	26 482	51 575	34 732
Ljung–Box $Q(10)$, r_t	91,6	70,0	20,2	221,7	32,1
Ljung–Box $Q(10)$, r_t^2	8 018	714	213	2 420	1 049
ARCH-LM (5 laguri)	2 229	371	115	871	483

- Descriptiv: cozi groase pe toate piețele (exces de kurtosis 9,3–17,8)
  - $Q(10)$ pe r_t^2 este de 10–90 de ori mai mare decît pe r_t
  - mărimea randamentelor este mult mai predictibilă decît direcția lor
- Inferențial: toate p-value-urile calculate sub ipoteza i.i.d. sînt sub 0,03
  - dar sînt valide doar sub ipotezele din tabelul celor trei teste clasice

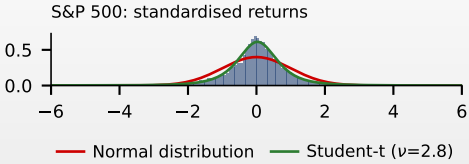
MFM_ch1_summary_statistics

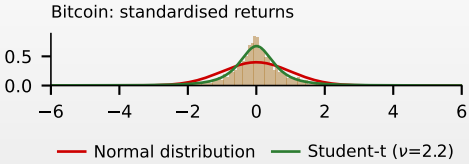
Faptele stilizate după Cont (2001)

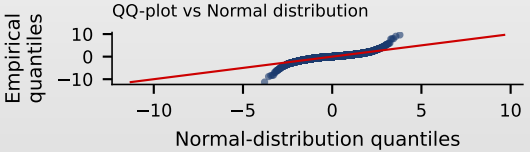
Grupă	Fapte
Distribuție	2. cozi groase; 3. asimetria cîștig/pierdere; 4. gaussianitate prin agregare; 7. cozi groase condiționate
Dependența randamentelor	1. absența autocorelației liniare
Dependența volatilității	5. intermitență; 6. volatility clustering; 8. scăderea lentă a autocorelației lui $\|r_t\|$; 11. asimetria scalelor de timp
Legături cu alte variabile	9. leverage effect; 10. corelația volum–volatilitate

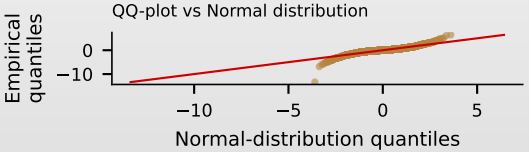
- Le testăm din nou pe cinci piețe, cu date pînă în septembrie 2026
  - completăm fiecare test cu inferența adecvată
- Primele dovezi empirice: Mandelbrot (1963), Fama (1965); în manuale: Taylor (2008), Franke, Härdle & Hafner (2019)

Faptul 2, cozi groase: histograme și grafice cuantilă–cuantilă (QQ plot-uri)









MFM_ch1_heavy_tails

Faptul 2: mai multe zile extreme decît sub distribuția Normală

- Randamentele extreme sînt mult mai frecvente decît sub distribuția Normală
  - la aceeași variantă
- Randamentele standardizate $(r_t - \bar{r})/\hat{\sigma}$ au un vîrf mai înalt și cozi mai groase
- QQ plot-urile compară cuantilele empirice cu cele ale distribuției Normale
  - punctele se abat de la dreaptă în ambele cozi
- O distribuție Student-t descrie centrul distribuției mult mai bine decît Normala
  - dacă descrie și cozile este o întrebare separată, la care răspunde estimatorul Hill

MFM_ch1_heavy_tails

Distribuția Student-t: un model cu cozi groase

- Distribuția Student-t, Praetz (1972): un model cu cozi groase pentru randamente, cu densitatea

$$f(x) \propto \left(1 + \frac{(x-\mu)^2}{\nu s^2}\right)^{-(\nu+1)/2}$$

- Notațiile
  - $f(x)$: densitatea în punctul x
  - $\propto$: „proporțional cu", adică fără constanta de normalizare
  - μ: centrul distribuției
  - $s > 0$: parametrul de scală
  - $\nu > 0$: numărul de grade de libertate
  - un ν mic înseamnă cozi groase
  - cînd $\nu \to \infty$ se obține distribuția Normală
- Pentru o variabilă X cu această distribuție
  - coada $P(X > x) \propto x^{-\nu}$: există doar momentele de ordin $< \nu$
  - varianța $s^2\nu/(\nu-2)$ pentru $\nu > 2$
  - excesul de kurtosis $6/(\nu-4)$ pentru $\nu > 4$

Zile extreme: observate, sub distribuția Normală și sub Student-t

	S&P 500	BET-TR	Bitcoin	EUR/RON	Aur
Zile dincolo de $3\hat{\sigma}$ (%)	1,55	1,44	1,82	2,06	1,42
Zile dincolo de $5\hat{\sigma}$ (număr)	30	12	10	29	26
Număr așteptat sub distribuția Normală, $> 5\hat{\sigma}$	0,005	0,002	0,003	0,003	0,005
Grade de libertate Student-t $\hat{\nu}$ (verosimilitate maximă)	2,8	3,1	2,2	1,2	2,9

- Sub distribuția Normală
  - 0,27% din zile sînt dincolo de 3σ (observat: de 5–8 ori mai mult)
  - o zi de 5σ apare în medie o dată la 6 900 de ani de tranzacționare (observat: 10–30 de zile)
- $\hat{\nu}$ se obține prin **verosimilitate maximă**, pe întreaga distribuție: se aleg μ, s și ν care fac datele observate cele mai probabile
  - numeroasele randamente mici domină estimarea, deci o ajustare slabă în centru deplasează $\hat{\nu}$
  - EUR/RON: $\hat{\nu} = 1{,}2$, deoarece 57% din variațiile zilnice sînt sub 0,1%, la care se adaugă salturi rare

Estimatorul Hill: tail index-ul din cele mai mari observații

- **Tail index-ul** α, definit înaintea testelor clasice: $P(|X| > x) \approx c\, x^{-\alpha}$ pentru x mare
  - X: variabila studiată, aici $|r_t|$
  - $\mathbb{E}|X|^p < \infty$ doar pentru $p < \alpha$
  - $\alpha > 2$: varianță finită
  - $\alpha > 4$: kurtosis finit
  - legile de putere au fost propuse prima dată de Mandelbrot (1963) și Fama (1965)
- **Estimatorul Hill**, Hill (1975): estimează α doar din cele mai mari k observații
  - ordonăm descrescător: $X_{(1)} \geq X_{(2)} \geq \cdots \geq X_{(n)}$
  - $X_{(i)}$: a i-a cea mai mare valoare
  - n: numărul de observații
  - k: numărul de observații din coadă
  - $X_{(k+1)}$ joacă rolul pragului peste care începe coada
- **Coada Pareto**: $P(X > x) = (x/u)^{-\alpha}$ pentru $x \geq u$, cu pragul u
- Aceasta este legea de putere exactă

Estimatorul Hill: inversul mediei depășirilor logaritmice

- Estimatorul Hill este inversul mediei depășirilor logaritmice peste prag

$$\hat{\alpha}_k = \left[\frac{1}{k} \sum_{i=1}^{k} \ln X_{(i)} - \ln X_{(k+1)} \right]^{-1} = \left[\frac{1}{k} \sum_{i=1}^{k} \ln \frac{X_{(i)}}{X_{(k+1)}} \right]^{-1}$$

  - $\ln(X_{(i)}/X_{(k+1)})$: cu cît depășește a i-a valoare pragul, pe scară logaritmică
  - pentru o coadă Pareto, aceste depășiri au în medie valoarea $1/\alpha$
  - depășiri mari înseamnă o coadă groasă, deci un $\hat{\alpha}_k$ mic

- Eroarea standard $\mathrm{SE}(\hat{\alpha}_k) \approx \hat{\alpha}_k/\sqrt{k}$
  - CI de 95%: $\hat{\alpha}_k \pm 1{,}96\,\mathrm{SE}$
  - presupune observații independente în coadă și o coadă de tip Pareto
  - gruparea valorilor extreme mărește SE (Anexă)

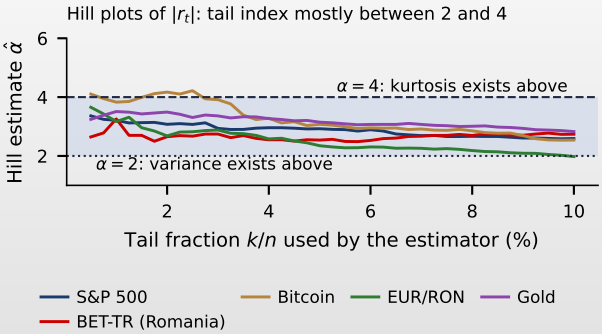
Estimatorul Hill de mînă: un exemplu cu cinci numere

- Date ilustrative: cele mai mari cinci valori $|r_t|$ dintr-un eșantion, în %: 4,0; 3,0; 2,5; 2,2; 2,0
  - luăm $k = 4$, deci pragul este $X_{(5)} = 2{,}0$
- Depășirile logaritmice $\ln(X_{(i)}/X_{(5)})$, $i = 1, \ldots, 4$
  - $\ln 2 = 0{,}693$, $\ln 1{,}5 = 0{,}405$, $\ln 1{,}25 = 0{,}223$, $\ln 1{,}1 = 0{,}095$
  - media $1{,}417/4 = 0{,}354$, deci $\hat{\alpha}_4 = 1/0{,}354 = 2{,}82$
- SE $\approx 2{,}82/\sqrt{4} = 1{,}41$; CI de 95%: [0,06; 5,59]
  - cu 4 puncte în coadă estimarea nu spune aproape nimic; de aceea tabelele folosesc k de ordinul sutelor
- **Verificare**: dublați toate valorile (o piață de două ori mai volatilă). Ce se întîmplă cu $\hat{\alpha}_4$?
  - răspuns: nimic; rapoartele $X_{(i)}/X_{(5)}$ nu se schimbă, deci o schimbare de scală nu modifică tail index-ul
- Exercițiu complet pe date de piață: Seminarul 1, A5

Alegerea lui k: între varianță și deplasare

- **Alegerea lui** k
  - un k mic crește varianța estimatorului
  - un k mare include observații din centrul distribuției și deplasează $\hat{\alpha}$
  - se citește nivelul din zona în care **Hill plot-ul** ($\hat{\alpha}_k$ în funcție de k) este plat
  - aici se folosește k între 1% și 5% din n
- Comparație cu distribuția Student-t, al cărei tail index este $\alpha = \nu$
  - EUR/RON: estimatorul Hill dă $\hat{\alpha} = 2{,}8$, iar $\hat{\nu} = 1{,}2$
  - distribuția Student-t estimată pe întregul eșantion descrie greșit cozile

Hill plot-urile pentru cele cinci piețe



- $\hat{\alpha}$ pentru $|r_t|$ la $k = 2{,}5\%$ din n
  - S&P 500 3,1, BET-TR 2,7, Bitcoin 4,2, EUR/RON 2,8, aur 3,3
- Pentru $k = 1$–5%: $\hat{\alpha}$ între 2,3 și 3,5, cu excepția Bitcoin (3,1–4,2)
- La prag comun, estimarea cozii pierderilor este mai mică pentru BET-TR și Bitcoin; EUR/RON inversează ordinea
  - BET-TR: 2,2 față de 3,1
  - Bitcoin: 2,7 față de 3,4
- Cozile se modelează cu teoria valorilor extreme (Capitolul 7)

MFM_ch1_heavy_tails

Tail index-uri cu intervale de încredere

$\lvert r_t \rvert$, $k = 2{,}5\%$ din n	n	k	$\hat{\alpha}$	SE i.i.d.	CI 95% (i.i.d.)	SE bootstrap pe blocuri
S&P 500	9 245	231	3,07	0,20	[2,68; 3,47]	0,33
BET-TR	2 992	74	2,67	0,31	[2,06; 3,28]	0,45
Bitcoin	4 384	109	4,22	0,40	[3,43; 5,01]	0,47
EUR/RON	5 352	133	2,82	0,24	[2,34; 3,30]	0,28
Aur	9 559	238	3,31	0,21	[2,89; 3,73]	0,24

- Bootstrap-ul pe blocuri mobile (blocuri de 20 de zile, 500 de reeșantionări) păstrează gruparea valorilor extreme
  - SE bootstrap sînt de 1,1–1,6 ori mai mari decît cele i.i.d.

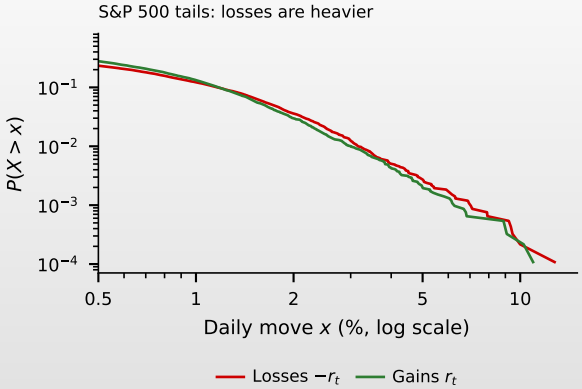
MFM_ch1_inference

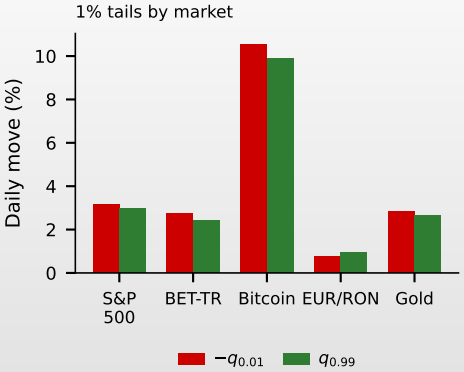
Momentul de ordinul patru este, cel mai probabil, infinit

- $\alpha = 4$ este în afara tuturor intervalelor, cu excepția celui pentru Bitcoin
  - inclusiv cînd intervalul se construiește cu SE bootstrap
  - cel mai probabil, momentul de ordinul patru nu este finit
- $\alpha = 2$ este în afara fiecărui interval i.i.d.
  - cu SE bootstrap, doar intervalul BET-TR îl include: limita inferioară $\hat{\alpha} - 1{,}96\,\mathrm{SE} = 2{,}67 - 1{,}96 \times 0{,}45 = 1{,}79$
- Valoarea 4,2 pentru Bitcoin corespunde unui prag la care Hill plot-ul nu este încă plat
  - la un prag comun, cele două cozi dau 2,71 și 3,36 (Anexă)

MFM_ch1_inference

Faptul 3: asimetria cîștig/pierdere în date





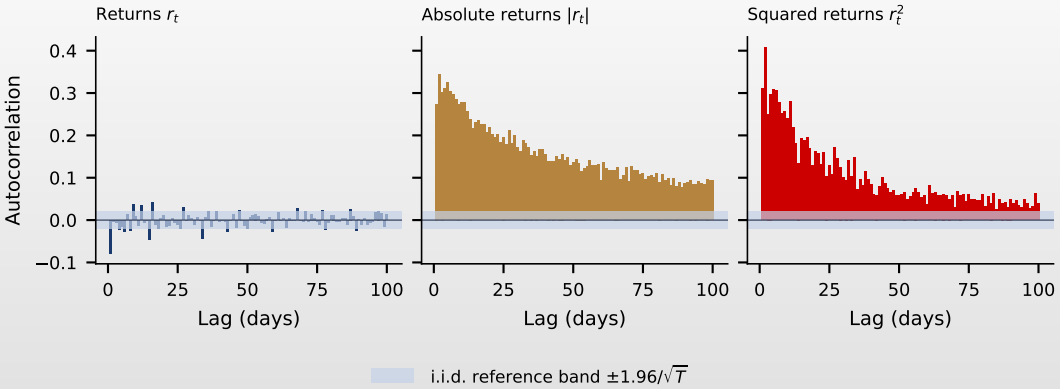
MFM_ch1_heavy_tails

Faptul 3: pierderile mari sînt mai frecvente decît cîștigurile mari

- Funcțiile de supraviețuire $P(X > x)$ ale pierderilor și cîștigurilor, pe scară log–log
  - $P(X > x)$: proporția zilelor în care X depășește x
  - $X = -r_t$ pentru pierderi, $X = r_t$ pentru cîștiguri
  - pierderile mari sînt mai frecvente decît cîștigurile de aceeași mărime
- **VaR** (Value-at-Risk) $1\% = -q_{0,01}$, pragul de pierdere zilnică depășit cu probabilitatea de 1%
- $q_{0,01}$: cuantila de 1% a randamentelor (Capitolul 7)
- VaR 1% depășește cuantila de 99% a randamentelor $q_{0,99}$ pe 4 din 5 piețe
  - de exemplu, pentru S&P 500: 3,15% față de 2,97%
- EUR/RON este excepția: deprecierile leului (creșterile cursului) sînt mai mari
  - $q_{0,99} = 0{,}94\%$ față de VaR $1\% = 0{,}76\%$
- Un model cu distribuție Normală și varianța corectă subestimează aceste cuantile
  - testele de stres bazate pe „evenimente de 3σ" sînt prea optimiste

MFM_ch1_heavy_tails

Faptele 1 și 6: randamente necorelate, dar dependente



MFM_ch1_volatility_clustering

Faptele 1 și 6: direcția nu se repetă, mărimea da

- **Faptul 1**: $\text{corr}(r_t, r_{t-k}) \approx 0$, unde k este lagul, în zile
  - S&P 500 1990–2026: autocorelația la lagul 1 este $-0{,}08$
  - banda de încredere sub ipoteza i.i.d.: $\pm 1{,}96/\sqrt{T}$
  - în afara ei, autocorelația este semnificativă la 5%
- **Faptul 6, volatility clustering**: $\text{corr}(|r_t|, |r_{t-k}|) > 0$ pentru multe laguri (lagul 1: 0,27)
  - variațiile mari sînt urmate de variații mari, indiferent de semn
- Independența presupune corelație nulă între **orice** funcții ale randamentelor
  - randamentele sînt necorelate, dar nu independente
- Modelul $r_t = \sigma_t \varepsilon_t$, cu σ_t determinat de randamentele trecute
  - σ_t: volatilitatea condiționată a zilei t
  - ε_t: șocuri i.i.d. cu media 0 și varianța 1
  - GARCH, ARCH generalizat (Capitolul 5)

MFM_ch1_volatility_clustering

ACF în prezența heteroscedasticității condiționate

- **ACF** (funcția de autocorelație): autocorelațiile de selecție $\hat{\rho}_k$, reprezentate în funcție de lagul k

$$\hat{\rho}_k = \frac{\sum_t x_t x_{t-k}}{\sum_t x_t^2}, \qquad x_t = r_t - \bar{r}$$

  - x_t: randamentul centrat
  - $\hat{\rho}_k \in [-1, 1]$
  - $\hat{\rho}_k > 0$: o zi peste medie tinde să fie urmată, după k zile, de o zi peste medie
- Pentru randamente necorelate, cu varianță condiționată variabilă: $\hat{\rho}_k \approx N(0, \tau_k)$ Romano & Thombs (1996)
  - τ_k: varianța lui $\hat{\rho}_k$, estimată prin $\hat{\tau}_k = \sum_t x_t^2 x_{t-k}^2 / (\sum_t x_t^2)^2$
  - i.i.d.: $T\tau_k = 1$, de unde banda clasică $\pm 1{,}96/\sqrt{T}$
  - volatility clustering: $T\tau_k > 1$
  - banda clasică este prea îngustă și declară prea des autocorelații semnificative

Testul portmanteau robust $\tilde{Q}(m)$

- Statistica t robustă: $\hat{\rho}_k / \sqrt{\hat{\tau}_k}$, comparată cu $\pm 1{,}96$
- Testul portmanteau robust Lobato, Nankervis & Savin (2001): ipoteza nulă $\rho_1 = \cdots = \rho_m = 0$

$$\tilde{Q}(m) = \sum_{k=1}^{m} \frac{\hat{\rho}_k^2}{\hat{\tau}_k}$$

  - suma pătratelor statisticilor t robuste pentru primele m laguri, deci $\tilde{Q}(m) \geq 0$
  - distribuția de referință χ^2_m
  - valorile mari resping ipoteza nulă
  - ipotezele testului: ▸ Anexă
- Diferența față de $Q(m)$ (Ljung–Box)
  - $Q(m)$ împarte, aproximativ, fiecare $\hat{\rho}_k^2$ la varianța i.i.d. $1/T$
  - $\tilde{Q}(m)$ împarte la varianța estimată $\hat{\tau}_k$

Cu erori standard robuste, rămîn semnificative doar S&P 500 și EUR/RON

Lagul 1	S&P 500	BET-TR	Bitcoin	EUR/RON	Aur
$\hat{\rho}_1$	−0,079	0,061	−0,022	0,170	−0,011
$T\hat{\tau}_1$	5,00	4,35	2,89	6,85	2,43
Statistica t, i.i.d. / robustă	−7,6 / −3,4	3,3 / 1,6	−1,5 / −0,9	12,4 / 4,7	−1,1 / −0,7

- S&P 500: $Q(10) = 91{,}6$, dar $\tilde{Q}(10) = 19{,}0$ (p = 0,041)
- Cu SE robuste, doar S&P 500 ($t = -3{,}4$) și EUR/RON ($t = 4{,}7$) păstrează o autocorelație de lag 1 semnificativă
  - dar este mică din punct de vedere economic

MFM_ch1_inference

Cozi groase din volatilitate aleatoare: mixturi de distribuții Normale

- Modelul: randamentul este un șoc Normal înmulțit cu o volatilitate aleatoare

$$r_t = \sigma_t \varepsilon_t, \qquad \varepsilon_t \sim N(0,1) \text{ independent de } \sigma_t$$

- Kurtosisul randamentelor este cel puțin 3

$$K = \frac{\mathbb{E}[r_t^4]}{\mathbb{E}[r_t^2]^2} = 3\,\frac{\mathbb{E}[\sigma_t^4]}{\mathbb{E}[\sigma_t^2]^2} \;\geq\; 3$$

  - egalitatea din mijloc: $\mathbb{E}[\varepsilon_t^4] = 3$ și $\mathbb{E}[\varepsilon_t^2] = 1$, iar σ_t și ε_t sînt independente
  - inegalitatea rezultă din inegalitatea lui Jensen ($\mathbb{E}[X^2] \geq \mathbb{E}[X]^2$) pentru $X = \sigma_t^2$
  - egalitate doar dacă σ_t este constantă
  - orice variație a volatilității creează exces de kurtosis

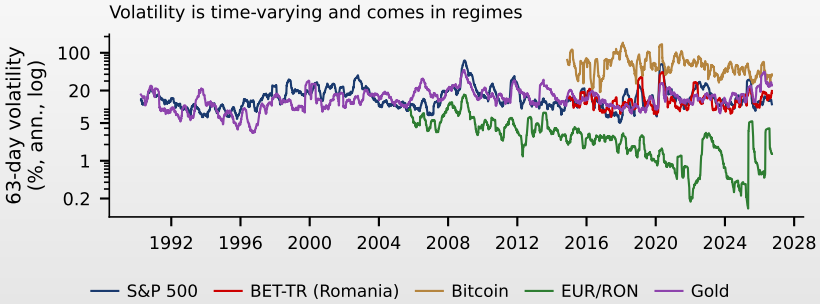
Exemplu numeric: kurtosis 8,33 din șocuri Normale

- Exemplu: $\sigma = 1\%$ în 90% din zile și 3% în 10% din zile

$$K = 3 \cdot \frac{0{,}9 \cdot 1 + 0{,}1 \cdot 81}{(0{,}9 + 0{,}1 \cdot 9)^2} = 3 \cdot \frac{9{,}0}{3{,}24} = 8{,}33$$

  - numărătorul: $\mathbb{E}[\sigma^4] = 0{,}9 \cdot 1^4 + 0{,}1 \cdot 3^4$, în unități de $(1\%)^4$
  - numitorul: $\mathbb{E}[\sigma^2]^2$, cu $\mathbb{E}[\sigma^2] = 0{,}9 \cdot 1^2 + 0{,}1 \cdot 3^2 = 1{,}8$
  - excesul de kurtosis este 5,33, deși randamentul fiecărei zile, condiționat de σ, are distribuție Normală
- Rezultatul leagă cozile groase (Faptul 2) de volatility clustering (Faptul 6)
  - o mixtură cu extrageri independente în fiecare zi are cozi groase, dar nu produce volatility clustering (Seminarul 1, A4 și A9)

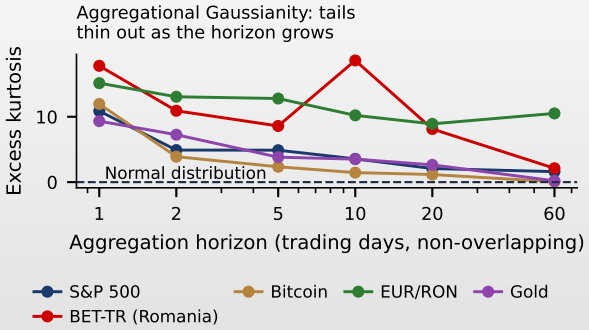
Faptul 5: intermitența în date



- Episoade de volatilitate ridicată separate de perioade calme: modelele cu volatilitate constantă nu pot reproduce acest tipar
- Volatilitatea pe fereastră mobilă de 63 de zile: $\sqrt{A}\times$ abaterea standard din fereastră, scară logaritmică
  - vîrfuri comune: 2008–2009, martie 2020
- Volatilitatea EUR/RON a scăzut puternic după 2012, sub regimul de managed float al BNR

MFM_ch1_volatility_clustering

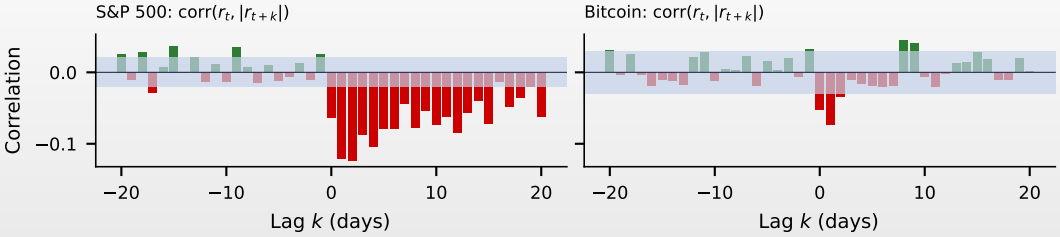
Faptul 4: gaussianitate prin agregare



- Randamentul pe h zile: $r_t(h) = r_t + \cdots + r_{t-h+1}$
  - calculat pe blocuri care nu se suprapun
  - conform CLT, distribuția sumelor se apropie de distribuția Normală
  - dar lent, deoarece randamentele zilnice sînt dependente
- Exces de kurtosis: S&P 500 10,9 $\to$ 1,6 la $h = 60$, Bitcoin 12,0 $\to$ 0,1
- La $h = 60$ rămîn doar 154 și 73 de randamente
  - SE a excesului de kurtosis (i.i.d., Normală): $\sqrt{24/n} = 0{,}39$ și $0{,}57$
  - n: numărul de randamente pe h zile
  - deci estimările sînt foarte imprecise
- $h = 60$ este un trimestru pentru S&P 500, dar două luni pentru Bitcoin

MFM_ch1_heavy_tails

Faptul 9: leverage effect



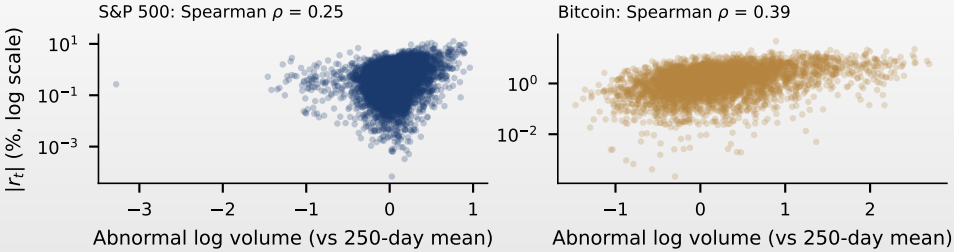
MFM_ch1_leverage_volume

Faptul 9: după scăderi, volatilitatea crește

- $L(k) = \text{corr}(r_t, |r_{t+k}|)$, $k > 0$: corelația dintre randamentul de azi și mărimea randamentului de peste k zile
  - $L(k) < 0$: după scăderi, randamentele devin mai mari în valoare absolută, adică volatilitatea crește
- S&P 500: $L(1) = -0{,}12$ și încă $-0{,}07$ la $k = 10$
  - niciun efect pentru $k < 0$
- BET-TR: un efect la fel de puternic, $-0{,}12$
- Celelalte active
  - Bitcoin: efect slab ($-0{,}07$)
  - aur: efect neglijabil ($-0{,}02$)
  - EUR/RON: efect inversat ($+0{,}10$)
- Explicații posibile
  - gradul de îndatorare al firmelor Christie (1982)
  - modelul volatilității cu efect întîrziat (retarded volatility) Bouchaud, Matacz & Potters (2001)
- Modele GARCH asimetrice: GJR-GARCH (Glosten–Jagannathan–Runkle) și EGARCH (GARCH exponențial) (Capitolul 5)

MFM_ch1_leverage_volume

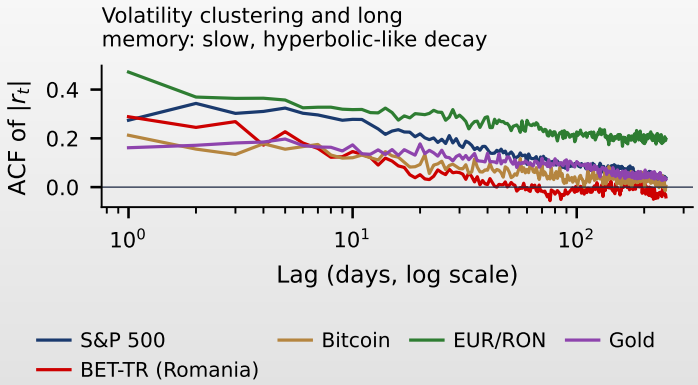
Faptul 10: volumul și volatilitatea evoluează împreună



- Volumul logaritmic anormal (ln V_t minus media mobilă pe 250 de zile) față de $|r_t|$
  - V_t: volumul tranzacționat în ziua t
  - corelația de rang Spearman, corelația dintre rangurile celor două serii, în $[-1, 1]$: 0,25 (S&P 500) și 0,39 (Bitcoin)
- Ipoteza mixturii de distribuții Clark (1973): fluxul de informații determină atît variațiile de preț, cît și volumul
  - sinteza dovezilor empirice: Karpoff (1987)
- Volumul Bitcoin este raportat de burse
  - include și **wash trading** (tranzacții fictive în care cumpărătorul și vînzătorul coincid) Cong, Li, Tang & Yang (2023)

MFM_ch1_leverage_volume

Faptul 8: scăderea lentă a ACF pentru $|r_t|$



MFM_ch1_volatility_clustering

Faptul 8: scădere exponențială sau hiperbolică?

- ρ_k: autocorelația lui $|r_t|$ la lagul k
- $c > 0$: o constantă
- **Memorie scurtă**: $\sum_k |\rho_k| < \infty$
  - de exemplu, o scădere exponențială $\rho_k \approx c\,\phi^k$, cu $0 < \phi < 1$ (GARCH(1,1), Capitolul 5)
- **Memorie lungă** Ding, Granger & Engle (1993)
  - scădere hiperbolică $\rho_k \approx c\,k^{2d-1}$, $0 < d < \frac{1}{2}$
  - d: parametrul de memorie
  - un d mai mare înseamnă o scădere mai lentă, iar $\sum_k \rho_k = \infty$
- S&P 500: 0,27 la lagul 1, 0,22 la lagul 20, încă 0,09 la lagul 100
  - BET-TR scade cel mai repede
- O scădere lentă a ACF empirice nu dovedește, în sine, memoria lungă
  - rupturile structurale (salturi ale nivelului volatilității) dau același tipar

MFM_ch1_volatility_clustering

Estimarea parametrului de memorie d

- Memoria lungă în domeniul frecvenței: densitatea spectrală crește nelimitat la frecvențe joase

$$f(\lambda) \approx G\lambda^{-2d} \quad \text{cînd } \lambda \to 0$$

  - $f(\lambda)$: densitatea spectrală, contribuția ciclurilor de frecvență λ la varianța seriei
  - λ mic: cicluri lungi
  - $G > 0$: o constantă
  - d: parametrul de memorie
  - estimatorii semiparametrici folosesc doar cele mai joase m frecvențe Fourier $\lambda_j = 2\pi j/T$, $j = 1, \ldots, m$

- Doi estimatori (formulele în Anexă)
  - Whittle local Robinson (1995): $\sqrt{m}(\hat{d} - d) \to N(0, \frac{1}{4})$, deci SE $= 1/(2\sqrt{m})$
  - regresia log-periodogramei Geweke & Porter-Hudak (1983): SE $= \pi/\sqrt{24m}$
  - aici $m = T^{0,65}$

$\hat{d} \approx 0{,}35$–$0{,}50$ pe toate cele cinci piețe

$\lvert r_t \rvert$, $m = T^{0{,}65}$	S&P 500	BET-TR	Bitcoin	EUR/RON	Aur
m	378	181	232	265	386
Whittle local $\hat{d}$ (SE)	0,48 (0,03)	0,37 (0,04)	0,35 (0,03)	0,39 (0,03)	0,40 (0,03)
Log-periodogramă $\hat{d}$ (SE)	0,50 (0,03)	0,41 (0,05)	0,35 (0,04)	0,38 (0,04)	0,42 (0,03)

- $\hat{d} \approx 0{,}35$–$0{,}50$ pe toate piețele
  - la cel puțin 8 SE distanță de $d = 0$ (memorie scurtă), cu ambii estimatori
- Estimația pentru S&P 500 este aproape de limita de staționaritate, $\frac{1}{2}$
  - pentru $d \geq \frac{1}{2}$ seria nu mai este staționară

MFM_ch1_inference

Memorie lungă sau rupturi structurale?

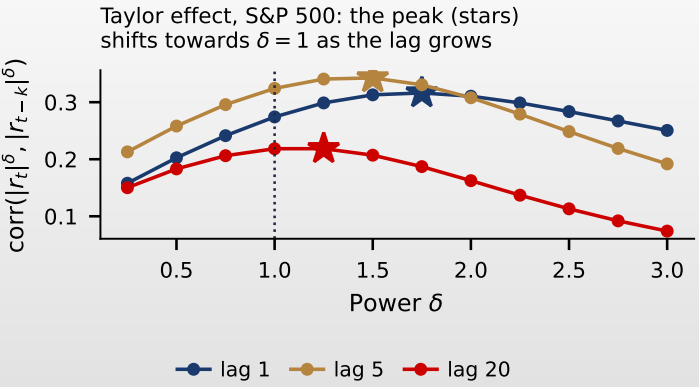
- Schimbări rare ale nivelului volatilității produc o ACF a lui $|r_t|$ care scade încet
  - și $\hat{d} > 0$ chiar în absența memoriei lungi Diebold & Inoue (2001), Mikosch & Stărică (2004)
- Verificare: localizăm o ruptură de variață cu testul sumelor cumulate ale pătratelor Inclán & Tiao (1994)
  - apoi reestimăm d (Whittle local) pe fiecare subeșantion

$\lvert r_t \rvert$	Data rupturii	Volatilitate înainte / după (%)	$\hat{d}$ înainte (SE)	$\hat{d}$ după (SE)
S&P 500	20 iul. 1998	12,6 / 19,3	0,28 (0,04)	0,51 (0,03)
BET-TR	17 dec. 2018	12,5 / 16,9	0,19 (0,05)	0,37 (0,04)
Bitcoin	19 iun. 2022	74,9 / 47,7	0,39 (0,04)	0,15 (0,05)
EUR/RON	27 iun. 2013	6,6 / 2,2	0,35 (0,04)	0,35 (0,04)
Aur	29 nov. 2005	13,2 / 18,3	0,30 (0,03)	0,37 (0,03)

- $\hat{d}$ rămîne cu cel puțin 3 SE peste 0 în fiecare subeșantion (cel mai slab caz: Bitcoin după 2022, $0{,}15/0{,}05 = 3$): o singură ruptură nu explică persistența
- S&P 500 după 1998: $\hat{d} = 0{,}51$, chiar la limita de staționaritate $\frac{1}{2}$; interpretați cu prudență
- $\hat{d}$ se schimbă (Bitcoin $0{,}39 \to 0{,}15$): rămîn posibile rupturi multiple sau un d variabil în timp; datele rupturilor au caracter descriptiv

MFM_ch1_inference

Efectul Taylor



MFM_ch1_volatility_clustering

Efectul Taylor: persistența este maximă sub pătrat

- **Efectul Taylor**, așa cum este formulat în literatură: randamentele absolute $|r_t|$ sînt mai puternic autocorelate decît pătratele r_t^2
  - în eșantioanele originale, $\text{corr}(|r_t|^\delta, |r_{t-k}|^\delta)$ este maximă pentru o putere δ apropiată de 1, nu pentru $\delta = 2$
  - efect documentat de Taylor (1986) și denumit astfel de Granger & Ding (1995)
- Graficul de pe slide-ul anterior arată această autocorelație în funcție de $\delta > 0$; $\delta = 1$: randamente absolute (linia punctată), $\delta = 2$: randamente la pătrat
- Eșantionul nostru S&P 500: maximul la $\delta = 1{,}75$ (lagul 1), 1,5 (lagul 5) și 1,25 (lagul 20)
  - maximul este sub 2 la fiecare lag și se apropie de 1 cînd lagul crește
  - la lagul 1 maximul este mai aproape de 2 decît de 1: aici dovezile pentru „$\delta \approx 1$" sînt mixte la laguri scurte
  - citiți curba fiecărui lag la $\delta = 1$ și la $\delta = 2$ pentru a vedea cît de mare este diferența
- Efectul motivează
  - modelele power-GARCH, care modelează σ_t^δ cu δ estimat (Capitolul 5)
  - măsurile de volatilitate bazate pe valori absolute

MFM_ch1_volatility_clustering

Ce inferență rămîne validă cînd momentele lipsesc

Statistica	Condiție	Pentru Hill $\hat{\alpha} \approx 2{,}5$–$3{,}5$
Media, varianța lui r_t	$\alpha > 2$	finite, convergență lentă
ACF a lui $\lvert r_t \rvert$, benzi ACF robuste, $\tilde{Q}$	$\alpha > 4$ pentru limite Normale	discutabilă
Kurtosis, ACF a lui r_t^2, ARCH-LM, Q pe r_t^2	$\alpha > 4$ pentru existență (și pentru χ^2 al ARCH-LM sub i.i.d.), $\alpha > 8$ pentru limite Normale sub dependență de tip GARCH	fără inferență standard
Asimetrie	$\alpha > 6$ pentru o limită Normală	fără inferență standard
Cuantile, frecvența depășirilor, Hill $\hat{\alpha}$	nu cere momente	valide, cu SE robuste la dependență

- Cînd momentul de ordinul patru este infinit, ACF de selecție a lui r_t^2 converge lent
  - iar distribuția ei limită nu este Normală Davis & Mikosch (1998)
  - banda $\pm 1{,}96/\sqrt{T}$ și p-value-urile pentru Q pe r_t^2 și ARCH-LM nu sînt de încredere
- Concluzia „există volatility clustering" este robustă
  - valorile numerice exacte nu sînt robuste
  - o explicație posibilă a efectului Taylor: $\lvert r_t \rvert$ cere mai puține momente finite decît r_t^2

Faptele 7 și 11: cozi condiționate și scale de timp

Faptul 7: cozi groase condiționate

- Estimăm un model de volatilitate, de exemplu GARCH (Capitolul 5)
  - și standardizăm: $\hat{z}_t = r_t/\hat{\sigma}_t$, cu $\hat{\sigma}_t$ volatilitatea estimată de model pentru ziua t
- Kurtosisul lui $\hat{z}_t$ este mai mic decît al lui r_t, dar rămîne peste 3
- Modelele necesită inovații cu cozi groase (distribuția Student-t, eventual asimetrică)

Faptul 11: asimetria scalelor de timp

- Volatilitatea săptămînală prognozează volatilitatea zilnică mai bine decît reciproc
- Investitorii cu orizonturi diferite reacționează la frecvențe diferite
- Modelul autoregresiv heterogen al volatilității realizate (**HAR-RV**, Capitolul 9)
  - volatilitatea realizată este suma pătratelor randamentelor intraday

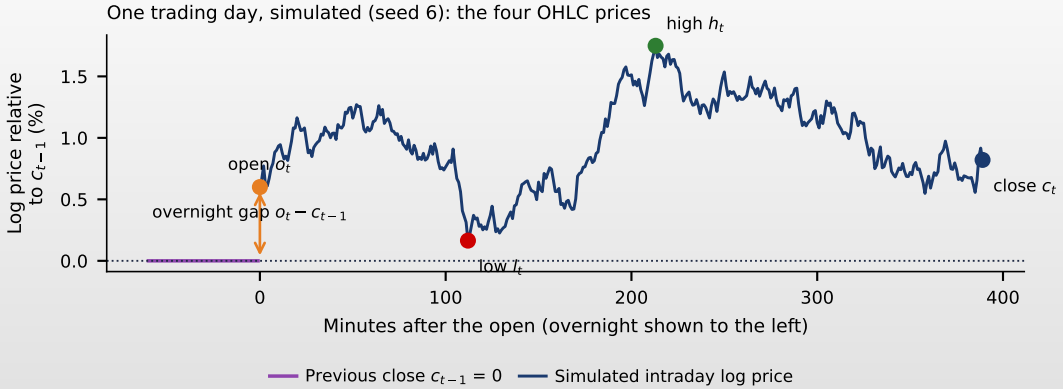
- Ambele fapte sînt documentate în Cont (2001)
- Randamentele standardizate cu volatilitatea realizată din date intraday sînt apropiate de distribuția Normală
  - Andersen, Bollerslev, Diebold & Ebens (2001) (Capitolul 9)

Diferențele dintre cele cinci piețe

Piață	Trăsătură instituțională	Diferențe	Explicație posibilă
Bitcoin	tranzacționat 24/7; $A = 365$	volatilitate 66,6% față de 18,0% (S&P 500); cea mai slabă zi $-46{,}5\%$; leverage effect slab ($-0{,}07$); ACF a lui $\lvert r_t \rvert$ la lagul 100: 0,02 față de 0,09	fără îndatorare corporativă; volatilitatea crește după variații mari de orice semn
EUR/RON	curs de referință zilnic BNR, managed float	volatilitate 4,4%, dar exces de kurtosis 15,1; $\hat{\rho}_1 = +0{,}17$; cele mai mari variații în octombrie 2008 ($+2{,}9\%$, $-2{,}5\%$)	ajustări ale cursului distribuite pe mai multe zile
BET-TR	randament total, piață de frontieră/emergentă	asimetrie $-1{,}40$; cea mai slabă zi $-11{,}9\%$ pe 19 dec. 2018 (taxa pe activele bancare anunțată pe 18 dec., Ordonanța de urgență 114/2018); $\hat{\rho}_1 = +0{,}06$	șocuri de politică economică; **tranzacționarea nesincronă** a componentelor Campbell, Lo & MacKinlay (1997), cap. 3

- Explicațiile sînt ipoteze, nu cauze identificate
- Volatilitatea mică nu înseamnă tail risk mic
- Cozile groase și volatility clustering apar pe toate cele cinci piețe
  - autocorelația și asimetria depind de cadrul instituțional

Deschiderea, maximul, minimul și închiderea (OHLC) unei zile



MFM_ch1_seminar_tests

Ce adaugă maximul și minimul zilei

- **OHLC**: patru prețuri ale zilei t
  - O_t: deschiderea (Open)
  - H_t: maximul (High)
  - L_t: minimul (Low)
  - C_t: închiderea (Close)
- Graficul: o zi simulată; axa verticală este logaritmul prețului față de închiderea precedentă c_{t-1}, în %
  - litera mică este logaritmul prețului (slide-ul următor); saltul de peste noapte $o_t - c_{t-1}$ apare în stînga deschiderii
- Estimatorii bazați pe **range** folosesc întreaga traiectorie a zilei
  - range-ul H_t/L_t este mare în zilele volatile
  - chiar dacă închiderea este egală cu deschiderea

MFM_ch1_seminar_tests

Range-ul logaritmic și eficiența unui estimator de volatilitate

- Logaritmii celor patru prețuri

$$o_t = \ln O_t, \qquad h_t = \ln H_t, \qquad l_t = \ln L_t, \qquad c_t = \ln C_t$$

  - litera mică este logaritmul prețului cu aceeași inițială
- Range-ul logaritmic al zilei t

$$h_t - l_t = \ln(H_t/L_t) \geq 0$$

  - aproximativ variația procentuală dintre maximul și minimul zilei
- Trei randamente logaritmice ale zilei t
  - close-to-close: $c_t - c_{t-1}$
  - peste noapte: $o_t - c_{t-1}$
  - în timpul zilei: $c_t - o_t$
- **Estimatorul close-to-close**: abaterea standard a randamentelor $c_t - c_{t-1}$
  - folosește o singură observație pe zi
- **Eficiența** unui estimator X: $\mathrm{Var}(\hat{\sigma}^2_{CC})/\mathrm{Var}(\hat{\sigma}^2_X)$
  - o eficiență de 5 înseamnă aceeași precizie cu de 5 ori mai puține zile

Estimatorul Parkinson: varianța din amplitudinea zilei

- **Parkinson**, Parkinson (1980): estimează varianța zilnică doar din amplitudinea zilnică

$$\hat{\sigma}_P^2 = \frac{1}{4 \ln 2} \frac{1}{n} \sum_{t=1}^{n} (h_t - l_t)^2$$

  - n: numărul de zile
  - $h_t - l_t$: amplitudinea logaritmică a zilei t
  - pentru o mișcare browniană cu varianța zilnică σ^2, $\mathbb{E}[(h_t - l_t)^2] = 4 \ln 2 \, \sigma^2$
  - împărțirea la $4 \ln 2$ face estimatorul nedeplasat
  - $\hat{\sigma}_P^2$ este o varianță zilnică
  - volatilitatea anuală este $\sqrt{A \, \hat{\sigma}_P^2}$

- Ipoteza: o mișcare browniană fără drift și fără salturi peste noapte
  - mișcarea browniană: mersul aleator în timp continuu (Capitolul 11)
  - eficiența față de close-to-close: circa 5 (Seminarul 1, A8)
  - adică aceeași precizie cu de 5 ori mai puține zile

Estimatorul Garman–Klass: amplitudinea plus mișcarea de la deschidere la închidere

- **Garman–Klass**, Garman & Klass (1980): combină amplitudinea cu variația de la deschidere la închidere

$$\hat{\sigma}^2_{GK} = \frac{1}{n}\sum_{t=1}^{n}\left[\tfrac{1}{2}(h_t - l_t)^2 - (2\ln 2 - 1)(c_t - o_t)^2\right]$$

  - $c_t - o_t$: randamentul logaritmic de la deschidere la închidere
  - ponderile $\frac{1}{2}$ și $2\ln 2 - 1 \approx 0{,}386$ provin din estimatorul cu variață minimă derivat de Garman și Klass
  - aceleași ipoteze ca la Parkinson: fără drift, fără salturi peste noapte
- Eficiența față de close-to-close: 7–8

Estimatorul Rogers–Satchell: corect și în prezența unui drift

- **Rogers–Satchell**, Rogers & Satchell (1991): nedeplasat în prezența unui **drift** nenul (tendința așteptată a logaritmului prețului)

$$\hat{\sigma}^2_{RS} = \frac{1}{n}\sum_{t=1}^{n}\left[(h_t - o_t)(h_t - c_t) + (l_t - o_t)(l_t - c_t)\right]$$

  - termenii măsoară cît de departe au ajuns maximul și minimul față de deschidere și de închidere
  - ambele produse sînt ≥ 0, deoarece $l_t \leq o_t, c_t \leq h_t$
  - pentru o mișcare browniană cu drift, media lor este exact varianța zilnică
  - nu include saltul de peste noapte

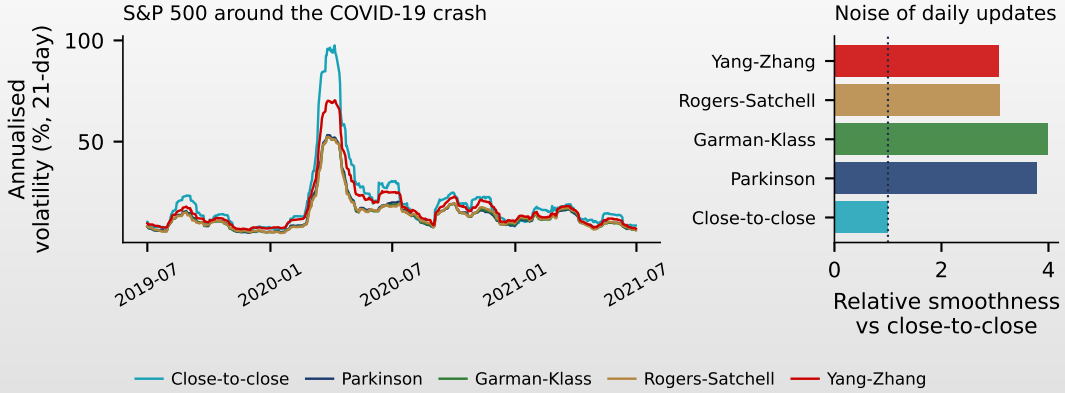
Estimatorul Yang–Zhang: include saltul de peste noapte

- **Yang–Zhang**, Yang & Zhang (2000): adaugă saltul de peste noapte (de la închidere la deschidere)

$$\hat{\sigma}^2_{YZ} = \hat{\sigma}^2_{\text{noapte}} + k\,\hat{\sigma}^2_{\text{desch-închid}} + (1-k)\,\hat{\sigma}^2_{RS}, \quad k = \frac{0{,}34}{1{,}34 + \frac{n+1}{n-1}}$$

  - $\hat{\sigma}^2_{\text{noapte}}$: varianța de selecție a lui $o_t - c_{t-1}$, randamentul de peste noapte
  - $\hat{\sigma}^2_{\text{desch-închid}}$: varianța de selecție a lui $c_t - o_t$
  - k: ponderea, aleasă astfel încît combinația să aibă varianță minimă (alt k decît cel din estimatorul Hill)
  - pentru n mare, $k \approx 0{,}145$
  - combinația cu varianță minimă dintre estimatorii independenți de drift și robuști la salturile de la deschidere
- Estimatorii bazați pe range fac legătura cu volatilitatea realizată din date intraday (Capitolul 9)

Estimatorii de volatilitate aplicați pe S&P 500



MFM_ch1_vol_estimators

Fără salturile de peste noapte, estimatorii din range dau valori mai mici

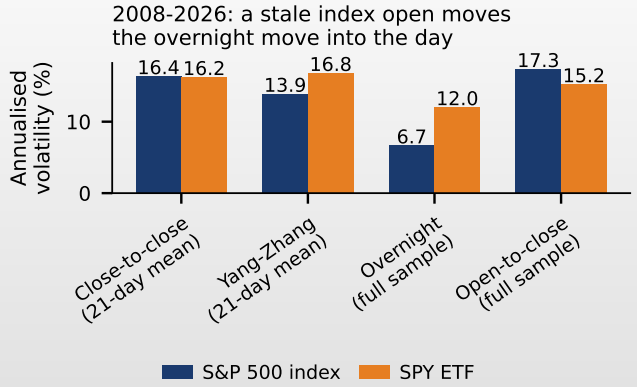
- Volatilitatea anualizată medie pe ferestre de 21 de zile, 2008–2026
  - close-to-close 16,4%, Yang–Zhang 13,9%, Parkinson 13,0%, Garman–Klass 12,4%, Rogers–Satchell 12,3%
- Estimatorii bazați doar pe amplitudine dau valori mai mici, deoarece nu surprind salturile de peste noapte
- Panoul din dreapta, „relative smoothness" a estimatorului X

$$\left[\frac{\text{abaterea std. a variațiilor zilnice, estimarea close-to-close}}{\text{abaterea std. a variațiilor zilnice, estimarea } X}\right]^2$$

  - ambele estimări sînt calculate pe ferestre de 21 de zile
  - egală cu 1 pentru close-to-close; valori mai mari înseamnă că estimarea sare mai puțin de la o zi la alta
- Seriile estimate din range sînt de 3–4 ori mai netede după această măsură
  - aceasta este o proprietate a estimărilor, nu o dovadă de eficiență: măsura nu le compară cu σ adevărat

MFM_ch1_vol_estimators

Stale open: indicele S&P 500 față de SPY, un fond tranzacționat la bursă (ETF)



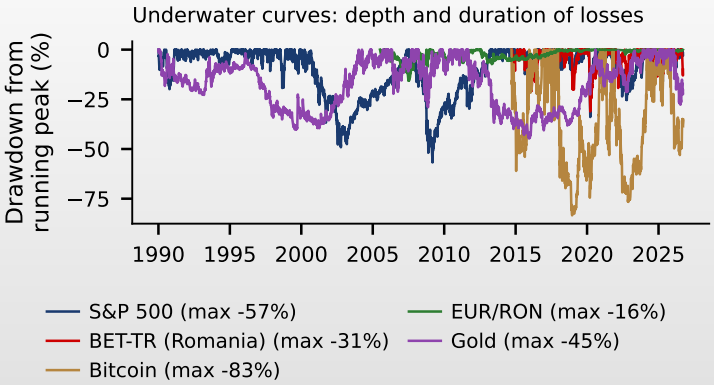
MFM_ch1_seminar_tests

Stale open: de ce deschiderea indicelui rămîne în urmă

- **Stale open**: deschiderea indicelui este calculată din ultimele prețuri ale componentelor
  - la 9:30 multe acțiuni nu s-au tranzacționat încă în ziua respectivă
  - pentru acestea se folosește prețul de închidere anterior
- SPY, ETF-ul care replică S&P 500
  - are un preț de deschidere rezultat din tranzacții
- Ponderea zilelor cu deschiderea egală cu închiderea precedentă
  - circa 96% în 1996–2005
  - 3,5% în 2008–2026 (pînă la 26% în 2012–2013)
- Un stale open transferă o parte din variația de peste noapte în intervalul de tranzacționare
  - volatilitatea de peste noapte a indicelui: 6,7%
  - pentru SPY, a cărui deschidere este un preț tranzacționat: 12,0%
- Estimatorul Yang–Zhang coboară sub close-to-close doar în cazul indicelui
  - pentru estimatorii care folosesc deschiderea, folosiți un instrument tranzacționat (Seminarul 1, B15 reface această comparație; valorile de aici sînt verificarea voastră)

MFM_ch1_seminar_tests

Drawdown-uri pe piețe



MFM_ch1_risk_measures

Drawdown-ul maxim: cît de adînc se poate cădea de la un vîrf

- Drawdown $DD_t = P_t / \max_{s \le t} P_s - 1$: pierderea față de vîrful atins pînă în ziua t (Capitolul 0)
  - $\max_{s \le t} P_s$: cel mai mare preț pînă în ziua t
  - $DD_t \in [-1, 0]$, cu 0 la un vîrf nou
  - drawdown-ul maxim $MDD = \min_t DD_t$: cea mai adîncă scădere de la un vîrf
- MDD pe cele cinci piețe
  - Bitcoin -83%, S&P 500 -57%, aur -45%
  - BET-TR -31% (martie 2020), EUR/RON -16%
- S&P 500: 9 octombrie 2007 (1 565,15) – 9 martie 2009 (676,53): $-56{,}8\%$
  - **recuperarea**: revenirea prețului la vîrful anterior
  - după o scădere x cere o creștere de $1/(1-x) - 1$
  - aici $1/(1 - 0{,}568) - 1 = +131\%$
- MDD crește odată cu lungimea eșantionului
  - comparați doar orizonturi egale (▸ Anexă)

MFM_ch1_risk_measures

Durata recuperării după drawdown-ul maxim

- **Durata recuperării**: timpul de la vîrf pînă cînd prețul atinge din nou acest nivel (recuperarea, definită pe slide-ul anterior)

	MDD	Vîrf	Minim	Vîrf recuperat
S&P 500	−57%	oct. 2007	mar. 2009	mar. 2013 (5,5 ani)
BET-TR	−31%	ian. 2020	mar. 2020	dec. 2020 (0,9 ani)
Bitcoin	−83%	dec. 2017	dec. 2018	nov. 2020 (3,0 ani)
EUR/RON	−16%	dec. 2005	iul. 2007	ian. 2008 (2,0 ani)
Aur	−45%	sept. 2011	dec. 2015	iul. 2020 (8,9 ani)

- Adîncimea și durata sînt dimensiuni distincte ale riscului
  - drawdown-ul aurului a fost mai puțin adînc decît al lui Bitcoin, dar a durat de trei ori mai mult
- Recuperări rapide în formă de V (BET-TR 2020)
  - față de perioade lungi underwater, sub vîrful anterior (aur 2011–2020)
- Pentru EUR/RON un „drawdown" este o scădere a euro față de leu

MFM_ch1_risk_measures

Raportul Sharpe: randament în exces pe unitatea de volatilitate

- **Raportul Sharpe** Sharpe (1966), Sharpe (1994)
  - randamentul în exces obținut pe unitatea de volatilitate

$$SR = \frac{\mu_{\text{an}} - r_f}{\sigma_{\text{an}}}$$

  - r_f: rata dobînzii fără risc
  - aici se ia $r_f = 0$, pentru comparabilitate
  - $\mu_{\text{an}} = A\bar{R}$: media anuală a randamentelor **simple**
  - $\bar{R}$: media randamentelor simple zilnice
  - σ_{an}: volatilitatea anuală a randamentelor simple
  - un SR mai mare înseamnă mai mult randament pentru același risc
- S&P 500 1990–2026: $\mu_{\text{an}} = 9{,}95\%$, $\sigma_{\text{an}} = 17{,}97\%$, $SR = 0{,}55$
  - μ_{an} = randamentul logaritmic mediu 8,33% plus $\approx \sigma^2/2 = 1{,}62$ pp
  - nu este media logaritmică $A\bar{r}$ de la slide-ul despre anualizare: cu 8,33% s-ar obține $8{,}33/17{,}97 = 0{,}46$

Raportul Sortino: la numitor doar pierderile

- **Raportul Sortino** Sortino & van der Meer (1991)
  - același numărător ca raportul Sharpe
  - la numitor: doar volatilitatea pierderilor

$$SoR = \frac{\mu_{\text{an}} - r_f}{\sigma^-_{\text{an}}}, \qquad \sigma^- = \sqrt{\frac{1}{T}\sum_{t=1}^{T} \min(R_t, 0)^2}$$

  - σ^-: downside deviation zilnică (în seminar: semiabaterea inferioară $\hat{\sigma}_D$)
  - $\min(R_t, 0)$ păstrează doar randamentele negative
  - media se calculează pe toate cele T zile
  - zilele cu randament pozitiv contribuie cu 0
  - $\sigma^-_{\text{an}} = \sqrt{A}\,\sigma^-$: varianta anuală
- S&P 500: $\sigma^-_{\text{an}} = 12{,}68\%$, $SoR = 0{,}78$

Raportul Calmar: creștere pe unitatea de drawdown maxim

- **Raportul Calmar**
  - creșterea anuală obținută pe unitatea de drawdown maxim

$$\text{Calmar} = \frac{\text{CAGR}}{|MDD|}$$

  - CAGR: rata anuală compusă de creștere
  - MDD: drawdown-ul maxim din eșantion
- S&P 500: $8{,}69\%/56{,}78\% = 0{,}15$
  - valoarea este determinată de un singur episod

Rapoarte Sharpe cu erori standard

- Metoda delta, sub ipoteza randamentelor i.i.d. din distribuția Normală Lo (2002)
  - SR_d: raportul Sharpe zilnic
  - $\widehat{SR}_d$: estimarea lui
  - $\text{Var}(\widehat{SR}_d) \approx (1 + SR_d^2/2)/T$
  - anualizat, $SR_{\text{an}} = \sqrt{A}\, SR_d$: $\text{SE}(\widehat{SR}_{\text{an}}) \approx \sqrt{A(1 + SR_d^2/2)/T} \approx 1/\sqrt{Y}$, cu $Y = T/A$ ani
  - precizia depinde de durata eșantionului, nu de frecvența observațiilor

	S&P 500	BET-TR	Bitcoin	EUR/RON	Aur
Ani Y	36,7	12,0	12,0	21,2	36,7
Raport Sharpe (SE, Normală)	0,55 (0,17)	1,34 (0,29)	0,98 (0,29)	0,43 (0,22)	0,48 (0,17)

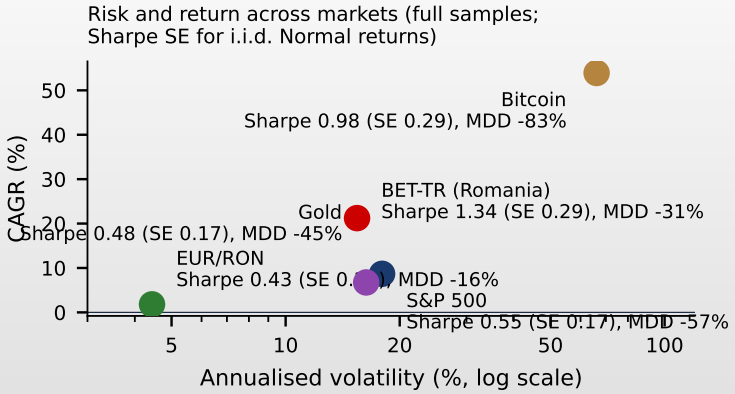
MFM_ch1_risk_measures

BET-TR față de S&P 500: diferența rapoartelor Sharpe nu este semnificativă la 5%

- În prezența volatility clustering: teste HAC sau bootstrap studentizat pe blocuri Ledoit & Wolf (2008)
  - și ele cer momente de ordinul patru finite, pe care estimările Hill le pun la îndoială
- BET-TR față de S&P 500, zile comune 2014–2026
  - diferența dintre rapoartele Sharpe: 0,61, $z = 1{,}75$ ($p = 0{,}08$)
  - z: diferența împărțită la eroarea ei standard, comparată cu $N(0,1)$
  - CI de 95% prin bootstrap pe blocuri: $[-0{,}01;\ 1{,}21]$ (Seminarul 1, B14 reface acest test; valorile de aici sînt verificarea voastră)
- Raportul Calmar nu are o teorie de eșantionare utilizabilă
  - MDD-ul de la numitor crește cu lungimea eșantionului

MFM_ch1_risk_measures

Risc și randament pe piețe



MFM_ch1_risk_measures

De ce graficul risc–randament nu este un clasament

- Etichetele: raportul Sharpe și, în paranteză, eroarea lui standard (SE)
  - SE: formula de la rapoartele Sharpe cu erori standard, pentru randamente simple i.i.d. cu distribuția Normală
  - tabelul complet în ▸ Anexă
- Perioadele diferă, deci graficul nu este un clasament
- S&P 500 este fără dividende
- BET-TR este cu dividende și în lei
  - dobînzile pe termen scurt în lei au fost mult peste cele în USD
  - cu $r_f = 0$, raportul Sharpe al BET-TR este supraestimat
- Cozi groase și asimetrie negativă
  - raportul Sharpe supraevaluează performanța
  - raportați-l împreună cu drawdown-urile
  - și cu măsurile de tail risk: VaR 1% și tail index-ul $\hat{\alpha}$

MFM_ch1_risk_measures

Studiu de caz (1/11): cît din volatilitate explică doar randamentele trecute?

- Lucrarea: Guyon & Lekeufack (2023), *Quantitative Finance*
  - lucrarea pornește de la Bollerslev, Hood, Huss & Pedersen (2018)
- Întrebarea de cercetare
  - ce proporție din volatilitatea unui indice bursier este explicată doar de randamentele lui zilnice trecute?
  - ce formă funcțională are această dependență?
- Trei variabile dependente, modelate separat (Secțiunile 3.4–3.5 din lucrare)
  - VIX (indicele de volatilitate al bursei Cboe): volatilitatea implicită a S&P 500 pe următoarele 30 de zile, calculată din prețurile opțiunilor
  - **volatilitatea implicită**: volatilitatea pentru care un model de evaluare a opțiunilor reproduce prețurile observate ale opțiunilor, adică volatilitatea anticipată de piață (Capitolul 12)
  - VIX9D: aceeași măsură, pe un orizont de 9 zile
  - volatilitatea realizată a zilei următoare, calculată din randamente pe 5 minute

Studiu de caz (2/11): un singur model pentru volatility clustering, memorie lungă și leverage effect

- Cerința: un singur model trebuie să reproducă simultan
  - volatility clustering (Faptul 6)
  - scăderea lentă a autocorelației lui $|r_t|$ (Faptul 8)
  - leverage effect (Faptul 9)
- Relevanța: dacă volatilitatea este în mare parte o funcție de traiectoria prețului, ea este în mare parte endogenă
  - un model de **volatilitate dependentă de traiectorie (PDV)** necesită doar o componentă aleatoare suplimentară redusă
  - spre deosebire de modelele cu volatilitate stochastică (Capitolele 11–12)
- Date: închiderile zilnice ale indicilor S&P 500 (SUA), Euro Stoxx 50 (zona euro), FTSE 100 (Regatul Unit), DAX (Germania) și Nikkei 225 (Japonia)
  - eșantionul de antrenare: 1 ian. 2000 – 31 dec. 2018
  - eșantionul de test: 1 ian. 2019 – 15 mai 2022

Studiu de caz (3/11): volatilitatea ca funcție de trend și de volatilitatea recentă

- Ecuația (3.7) din lucrare: volatilitatea de azi este o funcție liniară de două rezumate ale randamentelor trecute

$$\sigma_t = \beta_0 + \beta_1 R_{1,t} + \beta_2 \Sigma_t$$

- Notațiile
  - σ_t: variabila dependentă, de exemplu VIX la închiderea zilei t
  - S_{t_i}: nivelul indicelui la închiderea zilei t_i
  - $t_i \leq t$ parcurge zilele de pînă la t, inclusiv
  - $r_{t_i} = S_{t_i}/S_{t_{i-1}} - 1$: randamentul **simplu** al zilei t_i (notația lucrării; în restul capitolului r_t este randamentul logaritmic)
  - $R_{1,t}$: componenta de trend, construită din randamentele trecute
  - Σ_t: componenta de volatilitate, construită din pătratele randamentelor trecute
  - $\beta_0, \beta_1, \beta_2$: coeficienți estimați din date

Studiu de caz (4/11): trendul recent și volatilitatea istorică ponderată

- Componenta de trend: o sumă ponderată a randamentelor trecute

$$R_{1,t} = \sum_{t_i \le t} K_1(t - t_i)\, r_{t_i}$$

  - $t - t_i$: vechimea zilei t_i, măsurată în ani, ca în lucrare (o zi $= 1/252$ ani)
  - $K_1(t - t_i)$: ponderea acelei zile
  - $R_{1,t} < 0$ după o perioadă de scăderi, $R_{1,t} > 0$ după o perioadă de creșteri
- Componenta de volatilitate: rădăcina pătrată a unei sume ponderate a randamentelor la pătrat

$$\Sigma_t = \Big(\sum_{t_i \le t} K_2(t - t_i)\, r_{t_i}^2 \Big)^{1/2}$$

  - $K_j \Delta t$ însumează unu: $R_{1,t}$ este 252 ori media ponderată, iar Σ_t este $\sqrt{252}$ ori rădăcina mediei pătratice ponderate
- Interpretarea coeficienților
  - $\beta_1 < 0$: după scăderi ($R_{1,t} < 0$) volatilitatea crește, adică leverage effect
  - $\beta_2 > 0$: o volatilitate recentă mare ridică volatilitatea de azi, adică volatility clustering, ca în GARCH
  - $\beta_2 < 1$ este un rezultat empiric, nu o restricție: estimările sînt 0,82 (lucrarea) și 0,868 (replicarea noastră), deci VIX variază mai puțin decît unu-la-unu cu Σ_t, iar $\beta_0 > 0$ asigură o parte din nivel

Studiu de caz (5/11): cît contează o zi veche?

- Un **nucleu** $K(\tau)$ dă ponderea unei zile vechi de τ, cu $\tau = i\Delta t$ pentru o zi veche de i zile și $\Delta t = 1/252$
- Ponderile zilnice $K(i\Delta t)\Delta t$ sînt pozitive și însumează 1 (axa verticală a graficului nucleelor)
- Lucrarea folosește o **lege de putere decalată în timp (TSPL)**, ec. (3.9)

$$K(\tau) = \frac{(\tau + \delta)^{-\alpha}}{Z_{\alpha,\delta}}, \qquad \alpha > 1,\ \delta > 0,\ \tau = i\Delta t,\ i = 0, 1, \ldots, 999$$

  - $Z_{\alpha,\delta}$: constanta de normalizare pe ultimele 1 000 de zile
  - α: viteza de scădere a ponderilor; un α mic înseamnă memorie lungă
  - δ: decalajul, în ani; un δ mic concentrează ponderea pe ultimele cîteva zile ($\delta = 0{,}05$ ani $\approx 12{,}6$ zile)
- Forma rezultată: pondere mare pe ultimele cîteva zile (memorie scurtă) și o coadă de tip lege de putere (memorie lungă, Faptul 8)
- K_1, K_2 au parametrii (α_1, δ_1), (α_2, δ_2); aici α, δ și K nu sînt tail index-ul, puterea din efectul Taylor sau kurtosisul

Studiu de caz (6/11): șapte parametri, evaluați și în afara eșantionului

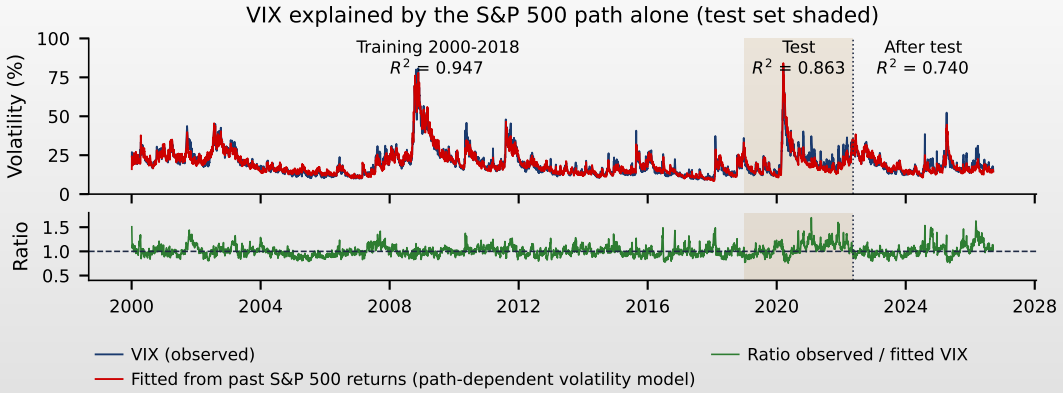
- Șapte parametri: $\beta_0, \beta_1, \beta_2, \alpha_1, \delta_1, \alpha_2, \delta_2$
  - estimați prin cele mai mici pătrate neliniare pe eșantionul de antrenare: se minimizează $\sum_t (\sigma_t - \hat{\sigma}_t)^2$
  - $\hat{\sigma}_t$: valoarea dată de model pentru ziua t
  - detaliile estimării: Anexă
- Criteriile de evaluare, calculate separat pe eșantionul de antrenare și pe cel de test
  - RMSE (rădăcina erorii pătratice medii) $= \sqrt{\frac{1}{T}\sum_t (\sigma_t - \hat{\sigma}_t)^2}$: eroarea tipică, în unități de volatilitate (zecimale: 0,01 = 1 punct VIX)
  - $R^2 = 1 - \sum_t (\sigma_t - \hat{\sigma}_t)^2 / \sum_t (\sigma_t - \bar{\sigma})^2$: proporția din variația lui σ_t explicată de model
  - $\bar{\sigma}$: media lui σ_t
  - $R^2 = 1$ înseamnă potrivire perfectă, $R^2 = 0$ nu este mai bun decît media

Studiu de caz (7/11): randamentele trecute explică 80–92% din volatilitatea implicită

Indice	Volatilitate implicită (lucrarea, Tabelul 2) R^2 antrenare	R^2 test	Volatilitate realizată (lucrarea, Tabelul 4) R^2 antrenare	R^2 test
S&P 500 (VIX)	0,946	0,855	0,738	0,654
S&P 500 (VIX), replicarea noastră	0,947	0,863	–	–
S&P 500 (VIX pe 9 zile)	0,876	0,914	–	–
Euro Stoxx 50	0,929	0,913	0,672	0,682
Nikkei 225	0,890	0,800	0,563	0,504

- Numai randamentele trecute ale indicelui explică 80–92% din varianța volatilității implicite în afara eșantionului
  - FTSE 100 și DAX în Anexă
- Pe datele noastre (S&P 500 și VIX): RMSE 0,020 (2 puncte VIX) la antrenare și 0,034 la test
  - față de 0,020 și 0,035 în Tabelul 2 din lucrare
- Scorurile pentru volatilitatea realizată sînt mai mici
  - volatilitatea realizată pe 5 minute este o variabilă explicată zgomotoasă (Remarca 3 din lucrare)
  - în acest curs nu folosim date pe 5 minute, deci Tabelul 4 din lucrare nu este replicat

Studiu de caz (8/11): VIX observat și VIX estimat din randamentele S&P 500



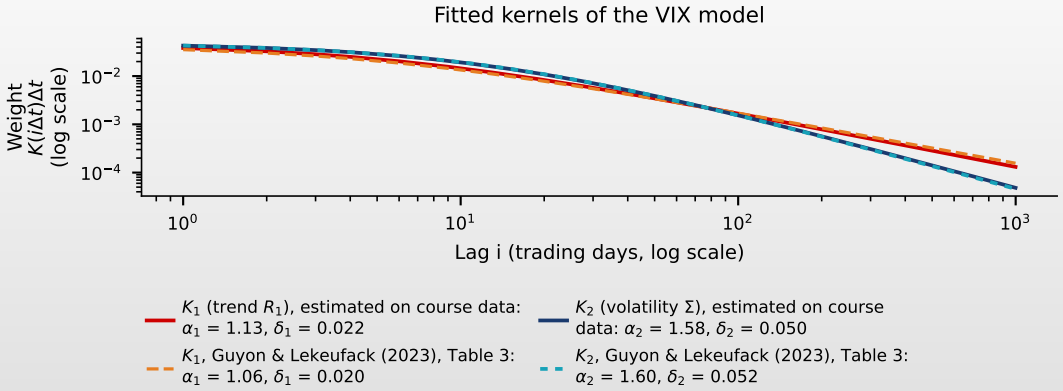
MFM_ch1_path_dependent_vol

Studiu de caz (9/11): după 2022, eroare mai mică, dar și R^2 mai mic

- Model estimat pe 3 ian. 2000 – 31 dec. 2018 (4 779 de zile)
  - pornind de la valorile din Tabelul 3 din lucrare
  - apoi parametrii sînt menținuți fixați
- Zona umbrită: eșantionul de test; graficul arată volatilitatea în %, textul în zecimale (0,026 = 2,6 puncte)
- După eșantionul de test, 16 mai 2022 – 18 sept. 2026: $R^2 = 0{,}740$, RMSE 0,026
  - RMSE mai mic, dar VIX a variat mai puțin
  - abaterea standard a VIX: 5,0 față de 9,3 puncte
  - deci R^2 scade
- Raportul dintre VIX observat și estimat
  - media 0,85 în aprilie–mai 2020
  - media 1,16 din octombrie 2020 pînă în mai 2022
  - 8 aprilie 2025: VIX 52,3 față de 39,2 estimat

MFM_ch1_path_dependent_vol

Studiu de caz (10/11): nucleele estimate



MFM_ch1_path_dependent_vol

Studiu de caz (11/11): un singur nucleu pentru memoria scurtă și lungă; ce rămîne exogen

- Ponderile zilnice $K(i\Delta t)\Delta t$, pe scară log–log; între paranteze, Tabelul 3 din lucrare
  - K_1 (trendul): $\hat{\alpha}_1 = 1{,}13$ (1,06), $\hat{\delta}_1 = 0{,}022$ (0,020)
  - K_2 (volatilitatea): $\hat{\alpha}_2 = 1{,}58$ (1,60), $\hat{\delta}_2 = 0{,}050$ (0,052)
- Ultimele 5 zile concentrează 20% din ponderea lui K_2
  - lagurile de peste 250 de zile primesc încă 10%
  - un singur nucleu captează atît memoria scurtă, cît și pe cea lungă
- Limite declarate de autori (Secțiunea 5 din lucrare)
  - rămîne o componentă exogenă mică
  - raportul dintre VIX observat și estimat revine în timp la 1
  - modelarea acestui raport necesită un factor stochastic
- Extindere deschisă (propunere de proiect)
  - descrie aceeași formulă volatilitatea realizată a lui Bitcoin sau a BET-TR?

MFM_ch1_path_dependent_vol

De la dovezi la cerințele unui model

Dovezi (cinci piețe)	Cerința pentru model	Capitolul din curs
exces de kurtosis pe cuantile (Crow–Siddiqui) > 0 pe toate cele cinci piețe; Hill $\hat{\alpha} \approx 2{,}5$–$3{,}5$	inovații cu cozi groase, inclusiv condiționat	Cap. 5, Cap. 7 (teoria valorilor extreme)
ACF a lui $\lvert r_t \rvert$ pozitivă pe orizonturi de mai multe luni; $\hat{d} \approx 0{,}35$–$0{,}50$	volatilitate persistentă, variabilă în timp; memorie lungă sau rupturi	Cap. 5, Cap. 9
$L(1) = -0{,}12$ (S&P 500, BET-TR); inversat pentru EUR/RON	răspuns asimetric la șocurile negative, acolo unde efectul există	Cap. 5 (GJR-GARCH, EGARCH)
$\hat{\rho}_1$ mic din punct de vedere economic (inferență robustă), cu excepția EUR/RON	randamente aproximativ necorelate; rolul microstructurii pieței	Cap. 2, Cap. 10
asimetrie negativă bazată pe cuantile doar pentru S&P 500	asimetria depinde de piață	Cap. 7–8

- Mersul aleator cu creșteri i.i.d. din distribuția Normală (lumea Bachelier–Black–Scholes) este incompatibil cu Faptele 2, 3 și 5–11
  - Faptul 4 este satisfăcut trivial
- Un test ARCH-LM semnificativ susține, descriptiv, existența volatility clustering
  - cum existența momentului de ordinul patru este îndoielnică, nu constituie o dovadă formală

Întrebare deschisă: sînt tail index-urile stabile în timp?

- Tail index-ul α este de obicei tratat ca o constantă
- Structura pieței criptoactivelor s-a schimbat
  - contracte futures (2017), ETF-uri spot pe Bitcoin (ianuarie 2024), deținători instituționali
  - Pele et al. (2023): un factor de coadă distinge criptomonedele de celelalte clase de active
- Ipoteza propusă de un asistent AI
  - după lansarea ETF-urilor spot (ianuarie 2024), intrarea investitorilor instituționali a redus grosimea cozilor distribuției randamentelor Bitcoin
  - adică a crescut tail index-ul α

Bucla de descoperire, parcursă o dată pentru tail index-ul Bitcoin

- Bucla de descoperire, parcursă o dată
  - **literatură**: cereți lucrări cu evaluare inter pares, cu DOI, apoi verificați fiecare DOI
  - Hoga (2017): teste de punct de schimbare pentru tail index, valide în condiții de dependență β-mixing
  - β-mixing: dependența se atenuează pe măsură ce distanța în timp crește, de exemplu în modelele GARCH
  - **ipoteze concurente**: o schimbare a formei cozii
  - doar o scădere a volatilității (scala nu modifică α)
  - zgomot de eșantionare
  - **date și cod**: replicați întîi estimările Hill ale capitolului (Bitcoin 4,2, S&P 500 3,1)
- Stabilite înaintea analizei
  - $k = 2{,}5\%$ din n, data rupturii 11 ianuarie 2024
  - SE bootstrap pe blocuri, un activ placebo

Mini studiu de caz: coada Bitcoin după lansarea ETF-urilor spot

- Test: estimatorul Hill pentru $|r_t|$, $k = 2{,}5\%$ din n
  - $H_0 : \alpha_{\text{după}} = \alpha_{\text{înainte}}$ față de $H_1 : \alpha_{\text{după}} > \alpha_{\text{înainte}}$
  - $\hat{\alpha}_{\text{înainte}}$, $\hat{\alpha}_{\text{după}}$: estimările Hill pe cele două subperioade
  - s: erorile lor standard, prin bootstrap pe blocuri mobile (blocuri de 20 de zile)
  - $z = (\hat{\alpha}_{\text{după}} - \hat{\alpha}_{\text{înainte}}) / \sqrt{s^2_{\text{înainte}} + s^2_{\text{după}}}$: diferența împărțită la eroarea ei standard
  - sub H_0, $z \approx N(0,1)$
  - respingem H_0 la 5% dacă $z > 1{,}645$
- Rezultate
  - înainte (sept. 2014 – 10 ian. 2024, $k = 85$): $\hat{\alpha} = 4{,}16$ ($s = 0{,}52$)
  - după (11 ian. 2024 – sept. 2026, $k = 24$): $\hat{\alpha} = 4{,}31$ ($s = 0{,}91$)
  - $z = 0{,}15$
- Placebo: S&P 500, 17 sept. 2014–18 sept. 2026; ruptură 11 ian. 2024, $k = 58/16$ înainte/după: $2{,}82 \to 2{,}86$, $z = 0{,}03$

MFM_ch1_ai_discovery

Un rezultat nesemnificativ, cu putere mică: ce nu putem concluziona

- **Schimbarea minimă detectabilă**, test unilateral la 5% cu putere de 80%
  - $(1{,}645 + 0{,}842) \times 1{,}05 = 2{,}6$
  - 1,645: valoarea critică unilaterală la 5%
  - 0,842: cuantila de 80% a distribuției $N(0,1)$, pentru puterea de 80%
  - $1{,}05 = \sqrt{0{,}52^2 + 0{,}91^2}$ este eroarea standard a diferenței
  - aproximarea prin distribuția Normală este grosieră cînd coada conține doar 24 de observații
  - datele nu pot distinge o coadă neschimbată de o subțiere puternică a cozii
- Un rezultat nesemnificativ nu dovedește absența efectului
  - sînt necesare date suplimentare sau un panel de active

MFM_ch1_ai_discovery

Propunere de proiect

- **Întrebare**: s-a schimbat tail index-ul pentru Bitcoin și Ethereum odată cu instituționalizarea (futures 2017, ETF-uri spot 2024)?
  - randamente brute și randamente standardizate cu GARCH (forma cozii față de scală)
  - coada pierderilor și coada cîștigurilor, separat
  - Bitcoin folosește seria din curs; Ethereum nu face parte din datele cursului: documentați sursa, ora și fusul orar al închiderii și moneda (USD) înainte de estimare
- **Replicați întîi**: tabelul Hill al capitolului și rezultatele mini studiului de caz
- **Preînregistrare**, depusă în repository înainte de obținerea rezultatelor
  - H_0, H_1, regula pentru k, datele rupturilor și bootstrap-ul
- **Raport**: testul de punct de schimbare al lui Hoga (2017), implementat ca Quantlet
  - estimări, ambele SE, schimbarea minimă detectabilă
- **Jurnal**: prompturile în `AI_USE.md`
  - fiecare eroare depistată (de exemplu, o SE i.i.d. sau o dată a rupturii aleasă după date) în `AI_ERRORS.md`
  - prompturi reutilizabile (▸ Anexă) și verificări (▸ Anexă)

Ce reținem: mărimea randamentelor se poate prognoza, direcția aproape deloc

Idei principale

- Randamentele sînt necorelate, dar nu independente: mărimea lor este predictibilă
- Cozile groase sînt regula: tail index-uri în jur de 3
  - cel mai probabil, momentul de ordinul patru nu este finit
  - inferența bazată pe kurtosis nu este validă
- Volatilitatea este persistentă (memorie lungă sau rupturi)
  - pe piețele de acțiuni, volatilitatea reacționează asimetric la pierderi
- Fiecare test se bazează pe o distribuție de referință ale cărei ipoteze pot fi încălcate de date

Verifică-ți înțelegerea

- Bitcoin, 12 martie 2020: $r_t = -46{,}5\%$; cu cît a scăzut prețul?
- De ce are $Q(10)$ pe randamentele Bitcoin $p = 0{,}028$, dar $\tilde{Q}(10)$ robust $p = 0{,}29$?
- De ce se poate estima tail index-ul cu estimatorul Hill cînd kurtosisul nu există?
- Capitolul 2: sînt randamentele predictibile?

Formule și ipotezele lor

Randamente și anualizare

- $R_t = P_t/P_{t-1} - 1$, $r_t = \ln(1 + R_t)$, $r_t(k) = \sum_{j=0}^{k-1} r_{t-j}$, $R_{p,t} = \sum_i w_i R_{i,t}$
- $\text{CAGR} = (P_T/P_0)^{1/Y} - 1$
- $\sigma_{\text{an}} = \sqrt{A}\,\hat{\sigma}$: randamente necorelate, varianță constantă

Teste

- $JB = T\left[\hat{S}^2/6 + (\hat{K} - 3)^2/24\right]$: χ^2_2 sub i.i.d. Normală
- $Q(m) = T(T+2)\sum_{k=1}^{m} \hat{\rho}_k^2/(T-k)$: χ^2_m sub i.i.d.
- $\tilde{Q}(m) = \sum_k \hat{\rho}_k^2/\hat{\tau}_k$: $\mathbb{E}r^4 < \infty$, termeni încrucișați nuli
- Hill $\text{SE}(\hat{\alpha}) \approx \hat{\alpha}/\sqrt{k}$: coadă Pareto, observații independente

Volatilitate

- Parkinson $\frac{1}{4\ln 2}\overline{(h-l)^2}$, cu bara media pe zile: fără drift, fără salturi peste noapte
- Mixtură $K = 3\,\mathbb{E}[\sigma^4]/\mathbb{E}[\sigma^2]^2$: σ_t independent de ε_t

Randament ajustat la risc și drawdown

- $SR = (\mu - r_f)/\sigma$ pe randamente simple: $\mu = A\bar{R}$, nu media logaritmică $A\bar{r}$
  - $\ln(1 + \text{CAGR}) \approx \mu - \sigma^2/2$ (volatility drag pe scară logaritmică)
  - $\text{SE} \approx 1/\sqrt{Y}$ pentru randamente i.i.d. Normale
- $SoR = (\mu - r_f)/\sigma^-$
- $DD_t = P_t/\max_{s \le t} P_s - 1$; $\text{Calmar} = \text{CAGR}/|MDD|$

înapoi

Prețurile înainte de calculatoare, tickerul bursier



Ticker bursier proiectat de Thomas Edison (colecția Smithsonian)

Foto: Jaclyn Nash, Smithsonian National Museum of American History; domeniu public; Wikimedia Commons

- Înainte de calculatoare, tranzacțiile ajungeau la brokeri ca prețuri tipărite pe o **bandă de ticker**
- Un preț zilnic de închidere este un instantaneu al acestui flux de prețuri
  - randamentele se construiesc din astfel de instantanee
- Alegerea momentului (închidere, fixing, instantaneu la miezul nopții) influențează rezultatele
  - așa cum s-a arătat în Capitolul 0
- Prețurile la nivel de tranzacție individuală: microstructura pieței, Capitolul 10

Înapoi

Oamenii din spatele faptelor stilizate (1/2)



Carl Friedrich Gauss (1777–1855)

Pictură: C.A. Jensen (1840); domeniu public; Wikimedia Commons

- **Distribuția Normală**: reperul de la care randamentele se abat



Louis Bachelier (1870–1946)

Foto: autor necunoscut; domeniu public; Wikimedia Commons

- Prețurile ca mers aleator, în teza sa Bachelier (1900)



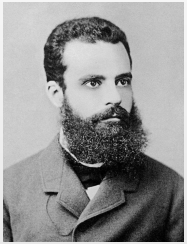
William S. Gosset, „Student" (1876–1937)

Foto: autor necunoscut; domeniu public; Wikimedia Commons

- Distribuția Student-t Student (1908), astăzi un model pentru cozi groase

înapoi

Oamenii din spatele faptelor stilizate (2/2)



Vilfredo Pareto (1848–1923)

Foto: autor necunoscut (anii 1870); domeniu public; Wikimedia Commons



Benoît Mandelbrot (1924–2010)

Foto: Rama (2007); CC BY-SA 2.0 France; Wikimedia Commons

- Pareto: **legi de putere** pentru veniturile mari, precursoarele modelelor cu cozi groase
- Mandelbrot (1963): prețul bumbaculuui
  - cozi groase, pe care distribuția Normală nu le descrie
- Exponentul α al legilor de putere
  - este tail index-ul estimat prin metoda Hill

Înapoi

Faptele lui Cont în studii recente

- Ratliff-Crain, Van Oort, Koehler & Tivnan (2025)
  - testează din nou toate cele 11 fapte pe randamentele intraday ale acțiunilor din Dow 30, octombrie 2018 – martie 2019
  - dovezi concludente pentru 8 fapte, nicio confirmare pentru celelalte 3
- Cozi groase dincolo de Student-t: estimarea distribuțiilor alfa-stabile, cu tail index sub 2 Pele (2014)
- Măsuri de tail risk bazate pe entropie, ca alternativă la kurtosis Pele, Lazar & Dufour (2017)
- Criptoactive: aceleași fapte, cu un factor de coadă care le distinge de celelalte clase de active Pele et al. (2023)

Înapoi

Varianța anuală în prezența autocorelației (1/2)

- Varianța unei sume de h randamente zilnice depinde de autocorelații

$$\text{Var}\Big(\sum_{j=1}^{h} r_{t+j}\Big) = h\sigma^2\Big[1 + 2\sum_{j=1}^{h-1}(1 - j/h)\rho_j\Big]$$

  - h: orizontul, în zile
  - σ^2: varianța zilnică
  - ρ_j: autocorelația la lagul j
  - ipoteza: randamente slab staționare (medie și varianță constante, autocovarianțe care depind doar de lag)
  - fără autocorelație ($\rho_j = 0$) rămîne $h\sigma^2$, adică regula $\sqrt{h}$ pentru volatilitate

- **Raportul variațelor** $VR(h) = \text{Var(suma pe } h \text{ zile)}/(h\sigma^2)$
  - $VR(h) = 1$: fără autocorelație
  - $VR(h) > 1$: autocorelație pozitivă
  - $VR(h) < 1$: autocorelație negativă
  - volatilitatea pe orizontul h este cea dată de regula $\sqrt{h}$, înmulțită cu $\sqrt{VR(h)}$

Înapoi

Varianța anuală în prezența autocorelației (2/2)

- Model autoregresiv de ordinul 1, AR(1), cu $\rho_j = \rho^j$: $\sqrt{VR(h)} \to \sqrt{(1+\rho)/(1-\rho)}$ cînd h crește
  - ρ: autocorelația de lag 1, $|\rho| < 1$
  - EUR/RON, $\rho_1 = 0{,}17$: factorul de corecție 1,19
  - cu această corecție, volatilitatea anualizată a EUR/RON crește de la 4,4% la 5,3%
  - S&P 500, $\rho_1 = -0{,}079$: factorul de corecție 0,92
- Utilizarea autocorelației de selecție de lag 1 ca parametru AR(1) este o ipoteză de modelare
  - verificați întreaga ACF (Seminarul 1, A7)
  - testele raportului variațelor: Capitolul 2

Ipoteza nulă a testului JB și teste pentru serii de timp

- JB este un test al multiplicatorului Lagrange Jarque & Bera (1980)
  - pentru randamente i.i.d. din distribuția Normală, $\sqrt{T}\,(\hat{S}, \hat{K} - 3) \to N\big(0, \mathrm{diag}(6, 24)\big)$, de unde rezultă distribuția χ^2_2
  - $\mathrm{diag}(6, 24)$: matricea de covarianță diagonală
  - $\hat{S}$ și $\hat{K}$ sînt asimptotic independente, cu variațele $6/T$ și $24/T$
  - JB este suma pătratelor celor două statistici standardizate, deci χ^2 cu 2 grade de libertate
- Dependența de tip GARCH modifică $\mathrm{Var}(\hat{S})$ și $\mathrm{Var}(\hat{K})$
  - o respingere nu separă abaterile distribuției marginale de lipsa independenței
- Bai & Ng (2005): teste de asimetrie, kurtosis și normalitate pentru distribuția marginală a unei serii de timp
  - studentizate cu variațe HAC
  - testele lor separate de asimetrie și kurtosis (ipoteza nulă $S = 0$ sau $K = 3$, fără normalitate) necesită $\mathbb{E}r^6 < \infty$ și $\mathbb{E}r^8 < \infty$

Înapoi

Testul portmanteau robust și ipotezele lui

- $\tilde{Q}(m) = \sum_{k=1}^{m} \hat{\rho}_k^2 / \hat{\tau}_k \sim \chi_m^2$ Lobato, Nankervis & Savin (2001) presupune $\mathbb{E}r^4 < \infty$
  - $\sim$: „are distribuția", aici asimptotic
  - și termeni încrucișați nuli: $\mathbb{E}[x_t^2 x_{t-k} x_{t-l}] = 0$ pentru două laguri diferite $k \neq l$
  - atunci $\hat{\rho}_k$ de la laguri diferite sînt asimptotic necorelate, iar suma are distribuția χ_m^2
- Dalla, Giraitis & Phillips (2022) păstrează în covarianța lui $\hat{\rho}_k$ doar termenii încrucișați semnificativi
  - pentru S&P 500, BET-TR și Bitcoin nu rămîne niciunul
- $\hat{\tau}_k$ este varianța estimată sub ipoteza $\rho_k = 0$
  - pentru a compara un ρ_1 nenul între perioade, folosiți SE HAC ale pantei din regresia lui r_t pe r_{t-1} (Seminarul 1, B11)
- ACF a lui $|r_t|$ și a lui r_t^2: distribuțiile limită Normale cer $\alpha > 4$, respectiv $\alpha > 8$ Davis & Mikosch (1998)

Înapoi

Estimatorul Hill, distribuția asimptotică și alternative

- Estimatorul Hill este estimatorul de verosimilitate maximă pentru o coadă Pareto peste pragul $u = X_{(k+1)}$, condiționat de u (Seminarul 1, A11)
- Dacă $k \to \infty$ și $k/n \to 0$, iar coada este Pareto pînă la un termen de ordinul doi

$$\sqrt{k}\,(\hat{\alpha}_k - \alpha) \;\to\; N(0, \alpha^2)$$

  - termen de ordinul doi: o corecție a legii de putere care dispare cînd $x \to \infty$
  - consecință: $\mathrm{SE}(\hat{\alpha}_k) \approx \alpha/\sqrt{k}$, formula din partea principală
  - dacă k crește prea repede, apare o deplasare, deoarece coada este doar aproximativ Pareto
- Date dependente (de tip GARCH): $\hat{\alpha}$ rămîne consistent
  - dar valorile extreme apar grupat, iar varianța depășește α^2/k Hsing (1991)
- Alegerea lui k: $\hat{\alpha}$ în funcție de $\log k$ (alt-Hill plot) Drees, Resnick & de Haan (2000)
  - scara logaritmică pune în evidență zona cu k mic, unde se află coada propriu-zisă
- Alternativa prin regresie Gabaix & Ibragimov (2011)
  - regresia logaritmului rangului pe logaritmul mărimii, cu rangul deplasat cu $-\frac{1}{2}$: $\ln(i - \frac{1}{2}) = a - b \ln X_{(i)}$, $i = 1, \ldots, k$
  - panta $\hat{b}$ estimează α
  - deplasarea cu $\frac{1}{2}$ reduce deplasarea estimatorului în eșantioane mici
  - $\mathrm{SE} = \hat{\alpha}\sqrt{2/k}$

înapoi

Cele două cozi și coada lui $|r_t|$

- $P(|X| > x) = P(X > x) + P(X < -x)$
  - dacă cozile au tail index-urile α_- (pierderi) și α_+ (cîștiguri), $|X|$ are tail index-ul $\min(\alpha_-, \alpha_+)$
- La același k, estimările nu sînt comparabile
  - cele mai mari k valori $|r_t|$ provin din ambele cozi
  - pragul comun u: cel mai mic dintre cele două praguri unilaterale la $k = 2{,}5\%$ din n

	u (%)	k pentru $\lvert r_t\rvert$	$\hat{\alpha}$, $\lvert r_t\rvert$	$\hat{\alpha}_-$, pierderi	$\hat{\alpha}_+$, cîștiguri
S&P 500	2,17	508	2,90	2,85	2,96
BET-TR	1,79	153	2,54	2,20	3,06
Bitcoin	7,11	233	3,02	2,71	3,36
EUR/RON	0,54	295	2,28	2,63	2,04
Aur	1,98	513	3,11	2,97	3,28

- La un prag comun, estimarea pentru $|r_t|$ se situează între estimările pentru cele două cozi
  - valoarea 4,2 pentru Bitcoin la $k = 2{,}5\%$ reflectă o deplasare de ordinul doi
  - raportați ambele tail index-uri unilaterale
  - Seminarul 1, B6 folosește $k = 2\%$ din n pe fiecare coadă: Bitcoin 2,89 / 3,62, BET-TR 2,19 / 3,08

înapoi

Care tail index este estimarea capitolului?

- Estimarea capitolului este cea fixată dinainte: $|r_t|$ la $k = 2{,}5\%$ din n (tabelul din partea principală)
- La pragul comun, k pentru $|r_t|$ iese din intervalul 1–5% din partea principală
  - S&P 500 $508/9\,245 = 5{,}5\%$, aur $513/9\,559 = 5{,}4\%$, EUR/RON $295/5\,352 = 5{,}5\%$, Bitcoin 5,3%, BET-TR 5,1%
  - un k mai mare include zile mai puțin extreme, care pot deplasa $\hat{\alpha}$ (alegerea lui k)
- EUR/RON scade de la 2,82 la 2,28
  - de peste două ori mai multe zile în coadă (295 față de 133)
  - iar coada cîștigurilor, $\hat{\alpha}_+ = 2{,}04$, este cea mai groasă: $|r_t|$ preia coada mai groasă
  - interpretați diferența ca sensibilitate la prag, nu ca o a doua estimare a aceleiași mărimi
- Tabelul cu prag comun răspunde la altă întrebare: care coadă, a pierderilor sau a cîștigurilor, este mai groasă

Formulele de estimare pentru d (1/2)

- Frecvențele Fourier $\lambda_j = 2\pi j/T$, $j = 1, \ldots, m$
- Se folosesc cele mai joase m frecvențe, aici $m = T^{0,65}$
- **Periodograma**: estimatorul de selecție al densității spectrale

$$I(\lambda_j) = \frac{1}{2\pi T}\left|\sum_{t=1}^{T} x_t\, e^{-\mathrm{i}\lambda_j t}\right|^2$$

  - x_t: seria centrată (aici $|r_t|$ minus media)
  - i: unitatea imaginară
  - $I(\lambda_j)$: cît din variația lui x_t provine din ciclul de frecvență λ_j
- Regresia log-periodogramei Geweke & Porter-Hudak (1983): $\ln I(\lambda_j)$ pe $-2\ln(2\sin(\lambda_j/2))$
  - motivul: $\ln f(\lambda) \approx \ln G - 2d \ln \lambda$, iar $2\sin(\lambda/2) \approx \lambda$ la frecvențe joase
  - panta este $\hat{d}$, SE $= \pi/\sqrt{24m}$

înapoi

Formulele de estimare pentru d (2/2)

- Whittle local Robinson (1995): $\hat{d}$ minimizează o funcție obiectiv construită din aproximarea $f(\lambda) \approx G\lambda^{-2d}$

$$\hat{d} = \arg\min_d \left[\ln\left(\frac{1}{m} \sum_{j=1}^{m} \lambda_j^{2d} I(\lambda_j) \right) - \frac{2d}{m} \sum_{j=1}^{m} \ln \lambda_j \right]$$

  - $\arg\min_d$: valoarea lui d care minimizează expresia
  - constanta G a fost eliminată analitic
  - $\sqrt{m}(\hat{d} - d) \to N(0, \frac{1}{4})$, deci $\mathrm{SE} = 1/(2\sqrt{m})$
- Whittle local este robust la abaterile de la normalitate
  - un m mai mare reduce SE
  - dar amplifică deplasarea lui $\hat{d}$ indusă de dinamica pe termen scurt (GARCH) (Seminarul 1, B12)

Pieţele în detaliu

- **Criptoactive**: o clasă de active cu profil statistic propriu Härdle, Harvey & Reule (2020)
  - factorii de coadă, memorie şi momente clasifică criptomonedele ca o clasă separată Pele et al. (2023)
  - separarea provine în principal din factorul de coadă
  - modelarea cripto şi indicele pieţei cripto CRIX (CRypto IndeX): Härdle, Chen & Overbeck (2017); Capitolul 16
- **EUR/RON**: cursul de referinţă BNR, începînd cu 1 iulie 2005
  - leul nou (RON, 1 RON = 10 000 lei vechi)
  - perioade calme lungi întrerupte de ajustări bruşte
  - seriile de cotaţii de piaţă (interbancare) EUR/RON prezintă o autocorelaţie negativă artificială, generată de erori de cotare
- **BET-TR**: taxa pe activele bancare a fost anunţată pe 18 decembrie 2018
  - adoptată pe 28 decembrie 2018 prin Ordonanţa de Urgenţă a Guvernului (OUG) 114/2018
  - şocurile de politică economică produc prăbuşiri de o zi, fără creşteri de amplitudine comparabilă
- **Tranzacţionarea nesincronă**: componentele indicelui nu se tranzacţionează toate în fiecare moment
  - indicele reflectă ştirile cu întîrziere
  - şi prezintă autocorelaţie pozitivă Campbell, Lo & MacKinlay (1997), cap. 3

Înapoi

Drawdown-ul maxim al unei mișcări browniene

- Mișcare browniană fără drift a logaritmului prețului, cu volatilitatea anuală σ, pe T ani
  - aici T este orizontul în ani, nu numărul de zile
- Drawdown-ul maxim **logaritmic** $D = -\ln(1 + MDD) \geq 0$, cea mai mare scădere a logaritmului prețului, are

$$\mathbb{E}[D] = \sqrt{\pi/2}\,\sigma\sqrt{T} \qquad \text{Magdon-Ismail, Atiya, Pratap \& Abu-Mostafa (2004)}$$

- $MDD = e^{-D} - 1$, iar factorul $\sqrt{\pi/2} \approx 1{,}25$
  - fără drift, drawdown-ul maxim așteptat crește proporțional cu $\sqrt{T}$
  - cu un drift pozitiv, $\mathbb{E}[D]$ crește doar ca $\ln T$
- Aur 1990–2026: $\sigma = 16{,}3\%$, $T = 36{,}7$
  - valoarea teoretică $\mathbb{E}[D] = 1{,}24$, față de 0,592 observat ($-44{,}7\%$) (Seminarul 1, A2(b–e) reface acest reper; valorile de aici sînt verificarea voastră)
- Drawdown-urile și rapoartele Calmar din eșantioane de lungimi diferite nu sînt comparabile

înapoi

Raportul Sharpe dincolo de distribuția Normală

- Randamente i.i.d. cu orice distribuție pentru care $\mathbb{E}r^4 < \infty$ Opdyke (2007)
  - $\text{Var}(\widehat{SR}_d) \approx (1 - S\,SR_d + \frac{K-1}{4} SR_d^2)/T$
  - S, K: asimetria și kurtosisul randamentelor zilnice
  - pentru distribuția Normală ($S = 0$, $K = 3$) se obține formula lui Lo
  - asimetria negativă și kurtosisul mare cresc varianța lui $\widehat{SR}_d$ cînd $SR_d > 0$
  - pe datele noastre, SE se modifică cu cel mult 0,02
- Deflated Sharpe Ratio corectează efectele abaterii de la normalitate și ale testării multiple (Capitolul 13)

	CAGR	Sharpe	Sortino	Calmar
S&P 500	8,7%	0,55	0,78	0,15
BET-TR	21,2%	1,34	1,87	0,68
Bitcoin	53,9%	0,98	1,45	0,65
EUR/RON	1,8%	0,43	0,65	0,12
Aur	6,7%	0,48	0,69	0,15

MFM_ch1_risk_measures

înapoi

Studiul de caz, detaliile estimării

- Variabile explicate (Secțiunile 3.4–3.5 din lucrare)
  - indicele de volatilitate implicită pe 30 de zile al fiecărui indice și VIX pe 9 zile
  - volatilitatea realizată a zilei $t+1$
  - volatilitatea în zecimale (0,03 = 3 puncte de volatilitate)
- Nucleele, ec. (3.9) din lucrare: $K(\tau) = Z^{-\mathbf{1}}_{\alpha,\delta}(\tau+\delta)^{-\alpha}$
  - normalizate astfel încît $\sum_i K(i\Delta t)\Delta t = 1$ pe fereastra de 1 000 de zile
  - i: vechimea zilei, în zile
  - $\Delta t = 1/252$: o zi, exprimată în ani
- Estimare: $(\beta_{\mathbf{0}}, \beta_{\mathbf{1}}, \beta_{\mathbf{2}}, \alpha_{\mathbf{1}}, \delta_{\mathbf{1}}, \alpha_{\mathbf{2}}, \delta_{\mathbf{2}})$ prin cele mai mici pătrate neliniare pe eșantionul de antrenare
  - pornind de la o regresie lasso pe variabile construite cu nuclee exponențiale
- Replicarea noastră
  - între paranteze, valorile din Tabelul 3 al lucrării
  - $\hat\beta_{\mathbf{0}} = 0{,}052$ (0,057), $\hat\beta_{\mathbf{1}} = -0{,}090$ ($-0{,}095$)
  - $\hat\beta_{\mathbf{2}} = 0{,}868$ (0,82), $\hat\alpha_{\mathbf{1}} = 1{,}13$ (1,06)
  - parametrii diferă ușor, dar $R^{\mathbf{2}}$ și RMSE sînt practic aceleași
- VIX pe 9 zile există doar din 2011 (eșantion de antrenare mai scurt)
- Modelele restricționate ($\beta_{\mathbf{1}} = 0$, $\beta_{\mathbf{2}} = 0$) sînt analizate în Seminarul 1, C3

Înapoi

Studiul de caz, R^2 pentru toți indicii (1/2)

Indice	Volatilitate implicită (lucrarea, Tabelul 2) R^2 antrenare	R^2 test	Volatilitate realizată (lucrarea, Tabelul 4) R^2 antrenare	R^2 test
S&P 500 (VIX)	0,946	0,855	0,738	0,654
S&P 500 (VIX pe 9 zile)	0,876	0,914	–	–
Euro Stoxx 50	0,929	0,913	0,672	0,682
FTSE 100	0,925	0,870	0,650	0,617
DAX	0,934	0,918	0,722	0,557
Nikkei 225	0,890	0,800	0,563	0,504

- Parametrii pentru VIX: $\beta_0 = 0{,}057$, $\beta_1 = -0{,}095$, $\beta_2 = 0{,}82$
- Pentru toate variabilele explicate, $\alpha_2 \in [1{,}2;\ 2{,}3]$ (Tabelele 3 și 5 din lucrare)
  - memorie lungă aproape de pragul critic (Secțiunea 3.2 din lucrare)

Înapoi

Studiul de caz, R^2 pentru toți indicii (2/2)

- Eliminarea lui Σ_t deteriorează cel mai mult calitatea ajustării
- Modelul are performanțe superioare față de două modele ARCH de referință și patru modele publicate dependente de traiectorie
  - Figurile 3.8–3.9 și Anexa C din lucrare
- Dincolo de acest curs (opțional): versiunea markoviană cu 4 factori, generată de mișcări browniene (Secțiunea 4.6 și Tabelul 9 din lucrare)
  - markoviană: valoarea următoare depinde doar de starea curentă (aici, 4 factori), nu de întreaga traiectorie
  - produce estimații ale exponentului Hurst H al volatilității realizate zilnice de circa 0,12–0,17, ca în datele observate
  - H: exponentul de neregularitate al unei traiectorii; mișcarea browniană are $H = 0{,}5$, iar $H < 0{,}5$ înseamnă o traiectorie mai neregulată (rough) decît mișcarea browniană
  - un model fără rough volatility (modele care au $H < 0{,}5$ încorporat în traiectoria volatilității) reproduce valorile mici ale lui H estimate din date zilnice

Bucla descoperirii, prompturi reutilizabile

Literatură

- Găsește lucrări cu evaluare inter pares, din 2015 încoace, despre variația în timp sau rupturile structurale ale tail index-urilor randamentelor, cu teste valide sub dependență de tip GARCH.
- Pentru fiecare: DOI, estimator, test, date.
- Marchează referințele de care nu ești sigur.

Ipoteză

- Formulează ipoteze concurente pentru o schimbare a cozii randamentelor Bitcoin după lansarea ETF-urilor spot în 2024.
- Ce implică fiecare pentru estimarea Hill a tail index-ului, pe randamentele brute și pe cele standardizate cu GARCH?

Date și cod

- Folosește prețurile zilnice de închidere ale Bitcoin (în USD); randamente logaritmice pe propriul calendar;
- estimarea Hill a tail index-ului pentru $|r|$, cu $k = 2{,}5\%$ din n, înainte și după 11 ianuarie 2024; erori standard prin bootstrap pe blocuri mobile.

Robustețe

- Scrie un plan preînregistrat: k de la 1% la 5% din n, coada pierderilor și coada câștigurilor, reziduuri standardizate GARCH, blocuri de 10 pînă la 50 de zile, o dată placebo și un activ placebo.

Critică

- Evaluează acest plan de cercetare ca un recenzent.
- Cu 24 de observații în coadă după ruptură, ce putere are testul față de o schimbare de 1 a tail index-ului?

înapoi

Verificările obligatorii ale cercetătorului

- **Serie greșită de randamente sau de prețuri**: reproduceți întîi tabelul Hill al capitolului
- **Alegerea lui k după ce vedeți rezultatul**
  - fixați regula ($k = 2{,}5\%$ din n) dinainte
  - prezentați Hill plot-ul pentru 1–5%
- **Erori standard i.i.d.**: $\hat{\alpha}/\sqrt{k}$ ignoră volatility clustering
  - comparați cu un bootstrap pe blocuri
  - S&P 500, 17 sept. 2014–10 ian. 2024: SE bootstrap 0,817, față de 0,370 i.i.d., de 2,2 ori mai mare
- **Data rupturii aleasă după inspectarea datelor**
  - folosiți o dată fixată de eveniment
  - sau un test de punct de schimbare de tip sup, cu propriile valori critice Hoga (2017)
- **Cotațiile eronate creează cozi false**
  - listați cele mai mari zece valori $|r_t|$ și asociați fiecăreia un eveniment datat
- **Putere mică**: raportați schimbarea minimă detectabilă
  - 2,8 SE ale diferenței pentru un test bilateral la 5% cu putere de 80%
  - 2,5 SE pentru un test unilateral

Înapoi

Listă de verificare pentru analiza empirică

- **Cunoașteți-vă datele**
  - indice de preț sau de randament total
  - prețuri ajustate sau brute
  - fixing sau preț tranzacționat
  - cursuri oficiale de referință, acolo unde există (EUR/RON)
- **Curățați înainte de a modela**
  - zile fără tranzacții, sărbători, cotații stale (neactualizate), erori evidente
  - asociați cele mai mari variații unor evenimente identificabile
- **Folosiți randamente logaritmice** pentru dinamica unui activ, randamente simple pentru portofolii
- **Raportați statistici robuste**: cuantile, frecvența depășirilor și tail index-ul $\hat{\alpha}$ alături de kurtosis
- **Anualizați cu atenție**
  - 252 sau 365 de perioade pe an
  - regula $\sqrt{A}$ presupune randamente necorelate cu variață constantă
- **Reproductibilitate**: cod și date pe GitHub, ca Quantlet-uri

Înapoi

Pentru aprofundare pe Quantinar

Cursuri avansate pe quantinar.com

- Statistics of Financial Markets
- Tukey's g- and h- transformations
- Applied Time Series Analysis with Python

Cod, date și lecturi recomandate

- Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_01
- Lecturi recomandate: Cont (2001); Franke, Härdle & Hafner (2019); Campbell, Lo & MacKinlay (1997), cap. 1–2

înapoi

Acronime folosite în acest material (1/2)

- **ACF**: AutoCorrelation Function — *funcția de autocorelație*
- **AI**: Artificial Intelligence — *inteligență artificială*
- **AR**: AutoRegressive (model) — *model autoregresiv*
- **ARCH**: AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă*
- **ARCH-LM**: ARCH Lagrange Multiplier (test) — *testul multiplicatorului Lagrange pentru efecte ARCH*
- **BET-TR**: BET Total Return (index) — *indicele BET cu dividendele reinvestite*
- **BNR**: Banca Națională a României
- **BVB**: Bursa de Valori București
- **CAGR**: Compound Annual Growth Rate — *rata anuală compusă de creștere*
- **CI**: Confidence Interval — *interval de încredere*
- **CLT**: Central Limit Theorem — *teorema limită centrală*
- **CRIX**: CRypto IndeX — *indicele pieței cripto*
- **DAX**: Deutscher Aktienindex — *indicele bursier german*
- **EGARCH**: Exponential GARCH — *GARCH exponențial*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- **FTSE**: Financial Times Stock Exchange (FTSE Russell, index provider) — *furnizorul de indici FTSE Russell*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GJR-GARCH**: Glosten–Jagannathan–Runkle GARCH — *GARCH asimetric Glosten–Jagannathan–Runkle*

Acronime folosite în acest material (2/2)

- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HAR-RV**: Heterogeneous AutoRegressive model of Realised Volatility — *model autoregresiv heterogen al volatilității realizate*
- **JB**: Jarque–Bera (test) — *testul de normalitate Jarque–Bera*
- **LB**: Ljung–Box (test) — *testul de autocorelație Ljung–Box*
- **LM**: Lagrange Multiplier — *multiplicatorul Lagrange*
- **MDD**: Maximum DrawDown — *drawdown-ul maxim*
- **OHLC**: Open, High, Low, Close — *deschidere, maxim, minim, închidere*
- **OUG**: Ordonanță de Urgență a Guvernului
- **PDV**: Path-Dependent Volatility — *volatilitate dependentă de traiectoria prețului*
- **QQ**: Quantile–Quantile (plot) — *graficul cuantilă–cuantilă*
- **RMSE**: Root Mean Squared Error — *rădăcina erorii pătratice medii*
- **SE**: Standard Error — *eroare standard*
- **SUA**: Statele Unite ale Americii
- **TSPL**: Time-Shifted Power Law (kernel) — *nucleu de tip lege de putere decalată în timp*
- **VIX**: CBOE Volatility IndeX — *indicele de volatilitate CBOE*
- **VIX9D**: Cboe 9-Day Volatility Index — *indicele Cboe de volatilitate implicită pe 9 zile*

Bibliografie (1/4)

- Andersen, T.G., Bollerslev, T., Diebold, F.X., Ebens, H. (2001). The distribution of realized stock return volatility. *Journal of Financial Economics*, 61(1), 43–76.
- Bachelier, L. (1900). Théorie de la spéculation. *Annales scientifiques de l'École Normale Supérieure*, 17, 21–86.
- Bai, J., Ng, S. (2005). Tests for skewness, kurtosis, and normality for time series data. *Journal of Business & Economic Statistics*, 23(1), 49–60.
- Bollerslev, T., Hood, B., Huss, J., Pedersen, L.H. (2018). Risk everywhere: modeling and managing volatility. *Review of Financial Studies*, 31(7), 2729–2773.
- Bouchaud, J.-P., Matacz, A., Potters, M. (2001). Leverage effect in financial markets: the retarded volatility model. *Physical Review Letters*, 87(22), 228701.
- Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). The Econometrics of Financial Markets. Princeton University Press.
- Christie, A.A. (1982). The stochastic behavior of common stock variances: value, leverage and interest rate effects. *Journal of Financial Economics*, 10(4), 407–432.
- Clark, P.K. (1973). A subordinated stochastic process model with finite variance for speculative prices. *Econometrica*, 41(1), 135–155.
- Cong, L.W., Li, X., Tang, K., Yang, Y. (2023). Crypto wash trading. *Management Science*, 69(11), 6427–6454.
- Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- Dalla, V., Giraitis, L., Phillips, P.C.B. (2022). Robust tests for white noise and cross-correlation. *Econometric Theory*, 38(5), 913–941.
- Davis, R.A., Mikosch, T. (1998). The sample autocorrelations of heavy-tailed processes with applications to ARCH. *Annals of Statistics*, 26(5), 2049–2080.
- Diebold, F.X., Inoue, A. (2001). Long memory and regime switching. *Journal of Econometrics*, 105(1), 131–159.
- Ding, Z., Granger, C.W.J., Engle, R.F. (1993). A long memory property of stock market returns and a new model. *Journal of Empirical Finance*, 1(1), 83–106.

Bibliografie (2/4)

- Drees, H., Resnick, S., de Haan, L. (2000). How to make a Hill plot. *Annals of Statistics*, 28(1), 254–274.
- Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- Fama, E.F. (1965). The behavior of stock-market prices. *Journal of Business*, 38(1), 34–105.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, ed. a 5-a. Springer.
- Gabaix, X., Ibragimov, R. (2011). Rank − 1/2: a simple way to improve the OLS estimation of tail exponents. *Journal of Business & Economic Statistics*, 29(1), 24–39.
- Garman, M.B., Klass, M.J. (1980). On the estimation of security price volatilities from historical data. *Journal of Business*, 53(1), 67–78.
- Geweke, J., Porter-Hudak, S. (1983). The estimation and application of long memory time series models. *Journal of Time Series Analysis*, 4(4), 221–238.
- Granger, C.W.J., Ding, Z. (1995). Some properties of absolute return: an alternative measure of risk. *Annales d'Économie et de Statistique*, 40, 67–91.
- Guyon, J., Lekeufack, J. (2023). Volatility is (mostly) path-dependent. *Quantitative Finance*, 23(9), 1221–1258.
- Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Ed.) (2017). Applied Quantitative Finance, ed. a 3-a. Springer.
- Härdle, W.K., Harvey, C.R., Reule, R.C.G. (2020). Understanding cryptocurrencies. *Journal of Financial Econometrics*, 18(2), 181–208.
- Hill, B.M. (1975). A simple general approach to inference about the tail of a distribution. *Annals of Statistics*, 3(5), 1163–1174.
- Hoga, Y. (2017). Change point tests for the tail index of β-mixing random variables. *Econometric Theory*, 33(4), 915–954.
- Hsing, T. (1991). On tail index estimation using dependent data. *Annals of Statistics*, 19(3), 1547–1569.

Bibliografie (3/4)

- Inclán, C., Tiao, G.C. (1994). Use of cumulative sums of squares for retrospective detection of changes of variance. *Journal of the American Statistical Association*, 89(427), 913–923.
- Jarque, C.M., Bera, A.K. (1980). Efficient tests for normality, homoscedasticity and serial independence of regression residuals. *Economics Letters*, 6(3), 255–259.
- Karpoff, J.M. (1987). The relation between price changes and trading volume: a survey. *Journal of Financial and Quantitative Analysis*, 22(1), 109–126.
- Kim, T.-H., White, H. (2004). On more robust estimation of skewness and kurtosis. *Finance Research Letters*, 1(1), 56–73.
- Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- Ljung, G.M., Box, G.E.P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.
- Lobato, I., Nankervis, J.C., Savin, N.E. (2001). Testing for autocorrelation using a modified Box–Pierce Q test. *International Economic Review*, 42(1), 187–205.
- Magdon-Ismail, M., Atiya, A.F., Pratap, A., Abu-Mostafa, Y.S. (2004). On the maximum drawdown of a Brownian motion. *Journal of Applied Probability*, 41(1), 147–161.
- Mandelbrot, B. (1963). The variation of certain speculative prices. *Journal of Business*, 36(4), 394–419.
- Mikosch, T., Stărică, C. (2004). Nonstationarities in financial time series, the long-range dependence, and the IGARCH effects. *Review of Economics and Statistics*, 86(1), 378–390.
- Opdyke, J.D. (2007). Comparing Sharpe ratios: so where are the p-values?. *Journal of Asset Management*, 8(5), 308–336.
- Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *Journal of Business*, 53(1), 61–65.

Bibliografie (4/4)

- Pele, D.T. (2014). A SAS approach for estimating the parameters of an alpha-stable distribution. *Procedia Economics and Finance*, 10, 68–77.
- Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *The European Journal of Finance*, 29(10), 1064–1105.
- Praetz, P.D. (1972). The distribution of share price changes. *Journal of Business*, 45(1), 49–55.
- Ratliff-Crain, E., Van Oort, C.M., Koehler, M., Tivnan, B.F. (2025). Revisiting Cont's stylized facts for modern stock markets. *Quantitative Finance*, 25(9), 1343–1373.
- Robinson, P.M. (1995). Gaussian semiparametric estimation of long range dependence. *Annals of Statistics*, 23(5), 1630–1661.
- Rogers, L.C.G., Satchell, S.E. (1991). Estimating variance from high, low and closing prices. *Annals of Applied Probability*, 1(4), 504–512.
- Romano, J.P., Thombs, L.A. (1996). Inference for autocorrelations under weak assumptions. *Journal of the American Statistical Association*, 91(434), 590–600.
- Sharpe, W.F. (1966). Mutual fund performance. *Journal of Business*, 39(1), 119–138.
- Sharpe, W.F. (1994). The Sharpe ratio. *Journal of Portfolio Management*, 21(1), 49–58.
- Sortino, F.A., van der Meer, R. (1991). Downside risk. *Journal of Portfolio Management*, 17(4), 27–31.
- Student (1908). The probable error of a mean. *Biometrika*, 6(1), 1–25.
- Taylor, S.J. (1986). Modelling Financial Time Series. Wiley; ed. a 2-a (2008), World Scientific, doi:10.1142/6578.
- Yang, D., Zhang, Q. (2000). Drift-independent volatility estimation based on high, low, open, and close prices. *Journal of Business*, 73(3), 477–492.