









Modelarea piețelor financiare

Capitolul 2: Eficiența pieței — de la EMH la piețe adaptive



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

O întrebare, cinci pași

- Poate informația disponibilă azi să îmbunătățească o decizie, după ajustarea la risc și costuri?
- La prima lectură, parcurge cei cinci pași și răspunde la întrebările de verificare.
- La seminar, folosește exemplele pentru a-ți justifica interpretarea.
- Pentru aprofundare, alege o demonstrație, un alt test sau o temă de cercetare.

- 1. Randamente și informație
- 2. De la tipar la test
- 3. Prognoza trebuie să funcționeze pe date noi
- 4. Cum reacționează prețurile la știri
- 5. Ce concluzii rezistă verificării?
- Teme

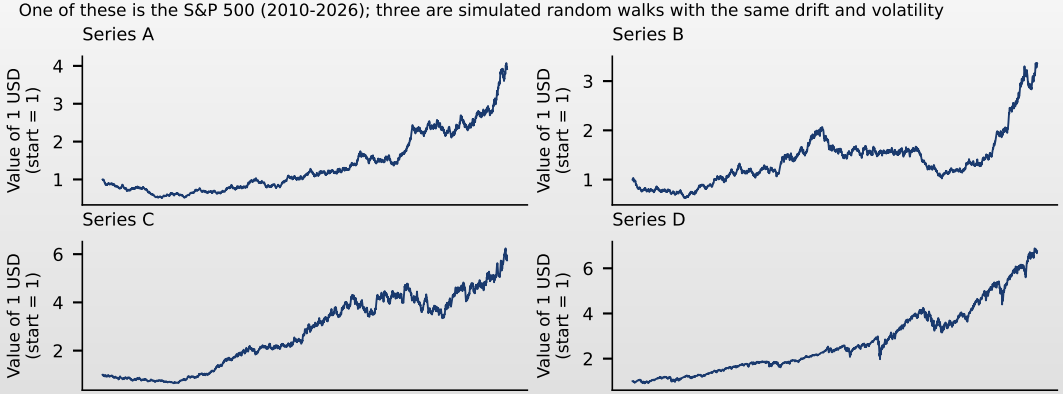
1. Randamente și informație

- **RW1**: Random Walk 1 — random walk cu variații independente și identic distribuite.
- **RW2**: Random Walk 2 — random walk cu variații independente, fără cerința unei distribuții identice.
- **RW3**: Random Walk 3 — random walk cu variații necorelate, care pot fi dependente.
- Calculează randamentul și precizează informația disponibilă înaintea tranzacției.
- Deosebește RW1, RW2 și RW3 prin ipotezele asupra randamentelor.
- Explică de ce respingerea depinde și de modelul de risc.
- Cuprins

- Prețul crește de la 100 la 105, fără dividend: randamentul simplu este $105/100 - 1 = 5\%$.
- Randamentul logaritmic este $\ln(105/100) \approx 0{,}04879$, adică $4{,}879\%$.
- Randamentul total (total return) include și dividendele: cu un dividend de 2, $(105 + 2)/100 - 1 = 7\%$.
- Un random walk adaugă o inovație imprevizibilă la valoarea precedentă
  - un exemplu este o serie de pași independenți de $+1$ sau -1, aleși prin aruncarea unei monede.

Un joc: identificarea seriei de piață reale (1/2)

S&P 500: Standard & Poor's 500 — indice al acțiunilor a 500 de companii mari din Statele Unite.



Un joc: identificarea seriei de piață reale (2/2)

- Un panou este S&P 500 (2010–2026)
- Trei sînt mersuri aleatoare cu aceeași medie și volatilitate. Votați: A, B, C sau D?

MFM_ch2_random_walk_game

Un joc: identificarea seriei de piață reale (2/2)

- Un panou este S&P 500 (2010–2026)
- Trei sînt mersuri aleatoare cu aceeași medie și volatilitate. Votați: A, B, C sau D?
- Răspuns: **D**. Roberts (1959): mersurile aleatoare produc „tipare" din întîmplare
- Avem nevoie de teste statistice, nu doar de inspecție vizuală
- Bachelier (1900) și Samuelson (1965): prețurile anticipate corect variază aleator, deci imprevizibilitatea este semnul unei piețe care funcționează bine

MFM_ch2_random_walk_game

Ajustarea la risc și informația: exemple

- Equity premium (prima de risc a acțiunilor) este randamentul așteptat al acțiunilor peste randamentul fără risc: $8\% - 3\% = 5$ puncte procentuale într-un an ilustrativ.
- Ajustarea la risc compară strategia cu un reper care are risc comparabil, după costurile de tranzacționare.
- Un randament așteptat de 10% față de un reper de risc de 8% lasă 2 puncte procentuale înainte de costuri
  - un randament realizat de 10% într-un singur an nu dovedește această medie.
- Prețurile trecute intră în informația formei slabe
  - un raport public de profit adaugă informație publică
  - profitul încă nepublicat este informație privată.

Eficiența și mulțimea de informații

- Fama (1970): o piață este **eficientă** dacă prețurile „reflectă complet" toată informația disponibilă $\mathcal{I}_t$
- portretul și articolele de sinteză: vezi Anexa
  - formal: nicio strategie bazată pe $\mathcal{I}_t$ nu obține randamente **așteptate** peste randamentul de echilibru (ajustat la risc)
  - precursorii Bachelier (1900) și Samuelson (1965), cu cele două rezultate: vezi Anexa

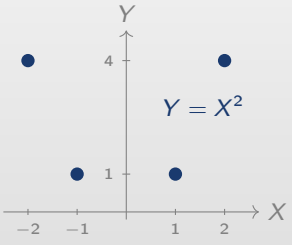
Forma	Mulțimea de informații $\mathcal{I}_t$	Testul tipic (în acest capitol)
Slabă	Prețurile și randamentele trecute	Autocorelație, secvențe, variance ratio-uri, memorie lungă
Semi-tare	Toată informația publică (știri, rapoartări)	Studii de eveniment
Tare	Informația publică și cea privilegiată	Randamentele persoanelor inițiate (insiders) și ale administratorilor de fonduri

- Cele trei forme se implică succesiv: tare $\Rightarrow$ semi-tare $\Rightarrow$ slabă
- În Capitolul 3 ajustăm randamentele la risc folosind modele factoriale

Corelația și dependența randamentelor

- Autocorelația la lag k este corelația dintre un randament și randamentul de acum k perioade.
- Corelația măsoară asocierea liniară: pozitivă pentru variații în același sens, negativă pentru variații în sens opus.
- Corelația zero exclude asocierea liniară, dar poate lăsa dependență între pătratele randamentelor.

- Exemplu ipotetic: $X = -2, -1, 1, 2$, la fel de probabile; $Y = X^2$.
- Media lui X este zero; media lui XY este $(-8-1+1+8)/4 = 0$. Covarianța, deci și corelația, este zero.
- Dar dacă știm X, știm exact Y: variabilele sînt dependente.



Medii condiționate și martingale: exemplu

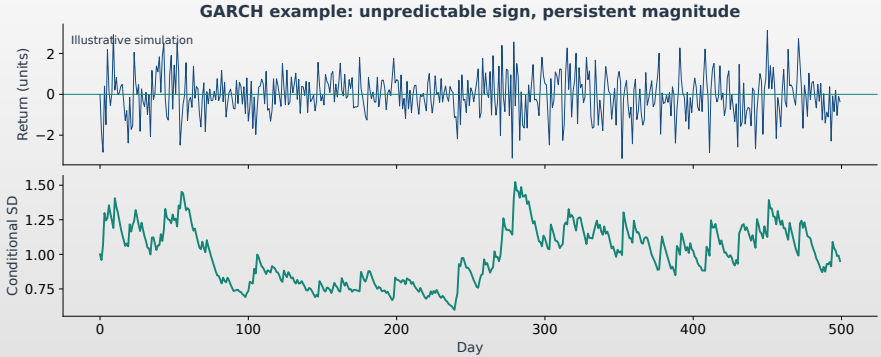
- Media condiționată combină rezultatele posibile de mîine cu probabilitățile lor, folosind informația cunoscută azi.
- Pornind de la 100, valorile 110 și 90, egal probabile, au media condiționată $0{,}5(110) + 0{,}5(90) = 100$.
- Dacă egalitatea se păstrează la fiecare dată, condiționat de toată informația trecută, procesul este un martingal
  - următoarea variație are media condiționată zero.
- Cu un randament cerut de 5%, randamentele egal probabile de 15% și -5% formează un fair game (joc echitabil) după scăderea celor 5%.

Independență, volatility clustering și GARCH

- **GARCH**: Generalized AutoRegressive Conditional Heteroskedasticity — model al dispersiei condiționate, explicată prin șocuri și dispersii trecute.
- **i.i.d.**: independent and identically distributed — independente și identic distribuite.
- Observațiile independente nu oferă informație unele despre altele
  - cele identic distribuite au aceeași distribuție.
  - Împreună: i.i.d.
- Volatility clustering (gruparea volatilității) înseamnă că variațiile mari în valoare absolută se grupează în timp, indiferent de semn
  - de exemplu $+3, -4, +5\%$ după zile calme în jur de $\pm 0{,}2\%$.
- Heteroskedasticity înseamnă dispersie variabilă
  - homoskedasticity înseamnă dispersie constantă pentru informația de condiționare precizată.
- GARCH modelează dispersia condiționată de mîine din pătratele șocurilor și dispersiile trecute
  - randamentele pot fi necorelate deși mărimile lor rămîn dependente.

Volatility clustering în randamente

SD: Standard Deviation — abaterea standard a observațiilor.



Exemplu GARCH: randamentele mari în modul apar în grupuri. Panoul inferior arată SD condiționată, nu o prognoză a semnului randamentului.

RW1, RW2, RW3: restricțiile asupra randamentelor

$$r_t = \ln P_t - \ln P_{t-1} = \mu + \varepsilon_t$$

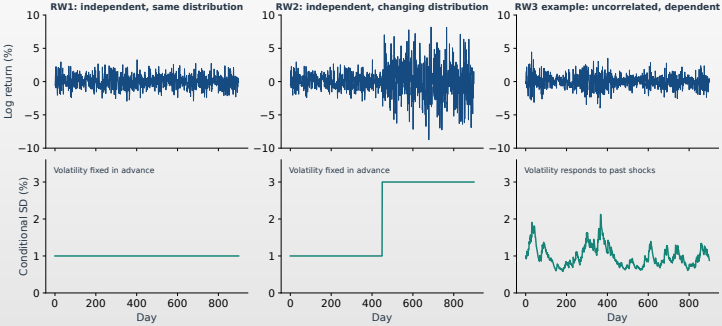
- μ: media constantă; ε_t: inovația cu media zero. Random walk-ul privește log-prețul; restricțiile privesc variațiile lui, adică randamentele logaritmice.

	Condiție	Exemplu de model pentru randamente
RW1	Independente, identic distribuite	$r_t = \mu + 0{,}01 z_t$, z_t i.i.d. $N(0,1)$
RW2	Independente, distribuția poate varia	$r_t = \mu + \sigma_t z_t$, σ_t = 1% apoi 3%, fixat dinainte
RW3	Necorelate, posibil dependente	GARCH: dispersia condiționată răspunde la pătratele șocurilor trecute

RW1 $\Rightarrow$ RW2 $\Rightarrow$ RW3

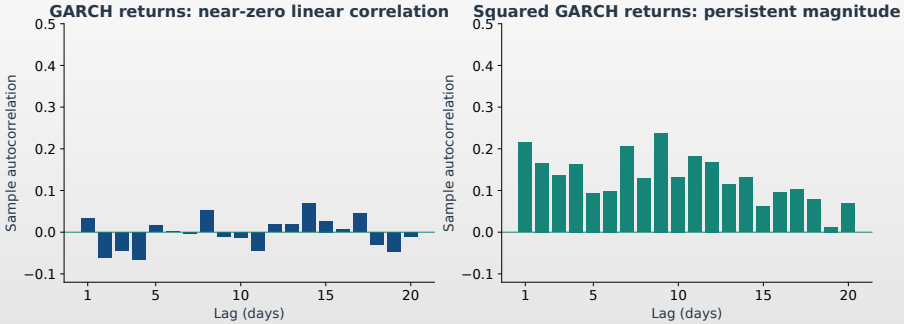
- De la RW1 la RW2: renunțăm la distribuția identică, păstrăm independența.
- De la RW2 la RW3: păstrăm corelația liniară zero, permitem dependența. Implicațiile cer existența momentelor relevante.
- Exemplele separă clasele: schimbarea dispersiei fixată dinainte încalcă RW1; dependența GARCH încalcă RW2.
- RW3 nu implică o medie condiționată imprevizibilă: poate rămîne predictibilitate neliniară. GARCH cu inovații independente cu media zero este un exemplu, nu definiția RW3.

Trei modele pentru randamente și volatilitate



- Modele ilustrative cu $\mu = 0$.
- Volatilitatea RW2 este fixată dinainte
- volatilitatea GARCH răspunde șocurilor observate.
- Gruparea vizuală nu dovedește singură dependența.

GARCH: randamente versus randamente la pătrat



- Corelațiile de selecție ale randamentelor fluctuează în jurul lui zero
- corelațiile pozitive ale pătratelor arată dependența mărimii variațiilor.
- Sînt estimații ilustrative, nu teste de ipoteze.

CAPM și ipoteza comună: exemplu

CAPM: Capital Asset Pricing Model — model care leagă randamentul cerut de expunerea la riscul pieței.

- CAPM folosește beta de piață, sensibilitatea la randamentul pieței, pentru a stabili randamentul cerut
  - Capitolul 3 dezvoltă modelul.
- Dacă strategia are randament așteptat 10%, iar CAPM cere 8%, randamentul anormal aparent este de 2 puncte procentuale.
- Dacă riscul omis cere de fapt 10%, anomalia aparentă dispare: respingerea poate privi modelul de risc, nu doar eficiența pieței.

Problema ipotezei comune

- Pentru a stabili „randamentul de echilibru" avem nevoie de un model al randamentelor așteptate (de ex. CAPM, Capitolul 3)
- Orice test de eficiență este un test **comun** al eficienței și al modelului de evaluare Fama (1991)
  - O respingere poate însemna o piață ineficientă **sau** un model de risc greșit
  - Randamentele **așteptate** predictibile sînt permise dacă ele compensează un risc variabil în timp
- Unii investitori depășesc piața din noroc: întrebarea relevantă este dacă performanța persistă
- La orizont zilnic randamentele așteptate sînt foarte mici, deci alegerea modelului contează puțin: testele formei slabe depind cel mai puțin de model
- Un test nu poate demonstra eficiența pieței; poate doar să nu o respingă pe baza datelor analizate

Verificare: randamente și informație

- Prețul crește de la 100 la 105, fără dividende. Care randament este 5%?
- Pot randamentele independente să aibă SD fixată dinainte la 1%, apoi la 3%?
- Autocorelația zero dovedește independența?
- Verifică raționamentul

Răspunsuri: randamente și informație

- 5% este randamentul simplu; cel logaritmic este circa 4,879%.
- Da: schimbarea SD fixată dinainte este compatibilă cu RW2, dar încalcă RW1.
- Nu: exemplul GARCH are mărimi dependente chiar dacă autocorelația randamentelor este zero.
- Continuă cu pasul următor

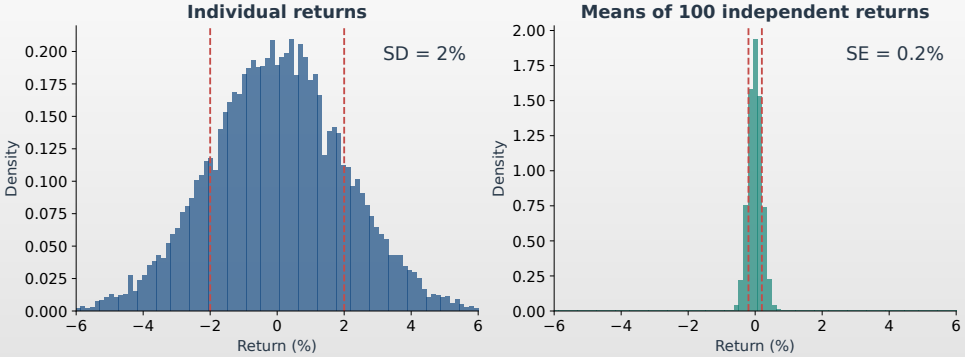
2. De la tipar la test

- Interpretează semnul, incertitudinea și mărimea economică a autocorelației.
- Explică de ce volatility clustering schimbă inferența.
- Citește un profil variance ratio fără să deduci direct un profit din tranzacționare.
- Cuprins

Dispersie și incertitudine

- Standard deviation (SD) măsoară cît de dispersate sînt randamentele.
- Standard error (SE) măsoară cît variază o estimație între selecții repetate.
- Pentru 100 de randamente i.i.d. cu SD 2%, media de selecție are SE $2\%/\sqrt{100} = 0{,}2\%$.
- O bandă sub ipoteza nulă arată estimațiile generate în mod obișnuit sub ipoteza nulă precizată.

SD și SE pe aceeași scară orizontală



Selecții Normale ilustrative: randamentele individuale au SD 2%; mediile a 100 de randamente independente au SE 0,2%.

Cum citim un test statistic

- H_0 este ipoteza nulă testată, de exemplu autocorelație zero
  - H_1 este alternativa, de exemplu autocorelație nenulă.
- p-value-ul este probabilitatea, sub H_0 și ipotezele testului, a unei statistici cel puțin la fel de extreme ca cea observată
  - nu este probabilitatea că H_0 este adevărată.
- La nivelul de semnificație $\alpha = 5\%$, $p = 0{,}03$ duce la respingere
  - $p = 0{,}20$ nu duce la respingere.
  - Un nivel valid controlează respingerile false cînd H_0 este adevărată.
- Puterea este probabilitatea de respingere pentru o alternativă precizată: detectarea efectului în 80 din 100 de selecții simulate înseamnă o putere estimată de 80%.

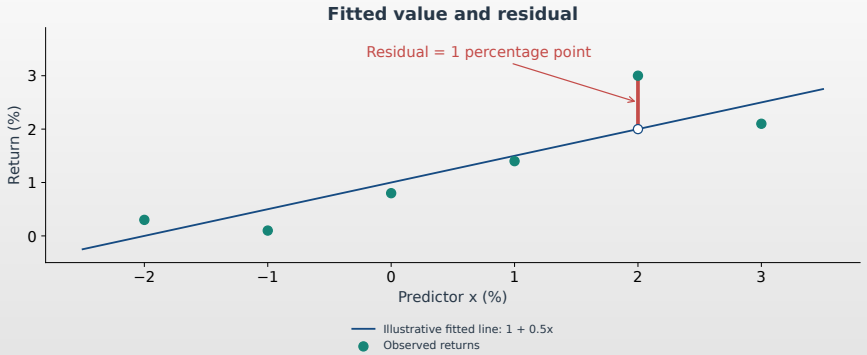
Autocorelația: ce citești mai întîi

- Autocorelația compară randamentul cu un randament anterior, la un lag precizat.
- Semnul pozitiv arată persistență; cel negativ, inversare. Niciun semn nu dovedește profitul.
- Estimația descrie mărimea efectului; eroarea ei standard descrie incertitudinea.
- Folosește inferență robustă cînd pătratele randamentelor sînt dependente.
- Estimatorul și eroarea standard robustă

OLS, reziduuri și persistență

- **OLS**: Ordinary Least Squares — metoda celor mai mici pătrate.
- **AR**: AutoRegressive model — model autoregresiv; AR(p) are ordinul p.
- OLS alege coeficienții regresiei pentru a minimiza suma pătratelor reziduurilor
  - un reziduu este randamentul observat minus cel estimat.
- Exemplu: randamentul estimat $1\% + 0{,}5x$ este 2% la $x = 2\%$
  - un randament observat de 3% lasă un reziduu de 1 punct procentual.
- AR(1) leagă o variabilă de valoarea ei precedentă
  - la coeficientul 0,9, un șoc unitar mai contribuie cu $0{,}9^2 = 0{,}81$ după două perioade.
- Unit root înseamnă coeficientul 1 în acest AR(1): șocurile nu se sting.
  - Un coeficient apropiat de 1 produce predictori persistenți și îngreunează inferența.

Cum citim o dreaptă de regresie



La x = 2%, dreapta ilustrată prognozează 2%; randamentul observat este 3%, deci reziduul este de 1 punct procentual.

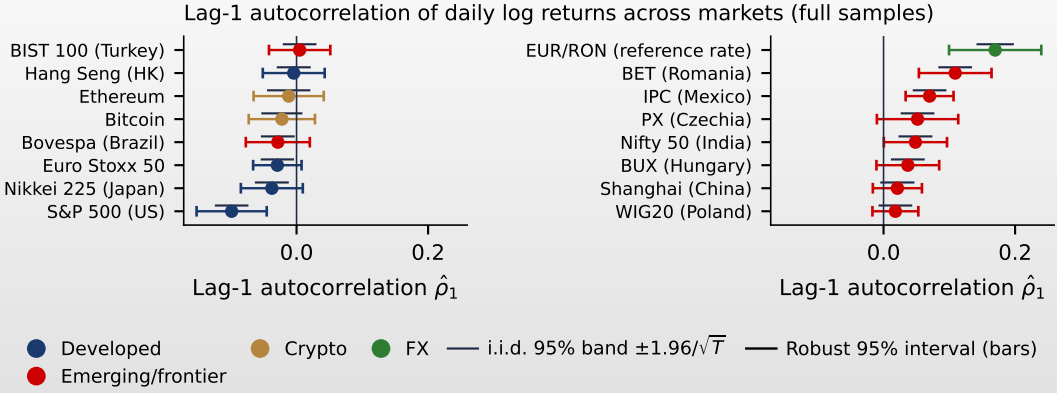
Interpretarea dependenței și a lui R^2

- R^2 este proporția variației din selecție explicată de regresia estimată
  - într-o regresie simplă cu intercept este pătratul corelației de selecție.
- O corelație de 0,10 corespunde unui $R^2 = 0{,}01$, adică 1% variație explicată: detectarea statistică poate coexista cu o predicție slabă.
- Thin trading (tranzacționare rară) lasă prețuri neactualizate: o știre de azi poate intra abia mîine în randamentul înregistrat al unei acțiuni rar tranzacționate.
- Liquidity provision (furnizarea de lichiditate) înseamnă acceptarea tranzacțiilor altora
  - concesiile temporare de preț se pot inversa.
  - Managed float (curs de schimb administrat) permite ajustarea cursului cu intervenții ale băncii centrale.

Piețe și surse de date

- **US**: United States — în grafice, seria indicelui S&P 500.
- **HK**: Hong Kong — în grafice, seria indicelui Hang Seng.
- **BIST**: Borsa İstanbul (BIST 100 index) — Bursa din Istanbul (indicele BIST 100).
- **WIG20**: Warszawski Indeks Giełdowy 20 — indicele celor mai mari 20 de companii de la Bursa din Varșovia.
- **BUX**: Budapesti Értéktőzsde index — indicele Bursei din Budapesta.
- **PX**: Prague Stock Exchange index (index Burzy cenných papírů Praha) — indicele Bursei din Praga.
- **IPC**: Índice de Precios y Cotizaciones — indicele Bursei din Mexic.
- **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București.
- **FX**: Foreign eXchange — piața valutară.

Autocorelația de ordinul 1 pe piețe (1/2)



MFM_ch2_autocorrelation

Autocorelația de ordinul 1 pe piețe (2/2)

- Puncte: $\hat{\rho}_1$ cu intervale robuste de 95%
- Segmentele subțiri: banda i.i.d. naivă
- Culori: grupul de piețe (FX, piața valutară: EUR/RON)
- Intervalele robuste folosesc $\sqrt{\hat{\tau}_1}$ în loc de $1/\sqrt{T}$ și sînt mai largi cînd variațiile mari se grupează: S&P 500, SE 0,027 (robustă) față de 0,012 (i.i.d.)
- Autocorelație pozitivă și semnificativă: BET 0,109 (SE 0,028), IPC 0,070, EUR/RON 0,170
- Autocorelație negativă și semnificativă: S&P 500 $-0{,}099$
- Bitcoin $-0{,}022$, Ethereum $-0{,}012$: autocorelațiile nu sînt semnificative
- Explicații posibile: tranzacționare rară (BET), regimul de managed float (EUR/RON), reacție excesivă pe termen scurt și furnizare de lichiditate (S&P 500)
- Cît explică relația din variația zilnică: $R^2 = \hat{\rho}_1^2$, adică 0,97% (S&P 500) și 1,19% (BET) din dispersia zilnică

MFM_ch2_autocorrelation

Staționaritate și randamente suprapuse

- Staționaritatea în covarianță (covariance stationarity) înseamnă medie constantă, dispersie finită constantă și covarianță care depinde doar de lag, nu de data calendaristică.
- Un AR(1) stabil, $x_t = 0{,}5x_{t-1} + u_t$, pornit din distribuția staționară, cu șocuri i.i.d. cu dispersie finită, este un exemplu
  - o schimbare permanentă de medie încalcă definiția.
- Randamentele suprapuse pe cinci zile folosesc zilele 1–5, apoi 2–6: patru zile sînt comune, deci sumele sînt dependente chiar dacă randamentele zilnice sînt independente.
- Leverage effect în volatilitate înseamnă că un șoc negativ mărește volatilitatea viitoare mai mult decît un șoc pozitiv egal în modul
  - diferă de cumpărarea unui activ cu bani împrumutați.

Variance ratio-ul: ideea

VR: Variance Ratio — dispersia randamentului pe mai multe perioade, raportată la dispersia de referință.

- Pentru randamente necorelate cu dispersie constantă, dispersia randamentului cumulat crește liniar cu orizontul, $\text{Var}(r_t + \cdots + r_{t-q+1}) = q\,\text{Var}(r_t)$
  - q: orizontul în zile (de ex. $q = 5$ este o săptămînă de tranzacționare)
  - Cu dispersii variabile (RW2, RW3) dispersia sumei este suma dispersiilor
  - Estimatorul de selecție $\widehat{\text{VR}}(q)$ tinde în continuare la 1 în condițiile din Lo & MacKinlay (1988)
- **Variance ratio-ul**: $\text{VR}(q) = \dfrac{\text{Var}(r_t + \cdots + r_{t-q+1})}{q\,\text{Var}(r_t)}$, egal cu 1 pentru orice serie necorelată staționară în covarianță
- Pentru o serie staționară în covarianță, raportul se exprimă printr-o sumă ponderată a autocorelațiilor: $\text{VR}(q) = 1 + 2\sum_{k=1}^{q-1}\left(1 - \frac{k}{q}\right)\rho_k$
- $\text{VR}(q) > 1$: momentum (autocorelație pozitivă)
- $\text{VR}(q) < 1$: revenire la medie
- Verificare: S&P 500 $1 + \hat{\rho}_1 = 0{,}901$ față de $\text{VR}(2) = 0{,}901$ estimat

Ce orizonturi testăm cu variance ratio?

- Lo & MacKinlay (1988), tabelul 1a: patru orizonturi, $q = 2, 4, 8, 16$, pentru observații săptămînale.
- Aici testăm patru orizonturi, $q = 2, 5, 10, 20$ zile: două zile, aproximativ o săptămînă, două săptămîni și o lună bursieră pentru acțiuni.
- Curba pînă la $q = 60$ este descriptivă. Banda este punctuală: incertitudinea se evaluează separat la fiecare orizont.
- Cele patru orizonturi sînt o alegere explicită, nu o garanție de suficiență.
- Testul Chow–Denning combină orizonturile alese într-o singură decizie de respingere Chow & Denning (1993).

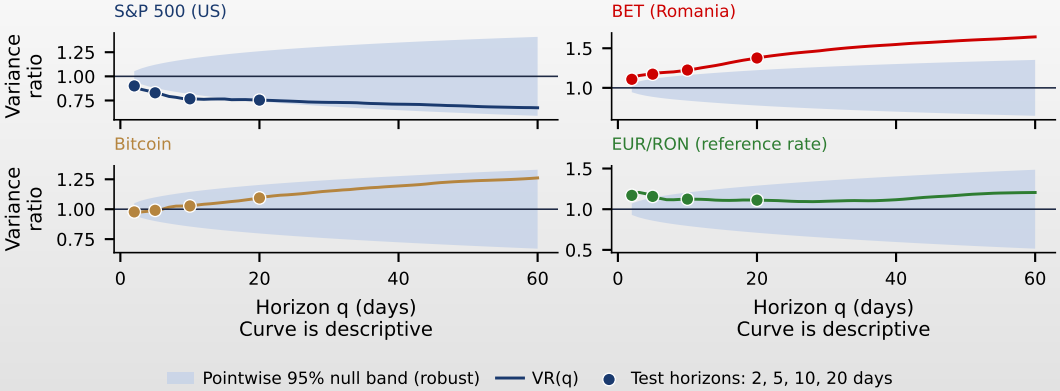
Cum citești banda robustă a variance ratio-ului

- Reperul $\mathrm{VR}(q) = 1$ este valabil pentru incremente necorelate chiar dacă dispersia lor condiționată variază, în condițiile RW3 precizate; banda robustă este construită pentru această ipoteză nulă.
- $\hat{\theta}(q)$ estimează dispersia lui $\sqrt{T}\,(\widehat{\mathrm{VR}}(q) - 1)$; cînd variațiile mari urmează altor variații mari, crește, iar banda se lărgește.
- Banda este punctuală: privește un singur orizont, nu toate orizonturile simultan.
- Formula și condițiile de validitate

De ce banda robustă este mai largă: verificare numerică

- Pentru $q = 2$: $z = \sqrt{T}\,(\widehat{\mathrm{VR}}(2) - 1)$ sub RW1, iar $z^* = \sqrt{T}\,(\widehat{\mathrm{VR}}(2) - 1)/\sqrt{\hat{\theta}(2)}$, cu $\hat{\theta}(2) = \hat{\delta}_1$.
- $\hat{\delta}_1$ tinde la 1 sub ipoteza i.i.d. și crește cînd variațiile mari urmează altor variații mari.
- Exemplu ipotetic: $T = 400$, $\widehat{\mathrm{VR}}(2) = 0{,}90$, deci $z = 20 \times (-0{,}10) = -2{,}0$: respingere la 5%.
- Dacă gruparea volatilității dă $\hat{\delta}_1 = 4$: $z^* = -2{,}0/\sqrt{4} = -1{,}0$, fără respingere; banda din jurul lui 1 este de două ori mai largă.
- S&P 500, aceleași formule: $z = -8{,}12$, dar $z^* = -3{,}64$: mai mic în valoare absolută, dar tot o respingere.

Profilul variance ratio-ului (1/2)



Profilul variance ratio-ului (2/2)

- $\widehat{\mathrm{VR}}(q)$ pentru $q = 2, \ldots, 60$
- zona hașurată: banda robustă de 95% în jurul lui 1, din $\hat{\theta}(q)$, construită pentru RW3 (increment necorelate, cu dispersie care se poate schimba)
- S&P 500 la cele patru orizonturi testate: inversare, în afara benzii la $q = 2, 5, 10$ și în interiorul ei la $q = 20$
  - $\widehat{\mathrm{VR}}(2) = 0{,}901$ și $\widehat{\mathrm{VR}}(5) = 0{,}830$
  - $\widehat{\mathrm{VR}}(10) = 0{,}767$ și $\widehat{\mathrm{VR}}(20) = 0{,}753$
- BET la aceleași orizonturi: persistență care se acumulează odată cu creșterea lui q, în afara benzii la toate patru
  - $\widehat{\mathrm{VR}}(2) = 1{,}108$ și $\widehat{\mathrm{VR}}(5) = 1{,}173$
  - $\widehat{\mathrm{VR}}(10) = 1{,}225$ și $\widehat{\mathrm{VR}}(20) = 1{,}377$
- $q = 60$, circa trei luni bursiere, este o extensie descriptivă: nu face parte din cele patru orizonturi testate
  - S&P 500: $\widehat{\mathrm{VR}}(60) = 0{,}674$
  - BET: $\widehat{\mathrm{VR}}(60) = 1{,}644$
- Bitcoin: în interiorul benzii pînă la circa o lună
- EUR/RON: persistența pe termen scurt specifică unui regim de managed float
- Banda se lărgește odată cu creșterea lui q: curba se poate abate de la reper fără ca abaterea să fie semnificativă
- Sensul abaterii nu constituie, singur, o dovadă statistică

MFM_ch2_variance_ratio

Verificare: tipare și incertitudine

- De ce poate induce în eroare banda i.i.d. în prezența volatility clustering?
- O autocorelație pozitivă implică profit după costuri?
- Ce sugerează un variance ratio sub unu?
- Aplicare: estimarea VR rămîne aceeași, dar eroarea standard se dublează. Ce se întîmplă cu o statistică de modul 2,4 și decizia bilaterală la 5%?
- Verifică raționamentul

Răspunsuri: tipare și incertitudine

- Eroarea standard i.i.d. ignoră dependența din pătratele randamentelor.
- Nu: mai contează mărimea efectului, riscul, implementarea și costurile.
- Sugerează inversare pe orizontul ales; semnificația cere inferență validă.
- Modulul statisticii scade la 1,2; nu mai depășește 1,96. Efectul estimat rămîne același, dar dovezile sînt mai slabe.
- Continuă cu pasul următor

3. Prognoza trebuie să funcționeze pe date noi

- Separă datele de estimare de cele pe care evaluezi prognoza.
- Compară erorile pătratice cu cele ale unui reper precizat.
- Separă acuratețea prognozei de profitul după risc și costuri.
- Cuprins

Ce informație intră într-o prognoză?

- Un predictor este o variabilă observabilă folosită pentru a prognoza un randament viitor.
- Aici dp este logaritmul raportului dividend–preț. Dividendele sînt plăți în numerar către acționari.
- Datele despre dividende sînt interpolate: exemplul este pseudo-out-of-sample, nu complet în timp real.
- Estimarea regresiei și bias

Cum comparăm prognozele out-of-sample

OS: Out-of-Sample — în afara selecției de estimare.

- $R^2_{OS} = 1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t (r_t - \bar{r}_t)^2$.
- $\hat{r}_t$: prognoza modelului; $\bar{r}_t$: prognoza mediei istorice pe aceleași date disponibile.
- Scor pozitiv: erori pătratice mai mici decît reperul pe selecția de evaluare.
- Scorul pozitiv singur nu dovedește semnificația statistică sau profitul.
- Formula Clark–West și detaliile estimării

Evaluarea prognozei: exemplu numeric

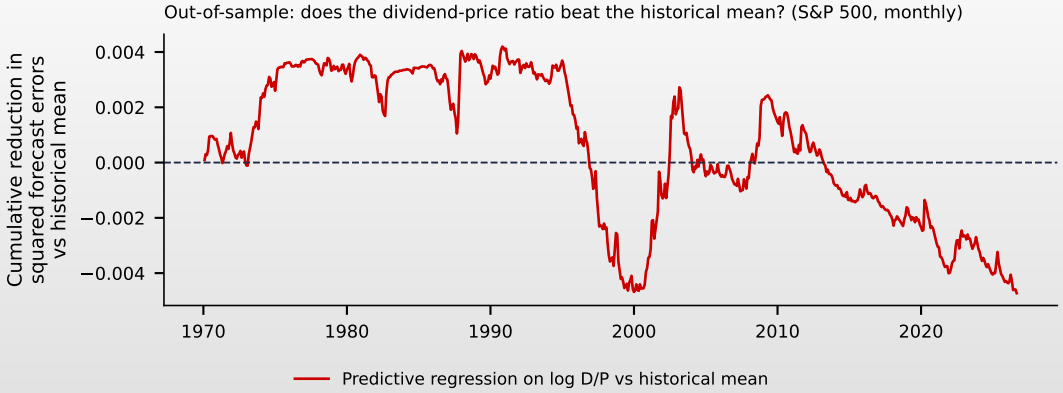
MSPE: Mean Squared Prediction Error — media pătratelor erorilor de prognoză.

- In-sample evaluează observațiile folosite la estimare
  - out-of-sample evaluează observații care nu au intrat în estimare.
- MSPE este media erorilor de predicție la pătrat: erori de 1 și 3 puncte procentuale dau $(1^2 + 3^2)/2 = 5$ puncte procentuale la pătrat.
- Dacă MSPE al reperului este 4, iar al predictorului 3, $R^2_{OS} = 1 - 3/4 = 25\%$: erorile pătratice scad cu un sfert.
- Modelele imbricate (nested) se includ unul în altul: anularea pantei reduce modelul cu intercept și predictor la modelul doar cu intercept.

Cum se construiesc prognozele

- O expanding window reestimează modelul în fiecare lună folosind numai observațiile anterioare lunii prognozate.
- Reperul folosește media istorică a acelorași observații disponibile.
- Regresiile predictive și bias-ul adaugă testul Clark–West și restricțiile Campbell–Thompson.

Raportul dividend–preț: prognoze în afara selecției



MFM_ch2_predictability

Cum citim graficul erorilor pătratice cumulate

- Fiecare lună t, începînd din 1970, adaugă $(r_t - \bar{r}_t)^2 - (r_t - \hat{r}_t)^2$: eroarea pătratică a mediei istorice minus cea a prognozei cu *dp*; curba este suma cumulată, în unități de randament logaritmic fracționar la pătrat.
- Un segment ascendent: în acele luni prognoza cu *dp* a fost mai precisă decît media istorică; un segment descendent: mai puțin precisă. O scădere este o pierdere de precizie, nu o pierdere din tranzacționare.
- Ultima valoare este $\sum_t (r_t - \bar{r}_t)^2 - \sum_t (r_t - \hat{r}_t)^2$, deci are semnul lui R^2_{OS}: peste zero, $R^2_{OS} > 0$; sub zero, $R^2_{OS} < 0$.
- Dacă o curbă s-ar termina la $-0{,}002$, prognozele cu *dp* ar avea cu 0,002 mai multă eroare pătratică cumulată decît reperul: $R^2_{OS} < 0$.
- Erorile de prognoză, în puncte procentuale: media istorică $2, 1, 3$; prognoza cu *dp* $1, 2, 3$.
- Termenii lunari $4 - 1 = 3$, $1 - 4 = -3$, $9 - 9 = 0$: curba urcă la 3, coboară înapoi la 0 și rămîne acolo.
- Ambele sume de erori pătratice sînt 14, deci $R^2_{OS} = 1 - 14/14 = 0$: niciuna dintre prognoze nu cîștigă pe această selecție.
- Rezultatele pentru curba S&P 500: R^2_{OS}, testul Clark–West și episodul anilor 1990

Verificare: prognoze pe date noi

- Ce date pot intra într-o prognoză făcută azi?
- Ce spune un scor out-of-sample negativ despre comparația cu reperul?
- De ce poate o ajustare excelentă în selecție să eșueze pe date noi?
- Aplicare: poate o strategie să aibă profit, dar prognoza ei să aibă R-pătrat out-of-sample negativ? Explică cele două repere.
- Verifică raționamentul

Răspunsuri: prognoze pe date noi

- În estimare intră doar informația disponibilă la momentul prognozei.
- Modelul are erori pătratice mai mari decît reperul pe acea selecție.
- Modelul poate ajusta zgomotul sau folosi informație indisponibilă la momentul prognozei.
- Da: R-pătrat out-of-sample negativ înseamnă erori pătratice mai mari decît ale mediei istorice. Profitul pozitiv poate veni din expunerea la piață; nu dovedește prognoze superioare sau profit ajustat la risc după costuri.
- Continuă cu pasul următor

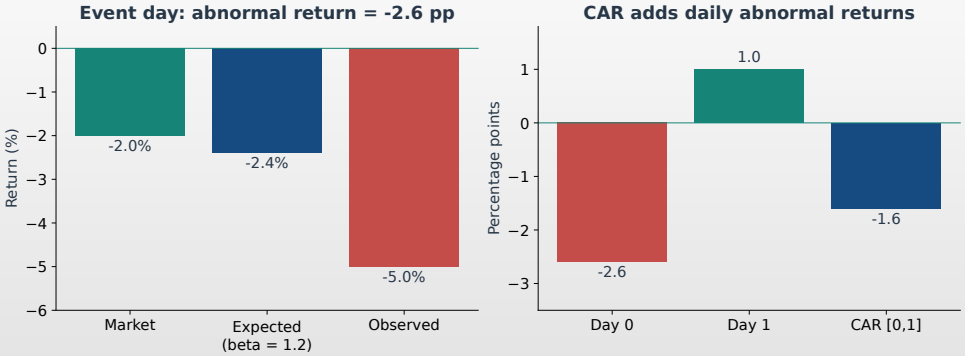
4. Cum reacționează prețurile la știri

- Separă randamentul observat, cel așteptat și cel anormal.
- Interpretează cumulative abnormal return (CAR, randamentul anormal cumulat) pentru o fereastră de eveniment precizată.
- Deosebește reacția măsurată de dovada cauzei ei.
- Cuprins

Event study: mărimile economice

- Un stock split schimbă numărul acțiunilor și prețul unitar fără să schimbe mecanic averea: o acțiune de 100 devine două de 50 la un split 2-la-1.
- Beta de piață măsoară sensibilitatea: cu intercept zero și beta 1,2, un randament al pieței de -2% prognozează $-2{,}4\%$.
- Abnormal return (AR, randamentul anormal) este randamentul observat minus cel prezis de reper: dacă acțiunea are randament -5%, $AR = -5 - (-2{,}4) = -2{,}6$ puncte procentuale.
  - În studiile de eveniment, AR înseamnă abnormal return, nu modelul autoregresiv AR(p).
- CAR adună valorile AR din fereastra evenimentului: $-2{,}6$ azi și $+1$ mîine dau $-1{,}6$ puncte procentuale.

Abnormal return și CAR: exemplu



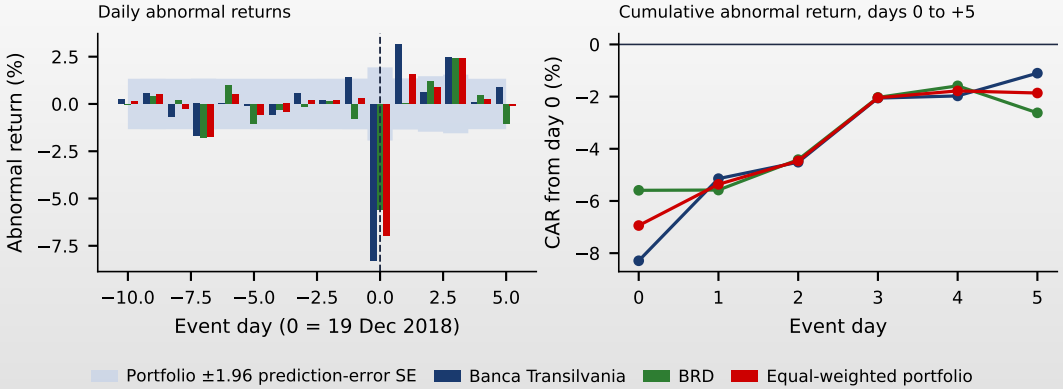
Reperul explică o parte din randamentul observat. Diferența este abnormal return (AR); CAR adună aceste diferențe în zilele alese.

Metoda studiului de eveniment



- Fama, Fisher, Jensen & Roll (1969): cît de repede sînt încorporate în prețuri știrile publice (divizări de acțiuni)?
- Modelul de piață: $r_{i,t} = a_i + b_i r_{m,t} + \varepsilon_{i,t}$, $r_{m,t}$ randamentul pieței
- Randamentul anormal $AR_{i,t} = r_{i,t} - \hat{a}_i - \hat{b}_i r_{m,t}$
- Randamentul anormal cumulat $CAR_i[\tau_1, \tau_2] = \sum_{t=\tau_1}^{\tau_2} AR_{i,t}$
- a_i, b_i: termenul liber și beta de piață al firmei i, estimate în fereastra de estimare
- $\hat{\sigma}_\varepsilon$: abaterea standard a reziduurilor din aceeași fereastră, $[\tau_1, \tau_2]$: zilele însumate
- Test de primă aproximare: $t = CAR_i/(\hat{\sigma}_\varepsilon\sqrt{L})$, L lungimea ferestrei evenimentului MacKinlay (1997)
  - AR: randamentul peste cel prezis de mișcarea pieței, iar $\sqrt{L}$ apare pentru că abaterea standard a unei sume de L reziduuri independente crește cu $\sqrt{L}$
- Pentru o știre neanticipată, eficiența implică un salt în ziua 0, fără drift și fără inversare predictibilă ulterior
- Datele zilnice pot arăta doar absorbția în aceeași zi, iar viteza măsurată în microsecunde necesită date intrazilnice (Capitolul 10)
- Literatura: ▸ Anexă

Exemplu rezolvat: taxa bancară din decembrie 2018 (1/2)



MFM_ch2_seminar

Exemplu rezolvat: taxa bancară din decembrie 2018 (2/2)

- Taxa a fost anunțată în seara de 18 dec. 2018; ziua 0 = 19 dec.
- Banca Transilvania (TLV), BRD și portofoliul lor egal ponderat față de BET (Seminarul 2, B9; context opțional: Seminarul 0, B7)
- TLV: $\hat{b} = 1{,}18$, $\hat{\sigma}_\varepsilon = 0{,}83\%$, $AR_0 = -8{,}3\%$ ($t = -10{,}0$, formula de primă aproximare)
  - Ziua 0 a fost și o zi extremă pentru piață (BET $-11{,}9\%$); dacă ținem cont de aceasta, t devine $-6{,}85$: inferența în studiile de eveniment
  - $CAR[0,+5] = -1{,}1\%$ ($t = -0{,}54$, primă aproximare), deoarece $CAR[+1,+5] = +7{,}2\%$ ($t = 3{,}82$ cu dispersia erorii de predicție; formula de primă aproximare dă 3,87)
- Cea mai mare parte a scăderii din ziua 0 este recuperată în aceeași săptămînă: fie o **reacție excesivă**, incompatibilă cu eficiența semi-tare, fie efectul unor știri ulterioare despre forma finală a ordonanței
- Un singur eveniment nu le poate deosebi

MFM_ch2_seminar

Verificare: reacția la știri

- Randamentul observat este -5%, cel așteptat $-2{,}4\%$. Care este randamentul anormal?
- De ce trebuie precizată fereastra de eveniment?
- Ar putea alt anunț explica aceeași mișcare?
- Verifică raționamentul

Răspunsuri: reacția la știri

- Randamentul anormal este $-2{,}6$ puncte procentuale.
- CAR adună randamentele anormale doar pentru datele alese.
- Da: știrile suprapuse sînt o explicație alternativă, deci reacția singură nu dovedește cauzalitatea.
- Continuă cu pasul următor

5. Ce concluzii rezistă verificării?

- Ține cont de numărul de ipoteze căutate.
- Precizează ce arată rezultatul și ce rămîne nedovedit.
- Alege o verificare care ar putea infirma concluzia.
- Cuprins

Calendar effects și data snooping

- Un calendar effect este o diferență de randament mediu asociată unei zile sau luni.
- Turn of the month (TOM): ultima zi de tranzacționare din lună și primele trei ale lunii următoare.
- Efectul lunii ianuarie compară randamentele din ianuarie cu cele din celelalte luni.
- Data snooping înseamnă selectarea unui tipar după căutarea multor alternative pe aceleași date.

Cum citești tabelul de calendar

HAC: Heteroskedasticity and Autocorrelation Consistent — erori standard care permit dispersie variabilă și autocorelație.

- Cele 15 teste combină cinci piețe cu trei efecte: ziua săptămînii, ianuarie și TOM.
- Erorile standard HAC permit heteroskedasticity și autocorelație; statistica t împarte efectul estimat la eroarea lui standard.
- Un punct de bază (bp) este o sutime de punct procentual.
- Specificația regresiei și alte anomalii

Efectul lunii ianuarie și efectul schimbării lunii

Piața	Diferența în ianuarie (%/lună)	t_{HAC}	Diferența TOM (bp/zi)	t_{HAC}	p
S&P 500	−0,66	−0,80	3,2	0,93	0,3539
BET (România)	3,48	1,49	17,3	3,62	0,0003
Euro Stoxx 50	−0,30	−0,29	5,1	1,21	0,2266
WIG20 (Polonia)	0,53	0,40	8,2	1,73	0,0841
BUX (Ungaria)	2,66	2,25	15,1	3,63	0,0003

- TOM: randamentul suplimentar este +17,3 bp pe zi pentru BET și +15,1 bp pentru BUX, ambele cu $|t| > 3{,}5$
- Pentru S&P 500 este doar +3,2 bp
- Efectul lunii ianuarie: mare, dar estimat imprecis pentru BET ($t = 1{,}49$)
- BUX, cu $t = 2{,}25$, este singura piață pentru care p-value-ul efectului lunii ianuarie este sub 0,05
- Am efectuat 15 teste (5 piețe $\times$ 3 efecte): care rămîn semnificative după o corecție pentru testare multiplă?

Testare multiplă: exemplu simplu

FWER: Family-Wise Error Rate — probabilitatea cel puțin unei respingeri false în familia de teste.

- FWER este probabilitatea a cel puțin unei respingeri false într-o familie de teste
  - zece teste separate de 5% nu o controlează în general la 5%.
- Pentru trei p-values $0{,}01, 0{,}03, 0{,}04$, Bonferroni compară fiecare cu $0{,}05/3 \approx 0{,}0167$: doar primul duce la respingere.
- Holm ordonează p-values: $0{,}01 < 0{,}05/3$ duce la respingere
  - $0{,}03 > 0{,}05/2$ oprește procedura, deci testele rămase nu resping.
- Formula $1 - (1 - \alpha)^m$ pentru cel puțin o respingere falsă presupune m teste independente cu ipoteze nule adevărate
  - dependența schimbă probabilitatea.

Testarea multiplă: Bonferroni și Holm

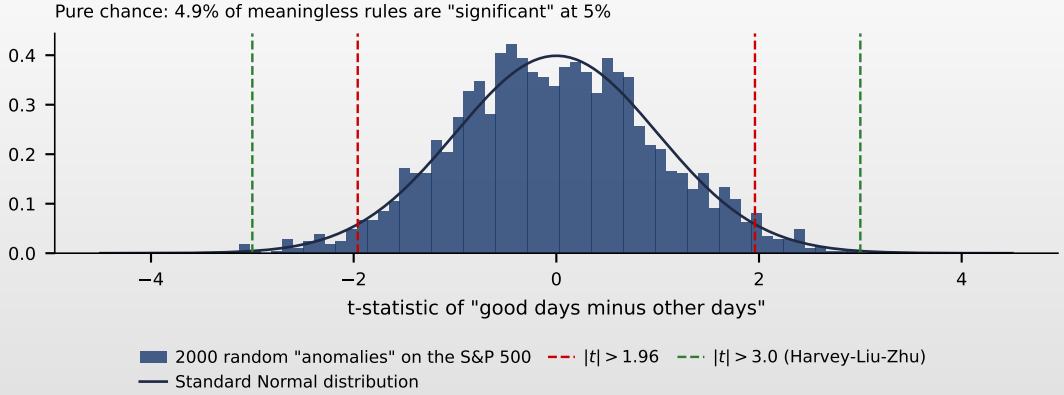
- **FWER**: probabilitatea a cel puțin unei respingeri false
- Cu M teste independente la nivelul α, FWER $= 1-(1-\alpha)^M$
  - $M = 15$, $\alpha = 5\%$: FWER $= 53{,}7\%$, aproximativ probabilitatea unui „cap" la aruncarea unei monede
- **Bonferroni**: respingem doar dacă $p_i < \alpha/M$
- Garantează FWER $\leq \alpha$ pentru orice dependență
- **Holm**: ordonăm $p_{(1)} \leq \cdots \leq p_{(M)}$
- Respingem cît timp $p_{(j)} < \alpha/(M-j+1)$, ne oprim la prima nerespingere
  - Holm oferă aceeași garanție și are o putere cel puțin egală cu cea a procedurii Bonferroni
- Cele 15 teste de calendar: pragul Bonferroni 0,0033
- 3 respingeri fără corecție, dintre care 2 rămîn semnificative după Holm (schimbarea lunii la BET și BUX)
- Holm se oprește la ianuarie pentru BUX
- Exercițiul B4 din seminar parcurge ordonarea pas cu pas
- Metodele bootstrap care țin cont de dependența dintre teste: vezi Anexa

Holm pe cele 15 p-value-uri de calendar

Piața	Zilele săptămînii, medii egale	Ianuarie	TOM
S&P 500	0,8263	0,4257	0,3539
BET (România)	0,3052	0,1368	0,0003
Euro Stoxx 50	0,6319	0,7738	0,2266
WIG20 (Polonia)	0,2262	0,6865	0,0841
BUX (Ungaria)	0,9327	0,0245	0,0003

- Cele mai mici două: TOM la BET și la BUX, sub $0{,}05/15 = 0{,}0033$ și $0{,}05/14 = 0{,}0036$: ambele respinse.
- A treia: ianuarie la BUX, $p = 0{,}0245$, peste $0{,}05/13 = 0{,}0038$: Holm se oprește. Fiind sub 0,05, este a treia respingere fără corecție.
- p-value-uri bilaterale; ianuarie și TOM din t HAC cu reper Normal; zilele săptămînii: test Wald cu patru restricții de egalitate (χ^2_4).

„Anomalii” produse de hazard (1/2)



MFM_ch2_multiple_testing

„Anomalii" produse de hazard (2/2)

- 2 000 de reguli arbitrare pe S&P 500: fiecare numește „bune" 20% din zile alese aleator și testează diferența dintre randamentul mediu al zilelor „bune" și cel al celorlalte zile
- 4,9% au $|t| > 1{,}96$, în acord cu nivelul nominal de 5%
- cel mai mare $|t|$ este 3,19
- Cine încearcă multe reguli și o raportează pe cea mai bună va găsi foarte probabil o „anomalie semnificativă"
- Data snooping în regulile de tranzacționare: Sullivan, Timmermann & White (1999)
- Harvey, Liu & Zhu (2016) propun $|t| > 3{,}0$ pentru un factor nou
- aici trec 0,25% din regulile aleatoare. Un prag mai înalt este o euristică, nu un substitut pentru definirea familiei de teste încercate

MFM_ch2_multiple_testing

Verificare: teste multiple și concluzii

- De ce schimbă testarea multor reguli interpretarea unui p-value mic?
- Nerespingerea dovedește eficiența?
- Ce selecție nouă sau verificare de robustețe ai cere?
- Verifică raționamentul

Răspunsuri: teste multiple și concluzii

- Căutarea multor reguli creează mai multe ocazii de respingere falsă.
- Nu: puterea limitată și alternativa aleasă limitează concluzia.
- Un răspuns bun numește verificarea și explică ce slăbiciune a rezultatului verifică.
- Recapitulare

Ce trebuie să poți explica

- Pentru fiecare rezultat, precizează informația, ipoteza nulă și reperul.
- Explică incertitudinea înainte să formulezi o concluzie economică.
- În seminar, justifică un calcul și verifică critic o interpretare.
- La prima lectură te poți opri aici.
- Teme

Teme pentru studiu suplimentar

- ⊡ Date și convenții
- ⊡ Fair game, evaluare și rational bubbles
- ⊡ Construcția testelor și alternative
- ⊡ Regresii predictive și bias
- ⊡ Memorie lungă și eficiență variabilă
- ⊡ Inferență în event studies
- ⊡ Anomalii și explicații comportamentale
- ⊡ Machine learning și proiectarea cercetării
- ⊡ Sinteză și referințe tehnice
- ⊡ Cuprins

Datele folosite în acest capitol (1/2)

- Ce observații și calendare de tranzacționare produc rezultatele?
- Reia: randamente și informație
- Teme
- Cuprins

BNR: Banca Națională a României.

- 16 serii zilnice pînă la 18 septembrie 2026
- volumul selecțiilor: vezi Anexa
  - 13 indici bursieri din 2000: 4 din piețe dezvoltate (S&P 500, Euro Stoxx 50, Nikkei 225, Hang Seng), 9 din piețe emergente sau de frontieră (BET, WIG20, BUX, PX, BIST 100, Bovespa, IPC, Nifty 50, Shanghai)
  - Bitcoin (din 2014; din 2011 în analiza anuală a criptoactivelor), Ethereum (din 2016) și EUR/RON, cursul de referință BNR (din iulie 2005)
- Randamente logaritmice zilnice $r_t = \ln P_t - \ln P_{t-1}$, fiecare serie pe propriul calendar
  - P_t: prețul de închidere (nivelul indicelui, cursul de schimb) din ziua t
  - ln: logaritmul natural
- Indici bursieri: doar zilele lucrătoare

Datele folosite în acest capitol (2/2)

- Eliminăm observațiile cu același preț de închidere ca în ziua precedentă; de obicei, ele corespund unor zile nelucrătoare completate cu ultimul preț disponibil
  - regula elimină și rarele zile reale cu randament zero (S&P 500: 3 din circa 6 700 de zile)
  - statisticile testelor se modifică cu mai puțin de 0,05
- Criptoactivele se tranzacționează 7 zile din 7: 365 de observații pe an
- Analizele care folosesc mai multe serii simultan (de ex. studiile de eveniment) aliniază prețurile pe zilele comune de tranzacționare înainte de calculul randamentelor

Arbitraj, poziții long și short

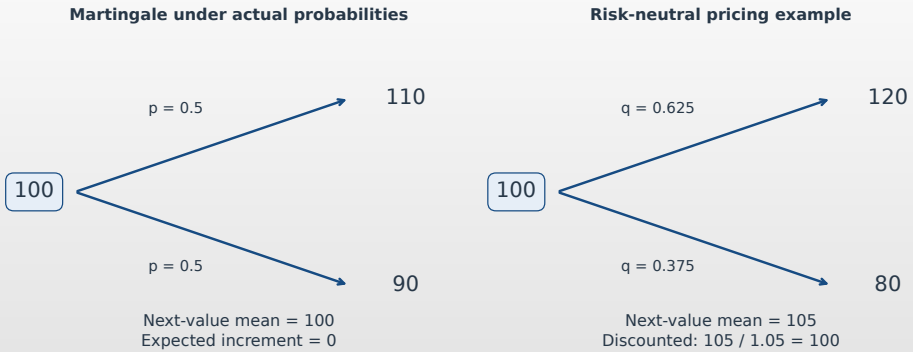
- Cum se leagă fair game, evaluarea și rational bubbles?
- Reia: randamente și informație
- Teme
- Cuprins

- Arbitrajul pur este o strategie fără plată inițială netă pozitivă, fără pierdere posibilă și cu un cîștig pozitiv în cel puțin o stare posibilă.
- Exemplu fără costuri: cumperi simultan cu 100 și vinzi cu 101 același activ livrabil
  - diferența fixată este 1.
- O poziție long cîștigă la creșterea prețului
  - un short sale împrumută și vinde activul, apoi îl răscumpără: vînzarea la 100 și răscumpărarea la 90 aduc 10 înainte de costuri.
- Tranzacționarea relative-value este riscantă cînd convergența nu este sigură: un ecart de preț de 20 poate crește la 30, cerînd garanții suplimentare (margin) și închiderea forțată a poziției.

Actualizare și risk-neutral measure

- Actualizarea exprimă o sumă viitoare în valoare de azi: 105 plătibili peste un an valorează $105/1{,}05 = 100$ la o rată de 5%.
- Măsura neutră la risc (risk-neutral measure) folosește probabilități de evaluare sub care prețurile tranzacționate, cu dividende incluse și actualizate, sînt martingale într-un model fără arbitraj.
- Exemplu fără dividende: acțiune 100, preț peste un an 120 sau 80, dobîndă fără risc 5%
  - probabilitatea de evaluare $q = 0{,}625$ dă $q\,120 + (1-q)80 = 105$.
- Acest q nu trebuie să coincidă cu probabilitatea reală de creștere: probabilitățile de evaluare nu prognozează frecvențe.

Probabilități și medii condiționate



Stînga: media condiționată reală rămîne 100. Dreapta: probabilitățile de evaluare dau 105, cu valoarea actualizată 100.

Fair game și martingal

- **Fair game** pentru randamentele în exces: $\mathbb{E}[r_{t+1} - \mu_t \mid \mathcal{I}_t] = 0$
  - $\mathcal{I}_t$: informația disponibilă la sfîrșitul zilei t
  - $\mathbb{E}[\cdot \mid \mathcal{I}_t]$: media condiționată de această informație
  - μ_t: randamentul cerut (de echilibru), compensația pentru risc
  - în cuvinte: randamentul peste μ_t nu poate fi prognozat din $\mathcal{I}_t$
- **Martingal**: un proces pentru care valoarea așteptată la momentul următor, dată fiind informația din trecut, este egală cu valoarea curentă
  - Cu un randament simplu cerut constant m, prețul cu dividendele reinvestite, actualizat cu m, $P_t/(1+m)^t$, este un martingal Campbell, Lo & MacKinlay (1997)
  - Actualizarea cu dobînda fără risc dă un martingal doar sub măsura neutră la risc
  - P_t însuși este martingal doar dacă $m = 0$, adică randamentul **simplu** așteptat este nul, nu randamentul logaritmic așteptat

Termenul lui Jensen: de ce diferă mediile

- Logaritmul este concav: media logaritmilor este mai mică decît logaritmul mediei, cu egalitate pentru rezultate constante.
- Randamentele simple egal probabile de $+10\%$ și -10% au media zero.
- Media randamentului logaritmic este $\frac{1}{2}\ln(1{,}1) + \frac{1}{2}\ln(0{,}9) = \frac{1}{2}\ln(0{,}99) \approx -0{,}00503$.
- Pe o traiectorie cu o creștere și o scădere, averea 100 devine $100(1{,}1)(0{,}9) = 99$: media aritmetică zero nu păstrează averea acumulată.

Prețuri, log-prețuri și informație

- „$\mathbb{E}[P_{t+1} \mid \mathcal{I}_t] = P_t$" și „$\mathbb{E}[\ln(P_{t+1}/P_t) \mid \mathcal{I}_t] = \mu$" sînt restricții diferite
  - Diferă prin actualizare și prin termenul lui Jensen: $\mathbb{E}[\ln(1+R)] \approx \mathbb{E}[R] - \mathrm{Var}(R)/2$ pentru randamente mici (neglijînd $\mathbb{E}[R]^2$)
  - $R = P_{t+1}/P_t - 1$: randamentul simplu
  - $\ln(1+R)$: randamentul logaritmic
  - media randamentului logaritmic este mai mică decît media randamentului simplu cu circa jumătate din dispersie
- Consecință: $\mathrm{corr}(\varepsilon_{t+1}, g(\mathcal{I}_t)) = 0$ pentru orice funcție g a informațiilor din trecut, $\varepsilon_{t+1} = r_{t+1} - \mu_t$
  - ε_{t+1}: partea neașteptată a randamentului
  - în cuvinte, nicio informație din trecut nu este corelată cu surpriza de mîine
  - În particular, toate autocorelațiile $\rho_k = \mathrm{corr}(r_t, r_{t-k})$, $k \geq 1$, sînt zero cînd $\mu_t = \mu$
  - k: lagul, în zile

Rational bubble: definiția

- Valoarea fundamentală: valoarea actualizată a fluxurilor de numerar așteptate de la activ.
  - Pentru o acțiune, aceste plăți sînt dividendele.
  - Actualizarea exprimă plățile viitoare în banii de astăzi.
- O **rational bubble** (bulă rațională) este o componentă pozitivă a prețului peste valoarea fundamentală.
  - Este susținută de anticiparea revînzării.
  - $P_t = P_t^* + B_t$: P_t este prețul, P_t^* valoarea fundamentală, iar B_t componenta de bulă.
- Așteptările raționale sînt compatibile cu modelul, inclusiv cu riscul de crah.
  - Ele nu implică un cîștig sigur.

Valoare fundamentală, rational bubble și fad

- Cu un randament simplu cerut constant m, condiția de fair game este $\mathbb{E}[P_{t+1} + D_{t+1} \mid \mathcal{I}_t] = (1+m)\,P_t$
- D_{t+1}: fluxul de numerar (dividendul) plătit în $t+1$
  - Valoarea fundamentală $P_t^* = \mathbb{E}\big[\sum_{j\geq 1} D_{t+j}/(1+m)^j \mid \mathcal{I}_t\big]$: valoarea actualizată a fluxurilor de numerar așteptate, la randamentul cerut
  - Eroarea de preț $B_t = P_t - P_t^*$
  - P_t^* satisface aceeași recurență
  - prin scădere: $P_t = P_t^* + B_t$, cu $\mathbb{E}[B_{t+1} \mid \mathcal{I}_t] = (1+m)\,B_t$
- Condiția de fair game nu impune egalitatea dintre preț și valoarea fundamentală; permite și o **rational bubble**
  - O abatere $B_t \neq 0$ este compatibilă cu modelul doar dacă, în medie, crește în ritmul randamentului cerut m (Capitolul 17)
  - O abatere care revine la medie (fad) face ε_{t+1} predictibil și încalcă condiția de fair game, deși testele pe orizont scurt au o capacitate redusă de a detecta această abatere Summers (1986)
- Restricția privește doar media condiționată: dispersia nu este restricționată, iar volatilitatea poate fi predictibilă (Capitolul 1)

Rational bubble: condiția de creștere în medie

- m: randamentul simplu cerut pe perioadă, presupus constant.
  - $\mathcal{I}_t$: informația disponibilă la momentul t.
  - $\mathbb{E}[\cdot \mid \mathcal{I}_t]$: media condiționată de această informație.
- Componenta de bulă trebuie să satisfacă $\mathbb{E}[B_{t+1} \mid \mathcal{I}_t] = (1+m)B_t$, recurența obținută mai sus din condiția de fair game.
  - În cuvinte: ritmul ei de creștere așteptat este egal cu randamentul cerut.
  - Dacă este posibil un crah, creșterea condiționată de supraviețuire trebuie să fie mai mare.
- Un fad este o abatere temporară a prețului care se așteaptă să dispară: un ecart de 20 așteptat să scadă la 10 diferă de o rational bubble care crește în medie cu rata cerută.

Rational bubble: exemplu numeric

- O acțiune plătește 10 lei la sfîrșitul fiecărui an, la nesfîrșit.
  - Primul dividend se plătește peste un an.
  - Randamentul cerut constant este $m = 10\%$; valoarea fundamentală este $P_t^* = 10/0{,}10 = 100$ lei.
- Astăzi $P_t = 120$ lei, deci $B_t = 20$ lei.
  - Fără crah, $B_{t+1} = 1{,}1 \times 20 = 22$ lei.
  - După plata dividendului de anul viitor, valoarea fundamentală rămîne 100 lei; prețul este deci 122 lei.
- Randamentul simplu total este $(122 + 10 - 120)/120 = 10\%$.

Rational bubble: ce se întîmplă în cazul unui crah?

- Bula inițială este $B_t = 20$ lei, iar randamentul cerut este $m = 10\%$.
  - Probabilitatea de supraviețuire este $\pi = 0{,}8$; probabilitatea de crah este $1 - \pi = 0{,}2$.
  - În cazul unui crah, bula devine zero; investitorii cunosc probabilitățile.
- Condiția de creștere cere o bulă așteptată de $(1 + m)B_t = 22$ lei.
  - Condiționat de supraviețuire: $B_{t+1} = 22/0{,}8 = 27{,}5$ lei.
  - Verificare: $0{,}8 \times 27{,}5 + 0{,}2 \times 0 = 22$.
  - Creșterea condiționată este $27{,}5/20 - 1 = 37{,}5\%$.
- Mecanismul crahului: Blanchard & Watson (1982), Bubbles, Rational Expectations and Financial Markets.
- Prețul de cumpărare este 120 lei; dividendul de la sfîrșitul anului este 10 lei.
- Supraviețuire: prețul după plata dividendului este 127,5 lei.
  - Randament simplu: $(127{,}5 + 10 - 120)/120 \approx 14{,}6\%$.
- Crah: prețul scade la valoarea fundamentală, 100 lei.
  - Randament simplu: $(100 + 10 - 120)/120 \approx -8{,}3\%$.
- Randament așteptat: $0{,}8 \times (17{,}5/120) + 0{,}2 \times (-10/120) = 10\%$.
  - Randamentul așteptat respectă fair game; randamentul realizat poate fi diferit.

Rational bubble și no-bubble condition

- Fair game restricționează randamentul așteptat în perioada următoare.
- Condiția suplimentară **no-bubble condition** (condiția de absență a bulei) este $\lim_{k\to\infty} \frac{\mathbb{E}[P_{t+k} \mid \mathcal{I}_t]}{(1+m)^k} = 0$.
  - k: numărul de perioade pînă la revînzare.
  - Valoarea actualizată a prețului așteptat de revînzare tinde la zero cînd orizontul crește.
  - Atunci prețul curent este susținut integral de fluxurile de numerar.
- Exemplele numerice verifică recurența de evaluare pe o perioadă.
  - Existența într-un echilibru economic cere ipoteze suplimentare: Tirole (1985), Asset Bubbles and Overlapping Generations.

Paradoxul Grossman–Stiglitz

- Colectarea informației este costisitoare (analiști, date, putere de calcul)
- Dacă prețurile ar reflecta **toată** informația, nimeni nu ar fi remunerat pentru colectarea ei Grossman & Stiglitz (1980)
  - Atunci nimeni nu ar colecta-o, iar prețurile nu ar mai putea să o reflecte
- Soluția: un **grad de ineficiență de echilibru**, suficient pentru a acoperi costurile celor informați
- Piețele mari și lichide, cu informație ieftină și costuri mici, ar trebui să fie mai aproape de eficiență: o predicție pentru comparația noastră între piețele dezvoltate, cele emergente și piețele de criptoactive
- Eficiența nu exclude nici bulele: spune doar că momentul lor este greu de anticipat (Capitolul 17)

Ipotezele de mers aleator RW1, RW2, RW3

- Logaritmul prețului, $p_t = \ln P_t$, cu $p_t = \mu + p_{t-1} + \varepsilon_t$
- Cele trei versiuni diferă prin ipotezele asupra lui ε_t Campbell, Lo & MacKinlay (1997)
  - μ: driftul, randamentul logaritmic zilnic așteptat
  - ε_t: șocul zilei t, cu media 0
  - deci $r_t = p_t - p_{t-1} = \mu + \varepsilon_t$
- **RW1**: ε_t i.i.d., independente și identic distribuite (cea mai restrictivă; exclude volatility clustering)
  - Respinsă de faptele stilizate din Capitolul 1
- **RW2**: ε_t independente, dar nu identic distribuite (dispersia se poate schimba)
- **RW3**: ε_t necorelate: $\mathrm{Cov}(\varepsilon_t, \varepsilon_{t-k}) = 0$, iar $\mathrm{Cov}(\varepsilon_t^2, \varepsilon_{t-k}^2) \neq 0$ este permisă
  - Pentru randamentele observate folosim această ipoteză și teste robuste la heteroscedasticitate

Momente, cozi și aproximații asimptotice

- Ce ipoteze fac testul valid și ce alternative poate detecta?
- Reia: de la tipar la test
- Teme
- Cuprins

- Momentul absolut de ordin k este $\mathbb{E}[|r|^k]$
  - un moment de ordin patru finit cere $\mathbb{E}[r^4] < \infty$, nu doar randamente observate finite.
- Heavy tails permit valori extreme mai des decît reperul Normal
  - distribuția Student t cu patru grade de libertate are dispersie finită, dar moment de ordin patru infinit.
- O aproximație asimptotică descrie comportamentul cînd numărul de observații crește
  - poate fi imprecisă într-o selecție scurtă.
- Condițiile de mixing cer ca blocurile suficient de depărtate să devină aproape independente într-un ritm adecvat
  - randamentele zilnice vecine nu trebuie să fie independente.

Autocorelația și eroarea ei standard robustă

- Autocorelația de selecție: $\hat{\rho}_k = \sum_{t=k+1}^{T} e_t e_{t-k} / \sum_{t=1}^{T} e_t^2$, cu $e_t = r_t - \bar{r}$
  - T: numărul de randamente zilnice
  - $\bar{r}$: media lor
  - k: lagul
  - $\hat{\rho}_k > 0$: persistență, $\hat{\rho}_k < 0$: inversare
- Sub RW1 (i.i.d.): $\mathrm{SE}(\hat{\rho}_k) \approx 1/\sqrt{T}$
- Banda de 95% $\pm 1{,}96/\sqrt{T}$
- Dacă media este imprevizibilă, dar există volatility clustering și momente de ordinul patru finite: $\mathrm{SE}(\hat{\rho}_k) \approx \sqrt{\hat{\tau}_k}$
  - $\hat{\tau}_k = \sum_t e_t^2 e_{t-k}^2 \,/\, \left(\sum_t e_t^2\right)^2$ (dispersia robustă)
  - Cînd există volatility clustering, $\hat{\tau}_k > 1/T$: banda i.i.d. este prea îngustă, iar testele clasice resping ipoteza nulă prea des
  - Toate testele de mai jos folosesc o dispersie care ține cont de acest lucru
- S&P 500: SE i.i.d. = 0,012, SE robustă = 0,027, de peste două ori mai mare

Teste comune și distribuții de referință

- Un test portmanteau combină corelațiile la mai multe laguri într-o singură statistică, în loc să alegem lagul cel mai spectaculos.
- Distribuția hi-pătrat cu m grade de libertate este distribuția sumei pătratelor a m variabile Normale standard independente.
- Pentru zece laguri testate, reperul este aproximativ χ^2_{10} în condițiile precizate
  - 25 depășește valoarea critică de 5%, 18,31.
- Un test Wald verifică în mod similar restricții comune asupra coeficienților
  - egalitatea celor cinci medii zilnice impune patru restricții, $\beta_1 = \beta_2$, $\beta_1 = \beta_3$, $\beta_1 = \beta_4$, $\beta_1 = \beta_5$, deci reperul este χ^2_4, cu valoarea critică de 5% egală cu 9,49.
- Cinci restricții, toate $\beta_d = 0$, ar testa altă ipoteză nulă: media fiecărei zile egală cu zero.

Teste portmanteau: Ljung–Box și versiunea robustă

- Ljung & Box (1978): $Q(m) = T(T+2)\sum_{k=1}^{m} \hat{\rho}_k^2/(T-k) \sim \chi^2_m$ pentru randamente i.i.d.
  - Testează împreună H_0: $\rho_1 = \cdots = \rho_m = 0$
  - m: numărul de laguri
  - χ^2_m: distribuția hi-pătrat cu m grade de libertate
  - Un Q mare duce la respingerea lui H_0
- Versiunea robustă Lobato, Nankervis & Savin (2001): $\tilde{Q}(m) = \sum_{k=1}^{m} \hat{\rho}_k^2/\hat{\tau}_k \to \chi^2_m$ sub RW3 cînd $\hat{\rho}_k$ sînt asimptotic necorelate (condiția de pe slide-ul Statistica z^*, robustă la heteroscedasticitate)
- Trei piețe la $m = 10$ (valoarea critică la 5% este 18,31)
  - S&P 500: $Q = 96{,}3$, dar $\tilde{Q} = 19{,}9$ ($p = 0{,}031$)
  - BET: $Q = 108{,}0$, $\tilde{Q} = 24{,}4$ ($p = 0{,}007$)
  - Bitcoin: $Q = 20{,}2$ ($p = 0{,}028$), dar $\tilde{Q} = 11{,}9$ ($p = 0{,}294$)
- Cu testul robust respingem în continuare ipoteza nulă pentru S&P 500 și BET, dar nu pentru Bitcoin

Testul secvențelor (runs test)

- Neparametric: folosește doar **semnele** randamentelor (randamentele nule sînt ignorate), deci nu este afectat de cozile groase Wald & Wolfowitz (1940)
- O **secvență** (run) este un bloc maximal de semne egale: ++|-|+++ are 3 secvențe (Exercițiul A5 din seminar le numără pe 20 de semne)
- Momentele numărului de secvențe R în ipoteza independenței, cu n_1 semne pozitive și n_2 negative, $n = n_1 + n_2$
  - $\mathbb{E}[R] = \dfrac{2n_1n_2}{n} + 1, \qquad \mathrm{Var}[R] = \dfrac{2n_1n_2(2n_1n_2 - n)}{n^2(n-1)}, \qquad z = \dfrac{R - \mathbb{E}[R]}{\sqrt{\mathrm{Var}[R]}} \approx N(0,1)$
  - R: numărul observat de secvențe, iar $\mathbb{E}[R]$, $\mathrm{Var}[R]$: media și dispersia lui dacă semnele ar fi independente
  - pentru $|z| > 1{,}96$ independența se respinge la 5%
- Prea **puține** secvențe ($z < 0$): semnele persistă
- Prea **multe** ($z > 0$): inversări de semn
- Testul presupune o probabilitate constantă a unei zile pozitive
- Trei piețe: S&P 500 $z = 4{,}34$ (mai multe secvențe, în acord cu $\hat{\rho}_1 < 0$)
- BET $z = -6{,}05$ (mai puține, în acord cu $\hat{\rho}_1 > 0$)
- Bitcoin $z = 2{,}68$, deși $\hat{\rho}_1$ nu este semnificativ
  - semnele și valorile absolute conțin informații diferite, iar rezultatele pentru toate piețele sînt în Anexă

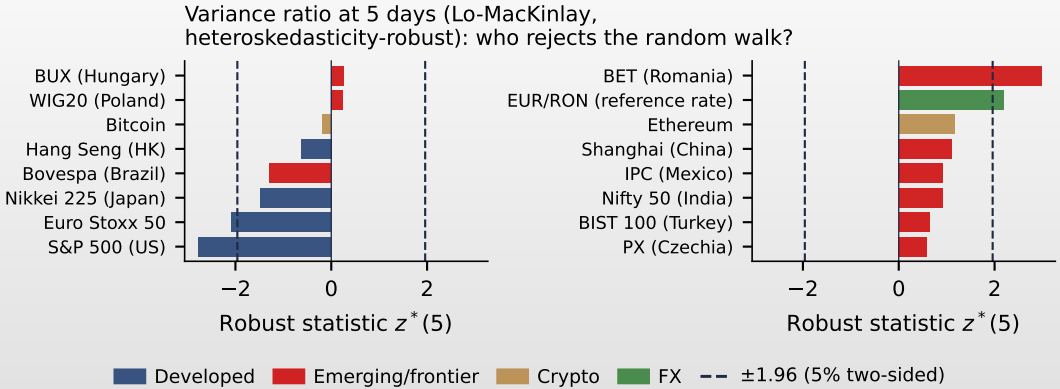
Testul Lo–MacKinlay

- Lo & MacKinlay (1988): sume suprapuse pe cîte q zile, cu corecții de deplasare
  - $\hat{\sigma}_a^2 = \frac{1}{T-1}\sum_t (r_t - \hat{\mu})^2, \quad \hat{\sigma}_c^2(q) = \frac{1}{m}\sum_{t=q}^{T}\left(\sum_{j=0}^{q-1} r_{t-j} - q\hat{\mu}\right)^2$
  - $m = q(T-q+1)(1-q/T); \quad \widehat{\mathrm{VR}}(q) = \hat{\sigma}_c^2(q)/\hat{\sigma}_a^2$
  - $\hat{\mu}$: randamentul zilnic mediu
  - $\hat{\sigma}_a^2$: dispersia randamentelor pe o zi
  - $\hat{\sigma}_c^2(q)$: dispersia sumelor suprapuse pe q zile, împărțită la q
  - m: numitorul care corectează deplasarea în selecții mici
- Statistica testului sub RW1 (randamente omoscedastice)
  - $z(q) = \dfrac{\widehat{\mathrm{VR}}(q) - 1}{\sqrt{2(2q-1)(q-1)/(3qT)}} \approx N(0,1)$
  - numitorul este eroarea standard a lui $\widehat{\mathrm{VR}}(q)$ sub RW1
  - $|z| > 1{,}96$ respinge $\mathrm{VR}(q) = 1$ la 5%
- Omoscedastic: dispersie constantă
- Acest z duce la respingeri prea frecvente cînd există volatility clustering (slide-ul următor)

Statistica z^*, robustă la heteroscedasticitate

- Sub RW3 plus condițiile din Lo & MacKinlay (1988) (momente finite, dependență slabă de tip mixing, $\mathbb{E}[\varepsilon_t^2 \varepsilon_{t-j}\varepsilon_{t-k}] = 0$ pentru $j \neq k$), $\hat{\rho}_k$ sînt asimptotic necorelate, cu dispersiile $\hat{\delta}_k / T$
  - $\hat{\delta}_k = T\hat{\tau}_k$, cu $\hat{\tau}_k$ de pe slide-ul autocorelației: dispersia robustă a lui $\sqrt{T}\hat{\rho}_k$, egală cu 1 fără volatility clustering
- Dispersia asimptotică a lui $\widehat{\mathrm{VR}}(q)$ și statistica testului
  - $\hat{\theta}(q) = \sum_{k=1}^{q-1} \left(\frac{2(q-k)}{q} \right)^2 \hat{\delta}_k, \qquad z^*(q) = \frac{\sqrt{T}\,(\widehat{\mathrm{VR}}(q) - 1)}{\sqrt{\hat{\theta}(q)}} \approx N(0,1)$
  - $2(q-k)/q$: ponderea lui $\hat{\rho}_k$ în $\widehat{\mathrm{VR}}(q)$
  - $|z^*| > 1{,}96$ respinge $\mathrm{VR}(q) = 1$ la 5%
- RW3 singură nu este suficientă: condițiile sînt îndeplinite de GARCH cu inovații simetrice, dar pot să nu fie îndeplinite în prezența efectului de levier
  - Fără ultima condiție, calculul lui $\hat{\theta}(q)$ necesită întreaga matrice de covarianță a estimatorilor $\hat{\rho}_k$
- S&P 500, $q = 2$: $\widehat{\mathrm{VR}} = 0{,}901$, $z = -8{,}12$, dar $z^* = -3{,}64$: rămîne semnificativ, dar este de două ori mai mic în valoare absolută (exercițiul B1 din seminar îl calculează pas cu pas)

Mai multe orizonturi și piețe: testul Chow–Denning (1/2)



MFM_ch2_variance_ratio

Mai multe orizonturi și piețe: testul Chow–Denning (2/2)

- Bare: $z^*(5)$ robust pentru toate cele 16 serii
- Linii întrerupte $\pm 1{,}96$
- La un singur orizont, ipoteza nulă este respinsă la 5% pentru: BET (2,98), EUR/RON (2,19), S&P 500 ($-2{,}77$), Euro Stoxx 50 ($-2{,}08$)
- Patru orizonturi la 5% fiecare: probabilitatea unei respingeri false ajunge la $1 - 0{,}95^4 = 18{,}5\%$
  - Chow & Denning (1993): $\mathrm{CD} = \max_i |z^*(q_i)|$, cel mai mare dintre cele patru $|z^*|$, pe $q_i = 2, 5, 10, 20$
  - valoarea critică la 5% este 2,49, peste 1,96, pentru că se fac patru verificări
- Testul comun respinge RW3 pentru 5 din cele 16 serii: BET, S&P 500, IPC, EUR/RON, Ethereum
- Bitcoin $p = 0{,}835$
- Ierarhia „dezvoltat = eficient" nu este confirmată: direcția abaterii diferă (inversare la unele piețe, persistență la altele)

MFM_ch2_variance_ratio

Ce examinează testele neliniare

- **BDS**: Brock–Dechert–Scheinkman–LeBaron test — test al independenței observațiilor.
- **MDH**: Martingale Difference Hypothesis — ipoteza diferenței de martingal.
- BDS compară frecvența secvențelor de randamente apropiate cu frecvența implicată de observații i.i.d.
  - gruparea excesivă poate semnala dependență. Brock, Dechert, Scheinkman & LeBaron (1996)
- De exemplu, regimurile calme și volatile persistente pot duce la respingere BDS chiar dacă media condiționată de mîine este zero.
- Testul spectral generalizat caută dependența mediei de transformări neliniare ale randamentelor trecute
  - poate detecta relații ratate de corelațiile obișnuite. Escanciano & Velasco (2006)
- Automatic portmanteau alege numărul de laguri testate folosind o penalizare
  - poate respinge MDH prin dependență liniară, dar nu detectează orice alternativă neliniară. Escanciano & Lobato (2009)

Dincolo de predictibilitatea liniară: ipoteza diferenței de martingal

- **MDH**: $\mathbb{E}[r_t \mid \mathcal{I}_{t-1}] = \mu$: nicio funcție a trecutului, liniară sau nu, nu prezice media
- RW3 (toate $\rho_k = 0$) este mai slabă. Contraexemplu: $r_t = \varepsilon_t + \theta(\varepsilon_{t-1}^2 - \sigma^2)$, ε_t i.i.d. simetrice
  - $\sigma^2 = \mathrm{Var}(\varepsilon_t)$, deci termenul suplimentar are media 0
  - $\theta \neq 0$: cît de mult deplasează pătratul șocului de ieri media de azi
  - toate $\rho_k = 0$, dar $\mathbb{E}[r_t \mid \varepsilon_{t-1}] = \theta(\varepsilon_{t-1}^2 - \sigma^2)$ este predictibilă: testele de autocorelație nu o pot detecta
  - Teste ale MDH propriu-zise: testul spectral generalizat Escanciano & Velasco (2006)
  - Un test portmanteau automat Escanciano & Lobato (2009)
  - Detalii și rezultate: vezi ▸ Anexa
- **BDS** Brock, Dechert, Scheinkman & LeBaron (1996) testează i.i.d., nu MDH: un model GARCH poate determina singur respingerea ipotezei nule
  - O respingere BDS este o dovadă împotriva RW1, nu împotriva eficienței slabe

Variabile predetermined, bias și consistență

- De ce distorsionează un predictor persistent inferența într-o selecție finită?
- Reia: prognoze pe date noi
- Teme
- Cuprins

- Un predictor predetermined este cunoscut înaintea șocului randamentului prognozat
  - exogenitatea strictă exclude în plus corelația cu șocurile de la toate datele.
- Raportul dividend–preț de azi poate prognoza ziua de mîine, dar șocul prețului de mîine schimbă raportul de mîine: acest feedback împiedică exogenitatea strictă.
- Deplasarea (bias) este media estimatorului în selecții repetate minus parametrul adevărat: o pantă medie de 0,03 cînd panta adevărată este zero înseamnă bias 0,03.
- Consistența înseamnă apropierea de parametrul adevărat cînd numărul de observații crește
  - nu implică bias zero într-o selecție finită.

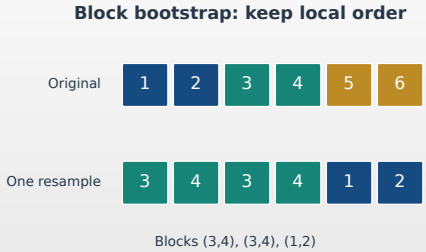
Erori standard HAC și bandwidth

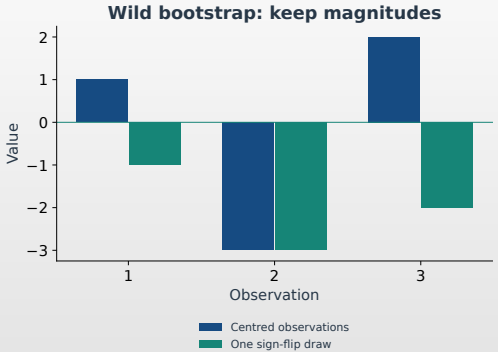
- HAC înseamnă heteroskedasticity and autocorrelation consistent: erorile standard permit atît dispersie variabilă, cît și dependență serială, în condițiile de regularitate cerute.
- Newey–West estimează long-run variance adăugînd covariațe la lag ponderate la dispersie
  - schimbă estimarea incertitudinii, nu coeficienții OLS.
- Pentru o serie staționară cu dispersie 1, covariață la lagul 1 de 0,2 și celelalte covariațe zero, long-run variance este $1 + 2(0{,}2) = 1{,}4$.
- Bandwidth precizează cîte laguri intră în estimare
  - bandwidth 5 folosește lagurile 1–5, cu ponderi care depind de estimator.

Bootstrap: construirea selecțiilor repetate

- Bootstrap aproximează distribuția de selecție generînd multe selecții artificiale și recalculînd statistica.
- Un bootstrap i.i.d. extrage observații cu înlocuire: din $(1, 2, 3)$ o selecție poate fi $(2, 2, 1)$
  - seriile dependente cer o procedură care ține cont de dependență.
- Block bootstrap extrage blocuri consecutive
  - extragerea blocurilor $(1, 2)$ și $(3, 4)$ păstrează ordinea din bloc, spre deosebire de amestecarea zilelor individuale.
- Wild bootstrap înmulțește randamentele centrate cu semne aleatoare: $(1, -3, 2)$ poate deveni $(-1, -3, -2)$, păstrînd modulele
  - validitatea depinde de modelul nul.

Ce păstrează fiecare bootstrap





Blocurile păstrează ordinea locală; schimbările de semn păstrează modulele. Cele două proceduri impun ipoteze diferite selecțiilor artificiale.

Regresii predictive și deplasarea Stambaugh (1/2)

- Întrebarea: poate un indicator de evaluare cunoscut azi să prognozeze randamentul perioadei următoare?
- Modelul: $r_{t+1} = \alpha + \beta x_t + u_{t+1}, \quad x_{t+1} = \theta + \rho x_t + v_{t+1}$, cu $\mathrm{Cov}(u, v) = \sigma_{uv}$
  - r: randamentul în exces
  - x: logaritmul raportului dividend–preț, $dp_t = \ln D_t - \ln P_t$, persistent ($\rho \approx 1$)
  - D_t: dividendele plătite în ultimul an
  - β: panta predictivă, 0 dacă randamentele sînt imprevizibile
  - α, θ: termeni liberi
  - ρ: persistența lui x
  - u, v: șocurile celor două ecuații
  - σ_{uv}: covariația lor
  - $\sigma_v^2 = \mathrm{Var}(v)$
  - T: numărul de perioade

Bonferroni Q: incertitudinea persistenței

- Inferența Campbell–Yogo ține cont de incertitudinea persistenței predictorului, în loc să trateze estimația ei ca valoare cunoscută. Campbell & Yogo (2006)
- Combină o mulțime de încredere pentru persistență cu teste ale pantei predictive pe acea mulțime, împărțind probabilitatea de eroare între etape.
- De exemplu, dacă valorile plauzibile ale persistenței sînt între 0,95 și 1, concluzia trebuie să țină cont de acest interval, nu doar de estimația punctuală 0,98.
- Acest test Q privește regresiile predictive
  - nu este statistica Q Ljung–Box pentru autocorelații.

Regresii predictive și deplasarea Stambaugh (2/2)

- x_t este predeterminat, nu strict exogen: estimatorul OLS este consistent, dar are deplasare în selecții finite Stambaugh (1999)
  - Proiectăm u pe v: $u = (\sigma_{uv}/\sigma_v^2)\, v + e$, deci $\hat{\beta} - \beta = (\sigma_{uv}/\sigma_v^2)(\hat{\rho} - \rho) + \text{zgomot}$
  - e: partea lui u necorelată cu v
  - Pasul folosește aceleași luni și același x_t centrat în ambele regresii
  - Termenul de zgomot are media zero cînd e este independent de întreaga traiectorie a lui x, de exemplu pentru (u, v) normale în comun și i.i.d.
  - $\hat{\rho}$ este deplasat în jos în selecții mici Kendall (1954), iar această deplasare se transmite estimatorului $\hat{\beta}$
  - Cu $\mathbb{E}[\hat{\rho} - \rho] \approx -(1 + 3\rho)/T$: $\quad \mathbb{E}[\hat{\beta} - \beta] \approx -\dfrac{\sigma_{uv}}{\sigma_v^2}\,\dfrac{1 + 3\rho}{T}$
- Prețul crește $\Rightarrow$ *dp* scade: $\sigma_{uv} < 0$, deci deplasarea este **în sus**: predictibilitatea pare mai puternică decît este
- Aproape de o rădăcină unitară nici statistica t nu are distribuția $N(0, 1)$: inferența validă se obține cu testul Q de tip Bonferroni, construit pe un interval de încredere pentru ρ Campbell & Yogo (2006)

Exemplu rezolvat: deplasarea Stambaugh pentru S&P 500

- Randamentul logaritmic lunar în exces, regresat pe dp_t decalat, 1934–2026, $T = 1\,111$ de luni
- Construcția datelor: vezi ▸ Anexa
- OLS: $\hat{\beta} = 0{,}267$ (% pe lună pe unitate de dp), t Newey–West $= 0{,}91$: nesemnificativ chiar înaintea oricărei corecții
- Date de intrare: $\hat{\rho} = 0{,}9988$, $\mathrm{corr}(\hat{u}, \hat{v}) = -0{,}97$, $\hat{\phi} = \hat{\sigma}_{uv}/\hat{\sigma}_v^2 = -0{,}925$ (exprimate ca fracții, nu în procente)
- Calcul: deplasarea $= -100\,\hat{\phi}\,(1 + 3\hat{\rho})/T = 0{,}333$ (în %, ca $\hat{\beta}$)
  - panta corectată $= 0{,}267 - 0{,}333 = -0{,}066$: întreaga estimație se datorează deplasării
  - corecția este ea însăși estimată: pentru inferența formală se folosește Campbell & Yogo (2006) sau un bootstrap
  - Formula lui Kendall este de ordinul întîi în $1/T$ și cea mai puțin precisă cînd $T(1 - \hat{\rho})$ este mic, aici 1,4 folosind persistența nerotunjită: $-0{,}066$ indică semnul și ordinul de mărime, nu o pantă precisă
- Simulare cu aceleași ρ și $\mathrm{corr}(u, v)$, $\beta = 0$, $T = 360$ de luni: testul t nominal de 5% respinge $\beta = 0$ în 26,5% din selecții

Comparația prognozelor și valoarea economică

- Diebold–Mariano testează media diferenței dintre pierderile prognozelor
  - Clark–West ajustează pierderile pătratice pentru zgomotul estimării modelului nested mai mare.
- Un test unilateral întreabă aici dacă media cîștigului ajustat este pozitivă
  - un test bilateral ar considera și un cîștig suficient de negativ drept abatere de la zero.
- Sharpe ratio împarte media randamentului în exces la SD, la aceeași frecvență: medie lunară 1%, SD 5%, Sharpe $= 0{,}2$.
- Un investitor mean–variance compară randamentul așteptat cu dispersia: la același randament așteptat preferă portofoliul cu dispersie mai mică.

Predictibilitatea în afara selecției: R^2_{OS} și testul Clark–West

- Prognoze recursive: în fiecare lună t, reestimăm doar pe datele pînă la $t-1$ (fereastră extinsă progresiv) și prognozăm $\hat{r}_t$
  - reper: media istorică $\bar{r}_t$ a acelorași date
  - $R^2_{OS} = 1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t (r_t - \bar{r}_t)^2$
  - $R^2_{OS} > 0$: predictorul este mai bun decît media
  - Majoritatea predictorilor au $R^2_{OS} < 0$ Welch & Goyal (2008)
  - Actualizarea din 2022 o confirmă Goyal, Welch & Zafirov (2024)
  - Prognoza este doar pseudo-out-of-sample (nu complet în timp real), ca în Welch & Goyal (2008): dividendele lunare sînt interpolate din totaluri trimestriale, deci dp_t nu este strict disponibil în timp real
- Modele imbricate: sub H_0 modelul mai complex estimează și un coeficient β nul, ceea ce îi mărește artificial MSPE (eroarea pătratică medie de predicție)
- Testul Diebold–Mariano Diebold & Mariano (1995) respinge atunci mai rar decît nivelul nominal
  - Clark & West (2007): $f_t = (r_t - \bar{r}_t)^2 - \left[(r_t - \hat{r}_t)^2 - (\bar{r}_t - \hat{r}_t)^2\right]$
  - t pentru un test unilateral asupra mediei lui f_t
  - f_t: reducerea erorii pătratice datorată predictorului, plus termenul $(\bar{r}_t - \hat{r}_t)^2$, care elimină zgomotul estimării lui β
  - o medie pozitivă favorizează predictorul
- Campbell & Thompson (2008): impunem semnul lui β și o prognoză nenegativă

Raportul dividend–preț: estimare și interpretare

- Reducerea cumulată a erorilor pătratice față de media istorică, pentru prognozele începînd din 1970
- O linie ascendentă arată că *dp* îmbunătățește prognoza
- 680 de prognoze: $R^2_{OS} = -0{,}51\%$
- restricțiile Campbell–Thompson sînt active în 5,7% din luni și lasă R^2_{OS} practic neschimbat, la $-0{,}51\%$
- Clark–West $t = 0{,}42$ (p unilateral $= 0{,}34$): nicio predictibilitate semnificativă în afara selecției
- Cîștigul atinge maximul în 1990 și se pierde în boom-ul anilor 1990, cînd *dp* a coborît la minime record
- După 2010 se erodează din nou
- Importanța economică: cu un raport Sharpe lunar de 0,160, chiar $R^2 = 0{,}5\%$ ar mări cu 20% randamentul așteptat al unui investitor care își alege portofoliul după criteriul medie–dispersie și își ajustează expunerea pe piață în funcție de prognoză
- Formula: vezi ▸ Anexa

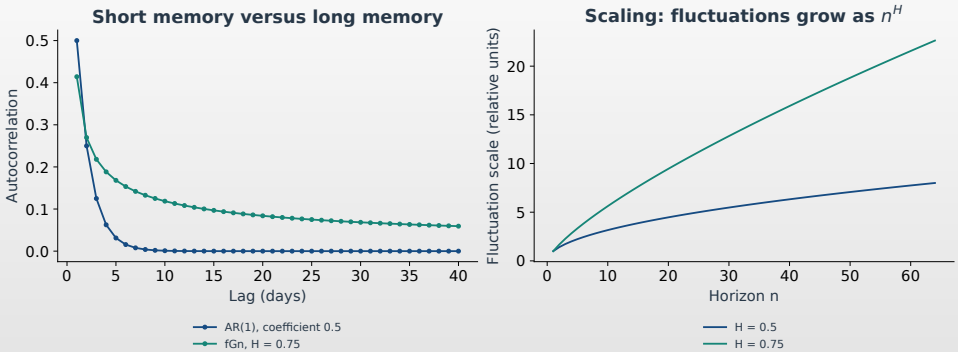
MFM_ch2_predictability

Short memory, long memory și scaling

- Persistă dependența pe orizonturi și în regimuri de piață diferite?
- Reia: de la tipar la test
- Teme
- Cuprins

- Short memory are o sumă finită a modulelor autocovarianțelor
  - un AR(1) cu coeficientul 0,5 are corelații $0{,}5^k$ la lagul k.
- Long memory înseamnă aici dependență pozitivă care scade atît de lent încît suma autocovarianțelor diverge
  - descreșterea de tip power law poate produce acest lucru.
- Scaling $F(n) \propto n^H$ înseamnă că dublarea orizontului multiplică fluctuațiile cu 2^H: circa 1,41 la $H = 0{,}5$, respectiv 1,68 la $H = 0{,}75$.
- Antipersistence descrie variații care tind să se compenseze, ca în fractional Gaussian noise (fGn) cu $H < 0{,}5$
  - fGn este un model de variații Gaussiene staționare cu dispersia sumelor proporțională cu n^{2H}.

Dependență la laguri și orizonturi diferite

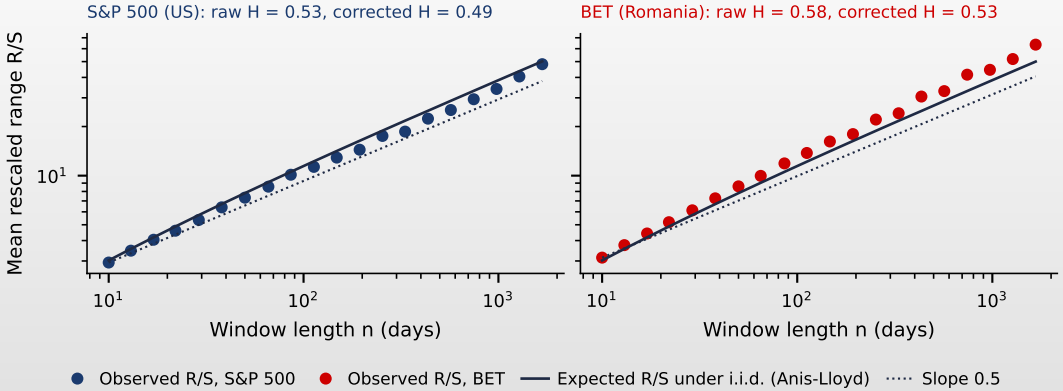


Corelațiile AR(1) scad geometric; în exemplul fGn scad lent. Dreapta compară creșterea fluctuațiilor odată cu orizontul.

Statistica rescaled range (R/S)

- Hurst (1951) a constatat, cu ajutorul rescaled range-ului, că pe Nil anii ploioși urmau anilor ploioși mai des decît ar permite hazardul
- detalii istorice: vezi Anexa
- Calculul pornește de la o fereastră de n randamente cu media $\bar{r}_n$ și abaterea standard s_n
  - Abaterile cumulate $Y_k = \sum_{i=1}^{k}(r_i - \bar{r}_n)$, $k = 1, \ldots, n$
  - Amplitudinea $R_n = \max_k Y_k - \min_k Y_k$
  - Rescaled range-ul R_n/s_n
- Legea de scalare: $\mathbb{E}[R_n/s_n] \approx c\, n^H$, unde H este **exponentul Hurst**
  - c: o constantă
  - prin logaritmare, $\ln(R/S) \approx \ln c + H \ln n$, deci H este o pantă
  - Estimare: panta lui $\ln(R/S)$ pe $\ln n$, cu R/S mediat pe ferestre disjuncte
- $H = 0{,}5$: fără memorie lungă (dependența pe termen scurt este permisă)
- $H > 0{,}5$: persistență
- $H < 0{,}5$: antipersistență
  - **Memorie lungă** ($H > 0{,}5$): autocorelațiile scad atît de lent încît suma lor diverge, $\rho_k \sim k^{2H-2}$

Analiza R/S: S&P 500 și BET (1/2)



MFM_ch2_hurst

Analiza R/S: S&P 500 și BET (2/2)

- Puncte: R/S mediu pentru fiecare lungime a ferestrei n
- Linia continuă: media teoretică Anis & Lloyd (1976) pentru randamente i.i.d. din distribuția Normală
- Formula exactă: vezi ▸ Anexa
- Deplasarea în selecții mici: chiar pentru randamente i.i.d. panta brută depășește 0,5
- Exponentul corectat Anis–Lloyd este $H_{AL} = 0{,}5+$ panta lui $\ln(R/S) - \ln \mathbb{E}[R_n/s_n]$
- S&P 500: brut 0,530, corectat 0,486: „persistența" era un artefact al deplasării
- BET: brut 0,578, corectat 0,533: persistența rămîne vizibilă după corecție
- Întrebare deschisă: valoarea $H > 0{,}5$ a BET indică memorie **lungă** sau doar reflectă $\hat{\rho}_1 = 0{,}109$? Statistica R/S clasică nu poate deosebi cele două cazuri

MFM_ch2_hurst

Exponentul Hurst și variance ratio-ul: limitele unui singur orizont

- Pentru creșteri (incremente) exact autosimilare (zgomot gaussian fracționar): $\mathrm{Var}(r_t + \cdots + r_{t-q+1}) = q^{2H}\mathrm{Var}(r_t)$
- Deci $\mathrm{VR}(q) = q^{2H-1}$ și $H(q)$ **implicit** $= 0{,}5 + \ln \mathrm{VR}(q)/(2 \ln q)$: BET 0,553, S&P 500 0,453 la $q = 20$
- Contraexemplu cu memorie scurtă: un AR(1) cu $\rho_1 = -0{,}1$, $\rho_k = (-0{,}1)^k$
  - $\mathrm{VR}(20) = 0{,}826$, deci $H(20) = 0{,}468$: „antipersistent" fără nicio memorie lungă
  - totuși $H(250) = 0{,}482$: pentru memoria scurtă $H(q) \to 0{,}5$ cînd $q \to \infty$ (exercițiile A2–A3 din seminar)
  - un AR(1) cu $\hat{\rho}_1 = 0{,}109$ al BET dă $H(20) = 0{,}535$: cea mai mare parte a abaterii lui $H(20)$ de la 0,5 pentru BET provine din memoria scurtă
- Separarea celor două necesită o statistică construită special în acest scop: statistica R/S modificată a lui Lo (slide-ul următor)

Testul R/S modificat al lui Lo

- Lo (1991): autocorelația pe termen scurt mărește artificial statistica R/S și imită memoria lungă
- Modificarea: s_n este înlocuit cu o abatere standard pe termen lung (HAC) $\hat{\sigma}_\ell$, cu ℓ laguri
  - $\hat{\sigma}_\ell^2 = \hat{\gamma}_0 + 2\sum_{j=1}^{\ell}\left(1 - \frac{j}{\ell+1}\right)\hat{\gamma}_j$, $\hat{\gamma}_j$: autocovarianța la lagul j ($\hat{\gamma}_0$: dispersia), cu ponderi descrescătoare
  - $V = \dfrac{\max_k Y_k - \min_k Y_k}{\hat{\sigma}_\ell \sqrt{T}}$
  - Y_k: abaterile cumulate pe toată selecția de T randamente
  - lățimea de bandă ℓ este aleasă ca în Andrews (1991)
- În ipoteza memoriei scurte, V se află în [0,809; 1,862] cu probabilitatea 95%
- Pe întreaga perioadă: S&P 500 $V = 1{,}559$, Bitcoin 1,547, PX 1,750, EUR/RON 1,429: memoria scurtă nu este respinsă
  - BET $V = 1{,}961$ ($\ell = 7$) și Ethereum $V = 1{,}980$: valorile sînt puțin peste 1,862, ceea ce oferă dovezi slabe în favoarea memoriei lungi

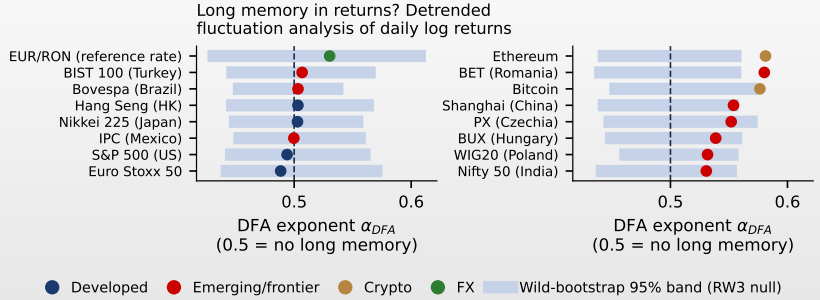
Detrended fluctuation analysis (DFA)

- Peng et al. (1994): eliminarea tendinței liniare din profil înlătură o medie local constantă a randamentelor
- pentru tendințe în randamente este nevoie de DFA de ordin superior
- Algoritmul în trei pași (exercițiul B5 din seminar arată o fereastră pas cu pas)
  - Profilul y_k: abaterile cumulate Y_k definite la R/S, calculate pe întreaga selecție
  - Profilul se împarte în segmente de lungime n
  - În fiecare segment se estimează o tendință liniară și se păstrează reziduurile
  - $F(n)$ = rădăcina mediei pătratelor tuturor reziduurilor
  - se repetă pentru mai multe n
- $F(n) \propto n^{\alpha_{DFA}}$: exponentul DFA α_{DFA} joacă rolul lui H ($\alpha_{DFA} = 0{,}5$: fără memorie lungă)
- Banda sub ipoteza nulă prin **wild bootstrap**: $e_t \eta_t$, $\eta_t = \pm 1$ cu probabilitatea 1/2 (199 de replicări)
- η_t: un semn aleator
  - Păstrează traiectoria volatilității $|e_t|$ (permisă sub RW3) și distruge corelația serială
  - Permutarea aleatoare le-ar distruge pe amîndouă
  - Ipoteza nulă implicită: semne simetrice și independente condiționat de $|e_t|$, mai restrictivă decît RW3: un reper, nu un test exact al RW3 și nici un interval de încredere pentru α_{DFA}

Frecvență, periodogramă și local Whittle

- O frecvență descrie cicluri pe unitatea de timp: un ciclu de zece zile are frecvența 1/10 pe zi
  - frecvențele joase descriu variația lentă.
- Densitatea spectrală repartizează dispersia pe frecvențe
  - periodograma este analogul brut din selecție, construit din pătratele amplitudinilor Fourier.
- Componentele Fourier sînt unde sinus și cosinus: combinarea amplitudinilor lor reprezintă oscilații la frecvențe diferite.
- Local Whittle estimează d din panta spectrului la frecvențe joase
  - $d = 0{,}1$ corespunde lui $H = 0{,}6$ în modelul de scaling precizat.
  - Bandwidth-ul m numără frecvențe, nu laguri. Robinson (1995)

Exponentul DFA pe piețe (1/2)



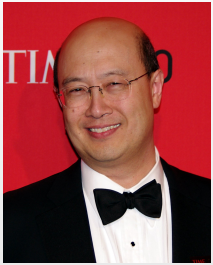
- Lecția: dovezile de memorie în randamente sînt slabe și sensibile la metoda folosită
- Memoria în volatilitate (Capitolul 1) este puternică

MFM_ch2_hurst

Exponentul DFA pe piețe (2/2)

- Puncte: α_{DFA}
- Bare: banda de 95% sub ipoteza nulă, obținută prin schimbări aleatoare de semn (volatilitatea este păstrată, autocorelația este eliminată)
- În interiorul benzii: S&P 500 0,494, Euro Stoxx 50 0,488, Nikkei 0,503, PX 0,552, Shanghai 0,554
- Peste bandă (3 din 16): Ethereum 0,581, BET 0,580 (banda pînă la 0,561), Bitcoin 0,576, la limită (banda pînă la 0,575)
- O bandă obținută prin permutarea aleatoare a randamentelor semnalează 5 serii: „memoria" aparentă a PX și Shanghai provenea doar din volatility clustering
- Verificări: statistica V a lui Lo respinge la limită memoria scurtă pentru BET și Ethereum, nu și pentru Bitcoin
- Estimatorul Whittle local al parametrului de memorie lungă $d = H - 0{,}5$, pentru BET: $\hat{d} = 0{,}118$, interval de încredere de 95% [0,062; 0,174]
- Detalii: vezi Anexa

Ipoteza piețelor adaptive (1/2)



Andrew W. Lo, MIT

Foto: David Shankbone (2012); CC BY 3.0; Wikimedia Commons

- Lo (2004)
- versiunea extinsă în carte: Lo (2017)
- Piețele formează un ecosistem de specii aflate în competiție (traderi, fonduri, algoritmi), care se adaptează prin încercare și eroare, nu prin optimizare perfectă
  - eficiența este o chestiune de grad și depinde de numărul de competitori, de oportunitățile de profit și de mediu
- Predicție: eficiența **variază în timp și în funcție de condițiile pieței**

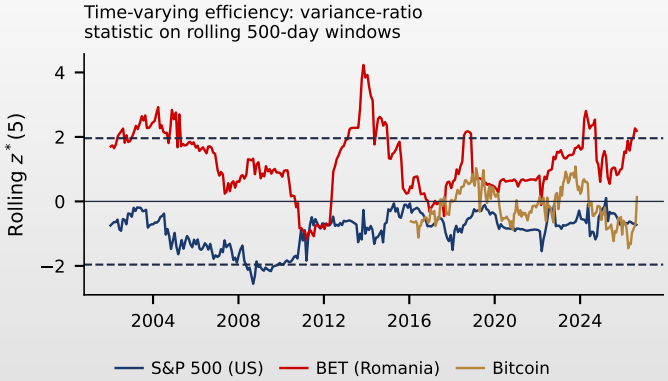
Ipoteza piețelor adaptive (2/2)

- **AMH**: Adaptive Markets Hypothesis — ipoteza că eficiența se schimbă odată cu adaptarea participanților.
- **EMH**: Efficient Market Hypothesis — ipoteza că prețurile reflectă informația disponibilă.
- Anomaliile apar, slăbesc și pot reapărea
- Atenție: variația în timp a statisticilor nu permite, singură, identificarea AMH, pentru că și o EMH cu prime de risc variabile o poate genera
- Tabelul comparativ: vezi Anexa
- Dovezi de variație în timp: sinteza Lim & Brooks (2011)
- Studiul pe indici cu istorie lungă Urquhart & McGroarty (2016)

Măsurarea eficienței variabile în timp

- Calculăm o statistică pe o **fereastră mobilă**: 500 de zile de tranzacționare (circa doi ani), deplasată cu 21 de zile (o lună)
  - Statistici: $z^*(5)$ al testului variance ratio-ului și exponentul DFA
- Banda sub ipoteza nulă pentru DFA: wild bootstrap **în fiecare fereastră** (199 de schimbări de semn), deci banda urmează volatilitatea ferestrei
  - O bandă i.i.d. Student-t_4 [0,380; 0,615] ignoră volatility clustering (permis de RW3), care mărește α_{DFA}
- Două precauții la interpretarea rezultatelor
  - Ferestrele suprapuse sînt puternic corelate: seriile de respingeri nu sînt dovezi independente
  - Chiar sub ipoteza nulă, aceasta este respinsă în circa 5% din ferestre
  - O proporție apropiată de 5% este o descriere, nu un test calibrat al stabilității

Variance ratio-ul pe ferestre mobile: S&P 500, BET, Bitcoin



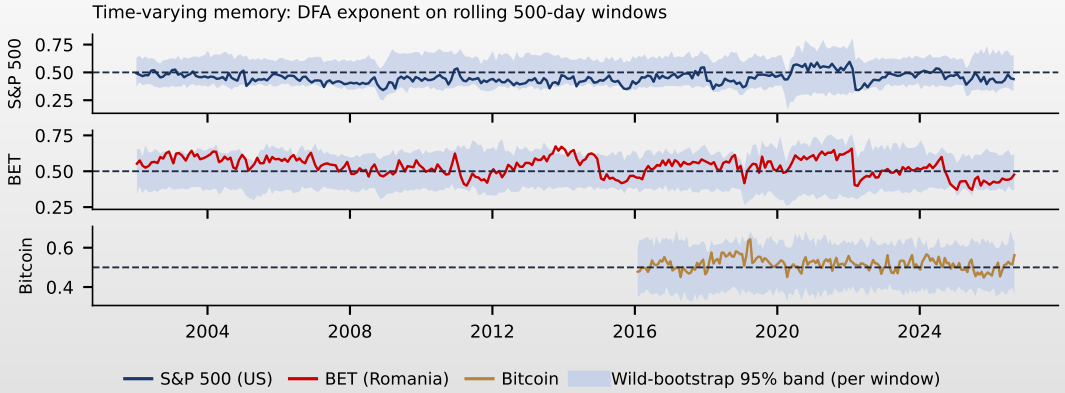
Variance ratio-ul pe ferestre mobile: S&P 500, BET, Bitcoin — interpretare

FTSE: Financial Times Stock Exchange (FTSE Russell, index provider) — furnizorul de indici FTSE Russell.

- $z^*(5)$ pe ferestre mobile de 500 de zile
- linii întrerupte $\pm 1{,}96$
- Proporția ferestrelor cu $|z^*(5)| > 1{,}96$: S&P 500 6,4%, BET 22,4%, Bitcoin 0,0%
- S&P 500: respingerea pe întreaga selecție provine din cîteva ferestre turbulente
- BET: respingerile se grupează în episoade, apoi dispar
- Reclasificarea FTSE în categoria piețelor emergente secundare, în vigoare din 21 sept. 2020, ar putea marca o schimbare a structurii investitorilor
- Vezi exercițiul C2 din seminar și Anexa
- Bitcoin, 2014–2026: ipoteza nu este respinsă în nicio fereastră

MFM_ch2_rolling_efficiency

Exponentul DFA pe ferestre mobile: S&P 500, BET, Bitcoin (1/2)



MFM_ch2_rolling_efficiency

Exponentul DFA pe ferestre mobile: S&P 500, BET, Bitcoin (2/2)

- α_{DFA} pe ferestre mobile de 500 de zile
- zona hașurată: banda wild bootstrap de 95% calculată în fiecare fereastră
- În afara propriei benzi: S&P 500 2,0%, BET 3,1%, Bitcoin 0,0% din ferestre
- Cu banda fixă i.i.d. Student-t_4: 6,4%, 11,2%, 1,1%: „episoadele" aparente ale BET proveneau din volatility clustering
- Puterea testului este mică: banda BET are în medie [0,36; 0,64]
- 500 de observații nu sînt suficiente pentru a estima precis exponentul de scalare

MFM_ch2_rolling_efficiency

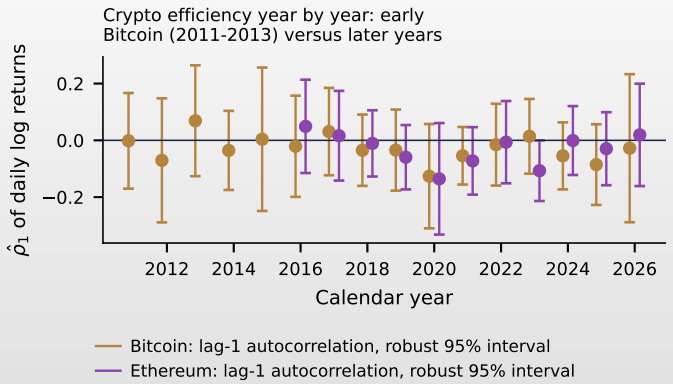
Indicatori și variabile de control

- Un dummy este 1 cînd condiția este îndeplinită și 0 în rest: un dummy de recesiune marchează lunile de recesiune.
- Într-o regresie, o variabilă de control ține statistic fixă o caracteristică observată
  - includerea volatilității compară perioade cu volatilitate similară.
- Un confounder influențează atît cauza presupusă, cît și rezultatul: o criză poate schimba atît participarea la tranzacționare, cît și predictibilitatea.
- O asociere după includerea variabilelor de control nu devine automat cauzală: pot rămîne factori de confuzie omiși.

Testarea AMH

- Kim, Shamsuddin & Lim (2011): date Statele Unite ale Americii pe un secol
- predictibilitatea variază în funcție de condițiile pieței (crize, bule), nu urmează o tendință
  - Aceasta transformă narațiunea AMH într-o regresie cu coeficienți testabili
- Versiunea noastră: regresăm $z^*(5)$, calculat pe ferestre mobile, în funcție de volatilitatea anualizată a ferestrei (%) și de o variabilă indicator pentru criză (fereastra acoperă sept. 2008–iun. 2009 sau febr.–iun. 2020)
  - Erori Newey–West cu 24 de laguri: ferestrele consecutive au în comun 95% din zile
- S&P 500: criză $-0{,}67$ ($t = -2{,}37$), volatilitate 0,006 ($t = 0{,}27$), $R^2 = 0{,}20$
- BET: criză $-0{,}82$ ($t = -2{,}77$), volatilitate $-0{,}008$ ($t = -0{,}36$), $R^2 = 0{,}15$
- Ferestrele de criză sînt asociate cu un $z^*(5)$ mai mic (spre inversare) pe ambele piețe, chiar și cu volatilitatea inclusă ca variabilă de control: o asociere condiționată, nu un efect cauzal
  - z^* combină $\widehat{\mathrm{VR}} - 1$ și eroarea lui standard
  - dependența de stare este compatibilă cu AMH, dar nu o identifică în mod unic

Eficiența criptoactivelor an de an



- Autocorelația de ordinul 1 pentru fiecare an calendaristic, intervale robuste de 95%
- Bitcoin din 2011
- Doar 1 din 27 de valori anuale $\hat{\rho}_1$ are $|t| > 1{,}96$ (Ethereum 2023, $-0{,}107$), față de $0{,}05 \times 27 = 1{,}35$ așteptate din întîmplare
- Diferența față de Urquhart (2016), care respinge eficiența în primii ani, se explică prin alte teste (inclusiv BDS), altă sursă de prețuri și erori standard clasice
- Literatura: vezi ▸ Anexa
- Puterea testului: un an cu 365 de randamente dă o SE robustă de circa 0,06–0,13, deci efectele mici nu pot fi detectate

MFM_ch2_crypto_efficiency

SD, SE și incertitudinea

- Standard deviation (SD) măsoară dispersia observațiilor
  - standard error (SE) măsoară dispersia unui estimator între selecții repetate.
- Pentru 100 de randamente i.i.d. cu SD 2%, media de selecție are SE $2\%/\sqrt{100} = 0{,}2\%$.
  - Dependența schimbă acest calcul.
- Un interval de încredere de 95% este construit printr-o procedură care acoperă parametrul fix necunoscut în 95% dintre selecțiile repetate, în condițiile presupuse.
- O bandă sub ipoteza nulă arată estimațiile obișnuite dacă ipoteza precizată este adevărată: o bandă simulată sub $H = 0{,}5$ nu este un interval de încredere în jurul unui H estimat.

Dependență cross-sectional și standardizare

- Cum afectează dependența și dispersia indusă de eveniment rezultatul testului?
- Reia: prețuri și știri
- Teme
- Cuprins

- O serie de timp urmărește un activ la date diferite
  - o cross-section compară mai multe active la aceeași dată.
- Două bănci afectate de aceeași știre nu sînt neapărat observații independente: abnormal returns se pot mișca împreună.
- Standardizarea împarte o mărime centrată la SD: un abnormal return de -4% cu SD 2% este de -2 abateri standard.
- Event-induced variance înseamnă că evenimentul însuși mărește dispersia
  - folosirea doar a zilelor calme anterioare poate subestima incertitudinea.

Studii de eveniment: inferența corectă (1/2)

- Dispersia erorii de predicție: $\text{Var}(AR_\tau) = \sigma_\varepsilon^2\left[1 + \frac{1}{T_0} + \frac{(r_{m,\tau} - \hat{\mu}_m)^2}{(T_0 - 1)\hat{\sigma}_m^2}\right]$, T_0 = numărul de zile din fereastra de estimare MacKinlay (1997)
  - $\hat{\mu}_m$, $\hat{\sigma}_m^2$: media și dispersia randamentului pieței în fereastra de estimare
  - paranteza crește cînd mișcarea pieței din ziua evenimentului este neobișnuită
  - Taxa bancară, BET $r_{m,0} = -11{,}9\%$: paranteza este 2,12, deci t pentru TLV se reduce în valoare absolută, de la $-10{,}0$ la $-6{,}85$
  - BRD: $AR_0 = -5{,}6\%$, $t = -4{,}03$
- Mai multe firme: standardizăm fiecare AR cu propria eroare de predicție și folosim dispersia transversală, robustă la dispersia indusă de eveniment Boehmer, Musumeci & Poulsen (1991)

Studii de eveniment: inferența corectă (2/2)

- Cînd evenimentul are loc în aceeași zi pentru toate firmele: randamentele anormale sînt corelate transversal, iar testele transversale resping ipoteza nulă prea des
- Testul pe portofoliul egal ponderat ține cont deja de corelație
  - TLV și BRD: $\bar{\varrho} = 0{,}153$
  - pentru AR_0 mediu, t calculat în ipoteza independenței $= -7{,}55$, iar t calculat pe portofoliu $= -7{,}03$
  - $\bar{\varrho}$: corelația medie dintre randamentele anormale ale firmelor
  - N: numărul de firme
  - Kolari & Pynnönen (2010) corectează un test transversal cu $\sqrt{(1-\bar{\varrho})/(1+(N-1)\bar{\varrho})}$
  - cu zece astfel de firme, $(1+9\bar{\varrho})/(1-\bar{\varrho}) = 2{,}81$: testul ar subestima de 2,81 ori dispersia lui AR mediu

Size, value, momentum și data snooping

- Rezistă tiparele de calendar și explicațiile comportamentale verificărilor de risc și data snooping?
- Reia: concluzii care rezistă verificării
- Teme
- Cuprins

- Size compară capitalizări bursiere mici și mari
  - value compară acțiuni ieftine față de fundamente, precum capitalul propriu contabil, cu acțiuni scumpe.
- Cross-sectional momentum ordonează activele: dacă A a cîștigat 10%, iar B 2%, o strategie relativă poate cumpăra A și vinde B în lipsă.
- Time-series momentum folosește semnul trecutului fiecărui activ: în acel exemplu, atît A cît și B primesc semnal pozitiv.
- Data snooping alege o regulă după încercarea multor variante pe aceleași date
  - raportarea doar a celei mai bune zile ascunde șansa unui rezultat norocos.

ETF-uri, placebo și price discovery

ETF: Exchange-Traded Fund — fond tranzacționat la bursă.

- Un spot ETF este un fond tranzacționat la bursă care deține activul suport
  - o unitate oferă expunere prin fond, în locul unui contract futures.
- Un contract futures fixează azi condițiile unei tranzacții viitoare
  - buy-and-hold înseamnă păstrarea poziției cumpărate, fără schimbarea semnului după un semnal.
- Un placebo repetă analiza la o dată fără eveniment: o schimbare aparentă similară în 2019 slăbește afirmația că lansarea din 2024 a produs schimbarea.
- Price discovery este încorporarea informației în prețuri: dacă piața A reacționează prima la știre și B o urmează, A poate contribui mai mult la price discovery.

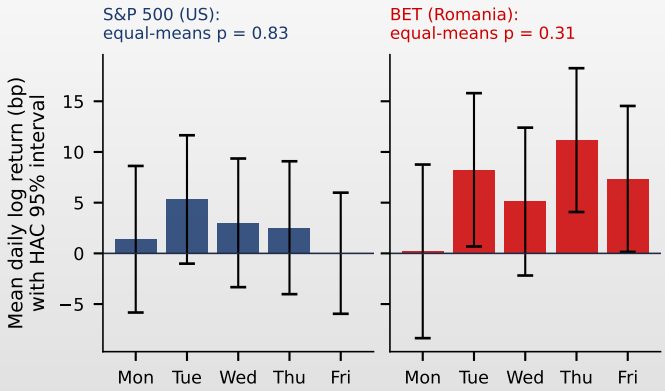
Anomalii și efecte de calendar (1/2)

- O **anomalie** este un tipar al randamentelor pe care modelul de evaluare nu îl poate explica: un factor de risc omis (model greșit specificat), o evaluare greșită (eroare comportamentală) sau data mining
  - Familii: de calendar, pe serii de timp (momentum-ul indicelui), transversale (mărime, valoare, momentum: **Capitolul 3**)
  - Randamentele anomaliilor sînt cu 26% mai mici în afara selecției și cu 58% mai mici după publicare McLean & Pontiff (2016)

Anomalii și efecte de calendar (2/2)

- Efecte de calendar: efectul zilei de luni French (1980), efectul lunii ianuarie Rozeff & Kinney (1976), efectul schimbării lunii (TOM, turn of the month: ultima zi de tranzacționare și primele trei ale lunii următoare) Lakonishok & Smidt (1988)și efectul lunar (prima jumătate a lunii) Ariel (1987)
  - Ziua săptămînii: $r_t = \sum_{d=1}^{5} \beta_d D_{d,t} + u_t$, testul Wald pentru $\beta_1 = \cdots = \beta_5$ (patru restricții de egalitate, reper χ^2_4)
  - TOM și ianuarie: cîte o variabilă indicator
  - $D_{d,t} = 1$ dacă ziua t este ziua săptămînii d (luni, ..., vineri), altfel 0
  - β_d: randamentul mediu din ziua d
  - u_t: reziduul
  - Erori HAC Newey–West Newey & West (1987), cu 5 laguri zilnice sau 3 laguri lunare: reziduurile sînt heteroscedastice și autocorelate

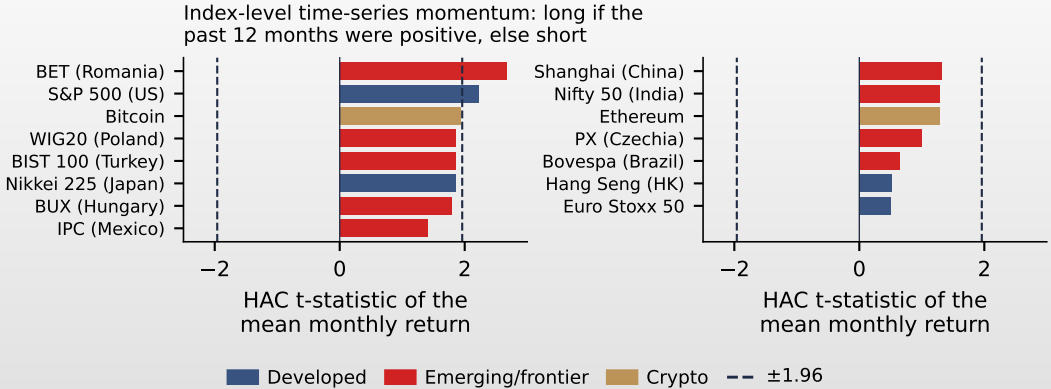
Efectul zilei săptămînii: S&P 500 și BET



- Randamentul logaritmic zilnic mediu, pe zile ale săptămînii, în puncte de bază (bp; 1 bp = 0,01%), 2000–2026, intervale HAC de 95%
- S&P 500: randamentul mediu variază de la 0,0 bp (vineri) la 5,3 bp (marți)
- p-value-ul testului de egalitate a mediilor = 0,83: niciun efect al zilei de luni după 2000, spre deosebire de French (1980)
- BET: joi 11,2 bp ($t = 3{,}09$), totuși testul comun dă $p = 0{,}31$
- Trebuie deosebite două ipoteze nule: media unei zile este zero (acest test poate confunda efectul zilei cu randamentul mediu pozitiv)
- Toate cele cinci medii sînt egale (efectul zilei propriu-zis)

MFM_ch2_calendar_anomalies

Momentum și momentum pe serii de timp la nivel de indice (1/3)



MFM_ch2_tsmom

Momentum și momentum pe serii de timp la nivel de indice (2/3)

TSMOM: Time-Series MOMentum — momentum pe serii de timp.

- Revenirea acțiunilor cu performanțe slabe pe un orizont de 3–5 ani De Bondt & Thaler (1985)
- Momentum transversal pe 3–12 luni Jegadeesh & Titman (1993) (Capitolul 3)
- TSMOM Moskowitz, Ooi & Pedersen (2012): semnalul $s_t = \text{sign}\left(\sum_{j=1}^{12} r_{t-j}\right)$
  - $+1$ (poziție lungă) dacă suma ultimelor 12 randamente logaritmice lunare este pozitivă, -1 (poziție scurtă) altfel
  - Randamentul strategiei este $s_t R_t$, R_t: randamentul indicelui în luna t
  - bare: t HAC (6 laguri)
- Semnificativ pentru BET ($t = 2{,}68$, 1,40% pe lună) și S&P 500 ($t = 2{,}22$)

Momentum și momentum pe serii de timp la nivel de indice (3/3)

- Pentru Bitcoin, $t = 1{,}94$
- Raportul Sharpe al TSMOM este sub cel al strategiei buy-and-hold: BET 0,65 față de 0,75, S&P 500 0,48 față de 0,52: o mare parte din randamentul TSMOM provine din prima de risc a acțiunilor (equity premium), obținută prin pozițiile lungi
  - anualizate ($\sqrt{12}\times$ media/SD lunară), pe randamente de preț, fără scăderea dobînzii fără risc: nu se compară direct cu raportul Sharpe lunar din exemplul de prognoză
- Limitele datelor: indici de preț fără dobînzi de finanțare sau dividende, 15 piețe testate
- Tabelul complet: vezi Anexa

MFM_ch2_tsmom

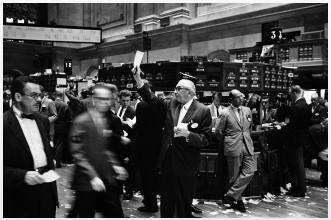
Noțiuni comportamentale: definiții și exemple

- Loss aversion acordă pierderilor o greutate mai mare decît cîștigurilor egale față de un reper: pierderea a 100 poate conta mai mult decît cîștigul a 100.
- Prospect theory evaluează cîștiguri și pierderi față de un reper, cu sensibilitate descrescătoare și ponderarea probabilităților
  - include mai mult decît loss aversion.
- Disposition effect este tendința de a vinde pozițiile pe cîștig și de a păstra pozițiile pe pierdere: vinzi la 110 o acțiune cumpărată la 100, dar refuzi să vinzi alta la 90.
- Anchoring acordă greutate excesivă unui număr inițial: tratezi prețul de cumpărare 100 ca țintă chiar după știri care schimbă valoarea.

Convingeri, atenție și herding

- Overconfidence supraestimează precizia propriilor convingeri: un trader tratează o prognoză incertă ca aproape sigură și tranzacționează prea mult.
- Limited attention lasă informație relevantă neprelucrată: investitorul reacționează la titlul unei știri, dar ratează cifrele datoriei din raport.
- Herding înseamnă urmarea acțiunilor altora: cumperi fiindcă alți traderi cumpără, fără o evaluare independentă a valorii.
- Underreaction ajustează inițial prea puțin prețul la știre
  - overreaction îl ajustează prea mult și este urmată de inversare.
  - Niciuna nu este demonstrată de o singură mișcare de preț.

Psihologia în prețuri, de la ring la rețelele sociale (1/2)



Ringul Bursei din New York, 1963

Foto: Thomas J. O'Halloran (1963); domeniu public; Wikimedia Commons

- **Volatilitate excesivă** Shiller (1981): prețurile variază mult mai mult decît dividendele care ar trebui să le justifice
- **Reacție excesivă**: sursa inversării pe 3–5 ani De Bondt & Thaler (1985)
- Portrete: vezi Anexa
- **Teoria perspectivei** Kahneman & Tversky (1979): pierderile cîntăresc mai mult decît cîștigurile față de un punct de referință
  - Efectul de dispoziție: activele profitabile sînt vîndute prea devreme, iar cele cu pierderi sînt păstrate prea mult

Psihologia în prețuri, de la ring la rețelele sociale (2/2)

- **Excesul de încredere** duce la prea multe tranzacții, iar **ancorarea** și **atenția limitată**, la o reacție lentă la știri, o cauză posibilă a momentum-ului
- **Comportamentul de turmă** Pele, Mazurencu-Marinescu & Nijkamp (2013): manifestat odinioară în ringul bursier și astăzi prin registre de ordine, algoritmi și rețele sociale (Capitolul 10)
- Erorile comportamentale nu anulează singure eficiența: arbitrajorii raționali ar putea exploata abaterile de preț produse de aceste erori. Pot face acest lucru?

Limitele arbitrajului



Andrei Shleifer, Harvard

Foto: Manuel Castells (2018); CC BY-SA 2.0; Wikimedia Commons

- Shleifer & Vishny (1997): arbitrajul real este riscant și are nevoie de capital
- **Noise-trader risk** De Long, Shleifer, Summers & Waldmann (1990): abaterea prețului de la valoarea fundamentală se poate accentua înainte de a se corecta
  - Noise traders: investitori care tranzacționează pe baza unor semnale fără conținut informațional (sentiment, zvonuri)
- Constrîngeri de finanțare: administratorii pierd clienți după pierderi și trebuie să închidă pozițiile în cel mai rău moment
- Costuri: limite la vînzarea în lipsă, marje, costuri de tranzacționare, lipsa substituților perfecți
- Anomaliile pot persista unde arbitrajul este dificil: pe piețe mici și nelichide, precum BET, găsim într-adevăr cea mai puternică persistență
- AMH reconciliază cele două perspective: comportamentul rațional și cel afectat de erori coexistă și evoluează

Machine learning și proiectarea cercetării

- Cum evaluăm corect un model flexibil sau un design de cercetare?
- Reia: prognoze pe date noi
- Teme
- Cuprins

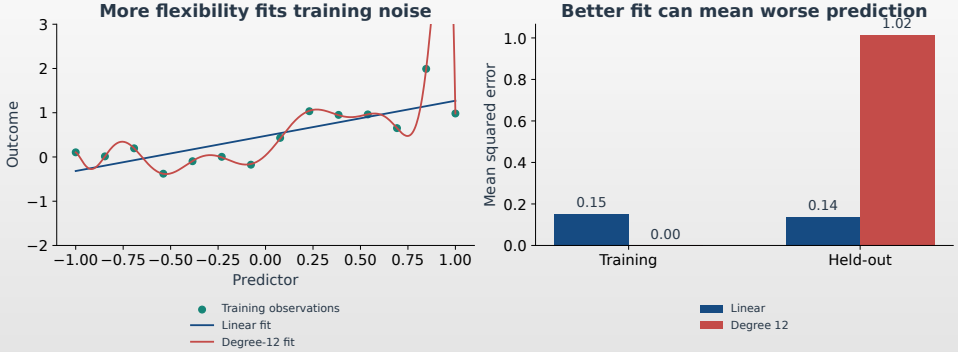
Instrumente pentru evaluarea unei afirmații despre eficiență

- Reia testele variance ratio robuste.
- Citește definițiile spot ETF și price discovery.
- Reia evaluarea out-of-sample.

Învățare, validare și leakage

- Un decision tree împarte observațiile după praguri ale predictorilor
  - o neural network combină transformări neliniare ponderate, învățate din date.
- Exemplu: un arbore poate prognoza diferit cînd volatilitatea trecută depășește 2%
  - flexibilitatea poate potrivi și tipare accidentale din selecție (overfitting).
- Cross-validation evaluează subseturi excluse din estimare
  - walk-forward validation respectă timpul, de exemplu estimezi pînă în 2020 și testezi în 2021.
- Leakage folosește informație indisponibilă la data prognozei: o cifră contabilă revizuită în 2022 nu poate intra într-o prognoză făcută în 2020.

Overfitting: ajustare versus prognoză



Simulare ilustrativă: curba flexibilă ajustează mai bine zgomotul din selecție, dar are eroare mai mare pe datele excluse. Modelele folosesc aceleași date de estimare.

Învățarea automată și piețele eficiente

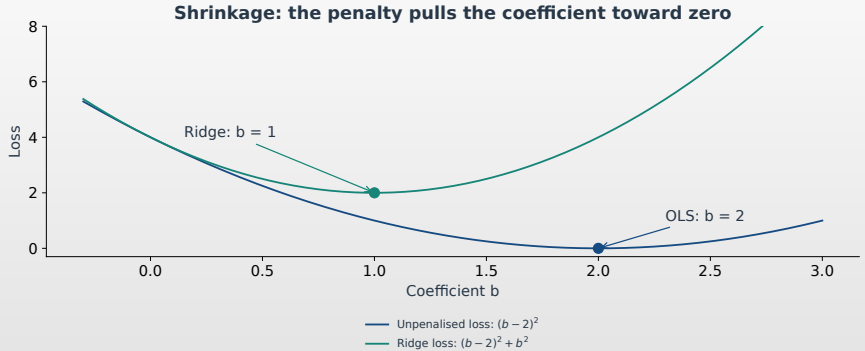
ML: Machine Learning — învățare automată.

- Metodele ML (învățare automată) construiesc reguli de predicție din date și surprinde tipare neliniare pe care testele de autocorelație le ratează (Capitolul 13)
- Gu, Kelly & Xiu (2020): arborii și rețelele neuronale aduc cîștiguri economice mari față de regresiile liniare pe secțiunea transversală a acțiunilor din Statele Unite ale Americii, deși R^2 lunar al acestora în afara selecției este sub 1%
- Modelele lingvistice mari citesc știri și raportări: Tak & Pele (2025) prognozează tendințele acțiunilor cu LLaMA
- Ce adaugă ML la precauțiile acestui capitol: **validarea cronologică**
  - modelul se antrenează doar pe datele disponibile înaintea fiecărei prognoze (walk-forward)
  - validarea încrucișată aleatoare introduce informație din viitor (leakage, look-ahead bias)
- Întrebarea-cheie: cînd sînt disponibili mulți predictori, ce înseamnă o respingere a eficienței în selecție (in-sample)? Studiul de caz oferă un răspuns

Învățare bayesiană și shrinkage

- Prior descrie incertitudinea parametrului înainte de datele noi
  - likelihood măsoară compatibilitatea datelor cu fiecare parametru
  - regula lui Bayes le combină într-un posterior.
- Exemplu: o medie prior 0, incertă, și o estimație din date de 2, cu aceeași precizie, dau media posterior 1 într-un model Normal.
- Ridge adaugă la criteriul OLS o penalizare proporțională cu pătratele coeficienților
  - shrinkage apropie coeficienții de zero pentru a reduce dispersia estimării.
- Într-un exemplu cu un coeficient, minimizarea lui $(b-2)^2 + b^2$ dă $b = 1$, față de 2 fără penalizare
  - shrinkage acceptă bias pentru dispersie mai mică.

Ridge: cum schimbă penalizarea optimul



Fără penalizare, minimul este la b = 2. Penalizarea cu pătratul coeficientului mută minimul la b = 1.

Studiu de caz: învățare rațională cu mulți predictori (1/2)

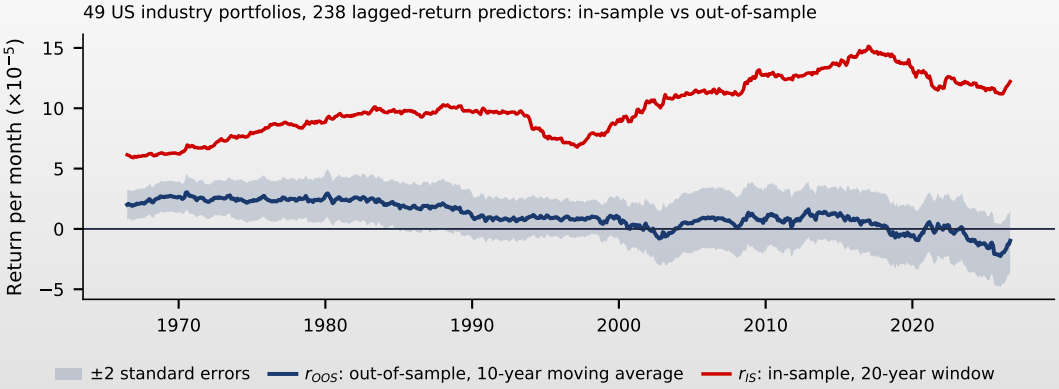
- Martin & Nagel (2022): investitorii evaluează N active ale căror fluxuri de numerar depind de J caracteristici, cu coeficienți **necunoscuți**, pe care îi învață optim (bayesian) din datele trecute
- întrebarea de cercetare: vezi Anexa
  - media a posteriori este o regresie ridge (OLS cu penalizarea sumei pătratelor coeficienților): prin shrinkage, coeficienții sînt apropiați de 0
  - investitorii sînt neutri la risc, deci predictibilitatea nu poate fi explicată printr-o primă de risc
- **În selecție**: cu $J/N \to \psi > 0$ testul de absență a predictibilității respinge ipoteza nulă cu o probabilitate care tinde la 1 (Martin & Nagel (2022), Prop. 4)

Studiu de caz: învățare rațională cu mulți predictori (2/2)

OOS: Out-of-Sample — în afara selecției de estimare; abreviat OS în indicele formulei.

- Rezultatele formale: vezi Anexa
  - ψ: limita numărului de predictori pe activ, J/N
  - respingerea nu dovedește iraționalitatea: ipoteza nulă a așteptărilor raționale este reperul greșit cînd parametrii trebuie învățați
- **În afara selecției**: un portofoliu construit cu coeficienți din alte perioade are $\mathbb{E}[r_{OOS}] = 0$ (Martin & Nagel (2022), Prop. 6)
  - r_{OOS}: randamentul acelui portofoliu într-o perioadă nefolosită la estimarea coeficienților
  - testele în afara selecției își păstrează sensul economic: în acest model, ele permit testarea eficienței
- Acțiunile americane: R^2 în selecție de circa 1%, stabil, iar în afara selecției mult mai mic și la mai puțin de două erori standard de 0 după 2014 (Fig. 8 din Martin & Nagel (2022)). Modelul, simulările și planul empiric: Anexă

Replicare pe datele cursului: în selecție și în afara selecției (1/2)



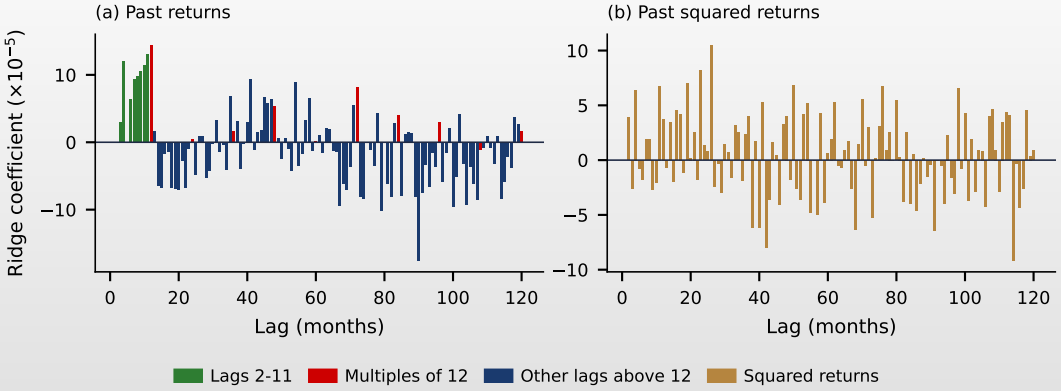
MFM_ch2_big_data

Replicare pe datele cursului: în selecție și în afara selecției (2/2)

- 49 de portofolii sectoriale (Kenneth French Data Library), iulie 1926 – august 2026, 238 de predictori din randamente decalate, OLS pe ferestre mobile de 20 de ani, specificația din secț. 7 a lucrării Martin & Nagel (2022)
- r_{IS} (randamentul în selecție, in-sample, al portofoliului construit din prognoze): de la 5,90 la 15,14 ($\times 10^{-5}$ pe lună), pozitiv prin construcție
- R^2 mediu în selecție: 5,4%
- r_{OOS} (randamentul în afara selecției, out-of-sample, al aceluiași portofoliu), 842 de luni: media $1{,}05 \times 10^{-5}$, circa 11% din r_{IS}
- pînă în iunie 1986, media este la 4,16 erori standard peste 0, iar după aceea la 0,62
- Benzile (± 2 SE) sînt descriptive, nu un test pentru $\mathbb{E}[r_{\text{OOS}}] = 0$
- Folosirea a 49 de portofolii în loc de mii de acțiuni face ca J/N să fie mare
- Detalii: vezi ▸ Anexa

MFM_ch2_big_data

Replicare pe datele cursului: coeficienții ridge pe laguri (1/2)



MFM_ch2_big_data

Replicare pe datele cursului: coeficienții ridge pe laguri (2/2)

- Ridge pe întreaga selecție, ianuarie 1971 – august 2026, penalizarea prin validare încrucișată cu cîte un an exclus (56 de ani)
- Comparați cu Fig. 7 din Martin & Nagel (2022)
- Coeficienții lagurilor 2–11: 8 din 10 pozitivi, **momentum** Jegadeesh & Titman (1993)
- Coeficienții lagurilor multiplu de 12: 9 din 10 pozitivi, **sezonalitate** Heston & Sadka (2008)
- Coeficienții celorlalte laguri peste 12: 67% negativi, **inversare** pe termen lung De Bondt & Thaler (1985)
- Coeficienții randamentelor la pătrat nu au un semn dominant
- R^2 din validarea încrucișată $= 0{,}013\%$ (OLS: $-2{,}26\%$): estimarea cu shrinkage reproduce tiparele anomaliilor cunoscute, dar acestea au o putere predictivă aproape nulă în anii excluși
- limite și extinderi: Anexă

MFM_ch2_big_data

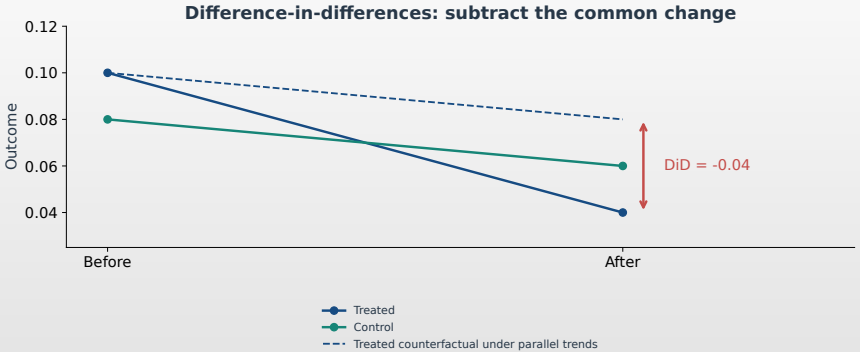
Ipoteză: efectul ETF-urilor spot asupra eficienței lui Bitcoin

- O propunere tipică a asistentului: „ETF-urile spot pe Bitcoin din Statele Unite ale Americii (tranzacționate din 11 ianuarie 2024) au adus arbitrajori, deci Bitcoin a devenit mai eficient"
- Bucla de descoperire, parcursă o singură dată
- Prompturi reutilizabile: vezi Anexa
  - **literatură**: Kia, Liu, Li, Song & Xu (2025) arată că după ETF-urile spot piața spot a redevenit locul dominant al descoperirii prețului
  - Tran & Leirvik (2020): eficiența criptoactivelor variază și a crescut (verificați personal fiecare DOI)
  - **ipoteză**: $H_0 : \rho_{1,\text{post}} = \rho_{1,\text{pre}}$, două ferestre de aceeași lungime în jurul datei lansării (prima zi de tranzacționare)
  - **date și cod**: prețul zilnic de închidere al lui Bitcoin (în USD), din care se replică întîi $\hat{\rho}_1 = -0{,}022$ din capitol, pe întreaga selecție
- Verificări stabilite înainte de a vedea rezultatele
- Motivarea fiecăreia: vezi Anexa
  - erori standard robuste (nu $1/\sqrt{T}$), ferestre egale, doar data lansării plus date placebo
  - un activ de control pentru factorii de confuzie (halving-ul din aprilie 2024, dobînzile, intrările de capital)
  - o corecție pentru fiecare statistică încercată și efectul minim detectabil

Difference-in-differences: exemplu și condiții

- DiD scade schimbarea înainte–după din grupul de control din schimbarea grupului tratat.
- Dacă rezultatul grupului tratat scade de la 0,10 la 0,04, iar al controlului de la 0,08 la 0,06, DiD este $(0{,}04 - 0{,}10) - (0{,}06 - 0{,}08) = -0{,}04$.
- Parallel trends înseamnă că grupurile ar fi avut aceeași schimbare fără tratament
  - tendințele anterioare similare susțin, dar nu dovedesc acest scenariu neobservat.
- Absența anticipării exclude reacția înainte de tratament
  - absența spillover exclude afectarea controlului, de exemplu un ETF Bitcoin care schimbă și tranzacționarea Ethereum.

Difference-in-differences: interpretarea contrastului



Rezultatul tratat scade cu 0,06, iar controlul cu 0,02. Scăderea suplimentară este 0,04; interpretarea cauzală cere condițiile precizate.

Estimare și putere (1/2)

- Test: două ferestre de 982 de zile în jurul datei de 11 ianuarie 2024
- $z = \Delta\hat{\rho}_1 / \sqrt{s_{\text{pre}}^2 + s_{\text{post}}^2}$, erori standard robuste s
  - $\Delta\hat{\rho}_1 = \hat{\rho}_{1,\text{post}} - \hat{\rho}_{1,\text{pre}}$
  - s_{pre}, s_{post}: erorile standard robuste ale celor două estimații (ferestrele sînt independente)
  - înainte (mai 2021 – ian. 2024): $\hat{\rho}_1 = -0{,}036$ ($s = 0{,}042$), VR(5) $= 1{,}000$ ($z^* = 0{,}00$)
  - după (ian. 2024 – sept. 2026): $\hat{\rho}_1 = -0{,}050$ ($s = 0{,}049$), VR(5) $= 0{,}939$ ($z^* = -0{,}64$)
  - $\Delta\hat{\rho}_1 = -0{,}014$, $z = -0{,}21$: testul nu respinge ipoteza că ρ_1 a rămas neschimbat

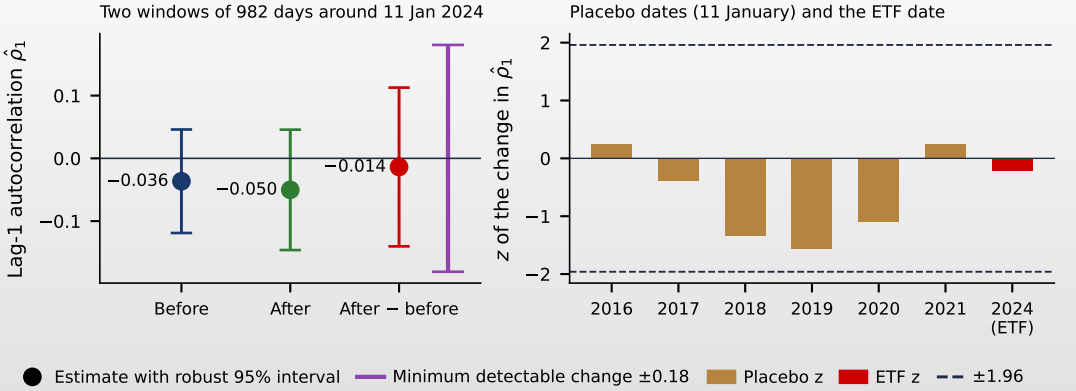
Estimare și putere (2/2)

MDE: Minimum Detectable Effect — efectul minim detectabil.

- **Efectul minim detectabil (MDE)**: cea mai mică schimbare reală care poate fi detectată cu o putere de 80% la nivelul de semnificație de 5%
  - $\text{MDE} = (z_{0,975} + z_{0,80}) \times \text{SE}(\Delta\hat{\rho}_1) \approx 2{,}8 \times \text{SE} = 0{,}18$, z_p: cuantila de ordin p a distribuției Normale standard (1,96 și 0,84)
  - dacă Bitcoin era deja aproape eficient înainte de 2024, acest plan de testare nu ar putea detecta o îmbunătățire mai mică
- Placebo la 11 ianuarie 2016–2021: 0 din 6 rezultate semnificative, cel mai mare $|z| = 1{,}57$
- O concluzie cauzală ar necesita și un activ de control (Ethereum înaintea propriilor ETF-uri, din iulie 2024), tendințe paralele înainte de lansare, absența anticipării și a efectelor de spillover

ai_discovery_case.py

Ministudiu de caz: estimare, placebo și MDE (1/2)



ai_discovery_case.py

Ministudiu de caz: estimare, placebo și MDE (2/2)

- Stînga: $\hat{\rho}_1$ înainte și după, cu intervale robuste de 95%
- Diferența, împreună cu $\pm$MDE
- Dreapta: z pentru ETF se află în intervalul valorilor obținute pentru cele șase date placebo
- Pentru placebo se încarcă randamentele Bitcoin din 2 ianuarie 2011; fiecare dată are 982 de randamente înainte și după, inclusiv în 2016 și 2017.
- „Nesemnificativ" nu înseamnă „fără efect": MDE este de cîteva ori mai mare decît estimația
- O variabilă-rezultat mai bună: descoperirea prețului intrazilnic între piețe, nu ρ_1 zilnic

ai_discovery_case.py

Temă de proiect propusă

AI: Artificial Intelligence — inteligență artificială.

- **Întrebare**: au schimbat ETF-urile spot eficiența variabilă în timp a lui Bitcoin, în comparație cu un activ de control?
  - VR și DFA pe ferestre mobile (acest capitol) pentru Bitcoin și Ethereum
  - Ethereum nu este „tratat" pînă în iulie 2024
  - dacă tendințele paralele, absența anticipării și a efectelor de spillover nu sînt plauzibile, raportați diferențe descriptive, nu cauzale
- **Replicați întîi**: autocorelațiile anuale ale lui Bitcoin din capitol și cifrele din ministudiul de caz
- Notați ce serie de prețuri Bitcoin și ce primă dată folosește fiecare fereastră, inclusiv ferestrele placebo
- **Preînregistrați**: H_0, H_1, date, ferestre și corecții, înregistrate printr-un commit înainte de obținerea rezultatelor
- **Raportați**: inferență robustă, teste placebo și MDE
- Codul, sub formă de Quantlet
- **Jurnale**: prompturile în `AI_USE.md`
- Fiecare eroare depistată (o eroare standard i.i.d., o referință inventată) în `AI_ERRORS.md`

Sinteză, autoverificare și următorul pas: Capitolul 3

Cinci pași pentru orice afirmație despre eficiență

- **Mulțimea de informații**: ce $\mathcal{I}_t$ (prețuri trecute, știri publice)?
- **Ipoteza nulă**: RW1, RW3 sau diferența de martingal, formulată împreună cu modelul de risc
- **Statistica**: folosim o estimare a dispersiei validă în prezența volatility clustering
- **Incertitudinea**: orizonturile, piețele și ferestrele încercate
- Dovezi în afara selecției
- **Economia**: respingere $\neq$ profit exploatabil $\neq$ piață irațională

Autoverificare

- De ce poate fi respinsă RW3 pentru S&P 500, deși piața rămîne eficientă în sens economic?
- De ce $H(20) > 0{,}5$ pentru BET nu dovedește memoria lungă?
- Care dintre cele două rezultate, persistența BET sau nerespingerea pentru Bitcoin, ar rămîne valabil dacă schimbăm testul, fereastra și metoda de inferență?
- Următorul pas, Capitolul 3: randamente ajustate la risc cu modele factoriale și factor zoo
- Cursuri avansate și manuale: vezi ▸ Anexa

Anexă: pionierii, Bachelier și Samuelson



Louis Bachelier (1870–1946)

Foto: autor necunoscut; domeniu public; Wikimedia Commons



Paul A. Samuelson

Foto: Bernard Gotfryd (1970–1975); domeniu public; Wikimedia Commons

- Bachelier (1900): prețurile obligațiunilor de stat franceze urmează un mers aleator
  - „Speranța matematică a cîștigului speculatorului este zero”
- Samuelson (1965): dacă prețurile sînt **anticipate corect**, variațiile lor sînt imprevizibile
- Ambele rezultate stau la originea ipotezei pieței eficiente

înapoi

Anexă: Eugene Fama



Eugene F. Fama, Premiul Nobel 2013

Foto: Bengt Nyman (2013); CC BY 2.0; Wikimedia Commons

- Fama (1970) a formulat definiția folosită în acest capitol și cele trei forme ale eficienței
- Premiul Nobel 2013, împărțit cu Robert Shiller (sceptic în privința eficienței) și Lars Peter Hansen
- Actualizare și sinteză: Fama (1991)
- O critică accesibilă: Malkiel (2003)

înapoi

Anexă: tabel de sinteză, teste de eficiență slabă 2000–2026

Piața	T	$\hat{\rho}_1$	SE robustă	$\widehat{\mathrm{VR}}(5)$	$z^*(5)$	CD p	Secvențe z
S&P 500	6 714	−0,099	0,027	0,830	−2,77	0,001	4,34
Euro Stoxx 50	6 836	−0,029	0,019	0,910	−2,08	0,097	3,41
Nikkei 225 (Japonia)	6 545	−0,038	0,024	0,923	−1,48	0,317	1,97
Hang Seng (HK)	6 583	−0,004	0,024	0,967	−0,64	0,872	−0,17
BET (România)	6 670	0,109	0,028	1,173	2,98	0,001	−6,05
WIG20 (Polonia)	6 685	0,018	0,018	1,009	0,24	0,777	2,25
BUX (Ungaria)	6 666	0,037	0,024	1,013	0,26	0,427	−0,42
PX (Cehia)	6 682	0,052	0,032	1,041	0,59	0,350	−2,53
BIST 100 (Turcia)	6 692	0,005	0,024	1,033	0,64	0,949	−0,63
Bovespa (Brazilia)	6 622	−0,028	0,025	0,928	−1,29	0,521	0,88
IPC (Mexic)	6 689	0,070	0,019	1,039	0,93	0,001	−3,27
Nifty 50 (India)	6 606	0,048	0,024	1,048	0,91	0,178	−5,46
Shanghai (China)	6 474	0,021	0,019	1,046	1,11	0,409	1,02
Bitcoin	4 384	−0,022	0,026	0,991	−0,19	0,835	2,68
Ethereum	3 913	−0,012	0,027	1,067	1,17	0,027	3,91
EUR/RON (curs de referință)	5 352	0,170	0,036	1,157	2,19	0,000	−1,66

- T: numărul de randamente zilnice
- CD: Chow–Denning pe $q = 2, 5, 10, 20$
- EUR/RON din iulie 2005, criptoactivele pe 365 de zile pe an

înapoi

Anexă: testul secvențelor pe toate piețele, alte teste VR

- z al testului secvențelor (tabelul de pe slide-ul anterior): Nifty 50 $-5{,}46$, IPC $-3{,}27$ (persistență pe piețele emergente)
- Ethereum 3,91, semnificativ, deși $\hat{\rho}_1$ nu este
- Choi (1999): un test VR automat care alege orizontul din date (estimare spectrală la frecvența zero)
- Versiuni wild bootstrap pentru selecții mici: Kim (2006)
- Aplicații pe piețele asiatice: Kim & Shamsuddin (2008)

înapoi

Anexă: alegerea lagurilor cu AIC și BIC

- **AIC**: Akaike Information Criterion — criteriul informațional Akaike.
- **BIC**: Bayesian Information Criterion — criteriul informațional bayesian.
- O penalizare descurajează adăugarea lagurilor doar fiindcă ajustarea se îmbunătățește întîmplător
  - testul automat compară ajustarea cu complexitatea.
- În criteriul de mai jos, AIC folosește penalizarea $2p$, iar BIC $p \ln T$, pentru p laguri incluse și T observații.
- La $T = 100$, un lag suplimentar costă 2 după AIC și circa 4,61 după BIC
  - un mic cîștig de ajustare nu justifică lagul în plus.

înapoi

Anexă: testul portmanteau automat al MDH

Noțiune necesară: AIC și BIC

- Escanciano & Lobato (2009): $AQ = T \sum_{j \le \tilde{p}} \hat{\gamma}_j^2 / \hat{\kappa}_j \to \chi^2_1$, cu $\hat{\gamma}_j = \frac{1}{T-j} \sum_t e_t e_{t-j}$ și $\hat{\kappa}_j = \frac{1}{T-j} \sum_t e_t^2 e_{t-j}^2$ (robust la heteroscedasticitate condiționată)
  - $\tilde{p} \le 10$ maximizează $Q_p = T \sum_{j \le p} \hat{\gamma}_j^2 / \hat{\kappa}_j$ minus o penalizare care trece de la BIC ($p \ln T$) la AIC ($2p$) cînd cel puțin un $\sqrt{T}|\hat{\rho}_j|$ este mare
- $e_t = r_t - \bar{r}$
- $\hat{\gamma}_j$: autocovarianța la lagul j
- $\hat{\kappa}_j$: dispersia ei robustă
- o valoare mare a lui AQ duce la respingerea MDH
- Statistica AQ: S&P 500 13,1 ($p = 0{,}0003$), BET 14,9 ($p = 0{,}0001$), Bitcoin 0,8 ($p = 0{,}385$)
- MDH este respinsă la 5% pentru 5 din cele 16 serii

Înapoi

Anexă: regresia predictivă, date și rezultate complete

FRED: Federal Reserve Economic Data — baza de date economice a Rezervei Federale (St. Louis).

- Randamentul logaritmic lunar în exces (cu dividende, minus dobînda T-bill la 3 luni), regresat pe dp_t decalat
  - Date: Shiller (2026) (S&P Composite, pînă în iunie 2026), prelungite cu mediile lunare ale închiderilor zilnice S&P 500 (scalate pe ultimele 12 luni comune) și cu dividendele fondului SPY
  - Randamentul titlurilor de stat americane la 3 luni (FRED, seria TB3MS; % anual), rata logaritmică lunară $\ln(1 + \text{TB3MS}/1\,200)$ decalată cu o lună
- OLS: $\hat{\beta} = 0{,}267$, SE Newey–West 0,293 (12 laguri), $t = 0{,}91$, t OLS $= 1{,}16$, $R^2 = 0{,}12\%$
- Panta corectată / SE HAC neajustată $= -0{,}22$: valoare doar ilustrativă, deoarece ignoră incertitudinea corecției
- Valoarea economică Campbell & Thompson (2008) (valoarea numerică apare pe slide-ul cu dovezile în afara selecției): creșterea proporțională a randamentului așteptat al investitorului care își ajustează expunerea
  - $\dfrac{R^2}{1 - R^2} \cdot \dfrac{1 + S^2}{S^2}$, S raportul Sharpe lunar
- t Diebold–Mariano Diebold & Mariano (1995) $= -0{,}57$ pentru aceleași prognoze, față de t Clark–West $= 0{,}42$

înapoi

Anexă: Harold Hurst și Nilul



Harold Edwin Hurst (1880–1978)

Foto: Elliott & Fry (1953); domeniu public; Wikimedia Commons



Nilometrul de pe insula Elefantina, Aswan

Foto: Olaf Tausch (2011); CC BY 3.0; Wikimedia Commons

- Hurst (1951) a proiectat lacuri de acumulare pe Nil
- constatarea lui și **rescaled range-ul**: vezi slide-ul R/S

înapoi

Anexă: funcția gamma

- Funcția gamma extinde factorialul: $\Gamma(x) = \int_0^\infty t^{x-1} e^{-t}\, dt$ pentru $x > 0$.
- Pentru întregi $n \geq 1$, $\Gamma(n) = (n-1)!$
  - de exemplu $\Gamma(4) = 6$, iar $\Gamma(1/2) = \sqrt{\pi}$.
- Aceste valori furnizează constantele din media exactă Anis–Lloyd
  - expresia este un reper sub randamente i.i.d. Normale, nu o tendință estimată.

înapoi

Anexă: media Anis–Lloyd

Noțiune necesară: funcția gamma

- Anis & Lloyd (1976): $\mathbb{E}[R_n/s_n]$ exact pentru randamente i.i.d. din distribuția Normală
  - $\mathbb{E}[R_n/s_n] = \dfrac{\Gamma((n-1)/2)}{\sqrt{\pi}\,\Gamma(n/2)} \sum_{i=1}^{n-1} \sqrt{\dfrac{n-i}{i}}$ (Γ: funcția gamma)
- Acest $\mathbb{E}[R_n/s_n]$ este referința care se scade în H_{AL} (slide-ul Analiza R/S)
- Estimările necorectate supraestimează memoria cu circa 0,04–0,05 pe date zilnice

Înapoi

Anexă: memorie lungă cu inferență, estimatorul Whittle local (1/2)

- $d = H - 0{,}5$, iar densitatea spectrală $f(\lambda) \sim G\lambda^{-2d}$ cînd $\lambda \to 0$ ($G > 0$ o constantă; $d > 0$: densitatea explodează la frecvențe joase, memorie lungă)
- estimarea folosește doar primele m frecvențe Fourier $\lambda_j = 2\pi j / T$
  - $\hat{d} = \arg\min_d \left[\ln\left(\frac{1}{m} \sum_{j=1}^{m} \lambda_j^{2d} I(\lambda_j) \right) - \frac{2d}{m} \sum_{j=1}^{m} \ln \lambda_j \right]$, I: periodograma
  - Robinson (1995): pentru $|d| < 1/2$, $m \to \infty$, $m/T \to 0$, f netedă în vecinătatea lui 0 și un proces liniar cu inovații de tip diferență de martingal, condiționat omoscedastice, $\sqrt{m}(\hat{d} - d) \to N(0, 1/4)$ fără a presupune distribuția Normală: un interval de încredere pentru parametru, în locul unei benzi sub ipoteza nulă

Înapoi

Anexă: memorie lungă cu inferență, estimatorul Whittle local (2/2)

- Estimații cu $m = T^{0,65}$ și intervalul de încredere de 95% $\hat{d} \pm 1{,}96/(2\sqrt{m})$
  - S&P 500: $\hat{d} = -0{,}013$, interval $[-0{,}069; 0{,}043]$
  - Bitcoin: $\hat{d} = 0{,}063$, interval $[-0{,}002; 0{,}127]$
  - BET: $\hat{d} = 0{,}118$, interval $[0{,}062; 0{,}174]$
  - Ethereum: $\hat{d} = 0{,}112$, interval $[0{,}045; 0{,}179]$
- Compromisul lățimii de bandă: un m mare include frecvențe la care autocorelația pe termen scurt (BET $\hat{\rho}_1 = 0{,}109$) deplasează $\hat{d}$ în sus
  - cu $m = T^{0,5}$, pentru BET se obține tot 0,135 (SE 0,056): o verificare de sensibilitate care susține, fără a demonstra, că valoarea $d > 0$ nu reflectă doar memoria scurtă
  - randamentele cu dinamică GARCH pot încălca și condițiile de mai sus

Anexă: EMH și AMH: comparație

	EMH	AMH
Investitorii	Raționali, optimizează	Raționalitate limitată, euristici
Eficiența	O proprietate de echilibru, testată ca restricție	O chestiune de grad, care se schimbă odată cu condițiile
Risc–randament	Prime de risc de echilibru, posibil variabile în timp	Se schimbă odată cu populația de investitori
Anomaliile	Factori de risc omiși sau data mining	Oportunități de profit temporare
Instrument empiric	Teste ale unei restricții de echilibru	Teste ale variației în timp și în funcție de starea pieței (ferestre mobile)

Înapoi

Anexă: eficiența lui Bitcoin în literatură

- Urquhart (2016): Bitcoin a fost ineficient în perioada 2010–2016; unele teste indică eficiență în subperioada a doua
  - Setul său de teste (Ljung–Box, secvențe, testul rangurilor Bartels (1982), VR automat, BDS, R/S) include BDS, care poate respinge ipoteza nulă chiar și numai din cauza volatility clustering: nu este un test al RW3
- Nadarajah & Chu (2017): cu o transformare de putere a randamentelor, Bitcoin este eficient în formă slabă
- Kristoufek (2018): piețele Bitcoin au fost în mare parte ineficiente în 2010–2017, iar eficiența lor s-a schimbat în timp
- Tran & Leirvik (2020): eficiența multor criptoactive variază în timp și crește
- Pele et al. (2023): criptoactivele au devenit o clasă de active distinctă; randamentele lor prezintă aceleași fapte stilizate ca alte piețe
- Estimările noastre, separat pentru fiecare an calendaristic (slide-ul Eficiența criptoactivelor an de an)
  - Bitcoin, autocorelația de ordinul 1 $\hat{\rho}_1$: $-0{,}002$ în 2011, $-0{,}071$ în 2012, $0{,}069$ în 2013, toate apropiate de zero
  - Statistica robustă a variance ratio-ului $z^*(5)$: cel mult 1,71 în valoare absolută, în toți anii și pentru toate criptoactivele, sub valoarea critică 1,96
  - Deci în primii ani nu respingem RW3, spre deosebire de Urquhart (2016)

Înapoi

Anexă: România, piață de frontieră, apoi emergentă

BVB: Bursa de Valori București.

- FTSE Russell (2019): România a fost reclasificată din piață de frontieră în piață emergentă secundară, decizie anunțată în septembrie 2019, cu efect de la 21 septembrie 2020
- Canale așteptate: mai mulți investitori străini, mai mulți analiști, mai multă lichiditate $\Rightarrow$ descoperirea mai rapidă a prețului
- Dovezi anterioare pentru BVB: crahuri și bule log-periodice Pele & Mazurencu-Marinescu (2012)
- Comportament de turmă pe o piață nelichidă Pele, Mazurencu-Marinescu & Nijkamp (2013)
- S-a îmbunătățit eficiența? Exercițiul C2 din seminar compară cei cinci ani dinainte și de după, folosind WIG20 și BUX ca grup de comparație și un bootstrap pe blocuri
  - Bootstrap pe blocuri: reeșantionează blocuri de zile consecutive pentru a păstra dependența Künsch (1989)
  - O comparație înainte/după este descriptivă dacă factorii de confuzie nu sînt controlați

înapoi

Anexă: viteza de ajustare a prețurilor

CME: Chicago Mercantile Exchange — Bursa de mărfuri din Chicago.

- La frecvență înaltă, prețurile futures reacționează în doar cîteva microsecunde la știrile macroeconomice programate
- Tak, Schlamp, Osterrieder & Pele (2026) măsoară această cursă la Eurex și CME
- Evenimente din piața criptoactivelor: Pele, Lin, Wang & Gaman (2025) studiază reacțiile pieței la etapele de dezvoltare Ethereum
- Viteza de ajustare este ea însăși o măsură a eficienței și depinde de tehnologie (Capitolul 10, microstructura pieței)

Înapoi

Anexă: Reality Check, SPA și StepM

SPA: Superior Predictive Ability (test) — testul abilității predictive superioare.

- Reality Check întreabă dacă cea mai bună dintre toate regulile încercate depășește reperul, folosind distribuția bootstrap a performanței maxime. White (2000)
- SPA standardizează performanța prin incertitudine (studentisation) și reduce influența regulilor slabe
  - un cîștig 2 cu SE 1 dă statistica studentizată 2. Hansen (2005)
- StepM testează întîi statistica cea mai puternică, apoi familia rămasă, cu praguri obținute prin reeșantionare comună
  - controlează FWER în condițiile sale. Romano & Wolf (2005)
- Exemplu: extragi aceleași luni pentru toate cele 15 reguli de calendar, păstrînd șocurile comune
  - reeșantionarea separată ar distruge această dependență.

Înapoi

Anexă: teste dependente, Reality Check, SPA și StepM (1/2)

Varianta explicată pe scurt

- Bonferroni și Holm ignoră corelația dintre teste (aceleași piețe, aceleași zile)
  - White (2000): Reality Check, bootstrap pentru $\max_j$, calculat pe toate regulile încercate
  - Hansen (2005): SPA, studentizat și mai puțin sensibil la regulile slabe
  - Romano & Wolf (2005): StepM (procedura step-down Romano–Wolf), control pas cu pas al FWER pe baza distribuției bootstrap **comune** a tuturor statisticilor

Înapoi

Anexă: teste dependente, Reality Check, SPA și StepM (2/2)

- Cele 15 teste de calendar: StepM cu bootstrap pe blocuri de 3 luni calendaristice, comune tuturor piețelor, 999 de replicări
  - Pragul critic al valorii p la primul pas: 0,0016 (Bonferroni: 0,0033)
  - 2 respingeri (efectul TOM la BET și BUX), ca la Holm
  - StepM este mai strict decît Bonferroni deoarece, la nivelul nominal de 5%, ratele de respingere bootstrap ale testelor HAC sînt 6,0% (ziua săptămînii), 6,4% (TOM), 6,4% (ianuarie)
- Pe baza a peste două milioane de strategii simulate, pragurile propuse sînt $|t| > 3{,}8$ (serii de timp) și 3,4 (transversal)
- Dacă aceste praguri sînt ignorate, circa 45% din respingeri sînt false Chordia, Goyal & Saretto (2020)
- Reducerea descoperirilor false mărește numărul celor ratate Harvey & Liu (2020)

Anexă: momentum pe serii de timp, toate pieţele

Piaţa	Media (%/lună)	t_{HAC}	Sharpe TSMOM	Sharpe buy-and-hold	$\hat{\rho}_1$ lunar
S&P 500	0,61	2,22	0,48	0,52	0,03
Euro Stoxx 50	0,16	0,51	0,11	0,16	0,05
Nikkei 225 (Japonia)	0,61	1,85	0,39	0,42	0,09
Hang Seng (HK)	0,18	0,53	0,10	0,19	0,04
BET (România)	1,40	2,68	0,65	0,75	0,19
WIG20 (Polonia)	0,67	1,86	0,36	0,26	0,02
BUX (Ungaria)	0,72	1,79	0,40	0,64	0,10
PX (Cehia)	0,38	0,99	0,24	0,45	0,10
BIST 100 (Turcia)	1,03	1,85	0,37	0,75	−0,08
Bovespa (Brazilia)	0,28	0,65	0,14	0,51	0,11
IPC (Mexic)	0,44	1,41	0,32	0,63	0,03
Nifty 50 (India)	0,50	1,29	0,28	0,64	0,02
Shanghai (China)	0,59	1,32	0,30	0,23	0,08
Bitcoin	4,47	1,94	0,72	1,08	0,13
Ethereum	6,50	1,28	0,57	0,90	0,16

- 307 de luni pentru indicii de acţiuni, mai puţine pentru criptoactive
- raportul Sharpe $\sqrt{12}\,\bar{x}/s_x$ al randamentelor de preţ ($\bar{x}$, s_x: media şi abaterea standard a randamentelor lunare ale strategiei), fără scăderea dobînzii fără risc
- Moskowitz, Ooi & Pedersen (2012) folosesc randamente în exces ale contractelor futures, scalate la o volatilitate ex ante de 40%

înapoi

Anexă: Robert Shiller și Richard Thaler



Robert J. Shiller, Premiul Nobel 2013

Foto: Bengt Nyman (2013); CC BY 2.0; Wikimedia Commons



Richard H. Thaler, Premiul Nobel 2017

Foto: Bengt Nyman (2017); CC BY 2.0; Wikimedia Commons

- Volatilitatea excesivă Shiller (1981) și reacția excesivă De Bondt & Thaler (1985): slide-ul despre psihologia în prețuri

înapoi

Anexă: studiul de caz, întrebarea de cercetare

- Martin & Nagel (2022): investitorii evaluează N active ale căror fluxuri de numerar depind de J caracteristici, cu coeficienți necunoscuți
- ce înseamnă respingerea ipotezei de absență a predictibilității cînd J este comparabil cu N?
  - coeficienții trebuie estimați din date istorice: o problemă de predicție cu multe variabile, ca în învățarea automată
- Eficiența semi-tare: prețurile „reflectă complet" informația publică Fama (1970)
- Două interpretări
  - investitorii cunosc parametrii modelului fluxurilor de numerar (așteptări raționale: ipoteza nulă a majorității testelor de eficiență)
  - investitorii își actualizează optim convingerile prin inferență bayesiană, folosind datele disponibile la momentul deciziei
- De ce contează: sute de predictori ai randamentelor găsiți în selecție, așa-numitul factor zoo Harvey, Liu & Zhu (2016)
- Textele, imaginile din satelit și rețelele sociale măresc continuu J
  - fiecare predictor semnificativ are oare nevoie de o explicație prin risc sau de una comportamentală?
- Legătura cu acest capitol: predictibilitatea în selecție și cea în afara selecției Campbell & Thompson (2008), Goyal, Welch & Zafirov (2024) și declinul anomaliilor după publicare McLean & Pontiff (2016)

înapoi

Anexă: studiul de caz, model și metodă (1/2)

- **Model** (Martin & Nagel (2022), sect. 2)
  - creșterea fluxurilor de numerar $\Delta y_t = Xg + e_t$, cu $e_t \sim N(0, I)$ și o rată a dobînzii egală cu zero
  - Δy_t: cele N rate de creștere ale fluxurilor de numerar
  - X: matricea $N \times J$ a caracteristicilor
  - g: cei J coeficienți necunoscuți
  - I: matricea identitate
- **Învățarea** (Prop. 1–2)
  - distribuția a priori $g \sim N(0, (\theta/J)\, I)$, care coincide cu distribuția reală din care este extras g
  - θ: intensitatea semnalului
  - randamentul realizat = reacția insuficientă (underreaction) produsă de shrinkage + zgomotul de estimare + șocul imprevizibil
- **Analiză asimptotică și simulări** (sect. 4)
  - $N, J \to \infty$ cu $J/N \to \psi > 0$
  - simulări cu $N = 1\,000$, elementele lui X extrase din distribuția Normală standard și $\theta = 1$

Înapoi

Anexă: studiul de caz, model și metodă (2/2)

- **Teste**
  - în selecție: o regresie OLS transversală a lui r_{t+1} pe X (cere $J < N$), cu un test χ^2 comun
  - în afara selecției: un portofoliu cu ponderile $\frac{1}{N} X h_{s+1}$, construite din coeficienți estimați în alte perioade
  - $r_{\text{OOS},t+1} = \frac{1}{N}\, h_{s+1}' X' r_{t+1}$, $s \neq t$ (ec. 19)
  - r_{IS}: la fel, cu $s = t$
  - h_{s+1}: vectorul coeficienților estimați
  - r_{t+1}: cele N randamente
- **CRSP**: Center for Research in Security Prices — Centrul de cercetare a prețurilor titlurilor (Universitatea din Chicago).
- **NYSE**: New York Stock Exchange — Bursa din New York.
- **Planul empiric** (secț. 7)
  - acțiunile americane din CRSP, fără cele sub percentila 20 a capitalizării NYSE sau cu prețul sub 1 \$
  - predictori: randamentele lunare simple și pătratele lor, cu lagurile $t-2$ pînă la $t-120$ (238 de predictori), centrate și standardizate transversal în fiecare lună
  - regresie ridge pe întreaga selecție, 1971 – iunie 2019, cu penalizarea aleasă prin validare încrucișată cu cîte un an exclus
  - regresiile OLS pe ferestre mobile de 20 de ani dau r_{OOS} începînd din ianuarie 1956

înapoi

Anexă: studiul de caz, rezultatele formale

- În selecție (Prop. 4 din Martin & Nagel (2022), slide-ul principal): pentru $\psi > 0{,}4$ ($\theta = 1$, o perioadă de învățare) probabilitatea de a nu respinge ipoteza nulă este de ordinul $e^{-0{,}015N}$ (Fig. 2)
- Simulări ($N = 1\,000$, patru perioade de învățare): un test cu nivelul nominal de 5% respinge ipoteza nulă cu o probabilitate de peste 90% de îndată ce $J > N/2$ (Fig. 3b)
  - nu este o distorsiune a nivelului testului: componenta predictibilă în selecție chiar există în prețuri
- Teste cu cîte un singur predictor și control k-FWER (probabilitatea a cel puțin k respingeri false este cel mult 5%): pentru $k = 20$ și $J/N = 0{,}05$, probabilitatea a cel puțin k respingeri este 25%, nu 5%
- Probabilitatea ajunge la circa 80% pentru J/N apropiat de 1 (Fig. 4)
  - corecțiile pentru testare multiplă nu rezolvă problema: problema este ipoteza nulă, nu testul
- În afara selecției: $\mathbb{E}[r_{\text{OOS},t+1}] = 0$ este valabil atît în ordine cronologică, cît și în ordine inversă (Prop. 6)
- Media este pozitivă doar dacă investitorii aplică un shrinkage mai puternic decît justifică datele (Fig. 6)
- Acțiunile americane: coeficienții ridge regăsesc efectul momentum, inversarea pe termen lung și sezonalitatea efectului momentum (Fig. 7)
- $r_{\text{IS}} \approx 0{,}006\%$ pe lună (Fig. 8)

înapoi

Anexă: studiul de caz, replicare, limite și extinderi

- **Aplicați metoda pe datele cursului** (datele CRSP pentru acțiuni individuale nu sînt incluse)
  - cele 49 de portofolii sectoriale ponderate cu capitalizarea de pe slide-urile principale de replicare (Seminarul 2, C3), cu aceiași predictori, aceeași standardizare și aceleași ferestre
  - filtrele de capitalizare și de preț nu se aplică portofoliilor
- **Limite precizate de autori**
  - randamentele decalate sînt rezultate de echilibru, nu matricea exogenă X din model: aplicația ilustrează diferența dintre predictibilitatea în selecție și cea în afara selecției, nu testează modelul
  - un test t pe r_{OOS} lunar nu este un test valid pentru $\mathbb{E}[r_{OOS}] = 0$: media se calculează și în raport cu g
  - rezultatul pentru ordinea temporală inversă poate depinde de ipoteza unor creșteri i.i.d. ale fluxurilor de numerar, iar modelul presupune investitori omogeni și caracteristici constante
- **Extinderi deschise**
  - seriile de timp, cum sugerează autorii: regresia pe raportul dividend–preț din acest capitol arată oare aceeași diferență între predictibilitatea în selecție și cea în afara selecției?
  - modelele neliniare (arbori, rețele neuronale Gu, Kelly & Xiu (2020)) adaugă flexibilitate funcțională fără să schimbe neapărat J: crește diferența?
  - AMH: poate shrinkage-ul excesiv aplicat de investitori cu resurse de calcul limitate să explice predictibilitatea în afara selecției din perioada timpurie?

Înapoi

Anexă: studiul de caz, în selecție și în afara selecției în detaliu

- $r_{\text{IS}} \geq 0$ în fiecare fereastră de 20 de ani prin construcție: $r_{\text{IS}} = b' G^{-1} b/240$, cu $G = \sum_s X_s' X_s / N_s$ și $b = \sum_s X_s' r_s / N_s$ pe cele 240 de luni s ale ferestrei
  - X_s: matricea $N_s \times 238$ a predictorilor din luna s
  - r_s: cele N_s randamente ale portofoliilor
  - $G^{-1} b$: coeficienții OLS estimați pe datele cumulate (pooled)
  - R^2 mediu în selecție de 5,4%, față de circa 1% pentru acțiunile individuale în Martin & Nagel (2022): 238 de predictori față de doar 40–49 de portofolii pe lună, cumulate pe 240 de luni, exagerează ajustarea în selecție
- În afara selecției (din iulie 1956), pînă în iunie 1986: media $r_{\text{OOS}} = 1{,}98 \times 10^{-5}$, la 4,16 erori standard peste 0
- După aceea, media este $0{,}36 \times 10^{-5}$, la doar 0,62 erori standard
  - media pe 10 ani depășește ultima dată două erori standard în fereastra încheiată în decembrie 1987
  - în ferestrele încheiate în 2014–2019, cel mai mare raport față de eroarea standard este 1,25, ca pentru acțiuni
- Interpretare sugerată de Martin & Nagel (2022): diferența este compatibilă cu învățarea investitorilor, dar nu o dovedește și nu exclude primele de risc
- Cîștigurile timpurii în afara selecției sînt compatibile și cu un shrinkage excesiv al coeficienților înainte de era calculatoarelor (Fig. 6)

Înapoi

Anexă: bucla descoperirii, prompturi reutilizabile (1/2)

- **Literatură**
  - `Listează studii publicate în reviste cu evaluare de specialitate, începînd din 2020, despre cum schimbă lansarea unui ETF eficiența sau descoperirea prețului activului suport. Pentru fiecare: DOI, metoda (studiu de eveniment, diferență în diferențe (DiD), ruptură structurală), măsura eficienței. Marchează orice intrare despre care nu ești sigur că există.`
  - Verificați fiecare DOI în Crossref
  - Titlul și autorii trebuie să coincidă cu cei ai lucrării citate
- **Ipoteză**
  - `Propune trei mecanisme prin care ETF-urile spot ar putea schimba dependența serială a lui Bitcoin (arbitraj, structura investitorilor, orele de tranzacționare). Pentru fiecare: semnul schimbării lui rho1 și VR(q) și o variabilă care îl deosebește de celelalte.`
- **Date și cod**
  - `Citește prețurile zilnice de închidere ale lui Bitcoin din datele cursului; calculează randamentele logaritmice, rho1 cu eroare standard robustă la heteroscedasticitate și VR(5) Lo-MacKinlay cu z*, în două ferestre de aceeași lungime în jurul datei de 11 ianuarie 2024.`

înapoi

Anexă: bucla descoperirii, prompturi reutilizabile (2/2)

- **Robustețe**
  - `Scrie un plan de robustețe preînregistrat: lungimea ferestrelor, doar închiderile din zilele lucrătoare, VR(q) pentru q = 2 până la 20 cu Chow-Denning, date placebo și Ethereum ca activ de control până la propriile ETF-uri spot (iulie 2024).`
- **Critică**
  - `Joacă rolul unui recenzent ostil: dacă Bitcoin era deja eficient înainte de 2024, ce ar putea detecta vreodată acest test? Calculează schimbarea minimă detectabilă a lui rho1 și propune o variabilă-rezultat mai bună.`
- **Raport**
  - Estimațiile, erorile standard robuste, distribuția placebo, toate testele efectuate (cu corecție pentru testare multiplă)
  - Prompturile care au influențat o decizie intră în `AI_USE.md`
- Asistentul propune testele
- Omul decide care dintre ele răspunde la întrebare

înapoi

Anexă: verificările cercetătorului

- **Erori standard i.i.d.**: $1/\sqrt{T}$ duce la respingeri prea frecvente în prezența volatility clustering
  - test: SE robustă și z^*, ca în testele de eficiență slabă din acest capitol
- **Ferestre inegale**: putere diferită înainte și după
- Test: lungimi egale, fixate dinainte
- **Data evenimentului aleasă din date**
  - test: doar data lansării (prima zi de tranzacționare), plus o distribuție placebo la date fără eveniment
- **Factori de confuzie**: o comparație înainte/după nu are interpretare cauzală
- Test: un activ de control (Ethereum înainte de iulie 2024) într-o diferență în diferențe
  - interpretarea cauzală este valabilă doar în condițiile de pe slide-ul Estimare și putere
  - perioada comună de după (ian.–iul. 2024) este scurtă
- **Multe statistici**: ρ_1, VR(2–20), secvențe
- Test: Chow–Denning sau Holm, nu cea mai mică valoare p luată izolat
- **Putere mică**: raportați MDE de pe slide-ul Estimare și putere

Înapoi

Anexă: studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- Efficiency of cryptocurrency markets - A GMM-based analysis
- Generalized Method of Moments

Cod, date și manuale

- Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_02
- Manuale: Campbell, Lo & MacKinlay (1997), cap. 2; Franke, Härdle & Hafner (2019)

înapoi

Acronime folosite în acest material (1/3)

- **AIC**: Akaike Information Criterion — *criteriul informațional Akaike*
- **AMH**: Adaptive Markets Hypothesis — *ipoteza piețelor adaptive*
- **AR(p)**: AutoRegressive model: model autoregresiv de ordin p.
- **AR**: Abnormal Return: randament anormal, în event studies.
- **BDS**: Brock–Dechert–Scheinkman (test) — *testul Brock–Dechert–Scheinkman de independență*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BIC**: Bayesian Information Criterion — *criteriul informațional bayesian*
- **BIST**: Borsa İstanbul (BIST 100 index) — *Bursa din Istanbul (indicele BIST 100)*
- **BNR**: Banca Națională a României
- **BUX**: Budapesti Értéktőzsde index — *indicele Bursei din Budapesta*
- **BVB**: Bursa de Valori București
- **CAPM**: Capital Asset Pricing Model — *modelul de evaluare a activelor financiare*
- **CAR**: Cumulative Abnormal Return — *randamentul anormal cumulat*
- **CD**: Chow–Denning (multiple variance-ratio test) — *testul multiplu Chow–Denning pentru raportul dispersiilor*
- **CME**: Chicago Mercantile Exchange — *Bursa de mărfuri din Chicago*
- **CRSP**: Center for Research in Security Prices — *Centrul de cercetare a prețurilor titlurilor (Universitatea din Chicago)*

Acronime folosite în acest material (2/3)

- **DFA**: Detrended Fluctuation Analysis — *analiza fluctuațiilor fără tendință*
- **EMH**: Efficient Market Hypothesis — *ipoteza pieței eficiente*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- **fGn**: fractional Gaussian noise — *zgomot gaussian fracționar*
- **FRED**: Federal Reserve Economic Data — *baza de date economice a Rezervei Federale (St. Louis)*
- **FTSE**: Financial Times Stock Exchange (FTSE Russell, index provider) — *furnizorul de indici FTSE Russell*
- **FWER**: Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **FX**: Foreign eXchange — *piața valutară*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GMM**: Generalized Method of Moments — *metoda generalizată a momentelor*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HK**: Hong Kong — în grafice, seria indicelui Hang Seng.
- **IPC**: Índice de Precios y Cotizaciones — *indicele Bursei din Mexic*
- **MDE**: Minimum Detectable Effect — *efectul minim detectabil*
- **MDH**: Martingale Difference Hypothesis — *ipoteza diferenței de martingal*

Acronime folosite în acest material (3/3)

- **MIT**: Massachusetts Institute of Technology — *Institutul de Tehnologie din Massachusetts*
- **ML**: Machine Learning — *învățare automată*
- **MSPE**: Mean Squared Prediction Error — *eroarea pătratică medie de predicție*
- **NYSE**: New York Stock Exchange — *Bursa din New York*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **PX**: Prague Stock Exchange index (index Burzy cenných papírů Praha) — *indicele Bursei din Praga*
- **RW1**: Random Walk 1 (i.i.d. increments) — *mersul aleator 1 (creșteri i.i.d.)*
- **RW2**: Random Walk 2 (independent increments) — *mersul aleator 2 (creșteri independente)*
- **RW3**: Random Walk 3 (uncorrelated increments) — *mersul aleator 3 (creșteri necorelate)*
- **SD**: Standard Deviation — *abatere standard*
- **SE**: Standard Error — *eroare standard*
- **SPA**: Superior Predictive Ability (test) — *testul abilității predictive superioare*
- **TOM**: Turn Of the Month — *schimbarea lunii (efectul schimbării lunii)*
- **TSMOM**: Time-Series MOMentum — *momentum pe serii de timp*
- **VR**: Variance Ratio — *raportul dispersiilor*
- **WIG20**: Warszawski Indeks Giełdowy 20 — *indicele celor mai mari 20 de companii de la Bursa din Varșovia*

Bibliografie (1/7)

- Andrews, D.W.K. (1991). Heteroskedasticity and autocorrelation consistent covariance matrix estimation. *Econometrica*, 59(3), 817–858.
- Anis, A.A., Lloyd, E.H. (1976). The expected value of the adjusted rescaled Hurst range of independent normal summands. *Biometrika*, 63(1), 111–116.
- Ariel, R.A. (1987). A monthly effect in stock returns. *Journal of Financial Economics*, 18(1), 161–174.
- Bachelier, L. (1900). Théorie de la spéculation. *Annales scientifiques de l'École Normale Supérieure*, 17, 21–86.
- Bartels, R. (1982). The rank version of von Neumann's ratio test for randomness. *Journal of the American Statistical Association*, 77(377), 40–46.
- Boehmer, E., Musumeci, J., Poulsen, A.B. (1991). Event-study methodology under conditions of event-induced variance. *Journal of Financial Economics*, 30(2), 253–272.
- Brock, W.A., Dechert, W.D., Scheinkman, J.A., LeBaron, B. (1996). A test for independence based on the correlation dimension. *Econometric Reviews*, 15(3), 197–235.
- Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). The Econometrics of Financial Markets. Princeton University Press.
- Campbell, J.Y., Thompson, S.B. (2008). Predicting excess stock returns out of sample: can anything beat the historical average?. *Review of Financial Studies*, 21(4), 1509–1531.
- Campbell, J.Y., Yogo, M. (2006). Efficient tests of stock return predictability. *Journal of Financial Economics*, 81(1), 27–60.
- Choi, I. (1999). Testing the random walk hypothesis for real exchange rates. *Journal of Applied Econometrics*, 14(3), 293–308.
- Chordia, T., Goyal, A., Saretto, A. (2020). Anomalies and false rejections. *Review of Financial Studies*, 33(5), 2134–2179.

Bibliografie (2/7)

- Chow, K.V., Denning, K.C. (1993). A simple multiple variance ratio test. *Journal of Econometrics*, 58(3), 385–401.
- Clark, T.E., West, K.D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311.
- De Bondt, W.F.M., Thaler, R. (1985). Does the stock market overreact?. *Journal of Finance*, 40(3), 793–805.
- De Long, J.B., Shleifer, A., Summers, L.H., Waldmann, R.J. (1990). Noise trader risk in financial markets. *Journal of Political Economy*, 98(4), 703–738.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Escanciano, J.C., Lobato, I.N. (2009). An automatic Portmanteau test for serial correlation. *Journal of Econometrics*, 151(2), 140–149.
- Escanciano, J.C., Velasco, C. (2006). Generalized spectral tests for the martingale difference hypothesis. *Journal of Econometrics*, 134(1), 151–185.
- Fama, E.F. (1970). Efficient capital markets: a review of theory and empirical work. *Journal of Finance*, 25(2), 383–417.
- Fama, E.F. (1991). Efficient capital markets: II. *Journal of Finance*, 46(5), 1575–1617.
- Fama, E.F., Fisher, L., Jensen, M.C., Roll, R. (1969). The adjustment of stock prices to new information. *International Economic Review*, 10(1), 1–21.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, ed. a 5-a. Springer.
- French, K.R. (1980). Stock returns and the weekend effect. *Journal of Financial Economics*, 8(1), 55–69.

Bibliografie (3/7)

- French, K.R. (2026). Kenneth R. French Data Library. Tuck School of Business, Dartmouth College.
- FTSE Russell (2019). FTSE Russell announces results of country classification review (comunicat de presă, 26 septembrie 2019).
- Goyal, A., Welch, I., Zafirov, A. (2024). A comprehensive 2022 look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 37(11), 3490–3557.
- Grossman, S.J., Stiglitz, J.E. (1980). On the impossibility of informationally efficient markets. *American Economic Review*, 70(3), 393–408.
- Gu, S., Kelly, B., Xiu, D. (2020). Empirical asset pricing via machine learning. *Review of Financial Studies*, 33(5), 2223–2273.
- Hansen, P.R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380.
- Harvey, C.R., Liu, Y. (2020). False (and missed) discoveries in financial economics. *Journal of Finance*, 75(5), 2503–2553.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). . . . and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Heston, S.L., Sadka, R. (2008). Seasonality in the cross-section of stock returns. *Journal of Financial Economics*, 87(2), 418–445.
- Hurst, H.E. (1951). Long-term storage capacity of reservoirs. *Transactions of the American Society of Civil Engineers*, 116(1), 770–799.
- Jegadeesh, N., Titman, S. (1993). Returns to buying winners and selling losers: implications for stock market efficiency. *Journal of Finance*, 48(1), 65–91.
- Kahneman, D., Tversky, A. (1979). Prospect theory: an analysis of decision under risk. *Econometrica*, 47(2), 263–291.

Bibliografie (4/7)

- Kendall, M.G. (1954). Note on bias in the estimation of autocorrelation. *Biometrika*, 41(3–4), 403–404.
- Kia, K., Liu, B., Li, Q., Song, V., Xu, K. (2025). Price discovery in Bitcoin ETF market. *Financial Review*, 61(2), 435–449.
- Kim, J.H. (2006). Wild bootstrapping variance ratio tests. *Economics Letters*, 92(1), 38–43.
- Kim, J.H., Shamsuddin, A. (2008). Are Asian stock markets efficient? Evidence from new multiple variance ratio tests. *Journal of Empirical Finance*, 15(3), 518–532.
- Kim, J.H., Shamsuddin, A., Lim, K.-P. (2011). Stock return predictability and the adaptive markets hypothesis: evidence from century-long U.S. data. *Journal of Empirical Finance*, 18(5), 868–879.
- Kolari, J.W., Pynnönen, S. (2010). Event study testing with cross-sectional correlation of abnormal returns. *Review of Financial Studies*, 23(11), 3996–4025.
- Kristoufek, L. (2018). On Bitcoin markets (in)efficiency and its evolution. *Physica A*, 503, 257–262.
- Künsch, H.R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- Lakonishok, J., Smidt, S. (1988). Are seasonal anomalies real? A ninety-year perspective. *Review of Financial Studies*, 1(4), 403–425.
- Lim, K.-P., Brooks, R. (2011). The evolution of stock market efficiency over time: a survey of the empirical literature. *Journal of Economic Surveys*, 25(1), 69–108.
- Ljung, G.M., Box, G.E.P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- Lo, A.W. (1991). Long-term memory in stock market prices. *Econometrica*, 59(5), 1279–1313.

Bibliografie (5/7)

- Lo, A.W. (2004). The adaptive markets hypothesis. *Journal of Portfolio Management*, 30(5), 15–29.
- Lo, A.W. (2017). Adaptive Markets: Financial Evolution at the Speed of Thought. Princeton University Press.
- Lo, A.W., MacKinlay, A.C. (1988). Stock market prices do not follow random walks: evidence from a simple specification test. *Review of Financial Studies*, 1(1), 41–66.
- Lobato, I., Nankervis, J.C., Savin, N.E. (2001). Testing for autocorrelation using a modified Box–Pierce Q test. *International Economic Review*, 42(1), 187–205.
- MacKinlay, A.C. (1997). Event studies in economics and finance. *Journal of Economic Literature*, 35(1), 13–39.
- Malkiel, B.G. (2003). The efficient market hypothesis and its critics. *Journal of Economic Perspectives*, 17(1), 59–82.
- Martin, I.W.R., Nagel, S. (2022). Market efficiency in the age of big data. *Journal of Financial Economics*, 145(1), 154–177.
- McLean, R.D., Pontiff, J. (2016). Does academic research destroy stock return predictability?. *Journal of Finance*, 71(1), 5–32.
- Moskowitz, T.J., Ooi, Y.H., Pedersen, L.H. (2012). Time series momentum. *Journal of Financial Economics*, 104(2), 228–250.
- Nadarajah, S., Chu, J. (2017). On the inefficiency of Bitcoin. *Economics Letters*, 150, 6–9.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Pele, D.T., Lin, M.-B., Wang, R., Gaman, S. (2025). Market responses to ETH development milestones. IDA Institute Digital Assets, Bucharest University of Economic Studies.

Bibliografie (6/7)

- Pele, D.T., Mazurencu-Marinescu, M. (2012). Modelling stock market crashes: the case of Bucharest Stock Exchange. *Procedia – Social and Behavioral Sciences*, 58, 533–542.
- Pele, D.T., Mazurencu-Marinescu, M., Nijkamp, P. (2013). Herding behaviour, bubbles and log periodic power laws in illiquid stock markets: a case study on the Bucharest Stock Exchange. SSRN Working Paper.
- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *European Journal of Finance*, 29(10), 1064–1105.
- Peng, C.-K., Buldyrev, S.V., Havlin, S., Simons, M., Stanley, H.E., Goldberger, A.L. (1994). Mosaic organization of DNA nucleotides. *Physical Review E*, 49(2), 1685–1689.
- Roberts, H.V. (1959). Stock-market "patterns" and financial analysis: methodological suggestions. *Journal of Finance*, 14(1), 1–10.
- Robinson, P.M. (1995). Gaussian semiparametric estimation of long range dependence. *Annals of Statistics*, 23(5), 1630–1661.
- Romano, J.P., Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282.
- Rozeff, M.S., Kinney, W.R. (1976). Capital market seasonality: the case of stock returns. *Journal of Financial Economics*, 3(4), 379–402.
- Samuelson, P.A. (1965). Proof that properly anticipated prices fluctuate randomly. *Industrial Management Review*, 6(2), 41–49; retipărit în 2015, World Scientific.
- Shiller, R.J. (1981). Do stock prices move too much to be justified by subsequent changes in dividends?. *American Economic Review*, 71(3), 421–436 (NBER Working Paper 456).
- Shiller, R.J. (2026). U.S. stock markets 1871–present and CAPE ratio (date lunare, accesat în septembrie 2026).
- Shleifer, A., Vishny, R.W. (1997). The limits of arbitrage. *Journal of Finance*, 52(1), 35–55.

Bibliografie (7/7)

- Stambaugh, R.F. (1999). Predictive regressions. *Journal of Financial Economics*, 54(3), 375–421.
- Sullivan, R., Timmermann, A., White, H. (1999). Data-snooping, technical trading rule performance, and the bootstrap. *Journal of Finance*, 54(5), 1647–1691.
- Summers, L.H. (1986). Does the stock market rationally reflect fundamental values?. *Journal of Finance*, 41(3), 591–601.
- Tak, R., Pele, D.T. (2025). LLM-driven stock prediction: capturing market trends with LLaMA. *Proceedings of the International Conference on Business Excellence*, 19(1), 529–540.
- Tak, R., Schlamp, S., Osterrieder, J., Pele, D.T. (2026). Racing the news: nanosecond market efficiency at Eurex and CME. SSRN Working Paper.
- Tran, V.L., Leirvik, T. (2020). Efficiency in the markets of crypto-currencies. *Finance Research Letters*, 35, 101382.
- Urquhart, A. (2016). The inefficiency of Bitcoin. *Economics Letters*, 148, 80–82.
- Urquhart, A., McGroarty, F. (2016). Are stock markets really efficient? Evidence of the adaptive market hypothesis. *International Review of Financial Analysis*, 47, 39–49.
- Wald, A., Wolfowitz, J. (1940). On a test whether two samples are from the same population. *Annals of Mathematical Statistics*, 11(2), 147–162.
- Welch, I., Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 21(4), 1455–1508.
- White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126.