

# Modelarea piețelor financiare

## Capitolul 2: Eficiența pieței — de la EMH la piețe adaptive



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

## Planul capitolului

- Pot prețurile trecute, știrile sau alte informații publice să prezică randamentele, după ajustarea la risc și costuri?
- Secțiunile 1–5 conțin materia de bază și se încheie cu o scurtă verificare.
- Temele pentru studiu suplimentar conțin demonstrațiile, celelalte teste și temele de proiect.


- 1. Randamente și informație
- 2. Autocorelație și variance ratio
- 3. Predictibilitate out-of-sample
- 4. Studii de eveniment
- 5. Testare multiplă și anomalii
- Teme pentru studiu suplimentar

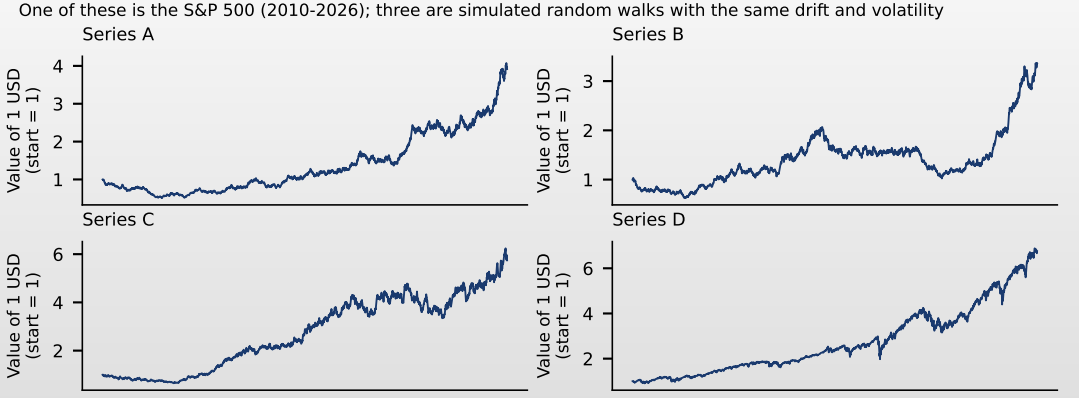
# 1. Randamente și informație

- **RW1**: Random Walk 1 — random walk cu variații independente și identic distribuite.
- **RW2**: Random Walk 2 — random walk cu variații independente, fără cerința unei distribuții identice.
- **RW3**: Random Walk 3 — random walk cu variații necorelate, care pot fi dependente.

- Întrebarea: ce înseamnă, precis, că prețurile trecute nu conțin informație despre randamentele viitoare?
- Există trei variante ale răspunsului, RW1, RW2 și RW3, de la cea mai strictă la cea mai slabă.
- Varianta contează: un test construit sub RW1 poate respinge doar pentru că volatilitatea variază în timp.
- Orice test are nevoie și de un model al randamentului așteptat, deci o respingere nu dovedește singură ineficiența.

# Un joc: identificarea seriei de piață reale (1/2)

**S&P 500**: Standard & Poor's 500 — indice al acțiunilor a 500 de companii mari din Statele Unite.



# Un joc: identificarea seriei de piață reale (2/2)

- Care panou este S&P 500? Votați: A, B, C sau D?

MFM_ch2_random_walk_game

## Un joc: identificarea seriei de piață reale (2/2)

- Care panou este S&P 500? Votați: A, B, C sau D?
- Răspuns: **D**.
- Roberts (1959): seriile random walk simulate produc „tipare" din întîmplare
- Avem nevoie de teste statistice, nu doar de inspecție vizuală
- Bachelier (1900) și Samuelson (1965): prețurile anticipate corect variază aleator, deci imprevizibilitatea este semnul unei piețe care funcționează bine

MFM_ch2_random_walk_game

## Eficiența și mulțimea de informații

- Fama (1970): o piață este **eficientă** (Efficient Market Hypothesis, EMH) dacă prețurile „reflectă complet" toată informația disponibilă $\mathcal{I}_t$ (portret și articole de sinteză: Anexa; precursori: Anexa)
  - formal: nicio strategie bazată pe $\mathcal{I}_t$ nu obține randamente **așteptate** peste randamentul de echilibru (ajustat la risc)

| Forma | Mulțimea de informații $\mathcal{I}_t$ | Testul tipic (în acest capitol) |
|---|---|---|
| Slabă | Prețurile și randamentele trecute | Autocorelație, variance ratio; în anexă: teste de secvențe (runs) și de memorie lungă |
| Semi-tare | Toată informația publică (știri, raportări) | Studii de eveniment |
| Tare | Informația publică și cea privilegiată | Randamentele persoanelor inițiate (insiders) și ale administratorilor de fonduri |

- Forma tare implică forma semi-tare, iar forma semi-tare implică forma slabă
- În Capitolul 3 ajustăm randamentele la risc folosind modele factoriale

## Problema ipotezei comune

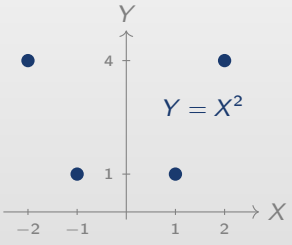
**CAPM**: Capital Asset Pricing Model — model care leagă randamentul cerut de expunerea la riscul pieței.

- Pentru a stabili „randamentul de echilibru" avem nevoie de un model al randamentelor așteptate (de ex. CAPM, Capitolul 3)
- Orice test de eficiență este un test **comun** al eficienței și al modelului de evaluare Fama (1991)
  - O respingere poate însemna o piață ineficientă **sau** un model de risc greșit
  - Randamentele **așteptate** predictibile sînt permise dacă ele compensează un risc variabil în timp
- La orizont zilnic randamentele așteptate sînt foarte mici, deci alegerea modelului contează puțin: testele formei slabe depind cel mai puțin de model
- Un test nu poate demonstra eficiența pieței; poate doar să nu o respingă pe baza datelor analizate

## Corelația și dependența randamentelor

- Testele formei slabe folosesc doar prețurile trecute. Ca să precizăm ce înseamnă că trecutul nu conține informație, avem nevoie de diferența dintre corelație și dependență.
- Autocorelația la lag k este corelația dintre un randament și randamentul de acum k perioade.
- Corelația zero exclude asocierea liniară, dar poate lăsa dependență între pătratele randamentelor.

- Exemplu ipotetic: $X = -2, -1, 1, 2$, la fel de probabile; $Y = X^2$.
- Media lui $X$ este zero; media lui $XY$ este $(-8-1+1+8)/4 = 0$. Covarianța, deci și corelația, este zero.
- Dar dacă știm $X$, știm exact $Y$: variabilele sînt dependente.



## Random walk: modelul

$$p_t = \mu + p_{t-1} + \varepsilon_t, \qquad p_t = \ln P_t$$

- $P_t$: nivelul indicelui la închiderea zilei $t$; $p_t$: log-prețul; $\mu$: drift-ul (creșterea medie pe zi); $\varepsilon_t$: șocul zilei, cu media zero și dispersia $\sigma^2$.
- Prin substituții repetate: $p_t = p_0 + \mu t + \sum_{s=1}^{t} \varepsilon_s$: log-prețul este un trend liniar plus suma tuturor șocurilor trecute.
- Echivalent, randamentul logaritmic $r_t = p_t - p_{t-1} = \mu + \varepsilon_t$.
- Cea mai bună prognoză: $\mathbb{E}[p_{t+h} \mid p_t, p_{t-1}, \ldots] = p_t + \mu h$: prețul de azi plus drift-ul; trecutul nu adaugă nimic.
- Cu șocuri necorelate de dispersie $\sigma^2$: $\mathrm{Var}(p_{t+h} - p_t) = h\,\sigma^2$, dispersia crește liniar cu orizontul (baza variance ratio-ului din secțiunea 2).
- RW1, RW2 și RW3 diferă doar prin ce presupun despre șocurile $\varepsilon_t$ Campbell, Lo & MacKinlay (1997).

# RW1, RW2, RW3: restricțiile asupra randamentelor

- **i.i.d.**: independent and identically distributed — independente și identic distribuite.
- **GARCH**: Generalized AutoRegressive Conditional Heteroskedasticity — model al dispersiei condiționate, explicată prin șocuri și dispersii trecute.
- $P_t$: nivelul indicelui la închiderea zilei $t$; $\mu$: media constantă; $\varepsilon_t$: inovația, cu media zero.
- $z_t$: șoc cu distribuția Normală standard $N(0,1)$; în GARCH(1,1), $\omega > 0$ și $\alpha, \beta \geq 0$.

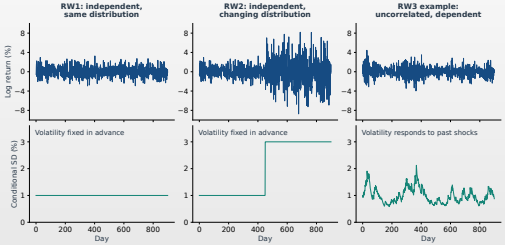
| | Condiția asupra șocurilor | Exemplu de model pentru randamente |
|---|---|---|
| RW1 | $\varepsilon_t$ i.i.d., media 0, dispersia $\sigma^2$ | $r_t = \mu + 0{,}01 z_t$, $z_t$ i.i.d. $N(0,1)$ |
| RW2 | $\varepsilon_t$ independente; dispersia $\sigma_t^2$ poate varia în timp | $r_t = \mu + \sigma_t z_t$, $\sigma_t = 1\%$ apoi $3\%$, fixat dinainte |
| RW3 | $\mathrm{Cov}(\varepsilon_t, \varepsilon_{t-k}) = 0$ pentru orice $k \geq 1$ | GARCH: $\varepsilon_t = \sigma_t z_t$, $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$ |

## Cum se leagă RW1, RW2 și RW3

- RW1 implică RW2: randamentele i.i.d. sînt în particular independente.
- RW2 implică RW3: randamentele independente sînt în particular necorelate, dacă dispersia lor există.
- Un model GARCH păstrează corelația zero, dar încalcă RW2: mărimea variației de azi depinde de șocurile trecute.
- RW3 nu garantează că media de mîine este imprevizibilă: o funcție neliniară a trecutului o poate prognoza.

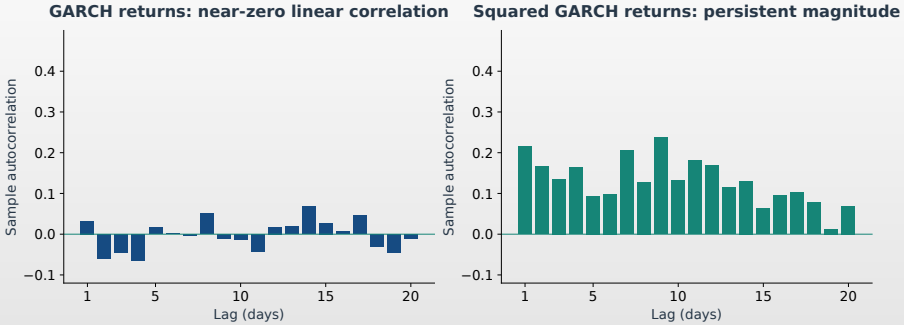
# Trei modele pentru randamente și volatilitate

**SD**: Standard Deviation — abaterea standard a observațiilor.




- Trei serii simulate, cu media zero: sus randamentele zilnice, jos abaterea standard condiționată folosită la simulare.
- Volatilitatea RW2 este fixată dinainte (1% apoi 3%, de la mijlocul eșantionului), iar cea GARCH răspunde șocurilor trecute.
- Volatility clustering: variațiile mari tind să fie urmate de variații mari.
- Și seria RW2 are o perioadă agitată, deși randamentele ei sînt independente: graficul singur nu deosebește o schimbare de regim fixată dinainte de volatility clustering.

# GARCH: randamente versus randamente la pătrat




- Stînga: autocorelațiile randamentelor GARCH simulate sînt aproape zero la toate lagurile.
- Dreapta: autocorelațiile pătratelor sînt pozitive pînă la lagul 20: o zi cu variație mare este urmată de alte zile cu variații mari.
- Sînt estimații ilustrative, nu teste de ipoteze.

## Verificare: randamente și informație

- Pot randamentele rămîne independente dacă abaterea lor standard trece de la 1% la 3% la o dată fixată dinainte?
- Autocorelația zero dovedește independența?
- De ce respingerea unui test de eficiență nu dovedește, singură, că piața este ineficientă?

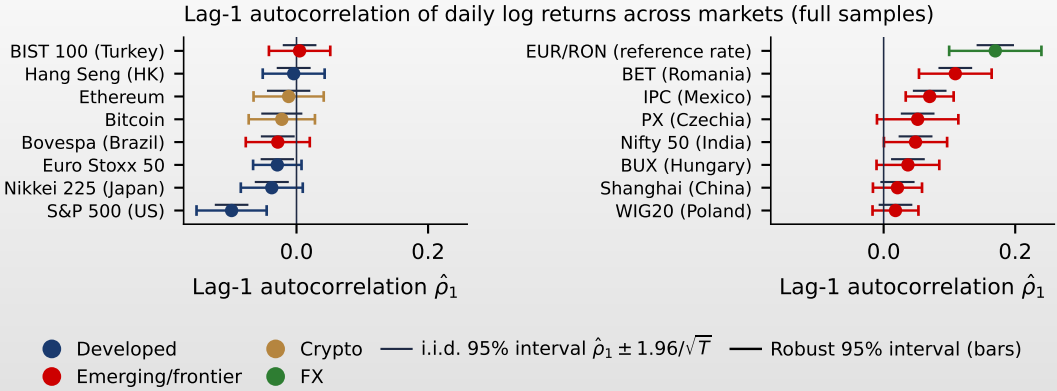
## Răspunsuri: randamente și informație

- Da. Seria respectă RW2, dar încalcă RW1, deoarece distribuția nu mai este identică.
- Nu. În exemplul GARCH, autocorelația randamentelor este zero, dar pătratele lor sînt dependente.
- Orice test de eficiență testează și modelul randamentului așteptat.
- Respingerea poate veni dintr-un model de risc greșit (problema ipotezei comune).

## 2. Autocorelație și variance ratio

- Întrebarea: prezice randamentul de azi randamentul de mîine pe pieţele de acţiuni, crypto și valutare?
- Începem cu forma slabă: ea folosește doar prețurile trecute și depinde cel mai puțin de modelul de risc.
- Autocorelația de lag 1, $\rho_1$, măsoară dependența liniară dintre două zile consecutive; variance ratio-ul cumulează autocorelațiile pînă la orizontul $q$.
- Pieţele: 13 indici bursieri (dezvoltați și emergenți, inclusiv BET), Bitcoin, Ethereum și cursul de referință EUR/RON.
- De ce această selecție: predictibilitatea are mai multe șanse acolo unde lichiditatea este mică (BET, crypto) sau unde cursul este administrat (EUR/RON).
- Eșantioanele: acțiuni din ianuarie 2000, EUR/RON din iulie 2005, Bitcoin din septembrie 2014 și Ethereum din ianuarie 2016, toate pînă la 18 septembrie 2026.
- Volatility clustering (secțiunea 1) cere erori standard robuste; fără ele respingem ipoteza nulă prea des.

# Autocorelația de ordinul 1 pe piețe (1/3)




MFM_ch2_autocorrelation

## Autocorelația de ordinul 1 pe piețe (2/3)

**SE**: Standard Error — eroare standard.

- Fiecare punct este autocorelația de lag 1, $\hat{\rho}_1$, a randamentelor logaritmice zilnice ale unei piețe, pe tot eșantionul ei.
- Bara colorată este intervalul de încredere robust de 95%, $\hat{\rho}_1 \pm 1{,}96\,\mathrm{SE}$ robustă (formula: Construcția testelor).
- Segmentul subțire de deasupra punctului este intervalul de 95% calculat sub ipoteza i.i.d., $\hat{\rho}_1 \pm 1{,}96/\sqrt{T}$, cu $T$ numărul de randamente zilnice.
- Regula de citire: respingem $\rho_1 = 0$ la 5% dacă bara robustă nu conține linia verticală din 0.
- Intervalul robust ține cont de volatility clustering și de aceea este mai larg decît cel i.i.d.
- Pentru S&P 500 ($T = 6\,714$), eroarea standard robustă este 0,027, iar cea i.i.d. este 0,012.
- BIST, WIG20, BUX, PX, IPC și BET sînt indicii burselor din Istanbul, Varșovia, Budapesta, Praga, Mexic și București; FX este piața valutară (cursul de referință EUR/RON).

## Autocorelația de ordinul 1 pe piețe (3/3)

- BET ($\hat{\rho}_1 = 0{,}109$), IPC (0,070) și EUR/RON (0,170): autocorelații pozitive și semnificative.
- S&P 500: $\hat{\rho}_1 = -0{,}099$, negativă și semnificativă.
- Bitcoin ($\hat{\rho}_1 = -0{,}022$) și Ethereum ($-0{,}012$): barele robuste conțin 0, deci nu respingem $\rho_1 = 0$.
- La BET, persistența poate proveni din tranzacționarea rară a unor acțiuni, ale căror prețuri încorporează știrile cu întîrziere.
- La EUR/RON, ea poate proveni din regimul de managed float, în care banca centrală netezește variațiile cursului.
- La S&P 500, inversarea poate proveni din reacția excesivă pe termen scurt și din furnizarea de lichiditate.
- Efectul este mic: $\hat{\rho}_1^2$, partea din dispersia randamentului de azi explicată de randamentul de ieri, este 0,97% la S&P 500 și 1,19% la BET.

MFM_ch2_autocorrelation

## Variance ratio-ul: de ce și ce măsoară

**VR**: Variance Ratio — raportul dintre dispersia randamentului pe q zile și q ori dispersia randamentului pe o zi.

- De ce încă un test: $\hat{\rho}_1$ privește un singur lag, iar autocorelații mici la multe laguri pot trece fiecare testul, dar se cumulează pe orizonturi mai lungi.
- Variance ratio-ul le adună într-un singur număr, pe orizontul de $q$ zile al unui investitor Lo & MacKinlay (1988).
- $q$: orizontul în zile (de ex. $q = 5$ este o săptămînă de tranzacționare).
- Pentru randamente necorelate cu dispersie constantă, $\mathrm{Var}(r_t + \cdots + r_{t-q+1}) = q\,\mathrm{Var}(r_t)$: dispersia crește liniar cu orizontul.
- **Variance ratio-ul**: $\mathrm{VR}(q) = \dfrac{\mathrm{Var}(r_t + \cdots + r_{t-q+1})}{q\,\mathrm{Var}(r_t)}$, egal cu 1 fără autocorelație.
- Fără autocorelație, estimatorul $\widehat{\mathrm{VR}}(q)$ tinde la 1 și cînd volatilitatea variază în timp (RW2, RW3), în condițiile din Lo & MacKinlay (1988).

## Variance ratio-ul și autocorelațiile

- Pentru o serie staționară în covarianță, $\mathrm{VR}(q) = 1 + 2\sum_{k=1}^{q-1}\left(1 - \frac{k}{q}\right)\rho_k$: o sumă a autocorelațiilor, cu ponderi care scad cu lagul $k$.
- $\mathrm{VR}(q) > 1$: persistență (autocorelații pozitive în medie).
- $\mathrm{VR}(q) < 1$: inversare (mean reversion).
- Pentru $q = 2$, formula dă $\mathrm{VR}(2) = 1 + \rho_1$.
- Verificare pe S&P 500: $1 + \hat{\rho}_1 = 1 - 0{,}099 = 0{,}901$, aceeași valoare ca $\widehat{\mathrm{VR}}(2)$ estimat direct.

## Null band-ul robust al variance ratio-ului

- Fără autocorelație, valoarea de referință este $\mathrm{VR}(q) = 1$, chiar dacă volatilitatea variază în timp (ipoteza RW3).
- Null band-ul robust de 95% este centrat în 1, valoarea sub ipoteza nulă: dacă $\widehat{\mathrm{VR}}(q)$ cade în afara lui, respingem ipoteza nulă la 5%.
- Null band-ul nu este un interval de încredere: un interval de încredere ar fi centrat în estimația $\widehat{\mathrm{VR}}(q)$, nu în 1.
- Null band-ul robust este $1 \pm 1{,}96\sqrt{\hat{\theta}(q)/T}$, cu $T$ numărul de randamente zilnice și $\hat{\theta}(q)$ dispersia estimată a lui $\sqrt{T}\,(\widehat{\mathrm{VR}}(q) - 1)$, robustă la heteroscedasticitate (Construcția testelor).
- Cînd variațiile mari urmează altor variații mari (volatility clustering), $\hat{\theta}(q)$ crește și null band-ul se lărgește.
- $\hat{\theta}(q)$ crește și cu $q$, deci null band-ul se lărgește la orizonturi lungi: un eșantion conține mai puține perioade independente de $q$ zile.

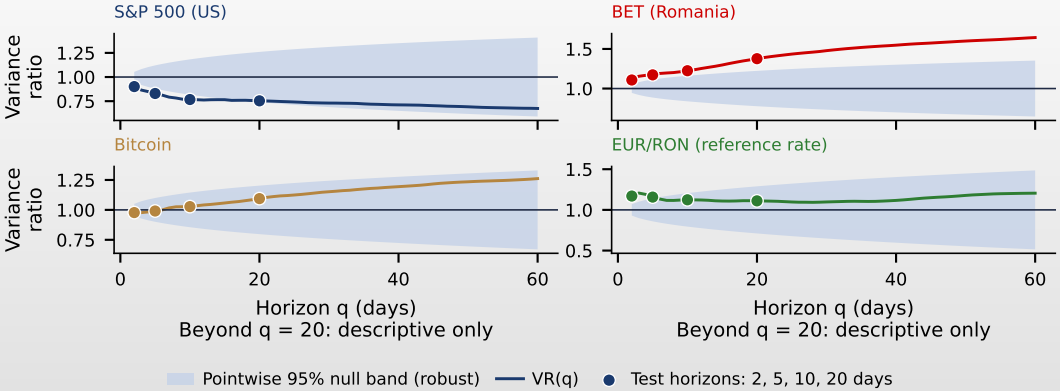
## De ce null band-ul robust este mai larg: verificare numerică

- Pentru $q = 2$, statistica clasică este $z = \sqrt{T}\,(\widehat{\mathrm{VR}}(2) - 1)$; ea presupune randamente i.i.d. (RW1).
- Statistica robustă $z^*$ împarte același numărător la $\sqrt{\hat{\theta}(2)}$.
- Fără volatility clustering, $\hat{\theta}(2) \approx 1$ și $z^* \approx z$; cu volatility clustering, $\hat{\theta}(2) > 1$ și $|z^*| < |z|$.
- Exemplu ipotetic: $T = 400$ de zile și $\widehat{\mathrm{VR}}(2) = 0{,}90$ dau $z = 20 \times (-0{,}10) = -2{,}0$: respingem ipoteza nulă la 5%.
- Dacă volatility clustering face $\hat{\theta}(2) = 4$, atunci $z^* = -2{,}0/\sqrt{4} = -1{,}0$ și nu mai respingem.
- Null band-ul robust din jurul lui 1 este atunci de $\sqrt{4} = 2$ ori mai larg.
- Pentru S&P 500, $z = -8{,}12$ și $z^* = -3{,}64$: statistica robustă este de circa 2,2 ori mai mică, dar respingem în continuare.

## Ce orizonturi testăm cu variance ratio?

- De ce mai multe orizonturi: inversarea sau persistența pot apărea la o zi, la o săptămînă sau la o lună, iar dinainte nu știm la care.
- Testăm patru orizonturi, $q = 2, 5, 10, 20$ zile de tranzacționare: două zile, aproximativ o săptămînă, două săptămîni și o lună bursieră.
- Alegerea urmează Lo & MacKinlay (1988), care folosesc $q = 2, 4, 8, 16$ pe date săptămînale; alte orizonturi pot da alt rezultat.
- Null band-ul robust are nivelul 5% la fiecare orizont separat: cu patru teste, o respingere falsă apare mai des decît în 5% din cazuri.
- Testul Chow–Denning Chow & Denning (1993) corectează acest lucru: folosește cel mai mare $|z^*(q)|$ dintre cele patru orizonturi și valoarea critică 2,49 în loc de 1,96.
- Testul Chow–Denning respinge RW3 pentru 5 din cele 16 serii, printre care BET și S&P 500.
- Pentru Bitcoin, testul Chow–Denning nu respinge RW3 (p-value = 0,835).

# Profilul variance ratio-ului (1/3)



## Profilul variance ratio-ului (2/3)

- Fiecare curbă arată variance ratio-ul estimat $\widehat{\mathrm{VR}}(q)$ pentru orizonturi $q$ de la 2 la 60 de zile.
- Zona hașurată este null band-ul robust de 95% în jurul valorii 1, valoarea fără autocorelație.
- S&P 500: $\widehat{\mathrm{VR}}(q)$ este sub 1 (inversare) și iese din null band la 2, 5 și 10 zile; la 20 de zile rămîne chiar în interiorul null band-ului (0,753 față de marginea 0,740)
  - $\widehat{\mathrm{VR}}(2) = 0{,}901$, $\widehat{\mathrm{VR}}(5) = 0{,}830$, $\widehat{\mathrm{VR}}(10) = 0{,}767$, $\widehat{\mathrm{VR}}(20) = 0{,}753$
- BET: $\widehat{\mathrm{VR}}(q)$ este peste 1 (persistență), crește cu $q$ și iese din null band la toate cele patru orizonturi testate
  - $\widehat{\mathrm{VR}}(2) = 1{,}108$, $\widehat{\mathrm{VR}}(5) = 1{,}173$, $\widehat{\mathrm{VR}}(10) = 1{,}225$, $\widehat{\mathrm{VR}}(20) = 1{,}377$

## Profilul variance ratio-ului (3/3)

- Orizontul $q = 60$, circa trei luni bursiere, este doar descriptiv: nu face parte din cele patru orizonturi testate
  - S&P 500: $\widehat{\mathrm{VR}}(60) = 0{,}674$; BET: $\widehat{\mathrm{VR}}(60) = 1{,}644$
- Bitcoin rămîne în interiorul null band-ului la toate orizonturile: nu respingem ipoteza nulă.
- EUR/RON: $\widehat{\mathrm{VR}}(q)$ rămîne peste 1 la toate orizonturile, dar iese din null band doar la 2 și 5 zile ($\widehat{\mathrm{VR}}(2) = 1{,}170$, $\widehat{\mathrm{VR}}(5) = 1{,}157$).
- Persistența pe termen scurt este compatibilă cu regimul de managed float al cursului.
- O curbă deasupra sau dedesubtul lui 1, dar în interiorul null band-ului, nu este o dovadă statistică de predictibilitate.

MFM_ch2_variance_ratio

## Verificare: autocorelație și variance ratio

- De ce poate induce în eroare null band-ul i.i.d. în prezența volatility clustering?
- O autocorelație pozitivă implică profit după costuri?
- Ce sugerează un variance ratio sub unu?
- Aplicare: o statistică de test are modulul 2,4. Dacă estimația VR rămîne aceeași, dar eroarea standard se dublează, cît devine modulul statisticii?
- Se mai respinge ipoteza nulă la 5% (test bilateral)?

## Răspunsuri: autocorelație și variance ratio

- Eroarea standard i.i.d. ignoră dependența din pătratele randamentelor, deci este prea mică: testul respinge ipoteza nulă prea des.
- Nu: mai contează mărimea efectului, riscul, implementarea și costurile.
- Un variance ratio sub 1 sugerează inversare pe orizontul ales.
- Pentru a afirma că abaterea este semnificativă avem nevoie de o eroare standard robustă.
- Modulul statisticii scade la 1,2.
- Nu: 1,2 nu depășește 1,96; efectul estimat rămîne același, dar dovezile sînt mai slabe.

## 3. Predictibilitate out-of-sample

- Întrebarea: prognozează o variabilă cunoscută azi randamentul pieței de luna viitoare?
- Candidatul clasic este *dp*, logaritmul raportului dividend–preț: dividendele pe ultimele 12 luni împărțite la nivelul mediu al indicelui în luna respectivă.
- In-sample, regresiile de acest tip par să funcționeze; pe date noi, majoritatea predictorilor publicați eșuează Welch & Goyal (2008).
- Testul corect: fiecare prognoză folosește doar datele disponibile în momentul în care este făcută.

## De ce raportul dividend–preț?

- Identitatea Campbell & Shiller (1988): $dp_t \approx c + \sum_{j \geq 0} \rho^j \left( r_{t+1+j} - \Delta d_{t+1+j} \right)$, cu $\rho$ puțin sub 1 și $\Delta d$ creșterea logaritmică a dividendelor.
- Identitatea rezultă din definiția randamentului printr-o aproximare log-liniară, fără vreun model economic.
- Consecință: dacă *dp* variază, el trebuie să prognozeze randamentele viitoare, creșterea viitoare a dividendelor sau amîndouă.
- Datele arată că *dp* prognozează slab creșterea dividendelor, deci variația lui ar trebui să prognozeze randamentele Cochrane (2008).
- De aceea *dp* este cel mai studiat predictor al pieței Fama & French (1988): dacă el nu prognozează out-of-sample, predictorii mai slabi au și mai puține șanse.
- O prognoză reușită nu ar dovedi ineficiența: poate reflecta o primă de risc care variază în timp.

## Cum construim prognozele

**OS**: Out-of-Sample.

- $r$: randamentul logaritmic lunar al S&P 500, cu dividende, minus dobînda la titlurile de stat americane pe 3 luni.
- În fiecare lună $t$ estimăm $r_{s+1} = \alpha + \beta\, dp_s + u_{s+1}$ pe toate lunile de pînă la $t$; la pasul următor fereastra crește cu o lună (expanding window).
- Prognoza cu $dp$ pentru luna $t+1$: $\hat{r}_{t+1} = \hat{\alpha} + \hat{\beta}\, dp_t$.
- Prognoza concurentă: media istorică $\bar{r}_{t+1}$, media randamentelor de pînă în luna $t$; ea corespunde lipsei de predictibilitate.
- Prima prognoză este pentru ianuarie 1970; rezultă 680 de prognoze lunare.
- Dividendele lunare sînt interpolate din totaluri trimestriale, deci $dp_t$ nu era cunoscut exact în luna $t$: exercițiul este pseudo-out-of-sample.

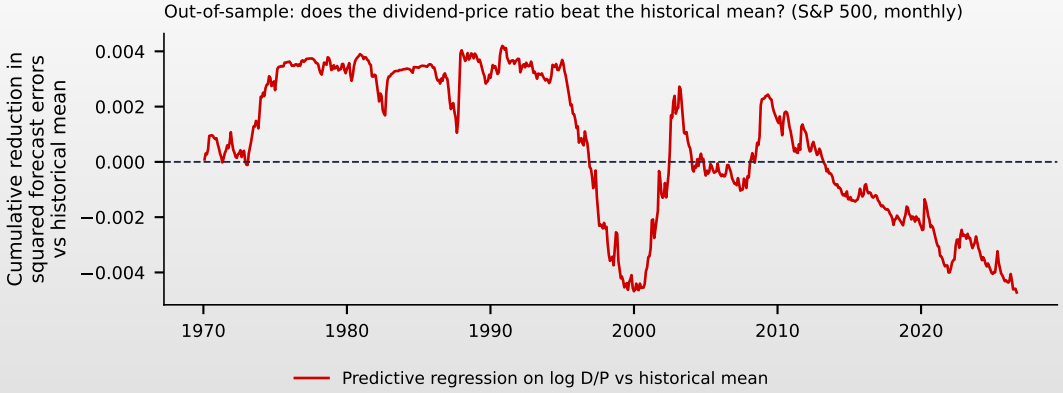
## Cum măsurăm rezultatul: $R^2_{OS}$

- $R^2_{OS} = 1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t (r_t - \bar{r}_t)^2$, cu sumele pe lunile prognozate.
- $R^2_{OS} > 0$: prognoza cu *dp* are erori pătratice mai mici decît media istorică.
- $R^2_{OS} < 0$: media istorică prognozează mai bine; spre deosebire de $R^2$ in-sample, $R^2_{OS}$ poate fi negativ.
- De ce diferă cele două: in-sample, $\hat{\beta}$ se potrivește și cu zgomotul lunilor pe care le explică.
- Un $R^2_{OS}$ pozitiv poate apărea și din întîmplare; semnificația lui o testăm separat (testul Clark–West, la rezultate).

## Cum citim graficul erorilor pătratice cumulate

- În fiecare lună, din 1970, adunăm diferența $(r_t - \bar{r}_t)^2 - (r_t - \hat{r}_t)^2$: eroarea pătratică a mediei istorice minus cea a prognozei cu *dp*.
- Curba urcă în lunile în care *dp* prognozează mai bine și coboară în cele în care prognozează mai prost.
- Exemplu: erori de 2, 1 și 3 puncte procentuale pentru media istorică și de 1, 2 și 3 pentru *dp* dau termenii 3, $-3$ și 0; curba urcă la 3 și revine la 0.
- Valoarea finală a curbei are semnul lui $R^2_{OS}$.
- Axa verticală: suma diferențelor, cu randamentele în fracții (0,01 = 1%), ridicate la pătrat.

# Raportul dividend–preț: prognoze out-of-sample



## Raportul dividend–preț: rezultatele pentru S&P 500 (1/2)

- Curba se termină sub zero: pe 680 de prognoze lunare, $R^2_{OS} = -0{,}51\%$.
- Prognoza cu *dp* greșește deci ceva mai mult decît media istorică.
- Testul Clark–West Clark & West (2007) compară erorile pătratice și corectează un dezavantaj al modelului cu *dp*: chiar dacă $\beta = 0$, estimarea lui $\beta$ adaugă zgomot prognozei.
- Pe S&P 500, testul dă $t = 0{,}42$ ($p$ unilateral $= 0{,}34$): nu respingem lipsa predictibilității.
- Pînă în 1990 curba urcă: *dp* a prognozat mai bine decît media istorică.
- În boom-ul anilor 1990, *dp* a coborît la minime record, iar prețurile au continuat să crească: avantajul s-a pierdut.
- În anii 2000 avantajul a revenit parțial, iar după 2010 s-a pierdut din nou.

# Raportul dividend–preț: rezultatele pentru S&P 500 (2/2)

- Contează economic un $R^2_{OS}$ mic? Campbell & Thompson (2008) arată că da: și 0,5% este mult pentru un investitor.
- Un investitor medie–dispersie care își mărește expunerea la acțiuni când prognoza este mare și o micșorează când este mică și-ar crește randamentul așteptat cu circa 20% (formula: Anexa).
- Calculul folosește raportul Sharpe lunar al pieței, 0,160: media randamentului în exces împărțită la abaterea lui standard.
- Campbell și Thompson impun și două restricții: $\hat{\beta}$ cu semnul prezis de teorie și prognoză nenegativă a primei de risc.
- Pe S&P 500, restricțiile se activează în 5,7% din luni și lasă $R^2_{OS}$ la $-0{,}51\%$: cîștigul economic lipsește.

## Verificare: predictibilitate out-of-sample

- Ce înseamnă un $R^2_{OS}$ negativ?
- De ce poate o regresie cu $R^2$ bun in-sample să eșueze pe date noi?
- Poate o strategie profitabilă să aibă $R^2_{OS}$ negativ?
- Ce spune pierderea avantajului lui *dp* în anii 1990 despre stabilitatea relației?

## Răspunsuri: predictibilitate out-of-sample

- Media istorică a prognozat mai bine decît modelul pe lunile evaluate.
- In-sample, $\hat{\beta}$ se potrivește și cu zgomotul; pe date noi zgomotul nu se repetă.
- Da: profitul poate veni din expunerea constantă la piață sau din cîteva prognoze corecte de semn, nu din erori pătratice mici.
- Relația nu este stabilă: un predictor util pînă în 1990 își pierde tot avantajul cînd *dp* coboară la minime record.

## 4. Studii de eveniment

- Întrebarea: cît de repede și cît de complet încorporează prețul o știre publică datată precis?
- Pentru răspuns avem nevoie de randamentul pe care acțiunea l-ar fi avut fără știre.
- Diferența dintre randamentul observat și acest randament așteptat este abnormal return (AR, randamentul anormal).
- Un event study măsoară AR în jurul știrii și testează astfel eficiența semi-tare Fama, Fisher, Jensen & Roll (1969).
- Exemplul secțiunii: taxa bancară anunțată în decembrie 2018, o știre neanticipată care a lovit direct băncile listate.

# Metoda studiului de eveniment (1/3)




- Modelul de piață: $r_{i,t} = a_i + b_i r_{m,t} + \varepsilon_{i,t}$, cu $a_i$ termenul liber, $b_i$ beta de piață a firmei $i$ și $r_{m,t}$ randamentul indicelui pieței în ziua $t$.
- Modelul scoate din randamentul firmei partea explicată de mișcarea pieței din aceeași zi.
- La date zilnice, modelele cu mai mulți factori reduc doar puțin dispersia lui *AR* MacKinlay (1997).
- Fereastra de estimare $[-250, -11]$: circa un an de tranzacționare în care estimăm $a_i$ și $b_i$.
- Ea se oprește cu 10 zile înainte de eveniment, ca o eventuală scurgere de informație să nu intre în estimare.
- Fereastra evenimentului $[0, +5]$: ziua anunțului și încă cinci zile, ca să vedem dacă reacția continuă sau se inversează.

## Metoda studiului de eveniment (2/3)

- Randamentul anormal: $AR_{i,t} = r_{i,t} - \hat{a}_i - \hat{b}_i r_{m,t}$, cu $\hat{a}_i$, $\hat{b}_i$ estimate în fereastra de estimare.
- Randamentul anormal cumulat (CAR, cumulative abnormal return): $CAR_i[\tau_1, \tau_2] = \sum_{t=\tau_1}^{\tau_2} AR_{i,t}$, unde $[\tau_1, \tau_2]$ sînt zilele însumate.
- $\hat{\sigma}_\varepsilon$: abaterea standard a reziduurilor din fereastra de estimare.
- Test de primă aproximare: $t = CAR_i/(\hat{\sigma}_\varepsilon\sqrt{L})$, cu $L$ numărul de zile însumate MacKinlay (1997).
- Numitorul este abaterea standard a sumei a $L$ reziduuri independente cu aceeași dispersie.
- Formula ignoră incertitudinea lui $\hat{a}_i$ și $\hat{b}_i$; corecția ei apare la exemplul rezolvat.

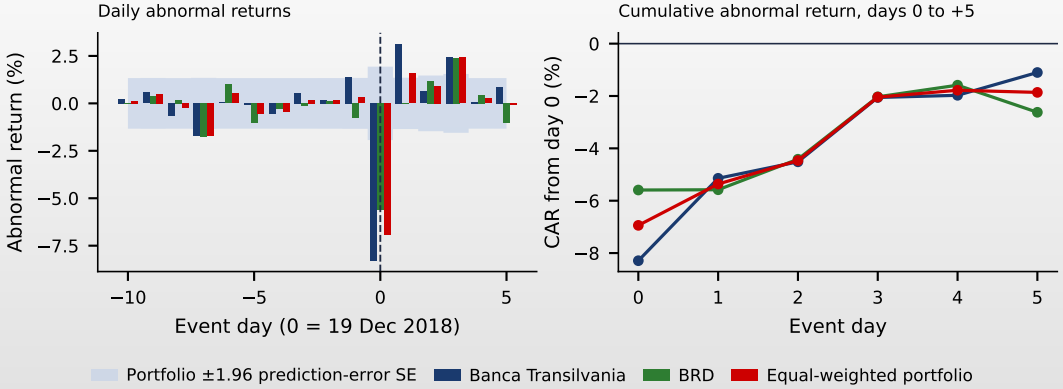
# Metoda studiului de eveniment (3/3)

- Pentru o știre neanticipată, eficiența implică un salt în ziua 0, fără drift și fără inversare predictibilă ulterior
- Datele zilnice pot arăta doar absorbția în aceeași zi, iar viteza la scara microsecundelor necesită date intrazilnice (Capitolul 10; literatura: Anexa)
- Aplicație: reacția prețului Ethereum la etapele de dezvoltare ale rețelei (Quantinar: Market Responses to ETH Development Milestones)

## Taxa bancară: datele și cum citim graficul

- Guvernul a anunțat taxa pe activele bancare în seara de 18 decembrie 2018; ziua 0 a evenimentului este 19 decembrie.
- Analizăm Banca Transilvania (TLV), BRD și portofoliul lor egal ponderat; $r_{m,t}$ este randamentul indicelui BET.
- Panoul din stînga: *AR* zilnic, în procente, din ziua $-10$ pînă în ziua $+5$.
- Banda albastră deschis: $\pm 1{,}96$ abateri standard ale erorii de predicție a portofoliului; o bară a portofoliului în afara ei este semnificativă la 5%.
- Panoul din dreapta: *CAR* de la ziua 0 pînă la ziua de pe axa orizontală, în procente.
- O curbă care revine spre zero după ziua 0 indică o reacție inversată.

# Exemplu rezolvat: taxa bancară din decembrie 2018




MFM_ch2_seminar

## Taxa bancară din decembrie 2018: rezultatele (1/2)

- Pentru TLV, beta de piață estimat este 1,18, iar abaterea standard a reziduurilor din fereastra de estimare este 0,83% pe zi.
- În ziua 0, randamentul anormal al TLV este $AR_0 = -8{,}3\%$, cu $t = -10{,}0$ după formula de primă aproximare.
- Tot în ziua 0: $AR_0 = -5{,}6\%$ pentru BRD și $-6{,}9\%$ pentru portofoliul egal ponderat.
- În aceeași zi, randamentul logaritmic al BET a fost $-11{,}9\%$, adică o scădere a indicelui de 11,2%.
- Cu un randament al pieței atît de extrem, incertitudinea lui $\hat{b}$ contează: eroarea standard a predicției pentru TLV crește de la 0,83% la 1,21%.
- Cu această eroare de predicție, $t = -6{,}85$; efectul rămîne puternic semnificativ.
- TLV și BRD au ponderi mari în BET, deci $r_{m,0}$ conține deja o parte din șoc, iar $AR_0$ subestimează scăderea.

## Taxa bancară din decembrie 2018: rezultatele (2/2)

- În zilele $+1, \ldots, +5$, randamentul anormal cumulat al TLV este $+7{,}2\%$ ($t = 3{,}82$).
- Pe fereastra $0, \ldots, +5$, randamentul anormal cumulat este doar $-1{,}1\%$ ($t = -0{,}54$): scăderea din ziua 0 a fost aproape recuperată într-o săptămînă.
- Prima explicație posibilă: o **reacție excesivă** în ziua 0, incompatibilă cu eficiența semi-tare.
- A doua explicație posibilă: știri ulterioare despre forma finală a ordonanței.
- A treia explicație posibilă: indicele BET, dominat de bănci, a revenit odată cu ele, deci $AR$ măsurat față de BET amestecă cele două mișcări.
- Un singur eveniment nu ne permite să alegem între cele trei explicații.

MFM_ch2_seminar

## Verificare: studii de eveniment

- De ce trebuie precizată fereastra de eveniment?
- Ar putea alt anunț explica aceeași mișcare?

## Răspunsuri: studii de eveniment

- CAR adună randamentele anormale doar din zilele ferestrei.
- O fereastră aleasă după ce vedem datele poate crea sau ascunde un efect.
- Da: știrile suprapuse sînt o explicație alternativă, deci reacția singură nu dovedește cauzalitatea.

## 5. Testare multiplă și anomalii

- Întrebarea: rămîne o anomalie de calendar semnificativă după ce ținem cont de cîte tipare au fost căutate?
- Literatura a testat mii de tipare pe aceleași date, iar unele trec testul doar din întîmplare Harvey, Liu & Zhu (2016).
- Un p-value mic are alt sens după 15 teste decît după unul singur.
- Întîi măsurăm cîte false anomalii produce hazardul, apoi corectăm testele reale cu Bonferroni și Holm.

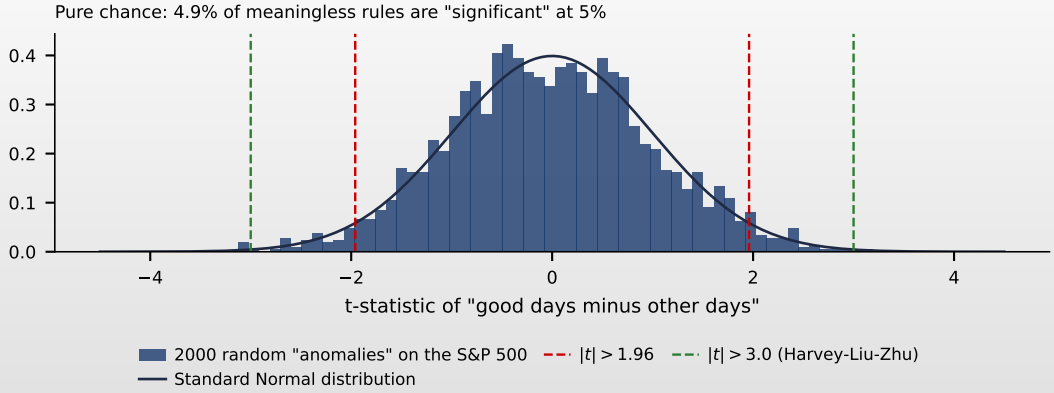
## Calendar effects și data snooping

- Un calendar effect este o diferență de randament mediu asociată unei zile sau luni.
- Efectul zilei săptămînii: randamentele medii diferă între luni, marți, . . . , vineri French (1980).
- Efectul lunii ianuarie: randamentul mediu din ianuarie diferă de cel din celelalte luni Rozeff & Kinney (1976).
- Turn of the month (TOM): ultima zi de tranzacționare din lună și primele trei ale lunii următoare Ariel (1987).
- Data snooping: selectarea unui tipar după căutarea multor alternative pe aceleași date.

## „Anomalii" produse de hazard (1/3)

- De ce simulăm: vrem să vedem cîte „anomalii" apar cînd știm sigur că nu există niciuna.
- Experimentul: 2 000 de reguli de tranzacționare fără niciun conținut economic, pe randamentele zilnice ale S&P 500.
- Fiecare regulă alege la întîmplare 20% din zile și le numește „zile bune".
- Pentru fiecare regulă, un test $t$ compară randamentul mediu din „zilele bune" cu cel din celelalte zile.
- Toate ipotezele nule sînt adevărate, deci orice respingere este falsă.
- Graficul: histograma celor 2 000 de statistici $t$, peste densitatea distribuției Normale standard.
- Liniile verticale: pragurile $|t| = 1{,}96$ (5%) și $|t| = 3{,}0$, pragul propus de Harvey, Liu & Zhu (2016).

# „Anomalii” produse de hazard (2/3)




MFM_ch2_multiple_testing

## „Anomalii" produse de hazard (3/3)

- Rezultat: 4,9% dintre reguli au $|t| > 1{,}96$, adică sînt „semnificative" la 5%, aproape cît prevede nivelul de 5%.
- Cea mai „spectaculoasă" regulă are $|t| = 3{,}19$: raportată singură, ar trece chiar și pragul strict $|t| > 3{,}0$, deși este pur hazard.
- Pragul $|t| > 3{,}0$ îl trec 0,25% dintre regulile aleatoare, adică 5 reguli din 2 000.
- Numărul de reguli încercate (familia de teste) contează la fel de mult ca pragul ales.
- Sullivan, Timmermann & White (1999) arată cum se corectează data snooping în regulile de tranzacționare.

MFM_ch2_multiple_testing

## Cum citim tabelul efectelor de calendar

**HAC**: Heteroskedasticity and Autocorrelation Consistent — erori standard care permit dispersie variabilă și autocorelație.

- Aplicăm aceeași logică la 15 teste reale: cinci piețe $\times$ trei efecte (ziua săptămînii, ianuarie, TOM), pe date zilnice din 2000.
- Comparăm piețe dezvoltate (S&P 500, Euro Stoxx 50) cu piețe emergente din regiune (BET, WIG20, BUX).
- Diferența în ianuarie: randamentul mediu din ianuarie minus media celorlalte luni, în procente pe lună.
- Diferența TOM: randamentul mediu din zilele TOM minus media celorlalte zile, în puncte de bază (bp; 1 bp $= 0{,}01$ puncte procentuale) pe zi.
- Folosim erori HAC pentru că randamentele au volatility clustering, iar erorile standard obișnuite ar umfla statisticile $t$.

## Efectul lunii ianuarie și efectul schimbării lunii

| **Piața** | Diferența în ianuarie (%/lună) | $t_{HAC}$ | Diferența TOM (bp/zi) | $t_{HAC}$ | $p$ (TOM) |
|---|---|---|---|---|---|
| S&P 500 | −0,66 | −0,80 | 3,2 | 0,93 | 0,3539 |
| BET (România) | 3,48 | 1,49 | 17,3 | 3,62 | 0,0003 |
| Euro Stoxx 50 | −0,30 | −0,29 | 5,1 | 1,21 | 0,2266 |
| WIG20 (Polonia) | 0,53 | 0,40 | 8,2 | 1,73 | 0,0841 |
| BUX (Ungaria) | 2,66 | 2,25 | 15,1 | 3,63 | 0,0003 |

- TOM: randamentul suplimentar este +17,3 bp pe zi pentru BET și +15,1 bp pentru BUX, ambele cu $|t| > 3{,}5$, peste pragul 3,0 al lui Harvey, Liu & Zhu (2016)
- Pentru S&P 500, randamentul suplimentar TOM este doar +3,2 bp pe zi și nu este semnificativ ($t = 0{,}93$)
- Pentru BET, randamentul din ianuarie depășește media celorlalte luni cu 3,48 puncte procentuale, dar estimația este imprecisă ($t = 1{,}49$)
- BUX, cu $t = 2{,}25$, este singura piață pentru care p-value-ul efectului lunii ianuarie este sub 0,05
- Al treilea efect, ziua săptămînii, nu este semnificativ pe nicio piață: cel mai mic p-value este 0,2262 (WIG20)
- Am efectuat 15 teste (5 piețe × 3 efecte): care rămîn semnificative după o corecție pentru testare multiplă?

## Testarea multiplă: Bonferroni și Holm

**FWER**: Family-Wise Error Rate — probabilitatea cel puțin unei respingeri false în familia de teste.

- De ce FWER: vrem ca fiecare anomalie raportată să fie reală, nu doar proporția lor.
- Cu $M$ teste independente la nivelul $\alpha$: FWER $= 1 - (1-\alpha)^M$.
- Pentru $M = 15$ și $\alpha = 5\%$, FWER ar fi 53,7% dacă testele ar fi independente.
- **Bonferroni**: respingem doar dacă $p_i < \alpha/M$; garantează FWER $\leq \alpha$ pentru orice dependență între teste.
- **Holm**: ordonăm $p_{(1)} \leq \cdots \leq p_{(M)}$ și respingem cît timp $p_{(j)} < \alpha/(M-j+1)$, oprindu-ne la prima nerespingere.
- Holm are aceeași garanție și respinge cel puțin tot ce respinge Bonferroni.
- Metode bootstrap care folosesc corelația dintre teste (StepM): Anexa.

## Holm pe cele 15 p-value-uri de calendar (1/2)

- Toate p-value-urile sînt bilaterale; pentru ianuarie și TOM provin din statistica $t$ HAC comparată cu distribuția Normală.
- Pentru zilele săptămînii provin dintr-un test Wald al egalității celor cinci medii zilnice (patru restricții, $\chi^2_4$).

| **Piața** | Zilele săptămînii, medii egale | Ianuarie | TOM |
|---|---|---|---|
| S&P 500 | 0,8263 | 0,4257 | 0,3539 |
| BET (România) | 0,3052 | 0,1368 | 0,0003 |
| Euro Stoxx 50 | 0,6319 | 0,7738 | 0,2266 |
| WIG20 (Polonia) | 0,2262 | 0,6865 | 0,0841 |
| BUX (Ungaria) | 0,9327 | 0,0245 | 0,0003 |

## Holm pe cele 15 p-value-uri de calendar (2/2)

- Cele mai mici două p-value-uri sînt TOM la BET și TOM la BUX, ambele 0,0003.
- Ele sînt sub pragurile Holm $0{,}05/15 = 0{,}0033$ și $0{,}05/14 = 0{,}0036$, deci ambele ipoteze nule se resping.
- Al treilea p-value, ianuarie la BUX (0,0245), depășește pragul $0{,}05/13 = 0{,}0038$, deci Holm se oprește aici.
- Fără corecție, ianuarie la BUX ar fi fost a treia respingere, pentru că $0{,}0245 < 0{,}05$.

## Verificare: testare multiplă și anomalii

- De ce schimbă testarea multor reguli interpretarea unui p-value mic?
- Nerespingerea dovedește eficiența?
- Ce selecție nouă sau verificare de robustețe ai cere?

## Răspunsuri: testare multiplă și anomalii

- Căutarea multor reguli creează mai multe ocazii de respingere falsă.
- Nu. Un test cu putere mică poate să nu respingă chiar dacă piața este ineficientă.
- Concluzia privește doar alternativa testată, nu orice formă de predictibilitate.
- Exemplu: aceeași regulă pe date de după publicare sau pe altă piață; un artefact de data snooping dispare out-of-sample.
- Un efect real slăbește de obicei după publicare, dar nu dispare McLean & Pontiff (2016).

## Rezultatele principale ale capitolului

- S&P 500: variance ratio pe 2 zile $\widehat{\mathrm{VR}}(2) = 0{,}901$, adică inversare a randamentelor la orizonturi de 2–10 zile.
- BET: variance ratio peste 1, adică persistență, la toate cele patru orizonturi testate.
- Raportul dividend–preț nu bate media istorică out-of-sample: $R^2_{OS} = -0{,}51\%$.
- Taxa bancară: $AR$ al TLV a fost $-8{,}3\%$ în ziua 0 și a fost aproape recuperat în cinci zile; un singur eveniment nu separă reacția excesivă de știrile ulterioare.
- După corecția Holm rămîn semnificative doar efectele TOM la BET și la BUX.

## Teme pentru studiu suplimentar

- ⊡ Date și convenții
- ⊡ Fair game, evaluare și rational bubbles
- ⊡ Construcția testelor și alternative
- ⊡ Regresii predictive și bias
- ⊡ Memorie lungă și eficiență variabilă
- ⊡ Inferență în event studies
- ⊡ Anomalii și explicații comportamentale
- ⊡ Machine learning și proiectarea cercetării
- ⊡ AI pentru descoperire științifică
- ⊡ Sinteză și referințe tehnice

# Datele folosite în acest capitol (1/2)

**BNR**: Banca Națională a României.

- Folosim 16 serii de prețuri zilnice, pînă la 18 septembrie 2026; numărul de observații al fiecărei serii este în Anexa
  - 13 indici bursieri din 2000: 4 din piețe dezvoltate (S&P 500, Euro Stoxx 50, Nikkei 225, Hang Seng), 9 din piețe emergente sau de frontieră (BET, WIG20, BUX, PX, BIST 100, Bovespa, IPC, Nifty 50, Shanghai)
  - Bitcoin din 2014 în testele pe întreaga selecție și pe ferestre rolling; analiza anuală a criptoactivelor începe din 2011, ca să acopere și primii ani ai pieței
  - Ethereum din 2016 și EUR/RON, cursul de referință BNR, din iulie 2005
- Randamente logaritmice zilnice $r_t = \ln P_t - \ln P_{t-1}$, fiecare serie pe propriul calendar
  - $P_t$: prețul de închidere (nivelul indicelui, cursul de schimb) din ziua $t$
- Pentru indicii bursieri folosim doar zilele de tranzacționare

## Datele folosite în acest capitol (2/2)

- Eliminăm observațiile cu același preț de închidere ca în ziua precedentă; de obicei, ele corespund unor zile nelucrătoare completate cu ultimul preț disponibil
  - regula elimină și rarele zile reale cu randament zero (S&P 500: 3 din circa 6 700 de zile)
  - statisticile testelor se modifică cu mai puțin de 0,05
- Criptoactivele se tranzacționează 7 zile din 7: 365 de observații pe an
- Analizele care folosesc mai multe serii simultan (de ex. studiile de eveniment) aliniază prețurile pe zilele comune de tranzacționare înainte de calculul randamentelor

## Piețele din grafice

- **US**: United States — în grafice, seria indicelui S&P 500.
- **HK**: Hong Kong — în grafice, seria indicelui Hang Seng.
- **BIST**: Borsa İstanbul — Bursa din Istanbul (indicele BIST 100).
- **WIG20**: Warszawski Indeks Giełdowy 20 — indicele celor mai mari 20 de companii de la Bursa din Varșovia.
- **BUX**: Budapesti Értéktőzsde index — indicele Bursei din Budapesta.
- **PX**: Prague Stock Exchange index (index Burzy cenných papírů Praha) — indicele Bursei din Praga.
- **IPC**: Índice de Precios y Cotizaciones — indicele Bursei din Mexic.
- **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București.
- **FX**: Foreign eXchange — piața valutară.

## Ce restricție impune eficiența asupra prețurilor?

- Întrebarea: ce restricție exactă impune eficiența asupra prețurilor și ce lasă liber?
- Răspunsul standard este fair game: randamentul peste cel cerut nu poate fi prognozat.
- Testele de autocorelație din secțiunea 2 verifică doar o consecință a acestei condiții.
- Randamentul cerut vine dintr-un model de evaluare, deci orice test de fair game este și un test al acelui model Fama (1991).
- Fair game permite rational bubbles, dar exclude abaterile care revin previzibil la valoarea fundamentală (fads).
- Abaterile nu dispar mereu: arbitrajul este riscant cînd convergența prețurilor este nesigură Shleifer & Vishny (1997) (ultimul slide al temei).

## Fair game și martingal

- **Fair game** pentru randamentele în exces: $\mathbb{E}[r_{t+1} - \mu_t \mid \mathcal{I}_t] = 0$
  - $\mathcal{I}_t$: informația disponibilă la sfîrșitul zilei $t$; $\mathbb{E}[\cdot \mid \mathcal{I}_t]$: media condiționată de această informație
  - $\mu_t$: randamentul cerut (de echilibru), compensația pentru risc
  - în cuvinte: randamentul peste $\mu_t$ nu poate fi prognozat din $\mathcal{I}_t$
- **Martingal**: un proces pentru care valoarea așteptată la momentul următor, dată fiind informația din trecut, este egală cu valoarea curentă
  - cu un randament simplu cerut constant $m$, valoarea $V_t$ a unei poziții cu dividendele reinvestite, actualizată cu $m$, $V_t/(1+m)^t$, este un martingal Campbell, Lo & MacKinlay (1997)
  - actualizarea cu dobînda fără risc dă un martingal doar sub măsura neutră la risc (slide-ul despre risk-neutral measure)
  - prețul $P_t$ însuși este martingal doar dacă nu se plătesc dividende și $m = 0$; atunci randamentul logaritmic așteptat este negativ (termenul lui Jensen, slide-ul următor)

## Termenul lui Jensen: de ce diferă mediile

- Logaritmul este concav: media logaritmilor este mai mică decît logaritmul mediei, cu egalitate pentru rezultate constante.
- Randamentele simple egal probabile de $+10\%$ și $-10\%$ au media zero.
- Media randamentului logaritmic este $\frac{1}{2}\ln(1{,}1) + \frac{1}{2}\ln(0{,}9) = \frac{1}{2}\ln(0{,}99) \approx -0{,}00503$.
- Pe o traiectorie cu o creștere și o scădere, averea 100 devine $100(1{,}1)(0{,}9) = 99$: media aritmetică zero nu păstrează averea acumulată.

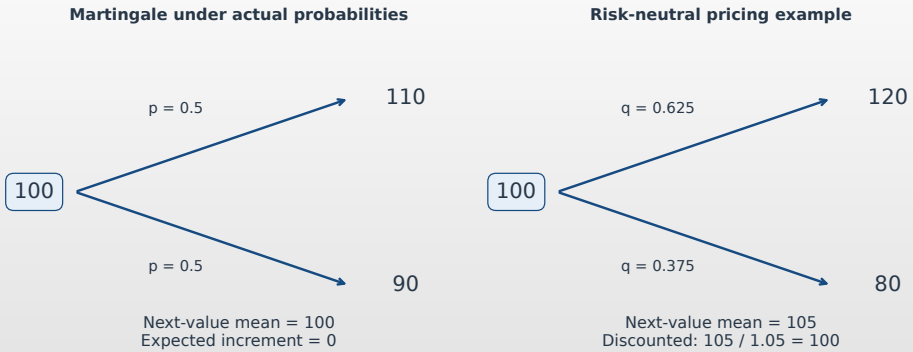
## Prețuri, log-prețuri și informație

- „$\mathbb{E}[P_{t+1} \mid \mathcal{I}_t] = P_t$" (martingal în prețuri) și „$\mathbb{E}[\ln(P_{t+1}/P_t) \mid \mathcal{I}_t] = \mu$" (media constantă a randamentului logaritmic) sînt restricții diferite
  - diferența este termenul lui Jensen: $\mathbb{E}[\ln(1+R)] \approx \mathbb{E}[R] - \mathrm{Var}(R)/2$, cu $R = P_{t+1}/P_t - 1$ randamentul simplu
- Consecința condiției de fair game: $\mathrm{corr}(\varepsilon_{t+1}, g(\mathcal{I}_t)) = 0$ pentru orice funcție $g$ a informației din trecut, unde $\varepsilon_{t+1} = r_{t+1} - \mu_t$ este partea neașteptată a randamentului
- Dacă $\mu_t = \mu$ este constant, toate autocorelațiile $\rho_k = \mathrm{corr}(r_t, r_{t-k})$, $k \geq 1$, sînt zero: aceasta este ipoteza testată în secțiunea 2
- Reciproca nu este adevărată: autocorelațiile zero nu exclud o medie predictibilă neliniar (MDH, în tema următoare)

## Actualizare și risk-neutral measure

- De ce: martingalul de mai sus folosește probabilitățile reale și randamentul cerut $m$; teoria evaluării folosește, echivalent, dobînda fără risc și probabilități ajustate la risc.
- Măsura neutră la risc (risk-neutral measure) folosește probabilități de evaluare sub care prețurile tranzacționate, cu dividende incluse și actualizate, sînt martingale într-un model fără arbitraj.
- Exemplu: o acțiune fără dividende costă azi 100; peste un an valorează 120 sau 80; dobînda fără risc este 5%.
  - Probabilitatea de evaluare $q = 0{,}625$ dă $q\,120 + (1-q)80 = 105$, iar $105/1{,}05 = 100$, prețul de azi.
- Acest $q$ nu trebuie să coincidă cu probabilitatea reală de creștere: probabilitățile de evaluare nu prognozează frecvențe.

# Probabilități și medii condiționate




Stînga: media condiționată reală rămîne 100. Dreapta: probabilitățile de evaluare dau 105, cu valoarea actualizată 100.

## Rational bubble: definiția

- Valoarea fundamentală: valoarea actualizată a fluxurilor de numerar așteptate de la activ.
  - Pentru o acțiune, aceste plăți sînt dividendele.
  - Actualizarea exprimă plățile viitoare în banii de astăzi.
- O **rational bubble** (bulă rațională) este o componentă pozitivă a prețului peste valoarea fundamentală.
  - Este susținută de anticiparea revînzării.
  - $P_t = P_t^* + B_t$: $P_t$ este prețul, $P_t^*$ valoarea fundamentală, iar $B_t$ componenta de bulă.
- Așteptările raționale sînt compatibile cu modelul, inclusiv cu riscul de crah.
  - Ele nu implică un cîștig sigur.

## Valoare fundamentală, rational bubble și fad

- Cu un randament simplu cerut constant $m$, condiția de fair game este $\mathbb{E}[P_{t+1} + D_{t+1} \mid \mathcal{I}_t] = (1+m)\,P_t$
- $D_{t+1}$: fluxul de numerar (dividendul) plătit în $t+1$
  - Valoarea fundamentală $P_t^* = \mathbb{E}\left[\sum_{j\geq 1} D_{t+j}/(1+m)^j \mid \mathcal{I}_t\right]$
  - Eroarea de preț $B_t = P_t - P_t^*$
  - Valoarea fundamentală $P_t^*$ satisface aceeași ecuație de fair game ca prețul
  - Scăzînd cele două ecuații, abaterea $B_t$ satisface $\mathbb{E}[B_{t+1} \mid \mathcal{I}_t] = (1+m)\,B_t$
- Condiția de fair game nu impune egalitatea dintre preț și valoarea fundamentală; permite și o **rational bubble**
  - O abatere $B_t \neq 0$ este compatibilă cu modelul doar dacă, în medie, crește în ritmul randamentului cerut $m$ (Capitolul 17)
  - O abatere care revine la medie (fad) face $\varepsilon_{t+1}$ predictibil și încalcă condiția de fair game, deși testele pe orizont scurt au o capacitate redusă de a detecta această abatere Summers (1986)
- Restricția privește doar media condiționată: dispersia nu este restricționată, iar volatilitatea poate fi predictibilă (Capitolul 1)

## Rational bubble: exemplu numeric

- O acțiune plătește 10 lei la sfîrșitul fiecărui an, la nesfîrșit.
  - Primul dividend se plătește peste un an.
  - Randamentul cerut constant este $m = 10\%$; valoarea fundamentală este $P_t^* = 10/0{,}10 = 100$ lei.
- Astăzi $P_t = 120$ lei, deci $B_t = 20$ lei.
  - Fără crah, $B_{t+1} = 1{,}1 \times 20 = 22$ lei.
  - După plata dividendului de anul viitor, valoarea fundamentală rămîne 100 lei; prețul este deci 122 lei.
- Randamentul simplu total este $(122 + 10 - 120)/120 = 10\%$.

# Rational bubble: ce se întîmplă în cazul unui crah?

- Bula inițială este $B_t = 20$ lei, iar randamentul cerut este $m = 10\%$.
  - Probabilitatea de supraviețuire este $\pi = 0{,}8$; probabilitatea de crah este $1 - \pi = 0{,}2$.
  - În cazul unui crah, bula devine zero; investitorii cunosc probabilitățile.
- Fair game pentru bulă, $\mathbb{E}[B_{t+1} \mid \mathcal{I}_t] = (1+m)B_t$, cere o bulă așteptată de $(1+m)B_t = 22$ lei.
  - Condiționat de supraviețuire: $B_{t+1} = 22/0{,}8 = 27{,}5$ lei.
  - Verificare: $0{,}8 \times 27{,}5 + 0{,}2 \times 0 = 22$.
  - Creșterea condiționată este $27{,}5/20 - 1 = 37{,}5\%$.
- Mecanismul crahului: Blanchard & Watson (1982), Bubbles, Rational Expectations and Financial Markets.
- Prețul de cumpărare este 120 lei; dividendul de la sfîrșitul anului este 10 lei.
- Supraviețuire: prețul după plata dividendului este 127,5 lei.
  - Randament simplu: $(127{,}5 + 10 - 120)/120 \approx 14{,}6\%$.
- Crah: prețul scade la valoarea fundamentală, 100 lei.
  - Randament simplu: $(100 + 10 - 120)/120 \approx -8{,}3\%$.
- Randament așteptat: $0{,}8 \times (127{,}5 + 10 - 120)/120 + 0{,}2 \times (100 + 10 - 120)/120 = 10\%$.
  - Randamentul așteptat respectă fair game; randamentul realizat poate fi diferit.

## Rational bubble și no-bubble condition

- Fair game restricționează doar randamentul așteptat pe perioada următoare; nu fixează nivelul prețului.
- **No-bubble condition** (condiția de absență a bulei, numită și condiție de transversalitate):
  $$\lim_{k\to\infty} \frac{\mathbb{E}[P_{t+k} \mid \mathcal{I}_t]}{(1+m)^k} = 0$$
  - $k$: orizontul revînzării; valoarea actualizată a prețului de revînzare așteptat tinde la zero
- Cu această condiție, prețul este egal cu valoarea fundamentală $P_t^*$: el este susținut integral de dividende.
- O rational bubble încalcă condiția: din $\mathbb{E}[B_{t+k} \mid \mathcal{I}_t] = (1+m)^k B_t$, valoarea actualizată a bulei rămîne $B_t \neq 0$ la orice orizont.
- În exemplul numeric, bula de 20 de lei valorează tot 20 de lei în bani de azi, oricît de departe ar fi revînzarea.
- Tirole (1985): în modelele cu generații suprapuse, o bulă poate exista doar dacă rata dobînzii este sub rata de creștere a economiei.

## Paradoxul Grossman–Stiglitz

- Colectarea informației este costisitoare (analiști, date, putere de calcul)
- Dacă prețurile ar reflecta **toată** informația, nimeni nu ar fi remunerat pentru colectarea ei Grossman & Stiglitz (1980)
  - Atunci nimeni nu ar colecta-o, iar prețurile nu ar mai putea să o reflecte
- Soluția: un **grad de ineficiență de echilibru**, suficient pentru a acoperi costurile celor informați
- Piețele mari și lichide, cu informație ieftină și costuri mici, ar trebui să fie mai aproape de eficiență: o predicție pentru comparația noastră între piețele dezvoltate, cele emergente și piețele de criptoactive
- Eficiența nu exclude bulele: spune doar că momentul lor este greu de anticipat (Capitolul 17)

## Arbitraj pur și tranzacționare relative-value

- Arbitrajul pur este o strategie fără plată inițială netă pozitivă, fără pierdere posibilă și cu un cîștig pozitiv în cel puțin o stare.
- Tranzacționarea relative-value este riscantă cînd convergența prețurilor nu este sigură.
- Exemplu: un ecart de preț de 20 de puncte poate crește la 30 înainte să se închidă; poziția cere atunci garanții suplimentare (margin) și poate fi închisă forțat.
- Legătura cu eficiența: cînd convergența este nesigură, arbitrajorii cu capital limitat nu pot elimina abaterile de la valoarea fundamentală Shleifer & Vishny (1997).

## Momente, cozi și aproximații asimptotice

- Întrebarea: ce ipoteze fac valid un test de eficiență și ce alternative poate detecta?
- Erorile standard robuste ale autocorelațiilor (slide-ul următor) cer un moment de ordin patru finit, $\mathbb{E}[r^4] < \infty$
  - heavy tails: distribuția Student $t$ cu patru grade de libertate are dispersie finită, dar $\mathbb{E}[r^4] = \infty$, iar atunci eroarea standard robustă nu mai converge
- Valorile critice ($\pm 1{,}96$, cuantilele $\chi^2$) sînt aproximații asimptotice: corecte cînd numărul de observații crește, posibil imprecise într-o selecție scurtă, de exemplu o fereastră de 500 de zile
- Teoremele limită cer și dependență slabă (mixing): observațiile suficient de depărtate în timp devin aproape independente
  - mixing permite volatility clustering și dependență între zilele vecine

## Autocorelația și eroarea ei standard robustă

- Autocorelația de selecție: $\hat{\rho}_k = \sum_{t=k+1}^{T} e_t e_{t-k} / \sum_{t=1}^{T} e_t^2$, cu $e_t = r_t - \bar{r}$
  - $T$: numărul de randamente zilnice
  - $\bar{r}$: media lor
  - $k$: lagul
  - $\hat{\rho}_k > 0$: persistență, $\hat{\rho}_k < 0$: inversare
- Sub RW1 (i.i.d.): $\mathrm{SE}(\hat{\rho}_k) \approx 1/\sqrt{T}$
- Null band-ul de 95% $\pm 1{,}96/\sqrt{T}$
- Dacă media este imprevizibilă, dar există volatility clustering și momente de ordinul patru finite: $\mathrm{SE}(\hat{\rho}_k) \approx \sqrt{\hat{\tau}_k}$
  - $\hat{\tau}_k = \sum_t e_t^2 e_{t-k}^2 \,/\, \left(\sum_t e_t^2\right)^2$ (dispersia robustă)
  - Cînd există volatility clustering, $\hat{\tau}_k > 1/T$: null band-ul i.i.d. este prea îngust, iar testele clasice resping ipoteza nulă prea des
  - Statisticile robuste $\tilde{Q}$ (Ljung–Box) și $z^*$ (variance ratio) folosesc $\hat{\tau}_k$ în locul lui $1/T$
- S&P 500: SE i.i.d. = 0,012, SE robustă = 0,027, de peste două ori mai mare

## Teste comune și distribuții de referință

- Un test portmanteau combină corelațiile la mai multe laguri într-o singură statistică, în loc să alegem lagul cel mai spectaculos.
- Distribuția hi-pătrat cu $m$ grade de libertate este distribuția sumei pătratelor a $m$ variabile Normale standard independente.
- Pentru zece laguri testate, reperul este aproximativ $\chi^2_{10}$ în condițiile precizate
  - o statistică egală cu 25 depășește valoarea critică de 5% a lui $\chi^2_{10}$, 18,31.
- Un test Wald verifică în mod similar restricții comune asupra coeficienților
  - egalitatea celor cinci medii zilnice impune patru restricții, $\beta_1 = \beta_2$, $\beta_1 = \beta_3$, $\beta_1 = \beta_4$, $\beta_1 = \beta_5$, deci reperul este $\chi^2_4$, cu valoarea critică de 5% egală cu 9,49.
- Cinci restricții, toate $\beta_d = 0$, ar testa altă ipoteză nulă: media fiecărei zile egală cu zero.

## Teste portmanteau: Ljung–Box și versiunea robustă

- Ljung & Box (1978): $Q(m) = T(T+2)\sum_{k=1}^{m} \hat{\rho}_k^2/(T-k) \sim \chi^2_m$ pentru randamente i.i.d.
  - Testează împreună $H_0$: $\rho_1 = \cdots = \rho_m = 0$
  - $m$: numărul de laguri
  - $\chi^2_m$: distribuția hi-pătrat cu $m$ grade de libertate
  - Un $Q$ mare duce la respingerea lui $H_0$
- Versiunea robustă Lobato, Nankervis & Savin (2001): $\tilde{Q}(m) = \sum_{k=1}^{m} \hat{\rho}_k^2/\hat{\tau}_k \to \chi^2_m$ sub RW3, dacă $\hat{\rho}_k$ de la laguri diferite sînt asimptotic necorelate; condiția, $\mathbb{E}[\varepsilon_t^2 \varepsilon_{t-j}\varepsilon_{t-k}] = 0$ pentru $j \neq k$, este îndeplinită de un GARCH cu inovații simetrice
- Trei piețe la $m = 10$ (valoarea critică la 5% este 18,31)
  - S&P 500: $Q = 96{,}3$, dar $\tilde{Q} = 19{,}9$ ($p = 0{,}031$)
  - BET: $Q = 108{,}0$, $\tilde{Q} = 24{,}4$ ($p = 0{,}007$)
  - Bitcoin: $Q = 20{,}2$ ($p = 0{,}028$), dar $\tilde{Q} = 11{,}9$ ($p = 0{,}294$)
- Cu testul robust respingem în continuare ipoteza nulă pentru S&P 500 și BET, dar nu pentru Bitcoin

## Testul secvențelor (runs test)

- Testul secvențelor Wald & Wolfowitz (1940) folosește doar **semnele** randamentelor (zilele cu randament zero sînt ignorate), deci cozile groase nu îl afectează
- O **secvență** (run) este un bloc maximal de semne egale: ++|-|+++ are 3 secvențe
- Cu $n_1$ zile pozitive, $n_2$ negative și $n = n_1 + n_2$, dacă semnele sînt independente:
  - $\mathbb{E}[R] = \dfrac{2n_1n_2}{n} + 1, \quad \mathrm{Var}[R] = \dfrac{2n_1n_2(2n_1n_2 - n)}{n^2(n-1)}, \quad z = \dfrac{R - \mathbb{E}[R]}{\sqrt{\mathrm{Var}[R]}} \approx N(0,1)$
  - $R$: numărul observat de secvențe; $|z| > 1{,}96$ respinge independența la 5%
  - testul presupune o probabilitate constantă a unei zile pozitive
- Prea **puține** secvențe ($z < 0$) înseamnă semne care persistă; prea **multe** ($z > 0$) înseamnă semne care alternează
- S&P 500: $z = 4{,}34$, semnele alternează, în acord cu $\hat{\rho}_1 < 0$
- BET: $z = -6{,}05$, semnele persistă, în acord cu $\hat{\rho}_1 > 0$
- Bitcoin: $z = 2{,}68$ respinge independența semnelor, deși $\hat{\rho}_1$ nu este semnificativ: semnele și mărimile conțin informații diferite (toate piețele: Anexa)

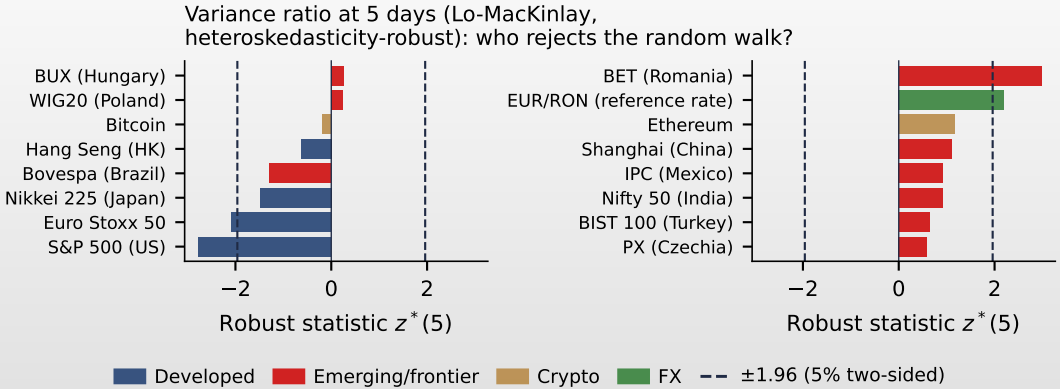
## Testul Lo–MacKinlay

- Lo & MacKinlay (1988) estimează $\mathrm{VR}(q)$ din sume suprapuse de $q$ randamente zilnice și corectează deplasarea din selecții mici
  - $\hat{\sigma}_a^2 = \frac{1}{T-1}\sum_t (r_t - \hat{\mu})^2, \quad \hat{\sigma}_c^2(q) = \frac{1}{m}\sum_{t=q}^{T}\left(\sum_{j=0}^{q-1} r_{t-j} - q\hat{\mu}\right)^2$
  - $m = q(T-q+1)(1-q/T); \quad \widehat{\mathrm{VR}}(q) = \hat{\sigma}_c^2(q)/\hat{\sigma}_a^2$
  - $\hat{\mu}$: randamentul zilnic mediu
  - $\hat{\sigma}_a^2$: dispersia randamentelor pe o zi
  - $\hat{\sigma}_c^2(q)$: dispersia sumelor suprapuse pe $q$ zile, împărțită la $q$
  - $m$: numitorul care corectează deplasarea în selecții mici
- Statistica testului sub RW1 (randamente omoscedastice, adică cu dispersie constantă)
  - $z(q) = \dfrac{\widehat{\mathrm{VR}}(q) - 1}{\sqrt{2(2q-1)(q-1)/(3qT)}} \approx N(0,1)$
  - numitorul este eroarea standard a lui $\widehat{\mathrm{VR}}(q)$ sub RW1
  - $|z| > 1{,}96$ respinge $\mathrm{VR}(q) = 1$ la 5%
- Acest $z$ duce la respingeri prea frecvente cînd există volatility clustering (slide-ul următor)

## Statistica $z^*$, robustă la heteroscedasticitate

- Sub RW3 plus condițiile din Lo & MacKinlay (1988) (momente finite, dependență slabă de tip mixing, $\mathbb{E}[\varepsilon_t^2 \varepsilon_{t-j}\varepsilon_{t-k}] = 0$ pentru $j \neq k$), $\hat{\rho}_k$ sînt asimptotic necorelate, cu dispersiile $\hat{\delta}_k / T$
  - $\hat{\delta}_k = T\hat{\tau}_k$, cu $\hat{\tau}_k$ de pe slide-ul autocorelației: dispersia robustă a lui $\sqrt{T}\hat{\rho}_k$, egală cu 1 fără volatility clustering
- Dispersia asimptotică a lui $\widehat{\mathrm{VR}}(q)$ și statistica testului
  - $\hat{\theta}(q) = \sum_{k=1}^{q-1} \left( \frac{2(q-k)}{q} \right)^2 \hat{\delta}_k, \qquad z^*(q) = \frac{\sqrt{T}\,(\widehat{\mathrm{VR}}(q) - 1)}{\sqrt{\hat{\theta}(q)}} \approx N(0,1)$
  - $2(q-k)/q$: ponderea lui $\hat{\rho}_k$ în $\widehat{\mathrm{VR}}(q)$
  - $|z^*| > 1{,}96$ respinge $\mathrm{VR}(q) = 1$ la 5%
- RW3 singură nu este suficientă: condițiile sînt îndeplinite de GARCH cu inovații simetrice, dar pot să nu fie îndeplinite în prezența efectului de levier
  - Fără condiția $\mathbb{E}[\varepsilon_t^2 \varepsilon_{t-j}\varepsilon_{t-k}] = 0$, calculul lui $\hat{\theta}(q)$ necesită întreaga matrice de covarianță a estimatorilor $\hat{\rho}_k$
- La $q = 5$, S&P 500 are $z^*(5) = -2{,}77$: inversarea rămîne semnificativă și cu eroarea standard robustă (comparația lui $z$ cu $z^*$ la $q = 2$: secțiunea 2)

## Variance ratio la 5 zile pe 16 serii




MFM_ch2_variance_ratio

## Variance ratio la 5 zile și testul Chow–Denning

- Fiecare bară din graficul anterior este statistica robustă $z^*(5)$ a uneia dintre cele 16 serii; liniile întrerupte marchează $\pm 1{,}96$.
- La 5 zile, $|z^*(5)| > 1{,}96$ pentru BET (2,98), S&P 500 ($-2{,}77$), EUR/RON (2,19) și Euro Stoxx 50 ($-2{,}08$).
- Testăm însă patru orizonturi, $q = 2, 5, 10, 20$: testul Chow & Denning (1993) folosește cel mai mare $|z^*(q)|$ dintre ele, cu valoarea critică de 5% egală cu 2,49, nu 1,96.
- Testul comun respinge RW3 pentru 5 din cele 16 serii: BET, S&P 500, EUR/RON, IPC (la 2 zile, $z^* = 3{,}68$) și Ethereum (la 20 de zile, $z^* = 2{,}70$).
- Euro Stoxx 50 respinge la 5 zile, dar nu și în testul comun: cel mai mare $|z^*|$ al lui este $2{,}24 < 2{,}49$.
- Bitcoin: p-value-ul testului Chow–Denning este 0,835, fără respingere.
- Ierarhia „dezvoltat = eficient" nu este confirmată: S&P 500 arată inversare, iar BET și EUR/RON persistență.

MFM_ch2_variance_ratio

## Dincolo de predictibilitatea liniară: ipoteza diferenței de martingal

- **MDH** (Martingale Difference Hypothesis, ipoteza diferenței de martingal): $\mathbb{E}[r_t \mid \mathcal{I}_{t-1}] = \mu$: nicio funcție a trecutului, liniară sau nu, nu prezice media
- RW3 (toate $\rho_k = 0$) este mai slabă. Contraexemplu: $r_t = \varepsilon_t + \theta(\varepsilon_{t-1}^2 - \sigma^2)$, $\varepsilon_t$ i.i.d. simetrice
  - $\sigma^2 = \mathrm{Var}(\varepsilon_t)$, deci termenul suplimentar are media 0
  - $\theta \neq 0$: cît de mult deplasează pătratul șocului de ieri media de azi
  - toate $\rho_k = 0$, dar $\mathbb{E}[r_t \mid \varepsilon_{t-1}] = \theta(\varepsilon_{t-1}^2 - \sigma^2)$ este predictibilă: testele de autocorelație nu o pot detecta
  - Testele MDH propriu-zise, pe slide-ul următor, caută exact acest tip de dependență (rezultate: Anexa)
- **BDS** (Brock–Dechert–Scheinkman) Brock, Dechert, Scheinkman & LeBaron (1996) compară frecvența secvențelor de randamente apropiate cu cea implicată de observații i.i.d.; testează i.i.d., nu MDH: un model GARCH poate determina singur respingerea ipotezei nule
  - O respingere BDS este o dovadă împotriva RW1, nu împotriva eficienței slabe

## Ce examinează testele neliniare

- De ce: contraexemplul de pe slide-ul anterior arată că autocorelațiile zero nu exclud o medie predictibilă
- Testul spectral generalizat Escanciano & Velasco (2006) măsoară covarianța dintre $r_t$ și funcții neliniare ale randamentelor trecute, $e^{\mathrm{i}xr_{t-j}}$, la toate lagurile $j$
  - el detectează contraexemplul $r_t = \varepsilon_t + \theta(\varepsilon_{t-1}^2 - \sigma^2)$, pe care autocorelațiile îl ratează
- Testul portmanteau automat Escanciano & Lobato (2009) este un Ljung–Box robust la heteroscedasticitate, cu numărul de laguri ales din date printr-o penalizare
  - el testează doar autocorelațiile, deci nu detectează contraexemplul neliniar

## Variabile predeterminate, bias și consistență

- De ce distorsionează un predictor persistent inferența într-o selecție finită?
- Un predictor predeterminat este cunoscut înaintea șocului randamentului prognozat
  - exogenitatea strictă exclude în plus corelația cu șocurile de la toate datele.
- Raportul dividend–preț de azi poate prognoza randamentul lunii următoare, dar șocul de preț din luna următoare modifică și raportul: acest feedback împiedică exogenitatea strictă.
- Deplasarea (bias) este media estimatorului în selecții repetate minus parametrul adevărat: o pantă medie de 0,03 cînd panta adevărată este zero înseamnă bias 0,03.
- Consistența înseamnă apropierea de parametrul adevărat cînd numărul de observații crește
  - nu implică bias zero într-o selecție finită.

## Erori standard HAC și bandwidth

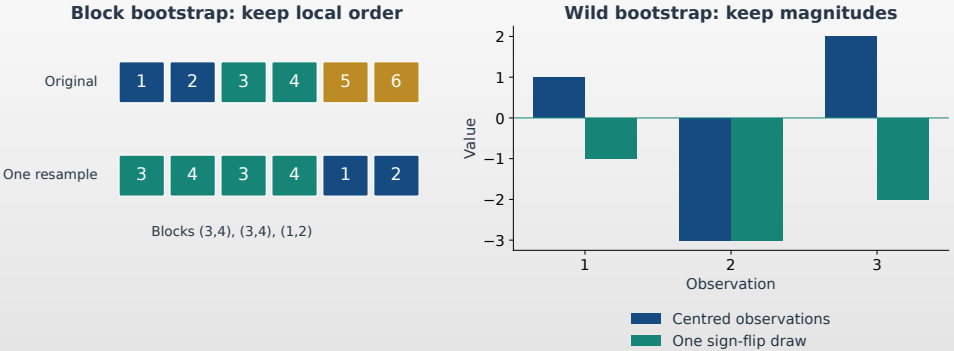
**OLS**: Ordinary Least Squares — metoda celor mai mici pătrate.

- De ce: în regresiile predictive și pe ferestrele rolling suprapuse, reziduurile sînt autocorelate și heteroscedastice, iar erorile standard OLS clasice sînt prea mici
- Erorile standard HAC estimează long-run variance: dispersia plus de două ori suma autocovariațelor
- Exemplu: dispersie 1, covariață la lagul 1 de 0,2 și celelalte zero dau long-run variance $1 + 2(0{,}2) = 1{,}4$
- Newey & West (1987) ponderează autocovariația de la lagul $j$ cu $1 - j/(\ell + 1)$, astfel încît estimația să nu fie negativă
- Bandwidth-ul $\ell$ este numărul de laguri incluse: cu $\ell = 5$, ponderile lagurilor 1–5 sînt $5/6, 4/6, \ldots, 1/6$
- HAC schimbă doar erorile standard, nu coeficienții OLS

## Bootstrap: construirea selecțiilor repetate

- De ce: nici deplasarea Stambaugh, nici null band-ul DFA nu au o distribuție exactă cunoscută; bootstrap o aproximează
- Bootstrap generează multe selecții artificiale sub ipoteza nulă și recalculează statistica în fiecare
- Bootstrap-ul i.i.d. extrage observații cu înlocuire: din $(1, 2, 3)$ o selecție poate fi $(2, 2, 1)$; el distruge orice dependență, inclusiv volatility clustering
- Block bootstrap Künsch (1989) extrage blocuri consecutive, de exemplu $(1, 2)$ și $(3, 4)$, și păstrează dependența din interiorul blocului
- Wild bootstrap înmulțește fiecare randament centrat cu un semn aleator: $(1, -3, 2)$ poate deveni $(-1, -3, -2)$
  - păstrează volatilitatea fiecărei zile, dar distruge corelația serială: reproduce o ipoteză nulă de tip RW3 cu semne simetrice (folosită la DFA)

# Ce păstrează fiecare bootstrap




Blocurile păstrează ordinea locală; schimbările de semn păstrează modulele. Cele două proceduri impun ipoteze diferite selecțiilor artificiale.

## Regresii predictive și deplasarea Stambaugh (1/2)

- Revenim la regresia din secțiunea 3: de ce poate *dp* să pară un predictor bun chiar dacă $\beta = 0$?
- Modelul: $r_{t+1} = \alpha + \beta x_t + u_{t+1}, \quad x_{t+1} = \theta + \rho x_t + v_{t+1}$, cu $\mathrm{Cov}(u, v) = \sigma_{uv}$
  - $r$: randamentul în exces
  - $x$: logaritmul raportului dividend–preț, $dp_t = \ln D_t - \ln P_t$, persistent ($\rho \approx 1$)
  - $D_t$: dividendele plătite în ultimul an
  - $\beta$: panta predictivă, 0 dacă randamentele sînt imprevizibile
  - $\alpha$, $\theta$: termeni liberi
  - $\rho$: persistența lui $x$, adică coeficientul AR(1) al lui *dp*; nu este autocorelația $\rho_k$ a randamentelor și nici $\rho$ din identitatea Campbell–Shiller
  - $u$, $v$: șocurile celor două ecuații
  - $\sigma_{uv}$: covariația lor
  - $\sigma_v^2 = \mathrm{Var}(v)$
  - $T$: numărul de perioade

# Regresii predictive și deplasarea Stambaugh (2/2)

- $x_t$ este predeterminat, nu strict exogen: estimatorul OLS este consistent, dar are deplasare în selecții finite Stambaugh (1999)
  - Proiectăm $u$ pe $v$: $u = (\sigma_{uv}/\sigma_v^2)\, v + e$, deci $\hat{\beta} - \beta = (\sigma_{uv}/\sigma_v^2)(\hat{\rho} - \rho) + \text{zgomot}$
  - $e$: partea lui $u$ necorelată cu $v$
  - Ambele regresii folosesc aceleași luni și același $x_t$, deci erorile de estimare $\hat{\beta} - \beta$ și $\hat{\rho} - \rho$ sînt legate prin corelația șocurilor $u$ și $v$
  - Termenul de zgomot are media zero cînd $e$ este independent de întreaga traiectorie a lui $x$, de exemplu pentru $(u, v)$ i.i.d. cu distribuția Normală bivariată
  - $\hat{\rho}$ este deplasat în jos în selecții mici Kendall (1954), iar această deplasare se transmite estimatorului $\hat{\beta}$
  - Cu $\mathbb{E}[\hat{\rho} - \rho] \approx -(1 + 3\rho)/T$: $\quad \mathbb{E}[\hat{\beta} - \beta] \approx -\dfrac{\sigma_{uv}}{\sigma_v^2} \dfrac{1 + 3\rho}{T}$
- Prețul crește $\Rightarrow$ *dp* scade: $\sigma_{uv} < 0$, deci deplasarea este **în sus**: predictibilitatea pare mai puternică decît este
- Aproape de o rădăcină unitară, statistica $t$ nu mai are distribuția $N(0, 1)$: inferența validă se obține cu testul $Q$ de tip Bonferroni, construit pe un interval de încredere pentru $\rho$ Campbell & Yogo (2006)

## Bonferroni Q: incertitudinea persistenței

- Inferența Campbell–Yogo ține cont de incertitudinea persistenței predictorului, în loc să trateze estimația ei ca valoare cunoscută. Campbell & Yogo (2006)
- Combină o mulțime de încredere pentru persistență cu teste ale pantei predictive pe acea mulțime, împărțind probabilitatea de eroare între etape.
- Pentru S&P 500, $\hat{\rho} = 0{,}9988$ și $T(1 - \hat{\rho}) = 1{,}4$: un test de rădăcină unitară nu poate respinge $\rho = 1$, iar acolo statistica $t$ a lui $\hat{\beta}$ se abate cel mai mult de la $N(0, 1)$.
- Acest test Q privește regresiile predictive
  - nu este statistica Q Ljung–Box pentru autocorelații.

## Exemplu rezolvat: deplasarea Stambaugh pentru S&P 500

- Randamentul logaritmic lunar în exces, regresat pe $dp_t$ decalat, 1934–2026, $T = 1\,111$ de luni (construcția datelor: Anexa)
- OLS: $\hat{\beta} = 0{,}267$ (% pe lună pe unitate de $dp$), $t$ Newey–West $= 0{,}91$: nesemnificativ chiar înaintea oricărei corecții
- Date de intrare: $\hat{\rho} = 0{,}9988$, $\text{corr}(\hat{u}, \hat{v}) = -0{,}97$, $\hat{\phi} = \hat{\sigma}_{uv}/\hat{\sigma}_v^2 = -0{,}925$ (exprimate ca fracții, nu în procente)
- Calcul: deplasarea $= -100\,\hat{\phi}\,(1 + 3\hat{\rho})/T = 0{,}333$ (în %, ca $\hat{\beta}$)
  - panta corectată $= 0{,}267 - 0{,}333 = -0{,}066$: întreaga estimație se datorează deplasării
  - corecția este ea însăși estimată: pentru inferența formală se folosește Campbell & Yogo (2006) sau un bootstrap
  - Formula lui Kendall este de ordinul întîi în $1/T$ și cea mai puțin precisă cînd $T(1 - \hat{\rho})$ este mic, aici 1,4 folosind persistența nerotunjită: $-0{,}066$ indică semnul și ordinul de mărime, nu o pantă precisă
- Simulare cu aceleași $\rho$ și $\text{corr}(u, v)$, $\beta = 0$ și o selecție de 30 de ani ($T = 360$ de luni): testul $t$ cu nivel nominal de 5% respinge $\beta = 0$ în 26,5% din selecții, de peste cinci ori mai des decît ar trebui

## Comparația prognozelor: Diebold–Mariano și Clark–West

- Secțiunea 3 a definit $R^2_{OS}$ și a aplicat testul Clark–West pe S&P 500; aici arătăm de ce testul are această formă
- Majoritatea predictorilor publicați au $R^2_{OS} < 0$ Welch & Goyal (2008); actualizarea Goyal, Welch & Zafirov (2024) confirmă rezultatul
- Testul Diebold & Mariano (1995) compară media diferenței dintre erorile pătratice ale celor două prognoze
- Modelul cu *dp* conține media istorică (modele nested): sub $H_0$ el estimează un $\beta$ nul, iar zgomotul acestei estimări îi mărește eroarea pătratică medie de predicție (MSPE)
- De aceea, testul Diebold–Mariano respinge mai rar decît nivelul nominal
- Clark & West (2007) adaugă înapoi acest zgomot: $f_t = (r_t - \bar{r}_t)^2 - \left[(r_t - \hat{r}_t)^2 - (\bar{r}_t - \hat{r}_t)^2\right]$
  - $(\bar{r}_t - \hat{r}_t)^2$: partea din eroarea modelului datorată estimării lui $\beta$
  - testul $t$ asupra mediei lui $f_t$ este unilateral: doar un cîștig pozitiv este dovadă pentru predictor

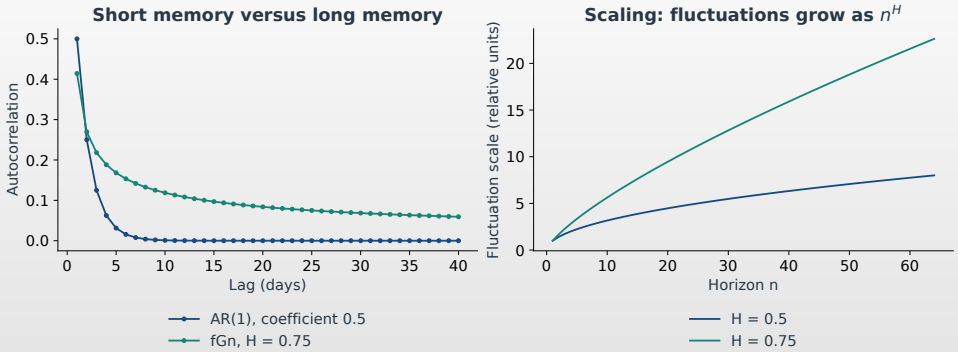
## Short memory, long memory și scaling

- Persistă dependența pe orizonturi și în regimuri de piață diferite?

**AR**: AutoRegressive model — model autoregresiv; AR(p) are ordinul p.

- Short memory are o sumă finită a modulelor autocovarianțelor
  - un AR(1) cu coeficientul 0,5 are corelații $0{,}5^k$ la lagul $k$.
- Long memory înseamnă aici dependență pozitivă care scade atît de lent încît suma autocovarianțelor diverge
  - descreșterea de tip power law poate produce acest lucru.
- Scaling: o măsură a fluctuațiilor pe $n$ zile, $F(n)$ (de exemplu abaterea standard a sumei a $n$ randamente), crește ca $n^H$; $H$ este exponentul Hurst, estimat pe slide-urile următoare
  - dublarea orizontului multiplică fluctuațiile cu $2^H$: circa 1,41 la $H = 0{,}5$ (fără memorie lungă) și 1,68 la $H = 0{,}75$
- Antipersistence descrie variații care tind să se compenseze, ca în fractional Gaussian noise (fGn) cu $H < 0{,}5$
  - fGn este un model de variații Gaussiene staționare cu dispersia sumelor proporțională cu $n^{2H}$.

# Dependență la laguri și orizonturi diferite

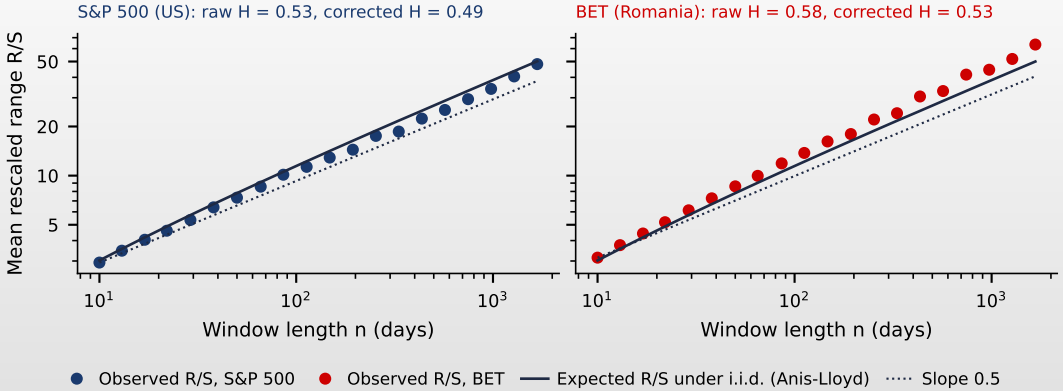



Corelațiile AR(1) scad geometric; în exemplul fGn scad lent. Dreapta compară creșterea fluctuațiilor odată cu orizontul.

## Statistica rescaled range (R/S)

- Hurst (1951) a constatat, cu ajutorul rescaled range-ului, că anii cu revărsări mari ale Nilului urmau altor ani cu revărsări mari mai des decît ar permite hazardul (detalii istorice: Anexa)
- Calculul pornește de la o fereastră de $n$ randamente cu media $\bar{r}_n$ și abaterea standard $s_n$
  - Abaterile cumulate $Y_k = \sum_{i=1}^{k}(r_i - \bar{r}_n)$, $k = 1, \ldots, n$
  - Amplitudinea $R_n = \max_k Y_k - \min_k Y_k$
  - Rescaled range-ul $R_n/s_n$
- Legea de scalare: $\mathbb{E}[R_n/s_n] \approx c\, n^H$, unde $H$ este **exponentul Hurst**
  - $c$: o constantă
  - prin logaritmare, $\ln(R/S) \approx \ln c + H \ln n$, deci $H$ este o pantă
  - Estimare: panta lui $\ln(R/S)$ pe $\ln n$, cu $R/S$ mediat pe ferestre disjuncte
- $H = 0{,}5$: fără memorie lungă (dependența pe termen scurt este permisă)
- $H > 0{,}5$: persistență; memorie lungă, cu $\rho_k \sim k^{2H-2}$
- $H < 0{,}5$: antipersistență

# Analiza R/S: S&P 500 și BET (1/2)




MFM_ch2_hurst

## Analiza R/S: S&P 500 și BET (2/2)

- În graficul anterior, punctele arată $R/S$ mediu pentru fiecare lungime $n$ a ferestrei.
- Linia continuă este media teoretică Anis & Lloyd (1976) pentru randamente i.i.d. din distribuția Normală (formula: Anexa).
- Corecția Anis–Lloyd elimină deplasarea pantei brute, care depășește 0,5 în selecții mici chiar pentru randamente i.i.d.: $H_{AL} = 0{,}5+$ panta regresiei lui $\ln(R/S) - \ln \mathbb{E}[R_n/s_n]$ pe $\ln n$.
- Pentru S&P 500, exponentul brut este 0,530, iar cel corectat 0,486: „persistența" aparentă venea din deplasarea în selecții mici.
- Pentru BET, exponentul brut este 0,578, iar cel corectat 0,533: persistența rămîne după corecție.
- Întrebare deschisă: $H > 0{,}5$ la BET indică memorie lungă sau doar reflectă autocorelația de ordinul 1, $\hat{\rho}_1 = 0{,}109$?
- Statistica R/S clasică nu poate deosebi cele două cazuri.

MFM_ch2_hurst

## Variance ratio-ul și exponentul Hurst: memorie lungă sau memorie scurtă?

- Pentru fGn, procesul exact autosimilar definit mai sus, dispersia sumei a $q$ randamente este $\mathrm{Var}(r_t + \cdots + r_{t-q+1}) = q^{2H}\mathrm{Var}(r_t)$.
- Rezultă $\mathrm{VR}(q) = q^{2H-1}$, deci din $\mathrm{VR}(q)$ observat deducem un exponent Hurst implicit, $H(q) = 0{,}5 + \ln \mathrm{VR}(q)/(2 \ln q)$.
- La orizontul $q = 20$ de zile, exponentul implicit este 0,553 pentru BET și 0,453 pentru S&P 500.
- Problema: un proces fără memorie lungă poate da $H(q) \neq 0{,}5$
  - Exemplu: un AR(1) cu $\rho_1 = -0{,}1$ are autocorelațiile $\rho_k = (-0{,}1)^k$, deci doar memorie scurtă.
  - Pentru acest AR(1), $\mathrm{VR}(20) = 0{,}826$, deci $H(20) = 0{,}468$: procesul pare „antipersistent", deși nu are memorie lungă.
  - La orizontul $q = 250$, același proces dă $H(250) = 0{,}482$: pentru memoria scurtă, $H(q)$ se apropie de 0,5 cînd $q$ crește.
- Un AR(1) cu autocorelația BET, $\hat{\rho}_1 = 0{,}109$, dă $H(20) = 0{,}535$.
- Deci cea mai mare parte din abaterea lui $H(20) = 0{,}553$ al BET față de 0,5 se explică prin memoria scurtă.
- Pentru a separa memoria lungă de cea scurtă avem nevoie de o statistică construită special: statistica R/S modificată a lui Lo (slide-ul următor).

## Testul R/S modificat al lui Lo

- Lo (1991): autocorelația pe termen scurt mărește artificial statistica R/S și imită memoria lungă
- Modificarea: $s_n$ este înlocuit cu o abatere standard pe termen lung (HAC) $\hat{\sigma}_\ell$, cu $\ell$ laguri
  - $\hat{\sigma}_\ell^2 = \hat{\gamma}_0 + 2\sum_{j=1}^{\ell}\left(1 - \frac{j}{\ell+1}\right)\hat{\gamma}_j$ , $\hat{\gamma}_j$: autocovarianța la lagul $j$ ($\hat{\gamma}_0$: dispersia), cu ponderi descrescătoare
  - $V = \dfrac{\max_k Y_k - \min_k Y_k}{\hat{\sigma}_\ell \sqrt{T}}$
  - $Y_k$: abaterile cumulate pe toată selecția de $T$ randamente
  - lățimea de bandă $\ell$ este aleasă ca în Andrews (1991)
- În ipoteza memoriei scurte, $V$ se află în [0,809; 1,862] cu probabilitatea 95%
- Pentru S&P 500 ($V = 1{,}559$), Bitcoin (1,547), PX (1,750) și EUR/RON (1,429), $V$ este în interval, deci memoria scurtă nu este respinsă
- Pentru BET ($V = 1{,}961$, cu $\ell = 7$ laguri) și Ethereum ($V = 1{,}980$), $V$ depășește puțin limita 1,862
- Aceasta este o dovadă slabă de memorie lungă

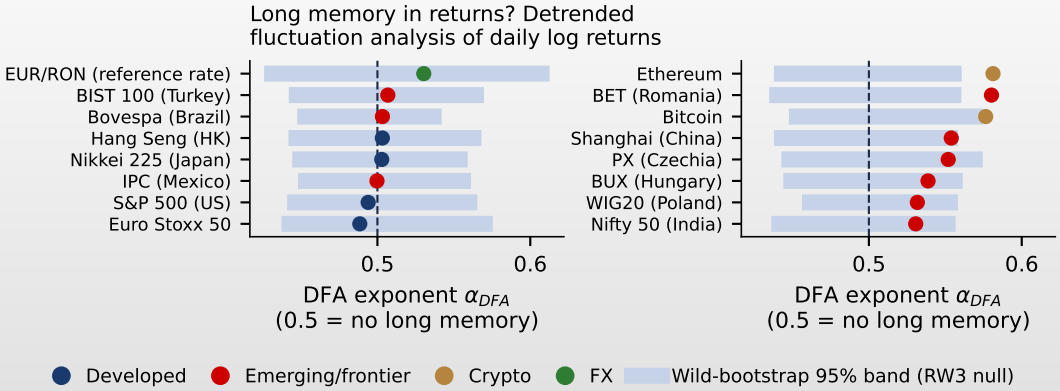
## Detrended fluctuation analysis (DFA) (1/2)

- Peng et al. (1994): DFA măsoară cum crește fluctuația randamentelor cumulate odată cu lungimea ferestrei.
- Eliminarea unei tendințe liniare din profil înlătură o medie constantă a randamentelor în fiecare segment.
- Dacă media randamentelor are ea însăși o tendință, este nevoie de DFA de ordin superior.
- Algoritmul
  - Profilul $y_k = \sum_{t \leq k}(r_t - \bar{r})$ este suma abaterilor randamentelor de la medie, pe întreaga selecție.
  - Profilul se împarte în segmente de lungime $n$.
  - În fiecare segment se estimează o tendință liniară și se păstrează reziduurile.
  - $F(n)$ este rădăcina mediei pătratelor tuturor reziduurilor; calculul se repetă pentru mai multe valori ale lui $n$.
- $F(n) \propto n^{\alpha_{DFA}}$: exponentul DFA $\alpha_{DFA}$ joacă rolul lui $H$ ($\alpha_{DFA} = 0{,}5$: fără memorie lungă).

## Detrended fluctuation analysis (DFA) (2/2)

- Null band-ul de 95% se obține prin **wild bootstrap**: fiecare reziduu $e_t = r_t - \bar{r}$ este înmulțit cu un semn aleator $\eta_t = \pm 1$, cu probabilitatea $1/2$ (199 de replicări).
- Schimbarea semnului păstrează volatilitatea $|e_t|$, permisă sub RW3, dar distruge corelația serială.
- O permutare aleatoare ar distruge și volatilitatea, și corelația.
- Ipoteza nulă implicită este mai strictă decît RW3: semne simetrice și independente, dată fiind volatilitatea.
- Null band-ul este deci un reper, nu un test exact al RW3 și nici un interval de încredere pentru $\alpha_{DFA}$.

# Exponentul DFA pe piețe (1/2)

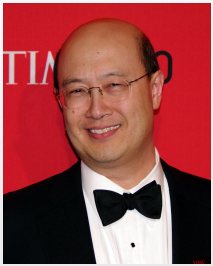



MFM_ch2_hurst

## Exponentul DFA pe piețe (2/2)

- Fiecare punct din graficul anterior este exponentul $\alpha_{DFA}$ al unei serii; bara este null band-ul de 95% obținut prin schimbări aleatoare de semn (volatilitatea se păstrează).
- S&P 500 (0,494), Euro Stoxx 50 (0,488) și Nikkei (0,503) sînt aproape de 0,5, în interiorul null band-ului.
- Trei din cele 16 serii depășesc null band-ul: Ethereum (0,581), BET (0,580, față de limita superioară 0,561) și, la limită, Bitcoin (0,576, față de 0,575).
- PX (0,552) și Shanghai (0,554) depășesc doar un null band obținut prin permutare, care distruge și volatility clustering: memoria lor aparentă vine din volatility clustering.
- Estimatorul local Whittle Robinson (1995) estimează $d = H - 0{,}5$ din frecvențele cele mai joase: pentru BET, $\hat{d} = 0{,}118$, cu intervalul de 95% [0,062; 0,174] (Anexa).
- Intervalul presupune inovații condiționat omoscedastice, condiție pe care volatility clustering o încalcă; el nu este deci o dovadă decisivă.
- Concluzie: dovezile de memorie lungă în randamente sînt slabe și depind de metodă; memoria în volatilitate (Capitolul 1) este puternică.

# Ipoteza piețelor adaptive (1/2)



Andrew W. Lo, MIT

Foto: David Shankbone (2012); CC BY 3.0; Wikimedia Commons

- Testele pe întreaga selecție dau dovezi slabe și instabile; o explicație posibilă: eficiența variază în timp
- Andrew Lo a propus ipoteza piețelor adaptive (AMH) în Lo (2004) și a dezvoltat-o în cartea Lo (2017)
- Piețele formează un ecosistem de specii aflate în competiție (traderi, fonduri, algoritmi), care se adaptează prin încercare și eroare, nu prin optimizare perfectă
  - eficiența este o chestiune de grad și depinde de numărul de competitori, de oportunitățile de profit și de mediu

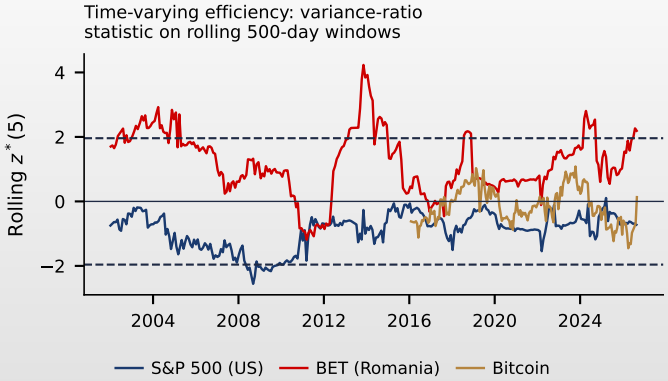
## Ipoteza piețelor adaptive (2/2)

- Anomaliile apar, slăbesc și pot reapărea
- Atenție: variația în timp a statisticilor nu permite, singură, identificarea AMH, pentru că și o EMH cu prime de risc variabile o poate genera (tabelul comparativ: Anexa)
- Lim & Brooks (2011), sinteză a literaturii: eficiența piețelor bursiere variază în timp, mai ales în jurul crizelor.
- Urquhart & McGroarty (2016): pe patru indici majori (Statele Unite, Marea Britanie, Japonia, zona euro), dependența serială apare și dispare între subperioade, în funcție de condițiile pieței.

## Măsurarea eficienței variabile în timp

- Calculăm o statistică pe o **fereastră rolling**: 500 de zile de tranzacționare (circa doi ani), deplasată cu 21 de zile (o lună)
  - Statistici: $z^*(5)$ al testului variance ratio-ului și exponentul DFA
- Null band-ul DFA se calculează ca înainte (schimbări aleatoare de semn), dar separat în fiecare fereastră, deci urmează volatilitatea ferestrei
- Pentru comparație, un null band fix simulat din randamente i.i.d. Student-$t$ cu 4 grade de libertate (cozi groase, fără volatility clustering) este [0,380; 0,615]
- Null band-ul fix ignoră volatility clustering, permis sub RW3; volatility clustering mărește $\alpha_{DFA}$, deci null band-ul fix semnalează prea multe ferestre
- Două precauții la interpretarea rezultatelor
  - Ferestrele suprapuse sînt puternic corelate: seriile de respingeri nu sînt dovezi independente
  - Chiar sub ipoteza nulă, circa 5% din ferestre resping: o proporție apropiată de 5% este o descriere, nu un test calibrat al stabilității

# Variance ratio-ul pe ferestre rolling: S&P 500, BET, Bitcoin

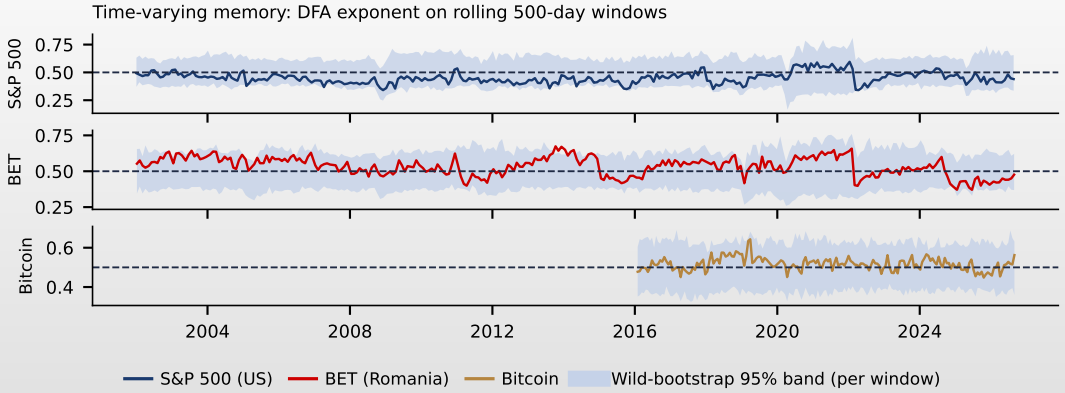


## Variance ratio-ul pe ferestre rolling: S&P 500, BET, Bitcoin — interpretare

- Graficul anterior arată $z^*(5)$ pe ferestre rolling de 500 de zile; fiecare punct este datat cu ultima zi a ferestrei, iar liniile întrerupte marchează $\pm 1{,}96$.
- Proporția ferestrelor cu $|z^*(5)| > 1{,}96$ este 6,4% pentru S&P 500, 22,4% pentru BET și 0% pentru Bitcoin.
- S&P 500: $z^*(5)$ este negativ în aproape toate ferestrele, dar trece de $-1{,}96$ doar în cele încheiate în 2008–2010, care cuprind criza financiară.
- Respingerea pe întreaga selecție vine din puterea mai mare a celor circa 6 700 de zile.
- BET: $z^*(5)$ depășește 1,96 în episoade (ferestre încheiate în 2002–2005, 2013–2014, 2018 și după 2023), separate de perioade apropiate de zero.
- Reclasificarea României de către FTSE Russell (21 sept. 2020, Anexa) nu apare ca o ruptură: $z^*(5)$ al BET era aproape de zero din 2016 și urcă din nou după 2023.

MFM_ch2_rolling_efficiency

# Exponentul DFA pe ferestre rolling: S&P 500, BET, Bitcoin (1/2)




MFM_ch2_rolling_efficiency

## Exponentul DFA pe ferestre rolling: S&P 500, BET, Bitcoin (2/2)

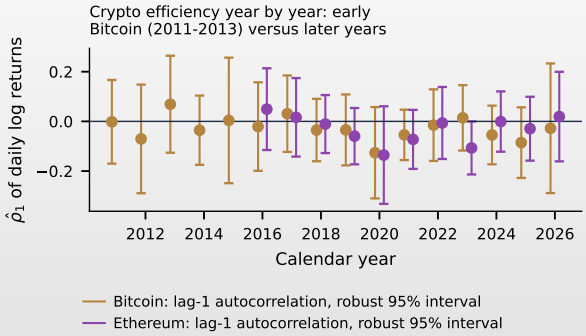
- În graficul anterior, zona hașurată este null band-ul wild bootstrap de 95%, calculat separat în fiecare fereastră de 500 de zile.
- Exponentul iese din propriul null band în 2,0% din ferestre pentru S&P 500, 3,1% pentru BET și 0% pentru Bitcoin.
- Cu un null band fix Student-$t_4$, care ignoră volatility clustering, proporțiile ar fi 6,4%, 11,2% și 1,1%: depășirile DFA suplimentare ale BET veneau din volatility clustering.
- Episoadele BET din graficul variance ratio rămîn: ele privesc autocorelația pe cîteva zile (memorie scurtă), pe care exponentul DFA nu o vizează.
- Testul are putere mică: pentru BET, null band-ul are în medie limitele [0,36; 0,64], deci 500 de observații nu fixează precis exponentul.
- Pe întreaga selecție, Bitcoin depășește null band-ul doar la limită (0,576 față de 0,575); pe ferestre de 500 de zile, efectul este prea mic pentru a fi detectat.

MFM_ch2_rolling_efficiency

## Testarea AMH

- Kim, Shamsuddin & Lim (2011) arată, pe un secol de date din Statele Unite ale Americii, că predictibilitatea variază cu condițiile pieței (crize, bule), fără o tendință descrescătoare, și fac AMH testabilă legînd-o de variabile de stare.
- Versiunea noastră: regresăm $z^*(5)$ din fiecare fereastră rolling pe volatilitatea anualizată a ferestrei (în %) și pe o variabilă indicator de criză
  - Variabila de criză este 1 dacă fereastra acoperă sept. 2008–iun. 2009 sau febr.–iun. 2020.
  - Folosim erori Newey–West cu 24 de laguri, pentru că ferestrele consecutive au în comun 95% din zile.
  - Volatilitatea este variabila de control: comparăm ferestre cu volatilitate similară.
- S&P 500: coeficientul de criză este $-0{,}67$ ($t = -2{,}37$), iar coeficientul volatilității 0,006 ($t = 0{,}27$); $R^2 = 0{,}20$.
- BET: coeficientul de criză este $-0{,}82$ ($t = -2{,}77$), iar coeficientul volatilității $-0{,}008$ ($t = -0{,}36$); $R^2 = 0{,}15$.
- În ferestrele de criză, $z^*(5)$ este mai mic, adică mai aproape de inversare, chiar la volatilitate egală: o asociere condiționată, nu un efect cauzal.
- Dependența de starea pieței este compatibilă cu AMH, dar nu o identifică: o schimbare a lui $z^*(5)$ poate veni din $\widehat{\mathrm{VR}}(5) - 1$ sau din eroarea lui standard.

# Eficiența criptoactivelor an de an




- AMH prezice că o piață nouă devine mai eficientă în timp: $\hat{\rho}_1 \neq 0$ în primii ani, apoi aproape de zero
- Graficul: $\hat{\rho}_1$ al randamentelor zilnice din fiecare an calendaristic, cu intervalul robust de 95%
- Bitcoin 2011–2013: intervalele sînt largi și includ zero, deci datele nu arată ineficiența timpurie prezisă de AMH
- Doar una din cele 27 de autocorelații anuale este semnificativă la 5%: Ethereum în 2023, $\hat{\rho}_1 = -0{,}107$; din întîmplare ne-am aștepta la circa 1,35
- Urquhart (2016) respinge eficiența în primii ani, cu alte teste, altă sursă de prețuri și erori standard clasice (Anexa)
- Puterea: un an cu 365 de randamente dă o SE robustă de 0,05–0,13; efectele mici nu se pot detecta

MFM_ch2_crypto_efficiency

## Inferență în event studies

- Întrebarea: cît de sigure sînt statisticile $t$ din secțiunea Studii de eveniment cînd ipotezele lor nu țin?
- Acolo am presupus că $\hat{a}_i$ și $\hat{b}_i$ sînt cunoscuți exact, că firmele sînt independente și că dispersia randamentelor anormale nu crește în ziua evenimentului.
- Eroarea de estimare: $\hat{a}_i$ și $\hat{b}_i$ provin dintr-o fereastră finită, deci și randamentul normal prezis are eroare.
- Dependența cross-sectional: două bănci afectate de aceeași știre au randamente anormale care se mișcă împreună.
- Dispersia indusă de eveniment (event-induced variance): evenimentul însuși mărește dispersia, iar zilele calme anterioare o subestimează.

## Studii de eveniment: eroarea de predicție

- Dispersia erorii de predicție MacKinlay (1997): $\text{Var}(AR_\tau) = \sigma_\varepsilon^2\left[1 + \frac{1}{T_0} + \frac{(r_{m,\tau} - \hat{\mu}_m)^2}{(T_0 - 1)\hat{\sigma}_m^2}\right]$, $T_0$: numărul de zile din fereastra de estimare
  - $\sigma_\varepsilon^2$: dispersia reziduurilor modelului de piață; $r_{m,\tau}$: randamentul pieței în ziua $\tau$ a evenimentului.
  - $\hat{\mu}_m$, $\hat{\sigma}_m^2$: media și dispersia randamentului pieței în fereastra de estimare.
  - Paranteza crește cînd mișcarea pieței din ziua evenimentului este neobișnuită.
- Revenim la taxa bancară din decembrie 2018 (secțiunea Studii de eveniment): în ziua evenimentului, randamentul logaritmic al BET a fost $-11{,}9\%$.
- Paranteza este atunci 2,12, deci eroarea de predicție crește.
- Statistica $t$ pentru Banca Transilvania (TLV) scade în valoare absolută de la $-10{,}0$ la $-6{,}85$.
- Pentru BRD, randamentul anormal din ziua 0 este $-5{,}6\%$, cu $t = -4{,}03$.
- Boehmer, Musumeci & Poulsen (1991) standardizează fiecare $AR$ cu propria eroare de predicție și estimează dispersia din valorile standardizate ale firmelor în ziua evenimentului, nu din zilele calme: testul rămîne valid dacă evenimentul mărește dispersia.

## Studii de eveniment: corelația dintre firme

- Întrebarea: ce se întîmplă cu testul pentru $\overline{AR}_0$ cînd toate firmele au evenimentul în aceeași zi?
- Fie $N$ numărul de firme și $\bar{\varrho}$ corelația medie dintre randamentele lor anormale, estimată în fereastra de estimare; pentru TLV și BRD, $\bar{\varrho} = 0{,}153$.
- Testul care presupune independența ignoră covariațele; cu $\bar{\varrho} > 0$, dispersia reală a mediei este de $1 + (N-1)\bar{\varrho}$ ori mai mare.
- Pentru TLV și BRD, $t$ calculat presupunînd independența este $-7{,}55$; împărțit la $\sqrt{1+\bar{\varrho}} = 1{,}074$ devine $-7{,}03$.
- Este statistica $t$ a portofoliului egal ponderat, care ține cont automat de corelație.
- Dacă dispersia se estimează transversal, ca în Boehmer, Musumeci & Poulsen (1991), ea subestimează în plus dispersia reală cu factorul $1 - \bar{\varrho}$; de aceea Kolari & Pynnönen (2010) înmulțesc statistica cu $\sqrt{(1-\bar{\varrho})/(1+(N-1)\bar{\varrho})}$.
- Cu zece firme și aceeași corelație, testul bazat pe independență subestimează dispersia de $1 + 9\bar{\varrho} = 2{,}38$ ori, iar testul transversal de $(1+9\bar{\varrho})/(1-\bar{\varrho}) = 2{,}81$ ori.

## Anomalii și explicații comportamentale

- Pot erorile comportamentale explica anomaliile care rezistă?

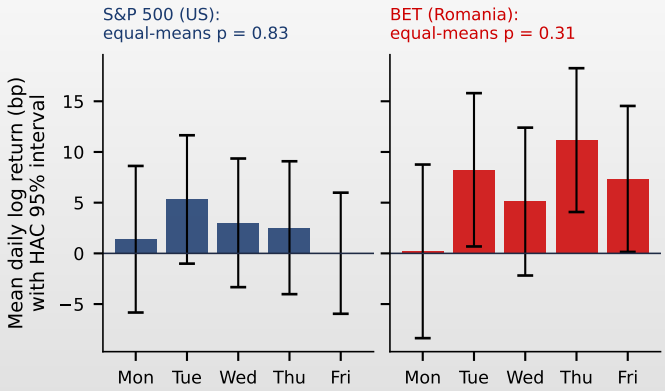
**Momentum**

- Cross-sectional momentum ordonează activele: dacă A a cîștigat 10%, iar B 2%, o strategie relativă poate cumpăra A și vinde B în lipsă.
- Time-series momentum folosește semnul trecutului fiecărui activ: în acel exemplu, atît A cît și B primesc semnal pozitiv.

## Anomalii și efecte de calendar

- Întrebarea: ce tipare rezistă după corecția pentru testare multiplă și ce le explică?
- O **anomalie** este un tipar al randamentelor pe care modelul de evaluare nu îl explică.
- Trei explicații posibile: un factor de risc omis, o evaluare greșită (eroare comportamentală) sau data snooping.
- Familii: de calendar (ziua de luni French (1980), ianuarie Rozeff & Kinney (1976), TOM Lakonishok & Smidt (1988), prima jumătate a lunii Ariel (1987); secțiunea 5), pe serii de timp (time-series momentum) și transversale (mărime, valoare, momentum: **Capitolul 3**).
- Randamentele anomaliilor publicate scad cu 26% după sfîrșitul perioadei studiate și cu 58% după publicare McLean & Pontiff (2016).
- Ziua săptămînii: $r_t = \sum_{d=1}^{5} \beta_d D_{d,t} + u_t$, cu $D_{d,t} = 1$ dacă ziua $t$ este ziua $d$ (luni, ..., vineri), altfel 0; $\beta_d$ este randamentul mediu din ziua $d$.
- Testul Wald pentru $\beta_1 = \cdots = \beta_5$ ($\chi^2_4$) folosește erori HAC Newey & West (1987) cu 5 laguri, pentru că $u_t$ este heteroscedastic și autocorelat.

# Efectul zilei săptămînii: S&P 500 și BET




- Randamentul logaritmic zilnic mediu, pe zile ale săptămînii, în puncte de bază (bp; 1 bp = 0,01%), 2000–2026, intervale HAC de 95%
- S&P 500: randamentul mediu variază de la 0,0 bp (vineri) la 5,3 bp (marți)
- p-value-ul testului de egalitate a mediilor = 0,83: după 2000 nu găsim un efect al zilei de luni, spre deosebire de French (1980)
- BET: joi 11,2 bp ($t = 3{,}09$), totuși testul comun dă $p = 0{,}31$
- Două ipoteze nule diferite:
  - media unei zile este zero (poate confunda efectul zilei cu randamentul mediu pozitiv)
  - toate cele cinci medii sînt egale (efectul zilei propriu-zis)

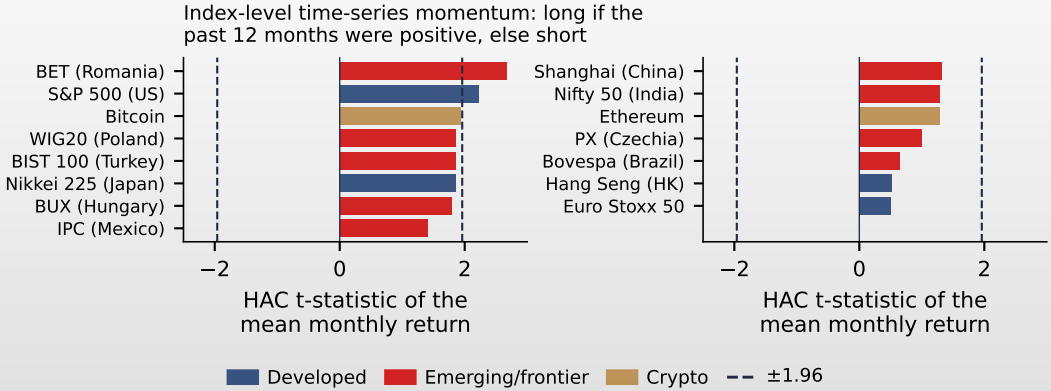
MFM_ch2_calendar_anomalies

## Time-series momentum pe indici (1/3)

**TSMOM**: Time-Series MOMentum — momentum pe serii de timp.

- TSMOM Moskowitz, Ooi & Pedersen (2012): semnalul $s_t = \text{sign}\left(\sum_{j=1}^{12} r_{t-j}\right)$
  - $+1$ (poziție lungă) dacă suma ultimelor 12 randamente logaritmice lunare este pozitivă, $-1$ (poziție scurtă) altfel
  - Randamentul strategiei este $s_t R_t$, $R_t$: randamentul indicelui în luna $t$
- În graficul următor, fiecare bară este statistica $t$ HAC (6 laguri) a randamentului lunar mediu al strategiei pe o piață.

# Time-series momentum pe indici (2/3)




MFM_ch2_tsmom

## Time-series momentum pe indici (3/3)

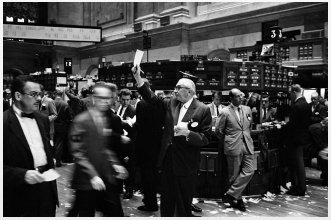
- Luată separat, strategia are un randament mediu semnificativ la 5% pentru BET (1,40% pe lună, $t = 2{,}68$) și pentru S&P 500 ($t = 2{,}22$).
- Pentru Bitcoin, $t = 1{,}94$, sub pragul de 1,96.
- Am testat însă 15 piețe: primul prag Holm este $0{,}05/15 = 0{,}0033$, iar cel mai mic p-value, al BET, este 0,007.
- După corecția pentru testare multiplă, nicio piață nu rămîne semnificativă.
- Raportul Sharpe al TSMOM este sub cel al strategiei buy-and-hold: 0,65 față de 0,75 pentru BET, 0,48 față de 0,52 pentru S&P 500.
- O parte din randamentul TSMOM poate fi equity premium (randamentul mediu al acțiunilor peste dobînda fără risc), cîștigat în lunile cu poziție lungă.
- Raportul Sharpe este anualizat ($\sqrt{12}\times$ media lunară împărțită la abaterea standard lunară), pe indici de preț fără dividende și fără dobînda fără risc (tabelul complet: Anexa).

MFM_ch2_tsmom

## Noțiuni comportamentale

- Prospect theory: cîștigurile și pierderile se evaluează față de un punct de referință, pierderile cîntăresc mai mult decît cîștigurile egale (loss aversion), iar probabilitățile mici sînt supraponderate.
- Disposition effect: tendința de a vinde pozițiile pe cîștig și de a le păstra pe cele pe pierdere.
- Anchoring: greutate excesivă acordată unui număr inițial, de exemplu prețul de cumpărare.
- Overconfidence: supraestimarea preciziei propriilor convingeri, care duce la prea multe tranzacții.
- Limited attention: informație relevantă lăsată neprelucrată.
- Herding: urmarea acțiunilor altora, fără o evaluare independentă.
- Underreaction și overreaction: ajustarea inițială prea mică, respectiv prea mare, a prețului la o știre; a doua este urmată de inversare.

# Psihologia în prețuri, de la ring la rețelele sociale



Ringul Bursei din New York, 1963

Foto: Thomas J. O'Halloran (1963); domeniu public; Wikimedia Commons

- **Volatilitate excesivă** Shiller (1981): prețurile variază mult mai mult decît dividendele care ar trebui să le justifice
- **Reacție excesivă**: De Bondt & Thaler (1985) explică prin ea inversarea randamentelor pe 3–5 ani (portrete: Anexa)
- **Prospect theory** Kahneman & Tversky (1979) explică disposition effect
- **Herding**: pe o piață nelichidă precum BVB, Pele, Mazurencu-Marinescu & Nijkamp (2013) leagă comportamentul de turmă de bule log-periodice (prețuri care cresc super-exponențial, cu oscilații tot mai rapide înaintea crahului); astăzi canalele sînt registrele de ordine, algoritmii și rețelele sociale (Capitolul 10)
- Erorile comportamentale nu anulează singure eficiența: arbitrajorii raționali ar putea exploata abaterile de preț. Pot face acest lucru?

# Limitele arbitrajului



Andrei Shleifer, Harvard

Foto: Manuel Castells (2018); CC BY-SA 2.0; Wikimedia Commons

- Shleifer & Vishny (1997): arbitrajul real este riscant și are nevoie de capital
- **Noise-trader risk** De Long, Shleifer, Summers & Waldmann (1990): abaterea prețului de la valoarea fundamentală se poate accentua înainte de a se corecta
  - Noise traders: investitori care tranzacționează pe baza unor semnale fără conținut informațional (sentiment, zvonuri)
- Constrîngeri de finanțare: administratorii pierd clienți după pierderi și trebuie să închidă pozițiile în cel mai rău moment
- Costuri: limite la vînzarea în lipsă, marje, costuri de tranzacționare, lipsa substituților perfecți
- Anomaliile pot persista unde arbitrajul este dificil: pe piețe mici și nelichide, precum bursa românească (BET), găsim cea mai puternică persistență dintre indicii bursieri
- AMH reconciliază cele două perspective: comportamentul rațional și cel afectat de erori coexistă și evoluează

## Machine learning și proiectarea cercetării

- Întrebarea: cînd testăm eficiența cu sute de predictori, ce înseamnă o respingere in-sample?
- Anomaliile se găsesc căutînd printre mulți predictori: Harvey, Liu & Zhu (2016) numără peste 300 de factori publicați.
- Secțiunea Testare multiplă și anomalii a arătat că 2 000 de reguli aleatoare produc „anomalii" in-sample.
- Aici: cum evaluăm corect un model flexibil și de ce o respingere in-sample poate apărea chiar și cu investitori raționali Martin & Nagel (2022).

## Învățarea automată și pieţele eficiente

**ML**: Machine Learning — învățare automată.

- Metodele ML construiesc reguli de predicție din date și surprind tipare neliniare pe care testele de autocorelație le ratează (Capitolul 13)
- Gu, Kelly & Xiu (2020): arborii și rețelele neuronale aduc cîștiguri economice mari față de regresiile liniare pe secțiunea transversală a acțiunilor din Statele Unite ale Americii, deși $R^2$ lunar al acestora out-of-sample este sub 1%
- Modelele lingvistice mari citesc știri și raportări: Tak & Pele (2025) prognozează tendințele acțiunilor cu LLaMA

## Validare, leakage și shrinkage

- Modelele flexibile, precum arborii și rețelele neuronale, pot potrivi și tipare accidentale in-sample (overfitting).
- Walk-forward validation: modelul se estimează doar pe date anterioare perioadei de test.
- Leakage: o prognoză folosește informație indisponibilă la data ei, de exemplu o cifră contabilă revizuită ulterior.
- Ridge: $\hat{g} = \arg\min_g \sum_t (r_t - x_t' g)^2 + \lambda \sum_j g_j^2 = (X'X + \lambda I)^{-1} X' r$; $\lambda > 0$ apropie coeficienții de zero (shrinkage) și reduce dispersia estimării.
- Cu erori $N(0, \sigma^2)$ și prior $g \sim N(0, \tau^2 I)$, ridge cu $\lambda = \sigma^2/\tau^2$ este media a posteriori a coeficienților (învățare bayesiană).
- Cross-validation: excludem pe rînd cîte un bloc de date (de exemplu un an), estimăm pe rest și alegem $\lambda$ cu cea mai mică eroare pe blocurile excluse.

## Studiu de caz: învățare rațională cu mulți predictori (1/2)

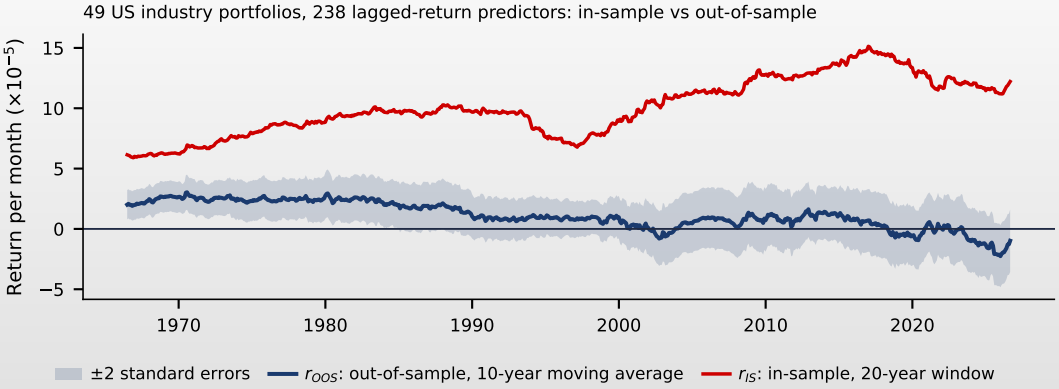
- Martin & Nagel (2022): investitorii evaluează $N$ active ale căror fluxuri de numerar depind de $J$ caracteristici, cu coeficienți **necunoscuți**, pe care îi învață optim (bayesian) din datele trecute (întrebarea de cercetare: Anexa)
  - Media a posteriori a coeficienților este estimatorul ridge de pe slide-ul anterior
  - Investitorii sînt neutri la risc, deci predictibilitatea nu poate fi explicată printr-o primă de risc
- **In-sample**: dacă numărul de predictori pe activ, $J/N$, tinde la o constantă $\psi > 0$, testul de absență a predictibilității respinge ipoteza nulă cu probabilitate care tinde la 1 (Martin & Nagel (2022), Prop. 4)
- Mecanismul: prețul încorporează coeficienții micșorați prin shrinkage, deci reacționează prea puțin la $X$; ex post, $X$ prezice randamentele chiar dacă investitorii sînt raționali.

## Studiu de caz: învățare rațională cu mulți predictori (2/2)

**OOS**: Out-of-Sample.

- In-sample, respingerea nu dovedește iraționalitatea: ipoteza nulă a așteptărilor raționale este reperul greșit cînd investitorii trebuie să învețe parametrii (rezultatele formale: Anexa; model și plan empiric: Anexa).
- $r_{OOS}$: randamentul unui portofoliu construit din prognoze, într-o perioadă nefolosită la estimarea coeficienților.
- Out-of-sample, un portofoliu construit cu coeficienți estimați în alte perioade are randament mediu zero: $\mathbb{E}[r_{OOS}] = 0$ (Martin & Nagel (2022), Prop. 6).
- Deci testele out-of-sample își păstrează sensul economic: în acest model, ele permit testarea eficienței.
- Pentru acțiunile americane, $R^2$ in-sample este de circa 1%.
- Randamentul out-of-sample, $r_{OOS}$, este mult mai mic decît cel in-sample și, după 2014, la mai puțin de două erori standard de zero (Fig. 8 din Martin & Nagel (2022)).

# Replicare pe datele cursului: in-sample și out-of-sample (1/2)



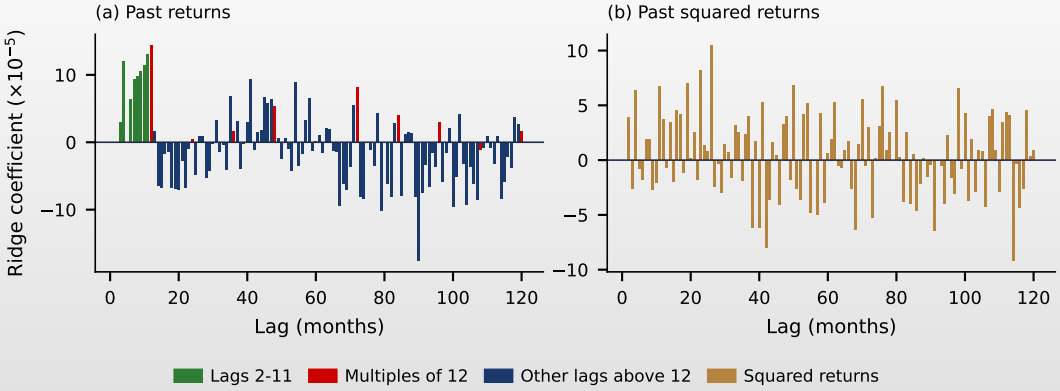

MFM_ch2_big_data

## Replicare pe datele cursului: in-sample și out-of-sample (2/2)

- Date: 40–49 de portofolii sectoriale (49 în ultimii ani; Kenneth French Data Library), iulie 1926 – august 2026; 238 de predictori (randamente decalate și pătratele lor, lagurile 2–120), OLS pe ferestre rolling de 20 de ani, ca în secț. 7 din Martin & Nagel (2022).
- Portofoliul: în fiecare lună, fiecare sector primește o pondere proporțională cu randamentul prognozat de model.
- Axa verticală: randamentul lunar al portofoliului, în unități de $10^{-5}$; o serie arată $r_{IS}$ (coeficienți din aceeași fereastră), cealaltă media rolling pe 10 ani a lui $r_{OOS}$ (coeficienți din fereastra anterioară), cu o bandă descriptivă de $\pm 2$ erori standard.
- $r_{IS}$ este între 5,90 și 15,14, pozitiv prin construcție, cu $R^2$ mediu in-sample de 5,4%.
- $r_{OOS}$ are pe 842 de luni (din iulie 1956) media $1{,}05 \times 10^{-5}$, circa 11% din $r_{IS}$.
- În primii 30 de ani out-of-sample (pînă în iunie 1986), media lui $r_{OOS}$ este la 4,16 erori standard peste zero; după, la doar 0,62.
- Cu $J/N \approx 5$, ajustarea in-sample este exagerată: $R^2$ de 5,4%, față de circa 1% în Martin & Nagel (2022) (Anexa).

MFM_ch2_big_data

# Replicare pe datele cursului: coeficienții ridge pe laguri (1/2)




MFM_ch2_big_data

## Replicare pe datele cursului: coeficienții ridge pe laguri (2/2)

- Ridge pe întreaga selecție, ianuarie 1971 – august 2026; penalizarea $\lambda$ este aleasă prin cross-validation, cu cîte un an exclus (56 de ani).
- Graficul anterior: coeficientul ridge al fiecărui predictor standardizat, pe lagul în luni; comparați cu Fig. 7 din Martin & Nagel (2022).
- Pentru lagurile 2–11, 8 din 10 coeficienți sînt pozitivi, ceea ce corespunde efectului **momentum** Jegadeesh & Titman (1993).
- Pentru lagurile multipli de 12, 9 din 10 coeficienți sînt pozitivi, ceea ce corespunde **sezonalității** Heston & Sadka (2008).
- Pentru celelalte laguri peste 12, 67% dintre coeficienți sînt negativi, ceea ce corespunde **inversării** pe termen lung De Bondt & Thaler (1985); coeficienții randamentelor la pătrat nu au un semn dominant.
- $R^2$ pe anii excluși, $1 - \sum(r - \hat{r})^2 / \sum r^2$: ridge 0,013%, OLS −2,26%.
- Ridge reproduce tiparele anomaliilor cunoscute, dar ele aproape nu prezic nimic în anii excluși (limite și extinderi: ▸ Anexa).

MFM_ch2_big_data

## O întrebare deschisă: devine o piață mai eficientă cînd intră arbitrajorii?

- Întrebarea: crește eficiența informațională a lui Bitcoin cînd instrumente reglementate, precum ETF-urile spot, aduc arbitrajori noi?
- Tran & Leirvik (2020) găsesc că eficiența criptoactivelor variază în timp și crește.
- Kia, Liu, Li, Song & Xu (2026) găsesc că, după ETF-urile spot, piața spot a redevenit locul dominant al descoperirii prețului.
- Nu știm dacă schimbarea vine din ETF-uri sau din maturizarea pieței: aceasta este întrebarea pe care o testăm în această secțiune.

## ETF-uri, placebo și price discovery

**ETF**: Exchange-Traded Fund — fond tranzacționat la bursă.

- Un spot ETF deține activul suport (aici Bitcoin), nu contracte futures ca ETF-urile pe Bitcoin lansate în 2021: arbitrajul dintre fond și piața spot devine direct.
- Un placebo repetă analiza la o dată fără eveniment: o schimbare aparentă similară în 2019 slăbește afirmația că lansarea din 2024 a produs schimbarea.
- Price discovery este încorporarea informației în prețuri: dacă piața A reacționează prima la știre și B o urmează, A poate contribui mai mult la price discovery.

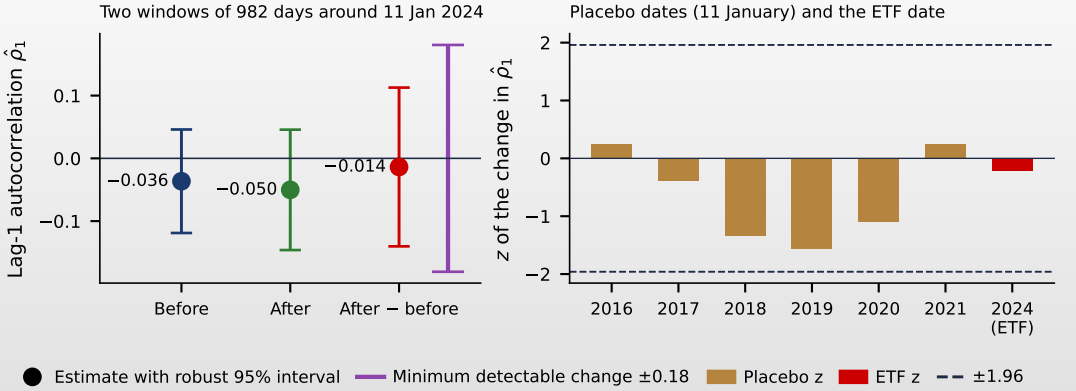
# Ministudiu de caz: au făcut ETF-urile spot Bitcoin mai eficient?

- Un asistent de inteligență artificială (AI) propune o ipoteză tipică: „ETF-urile spot pe Bitcoin din Statele Unite ale Americii (tranzacționate din 11 ianuarie 2024) au adus arbitrajori, deci Bitcoin a devenit mai eficient"
- Bucla de descoperire (prompturi: Anexa)
  - **literatură**: Kia, Liu, Li, Song & Xu (2026) arată că după ETF-urile spot piața spot a redevenit locul dominant al descoperirii prețului
  - Tran & Leirvik (2020): eficiența criptoactivelor variază și a crescut
  - **ipoteză**: $H_0 : \rho_{1,\text{post}} = \rho_{1,\text{pre}}$, două ferestre de aceeași lungime în jurul datei lansării (prima zi de tranzacționare)
  - **date și cod**: prețul zilnic de închidere al lui Bitcoin (în USD), din care se replică întîi $\hat{\rho}_1 = -0{,}022$ din capitol, pe întreaga selecție
- Verificări stabilite înainte de a vedea rezultatele (motivarea: Anexa)
  - erori standard robuste (nu $1/\sqrt{T}$), ferestre egale, doar data lansării plus date placebo
  - un activ de control pentru factorii de confuzie (halving-ul din aprilie 2024, dobînzile, intrările de capital)
  - o corecție pentru testare multiplă (Holm sau Chow–Denning) pentru toate statisticile încercate și efectul minim detectabil (MDE)

## Estimare și putere (1/3)

- Testul: două ferestre de cîte 982 de zile, înainte și după 11 ianuarie 2024, care nu se suprapun.
- $z = \Delta\hat{\rho}_1 / \sqrt{s^2_{\text{pre}} + s^2_{\text{post}}}$, cu $\Delta\hat{\rho}_1 = \hat{\rho}_{1,\text{post}} - \hat{\rho}_{1,\text{pre}}$ și erorile standard robuste $s$ ale celor două estimații.
- **Efectul minim detectabil (MDE)**: cea mai mică schimbare reală care poate fi detectată cu o putere de 80% la nivelul de 5%.
- $\text{MDE} = (z_{0,975} + z_{0,80}) \times \text{SE}(\Delta\hat{\rho}_1) \approx 2{,}8 \times \text{SE}(\Delta\hat{\rho}_1)$
  - $z_p$: cuantila de ordin $p$ a distribuției Normale standard; $z_{0,975} = 1{,}96$ și $z_{0,80} = 0{,}84$
- Date placebo: 11 ianuarie din fiecare an 2016–2021, cu ferestre de cîte 982 de randamente.

# Ministudiu de caz: estimare, placebo și MDE




MFM_ch2_ai_discovery

## Estimare și putere (2/3)

- Graficul anterior, stînga: $\hat{\rho}_1$ înainte și după lansare, cu intervale robuste de 95%; al treilea punct este diferența, cu bara $\pm$MDE.
- Dreapta: statistica $z$ pentru data ETF, printre valorile celor șase date placebo.
- Înainte (mai 2021 – ian. 2024): $\hat{\rho}_1 = -0{,}036$ ($s = 0{,}042$), VR(5) $= 1{,}000$ ($z^* = 0{,}00$).
- După (ian. 2024 – sept. 2026): $\hat{\rho}_1 = -0{,}050$ ($s = 0{,}049$), VR(5) $= 0{,}939$ ($z^* = -0{,}64$).
- $\Delta\hat{\rho}_1 = -0{,}014$, $z = -0{,}21$: testul nu respinge ipoteza că $\rho_1$ a rămas neschimbat.
- Niciuna dintre cele șase date placebo nu dă o schimbare semnificativă a lui $\rho_1$ la 5%; cea mai mare statistică este $|z| = 1{,}57$.

## Estimare și putere (3/3)

- Aici $\mathrm{SE}(\Delta\hat{\rho}_1) = \sqrt{0{,}042^2 + 0{,}049^2} \approx 0{,}065$, deci MDE $\approx 0{,}18$.
- „Nesemnificativ" nu înseamnă „fără efect": MDE (0,18) este de peste zece ori mai mare decît schimbarea estimată ($-0{,}014$).
- Înainte de 2024, $\hat{\rho}_1 = -0{,}036$: chiar și o trecere completă la $\rho_1 = 0$ ar fi o schimbare de cinci ori mai mică decît MDE (0,18), deci acest plan ar detecta-o cu o probabilitate mult sub 80%.
- O variabilă-rezultat mai bună: descoperirea prețului intrazilnic între piețe, nu $\rho_1$ zilnic.

MFM_ch2_ai_discovery

## Difference-in-differences: exemplu și condiții

- Testul înainte/după nu poate separa efectul ETF-urilor de alte schimbări din 2024.
- Pentru o concluzie cauzală avem nevoie de un grup de control, de exemplu Ethereum înaintea propriilor ETF-uri (din iulie 2024).
- Difference-in-differences (DiD) scade schimbarea înainte–după din grupul de control din schimbarea grupului tratat.
- Parallel trends: fără tratament, grupul tratat și grupul de control ar fi avut aceeași schimbare.
- Tendințe similare înainte de tratament susțin această ipoteză, dar nu o pot dovedi.
- No anticipation: grupul tratat nu reacționează înainte de tratament.
- No spillover: tratamentul nu afectează grupul de control; de exemplu, un ETF pe Bitcoin nu trebuie să schimbe tranzacționarea Ethereum.

## Temă de proiect propusă

- **Întrebare**: au schimbat ETF-urile spot eficiența variabilă în timp a lui Bitcoin, în comparație cu un activ de control?
  - VR și DFA pe ferestre rolling (acest capitol) pentru Bitcoin și Ethereum
  - Ethereum nu este „tratat" pînă în iulie 2024
  - dacă tendințele paralele, absența anticipării și a efectelor de spillover nu sînt plauzibile, raportați diferențe descriptive, nu cauzale
- **Replicați întîi**: autocorelațiile anuale ale lui Bitcoin din capitol și cifrele din ministudiul de caz
- Notați ce serie de prețuri Bitcoin și ce primă dată folosește fiecare fereastră, inclusiv ferestrele placebo
- **Preînregistrați**: $H_0$, $H_1$, date, ferestre și corecții, înregistrate printr-un commit înainte de obținerea rezultatelor
- **Raportați**: inferență robustă, teste placebo și MDE
- Publicați codul sub formă de Quantlet
- **Jurnale**: notați în `AI_USE.md` prompturile folosite
- Notați în `AI_ERRORS.md` fiecare eroare a asistentului AI depistată (de exemplu o eroare standard i.i.d. sau o referință inventată)

# Sinteză, autoverificare și următorul pas: Capitolul 3

## Cinci pași pentru orice afirmație despre eficiență

- **Mulțimea de informații**: ce informație $\mathcal{I}_t$ presupunem că este reflectată în prețuri (prețuri trecute, știri publice)?
- **Ipoteza nulă**: RW1, RW3 sau diferența de martingal, formulată împreună cu modelul de risc
- **Statistica**: folosim o estimare a dispersiei validă în prezența volatility clustering
- **Incertitudinea**: orizonturile, piețele și ferestrele încercate, plus dovezi out-of-sample
- **Economia**: o respingere statistică nu înseamnă profit exploatabil după costuri, iar profitul nu dovedește că piața este irațională

## Autoverificare și următorul pas

- De ce poate fi respinsă RW3 pentru S&P 500, deși piața rămîne eficientă în sens economic?
- De ce $H(20) > 0{,}5$ pentru BET nu dovedește memoria lungă?
- Care dintre cele două rezultate, persistența BET sau nerespingerea pentru Bitcoin, ar rămîne valabil dacă schimbăm testul, fereastra și metoda de inferență?
- Următorul pas, Capitolul 3: randamente ajustate la risc cu modele factoriale și factor zoo
- Manuale: Campbell, Lo & MacKinlay (1997), cap. 2; Franke, Härdle & Hafner (2019); cursuri avansate: ▸ Anexa

# Anexă: pionierii, Bachelier și Samuelson



Louis Bachelier (1870–1946)

Foto: autor necunoscut; domeniu public; Wikimedia Commons



Paul A. Samuelson (1915–2009)

Foto: Bernard Gotfryd (1970–1975); domeniu public; Wikimedia Commons

- Bachelier (1900): prețurile obligațiunilor de stat franceze urmează un mers aleator
  - „Media matematică a cîștigului speculatorului este zero”
- Samuelson (1965): dacă prețurile sînt **anticipate corect**, variațiile lor sînt imprevizibile
- Ambele rezultate stau la originea ipotezei pieței eficiente

înapoi

# Anexă: Eugene Fama



Eugene F. Fama, Premiul Nobel 2013

Foto: Bengt Nyman (2013); CC BY 2.0; Wikimedia Commons

- Fama (1970) a formulat definiția folosită în acest capitol și cele trei forme ale eficienței
- Premiul Nobel 2013, împărțit cu Robert Shiller (sceptic în privința eficienței) și Lars Peter Hansen
- Actualizare și sinteză: Fama (1991)
- O apărare accesibilă a EMH față de critici: Malkiel (2003)

înapoi

# Anexă: tabel de sinteză, teste de eficiență slabă 2000–2026

| **Piața** | $T$ | $\hat{\rho}_1$ | SE robustă | $\widehat{\mathrm{VR}}(5)$ | $z^*(5)$ | CD $p$ | Secvențe $z$ |
|---|---|---|---|---|---|---|---|
| S&P 500 | 6 714 | −0,099 | 0,027 | 0,830 | −2,77 | 0,001 | 4,34 |
| Euro Stoxx 50 | 6 836 | −0,029 | 0,019 | 0,910 | −2,08 | 0,097 | 3,41 |
| Nikkei 225 (Japonia) | 6 545 | −0,038 | 0,024 | 0,923 | −1,48 | 0,317 | 1,97 |
| Hang Seng (HK) | 6 583 | −0,004 | 0,024 | 0,967 | −0,64 | 0,872 | −0,17 |
| BET (România) | 6 670 | 0,109 | 0,028 | 1,173 | 2,98 | 0,001 | −6,05 |
| WIG20 (Polonia) | 6 685 | 0,018 | 0,018 | 1,009 | 0,24 | 0,777 | 2,25 |
| BUX (Ungaria) | 6 666 | 0,037 | 0,024 | 1,013 | 0,26 | 0,427 | −0,42 |
| PX (Cehia) | 6 682 | 0,052 | 0,032 | 1,041 | 0,59 | 0,350 | −2,53 |
| BIST 100 (Turcia) | 6 692 | 0,005 | 0,024 | 1,033 | 0,64 | 0,949 | −0,63 |
| Bovespa (Brazilia) | 6 622 | −0,028 | 0,025 | 0,928 | −1,29 | 0,521 | 0,88 |
| IPC (Mexic) | 6 689 | 0,070 | 0,019 | 1,039 | 0,93 | 0,001 | −3,27 |
| Nifty 50 (India) | 6 606 | 0,048 | 0,024 | 1,048 | 0,91 | 0,178 | −5,46 |
| Shanghai (China) | 6 474 | 0,021 | 0,019 | 1,046 | 1,11 | 0,409 | 1,02 |
| Bitcoin | 4 384 | −0,022 | 0,026 | 0,991 | −0,19 | 0,835 | 2,68 |
| Ethereum | 3 913 | −0,012 | 0,027 | 1,067 | 1,17 | 0,027 | 3,91 |
| EUR/RON (curs de referință) | 5 352 | 0,170 | 0,036 | 1,157 | 2,19 | 0,000 | −1,66 |

- $T$: numărul de randamente zilnice
- CD: Chow–Denning pe $q = 2, 5, 10, 20$
- EUR/RON din iulie 2005, criptoactivele pe 365 de zile pe an

înapoi

## Anexă: testul secvențelor pe toate piețele, alte teste VR

- $z$ al testului secvențelor (tabelul de pe slide-ul anterior): Nifty 50 $-5{,}46$, IPC $-3{,}27$ (persistență pe piețele emergente)
- Pentru Ethereum, $z$ al testului secvențelor este 3,91 (semnificativ), deși $\hat{\rho}_1$ nu este
- Choi (1999): un test VR automat care alege orizontul din date (estimare spectrală la frecvența zero)
- Versiuni wild bootstrap pentru selecții mici: Kim (2006)
- Aplicații pe piețele asiatice: Kim & Shamsuddin (2008)

înapoi

# Anexă: testul portmanteau automat al MDH

- Ce derivăm: un test portmanteau valid sub MDH cu heteroscedasticitate condiționată, cu numărul de laguri ales din date Escanciano & Lobato (2009).
- $AQ = T \sum_{j \le \tilde{p}} \tilde{\rho}_j^2$, cu $\tilde{\rho}_j = \hat{\gamma}_j / \sqrt{\hat{\kappa}_j}$, $\hat{\gamma}_j = \frac{1}{T-j} \sum_t e_t e_{t-j}$ și $\hat{\kappa}_j = \frac{1}{T-j} \sum_t e_t^2 e_{t-j}^2$
  - $e_t = r_t - \bar{r}$; $\hat{\gamma}_j$: autocovarianța la lagul $j$; $\hat{\kappa}_j$: dispersia ei robustă
  - $\tilde{p} \le 10$ maximizează $T \sum_{j \le p} \tilde{\rho}_j^2$ minus o penalizare: BIC ($p \ln T$), dar AIC ($2p$) cînd $\max_j \sqrt{T} |\tilde{\rho}_j|$ depășește $\sqrt{2{,}4 \ln T}$
- Sub MDH, $\tilde{p} \to 1$ cu probabilitatea 1, de aceea distribuția limită este $\chi_1^2$; o valoare mare a lui $AQ$ respinge MDH.
- $AQ$: S&P 500 13,14 ($p = 0{,}0003$), BET 14,92 ($p = 0{,}0001$), Bitcoin 0,75 ($p = 0{,}385$); MDH este respinsă la 5% pentru 5 din cele 16 serii.

Înapoi

# Anexă: regresia predictivă, date și rezultate complete

**FRED**: Federal Reserve Economic Data — baza de date economice a Rezervei Federale (St. Louis).

- Randamentul logaritmic lunar în exces (cu dividende, minus dobînda T-bill la 3 luni), regresat pe $dp_t$ decalat
  - Date: Shiller (2026) (S&P Composite, pînă în iunie 2026), prelungite cu mediile lunare ale închiderilor zilnice S&P 500 (scalate pe ultimele 12 luni comune) și cu dividendele fondului SPDR S&P 500 ETF (SPY)
  - Randamentul titlurilor de stat americane la 3 luni (FRED, seria TB3MS; % anual), rata logaritmică lunară $\ln(1 + \text{TB3MS}/1\,200)$ decalată cu o lună
- OLS: $\hat{\beta} = 0{,}267$, SE Newey–West 0,293 (12 laguri), $t = 0{,}91$, $t$ OLS $= 1{,}16$, $R^2 = 0{,}12\%$
- Raportul dintre panta corectată Stambaugh și eroarea standard HAC necorectată este $-0{,}22$; valoarea este doar ilustrativă, pentru că ignoră incertitudinea corecției
- Valoarea economică Campbell & Thompson (2008) (valoarea numerică: slide-ul Raportul dividend–preț: rezultatele pentru S&P 500): creșterea proporțională a randamentului așteptat al investitorului care își ajustează expunerea
  - $\dfrac{R^2}{1 - R^2} \cdot \dfrac{1 + S^2}{S^2}$ , $S$ raportul Sharpe lunar
- Testul Diebold & Mariano (1995) dă $t = -0{,}57$, dar favorizează modelul mic cînd modelele sînt incluse unul în altul; Clark & West (2007) corectează aceasta și dă $t = 0{,}42$

înapoi

## Anexă: viteza de ajustare a prețurilor

**CME**: Chicago Mercantile Exchange — Bursa de mărfuri din Chicago.

- La frecvență înaltă, prețurile futures reacționează în microsecunde sau mai puțin la știrile macroeconomice programate
- Tak, Schlamp, Osterrieder & Pele (2026) măsoară această cursă la Eurex și CME
- Evenimente din piața criptoactivelor: Pele, Lin, Wang & Gaman (2025) studiază reacțiile pieței la etapele de dezvoltare Ethereum
- Viteza de ajustare este ea însăși o măsură a eficienței și depinde de tehnologie (Capitolul 10, microstructura pieței)

înapoi

# Anexă: Harold Hurst și Nilul



Harold Edwin Hurst (1880–1978)

Foto: Elliott & Fry (1953); domeniu public; Wikimedia Commons



Nilometrul de pe insula Elefantina, Aswan

Foto: Olaf Tausch (2011); CC BY 3.0; Wikimedia Commons

- Hurst (1951) a proiectat lacuri de acumulare pe Nil
- Hurst a constatat că amplitudinea debitelor cumulate ale Nilului crește mai repede decît $\sqrt{n}$: anii cu revărsări mari urmează altor ani cu revărsări mari; de aici statistica **rescaled range** (R/S)

înapoi

## Anexă: media Anis–Lloyd

- Anis & Lloyd (1976): $\mathbb{E}[R_n/s_n]$ exact pentru randamente i.i.d. din distribuția Normală
  - $\mathbb{E}[R_n/s_n] = \dfrac{\Gamma((n-1)/2)}{\sqrt{\pi}\,\Gamma(n/2)} \sum_{i=1}^{n-1} \sqrt{\dfrac{n-i}{i}}$
  - $\Gamma(x) = \int_0^\infty t^{x-1} e^{-t}\, dt$: funcția gamma, care extinde factorialul: $\Gamma(n) = (n-1)!$ pentru $n$ întreg, $\Gamma(1/2) = \sqrt{\pi}$
- Acest $\mathbb{E}[R_n/s_n]$ este referința care se scade în $H_{AL}$ (slide-ul Analiza R/S)
- Estimările necorectate supraestimează memoria cu circa 0,04–0,05 pe date zilnice

înapoi

## Anexă: frecvență, periodogramă și local Whittle

- Densitatea spectrală repartizează dispersia pe frecvențe
  - Periodograma este analogul ei brut din selecție, construit din pătratele amplitudinilor Fourier.
- Componentele Fourier sînt unde sinus și cosinus; combinarea amplitudinilor lor reprezintă oscilații la frecvențe diferite.
- Local Whittle estimează parametrul de memorie lungă $d$ din panta spectrului la frecvențe joase
  - $d = H - 0{,}5$; de exemplu, $d = 0{,}1$ corespunde lui $H = 0{,}6$.
  - Robinson (1995): bandwidth-ul $m$ este numărul de frecvențe joase folosite, nu un număr de laguri.

# Anexă: memorie lungă cu inferență, estimatorul Whittle local (1/2)

- $d = H - 0{,}5$, iar densitatea spectrală $f(\lambda) \sim G\lambda^{-2d}$ cînd $\lambda \to 0$ ($G > 0$ o constantă; $d > 0$: densitatea explodează la frecvențe joase, memorie lungă)
- Estimarea folosește doar primele $m$ frecvențe Fourier $\lambda_j = 2\pi j/T$
  - $\hat{d} = \arg\min_d \left[ \ln\left( \frac{1}{m} \sum_{j=1}^{m} \lambda_j^{2d} I(\lambda_j) \right) - \frac{2d}{m} \sum_{j=1}^{m} \ln \lambda_j \right]$ , $I$: periodograma
  - Robinson (1995): pentru $|d| < 1/2$, $m \to \infty$, $m/T \to 0$, $f$ netedă în vecinătatea lui 0 și un proces liniar cu inovații de tip diferență de martingal, condiționat omoscedastice, $\sqrt{m}(\hat{d} - d) \to N(0, 1/4)$ fără a presupune distribuția Normală: un interval de încredere pentru parametru, în locul unei benzi sub ipoteza nulă

Înapoi

# Anexă: memorie lungă cu inferență, estimatorul Whittle local (2/2)

- Estimații cu $m = T^{0,65}$ și intervalul de încredere de 95% $\hat{d} \pm 1{,}96/(2\sqrt{m})$
  - S&P 500: $\hat{d} = -0{,}013$, interval $[-0{,}069; 0{,}043]$
  - Bitcoin: $\hat{d} = 0{,}063$, interval $[-0{,}002; 0{,}127]$
  - BET: $\hat{d} = 0{,}118$, interval $[0{,}062; 0{,}174]$
  - Ethereum: $\hat{d} = 0{,}112$, interval $[0{,}045; 0{,}179]$
- Compromisul lățimii de bandă: un $m$ mare include frecvențe la care autocorelația pe termen scurt (BET $\hat{\rho}_1 = 0{,}109$) deplasează $\hat{d}$ în sus
  - cu $m = T^{0,5}$, pentru BET se obține $\hat{d} = 0{,}135$ (SE 0,056): o verificare de sensibilitate care susține, fără a demonstra, că valoarea $d > 0$ nu reflectă doar memoria scurtă
  - randamentele cu dinamică GARCH pot încălca și condițiile de mai sus

Înapoi

# Anexă: EMH și AMH: comparație

| | EMH | AMH |
|---|---|---|
| Investitorii | Raționali, optimizează | Raționalitate limitată, euristici |
| Eficiența | O proprietate de echilibru, testată ca restricție | O chestiune de grad, care se schimbă odată cu condițiile |
| Risc–randament | Prime de risc de echilibru, posibil variabile în timp | Se schimbă odată cu populația de investitori |
| Anomaliile | Factori de risc omiși sau data mining | Oportunități de profit temporare |
| Instrument empiric | Teste ale unei restricții de echilibru | Teste ale variației în timp și în funcție de starea pieței (ferestre rolling) |

Înapoi

# Anexă: eficiența lui Bitcoin în literatură

- Urquhart (2016): Bitcoin a fost ineficient în perioada 2010–2016; unele teste indică eficiență în subperioada a doua
  - Setul său de teste (Ljung–Box, secvențe, testul rangurilor Bartels (1982), VR automat, BDS, R/S) include BDS, care poate respinge ipoteza nulă chiar și numai din cauza volatility clustering: nu este un test al RW3
- Nadarajah & Chu (2017): cu o transformare de putere a randamentelor, Bitcoin este eficient în formă slabă
- Kristoufek (2018): piețele Bitcoin au fost în mare parte ineficiente în 2010–2017, iar eficiența lor s-a schimbat în timp
- Tran & Leirvik (2020): eficiența multor criptoactive variază în timp și crește
- Pele et al. (2023): criptoactivele au devenit o clasă de active distinctă; randamentele lor prezintă aceleași fapte stilizate ca alte piețe
- Estimările noastre, separat pentru fiecare an calendaristic (slide-ul Eficiența criptoactivelor an de an)
  - Bitcoin, autocorelația de ordinul 1 $\hat{\rho}_1$: $-0{,}002$ în 2011, $-0{,}071$ în 2012, 0,069 în 2013, toate apropiate de zero
  - Statistica robustă a variance ratio-ului $z^*(5)$: cel mult 1,71 în valoare absolută, în toți anii și pentru toate criptoactivele, sub valoarea critică 1,96
  - În 2011–2013, eroarea standard robustă a lui $\hat{\rho}_1$ este de 0,09–0,11: nerespingerea anuală are putere mică și nu contrazice singură Urquhart (2016)

Înapoi

# Anexă: România, piață de frontieră, apoi emergentă

**BVB**: Bursa de Valori București.

- FTSE Russell (2019): România a fost reclasificată din piață de frontieră în piață emergentă secundară, decizie anunțată în septembrie 2019, cu efect de la 21 septembrie 2020
- Canale așteptate: mai mulți investitori străini, mai mulți analiști, mai multă lichiditate $\Rightarrow$ descoperirea mai rapidă a prețului
- Dovezi anterioare pentru BVB: crahuri și bule log-periodice Pele & Mazurencu-Marinescu (2012)
- Comportament de turmă pe o piață nelichidă Pele, Mazurencu-Marinescu & Nijkamp (2013)
- S-a îmbunătățit eficiența? Exercițiul C2 din seminar compară cei cinci ani dinainte și de după, folosind WIG20 și BUX ca grup de comparație și un bootstrap pe blocuri
  - Bootstrap pe blocuri: reeșantionează blocuri de zile consecutive pentru a păstra dependența Künsch (1989)
  - O comparație înainte/după este descriptivă dacă factorii de confuzie nu sînt controlați

Înapoi

# Anexă: Reality Check, SPA și StepM

**SPA**: Superior Predictive Ability (test) — testul abilității predictive superioare.

- Reality Check întreabă dacă cea mai bună dintre toate regulile încercate depășește reperul, folosind distribuția bootstrap a performanței maxime. White (2000)
- SPA standardizează performanța prin incertitudinea ei (studentisation) și reduce influența regulilor slabe. Hansen (2005)
- StepM testează întîi statistica cea mai puternică, apoi familia rămasă, cu praguri obținute prin reeșantionare comună
  - controlează FWER în condițiile sale. Romano & Wolf (2005)
- Exemplu: pentru toate cele 15 teste de calendar se extrag aceleași luni, astfel încît șocurile comune se păstrează
  - reeșantionarea separată ar distruge această dependență.

înapoi

# Anexă: StepM pe cele 15 teste de calendar

- Bonferroni și Holm ignoră corelația dintre teste (aceleași piețe, aceleași zile); Reality Check, SPA și StepM țin cont de ea (explicația: slide-ul anterior)
- Cele 15 teste de calendar: StepM cu bootstrap pe blocuri de 3 luni calendaristice, comune tuturor piețelor, 999 de replicări
  - Pragul critic pentru p-value la primul pas: 0,0016 (Bonferroni: 0,0033)
  - 2 respingeri (efectul TOM la BET și BUX), ca la Holm
  - StepM este mai strict decît Bonferroni deoarece, la nivelul nominal de 5%, ratele de respingere bootstrap ale testelor HAC sînt 6,0% (ziua săptămînii), 6,4% (TOM), 6,4% (ianuarie)
- Chordia, Goyal & Saretto (2020), pe peste două milioane de strategii generate aleator din date contabile reale: pragurile sînt $|t| > 3{,}8$ (serii de timp) și $|t| > 3{,}4$ (transversal); fără ele, circa 45% din respingeri sînt false
- Reducerea descoperirilor false mărește numărul celor ratate Harvey & Liu (2020)

înapoi

# Anexă: momentum pe serii de timp, toate pieţele

| **Piaţa** | Media (%/lună) | $t_{HAC}$ | Sharpe TSMOM | Sharpe buy-and-hold | $\hat{\rho}_1$ lunar |
|---|---|---|---|---|---|
| S&P 500 | 0,61 | 2,22 | 0,48 | 0,52 | 0,03 |
| Euro Stoxx 50 | 0,16 | 0,51 | 0,11 | 0,16 | 0,05 |
| Nikkei 225 (Japonia) | 0,61 | 1,85 | 0,39 | 0,42 | 0,09 |
| Hang Seng (HK) | 0,18 | 0,53 | 0,10 | 0,19 | 0,04 |
| BET (România) | 1,40 | 2,68 | 0,65 | 0,75 | 0,19 |
| WIG20 (Polonia) | 0,67 | 1,86 | 0,36 | 0,26 | 0,02 |
| BUX (Ungaria) | 0,72 | 1,79 | 0,40 | 0,64 | 0,10 |
| PX (Cehia) | 0,38 | 0,99 | 0,24 | 0,45 | 0,10 |
| BIST 100 (Turcia) | 1,03 | 1,85 | 0,37 | 0,75 | −0,08 |
| Bovespa (Brazilia) | 0,28 | 0,65 | 0,14 | 0,51 | 0,11 |
| IPC (Mexic) | 0,44 | 1,41 | 0,32 | 0,63 | 0,03 |
| Nifty 50 (India) | 0,50 | 1,29 | 0,28 | 0,64 | 0,02 |
| Shanghai (China) | 0,59 | 1,32 | 0,30 | 0,23 | 0,08 |
| Bitcoin | 4,47 | 1,94 | 0,72 | 1,08 | 0,13 |
| Ethereum | 6,50 | 1,28 | 0,57 | 0,90 | 0,16 |

- 307 de luni pentru indicii de acţiuni, mai puţine pentru criptoactive
- raportul Sharpe $\sqrt{12}\,\bar{x}/s_x$ ($\bar{x}$, $s_x$: media şi abaterea standard lunare ale strategiei), fără scăderea dobînzii fără risc
- Moskowitz, Ooi & Pedersen (2012): randamente în exces ale contractelor futures, scalate la 40% volatilitate ex ante

înapoi

# Anexă: Robert Shiller și Richard Thaler



Robert J. Shiller, Premiul Nobel 2013

Foto: Bengt Nyman (2013); CC BY 2.0; Wikimedia Commons



Richard H. Thaler, Premiul Nobel 2017

Foto: Bengt Nyman (2017); CC BY 2.0; Wikimedia Commons

- Volatilitatea excesivă Shiller (1981) și reacția excesivă De Bondt & Thaler (1985): slide-ul despre psihologia în prețuri

înapoi

# Anexă: studiul de caz, întrebarea de cercetare

- Martin & Nagel (2022): investitorii evaluează $N$ active ale căror fluxuri de numerar depind de $J$ caracteristici, cu coeficienți necunoscuți
- Întrebarea: ce înseamnă respingerea ipotezei de absență a predictibilității cînd $J$ este comparabil cu $N$?
  - coeficienții trebuie estimați din date istorice: o problemă de predicție cu multe variabile, ca în învățarea automată
- Eficiența semi-tare: prețurile „reflectă complet" informația publică Fama (1970)
- Două interpretări
  - investitorii cunosc parametrii modelului fluxurilor de numerar (așteptări raționale: ipoteza nulă a majorității testelor de eficiență)
  - investitorii își actualizează optim convingerile prin inferență bayesiană, folosind datele disponibile la momentul deciziei
- De ce contează: sute de predictori ai randamentelor găsiți in-sample, așa-numitul factor zoo Harvey, Liu & Zhu (2016)
- Textele, imaginile din satelit și rețelele sociale măresc continuu $J$
  - fiecare predictor semnificativ are oare nevoie de o explicație prin risc sau de una comportamentală?
- Legătura cu acest capitol: predictibilitatea out-of-sample Campbell & Thompson (2008) și declinul anomaliilor după publicare McLean & Pontiff (2016)

înapoi

# Anexă: studiul de caz, model și metodă (1/2)

- **Model** (Martin & Nagel (2022), sect. 2)
  - creșterea fluxurilor de numerar $\Delta y_t = Xg + e_t$, cu $e_t \sim N(0, I)$ și o rată a dobînzii egală cu zero
  - $\Delta y_t$: cele $N$ rate de creștere ale fluxurilor de numerar
  - $X$: matricea $N \times J$ a caracteristicilor
  - $g$: cei $J$ coeficienți necunoscuți
  - $I$: matricea identitate
- **Învățarea** (Prop. 1–2)
  - distribuția a priori $g \sim N(0, (\theta/J)\, I)$, care coincide cu distribuția reală din care este extras $g$
  - $\theta$: intensitatea semnalului
  - schematic, cu o perioadă: prețul este $X\hat{g}_t$, cu $\hat{g}_t = (tX'X + (J/\theta)I)^{-1}X' \sum_{s \le t} \Delta y_s$, deci $\mathbb{E}[\hat{g}_t \mid g] = Ag$, cu $A$ „mai mică" decît $I$
  - $r_{t+1} = X(I - A)g$ (underreaction din shrinkage) $-X(\hat{g}_t - Ag)$ (zgomot de estimare) $+e_{t+1}$ (șoc imprevizibil)
- **Analizã asimptoticã și simulări** (sect. 4)
  - $N, J \to \infty$ cu $J/N \to \psi > 0$
  - simulări cu $N = 1\,000$, elementele lui $X$ extrase din distribuția Normală standard și $\theta = 1$

Înapoi

# Anexă: studiul de caz, model și metodă (2/2)

- **CRSP**: Center for Research in Security Prices (Universitatea din Chicago).
- **NYSE**: New York Stock Exchange — Bursa din New York.
- **Teste**
  - in-sample: o regresie OLS transversală a lui $r_{t+1}$ pe $X$ (cere $J < N$), cu un test $\chi^2$ comun
  - out-of-sample: un portofoliu cu ponderile $\frac{1}{N} X h_{s+1}$, construite din coeficienți estimați în alte perioade
  - $r_{\text{OOS},t+1} = \frac{1}{N}\, h'_{s+1} X' r_{t+1}$, $s \neq t$ (ec. 19)
  - $r_{\text{IS}}$: la fel, cu $s = t$
  - $h_{s+1}$: vectorul coeficienților estimați
  - $r_{t+1}$: cele $N$ randamente
- **Planul empiric** (secț. 7)
  - acțiunile americane din CRSP, fără cele sub percentila 20 a capitalizării NYSE sau cu prețul sub 1 \$
  - predictori: randamentele lunare simple și pătratele lor, cu lagurile $t-2$ pînă la $t-120$ (238 de predictori), centrate și standardizate transversal în fiecare lună
  - regresie ridge pe întreaga selecție, 1971 – iunie 2019, cu penalizarea aleasă prin validare încrucișată cu cîte un an exclus
  - regresiile OLS pe ferestre rolling de 20 de ani dau $r_{\text{OOS}}$ începînd din ianuarie 1956

înapoi

# Anexă: studiul de caz, rezultatele formale

- In-sample (Prop. 4 din Martin & Nagel (2022), slide-ul principal): pentru $\psi > 0{,}4$ ($\theta = 1$, o perioadă de învățare) probabilitatea de a nu respinge ipoteza nulă este de ordinul $e^{-0{,}015N}$ (Fig. 2)
- Simulări ($N = 1\,000$, patru perioade de învățare): un test cu nivelul nominal de 5% respinge ipoteza nulă cu o probabilitate de peste 90% de îndată ce $J > N/2$ (Fig. 3b)
  - nu este o distorsiune a nivelului testului: componenta predictibilă in-sample chiar există în prețuri
- Teste cu cîte un singur predictor și control $k$-FWER (probabilitatea a cel puțin $k$ respingeri false este cel mult 5%): pentru $k = 20$ și $J/N = 0{,}05$, probabilitatea a cel puțin $k$ respingeri este 25%, nu 5%
- Probabilitatea ajunge la circa 80% pentru $J/N$ apropiat de 1 (Fig. 4)
  - corecțiile pentru testare multiplă nu rezolvă problema: problema este ipoteza nulă, nu testul
- Out-of-sample: $\mathbb{E}[r_{\mathrm{OOS},t+1}] = 0$ este valabil atît în ordine cronologică, cît și în ordine inversă (Prop. 6)
- Media este pozitivă doar dacă investitorii aplică un shrinkage mai puternic decît justifică datele (Fig. 6)
- Acțiunile americane: coeficienții ridge regăsesc efectul momentum, inversarea pe termen lung și sezonalitatea efectului momentum (Fig. 7)
- Randamentul in-sample al portofoliului, $r_{\mathrm{IS}}$, este de circa 0,006% pe lună (Fig. 8)

înapoi

# Anexă: studiul de caz, in-sample și out-of-sample în detaliu

- $r_{\text{IS}} \geq 0$ în fiecare fereastră de 20 de ani prin construcție: $r_{\text{IS}} = b' G^{-1} b/240$, cu $G = \sum_s X_s' X_s / N_s$ și $b = \sum_s X_s' r_s / N_s$ pe cele 240 de luni $s$ ale ferestrei
  - $X_s$: matricea $N_s \times 238$ a predictorilor din luna $s$
  - $r_s$: cele $N_s$ randamente ale portofoliilor
  - $G^{-1} b$: coeficienții OLS estimați pe datele cumulate (pooled)
  - $R^2$ mediu in-sample de 5,4%, față de circa 1% pentru acțiunile individuale în Martin & Nagel (2022): 238 de predictori față de doar 40–49 de portofolii pe lună, cumulate pe 240 de luni, exagerează ajustarea in-sample
- Out-of-sample (din iulie 1956), pînă în iunie 1986: media $r_{\text{OOS}} = 1{,}98 \times 10^{-5}$, la 4,16 erori standard peste 0
- După aceea, media este $0{,}36 \times 10^{-5}$, la doar 0,62 erori standard
  - media pe 10 ani depășește ultima dată două erori standard în fereastra încheiată în decembrie 1987
  - în ferestrele încheiate în 2014–2019, cel mai mare raport față de eroarea standard este 1,25, ca pentru acțiuni
- Interpretare sugerată de Martin & Nagel (2022): diferența este compatibilă cu învățarea investitorilor, dar nu o dovedește și nu exclude primele de risc
- Cîștigurile timpurii out-of-sample sînt compatibile și cu un shrinkage excesiv al coeficienților înainte de era calculatoarelor (Fig. 6)

Înapoi

# Anexă: studiul de caz, replicare, limite și extinderi

- **Aplicați metoda pe datele cursului** (datele CRSP pentru acțiuni individuale nu sînt incluse)
  - cele 49 de portofolii sectoriale de pe slide-urile de replicare, cu aceiași predictori, standardizare și ferestre
  - filtrele de capitalizare și de preț nu se aplică portofoliilor
- **Limite precizate de autori**
  - randamentele decalate sînt rezultate de echilibru, nu matricea exogenă $X$ din model: aplicația ilustrează diferența dintre predictibilitatea in-sample și cea out-of-sample, nu testează modelul
  - un test $t$ pe $r_{\text{OOS}}$ lunar nu este un test valid pentru $\mathbb{E}[r_{\text{OOS}}] = 0$, o medie calculată și peste distribuția a priori a lui $g$
  - rezultatul pentru ordinea temporală inversă poate depinde de ipoteza unor creșteri i.i.d. ale fluxurilor de numerar, iar modelul presupune investitori omogeni și caracteristici constante
- **Extinderi deschise**
  - seriile de timp: regresia pe raportul dividend–preț din secțiunea 3 are un singur predictor ($J = 1$), dar $R^2$ in-sample de 0,12% și $R^2_{OS} = -0{,}51\%$: ce explică diferența, dacă nu numărul de predictori?
  - modelele neliniare (arbori, rețele neuronale Gu, Kelly & Xiu (2020)) adaugă flexibilitate funcțională fără să schimbe neapărat $J$: crește diferența?
  - AMH: poate shrinkage-ul excesiv aplicat de investitori cu resurse de calcul limitate să explice predictibilitatea out-of-sample din perioada timpurie?

înapoi

# Anexă: bucla descoperirii, prompturi reutilizabile (1/2)

- **Literatură**
  - `Listează studii publicate în reviste cu evaluare de specialitate, începînd din 2020, despre cum schimbă lansarea unui ETF eficiența sau descoperirea prețului activului suport. Pentru fiecare: DOI, metoda (studiu de eveniment, difference-in-differences (DiD), ruptură structurală), măsura eficienței. Marchează orice intrare despre care nu ești sigur că există.`
  - Verificați fiecare DOI în Crossref
  - Titlul și autorii trebuie să coincidă cu cei ai lucrării citate
- **Ipoteză**
  - `Propune trei mecanisme prin care ETF-urile spot ar putea schimba dependența serială a lui Bitcoin (arbitraj, structura investitorilor, orele de tranzacționare). Pentru fiecare: semnul schimbării lui rho1 și VR(q) și o variabilă care îl deosebește de celelalte.`
- **Date și cod**
  - `Citește prețurile zilnice de închidere ale lui Bitcoin din datele cursului; calculează randamentele logaritmice, rho1 cu eroare standard robustă la heteroscedasticitate și VR(5) Lo-MacKinlay cu z*, în două ferestre de aceeași lungime în jurul datei de 11 ianuarie 2024.`

înapoi

# Anexă: bucla descoperirii, prompturi reutilizabile (2/2)

- **Robustețe**
  - `Scrie un plan de robustețe preînregistrat: lungimea ferestrelor, doar închiderile din zilele lucrătoare, VR(q) pentru q = 2 până la 20 cu Chow-Denning, date placebo și Ethereum ca activ de control până la propriile ETF-uri spot (iulie 2024).`
- **Critică**
  - `Joacă rolul unui recenzent ostil: dacă Bitcoin era deja eficient înainte de 2024, ce ar putea detecta vreodată acest test? Calculează schimbarea minimă detectabilă a lui rho1 și propune o variabilă-rezultat mai bună.`
- **Raport**
  - Estimațiile, erorile standard robuste, distribuția placebo, toate testele efectuate (cu corecție pentru testare multiplă)
  - Prompturile care au influențat o decizie intră în `AI_USE.md`

înapoi

# Anexă: verificările cercetătorului

- **Erori standard i.i.d.**: $1/\sqrt{T}$ duce la respingeri prea frecvente în prezența volatility clustering
  - test: SE robustă și $z^*$, ca în testele de eficiență slabă din acest capitol
- **Ferestre inegale**: putere diferită înainte și după
  - test: lungimi egale, fixate dinainte
- **Data evenimentului aleasă din date**
  - test: doar data lansării (prima zi de tranzacționare), plus o distribuție placebo la date fără eveniment
- **Factori de confuzie**: o comparație înainte/după nu are interpretare cauzală
  - test: un activ de control (Ethereum înainte de iulie 2024) într-o difference-in-differences
  - interpretarea cauzală este valabilă doar în condițiile de pe slide-ul Difference-in-differences
  - perioada comună de după (ian.–iul. 2024) este scurtă
- **Multe statistici**: $\rho_1$, VR(2–20), secvențe
  - test: Chow–Denning sau Holm, nu cel mai mic p-value luat izolat
- **Putere mică**: raportați MDE de pe slide-ul Estimare și putere

Înapoi

# Anexă: studiu suplimentar pe Quantinar

## Cursuri avansate pe quantinar.com

- Efficiency of cryptocurrency markets - A GMM-based analysis
- Generalized Method of Moments
- Market Responses to ETH Development Milestones

## Cod, date și manuale

- Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_02
- Manuale: Campbell, Lo & MacKinlay (1997), cap. 2; Franke, Härdle & Hafner (2019)

înapoi

# Acronime folosite în acest material (1/3)

- **AIC**: Akaike Information Criterion — *criteriul informațional Akaike*
- **AMH**: Adaptive Markets Hypothesis — *ipoteza piețelor adaptive*
- **AR(p)**: AutoRegressive model — *model autoregresiv de ordin p*
- **AR**: Abnormal Return — *randament anormal, în event studies*
- **BDS**: Brock–Dechert–Scheinkman (test) — *testul Brock–Dechert–Scheinkman de independență*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BIC**: Bayesian Information Criterion — *criteriul informațional bayesian*
- **BIST**: Borsa İstanbul (BIST 100 index) — *Bursa din Istanbul (indicele BIST 100)*
- **BNR**: Banca Națională a României
- **BUX**: Budapesti Értéktőzsde index — *indicele Bursei din Budapesta*
- **BVB**: Bursa de Valori București
- **CAPM**: Capital Asset Pricing Model — *modelul de evaluare a activelor financiare*
- **CAR**: Cumulative Abnormal Return — *randamentul anormal cumulat*
- **CD**: Chow–Denning (multiple variance-ratio test) — *testul multiplu Chow–Denning pentru raportul dispersiilor*
- **CME**: Chicago Mercantile Exchange — *Bursa de mărfuri din Chicago*
- **CRSP**: Center for Research in Security Prices — *Centrul de cercetare a prețurilor titlurilor (Universitatea din Chicago)*

# Acronime folosite în acest material (2/3)

- **DFA**: Detrended Fluctuation Analysis — *analiza fluctuațiilor fără tendință*
- **EMH**: Efficient Market Hypothesis — *ipoteza pieței eficiente*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- **fGn**: fractional Gaussian noise — *zgomot gaussian fracționar*
- **FRED**: Federal Reserve Economic Data — *baza de date economice a Rezervei Federale (St. Louis)*
- **FTSE**: Financial Times Stock Exchange (FTSE Russell, index provider) — *furnizorul de indici FTSE Russell*
- **FWER**: Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **FX**: Foreign eXchange — *piața valutară*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GMM**: Generalized Method of Moments — *metoda generalizată a momentelor*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HK**: Hong Kong — în grafice, seria indicelui Hang Seng.
- **IPC**: Índice de Precios y Cotizaciones — *indicele Bursei din Mexic*
- **MDE**: Minimum Detectable Effect — *efectul minim detectabil*
- **MDH**: Martingale Difference Hypothesis — *ipoteza diferenței de martingal*

# Acronime folosite în acest material (3/3)

- **MIT**: Massachusetts Institute of Technology — *Institutul de Tehnologie din Massachusetts*
- **ML**: Machine Learning — *învățare automată*
- **MSPE**: Mean Squared Prediction Error — *eroarea pătratică medie de predicție*
- **NYSE**: New York Stock Exchange — *Bursa din New York*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **PX**: Prague Stock Exchange index (index Burzy cenných papírů Praha) — *indicele Bursei din Praga*
- **RW1**: Random Walk 1 (i.i.d. increments) — *mersul aleator 1 (creșteri i.i.d.)*
- **RW2**: Random Walk 2 (independent increments) — *mersul aleator 2 (creșteri independente)*
- **RW3**: Random Walk 3 (uncorrelated increments) — *mersul aleator 3 (creșteri necorelate)*
- **SD**: Standard Deviation — *abatere standard*
- **SE**: Standard Error — *eroare standard*
- **SPA**: Superior Predictive Ability (test) — *testul abilității predictive superioare*
- **TOM**: Turn Of the Month — *schimbarea lunii (efectul schimbării lunii)*
- **TSMOM**: Time-Series MOMentum — *momentum pe serii de timp*
- **VR**: Variance Ratio — *raportul dispersiilor*
- **WIG20**: Warszawski Indeks Giełdowy 20 — *indicele celor mai mari 20 de companii de la Bursa din Varșovia*

# Bibliografie (1/7)


- Andrews, D.W.K. (1991). Heteroskedasticity and autocorrelation consistent covariance matrix estimation. *Econometrica*, 59(3), 817–858.
- Anis, A.A., Lloyd, E.H. (1976). The expected value of the adjusted rescaled Hurst range of independent normal summands. *Biometrika*, 63(1), 111–116.
- Ariel, R.A. (1987). A monthly effect in stock returns. *Journal of Financial Economics*, 18(1), 161–174.
- Bachelier, L. (1900). Théorie de la spéculation. *Annales scientifiques de l'École Normale Supérieure*, 17, 21–86.
- Bartels, R. (1982). The rank version of von Neumann's ratio test for randomness. *Journal of the American Statistical Association*, 77(377), 40–46.
- Blanchard, O.J., Watson, M.W. (1982). Bubbles, rational expectations and financial markets. In P. Wachtel (ed.), *Crises in the Economic and International Financial System*, Lexington Books, 295–315.
- Boehmer, E., Musumeci, J., Poulsen, A.B. (1991). Event-study methodology under conditions of event-induced variance. *Journal of Financial Economics*, 30(2), 253–272.
- Brock, W.A., Dechert, W.D., Scheinkman, J.A., LeBaron, B. (1996). A test for independence based on the correlation dimension. *Econometric Reviews*, 15(3), 197–235.
- Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). The Econometrics of Financial Markets. Princeton University Press.
- Campbell, J.Y., Shiller, R.J. (1988). The dividend-price ratio and expectations of future dividends and discount factors. *Review of Financial Studies*, 1(3), 195–228.
- Campbell, J.Y., Thompson, S.B. (2008). Predicting excess stock returns out of sample: can anything beat the historical average? *Review of Financial Studies*, 21(4), 1509–1531.
- Campbell, J.Y., Yogo, M. (2006). Efficient tests of stock return predictability. *Journal of Financial Economics*, 81(1), 27–60.
- Choi, I. (1999). Testing the random walk hypothesis for real exchange rates. *Journal of Applied Econometrics*, 14(3), 293–308.
- Chordia, T., Goyal, A., Saretto, A. (2020). Anomalies and false rejections. *Review of Financial Studies*, 33(5), 2134–2179.

# Bibliografie (2/7)


- Chow, K.V., Denning, K.C. (1993). A simple multiple variance ratio test. *Journal of Econometrics*, 58(3), 385–401.
- Clark, T.E., West, K.D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311.
- Cochrane, J.H. (2008). The dog that did not bark: a defense of return predictability. *Review of Financial Studies*, 21(4), 1533–1575.
- De Bondt, W.F.M., Thaler, R. (1985). Does the stock market overreact? *Journal of Finance*, 40(3), 793–805.
- De Long, J.B., Shleifer, A., Summers, L.H., Waldmann, R.J. (1990). Noise trader risk in financial markets. *Journal of Political Economy*, 98(4), 703–738.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Escanciano, J.C., Lobato, I.N. (2009). An automatic Portmanteau test for serial correlation. *Journal of Econometrics*, 151(2), 140–149.
- Escanciano, J.C., Velasco, C. (2006). Generalized spectral tests for the martingale difference hypothesis. *Journal of Econometrics*, 134(1), 151–185.
- Fama, E.F. (1970). Efficient capital markets: a review of theory and empirical work. *Journal of Finance*, 25(2), 383–417.
- Fama, E.F. (1991). Efficient capital markets: II. *Journal of Finance*, 46(5), 1575–1617.
- Fama, E.F., Fisher, L., Jensen, M.C., Roll, R. (1969). The adjustment of stock prices to new information. *International Economic Review*, 10(1), 1–21.
- Fama, E.F., French, K.R. (1988). Dividend yields and expected stock returns. *Journal of Financial Economics*, 22(1), 3–25.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, ed. a 5-a. Springer.
- French, K.R. (1980). Stock returns and the weekend effect. *Journal of Financial Economics*, 8(1), 55–69.
- French, K.R. (2026). Kenneth R. French Data Library. Tuck School of Business, Dartmouth College.

# Bibliografie (3/7)


- FTSE Russell (2019). FTSE Russell announces results of country classification review (comunicat de presă, 26 septembrie 2019).
- Goyal, A., Welch, I., Zafirov, A. (2024). A comprehensive 2022 look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 37(11), 3490–3557.
- Grossman, S.J., Stiglitz, J.E. (1980). On the impossibility of informationally efficient markets. *American Economic Review*, 70(3), 393–408.
- Gu, S., Kelly, B., Xiu, D. (2020). Empirical asset pricing via machine learning. *Review of Financial Studies*, 33(5), 2223–2273.
- Hansen, P.R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380.
- Harvey, C.R., Liu, Y. (2020). False (and missed) discoveries in financial economics. *Journal of Finance*, 75(5), 2503–2553.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). . . . and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Heston, S.L., Sadka, R. (2008). Seasonality in the cross-section of stock returns. *Journal of Financial Economics*, 87(2), 418–445.
- Hurst, H.E. (1951). Long-term storage capacity of reservoirs. *Transactions of the American Society of Civil Engineers*, 116(1), 770–799.
- Jegadeesh, N., Titman, S. (1993). Returns to buying winners and selling losers: implications for stock market efficiency. *Journal of Finance*, 48(1), 65–91.
- Kahneman, D., Tversky, A. (1979). Prospect theory: an analysis of decision under risk. *Econometrica*, 47(2), 263–291.
- Kendall, M.G. (1954). Note on bias in the estimation of autocorrelation. *Biometrika*, 41(3–4), 403–404.
- Kia, K., Liu, B., Li, Q., Song, V., Xu, K. (2026). Price discovery in Bitcoin ETF market. *Financial Review*, 61(2), 435–449.

# Bibliografie (4/7)


- Kim, J.H. (2006). Wild bootstrapping variance ratio tests. *Economics Letters*, 92(1), 38–43.
- Kim, J.H., Shamsuddin, A. (2008). Are Asian stock markets efficient? Evidence from new multiple variance ratio tests. *Journal of Empirical Finance*, 15(3), 518–532.
- Kim, J.H., Shamsuddin, A., Lim, K.-P. (2011). Stock return predictability and the adaptive markets hypothesis: evidence from century-long U.S. data. *Journal of Empirical Finance*, 18(5), 868–879.
- Kolari, J.W., Pynnönen, S. (2010). Event study testing with cross-sectional correlation of abnormal returns. *Review of Financial Studies*, 23(11), 3996–4025.
- Kristoufek, L. (2018). On Bitcoin markets (in)efficiency and its evolution. *Physica A*, 503, 257–262.
- Künsch, H.R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- Lakonishok, J., Smidt, S. (1988). Are seasonal anomalies real? A ninety-year perspective. *Review of Financial Studies*, 1(4), 403–425.
- Lim, K.-P., Brooks, R. (2011). The evolution of stock market efficiency over time: a survey of the empirical literature. *Journal of Economic Surveys*, 25(1), 69–108.
- Ljung, G.M., Box, G.E.P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- Lo, A.W. (1991). Long-term memory in stock market prices. *Econometrica*, 59(5), 1279–1313.
- Lo, A.W. (2004). The adaptive markets hypothesis. *Journal of Portfolio Management*, 30(5), 15–29.
- Lo, A.W. (2017). Adaptive Markets: Financial Evolution at the Speed of Thought. Princeton University Press.
- Lo, A.W., MacKinlay, A.C. (1988). Stock market prices do not follow random walks: evidence from a simple specification test. *Review of Financial Studies*, 1(1), 41–66.

# Bibliografie (5/7)


- Lobato, I., Nankervis, J.C., Savin, N.E. (2001). Testing for autocorrelation using a modified Box–Pierce Q test. *International Economic Review*, 42(1), 187–205.
- MacKinlay, A.C. (1997). Event studies in economics and finance. *Journal of Economic Literature*, 35(1), 13–39.
- Malkiel, B.G. (2003). The efficient market hypothesis and its critics. *Journal of Economic Perspectives*, 17(1), 59–82.
- Martin, I.W.R., Nagel, S. (2022). Market efficiency in the age of big data. *Journal of Financial Economics*, 145(1), 154–177.
- McLean, R.D., Pontiff, J. (2016). Does academic research destroy stock return predictability? *Journal of Finance*, 71(1), 5–32.
- Moskowitz, T.J., Ooi, Y.H., Pedersen, L.H. (2012). Time series momentum. *Journal of Financial Economics*, 104(2), 228–250.
- Nadarajah, S., Chu, J. (2017). On the inefficiency of Bitcoin. *Economics Letters*, 150, 6–9.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Pele, D.T., Lin, M.-B., Wang, R., Gaman, S. (2025). Market responses to ETH development milestones. IDA Institute Digital Assets, Bucharest University of Economic Studies.
- Pele, D.T., Mazurencu-Marinescu, M. (2012). Modelling stock market crashes: the case of Bucharest Stock Exchange. *Procedia – Social and Behavioral Sciences*, 58, 533–542.
- Pele, D.T., Mazurencu-Marinescu, M., Nijkamp, P. (2013). Herding behaviour, bubbles and log periodic power laws in illiquid stock markets: a case study on the Bucharest Stock Exchange. SSRN Working Paper.
- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets? *European Journal of Finance*, 29(10), 1064–1105.
- Peng, C.-K., Buldyrev, S.V., Havlin, S., Simons, M., Stanley, H.E., Goldberger, A.L. (1994). Mosaic organization of DNA nucleotides. *Physical Review E*, 49(2), 1685–1689.

# Bibliografie (6/7)


- Roberts, H.V. (1959). Stock-market "patterns" and financial analysis: methodological suggestions. *Journal of Finance*, 14(1), 1–10.
- Robinson, P.M. (1995). Gaussian semiparametric estimation of long range dependence. *Annals of Statistics*, 23(5), 1630–1661.
- Romano, J.P., Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282.
- Rozeff, M.S., Kinney, W.R. (1976). Capital market seasonality: the case of stock returns. *Journal of Financial Economics*, 3(4), 379–402.
- Samuelson, P.A. (1965). Proof that properly anticipated prices fluctuate randomly. *Industrial Management Review*, 6(2), 41–49; retipărit în 2015, World Scientific.
- Shiller, R.J. (1981). Do stock prices move too much to be justified by subsequent changes in dividends? *American Economic Review*, 71(3), 421–436.
- Shiller, R.J. (2026). U.S. stock markets 1871–present and CAPE ratio (date lunare, accesat în septembrie 2026).
- Shleifer, A., Vishny, R.W. (1997). The limits of arbitrage. *Journal of Finance*, 52(1), 35–55.
- Stambaugh, R.F. (1999). Predictive regressions. *Journal of Financial Economics*, 54(3), 375–421.
- Sullivan, R., Timmermann, A., White, H. (1999). Data-snooping, technical trading rule performance, and the bootstrap. *Journal of Finance*, 54(5), 1647–1691.
- Summers, L.H. (1986). Does the stock market rationally reflect fundamental values? *Journal of Finance*, 41(3), 591–601.
- Tak, R., Pele, D.T. (2025). LLM-driven stock prediction: capturing market trends with LLaMA. *Proceedings of the International Conference on Business Excellence*, 19(1), 529–540.
- Tak, R., Schlamp, S., Osterrieder, J., Pele, D.T. (2026). Racing the news: nanosecond market efficiency at Eurex and CME. SSRN Working Paper.

# Bibliografie (7/7)


- Tirole, J. (1985). Asset bubbles and overlapping generations. *Econometrica*, 53(6), 1499–1528.
- Tran, V.L., Leirvik, T. (2020). Efficiency in the markets of crypto-currencies. *Finance Research Letters*, 35, 101382.
- Urquhart, A. (2016). The inefficiency of Bitcoin. *Economics Letters*, 148, 80–82.
- Urquhart, A., McGroarty, F. (2016). Are stock markets really efficient? Evidence of the adaptive market hypothesis. *International Review of Financial Analysis*, 47, 39–49.
- Wald, A., Wolfowitz, J. (1940). On a test whether two samples are from the same population. *Annals of Mathematical Statistics*, 11(2), 147–162.
- Welch, I., Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 21(4), 1455–1508.
- White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126.