









Modelarea piețelor financiare

Capitolul 3: Modele factoriale și evaluarea activelor



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

De ce au activele randamente medii diferite?

Ce vom explica

- Ce explică randamentele așteptate? Modelul de evaluare a activelor financiare (CAPM, Capital Asset Pricing Model) și modelele multifactoriale
- Cum se estimează expunerile? Beta, incertitudinea lui și shrinkage (estimația este trasă spre o valoare-țintă, ca să scadă zgomotul)
- Cum se testează restricțiile de evaluare? Testul simultan al valorilor alfa, regresiile Fama–MacBeth, compararea modelelor
- Rezistă rezultatele? Testare multiplă, factori latenți, replicare

Ce trebuie să poți face

- să estimezi un beta cu erori robuste la heteroscedasticitate și autocorelație și să-i aplici shrinkage
- să testezi simultan valorile alfa ale CAPM și să estimezi prime de risc cu erori robuste
- să evaluezi un factor nou în raport cu pragurile testării multiple și cu dovezile de replicare

Parcursul capitolului

1. Ce explică randamentele așteptate?
2. De la Markowitz la CAPM
3. Estimarea lui beta, cu o verificare rapidă
4. Testarea CAPM, cu o verificare rapidă
5. Modele multifactoriale
6. Regresii Fama–MacBeth, cu o verificare rapidă
7. Factori de actualizare și compararea modelelor
8. Factor zoo și testarea multiplă, cu o verificare rapidă
9. Factori latenți: PCA și IPCA
10. Investiții factoriale
11. Studiu de caz: există o criză a replicării?
12. AI (inteligența artificială) pentru descoperire științifică
13. Concluzii

- **Prima lectură**: Secțiunile 1–6, 8 și 10, rezultatele Secțiunii 11 și concluziile; rezolvați fiecare verificare rapidă înainte de a-i deschide răspunsul din Anexă
- **Aprofundare**: slide-urile marcate *(aprofundare)* în titlu (metoda generalizată a momentelor, factori inutili, factori de actualizare, numărul de factori, PCA instrumentată, ierarhia bayesiană din studiul de caz) și Anexa, accesată prin butoanele de pe slide-uri
- **Exercițiu**: fiecare metodă are o problemă în Seminarul 3, numită și legată pe slide-ul care o folosește
- Secțiunea 12 pregătește proiectul de curs

Ce este un model factorial?

- Un **model factorial** explică randamentul activului i prin cîteva variabile comune $f_{1,t}, \ldots, f_{K,t}$, numite **factori**

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_{i,1} f_{1,t} + \cdots + \beta_{i,K} f_{K,t} + \varepsilon_{i,t}$$

- $R_{i,t}$: randamentul activului i în perioada t
- $R_{f,t}$: rata fără risc
- K: numărul de factori
- α_i: randamentul mediu neexplicat de factori, 0 dacă factorii evaluează corect activul
- $\beta_{i,k}$: **încărcarea factorială** (expunerea) activului i la factorul k
- $\varepsilon_{i,t}$: șoc specific activului (idiosincratic)

La ce folosește un model factorial?

- Două utilizări în acest capitol
  - Explicarea unui activ: ETF-ul (Exchange-Traded Fund, fond tranzacționat la bursă) de tehnologie XLK are o sensibilitate de 1,28 față de piața americană (Secțiunea 3)
  - Evaluarea unui fond: rămîne α_i pozitiv după ce ținem cont de expunerile lui (Secțiunile 4 și 10)?
- Alte utilizări: costul capitalului, construcția portofoliilor și managementul riscului (Campbell, Lo & MacKinlay (1997), capitolele 5–6)
- Avantajul în managementul riscului: N active au $N(N+1)/2$ variațe și covariațe, dar un model cu K factori are nevoie doar de încărcări, de covariația factorilor și de N variațe specifice
- Mesajul-cheie: randamentele așteptate ar trebui explicate prin **expuneri la riscuri remunerate**, nu prin numele activului

Datele: factori americani, ETF-uri și Bursa de Valori București

Serie	Conținut	Perioadă
Factori Fama–French	piață, mărime, valoare, profitabilitate, investiții	1963–2026
Momentum	câștigători minus perdanți	1963–2026
25 portofolii mărime × B/M	acțiuni SUA, 2 sortări	1963–2026
ETF-uri sectoriale	sectoare S&P 500: 9 din 1999, 11 din 2018	1999–2026
ETF-uri factoriale	momentum, valoare, mărime, calitate, volatilitate minimă	2013–2026
Blue chips BVB, BET	11 acțiuni și indicele lor	2015–2026

- Simbolurile ETF-urilor sectoriale: XLB materiale, XLE energie, XLF financiar, XLI industrie, XLK tehnologie, XLP bunuri de larg consum, XLU utilități, XLV sănătate, XLY consum discreționar
- Din 2018 și XLRE imobiliare, XLC servicii de comunicații

- Factori și portofolii: Kenneth French Data Library, randamente lunare în procente, până în iulie 2026 (momentum: până în august 2026)
- ETF-uri și acțiuni: prețuri zilnice de închidere ajustate (dividende reinvestite), până la 18 septembrie 2026
- **S&P 500**: indicele celor 500 de mari companii americane
- **BVB**: Bursa de Valori București; **BET**: indicele ei de referință, un indice de preț (fără dividende)
- **B/M**: valoarea contabilă a capitalului propriu împărțită la valoarea sa de piață
- **Randament în exces** $R^e_{i,t} = R_{i,t} - R_{f,t}$
- $R_{f,t}$: rata titlurilor de stat americane la o lună (RF în datele French)
- **Mkt-RF**: randamentul în exces al pieței americane de acțiuni, ponderat după capitalizare, din aceleași date

Randamente simple sau logaritmice?

- **Randamentul simplu** (variația procentuală a prețului): $R_{i,t} = P_{i,t}/P_{i,t-1} - 1$
  - $P_{i,t}$: prețul ajustat (dividende reinvestite) al activului i la sfîrșitul perioadei t
- **Randamentul logaritmic**: $r_{i,t} = \ln(P_{i,t}/P_{i,t-1}) = \ln(1 + R_{i,t})$
- Exemplu: prețul crește de la 100 la 110, deci $R = 10\%$, dar $r = \ln 1{,}1 = 9{,}53\%$
- Dacă prețul revine la 100: $R = -9{,}09\%$, iar $r = -9{,}53\%$, deci randamentele logaritmice ale celor două perioade au suma 0
- Randamentele logaritmice se adună în timp, cele simple se adună între active: $R_{p,t} = \sum_i w_i R_{i,t}$ (Capitolul 0)
- Factorii French sînt randamente de portofolii, deci regresiile pe acești factori folosesc randamente simple
- Beta pe ferestre mobile, beta la BVB și analiza componentelor principale (Secțiunea 9) folosesc randamente logaritmice zilnice
- Curățarea datelor BVB elimină zilele cu $|r_t| > 0{,}5$: o creștere de peste 64,9% ($e^{0,5} - 1$) sau o scădere de peste 39,3% ($1 - e^{-0,5}$) într-o singură zi
- La BVB, rata fără risc zilnică este tratată ca o constantă: o constantă nu modifică nicio covarianță, deci beta rămîne același

Frontiera medie–varianță

- Markowitz (1952): cu ponderile w, randamentele în exces așteptate $\boldsymbol{\mu}$ și matricea de covarianță $\boldsymbol{\Sigma}$, portofoliile de pe frontieră se obțin rezolvînd

$$\min_{\mathrm{w}} \ \mathrm{w}^\top \boldsymbol{\Sigma}\, \mathrm{w} \quad \text{cu condițiile} \quad \mathrm{w}^\top \boldsymbol{\mu} = \mu^*,\ \mathrm{w}^\top 1 = 1$$

  - în cuvinte: varianța minimă pentru o medie-țintă μ^*
  - 1: vectorul cu toate elementele egale cu 1, deci ponderile au suma 1
  - $^\top$: transpusa

- Ponderile negative sînt **poziții short** (vînzări în lipsă: activul este împrumutat și vîndut)

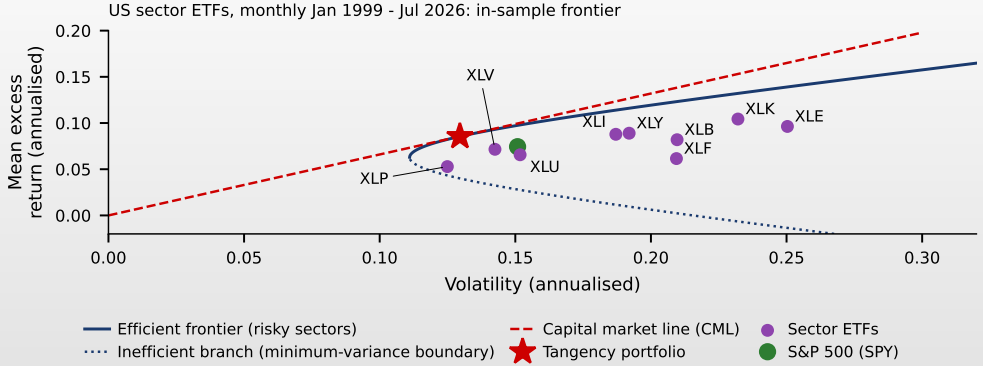
Raportul Sharpe și portofoliul tangent

- **Raportul Sharpe** $SR_p = \mathbb{E}[R_p - R_f]/\sigma_p$: randamentul în exces pe unitatea de volatilitate
- **Portofoliul tangent**: portofoliul cu cel mai mare raport Sharpe (formula de mai jos este valabilă dacă $\mathbf{\Sigma}$ este pozitiv definită și numitorul este pozitiv)

$$w_{\text{tan}} = \mathbf{\Sigma}^{-1}\boldsymbol{\mu} \,/\, 1^\top \mathbf{\Sigma}^{-1}\boldsymbol{\mu}$$

  - R_p, σ_p: randamentul și volatilitatea portofoliului p
  - numitorul rescalează $\mathbf{\Sigma}^{-1}\mu$ astfel încît ponderile să aibă suma 1
- **CML** (Capital Market Line, dreapta pieței de capital): toate combinațiile dintre activul fără risc și portofoliul tangent, $\mu_p = SR_{\text{tan}}\,\sigma_p$
- Evaluarea prin beta: Seminarul 3, problema A2
- Eroarea de estimare și shrinkage: Capitolul 4

Frontiera eficientă a sectoarelor din SUA (1/2)



Legenda: Efficient frontier (risky sectors): frontiera eficientă a sectoarelor; Inefficient branch: ramura ineficientă a frontierei de varianță minimă; Tangency portfolio: portofoliul tangent; in-sample frontier: frontieră calculată în eșantion

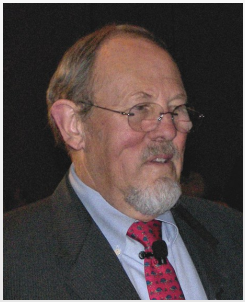
MFM_ch3_frontier

Frontiera eficientă a sectoarelor din SUA (2/2)

- Randamente lunare în exces ale a 9 ETF-uri sectoriale, ianuarie 1999 – iulie 2026 ($T = 331$ luni)
- Portofoliul tangent: medie 8,55%, volatilitate 12,96%, raport Sharpe 0,66
- SPY (ETF-ul care replică S&P 500, folosit ca aproximare a pieței): medie 7,44%, volatilitate 15,08%, raport Sharpe 0,49
- CAPM cere ca piața să fie pe frontieră; în acest eșantion, SPY **nu** este pe frontieră
- Axele graficului sînt fracții anualizate, cu punct zecimal: 0.10 pe axă înseamnă 10%
- Ponderile portofoliului tangent: $-0{,}37$ în financiar, $-0{,}21$ în materiale, $+0{,}37$ în sănătate
- Frontiera este calculată **în eșantion**, din medii estimate cu multă incertitudine (Capitolul 4)
- Este distanța dintre SPY și frontieră mai mare decît zgomotul de estimare? Testul GRS (Gibbons–Ross–Shanken, Secțiunea 4) de pe slide-ul Limitele testelor CAPM răspunde că nu ($p = 0{,}85$)

MFM_ch3_frontier

CAPM: Sharpe, Lintner, Black



William F. Sharpe, Premiul Nobel pentru Economie 1990

Foto: Larry D. Moore (2007); CC BY 4.0; Wikimedia Commons

- **CAPM** a fost formulat de Sharpe (1964) și Lintner (1965)
- Dacă toți investitorii aleg portofolii eficiente medie–varianță și au aceleași așteptări, toți dețin același portofoliu tangent
- Cum fiecare activ trebuie deținut de cineva, portofoliul tangent este chiar **portofoliul pieței**
- Randamentul în exces așteptat este proporțional cu **beta**

$$\mathbb{E}[R_i] - R_f = \beta_i \left(\mathbb{E}[R_m] - R_f\right), \qquad \beta_i = \frac{\mathrm{Cov}(R_i, R_m)}{\mathrm{Var}(R_m)}$$

- R_i, R_m: randamentele activului i și ale portofoliului pieței
- $\mathbb{E}[R_m] - R_f$: **prima de risc a pieței**
- β_i: sensibilitatea activului i la piață, $\beta_i > 1$ amplifică mișcările pieței
- Black (1972): o versiune fără împrumut nelimitat la rata fără risc, CAPM cu beta zero (Secțiunea 4)
- Sharpe a împărțit Premiul Nobel din 1990 cu Markowitz și Miller

Implicațiile CAPM

- Ipoteze principale
  - Investitori medie–variață cu aceleași așteptări, o singură perioadă
  - Împrumut și plasament nelimitate la R_f
  - Fără taxe sau costuri de tranzacționare
- Doar beta este remunerat: nicio altă caracteristică nu ar trebui să prezică randamentele
- Riscul idiosincratic nu este remunerat
- **SML** (Security Market Line, dreapta pieței titlurilor): afirmația testabilă a CAPM (Secțiunea 4)
  - orice activ se află pe dreapta (beta, medie), cu panta egală cu prima pieței
  - CML conține doar portofoliile eficiente
- Costul capitalului prin CAPM este beta estimat înmulțit cu prima pieței estimată; incertitudinea primei cîntărește mult mai mult decît cea a lui beta
  - Exemplu XLK: eroarea standard (e.s.) a primei pieței este $15{,}4\%/\sqrt{63} = 1{,}9\%$ pe an (15,4%: volatilitatea anuală a pieței, 63 de ani de date), înmulțită cu $\hat{\beta} = 1{,}28$ dă 2,5%
  - Incertitudinea lui beta contribuie doar cu $0{,}082 \times 7{,}2\% = 0{,}6\%$ (e.s. a lui beta înmulțită cu prima)
- Care portofoliu este „piața”? Răspunsul determină ce poate stabili un test al CAPM (critica lui Roll, Secțiunea 4)

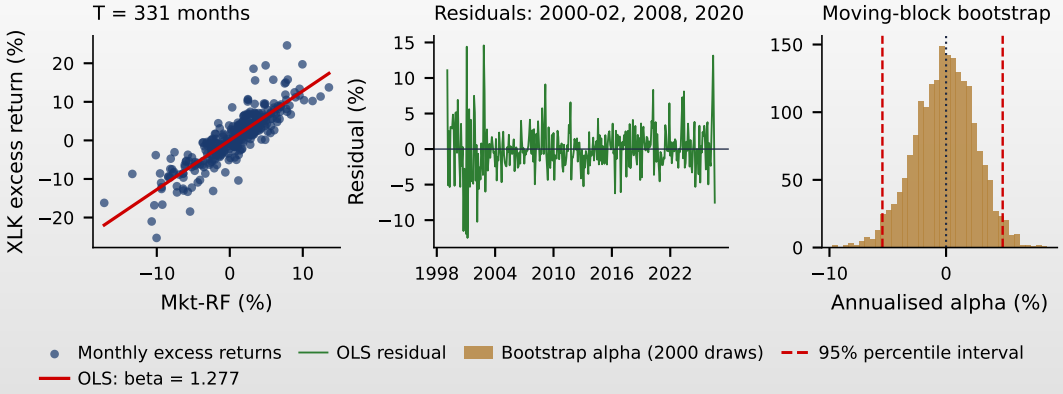
Modelul de piață și erorile HAC

- Modelul de piață $R^e_{i,t} = \alpha_i + \beta_i R^e_{m,t} + \varepsilon_{i,t}$
- **OLS** (Ordinary Least Squares, metoda celor mai mici pătrate): $\hat{\beta}_i = \widehat{\text{Cov}}(R^e_i, R^e_m)/\widehat{\text{Var}}(R^e_m)$
- Descompunerea $\sigma_i^2 = \beta_i^2 \sigma_m^2 + \sigma_{\varepsilon,i}^2$: risc sistematic (remunerat în CAPM) plus risc idiosincratic (diversificabil)
  - σ_i^2, σ_m^2: variațele activului și ale pieței, $\sigma_{\varepsilon,i}^2$: varianța reziduurilor
  - $R^2 = \beta_i^2 \sigma_m^2 / \sigma_i^2$ este ponderea sistematică
- Volatility clustering (Capitolul 1) face reziduurile heteroscedastice: folosiți erori **HAC** (Heteroskedasticity and Autocorrelation Consistent, robuste la heteroscedasticitate și autocorelație; Newey & West (1987))
  - ponderi Bartlett și $L = \lfloor 4(T/100)^{2/9} \rfloor$ laguri (Newey & West (1994))
  - T: numărul de perioade, $\lfloor \cdot \rfloor$: partea întreagă
  - pentru $T = 331$ se obține $L = 5$, pentru $T = 757$ se obține $L = 6$
  - estimațiile punctuale rămîn cele OLS

Alegeri de raportat pentru orice beta

- Fiecare dintre aceste alegeri poate schimba beta estimat
  - Frecvența și fereastra: 3–5 ani de date lunare sau 1–2 ani de date zilnice
  - Datele zilnice suferă de tranzacționarea asincronă: prețurile de închidere ale activelor nu sînt înregistrate în același moment
  - Aproximarea pieței: SPY (S&P 500) sau Mkt-RF pentru active din SUA, BET pentru acțiuni românești
  - Curățarea datelor: o eroare de scală creează un randament fals
  - Exemplu: la Digi Communications (simbolul DIGI), prețurile din 17–22 mai 2017 sînt de circa 725 de ori mai mari decît cele de după 23 mai, deci apare un randament logaritmic fals de $-6{,}6$ într-o zi

Exemplu rezolvat: beta ETF-ului de tehnologie (1/2)



MFM_ch3_seminar

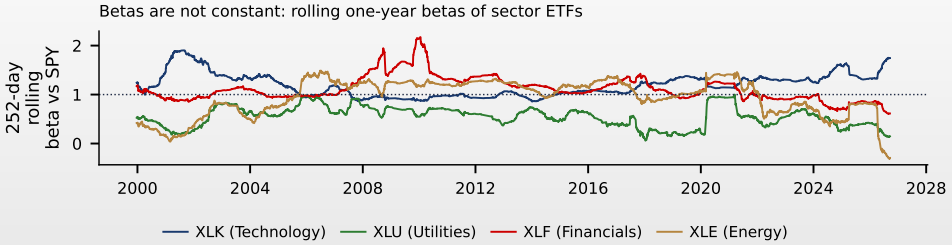
Exemplu rezolvat: beta ETF-ului de tehnologie (2/2)

		Eroare standard		
	Estimație	**Clasică**	**White**	**Newey–West**
α (anual)	0,33%	2,27%	2,32%	2,45%
β	1,277	0,041	0,054	0,082

- XLK pe Mkt-RF, lunar 1999–2026, $T = 331$, $R^2 = 0{,}742$
- **Clasică**: erori presupuse homoscedastice și neautocorelate
- **White**: robustă la heteroscedasticitate (White (1980))
- **Newey–West**: robustă și la autocorelație, $L = 5$ laguri
- Eroarea standard robustă a lui β este dublul celei clasice
- Heteroscedasticitatea explică o parte din creștere (coloana White), autocorelația produsului $f_t\varepsilon_t$ explică restul
- Statistica t a lui alfa: $t(\alpha) = 0{,}33/2{,}45 = 0{,}13$
- Intervalul bootstrap de 95% pentru alfa: $[-5{,}5\%; 4{,}9\%]$
  - bootstrap pe blocuri mobile: se reeșantionează blocuri de 12 luni consecutive din perechile (R_t^e, f_t), ca să se păstreze dependența în timp; 2 000 de reeșantionări (Seminarul 3, problema B1)
  - e.s. bootstrap este 2,61%, deci intervalul este puțin mai larg decît $\pm 1{,}96 \times 2{,}45\%$

MFM_ch3_seminar

Beta nu este constant



- Beta OLS din ultimele 252 de randamente logaritmice zilnice, recalculat zilnic
- Financiar (XLF): de la 0,60 la 2,17
- Maximul urmează crizei bancare din 2008–2009
- Tehnologie (XLK): de la 0,86 la 1,90
- Ridicat în anii bulei dot-com (1998–2001), 1,75 la final
- Energie (XLE): de la $-0{,}31$ la 1,49
- Negativ la final, cînd petrolul a evoluat în sens opus pieței
- Utilități (XLU): de la 0,06 la 1,00, sectorul defensiv clasic
- Un beta pe tot eșantionul ascunde aceste regimuri
- Modele condiționale: Capitolele 5–6

MFM_ch3_rolling_beta

Shrinkage pentru beta: Blume și Vasicek (1/2)

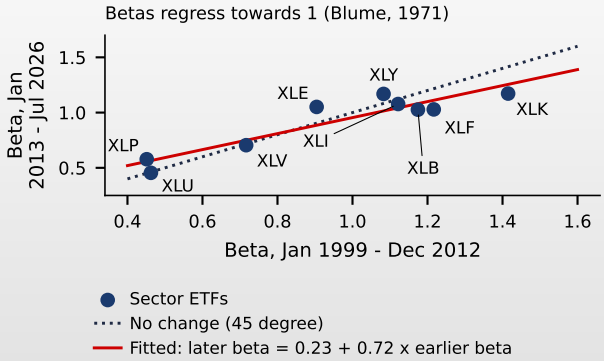
- **Regresia spre medie**: un beta estimat foarte mare sau foarte mic conține și zgomot, deci în perioada următoare tinde să se apropie de 1
- Blume (1971): regresia valorilor beta dintr-o perioadă pe cele din perioada anterioară
- De aici regula folosită de practicieni: $\beta^{\text{Blume}} = 0{,}33 + 0{,}67\,\hat{\beta}$
- Vasicek (1973): o medie ponderată între estimația activului și media $\bar{\beta}$ a valorilor beta ale tuturor activelor (distribuția a priori)

$$\beta_i^V = w_i \hat{\beta}_i + (1 - w_i)\bar{\beta}, \qquad w_i = \frac{\sigma_\beta^2}{\sigma_\beta^2 + \text{se}(\hat{\beta}_i)^2}$$

Shrinkage pentru beta: Blume și Vasicek (2/2)

- w_i: ponderea estimației, mai mare cînd $\hat{\beta}_i$ este precis (e.s. mică)
- $\text{se}(\hat{\beta}_i)$: eroarea lui standard
- σ^2_β: varianța valorilor beta **adevărate** între active
- Varianța estimațiilor între active, $\text{Var}_{cs}(\hat{\beta})$, adună varianța adevărată și zgomotul: $\text{Var}_{cs}(\hat{\beta}) = \sigma^2_\beta + \overline{\text{se}^2}$, unde $\overline{\text{se}^2}$ este media pătratelor erorilor standard
- Deci $\sigma^2_\beta = \text{Var}_{cs}(\hat{\beta}) - \overline{\text{se}^2}$ (estimația Bayes empirică; derivarea: Seminarul 3, problema A3)
- Exemplu: XLK pe SPY, lunar 1999–2012 (pe SPY, nu pe Mkt-RF, deci alt beta decît 1,28), cu distribuția a priori estimată din cele 9 sectoare
  - $\hat{\beta} = 1{,}415$ (e.s. Newey–West 0,139), $\bar{\beta} = 0{,}949$
  - $\sigma^2_\beta = 0{,}116 - 0{,}008 = 0{,}108$, deci $w = 0{,}1082/(0{,}1082 + 0{,}139^2) = 0{,}849$ (cu valorile nerotunjite)
  - $\beta^V = 0{,}849 \times 1{,}415 + 0{,}151 \times 0{,}949 = 1{,}344$
  - ajustarea Blume dă 1,278
  - beta estimat ulterior, pe 2013–2026, este 1,172

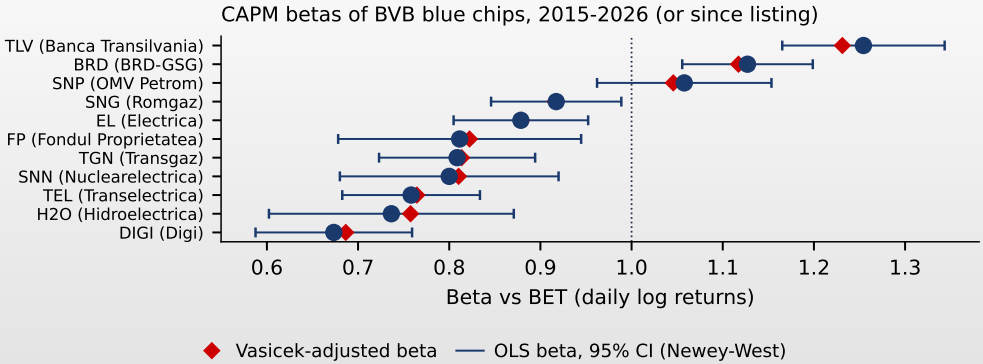
Revenirea valorilor beta spre unu



- Valori beta lunare ale celor 9 ETF-uri sectoriale față de SPY: 1999–2012 (pe orizontală) față de 2013–2026 (pe verticală)
- Dreapta estimată $\hat{\beta}_{\textbf{ulterior}} = 0{,}23 + 0{,}72\,\hat{\beta}_{\textbf{anterior}}$, foarte aproape de regula Blume $0{,}33 + 0{,}67\,\hat{\beta}$
- **RMSE** (Root Mean Squared Error, rădăcina erorii pătratice medii) a prognozei valorilor beta ulterioare, $\sqrt{\frac{1}{N}\sum_i (\text{prognoza}_i - \hat{\beta}_{i,\textbf{ulterior}})^2}$: beta neajustat 0,135, Blume 0,109, Vasicek 0,114
- Shrinkage-ul reduce eroarea de prognoză cu 15–20%
- Cu doar 9 sectoare, concluzia este calitativă

MFM_ch3_beta_shrink

Beta CAPM la Bursa de Valori București (1/2)



Legenda: OLS beta, 95% CI: beta OLS cu intervalul de încredere (CI, confidence interval) de 95%, erori Newey–West; Vasicek-adjusted beta: beta ajustat Vasicek

MFM_ch3_bvb_betas

Beta CAPM la Bursa de Valori București (2/2)

- Randamente logaritmice zilnice, regresate pe BET, de la 6 ianuarie 2015 sau de la listare (Digi, DIGI, 2017; Hidroelectrica, H2O, 2023)
- Zilele cu $|r_t| > 0{,}5$ sînt eliminate (una pentru DIGI, două pentru Fondul Proprietatea, FP)
- Băncile sînt cele mai sensibile la piață: Banca Transilvania (TLV) 1,25, BRD–Groupe Société Générale (BRD) 1,13
- OMV Petrom are un beta apropiat de 1: 1,06
- Mai puțin sensibile: Transelectrica (0,76) și Digi (0,67)
- R^2: 0,59 pentru TLV, doar 0,21 pentru DIGI
- O acțiune cu pondere mare în BET are un R^2 mare și pentru că face ea însăși parte din indice
- Shrinkage-ul Vasicek schimbă puțin estimațiile, pentru că valorile beta zilnice sînt precise (e.s. între 0,04 și 0,07)
- Prețurile neactualizate (stale prices) deplasează beta zilnic al acțiunilor mai puțin lichide (Seminarul 3, problema B4)
- Atenție: BET nu include dividendele, dar prețurile acțiunilor sînt ajustate cu dividendele
  - alfa ar fi deplasat în sus cu aproximativ beta înmulțit cu randamentul dividendelor indicelui
  - beta depinde de mișcările zilnice comune, deci ar trebui să se schimbe puțin cu BET-TR (varianta cu dividende reinvestite)

MFM_ch3_bvb_betas

Verificare rapidă: un beta, eroarea și shrinkage-ul lui

- O acțiune, 120 de randamente lunare: $\hat{\beta} = 0{,}90$, e.s. clasică 0,05, e.s. Newey–West 0,09
  1. Calculați ambele intervale de 95%. Este acțiunea mai puțin riscantă decît piața după fiecare dintre ele?
  2. Ce interval raportați și de ce nu se schimbă estimația punctuală?
- O secțiune transversală de valori beta are $\mathrm{Var}_{cs}(\hat{\beta}) = 0{,}10$, $\overline{\mathrm{se}^2} = 0{,}02$ și media $\bar{\beta} = 1{,}0$
  3. Calculați $\sigma^2_{\hat{\beta}}$ și beta Vasicek pentru un activ cu $\hat{\beta} = 1{,}6$, o dată cu e.s. 0,2 și o dată cu e.s. 0,1
  4. Care dintre cele două primește mai mult shrinkage și de ce? Comparați ambele cu beta Blume
- Răspunsuri: ▸ Anexă

De la o singură valoare alfa la testul GRS (1/2)

- **Alfa lui Jensen** (Jensen (1968)): termenul liber al modelului de piață, α_i
  - CAPM implică $\alpha_i = 0$ pentru orice activ
- Un test t separat pentru fiecare activ: XLK are $t = 0{,}13$
  - Cu multe active, unele valori alfa par semnificative doar din întîmplare (Secțiunea 8)
- **Testul GRS** (Gibbons–Ross–Shanken, Gibbons, Ross & Shanken (1989)): un singur test pentru toate activele, $H_0 : \alpha_1 = \cdots = \alpha_N = 0$

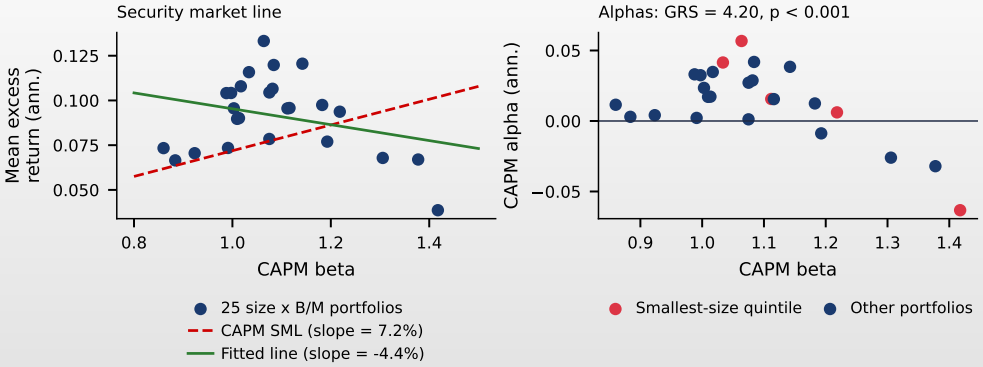
$$W = \frac{T - N - 1}{N} \, \frac{\hat{\boldsymbol{\alpha}}^\top \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\alpha}}}{1 + \hat{\mu}_m^2 / \hat{\sigma}_m^2} \;\sim\; F(N,\, T - N - 1)$$

- Notațiile
  - N: numărul activelor de test
  - T: numărul de luni
  - $\hat{\boldsymbol{\alpha}}$: cele N valori alfa estimate
  - $\hat{\boldsymbol{\Sigma}}$: covarianța reziduurilor estimată prin verosimilitate maximă (împărțire la T)
  - $\hat{\mu}_m / \hat{\sigma}_m$: raportul Sharpe al pieței

De la o singură valoare alfa la testul GRS (2/2)

- $\hat{\boldsymbol{\alpha}}^{\top}\hat{\boldsymbol{\Sigma}}^{-1}\hat{\boldsymbol{\alpha}}$: o sumă ponderată a pătratelor valorilor alfa; un alfa cîntărește mai mult cînd reziduurile activului sînt puțin volatile
- Decizia: H_0 se respinge cînd W depășește cuantila de 95% a distribuției $F(N, T-N-1)$
- F: distribuția Fisher
- Distribuția este exactă, condiționat de factori
  - erori i.i.d. (independente și identic distribuite) cu distribuția Normală multivariată, independente de factori
  - medie zero și covarianță constantă nesingulară
- Interpretare: un W mare arată că portofoliul pieței este departe de frontiera eficientă construită din piață și din activele de test

Dreapta pieței titlurilor (SML) în date (1/2)



Legenda: CAPM SML: dreapta CAPM, cu panta egală cu prima pieței; Fitted line: dreapta estimată pe date; Alphas: valorile alfa ale celor 25 de portofolii; Smallest-size quintile: cvintila firmelor celor mai mici

MFM_ch3_sml

Dreapta pieței titlurilor (SML) în date (2/2)

- Active de test: acțiunile americane sortate în fiecare iunie în 5 cvintile de mărime și 5 de B/M, 25 de portofolii ponderate după valoare (Fama & French (1993)), iulie 1963 – iulie 2026, $T = 757$
- Dreapta CAPM are panta 7,2% pe an (în grafic, axele sînt fracții anuale: $0.05 = 5\%$)
- Dreapta estimată are panta $-4{,}4\%$: beta mai mare, randament mediu **mai mic**
- Valorile beta acoperă doar 0,86–1,42, randamentele medii în exces 3,9%–13,3%
- Alfa este $+5{,}7\%$ pe an pentru firmele mici cu B/M mare (small-value) și $-6{,}3\%$ pe an pentru firmele mici cu B/M mic (small-growth)
- 10 din 25 de valori alfa au $|t| > 1{,}96$
- GRS $= 4{,}20$, p-value-ul 8×10^{-11}: CAPM este respins

MFM_ch3_sml

GRS ca test al raportului Sharpe

- O identitate algebrică (Gibbons, Ross & Shanken (1989)), cu toate momentele estimate prin verosimilitate maximă

$$\hat{\boldsymbol{\alpha}}^\top \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\alpha}} = \widehat{SR}^2(f, \mathrm{R}) - \widehat{SR}^2(f)$$

  - $\widehat{SR}^2(f, \mathrm{R})$: pătratul raportului Sharpe al portofoliului tangent format din factor și cele N active de test
  - $\widehat{SR}^2(f)$: cel al factorului singur
- Deci GRS măsoară creșterea raportului Sharpe obținută prin adăugarea activelor de test

$$W = \frac{T - N - 1}{N} \cdot \frac{\widehat{SR}^2(f, \mathrm{R}) - \widehat{SR}^2(f)}{1 + \widehat{SR}^2(f)}$$

- Pe cele 25 de portofolii, raportul Sharpe lunar al pieței singure este 0,134 (nerotunjit 0,1344, înmulțit cu $\sqrt{12}$: 0,47 pe an)
- Raportul Sharpe lunar al portofoliului tangent format din piață și cele 25 de portofolii este 0,405 (1,40 pe an)
- $W = 29{,}24 \times (0{,}405^2 - 0{,}134^2)/(1 + 0{,}134^2) = 4{,}20$, cu $29{,}24 = (757 - 25 - 1)/25$
- Dacă H_0 ar fi adevărată, zgomotul singur ar produce un cîștig mult mai mic (Anexă)
- Demonstrația identității, cu aceste cifre ca țintă de replicare: Seminarul 3, problema A4

Metoda generalizată a momentelor, pe scurt (1/2) *(aprofundare)*

- Un model economic implică $\mathbb{E}[g_t(\boldsymbol{\theta})] = 0$ pentru un vector de condiții de momente g_t
- **GMM** (Generalized Method of Moments, metoda generalizată a momentelor, Hansen (1982)) alege $\hat{\boldsymbol{\theta}}$ astfel încît media de selecție a momentelor să fie zero

$$\bar{g}(\hat{\boldsymbol{\theta}}) = \tfrac{1}{T} \textstyle\sum_{t=1}^{T} g_t(\hat{\boldsymbol{\theta}}) = 0$$

  - cazul exact identificat: tot atîtea momente cîți parametri
  - cu mai multe momente decît parametri, nu toate pot fi zero, iar $\bar{g}$ se face cît mai mic, cu o matrice de ponderare
- Varianța sandwich în cazul exact identificat

$$\mathrm{Var}(\hat{\boldsymbol{\theta}}) \approx \tfrac{1}{T} \mathrm{D}^{-1} \mathrm{S} \mathrm{D}^{-1\top}, \qquad \mathrm{D} = \mathbb{E}\big[\partial g_t / \partial \boldsymbol{\theta}^\top\big], \qquad \mathrm{S} = \textstyle\sum_{j=-\infty}^{\infty} \mathrm{Cov}(g_t, g_{t-j})$$

  - D: jacobianul momentelor (derivatele lor după parametri)
  - S: varianța pe termen lung a momentelor, inclusiv autocovariațele, estimată Newey–West (Secțiunea 3)
- Cazul cel mai simplu, o medie: $g_t = R_t - \mu$ dă $D = -1$ și $\mathrm{Var}(\hat{\mu}) \approx S/T$; așa se obține statistica t HAC a randamentului mediu al unui factor (Stabilitatea primelor în timp)
- OLS: $g_t = x_t(y_t - x_t^\top \boldsymbol{\theta})$ dă $\mathrm{D} = -\mathbb{E}[x_t x_t^\top]$: erorile White cînd S nu are laguri, Newey–West în rest (tabelul XLK)

Metoda generalizată a momentelor, pe scurt (2/2) *(aprofundare)*

- **GRS ca GMM**: parametrii (α_i, β_i), $i = 1, \ldots, N$; $2N$ momente $\varepsilon_t \otimes (1, f_t)$, fiecare reziduu înmulțit cu 1 și cu factorul ($\otimes$: produsul Kronecker)
  - sistemul este exact identificat, deci estimațiile sînt chiar cele OLS, activ cu activ; GMM schimbă doar varianța lor
  - parametrii ordonați activ cu activ, $(\alpha_1, \beta_1, \alpha_2, \beta_2, \ldots)$, dau $\mathrm{D} = -\mathrm{I}_N \otimes (\mathrm{Z}^\top \mathrm{Z}/T)$, unde Z este matricea $T \times 2$ cu rîndurile $(1, f_t)$
  - Seminarul 3, problema B7, pune întîi toate valorile alfa; testul rezultat este același
- $\hat{\mathrm{V}}_\alpha$: blocul matricei sandwich care corespunde valorilor alfa, calculat cu un $\hat{\mathrm{S}}$ HAC
- Statistica Wald $W_{\mathrm{GMM}} = \hat{\boldsymbol{\alpha}}^\top \hat{\mathrm{V}}_\alpha^{-1} \hat{\boldsymbol{\alpha}} \to \chi^2_N$ sub H_0
- Același aparat dă erorile primelor robuste la specificarea greșită (▸ Anexă) și estimează modelul cu factor de actualizare din Secțiunea 7

Încălcarea ipotezelor GRS

- **Cozi groase și volatility clustering** (Capitolul 1): distribuția F nu mai este exactă
  - Bootstrap pe reziduuri sub H_0: se reeșantionează rînduri întregi de reziduuri și se reconstruiesc randamentele cu $\alpha = 0$ (Seminarul 3, problema B7)
  - Bootstrap-ul este robust la lipsa normalității doar dacă erorile sînt i.i.d. și independente de factori
  - Testul Wald GMM: momentele $\varepsilon_t \otimes (1, f_t)$, fiecare reziduu înmulțit cu 1 și cu factorul ($\otimes$: produsul Kronecker; construcția și ordinea: GMM pe scurt)
  - $W_{\text{GMM}} = \hat{\boldsymbol{\alpha}}^\top \hat{\mathrm{V}}_\alpha^{-1} \hat{\boldsymbol{\alpha}} \to \chi^2_N$, $\hat{\mathrm{V}}_\alpha$: estimatorul HAC al lui $\mathrm{Var}(\hat{\boldsymbol{\alpha}})$
  - robust la heteroscedasticitate și autocorelație
- **Prea multe active față de numărul de luni**: $\hat{\boldsymbol{\Sigma}}$ are rangul cel mult $T - 2$
  - cînd $N \geq T - 1$, $\hat{\boldsymbol{\Sigma}}$ nu se poate inversa și GRS nu se poate calcula
  - puterea testului scade mult înainte de această limită
- Teste construite pentru multe active: ▸ Anexă

O SML plată: Black și Betting Against Beta



Fischer Black (1938–1995)

Foto: Dalmatine at English Wikipedia (încărcată 2009); domeniu public; Wikimedia Commons

- Black (1972): dacă investitorii nu se pot împrumuta liber la R_f, randamentul rămîne liniar în beta, dar dreapta pornește de la randamentul unui portofoliu **cu beta zero**, mai mare decît R_f
- Predicție: SML este **mai plată** decît dreapta CAPM
- Frazzini & Pedersen (2014): investitorii care vor mai mult risc, dar nu se pot împrumuta, cumpără direct active cu beta mare
- cererea suplimentară face aceste active scumpe, deci randamentele lor viitoare sînt mai mici
- Strategia lor, **BAB** (Betting Against Beta, pariul împotriva lui beta)

$$r_t^{\mathbf{BAB}} = \frac{R_{L,t} - R_{f,t}}{\beta_L} - \frac{R_{H,t} - R_{f,t}}{\beta_H}$$

- L: portofoliu cu beta mic, cu levier pînă la beta 1
- H: portofoliu cu beta mare, redus la beta 1
- Concret, pentru 1 unitate de capital: se investesc $1/\beta_L > 1$ unități în L (diferența se împrumută) și $1/\beta_H < 1$ unități în H (restul se plasează la R_f)
- BAB are beta zero prin construcție și un randament mediu pozitiv în datele lor
- Simpla diferență beta mic minus beta mare, fără scalare, are beta negativ: media ei amestecă prima BAB cu o expunere negativă la piață (Seminarul 3, problema C2)

Limitele testelor CAPM

- Roll (1977): CAPM se referă la portofoliul **adevărat** al pieței, care cuprinde întreaga avuție
- indicii bursieri omit obligațiunile, activele imobiliare, firmele private și capitalul uman
- Matematic, beta calculat față de **orice** portofoliu eficient explică exact randamentele medii ale tuturor activelor (Seminarul 3, problema A2)
  - deci un test CAPM verifică de fapt dacă indicele folosit ca piață este eficient
  - respingerea poate veni din model sau din alegerea indicelui
- **Activele de test contează**: 9 ETF-uri sectoriale, ianuarie 1999 – iulie 2026 ($T = 331$): GRS $= 0{,}53$, $p = 0{,}85$, CAPM nerespins
  - Sînt sectoarele de pe slide-ul frontierei, cu Mkt-RF ca piață (raport Sharpe 0,51 pe an, apropiat de 0,49 al SPY)
  - Adăugarea sectoarelor crește pătratul raportului Sharpe lunar cu 0,015, mai puțin decît 0,029, cît ar produce zgomotul singur (Anexă)
  - Pe aceleași 331 de luni, cele 25 de portofolii mărime $\times$ B/M îl resping: GRS $= 2{,}91$, $p = 9 \times 10^{-6}$
  - Explicația: fiecare sector amestecă firme mici și mari, de valoare și de creștere, deci sectoarele diferă puțin prin caracteristicile care explică randamentele
- Concluzie: faptul că un test nu respinge modelul este o dovadă slabă în favoarea lui
- Testați modelele pe active ale căror randamente medii diferă mult între ele

Verificare rapidă: citirea unei statistici GRS

- Un factor, $N = 4$ active de test, $T = 65$ de luni; rapoarte Sharpe lunare: factorul singur 0,15, portofoliul tangent al factorului și celor 4 active 0,25
  1. Calculați W din forma cu rapoarte Sharpe. Cuantila de 95% a lui $F(4, 60)$ este circa 2,53: respingeți?
  2. Calculați creșterea așteptată sub H_0 a pătratului raportului Sharpe, $N(1 + \widehat{SR}^2(f))/(T - N - 3)$, și comparați-o cu cea observată
  3. Aceleași rapoarte Sharpe, $T = 650$ de luni: recalculați W (cuantila de 95% a lui $F(4, 645)$: circa 2,39). Ce s-a schimbat, distanța sau dovezile?
- Legătura cu capitolul: frontiera sectoarelor arată o distanță vizibilă față de SPY, totuși GRS nu respinge pe 331 de luni
- Răspunsuri: ▸ Anexă

Teoria evaluării prin arbitraj

- **APT**: Arbitrage Pricing Theory (teoria evaluării prin arbitraj), Ross (1976)
- Ipoteza: randamentele urmează un model cu K factori, iar riscurile specifice se pot elimina prin diversificare

$$R_{i,t} = \mathbb{E}[R_i] + \boldsymbol{\beta}_i^\top \mathrm{f}_t + \varepsilon_{i,t}, \qquad \mathbb{E}[\mathrm{f}_t] = 0$$

- **Absența arbitrajului** (nu există profit sigur fără capital investit) implică, aproximativ

$$\mathbb{E}[R_i] - R_f = \boldsymbol{\beta}_i^\top \boldsymbol{\lambda}$$

- $\boldsymbol{\beta}_i$: cele K încărcări ale activului i
- f_t: componentele neanticipate ale factorilor, cu media 0
- $\boldsymbol{\lambda}$: **primele de risc**, randamentul așteptat suplimentar pe unitatea fiecărei expuneri
- Teoria nu spune **care** sînt factorii: ei trebuie găsiți în date

Construcția factorilor: portofolii long–short

mărime: mediana NYSE; B/M: 30% / 40% / 30%

	Mic (growth)	Neutru	Mare (value)
Mici	S_L	S_N	S_H
Mari	B_L	B_N	B_H

$$\text{SMB} = \tfrac{1}{3}(S_L + S_N + S_H) - \tfrac{1}{3}(B_L + B_N + B_H)$$

$$\text{HML} = \tfrac{1}{2}(S_H + B_H) - \tfrac{1}{2}(S_L + B_L)$$

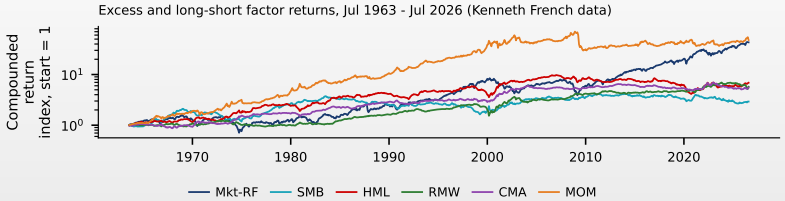
- Un **factor construit prin sortare** cumpără acțiunile cu valoare mare a unei caracteristici și le vinde pe cele cu valoare mică
- Ce se vinde finanțează ce se cumpără, deci randamentul factorului este o diferență de randamente, $f_t = R_{\textbf{mare},t} - R_{\textbf{mic},t}$
- Fama–French: în fiecare iunie, acțiunile sînt împărțite în 2×3 grupe, cu datele contabile din anul anterior; fiecare grupă este un portofoliu ponderat după capitalizare
- Pragul de mărime este mediana capitalizării acțiunilor de la NYSE (New York Stock Exchange)
  - **SMB** (Small Minus Big): acțiuni mici minus acțiuni mari
  - **HML** (High Minus Low): B/M mare (valoare) minus B/M mic (creștere)
- Aceeași construcție pe profitabilitate și investiții dă RMW și CMA (slide-ul următor)

Modelele factoriale standard

Model	Factori	Referință	Motivație
CAPM	Mkt-RF	Sharpe (1964)	echilibru
FF3	Mkt-RF, SMB, HML	Fama & French (1993)	efectele de mărime și B/M (Fama & French (1992))
Carhart	FF3 + MOM	Carhart (1997)	evaluarea fondurilor
modelul q	piață, mărime, investiții, ROE	Hou, Xue & Zhang (2015)	deciziile de investiții ale firmelor
FF5	Mkt-RF, SMB, HML, RMW, CMA	Fama & French (2015)	modelul de actualizare a dividendelor

- FF3 și FF5: modelele Fama–French cu trei, respectiv cinci factori; regresia FF3 este $R^e_{i,t} = \alpha_i + b_i\,\mathrm{MKT}_t + s_i\,\mathrm{SMB}_t + h_i\,\mathrm{HML}_t + \varepsilon_{i,t}$, cu MKT = Mkt-RF și încărcările b_i, s_i, h_i pe cei trei factori
- Un model bun lasă valori alfa apropiate de zero în regresiile pe serii de timp, deci GRS nu îl respinge
- Factorii adăugați la FF3 (ROE: Return On Equity, rentabilitatea capitalului propriu)
  - **RMW** (Robust Minus Weak): profitabilitate operațională mare minus mică
  - **CMA** (Conservative Minus Aggressive): creștere mică minus mare a activelor
  - **MOM** (momentum, notat și UMD, Up Minus Down): acțiunile cu randament mare minus cele cu randament mic în lunile $t-12$ până la $t-2$ (ultima lună se omite)
  - Cîștigătorii trecuți continuă să cîștige 3–12 luni (Jegadeesh & Titman (1993))
- Atenție: SMB din FF3 vine dintr-o singură sortare (mărime și B/M), iar SMB din FF5 este media a trei sortări
- Din acest motiv, FF3 nu este un caz particular al FF5

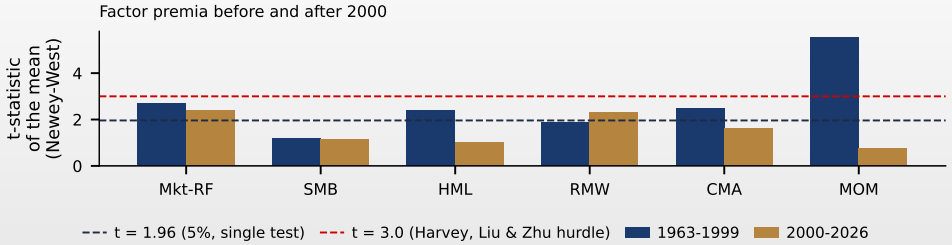
Șase factori în șaizeci și trei de ani



- Randamentele lunare ale factorilor, cumulate pornind de la 1, pe scară logaritmică
- Factorii sînt randamente în exces sau long–short, deci curbele nu includ dobînda pe capital sau pe garanția pozițiilor short
- Curbele nu arată deci averea unui investitor real
- Valoarea finală a unei unități investite, iulie 1963 – iulie 2026: Mkt-RF 43,2, MOM 48,0, HML 6,9, RMW 5,7, CMA 5,5, SMB 2,9
- Momentum a atins maximul înainte de 2009 și a pierdut mult cînd piața și-a revenit brusc în 2009: un **crah de momentum**
- Factorul valoare a stagnat sau a pierdut, aproximativ din 2007 pînă în 2020
- Randamente anuale medii: Mkt-RF 7,2%, MOM 7,3%, HML 3,6%, RMW 3,1%, CMA 3,0%, SMB 2,3%

MFM_ch3_factor_cum

Stabilitatea primelor în timp



- Statistica t a randamentului lunar mediu al factorului (Newey–West), 1963–1999 față de 2000–2026
- Momentum: $t = 5{,}53$ înainte de 2000 și 0,75 după
- Media anuală a momentum a scăzut de la 10,7% la 2,5%
- Valoare (HML): $t = 2{,}39$ înainte de 2000 și 1,02 după
- Media anuală HML a scăzut de la 4,2% la 2,8%
- Profitabilitatea (RMW) este excepția: $t = 1{,}90$, apoi 2,31
- Prima pieței rămîne semnificativă în ambele jumătăți ($t = 2{,}70$ și 2,39)
- Anul 2000 este o tăietură arbitrară, nu data publicării factorilor; scăderea legată de publicare se testează în Secțiunea 12

MFM_ch3_factor_tstats

Cele două etape



Eugene Fama, premiul Morgan Stanley–AFA (American Finance Association), 2008

Foto: TonyTheTiger (2008); CC BY-SA 3.0; Wikimedia Commons

- Fama & MacBeth (1973) estimează primele de risc $\boldsymbol{\lambda}$ din $\mathbb{E}[R_i^e] = \lambda_{\mathbf{0}} + \boldsymbol{\beta}_i^\top \boldsymbol{\lambda}$ (Fama: Premiul Nobel 2013)
- **Etapa 1**: serii de timp, cîte o regresie pentru fiecare activ
  - randamente $T \times N$, factori $T \times K \Rightarrow$ valorile beta $\hat{\mathrm{B}}$, $N \times K$

$$R_{i,t}^e = a_i + \boldsymbol{\beta}_i^\top \mathbf{f}_t + \varepsilon_{i,t}$$

- **Etapa 2**: transversal, în fiecare lună o regresie a celor N randamente pe $\mathrm{X} = [1, \hat{\mathrm{B}}]$

$$R_{i,t}^e = \lambda_{\mathbf{0},t} + \hat{\boldsymbol{\beta}}_i^\top \boldsymbol{\lambda}_t + u_{i,t}, \qquad \hat{\boldsymbol{\lambda}} = \tfrac{1}{T} \textstyle\sum_t \hat{\boldsymbol{\lambda}}_t$$

- $\lambda_{\mathbf{0}}$: termenul liber, zero dacă modelul este corect (la Black (1972): cu cît depășește randamentul cu beta zero rata R_f)
- a_i: termenul liber din etapa 1
- $u_{i,t}$: reziduul din etapa 2
- $\hat{\boldsymbol{\lambda}}$: media pantelor lunare
- Metoda funcționează și cu factori care **nu** sînt portofolii tranzacționate (de exemplu, inflația) și cu caracteristici ale firmelor ca regresori

Erori standard pentru primele de risc (1/2)

- **Fama–MacBeth**: estimațiile lunare $\hat{\lambda}_{k,t}$ formează un eșantion de volum T

$$\text{se}_{FM}(\hat{\lambda}_k) = s(\hat{\lambda}_{k,t})/\sqrt{T}$$

  - $s(\cdot)$: abaterea standard de selecție pe cele T luni
  - robuste la corelația reziduurilor între active în aceeași lună
  - dacă $\hat{\lambda}_{k,t}$ este autocorelat, se folosește Newey–West pe această serie
- **Model greșit specificat**: erorile Fama–MacBeth, Newey–West și Shanken (slide-ul următor) presupun că modelul este corect
  - adică erorile de evaluare sînt zero: $\mathrm{e} = \boldsymbol{\mu} - \mathrm{X}\boldsymbol{\gamma} = 0$
  - $\boldsymbol{\mu}$: randamentele medii în exces, $\boldsymbol{\gamma} = (\lambda_0, \boldsymbol{\lambda}^\top)^\top$
  - dacă modelul este greșit ($\mathrm{e} \neq 0$), zgomotul din valorile beta estimate adaugă varianță primelor (Kan, Robotti & Shanken (2013); formula: ▸ Anexă)

Erori standard pentru primele de risc (2/2)

- **Erori în variabile**: etapa 2 folosește valorile beta estimate, nu pe cele adevărate, deci se_{FM} subestimează incertitudinea
- Corecția Shanken (1992) mărește cu factorul $(1 + c)$ partea variației care nu provine din variabilitatea factorilor

$$\text{Var}_{\text{Sh}}(\hat{\boldsymbol{\lambda}}) = (1 + c)\Big[\text{Var}_{FM}(\hat{\boldsymbol{\lambda}}) - \tfrac{1}{T}\boldsymbol{\Sigma}_f\Big] + \tfrac{1}{T}\boldsymbol{\Sigma}_f, \qquad c = \hat{\boldsymbol{\lambda}}^\top \boldsymbol{\Sigma}_f^{-1}\hat{\boldsymbol{\lambda}}$$

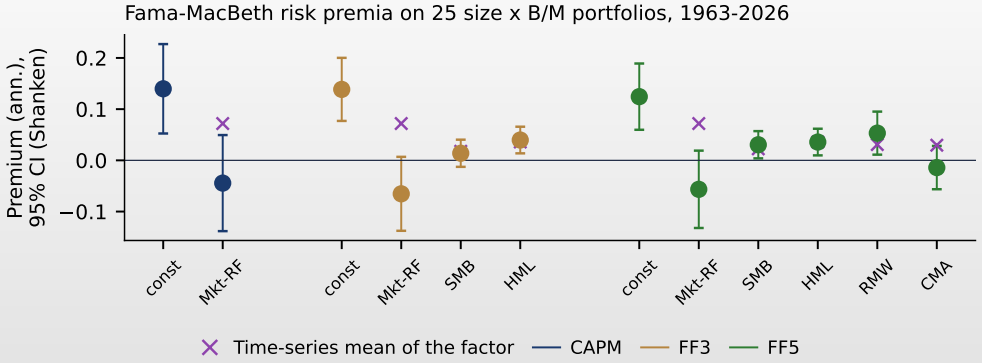
  - Var_{FM}: varianța Fama–MacBeth, $s^2(\hat{\boldsymbol{\lambda}}_t)/T$
  - $\boldsymbol{\Sigma}_f$: covarianța factorilor
  - c: pătratul raportului Sharpe al primelor, pe lună; aici 0,03 pentru FF3, dar poate fi mult mai mare pentru factori netranzacționați
- Un c mic (factori tranzacționați, date lunare): corecția este mică
- Un c mare: statisticile t Fama–MacBeth sînt supraestimate

Exemplu rezolvat: patru erori standard pentru prima de valoare

FF3, HML	$\hat{\lambda}$	**e.s.**	t	**Semnificativ la 5%?**
Fama–MacBeth	3,97%	1,33%	2,99	da
Newey–West (6 laguri)	3,97%	1,62%	2,45	da
Shanken	3,97%	1,33%	2,99	da
Kan–Robotti–Shanken	3,97%	1,32%	3,00	da

- 25 de portofolii mărime $\times$ B/M, 1963–2026
- Corecția Shanken modifică foarte puțin eroarea, pentru că $c = 0{,}03$ pe lună
- Cel mai mult contează autocorelația pantelor lunare $\hat{\lambda}_t$, corectată prin Newey–West cu 6 laguri ($T = 757$)
- Kan–Robotti–Shanken: eroarea robustă la un model greșit; pentru RMW din FF5 ea crește de la 2,1% la 2,6%, iar t scade de la 2,5 la 2,1
- HML depășește pragul clasic 1,96 cu toate cele patru erori
- Pragul mai strict $t > 3$ (Secțiunea 8) este atins la limită doar cu Kan–Robotti–Shanken (3,00) și ratat clar cu Newey–West (2,45)

Primele de risc estimate (1/2)



Legenda: Fama-MacBeth risk premia: primele de risc Fama–MacBeth, cu intervale de 95%; Time-series mean of the factor: media factorului în timp

MFM_ch3_fama_macbeth

Primele de risc estimate (2/2)

- 25 de portofolii mărime × B/M, 1963–2026
- bare: intervale de 95% cu erori Shanken, în fracții anuale ($0.1 = 10\%$)
- cruciulițe: mediile factorilor
- CAPM: termen liber 14,0% (e.s. 4,4%), prima pieței −4,4% (e.s. 4,8%)
- Prime estimate, cu eroarea standard în paranteză
  - FF3: SMB 1,4% (1,4%), HML 4,0% (1,3%)
  - FF5: RMW 5,3% (2,1%), CMA −1,4% (2,2%)
- Factor tranzacționat: λ ar trebui să fie egal cu media lui în timp
- HML: prima estimată 4,0%, media factorului 3,6%, deci valori apropiate
- Piața (FF3): prima estimată −6,5%, media factorului 7,2%, deci valori îndepărtate
- De ce? Valorile beta de piață diferă puțin între portofolii: 0,86–1,42 în CAPM și 0,89–1,14 în FF3
- Cu o dispersie atît de mică, prima pieței este **slab identificată**: termenul liber preia nivelul mediu al randamentelor (Lewellen, Nagel & Shanken (2010))

MFM_ch3_fama_macbeth

Factori inutili și factori slabi *(aprofundare)*

- Un **factor inutil** g_t este independent de toate randamentele: valorile beta adevărate sînt zero, iar cele estimate sînt doar zgomot, de ordinul $1/\sqrt{T}$
- Etapa 2 regresează randamentele pe acest zgomot: $\hat{\lambda}_g$ nu tinde spre zero, iar testul t declară prea des factorul remunerat cînd modelul este greșit (Kan & Zhang (1999))
- Simulare pe cele 25 de portofolii: CAPM plus un factor independent cu distribuția Normală, 2 000 de replicări, nivel nominal 5%
  - $\lambda_g = 0$ este respins în 60% (erori Fama–MacBeth) și 27% (erori Shanken) din replicări
  - Remediu: testați întîi, în etapa 1, dacă toate valorile beta ale factorului sînt zero (test Wald); acest test respinge doar în 6,7% din replicări, aproape de nivelul nominal
- **Identificare slabă**: valorile beta sînt aproape de zero (factor slab) sau aproape egale între active (piața, în exemplul nostru)
  - teste robuste la identificare (Kleibergen (2009))
  - cu multe active, consistența etapei 2 depinde de cît de puternici sînt factorii (Anatolyev & Mikusheva (2022))

O evaluare sceptică: adăugarea a 30 de portofolii pe industrii *(aprofundare)*

	R^2 OLS		R^2 GLS	
Model	25	25 + 30	25	25 + 30
CAPM	0,08	0,00	0,06	0,01
FF3	0,66	0,22	0,21	0,08
FF5	0,76	0,24	0,26	0,10

Lunar 1963–2026, termen liber și prime fără restricții; țintă de replicare pentru Seminarul 3, problema B6

- Randamentele celor 25 de portofolii sînt explicate aproape complet de trei factori: orice factori corelați cu SMB și HML le reproduc mediile
- Deci un R^2 OLS mare pe aceste portofolii nu dovedește mare lucru (Lewellen, Nagel & Shanken (2010))

O evaluare sceptică: trei verificări *(aprofundare)*

- Trei verificări (Lewellen, Nagel & Shanken (2010))
  - Lărgiți mulțimea activelor de test: FF3 scade de la 0,66 la 0,22 cînd se adaugă 30 de industrii
  - Raportați și R^2 **GLS** (Generalised Least Squares, metoda celor mai mici pătrate generalizate), care ponderează erorile cu inversa covarianței randamentelor, ca GRS: niciodată peste 0,26
  - Impuneți ca prima unui factor tranzacționat să fie media lui și eliminați termenul liber: FF3 pe cele 55 de active dă $R^2 = -0{,}27$
  - $R^2 = 1 - \text{SSE}/\text{SST}$, cu SSE suma pătratelor erorilor și SST suma pătratelor abaterilor de la medie
  - R^2 este negativ cînd modelul greșește mai mult decît simpla medie a randamentelor; OLS cu termen liber nu poate face mai rău decît această medie
- Acțiuni individuale în locul portofoliilor: valori beta mai dispersate, dar și estimate mai zgomotos (Ang, Liu & Schwarz (2020))

Verificare rapidă: prime, Shanken și un R^2 negativ

- Un factor netranzacționat (de exemplu, creșterea producției industriale) cu volatilitatea $\sigma_f = 1\%$ pe lună; $T = 400$ de luni; etapa 2 dă $\hat{\lambda} = 0{,}5\%$ pe lună, cu $s(\hat{\lambda}_t) = 3\%$
  1. Calculați se_{FM} și statistica t Fama–MacBeth
  2. Calculați c, varianța Shanken și statistica t Shanken. Trece factorul pragul $t > 3$?
  3. De ce ar fi c foarte mic pentru un factor tranzacționat cu $\sigma_f = 4{,}5\%$ și același $\hat{\lambda}$?
- Trei portofolii au randamentele medii în exces 2%, 4%, 6% pe an; un model cu prime impuse și fără termen liber estimează 6%, 4%, 2%
  4. Calculați SST, SSE și R^2
  5. De ce nu poate fi negativ R^2-ul unei regresii OLS cu termen liber?
- Răspunsuri: ▸ Anexă

Factorii ca factor stochastic de actualizare *(aprofundare)*



Lars Peter Hansen, Premiul Nobel pentru Economie 2013

Foto: Bengt Nyman (2013); CC BY 2.0; Wikimedia Commons

- **SDF** (Stochastic Discount Factor, factorul stochastic de actualizare) m_t: evaluează toate randamentele în exces, $\mathbb{E}[m_t R^e_{i,t}] = 0$
- m_t este mare în perioadele proaste (de exemplu, cînd piața scade); un activ care cîștigă tocmai atunci funcționează ca o asigurare, deci investitorii acceptă pentru el un randament mediu mic
- Un model factorial liniar este un SDF, $m_t = 1 - \mathrm{b}^\top(\mathrm{f}_t - \mathbb{E}\mathrm{f})$
- b: coeficienții SDF, $\mathbb{E}\mathrm{f}$: mediile factorilor
- Prin înlocuire: $\mathbb{E}[R^e_i] = \mathrm{Cov}(R^e_i, \mathrm{f}_t)^\top \mathrm{b} = \boldsymbol{\beta}_i^\top \boldsymbol{\lambda}$ cu $\boldsymbol{\lambda} = \boldsymbol{\Sigma}_f \mathrm{b}$: modelul de evaluare prin beta din Secțiunea 6
- Testul $\mathrm{b} = 0$ arată dacă un factor ajută la evaluarea activelor, ținînd cont de ceilalți factori
- Testul $\boldsymbol{\lambda} = 0$ arată dacă expunerea la factor este remunerată
- Aceste condiții de momente se estimează prin GMM, Hansen (1982) (GMM pe scurt: aici $\mathrm{g}_t(\mathrm{b}) = m_t(\mathrm{b})\,\mathrm{R}^e_t$)
- O sinteză a acestei perspective: Cochrane (2011)

Compararea modelelor: rapoarte Sharpe maxime *(aprofundare)*

Raport Sharpe maxim (anual)	CAPM	FF3	Carhart	FF5	FF5 + MOM
1963–2026 ($T = 757$)	0,47	0,66	0,97	0,97	1,16
2000–2026 ($T = 319$)	0,48	0,54	0,67	0,97	1,02

- Barillas & Shanken (2018): modelul mai bun este cel ai cărui factori permit cel mai mare raport Sharpe, $SR^2(\mathrm{f}) = \boldsymbol{\mu}_f^\top \boldsymbol{\Sigma}_f^{-1} \boldsymbol{\mu}_f$ ($\boldsymbol{\mu}_f$, $\boldsymbol{\Sigma}_f$: mediile și covarianța factorilor)
- Comparația nu depinde de alegerea activelor de test
- Cînd un model îl include pe celălalt, SR^2 în eșantion nu poate decît să crească
- Atunci se face o **regresie de spanning**: factorul adăugat se regresează pe ceilalți; un alfa nenul arată că el aduce ceva nou
  - HML pe ceilalți cinci factori: $\alpha = 0{,}9\%$ pe an ($t = 0{,}75$)
  - din 2000: $\alpha = -1{,}7\%$ ($t = -0{,}81$), deci nicio contribuție incrementală semnificativă a HML, ca în Fama & French (2015)
- FF5 față de Carhart (niciunul nu îl include pe celălalt): diferența dintre SR^2 anuale este 0,00, cu intervalul de 95% $[-0{,}57; 0{,}66]$
- Din 2000: diferența este 0,50, cu intervalul de 95% $[-0{,}24; 1{,}48]$, deci nici aici nu este semnificativă (bootstrap staționar, Politis & Romano (1994); Seminarul 3, problema B8)
- O altă măsură comună tuturor modelelor, distanța Hansen–Jagannathan: ▸ Anexă

Factor zoo

- Cochrane (2011) a numit lista tot mai lungă de factori noi un *factor zoo*
- Harvey, Liu & Zhu (2016) catalogează sute de factori publicați (316 în lista lor)
- Fiecare factor a fost testat ca și cum ar fi fost singurul încercat: $|t| > 1{,}96$ la 5%
- Cu multe teste, unii factori trec pragul din întîmplare
- **Data mining** (sau p-hacking): căutarea printre multe variante pînă cînd una pare semnificativă
- Propunerea lor: un factor nou are nevoie de $|t| > 3{,}0$

Controlul descoperirilor false

- **FDR** (False Discovery Rate, rata descoperirilor false): ponderea așteptată a respingerilor false în totalul respingerilor
- **FWER** (Family-Wise Error Rate, rata erorii pe familia de teste): probabilitatea de a avea cel puțin o respingere falsă (Capitolul 2)
- Notațiile tabelului: M: numărul de teste
- α: nivelul de semnificație (nu o eroare de evaluare)
- $p_{(\mathbf{1})} \leq \cdots \leq p_{(M)}$: p-value-urile ordonate
- $H_{(j)}$: ipoteza cu al j-lea cel mai mic p-value
- **BH**: procedura Benjamini–Hochberg; **BY**: procedura Benjamini–Yekutieli

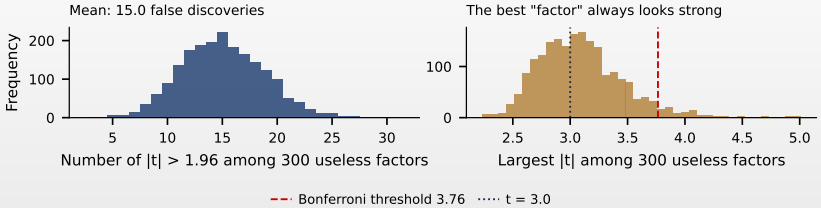
Procedura	**Controlează**	**Respinge $H_{(j)}$ dacă**	**Validă pentru**
Bonferroni	FWER	$p_{(j)} \leq \alpha/M$	orice dependență
Holm (Holm (1979))	FWER	$p_{(k)} \leq \alpha/(M-k+1)$, $\forall k \leq j$	orice dependență
BH (Benjamini & Hochberg (1995))	FDR	$j \leq$ cel mai mare k cu $p_{(k)} \leq k\alpha/M$	dependență pozitivă
BY (Benjamini & Yekutieli (2001))	FDR	ca BH, pragurile împărțite la $\sum_{k=\mathbf{1}}^{M} 1/k$	orice dependență

- Dependență pozitivă: statisticile de test tind să crească împreună; independența este un caz particular (condiția tehnică se numește PRDS, Positive Regression Dependence on a Subset, Benjamini & Yekutieli (2001))
- FWER: potrivit cînd nicio descoperire falsă nu este acceptabilă
- FDR: potrivit cînd căutăm printre mulți factori candidați și acceptăm o mică proporție de descoperiri false

Exemplu rezolvat: zece factori candidați

- p-value-uri ordonate: 0,0004; 0,002; 0,006; 0,011; 0,018; 0,027; 0,041; 0,070; 0,15; 0,62
- nivel de semnificație $\alpha = 5\%$
- Naiv ($p \leq 0{,}05$): **7** descoperiri
- Bonferroni ($p \leq 0{,}005$): **2**
- Holm compară p-value-urile, pe rînd, cu 0,05/10, 0,05/9, 0,05/8, ...: $0{,}0004 \leq 0{,}005$, $0{,}002 \leq 0{,}0056$, $0{,}006 \leq 0{,}00625$, apoi $0{,}011 > 0{,}0071$ și se oprește: **3**
- BH compară $p_{(j)}$ cu $0{,}005j$; ultimul p-value sub prag este $p_{(6)} = 0{,}027 \leq 0{,}030$: **6**
- Seminarul 3, problema A1 repetă procedura pe un alt vector, cu un grafic al pragurilor

Simulare: 300 de factori inutili



Legenda: false discoveries: descoperiri false; The best "factor" always looks strong: cel mai bun „factor" pare întotdeauna puternic; Bonferroni threshold: pragul Bonferroni

- 2 000 de replicări, fiecare cu 300 de statistici t independente din distribuția Normală standard (fără primă reală)
- În medie, 15,0 factori inutili trec pragul $|t| > 1{,}96$, cît se așteaptă: $300 \times 0{,}05 = 15$
- În medie, 0,83 factori inutili trec pragul $|t| > 3$
- Cel puțin un factor inutil trece acest prag în 57% din replicări
- Mediana celui mai mare $|t|$ dintr-o replicare este 3,06
- Pragul Bonferroni pentru 300 de teste: $|t| > 3{,}76$
- Pragul corect depinde de cîte teste s-au încercat efectiv, inclusiv cele nepublicate

MFM_ch3_false_discoveries

Verificare rapidă: numărarea descoperirilor

- Cinci factori candidați, p-value-uri ordonate 0,004; 0,012; 0,020; 0,030; 0,200; nivel de semnificație $\alpha = 5\%$
  1. Cîte descoperiri dau regula naivă, Bonferroni, Holm și BH? Scrieți fiecare prag cu care comparați
  2. La BY, pragurile BH se împart la $1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \frac{1}{5}$: cîte descoperiri rămîn?
  3. Dacă toate cele cinci ipoteze nule ar fi adevărate și testele independente, care este probabilitatea ca cel puțin un p-value să fie sub 0,05?
- Ce număr ați raporta pentru o căutare printre mulți factori candidați?
- Ce număr ați raporta pentru afirmația că **niciun** factor găsit nu este fals?
- Răspunsuri: ▸ Anexă

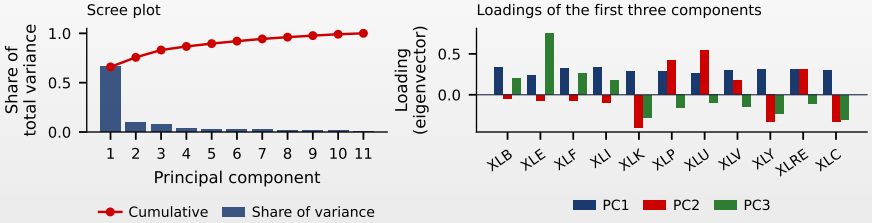
Componentele principale, pe scurt

- **Factori latenți**: factori neobservați, estimați doar din randamente, fără a spune dinainte ce reprezintă
- **PCA** (Principal Component Analysis, analiza componentelor principale) a matricei de corelație C a randamentelor standardizate

$$\mathsf{C} = \mathbf{\Gamma}\mathsf{D}\mathbf{\Gamma}^\top, \qquad \mathsf{y}_t = \mathbf{\Gamma}^\top \mathsf{z}_t$$

  - z_t: randamentele standardizate ale zilei t
  - y_t: componentele
  - $\mathbf{\Gamma}$: vectorii proprii pe coloane
  - D: matricea diagonală a valorilor proprii ℓ_k
- Valorile proprii, ordonate: $\ell_1 \geq \cdots \geq \ell_N$ (notate ℓ, ca să nu se confunde cu primele de risc λ)
- Vectorii proprii sînt **încărcările**
- Componenta k explică ℓ_k/N din varianța totală
- Exemplu, două active cu corelația ρ: $\ell = 1 \pm \rho$; vectorul $(1,1)/\sqrt{2}$ este „piața", iar $(1,-1)/\sqrt{2}$ este diferența dintre ele
- În criză ρ crește și prima componentă domină
- Manual: Härdle & Simar (2019), capitolul despre componente principale
- N active cu corelații egale: Seminarul 3, problema A8

PCA pe ETF-urile sectoriale din SUA



Legenda: Scree plot: graficul valorilor proprii; Share of variance: ponderea în varianță; Cumulative: cumulat; Loadings of the first three components: încărcările primelor trei componente

- 11 ETF-uri sectoriale, randamente logaritmice zilnice, 20 iunie 2018 – 18 septembrie 2026 ($T = 2\,073$ zile comune)
- Prima componentă principală (PC1) explică 66,0% din varianță
- Toate încărcările PC1 sînt pozitive, între 0,24 și 0,34
- Corelația PC1 cu SPY este 0,954: prima componentă este, practic, factorul pieței
- A doua componentă, PC2 (9,7%): utilități $+0{,}55$, bunuri de larg consum $+0{,}42$, imobiliare $+0{,}31$ față de tehnologie $-0{,}40$, consum discreționar $-0{,}33$: **sectoare defensive față de sectoare de creștere**, deși PCA nu a primit nicio etichetă
- A treia componentă, PC3 (7,4%), este dominată de energie, iar primele trei componente explică 83,1%

MFM_ch3_pca

Numărul de factori *(aprofundare)*

- Model factorial aproximativ $x_{it} = \mathbf{\Lambda}_i^\top \mathsf{F}_t + e_{it}$, cu numărul de active N și de perioade T ambele mari
  - x_{it}: randamentul standardizat, F_t: factorii, $\mathbf{\Lambda}_i$: încărcările, e_{it}: partea idiosincratică
  - $V(k)$: media pătratelor reziduurilor după primele k componente
  - ℓ_k: a k-a cea mai mare valoare proprie
- Bai & Ng (2002): alege k care minimizează $\ln V(k) + k\,\frac{N+T}{NT}\ln\min(N,T)$ (criteriul de informație IC_{p2}: potrivire plus o penalizare pe factor)
- Ahn & Horenstein (2013): alege k unde raportul ℓ_k/ℓ_{k+1} este maxim, adică acolo unde valorile proprii scad cel mai brusc
- Regula lui Kaiser (1960) ($\ell_k > 1$) nu are o justificare teoretică: chiar și zgomotul pur produce valori proprii împrăștiate în jurul lui 1

Panel	N	T	Kaiser	Bai–Ng	Ahn–Horenstein
11 ETF-uri sectoriale, zilnic 2018–2026	11	2 073	2	5	1
100 portofolii mărime × B/M, lunar 1963–2026	95	757	3	4	1

- Randamente standardizate, cu cel mult $k = 5$ factori pentru sectoare și $k = 8$ pentru portofolii (5 portofolii cu luni lipsă sînt eliminate)
- Ahn–Horenstein alege doar factorul pieței (raport 14,6); al doilea vîrf este la $k = 3$ (raport 3,5), ca în FF3
- Bai–Ng pe 11 sectoare alege numărul maxim permis, $k = 5$: penalizarea este gîndită pentru multe active, deci cu doar 11 răspunsul nu este de încredere (▸ Anexă)

Limitele PCA în evaluarea activelor

- Încărcările sînt **constante**: PCA nu poate urmări o acțiune a cărei mărime sau valoare se schimbă
- Componentele explică **varianța**, nu neapărat **randamentele medii**
- Acțiunile individuale intră și ies din eșantion (listări, delistări), deci lipsesc multe observații, iar PCA clasic cere un panel complet
- Semnul fiecărei componente este arbitrar: $-\gamma_k$ este la fel de bun ca γ_k
- Factorii latenți sînt determinați doar pînă la o rotație: orice combinație rotită a lor explică datele la fel de bine, deci interpretarea lor este o alegere
- Două extensii ale PCA țin cont și de randamentele medii: PCA cu primă de risc și estimatorul în trei etape (▸ Anexă)
- PCA și analiza factorială în finanțe: Franke, Härdle & Hafner (2019)

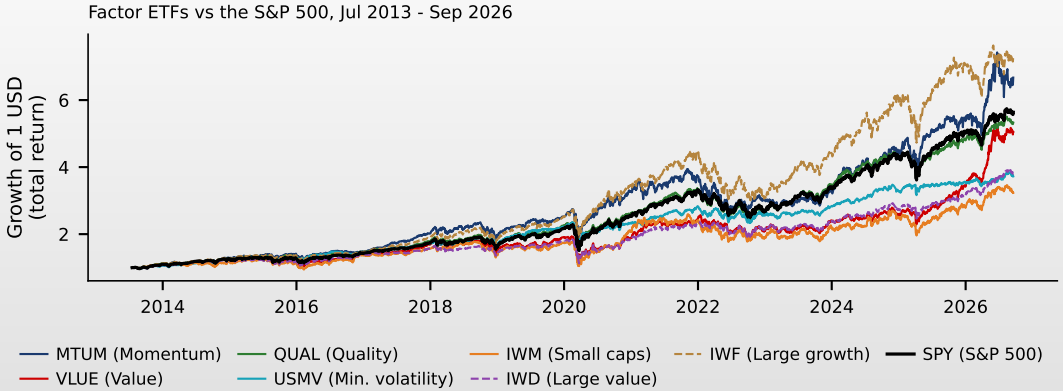
PCA instrumentată *(aprofundare)*

- **IPCA**: Instrumented Principal Component Analysis (PCA instrumentată), Kelly, Pruitt & Su (2019)
- Încărcările sînt funcții de L caracteristici observate $z_{i,t}$ (mărime, B/M, momentum, ...)

$$R^e_{i,t+1} = \alpha_{i,t} + \boldsymbol{\beta}^\top_{i,t} f_{t+1} + \varepsilon_{i,t+1}, \qquad \boldsymbol{\beta}^\top_{i,t} = z^\top_{i,t} \boldsymbol{\Gamma}_\beta$$

- $\boldsymbol{\Gamma}_\beta$ ($L \times K$) și factorii latenți f_t se estimează împreună, alternativ: factorii fiind dați se estimează $\boldsymbol{\Gamma}_\beta$, apoi invers
- Întrebarea testată: prezic caracteristicile randamentele pentru că măsoară expunerea la risc (prin beta) sau direct, ca alfa ($\alpha_{i,t} = z^\top_{i,t} \boldsymbol{\Gamma}_\alpha$)?
- Rezultatul, pe acțiuni americane: cîțiva factori IPCA explică randamentele medii mai bine decît modelele cu tot atîția factori observați
- $\boldsymbol{\Gamma}_\alpha$ nu este semnificativ, de unde titlul articolului: „caracteristicile sînt covariațe"
- Factorii criptoactivelor: ▸ Anexă

ETF-urile factoriale față de piață (1/2)



MFM_ch3_factor_etfs

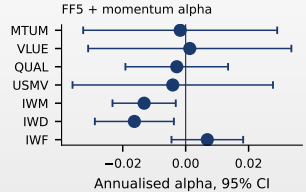
ETF-urile factoriale față de piață (2/2)

- **Smart beta**: ETF-uri care cumpără acțiuni după reguli fixe, ca să aibă o expunere mai mare la un factor; nu vînd nimic în lipsă (doar long)
  - păstrează deci expunerea la piață și nu reproduc exact factorul academic long–short
- Treisprezece ani reprezintă o singură traiectorie istorică, prea scurtă pentru a respinge primele factorilor

- **CAGR** (Compound Annual Growth Rate, rata anuală compusă de creștere), $(V_T/V_0)^{1/n} - 1$ pe n ani, a unei investiții de 1 USD (dolar american), cu dividende reinvestite, din 18 iulie 2013
  - peste SPY (14,0%): firmele mari de creștere (IWF) 16,3%, momentum (MTUM) 15,5%
  - sub SPY: calitate (QUAL) 13,5%, valoare (VLUE) 13,1%, firme mari de valoare (IWD) 10,7%, volatilitate minimă (USMV) 10,5%, firme mici (IWM, indicele Russell 2000) 9,3%
  - Indicii Russell: Russell 1000 cuprinde cele mai mari 1000 de acțiuni americane, cu subindici de valoare (IWD) și de creștere (IWF); Russell 2000 cuprinde următoarele 2000, firme mai mici (IWM)

MFM_ch3_factor_etfs

Valorile alfa ale ETF-urilor factoriale



Factor loadings

	Mkt-RF	SMB	HML	RMW	CMA	MOM
MTUM	1.03	-0.12	0.01	-0.22	-0.05	0.36
VLUE	0.98	0.08	0.34	-0.06	0.09	-0.03
QUAL	0.97	-0.08	-0.04	0.15	0.03	-0.04
USMV	0.74	-0.11	-0.02	0.20	0.21	-0.02
IWM	1.04	0.85	0.08	-0.10	-0.02	0.03
IWD	0.94	-0.04	0.29	0.09	0.19	-0.04
IWF	1.03	-0.11	-0.28	-0.03	-0.12	-0.00

- Regresii zilnice pe cei șase factori (FF5 + MOM), erori Newey–West, fiecare ETF pe propriile zile de tranzacționare, în perioada 2000–2026
- În grafic, valorile alfa sînt fracții anuale ($0.02 = 2\%$)
- Încărcările corespund denumirilor: MTUM pe MOM 0,36, VLUE pe HML 0,34, IWM pe SMB 0,85
- IWF (growth) are încărcarea $-0{,}28$ pe HML
- USMV (volatilitate minimă) are beta de piață 0,74
- Valori alfa aproape de zero: MTUM $-0{,}2\%$ ($t = -0{,}11$), QUAL $-0{,}3\%$
- ETF-urile Russell au valori alfa negative: IWM $-1{,}3\%$ ($t = -2{,}57$), IWD $-1{,}6\%$ ($t = -2{,}54$), explicabile prin comisioane și prin regulile de construcție a indicelui
- R^2 între 0,81 și 0,97: ETF-urile factoriale vînd, în mare parte, expuneri la factori cunoscuți (Seminarul 3, problema B11)

MFM_ch3_etf_alphas

Factor timing, crowding și costuri

- **Factor timing**: mutarea capitalului între factori după semnale, de exemplu cît de ieftin este un factor sau cum a evoluat recent
  - Primele sînt incerte și seriile scurte, deci este greu de demonstrat că factor timing funcționează în afara eșantionului (Capitolul 8)
- **Crowding** (aglomerarea pozițiilor): mulți investitori dețin aceleași poziții factoriale
  - Primele se pot micșora (McLean & Pontiff (2016)), iar crowding-ul poate amplifica pierderile la lichidări forțate
  - Crahul de momentum din 2009 a coincis cu o revenire bruscă a fostelor acțiuni perdante (Daniel & Moskowitz (2016))
- **Implementarea**: randamentele factorilor academici nu scad costurile de tranzacționare și costul împrumutului acțiunilor vîndute în lipsă
- Un ETF plătește aceste costuri, deci randamentul lui este mai mic

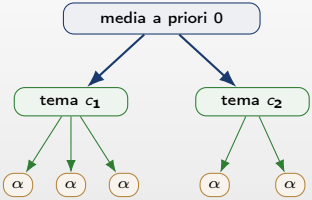
Se replică factorii publicați?

- **Două critici** la adresa cercetării despre factori (Jensen, Kelly & Pedersen (2023), Introducere)
  - Rezultatele nu se pot reproduce: Hou, Xue & Zhang (2020) reușesc să replice doar 35% dintre anomaliile studiate
  - Rezultatele sînt produsul testării multor factori fără corecție: Harvey, Liu & Zhu (2016) conchid că majoritatea descoperirilor raportate sînt probabil false
- **Anomalie**: un randament mediu pe care CAPM nu îl explică
- **Întrebările**
  - au factorii publicați valori alfa CAPM semnificative în datele originale?
  - sînt aceste valori alfa semnificative în afara eșantionului și în alte țări?
  - rămîn ele semnificative după ce se ține cont de testarea multiplă?

De ce contează replicarea pentru acest capitol

- **Relevanța**
  - dacă majoritatea factorilor sînt descoperiri false, modelele multifactoriale și investițiile factoriale (Secțiunile 5 și 10) se sprijină pe zgomot
- **O a doua perspectivă asupra factor zoo** (Feng, Giglio & Xiu (2020), Anexă)
  - majoritatea factorilor noi nu aduc nimic în plus față de cei existenți
  - Jensen, Kelly & Pedersen văd în schimb factor zoo ca multe măsurători corelate ale acelorași cîteva teme economice
- **Legătura cu acest capitol**
  - alfa lui Jensen (Secțiunea 4) este mărimea testată
  - corecția Benjamini–Yekutieli (Secțiunea 8) este reperul clasic (non-bayesian)
  - shrinkage-ul bayesian aplică valorilor alfa aceeași idee ca Vasicek pentru beta (Secțiunea 3)

153 de factori grupați în 13 teme *(aprofundare)*



alfa fiecărui factor împrumută informație de la ceilalți factori ai temei sale

- **Date** (Secțiunea II): 153 de factori în 93 de țări
  - acțiunile sînt împărțite în treimi după fiecare caracteristică, cu ponderi după capitalizare, plafonate
  - se cumpără treimea care avea randamentul mai mare în studiul inițial și se vinde cealaltă treime extremă
  - fiecare factor este scalat la o volatilitate specifică (necorelată cu piața) de 10% pe an, ca valorile alfa să fie comparabile
- **Teme**: 13 grupe de factori americani
  - grupare ierarhică (clustering): factorii ale căror reziduuri CAPM sînt puternic corelate intră în aceeași temă
- **Modelul** (Secțiunea I): $f_{i,t} = \alpha_i + \beta_i r_t^m + \varepsilon_{i,t}$
  - $f_{i,t}$: randamentul factorului i
  - r_t^m: randamentul în exces al pieței
  - alfa fiecărui factor este o sumă: $\alpha_i = c_j + s_n + w_i$ (componenta temei, a semnalului și a factorului), cu media a priori 0

Shrinkage pentru alfa și rata de replicare *(aprofundare)*

- Cazul unui singur factor: alfa estimat este micșorat spre zero (ecuația 5 din articol)

$$\mathbb{E}(\alpha \mid \hat{\alpha}) = \kappa\hat{\alpha}, \qquad \kappa = \frac{1}{1 + \sigma^2/(\tau^2 T)}$$

  - σ: volatilitatea reziduurilor
  - τ: dispersia valorilor alfa adevărate
  - T: numărul de luni
  - eșantioanele scurte și zgomotoase primesc mai mult shrinkage, ca la Vasicek (Secțiunea 3): σ^2/T joacă rolul lui $\mathrm{se}(\hat{\beta}_i)^2$, iar τ^2 pe cel al lui σ^2_β

- **Rata de replicare**: dintre factorii semnificativi în studiile inițiale, ce proporție are alfa semnificativ și în datele noi
  - în varianta bayesiană, un factor este „semnificativ" dacă media a posteriori împărțită la abaterea standard a posteriori este cel puțin 1,96

- Ierarhia completă și estimarea: ▸ Anexă

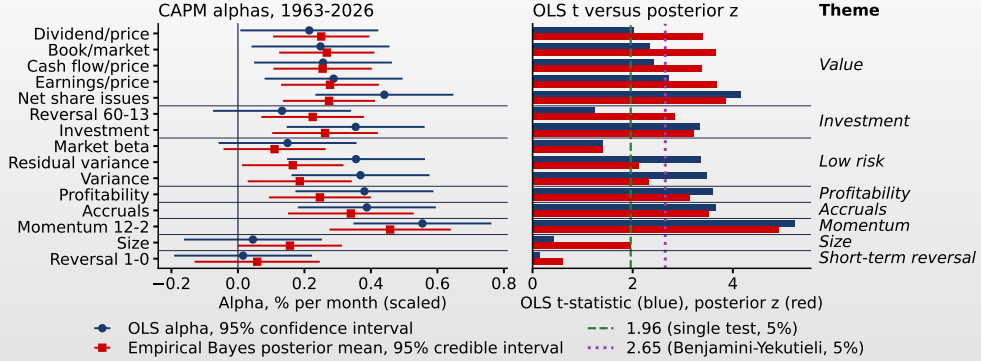
Majoritatea factorilor se replică, dar scad după publicare

Rate de replicare, SUA (Figura 1)

Hou, Xue & Zhang (2020), randamente brute	35,0%
Jensen, Kelly & Pedersen, randamente brute	55,6%
Randamente brute, 119 semnificativi inițial	61,3%
Alfa CAPM, OLS	82,4%
Alfa CAPM, Benjamini–Yekutieli	75,6%
Alfa CAPM, Bayes empiric	82,4%
Global, Bayes empiric	82,4%

- De la 35% la 82%, pas cu pas, față de Hou, Xue & Zhang (2020)
  - eșantion mai lung, 15 factori în plus, altă construcție: 55,6%
  - doar factorii semnificativi în studiile inițiale: 61,3%
  - alfa CAPM în locul randamentelor brute, cel mai mare pas: 82,4%
- Bayes empiric dă tot 82,4%: micșorarea spre zero pierde unele descoperiri, informația împrumutată de la temă adaugă altele, iar efectele se compensează
- Proporția estimată de descoperiri false (FDR bayesian) este doar 0,1%, fără a ridica pragul t
- **Scăderea** după perioada studiului inițial
  - alfa mediu: 0,49% pe lună în eșantion, 0,26% după aceea (-47%)
  - regresia valorilor alfa ulterioare pe cele din eșantion are panta 0,26 (Figura 8); shrinkage-ul singur ar explica o pantă de circa 0,9
- Cei mai puternici factori scad cel mai mult: semn de arbitraj sau de data mining (Secțiunea 12)
- Rezultatele complete: ▸ Anexă

Se replică 15 factori americani? (1/2)



Legenda: OLS alpha, 95% confidence interval: alfa OLS cu intervalul de încredere; Empirical Bayes posterior mean, 95% credible interval: media a posteriori Bayes empiric cu intervalul de credibilitate; OLS t versus posterior z: t OLS față de z a posteriori; Theme: tema

MFM_ch3_jkp_replication

Se replică 15 factori americani? (2/2)

- 15 factori americani long–short din sortările ponderate după valoare ale Kenneth French Data Library, iulie 1963 – iulie 2026 ($T = 757$)
- Valorile alfa CAPM sînt scalate la o volatilitate idiosincratică de 10%
- Factorii sînt grupați pe temele articolului (etichetele autorilor)
- Rate de replicare
  - OLS: 73,3% (11 din 15 factori)
  - Benjamini–Yekutieli: 53,3% (8 factori; $|t|$ critic 2,65)
  - Bayes empiric: 86,7% (13 factori)
- Shrinkage-ul trage alfa spre media temei, nu doar spre zero
- Exemplu: inversarea pe termen lung (tema investiții) crește de la 0,13% la 0,23% pe lună; t OLS este 1,25, dar z a posteriori este 2,85
- Nu se replică: beta de piață și inversarea pe termen scurt ($z \leq 1{,}41$)
- Mărimea trece la limită ($z = 1{,}96$); și în articol mărimea este una dintre cele două teme cu rata sub 50%
- Rata se calculează aici pe toate cele 15 semnale, fără a verifica dacă fiecare a fost semnificativ în studiul inițial
- Detalii: Anexă; țintă de replicare pentru Seminarul 3, problema C3

MFM_ch3_jkp_replication

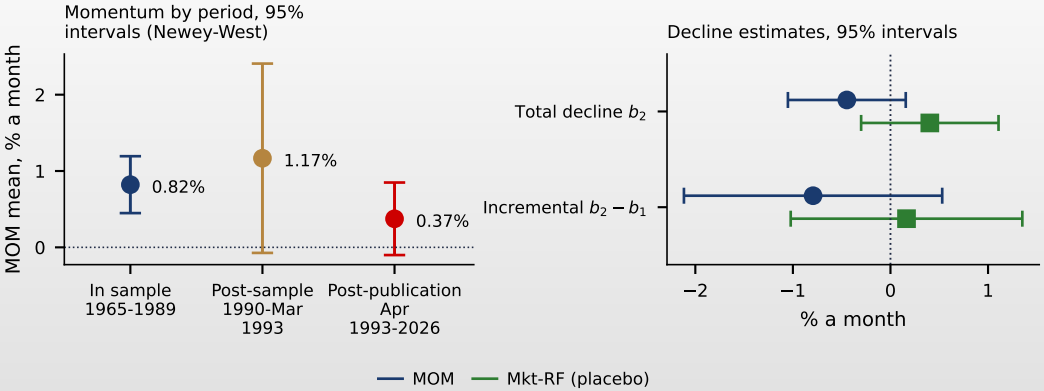
Ce nu poate arăta replicarea din curs

- **Limitele versiunii de curs**
  - 15 semnale americane în loc de 153 în 93 de țări
  - portofoliile din Kenneth French Data Library, nu treimile construite fără firmele foarte mici (microcapitalizări)
  - o singură țară, deci fiecare semnal apare o singură dată și componenta semnalului nu se poate estima ($\tau_s = 0$)
  - rezultatul depinde de gruparea pe teme: dacă toți factorii ar fi într-o singură temă, rata Bayes empiric ar fi 100%
- **Limite precizate de autori** (Anexă)
  - CAPM este singurul model de referință
  - toate caracteristicile sînt construite după aceeași metodă
  - distribuția a priori nu ține cont de factorii nepublicați
- **Întrebări deschise** (datele articolului se opresc în 2020)
  - s-au menținut valorile alfa și rata de replicare în 2021–2026?
  - pot factorii americani, folosiți ca distribuție a priori, să îmbunătățească estimările factorilor de la BVB, unde seriile sînt scurte?
- Datele și codul articolului: jkpfactors.com
- Proiectul de curs: Seminarul 3, C3

Întrebări deschise și bucla descoperirii

- **Întrebări deschise**
  - de ce scad primele factorilor după publicare: arbitraj, data mining sau o schimbare a riscului?
  - diferă scăderea între factori și piețe?
- Stadiul cunoașterii
  - McLean & Pontiff (2016): pe 97 de predictori, randamentele sînt cu 26% mai mici în afara eșantionului și cu 58% mai mici după publicare
  - autorii atribuie diferența investitorilor care tranzacționează pe baza articolelor publicate
  - Jensen, Kelly & Pedersen (2023): majoritatea factorilor se replică, dar cei mai puternici scad cel mai mult
  - Chen & Zimmermann (2022): date și cod deschise pentru predictorii publicați
- **Bucla descoperirii, parcursă o dată**
  - Asistentul AI propune: un tabel al literaturii cu DOI (Digital Object Identifier, identificator digital de obiect), ipoteze concurente și ce prezice fiecare, codul regresiei, un plan de robustețe
  - Cercetătorul fixează înainte de rulare: datele evenimentelor (Jegadeesh & Titman (1993): eșantionul se termină în 1989, articolul apare în martie 1993), lista factorilor, corecția pentru testarea multiplă și testul placebo (un factor la care nu ar trebui să apară efectul)
  - Verificări: fiecare link DOI funcționează
  - Statisticile t pe subperioade din capitol se reproduc întîi
  - Se notează versiunea datelor
- Prompturi reutilizabile și lista completă de verificări: Anexă

Ministudiu de caz: arbitrajul și declinul momentum-ului (1/2)



MFM_ch3_ai_discovery

Ministudiu de caz: arbitrajul și declinul momentum-ului (2/2)

- Specificația din McLean & Pontiff (2016): $\text{MOM}_t = a + b_1\text{PostSample}_t + b_2\text{PostPub}_t + e_t$, lunar, ianuarie 1965 – august 2026 ($T = 740$), erori Newey–West
- După eșantion: ianuarie 1990 – martie 1993
- După publicare: din aprilie 1993
- PostSample_t, PostPub_t: variabile dummy (indicatori 0/1) egale cu 1 în aceste perioade
- a: media din eșantion
- b_2: scăderea totală față de media din eșantion
- $b_2 - b_1$: efectul incremental al publicării
- Media momentum în eșantion: $a = 0{,}82\%$ pe lună ($t = 4{,}32$)
- Scăderea după publicare: $b_2 = -0{,}45\%$ ($t = -1{,}45$, interval $[-1{,}05\%; 0{,}16\%]$), adică o medie cu 54% mai mică
- Efectul incremental al publicării: $b_2 - b_1 = -0{,}79\%$ ($t = -1{,}17$)
- Placebo pe Mkt-RF: $b_2 = +0{,}40\%$ ($t = 1{,}12$)
- Scăderea este apropiată de 58% din McLean & Pontiff (2016), dar cu un singur factor nu putem respinge $H_0 : b_2 = 0$ la 5%
- Arbitrajul este o interpretare posibilă, nu o cauză demonstrată

MFM_ch3_ai_discovery

Proiect: descoperirea unui factor

- **Întrebări**
  - scad primele factorilor Fama–French și momentum după publicare?
  - diferă scăderea între factori?
- **Metoda**
  - o regresie comună pentru SMB, HML, RMW, CMA și MOM, cu variabile dummy proprii fiecărui factor pentru perioadele după eșantion și după publicare
  - Mkt-RF ca placebo
  - Erori robuste la corelația dintre factori și la autocorelație
  - dacă scăderea este mai mare acolo unde arbitrajul este mai ușor se poate testa doar cu date la nivel de acțiune (mărime, lichiditate, costul vînzării în lipsă)
- **Replicați întîi**: statisticile t pe subperioade și estimațiile din ministudiul de caz

Proiect: datele eșantionului și rezultatele cerute

- **Livrabile**
  - mai întîi, un tabel al evenimentelor: factorul, lucrarea inițială cu DOI, sfîrșitul eșantionului ei, data publicării, toate citite din lucrare (rîndul-model: MOM, Jegadeesh & Titman (1993), eșantionul se termină în 1989, publicat în martie 1993)
  - o notă de preînregistrare (H_0, H_1, datele din tabel, lista factorilor, corecțiile), salvată în Git (commit) înainte de a vedea rezultatele
  - codul ca Quantlet: un director cu scriptul, sursa datelor și o scurtă descriere, ca în Quantlet-urile capitolului
  - un raport cu erori Newey–West, perioade placebo și puterea testului
  - puterea: probabilitatea de a respinge $b_2 = 0$ la 5% dacă scăderea reală ar fi, de exemplu, cei 58% din McLean & Pontiff (2016); prin simulare sau aproximativ $\Phi(\delta/\,\mathrm{se}(b_2) - 1{,}96)$ (δ: scăderea presupusă; Φ: funcția de repartiție a distribuției Normale standard)
- **Jurnale**: prompturile în `AI_USE.md`
- Erorile depistate în `AI_ERRORS.md`

Idei principale: un flux de lucru empiric

1. **Estimați expunerile** cu erori HAC, raportați eșantionul și aproximarea pieței, aplicați shrinkage valorilor beta extreme (Blume, Vasicek)
2. **Testați toate valorile alfa deodată**: GRS măsoară cît crește raportul Sharpe cînd adăugăm activele de test
   - CAPM eșuează pe cele 25 de portofolii mărime $\times$ B/M (SML plată, GRS $= 4{,}20$)
3. **Estimați primele** în două etape, cu erori care țin cont că beta este estimat și că modelul poate fi greșit
   - un R^2 mare pe cele 25 de portofolii nu dovedește mare lucru
4. **Protejați-vă de factor zoo**: praguri corectate pentru testarea multiplă, regresii de spanning, compararea modelelor prin raportul Sharpe maxim
5. **Replicați**: factori latenți și dovezi în afara eșantionului
   - ETF-urile factoriale oferă expunere factorială ieftină, nu alfa

⊡ Întrebări deschise

- de ce scad primele după publicare?
- cum se evaluează activele cu beta variabil în timp?
- ce factori explică randamentele așteptate pe piețe mici precum BVB?

Verifică-ți înțelegerea

Întrebări de verificare

- De ce diferă eroarea standard HAC a unui beta de cea clasică, deși beta nu se schimbă? (exemplul XLK)
- De ce poate GRS să nu respingă CAPM pe ETF-urile sectoriale, dar să-l respingă pe cele 25 de portofolii, în aceleași luni? (activele de test)
- De ce pare remunerat un factor inutil în etapa 2? (factori inutili)
- De ce poate rata de replicare Bayes empiric să depășească rata Benjamini–Yekutieli? (studiul de caz)

Unde continuă ideile

- Capitolul 2: un alfa este o anomalie sau un factor de risc omis, problema ipotezei comune
- Capitolul 4: modele factoriale de covariață și shrinkage pentru Markowitz
- Capitolele 5–6: volatilitate, corelații și beta variabile în timp
- Capitolul 8: backtesting pentru strategii factoriale fără overfitting
- Capitolul 13: machine learning pentru secțiunea transversală a randamentelor

GRS sub ipoteza nulă

- Sub H_0 și ipotezele exacte, $W \sim F(N, T-N-1)$, deci $\mathbb{E}[W] = \frac{T-N-1}{T-N-3}$
- Inversînd forma Sharpe a lui W, creșterea așteptată sub H_0 a pătratului raportului Sharpe este

$$\mathbb{E}\big[\widehat{SR}^2(f, \mathrm{R}) - \widehat{SR}^2(f)\big] \approx \frac{N\,(1 + \widehat{SR}^2(f))}{T-N-3}$$

- 25 de portofolii, $T = 757$: $25 \times 1{,}018/729 = 0{,}035$ (lunar), față de $0{,}405^2 - 0{,}134^2 = 0{,}146$ observat
- Adăugarea a N active crește întotdeauna raportul Sharpe în eșantion; testul verifică dacă această creștere depășește ce ar produce zgomotul
- 9 ETF-uri sectoriale, $T = 331$: cîștig observat $0{,}191^2 - 0{,}146^2 = 0{,}015$, sub cel așteptat, $9 \times 1{,}021/319 = 0{,}029$

înapoi

Teste pentru multe active

- $\hat{\mathbf{\Sigma}} = \hat{\mathbf{E}}^\top \hat{\mathbf{E}}/T$ are rangul cel mult $T - 2$ (doi parametri în fiecare regresie)
  - $\hat{\mathbf{E}}$: matricea $T \times N$ a reziduurilor
  - Exemplu: 100 de portofolii mărime $\times$ B/M pe 8 ani de date lunare ($T = 96$): $\hat{\mathbf{\Sigma}}$ este singulară, GRS nu există (Seminarul 3, problema B7)
  - Cu mult înainte de acest punct, inversa este estimată imprecis și puterea scade
- Teste pentru multe active care evită $\hat{\mathbf{\Sigma}}^{-1}$: sume standardizate ale pătratelor statisticilor t, Pesaran & Yamagata (2024)
- Creșterea puterii prin selecția valorilor alfa mari: Fan, Liao & Yao (2015)

înapoi

Erori standard robuste la specificarea greșită

- Erorile Fama–MacBeth și Shanken presupun un model **corect**: toate erorile de evaluare $e = \mu - X\gamma$ sînt zero ($X = [1, B]$)
- Aici GRS respinge modelul, deci γ nu are o valoare „adevărată": se estimează valoarea care minimizează erorile de evaluare (valoarea pseudo-adevărată)
- Zgomotul din $\hat{B}$ se înmulțește cu e și adaugă un termen de varianță (Kan, Robotti & Shanken (2013))
- Scriem ambele etape ca un singur sistem GMM exact identificat (GMM pe scurt): momentele $(R_t - a - Bf_t) \otimes (1, f_t)$ și $X^\top (R_t - X\gamma)$
  - varianța sandwich cu jacobianul complet este cea robustă
  - Cu $e = 0$ în jacobian se obține versiunea pentru un model corect specificat, robustă la heteroscedasticitate, a lui Jagannathan & Wang (1998)
- FF5 pe cele 25 de portofolii (RMW: slide-ul cu exemplul numeric): eroarea standard pentru CMA 2,2% → 2,7%, termenul liber 3,3% → 3,8%
- Pentru HML schimbarea este sub 0,05 puncte procentuale
- Curs avansat: Generalized Method of Moments

Înapoi

Distanța Hansen–Jagannathan și selecția bayesiană

- **Distanța Hansen–Jagannathan** (Hansen & Jagannathan (1997)): cît de departe este SDF-ul modelului de cel mai apropiat SDF care evaluează corect toate activele

$$\delta^2 = \min_{\mathrm{b}} \; \mathrm{e(b)}^\top \, \mathbb{E}[\mathrm{R}^e \mathrm{R}^{e\top}]^{-1} \, \mathrm{e(b)}, \qquad \mathrm{e(b)} = \mathbb{E}[m_t(\mathrm{b}) \, \mathrm{R}^e_t]$$

  - Randamente în exces R^e_t cu normalizarea $\mathbb{E}[m] = 1$
  - Pentru randamente brute R_t: $\mathrm{e} = \mathbb{E}[m\mathrm{R}] - 1$, iar SDF-ul are nevoie de o scală liberă ($\mathbb{E}[m] = 1/(1 + R_f)$)
  - Aceeași matrice de ponderare pentru orice model, deci distanțele sînt comparabile
  - Statistica de test are o limită χ^2 ponderată
- Selecție printre foarte multe modele: Bryzgalova, Huang & Julliard (2023) fac media bayesiană a circa 2×10^{15} de modele factoriale, robustă la factori slabi
- Kozak, Nagel & Santosh (2020) aplică shrinkage coeficienților SDF și găsesc că cîteva componente principale ale anomaliilor sînt suficiente
- Lecția comună: comparați toate modelele cu aceeași măsură și raportați incertitudinea ei

înapoi

Factor zoo redus prin LASSO cu dublă selecție

- Feng, Giglio & Xiu (2020): aduce un factor nou informație suplimentară față de factorii deja cunoscuți?
- **LASSO cu dublă selecție** (Least Absolute Shrinkage and Selection Operator)
  - LASSO: regresie cu o penalizare care pune exact la zero coeficienții variabilelor neimportante, deci selectează variabilele
  - Pasul 1: dintre sute de factori existenți, LASSO îi alege pe cei care explică randamentele medii ale activelor de test
  - Pasul 2: un al doilea LASSO îi alege pe cei corelați cu factorul nou, ca omiterea lor să nu distorsioneze rezultatul
  - Pasul 3: se testează coeficientul factorului nou în SDF, controlînd pentru toți factorii aleși în pașii 1 și 2
- Rezultat: majoritatea factorilor noi sînt redundanți
- Doar cîțiva factori noi explică randamente pe care cei vechi nu le explică
- Studiul de caz ajunge la o concluzie compatibilă: mulți factori sînt redundanți, iar informația se concentrează în cîteva teme

Înapoi

De ce nu concordă estimatorii numărului de factori

- Onatski (2010): un factor este real dacă valoarea lui proprie iese clar din intervalul în care cad valorile proprii ale zgomotului
- Regula Kaiser ($\ell_k > 1$) pe o matrice de corelație: pentru N active și zgomot pur, valorile proprii sînt dispersate în jurul lui 1 pe o lățime care depinde de N/T
- Bai–Ng cu $N = 11$ și $T = 2\,073$: penalizarea este $\frac{N+T}{NT} \ln 11 = 0{,}219$ pe factor
- Pe sectoare, criteriul $IC_{p2}(k)$ pentru $k = 0, \ldots, 5$ este 0; $-0{,}86$; $-0{,}97$; $-1{,}12$; $-1{,}14$; $-1{,}17$
- Criteriul scade pînă la maximul permis, $k_{\max} = 5$: penalizarea este prea mică pentru a opri adăugarea factorilor slabi
- Raportați intervalul estimațiilor și sensibilitatea la $k_{\max}$, nu un singur număr (Seminarul 3, problema B3)

Înapoi

PCA cu primă de risc și estimarea primelor în trei etape

- **RP-PCA** (Risk-Premium PCA, PCA cu primă de risc, Lettau & Pelger (2020)): componentele principale ale matricei $\frac{1}{T}X^\top X + \gamma \bar{x}\bar{x}^\top$
  - X: matricea $T \times N$ a randamentelor în exces, $\bar{x}$: mediile lor, γ: ponderea randamentelor medii
  - $\gamma = -1$ dă PCA pe covarianță
  - $\gamma > -1$ favorizează și factorii care explică randamentele medii
  - În datele autorilor, metoda găsește factori cu rapoarte Sharpe mai mari și erori de evaluare mai mici decît PCA
- **Estimatorul în trei etape** (Giglio & Xiu (2021)): prima unui factor observat g_t cînd modelul omite factori
  - (1) PCA pe randamentele activelor de test
  - (2) regresia transversală a mediilor pe valorile beta latente
  - (3) regresia lui g_t pe factorii latenți; prima lui g_t se obține din primele factorilor latenți și din coeficienții acestei regresii
- Ambele păstrează baza statistică a PCA, dar urmăresc explicarea randamentelor medii, nu doar a variației
- IPCA adaugă în plus caracteristicile activelor

Înapoi

IPCA și factorii criptoactivelor

- IPCA (Kelly, Pruitt & Su (2019)): caracteristicile prezic randamentele pentru că măsoară expunerea la risc
- IPCA leagă PCA (statistica) de sortările după caracteristici (Fama–French): beta variabil în timp, puțini factori
- Criptoactive: factorii piață, mărime și momentum evaluează secțiunea transversală a criptomonedelor (Liu, Tsyvinski & Wu (2022))
- Reducerea dimensionalității pe caracteristicile randamentelor criptoactivelor și activelor tradiționale: Pele et al. (2023), Jheng et al. (2026)
- Curs avansat: Multivariate Statistical Analysis

Înapoi

Construcția celor 153 de factori

- **Date** (Secțiunea II): 153 de factori în 93 de țări
  - 138 din lista alcătuită de Hou, Xue & Zhang (2020) și 15 din alte studii
  - randamente americane din 1926, majoritatea piețelor dezvoltate din 1986
  - toate în dolari americani, în exces față de rata titlurilor de stat americane pe termen scurt
- **Construcția**, în fiecare țară și lună
  - treimi după caracteristică, cu praguri calculate fără firmele foarte mici (microcapitalizări)
  - ponderi după capitalizarea plafonată la percentila 80 a NYSE
  - perioada de deținere: o lună
  - cel puțin 5 acțiuni pe fiecare parte și 60 de observații lunare
- **Teme**: 13 grupe de factori americani (Secțiunea II.B)
  - grupare ierarhică, cu distanța $1-$ corelația reziduurilor CAPM și metoda Ward (unește grupele care cresc cel mai puțin varianța din interiorul grupelor)

Înapoi

Ierarhia bayesiană a valorilor alfa

- **Modelul** (Secțiunea I): $f_{i,t} = \alpha_i + \beta_i r_t^m + \varepsilon_{i,t}$
  - valorile alfa $\alpha_i = c_j + s_n + w_i$ (tema j, semnalul n, factorul i; ec. 21), media a priori 0
  - varianța a priori $\mathbf{\Omega} = \mathrm{M}\mathrm{M}^\top \tau_c^2 + \mathrm{Z}\mathrm{Z}^\top \tau_s^2 + \mathrm{I}\tau_w^2$ (ec. 23)
  - media a posteriori $(\mathbf{\Omega}^{-1} + T\mathbf{\Sigma}^{-1})^{-1} T\mathbf{\Sigma}^{-1}\hat{\boldsymbol{\alpha}}$ (Propoziția 4)
  - M, Z: matrice 0/1 care leagă fiecare factor de tema și semnalul lui
  - $\tau_c^2, \tau_s^2, \tau_w^2$: variațele celor trei componente ale lui alfa
  - $\mathbf{\Sigma}$: covarianța reziduurilor
  - estimare Bayes empirică: τ_c, τ_s, τ_w prin verosimilitate maximă pentru $\hat{\boldsymbol{\alpha}} \sim N(0, \mathbf{\Omega} + \hat{\mathbf{\Sigma}}/T)$ (Secțiunea I.C.2)
- **Rata de replicare**
  - ponderea factorilor semnificativi în studiile inițiale al căror alfa este semnificativ în datele noi

Înapoi

Rezultatele complete

- Randamente brute, doar cei 119 factori semnificativi în studiile inițiale: 61,3% (Figura 1)
- Cu OLS se replică 98 din 119 factori americani
- Corecția Benjamini–Yekutieli cere $|t| > 2{,}7$ (Figura 4)
- FDR bayesian: 0,1%, cu intervalul de 95% $[0; 1\%]$
- Ponderea așteptată a factorilor adevărați: 94% (Secțiunea III.C)
- Rata de replicare pentru firmele cu capitalizare foarte mare și mare: 77,3% și 79,8% (Figura 5)
- 11 din 13 teme au o rată de cel puțin 50%; excepțiile sînt îndatorarea redusă și mărimea
- Rata mare și la firmele mari arată că rezultatul nu vine doar din firmele foarte mici
- Raportul Sharpe (lunar) al portofoliului tangent, SUA 1972–2020: piața 0,13, toți factorii 0,80 (Figura 14)

Înapoi

Replicarea din curs în detaliu

- Benjamini–Yekutieli dă cea mai mică rată, ca în rezultatele americane din articol (Figura 1)
- Emisiunile nete de acțiuni sînt trase spre media temei lor: de la 0,44% la 0,27% pe lună
- Abaterea standard a posteriori este 0,07%–0,10%, sub eroarea standard OLS de 0,11%: fiecare factor împrumută informație de la ceilalți factori ai temei
- **Dispersia a priori**: $\hat{\tau}_c = 0{,}28\%$, $\hat{\tau}_w = 0{,}04\%$ pe lună
  - față de 0,35% și 0,21% raportate în Tabelul I al articolului
  - cu 15 semnale rămîne puțină dispersie specifică factorilor
- **Teme**: cele 15 semnale se încadrează în 8 dintre cele 13 teme ale articolului
  - 5 în valoare, 3 în risc scăzut, 2 în investiții

Înapoi

Limite precizate de autori și extinderi

- **Limite precizate de autori**
  - CAPM este singurul model de referință: factorii de îndatorare redusă nu au alfa CAPM semnificativ, dar contribuie cînd sînt combinați cu celelalte teme (Secțiunea III.A)
  - Toate caracteristicile sînt construite după aceeași regulă, uneori altfel decît în articolul original (Secțiunea II.C)
  - Factorii încercați, dar nepublicați, ar schimba distribuția a priori: în scenariile lui Harvey, Liu & Zhu (2016), rata pentru SUA scade la 81,5%, respectiv 79,8% (Figura 10)
- **Completarea replicării de curs** (Seminarul 3, C3)
  - justificați semnul fiecărui factor pe baza studiului inițial
  - comparați dendrograma cu temele articolului
  - adăugați FDR bayesian și panta după eșantion (Figura 8)
- Datele și codul articolului: jkpfactors.com, github.com/bkelly-lab/ReplicationCrisis

Înapoi

Bucla descoperirii, prompturi reutilizabile (1/2)

- **Literatură**
  - `Rezumă dovezile din 2016 încoace despre scăderea după publicare și replicarea randamentelor anomaliilor. Pentru fiecare lucrare: DOI, eșantion, numărul de factori, estimația principală, identificarea scăderii. Marchează intrările nesigure.`
  - Verificați fiecare DOI în Crossref
  - Verificați fiecare cifră principală în rezumat
- **Ipoteză**
  - `Compară data mining-ul, arbitrajul bazat pe informația publicată și riscul variabil în timp ca explicații ale scăderii. Pentru fiecare: tiparul prezis între perioadele din eșantion, după eșantion și după publicare, și între acțiunile cu limite mari și cele cu limite mici ale arbitrajului.`
- **Date și cod**
  - `Încarcă factorul lunar de momentum din Kenneth French Data Library; din 1965, regresează MOM pe o variabilă dummy după eșantion (1990-01 până la 1993-03) și una după publicare (din 1993-04), cu erori Newey-West.`
  - Replicați întîi o cifră cunoscută: momentum $t = 5{,}53$ înainte de 2000 și 0,75 după (graficul pe subperioade)

Înapoi

Bucla descoperirii, prompturi reutilizabile (2/2)

- **Robustețe**
  - `Scrie un plan de robustețe preînregistrat: cîte o dată de publicare pentru fiecare factor, corecția Holm între factori, excluderea crahului de momentum din 2009, data documentului de lucru în locul datei din revistă și perioada 1927-1962 ca placebo pentru Mkt-RF, SMB, HML și MOM (RMW și CMA încep în iulie 1963).`
- **Critică**
  - `Evaluează critic: un factor, o dată de publicare, t = -1,45. Care este puterea de a detecta o scădere de 58%? De ce o schimbă combinarea mai multor anomalii?`
- **Raport**
  - Media din eșantion, ambele variabile dummy cu erori Newey–West, placebo-ul, versiunea datelor (data descărcării)
  - Factori combinați: erori robuste la corelația dintre factori în aceeași lună și la autocorelație
  - Prompturile care au influențat o decizie intră în `AI_USE.md`
- Asistentul enumeră specificațiile
- Omul fixează dinainte care dintre ele contează

Înapoi

Verificările cercetătorului

- **Data greșită a evenimentului**: data încheierii eșantionului, data difuzării documentului de lucru și data publicării în revistă sînt diferite
  - test: citiți-le din lucrarea însăși
  - Jegadeesh & Titman (1993): eșantionul se termină în 1989, articolul apare în martie 1993
- **Alegerea factorului după ce s-a văzut că a scăzut**: fixați dinainte lista factorilor
- Aplicați Holm sau BH pe toți factorii
- **Randamente autocorelate, cu crahuri**: erori Newey–West
- Reestimați fără anul 2009
- **Versiunile datelor**: biblioteca de factori este revizuită retroactiv
  - test: notați data descărcării
  - reproduceți statisticile t pe subperioade din capitol
- **Literatură citată greșit**: o greșeală frecventă dă 58% drept scăderea în afara eșantionului
- În realitate, 58% este scăderea după publicare; în afara eșantionului scăderea este 26%
- **Putere mică**: cu un singur factor, H_0 se respinge rar
- Raportați intervalul de încredere al scăderii, nu doar semnul ei

Înapoi

Răspunsurile la verificările rapide (1/2)

Beta, eroarea și shrinkage-ul

- Clasic: $0{,}90 \pm 1{,}96 \times 0{,}05 = [0{,}80; 1{,}00]$, imediat sub 1; Newey–West: $0{,}90 \pm 0{,}18 = [0{,}72; 1{,}08]$, conține 1: nicio dovadă că acțiunea este mai puțin riscantă
- Raportați Newey–West: reziduurile sînt heteroscedastice și autocorelate; HAC schimbă varianța estimată, nu estimația OLS
- $\sigma^2_\beta = 0{,}10 - 0{,}02 = 0{,}08$; e.s. 0,2: $w = 0{,}08/0{,}12 = 0{,}67$, $\beta^V = 0{,}67 \times 1{,}6 + 0{,}33 \times 1{,}0 = 1{,}40$; e.s. 0,1: $w = 0{,}08/0{,}09 = 0{,}89$, $\beta^V = 1{,}53$
- Estimația mai zgomotoasă primește mai mult shrinkage; Blume dă $0{,}33 + 0{,}67 \times 1{,}6 = 1{,}40$ indiferent de precizie

Citirea unei statistici GRS

- $W = \frac{60}{4} \times (0{,}25^2 - 0{,}15^2)/(1 + 0{,}15^2) = 15 \times 0{,}040/1{,}0225 = 0{,}59 < 2{,}53$: nerespins
- Cîștigul așteptat $4 \times 1{,}0225/58 = 0{,}071$, peste cel observat, 0,040: distanța este în limitele zgomotului
- $T = 650$: $W = \frac{645}{4} \times 0{,}0391 = 6{,}31 > 2{,}39$: respins; distanța este aceeași, dovezile cresc cu T

înapoi

Răspunsurile la verificările rapide (2/2)

Prime, Shanken și un R^2 negativ

- $\text{se}_{FM} = 3\%/\sqrt{400} = 0{,}15\%$, $t = 3{,}33$
- $c = 0{,}5^2/1^2 = 0{,}25$; $\text{Var}_{\text{Sh}} = 1{,}25 \times (0{,}0225 - 0{,}0025) + 0{,}0025 = 0{,}0275$, e.s. 0,166%, $t = 3{,}02$: doar puțin peste 3
- Factor tranzacționat: $c = 0{,}25/4{,}5^2 = 0{,}012$, deci corecția este neglijabilă
- Media 4%: $\text{SST} = 4 + 0 + 4 = 8$, $\text{SSE} = 16 + 0 + 16 = 32$, $R^2 = 1 - 32/8 = -3$; cu termen liber, pantele zero dau deja $\text{SSE} = \text{SST}$, iar OLS poate doar să micșoreze SSE

Numărarea descoperirilor

- Naiv 4; Bonferroni (0,01) 1; Holm: $0{,}004 \leq 0{,}01$, $0{,}012 \leq 0{,}0125$, $0{,}020 > 0{,}0167$ oprire: 2; pragurile BH $0{,}01j$: $0{,}030 \leq 0{,}040$ este ultima respingere: 4
- BY: suma este 2,283, pragurile $0{,}0044j$: trece doar 0,004: 1
- $1 - 0{,}95^5 = 0{,}23$; o căutare printre candidați: BH (FDR); „niciun factor nu este fals”: Holm sau Bonferroni (FWER)

înapoi

Pentru aprofundare: cursuri și cod

Cursuri avansate pe quantinar.com

- Generalized Method of Moments
- Multivariate Statistical Analysis

Cod și date

- Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_03
- Datele factorilor: Kenneth French Data Library

Înapoi

Bibliografie (1/6)

- Ahn, S.C., Horenstein, A.R. (2013). Eigenvalue ratio test for the number of factors. *Econometrica*, 81(3), 1203–1227.
- Anatolyev, S., Mikusheva, A. (2022). Factor models with many assets: strong factors, weak factors, and the two-pass procedure. *Journal of Econometrics*, 229(1), 103–126.
- Ang, A., Liu, J., Schwarz, K. (2020). Using stocks or portfolios in tests of factor models. *Journal of Financial and Quantitative Analysis*, 55(3), 709–750.
- Bai, J., Ng, S. (2002). Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 191–221.
- Barillas, F., Shanken, J. (2018). Comparing asset pricing models. *Journal of Finance*, 73(2), 715–754.
- Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- Benjamini, Y., Yekutieli, D. (2001). The control of the false discovery rate in multiple testing under dependency. *Annals of Statistics*, 29(4), 1165–1188.
- Black, F. (1972). Capital market equilibrium with restricted borrowing. *Journal of Business*, 45(3), 444–455.
- Blume, M.E. (1971). On the assessment of risk. *Journal of Finance*, 26(1), 1–10.
- Bryzgalova, S., Huang, J., Julliard, C. (2023). Bayesian solutions for the factor zoo: we just ran two quadrillion models. *Journal of Finance*, 78(1), 487–557.

Bibliografie (2/6)

- Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). The Econometrics of Financial Markets. Princeton University Press.
- Carhart, M.M. (1997). On persistence in mutual fund performance. *Journal of Finance*, 52(1), 57–82.
- Chen, A.Y., Zimmermann, T. (2022). Open source cross-sectional asset pricing. *Critical Finance Review*, 11(2), 207–264.
- Cochrane, J.H. (2011). Presidential address: discount rates. *Journal of Finance*, 66(4), 1047–1108.
- Daniel, K., Moskowitz, T.J. (2016). Momentum crashes. *Journal of Financial Economics*, 122(2), 221–247.
- Fama, E.F., French, K.R. (1992). The cross-section of expected stock returns. *Journal of Finance*, 47(2), 427–465.
- Fama, E.F., French, K.R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56.
- Fama, E.F., French, K.R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- Fama, E.F., MacBeth, J.D. (1973). Risk, return, and equilibrium: empirical tests. *Journal of Political Economy*, 81(3), 607–636.
- Fan, J., Liao, Y., Yao, J. (2015). Power enhancement in high-dimensional cross-sectional tests. *Econometrica*, 83(4), 1497–1541.

Bibliografie (3/6)

- Feng, G., Giglio, S., Xiu, D. (2020). Taming the factor zoo: a test of new factors. *Journal of Finance*, 75(3), 1327–1370.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, ed. a 5-a. Springer.
- Frazzini, A., Pedersen, L.H. (2014). Betting against beta. *Journal of Financial Economics*, 111(1), 1–25.
- Gibbons, M.R., Ross, S.A., Shanken, J. (1989). A test of the efficiency of a given portfolio. *Econometrica*, 57(5), 1121–1152.
- Giglio, S., Xiu, D. (2021). Asset pricing with omitted factors. *Journal of Political Economy*, 129(7), 1947–1990.
- Hansen, L.P. (1982). Large sample properties of generalized method of moments estimators. *Econometrica*, 50(4), 1029–1054.
- Hansen, L.P., Jagannathan, R. (1997). Assessing specification errors in stochastic discount factor models. *Journal of Finance*, 52(2), 557–590.
- Härdle, W.K., Simar, L. (2019). Applied Multivariate Statistical Analysis, ed. a 5-a. Springer.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). . . . and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.

Bibliografie (4/6)

- Hou, K., Xue, C., Zhang, L. (2015). Digesting anomalies: an investment approach. *Review of Financial Studies*, 28(3), 650–705.
- Hou, K., Xue, C., Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133.
- Jagannathan, R., Wang, Z. (1998). An asymptotic theory for estimating beta-pricing models using cross-sectional regression. *Journal of Finance*, 53(4), 1285–1309.
- Jegadeesh, N., Titman, S. (1993). Returns to buying winners and selling losers: implications for stock market efficiency. *Journal of Finance*, 48(1), 65–91.
- Jensen, M.C. (1968). The performance of mutual funds in the period 1945–1964. *Journal of Finance*, 23(2), 389–416.
- Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance? *Journal of Finance*, 78(5), 2465–2518.
- Jheng, S.-L., Găman, Ș., Conda, A., Pele, D.T., Härdle, W.K., Teng, H.-W., Osterrieder, J. (2026). Crypto currency returns. Document de lucru SSRN.
- Kaiser, H.F. (1960). The application of electronic computers to factor analysis. *Educational and Psychological Measurement*, 20(1), 141–151.
- Kan, R., Robotti, C., Shanken, J. (2013). Pricing model performance and the two-pass cross-sectional regression methodology. *Journal of Finance*, 68(6), 2617–2649.
- Kan, R., Zhang, C. (1999). Two-pass tests of asset pricing models with useless factors. *Journal of Finance*, 54(1), 203–235.
- Kelly, B.T., Pruitt, S., Su, Y. (2019). Characteristics are covariances: a unified model of risk and return. *Journal of Financial Economics*, 134(3), 501–524.

Bibliografie (5/6)

- Kleibergen, F. (2009). Tests of risk premia in linear factor models. *Journal of Econometrics*, 149(2), 149–173.
- Kozak, S., Nagel, S., Santosh, S. (2020). Shrinking the cross-section. *Journal of Financial Economics*, 135(2), 271–292.
- Lettau, M., Pelger, M. (2020). Factors that fit the time series and cross-section of stock returns. *Review of Financial Studies*, 33(5), 2274–2325.
- Lewellen, J., Nagel, S., Shanken, J. (2010). A skeptical appraisal of asset pricing tests. *Journal of Financial Economics*, 96(2), 175–194.
- Lintner, J. (1965). The valuation of risk assets and the selection of risky investments in stock portfolios and capital budgets. *Review of Economics and Statistics*, 47(1), 13–37.
- Liu, Y., Tsyvinski, A., Wu, X. (2022). Common risk factors in cryptocurrency. *Journal of Finance*, 77(2), 1133–1177.
- Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- McLean, R.D., Pontiff, J. (2016). Does academic research destroy stock return predictability? *Journal of Finance*, 71(1), 5–32.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Newey, W.K., West, K.D. (1994). Automatic lag selection in covariance matrix estimation. *Review of Economic Studies*, 61(4), 631–653.
- Onatski, A. (2010). Determining the number of factors from empirical distribution of eigenvalues. *Review of Economics and Statistics*, 92(4), 1004–1016.

Bibliografie (6/6)

- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets? *The European Journal of Finance*, 29(10), 1064–1105.
- Pesaran, M.H., Yamagata, T. (2024). Testing for alpha in linear factor pricing models with a large number of securities. *Journal of Financial Econometrics*, 22(2), 407–460.
- Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- Roll, R. (1977). A critique of the asset pricing theory's tests. Part I. *Journal of Financial Economics*, 4(2), 129–176.
- Ross, S.A. (1976). The arbitrage theory of capital asset pricing. *Journal of Economic Theory*, 13(3), 341–360.
- Shanken, J. (1992). On the estimation of beta-pricing models. *Review of Financial Studies*, 5(1), 1–33.
- Sharpe, W.F. (1964). Capital asset prices: a theory of market equilibrium under conditions of risk. *Journal of Finance*, 19(3), 425–442.
- Vasicek, O.A. (1973). A note on using cross-sectional information in Bayesian estimation of security betas. *Journal of Finance*, 28(5), 1233–1239.
- White, H. (1980). A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4), 817–838.
- Date: Kenneth R. French Data Library, mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html.

Acronime folosite în acest material (1/3)

- **AI**: Artificial Intelligence — *inteligență artificială*
- **APT**: Arbitrage Pricing Theory — *teoria evaluării prin arbitraj*
- **BAB**: Betting Against Beta — *strategia „pariu împotriva lui beta"*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BET-TR**: BET Total Return (index) — *indicele BET cu dividendele reinvestite*
- **BH**: Benjamini–Hochberg (procedure) — *procedura Benjamini–Hochberg*
- **BVB**: Bursa de Valori București
- **BY**: Benjamini–Yekutieli (procedure) — *procedura Benjamini–Yekutieli*
- **CAGR**: Compound Annual Growth Rate — *rata anuală compusă de creștere*
- **CAPM**: Capital Asset Pricing Model — *modelul de evaluare a activelor financiare*
- **CMA**: Conservative Minus Aggressive (investment factor) — *factorul investiții: firme conservatoare minus agresive*
- **CML**: Capital Market Line — *dreapta pieței de capital*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- **FDR**: False Discovery Rate — *rata descoperirilor false*
- **FF3**: Fama–French three-factor model — *modelul Fama–French cu trei factori*
- **FF5**: Fama–French five-factor model — *modelul Fama–French cu cinci factori*

Acronime folosite în acest material (2/3)

- **FWER**: Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **GLS**: Generalised Least Squares — *metoda celor mai mici pătrate generalizate*
- **GMM**: Generalized Method of Moments — *metoda generalizată a momentelor*
- **GRS**: Gibbons–Ross–Shanken (test) — *testul Gibbons–Ross–Shanken*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HML**: High Minus Low (value factor) — *factorul valoare: B/M mare minus mic*
- **IPCA**: Instrumented Principal Component Analysis — *analiza instrumentată a componentelor principale*
- **LASSO**: Least Absolute Shrinkage and Selection Operator — *regresie penalizată L1 cu selecția variabilelor*
- **MOM**: Momentum (factor) — *factorul momentum*
- **NYSE**: New York Stock Exchange — *Bursa din New York*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **OMV**: Österreichische Mineralölverwaltung — *Administrația Austriacă a Petrolului (grupul OMV)*
- **PC1**: first Principal Component — *prima componentă principală*

Acronime folosite în acest material (3/3)

- **PC2**: second Principal Component — *a doua componentă principală*
- **PC3**: third Principal Component — *a treia componentă principală*
- **PCA**: Principal Component Analysis — *analiza componentelor principale*
- **PRDS**: Positive Regression Dependence on a Subset (of p-values) — *dependența pozitivă de regresie pe o submulțime (a p-value-urilor)*
- **RF**: Risk-Free rate — *rata fără risc*
- **RMSE**: Root Mean Squared Error — *rădăcina erorii pătratice medii*
- **RMW**: Robust Minus Weak (profitability factor) — *factorul profitabilitate: firme robuste minus slabe*
- **ROE**: Return On Equity — *rentabilitatea capitalului propriu*
- **RP-PCA**: Risk-Premium Principal Component Analysis — *analiza componentelor principale cu primă de risc*
- **SDF**: Stochastic Discount Factor — *factorul stochastic de actualizare*
- **SMB**: Small Minus Big (size factor) — *factorul mărime: firme mici minus mari*
- **SML**: Security Market Line — *dreapta pieței titlurilor*
- **SSE**: Sum of Squared Errors — *suma pătratelor erorilor*
- **SST**: Total Sum of Squares — *suma totală a pătratelor abaterilor de la medie*
- **SUA**: Statele Unite ale Americii
- **UMD**: Up Minus Down (momentum factor) — *factorul momentum: cîștigători minus perdanți*