









Modelarea piețelor financiare

Capitolul 3: Modele factoriale și evaluarea activelor



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

De ce au activele randamente medii diferite?

Ce vom explica

- Ce explică randamentele așteptate?
  - Modelul de evaluare a activelor financiare (CAPM, Capital Asset Pricing Model) și modelele multifactoriale
- Cum se estimează expunerile?
  - Beta, incertitudinea lui și shrinkage
  - shrinkage: estimația este trasă spre o valoare-țintă, ca să scadă zgomotul
- Cum se testează restricțiile de evaluare?
  - Testul simultan al valorilor alfa, regresiile Fama–MacBeth, compararea modelelor
- Rezistă rezultatele? Testare multiplă și replicare
- Ce factori găsim direct în date? PCA și IPCA

Ce trebuie să puteți face

- să estimați un beta cu erori robuste la heteroscedasticitate și autocorelație și să-i aplicați shrinkage
- să testați simultan valorile alfa ale CAPM și să estimați prime de risc cu erori robuste
- să evaluați un factor nou în raport cu pragurile testării multiple și cu dovezile de replicare
- să extrageți factori latenți prin PCA și să alegeți numărul lor
- să descompuneți un ETF factorial în expuneri la factori și alfa

Parcursul capitolului

1. Ce explică randamentele așteptate?
2. De la Markowitz la CAPM
3. Estimarea lui beta
4. Testarea CAPM
5. Modele multifactoriale
6. Regresii Fama–MacBeth
7. Factori de actualizare și compararea modelelor
8. Factor zoo și testarea multiplă
9. Factori latenți: PCA și IPCA
10. Investiții factoriale
11. Studiu de caz: există o criză a replicării?
12. AI (inteligența artificială) pentru descoperire științifică
13. Concluzii

- Răspunsurile la cele patru verificări rapide sînt în Anexă
  - verificările din Secțiunile 3–4
  - verificările din Secțiunile 6–8

Ce este un model factorial?

- Un **model factorial** explică randamentul activului i prin cîteva variabile comune $f_{1,t}, \ldots, f_{K,t}$, numite **factori**

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_{i,1} f_{1,t} + \cdots + \beta_{i,K} f_{K,t} + \varepsilon_{i,t}$$

  - $R_{i,t}$: randamentul activului i în perioada t
  - $R_{f,t}$: rata fără risc
  - K: numărul de factori
  - α_i: randamentul mediu neexplicat de factori, 0 dacă factorii evaluează corect activul
  - $\beta_{i,k}$: **loading factorial** (expunerea) al activului i la factorul k
  - $\varepsilon_{i,t}$: șoc specific activului (idiosincratic)

La ce folosește un model factorial?

- Două utilizări în acest capitol
  - Explicarea unui activ: ETF-ul (Exchange-Traded Fund, fond tranzacționat la bursă) de tehnologie XLK are o sensibilitate de 1,28 față de piața americană (Secțiunea 3)
  - Evaluarea unui fond: rămîne α_i pozitiv după ce ținem cont de expunerile lui (Secțiunile 4 și 10)?
- Alte utilizări (Campbell, Lo & MacKinlay (1997), capitolele 5–6)
  - costul capitalului
  - construcția portofoliilor
  - managementul riscului
- Avantajul în managementul riscului: numărul de parametri
  - N active au $N(N+1)/2$ variațe și covariațe
  - un model cu K factori are nevoie doar de loadings, de covariația factorilor și de N variațe specifice
  - în total, $NK + K(K+1)/2 + N$ parametri
- Ideea capitolului: randamentul mediu este **plata pentru risc**
  - investitorii cer o primă pentru riscurile comune: factorii (piața, mărimea, valoarea ...)
  - un activ cîștigă mai mult dacă are expunere β mare la acești factori
  - nu pentru că este „tehnologie" sau „Apple": ce rămîne neexplicat de β este α

Datele: ce serii folosim

Serie	Ce conține	Frecvență	Perioadă
Factorii Fama–French	randamentele a cinci factori: piața, mărimea, valoarea, profitabilitatea și investițiile	lunară	1963–2026
Factorul momentum	acțiunile cu cele mai mari randamente în lunile $t-12$ pînă la $t-2$ minus cele cu cele mai mici	lunară	1963–2026
25 de portofolii	acțiuni americane sortate independent în 5 grupe după mărime și 5 după B/M (valoarea contabilă / valoarea de piață); cele 25 de intersecții formează portofoliile	lunară	1963–2026
ETF-uri sectoriale	cîte un ETF pentru fiecare sector din S&P 500 (indicele a 500 de mari companii americane): 9 sectoare din 1999, 11 din 2018	zilnică	1999–2026
ETF-uri factoriale	momentum, valoare, calitate, volatilitate minimă (din 2013); mărime, valoare și creștere, indici Russell (din 2000)	zilnică	2000–2026
Bursa de Valori București (BVB)	11 acțiuni mari (blue chips) și indicele bursei, BET	zilnică	2015–2026

- Simbolurile ETF-urilor sectoriale
  - XLB materiale, XLE energie, XLF financiar, XLI industrie, XLK tehnologie
  - XLP bunuri de larg consum, XLU utilități, XLV sănătate, XLY consum discreționar
  - din 2018 se adaugă XLRE imobiliare și XLC servicii de comunicații

Datele: surse și notații

Surse

- Factorii și cele 25 de portofolii: Kenneth French Data Library, randamente lunare în procente
- Ultima lună disponibilă: iulie 2026 (pentru momentum: august 2026)
- ETF-uri și acțiuni: prețuri zilnice de închidere ajustate (dividende reinvestite)
- Ultima zi disponibilă: 18 septembrie 2026

Notații

- **BET**: indicele de referință al BVB, un indice de preț (fără dividende)
- **Randament în exces**: $R^e_{i,t} = R_{i,t} - R_{f,t}$
- $R_{f,t}$: rata titlurilor de stat americane la o lună (RF în datele French)
- **Mkt-RF**: randamentul în exces al pieței americane de acțiuni, cu ponderi după capitalizare

- De ce aceste date
  - randamentele medii foarte diferite ale celor 25 de portofolii fac testul exigent
  - ETF-urile sînt investibile
  - BVB aplică metodele pe piața locală

Ce randamente folosim în acest capitol

- Notații
  - $R_{i,t} = P_{i,t}/P_{i,t-1} - 1$: randament simplu
  - $r_{i,t} = \ln(1 + R_{i,t})$: randament logaritmic
  - $P_{i,t}$: prețul ajustat pentru dividende și split-uri
- Regresiile pe factorii French folosesc randamente simple lunare
  - Factorii sînt randamente de portofolii, iar randamentul unui portofoliu se calculează din randamente simple
  - Media randamentelor logaritmice ar fi mai mică cu aproximativ $\sigma^2/2$: la o volatilitate anuală de 20%, circa 2 puncte procentuale pe an
- Randamente logaritmice zilnice folosesc
  - beta pe ferestre rolling
  - beta la BVB
  - analiza componentelor principale (Secțiunea 9)
- La BVB, rata fără risc zilnică este tratată ca o constantă
  - deci beta este același cu randamente brute sau în exces

Ce portofoliu deține un investitor medie–varianță?

- Întrebarea secțiunii: dacă investitorii aleg doar după medie și varianță, ce portofoliu dețin?
- A doua întrebare: ce randament mediu rezultă atunci pentru fiecare activ?
- Pasul 1: frontiera lui Markowitz (1952) dă portofoliul cu cel mai mare raport Sharpe
- Pasul 2: CAPM (Sharpe (1964); Lintner (1965)) spune că acest portofoliu este chiar portofoliul pieței
- Aplicăm pe cele 9 ETF-uri sectoriale din SUA: sînt investibile și împreună acoperă S&P 500

Frontiera medie–varianță

- Markowitz (1952): portofoliile de pe frontieră se obțin rezolvînd

$$\min_{\mathrm{w}} \ \mathrm{w}^\top \boldsymbol{\Sigma}\, \mathrm{w} \quad \text{cu condițiile} \quad \mathrm{w}^\top \boldsymbol{\mu} = \mu^*,\ \mathrm{w}^\top 1 = 1$$

  - w: ponderile
  - $\boldsymbol{\mu}$: randamentele în exces așteptate
  - $\boldsymbol{\Sigma}$: matricea de covarianță
- Ponderile negative sînt **poziții short**
- Soluția: $\mathrm{w}^* = \boldsymbol{\Sigma}^{-1}(\eta_1 \boldsymbol{\mu} + \eta_2 1)$
  - η_1, η_2: multiplicatorii Lagrange, fixați de cele două restricții
- Ponderile w^* sînt liniare în μ^*
  - orice portofoliu de pe frontieră este o combinație a două portofolii de pe frontieră (teorema celor două fonduri)
- În planul (σ_p, μ_p) frontiera este o hiperbolă
  - ramura de deasupra portofoliului de varianță minimă este **frontiera eficientă**

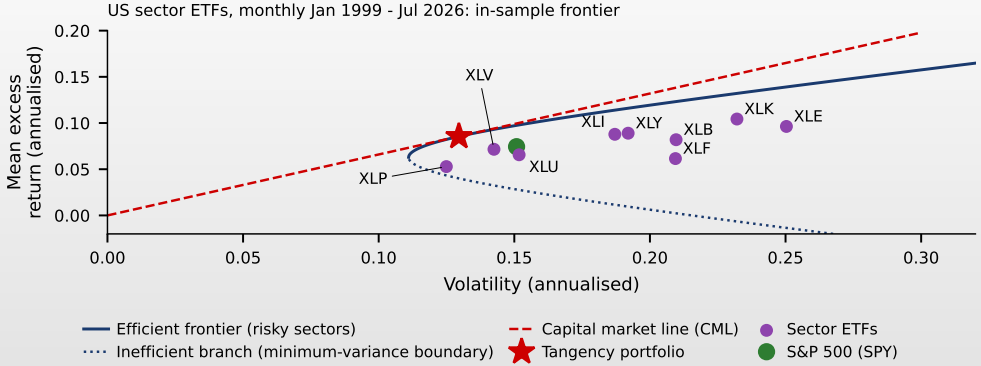
Raportul Sharpe și portofoliul tangent

- **Raportul Sharpe** $SR_p = \mathbb{E}[R_p - R_f]/\sigma_p$: randamentul în exces pe unitatea de volatilitate
- **Portofoliul tangent**: portofoliul cu cel mai mare raport Sharpe

$$w_{\text{tan}} = \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} \,/\, 1^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$$

  - formula este valabilă dacă $\boldsymbol{\Sigma}$ este pozitiv definită și numitorul este pozitiv
  - R_p, σ_p: randamentul și volatilitatea portofoliului p
  - numitorul rescalează $\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$ astfel încît ponderile să aibă suma 1
- **CML** (Capital Market Line, dreapta pieței de capital): $\mu_p = SR_{\text{tan}}\,\sigma_p$
  - toate combinațiile dintre activul fără risc și portofoliul tangent
- Dacă piața este portofoliul tangent, randamentul mediu al oricărui activ este liniar în beta
  - Seminarul 3, problema A2

Frontiera eficientă a sectoarelor din SUA (1/2)



Legenda: Efficient frontier (risky sectors): frontiera eficientă a sectoarelor; Inefficient branch: ramura ineficientă a frontierei de varianță minimă; Tangency portfolio: portofoliul tangent; in-sample frontier: frontiera estimată in-sample, pe tot eșantionul 1999–2026

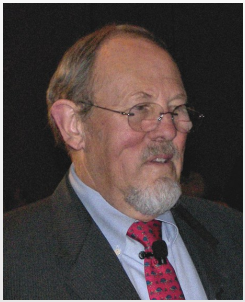
MFM_ch3_frontier

Frontiera eficientă a sectoarelor din SUA (2/2)

- Axele graficului: volatilitatea și randamentul mediu în exces, anualizate
  - ca fracții ($0.10 = 10\%$)
  - 9 ETF-uri sectoriale, lunar, ianuarie 1999 – iulie 2026 ($T = 331$ luni)
- Portofoliul tangent (steaua roșie): medie 8,55%, volatilitate 12,96%, raport Sharpe 0,66
- SPY (cercul verde): medie 7,44%, volatilitate 15,08%, raport Sharpe 0,49
  - ETF-ul care replică S&P 500, folosit ca aproximare a pieței
- CAPM (slide-urile următoare) cere ca piața să fie chiar portofoliul tangent
  - în acest eșantion, SPY se află sub frontieră
- Distanța nu este semnificativă: testul GRS din Secțiunea 4 dă $p = 0{,}85$
  - cu Mkt-RF în locul lui SPY ca piață
- Portofoliul tangent are poziții short mari
  - $-0{,}37$ în financiar și $-0{,}21$ în materiale
  - $+0{,}37$ în sănătate
- Ponderile extreme apar pentru că mediile sînt estimate cu zgomot (Capitolul 4)

MFM_ch3_frontier

CAPM: Sharpe, Lintner, Black



William F. Sharpe, Premiul Nobel pentru Economie 1990, cu Markowitz și Miller

Foto: Larry D. Moore (2007); CC BY 4.0; Wikimedia Commons

- **CAPM** a fost formulat de Sharpe (1964) și Lintner (1965)
- Toți investitorii dețin același portofoliu tangent
  - dacă toți aleg portofolii eficiente medie–varianță și au aceleași așteptări
- Cum fiecare activ trebuie deținut de cineva, portofoliul tangent este chiar **portofoliul pieței**
- Randamentul în exces așteptat este proporțional cu **beta**

$$\mathbb{E}[R_i] - R_f = \beta_i \left(\mathbb{E}[R_m] - R_f\right), \qquad \beta_i = \frac{\mathrm{Cov}(R_i, R_m)}{\mathrm{Var}(R_m)}$$

  - R_i, R_m: randamentele activului i și ale portofoliului pieței
  - $\mathbb{E}[R_m] - R_f$: **prima de risc a pieței**
  - β_i: sensibilitatea activului i la piață, $\beta_i > 1$ amplifică mișcările pieței
- Black (1972): CAPM cu beta zero (Secțiunea 4)
  - o versiune fără împrumut nelimitat la rata fără risc

Implicațiile CAPM

- Ipotezele CAPM
  - investitori medie–variață cu aceleași așteptări, o singură perioadă
  - împrumut și plasament nelimitate la R_f
  - fără taxe sau costuri de tranzacționare
- Doar beta aduce o **primă de risc**: un randament mediu mai mare pentru riscul purtat
  - nicio altă caracteristică nu ar trebui să prezică randamentele
- Riscul idiosincratic nu aduce nicio primă
  - se elimină prin diversificare, deci nimeni nu plătește pentru el
- **SML** (Security Market Line, dreapta pieței titlurilor): orice activ se află pe dreapta (beta, medie)
  - panta dreptei este egală cu prima pieței
  - SML este afirmația testabilă a CAPM (Secțiunea 4)
- Spre deosebire de SML, CML conține doar portofoliile eficiente
- Care portofoliu este „piața”?
  - răspunsul determină ce poate stabili un test al CAPM (critica lui Roll, Secțiunea 4)

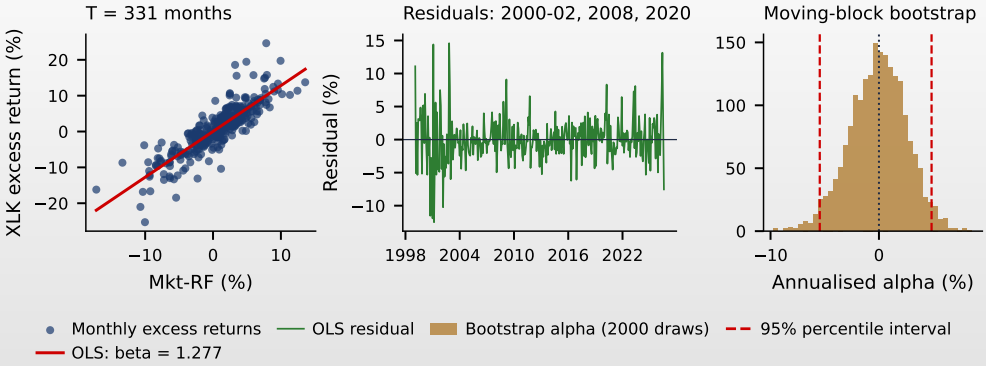
Costul capitalului: care incertitudine contează?

- Costul capitalului prin CAPM: $R_f + \hat{\beta}_i \left(\widehat{\mathbb{E}[R_m]} - R_f\right)$
- Eroarea standard (SE) a primei pieței: $15{,}4\%/\sqrt{63} = 1{,}9\%$ pe an
  - 15,4%: volatilitatea anuală a pieței
  - 63 de ani de date
- Înmulțită cu beta XLK, această incertitudine dă 2,5% pe an în costul capitalului
  - $\hat{\beta} = 1{,}28$ (Secțiunea 3)
- Incertitudinea lui beta adaugă doar $0{,}082 \times 7{,}2\% = 0{,}6\%$ pe an
  - SE a lui beta înmulțită cu prima
- Concluzie: incertitudinea primei pieței cîntărește mult mai mult decît cea a lui beta

Cît de precis putem măsura beta?

- Întrebarea secțiunii: cu cît se mișcă un activ cînd piața se mișcă cu 1%?
  - cît de sigură este această cifră?
- Beta intră în costul capitalului și în acoperirea riscului
- Exemplul de lucru: XLK, ETF-ul de tehnologie, sectorul cu cel mai mare beta din eșantion
- Pașii secțiunii
  - erori standard robuste
  - de ce depinde un beta estimat
  - beta pe ferestre rolling
  - shrinkage
  - aplicarea la BVB

Beta ETF-ului de tehnologie (XLK) în date



Stînga: dreapta OLS pe randamentele lunare; mijloc: reziduurile OLS, cu vîrfuri în 2000–2002, 2008 și 2020; dreapta: distribuția bootstrap a lui alfa, cu intervalul de 95%

MFM_ch3_seminar

Modelul de piață și erorile HAC

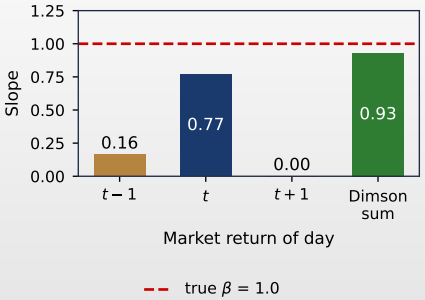
- Modelul de piață $R^e_{i,t} = \alpha_i + \beta_i R^e_{m,t} + \varepsilon_{i,t}$
- **OLS**: $\hat{\beta}_i = \widehat{\text{Cov}}(R^e_i, R^e_m)/\widehat{\text{Var}}(R^e_m)$
  - Ordinary Least Squares, metoda celor mai mici pătrate
- Descompunerea $\sigma^2_i = \beta^2_i \sigma^2_m + \sigma^2_{\varepsilon,i}$
  - risc sistematic (cu primă de risc în CAPM) plus risc idiosincratic (diversificabil)
  - σ^2_i, σ^2_m: variațele activului și ale pieței, $\sigma^2_{\varepsilon,i}$: varianța reziduurilor
  - $R^2 = \beta^2_i \sigma^2_m / \sigma^2_i$ este ponderea sistematică
- De ce erori **HAC** (Newey & West (1987))?
  - HAC: Heteroskedasticity and Autocorrelation Consistent, robuste la heteroscedasticitate și autocorelație
  - volatility clustering (Capitolul 1) face reziduurile heteroscedastice
  - produsul $R^e_{m,t}\varepsilon_{i,t}$ poate fi autocorelat
  - ambele fac eroarea standard clasică a lui $\hat{\beta}$ prea mică
- Erorile HAC: ponderi Bartlett și $L = \lfloor 4(T/100)^{2/9} \rfloor$ laguri (Newey & West (1994))
  - pentru $T = 331$ se obține $L = 5$, pentru $T = 757$ se obține $L = 6$
  - estimațiile punctuale rămîn cele OLS

De ce depinde un beta estimat (1/2)

- Frecvența și fereastra: de obicei 3–5 ani de date lunare sau 1–2 ani de date zilnice
  - o fereastră mai lungă reduce eroarea standard
  - dar amestecă regimuri diferite ale lui beta (Beta nu este constant)
- Aproximarea pieței: SPY (S&P 500) sau Mkt-RF pentru active din SUA, BET pentru acțiuni românești
- Curățarea datelor: un eveniment de capital neajustat creează un randament fals
  - Exemplu: 7 septembrie 2023 este data ex a dividendului special de 1,7225 lei pe acțiune al Fondului Proprietatea (FP)
  - În acea zi prețul de închidere scade cu 81%, dar randamentul total al zilei este +6,0%

De ce depinde un beta estimat (2/2)

- Tranzacționarea asincronă: prețurile de închidere ale activelor nu sînt înregistrate în același moment
- O acțiune nelichidă reacționează cu întîrziere la știrile pieței, deci beta OLS zilnic este deplasat spre 0
- Beta Dimson (Dimson (1979)) regresează randamentul acțiunii pe trei randamente ale pieței
  - din ziua anterioară, din aceeași zi și din ziua următoare
  - $R_{i,t} = a + b_{-\mathbf{1}} R_{m,t-\mathbf{1}} + b_{\mathbf{0}} R_{m,t} + b_{+\mathbf{1}} R_{m,t+\mathbf{1}} + \varepsilon_{i,t}$
  - adună pantele: $\beta^D = b_{-\mathbf{1}} + b_{\mathbf{0}} + b_{+\mathbf{1}}$
- Graficul arată o simulare
  - o acțiune cu $\beta = 1$ se tranzacționează doar în 75% din zile
- Panta pe randamentul pieței din aceeași zi este 0,77, deci subestimează beta
- Panta pe randamentul pieței din ziua anterioară este 0,16
  - o parte din reacție vine cu o zi întîrziere
- Beta Dimson este 0,93, mult mai aproape de 1



Exemplu rezolvat: beta ETF-ului de tehnologie (1/2)

		Eroare standard		
	Estimație	**Clasică**	**White**	**Newey–West**
α (anual)	0,33%	2,27%	2,32%	2,45%
β	1,277	0,041	0,054	0,082

- XLK pe Mkt-RF, lunar ianuarie 1999 – iulie 2026, $T = 331$, $R^2 = 0{,}742$
- Coloanele erorilor standard
  - **Clasică**: erori presupuse homoscedastice și neautocorelate
  - **White**: robustă la heteroscedasticitate (White (1980))
  - **Newey–West**: robustă și la autocorelație, $L = 5$ laguri
- Eroarea standard robustă a lui β este dublul celei clasice
- Heteroscedasticitatea explică o parte din creștere (coloana White)
  - autocorelația produsului $R^e_{m,t}\varepsilon_t$ explică restul

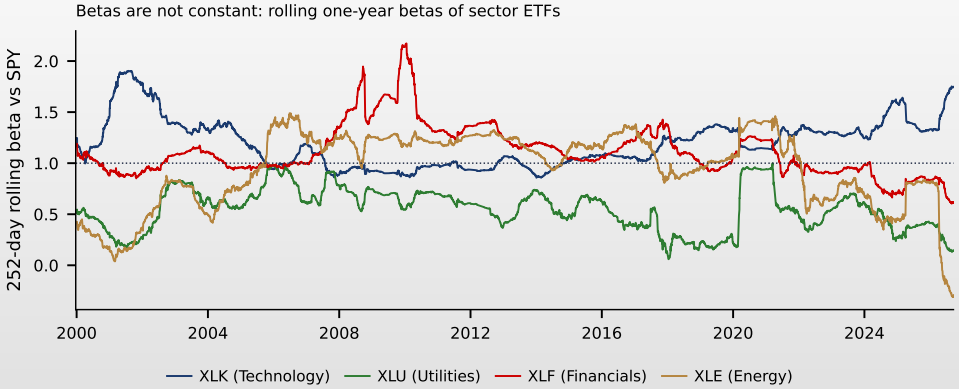
MFM_ch3_seminar

Exemplu rezolvat: beta ETF-ului de tehnologie (2/2)

- Statistica t a lui alfa: $t(\alpha) = 0{,}33/2{,}45 = 0{,}13$
- Intervalul bootstrap de 95% pentru alfa: $[-5{,}5\%; 4{,}9\%]$
  - SE bootstrap 2,61%, puțin peste 2,45%
  - bootstrap pe blocuri suprapuse de 12 luni din perechile $(R^e_{\text{XLK},t}, R^e_{m,t})$, care păstrează dependența în timp
  - 2 000 de reeșantionări (Seminarul 3, problema B1)

MFM_ch3_seminar

Beta nu este constant (1/2)



MFM_ch3_rolling_beta

Beta nu este constant (2/2)

- Graficul: beta OLS rolling pe 252 de randamente logaritmice zilnice (circa un an)
- Beta sectorului financiar (XLF) a variat între 0,60 și 2,17
- Beta XLF a atins maximul imediat după criza bancară din 2008–2009
- Beta sectorului tehnologic (XLK) a variat între 0,86 și 1,90
- Beta XLK a fost ridicat în anii bulei dot-com (2000–2001)
  - la sfîrșitul eșantionului este 1,75
- Beta sectorului energetic (XLE) a variat între −0,31 și 1,49
- Beta XLE este negativ la sfîrșitul eșantionului
  - petrolul a evoluat în sens opus pieței
- Beta utilităților (XLU), sectorul defensiv clasic, a variat între 0,06 și 1,00
- Un singur beta pe tot eșantionul ascunde aceste regimuri
- Modelele cu beta variabil în timp sînt tratate în Capitolele 5–6

MFM_ch3_rolling_beta

Shrinkage pentru beta: Blume și Vasicek (1/2)

- **Regresia spre medie**: un beta estimat foarte mare sau foarte mic conține și zgomot
  - deci în perioada următoare tinde să se apropie de 1
- Blume (1971): regresia valorilor beta dintr-o perioadă pe cele din perioada anterioară
- De aici regula folosită de practicieni: $\beta^{\text{Blume}} = 0{,}33 + 0{,}67\,\hat{\beta}$
- Vasicek (1973): o medie ponderată între estimația activului și media $\bar{\beta}$

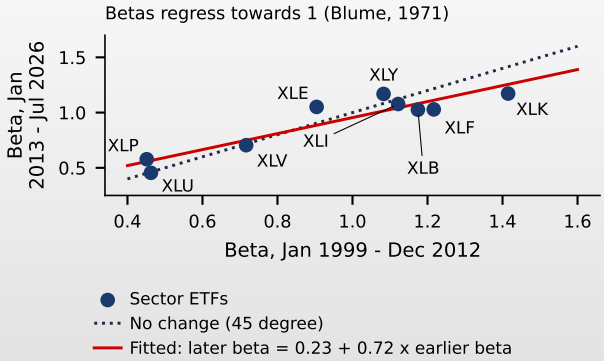
$$\beta_i^V = w_i\hat{\beta}_i + (1 - w_i)\bar{\beta}, \qquad w_i = \frac{\sigma_\beta^2}{\sigma_\beta^2 + \text{se}(\hat{\beta}_i)^2}$$

  - $\bar{\beta}$: media valorilor beta ale tuturor activelor (distribuția a priori)
  - w_i: ponderea estimației, mai mare cînd $\hat{\beta}_i$ este precis (SE mică)
  - $\text{se}(\hat{\beta}_i)$: eroarea lui standard
  - σ_β^2: varianța între active a parametrilor β_i, nu a estimărilor $\hat{\beta}_i$

Shrinkage pentru beta: Blume și Vasicek (2/2)

- Varianța estimațiilor între active adună varianța adevărată și zgomotul
  - $\text{Var}_{cs}(\hat{\beta}) = \sigma_\beta^2 + \overline{\text{se}^2}$
  - $\overline{\text{se}^2}$: media pătratelor erorilor standard
- Deci $\sigma_\beta^2 = \text{Var}_{cs}(\hat{\beta}) - \overline{\text{se}^2}$ (estimația Bayes empirică)
  - derivarea: Seminarul 3, problema A3
- Exemplu: XLK față de SPY, lunar 1999–2012: $\hat{\beta} = 1{,}415$, SE Newey–West 0,139
  - reperul este SPY, deci alt beta decît 1,28
- Distribuția a priori, din cele 9 sectoare: $\bar{\beta} = 0{,}949$ și $\sigma_\beta^2 = 0{,}1159 - 0{,}0077 = 0{,}1082$
- Ponderea estimației proprii: $w = 0{,}1082/(0{,}1082 + 0{,}139^2) = 0{,}849$
  - beta Vasicek: $\beta^V = 0{,}849 \times 1{,}415 + 0{,}151 \times 0{,}949 = 1{,}344$
- Beta Blume: $0{,}33 + 0{,}67 \times 1{,}415 = 1{,}278$
- Beta realizat pe 2013–2026 a fost 1,172
  - ambele ajustări sînt mai aproape de el decît beta neajustat
  - Blume este cel mai aproape

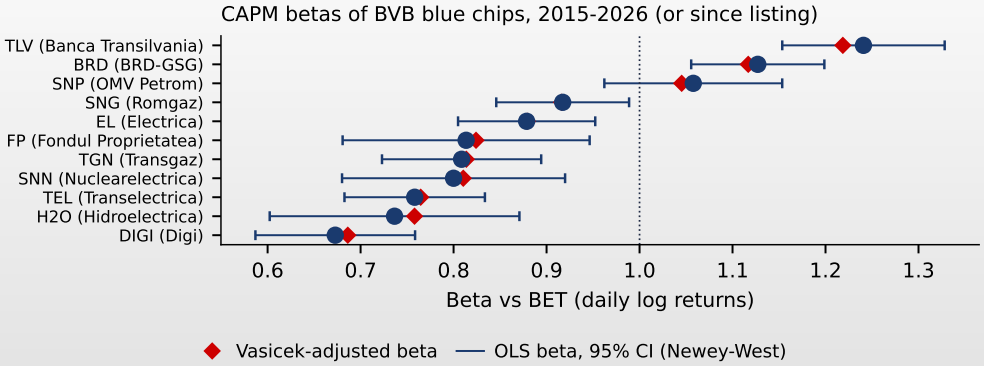
Revenirea valorilor beta spre unu



- Valori beta lunare ale celor 9 ETF-uri sectoriale față de SPY
  - 1999–2012 pe orizontală
  - 2013–2026 pe verticală
- Dreapta estimată: $\hat{\beta}_{\text{ulterior}} = 0{,}23 + 0{,}72\,\hat{\beta}_{\text{anterior}}$
  - foarte aproape de regula Blume $0{,}33 + 0{,}67\,\hat{\beta}$
- Eroarea prognozei: **RMSE** (Root Mean Squared Error, rădăcina erorii pătratice medii)
  - beta neajustat: RMSE 0,135
  - beta Blume: RMSE 0,109
  - beta Vasicek: RMSE 0,114
- Shrinkage-ul reduce eroarea de prognoză cu 15–20%
- Cu doar 9 sectoare, concluzia este calitativă

MFM_ch3_beta_shrink

Beta CAPM la Bursa de Valori București (1/3)



Legenda: OLS beta, 95% CI: beta OLS cu intervalul de încredere (CI, confidence interval) de 95%, erori Newey–West; Vasicek-adjusted beta: beta ajustat Vasicek

MFM_ch3_bvb_betas

Beta CAPM la Bursa de Valori București (2/3)

- Randamente logaritmice zilnice pe BET, de la 6 ianuarie 2015 sau de la listare
  - DIGI: mai 2017, H2O: iulie 2023
  - prețurile FP sînt ajustate pentru dividendul special
- Băncile sînt cele mai sensibile la piață
  - Banca Transilvania (TLV): 1,24, cu $R^2 = 0{,}62$
  - BRD: 1,13
- Cele mai puțin sensibile
  - Digi: 0,67, cu $R^2 = 0{,}21$
  - Hidroelectrica: 0,74, Transelectrica: 0,76
- R^2 este mare la TLV și pentru că TLV are pondere mare în BET
  - acțiunea face parte din propriul reper

MFM_ch3_bvb_betas

Beta CAPM la Bursa de Valori București (3/3)

- Shrinkage-ul Vasicek schimbă puțin estimațiile
  - valorile beta zilnice sînt precise (SE între 0,04 și 0,07)
- Prețurile neactualizate (stale prices) deplasează beta zilnic spre zero
  - beta Dimson urcă de la 0,80 la 0,94 la Nuclearelectrica
  - și de la 0,81 la 0,905 la Transgaz (Seminarul 3, problema B4)
- BET este un indice de preț, iar prețurile acțiunilor includ dividendele
  - alfa este deplasat în sus cu aproximativ beta înmulțit cu randamentul dividendelor indicelui
  - beta se schimbă puțin cu BET-TR

MFM_ch3_bvb_betas

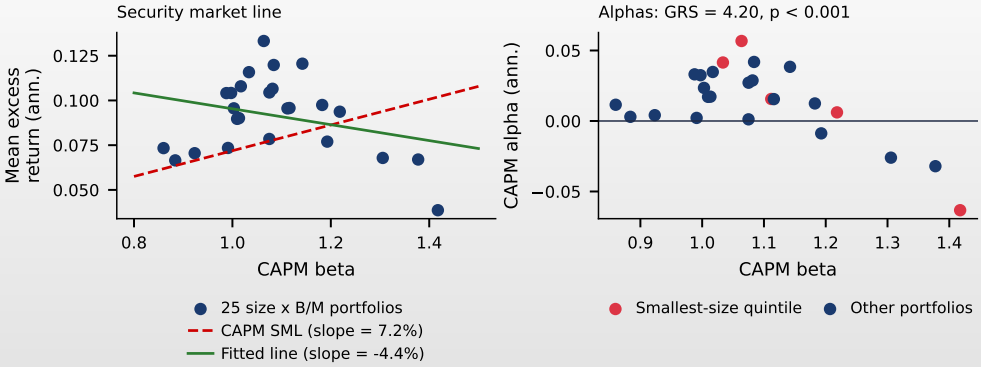
Verificare rapidă: un beta, eroarea și shrinkage-ul lui

- O acțiune, 120 de randamente lunare: $\hat{\beta} = 0{,}90$, SE clasică 0,05, SE Newey–West 0,09
  1. Calculați ambele intervale de 95%. Este acțiunea mai puțin riscantă decît piața după fiecare dintre ele?
  2. Ce interval raportați și de ce nu se schimbă estimația punctuală?
- O secțiune transversală de valori beta
  - $\mathrm{Var}_{cs}(\hat{\beta}) = 0{,}10$, $\overline{\mathrm{se}^2} = 0{,}02$, media $\bar{\beta} = 1{,}0$
  3. Calculați σ_β^2 și beta Vasicek pentru un activ cu $\hat{\beta} = 1{,}6$, o dată cu SE 0,2 și o dată cu SE 0,1
  4. Care dintre cele două primește mai mult shrinkage și de ce? Comparați ambele cu beta Blume
- O acțiune nelichidă de la BVB, randamente zilnice, pantele pe BET
  - din ziua anterioară: 0,25; din aceeași zi: 0,55; din ziua următoare: 0,00
  5. Ce beta Dimson raportați?
  6. De ce este panta din aceeași zi mai mică decît beta Dimson?
- Răspunsuri: Anexă

Este CAPM respins de date?

- Întrebarea secțiunii: se află randamentele medii pe dreapta $\mathbb{E}[R_i^e] = \beta_i \, \mathbb{E}[R_m^e]$?
  - adică: au toate activele alfa zero?
- Active de test: cele 25 de portofolii mărime $\times$ B/M (Fama & French (1993))
- De ce aceste portofolii: randamentele lor medii diferă mult
  - între 3,9% și 13,3% pe an
  - deci testul are putere
- Pașii secțiunii
  - SML în date
  - testul GRS, care verifică simultan toate valorile alfa
  - limitele testului

Dreapta pieței titlurilor (SML) în date (1/2)



Legenda: CAPM SML: dreapta CAPM, cu panta egală cu prima pieței; Fitted line: dreapta estimată pe date; Alphas: valorile alfa ale celor 25 de portofolii; Smallest-size quintile: cvintila firmelor celor mai mici

MFM_ch3_sml

Dreapta pieței titlurilor (SML) în date (2/2)

- Cele 25 de portofolii, resortate în fiecare iunie și ponderate după valoare
  - iulie 1963 – iulie 2026, $T = 757$
- Dreapta CAPM are panta 7,2% pe an
  - axele graficului: fracții anuale, $0.05 = 5\%$
- Dreapta estimată este regresia transversală a randamentelor medii pe beta
  - panta ei este $-4{,}4\%$
  - beta mai mare, randament mediu **mai mic**
- Valorile beta acoperă doar 0,86–1,42
- Alfa este $+5{,}7\%$ pe an pentru firmele mici cu B/M mare (small-value)
  - și $-6{,}3\%$ pe an pentru firmele mici cu B/M mic (small-growth)
- 10 din 25 de valori alfa au $|t| > 1{,}96$
- Testul comun al celor 25 de valori alfa (GRS, slide-urile următoare) dă 4,20
  - $p = 8 \times 10^{-11}$: CAPM este respins

MFM_ch3_sml

De la o singură valoare alfa la testul GRS (1/2)

- **Alfa lui Jensen** (Jensen (1968)): termenul liber al modelului de piață, α_i
  - CAPM implică $\alpha_i = 0$ pentru orice activ
- Un test t separat pentru fiecare activ: XLK are $t = 0{,}13$
  - Cu multe active, unele valori alfa par semnificative doar din întîmplare (Secțiunea 8)
- **Testul GRS** (Gibbons, Ross & Shanken (1989)): un singur test pentru toate activele
  - $H_0 : \alpha_1 = \cdots = \alpha_N = 0$

$$W = \frac{T - N - 1}{N} \, \frac{\hat{\boldsymbol{\alpha}}^\top \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\alpha}}}{1 + \hat{\mu}_m^2 / \hat{\sigma}_m^2} \sim F(N, T - N - 1)$$

- Notațiile
  - N: numărul activelor de test
  - T: numărul de luni
  - $\hat{\boldsymbol{\alpha}}$: cele N valori alfa estimate
  - $\hat{\boldsymbol{\Sigma}}$: covariația reziduurilor estimată prin verosimilitate maximă (împărțire la T)
  - $\hat{\mu}_m / \hat{\sigma}_m$: raportul Sharpe al pieței

De la o singură valoare alfa la testul GRS (2/2)

- $\hat{\boldsymbol{\alpha}}^\top \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\alpha}}$: o sumă ponderată a pătratelor valorilor alfa
  - un alfa cîntărește mai mult cînd reziduurile activului sînt puțin volatile
- Decizia: H_0 se respinge cînd W depășește cuantila de 95% a distribuției $F(N, T-N-1)$
- Distribuția este exactă, condiționat de factori
  - erori i.i.d. cu distribuția Normală multivariată, independente de factori
  - medie zero și covariânță constantă nesingulară
- Interpretare: un W mare arată că portofoliul pieței este departe de frontiera eficientă
  - frontiera construită din piață și din activele de test
- Pentru $N = 1$, $W = t^2$, pătratul statisticii t OLS a lui alfa
  - $F(1, T-2)$ este distribuția pătratului unei variabile Student-t cu $T-2$ grade de libertate
  - GRS generalizează testul t

O SML plată: Black și Betting Against Beta



Fischer Black (1938–1995)

Foto: Dalmatine at English Wikipedia (încărcată 2009); domeniu public; Wikimedia Commons

- Black (1972): fără împrumut nelimitat la R_f, randamentul rămîne liniar în beta
  - dar dreapta pornește de la randamentul unui portofoliu **cu beta zero**
  - acest randament este mai mare decît R_f
- Predicție: SML este **mai plată** decît dreapta CAPM
- Frazzini & Pedersen (2014): investitorii care vor mai mult risc, dar nu se pot împrumuta, cumpără active cu beta mare
  - acestea devin scumpe și au randamente viitoare mai mici
- Strategia lor, **BAB** (Betting Against Beta, pariul împotriva lui beta):

$$r_t^{\mathbf{BAB}} = \frac{R_{L,t} - R_{f,t}}{\beta_L} - \frac{R_{H,t} - R_{f,t}}{\beta_H}$$

  - $R_{L,t}$, $R_{H,t}$: randamentele portofoliilor cu beta mic (L) și cu beta mare (H)
  - β_L, β_H: valorile lor beta
- Strategia este long $1/\beta_L > 1$ unități în L și short $1/\beta_H < 1$ unități în H
  - poziția long este finanțată la R_f, iar încasările din short sînt plasate la R_f
  - strategia are beta zero și un randament mediu pozitiv în datele lor
- Simpla diferență beta mic minus beta mare, fără scalare, are beta negativ
  - media ei amestecă prima BAB cu o expunere negativă la piață (Seminarul 3, problema C2)

GRS ca test al raportului Sharpe

- O identitate algebrică (Gibbons, Ross & Shanken (1989)), cu toate momentele estimate prin verosimilitate maximă

$$\hat{\boldsymbol{\alpha}}^\top \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\alpha}} = \widehat{SR}^2(f, \mathrm{R}) - \widehat{SR}^2(f)$$

  - $\widehat{SR}^2(f, \mathrm{R})$: pătratul raportului Sharpe al portofoliului tangent format din factor și cele N active de test
  - $\widehat{SR}^2(f)$: cel al factorului singur
- Deci GRS măsoară creșterea raportului Sharpe obținută prin adăugarea activelor de test

$$W = \frac{T - N - 1}{N} \cdot \frac{\widehat{SR}^2(f, \mathrm{R}) - \widehat{SR}^2(f)}{1 + \widehat{SR}^2(f)}$$

- Raportul Sharpe lunar al pieței (Mkt-RF) singure este 0,134 (0,47 pe an)
- Raportul Sharpe lunar al portofoliului tangent format din piață și cele 25 de portofolii este 0,405 (1,40 pe an)
- $W = 29{,}24 \times (0{,}405^2 - 0{,}134^2)/(1 + 0{,}134^2) = 4{,}20$
  - $29{,}24 = (757 - 25 - 1)/25$
- Sub CAPM, zgomotul ar crește $\widehat{SR}^2$ lunar în medie cu $N(1 + \widehat{SR}^2(f))/(T - N - 3) = 0{,}035$
  - observat: 0,146 (Anexă)

Metoda generalizată a momentelor (1/2) *(aprofundare)*

- Un model economic implică $\mathbb{E}[\mathrm{g}_t(\boldsymbol{\theta})] = 0$ pentru un vector de condiții de momente g_t
- **GMM** (Hansen (1982)) alege $\hat{\boldsymbol{\theta}}$ astfel încît media empirică a momentelor să fie zero

$$\bar{\mathrm{g}}(\hat{\boldsymbol{\theta}}) = \tfrac{1}{T} \textstyle\sum_{t=1}^{T} \mathrm{g}_t(\hat{\boldsymbol{\theta}}) = 0$$

  - GMM: Generalized Method of Moments, metoda generalizată a momentelor
  - cazul exact identificat: tot atîtea momente cîți parametri
  - cu mai multe momente decît parametri, nu toate pot fi zero, iar $\bar{\mathrm{g}}$ se face cît mai mic, cu o matrice de ponderare
- Varianța sandwich în cazul exact identificat

$$\mathrm{Var}(\hat{\boldsymbol{\theta}}) \approx \tfrac{1}{T}\, \mathrm{D}^{-1} \mathrm{S}\, \mathrm{D}^{-1\top}, \qquad \mathrm{D} = \mathbb{E}\big[\partial \mathrm{g}_t / \partial \boldsymbol{\theta}^{\top}\big], \qquad \mathrm{S} = \textstyle\sum_{j=-\infty}^{\infty} \mathrm{Cov}(\mathrm{g}_t, \mathrm{g}_{t-j})$$

  - D: jacobianul momentelor (derivatele lor după parametri)
  - S: varianța pe termen lung a momentelor, inclusiv autocovariațele, estimată Newey–West (Secțiunea 3)
- Cazul cel mai simplu, o medie: $g_t = R_t - \mu$ dă $D = -1$ și $\mathrm{Var}(\hat{\mu}) \approx S/T$
  - așa se obține statistica t HAC a randamentului mediu al unui factor (Secțiunea 5)

Metoda generalizată a momentelor (2/2) *(aprofundare)*

- OLS: $g_t = x_t(y_t - x_t^\top \boldsymbol{\theta})$ dă $D = -\mathbb{E}[x_t x_t^\top]$
  - erorile White cînd S nu are laguri
  - Newey–West în rest (Secțiunea 3)
- **GRS ca GMM**: parametrii (α_i, β_i), $i = 1, \ldots, N$
  - $2N$ momente $\varepsilon_t \otimes (1, f_t)$: fiecare reziduu înmulțit cu 1 și cu factorul ($\otimes$: produsul Kronecker)
  - sistemul este exact identificat, deci estimațiile sînt chiar cele OLS, activ cu activ; GMM schimbă doar varianța lor
  - parametrii ordonați activ cu activ, $(\alpha_1, \beta_1, \alpha_2, \beta_2, \ldots)$, dau $D = -I_N \otimes (Z^\top Z/T)$, unde Z este matricea $T \times 2$ cu rîndurile $(1, f_t)$
- $\hat{V}_\alpha$: blocul matricei sandwich care corespunde valorilor alfa, calculat cu un $\hat{S}$ HAC
- Statistica Wald $W_{\text{GMM}} = \hat{\boldsymbol{\alpha}}^\top \hat{V}_\alpha^{-1} \hat{\boldsymbol{\alpha}} \to \chi^2_N$ sub H_0
- Același aparat dă erorile primelor robuste la specificarea greșită (▸ Anexă)
  - și estimează modelul cu factor de actualizare din Secțiunea 7

Încălcarea ipotezelor GRS

- **Cozi groase și volatility clustering** (Capitolul 1): distribuția F nu mai este exactă
  - Bootstrap pe reziduuri sub H_0: se reeșantionează rînduri întregi de reziduuri și se reconstruiesc randamentele cu $\alpha = 0$ (Seminarul 3, problema B7)
  - Bootstrap-ul este robust la lipsa normalității doar dacă erorile sînt i.i.d. și independente de factori
  - Testul Wald GMM (Secțiunea 4), cu $\hat{V}_\alpha$ HAC: robust la heteroscedasticitate și autocorelație
- **Prea multe active față de numărul de luni**: $\hat{\Sigma}$ are rangul cel mult $T - 2$
  - cînd $N \geq T - 1$, $\hat{\Sigma}$ nu se poate inversa și GRS nu se poate calcula
  - puterea testului scade mult înainte de această limită
- Pentru multe active există teste care nu inversează $\hat{\Sigma}$ (Pesaran & Yamagata (2024); ▸ Anexă)

Critica lui Roll

- Roll (1977): CAPM se referă la portofoliul **adevărat** al pieței, care cuprinde întreaga avuție
- Indicii bursieri folosiți ca piață omit
  - obligațiunile, activele imobiliare, firmele private și capitalul uman
- Beta calculat față de **orice** portofoliu eficient explică exact randamentele medii ale tuturor activelor
  - rezultat matematic: Seminarul 3, problema A2
- Deci un test CAPM verifică de fapt dacă indicele folosit ca piață este eficient
- Respingerea poate veni din model sau din alegerea indicelui

Alegerea activelor de test schimbă concluzia

- Pe cele 9 ETF-uri sectoriale din Secțiunea 2, cu Mkt-RF ca piață, CAPM nu este respins
  - ianuarie 1999 – iulie 2026, $T = 331$
  - GRS $= 0{,}53$, cu $p = 0{,}85$
- Adăugarea sectoarelor crește pătratul raportului Sharpe lunar cu 0,015
  - mai puțin decît 0,029, cît ar produce zgomotul singur (Anexă)
- Pe aceleași 331 de luni, cele 25 de portofolii mărime $\times$ B/M îl resping
  - GRS $= 2{,}91$, $p = 9 \times 10^{-6}$
- Explicația: fiecare sector amestecă firme mici și mari, de valoare și de creștere
  - deci sectoarele diferă puțin prin caracteristicile care explică randamentele
- Concluzie: faptul că un test nu respinge modelul este o dovadă slabă în favoarea lui
  - testați modelele pe active ale căror randamente medii diferă mult între ele

Verificare rapidă: citirea unei statistici GRS

- Un factor, $N = 4$ active de test, $T = 65$ de luni, rapoarte Sharpe lunare
  - factorul singur: 0,15
  - portofoliul tangent al factorului și celor 4 active: 0,25
  1. Calculați W din forma cu rapoarte Sharpe. Cuantila de 95% a lui $F(4, 60)$ este circa 2,53: respingeți?
  2. Calculați creșterea așteptată sub H_0 a pătratului raportului Sharpe, $N(1 + \widehat{SR}^2(f))/(T - N - 3)$, și comparați-o cu cea observată
  3. Aceleași rapoarte Sharpe, $T = 650$ de luni: recalculați W (cuantila de 95% a lui $F(4, 645)$: circa 2,39). Ce s-a schimbat, distanța sau dovezile?
- Răspunsuri: Anexă

Teoria evaluării prin arbitraj

- Întrebarea secțiunii: beta de piață nu explică randamentele medii (Secțiunea 4)
  - de cîți factori și de care avem nevoie?
- **APT**: Arbitrage Pricing Theory (teoria evaluării prin arbitraj), Ross (1976)
- Ipoteza: randamentele urmează un model cu K factori

$$R_{i,t} = \mathbb{E}[R_i] + \boldsymbol{\beta}_i^\top \mathsf{f}_t + \varepsilon_{i,t}, \qquad \mathbb{E}[\mathsf{f}_t] = 0$$

  - riscurile specifice se pot elimina prin diversificare
  - $\boldsymbol{\beta}_i$: cele K loadings ale activului i
  - f_t: componentele neanticipate ale factorilor
- **Absența arbitrajului** implică $\mathbb{E}[R_i] - R_f = \boldsymbol{\beta}_i^\top \boldsymbol{\lambda}$
  - absența arbitrajului: nu există profit sigur fără capital investit
- Relația este aproximativă: ține pentru aproape toate activele, nu exact pentru fiecare
- $\boldsymbol{\lambda}$: **primele de risc**, randamentul așteptat suplimentar pe unitatea fiecărei expuneri
- Teoria nu spune **care** sînt factorii: ei trebuie găsiți în date

Construcția factorilor: portofolii long–short

mărime: mediana NYSE; B/M: 30% / 40% / 30%

	Mic (growth)	Neutru	Mare (value)
Mici	S_L	S_N	S_H
Mari	B_L	B_N	B_H

$$\text{SMB} = \tfrac{1}{3}(S_L + S_N + S_H) - \tfrac{1}{3}(B_L + B_N + B_H)$$

$$\text{HML} = \tfrac{1}{2}(S_H + B_H) - \tfrac{1}{2}(S_L + B_L)$$

- Un **factor construit prin sortare** cumpără acțiunile cu valoare mare a unei caracteristici
  - și le vinde pe cele cu valoare mică
- Ce se vinde finanțează ce se cumpără
  - deci randamentul factorului este o diferență de randamente, $f_t = R_{\textbf{mare},t} - R_{\textbf{mic},t}$

- Fama–French: în fiecare iunie, acțiunile sînt împărțite în 2×3 grupe
  - cu datele contabile din anul anterior
  - fiecare grupă este un portofoliu ponderat după capitalizare
- Pragul de mărime este mediana capitalizării acțiunilor de la NYSE (New York Stock Exchange)
- Pragurile NYSE și ponderarea după capitalizare împiedică microcapitalizările să domine portofoliile
  - **SMB** (Small Minus Big): acțiuni mici minus acțiuni mari
  - **HML** (High Minus Low): B/M mare (valoare) minus B/M mic (creștere), în medie pe firme mici și mari, deci la aceeași mărime
- Aceeași construcție pe profitabilitate și investiții dă RMW și CMA (slide-ul următor)

Modelele factoriale standard

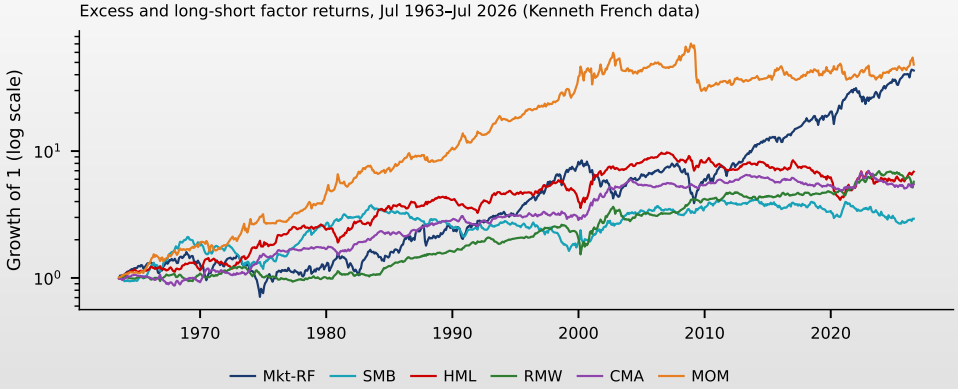
Model	Factori	Referință	Motivație
CAPM	Mkt-RF	Sharpe (1964)	echilibru
FF3	Mkt-RF, SMB, HML	Fama & French (1993)	efectele de mărime și B/M (Fama & French (1992))
Carhart	FF3 + MOM	Carhart (1997)	evaluarea fondurilor
modelul q	piață, mărime, investiții, ROE	Hou, Xue & Zhang (2015)	deciziile de investiții ale firmelor
FF5	Mkt-RF, SMB, HML, RMW, CMA	Fama & French (2015)	modelul de actualizare a dividendelor

- FF3 și FF5: modelele Fama–French cu trei, respectiv cinci factori
  - regresia FF3: $R^e_{i,t} = \alpha_i + b_i\,\mathrm{MKT}_t + s_i\,\mathrm{SMB}_t + h_i\,\mathrm{HML}_t + \varepsilon_{i,t}$
  - MKT = Mkt-RF; b_i, s_i, h_i: loadings pe cei trei factori
- Un model bun lasă valori alfa apropiate de zero în regresiile pe serii de timp
  - deci GRS nu îl respinge
- FF5 pornește de la $\frac{M_t}{B_t} = \frac{\sum_{\tau \geq \mathbf{1}} \mathbb{E}[Y_{t+\tau} - dB_{t+\tau}]/(\mathbf{1}+r)^\tau}{B_t}$
  - M: capitalizarea, B: valoarea contabilă, Y: profitul, dB: investițiile
  - la M/B dat, profit mare (RMW) sau investiții mici (CMA) înseamnă randament așteptat r mare

Factorii adăugați la FF3

- **RMW** (Robust Minus Weak): profitabilitate operațională mare minus mică
- **CMA** (Conservative Minus Aggressive): creștere mică minus mare a activelor
- **ROE** (Return On Equity, rentabilitatea capitalului propriu): factorul de profitabilitate al modelului q
- **MOM** (momentum, notat și UMD, Up Minus Down)
  - acțiunile cu randament mare minus cele cu randament mic în lunile $t-12$ până la $t-2$
  - ultima lună se omite
- Câștigătorii trecuți continuă să câștige 3–12 luni (Jegadeesh & Titman (1993))
- SMB din FF3 vine dintr-o singură sortare (mărime și B/M)
  - SMB din FF5 este media a trei sortări
  - deci FF3 nu este un caz particular al FF5

Randamentele cumulate ale celor șase factori, 1963–2026 (1/2)



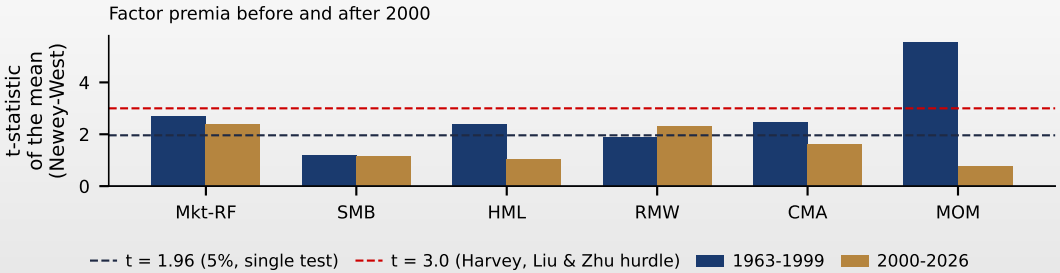
MFM_ch3_factor_cum

Randamentele cumulate ale celor șase factori, 1963–2026 (2/2)

- Randamentele lunare ale factorilor, cumulate pornind de la 1, pe scară logaritmică
- Factorii sînt randamente în exces sau long–short
  - curbele nu includ dobînda pe capital sau pe garanția pozițiilor short
  - deci nu arată averea unui investitor real
- Valoarea finală a unei unități investite, iulie 1963 – iulie 2026
  - Mkt-RF 43,2, MOM 48,0, HML 6,9
  - RMW 5,7, CMA 5,5, SMB 2,9
- Momentum a atins maximul înainte de 2009
  - a pierdut mult cînd piața și-a revenit brusc în 2009: un **crah de momentum**
- Factorul valoare a stagnat sau a pierdut, aproximativ din 2007 pînă în 2020
- Randamente anuale medii
  - Mkt-RF 7,2%, MOM 7,3%, HML 3,6%
  - RMW 3,1%, CMA 3,0%, SMB 2,3%

MFM_ch3_factor_cum

Stabilitatea primelor în timp (1/2)



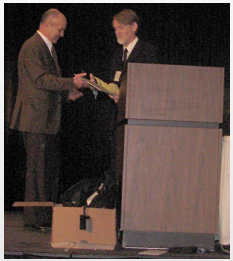
MFM_ch3_factor_tstats

Stabilitatea primelor în timp (2/2)

- Barele: statistica t Newey–West a randamentului lunar mediu
  - 1963–1999 față de 2000–2026
  - tăietură arbitrară, nu data publicării
  - scăderea după publicare: Secțiunea 12
- Liniile: $t = 1{,}96$ (5%, un singur test) și $t = 3$
  - $t = 3$: pragul pentru testarea multiplă al Harvey, Liu & Zhu (2016) (Secțiunea 8)
- A doua perioadă are 319 luni față de 438
  - deci t scade cu factorul $\sqrt{319/438} \approx 0{,}85$ chiar la o medie neschimbată
  - de aceea comparăm și mediile
- Momentum: t scade de la 5,53 la 0,75
  - media anuală scade de la 10,7% la 2,5%
- Valoare (HML): t scade de la 2,39 la 1,02
  - media anuală scade de la 4,2% la 2,8%
- Profitabilitatea (RMW) este excepția
  - t crește de la 1,90 la 2,31
- Prima pieței rămîne semnificativă în ambele perioade ($t = 2{,}70$ și 2,39)

MFM_ch3_factor_tstats

Cele două etape



Eugene Fama, premiul Morgan Stanley–AFA (American Finance Association), 2008

Foto: TonyTheTiger (2008); CC BY-SA 3.0; Wikimedia Commons

- Întrebarea: aduce expunerea la un factor o primă de risc?
  - adică: explică valorile beta diferențele dintre randamentele medii, $\mathbb{E}[R_i^e] = \lambda_{\mathbf{0}} + \boldsymbol{\beta}_i^\top \boldsymbol{\lambda}$?
- De ce Fama & MacBeth (1973)?
  - pentru un factor tranzacționat, λ este media lui
  - pentru unul netranzacționat (de exemplu, inflația) sau pentru caracteristici ale firmelor, doar regresia transversală dă λ
- **Etapa 1** (serii de timp, cîte o regresie pe activ)
  - $R_{i,t}^e = a_i + \boldsymbol{\beta}_i^\top \mathrm{f}_t + \varepsilon_{i,t}$ dă matricea $\hat{\mathrm{B}}$ $(N \times K)$
  - a_i: termenul liber din etapa 1
- **Etapa 2** (transversal, cîte o regresie în fiecare lună pe $\mathrm{X} = [1, \hat{\mathrm{B}}]$)

$$R_{i,t}^e = \lambda_{\mathbf{0},t} + \hat{\boldsymbol{\beta}}_i^\top \boldsymbol{\lambda}_t + u_{i,t}, \qquad \hat{\boldsymbol{\lambda}} = \tfrac{\mathbf{1}}{T} \textstyle\sum_t \hat{\boldsymbol{\lambda}}_t$$

  - $\lambda_{\mathbf{0}}$: zero dacă modelul este corect
  - în versiunea Black (1972), $\lambda_{\mathbf{0}}$ este randamentul portofoliului cu beta zero minus R_f
  - $u_{i,t}$: reziduul din etapa 2
- De ce regresii lunare?
  - variația celor T pante $\hat{\boldsymbol{\lambda}}_t$ dă direct eroarea standard (slide-ul următor)

Erori standard pentru primele de risc (1/2)

- **Fama–MacBeth**: estimațiile lunare $\hat{\lambda}_{k,t}$ formează un eșantion de volum T

$$\text{se}_{FM}(\hat{\lambda}_k) = s(\hat{\lambda}_{k,t})/\sqrt{T}$$

  - $s(\cdot)$: abaterea standard empirică pe cele T luni
  - robuste la corelația reziduurilor între active în aceeași lună
  - dacă $\hat{\lambda}_{k,t}$ este autocorelat, se folosește Newey–West pe această serie
- **Erori în variabile**: etapa 2 folosește estimările $\hat{\beta}_i$ în locul parametrilor β_i
  - deci se_{FM} subestimează incertitudinea

Erori standard pentru primele de risc (2/2)

- Corecția Shanken (1992) mărește cu factorul $(1 + c)$ partea variației care nu provine din variabilitatea factorilor

$$\text{Var}_{\text{Sh}}(\hat{\boldsymbol{\lambda}}) = (1 + c)\Big[\text{Var}_{FM}(\hat{\boldsymbol{\lambda}}) - \tfrac{1}{T}\boldsymbol{\Sigma}_f\Big] + \tfrac{1}{T}\boldsymbol{\Sigma}_f, \qquad c = \hat{\boldsymbol{\lambda}}^\top \boldsymbol{\Sigma}_f^{-1}\hat{\boldsymbol{\lambda}}$$

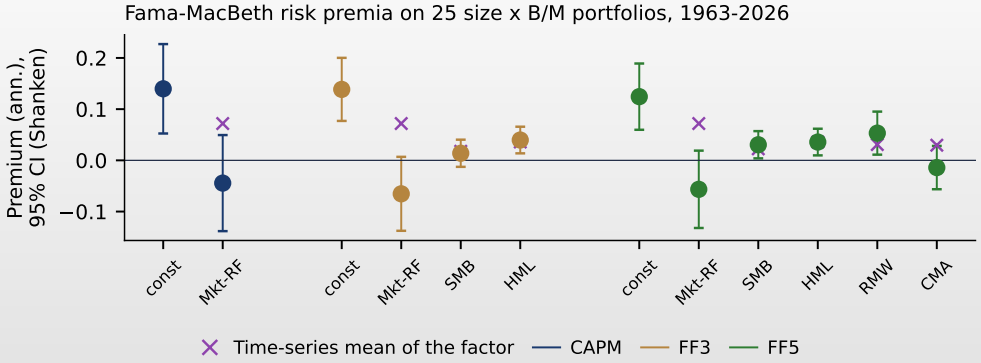
  - Var_{FM}: varianța Fama–MacBeth, $s^2(\hat{\boldsymbol{\lambda}}_t)/T$
  - $\boldsymbol{\Sigma}_f$: covarianța factorilor
  - c: pătratul raportului Sharpe al primelor, pe lună (0,03 pentru FF3)
- Un c mic (factori tranzacționați, date lunare): corecția este mică
- Un c mare (factori netranzacționați): statisticile t Fama–MacBeth sînt supraestimate
- **Model greșit specificat**: erorile Fama–MacBeth, Newey–West și Shanken presupun că modelul este corect
  - adică erorile de evaluare sînt zero: $\mathrm{e} = \boldsymbol{\mu} - \mathrm{X}\boldsymbol{\gamma} = 0$
  - $\boldsymbol{\mu}$: randamentele medii în exces, $\boldsymbol{\gamma} = (\lambda_0, \boldsymbol{\lambda}^\top)^\top$
  - dacă modelul este greșit ($\mathrm{e} \neq 0$), zgomotul din valorile beta estimate adaugă varianță primelor
  - erorile standard robuste la această problemă sînt cele Kan–Robotti–Shanken (Kan, Robotti & Shanken (2013); formula: ▸ Anexă)

Exemplu rezolvat: patru erori standard pentru prima de valoare

FF3, HML	$\hat{\lambda}$	SE	t	Semnificativ la 5%?
Fama–MacBeth	3,97%	1,33%	2,99	da
Newey–West (6 laguri)	3,97%	1,62%	2,45	da
Shanken	3,97%	1,33%	2,99	da
Kan–Robotti–Shanken	3,97%	1,32%	3,00	da

- 25 de portofolii mărime $\times$ B/M, 1963–2026
- Corecția Shanken nu schimbă eroarea, pentru că $c = 0{,}03$ pe lună
- Cel mai mult contează autocorelația pantelor lunare $\hat{\lambda}_t$
  - Newey–West cu 6 laguri mărește SE de la 1,33% la 1,62%
- Pentru RMW din FF5, Kan–Robotti–Shanken crește eroarea de la 2,1% la 2,6%
  - t scade de la 2,5 la 2,1
- Pragul $t > 3$ (Secțiunea 8) nu este depășit clar cu nicio eroare standard

Primele de risc estimate (1/2)



Legenda: Fama-MacBeth risk premia: primele de risc Fama–MacBeth, cu intervale de 95%; Time-series mean of the factor: media factorului în timp

MFM_ch3_fama_macbeth

Primele de risc estimate (2/2)

- Barele: intervale de încredere de 95% cu erori Shanken
  - în fracții anuale ($0.1 = 10\%$)
- Crucile: media în timp a fiecărui factor tranzacționat
  - egală cu λ dacă modelul este corect
- Prime estimate (25 de portofolii, 1963–2026), cu SE în paranteză
  - CAPM: termenul liber 14,0% (4,4%), piața −4,4% (4,8%)
  - FF3: SMB 1,4% (1,4%), HML 4,0% (1,3%)
  - FF5: RMW 5,3% (2,1%), CMA −1,4% (2,2%)
- HML: prima estimată 4,0%, media factorului 3,6%
  - valori apropiate
- Piața (FF3): prima estimată −6,5%, media factorului 7,2%
  - valori îndepărtate
- Cauza: valorile beta de piață diferă puțin între portofolii
  - 0,86–1,42 în CAPM
  - 0,89–1,14 în FF3
- Prima pieței este deci **slab identificată**
  - termenul liber preia nivelul mediu al randamentelor (Lewellen, Nagel & Shanken (2010))

MFM_ch3_fama_macbeth

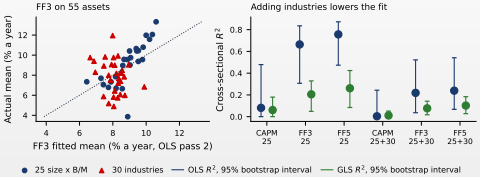
Factori inutili și factori slabi (1/2) *(aprofundare)*

- Un **factor inutil** g_t este independent de toate randamentele
  - toți parametrii β_i sînt zero
  - estimările $\hat{\beta}_i$ sînt doar zgomot, de ordinul $1/\sqrt{T}$
- Etapa 2 regresează randamentele pe acest zgomot
  - $\hat{\lambda}_g$ nu tinde spre zero
  - testul t declară prea des că factorul are o primă cînd modelul este greșit (Kan & Zhang (1999))
- Experimentul: pe cele 25 de portofolii, unde GRS respinge CAPM (Secțiunea 4)
  - estimăm CAPM plus un factor inventat, extras independent din distribuția Normală
  - Repetăm experimentul de 2 000 de ori și testăm la nivelul 5% dacă prima factorului inventat este zero
  - Un test corect ar respinge în aproximativ 5% din repetări
  - Cu erori Fama–MacBeth, prima falsă pare semnificativă în 60% din repetări
  - Cu erori Shanken, prima falsă pare semnificativă în 27% din repetări

Factori inutili și factori slabi (2/2) *(aprofundare)*

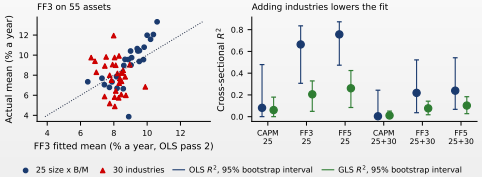
- Remediul: testați întîi, în etapa 1, $H_0 : \beta_g = 0$ pe toate cele N active
  - statistica: $W = \hat{\beta}_g^\top \widehat{\text{Var}}(\hat{\beta}_g)^{-1} \hat{\beta}_g \sim \chi^2_N$
  - dacă nu respingeți, prima factorului nu se poate estima
  - Testul Wald respinge doar în 6,7% din repetări, aproape de 5%
- **Identificare slabă**
  - valorile beta sînt aproape de zero (factor slab)
  - sau aproape egale între active (piața, în exemplul nostru)
  - Există teste robuste la identificarea slabă (Kleibergen (2009))
  - Cu multe active, consistența etapei 2 depinde de cît de puternici sînt factorii (Anatolyev & Mikusheva (2022))

Un test mai sever: adăugarea a 30 de portofolii pe industrii (1/2) *(aprofundare)*



- Cele 25 de portofolii au o structură factorială puternică (Lewellen, Nagel & Shanken (2010))
  - trei factori explică în medie 91% din variația lor în timp (între 79% și 95%)
  - deci orice factori corelați cu SMB și HML le reproduc mediile
- Stînga: media efectivă (vertical) față de media prezisă de FF3 (orizontal), % pe an
  - un model exact ar pune toate punctele pe diagonală
  - industriile (triunghiuri roșii) se împrăștie vertical

Un test mai sever: adăugarea a 30 de portofolii pe industrii (2/2) *(aprofundare)*



- Dreapta: R^2 transversal cu intervale bootstrap de 95%
  - cu 30 de industrii adăugate, R^2 OLS al FF3 scade de la 0,66 la 0,22
  - R^2 OLS al FF5 scade de la 0,76 la 0,24
- Intervalele FF3 se suprapun: scăderea este sugestivă, nu precisă
  - [0,31; 0,84] pe 25 de portofolii
  - [0,04; 0,52] pe 55 de active
- R^2 GLS ponderează erorile cu inversa covarianței randamentelor
  - GLS: Generalised Least Squares, metoda celor mai mici pătrate generalizate
  - R^2 GLS nu depășește niciodată 0,26

Trei verificări ale unui model factorial *(aprofundare)*

- Trei verificări (Lewellen, Nagel & Shanken (2010))
  - Lărgiți mulțimea activelor de test (slide-ul anterior)
  - Raportați și R^2 **GLS**, care ponderează erorile ca GRS
  - Impuneți ca prima unui factor tranzacționat să fie media lui și eliminați termenul liber: FF3 pe cele 55 de active dă $R^2 = -0{,}27$
- R^2 transversal: $R^2 = 1 - \sum_i (\bar{R}_i^e - \hat{\mu}_i)^2 / \sum_i (\bar{R}_i^e - \bar{R}^e)^2$
  - $\hat{\mu}_i$: media prezisă
  - $\bar{R}^e$: media celor N active
- $R^2 < 0$ cînd modelul greșește mai mult decît simpla medie $\bar{R}^e$
  - OLS cu termen liber nu poate face mai rău decît ea
- Acțiuni individuale în locul portofoliilor (Ang, Liu & Schwarz (2020))
  - valori beta mai dispersate
  - dar estimate mai zgomotos

Verificare rapidă: prime, Shanken și un R^2 negativ

- Un factor netranzacționat (de exemplu, creșterea producției industriale)
  - volatilitatea $\sigma_f = 1\%$ pe lună, $T = 400$ de luni
  - etapa 2 dă $\hat{\lambda} = 0{,}5\%$ pe lună, cu $s(\hat{\lambda}_t) = 3\%$
  1. Calculați se_{FM} și statistica t Fama–MacBeth
  2. Calculați c, varianța Shanken și statistica t Shanken. Trece factorul pragul $t > 3$?
  3. De ce ar fi c foarte mic pentru un factor tranzacționat cu $\sigma_f = 4{,}5\%$ și același $\hat{\lambda}$?
- Trei portofolii au randamentele medii în exces 2%, 4%, 6% pe an
  - un model cu prime impuse și fără termen liber estimează 6%, 4%, 2%
  4. Calculați SST, SSE și R^2
  5. De ce nu poate fi negativ R^2-ul unei regresii OLS cu termen liber?
- Răspunsuri: Anexă

Factorii ca factor stocastic de actualizare *(aprofundare)*



Lars Peter Hansen, Premiul Nobel pentru Economie 2013

Foto: Bengt Nyman (2013); CC BY 2.0; Wikimedia Commons

- Întrebarea: este un factor necesar pentru evaluarea activelor, odată ce avem ceilalți factori?
  - sinteză: Cochrane (2011)
- **SDF** m_t: evaluează toate randamentele în exces, $\mathbb{E}[m_t R^e_{i,t}] = 0$
  - SDF: Stochastic Discount Factor, factorul stocastic de actualizare
- m_t este mare în perioadele proaste
  - un activ care cîștigă tocmai atunci este o asigurare
  - deci are un randament mediu mic
- Un model factorial liniar este un SDF, $m_t = 1 - \mathrm{b}^\top(\mathrm{f}_t - \mathbb{E}\mathrm{f})$
  - b: coeficienții SDF
- Prin înlocuire: $\mathbb{E}[R^e_i] = \mathrm{Cov}(R^e_i, \mathrm{f}_t)^\top \mathrm{b} = \boldsymbol{\beta}_i^\top \boldsymbol{\lambda}$
  - $\boldsymbol{\lambda} = \boldsymbol{\Sigma}_f \mathrm{b}$ (Secțiunea 6)
- Două teste diferite
  - $b_k = 0$: factorul k nu ajută la evaluare, ținînd cont de ceilalți factori
  - $\lambda_k = 0$: expunerea la factorul k nu aduce nicio primă
  - cu factori corelați, $\lambda_k \neq 0$ și $b_k = 0$ pot coexista
- b se estimează prin GMM (Hansen (1982); Secțiunea 4)
  - media empirică a lui $m_t(\mathrm{b})\, \mathrm{R}^e_t$ trebuie să fie zero pentru fiecare activ

Compararea modelelor: rapoarte Sharpe maxime (1/2) *(aprofundare)*

Raport Sharpe maxim (anual)	CAPM	FF3	Carhart	FF5	FF5 + MOM
1963–2026 ($T = 757$)	0,47	0,66	0,97	0,97	1,16
2000–2026 ($T = 319$)	0,48	0,54	0,67	0,97	1,02

- Barillas & Shanken (2018): modelul mai bun este cel ai cărui factori permit cel mai mare raport Sharpe
  - $SR^2(\mathrm{f}) = \boldsymbol{\mu}_f^\top \boldsymbol{\Sigma}_f^{-1} \boldsymbol{\mu}_f$
  - $\boldsymbol{\mu}_f$, $\boldsymbol{\Sigma}_f$: mediile și covarianța factorilor
- Motivul vine din GRS
  - valorile alfa ale unui model sînt mici exact cînd factorii lui se apropie de raportul Sharpe maxim
  - comparînd direct $SR^2(\mathrm{f})$, activele de test nu mai contează
  - spre deosebire de distanța Hansen–Jagannathan, calculată pe activele de test (Anexă)

Compararea modelelor: rapoarte Sharpe maxime (2/2) *(aprofundare)*

- Cînd un model îl include pe celălalt, SR^2 in-sample nu poate decît să crească
- Atunci se face o **regresie de spanning**: factorul adăugat se regresează pe ceilalți
  - un alfa nenul arată că el aduce ceva nou
  - HML pe ceilalți cinci factori: $\alpha = 0{,}9\%$ pe an ($t = 0{,}75$)
  - din 2000: $\alpha = -1{,}7\%$ ($t = -0{,}81$), deci nicio contribuție incrementală semnificativă a HML, ca în Fama & French (2015)
- FF5 față de Carhart (niciunul nu îl include pe celălalt): diferența dintre SR^2 anuale este 0,00
  - intervalul de 95%: $[-0{,}57; 0{,}66]$
- Din 2000: diferența este 0,50, cu intervalul de 95% $[-0{,}24; 1{,}48]$
  - deci nici aici nu este semnificativă
  - bootstrap staționar, Politis & Romano (1994); Seminarul 3, problema B8

Factor zoo

- Întrebarea: cîți dintre factorii publicați sînt reali?
  - fiecare a fost testat ca și cum ar fi fost singurul
- Cochrane (2011) a numit lista tot mai lungă de factori un *factor zoo*
  - Harvey, Liu & Zhu (2016) catalogează 316 factori publicați
- Fiecare a trecut pragul $|t| > 1{,}96$ (5%)
  - dacă niciunul nu ar fi real, din 316 teste ar trece din întîmplare circa $0{,}05 \times 316 \approx 16$
- **Data mining** (sau p-hacking): căutarea printre multe variante pînă cînd una pare semnificativă
- Corecția Bonferroni împarte 5% la numărul de teste
  - pentru 316: $p \leq 0{,}00016$, adică $|t| > 3{,}78$
- Harvey, Liu & Zhu (2016) propun $|t| > 3{,}0$ pentru un factor nou
  - pragul care rezultă din corecțiile pentru testarea multiplă (slide-ul următor) aplicate tuturor factorilor testați
- Pragul crește cu fiecare factor publicat
  - o parte dintre factorii publicați nu se replică (Secțiunea 11)

Controlul descoperirilor false (1/2)

- **FDR**: ponderea așteptată a respingerilor false în totalul respingerilor
  - FDR: False Discovery Rate, rata descoperirilor false
- **FWER**: probabilitatea de a avea cel puțin o respingere falsă (Capitolul 2)
  - FWER: Family-Wise Error Rate, rata erorii pe familia de teste
- Notațiile tabelului (slide-ul următor)
  - M: numărul de teste
  - α: nivelul de semnificație al testelor (aici α nu este alfa lui Jensen)
  - $p_{(1)} \leq \cdots \leq p_{(M)}$: p-value-urile ordonate
  - $H_{(j)}$: ipoteza cu al j-lea cel mai mic p-value
  - **BH**: procedura Benjamini–Hochberg
  - **BY**: procedura Benjamini–Yekutieli

Controlul descoperirilor false (2/2)

Procedura	**Controlează**	**Respinge $H_{(j)}$ dacă**	**Validă pentru**
Bonferroni	FWER	$p_{(j)} \leq \alpha/M$	orice dependență
Holm (Holm (1979))	FWER	$p_{(k)} \leq \alpha/(M-k+1)$, $\forall k \leq j$	orice dependență
BH (Benjamini & Hochberg (1995))	FDR	$j \leq$ cel mai mare k cu $p_{(k)} \leq k\alpha/M$	dependență pozitivă
BY (Benjamini & Yekutieli (2001))	FDR	ca BH, pragurile împărțite la $\sum_{k=1}^{M} 1/k$	orice dependență

- Dependență pozitivă: statisticile de test tind să crească împreună
  - independența este un caz particular
  - condiția tehnică se numește PRDS, Positive Regression Dependence on a Subset (Benjamini & Yekutieli (2001))
- FWER: potrivit cînd nicio descoperire falsă nu este acceptabilă
- FDR: potrivit cînd căutăm printre mulți factori candidați
  - și acceptăm o mică proporție de descoperiri false

Exemplu rezolvat: zece factori candidați (1/2)

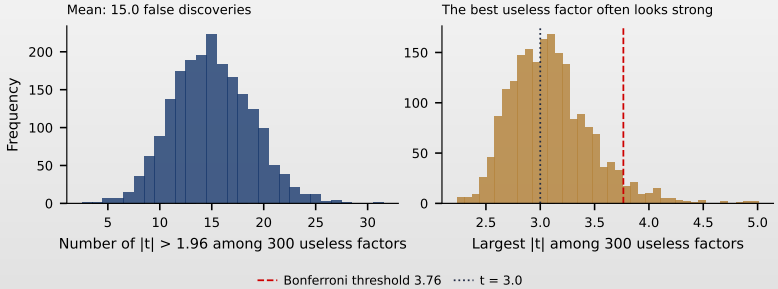
- Zece factori candidați, nivel $\alpha = 5\%$
  - p-value-urile ordonate: 0,0004; 0,002; 0,006; 0,011; 0,018; 0,027; 0,041; 0,070; 0,15; 0,62
- Regula naivă respinge orice ipoteză cu $p \leq 0{,}05$
  - găsește **7** factori semnificativi
- Bonferroni împarte 5% la cele 10 teste, deci pragul este 0,005
  - trec doar **2** factori

Exemplu rezolvat: zece factori candidați (2/2)

- Holm compară al j-lea p-value cu $0{,}05/(11-j)$
  - se oprește la primul care nu trece
- Primele trei p-value-uri trec
  - $0{,}0004 \leq 0{,}005$
  - $0{,}002 \leq 0{,}0056$
  - $0{,}006 \leq 0{,}00625$
- Al patrulea, 0,011, depășește pragul 0,0071
  - deci Holm se oprește la **3** factori
- BH compară al j-lea p-value cu $0{,}005\,j$
  - cel mai mare j care trece este 6 ($0{,}027 \leq 0{,}030$)
  - deci BH declară semnificativi primii **6** factori

Simulare: 300 de factori inutili (1/2)

- Experimentul: 300 de factori fără nicio primă reală
  - statistica t a fiecăruia este o extragere independentă din distribuția Normală standard
- Repetăm experimentul de 2 000 de ori și numărăm, de fiecare dată, câți factori trec pragul



Legenda: false discoveries: descoperiri false; The best useless factor often looks strong: cel mai bun factor inutil pare adesea puternic; Bonferroni threshold: pragul Bonferroni

MFM_ch3_false_discoveries

Simulare: 300 de factori inutili (2/2)

- La pragul clasic $|t| > 1{,}96$ trec, în medie, 15,0 factori inutili, adică 5% din 300
- La pragul $|t| > 3$ trec, în medie, 0,83 factori inutili
- În 57% din repetări, cel puțin un factor inutil trece pragul $|t| > 3$
- În jumătate din repetări, cel mai bun factor inutil are $|t|$ peste 3,06
- Pragul Bonferroni pentru 300 de teste este $|t| > 3{,}76$
- Pragul corect depinde de cîte teste s-au încercat efectiv, inclusiv cele nepublicate

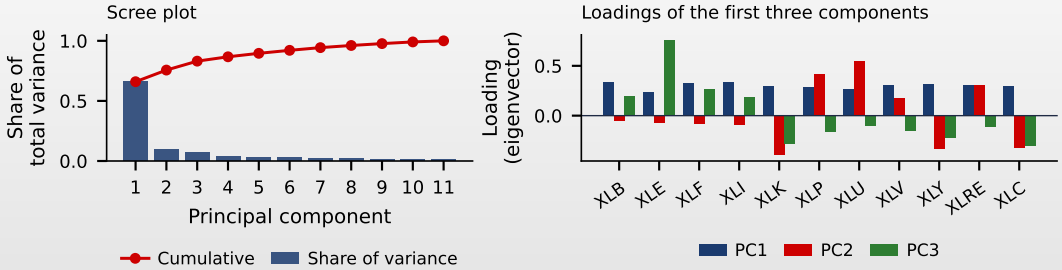
MFM_ch3_false_discoveries

Verificare rapidă: numărarea descoperirilor

- Cinci factori candidați
  - p-value-uri ordonate: 0,004; 0,012; 0,020; 0,030; 0,200
  - nivel de semnificație $\alpha = 5\%$
  1. Cîte descoperiri dau regula naivă, Bonferroni, Holm și BH? Scrieți fiecare prag cu care comparați
  2. La BY, pragurile BH se împart la $1 + \frac{1}{2} + \frac{1}{3} + \frac{1}{4} + \frac{1}{5}$: cîte descoperiri rămîn?
  3. Dacă toate cele cinci ipoteze nule ar fi adevărate și testele independente, care este probabilitatea ca cel puțin un p-value să fie sub 0,05?
  4. Ce procedură ați folosi într-o căutare printre mulți factori candidați?
  5. Ce procedură ați folosi ca să afirmați că **niciun** factor găsit nu este fals?
- Răspunsuri: ▸ Anexă

PCA pe ETF-urile sectoriale din SUA (1/2)

Întrebarea: ce factori apar din randamente dacă nu îi alegem dinainte?



Stînga (Scree plot): ponderea fiecărei componente în varianța totală (bare, Share of variance) și ponderea cumulată (linie, Cumulative); dreapta: loadings (eigenvector) ale primelor trei componente pe fiecare ETF

MFM_ch3_pca

PCA pe ETF-urile sectoriale din SUA (2/2)

- **PCA** (Principal Component Analysis, analiza componentelor principale)
  - combinațiile liniare ale randamentelor care explică, pe rînd, cea mai mare parte a variației rămase
  - formula: slide-ul următor
- 11 ETF-uri sectoriale, randamente logaritmice zilnice
  - 20 iunie 2018 – 18 septembrie 2026 ($T = 2\,073$ zile comune)
- PC1 explică 66,0% din variață
  - loadings toate pozitive (0,24–0,34)
  - o medie aproape egală a sectoarelor
- PC1 este factorul pieței: corelația cu SPY este 0,954
- PC2 (9,7%): **sectoare defensive față de sectoare de creștere**
  - utilități $+0{,}55$, bunuri de larg consum $+0{,}42$, imobiliare $+0{,}31$
  - față de tehnologie $-0{,}40$, consum discreționar $-0{,}33$
- PC3 (7,4%) este dominată de energie
- Primele trei componente explică 83,1%

MFM_ch3_pca

Componentele principale

- **Factori latenți**: factori neobservați, estimați doar din randamente
  - fără a spune dinainte ce reprezintă
- PCA a matricei de corelație C a randamentelor standardizate

$$\mathrm{C} = \mathbf{\Gamma} \mathrm{D} \mathbf{\Gamma}^\top, \qquad \mathrm{y}_t = \mathbf{\Gamma}^\top \mathrm{z}_t$$

  - z_t: randamentele standardizate ale zilei t
  - y_t: componentele
  - $\mathbf{\Gamma}$: vectorii proprii pe coloane, adică **loadings**
  - D: matricea diagonală a valorilor proprii ℓ_k
- Valorile proprii, ordonate: $\ell_1 \geq \cdots \geq \ell_N$
  - notate ℓ, ca să nu se confunde cu primele de risc λ
- Componenta k explică ℓ_k / N din varianța totală
- Exemplu, două active cu corelația ρ: $\ell = 1 \pm \rho$
  - vectorul $(1, 1)/\sqrt{2}$ este „piața"
  - vectorul $(1, -1)/\sqrt{2}$ este diferența dintre ele
- În criză ρ crește și prima componentă domină

Numărul de factori (1/2)

- Model factorial aproximativ $x_{it} = \mathbf{\Lambda}_i^\top \mathsf{F}_t + e_{it}$
  - numărul de active N și cel de perioade T sînt ambele mari
  - x_{it}: randamentul standardizat, F_t: factorii, $\mathbf{\Lambda}_i$: loadings, e_{it}: partea idiosincratică
  - $V(k)$: media pătratelor reziduurilor după primele k componente
- Bai & Ng (2002): alege k care minimizează $\ln V(k) + k \frac{N+T}{NT} \ln \min(N, T)$
  - criteriul de informație IC_{p2}: potrivire plus o penalizare pe factor
- Ahn & Horenstein (2013): alege k unde raportul ℓ_k / ℓ_{k+1} este maxim
  - adică acolo unde valorile proprii scad cel mai brusc
- Regula lui Kaiser (1960) ($\ell_k > 1$) nu are o justificare teoretică
  - chiar și zgomotul pur produce valori proprii împrăștiate în jurul lui 1

Numărul de factori (2/2)

Panel	N	T	Kaiser	Bai–Ng	Ahn–Horenstein
11 ETF-uri sectoriale, zilnic 2018–2026	11	2 073	2	5	1
100 portofolii mărime $\times$ B/M, lunar 1963–2026	95	757	3	4	1

- Randamente standardizate
  - cel mult $k = 5$ factori pentru sectoare și $k = 8$ pentru portofolii
  - 5 portofolii cu luni lipsă sînt eliminate
- Pe cele 95 de portofolii, Ahn–Horenstein alege doar factorul pieței (raport 14,6)
  - al doilea vîrf este la $k = 3$ (raport 3,5), ca în FF3
- Bai–Ng pe 11 sectoare alege numărul maxim permis, $k = 5$
  - penalizarea este gîndită pentru multe active
  - deci cu doar 11 răspunsul nu este de încredere (▸ Anexă)

Limitele PCA în evaluarea activelor

- Loadings sînt **constante**
  - PCA nu poate urmări o acțiune a cărei mărime sau valoare se schimbă
- Componentele explică **varianța**, nu neapărat **randamentele medii**
- Acțiunile individuale intră și ies din eșantion (listări, delistări)
  - deci lipsesc multe observații
  - iar PCA clasic cere un panel complet
- Semnul fiecărei componente este arbitrar
  - schimbarea semnului unui vector propriu nu schimbă nimic
- Factorii latenți sînt determinați doar pînă la o rotație
  - orice combinație rotită a lor explică datele la fel de bine
  - deci interpretarea lor este o alegere
- Două extensii ale PCA țin cont și de randamentele medii (Anexă)
  - PCA cu primă de risc
  - estimatorul în trei etape

PCA instrumentată (1/2) *(aprofundare)*

- **IPCA**: Instrumented Principal Component Analysis (PCA instrumentată), Kelly, Pruitt & Su (2019)
- Loadings sînt funcții de L caracteristici observate $\mathbf{z}_{i,t}$ (mărime, B/M, momentum, ...)

$$R^e_{i,t+1} = \alpha_{i,t} + \boldsymbol{\beta}^\top_{i,t}\mathbf{f}_{t+1} + \varepsilon_{i,t+1}, \qquad \boldsymbol{\beta}^\top_{i,t} = \mathbf{z}^\top_{i,t}\boldsymbol{\Gamma}_\beta$$

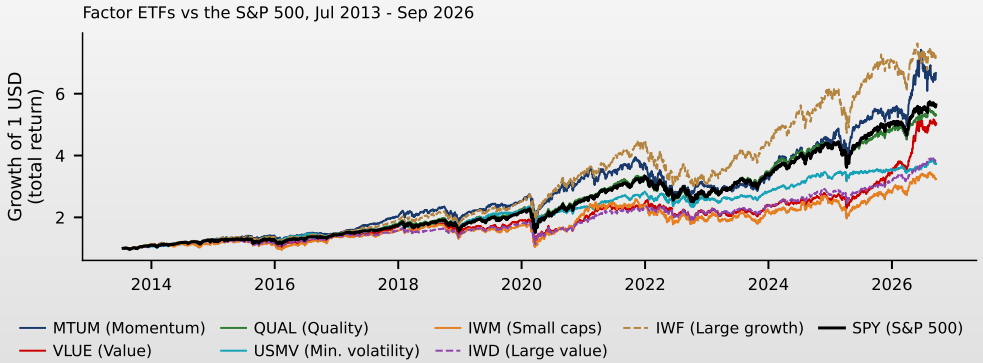
- $\boldsymbol{\Gamma}_\beta$ ($L \times K$) și factorii $\mathbf{f}_{t+1}$ minimizează $\sum_{i,t}(R^e_{i,t+1} - \mathbf{z}^\top_{i,t}\boldsymbol{\Gamma}_\beta\mathbf{f}_{t+1})^2$
  - prin pași alternativi
  - cu $\boldsymbol{\Gamma}_\beta$ fixat, $\mathbf{f}_{t+1}$ vine dintr-o regresie transversală
  - cu factorii fixați, $\boldsymbol{\Gamma}_\beta$ vine dintr-o regresie pe panel

PCA instrumentată (2/2) *(aprofundare)*

- Întrebarea testată: prezic caracteristicile randamentele pentru că măsoară expunerea la risc (prin beta)?
  - sau direct, ca alfa ($\alpha_{i,t} = z_{i,t}^\top \mathbf{\Gamma}_\alpha$)?
- Rezultatul, pe acțiuni americane: cîțiva factori IPCA explică randamentele medii mai bine
  - decît modelele cu tot atîția factori observați
- $\mathbf{\Gamma}_\alpha$ nu este semnificativ
  - de unde titlul articolului: „caracteristicile sînt covariațe"
- Motivația: IPCA rezolvă două limite ale PCA de pe slide-ul „Limitele PCA"
  - loadings constante
  - cerința unui panel complet
  - extinderi: Anexă

ETF-urile factoriale față de piață (1/2)

Întrebarea: cîștigă un investitor care cumpără factorii prin ETF-uri mai mult decît cu piața?



MFM_ch3_factor_etfs

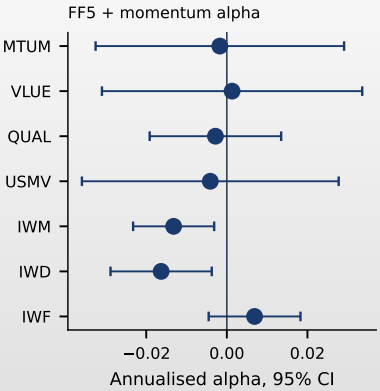
ETF-urile factoriale față de piață (2/2)

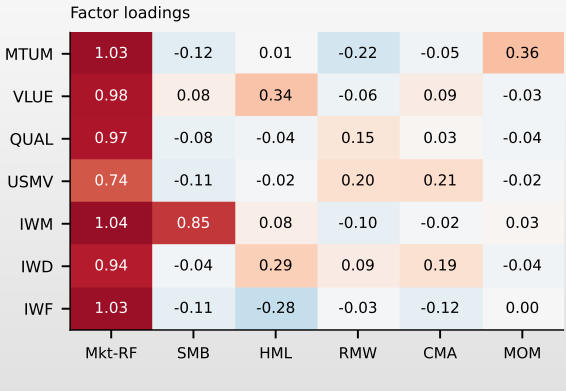
- Graficul: valoarea a 1 USD investit la 18 iulie 2013
  - cu dividendele reinvestite (total return)
  - SPY este linia neagră
- **Smart beta**: ETF-uri doar long care cumpără acțiuni după reguli fixe
  - deci păstrează expunerea la piață
  - și nu reproduc factorul academic long–short
- Indicii Russell
  - Russell 1000: cele mai mari 1000 de acțiuni americane
  - subindicii lui: valoare (IWD) și creștere (IWF)
  - Russell 2000: următoarele 2000 (IWM)

- **CAGR**: $(V_T/V_0)^{1/n} - 1$ pe n ani
  - Compound Annual Growth Rate, rata anuală compusă de creștere
- Peste SPY (14,0%)
  - firmele mari de creștere (IWF): 16,3%
  - momentum (MTUM): 15,5%
- Sub SPY
  - QUAL 13,5%, VLUE 13,1%, IWD 10,7%
  - USMV 10,5%, IWM 9,3%
- Treisprezece ani reprezintă o singură traiectorie istorică
  - prea scurtă pentru a respinge primele factorilor

MFM_ch3_factor_etfs

Valorile alfa ale ETF-urilor factoriale (1/2)





MFM_ch3_etf_alphas

Valorile alfa ale ETF-urilor factoriale (2/2)

- Întrebarea: au ETF-urile un randament peste cel explicat de expunerile lor?
  - $R_t^e = \alpha + \beta^\top \mathrm{f}_t + \varepsilon_t$, cu cei șase factori (FF5 + MOM)
- Regresii zilnice, erori Newey–West
  - fiecare ETF pe propriile zile de tranzacționare din 2000–2026
  - graficul: alfa anualizat cu interval de 95% ($0.02 = 2\%$) și loadings
- Loadings corespund denumirilor
  - MTUM pe MOM 0,36, VLUE pe HML 0,34
  - IWM pe SMB 0,85, IWF pe HML $-0{,}28$
- USMV (volatilitate minimă) are beta de piață 0,74
- Valori alfa aproape de zero
  - MTUM: $-0{,}2\%$ ($t = -0{,}11$)
  - QUAL: $-0{,}3\%$ ($t = -0{,}34$)
- ETF-urile Russell au valori alfa negative
  - IWM: $-1{,}3\%$ ($t = -2{,}57$), IWD: $-1{,}6\%$ ($t = -2{,}54$)
  - comisioanele (sub 0,2% pe an) explică doar o mică parte
  - restul ține de reconstituirea anuală a indicilor Russell și de diferențele față de portofoliile Fama–French
- R^2 între 0,81 și 0,97
  - ETF-urile factoriale vînd, în mare parte, expuneri la factori cunoscuți (Seminarul 3, problema B11)

MFM_ch3_etf_alphas

Factor timing, crowding și costuri

- **Factor timing**: mutarea capitalului între factori după semnale
  - de exemplu, cît de ieftin este un factor sau cum a evoluat recent
  - Primele sînt incerte și seriile scurte, deci este greu de demonstrat că factor timing funcționează out-of-sample (Capitolul 13)
- **Crowding** (aglomerarea pozițiilor): mulți investitori dețin aceleași poziții factoriale
  - Primele se pot micșora (McLean & Pontiff (2016)), iar crowding-ul poate amplifica pierderile la lichidări forțate
  - Momentum crash: după o scădere a pieței, portofoliul momentum are beta negativ, deci pierde mult cînd piața revine brusc, ca în 2009 (Daniel & Moskowitz (2016))
- **Implementarea**: randamentele factorilor academici nu scad două costuri
  - costurile de tranzacționare
  - costul împrumutului acțiunilor vîndute în lipsă

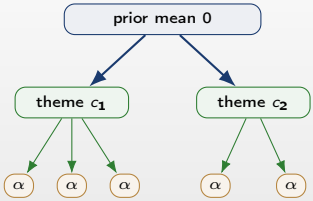
Se replică factorii publicați?

- **Anomalie**: un randament mediu pe care CAPM nu îl explică
- **Două critici** la adresa cercetării despre factori (Jensen, Kelly & Pedersen (2023))
  - Rezultatele nu se pot reproduce: Hou, Xue & Zhang (2020) reușesc să replice doar 35% dintre anomaliile studiate
  - Rezultatele sînt produsul testării multor factori fără corecție: Harvey, Liu & Zhu (2016) conchid că majoritatea descoperirilor raportate sînt probabil false
- **Întrebările**
  - au factorii publicați valori alfa CAPM semnificative în datele originale?
  - sînt aceste valori alfa semnificative out-of-sample și în alte țări?
  - rămîn ele semnificative după ce se ține cont de testarea multiplă?

De ce contează replicarea pentru acest capitol

- Dacă majoritatea factorilor ar fi descoperiri false, s-ar sprijini pe zgomot
  - modelele multifactoriale (Secțiunea 5)
  - ETF-urile factoriale (Secțiunea 10)
- Feng, Giglio & Xiu (2020) arată că majoritatea factorilor noi nu aduc nimic în plus față de cei existenți (▸ Anexă)
- Jensen, Kelly & Pedersen (2023) văd în schimb factor zoo ca multe măsurători corelate ale acelorași cîteva teme economice
- Mărimea testată în studiul de caz este alfa lui Jensen (Secțiunea 4)
- Reperul clasic (non-bayesian) este corecția Benjamini–Yekutieli (Secțiunea 8)

153 de factori grupați în 13 teme *(aprofundare)*



each factor's alpha borrows strength from the other factors of its theme

- **Date** (Secțiunea II a articolului): 153 de factori în 93 de țări
  - acțiunile sînt împărțite în treimi după fiecare caracteristică, cu ponderi după capitalizare, plafonate
  - se cumpără treimea care avea randamentul mai mare în studiul inițial și se vinde cealaltă treime extremă
  - fiecare factor este scalat la o volatilitate specifică (necorelată cu piața) de 10% pe an, ca valorile alfa să fie comparabile
- **Teme**: 13 grupe de factori americani
  - grupare ierarhică (clustering): factorii ale căror reziduuri CAPM sînt puternic corelate intră în aceeași temă
- **Modelul** (Secțiunea I): $f_{i,t} = \alpha_i + \beta_i r_t^m + \varepsilon_{i,t}$
  - $f_{i,t}$: randamentul factorului i; r_t^m: randamentul în exces al pieței; β_i: expunerea la piață; $\varepsilon_{i,t}$: zgomotul
  - $\alpha_i = c_j + s_n + w_i$: componenta temei j, a semnalului n (caracteristica, de exemplu B/M) și componenta specifică factorului i (semnalul n construit într-o anumită țară), toate cu media a priori 0

Shrinkage pentru alfa și rata de replicare *(aprofundare)*

- Cazul unui singur factor: alfa estimat este micșorat spre zero

$$\mathbb{E}(\alpha \mid \hat{\alpha}) = \kappa \hat{\alpha}, \qquad \kappa = \frac{1}{1 + \sigma^2/(\tau^2 T)}$$

  - ecuația 5 din articol; ierarhia completă: ▸ Anexă
  - σ: volatilitatea reziduurilor
  - τ: dispersia valorilor alfa adevărate
  - T: numărul de luni
  - eșantioanele scurte și zgomotoase primesc mai mult shrinkage, ca la Vasicek (Secțiunea 3): σ^2/T joacă rolul lui $\text{se}(\hat{\beta}_i)^2$, iar τ^2 pe cel al lui σ_β^2

- **Rata de replicare**
  - dintre factorii semnificativi în studiile inițiale, ce proporție are alfa semnificativ și în datele noi
  - în varianta bayesiană, un factor este „semnificativ" dacă media a posteriori împărțită la abaterea standard a posteriori este cel puțin 1,96

Majoritatea factorilor se replică, dar alfa scade după eșantionul inițial (1/2)

Rate de replicare (Figura 1)

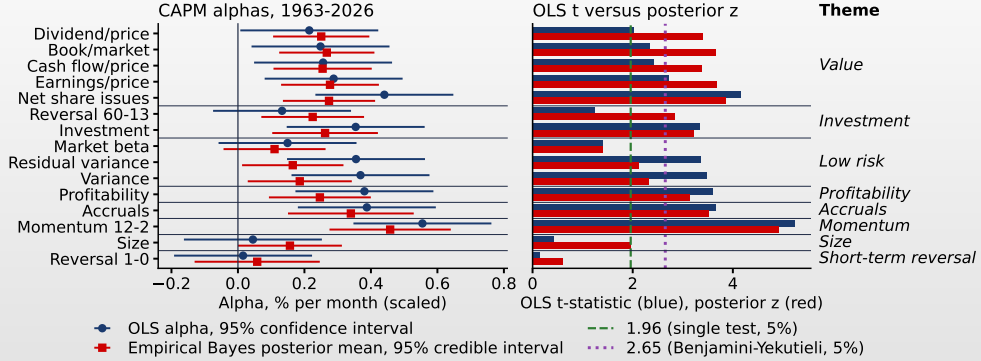
Hou, Xue & Zhang (2020), randamente brute	35,0%
Jensen, Kelly & Pedersen (2023), randamente brute	55,6%
Randamente brute, 119 semnificativi inițial	61,3%
Alfa CAPM, OLS	82,4%
Alfa CAPM, Benjamini–Yekutieli	75,6%
Alfa CAPM, Bayes empiric	82,4%
Global, Bayes empiric	82,4%

- De la 35% (Hou, Xue & Zhang (2020)) la 82,4%
  - Cu un eșantion mai lung, 15 factori în plus și o construcție diferită, rata urcă la 55,6%
  - Dacă se păstrează doar factorii semnificativi în studiile inițiale, rata devine 61,3%
  - Dacă se testează alfa CAPM în locul randamentului brut, rata devine 82,4%
  - acesta este cel mai mare pas

Majoritatea factorilor se replică, dar alfa scade după eșantionul inițial (2/2)

- Bayes empiric dă tot 82,4% (rezultatele complete: Anexă)
  - micșorarea spre zero pierde unele descoperiri
  - informația împrumutată de la temă adaugă altele
  - efectele se compensează
- Proporția estimată de descoperiri false (FDR bayesian) printre factorii cu $z \geq 1{,}96$ este doar 0,1%
  - deși pragul rămîne 1,96
- **Scăderea** după perioada studiului inițial
  - În medie, alfa unui factor scade de la 0,49% pe lună in-sample (eșantionul studiului inițial) la 0,26% pe lună out-of-sample, adică cu 47%
  - Panta regresiei alfa out-of-sample pe alfa in-sample este 0,26 (Figura 8)
  - un alfa inițial mai mare cu 1 punct procentual pe lună rămîne ulterior mai mare doar cu 0,26 puncte procentuale
  - Shrinkage-ul statistic singur ar explica o pantă de circa 0,9, deci scăderea reală este mai mare decît zgomotul
- Cei mai puternici factori scad cel mai mult
  - semn de arbitraj sau de data mining (Secțiunea 12)

Se replică 15 factori americani? (1/2)



Legenda: OLS alpha, 95% confidence interval: alfa OLS cu intervalul de încredere; Empirical Bayes posterior mean, 95% credible interval: media a posteriori Bayes empiric cu intervalul de credibilitate; OLS t versus posterior z: t OLS față de z a posteriori; Theme: tema

MFM_ch3_jkp_replication

Se replică 15 factori americani? Cum citim graficul

- Panoul stîng: alfa CAPM al fiecărui factor, în % pe lună
  - scalat la o volatilitate idiosincratică de 10% pe an
  - albastru: alfa OLS cu intervalul de încredere de 95%
  - roșu: media a posteriori Bayes empiric cu intervalul de credibilitate de 95%
- Panoul drept: t OLS (albastru) și z a posteriori (roșu)
  - z = media a posteriori împărțită la abaterea standard a posteriori
- Liniile punctate
  - 1,96: un singur test, 5%
  - 2,65: pragul Benjamini–Yekutieli, 5%
- 15 factori americani long–short din sortările ponderate după valoare ale Kenneth French Data Library
  - iulie 1963 – iulie 2026 ($T = 757$)
  - grupați pe temele articolului (etichetele autorilor)

Se replică 15 factori americani? (2/2)

- Rate de replicare
  - OLS: 73,3% (11 din 15 factori)
  - Benjamini–Yekutieli: 53,3% (8 factori; $|t|$ critic 2,65)
  - Bayes empiric: 86,7% (13 factori)
- Shrinkage-ul trage alfa spre media temei, nu doar spre zero
- Exemplu: inversarea pe termen lung (tema investiții) crește de la 0,13% la 0,23% pe lună
  - t OLS este 1,25, dar z a posteriori este 2,85
- Nu se replică: beta de piață și inversarea pe termen scurt ($z \leq 1{,}41$)
- Mărimea trece la limită ($z = 1{,}96$)
  - și în articol mărimea este una dintre cele două teme cu rata sub 50%
- Rata se calculează aici pe toate cele 15 semnale (Anexă)
  - fără a verifica dacă fiecare a fost semnificativ în studiul inițial

MFM_ch3_jkp_replication

Ce nu poate arăta replicarea din curs

- **Limitele versiunii de curs**
  - 15 semnale americane în loc de 153 în 93 de țări
  - portofoliile din Kenneth French Data Library, nu treimile construite fără firmele foarte mici (microcapitalizări)
  - o singură țară, deci fiecare semnal apare o singură dată și componenta semnalului nu se poate estima (dispersia ei se fixează la zero)
  - rezultatul depinde de gruparea pe teme: dacă toți factorii ar fi într-o singură temă, rata Bayes empiric ar fi 100%
- **Limite precizate de autori** (▸ Anexă)
  - CAPM este singurul reper
  - toate caracteristicile sînt construite după aceeași metodă
  - distribuția a priori ignoră factorii nepublicați
- **Întrebări deschise** (datele articolului se opresc în 2020)
  - s-au menținut valorile alfa și rata de replicare în 2021–2026?
  - pot factorii americani, folosiți ca distribuție a priori, să îmbunătățească estimările factorilor de la BVB, unde seriile sînt scurte?
- Datele și codul articolului: jkpfactors.com

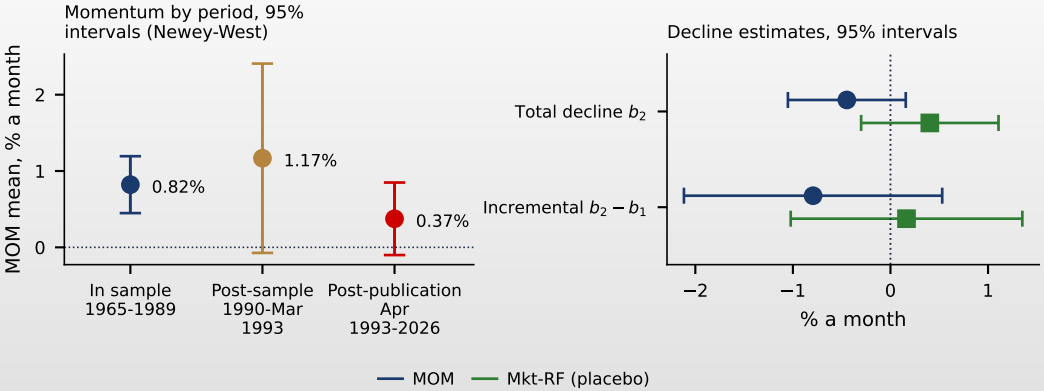
Întrebări deschise și bucla descoperirii

- **Întrebări deschise**
  - de ce scad primele factorilor după publicare: arbitraj, data mining sau o schimbare a riscului?
  - diferă scăderea între factori și piețe?
- Stadiul cunoașterii
  - McLean & Pontiff (2016): pe 97 de predictori, randamentele sînt cu 26% mai mici out-of-sample și cu 58% mai mici după publicare
  - autorii atribuie diferența investitorilor care tranzacționează pe baza articolelor publicate
  - Chen & Zimmermann (2022): date și cod deschise pentru predictorii publicați
- **Bucla descoperirii**
  - Asistentul AI propune: un tabel al literaturii cu DOI (Digital Object Identifier, identificator digital de obiect), ipoteze concurente și ce prezice fiecare, codul regresiei, un plan de robustețe (prompturi: ▸ Anexă)
  - Cercetătorul fixează înainte de rulare: datele evenimentelor, lista factorilor, corecția pentru testarea multiplă și testul placebo (un factor la care nu ar trebui să apară efectul)
  - Înainte de interpretare: fiecare DOI se deschide în Crossref, statisticile t pe subperioade din Secțiunea 5 se reproduc, iar versiunea datelor French este notată

Ministudiu de caz: arbitrajul și declinul momentum-ului (1/3)

- Specificația din McLean & Pontiff (2016): $\text{MOM}_t = a + b_1 \text{PostSample}_t + b_2 \text{PostPub}_t + e_t$
  - lunar, ianuarie 1965 – august 2026 ($T = 740$)
  - erori Newey–West
- Variabile dummy
  - $\text{PostSample}_t = 1$ în ianuarie 1990 – martie 1993 (după eșantion)
  - $\text{PostPub}_t = 1$ din aprilie 1993 (după publicare)
- a: media in-sample (1965–1989)
- b_2: scăderea totală față de media in-sample
- $b_2 - b_1$: efectul incremental al publicării

Ministudiu de caz: arbitrajul și declinul momentum-ului (2/3)



MFM_ch3_ai_discovery

Ministudiu de caz: arbitrajul și declinul momentum-ului (3/3)

- Media momentum in-sample: $a = 0{,}82\%$ pe lună ($t = 4{,}32$)
- Scăderea după publicare: $b_2 = -0{,}45\%$ pe lună ($t = -1{,}45$)
  - interval $[-1{,}05\%; 0{,}16\%]$
  - adică o medie cu 54% mai mică
- Efectul incremental al publicării: $b_2 - b_1 = -0{,}79\%$ ($t = -1{,}17$)
- Placebo pe Mkt-RF: $b_2 = +0{,}40\%$ ($t = 1{,}12$)
- Scăderea este apropiată de 58% din McLean & Pontiff (2016)
  - dar cu un singur factor nu putem respinge $H_0 : b_2 = 0$ la 5%
- Arbitrajul este o interpretare posibilă, nu o cauză demonstrată

MFM_ch3_ai_discovery

Proiect: scad primele factorilor după publicare?

- **Întrebări**
  - scad primele factorilor Fama–French și momentum după publicare?
  - diferă scăderea între factori?
- **Metoda**
  - o regresie comună pentru SMB, HML, RMW, CMA și MOM, cu variabile dummy proprii fiecărui factor pentru perioadele după eșantion și după publicare
  - Mkt-RF ca placebo
  - Erori robuste la corelația dintre factori și la autocorelație
  - dacă scăderea este mai mare acolo unde arbitrajul este mai ușor se poate testa doar cu date la nivel de acțiune (mărime, lichiditate, costul vînzării în lipsă)
- **Replicați întîi**
  - statisticile t pe subperioade
  - estimațiile din ministudiul de caz

Proiect: datele eșantionului și rezultatele cerute

- **Livrabile**
  - mai întîi, un tabel al evenimentelor: factorul, lucrarea inițială cu DOI, sfîrșitul eșantionului ei, data publicării, toate citite din lucrare (rîndul-model: MOM, Jegadeesh & Titman (1993))
  - o notă de preînregistrare (H_0, H_1, datele din tabel, lista factorilor, corecțiile), salvată în Git (commit) înainte de a vedea rezultatele
  - codul ca Quantlet: un director cu scriptul, sursa datelor și o scurtă descriere, ca în Quantlet-urile capitolului
  - un raport cu erori Newey–West, perioade placebo și puterea testului
  - puterea: probabilitatea de a respinge $b_2 = 0$ la 5% dacă scăderea reală ar fi, de exemplu, cei 58% din McLean & Pontiff (2016)
  - puterea se obține prin simulare sau aproximativ $\Phi(\delta / \mathrm{se}(b_2) - 1{,}96)$
  - δ: scăderea presupusă; Φ: funcția de repartiție a distribuției Normale standard
- **Jurnale**: prompturile în `AI_USE.md`, erorile depistate în `AI_ERRORS.md`

Concluzii: pașii unei analize factoriale

1. **Estimați expunerile** cu erori HAC
   - raportați eșantionul și aproximarea pieței
   - aplicați shrinkage valorilor beta extreme (Blume (1971), Vasicek (1973))
2. **Testați toate valorile alfa deodată**
   - GRS măsoară cît crește raportul Sharpe cînd adăugăm activele de test
   - CAPM eșuează pe cele 25 de portofolii mărime $\times$ B/M (SML plată, GRS respinge)
3. **Estimați primele** în două etape
   - cu erori care țin cont că beta este estimat și că modelul poate fi greșit
   - un R^2 mare pe cele 25 de portofolii nu dovedește mare lucru
4. **Protejați-vă de factor zoo**: folosiți praguri corectate pentru testarea multiplă
5. **Verificați replicarea**: majoritatea factorilor publicați se replică
   - dar alfa scade cu circa jumătate după eșantionul inițial
6. **Descompuneți ETF-urile factoriale**
   - ele vînd în mare parte expuneri la factori cunoscuți, nu alfa

Verifică-ți înțelegerea

Întrebări de verificare

- De ce diferă eroarea standard HAC a unui beta de cea clasică, deși beta nu se schimbă? (Secțiunea 3)
- De ce poate GRS să nu respingă CAPM pe ETF-urile sectoriale, dar să-l respingă pe cele 25 de portofolii?
  - în aceleași luni (Secțiunea 4)
- De ce pare să aibă o primă un factor inutil în etapa 2? (Secțiunea 6)
- De ce poate rata de replicare Bayes empiric să depășească rata Benjamini–Yekutieli? (Secțiunea 11)

Unde continuă ideile

- Capitolul 2: un alfa nenul poate fi o anomalie sau un factor de risc omis
  - problema ipotezei comune
- Capitolul 4: modele factoriale de covariață și shrinkage pentru Markowitz
- Capitolele 5–6: volatilitate, corelații și beta variabile în timp
- Capitolul 13: overfitting-ul backtest-ului
  - și machine learning pentru secțiunea transversală a randamentelor

GRS sub ipoteza nulă

- Adăugarea a N active crește întotdeauna raportul Sharpe in-sample
  - testul verifică dacă această creștere depășește ce ar produce zgomotul
- Forma Sharpe: $W = \frac{T-N-1}{N} \frac{\widehat{SR}^2(f,\mathrm{R}) - \widehat{SR}^2(f)}{1+\widehat{SR}^2(f)}$
- Sub H_0, cu reziduuri Normale i.i.d., $W \sim F(N, T-N-1)$
  - deci $\mathbb{E}[W] = \frac{T-N-1}{T-N-3}$
- Înmulțind cu $\frac{N(1+\widehat{SR}^2(f))}{T-N-1}$
  - $\mathbb{E}\left[\widehat{SR}^2(f,\mathrm{R}) - \widehat{SR}^2(f)\right] \approx \frac{N\,(1+\widehat{SR}^2(f))}{T-N-3}$
- 25 de portofolii, $T = 757$: $25 \times 1{,}018/729 = 0{,}035$ (lunar)
  - față de $0{,}405^2 - 0{,}134^2 = 0{,}146$ observat
- 9 ETF-uri sectoriale, $T = 331$: cîștig observat $0{,}191^2 - 0{,}146^2 = 0{,}015$
  - sub cel așteptat, $9 \times 1{,}021/319 = 0{,}029$

Înapoi

Teste pentru multe active

- $\hat{\boldsymbol{\Sigma}} = \hat{\mathbf{E}}^\top \hat{\mathbf{E}}/T$ are rangul cel mult $T - 2$
  - doi parametri în fiecare regresie
  - $\hat{\mathbf{E}}$: matricea $T \times N$ a reziduurilor
  - Exemplu: 100 de portofolii mărime $\times$ B/M pe 8 ani de date lunare ($T = 96$): $\hat{\boldsymbol{\Sigma}}$ este singulară, GRS nu există (Seminarul 3, problema B7)
- Teste pentru multe active care evită $\hat{\boldsymbol{\Sigma}}^{-1}$ (Pesaran & Yamagata (2024))
  - sume standardizate ale pătratelor statisticilor t
- Creșterea puterii prin selecția valorilor alfa mari: Fan, Liao & Yao (2015)

înapoi

Erori standard robuste la specificarea greșită

- Erorile Fama–MacBeth și Shanken presupun un model **corect**
  - toate erorile de evaluare $e = \boldsymbol{\mu} - X\gamma$ sînt zero, cu $X = [1, B]$
- Aici GRS respinge modelul, deci γ nu are o valoare „adevărată"
  - se estimează valoarea care minimizează erorile de evaluare (valoarea pseudo-adevărată)
- Zgomotul din $\hat{B}$ se înmulțește cu e și adaugă un termen de varianță (Kan, Robotti & Shanken (2013))
- Scriem ambele etape ca un singur sistem GMM exact identificat (Secțiunea 4)
  - momentele: $(R_t - a - Bf_t) \otimes (1, f_t)$ și $X^\top(R_t - X\gamma)$
  - varianța sandwich cu jacobianul complet este cea robustă
  - Cu $e = 0$ în jacobian se obține versiunea pentru un model corect specificat, robustă la heteroscedasticitate, a lui Jagannathan & Wang (1998)
- FF5 pe cele 25 de portofolii (Secțiunea 6): erorile standard robuste
  - CMA: 2,2% → 2,7%
  - termenul liber: 3,3% → 3,8%
  - HML: schimbarea este sub 0,05 puncte procentuale
- Curs avansat: Generalized Method of Moments

înapoi

Distanța Hansen–Jagannathan și selecția bayesiană

- **Distanța Hansen–Jagannathan** (Hansen & Jagannathan (1997))

$$\delta^2 = \min_{\mathsf{b}} \; \mathsf{e}(\mathsf{b})^\top \, \mathbb{E}[\mathsf{R}^e \mathsf{R}^{e\top}]^{-1} \, \mathsf{e}(\mathsf{b}), \qquad \mathsf{e}(\mathsf{b}) = \mathbb{E}[m_t(\mathsf{b}) \, \mathsf{R}_t^e]$$

  - cît de departe este SDF-ul modelului de cel mai apropiat SDF care evaluează corect toate activele
  - Randamente în exces R_t^e cu normalizarea $\mathbb{E}[m] = 1$
  - Pentru randamente brute R_t: $\mathsf{e} = \mathbb{E}[m\mathsf{R}] - 1$, iar SDF-ul are nevoie de o scală liberă ($\mathbb{E}[m] = 1/(1 + R_f)$)
  - Aceeași matrice de ponderare pentru orice model, deci distanțele sînt comparabile
  - Statistica de test are o limită χ^2 ponderată
- Selecție printre foarte multe modele (Bryzgalova, Huang & Julliard (2023))
  - media bayesiană a circa 2×10^{15} de modele factoriale
  - robustă la factori slabi
- Kozak, Nagel & Santosh (2020) aplică shrinkage coeficienților SDF
  - cîteva componente principale ale anomaliilor sînt suficiente
- Lecția comună: comparați toate modelele cu aceeași măsură și raportați incertitudinea ei

Înapoi

Factor zoo redus prin LASSO cu dublă selecție

- Feng, Giglio & Xiu (2020): aduce un factor nou informație suplimentară față de factorii deja cunoscuți?
- **LASSO cu dublă selecție** (Least Absolute Shrinkage and Selection Operator)
  - LASSO: regresie cu o penalizare care pune exact la zero coeficienții variabilelor neimportante, deci selectează variabilele
  - Pasul 1: dintre sute de factori existenți, LASSO îi alege pe cei care explică randamentele medii ale activelor de test
  - Pasul 2: un al doilea LASSO îi alege pe cei corelați cu factorul nou, ca omiterea lor să nu distorsioneze rezultatul
  - Pasul 3: se testează coeficientul factorului nou în SDF, controlînd pentru toți factorii aleși în pașii 1 și 2
- Rezultat: majoritatea factorilor noi sînt redundanți
- Doar cîțiva factori noi explică randamente pe care cei vechi nu le explică
- Studiul de caz ajunge la o concluzie compatibilă
  - mulți factori sînt redundanți
  - informația se concentrează în cîteva teme

Înapoi

De ce nu concordă estimatorii numărului de factori

- Onatski (2010): un factor este real dacă valoarea lui proprie iese clar dintr-un interval
  - intervalul în care cad valorile proprii ale zgomotului
- Pentru zgomot pur, valorile proprii ale matricei de corelație cad în $[(1-\sqrt{N/T})^2, (1+\sqrt{N/T})^2]$
  - $=[0{,}86;\ 1{,}15]$ pentru $N=11,\ T=2\,073$
  - a doua valoare proprie, 1,06, este în interval
  - deci regula Kaiser ($\ell_k > 1$) numără un factor de zgomot
- Bai & Ng (2002): cu $N=11,\ T=2\,073$, penalizarea din IC_{p2} este 0,219 pe factor
- Pe sectoare, criteriul $IC_{p2}(k)$ pentru $k=0,\ldots,5$
  - $0;\ -0{,}86;\ -0{,}97;\ -1{,}12;\ -1{,}14;\ -1{,}17$
- Criteriul scade pînă la maximul permis, $k_{\max}=5$
  - penalizarea este prea mică pentru a opri adăugarea factorilor slabi
- Raportați intervalul estimațiilor și sensibilitatea la $k_{\max}$, nu un singur număr
  - Seminarul 3, problema B3

Înapoi

PCA cu primă de risc și estimarea primelor în trei etape

- **RP-PCA** (Risk-Premium PCA, PCA cu primă de risc, Lettau & Pelger (2020))
  - componentele principale ale matricei $\frac{1}{T}\mathbf{X}^\top\mathbf{X} + \gamma\bar{\mathbf{x}}\bar{\mathbf{x}}^\top$
  - $\mathbf{X}$: matricea $T \times N$ a randamentelor în exces, $\bar{\mathbf{x}}$: mediile lor, γ: ponderea randamentelor medii
  - $\gamma = -1$ dă PCA pe covariață
  - $\gamma > -1$ favorizează și factorii care explică randamentele medii
  - În datele autorilor, metoda găsește factori cu rapoarte Sharpe mai mari și erori de evaluare mai mici decît PCA
- **Estimatorul în trei etape** (Giglio & Xiu (2021))
  - prima unui factor observat g_t cînd modelul omite factori
  - (1) PCA pe randamentele activelor de test
  - (2) regresia transversală a mediilor pe valorile beta latente
  - (3) regresia lui g_t pe factorii latenți
  - prima lui g_t se obține din primele factorilor latenți și din coeficienții acestei regresii
- Ambele păstrează baza statistică a PCA
  - dar urmăresc explicarea randamentelor medii, nu doar a variației
- IPCA adaugă în plus caracteristicile activelor

Înapoi

IPCA și factorii criptoactivelor

- IPCA leagă PCA (statistica) de sortările după caracteristici (Fama–French)
  - beta variabil în timp, puțini factori
- Criptoactive: factorii piață, mărime și momentum (Liu, Tsyvinski & Wu (2022))
  - evaluează secțiunea transversală a criptomonedelor
- Reducerea dimensionalității: Pele et al. (2023), Jheng et al. (2026)
  - pe caracteristicile randamentelor criptoactivelor și activelor tradiționale
- Curs avansat: Multivariate Statistical Analysis

Înapoi

Construcția celor 153 de factori

- **Date** (Secțiunea II a articolului)
  - 138 din lista alcătuită de Hou, Xue & Zhang (2020) și 15 din alte studii
  - randamente americane din 1926, majoritatea piețelor dezvoltate din 1986
  - toate în dolari americani, în exces față de rata titlurilor de stat americane pe termen scurt
- **Construcția**, în fiecare țară și lună
  - treimi după caracteristică, cu praguri calculate fără firmele foarte mici (microcapitalizări)
  - ponderi după capitalizarea plafonată la percentila 80 a NYSE
  - perioada de deținere: o lună
  - cel puțin 5 acțiuni pe fiecare parte și 60 de observații lunare
- **Teme**: 13 grupe de factori americani (Secțiunea II.B)
  - grupare ierarhică, cu distanța $1-$ corelația reziduurilor CAPM și metoda Ward (unește grupele care cresc cel mai puțin varianța din interiorul grupelor)

înapoi

Ierarhia bayesiană a valorilor alfa

- **Ierarhia** (Secțiunea I a articolului)
  - $\alpha_i = c_j + s_n + w_i$ (tema j, semnalul n, factorul i; ec. 21)
  - varianța a priori $\mathbf{\Omega} = \mathrm{M}\mathrm{M}^\top \tau_c^2 + \mathrm{Z}\mathrm{Z}^\top \tau_s^2 + \mathrm{I}\tau_w^2$ (ec. 23)
  - media a posteriori $(\mathbf{\Omega}^{-1} + T\mathbf{\Sigma}^{-1})^{-1} T\mathbf{\Sigma}^{-1}\hat{\boldsymbol{\alpha}}$ (Propoziția 4)
  - M, Z: matrice 0/1 care leagă fiecare factor de tema și semnalul lui
  - $\tau_c^2, \tau_s^2, \tau_w^2$: variațele celor trei componente ale lui alfa
  - $\mathbf{\Sigma}$: covarianța reziduurilor
  - estimare Bayes empirică: τ_c, τ_s, τ_w prin verosimilitate maximă pentru $\hat{\boldsymbol{\alpha}} \sim N(0, \mathbf{\Omega} + \hat{\mathbf{\Sigma}}/T)$ (Secțiunea I.C.2)

înapoi

Rezultatele complete

- Cu OLS se replică 98 din 119 factori americani
- Corecția Benjamini–Yekutieli cere $|t| > 2{,}7$ (Figura 4)
- FDR bayesian: 0,1%, cu intervalul de 95% $[0; 1\%]$
- Ponderea așteptată a factorilor adevărați: 94% (Secțiunea III.C)
- Rata de replicare pentru firmele cu capitalizare foarte mare și mare (Figura 5)
  - 77,3% și 79,8%
- 11 din 13 teme au o rată de cel puțin 50%
  - excepțiile sînt îndatorarea redusă și mărimea
- Rata mare și la firmele mari arată că rezultatul nu vine doar din firmele foarte mici
- Raportul Sharpe (lunar) al portofoliului tangent, SUA 1972–2020 (Figura 14)
  - piața: 0,13
  - toți factorii: 0,80

Înapoi

Replicarea din curs în detaliu

- Benjamini–Yekutieli dă cea mai mică rată, ca în rezultatele americane din articol (Figura 1)
- Emisiunile nete de acțiuni sînt trase spre media temei lor
  - de la 0,44% la 0,27% pe lună
- Abaterea standard a posteriori este 0,07%–0,10%, sub eroarea standard OLS de 0,11%
  - fiecare factor împrumută informație de la ceilalți factori ai temei
- **Dispersia a priori**: $\hat{\tau}_c = 0{,}28\%$, $\hat{\tau}_w = 0{,}04\%$ pe lună
  - față de 0,35% și 0,21% raportate în Tabelul I al articolului
  - cu 15 semnale rămîne puțină dispersie specifică factorilor
- **Teme**: cele 15 semnale se încadrează în 8 dintre cele 13 teme ale articolului
  - 5 în valoare, 3 în risc scăzut, 2 în investiții

Înapoi

Limite precizate de autori și extinderi

- **Limite precizate de autori**
  - CAPM este singurul model de referință: factorii de îndatorare redusă nu au alfa CAPM semnificativ, dar contribuie cînd sînt combinați cu celelalte teme (Secțiunea III.A)
  - Toate caracteristicile sînt construite după aceeași regulă, uneori altfel decît în articolul original (Secțiunea II.C)
  - Factorii încercați, dar nepublicați, ar schimba distribuția a priori: în scenariile lui Harvey, Liu & Zhu (2016), rata pentru SUA scade la 81,5%, respectiv 79,8% (Figura 10)
- **Completarea replicării de curs** (Seminarul 3, C3)
  - justificați semnul fiecărui factor pe baza studiului inițial
  - comparați dendrograma cu temele articolului
  - adăugați FDR bayesian și panta după eșantion (Figura 8)
- Datele și codul articolului
  - jkpfactors.com
  - github.com/bkelly-lab/ReplicationCrisis

înapoi

Bucla descoperirii, prompturi reutilizabile (1/2)

- **Literatură**
  - `Rezumă dovezile din 2016 încoace despre scăderea după publicare și replicarea randamentelor anomaliilor. Pentru fiecare lucrare: DOI, eșantion, numărul de factori, estimația principală, identificarea scăderii. Marchează intrările nesigure.`
  - Verificați fiecare DOI în Crossref
  - Verificați fiecare cifră principală în rezumat
- **Ipoteză**
  - `Compară data mining-ul, arbitrajul bazat pe informația publicată și riscul variabil în timp ca explicații ale scăderii. Pentru fiecare: tiparul prezis între perioadele din eșantion, după eșantion și după publicare, și între acțiunile cu limite mari și cele cu limite mici ale arbitrajului.`
- **Date și cod**
  - `Încarcă factorul lunar de momentum din Kenneth French Data Library; din 1965, regresează MOM pe o variabilă dummy după eșantion (1990-01 până la 1993-03) și una după publicare (din 1993-04), cu erori Newey-West.`
  - Replicați întîi o cifră cunoscută: momentum $t = 5{,}53$ înainte de 2000 și 0,75 după (graficul pe subperioade)

Înapoi

Bucla descoperirii, prompturi reutilizabile (2/2)

- **Robustețe**
  - `Scrie un plan de robustețe preînregistrat: cîte o dată de publicare pentru fiecare factor, corecția Holm între factori, excluderea crahului de momentum din 2009, data documentului de lucru în locul datei din revistă și perioada 1927-1962 ca placebo pentru Mkt-RF, SMB, HML și MOM (RMW și CMA încep în iulie 1963).`
- **Critică**
  - `Evaluează critic: un factor, o dată de publicare, t = -1,45. Care este puterea de a detecta o scădere de 58%? De ce o schimbă combinarea mai multor anomalii?`
- **Raport**
  - Media in-sample, ambele variabile dummy cu erori Newey–West, placebo-ul, versiunea datelor (data descărcării)
  - Factori combinați: erori robuste la corelația dintre factori în aceeași lună și la autocorelație
  - Prompturile care au influențat o decizie intră în `AI_USE.md`
- Asistentul AI propune variantele de robustețe
- Cercetătorul alege dinainte care sînt raportate

Înapoi

Verificările cercetătorului

- **Data greșită a evenimentului**
  - data încheierii eșantionului, data difuzării documentului de lucru și data publicării în revistă sînt diferite
  - test: citiți-le din lucrarea însăși
- **Alegerea factorului după ce s-a văzut că a scăzut**: fixați dinainte lista factorilor
- Aplicați Holm sau BH pe toți factorii
- **Randamente autocorelate, cu crahuri**: erori Newey–West
- Reestimați fără anul 2009
- **Versiunile datelor**: biblioteca de factori este revizuită retroactiv
  - test: notați data descărcării
  - reproduceți statisticile t pe subperioade din capitol
- **Putere mică**: cu un singur factor, H_0 se respinge rar
- Raportați intervalul de încredere al scăderii, nu doar semnul ei

Înapoi

Răspunsurile la verificările rapide (1/2)

Beta, eroarea și shrinkage-ul

- Clasic: $0{,}90 \pm 1{,}96 \times 0{,}05 = [0{,}80; 1{,}00]$, imediat sub 1
- Newey–West: $0{,}90 \pm 0{,}18 = [0{,}72; 1{,}08]$, conține 1: nicio dovadă că acțiunea este mai puțin riscantă
- Raportați Newey–West: reziduurile sînt heteroscedastice și autocorelate; HAC schimbă varianța estimată, nu estimația OLS
- $\sigma_\beta^2 = 0{,}10 - 0{,}02 = 0{,}08$; SE 0,2: $w = 0{,}08/0{,}12 = 0{,}67$, $\beta^V = 0{,}67 \times 1{,}6 + 0{,}33 \times 1{,}0 = 1{,}40$; SE 0,1: $w = 0{,}08/0{,}09 = 0{,}89$, $\beta^V = 1{,}53$
- Estimația mai zgomotoasă primește mai mult shrinkage; Blume dă $0{,}33 + 0{,}67 \times 1{,}6 = 1{,}40$ indiferent de precizie
- Beta Dimson: $0{,}25 + 0{,}55 + 0{,}00 = 0{,}80$; prețul acțiunii încorporează randamentul pieței cu o zi întîrziere, deci panta din aceeași zi pierde partea de 0,25

Citirea unei statistici GRS

- $W = \frac{60}{4} \times (0{,}25^2 - 0{,}15^2)/(1 + 0{,}15^2) = 15 \times 0{,}040/1{,}0225 = 0{,}59 < 2{,}53$: nerespins
- Cîștigul așteptat $4 \times 1{,}0225/58 = 0{,}071$, peste cel observat, 0,040: distanța este în limitele zgomotului
- $T = 650$: $W = \frac{645}{4} \times 0{,}0391 = 6{,}31 > 2{,}39$: respins; distanța este aceeași, dovezile cresc cu T

înapoi

Răspunsurile la verificările rapide (2/2)

Prime, Shanken și un R^2 negativ

- $\text{se}_{FM} = 3\%/\sqrt{400} = 0{,}15\%$, $t = 3{,}33$
- $c = 0{,}5^{\mathbf{2}}/1^{\mathbf{2}} = 0{,}25$; $\text{Var}_{\mathbf{Sh}} = 1{,}25 \times (0{,}0225 - 0{,}0025) + 0{,}0025 = 0{,}0275$, SE 0,166%, $t = 3{,}02$: doar puțin peste 3
- Factor tranzacționat: $c = 0{,}25/4{,}5^{\mathbf{2}} = 0{,}012$, deci corecția este neglijabilă
- Media 4%: $\text{SST} = 4 + 0 + 4 = 8$, $\text{SSE} = 16 + 0 + 16 = 32$, $R^{\mathbf{2}} = 1 - 32/8 = -3$; cu termen liber, pantele zero dau deja SSE = SST, iar OLS poate doar să micșoreze SSE

Numărarea descoperirilor

- Naiv 4; Bonferroni (0,01) 1; Holm: $0{,}004 \leq 0{,}01$, $0{,}012 \leq 0{,}0125$, $0{,}020 > 0{,}0167$ oprire: 2; pragurile BH $0{,}01j$: $0{,}030 \leq 0{,}040$ este ultima respingere: 4
- BY: suma este 2,283, pragurile $0{,}0044j$: trece doar 0,004: 1
- $1 - 0{,}95^{\mathbf{5}} = 0{,}23$
- O căutare printre candidați: BH (FDR)
- „Niciun factor nu este fals”: Holm sau Bonferroni (FWER)

Înapoi

Pentru aprofundare: cursuri și cod

Cursuri avansate pe quantinar.com

- Generalized Method of Moments
- Multivariate Statistical Analysis

Cod și date

- Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_03
- Datele factorilor: Kenneth French Data Library

Înapoi

Bibliografie (1/6)

- Ahn, S.C., Horenstein, A.R. (2013). Eigenvalue ratio test for the number of factors. *Econometrica*, 81(3), 1203–1227.
- Anatolyev, S., Mikusheva, A. (2022). Factor models with many assets: strong factors, weak factors, and the two-pass procedure. *Journal of Econometrics*, 229(1), 103–126.
- Ang, A., Liu, J., Schwarz, K. (2020). Using stocks or portfolios in tests of factor models. *Journal of Financial and Quantitative Analysis*, 55(3), 709–750.
- Bai, J., Ng, S. (2002). Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 191–221.
- Barillas, F., Shanken, J. (2018). Comparing asset pricing models. *Journal of Finance*, 73(2), 715–754.
- Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- Benjamini, Y., Yekutieli, D. (2001). The control of the false discovery rate in multiple testing under dependency. *Annals of Statistics*, 29(4), 1165–1188.
- Black, F. (1972). Capital market equilibrium with restricted borrowing. *Journal of Business*, 45(3), 444–455.
- Blume, M.E. (1971). On the assessment of risk. *Journal of Finance*, 26(1), 1–10.
- Bryzgalova, S., Huang, J., Julliard, C. (2023). Bayesian solutions for the factor zoo: we just ran two quadrillion models. *Journal of Finance*, 78(1), 487–557.

Bibliografie (2/6)

- Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). The Econometrics of Financial Markets. Princeton University Press.
- Carhart, M.M. (1997). On persistence in mutual fund performance. *Journal of Finance*, 52(1), 57–82.
- Chen, A.Y., Zimmermann, T. (2022). Open source cross-sectional asset pricing. *Critical Finance Review*, 11(2), 207–264.
- Cochrane, J.H. (2011). Presidential address: discount rates. *Journal of Finance*, 66(4), 1047–1108.
- Daniel, K., Moskowitz, T.J. (2016). Momentum crashes. *Journal of Financial Economics*, 122(2), 221–247.
- Dimson, E. (1979). Risk measurement when shares are subject to infrequent trading. *Journal of Financial Economics*, 7(2), 197–226.
- Fama, E.F., French, K.R. (1992). The cross-section of expected stock returns. *Journal of Finance*, 47(2), 427–465.
- Fama, E.F., French, K.R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56.
- Fama, E.F., French, K.R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- Fama, E.F., MacBeth, J.D. (1973). Risk, return, and equilibrium: empirical tests. *Journal of Political Economy*, 81(3), 607–636.
- Fan, J., Liao, Y., Yao, J. (2015). Power enhancement in high-dimensional cross-sectional tests. *Econometrica*, 83(4), 1497–1541.

Bibliografie (3/6)

- Feng, G., Giglio, S., Xiu, D. (2020). Taming the factor zoo: a test of new factors. *Journal of Finance*, 75(3), 1327–1370.
- Frazzini, A., Pedersen, L.H. (2014). Betting against beta. *Journal of Financial Economics*, 111(1), 1–25.
- Gibbons, M.R., Ross, S.A., Shanken, J. (1989). A test of the efficiency of a given portfolio. *Econometrica*, 57(5), 1121–1152.
- Giglio, S., Xiu, D. (2021). Asset pricing with omitted factors. *Journal of Political Economy*, 129(7), 1947–1990.
- Hansen, L.P. (1982). Large sample properties of generalized method of moments estimators. *Econometrica*, 50(4), 1029–1054.
- Hansen, L.P., Jagannathan, R. (1997). Assessing specification errors in stochastic discount factor models. *Journal of Finance*, 52(2), 557–590.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). . . . and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.

Bibliografie (4/6)

- Hou, K., Xue, C., Zhang, L. (2015). Digesting anomalies: an investment approach. *Review of Financial Studies*, 28(3), 650–705.
- Hou, K., Xue, C., Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133.
- Jagannathan, R., Wang, Z. (1998). An asymptotic theory for estimating beta-pricing models using cross-sectional regression. *Journal of Finance*, 53(4), 1285–1309.
- Jegadeesh, N., Titman, S. (1993). Returns to buying winners and selling losers: implications for stock market efficiency. *Journal of Finance*, 48(1), 65–91.
- Jensen, M.C. (1968). The performance of mutual funds in the period 1945–1964. *Journal of Finance*, 23(2), 389–416.
- Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance? *Journal of Finance*, 78(5), 2465–2518.
- Jheng, S.-L., Găman, Ș., Conda, A., Pele, D.T., Härdle, W.K., Teng, H.-W., Osterrieder, J. (2026). Crypto currency returns. Document de lucru SSRN.
- Kaiser, H.F. (1960). The application of electronic computers to factor analysis. *Educational and Psychological Measurement*, 20(1), 141–151.
- Kan, R., Robotti, C., Shanken, J. (2013). Pricing model performance and the two-pass cross-sectional regression methodology. *Journal of Finance*, 68(6), 2617–2649.
- Kan, R., Zhang, C. (1999). Two-pass tests of asset pricing models with useless factors. *Journal of Finance*, 54(1), 203–235.
- Kelly, B.T., Pruitt, S., Su, Y. (2019). Characteristics are covariances: a unified model of risk and return. *Journal of Financial Economics*, 134(3), 501–524.

Bibliografie (5/6)

- Kleibergen, F. (2009). Tests of risk premia in linear factor models. *Journal of Econometrics*, 149(2), 149–173.
- Kozak, S., Nagel, S., Santosh, S. (2020). Shrinking the cross-section. *Journal of Financial Economics*, 135(2), 271–292.
- Lettau, M., Pelger, M. (2020). Factors that fit the time series and cross-section of stock returns. *Review of Financial Studies*, 33(5), 2274–2325.
- Lewellen, J., Nagel, S., Shanken, J. (2010). A skeptical appraisal of asset pricing tests. *Journal of Financial Economics*, 96(2), 175–194.
- Lintner, J. (1965). The valuation of risk assets and the selection of risky investments in stock portfolios and capital budgets. *Review of Economics and Statistics*, 47(1), 13–37.
- Liu, Y., Tsyvinski, A., Wu, X. (2022). Common risk factors in cryptocurrency. *Journal of Finance*, 77(2), 1133–1177.
- Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- McLean, R.D., Pontiff, J. (2016). Does academic research destroy stock return predictability? *Journal of Finance*, 71(1), 5–32.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Newey, W.K., West, K.D. (1994). Automatic lag selection in covariance matrix estimation. *Review of Economic Studies*, 61(4), 631–653.
- Onatski, A. (2010). Determining the number of factors from empirical distribution of eigenvalues. *Review of Economics and Statistics*, 92(4), 1004–1016.

Bibliografie (6/6)

- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets? *The European Journal of Finance*, 29(10), 1064–1105.
- Pesaran, M.H., Yamagata, T. (2024). Testing for alpha in linear factor pricing models with a large number of securities. *Journal of Financial Econometrics*, 22(2), 407–460.
- Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- Roll, R. (1977). A critique of the asset pricing theory's tests Part I: On past and potential testability of the theory. *Journal of Financial Economics*, 4(2), 129–176.
- Ross, S.A. (1976). The arbitrage theory of capital asset pricing. *Journal of Economic Theory*, 13(3), 341–360.
- Shanken, J. (1992). On the estimation of beta-pricing models. *Review of Financial Studies*, 5(1), 1–33.
- Sharpe, W.F. (1964). Capital asset prices: a theory of market equilibrium under conditions of risk. *Journal of Finance*, 19(3), 425–442.
- Vasicek, O.A. (1973). A note on using cross-sectional information in Bayesian estimation of security betas. *Journal of Finance*, 28(5), 1233–1239.
- White, H. (1980). A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4), 817–838.
- Date: Kenneth R. French Data Library, mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html.

Acronime folosite în acest material (1/3)

- **AI**: Artificial Intelligence — *inteligență artificială*
- **APT**: Arbitrage Pricing Theory — *teoria evaluării prin arbitraj*
- **BAB**: Betting Against Beta — *strategia „pariu împotriva lui beta"*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BET-TR**: BET Total Return (index) — *indicele BET cu dividendele reinvestite*
- **B/M**: Book-to-Market — *raportul dintre valoarea contabilă și valoarea de piață*
- **BH**: Benjamini–Hochberg (procedure) — *procedura Benjamini–Hochberg*
- **BVB**: Bursa de Valori București
- **BY**: Benjamini–Yekutieli (procedure) — *procedura Benjamini–Yekutieli*
- **CAGR**: Compound Annual Growth Rate — *rata anuală compusă de creștere*
- **CAPM**: Capital Asset Pricing Model — *modelul de evaluare a activelor financiare*
- **CMA**: Conservative Minus Aggressive (investment factor) — *factorul investiții: firme conservatoare minus agresive*
- **CML**: Capital Market Line — *dreapta pieței de capital*
- **DOI**: Digital Object Identifier — *identificator digital de obiect*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- **FDR**: False Discovery Rate — *rata descoperirilor false*
- **FF3**: Fama–French three-factor model — *modelul Fama–French cu trei factori*
- **FF5**: Fama–French five-factor model — *modelul Fama–French cu cinci factori*

Acronime folosite în acest material (2/3)

- **FWER**: Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **GLS**: Generalised Least Squares — *metoda celor mai mici pătrate generalizate*
- **GMM**: Generalized Method of Moments — *metoda generalizată a momentelor*
- **GRS**: Gibbons–Ross–Shanken (test) — *testul Gibbons–Ross–Shanken*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HML**: High Minus Low (value factor) — *factorul valoare: B/M mare minus mic*
- **IPCA**: Instrumented Principal Component Analysis — *analiza instrumentată a componentelor principale*
- **LASSO**: Least Absolute Shrinkage and Selection Operator — *regresie penalizată L1 cu selecția variabilelor*
- **MOM**: Momentum (factor) — *factorul momentum*
- **NYSE**: New York Stock Exchange — *Bursa din New York*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **OMV**: Österreichische Mineralölverwaltung — *Administrația Austriacă a Petrolului (grupul OMV)*
- **PC1**: first Principal Component — *prima componentă principală*

Acronime folosite în acest material (3/3)

- **PC2**: second Principal Component — *a doua componentă principală*
- **PC3**: third Principal Component — *a treia componentă principală*
- **PCA**: Principal Component Analysis — *analiza componentelor principale*
- **PRDS**: Positive Regression Dependence on a Subset (of p-values) — *dependența pozitivă de regresie pe o submulțime (a p-value-urilor)*
- **RF**: Risk-Free rate — *rata fără risc*
- **RMSE**: Root Mean Squared Error — *rădăcina erorii pătratice medii*
- **RMW**: Robust Minus Weak (profitability factor) — *factorul profitabilitate: firme robuste minus slabe*
- **ROE**: Return On Equity — *rentabilitatea capitalului propriu*
- **RP-PCA**: Risk-Premium Principal Component Analysis — *analiza componentelor principale cu primă de risc*
- **SDF**: Stochastic Discount Factor — *factorul stocastic de actualizare*
- **SE**: Standard Error — *eroarea standard*
- **SMB**: Small Minus Big (size factor) — *factorul mărime: firme mici minus mari*
- **SML**: Security Market Line — *dreapta pieței titlurilor*
- **SSE**: Sum of Squared Errors — *suma pătratelor erorilor*
- **SST**: Total Sum of Squares — *suma totală a pătratelor abaterilor de la medie*
- **SUA**: Statele Unite ale Americii
- **UMD**: Up Minus Down (momentum factor) — *factorul momentum: cîștigători minus perdanți*