



Modelarea piețelor financiare

Capitolul 3: Modele factoriale și evaluarea activelor



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ APT: Arbitrage Pricing Theory (teoria evaluării prin arbitraj)
- ▣ BAB: Betting Against Beta (strategia „pariu împotriva lui beta”)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- ▣ BVB: Bursa de Valori București
- ▣ CAGR: Compound Annual Growth Rate (rata anuală compusă de creștere)
- ▣ CAPM: Capital Asset Pricing Model (modelul de evaluare a activelor financiare)
- ▣ CMA: Conservative Minus Aggressive (investment factor) (factorul investiții: firme conservatoare minus agresive)
- ▣ CML: Capital Market Line (dreapta pieței de capital)
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ FDR: False Discovery Rate (rata descoperirilor false)
- ▣ FF3: Fama–French three-factor model (modelul Fama–French cu trei factori)
- ▣ FF5: Fama–French five-factor model (modelul Fama–French cu cinci factori)
- ▣ FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- ▣ GLS: Generalised Least Squares (metoda celor mai mici pătrate generalizate)
- ▣ GMM: Generalized Method of Moments (metoda generalizată a momentelor)
- ▣ GRS: Gibbons–Ross–Shanken (test) (testul Gibbons–Ross–Shanken)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HJ: Hansen–Jagannathan (distance) (distanța Hansen–Jagannathan)
- ▣ HML: High Minus Low (value factor) (factorul valoare: B/M mare minus mic)
- ▣ IPCA: Instrumented Principal Component Analysis (analiza componentelor principale instrumentată)
- ▣ LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- ▣ MOM: MOMentum factor (factorul momentum)
- ▣ NYSE: New York Stock Exchange (Bursa din New York)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)

Acronime folosite în acest material (2/2)

- ▣ OMV: Österreichische Mineralölverwaltung (Administrația austriacă a uleiurilor minerale (grupul OMV))
- ▣ PC1: first Principal Component (prima componentă principală)
- ▣ PC2: second Principal Component (a doua componentă principală)
- ▣ PC3: third Principal Component (a treia componentă principală)
- ▣ PCA: Principal Component Analysis (analiza componentelor principale)
- ▣ RF: Risk-Free rate (rata fără risc)
- ▣ RMSE: Root Mean Squared Error (rădăcina erorii pătratice medii)
- ▣ RMW: Robust Minus Weak (profitability factor) (factorul profitabilitate: firme robuste minus slabe)
- ▣ ROE: Return On Equity (rentabilitatea capitalului propriu)
- ▣ RP-PCA: Risk-Premium Principal Component Analysis (analiza componentelor principale cu prima de risc)
- ▣ SDF: Stochastic Discount Factor (factorul stochastic de actualizare)
- ▣ SMB: Small Minus Big (size factor) (factorul mărime: firme mici minus mari)
- ▣ SML: Security Market Line (dreapta pieței titlurilor)
- ▣ SUA: Statele Unite ale Americii
- ▣ UMD: Up Minus Down (momentum factor) (factorul momentum: câștigători minus perdanți)

Cuprins

Motivație

De la Markowitz la CAPM

Estimarea lui beta

Testarea CAPM

Regresii Fama–MacBeth

Modele multifactoriale

Grădina zoologică a factorilor și testarea multiplă

Factori latenți: PCA și IPCA

Investiții factoriale

Studiu de caz: există o criză a replicării în finanțe?

AI pentru descoperire științifică

Concluzii

Bibliografie

Ce este un model factorial?

Definiție

- Un **model factorial** explică randamentul activului i prin câteva variabile comune $f_{1,t}, \dots, f_{K,t}$, numite **factori**

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_{i,1}f_{1,t} + \dots + \beta_{i,K}f_{K,t} + \varepsilon_{i,t}$$

- $\beta_{i,k}$: **încărcarea factorială** (expunerea) activului i la factorul k ; $\varepsilon_{i,t}$: șoc specific activului (idiosincratic)

Mesajul-cheie al capitolului

- Randamentele așteptate ar trebui explicate prin **expuneri la riscuri remunerate**, nu prin numele activului; testarea acestei afirmații este miezul evaluării empirice a activelor

De ce contează modelele factoriale

- ▣ **Costul capitalului:** randamentul cerut de investitori de la o firmă sau un proiect
- ▣ **Evaluarea performanței:** a obținut fondul un randament mai mare decât piața sau doar și-a asumat mai mult risc?
- ▣ **Managementul riscului:** N active necesită $N(N + 1)/2$ covarianțe; K factori reduc drastic acest număr
- ▣ **Construcția portofoliilor:** expunerile factoriale se pot cumpăra direct (ETF-uri factoriale, Secțiunea 8)
- ▣ **Evaluarea activelor:** ce riscuri sunt remunerate și de ce? (manual: [Campbell, Lo & MacKinlay \(1997\)](#), cap. 5–6)

Datele folosite în acest capitol

Serie	Conținut	Perioadă
Factorii Fama–French	piață, mărime, valoare, profitabilitate, investiții	1963–2026
Factorul momentum	câștigători minus perdanți	1963–2026
25 portofolii mărime $\times$ B/M	acțiuni SUA sortate după două caracteristici	1963–2026
ETF-uri sectoriale SUA	11 sectoare ale S&P 500	1999–2026
ETF-uri factoriale	momentum, valoare, calitate, vol. minimă, mărime	2013–2026
Blue chips BVB, BET	11 acțiuni românești și indicele lor	2015–2026

- Randamentele factorilor și ale portofoliilor: [Kenneth French Data Library](#)
- Prețuri: folderul data/market din repository, până la 18 septembrie 2026

Datele

- ▣ **ETF**-uri folosite în capitol
 - ▶ ETF-uri sectoriale: XLK (tehnologie), XLF (financiar), XLE (energie), XLU (utilități), ...; SPY replică S&P 500
- ▣ **B/M**: book-to-market, valoarea contabilă a capitalului propriu împărțită la valoarea sa de piață
- ▣ **BET**: indicele de referință al BVB
- ▣ Blue chips folosite: TLV, SNP, BRD, TGN, FP, SNG, H2O, SNN, EL, DIGI, TEL (denumirile complete pe grafic)
- ▣ ETF-uri și acțiuni: prețuri ajustate pentru dividende și split-uri; indici: valori de închidere (Capitolul 1)

Randamente în exces și rata fără risc

- ▣ **Rata fără risc** $R_{f,t}$: randamentul unui activ fără risc de neplată pe perioada respectivă
 - ▶ SUA: rata titlurilor de stat la o lună (coloana RF din fișierele Fama–French); media 4,35% pe an din 1963
- ▣ **Randament în exces**: $R_{i,t}^e = R_{i,t} - R_{f,t}$, recompensa pentru asumarea riscului
- ▣ **Randamentul în exces al pieței** (Mkt-RF): piața SUA ponderată după capitalizare minus $R_{f,t}$
- ▣ Ipoteză pentru BVB: $R_{f,t}$ zilnică este tratată ca fiind constantă
 - ▶ O constantă se anulează în covarianțe, deci beta nu se schimbă; se modifică doar termenul liber
- ▣ Regresiile pe factorii Fama–French folosesc randamente simple (factorii sunt randamente simple); analizele rulante, BVB și PCA folosesc randamente logaritmice (Capitolul 1)

Recapitularea cunoștințelor necesare: medie–varianță și portofoliul tangent

- **Markowitz (1952)**: cu ponderile w , randamentele în exces așteptate μ și matricea de covarianță Σ , portofoliile de pe frontieră se obțin rezolvând


$$\min_w w^\top \Sigma w \quad \text{s.t.} \quad w^\top \mu = \mu^*, w^\top \mathbf{1} = 1$$

- **Raportul Sharpe** $SR_p = \mathbb{E}[R_p - R_f] / \sigma_p$; cu un activ fără risc, cel mai bun portofoliu riscant este **portofoliul tangent**

$$w_{\text{tan}} = \Sigma^{-1} \mu / \mathbf{1}^\top \Sigma^{-1} \mu$$

- **CML**: combinații între R_f și portofoliul tangent, $\mu_p = SR_{\text{tan}} \sigma_p$; ponderile negative sunt **poziții short**
- De la portofoliul tangent la ecuația de evaluare prin beta: Seminarul A1; eroarea de estimare și shrinkage: Capitolul 4

Frontiera eficientă a sectoarelor din SUA



□ Randamente lunare în exces ale a 9 ETF-uri sectoriale, ianuarie 1999 – iulie 2026 ($T = 331$ luni)

Interpretarea frontierei

- Portofoliul tangent: medie 8,55%, volatilitate 12,96%, raport Sharpe 0,66
- SPY (aproximarea pieței): medie 7,44%, volatilitate 15,08%, raport Sharpe 0,49
 - ▶ Aici piața **nu** se află pe frontieră, cum ar cere CAPM
- Ponderile portofoliului tangent: $-0,37$ în financiar, $-0,21$ în materiale, $+0,37$ în sănătate
- Atenție: frontiera este **în eșantion**; mediile sunt estimate cu multă incertitudine
 - ▶ Optimizarea în afara eșantionului și shrinkage-ul covarianței: Capitolul 4

CAPM: Sharpe, Lintner, Black



William F. Sharpe, Premiul Nobel pentru
Economie 1990

Foto: [Larry D. Moore \(2007\)](#); CC BY 4.0;
[Wikimedia Commons](#)

- **CAPM**: Capital Asset Pricing Model (modelul de evaluare a activelor financiare), [Sharpe \(1964\)](#) și [Lintner \(1965\)](#)
- Întrebarea: dacă fiecare investitor deține un portofoliu eficient medie-varianță, care sunt prețurile de echilibru?
- Răspunsul: toți dețin același portofoliu tangent, deci acesta trebuie să fie **portofoliul pieței**
- [Black \(1972\)](#): o versiune fără activ fără risc (CAPM cu beta zero)
- Sharpe a împărțit Premiul Nobel din 1990 cu Markowitz și Miller

Ecuția CAPM

- Randamentul în exces așteptat este proporțional cu **beta**

$$\mathbb{E}[R_i] - R_f = \beta_i (\mathbb{E}[R_m] - R_f), \quad \beta_i = \frac{\text{Cov}(R_i, R_m)}{\text{Var}(R_m)}$$

- $\mathbb{E}[R_m] - R_f$: **prima de risc a pieței**; β_i : sensibilitatea activului i la piață
- Ipoteze principale
 - ▶ Investitori medie-varianță cu aceleași așteptări, o singură perioadă
 - ▶ Împrumut și plasament nelimitat la R_f ; fără taxe sau costuri de tranzacționare
- Doar beta este remunerat: nicio altă caracteristică nu ar trebui să prezică randamentele
- **SML** (Security Market Line, dreapta pieței titlurilor): orice activ se află pe dreapta (beta, medie) cu panta egală cu prima; CML conține doar portofoliile eficiente. SML este afirmația testabilă (Secțiunea 4)

Recapitulare: de la Markowitz la CAPM

- ▣ Investitorii medie–varianță dețin portofoliul tangent combinat cu activul fără risc
- ▣ La echilibru acest portofoliu este piața, iar randamentele în exces așteptate sunt β_i ori prima
- ▣ CML: portofolii eficiente în (volatilitate, medie); SML: orice activ în (beta, medie)
- ▣ Doar riscul sistematic este remunerat în CAPM
- ▣ În datele sectoriale, aproximarea pieței este departe de frontiera din eșantion
- ▣ Costul capitalului prin CAPM cere un beta estimat și o primă estimată: eroarea primei domină

Recapitularea cunoștințelor necesare: modelul de piață și erorile HAC

- ▣ Modelul de piață $R_{i,t}^e = \alpha_i + \beta_i R_{m,t}^e + \varepsilon_{i,t}$; **OLS** (Ordinary Least Squares, metoda celor mai mici pătrate):
 $\hat{\beta}_i = \widehat{\text{Cov}}(R_i^e, R_m^e) / \widehat{\text{Var}}(R_m^e)$
- ▣ Descompunerea $\sigma_i^2 = \beta_i^2 \sigma_m^2 + \sigma_{\varepsilon,i}^2$: risc sistematic (remunerat în CAPM) plus risc idiosincratic (diversificabil);
 R^2 este ponderea sistematică
- ▣ Grupările de volatilitate (Capitolul 1) fac reziduurile heteroscedastice: folosiți erori **HAC**, [Newey & West \(1987\)](#), cu ponderi Bartlett
- ▣ Regula lagurilor $L = \lfloor 4(T/100)^{2/9} \rfloor$: $T = 331$ luni dă $L = 5$; $T = 757$ dă $L = 6$
- ▣ Aceleași estimății punctuale ca OLS; se schimbă doar erorile standard

Exemplu rezolvat: beta ETF-ului de tehnologie


	Estimație	Eroare std. clasică	Eroare std. Newey–West
α (anualizat)	0,33%	2,27%	2,45%
β	1,277	0,041	0,082

- ▣ XLK pe factorul de piață Mkt-RF din SUA, randamente lunare în exces 1999–2026, $T = 331$, $R^2 = 0,742$
- ▣ Newey–West cu $L = \lfloor 4(3,31)^{2/9} \rfloor = \lfloor 5,2 \rfloor = 5$ laguri
- ▣ Eroarea standard robustă a lui beta este de **două ori** cea clasică
- ▣ Alfa nu se distinge statistic de zero: $t = 0,33/2,45 = 0,13$

Alegeri practice în estimare

- ▣ **Frecvența:** datele zilnice dau mai multe observații, dar suferă de tranzacționare asincronă
- ▣ **Fereastra:** uzual 3–5 ani de date lunare sau 1–2 ani de date zilnice
- ▣ **Aproximarea pieței:** S&P 500 (SPY) pentru active din SUA, BET pentru acțiuni românești
- ▣ **Curățarea datelor:** evenimentele de capital neajustate creează randamente false
 - ▶ Exemplu: un randament logaritmă zilnic de $-6,6$ pentru DIGI în mai 2017; astfel de zile sunt eliminate
- ▣ Raportați mereu eșantionul, frecvența și eroarea standard a lui beta

Beta nu este constant



- Beta pe fereastră mobilă: beta OLS estimat din ultimele 252 de randamente logaritmice zilnice, recalculat zilnic

Interpretarea valorilor beta estimate pe ferestre mobile

- ▣ Financiar (XLF): de la 0,60 la 2,17; maximul urmează crizei bancare din 2008–2009
- ▣ Tehnologie (XLK): de la 0,86 la 1,90; ridicat în anii dot-com, 1,75 la finalul eşantionului
- ▣ Energie (XLE): de la $-0,31$ la 1,49; negativ la final, când petrolul a evoluat contrar pieţei
- ▣ Utilităţi (XLU): de la 0,06 la 1,00; sectorul defensiv clasic
- ▣ Un singur beta pe tot eşantionul ascunde aceste regimuri; modele condiţionale: Capitolele 5–6

Ajustarea lui beta: Blume și Vasicek

- ▣ **Regresia spre medie:** valorile beta extreme sunt parțial zgomot și se apropie ulterior de 1
- ▣ **Blume (1971):** regresia valorilor beta ulterioare pe cele anterioare; regula practicienilor este

$$\beta^{\text{Blume}} = 0,33 + 0,67 \hat{\beta}$$

- ▣ **Vasicek (1973):** medie bayesiană între estimăție și media transversală a priori $\bar{\beta}$

$$\beta_i^V = w_i \hat{\beta}_i + (1 - w_i) \bar{\beta}, \quad w_i = \frac{\sigma_{\beta}^2}{\sigma_{\beta}^2 + \text{se}(\hat{\beta}_i)^2}$$

- ▣ β_i^V este media a posteriori pentru o distribuție a priori Normală $\beta_i \sim N(\bar{\beta}, \sigma_{\beta}^2)$ și $\hat{\beta}_i | \beta_i \sim N(\beta_i, \text{se}_i^2)$ (Seminarul A3)
- ▣ σ_{β}^2 este varianța valorilor beta **adevărate**: $\text{Var}_{cs}(\hat{\beta}) = \sigma_{\beta}^2 + \overline{\text{se}^2}$, deci estimația Bayes empirică este $\sigma_{\beta}^2 = \text{Var}_{cs}(\hat{\beta}) - \overline{\text{se}^2}$


Exemplu rezolvat: beta Vasicek pentru XLK

- ▣ Eșantion ianuarie 1999 – decembrie 2012, lunar, 9 ETF-uri sectoriale
- ▣ XLK: $\hat{\beta} = 1,415$, $\text{se}(\hat{\beta}) = 0,139$ (Newey–West)
- ▣ Media a priori $\bar{\beta} = 0,949$; varianța a priori $\sigma_{\bar{\beta}}^2 = 0,116 - 0,008 = 0,108$
 - ▶ 0,116: varianța celor 9 valori beta estimate; 0,008: media pătratelor erorilor lor standard
- ▣ Ponderea: $w = 0,108 / (0,108 + 0,139^2) = 0,849$

$$\beta^V = 0,849 \times 1,415 + 0,151 \times 0,949 = 1,344$$

- ▣ Beta realizat în 2013–2026 a fost 1,172: ajustarea a mutat estimația în direcția corectă

Regresează beta spre unu?



- Valori beta lunare ale celor 9 ETF-uri sectoriale față de SPY: 1999–2012 (orizontal) vs 2013–2026 (vertical)

Interpretarea regresiei valorilor beta

- Dreapta estimată: $\hat{\beta}_{\text{ulterior}} = 0,23 + 0,72 \hat{\beta}_{\text{anterior}}$, foarte aproape de regula Blume $0,33 + 0,67 \hat{\beta}$
- **RMSE** (Root Mean Squared Error, rădăcina erorii pătratice medii) a prognozei valorilor beta ulterioare


$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_i (\text{prognoza}_i - \hat{\beta}_{i,\text{ulterior}})^2}$$

- Beta brut: 0,135; regula Blume: 0,109; Vasicek: 0,114
- Ajustarea reduce eroarea de prognoză cu 15–20%
- Doar 9 sectoare: lecția este calitativă

România: beta pentru blue chips de la BVB

- Regresia randamentelor logaritmice zilnice ale fiecărei acțiuni pe randamentele logaritmice zilnice ale BET
- Eșantion de la 6 ianuarie 2015 sau de la listare (DIGI 2017, H2O 2023)
- Rata fără risc: presupusă constantă la frecvență zilnică, deci nu afectează beta
- Zilele cu $|r_t| > 0,5$ (evenimente de capital neajustate în prețuri) sunt eliminate: o zi pentru DIGI, două pentru FP
- Intervale de încredere Newey–West de 95% și beta ajustat Vasicek (a priori Bayes empiric din cele 11 acțiuni)

Beta CAPM la Bursa de Valori București



□ Puncte albastre: beta OLS cu intervale de 95%; romburi roșii: beta ajustat Vasicek

Interpretarea valorilor beta de la BVB

- ▣ Băncile sunt cele mai sensibile la piață: Banca Transilvania 1,25, BRD 1,13
- ▣ OMV Petrom 1,06; Romgaz 0,92; valorile pentru utilități și telecomunicații sunt mai mici: Transelectrica 0,76, Digi 0,67
- ▣ R^2 : 0,59 pentru TLV și 0,52 pentru BRD, dar doar 0,21 pentru DIGI
- ▣ Ponderile mari în indice (TLV, SNP, BRD) le cresc mecanic R^2 față de BET
- ▣ Ajustarea Vasicek schimbă puțin: estimațiile zilnice sunt precise (se $\approx$ 0,04–0,07)

Recapitulare: estimarea lui beta

- Beta este o pantă OLS; raportați-l cu erori standard Newey–West
- Beta se schimbă în timp: valorile beta sectoriale între aproximativ $-0,3$ și $2,2$ în ferestre rulante
- Valorile beta extreme regresează spre unu: ajustările Blume și Vasicek îmbunătățesc prognozele
- Băncile românești au cele mai mari valori beta față de BET; utilitățile și telecomul cele mai mici
- Curățați întâi datele: un singur eveniment corporativ neajustat distruge o regresie

Alfa lui Jensen și testul GRS

- ▣ **Alfa lui Jensen** (Jensen (1968)): termenul liber al modelului de piață, $\alpha_i = \mathbb{E}[R_i^e] - \beta_i \mathbb{E}[R_m^e]$; CAPM implică $\alpha_i = 0$ pentru orice activ
- ▣ Câte un test t pentru fiecare activ crește riscul respingerilor false (Secțiunea 7): **GRS**, Gibbons, Ross & Shanken (1989), testează simultan $H_0 : \alpha_1 = \dots = \alpha_N = 0$


$$W = \frac{T - N - 1}{N} \frac{\hat{\alpha}^\top \hat{\Sigma}^{-1} \hat{\alpha}}{1 + \hat{\mu}_m^2 / \hat{\sigma}_m^2} \sim F(N, T - N - 1)$$

- ▣ $\hat{\Sigma}$: covarianța reziduurilor estimată prin verosimilitate maximă (împărțire la T); $\hat{\mu}_m / \hat{\sigma}_m$: raportul Sharpe al pieței
- ▣ Exact, condiționat pe factori, pentru erori i.i.d. cu distribuția Normală multivariată, independente de factori, cu medie zero și covarianță constantă nesară; F : distribuția Fisher
- ▣ Un W mare: piața este departe de frontiera medie–varianță a activelor testate

Cele 25 de portofolii mărime și book-to-market

- Acțiunile din SUA sunt sortate în fiecare iunie în 5 chintile de **mărime** (valoare de piață) și 5 chintile de **B/M**
- $5 \times 5 = 25$ de portofolii ponderate după valoare: de la small-growth (mici, B/M mic) la big-value
- Active de test standard de la [Fama & French \(1993\)](#): prezintă o dispersie mare a randamentelor medii
- Lunar, iulie 1963 – iulie 2026, $T = 757$
- Portofolii în loc de acțiuni individuale: beta este estimat mult mai precis

Dreapta titlurilor în date



- Stânga: randamente medii în exces vs beta CAPM; dreapta: valorile alfa, chintila celor mai mici firme este reprezentată cu roșu

Interpretarea dreptei titlurilor

- CAPM prezice o dreaptă cu panta egală cu prima, 7,2% pe an
- Dreapta transversală estimată are panta $-4,4\%$: beta mai mare, randament mediu **mai mic**
- Valorile beta acoperă doar 0,86–1,42, iar randamentele medii în exces 3,9%–13,3%
- Alfa small-value $+5,7\%$, alfa small-growth $-6,3\%$ pe an; 10 din 25 de valori alfa au $|t| > 1,96$
- $GRS = 4,20$, p -valoare 8×10^{-11} : CAPM este respins

GRS ca test al raportului Sharpe

- Identitate (Gibbons, Ross & Shanken (1989)): cu $\hat{\Sigma}$ și momentele estimate prin verosimilitate maximă

$$\hat{\alpha}^\top \hat{\Sigma}^{-1} \hat{\alpha} = \widehat{SR}^2(f, R) - \widehat{SR}^2(f)$$

- $\widehat{SR}^2(f, R)$: pătratul raportului Sharpe al portofoliului tangent format din factor și cele N active de test

- Deci GRS măsoară creșterea raportului Sharpe obținută prin adăugarea activelor de test

$$W = \frac{T - N - 1}{N} \cdot \frac{\widehat{SR}^2(f, R) - \widehat{SR}^2(f)}{1 + \widehat{SR}^2(f)}$$

- 25 de portofolii, rapoarte Sharpe lunare: piața 0,134 (0,47 pe an); piața plus portofoliile 0,405 (1,40 pe an)
- $W = 29,24 \times (0,405^2 - 0,134^2)/(1 + 0,134^2) = 4,20$; sub H_0 , $\mathbb{E}[W] = \frac{T-N-1}{T-N-3}$, deci câștigul așteptat este doar $N(1 + \widehat{SR}^2(f))/(T - N - 3) = 0,035$, față de 0,146 observat

Când ipotezele GRS nu sunt îndeplinite

- ▣ **Cozi groase și grupări de volatilitate** (Capitolul 1): distribuția F nu mai este exactă
 - ▶ Test Wald GMM: momentele $\varepsilon_t \otimes (1, f_t)$, $W_{\text{GMM}} = \hat{\alpha}^\top \hat{V}_\alpha^{-1} \hat{\alpha} \rightarrow \chi_N^2$, cu $\hat{V}_\alpha$ estimatorul HAC al lui $\text{Var}(\hat{\alpha})$: robust la heteroscedasticitate și autocorelare
 - ▶ Bootstrap pe reziduuri sub H_0 : se reeșantionează rânduri întregi de reziduuri și se reconstruiesc randamentele cu $\alpha = 0$ (Seminarul B11); robust la lipsa normalității doar dacă erorile sunt i.i.d. și independente de factori
- ▣ **N mare**: $\hat{\Sigma}$ are rangul cel mult $T - 2$, deci GRS nu se poate calcula când $N \geq T - 1$
 - ▶ Exemplu: 100 de portofolii mărime $\times$ B/M pe 8 ani de date lunare ($T = 96$); puterea scade mult înainte de acest punct
- ▣ Teste pentru multe active care evită $\hat{\Sigma}^{-1}$: [Pesaran & Yamagata \(2024\)](#); creșterea puterii prin selecția valorilor alfa mari: [Fan, Liao & Yao \(2015\)](#)

O SML plată: intuiția lui Black



Fischer Black (1938–1995)

Foto: Dalmatine at English Wikipedia (încărcată 2009); domeniu public; Wikimedia Commons

- Black (1972): dacă împrumutul este restricționat, investitorii care vor mai mult risc cumpără active cu beta mare în loc să folosească efectul de levier
- Activele cu beta mare devin scumpe, deci randamentele lor viitoare sunt mai mici
- Predicție: SML este **mai plată** decât dreapta CAPM și pornește de la o rată **beta zero** peste R_f
- Același Black este coautor al formulei Black–Scholes pentru opțiuni (Capitolul 12)

Betting Against Beta

- Frazzini & Pedersen (2014) transformă SML plată într-o strategie de tranzacționare, **BAB** (Betting Against Beta, pariul împotriva lui beta)

$$r_t^{\text{BAB}} = \frac{R_{L,t} - R_{f,t}}{\beta_L} - \frac{R_{H,t} - R_{f,t}}{\beta_H}$$

- L : portofoliu cu beta mic, cu levier până la beta 1; H : portofoliu cu beta mare, redus la beta 1
- Portofoliul are beta zero prin construcție, dar câștigă un randament mediu pozitiv în datele lor
- Explicația: constrângerile de levier ale investitorilor, ca la Black (1972)

Critica lui Roll

- Roll (1977): CAPM se referă la portofoliul **adevărat** al pieței, care cuprinde întreaga avuție
- Indicii bursieri omit obligațiunile, imobiliarele, firmele private și capitalul uman
- Fapt matematic: un portofoliu eficient evaluează exact toate activele prin beta: cu R_f pe CML, cu o rată zero-beta (Black (1972)) pe frontiera activelor riscante
- Deci un test CAPM este un test comun al modelului și al eficienței aproximării pieței
- Răspunsul practic: modelele se evaluează după cât de bine evaluează activele, nu ca adevăruri literale

Putere redusă: GRS pe ETF-urile sectoriale

- ▣ Același test pe cele 9 ETF-uri sectoriale, lunar 1999–2026 ($T = 331$)
- ▣ $GRS = 0,53$, $p = 0,85$: CAPM **nu** este respins; sectoarele ridică raportul Sharpe anual doar de la 0,51 la 0,66
- ▣ Valori alfa: utilități +3,4%, energie +2,4%, financiar −2,3% pe an, toate slab susținute statistic
- ▣ Portofoliile sectoriale combină firme mici și mari, de valoare și de creștere: au o dispersie redusă a caracteristicilor relevante
- ▣ Lecția: nerespingerea este o dovadă slabă; alegeți active de test cu dispersie în randamentele așteptate

Recapitulare: testarea CAPM

- CAPM spune că toate valorile alfa sunt zero; testul GRS verifică acest lucru în comun
- Pe cele 25 de portofolii mărime $\times$ B/M, 1963–2026, CAPM este respins categoric
- SML empirică este plată sau negativă; constrângerile de levier (Black; BAB) oferă o explicație
- Roll: orice test testează și aproximarea pieței
- Activele de test contează: ETF-urile sectoriale nu pot respinge CAPM

Teste transversale: Fama și MacBeth



Eugene Fama primind premiul Morgan
Stanley–AFA, 2008

Foto: TonyTheTiger (2008); CC BY-SA 3.0;
Wikimedia Commons

- **Fama & MacBeth (1973)**: estimează **prețul riscului** λ pentru fiecare factor
- **Prima de risc** λ_k : randamentul așteptat suplimentar pe unitatea de expunere $\beta_{i,k}$
- Modelul: $\mathbb{E}[R_i^e] = \lambda_0 + \beta_i^\top \lambda$
- Permite factori care **nu** sunt portofolii tranzacționate și caracteristici ale firmelor ca regresori
- Fama: Premiul Nobel pentru Economie 2013

Cele două etape

- ▣ **Etapa 1** (serii de timp): pentru fiecare activ i , estimăm încărcările

$$R_{i,t}^e = a_i + \beta_i^\top f_t + \varepsilon_{i,t} \quad \Rightarrow \quad \hat{\beta}_i$$

- ▣ **Etapa 2** (transversal): pentru fiecare lună t , regresăm randamentele pe valorile beta estimate

$$R_{i,t}^e = \lambda_{0,t} + \hat{\beta}_i^\top \lambda_t + u_{i,t}, \quad i = 1, \dots, N$$

- ▣ Estimația: $\hat{\lambda} = \frac{1}{T} \sum_t \hat{\lambda}_t$, media celor T pante lunare
- ▣ λ_0 : eroare de evaluare comună tuturor activelor; zero dacă modelul este corect

Erori standard Fama–MacBeth

- ▣ Estimațiile lunare $\hat{\lambda}_{k,t}$ sunt tratate ca un eșantion de volum T

$$se_{FM}(\hat{\lambda}_k) = \frac{s(\hat{\lambda}_{k,t})}{\sqrt{T}}, \quad s^2 = \frac{1}{T-1} \sum_t (\hat{\lambda}_{k,t} - \hat{\lambda}_k)^2$$

- ▣ Avantaj: erorile standard sunt automat robuste la corelația transversală a reziduurilor
- ▣ Dacă $\hat{\lambda}_{k,t}$ este autocorelat, se folosește Newey–West pe această serie
- ▣ Problema: valorile beta din Etapa 2 sunt **estimate**, nu cunoscute


Erori în variabile: corecția Shanken

- ▣ **Erori în variabile:** folosirea lui $\hat{\beta}$ în locul lui β face se_{FM} prea mică
- ▣ Varianța Fama–MacBeth conține deja termenul factorilor Σ_f/T ; [Shanken \(1992\)](#) înmulțește doar restul cu $(1 + c)$

$$\text{Var}_{Sh}(\hat{\lambda}) = (1 + c) \left[\text{Var}_{FM}(\hat{\lambda}) - \frac{1}{T} \Sigma_f \right] + \frac{1}{T} \Sigma_f, \quad c = \hat{\lambda}^\top \Sigma_f^{-1} \hat{\lambda}$$

- ▣ Σ_f : matricea de covarianță a factorilor; c : pătratul raportului Sharpe al primelor, pe perioadă
- ▣ Mică pentru FF3 aici ($c = 0,03$ pe lună); potențial mare când primele estimate sunt mari față de covarianța factorilor, ca la unii factori netranzaționați; rescalarea unui factor nu schimbă c
- ▣ Același rezultat prin **GMM** (Generalized Method of Moments, metoda generalizată a momentelor, [Hansen \(1982\)](#)); vezi Quantinar

Primele de risc estimate



25 de portofolii mărime × B/M, 1963–2026; bare: intervale de 95% cu erori Shanken; cruciuțe: mediile factorilor

Interpretarea primelor de risc

- CAPM: termen liber 14,0% (se 4,4%), prima pieței $-4,4\%$ (se 4,8%)
- FF3: SMB 1,4% (1,4%), HML 4,0% (1,3%); prima pieței rămâne negativă
- FF5: RMW 5,3% (2,1%); CMA $-1,4\%$ (2,2%) nu se distinge statistic de zero (interval 95% de aproximativ $[-5,7\%, 2,9\%]$)
- Pentru un factor tranzacționat, λ ar trebui să fie egal cu media factorului în timp (cruciulițele)
 - ▶ HML: 4,0% vs media 3,6%, apropiate; piața: $-6,5\%$ vs media 7,2%, departe
- Valorile beta de piață acoperă doar 0,86–1,42 (abatere standard transversală 0,14): λ_m este **slab identificat**, iar un termen liber mare absoarbe nivelul (Lewellen, Nagel & Shanken (2010))

Erori standard robuste la specificarea greșită

- Erorile Fama–MacBeth și Shanken presupun un model **corect**: toate erorile de evaluare $e = \mu - X\gamma$ sunt zero ($X = [1, B]$)
- Aici GRS respinge, deci γ este o valoare pseudo-adevărată; zgomotul din $\hat{B}$ se înmulțește cu e și adaugă un termen de varianță (Kan, Robotti & Shanken (2013))
- Scriem ambele etape ca un singur sistem GMM exact identificat; varianța sandwich cu jacobianul complet este cea robustă
 - ▶ Cu $e = 0$ în jacobian se obține versiunea pentru un model corect specificat, robustă la heteroscedasticitate, prezentată de Jagannathan & Wang (1998)
- FF5 pe cele 25 de portofolii: eroarea standard pentru RMW 2,1% → 2,6%, CMA 2,2% → 2,7%, termenul liber 3,3% → 3,8%
- RMW: t scade de la 2,5 la 2,1; pentru HML schimbarea este sub 0,05 puncte procentuale

Exemplu rezolvat: patru erori standard pentru prima de valoare

FF3, HML	$\hat{\lambda}$	Eroare std.	t	Semnificativ la 5%?
Fama–MacBeth	3,97%	1,33%	2,99	da
Newey–West (6 laguri)	3,97%	1,62%	2,45	da
Shanken	3,97%	1,33%	2,99	da
Kan–Robotti–Shanken	3,97%	1,32%	3,00	da

- ▣ Corecția Shanken modifică foarte puțin eroarea standard: $c = 0,03$ pe lună
- ▣ Aici contează cel mai mult autocorelarea pantelor lunare $\hat{\lambda}_t$: Newey–West, 6 laguri conform regulii pentru $T = 757$
- ▣ La pragul $t > 3$ din Secțiunea 7, HML este la limită pentru orice alegere (2,45–3,00)

Factori inutili și factori slabi

- ▣ Un **factor inutil** g_t este independent de toate randamentele: $\beta_g = 0$, deci $\hat{\beta}_{i,g} = O_p(T^{-1/2})$ este doar zgomot
- ▣ Etapa 2 împarte la acest zgomot: $\hat{\lambda}_g$ nu converge la zero, iar testul t respinge prea des când modelul este greșit specificat ([Kan & Zhang \(1999\)](#))
- ▣ Simulare pe cele 25 de portofolii: CAPM plus un factor independent cu distribuția Normală, 2000 de replicări, nivel nominal 5%
 - ▶ $\lambda_g = 0$ este respins în 60% (erori Fama–MacBeth) și 27% (erori Shanken) din replicări
 - ▶ Testul Wald din prima etapă pentru $\beta_{i,g} = 0$, pentru toți i : respins în 6,7%; rulați-l înaintea etapei 2
- ▣ **Factori slabi** (dispersie mică a valorilor beta, ca piața aici): teste robuste la identificare ([Kleibergen \(2009\)](#)); cu multe active, consistența etapei 2 depinde de tăria factorilor ([Anatolyev & Mikusheva \(2022\)](#))

O evaluare sceptică: R^2 transversal

- ▣ Cele 25 de portofolii mărime $\times$ B/M au o structură puternică de trei factori
 - ▶ Orice factori corelați cu SMB și HML pot reproduce randamentele lor medii: un R^2 OLS mare este un criteriu puțin exigent (Lewellen, Nagel & Shanken (2010))
- ▣ Recomandările Lewellen, Nagel & Shanken (2010)
 - ▶ Adăugați active de test cu alte caracteristici, de exemplu 30 de portofolii pe industrii
 - ▶ Pentru factorii tranzacționați impuneți $\lambda = \mathbb{E}[f]$ (factorul se evaluează pe sine)
 - ▶ Raportați R^2 GLS (Generalized Least Squares, metoda celor mai mici pătrate generalizate), ponderat cu $\hat{V}^{-1}$ ca GRS, și intervale de încredere pentru R^2
- ▣ Acțiuni individuale în locul portofoliilor: mai multă dispersie a valorilor beta, dar erori în variabile mai mari (Ang, Liu & Schwarz (2020))

Exemplu rezolvat: adăugăm 30 de portofolii pe industrii

Model	R^2 OLS		R^2 GLS	
	25	25 + 30	25	25 + 30
CAPM	0,08	0,00	0,06	0,01
FF3	0,66	0,22	0,21	0,08
FF5	0,76	0,24	0,26	0,10

- Lunar 1963–2026, termen liber și prime estimate fără restricții; $\hat{V}$: covarianța de selecție a randamentelor activelor de test
- Puterea explicativă a FF3 scade de la 66% la 22% când adăugăm portofoliile pe industrii; R^2 GLS nu depășește niciodată 26%
- Cu $\lambda = \mathbb{E}[f]$ și fără termen liber, R^2 FF3 pe cele 55 de active este negativ ($-0,27$)

Recapitulare: Fama–MacBeth

- ▣ Etapa 1 estimează beta; Etapa 2 face media pantelor transversale lunare
- ▣ Erorile Fama–MacBeth tratează corelația transversală; Newey–West tratează autocorelarea
- ▣ Shanken corectează erorile standard pentru incertitudinea estimării lui beta (efect mic pentru factorii tranzacționați, la frecvență lunară); Kan–Robotti–Shanken ține cont și de specificarea greșită
- ▣ Factorii inutili par remunerați în etapa 2: testați mai întâi valorile beta din prima etapă
- ▣ Pe cele 25 de portofolii primele valori și profitabilității sunt semnificative, dar R^2 transversal se prăbușește când adăugăm industriile

Teoria evaluării prin arbitraj

- ▣ **APT**: Arbitrage Pricing Theory (teoria evaluării prin arbitraj), Ross (1976)
- ▣ Randamentele urmează un model cu K factori și riscuri idiosincratice mici

$$R_{i,t} = \mathbb{E}[R_i] + \beta_i^\top f_t + \varepsilon_{i,t}, \quad \mathbb{E}[f_t] = 0$$

- ▣ **Absența arbitrajului** (niciun profit fără risc și fără investiție) implică, aproximativ

$$\mathbb{E}[R_i] - R_f = \beta_i^\top \lambda$$

- ▣ Teoria nu spune **care** sunt factorii: ei trebuie găsiți în date

Construcția factorilor: portofolii long–short

- Un **factor construit prin sortare** cumpără acțiunile cu valoare mare a unei caracteristici și le vinde pe cele cu valoare mică
- Investiție netă zero: randamentul este o diferență de randamente, $f_t = R_{\text{mare},t} - R_{\text{mic},t}$
- Sortarea Fama–French 2×3: mărime (mic/mare) × caracteristică (30% / 40% / 30%)
 - ▶ **SMB** (Small Minus Big): acțiuni mici minus acțiuni mari
 - ▶ **HML** (High Minus Low): B/M mare (value) minus B/M mic (growth)
- Portofolii reechilibrate în fiecare iunie cu datele contabile din anul anterior

Modelele Fama–French

- Fama & French (1992): mărimea și B/M explică secțiunea transversală; beta nu
- **FF3** (modelul cu trei factori), Fama & French (1993)


$$R_{i,t}^e = \alpha_i + b_i \text{MKT}_t + s_i \text{SMB}_t + h_i \text{HML}_t + \varepsilon_{i,t}$$

- **FF5** (modelul cu cinci factori), Fama & French (2015), adaugă
 - ▶ **RMW** (Robust Minus Weak): profitabilitate operațională mare minus mică
 - ▶ **CMA** (Conservative Minus Aggressive): creștere mică minus mare a activelor (investiții)
- FF3 folosește factorul SMB construit prin sortări 2×3 după mărime și B/M; SMB din FF5 este media diferențelor de randament dintre firmele mici și mari din sortările după B/M, profitabilitate și investiții, deci FF3 nu este inclus în FF5
- Testul unui model: valori alfa din serii de timp apropiate de zero, GRS nerespins

Momentum, Carhart și modelul q

- ▣ **Momentum:** acțiunile cu randamente ridicate în trecut tind să aibă randamente ridicate în următoarele 3–12 luni, Jegadeesh & Titman (1993)
- ▣ **MOM** (UMD, Up Minus Down): acțiuni cu randament mare minus mic din luna $t - 12$ până în $t - 2$
- ▣ Modelul cu patru factori Carhart (1997): $FF3 + MOM$, standard pentru evaluarea fondurilor
- ▣ **Modelul q**, Hou, Xue & Zhang (2015): piață, mărime, investiții și profitabilitate (ROE)
 - ▶ ROE: Return On Equity (rentabilitatea capitalului propriu); motivat de deciziile de investiții ale firmelor
- ▣ FF5 și modelul q sunt rude apropiate; FF5 omite momentum

Şase factori în şaizeci şi trei de ani




- Randamente factoriale lunare compuse, pornind de la 1: randamente în exces sau long-short, deci fără dobânda pe capital sau pe colateral; scară logaritmică

Interpretarea evoluției factorilor

- ▣ Iulie 1963 – iulie 2026: indicele compus a ajuns la 43,2 pentru Mkt-RF și 48,0 pentru MOM
- ▣ Valoare (HML) 6,9, profitabilitate (RMW) 5,7, investiții (CMA) 5,5, mărime (SMB) 2,9
- ▣ Momentum a atins maximul înainte de 2009 și a pierdut mult la revenirea din 2009: un **crash de momentum**
- ▣ Valoarea a stagnat sau a pierdut aproximativ din 2007 până în 2020
- ▣ Randamente anuale medii: Mkt-RF 7,2%, MOM 7,3%, HML 3,6%, RMW 3,1%, CMA 3,0%, SMB 2,3%

Supraviețuiesc primele?



- Statistica t a randamentului lunar mediu al factorului (Newey–West), 1963–1999 vs 2000–2026

Interpretarea statisticilor t pe subperioade

- Momentum: $t = 5,53$ înainte de 2000, 0,75 după; media 10,7% vs 2,5% pe an
- Valoare (HML): $t = 2,39$, apoi 1,02; media 4,2% vs 2,8%
- Profitabilitatea (RMW) este excepția: $t = 1,90$, apoi 2,31
- Prima pieței este robustă în ambele jumătăți ($t = 2,70$ și 2,39)
- McLean & Pontiff (2016): randamentele anomaliilor sunt cu 58% mai mici după publicarea academică, în acord cu această scădere

Factorii ca factor stochastic de actualizare



Lars Peter Hansen, Premiul Nobel pentru
Economie 2013

Foto: [Bengt Nyman \(2013\)](#); CC BY 2.0;
[Wikimedia Commons](#)

- **SDF** (Stochastic Discount Factor, factorul stochastic de actualizare) m_t :
evaluează toate randamentele în exces, $\mathbb{E}[m_t R_{i,t}^e] = 0$
- Un model factorial liniar este un SDF $m_t = 1 - \mathbf{b}^\top (\mathbf{f}_t - \mathbb{E}\mathbf{f})$
- Aceste condiții de momente se estimează prin GMM, [Hansen \(1982\)](#)
- Sinteză a perspectivei ratelor de actualizare: [Cochrane \(2011\)](#)
- Hansen a împărțit Premiul Nobel din 2013 cu Fama și Shiller

Compararea modelelor: rapoarte Sharpe maxime

Raport Sharpe maxim (anual)	CAPM	FF3	Carhart	FF5	FF5 + MOM
1963–2026 ($T = 757$)	0,47	0,66	0,97	0,97	1,16
2000–2026 ($T = 319$)	0,48	0,54	0,67	0,97	1,02

- Barillas & Shanken (2018): un model se judecă după $SR^2(f) = \mu_f^\top \Sigma_f^{-1} \mu_f$ al factorilor săi; activele de test nu contează în comparație
- Modele incluse unul în altul: în eșantion SR^2 nu poate decât să crească, deci testați alfa factorului adăugat pe ceilalți (regresie de acoperire)
 - HML pe ceilalți cinci factori: $\alpha = 0,9\%$ pe an ($t = 0,75$); din 2000 $-1,7\%$ ($t = -0,81$): nicio contribuție incrementală semnificativă a HML, ca în Fama & French (2015)
- FF5 vs Carhart (neincluse unul în altul): diferența SR^2 anual 0,00, interval de 95% $[-0,57; 0,66]$; din 2000 0,50, $[-0,24; 1,48]$ (bootstrap staționar, Politis & Romano (1994))

Dincolo de raportul Sharpe: distanța HJ și selecția bayesiană

- ▣ **Distanța Hansen–Jagannathan** (Hansen & Jagannathan (1997)): distanța în sensul celor mai mici pătrate dintre SDF-ul modelului și mulțimea SDF-urilor valide

$$\delta^2 = \min_b e(b)^\top \mathbb{E}[R^e R^{e\top}]^{-1} e(b), \quad e(b) = \mathbb{E}[m_t(b) R_t^e]$$

- ▶ Randamente în exces R_t^e cu normalizarea $\mathbb{E}[m] = 1$ de pe slide-ul anterior; pentru randamente brute R_t : $e = \mathbb{E}[mR] - 1$, iar SDF-ul are nevoie de o scală liberă ($\mathbb{E}[m] = 1/(1 + R_f)$)
- ▶ Aceeași matrice de ponderare pentru orice model, deci distanțele sunt comparabile; statistica de test are o limită χ^2 ponderată
- ▣ Selecție la scara „grădinii zoologice”: medierea bayesiană a două cvadrilioane de modele factoriale, robustă la factori slabi (Bryzgalova, Huang & Julliard (2023))
- ▣ Shrinkage pentru SDF pe factori construiți din caracteristici: câteva componente principale ale randamentelor anomaliilor captează SDF-ul (Kozak, Nagel & Santosh (2020))
- ▣ Lecția comună: comparați modelele printr-o singură măsură, independentă de model, cu incertitudinea ei de eșantionare

Recapitulare: modele multifactoriale

- APT justifică mai mulți factori remunerați, dar nu îi numește
- Factorii sunt portofolii long–short sortate după caracteristici: SMB, HML, RMW, CMA, MOM
- FF3, Carhart, FF5 și modelul q sunt modelele de referință
- Momentum și valoarea au fost mult mai slabe după 2000; profitabilitatea a rămas puternică
- Modelele factoriale sunt SDF-uri; se compară prin raportul Sharpe al factorilor (HML nu adaugă alfa semnificativ față de ceilalți factori FF5 și MOM) sau prin distanța HJ

„Grădina zoologică” a factorilor

- ▣ [Cochrane \(2011\)](#) a numit lista tot mai lungă de factori noi o „grădină zoologică” (zoo)
- ▣ [Harvey, Liu & Zhu \(2016\)](#) catalogează sute de factori publicați (316 în lista lor)
- ▣ Fiecare a fost testat ca și cum ar fi fost singurul: $|t| > 1,96$ la 5%
- ▣ Cu multe teste, unii trec din întâmplare: **data mining**, numit și p-hacking
- ▣ Propunerea lor: un factor nou are nevoie de $|t| > 3,0$

Rata descoperirilor false: Benjamini–Hochberg

- ▣ **FDR** (False Discovery Rate): ponderea așteptată a respingerilor false în totalul respingerilor
- ▣ Procedura **BH** (Benjamini & Hochberg (1995)): găsim cel mai mare j cu

$$p_{(j)} \leq \frac{j}{M} \alpha$$



și respingem $H_{(1)}, \dots, H_{(j)}$

- ▣ Controlează FDR la nivelul α pentru teste independente sau sub dependență de regresie pozitivă pe ipotezele nule adevărate (Benjamini & Yekutieli (2001))
 - ▶ Sub orice dependență: varianta Benjamini–Yekutieli împarte pragurile la $\sum_{j=1}^M 1/j$
- ▣ Mai puțin strict decât controlul **FWER** (Family-Wise Error Rate) prin Bonferroni sau Holm (Holm (1979)), definite în Capitolul 2: potrivit pentru căutarea printre mulți factori candidați

Exemplu rezolvat: zece factori candidați

- ▣ p -valori ordonate: 0,0004; 0,002; 0,006; 0,011; 0,018; 0,027; 0,041; 0,070; 0,15; 0,62; $\alpha = 5\%$
- ▣ Naiv ($p \leq 0,05$): **7** descoperiri
- ▣ Bonferroni ($p \leq 0,005$): **2**
- ▣ Holm: $0,0004 \leq 0,005$, $0,002 \leq 0,0056$, $0,006 \leq 0,00625$, $0,011 > 0,0071$ stop: **3**
- ▣ Pragurile BH $0,005j$: $p_{(6)} = 0,027 \leq 0,030$ este ultimul succes: **6**

Simulare: 300 de factori inutili



- 2000 de replicări; fiecare extrage 300 de statistici t independente din distribuția Normală standard (fără primă reală)

Interpretarea simulării

- ▣ În medie, 15,0 factori inutili trec pragul $|t| > 1,96$; valoarea așteptată $300 \times 0,05 = 15$
- ▣ În medie, 0,83 trec pragul $|t| > 3$; cel puțin unul trece în 57% din replicări
- ▣ Mediana celui mai mare $|t|$ este 3,06: cel mai bun „factor” pare mereu puternic
- ▣ Pragul Bonferroni pentru 300 de teste: $|t| > 3,76$
- ▣ Pragurile cresc cu numărul de teste încercate efectiv, inclusiv cele nepublicate

Îmblânzirea grădinii zoologice și dezbateră replicării

- **Feng, Giglio & Xiu (2020)**: aduce un factor nou informație suplimentară față de factorii deja cunoscuți?
 - ▶ **LASSO cu dublă selecție** (Least Absolute Shrinkage and Selection Operator): regresii penalizate aleg variabilele de control dintre sute de factori
 - ▶ Majoritatea factorilor noi sunt redundanți; doar câțiva adaugă informație de evaluare
- **Jensen, Kelly & Pedersen (2023)**: o perspectivă bayesiană asupra a 153 de factori în 93 de țări
 - ▶ Majoritatea factorilor se replică; se grupează în 13 teme; rezultatele din afara eșantionului și cele internaționale sunt concordante
- Cele două perspective sunt compatibile: mulți factori sunt redundanți, iar informația se concentrează în câteva teme



Recapitulare: grădina zoologică a factorilor

- ▣ Sute de factori publicați implică multe descoperiri false la $|t| > 1,96$
- ▣ Bonferroni și Holm controlează șansa oricărei descoperiri false; BH controlează ponderea lor
- ▣ Cu 300 de factori inutili, cel mai bun are $|t| \approx 3$: pragul trebuie ridicat
- ▣ Redundanța este problema principală: cea mai mare parte a informației se concentrează în câteva teme

Recapitularea cunoștințelor necesare: analiza componentelor principale

- ▣ **Factori latenți:** estimați doar din randamente, fără a-i numi dinainte
- ▣ **PCA** (Principal Component Analysis, analiza componentelor principale) a matricei de corelație a randamentelor standardizate: $C = \mathbf{\Gamma} \mathbf{\Lambda} \mathbf{\Gamma}^\top$, componente $y_t = \mathbf{\Gamma}^\top z_t$
- ▣ Valori proprii $\lambda_1 \geq \dots \geq \lambda_N$; vectorii proprii sunt **încărcările**; componenta k explică λ_k/N din varianță
- ▣ Două active cu corelația ρ : $\lambda = 1 \pm \rho$, vectori proprii $(1, 1)/\sqrt{2}$ („piața”) și $(1, -1)/\sqrt{2}$ (spread-ul); în criză ρ crește și PC1 domină
- ▣ Manual: [Härdle & Simar \(2019\)](#), capitolul despre componente principale; mai multe exemple în Seminarul A8

PCA pe ETF-urile sectoriale din SUA



11 ETF-uri sectoriale, randamente logaritmice zilnice, 20 iunie 2018 – 18 septembrie 2026 ($T = 2073$ zile comune)

Interpretarea componentelor principale

- ▣ PC1 explică 66,0% din varianță; toate încărcările sunt pozitive (0,24–0,34)
 - ▶ Corelația PC1 cu SPY: 0,954; primul factor latent este piața
- ▣ PC2 (9,7%): utilități +0,55, bunuri de larg consum +0,42, imobiliare +0,31 vs tehnologie –0,40, consum discreționar –0,33
 - ▶ Un factor **defensiv versus creștere**, fără nume dat dinainte
- ▣ PC3 (7,4%) este dominată de energie; trei componente explică 83,1%
- ▣ Doar 2 valori proprii depășesc 1 (regula Kaiser): o euristică, nu un estimator consistent al numărului de factori (slide-urile următoare)

Câți factori? Estimatori consistenți

- ▣ Model factorial aproximativ $x_{it} = \lambda_i^\top F_t + e_{it}$ cu $N, T \rightarrow \infty$; $V(k)$: media pătratelor reziduurilor după primele k componente principale
- ▣ Bai & Ng (2002): $\hat{k} = \arg \min_k \left[\ln V(k) + k \frac{N+T}{NT} \ln \min(N, T) \right]$ (criteriul IC_{p2}), consistent când $N, T \rightarrow \infty$
- ▣ Ahn & Horenstein (2013): raportul valorilor proprii $\hat{k} = \arg \max_k \mu_k / \mu_{k+1}$, fără a necesita alegerea unei penalizări
- ▣ Onatski (2010): separă valorile proprii ale factorilor de marginea distribuției valorilor proprii ale zgomotului
- ▣ Regula Kaiser ($\lambda_k > 1$) nu are justificare asimptotică: valorile proprii ale zgomotului dintr-o matrice de corelație se împrăștie în jurul lui 1

Exemplu rezolvat: numărul de factori în datele noastre

Panel	N	T	Kaiser	Bai–Ng	Ahn–Horenstein
11 ETF-uri sectoriale, zilnic 2018–2026	11	2073	2	5	1
100 portofolii mărime $\times$ B/M, lunar 1963–2026	95	757	3	4	1

- Randamente standardizate; k maxim: 5 pentru sectoare, 8 pentru portofolii; 5 portofolii cu luni lipsă sunt eliminate
- Ahn–Horenstein alege factorul dominant al pieței (raport 14,6); următorul vârf este la $k = 3$ (raport 3,5), structura FF3
- Bai–Ng pe 11 sectoare atinge limita superioară $k = 5$: penalizarea este construită pentru N mare, deci cu N mic răspunsul este fragil

Limitele PCA în evaluarea activelor

- ▣ Încărcările sunt **constante**: PCA nu poate urmări o acțiune a cărei mărime sau valoare se schimbă
- ▣ Componentele explică **varianța**, nu neapărat **randamentele medii**
- ▣ Acțiunile individuale intră și ies din eșantion: un panel de acțiuni este dezechilibrat
- ▣ Semnele componentelor sunt arbitrare; rotațiile păstrează componentele principale doar în subspațiile proprii cu valori proprii egale, iar un model cu factori latenți este identificat doar până la o rotație
- ▣ PCA și analiza factorială în finanțe: [Franke, Härdle & Hafner \(2019\)](#); fundamente multivariate: [Härdle & Simar \(2019\)](#)

PCA cu primă de risc și prime în trei etape

- ▣ **RP-PCA** (PCA cu primă de risc, [Lettau & Pelger \(2020\)](#)): componentele principale ale matricei $\frac{1}{T}X^T X + \gamma \bar{x}\bar{x}^T$
 - ▶ $\gamma = -1$ dă PCA pe covarianță; $\gamma > -1$ favorizează și factorii care explică randamentele medii
 - ▶ În datele lor găsește factori cu rapoarte Sharpe mai mari și erori de evaluare mai mici decât PCA
- ▣ **Estimatorul în trei etape** ([Giglio & Xiu \(2021\)](#)): prima unui factor observat g_t când modelul omite factori
 - ▶ (1) PCA pe randamentele activelor de test; (2) regresia transversală a mediilor pe valorile beta latente; (3) regresia lui g_t pe factorii latenți și transferul primelor lor la g_t
- ▣ Ambele păstrează baza statistică a PCA, dar ținesc evaluarea, nu doar varianța; IPCA (următorul) adaugă caracteristicile

PCA instrumentată

- ▣ **IPCA:** Instrumented Principal Component Analysis, [Kelly, Pruitt & Su \(2019\)](#)
- ▣ Încărcările sunt funcții de L caracteristici observate $\mathbf{z}_{i,t}$ (mărime, B/M, momentum, ...)

$$R_{i,t+1}^e = \alpha_{i,t} + \beta_{i,t}^\top \mathbf{f}_{t+1} + \varepsilon_{i,t+1}, \quad \beta_{i,t}^\top = \mathbf{z}_{i,t}^\top \mathbf{\Gamma}_\beta$$

- ▣ $\mathbf{\Gamma}_\beta$ ($L \times K$) și factorii latenți $\mathbf{f}_t$ se estimează împreună prin metoda alternantă a celor mai mici pătrate
- ▣ Test: sunt caracteristicile remunerate prin beta („covarianțe”) sau direct ca alfa ($\alpha_{i,t} = \mathbf{z}_{i,t}^\top \mathbf{\Gamma}_\alpha$)?

Ce ne învață IPCA

- ▣ Titlul articolului: „Characteristics are covariances” (caracteristicile sunt covarianțe)
- ▣ În datele lor pentru acțiuni din SUA, câțiva factori IPCA evaluează secțiunea transversală mai bine decât modelele cu tot atâția factori observabili
- ▣ Termenul alfa Γ_α devine nesemnificativ: caracteristicile prezic randamentele pentru că măsoară expunerea la risc
- ▣ Leagă PCA (statistica) de sortările după caracteristici (Fama–French): beta variabil în timp, puțini factori
- ▣ Criptoactive: factorii piață, mărime și momentum evaluează secțiunea transversală a monedelor (Liu, Tsyvinski & Wu (2022)); reducerea dimensionalității pe caracteristicile randamentelor criptoactivelor și activelor tradiționale: Pele et al. (2023), Jheng et al. (2026)


Recapitulare: factori latenți

- PCA găsește factorii ca vectori proprii ai matricei de corelație; numărul lor se alege cu Bai–Ng sau Ahn–Horenstein, nu cu Kaiser
- La ETF-urile sectoriale, PC1 este piața (66%), PC2 un factor defensiv versus creștere (10%)
- PCA explică varianța, cu încărcări fixe; nu este în sine un model de evaluare
- IPCA face încărcările dependente de caracteristici și testează dacă acestea sunt risc

ETF-uri factoriale

- ▣ **Smart beta:** portofolii bazate pe reguli, cu expuneri sporite la anumiți factori, oferite sub formă de ETF-uri
- ▣ MTUM (momentum), VLU (valoare), QUAL (calitate: profitabilitate mare, îndatorare mică)
- ▣ USMV (volatilitate minimă: anomalia riscului scăzut), IWM (firme mici, Russell 2000)
- ▣ IWD / IWF: Russell 1000 value / growth (firme mari)
- ▣ Doar poziții long: păstrează expunerea la piață și sporesc expunerea la anumiți factori; nu reproduc neapărat partea long a unui factor academic și nu au neapărat beta de piață aproape de 1

ETF-urile factoriale față de piață




□ Evoluția a 1 USD cu dividende reinvestite, de la 18 iulie 2013 (prima zi comună)

Interpretarea randamentelor ETF-urilor factoriale

- ▣ **CAGR:** firmele mari de creștere (IWF) 16,3% și momentum (MTUM) 15,5% au depășit randamentul SPY (14,0%)
- ▣ Calitate 13,5%, valoare 13,1%, firme mari value 10,7%, volatilitate minimă 10,5%, firme mici 9,3%
- ▣ Perioada a favorizat firmele mari de creștere: value și firmele mici au rămas în urmă
- ▣ O singură perioadă de treisprezece ani nu oferă, în sine, dovezi suficiente împotriva existenței primelor

Valorile alfa ale ETF-urilor factoriale



Factor loadings

	Mkt-RF	SMB	HML	RMW	CMA	MOM
MTUM	1.03	-0.12	0.01	-0.22	-0.05	0.36
VLUE	0.98	0.08	0.34	-0.06	0.09	-0.03
QUAL	0.97	-0.08	-0.04	0.15	0.03	-0.04
USMV	0.74	-0.11	-0.02	0.20	0.21	-0.02
IWM	1.04	0.85	0.08	-0.10	-0.02	0.03
IWD	0.94	-0.04	0.29	0.09	0.19	-0.04
IWF	1.03	-0.11	-0.28	-0.03	-0.12	-0.00

- Regresii zilnice pe FF5 + MOM cu erori Newey–West, fiecare ETF pe propriul calendar de tranzacționare (2000–2026)

Interpretarea valorilor alfa ale ETF-urilor

- ▣ Încărcările corespund denumirilor: MTUM pe MOM 0,36, VLUUE pe HML 0,34, IWM pe SMB 0,85
- ▣ Growth (IWF) are încărcarea $-0,28$ pe HML; USMV are beta de piață 0,74 și RMW, CMA pozitive
- ▣ Valorile alfa din modelul factorial sunt aproape de zero: MTUM $-0,2\%$ ($t = -0,11$), QUAL $-0,3\%$
- ▣ ETF-urile Russell: IWM $-1,3\%$ ($t = -2,57$), IWD $-1,6\%$ ($t = -2,55$): costuri și construcția indicelui
- ▣ R^2 între 0,81 și 0,97: ETF-urile sunt în mare parte expunere factorială reambalată

Sincronizarea factorilor și aglomerarea

- ▣ **Factor timing:** trecerea de la un factor la altul pe baza unor semnale (spread-uri de evaluare, randamente recente)
 - ▶ Incertitudinea estimării primelor și seriile scurte îngreunează evaluarea sincronizării în afara eșantionului (Capitolul 8)
- ▣ **Aglomerarea** (crowding): mulți investitori dețin aceleași poziții factoriale
 - ▶ Primele se pot micșora (McLean & Pontiff (2016)), iar pozițiile aglomerate pot amplifica pierderile la lichidări forțate; prăbușirea momentumului din 2009 a coincis cu o revenire bruscă a fostelor acțiuni perdante (Daniel & Moskowitz (2016))
- ▣ Costuri: factorii long-short ignoră costurile de tranzacționare și comisioanele pentru vânzarea în lipsă; ETF-urile le plătesc

Recapitulare: investiții factoriale

- ▣ ETF-urile factoriale oferă expunerile promise și păstrează cea mai mare parte a expunerii la piață (beta 0,74–1,04)
- ▣ După ajustarea pentru expunerile la factori, valorile lor alfa sunt zero sau ușor negative
- ▣ 2013–2026 a recompensat creșterea și momentum, a penalizat valoarea și firmele mici
- ▣ Sincronizarea și aglomerarea sunt probleme deschise; evaluați-le în afara eșantionului

Studiu de caz: întrebarea de cercetare

- **Critica** la adresa cercetării despre factori are două forme (Jensen, Kelly & Pedersen (2023), Introducere)
 - ▶ Lipsa validității interne: rezultatele nu pot fi reproduse; Hou, Xue & Zhang (2020) replică doar 35% dintre anomaliiile studiate
 - ▶ Lipsa validității externe: rezultatele provin din testarea multor factori fără controlul FDR; Harvey, Liu & Zhu (2016) conchid că majoritatea descoperirilor raportate sunt probabil false
- **Întrebarea:** au factorii publicați valori alfa CAPM semnificative în datele originale, în afara eșantionului și în alte țări, după ce se ține cont de testarea multiplă?
- **De ce contează**
 - ▶ Dacă majoritatea factorilor sunt descoperiri false, modelele multifactoriale și investițiile factoriale (Secțiunile 6 și 9) se sprijină pe zgomot
 - ▶ Grădina zoologică a factorilor (Secțiunea 7) este tratată în curs ca o problemă statistică; articolul o interpretează ca dovezi corelate despre câteva teme economice
- **Legătura cu acest capitol:** alfa lui Jensen (Secțiunea 4) este mărimea testată; Benjamini–Yekutieli (Secțiunea 7) este reperul frecventist; ajustarea bayesiană aplică valorilor alfa principiul estimării Vasicek pentru beta (Seminarul 3, A3)

Studiu de caz: date și metodă

- **Date** (Secțiunea II): 153 de factori în 93 de țări; 138 din lista alcătuită de [Hou, Xue & Zhang \(2020\)](#) și 15 din alte studii; randamente americane din 1926, majoritatea piețelor dezvoltate din 1986; toate exprimate în dolari americani, în exces față de rata titlurilor de stat americane pe termen scurt
 - ▶ În fiecare țară, lunar: sortare în terțile după caracteristică, cu praguri calculate excluzând firmele cu microcapitalizare; ponderi după capitalizarea plafonată la percentila 80 a NYSE; cumpărarea terțilei cu randamentul așteptat mai mare în studiul inițial; deținere timp de o lună
 - ▶ Cel puțin 5 acțiuni în fiecare dintre portofoliile long și short și 60 de observații lunare; fiecare factor este scalat la o volatilitate idiosincratică anuală de 10%
 - ▶ 13 teme: grupare ierarhică a factorilor americani, distanța 1 – corelația reziduurilor CAPM, criteriul Ward (Secțiunea II.B)
- **Modelul** (Secțiunea I): $f_{i,t} = \alpha_i + \beta_i r_t^m + \varepsilon_{i,t}$; valorile alfa $\alpha_i = c_j + s_n + w_i$ (tema j , semnalul n , factorul i ; ec. 21), media a priori 0
 - ▶ Varianța a priori $\Omega = \text{MM}^\top \tau_c^2 + \text{ZZ}^\top \tau_s^2 + \text{I} \tau_w^2$ (ec. 23); media a posteriori $(\Omega^{-1} + T \Sigma^{-1})^{-1} T \Sigma^{-1} \hat{\alpha}$ (Propoziția 4)
 - ▶ Un singur factor: $E(\alpha \mid \hat{\alpha}) = \kappa \hat{\alpha}$, $\kappa = 1/(1 + \sigma^2/(\tau^2 T))$ (ec. 5): estimațiile din eșantioane scurte și zgomotoase sunt ajustate mai mult spre zero
 - ▶ Bayes empiric: τ_c, τ_s, τ_w prin verosimilitate maximă pentru $\hat{\alpha} \sim N(0, \Omega + \hat{\Sigma}/T)$ (Secțiunea I.C.2)
- **Rata de replicare**: ponderea factorilor semnificativi în articolul original a căror alfa este semnificativă aici; descoperire bayesiană dacă media a posteriori / abaterea standard a posteriori $\geq 1,96$ (ec. 26)


Studiu de caz: rezultatele principale

Rate de replicare (Figura 1)

Hou, Xue & Zhang (2020)	35,0%
SUA, randament brut	55,6%
semnificativi inițial	61,3%
alfa CAPM	82,4%
Benjamini–Yekutieli	75,6%
Bayes empiric	82,4%
Global, Bayes empiric	82,4%

- OLS: 98 din 119 factori americani; Benjamini–Yekutieli cere $|t| > 2,7$ (Figura 4)
 - ▶ $\Rightarrow$ testarea valorilor alfa, nu a randamentelor brute, explică cea mai mare parte a diferenței față de Hou, Xue & Zhang (2020)
- FDR bayesian 0,1%, interval de 95% [0, 1%]; ponderea așteptată a factorilor adevărați 94% (Secțiunea III.C)
 - ▶ $\Rightarrow$ contracția controlează descoperirile false fără pierderea de putere a unui prag t mai înalt
- Firme cu capitalizare foarte mare și mare: 77,3% și 79,8% (Figura 5); 11 din 13 teme cel puțin 50%, toate în afară de îndatorare redusă și mărime
 - ▶ $\Rightarrow$ rezultatul nu este un artefact al microcapitalizărilor
- Alfa medie 0,49% pe lună în eşantion, 0,26% după eşantionul original: -47% ; panta regresiei valorilor alfa ulterioare pe cele din eşantionul inițial este 0,26 (Figura 8), față de circa 0,9 așteptat doar din efectul de shrinkage
 - ▶ $\Rightarrow$ scăderea este de așteptat, dar factorii cei mai puternici scad mai mult: arbitraj sau căutare în date
- Raportul Sharpe (lunar) al portofoliului tangent, SUA 1972–2020: piața 0,13, toți factorii 0,80 (Figura 14)

Studiu de caz: replicare pe datele cursului



- 15 factori americani long-short din sortările ponderate cu valoarea de piață ale [Kenneth French Data Library](#), iulie 1963 – iulie 2026 ($T = 757$ luni); valori alfa CAPM scalate la volatilitate idiosincronică de 10% (Secțiunea II.A); temele articolului ([etichetele autorilor](#)), media a priori 0

Studiu de caz: interpretarea replicării din curs

- **Rate de replicare** (alfa pozitivă semnificativă): OLS 73,3% (11 din 15), Benjamini–Yekutieli 53,3% (8; t critic 2,72), Bayes empiric 86,7% (13)
 - ▶ Benjamini–Yekutieli este cel mai strict, ca în ratele americane din articol: 82,4%, 75,6%, 82,4% (Figura 1)
- **Contractie spre temă**, nu doar spre zero: inversarea pe termen lung (tema investiții) 0,13% $\rightarrow$ 0,23% pe lună ($t = 1,25$, z a posteriori 2,85); emisiunile nete de acțiuni 0,44% $\rightarrow$ 0,27%
 - ▶ Abaterea standard a posteriori 0,07%–0,10%, față de eroarea standard OLS 0,11%: fiecare temă cumulează informația factorilor ei
- **Dispersia a priori**: $\hat{\tau}_c = 0,28\%$, $\hat{\tau}_w = 0,04\%$ pe lună, față de 0,35% și 0,21% în Tabelul I; cu 15 semnale rămâne puțină dispersie specifică factorilor
- **Teme**: cele 15 semnale se încadrează în 8 dintre cele 13 teme ale articolului (5 în valoare, 3 în risc scăzut, 2 în investiții); cu o singură temă comună, rata Bayes empiric este 100%
- **Factori nereplicați**: beta de piață și inversarea pe termen scurt ($z \leq 1,41$); mărimea trece la limită ($z = 1,96$), în linie cu articolul, unde mărimea este una dintre cele două teme sub 50%

Studiu de caz: replicare, limite și extinderi

- **Completarea replicării de curs** (Seminarul 3, C3): justificați semnul fiecărui factor pe baza studiului inițial și comparați dendrograma cu temele articolului, adăugați FDR bayesian și panta după eşantion (Figura 8)
- Datele și codul articolului: jkpfactors.com, github.com/bkelly-lab/ReplicationCrisis
- **Limite precizate de autori**
 - ▶ CAPM este singurul reper: factorii de îndatorare redusă nu trec testul alfa CAPM, dar contează împreună cu celelalte teme (Secțiunea III.A)
 - ▶ Caracteristicile sunt construite unitar, uneori altfel decât în articolul original (Secțiunea II.C)
 - ▶ Factorii nepublicați deplasează distribuția a priori: în scenariile analizate de [Harvey, Liu & Zhu \(2016\)](#), rata pentru SUA scade la 81,5% și 79,8% (Figura 10)
- **Limitele versiunii de curs**: 15 semnale americane în loc de 153 în 93 de țări; pragurile bibliotecii în loc de terțile fără microcapitalizări cu ponderi plafonate; o singură regiune, deci $\tau_s = 0$
- **Extindere deschisă**: datele articolului se opresc în 2020; s-au menținut valorile alfa a posteriori și rata de replicare în 2021–2026 și poate o distribuție a priori estimată pe factorii americani să facă mai precise estimările factorilor BVB pe eşantioane scurte (Seminarul 3, C1)?

O întrebare deschisă: de ce scad primele factorilor după publicare?

- ▣ **McLean & Pontiff (2016)**: pe 97 de predictorii, randamentele sunt cu 26% mai mici în afara eșantionului și cu 58% mai mici după publicare
 - ▶ diferența, 32%, este atribuită tranzacțiilor informate de publicare; scăderea în afara eșantionului oferă o limită pentru efectul data mining-ului
- ▣ **Jensen, Kelly & Pedersen (2023)**: într-un model bayesian care contractă primele din eșantion, majoritatea celor 153 de factori se replică, în SUA și în 93 de țări
- ▣ **Chen & Zimmermann (2022)**: date și cod open-source care reproduc predictorii publicați pe secțiunea transversală
- ▣ Deschis: cât din scădere este arbitraj, data mining sau o schimbare a riscului și diferă ea între factori și piețe?

Bucula descoperirii, pas cu pas (1/2)

▣ Literatură

- ▶ Rezumă dovezile din 2016 încoace despre scăderea după publicare și replicarea randamentelor anomaliilor. Pentru fiecare lucrare: DOI, eșantion, numărul de factori, estimația principală, identificarea scăderii. Marchează intrările nesigure.
- ▶ Verificați fiecare DOI în Crossref; verificați fiecare cifră principală în rezumat

▣ Ipoteză

- ▶ Compară data mining-ul, arbitrajul informat de publicare și riscul variabil în timp ca explicații ale scăderii. Pentru fiecare: tiparul prezis între perioadele din eșantion, după eșantion și după publicare, și între acțiunile cu limite mari vs mici ale arbitrajului.

▣ Date și cod

- ▶ Încarcă factorul lunar de momentum din Kenneth French Data Library; din 1965, regresează MOM pe o variabilă dummy după eșantion (1990-01 până la 1993-03) și una după publicare (din 1993-04), cu erori Newey-West.
- ▶ Replicați întâi o cifră cunoscută: momentum $t = 5,53$ înainte de 2000 și 0,75 după (graficul pe subperioade)

Bucula descoperirii, pas cu pas (2/2)

▣ Robustețe

- ▶ Scrie un plan de robustețe preînregistrat: câte o dată de publicare pentru fiecare factor, corecția Holm între factori, excluderea prăbușirii momentumului din 2009, data working paper-ului în locul datei din revistă și perioada 1927-1962 ca placebo pentru Mkt-RF, SMB, HML și MOM (RMW și CMA încep în iulie 1963).

▣ Critică

- ▶ Evaluatează critic: un factor, o dată de publicare, $t = -1,45$. Care este puterea de a detecta o scădere de 58% și de ce o schimbă combinarea mai multor anomalii?

▣ Raport

- ▶ Media din eșantion, ambele variabile dummy cu erori Newey–West, placebo-ul, versiunea datelor (data descărcării)
- ▶ Factori combinați: erori robuste la corelația dintre factori în aceeași lună și la autocorelare
- ▶ Prompturile care au influențat o decizie intră în AI_USE.md

- ▣ Asistentul enumeră specificațiile; omul fixează dinainte care dintre ele contează

Ce verifică cercetătorul

- **Data greșită a evenimentului:** data încheierii eșantionului, data difuzării documentului de lucru și data publicării în revistă sunt diferite
 - ▶ test: citiți-le din lucrarea înșăși; Jegadeesh–Titman: eșantionul se termină în 1989, publicat în martie 1993
- **Alegerea factorului după ce a scăzut:** fixați dinainte mulțimea factorilor; Holm sau BH pe toți
- **Randamente autocorelate, cu prăbușiri:** erori Newey–West; rulați din nou fără 2009
- **Versiunile datelor:** biblioteca de factori este revizuită retroactiv
 - ▶ test: notați data descărcării; reproduceți statisticile t pe subperioade din capitol
- **Literatură citată greșit:** o greșeală frecventă dă 58% drept scăderea în afara eșantionului; este cea de după publicare (26% în afara eșantionului)
- **Putere mică:** un singur factor respinge rar; raportați intervalul de încredere al scăderii, nu doar semnul ei

Mini-caz: a fost momentumul eliminat prin arbitraj?

- O propunere tipică a asistentului: „momentumul a dispărut după ce [Jegadeesh & Titman \(1993\)](#) l-au publicat”
- Specificația empirică din [McLean & Pontiff \(2016\)](#): $MOM_t = a + b_1 \text{PostSample}_t + b_2 \text{PostPub}_t + e_t$, lunar, 1965–2026, erori Newey–West
 - ▶ după eşantion: 1990-01 – 1993-03; după publicare: din 1993-04; $H_0 : b_2 = 0$ față de $H_1 : b_2 < 0$
 - ▶ b_2 : scăderea totală față de media din eşantion; $b_2 - b_1$: efectul incremental al publicării
- Media din eşantion $a = 0,82\%$ pe lună ($t = 4,32$)
- Scăderea totală $b_2 = -0,45\%$ ($t = -1,45$; interval 95% $[-1,05\%, 0,16\%]$): media 0,37% pe lună, cu 54% mai mică
- Efectul incremental $b_2 - b_1 = -0,79\%$ (s.e. 0,68%, $t = -1,18$); placebo, Mkt-RF: $b_2 = +0,40\%$ ($t = 1,12$)
- Interpretare: estimația punctuală este apropiată de 58% din [McLean & Pontiff \(2016\)](#), dar un singur factor nu poate respinge H_0 la 5%
 - ▶ arbitrajul este o interpretare, nu o cauză identificată; combinarea a 97 de predictorii crește precizia, iar eşantionul, dependența dintre predictorii și eterogenitatea diferă și ele

 ai_discovery_case.py

Rândul vostru: un punct de plecare pentru proiect

- **Întrebare:** scad factorii Fama–French și momentumul după publicare și diferă scăderea între factori?
 - ▶ regresie comună pentru SMB, HML, RMW, CMA și MOM pe variabile dummy specifice fiecărui factor, după eşantion și după publicare (Mkt-RF: placebo, fără dată de publicare); erori robuste la corelația dintre factori și la autocorelare
 - ▶ pentru a testa dacă scăderea este mai mare acolo unde arbitrajul este mai ușor, sunt necesari indicatori la nivel de acțiune (mărime, lichiditate, costul vânzării în lipsă), nu randamente factoriale
- **Replicați întâi:** statisticile t pe subperioade din capitol și estimațiile din mini-caz
- **Livrabile**
 - ▶ o notă de preînregistrare (H_0 , H_1 , datele din fiecare lucrare, mulțimea factorilor, corecții) încărcată prin commit înainte de rezultate
 - ▶ codul ca Quantlet; un raport cu inferență Newey–West, perioade placebo și putere
- **Jurnale:** prompturile în AI_USE.md; fiecare eroare prinsă (o dată de publicare greșită, o cifră citată greșit) în AI_ERRORS.md

Concluzii

- CAPM este elegant, dar eșuează pe cele 25 de portofolii mărime $\times$ B/M: SML este plată (panta $-4,4\%$), GRS = 4,20
- Beta trebuie estimat cu erori robuste, se schimbă în timp și trebuie ajustat (shrinkage)
- Primele din cele două etape cer erori robuste la beta estimat și la specificarea greșită; un R^2 mare pe 25 de portofolii este un criteriu puțin exigent
- Sute de factori impun praguri pentru testarea multiplă ($|t| > 3$); modelele se compară prin raportul Sharpe al factorilor
- Factori latenți: PCA recuperează piața și un factor defensiv versus creștere; IPCA îi leagă de caracteristici
- ETF-urile factoriale sunt expunere factorială ieftină, nu alfa

Legături cu alte capitole

- ▣ **Capitolul 2** (eficiența pieței): un alfa este fie o anomalie (ineficiență), fie un factor de risc omis; problema ipotezei comune
- ▣ **Capitolul 4** (optimizarea portofoliului): modele factoriale de covarianță și shrinkage pentru Markowitz
- ▣ **Capitolele 5–6**: volatilitate și corelații variabile în timp, beta condiționat
- ▣ **Capitolul 8**: backtesting pentru strategii factoriale fără supraajustare
- ▣ **Capitolul 13**: machine learning pentru secțiunea transversală a randamentelor

Pentru aprofundare pe Quantinar

Cursuri avansate pe quantinar.com

- ▣  Generalized Method of Moments
- ▣  Multivariate Statistical Analysis

Cod și date

- ▣ Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_03
- ▣ Datele factorilor: [Kenneth French Data Library](#)

Bibliografie (1/7)

- ▣ Ahn, S.C., Horenstein, A.R. (2013). Eigenvalue ratio test for the number of factors. *Econometrica*, 81(3), 1203–1227.
- ▣ Anatolyev, S., Mikusheva, A. (2022). Factor models with many assets: strong factors, weak factors, and the two-pass procedure. *Journal of Econometrics*, 229(1), 103–126.
- ▣ Ang, A., Liu, J., Schwarz, K. (2020). Using stocks or portfolios in tests of factor models. *Journal of Financial and Quantitative Analysis*, 55(3), 709–750.
- ▣ Bai, J., Ng, S. (2002). Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 191–221.
- ▣ Barillas, F., Shanken, J. (2018). Comparing asset pricing models. *Journal of Finance*, 73(2), 715–754.
- ▣ Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- ▣ Black, F. (1972). Capital market equilibrium with restricted borrowing. *Journal of Business*, 45(3), 444–455.
- ▣ Blume, M.E. (1971). On the assessment of risk. *Journal of Finance*, 26(1), 1–10.
- ▣ Benjamini, Y., Yekutieli, D. (2001). The control of the false discovery rate in multiple testing under dependency. *Annals of Statistics*, 29(4), 1165–1188.
- ▣ Bryzgalova, S., Huang, J., Julliard, C. (2023). Bayesian solutions for the factor zoo: we just ran two quadrillion models. *Journal of Finance*, 78(1), 487–557.

Bibliografie (2/7)

- ▣ Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). *The Econometrics of Financial Markets*. Princeton University Press.
- ▣ Carhart, M.M. (1997). *On persistence in mutual fund performance*. *Journal of Finance*, 52(1), 57–82.
- ▣ Chen, A.Y., Zimmermann, T. (2022). *Open source cross-sectional asset pricing*. *Critical Finance Review*, 11(2), 207–264.
- ▣ Cochrane, J.H. (2011). *Presidential address: discount rates*. *Journal of Finance*, 66(4), 1047–1108.
- ▣ Daniel, K., Moskowitz, T.J. (2016). *Momentum crashes*. *Journal of Financial Economics*, 122(2), 221–247.
- ▣ Fama, E.F., French, K.R. (1992). *The cross-section of expected stock returns*. *Journal of Finance*, 47(2), 427–465.
- ▣ Fama, E.F., French, K.R. (1993). *Common risk factors in the returns on stocks and bonds*. *Journal of Financial Economics*, 33(1), 3–56.
- ▣ Fama, E.F., French, K.R. (2015). *A five-factor asset pricing model*. *Journal of Financial Economics*, 116(1), 1–22.
- ▣ Fama, E.F., MacBeth, J.D. (1973). *Risk, return, and equilibrium: empirical tests*. *Journal of Political Economy*, 81(3), 607–636.
- ▣ Fan, J., Liao, Y., Yao, J. (2015). *Power enhancement in high-dimensional cross-sectional tests*. *Econometrica*, 83(4), 1497–1541.

Bibliografie (3/7)

- ▣ Feng, G., Giglio, S., Xiu, D. (2020). Taming the factor zoo: a test of new factors. *Journal of Finance*, 75(3), 1327–1370.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, ed. a 5-a. Springer.
- ▣ Frazzini, A., Pedersen, L.H. (2014). Betting against beta. *Journal of Financial Economics*, 111(1), 1–25.
- ▣ Gibbons, M.R., Ross, S.A., Shanken, J. (1989). A test of the efficiency of a given portfolio. *Econometrica*, 57(5), 1121–1152.
- ▣ Giglio, S., Xiu, D. (2021). Asset pricing with omitted factors. *Journal of Political Economy*, 129(7), 1947–1990.
- ▣ Hansen, L.P. (1982). Large sample properties of generalized method of moments estimators. *Econometrica*, 50(4), 1029–1054.
- ▣ Hansen, L.P., Jagannathan, R. (1997). Assessing specification errors in stochastic discount factor models. *Journal of Finance*, 52(2), 557–590.
- ▣ Härdle, W.K., Simar, L. (2019). *Applied Multivariate Statistical Analysis*, ed. a 5-a. Springer.
- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.

Bibliografie (4/7)

- ▣ Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- ▣ Hou, K., Xue, C., Zhang, L. (2015). Digesting anomalies: an investment approach. *Review of Financial Studies*, 28(3), 650–705.
- ▣ Hou, K., Xue, C., Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133.
- ▣ Jagannathan, R., Wang, Z. (1998). An asymptotic theory for estimating beta-pricing models using cross-sectional regression. *Journal of Finance*, 53(4), 1285–1309.
- ▣ Jegadeesh, N., Titman, S. (1993). Returns to buying winners and selling losers: implications for stock market efficiency. *Journal of Finance*, 48(1), 65–91.
- ▣ Jensen, M.C. (1968). The performance of mutual funds in the period 1945–1964. *Journal of Finance*, 23(2), 389–416.
- ▣ Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance?. *Journal of Finance*, 78(5), 2465–2518.
- ▣ Jheng, S.-L., Găman, Ș., Conda, A., Pele, D.T., Härdle, W.K., Teng, H.-W., Osterrieder, J. (2026). Crypto currency returns. Document de lucru SSRN.
- ▣ Kan, R., Robotti, C., Shanken, J. (2013). Pricing model performance and the two-pass cross-sectional regression methodology. *Journal of Finance*, 68(6), 2617–2649.
- ▣ Kan, R., Zhang, C. (1999). Two-pass tests of asset pricing models with useless factors. *Journal of Finance*, 54(1), 203–235.

Bibliografie (5/7)

- ▣ Kelly, B.T., Pruitt, S., Su, Y. (2019). [Characteristics are covariances: a unified model of risk and return](#). *Journal of Financial Economics*, 134(3), 501–524.
- ▣ Kleibergen, F. (2009). [Tests of risk premia in linear factor models](#). *Journal of Econometrics*, 149(2), 149–173.
- ▣ Kozak, S., Nagel, S., Santosh, S. (2020). [Shrinking the cross-section](#). *Journal of Financial Economics*, 135(2), 271–292.
- ▣ Lettau, M., Pelger, M. (2020). [Factors that fit the time series and cross-section of stock returns](#). *Review of Financial Studies*, 33(5), 2274–2325.
- ▣ Lewellen, J., Nagel, S., Shanken, J. (2010). [A skeptical appraisal of asset pricing tests](#). *Journal of Financial Economics*, 96(2), 175–194.
- ▣ Lintner, J. (1965). [The valuation of risk assets and the selection of risky investments in stock portfolios and capital budgets](#). *Review of Economics and Statistics*, 47(1), 13–37.
- ▣ Liu, Y., Tsyvinski, A., Wu, X. (2022). [Common risk factors in cryptocurrency](#). *Journal of Finance*, 77(2), 1133–1177.
- ▣ Markowitz, H. (1952). [Portfolio selection](#). *Journal of Finance*, 7(1), 77–91.
- ▣ McLean, R.D., Pontiff, J. (2016). [Does academic research destroy stock return predictability?](#). *Journal of Finance*, 71(1), 5–32.

Bibliografie (6/7)

- ▣ Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- ▣ Onatski, A. (2010). Determining the number of factors from empirical distribution of eigenvalues. *Review of Economics and Statistics*, 92(4), 1004–1016.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *The European Journal of Finance*, 29(10), 1064–1105.
- ▣ Pesaran, M.H., Yamagata, T. (2024). Testing for alpha in linear factor pricing models with a large number of securities. *Journal of Financial Econometrics*, 22(2), 407–460.
- ▣ Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- ▣ Roll, R. (1977). A critique of the asset pricing theory's tests. Part I. *Journal of Financial Economics*, 4(2), 129–176.
- ▣ Ross, S.A. (1976). The arbitrage theory of capital asset pricing. *Journal of Economic Theory*, 13(3), 341–360.
- ▣ Shanken, J. (1992). On the estimation of beta-pricing models. *Review of Financial Studies*, 5(1), 1–33.
- ▣ Sharpe, W.F. (1964). Capital asset prices: a theory of market equilibrium under conditions of risk. *Journal of Finance*, 19(3), 425–442.

Bibliografie (7/7)

- ▣ Vasicek, O.A. (1973). A note on using cross-sectional information in Bayesian estimation of security betas. *Journal of Finance*, 28(5), 1233–1239.
- ▣ Date: Kenneth R. French Data Library, mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html.