









Modelarea piețelor financiare

Capitolul 3: Modele factoriale și evaluarea activelor



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Acronime folosite în acest material (1/3)

- **AI**: Artificial Intelligence — *inteligență artificială*
- **APT**: Arbitrage Pricing Theory — *teoria evaluării prin arbitraj*
- **BAB**: Betting Against Beta — *strategia „pariu împotriva lui beta"*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BH**: Benjamini–Hochberg (procedure) — *procedura Benjamini–Hochberg*
- **BVB**: Bursa de Valori București
- **CAGR**: Compound Annual Growth Rate — *rata anuală compusă de creștere*
- **CAPM**: Capital Asset Pricing Model — *modelul de evaluare a activelor financiare*
- **CMA**: Conservative Minus Aggressive (investment factor) — *factorul investiții: firme conservatoare minus agresive*
- **CML**: Capital Market Line — *dreapta pieței de capital*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- **FDR**: False Discovery Rate — *rata descoperirilor false*
- **FF3**: Fama–French three-factor model — *modelul Fama–French cu trei factori*
- **FF5**: Fama–French five-factor model — *modelul Fama–French cu cinci factori*

Acronime folosite în acest material (2/3)

- **FWER**: Family-Wise Error Rate — *probabilitatea a cel puțin unei erori de tip I în familia de teste*
- **GLS**: Generalised Least Squares — *metoda celor mai mici pătrate generalizate*
- **GMM**: Generalized Method of Moments — *metoda generalizată a momentelor*
- **GRS**: Gibbons–Ross–Shanken (test) — *testul Gibbons–Ross–Shanken*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HML**: High Minus Low (value factor) — *factorul valoare: B/M mare minus mic*
- **IPCA**: Instrumented Principal Component Analysis — *analiza instrumentată a componentelor principale*
- **LASSO**: Least Absolute Shrinkage and Selection Operator — *regresie penalizată L1 cu selecția variabilelor*
- **MOM**: Momentum (factor) — *factorul momentum*
- **NYSE**: New York Stock Exchange — *Bursa din New York*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **OMV**: Österreichische Mineralölverwaltung — *Administrația Austriacă a Petrolului (grupul OMV)*
- **PC1**: first Principal Component — *prima componentă principală*

Acronime folosite în acest material (3/3)

- **PC2**: second Principal Component — *a doua componentă principală*
- **PC3**: third Principal Component — *a treia componentă principală*
- **PCA**: Principal Component Analysis — *analiza componentelor principale*
- **PRDS**: Positive Regression Dependence on a Subset (of p-values) — *dependența pozitivă de regresie pe o submulțime (a p-value-urilor)*
- **RF**: Risk-Free rate — *rata fără risc*
- **RMSE**: Root Mean Squared Error — *rădăcina erorii pătratice medii*
- **RMW**: Robust Minus Weak (profitability factor) — *factorul profitabilitate: firme robuste minus slabe*
- **ROE**: Return On Equity — *rentabilitatea capitalului propriu*
- **RP-PCA**: Risk-Premium Principal Component Analysis — *analiza componentelor principale cu primă de risc*
- **SDF**: Stochastic Discount Factor — *factorul stochastic de actualizare*
- **SMB**: Small Minus Big (size factor) — *factorul mărime: firme mici minus mari*
- **SML**: Security Market Line — *dreapta pieței titlurilor*
- **SUA**: Statele Unite ale Americii
- **UMD**: Up Minus Down (momentum factor) — *factorul momentum: cîștigători minus perdanți*

Traseul capitolului și rezultatele învățării

Patru întrebări

- Ce explică randamentele așteptate? CAPM și modelele multifactoriale
- Cum se estimează expunerile? Beta, incertitudinea lui și shrinkage
- Cum se testează restricțiile de evaluare? GRS, Fama–MacBeth, compararea modelelor
- Rezistă rezultatele? Testare multiplă, factori latenți, replicare

După acest capitol veți putea

- estima un beta cu erori HAC și aplica shrinkage
- testa simultan valorile alfa ale CAPM și estima prime de risc cu erori robuste
- evalua un factor nou în raport cu pragurile testării multiple și cu dovezile de replicare

- **Partea I**, Secțiunile 1–5: 1 Traseu și date; 2 De la Markowitz la CAPM; 3 Estimarea lui beta; 4 Testarea CAPM; 5 Modele multifactoriale
- **Partea a II-a**, Secțiunile 6–13: 6 Regresii Fama–MacBeth; 7 Factori de actualizare și compararea modelelor; 8 Factor zoo și testarea multiplă; 9 Factori latenți; 10 Investiții factoriale; 11 Studiu de caz; 12 AI pentru descoperire științifică; 13 Concluzii
- Detaliile tehnice sînt legate de fiecare temă; aprofundare și cod: ▸ Anexă

Modelul factorial: definiție

- Un **model factorial** explică randamentul activului i prin cîteva variabile comune $f_{1,t}, \ldots, f_{K,t}$, numite **factori**

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_{i,1} f_{1,t} + \cdots + \beta_{i,K} f_{K,t} + \varepsilon_{i,t}$$

- $R_{i,t}$: randamentul activului i în perioada t; $R_{f,t}$: rata fără risc; K: numărul de factori; α_i: randamentul mediu neexplicat de factori, 0 dacă factorii evaluează corect activul
- $\beta_{i,k}$: **încărcarea factorială** (expunerea) activului i la factorul k; $\varepsilon_{i,t}$: șoc specific activului (idiosincratic)
- Două utilizări în acest capitol
  - Explicarea unui activ: ETF-ul de tehnologie XLK are o sensibilitate de 1,28 față de piața americană (Secțiunea 3)
  - Evaluarea unui fond: rămîne α_i pozitiv după ce ținem cont de expunerile lui (Secțiunile 4 și 10)?
- Alte utilizări: costul capitalului, managementul riscului (N active necesită $N(N+1)/2$ covariațe, K factori mult mai puține), construcția portofoliilor (Campbell, Lo & MacKinlay (1997), cap. 5–6)
- Mesajul-cheie: randamentele așteptate ar trebui explicate prin **expuneri la riscuri remunerate**, nu prin numele activului

Date și convenții

Serie	Conținut	Perioadă
Factori Fama–French	piață, mărime, valoare, profitabilitate, investiții	1963–2026
Momentum	câștigători minus perdanți	1963–2026
25 portofolii mărime × B/M	acțiuni SUA, 2 sortări	1963–2026
ETF-uri sectoriale	sectoare S&P 500: 9 din 1999, 11 din 2018	1999–2026
ETF-uri factoriale	momentum, valoare, calitate, vol. minimă, mărime	2013–2026
Blue chips BVB, BET	11 acțiuni și indicele lor	2015–2026

- Simbolurile ETF-urilor sectoriale: XLB materiale, XLE energie, XLF financiar, XLI industrie, XLK tehnologie, XLP bunuri de larg consum, XLU utilități, XLV sănătate, XLY consum discreționar; din 2018 și XLRE imobiliare, XLC servicii de comunicații

- Factori și portofolii: Kenneth French Data Library, în procente (se împart la 100); ETF-uri și acțiuni: prețuri zilnice de închidere ajustate (BET: valori de închidere), până la 18 sept. 2026
- **Randament în exces** $R^e_{i,t} = R_{i,t} - R_{f,t}$; $R_{f,t}$: rata titlurilor de stat americane la o lună (RF în datele French); **Mkt-RF**: randamentul în exces al pieței americane de acțiuni, ponderat după capitalizare, din aceleași date
- **B/M**: valoarea contabilă a capitalului propriu împărțită la valoarea sa de piață; **BET**: indicele de referință al BVB
- Randamente simple pentru regresiile pe factorii French; randamente logaritmice pentru analizele pe ferestre mobile, BVB și PCA
- BVB: $R_{f,t}$ zilnică tratată ca fiind constantă; se anulează în covariațe, deci beta nu se schimbă

Medie–varianță și portofoliul tangent

- Markowitz (1952): cu ponderile w, randamentele în exces așteptate $\boldsymbol{\mu}$ și matricea de covarianță $\boldsymbol{\Sigma}$, portofoliile de pe frontieră se obțin rezolvînd

$$\min_{\mathrm{w}} \ \mathrm{w}^\top \boldsymbol{\Sigma}\, \mathrm{w} \quad \text{a.î.} \quad \mathrm{w}^\top \boldsymbol{\mu} = \mu^*,\ \mathrm{w}^\top 1 = 1$$

  - în cuvinte: varianța minimă pentru o medie-țintă μ^*; 1: vectorul cu toate elementele egale cu 1, deci ponderile au suma 1; $^\top$: transpusa

- **Raportul Sharpe** $SR_p = \mathbb{E}[R_p - R_f]/\sigma_p$; cu un activ fără risc, cel mai bun portofoliu riscant este **portofoliul tangent**

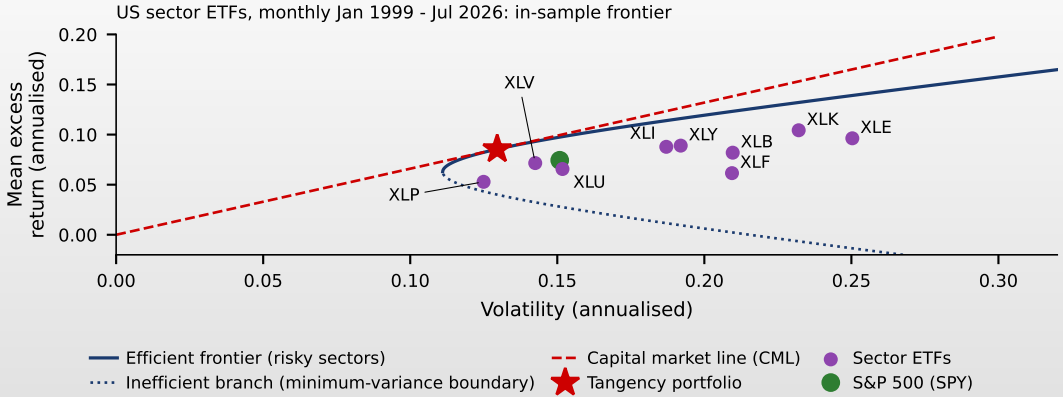
$$\mathrm{w}_{\mathbf{tan}} = \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} \,/\, 1^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$$

  - R_p, σ_p: randamentul și volatilitatea portofoliului p; numitorul rescalează $\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$ astfel încît ponderile să aibă suma 1

- **CML**: combinații între R_f și portofoliul tangent, $\mu_p = SR_{\mathbf{tan}}\,\sigma_p$; ponderile negative sînt **poziții short**

- De la portofoliul tangent la ecuația de evaluare prin beta: Seminarul 3, problema A2; eroarea de estimare și shrinkage: Capitolul 4

Frontiera eficientă a sectoarelor din SUA (1/2)



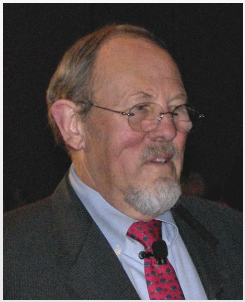
MFM_ch3_frontier

Frontiera eficientă a sectoarelor din SUA (2/2)

- Randamente lunare în exces ale a 9 ETF-uri sectoriale, ianuarie 1999 – iulie 2026 ($T = 331$ luni)
- Portofoliul tangent: medie 8,55%, volatilitate 12,96%, raport Sharpe 0,66
- SPY (ETF-ul pe S&P 500, aproximarea pieței): medie 7,44%, volatilitate 15,08%, raport Sharpe 0,49: aici piața **nu** se află pe frontieră, deși CAPM ar cere acest lucru
- Ponderile portofoliului tangent: $-0{,}37$ în financiar, $-0{,}21$ în materiale, $+0{,}37$ în sănătate
- Frontiera este calculată **în eșantion**; mediile sînt estimate cu multă incertitudine (Capitolul 4)

MFM_ch3_frontier

CAPM: Sharpe, Lintner, Black



William F. Sharpe, Premiul Nobel pentru Economie 1990

Foto: Larry D. Moore (2007); CC BY 4.0; Wikimedia Commons

- **CAPM**: Capital Asset Pricing Model (modelul de evaluare a activelor financiare), Sharpe (1964) și Lintner (1965)
- Dacă fiecare investitor deține un portofoliu eficient medie–varianță, toți dețin același portofoliu tangent, care trebuie atunci să fie **portofoliul pieței**
- Randamentul în exces așteptat este proporțional cu **beta**

$$\mathbb{E}[R_i] - R_f = \beta_i \left(\mathbb{E}[R_m] - R_f\right), \qquad \beta_i = \frac{\mathrm{Cov}(R_i, R_m)}{\mathrm{Var}(R_m)}$$

- R_i, R_m: randamentele activului i și ale portofoliului pieței; $\mathbb{E}[R_m] - R_f$: **prima de risc a pieței**; β_i: sensibilitatea activului i la piață, $\beta_i > 1$ amplifică mișcările pieței
- Black (1972): o versiune fără activ fără risc, CAPM cu beta zero (Secțiunea 4)
- Sharpe a împărțit Premiul Nobel din 1990 cu Markowitz și Miller

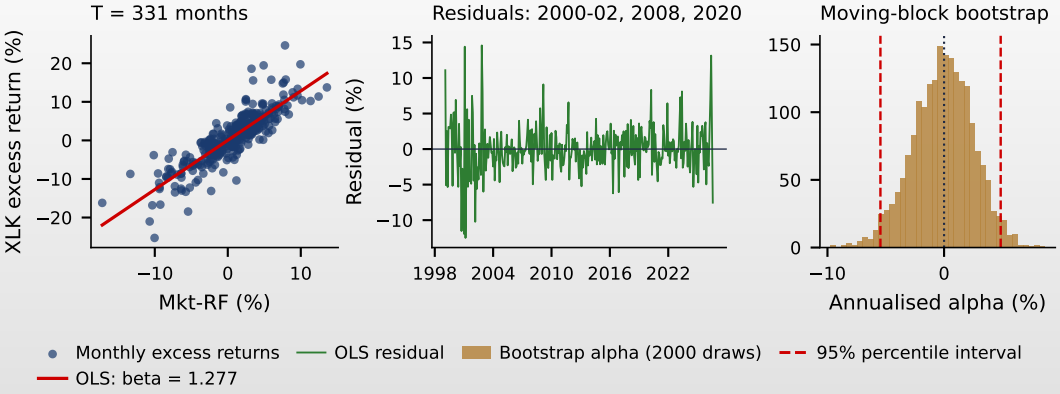
Implicațiile CAPM

- Ipoteze principale
  - Investitori medie–varianță cu aceleași așteptări, o singură perioadă
  - Împrumut și plasament nelimitate la R_f; fără taxe sau costuri de tranzacționare
- Doar beta este remunerat: nicio altă caracteristică nu ar trebui să prezică randamentele; riscul idiosincratic nu este remunerat
- **SML** (Security Market Line, dreapta pieței titlurilor): afirmația testabilă a CAPM (Secțiunea 4)
  - orice activ se află pe dreapta (beta, medie), cu panta egală cu prima pieței
  - CML conține doar portofoliile eficiente
- Costul capitalului prin CAPM necesită un beta estimat și o primă estimată: eroarea de estimare a primei domină
- Care portofoliu este „piața"? Răspunsul determină ce poate stabili un test al CAPM (critica lui Roll, Secțiunea 4)

Modelul de piață, erorile HAC și alegerile de estimare

- Modelul de piață $R^e_{i,t} = \alpha_i + \beta_i R^e_{m,t} + \varepsilon_{i,t}$; **OLS** (Ordinary Least Squares, metoda celor mai mici pătrate): $\hat{\beta}_i = \widehat{\text{Cov}}(R^e_i, R^e_m)/\widehat{\text{Var}}(R^e_m)$
- Descompunerea $\sigma^2_i = \beta^2_i \sigma^2_m + \sigma^2_{\varepsilon,i}$: risc sistematic (remunerat în CAPM) plus risc idiosincratic (diversificabil); R^2 este ponderea sistematică
  - σ^2_i, σ^2_m: variațele activului și ale pieței; $\sigma^2_{\varepsilon,i}$: varianța reziduurilor; $R^2 = \beta^2_i \sigma^2_m / \sigma^2_i$
- Volatility clustering (Capitolul 1) face reziduurile heteroscedastice: folosiți erori **HAC** (Newey & West (1987))
  - ponderi Bartlett și $L = \lfloor 4(T/100)^{2/9} \rfloor$ laguri (Newey & West (1994)); T: numărul de perioade, $\lfloor \cdot \rfloor$: partea întreagă
  - $T = 331$: $L = 5$; $T = 757$: $L = 6$; estimațiile punctuale sînt cele OLS
- Alegeri de raportat pentru orice beta
  - Frecvența și fereastra: 3–5 ani de date lunare sau 1–2 ani de date zilnice; datele zilnice sînt afectate de tranzacționarea asincronă
  - Aproximarea pieței: SPY (S&P 500) sau Mkt-RF pentru active din SUA, BET pentru acțiuni românești
  - Curățarea datelor: o eroare de scală în primele înregistrări creează un randament fals (DIGI: închiderile din 17–22 mai 2017 sînt de circa 725 de ori mai mari decît cele de după 23 mai; randament logaritmic zilnic de $-6{,}6$)

Exemplu rezolvat: beta ETF-ului de tehnologie (1/2)



MFM_ch3_seminar

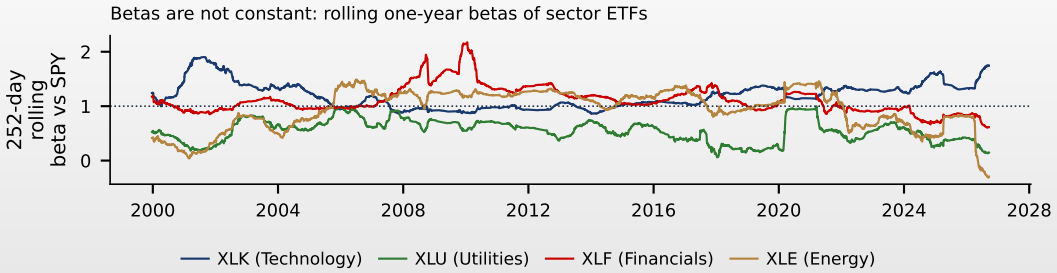
Exemplu rezolvat: beta ETF-ului de tehnologie (2/2)

		Eroare standard		
	Estimație	**Clasică**	**White**	**Newey–West**
α (anual)	0,33%	2,27%	2,32%	2,45%
β	1,277	0,041	0,054	0,082

- XLK pe Mkt-RF, lunar 1999–2026, $T = 331$, $R^2 = 0{,}742$
- **Clasică**: erori presupuse homoscedastice și neautocorelate; **White**: robustă la heteroscedasticitate (White (1980)); **Newey–West**: robustă și la autocorelație, $L = 5$ laguri
- Eroarea standard (e.s.) robustă a lui β: dublul celei clasice; heteroscedasticitatea explică o parte (White), autocorelația lui $f_t\varepsilon_t$ restul
- $t(\alpha) = 0{,}33/2{,}45 = 0{,}13$; interval bootstrap $[-5{,}5\%; 4{,}9\%]$

MFM_ch3_seminar

Beta nu este constant



- Beta OLS din ultimele 252 de randamente logaritmice zilnice, recalculat zilnic
- Financiar (XLF): de la 0,60 la 2,17; maximul urmează crizei bancare din 2008–2009
- Tehnologie (XLK): de la 0,86 la 1,90; ridicat în anii dot-com, 1,75 la final
- Energie (XLE): de la $-0{,}31$ la 1,49; negativ la final, cînd petrolul a evoluat în sens opus pieței
- Utilități (XLU): de la 0,06 la 1,00, sectorul defensiv clasic
- Un beta pe tot eșantionul ascunde aceste regimuri; modele condiționale: Capitolele 5–6

MFM_ch3_rolling_beta

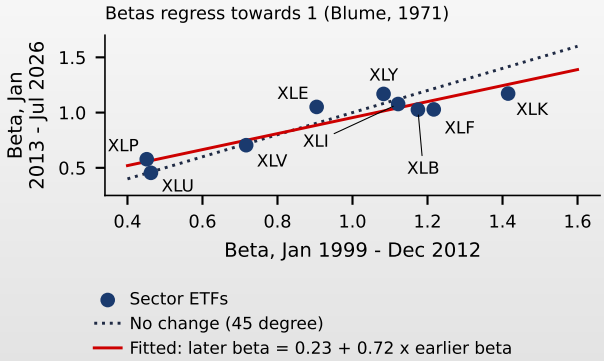
Shrinkage pentru beta: Blume și Vasicek

- **Regresia spre medie**: valorile beta extreme sînt parțial zgomot și se apropie ulterior de 1
- Blume (1971): regresia valorilor beta ulterioare pe cele anterioare; regula practicienilor este $\beta^{\text{Blume}} = 0{,}33 + 0{,}67\,\hat{\beta}$
- Vasicek (1973): medie bayesiană între estimație și media transversală a priori $\bar{\beta}$

$$\beta_i^V = w_i\hat{\beta}_i + (1 - w_i)\bar{\beta}, \qquad w_i = \frac{\sigma_\beta^2}{\sigma_\beta^2 + \text{se}(\hat{\beta}_i)^2}$$

- w_i: ponderea estimației, mai mare cînd $\hat{\beta}_i$ este precis (e.s. mică); $\text{se}(\hat{\beta}_i)$: eroarea lui standard
- σ_β^2 este varianța valorilor beta **adevărate** (Var_{cs}: varianța între active; $\overline{\text{se}^2}$: media pătratelor erorilor standard): $\text{Var}_{cs}(\hat{\beta}) = \sigma_\beta^2 + \overline{\text{se}^2}$, deci estimația Bayes empirică este $\sigma_\beta^2 = \text{Var}_{cs}(\hat{\beta}) - \overline{\text{se}^2}$ (derivarea distribuției a posteriori: Seminarul 3, problema A3)
- XLK, lunar 1999–2012, 9 sectoare: $\hat{\beta} = 1{,}415$ (e.s. 0,139), $\bar{\beta} = 0{,}949$, $\sigma_\beta^2 = 0{,}116 - 0{,}008 = 0{,}108$, $w = 0{,}849$
  - $\beta^V = 0{,}849 \times 1{,}415 + 0{,}151 \times 0{,}949 = 1{,}344$; Blume 1,278; beta estimat pe 2013–2026: 1,172

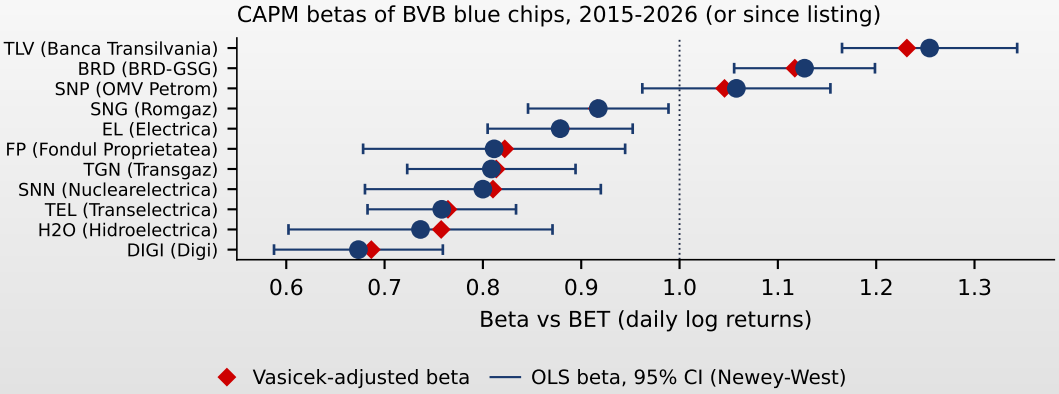
Revenirea valorilor beta spre unu



- Valori beta lunare ale celor 9 ETF-uri sectoriale față de SPY: 1999–2012 (pe orizontală) față de 2013–2026 (pe verticală)
- Dreapta estimată $\hat{\beta}_{\text{ulterior}} = 0{,}23 + 0{,}72\,\hat{\beta}_{\text{anterior}}$, foarte aproape de regula Blume $0{,}33 + 0{,}67\,\hat{\beta}$
- **RMSE** a prognozei valorilor beta ulterioare, $\sqrt{\frac{1}{N}\sum_i (\text{prognoza}_i - \hat{\beta}_{i,\text{ulterior}})^2}$: brut 0,135, Blume 0,109, Vasicek 0,114
- Shrinkage-ul reduce eroarea de prognoză cu 15–20%; cu doar 9 sectoare, concluzia este calitativă

MFM_ch3_beta_shrink

Beta CAPM la Bursa de Valori București (1/2)



MFM_ch3_bvb_betas

Beta CAPM la Bursa de Valori București (2/2)

- Randamente logaritmice zilnice, regresate pe BET, de la 6 ianuarie 2015 sau de la listare (Digi, DIGI, 2017; Hidroelectrica, H2O, 2023); zilele cu $|r_t| > 0{,}5$ sînt eliminate (una pentru DIGI, două pentru Fondul Proprietatea, FP)
- Băncile sînt cele mai sensibile la piață: Banca Transilvania (TLV) 1,25, BRD 1,13; OMV Petrom 1,06; Transelectrica 0,76, Digi 0,67
- R^2: 0,59 pentru TLV, doar 0,21 pentru DIGI; ponderile mari în indice măresc mecanic R^2
- Shrinkage-ul Vasicek modifică puțin estimațiile: estimațiile zilnice sînt precise (se $\approx 0{,}04$–$0{,}07$); prețurile neactualizate (stale prices) deplasează beta zilnic al acțiunilor mai puțin lichide (Seminarul 3, problema B4)

MFM_ch3_bvb_betas

De la o singură valoare alfa la testul GRS (1/2)

- **Alfa lui Jensen** (Jensen (1968)): termenul liber al modelului de piață, α_i
  - CAPM implică $\alpha_i = 0$ pentru orice activ
- Cîte un test t pentru fiecare activ: XLK are $t = 0{,}13$
  - Respingerile false se acumulează cînd activele sînt multe (Secțiunea 8)
- **GRS** (Gibbons, Ross & Shanken (1989)): test simultan al ipotezei $H_0 : \alpha_1 = \cdots = \alpha_N = 0$

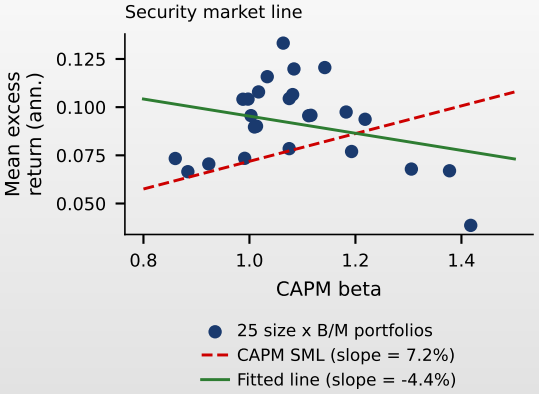
$$W = \frac{T - N - 1}{N} \, \frac{\hat{\boldsymbol{\alpha}}^\top \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\alpha}}}{1 + \hat{\mu}_m^2 / \hat{\sigma}_m^2} \sim F(N, \, T - N - 1)$$

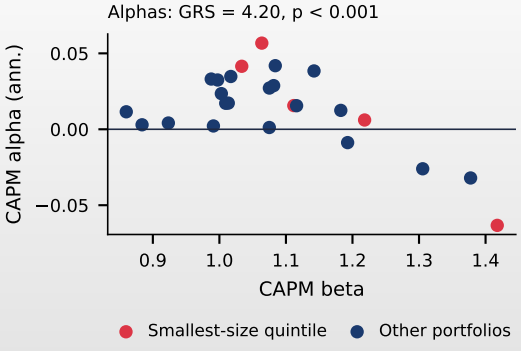
- Notațiile
  - N: numărul activelor de test; T: numărul de luni; $\hat{\boldsymbol{\alpha}}$: cele N valori alfa estimate
  - $\hat{\boldsymbol{\Sigma}}$: covariança reziduurilor estimată prin verosimilitate maximă (împărțire la T)
  - $\hat{\mu}_m / \hat{\sigma}_m$: raportul Sharpe al pieței

De la o singură valoare alfa la testul GRS (2/2)

- $\hat{\boldsymbol{\alpha}}^{\top}\hat{\boldsymbol{\Sigma}}^{-1}\hat{\boldsymbol{\alpha}}$: valorile alfa ridicate la pătrat și ponderate cu inversa covarianței reziduurilor
- Decizia: H_0 se respinge cînd W depășește cuantila de 95% a distribuției $F(N, T-N-1)$; F: distribuția Fisher
- Distribuția este exactă, condiționat de factori
  - erori i.i.d. (independente și identic distribuite) cu distribuția Normală multivariată, independente de factori
  - medie zero și covarianță constantă nesingulară
- Un W mare: piața este departe de frontiera medie–varianță generată de piață și de activele de test

Dreapta pieței titlurilor (SML) în date (1/2)





MFM_ch3_sml

Dreapta pieței titlurilor (SML) în date (2/2)

- Active de test: acțiunile americane sortate în fiecare iunie în 5 cvintile de mărime și 5 de B/M, 25 de portofolii ponderate după valoare (Fama & French (1993)), iulie 1963 – iulie 2026, $T = 757$
- Dreapta CAPM are panta 7,2% pe an; dreapta estimată are panta $-4{,}4\%$: beta mai mare, randament mediu **mai mic**
- Valorile beta acoperă doar 0,86–1,42, randamentele medii în exces 3,9%–13,3%
- Alfa small-value $+5{,}7\%$, small-growth $-6{,}3\%$ pe an; 10 din 25 de valori alfa au $|t| > 1{,}96$
- GRS $= 4{,}20$, p-value-ul 8×10^{-11}: CAPM este respins

MFM_ch3_sml

GRS ca test al raportului Sharpe

- Identitate (Gibbons, Ross & Shanken (1989)): cu $\hat{\boldsymbol{\Sigma}}$ și momentele estimate prin verosimilitate maximă

$$\hat{\boldsymbol{\alpha}}^\top \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\alpha}} = \widehat{SR}^2(f, \mathrm{R}) - \widehat{SR}^2(f)$$

  - $\widehat{SR}^2(f, \mathrm{R})$: pătratul raportului Sharpe al portofoliului tangent format din factor și cele N active de test; $\widehat{SR}^2(f)$: cel al factorului singur
- Deci GRS măsoară creșterea raportului Sharpe obținută prin adăugarea activelor de test

$$W = \frac{T - N - 1}{N} \cdot \frac{\widehat{SR}^2(f, \mathrm{R}) - \widehat{SR}^2(f)}{1 + \widehat{SR}^2(f)}$$

- 25 de portofolii, rapoarte Sharpe lunare: piața 0,134 (0,47 pe an); piața plus portofoliile 0,405 (1,40 pe an)
- $W = 29{,}24 \times (0{,}405^2 - 0{,}134^2)/(1 + 0{,}134^2) = 4{,}20$; cîștigul așteptat sub H_0 este mult mai mic (Anexă)

Încălcarea ipotezelor GRS

- **Cozi groase și volatility clustering** (Capitolul 1): distribuția F nu mai este exactă
  - Bootstrap pe reziduuri sub H_0: se reeșantionează rînduri întregi de reziduuri și se reconstruiesc randamentele cu $\alpha = 0$ (Seminarul 3, problema B7)
  - Bootstrap-ul este robust la lipsa normalității doar dacă erorile sînt i.i.d. și independente de factori
  - Test Wald GMM: momentele $\varepsilon_t \otimes (1, f_t)$, fiecare reziduu înmulțit cu 1 și cu factorul ($\otimes$: produsul Kronecker)
  - $W_{\text{GMM}} = \hat{\boldsymbol{\alpha}}^\top \hat{\mathrm{V}}_{\alpha}^{-1} \hat{\boldsymbol{\alpha}} \to \chi^2_N$, $\hat{\mathrm{V}}_\alpha$: estimatorul HAC al lui $\mathrm{Var}(\hat{\boldsymbol{\alpha}})$; robust la heteroscedasticitate și autocorelație
- **Condiția de rang**: $\hat{\boldsymbol{\Sigma}}$ are rangul cel mult $T - 2$
  - GRS nu se poate calcula cînd $N \geq T - 1$, iar puterea lui scade mult înainte de acest punct
- Teste construite pentru multe active: ▸ Anexă

O SML plată: Black și Betting Against Beta



Fischer Black (1938–1995)

Foto: Dalmatine at English Wikipedia (încărcată 2009); domeniu public; Wikimedia Commons

- Black (1972): cu împrumut restricționat, evaluarea prin beta se păstrează cu o rată **cu beta zero** peste R_f în locul ratei fără risc
- Predicție: SML este **mai plată** decît dreapta CAPM și pornește de la rata cu beta zero
- Frazzini & Pedersen (2014): investitorii constrînși care doresc mai mult risc cumpără active cu beta mare în loc să folosească efectul de levier; aceste active devin scumpe și au randamente mai mici
- Strategia lor, **BAB** (Betting Against Beta, pariul împotriva lui beta)

$$r_t^{\mathbf{BAB}} = \frac{R_{L,t} - R_{f,t}}{\beta_L} - \frac{R_{H,t} - R_{f,t}}{\beta_H}$$

- L: portofoliu cu beta mic, cu levier pînă la beta 1; H: portofoliu cu beta mare, redus la beta 1; BAB are beta zero prin construcție și un randament mediu pozitiv în datele lor
- Un spread nescalat beta mic minus beta mare (Seminarul 3, problema C2) nu este neutru față de beta: media lui combină prima cu o expunere negativă la piață

Limitele testelor CAPM

- Roll (1977): CAPM se referă la portofoliul **adevărat** al pieței, care cuprinde întreaga avuție; indicii bursieri omit obligațiunile, activele imobiliare, firmele private și capitalul uman
- Orice portofoliu eficient evaluează exact toate activele prin beta: cu R_f pe CML, cu o rată cu beta zero (Black (1972)) pe frontiera activelor riscante (Seminarul 3, problema A2)
  - Un test CAPM este un test comun al modelului și al eficienței aproximării pieței
- **Activele de test contează**: 9 ETF-uri sectoriale, ianuarie 1999 – iulie 2026 ($T = 331$): GRS $= 0{,}53$, $p = 0{,}85$, CAPM nerespins
  - Pe aceleași 331 de luni, cele 25 de portofolii mărime $\times$ B/M îl resping: GRS $= 2{,}91$, $p = 9 \times 10^{-6}$
  - Sectoarele combină firme mici și mari, de valoare și de creștere: nu creează dispersie în caracteristicile care contează
- Nerespingerea este o dovadă slabă; evaluați modelele pe active cu dispersie în randamentele așteptate

Teoria evaluării prin arbitraj

- **APT**: Arbitrage Pricing Theory (teoria evaluării prin arbitraj), Ross (1976)
- Randamentele urmează un model cu K factori și riscuri idiosincratice mici

$$R_{i,t} = \mathbb{E}[R_i] + \boldsymbol{\beta}_i^\top \mathrm{f}_t + \varepsilon_{i,t}, \qquad \mathbb{E}[\mathrm{f}_t] = 0$$

- **Absența arbitrajului** (niciun profit fără risc și fără investiție) implică, aproximativ

$$\mathbb{E}[R_i] - R_f = \boldsymbol{\beta}_i^\top \boldsymbol{\lambda}$$

- $\boldsymbol{\beta}_i$: cele K încărcări ale activului i; f_t: componentele neanticipate ale factorilor, cu media 0; $\boldsymbol{\lambda}$: **primele de risc**, randamentul așteptat suplimentar pe unitatea fiecărei expuneri
- Teoria nu spune **care** sînt factorii: ei trebuie găsiți în date

Construcția factorilor: portofolii long–short

mărime: mediana NYSE; B/M: 30% / 40% / 30%

	Mic (growth)	Neutru	Mare (value)
Mici	S_L	S_N	S_H
Mari	B_L	B_N	B_H

$$\text{SMB} = \tfrac{1}{3}(S_L + S_N + S_H) - \tfrac{1}{3}(B_L + B_N + B_H)$$

$$\text{HML} = \tfrac{1}{2}(S_H + B_H) - \tfrac{1}{2}(S_L + B_L)$$

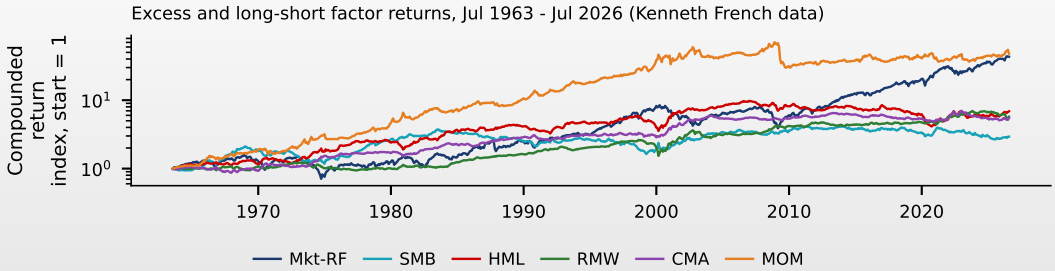
- Un **factor construit prin sortare** cumpără acțiunile cu valoare mare a unei caracteristici și le vinde pe cele cu valoare mică
- Investiție netă zero: randamentul este o diferență de randamente, $f_t = R_{\textbf{mare},t} - R_{\textbf{mic},t}$
- Sortarea Fama–French 2×3 în fiecare iunie, cu datele contabile din anul anterior, portofolii ponderate după valoare
  - **SMB** (Small Minus Big): acțiuni mici minus acțiuni mari
  - **HML** (High Minus Low): B/M mare (valoare) minus B/M mic (creștere)
- Aceeași construcție pe profitabilitate și investiții dă RMW și CMA (slide-ul următor)

Modelele factoriale standard

Model	Factori	Referință	Motivație
CAPM	Mkt-RF	Sharpe (1964)	echilibru
FF3	Mkt-RF, SMB, HML	Fama & French (1993)	efectele de mărime și B/M (Fama & French (1992))
Carhart	FF3 + MOM	Carhart (1997)	evaluarea fondurilor
modelul q	piață, mărime, investiții, ROE	Hou, Xue & Zhang (2015)	deciziile de investiții ale firmelor
FF5	Mkt-RF, SMB, HML, RMW, CMA	Fama & French (2015)	modelul de actualizare a dividendelor

- FF3: $R^e_{i,t} = \alpha_i + b_i \, \text{MKT}_t + s_i \, \text{SMB}_t + h_i \, \text{HML}_t + \varepsilon_{i,t}$, cu MKT = Mkt-RF și încărcările b_i, s_i, h_i pe cei trei factori; un model bun produce, în regresiile pe serii de timp, valori alfa apropiate de zero (GRS nerespins)
- Factorii adăugați la FF3 (ROE: Return On Equity, rentabilitatea capitalului propriu)
  - **RMW** (Robust Minus Weak): profitabilitate operațională mare minus mică
  - **CMA** (Conservative Minus Aggressive): creștere mică minus mare a activelor
  - **MOM** (UMD, Up Minus Down): randament mare minus mic din luna $t-12$ pînă în $t-2$; cîștigătorii trecuți continuă să cîștige 3–12 luni (Jegadeesh & Titman (1993))
- FF3 folosește propriul SMB (sortări 2×3 după mărime și B/M); SMB din FF5 este media diferențelor de mărime din trei sortări, deci FF3 nu este inclus în FF5

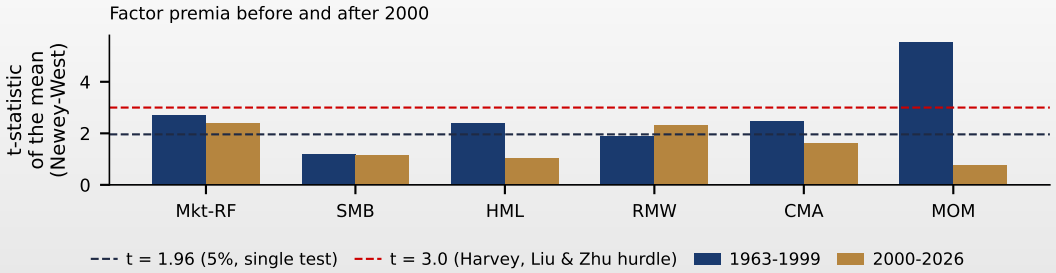
Șase factori în șaizeci și trei de ani



- Randamente factoriale lunare capitalizate pornind de la 1, pe scară logaritmică: randamente în exces sau long–short, deci fără dobînda la capital sau la colateral; curbele nu reprezintă avuția unei investiții finanțate
- Iulie 1963 – iulie 2026: Mkt-RF 43,2, MOM 48,0, HML 6,9, RMW 5,7, CMA 5,5, SMB 2,9
- Momentum a atins maximul înainte de 2009 și a pierdut mult la revenirea din 2009: un **crah de momentum**
- Factorul valoare a stagnat sau a pierdut, aproximativ din 2007 pînă în 2020
- Randamente anuale medii: Mkt-RF 7,2%, MOM 7,3%, HML 3,6%, RMW 3,1%, CMA 3,0%, SMB 2,3%

MFM_ch3_factor_cum

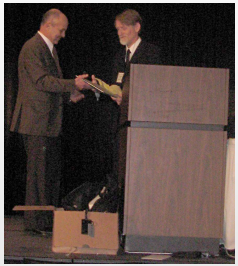
Stabilitatea primelor în timp



- Statistica t a randamentului lunar mediu al factorului (Newey–West), 1963–1999 față de 2000–2026
- Momentum: $t = 5{,}53$ înainte de 2000, 0,75 după; media 10,7% față de 2,5% pe an
- Valoare (HML): $t = 2{,}39$, apoi 1,02; media 4,2% față de 2,8%
- Profitabilitatea (RMW) este excepția: $t = 1{,}90$, apoi 2,31; prima pieței rămîne semnificativă în ambele jumătăți ($t = 2{,}70$ și 2,39)
- O împărțire calendaristică nu este un eveniment de publicare: datarea scăderii necesită specificația din Secțiunea 12

MFM_ch3_factor_tstats

Cele două etape



Eugene Fama, premiul Morgan Stanley–AFA, 2008

Foto: TonyTheTiger (2008); CC BY-SA 3.0; Wikimedia Commons

- Fama & MacBeth (1973) estimează primele de risc $\boldsymbol{\lambda}$ din $\mathbb{E}[R_i^e] = \lambda_{\mathbf{0}} + \boldsymbol{\beta}_i^\top \boldsymbol{\lambda}$ (Fama: Premiul Nobel 2013)
- **Etapa 1**: serii de timp, cîte o regresie pentru fiecare activ
  - randamente $T \times N$, factori $T \times K \Rightarrow$ valorile beta $\hat{\mathrm{B}}$, $N \times K$

$$R_{i,t}^e = a_i + \boldsymbol{\beta}_i^\top \mathbf{f}_t + \varepsilon_{i,t}$$

- **Etapa 2**: transversal, în fiecare lună o regresie a celor N randamente pe $\mathrm{X} = [1, \hat{\mathrm{B}}]$

$$R_{i,t}^e = \lambda_{\mathbf{0},t} + \hat{\boldsymbol{\beta}}_i^\top \boldsymbol{\lambda}_t + u_{i,t}, \qquad \hat{\boldsymbol{\lambda}} = \tfrac{1}{T} \textstyle\sum_t \hat{\boldsymbol{\lambda}}_t$$

- $\lambda_{\mathbf{0}}$: eroare de evaluare comună tuturor activelor, zero dacă modelul este corect; a_i: termenul liber din etapa 1; $u_{i,t}$: reziduul din etapa 2; $\hat{\boldsymbol{\lambda}}$: media pantelor lunare
- Metoda admite factori care **nu** sînt portofolii tranzacționate, precum și caracteristici ale firmelor ca regresori

Erori standard pentru primele de risc (1/2)

- **Fama–MacBeth**: estimațiile lunare $\hat{\lambda}_{k,t}$ formează un eșantion de volum T

$$\text{se}_{FM}(\hat{\lambda}_k) = s(\hat{\lambda}_{k,t})/\sqrt{T}$$

  - $s(\cdot)$: abaterea standard de selecție pe cele T luni
  - robuste la corelația transversală a reziduurilor
  - dacă $\hat{\lambda}_{k,t}$ este autocorelat, se folosește Newey–West pe această serie
- **Specificare greșită**: erorile Fama–MacBeth, Newey–West și Shanken (slide-ul următor) presupun un model corect
  - erori de evaluare $\mathbf{e} = \boldsymbol{\mu} - \mathbf{X}\boldsymbol{\gamma} = 0$; $\boldsymbol{\mu}$: randamentele medii în exces, $\boldsymbol{\gamma} = (\lambda_0, \boldsymbol{\lambda}^\top)^\top$
  - cînd GRS respinge modelul, zgomotul din $\hat{\mathbf{B}}$ se înmulțește cu e și adaugă variață (Kan, Robotti & Shanken (2013); forma GMM în Anexă)

Erori standard pentru primele de risc (2/2)

- **Erori în variabile**: etapa 2 folosește $\hat{\beta}$, nu β, deci se_{FM} este prea mică
- Shanken (1992) înmulțește cu $(1+c)$ partea varianței care nu ține de factori

$$\text{Var}_{\text{Sh}}(\hat{\boldsymbol{\lambda}}) = (1+c)\left[\text{Var}_{FM}(\hat{\boldsymbol{\lambda}}) - \tfrac{1}{T}\boldsymbol{\Sigma}_f\right] + \tfrac{1}{T}\boldsymbol{\Sigma}_f, \qquad c = \hat{\boldsymbol{\lambda}}^\top \boldsymbol{\Sigma}_f^{-1}\hat{\boldsymbol{\lambda}}$$

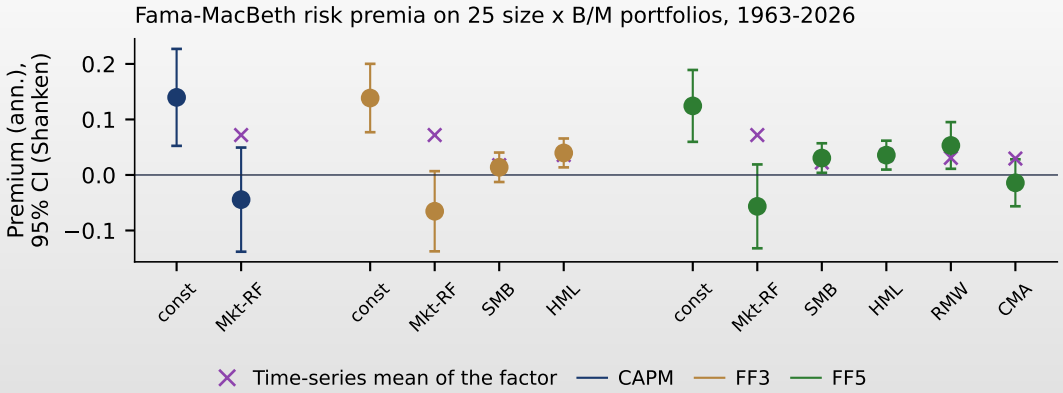
  - Var_{FM}: varianța Fama–MacBeth, $s^2(\hat{\boldsymbol{\lambda}}_t)/T$; $\boldsymbol{\Sigma}_f$: covarianța factorilor
  - c: pătratul raportului Sharpe al primelor pe perioadă, 0,03 pentru FF3 aici, mai mare pentru unii factori netranzacționați
- Un c mic (factori tranzacționați, date lunare): corecția este mică; un c mare: statisticile t Fama–MacBeth sînt supraestimate

Exemplu rezolvat: patru erori standard pentru prima de valoare

FF3, HML	$\hat{\lambda}$	**e.s.**	t	**Semnificativ la 5%?**
Fama–MacBeth	3,97%	1,33%	2,99	da
Newey–West (6 laguri)	3,97%	1,62%	2,45	da
Shanken	3,97%	1,33%	2,99	da
Kan–Robotti–Shanken	3,97%	1,32%	3,00	da

- 25 de portofolii mărime $\times$ B/M, 1963–2026; corecția Shanken modifică foarte puțin eroarea ($c = 0{,}03$ pe lună)
- Aici contează cel mai mult autocorelația pantelor lunare $\hat{\lambda}_t$: Newey–West, 6 laguri conform regulii pentru $T = 757$
- FF5: pentru RMW, eroarea standard robustă la specificarea greșită crește de la 2,1% la 2,6%, iar t scade de la 2,5 la 2,1
- La pragul $t > 3$ din Secțiunea 8, HML este la limită pentru orice alegere (2,45–3,00)

Primele de risc estimate (1/2)



MFM_ch3_fama_macbeth

Primele de risc estimate (2/2)

- 25 de portofolii mărime × B/M, 1963–2026; bare: intervale de 95% cu erori Shanken; cruciulițe: mediile factorilor
- CAPM: termen liber 14,0% (e.s. 4,4%), prima pieței −4,4% (e.s. 4,8%)
- FF3: SMB 1,4% (1,4%), HML 4,0% (1,3%); FF5: RMW 5,3% (2,1%), CMA −1,4% (2,2%)
- Factor tranzacționat: λ ar trebui să fie egal cu media lui în timp; HML 4,0% față de 3,6%, valori apropiate; piața (FF3) −6,5% față de 7,2%, valori îndepărtate
- Valorile beta de piață acoperă doar 0,86–1,42 în CAPM (abatere standard transversală 0,14) și 0,89–1,14 în FF3 (0,07): λ_m este **slab identificat**, iar un termen liber mare absoarbe nivelul (Lewellen, Nagel & Shanken (2010))

MFM_ch3_fama_macbeth

Factori inutili și factori slabi

- Un **factor inutil** g_t este independent de toate randamentele: $\beta_g = 0$, deci $\hat{\beta}_{i,g} = O_p(T^{-1/2})$, adică de ordinul lui $1/\sqrt{T}$: este doar zgomot
- Etapa 2 împarte la acest zgomot: $\hat{\lambda}_g$ nu converge la zero, iar testul t respinge prea des cînd modelul este greșit specificat (Kan & Zhang (1999))
- Simulare pe cele 25 de portofolii: CAPM plus un factor independent cu distribuția Normală, 2 000 de replicări, nivel nominal 5%
  - $\lambda_g = 0$ este respins în 60% (erori Fama–MacBeth) și 27% (erori Shanken) din replicări
  - Testul Wald din prima etapă pentru $\beta_{i,g} = 0$, pentru toți i: respins în 6,7%; aplicați-l înaintea etapei 2
- **Identificare slabă**: valori beta apropiate de zero (factor slab) sau aproape constante între active (piața, aici)
  - teste robuste la identificare (Kleibergen (2009))
  - cu multe active, consistența etapei 2 depinde de cît de puternici sînt factorii (Anatolyev & Mikusheva (2022))

O evaluare sceptică: adăugarea a 30 de portofolii pe industrii

	R^2 OLS		R^2 GLS	
Model	25	25 + 30	25	25 + 30
CAPM	0,08	0,00	0,06	0,01
FF3	0,66	0,22	0,21	0,08
FF5	0,76	0,24	0,26	0,10

Lunar 1963–2026, termen liber și prime fără restricții

- Cele 25 de portofolii au o structură puternică de trei factori: orice factori corelați cu SMB și HML le reproduc mediile, deci un R^2 OLS mare este un criteriu puțin exigent (Lewellen, Nagel & Shanken (2010))
- Trei verificări
  - Lărgiți mulțimea activelor de test: FF3 scade de la 0,66 la 0,22 cînd se adaugă 30 de industrii
  - Raportați R^2 **GLS** (Generalised Least Squares, metoda celor mai mici pătrate generalizate), ponderat, ca în GRS, cu $\hat{V}^{-1}$, inversa matricei de covarianță a randamentelor: niciodată peste 0,26
  - Impuneți $\lambda = \mathbb{E}[f]$ pentru factorii tranzacționați, fără termen liber: FF3 pe cele 55 de active dă $R^2 = -0{,}27$
- Acțiuni în locul portofoliilor: mai multă dispersie a valorilor beta, erori în variabile mai mari (Ang, Liu & Schwarz (2020))

Factorii ca factor stochastic de actualizare



Lars Peter Hansen, Premiul Nobel pentru Economie 2013

Foto: Bengt Nyman (2013); CC BY 2.0; Wikimedia Commons

- **SDF** (Stochastic Discount Factor, factorul stochastic de actualizare) m_t: evaluează toate randamentele în exces, $\mathbb{E}[m_t R^e_{i,t}] = 0$
- Un model factorial liniar este un SDF, $m_t = 1 - \mathrm{b}^\top(\mathrm{f}_t - \mathbb{E}\mathrm{f})$; b: coeficienții SDF, $\mathbb{E}$f: mediile factorilor
- Prin înlocuire: $\mathbb{E}[R^e_i] = \mathrm{Cov}(R^e_i, \mathrm{f}_t)^\top \mathrm{b} = \boldsymbol{\beta}_i^\top \boldsymbol{\lambda}$ cu $\boldsymbol{\lambda} = \boldsymbol{\Sigma}_f \mathrm{b}$: modelul de evaluare prin beta din Secțiunea 6
- Testul $\mathrm{b} \neq 0$ arată dacă un factor ajută la evaluarea activelor; testul $\boldsymbol{\lambda} \neq 0$, dacă factorul este remunerat
- Aceste condiții de momente se estimează prin GMM, Hansen (1982); sinteză a perspectivei ratelor de actualizare: Cochrane (2011)

Compararea modelelor: rapoarte Sharpe maxime

Raport Sharpe maxim (anual)	CAPM	FF3	Carhart	FF5	FF5 + MOM
1963–2026 ($T = 757$)	0,47	0,66	0,97	0,97	1,16
2000–2026 ($T = 319$)	0,48	0,54	0,67	0,97	1,02

- Barillas & Shanken (2018): un model se evaluează după $SR^2(\mathrm{f}) = \boldsymbol{\mu}_f^\top \boldsymbol{\Sigma}_f^{-1} \boldsymbol{\mu}_f$ al factorilor săi ($\boldsymbol{\mu}_f$, $\boldsymbol{\Sigma}_f$: mediile și covariația factorilor), pătratul raportului Sharpe al portofoliului lor tangent; activele de test nu contează în comparație
- Modele incluse unul în altul: în eșantion SR^2 nu poate decît să crească, deci testați alfa din regresia factorului adăugat pe ceilalți (regresie de spanning)
  - HML pe ceilalți cinci factori: $\alpha = 0{,}9\%$ pe an ($t = 0{,}75$); din 2000 $-1{,}7\%$ ($t = -0{,}81$): nicio contribuție incrementală semnificativă a HML, ca în Fama & French (2015)
- FF5 față de Carhart (neincluse unul în altul): diferența SR^2 anual 0,00, interval de 95% $[-0{,}57; 0{,}66]$; din 2000 0,50, $[-0{,}24; 1{,}48]$ (bootstrap staționar, Politis & Romano (1994))
- O altă măsură independentă de model, distanța Hansen–Jagannathan: ▸ Anexă

Factor zoo

- Cochrane (2011) a numit lista tot mai lungă de factori noi un *factor zoo*
- Harvey, Liu & Zhu (2016) catalogează sute de factori publicați (316 în lista lor)
- Fiecare a fost testat ca și cum ar fi fost singurul: $|t| > 1{,}96$ la 5%
- Cu multe teste, unii factori trec pragul din întîmplare: **data mining**, numit și p-hacking
- Propunerea lor: un factor nou are nevoie de $|t| > 3{,}0$

Controlul descoperirilor false

- **FDR** (False Discovery Rate, rata descoperirilor false): ponderea așteptată a respingerilor false în totalul respingerilor
- **FWER** (Family-Wise Error Rate): probabilitatea de a avea cel puțin o respingere falsă (Capitolul 2)
- Notațiile tabelului: M: numărul de teste; α: nivelul de semnificație (nu o eroare de evaluare); $p_{(1)} \leq \cdots \leq p_{(M)}$: p-value-urile ordonate; $H_{(j)}$: ipoteza cu a j-a cea mai mică valoare; **BH**: procedura Benjamini–Hochberg

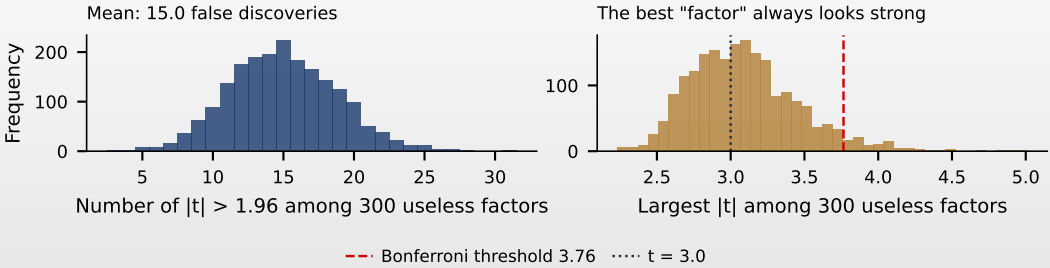
Procedura	**Controlează**	**Respinge $H_{(j)}$ dacă**	**Validă pentru**
Bonferroni	FWER	$p_{(j)} \leq \alpha/M$	orice dependență
Holm (Holm (1979))	FWER	$p_{(k)} \leq \alpha/(M-k+1)$, $\forall k \leq j$	orice dependență
BH (Benjamini & Hochberg (1995))	FDR	$j \leq$ cel mai mare k cu $p_{(k)} \leq k\alpha/M$	independență, dep. pozitivă
BY (Benjamini & Yekutieli (2001))	FDR	ca BH, pragurile împărțite la $\sum_{k=1}^{M} 1/k$	orice dependență

- Dependență pozitivă: statisticile de test asociate ipotezelor nule adevărate cresc împreună (condiția PRDS, Benjamini & Yekutieli (2001))
- Controlul FDR se potrivește căutării printre mulți factori candidați

Exemplu rezolvat: zece factori candidați

- p-value-uri ordonate: 0,0004; 0,002; 0,006; 0,011; 0,018; 0,027; 0,041; 0,070; 0,15; 0,62; nivel de semnificație $\alpha = 5\%$
- Naiv ($p \leq 0{,}05$): **7** descoperiri
- Bonferroni ($p \leq 0{,}005$): **2**
- Holm: $0{,}0004 \leq 0{,}005$, $0{,}002 \leq 0{,}0056$, $0{,}006 \leq 0{,}00625$, $0{,}011 > 0{,}0071$, oprire: **3**
- Pragurile BH $0{,}005j$: $p_{(6)} = 0{,}027 \leq 0{,}030$ este ultima respingere: **6**
- Seminarul 3, problema A1 repetă procedura pe un alt vector, cu un grafic al pragurilor

Simulare: 300 de factori inutili



- 2 000 de replicări; fiecare extrage 300 de statistici t independente din distribuția Normală standard (fără primă reală)
- În medie, 15,0 factori inutili trec pragul $|t| > 1{,}96$; valoarea așteptată $300 \times 0{,}05 = 15$
- În medie, 0,83 trec pragul $|t| > 3$; cel puțin unul trece în 57% din replicări; mediana celui mai mare $|t|$: 3,06
- Pragul Bonferroni pentru 300 de teste: $|t| > 3{,}76$; pragurile cresc cu numărul de teste încercate efectiv, inclusiv cele nepublicate

MFM_ch3_false_discoveries

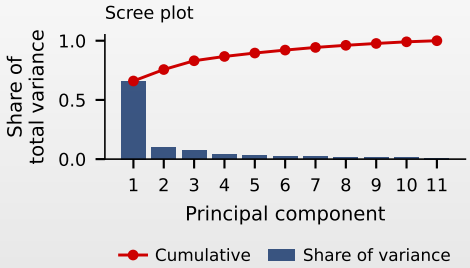
Componentele principale, pe scurt

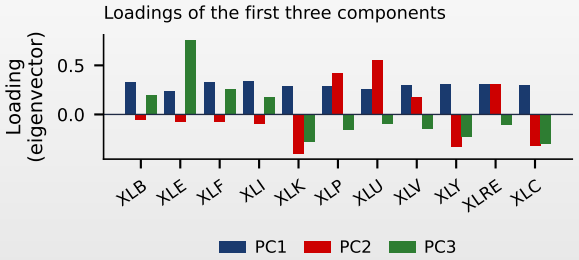
- **Factori latenți**: estimați doar din randamente, fără a-i numi dinainte
- **PCA** (Principal Component Analysis, analiza componentelor principale) a matricei de corelație C a randamentelor standardizate

$$\mathrm{C} = \mathbf{\Gamma} \mathrm{D} \mathbf{\Gamma}^\top, \qquad \mathrm{y}_t = \mathbf{\Gamma}^\top \mathrm{z}_t$$

  - z_t: randamentele standardizate ale zilei t; y_t: componentele
  - $\mathbf{\Gamma}$: vectorii proprii pe coloane; D: matricea diagonală a valorilor proprii ℓ_k
- Valori proprii $\ell_1 \geq \cdots \geq \ell_N$ (ℓ, nu prima de risc λ); vectorii proprii sînt **încărcările**; componenta k explică ℓ_k / N din varianță
- Două active cu corelația ρ: $\ell = 1 \pm \rho$, vectori proprii $(1,1)/\sqrt{2}$ („piața") și $(1,-1)/\sqrt{2}$ (spread-ul); în criză ρ crește și PC1 domină
- Manual: Härdle & Simar (2019), capitolul despre componente principale; N active cu corelații egale: Seminarul 3, problema A8

PCA pe ETF-urile sectoriale din SUA





- 11 ETF-uri sectoriale, randamente logaritmice zilnice, 20 iunie 2018 – 18 septembrie 2026 ($T = 2\,073$ zile comune)
- PC1 explică 66,0%; toate încărcările sînt pozitive (0,24–0,34); corelația cu SPY 0,954: puternic legată de piață
- PC2 (9,7%): utilități $+0{,}55$, bunuri de larg consum $+0{,}42$, imobiliare $+0{,}31$ față de tehnologie $-0{,}40$, consum discreționar $-0{,}33$: **sectoare defensive față de sectoare de creștere**, fără nume dat dinainte
- PC3 (7,4%) este dominată de energie; trei componente explică 83,1%

MFM_ch3_pca

Numărul de factori

- Model factorial aproximativ $x_{it} = \mathbf{\Lambda}_i^\top \mathrm{F}_t + e_{it}$, $N, T \to \infty$
  - x_{it}: randamentul standardizat; F_t: factorii; $\mathbf{\Lambda}_i$: încărcările; e_{it}: partea idiosincratică
  - $V(k)$: media pătratelor reziduurilor după primele k componente; ℓ_k: a k-a cea mai mare valoare proprie
- Bai & Ng (2002): $\hat{k} = \arg\min_k \left[\ln V(k) + k \, \frac{N+T}{NT} \ln \min(N, T) \right]$ (criteriul IC_{p2}); Ahn & Horenstein (2013): raportul valorilor proprii $\hat{k} = \arg\max_k \ell_k / \ell_{k+1}$, fără o penalizare care trebuie aleasă
- Regula lui Kaiser (1960) ($\ell_k > 1$) nu are justificare asimptotică: valorile proprii ale zgomotului dintr-o matrice de corelație sînt dispersate în jurul lui 1

Panel	N	T	Kaiser	Bai–Ng	Ahn–Horenstein
11 ETF-uri sectoriale, zilnic 2018–2026	11	2 073	2	5	1
100 portofolii mărime × B/M, lunar 1963–2026	95	757	3	4	1

- Randamente standardizate; k maxim: 5 pentru sectoare, 8 pentru portofolii; 5 portofolii cu luni lipsă sînt eliminate
- Ahn–Horenstein alege factorul dominant al pieței (raport 14,6); următorul vîrf este la $k = 3$ (raport 3,5), structura FF3
- Bai–Ng pe 11 sectoare atinge limita superioară $k = 5$: penalizarea este construită pentru N mare, deci cu N mic răspunsul este fragil (Anexă)

Limitele PCA în evaluarea activelor

- Încărcările sînt **constante**: PCA nu poate urmări o acțiune a cărei mărime sau valoare se schimbă
- Componentele explică **varianța**, nu neapărat **randamentele medii**
- Acțiunile individuale intră și ies din eșantion: un panel de acțiuni este nebalansat
- Semnele componentelor sînt arbitrare; rotațiile păstrează componentele principale doar în subspațiile proprii cu valori proprii egale, iar un model cu factori latenți este identificat doar pînă la o rotație
- PCA cu primă de risc și estimatorul în trei etape al primelor păstrează baza PCA, dar urmăresc explicarea randamentelor medii (Anexă); PCA și analiza factorială în finanțe: Franke, Härdle & Hafner (2019)

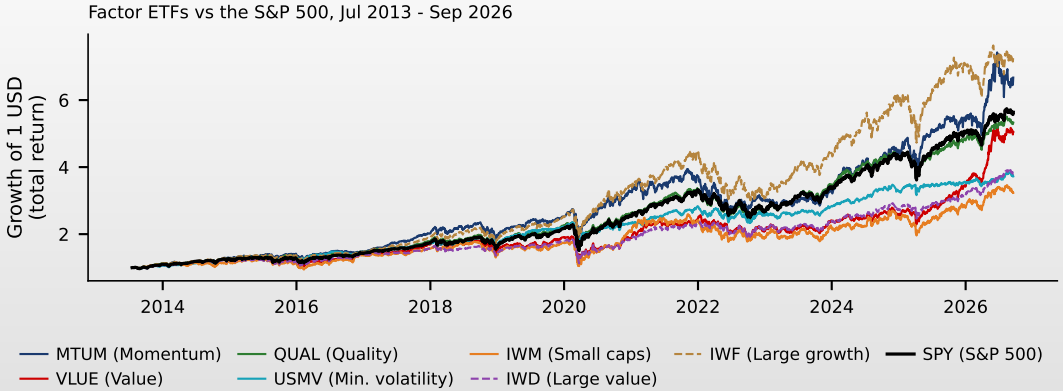
PCA instrumentată

- **IPCA**: Instrumented Principal Component Analysis (PCA instrumentată), Kelly, Pruitt & Su (2019)
- Încărcările sînt funcții de L caracteristici observate $z_{i,t}$ (mărime, B/M, momentum, ...)

$$R^e_{i,t+1} = \alpha_{i,t} + \boldsymbol{\beta}^\top_{i,t} f_{t+1} + \varepsilon_{i,t+1}, \qquad \boldsymbol{\beta}^\top_{i,t} = z^\top_{i,t} \boldsymbol{\Gamma}_\beta$$

- $\boldsymbol{\Gamma}_\beta$ ($L \times K$) și factorii latenți f_t se estimează împreună prin metoda celor mai mici pătrate alternante
- Test: sînt caracteristicile remunerate prin beta („covariațe") sau direct ca alfa ($\alpha_{i,t} = z^\top_{i,t} \boldsymbol{\Gamma}_\alpha$)?
- Rezultatul, în datele lor pentru acțiuni americane: cîțiva factori IPCA evaluează secțiunea transversală mai bine decît modelele cu tot atîția factori observabili, iar $\boldsymbol{\Gamma}_\alpha$ este nesemnificativ: „caracteristicile sînt covariațe"; factorii criptoactivelor: ▸ Anexă

ETF-urile factoriale față de piață (1/2)



MFM_ch3_factor_etfs

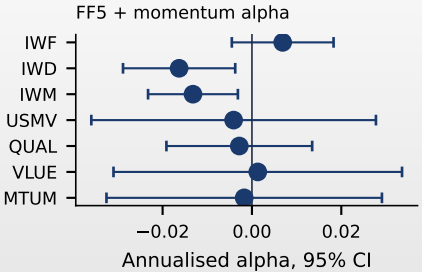
ETF-urile factoriale față de piață (2/2)

- **Smart beta**: portofolii doar long, bazate pe reguli, cu expuneri sporite la anumiți factori, oferite ca ETF-uri
  - păstrează expunerea la piață și nu reproduc neapărat un factor academic long–short
- Treisprezece ani dintr-o singură realizare: nu sînt, în sine, dovezi împotriva primelor

- **CAGR** (rata anuală compusă de creștere) a unei investiții de 1 USD (dolar american), cu dividende reinvestite, din 18 iulie 2013
  - peste SPY (14,0%): firmele mari de creștere (IWF) 16,3%, momentum (MTUM) 15,5%
  - sub SPY: calitate (QUAL) 13,5%, valoare (VLUE) 13,1%, firme mari de valoare (IWD) 10,7%, volatilitate minimă (USMV) 10,5%, firme mici (IWM, indicele Russell 2000) 9,3%

MFM_ch3_factor_etfs

Valorile alfa ale ETF-urilor factoriale



Factor loadings

	Mkt-RF	SMB	HML	RMW	CMA	MOM
MTUM	1.03	-0.12	0.01	-0.22	-0.05	0.36
VLUE	0.98	0.08	0.34	-0.06	0.09	-0.03
QUAL	0.97	-0.08	-0.04	0.15	0.03	-0.04
USMV	0.74	-0.11	-0.02	0.20	0.21	-0.02
IWM	1.04	0.85	0.08	-0.10	-0.02	0.03
IWD	0.94	-0.04	0.29	0.09	0.19	-0.04
IWF	1.03	-0.11	-0.28	-0.03	-0.12	-0.00

- Regresii zilnice pe FF5 + MOM, erori Newey–West, fiecare ETF pe propriul calendar de tranzacționare (2000–2026)
- Încărcările corespund denumirilor: MTUM pe MOM 0,36, VLUE pe HML 0,34, IWM pe SMB 0,85; IWF $-0,28$ pe HML; USMV beta de piață 0,74
- Valori alfa aproape de zero: MTUM $-0,2\%$ ($t = -0,11$), QUAL $-0,3\%$; ETF-urile Russell IWM $-1,3\%$ ($t = -2,57$), IWD $-1,6\%$ ($t = -2,54$), compatibile cu costurile și construcția indicelui
- R^2 între 0,81 și 0,97: în mare parte expunere factorială reambalată

MFM_ch3_etf_alphas

Factor timing, crowding și costuri

- **Factor timing** (sincronizarea factorilor): trecerea de la un factor la altul pe baza unor semnale (spread-uri de evaluare, randamente recente)
  - Incertitudinea primelor și seriile scurte îngreunează verificarea factor timing în afara eșantionului (Capitolul 8)
- **Crowding** (aglomerarea pozițiilor): mulți investitori dețin aceleași poziții factoriale
  - Primele se pot micșora (McLean & Pontiff (2016)), iar crowding-ul poate amplifica pierderile la lichidări forțate; crahul de momentum din 2009 a coincis cu o revenire bruscă a fostelor acțiuni perdante (Daniel & Moskowitz (2016))
- **Implementarea**: factorii long–short ignoră costurile de tranzacționare și comisioanele pentru vînzarea în lipsă; ETF-urile le plătesc

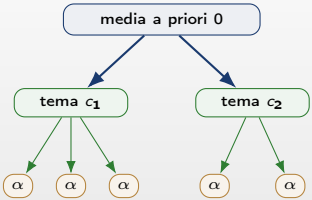
Studiu de caz: întrebările de cercetare (1/2)

- **Critica** la adresa cercetării despre factori are două forme (Jensen, Kelly & Pedersen (2023), Introducere)
  - Lipsa validității interne: rezultatele nu pot fi reproduse; Hou, Xue & Zhang (2020) replică doar 35% dintre anomaliile studiate
  - Lipsa validității externe: rezultatele provin din testarea multor factori fără controlul FDR; Harvey, Liu & Zhu (2016) conchid că majoritatea descoperirilor raportate sînt probabil false
- **Întrebările**
  - au factorii publicați valori alfa CAPM semnificative în datele originale?
  - sînt aceste valori alfa semnificative în afara eșantionului și în alte țări?
  - rămîn ele semnificative după ce se ține cont de testarea multiplă?

Studiu de caz: întrebările de cercetare (2/2)

- **Relevanța**
  - dacă majoritatea factorilor sînt descoperiri false, modelele multifactoriale și investițiile factoriale (Secțiunile 5 și 10) se sprijină pe zgomot
- **O a doua perspectivă asupra factor zoo** (Feng, Giglio & Xiu (2020), Anexă)
  - majoritatea factorilor noi sînt redundanți față de cei existenți
  - Jensen, Kelly & Pedersen tratează în schimb factor zoo ca dovezi corelate despre cîteva teme economice
- **Legătura cu acest capitol**
  - alfa lui Jensen (Secțiunea 4) este mărimea testată
  - Benjamini–Yekutieli (Secțiunea 8) este reperul frecventist
  - shrinkage-ul bayesian extinde la valorile alfa estimarea Vasicek pentru beta (Secțiunea 3)

Studiu de caz: date și metodă (1/2)



alfa fiecărui factor împrumută informație de la ceilalți factori ai temei sale

- **Date** (Secțiunea II): 153 de factori în 93 de țări
  - terțile ale fiecărei caracteristici, ponderi după capitalizarea plafonată
  - poziție long pe partea cu randamentul așteptat mai mare în studiul inițial
  - fiecare factor scalat la o volatilitate idiosincratică anuală de 10%
- **Teme**: 13 grupe de factori americani
  - grupare ierarhică după corelația reziduurilor CAPM
- **Modelul** (Secțiunea I): $f_{i,t} = \alpha_i + \beta_i r_t^m + \varepsilon_{i,t}$
  - $f_{i,t}$: randamentul factorului i; r_t^m: randamentul în exces al pieței
  - valorile alfa $\alpha_i = c_j + s_n + w_i$: componentele temei, semnalului și factorului, cu media a priori 0

Studiu de caz: date și metodă (2/2)

- Un singur factor: media a posteriori aplică shrinkage valorii alfa estimate (ec. 5)

$$\mathbb{E}(\alpha \mid \hat{\alpha}) = \kappa\hat{\alpha}, \qquad \kappa = \frac{1}{1 + \sigma^2/(\tau^2 T)}$$

  - σ: volatilitatea reziduurilor; τ: dispersia valorilor alfa adevărate; T: numărul de luni
  - eșantioanele scurte și zgomotoase primesc mai mult shrinkage, ca la Vasicek (Secțiunea 3)
- **Rata de replicare**: ponderea factorilor semnificativi în studiile inițiale al căror alfa este semnificativ în datele noi
  - descoperire bayesiană: media a posteriori / abaterea standard a posteriori $\geq 1{,}96$
- Ierarhia completă și estimarea: Anexă

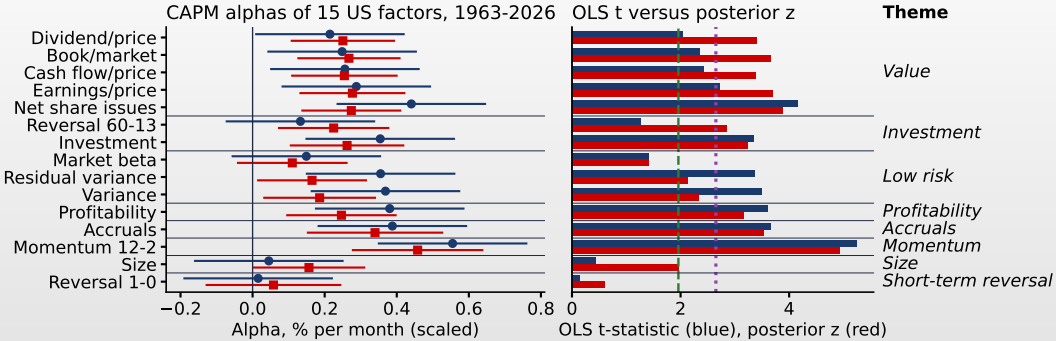
Studiu de caz: rezultatele principale

Rate de replicare, SUA (Figura 1)

Hou, Xue & Zhang (2020), randam. brute	35,0%
Jensen, Kelly & Pedersen, randam. brute	55,6%
Randam. brute, 119 semnificativi inițial	61,3%
Alfa CAPM, OLS	82,4%
Alfa CAPM, Benjamini–Yekutieli	75,6%
Alfa CAPM, Bayes empiric	82,4%
Global, Bayes empiric	82,4%

- Diferența față de Hou, Xue & Zhang (2020): testarea valorilor alfa în locul randamentelor brute este cel mai mare pas (61,3% → 82,4%); eșantionul și construcția factorilor contează aproape la fel de mult (35,0% → 55,6%)
- FDR bayesian 0,1%: shrinkage-ul controlează descoperirile false fără pierderea de putere a unui prag t mai înalt
- **Scăderea** după eșantionul original
  - alfa mediu 0,49% pe lună în eșantion, 0,26% după aceea (−47%)
  - panta valorilor alfa ulterioare pe cele din eșantion: 0,26 (Figura 8), față de circa 0,9, cît ar implica shrinkage-ul singur
- Primele celor mai puternici factori scad cel mai mult: arbitraj sau data mining (Secțiunea 12)
- Rezultatele complete: ▸ Anexă

Studiu de caz: replicare pe datele cursului (1/2)



MFM_ch3_jkp_replication

Studiu de caz: replicare pe datele cursului (2/2)

- 15 factori americani long–short din sortările ponderate după valoare ale Kenneth French Data Library, iulie 1963 – iulie 2026 ($T = 757$); valori alfa CAPM scalate la volatilitate idiosincratică de 10%; temele articolului (etichetele autorilor)
- Rate de replicare: OLS 73,3% (11 din 15), Benjamini–Yekutieli 53,3% (8; $|t|$ critic 2,65), Bayes empiric 86,7% (13); detalii: Anexă
- Shrinkage spre temă, nu doar spre zero: inversarea pe termen lung (tema investiții) 0,13% $\rightarrow$ 0,23% pe lună ($t = 1{,}25$, z a posteriori 2,85)
- Factori nereplicați: beta de piață și inversarea pe termen scurt ($z \leq 1{,}41$); mărimea trece la limită ($z = 1{,}96$), ca în articol, unde mărimea este una dintre cele două teme sub 50%

MFM_ch3_jkp_replication

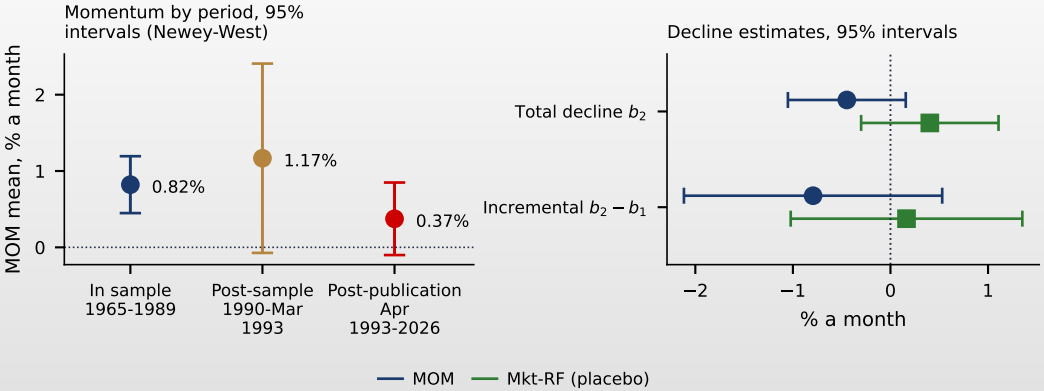
Studiu de caz: limite și întrebări deschise

- **Limitele versiunii de curs**
  - 15 semnale americane în loc de 153 în 93 de țări
  - pragurile de sortare din Kenneth French Data Library în loc de terțile fără microcapitalizări, cu ponderi plafonate
  - o singură regiune, deci fără nivelul semnalului: $\tau_s = 0$ (τ_s: dispersia componentelor s_n ale semnalelor)
  - rata depinde de structura temelor: cu o singură temă comună, rata Bayes empiric este 100%
- **Limite precizate de autori** (▸ Anexă)
  - CAPM ca singur reper; construcția unitară a caracteristicilor; factorii nepublicați în distribuția a priori
- **Întrebări deschise**: datele articolului se opresc în 2020
  - s-au menținut valorile alfa a posteriori și rata de replicare în 2021–2026?
  - poate o distribuție a priori estimată pe factorii americani să facă mai precise estimările factorilor BVB pe eșantioane scurte?
- Datele și codul articolului: jkpfactors.com; proiectul de curs: Seminarul 3, C3

Întrebări deschise și bucla descoperirii

- **Întrebări deschise**
  - de ce scad primele factorilor după publicare: arbitraj, data mining sau o schimbare a riscului?
  - diferă scăderea între factori și piețe?
- Stadiul cunoașterii
  - McLean & Pontiff (2016): pe 97 de predictori, randamentele sînt cu 26% mai mici în afara eșantionului și cu 58% mai mici după publicare; diferența este atribuită tranzacțiilor bazate pe informația publicată
  - Jensen, Kelly & Pedersen (2023): majoritatea factorilor se replică, dar cei mai puternici scad cel mai mult; Chen & Zimmermann (2022): date și cod deschise pentru predictorii publicați
- **Bucla descoperirii, parcursă o dată**
  - Asistentul propune: un tabel al literaturii cu DOI (Digital Object Identifier, identificator digital de obiect), ipoteze concurente cu tiparele prezise, codul regresiei, un plan de robustețe
  - Omul fixează înainte de rulare: datele calendaristice ale evenimentelor (Jegadeesh & Titman (1993): eșantionul se termină în 1989, articolul apare în martie 1993), mulțimea factorilor, corecția pentru testarea multiplă, placebo-ul
  - Verificări: fiecare link DOI funcționează; statisticile t pe subperioade din capitol se reproduc întîi; se notează versiunea datelor
- Prompturi reutilizabile și lista completă de verificări: ▸ Anexă

Ministudiu de caz: arbitrajul și declinul momentum-ului (1/2)



MFM_ch3_ai_discovery

Ministudiu de caz: arbitrajul și declinul momentum-ului (2/2)

- Specificația din McLean & Pontiff (2016): $\text{MOM}_t = a + b_1\text{PostSample}_t + b_2\text{PostPub}_t + e_t$, lunar, ianuarie 1965 – august 2026 ($T = 740$), erori Newey–West; după eșantion: ianuarie 1990 – martie 1993; după publicare: din aprilie 1993
- PostSample_t, PostPub_t: variabile dummy egale cu 1 în acele perioade; a: media din eșantion; b_2: scăderea totală față de media din eșantion; $b_2 - b_1$: efectul incremental al publicării
- $a = 0{,}82\%$ pe lună ($t = 4{,}32$); $b_2 = -0{,}45\%$ ($t = -1{,}45$, interval $[-1{,}05\%; 0{,}16\%]$): cu 54% mai mic; $b_2 - b_1 = -0{,}79\%$ ($t = -1{,}17$); placebo Mkt-RF $b_2 = +0{,}40\%$ ($t = 1{,}12$)
- Aproape de 58% din McLean & Pontiff (2016), dar un singur factor nu poate respinge $H_0 : b_2 = 0$ la 5%; arbitrajul este o interpretare, nu o cauză identificată

MFM_ch3_ai_discovery

Temă de proiect propusă

- **Întrebări**
  - scad primele factorilor Fama–French și momentum după publicare?
  - diferă scăderea între factori?
- **Metoda**
  - regresie comună pentru SMB, HML, RMW, CMA și MOM pe variabile dummy specifice fiecărui factor, după eșantion și după publicare
  - Mkt-RF ca placebo; erori robuste la corelația dintre factori și la autocorelație
  - testarea unei scăderi mai mari acolo unde arbitrajul este mai ușor necesită indicatori la nivel de acțiune (mărime, lichiditate, costul vînzării în lipsă)
- **Replicați întîi**: statisticile t pe subperioade și estimațiile din ministudiul de caz
- **Livrabile**
  - o notă de preînregistrare (H_0, H_1, datele calendaristice din fiecare lucrare, mulțimea factorilor, corecții), fixată printr-un commit înainte de rezultate
  - codul ca Quantlet; un raport cu inferență Newey–West, perioade placebo și putere
- **Jurnale**: prompturile în `AI_USE.md`; erorile depistate în `AI_ERRORS.md`

Idei principale: un flux de lucru empiric

1. **Estimați expunerile** cu erori HAC, raportați eșantionul și aproximarea pieței, aplicați shrinkage valorilor beta extreme (Blume, Vasicek)
2. **Testați simultan restricția de evaluare**: GRS măsoară creșterea raportului Sharpe adusă de activele de test; CAPM eșuează pe cele 25 de portofolii mărime $\times$ B/M (SML plată, GRS $= 4{,}20$)
3. **Estimați primele** în două etape, cu erori robuste la beta estimat și la specificarea greșită; un R^2 mare pe 25 de portofolii este un criteriu puțin exigent
4. **Protejați-vă de factor zoo**: praguri pentru testarea multiplă, teste de spanning, compararea modelelor prin rapoartele Sharpe maxime
5. **Replicați**: factori latenți și dovezi în afara eșantionului; ETF-urile factoriale oferă expunere factorială ieftină, nu alfa

⊡ Întrebări deschise

- de ce scad primele după publicare?
- cum se evaluează activele cu beta variabil în timp?
- ce factori explică randamentele așteptate pe piețe mici precum BVB?

Autoevaluare și capitolele următoare

Întrebări de verificare

- De ce diferă eroarea standard HAC a unui beta de cea clasică, deși beta nu se schimbă?
- De ce poate GRS să nu respingă CAPM pe ETF-urile sectoriale, dar să-l respingă pe cele 25 de portofolii, în aceleași luni?
- De ce pare remunerat un factor inutil în etapa 2?
- De ce poate rata de replicare Bayes empiric să depășească rata Benjamini–Yekutieli?

Legături cu alte capitole

- Capitolul 2: un alfa este o anomalie sau un factor de risc omis, problema ipotezei comune
- Capitolul 4: modele factoriale de covariață și shrinkage pentru Markowitz
- Capitolele 5–6: volatilitate, corelații și beta variabile în timp
- Capitolul 8: backtesting pentru strategii factoriale fără overfitting
- Capitolul 13: machine learning pentru secțiunea transversală a randamentelor

Anexă: GRS sub ipoteza nulă

- Sub H_0 și ipotezele exacte, $W \sim F(N, T-N-1)$, deci $\mathbb{E}[W] = \frac{T-N-1}{T-N-3}$
- Inversînd forma Sharpe a lui W, creșterea așteptată sub H_0 a pătratului raportului Sharpe este

$$\mathbb{E}\big[\widehat{SR}^2(f, \mathrm{R}) - \widehat{SR}^2(f)\big] \approx \frac{N\,(1 + \widehat{SR}^2(f))}{T-N-3}$$

- 25 de portofolii, $T = 757$: $25 \times 1{,}018/729 = 0{,}035$ (lunar), față de $0{,}405^2 - 0{,}134^2 = 0{,}146$ observat
- Maximizarea în eșantion pe N active mărește întotdeauna raportul Sharpe: testul verifică dacă cîștigul depășește acest nivel al zgomotului
- 9 ETF-uri sectoriale, $T = 331$: cîștig observat $0{,}191^2 - 0{,}146^2 = 0{,}015$, sub cel așteptat, $9 \times 1{,}021/319 = 0{,}029$

Înapoi

Anexă: teste pentru multe active

- $\hat{\mathbf{\Sigma}} = \hat{\mathbf{E}}^\top \hat{\mathbf{E}}/T$ are rangul cel mult $T - 2$ (doi parametri în fiecare regresie); $\hat{\mathbf{E}}$: matricea $T \times N$ a reziduurilor
  - Exemplu: 100 de portofolii mărime $\times$ B/M pe 8 ani de date lunare ($T = 96$): $\hat{\mathbf{\Sigma}}$ este singulară, GRS nu există
  - Cu mult înainte de acest punct, inversa este estimată imprecis și puterea scade
- Teste pentru multe active care evită $\hat{\mathbf{\Sigma}}^{-1}$: sume standardizate ale pătratelor statisticilor t, Pesaran & Yamagata (2024)
- Creșterea puterii prin selecția valorilor alfa mari: Fan, Liao & Yao (2015)

Înapoi

Anexă: erori standard robuste la specificarea greșită

- Erorile Fama–MacBeth și Shanken presupun un model **corect**: toate erorile de evaluare $e = \mu - X\gamma$ sînt zero ($X = [1, B]$)
- Aici GRS respinge modelul, deci γ este o valoare pseudo-adevărată; zgomotul din $\hat{B}$ se înmulțește cu e și adaugă un termen de varianță (Kan, Robotti & Shanken (2013))
- Scriem ambele etape ca un singur sistem GMM exact identificat: momentele $(R_t - a - Bf_t) \otimes (1, f_t)$ și $X^\top(R_t - X\gamma)$; varianța sandwich cu jacobianul complet este cea robustă
  - Cu $e = 0$ în jacobian se obține versiunea pentru un model corect specificat, robustă la heteroscedasticitate, a lui Jagannathan & Wang (1998)
- FF5 pe cele 25 de portofolii (RMW: slide-ul cu exemplul numeric): eroarea standard pentru CMA 2,2% → 2,7%, termenul liber 3,3% → 3,8%; pentru HML schimbarea este sub 0,05 puncte procentuale
- Curs avansat: Generalized Method of Moments

Înapoi

Anexă: distanța Hansen–Jagannathan și selecția bayesiană

- **Distanța Hansen–Jagannathan** (Hansen & Jagannathan (1997)): distanța în sensul celor mai mici pătrate dintre SDF-ul modelului și mulțimea SDF-urilor valide

$$\delta^2 = \min_{\mathrm{b}} \; \mathrm{e}(\mathrm{b})^\top \, \mathbb{E}[\mathrm{R}^e \mathrm{R}^{e\top}]^{-1} \, \mathrm{e}(\mathrm{b}), \qquad \mathrm{e}(\mathrm{b}) = \mathbb{E}[m_t(\mathrm{b}) \, \mathrm{R}_t^e]$$

  - Randamente în exces R_t^e cu normalizarea $\mathbb{E}[m] = 1$; pentru randamente brute R_t: $\mathrm{e} = \mathbb{E}[m\mathrm{R}] - 1$, iar SDF-ul are nevoie de o scală liberă ($\mathbb{E}[m] = 1/(1 + R_f)$)
  - Aceeași matrice de ponderare pentru orice model, deci distanțele sînt comparabile; statistica de test are o limită χ^2 ponderată
- Selecție la scara factor zoo: medierea bayesiană a circa 2×10^{15} de modele factoriale, robustă la factori slabi (Bryzgalova, Huang & Julliard (2023))
- Shrinkage pentru SDF pe factori construiți din caracteristici: cîteva componente principale ale randamentelor anomaliilor captează SDF-ul (Kozak, Nagel & Santosh (2020))
- Lecția comună: comparați modelele printr-o singură măsură, independentă de model, cu incertitudinea ei de eșantionare

Înapoi

Anexă: factor zoo redus prin LASSO cu dublă selecție

- Feng, Giglio & Xiu (2020): aduce un factor nou informație suplimentară față de factorii deja cunoscuți?
- **LASSO cu dublă selecție** (Least Absolute Shrinkage and Selection Operator)
  - Pasul 1: un LASSO al randamentelor medii ale activelor de test pe covariațele lor cu sute de factori alege variabilele de control care evaluează secțiunea transversală
  - Pasul 2: un al doilea LASSO alege factorii ale căror covariațe le explică pe cele ale factorului nou, ca variabilele de control omise să nu deplaseze coeficientul lui din SDF
  - Pasul 3: coeficientul din SDF al factorului nou se estimează cu reuniunea celor două mulțimi de variabile de control și se testează
- Rezultat: majoritatea factorilor noi sînt redundanți; doar cîțiva adaugă informație de evaluare
- Studiul de caz ajunge la o concluzie compatibilă: mulți factori sînt redundanți, iar informația se concentrează în cîteva teme

Înapoi

Anexă: mai mult despre numărul de factori

- Onatski (2010): separă valorile proprii ale factorilor de marginea distribuției valorilor proprii ale zgomotului
- Regula Kaiser ($\ell_k > 1$) pe o matrice de corelație: pentru N active și zgomot pur, valorile proprii sînt dispersate în jurul lui 1 pe o lățime care depinde de N/T, deci regula nu are justificare asimptotică
- Raportați intervalul estimațiilor și sensibilitatea la $k_{\max}$, nu un singur număr (Seminarul 3, problema B3)

înapoi

Anexă: PCA cu primă de risc și estimarea primelor în trei etape

- **RP-PCA** (Risk-Premium PCA, PCA cu primă de risc, Lettau & Pelger (2020)): componentele principale ale matricei $\frac{1}{T}\mathbf{X}^\top\mathbf{X} + \gamma\,\bar{\mathbf{x}}\bar{\mathbf{x}}^\top$
  - $\mathbf{X}$: matricea $T \times N$ a randamentelor în exces, $\bar{\mathbf{x}}$: mediile lor, γ: ponderea randamentelor medii
  - $\gamma = -1$ dă PCA pe covarianță; $\gamma > -1$ favorizează și factorii care explică randamentele medii
  - În datele autorilor, metoda găsește factori cu rapoarte Sharpe mai mari și erori de evaluare mai mici decît PCA
- **Estimatorul în trei etape** (Giglio & Xiu (2021)): prima unui factor observat g_t cînd modelul omite factori
  - (1) PCA pe randamentele activelor de test; (2) regresia transversală a mediilor pe valorile beta latente; (3) regresia lui g_t pe factorii latenți și transferul primelor lor la g_t
- Ambele păstrează baza statistică a PCA, dar urmăresc explicarea randamentelor medii, nu doar a variației; IPCA adaugă caracteristicile

Înapoi

Anexă: IPCA și factorii criptoactivelor

- IPCA (Kelly, Pruitt & Su (2019)): caracteristicile prezic randamentele pentru că măsoară expunerea la risc
- IPCA leagă PCA (statistica) de sortările după caracteristici (Fama–French): beta variabil în timp, puțini factori
- Criptoactive: factorii piață, mărime și momentum evaluează secțiunea transversală a criptomonedelor (Liu, Tsyvinski & Wu (2022)); reducerea dimensionalității pe caracteristicile randamentelor criptoactivelor și activelor tradiționale: Pele et al. (2023), Jheng et al. (2026)
- Curs avansat: Multivariate Statistical Analysis

Înapoi

Anexă: studiu de caz, date și construcție (1/2)

- **Date** (Secțiunea II): 153 de factori în 93 de țări
  - 138 din lista alcătuită de Hou, Xue & Zhang (2020) și 15 din alte studii
  - randamente americane din 1926, majoritatea piețelor dezvoltate din 1986
  - toate în dolari americani, în exces față de rata titlurilor de stat americane pe termen scurt
- **Construcția**, în fiecare țară și lună
  - terțile după caracteristică, cu praguri calculate fără firmele cu microcapitalizare
  - ponderi după capitalizarea plafonată la percentila 80 a NYSE
  - perioada de deținere: o lună
  - cel puțin 5 acțiuni pe fiecare parte și 60 de observații lunare
- **Teme**: 13 grupe de factori americani (Secțiunea II.B)
  - grupare ierarhică, distanța 1− corelația reziduurilor CAPM, criteriul Ward

Înapoi

Anexă: studiu de caz, date și construcție (2/2)

- **Modelul** (Secțiunea I): $f_{i,t} = \alpha_i + \beta_i r_t^m + \varepsilon_{i,t}$
  - valorile alfa $\alpha_i = c_j + s_n + w_i$ (tema j, semnalul n, factorul i; ec. 21), media a priori 0
  - varianța a priori $\mathbf{\Omega} = \mathrm{M}\mathrm{M}^\top \tau_c^2 + \mathrm{Z}\mathrm{Z}^\top \tau_s^2 + \mathrm{I}\tau_w^2$ (ec. 23); media a posteriori $(\mathbf{\Omega}^{-1} + T\mathbf{\Sigma}^{-1})^{-1} T\mathbf{\Sigma}^{-1}\hat{\boldsymbol{\alpha}}$ (Propoziția 4)
  - M, Z: matrice 0/1 care leagă fiecare factor de tema și semnalul lui; $\tau_c^2, \tau_s^2, \tau_w^2$: variațele celor trei componente ale lui alfa; $\mathbf{\Sigma}$: covarianța reziduurilor
  - estimare Bayes empirică: τ_c, τ_s, τ_w prin verosimilitate maximă pentru $\hat{\boldsymbol{\alpha}} \sim N(0, \mathbf{\Omega} + \hat{\mathbf{\Sigma}}/T)$ (Secțiunea I.C.2)
- **Rata de replicare**
  - ponderea factorilor semnificativi în studiile inițiale al căror alfa este semnificativ în datele noi

Înapoi

Anexă: studiu de caz, rezultatele complete

- Randamente brute, doar cei 119 factori semnificativi în studiile inițiale: 61,3% (Figura 1)
- OLS: 98 din 119 factori americani; Benjamini–Yekutieli impune $|t| > 2{,}7$ (Figura 4)
- FDR bayesian 0,1%, interval de 95% [0; 1%]; ponderea așteptată a factorilor adevărați 94% (Secțiunea III.C)
- Firme cu capitalizare foarte mare și mare: 77,3% și 79,8% (Figura 5); 11 din 13 teme cel puțin 50%, toate în afară de îndatorare redusă și mărime: rezultatul nu este un artefact al microcapitalizărilor
- Raportul Sharpe (lunar) al portofoliului tangent, SUA 1972–2020: piața 0,13, toți factorii 0,80 (Figura 14)

Înapoi

Anexă: studiu de caz, replicarea din curs în detaliu

- Benjamini–Yekutieli este cel mai strict, ca în ratele americane din articol (Figura 1)
- Emisiunile nete de acțiuni se apropie de tema lor: 0,44% $\rightarrow$ 0,27% pe lună
- Abaterea standard a posteriori 0,07%–0,10%, față de eroarea standard OLS 0,11%: fiecare temă cumulează informația factorilor ei
- **Dispersia a priori**: $\hat{\tau}_c = 0{,}28\%$, $\hat{\tau}_w = 0{,}04\%$ pe lună
  - față de 0,35% și 0,21% în Tabelul I; cu 15 semnale rămîne puțină dispersie specifică factorilor
- **Teme**: cele 15 semnale se încadrează în 8 dintre cele 13 teme ale articolului
  - 5 în valoare, 3 în risc scăzut, 2 în investiții

Înapoi

Anexă: studiu de caz, limite precizate de autori și extinderi

- **Limite precizate de autori**
  - CAPM este singurul reper: factorii de îndatorare redusă nu trec testul alfa CAPM, dar contează împreună cu celelalte teme (Secțiunea III.A)
  - Caracteristicile sînt construite unitar, uneori altfel decît în articolul original (Secțiunea II.C)
  - Factorii nepublicați deplasează distribuția a priori: în scenariile analizate de Harvey, Liu & Zhu (2016), rata pentru SUA scade la 81,5% și 79,8% (Figura 10)
- **Completarea replicării de curs** (Seminarul 3, C3)
  - justificați semnul fiecărui factor pe baza studiului inițial
  - comparați dendrograma cu temele articolului
  - adăugați FDR bayesian și panta după eșantion (Figura 8)
- Datele și codul articolului: jkpfactors.com, github.com/bkelly-lab/ReplicationCrisis

Înapoi

Anexă: bucla descoperirii, prompturi reutilizabile (1/2)

- **Literatură**
  - `Rezumă dovezile din 2016 încoace despre scăderea după publicare și replicarea randamentelor anomaliilor. Pentru fiecare lucrare: DOI, eșantion, numărul de factori, estimația principală, identificarea scăderii. Marchează intrările nesigure.`
  - Verificați fiecare DOI în Crossref; verificați fiecare cifră principală în rezumat
- **Ipoteză**
  - `Compară data mining-ul, arbitrajul bazat pe informația publicată și riscul variabil în timp ca explicații ale scăderii. Pentru fiecare: tiparul prezis între perioadele din eșantion, după eșantion și după publicare, și între acțiunile cu limite mari și cele cu limite mici ale arbitrajului.`
- **Date și cod**
  - `Încarcă factorul lunar de momentum din Kenneth French Data Library; din 1965, regresează MOM pe o variabilă dummy după eșantion (1990-01 pînă la 1993-03) și una după publicare (din 1993-04), cu erori Newey-West.`
  - Replicați întîi o cifră cunoscută: momentum $t = 5{,}53$ înainte de 2000 și 0,75 după (graficul pe subperioade)

Înapoi

Anexă: bucla descoperirii, prompturi reutilizabile (2/2)

- **Robustețe**
  - `Scrie un plan de robustețe preînregistrat: cîte o dată de publicare pentru fiecare factor, corecția Holm între factori, excluderea crahului de momentum din 2009, data documentului de lucru în locul datei din revistă și perioada 1927-1962 ca placebo pentru Mkt-RF, SMB, HML și MOM (RMW și CMA încep în iulie 1963).`
- **Critică**
  - `Evaluează critic: un factor, o dată de publicare, t = -1,45. Care este puterea de a detecta o scădere de 58%? De ce o schimbă combinarea mai multor anomalii?`
- **Raport**
  - Media din eșantion, ambele variabile dummy cu erori Newey–West, placebo-ul, versiunea datelor (data descărcării)
  - Factori combinați: erori robuste la corelația dintre factori în aceeași lună și la autocorelație
  - Prompturile care au influențat o decizie intră în `AI_USE.md`
- Asistentul enumeră specificațiile; omul fixează dinainte care dintre ele contează

Înapoi

Anexă: verificările cercetătorului

- **Data greșită a evenimentului**: data încheierii eșantionului, data difuzării documentului de lucru și data publicării în revistă sînt diferite
  - test: citiți-le din lucrarea însăși; Jegadeesh & Titman (1993): eșantionul se termină în 1989, articolul apare în martie 1993
- **Alegerea factorului după ce a scăzut**: fixați dinainte mulțimea factorilor; Holm sau BH pe toți
- **Randamente autocorelate, cu crahuri**: erori Newey–West; reestimați fără 2009
- **Versiunile datelor**: biblioteca de factori este revizuită retroactiv
  - test: notați data descărcării; reproduceți statisticile t pe subperioade din capitol
- **Literatură citată greșit**: o greșeală frecventă dă 58% drept scăderea în afara eșantionului; este cea de după publicare (26% în afara eșantionului)
- **Putere mică**: cu un singur factor, H_0 se respinge rar; raportați intervalul de încredere al scăderii, nu doar semnul ei

Înapoi

Anexă: aprofundare și cod

Cursuri avansate pe quantinar.com

- Generalized Method of Moments
- Multivariate Statistical Analysis

Cod și date

- Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_03
- Datele factorilor: Kenneth French Data Library

înapoi

Bibliografie (1/6)

- Ahn, S.C., Horenstein, A.R. (2013). Eigenvalue ratio test for the number of factors. *Econometrica*, 81(3), 1203–1227.
- Anatolyev, S., Mikusheva, A. (2022). Factor models with many assets: strong factors, weak factors, and the two-pass procedure. *Journal of Econometrics*, 229(1), 103–126.
- Ang, A., Liu, J., Schwarz, K. (2020). Using stocks or portfolios in tests of factor models. *Journal of Financial and Quantitative Analysis*, 55(3), 709–750.
- Bai, J., Ng, S. (2002). Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 191–221.
- Barillas, F., Shanken, J. (2018). Comparing asset pricing models. *Journal of Finance*, 73(2), 715–754.
- Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- Benjamini, Y., Yekutieli, D. (2001). The control of the false discovery rate in multiple testing under dependency. *Annals of Statistics*, 29(4), 1165–1188.
- Black, F. (1972). Capital market equilibrium with restricted borrowing. *Journal of Business*, 45(3), 444–455.
- Blume, M.E. (1971). On the assessment of risk. *Journal of Finance*, 26(1), 1–10.
- Bryzgalova, S., Huang, J., Julliard, C. (2023). Bayesian solutions for the factor zoo: we just ran two quadrillion models. *Journal of Finance*, 78(1), 487–557.

Bibliografie (2/6)

- Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). The Econometrics of Financial Markets. Princeton University Press.
- Carhart, M.M. (1997). On persistence in mutual fund performance. *Journal of Finance*, 52(1), 57–82.
- Chen, A.Y., Zimmermann, T. (2022). Open source cross-sectional asset pricing. *Critical Finance Review*, 11(2), 207–264.
- Cochrane, J.H. (2011). Presidential address: discount rates. *Journal of Finance*, 66(4), 1047–1108.
- Daniel, K., Moskowitz, T.J. (2016). Momentum crashes. *Journal of Financial Economics*, 122(2), 221–247.
- Fama, E.F., French, K.R. (1992). The cross-section of expected stock returns. *Journal of Finance*, 47(2), 427–465.
- Fama, E.F., French, K.R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3–56.
- Fama, E.F., French, K.R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- Fama, E.F., MacBeth, J.D. (1973). Risk, return, and equilibrium: empirical tests. *Journal of Political Economy*, 81(3), 607–636.
- Fan, J., Liao, Y., Yao, J. (2015). Power enhancement in high-dimensional cross-sectional tests. *Econometrica*, 83(4), 1497–1541.

Bibliografie (3/6)

- Feng, G., Giglio, S., Xiu, D. (2020). Taming the factor zoo: a test of new factors. *Journal of Finance*, 75(3), 1327–1370.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, ed. a 5-a. Springer.
- Frazzini, A., Pedersen, L.H. (2014). Betting against beta. *Journal of Financial Economics*, 111(1), 1–25.
- Gibbons, M.R., Ross, S.A., Shanken, J. (1989). A test of the efficiency of a given portfolio. *Econometrica*, 57(5), 1121–1152.
- Giglio, S., Xiu, D. (2021). Asset pricing with omitted factors. *Journal of Political Economy*, 129(7), 1947–1990.
- Hansen, L.P. (1982). Large sample properties of generalized method of moments estimators. *Econometrica*, 50(4), 1029–1054.
- Hansen, L.P., Jagannathan, R. (1997). Assessing specification errors in stochastic discount factor models. *Journal of Finance*, 52(2), 557–590.
- Härdle, W.K., Simar, L. (2019). Applied Multivariate Statistical Analysis, ed. a 5-a. Springer.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). . . . and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.

Bibliografie (4/6)

- Hou, K., Xue, C., Zhang, L. (2015). Digesting anomalies: an investment approach. *Review of Financial Studies*, 28(3), 650–705.
- Hou, K., Xue, C., Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133.
- Jagannathan, R., Wang, Z. (1998). An asymptotic theory for estimating beta-pricing models using cross-sectional regression. *Journal of Finance*, 53(4), 1285–1309.
- Jegadeesh, N., Titman, S. (1993). Returns to buying winners and selling losers: implications for stock market efficiency. *Journal of Finance*, 48(1), 65–91.
- Jensen, M.C. (1968). The performance of mutual funds in the period 1945–1964. *Journal of Finance*, 23(2), 389–416.
- Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance?. *Journal of Finance*, 78(5), 2465–2518.
- Jheng, S.-L., Găman, Ș., Conda, A., Pele, D.T., Härdle, W.K., Teng, H.-W., Osterrieder, J. (2026). Crypto currency returns. Document de lucru SSRN.
- Kaiser, H.F. (1960). The application of electronic computers to factor analysis. *Educational and Psychological Measurement*, 20(1), 141–151.
- Kan, R., Robotti, C., Shanken, J. (2013). Pricing model performance and the two-pass cross-sectional regression methodology. *Journal of Finance*, 68(6), 2617–2649.
- Kan, R., Zhang, C. (1999). Two-pass tests of asset pricing models with useless factors. *Journal of Finance*, 54(1), 203–235.
- Kelly, B.T., Pruitt, S., Su, Y. (2019). Characteristics are covariances: a unified model of risk and return. *Journal of Financial Economics*, 134(3), 501–524.

Bibliografie (5/6)

- Kleibergen, F. (2009). Tests of risk premia in linear factor models. *Journal of Econometrics*, 149(2), 149–173.
- Kozak, S., Nagel, S., Santosh, S. (2020). Shrinking the cross-section. *Journal of Financial Economics*, 135(2), 271–292.
- Lettau, M., Pelger, M. (2020). Factors that fit the time series and cross-section of stock returns. *Review of Financial Studies*, 33(5), 2274–2325.
- Lewellen, J., Nagel, S., Shanken, J. (2010). A skeptical appraisal of asset pricing tests. *Journal of Financial Economics*, 96(2), 175–194.
- Lintner, J. (1965). The valuation of risk assets and the selection of risky investments in stock portfolios and capital budgets. *Review of Economics and Statistics*, 47(1), 13–37.
- Liu, Y., Tsyvinski, A., Wu, X. (2022). Common risk factors in cryptocurrency. *Journal of Finance*, 77(2), 1133–1177.
- Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- McLean, R.D., Pontiff, J. (2016). Does academic research destroy stock return predictability?. *Journal of Finance*, 71(1), 5–32.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Newey, W.K., West, K.D. (1994). Automatic lag selection in covariance matrix estimation. *Review of Economic Studies*, 61(4), 631–653.
- Onatski, A. (2010). Determining the number of factors from empirical distribution of eigenvalues. *Review of Economics and Statistics*, 92(4), 1004–1016.

Bibliografie (6/6)

- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *The European Journal of Finance*, 29(10), 1064–1105.
- Pesaran, M.H., Yamagata, T. (2024). Testing for alpha in linear factor pricing models with a large number of securities. *Journal of Financial Econometrics*, 22(2), 407–460.
- Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- Roll, R. (1977). A critique of the asset pricing theory's tests. Part I. *Journal of Financial Economics*, 4(2), 129–176.
- Ross, S.A. (1976). The arbitrage theory of capital asset pricing. *Journal of Economic Theory*, 13(3), 341–360.
- Shanken, J. (1992). On the estimation of beta-pricing models. *Review of Financial Studies*, 5(1), 1–33.
- Sharpe, W.F. (1964). Capital asset prices: a theory of market equilibrium under conditions of risk. *Journal of Finance*, 19(3), 425–442.
- Vasicek, O.A. (1973). A note on using cross-sectional information in Bayesian estimation of security betas. *Journal of Finance*, 28(5), 1233–1239.
- White, H. (1980). A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4), 817–838.
- Date: Kenneth R. French Data Library, mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html.