



Modelarea piețelor financiare

Capitolul 3: Modele factoriale și evaluarea activelor



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ APT: Arbitrage Pricing Theory (teoria evaluării prin arbitraj)
- ▣ BAB: Betting Against Beta (strategia „pariu împotriva lui beta”)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- ▣ BVB: Bursa de Valori București
- ▣ CAGR: Compound Annual Growth Rate (rata anuală compusă de creștere)
- ▣ CAPM: Capital Asset Pricing Model (modelul de evaluare a activelor financiare)
- ▣ CMA: Conservative Minus Aggressive (investment factor) (factorul investiții: firme conservatoare minus agresive)
- ▣ CML: Capital Market Line (dreapta pieței de capital)
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ FDR: False Discovery Rate (rata descoperirilor false)
- ▣ FF3: Fama–French three-factor model (modelul Fama–French cu trei factori)
- ▣ FF5: Fama–French five-factor model (modelul Fama–French cu cinci factori)
- ▣ FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- ▣ GLS: Generalised Least Squares (metoda celor mai mici pătrate generalizate)
- ▣ GMM: Generalized Method of Moments (metoda generalizată a momentelor)
- ▣ GRS: Gibbons–Ross–Shanken (test) (testul Gibbons–Ross–Shanken)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HML: High Minus Low (value factor) (factorul valoare: B/M mare minus mic)
- ▣ IPCA: Instrumented Principal Component Analysis (analiza componentelor principale instrumentată)
- ▣ LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- ▣ MOM: MOMentum factor (factorul momentum)
- ▣ NYSE: New York Stock Exchange (Bursa din New York)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ OMV: Österreichische Mineralölverwaltung (Administrația austriacă a uleiurilor minerale (grupul OMV))

Acronime folosite în acest material (2/2)

- PC1: first Principal Component (prima componentă principală)
- PC2: second Principal Component (a doua componentă principală)
- PC3: third Principal Component (a treia componentă principală)
- PCA: Principal Component Analysis (analiza componentelor principale)
- PRDS: Positive Regression Dependence on a Subset (of p-values)
(dependența pozitivă de regresie pe o submulțime (a valorilor p))
- RF: Risk-Free rate (rata fără risc)
- RMSE: Root Mean Squared Error (rădăcina erorii pătratice medii)
- RMW: Robust Minus Weak (profitability factor) (factorul
profitabilitate: firme robuste minus slabe)
- ROE: Return On Equity (rentabilitatea capitalului propriu)
- RP-PCA: Risk-Premium Principal Component Analysis (analiza
componentelor principale cu prima de risc)
- SDF: Stochastic Discount Factor (factorul stochastic de actualizare)
- SMB: Small Minus Big (size factor) (factorul mărime: firme mici minus
mari)
- SML: Security Market Line (dreapta pieței titlurilor)
- SUA: Statele Unite ale Americii
- UMD: Up Minus Down (momentum factor) (factorul momentum:
câștigători minus perdanți)

Traseul capitolului și ce veți ști să faceți

Patru întrebări

- Ce explică randamentele așteptate? CAPM și modelele multifactoriale
- Cum se estimează expunerile? Beta, incertitudinea lui și shrinkage
- Cum se testează restricțiile de evaluare? GRS, Fama–MacBeth, compararea modelelor
- Rezistă rezultatele? Testare multiplă, factori latenți, replicare

După acest capitol puteți

- estima un beta cu erori HAC și aplica shrinkage
- testa CAPM în comun și estima prime de risc cu erori robuste
- judeca un factor nou față de pragurile testării multiple și de dovezile de replicare

Partea I: Secțiunile 1–5; Partea a II-a: Secțiunile 6–13; detaliile tehnice în

► Anexă

Ce este un model factorial?

- Un **model factorial** explică randamentul activului i prin câteva variabile comune $f_{1,t}, \dots, f_{K,t}$, numite **factori**

$$R_{i,t} - R_{f,t} = \alpha_i + \beta_{i,1}f_{1,t} + \dots + \beta_{i,K}f_{K,t} + \varepsilon_{i,t}$$

- $\beta_{i,k}$: **încărcarea factorială** (expunerea) activului i la factorul k ; $\varepsilon_{i,t}$: șoc specific activului (idiosincratic)
- Două utilizări în acest capitol
 - Explicarea unui activ: ETF-ul de tehnologie XLK se mișcă de 1,28 ori cât piața americană (Secțiunea 3)
 - Evaluarea unui fond: rămîne α_i pozitiv după ce ținem cont de expunerile lui (Secțiunile 4 și 10)?
- Și: costul capitalului, managementul riscului (N active necesită $N(N+1)/2$ covarianțe, K factori mult mai puține), construcția portofoliilor (Campbell, Lo & MacKinlay (1997), cap. 5–6)
- Mesajul-cheie: randamentele așteptate ar trebui explicate prin **expuneri la riscuri remunerate**, nu prin numele activului

Date și convenții

Serie	Conținut	Perioadă
Factori Fama–French	piață, mărime, valoare, profitabilitate, investiții	1963–2026
Momentum	câștigători minus perdanți	1963–2026
25 portofolii mărime $\times$ B/M	acțiuni SUA, 2 sortări	1963–2026
ETF-uri sectoriale	sectoare S&P 500: 9 din 1999, 11 din 2018	1999–2026
ETF-uri factoriale	momentum, valoare, calitate, vol. minimă, mărime	2013–2026
Blue chips BVB, BET	11 acțiuni și indicele lor	2015–2026

- Factori și portofolii: [Kenneth French Data Library](#), în procente (se împart la 100); ETF-uri și acțiuni: prețuri zilnice de închidere ajustate (BET: valori de închidere), până la 18 sept. 2026
- **Randament în exces** $R_{i,t}^e = R_{i,t} - R_{f,t}$; $R_{f,t}$: rata titlurilor de stat americane la o lună (RF în datele French)
- **B/M**: valoarea contabilă a capitalului propriu împărțită la valoarea sa de piață; **BET**: indicele de referință al BVB
- Randamente simple pentru regresii pe factorii French; randamente logaritmice pentru analizele pe ferestre mobile, BVB și PCA
- BVB: $R_{f,t}$ zilnică tratată ca fiind constantă; se anulează în covarianțe, deci beta nu se schimbă
- ETF-uri și acțiuni: prețuri ajustate pentru dividende și split-uri; indici: valori de închidere

Medie–varianță și portofoliul tangent

- **Markowitz (1952)**: cu ponderile w , randamentele în exces așteptate μ și matricea de covarianță Σ , portofoliile de pe frontieră se obțin rezolvînd


$$\min_w w^\top \Sigma w \quad \text{s.t.} \quad w^\top \mu = \mu^*, \quad w^\top \mathbf{1} = 1$$

- **Raportul Sharpe** $SR_p = \mathbb{E}[R_p - R_f] / \sigma_p$; cu un activ fără risc, cel mai bun portofoliu riscant este **portofoliul tangent**

$$w_{\text{tan}} = \Sigma^{-1} \mu / \mathbf{1}^\top \Sigma^{-1} \mu$$

- **CML**: combinații între R_f și portofoliul tangent, $\mu_p = SR_{\text{tan}} \sigma_p$; ponderile negative sînt **poziții short**
- De la portofoliul tangent la ecuația de evaluare prin beta: Seminarul 3, problema A1; eroarea de estimare și shrinkage: [Capitolul 4](#)

Frontiera eficientă a sectoarelor din SUA



- Randamente lunare în exces ale a 9 ETF-uri sectoriale, ianuarie 1999 – iulie 2026 ($T = 331$ luni)
- Portofoliul tangent: medie 8,55%, volatilitate 12,96%, raport Sharpe 0,66
- SPY (ETF-ul pe S&P 500, aproximarea pieței): medie 7,44%, volatilitate 15,08%, raport Sharpe 0,49: aici piața **nu** se află pe frontieră, cum ar cere CAPM
- Ponderile portofoliului tangent: $-0,37$ în financiar, $-0,21$ în materiale, $+0,37$ în sănătate
- Frontiera este **în eșantion**; mediile sînt estimate cu multă incertitudine ([Capitolul 4](#))

 MFM_ch3_frontier

CAPM: Sharpe, Lintner, Black



William F. Sharpe, Premiul Nobel
pentru Economie 1990

Foto: Larry D. Moore (2007); CC BY 4.0;
[Wikimedia Commons](#)

- **CAPM**: Capital Asset Pricing Model (modelul de evaluare a activelor financiare), Sharpe (1964) și Lintner (1965)
- Dacă fiecare investitor deține un portofoliu eficient medie–varianță, toți dețin același portofoliu tangent, care trebuie atunci să fie **portofoliul pieței**
- Randamentul în exces așteptat este proporțional cu **beta**

$$\mathbb{E}[R_i] - R_f = \beta_i (\mathbb{E}[R_m] - R_f), \quad \beta_i = \frac{\text{Cov}(R_i, R_m)}{\text{Var}(R_m)}$$

- $\mathbb{E}[R_m] - R_f$: **prima de risc a pieței**; β_i : sensibilitatea activului i la piață
- **Black (1972)**: o versiune fără activ fără risc, CAPM cu beta zero (Secțiunea 4)
- Sharpe a împărțit Premiul Nobel din 1990 cu Markowitz și Miller

Ce implică CAPM


- Ipoteze principale
 - ▶ Investitori medie–varianță cu aceleași așteptări, o singură perioadă
 - ▶ Împrumut și plasament nelimitat la R_f ; fără taxe sau costuri de tranzacționare
- Doar beta este remunerat: nicio altă caracteristică nu ar trebui să prezică randamentele; riscul idiosincratic nu aduce nimic
- **SML** (Security Market Line, dreapta pieței titlurilor): orice activ se află pe dreapta (beta, medie) cu panta egală cu prima; CML conține doar portofoliile eficiente. SML este afirmația testabilă (Secțiunea 4)
- Costul capitalului prin CAPM cere un beta estimat și o primă estimată: eroarea primei domină
- Care portofoliu este „piața”? Răspunsul decide ce poate stabili un test al CAPM (critica lui Roll, Secțiunea 4)

Modelul de piață, erorile HAC și alegerile de estimare

- ▣ Modelul de piață $R_{i,t}^e = \alpha_i + \beta_i R_{m,t}^e + \varepsilon_{i,t}$; **OLS** (Ordinary Least Squares, metoda celor mai mici pătrate):

$$\hat{\beta}_i = \widehat{\text{Cov}}(R_i^e, R_m^e) / \widehat{\text{Var}}(R_m^e)$$
- ▣ Descompunerea $\sigma_i^2 = \beta_i^2 \sigma_m^2 + \sigma_{\varepsilon,i}^2$: risc sistematic (remunerat în CAPM) plus risc idiosincratic (diversificabil); R^2 este ponderea sistematică
- ▣ Grupările de volatilitate ([Capitolul 1](#)) fac reziduurile heteroscedastice: folosiți erori **HAC**, [Newey & West \(1987\)](#), cu ponderi Bartlett și $L = \lfloor 4(T/100)^{2/9} \rfloor$ laguri ($T = 331$: $L = 5$; $T = 757$: $L = 6$); estimațiile punctuale sînt cele OLS
- ▣ Alegeri de raportat pentru orice beta
 - ▶ Frecvența și fereastra: 3–5 ani de date lunare sau 1–2 ani de date zilnice; datele zilnice suferă de tranzacționare asincronă
 - ▶ Aproximarea pieței: SPY (S&P 500) pentru active din SUA, BET pentru acțiuni românești
 - ▶ Curățarea datelor: un eveniment de capital neajustat creează un randament fals (DIGI, mai 2017: un randament logaritmico zilnic de $-6,6$)


Exemplu rezolvat: beta ETF-ului de tehnologie



	Estimație	Clasică	White	Newey–West
α (anual)	0,33%	2,27%	2,32%	2,45%
β	1,277	0,041	0,054	0,082

- XLK pe Mkt-RF, lunar 1999–2026, $T = 331$, $R^2 = 0,742$
- Eroarea standard robustă a lui β : dublul celei clasice; heteroscedasticitatea explică o parte (White), autocorelarea lui $f_t \varepsilon_t$ restul
- $t(\alpha) = 0,13$; interval bootstrap $[-5,5\%; 4,9\%]$

Beta nu este constant



- Beta OLS din ultimele 252 de randamente logaritmice zilnice, recalculat zilnic
- Financiar (XLF): de la 0,60 la 2,17; maximul urmează crizei bancare din 2008–2009
- Tehnologie (XLK): de la 0,86 la 1,90; ridicat în anii dot-com, 1,75 la final
- Energie (XLE): de la –0,31 la 1,49; negativ la final, când petrolul a evoluat contrar pieței
- Utilități (XLU): de la 0,06 la 1,00, sectorul defensiv clasic
- Un beta pe tot eșantionul ascunde aceste regimuri; modele condiționale: [Capitolele 5–6](#)


Shrinkage pentru beta: Blume și Vasicek

- ▣ **Regresia spre medie:** valorile beta extreme sînt parțial zgomot și se apropie ulterior de 1
- ▣ **Blume (1971):** regresia valorilor beta ulterioare pe cele anterioare; regula practicienilor este $\beta^{\text{Blume}} = 0,33 + 0,67 \hat{\beta}$
- ▣ **Vasicek (1973):** medie bayesiană între estimăție și media transversală a priori $\bar{\beta}$

$$\beta_i^V = w_i \hat{\beta}_i + (1 - w_i) \bar{\beta}, \quad w_i = \frac{\sigma_{\beta}^2}{\sigma_{\beta}^2 + \text{se}(\hat{\beta}_i)^2}$$

- ▣ σ_{β}^2 este varianța valorilor beta **adevărate**: $\text{Var}_{cs}(\hat{\beta}) = \sigma_{\beta}^2 + \overline{\text{se}^2}$, deci estimăția Bayes empirică este $\sigma_{\beta}^2 = \text{Var}_{cs}(\hat{\beta}) - \overline{\text{se}^2}$ (derivarea distribuției a posteriori: Seminarul 3, problema A3)
- ▣ XLK, lunar 1999–2012, 9 sectoare: $\hat{\beta} = 1,415$ (e.s. 0,139), $\bar{\beta} = 0,949$, $\sigma_{\beta}^2 = 0,116 - 0,008 = 0,108$, $w = 0,849$
 ► $\beta^V = 0,849 \times 1,415 + 0,151 \times 0,949 = 1,344$; Blume 1,278; beta estimat pe 2013–2026: 1,172


Revin valorile beta spre unu?



- Valori beta lunare ale celor 9 ETF-uri sectoriale față de SPY: 1999–2012 (orizontal) vs 2013–2026 (vertical)
- Dreapta estimată
 $\hat{\beta}_{\text{ulterior}} = 0,23 + 0,72 \hat{\beta}_{\text{anterior}}$, foarte aproape de regula Blume $0,33 + 0,67 \hat{\beta}$
- RMSE a prognozei valorilor beta ulterioare,
 $\sqrt{\frac{1}{N} \sum_i (\text{prognoza}_i - \hat{\beta}_{i,\text{ulterior}})^2}$: brut 0,135, Blume 0,109, Vasicek 0,114
- Shrinkage-ul reduce eroarea de prognoză cu 15–20%; cu 9 sectoare lecția este calitativă

 MFM_ch3_beta_shrink

Beta CAPM la Bursa de Valori București



- Randamente logaritmice zilnice pe BET, de la 6 ianuarie 2015 sau de la listare (Digi, DIGI, 2017; Hidroelectrica, H2O, 2023); zilele cu $|r_t| > 0,5$ sînt eliminate (una pentru DIGI, două pentru Fondul Proprietatea, FP)
- Băncile sînt cele mai sensibile la piață: Banca Transilvania (TLV) 1,25, BRD 1,13; OMV Petrom 1,06; Transelectrica 0,76, Digi 0,67
- R^2 : 0,59 pentru TLV, doar 0,21 pentru DIGI; ponderile mari în indice cresc mecanic R^2
- Shrinkage-ul Vasicek schimbă puțin: estimațiile zilnice sînt precise (se $\approx 0,04-0,07$); prețurile învechite deplasează beta zilnic al acțiunilor mai puțin lichide (Seminarul 3, problema B4)

 MFM_ch3_bvb_betas



De la o singură valoare alfa la testul GRS

- ▣ **Alfa lui Jensen** (Jensen (1968)) este termenul liber al modelului de piață, α_i ; CAPM implică $\alpha_i = 0$ pentru orice activ
- ▣ Cîte un test t pentru fiecare activ (XLK: $t = 0,13$) crește riscul respingerilor false cînd activele sînt multe (Secțiunea 8): **GRS**, Gibbons, Ross & Shanken (1989), testează simultan $H_0 : \alpha_1 = \dots = \alpha_N = 0$

$$W = \frac{T - N - 1}{N} \frac{\hat{\alpha}^\top \hat{\Sigma}^{-1} \hat{\alpha}}{1 + \hat{\mu}_m^2 / \hat{\sigma}_m^2} \sim F(N, T - N - 1)$$

- ▣ $\hat{\Sigma}$: covarianța reziduurilor estimată prin verosimilitate maximă (împărțire la T); $\hat{\mu}_m / \hat{\sigma}_m$: raportul Sharpe al pieței
- ▣ Exact, condiționat de factori, pentru erori i.i.d. cu distribuția Normală multivariată, independente de factori, cu medie zero și covarianță constantă nesară; F : distribuția Fisher
- ▣ Un W mare: piața este departe de frontiera medie–varianță a activelor testate

Dreapta pieței titlurilor (SML) în date



- Active de test: acțiunile americane sortate în fiecare iunie în 5 chintile de mărime și 5 de B/M, 25 de portofolii ponderate după valoare (Fama & French (1993)), iulie 1963 – iulie 2026, $T = 757$
- Dreapta CAPM are panta 7,2% pe an; dreapta estimată are panta -4,4%: beta mai mare, randament mediu **mai mic**

- Valorile beta acoperă doar 0,86–1,42, randamentele medii în exces 3,9%–13,3%
- Alfa small-value +5,7%, small-growth -6,3% pe an; 10 din 25 de valori alfa au $|t| > 1,96$
- $GRS = 4,20$, p -valoare 8×10^{-11} : CAPM este respins

GRS ca test al raportului Sharpe

- Identitate (Gibbons, Ross & Shanken (1989)): cu $\hat{\Sigma}$ și momentele estimate prin verosimilitate maximă

$$\hat{\alpha}^\top \hat{\Sigma}^{-1} \hat{\alpha} = \widehat{SR}^2(f, R) - \widehat{SR}^2(f)$$

- $\widehat{SR}^2(f, R)$: pătratul raportului Sharpe al portofoliului tangent format din factor și cele N active de test

- Deci GRS măsoară creșterea raportului Sharpe obținută prin adăugarea activelor de test

$$W = \frac{T - N - 1}{N} \cdot \frac{\widehat{SR}^2(f, R) - \widehat{SR}^2(f)}{1 + \widehat{SR}^2(f)}$$

- 25 de portofolii, rapoarte Sharpe lunare: piața 0,134 (0,47 pe an); piața plus portofoliile 0,405 (1,40 pe an)
- $W = 29,24 \times (0,405^2 - 0,134^2) / (1 + 0,134^2) = 4,20$; câștigul așteptat sub H_0 este mult mai mic (▶ Anexă)

Cînd ipotezele GRS nu sînt îndeplinite

- **Cozi groase și grupări de volatilitate** (Capitolul 1): distribuția F nu mai este exactă
 - ▶ Bootstrap pe reziduuri sub H_0 : se reeșantionează rînduri întregi de reziduuri și se reconstruiesc randamentele cu $\alpha = 0$ (Seminarul 3, problema B11); robust la lipsa normalității doar dacă erorile sînt i.i.d. și independente de factori
 - ▶ Test Wald GMM: momentele $\varepsilon_t \otimes (1, f_t)$, $W_{\text{GMM}} = \hat{\alpha}^\top \hat{V}_\alpha^{-1} \hat{\alpha} \rightarrow \chi_N^2$, cu $\hat{V}_\alpha$ estimatorul HAC al lui $\text{Var}(\hat{\alpha})$: robust la heteroscedasticitate și autocorelare
- **Condiția de rang**: $\hat{\Sigma}$ are rangul cel mult $T - 2$, deci GRS nu se poate calcula cînd $N \geq T - 1$, iar puterea lui scade mult înainte de acest punct
- Teste construite pentru multe active: [▶ Anexă](#)

O SML plată: Black și Betting Against Beta



Fischer Black (1938–1995)

Foto: Dalmatine at English Wikipedia

(încărcată 2009); domeniu public;

Wikimedia Commons

- **Black (1972)**: dacă împrumutul este restricționat, investitorii care vor mai mult risc cumpără active cu beta mare în loc să folosească efectul de levier; aceste active devin scumpe și au randamente mai mici
- Predicție: SML este **mai plată** decât dreapta CAPM și pornește de la o rată **beta zero** peste R_f
- **Frazzini & Pedersen (2014)** transformă ideea într-o strategie, **BAB** (Betting Against Beta, pariul împotriva lui beta)

$$r_t^{\text{BAB}} = \frac{R_{L,t} - R_{f,t}}{\beta_L} - \frac{R_{H,t} - R_{f,t}}{\beta_H}$$

- L : portofoliu cu beta mic, cu levier pînă la beta 1; H : portofoliu cu beta mare, redus la beta 1; BAB are beta zero prin construcție și un randament mediu pozitiv în datele lor
- Un spread nescalat beta mic minus beta mare (Seminarul 3, problema C1) nu este neutru față de beta: media lui amestecă prima cu o expunere negativă la piață

Ce poate stabili un test al CAPM

- **Roll (1977)**: CAPM se referă la portofoliul **adevărat** al pieței, care cuprinde întreaga avuție; indicii bursieri omit obligațiunile, imobiliarele, firmele private și capitalul uman
- Orice portofoliu eficient evaluează exact toate activele prin beta: cu R_f pe CML, cu o rată beta zero (**Black (1972)**) pe frontiera activelor riscante (Seminarul 3, problema A1)
 - ▶ Un test CAPM este un test comun al modelului și al eficienței aproximării pieței
- **Activele de test contează**: 9 ETF-uri sectoriale, ianuarie 1999 – iulie 2026 ($T = 331$): $GRS = 0,53$, $p = 0,85$, CAPM nerespins
 - ▶ Pe aceleași 331 de luni, cele 25 de portofolii mărime $\times$ B/M îl resping: $GRS = 2,91$, $p = 9 \times 10^{-6}$
 - ▶ Sectoarele combină firme mici și mari, de valoare și de creștere: nu creează dispersie în caracteristicile care contează
- Nerespingerea este o dovadă slabă; evaluați modelele pe active cu dispersie în randamentele așteptate

Teoria evaluării prin arbitraj

- ▣ **APT**: Arbitrage Pricing Theory (teoria evaluării prin arbitraj), Ross (1976)
- ▣ Randamentele urmează un model cu K factori și riscuri idiosincratice mici

$$R_{i,t} = \mathbb{E}[R_i] + \beta_i^\top f_t + \varepsilon_{i,t}, \quad \mathbb{E}[f_t] = 0$$

- ▣ **Absența arbitrajului** (niciun profit fără risc și fără investiție) implică, aproximativ

$$\mathbb{E}[R_i] - R_f = \beta_i^\top \lambda$$

- ▣ λ : **primele de risc**, randamentul așteptat suplimentar pe unitatea fiecărei expuneri
- ▣ Teoria nu spune **care** sînt factorii: ei trebuie găsiți în date

Construcția factorilor: portofolii long–short

mărime: mediana NYSE; B/M: 30% / 40% / 30%

	Mic (growth)	Neutru	Mare (value)
Mici	S_L	S_N	S_H
Mari	B_L	B_N	B_H

$$\text{SMB} = \frac{1}{3}(S_L + S_N + S_H) - \frac{1}{3}(B_L + B_N + B_H)$$

$$\text{HML} = \frac{1}{2}(S_H + B_H) - \frac{1}{2}(S_L + B_L)$$


- Un **factor construit prin sortare** cumpără acțiunile cu valoare mare a unei caracteristici și le vinde pe cele cu valoare mică
- Investiție netă zero: randamentul este o diferență de randamente, $f_t = R_{\text{mare},t} - R_{\text{mic},t}$
- Sortarea Fama–French 2×3 în fiecare iunie, cu datele contabile din anul anterior, portofolii ponderate după valoare
 - ▶ **SMB** (Small Minus Big): acțiuni mici minus acțiuni mari
 - ▶ **HML** (High Minus Low): B/M mare (valoare) minus B/M mic (creștere)
- Aceeași construcție pe profitabilitate și investiții dă RMW și CMA (slide-ul următor)

Modelele factoriale standard

Model	Factori	Referință	Motivație
CAPM	Mkt-RF	Sharpe (1964)	echilibru
FF3	Mkt-RF, SMB, HML	Fama & French (1993)	efectele de mărime și B/M (Fama & French (1992))
Carhart q	FF3 + MOM piață, mărime, investiții, ROE	Carhart (1997) Hou, Xue & Zhang (2015)	evaluarea fondurilor deciziile de investiții ale firmelor
FF5	Mkt-RF, SMB, HML, RMW, CMA	Fama & French (2015)	modelul actualizării dividendelor

- FF3: $R_{i,t}^e = \alpha_i + b_i \text{MKT}_t + s_i \text{SMB}_t + h_i \text{HML}_t + \varepsilon_{i,t}$; un model bun lasă valori alfa din serii de timp apropiate de zero (GRS nerespins)
- **RMW** (Robust Minus Weak): profitabilitate operațională mare minus mică; **CMA** (Conservative Minus Aggressive): creștere mică minus mare a activelor; **ROE**: Return On Equity (rentabilitatea capitalului propriu)
- **MOM** (UMD, Up Minus Down): randament mare minus mic din luna $t - 12$ până în $t - 2$; câștigătorii trecuți continuă să câștige 3–12 luni (Jegadeesh & Titman (1993))
- FF3 folosește propriul SMB (sortări 2×3 după mărime și B/M); SMB din FF5 face media diferențelor de mărime din trei sortări, deci FF3 nu este inclus în FF5

Şase factori în şaizeci şi trei de ani




- Randamente factoriale lunare compuse de la 1, scară logaritmică: randamente în exces sau long-short, deci fără dobînda pe capital sau pe colateral; nu este avuţia unei investiţii finanţate
- Iulie 1963 – iulie 2026: Mkt-RF 43,2, MOM 48,0, HML 6,9, RMW 5,7, CMA 5,5, SMB 2,9

- Momentum a atins maximum înainte de 2009 şi a pierdut mult la revenirea din 2009: un **crah de momentum**
- Valoarea a stagnat sau a pierdut aproximativ din 2007 pînă în 2020
- Randamente anuale medii: Mkt-RF 7,2%, MOM 7,3%, HML 3,6%, RMW 3,1%, CMA 3,0%, SMB 2,3%

 MFM_ch3_factor_cum

Se mențin primele în timp?



- Statistica t a randamentului lunar mediu al factorului (Newey-West), 1963–1999 vs 2000–2026
- Momentum: $t = 5,53$ înainte de 2000, $0,75$ după; media $10,7\%$ vs $2,5\%$ pe an
- Valoare (HML): $t = 2,39$, apoi $1,02$; media $4,2\%$ vs $2,8\%$
- Profitabilitatea (RMW) este excepția: $t = 1,90$, apoi $2,31$; prima pieței rezistă în ambele jumătăți ($t = 2,70$ și $2,39$)
- O împărțire calendaristică nu este un eveniment de publicare: datarea scăderii cere specificația din Secțiunea 12

Cele două etape



Eugene Fama, premiul Morgan
Stanley–AFA, 2008

Foto: TonyTheTiger (2008); CC BY-SA

3.0; Wikimedia Commons

- **Fama & MacBeth (1973)** estimează primele de risc λ din $\mathbb{E}[R_i^e] = \lambda_0 + \beta_i^\top \lambda$ (Fama: Premiul Nobel 2013)
- **Etapa 1** (serii de timp, câte o regresie pentru fiecare activ): randamente $T \times N$, factori $T \times K \Rightarrow$ valorile beta $\hat{B}$, $N \times K$

$$R_{i,t}^e = a_i + \beta_i^\top f_t + \varepsilon_{i,t}$$

- **Etapa 2** (transversal, câte o regresie pentru fiecare lună): cele N randamente pe $X = [1, \hat{B}]$

$$R_{i,t}^e = \lambda_{0,t} + \hat{\beta}_i^\top \lambda_t + u_{i,t}, \quad \hat{\lambda} = \frac{1}{T} \sum_t \hat{\lambda}_t$$

- λ_0 : eroare de evaluare comună tuturor activelor, zero dacă modelul este corect
- Permite factori care **nu** sînt portofolii tranzacționate și caracteristici ale firmelor ca regresori

Erori standard pentru primele de risc

- ▣ **Fama–MacBeth**: estimațiile lunare $\hat{\lambda}_{k,t}$ sînt tratate ca un eșantion de volum T , $se_{FM}(\hat{\lambda}_k) = s(\hat{\lambda}_{k,t})/\sqrt{T}$; robuste la corelația transversală a reziduurilor; dacă $\hat{\lambda}_{k,t}$ este autocorelat, se folosește Newey–West pe această serie
- ▣ **Erori în variabile**: etapa 2 folosește $\hat{\beta}$, nu β , deci se_{FM} este prea mică; [Shanken \(1992\)](#) înmulțește partea care nu ține de factori cu $(1 + c)$

$$\text{Var}_{Sh}(\hat{\lambda}) = (1 + c) \left[\text{Var}_{FM}(\hat{\lambda}) - \frac{1}{T} \Sigma_f \right] + \frac{1}{T} \Sigma_f, \quad c = \hat{\lambda}^\top \Sigma_f^{-1} \hat{\lambda}$$


- Σ_f : covarianța factorilor; c : pătratul raportului Sharpe al primelor pe perioadă, 0,03 pentru FF3 aici, mai mare pentru unii factori netranzaționați
- ▣ **Specificare greșită**: toate trei presupun un model corect, cu erori de evaluare $e = \mu - X\gamma = 0$; cînd GRS respinge, zgomotul din $\hat{B}$ se înmulțește cu e și adaugă varianță ([Kan, Robotti & Shanken \(2013\)](#); forma GMM în [► Anexă](#))

Exemplu rezolvat: patru erori standard pentru prima de valoare

FF3, HML	$\hat{\lambda}$	Eroare std.	t	Semnificativ la 5%?
Fama–MacBeth	3,97%	1,33%	2,99	da
Newey–West (6 laguri)	3,97%	1,62%	2,45	da
Shanken	3,97%	1,33%	2,99	da
Kan–Robotti–Shanken	3,97%	1,32%	3,00	da

- 25 de portofolii mărime $\times$ B/M, 1963–2026; corecția Shanken modifică foarte puțin eroarea ($c = 0,03$ pe lună)
- Aici contează cel mai mult autocorelarea pantelor lunare $\hat{\lambda}_t$: Newey–West, 6 laguri conform regulii pentru $T = 757$
- FF5: eroarea standard robustă la specificarea greșită a lui RMW crește de la 2,1% la 2,6%, iar t scade de la 2,5 la 2,1
- La pragul $t > 3$ din Secțiunea 8, HML este la limită pentru orice alegere (2,45–3,00)

Primele de risc estimate



- 25 de portofolii mărime $\times$ B/M, 1963–2026; bare: intervale de 95% cu erori Shanken; cruciuile: mediile factorilor
- CAPM: termen liber 14,0% (e.s. 4,4%), prima pieței –4,4% (e.s. 4,8%)
- FF3: SMB 1,4% (1,4%), HML 4,0% (1,3%); FF5: RMW 5,3% (2,1%), CMA –1,4% (2,2%)

- Factor tranzacționat: λ ar trebui să fie egal cu media lui în timp: HML 4,0% vs 3,6%, apropiate; piața (FF3) –6,5% vs 7,2%, departe
- Valorile beta de piață acoperă doar 0,86–1,42 (abatere standard transversală 0,14): λ_m este **slab identificat**, iar un termen liber mare absoarbe nivelul (Lewellen, Nagel & Shanken (2010))

Factori inutili și factori slabi

- Un **factor inutil** g_t este independent de toate randamentele: $\beta_g = 0$, deci $\hat{\beta}_{i,g} = O_p(T^{-1/2})$ este doar zgomot
- Etapa 2 împarte la acest zgomot: $\hat{\lambda}_g$ nu converge la zero, iar testul t respinge prea des când modelul este greșit specificat ([Kan & Zhang \(1999\)](#))
- Simulare pe cele 25 de portofolii: CAPM plus un factor independent cu distribuția Normală, 2000 de replicări, nivel nominal 5%
 - ▶ $\lambda_g = 0$ este respins în 60% (erori Fama–MacBeth) și 27% (erori Shanken) din replicări
 - ▶ Testul Wald din prima etapă pentru $\beta_{i,g} = 0$, pentru toți i : respins în 6,7%; rulați-l înaintea etapei 2
- **Factori slabi** (dispersie mică a valorilor beta, ca piața aici): teste robuste la identificare ([Kleibergen \(2009\)](#)); cu multe active, consistența etapei 2 depinde de tăria factorilor ([Anatolyev & Mikusheva \(2022\)](#))

O evaluare sceptică: adăugăm 30 de portofolii pe industrii

Model	R^2 OLS		R^2 GLS	
	25	25 + 30	25	25 + 30
CAPM	0,08	0,00	0,06	0,01
FF3	0,66	0,22	0,21	0,08
FF5	0,76	0,24	0,26	0,10

Lunar 1963–2026, termen liber și prime fără restricții

- Cele 25 de portofolii au o structură puternică de trei factori: orice factori corelați cu SMB și HML le reproduc mediile, deci un R^2 OLS mare este un criteriu puțin exigent ([Lewellen, Nagel & Shanken \(2010\)](#))
- Trei verificări
 - ▶ Lărgiți activele de test: FF3 scade de la 0,66 la 0,22 când se adaugă 30 de industrii
 - ▶ Raportați R^2 GLS (Generalised Least Squares, metoda celor mai mici pătrate generalizate), ponderat cu $\hat{V}^{-1}$ ca GRS: niciodată peste 0,26
 - ▶ Impuneți $\lambda = \mathbb{E}[f]$ pentru factorii tranzacționați, fără termen liber: FF3 pe cele 55 de active dă $R^2 = -0,27$
- Acțiuni în locul portofoliilor: mai multă dispersie a valorilor beta, erori în variabile mai mari ([Ang, Liu & Schwarz \(2020\)](#))

Factorii ca factor stochastic de actualizare



Lars Peter Hansen, Premiul Nobel
pentru Economie 2013

Foto: Bengt Nyman (2013); CC BY 2.0;
Wikimedia Commons

- **SDF** (Stochastic Discount Factor, factorul stochastic de actualizare) m_t : evaluează toate randamentele în exces, $\mathbb{E}[m_t R_{i,t}^e] = 0$
- Un model factorial liniar este un SDF, $m_t = 1 - \mathbf{b}^\top (\mathbf{f}_t - \mathbb{E}\mathbf{f})$
- Prin înlocuire: $\mathbb{E}[R_i^e] = \text{Cov}(R_i^e, \mathbf{f}_t)^\top \mathbf{b} = \boldsymbol{\beta}_i^\top \boldsymbol{\lambda}$ cu $\boldsymbol{\lambda} = \boldsymbol{\Sigma}_f \mathbf{b}$: modelul de evaluare prin beta din Secțiunea 6
- Testul $\mathbf{b} \neq 0$ arată dacă un factor ajută la evaluarea activelor; testul $\boldsymbol{\lambda} \neq 0$, dacă factorul este remunerat
- Aceste condiții de momente se estimează prin GMM, Hansen (1982); sinteză a perspectivei ratelor de actualizare: Cochrane (2011)

Compararea modelelor: rapoarte Sharpe maxime

Raport Sharpe maxim (anual)	CAPM	FF3	Carhart	FF5	FF5 + MOM
1963–2026 ($T = 757$)	0,47	0,66	0,97	0,97	1,16
2000–2026 ($T = 319$)	0,48	0,54	0,67	0,97	1,02

- Barillas & Shanken (2018): un model se judecă după $SR^2(f) = \mu_f^\top \Sigma_f^{-1} \mu_f$ al factorilor săi; activele de test nu contează în comparație
- Modele incluse unul în altul: în eșantion SR^2 nu poate decât să crească, deci testați alfa factorului adăugat pe ceilalți (regresie de spanning)
 - ▶ HML pe ceilalți cinci factori: $\alpha = 0,9\%$ pe an ($t = 0,75$); din 2000 $-1,7\%$ ($t = -0,81$): nicio contribuție incrementală semnificativă a HML, ca în Fama & French (2015)
- FF5 vs Carhart (neincluse unul în altul): diferența SR^2 anual 0,00, interval de 95% $[-0,57; 0,66]$; din 2000 0,50, $[-0,24; 1,48]$ (bootstrap staționar, Politis & Romano (1994))
- O altă măsură independentă de model, distanța Hansen–Jagannathan: ▶ Anexă

Factor zoo

- ▣ [Cochrane \(2011\)](#) a numit lista tot mai lungă de factori noi un *factor zoo*
- ▣ [Harvey, Liu & Zhu \(2016\)](#) catalogează sute de factori publicați (316 în lista lor)
- ▣ Fiecare a fost testat ca și cum ar fi fost singurul: $|t| > 1,96$ la 5%
- ▣ Cu multe teste, unii trec din întâmplare: **data mining**, numit și p-hacking
- ▣ Propunerea lor: un factor nou are nevoie de $|t| > 3,0$

Controlul descoperirilor false

- **FDR** (False Discovery Rate, rata descoperirilor false): ponderea așteptată a respingerilor false în totalul respingerilor;
FWER (Family-Wise Error Rate): probabilitatea de a avea cel puțin o respingere falsă ([Capitolul 2](#))
- Procedura **BH** ([Benjamini & Hochberg \(1995\)](#)): găsim cel mai mare j cu $p_{(j)} \leq \frac{j}{M} \alpha$ și respingem $H_{(1)}, \dots, H_{(j)}$



Procedura	Controlează	Respinge $H_{(j)}$ dacă	Validă pentru
Bonferroni	FWER	$p_{(j)} \leq \alpha/M$	orice dependență
Holm (Holm (1979))	FWER	$p_{(k)} \leq \alpha/(M - k + 1), \forall k \leq j$	orice dependență
BH (Benjamini & Hochberg (1995))	FDR	$j \leq \text{cel mai mare } k \text{ cu } p_{(k)} \leq k\alpha/M$	independență, dep. pozitivă
BY (Benjamini & Yekutieli (2001))	FDR	ca BH, pragurile împărțite la $\sum_{k=1}^M 1/k$	orice dependență

- Dependență pozitivă: statisticile testelor ipotezelor nule adevărate cresc împreună (condiția PRDS a lui Benjamini–Yekutieli: *positive regression dependence on a subset*); controlul FDR se potrivește căutării printre mulți factori candidați

Exemplu rezolvat: zece factori candidați

- ▣ p -valori ordonate: 0,0004; 0,002; 0,006; 0,011; 0,018; 0,027; 0,041; 0,070; 0,15; 0,62; $\alpha = 5\%$
- ▣ Naiv ($p \leq 0,05$): **7** descoperiri
- ▣ Bonferroni ($p \leq 0,005$): **2**
- ▣ Holm: $0,0004 \leq 0,005$, $0,002 \leq 0,0056$, $0,006 \leq 0,00625$, $0,011 > 0,0071$ stop: **3**
- ▣ Pragurile BH $0,005j$: $p_{(6)} = 0,027 \leq 0,030$ este ultima respingere: **6**
- ▣ Seminarul 3, problema A5 repetă procedura pe un alt vector, cu un grafic al pragurilor

Simulare: 300 de factori inutili





- 2000 de replicări; fiecare extrage 300 de statistici t independente din distribuția Normală standard (fără primă reală)
- În medie, 15,0 factori inutili trec pragul $|t| > 1,96$; valoarea așteptată $300 \times 0,05 = 15$

- În medie, 0,83 trec pragul $|t| > 3$; cel puțin unul trece în 57% din replicări; mediana celui mai mare $|t|$: 3,06
- Pragul Bonferroni pentru 300 de teste: $|t| > 3,76$; pragurile cresc cu numărul de teste încercate efectiv, inclusiv cele nepublicate

Componentele principale, pe scurt

- ▣ **Factori latenți:** estimați doar din randamente, fără a-i numi dinainte
- ▣ **PCA** (Principal Component Analysis, analiza componentelor principale) a matricei de corelație a randamentelor standardizate: $C = \mathbf{\Gamma} \mathbf{\Lambda} \mathbf{\Gamma}^\top$, componente $y_t = \mathbf{\Gamma}^\top z_t$
- ▣ Valori proprii $\lambda_1 \geq \dots \geq \lambda_N$; vectorii proprii sînt **încărcările**; componenta k explică λ_k/N din varianță
- ▣ Două active cu corelația ρ : $\lambda = 1 \pm \rho$, vectori proprii $(1, 1)/\sqrt{2}$ („piața”) și $(1, -1)/\sqrt{2}$ (spread-ul); în criză ρ crește și PC1 domină
- ▣ Manual: [Härdle & Simar \(2019\)](#), capitolul despre componente principale; N active cu corelații egale: Seminarul 3, problema A8

PCA pe ETF-urile sectoriale din SUA



- 11 ETF-uri sectoriale, randamente logaritmice zilnice, 20 iunie 2018 – 18 septembrie 2026 ($T = 2073$ zile comune)
- PC1 explică 66,0%; toate încărcările sînt pozitive (0,24–0,34); corelația cu SPY 0,954: puternic legată de piață

- PC2 (9,7%): utilități +0,55, bunuri de larg consum +0,42, imobiliare +0,31 vs tehnologie -0,40, consum discreționar -0,33: **defensiv versus creștere**, fără nume dat dinainte
- PC3 (7,4%) este dominată de energie; trei componente explică 83,1%

Câți factori?

- Model factorial aproximativ $x_{it} = \lambda_i^T F_t + e_{it}$, $N, T \rightarrow \infty$; $V(k)$: media pătratelor reziduurilor după primele k componente
- Bai & Ng (2002): $\hat{k} = \arg \min_k [\ln V(k) + k \frac{N+T}{NT} \ln \min(N, T)]$ (criteriul IC_{p2}); Ahn & Horenstein (2013): raportul valorilor proprii $\hat{k} = \arg \max_k \mu_k / \mu_{k+1}$, fără penalizare de ales
- Regula Kaiser ($\lambda_k > 1$) nu are justificare asimptotică: valorile proprii ale zgomotului dintr-o matrice de corelație se împrăștie în jurul lui 1

Panel	N	T	Kaiser	Bai–Ng	Ahn–Horenstein
11 ETF-uri sectoriale, zilnic 2018–2026	11	2073	2	5	1
100 portofolii mărime $\times$ B/M, lunar 1963–2026	95	757	3	4	1

- Randamente standardizate; k maxim: 5 pentru sectoare, 8 pentru portofolii; 5 portofolii cu luni lipsă sînt eliminate
- Ahn–Horenstein alege factorul dominant al pieței (raport 14,6); următorul vîrf este la $k = 3$ (raport 3,5), structura FF3
- Bai–Ng pe 11 sectoare atinge limita superioară $k = 5$: penalizarea este construită pentru N mare, deci cu N mic răspunsul este fragil

Limitele PCA în evaluarea activelor

- ▣ Încărcările sînt **constante**: PCA nu poate urmări o acțiune a cărei mărime sau valoare se schimbă
- ▣ Componentele explică **varianța**, nu neapărat **randamentele medii**
- ▣ Acțiunile individuale intră și ies din eșantion: un panel de acțiuni este dezechilibrat
- ▣ Semnele componentelor sînt arbitrare; rotațiile păstrează componentele principale doar în subspațiile proprii cu valori proprii egale, iar un model cu factori latenți este identificat doar pînă la o rotație
- ▣ PCA cu primă de risc și primele în trei etape păstrează baza PCA, dar urmăresc explicarea randamentelor medii (▶ Anexă); PCA și analiza factorială în finanțe: [Franke, Härdle & Hafner \(2019\)](#)

PCA instrumentată

▣ **IPCA:** Instrumented Principal Component Analysis (PCA instrumentată), [Kelly, Pruitt & Su \(2019\)](#)

▣ Încărcările sînt funcții de L caracteristici observate $\mathbf{z}_{i,t}$ (mărime, B/M, momentum, ...)


$$R_{i,t+1}^e = \alpha_{i,t} + \beta_{i,t}^\top \mathbf{f}_{t+1} + \varepsilon_{i,t+1}, \quad \beta_{i,t}^\top = \mathbf{z}_{i,t}^\top \mathbf{\Gamma}_\beta$$

▣ $\mathbf{\Gamma}_\beta$ ($L \times K$) și factorii latenți $\mathbf{f}_t$ se estimează împreună prin metoda alternantă a celor mai mici pătrate

▣ Test: sînt caracteristicile remunerate prin beta („covarianțe”) sau direct ca alfa ($\alpha_{i,t} = \mathbf{z}_{i,t}^\top \mathbf{\Gamma}_\alpha$)?


▣ Rezultatul, în datele lor pentru acțiuni americane: cîțiva factori IPCA evaluează secțiunea transversală mai bine decît modelele cu tot atîția factori observabili, iar $\mathbf{\Gamma}_\alpha$ este nesemnificativ: „caracteristicile sînt covarianțe”

ETF-urile factoriale față de piață



- Smart beta: portofolii doar long, bazate pe reguli, cu expuneri sporite la anumiți factori, oferite ca ETF-uri; păstrează expunerea la piață și nu reproduc neapărat un factor academic long-short
- Evoluția a 1 USD cu dividende reinvestite, de la 18 iulie 2013 (prima zi comună)
- CAGR: firmele mari de creștere (IWF) 16,3% și momentum (MTUM) 15,5% au depășit SPY (14,0%); calitate (QUAL) 13,5%, valoare (VLUE) 13,1%, firme mari de valoare (IWD) 10,7%, volatilitate minimă (USMV) 10,5%, firme mici (IWM, indicele Russell 2000) 9,3%
- Treisprezece ani dintr-o singură realizare: nu sînt, în sine, dovezi împotriva primelor

Valorile alfa ale ETF-urilor factoriale



Factor loadings

	Mkt-RF	SMB	HML	RMW	CMA	MOM
MTUM	1.03	-0.12	0.01	-0.22	-0.05	0.36
VLUE	0.98	0.08	0.34	-0.06	0.09	-0.03
QUAL	0.97	-0.08	-0.04	0.15	0.03	-0.04
USMV	0.74	-0.11	-0.02	0.20	0.21	-0.02
IWM	1.04	0.85	0.08	-0.10	-0.02	0.03
IWD	0.94	-0.04	0.29	0.09	0.19	-0.04
IWF	1.03	-0.11	-0.28	-0.03	-0.12	-0.00

- Regresii zilnice pe FF5 + MOM, erori Newey–West, fiecare ETF pe propriul calendar de tranzacționare (2000–2026)
- Încărcările corespund denumirilor: MTUM pe MOM 0,36, VLUE pe HML 0,34, IWM pe SMB 0,85; IWF –0,28 pe HML; USMV beta de piață 0,74

- Valori alfa aproape de zero: MTUM –0,2% ($t = -0,11$), QUAL –0,3%; ETF-urile Russell IWM –1,3% ($t = -2,57$), IWD –1,6% ($t = -2,55$), compatibile cu costurile și construcția indicelui
- R^2 între 0,81 și 0,97: în mare parte expunere factorială reambalată


Factor timing, crowding și costuri

- ▣ **Factor timing** (sincronizarea factorilor): trecerea de la un factor la altul pe baza unor semnale (spread-uri de evaluare, randamente recente)
 - ▶ Incertitudinea primelor și seriile scurte îngreunează verificarea factor timing în afara eșantionului ([Capitolul 8](#))
- ▣ **Crowding** (aglomerarea pozițiilor): mulți investitori dețin aceleași poziții factoriale
 - ▶ Primele se pot micșora ([McLean & Pontiff \(2016\)](#)), iar crowding-ul poate amplifica pierderile la lichidări forțate; crahul de momentum din 2009 a coincis cu o revenire bruscă a fostelor acțiuni perdante ([Daniel & Moskowitz \(2016\)](#))
- ▣ **Implementarea**: factorii long-short ignoră costurile de tranzacționare și comisioanele pentru vânzarea în lipsă; ETF-urile le plătesc

Studiu de caz: întrebarea de cercetare

- **Critica** la adresa cercetării despre factori are două forme (Jensen, Kelly & Pedersen (2023), Introducere)
 - ▶ Lipsa validității interne: rezultatele nu pot fi reproduse; Hou, Xue & Zhang (2020) replică doar 35% dintre anomaliile studiate
 - ▶ Lipsa validității externe: rezultatele provin din testarea multor factori fără controlul FDR; Harvey, Liu & Zhu (2016) conchid că majoritatea descoperirilor raportate sînt probabil false
- **Întrebarea:** au factorii publicați valori alfa CAPM semnificative în datele originale, în afara eșantionului și în alte țări, după ce se ține cont de testarea multiplă?
- **De ce contează:** dacă majoritatea factorilor sînt descoperiri false, modelele multifactoriale și investițiile factoriale (Secțiunile 5 și 10) se sprijină pe zgomot
- **O a doua perspectivă asupra factor zoo:** majoritatea factorilor noi sînt redundanți față de cei existenți (Feng, Giglio & Xiu (2020), [▶ Anexă](#)); articolul o tratează în schimb ca dovezi corelate despre cîteva teme economice
- **Legătura cu acest capitol:** alfa lui Jensen (Secțiunea 4) este mărimea testată; Benjamini–Yekutieli (Secțiunea 8) este reperul frecventist; shrinkage-ul bayesian extinde la valorile alfa estimarea Vasicek pentru beta (Secțiunea 3)

Studiu de caz: date și metodă



- **Date** (Secțiunea II): 153 de factori în 93 de țări; terțile ale fiecărei caracteristici, ponderi după capitalizarea plafonată, cumpărarea părții cu randamentul așteptat mai mare în studiul inițial; fiecare factor scalat la o volatilitate idiosincronică anuală de 10%
- **Teme**: 13 grupe de factori americani, grupare ierarhică după corelația reziduurilor CAPM
- **Modelul** (Secțiunea I): $f_{i,t} = \alpha_i + \beta_i r_t^m + \varepsilon_{i,t}$, valorile alfa $\alpha_i = c_j + s_n + w_i$ (temă, semnal, factor), media a priori 0
- **Un singur factor**: $\mathbb{E}(\alpha \mid \hat{\alpha}) = \kappa \hat{\alpha}$, $\kappa = 1/(1 + \sigma^2/(\tau^2 T))$ (ec. 5): eșantioanele scurte și zgomotoase primesc mai mult shrinkage, ca la Vasicek
- **Rata de replicare**: ponderea factorilor cu alfa semnificativ; descoperire bayesiană dacă media a posteriori / abaterea standard a posteriori $\geq 1,96$
- **Ierarhia completă și estimarea**: [▶ Anexă](#)


Studiu de caz: rezultatele principale

Rate de replicare, SUA (Figura 1)

Hou, Xue & Zhang (2020), random. brute	35,0%
Acest articol, random. brute	55,6%
Alfa CAPM, OLS	82,4%
Alfa CAPM, Benjamini–Yekutieli	75,6%
Alfa CAPM, Bayes empiric	82,4%
Global, Bayes empiric	82,4%

- Testarea valorilor alfa în locul randamentelor brute explică cea mai mare parte a diferenței față de Hou, Xue & Zhang (2020)
- FDR bayesian 0,1%: shrinkage-ul controlează descoperirile false fără pierderea de putere a unui prag t mai înalt
- **Scăderea:** alfa medie 0,49% pe lună în eșantion, 0,26% după eșantionul original (−47%); panta valorilor alfa ulterioare pe cele din eșantion 0,26 (Figura 8), față de circa 0,9 doar din shrinkage
- Factorii cei mai puternici scad mai mult: arbitraj sau data mining (Secțiunea 12)
- Rezultatele complete: [▶ Anexă](#)

Studiu de caz: replicare pe datele cursului



- 15 factori americani long-short din sortările ponderate după valoare ale [Kenneth French Data Library](#), iulie 1963 – iulie 2026 ($T = 757$); valori alfa CAPM scalate la volatilitate idiosincronică de 10%; temele articolului ([etichetele autorilor](#))
- Rate de replicare: OLS 73,3% (11 din 15), Benjamini-Yekutieli 53,3% (8; t critic 2,72), Bayes empiric 86,7% (13)

- Shrinkage spre temă, nu doar spre zero: inversarea pe termen lung (tema investiții) 0,13% $\rightarrow$ 0,23% pe lună ($t = 1,25$, z a posteriori 2,85)
- Factori nereplicați: beta de piață și inversarea pe termen scurt ($z \leq 1,41$); mărimea trece la limită ($z = 1,96$), ca în articol, unde mărimea este una dintre cele două teme sub 50%

Studiu de caz: limite și o întrebare deschisă

▣ **Limitele versiunii de curs**

- ▶ 15 semnale americane în loc de 153 în 93 de țări; pragurile de sortare din Kenneth French Data Library în loc de terțile fără microcapitalizări cu ponderi plafonate; o singură regiune, deci fără nivelul semnalului ($\tau_s = 0$)
- ▶ Rata depinde de structura temelor: cu o singură temă comună, rata Bayes empiric este 100%

▣ **Limite precizate de autori:** CAPM ca singur reper, construcția unitară a caracteristicilor, factorii nepublicați în distribuția a priori (▶ Anexă)


▣ **Întrebare deschisă:** datele articolului se opresc în 2020; s-au menținut valorile alfa a posteriori și rata de replicare în 2021–2026 și poate o distribuție a priori estimată pe factorii americani să facă mai precise estimările factorilor BVB pe eșantioane scurte?

▣ Datele și codul articolului: jkpfactors.com; proiectul de curs: Seminarul 3, C3

O întrebare deschisă și bucla descoperirii

- **Întrebare deschisă:** de ce scad primele factorilor după publicare: arbitraj, data mining sau o schimbare a riscului, și diferă scăderea între factori și piețe?
- Ce se știe
 - ▶ [McLean & Pontiff \(2016\)](#): pe 97 de predictorii, randamentele sînt cu 26% mai mici în afara eșantionului și cu 58% mai mici după publicare; diferența este atribuită tranzacțiilor informate de publicare
 - ▶ [Jensen, Kelly & Pedersen \(2023\)](#): majoritatea factorilor se replică, dar cei mai puternici scad cel mai mult; [Chen & Zimmermann \(2022\)](#): date și cod deschise pentru predictorii publicați
- **Bucla descoperirii, parcursă o dată**
 - ▶ Asistentul propune: un tabel al literaturii cu DOI, ipoteze concurente cu tiparele prezise, codul regresiei, un plan de robustețe
 - ▶ Omul fixează înainte de rulare: datele evenimentelor (Jegadeesh–Titman: eșantionul se termină în 1989, publicat în martie 1993), mulțimea factorilor, corecția pentru testarea multiplă, placebo-ul
 - ▶ Verificări: fiecare link DOI funcționează; statisticile t pe subperioade din capitol se reproduc întîi; se notează versiunea datelor
- Prompturi reutilizabile și lista completă de verificări: [▶ Anexă](#)

Mini studiu de caz: a fost momentumul eliminat prin arbitraj?



- Specificația din [McLean & Pontiff \(2016\)](#):

$$MOM_t = a + b_1 \text{PostSample}_t + b_2 \text{PostPub}_t + e_t$$
 lunar 1965–2026, erori Newey–West; după eșantion 1990-01 – 1993-03, după publicare din 1993-04
- b_2 : scăderea totală față de media din eșantion; $b_2 - b_1$: efectul incremental al publicării

- $a = 0,82\%$ pe lună ($t = 4,32$); $b_2 = -0,45\%$ ($t = -1,45$, interval $[-1,05\%; 0,16\%]$): cu 54% mai mic; $b_2 - b_1 = -0,79\%$ ($t = -1,18$); placebo Mkt-RF $b_2 = +0,40\%$ ($t = 1,12$)
- Aproape de 58% din [McLean & Pontiff \(2016\)](#), dar un singur factor nu poate respinge $H_0 : b_2 = 0$ la 5%; arbitrajul este o interpretare, nu o cauză identificată

Rîndul vostru: un punct de plecare pentru proiect

- ▣ **Întrebare:** scad factorii Fama–French și momentumul după publicare și diferă scăderea între factori?
 - ▶ Regresie comună pentru SMB, HML, RMW, CMA și MOM pe variabile dummy specifice fiecărui factor, după eşantion și după publicare; Mkt-RF ca placebo; erori robuste la corelația dintre factori și la autocorelare
 - ▶ Pentru a testa dacă scăderea este mai mare acolo unde arbitrajul este mai ușor sînt necesari indicatori la nivel de acțiune (mărime, lichiditate, costul vânzării în lipsă), nu randamente factoriale
- ▣ **Replicați întîi:** statisticile t pe subperioade și estimațiile din mini studiu de caz
- ▣ **Livrabile:** o notă de preînregistrare (H_0 , H_1 , datele din fiecare lucrare, mulțimea factorilor, corecții) fixată în scris, printr-un commit, înainte de rezultate; codul ca Quantlet; un raport cu inferență Newey–West, perioade placebo și putere
- ▣ **Jurnale:** prompturile în AI_USE.md; fiecare eroare depistată (o dată de publicare greșită, o cifră citată greșit) în AI_ERRORS.md

Idei principale: un flux de lucru empiric

1. **Estimați expunerile** cu erori HAC, raportați eșantionul și aproximarea pieței, aplicați shrinkage valorilor beta extreme (Blume, Vasicek)
 2. **Testați restricția de evaluare în comun:** GRS măsoară creșterea raportului Sharpe adusă de activele de test; CAPM eșuează pe cele 25 de portofolii mărime $\times$ B/M (SML plată, $GRS = 4,20$)
 3. **Estimați primele** în două etape, cu erori robuste la beta estimat și la specificarea greșită; un R^2 mare pe 25 de portofolii este un criteriu puțin exigent
 4. **Protejați-vă de factor zoo:** praguri pentru testarea multiplă, teste de spanning, compararea modelelor prin rapoartele Sharpe maxime
 5. **Replicați:** factori latenți și dovezi în afara eșantionului; ETF-urile factoriale sînt expunere factorială ieftină, nu alfa
- Deschis: de ce scad primele după publicare; cum se evaluează activele cu beta variabil în timp; ce factori explică randamentele așteptate pe piețe mici precum BVB

Autoevaluare și capitolele următoare

Întrebări de verificare

- De ce diferă eroarea standard HAC a unui beta de cea clasică, deși beta nu se schimbă?
- De ce poate GRS să nu respingă CAPM pe ETF-urile sectoriale, dar să-l respingă pe cele 25 de portofolii, în aceleași luni?
- De ce pare remunerat un factor inutil în etapa 2?
- De ce poate rata de replicare Bayes empiric să depășească rata Benjamini–Yekutieli?

Legături cu alte capitole

- **Capitolul 2:** un alfa este o anomalie sau un factor de risc omis, problema ipotezei comune
- **Capitolul 4:** modele factoriale de covarianță și shrinkage pentru Markowitz
- **Capitolele 5–6:** volatilitate, corelații și beta variabile în timp
- **Capitolul 8:** backtesting pentru strategii factoriale fără overfitting
- **Capitolul 13:** machine learning pentru secțiunea transversală a randamentelor

Anexă: GRS sub ipoteza nulă

- Sub H_0 și ipotezele exacte, $W \sim F(N, T - N - 1)$, deci $\mathbb{E}[W] = \frac{T-N-1}{T-N-3}$
- Inversînd forma Sharpe a lui W , creșterea așteptată sub H_0 a pătratului raportului Sharpe este

$$\mathbb{E}[\widehat{SR}^2(f, R) - \widehat{SR}^2(f)] \approx \frac{N(1 + \widehat{SR}^2(f))}{T - N - 3}$$

- 25 de portofolii, $T = 757$: $25 \times 1,018/729 = 0,035$ (lunar), față de $0,405^2 - 0,134^2 = 0,146$ observat
- Maximizarea în eșantion pe N active adaugă întotdeauna ceva raport Sharpe: testul verifică dacă câștigul depășește acest nivel al zgomotului
- 9 ETF-uri sectoriale, $T = 331$: câștig observat $0,191^2 - 0,146^2 = 0,015$, sub cel așteptat, $9 \times 1,021/319 = 0,029$

Anexă: teste pentru multe active

- $\hat{\Sigma} = \hat{E}^\top \hat{E} / T$ are rangul cel mult $T - 2$ (doi parametri în fiecare regresie)
 - ▶ Exemplu: 100 de portofolii mărime $\times$ B/M pe 8 ani de date lunare ($T = 96$): $\hat{\Sigma}$ este singulară, GRS nu există
 - ▶ Cu mult înainte de acest punct, inversa este prost estimată și puterea scade
- Teste pentru multe active care evită $\hat{\Sigma}^{-1}$: sume standardizate ale pătratelor statisticilor t , [Pesaran & Yamagata \(2024\)](#)
- Creșterea puterii prin selecția valorilor alfa mari: [Fan, Liao & Yao \(2015\)](#)
- Cu multe active, consistența etapei a doua depinde de tăria factorilor: [Anatolyev & Mikusheva \(2022\)](#)

Anexă: erori standard robuste la specificarea greșită

- Erorile Fama–MacBeth și Shanken presupun un model **corect**: toate erorile de evaluare $e = \mu - X\gamma$ sînt zero ($X = [1, B]$)
- Aici GRS respinge, deci γ este o valoare pseudo-adevărată; zgomotul din $\hat{B}$ se înmulțește cu e și adaugă un termen de varianță (Kan, Robotti & Shanken (2013))
- Scriem ambele etape ca un singur sistem GMM exact identificat: momentele $(R_t - a - Bf_t) \otimes (1, f_t)$ și $X^\top (R_t - X\gamma)$; varianța sandwich cu jacobianul complet este cea robustă
 - ▶ Cu $e = 0$ în jacobian se obține versiunea pentru un model corect specificat, robustă la heteroscedasticitate, a lui Jagannathan & Wang (1998)
- FF5 pe cele 25 de portofolii: eroarea standard pentru RMW 2,1% $\rightarrow$ 2,6%, CMA 2,2% $\rightarrow$ 2,7%, termenul liber 3,3% $\rightarrow$ 3,8%
- RMW: t scade de la 2,5 la 2,1; pentru HML schimbarea este sub 0,05 puncte procentuale
- Curs avansat:  Generalized Method of Moments

Anexă: distanța Hansen–Jagannathan și selecția bayesiană

- **Distanța Hansen–Jagannathan** (Hansen & Jagannathan (1997)): distanța în sensul celor mai mici pătrate dintre SDF-ul modelului și mulțimea SDF-urilor valide

$$\delta^2 = \min_b e(b)^\top \mathbb{E}[R^e R^{e\top}]^{-1} e(b), \quad e(b) = \mathbb{E}[m_t(b) R_t^e]$$

- ▶ Randamente în exces R_t^e cu normalizarea $\mathbb{E}[m] = 1$; pentru randamente brute R_t : $e = \mathbb{E}[mR] - 1$, iar SDF-ul are nevoie de o scală liberă ($\mathbb{E}[m] = 1/(1 + R_f)$)
- ▶ Aceeași matrice de ponderare pentru orice model, deci distanțele sînt comparabile; statistica de test are o limită χ^2 ponderată
- Selecție la scara factor zoo: medierea bayesiană a două cvadrilioane de modele factoriale, robustă la factori slabi (Bryzgalova, Huang & Julliard (2023))
- Shrinkage pentru SDF pe factori construiți din caracteristici: cîteva componente principale ale randamentelor anomaliilor captează SDF-ul (Kozak, Nagel & Santosh (2020))
- Lecția comună: comparați modelele printr-o singură măsură, independentă de model, cu incertitudinea ei de eşantionare

Anexă: factor zoo redus prin LASSO cu dublă selecție

- Feng, Giglio & Xiu (2020): aduce un factor nou informație suplimentară față de factorii deja cunoscuți?
- **LASSO cu dublă selecție** (Least Absolute Shrinkage and Selection Operator)
 - ▶ Pasul 1: un LASSO al randamentelor medii ale activelor de test pe covarianțele lor cu sute de factori alege variabilele de control care evaluează secțiunea transversală
 - ▶ Pasul 2: un al doilea LASSO alege factorii ale căror covarianțe le explică pe cele ale factorului nou, ca variabilele de control omise să nu deplaseze coeficientul lui din SDF
 - ▶ Pasul 3: coeficientul din SDF al factorului nou se estimează cu reuniunea celor două mulțimi de variabile de control și se testează
- Rezultat: majoritatea factorilor noi sînt redundanți; doar cîțiva adaugă informație de evaluare
- Studiul de caz ajunge la o concluzie compatibilă: mulți factori sînt redundanți, iar informația se concentrează în cîteva teme

Anexă: mai mult despre numărul de factori

- ▣ Onatski (2010): separă valorile proprii ale factorilor de marginea distribuției valorilor proprii ale zgomotului
- ▣ Regula Kaiser ($\lambda_k > 1$) pe o matrice de corelație: pentru N active și zgomot pur, valorile proprii se împrăștie în jurul lui 1 pe o lățime care depinde de N/T , deci regula nu are justificare asimptotică
- ▣ Penalizările Bai–Ng sînt construite pentru N și T mari: la 11 sectoare criteriul scade pînă la $k_{\max}$
- ▣ Ahn–Horenstein nu cere nicio penalizare: raportul valorilor proprii consecutive are un vîrf după ultimul factor puternic
- ▣ Raportați intervalul estimațiilor și sensibilitatea la $k_{\max}$, nu un singur număr (Seminarul 3, problema B3)

Anexă: PCA cu primă de risc și prime în trei etape

- **RP-PCA** (Risk-Premium PCA, PCA cu primă de risc, [Lettau & Pelger \(2020\)](#)): componentele principale ale matricei $\frac{1}{T}X^\top X + \gamma \bar{x}\bar{x}^\top$
 - ▶ $\gamma = -1$ dă PCA pe covarianță; $\gamma > -1$ favorizează și factorii care explică randamentele medii
 - ▶ În datele lor găsește factori cu rapoarte Sharpe mai mari și erori de evaluare mai mici decât PCA
- **Estimatorul în trei etape** ([Giglio & Xiu \(2021\)](#)): prima unui factor observat g_t când modelul omite factori
 - ▶ (1) PCA pe randamentele activelor de test; (2) regresia transversală a mediilor pe valorile beta latente; (3) regresia lui g_t pe factorii latenți și transferul primelor lor la g_t
- Ambele păstrează baza statistică a PCA, dar urmăresc explicarea randamentelor medii, nu doar a varianței; IPCA adaugă caracteristicile

Anexă: IPCA și factorii criptoactivelor

- Titlul articolului IPCA, [Kelly, Pruitt & Su \(2019\)](#): „Characteristics are covariances” (caracteristicile sînt covarianțe)
- În datele lor pentru acțiuni americane, cîțiva factori IPCA evaluează secțiunea transversală mai bine decît modelele cu tot atîția factori observabili
- Termenul alfa Γ_α devine ne semnificativ: caracteristicile prezic randamentele pentru că măsoară expunerea la risc
- IPCA leagă PCA (statistica) de sortările după caracteristici (Fama–French): beta variabil în timp, puțini factori
- Criptoactive: factorii piață, mărime și momentum evaluează secțiunea transversală a monedelor ([Liu, Tsyvinski & Wu \(2022\)](#)); reducerea dimensionalității pe caracteristicile randamentelor criptoactivelor și activelor tradiționale: [Pele et al. \(2023\)](#), [Jheng et al. \(2026\)](#)
- Curs avansat:  [Multivariate Statistical Analysis](#)

Anexă: studiu de caz, date și construcție

- **Date** (Secțiunea II): 153 de factori în 93 de țări; 138 din lista alcătuită de [Hou, Xue & Zhang \(2020\)](#) și 15 din alte studii; randamente americane din 1926, majoritatea piețelor dezvoltate din 1986; toate exprimate în dolari americani, în exces față de rata titlurilor de stat americane pe termen scurt
 - ▶ În fiecare țară, lunar: sortare în terțile după caracteristică, cu praguri calculate excluzând firmele cu microcapitalizare; ponderi după capitalizarea plafonată la percentila 80 a NYSE; cumpărarea terțilei cu randamentul așteptat mai mare în studiul inițial; deținere timp de o lună
 - ▶ Cel puțin 5 acțiuni în fiecare dintre portofoliile long și short și 60 de observații lunare; fiecare factor este scalat la o volatilitate idiosincratică anuală de 10%
 - ▶ 13 teme: grupare ierarhică a factorilor americani, distanța 1— corelația reziduurilor CAPM, criteriul Ward (Secțiunea II.B)
- **Modelul** (Secțiunea I): $f_{i,t} = \alpha_i + \beta_i r_t^m + \varepsilon_{i,t}$; valorile alfa $\alpha_i = c_j + s_n + w_i$ (tema j , semnalul n , factorul i ; ec. 21), media a priori 0
 - ▶ Varianța a priori $\Omega = MM^\top \tau_c^2 + ZZ^\top \tau_s^2 + I\tau_w^2$ (ec. 23); media a posteriori $(\Omega^{-1} + T\Sigma^{-1})^{-1} T\Sigma^{-1} \hat{\alpha}$ (Propoziția 4)
 - ▶ Bayes empiric: τ_c, τ_s, τ_w prin verosimilitate maximă pentru $\hat{\alpha} \sim N(0, \Omega + \hat{\Sigma}/T)$ (Secțiunea I.C.2)
- **Rata de replicare**: ponderea factorilor semnificativi în articolul original a căror alfa este semnificativă aici; descoperire bayesiană dacă media a posteriori / abaterea standard a posteriori $\geq 1,96$ (ec. 26)

Anexă: studiu de caz, rezultatele complete

- Rate de replicare (Figura 1): Hou, Xue & Zhang (2020) 35,0%; SUA, randament brut 55,6%; semnificativi inițial 61,3%; alfa CAPM 82,4%; Benjamini–Yekutieli 75,6%; Bayes empiric 82,4%; global, Bayes empiric 82,4%
- OLS: 98 din 119 factori americani; Benjamini–Yekutieli cere $|t| > 2,7$ (Figura 4)
- FDR bayesian 0,1%, interval de 95% [0, 1%]; ponderea așteptată a factorilor adevărați 94% (Secțiunea III.C)
- Firme cu capitalizare foarte mare și mare: 77,3% și 79,8% (Figura 5); 11 din 13 teme cel puțin 50%, toate în afară de îndatorare redusă și mărime: rezultatul nu este un artefact al microcapitalizărilor
- Alfa medie 0,49% pe lună în eșantion, 0,26% după eșantionul original: –47%; panta regresiei valorilor alfa ulterioare pe cele din eșantionul inițial este 0,26 (Figura 8), față de circa 0,9 așteptat doar din shrinkage
- Raportul Sharpe (lunar) al portofoliului tangent, SUA 1972–2020: piața 0,13, toți factorii 0,80 (Figura 14)

Anexă: studiu de caz, replicarea din curs în detaliu

- Benjamini–Yekutieli este cel mai strict, ca în ratele americane din articol: 82,4%, 75,6%, 82,4% (Figura 1)
- Emisiunile nete de acțiuni se apropie de tema lor: 0,44% → 0,27% pe lună
- Abaterea standard a posteriori 0,07%–0,10%, față de eroarea standard OLS 0,11%: fiecare temă cumulează informația factorilor ei
- **Dispersia a priori:** $\hat{\tau}_c = 0,28\%$, $\hat{\tau}_w = 0,04\%$ pe lună, față de 0,35% și 0,21% în Tabelul I; cu 15 semnale rămîne puțină dispersie specifică factorilor
- **Teme:** cele 15 semnale se încadrează în 8 dintre cele 13 teme ale articolului (5 în valoare, 3 în risc scăzut, 2 în investiții); cu o singură temă comună, rata Bayes empiric este 100%

Anexă: studiu de caz, limite precizate de autori și extinderi

▣ Limite precizate de autori

- ▶ CAPM este singurul reper: factorii de îndatorare redusă nu trec testul alfa CAPM, dar contează împreună cu celelalte teme (Secțiunea III.A)
- ▶ Caracteristicile sînt construite unitar, uneori altfel decît în articolul original (Secțiunea II.C)
- ▶ Factorii nepublicați deplasează distribuția a priori: în scenariile analizate de [Harvey, Liu & Zhu \(2016\)](#), rata pentru SUA scade la 81,5% și 79,8% (Figura 10)

▣ Completarea replicării de curs (Seminarul 3, C3): justificați semnul fiecărui factor pe baza studiului inițial, comparați dendrograma cu temele articolului, adăugați FDR bayesian și panta după eşantion (Figura 8)

▣ Datele și codul articolului: jkpfactors.com, github.com/bkelly-lab/ReplicationCrisis

Anexă: bucla descoperirii, prompturi reutilizabile (1/2)

□ Literatură

- ▶ Rezumă dovezile din 2016 încoace despre scăderea după publicare și replicarea randamentelor anomaliilor. Pentru fiecare lucrare: DOI, eşantion, numărul de factori, estimația principală, identificarea scăderii. Marchează intrările nesigure.
- ▶ Verificați fiecare DOI în Crossref; verificați fiecare cifră principală în rezumat

□ Ipoteză

- ▶ Compară data mining-ul, arbitrajul informat de publicare și riscul variabil în timp ca explicații ale scăderii. Pentru fiecare: tiparul prezis între perioadele din eşantion, după eşantion și după publicare, și între acțiunile cu limite mari vs mici ale arbitrajului.

□ Date și cod

- ▶ Încarcă factorul lunar de momentum din Kenneth French Data Library; din 1965, regresează MOM pe o variabilă dummy după eşantion (1990-01 până la 1993-03) și una după publicare (din 1993-04), cu erori Newey-West.
- ▶ Replicați întâi o cifră cunoscută: momentum $t = 5,53$ înainte de 2000 și 0,75 după (graficul pe subperioade)

Anexă: bucla descoperirii, prompturi reutilizabile (2/2)

▣ Robustețe

- ▶ Scrie un plan de robustețe preînregistrat: cite o dată de publicare pentru fiecare factor, corecția Holm între factori, excluderea crahului de momentum din 2009, data working paper-ului în locul datei din revistă și perioada 1927-1962 ca placebo pentru Mkt-RF, SMB, HML și MOM (RMW și CMA încep în iulie 1963).

▣ Critică

- ▶ Evaluează critic: un factor, o dată de publicare, $t = -1,45$. Care este puterea de a detecta o scădere de 58% și de ce o schimbă combinarea mai multor anomalii?

▣ Raport

- ▶ Media din eșantion, ambele variabile dummy cu erori Newey–West, placebo-ul, versiunea datelor (data descărcării)
- ▶ Factori combinați: erori robuste la corelația dintre factori în aceeași lună și la autocorelare
- ▶ Prompturile care au influențat o decizie întră în AI_USE.md

- ▣ Asistentul enumeră specificațiile; omul fixează dinainte care dintre ele contează

Anexă: ce verifică cercetătorul

- **Data greșită a evenimentului:** data încheierii eșantionului, data difuzării documentului de lucru și data publicării în revistă sînt diferite
 - ▶ test: citiți-le din lucrarea însăși; Jegadeesh–Titman: eșantionul se termină în 1989, publicat în martie 1993
- **Alegerea factorului după ce a scăzut:** fixați dinainte mulțimea factorilor; Holm sau BH pe toți
- **Randamente autocorelate, cu crahuri:** erori Newey–West; rulați din nou fără 2009
- **Versiunile datelor:** biblioteca de factori este revizuită retroactiv
 - ▶ test: notați data descărcării; reproduceți statisticile t pe subperioade din capitol
- **Literatură citată greșit:** o greșeală frecventă dă 58% drept scăderea în afara eșantionului; este cea de după publicare (26% în afara eșantionului)
- **Putere mică:** un singur factor respinge rar; raportați intervalul de încredere al scăderii, nu doar semnul ei

Anexă: aprofundare și cod

Cursuri avansate pe quantinar.com

- ▣  Generalized Method of Moments
- ▣  Multivariate Statistical Analysis

Cod și date

- ▣ Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_03
- ▣ Datele factorilor: [Kenneth French Data Library](#)

Bibliografie (1/7)

- ▣ Ahn, S.C., Horenstein, A.R. (2013). Eigenvalue ratio test for the number of factors. *Econometrica*, 81(3), 1203–1227.
- ▣ Anatolyev, S., Mikusheva, A. (2022). Factor models with many assets: strong factors, weak factors, and the two-pass procedure. *Journal of Econometrics*, 229(1), 103–126.
- ▣ Ang, A., Liu, J., Schwarz, K. (2020). Using stocks or portfolios in tests of factor models. *Journal of Financial and Quantitative Analysis*, 55(3), 709–750.
- ▣ Bai, J., Ng, S. (2002). Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 191–221.
- ▣ Barillas, F., Shanken, J. (2018). Comparing asset pricing models. *Journal of Finance*, 73(2), 715–754.
- ▣ Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- ▣ Black, F. (1972). Capital market equilibrium with restricted borrowing. *Journal of Business*, 45(3), 444–455.
- ▣ Blume, M.E. (1971). On the assessment of risk. *Journal of Finance*, 26(1), 1–10.
- ▣ Benjamini, Y., Yekutieli, D. (2001). The control of the false discovery rate in multiple testing under dependency. *Annals of Statistics*, 29(4), 1165–1188.
- ▣ Bryzgalova, S., Huang, J., Julliard, C. (2023). Bayesian solutions for the factor zoo: we just ran two quadrillion models. *Journal of Finance*, 78(1), 487–557.

Bibliografie (2/7)

- ▣ Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). *The Econometrics of Financial Markets*. Princeton University Press.
- ▣ Carhart, M.M. (1997). *On persistence in mutual fund performance*. *Journal of Finance*, 52(1), 57–82.
- ▣ Chen, A.Y., Zimmermann, T. (2022). *Open source cross-sectional asset pricing*. *Critical Finance Review*, 11(2), 207–264.
- ▣ Cochrane, J.H. (2011). *Presidential address: discount rates*. *Journal of Finance*, 66(4), 1047–1108.
- ▣ Daniel, K., Moskowitz, T.J. (2016). *Momentum crashes*. *Journal of Financial Economics*, 122(2), 221–247.
- ▣ Fama, E.F., French, K.R. (1992). *The cross-section of expected stock returns*. *Journal of Finance*, 47(2), 427–465.
- ▣ Fama, E.F., French, K.R. (1993). *Common risk factors in the returns on stocks and bonds*. *Journal of Financial Economics*, 33(1), 3–56.
- ▣ Fama, E.F., French, K.R. (2015). *A five-factor asset pricing model*. *Journal of Financial Economics*, 116(1), 1–22.
- ▣ Fama, E.F., MacBeth, J.D. (1973). *Risk, return, and equilibrium: empirical tests*. *Journal of Political Economy*, 81(3), 607–636.
- ▣ Fan, J., Liao, Y., Yao, J. (2015). *Power enhancement in high-dimensional cross-sectional tests*. *Econometrica*, 83(4), 1497–1541.

Bibliografie (3/7)

- ▣ Feng, G., Giglio, S., Xiu, D. (2020). Taming the factor zoo: a test of new factors. *Journal of Finance*, 75(3), 1327–1370.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, ed. a 5-a. Springer.
- ▣ Frazzini, A., Pedersen, L.H. (2014). Betting against beta. *Journal of Financial Economics*, 111(1), 1–25.
- ▣ Gibbons, M.R., Ross, S.A., Shanken, J. (1989). A test of the efficiency of a given portfolio. *Econometrica*, 57(5), 1121–1152.
- ▣ Giglio, S., Xiu, D. (2021). Asset pricing with omitted factors. *Journal of Political Economy*, 129(7), 1947–1990.
- ▣ Hansen, L.P. (1982). Large sample properties of generalized method of moments estimators. *Econometrica*, 50(4), 1029–1054.
- ▣ Hansen, L.P., Jagannathan, R. (1997). Assessing specification errors in stochastic discount factor models. *Journal of Finance*, 52(2), 557–590.
- ▣ Härdle, W.K., Simar, L. (2019). *Applied Multivariate Statistical Analysis*, ed. a 5-a. Springer.
- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.

Bibliografie (4/7)

- ▣ Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- ▣ Hou, K., Xue, C., Zhang, L. (2015). Digesting anomalies: an investment approach. *Review of Financial Studies*, 28(3), 650–705.
- ▣ Hou, K., Xue, C., Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133.
- ▣ Jagannathan, R., Wang, Z. (1998). An asymptotic theory for estimating beta-pricing models using cross-sectional regression. *Journal of Finance*, 53(4), 1285–1309.
- ▣ Jegadeesh, N., Titman, S. (1993). Returns to buying winners and selling losers: implications for stock market efficiency. *Journal of Finance*, 48(1), 65–91.
- ▣ Jensen, M.C. (1968). The performance of mutual funds in the period 1945–1964. *Journal of Finance*, 23(2), 389–416.
- ▣ Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance?. *Journal of Finance*, 78(5), 2465–2518.
- ▣ Jheng, S.-L., Găman, Ș., Conda, A., Pele, D.T., Härdle, W.K., Teng, H.-W., Osterrieder, J. (2026). Crypto currency returns. Document de lucru SSRN.
- ▣ Kan, R., Robotti, C., Shanken, J. (2013). Pricing model performance and the two-pass cross-sectional regression methodology. *Journal of Finance*, 68(6), 2617–2649.
- ▣ Kan, R., Zhang, C. (1999). Two-pass tests of asset pricing models with useless factors. *Journal of Finance*, 54(1), 203–235.

Bibliografie (5/7)

- ▣ Kelly, B.T., Pruitt, S., Su, Y. (2019). Characteristics are covariances: a unified model of risk and return. *Journal of Financial Economics*, 134(3), 501–524.
- ▣ Kleibergen, F. (2009). Tests of risk premia in linear factor models. *Journal of Econometrics*, 149(2), 149–173.
- ▣ Kozak, S., Nagel, S., Santosh, S. (2020). Shrinking the cross-section. *Journal of Financial Economics*, 135(2), 271–292.
- ▣ Lettau, M., Pelger, M. (2020). Factors that fit the time series and cross-section of stock returns. *Review of Financial Studies*, 33(5), 2274–2325.
- ▣ Lewellen, J., Nagel, S., Shanken, J. (2010). A skeptical appraisal of asset pricing tests. *Journal of Financial Economics*, 96(2), 175–194.
- ▣ Lintner, J. (1965). The valuation of risk assets and the selection of risky investments in stock portfolios and capital budgets. *Review of Economics and Statistics*, 47(1), 13–37.
- ▣ Liu, Y., Tsyvinski, A., Wu, X. (2022). Common risk factors in cryptocurrency. *Journal of Finance*, 77(2), 1133–1177.
- ▣ Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- ▣ McLean, R.D., Pontiff, J. (2016). Does academic research destroy stock return predictability?. *Journal of Finance*, 71(1), 5–32.

Bibliografie (6/7)

- ▣ Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- ▣ Onatski, A. (2010). Determining the number of factors from empirical distribution of eigenvalues. *Review of Economics and Statistics*, 92(4), 1004–1016.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *The European Journal of Finance*, 29(10), 1064–1105.
- ▣ Pesaran, M.H., Yamagata, T. (2024). Testing for alpha in linear factor pricing models with a large number of securities. *Journal of Financial Econometrics*, 22(2), 407–460.
- ▣ Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- ▣ Roll, R. (1977). A critique of the asset pricing theory's tests. Part I. *Journal of Financial Economics*, 4(2), 129–176.
- ▣ Ross, S.A. (1976). The arbitrage theory of capital asset pricing. *Journal of Economic Theory*, 13(3), 341–360.
- ▣ Shanken, J. (1992). On the estimation of beta-pricing models. *Review of Financial Studies*, 5(1), 1–33.
- ▣ Sharpe, W.F. (1964). Capital asset prices: a theory of market equilibrium under conditions of risk. *Journal of Finance*, 19(3), 425–442.

Bibliografie (7/7)

- Vasicek, O.A. (1973). A note on using cross-sectional information in Bayesian estimation of security betas. *Journal of Finance*, 28(5), 1233–1239.
- Date: Kenneth R. French Data Library, mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html.