



Modelarea piețelor financiare

Capitolul 4: Optimizarea portofoliului



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economic

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (inteligență artificială)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- BVB: Bursa de Valori București
- CAPM: Capital Asset Pricing Model (modelul de evaluare a activelor financiare)
- DSR: Deflated Sharpe Ratio (raportul Sharpe deflatat)
- ERC: Equal Risk Contribution portfolio (portofoliul cu contribuții egale la risc)
- ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- FDR: False Discovery Rate (rata descoperirilor false)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- GLS: Generalised Least Squares (metoda celor mai mici pătrate generalizate)
- GMV: Global Minimum-Variance portfolio (portofoliul de varianță minimă globală)
- GMV-LO: Global Minimum-Variance portfolio, Long-Only (portofoliul de varianță minimă globală, doar poziții long)
- GMV-LW: Global Minimum-Variance portfolio with Ledoit–Wolf covariance (portofoliul de varianță minimă globală cu covarianța Ledoit–Wolf)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HRP: Hierarchical Risk Parity (paritatea ierarhică a riscului)
- HYG: iShares iBoxx High Yield Corporate Bond ETF (ETF de obligațiuni corporative americane cu randament ridicat, sub rating investițional)
- IEF: iShares 7–10 Year Treasury Bond ETF (ETF de obligațiuni de stat americane cu scadența 7–10 ani)
- LO: Long-Only, no short sales (doar poziții long, fără vânzări în lipsă)
- LQD: iShares iBoxx Investment Grade Corporate Bond ETF (ETF de obligațiuni corporative americane cu rating investițional)
- ML: Machine Learning (învățare automată)
- MV: Mean–Variance tangency portfolio estimated from sample moments (portofoliul tangent medie–varianță estimat din momentele de eșantion)
- MV-LO: Mean–Variance tangency portfolio, Long-Only (portofoliul tangent medie–varianță, doar poziții long)
- NYSE: New York Stock Exchange (Bursa din New York)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- OMV: Österreichische Mineralölverwaltung (Administrația austriacă a uleiurilor minerale (grupul OMV))

Acronime folosite în acest material (2/2)

- OOS: Out-Of-Sample (în afara eșantionului)
- POET: Principal Orthogonal complement Thresholding (estimatorul prin prag aplicat complementului ortogonal al componentelor principale)
- SUA: Statele Unite ale Americii

Întrebarea și traseul capitolului

Întrebarea

- Un **portofoliu** este un vector de ponderi $w = (w_1, \dots, w_N)^\top$ cu $w^\top \mathbf{1} = 1$; optimizarea alege w care maximizează un criteriu, sub restricții
- Optimul are formă închisă când mediile și covarianțele sînt cunoscute, dar estimarea lui este dificilă
 - ▶ Optimizatorul atribuie ponderi mari exact acolo unde erorile de estimare sînt cele mai mari
 - ▶ 16 active: $16 + 136 = 152$ de parametri, estimați din 60 de observații lunare ale unui vector de randamente de dimensiune 16
- Întrebarea capitolului: poate o regulă estimată să depășească ponderile egale în afara eșantionului, după costuri?

Traseu

- Partea I: teoria medie–varianță, riscul de estimare, shrinkage-ul covarianței, Black–Litterman
- Partea a II-a: risk parity și HRP, teste în afara eșantionului, portofolii BVB, un studiu de caz, un exemplu complet al buclei de cercetare asistate de AI
- Detaliile tehnice sînt în [▶ Anexă](#); manual: [Franke, Härdle & Hafner \(2019\)](#), Partea I

Date, active și reperul 1/N

Univers	Active	Randamente	Monedă
Sectoare	9 ETF-uri sectoriale din SUA: XLB, XLE, XLF, XLI, XLK, XLP, XLU, XLV, XLY	1999/01 – 2026/07	USD
Multi-active	SPY, EFA, EEM (acțiuni); TLT, IEF (titluri de stat); LQD, HYG (credit); GLD (aur)	2007/05 – 2026/07	USD
Combinat	9 sectoare + cele 7 ETF-uri multi-active, fără SPY (16 ETF-uri)	2007/05 – 2026/07	USD
România	8 blue chips BVB: TLV, SNP, BRD, TGN, SNG, SNN, EL, TEL; BET, BET-TR	2014/10 – 2026/08	RON

- Randamente lunare simple din prețurile de sfârșit de lună, în zilele comune de tranzacționare; ETF-uri și acțiuni cu dividendele reinvestite; BET este indice de preț, BET-TR reinvestește dividendele
- Randamente în exces față de titlul de stat la o lună ([Kenneth French Data Library](#)); BVB: $R_f = 0$
- Sectoare: XLB materiale, XLE energie, XLF financiar, XLI industrie, XLK tehnologie, XLP bunuri de consum de bază, XLU utilități, XLV sănătate, XLY consum discreționar
- Multi-active: SPY (S&P 500), EFA (acțiuni din țări dezvoltate, fără SUA și Canada), EEM (acțiuni din piețe emergente), TLT (titluri de stat SUA, peste 20 de ani), IEF (titluri de stat SUA, 7–10 ani), LQD (obligațiuni corporative investment grade), HYG (obligațiuni corporative high yield), GLD (aur)
- BVB: TLV Banca Transilvania, SNP OMV Petrom, BRD BRD–Groupe Société Générale, TGN Transgaz, SNG Romgaz, SNN Nuclearelectrica, EL Electrica, TEL Transelectrica
- 1/N: ponderi egale $w_i = 1/N$, reechilibrate lunar; nicio estimare, reperul oricărei comparații

Notație

- ▣ Randament simplu $R_{i,t} = P_{i,t}/P_{i,t-1} - 1$, $P_{i,t}$ prețul de la sfârșitul lunii al activului i ; randament în exces $R_{i,t}^e = R_{i,t} - R_{f,t}$, $R_{f,t}$ rata fără risc
- ▣ N active; w : vectorul ponderilor portofoliului; μ : vectorul randamentelor (în exces) așteptate; Σ : matricea lor de covarianță $N \times N$; 1 : vectorul de unu; media portofoliului $w^\top \mu$, varianța $w^\top \Sigma w$
- ▣ **Raportul Sharpe** ([Sharpe \(1966\)](#)): $SR_p = \mathbb{E}[R_p^e]/\sigma(R_p^e)$, randamentul mediu în exces pe unitatea de volatilitate σ ; cifrele lunare se anualizează cu $\times 12$ (media) și $\times \sqrt{12}$ (volatilitatea, Sharpe)
- ▣ **Drawdown maxim**: $\min_t (W_t / \max_{s \leq t} W_s - 1)$, cea mai mare scădere a averii W_t față de un maxim anterior
- ▣ **În afara eșantionului** (OOS): ponderile deținute în luna t folosesc doar date pînă în luna $t - 1$
- ▣ Regulile capitolului: MV (tangent din momente de eșantion), GMV (varianță minimă globală), versiunile lor long-only MV-LO și GMV-LO, GMV-LW (GMV cu shrinkage), ERC, HRP și 1/N


Problema lui Markowitz

- ▣ **Markowitz (1952)**: investitorii țin cont de media și de varianța randamentelor portofoliului
- ▣ **Frontiera de varianță minimă**: varianța minimă pentru fiecare medie-țintă m ; ramura ei superioară, $m \geq \mu_{\text{GMV}}$ (media portofoliului GMV), este **frontiera eficientă**

$$\min_w w^\top \Sigma w \quad \text{cu} \quad w^\top \mu = m, \quad w^\top \mathbf{1} = 1$$

- ▶ Obiectivul: varianța portofoliului; restricțiile: media-țintă m și investirea integrală (ponderile însumează 1)
- ▣ Forma cu utilitate, aversiunea la risc $\gamma > 0$: $\max_w w^\top \mu - \frac{\gamma}{2} w^\top \Sigma w$ cu $w^\top \mathbf{1} = 1$; când γ variază, soluția parcurge exact ramura eficientă
- ▣ Ponderile pot fi negative: o **vânzare în lipsă** (vânzarea unui activ împrumutat)

Două active: efectul corelației asupra diversificării



- Două active, corelația ρ :

$$\sigma_p^2 = w^2\sigma_1^2 + (1-w)^2\sigma_2^2 + 2w(1-w)\rho\sigma_1\sigma_2$$
 w : ponderea activului 1, σ_1 , σ_2 : volatilitățile, σ_p : volatilitatea portofoliului
- Minimul este la $w^* = \frac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}$
- SPY și TLT, lunar 2002–2026: $\rho = -0,10$, $w^* = 46\%$ SPY, volatilitate 9,4% față de 14,7% și 13,5%
- Cu cât ρ este mai mic, cu atât curba este mai convexă spre stînga; la $\rho = 1$ nu există diversificare
- Corelația variabilă în timp: [Capitolul 6](#)

Portofoliile GMV și tangent pentru N active

- GMV: $\min_w w^\top \Sigma w$ cu $w^\top \mathbf{1} = 1$; lagrangianul $\mathcal{L} = w^\top \Sigma w - \lambda(w^\top \mathbf{1} - 1)$, Σ pozitiv definită
 - ▶ λ : multiplicatorul Lagrange al restricției de buget; condiția de ordinul întâi $2\Sigma w = \lambda \mathbf{1}$, deci $w = \frac{\lambda}{2} \Sigma^{-1} \mathbf{1}$; restricția dă $\frac{\lambda}{2} = 1/A$, $A = \mathbf{1}^\top \Sigma^{-1} \mathbf{1}$
- Tangent: se maximizează $w^\top \mu / \sqrt{w^\top \Sigma w}$, μ randamentele așteptate **în exces**; condiția $\mu \propto \Sigma w$ dă $w \propto \Sigma^{-1} \mu$ ($\propto$: proporțional cu); θ : raportul Sharpe maxim

	GMV	Tangent (MV)
Ponderi	$w_{\text{GMV}} = \Sigma^{-1} \mathbf{1} / A$	$w_{\text{MV}} = \Sigma^{-1} \mu / B$, $B = \mathbf{1}^\top \Sigma^{-1} \mu$
Rezultat	varianța $\sigma_{\text{GMV}}^2 = 1/A$	Sharpe la pătrat $\theta^2 = \mu^\top \Sigma^{-1} \mu$
Necesită	doar Σ	μ și Σ ; Sharpe $\text{sign}(B) \theta$

- $\Sigma^{-1} \mu / B$ normalizat este maximul doar dacă $B > 0$; $B < 0$ dă portofoliul cu Sharpe minim, iar pentru $B = 0$ nu există soluție complet investită

Separarea și frontiera în formă închisă



James Tobin, Premiul Nobel pentru
economie 1981


Foto: autor necunoscut (1962);

domeniu public; Wikimedia Commons

- **Tobin (1958)**: se adaugă un activ fără risc cu randamentul R_f ; fiecare investitor deține **același** portofoliu riscant, portofoliul tangent, combinat cu numerar sau cu împrumut
 - ▶ Aversiunea la risc schimbă doar combinația de-a lungul dreptei de alocare a capitalului: **separarea în două fonduri**, puntea spre CAPM ([Capitolul 3](#))
- **Merton (1972)**: cu vânzări în lipsă, frontiera este o hiperbolă; Σ pozitiv definită, μ neproportional cu 1
 - ▶ $A = 1^\top \Sigma^{-1} 1$, $B = 1^\top \Sigma^{-1} \mu$, $C = \mu^\top \Sigma^{-1} \mu$, $D = AC - B^2 > 0$

$$\sigma^2(m) = \frac{Am^2 - 2Bm + C}{D}$$
- $\sigma^2(m)$: cea mai mică varianță posibilă cu media m , o parabolă în m ; GMV se află la $m = B/A$, $\sigma^2 = 1/A$; orice portofoliu de pe frontieră combină oricare două portofolii distincte de pe frontieră, de exemplu GMV și tangentul (dacă $B \neq 0$)

Frontiera sectoarelor din SUA



- Randamente lunare în exces, ianuarie 1999 – iulie 2026 ($T = 331$); toți parametrii estimați pe tot eșantionul: o imagine **în eșantion**
- Tangent: Sharpe 0,66; GMV: 0,57 (volatilitate 11,1%); 1/N: 0,54
- Ponderile tangente: $-0,37$ financiar, $-0,21$ materiale, $+0,37$ sănătate: poziții short
- Tangent long-only: Sharpe 0,61; materialele, financiarul și industria primesc exact zero, o **soluție de colț**
- Câștigul față de 1/N este mic chiar dacă se folosește întregul eșantion istoric

Restricții

- ▣ **Long-only (LO):** $w_i \geq 0$; fără formă închisă, se rezolvă prin programare pătratică
- ▣ Limite pe poziții: $w_i \leq 0,2$; limite pe sectoare sau clase de active: $\sum_{i \in G} w_i \leq c_G$, G un grup de active, c_G plafonul lui
- ▣ Limită de levier: $\sum_i |w_i| \leq L$; $\sum_i |w_i|$: expunerea brută, $L = 1$ înseamnă fără vânzări în lipsă
- ▣ **Frost & Savarino (1988)**: restricționarea ponderilor a îmbunătățit rezultatele în afara eșantionului; explicația ține de shrinkage (secțiunea următoare)
- ▣ MV-LO și GMV-LO sînt versiunile long-only ale MV și GMV

Imprecizia mediilor estimate: argumentul lui Merton




Robert C. Merton, Premiul
Nobel pentru economie 1997

Foto: Digarnick (2006); domeniu
public; Wikimedia Commons

- **Merton (1980)**: Y ani observați de h ori pe an, randamente i.i.d. din distribuția Normală (o difuzie) cu media anuală μ și varianța σ^2
 - ▶ $\text{Var}(\hat{\mu}) = \sigma^2/Y$: nu depinde de h ; ajută doar **lungimea** eșantionului
 - ▶ $\text{Var}(\hat{\sigma}^2) \approx 2\sigma^4/(hY) \rightarrow 0$ când $h \rightarrow \infty$ (distribuția Normală; în general $(\kappa - 1)\sigma^4/(hY)$, κ kurtosisul): varianța se estimează mai precis pe măsură ce crește frecvența
- SPY, $Y = 24$, $\sigma = 14,7\%$: eroarea standard 3,0%, intervalul de 95% [5,8%; 17,6%] pentru o medie de 11,7%
- O eroare standard de 1% cere $(0,147/0,01)^2 \approx 217$ ani
- **Chopra & Ziemba (1993)**: erorile de estimare a mediilor costă de circa zece ori mai mult decât cele ale varianțelor; regulile care nu folosesc medii (GMV, risk parity) sînt mai robuste

Maximizarea erorii: frontiere estimate față de frontiere realizate



- **Michaud (1989)**: optimizatorii sînt **maximizatori ai erorii de estimare**; **Best & Grauer (1991)**: o mică schimbare într-o medie mută multe ponderi
- Parametrii adevărați = momentele sectoarelor 1999–2026; se extrag 60 de luni din distribuția Normală, se optimizează, se evaluează cu parametrii adevărați
- Roșu: frontierele estimate, sistematic prea optimiste; verde: aceleași portofolii cu parametrii adevărați, toate sub frontiera adevărată
- 2000 de portofolii tangente simulate: Sharpe maxim estimat median 1,56, Sharpe adevărat median 0,30, optimul adevărat 0,66
- 96% au Sharpe adevărat sub $1/N$ (0,54), 7,5% sub zero; în 11% din eșantioane $1^T \hat{\Sigma}^{-1} \hat{\mu} < 0$

 MFM_ch4_estimation_error

Raportul Sharpe estimat direct este deplasat

- Randamente i.i.d. $N(\mu, \Sigma)$, $\hat{\mu}$ și $\hat{\Sigma}$ de verosimilitate maximă, $\hat{\theta}^2 = \hat{\mu}^\top \hat{\Sigma}^{-1} \hat{\mu}$, pătratul raportului Sharpe maxim în eșantion; T luni, N active (Kan & Zhou (2007); momentele Wishart în [Anexă](#))

$$\mathbb{E}[\hat{\theta}^2] = \frac{T}{T - N - 2} \left(\theta^2 + \frac{N}{T} \right) = \frac{T\theta^2 + N}{T - N - 2}, \quad T > N + 2$$


- Sectoare: $N = 9$, $T = 60$, θ adevărat = 0,66 pe an: $\mathbb{E}[\hat{\theta}^2]$ corespunde unui Sharpe de 1,65 pe an, echivalentul analitic al mediane simulate 1,56
- Estimatorul nedeplasat al lui θ^2 : $\hat{\theta}_u^2 = [(T - N - 2)\hat{\theta}^2 - N]/T$
 - Poate fi negativ; trunchierea la zero dă un estimator nenegativ, dar deplasat în sus, iar $\sqrt{\hat{\theta}_u^2}$ nu este nedeplasat pentru θ
- Sectoare, tot eșantionul ($T = 331$): $\hat{\theta} = 0,66$ estimat direct, $\sqrt{\hat{\theta}_u^2} = 0,31$ pe an după corecție: peste jumătate din raportul Sharpe în eșantion se datorează zgomotului, chiar și pe 27 de ani
- Ponderile tangente sînt coeficienții OLS ai regresiei lui 1 pe randamente (Britten-Jones (1999); [Anexă](#), Seminarul A2 și B9)

Ponderi instabile



- Nouă ETF-uri sectoriale; în fiecare lună ponderile folosesc doar ultimele 60 de luni; panoul de sus trunchiat la ± 6
- MV: expunere brută mediană $\sum_i |w_i| = 4,9$, peste 3 în 90% din luni; cea mai mare pondere individuală 26 în valoare absolută
- Salturi extreme în 2004–2006 și 2009: numitorul $1^\top \hat{\Sigma}^{-1} \hat{\mu}$ este aproape de zero, deci ponderile tangente au cozi foarte groase
 - Negativ în 12 din 271 de ferestre: MV deține atunci portofoliul cu Sharpe minim
- GMV-LW (jos): expunere brută 1,5, cea mai mare pondere 0,94
- Ponderile instabile înseamnă turnover mare, deci costuri mari de tranzacționare

Lungimea ferestrei necesară pentru a depăși 1/N



- DeMiguel, Garlappi & Uppal (2009): 14 modele pe 7 seturi de date; niciunul nu depășește consecvent $1/N$ în raport Sharpe, randament echivalent cert sau turnover; pentru 25 de active, calibrarea lor ar necesita circa 3000 de luni
- Aici: 300 de eșantioane simulate pentru fiecare fereastră, parametrii populației = momentele sectoarelor
- MV depășește $1/N$ abia la 480 de luni (40 de ani): Sharpe adevărat median 0,55 față de 0,54; cu 60 de luni 0,31
- MV-LO, GMV, GMV-LW sînt aproape de $1/N$ de la 60 de luni; ERC este aproape insensibil la lungimea ferestrei, 0,56
- În această calibrare $1/N$ este aproape eficient (tangenta adevărat 0,66): rezultat de simulare, nu un test empiric

 MFM_ch4_window_length

Limitele matricei de covarianță de eșantion


- ▣ Valorile proprii de eșantion sînt prea dispersate: cele mari prea mari, cele mici prea mici
- ▣ **Numărul de condiționare**: cea mai mare valoare proprie împărțită la cea mai mică; o valoare mare înseamnă că Σ^{-1} amplifică zgomotul
- ▣ Optimizatorii inversează Σ , deci pun ponderi mari pe direcțiile cu cea mai mică varianță estimată
- ▣ Matricea de eșantion centrată are rangul cel mult $T - 1$: este singulară, deci neinvertibilă, ori de cîte ori $T \leq N$
- ▣ Reperul **Marchenko–Pastur** ([Marčenko & Pastur \(1967\)](#)): randamente i.i.d. cu $\Sigma = \sigma^2 I$; cînd $N, T \rightarrow \infty$ cu $N/T \rightarrow c \in (0, 1)$, valorile proprii de eșantion acoperă intervalul

$$[\lambda_-, \lambda_+] = [\sigma^2(1 - \sqrt{c})^2, \sigma^2(1 + \sqrt{c})^2]$$

- ▶ I : matricea identitate; λ_-, λ_+ : cea mai mică și cea mai mare valoare proprie produse de zgomotul pur; $c = 16/60 = 0,27$: banda $[0,23; 2,30]$ pentru o matrice de corelație ($\sigma^2 = 1$): un raport de zece între extreme, generat numai de zgomot
- ▶ [Laloux et al. \(1999\)](#): valorile proprii din afara benzii sînt candidate la structură; cele din interior nu se pot deosebi de zgomot doar prin această comparație

Valorile proprii de eşantion și banda de zgomot

Last 60-month window, Aug 2021 - Jul 2026



- Matrice de corelație ale randamentelor lunare în exces, ultima fereastră de 60 de luni (august 2021 – iulie 2026); banda colorată: $[\lambda_-, \lambda_+]$ pentru $\sigma^2 = 1$
- Doar valoarea proprie a pieței depășește λ_+ : 9,0 (56% din urma matricei) la 16 ETF-uri, 5,2 la nouă sectoare ($\lambda_+ = 1,92$); cu zgomotul rescalat la $\sigma^2 = 1 - \lambda_1/N$ (Laloux et al. (1999)), trei valori proprii depășesc banda în fiecare univers
- Șase din 16 valori proprii sînt **sub** bandă: combinații aproape fără risc, precum o poziție long TLT și short IEF; GMV le atribuie ponderi mari, deci, dacă ele sînt subestimate, este subestimat și riscul GMV

Estimatorul de shrinkage


- Matricea de eșantion S este trasă spre o țintă structurată F

$$\hat{\Sigma}_{\text{LW}} = \delta F + (1 - \delta) S, \quad 0 \leq \delta \leq 1$$

- Ținte

- Modelul cu un singur indice (al pieței): [Ledoit & Wolf \(2003\)](#)
 - Identitatea scalată: [Ledoit & Wolf \(2004a\)](#)
 - Corelația constantă, $f_{ii} = s_{ii}$ și $f_{ij} = \bar{r} \sqrt{s_{ii} s_{jj}}$ pentru $i \neq j$, $\bar{r}$ corelația medie de eșantion: [Ledoit & Wolf \(2004b\)](#), folosită aici
- δ echilibrează varianța lui S cu deplasarea lui F : date zgomotoase sau o țintă bună, δ mare; eșantioane lungi, $\delta \rightarrow 0$ (δ^* optim în [Anexă](#))

Shrinkage pe sectoarele din SUA



- Nouă ETF-uri sectoriale, randamente lunare în exces; ultima fereastră august 2021 – iulie 2026: $\delta = 0,24$; cele mai mici valori proprii cresc, cele mai mari rămân aproape neschimbate; numărul de condiționare $51,6 \rightarrow 32,5$
- δ pe ferestre mobile: media 0,43, între 0,19 și 1,00; $\delta = 1$ în primele ferestre, unde 60 de luni sînt prea puține pentru ca matricea de eșantion să fie preferabilă țintei
- GMV-LW: portofoliul GMV calculat cu $\hat{\Sigma}_{LW}$

Restricțiile ca formă de shrinkage

- ▣ Jagannathan & Ma (2003): GMV long-only este egal cu GMV fără restricții al unei matrice de covarianță modificate

$$\tilde{S} = S - (\lambda \mathbf{1}^\top + \mathbf{1} \lambda^\top), \quad \mathcal{L} = \frac{1}{2} \mathbf{w}^\top S \mathbf{w} - \lambda_0 (\mathbf{w}^\top \mathbf{1} - 1) - \lambda^\top \mathbf{w}$$

- ▶ $\lambda \geq 0$: multiplicatorii Lagrange ai restricțiilor $w_i \geq 0$ din $\mathcal{L}$; $\lambda_i > 0$ doar unde restricția este activă
- ▶ Condiția de ordinul întâi $S \mathbf{w} = \lambda_0 \mathbf{1} + \lambda$ și $\lambda^\top \mathbf{w} = 0$ dau $\tilde{S} \mathbf{w} = \lambda_0 \mathbf{1}$: condiția GMV pentru $\tilde{S}$
- ▣ $\tilde{s}_{ij} = s_{ij} - \lambda_i - \lambda_j$: o restricție activă pe activul i îi reduce covarianțele, ceea ce corectează în jos estimările mari
- ▣ Restricția „greșită” (fără vânzări în lipsă) poate reduce riscul în afara eșantionului; efectul este cel mai mare când covarianțele sînt estimate din puține observații

Shrinkage neliniar

- ▣ Shrinkage-ul liniar amestecă două matrice cu un singur δ ; shrinkage-ul **neliniar** păstrează vectorii proprii de eşantion şi corectează separat fiecare valoare proprie
 - ▶ Ledoit & Wolf (2017): calibrat pentru alegerea portofoliului; Ledoit & Wolf (2020): o formulă analitică, fără optimizare
- ▣ În afara eşantionului, fereastră de 60 de luni, volatilitatea GMV
 - ▶ Sectoare: eşantion 11,90%, liniar (corelație constantă) 11,80%, neliniar 11,62%
 - ▶ 16 ETF-uri: eşantion 4,06%, liniar 4,38%, neliniar 4,31%: neliniarul este mai bun decât shrinkage-ul liniar, dar nu şi decât matricea de eşantion
- ▣ O corelație constantă nu descrie nici perechile acțiuni–acțiuni (corelații pozitive), nici perechile acțiuni–obligațiuni (corelații negative): alegerea țintei contează (Seminarul 4, B4)
- ▣ Regulă practică: aplicați shrinkage, restricții sau ambele; nu inversați niciodată matricea de eşantion brută pentru un număr mare de active

De la shrinkage-ul covarianței la shrinkage-ul mediilor



Fischer Black (1938–1995)

Foto: Dalmatine, Wikipedia în limba engleză; domeniu public; Wikimedia

[Commons](#)

- Shrinkage-ul corectează $\hat{\Sigma}$; [Black & Litterman \(1992\)](#), dezvoltat la Goldman Sachs, contractă mediile spre cele implicate de un portofoliu **de referință** w_b
- Optimizarea inversă: un investitor medie–varianță cu aversiunea la risc δ_{RA} și acces la numerar deține $w^* = (\delta_{\text{RA}} \Sigma)^{-1} \mu$ în active riscante; randamentele care fac w_b optim sînt

$$\pi = \delta_{\text{RA}} \Sigma w_b$$


- π : randamente în exces **implicite** (de echilibru); cu ponderile pieței, ele sînt randamentele CAPM
- Aici: capitalizările sectoarelor nu sînt disponibile, deci $w_b = 1/N$, $\delta_{\text{RA}} = 2,5$
- Apoi se adaugă **opiniile** investitorului, ponderate cu încrederea în ele: ponderile se îndepărtează de reper doar unde există opinii

Opiniile și distribuția a posteriori

- K opinii: $P\mu = q + \epsilon$, $\epsilon \sim N(0, \Omega)$; a priori $\mu \sim N(\pi, \tau\Sigma)$
 - P : matrice $K \times N$, linia k = portofoliul opiniei k ; q : randamentele din opinii; Ω : incertitudinea lor; τ : scalează incertitudinea distribuției a priori π
- Media a posteriori: o medie ponderată cu preciziile; ponderile $w_{BL} = (\delta_{RA}\Sigma)^{-1}\mu_{BL}$

$$\mu_{BL} = [(\tau\Sigma)^{-1} + P^T\Omega^{-1}P]^{-1}[(\tau\Sigma)^{-1}\pi + P^T\Omega^{-1}q]$$
- Limite: $\Omega \rightarrow 0$ dă exact $P\mu_{BL} = q$; $\Omega \rightarrow \infty$ dă π ; fără opinii se obține chiar portofoliul de referință
- He & Litterman (2002): $\tau = 0,05$, $\Omega = \text{diag}(P\tau\Sigma P^T)$; când ponderile folosesc aceeași Σ , se modifică doar ponderile activelor din opinii
- Un activ, $\pi = 5\%$, $\tau\sigma^2 = 0,00128$, opinia 8% cu varianța 0,0004: $\mu_{BL} = 7,29\%$, ponderea opiniei 0,76
- Același estimator este o regresie GLS (mixtă) (Theil & Goldberger (1961); [► Anexă](#), Seminarul A5)

Black-Litterman pe sectoarele din SUA



- Σ din randamentele lunare în exces, august 2016 – iulie 2026; o opinie: XLK minus XLU = 3% pe an; implicit 2,2%, a posteriori 2,6% (media, pentru că Ω este egală cu varianța a priori a opiniei)
- Ponderi: XLK de la 11,1% la 14,4%, XLU de la 11,1% la 7,8%, restul neschimbate
 - Opinia este relativă ($P1 = 0$), deci ajustarea $\propto P^\top$ are suma zero, iar portofoliul rămîne complet investit
- Cu mediile de eșantion: XLK 21,3% pe an; ponderile MV +115% XLK, -68% XLY, -46% XLB

Contribuțiile la risc

- Volatilitatea este omogenă de gradul întâi în ponderi (Euler)

$$\sigma_p = \sum_{i=1}^N w_i \frac{\partial \sigma_p}{\partial w_i} = \sum_{i=1}^N \frac{w_i (\Sigma w)_i}{\sigma_p}$$

- Contribuția la risc** a activului i : $RC_i = w_i (\Sigma w)_i / \sigma_p$; cota procentuală $RC_i / \sigma_p = w_i (\Sigma w)_i / \sigma_p^2$
- Exemplu numeric, 50/50 în SPY și IEF (lunar 2002–2026, anualizat): $\sigma_1^2 = 0,02166$, $\sigma_2^2 = 0,00441$, $\sigma_{12} = -0,00098$
 - $(\Sigma w)_1 = 0,5(0,02166) + 0,5(-0,00098) = 0,01034$, $(\Sigma w)_2 = 0,5(-0,00098) + 0,5(0,00441) = 0,00172$
 - $\sigma_p^2 = 0,5(0,01034) + 0,5(0,00172) = 0,00603$, $\sigma_p = 7,76\%$; cotele: SPY 85,8%, IEF 14,2%
- Ponderile egale nu înseamnă riscuri egale: riscul este dominat de activele volatile; bugetarea riscului alege w astfel încât cotele să fie egale cu bugetele fixate b_i

Contribuții egale la risc (ERC)


- ERC (Maillard, Roncalli & Teïletche (2010)): $RC_i = RC_j$ pentru orice i, j ; se calculează dintr-o problemă convexă, apoi se normalizează

$$\min_{y>0} \frac{1}{2} y^\top \Sigma y - \frac{1}{N} \sum_i \ln y_i, \quad w = y / 1^\top y$$

- y : ponderi pozitive nenormalizate; termenul logaritmic menține $y_i > 0$, iar condiția de ordinul întâi dă $y_i(\Sigma y)_i = 1/N$ pentru orice i
- Pentru Σ pozitiv definită soluția există și este unică (obiectiv strict convex, infinit la frontieră)
- Ordinea volatilităților: $\sigma_{GMV} \leq \sigma_{ERC} \leq \sigma_{1/N}$
- Două active: ERC înseamnă **inversul volatilității**, $w_1 = \sigma_1^{-1} / (\sigma_1^{-1} + \sigma_2^{-1})$, pentru orice $\rho \in (-1, 1)$
 - SPY (14,7%) și IEF (6,6%): ERC deține 31% SPY, volatilitate 6,1%, fiecare activ contribuind cu 50% la varianță
- Nu are nevoie de randamente așteptate, doar de Σ ; ERC este portofoliul tangent dacă toate activele au același raport Sharpe și corelații egale

Ponderi și contribuții la risc

Eight multi-asset ETFs, monthly May 2007 - Jul 2026




- Opt ETF-uri multi-active, matricea de covarianță pe tot eșantionul, mai 2007 – iulie 2026 ($T = 231$)
- 1/N: acțiunile și high yield primesc jumătate din pondere, dar generează 69% din risc
 - ▶ ERC: fiecare activ contribuie cu 12,5% la risc, iar IEF primește cea mai mare pondere (25%)
 - ▶ GMV long-only: 73% IEF, 22% HYG, 5% SPY, cinci active cu pondere zero
- Volatilitate: 1/N 9,4%, ERC 7,9%, HRP 7,1%, GMV long-only 5,8%: ERC se află între 1/N și GMV, conform teoriei

Hierarchical Risk Parity: de la arbore la ponderi

- HRP (López de Prado (2016)), trei pași, fără inversarea matricei (funcționează chiar dacă Σ este singulară), toate ponderile pozitive
 1. **Arbore**: distanța de corelație $d_{ij} = \sqrt{(1 - \rho_{ij})/2} \in [0, 1]$; apoi distanța euclidiană dintre **coloanele** lui $D = (d_{ij})$, $\tilde{d}_{ij} = \sqrt{\sum_k (d_{ki} - d_{kj})^2}$; legătura simplă pe $\tilde{d}_{ij}$ (se unesc repetat cele mai apropiate două grupuri) dă o **dendrogramă**
 2. **Cvasi-diagonalizare**: activele se ordonează ca frunzele arborelui, astfel încât cele asemănătoare sînt vecine
 3. **Bisecție recursivă**: **lista ordonată** se împarte în două jumătăți; fiecare jumătate primește pondere invers proporțională cu varianța ei $\tilde{w}^\top \Sigma \tilde{w}$, cu $\tilde{w}$ ponderile invers proporționale cu varianța în interiorul jumătății; se repetă în fiecare jumătate
- Mantegna (1999): aceeași distanță și **arborele de acoperire minim** arată ierarhia unei piețe de acțiuni; manual: Härdle & Simar (2019), analiza cluster
- Un exemplu rezolvat cu patru active: Seminarul 4, B3

HRP pe 16 ETF-uri



- Nouă sectoare și șapte ETF-uri multi-active, lunar, mai 2007 – iulie 2026; cea mai apropiată pereche TLT și IEF ($\tilde{d} = 0,29$), aurul se alătură ultimul (0,96)
- Grupul de acțiuni: sectoarele ciclice, EFA, EEM și creditul high yield; sectoarele defensive (utilități, bunuri de consum de bază, sănătate) și energia i se alătură târziu
- HRP: toate cele 16 ponderi pozitive, cele mai mari IEF 26,7%, LQD 17,6%, HYG 12,6%; GMV long-only: 75,6% în IEF și doar cinci active peste zero


Protocolul de backtesting

- ▣ Fereastră mobilă de 60 de luni, reechilibrare lunară; ponderile lunii t folosesc doar lunile $t - 60, \dots, t - 1$
- ▣ Opt reguli: 1/N, MV, MV-LO, GMV, GMV-LO, GMV-LW, ERC, HRP
- ▣ Trei universuri
 - ▶ Sectoare: în afara eşantionului ianuarie 2004 – iulie 2026, 271 de luni (prima fereastră ianuarie 1999 – decembrie 2003)
 - ▶ Multi-active şi combinat: mai 2012 – iulie 2026, 171 de luni
- ▣ Media, volatilitatea şi raportul Sharpe anualizate ale randamentelor în exces; drawdown-ul maxim al averii din randamente totale
- ▣ Fiecare diferenţă de Sharpe se raportează cu un test (slide-urile următoare), iar toate testele efectuate întră în corecţia pentru testare multiplă

Turnover şi costuri: un exemplu numeric pe o lună

- ▣ Între reechilibrări ponderile se modifică odată cu randamentele (drift): $w_{i,t}^+ = w_{i,t}(1 + R_{i,t}) / \sum_j w_{j,t}(1 + R_{j,t})$
- ▣ **Turnover**: fracţiunea din avere tranzacţionată, $TO_{t+1} = \sum_i |w_{i,t+1} - w_{i,t}^+|$
- ▣ Exemplu numeric, sectoare, 1/N: în ianuarie 2004 XLB a avut $-4,4\%$ şi XLK $+4,3\%$, deci ponderile de $11,11\%$ s-au modificat (drift) la $10,50\%$ şi $11,45\%$
 - ▶ Revenirea la 1/N în februarie 2004 tranzacţionează $TO = 0,019$: şi 1/N tranzacţionează, vinde câştigătorii şi cumpără perdantii
 - ▶ MV-LO, reestimat pe noua fereastră, tranzacţionează $0,748$ în aceeaşi lună
- ▣ Randamentul net cu costul c pe unitate tranzacţionată: $R_{p,t}^{\text{net}} = R_{p,t} - c TO_t$; 1 punct de bază (bp) = $0,01\%$, deci 20 bp înseamnă $c = 0,002$
 - ▶ La 20 bp, tranzacţia din februarie costă MV-LO $0,002 \times 0,748 = 0,15\%$ din avere, iar 1/N $0,004\%$


Evoluția averii în afara eşantionului: multi-active



- Opt ETF-uri multi-active; averea relativă la un cont în titluri de stat, înainte de costuri
- MV eşuează complet: volatilitate 518% pe an, turnover de 44 de ori averea pe lună; o pierdere lunară de peste 100% anulează averea
- MV-LO are cel mai mare Sharpe (0,80); 1/N 0,52; ERC 0,49
- Regulile GMV: cea mai mică volatilitate (3,8%–5,4%), Sharpe scăzut (0,27–0,37); pun ponderi mari pe titlurile de stat, ale căror randamente în exces au fost ușor negative după mai 2012 (TLT -0,5%, IEF -0,2% pe an)
- Superioritatea MV-LO poate fi reală sau întâmplătoare: este necesar un test statistic

 MFM_ch4_oos_backtest


Rapoartele Sharpe în cele trei universuri



- Fereastră mobilă de 60 de luni, reechilibrare lunară, anualizat, înainte de costuri; tablele complete în [▶ Anexă](#)
- Sectoare: toate regulile, cu excepția MV, se situează la cel mult 0,07 de 1/N (0,66); MV 0,26 cu drawdown –100%
- Combinat: 1/N 0,76, MV-LO 0,81, ERC 0,71; regulile GMV 0,20–0,36
- MV: o pierdere lunară de peste 100% anulează capitalul; media și raportul Sharpe descriu o serie ipotetică de randamente, nu o avere investibilă
- Turnover lunar, sectoare: 1/N 0,02, ERC 0,03, GMV-LW 0,14, MV-LO 0,23, MV 3,86

 MFM_ch4_oos_backtest

Rapoartele Sharpe după costuri



- Universul combinat (16 ETF-uri); costul c între 0 și 100 bp pe unitate de turnover; turnover de la 0,02 (1/N) la 22 (MV) pe lună
- Sharpe-ul net devine negativ la circa 11 bp pentru MV, 29 bp pentru GMV, 58 bp pentru GMV-LW; MV-LO depășește 1/N doar la costuri sub circa 22 bp (Seminarul 4, B8)
- 1/N și ERC aproape nu se modifică: turnover-ul mic este un avantaj; raportați și rezultatele nete de costuri

Inferența pentru un raport Sharpe: Lo (2002)

- ▣ Lo (2002), randamente i.i.d. din distribuția Normală: $\sqrt{T}(\widehat{SR} - SR) \rightarrow N(0, 1 + SR^2/2)$, cu SR lunar și T numărul de luni: eroarea standard este $\sqrt{(1 + SR^2/2)/T}$
- ▣ $1/N$ pe sectoare, $T = 271$: $\widehat{SR}$ lunar = 0,191, eroarea standard 0,061
 - Anualizat $0,66 \pm 1,96 \times 0,21$: intervalul de 95% [0,25; 1,08]
- ▣ Anualizarea cu $\sqrt{A}$ ($A = 12$ luni pe an) este exactă doar fără autocorelație; în general $SR(A) = \eta(A) SR$

$$\eta(A) = \frac{A}{\sqrt{A + 2 \sum_{k=1}^{A-1} (A-k) \rho_k}}$$

- ρ_k : autocorelația randamentelor lunare la lagul k ; ρ_k pozitive scad η , ρ_k negative îl cresc; $\rho_k = 0$ dă $\eta = \sqrt{A}$
- ▣ Aici $\rho_1 = -0,03$, $\sum_{k=1}^{11} \rho_k = -0,11$: $\eta = 3,62$ în loc de $\sqrt{12} = 3,46$, Sharpe anual 0,69

Testarea unei diferențe de rapoarte Sharpe

- ▣ H_0 : $SR_1 = SR_2$ pentru două strategii evaluate pe aceleași luni; Jobson & Korkie (1981): un test pentru randamente i.i.d. din distribuția Normală
- ▣ Ledoit & Wolf (2008): o variantă robustă
 - ▶ r_{1t}, r_{2t} : randamentele în exces ale celor două strategii; μ_1, μ_2 : mediile lor; $\hat{\Delta} = \widehat{SR}_1 - \widehat{SR}_2 = f(\hat{v})$,
 $v = (\mu_1, \mu_2, \mathbb{E}[r_1^2], \mathbb{E}[r_2^2])$, $f = \frac{\mu_1}{\sqrt{\mathbb{E}r_1^2 - \mu_1^2}} - \frac{\mu_2}{\sqrt{\mathbb{E}r_2^2 - \mu_2^2}}$
 - ▶ Eroarea standard prin metoda delta: $\sqrt{\nabla f^\top \hat{\Psi} \nabla f / T}$, ∇f gradientul lui f , $\hat{\Psi}$ o covarianță HAC (consistentă la heteroscedasticitate și autocorelație) a celor patru momente
- ▣ Strategiile pe aceleași active sînt puternic corelate: diferențe mici pot fi semnificative

Bootstrap-ul pe blocuri




Bradley Efron, inventatorul
bootstrap-ului (1979)

Foto: Ryan K. Morris (2007); domeniu
public; [Wikimedia Commons](#)

- Bootstrap: datele se reeșantionează pentru a aproxima distribuția de eșantionare a lui $\hat{\Delta}$
- Randamentele sînt dependente (volatility clustering): se reeșantionează **blocuri** de luni consecutive ([Künsch \(1989\)](#))
- [Ledoit & Wolf \(2008\)](#), Secțiunea 3.2.2: blocuri circulare de **perechi** (r_{1t}, r_{2t}) , care trec peste sfîrșitul eșantionului, astfel încît corelația celor două strategii se păstrează
- Centrare și studentizare: bootstrap pentru $|\hat{\Delta}^* - \hat{\Delta}|/s(\hat{\Delta}^*)$; asimptotic pivotal, mai precis decît aproximarea prin distribuția Normală a testului HAC
- $p = [\#\{\tilde{d}^{*m} \geq |\hat{\Delta}|/s(\hat{\Delta})\} + 1]/(M + 1)$, $M = 4999$ de extrageri; $\tilde{d}^{*m}$: statistica studentizată din extragerea m , $s(\cdot)$: eroarea standard, $\#\{\cdot\}$: numărul extragerilor
- Lungimea blocului se alege prin calibrarea din [Ledoit & Wolf \(2008\)](#), Algoritmul 3.1 ([▶ Anexă](#)): de regulă 1 pentru sectoare, 8–10 pentru regulile multi-active și combinate

Testul diferenței de Sharpe față de $1/N$



- ▣ Distribuțiile bootstrap ale diferenței studentizate față de $1/N$; roșu: statistica observată; întrerupt: valorile critice bootstrap
- ▣ Sectoare, GMV-LW minus $1/N$: $-0,02$, intervalul de 95% $[-0,36; 0,33]$, p HAC = 0,93, p bootstrap = 0,94 (bloc 1)
- ▣ Multi-active, ERC minus $1/N$: $-0,03$, $[-0,15; 0,08]$, p HAC = 0,61, p bootstrap = 0,58 (bloc 10)
 - ERC este atât de corelat cu $1/N$ încât intervalul este îngust, dar conține totuși zero
- ▣ Sectoare: nicio regulă nu diferă de $1/N$ la 5% (cea mai apropiată ERC, $+0,04$, p HAC = 0,09); multi-active: MV-LO $+0,29$ nu este semnificativ (p HAC = 0,12, bootstrap 0,16)

Multe reguli, multe teste: testarea multiplă


Univers	Regula minus 1/N	$\hat{\Delta}$	p HAC	p bootstrap
Multi-active	MV	-0,74	0,01	0,06
Multi-active	HRP	-0,16	0,07	0,05
Combinat	GMV	-0,57	0,03	0,05
Combinat	GMV-LO	-0,40	0,05	0,08
Combinat	GMV-LW	-0,56	0,02	0,03
Combinat	MV-LO	+0,05	0,82	0,82

- Nicio regulă nu depășește semnificativ $1/N$ în niciun univers; neajustat, regulile GMV au Sharpe semnificativ mai mic decât $1/N$ pe universul combinat: riscul este mic, dar randamentul este și mai mic
- Familia: $H_0: \Delta_k = SR_k - SR_{1/N} \leq 0$ pentru orice k ; 21 de teste (7 reguli $\times$ 3 universuri); p-value-urile ajustate Holm sînt cel puțin 0,29 (HAC) și 0,68 (bootstrap): nicio diferență nu rămîne semnificativă ([Capitolul 3](#), testarea multiplă)
- O întrebare distinctă privește cea mai bună dintre 24 de configurații: raportul Sharpe deflatat din [Bailey & López de Prado \(2014\)](#) dă $0,84 < 0,95$ pentru MV-LO pe 16 ETF-uri, dar verdictul depinde de numărul efectiv de încercări ([▶ Anexă](#))

Cadrul: un investitor român

- ▣ Opt blue chips listate din 2014: TLV, SNP, BRD, TGN, SNG, SNN, EL, TEL
- ▣ Randamente lunare în lei, octombrie 2014 – august 2026; fereastră de 36 de luni, primul portofoliu în octombrie 2017
- ▣ Reguli: 1/N, MV-LO, GMV-LO, GMV-LW, ERC, HRP; repere BET-TR și BET
- ▣ Rapoarte Sharpe cu $R_f = 0$ (datele nu conțin o serie a pieței monetare în lei): randament pe unitate de risc, mai mare decât Sharpe-ul din randamente în exces
- ▣ Dovezi anterioare despre diversificare în România: Dragotă, Șerbănescu & Pele (2008)

Portofoliile BVB față de BET-TR



- În afara eșantionului, octombrie 2017 – august 2026 (107 luni), înainte de costuri, $R_f = 0$
- BET-TR: media 24,7% pe an, volatilitatea 17,0%, Sharpe 1,45; BET: media 17,8%, Sharpe 1,07
 - ▶ Diferența de circa 7% pe an provine din dividende: comparați cu BET-TR, niciodată cu BET
- 1/N 1,41, ERC 1,38, HRP 1,31: aproape de BET-TR
- MV-LO 1,66 (diferența +0,21, $p = 0,44$); GMV-LW 0,83 (−0,63, $p = 0,05$)
- Corelația medie a celor opt acțiuni 0,44: diversificare limitată în interiorul BVB; ultimul GMV-LO alocă 70% în TLV
- Întrebare deschisă: aduce diversificarea dincolo de BET un câștig? (Seminarul 4, C1)


Studiu de caz: frontiera accesibilă unui investitor mare

- [Jensen, Kelly, Malamud & Pedersen \(2026\)](#), *Review of Financial Studies*: construcția portofoliilor din prognoze de randament obținute prin machine learning, când fiecare tranzacție are impact asupra prețurilor
- **Frontiera eficientă implementabilă** (ec. 12): pentru fiecare volatilitate σ , cel mai mare randament așteptat **net de costurile de tranzacționare**, $k(\sigma) = \max_{\pi} E[r_{t+1}^{\text{net}}]$ cu $E[\pi_t^\top \Sigma \pi_t] = \sigma^2$
 - ▶ π_t : vectorul ponderilor activelor riscante la t ; r_{t+1}^{net} : randamentul portofoliului după costurile de tranzacționare; $k(\sigma)$: cel mai bun randament net așteptat la volatilitatea σ
 - ▶ Propoziția 1: raportul Sharpe net $k(\sigma)/\sigma$ scade de-a lungul frontierei, iar un investitor mai mare are o frontieră mai joasă
- Costul ca fracțiune din averea W_t (ec. 4, 7): $c_t = \frac{W_t}{2} (\pi_t - g_t \pi_{t-1})^\top \Lambda (\pi_t - g_t \pi_{t-1})$, pătratic în tranzacție; g_t aplică drift-ul ponderilor lunii trecute, $\Lambda = \text{diag}(0, 2/V_i)$, V_i volumul în dolari
- Regula optimă: se parcurge prin tranzacții doar o parte din distanța pînă la un **portofoliu-țintă**, $\pi_t = m g_t \pi_{t-1} + (1 - m) A_t$, m : partea păstrată din poziția veche, A_t : portofoliul-țintă ([Gârleanu & Pedersen \(2013\)](#)); Portfolio-ML învață A_t din semnale printr-o regresie ridge care maximizează utilitatea netă de costuri

	Articol	Replicarea din curs
Active	acțiuni NYSE peste mărimea mediană (184–805)	14 acțiuni din SUA + 9 ETF-uri sectoriale
Semnale	115 caracteristici (Jensen, Kelly & Pedersen (2023))	5 semnale de preț și volum
În afara eșantionului	1981–2020, lunar	februarie 2014 – august 2026 (151 de luni)
Investitor	$\gamma = 10$, avere de 10 miliarde \$ la sfîrșitul lui 2020	la fel

Studiu de caz: Tabelul 2 pe scurt


Out of sample 1981-2020, US stocks, wealth \$10 billion (Markowitz-ML off scale)



- Jensen, Kelly, Malamud & Pedersen (2026), Tabelul 2: net de costuri, 1981–2020, $\gamma = 10$; utilitatea (ec. 11) = randamentul net anual $-\frac{\gamma}{2} \times \text{varianța anuală}$
- Markowitz-ML (medie–varianță pe prognozele ML de randament, fără costuri): Sharpe brut 2,06, turnover 79,36, levier 74,61: randament net extrem de negativ
- Portfolio-ML: Sharpe net 1,33, utilitate 0,086 (randament net 15%, volatilitate 11%, cost 0,6% pe an)
- Static-ML* (costuri pe o singură perioadă; * = nivel suplimentar de calibrare) 0,81, 0,030; 1/N 0,54, -0,051; piața 0,51, -0,033: doar regulile care țin cont de costuri au utilitate pozitivă

 MFM_ch4_implementable_frontier

Studiu de caz: brut și net de costuri pe datele cursului



- Marcaj gol: înainte de costuri; plin: după costurile din ec. (35); curba întreruptă: perechile cu utilitatea Portfolio-ML (0,016), punctată: utilitatea 0
- Portfolio-ML se schimbă puțin după costuri: 3,8% brut, 3,3% net, volatilitate 5,7%; Sharpe net 0,57
- 1/N păstrează 18,1% net (Sharpe 0,61), dar la volatilitatea de 29,8% utilitatea lui este -0,26
- Variația minimă: +6,6% brut, -36,1% net; reechilibrarea unui levier de 2,6 costă 43% pe an
- Limite: 23 de active, 5 semnale, fără model factorial pentru Σ ; frontiera relevantă este cea netă de costuri (Seminarul 4, C3)

 MFM_ch4_implementable_frontier

Întrebări deschise

▣ Întrebări

- ▶ depășește vreo regulă de alocare **estimată** ponderile $1/N$ în afara eșantionului, net de costuri?
- ▶ rămîne superioară după ce se iau în calcul toate regulile, ferestrele și universurile încercate?

▣ Dovezile actuale sînt contradictorii

- ▶ Shrinkage-ul neliniar al lui Σ îmbunătățește GMV în afara eșantionului pe secțiuni transversale mari: [Ledoit & Wolf \(2017\)](#)
- ▶ Combinarea portofoliului tangent, a GMV și a lui $1/N$ sub riscul de estimare: [Kan, Wang & Zhou \(2022\)](#)
- ▶ Rezultatele backtest-urilor trebuie ajustate pentru numărul de specificații încercate: [Harvey & Liu \(2015\)](#)

▣ Formularea pentru K reguli pe un univers: $H_0: \Delta_k = SR_k - SR_{1/N} \leq 0$ pentru orice k ; $H_1: \Delta_k > 0$ pentru un k ; rata de eroare fixată pentru toată familia

- ▣ Bucla de cercetare, parcursă o dată cu un asistent AI: literatură cu DOI, ipoteze concurente, cod pe datele lunare ale cursului, o familie de teste preînregistrată, o critică în stilul unui recenzent (prompturile în [▶ Anexă](#))
- ▣ H_0 ar fi respinsă de un $\hat{\Delta}_k$ pozitiv care rămîne semnificativ după corecția pentru toată familia, după costuri și pe un al doilea eșantion

Verificările necesare pentru cercetător

- ▣ **Look-ahead:** ponderile lunii t construite cu randamentele aceleiași luni; verificați că ultima dată de estimare este înainte de t
- ▣ **Survivorship bias și selecție:** o listă de ETF-uri aleasă azi; folosiți universul disponibil la fiecare dată, inclusiv ETF-urile delistate ulterior, sau declarați limita
- ▣ **Testare multiplă:** 7 reguli $\times$ 3 universuri dau deja 21 de teste; p-value-uri ajustate Holm (FWER) sau Benjamini–Hochberg (FDR, [Benjamini & Hochberg \(1995\)](#))
- ▣ **Putere:** $\hat{\Delta}$ are o eroare standard de circa 0,18 pe 171 de luni; calculați efectul minim detectabil înainte de a rula testele
- ▣ **Tipul randamentului:** portofoliile agregă randamente **simple**, rapoartele Sharpe folosesc randamente **în exces**; recalculați o lună pas cu pas
- ▣ **Referințe inventate:** un link DOI nefuncțional sau un titlu diferit duce la eliminarea afirmației și la înregistrarea ei în `AI_ERRORS.md`

Mini studiu de caz: data snooping în backtest-ul acestui capitol

- ▣ O propunere tipică a asistentului: „MV-LO depășește $1/N$ pe universul multi-active”; superioritatea este unilaterală: $H_0: \Delta \leq 0$, $p = 1 - \Phi(\hat{\Delta}/se)$, Φ funcția de repartiție Normală standard, se eroarea standard
- ▣ Replicare: $\hat{\Delta} = +0,29$, eroarea standard HAC 0,18, p unilateral = 0,06 (HAC bilateral 0,12, bootstrap 0,16)
- ▣ Testați familia, nu câștigătorul: 21 de teste (7 reguli $\times$ 3 universuri)
 - ▶ Doar 7 din 21 de diferențe sînt pozitive; cele 4 p-value-uri HAC bilaterale sub 0,05 corespund toate unor diferențe **negative**, care nu pot respinge o ipoteză nulă de superioritate
 - ▶ Unilateral: cel mai mic $p = 0,046$ (sectoare, ERC); ajustat Holm 0,96, Benjamini–Hochberg 0,62; 0 descoperiri la un FDR de 10%
- ▣ Puterea 0,8 pentru $\Delta = 0,29$, unilateral: circa 435 de luni (36 de ani) la 5%, 944 de luni (79 de ani) la nivelul Holm 5%/21
- ▣ Interpretare: datele nu permit ordonarea acestor reguli; intervalul bootstrap pentru MV-LO, $[-0,13; 0,70]$, este compatibil atît cu pierderi, cît și cu câștiguri mari; nerespingerea nu dovedește egalitatea

O idee de proiect de cercetare

▣ Întrebări

- ▶ depășește shrinkage-ul neliniar (Ledoit & Wolf (2017)) ponderile $1/N$ pe cele 16 ETF-uri ale capitolului, după costuri de 10–50 bp?
- ▶ depășește o combinație de trei fonduri (Kan, Wang & Zhou (2022)) ponderile $1/N$ pe aceleași ETF-uri, după aceleași costuri?

- ▣ **Replicați întâi:** rezultatele pe universul combinat (Sharpe $1/N$ 0,76, MV-LO 0,81) și p-value-urile ajustate din mini studiul de caz

- ▣ **Preînregistrați:** ipotezele, familia de teste, rata de eroare, puterea și un placebo (ponderi long-only aleatoare cu același turnover), fixate înainte de orice rezultat

- ▣ **Raportați:** cod pe datele lunare ale cursului, un tabel cu toate specificațiile, o autocritică în stilul unui recenzent

- ▣ **Jurnal:** prompturile în AI_USE.md; fiecare eroare depistată și verificarea care a depistat-o în AI_ERRORS.md

Concluzii: alegerea regulii de alocare

Regula	Obiectiv	Date necesare	Principalul mod de eșec	Dovezi din acest capitol
MV	Sharpe maxim	$\hat{\mu}, \hat{\Sigma}^{-1}$	maximizarea erorii, ponderi explozive	cea mai slabă în toate universurile; averea se anulează
MV-LO	Sharpe maxim, $w_i \geq 0$	$\hat{\mu}, \hat{\Sigma}$	soluții de colț, turnover	cele mai bune estimări punctuale, niciodată semnificative
GMV, GMV-LW	varianță minimă	$\hat{\Sigma}$ (cu shrinkage)	concentrează ponderile în active cu randament mic	cel mai mic risc; Sharpe sub 1/N pe 16 ETF-uri (neajustat)
ERC, HRP	risc echilibrat	$\hat{\Sigma}$	o abatere moderată de la 1/N; HRP tranzacționează mai mult	niciodată semnificativ mai bune decât 1/N
Black–Litterman	reper plus opinii	w_b , opinii, Ω	încredere fixată prea mare	modifică doar activele din opinii
1/N	niciunul	niciuna	ignoră diferențele de risc	greu de depășit după costuri

- Evaluați orice regulă în afara eșantionului, net de costuri, cu un test al diferenței de Sharpe și luînd în calcul toate testele efectuate; aceste concluzii sînt specifice eșantioanelor analizate

Autoevaluare și legături cu alte capitole

Întrebări de recapitulare

- ▣ De ce supraestimează Sharpe-ul tangent în eșantion pe cel realizabil?
- ▣ Cu cât îl supraestimează pentru $N = 9$, $T = 60$?
- ▣ De ce acționează o restricție long-only ca un shrinkage?
- ▣ De ce poate o diferență mică de Sharpe între ERC și $1/N$ să fie aproape semnificativă, iar una mai mare între GMV și $1/N$ nu?

Legături cu alte capitole

- ▣ **Capitolul 3:** portofoliul tangent și CAPM; modele factoriale de covarianță
- ▣ **Capitolele 5–6:** volatilitate și corelație variabile în timp pentru ponderi dinamice
- ▣ **Capitolul 7:** Value-at-Risk și Expected Shortfall de portofoliu
- ▣ **Capitolul 8:** backtesting fără overfitting
- ▣ **Capitolul 13:** machine learning pentru randamente și portofolii

Anexă: momentele Wishart și distribuția ponderilor

- ▣ Randamente i.i.d. $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, estimatori de verosimilitate maximă: $\hat{\boldsymbol{\mu}} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}/T)$, $T\hat{\boldsymbol{\Sigma}} \sim W_N(T-1, \boldsymbol{\Sigma})$ (Wishart: analogul matriceal al lui χ^2 , cu $T-1$ grade de libertate), independenți
- ▣ Momentul Wishart invers, finit pentru $T > N+2$: $\mathbb{E}[\hat{\boldsymbol{\Sigma}}^{-1}] = \frac{T}{T-N-2}\boldsymbol{\Sigma}^{-1}$, o deplasare **în sus** care crește cu N/T
- ▣ Condiționând pe $\hat{\boldsymbol{\mu}}$ și folosind $\mathbb{E}[\mathbf{x}^\top \mathbf{K} \mathbf{x}] = \text{tr}(\mathbf{K} \text{Var}(\mathbf{x})) + \mathbb{E}[\mathbf{x}]^\top \mathbf{K} \mathbb{E}[\mathbf{x}]$ (orice vector aleator $\mathbf{x}$, matrice fixă $\mathbf{K}$, tr: urma) se obține $\mathbb{E}[\hat{\theta}^2]$ din curs (Seminarul A9)
- ▣ Ponderile GMV cu $\hat{\boldsymbol{\Sigma}}$ Wishart și T suficient de mare față de N : $\hat{\mathbf{w}}_{\text{GMV}}$ este nedeplasat, iar distribuția și covarianța lui exacte sînt cunoscute ([Okhrin & Schmid \(2006\)](#))
- ▣ Ponderile tangente împart la $\mathbf{1}^\top \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\mu}}$, care poate fi aproape de zero: cozi foarte groase
- ▣ Combinații optime sub riscul de estimare ale portofoliului tangent, GMV și $1/N$: [Kan & Zhou \(2007\)](#), [Kan, Wang & Zhou \(2022\)](#)

Anexă: ponderile tangente prin regresie, Britten-Jones (1999)

- Britten-Jones (1999): regresia constantei 1 pe randamentele în exces, **fără** termen liber

$$1 = \mathbf{b}^\top \mathbf{r}_t + u_t, \quad \hat{\mathbf{b}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{1}_T \propto \hat{\Sigma}^{-1} \hat{\mu}$$

- $\mathbf{r}_t$: vectorul randamentelor în exces din luna t ; $\mathbf{X}$: matricea $T \times N$ cu liniile $\mathbf{r}_t^\top$; $\mathbf{1}_T$: vectorul de T unități; u_t : eroarea regresiei
- Sherman–Morrison aplicat lui $\mathbf{X}^\top \mathbf{X} / T = \hat{\Sigma} + \hat{\mu} \hat{\mu}^\top$ dă proporționalitatea (Seminarul A2); $\hat{\mathbf{b}} / \mathbf{1}^\top \hat{\mathbf{b}} =$ ponderile tangente de eşantion dacă $\mathbf{1}^\top \hat{\mathbf{b}} > 0$
- Testul t OLS al lui $b_i = 0$: activul i are pondere zero în portofoliul tangent; testul F al lui $\mathbf{Rb} = 0$ cu $\mathbf{R} = [\mathbf{I}_{N-1}, -\mathbf{1}_{N-1}]$: „portofoliul tangent este $1/N$ ”
- Distribuții t și F exacte în eşantion finit pentru randamente i.i.d. din distribuția Normală; altfel erori standard HAC
- Nouă sectoare, ianuarie 1999 – iulie 2026 ($T = 331$): $\hat{\mathbf{b}}$ normalizat reproduce ponderile tangente; cel mai mare $|t| = 1,12$ (financiar), HAC 1,19
- H_0 : tangent = $1/N$, opt restricții: $F(8, 322) = 0,48$, $p = 0,87$; Wald HAC $\chi_8^2 = 4,50$, $p = 0,81$; nerespingerea nu dovedește ponderi egale

Anexă: intensitatea optimă de shrinkage

- Ledoit și Wolf aleg δ care minimizează distanța pătratică așteptată (Frobenius) față de Σ adevărată

$$\delta^* = \max \left\{ 0, \min \left\{ 1, \frac{\hat{\kappa}}{T} \right\} \right\}, \quad \hat{\kappa} = \frac{\hat{\pi} - \hat{\rho}}{\hat{\gamma}}$$

- $\hat{\pi}$: suma varianțelor asimptotice ale elementelor lui S (zgomotul)
- $\hat{\rho}$: covarianțele lor asimptotice cu elementele țintei
- $\hat{\gamma} = \|F - S\|^2$: eroarea de specificare a țintei
- Formulele complete pentru ținta de corelație constantă: [Ledoit & Wolf \(2004b\)](#), Anexă; codul: [Quantlet-ul de shrinkage](#)

Anexă: shrinkage-ul mediilor și alți estimatori de covarianță

- ▣ Bayes–Stein ([Jorion \(1986\)](#)): $\hat{\mu}_{BS} = (1 - \hat{\phi}) \hat{\mu} + \hat{\phi} \hat{\mu}_{GMV}$
 - ▶ Shrinkage Bayes empiric al fiecărei medii spre media portofoliului GMV; $\hat{\phi}$ dintr-un argument Stein, mai mare când N/T este mare
- ▣ [Tu & Zhou \(2011\)](#): combinația convexă dintre o regulă sofisticată și $1/N$ care minimizează pierderea așteptată în afara eșantionului
- ▣ [DeMiguel, Garlappi, Nogales & Uppal \(2009\)](#): restricțiile de normă $\|w\|_1 \leq \delta$ sau $\|w\|_2 \leq \delta$ includ GMV long-only, GMV cu shrinkage și $1/N$; puntea spre portofoliile lasso din [Capitolul 13](#)
- ▣ Structură factorială plus o covarianță reziduală rară: POET ([Fan, Liao & Mincheva \(2013\)](#)), legătura cu [Capitolul 3](#)
- ▣ GMV în dimensiune mare, cu shrinkage spre un portofoliu-țintă: [Bodnar, Parolya & Schmid \(2018\)](#)

Anexă: Black–Litterman ca estimare mixtă (GLS)

- ▣ Theil & Goldberger (1961): distribuția a priori și opiniile se scriu ca o singură regresie pentru μ

$$\begin{pmatrix} \pi \\ q \end{pmatrix} = \begin{pmatrix} I \\ P \end{pmatrix} \mu + \begin{pmatrix} e_1 \\ e_2 \end{pmatrix}, \quad \text{Var} \begin{pmatrix} e_1 \\ e_2 \end{pmatrix} = \begin{pmatrix} \tau \Sigma & 0 \\ 0 & \Omega \end{pmatrix}$$

- ▣ GLS dă exact μ_{BL} , cu covarianța $M = [(\tau \Sigma)^{-1} + P^T \Omega^{-1} P]^{-1}$
- ▣ Formă echivalentă: $\mu_{BL} = \pi + \tau \Sigma P^T (P \tau \Sigma P^T + \Omega)^{-1} (q - P \pi)$
- ▣ $\Omega \rightarrow 0$: cele mai mici pătrate cu restricții, $P \mu_{BL} = q$
- ▣ Covarianța predictivă $\Sigma + M$ în ponderi ar modifica toate ponderile; fără opinii, le scalează pe toate cu $1/(1 + \tau)$

Anexă: alte reguli bazate pe risc

- ▣ **Inversul volatilității:** $w_i \propto 1/\sigma_i$; coincide cu ERC când toate corelațiile sînt egale
- ▣ **Diversificare maximă** (Choueifaty & Coignard (2008)): se maximizează $w^\top \sigma / \sqrt{w^\top \Sigma w}$, raportul dintre volatilitatea medie a activelor și volatilitatea portofoliului; σ : vectorul volatilităților activelor
- ▣ **Varianță minimă:** GMV, regula extremă bazată pe risc
- ▣ Toate ignoră randamentele așteptate: robuste la eroarea de estimare, dar optime doar în ipoteze speciale

Anexă: rezultate, universul sectoarelor

Regula	Media	Volatilitate	Sharpe	Turnover	Drawdown maxim
1/N	9,4%	14,3%	0,66	0,02	−49%
MV	17,8%	69,0%	0,26	3,86	−100%
MV-LO	10,7%	14,7%	0,72	0,23	−42%
GMV	8,5%	11,9%	0,71	0,23	−33%
GMV-LO	8,1%	11,5%	0,70	0,09	−34%
GMV-LW	7,6%	11,8%	0,65	0,14	−31%
ERC	9,3%	13,2%	0,70	0,03	−47%
HRP	8,9%	12,8%	0,70	0,08	−45%

- Ianuarie 2004 – iulie 2026; turnover: fracțiunea medie lunară din avere tranzacționată; drawdown-ul averii din randamente totale
- MV: o pierdere lunară de peste 100% anulează capitalul (drawdown −100%); media și raportul Sharpe descriu o serie ipotetică de randamente

Anexă: rezultate, universul combinat (16 ETF-uri)

Regula	Media	Volatilitate	Sharpe	Turnover	Sharpe, 50 bp
1/N	7,9%	10,3%	0,76	0,02	0,75
MV	28,7%	261,8%	0,11	22,10	-0,51
MV-LO	8,0%	9,8%	0,81	0,20	0,69
GMV	0,8%	4,1%	0,20	0,24	-0,15
GMV-LO	2,0%	5,4%	0,36	0,06	0,30
GMV-LW	0,9%	4,4%	0,20	0,13	0,03
ERC	5,5%	7,8%	0,71	0,03	0,68
HRP	4,0%	7,0%	0,56	0,11	0,47

□ Mai 2012 – iulie 2026; ultima coloană: net de 50 de puncte de bază pe unitate de turnover

Anexă: detaliile bootstrap-ului și lungimea blocului

- Studentizare: $s(\hat{\Delta}^*)$ din sumele pe blocuri ale fiecărei reeșantionări; $s(\hat{\Delta})$ pe date, cu un nucleu pătratic-spectral cu prealbire (Andrews & Monahan (1992)) și lățime de bandă automată (Andrews (1991))
- Ledoit & Wolf (2008), Algoritm 3.1: se alege blocul b al cărui interval bootstrap are acoperirea efectivă cea mai apropiată de 95%
 - ▶ Se estimează o autoregresie vectorială de ordinul întâi pentru perechea de randamente; reziduurile se reeșantionează printr-un bootstrap staționar (Politis & Romano (1994)), bloc mediu 5
 - ▶ Se generează $K = 5000$ de pseudo-eșantioane de lungime T ; în fiecare se construiește intervalul de 95% pentru $b \in \{1, 2, 4, 6, 8, 10\}$
 - ▶ $\hat{g}(b)$: proporția intervalelor care conțin $\hat{\Delta}$ pseudo-adevărat; se alege $\tilde{b} = \arg \min_b |\hat{g}(b) - 0,95|$
- Grila și K urmează articolul (Secțiunile 4–5) și se aplică fiecăreia dintre cele 21 de perechi din capitol
- Un bootstrap nestudentizat cu bloc fix de 6 luni nu este echivalent cu acest test: lungimea blocului nu este calibrată pentru acoperire

Anexă: raportul Sharpe deflatat

- Bailey & López de Prado (2014): cel mai bun dintre N rapoarte Sharpe este deplasat în sus chiar dacă toate rapoartele Sharpe adevărate sînt zero
- Maximul așteptat sub H_0 : toate rapoartele Sharpe adevărate sînt zero, N încercări independente, T în unități lunare; cu $\gamma_E = 0,5772$ (constanta lui Euler) și $\hat{V}$ varianța celor N estimații; Φ : funcția de repartiție Normală standard, e : numărul lui Euler

$$SR_0 = \sqrt{\hat{V}} \left[(1 - \gamma_E) \Phi^{-1} \left(1 - \frac{1}{N} \right) + \gamma_E \Phi^{-1} \left(1 - \frac{1}{Ne} \right) \right]$$

- Raportul Sharpe deflatat: probabilitatea ca raportul Sharpe adevărat al câștigătorului să depășească SR_0 , cu asimetria $\hat{\gamma}_3$ și kurtosis-ul $\hat{\gamma}_4$ ale câștigătorului

$$DSR = \Phi \left(\frac{(\widehat{SR} - SR_0) \sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3 \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \widehat{SR}^2}} \right)$$

- Acest capitol: 24 de configurații (8 reguli $\times$ 3 universuri); câștigător MV-LO pe 16 ETF-uri, 0,81 pe an
 - ▶ Ca 24 de încercări independente: $SR_0 = 0,52$ pe an, $DSR = 0,84 < 0,95$
 - ▶ Configurațiile sînt puternic corelate (pînă la 0,99), deci numărul efectiv de încercări independente este mai mic: $N = 8$ dă DSR 0,93, $N = 3$ dă 0,98
- Holm ajustează întreaga familie de teste pe perechi față de $1/N$; DSR verifică dacă performanța celei mai bune configurații depășește ceea ce ar produce hazardul

Anexă: dincolo de acțiuni, activele digitale

- ▣ [Petukhina, Trimborn, Härdle & Elendner \(2021\)](#): criptomonedele în regulile de alocare a portofoliului; câștigurile depind de regulă și de lichiditate
- ▣ [Pele et al. \(2023\)](#): devin criptomonedele active alternative?
- ▣ Bitcoin: volatilitatea anualizată 172% (lunar, 2010–2026; o criptomonedă supraviețuitoare, aleasă ex post), IEF 6,6%
- ▣ Contribuțiile la risc cresc cu volatilitatea: regulile bazate pe risc atribuie automat lui Bitcoin o pondere mică (Seminarul 4, B5)
- ▣ Markowitz robust pentru crypto-active: [Pele \(2023\)](#)

Anexă: studiul de caz, metoda în detaliu (1/2)

- Costul (ec. 4, 7): π_t ponderile activelor riscante, $1 - 1^\top \pi_t$ în activul fără risc; $g_t = \text{diag}((1 + r_t^f + r_t)/(1 + g_t^w))$ (ec. 6), g_t^w creșterea averii; $\Lambda = \text{diag}(0, 2/V_i)$, V_i volumul zilnic mediu în dolari pe 6 luni: tranzacționarea a 1% din V_i modifică prețul cu 0,1% (ec. 35, [Frazzini, Israel & Moskowitz \(2018\)](#))
- Regula optimă (Propoziția 3): $\pi_t = m g_t \pi_{t-1} + (1 - m) A_t$, A_t o sumă ponderată a portofoliilor Markowitz de azi și a celor viitoare așteptate; m rezolvă ec. (14); generalizează [Gârleanu & Pedersen \(2013\)](#)
- Portfolio-ML (Propoziția 4, ec. 40): $A_t = \text{diag}(1/\sigma_{i,t}) f(s_t) \beta$, $f = p$ caracteristici Fourier aleatoare ale semnalelor s_t ; $\hat{\beta} = (E_T[\tilde{\Sigma}_t] + \lambda I)^{-1} E_T[\tilde{r}_{t+1}]$, o regresie ridge care maximizează în formă închisă utilitatea netă de costuri (ec. 24–26), învățând direct ponderile, ca [Brandt, Santa-Clara & Valkanov \(2009\)](#), care însă ignoră costurile

Anexă: studiul de caz, metoda în detaliu (2/2)

- Date (Secțiunea 5.1): acțiuni ordinare NYSE peste capitalizarea mediană (184–805 acțiuni), 115 caracteristici din [Jensen, Kelly & Pedersen \(2023\)](#) ordonate în $[0, 1]$; decembrie 1952 – decembrie 2020, în afara eșantionului 1981–2020, lunar
- Σ : 13 teme de caracteristici și 12 industrii ca factori, ponderi exponențiale cu timpi de înjumătățire de 378 de zile (corelații) și 126 de zile (varianțe); investitorul $\gamma = 10$, avere de 10 miliarde \$ la sfârșitul lui 2020, care crește odată cu piața (Secțiunea 5.1.3)
- Calibrare (Tabelul 1): $\lambda \in \{0, e^{-10}, e^{-9.8}, \dots, e^{10}\}$, $p \in \{2^6, \dots, 2^9\}$, $\eta \in \{e^{-3}, e^{-2}\}$ (abaterea standard a ponderilor aleatoare), alese anual după utilitatea backtest-urilor de validare din 1971
- Reguli concurente: Markowitz-ML (ec. 32), Static-ML (cost pe o perioadă, ec. 34), Multiperiod-ML (prognoze pentru 12 orizonturi, ec. 22), sortări pe factori, $1/N$, varianță minimă, piața; „*” marchează un nivel suplimentar de calibrare (Secțiunea 5.3)

Anexă: studiul de caz, rezultatele complete

- Tabelul 2, Portfolio-ML: raport Sharpe net 1,33, utilitate 0,086 (randament net 15%, volatilitate 11%, cost 0,6% pe an, turnover 0,25)
- Tabelul 2, Multiperiod-ML*: Sharpe net 0,83, utilitate 0,020; Portfolio-ML nu are nevoie de un al doilea nivel de calibrare
- Tabelul 3: probabilitatea a posteriori ca Portfolio-ML să aibă utilitatea mai mare: 99,9% față de Static-ML* și Multiperiod-ML*, 100% față de Markowitz-ML
- Figura 1(B) (Secțiunea 6.2): cu 10 miliarde \$ și $\gamma = 10$, randament net în exces 14,6% la volatilitatea de 11%; cu 1 miliard \$, 16,3% la aceeași volatilitate: dimensiunea portofoliului generează costuri
- Figura 5: net de costuri, calitatea este tema cea mai importantă, iar reversal-ul pe termen scurt aproape irelevant; autocorelația lunară $-0,04$ pentru reversal-ul de o lună, $0,94$ pentru book-to-market (Secțiunea 6.3): semnalele persistente generează costuri de tranzacționare mici
- Limite declarate de autori: comisioane și alte fricțiuni, putere de calcul și metode ML indisponibile în timp real la începutul eșantionului (Secțiunea 6.1); costurile și riscul considerate constante pe orizontul fiecărei optimizări (Secțiunea 5.1.3); pe cele mai mici 20% dintre acțiuni, Portfolio-ML obține rezultate inferioare față de Multiperiod-ML* și Static-ML* (Figura 8)

Anexă: studiul de caz, replicarea din curs

- Datele cursului: 14 acțiuni din SUA și 9 ETF-uri sectoriale; cinci semnale (randamentul pe o lună, momentum de la $t - 6$ și de la $t - 12$ la $t - 1$, volatilitatea pe un an, volumul în dolari pe 6 luni); aceeași regulă de cost, γ , avere și grilă; Σ cu aceleași ponderi pe cele 23 de active; validare din 2011; randamente în afara eșantionului februarie 2014 – august 2026 (151 de luni)
- Portfolio-ML: Sharpe net 0,57, utilitate 0,016, cost 0,6% pe an, levier 0,32; 1/N: Sharpe net 0,61, utilitate $-0,26$ (volatilitate netă 30%)
- Utilitate: Static-ML $-0,13$; varianța minimă $-0,72$ (cost 43% pe an); Markowitz-ML extrem de negativă (levier 18)
- Probabilitatea a posteriori a unei utilități mai mari pentru Portfolio-ML: 99,5% față de Static-ML, 99,9% față de varianța minimă, 93,3% față de 1/N
- Regulile care țin cont de costuri le domină pe cele care le ignoră, ca în Tabelul 2; avantajul Portfolio-ML provine din poziții mici, ajustate lent, nu printr-un Sharpe brut mai mare (0,68 față de 0,87 pentru 1/N)
- Limite: 23 de active în loc de 184–805, cinci semnale în loc de 115, fără model factorial pentru Σ , a cărui fereastră ajunge la 10 ani abia în august 2014 (prețuri comune din august 2004); prognoze de randament cu $p \geq 2^6$ și trei ani de validare (articolul: 2^1-2^9 , zece ani), fără regulile concurente marcate cu stea
- Extindere deschisă: frontiere implementabile pentru averi de 1, 10 și 100 de miliarde \$ și $\gamma \in \{1, 5, 10, 20, 100\}$, cu costurile lui 1/N calculate la fiecare nivel de avere (Seminarul 4, C3)

Anexă: bucla descoperirii, prompturi reutilizabile (1/2)

- Instrumentele sînt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și motoare de căutare a literaturii (Semantic Scholar, Elicit, Google Scholar)
- **Literatură:** „Enumeră studiile publicate în reviste cu evaluare inter pares din 2015 încoace care compară regulile cu shrinkage sau bazate pe risc cu $1/N$ în afara eșantionului; pentru fiecare dă DOI, N , T , ipoteza de cost și testul.” Verificați fiecare DOI în Crossref și deschideți tabelul citat
- **Ipoteze:** „Dă trei explicații concurente pentru un câștig de Sharpe față de $1/N$ (o Σ mai bună, o primă de volatilitate redusă, noroc) și implicația testabilă a fiecăreia pentru turnover, subperioade și expunerile la factori.”
- **Date și cod:** „Scrie cod Python care citește prețurile zilnice din datele cursului, aliniază prețurile pe zilele comune și rulează GMV-LW și $1/N$ cu o fereastră mobilă de 60 de luni; ponderile de la t pot folosi date doar pînă la $t - 1$.” Replicați întîi: $1/N$ 0,76, GMV-LW 0,20 pe universul combinat

Anexă: bucla descoperirii, prompturi reutilizabile (2/2)

- ▣ **Robustețe:** „Scrie o preînregistrare: familia de teste (reguli $\times$ universuri $\times$ ferestre $\times$ costuri), rata de eroare (FWER sau FDR), subperioadele și un placebo, fixate înainte de a vedea vreun rezultat.”
- ▣ **Critică:** „Joacă rolul unui recenzent sever: dă cele mai puternice trei motive pentru care câștigul meu de Sharpe ar putea fi aparent și testul care l-ar demasca pe fiecare.”
- ▣ **Raport:** fiecare specificație încercată, p-value-uri ajustate, puterea testului, codul și seed-urile; orice specificație aleasă după ce ai văzut rezultatele este exploratorie
- ▣ Portofoliile agregă randamente **simple**, iar rapoartele Sharpe folosesc randamente **în exces**: recalculați o lună pas cu pas

Anexă: studiu suplimentar, cod și date

Cursuri avansate pe quantinar.com

-  Hierarchical Clustering
-  Minimum Spanning Tree
-  Multivariate Statistical Analysis

Cod și date

- Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_04
- Rata fără risc: [Kenneth French Data Library](#)

Bibliografie (1/10)

- ▣ Andrews, D.W.K. (1991). [Heteroskedasticity and autocorrelation consistent covariance matrix estimation](#). *Econometrica*, 59(3), 817–858.
- ▣ Andrews, D.W.K., Monahan, J.C. (1992). [An improved heteroskedasticity and autocorrelation consistent covariance matrix estimator](#). *Econometrica*, 60(4), 953–966.
- ▣ Bailey, D.H., López de Prado, M. (2014). [The deflated Sharpe ratio: correcting for selection bias, backtest overfitting, and non-normality](#). *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Benjamini, Y., Hochberg, Y. (1995). [Controlling the false discovery rate: a practical and powerful approach to multiple testing](#). *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300.
- ▣ Best, M.J., Grauer, R.R. (1991). [On the sensitivity of mean-variance-efficient portfolios to changes in asset means: some analytical and computational results](#). *Review of Financial Studies*, 4(2), 315–342.
- ▣ Black, F., Litterman, R. (1992). [Global portfolio optimization](#). *Financial Analysts Journal*, 48(5), 28–43.

Bibliografie (2/10)

- ▣ Bodnar, T., Parolya, N., Schmid, W. (2018). Estimation of the global minimum variance portfolio in high dimensions. *European Journal of Operational Research*, 266(1), 371–390.
- ▣ Brandt, M.W., Santa-Clara, P., Valkanov, R. (2009). Parametric portfolio policies: exploiting characteristics in the cross-section of equity returns. *Review of Financial Studies*, 22(9), 3411–3447.
- ▣ Britten-Jones, M. (1999). The sampling error in estimates of mean-variance efficient portfolio weights. *Journal of Finance*, 54(2), 655–671.
- ▣ Chopra, V.K., Ziemba, W.T. (1993). The effect of errors in means, variances, and covariances on optimal portfolio choice. *Journal of Portfolio Management*, 19(2), 6–11.
- ▣ Choueifaty, Y., Coignard, Y. (2008). Toward maximum diversification. *Journal of Portfolio Management*, 35(1), 40–51.
- ▣ DeMiguel, V., Garlappi, L., Nogales, F.J., Uppal, R. (2009). A generalized approach to portfolio optimization: improving performance by constraining portfolio norms. *Management Science*, 55(5), 798–812.

Bibliografie (3/10)

- ▣ DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy?. *Review of Financial Studies*, 22(5), 1915–1953.
- ▣ Dragotă, M., Șerbănescu, C.I., Pele, D.T. (2008). Portfolio diversification and market share analysis for Romanian insurance companies. În *Risk Management and Value*, World Scientific, 277–298.
- ▣ Fan, J., Liao, Y., Mincheva, M. (2013). Large covariance estimation by thresholding principal orthogonal complements. *Journal of the Royal Statistical Society: Series B*, 75(4), 603–680.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, ed. a 5-a. Springer.
- ▣ Frazzini, A., Israel, R., Moskowitz, T.J. (2018). *Trading costs*. SSRN Working Paper 3229719.
- ▣ Frost, P.A., Savarino, J.E. (1988). For better performance: constrain portfolio weights. *Journal of Portfolio Management*, 15(1), 29–34.

Bibliografie (4/10)

- ▣ Gârleanu, N., Pedersen, L.H. (2013). *Dynamic trading with predictable returns and transaction costs*. *Journal of Finance*, 68(6), 2309–2340.
- ▣ Härdle, W.K., Simar, L. (2019). *Applied Multivariate Statistical Analysis*, ed. a 5-a. Springer.
- ▣ Harvey, C.R., Liu, Y. (2015). *Backtesting*. *Journal of Portfolio Management*, 42(1), 13–28.
- ▣ He, G., Litterman, R. (2002). *The intuition behind Black-Litterman model portfolios*. SSRN Working Paper 334304.
- ▣ Jagannathan, R., Ma, T. (2003). *Risk reduction in large portfolios: why imposing the wrong constraints helps*. *Journal of Finance*, 58(4), 1651–1683.
- ▣ Jensen, T.I., Kelly, B., Malamud, S., Pedersen, L.H. (2026). *Machine learning and the implementable efficient frontier*. *Review of Financial Studies*, 39(10), 3035–3078.

Bibliografie (5/10)

- ▣ Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). *Is there a replication crisis in finance?*. *Journal of Finance*, 78(5), 2465–2518.
- ▣ Jobson, J.D., Korkie, B.M. (1981). *Performance hypothesis testing with the Sharpe and Treynor measures*. *Journal of Finance*, 36(4), 889–908.
- ▣ Jorion, P. (1986). *Bayes-Stein estimation for portfolio analysis*. *Journal of Financial and Quantitative Analysis*, 21(3), 279–292.
- ▣ Kan, R., Wang, X., Zhou, G. (2022). *Optimal portfolio choice with estimation risk: no risk-free asset case*. *Management Science*, 68(3), 2047–2068.
- ▣ Kan, R., Zhou, G. (2007). *Optimal portfolio choice with parameter uncertainty*. *Journal of Financial and Quantitative Analysis*, 42(3), 621–656.
- ▣ Künsch, H.R. (1989). *The jackknife and the bootstrap for general stationary observations*. *Annals of Statistics*, 17(3), 1217–1241.

Bibliografie (6/10)

- ▣ Laloux, L., Cizeau, P., Bouchaud, J.-P., Potters, M. (1999). Noise dressing of financial correlation matrices. *Physical Review Letters*, 83(7), 1467–1470.
- ▣ Ledoit, O., Wolf, M. (2003). Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10(5), 603–621.
- ▣ Ledoit, O., Wolf, M. (2004a). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- ▣ Ledoit, O., Wolf, M. (2004b). Honey, I shrunk the sample covariance matrix. *Journal of Portfolio Management*, 30(4), 110–119.
- ▣ Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- ▣ Ledoit, O., Wolf, M. (2017). Nonlinear shrinkage of the covariance matrix for portfolio selection: Markowitz meets Goldilocks. *Review of Financial Studies*, 30(12), 4349–4388.

Bibliografie (7/10)

- ▣ Ledoit, O., Wolf, M. (2020). Analytical nonlinear shrinkage of large-dimensional covariance matrices. *Annals of Statistics*, 48(5), 3043–3065.
- ▣ Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.
- ▣ López de Prado, M. (2016). Building diversified portfolios that outperform out of sample. *Journal of Portfolio Management*, 42(4), 59–69.
- ▣ Maillard, S., Roncalli, T., Teïletche, J. (2010). The properties of equally weighted risk contribution portfolios. *Journal of Portfolio Management*, 36(4), 60–70.
- ▣ Mantegna, R.N. (1999). Hierarchical structure in financial markets. *European Physical Journal B*, 11(1), 193–197.
- ▣ Marčenko, V.A., Pastur, L.A. (1967). Distribution of eigenvalues for some sets of random matrices. *Mathematics of the USSR-Sbornik*, 1(4), 457–483.

Bibliografie (8/10)

- ▣ Markowitz, H. (1952). *Portfolio selection*. *Journal of Finance*, 7(1), 77–91.
- ▣ Merton, R.C. (1972). *An analytic derivation of the efficient portfolio frontier*. *Journal of Financial and Quantitative Analysis*, 7(4), 1851–1872.
- ▣ Merton, R.C. (1980). *On estimating the expected return on the market: an exploratory investigation*. *Journal of Financial Economics*, 8(4), 323–361.
- ▣ Michaud, R.O. (1989). *The Markowitz optimization enigma: is 'optimized' optimal?*. *Financial Analysts Journal*, 45(1), 31–42.
- ▣ Okhrin, Y., Schmid, W. (2006). *Distributional properties of portfolio weights*. *Journal of Econometrics*, 134(1), 235–256.
- ▣ Pele, D.T. (2023). *Robust Markowitz for crypto-assets*. Curs Quantinar, Academia de Studii Economice din București.

Bibliografie (9/10)

- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). *Are cryptos becoming alternative assets?*. *The European Journal of Finance*, 29(10), 1064–1105.
- ▣ Petukhina, A., Trimborn, S., Härdle, W.K., Elendner, H. (2021). *Investing with cryptocurrencies – evaluating their potential for portfolio allocation strategies*. *Quantitative Finance*, 21(11), 1825–1853.
- ▣ Politis, D.N., Romano, J.P. (1994). *The stationary bootstrap*. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- ▣ Sharpe, W.F. (1966). *Mutual fund performance*. *Journal of Business*, 39(S1), 119–138.
- ▣ Theil, H., Goldberger, A.S. (1961). *On pure and mixed statistical estimation in economics*. *International Economic Review*, 2(1), 65–78.
- ▣ Tobin, J. (1958). *Liquidity preference as behavior towards risk*. *Review of Economic Studies*, 25(2), 65–86.

Bibliografie (10/10)

- Tu, J., Zhou, G. (2011). Markowitz meets Talmud: a combination of sophisticated and naive diversification strategies. *Journal of Financial Economics*, 99(1), 204–215.
- Date: Kenneth R. French Data Library, mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html.