








Modelarea piețelor financiare

Capitolul 4: Optimizarea portofoliului



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

De ce schimbă estimarea problema optimizării?

Optimul este simplu, estimarea nu

- Un **portofoliu** este un vector de ponderi $\mathrm{w} = (w_1, \ldots, w_N)^\top$ cu $\mathrm{w}^\top 1 = 1$
- Optimizarea alege w care maximizează un criteriu, sub restricții
- Optimul are formă închisă cînd mediile și covariațele sînt cunoscute, dar estimarea lui este dificilă
  - Optimizatorul atribuie ponderi mari exact acolo unde erorile de estimare sînt cele mai mari
  - 16 active: 16 medii + 136 variațe și covariațe = 152 de parametri, estimați din 60 de observații lunare
- Întrebarea capitolului: poate o regulă estimată să depășească ponderile egale în afara eșantionului, după costuri?

Ce conține capitolul

Traseul de bază

- Medie–varianță: ponderile de varianță minimă globală (GMV) și tangente, frontiera, restricțiile
- Riscul de estimare: de ce rapoartele Sharpe în eșantion sînt prea optimiste
- Trei corecții ale datelor de intrare: shrinkage-ul covarianței, restricțiile, Black–Litterman
- Reguli care folosesc doar $\boldsymbol{\Sigma}$: equal risk contribution (ERC) și Hierarchical Risk Parity (HRP)
- Evaluarea în afara eșantionului: turnover și costuri, teste ale diferenței de Sharpe, Holm și Benjamini–Hochberg
- Aplicația pe Bursa de Valori București (BVB)

Pentru aprofundare

- Costurile de tranzacționare ale unui investitor mare (studiu de caz)
- Cercetarea asistată de inteligența artificială (AI) și data snooping
- Anexa: demonstrațiile și tabelele complete
- Manual: Franke, Härdle & Hafner (2019), Partea I

Ce trebuie să poți face

- să calculezi ponderile de varianță minimă, tangente și cu risc egal
- să explici de ce erorile de estimare favorizează 1/N
- să testezi o diferență de Sharpe după costuri și după testarea multiplă

Date, active și reperul 1/N

Univers	Active	Randamente	Monedă
Sectoare	9 ETF-uri sectoriale din SUA	1999/01 – 2026/07	USD
Multi-active	8 ETF-uri: acțiuni (3), titluri de stat (2), credit (2), aur	2007/05 – 2026/07	USD
Combinat	9 sectoare + cele 7 ETF-uri multi-active, fără SPY (S&P 500) (16 ETF-uri)	2007/05 – 2026/07	USD
România	8 blue chips BVB; indicii BET și BET-TR	2014/10 – 2026/08	RON

- ETF (exchange-traded fund): fond tranzacționat la bursă, care replică un indice
- Randamente lunare simple din prețurile de sfîrșit de lună, în zilele comune de tranzacționare
  - ETF-uri și acțiuni cu dividendele reinvestite
  - BET (Bucharest Exchange Trading), indicele de referință al BVB, este indice de preț
  - BET-TR (total return) reinvestește dividendele
- Randamente în exces față de titlul de stat la o lună (Kenneth French Data Library)
- Pentru BVB se ia $R_f = 0$
- **1/N**: ponderi egale $w_i = 1/N$, reechilibrate lunar
- Nu necesită nicio estimare și este reperul oricărei comparații

Activele în detaliu

- **Sectoare** (9 ETF-uri sectoriale din SUA)
  - XLB materiale, XLE energie, XLF financiar, XLI industrie, XLK tehnologie
  - XLP bunuri de consum de bază, XLU utilități, XLV sănătate, XLY consum discreționar
- **Multi-active**
  - acțiuni: SPY (S&P 500), EFA (țări dezvoltate, fără SUA și Canada), EEM (piețe emergente)
  - obligațiuni: TLT (titluri de stat SUA, peste 20 de ani), IEF (titluri de stat SUA, 7–10 ani), LQD (investment grade), HYG (high yield)
  - aur: GLD
- **BVB** (8 blue chips)
  - TLV Banca Transilvania, SNP OMV Petrom, BRD BRD–Groupe Société Générale, TGN Transgaz
  - SNG Romgaz, SNN Nuclearelectrica, EL Electrica, TEL Transelectrica

Notație (1/2)

- **Randamente**
  - randamentul simplu $R_{i,t} = P_{i,t}/P_{i,t-1} - 1$
  - $P_{i,t}$: prețul de la sfîrșitul lunii al activului i
  - randamentul în exces $R^e_{i,t} = R_{i,t} - R_{f,t}$ (în seminar: r_t și r^e_t)
  - $R_{f,t}$: rata fără risc
  - randamentul logaritmic $\ln(P_{i,t}/P_{i,t-1}) = \ln(1 + R_{i,t})$ se adună în timp, dar nu între active; de exemplu, prețul crește de la 100 la 110: $R = 10\%$, $\ln 1{,}1 = 9{,}53\%$
  - portofoliile folosesc randamente simple, deoarece $R_{p,t} = \sum_i w_i R_{i,t}$ este exact
- **Portofoliu** de N active
  - w: vectorul ponderilor
  - $\boldsymbol{\mu}$: vectorul randamentelor (în exces) așteptate
  - 1: vectorul de unu
  - $\boldsymbol{\Sigma}$: matricea de covariață $N \times N$ a randamentelor
  - media portofoliului $\mathrm{w}^\top \boldsymbol{\mu}$, varianța portofoliului $\mathrm{w}^\top \boldsymbol{\Sigma} \mathrm{w}$

Notație (2/2)

- **Raportul Sharpe** (Sharpe (1966)): $SR_p = \mathbb{E}[R_p^e]/\sigma(R_p^e)$
  - randamentul mediu în exces pe unitatea de volatilitate σ
  - cifrele lunare se anualizează cu $\times 12$ (media) și $\times\sqrt{12}$ (volatilitatea, Sharpe)
- **Drawdown maxim**: $\min_t(W_t/\max_{s\leq t} W_s - 1)$
  - cea mai mare scădere a averii W_t față de un maxim anterior
  - exemplu: averea urcă la 1,50, apoi coboară la 1,20: $1{,}20/1{,}50 - 1 = -20\%$
- **În afara eșantionului** (OOS, out of sample): ponderile deținute în luna t folosesc doar date pînă în luna $t-1$
- **Regulile capitolului**
  - MV (mean–variance): portofoliul tangent din momente de eșantion
  - GMV (global minimum variance): variață minimă globală
  - MV-LO și GMV-LO: versiunile lor long-only (LO), fără vînzări în lipsă
  - GMV-LW: GMV cu shrinkage Ledoit–Wolf (LW) al covarianței
  - ERC (equal risk contribution) și HRP: reguli bazate pe risc
  - 1/N: ponderi egale

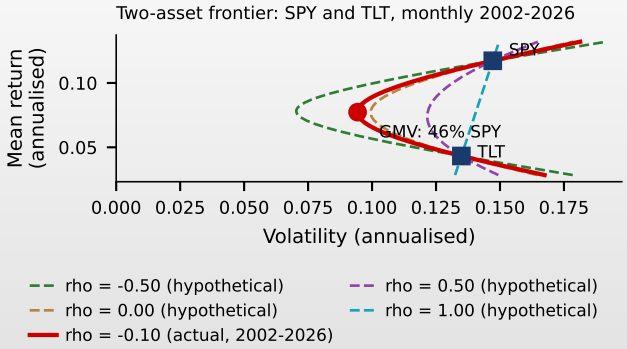
Problema lui Markowitz

- Markowitz (1952): investitorii țin cont de media și de varianța randamentelor portofoliului
- **Frontiera de varianță minimă**: varianța minimă pentru fiecare medie-țintă m
  - ramura ei superioară, $m \geq \mu_{\text{GMV}}$ (media portofoliului GMV), este **frontiera eficientă**

$$\min_{\mathrm{w}} \ \mathrm{w}^\top \boldsymbol{\Sigma} \mathrm{w} \quad \text{cu} \quad \mathrm{w}^\top \boldsymbol{\mu} = m, \ \ \mathrm{w}^\top 1 = 1$$

  - Obiectivul: varianța portofoliului
  - Restricțiile: media-țintă m și investirea integrală (ponderile însumează 1)
- Forma cu utilitate, aversiunea la risc $\gamma > 0$: $\max_{\mathrm{w}} \ \mathrm{w}^\top \boldsymbol{\mu} - \frac{\gamma}{2} \mathrm{w}^\top \boldsymbol{\Sigma} \mathrm{w}$ cu $\mathrm{w}^\top 1 = 1$
  - cînd γ variază, soluția parcurge exact ramura eficientă
- Ponderile pot fi negative: o **vînzare în lipsă** (vînzarea unui activ împrumutat)

Două active: efectul corelației asupra diversificării



- Două active, corelația ρ: $\sigma_p^2 = w^2\sigma_1^2 + (1-w)^2\sigma_2^2 + 2w(1-w)\rho\sigma_1\sigma_2$
- w: ponderea activului 1, σ_1, σ_2: volatilitățile, σ_p: volatilitatea portofoliului
- Minimul este la $w^* = \dfrac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}$
- SPY și TLT, lunar 2002–2026: $\rho = -0{,}10$, $w^* = 46\%$ SPY, volatilitate 9,4% față de SPY 14,7% și TLT 13,5%
- Graficul: medii ale randamentelor totale și volatilități anualizate, în zecimale ($0{,}10 = 10\%$)
- Cu cît ρ este mai mic, cu atît curba este mai convexă spre stînga
- La $\rho = 1$, portofoliile long-only din grafic nu au beneficiu de diversificare
- Corelația variabilă în timp: Capitolul 6

MFM_ch4_two_asset

Portofoliile GMV și tangent pentru N active

- GMV: $\min_{\mathrm{w}} \mathrm{w}^\top \boldsymbol{\Sigma} \mathrm{w}$ cu $\mathrm{w}^\top 1 = 1$
  - lagrangianul $\mathcal{L} = \mathrm{w}^\top \boldsymbol{\Sigma} \mathrm{w} - \lambda(\mathrm{w}^\top 1 - 1)$, $\boldsymbol{\Sigma}$ pozitiv definită
  - λ: multiplicatorul Lagrange al restricției de buget
  - condiția de ordinul întîi $2\boldsymbol{\Sigma}\mathrm{w} = \lambda 1$, deci $\mathrm{w} = \frac{\lambda}{2}\boldsymbol{\Sigma}^{-1}1$
  - restricția dă $\frac{\lambda}{2} = 1/A$, $A = 1^\top \boldsymbol{\Sigma}^{-1} 1$
- Tangent: se maximizează $\mathrm{w}^\top \boldsymbol{\mu} / \sqrt{\mathrm{w}^\top \boldsymbol{\Sigma} \mathrm{w}}$, $\boldsymbol{\mu}$ randamentele așteptate **în exces**
- Condiția $\boldsymbol{\mu} \propto \boldsymbol{\Sigma}\mathrm{w}$ dă $\mathrm{w} \propto \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$ ($\propto$: proporțional cu)
- θ: raportul Sharpe maxim

	GMV	**Tangent (MV)**
Ponderi	$\mathrm{w}_{\mathrm{GMV}} = \boldsymbol{\Sigma}^{-1}1/A$	$\mathrm{w}_{\mathrm{MV}} = \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}/B$, $B = 1^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$
Rezultat	varianța $\sigma^2_{\mathrm{GMV}} = 1/A$	Sharpe la pătrat $\theta^2 = \boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$
Necesită	doar $\boldsymbol{\Sigma}$	$\boldsymbol{\mu}$ și $\boldsymbol{\Sigma}$; Sharpe sign$(B)\,\theta$

- $\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}/B$ normalizat este maximul doar dacă $B > 0$
- $B < 0$ dă portofoliul cu Sharpe minim, iar pentru $B = 0$ nu există soluție complet investită

Separarea și frontiera în formă închisă



James Tobin, Premiul Nobel pentru economie 1981

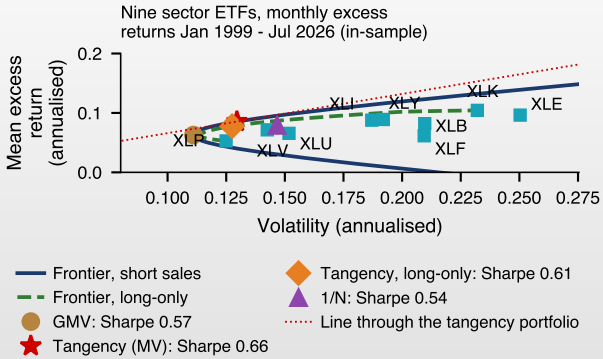
Foto: autor necunoscut (1962); domeniu public; Wikimedia Commons

- Tobin (1958): se adaugă un activ fără risc cu randamentul R_f
  - fiecare investitor deține **același** portofoliu riscant, portofoliul tangent, combinat cu numerar sau cu împrumut
  - aversiunea la risc schimbă doar combinația: **separarea în două fonduri**, puntea spre modelul de evaluare a activelor financiare (CAPM, Capital Asset Pricing Model; Capitolul 3)
- Merton (1972): cu vînzări în lipsă, frontiera este o hiperbolă
  - $\boldsymbol{\Sigma}$ pozitiv definită, $\boldsymbol{\mu}$ neproporțional cu 1
  - A, B ca pe slide-ul anterior
  - $C = \boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu} = \theta^2$, $D = AC - B^2 > 0$

$$\sigma^2(m) = \frac{Am^2 - 2Bm + C}{D}$$

- $\sigma^2(m)$: cea mai mică varianță posibilă cu media m; o parabolă în planul (σ^2, m), adică hiperbola de mai sus în planul (σ, m) (derivarea: Anexă)
  - GMV se află la $m = B/A$, $\sigma^2 = 1/A$
  - orice portofoliu de pe frontieră combină oricare două portofolii distincte de pe frontieră, de exemplu GMV și tangentul (dacă $B \neq 0$)

Frontiera sectoarelor din SUA



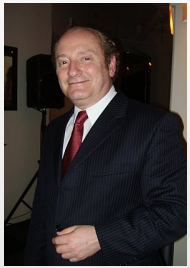
- Randamente lunare în exces, ianuarie 1999 – iulie 2026 ($T = 331$); axele anualizate, în zecimale
- Toți parametrii estimați pe tot eșantionul: o imagine **în eșantion**
- Raportul Sharpe: tangent 0,66, GMV 0,57 (volatilitate 11,1%), 1/N 0,54
- Ponderile tangente includ poziții short: $-0{,}37$ financiar, $-0{,}21$ materiale
- Cea mai mare poziție long a portofoliului tangent: $+0{,}37$ sănătate
- Tangent long-only: Sharpe 0,61
- Materialele, financiarul și industria primesc exact zero, o **soluție de colț**
- Cîștigul față de 1/N este mic chiar dacă se folosește întregul eșantion istoric

MFM_ch4_frontier

Restricții

- **Long-only** (LO): $w_i \geq 0$
- Fără formă închisă, se rezolvă prin programare pătratică
- Limite pe poziții: $w_i \leq 0{,}2$
- Limite pe sectoare sau clase de active: $\sum_{i \in G} w_i \leq c_G$, G un grup de active, c_G plafonul lui
- Limită de levier: $\sum_i |w_i| \leq L$
- $\sum_i |w_i|$: expunerea brută, $L = 1$ înseamnă fără vînzări în lipsă
- Frost & Savarino (1988): restricționarea ponderilor a îmbunătățit rezultatele în afara eșantionului
- Explicația: restricțiile acționează ca un shrinkage al covarianței (Jagannathan & Ma (2003); slide-ul Restricțiile ca formă de shrinkage)

Imprecizia mediilor estimate: argumentul lui Merton

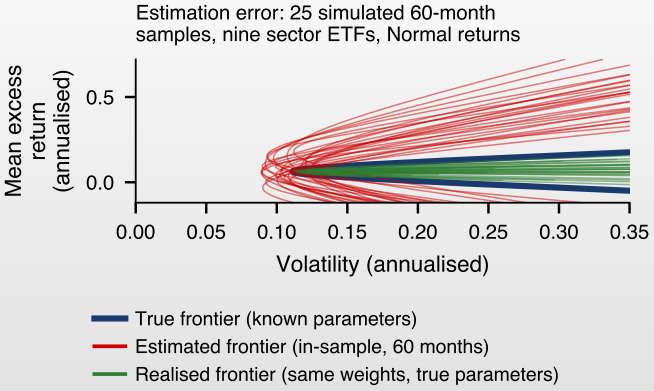


Robert C. Merton, Premiul Nobel pentru economie 1997

Foto: Digarnick (2006); domeniu public; Wikimedia Commons

- Merton (1980): Y ani observați de h ori pe an, randamente i.i.d. din distribuția Normală (o difuzie) cu media anuală μ și varianța σ^2
  - $\mathrm{Var}(\hat{\mu}) = \sigma^2/Y$: nu depinde de h
  - precizia crește doar cu **lungimea** eșantionului
  - $\mathrm{Var}(\hat{\sigma}^2) \approx 2\sigma^4/(hY) \to 0$ cînd $h \to \infty$ (distribuția Normală; în general $(\kappa - 1)\sigma^4/(hY)$, κ kurtosisul): varianța se estimează mai precis pe măsură ce crește frecvența
- SPY, $Y = 24$, $\sigma = 14{,}7\%$: eroarea standard 3,0%, intervalul de 95% [5,8%; 17,6%] pentru o medie de 11,7%
- O eroare standard de 1% cere $(0{,}147/0{,}01)^2 \approx 217$ ani
- Chopra & Ziemba (1993): erorile de estimare a mediilor costă de circa zece ori mai mult decît cele ale variațelor
- Regulile care nu folosesc medii (GMV, risk parity) sînt mai robuste

Maximizarea erorii: frontiere estimate față de frontiere realizate (1/2)



MFM_ch4_estimation_error

Maximizarea erorii: frontiere estimate față de frontiere realizate (2/2)

- Michaud (1989): optimizatorii sînt **maximizatori ai erorii de estimare**
- Best & Grauer (1991): o mică schimbare într-o medie mută multe ponderi
- Parametrii adevărați = momentele sectoarelor 1999–2026: se extrag 60 de luni din distribuția Normală, se optimizează și se evaluează cu parametrii adevărați
- Graficul arată 25 de eșantioane simulate de 60 de luni, axele anualizate, în zecimale
- Roșu: frontierele estimate, sistematic prea optimiste
- Verde: aceleași portofolii cu parametrii adevărați, toate sub frontiera adevărată
- 2 000 de portofolii tangente simulate: Sharpe maxim estimat median 1,56, Sharpe adevărat median 0,30, optimul adevărat 0,66
- 96% dintre ele au un Sharpe adevărat sub cel al lui 1/N (0,54), iar 7,5% au un Sharpe adevărat negativ
- În 11% din eșantioane $\hat{B} = 1^\top \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\mu}} < 0$, deci formula tangentă dă portofoliul cu Sharpe minim

MFM_ch4_estimation_error

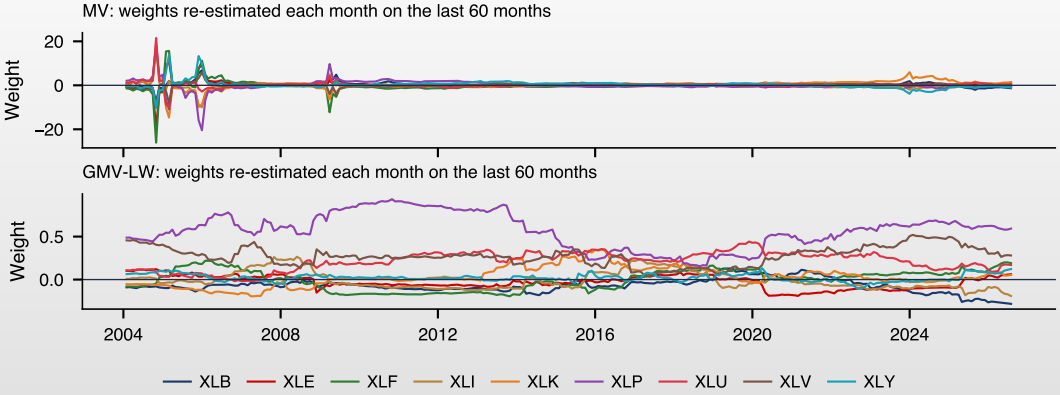
Raportul Sharpe estimat direct este deplasat

- Randamente i.i.d. $N(\mu, \Sigma)$, T luni, N active (Kan & Zhou (2007); momentele Wishart în Anexă)
  - $\hat{\theta}^2 = \hat{\mu}^\top \hat{\Sigma}^{-1} \hat{\mu}$: pătratul raportului Sharpe maxim în eșantion, din $\hat{\mu}$ și $\hat{\Sigma}$ de verosimilitate maximă
  - θ^2: valoarea lui adevărată

$$\mathbb{E}[\hat{\theta}^2] = \frac{T}{T-N-2}\left(\theta^2 + \frac{N}{T}\right) = \frac{T\theta^2 + N}{T-N-2}, \qquad T > N+2$$

- Sectoare: $N = 9$, $T = 60$, θ adevărat $= 0{,}66$ pe an: $\sqrt{12\,\mathbb{E}[\hat{\theta}^2]} = 1{,}65$ pe an, o medie pătratică, nu o mediană
  - mediana simulată 1,56 este mai mică: $\hat{\theta}$ are asimetrie la dreapta, iar simularea folosește numitorul $T-1$ în $\hat{\Sigma}$; derivarea formulei: Seminarul 4, A8
- Estimatorul nedeplasat al lui θ^2: $\hat{\theta}_u^2 = \left[(T-N-2)\,\hat{\theta}^2 - N\right]/T$
  - Poate fi negativ
  - Trunchierea la zero dă un estimator nenegativ, dar deplasat în sus, iar $\sqrt{\hat{\theta}_u^2}$ nu este nedeplasat pentru θ
- Sectoare, tot eșantionul ($T = 331$): $\hat{\theta} = 0{,}66$ estimat direct, $\sqrt{\hat{\theta}_u^2} = 0{,}31$ pe an după corecție
  - peste jumătate din raportul Sharpe în eșantion se datorează zgomotului, chiar și pe 27 de ani
- Ponderile tangente sînt coeficienții regresiei lui 1 pe randamente, estimată prin metoda celor mai mici pătrate (OLS, ordinary least squares) (Britten-Jones (1999); Anexă; Seminarul 4, A9 și B6)

Ponderi instabile (1/2)



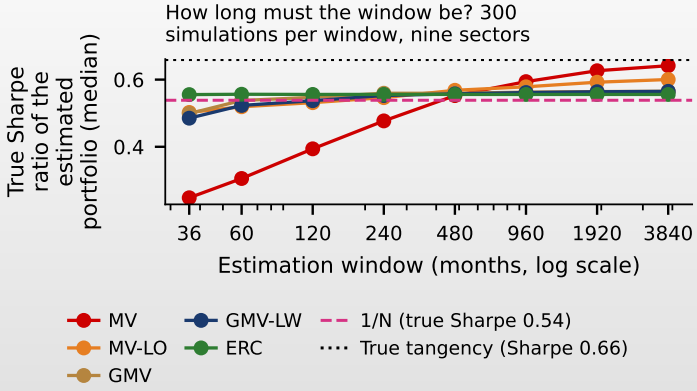
MFM_ch4_oos_backtest

Ponderi instabile (2/2)

- Nouă ETF-uri sectoriale
- În fiecare lună ponderile folosesc doar ultimele 60 de luni
- MV: expunerea brută mediană este $\sum_i |w_i| = 4{,}9$ și depășește 3 în 90% din luni
- Cea mai mare pondere individuală a lui MV ajunge la 26 în valoare absolută
- Salturi extreme în 2004–2006 și 2009: numitorul $1^\top \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\mu}}$ este aproape de zero, deci ponderile tangente au cozi foarte groase
  - Negativ în 12 din 271 de ferestre: MV deține atunci portofoliul cu Sharpe minim
- GMV-LW (jos): expunere brută 1,5, cea mai mare pondere 0,94
- Ponderile instabile înseamnă turnover mare, deci costuri mari de tranzacționare

MFM_ch4_oos_backtest

Lungimea ferestrei necesară pentru a depăși 1/N (1/2)



MFM_ch4_window_length

Lungimea ferestrei necesară pentru a depăși 1/N (2/2)

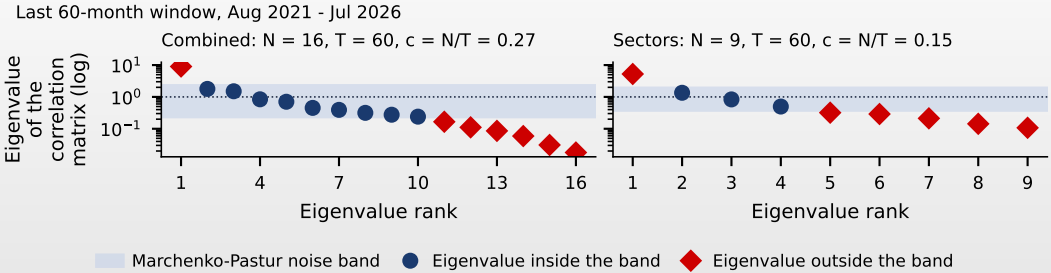
- DeMiguel, Garlappi & Uppal (2009): niciunul dintre cele 14 modele, pe 7 seturi de date, nu depășește consecvent 1/N în raport Sharpe, randament echivalent cert (media $-\frac{\gamma}{2}\times$ varianța, randamentul fără risc care aduce aceeași utilitate) sau turnover
- Pentru 25 de active, calibrarea lor ar necesita circa 3 000 de luni
- Aici: 300 de eșantioane simulate pentru fiecare fereastră, parametrii populației = momentele sectoarelor
- MV depășește 1/N abia la 480 de luni (40 de ani): Sharpe adevărat median 0,55 față de 0,54, dar doar 0,31 cu o fereastră de 60 de luni (0,30 în cele 2 000 de simulări de pe slide-ul Maximizarea erorii)
- MV-LO, GMV, GMV-LW sînt aproape de 1/N de la 60 de luni
- ERC este aproape insensibil la lungimea ferestrei, cu un Sharpe adevărat median de 0,56
- În această calibrare 1/N este aproape eficient (tangentul adevărat 0,66): rezultat de simulare, nu un test empiric

MFM_ch4_window_length

Limitele matricei de covarianță de eșantion

- Valorile proprii de eșantion sînt prea dispersate: cele mari prea mari, cele mici prea mici
- **Numărul de condiționare**: cea mai mare valoare proprie împărțită la cea mai mică
- O valoare mare înseamnă că $\boldsymbol{\Sigma}^{-1}$ amplifică zgomotul
- Optimizatorii inversează $\boldsymbol{\Sigma}$, deci pun ponderi mari pe direcțiile cu cea mai mică varianță estimată
- Matricea de eșantion centrată are rangul cel mult $T-1$: este singulară, deci neinversabilă, ori de cîte ori $T \leq N$
- Reperul **Marchenko–Pastur** (Marčenko & Pastur (1967)): randamente i.i.d. cu $\boldsymbol{\Sigma} = \sigma^2 \mathbf{I}$ ($\mathbf{I}$: matricea identitate)
  - cînd $N, T \to \infty$ cu $N/T \to c \in (0,1)$, valorile proprii de eșantion acoperă intervalul
    $$\left[\lambda_-, \lambda_+\right] = \left[\sigma^2(1-\sqrt{c})^2,\ \sigma^2(1+\sqrt{c})^2\right]$$
  - λ_-, λ_+: cea mai mică și cea mai mare valoare proprie produse de zgomotul pur
  - $c = 16/60 = 0{,}27$: banda $[0{,}23; 2{,}30]$ pentru o matrice de corelație ($\sigma^2 = 1$), un raport de zece între extreme, generat numai de zgomot
  - Laloux et al. (1999): valorile proprii din afara benzii sînt candidate la structură
  - cele din interior nu se pot deosebi de zgomot doar prin această comparație

Valorile proprii de eșantion și banda de zgomot



- Matrice de corelație ale randamentelor lunare în exces, ultima fereastră de 60 de luni (august 2021 – iulie 2026), cu banda colorată $[\lambda_-, \lambda_+]$ pentru $\sigma^2 = 1$
- Doar valoarea proprie a pieței depășește λ_+: 9,0 (56% din urma matricei) la 16 ETF-uri, 5,2 la nouă sectoare ($\lambda_+ = 1{,}92$)
- Cu zgomotul rescalat la $\sigma^2 = 1 - \lambda_1/N$ (Laloux et al. (1999)), trei valori proprii depășesc banda în fiecare univers
- Șase din 16 valori proprii sînt **sub** bandă: combinații aproape fără risc, de exemplu long TLT și short IEF
- GMV pune ponderi mari pe aceste combinații; dacă varianța lor este subestimată, este subestimat și riscul GMV

MFM_ch4_inference

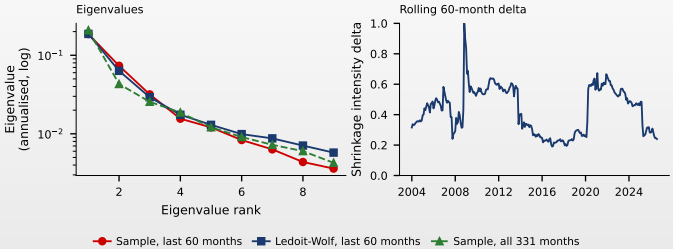
Estimatorul de shrinkage

- Matricea de eșantion S este trasă spre o țintă structurată F

$$\hat{\mathbf{\Sigma}}_{\mathsf{LW}} = \delta\,\mathsf{F} + (1-\delta)\,\mathsf{S}, \qquad 0 \leq \delta \leq 1$$

- Ținte
  - Modelul cu un singur indice (al pieței): Ledoit & Wolf (2003)
  - Identitatea scalată: Ledoit & Wolf (2004a)
  - Corelația constantă, $f_{ii} = s_{ii}$ și $f_{ij} = \bar{r}\sqrt{s_{ii}s_{jj}}$ pentru $i \neq j$, $\bar{r}$ corelația medie de eșantion: Ledoit & Wolf (2004b), folosită aici
- δ echilibrează varianța lui S cu deplasarea lui F; δ este mare cînd S este zgomotoasă sau cînd ținta F este apropiată de $\mathbf{\Sigma}$
- Pentru eșantioane lungi, $\delta \to 0$ (δ^* optim în Anexă)

Shrinkage pe sectoarele din SUA



- Nouă ETF-uri sectoriale, randamente lunare în exces
- Pe ultima fereastră, august 2021 – iulie 2026, intensitatea shrinkage-ului este $\delta = 0{,}24$
- Cele mai mici valori proprii cresc, cele mai mari rămîn aproape neschimbate
- Numărul de condiționare scade de la 51,6 la 32,5
- Pe ferestre mobile, δ are media 0,43 și variază între 0,19 și 1,00
- $\delta = 1$ în primele ferestre, unde 60 de luni sînt prea puține pentru ca matricea de eșantion să fie preferabilă țintei
- GMV-LW: portofoliul GMV calculat cu $\hat{\boldsymbol{\Sigma}}_{\mathbf{LW}}$

MFM_ch4_shrinkage

Restricțiile ca formă de shrinkage

- Jagannathan & Ma (2003): GMV long-only este egal cu GMV fără restricții al unei matrice de covarianță modificate

$$\tilde{S} = S - (\boldsymbol{\lambda} 1^\top + 1\boldsymbol{\lambda}^\top), \qquad \mathcal{L} = \tfrac{1}{2} w^\top S w - \lambda_0 (w^\top 1 - 1) - \boldsymbol{\lambda}^\top w$$

  - $\boldsymbol{\lambda} \geq 0$: multiplicatorii Lagrange ai restricțiilor $w_i \geq 0$ din $\mathcal{L}$
  - $\lambda_i > 0$ doar unde restricția este activă
  - Condiția de ordinul întîi $Sw = \lambda_0 1 + \boldsymbol{\lambda}$ și $\boldsymbol{\lambda}^\top w = 0$ dau $\tilde{S}w = \lambda_0 1$: condiția GMV pentru $\tilde{S}$
  - pas cu pas, cu bugetul $1^\top w = 1$: $\tilde{S}w = Sw - \boldsymbol{\lambda}(1^\top w) - 1(\boldsymbol{\lambda}^\top w) = \lambda_0 1 + \boldsymbol{\lambda} - \boldsymbol{\lambda} - 0$
- $\tilde{s}_{ij} = s_{ij} - \lambda_i - \lambda_j$: o restricție activă pe activul i îi reduce covariațele, ceea ce corectează în jos estimările mari
  - de ce acolo: GMV fără restricții vinde în lipsă activele cu covariațe mari cu celelalte, deci $w_i \geq 0$ devine activă exact pentru ele, iar covariațele lor mari sînt cele mai probabil umflate de zgomot
- Restricția „greșită" (fără vînzări în lipsă) poate reduce riscul în afara eșantionului
- Efectul este cel mai mare cînd covariațele sînt estimate din puține observații

Restricțiile ca shrinkage: un exemplu cu două active

- $\sigma_1 = 25\%$, $\sigma_2 = 10\%$, $\rho = 0{,}5$: $s_{11} = 0{,}0625$, $s_{22} = 0{,}0100$, $s_{12} = 0{,}0125$
- GMV fără restricții: $w_1^* = (s_{22} - s_{12})/(s_{11} + s_{22} - 2s_{12}) = -0{,}0025/0{,}0475 = -0{,}053$
  - activul volatil este vîndut în lipsă pentru că evoluează puternic împreună cu celălalt; volatilitatea 9,93%
- Long-only: restricția $w_1 \geq 0$ devine activă, $\mathrm{w} = (0, 1)$, volatilitatea 10%
  - condiția de ordinul întîi: $\mathrm{Sw} = (s_{12}, s_{22}) = (0{,}0125;\ 0{,}0100) = \lambda_0 1 + \boldsymbol{\lambda}$, deci $\lambda_0 = 0{,}0100$, $\boldsymbol{\lambda} = (0{,}0025;\ 0)$
- Matricea modificată: $\tilde{s}_{12} = 0{,}0125 - 0{,}0025 = 0{,}0100$, $\tilde{s}_{11} = 0{,}0625 - 2(0{,}0025) = 0{,}0575$, $\tilde{s}_{22} = 0{,}0100$
  - corelația scade de la 0,5 la $0{,}0100/\sqrt{0{,}0575 \times 0{,}0100} \approx 0{,}42$; și dispersia primului activ scade
  - GMV fără restricții pentru $\tilde{\mathrm{S}}$: $w_1^* = (0{,}0100 - 0{,}0100)/(\cdots) = 0$, adică soluția long-only

Shrinkage neliniar

- Shrinkage-ul liniar amestecă două matrice cu un singur δ
  - shrinkage-ul **neliniar** păstrează vectorii proprii de eșantion și corectează separat fiecare valoare proprie
  - Ledoit & Wolf (2017): calibrat pentru alegerea portofoliului
  - Ledoit & Wolf (2020): o formulă analitică, fără optimizare
- În afara eșantionului, fereastră de 60 de luni, volatilitatea GMV
  - Sectoare: eșantion 11,90%, liniar (corelație constantă) 11,80%, neliniar 11,62%
  - 16 ETF-uri: eșantion 4,06%, liniar 4,38%, neliniar 4,31%: neliniarul este mai bun decît shrinkage-ul liniar, dar nu și decît matricea de eșantion
- O corelație constantă nu descrie nici perechile acțiuni–acțiuni (corelații pozitive), nici perechile acțiuni–obligațiuni (corelații negative): alegerea țintei contează (Seminarul 4, B7)
- Regulă practică: aplicați shrinkage, restricții sau ambele
- Matricea de eșantion brută devine inutilizabilă cînd N se apropie de T (singulară pentru $T \leq N$); la $N = 16$, $T = 60$ ea a fost încă competitivă

De la shrinkage-ul covarianței la shrinkage-ul mediilor



Fischer Black (1938–1995)

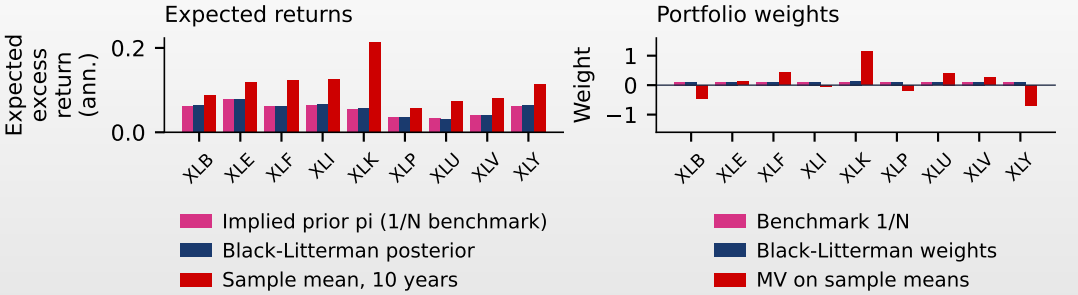
Foto: Dalmatine, Wikipedia în limba engleză; domeniu public; Wikimedia Commons

- Shrinkage-ul corectează $\hat{\boldsymbol{\Sigma}}$
- Black & Litterman (1992), dezvoltat la Goldman Sachs, contractă mediile spre cele implicate de un portofoliu **de referință** w_b
- Optimizarea inversă: un investitor medie–variață cu aversiunea la risc $\delta_{\mathbf{RA}}$ și acces la numerar deține $w^* = (\delta_{\mathbf{RA}} \boldsymbol{\Sigma})^{-\mathbf{1}} \boldsymbol{\mu}$ în active riscante
- Randamentele care fac w_b optim sînt

$$\boldsymbol{\pi} = \delta_{\mathbf{RA}} \boldsymbol{\Sigma} w_b$$

- $\boldsymbol{\pi}$: randamente în exces **implicite** (de echilibru)
- Cu ponderile pieței, ele sînt randamentele CAPM
- Aici: capitalizările sectoarelor nu sînt disponibile, deci $w_b = 1/N$, $\delta_{\mathbf{RA}} = 2{,}5$
- Apoi se adaugă **opiniile** investitorului, ponderate cu încrederea în ele: ponderile se îndepărtează de reper doar unde există opinii

Black–Litterman pe sectoarele din SUA (1/2)



MFM_ch4_black_litterman

Black–Litterman pe sectoarele din SUA (2/2)

- $\boldsymbol{\Sigma}$ din randamentele lunare în exces, august 2016 – iulie 2026, și o singură opinie: XLK minus XLU $= 3\%$ pe an
- Diferența implicită XLK minus XLU este 2,2%, iar cea a posteriori 2,6%
- Ponderi: XLK de la 11,1% la 14,4%, XLU de la 11,1% la 7,8%, restul neschimbate
  - Opinia este relativă ($P1 = 0$), deci ajustarea $\propto P^\top$ are suma zero, iar portofoliul rămîne complet investit
- Cu mediile de eșantion (XLK: 21,3% pe an), ponderile MV ar deveni $+115\%$ în XLK, -68% în XLY și -46% în XLB
- Calculul de mînă al ponderilor XLK și XLU: Seminarul 4, A7

MFM_ch4_black_litterman

Opiniile și distribuția a posteriori

- K opinii: $\mathrm{P}\boldsymbol{\mu} = \mathrm{q} + \boldsymbol{\varepsilon}$, $\boldsymbol{\varepsilon} \sim N(0, \boldsymbol{\Omega})$
  - a priori $\boldsymbol{\mu} \sim N(\boldsymbol{\pi}, \tau\boldsymbol{\Sigma})$
  - P: matrice $K \times N$, linia k = portofoliul opiniei k
  - q: randamentele din opinii
  - $\boldsymbol{\Omega}$: incertitudinea lor
  - τ: scalează incertitudinea distribuției a priori $\boldsymbol{\pi}$
- Ponderile Black–Litterman: $\mathrm{w}_{\mathbf{BL}} = (\delta_{\mathbf{RA}}\boldsymbol{\Sigma})^{-\mathbf{1}}\boldsymbol{\mu}_{\mathbf{BL}}$
- Media a posteriori este o medie ponderată cu preciziile

$$\boldsymbol{\mu}_{\mathbf{BL}} = \left[(\tau\boldsymbol{\Sigma})^{-\mathbf{1}} + \mathrm{P}^{\top}\boldsymbol{\Omega}^{-\mathbf{1}}\mathrm{P}\right]^{-\mathbf{1}}\left[(\tau\boldsymbol{\Sigma})^{-\mathbf{1}}\boldsymbol{\pi} + \mathrm{P}^{\top}\boldsymbol{\Omega}^{-\mathbf{1}}\mathrm{q}\right]$$

- Limite: $\boldsymbol{\Omega} \to 0$ dă exact $\mathrm{P}\boldsymbol{\mu}_{\mathbf{BL}} = \mathrm{q}$
- $\boldsymbol{\Omega} \to \infty$ dă $\boldsymbol{\pi}$
- Fără opinii se obține chiar portofoliul de referință
- He & Litterman (2002): $\tau = 0{,}05$, $\boldsymbol{\Omega} = \mathrm{diag}(\mathrm{P}\,\tau\boldsymbol{\Sigma}\,\mathrm{P}^{\top})$
- Cînd ponderile folosesc aceeași $\boldsymbol{\Sigma}$, se modifică doar ponderile activelor din opinii
- Un activ, $\pi = 5\%$, $\tau\sigma^{\mathbf{2}} = 0{,}00128$, opinia 8% cu varianța 0,0004: $\mu_{\mathbf{BL}} = 7{,}29\%$, ponderea opiniei 0,76
- Același estimator este o regresie mixtă estimată prin cele mai mici pătrate generalizate (GLS, generalised least squares) (Theil & Goldberger (1961); Anexă; Seminarul 4, A6)

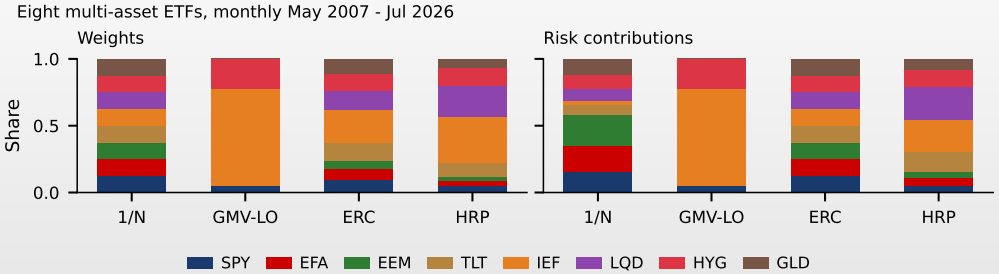
Black–Litterman: rolul lui δ_{RA} și τ

- $\delta_{\text{RA}} = 2{,}5$ și $\tau = 0{,}05$ sînt valorile din He & Litterman (2002)
- **Aversiunea la risc**: se înmulțește $\boldsymbol{\pi} = \delta_{\text{RA}} \boldsymbol{\Sigma} \mathrm{w}_b$ la stînga cu $\mathrm{w}_b^\top$

$$\delta_{\text{RA}} = \frac{\mathrm{w}_b^\top \boldsymbol{\pi}}{\mathrm{w}_b^\top \boldsymbol{\Sigma} \mathrm{w}_b} = \frac{\text{randamentul în exces al reperului}}{\text{varianța reperului}}$$

  - de exemplu, 6% randament în exces la volatilitatea 15,5%: $0{,}06/0{,}155^2 = 2{,}5$
  - $\boldsymbol{\pi}$ este liniar în δ_{RA}: dublarea lui dublează diferența implicită XLK minus XLU de 2,2%
- **Incertitudinea a priori**: $\tau\boldsymbol{\Sigma}$ este incertitudinea asupra mediei; o interpretare este $\tau \approx 1/Y$, varianța unei medii estimate pe Y ani raportată la $\boldsymbol{\Sigma}$ (argumentul lui Merton), deci $\tau = 0{,}05$ corespunde la circa 20 de ani de date
- Cu $\boldsymbol{\Omega} = \operatorname{diag}(\mathrm{P}\,\tau\boldsymbol{\Sigma}\,\mathrm{P}^\top)$ și o singură opinie, τ se simplifică: diferența a posteriori este mijlocul $(2{,}2\% + 3\%)/2 = 2{,}6\%$, iar ponderile nu depind de τ
- Încrederea în opinie este dată de $\boldsymbol{\Omega}$ relativ la $\tau\boldsymbol{\Sigma}$, nu de τ singur

Ponderi și contribuții la risc



- Opt ETF-uri multi-active, matricea de covarianță pe tot eșantionul, mai 2007 – iulie 2026 ($T = 231$); cotele din grafic sînt în zecimale (0,5 = 50%)
- 1/N: acțiunile și high yield primesc jumătate din pondere, dar generează 69% din risc
  - ERC: fiecare activ contribuie cu 12,5% la risc, iar IEF primește cea mai mare pondere (25%)
  - GMV long-only: 73% IEF, 22% HYG, 5% SPY, cinci active cu pondere zero
- Volatilitate: 1/N 9,4%, ERC 7,9%, HRP 7,1%, GMV long-only 5,8%: ERC se află între 1/N și GMV, conform teoriei

MFM_ch4_risk_contrib

Contribuțiile la risc

- Volatilitatea este omogenă de gradul întîi în ponderi (Euler)

$$\sigma_p = \sum_{i=1}^{N} w_i \frac{\partial \sigma_p}{\partial w_i} = \sum_{i=1}^{N} \frac{w_i (\Sigma \mathrm{w})_i}{\sigma_p}$$

- **Contribuția la risc** a activului i: $RC_i = w_i(\Sigma \mathrm{w})_i/\sigma_p$
- Cota procentuală $RC_i/\sigma_p = w_i(\Sigma \mathrm{w})_i/\sigma_p^2$
- Exemplu numeric, 50/50 în SPY și IEF (lunar 2002–2026, anualizat): $\sigma_1^2 = 0{,}02166$, $\sigma_2^2 = 0{,}00441$, $\sigma_{12} = -0{,}00098$
  - $(\Sigma \mathrm{w})_1 = 0{,}5(0{,}02166) + 0{,}5(-0{,}00098) = 0{,}01034$, $(\Sigma \mathrm{w})_2 = 0{,}5(-0{,}00098) + 0{,}5(0{,}00441) = 0{,}00172$
  - $\sigma_p^2 = 0{,}5(0{,}01034) + 0{,}5(0{,}00172) = 0{,}00603$, $\sigma_p = 7{,}76\%$
  - cotele din risc: SPY 85,8%, IEF 14,2%
- Ponderile egale nu înseamnă riscuri egale: riscul este dominat de activele volatile
- Bugetarea riscului alege w astfel încît cotele să fie egale cu bugetele fixate b_i

Contribuții egale la risc (ERC)

- ERC (Maillard, Roncalli & Teïletche (2010)): $RC_i = RC_j$ pentru orice i, j
- Ponderile se calculează dintr-o problemă convexă, apoi se normalizează

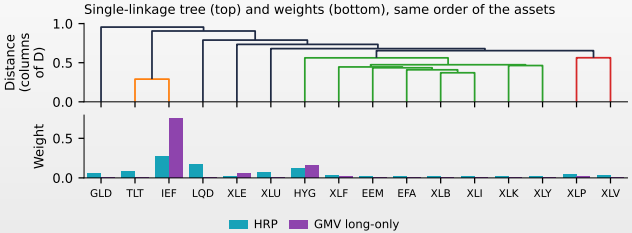
$$\min_{\mathrm{y}>0} \ \tfrac{1}{2}\mathrm{y}^\top \boldsymbol{\Sigma}\mathrm{y} - \tfrac{1}{N}\textstyle\sum_i \ln y_i, \qquad \mathrm{w} = \mathrm{y}/1^\top\mathrm{y}$$

  - y: ponderi pozitive nenormalizate
  - termenul logaritmic menține $y_i > 0$, iar condiția de ordinul întîi dă $y_i(\boldsymbol{\Sigma}\mathrm{y})_i = 1/N$ pentru orice i
- Pentru $\boldsymbol{\Sigma}$ pozitiv definită soluția există și este unică (obiectiv strict convex, infinit la frontieră)
- Ordinea volatilităților: $\sigma_{\mathrm{GMV}} \le \sigma_{\mathrm{ERC}} \le \sigma_{1/N}$
- Două active: ERC înseamnă **inversul volatilității**, $w_1 = \sigma_1^{-1}/(\sigma_1^{-1} + \sigma_2^{-1})$, pentru orice $\rho \in (-1, 1)$
  - SPY (14,7%) și IEF (6,6%): ERC deține 31% SPY, volatilitate 6,1%, fiecare activ contribuind cu 50% la variantă
- Nu are nevoie de randamente așteptate, doar de $\boldsymbol{\Sigma}$
- ERC este portofoliul tangent dacă toate activele au același raport Sharpe și corelații egale

Hierarchical Risk Parity: de la arbore la ponderi

- HRP (López de Prado (2016)): trei pași, fără inversarea matricei, toate ponderile pozitive
  - funcționează chiar dacă $\mathbf{\Sigma}$ este singulară
- **Pasul 1, arborele**
  - distanța de corelație $d_{ij} = \sqrt{(1-\rho_{ij})/2} \in [0,1]$
  - ρ_{ij}: corelația activelor i și j
  - distanța euclidiană dintre **coloanele** lui $\mathrm{D} = (d_{ij})$: $\tilde{d}_{ij} = \sqrt{\sum_k (d_{ki} - d_{kj})^2}$
  - legătura simplă pe $\tilde{d}_{ij}$ (se unesc repetat cele mai apropiate două grupuri) dă o **dendrogramă**
- **Pasul 2, cvasi-diagonalizarea**
  - activele se ordonează ca frunzele arborelui, astfel încît cele asemănătoare sînt vecine
- **Pasul 3, bisecția recursivă**: **lista ordonată** se împarte în două jumătăți
  - fiecare jumătate primește pondere invers proporțională cu varianța ei $\tilde{\mathrm{w}}^\top \mathbf{\Sigma} \tilde{\mathrm{w}}$
  - $\tilde{\mathrm{w}}$: ponderile invers proporționale cu varianța în interiorul jumătății
  - se repetă în fiecare jumătate, pînă rămîn active individuale
- Mantegna (1999): aceeași distanță și **arborele de acoperire minim** arată ierarhia unei piețe de acțiuni
- Manual: Härdle & Simar (2019), analiza cluster
- Un exemplu rezolvat cu patru active: Seminarul 4, B4

HRP pe 16 ETF-uri



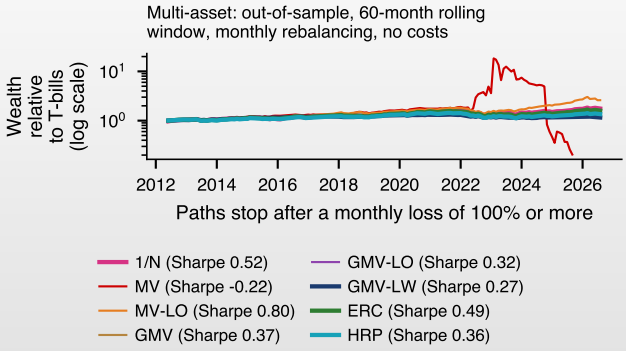
- Nouă sectoare și șapte ETF-uri multi-active, lunar, mai 2007 – iulie 2026
- Cea mai apropiată pereche este TLT–IEF ($\tilde{d} = 0{,}29$)
- Aurul se alătură ultimul ($\tilde{d} = 0{,}96$)
- Grupul de acțiuni: sectoarele ciclice, EFA, EEM și creditul high yield
- Sectoarele defensive (utilități, bunuri de consum de bază, sănătate) și energia i se alătură tîrziu
- HRP: toate cele 16 ponderi sînt pozitive; cele mai mari sînt IEF 26,7%, LQD 17,6% și HYG 12,6%
- GMV long-only: 75,6% în IEF și doar cinci active cu pondere nenulă

MFM_ch4_hrp

Protocolul de backtesting

- Fereastră mobilă de 60 de luni, reechilibrare lunară
- Ponderile lunii t folosesc doar lunile $t-60, \ldots, t-1$
- Opt reguli: 1/N, MV, MV-LO, GMV, GMV-LO, GMV-LW, ERC, HRP
- Trei universuri
  - Sectoare: în afara eșantionului ianuarie 2004 – iulie 2026, 271 de luni (prima fereastră ianuarie 1999 – decembrie 2003)
  - Multi-active și combinat: mai 2012 – iulie 2026, 171 de luni
- Media, volatilitatea și raportul Sharpe anualizate ale randamentelor în exces
- Drawdown-ul maxim al averii din randamente totale
- Fiecare diferență de Sharpe se raportează cu un test (slide-urile următoare), iar toate testele efectuate intră în corecția pentru testare multiplă

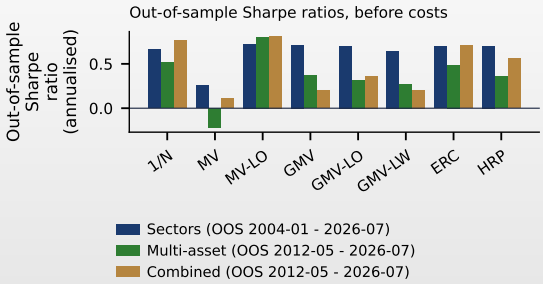
Evoluția averii în afara eșantionului: multi-active



- Opt ETF-uri multi-active: averea relativă la un cont în titluri de stat, înainte de costuri
- MV eșuează complet: volatilitate 518% pe an, turnover de 44 de ori averea pe lună, iar o pierdere lunară de peste 100% anulează averea
- MV-LO are cel mai mare Sharpe (0,80), urmat de 1/N (0,52) și ERC (0,49)
- Regulile GMV: cea mai mică volatilitate (3,8%–5,4%), Sharpe scăzut (0,27–0,37)
- Pun ponderi mari pe titlurile de stat, ale căror randamente în exces au fost ușor negative după mai 2012 (TLT −0,5%, IEF −0,2% pe an)
- Superioritatea MV-LO poate fi reală sau întîmplătoare: este necesar un test statistic

MFM_ch4_oos_backtest

Rapoartele Sharpe în cele trei universuri



- Fereastră mobilă de 60 de luni, reechilibrare lunară, anualizat, înainte de costuri
- Tabelele complete pentru toate cele trei universuri în Anexă
- Sectoare: rapoartele Sharpe ale tuturor regulilor, cu excepția MV, se situează la cel mult 0,07 de cel al lui 1/N (0,66)
- Sharpe-ul în afara eșantionului al lui 1/N (0,66, 2004–2026) diferă de cel din simulări (0,54, 1999–2026) pentru că perioadele diferă; coincidența cu Sharpe-ul tangent adevărat (0,66) nu are semnificație
- MV are Sharpe 0,26 și un drawdown de -100%
- Universul combinat: Sharpe 0,76 pentru 1/N, 0,81 pentru MV-LO, 0,71 pentru ERC
- Regulile GMV au Sharpe între 0,20 și 0,36
- Turnover lunar pe sectoare: 1/N 0,02, ERC 0,03, GMV-LW 0,14, MV-LO 0,23, MV 3,86

MFM_ch4_oos_backtest

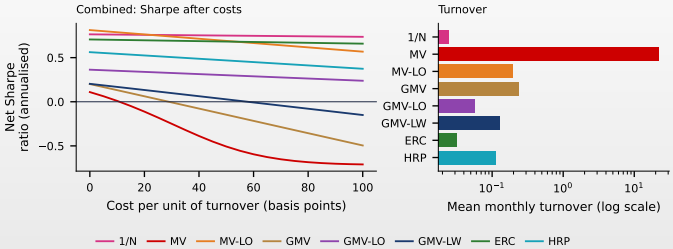
Turnover și costuri: un exemplu numeric pe o lună (1/2)

- Între reechilibrări ponderile se modifică odată cu randamentele (drift): $w_{i,t}^{+} = w_{i,t}(1 + R_{i,t}) / \sum_j w_{j,t}(1 + R_{j,t})$
  - $R_{i,t}$: randamentul **total** al activului i în luna t; numitorul este $1 + R_{p,t}$, unu plus randamentul total al portofoliului
- **Turnover**: fracțiunea din avere tranzacționată, $TO_{t+1} = \sum_i |w_{i,t+1} - w_{i,t}^{+}|$, însumată pe toate cele N active
- Exemplu numeric, sectoare, 1/N: în ianuarie 2004 XLB a avut $-4{,}4\%$ și XLK $+4{,}3\%$, deci ponderile de 11,11% s-au modificat (drift) la 10,50% și 11,45%
  - randamentul total al lui 1/N în ianuarie 2004: 1,18% (în exces 1,11%, plus titlul de stat 0,07%; Seminarul 4, B1)
  - XLB: $\frac{1}{9}(1 - 0{,}044)/1{,}0118 = 10{,}50\%$; XLK: $\frac{1}{9}(1 + 0{,}043)/1{,}0118 = 11{,}45\%$

Turnover și costuri: un exemplu numeric pe o lună (2/2)

- Revenirea la 1/N în februarie 2004 tranzacționează $TO = 0{,}019$: și 1/N tranzacționează, vinde cîștigătorii și cumpără perdanții
  - XLB și XLK contribuie cu $|0{,}1111 - 0{,}1050| + |0{,}1111 - 0{,}1145| = 0{,}0061 + 0{,}0034 = 0{,}0095$; celelalte șapte sectoare, împreună, cu circa 0,009
  - MV-LO, reestimat pe noua fereastră, tranzacționează 0,748 în aceeași lună
- Randamentul net cu costul c pe unitate tranzacționată: $R^{\text{net}}_{p,t} = R_{p,t} - c\, TO_t$
  - 1 punct de bază (bp) $= 0{,}01\%$, deci 20 bp înseamnă $c = 0{,}002$
  - La 20 bp, tranzacția din februarie costă MV-LO $0{,}002 \times 0{,}748 = 0{,}15\%$ din avere, iar 1/N $0{,}002 \times 0{,}019 = 0{,}004\%$

Rapoartele Sharpe după costuri



- Universul combinat (16 ETF-uri)
- Costul c variază între 0 și 100 bp pe unitate de turnover
- Turnover-ul lunar variază de la 0,02 (1/N) la 22 (MV)
- Sharpe-ul net devine negativ la circa 11 bp pentru MV, 29 bp pentru GMV, 58 bp pentru GMV-LW
- MV-LO depășește 1/N doar la costuri sub circa 22 bp (Seminarul 4, B2)
- 1/N și ERC aproape nu se modifică: turnover-ul mic este un avantaj
- Raportați și rezultatele nete de costuri

MFM _ch4_ costs

Inferența pentru un raport Sharpe: Lo (2002)

- Lo (2002), randamente i.i.d. din distribuția Normală: $\sqrt{T}(\widehat{SR} - SR) \to N(0,\ 1 + SR^2/2)$, cu SR lunar și T numărul de luni: eroarea standard este $\sqrt{(1 + SR^2/2)/T}$
- 1/N pe sectoare, $T = 271$: $\widehat{SR}$ lunar $= 0{,}191$, eroarea standard $0{,}061$
  - Anualizat $0{,}66 \pm 1{,}96 \times 0{,}21$: intervalul de 95% $[0{,}25; 1{,}08]$
- Anualizarea cu $\sqrt{q}$ ($q = 12$ luni pe an) este exactă doar fără autocorelație
- În general, $SR(q) = \eta(q)\, SR$

$$\eta(q) = \frac{q}{\sqrt{q + 2\sum_{k=1}^{q-1}(q-k)\rho_k}}$$

  - ρ_k: autocorelația randamentelor lunare la lagul k
  - ρ_k pozitive scad η, ρ_k negative îl cresc
  - $\rho_k = 0$ dă $\eta = \sqrt{q}$
- Pentru 1/N pe sectoare: $\rho_1 = -0{,}03$, $\sum_{k=1}^{11} \rho_k = -0{,}11$; formula cere suma ponderată $\sum_{k=1}^{11}(12-k)\rho_k = -0{,}50$
  - $\eta = 12/\sqrt{12 - 2(0{,}50)} = 12/\sqrt{11{,}0} = 3{,}62$ în loc de $\sqrt{12} = 3{,}46$, Sharpe anual $0{,}191 \times 3{,}62 = 0{,}69$

Testarea unei diferențe de rapoarte Sharpe

- H_0: $SR_1 = SR_2$ pentru două strategii evaluate pe aceleași luni
- Jobson & Korkie (1981): un test pentru randamente i.i.d. din distribuția Normală
- Ledoit & Wolf (2008): o variantă robustă, prin metoda delta

$$\hat{\Delta} = \widehat{SR}_1 - \widehat{SR}_2 = f(\hat{\mathrm{v}}), \qquad f(\mathrm{v}) = \frac{\mu_1}{\sqrt{\mathbb{E}r_1^2 - \mu_1^2}} - \frac{\mu_2}{\sqrt{\mathbb{E}r_2^2 - \mu_2^2}}$$

  - r_{1t}, r_{2t}: randamentele în exces ale celor două strategii
  - μ_1, μ_2: mediile lor
  - $\mathrm{v} = (\mu_1, \mu_2, \mathbb{E}[r_1^2], \mathbb{E}[r_2^2])$
  - eroarea standard $\sqrt{\nabla f^\top \hat{\Psi} \nabla f / T}$
  - ∇f: gradientul lui f
  - $\hat{\Psi}$: o covarianță HAC (consistentă la heteroscedasticitate și autocorelație) a celor patru momente
- Strategiile pe aceleași active sînt puternic corelate: diferențe mici pot fi semnificative

Testul HAC pas cu pas

- Gradientul lui f în raport cu $\mathrm{v} = (\mu_1, \mu_2, \mathbb{E}[r_1^2], \mathbb{E}[r_2^2])$, cu notația $\sigma_i^2 = \mathbb{E}[r_i^2] - \mu_i^2$

$$\nabla f = \Big(\frac{\mathbb{E}[r_1^2]}{\sigma_1^3},\ -\frac{\mathbb{E}[r_2^2]}{\sigma_2^3},\ -\frac{\mu_1}{2\sigma_1^3},\ \frac{\mu_2}{2\sigma_2^3} \Big)$$

  - derivatele sînt în momentele de ordinul doi **necentrate**; un gradient în (μ_i, σ_i^2) nu se potrivește cu această $\hat{\mathbf{\Psi}}$

- $\hat{\mathbf{\Psi}}$: covarianța pe termen lung a lui $\mathrm{y}_t = (r_{1t} - \hat{\mu}_1,\ r_{2t} - \hat{\mu}_2,\ r_{1t}^2 - \widehat{\mathbb{E}r_1^2},\ r_{2t}^2 - \widehat{\mathbb{E}r_2^2})$

- P-value-urile HAC din tabelele capitolului: nucleul Bartlett (Newey–West) cu $\lfloor 4(T/100)^{2/9} \rfloor = 4$ laguri pentru orice T între 107 și 271; $z = \hat{\Delta}/\mathrm{SE}$, $p = 2[1 - \Phi(|z|)]$

- Bootstrap-ul studentizează cu altă eroare standard (nucleu pătratic-spectral cu prealbire, ▸ Anexă), deci cele două statistici diferă puțin
  - sectoare, MV-LO minus 1/N: $\hat{\Delta} = 0{,}063$; SE Bartlett 0,120, $z = 0{,}53$, p HAC $= 0{,}60$; SE pătratic-spectral (QS) 0,127, statistica studentizată 0,50

Bootstrap-ul pe blocuri

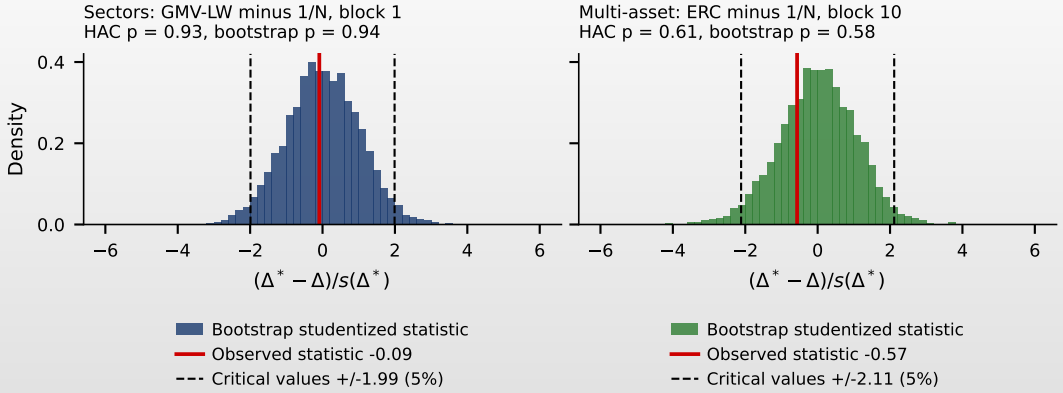


Bradley Efron, inventatorul bootstrap-ului (1979)

Foto: Ryan K. Morris (2007); domeniu public; Wikimedia Commons

- Bootstrap: datele se reeșantionează pentru a aproxima distribuția de eșantionare a lui $\hat{\Delta}$
- Randamentele sînt dependente (volatility clustering): se reeșantionează **blocuri** de luni consecutive (Künsch (1989))
- Ledoit & Wolf (2008), Secțiunea 3.2.2: blocuri circulare de **perechi** (r_{1t}, r_{2t}), care trec peste sfîrșitul eșantionului, astfel încît corelația celor două strategii se păstrează
- Centrare și studentizare (împărțire la o eroare standard estimată): bootstrap pentru $|\hat{\Delta}^* - \hat{\Delta}|/s(\hat{\Delta}^*)$
- Asimptotic pivotal (distribuția limită nu conține parametri necunoscuți), mai precis decît aproximarea prin distribuția Normală a testului HAC
- $p = \left[\#\{\tilde{d}^{*m} \geq |\hat{\Delta}|/s(\hat{\Delta})\} + 1\right]/(M+1)$, $M = 4\,999$ de extrageri
- $\tilde{d}^{*m}$: statistica studentizată din extragerea m, $s(\cdot)$: eroarea standard (SE în seminar), $\#\{\cdot\}$: numărul extragerilor
- Lungimea blocului se alege prin calibrarea din Ledoit & Wolf (2008), Algoritmul 3.1 (▸ Anexă): 1 pentru șase dintre cele șapte reguli pe sectoare; între 1 și 10, cel mai des 10, pentru regulile multi-active și combinate (fiecare bloc în tabelul celor 21 de teste din Anexă)

Testul diferenței de Sharpe față de 1/N (1/2)



MFM_ch4_sharpe_test

Testul diferenței de Sharpe față de 1/N (2/2)

- Distribuțiile bootstrap ale diferenței studentizate față de 1/N
- Roșu: statistica observată
- Linii întrerupte: valorile critice bootstrap
- Sectoare, GMV-LW minus 1/N: $-0{,}02$, intervalul de 95% $[-0{,}36; 0{,}33]$, p HAC $= 0{,}93$, p bootstrap $= 0{,}94$ (bloc 1)
- Multi-active, ERC minus 1/N: $-0{,}03$, $[-0{,}15; 0{,}08]$, p HAC $= 0{,}61$, p bootstrap $= 0{,}58$ (bloc 10)
  - ERC este atît de corelat cu 1/N încît intervalul este îngust, dar conține totuși zero
- Sectoare: nicio regulă nu diferă de 1/N la 5%; cel mai mic p-value îl are ERC ($+0{,}04$, p HAC $= 0{,}09$)
- Multi-active: MV-LO $+0{,}29$ **nu** este semnificativ (p HAC $= 0{,}12$, bootstrap 0,16)

MFM_ch4_sharpe_test

Multe reguli, multe teste: testarea multiplă

Univers	Regula minus 1/N	$\hat{\Delta}$	p HAC	p bootstrap
Multi-active	MV	$-0{,}74$	0,01	0,06
Multi-active	HRP	$-0{,}16$	0,07	0,05
Combinat	GMV	$-0{,}56$	0,03	0,05
Combinat	GMV-LO	$-0{,}40$	0,05	0,08
Combinat	GMV-LW	$-0{,}56$	0,02	0,03
Combinat	MV-LO	$+0{,}05$	0,82	0,82

- Nicio regulă nu depășește semnificativ 1/N în niciun univers
- Fără ajustare pentru testare multiplă, regulile GMV au pe universul combinat un Sharpe semnificativ mai mic decît 1/N: riscul este mic, dar randamentul este și mai mic
- Tabelul arată 6 dintre cele 21 de teste bilaterale, H_0: $\Delta_k = 0$ (7 reguli $\times$ 3 universuri; toate 21 în Anexă)
- Holm pe toate cele 21: cel mai mic p-value ajustat este 0,29 (HAC, $21 \times 0{,}014$) și 0,68 (bootstrap, $21 \times 0{,}032$): nicio diferență nu rămîne semnificativă (slide-ul următor; Capitolul 3)
- O întrebare distinctă privește cea mai bună dintre cele 24 de configurații (8 reguli $\times$ 3 universuri): raportul Sharpe deflatat (DSR, deflated Sharpe ratio) din Bailey & López de Prado (2014) dă $0{,}84 < 0{,}95$ pentru MV-LO pe 16 ETF-uri, dar verdictul depinde de numărul efectiv de încercări (Anexă)

Holm și Benjamini–Hochberg pe testele capitolului

- **FWER** (family-wise error rate): probabilitatea a cel puțin unei respingeri false în familie; **FDR** (false discovery rate): proporția așteptată de respingeri false printre respingeri
- Se ordonează cele m p-value-uri, $p_{(1)} \le \cdots \le p_{(m)}$
  - **Holm** (controlează FWER sub orice dependență): $\tilde{p}_{(i)} = \max_{j \le i} \min\{1, (m-j+1)\, p_{(j)}\}$
  - **Benjamini–Hochberg** (Benjamini & Hochberg (1995); controlează FDR): $\tilde{p}_{(i)} = \min_{j \ge i} \min\{1, \frac{m}{j}\, p_{(j)}\}$
  - se respinge unde $\tilde{p} < 0{,}05$ (Holm) sau $\tilde{p} <$ FDR-ul ales (BH)
- Cele mai mici patru p-value-uri HAC bilaterale, $m = 21$

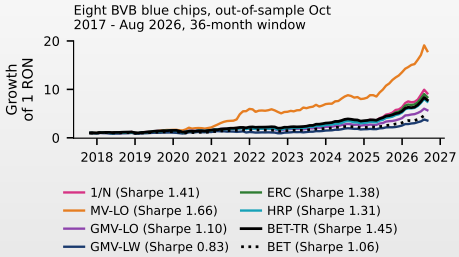
Testul	$p_{(j)}$	**Holm**	$\frac{21}{j}\, p_{(j)}$
Multi-active, MV	0,0138	$21 \times 0{,}0138 = 0{,}289$	0,289
Combinat, GMV-LW	0,0238	$20 \times 0{,}0238 = 0{,}475$	0,249
Combinat, GMV	0,0304	$19 \times 0{,}0304 = 0{,}577$	0,213
Combinat, GMV-LO	0,0477	$18 \times 0{,}0477 = 0{,}858$	0,250

- BH ia minimul de jos în sus: primele trei devin toate 0,213; nicio respingere la un FDR de 10%

Cadrul: un investitor român

- Opt blue chips listate din 2014: TLV, SNP, BRD, TGN, SNG, SNN, EL, TEL
- Randamente lunare în lei, octombrie 2014 – august 2026
- Fereastră de 36 de luni, primul portofoliu în octombrie 2017
- Reguli: 1/N, MV-LO, GMV-LO, GMV-LW, ERC, HRP
- Repere: BET-TR și BET
- Rapoarte Sharpe cu $R_f = 0$ (datele nu conțin o serie a pieței monetare în lei): randament pe unitate de risc, mai mare decît Sharpe-ul din randamente în exces
- Dovezi anterioare despre diversificare în România: Dragotă, Șerbănescu & Pele (2008)

Portofoliile BVB față de BET-TR



- În afara eșantionului, octombrie 2017 – august 2026 (107 luni), înainte de costuri, $R_f = 0$
- BET-TR: media 24,7% pe an, volatilitatea 17,0%, Sharpe 1,45
- BET: media 17,8% pe an, Sharpe 1,06; diferența de circa 7% pe an provine din dividende: comparați cu BET-TR, niciodată cu BET
- Sharpe apropiate de BET-TR: 1/N 1,41, ERC 1,38, HRP 1,31
- MV-LO: Sharpe 1,66, cu 0,21 peste BET-TR (p HAC $= 0{,}44$, bootstrap 0,53)
- GMV-LW: Sharpe 0,83, cu 0,63 sub BET-TR (p HAC $= 0{,}05$, bootstrap 0,10)
- Corelația medie a celor opt acțiuni, 0,44, limitează diversificarea în interiorul BVB; ultimul GMV-LO alocă 70% în TLV
- Întrebare deschisă: aduce diversificarea **dincolo** de BVB un cîștig? (Seminarul 4, C2)

MFM_ch4_bvb

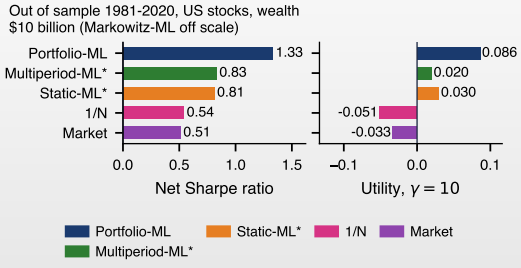
Frontiera accesibilă unui investitor mare (1/2)

- Ideea centrală: strategiile se compară pe frontiera **netă de costurile de tranzacționare**
- Jensen, Kelly, Malamud & Pedersen (2026), *Review of Financial Studies*
  - construcția portofoliilor din prognoze de randament obținute prin machine learning (ML), cînd fiecare tranzacție are impact asupra prețurilor
- **Frontiera eficientă implementabilă** (ec. 12): pentru fiecare volatilitate σ, cel mai mare randament așteptat **net de costurile de tranzacționare**

$$k(\sigma) = \max_{\pi} \; E[r_{t+1}^{\text{net}}] \quad \text{cu} \quad E[\pi_t^\top \Sigma \pi_t] = \sigma^2$$

  - π_t: vectorul ponderilor activelor riscante la t (notația articolului; nu randamentele implicite $\boldsymbol{\pi}$ din Black–Litterman)
  - r_{t+1}^{net}: randamentul portofoliului după costurile de tranzacționare
  - $k(\sigma)$: cel mai bun randament net așteptat la volatilitatea σ
- Propoziția 1: raportul Sharpe net $k(\sigma)/\sigma$ scade de-a lungul frontierei
  - un investitor mai mare are o frontieră mai joasă

Rezultatele articolului: Sharpe net și utilitate



- Jensen, Kelly, Malamud & Pedersen (2026), Tabelul 2: net de costuri, 1981–2020, $\gamma = 10$, cu utilitatea (ec. 11) = randamentul net anual $-\frac{\gamma}{2} \times$ varianța anuală
- Markowitz-ML (medie–varianță pe prognozele ML de randament, fără costuri): Sharpe brut 2,06, turnover 79,36, levier 74,61: randament net extrem de negativ
- Portfolio-ML: Sharpe net 1,33, utilitate 0,086 (randament net 15%, volatilitate 11%, cost 0,6% pe an)
- Static-ML* (costuri pe o singură perioadă; * = nivel suplimentar de calibrare): Sharpe net 0,81, utilitate 0,030
- Multiperiod-ML* (prognoze pe 12 orizonturi): Sharpe net 0,83, utilitate 0,020
- 1/N și piața: Sharpe net 0,54 și 0,51, utilitate $-0{,}051$ și $-0{,}033$
- Doar regulile care țin cont de costuri au utilitate pozitivă

MFM_ch4_implementable_frontier

Frontiera accesibilă unui investitor mare (2/2)

- Costul ca fracțiune din averea W_t (ec. 4, 7), pătratic în tranzacție

$$c_t = \tfrac{W_t}{2}(\pi_t - g_t\pi_{t-\mathbf{1}})^\top \mathbf{\Lambda}(\pi_t - g_t\pi_{t-\mathbf{1}}), \qquad \mathbf{\Lambda} = \mathrm{diag}(0{,}2/V_i)$$

  - g_t: aplică drift-ul ponderilor lunii trecute
  - V_i: volumul în dolari al activului i

- Regula optimă: se parcurge prin tranzacții doar o parte din distanța pînă la un **portofoliu-țintă** A_t (Gârleanu & Pedersen (2013))

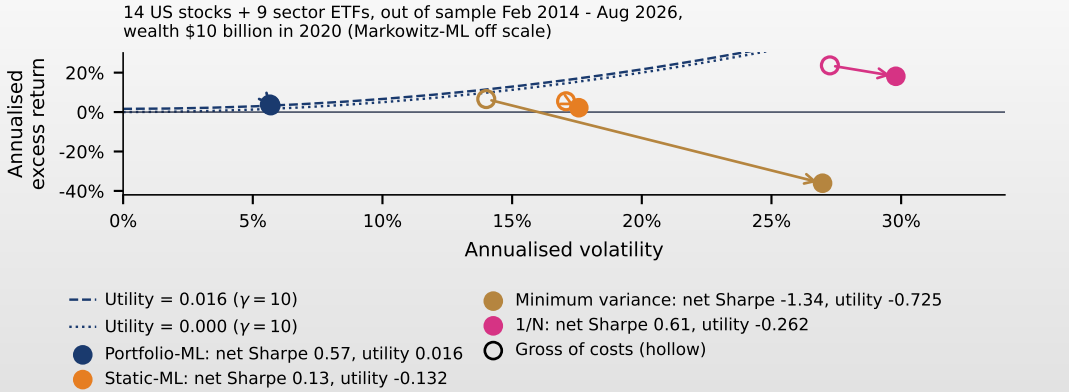
$$\pi_t = m\, g_t\pi_{t-\mathbf{1}} + (\mathbf{I} - m)A_t$$

  - A_t: portofoliul pe care l-am deține dacă tranzacționarea ar fi gratuită, o medie ponderată a portofoliilor Markowitz de azi și a celor viitoare așteptate
  - m: o matrice $N \times N$ a ritmurilor de tranzacționare (ec. 14), deci și $\mathbf{I} - m$ este o matrice; în cazul scalar din Gârleanu & Pedersen (2013), m este partea păstrată din poziția veche în fiecare perioadă
  - Portfolio-ML învață A_t din semnale printr-o regresie ridge (cele mai mici pătrate cu o penalizare pe mărimea coeficienților) al cărei obiectiv este utilitatea netă de costuri

Articolul și aplicația din curs: ce comparăm?

	Articol	**Replicarea din curs**
Active	acțiuni NYSE (New York Stock Exchange) peste mărimea mediană (184–805)	14 acțiuni din SUA + 9 ETF-uri sectoriale
Semnale	115 caracteristici (Jensen, Kelly & Pedersen (2023))	5 semnale de preț și volum
În afara eșantionului	1981–2020, lunar	februarie 2014 – august 2026 (151 de luni)
Investitor	$\gamma = 10$, avere de 10 miliarde \$ la sfîrșitul lui 2020, care crește odată cu piața	la fel; averea scalată cu randamentul cumulat al SPY înainte și după 2020
Utilitate	randamentul net anual $-\frac{\gamma}{2}\times$ varianța anuală	la fel: $12\times$ media lunară $-\frac{\gamma}{2}\times 12\times$ varianța lunară

Brut și net de costuri pe datele cursului (1/2)



MFM_ch4_implementable_frontier

Brut și net de costuri pe datele cursului (2/2)

- Marcaj gol: înainte de costuri
- Marcaj plin: după costul pătratic c_t cu $\mathbf{\Lambda} = \mathrm{diag}(0{,}2/V_i)$ (ec. 35 din articol)
- Curba întreruptă: perechile (volatilitate, randament) cu aceeași utilitate ca Portfolio-ML (0,016)
- Curba punctată: utilitatea 0
- Portfolio-ML se schimbă puțin după costuri: randament 3,8% brut și 3,3% net, la o volatilitate de 5,7%
- Sharpe-ul lui net este 0,57; utilitatea, în unități anuale: $3{,}26\% - \frac{10}{2} \times (5{,}69\%)^2 = 0{,}0326 - 0{,}0162 = 0{,}016$ (media netă și volatilitatea netă)
- 1/N păstrează 18,1% net (Sharpe 0,61), dar la volatilitatea de 29,8% utilitatea lui este $-0{,}26$
- Varianța minimă: randament $+6{,}6\%$ brut, dar $-36{,}1\%$ net
- Varianța minimă are un levier de 2,6; reechilibrarea lui costă 43% pe an
- Limite: 23 de active, 5 semnale, fără model factorial pentru $\mathbf{\Sigma}$
- Frontiera relevantă este cea netă de costuri (Seminarul 4, C3)

MFM_ch4_implementable_frontier

Întrebări deschise

- Întrebări
  - depășește vreo regulă de alocare **estimată** ponderile 1/N în afara eșantionului, net de costuri?
  - rămîne superioară după ce se iau în calcul toate regulile, ferestrele și universurile încercate?
- Dovezile actuale sînt contradictorii
  - Shrinkage-ul neliniar al lui $\boldsymbol{\Sigma}$ îmbunătățește GMV în afara eșantionului pe secțiuni transversale mari: Ledoit & Wolf (2017)
  - Combinarea portofoliului tangent, a GMV și a lui 1/N sub riscul de estimare: Kan, Wang & Zhou (2022)
  - Rezultatele backtest-urilor trebuie ajustate pentru numărul de specificații încercate: Harvey & Liu (2015)
- Formularea: ipoteza H_0 a familiei din Multe reguli, multe teste, față de H_1: $\Delta_k > 0$ pentru un k, cu rata de eroare fixată pentru toată familia
- Bucla de cercetare, parcursă o dată cu un asistent AI: literatură cu DOI, ipoteze concurente, cod pe datele lunare ale cursului, o familie de teste preînregistrată, o critică în stilul unui recenzent (prompturile în Anexă)
- H_0 ar fi respinsă de un $\hat{\Delta}_k$ pozitiv care rămîne semnificativ după corecția pentru toată familia, după costuri și pe un al doilea eșantion

Verificările necesare pentru cercetător

- **Look-ahead**: ponderile lunii t construite cu randamentele aceleiași luni
  - test: verificați că ultima dată de estimare este înainte de t
- **Survivorship bias și selecție**: o listă de ETF-uri aleasă azi
  - test: folosiți universul disponibil la fiecare dată, inclusiv ETF-urile delistate ulterior, sau declarați limita
- **Testare multiplă**: 7 reguli $\times$ 3 universuri dau deja 21 de teste
  - test: p-value-uri ajustate Holm (FWER) sau Benjamini–Hochberg (FDR)
- **Putere**: $\hat{\Delta}$ are o eroare standard de circa 0,18 pe 171 de luni
  - test: calculați efectul minim detectabil înainte de a rula testele
- **Tipul randamentului**: portofoliile agregă randamente **simple**, rapoartele Sharpe folosesc randamente **în exces**
  - test: recalculați o lună pas cu pas
- **Referințe inventate**: un link DOI nefuncțional sau un titlu diferit
  - afirmația se elimină, iar eroarea se înregistrează în `AI_ERRORS.md`

Mini studiu de caz: data snooping în backtest-ul acestui capitol (1/2)

- O propunere tipică a asistentului: „MV-LO depășește 1/N pe universul multi-active"
- Superioritatea este unilaterală: H_0: $\Delta \leq 0$, $p = 1 - \Phi(\hat{\Delta}/\mathrm{SE})$, Φ funcția de repartiție a distribuției Normale standard, SE eroarea standard
- Replicare: $\hat{\Delta} = +0{,}29$, eroarea standard HAC 0,18, p unilateral $= 0{,}06$ (HAC bilateral 0,12, bootstrap 0,16)
  - recalculați cu patru zecimale, nu din valorile rotunjite: $z = 0{,}2863/0{,}1836 = 1{,}56$, $p = 1 - \Phi(1{,}56) = 0{,}06$; valorile rotunjite $0{,}29/0{,}18 = 1{,}61$ ar da 0,054
- Puterea 0,8 pentru $\Delta = 0{,}29$, unilateral: circa 435 de luni (36 de ani) la 5%, 944 de luni (79 de ani) la nivelul Holm 5%/21
  - lunile necesare: $T_{\mathrm{obs}}\left[(z_{1-\alpha} + z_{0{,}8})\,\mathrm{SE}/\Delta\right]^2 = 171\,\left[(1{,}645 + 0{,}842) \times 0{,}1836/0{,}2863\right]^2 \approx 435$
  - la $\alpha = 0{,}05/21$, $z_{1-\alpha} = 2{,}82$, ceea ce dă ≈ 944

MFM_ch4_ai_discovery

Mini studiu de caz: data snooping în backtest-ul acestui capitol (2/2)

- Testați familia, nu cîștigătorul: 21 de teste (7 reguli $\times$ 3 universuri; p-value-urile unilaterale ale tuturor în Anexă)
  - Doar 7 din 21 de diferențe sînt pozitive
  - Cele 4 p-value-uri HAC bilaterale sub 0,05 corespund toate unor diferențe **negative**, care nu pot respinge o ipoteză nulă de superioritate
  - cel mai mic p-value unilateral este 0,046 (sectoare, ERC); după ajustare devine 0,96 cu Holm și 0,62 cu Benjamini–Hochberg; nicio descoperire la un FDR de 10%
- De ce 0,96 aici, dar 0,29 la Multe reguli, multe teste: o pierdere are un p-value unilateral mare (circa $1 - p_{\text{bilateral}}/2$, de exemplu 0,99 pentru MV multi-active), deci pierderile semnificative ies din calcul; cel mai mic p-value unilateral aparține unui cîștig, 0,046, iar Holm îl înmulțește cu 21
- Interpretare: datele nu permit ordonarea acestor reguli
- Intervalul bootstrap pentru MV-LO, $[-0{,}13; 0{,}70]$, este compatibil atît cu pierderi, cît și cu cîștiguri mari
- Nerespingerea nu dovedește egalitatea

MFM_ch4_ai_discovery

O idee de proiect de cercetare

- **Întrebări**
  - depășește shrinkage-ul neliniar (Ledoit & Wolf (2017)) ponderile 1/N pe cele 16 ETF-uri ale capitolului, după costuri de 10–50 bp?
  - depășește o combinație de trei fonduri (Kan, Wang & Zhou (2022)) ponderile 1/N pe aceleași ETF-uri, după aceleași costuri?
- **Replicați întîi**: rezultatele pe universul combinat (Sharpe 1/N 0,76, MV-LO 0,81) și p-value-urile ajustate din mini studiul de caz
- **Preînregistrați**, înainte de orice rezultat
  - ipotezele, familia de teste, rata de eroare și puterea
  - un placebo: ponderi long-only aleatoare cu același turnover
- **Raportați**: cod pe datele lunare ale cursului, un tabel cu toate specificațiile, o autocritică în stilul unui recenzent
- **Jurnal**: prompturile în `AI_USE.md`
- Fiecare eroare depistată și verificarea care a depistat-o în `AI_ERRORS.md`

Concluzii: alegerea regulii de alocare

Regula	Obiectiv	Date necesare	Principalul mod de eșec	Dovezi din acest capitol
MV	Sharpe maxim	$\hat{\boldsymbol{\mu}}$, $\hat{\boldsymbol{\Sigma}}^{-1}$	maximizarea erorii, ponderi explozive	cea mai slabă în toate universurile; averea se anulează
MV-LO	Sharpe maxim, $w_i \geq 0$	$\hat{\boldsymbol{\mu}}$, $\hat{\boldsymbol{\Sigma}}$	soluții de colț, turnover	cele mai bune estimații punctuale, niciodată semnificative
GMV, GMV-LW	varianță minimă	$\hat{\boldsymbol{\Sigma}}$ (cu shrinkage)	concentrează ponderile în active cu randament mic	cel mai mic risc; Sharpe sub 1/N pe 16 ETF-uri (neajustat)
ERC, HRP	risc echilibrat	$\hat{\boldsymbol{\Sigma}}$	o abatere moderată de la 1/N; HRP tranzacționează mai mult	niciodată semnificativ mai bune decît 1/N
Black–Litterman	reper plus opinii	w_b, opinii, $\boldsymbol{\Omega}$	încredere fixată prea mare	modifică doar activele din opinii
1/N	niciunul	niciuna	ignoră diferențele de risc	greu de depășit după costuri

- Evaluați orice regulă în afara eșantionului, net de costuri, cu un test al diferenței de Sharpe și luînd în calcul toate testele efectuate
- Aceste concluzii sînt specifice eșantioanelor analizate

Verificări rapide cu cifre simple (1/2)

- **Trei reguli, două active**: $\sigma_1 = 30\%$, $\sigma_2 = 15\%$, $\rho = 0{,}2$
  - calculați ponderile și volatilitățile GMV, ERC și 1/N; verificați $\sigma_{\text{GMV}} \leq \sigma_{\text{ERC}} \leq \sigma_{1/N}$
  - ce parte din varianța lui 1/N provine din activul 1? (Două active; Contribuțiile la risc; ERC)
- **Optimismul Sharpe-ului estimat direct**: $N = 4$ active, $T = 120$ de luni, θ adevărat $= 0{,}50$ pe an
  - ce Sharpe maxim în eșantion (medie pătratică, anual) vă așteptați să obțineți? (Raportul Sharpe estimat direct este deplasat)
- **Banda de zgomot**: $N = 10$, $T = 40$, matrice de corelație
  - calculați banda Marchenko–Pastur; este o valoare proprie de eșantion de 2,0 un semn de structură? (Limitele matricei de covarianță de eșantion)

Verificări rapide cu cifre simple (2/2)

- **O opinie, un activ**: $\pi = 4\%$, $\tau\sigma^2 = 0{,}0009$, opinia 10%
  - media a posteriori și ponderea opiniei pentru $\Omega = 0{,}0009$ și pentru $\Omega = 0{,}0003$ (Opiniile și distribuția a posteriori)
- **Un raport Sharpe**: $\widehat{SR}$ lunar $= 0{,}15$, $T = 120$, i.i.d. din distribuția Normală
  - Sharpe-ul anual și intervalul lui de 95%: este semnificativ pozitiv? (Inferența pentru un raport Sharpe)
- **Patru teste**: $p = 0{,}004;\ 0{,}020;\ 0{,}030;\ 0{,}300$
  - p-value-urile ajustate Holm și Benjamini–Hochberg; cîte respingeri la 5% cu fiecare? (Holm și Benjamini–Hochberg)
- Răspunsurile: ▸ Anexă

Autoevaluare și legături cu alte capitole

Întrebări de recapitulare

- De ce supraestimează Sharpe-ul tangent în eșantion pe cel realizabil? (Sharpe estimat direct; Seminarul 4, A8)
- Cu cît îl supraestimează pentru $N = 9$, $T = 60$?
- De ce acționează o restricție long-only ca un shrinkage? (Jagannathan–Ma și exemplul cu două active)
- De ce poate o diferență mică de Sharpe între ERC și 1/N să fie aproape semnificativă, iar una mai mare între GMV și 1/N nu? (testul HAC: comparați erorile standard 0,023 și 0,159 din tabelul din Anexă)

Legături cu alte capitole

- **Capitolul 3**: portofoliul tangent, CAPM și modelele factoriale de covarianță
- **Capitolele 5–6**: volatilitate și corelație variabile în timp pentru ponderi dinamice
- **Capitolul 7**: Value-at-Risk și Expected Shortfall de portofoliu
- **Capitolul 13**: machine learning pentru randamente și portofolii; overfitting-ul backtest-ului

Frontiera în formă închisă, pas cu pas

- Două restricții, doi multiplicatori: $\mathcal{L} = \frac{1}{2}\mathrm{w}^\top \boldsymbol{\Sigma}\mathrm{w} - \lambda_1(\mathrm{w}^\top \boldsymbol{\mu} - m) - \lambda_2(\mathrm{w}^\top 1 - 1)$
- Condiția de ordinul întîi: $\boldsymbol{\Sigma}\mathrm{w} = \lambda_1\boldsymbol{\mu} + \lambda_2 1$, deci $\mathrm{w} = \lambda_1\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} + \lambda_2\boldsymbol{\Sigma}^{-1}1$
- Restricțiile, cu $A = 1^\top\boldsymbol{\Sigma}^{-1}1$, $B = 1^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$, $C = \boldsymbol{\mu}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$, $D = AC - B^2$

$$\boldsymbol{\mu}^\top \mathrm{w} = \lambda_1 C + \lambda_2 B = m, \qquad 1^\top \mathrm{w} = \lambda_1 B + \lambda_2 A = 1$$

- Soluția sistemului 2×2: $\lambda_1 = (Am - B)/D$, $\lambda_2 = (C - Bm)/D$
- Varianța: $\mathrm{w}^\top\boldsymbol{\Sigma}\mathrm{w} = \mathrm{w}^\top(\lambda_1\boldsymbol{\mu} + \lambda_2 1) = \lambda_1 m + \lambda_2 = \dfrac{Am^2 - 2Bm + C}{D}$
- Verificare: la $m = B/A$ varianța este $(C - B^2/A)/D = 1/A$, adică GMV
- Forme: σ^2 este pătratică în m (parabolă în planul (σ^2, m)); $\sigma^2 - A(m - B/A)^2/D = 1/A$ este o hiperbolă în planul (σ, m)

înapoi

Momentele Wishart și distribuția ponderilor

- Randamente i.i.d. $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, estimatori de verosimilitate maximă: $\hat{\boldsymbol{\mu}} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}/T)$, $T\hat{\boldsymbol{\Sigma}} \sim W_N(T-1, \boldsymbol{\Sigma})$ (Wishart: analogul matriceal al lui χ^2, cu $T-1$ grade de libertate), independenți
- Momentul Wishart invers, finit pentru $T > N+2$: $\mathbb{E}[\hat{\boldsymbol{\Sigma}}^{-1}] = \frac{T}{T-N-2}\boldsymbol{\Sigma}^{-1}$, o deplasare **în sus** care crește cu N/T
- Condiționînd pe $\hat{\boldsymbol{\mu}}$ și folosind $\mathbb{E}[\mathrm{x}^\top \mathrm{K}\mathrm{x}] = \mathrm{tr}(\mathrm{K}\,\mathrm{Var}(\mathrm{x})) + \mathbb{E}[\mathrm{x}]^\top \mathrm{K}\,\mathbb{E}[\mathrm{x}]$ (orice vector aleator x, matrice fixă K, tr: urma) se obține $\mathbb{E}[\hat{\theta}^2]$ din curs (Seminarul 4, A8)
- Ponderile GMV cu $\hat{\boldsymbol{\Sigma}}$ Wishart și T suficient de mare față de N: $\hat{\mathrm{w}}_{\mathrm{GMV}}$ este nedeplasat, iar distribuția și covarianța lui exacte sînt cunoscute (Okhrin & Schmid (2006))
- Ponderile tangente împart la $1^\top \hat{\boldsymbol{\Sigma}}^{-1}\hat{\boldsymbol{\mu}}$, care poate fi aproape de zero: cozi foarte groase
- Combinații optime sub riscul de estimare ale portofoliului tangent, GMV și 1/N: Kan & Zhou (2007), Kan, Wang & Zhou (2022)

Înapoi

Ponderile tangente prin regresie, Britten-Jones (1999)

- Britten-Jones (1999): regresia constantei 1 pe randamentele în exces, **fără** termen liber

$$1 = \mathrm{b}^\top \mathrm{r}_t + u_t, \qquad \hat{\mathrm{b}} = (\mathrm{X}^\top \mathrm{X})^{-1} \mathrm{X}^\top 1_T \propto \hat{\boldsymbol{\Sigma}}^{-1} \hat{\boldsymbol{\mu}}$$

- r_t: vectorul randamentelor în exces din luna t
- X: matricea $T \times N$ cu liniile $\mathrm{r}_t^\top$
- 1_T: vectorul de T unități
- u_t: eroarea regresiei
- Sherman–Morrison aplicat lui $\mathrm{X}^\top \mathrm{X}/T = \hat{\boldsymbol{\Sigma}} + \hat{\boldsymbol{\mu}} \hat{\boldsymbol{\mu}}^\top$ dă proporționalitatea (Seminarul 4, A9)
- $\hat{\mathrm{b}}/1^\top \hat{\mathrm{b}}$ = ponderile tangente de eșantion dacă $1^\top \hat{\mathrm{b}} > 0$
- Distribuții t și F exacte în eșantion finit pentru randamente i.i.d. din distribuția Normală
- Altfel se folosesc erori standard HAC

- Testul t OLS al lui $b_i = 0$: activul i are pondere zero în portofoliul tangent
- Testul F al lui $\mathrm{Rb} = 0$ cu $\mathrm{R} = [\mathrm{I}_{N-1}, -1_{N-1}]$: „portofoliul tangent este 1/N”
- Nouă sectoare, ianuarie 1999 – iulie 2026 ($T = 331$): $\hat{\mathrm{b}}$ normalizat reproduce ponderile tangente
- Cel mai mare $|t|$ este 1,12 (financiar), iar cu erori HAC 1,19
- H_0: tangent = 1/N, opt restricții: $F(8, 322) = 0{,}48$, $p = 0{,}87$
- Testul Wald cu erori HAC: $\chi^2_8 = 4{,}50$, $p = 0{,}81$
- Nerespingerea nu dovedește ponderi egale

Înapoi

Intensitatea optimă de shrinkage

- Ledoit și Wolf aleg δ care minimizează distanța pătratică așteptată (Frobenius) față de $\boldsymbol{\Sigma}$ adevărată

$$\delta^* = \max\left\{0, \min\left\{1, \frac{\hat{\kappa}}{T}\right\}\right\}, \qquad \hat{\kappa} = \frac{\hat{\pi} - \hat{\rho}}{\hat{\gamma}}$$

- $\hat{\pi}$: suma variațelor asimptotice ale elementelor lui S (zgomotul)
- $\hat{\rho}$: covariațele lor asimptotice cu elementele țintei
- $\hat{\gamma} = \|\mathrm{F} - \mathrm{S}\|^2$: eroarea de specificare a țintei (nu aversiunea la risc γ)
- Formulele complete pentru ținta de corelație constantă: Ledoit & Wolf (2004b), Anexă
- Codul: Quantlet-ul de shrinkage

înapoi

Shrinkage-ul mediilor și alți estimatori de covarianță

- Bayes–Stein (Jorion (1986)): $\hat{\boldsymbol{\mu}}_{\text{BS}} = (1 - \hat{\phi})\,\hat{\boldsymbol{\mu}} + \hat{\phi}\,\hat{\mu}_{\text{GMV}}\mathbf{1}$
  - Shrinkage Bayes empiric al fiecărei medii spre media portofoliului GMV
  - $\hat{\phi}$ dintr-un argument Stein, mai mare cînd N/T este mare
- Tu & Zhou (2011): combinația convexă dintre o regulă sofisticată și 1/N care minimizează pierderea așteptată în afara eșantionului
- DeMiguel, Garlappi, Nogales & Uppal (2009): restricțiile de normă $\|\mathrm{w}\|_1 \leq \delta$ sau $\|\mathrm{w}\|_2 \leq \delta$ includ GMV long-only, GMV cu shrinkage și 1/N
- Aceste restricții de normă sînt puntea spre portofoliile lasso din Capitolul 13
- Structură factorială plus o covarianță reziduală rară: POET (principal orthogonal complement thresholding, Fan, Liao & Mincheva (2013)), legătura cu Capitolul 3
- GMV în dimensiune mare, cu shrinkage spre un portofoliu-țintă: Bodnar, Parolya & Schmid (2018)

Înapoi

Black–Litterman ca estimare mixtă (GLS)

- Theil & Goldberger (1961): distribuția a priori și opiniile se scriu ca o singură regresie pentru $\boldsymbol{\mu}$

$$\begin{pmatrix} \boldsymbol{\pi} \\ \mathrm{q} \end{pmatrix} = \begin{pmatrix} \mathrm{I} \\ \mathrm{P} \end{pmatrix} \boldsymbol{\mu} + \begin{pmatrix} \mathrm{e}_1 \\ \mathrm{e}_2 \end{pmatrix}, \qquad \operatorname{Var} \begin{pmatrix} \mathrm{e}_1 \\ \mathrm{e}_2 \end{pmatrix} = \begin{pmatrix} \tau\boldsymbol{\Sigma} & 0 \\ 0 & \boldsymbol{\Omega} \end{pmatrix}$$

- GLS dă exact $\boldsymbol{\mu}_{\mathrm{BL}}$, cu covarianța $\mathrm{M} = \left[(\tau\boldsymbol{\Sigma})^{-1} + \mathrm{P}^{\top}\boldsymbol{\Omega}^{-1}\mathrm{P}\right]^{-1}$
- Formă echivalentă: $\boldsymbol{\mu}_{\mathrm{BL}} = \boldsymbol{\pi} + \tau\boldsymbol{\Sigma}\mathrm{P}^{\top}(\mathrm{P}\tau\boldsymbol{\Sigma}\mathrm{P}^{\top} + \boldsymbol{\Omega})^{-1}(\mathrm{q} - \mathrm{P}\boldsymbol{\pi})$
- $\boldsymbol{\Omega} \to 0$: cele mai mici pătrate cu restricții, $\mathrm{P}\boldsymbol{\mu}_{\mathrm{BL}} = \mathrm{q}$
- Covarianța predictivă $\boldsymbol{\Sigma} + \mathrm{M}$ în ponderi ar modifica toate ponderile
- Fără opinii, le scalează pe toate cu $1/(1+\tau)$

înapoi

Alte reguli bazate pe risc

- **Inversul volatilității**: $w_i \propto 1/\sigma_i$
- Coincide cu ERC cînd toate corelațiile sînt egale
- **Diversificare maximă** (Choueifaty & Coignard (2008)): se maximizează $\mathrm{w}^\top \boldsymbol{\sigma} / \sqrt{\mathrm{w}^\top \boldsymbol{\Sigma} \mathrm{w}}$, raportul dintre volatilitatea medie a activelor și volatilitatea portofoliului
- $\boldsymbol{\sigma}$: vectorul volatilităților activelor
- **Varianță minimă**: GMV, regula extremă bazată pe risc
- Toate ignoră randamentele așteptate: robuste la eroarea de estimare, dar optime doar în ipoteze speciale

Înapoi

Rezultate, universul sectoarelor

Regula	Media	Volatilitate	Sharpe	Turnover	Drawdown maxim
1/N	9,4%	14,3%	0,66	0,02	−49%
MV	17,8%	69,0%	0,26	3,86	−100%
MV-LO	10,7%	14,7%	0,72	0,23	−42%
GMV	8,5%	11,9%	0,71	0,23	−33%
GMV-LO	8,1%	11,5%	0,70	0,09	−34%
GMV-LW	7,6%	11,8%	0,65	0,14	−31%
ERC	9,3%	13,2%	0,70	0,03	−47%
HRP	8,9%	12,8%	0,70	0,08	−45%

- Perioada: ianuarie 2004 – iulie 2026
- Turnover: fracțiunea medie lunară din avere care este tranzacționată
- Drawdown-ul este calculat pe averea din randamente totale

înapoi

Rezultate, universul multi-active (8 ETF-uri)

Regula	Media	Volatilitate	Sharpe	Turnover	Drawdown maxim	Sharpe, 50 bp
1/N	4,3%	8,4%	0,52	0,02	−21%	0,50
MV	−113,0%	517,5%	−0,22	44,46	−100%	−0,54
MV-LO	7,1%	8,9%	0,80	0,12	−24%	0,72
GMV	1,4%	3,8%	0,37	0,14	−11%	0,16
GMV-LO	1,7%	5,4%	0,32	0,05	−17%	0,27
GMV-LW	1,1%	4,2%	0,27	0,09	−13%	0,15
ERC	3,6%	7,3%	0,49	0,02	−21%	0,47
HRP	2,4%	6,6%	0,36	0,04	−20%	0,32

- Perioada: mai 2012 – iulie 2026 (171 de luni)
- Media și volatilitatea lui MV sînt medii aritmetice ale unor randamente lunare care includ o pierdere de peste 100%, deci doar drawdown-ul lui are sens economic

înapoi

Rezultate, universul combinat (16 ETF-uri)

Regula	Media	Volatilitate	Sharpe	Turnover	Sharpe, 50 bp
1/N	7,9%	10,3%	0,76	0,02	0,75
MV	28,7%	261,8%	0,11	22,10	−0,51
MV-LO	8,0%	9,8%	0,81	0,20	0,69
GMV	0,8%	4,1%	0,20	0,24	−0,15
GMV-LO	2,0%	5,4%	0,36	0,06	0,30
GMV-LW	0,9%	4,4%	0,20	0,13	0,03
ERC	5,5%	7,8%	0,71	0,03	0,68
HRP	4,0%	7,0%	0,56	0,11	0,47

- Perioada: mai 2012 – iulie 2026
- Ultima coloană: Sharpe net de 50 de puncte de bază pe unitate de turnover

înapoi

Toate cele 21 de teste față de 1/N (1/3), sectoare

Regula	$\hat{\Delta}$	SE HAC	p HAC	Holm	p unilateral	p bootstrap	Bloc
MV	−0,40	0,331	0,22	1,00	0,889	0,30	6
MV-LO	+0,06	0,120	0,60	1,00	0,299	0,63	1
GMV	+0,05	0,159	0,75	1,00	0,377	0,76	1
GMV-LO	+0,04	0,112	0,73	1,00	0,363	0,73	1
GMV-LW	−0,02	0,166	0,93	1,00	0,537	0,94	1
ERC	+0,04	0,023	0,09	1,00	0,046	0,13	1
HRP	+0,04	0,040	0,32	1,00	0,162	0,36	1

- Ianuarie 2004 – iulie 2026, $T = 271$; $\hat{\Delta}$: Sharpe-ul anualizat al regulii minus cel al lui 1/N, înainte de costuri
- HAC: Bartlett, 4 laguri, bilateral; Holm pe toate cele 21 de teste HAC bilaterale; unilateral: $1 - \Phi(\hat{\Delta}/\mathrm{SE})$; bootstrap: bootstrap circular pe blocuri, studentizat, bilateral, blocul din Algoritmul 3.1

înapoi

Toate cele 21 de teste față de 1/N (2/3), multi-active

Regula	$\hat{\Delta}$	SE HAC	p HAC	Holm	p unilateral	p bootstrap	Bloc
MV	−0,74	0,300	0,01	0,29	0,993	0,06	10
MV-LO	+0,29	0,184	0,12	1,00	0,059	0,16	10
GMV	−0,15	0,226	0,51	1,00	0,745	0,54	1
GMV-LO	−0,20	0,137	0,14	1,00	0,930	0,15	8
GMV-LW	−0,25	0,191	0,19	1,00	0,903	0,20	4
ERC	−0,03	0,060	0,61	1,00	0,694	0,58	10
HRP	−0,16	0,089	0,07	1,00	0,964	0,05	6

- Mai 2012 – iulie 2026, $T = 171$; aceleași coloane ca la sectoare

înapoi

Toate cele 21 de teste față de 1/N (3/3), combinat

Regula	$\hat{\Delta}$	SE HAC	p HAC	Holm	p unilateral	p bootstrap	Bloc
MV	−0,66	0,355	0,06	1,00	0,968	0,22	10
MV-LO	+0,05	0,210	0,82	1,00	0,409	0,82	10
GMV	−0,56	0,261	0,03	0,58	0,985	0,05	1
GMV-LO	−0,40	0,203	0,05	0,86	0,976	0,08	6
GMV-LW	−0,56	0,249	0,02	0,48	0,988	0,03	2
ERC	−0,06	0,114	0,61	1,00	0,695	0,62	10
HRP	−0,20	0,152	0,18	1,00	0,908	0,20	8

- Mai 2012 – iulie 2026, $T = 171$; 7 dintre cele 21 de $\hat{\Delta}$ sînt pozitive, iar orice p HAC bilateral $< 0{,}05$ corespunde unei pierderi
- Familia unilaterală: Holm $21 \times 0{,}046 = 0{,}96$; Benjamini–Hochberg $\min\{21 \times 0{,}046;\ \frac{21}{2} \times 0{,}059\} = 0{,}62$ pentru primele două

înapoi

Detaliile bootstrap-ului și lungimea blocului

- Studentizare: $s(\hat{\Delta}^*)$ din sumele pe blocuri ale fiecărei reeșantionări
- $s(\hat{\Delta})$ pe date, cu un nucleu pătratic-spectral cu prealbire (Andrews & Monahan (1992)) și lățime de bandă automată (Andrews (1991))
- P-value-urile HAC din tabele folosesc nucleul Bartlett, mai simplu, cu 4 laguri (testul HAC); cele două erori standard diferă de regulă la a doua zecimală
- Ledoit & Wolf (2008), Algoritmul 3.1: se alege blocul b al cărui interval bootstrap are acoperirea efectivă cea mai apropiată de 95%
  - Se estimează o autoregresie vectorială de ordinul întîi pentru perechea de randamente
  - Reziduurile se reeșantionează printr-un bootstrap staționar (Politis & Romano (1994)), bloc mediu 5
  - Se generează $K = 5\,000$ de pseudo-eșantioane de lungime T
  - În fiecare se construiește intervalul de 95% pentru $b \in \{1, 2, 4, 6, 8, 10\}$
  - $\hat{g}(b)$: proporția intervalelor care conțin $\hat{\Delta}$ pseudo-adevărat
  - se alege $\tilde{b} = \arg\min_b |\hat{g}(b) - 0{,}95|$
- Grila și K urmează articolul (Secțiunile 4–5) și se aplică fiecăreia dintre cele 21 de perechi din capitol
- Un bootstrap nestudentizat cu bloc fix de 6 luni nu calibrează acoperirea: nu este același test

Înapoi

Raportul Sharpe deflatat

- Bailey & López de Prado (2014): cel mai bun dintre N rapoarte Sharpe este deplasat în sus chiar dacă toate rapoartele Sharpe adevărate sînt zero
- Maximul așteptat sub H_0: toate rapoartele Sharpe adevărate sînt zero, N încercări independente, T în unități lunare; pe acest slide N numără încercările (configurațiile), nu activele
  - $\gamma_E = 0{,}5772$: constanta lui Euler, e: numărul lui Euler
  - $\hat{V}$: varianța celor N estimații, Φ: funcția de repartiție a distribuției Normale standard

$$SR_0 = \sqrt{\hat{V}}\left[(1-\gamma_E)\,\Phi^{-1}\left(1-\tfrac{1}{N}\right) + \gamma_E\,\Phi^{-1}\left(1-\tfrac{1}{Ne}\right)\right]$$

- Raportul Sharpe deflatat: probabilitatea ca raportul Sharpe adevărat al cîștigătorului să depășească SR_0, cu asimetria $\hat{\gamma}_3$ și kurtosis-ul $\hat{\gamma}_4$ ale cîștigătorului

$$\text{DSR} = \Phi\left(\frac{(\widehat{SR} - SR_0)\sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3\widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4}\widehat{SR}^2}}\right)$$

- Acest capitol: 24 de configurații (8 reguli $\times$ 3 universuri)
  - cîștigătorul este MV-LO pe 16 ETF-uri, cu Sharpe 0,81 pe an
  - Ca 24 de încercări independente: $SR_0 = 0{,}52$ pe an, DSR $= 0{,}84 < 0{,}95$
  - Configurațiile sînt puternic corelate (pînă la 0,99), deci numărul efectiv de încercări independente este mai mic: $N = 8$ dă DSR 0,93, $N = 3$ dă 0,98
- Holm ajustează întreaga familie de teste pe perechi față de 1/N
- DSR compară performanța cîștigătorului cu efectul hazardului

înapoi

Dincolo de acțiuni, activele digitale

- Petukhina, Trimborn, Härdle & Elendner (2021): criptomonedele în regulile de alocare a portofoliului
- Cîștigul adus de criptomonede depinde de regula de alocare și de lichiditate
- Pele et al. (2023): devin criptomonedele active alternative?
- Bitcoin: volatilitatea anualizată 172% (lunar, 2010–2026; o criptomonedă supraviețuitoare, aleasă ex post), IEF 6,6%
- Contribuțiile la risc cresc cu volatilitatea: regulile bazate pe risc atribuie automat lui Bitcoin o pondere mică (Seminarul 4, B8)
- Markowitz robust pentru cripto-active: Pele (2023)

înapoi

Studiul de caz, metoda în detaliu (1/2)

- **Costul** (ec. 4, 7)
  - π_t: ponderile activelor riscante
  - $1 - 1^\top \pi_t$: ponderea activului fără risc
  - $g_t = \mathrm{diag}((1 + r_t^f + r_t)/(1 + g_t^w))$ (ec. 6)
  - r_t^f: rata fără risc, r_t: randamentele activelor, g_t^w: creșterea averii
  - $\mathbf{\Lambda} = \mathrm{diag}(0{,}2/V_i)$
  - V_i: volumul zilnic mediu în dolari pe 6 luni
  - tranzacționarea a 1% din V_i modifică prețul cu 0,1% (ec. 35, Frazzini, Israel & Moskowitz (2018))
- **Regula optimă** (Propoziția 3): $\pi_t = m\, g_t \pi_{t-\mathbf{1}} + (\mathrm{I} - m) A_t$, care generalizează Gârleanu & Pedersen (2013)
  - A_t: o sumă ponderată a portofoliilor Markowitz de azi și a celor viitoare așteptate
  - m rezolvă ec. (14)
- **Portfolio-ML** (Propoziția 4, ec. 40): $A_t = \mathrm{diag}(1/\sigma_{i,t})\, f(s_t)\beta$
  - $\sigma_{i,t}$: volatilitatea activului i
  - f: p caracteristici Fourier aleatoare ale semnalelor s_t
  - $\hat{\beta} = (E_T[\tilde{\mathbf{\Sigma}}_t] + \lambda \mathrm{I})^{-\mathbf{1}} E_T[\tilde{r}_{t+\mathbf{1}}]$: o regresie ridge ($\lambda$: penalizarea) care maximizează în formă închisă utilitatea netă de costuri (ec. 24–26)
  - învață direct ponderile, ca Brandt, Santa-Clara & Valkanov (2009), care însă ignoră costurile

Înapoi

Studiul de caz, metoda în detaliu (2/2)

- **Date** (Secțiunea 5.1): acțiuni ordinare NYSE peste capitalizarea mediană (184–805 acțiuni)
  - 115 caracteristici din Jensen, Kelly & Pedersen (2023), ordonate în $[0, 1]$
  - decembrie 1952 – decembrie 2020, în afara eșantionului 1981–2020, lunar
- **Covarianța $\boldsymbol{\Sigma}$**: 13 teme de caracteristici și 12 industrii ca factori
  - ponderi exponențiale cu timpi de înjumătățire de 378 de zile (corelații) și 126 de zile (variațe)
  - investitorul $\gamma = 10$, avere de 10 miliarde \$ la sfîrșitul lui 2020, care crește odată cu piața (Secțiunea 5.1.3)
- **Calibrare** (Tabelul 1), aleasă anual după utilitatea backtest-urilor de validare din 1971
  - $\lambda \in \{0, e^{-\mathbf{10}}, e^{-\mathbf{9,8}}, \ldots, e^{\mathbf{10}}\}$, $p \in \{2^{\mathbf{6}}, \ldots, 2^{\mathbf{9}}\}$, $\eta \in \{e^{-\mathbf{3}}, e^{-\mathbf{2}}\}$
  - η: abaterea standard a ponderilor aleatoare
- **Reguli concurente** („*" marchează un nivel suplimentar de calibrare, Secțiunea 5.3)
  - Markowitz-ML (ec. 32), Static-ML (cost pe o perioadă, ec. 34), Multiperiod-ML (prognoze pentru 12 orizonturi, ec. 22)
  - sortări pe factori, 1/N, variață minimă, piața

Înapoi

Studiul de caz, rezultatele complete

- **Tabelul 2**, Portfolio-ML: turnover 0,25 pe lună (raport Sharpe net 1,33)
- **Tabelul 2**, Multiperiod-ML*: Sharpe net 0,83, utilitate 0,020
  - Portfolio-ML nu are nevoie de un al doilea nivel de calibrare
- **Tabelul 3**: probabilitatea a posteriori ca Portfolio-ML să aibă utilitatea mai mare
  - 99,9% față de Static-ML* și Multiperiod-ML*, 100% față de Markowitz-ML
- **Figura 1(B)** (Secțiunea 6.2), $\gamma = 10$: dimensiunea portofoliului generează costuri
  - cu 10 miliarde \$, randament net în exces 14,6% la volatilitatea de 11%
  - cu 1 miliard \$, randamentul net în exces este 16,3%
- **Figura 5**: net de costuri, calitatea este tema cea mai importantă
  - reversal-ul pe termen scurt este aproape irelevant
  - autocorelația lunară $-0{,}04$ pentru reversal-ul de o lună, 0,94 pentru book-to-market (Secțiunea 6.3)
  - semnalele persistente generează costuri de tranzacționare mici
- **Limite declarate de autori**
  - comisioane și alte fricțiuni
  - putere de calcul și metode ML indisponibile în timp real la începutul eșantionului (Secțiunea 6.1)
  - costurile și riscul considerate constante pe orizontul fiecărei optimizări (Secțiunea 5.1.3)
  - pe cele mai mici 20% dintre acțiuni, Portfolio-ML obține rezultate inferioare față de Multiperiod-ML* și Static-ML* (Figura 8)

Înapoi

Studiul de caz, replicarea din curs (1/2)

- **Datele cursului**: 14 acțiuni din SUA și 9 ETF-uri sectoriale
  - cinci semnale: randamentul logaritmic pe o lună, momentum logaritmic de la $t-6$ și de la $t-12$ la $t-1$, volatilitatea pe un an, volumul în dolari pe 6 luni (formulele în Seminarul 4, C3)
  - aceeași regulă de cost, γ, avere și grilă
  - $\boldsymbol{\Sigma}$ cu aceleași ponderi pe cele 23 de active
  - validarea începe în 2011
  - perioada în afara eșantionului: februarie 2014 – august 2026 (151 de luni)
- **Portfolio-ML**: cost 0,6% pe an, levier 0,32
- **Alte reguli**: utilitatea Static-ML $-0{,}13$
- Utilitatea variației minime: $-0{,}72$
- Utilitatea Markowitz-ML: extrem de negativă (levier 18)
- **Probabilitatea a posteriori** a unei utilități mai mari pentru Portfolio-ML
  - 99,5% față de Static-ML, 99,9% față de varianța minimă, 93,3% față de 1/N

Înapoi

Studiul de caz, replicarea din curs (2/2)

- Regulile care țin cont de costuri le domină pe cele care le ignoră, ca în Tabelul 2
  - avantajul Portfolio-ML provine din poziții mici, ajustate lent, nu dintr-un Sharpe brut mai mare (0,68 față de 0,87 pentru 1/N)
- **Limite**
  - 23 de active în loc de 184–805
  - cinci semnale în loc de 115
  - fără model factorial pentru $\mathbf{\Sigma}$, a cărui fereastră ajunge la 10 ani abia în august 2014 (prețuri comune din august 2004)
  - prognoze de randament cu $p \geq 2^6$ și trei ani de validare în loc de zece
  - fără regulile concurente marcate cu stea
- **Extindere deschisă** (Seminarul 4, C3)
  - frontiere implementabile pentru averi de 1, 10 și 100 de miliarde \$ și $\gamma \in \{1, 5, 10, 20, 100\}$
  - costurile lui 1/N calculate la fiecare nivel de avere

Înapoi

Bucla descoperirii, prompturi reutilizabile

- Instrumentele sînt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și motoare de căutare a literaturii (Semantic Scholar, Elicit, Google Scholar)
- **Literatură**: *„Enumeră studiile publicate în reviste cu evaluare inter pares din 2015 încoace care compară regulile cu shrinkage sau bazate pe risc cu 1/N în afara eșantionului; pentru fiecare dă DOI, N, T, ipoteza de cost și testul."* Verificați fiecare DOI în Crossref și deschideți tabelul citat
- **Ipoteze**: *„Dă trei explicații concurente pentru un cîștig de Sharpe față de 1/N (o $\boldsymbol{\Sigma}$ mai bună, o primă de volatilitate redusă, noroc) și implicația testabilă a fiecăreia pentru turnover, subperioade și expunerile la factori."*
- **Date și cod**: *„Scrie cod Python care citește prețurile zilnice din datele cursului, aliniază prețurile pe zilele comune și rulează GMV-LW și 1/N cu o fereastră mobilă de 60 de luni; ponderile de la t pot folosi date doar pînă la $t-1$."* Replicați întîi: 1/N 0,76, GMV-LW 0,20 pe universul combinat
- **Robustețe**: *„Scrie o preînregistrare: familia de teste (reguli × universuri × ferestre × costuri), rata de eroare (FWER sau FDR), subperioadele și un placebo, fixate înainte de a vedea vreun rezultat."*
- **Critică**: *„Joacă rolul unui recenzent sever: dă cele mai puternice trei motive pentru care cîștigul meu de Sharpe ar putea fi aparent și testul care l-ar demasca pe fiecare."*
- **Raport**: fiecare specificație încercată, p-value-uri ajustate, puterea testului, codul și seed-urile
- Orice specificație aleasă după ce ați văzut rezultatele este exploratorie

Înapoi

Răspunsurile la verificările rapide

- **Trei reguli**: $s_{11} = 0{,}09$, $s_{22} = 0{,}0225$, $s_{12} = 0{,}2 \times 0{,}30 \times 0{,}15 = 0{,}009$
  - GMV: $w_1 = (0{,}0225 - 0{,}009)/(0{,}09 + 0{,}0225 - 0{,}018) = 1/7$, volatilitate 14,3%; ERC (inversul volatilității): $w_1 = 1/3$, volatilitate 15,5%; 1/N: 18,1%
  - 1/N: $w_1(\Sigma w)_1 = 0{,}5 \times 0{,}0495 = 0{,}02475$ din $\sigma_p^2 = 0{,}0326$: activul 1 aduce 76% din risc cu 50% din pondere
- **Sharpe estimat direct**: θ^2 lunar $= 0{,}25/12 = 0{,}0208$; $(120 \times 0{,}0208 + 4)/(120 - 6) = 0{,}0570$; $\sqrt{12 \times 0{,}0570} = 0{,}83$ pe an, față de 0,50 adevărat
- **Banda de zgomot**: $c = 10/40 = 0{,}25$, banda $[(1 - 0{,}5)^2; (1 + 0{,}5)^2] = [0{,}25; 2{,}25]$; 2,0 este în interior, deci această comparație nu o poate separa de zgomot
- **O opinie**: precizii egale dau ponderea opiniei $0{,}0009/(0{,}0009 + 0{,}0009) = 0{,}5$, media a posteriori 7%; cu $\Omega = 0{,}0003$, ponderea $0{,}0009/0{,}0012 = 0{,}75$, media a posteriori $4\% + 0{,}75 \times 6\% = 8{,}5\%$
- **Un raport Sharpe**: SE $= \sqrt{(1 + 0{,}15^2/2)/120} = 0{,}092$; anual $0{,}52 \pm 1{,}96 \times 0{,}32$, intervalul $[-0{,}10; 1{,}14]$: nesemnificativ
- **Patru teste**: Holm 0,016; 0,060; 0,060; 0,300: o respingere; Benjamini–Hochberg 0,016; 0,040; 0,040; 0,300: trei respingeri

înapoi

Cursuri, cod și date

Cursuri avansate pe quantinar.com

- Hierarchical Clustering
- Minimum Spanning Tree
- Multivariate Statistical Analysis

Cod și date

- Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_04
- Rata fără risc: Kenneth French Data Library

Înapoi

Bibliografie (1/6)

- Andrews, D.W.K. (1991). Heteroskedasticity and autocorrelation consistent covariance matrix estimation. *Econometrica*, 59(3), 817–858.
- Andrews, D.W.K., Monahan, J.C. (1992). An improved heteroskedasticity and autocorrelation consistent covariance matrix estimator. *Econometrica*, 60(4), 953–966.
- Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting, and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300.
- Best, M.J., Grauer, R.R. (1991). On the sensitivity of mean-variance-efficient portfolios to changes in asset means: some analytical and computational results. *Review of Financial Studies*, 4(2), 315–342.
- Black, F., Litterman, R. (1992). Global portfolio optimization. *Financial Analysts Journal*, 48(5), 28–43.
- Bodnar, T., Parolya, N., Schmid, W. (2018). Estimation of the global minimum variance portfolio in high dimensions. *European Journal of Operational Research*, 266(1), 371–390.
- Brandt, M.W., Santa-Clara, P., Valkanov, R. (2009). Parametric portfolio policies: exploiting characteristics in the cross-section of equity returns. *Review of Financial Studies*, 22(9), 3411–3447.
- Britten-Jones, M. (1999). The sampling error in estimates of mean-variance efficient portfolio weights. *Journal of Finance*, 54(2), 655–671.
- Chopra, V.K., Ziemba, W.T. (1993). The effect of errors in means, variances, and covariances on optimal portfolio choice. *Journal of Portfolio Management*, 19(2), 6–11.

Bibliografie (2/6)

- Choueifaty, Y., Coignard, Y. (2008). Toward maximum diversification. *Journal of Portfolio Management*, 35(1), 40–51.
- DeMiguel, V., Garlappi, L., Nogales, F.J., Uppal, R. (2009). A generalized approach to portfolio optimization: improving performance by constraining portfolio norms. *Management Science*, 55(5), 798–812.
- DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy?. *Review of Financial Studies*, 22(5), 1915–1953.
- Dragotă, M., Șerbănescu, C.I., Pele, D.T. (2008). Portfolio diversification and market share analysis for Romanian insurance companies. În *Risk Management and Value*, World Scientific, 277–298.
- Fan, J., Liao, Y., Mincheva, M. (2013). Large covariance estimation by thresholding principal orthogonal complements. *Journal of the Royal Statistical Society: Series B*, 75(4), 603–680.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, ed. a 5-a. Springer.
- Frazzini, A., Israel, R., Moskowitz, T.J. (2018). Trading costs. SSRN Working Paper 3229719.
- Frost, P.A., Savarino, J.E. (1988). For better performance: constrain portfolio weights. *Journal of Portfolio Management*, 15(1), 29–34.
- Gârleanu, N., Pedersen, L.H. (2013). Dynamic trading with predictable returns and transaction costs. *Journal of Finance*, 68(6), 2309–2340.
- Härdle, W.K., Simar, L. (2019). Applied Multivariate Statistical Analysis, ed. a 5-a. Springer.

Bibliografie (3/6)

- Harvey, C.R., Liu, Y. (2015). Backtesting. *Journal of Portfolio Management*, 42(1), 13–28.
- He, G., Litterman, R. (2002). The intuition behind Black-Litterman model portfolios. SSRN Working Paper 334304.
- Jagannathan, R., Ma, T. (2003). Risk reduction in large portfolios: why imposing the wrong constraints helps. *Journal of Finance*, 58(4), 1651–1683.
- Jensen, T.I., Kelly, B., Malamud, S., Pedersen, L.H. (2026). Machine learning and the implementable efficient frontier. *Review of Financial Studies*, 39(10), 3035–3078.
- Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance?. *Journal of Finance*, 78(5), 2465–2518.
- Jobson, J.D., Korkie, B.M. (1981). Performance hypothesis testing with the Sharpe and Treynor measures. *Journal of Finance*, 36(4), 889–908.
- Jorion, P. (1986). Bayes-Stein estimation for portfolio analysis. *Journal of Financial and Quantitative Analysis*, 21(3), 279–292.
- Kan, R., Wang, X., Zhou, G. (2022). Optimal portfolio choice with estimation risk: no risk-free asset case. *Management Science*, 68(3), 2047–2068.
- Kan, R., Zhou, G. (2007). Optimal portfolio choice with parameter uncertainty. *Journal of Financial and Quantitative Analysis*, 42(3), 621–656.

Bibliografie (4/6)

- Künsch, H.R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- Laloux, L., Cizeau, P., Bouchaud, J.-P., Potters, M. (1999). Noise dressing of financial correlation matrices. *Physical Review Letters*, 83(7), 1467–1470.
- Ledoit, O., Wolf, M. (2003). Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10(5), 603–621.
- Ledoit, O., Wolf, M. (2004a). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- Ledoit, O., Wolf, M. (2004b). Honey, I shrunk the sample covariance matrix. *Journal of Portfolio Management*, 30(4), 110–119.
- Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- Ledoit, O., Wolf, M. (2017). Nonlinear shrinkage of the covariance matrix for portfolio selection: Markowitz meets Goldilocks. *Review of Financial Studies*, 30(12), 4349–4388.
- Ledoit, O., Wolf, M. (2020). Analytical nonlinear shrinkage of large-dimensional covariance matrices. *Annals of Statistics*, 48(5), 3043–3065.
- Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.

Bibliografie (5/6)

- López de Prado, M. (2016). Building diversified portfolios that outperform out of sample. *Journal of Portfolio Management*, 42(4), 59–69.
- Maillard, S., Roncalli, T., Teïletche, J. (2010). The properties of equally weighted risk contribution portfolios. *Journal of Portfolio Management*, 36(4), 60–70.
- Mantegna, R.N. (1999). Hierarchical structure in financial markets. *European Physical Journal B*, 11(1), 193–197.
- Marčenko, V.A., Pastur, L.A. (1967). Distribution of eigenvalues for some sets of random matrices. *Mathematics of the USSR-Sbornik*, 1(4), 457–483.
- Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- Merton, R.C. (1972). An analytic derivation of the efficient portfolio frontier. *Journal of Financial and Quantitative Analysis*, 7(4), 1851–1872.
- Merton, R.C. (1980). On estimating the expected return on the market: an exploratory investigation. *Journal of Financial Economics*, 8(4), 323–361.
- Michaud, R.O. (1989). The Markowitz optimization enigma: is 'optimized' optimal?. *Financial Analysts Journal*, 45(1), 31–42.
- Okhrin, Y., Schmid, W. (2006). Distributional properties of portfolio weights. *Journal of Econometrics*, 134(1), 235–256.

Bibliografie (6/6)

- Pele, D.T. (2023). Robust Markowitz for crypto-assets. Curs Quantinar, Academia de Studii Economice din București.
- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *The European Journal of Finance*, 29(10), 1064–1105.
- Petukhina, A., Trimborn, S., Härdle, W.K., Elendner, H. (2021). Investing with cryptocurrencies – evaluating their potential for portfolio allocation strategies. *Quantitative Finance*, 21(11), 1825–1853.
- Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- Sharpe, W.F. (1966). Mutual fund performance. *Journal of Business*, 39(S1), 119–138.
- Theil, H., Goldberger, A.S. (1961). On pure and mixed statistical estimation in economics. *International Economic Review*, 2(1), 65–78.
- Tobin, J. (1958). Liquidity preference as behavior towards risk. *Review of Economic Studies*, 25(2), 65–86.
- Tu, J., Zhou, G. (2011). Markowitz meets Talmud: a combination of sophisticated and naive diversification strategies. *Journal of Financial Economics*, 99(1), 204–215.
- Date: Kenneth R. French Data Library, mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html.

Acronime folosite în acest material (1/2)

- **AI**: Artificial Intelligence — *inteligență artificială*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BET-TR**: BET Total Return (index) — *indicele BET cu dividendele reinvestite*
- **BVB**: Bursa de Valori București
- **CAPM**: Capital Asset Pricing Model — *modelul de evaluare a activelor financiare*
- **DSR**: Deflated Sharpe Ratio — *raportul Sharpe deflatat*
- **ERC**: Equal Risk Contribution portfolio — *portofoliul cu contribuții egale la risc*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- **FDR**: False Discovery Rate — *rata descoperirilor false*
- **FWER**: Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **GLS**: Generalised Least Squares — *metoda celor mai mici pătrate generalizate*
- **GMV**: Global Minimum-Variance portfolio — *portofoliul de variață minimă globală*
- **GMV-LO**: Global Minimum-Variance portfolio, Long-Only — *portofoliul de variață minimă globală, doar poziții long*
- **GMV-LW**: Global Minimum-Variance portfolio with Ledoit–Wolf covariance — *portofoliul de variață minimă globală cu covarianța Ledoit–Wolf*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*

Acronime folosite în acest material (2/2)

- **HRP**: Hierarchical Risk Parity — *paritatea ierarhică a riscului*
- **HYG**: iShares iBoxx High Yield Corporate Bond ETF — *ETF de obligațiuni corporative americane cu randament ridicat, sub rating investițional*
- **IEF**: iShares 7–10 Year Treasury Bond ETF — *ETF de obligațiuni de stat americane cu scadența 7–10 ani*
- **LO**: Long-Only, no short sales — *doar poziții long, fără vînzări în lipsă*
- **LQD**: iShares iBoxx Investment Grade Corporate Bond ETF — *ETF de obligațiuni corporative americane cu rating investițional*
- **ML**: Machine Learning — *învățare automată*
- **MV**: Mean–Variance tangency portfolio estimated from sample moments — *portofoliul tangent medie–varianță estimat din momentele de eșantion*
- **MV-LO**: Mean–Variance tangency portfolio, Long-Only — *portofoliul tangent medie–varianță, doar poziții long*
- **NYSE**: New York Stock Exchange — *Bursa din New York*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **OMV**: Österreichische Mineralölverwaltung — *Administrația austriacă a uleiurilor minerale (grupul OMV)*
- **OOS**: Out-Of-Sample — *în afara eșantionului*
- **POET**: Principal Orthogonal complEment Thresholding — *estimatorul prin prag aplicat complementului ortogonal al componentelor principale*
- **SUA**: Statele Unite ale Americii