



Modelarea piețelor financiare

Capitolul 4: Optimizarea portofoliului



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (inteligență artificială)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- BVB: Bursa de Valori București
- CAPM: Capital Asset Pricing Model (modelul de evaluare a activelor financiare)
- DSR: Deflated Sharpe Ratio (raportul Sharpe deflatat)
- ERC: Equal Risk Contribution portfolio (portofoliul cu contribuții egale la risc)
- ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- FDR: False Discovery Rate (rata descoperirilor false)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- GLS: Generalised Least Squares (metoda celor mai mici pătrate generalizate)
- GMV: Global Minimum-Variance portfolio (portofoliul de varianță minimă globală)
- GMV-LO: Global Minimum-Variance portfolio, Long-Only (portofoliul de varianță minimă globală, doar poziții long)
- GMV-LW: Global Minimum-Variance portfolio with Ledoit–Wolf covariance (portofoliul de varianță minimă globală cu covarianța Ledoit–Wolf)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HRP: Hierarchical Risk Parity (paritatea ierarhică a riscului)
- HYG: iShares iBoxx High Yield Corporate Bond ETF (ETF de obligațiuni corporative americane cu randament ridicat, sub rating investițional)
- IEF: iShares 7–10 Year Treasury Bond ETF (ETF de obligațiuni de stat americane cu scadența 7–10 ani)
- LO: Long-Only, no short sales (doar poziții long, fără vânzări în lipsă)
- LQD: iShares iBoxx Investment Grade Corporate Bond ETF (ETF de obligațiuni corporative americane cu rating investițional)
- ML: Machine Learning (învățare automată)
- MV: Mean–Variance tangency portfolio estimated from sample moments (portofoliul tangent medie–varianță estimat din momentele de selecție)
- MV-LO: Mean–Variance tangency portfolio, Long-Only (portofoliul tangent medie–varianță, doar poziții long)
- NYSE: New York Stock Exchange (Bursa din New York)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- OOS: Out-Of-Sample (în afara eșantionului)

Acronime folosite în acest material (2/2)

- POET: Principal Orthogonal compleMent Thresholding (estimatorul prin prag aplicat complementului ortogonal al componentelor principale)
- SUA: Statele Unite ale Americii

Cuprins

Motivație

Optimizarea medie–varianță

Limitele modelului Markowitz

Shrinkage al covarianței

Black–Litterman

Risk parity și Hierarchical Risk Parity

Evaluarea în afara eșantionului

Un portofoliu de blue chips BVB

Studiu de caz: frontiera eficientă implementabilă

AI pentru descoperire științifică

Concluzii

Bibliografie

Optimizarea portofoliului: ușor de scris, greu de estimat

- Un **portofoliu** este un vector de ponderi $w = (w_1, \dots, w_N)^\top$ cu $w^\top \mathbf{1} = 1$; optimizarea alege w care maximizează un criteriu, cu restricții
- Datele de intrare sunt **estimate**: N medii și $N(N+1)/2$ varianțe și covarianțe
 - ▶ 16 active: $16 + 136 = 152$ de parametri dintr-o fereastră de 60 de luni, adică 960 de observații
- Utilizări: alocarea strategică (fonduri de pensii), preferința investitorilor individuali pentru piața locală, matricea de covarianță din managementul riscului (Capitolele 6–7)
- Mesajul central: judecăm orice regulă **în afara eșantionului**, după costuri, cu un test al diferenței
- Tratare în manual: [Franke, Härdle & Hafner \(2019\)](#), Partea I (teoria portofoliului)

Tensiunea centrală

În teorie

- Medii și covarianțe cunoscute
- Portofoliul medie–varianță este optim
- Mai multe active ajută întotdeauna

În practică

- Parametrii sunt estimați cu erori
- Optimizatorul acordă ponderi mari activelor cu cele mai mari erori de estimare
- Mai multe active, mai mulți parametri, mai mult zgomot

- În acest capitol: estimări mai bune (shrinkage, Black–Litterman), reguli fără medii (risk parity, HRP) și o comparație corectă în afara eșantionului

Datele folosite în capitol

Univers	Active	Perioadă
Sectoare	9 ETF-uri sectoriale SUA (XLB . . . XLY)	1999–2026
Multi-active	SPY, EFA, EEM, TLT, IEF, LQD, HYG, GLD	2007–2026
Combinat	9 sectoare + 7 ETF-uri multi-active (fără SPY)	2007–2026
România	8 blue chips BVB, BET, BET-TR	2014–2026

- Randamente lunare din prețurile de sfârșit de lună, pe zilele comune de tranzacționare; datele SUA până în iulie 2026, cele BVB până în august 2026
- Rata fără risc: titlul de stat american la o lună, [Kenneth French Data Library](#)

Activele

- ▣ Acțiuni: SPY (S&P 500), EFA (piețe dezvoltate din afara Americii de Nord), EEM (piețe emergente)
- ▣ Titluri de stat americane: TLT (scadențe peste 20 de ani), IEF (7–10 ani)
- ▣ Credit: LQD (obligațiuni corporative cu rating investițional), HYG (obligațiuni corporative cu randament ridicat)
- ▣ Aur: GLD; sectoare: XLK tehnologie, XLU utilități, XLP bunuri de consum de bază, ...
- ▣ BVB: TLV, SNP, BRD, TGN, SNG, SNN, EL, TEL; BET este indice de preț, BET-TR reinvestește dividendele

Recapitularea cunoștințelor: notații și două active

- ▣ Randament simplu $R_{i,t} = P_{i,t}/P_{i,t-1} - 1$; randament în exces $R_{i,t}^e = R_{i,t} - R_{f,t}$; media portofoliului $w^\top \mu$, varianța $w^\top \Sigma w$
- ▣ **Raportul Sharpe** (Sharpe (1966)): $SR_p = \mathbb{E}[R_p^e]/\sigma(R_p^e)$; cifrele lunare se anualizează cu $\times 12$ (media) și $\times \sqrt{12}$ (volatilitatea, raportul Sharpe)
- ▣ **Scăderea maximă** (maximum drawdown): $\min_t (W_t / \max_{s \leq t} W_s - 1)$, cea mai mare cădere a averii W_t de la un maxim anterior
- ▣ Două active, corelație ρ : $\sigma_p^2 = w^2 \sigma_1^2 + (1-w)^2 \sigma_2^2 + 2w(1-w)\rho\sigma_1\sigma_2$, minimă la $w^* = \frac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}$
- ▣ SPY și TLT, lunar 2002–2026: $\rho = -0,10$, $w^* = 46\%$ SPY, volatilitate 9,4% față de 14,7% și 13,5% (corelația variabilă în timp: Capitolul 6)

Problema lui Markowitz

- ▣ **Markowitz (1952)**: investitorii țin cont de media și de varianța randamentului portofoliului
- ▣ **Frontiera de varianță minimă**: varianța minimă pentru fiecare medie țintă m ; ramura ei superioară, $m \geq \mu_{\text{GMV}}$ (media portofoliului GMV), este **frontiera eficientă**

$$\min_w w^\top \Sigma w \quad \text{s.t.} \quad w^\top \mu = m, \quad w^\top \mathbf{1} = 1$$

- ▣ Forma cu utilitate, aversiune la risc $\gamma > 0$: $\max_w w^\top \mu - \frac{\gamma}{2} w^\top \Sigma w$ s.t. $w^\top \mathbf{1} = 1$; când γ variază, descrie exact ramura eficientă
- ▣ Date de intrare: N medii, N varianțe, $N(N-1)/2$ covarianțe
- ▣ Ponderile pot fi negative: o **vânzare în lipsă** (vânzarea unui activ împrumutat)

Derivarea portofoliilor GMV și tangent pentru N active

- GMV: $\min_w w^\top \Sigma w$ cu $w^\top 1 = 1$; lagrangianul $\mathcal{L} = w^\top \Sigma w - \lambda(w^\top 1 - 1)$
 - ▶ Condiția de ordinul întâi $2\Sigma w = \lambda 1$, deci $w = \frac{\lambda}{2} \Sigma^{-1} 1$; restricția dă $\frac{\lambda}{2} = 1/A$, $A = 1^\top \Sigma^{-1} 1$
 - ▶ $w_{\text{GMV}} = \Sigma^{-1} 1/A$ și $\sigma_{\text{GMV}}^2 = w_{\text{GMV}}^\top \Sigma w_{\text{GMV}} = 1/A$
- $N = 2$: $\Sigma^{-1} \propto \begin{pmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{pmatrix}$ redă w^* de pe slide-ul de recapitulare
- Tangent: maximizăm $w^\top \mu / \sqrt{w^\top \Sigma w}$; condiția $\mu \propto \Sigma w$ dă $w \propto \Sigma^{-1} \mu$
- Pătratul raportului Sharpe maxim: $\theta^2 = \mu^\top \Sigma^{-1} \mu$, mărimea al cărei estimator deplasat este analizat în Secțiunea 3
- Cu Σ pozitiv definită și $B = 1^\top \Sigma^{-1} \mu$, ponderile normalizate $\Sigma^{-1} \mu / B$ au raportul Sharpe $\text{sign}(B) \theta$
 - ▶ Maxim doar dacă $B > 0$; $B < 0$ dă minimul, iar pentru $B = 0$ nu există soluție investită integral

Tobin: separarea



James Tobin, Premiul Nobel pentru Economie
1981

Foto: autor necunoscut (1962); domeniu public;
[Wikimedia Commons](#)

- **Tobin (1958)**: adăugăm un activ fără risc cu randamentul R_f
- Toți investitorii dețin **același** portofoliu riscant, combinat cu numerar sau cu împrumut
- Aversiunea la risc schimbă doar combinația, nu și portofoliul riscant: **separarea în două fonduri**
- Cel mai bun portofoliu riscant maximizează raportul Sharpe: **portofoliul tangent**
- Separarea este puntea de la Markowitz la CAPM (Capitolul 3)

Două portofolii speciale

Varianța minimă globală (GMV)

- Cea mai mică varianță dintre toate portofoliile

$$w_{\text{GMV}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}$$

- **Nu** necesită randamente așteptate

Tangent (Sharpe maxim)

- Cel mai mare raport Sharpe

$$w_{\text{MV}} = \frac{\Sigma^{-1} \mu}{\mathbf{1}^\top \Sigma^{-1} \mu}$$

- μ : randamente așteptate **în exces**; necesită $\mathbf{1}^\top \Sigma^{-1} \mu > 0$

- În acest capitol, MV desemnează regula tangentă estimată din mediile și covarianțele de selecție

Merton: frontiera în formă închisă



Robert C. Merton, Premiul Nobel pentru
Economie 1997


Foto: Digarnick (2006); domeniu public;
[Wikimedia Commons](#)

- Merton (1972): cu vânzări în lipsă, frontiera este o hiperbolă
- Fie $A = \mathbf{1}^\top \Sigma^{-1} \mathbf{1}$, $B = \mathbf{1}^\top \Sigma^{-1} \boldsymbol{\mu}$, $C = \boldsymbol{\mu}^\top \Sigma^{-1} \boldsymbol{\mu}$, $D = AC - B^2$

$$\sigma^2(m) = \frac{Am^2 - 2Bm + C}{D}$$

- GMV se află la $m = B/A$, cu $\sigma^2 = 1/A$
- Orice portofoliu de pe frontieră este o combinație între GMV și portofoliul tangent

Frontiera sectoarelor americane



□ Randamente lunare în exces, ianuarie 1999 – iulie 2026 ($T = 331$); toți parametrii estimați pe întreg eșantionul

Interpretarea frontierei sectoarelor

- ▣ Tangent: Sharpe 0,66; GMV: 0,57 (volatilitate 11,1%); $1/N$: 0,54
- ▣ Ponderi tangente: $-0,37$ financiar, $-0,21$ materiale, $+0,37$ sănătate
- ▣ Tangent doar long: Sharpe 0,61; materiale, financiar și industrie primesc exact zero
 - ▶ O **soluție de colț**: restricția este activă și activele ies din portofoliu
- ▣ Câștigul optimizatorului față de $1/N$ este mic chiar **în eșantion**, cu informație perfectă a posteriori

Restricții

- ▣ **Doar long (LO):** $w_i \geq 0$; fără formă închisă, rezolvată prin programare pătratică
- ▣ Limite pe poziție: $w_i \leq 0,2$; limite pe sector sau clasă de active: $\sum_{i \in G} w_i \leq c_G$
- ▣ Limită de levier: $\sum_i |w_i| \leq L$
- ▣ **Frost & Savarino (1988):** restricțiile asupra ponderilor au îmbunătățit performanța în afara eșantionului
- ▣ În acest capitol: MV-LO și GMV-LO sunt versiunile doar long ale MV și GMV

Recapitulare: optimizarea medie–varianță

- ▣ Frontiera exprimă compromisul dintre medie și varianță; corelația determină diversificarea
- ▣ Două portofolii speciale: GMV, care nu necesită medii, și cel tangent, care maximizează raportul Sharpe
- ▣ Cu un activ fără risc, partea riscantă a oricărui portofoliu eficient este portofoliul tangent
- ▣ Restricțiile doar long produc soluții de colț
- ▣ Tot ce am văzut până acum presupune parametri **cunoscuți**


Mediile se estimează greu: argumentul lui Merton

- **Merton (1980)**: Y ani eşantionaţi de h ori pe an, randamente i.i.d. cu media anuală μ şi varianţa σ^2
 - ▶ $\text{Var}(\hat{\mu}) = \sigma^2/Y$: nu depinde de h ; ajută doar **durata** eşantionului
 - ▶ $\text{Var}(\hat{\sigma}^2) \approx 2\sigma^4/(hY) \rightarrow 0$ când $h \rightarrow \infty$: estimările varianţelor devin mai precise odată cu creşterea frecvenţei de observare
- SPY, $Y = 24$, $\sigma = 14,7\%$: eroare standard 3,0%, interval de 95% [5,8%, 17,6%] pentru o medie de 11,7%
- O eroare standard de 1% cere $(0,147/0,01)^2 \approx 217$ ani
- **Chopra & Ziemba (1993)**: erorile în medii costă de circa zece ori mai mult decât cele în varianţe; regulile fără medii (GMV, risk parity) sunt mai robuste

Maximizarea erorilor

- Michaud (1989): optimizatorii medie–varianță sunt **maximizatori ai erorilor de estimare**
 - ▶ Supraponderează activele cu medii supraestimate și risc subestimat
- Best & Grauer (1991): modificări mici ale unei medii pot muta ponderile multor active
- Performanța în eșantion este deci **deplasată în sus**
- Experiment: simulăm randamente din parametri cunoscuți, optimizăm, evaluăm cu parametrii adevărați

Frontiere estimate versus realizate



- Parametri adevărați: mediile și covarianțele de selecție ale sectoarelor, 1999–2026; randamente extrase din distribuția Normală

Interpretarea simulării

- ▣ Roșu: frontiere estimate din 60 de luni, mult prea optimiste
- ▣ Verde: aceleași portofolii evaluate cu parametrii adevărați, toate **sub** frontiera adevărată
- ▣ 2000 de portofolii tangente simulate, câte 60 de luni
 - ▶ Sharpe maxim estimat median $\hat{\theta}$ 1,56; Sharpe adevărat median 0,30; optimul adevărat 0,66
 - ▶ În 11% dintre eșantioane $1^\top \hat{\Sigma}^{-1} \hat{\mu} < 0$: ponderile normalizate sunt atunci minimul în eșantion
 - ▶ 96% au un Sharpe adevărat sub $1/N$ (0,54); 7,5% sub zero
- ▣ Chiar cu randamente Normale și stabile, eroarea de estimare distruge optimul

Raportul Sharpe estimat direct este deplasat: un rezultat exact

- ▣ Randamente i.i.d. $N(\mu, \Sigma)$, $\hat{\mu}$ și $\hat{\Sigma}$ de verosimilitate maximă: $\hat{\mu} \sim N(\mu, \Sigma/T)$, $T\hat{\Sigma} \sim W_N(T-1, \Sigma)$ (Wishart), independente
- ▣ Momentul Wishart invers, finit pentru $T > N + 2$: $\mathbb{E}[\hat{\Sigma}^{-1}] = \frac{T}{T-N-2}\Sigma^{-1}$, o deplasare **în sus** care crește cu N/T
- ▣ Prin urmare, cu $\hat{\theta}^2 = \hat{\mu}^\top \hat{\Sigma}^{-1} \hat{\mu}$ (Kan & Zhou (2007))

$$\mathbb{E}[\hat{\theta}^2] = \frac{T}{T-N-2} \left(\theta^2 + \frac{N}{T} \right) = \frac{T\theta^2 + N}{T-N-2}$$

- ▣ Sectoare: $N = 9$, $T = 60$, θ adevărat = 0,66 pe an: $\mathbb{E}[\hat{\theta}^2]$ corespunde unui Sharpe de 1,65 pe an
 - Corespondentul analitic al medianei simulate de 1,56 de pe slide-ul anterior

Corectarea deplasării și distribuția ponderilor

- Estimator nedeplasat al lui θ^2 (Kan & Zhou (2007)): $\hat{\theta}_u^2 = [(T - N - 2)\hat{\theta}^2 - N]/T$
 - Poate fi negativ (atunci se trunchiază la zero), iar $\sqrt{\hat{\theta}_u^2}$ nu este nedeplasat pentru θ
- Sectoare, tot eșantionul ($T = 331$, $N = 9$): $\hat{\theta} = 0,66$ estimat direct, $\sqrt{\hat{\theta}_u^2} = 0,31$ pe an după corecție
 - Corecția elimină mai mult de jumătate din Sharpe-ul tangent în eșantion, chiar cu 27 de ani de date
- Ponderile GMV: $\hat{w}_{GMV}$ este nedeplasat, iar distribuția și covarianța lui exacte sunt cunoscute (Okhrin & Schmid (2006))
- Ponderile tangente se împart la $1^\top \hat{\Sigma}^{-1} \hat{\mu}$, care poate fi aproape de zero: cozi foarte grele, exploziile ponderilor rulante
- Combinații ale portofoliilor tangent, GMV și $1/N$, optime în prezența riscului de estimare: Kan & Zhou (2007), Kan, Wang & Zhou (2022)

Ponderile tangente prin regresie: Britten-Jones (1999)

- Britten-Jones (1999): regresăm constanta 1 pe randamentele în exces, **fără** termen liber

$$1 = \mathbf{b}^\top \mathbf{r}_t + u_t, \quad \hat{\mathbf{b}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{1} \propto \hat{\Sigma}^{-1} \hat{\boldsymbol{\mu}}$$

- Sherman–Morrison aplicat lui $\mathbf{X}^\top \mathbf{X} / T = \hat{\Sigma} + \hat{\boldsymbol{\mu}} \hat{\boldsymbol{\mu}}^\top$ dă proporționalitatea (Seminarul 4, A2); $\hat{\mathbf{b}} / \mathbf{1}^\top \hat{\mathbf{b}} =$ ponderile tangente de selecție
- Testul t OLS al lui $b_i = 0$: activul i are pondere nulă în portofoliul tangent
- Testul F al lui $\mathbf{R}\mathbf{b} = 0$: de exemplu $b_1 = \dots = b_N$, adică „portofoliul tangent este $1/N$ ”
- Distribuții t și F exacte în eșantion finit pentru randamente i.i.d. Normale; altfel erori standard HAC

Britten-Jones pe cele nouă sectoare

- ▣ Randamente lunare în exces, ianuarie 1999 – iulie 2026 ($T = 331$); $\hat{b}$ normalizat redă ponderile tangente ($-0,37$ financiar, $+0,37$ sănătate)
- ▣ Nicio pondere nu diferă de zero: cel mai mare $|t| = 1,12$ (financiar); cu erori HAC 1,19
- ▣ H_0 : tangent = $1/N$, opt restricții $b_i = b_9$
 - ▶ $F(8, 322) = 0,48$, $p = 0,87$; Wald HAC $\chi^2_8 = 4,50$, $p = 0,81$
- ▣ 27 de ani de date nu pot deosebi optimul estimat de ponderile egale
- ▣ Același verdict ca simularea lungimii ferestrei și testele în afara eșantionului de mai jos

Ponderi instabile



- Nouă ETF-uri sectoriale; în fiecare lună ponderile folosesc doar ultimele 60 de luni (panoul de sus tăiat la ± 6)


Interpretarea ponderilor rulante

- MV: expunere brută mediană $\sum_i |w_i| = 4,9$; cea mai mare pondere 26 în valoare absolută
- Expunere brută peste 3 în 90% din luni
- Explozii în 2004–2006 și 2009: $1^\top \hat{\Sigma}^{-1} \hat{\mu}$ apropiat de zero la numitor
 - Negativ în 12 din 271 de ferestre: MV, așa cum este publicat, deține atunci portofoliul cu Sharpe minim
- GMV cu shrinkage (secțiunea următoare): expunere brută 1,5, pondere maximă 0,94
- Ponderi instabile înseamnă rulaj mare, deci costuri mari de tranzacționare

Reperul 1/N

- ▣ **1/N**: ponderi egale $w_i = 1/N$, reechilibrate lunar; nicio estimare
- ▣ DeMiguel, Garlappi & Uppal (2009): 14 modele de optimizare pe 7 seturi de date
 - Niciunul nu bate consecvent 1/N în raport Sharpe, randament cert echivalent sau rulaj
- ▣ Calibrarea lor: circa 3000 de luni de date pentru ca MV de selecție să bată 1/N cu 25 de active
- ▣ Kan & Zhou (2007): combinarea portofoliului tangent cu GMV reduce riscul de estimare
- ▣ Întrebare: cât de lungă trebuie să fie fereastra pentru cele nouă sectoare?

Cât de lungă trebuie să fie fereastra?



- 300 de eşantioane simulate pentru fiecare lungime a ferestrei; parametrii adevărați ca în simularea anterioară

Interpretarea experimentului cu fereastra

- ▣ MV bate 1/N doar cu 480 de luni (40 de ani) de date: Sharpe adevărat median 0,55 față de 0,54
- ▣ Cu 60 de luni, MV atinge 0,31, sub 60% din 1/N
- ▣ MV doar long, GMV și GMV cu shrinkage sunt aproape de 1/N de la 60 de luni
- ▣ ERC (Secțiunea 6) este aproape insensibil la fereastră: 0,56 peste tot
- ▣ Aici 1/N este aproape eficient: Sharpe-ul tangent adevărat este doar 0,66

Recapitulare: limitele modelului Markowitz

- Mediile se estimează cu erori mari; optimizatorul le amplifică
- Rapoartele Sharpe în eșantion ale portofoliilor optimizate sunt deplasate în sus: $\mathbb{E}[\hat{\theta}^2] = (T\theta^2 + N)/(T - N - 2)$
- Regresia Britten-Jones: ponderile tangente sunt coeficienții OLS normalizați la suma unu; pe sectoare nu se deosebesc statistic de $1/N$
- Ponderile MV de selecție sunt instabile și extreme
- $1/N$ este un reper greu de bătut: MV are nevoie de decenii de date
- Remedii: covarianțe mai bune, medii mai bune sau reguli care evită mediile

De ce eșuează matricea de covarianță de selecție

- ▣ N active: $N(N + 1)/2$ varianțe și covarianțe; 16 active: 136 de parametri din 60 de luni
- ▣ Valorile proprii de selecție sunt prea dispersate: cea mai mare prea mare, cea mai mică prea mică
- ▣ **Numărul de condiționare**: cea mai mare valoare proprie împărțită la cea mai mică; o valoare mare înseamnă că Σ^{-1} amplifică zgomotul
- ▣ Optimizatorii inversează Σ , deci concentrează expunerea pe direcțiile cu cea mai mică varianță estimată
- ▣ Matricea de selecție centrată are rangul cel mult $T - 1$: singulară, neinvertibilă, ori de câte ori $T \leq N$

Valorile proprii ale zgomotului pur: Marchenko–Pastur


- ▣ Randamente i.i.d. cu $\Sigma = \sigma^2 I$: toate valorile proprii adevărate sunt egale cu σ^2
- ▣ Marčenko & Pastur (1967): când $N, T \rightarrow \infty$ cu $N/T \rightarrow c \in (0, 1)$, valorile proprii de selecție umplu

$$[\lambda_-, \lambda_+] = [\sigma^2(1 - \sqrt{c})^2, \sigma^2(1 + \sqrt{c})^2]$$

- ▣ $c = 16/60 = 0,27$: banda $[0,23; 2,30]$ pentru o matrice de corelație ($\sigma^2 = 1$), o împrăștiere de zece ori doar din zgomot
- ▣ Laloux et al. (1999): valorile proprii din afara benzii sunt candidate pentru o structură dincolo de acest model de zgomot; cele din interior nu se pot deosebi de el doar prin această comparație
- ▣ Afirmatia „valorile proprii de selecție sunt prea dispersate” devine un reper cantitativ

Valorile proprii de selecție versus banda zgomotului

Last 60-month window, Aug 2021 - Jul 2026



- Matricele de corelație ale randamentelor lunare în exces, ultima fereastră de 60 de luni (august 2021 – iulie 2026); banda gri: $[\lambda_-, \lambda_+]$ pentru $\sigma^2 = 1$

Interpretarea graficului valorilor proprii

- ▣ 16 ETF-uri: o singură valoare proprie peste $\lambda_+ = 2,30$, modul pieței (9,0, 56% din urmă); nouă sunt în bandă
- ▣ Nouă sectoare: tot doar modul pieței (5,2) este peste $\lambda_+ = 1,92$
- ▣ Cu varianța zgomotului rescalată la $\sigma^2 = 1 - \lambda_1/N$ (Laloux et al. (1999)): trei valori proprii peste bandă în fiecare univers
- ▣ Valori proprii **sub** bandă (șase din 16): combinații aproape fără risc, de exemplu TLT contra IEF
 - ▶ GMV concentrează expunerea exact pe aceste direcții: dacă varianțele lor sunt subestimate, și riscul portofoliului este subestimat

Estimatorul de tip shrinkage

- ▣ **Shrinkage** (contractie): apropiem matricea de selecție S de o țintă structurată F

$$\hat{\Sigma}_{\text{LW}} = \delta F + (1 - \delta) S, \quad 0 \leq \delta \leq 1$$

- ▣ Ținte

- ▶ Modelul cu un singur indice (piața): Ledoit & Wolf (2003)
- ▶ Matricea identitate scalată: Ledoit & Wolf (2004a)
- ▶ Corelație constantă, $f_{ii} = s_{ii}$ și $f_{ij} = \bar{r} \sqrt{s_{ii}s_{jj}}$ pentru $i \neq j$, $\bar{r}$ corelația medie de selecție: Ledoit & Wolf (2004b), folosită aici

- ▣ δ controlează compromisul dintre varianța estimatorului S și deplasarea estimatorului F


Intensitatea optimă a shrinkage-ului

- ▣ Ledoit–Wolf aleg δ care minimizează distanța pătratică așteptată (Frobenius) față de Σ adevărată

$$\delta^* = \max \left\{ 0, \min \left\{ 1, \frac{\hat{\kappa}}{T} \right\} \right\}, \quad \hat{\kappa} = \frac{\hat{\pi} - \hat{\rho}}{\hat{\gamma}}$$

- ▣ $\hat{\pi}$: suma varianțelor asimptotice ale elementelor lui S (zgomotul)
- ▣ $\hat{\rho}$: covarianțele lor cu ținta; $\hat{\gamma} = \|F - S\|^2$ (specificarea greșită a țintei)
- ▣ Date zgomotoase sau o țintă bună: δ mare; eşantioane lungi: $\delta \rightarrow 0$

Shrinkage pe sectoarele americane



- Nouă ETF-uri sectoriale, randamente lunare în exces; ultima fereastră august 2021 – iulie 2026

Interpretarea graficului de shrinkage

- ▣ Ultima fereastră: $\delta = 0,24$; cele mai mici valori proprii cresc, cele mai mari aproape nu se schimbă
- ▣ Numărul de condiționare: selecție 51,6, după shrinkage 32,5
- ▣ δ rulant: medie 0,43, interval 0,19–1,00
 - ▶ $\delta = 1$ în primele ferestre: 60 de luni sunt prea puține pentru a bate ținta
- ▣ GMV-LW: portofoliul GMV calculat cu $\hat{\Sigma}_{LW}$

Și restricțiile sunt shrinkage

- ▣ Jagannathan & Ma (2003): GMV doar long este GMV fără restricții al unei matrice de covarianță modificate

$$\tilde{S} = S - (\lambda \mathbf{1}^\top + \mathbf{1} \lambda^\top), \quad \lambda \geq 0 \text{ multiplicatorii lui } w_i \geq 0$$

- ▶ $\tilde{s}_{ij} = s_{ij} - \lambda_i - \lambda_j$: o restricție activă pe activul i îi scade toate covarianțele, ceea ce contractă estimările mari
- ▣ Impunerea restricției „greșite” (fără vânzări în lipsă) poate reduce riscul în afara eșantionului
- ▣ Efectul este mai mare când covarianțele sunt estimate din puține observații
- ▣ Regulă practică: aplicăm shrinkage, restricții sau ambele, dar nu inversăm niciodată o matrice de selecție brută pentru multe active

Dincolo de shrinkage-ul liniar

- ▣ Shrinkage-ul liniar mută toate valorile proprii spre țintă cu un singur δ ; shrinkage-ul **neliniar** corectează fiecare valoare proprie separat
 - ▶ Ledoit & Wolf (2017): calibrat pentru selecția portofoliului; Ledoit & Wolf (2020): o formulă analitică, fără optimizare
- ▣ Structură factorială plus o matrice rară a covarianțelor reziduale: POET (Fan, Liao & Mincheva (2013)), legătura cu Capitolul 3
- ▣ GMV în dimensiune mare, cu shrinkage spre un portofoliu țintă: Bodnar, Parolya & Schmid (2018)
- ▣ În afara eșantionului, fereastră de 60 de luni, volatilitatea GMV
 - ▶ Sectoare: de selecție 11,90%, liniar (corelație constantă) 11,80%, neliniar 11,62%
 - ▶ 16 ETF-uri: de selecție 4,06%, liniar 4,38%, neliniar 4,31%: mai bun decât ținta liniară, nu și decât matricea brută

Recapitulare: shrinkage al covarianței

- ▣ Matricea de covarianță de selecție este zgomotoasă și prost condiționată când N este mare față de T
- ▣ Shrinkage-ul o combină cu o țintă structurată; datele aleg ponderea δ
- ▣ Ținta contează: corelația constantă se potrivește mai bine unei singure clase de active decât unui amestec de acțiuni și obligațiuni
- ▣ Restricțiile fără vânzări în lipsă acționează ca un shrinkage implicit
- ▣ Marchenko–Pastur oferă un reper asimptotic de zgomot pentru valorile proprii; shrinkage-ul neliniar le tratează pe fiecare separat

Shrinkage-ul mediilor: o familie de estimatori

- Bayes–Stein (Jorion (1986)): $\hat{\mu}_{BS} = (1 - \hat{\phi}) \hat{\mu} + \hat{\phi} \hat{\mu}_{GMV}$
 - Shrinkage bayesian empiric al fiecărei medii spre media portofoliului GMV; $\hat{\phi}$ dintr-un argument de tip Stein, mai mare când N/T este mare
- Tu & Zhou (2011): combinația convexă dintre o regulă sofisticată și $1/N$ care minimizează pierderea așteptată în afara eșantionului
- DeMiguel, Garlappi, Nogales & Uppal (2009): restricțiile de normă $\|w\|_1 \leq \delta$ sau $\|w\|_2 \leq \delta$ includ GMV doar long, GMV cu shrinkage și $1/N$; puntea spre portofoliile lasso din Capitolul 13
- Black–Litterman (slide-urile următoare): shrinkage bayesian al lui μ spre randamentele implicite ale unui portofoliu de referință

Black și Litterman: pornind de la echilibru



Fischer Black (1938–1995)

Foto: Dalmatine at English Wikipedia; domeniu
public; Wikimedia Commons

- Black & Litterman (1992), dezvoltat la Goldman Sachs
- Problema: mediile de selecție dau ponderi extreme, contraintuitive
- Ideea: pornim de la randamentele care fac optim un portofoliu de **referință**
- Adăugăm **opiniile** investitorului, ponderate cu încrederea în ele
- Rezultat: ponderile se îndepărtează de referință doar acolo unde există opinii

Pasul 1: optimizarea inversă

- Un investitor medie–varianță cu aversiunea la risc δ_{RA} și acces la numerar deține $w^* = (\delta_{RA} \Sigma)^{-1} \mu$ în active riscante și $1 - 1^\top w^*$ în numerar
- Inversăm relația: randamentele care fac optim portofoliul de referință w_b

$$\pi = \delta_{RA} \Sigma w_b$$

- π : randamente în exces **implicite** (de echilibru); cu ponderile pieței, randamentele CAPM
- Aici: nu avem capitalizările sectoarelor, deci $w_b = 1/N$, $\delta_{RA} = 2,5$

Pasul 2: opiniile și distribuția a posteriori

- ▣ K opinii: $P\mu = q + \varepsilon$, $\varepsilon \sim N(0, \Omega)$; a priori $\mu \sim N(\pi, \tau\Sigma)$
- ▣ Media a posteriori: o medie ponderată cu precizia

$$\mu_{BL} = [(\tau\Sigma)^{-1} + P^\top \Omega^{-1} P]^{-1} [(\tau\Sigma)^{-1} \pi + P^\top \Omega^{-1} q]$$

- ▣ Ponderi: $w_{BL} = (\delta_{RA}\Sigma)^{-1} \mu_{BL}$
- ▣ **He & Litterman (2002)**: $\tau = 0,05$, $\Omega = \text{diag}(P \tau\Sigma P^\top)$; cu Σ în formula ponderilor, se modifică doar ponderile activelor incluse în opinii (covarianța a posteriori ar scala în plus toate ponderile cu $1/(1 + \tau)$)


Black–Litterman ca estimare mixtă (GLS)

- ▣ Theil & Goldberger (1961): suprapunem distribuția a priori și opiniile într-o singură regresie pentru μ

$$\begin{pmatrix} \pi \\ q \end{pmatrix} = \begin{pmatrix} I \\ P \end{pmatrix} \mu + \begin{pmatrix} e_1 \\ e_2 \end{pmatrix}, \quad \text{Var} \begin{pmatrix} e_1 \\ e_2 \end{pmatrix} = \begin{pmatrix} \tau \Sigma & 0 \\ 0 & \Omega \end{pmatrix}$$

- ▣ GLS dă exact μ_{BL} de pe slide-ul anterior, cu covarianța $M = [(\tau \Sigma)^{-1} + P^T \Omega^{-1} P]^{-1}$
- ▣ Formă echivalentă: $\mu_{BL} = \pi + \tau \Sigma P^T (P \tau \Sigma P^T + \Omega)^{-1} (q - P \pi)$
- ▣ Limite: $\Omega \rightarrow 0$ dă exact $P \mu_{BL} = q$ (cele mai mici pătrate cu restricții); $\Omega \rightarrow \infty$ dă π
- ▣ Un activ, $\pi = 5\%$, $\tau \sigma^2 = 0,00128$, opinia 8% cu varianța 0,0004: $\mu_{BL} = 7,29\%$, ponderea opiniei 0,76

Black-Litterman pe sectoarele americane



□ Σ din randamentele lunare în exces, august 2016 – iulie 2026; o opinie: XLK minus XLU = 3% pe an

Interpretarea Black–Litterman

- XLK minus XLU implicit: 2,2%; opinia 3%; a posteriori 2,6% (media simplă, deoarece Ω este egală cu varianța a priori a opiniei)
- Ponderi: XLK de la 11,1% la 14,4%, XLU de la 11,1% la 7,8%, restul neschimbate
- Cu mediile de selecție: XLK 21,3% pe an; ponderi MV +115% XLK, −68% XLY, −46% XLB
- Opinia este relativă ($P1 = 0$): înclinarea $\propto P^T$ are suma zero, deci portofoliul rămâne investit integral; o opinie absolută ar muta și poziția în numerar
- Black–Litterman este un shrinkage bayesian al mediilor spre echilibru

Recapitulare: Black–Litterman

- Distribuția a priori vine dintr-un portofoliu de referință, nu din medii de selecție zgomotoase
- Opiniile sunt incluse cu un nivel explicit de încredere; se modifică doar ponderile activelor vizate de opinii
- Rezultatele depind de referință, de τ , de Ω și de aversiunea la risc
- Fără opinii, Black–Litterman reproduce portofoliul de referință
- Formal, un estimator GLS (mixt): un membru al familiei de estimatori cu shrinkage al mediilor, alături de Bayes–Stein și de combinațiile cu $1/N$

Contribuțiile la risc

- ▣ Volatilitatea este omogenă de gradul unu în ponderi (Euler)

$$\sigma_p = \sum_{i=1}^N w_i \frac{\partial \sigma_p}{\partial w_i} = \sum_{i=1}^N \frac{w_i (\Sigma w)_i}{\sigma_p}$$

- ▣ **Contribuția la risc** a activului i : $RC_i = w_i (\Sigma w)_i / \sigma_p$; cota procentuală RC_i / σ_p
- ▣ Ponderi egale nu înseamnă riscuri egale: activele volatile domină
- ▣ Bugetarea riscului: alegem w astfel încât cotele RC_i / σ_p să fie egale cu bugete prestabilite b_i

Contribuții egale la risc


- ERC (Maillard, Roncalli & Teïletche (2010)): $RC_i = RC_j$ pentru orice i, j
- Se calculează dintr-o problemă convexă, apoi se normalizează la suma unu

$$\min_{y>0} \frac{1}{2} y^\top \Sigma y - \frac{1}{N} \sum_i \ln y_i, \quad w = y / 1^\top y$$

- Ordinea volatilităților: $\sigma_{GMV} \leq \sigma_{ERC} \leq \sigma_{1/N}$
- Două active: ERC are **ponderi invers proporționale cu volatilitatea**, $w_1 = \sigma_1^{-1} / (\sigma_1^{-1} + \sigma_2^{-1})$, pentru orice $\rho \in (-1, 1)$
 - SPY (14,7%) și IEF (6,6%): ERC deține 31% SPY; într-un portofoliu 60/40, SPY poartă 94% din risc
- Nu necesită randamente așteptate, doar Σ ; pentru Σ pozitiv definită soluția există și este unică (funcție obiectiv strict convexă, infinită la frontieră)

Ponderi versus contribuții la risc

Eight multi-asset ETFs, monthly May 2007 - Jul 2026



- Opt ETF-uri multi-active, matricea de covarianță pe tot eșantionul, mai 2007 – iulie 2026 ($T = 231$)

Interpretarea contribuțiilor la risc

- ▣ 1/N: acțiunile și obligațiunile cu randament ridicat primesc jumătate din pondere, dar 69% din risc
- ▣ ERC: 12,5% din risc de la fiecare activ; IEF primește cea mai mare pondere (25%)
- ▣ GMV doar long: 73% IEF, 22% HYG, 5% SPY; cinci active la zero
- ▣ Volatilitate: 1/N 9,4%, ERC 7,9%, HRP 7,1%, GMV doar long 5,8%
- ▣ ERC se află între 1/N și GMV, așa cum prezice teoria


Gruparea ierarhică a activelor

- ▣ Distanța de corelație: $d_{ij} = \sqrt{(1 - \rho_{ij})/2} \in [0, 1]$
- ▣ **Legătura simplă** (single linkage): unim repetat cele mai apropiate două grupe; distanța dintre grupe = cea mai apropiată pereche
- ▣ Rezultatul este un arbore (**dendrogramă**); tăiat la un nivel, dă grupe de active similare
- ▣ **Mantegna (1999)**: aceeași distanță și **arborele de acoperire minimă** arată ierarhia unei piețe de acțiuni
- ▣ Manual: **Härdle & Simar (2019)**, analiza de grupare

Hierarchical Risk Parity

- ▣ HRP (López de Prado (2016)), trei pași
 - ▶ Gruparea în arbore: distanța euclidiană dintre coloanele matricei $D = (d_{ij})$, $\tilde{d}_{ij} = \sqrt{\sum_k (d_{ki} - d_{kj})^2}$, apoi legătura simplă pe $\tilde{d}_{ij}$
 - ▶ Cvasi-diagonalizarea: reordonăm activele astfel încât cele similare să fie alăturate
 - ▶ Bisecția recursivă: împărțim lista ordonată în două; împărțim ponderea invers proporțional cu varianța fiecărei jumătăți
- ▣ Varianța unei jumătăți: ponderi invers proporționale cu varianța în interiorul ei, $\tilde{w}^\top \Sigma \tilde{w}$
- ▣ Fără inversarea matricei: funcționează chiar dacă Σ este singulară
- ▣ Toate ponderile sunt pozitive

HRP pe 16 ETF-uri



- Nouă sectoare și șapte ETF-uri multi-active, lunar, mai 2007 – iulie 2026

Interpretarea arborelui

- ▣ Cea mai apropiată pereche: TLT și IEF ($\tilde{d} = 0,29$); aurul se alătură ultimul (0,96)
- ▣ Grupa acțiunilor: sectoarele ciclice, EFA, EEM și creditul cu randament ridicat
- ▣ Sectoarele defensive (utilități, bunuri de bază, sănătate) și energia se alătură târziu grupei acțiunilor
- ▣ HRP: toate cele 16 ponderi pozitive, cele mai mari IEF 26,7%, LQD 17,6% și HYG 12,6%
- ▣ GMV doar long: 75,6% în IEF și doar cinci active cu ponderi strict pozitive

Alte reguli bazate pe risc

- ▣ **Ponderare invers proporțională cu volatilitatea:** $w_i \propto 1/\sigma_i$; coincide cu ERC când toate corelațiile sunt egale
- ▣ **Diversificarea maximă** (Choueifaty & Coignard (2008)): maximizăm $w^T \sigma / \sqrt{w^T \Sigma w}$
- ▣ **Varianța minimă:** GMV, regula extremă bazată pe risc
- ▣ Toate ignoră randamentele așteptate: robuste la erori de estimare, dar optime doar în ipoteze speciale
 - ▶ ERC este portofoliul tangent dacă toate activele au același raport Sharpe și corelații egale

Recapitulare: alocarea bazată pe risc

- ▣ Contribuțiile la risc descompun aditiv volatilitatea portofoliului
- ▣ ERC le egalizează; se află între $1/N$ și GMV
- ▣ HRP folosește un arbore al corelațiilor și nu inversează matrice
- ▣ Aceste reguli evită complet randamentele așteptate: mai puține erori de estimare, nicio opinie asupra randamentelor

Construcția backtest-ului

- ▣ **În afara eșantionului** (OOS): ponderile din luna t folosesc doar date până la $t - 1$
- ▣ Fereastră rulantă de 60 de luni; reechilibrare lunară
- ▣ Opt reguli: 1/N, MV, MV-LO, GMV, GMV-LO, GMV-LW, ERC, HRP
- ▣ Trei universuri: sectoare (OOS ianuarie 2004 – iulie 2026, 271 de luni), multi-active și combinat (mai 2012 – iulie 2026, 171 de luni)
- ▣ Media, volatilitatea (anualizate) și raportul Sharpe ale randamentelor în exces; scăderea maximă de la vârf a averii din randamente totale


Rulajul şi costurile de tranzacţionare

- ▣ Între reechilibrări, ponderile se modifică odată cu randamentele

$$w_{i,t}^+ = \frac{w_{i,t}(1 + R_{i,t})}{\sum_j w_{j,t}(1 + R_{j,t})}$$

- ▣ **Rulajul** (turnover): fracţiunea din avere tranzacţionată, $TO_{t+1} = \sum_i |w_{i,t+1} - w_{i,t}^+|$
- ▣ Randament net cu costul c pe unitatea tranzacţionată: $R_{p,t}^{\text{net}} = R_{p,t} - c TO_t$
- ▣ Şi $1/N$ tranzacţionează: vinde câştigătorii şi cumpără perdantii în fiecare lună

Creşterea în afara eşantionului: multi-active




- Opt ETF-uri multi-active; averea relativă la un cont de titluri de stat pe termen scurt (T-bills), înainte de costuri; o traiectorie se opreşte la o pierdere lunară de 100% sau mai mare (MV)

Interpretarea backtest-ului multi-active

- ▣ MV se prăbuşeşte: volatilitate anualizată 518%, rulaj de 44 de ori averea pe lună; o pierdere lunară de peste 100% îi încheie traiectoria averii
- ▣ MV-LO are cel mai mare Sharpe (0,80); 1/N 0,52; ERC 0,49
- ▣ Regulile GMV au cea mai mică volatilitate (3,8%–5,4%), dar şi rapoarte Sharpe mici (0,27–0,37)
 - ▶ Concentrează expunerea pe titluri de stat, ale căror randamente în exces au fost uşor negative după mai 2012 (TLT –0,5%, IEF –0,2% pe an)
- ▣ Este MV-LO chiar mai bun sau doar norocos? E nevoie de un test

Rapoarte Sharpe în cele trei universuri



☐ Fereastră rulantă de 60 de luni, reechilibrare lunară, rapoarte Sharpe anualizate, înainte de costuri

 MFM_ch4_oos_backtest

Rezultate: universul sectoarelor

Regula	Medie	Volatilitate	Sharpe	Rulaj	Scădere maximă
1/N	9,4%	14,3%	0,66	0,02	−49%
MV	17,8%	69,0%	0,26	3,86	−100%
MV-LO	10,7%	14,7%	0,72	0,23	−42%
GMV	8,5%	11,9%	0,71	0,23	−33%
GMV-LO	8,1%	11,5%	0,70	0,09	−34%
GMV-LW	7,6%	11,8%	0,65	0,14	−31%
ERC	9,3%	13,2%	0,70	0,03	−47%
HRP	8,9%	12,8%	0,70	0,08	−45%


- Ianuarie 2004 – iulie 2026; rulaj: fracțiunea medie lunară din avere tranzacționată; scăderea maximă a averii din randamente totale
- MV: o pierdere lunară de peste 100% anulează capitalul (scădere −100%); media și Sharpe-ul lui descriu o serie ipotetică de randamente, nu o avere investibilă
- Toate regulile, în afară de MV, sunt la cel mult 0,07 de 1/N

Rezultate: universul combinat (16 ETF-uri)

Regula	Medie	Volatilitate	Sharpe	Rulaj	Sharpe, 50 bp
1/N	7,9%	10,3%	0,76	0,02	0,75
MV	28,7%	261,8%	0,11	22,10	-0,51
MV-LO	8,0%	9,8%	0,81	0,20	0,69
GMV	0,8%	4,1%	0,20	0,24	-0,15
GMV-LO	2,0%	5,4%	0,36	0,06	0,30
GMV-LW	0,9%	4,4%	0,20	0,13	0,03
ERC	5,5%	7,8%	0,71	0,03	0,68
HRP	4,0%	7,0%	0,56	0,11	0,47

- Mai 2012 – iulie 2026; ultima coloană: după deducerea costurilor de 50 de puncte de bază pe unitatea de rulaj
- 1 punct de bază (bp) = 0,01%

Rapoarte Sharpe după costuri



□ Universul combinat (16 ETF-uri); costul c de la 0 la 100 bp pe unitatea de rulaj

Interpretarea graficului costurilor

- ▣ Rulajul variază de la 0,02 ($1/N$) la 22 (MV) pe lună
- ▣ Sharpe-ul net devine negativ la circa 11 bp pentru MV, 29 bp pentru GMV, 58 bp pentru GMV-LW
- ▣ MV-LO depășește $1/N$ doar pentru costuri sub circa 22 bp (Seminar, B8)
- ▣ $1/N$ și ERC aproape nu se mișcă: rulajul mic este un avantaj ascuns
- ▣ Regulă: raportăm performanța netă pentru costuri realiste, nu doar pe cea brută

Inferența pentru un singur raport Sharpe: Lo (2002)

- ▣ Lo (2002), randamente i.i.d. Normale: $\sqrt{T}(\widehat{SR} - SR) \rightarrow N(0, 1 + SR^2/2)$, cu SR lunar
- ▣ $1/N$ pe sectoare, $T = 271$: $\widehat{SR}$ lunar = 0,191, eroare standard 0,061
 - ▶ Anualizat $0,66 \pm 1,96 \times 0,21$: interval de 95% [0,25; 1,08]
- ▣ Anualizarea cu $\sqrt{q}$ ($q = 12$) este exactă doar fără autocorelație; în general $SR(q) = \eta(q) SR$

$$\eta(q) = \frac{q}{\sqrt{q + 2 \sum_{k=1}^{q-1} (q-k) \rho_k}}$$

- ▣ Aici $\rho_1 = -0,03$, $\sum_{k=1}^{11} \rho_k = -0,11$: $\eta = 3,62$ în loc de $\sqrt{12} = 3,46$, Sharpe anual 0,69

Testarea unei diferențe de rapoarte Sharpe

- ▣ H_0 : $SR_1 = SR_2$ pentru două strategii evaluate pe aceleași luni
- ▣ Jobson & Korkie (1981): un test pentru randamente i.i.d. Normale
- ▣ Ledoit & Wolf (2008): o versiune robustă
 - ▶ $\hat{\Delta} = f(\hat{v})$, $v = (\mu_1, \mu_2, \mathbb{E}[r_1^2], \mathbb{E}[r_2^2])$, $f = \frac{\mu_1}{\sqrt{\mathbb{E}r_1^2 - \mu_1^2}} - \frac{\mu_2}{\sqrt{\mathbb{E}r_2^2 - \mu_2^2}}$
 - ▶ Eroarea standard prin metoda delta: $\sqrt{\nabla f^\top \hat{\Psi} \nabla f / T}$, $\hat{\Psi}$ o covarianță HAC
- ▣ Strategiile pe aceleași active sunt puternic corelate: diferențe mici pot fi semnificative

Bootstrap pe blocuri




Bradley Efron, inventatorul bootstrap-ului
(1979)

Foto: Ryan K. Morris (2007); domeniu
public; [Wikimedia Commons](#)

- Bootstrap: reeșantionăm datele pentru a aproxima distribuția de selecție a lui $\hat{\Delta}$
- Randamentele sunt dependente (grupări de volatilitate): reeșantionăm **blocuri** de luni consecutive ([Künsch \(1989\)](#))
- [Ledoit & Wolf \(2008\)](#), Secțiunea 3.2.2: blocuri circulare de perechi (r_{1t}, r_{2t}) , care continuă de la sfârșitul eșantionului la început
- **Studentizat**: bootstrap pentru $|\hat{\Delta}^* - \hat{\Delta}|/s(\hat{\Delta}^*)$, cu $s(\hat{\Delta}^*)$ din sumele pe blocuri ale fiecărei reeșantionări
 - Statistica studentizată este asimptotic pivotală: mai precisă decât aproximarea Normală a testului HAC
- $s(\hat{\Delta})$ pe date: nucleul pătratic-spectral prealbit ([Andrews & Monahan \(1992\)](#)), lățime de bandă automată ([Andrews \(1991\)](#))
- $p = [\#\{\tilde{d}^{*m} \geq |\hat{\Delta}|/s(\hat{\Delta})\} + 1]/(M + 1)$, $M = 4999$ extrageri

Alegerea lungimii blocului: Algoritmul 3.1

- Ledoit & Wolf (2008), Algoritmul 3.1: alegem blocul b al cărui interval bootstrap are acoperirea efectivă cea mai apropiată de 95%
 - ▶ Estimăm un model vectorial autoregresiv de ordinul întâi pentru perechea de randamente; reeşantionăm reziduurile printr-un bootstrap staţionar (Politis & Romano (1994)), bloc mediu 5
 - ▶ Generăm $K = 5000$ de pseudo-eşantioane de lungime T ; în fiecare construim intervalul de 95% pentru $b \in \{1, 2, 4, 6, 8, 10\}$
 - ▶ $\hat{g}(b)$: ponderea intervalelor care conţin $\hat{\Delta}$ pseudo-adevărat; alegem $\tilde{b} = \arg \min_b |\hat{g}(b) - 0,95|$
- Grila şi K sunt cele din articol (Secţiunile 4–5); aplicate fiecareia dintre cele 21 de perechi ale capitolului
- Blocuri alese: mai ales 1 pentru sectoare, 8–10 pentru regulile multi-active şi combinate (dependenţă mai puternică)
- Bootstrap-ul anterior, nestudentizat, cu bloc fix de 6 luni nu este testul publicat şi nu mai este folosit

Este ceva mai bun decât $1/N$?

- Distribuțiile bootstrap ale diferenței studentizate de raport Sharpe față de $1/N$; roșu: statistica observată; linii întrerupte: valorile critice bootstrap

Interpretarea testelor

- ▣ Sectoare, GMV-LW minus $1/N$: $-0,02$, interval 95% $[-0,36; 0,33]$; p HAC = 0,93, p bootstrap = 0,94 (bloc 1)
- ▣ Multi-active, ERC minus $1/N$: $-0,03$, interval $[-0,15; 0,08]$; p HAC = 0,61, p bootstrap = 0,58 (bloc 10)
 - ▶ ERC și $1/N$ sunt atât de corelate încât intervalul este îngust, dar tot conține zero
- ▣ Sectoare: nicio regulă nu diferă de $1/N$ la 5%; cea mai apropiată este ERC, $+0,04$ (p HAC = 0,09, bootstrap 0,13)
- ▣ Multi-active: MV-LO $+0,29$ **nu** este semnificativ (p HAC = 0,12, bootstrap 0,16)

Diferențe semnificative: mai ales pierderi

Univers	Regula minus 1/N	$\hat{\Delta}$	p HAC	p bootstrap
Multi-active	MV	-0,74	0,01	0,06
Multi-active	HRP	-0,16	0,07	0,05
Combinat	GMV	-0,57	0,03	0,05
Combinat	GMV-LO	-0,40	0,05	0,08
Combinat	GMV-LW	-0,56	0,02	0,03
Combinat	MV-LO	+0,05	0,82	0,82

- Nicio regulă nu bate semnificativ 1/N în niciun univers
- Regulile GMV pierd semnificativ în universul combinat: risc mic, dar prea puțin randament
- 21 de teste: valorile p ajustate Holm sunt cel puțin 0,29 (HAC) și 0,68 (bootstrap): nimic nu rezistă (Capitolul 3, testarea multiplă)

Multe reguli, un câştigător: raportul Sharpe deflatat

- ▣ Bailey & López de Prado (2014): cel mai mare dintre N rapoarte Sharpe este deplasat în sus chiar dacă toate rapoartele adevărate sunt zero
- ▣ Maximul aşteptat sub H_0 : toate rapoartele adevărate zero, N încercări independente, unităţi lunare ca T ; cu $\gamma_E = 0,5772$ (constanta lui Euler) şi $\hat{V}$ varianţa celor N estimăţii

$$SR_0 = \sqrt{\hat{V}} \left[(1 - \gamma_E) \Phi^{-1} \left(1 - \frac{1}{N} \right) + \gamma_E \Phi^{-1} \left(1 - \frac{1}{Ne} \right) \right]$$

- ▣ Raportul Sharpe deflatat, cu asimetria $\hat{\gamma}_3$ şi applatizarea $\hat{\gamma}_4$ ale câştigătorului

$$DSR = \Phi \left(\frac{(\widehat{SR} - SR_0) \sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3 \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \widehat{SR}^2}} \right)$$

- ▣ În acest capitol: 24 de configuraţii ($8 \text{ reguli} \times 3 \text{ universuri}$); câştigător MV-LO pe 16 ETF-uri, 0,81 pe an
 - ▶ Ca 24 de încercări independente: $SR_0 = 0,52$ pe an, $DSR = 0,84 < 0,95$
 - ▶ Configuraţiile sunt puternic corelate (până la 0,99), deci mai puţine sunt independente: $N = 8$ dă DSR 0,93, $N = 3$ dă 0,98; verdictul depinde de N efectiv


Recapitulare: evaluarea în afara eșantionului

- ▣ Doar rezultatele în afara eșantionului, nete de costuri, sunt informative
- ▣ MV de selecție eșuează în toate universurile; restricțiile și shrinkage-ul îl îmblânzesc
- ▣ Regulile bazate pe risc și $1/N$ sunt greu de separat statistic
- ▣ Testăm diferențele de Sharpe cu erori HAC sau cu bootstrap-ul studentizat pe blocuri și numărăm testele
- ▣ Un singur raport Sharpe cere o eroare standard și o analizare care țină cont de autocorelație; un câștigător dintre multe reguli trebuie deflatat

Cadrul: un investitor român

- ▣ Opt blue chips listate din 2014: TLV, SNP, BRD, TGN, SNG, SNN, EL, TEL
- ▣ Randamente lunare în RON, octombrie 2014 – august 2026; fereastră de 36 de luni, primul portofoliu în octombrie 2017
- ▣ Reguli: 1/N, MV-LO, GMV-LO, GMV-LW, ERC, HRP; repere BET-TR și BET
- ▣ Rapoarte Sharpe cu $R_f = 0$ (nu avem o serie a pieței monetare în RON): randament pe unitatea de risc, mai mare decât Sharpe-ul randamentelor în exces
- ▣ Dovezi românești anterioare despre diversificare: Dragotă, Șerbănescu & Pele (2008)

Portofolii BVB versus BET-TR



□ În afara eșantionului, octombrie 2017 – august 2026 (107 luni), înainte de costuri

Interpretarea backtest-ului BVB

- ▣ BET-TR: medie 24,7% pe an, volatilitate 17,0%, Sharpe 1,45; BET: medie 17,8%, Sharpe 1,07
 - ▶ Diferența de circa 7% pe an o reprezintă dividendele: comparăm cu BET-TR, niciodată cu BET
- ▣ 1/N 1,41, ERC 1,38, HRP 1,31: aproape de BET-TR
- ▣ MV-LO 1,66 (diferență +0,21, $p = 0,44$); GMV-LW 0,83 ($-0,63$, $p = 0,05$)
- ▣ Corelația medie a celor opt acțiuni: 0,44; cel mai recent GMV-LO pune 70% în TLV

Dincolo de acțiuni: activele digitale

- ▣ [Petukhina, Trimborn, Härdle & Elendner \(2021\)](#): criptomonedele în regulile de alocare; câștigurile depind de regulă și de lichiditate
- ▣ [Pele et al. \(2023\)](#): devin criptomonedele active alternative?
- ▣ Bitcoin: volatilitate anualizată 172% (lunar, 2010–2026), IEF 6,6%
- ▣ Contribuțiile la risc cresc cu volatilitatea: regulile bazate pe risc dau automat o pondere mică lui Bitcoin
- ▣ Medie–varianță robustă pentru crypto-active: [Pele \(2023\)](#); Seminarul 4, B5

Recapitulare: portofolii BVB

- ▣ Alegerea reperului contează: BET omite circa 7% pe an din dividende
- ▣ Nicio regulă optimizată doar pe BVB nu bate semnificativ BET-TR
- ▣ Opt acțiuni cu corelația medie 0,44: puțin loc pentru diversificare în interiorul BVB
- ▣ Întrebare deschisă: merită diversificarea **dincolo** de BET? (Seminarul 4, Partea C)

Studiu de caz: ce frontieră poate atinge un investitor mare?

- Jensen, Kelly, Malamud & Pedersen (2026), *Review of Financial Studies*: cum devin prognozele de randament obținute prin ML portofolii, când fiecare tranzacție mișcă prețul?
- Regulile din acest capitol combat riscul de estimare; Ledoit & Wolf (2017) este lucrarea de referință pentru intrarea de risc $\hat{\Sigma}$, dar costurile apar cel mult ca rată fixă pe unitatea de rulaj
- Frontiera eficientă implementabilă (ec. 12): pentru fiecare volatilitate σ , cel mai mare randament așteptat **net de costurile de tranzacționare**
 - ▶ $k(\sigma) = \max_{\pi} E[r_{t+1}^{\text{net}}]$ cu restricția $E[\pi_t^T \Sigma \pi_t] = \sigma^2$
 - ▶ Propoziția 1: raportul Sharpe net $k(\sigma)/\sigma$ scade de-a lungul frontierei, iar un investitor mai mare are o frontieră mai joasă
- Practica obișnuită în doi pași: prognoza randamentelor prin ML, apoi optimizarea; prognozele se sprijină pe semnale de scurtă durată ale acțiunilor mici, al căror rulaj consumă randamentul
- Răspunsul lucrării generalizează regula de tranzacționare dinamică din Gârleanu & Pedersen (2013) și învață ponderile direct din semnale, cum fac Brandt, Santa-Clara & Valkanov (2009) fără costuri

Studiu de caz: date și metodă


- ▣ Costul de tranzacționare ca fracțiune din averea W_t (ec. 4, 7): $c_t = \frac{W_t}{2} (\pi_t - g_t \pi_{t-1})^\top \Lambda (\pi_t - g_t \pi_{t-1})$
 - π_t : ponderile; g_t : deriva ponderilor din luna trecută odată cu randamentele; $\Lambda = \text{diag}(0,2/V_i)$, V_i volumul zilnic mediu în dolari pe 6 luni; tranzacționarea a 1% din V_i mișcă prețul cu 0,1% (ec. 35, [Frazzini, Israel & Moskowitz \(2018\)](#))
- ▣ Regula optimă (Propoziția 3): $\pi_t = m g_t \pi_{t-1} + (1 - m) A_t$: tranzacționezi doar o parte din drumul spre un portofoliu-țintă A_t , o sumă ponderată a portofoliilor Markowitz de azi și a celor așteptate în viitor; m rezolvă ec. (14)
- ▣ Portfolio-ML (Propoziția 4, ec. 40): $A_t = \text{diag}(1/\sigma_{i,t}) f(s_t) \beta$, $f = p$ caracteristici Fourier aleatoare ale semnalelor s_t
 - $\hat{\beta} = (E_T[\tilde{\Sigma}_t] + \lambda I)^{-1} E_T[\tilde{r}_{t+1}]$: o regresie ridge care maximizează utilitatea netă de costuri, în formă închisă (ec. 24–26)
- ▣ Date (Secțiunea 5.1): acțiuni ordinare NYSE peste capitalizarea mediană (184–805 acțiuni), 115 caracteristici din [Jensen, Kelly & Pedersen \(2023\)](#) transformate în ranguri în $[0, 1]$; decembrie 1952 – decembrie 2020, în afara eșantionului 1981–2020, lunar
- ▣ Σ : 13 teme de caracteristici și 12 industrii ca factori, ponderi exponențiale cu timp de înjumătățire de 378 de zile (corelații) și 126 de zile (varianțe); investitorul: $\gamma = 10$, avere de 10 miliarde de dolari la finalul lui 2020, care crește odată cu piața
- ▣ Calibrare (Tabelul 1): $\lambda \in \{0, e^{-10}, e^{-9,8}, \dots, e^{10}\}$, $p \in \{2^6, \dots, 2^9\}$, $\eta \in \{e^{-3}, e^{-2}\}$ (abaterea standard a ponderilor aleatoare), alese anual după utilitatea backtest-urilor de validare din 1971
- ▣ Rivali: Markowitz-ML (ec. 32), Static-ML (cost pe o singură perioadă, ec. 34), Multiperiod-ML (prognoze pe 12 orizonturi, ec. 22), sortări pe factori, $1/N$, varianță minimă, piața; “*” marchează un strat suplimentar de calibrare (Secțiunea 5.3)

Studiu de caz: rezultatele principale

- Tabelul 2, Markowitz-ML: raportul Sharpe brut 2,06, dar rulaj lunar 79,36 și levier 74,61: randament net extrem de negativ
 - ▶ Frontiera din manuale există doar pe hârtie
- Tabelul 2, Portfolio-ML: raportul Sharpe net 1,33, utilitate 0,086 (randament net 15%, volatilitate 11%, cost 0,6% pe an, rulaj 0,25)
 - ▶ Utilitatea (ec. 11): randamentul net anualizat minus $\frac{\gamma}{2}$ ori varianța anualizată
- Tabelul 2, rivalii (raportul Sharpe net, utilitate): Static-ML* 0,81, 0,030; Multiperiod-ML* 0,83, 0,020; 1/N 0,54, -0,051; piața 0,51, -0,033
 - ▶ Doar regulile care țin cont de costuri au utilitate pozitivă; Portfolio-ML nu are nevoie de al doilea strat de calibrare
- Tabelul 3: probabilitatea a posteriori ca Portfolio-ML să aibă utilitatea mai mare: 99,9% față de Static-ML* și Multiperiod-ML*, 100% față de Markowitz-ML
- Figura 1(B) (Secțiunea 6.2), $\gamma = 10$, volatilitate 11%: randament net în exces de 14,6% cu 10 miliarde de dolari, 16,3% cu 1 miliard
 - ▶ Frontiera depinde de cine investește: dimensiunea este un cost
- Figura 5: net de costuri, calitatea este tema cea mai importantă, iar inversarea pe termen scurt aproape irelevantă; autocorelația lunară este -0,04 pentru inversarea pe o lună și 0,94 pentru raportul valoare contabilă/valoare de piață (Secțiunea 6.3)
 - ▶ Semnalele persistente sunt ieftin de tranzacționat

Studiu de caz: Tabelul 2 dintr-o privire

Out of sample 1981-2020, US stocks, wealth \$10 billion (Markowitz-ML off scale)




- Sursa: Jensen, Kelly, Malamud & Pedersen (2026), Tabelul 2; net de costurile de tranzacționare, în afara eșantionului 1981–2020, $\gamma = 10$
- Utilitatea și raportul Sharpe net ordonează diferit 1/N și piața: volatilitatea suplimentară a lui 1/N costă mai mult decât aduce raportul Sharpe mai mare

Studiu de caz: replicare, limite și o extensie deschisă

- ▣ Datele cursului: 14 acțiuni americane și 9 ETF-uri sectoriale (data/market); cinci semnale din prețuri și volume (randamente pe 1, 6 și 12 luni, volatilitatea pe un an, volumul în dolari pe 6 luni); aceeași regulă de cost, același γ , aceeași avere și aceeași grilă; Σ cu aceleași ponderi pe cele 23 de active; validare din 2011, în afara eșantionului februarie 2014 – august 2026 (151 de luni)
- ▣ Portfolio-ML: raportul Sharpe net 0,57, utilitate 0,016, cost 0,6% pe an, levier 0,32; 1/N: raportul Sharpe net 0,61, dar utilitate $-0,26$ (volatilitate netă 30%)
 - ▶ Static-ML $-0,13$; varianță minimă $-0,73$ (cost 43% pe an); Markowitz-ML extrem de negativ (levier 18)
 - ▶ Probabilitatea a posteriori ca Portfolio-ML să aibă utilitatea mai mare: 99,5% față de Static-ML, 99,9% față de varianța minimă, 93,3% față de 1/N
- ▣ Aceeași ordine a regulilor care țin cont de costuri față de cele care le ignoră ca în Tabelul 2; Portfolio-ML câștigă prin poziții mici, tranzacționate lent, nu printr-un raport Sharpe brut mai mare (0,68 față de 0,87 pentru 1/N)
- ▣ Limitele datelor cursului: 23 de active în loc de 184–805, cinci semnale în loc de 115, trei ani de validare în loc de zece, fără model factorial pentru Σ
- ▣ Limite declarate de autori: comisioane și alte fricțiuni reale, putere de calcul și metode ML indisponibile în timp real la începutul eșantionului (Secțiunea 6.1); costuri și risc tratate drept constante în timp (Secțiunea 5.1.3); în cele mai mici 20% dintre acțiuni, Portfolio-ML se clasează după Multiperiod-ML* și Static-ML* (Figura 8)
- ▣ Extensie deschisă: frontiere implementabile pe datele cursului pentru averi de 1, 10 și 100 de miliarde de dolari și $\gamma \in \{1, 5, 10, 20, 100\}$: unde se află 1/N față de ele? (Seminarul 4, C3)

Studiu de caz: brut și net de costuri pe datele cursului



- În afara eșantionului, februarie 2014 – august 2026 (151 de luni); marcaj gol: înainte de costuri; marcaj plin: după costurile din ec. (35)

Studiu de caz: cum citim replicarea

- ▣ Curba întreruptă: toate perechile volatilitate–randament cu utilitatea lui Portfolio-ML (0,016); curba punctată: utilitate 0
 - ▶ Orice punct aflat sub curba întreruptă este mai slab pentru un investitor cu $\gamma = 10$
- ▣ Portfolio-ML aproape nu se mișcă: 3,8% brut, 3,3% net pe an, la o volatilitate de 5,7%
- ▣ Varianța minimă coboară de la +6,6% brut la −36,1% net: reechilibrarea unui levier de 2,6 costă 43% pe an
- ▣ $1/N$ păstrează 18,1% net, dar, la o volatilitate de 29,8%, se află mult sub curba întreruptă
- ▣ Contează frontiera de după costuri (Jensen, Kelly, Malamud & Pedersen (2026), ec. 12)

O întrebare deschisă

- Bate vreo regulă de alocare **estimată** portofoliul $1/N$ în afara eșantionului, net de costuri, după ce numărăm toate regulile, ferestrele și universurile încercate?
- Dovezile recente merg în ambele direcții
 - ▶ Shrinkage-ul neliniar al lui Σ îmbunătățește GMV în afara eșantionului pe secțiuni transversale mari: [Ledoit & Wolf \(2017\)](#)
 - ▶ Combinarea portofoliului tangent, a GMV și a lui $1/N$ sub risc de estimare: [Kan, Wang & Zhou \(2022\)](#)
 - ▶ Performanțele din backtest-uri trebuie ajustate în funcție de numărul de specificații încercate: [Harvey & Liu \(2015\)](#)
- Formularea formală pentru K reguli pe un univers
 - ▶ H_0 : $\Delta_k = SR_k - SR_{1/N} \leq 0$ pentru orice k ; H_1 : $\Delta_k > 0$ pentru un k
 - ▶ Statistica: $\hat{\Delta}_k$ cu erori HAC sau bootstrap pe blocuri ([Ledoit & Wolf \(2008\)](#)); rata de eroare fixată pentru întreaga familie
- Infirmată de: un $\hat{\Delta}_k$ pozitiv care supraviețuiește unei corecții pe familie, costurilor și unui al doilea eșantion

Bucula descoperirii, pas cu pas (1/2)

- Instrumentele sunt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și motoare de căutare a literaturii științifice (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „Listează studiile evaluate colegial și publicate începând cu 2015 care compară regulile cu shrinkage sau bazate pe risc cu $1/N$ în afara eșantionului; pentru fiecare dă DOI, N , T , ipoteza de costuri și testul.”
 - Rezolvăm fiecare DOI pe Crossref și deschidem tabelul citat; asistenții amestecă autori și inventează DOI
- **Ipoteze:** „Dă trei explicații concurente pentru un câștig de Sharpe față de $1/N$ (o estimare mai bună a lui Σ , o primă asociată volatilității scăzute, noroc) și implicația testabilă a fiecăreia pentru rulaj, subperioade și expunerile factoriale.”
- **Date și cod:** „Scrie cod Python care citește data/market, unește prețurile pe zilele comune și rulează GMV-LW și $1/N$ pe ferestre mobile de 60 de luni; ponderile de la t folosesc doar date până la $t - 1$.”
 - Replicăm întâi: tabelul universului combinat din acest capitol ($1/N$ 0,76, GMV-LW 0,20), înainte de orice modificare

Bucula descoperirii, pas cu pas (2/2)

- **Robustețe:** „Redactează o pre-înregistrare: familia de teste ($\text{reguli} \times \text{universuri} \times \text{ferestre} \times \text{costuri}$), rata de eroare (FWER sau FDR), subperioadele și un test placebo, fixate înainte de a vedea vreun rezultat.”
 - ▶ Placebo: ponderi long-only aleatoare cu același rulaj; un efect real trebuie să le bată distribuția
- **Critica:** „Joacă rolul unui referent: dă cele mai puternice trei motive pentru care câștigul meu de Sharpe este fals și testul care l-ar expune pe fiecare.”
- **Raportul:** toate specificațiile încercate, valorile p ajustate, puterea statistică a studiului, codul și valorile de inițializare ale generatorului de numere pseudoaleatoare
- Fixăm planul înainte de prima rulare: orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare

Ce verifică cercetătorul

- ▣ **Informație din viitor:** ponderi la t construite cu randamentele lunii $t \Rightarrow$ verificăm că ultima dată de estimare este înainte de t ; decalarea ponderilor cu încă o lună este doar o analiză de sensibilitate
- ▣ **Supraviețuire și selecție:** o listă de ETF-uri aleasă azi $\Rightarrow$ folosim universul disponibil la fiecare dată, inclusiv ETF-urile delistate ulterior și randamentele lor finale; altfel declarăm limitarea
- ▣ **Testare multiplă:** 7 reguli $\times$ 3 universuri dau deja 21 de teste $\Rightarrow$ valori p ajustate Holm (FWER) sau Benjamini–Hochberg (FDR, [Benjamini & Hochberg \(1995\)](#))
- ▣ **Putere:** $\hat{\Delta}$ are o eroare standard de circa 0,18 pe 171 de luni $\Rightarrow$ calculăm efectul detectabil înainte de a rula
- ▣ **Tipul de randament:** portofoliile agregă randamente **simple**; raportul Sharpe folosește randamente **în exces** $\Rightarrow$ recalculăm o lună pas cu pas
- ▣ **Referințe inventate:** un DOI care nu se rezolvă sau un titlu diferit $\Rightarrow$ renunțăm la afirmație și o notăm în `AI_ERRORS.md`

Mini-studiu de caz: data snooping în backtest-ul acestui capitol

- O propunere tipică a unui asistent: „MV-LO bate $1/N$ pe universul multi-activ”; $H_0: \Delta \leq 0$, p unilateral = $1 - \Phi(\hat{\Delta}/\text{se})$
- Replicăm: $\hat{\Delta} = +0,29$, eroare standard HAC 0,18, p unilateral = 0,06 (HAC bilateral 0,12, bootstrap 0,16, Secțiunea 7)
- Testăm familia, nu câștigătorul: 21 de teste (7 reguli $\times 3$ universuri)
 - ▶ Doar 7 din 21 de diferențe sunt pozitive; cele 4 valori p HAC bilaterale sub 0,05 sunt toate **pierderi**, care nu resping niciodată o ipoteză nulă de superioritate
 - ▶ Unilateral: cel mai mic $p = 0,046$ (sectoare, ERC); ajustat Holm 0,96, Benjamini–Hochberg 0,62; 0 descoperiri la un FDR de 10%
- Putere 0,8 pentru $\Delta = 0,29$, unilateral: circa 435 de luni (36 de ani) la 5%, 944 de luni (79 de ani) la nivelul Holm 5%/21
- Interpretare: datele nu pot ordona aceste reguli; intervalul bootstrap pentru MV-LO, $[-0,13; 0,70]$, admite pierderi și câștiguri mari; nerespingerea nu dovedește egalitatea

Rândul vostru: un punct de plecare pentru proiectul de echipă

- Întrebarea: bate shrinkage-ul neliniar ([Ledoit & Wolf \(2017\)](#)) sau o combinație de trei fonduri ([Kan, Wang & Zhou \(2022\)](#)) portofoliul 1/N pe cele 16 ETF-uri ale capitolului, după costuri de 10–50 bp?
- Replicăm întâi: tabelul universului combinat (Sharpe 1/N 0,76, MV-LO 0,81) și valorile p ajustate din mini-studiul de caz
- Livrabile
 - ▶ O pre-înregistrare de o pagină: ipoteze, familia de teste, rata de eroare, puterea, testul placebo
 - ▶ Cod pe data/market, un tabel cu toate specificațiile, o autocritică în stilul unui referent
- Notăm fiecare prompt, instrument și rezultat acceptat în `AI_USE.md`; fiecare eroare prinsă (DOI inventat, informație din viitor, tip greșit de randament) și testul care a prins-o în `AI_ERRORS.md`
- Codul mini-studiului de caz: [Quantlets/Ch_04/ai_discovery_case.py](#)

Concluzii

- ▣ Markowitz pune întrebarea corectă, dar răspunsurile sunt fragile: eroarea de estimare domină
- ▣ MV de selecție are nevoie de decenii de date ca să bată $1/N$; în afara eșantionului eșuează în toate universurile
- ▣ Shrinkage-ul, restricțiile, Black–Litterman și regulile bazate pe risc stabilizează portofoliile
- ▣ Nicio regulă nu bate semnificativ $1/N$ aici; mai multe pierd după costuri
- ▣ Evaluăm în afara eșantionului, net de costuri, cu un test al diferenței de Sharpe

Legături cu alte capitole

- ▣ **Capitolul 3** (modele factoriale): portofoliul tangent și CAPM; modele factoriale ale covarianței
- ▣ **Capitolele 5–6**: volatilitate și corelație variabile în timp pentru ponderi dinamice
- ▣ **Capitolul 7**: Value-at-Risk și Expected Shortfall ale portofoliului
- ▣ **Capitolul 8**: backtesting fără supraajustare
- ▣ **Capitolul 13**: machine learning pentru randamente și portofolii

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

-  Hierarchical Clustering
-  Minimum Spanning Tree
-  Multivariate Statistical Analysis

Cod și date

- Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_04
- Rata fără risc: [Kenneth French Data Library](#)

Bibliografie (1/10)

- ▣ Andrews, D.W.K. (1991). [Heteroskedasticity and autocorrelation consistent covariance matrix estimation](#). *Econometrica*, 59(3), 817–858.
- ▣ Andrews, D.W.K., Monahan, J.C. (1992). [An improved heteroskedasticity and autocorrelation consistent covariance matrix estimator](#). *Econometrica*, 60(4), 953–966.
- ▣ Bailey, D.H., López de Prado, M. (2014). [The deflated Sharpe ratio: correcting for selection bias, backtest overfitting, and non-normality](#). *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Benjamini, Y., Hochberg, Y. (1995). [Controlling the false discovery rate: a practical and powerful approach to multiple testing](#). *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300.
- ▣ Best, M.J., Grauer, R.R. (1991). [On the sensitivity of mean-variance-efficient portfolios to changes in asset means: some analytical and computational results](#). *Review of Financial Studies*, 4(2), 315–342.
- ▣ Black, F., Litterman, R. (1992). [Global portfolio optimization](#). *Financial Analysts Journal*, 48(5), 28–43.

Bibliografie (2/10)

- ▣ Bodnar, T., Parolya, N., Schmid, W. (2018). Estimation of the global minimum variance portfolio in high dimensions. *European Journal of Operational Research*, 266(1), 371–390.
- ▣ Brandt, M.W., Santa-Clara, P., Valkanov, R. (2009). Parametric portfolio policies: exploiting characteristics in the cross-section of equity returns. *Review of Financial Studies*, 22(9), 3411–3447.
- ▣ Britten-Jones, M. (1999). The sampling error in estimates of mean-variance efficient portfolio weights. *Journal of Finance*, 54(2), 655–671.
- ▣ Chopra, V.K., Ziemba, W.T. (1993). The effect of errors in means, variances, and covariances on optimal portfolio choice. *Journal of Portfolio Management*, 19(2), 6–11.
- ▣ Choueifaty, Y., Coignard, Y. (2008). Toward maximum diversification. *Journal of Portfolio Management*, 35(1), 40–51.
- ▣ DeMiguel, V., Garlappi, L., Nogales, F.J., Uppal, R. (2009). A generalized approach to portfolio optimization: improving performance by constraining portfolio norms. *Management Science*, 55(5), 798–812.

Bibliografie (3/10)

- ▣ DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy?. *Review of Financial Studies*, 22(5), 1915–1953.
- ▣ Dragotă, M., Șerbănescu, C.I., Pele, D.T. (2008). Portfolio diversification and market share analysis for Romanian insurance companies. În *Risk Management and Value*, World Scientific, 277–298.
- ▣ Fan, J., Liao, Y., Mincheva, M. (2013). Large covariance estimation by thresholding principal orthogonal complements. *Journal of the Royal Statistical Society: Series B*, 75(4), 603–680.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, ed. a 5-a. Springer.
- ▣ Frazzini, A., Israel, R., Moskowitz, T.J. (2018). *Trading costs*. SSRN Working Paper 3229719.
- ▣ Frost, P.A., Savarino, J.E. (1988). For better performance: constrain portfolio weights. *Journal of Portfolio Management*, 15(1), 29–34.

Bibliografie (4/10)

- ▣ Gârleanu, N., Pedersen, L.H. (2013). *Dynamic trading with predictable returns and transaction costs*. *Journal of Finance*, 68(6), 2309–2340.
- ▣ Härdle, W.K., Simar, L. (2019). *Applied Multivariate Statistical Analysis*, ed. a 5-a. Springer.
- ▣ Harvey, C.R., Liu, Y. (2015). *Backtesting*. *Journal of Portfolio Management*, 42(1), 13–28.
- ▣ He, G., Litterman, R. (2002). *The intuition behind Black-Litterman model portfolios*. SSRN Working Paper 334304.
- ▣ Jagannathan, R., Ma, T. (2003). *Risk reduction in large portfolios: why imposing the wrong constraints helps*. *Journal of Finance*, 58(4), 1651–1683.
- ▣ Jensen, T.I., Kelly, B., Malamud, S., Pedersen, L.H. (2026). *Machine learning and the implementable efficient frontier*. *Review of Financial Studies*, 39(10), 3035–3078.

Bibliografie (5/10)

- ▣ Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). *Is there a replication crisis in finance?*. *Journal of Finance*, 78(5), 2465–2518.
- ▣ Jobson, J.D., Korkie, B.M. (1981). *Performance hypothesis testing with the Sharpe and Treynor measures*. *Journal of Finance*, 36(4), 889–908.
- ▣ Jorion, P. (1986). *Bayes-Stein estimation for portfolio analysis*. *Journal of Financial and Quantitative Analysis*, 21(3), 279–292.
- ▣ Kan, R., Wang, X., Zhou, G. (2022). *Optimal portfolio choice with estimation risk: no risk-free asset case*. *Management Science*, 68(3), 2047–2068.
- ▣ Kan, R., Zhou, G. (2007). *Optimal portfolio choice with parameter uncertainty*. *Journal of Financial and Quantitative Analysis*, 42(3), 621–656.
- ▣ Künsch, H.R. (1989). *The jackknife and the bootstrap for general stationary observations*. *Annals of Statistics*, 17(3), 1217–1241.

Bibliografie (6/10)

- ▣ Laloux, L., Cizeau, P., Bouchaud, J.-P., Potters, M. (1999). Noise dressing of financial correlation matrices. *Physical Review Letters*, 83(7), 1467–1470.
- ▣ Ledoit, O., Wolf, M. (2003). Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10(5), 603–621.
- ▣ Ledoit, O., Wolf, M. (2004a). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- ▣ Ledoit, O., Wolf, M. (2004b). Honey, I shrunk the sample covariance matrix. *Journal of Portfolio Management*, 30(4), 110–119.
- ▣ Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- ▣ Ledoit, O., Wolf, M. (2017). Nonlinear shrinkage of the covariance matrix for portfolio selection: Markowitz meets Goldilocks. *Review of Financial Studies*, 30(12), 4349–4388.

Bibliografie (7/10)

- ▣ Ledoit, O., Wolf, M. (2020). Analytical nonlinear shrinkage of large-dimensional covariance matrices. *Annals of Statistics*, 48(5), 3043–3065.
- ▣ Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.
- ▣ López de Prado, M. (2016). Building diversified portfolios that outperform out of sample. *Journal of Portfolio Management*, 42(4), 59–69.
- ▣ Maillard, S., Roncalli, T., Teïletche, J. (2010). The properties of equally weighted risk contribution portfolios. *Journal of Portfolio Management*, 36(4), 60–70.
- ▣ Mantegna, R.N. (1999). Hierarchical structure in financial markets. *European Physical Journal B*, 11(1), 193–197.
- ▣ Marčenko, V.A., Pastur, L.A. (1967). Distribution of eigenvalues for some sets of random matrices. *Mathematics of the USSR-Sbornik*, 1(4), 457–483.

Bibliografie (8/10)

- ▣ Markowitz, H. (1952). *Portfolio selection*. *Journal of Finance*, 7(1), 77–91.
- ▣ Merton, R.C. (1972). *An analytic derivation of the efficient portfolio frontier*. *Journal of Financial and Quantitative Analysis*, 7(4), 1851–1872.
- ▣ Merton, R.C. (1980). *On estimating the expected return on the market: an exploratory investigation*. *Journal of Financial Economics*, 8(4), 323–361.
- ▣ Michaud, R.O. (1989). *The Markowitz optimization enigma: is 'optimized' optimal?*. *Financial Analysts Journal*, 45(1), 31–42.
- ▣ Okhrin, Y., Schmid, W. (2006). *Distributional properties of portfolio weights*. *Journal of Econometrics*, 134(1), 235–256.
- ▣ Pele, D.T. (2023). *Robust Markowitz for crypto-assets*. Curs Quantinar, Academia de Studii Economice din București.

Bibliografie (9/10)

- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). *Are cryptos becoming alternative assets?*. *The European Journal of Finance*, 29(10), 1064–1105.
- ▣ Petukhina, A., Trimborn, S., Härdle, W.K., Elendner, H. (2021). *Investing with cryptocurrencies – evaluating their potential for portfolio allocation strategies*. *Quantitative Finance*, 21(11), 1825–1853.
- ▣ Politis, D.N., Romano, J.P. (1994). *The stationary bootstrap*. *Journal of the American Statistical Association*, 89(428), 1303–1313.
- ▣ Sharpe, W.F. (1966). *Mutual fund performance*. *Journal of Business*, 39(S1), 119–138.
- ▣ Theil, H., Goldberger, A.S. (1961). *On pure and mixed statistical estimation in economics*. *International Economic Review*, 2(1), 65–78.
- ▣ Tobin, J. (1958). *Liquidity preference as behavior towards risk*. *Review of Economic Studies*, 25(2), 65–86.

Bibliografie (10/10)

- Tu, J., Zhou, G. (2011). Markowitz meets Talmud: a combination of sophisticated and naive diversification strategies. *Journal of Financial Economics*, 99(1), 204–215.
- Date: Kenneth R. French Data Library, mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html.