



Modelarea piețelor financiare

Capitolul 5: Volatilitate condiționată — modele GARCH



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ACF: AutoCorrelation Function (funcția de autocorelație)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ ARIMA: AutoRegressive Integrated Moving Average (model) (model autoregresiv integrat cu medie mobilă)
- ▣ ARMA: AutoRegressive Moving Average (model) (model autoregresiv cu medie mobilă)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- ▣ BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- ▣ BNR: Banca Națională a României
- ▣ COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- ▣ DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ EGARCH: Exponential GARCH (GARCH exponențial)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ FIGARCH: Fractionally Integrated GARCH (GARCH integrat fracționar)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GARCH-M: GARCH-in-Mean (GARCH cu volatilitatea în ecuația mediei)
- ▣ GARCH-MIDAS: GARCH with Mixed Data Sampling (long-run component) (GARCH cu eșantionare mixtă a datelor (componentă de termen lung))
- ▣ GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- ▣ GAS: Generalised Autoregressive Score (model) (model cu scor autoregresiv generalizat)
- ▣ GED: Generalised Error Distribution (distribuția generalizată a erorilor)
- ▣ GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- ▣ GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- ▣ GW: Giacomini–White (test) (testul Giacomini–White)

Acronime folosite în acest material (2/2)

- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- IGARCH: Integrated GARCH (GARCH integrat)
- LM: Lagrange Multiplier (multiplicatorul Lagrange)
- LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- MLE: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- MSE: Mean Squared Error (eroarea pătratică medie)
- MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- PIT: Probability Integral Transform (transformarea integrală de probabilitate)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)
- QQ: Quantile–Quantile (plot) (graficul cuantilă–cuantilă)
- QSD: Quasi Score-Driven (model) (model bazat pe un cvasi-scor)
- VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)
- XAU: gold, ISO 4217 code (one troy ounce) (aur, codul ISO 4217 (o uncie troy))

Structura capitolului și rezultatele învățării

Trei întrebări

- Cum evoluează dispersia? ARCH, GARCH, persistență, prognoze (partea I)
- Cum se estimează și se verifică modelele? Verosimilitate, inferență QMLE, teste la frontieră, asimetrie, diagnostic (partea I)
- Îmbunătățesc modelele prognozele? Pierderi în afara eșantionului, teste pentru mai multe modele, limite și extensii, un studiu de caz (partea a II-a)
- Detaliile tehnice sînt în [▶ Anexa](#) de la final

La sfîrșitul capitolului veți putea

- estima GARCH, GJR și EGARCH cu inovații cu cozi groase și interpreta fiecare parametru
- cuantifica corect incertitudinea persistenței și a timpului de înjumătățire și testa ipoteze aflate la frontiera spațiului parametrilor
- diagnostica reziduurile standardizate și compara prognozele dispersiei cu pierderi robuste la aproximarea volatilității

Episoade de volatilitate ridicată




Bursa din Amsterdam, 21 octombrie 1987, după crahul din 19 octombrie

Foto: Bart Molendijk / Anefo (1987); CC0; Wikimedia Commons


- Crahurile nu se limitează la zile izolate: variațiile mari sînt urmate de variații mari
 - ▶ „Schimbările mari tind să fie urmate de schimbări mari, de orice semn” [Mandelbrot \(1963\)](#)
- Acest **volatility clustering** este faptul stilizat 6 din [Capitolul 1](#)
- Volatilitatea intervine în calculul Value at Risk ([Capitolul 7](#)), al ponderilor portofoliului ([Capitolul 4](#)) și al prețurilor opțiunilor
- Întrebări
 - ▶ putem folosi volatility clustering pentru a **prognoza** riscul de mîine?
 - ▶ putem evalua corect incertitudinea prognozei?

Volatility clustering pe orice piață



- Log-randamente zilnice
 $r_t = 100 (\ln P_t - \ln P_{t-1})$ în %, închideri pînă la 18 septembrie 2026; S&P 500 și BET din 2000, Bitcoin din 17 septembrie 2014
 - P_t : prețul (nivelul indicelui) la închiderea zilei t ; r_t : variația procentuală de la închiderea $t - 1$ la închiderea t
- Indici bursieri: zilele lucrătoare; zilele cu închiderea egală cu cea precedentă (șărbători completate cu ultimul preț) se elimină: 3 la S&P 500, 0 la BET; Bitcoin: toate cele 7 zile ale săptămînii
- În toate cele trei serii, perioadele calme alternează cu luni de volatilitate ridicată: 2008, martie 2020, aprilie 2025

Semnul este imprevizibil, mărimea nu



- Autocorelația de selecție la decalajul k :
 $\hat{\rho}_k = \widehat{\text{Corr}}(x_t, x_{t-k})$, calculată pentru $x_t = r_t$
 și $x_t = r_t^2$
 - ▶ Banda $\pm 1,96/\sqrt{n}$ (n : numărul de randamente): intervalul de 95% al lui $\hat{\rho}_k$ dacă seria ar fi i.i.d.
- S&P 500, decalajul 1: -0,099 pentru r_t , 0,313 pentru r_t^2 ; toate cele 50 de autocorelații ale lui r_t^2 pînă la decalajul 50 depășesc banda $\pm 0,024$
- Cozi groase: exces de kurtosis (kurtosis minus 3) 10,7 (S&P 500), 11,1 (BET), 12,0 (Bitcoin); 0 pentru distribuția Normală
- Mărimea modelată: $\sigma_t^2 = \text{Var}(r_t | \mathcal{F}_{t-1})$, cu $\mathcal{F}_{t-1}$ informația de la închiderea zilei $t-1$

 MFM_ch5_arch_effects

Testarea efectelor ARCH (1/2): cele două teste

- H_0 : fără volatility clustering, $\text{Var}(r_t | \mathcal{F}_{t-1})$ constantă; ambele teste caută autocorelație în pătratele randamentelor
- **McLeod–Li** [McLeod & Li \(1983\)](#): statistica Ljung–Box aplicată lui r_t^2
 - ▶ $Q(m) = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n-k}$
 - ▶ $\hat{\rho}_k$: autocorelația lui r_t^2 la decalajul k ; n : volumul eșantionului; $m = 10$ decalaje
 - ▶ Măsoară mărimea comună a primelor m autocorelații; $Q \geq 0$, χ_{10}^2 sub H_0 ; respingem dacă $Q(10) > 18,3$ (5%)
- **Testul LM al lui Engle** [Engle \(1982\)](#): regresăm $\hat{\varepsilon}_t^2$ pe o constantă și pe $\hat{\varepsilon}_{t-1}^2, \dots, \hat{\varepsilon}_{t-5}^2$
 - ▶ $\hat{\varepsilon}_t = r_t - \bar{r}$: randamentul centrat, $\bar{r}$: media de selecție
 - ▶ $LM = nR^2$, cu R^2 coeficientul de determinare al acestei regresii; H_0 : toate cele cinci pante sînt 0
 - ▶ χ_5^2 sub H_0 ; respingem dacă $LM > 11,1$ (5%); un LM mare înseamnă că pătratele șocurilor trecute le prezic pe cele de azi

Testarea efectelor ARCH (2/2): rezultate

- ▣ $\hat{\rho}_1(r^2)$: autocorelația de ordinul 1 a pătratelor randamentelor
- ▣ Toate statisticile sînt mult peste valorile critice (toate $p < 0,001$): volatility clustering la acțiuni, cripto, un curs de schimb în regim de managed float și aur; efectul cel mai slab apare la Bitcoin și aur
- ▣ Testele scorului unilaterale și tabelul complet: [▶ Anexă](#)

Serie	$Q(10)$ pe r^2	LM(5)	$\hat{\rho}_1(r^2)$
S&P 500	6133	1684	0,313
BET	2440	982	0,330
BET-TR	714	371	0,171
Bitcoin	213	115	0,137
EUR/RON	2420	871	0,342
Aur	744	329	0,110

 MFM_ch5_arch_effects

Modelul ARCH al lui Engle (1982)

- ▣ Cadrul: $r_t = \mu + \varepsilon_t$, $\varepsilon_t = \sigma_t z_t$, inovațiile z_t i.i.d. cu media 0 și dispersia 1
 - ▶ μ : randamentul mediu; ε_t : șocul (partea neașteptată a randamentului); σ_t : volatilitatea condiționată
 - ▶ Dispersia condiționată $\sigma_t^2 = \text{Var}(r_t | \mathcal{F}_{t-1})$; dispersia necondiționată $\sigma^2 = \mathbb{E}\sigma_t^2$
- ▣ **ARCH(q)**: dispersia de azi este o constantă plus o sumă ponderată a pătratelor ultimelor q șocuri [Engle \(1982\)](#)
 - ▶ $\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2$
 - ▶ q : numărul de decalaje; ω : nivelul minim al dispersiei; α_i : ponderea șocului de acum i zile
 - ▶ $\omega > 0$, $\alpha_i \geq 0$: dispersia este mereu pozitivă
- ▣ Un șoc mare ieri (ε_{t-1}^2 mare) crește dispersia de azi: volatility clustering rezultă direct din specificația modelului
- ▣ ARCH(1): dispersia necondiționată $\sigma^2 = \omega / (1 - \alpha_1)$, finită dacă $\alpha_1 < 1$; momentul său de ordin patru este cazul $\beta = 0$ al rezultatului GARCH de mai jos
- ▣ Engle a primit Premiul Nobel în 2003 pentru ARCH (istoric: [▶ Anexă](#))

De la ARCH la GARCH (Bollerslev, 1986)

- ▣ Problema ARCH: episoadele de volatility clustering din datele reale durează luni, deci q trebuie să fie mare (mulți parametri)
- ▣ **GARCH(1,1)** Bollerslev (1986): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$
 - ▶ Dispersia de azi = constantă + reacția la pătratul șocului de ieri + o parte din dispersia de ieri
 - ▶ $\omega > 0$, $\alpha \geq 0$, $\beta \geq 0$; α : reacția la știri; β : memoria dispersiei trecute
- ▣ Prin substituții succesive în recursie: $\sigma_t^2 = \frac{\omega}{1-\beta} + \alpha \sum_{j \geq 1} \beta^{j-1} \varepsilon_{t-j}^2$
 - ▶ Valabil pentru $\beta < 1$; j : vechimea șocului în zile, cu ponderea $\alpha \beta^{j-1}$
 - ▶ Un ARCH(∞) cu ponderi descrescătoare geometric, cu doar trei parametri
- ▣ GARCH(p, q) adaugă decalaje (p decalaje ale lui σ^2 , q ale lui ε^2); în practică GARCH(1,1) este modelul de bază Hansen & Lunde (2005)

GARCH(1,1) ca model ARMA pentru pătratele șocurilor

- ▣ Definim $\nu_t = \varepsilon_t^2 - \sigma_t^2$, surpriza din pătratul șocului ($\mathbb{E}[\nu_t | \mathcal{F}_{t-1}] = 0$)
- ▣ Atunci $\varepsilon_t^2 = \omega + (\alpha + \beta) \varepsilon_{t-1}^2 + \nu_t - \beta \nu_{t-1}$
 - ▶ Se obține adunînd ν_t în ambii membri ai recursiei GARCH și scriind $\sigma_{t-1}^2 = \varepsilon_{t-1}^2 - \nu_{t-1}$
 - ▶ Un ARMA(1,1) în ε_t^2 cu coeficientul autoregresiv $\alpha + \beta$ și coeficientul de medie mobilă $-\beta$
- ▣ Consecință: autocorelațiile lui ε_t^2 scad geometric, $\rho_k = \rho_1(\alpha + \beta)^{k-1}$
 - ▶ $\rho_k = \text{Corr}(\varepsilon_t^2, \varepsilon_{t-k}^2)$: autocorelația pătratelor șocurilor la decalajul k
 - ▶ $\rho_1 = \alpha(1 - \beta^2 - \alpha\beta)/(1 - \beta^2 - 2\alpha\beta)$ dacă $\mathbb{E}\varepsilon_t^4 < \infty$ (Seminarul 5, A6)
 - ▶ S&P 500, GARCH(1,1) cu inovații Normale: $\rho_1 = 0,356$, $\rho_{10} = 0,298$; în eșantion 0,313 și 0,248
- ▣ De aceea $\alpha + \beta$ se numește **persistența** volatilității

Staționaritatea și dispersia necondiționată

- ▣ **Staționaritate în covarianță:** $\alpha + \beta < 1$; atunci

- ▶ $\sigma^2 = \mathbb{E}[\sigma_t^2] = \frac{\omega}{1 - \alpha - \beta}$

- ▣ Derivare: luăm valoarea așteptată în recursie, $\mathbb{E}\sigma_t^2 = \omega + (\alpha + \beta)\mathbb{E}\sigma_{t-1}^2$, și impunem $\mathbb{E}\sigma_t^2 = \mathbb{E}\sigma_{t-1}^2$

- ▣ **IGARCH** (GARCH integrat): $\alpha + \beta = 1$; dispersia necondiționată este infinită


- ▶ Totuși, dacă $\alpha > 0$ și z_t^2 este nedegenerat, procesul rămîne **strict** staționar: condiția $\mathbb{E}\ln(\alpha z_t^2 + \beta) < 0$ **Nelson (1990)** este îndeplinită din inegalitatea lui Jensen, deoarece $\mathbb{E}\ln(\alpha z_t^2 + \beta) < \ln(\alpha + \beta) = 0$

- ▣ Variance targeting: se fixează $\omega = \hat{\sigma}^2(1 - \alpha - \beta)$ cu dispersia de selecție $\hat{\sigma}^2$

Momentul de ordin patru și kurtosis-ul

- Cu z_t Normal, kurtosis-ul lui ε_t este $K = \frac{3[1 - (\alpha + \beta)^2]}{1 - (\alpha + \beta)^2 - 2\alpha^2}$
 - ▶ $K = \mathbb{E}\varepsilon_t^4 / (\mathbb{E}\varepsilon_t^2)^2$: 3 pentru distribuția Normală, peste 3 pentru cozi groase
 - ▶ Finită doar dacă $(\alpha + \beta)^2 + 2\alpha^2 < 1$ (Seminarul 1, Exercițiul A9)
 - ▶ ARCH(1) este cazul $\beta = 0$: $K = 3(1 - \alpha^2)/(1 - 3\alpha^2)$, finită doar dacă $\alpha < 1/\sqrt{3}$: cozi groase chiar cu inovații Normale
- S&P 500, GARCH(1,1) cu inovații Normale: $\hat{\alpha} = 0,120604$, $\hat{\beta} = 0,859878$
 - ▶ $(\hat{\alpha} + \hat{\beta})^2 + 2\hat{\alpha}^2 = 0,990435$: puțin sub 1, deci $K = 12,1$; kurtosis-ul de selecție al randamentelor: 13,7
- K este foarte sensibil la erori în apropierea frontierei momentelor: se calculează din estimări nerotunjite (un exemplu de rotunjire: [▶ Anexă](#); Seminarul 5, A4)
- Volatility clustering explică singur o mare parte din cozile groase; restul provine din z_t cu cozi groase

Simulare: GARCH produce volatility clustering



- Sus: randamente Normale i.i.d.; jos: GARCH(1,1) cu $\omega = 0,02$, $\alpha = 0,10$, $\beta = 0,88$, aceeași dispersie necondiționată (1) și benzile $\pm 2\sigma_t$
- Perioadele calme și episoadele de volatilitate ridicată apar doar în traiectoria GARCH
- Inovații Normale, dar randamente cu cozi groase: un amestec de distribuții Normale cu dispersii diferite are cozi groase (kurtosis-ul pe o traiectorie lungă: [▶ Anexă](#))

Persistența și timpul de înjumătățire

- ▣ Prognoza pe mai mulți pași: $\mathbb{E}[\sigma_{t+h}^2 | \mathcal{F}_t] = \sigma^2 + (\alpha + \beta)^{h-1}(\sigma_{t+1}^2 - \sigma^2)$
 - ▶ h : orizontul prognozei, în zile; σ^2 : dispersia necondiționată (de termen lung); σ_{t+1}^2 : dispersia pentru ziua următoare, cunoscută la t
 - ▶ Distanța față de dispersia de termen lung scade cu factorul $\alpha + \beta$ în fiecare zi
- ▣ **Timpul de înjumătățire**: numărul de zile după care jumătate dintr-un șoc de dispersie a dispărut
 - ▶ $(\alpha + \beta)^h = 0,5 \Rightarrow h_{1/2} = \frac{\ln 0,5}{\ln(\alpha + \beta)}$
 - ▶ $h_{1/2}$ crește nelimitat când $\alpha + \beta \rightarrow 1$
- ▣ Exemple: $\alpha + \beta = 0,95$: 13,5 zile; 0,99: 69 de zile; 0,995: 138 de zile
- ▣ Schimbări mici ale lui $\alpha + \beta$ lângă 1 dau timpi de înjumătățire foarte diferiți: incertitudinea estimării contează (secțiunea următoare; Seminarul 5, A3 și B7)

EWMA și IGARCH: fără revenire la medie

- ▣ **EWMA J.P. Morgan/Reuters (1996):** $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, cu $\lambda = 0,94$ pentru date zilnice și randamente de medie zero
 - ▶ $\lambda \in (0, 1)$: factorul de descreștere; un λ mai mare înseamnă o memorie mai lungă
 - ▶ Ponderi $(1 - \lambda)\lambda^{j-1}$ pe pătratele randamentelor trecute: zilele recente contează cel mai mult
 - ▶ EWMA este un IGARCH(1,1) cu $\omega = 0$, $\alpha = 1 - \lambda$, $\beta = \lambda$: niciun parametru de estimat
- ▣ Prognozele pe mai mulți pași, la închiderea zilei t , diferă
 - ▶ $\mathbb{E}_t[\cdot] = \mathbb{E}[\cdot \mid \mathcal{F}_t]$: valoarea așteptată condiționată de informația de la t
 - ▶ EWMA: constantă, $\mathbb{E}_t \sigma_{t+h}^2 = \sigma_{t+1}^2$ pentru orice h
 - ▶ IGARCH cu $\omega > 0$: crescătoare, $\mathbb{E}_t \sigma_{t+h}^2 = \sigma_{t+1}^2 + (h - 1)\omega$
 - ▶ GARCH staționar: converge spre σ^2 cu rata $\alpha + \beta$
- ▣ EWMA servește drept reper în comparația prognozelor

Verosimilitatea maximă

- Parametrii $\theta = (\mu, \omega, \alpha, \beta)$; dat fiind θ , recursia produce $\sigma_1^2(\theta), \dots, \sigma_n^2(\theta)$
- Log-verosimilitatea Normală: $\ell(\theta) = -\frac{1}{2} \sum_{t=1}^n [\ln 2\pi + \ln \sigma_t^2 + \varepsilon_t^2 / \sigma_t^2]$
 - ▶ $\ell(\theta)$: logaritmul densității comune a celor n randamente observate, privit ca funcție de θ ; $\hat{\theta}$ îl maximizează; $\varepsilon_t = r_t - \mu$
 - ▶ Fiecare zi contribuie cu densitatea lui ε_t condiționată de trecut: verosimilitatea se factorizează în timp
- Fără formulă explicită: optimizare numerică sub restricțiile $\omega > 0, \alpha, \beta \geq 0, \alpha + \beta < 1$
- Inițializarea: σ_1^2 se fixează la dispersia de selecție (efectul său dispăre cu rata β)
- Scalarea: randamente în %, astfel încât dispersia să fie de ordinul 1
 - ▶ EUR/RON (abatere standard zilnică de circa 0,28%) se estimează pe 10 r_t : nescalat, optimizatorul s-a oprit într-un optim local

QMLE Gaussian (1/2): definiția și consistența

- **QMLE Gaussian** (cvasi-verosimilitate maximă): maximizăm verosimilitatea Normală chiar dacă z_t nu este Normal [Bollerslev & Wooldridge \(1992\)](#)
 - ▶ $\ell(\theta)$ Normală este folosită drept criteriu, nu ca ipoteză despre legea lui z_t
 - ▶ θ_0 : valoarea adevărată a parametrilor; $\hat{\theta}$: estimarea, punctul de maxim al lui ℓ
- **Consistența** (GARCH(1,1)): $\hat{\theta} \rightarrow \theta_0$ când $n \rightarrow \infty$ [Berkes, Horváth & Kokoszka \(2003\)](#), [Francq & Zakoïan \(2004\)](#)
 - ▶ Staționaritate strictă: $\mathbb{E} \ln(\alpha z_t^2 + \beta) < 0$
 - ▶ θ_0 într-o mulțime compactă (închisă și mărginită) de parametri; z_t^2 nedegenerat (nu este o constantă)
 - ▶ Nicio condiție de moment asupra lui ε_t : consistența are loc și pentru IGARCH

QMLE Gaussian (2/2): normalitatea asimptotică și erorile standard

- **Normalitatea asimptotică** a lui $\vartheta = (\omega, \alpha, \beta)$ (GARCH pur, media cunoscută): adăugăm ϑ_0 interior și $\kappa_z = \mathbb{E}z_t^4 < \infty$
 - ▶ $\sqrt{n}(\hat{\vartheta} - \vartheta_0) \rightarrow N(0, (\kappa_z - 1)J^{-1})$, $J = \mathbb{E}[g_t g_t']$, $g_t = \partial \ln \sigma_t^2 / \partial \vartheta$
 - ▶ În cuvinte: eroarea de estimare scade ca $1/\sqrt{n}$ și este aproximativ Normală
 - ▶ κ_z : kurtosis-ul lui z_t (3 dacă este Normal); g_t : gradientul lui $\ln \sigma_t^2$; J : media produsului său exterior; interior: nicio restricție activă
- Estimatorul sandwich $\hat{A}^{-1} \hat{B} \hat{A}^{-1}$ estimează $(\kappa_z - 1)J^{-1}$; inversa hessianei $\hat{A}^{-1}$ estimează $2J^{-1}$
 - ▶ A : minus hessiana medie (derivatele de ordinul doi) a lui ℓ/n ; B : dispersia scorului (derivatele de ordinul întâi) pe observație
 - ▶ E.s. robustă / clasică = $\sqrt{(\kappa_z - 1)/2}$: 1 sub normalitate, peste 1 cu cozi groase
- Variante (medie estimată, IGARCH, cazul exploziv): ▶ Anexă

QMLE: validitatea inferenței în aplicații

- S&P 500, GARCH(1,1) cu verosimilitate Normală: kurtosis-ul reziduurilor $\hat{\kappa}_z = 4,73$
 - ▶ Teoria: e.s. robustă / clasică = $\sqrt{(4,73 - 1)/2} = 1,37$; observat: 1,37 pentru $\hat{\alpha}$, 1,37 pentru $\hat{\beta}$
- Bitcoin: GARCH-t (sufixul -t: inovații Student-t) dă $\hat{\nu} = 3,18 < 4$ (ν : gradele de libertate, slide-ul următor): sub această lege $\mathbb{E}z_t^4 = \infty$, iar condiția pentru normalitatea asimptotică a QMLE Gaussian nu este îndeplinită
 - ▶ Kurtosis-ul reziduurilor nu se stabilizează: 19,8 pe prima jumătate, 14,6 pe tot eșantionul; rapoartele e.s. 2,51 și 2,01
- Hall & Yao (2003): atunci QMLE Gaussian converge mai lent decât $\sqrt{n}$, spre o distribuție-limită care nu este Normală: statisticile t robuste ale QMLE Gaussian nu sînt valide
- Remedii: o cvasi-verosimilitate cu cozi groase, cu ajustarea scalei Fan, Qi & Xiu (2014), sau MLE Student-t (scor mărginit: nu cere momentul de ordin patru dacă legea este corectă), cu inferență bootstrap lîngă frontiere

Inovații cu cozi groase


- **Student-t Bollerslev (1987):** $z_t = \sqrt{(\nu - 2)/\nu} t_\nu$, dispersie unitară pentru $\nu > 2$
 - ▶ t_ν : o variabilă Student-t standard, cu dispersia $\nu/(\nu - 2)$; factorul o rescalează la dispersia 1
 - ▶ ν (grade de libertate): cu cât ν este mai mic, cu atât cozile sînt mai groase; momentul de ordin patru există doar pentru $\nu > 4$
- **t asimetric Hansen (1994):** adaugă un parametru de asimetrie $\lambda \in (-1, 1)$
 - ▶ $\lambda < 0$: coada stîngă este mai lungă (pierderile mari mai probabile decît câștigurile mari)
- **GED Nelson (1991):** densitate $\propto \exp(-\frac{1}{2}|z/\lambda_\nu|^\nu)$
 - ▶ GED: distribuția generalizată a erorilor; $\nu > 0$: parametrul de formă; λ_ν : constanta de scală
 - ▶ $\nu = 2$: distribuția Normală; $\nu = 1$: Laplace; $\nu < 2$: cozi mai groase (λ_ν asigură dispersia unitară)

S&P 500: estimările GARCH(1,1)-t

Parametru	Estimare	E.s. robustă	E.s. clasică	Raport
ω	0,0157			
α	0,123	0,011	0,010	1,06
β	0,872	0,010	0,010	1,08
ν	6,26	0,48		
$\alpha + \beta$	0,9947			

- Randamente zilnice în %, 2000–2026; media $\hat{\mu} = 0,079\%$ pe zi; tabelul complet, cu toate erorile standard: Seminarul 5, B1
- $\hat{\beta}$: dispersia de azi este determinată în cea mai mare parte de dispersia de ieri; $\hat{\alpha}$: știrile au un efect moderat asupra dispersiei; $\hat{\nu} = 6,26$: cozi clar mai groase decât cele ale distribuției Normale
- Timp de înjumătățire 131 de zile; volatilitatea de termen lung $\sqrt{251,4 \hat{\omega} / (1 - \hat{\alpha} - \hat{\beta})} = 27,3\%$ anual ($A = 251,4$ randamente pe an), peste valoarea din eșantion 19,2%: împărțirea la $1 - \hat{\alpha} - \hat{\beta}$ o face imprecisă (slide-ul următor)

Persistență aproape de 1: limitele metodei delta



- $g(\theta)$: o funcție netedă de parametri (volatilitatea de termen lung, timpul de înjumătățire); ∇g : gradientul ei; $p = \alpha + \beta$, $h = \ln 0.5 / \ln p$
- Metoda delta: $\widehat{\text{e.s.}} g(\hat{\theta}) \approx \sqrt{\nabla g' \hat{V} \nabla g}$, $\hat{V}$ covarianța robustă a lui $(\hat{\omega}, \hat{\alpha}, \hat{\beta})$; volatilitatea de termen lung 27,3% anual, e.s. 10,8 puncte
- Timpul de înjumătățire: $\partial h / \partial p = 24\,789$ la $\hat{p} = 0.994712$, $\widehat{\text{e.s.}}(\hat{p}) = 0.0047$, deci $\widehat{\text{e.s.}}(\hat{h}) \approx 116$ zile, iar $\hat{h} \pm 1.96 \widehat{\text{e.s.}}$ conține timpi de înjumătățire negativi: liniarizarea eșuează
- Transformăm în schimb intervalul pentru p : $[0.9855; 1.0039]$ dă $h \in [48; \infty)$; plauzibilitatea lui $p = 1$ cere un test la frontieră (slide-urile următoare)

Testarea la frontieră: un tabel de decizie

Situația sub H_0	Exemplu	Legea lui $LR = 2(\ell_1 - \ell_0)$	Valoare critică 5%
Restricție interioară	GJR (GARCH asimetric) față de GARCH, $\gamma = 0$ (cu $\alpha > 0$)	χ_1^2	3,84
Un parametru pe frontieră, ceilalți identificați și interiori	Normală față de Student-t ($1/\nu = 0$); IGARCH ($\alpha + \beta = 1$)	$\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ Self & Liang (1987), Andrews (2001)	2,71
Un parametru perturbator (nuisance) neidentificat	Fără ARCH: $\alpha = 0$ lasă β neidentificat	nestandard Andrews (2001)	simulare
Mai multe restricții active simultan	GJR cu $\hat{\alpha} = 0$, testul $\gamma = 0$	nestandard	simulare

- ℓ_1, ℓ_0 : log-verosimilitățile maxime fără și cu restricție; $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$: $LR = 0$ cu probabilitatea $\frac{1}{2}$, altfel χ_1^2
- Modele neimbricate: **AIC** = $-2\ell + 2k$, **BIC** = $-2\ell + k \ln n$ (k parametri); se preferă valoarea mai mică
- Testul Wald t pentru o estimare la limită (de ex. $\hat{\alpha} = 0$) nu este $N(0, 1)$; bootstrap-ul parametric din $\hat{\theta}$ este inconsistent când θ_0 este pe frontieră Andrews (2000): simulăm în schimb sub H_0


Teste la frontieră pe datele cursului

- Inovații Normale față de Student-t, GARCH(1,1): $LR = 311,0$ (S&P 500), 1082,0 (Bitcoin)
 - ▶ Mult peste 2,71: cozile groase sînt clar susținute de date; distribuția de tip amestec contează doar în cazurile la limită
- GJR-t (GJR: un GARCH asimetric, secțiunea următoare), S&P 500: $\hat{\alpha} = 0,000$; testul său t nu este standard, iar legea χ^2_1 a LR pentru $\gamma = 0$ presupune $\alpha_0 > 0$
- IGARCH, $H_0: \alpha + \beta = 1$ (GARCH-t): $LR = 1,11$ (S&P 500), 1,14 (BET)
 - ▶ S&P 500: $p = 0,29$ (χ^2_1), 0,15 (amestec), 0,17 (bootstrap parametric sub H_0 , $B = 999$ eșantioane simulate)
 - ▶ BET: $p = 0,28$, 0,14 și 0,17
- Sub H_0 , 52% din reestimări au $\hat{\alpha} + \hat{\beta} \geq 0,999$ (la frontiera $\alpha + \beta = 1$), conform distribuției de tip amestec: rădăcina unitară în dispersie nu poate fi respinsă pentru niciunul dintre indici

Exemplu lucrat: prognozele pe o zi și pe zece zile

- S&P 500, GARCH(1,1)-t: $\hat{\omega} = 0,0157$, $\hat{\alpha} = 0,123$, $\hat{\beta} = 0,872$, $\hat{\mu} = 0,079$
- Ultima zi $T = 18.09.2026$: $\hat{\varepsilon}_T = r_T - \hat{\mu} = 0,088$, dispersia filtrată $\hat{\sigma}_T^2 = 0,565$
 - $\hat{\sigma}_{T+1}^2 = \hat{\omega} + \hat{\alpha}\hat{\varepsilon}_T^2 + \hat{\beta}\hat{\sigma}_T^2 = \hat{\omega} + 0,0009 + 0,493 = 0,509$, adică 11,3% anual
- Dispersia de termen lung $\hat{\sigma}^2 = \hat{\omega}/(1 - \hat{\alpha} - \hat{\beta}) = 2,97$; ziua 10: $\hat{\sigma}^2 + (\hat{\alpha} + \hat{\beta})^9(\hat{\sigma}_{T+1}^2 - \hat{\sigma}^2)$
 - $= 2,97 + 0,953 \times (0,509 - 2,97) = 0,624$
- Dispersia pe 10 zile $\sum_{h=1}^{10} \hat{\sigma}_{T+h}^2 = 5,67$, volatilitatea 2,38%
 - Regula rădăcinii pătrate a timpului dă $\sqrt{10} \times 0,714 = 2,26\%$: o subestimare, deoarece $\hat{\sigma}_{T+1}^2 < \hat{\sigma}^2$ și volatilitatea este prognozată în creștere

Structura la termen a volatilității




- Volatilitatea medie pe următoarele h zile, prognozată din 18.09.2026 (GARCH(1,1)-t); punctat: nivelul de termen lung
- S&P 500 crește de la 11,3% la 20,1% într-un an (nivelul curent este sub cel de termen lung); aurul scade de la 23,9% la 22,4%
- Bitcoin, EUR/RON: IGARCH cu $\hat{\omega} > 0$, prognoza dispersiei crește cu $\hat{\omega}$ pe zi (Bitcoin: 108,3% într-un an): o consecință a rădăcinii unitare estimate

GARCH(1,1)-t pe șase piețe

Serie	$\hat{\omega}$	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\alpha} + \hat{\beta}$	$h_{1/2}$ (zile)	$\hat{\nu}$	Vol. termen lung
S&P 500	0,0157	0,123	0,872	0,9947	131	6,26	27,3
BET	0,0448	0,192	0,799	0,9907	74	5,01	34,7
BET-TR	0,0755	0,206	0,713	0,9188	8	5,02	15,2
Bitcoin	0,1937	0,109	0,891	1,0000	∞	3,18	–
EUR/RON	0,0000	0,123	0,877	1,0000	∞	4,20	–
Aur	0,0107	0,049	0,944	0,9935	106	4,58	20,7


- Volatilitatea de termen lung în % anual, fiecare serie anualizată cu frecvența ei; – când $\hat{\alpha} + \hat{\beta} \geq 0,999$; la EUR/RON $\hat{\omega}$ este 0,0000 la patru zecimale
- Acțiuni și aur: persistență 0,99–0,995; BET reacționează mai puternic la știri ($\hat{\alpha} = 0,192$) și are o memorie mai scurtă decât S&P 500
- Eșantioane diferite: BET-TR începe în 2014, deci persistența sa mai mică nu este comparabilă cu cea a BET 2000–2026; Bitcoin: $\hat{\nu} < 4$, moment de ordin patru infinit sub legea estimată
- EUR/RON, un curs în regim de managed float: pe 6 mai 2025, o variație de +1,20% după zile de $\pm 0,004\%$ dă un reziduu standardizat de 154

Persistența: viteza de disipare a șocurilor



- $(\hat{\alpha} + \hat{\beta})^h$: partea dintr-un șoc de dispersie rămasă după h zile; linia întreruptă: o jumătate
- Timpi de înjumătățire: S&P 500 131 de zile, aur 106, BET 74, BET-TR 8; la Bitcoin și EUR/RON șocurile nu se disipă niciodată în model
- Schimbările structurale ale nivelului volatilității pot genera o persistență aparent mare [Lamoureux & Lastrapes \(1990\)](#) (schimbare de regim: [Hamilton & Susmel \(1994\)](#)): raportați timpii de înjumătățire ca intervale (Seminarul 5, B7)





S&P 500: volatilitatea GARCH și VIX



- $\hat{\sigma}_t \sqrt{A}$ ($A = 251,4$ randamente pe an) din GARCH(1,1)-t și VIX (volatilitatea implicită pe 30 de zile), 2000–2026: corelația 0,89
- VIX este mai mare în medie: 19,8% față de 17,0%, peste GARCH în 84% din zile
- Diferența nu măsoară variance risk premium (prima de risc a dispersiei): prima compară VIX^2 cu o prognoză a dispersiei pe 30 de zile sub probabilitatea reală; $\hat{\sigma}_t$ este o volatilitate pe o zi

MFM_ch5_sp500_vix

BET, Bitcoin, EUR/RON și aur



- Volatilitatea GJR-GARCH-t, fiecare serie anualizată cu frecvența ei (Bitcoin: 365 de zile)
- BET: anul 2008 domină, nivelul actual este 26,4%; Bitcoin: valorile de 50–100% sînt obișnuite, cel mai înalt vîrf este în martie 2020
- EUR/RON: perioade calme, specifice regimului de managed float, întrerupte de episoade de volatilitate ridicată în 2022 și 2025, pe care un GARCH zilnic le descrie slab; aur: un nou maxim de 53% în 2026


GJR-GARCH (Glosten, Jagannathan și Runkle, 1993)

- Știrile proaste cresc volatilitatea viitoare mai mult decât știrile bune de aceeași mărime (faptul stilizat 9, [Capitolul 1](#)); GARCH(1,1) ignoră semnul: ε_{t-1}^2 este același pentru -3 și $+3$
- GJR: un șoc negativ primește panta suplimentară γ [Glosten, Jagannathan & Runkle \(1993\)](#)
 - ▶ $\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, cu $I_{t-1} = 1$ dacă $\varepsilon_{t-1} < 0$, altfel 0
 - ▶ Știri bune: panta α ; știri proaste: panta $\alpha + \gamma$; pozitivitatea: $\omega > 0$, $\alpha \geq 0$, $\alpha + \gamma \geq 0$, $\beta \geq 0$ (γ poate fi negativ)
 - ▶ Persistența $\alpha + \gamma/2 + \beta$ pentru z_t simetric; pentru z_t asimetric, $1/2$ se înlocuiește cu $\mathbb{E}[z_t^2 1(z_t < 0)]$, $1(\cdot)$ fiind indicatorul (Seminarul 5, A2)
- S&P 500: $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t = 10,0$), $\hat{\beta} = 0,881$; testul simetriei: $H_0: \gamma = 0$ prin t sau prin LR față de GARCH(1,1)
- Mecanisme posibile, netestate aici: levierul (un preț în scădere crește raportul datorii/capital propriu) și feedback-ul volatilității (volatilitatea așteptată mai mare crește randamentul cerut, deci prețurile scad acum)

EGARCH (Nelson, 1991)


- ▣ EGARCH modelează logaritmul dispersiei, în funcție de mărimea și de semnul șocului standardizat de ieri [Nelson \(1991\)](#)
 - ▶ $\ln \sigma_t^2 = \omega + \alpha (|z_{t-1}| - \mathbb{E}|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$
 - ▶ $z_{t-1} = \varepsilon_{t-1}/\sigma_{t-1}$: șocul standardizat; $|z_{t-1}| - \mathbb{E}|z_{t-1}|$: mărimea sa peste mărimea medie
 - ▶ Efectul de mărime α , efectul de semn γ ; $\gamma < 0$: șocurile negative cresc volatilitatea mai mult
- ▣ Forma logaritmică garantează $\sigma_t^2 > 0$ fără restricții de semn asupra parametrilor
- ▣ Persistența: β (staționar dacă $|\beta| < 1$)
- ▣ S&P 500: $\hat{\alpha} = 0,138$, $\hat{\gamma} = -0,165$ ($t = -15,2$), $\hat{\beta} = 0,979$
- ▣ În arch, $\mathbb{E}|z|$ este fixat la $\sqrt{2/\pi}$, valoarea sa sub distribuția Normală

Curba de impact a știrilor pentru S&P 500



- Curba de impact a știrilor Engle & Ng (1993): σ_t^2 ca funcție de ε_{t-1} , cu σ_{t-1}^2 fixată la dispersia de selecție 1,47 ($\%^2$)
- Șoc de -3%: GJR 3,16, EGARCH 2,76; +3%: GJR 1,31, EGARCH 1,22; GARCH: 2,40 pentru ambele
- După știri proaste prognoza este de 2,4 ori (GJR) și de 2,3 ori (EGARCH) cea după știri bune: rapoarte de niveluri, nu de creșteri

Detaliu: crahul COVID-19, 2020



- Ianuarie–iulie 2020: $|r_t|$ anualizat, volatilitatea GARCH-t și GJR-GARCH-t, VIX
- 24 februarie ($r_t = -3,41\%$): VIX a trecut de la 17,1% la 25,0% în aceeași zi; GARCH-t de la 12,2% la 22,5% abia a doua zi: GARCH reacționează cu o zi întârziere, piața include informația în preț imediat
- După $r_t = -12,8\%$ pe 16 martie, vîrfuri pe 17 martie: GARCH-t 111%, GJR-t 127%, mai ridicată deoarece șocurile au fost negative

Asimetria pe șase piețe

Serie	$\hat{\gamma}_{GJR}$	t	LR față de GARCH	valoare p	$\hat{\gamma}_{EGARCH}$	t
S&P 500	0,205	10,0	235,7	< 0,001	-0,165	-15,2
BET	0,043	2,1	4,9	0,026	-0,028	-2,6
BET-TR	0,111	2,9	10,3	0,001	-0,063	-3,5
Bitcoin	-0,013	-0,7	0,7	0,416	0,015	1,2
EUR/RON	0,039	3,0	9,3	0,002	-0,040	-2,5
Aur	-0,043	-4,7	27,6	< 0,001	0,038	5,7

- Inovații Student-t; t robust; $LR \sim \chi^2_1(3,84)$ dacă densitatea Student-t este corectă; t robust este $N(0, 1)$ doar dacă ceilalți parametri sînt interiori (nu pentru $\hat{\alpha} = 0$)
- Știrile proaste contează mai mult (GJR $\hat{\gamma} > 0$, EGARCH $\hat{\gamma} < 0$): efect puternic la S&P 500 ($LR = 235,7$), slab la BET și BET-TR (4,9; 10,3), redus la EUR/RON; la Bitcoin nu este detectat ($LR = 0,7$); la aur este inversat ($\hat{\gamma}_{GJR} = -0,043$)
- Levierul pentru acțiuni și rolul de activ de refugiu (safe haven) al aurului sînt interpretări compatibile cu aceste semne, nu mecanisme testate

S&P 500: douăsprezece modele comparate prin BIC


ΔBIC	$N(0, 1)$	Student-t	t asimetric	GED
GARCH(1,1)	648,9	346,7	307,4	339,8
GJR-GARCH(1,1)	394,7	119,9	49,6	141,6
EGARCH(1,1)	372,9	74,8	0,0	111,4

- ΔBIC : $BIC = -2\ell + k \ln n$ minus cel mai mic BIC dintre cele 12 modele (0 = modelul preferat)
- Contează două alegeri: inovațiile Student-t în locul celor Normale scad BIC cu circa 300; asimetria îl mai scade cu 230–270; modelul preferat: EGARCH cu inovații t asimetrice
- BIC ordonează adecvarea în eșantion, nu acuratețea prognozelor: secțiunea despre prognoze testează dacă aceste câștiguri se păstrează în afara eșantionului

Reziduurile standardizate și testele de asimetrie

- **Reziduul standardizat:** $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$; dacă modelul este corect, $\hat{z}_t$ este aproape i.i.d. cu dispersia 1
- Verificări, fiecare cu H_0 : modelul reproduce proprietatea respectivă
 - ▶ Ecuația mediei: Ljung–Box $Q(10)$ pe $\hat{z}_t$; ecuația dispersiei: $Q(10)$ pe $\hat{z}_t^2$ și LM(5); distribuția: grafic QQ față de densitatea presupusă
- Regresia de asimetrie Engle & Ng (1993): $\hat{z}_t^2 = b_0 + b_1 S_{t-1}^- + b_2 S_{t-1}^- \hat{\varepsilon}_{t-1} + b_3 S_{t-1}^+ \hat{\varepsilon}_{t-1} + u_t$
 - ▶ $S_{t-1}^- = 1$ dacă $\hat{\varepsilon}_{t-1} < 0$, altfel 0; $S_{t-1}^+ = 1 - S_{t-1}^-$; u_t : eroarea regresiei; termenii de mărime folosesc reziduul nestandardizat $\hat{\varepsilon}_{t-1}$ (ec. 18 din Engle și Ng, 1993)
 - ▶ b_1 : asimetria de semn; b_2 , b_3 : asimetria de mărime negativă și pozitivă; testul comun $nR^2 \sim \chi_3^2$ (7,81 la 5%), conservator deoarece omite gradientul dispersiei estimate

S&P 500: normalitatea inovațiilor



- Reziduurile standardizate ale GARCH(1,1) cu inovații Normale: excesul de kurtosis scade de la 10,7 (randamente) la 1,73; asimetria -0,53, Jarque–Bera 1153
- 15 reziduuri sub -4: 0,21 așteptate sub distribuția Normală, 8,5 sub Student-t cu $\nu = 6,3$; cel mai mare: $\hat{z} = -6,6$ (27 februarie 2007)
- O coadă stângă mai lungă: t asimetric cu $\hat{\lambda} = -0,150$ (GJR, $\hat{\nu} = 7,7$ grade de libertate), de aceea BIC preferă inovațiile t asimetrice

S&P 500: diagnosticul a cinci modele


Model	$Q(10)$ pe $\hat{z}$	$Q(10)$ pe $\hat{z}^2$	LM(5)	Asim. semn t	Comun χ^2_3
GARCH-N	21,2	16,4	8,0	3,64	41,8
GARCH-t	21,9	13,6	5,8	3,56	40,7
GJR-t	22,3	10,2	4,5	3,61	28,1
EGARCH-t	27,6	10,5	8,2	2,04	9,9
GJR cu t asimetric	19,7	10,7	5,0	3,91	31,8

- Valori critice la 5%: 18,3 (χ^2_{10}), 11,1 (χ^2_5), 7,81 (χ^2_3), $|t| > 1,96$; legi naive, conservatoare cu parametri estimați (slide-ul următor)
- Media: $Q(10)$ pe $\hat{z}$ între 20 și 28 în toate modelele: o mică autocorelație pe care media constantă o ignoră
- Dispersia: $Q(10)$ pe $\hat{z}^2$ scade de la 6133 (pe r_t^2) la 10–16, iar LM(5) nu este semnificativ: aceste teste naive nu detectează volatility clustering rămas
- Asimetria: GARCH simetric este respins de testul comun (40,7), GJR la fel (28,1), EGARCH se apropie cel mai mult (9,9, $p = 0,020$); cu $n = 6\,714$, judecați mărimea economică, nu doar valorile p

Diagnosticul reziduurilor depinde de parametrii estimați

- ▣ $\hat{z}_t$ depinde de $\hat{\theta}$: statistica Ljung–Box pe $\hat{z}_t^2$ nu este exact χ_m^2 Li & Mak (1994); dispersia estimată a preluat deja o parte din dependența de la decalajele mici
- ▣ S&P 500, QMLE Gaussian pentru GARCH(1,1), $Q(10)$ pe $\hat{z}_t^2$
 - ▶ Ljung–Box naiv: 16,4, $p = 0,089$: nerespins la 5%
 - ▶ Corectat pentru parametrii estimați: 19,1, $p = 0,038$: respins la 5%, verdictul se inversează
- ▣ Testul naiv este conservator: respinge prea rar o ecuație a dispersiei greșit specificată; testul comun de asimetrie are aceeași limită
- ▣ Matricea de corecție și elementele ei: [▶ Anexă](#)

Diagnostic: pătratele randamentelor și pătratele reziduurilor



- S&P 500, decalajele 1–30: autocorelațiile lui r_t^2 (înainte de model) și ale lui $\hat{z}_t^2$ din GJR-GARCH-t
- După model ele sînt în banda i.i.d.: la aceste decalaje nu se mai detectează dinamică a dispersiei
- Banda este cea naivă: cu parametri estimați este prea largă la decalaje mici (slide-ul anterior)

Diagnostic pe alte piețe: un tabel de decizie

Piața	Tiparul reziduurilor	Problema posibilă	Verificarea următoare
BET	$Q(10)$ pe $\hat{z} = 116,6$	autocorelație în medie (tranzacționare redusă, Capitolul 2)	ecuația mediei AR(1)
Bitcoin	$Q(10)$ pe $\hat{z}^2 = 4,7$, testul comun de asimetrie 1,3: nerespins	$\hat{\nu} = 3,18 < 4$: $\text{Var}(z_t^2) = \infty$, deci calibrarea χ^2 nu este justificată	teste pe $ \hat{z}_t $
EUR/RON	exces de kurtosis 3190	un singur reziduu de 154 (mai 2025) domină	inspectarea celor mai mari reziduuri; un model cu scor mărginit
Aur	EGARCH: $Q(10)$ pe $\hat{z}^2 = 48,8$	volatility clustering rămas, deși BIC este bun	alegere prin diagnostic, nu doar prin BIC

□ Examinați întotdeauna cele mai mari reziduuri: o singură observație poate domina toate diagnosticele

Problema aproximării și pierderile robuste

- Volatilitatea nu este observată niciodată: comparăm prognozele cu o **aproximare** zgomotoasă, de ex. r_t^2
- $r_t^2 = \sigma_t^2 z_t^2$ este nedeplasat ($\mathbb{E}[r_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2$ pentru $\mu = 0$), dar foarte zgomotos
 - ▶ R^2 -ul său față de dispersia reală este mic chiar pentru o prognoză perfectă [Andersen & Bollerslev \(1998\)](#)
 - ▶ S&P 500: ignorăm media, deoarece $\hat{\mu}^2 = 0,0062$ față de o dispersie zilnică medie de 1,47 (%²), o deplasare sub 1%
- [Patton \(2011\)](#): doar unele funcții de pierdere ordonează corect prognozele cu o aproximare zgomotoasă
 - ▶ Robuste: MSE (eroarea pătratică) $(r_t^2 - h_t)^2$ și **QLIKE** $r_t^2/h_t + \ln h_t$, cu h_t prognoza dispersiei pentru ziua t ; ambele se mediază pe zilele de prognoză, valoarea mai mică este mai bună
 - ▶ Nerobuste: pierderile pe volatilitate $|r_t| - \sqrt{h_t}$ sau pe logaritmi
- QLIKE este (pînă la constante) minus log-verosimilitatea Normală; valoarea sa așteptată este minimă pentru $h_t = \sigma_t^2$; penalizează mai mult subestimarea


Evaluarea prognozelor (1/2): Mincer–Zarnowitz

- **Regresia Mincer–Zarnowitz** Mincer & Zarnowitz (1969): regresăm aproximarea pe prognoză
 - ▶ $r_t^2 = a + b h_t + u_t$
 - ▶ a : termenul liber; b : panta; u_t : eroarea regresiei
- Prognoză nedeplasată: $a = 0$, $b = 1$
 - ▶ Test Wald comun cu erori HAC (consistente la heteroscedasticitate și autocorelație); χ^2_2 sub H_0
 - ▶ $b < 1$: prognoze prea dispersate (prea mari când sînt mari, prea mici când sînt mici)
 - ▶ $R^2 \in [0, 1]$: proporția din variația lui r_t^2 explicată de h_t ; mic chiar pentru prognoze bune, deoarece r_t^2 este zgomotos

Evaluarea prognozelor (2/2): Diebold–Mariano

- **Testul Diebold–Mariano** Diebold & Mariano (1995): au două prognoze aceeași pierdere așteptată?
 - ▶ Diferența de pierderi $d_t = L(r_t^2, h_t^A) - L(r_t^2, h_t^B)$
 - ▶ L : funcția de pierdere (QLIKE sau MSE); h_t^A, h_t^B : prognozele modelelor A și B; $d_t < 0$: A a fost mai bun în ziua t
- Statistica: $DM = \bar{d} / \widehat{e.s.}(\bar{d})$
 - ▶ $\bar{d}$: media lui d_t pe zilele de prognoză; eroare standard HAC, deoarece d_t este autocorelat
 - ▶ $\approx N(0, 1)$ sub acuratețe egală; $DM < -1,96$: A semnificativ mai bun; $DM > 1,96$: B semnificativ mai bun
- Legea $N(0, 1)$ presupune prognoze date; pentru modele estimate și imbricate (GARCH-t în GJR-t) poate să nu fie valabilă, deci acolo statistica DM se interpretează descriptiv (slide-ul GW de mai jos)


Schema în afara eșantionului și traiectoriile prognozelor, 2016–2026



- S&P 500: 2 692 de prognoze pe o zi; reestimare în fiecare ianuarie pe toate datele din 2000 (fereastră în expansiune), actualizare zilnică cu parametri ficși
- Alinierea în timp: h_t folosește datele pînă la închiderea zilei $t - 1$ și se compară cu r_t^2 ; modificarea lui r_t nu trebuie să schimbe h_t
- Modele: GARCH-N, GARCH-t, GJR-t, EGARCH-t; repere: EWMA și Hist-20 (dispersia istorică pe 20 de zile); în grafic: GJR-t, EWMA, $|r_t|\sqrt{A}$ ($A = 251,4$)

 MFM_ch5_forecast_evaluation

S&P 500: evaluarea prognozelor față de GARCH(1,1)



- QLIKE mediu minus cel al GARCH-t, cu t DM (HAC, 5 decalaje); cel mai mic QLIKE: GJR-t (0,732)
- Familia GARCH: t DM între -1,47 și -0,36, descriptiv pentru aceste perechi imbricate
- EWMA și Hist-20 sînt clar mai slabe ($t = 3,48; 4,10$): revenirea la medie și parametrii estimați aduc un câștig [Hansen & Lunde \(2005\)](#)
- MZ: nedeplasarea nu este respinsă pentru prognozele de tip GARCH, este respinsă pentru Hist-20 (toate statisticile: [Anexă](#))

 [MFM_ch5_forecast_evaluation](#)


Compararea metodelor de prognoză: Giacomini–White și Model Confidence Set

- Cu parametri estimați, modele imbricate și fereastră în expansiune, diferența DM degenerează sub H_0 : DM nu este $N(0, 1)$ West (1996), Clark & McCracken (2001)
- Giacomini & White (2006): testăm metoda de prognoză (model + fereastră mobilă de $W = 1000$ de zile), validă pentru modele imbricate, deoarece zgomotul estimării nu dispare
- Șase modele, cinci teste pe perechi: o problemă de comparații multiple; **Model Confidence Set** Hansen, Lunde & Nason (2011) elimină cel mai slab model pînă cînd acuratețea egală nu mai este respinsă; mulțimea conține cel mai bun model cu probabilitatea $\geq 1 - \alpha$ (α aici: rata de eroare aleasă, 10%)
- Rezultat: GW respinge doar EWMA și Hist-20; MCS 90% păstrează cele patru modele GARCH: aceeași concluzie ca testul DM, de această dată cu inferență calibrată (formule și tabelul complet: [▶ Anexă](#))

Model	GW p	MCS p
GARCH-N	0,054	0,586
GARCH-t	–	0,353
GJR-t	0,288	1,000
EGARCH-t	0,201	0,586
EWMA	0,003	0,008
Hist-20	< 0,001	0,001

- GW: fereastră mobilă, 2 692 de prognoze, față de GARCH-t; MCS: fereastră în expansiune, QLIKE, bootstrap staționar

Proгноze pe o lună: Mincer-Zarnowitz în logaritmi




- Prognoza GJR-t a dispersiei pe 22 de zile față de suma realizată a 22 de pătrate ale randamentelor, 122 de ferestre nesuprapuse; regresia $\ln Y = a + b \ln \hat{h} + u$, Y : suma realizată, $\hat{h}$: prognoza; R^2 în logaritmi 0,38
- Panta în logaritmi $b = 0,75$ (e.s. 0,07): doar descriptivă, deoarece $\mathbb{E}[\ln Y | \mathcal{F}] \neq \ln \mathbb{E}[Y | \mathcal{F}]$; $b < 1$ nu dovedește prognoze prea dispersate
- În niveluri b este doar 0,27: două ferestre COVID-19 domină; comparăm prognozele cu QLIKE [Patton \(2011\)](#)

GARCH-in-mean: remunerarea riscului

- **GARCH-M Engle, Lilien & Robins (1987):** $r_t = c + \kappa \sigma_t + \varepsilon_t$ (sau $\kappa \sigma_t^2$)
 - ▶ c : constantă; κ : prețul riscului, randamentul așteptat suplimentar pe unitate de volatilitate
 - ▶ $\kappa > 0$: investitorii cer un randament așteptat mai mare când riscul este mai mare (compromisul risc–randament)
- S&P 500, GARCH(1,1)-t în medie: $\hat{\kappa} = 0,096$ ($t = 3,02$) cu σ_t ; $0,028$ ($t = 2,35$) cu σ_t^2
 - ▶ Pozitiv și semnificativ în acest eșantion, dar rezultatele din literatură sînt contradictorii: GJR (1993) au găsit o relație negativă
- Atenție: un efect zilnic în medie este mic și fragil; depinde de eșantion și de asimetria dispersiei

Memoria lungă: o limită a modelului GARCH



- S&P 500, ACF a lui $|r_t|$ (scară log): datele 0,289, 0,082, 0,009 la decalajele 1, 100, 250; GARCH(1,1)-t prea mare la decalajul 1 (0,416), apoi o scădere exponențială
- **FIGARCH** Baillie, Bollerslev & Mikkelsen (1996), $(1 - L)^d$ (L : operatorul de decalaj, $Lx_t = x_{t-1}$; $d \in (0, 1)$: ordinul fracționar): scădere hiperbolică; $\hat{d} = 0,60$ (e.s. 0,06), BIC mai mic cu 34,2, dar memoria este acum prea lungă (0,144 la decalajul 250)
- Niciun model cu o singură scară de timp nu descrie toate orizonturile: volatilitatea realizată și HAR în Capitolul 9

 MFM_ch5_long_memory

Limitele GARCH și extensiile pe care le motivează

Limita	Dovada din acest capitol	Extensia
Schimbările de nivel exagerează $\alpha + \beta$ Lamoureux & Lastrapes (1990)	BET-TR (2014–2026) 0,9188 față de BET (2000–2026) 0,9907	GARCH-MIDAS, o componentă lentă de termen lung Engle, Ghysels & Sohn (2013) ; schimbare de regim Hamilton & Susmel (1994)
Reacție întârziată cu o zi	COVID-19: VIX a reacționat în aceeași zi, GARCH a doua zi	Realized GARCH, cu o ecuație de măsurare pentru dispersia realizată Hansen, Huang & Shek (2012) (Capitolul 9)
O valoare extremă domină actualizarea	reziduul EUR/RON de 154 (mai 2025)	Modele bazate pe scor (GAS), cu scor mărginit Creal, Koopman & Lucas (2013) ; studiul de caz de mai jos
Memorie scurtă	ACF a lui $ r_t $ la decalajele 100–250	FIGARCH; HAR pe dispersia realizată (Capitolul 9)
Un singur activ Curs în regim de managed float	portofoliile au nevoie de covarianțe EUR/RON: perioade lungi de stabilitate, apoi salturi	GARCH multivariat și DCC (Capitolul 6) Intervențiile modelate ca salturi sau regimuri

- Fiecare extensie se judecă la fel ca GARCH: în afara eșantionului, pierdere robustă, Model Confidence Set (ecuațiile modelelor: [▶ Anexă](#))

Studiu de caz (1/2): întrebarea și actualizarea bazată pe scor

- **Întrebarea** Blasques, Francq & Laurent (2023): trebuie ca un model de volatilitate bazat pe scor să actualizeze σ_t^2 cu scorul aceleiași densități care descrie randamentele?
- Actualizarea bazată pe scor (GAS) Creal, Koopman & Lucas (2013): parametrul de mîine se deplasează în direcția care ar fi făcut observația de azi mai probabilă
 - ▶ $f_{t+1} = \omega + \alpha S(f_t) \partial \log p(y_t | f_t) / \partial f_t + \beta f_t$
 - ▶ y_t : randamentul; f_t : parametrul variabil în timp (aici dispersia); $p(y_t | f_t)$: densitatea lui y_t dată fiind f_t
 - ▶ $\partial \log p / \partial f_t$: scorul; $S(f_t) > 0$: un factor de scalare; ω, α, β : ca în GARCH
- Cu o densitate Student-t, un singur parametru ν determină atât
 - ▶ cozile lui z_t
 - ▶ cît și cît de puternic este atenuat un șoc mare în actualizare

Studiu de caz (2/2): modelul QSD și datele


- **QSD GARCH(1,1)-t**, ec. (30) din lucrare: $y_t = \sqrt{f_t} \epsilon_t$, ϵ_t Student-t standardizat cu $1/\xi$ grade de libertate (f_t este σ_t^2 , ϵ_t este z_t)
 - ▶ $f_{t+1} = \omega + \varpi X_t + \alpha \frac{1 + \zeta}{1 - 2\zeta + \zeta \epsilon_t^2} \epsilon_t^2 f_t + \beta f_t$
 - ▶ X_t : o variabilă exogenă, pătratul VIX la orizont zilnic; ϖ : coeficientul ei
 - ▶ ξ : grosimea cozilor lui ϵ_t ($\xi = 0$: Normală); ζ : atenuarea valorilor mari ale lui ϵ_t^2 în actualizare
 - ▶ $\zeta = 0$: GARCH(1,1)-t; $\zeta = \xi$: Beta-t-GARCH (bazat pe scor)
- Date: 400 de acțiuni din S&P 500, 3 ianuarie 1995 (sau mai târziu) – 28 februarie 2019; verosimilitate maximă cu medie AR(1)
 - ▶ Testele LR pentru $\zeta = 0$ și $\xi = \zeta$, față de χ_1^2 (metoda completă: [▶ Anexă](#))
 - ▶ Testul PIT: $u_t = F(y_t | \mathcal{F}_{t-1})$, funcția de repartiție estimată în randamentul observat, trebuie să fie i.i.d. uniformă pe $(0, 1)$ dacă densitatea este corectă

Studiu de caz: rezultatele principale (lucrarea, Tabelele 4–6)

Respinse la 5%, % din cele 400 de acțiuni	Student-t (Tabelul 4)	t asimetric (Tabelul 6)
LR, $H_0: \zeta = 0$ (actualizare GARCH)	89,5	98,8
LR, $H_0: \xi = \zeta$ (bazat pe scor; asimetric: și $\kappa = \tau$)	53,5	100,0
Testul PIT: GARCH(1,1)	40,0	33,1
Testul PIT: Beta-t-GARCH	46,0	72,2
Testul PIT: QSD GARCH(1,1)	45,7	11,3


- Atenuarea șocurilor mari contează: $\zeta = 0$ este respinsă pentru 89,5% din acțiuni și toate valorile $\hat{\zeta}$ sînt pozitive (Tabelul 4)
- Totuși, Beta-t-GARCH atenuează excesiv: acolo unde $\hat{\xi} - \hat{\zeta}$ este semnificativă, $\hat{\xi} > \hat{\zeta}$ pentru toate acțiunile, cu o excepție; mediana lui $1/\hat{\zeta}$ este 9,48, față de 5,07 la Beta-t-GARCH ($\zeta = \xi$) (lucrarea, Fig. 2–3): grosimea cozilor și atenuarea șocurilor sînt parametri diferiți
- t asimetric (κ : asimetria densității, τ : asimetria actualizării, 0,5: simetric): $\hat{\tau}$ mult sub 0,5 (mediana 0,333), iar $\hat{\kappa}$ rămîne aproape de 0,5 (Fig. 5–6): efectul de levier acționează prin ecuația de actualizare, nu prin densitate; testul PIT respinge apoi modelul QSD pentru doar 11,3% din acțiuni

Studiu de caz: replicare pe 11 acțiuni (cf. lucrarea, Fig. 2)



- Eșantionul cursului: 11 acțiuni mari, încă listate (lucrarea: 400), 1995 (sau mai târziu) – februarie 2019, 4986–6081 randamente fiecare; $X_t = \text{VIX}_t^2/252$
- $\zeta = 0$ respinsă pentru 9 din 11 (lucrarea: 89,5%); $\xi = \zeta$ respinsă pentru 8 (lucrarea: 53,5%); $\hat{\xi} > \hat{\zeta}$ pentru 10 din 11
- Mediana lui $1/\hat{\zeta}$: 21,4 (QSD) față de 6,32 (Beta-t-GARCH); lucrarea: 9,48 față de 5,07; 11 companii selectate, încă listate: rezultate imprecise și nerepresentative

Studiu de caz: impactul știrilor (cf. lucrarea, Fig. 3)



- GARCH(1,1)-t ($\zeta = 0$)
- Beta-t-GARCH, $\zeta = \hat{\zeta}$, median over stocks (0.158)
- Beta-t-GARCH, $\zeta = \hat{\zeta}$, 5% and 95% quantiles (0.139, 0.231)
- QSD GARCH(1,1)-t, $\hat{\zeta}$, median over stocks (0.047)
- QSD GARCH(1,1)-t, $\hat{\zeta}$, 5% and 95% quantiles (0.018, 0.188)

- Contribuția lui ϵ_t la f_{t+1} (în unități de αf_t) la cuantile ale celor 11 estimări: funcții de actualizare la același αf_t , nu traiectorii estimate
- Un șoc de 5 abateri standard adaugă 25 (GARCH-t), 12,6 (QSD median), 6,2 (Beta-t-GARCH median); la 10 abateri standard: 100, 18,8, 7,0 (limita $(1 + \zeta)/\zeta = 7,3$)
- QSD se află între cele două: șocurile mari sînt atenuate, dar mult mai puțin decît impune Beta-t-GARCH

 MFM_ch5_quasi_score_driven

Întrebări deschise și bucla descoperirii

□ Întrebări

- ▶ depășesc prognozele bazate pe învățare automată sau pe măsuri realizate un GARCH bine specificat pentru dispersia zilnică a acțiunilor, în afara eșantionului?
- ▶ rămîne răspunsul valabil după luarea în calcul a numărului de modele comparate?

□ Christensen, Siggaard & Veliyev (2023): metodele de învățare automată, cu puțină calibrare, sînt competitive cu modelele de tip HAR; Hansen, Lunde & Nason (2011): Model Confidence Set este instrumentul potrivit cînd concurează multe modele

□ Formal: $d_t = L(r_t^2, h_t^A) - L(r_t^2, h_t^B)$, $H_0: \mathbb{E}d_t = 0$; afirmația este infirmată dacă A este eliminat din Model Confidence Set sau dacă semnul lui $\bar{d}$ se schimbă între subperioadele pre-înregistrate

□ Bucla: un asistent AI propune harta literaturii, ipoteze concurente, codul, un plan de robustețe și o critică în stilul unui referent; cercetătorul verifică fiecare DOI, reproduce fiecare cifră și fixează planul înainte de prima rulare

□ Verificări specifice prognozelor de volatilitate

- ▶ Look-ahead bias (h_t nu trebuie să se schimbe cînd se modifică r_t); pierdere robustă la aproximare (QLIKE, MSE); căutarea modelelor (Model Confidence Set sau Bonferroni); scara și convergența optimizatorului; DOI sau argumente arch inventate
- ▶ Prompturi reutilizabile și lista completă de verificare: [▶ Anexă](#)

Mini-studiu de caz și un punct de plecare pentru proiect

- O afirmație tipică a unui asistent: „GJR-t depășește GARCH-t datorită efectului de levier”; $d_t = \text{QLIKE}(\text{GJR-t}) - \text{QLIKE}(\text{GARCH-t})$, 2 692 de zile, 2016–2026: $\bar{d} = -0,025$, DM $t = -1,22$
- Implicația testabilă a levierului: câștigul apare după zilele de scădere
 - ▶ După $r_{t-1} < 0$ (1 223 de zile): $\bar{d} = -0,015$, $t = -0,51$; după $r_{t-1} \geq 0$ (1 469): $\bar{d} = -0,034$, $t = -1,12$: nesuștinută; 2016–2020 $t = -0,02$, 2021–2026 $t = -4,06$
 - ▶ Doar descriptiv (modele imbricate, fereastră în expansiune): continuarea calibrată este un test GW cu fereastră fixă pentru diferența dintre semne, cu regresia lui d_t pe $1(r_{t-1} < 0)$
- **Punct de plecare pentru proiect:** intră prognozele bazate pe învățare automată în Model Confidence Set alături de GARCH, GJR și EGARCH pentru S&P 500 și BET, 2016–2026?
 - ▶ Replicați întâi tabelul QLIKE; pre-înregistrați modelele, pierderile, împărțirile și rata de eroare; notați utilizarea AI în AI_USE.md și fiecare eroare depistată în AI_ERRORS.md (descrierea completă: [▶ Anexă](#))

Sinteză: un flux de decizie

- ▣ 1. **Detectăm:** $Q(10)$ pe r_t^2 și testul LM; volatility clustering este universal, persistența $\alpha + \beta$ este aproape de 1 pe toate piețele analizate
- ▣ 2. **Estimăm:** GARCH, GJR, EGARCH cu inovații Normale, Student-t, t asimetrice; randamente în %; verificăm convergența și parametrii la limită
- ▣ 3. **Diagnosticăm:** nivelul, pătratele și semnele lui $\hat{z}_t$ și cele mai mari valori; testele naive sînt conservatoare
- ▣ 4. **Prognostăm:** recursia dă dispersiile pe mai mulți pași; regula rădăcinii pătrate a timpului ignoră revenirea la medie
- ▣ 5. **Comparăm:** în afara eșantionului, QLIKE, GW cu fereastră mobilă și Model Confidence Set: GARCH depășește EWMA și Hist-20, modelele din familia GARCH sînt greu de departajat
- ▣ 6. **Raportăm incertitudinea:** e.s. robuste (valide dacă $\mathbb{E}z_t^4 < \infty$), teste care țin cont de frontieră, timpi de înjumătățire ca intervale $[h_{10}; \infty)$ cînd $\alpha + \beta \approx 1$

Autoevaluare și legătura cu Capitolul 6

Întrebări de verificare

- De ce supraestimează regula rădăcinii pătrate a timpului riscul pe 10 zile după o zi cu volatilitate ridicată?
- De ce se compară testul LR al inovațiilor Normale față de Student-t cu 2,71 și nu cu 3,84?
- De ce poate un interval simetric pentru timpul de înjumătățire să conțină valori negative?
- De ce diferența dintre VIX și volatilitatea GARCH nu măsoară variance risk premium?

Capitolele următoare

- **Capitolul 6:** volatilitate multivariată și corelații dinamice (DCC)
- **Capitolele 7–8:** Value at Risk și expected shortfall cu volatilitate GARCH și backtesting-ul lor
- **Capitolul 9:** volatilitatea realizată și memoria lungă
- **Seminarul 5:** recursia dispersiei pas cu pas, GARCH-t și GJR pe date reale, un răspuns AI de verificat, teste bootstrap și comparații de prognoze

Anexă: Datele folosite în acest capitol

Serie	Proprietar / sursă	Început	Obs.	Obs. pe an
S&P 500	S&P Dow Jones Indices	2000	6 714	251,4
BET	Bursa de Valori București	2000	6 670	249,8
BET-TR	Bursa de Valori București	2014	2 992	249,7
Bitcoin (BTC/USD)	burse crypto (compozit)	2014	4 384	365,3
EUR/RON, curs de referință	BNR	2005	5 352	252,4
Aur (XAU/USD)	piața spot	2000	6 922	259,2

- ▣ Prețuri zilnice de închidere până la 18 septembrie 2026; randamente $r_t = 100 (\ln P_t - \ln P_{t-1})$, în %
- ▣ Indici bursieri și aur: doar zilele lucrătoare; volatilitatea aurului este anualizată cu frecvența reală a observațiilor
- ▣ Bitcoin se tranzacționează în toate cele 7 zile ale săptămânii; indicele VIX al Chicago Board Options Exchange este folosit ca reper

 MFM_ch5_arch_effects

Anexă: Efecte ARCH, toate statisticile

Serie	Vol. (% anual)	Exces de kurtosis	$\hat{\rho}_1(r^2)$	Q(10) pe r^2	LM(5)
S&P 500	19,2	10,7	0,313	6133	1684
BET	22,1	11,1	0,330	2440	982
BET-TR	15,4	17,8	0,171	714	371
Bitcoin	66,6	12,0	0,137	213	115
EUR/RON	4,4	15,1	0,342	2420	871
Aur	17,6	7,7	0,110	744	329

▣ Valori critice la 5%: χ_{10}^2 : 18,3; χ_5^2 : 11,1; toate valorile $p < 0,001$

 MFM_ch5_arch_effects

Anexă: Teste ale scorului unilaterale și problema Davies

- Alternativa este unilaterală ($\alpha_i \geq 0$): testul χ^2 bilateral pierde putere
 - ▶ [Lee & King \(1993\)](#): test al scorului unilateral, construit pe suma componentelor scorului, $N(0, 1)$ sub H_0 , respinge doar în coada superioară
- Față de GARCH(1,1), ipoteza nulă $\alpha = 0$ lasă β neidentificat (problema Davies)
 - ▶ Statistica LM ARCH(q) este și testul scorului față de GARCH(p, q) [Lee & King \(1993\)](#): aceeași statistică servește ambele alternative

Anexă: Robert Engle și Premiul Nobel din 2003



Robert F. Engle (2022)

Foto: Jon Demske (2022); CC

BY-SA 4.0; Wikimedia Commons



Clive W.J. Granger (2008)

Foto: Olaf Storbeck (2008); CC

BY-SA 2.0; Wikimedia Commons

- **Premiul Nobel 2003:** Engle „pentru metode de analiză a seriilor de timp economice cu volatilitate variabilă în timp (ARCH)”
 - ▶ Împărțit cu Clive Granger (cointegrare)
- **Prelegerea Nobel:** [Engle \(2004\)](#), despre risc și volatilitate în practica financiară
- Tim Bollerslev, doctorandul lui Engle, a generalizat ARCH la GARCH în 1986

Anexă: Kurtosis-ul: rotunjirea și o traiectorie simulată lungă

- S&P 500, GARCH-N: condiția de moment este 0,990435, deci $K = 12,1$ are numitorul $1 - 0,990435$
 - ▶ Rotunjirea la $\hat{\alpha} = 0,121$, $\hat{\beta} = 0,860$ dă 0,9916 și $K = 13,5$: raportați astfel de funcții din estimări nerotunjite
- GARCH(1,1) simulat de pe slide-ul de simulare, un milion de zile
 - ▶ Exces de kurtosis 2,47 (teoretic 3,06); autocorelația de ordin 1 a lui ε_t^2 : 0,26
 - ▶ Kurtosis-ul de selecție converge încet: precizia ei depinde de momentul de ordin opt, infinit pentru acești parametri

Anexă: QMLE: variante ale teoremei

- Media estimată: scorul capătă termenul $\varepsilon_t / \sigma_t^2$, iar covarianța $(\kappa_z - 1)J^{-1}$ își schimbă forma
- IGARCH ($\alpha + \beta = 1$): staționaritatea strictă rămîne valabilă, iar QMLE rămîne consistent și asimptotic Normal [Lumsdaine \(1996\)](#)
- Cazul exploziv, $\mathbb{E} \ln(\alpha z_t^2 + \beta) \geq 0$: [Jensen & Rahbek \(2004\)](#) tratează (α, β) cu ω fixat, deoarece ω nu este identificat
- Cozi groase, $\kappa_z = \infty$: convergență mai lentă decît $\sqrt{n}$, distribuții-limită care nu sînt Normale [Hall & Yao \(2003\)](#); cvasi-verosimilități cu cozi groase, cu ajustarea scalei [Fan, Qi & Xiu \(2014\)](#)

Anexă: Corecția Li–Mak pentru autocorelațiile pătratelor reziduurilor

- Autocorelațiile pătratelor reziduurilor $\hat{r}_k$: $\sqrt{n} \hat{r} \rightarrow N(0, C)$, $C = I - H' J^{-1} H / (\kappa_z - 1)$ Li & Mak (1994)
 - ▶ $\hat{r} = (\hat{r}_1, \dots, \hat{r}_m)'$; I : matricea identitate; C : covarianța corectată, mai mică decât I pe diagonală; g_t , J : ca în teorema QMLE
 - ▶ $H_k = \mathbb{E}[g_t(z_{t-k}^2 - 1)]$: cît din dependența de ordin k absoarbe dispersia estimată; regula ARMA χ_{m-p-q}^2 nu se aplică
- S&P 500, QMLE Gaussian pentru GARCH(1,1): $C_{1,1} = 0,78$, $C_{5,5} = 0,93$, $C_{10,10} = 0,97$
 - ▶ Corecția este cea mai mare la decalaje mici, unde $\hat{\alpha}$ a preluat deja dependența; statistica corectată $n\hat{r}' C^{-1} \hat{r} = 19,1$, χ_{10}^2 sub H_0

 MFM_ch5_inference

Anexă: S&P 500: evaluarea prognozelor, toate statisticile

Model	QLIKE	MSE	DM t față de GARCH-t	MZ b	MZ R^2	Wald p
GARCH-N	0,751	22,3	-1,47	0,97	0,250	1,00
GARCH-t	0,757	22,8	–	0,88	0,238	0,80
GJR-t	0,732	21,8	-1,22	0,84	0,276	0,68
EGARCH-t	0,745	21,3	-0,36	1,24	0,293	0,71
EWMA	0,815	24,7	3,48	0,89	0,172	0,69
Hist-20	0,889	26,1	4,10	0,68	0,152	0,03

- ▣ Pierderi medii pe 2692 de zile; DM pe QLIKE, HAC cu 5 decalaje; t negativ: mai bun decât GARCH-t
- ▣ MZ: $r_t^2 = a + b h_t$; Wald p: testul $a = 0$, $b = 1$

 MFM_ch5_forecast_evaluation

Anexă: Giacomini–White și MCS: formule și tabelul complet

Model	QLIKE (W)	t necond.	GW	p	MCS p
GARCH-N	0,751	1,87	5,85	0,054	0,586
GARCH-t	0,743	–	–	–	0,353
GJR-t	0,738	-0,18	2,49	0,288	1,000
EGARCH-t	0,746	0,07	3,21	0,201	0,586
EWMA	0,815	3,20	11,40	0,003	0,008
Hist-20	0,889	3,87	16,41	< 0,001	0,001

- Testul condițional $\mathbb{E}[d_{t+1} | \mathcal{F}_t] = 0$ cu instrumentele $x_t = (1, d_t)$: $GW = n \bar{Z}' \hat{\Omega}^{-1} \bar{Z} \rightarrow \chi_2^2$, $Z_{t+1} = x_t d_{t+1}$ (valoarea critică 5,99); $\bar{Z}$: media lui Z_{t+1} , $\hat{\Omega}$: covarianța sa HAC, n : numărul de prognoze
- Fereastră mobilă $W = 1000$ de zile, reestimată în fiecare ianuarie, 2692 de prognoze; teste față de GARCH-t, HAC cu 5 decalaje
- MCS pe prognozele cu fereastră în expansiune: QLIKE, statistica T_R (cel mai mare $|t|$ al diferențelor de pierderi pe perechi), bootstrap staționar (bloc mediu 10, 10 000 de extrageri); MCS 90%: GARCH-N, GARCH-t, GJR-t, EGARCH-t

Anexă: Modele bazate pe scor, Realized GARCH și modele cu componente

- **Bazate pe scor (GAS)** Creal, Koopman & Lucas (2013): $\sigma_{t+1}^2 = \omega + \alpha s_t + \beta \sigma_t^2$, s_t scorul scalat al densității Student-t în raport cu σ_t^2
 - ▶ Scorul este mărginit în z_t : o valoare extremă ca reziduul EUR/RON de 154 modifică dispersia mult mai puțin decât în GARCH
- **Realized GARCH** Hansen, Huang & Shek (2012): adaugă o ecuație de măsurare care leagă σ_t^2 de o dispersie realizată
 - ▶ Folosește informația intrazilnică și reacționează mai repede; puntea spre [Capitolul 9](#)
- **GARCH-MIDAS** Engle, Ghysels & Sohn (2013): $\sigma_t^2 = \tau_t g_t$, o componentă lentă de termen lung τ_t determinată de date macro (frecvențe mixte)
 - ▶ g_t : o componentă GARCH(1,1) de medie 1 pentru variațiile pe termen scurt
 - ▶ Un nivel de termen lung variabil în timp preia schimbările de nivel care deplasează $\hat{\alpha} + \hat{\beta}$ spre 1

Anexă: Dincolo de dispersie: entropie și tail risk

- [Pele, Lazar & Dufour \(2017\)](#): entropia distribuției randamentelor intrazilnice și riscul de piață (EUR/JPY)
 - ▶ O entropie mai mare se asociază cu Value at Risk și expected shortfall intrazilnice mai mici; entropia prognozează apoi Value at Risk zilnic
- [Pele & Mazurencu-Marinescu-Pele \(2019\)](#): entropia randamentelor intrazilnice Bitcoin propusă ca semnal suplimentar pentru Value at Risk zilnic
- [Pele, Lazar & Mazurencu-Marinescu-Pele \(2019\)](#): o măsură neparametrică a cozii bazată pe entropie, comparată cu modelele standard de expected shortfall
- Volatilitatea GARCH intră direct în Value at Risk și expected shortfall: [Capitolele 7–8](#)

Anexă: Studiu de caz, metoda completă

- **Motivația:** GARCH este determinat de ε_t^2 oricare ar fi densitatea, deci un șoc extrem izolat poate produce o reacție excesivă a volatilității, care durează zile sau săptămâni (Secțiunea 1 din lucrare)
 - ▶ Cu o densitate asimetrică la stînga, un model pur bazat pe scor crește volatilitatea mai mult după randamente pozitive: opusul efectului de levier (Exemplul 2)
 - ▶ Modelele QSD, ec. (3): $f_{t+1} = \omega + \alpha \psi(y_t, X_t, f_t, \theta) + \beta f_t$, ψ scorul scalat al unei funcții de actualizare ρ care nu coincide neapărat cu $\log p$; teoria: consistență, normalitate asimptotică, testele LR și LM cu limite χ^2 (Secțiunea 3)
- **Estimarea:** $\zeta = 0$ rămîne în interiorul spațiului parametrilor prin ec. (31)–(32): $\zeta \in (-1, 1/2)$ și $\Psi(x) = x(1 - e^{-cx})/(1 + e^{-cx})$ aplicată ponderii, $c = 1000$
 - ▶ Testul PIT Diebold, Gunther & Tay (1998): $u_t = F(\varepsilon_t)$ i.i.d. $U(0, 1)$ dacă modelul este corect; cu estimatorul de verosimilitate maximă și Pierce (1982), se respinge dacă $|\sum_t \hat{u}_t - T/2|/\sqrt{T(1/12 - B\mathcal{I}(\hat{\theta})^{-1}B^\top)} > 1,96$, $B = \lim_{T \rightarrow \infty} \mathbb{E}[\partial \sum_t (u_t - T/2)/\partial \theta^\top]$, $\mathcal{I}$ informația Fisher, T lungimea eșantionului; detectează o medie PIT deplasată, nu orice abatere de la uniformitate
- **Date:** se elimină acțiunile cu mai puțin de 4000 de observații sau cu probleme de convergență: 400 de acțiuni (Secțiunea 5)
 - ▶ Varianta asimetrică, ec. (47): o distribuție Student-t asimetrică pentru ε_t , cu parametrul de asimetrie κ , și parametri separați (ζ, τ) pentru actualizare; $\tau < 0,5$ produce efect de levier oricare ar fi κ (Secțiunea 5.2)

Anexă: Studiu de caz, un exemplu și limitele indicate de autori

- Centene, 4330 de zile: $\hat{\xi} \approx 0,26$ (circa 4 grade de libertate) în toate cele trei modele, dar $\hat{\zeta} = 0,048$ (e.s. 0,027); LR 8,81 ($p = 0,003$) pentru $\xi = \zeta$ și 8,42 ($p = 0,004$) pentru $\zeta = 0$ (Tabelul 5); după o zi de crah din martie–aprilie 2008, volatilitatea GARCH-t rămîne mult peste cea Beta-t-GARCH, iar QSD se află între ele (Fig. 4)
- **Limitele indicate de autori**
 - ▶ Rezultatele mai bune decît cele ale GARCH-t și Beta-t-GARCH nu garantează adecvarea modelului QSD Student-t: testul PIT respinge cele trei modele pentru 40,0–46,0% din acțiuni (Tabelul 4)
 - ▶ În recursia nemodificată (30), $\zeta < 0$ sau $\zeta > 1/2$ nu definesc un model de volatilitate propriu-zis, iar $\zeta = 1/2$ cu $\varpi = 0$ este degenerat (Secțiunea 4.1)
 - ▶ Legea $N(T/2, T/12)$ pentru $\sum_t u_t$ este valabilă doar pentru parametri cunoscuți; cu parametri estimați testul PIT are nevoie de corecția de mai sus (Secțiunea 5.1)
- **Extinderi deschise** (Seminarul 5, C3)
 - ▶ Depășește actualizarea mărginită QSD modelul GJR-GARCH-t în QLIKE, în afara eșantionului, mai ales după martie 2020?
 - ▶ Reduce această actualizare influența reziduuului EUR/RON de 154?

Anexă: Bucla descoperirii: prompturi reutilizabile (1/2)

- Instrumentele sînt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și instrumente de căutare a literaturii științifice (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „Listează comparațiile în afara eșantionului dintre prognozele dispersiei bazate pe GARCH, HAR și învățare automată publicate după 2015, cu DOI, activ, funcție de pierdere, test și orizont.”
 - ▶ Verificăm fiecare DOI în Crossref; verificăm că pierderea este robustă la o aproximare zgomotoasă [Patton \(2011\)](#)
- **Ipoteze:** „Pentru afirmația că asimetria îmbunătățește prognozele pe o zi, listează mecanismele concurente (levier, feedback de volatilitate, cîteva zile de criză) și ce prezice fiecare pentru d_t după semnul lui r_{t-1} și pe subperioade.”
- **Date și cod:** „Scrie cod Python cu `arch` care reestimează GARCH-t și GJR-t în fiecare ianuarie pe o fereastră în expansiune, din fișierele de prețuri zilnice ale cursului, și salvează prognozele dispersiei pe o zi; niciun parametru nu folosește date de după originea prognozei.”
 - ▶ Replicăm întîi: QLIKE 0,757 (GARCH-t) și 0,732 (GJR-t), DM $t = -1,22$

Anexă: Bucla descoperirii: prompturi reutilizabile (2/2)

- **Robustețe:** „Scrie un plan pre-înregistrat: împărțiri după semnul lui r_{t-1} și pe subperioade, MSE pe lângă QLIKE, orizontul de 22 de zile, decalajul HAC și o corecție Bonferroni sau Model Confidence Set.”
 - Un placebo cu împărțiri aleatoare este calibrat doar dacă realocă blocuri de zile, păstrînd volatility clustering
- **Critica:** „Joacă rolul unui referent: ar putea aproximarea r_t^2 , un singur an de criză sau decalajul HAC să creeze rezultatul meu? Propune cîte un test pentru a verifica fiecare explicație.”
- **Raportul:** toate împărțirile și pierderile încercate, valorile p ajustate, codul, valorile de inițializare ale generatoarelor de numere aleatoare și versiunile pachetelor; o specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare
- **Perioade influente:** un an de criză poate domina $\bar{d}$; raportăm subperioadele și declarăm dinainte dacă vreun an poate fi exclus

Anexă: Punctul de plecare pentru proiect, complet

- Întrebarea: intră prognozele bazate pe învățare automată, pe date zilnice, în Model Confidence Set alături de GARCH, GJR și EGARCH pentru S&P 500 și BET, 2016–2026?
- Ramura cu dispersie realizată (HAR): setul de date al cursului cu dispersii realizate la 5 minute conține 40 de acțiuni americane mari, ianuarie 2015 – ianuarie 2026; pentru indicele S&P 500 și pentru BET nu există date intrazilnice, deci această ramură se aplică acțiune cu acțiune
- Replicăm întâi: tabelul QLIKE (GARCH- t 0,757, DM EWMA $t = 3,48$) și împărțirile din mini-studiul de caz
- Livrabile
 - ▶ O pre-înregistrare de o pagină: modele, pierderi, împărțiri, rata de eroare și ce ar infirma afirmația
 - ▶ Cod pe datele de piață ale cursului, Model Confidence Set la 10%, o autocritică în stilul unui referent; `AI_USE.md` și `AI_ERRORS.md`
- Codul mini-studiului de caz: [Quantlets/Ch_05/ai_discovery_case.py](#)

Anexă: Resurse suplimentare

▣ Cărți

- ▶ Franke, Härdle & Hafner (2019), capitolele despre modelele ARIMA și GARCH pentru serii financiare
- ▶ Francq & Zakoïan (2019): teoria matematică a modelelor GARCH

▣ Cursuri Quantinar

- ▶  Statistics of Financial Markets
- ▶  Applied Time Series Analysis with Python

▣ Cod

- ▶ Toate graficele și tabelele: [Quantlets/Ch_05](#); pachetul Python [Sheppard](#), [arch](#)

Bibliografie (1/6)

- ▣ Andersen, T.G., Bollerslev, T. (1998). Answering the skeptics: yes, standard volatility models do provide accurate forecasts. *International Economic Review*, 39(4), 885–905.
- ▣ Andrews, D.W.K. (2000). Inconsistency of the bootstrap when a parameter is on the boundary of the parameter space. *Econometrica*, 68(2), 399–405.
- ▣ Andrews, D.W.K. (2001). Testing when a parameter is on the boundary of the maintained hypothesis. *Econometrica*, 69(3), 683–734.
- ▣ Baillie, R.T., Bollerslev, T., Mikkelsen, H.O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30.
- ▣ Berkes, I., Horváth, L., Kokoszka, P. (2003). GARCH processes: structure and estimation. *Bernoulli*, 9(2), 201–227.
- ▣ Blasques, F., Francq, C., Laurent, S. (2023). Quasi score-driven models. *Journal of Econometrics*, 234(1), 251–275.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *Review of Economics and Statistics*, 69(3), 542–547.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.

Bibliografie (2/6)

- ▣ Christensen, K., Siggaard, M., Veliyev, B. (2023). A machine learning approach to volatility forecasting. *Journal of Financial Econometrics*, 21(5), 1680–1727.
- ▣ Clark, T.E., McCracken, M.W. (2001). Tests of equal forecast accuracy and encompassing for nested models. *Journal of Econometrics*, 105(1), 85–110.
- ▣ Creal, D., Koopman, S.J., Lucas, A. (2013). Generalized autoregressive score models with applications. *Journal of Applied Econometrics*, 28(5), 777–795.
- ▣ Diebold, F.X., Gunther, T.A., Tay, A.S. (1998). Evaluating density forecasts with applications to financial risk management. *International Economic Review*, 39(4), 863–883.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- ▣ Engle, R.F. (2004). Risk and volatility: econometric models and financial practice. *American Economic Review*, 94(3), 405–420.
- ▣ Engle, R.F., Ghysels, E., Sohn, B. (2013). Stock market volatility and macroeconomic fundamentals. *Review of Economics and Statistics*, 95(3), 776–797.
- ▣ Engle, R.F., Lilien, D.M., Robins, R.P. (1987). Estimating time varying risk premia in the term structure: the ARCH-M model. *Econometrica*, 55(2), 391–407.

Bibliografie (3/6)

- ▣ Engle, R.F., Ng, V.K. (1993). [Measuring and testing the impact of news on volatility](#). *Journal of Finance*, 48(5), 1749–1778.
- ▣ Fan, J., Qi, L., Xiu, D. (2014). [Quasi-maximum likelihood estimation of GARCH models with heavy-tailed likelihoods](#). *Journal of Business & Economic Statistics*, 32(2), 178–191.
- ▣ Francq, C., Zakoïan, J.-M. (2004). [Maximum likelihood estimation of pure GARCH and ARMA-GARCH processes](#). *Bernoulli*, 10(4), 605–637.
- ▣ Francq, C., Zakoïan, J.-M. (2019). [GARCH Models: Structure, Statistical Inference and Financial Applications](#), ed. a 2-a. Wiley.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), ed. a 5-a. Springer.
- ▣ Giacomini, R., White, H. (2006). [Tests of conditional predictive ability](#). *Econometrica*, 74(6), 1545–1578.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). [On the relation between the expected value and the volatility of the nominal excess return on stocks](#). *Journal of Finance*, 48(5), 1779–1801.
- ▣ Hall, P., Yao, Q. (2003). [Inference in ARCH and GARCH models with heavy-tailed errors](#). *Econometrica*, 71(1), 285–317.
- ▣ Hamilton, J.D., Susmel, R. (1994). [Autoregressive conditional heteroskedasticity and changes in regime](#). *Journal of Econometrics*, 64(1–2), 307–333.

Bibliografie (4/6)

- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- ▣ Hansen, P.R., Huang, Z., Shek, H.H. (2012). Realized GARCH: a joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6), 877–906.
- ▣ Hansen, P.R., Lunde, A. (2005). A forecast comparison of volatility models: does anything beat a GARCH(1,1)? *Journal of Applied Econometrics*, 20(7), 873–889.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ J.P. Morgan/Reuters (1996). RiskMetrics — Technical Document, ed. a 4-a. New York.
- ▣ Jensen, S.T., Rahbek, A. (2004). Asymptotic inference for nonstationary GARCH. *Econometric Theory*, 20(6), 1203–1226.
- ▣ Lamoureux, C.G., Lastrapes, W.D. (1990). Persistence in variance, structural change, and the GARCH model. *Journal of Business & Economic Statistics*, 8(2), 225–234.
- ▣ Lee, J.H.H., King, M.L. (1993). A locally most mean powerful based score test for ARCH and GARCH regression disturbances. *Journal of Business & Economic Statistics*, 11(1), 17–27.
- ▣ Li, W.K., Mak, T.K. (1994). On the squared residual autocorrelations in non-linear time series with conditional heteroskedasticity. *Journal of Time Series Analysis*, 15(6), 627–636.

Bibliografie (5/6)

- ▣ Lumsdaine, R.L. (1996). Consistency and asymptotic normality of the quasi-maximum likelihood estimator in IGARCH(1,1) and covariance stationary GARCH(1,1) models. *Econometrica*, 64(3), 575–596.
- ▣ Mandelbrot, B. (1963). The variation of certain speculative prices. *Journal of Business*, 36(4), 394–419.
- ▣ McLeod, A.I., Li, W.K. (1983). Diagnostic checking ARMA time series models using squared-residual autocorrelations. *Journal of Time Series Analysis*, 4(4), 269–273.
- ▣ Mincer, J., Zarnowitz, V. (1969). The evaluation of economic forecasts. În J. Mincer (ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*, NBER.
- ▣ Nelson, D.B. (1990). Stationarity and persistence in the GARCH(1,1) model. *Econometric Theory*, 6(3), 318–334.
- ▣ Nelson, D.B. (1991). Conditional heteroskedasticity in asset returns: a new approach. *Econometrica*, 59(2), 347–370.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). Modeling expected shortfall using tail entropy. *Entropy*, 21(12), 1204.

Bibliografie (6/6)

- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). Using high-frequency entropy to forecast Bitcoin's daily Value at Risk. *Entropy*, 21(2), 102.
- ▣ Pierce, D.A. (1982). The asymptotic effect of substituting estimators for parameters in certain types of statistics. *The Annals of Statistics*, 10(2), 475–478.
- ▣ Self, S.G., Liang, K.-Y. (1987). Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, 82(398), 605–610.
- ▣ Sheppard, K. arch: ARCH models and other tools for financial econometrics in Python (software documentation).
- ▣ West, K.D. (1996). Asymptotic inference about predictive ability. *Econometrica*, 64(5), 1067–1084.