



Modelarea piețelor financiare

Capitolul 5: Volatilitate condiționată — modele GARCH



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ACF: AutoCorrelation Function (funcția de autocorelație)
- AI: Artificial Intelligence (inteligență artificială)
- AIC: Akaike Information Criterion (criteriul informațional Akaike)
- AR: AutoRegressive (model) (model autoregresiv)
- ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ARIMA: AutoRegressive Integrated Moving Average (model) (model autoregresiv integrat cu medie mobilă)
- ARMA: AutoRegressive Moving Average (model) (model autoregresiv cu medie mobilă)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BNR: Banca Națională a României
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- EGARCH: Exponential GARCH (GARCH exponențial)
- ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- FIGARCH: Fractionally Integrated GARCH (GARCH integrat fracționar)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-M: GARCH-in-Mean (GARCH cu volatilitatea în ecuația mediei)
- GARCH-MIDAS: GARCH with Mixed Data Sampling (long-run component) (GARCH cu eșantionare mixtă a datelor (componentă de termen lung))
- GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- GAS: Generalised Autoregressive Score (model) (model cu scor autoregresiv generalizat)
- GED: Generalised Error Distribution (distribuția generalizată a erorilor)
- GJR: GJosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric GJosten–Jagannathan–Runkle)
- GJR-GARCH: GJosten–Jagannathan–Runkle GARCH (GARCH asimetric GJosten–Jagannathan–Runkle)

Acronime folosite în acest material (2/2)

- GW: Giacomini–White (test) (testul Giacomini–White)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- IGARCH: Integrated GARCH (GARCH integrat)
- LM: Lagrange Multiplier (multiplicatorul Lagrange)
- LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- MCS: Model Confidence Set (mulțimea de modele de încredere)
- MLE: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- MSE: Mean Squared Error (eroarea pătratică medie)
- MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- PIT: Probability Integral Transform (transformarea integrală de probabilitate)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)
- QQ: Quantile–Quantile (plot) (graficul cuantilă–cuantilă)
- QSD: Quasi Score-Driven (model) (model bazat pe un cvasi-scor)
- SUA: Statele Unite ale Americii
- VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)
- XAU: gold, ISO 4217 code (one troy ounce) (aur, codul ISO 4217 (o uncie troy))

Cuprins

Motivație

De la ARCH la GARCH

Estimare și alegerea modelului

Exemplu lucrat și rezultate pe piețe

Volatilitate asimetrică

Inovații și diagnostic

Prognoza și evaluarea prognozelor

Extensii și limite


Studiu de caz: volatilitate bazată pe un cvasi-scor

AI pentru descoperire științifică

Concluzii

Bibliografie

Episoade de volatilitate ridicată



Bursa din Amsterdam, 21 octombrie 1987, după prăbușirea din 19 octombrie

Foto: Bart Molendijk / Anefo (1987); CC0; Wikimedia Commons

- Prăbușirile nu se limitează la zile izolate: variațiile mari sunt urmate de variații mari
 - ▶ „Schimbările mari tind să fie urmate de schimbări mari, de orice semn” [Mandelbrot \(1963\)](#)
- Această **grupare a volatilității** este faptul stilizat 6 din Capitolul 1
- Volatilitatea intervine în calculul Value at Risk (Capitolul 7), al ponderilor portofoliului (Capitolul 4) și al prețurilor opțiunilor
- Putem folosi gruparea volatilității pentru a **prognoza** riscul de mâine și a evalua corect incertitudinea prognozei?

Datele folosite în acest capitol

Serie	Proprietar / sursă	Început	Obs.	Obs. pe an
S&P 500	S&P Dow Jones Indices	2000	6 714	251,4
BET	Bursa de Valori București	2000	6 670	249,8
BET-TR	Bursa de Valori București	2014	2 992	249,7
Bitcoin (BTC/USD)	burse cripto (compozit)	2014	4 384	365,3
EUR/RON, curs de referință	BNR	2005	5 352	252,4
Aur (XAU/USD)	piața spot	2000	6 922	259,2

- Prețuri zilnice de închidere până la 18 septembrie 2026; randamente $r_t = 100 (\ln P_t - \ln P_{t-1})$, în %
- Indici bursieri și aur: doar zilele lucrătoare; volatilitatea aurului este anualizată cu frecvența reală a observațiilor
- Bitcoin se tranzacționează 7 zile din 7; indicele VIX al Chicago Board Options Exchange este folosit ca reper

Recapitularea cunoștințelor necesare: grupare și cozi groase (Capitolul 1)

- Cozi groase: excesul de aplatizare S&P 500 10,7, BET 11,1, Bitcoin 12,0 (0 pentru distribuția Normală)
 - ▶ Volatilitatea anuală: Bitcoin 66,6%, S&P 500 19,2%, BET 22,1%
- S&P 500: autocorelația de ordin 1 a lui r_t este -0,099, a lui r_t^2 este 0,313
 - ▶ Toate cele 50 de autocorelații ale lui r_t^2 până la decalajul 50 ies din $\pm 0,024$; încă 0,053 la decalajul 50
- Semnul randamentului de mâine este aproape imprevizibil; mărimea lui nu: obiectul de modelat este $\text{Var}(r_t \mid \mathcal{F}_{t-1})$
- Grafice pentru ambele proprietăți: Quantlet-ul de mai jos și Capitolul 1

 MFM_ch5_arch_effects

Testarea efectelor ARCH

- **McLeod–Li** [McLeod & Li \(1983\)](#): Ljung–Box $Q(10)$ pe r_t^2 , χ_{10}^2 în absența grupării
- **Testul LM al lui Engle** [Engle \(1982\)](#): nR^2 din regresia lui $\hat{\varepsilon}_t^2$ pe o constantă și pe $\hat{\varepsilon}_{t-1}^2, \dots, \hat{\varepsilon}_{t-5}^2$, χ_5^2 ; $\hat{\varepsilon}_t = r_t - \bar{r}$
- Alternativa este unilaterală ($\alpha_i \geq 0$): testul χ^2 bilateral pierde putere
 - ▶ [Lee & King \(1993\)](#): test al scorului unilateral, construit pe suma componentelor scorului, $N(0, 1)$ sub H_0 , respinge doar în coada superioară
- Față de GARCH(1,1), ipoteza nulă $\alpha = 0$ lasă β neidentificat (problema Davies)
 - ▶ Statistica LM ARCH(q) este și testul scorului față de GARCH(p, q) [Lee & King \(1993\)](#): aceeași statistică servește ambele alternative

Efecte ARCH pe șase piețe

Serie	Vol. (% anual)	Exces aplatare	$\hat{\rho}_1(r^2)$	$Q(10)$ pe r^2	LM(5)
S&P 500	19,2	10,7	0,313	6133	1684
BET	22,1	11,1	0,330	2440	982
BET-TR	15,4	17,8	0,171	714	371
Bitcoin	66,6	12,0	0,137	213	115
EUR/RON	4,4	15,1	0,342	2420	871
Aur	17,6	7,7	0,110	744	329

- Valori critice la 5%: χ_{10}^2 : 18,3; χ_5^2 : 11,1; toate statisticile sunt mult peste ele (toate valorile $p < 0,001$)
- Gruparea este universală: acțiuni, crypto, un curs de schimb administrat și aur
- Cea mai slabă (dar tot decisivă) pentru Bitcoin și aur, cea mai puternică pentru S&P 500

Modelul ARCH al lui Engle (1982)

- Cadrul: $r_t = \mu + \varepsilon_t$, $\varepsilon_t = \sigma_t z_t$, inovațiile z_t i.i.d. cu media 0 și dispersia 1
 - ▶ Dispersia condiționată $\sigma_t^2 = \text{Var}(r_t \mid \mathcal{F}_{t-1})$ ($\mathcal{F}_{t-1}$: informația de la $t - 1$); necondiționată $\sigma^2 = \mathbb{E}\sigma_t^2$
- **ARCH(q)**: $\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2$ [Engle \(1982\)](#)
 - ▶ $\omega > 0$, $\alpha_i \geq 0$: dispersia este mereu pozitivă
- Un șoc mare ieri (ε_{t-1}^2 mare) crește dispersia de azi: grupare prin construcție
- **ARCH(1)**: dispersia necondiționată $\sigma^2 = \omega/(1 - \alpha_1)$, finită dacă $\alpha_1 < 1$
 - ▶ z_t Normal: applatizarea $3(1 - \alpha_1^2)/(1 - 3\alpha_1^2)$, finită doar dacă $3\alpha_1^2 < 1$
 - ▶ Este 3 la $\alpha_1 = 0$, depășește 3 pentru $0 < \alpha_1 < 1/\sqrt{3}$ și este infinită pentru $\alpha_1 \geq 1/\sqrt{3}$: cozi groase chiar cu inovații Normale

Robert Engle și Premiul Nobel din 2003



Robert F. Engle (2022)

Foto: Jon Demske (2022); CC

BY-SA 4.0; Wikimedia Commons



Clive W.J. Granger (2008)

Foto: Olaf Storbeck (2008); CC

BY-SA 2.0; Wikimedia Commons

- **Premiul Nobel 2003:** Engle „pentru metode de analiză a seriilor de timp economice cu volatilitate variabilă în timp (ARCH)”
 - ▶ Împărțit cu Clive Granger (cointegrare)
- **Prelegerea Nobel:** [Engle \(2004\)](#), despre risc și volatilitate în practica financiară
- Tim Bollerslev, doctorandul lui Engle, a generalizat ARCH la GARCH în 1986

De la ARCH la GARCH (Bollerslev, 1986)

- ▣ Problema ARCH: gruparea în datele reale durează luni de zile, deci q trebuie să fie mare (mulți parametri)
- ▣ **GARCH(1,1)** Bollerslev (1986): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$
 - ▶ $\omega > 0, \alpha \geq 0, \beta \geq 0$; α : reacția la știri; β : memoria dispersiei trecute
- ▣ Prin substituții succesive în recursie: $\sigma_t^2 = \frac{\omega}{1-\beta} + \alpha \sum_{j \geq 1} \beta^{j-1} \varepsilon_{t-j}^2$
 - ▶ Un ARCH(∞) cu ponderi descrescătoare geometric, cu doar trei parametri
- ▣ GARCH(p, q) adaugă decalaje; în practică GARCH(1,1) este modelul de bază Hansen & Lunde (2005)

GARCH(1,1) ca model ARMA pentru pătratele șocurilor

- Definim $\nu_t = \varepsilon_t^2 - \sigma_t^2$, surpriza din pătratul șocului ($\mathbb{E}[\nu_t | \mathcal{F}_{t-1}] = 0$)
- Atunci $\varepsilon_t^2 = \omega + (\alpha + \beta) \varepsilon_{t-1}^2 + \nu_t - \beta \nu_{t-1}$
 - ▶ Un ARMA(1,1) în ε_t^2 cu coeficientul autoregresiv $\alpha + \beta$
- Consecință: autocorelațiile lui ε_t^2 scad geometric, $\rho_k = \rho_1(\alpha + \beta)^{k-1}$
 - ▶ $\rho_1 = \alpha(1 - \beta^2 - \alpha\beta)/(1 - \beta^2 - 2\alpha\beta)$ dacă $\mathbb{E}\varepsilon_t^4 < \infty$ (Seminarul 5, A6)
 - ▶ S&P 500, GARCH(1,1) cu inovații Normale: $\rho_1 = 0,356$, $\rho_{10} = 0,298$; în eșantion 0,313 și 0,248
- De aceea $\alpha + \beta$ se numește **persistența** volatilității

Staționaritatea și dispersia necondiționată

- **Staționaritate în covarianță:** $\alpha + \beta < 1$; atunci

- ▶ $\sigma^2 = \mathbb{E}[\sigma_t^2] = \frac{\omega}{1 - \alpha - \beta}$

- Derivare: luăm valoarea așteptată în recursie, $\mathbb{E}\sigma_t^2 = \omega + (\alpha + \beta)\mathbb{E}\sigma_{t-1}^2$, și impunem $\mathbb{E}\sigma_t^2 = \mathbb{E}\sigma_{t-1}^2$

- **IGARCH** (GARCH integrat): $\alpha + \beta = 1$; dispersia necondiționată este infinită

- ▶ Totuși, dacă $\alpha > 0$ și z_t^2 este nedegenerat, procesul rămâne **strict** staționar: condiția $\mathbb{E} \ln(\alpha z_t^2 + \beta) < 0$ **Nelson (1990)** este îndeplinită din inegalitatea lui Jensen, deoarece $\mathbb{E} \ln(\alpha z_t^2 + \beta) < \ln(\alpha + \beta) = 0$

- Țintirea dispersiei: fixăm $\omega = \hat{\sigma}^2(1 - \alpha - \beta)$ cu dispersia de selecție $\hat{\sigma}^2$


Persistența și timpul de înjumătățire

- Prognoza pe mai mulți pași: $\mathbb{E}[\sigma_{t+h}^2 \mid \mathcal{F}_t] = \sigma^2 + (\alpha + \beta)^{h-1}(\sigma_{t+1}^2 - \sigma^2)$
 - Distanța față de dispersia de termen lung scade cu factorul $\alpha + \beta$ în fiecare zi
- **Timpul de înjumătățire:** numărul de zile după care jumătate dintr-un șoc de dispersie a dispărut
 - $(\alpha + \beta)^h = 0,5 \Rightarrow h_{1/2} = \frac{\ln 0,5}{\ln(\alpha + \beta)}$
- Exemple: $\alpha + \beta = 0,95$: 13,5 zile; 0,99: 69 de zile; 0,995: 138 de zile
- Schimbări mici ale lui $\alpha + \beta$ lângă 1 dau timpi de înjumătățire foarte diferiți: incertitudinea estimării contează (Seminarul 5)

Momentul de ordin patru și aplatizarea

- Cu z_t Normal, aplatizarea lui ε_t este $K = \frac{3[1 - (\alpha + \beta)^2]}{1 - (\alpha + \beta)^2 - 2\alpha^2}$
 - ▶ Finită doar dacă $(\alpha + \beta)^2 + 2\alpha^2 < 1$ (Seminarul 1, Exercițiul A9)
- S&P 500, GARCH(1,1) cu inovații Normale: $\hat{\alpha} = 0,120604$, $\hat{\beta} = 0,859878$
 - ▶ $(\hat{\alpha} + \hat{\beta})^2 + 2\hat{\alpha}^2 = 0,990435$: puțin sub 1, deci $K = 12,1$; aplatizarea de selecție a randamentelor: 13,7
- K este prost condiționat lângă frontiera momentelor: numitorul este $1 - 0,990435$
 - ▶ Rotunjirea la $\hat{\alpha} = 0,121$, $\hat{\beta} = 0,860$ dă 0,9916 și $K = 13,5$: raportați astfel de funcții din estimări nerotunjite
- Gruparea singură generează o mare parte din cozile groase; restul vine din z_t cu cozi groase (Secțiunea 6)

Simulare: GARCH produce gruparea volatilității



□ Sus: randamente Normale i.i.d.; jos: GARCH(1,1) cu aceeași dispersie necondiționată (1) și benzile $\pm 2\sigma_t$

Interpretare: grupare dintr-o regulă cu trei parametri

- Aceeași dispersie necondiționată, traiectorii foarte diferite: perioadele liniștite și rafalele apar doar în traiectoria GARCH
- Pe o traiectorie simulată lungă (un milion de zile)
 - ▶ Exces de aplatizare 2,47 (teoretic 3,06); autocorelația de ordin 1 a lui ε_t^2 : 0,26
 - ▶ Aplatizarea de selecție converge încet: precizia ei depinde de momentul de ordin opt, infinit pentru acești parametri
- Inovații Normale, dar randamente cu cozi groase: amestecul de dispersii creează cozile

EWMA: un caz particular de GARCH

- ▣ **EWMA** J.P. Morgan/Reuters (1996): $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, cu $\lambda = 0,94$ pentru date zilnice și randamente de medie zero
 - ▶ Ponderi $(1 - \lambda)\lambda^{j-1}$ pe pătratele randamentelor trecute: zilele recente contează cel mai mult
- ▣ EWMA este un IGARCH(1,1) cu $\omega = 0$, $\alpha = 1 - \lambda$, $\beta = \lambda$: niciun parametru de estimat
- ▣ Prețul simplității: fără revenire la medie
 - ▶ La închiderea zilei t , prognoza pentru orice orizont este egală cu dispersia actualizată pentru ziua următoare, σ_{t+1}^2 ; într-un model GARCH staționar, prognoza converge către σ^2
- ▣ Folosim EWMA ca reper în comparația prognozelor din Secțiunea 7

Recapitulare: ARCH și GARCH

Idei-cheie

- ▣ σ_t^2 este dispersia condiționată de informația disponibilă ieri; variază în funcție de mărimea șocurilor recente
- ▣ $\text{GARCH}(1,1) = \text{ARCH}(\infty)$ cu trei parametri; $\alpha + \beta$ este persistența
- ▣ $\alpha + \beta < 1$: dispersie de termen lung finită $\omega/(1 - \alpha - \beta)$ și timp de înjumătățire $\ln 0,5 / \ln(\alpha + \beta)$
- ▣ Gruparea creează cozi groase, chiar cu inovații Normale
- ▣ EWMA este cazul particular IGARCH cu $\omega = 0$

Verosimilitatea maximă

- Parametrii $\theta = (\mu, \omega, \alpha, \beta)$; dat fiind θ , recursia produce $\sigma_1^2(\theta), \dots, \sigma_n^2(\theta)$
- Log-verosimilitatea Normală: $\ell(\theta) = -\frac{1}{2} \sum_{t=1}^n [\ln 2\pi + \ln \sigma_t^2 + \varepsilon_t^2 / \sigma_t^2]$
 - Fiecare zi contribuie cu densitatea lui ε_t condiționată de trecut: verosimilitatea se factorizează în timp
- Fără formulă explicită: optimizare numerică sub restricțiile $\omega > 0, \alpha, \beta \geq 0, \alpha + \beta < 1$
- Pornirea: σ_1^2 se fixează la dispersia de selecție (efectul său dispăre cu rata β)
- Scara: randamente în %, astfel încât dispersia să fie de ordinul 1
 - EUR/RON (abatere standard zilnică de circa 0,28%) se estimează pe 10 r_t : nescalat, optimizatorul s-a oprit într-un optim local

QMLE: consistență și normalitate asimptotică

- **QMLE Gaussian:** maximizăm verosimilitatea Normală chiar dacă z_t nu este Normal [Bollerslev & Wooldridge \(1992\)](#)
- **Consistența** (GARCH(1,1)) [Berkas, Horváth & Kokoszka \(2003\)](#), [Francq & Zakoïan \(2004\)](#)
 - ▶ Staționaritate strictă $\mathbb{E} \ln(\alpha z_t^2 + \beta) < 0$; θ_0 într-o mulțime compactă; z_t^2 nedegenerat
 - ▶ Nicio condiție de moment asupra lui ε_t : cazurile IGARCH și cu dispersie infinită sunt acoperite
- **Normalitatea asimptotică** a lui $\vartheta = (\omega, \alpha, \beta)$ (GARCH pur, media cunoscută): adăugăm ϑ_0 interior și $\kappa_z = \mathbb{E} z_t^4 < \infty$
 - ▶ $\sqrt{n}(\hat{\vartheta} - \vartheta_0) \rightarrow N(0, (\kappa_z - 1)J^{-1})$, $J = \mathbb{E}[g_t g_t']$, $g_t = \partial \ln \sigma_t^2 / \partial \vartheta$; o medie estimată adaugă termenul de scor $\varepsilon_t / \sigma_t^2$ și schimbă această formă
 - ▶ Staționaritatea strictă permite $\alpha + \beta \geq 1$ (IGARCH: [Lumsdaine \(1996\)](#)); cazul exploziv, $\mathbb{E} \ln(\alpha z_t^2 + \beta) \geq 0$: [Jensen & Rahbek \(2004\)](#) tratează (α, β) cu ω fixat, deoarece ω nu este identificat
- „Sandvișul” $\hat{A}^{-1} \hat{B} \hat{A}^{-1}$ estimează $(\kappa_z - 1)J^{-1}$; inversa hessienei $\hat{A}^{-1}$ estimează $2J^{-1}$
 - ▶ A: minus hessiana medie; B: dispersia scorului; e.s. robustă / clasică = $\sqrt{(\kappa_z - 1)/2}$, 1 sub normalitate

QMLE: validitatea inferenței în aplicații

- S&P 500, GARCH(1,1) cu verosimilitate Normală: aplatizarea reziduurilor $\hat{\kappa}_z = 4,73$
 - ▶ Teoria: e.s. robustă / clasică = $\sqrt{(4,73 - 1)/2} = 1,37$; observat: 1,37 pentru $\hat{\alpha}$, 1,37 pentru $\hat{\beta}$
- Bitcoin: GARCH-t dă $\hat{\nu} = 3,18 < 4$: sub această lege $\mathbb{E}z_t^4 = \infty$, iar condiția normalității QMLE Gaussian nu este îndeplinită
 - ▶ Aplatizarea reziduurilor nu se stabilizează: 19,8 pe prima jumătate, 14,6 pe tot eșantionul; rapoartele e.s. 2,51 și 2,01
- Hall & Yao (2003): atunci QMLE Gaussian converge mai lent decât $\sqrt{n}$, spre o limită non-Gaussiană: statisticile t robuste ale QMLE Gaussian nu sunt valide
- Remedii: o cvasi-verosimilitate cu cozi groase, cu ajustarea scalei Fan, Qi & Xiu (2014), sau MLE Student-t (scor mărginit: nu cere momentul de ordin patru dacă legea este corectă), cu inferență bootstrap lângă frontiere

Inovații cu cozi groase

- **Student-t Bollerslev (1987)**: $z_t = \sqrt{(\nu - 2)/\nu} t_\nu$, dispersie unitară pentru $\nu > 2$
 - ▶ ν (grade de libertate): cu cât ν este mai mic, cu atât cozile sunt mai groase; momentul de ordin patru există doar pentru $\nu > 4$
- **t asimetric Hansen (1994)**: adaugă un parametru de asimetrie $\lambda \in (-1, 1)$
 - ▶ $\lambda < 0$: coada stângă este mai lungă (pierderile mari mai probabile decât câștigurile mari)
- **GED Nelson (1991)**: densitate $\propto \exp(-\frac{1}{2}|z/\lambda_\nu|^\nu)$
 - ▶ $\nu = 2$: distribuția Normală; $\nu = 1$: Laplace; $\nu < 2$: cozi mai groase (λ_ν asigură dispersia unitară)

Testarea la frontiera spațiului parametrilor

- $LR = 2(\ell_1 - \ell_0) \rightarrow \chi_m^2$ doar pentru restricții interioare (de ex. GJR față de GARCH: $\gamma = 0, m = 1$)
 - ▶ Modele neimbricate: $AIC = -2\ell + 2k$, $BIC = -2\ell + k \ln n$ (k parametri); mai mic este mai bun
- Restricțiile GARCH $\alpha, \beta \geq 0, 1/\nu \geq 0, \alpha + \beta \leq 1$ pun multe ipoteze nule **pe frontieră**
 - ▶ Un parametru pe frontieră, verosimilitate regulată, ceilalți parametri identificați și interiori: $LR \rightarrow \frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ [Self & Liang \(1987\)](#), [Andrews \(2001\)](#); valoarea critică la 5% este 2,71, nu 3,84
 - ▶ Cazuri: distribuția Normală față de distribuția Student-t ($1/\nu = 0$); GJR cu $\alpha = 0$ ($\gamma > 0$); IGARCH
 - ▶ Neacoperite: fără ARCH ($\alpha = 0$ lasă β neidentificat: limită nestandard [Andrews \(2001\)](#)) și mai multe restricții active simultan
- Testele Wald t pentru un parametru estimat la limită (de ex. $\hat{\alpha} = 0$) nu sunt $N(0, 1)$
 - ▶ Bootstrap-ul parametric din $\hat{\theta}$ este inconsistent când θ_0 este pe frontieră [Andrews \(2000\)](#): simulăm în schimb sub H_0

Teste la frontieră pe datele noastre

- Inovații Normale vs Student-t, GARCH(1,1): $LR = 311,0$ (S&P 500), 1082,0 (Bitcoin)
 - ▶ Mult peste 2,71: cozile groase sunt decisive; amestecul contează doar în cazurile la limită
- GJR-t, S&P 500: $\hat{\alpha} = 0,000$; testul său t nu este standard, iar legea χ^2_1 a LR pentru $\gamma = 0$ presupune $\alpha_0 > 0$
- IGARCH, $H_0: \alpha + \beta = 1$ (GARCH-t): $LR = 1,11$ (S&P 500), 1,14 (BET)
 - ▶ S&P 500: $p = 0,29$ (χ^2_1), 0,15 (amestec), 0,17 (bootstrap parametric sub H_0 , $B = 999$)
 - ▶ BET: $p = 0,28$, 0,14 și 0,17
- Sub H_0 , 52% din reestimări sunt la $\alpha + \beta = 1$, cum prezice amestecul: rădăcina unitară în dispersie nu poate fi respinsă pentru niciunul dintre indici

S&P 500: estimările GARCH(1,1)-t

Parametru	Estimare	E.s. robustă	E.s. clasică	Raport
ω	0,0157			
α	0,123	0,011	0,010	1,06
β	0,872	0,010	0,010	1,08
ν	6,26	0,48		
$\alpha + \beta$	0,9947			

- Randamente zilnice în %, 2000–2026; media $\hat{\mu} = 0,079\%$ pe zi
- Timp de înjumătățire 131 zile; volatilitatea de termen lung $\sqrt{251,4 \hat{\omega} / (1 - \hat{\alpha} - \hat{\beta})} = 27,3\%$ anual

Interpretare: estimările pentru S&P 500

- ▣ $\hat{\beta} = 0,872$: cea mai mare parte a dispersiei de azi este dispersia de ieri; $\hat{\alpha} = 0,123$: știrile adaugă o actualizare moderată
- ▣ Persistența 0,9947: șocurile de volatilitate durează luni, nu zile
- ▣ Volatilitatea de termen lung (27,3%) depășește volatilitatea de selecție (19,2%)
 - Lângă $\alpha + \beta = 1$, $\omega/(1 - \alpha - \beta)$ are un numitor foarte mic, ceea ce reduce precizia estimării
- ▣ $\hat{\nu} = 6,26$: inovațiile au cozi clar mai groase decât cele ale distribuției Normale
- ▣ Erorile standard robuste sunt cu circa 5–7% mai mari decât cele clasice pentru α și β

S&P 500: douăsprezece modele comparate prin BIC

ΔBIC	$N(0, 1)$	Student-t	t asimetric	GED
GARCH(1,1)	648,9	346,7	307,4	339,8
GJR-GARCH(1,1)	394,7	119,9	49,6	141,6
EGARCH(1,1)	372,9	74,8	0,0	111,4

- ▣ ΔBIC : BIC minus cel mai mic BIC dintre cele 12 modele (0 = modelul preferat)
- ▣ Contează două alegeri: o ecuație a dispersiei asimetrică și o inovație cu cozi groase și asimetrică
- ▣ Trecerea de la inovații Normale la inovații Student-t scade BIC cu circa 300; adăugarea asimetriei îl mai scade cu 230–270
- ▣ Câștigător: EGARCH cu inovații t asimetrice; Secțiunile 5–6 explică de ce

Recapitulare: Estimare

Idei-cheie


- ▣ GARCH se estimează prin verosimilitate maximă; verosimilitatea se construiește zi cu zi din recursie
- ▣ QMLE Gaussian este consistent fără condiții de moment; normalitatea sa în $\sqrt{n}$ cere $\mathbb{E}z_t^4 < \infty$, condiție care nu se verifică la Bitcoin sub legea Student-t estimată
- ▣ Distribuțiile Student-t, t asimetrică și GED surprind cozile groase pe care dinamica GARCH singură nu le explică
- ▣ Ipoteze nule pe frontieră ($1/\nu = 0$; GJR $\alpha = 0$): LR față de $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$; IGARCH: simulăm sub H_0 ; lipsa ARCH (β neidentificat) este nestandard
- ▣ Rescalăm seriile cu volatilitate mică; comparăm modelele neimbricate cu AIC/BIC

Exemplu lucrat: prognozele pe o zi și pe zece zile

- S&P 500, GARCH(1,1)-t: $\hat{\omega} = 0,0157$, $\hat{\alpha} = 0,123$, $\hat{\beta} = 0,872$, $\hat{\mu} = 0,079$
- Ultima zi $T = 18.09.2026$: $\hat{\varepsilon}_T = r_T - \hat{\mu} = 0,088$, dispersia filtrată $\hat{\sigma}_T^2 = 0,565$
 - ▶ $\hat{\sigma}_{T+1}^2 = \hat{\omega} + \hat{\alpha}\hat{\varepsilon}_T^2 + \hat{\beta}\hat{\sigma}_T^2 = \hat{\omega} + 0,0009 + 0,493 = 0,509$, adică 11,3% anual
- Dispersia de termen lung $\hat{\sigma}^2 = \hat{\omega}/(1 - \hat{\alpha} - \hat{\beta}) = 2,97$; ziua 10: $\hat{\sigma}^2 + (\hat{\alpha} + \hat{\beta})^9(\hat{\sigma}_{T+1}^2 - \hat{\sigma}^2)$
 - ▶ $= 2,97 + 0,953 \times (0,509 - 2,97) = 0,624$
- Dispersia pe 10 zile $\sum_{h=1}^{10} \hat{\sigma}_{T+h}^2 = 5,67$, volatilitatea 2,38%
 - ▶ Regula rădăcinii pătrate a timpului dă $\sqrt{10} \times 0,714 = 2,26\%$: prea puțin, deoarece $\hat{\sigma}_{T+1}^2 < \hat{\sigma}^2$ și volatilitatea este prognozată în creștere

 MFM_ch5_garch_estimation

Structura la termen a volatilității



□ Prognoza, din 18.09.2026, a volatilității medii pe următoarele h zile (GARCH(1,1)-t); punctat: nivelul de termen lung

Interpretare: revenire la medie sau nu

- ▣ S&P 500: de la 11,3% (ziua următoare) la 20,1% (un an), urcând încet spre nivelul de termen lung
- ▣ Aur: azi peste nivelul de termen lung, deci curba scade, de la 23,9% la 22,4%
- ▣ Bitcoin și EUR/RON: $\hat{\alpha} + \hat{\beta} = 1$ (IGARCH), fără nivel de termen lung
 - ▶ Prognoza dispersiei crește cu $\hat{\omega}$ pe zi: Bitcoin de la 54,1% la 108,3% într-un an
 - ▶ Un rezultat al estimării cu rădăcină unitară, care nu justifică singur o decizie de tranzacționare
- ▣ Prognozele GARCH pe orizonturi lungi moștenesc toată incertitudinea despre $\alpha + \beta$

GARCH(1,1)-t pe șase piețe


Serie	$\hat{\omega}$	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\alpha} + \hat{\beta}$	$h_{1/2}$ (zile)	$\hat{\nu}$	Vol. termen lung
S&P 500	0,0157	0,123	0,872	0,9947	131	6,26	27,3
BET	0,0448	0,192	0,799	0,9907	74	5,01	34,7
BET-TR	0,0755	0,206	0,713	0,9188	8	5,02	15,2
Bitcoin	0,1937	0,109	0,891	1,0000	∞	3,18	–
EUR/RON	0,0000	0,123	0,877	1,0000	∞	4,20	–
Aur	0,0107	0,049	0,944	0,9935	106	4,58	20,7

- Volatilitatea de termen lung în % anual (anualizată cu frecvența proprie a fiecărei serii); – când $\hat{\alpha} + \hat{\beta} \geq 0,999$
- EUR/RON: $\hat{\omega}$ este 0,0000 la patru zecimale (cursul se mișcă cu fracțiuni de ban în cele mai multe zile)

Interpretare: șase „personalități” ale volatilității

- Acțiuni (S&P 500, BET) și aur: persistență 0,99–0,995, timpi de înjumătățire de 3–6 luni de tranzacționare
- BET reacționează mai puternic la știri ($\hat{\alpha} = 0,192$) și uită mai repede decât S&P 500
 - ▶ BET-TR (doar 2014–2026): timp de înjumătățire 8 zile; un eșantion mai scurt și mai calm dă o persistență mai mică
- Bitcoin: cele mai groase cozi ($\hat{\nu} = 3,18$: moment de ordin patru infinit sub legea estimată) și rădăcină unitară în dispersie
- EUR/RON: un curs de schimb administrat; perioade lungi liniștite, apoi salturi
 - ▶ 6 mai 2025: +1,20% după zile de $\pm 0,004\%$: reziduu standardizat de 154

Persistența: cât de repede se sting șocurile?



□ Partea dintr-un șoc de dispersie încă prezentă după h zile, $(\hat{\alpha} + \hat{\beta})^h$; linia întreruptă: o jumătate


Interpretare: persistența

- ▣ Timpi de înjumătățire: S&P 500 131 zile, aur 106, BET 74, BET-TR 8
- ▣ Bitcoin și EUR/RON sunt pe linia orizontală: un $\alpha + \beta$ estimat de 1 înseamnă că șocurile nu se sting niciodată în model
- ▣ O persistență foarte mare poate fi aparentă: schimbările nivelului volatilității pot imita o rădăcină unitară
Lamoureux & Lastrapes (1990)
 - ▶ Alternative cu schimbare de regim: Hamilton & Susmel (1994)
- ▣ Regulă practică: raportați timpii de înjumătățire cu un interval de încredere (bootstrap parametric, Seminarul 5)

Metoda delta pentru volatilitatea de termen lung și timpul de înjumătățire

- Pentru o funcție netedă $g(\theta)$: $\widehat{\text{e.s.}} g(\hat{\theta}) \approx \sqrt{\nabla g' \hat{V} \nabla g}$, cu $\hat{V}$ covarianța robustă a lui $(\hat{\omega}, \hat{\alpha}, \hat{\beta})$
- S&P 500, GARCH(1,1)-t: volatilitatea de termen lung 27,3% anual, e.s. 10,8 puncte: gradientul dispersiei $\omega/(1 - \alpha - \beta)$ este scalat cu $1/(1 - \alpha - \beta)^2$; radicalul îl înmulțește cu $1/(2\sqrt{\cdot})$, deci $\partial v / \partial p \propto (1 - p)^{-3/2}$
- Timpul de înjumătățire $h = \ln 0,5 / \ln p$, $p = \alpha + \beta$: $\partial h / \partial p = -\ln 0,5 / [p (\ln p)^2] = 24\,789$ la $\hat{p} = 0,994712$
 - ▶ $\widehat{\text{e.s.}}(\hat{p}) = 0,0047$, deci $\widehat{\text{e.s.}}(\hat{h}) \approx 116$ zile pentru $\hat{h} = 131$: un interval simetric ar include timpi de înjumătățire negativi
- Liniarizarea eșuează deoarece $h(p)$ explodează când $p \rightarrow 1$
 - ▶ Transformăm în schimb un interval pentru p (h este monotonă): $[0,9855; 1,0039]$ dă $h \in [48; \infty)$
 - ▶ Sau folosim un bootstrap parametric și un test simulat sub H_0 (Seminarul 5, B7)

S&P 500: volatilitatea GARCH și VIX




□ Volatilitatea condiționată GARCH(1,1)-t anualizată $\hat{\sigma}_t \sqrt{252}$ și VIX, volatilitatea implicită pe 30 de zile, 2000–2026

Interpretare: volatilitate statistică și volatilitate implicită

- ▣ Corelația celor două serii: 0,89; GARCH folosește doar randamentele trecute, VIX folosește prețurile opțiunilor
- ▣ VIX mediu 19,8% față de volatilitatea GARCH medie 17,0%; VIX este mai mare în 84% din zile
 - ▶ O diferență între volatilitatea implicită și cea statistică, în concordanță cu o **primă de risc a dispersiei** (cumpărătorii de opțiuni plătesc pentru asigurarea împotriva volatilității); diferă și orizonturile (30 de zile față de o zi)
 - ▶ Prima propriu-zisă compară VIX^2 cu o prognoză pe 30 de zile a dispersiei sub probabilitatea reală
- ▣ Intervalul GARCH: de la 6,2% (octombrie 2017) la 111% (martie 2020)
- ▣ GARCH reacționează cu o zi întârziere prin construcție: își actualizează prognoza după observarea șocului

Detaliu: prăbușirea COVID-19, 2020




■ Ianuarie–iulie 2020: randamente absolute (anualizate), volatilitatea GARCH-t și GJR-GARCH-t, VIX

MFM_ch5_sp500_vix

Interpretare: COVID-19

- ▣ 16 martie 2020: $r_t = -12,8\%$, cea mai mare scădere zilnică din eșantion; VIX a închis la 82,7%
- ▣ Volatilitatea maximă a modelelor pe 17 martie: GARCH-t 111%, GJR-GARCH-t 127%
 - ▶ GJR urcă mai sus deoarece șocurile au fost negative (Secțiunea 5)
- ▣ 24 februarie 2020 ($r_t = -3,41\%$): VIX a sărit în aceeași zi, de la 17,1% la 25,0%
 - ▶ GARCH-t s-a mișcat abia a doua zi, de la 12,2% la 22,5%: piețele evaluează știrile imediat, GARCH doar reacționează
- ▣ După vârf, abaterea prognozei dispersiei de la nivelul de termen lung scade cu factorul $\alpha + \beta$ pe zi; traiectoria realizată reflectă și șocurile noi

BET, Bitcoin, EUR/RON și aur



- Volatilitatea condiționată GJR-GARCH-t, anualizată cu frecvența fiecărei serii (Bitcoin: 365 de zile)

Interpretare: patru piețe

- ▣ BET: criza din 2008 domină; apoi vârfuri scurte și abrupte; nivelul actual 26,4%
- ▣ Bitcoin: volatilitatea de 50–100% este normală; martie 2020 este vârful cel mai înalt
- ▣ EUR/RON: volatilitate mare până în 2012, apoi o perioadă lungă de calm administrat, cu rafale în 2022 și 2025
 - ▶ Volatilitate aproape de zero în multe zile: un GARCH zilnic descrie slab un curs administrat
- ▣ Aur: vârfuri de 52% (2008), 31% (2013), 41% (2020) și un nou maxim de 53% în 2026

Recapitulare: Rezultate pe piețe

Idei-cheie

- ▣ Prognozele pe un pas și pe mai mulți pași rezultă din recursie; dispersia pe 10 zile este suma dispersiilor zilnice
- ▣ Persistența este mare peste tot; timpii de înjumătățire variază de la circa o săptămână (BET-TR) la câteva luni
- ▣ Rădăcinile unitare estimate (Bitcoin, EUR/RON) fac prognozele de termen lung lipsite de sens
- ▣ GARCH urmărește îndeaproape VIX, dar cu întârziere; VIX este mai mare în medie (o diferență implicită–statistică, în concordanță cu o primă de risc a dispersiei)

Șocurile negative cresc mai mult volatilitatea

- Faptul stilizat 9 (Capitolul 1): randamentele negative cresc volatilitatea viitoare mai mult decât cele pozitive de aceeași mărime
- **Efectul de levier:** un preț în scădere crește raportul datorii/capital propriu, deci acțiunea devine mai riscantă
 - ▶ **Feedback-ul volatilității:** volatilitatea așteptată mai mare crește randamentul cerut, deci prețurile scad acum
- GARCH(1,1) nu vede semnul: ε_{t-1}^2 este același pentru -3 și $+3$
- Două soluții: GJR adaugă un termen pentru șocurile negative, EGARCH modelează logaritmul dispersiei

GJR-GARCH (Glosten, Jagannathan și Runkle, 1993)

- $\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, cu $I_{t-1} = 1$ dacă $\varepsilon_{t-1} < 0$ Glosten, Jagannathan & Runkle (1993)
 - ▶ Știri bune: panta α ; știri proaste: panta $\alpha + \gamma$; $\gamma > 0$ înseamnă asimetrie
 - ▶ Pozitivitatea: $\omega > 0$, $\alpha \geq 0$, $\alpha + \gamma \geq 0$, $\beta \geq 0$; γ poate fi negativ (aurul, mai jos)
- Persistența cu z_t simetric: $\alpha + \gamma/2 + \beta$ (jumătate din șocuri sunt negative)
 - ▶ Dispersia de termen lung $\omega/(1 - \alpha - \gamma/2 - \beta)$, finită dacă $\alpha + \gamma/2 + \beta < 1$; pentru z_t asimetric, $1/2$ se înlocuiește cu $\mathbb{E}[z_t^2 1(z_t < 0)]$ (Seminarul 5, A2)
- Testul simetriei: $H_0: \gamma = 0$ printr-un test t sau prin LR față de GARCH(1,1)
- S&P 500: $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t = 10,0$), $\hat{\beta} = 0,881$


EGARCH (Nelson, 1991)

- $\ln \sigma_t^2 = \omega + \alpha (|z_{t-1}| - \mathbb{E}|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$ Nelson (1991)
 - ▶ Efectul de mărime α , efectul de semn γ ; $\gamma < 0$: șocurile negative cresc volatilitatea mai mult
- Forma logaritmică păstrează $\sigma_t^2 > 0$ fără restricții de semn asupra parametrilor
- Persistența: β (staționar dacă $|\beta| < 1$)
- S&P 500: $\hat{\alpha} = 0,138$, $\hat{\gamma} = -0,165$ ($t = -15,2$), $\hat{\beta} = 0,979$
- În arch, $\mathbb{E}|z|$ este fixat la $\sqrt{2/\pi}$, valoarea sa sub distribuția Normală

Curba de impact a știrilor

- **Curba de impact a știrilor Engle & Ng (1993):** σ_t^2 ca funcție de ε_{t-1} , cu σ_{t-1}^2 fixată la dispersia de selecție
 - ▶ GARCH: o parabolă simetrică în jurul lui 0
 - ▶ GJR: două semi-parabole cu pante diferite
 - ▶ EGARCH: exponențială în $|\varepsilon|$, înclinată de γ
- Ea izolează modul în care fiecare model transformă o zi de știri în dispersia de mâine
- Engle și Ng propun și testele de asimetrie folosite la diagnostic (Secțiunea 6)

Curbe de impact al știrilor pentru S&P 500



□ Dispersia de a doua zi după un șoc ε_{t-1} (în %), pentru cele trei modele estimate cu inovații Student-t

Interpretare: impactul știrilor

- Dispersia de pornire 1,47 (dispersia de selecție, %²)
- Un șoc de -3% : GJR dă 3,16, EGARCH 2,76; un șoc de $+3\%$: GJR 1,31, EGARCH 1,22
 - ▶ Prognoza dispersiei după știri proaste este de 2,4 ori cea după știri bune în GJR, de 2,3 ori în EGARCH (rapoarte de niveluri, nu de creșteri)
- GARCH simetric dă 2,40 pentru ambele semne: prea mult după știrile bune, prea puțin după cele proaste
- Pentru S&P 500, $\hat{\alpha} = 0$ în GJR: șocurile pozitive nu cresc deloc volatilitatea

Asimetria pe șase piețe

Serie	$\hat{\gamma}_{GJR}$	t	LR vs GARCH	valoare p	$\hat{\gamma}_{EGARCH}$	t
S&P 500	0,205	10,0	235,7	< 0,001	-0,165	-15,2
BET	0,043	2,1	4,9	0,026	-0,028	-2,6
BET-TR	0,111	2,9	10,3	0,001	-0,063	-3,5
Bitcoin	-0,013	-0,7	0,7	0,416	0,015	1,2
EUR/RON	0,039	3,0	9,3	0,002	-0,040	-2,5
Aur	-0,043	-4,7	27,6	< 0,001	0,038	5,7

- Toate modelele cu inovații Student-t; statistici t cu erori standard robuste; $LR \sim \chi_1^2$ (valoarea critică 3,84) dacă densitatea Student-t este corectă, altfel ne bazăm pe t robust, el însuși $N(0, 1)$ doar dacă ceilalți parametri sunt interiori (nu pentru $\hat{\alpha} = 0$)
- Asimetria: $\hat{\gamma} > 0$ în GJR și $\hat{\gamma} < 0$ în EGARCH pentru aceeași direcție (știrile proaste contează mai mult)

Interpretare: unde este efectul de levier?

- S&P 500: foarte puternic ($LR = 235,7$); efectul de levier clasic al unui indice bursier dezvoltat
 - ▶ BET și BET-TR: prezent, dar slab ($LR = 4,9$ și $10,3$)
- Bitcoin: nu se detectează asimetrie ($LR = 0,7$); în acest eșantion, creșterile cripto sunt cam la fel de volatile ca prăbușirile
- Aur: asimetrie **inversă** ($\hat{\gamma}_{GJR} = -0,043$): creșterile de preț cresc volatilitatea mai mult
 - ▶ În concordanță cu rolul aurului ca activ de refugiu: crește în perioadele agitate
- EUR/RON: GJR $\hat{\gamma} > 0$, EGARCH $\hat{\gamma} < 0$: scăderile cursului (aprecierea leului) cresc volatilitatea ceva mai mult

Recapitulare: Asimetrie

Idei-cheie

- GARCH simetric ignoră semnul știrilor; datele bursiere resping puternic această ipoteză
- GJR adaugă o pantă γ pentru șocurile negative; EGARCH modelează $\ln \sigma_t^2$ cu un termen de semn
- Curba de impact a știrilor arată direct asimetria
- Asimetria depinde de piață: șocurile negative contează mai mult la acțiuni (slab la BET) și la EUR/RON; nu este detectată la Bitcoin; este inversă la aur



Reziduuri standardizate: proprietăți așteptate

- ▣ **Reziduul standardizat:** $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$; dacă modelul este corect, $\hat{z}_t$ este aproape i.i.d. cu dispersia 1
- ▣ Verificări
 - ▶ Fără autocorelație în $\hat{z}_t$: Ljung–Box $Q(10)$ pe $\hat{z}_t$ (ecuația mediei)
 - ▶ Fără grupare rămasă: $Q(10)$ pe $\hat{z}_t^2$ și testul LM(5) (ecuația dispersiei)
 - ▶ Fără asimetrie rămasă: testele de asimetrie [Engle & Ng \(1993\)](#)
 - ▶ Distribuția: comparăm $\hat{z}_t$ cu densitatea presupusă (grafic QQ)

Testele de asimetrie (Engle și Ng, 1993)

- ▣ Estimăm regresia $\hat{z}_t^2 = b_0 + b_1 S_{t-1}^- + b_2 S_{t-1}^- \hat{\varepsilon}_{t-1} + b_3 S_{t-1}^+ \hat{\varepsilon}_{t-1} + u_t$
 - ▶ $S_{t-1}^- = 1$ dacă $\hat{\varepsilon}_{t-1} < 0$, altfel 0; $S_{t-1}^+ = 1 - S_{t-1}^-$; termenii de mărime folosesc reziduul nestandardizat $\hat{\varepsilon}_{t-1}$ (ec. 18 din Engle & Ng (1993))
- ▣ **Asimetria de semn** (b_1): influențează semnul negativ al șocului pătratul reziduului următor?
- ▣ **Asimetria legată de mărimea șocurilor negative / pozitive** (b_2, b_3): contează mărimea șocurilor negative / pozitive dincolo de model?
- ▣ Testul comun: $nR^2 \sim \chi_3^2$ (valoarea critică la 5%: 7,81); omite gradientul dispersiei estimate, deci este conservator (Engle și Ng)

S&P 500: sunt inovațiile Normale?



- Reziduurile standardizate ale GARCH(1,1) cu inovații Normale: logaritmul densității și graficul QQ față de distribuția Normală și distribuția Student-t

Interpretare: cozile după GARCH

- ▣ Excesul de aplatizare scade de la 10,7 (randamente) la 1,73 (reziduuri standardizate): GARCH explică cea mai mare parte
- ▣ Dar nu tot: Jarque–Bera 1153; asimetria -0,53
 - ▶ 15 reziduuri sub -4 ; numărul așteptat este 0,21 sub distribuția Normală și 8,5 sub distribuția Student-t cu $\nu = 6,3$
 - ▶ Cel mai mare în valoare absolută: $\hat{z} = -6,6$ pe 27 februarie 2007, o scădere mare într-o perioadă calmă
- ▣ Coda stângă este mai lungă decât cea dreaptă: t asimetric cu $\hat{\lambda} = -0,150$ (GJR, $\hat{\eta} = 7,7$)
- ▣ De aceea BIC preferă inovațiile t asimetrice pentru S&P 500

S&P 500: diagnosticul a cinci modele

Model	$Q(10)$ pe $\hat{z}$	$Q(10)$ pe $\hat{z}^2$	LM(5)	Asim. semn t	Comun χ^2_3
GARCH-N	21,2	16,4	8,0	3,64	41,8
GARCH-t	21,9	13,6	5,8	3,56	40,7
GJR-t	22,3	10,2	4,5	3,61	28,1
EGARCH-t	27,6	10,5	8,2	2,04	9,9
GJR-t asimetric	19,7	10,7	5,0	3,91	31,8

- ▣ Valori critice la 5%: χ^2_{10} : 18,3; χ^2_5 : 11,1; χ^2_3 : 7,81; $|t| > 1,96$
- ▣ Înainte de modelare, $Q(10)$ pe r_t^2 era 6133


Interpretare: ce spun diagnosticele

- Testele naive nu detectează grupare rămasă: $Q(10)$ pe $\hat{z}^2$ scade de la 6133 la 10–16, $LM(5)$ nu este semnificativ; urmează diagnosticele ajustate pentru parametri
- Modelul GARCH simetric este respins de testul de asimetrie (comun 40,7): asimetrie rămasă
 - ▶ Modelul GJR este de asemenea respins (28,1); EGARCH se apropie cel mai mult (9,9, $p = 0,020$)
- $Q(10)$ pe $\hat{z}$ în jur de 20–28: o autocorelație în medie, pe care media constantă o ignoră
- Cu $n = 6\,714$, efectele mici sunt semnificative: judecați mărimea economică, nu doar valorile p

Diagnosticul reziduurilor depinde de parametrii estimați

- $\hat{z}_t$ depinde de $\hat{\theta}$: statistica Ljung–Box pe $\hat{z}_t^2$ nu este exact χ_m^2 Li & Mak (1994)
 - ▶ Autocorelațiile pătratelor reziduurilor $\hat{r}_k$: $\sqrt{n} \hat{r} \rightarrow N(0, C)$, $C = I - H' J^{-1} H / (\kappa_z - 1)$
 - ▶ $H_k = \mathbb{E}[g_t(z_{t-k}^2 - 1)]$: cât din dependența de ordin k absoarbe dispersia estimată; regula ARMA χ_{m-p-q}^2 nu se aplică
- S&P 500, QMLE Gaussian pentru GARCH(1,1): $C_{1,1} = 0,78$, $C_{5,5} = 0,93$, $C_{10,10} = 0,97$
 - ▶ Corecția este cea mai mare la decalaje mici, unde $\hat{\alpha}$ a preluat deja dependența
- $Q(10)$ pe $\hat{z}_t^2$: Ljung–Box 16,4 ($p = 0,089$); corectat $n \hat{r}' C^{-1} \hat{r} = 19,1$ ($p = 0,038$): verdictul la 5% se inversează
- Testul naiv este conservator: respinge prea rar o ecuație a dispersiei greșit specificată; testul comun de asimetrie are aceeași limită

Diagnostic: pătratele randamentelor și pătratele reziduurilor



- S&P 500: autocorelațiile lui r_t^2 și ale lui $\hat{z}_t^2$ din GJR-GARCH-t, decalaje 1–30
- După model, autocorelațiile sunt în interiorul benzii i.i.d.: la aceste decalaje nu se mai detectează dinamică a dispersiei

Diagnostic pe alte piețe

- BET: $Q(10)$ pe $\hat{z} = 116,6$: autocorelație puternică în medie (tranzacționare redusă, Capitolul 2)
 - ▶ Remediul: o ecuație a mediei $AR(1)$, $r_t = \mu + \phi r_{t-1} + \varepsilon_t$
- Bitcoin: $Q(10)$ pe $\hat{z}^2 = 4,7$ și statistica comună de asimetrie 1,3 nu resping
 - ▶ Sub legea Student-t estimată ($\hat{\nu} = 3,18 < 4$), $\text{Var}(z_t^2) = \infty$: calibrarea χ^2 a testelor pe $\hat{z}_t^2$ nu este justificată; verificăm și $|\hat{z}_t|$
- EUR/RON: exces de aplatizare reziduală 3190, provocat de un singur reziduu de 154 (mai 2025)
 - ▶ O singură observație poate domina diagnosticele: priviți mereu cele mai mari reziduuri
- Aur: EGARCH lasă grupare ($Q(10)$ pe $\hat{z}^2 = 48,8$) deși BIC-ul său este printre cele mai bune

Recapitulare: Inovații și diagnostic

Idei-cheie

- ▣ Reziduurile standardizate trebuie să arate i.i.d.: le testăm nivelul, pătratele și semnele
- ▣ GARCH elimină gruparea și cea mai mare parte a aplatizării, nu și asimetria
- ▣ Pentru S&P 500 sunt necesare atât inovațiile cu cozi groase și asimetrice, cât și dispersia asimetrică
- ▣ Diagnosticalele pot contrazice criteriile informaționale; un singur reziduu extrem le poate determina

Problema variabilei aproximative

- Volatilitatea nu este observată niciodată: comparăm prognozele cu o **aproximare** zgomotoasă, de ex. r_t^2
- $r_t^2 = \sigma_t^2 z_t^2$ este nedeplasat ($\mathbb{E}[r_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2$ pentru $\mu = 0$), dar foarte zgomotos
 - ▶ R^2 -ul său față de dispersia reală este mic chiar pentru o prognoză perfectă [Andersen & Bollerslev \(1998\)](#)
 - ▶ S&P 500: ignorăm media, deoarece $\hat{\mu}^2 = 0,0062$ față de o dispersie zilnică medie de 1,47 (%²), o deplasare sub 1%
- [Patton \(2011\)](#): doar unele funcții de pierdere ordonează corect prognozele cu o aproximare zgomotoasă
 - ▶ Robuste: MSE $(r_t^2 - h_t)^2$ și **QLIKE** $r_t^2/h_t + \ln h_t$, cu h_t prognoza dispersiei
 - ▶ Nerobuste: pierderile pe volatilitate $|r_t| - \sqrt{h_t}$ sau pe logaritmi
- QLIKE este (până la constante) minus log-verosimilitatea Normală; penalizează mai mult subestimarea


Mincer–Zarnowitz și Diebold–Mariano

- **Regresia Mincer–Zarnowitz** Mincer & Zarnowitz (1969): $r_t^2 = a + b h_t + u_t$
 - ▶ Prognoză nedeplasată: $a = 0$, $b = 1$ (test Wald comun cu erori HAC); R^2 măsoară conținutul informațional
 - ▶ $b < 1$: prognoze prea dispersate (prea mari când sunt mari, prea mici când sunt mici)
- **Testul Diebold–Mariano** Diebold & Mariano (1995): diferența de pierderi $d_t = L(r_t^2, h_t^A) - L(r_t^2, h_t^B)$
 - ▶ $DM = \bar{d} / \widehat{s.e.}(\bar{d})$ cu eroare standard HAC; $\approx N(0, 1)$ sub acuratețe egală
 - ▶ $DM < -1,96$: modelul A semnificativ mai bun

Schema de evaluare în afara eșantionului

- ▣ S&P 500; perioada de prognoză 2016–2026: 2 692 prognoze pentru ziua următoare
- ▣ Parametrii reestimați la începutul fiecărui an pe toate datele din 2000 (fereastră în expansiune)
 - ▶ În cursul anului, dispersia este actualizată zilnic cu parametri ficși: fără informație din viitor
- ▣ Modele: GARCH cu inovații Normale și Student-t, GJR-t, EGARCH-t
- ▣ Repere: EWMA ($\lambda = 0,94$) și dispersia istorică pe 20 de zile (Hist-20)
- ▣ De asemenea, prognoze ale dispersiei cumulate pe 22 de zile (o lună) pe 122 ferestre nesuprapuse

Proгноze și variații observate, 2016–2026




□ Prognozele volatilității pentru ziua următoare (anualizate) din GJR-GARCH-t și EWMA; puncte turcoaz: $|r_t|\sqrt{252}$

S&P 500: evaluarea prognozelor, 2016–2026

Model	QLIKE	MSE	DM t vs GARCH-t	MZ b	MZ R^2	Wald p
GARCH-N	0,751	22,3	-1,47	0,97	0,250	1,00
GARCH-t	0,757	22,8	—	0,88	0,238	0,80
GJR-t	0,732	21,8	-1,22	0,84	0,276	0,68
EGARCH-t	0,745	21,3	-0,36	1,24	0,293	0,71
EWMA	0,815	24,7	3,48	0,89	0,172	0,69
Hist-20	0,889	26,1	4,10	0,68	0,152	0,03

- Pierderi medii pe 2692 zile; DM pe QLIKE, HAC cu 5 decalaje; t negativ: mai bun decât GARCH-t
- MZ: $r_t^2 = a + b h_t$; Wald p: testul $a = 0$, $b = 1$

QLIKE relativ la GARCH-t



- QLIKE mediu al fiecărui model minus cel al GARCH-t, cu statistica t Diebold–Mariano

Interpretare: există un model mai bun decât GARCH(1,1)?

- Cel mai bun QLIKE: GJR-t (0,732); dar diferențele din familia GARCH nu sunt semnificative (DM t de la -1,47 la -0,36)
- EWMA și Hist-20 sunt semnificativ mai slabe (DM t = 3,48 și 4,10)
 - ▶ Revenirea la medie și parametrii estimați aduc un câștig
- MZ: nedeplasarea nu este respinsă pentru prognozele de tip GARCH (b aproape de 1, Wald $p > 0,6$); este respinsă pentru Hist-20 ($p = 0,03$)
- R^2 de doar 0,15–0,29: zgomotul lui r_t^2 , nu un model prost
- Același mesaj ca Hansen & Lunde (2005): GARCH(1,1) este greu de bătut; asimetria ajută puțin la acțiuni

Compararea prognozelor din modele estimate și imbricate


- DM tratează prognozele ca date; ale noastre vin din parametri estimați, iar GARCH-t este imbricat în GJR-t
 - ▶ Fereastră în expansiune, modele imbricate: sub H_0 diferența de pierderi degenerază, deci DM nu este $N(0, 1)$ West (1996), Clark & McCracken (2001)
- Giacomini & White (2006): testăm **metoda** de prognoză (model + fereastră mobilă de lungime fixă W)
 - ▶ Valid pentru modele imbricate și parametri estimați, deoarece zgomotul estimării nu dispare
 - ▶ Testul condițional $\mathbb{E}[d_{t+1} | \mathcal{F}_t] = 0$ cu instrumentele $h_t = (1, d_t)$: $GW = n \bar{Z}' \hat{\Omega}^{-1} \bar{Z} \rightarrow \chi^2_2$, $Z_{t+1} = h_t d_{t+1}$
- Șase modele și cinci teste DM pe perechi: o problemă de comparații multiple
 - ▶ **Model Confidence Set Hansen, Lunde & Nason (2011)**: eliminăm cel mai slab model până când acuratețea egală nu mai este respinsă; mulțimea conține cel mai bun model cu probabilitatea $\geq 1 - \alpha$

S&P 500: testele Giacomini–White și Model Confidence Set

Model	QLIKE (W)	t necond.	GW	p	MCS p
GARCH-N	0,751	1,87	5,85	0,054	0,586
GARCH-t	0,743	—	—	—	0,353
GJR-t	0,738	-0,18	2,49	0,288	1,000
EGARCH-t	0,746	0,07	3,21	0,201	0,586
EWMA	0,815	3,20	11,40	0,003	0,008
Hist-20	0,889	3,87	16,41	< 0,001	0,001

- Fereastră mobilă $W = 1\,000$ de zile, reestimată în fiecare ianuarie, 2 692 prognoze; teste față de GARCH-t, HAC cu 5 decalaje
- MCS pe prognozele cu fereastră în expansiune din Secțiunea 7: QLIKE, statistica T_R , bootstrap staționar (bloc mediu 10, 10 000 de extrageri)
- MCS 90%: GARCH-N, GARCH-t, GJR-t, EGARCH-t; EWMA și Hist-20 excluse: același verdict ca DM, acum cu rata erorii controlată

Proгноze pe o lună: Mincer-Zarnowitz în logaritmi



- Prognoza GJR-GARCH-t a dispersiei pe 22 de zile față de suma realizată a 22 de pătrate ale randamentelor, 122 ferestre nesuprapuse

Interpretare: orizontul lunar

- ▣ Agregarea a 22 de zile reduce zgomotul aproximării: R^2 în logaritmi 0,38 (GJR-t); nu este comparabil cu 0,28 pentru o zi, în niveluri (alt orizont, altă scară)
- ▣ Panta în logaritmi $b = 0,75$ (e.s. 0,07): o descriere, nu un test al nedeplasării
 - ▶ $\mathbb{E}[\ln Y \mid \mathcal{F}] \neq \ln \mathbb{E}[Y \mid \mathcal{F}]$: o prognoză nedeplasată a dispersiei nu dă neapărat $b = 1$ în logaritmi, deci $b < 1$ nu dovedește prognoze prea dispersate
- ▣ În niveluri panta este doar 0,27: două ferestre COVID-19 (februarie și martie 2020) domină regresia
- ▣ Folosiți QLIKE pentru comparații robuste la aproximare [Patton \(2011\)](#); folosiți graficele în logaritmi descriptiv când câteva luni de criză au dispersii uriașe

Recapitulare: Prognoză

Idei-cheie


- ▣ Evaluăm prognozele în afara eșantionului, cu parametri estimați doar pe datele trecute
- ▣ Cu o aproximare zgomotoasă folosim pierderi robuste (QLIKE, MSE) și testul Diebold–Mariano
- ▣ Modele imbricate cu parametri estimați: Giacomini–White cu fereastră mobilă; multe modele: Model Confidence Set
- ▣ Mincer–Zarnowitz verifică nedeplasarea; un R^2 mic la o zi este de așteptat
- ▣ GARCH bate EWMA și dispersia istorică; membrii familiei GARCH sunt greu de departajat

GARCH-in-mean: este riscul recompensat?

- ▣ **GARCH-M** Engle, Lilien & Robins (1987): $r_t = c + \kappa \sigma_t + \varepsilon_t$ (sau $\kappa \sigma_t^2$)
 - ▶ $\kappa > 0$: investitorii cer un randament așteptat mai mare când riscul este mai mare (compromisul risc–randament)
- ▣ S&P 500, GARCH(1,1)-t în medie: $\hat{\kappa} = 0,096$ (t = 3,02) cu σ_t ; 0,028 (t = 2,35) cu σ_t^2
 - ▶ Pozitiv și semnificativ în acest eșantion, dar literatura este împărțită: GJR (1993) au găsit o relație negativă
- ▣ Atenție: un efect zilnic în medie este mic și fragil; depinde de eșantion și de asimetria dispersiei

 MFM_ch5_long_memory

Memoria lungă: unde GARCH nu ajunge



- S&P 500: autocorelația lui $|r_t|$ (decalaje 1–250, scară log) în date și în traiectorii lungi simulate din GARCH(1,1)-t și FIGARCH(1,d,1)-t estimate

Interpretare: memoria lungă

- Date: 0,289 la decalajul 1, 0,082 la 100, 0,009 la 250: o scădere lentă, aproximativ log-liniară
 - ▶ GARCH: prea mare la decalaje mici (0,416), apoi o prăbușire exponențială: ACF-ul său are un timp caracteristic
- **FIGARCH** Baillie, Bollerslev & Mikkelsen (1996): integrarea fracționară $(1 - L)^d$ dă o scădere hiperbolică
 - ▶ $\hat{d} = 0,60$ (e.s. 0,06); BIC mai mic cu 34,2 decât GARCH, dar memoria simulată este acum prea lungă (0,144 la decalajul 250)
- Niciun model cu o singură scară nu se potrivește tuturor orizonturilor: Capitolul 9 folosește volatilitatea realizată și modelul HAR

Alte limite ale GARCH

- ▣ **Rupturi structurale:** schimbările nivelului volatilității umflă $\alpha + \beta$ spre 1 [Lamoureux & Lastrapes \(1990\)](#)
 - ▶ Persistența estimată pentru BET-TR (2014–2026) 0,9188 față de BET (2000–2026) 0,9907: eșantionul contează
- ▣ **Întârzierea reacției:** GARCH zilnic se actualizează doar după ce observă șocul randamentului; volatilitatea implicită, de ex. VIX, încorporează informația nouă din piața opțiunilor în aceeași zi
- ▣ **Doar date zilnice în acest capitol:** informația intrazilnică este omisă; măsurile realizate o folosesc (Capitolul 9)
- ▣ **Un singur activ:** portofoliile au nevoie de covarianțe; GARCH multivariat și DCC în Capitolul 6
- ▣ **Prețuri administrate (EUR/RON):** un GARCH zilnic descrie slab intervențiile

Extensii: GAS, Realized GARCH și GARCH-MIDAS

- **Bazate pe scor (GAS)** Creal, Koopman & Lucas (2013): $\sigma_{t+1}^2 = \omega + A s_t + B \sigma_t^2$, s_t scorul scalat al densității Student-t
 - ▶ Scorul este mărginit în z_t : o valoare extremă ca reziduul EUR/RON de 154 mișcă dispersia mult mai puțin decât în GARCH
- **Realized GARCH** Hansen, Huang & Shek (2012): adaugă o ecuație de măsurare care leagă σ_t^2 de o dispersie realizată
 - ▶ Folosește informația intrazilnică și reacționează mai repede; puntea spre Capitolul 9
- **GARCH-MIDAS** Engle, Ghysels & Sohn (2013): $\sigma_t^2 = \tau_t g_t$, o componentă lentă de termen lung τ_t determinată de date macro (frecvențe mixte)
 - ▶ Un nivel de termen lung mobil absoarbe schimbările de nivel care împing $\hat{\alpha} + \hat{\beta}$ spre 1
- Fiecare extensie se judecă la fel ca GARCH: în afara eșantionului, pierdere robustă, Model Confidence Set

Dincolo de dispersie: entropie și risc de coadă

- ▣ [Pele, Lazar & Dufour \(2017\)](#): entropia distribuției randamentelor intrazilnice și riscul de piață (EUR/JPY)
 - ▶ O entropie mai mare se asociază cu Value at Risk și expected shortfall intrazilnice mai mici; entropia prognozează apoi Value at Risk zilnic
- ▣ [Pele & Mazurencu-Marinescu-Pele \(2019\)](#): entropia randamentelor intrazilnice Bitcoin propusă ca semnal suplimentar pentru Value at Risk zilnic
- ▣ [Pele, Lazar & Mazurencu-Marinescu-Pele \(2019\)](#): o măsură neparametrică a cozii bazată pe entropie, comparată cu modelele standard de expected shortfall
- ▣ Volatilitatea GARCH intră direct în Value at Risk și expected shortfall: Capitolele 7–8

Studiu de caz: întrebarea de cercetare

- **Întrebarea Blasques, Francq & Laurent (2023):** trebuie ca un model de volatilitate bazat pe scor să actualizeze σ_t^2 cu scorul aceleiași densități care descrie randamentele?
 - ▶ Actualizarea bazată pe scor (GAS) **Creal, Koopman & Lucas (2013):** $f_{t+1} = \omega + \alpha S(f_t) \partial \log p(y_t | f_t) / \partial f_t + \beta f_t$, ec. (2), $S(f_t)$ este un factor de scalare, de ex. inversa informației Fisher
 - ▶ În cazul distribuției Student-t, același ν determină grosimea cozilor lui z_t și atenuarea șocurilor mari în f_{t+1} (Secțiunea 4.1)
- De ce contează: GARCH este determinat de ε_t^2 oricare ar fi densitatea, deci un șoc extrem izolat poate produce o reacție excesivă a volatilității, care durează zile sau săptămâni (Secțiunea 1)
 - ▶ Cu o densitate asimetrică la stânga, un model pur bazat pe scor crește volatilitatea mai mult după randamente pozitive: opusul efectului de levier din Secțiunea 5 a acestui capitol (Exemplul 2)
- Ideea: modelele bazate pe un cvasi-scor (QSD), $f_{t+1} = \omega + \alpha \psi(y_t, X_t, f_t, \theta) + \beta f_t$, ec. (3), cu ψ scorul scalat al unei funcții de actualizare ρ care nu trebuie să coincidă cu $\log p$, ec. (4)
 - ▶ ρ Gaussian cu p Student-t dă GARCH-t **Bollerslev (1987)**; $\rho = \log p$ dă modelele bazate pe scor; pot intra variabile exogene X_t (Secțiunea 2.1)
 - ▶ Teoria: consistența și normalitatea asimptotică a estimatorilor de cvasi-verosimilitate, QMLE și de verosimilitate maximă; testele LR și LM cu distribuțiile limită χ^2 obișnuite (Secțiunea 3)

Studiu de caz: date și metodă


- **Modelul:** QSD GARCH(1,1)-t, ec. (30): $y_t = \sqrt{f_t} \epsilon_t$, unde f_t este σ_t^2 , iar ϵ_t este z_t din acest capitol, Student-t standardizat cu $1/\xi$ grade de libertate
 - ▶ $f_{t+1} = \omega + \varpi X_t + \alpha \frac{1 + \zeta}{1 - 2\zeta + \zeta \epsilon_t^2} \epsilon_t^2 f_t + \beta f_t$: ponderea lui ϵ_t^2 scade când ϵ_t^2 crește, deci șocurile mari sunt atenuate
 - ▶ $\zeta = 0$: GARCH(1,1)-t; $\zeta = \xi$: Beta-t-GARCH, modelul bazat pe scor al lui Harvey și Chakravarty, ec. (28)–(29); $1/\zeta$ reprezintă numărul de grade de libertate al distribuției folosite la actualizare
- **Estimarea:** verosimilitate maximă cu medie AR(1); testele LR pentru $H_0: \zeta = 0$ și $H_0: \xi = \zeta$, cu distribuția χ_1^2 (Secțiunea 5.1)
 - ▶ $\zeta = 0$ rămâne în interiorul spațiului parametrilor prin ec. (31)–(32): $\zeta \in (-1, 1/2)$ și $\Psi(x) = x(1 - e^{-cx})/(1 + e^{-cx})$ aplicată ponderii, $c = 1000$
 - ▶ Adecvarea: testul PIT [Diebold, Gunther & Tay \(1998\)](#), $u_t = F(\epsilon_t)$ i.i.d. $U(0, 1)$ dacă modelul este corect, deci $(\sum_t u_t - T/2)/\sqrt{T/12} \rightarrow N(0, 1)$; cu estimatorul de verosimilitate maximă $\hat{\theta}$ și teorema din [Pierce \(1982\)](#), se respinge dacă $|\sum_t \hat{u}_t - T/2|/\sqrt{T(1/12 - B \mathcal{I}(\hat{\theta})^{-1} B^\top)} > 1,96$, $B = \lim_{T \rightarrow \infty} \mathbb{E}[\partial \sum_t (u_t - T/2)/\partial \theta^\top]$, $\mathcal{I}$ informația Fisher (Secțiunea 5.1; Anexa C din suplimentul online); detectează o medie PIT deplasată, nu orice abatere de la uniformitate
- **Date:** toate acțiunile din S&P 500, 3 ianuarie 1995 (sau mai târziu) – 28 februarie 2019; se elimină acțiunile cu mai puțin de 4000 de observații sau cu probleme de convergență: 400 de acțiuni (Secțiunea 5)
 - ▶ X_t : pătratul VIX, convertit de la orizont anual la orizont zilnic (Secțiunea 5.1)
 - ▶ Varianta asimetrică, ec. (47): o distribuție Student-t asimetrică pentru ϵ_t , cu parametrul de asimetrie κ , și parametri separați (ζ, τ) pentru actualizare; $\tau < 0,5$ produce efect de levier oricare ar fi κ (Secțiunea 5.2)

Studiu de caz: rezultatele principale (Tabelele 4–6)

Respinse la 5%, % din cele 400 de acțiuni	Student-t (Tabelul 4)	t asimetric (Tabelul 6)
LR, $H_0: \zeta = 0$ (actualizare GARCH)	89,5	98,8
LR, $H_0: \xi = \zeta$ (bazat pe scor; asimetric: și $\kappa = \tau$)	53,5	100,0
Testul PIT: GARCH(1,1)	40,0	33,1
Testul PIT: Beta-t-GARCH	46,0	72,2
Testul PIT: QSD GARCH(1,1)	45,7	11,3

- Atenuarea șocurilor mari contează: $\zeta = 0$ este respinsă pentru 89,5% din acțiuni și toate valorile $\hat{\zeta}$ sunt pozitive (Tabelul 4, Secțiunea 5.1)
- Dar Beta-t-GARCH atenuează prea mult: acolo unde diferența $\hat{\xi} - \hat{\zeta}$ este semnificativă, $\hat{\xi} > \hat{\zeta}$ pentru toate acțiunile, cu o excepție (Fig. 2); mediana lui $1/\hat{\zeta}$ este 9,48, față de 5,07 (Fig. 3)
- Centene, 4330 de zile: $\hat{\xi} \approx 0,26$ (circa 4 grade de libertate) în toate cele trei modele, dar $\hat{\zeta} = 0,048$ (e.s. 0,027); LR 8,81 ($p = 0,003$) pentru $\xi = \zeta$ și 8,42 ($p = 0,004$) pentru $\zeta = 0$ (Tabelul 5): grosimea cozilor și atenuarea șocurilor sunt controlate de parametri diferiți
- t asimetric: $\hat{\tau}$ este mult sub 0,5 (mediana 0,333), iar $\hat{\kappa}$ rămâne aproape de 0,5 (Fig. 5–6): efectul de levier este modelat prin actualizare, nu prin densitate; testul PIT respinge modelul QSD pentru doar 11,3% din acțiuni

Studiu de caz: replicare pe 11 acțiuni (Fig. 2)




- QSD GARCH(1,1)-t prin verosimilitate maximă, medie AR(1), $X_t = \text{VIX}_t^2/252$; 1995 (sau mai târziu) – februarie 2019, 4986–6081 randamente zilnice pe acțiuni

Interpretare: cozi groase și atenuarea șocurilor

- $H_0: \zeta = 0$ (actualizare GARCH) este respinsă la 5% pentru 9 din cele 11 acțiuni; în lucrare: 89,5% din 400 (Tabelul 4)
 - Nerespinsă: Goldman Sachs ($\hat{\zeta} = 0,031$, LR 3,42), Morgan Stanley ($\hat{\zeta} = 0,006$, LR 0,13)
- $H_0: \xi = \zeta$ (Beta-t-GARCH) este respinsă pentru 8 din cele 11 acțiuni; în lucrare: 53,5%
 - Nerespinsă: Apple, Amazon, Cisco
- $\hat{\zeta} > 0$ pentru 11 din 11 acțiuni și $\hat{\xi} > \hat{\zeta}$ pentru 10 din 11 (diferență semnificativă pentru 8): Beta-t-GARCH atenuază prea mult șocurile mari (Fig. 2)
- Mediana lui $1/\hat{\zeta}$: 21,4 în modelul QSD, față de 6,32 în Beta-t-GARCH; în lucrare: 9,48, față de 5,07 (Secțiunea 5.1)

Studiu de caz: impactul știrilor (Fig. 3)



- Contribuția șocului ε_t la f_{t+1} (în unități de αf_t), calculată la mediana și la cuantilele de 5% și 95% ale celor 11 estimări

Interpretare: impactul unui șoc extrem

- Un șoc de 5 abateri standard adaugă, în unități de αf_t : 25 în GARCH-t, 12,6 în modelul QSD median și 6,2 în Beta-t-GARCH median
 - La 10 abateri standard: 100, 18,8 și 7,0; ponderea Beta-t-GARCH este mărginită de $(1 + \zeta)/\zeta = 7,3$ la mediană; comparația izolează funcția de actualizare la același αf_t , nu traiectoriile dispersiei estimate
- Curba QSD calculată la mediană se află între celelalte două (Fig. 3): șocurile mari sunt atenuate mai puțin decât în Beta-t-GARCH
- Eterogenitate mai mare între acțiuni în modelul QSD: la 5 abateri standard, între 5,6 și 17,9 (cuantilele de 5%–95% ale lui $\hat{\zeta}$), față de valori între 4,9 și 6,8 pentru Beta-t-GARCH
- După o zi de crah, volatilitatea GARCH-t rămâne mult peste cea Beta-t-GARCH câteva zile, iar QSD se află între cele două (Fig. 4 din lucrare: Centene, martie–aprilie 2008)

Studiu de caz: replicare, limite, extindere

- **Replicarea** (cele patru slide-uri anterioare) pe cele 11 acțiuni din data/market care erau în S&P 500 în februarie 2019 și au cel puțin 4000 de randamente zilnice în fereastră
 - ▶ Apple, Amazon, Bank of America, Citigroup, Cisco, Goldman Sachs, JPMorgan, Microsoft, Morgan Stanley, Nvidia, Wells Fargo; $X_t = \text{VIX}_t^2 / 252$
 - ▶ GARCH(1,1)-t, Beta-t-GARCH și QSD GARCH(1,1)-t prin verosimilitate maximă cu medie AR(1), testele LR și PIT alături de Tabelul 4 (Seminarul 5, C3)
 - ▶ Limita datelor: eșantionul cuprinde 11 companii mari, încă listate, față de 400 în studiu; frecvențele de respingere sunt imprecise și nereprezentative pentru indice
- **Limitele** indicate de autori
 - ▶ Performanța superioară față de GARCH-t și Beta-t-GARCH nu garantează adecvarea modelului QSD Student-t: testul PIT respinge cele trei modele pentru 40,0–46,0% din acțiuni (Tabelul 4, Secțiunea 5.1)
 - ▶ În recursia nemodificată (30), $\zeta < 0$ sau $\zeta > 1/2$ nu definesc un model de volatilitate propriu-zis, iar $\zeta = 1/2$ cu $\varpi = 0$ este degenerat (Secțiunea 4.1)
 - ▶ Legea asimptotică $N(T/2, T/12)$ pentru $\sum_t u_t$ este valabilă doar pentru parametri cunoscuți; cu parametri estimați testul PIT are nevoie de o corecție (Secțiunea 5.1)
- **Extindere deschisă**
 - ▶ Depășește actualizarea mărginită QSD modelul GJR-GARCH-t în QLIKE, în afara eșantionului, mai ales după martie 2020 (testul DM, Secțiunea 7 a acestui capitol)?
 - ▶ EUR/RON, unde un singur reziduu de 154 domină dispersia GARCH: îi reduce actualizarea QSD influența asupra dispersiei?

O întrebare deschisă

- Depășesc prognozele bazate pe învățare automată sau pe măsuri realizate performanța unui model GARCH bine specificat pentru dispersia zilnică a acțiunilor, în afara eșantionului, după ce ținem cont de numărul de modele comparate?
- Întrebarea este deschisă
 - ▶ Christensen, Siggaard & Veliyev (2023): metodele de învățare automată, cu puțină calibrare, sunt competitive cu modelele de tip HAR pentru dispersia realizată a acțiunilor din Dow Jones
 - ▶ Hansen, Lunde & Nason (2011): Model Confidence Set păstrează toate modelele care nu sunt semnificativ mai slabe decât cel mai bun, obiectul potrivit când concurează multe modele
 - ▶ Acest capitol: în familia GARCH, statistica DM variază între $-1,47$ și $-0,36$: niciun câștigător semnificativ
- Formularea formală pentru modelele A și B, pierderea QLIKE L
 - ▶ $d_t = L(r_t^2, h_t^A) - L(r_t^2, h_t^B)$; $H_0: \mathbb{E}[d_t] = 0$; $H_1: \mathbb{E}[d_t] < 0$; statistica DM cu erori HAC Diebold & Mariano (1995)
 - ▶ Infirmată dacă A iese din Model Confidence Set sau dacă semnul lui $\bar{d}$ se schimbă între subperioadele pre-înregistrate

Bucula descoperirii, pas cu pas (1/2)

- Instrumentele sunt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și instrumente de căutare a literaturii științifice (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „Listează comparațiile în afara eșantionului dintre prognozele dispersiei bazate pe GARCH, HAR și învățare automată publicate după 2015, cu DOI, activ, funcție de pierdere, test și orizont.”
 - ▶ Verificăm fiecare DOI în Crossref; verificăm că pierderea este robustă la o aproximare zgomotoasă [Patton \(2011\)](#)
- **Ipoteze:** „Pentru afirmația că asimetria îmbunătățește prognozele pe o zi, listează mecanismele concurente (levier, feedback de volatilitate, câteva zile de criză) și ce prezice fiecare pentru d_t după semnul lui r_{t-1} și pe subperioade.”
- **Date și cod:** „Scrie cod Python cu `arch` care reestimează GARCH-t și GJR-t în fiecare ianuarie pe o fereastră în expansiune din data/market și salvează prognozele dispersiei pe o zi; niciun parametru nu folosește date de după originea prognozei.”
 - ▶ Replicăm întâi: QLIKE 0,757 (GARCH-t) și 0,732 (GJR-t), DM $t = -1,22$ (Secțiunea 7)

Bucula descoperirii, pas cu pas (2/2)

- **Robustețe:** „Scrie un plan pre-înregistrat: împărțiri după semnul lui r_{t-1} și pe subperioade, MSE pe lângă QLIKE, orizontul de 22 de zile, decalajul HAC și o corecție Bonferroni sau Model Confidence Set.”
 - ▶ Testul direct al efectului semnului: regresia lui d_t pe o constantă și pe $1(r_{t-1} < 0)$, cu erori HAC; un placebo cu împărțiri aleatoare este calibrat doar dacă realocă blocuri de zile, păstrând gruparea volatilității
- **Critica:** „Joacă rolul unui referent: ar putea aproximarea r_t^2 , un singur an de criză sau decalajul HAC să creeze rezultatul meu? Propune câte un test pentru a verifica fiecare explicație.”
- **Raportul:** toate împărțirile și pierderile încercate, valorile p ajustate, codul, valorile de inițializare ale generatoarelor de numere aleatoare și versiunile pachetelor
- Fixăm planul înainte de prima rulare: orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare

Ce verifică cercetătorul

- ▣ **Informație din viitor:** parametri estimați pe tot eșantionul sau h_t construit cu r_t însuși; h_t folosește datele până la închiderea zilei $t - 1$ și se evaluează față de $r_t^2 \Rightarrow$ verificăm că ultima dată de estimare precede fiecare origine; modificăm r_t și verificăm că h_t nu se schimbă
- ▣ **Pierdere nerobustă:** pierderile pe $|r_t|$ sau pe logaritmi pot ordona greșit prognozele cu o aproximare zgomotoasă [Patton \(2011\)](#) $\Rightarrow$ doar QLIKE și MSE
- ▣ **Căutarea modelelor:** 3 ecuații ale dispersiei $\times$ 4 distribuții $\times$ ferestre $\Rightarrow$ Model Confidence Set sau Bonferroni pe mulțimea pre-înregistrată
- ▣ **Perioade influente:** un an de criză poate domina $\bar{d} \Rightarrow$ raportăm subperioadele și declarăm dinainte dacă vreun an poate fi exclus
- ▣ **Scara și convergența:** randamente în % sau în zecimale, optimizări eșuate $\Rightarrow$ verificăm indicatorii optimizatorului și o actualizare a dispersiei pas cu pas
- ▣ **Referințe sau funcții inventate:** DOI care nu se rezolvă, argumente arch inexistente $\Rightarrow$ Crossref și rularea codului; notăm în `AI_ERRORS.md`

Mini-studiu de caz: îmbunătățește asimetria prognoza?

- O propunere tipică a unui asistent: „GJR-t bate GARCH-t datorită efectului de levier”; $d_t = \text{QLIKE}(\text{GJR-t}) - \text{QLIKE}(\text{GARCH-t})$
- Replicăm: 2 692 zile, 2016–2026: $\bar{d} = -0,025$, DM $t = -1,22$ ($p = 0,22$): nesemnificativ
- Implicația testabilă a levierului: câștigul apare după zilele de scădere
 - ▶ După $r_{t-1} < 0$ (1 223 zile): $\bar{d} = -0,015$, $t = -0,51$; după $r_{t-1} \geq 0$ (1 469): $\bar{d} = -0,034$, $t = -1,12$
 - ▶ Nesusținută: GJR are $\hat{\alpha} = 0,000$, deci o creștere nu îi ridică prognoza; câștigul nu este mai mic după zilele de creștere
- Subperioade: 2016–2020 $t = -0,02$; 2021–2026 $t = -4,06$ ($p < 0,001$); fără 2020 $t = -4,26$
 - ▶ Doar descriptiv: GARCH-t este imbricat în GJR-t, iar fereastra este în expansiune, deci aceste valori DM t și p nu sunt calibrate $N(0, 1)$ (Secțiunea 7), iar o corecție Bonferroni nu le poate repara; este nevoie de un test GW cu fereastră fixă
- Interpretare (descriptivă): câștigul nu este concentrat după zilele de scădere și lipsește în 2016–2020; confirmarea sau respingerea canalului de levier cere un test calibrat al diferenței dintre semne

Rândul vostru: un punct de plecare pentru proiectul de echipă

- Întrebarea: intră prognozele bazate pe învățare automată, pe date zilnice, în Model Confidence Set alături de GARCH, GJR și EGARCH pentru S&P 500 și BET, 2016–2026?
 - ▶ Ramura cu dispersie realizată (HAR): doar ETF-ul SPY, un substitut al S&P 500 cu observații la intervale de 5 minute în data/intraday din octombrie 2020, evaluată pe 2021–2026; pentru BET nu există date intrazilnice
- Replicăm întâi: tabelul QLIKE din Secțiunea 7 (GARCH-t 0,757, DM EWMA $t = 3,48$) și împărțirile din mini-studiul de caz
- Livrabile
 - ▶ O pre-înregistrare de o pagină: modele, pierderi, împărțiri, rata de eroare și ce ar infirma afirmația
 - ▶ Cod pe data/market (zilnic) și data/intraday (SPY), Model Confidence Set la 10%, o autocritică în stilul unui referent
- Notăm fiecare prompt, instrument și rezultat acceptat în AI_USE.md; fiecare eroare prinsă (informație din viitor, scară greșită, DOI inventat) și testul care a prins-o în AI_ERRORS.md
- Codul mini-studiului de caz: [Quantlets/Ch_05/ai_discovery_case.py](#)

Idei principale

Ce reținem

- ▣ Randamentele sunt aproape imprevizibile, mărimea lor nu: GARCH transformă gruparea în prognoze
- ▣ GARCH(1,1): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$; persistența $\alpha + \beta$ aproape de 1 pe toate piețele noastre
- ▣ Volatilitatea acțiunilor este asimetrică (GJR, EGARCH); la Bitcoin nu se detectează asimetrie; la aur este inversată
- ▣ Inovațiile au cozi groase și sunt asimetrice: Student-t sau t asimetric, cu erori standard robuste
- ▣ În afara eșantionului, modelele GARCH bat EWMA și dispersia istorică; între ele, diferențele sunt mici

O listă practică de verificare

- ▣ 1. Testați efectele ARCH: Q pe r_t^2 și testul LM
- ▣ 2. Estimați GARCH, GJR și EGARCH cu inovații Normale, Student-t și t asimetrice; randamente în %
- ▣ 3. Verificați convergența, frontierele și erorile standard robuste (QMLE Gaussian: valide doar dacă $\mathbb{E}z_t^4 < \infty$); LR ajustat la frontieră și BIC
- ▣ 4. Diagnosticați reziduurile standardizate (nivel, pătrate, semne, cele mai mari valori)
- ▣ 5. Evaluați prognozele în afara eșantionului: QLIKE, Diebold–Mariano sau Giacomini–White, Model Confidence Set, Mincer–Zarnowitz
- ▣ 6. Raportați timpul de înjumătățire cu incertitudinea sa; nu vă bazați pe cifrele de termen lung când $\alpha + \beta \approx 1$

Resurse suplimentare

▣ Cărți

- ▶ Franke, Härdle & Hafner (2019), capitolele despre modelele ARIMA și GARCH pentru serii financiare
- ▶ Francq & Zakoïan (2019): teoria matematică a modelelor GARCH

▣ Cursuri Quantinar

- ▶  Statistics of Financial Markets
- ▶  Applied Time Series Analysis with Python

▣ Cod

- ▶ Toate graficele și tabelele: [Quantlets/Ch_05](#); pachetul Python [Sheppard](#), [arch](#)

Ce urmează

- ▣ Capitolul 6: dependența dintre piețe, volatilitatea multivariată și corelațiile dinamice
- ▣ Capitolul 7: Value at Risk și expected shortfall, cu volatilitatea GARCH ca intrare
- ▣ Capitolul 8: testarea retrospectivă a prognozelor de risc
- ▣ Capitolul 9: volatilitatea realizată și memoria lungă
- ▣ Seminarul 5: dispersia pe mai mulți pași, derivări pentru metoda delta și dispersia robustă și clasică a QMLE, LR la frontieră, Giacomini–White și MCS, testul IGARCH prin bootstrap, transmiterea șocurilor din SUA către BET

Bibliografie (1/6)

- ▣ Andersen, T.G., Bollerslev, T. (1998). Answering the skeptics: yes, standard volatility models do provide accurate forecasts. *International Economic Review*, 39(4), 885–905.
- ▣ Andrews, D.W.K. (2000). Inconsistency of the bootstrap when a parameter is on the boundary of the parameter space. *Econometrica*, 68(2), 399–405.
- ▣ Andrews, D.W.K. (2001). Testing when a parameter is on the boundary of the maintained hypothesis. *Econometrica*, 69(3), 683–734.
- ▣ Baillie, R.T., Bollerslev, T., Mikkelsen, H.O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30.
- ▣ Berkes, I., Horváth, L., Kokoszka, P. (2003). GARCH processes: structure and estimation. *Bernoulli*, 9(2), 201–227.
- ▣ Blasques, F., Francq, C., Laurent, S. (2023). Quasi score-driven models. *Journal of Econometrics*, 234(1), 251–275.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *Review of Economics and Statistics*, 69(3), 542–547.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.

Bibliografie (2/6)

- ▣ Christensen, K., Siggaard, M., Veliyev, B. (2023). A machine learning approach to volatility forecasting. *Journal of Financial Econometrics*, 21(5), 1680–1727.
- ▣ Clark, T.E., McCracken, M.W. (2001). Tests of equal forecast accuracy and encompassing for nested models. *Journal of Econometrics*, 105(1), 85–110.
- ▣ Creal, D., Koopman, S.J., Lucas, A. (2013). Generalized autoregressive score models with applications. *Journal of Applied Econometrics*, 28(5), 777–795.
- ▣ Diebold, F.X., Gunther, T.A., Tay, A.S. (1998). Evaluating density forecasts with applications to financial risk management. *International Economic Review*, 39(4), 863–883.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- ▣ Engle, R.F. (2004). Risk and volatility: econometric models and financial practice. *American Economic Review*, 94(3), 405–420.
- ▣ Engle, R.F., Ghysels, E., Sohn, B. (2013). Stock market volatility and macroeconomic fundamentals. *Review of Economics and Statistics*, 95(3), 776–797.
- ▣ Engle, R.F., Lilien, D.M., Robins, R.P. (1987). Estimating time varying risk premia in the term structure: the ARCH-M model. *Econometrica*, 55(2), 391–407.

Bibliografie (3/6)

- ▣ Engle, R.F., Ng, V.K. (1993). [Measuring and testing the impact of news on volatility](#). *Journal of Finance*, 48(5), 1749–1778.
- ▣ Fan, J., Qi, L., Xiu, D. (2014). [Quasi-maximum likelihood estimation of GARCH models with heavy-tailed likelihoods](#). *Journal of Business & Economic Statistics*, 32(2), 178–191.
- ▣ Francq, C., Zakoïan, J.-M. (2004). [Maximum likelihood estimation of pure GARCH and ARMA-GARCH processes](#). *Bernoulli*, 10(4), 605–637.
- ▣ Francq, C., Zakoïan, J.-M. (2019). [GARCH Models: Structure, Statistical Inference and Financial Applications](#), 2nd ed. Wiley.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Giacomini, R., White, H. (2006). [Tests of conditional predictive ability](#). *Econometrica*, 74(6), 1545–1578.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). [On the relation between the expected value and the volatility of the nominal excess return on stocks](#). *Journal of Finance*, 48(5), 1779–1801.
- ▣ Hall, P., Yao, Q. (2003). [Inference in ARCH and GARCH models with heavy-tailed errors](#). *Econometrica*, 71(1), 285–317.
- ▣ Hamilton, J.D., Susmel, R. (1994). [Autoregressive conditional heteroskedasticity and changes in regime](#). *Journal of Econometrics*, 64(1–2), 307–333.

Bibliografie (4/6)

- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- ▣ Hansen, P.R., Huang, Z., Shek, H.H. (2012). Realized GARCH: a joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6), 877–906.
- ▣ Hansen, P.R., Lunde, A. (2005). A forecast comparison of volatility models: does anything beat a GARCH(1,1)? *Journal of Applied Econometrics*, 20(7), 873–889.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ J.P. Morgan/Reuters (1996). RiskMetrics — Technical Document, 4th ed. New York.
- ▣ Jensen, S.T., Rahbek, A. (2004). Asymptotic inference for nonstationary GARCH. *Econometric Theory*, 20(6), 1203–1226.
- ▣ Lamoureux, C.G., Lastrapes, W.D. (1990). Persistence in variance, structural change, and the GARCH model. *Journal of Business & Economic Statistics*, 8(2), 225–234.
- ▣ Lee, J.H.H., King, M.L. (1993). A locally most mean powerful based score test for ARCH and GARCH regression disturbances. *Journal of Business & Economic Statistics*, 11(1), 17–27.
- ▣ Li, W.K., Mak, T.K. (1994). On the squared residual autocorrelations in non-linear time series with conditional heteroskedasticity. *Journal of Time Series Analysis*, 15(6), 627–636.

Bibliografie (5/6)

- ▣ Lumsdaine, R.L. (1996). Consistency and asymptotic normality of the quasi-maximum likelihood estimator in IGARCH(1,1) and covariance stationary GARCH(1,1) models. *Econometrica*, 64(3), 575–596.
- ▣ Mandelbrot, B. (1963). The variation of certain speculative prices. *Journal of Business*, 36(4), 394–419.
- ▣ McLeod, A.I., Li, W.K. (1983). Diagnostic checking ARMA time series models using squared-residual autocorrelations. *Journal of Time Series Analysis*, 4(4), 269–273.
- ▣ Mincer, J., Zarnowitz, V. (1969). The evaluation of economic forecasts. In J. Mincer (ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*, NBER.
- ▣ Nelson, D.B. (1990). Stationarity and persistence in the GARCH(1,1) model. *Econometric Theory*, 6(3), 318–334.
- ▣ Nelson, D.B. (1991). Conditional heteroskedasticity in asset returns: a new approach. *Econometrica*, 59(2), 347–370.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). Modeling expected shortfall using tail entropy. *Entropy*, 21(12), 1204.

Bibliografie (6/6)

- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). Using high-frequency entropy to forecast Bitcoin's daily Value at Risk. *Entropy*, 21(2), 102.
- ▣ Pierce, D.A. (1982). The asymptotic effect of substituting estimators for parameters in certain types of statistics. *The Annals of Statistics*, 10(2), 475–478.
- ▣ Self, S.G., Liang, K.-Y. (1987). Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, 82(398), 605–610.
- ▣ Sheppard, K. arch: ARCH models and other tools for financial econometrics in Python (software documentation).
- ▣ West, K.D. (1996). Asymptotic inference about predictive ability. *Econometrica*, 64(5), 1067–1084.