



Modelarea piețelor financiare

Capitolul 5: Volatilitate condiționată — modele GARCH



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ACF: AutoCorrelation Function (funcția de autocorelație)
- AI: Artificial Intelligence (inteligență artificială)
- AIC: Akaike Information Criterion (criteriul informațional Akaike)
- AR: AutoRegressive (model) (model autoregresiv)
- ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ARIMA: AutoRegressive Integrated Moving Average (model) (model autoregresiv integrat cu medie mobilă)
- ARMA: AutoRegressive Moving Average (model) (model autoregresiv cu medie mobilă)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BNR: Banca Națională a României
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- EGARCH: Exponential GARCH (GARCH exponențial)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- FIGARCH: Fractionally Integrated GARCH (GARCH integrat fracționar)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-M: GARCH-in-Mean (GARCH cu volatilitatea în ecuația mediei)
- GARCH-MIDAS: GARCH with Mixed Data Sampling (long-run component) (GARCH cu eșantionare mixtă a datelor (componentă de termen lung))
- GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- GAS: Generalised Autoregressive Score (model) (model cu scor autoregresiv generalizat)
- GED: Generalised Error Distribution (distribuția generalizată a erorilor)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)

Acronime folosite în acest material (2/2)

- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- IGARCH: Integrated GARCH (GARCH integrat)
- LM: Lagrange Multiplier (multiplicatorul Lagrange)
- LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- MCS: Model Confidence Set (mulțimea de modele de încredere)
- MLE: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- MSE: Mean Squared Error (eroarea pătratică medie)
- MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)
- QQ: Quantile–Quantile (plot) (graficul cuantilă–cuantilă)
- SUA: Statele Unite ale Americii
- VIX: CBOE Volatility Index (indicele de volatilitate CBOE)
- XAU: gold, ISO 4217 code (one troy ounce) (aur, codul ISO 4217 (o uncie troy))

Cuprins

Motivație

De la ARCH la GARCH

Estimare și alegerea modelului

Exemplu lucrat și rezultate pe piețe

Volatilitate asimetrică

Inovații și diagnostic

Prognoza și evaluarea prognozelor


Extensii și limite

AI pentru descoperire științifică

Concluzii

Bibliografie

Volatilitatea vine în rafale



Bursa din Amsterdam, 21 octombrie 1987, după prăbușirea din 19 octombrie

Foto: Bart Molendijk / Anefo (1987); CC0; Wikimedia Commons

- Prăbușirile nu sunt zile izolate: mișcările mari sunt urmate de mișcări mari
 - ▶ „Schimbările mari tind să fie urmate de schimbări mari, de orice semn” [Mandelbrot \(1963\)](#)
- Această **grupare a volatilității** este faptul stilizat 6 din Capitolul 1
- Volatilitatea intră în orice cifră de risc: Value at Risk (Capitolul 7), ponderile portofoliului (Capitolul 4), prețul opțiunilor
- Întrebarea: putem transforma gruparea într-o **prognoză** a riscului de mâine și face inferență validă asupra ei?

Datele folosite în acest capitol

Serie	Proprietar / sursă	Început	Obs.	Obs. pe an
S&P 500	S&P Dow Jones Indices	2000	6 714	251,4
BET	Bursa de Valori București	2000	6 670	249,8
BET-TR	Bursa de Valori București	2014	2 992	249,7
Bitcoin (BTC/USD)	burse cripto (compozit)	2014	4 384	365,3
EUR/RON, curs de referință	BNR	2005	5 352	252,4
Aur (XAU/USD)	piața spot	2000	6 922	259,2

- Închideri zilnice până la 18 septembrie 2026; randamente $r_t = 100 (\ln P_t - \ln P_{t-1})$, în %
- Indici bursieri și aur: doar zilele lucrătoare; aurul este anualizat cu frecvența sa reală
- Bitcoin se tranzacționează 7 zile din 7; indicele VIX al Chicago Board Options Exchange este folosit ca reper

Recapitularea cunoștințelor necesare: grupare și cozi groase (Capitolul 1)

- Cozi groase: excesul de aplatizare S&P 500 10,7, BET 11,1, Bitcoin 12,0 (0 pentru distribuția Normală)
 - ▶ Volatilitatea anuală: Bitcoin 66,6%, S&P 500 19,2%, BET 22,1%
- S&P 500: autocorelația de ordin 1 a lui r_t este -0,099, a lui r_t^2 este 0,313
 - ▶ Toate cele 50 autocorelații ale lui r_t^2 până la decalajul 50 ies din $\pm 0,024$; încă 0,053 la decalajul 50
- Semnul randamentului de mâine este aproape imprevizibil; mărimea lui nu: obiectul de modelat este $\text{Var}(r_t \mid \mathcal{F}_{t-1})$
- Graficele ambelor fapte: Quantlet-ul de mai jos și Capitolul 1

 MFM_ch5_arch_effects

Testarea efectelor ARCH

- **McLeod–Li** [McLeod & Li \(1983\)](#): Ljung–Box $Q(10)$ pe r_t^2 , χ_{10}^2 în absența grupării
- **Testul LM al lui Engle** [Engle \(1982\)](#): nR^2 din regresia lui $\hat{\varepsilon}_t^2$ pe $\hat{\varepsilon}_{t-1}^2, \dots, \hat{\varepsilon}_{t-5}^2$, χ_5^2 ; $\hat{\varepsilon}_t = r_t - \bar{r}$
- Alternativa este unilaterală ($\alpha_i \geq 0$): testul χ^2 bilateral pierde putere
 - ▶ [Lee & King \(1993\)](#): test al scorului unilateral, construit pe suma componentelor scorului, $N(0, 1)$ sub H_0 , respinge doar în coada superioară
- Față de GARCH(1,1), ipoteza nulă $\alpha = 0$ lasă β neidentificat (problema Davies)
 - ▶ Statistica LM ARCH(q) este și testul scorului față de GARCH(p, q) [Lee & King \(1993\)](#): aceeași statistică servește ambele alternative

Efecte ARCH pe șase piețe

Serie	Vol. (% anual)	Exces aplatare	$\hat{\rho}_1(r^2)$	$Q(10)$ pe r^2	LM(5)
S&P 500	19,2	10,7	0,313	6133	1679
BET	22,1	11,1	0,330	2440	983
BET-TR	15,4	17,8	0,171	714	372
Bitcoin	66,6	12,0	0,137	213	115
EUR/RON	4,4	15,1	0,342	2420	872
Aur	17,6	7,7	0,110	744	330

- ▣ Valori critice la 5%: χ_{10}^2 : 18,3; χ_5^2 : 11,1; toate statisticile sunt mult peste ele (toate valorile $p < 0,001$)
- ▣ Gruparea este universală: acțiuni, crypto, un curs de schimb administrat și aur
- ▣ Cea mai slabă (dar tot decisivă) pentru Bitcoin și aur, cea mai puternică pentru S&P 500

Modelul ARCH al lui Engle (1982)

- Cadrul: $r_t = \mu + \varepsilon_t$, $\varepsilon_t = \sigma_t z_t$, inovațiile z_t i.i.d. cu media 0 și dispersia 1
 - ▶ Dispersia condiționată $\sigma_t^2 = \text{Var}(r_t \mid \mathcal{F}_{t-1})$ ($\mathcal{F}_{t-1}$: informația de la $t - 1$); necondiționată $\sigma^2 = \mathbb{E}\sigma_t^2$
- **ARCH(q)**: $\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2$ [Engle \(1982\)](#)
 - ▶ $\omega > 0$, $\alpha_i \geq 0$: dispersia este mereu pozitivă
- Un șoc mare ieri (ε_{t-1}^2 mare) crește dispersia de azi: grupare prin construcție
- ARCH(1): dispersia necondiționată $\sigma^2 = \omega / (1 - \alpha_1)$, finită dacă $\alpha_1 < 1$
 - ▶ Aplatizarea $3(1 - \alpha_1^2) / (1 - 3\alpha_1^2) > 3$ pentru z_t Normal: cozile groase apar chiar cu inovații Normale

Robert Engle și Premiul Nobel din 2003



Robert F. Engle (2022)

Foto: Jon Demske (2022); CC

BY-SA 4.0; Wikimedia Commons



Clive W.J. Granger (2008)

Foto: Olaf Storbeck (2008); CC

BY-SA 2.0; Wikimedia Commons

- **Premiul Nobel 2003:** Engle „pentru metode de analiză a seriilor de timp economice cu volatilitate variabilă în timp (ARCH)”
 - ▶ Împărțit cu Clive Granger (cointegrare)
- Prelegerea Nobel: [Engle \(2004\)](#), despre risc și volatilitate în practica financiară
- Tim Bollerslev, doctorandul lui Engle, a generalizat ARCH la GARCH în 1986

De la ARCH la GARCH (Bollerslev, 1986)

- Problema ARCH: gruparea în datele reale durează luni de zile, deci q trebuie să fie mare (mulți parametri)
- **GARCH(1,1)** [Bollerslev \(1986\)](#): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$
 - ▶ $\omega > 0, \alpha \geq 0, \beta \geq 0$; α : reacția la știri; β : memoria dispersiei trecute
- Prin substituție înapoi: $\sigma_t^2 = \frac{\omega}{1-\beta} + \alpha \sum_{j \geq 1} \beta^{j-1} \varepsilon_{t-j}^2$
 - ▶ Un ARCH(∞) cu ponderi descrescătoare geometric, cu doar trei parametri
- GARCH(p, q) adaugă decalaje; în practică GARCH(1,1) este modelul de bază [Hansen & Lunde \(2005\)](#)

GARCH(1,1) ca model ARMA pentru pătratele șocurilor

- Definim $\nu_t = \varepsilon_t^2 - \sigma_t^2$, surpriza din pătratul șocului ($\mathbb{E}[\nu_t | \mathcal{F}_{t-1}] = 0$)
- Atunci $\varepsilon_t^2 = \omega + (\alpha + \beta) \varepsilon_{t-1}^2 + \nu_t - \beta \nu_{t-1}$
 - ▶ Un ARMA(1,1) în ε_t^2 cu coeficientul autoregresiv $\alpha + \beta$
- Consecință: autocorelațiile lui ε_t^2 scad geometric, $\rho_k = \rho_1(\alpha + \beta)^{k-1}$
 - ▶ $\rho_1 = \alpha(1 - \beta^2 - \alpha\beta)/(1 - \beta^2 - 2\alpha\beta)$ dacă $\mathbb{E}\varepsilon_t^4 < \infty$ (Seminarul 5, A6)
 - ▶ S&P 500, GARCH(1,1) cu inovații Normale: $\rho_1 = 0,356$, $\rho_{10} = 0,298$; în eșantion 0,313 și 0,248
- De aceea $\alpha + \beta$ se numește **persistența** volatilității

Staționaritatea și dispersia necondiționată

- **Staționaritate în covarianță:** $\alpha + \beta < 1$; atunci

- ▶ $\sigma^2 = \mathbb{E}[\sigma_t^2] = \frac{\omega}{1 - \alpha - \beta}$

- Derivare: aplicăm media în recursie, $\mathbb{E}\sigma_t^2 = \omega + (\alpha + \beta) \mathbb{E}\sigma_{t-1}^2$, și impunem $\mathbb{E}\sigma_t^2 = \mathbb{E}\sigma_{t-1}^2$

- **IGARCH** (GARCH integrat): $\alpha + \beta = 1$; dispersia necondiționată este infinită

- ▶ Totuși procesul rămâne **strict** staționar: condiția este $\mathbb{E} \ln(\alpha z_t^2 + \beta) < 0$ [Nelson \(1990\)](#)

- Țintirea dispersiei: fixăm $\omega = \hat{\sigma}^2(1 - \alpha - \beta)$ cu dispersia de selecție $\hat{\sigma}^2$


Persistența și timpul de înjumătățire

- Prognoza pe mai mulți pași: $\mathbb{E}[\sigma_{t+h}^2 \mid \mathcal{F}_t] = \sigma^2 + (\alpha + \beta)^{h-1}(\sigma_{t+1}^2 - \sigma^2)$
 - Distanța față de dispersia de termen lung scade cu factorul $\alpha + \beta$ în fiecare zi
- **Timpul de înjumătățire:** numărul de zile după care jumătate dintr-un șoc de dispersie a dispărut
 - $(\alpha + \beta)^h = 0,5 \Rightarrow h_{1/2} = \frac{\ln 0,5}{\ln(\alpha + \beta)}$
- Exemple: $\alpha + \beta = 0,95$: 13,5 zile; 0,99: 69 de zile; 0,995: 138 de zile
- Schimbări mici ale lui $\alpha + \beta$ lângă 1 dau timpi de înjumătățire foarte diferiți: incertitudinea estimării contează (Seminarul 5)

Momentul de ordin patru și aplatizarea

- Cu z_t Normal, aplatizarea lui ε_t este $K = \frac{3[1 - (\alpha + \beta)^2]}{1 - (\alpha + \beta)^2 - 2\alpha^2}$
 - ▶ Finită doar dacă $(\alpha + \beta)^2 + 2\alpha^2 < 1$ (Seminarul 1, Exercițiul A9)
- S&P 500, GARCH(1,1) cu inovații Normale: $\hat{\alpha} = 0,1206$, $\hat{\beta} = 0,8599$
 - ▶ $(\hat{\alpha} + \hat{\beta})^2 + 2\hat{\alpha}^2 = 0,9904$: puțin sub 1, deci $K = 12,1$; aplatizarea de selecție a randamentelor: 13,7
- K este prost condiționat lângă frontiera momentelor: numitorul este $1 - 0,9904$
 - ▶ Rotunjirea la $\hat{\alpha} = 0,121$, $\hat{\beta} = 0,860$ dă 0,9916 și $K = 13,5$: raportați astfel de funcții din estimări nerotunjite
- Gruparea singură generează o mare parte din cozile groase; restul vine din z_t cu cozi groase (Secțiunea 6)

Simulare: GARCH produce gruparea volatilității



□ Sus: randamente Normale i.i.d.; jos: GARCH(1,1) cu aceeași dispersie necondiționată (1) și benzile $\pm 2\sigma_t$

Interpretare: grupare dintr-o regulă cu trei parametri

- Aceeași dispersie necondiționată, traiectorii foarte diferite: perioadele liniștite și rafalele apar doar în traiectoria GARCH
- Pe o traiectorie simulată lungă (un milion de zile)
 - ▶ Exces de aplatizare 2,47 (teoretic 3,06); autocorelația de ordin 1 a lui ε_t^2 : 0,26
 - ▶ Aplatizarea de selecție converge încet: precizia ei depinde de momentul de ordin opt, infinit pentru acești parametri
- Inovații Normale, dar randamente cu cozi groase: amestecul de dispersii creează cozile

EWMA: un caz particular de GARCH

- **EWMA** J.P. Morgan/Reuters (1996): $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, cu $\lambda = 0,94$ pentru date zilnice
 - ▶ Ponderi $(1 - \lambda)\lambda^{j-1}$ pe pătratele randamentelor trecute: zilele recente contează cel mai mult
- EWMA este un IGARCH(1,1) cu $\omega = 0$, $\alpha = 1 - \lambda$, $\beta = \lambda$: niciun parametru de estimat
- Prețul simplității: fără revenire la medie
 - ▶ Prognoza pentru orice orizont este egală cu dispersia de azi; GARCH o trage spre σ^2
- Folosim EWMA ca reper în comparația prognozelor din Secțiunea 7

Recapitulare: ARCH și GARCH

Idei-cheie

- ▣ σ_t^2 este dispersia dată fiind informația de ieri; se mișcă odată cu mărimea șocurilor recente
- ▣ $\text{GARCH}(1,1) = \text{ARCH}(\infty)$ cu trei parametri; $\alpha + \beta$ este persistența
- ▣ $\alpha + \beta < 1$: dispersie de termen lung finită $\omega/(1 - \alpha - \beta)$ și timp de înjumătățire $\ln 0,5 / \ln(\alpha + \beta)$
- ▣ Gruparea creează cozi groase, chiar cu inovații Normale
- ▣ EWMA este cazul particular IGARCH cu $\omega = 0$

Verosimilitatea maximă

- Parametrii $\theta = (\mu, \omega, \alpha, \beta)$; dat fiind θ , recursia produce $\sigma_1^2(\theta), \dots, \sigma_n^2(\theta)$
- Log-verosimilitatea Normală: $\ell(\theta) = -\frac{1}{2} \sum_{t=1}^n [\ln 2\pi + \ln \sigma_t^2 + \varepsilon_t^2 / \sigma_t^2]$
 - Fiecare zi contribuie cu densitatea lui ε_t condiționată de trecut: verosimilitatea se factorizează în timp
- Fără formulă explicită: optimizare numerică sub restricțiile $\omega > 0, \alpha, \beta \geq 0, \alpha + \beta < 1$
- Pornirea: σ_1^2 se fixează la dispersia de selecție (efectul său dispăre cu rata β)
- Scara: randamente în %, astfel încât dispersia să fie de ordinul 1
 - EUR/RON (abatere standard zilnică de circa 0,28%) se estimează pe 10 r_t : nescalat, optimizatorul s-a oprit într-un optim local

QMLE: consistență și normalitate asimptotică

- **QMLE Gaussian:** maximizăm verosimilitatea Normală chiar dacă z_t nu este Normal [Bollerslev & Wooldridge \(1992\)](#)
- **Consistența** (GARCH(1,1)) [Berkas, Horváth & Kokoszka \(2003\)](#), [Francq & Zakoïan \(2004\)](#)
 - ▶ Staționaritate strictă $\mathbb{E} \ln(\alpha z_t^2 + \beta) < 0$; θ_0 într-o mulțime compactă; z_t^2 nedegenerat
 - ▶ Nicio condiție de moment asupra lui ε_t : cazurile IGARCH și cu dispersie infinită sunt acoperite
- **Normalitatea asimptotică:** adăugăm θ_0 interior și $\kappa_z = \mathbb{E} z_t^4 < \infty$
 - ▶ $\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow N(0, (\kappa_z - 1)J^{-1})$, $J = \mathbb{E}[g_t g_t']$, $g_t = \partial \ln \sigma_t^2 / \partial \theta$
 - ▶ Rămâne valabilă și pentru $\alpha + \beta \geq 1$: [Lumsdaine \(1996\)](#) (IGARCH), [Jensen & Rahbek \(2004\)](#) (nestaționar)
- „Sandvișul” $\hat{A}^{-1} \hat{B} \hat{A}^{-1}$ estimează $(\kappa_z - 1)J^{-1}$; inversa hessianei $\hat{A}^{-1}$ estimează $2J^{-1}$
 - ▶ A: minus hessiana medie; B: dispersia scorului; e.s. robustă / clasică = $\sqrt{(\kappa_z - 1)/2}$, 1 sub normalitate

QMLE pe datele noastre: când teoria funcționează și când nu

- S&P 500, GARCH(1,1) cu verosimilitate Normală: applatizarea reziduurilor $\hat{\kappa}_z = 4,73$
 - ▶ Teoria: e.s. robustă / clasică = $\sqrt{(4,73 - 1)/2} = 1,37$; observat: 1,37 pentru $\hat{\alpha}$, 1,37 pentru $\hat{\beta}$
- Bitcoin: GARCH-t dă $\hat{\nu} = 3,18 < 4$, deci $\mathbb{E}z_t^4 = \infty$ și condiția normalității nu este îndeplinită
 - ▶ Aplatizarea reziduurilor nu se stabilizează: 19,8 pe prima jumătate, 14,6 pe tot eșantionul; rapoartele e.s. 2,51 și 2,01
- Hall & Yao (2003): atunci QMLE Gaussian converge mai lent decât $\sqrt{n}$, spre o limită non-Gaussiană: statisticile t robuste nu sunt valide
- Remedii: o cvasi-verosimilitate cu cozi groase Fan, Qi & Xiu (2014) sau MLE Student-t cu inferență prin bootstrap parametric

Inovații cu cozi groase

- **Student-t Bollerslev (1987)**: $z_t = \sqrt{(\nu - 2)/\nu} t_\nu$, dispersie unitară pentru $\nu > 2$
 - ▶ ν (grade de libertate): cu cât ν este mai mic, cu atât cozile sunt mai groase; momentul de ordin patru există doar pentru $\nu > 4$
- **t asimetric Hansen (1994)**: adaugă un parametru de asimetrie $\lambda \in (-1, 1)$
 - ▶ $\lambda < 0$: coada stângă este mai lungă (pierderile mari mai probabile decât câștigurile mari)
- **GED Nelson (1991)**: densitate $\propto \exp(-\frac{1}{2}|z/\lambda_\nu|^\nu)$
 - ▶ $\nu = 2$: distribuția Normală; $\nu = 1$: Laplace; $\nu < 2$: cozi mai groase (λ_ν asigură dispersia unitară)

Testarea la frontiera spațiului parametrilor

- $LR = 2(\ell_1 - \ell_0) \rightarrow \chi_m^2$ doar pentru restricții interioare (de ex. GJR față de GARCH: $\gamma = 0, m = 1$)
 - ▶ Modele neimbricate: $AIC = -2\ell + 2k$, $BIC = -2\ell + k \ln n$ (k parametri); mai mic este mai bun
- Restricțiile GARCH $\alpha, \beta \geq 0, 1/\nu \geq 0, \alpha + \beta \leq 1$ pun multe ipoteze nule **pe frontieră**
 - ▶ Un parametru pe frontieră: $LR \rightarrow \frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ [Self & Liang \(1987\)](#), [Andrews \(2001\)](#); valoarea critică la 5% este 2,71, nu 3,84
 - ▶ Cazuri: Normală vs Student-t ($1/\nu = 0$); GJR cu $\alpha = 0$; IGARCH; fără ARCH ($\alpha = 0, \beta$ neidentificat)
- Testele Wald t pentru un parametru estimat la limită (de ex. $\hat{\alpha} = 0$) nu sunt $N(0, 1)$
 - ▶ Bootstrap-ul parametric din $\hat{\theta}$ este inconsistent când θ_0 este pe frontieră [Andrews \(2000\)](#): simulăm în schimb sub H_0

Teste la frontieră pe datele noastre

- Inovații Normale vs Student-t, GARCH(1,1): $LR = 311,0$ (S&P 500), 1082,0 (Bitcoin)
 - ▶ Mult peste 2,71: cozile groase sunt decisive; amestecul contează doar în cazurile la limită
- GJR-t, S&P 500: $\hat{\alpha} = 0,000$; testul său t nu este standard, iar legea χ^2_1 a LR pentru $\gamma = 0$ presupune $\alpha_0 > 0$
- IGARCH, $H_0: \alpha + \beta = 1$ (GARCH-t): $LR = 1,11$ (S&P 500), 1,14 (BET)
 - ▶ S&P 500: $p = 0,29$ (χ^2_1), 0,15 (amestec), 0,17 (bootstrap parametric sub H_0 , $B = 999$)
 - ▶ BET: $p = 0,28$, 0,14 și 0,17
- Sub H_0 , 52% din reestimări sunt la $\alpha + \beta = 1$, cum prezice amestecul: rădăcina unitară în dispersie nu poate fi respinsă pentru niciunul dintre indici

S&P 500: estimările GARCH(1,1)-t

Parametru	Estimare	E.s. robustă	E.s. clasică	Raport
ω	0,0157			
α	0,123	0,011	0,010	1,06
β	0,872	0,010	0,010	1,08
ν	6,26	0,48		
$\alpha + \beta$	0,9947			

- Randamente zilnice în %, 2000–2026; media $\hat{\mu} = 0,079\%$ pe zi
- Timp de înjumătățire 131 zile; volatilitatea de termen lung $\sqrt{252 \hat{\omega} / (1 - \hat{\alpha} - \hat{\beta})} = 27,3\%$ anual

Interpretare: estimările pentru S&P 500

- ▣ $\hat{\beta} = 0,872$: cea mai mare parte a dispersiei de azi este dispersia de ieri; $\hat{\alpha} = 0,123$: știrile adaugă o actualizare moderată
- ▣ Persistența 0,9947: șocurile de volatilitate durează luni, nu zile
- ▣ Volatilitatea de termen lung (27,3%) depășește volatilitatea de selecție (19,2%)
 - Lângă $\alpha + \beta = 1$, $\omega/(1 - \alpha - \beta)$ împarte la un număr foarte mic și este imprecisă
- ▣ $\hat{\nu} = 6,26$: inovațiile au cozi clar mai groase decât distribuția Normală
- ▣ Erorile standard robuste sunt cu circa 5–7% mai mari decât cele clasice pentru α și β

S&P 500: douăsprezece modele comparate prin BIC

ΔBIC	$N(0, 1)$	Student-t	t asimetric	GED
GARCH(1,1)	648,9	346,7	307,4	339,8
GJR-GARCH(1,1)	394,7	119,9	49,6	141,6
EGARCH(1,1)	372,9	74,8	0,0	111,4

- ▣ ΔBIC : BIC minus cel mai mic BIC dintre cele 12 modele (0 = modelul preferat)
- ▣ Contează două alegeri: o ecuație a dispersiei asimetrică și o inovație cu cozi groase și asimetrică
- ▣ Trecerea de la inovații Normale la inovații Student-t scade BIC cu circa 300; adăugarea asimetriei îl mai scade cu 230–270
- ▣ Câștigător: EGARCH cu inovații t asimetrice; Secțiunile 5–6 explică de ce

Recapitulare: Estimare


Idei-cheie

- ▣ GARCH se estimează prin verosimilitate maximă; verosimilitatea se construiește zi cu zi din recursie
- ▣ QMLE este consistent fără condiții de moment; normalitatea sa în $\sqrt{n}$ cere $\mathbb{E}z_t^4 < \infty$, condiție care nu se verifică la Bitcoin
- ▣ Student-t, t asimetric și GED surprind cozile pe care GARCH singur le lasă
- ▣ Ipoteze nule pe frontieră ($1/\nu = 0$, $\alpha = 0$): LR față de $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$; IGARCH: simulăm sub H_0
- ▣ Rescalăm seriile cu volatilitate mică; comparăm modelele neimbricate cu AIC/BIC

Exemplu lucrat: prognozele pe o zi și pe zece zile

- S&P 500, GARCH(1,1)-t: $\hat{\omega} = 0,0157$, $\hat{\alpha} = 0,123$, $\hat{\beta} = 0,872$, $\hat{\mu} = 0,079$
- Ultima zi $T = 18.09.2026$: $\hat{\varepsilon}_T = r_T - \hat{\mu} = 0,088$, dispersia filtrată $\hat{\sigma}_T^2 = 0,565$
 - ▶ $\hat{\sigma}_{T+1}^2 = \hat{\omega} + \hat{\alpha}\hat{\varepsilon}_T^2 + \hat{\beta}\hat{\sigma}_T^2 = \hat{\omega} + 0,0009 + 0,493 = 0,509$, adică 11,3% anual
- Dispersia de termen lung $\hat{\sigma}^2 = \hat{\omega}/(1 - \hat{\alpha} - \hat{\beta}) = 2,97$; ziua 10: $\hat{\sigma}^2 + (\hat{\alpha} + \hat{\beta})^9(\hat{\sigma}_{T+1}^2 - \hat{\sigma}^2)$
 - ▶ $= 2,97 + 0,953 \times (0,509 - 2,97) = 0,624$
- Dispersia pe 10 zile $\sum_{h=1}^{10} \hat{\sigma}_{T+h}^2 = 5,67$, volatilitatea 2,38%
 - ▶ Regula rădăcinii pătrate a timpului dă $\sqrt{10} \times 0,714 = 2,26\%$: prea puțin, deoarece $\hat{\sigma}_{T+1}^2 < \hat{\sigma}^2$ și volatilitatea este prognozată în creștere

Structura la termen a volatilității



□ Prognoza, din 18.09.2026, a volatilității medii pe următoarele h zile (GARCH(1,1)-t); punctat: nivelul de termen lung

Interpretare: revenire la medie sau nu

- ▣ S&P 500: de la 11,3% (ziua următoare) la 20,1% (un an), urcând încet spre nivelul de termen lung
- ▣ Aur: azi peste nivelul de termen lung, deci curba scade, de la 23,9% la 22,4%
- ▣ Bitcoin și EUR/RON: $\hat{\alpha} + \hat{\beta} = 1$ (IGARCH), fără nivel de termen lung
 - ▶ Prognoza dispersiei crește cu $\hat{\omega}$ pe zi: Bitcoin de la 54,1% la 108,3% într-un an
 - ▶ Un artefact al estimării cu rădăcină unitară, nu o predicție pe care să tranzacționăm
- ▣ Prognozele GARCH pe orizonturi lungi moștenesc toată incertitudinea despre $\alpha + \beta$

GARCH(1,1)-t pe șase piețe


Serie	$\hat{\omega}$	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\alpha} + \hat{\beta}$	$h_{1/2}$ (zile)	$\hat{\nu}$	Vol. termen lung
S&P 500	0,0157	0,123	0,872	0,9947	131	6,26	27,3
BET	0,0448	0,192	0,799	0,9907	74	5,01	34,7
BET-TR	0,0755	0,206	0,713	0,9188	8	5,02	15,2
Bitcoin	0,1937	0,109	0,891	1,0000	∞	3,18	–
EUR/RON	0,0000	0,123	0,877	1,0000	∞	4,20	–
Aur	0,0107	0,049	0,944	0,9935	106	4,58	20,7

- ▣ Volatilitatea de termen lung în % anual (anualizată cu frecvența proprie a fiecărei serii); – când $\hat{\alpha} + \hat{\beta} \geq 0,999$
- ▣ EUR/RON: $\hat{\omega}$ este 0,0000 la patru zecimale (cursul se mișcă cu fracțiuni de ban în cele mai multe zile)

Interpretare: șase „personalități” ale volatilității

- Acțiuni (S&P 500, BET) și aur: persistență 0,99–0,995, timpi de înjumătățire de 3–6 luni de tranzacționare
- BET reacționează mai puternic la știri ($\hat{\alpha} = 0,192$) și uită mai repede decât S&P 500
 - ▶ BET-TR (doar 2014–2026): timp de înjumătățire 8 zile; un eșantion mai scurt și mai calm dă o persistență mai mică
- Bitcoin: cele mai groase cozi ($\hat{\nu} = 3,18$, momentul de ordin patru infinit) și rădăcină unitară în dispersie
- EUR/RON: un curs de schimb administrat; perioade lungi liniștite, apoi salturi
 - ▶ 6 mai 2025: +1,20% după zile de $\pm 0,004\%$: reziduu standardizat de 154

Persistența: cât de repede se sting șocurile?



□ Partea dintr-un șoc de dispersie încă prezentă după h zile, $(\hat{\alpha} + \hat{\beta})^h$; linia întreruptă: o jumătate


Interpretare: persistența

- ▣ Timpi de înjumătățire: S&P 500 131 zile, aur 106, BET 74, BET-TR 8
- ▣ Bitcoin și EUR/RON sunt pe linia orizontală: un $\alpha + \beta$ estimat de 1 înseamnă că șocurile nu se sting niciodată în model
- ▣ O persistență foarte mare poate fi falsă: schimbările de nivel ale volatilității imită o rădăcină unitară [Lamoureux & Lastrapes \(1990\)](#)
 - ▶ Alternative cu schimbare de regim: [Hamilton & Susmel \(1994\)](#)
- ▣ Regulă practică: raportați timpii de înjumătățire cu un interval de încredere (bootstrap parametric, Seminarul 5)

Metoda delta pentru volatilitatea de termen lung și timpul de înjumătățire

- Pentru o funcție netedă $g(\theta)$: $\widehat{e.s.} g(\hat{\theta}) \approx \sqrt{\nabla g' \hat{V} \nabla g}$, cu $\hat{V}$ covarianța robustă a lui $(\hat{\omega}, \hat{\alpha}, \hat{\beta})$
- S&P 500, GARCH(1,1)-t: volatilitatea de termen lung 27,4% anual, e.s. 10,8 puncte: gradientul este scalat cu $1/(1 - \alpha - \beta)^2$
- Timpul de înjumătățire $h = \ln 0,5 / \ln p$, $p = \alpha + \beta$: $\partial h / \partial p = -\ln 0,5 / [p (\ln p)^2] = 24\,789$ la $\hat{p} = 0,9947$
 - ▶ $\widehat{e.s.}(\hat{p}) = 0,0047$, deci $\widehat{e.s.}(\hat{h}) \approx 116$ zile pentru $\hat{h} = 131$: un interval simetric ar include timpi de înjumătățire negativi
- Liniarizarea eșuează deoarece $h(p)$ explodează când $p \rightarrow 1$
 - ▶ Transformăm în schimb un interval pentru p (h este monotonă): $[0,9855; 1,0039]$ dă $h \in [48; \infty)$
 - ▶ Sau folosim un bootstrap parametric și un test simulat sub H_0 (Seminarul 5, B7)

S&P 500: volatilitatea GARCH și VIX




- Volatilitatea condiționată GARCH(1,1)-t anualizată $\hat{\sigma}_t \sqrt{252}$ și VIX, volatilitatea implicită pe 30 de zile, 2000–2026

Interpretare: volatilitate statistică și volatilitate implicită

- ▣ Corelația celor două serii: 0,89; GARCH folosește doar randamentele trecute, VIX folosește prețurile opțiunilor
- ▣ VIX mediu 19,8% față de volatilitatea GARCH medie 17,0%; VIX este mai mare în 84% din zile
 - ▶ Diferența este **prima de risc a dispersiei**: cumpărătorii de opțiuni plătesc pentru asigurarea împotriva volatilității
- ▣ Intervalul GARCH: de la 6,2% (octombrie 2017) la 111% (martie 2020)
- ▣ GARCH reacționează cu o zi întârziere prin construcție: are nevoie de șoc înainte să se miște

Detaliu: prăbușirea COVID-19, 2020




■ Ianuarie–iulie 2020: randamente absolute (anualizate), volatilitatea GARCH-t și GJR-GARCH-t, VIX

MFM_ch5_sp500_vix

Interpretare: COVID-19

- ▣ 16 martie 2020: $r_t = -12,8\%$, cea mai mare scădere zilnică din eșantion; VIX a închis la 82,7%
- ▣ Volatilitatea maximă a modelelor pe 17 martie: GARCH-t 111%, GJR-GARCH-t 127%
 - ▶ GJR urcă mai sus deoarece șocurile au fost negative (Secțiunea 5)
- ▣ 24 februarie 2020 ($r_t = -3,41\%$): VIX a sărit în aceeași zi, de la 17,1% la 25,0%
 - ▶ GARCH-t s-a mișcat abia a doua zi, de la 12,2% la 22,5%: piețele evaluează știrile imediat, GARCH doar reacționează
- ▣ După vârf, volatilitatea scade cu rata $\alpha + \beta$ pe zi, cum prezice modelul

BET, Bitcoin, EUR/RON și aur



- Volatilitatea condiționată GJR-GARCH-t, anualizată cu frecvența fiecărei serii (Bitcoin: 365 de zile)

Interpretare: patru piețe

- ▣ BET: criza din 2008 domină; apoi vârfuri scurte și abrupte; nivelul actual 26,4%
- ▣ Bitcoin: volatilitatea de 50–100% este normală; martie 2020 este vârful cel mai înalt
- ▣ EUR/RON: volatilitate mare până în 2012, apoi o perioadă lungă de calm administrat, cu rafale în 2022 și 2025
 - ▶ Volatilitate aproape de zero în multe zile: un GARCH zilnic descrie slab un curs administrat
- ▣ Aur: vârfuri de 52% (2008), 31% (2013), 41% (2020) și un nou maxim de 53% în 2026

Recapitulare: Rezultate pe piețe

Idei-cheie

- ▣ Prognozele pe un pas și pe mai mulți pași rezultă din recursie; dispersia pe 10 zile este suma dispersiilor zilnice
- ▣ Persistența este mare peste tot; timpii de înjumătățire variază de la circa o săptămână (BET-TR) la câteva luni
- ▣ Rădăcinile unitare estimate (Bitcoin, EUR/RON) fac prognozele de termen lung lipsite de sens
- ▣ GARCH urmărește îndeaproape VIX, dar cu întârziere; VIX este mai mare în medie (prima de risc a dispersiei)

Știrile proaste mișcă volatilitatea mai mult

- ▣ Faptul stilizat 9 (Capitolul 1): randamentele negative cresc volatilitatea viitoare mai mult decât cele pozitive de aceeași mărime
- ▣ **Efectul de levier:** un preț în scădere crește raportul datorii/capital propriu, deci acțiunea devine mai riscantă
 - ▶ **Feedback-ul volatilității:** volatilitatea așteptată mai mare crește randamentul cerut, deci prețurile scad acum
- ▣ GARCH(1,1) nu vede semnul: ε_{t-1}^2 este același pentru -3 și $+3$
- ▣ Două soluții: GJR adaugă un termen pentru șocurile negative, EGARCH modelează logaritmul dispersiei

GJR-GARCH (Glosten, Jagannathan și Runkle, 1993)

- $\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, cu $I_{t-1} = 1$ dacă $\varepsilon_{t-1} < 0$ Glosten, Jagannathan & Runkle (1993)
 - ▶ Știri bune: panta α ; știri proaste: panta $\alpha + \gamma$; $\gamma > 0$ înseamnă asimetrie
- Persistența cu z_t simetric: $\alpha + \gamma/2 + \beta$ (jumătate din șocuri sunt negative)
 - ▶ Dispersia de termen lung $\omega/(1 - \alpha - \gamma/2 - \beta)$
- Testul simetriei: $H_0: \gamma = 0$ printr-un test t sau prin LR față de GARCH(1,1)
- S&P 500: $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t = 10,0$), $\hat{\beta} = 0,881$


EGARCH (Nelson, 1991)

- $\ln \sigma_t^2 = \omega + \alpha (|z_{t-1}| - \mathbb{E}|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$ Nelson (1991)
 - ▶ Efectul de mărime α , efectul de semn γ ; $\gamma < 0$: șocurile negative cresc volatilitatea mai mult
- Forma logaritmică păstrează $\sigma_t^2 > 0$ fără restricții de semn asupra parametrilor
- Persistența: β (staționar dacă $|\beta| < 1$)
- S&P 500: $\hat{\alpha} = 0,138$, $\hat{\gamma} = -0,165$ ($t = -15,2$), $\hat{\beta} = 0,979$
- În arch, $\mathbb{E}|z|$ este fixat la $\sqrt{2/\pi}$, valoarea sa sub distribuția Normală

Curba de impact a știrilor

- **Curba de impact a știrilor Engle & Ng (1993):** σ_t^2 ca funcție de ε_{t-1} , cu σ_{t-1}^2 fixat la dispersia de selecție
 - ▶ GARCH: o parabolă simetrică în jurul lui 0
 - ▶ GJR: două semi-parabole cu pante diferite
 - ▶ EGARCH: exponențială în $|\varepsilon|$, înclinată de γ
- Ea izolează modul în care fiecare model transformă o zi de știri în dispersia de mâine
- Engle și Ng propun și testele de asimetrie folosite la diagnostic (Secțiunea 6)

Curbe de impact al știrilor pentru S&P 500



□ Dispersia de a doua zi după un șoc ε_{t-1} (în %), pentru cele trei modele estimate cu inovații Student-t

Interpretare: impactul știrilor

- ▣ Dispersia de pornire 1,47 (dispersia de selecție, %²)
- ▣ Un șoc de -3% : GJR dă 3,16, EGARCH 2,76; un șoc de $+3\%$: GJR 1,31, EGARCH 1,22
 - ▶ Știrile proaste cresc dispersia de 2,4 ori mai mult decât știrile bune în GJR, de 2,3 ori în EGARCH
- ▣ GARCH simetric dă 2,40 pentru ambele semne: prea mult după știrile bune, prea puțin după cele proaste
- ▣ Pentru S&P 500, $\hat{\alpha} = 0$ în GJR: șocurile pozitive nu cresc deloc volatilitatea

Asimetria pe șase piețe

Serie	$\hat{\gamma}_{GJR}$	t	LR vs GARCH	valoare p	$\hat{\gamma}_{EGARCH}$	t
S&P 500	0,205	10,0	235,7	< 0,001	-0,165	-15,2
BET	0,043	2,1	4,9	0,026	-0,028	-2,6
BET-TR	0,111	2,9	10,3	0,001	-0,063	-3,5
Bitcoin	-0,013	-0,7	0,7	0,416	0,015	1,2
EUR/RON	0,039	3,0	9,3	0,002	-0,040	-2,5
Aur	-0,043	-4,7	27,6	< 0,001	0,038	5,7

- ▣ Toate modelele cu inovații Student-t; statistici t cu erori standard robuste; $LR \sim \chi_1^2$ (valoarea critică 3,84)
- ▣ Asimetria: $\hat{\gamma} > 0$ în GJR și $\hat{\gamma} < 0$ în EGARCH pentru aceeași direcție (știrile proaste contează mai mult)

Interpretare: unde este efectul de levier?

- S&P 500: foarte puternic ($LR = 235,7$); efectul de levier clasic al unui indice bursier dezvoltat
 - ▶ BET și BET-TR: prezent, dar slab ($LR = 4,9$ și $10,3$)
- Bitcoin: fără asimetrie ($LR = 0,7$); creșterile crypto sunt la fel de volatile ca prăbușirile
- Aur: asimetrie **inversă** ($\hat{\gamma}_{GJR} = -0,043$): creșterile de preț cresc volatilitatea mai mult
 - ▶ Consistent cu aurul ca activ de refugiu: crește în perioadele agitate
- EUR/RON: GJR $\hat{\gamma} > 0$, EGARCH $\hat{\gamma} < 0$: scăderile cursului (aprecierea leului) cresc volatilitatea ceva mai mult

Recapitulare: Asimetrie

Idei-cheie

- GARCH simetric ignoră semnul știrilor; datele bursiere resping puternic această ipoteză
- GJR adaugă o pantă γ pentru șocurile negative; EGARCH modelează $\ln \sigma_t^2$ cu un termen de semn
- Curba de impact a știrilor arată direct asimetria
- Asimetria este un fenomen al acțiunilor: absentă la Bitcoin, inversată la aur



Reziduurile standardizate: ce trebuie să fie adevărat

- ▣ **Reziduul standardizat:** $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$; dacă modelul este corect, $\hat{z}_t$ este aproape i.i.d. cu dispersia 1
- ▣ Verificări
 - ▶ Fără autocorelație în $\hat{z}_t$: Ljung–Box $Q(10)$ pe $\hat{z}_t$ (ecuația mediei)
 - ▶ Fără grupare rămasă: $Q(10)$ pe $\hat{z}_t^2$ și testul LM(5) (ecuația dispersiei)
 - ▶ Fără asimetrie rămasă: testele de asimetrie [Engle & Ng \(1993\)](#)
 - ▶ Distribuția: comparăm $\hat{z}_t$ cu densitatea presupusă (grafic QQ)

Testele de asimetrie (Engle și Ng, 1993)

- ▣ Regresăm $\hat{z}_t^2 = b_0 + b_1 S_{t-1}^- + b_2 S_{t-1}^- \hat{z}_{t-1} + b_3 S_{t-1}^+ \hat{z}_{t-1} + u_t$
 - ▶ $S_{t-1}^- = 1$ dacă $\hat{z}_{t-1} < 0$, altfel 0; $S_{t-1}^+ = 1 - S_{t-1}^-$
- ▣ **Asimetria de semn** (b_1): doar șocurile negative cresc pătratul reziduului următor?
- ▣ **Asimetria de mărime negativă / pozitivă** (b_2, b_3): contează mărimea șocurilor negative / pozitive dincolo de model?
- ▣ Testul comun: $nR^2 \sim \chi_3^2$ (valoarea critică la 5%: 7,81)

S&P 500: sunt inovațiile Normale?



□ Reziduurile standardizate ale GARCH(1,1) cu inovații Normale: log-densitatea și graficul QQ față de Normală și Student-t

Interpretare: cozile după GARCH

- ▣ Excesul de aplatizare scade de la 10,7 (randamente) la 1,73 (reziduuri standardizate): GARCH explică cea mai mare parte
- ▣ Dar nu tot: Jarque–Bera 1153; asimetria -0,53
 - ▶ 15 reziduuri sub -4 ; distribuția Normală se așteaptă la 0,21, o Student-t cu $\nu = 6,3$ la 8,5
 - ▶ Cel mai mare: $\hat{z} = -6,6$ pe 27 februarie 2007, o scădere mare într-o perioadă calmă
- ▣ Coadă stângă este mai lungă decât cea dreaptă: t asimetric cu $\hat{\lambda} = -0,150$ (GJR, $\hat{\eta} = 7,7$)
- ▣ De aceea BIC preferă inovațiile t asimetrice pentru S&P 500

S&P 500: diagnosticul a cinci modele

Model	$Q(10)$ pe $\hat{z}$	$Q(10)$ pe $\hat{z}^2$	LM(5)	Asim. semn t	Comun χ^2_3
GARCH-N	21,2	16,4	8,0	2,59	44,5
GARCH-t	21,9	13,6	5,8	2,47	39,3
GJR-t	22,3	10,2	4,5	3,96	23,5
EGARCH-t	27,6	10,5	8,2	2,95	8,8
GJR-t asimetric	19,7	10,7	5,0	4,22	27,1

- ▣ Valori critice la 5%: χ^2_{10} : 18,3; χ^2_5 : 11,1; χ^2_3 : 7,81; $|t| > 1,96$
- ▣ Înainte de modelare, $Q(10)$ pe r_t^2 era 6133


Interpretare: ce spun diagnosticele

- ▣ Gruparea a dispărut pentru toate modelele: $Q(10)$ pe $\hat{z}^2$ scade de la 6133 la 10–16, LM(5) nu este semnificativ
- ▣ GARCH simetric pică testul de asimetrie (comun 39,3): asimetrie rămasă
 - ▶ GJR tot pică (23,5); EGARCH se apropie cel mai mult (8,8, $p = 0,032$)
- ▣ $Q(10)$ pe $\hat{z}$ în jur de 20–28: o autocorelație în medie, pe care media constantă o ignoră
- ▣ Cu $n = 6\,714$, efectele mici sunt semnificative: judecați mărimea economică, nu doar valorile p

Diagnosticul reziduurilor are parametri estimați

- $\hat{z}_t$ depinde de $\hat{\theta}$: statistica Ljung–Box pe $\hat{z}_t^2$ nu este exact χ_m^2 Li & Mak (1994)
 - ▶ Autocorelațiile pătratelor reziduurilor $\hat{r}_k$: $\sqrt{n} \hat{r} \rightarrow N(0, C)$, $C = I - H' J^{-1} H / (\kappa_z - 1)$
 - ▶ $H_k = \mathbb{E}[g_t(z_{t-k}^2 - 1)]$: cât din dependența de ordin k absoarbe dispersia estimată; regula ARMA χ_{m-p-q}^2 nu se aplică
- S&P 500, QMLE Gaussian pentru GARCH(1,1): $C_{1,1} = 0,78$, $C_{5,5} = 0,93$, $C_{10,10} = 0,97$
 - ▶ Corecția este cea mai mare la decalaje mici, unde $\hat{\alpha}$ a preluat deja dependența
- $Q(10)$ pe $\hat{z}_t^2$: Ljung–Box 16,4 ($p = 0,089$); corectat $n \hat{r}' C^{-1} \hat{r} = 19,1$ ($p = 0,038$): verdictul la 5% se inversează
- Testul naiv este conservator: respinge prea rar o ecuație a dispersiei greșit specificată; testul comun de asimetrie are aceeași limită

Diagnostic: pătratele randamentelor și pătratele reziduurilor



- S&P 500: autocorelațiile lui r_t^2 și ale lui $\hat{z}_t^2$ din GJR-GARCH-t, decalaje 1–30
- După model, autocorelațiile sunt în interiorul benzii i.i.d.: dinamica dispersiei este surprinsă

Diagnostic pe alte piețe

- BET: $Q(10)$ pe $\hat{z} = 116,6$: autocorelație puternică în medie (tranzacționare redusă, Capitolul 2)
 - ▶ Remediul: o ecuație a mediei AR(1), $r_t = \mu + \phi r_{t-1} + \varepsilon_t$
- Bitcoin: ecuația dispersiei trece ($Q(10)$ pe $\hat{z}^2 = 4,7$), fără asimetrie (comun 2,3)
- EUR/RON: exces de aplatizare reziduală 3190, provocat de un singur reziduu de 154 (mai 2025)
 - ▶ O singură observație poate domina diagnosticele: priviți mereu cele mai mari reziduuri
- Aur: EGARCH lasă grupare ($Q(10)$ pe $\hat{z}^2 = 48,8$) deși BIC-ul său este printre cele mai bune

Recapitulare: Inovații și diagnostic

Idei-cheie

- ▣ Reziduurile standardizate trebuie să arate i.i.d.: le testăm nivelul, pătratele și semnele
- ▣ GARCH elimină gruparea și cea mai mare parte a aplatizării, nu și asimetria
- ▣ Pentru S&P 500 sunt necesare atât inovațiile cu cozi groase și asimetrice, cât și dispersia asimetrică
- ▣ Diagnosticile pot contrazice criteriile informaționale; un singur reziduu extrem le poate determina

Problema variabilei aproximative

- Volatilitatea nu este observată niciodată: comparăm prognozele cu o **aproximare** zgomotoasă, de ex. r_t^2
- $r_t^2 = \sigma_t^2 z_t^2$ este nedeplasat ($\mathbb{E}[r_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2$ pentru $\mu = 0$), dar foarte zgomotos
 - ▶ R^2 -ul său față de dispersia reală este mic chiar pentru o prognoză perfectă [Andersen & Bollerslev \(1998\)](#)
- [Patton \(2011\)](#): doar unele funcții de pierdere ordonează corect prognozele cu o aproximare zgomotoasă
 - ▶ Robuste: $\text{MSE } (r_t^2 - h_t)^2$ și **QLIKE** $r_t^2/h_t + \ln h_t$, cu h_t prognoza dispersiei
 - ▶ Nerobuste: pierderile pe volatilitate $|r_t| - \sqrt{h_t}$ sau pe logaritmi
- QLIKE este (până la constante) minus log-verosimilitatea Normală; penalizează mai mult subestimarea


Mincer–Zarnowitz și Diebold–Mariano

- **Regresia Mincer–Zarnowitz** Mincer & Zarnowitz (1969): $r_t^2 = a + b h_t + u_t$
 - ▶ Prognoză nedeplasată: $a = 0$, $b = 1$ (test Wald comun cu erori HAC); R^2 măsoară conținutul informațional
 - ▶ $b < 1$: prognoze prea dispersate (prea mari când sunt mari, prea mici când sunt mici)
- **Testul Diebold–Mariano** Diebold & Mariano (1995): diferența de pierderi $d_t = L(r_t^2, h_t^A) - L(r_t^2, h_t^B)$
 - ▶ $DM = \bar{d} / \widehat{s.e.}(\bar{d})$ cu eroare standard HAC; $\approx N(0, 1)$ sub acuratețe egală
 - ▶ $DM < -1,96$: modelul A semnificativ mai bun

Designul în afara eșantionului

- ▣ S&P 500; perioada de prognoză 2016–2026: 2 692 prognoze pentru ziua următoare
- ▣ Parametrii reestimați la începutul fiecărui an pe toate datele din 2000 (fereastră în expansiune)
 - ▶ În cursul anului, dispersia este actualizată zilnic cu parametri ficși: fără informație din viitor
- ▣ Modele: GARCH cu inovații Normale și Student-t, GJR-t, EGARCH-t
- ▣ Repere: EWMA ($\lambda = 0,94$) și dispersia istorică pe 20 de zile (Hist-20)
- ▣ De asemenea, prognoze ale dispersiei cumulate pe 22 de zile (o lună) pe 122 ferestre nesuprapuse

Proгноze și mișcări realizate, 2016–2026




□ Prognozele volatilității pentru ziua următoare (anualizate) din GJR-GARCH-t și EWMA; puncte turcoaz: $|r_t|\sqrt{252}$

S&P 500: evaluarea prognozelor, 2016–2026

Model	QLIKE	MSE	DM t vs GARCH-t	MZ b	MZ R^2	Wald p
GARCH-N	0,751	22,3	-1,47	0,97	0,250	1,00
GARCH-t	0,757	22,8	—	0,88	0,238	0,80
GJR-t	0,732	21,8	-1,22	0,84	0,276	0,68
EGARCH-t	0,745	21,3	-0,36	1,24	0,293	0,71
EWMA	0,815	24,7	3,48	0,89	0,172	0,69
Hist-20	0,889	26,1	4,10	0,68	0,152	0,03

- Pierderi medii pe 2692 zile; DM pe QLIKE, HAC cu 5 decalaje; t negativ: mai bun decât GARCH-t
- MZ: $r_t^2 = a + b h_t$; Wald p: testul $a = 0$, $b = 1$

QLIKE relativ la GARCH-t



- QLIKE mediu al fiecărui model minus cel al GARCH-t, cu statistica t Diebold–Mariano

Interpretare: bate ceva GARCH(1,1)?

- Cel mai bun QLIKE: GJR-t (0,732); dar diferențele din familia GARCH nu sunt semnificative (DM t de la -1,22 la -0,36)
- EWMA și Hist-20 sunt semnificativ mai slabe (DM t = 3,48 și 4,10)
 - ▶ Revenirea la medie și parametrii estimați aduc un câștig
- MZ: prognozele de tip GARCH sunt nedeplasate (b aproape de 1, Wald $p > 0,6$); Hist-20 nu este ($p = 0,03$)
- R^2 de doar 0,15–0,29: zgomotul lui r_t^2 , nu un model prost
- Același mesaj ca Hansen & Lunde (2005): GARCH(1,1) este greu de bătut; asimetria ajută puțin la acțiuni

Compararea prognozelor din modele estimate și imbricate


- DM tratează prognozele ca date; ale noastre vin din parametri estimați, iar GARCH-t este imbricat în GJR-t
 - ▶ Fereastră în expansiune, modele imbricate: sub H_0 diferența de pierderi degenerează, deci DM nu este $N(0, 1)$ West (1996), Clark & McCracken (2001)
- Giacomini & White (2006): testăm **metoda** de prognoză (model + fereastră mobilă de lungime fixă W)
 - ▶ Valid pentru modele imbricate și parametri estimați, deoarece zgomotul estimării nu dispare
 - ▶ Testul condițional $\mathbb{E}[d_{t+1} | \mathcal{F}_t] = 0$ cu instrumentele $h_t = (1, d_t)$: $GW = n \bar{Z}' \hat{\Omega}^{-1} \bar{Z} \rightarrow \chi^2_2$, $Z_{t+1} = h_t d_{t+1}$
- Șase modele și cinci teste DM pe perechi: o problemă de comparații multiple
 - ▶ **Model Confidence Set Hansen, Lunde & Nason (2011)**: eliminăm cel mai slab model până când acuratețea egală nu mai este respinsă; mulțimea conține cel mai bun model cu probabilitatea $\geq 1 - \alpha$

S&P 500: testele Giacomini–White și Model Confidence Set

Model	QLIKE (W)	t necond.	GW	p	MCS p
GARCH-N	0,751	1,87	5,85	0,054	0,586
GARCH-t	0,743	—	—	—	0,353
GJR-t	0,738	-0,18	2,49	0,288	1,000
EGARCH-t	0,746	0,07	3,21	0,201	0,586
EWMA	0,815	3,20	11,40	0,003	0,008
Hist-20	0,889	3,87	16,41	< 0,001	0,001

- Fereastră mobilă $W = 1\,000$ de zile, reestimată în fiecare ianuarie, 2 692 prognoze; teste față de GARCH-t, HAC cu 5 decalaje
- MCS pe prognozele cu fereastră în expansiune din Secțiunea 7: QLIKE, statistica T_R , bootstrap staționar (bloc mediu 10, 10 000 de extrageri)
- MCS 90%: GARCH-N, GARCH-t, GJR-t, EGARCH-t; EWMA și Hist-20 excluse: același verdict ca DM, acum cu rata erorii controlată

Proгноze pe o lună: Mincer-Zarnowitz în logaritmi



- Prognoza GJR-GARCH-t a dispersiei pe 22 de zile față de suma realizată a 22 de pătrate ale randamentelor, 122 ferestre nesuprapuse

Interpretare: orizontul lunar

- ▣ Agregarea a 22 de zile reduce zgomotul aproximării: R^2 în logaritmi 0,38 (GJR-t), față de 0,28 pentru o zi, în niveluri
- ▣ Panta $b = 0,75$ (e.s. 0,07): prognozele lunare sunt prea dispersate
 - ▶ Prognozele mari sunt urmate de mai puțină dispersie decât s-a prezis: consistent cu o revenire la medie mai rapidă decât implică $\alpha + \beta$
- ▣ În niveluri panta este doar 0,27: două ferestre COVID-19 (februarie și martie 2020) domină regresia
- ▣ Evaluați în logaritmi sau cu QLIKE când câteva luni de criză au dispersii uriașe

Recapitulare: Prognoză

Idei-cheie


- ▣ Evaluăm prognozele în afara eșantionului, cu parametri estimați doar pe datele trecute
- ▣ Cu o aproximare zgomotoasă folosim pierderi robuste (QLIKE, MSE) și testul Diebold–Mariano
- ▣ Modele imbricate cu parametri estimați: Giacomini–White cu fereastră mobilă; multe modele: Model Confidence Set
- ▣ Mincer–Zarnowitz verifică nedeplasarea; un R^2 mic la o zi este de așteptat
- ▣ GARCH bate EWMA și dispersia istorică; membrii familiei GARCH sunt greu de departajat

GARCH-in-mean: este riscul recompensat?

- ▣ **GARCH-M** Engle, Lilien & Robins (1987): $r_t = c + \kappa \sigma_t + \varepsilon_t$ (sau $\kappa \sigma_t^2$)
 - ▶ $\kappa > 0$: investitorii cer un randament așteptat mai mare când riscul este mai mare (compromisul risc–randament)
- ▣ S&P 500, GARCH(1,1)-t în medie: $\hat{\kappa} = 0,096$ (t = 3,02) cu σ_t ; 0,028 (t = 2,35) cu σ_t^2
 - ▶ Pozitiv și semnificativ în acest eșantion, dar literatura este împărțită: GJR (1993) au găsit o relație negativă
- ▣ Atenție: un efect zilnic în medie este mic și fragil; depinde de eșantion și de asimetria dispersiei

 MFM_ch5_long_memory

Memoria lungă: unde GARCH nu ajunge



- S&P 500: autocorelația lui $|r_t|$ (decalaje 1–250, scară log) în date și în traiectorii lungi simulate din GARCH(1,1)-t și FIGARCH(1,d,1)-t estimate

Interpretare: memoria lungă

- Date: 0,289 la decalajul 1, 0,082 la 100, 0,009 la 250: o scădere lentă, aproximativ log-liniară
 - ▶ GARCH: prea mare la decalaje mici (0,416), apoi o prăbușire exponențială: ACF-ul său are un timp caracteristic
- **FIGARCH** Baillie, Bollerslev & Mikkelsen (1996): integrarea fracționară $(1 - L)^d$ dă o scădere hiperbolică
 - ▶ $\hat{d} = 0,60$ (e.s. 0,06); BIC mai mic cu 34,2 decât GARCH, dar memoria simulată este acum prea lungă (0,144 la decalajul 250)
- Niciun model cu o singură scară nu se potrivește tuturor orizonturilor: Capitolul 9 folosește volatilitatea realizată și modelul HAR

Alte limite ale GARCH

- ▣ **Rupturi structurale:** schimbările nivelului volatilității umflă $\alpha + \beta$ spre 1 [Lamoureux & Lastrapes \(1990\)](#)
 - ▶ Persistența noastră BET-TR (2014–2026) 0,9188 față de BET (2000–2026) 0,9907: eșantionul contează
- ▣ **Întârzierea reacției:** GARCH răspunde după șoc; volatilitatea implicită, de ex. VIX, se mișcă înainte
- ▣ **Doar date zilnice:** informația intrazilnică se pierde; măsurile realizate o folosesc (Capitolul 9)
- ▣ **Un singur activ:** portofoliile au nevoie de covarianțe; GARCH multivariat și DCC în Capitolul 6
- ▣ **Prețuri administrate (EUR/RON):** un GARCH zilnic descrie slab intervențiile

Dincolo de GARCH(1,1): modele bazate pe scor, realizate și cu componente

- **Bazate pe scor (GAS)** Creal, Koopman & Lucas (2013): $\sigma_{t+1}^2 = \omega + A s_t + B \sigma_t^2$, s_t scorul scalat al densității Student-t
 - ▶ Scorul este mărginit în z_t : o valoare extremă ca reziduul EUR/RON de 154 mișcă dispersia mult mai puțin decât în GARCH
- **Realized GARCH** Hansen, Huang & Shek (2012): adaugă o ecuație de măsurare care leagă σ_t^2 de o dispersie realizată
 - ▶ Folosește informația intrazilnică și reacționează mai repede; puntea spre Capitolul 9
- **GARCH-MIDAS** Engle, Ghysels & Sohn (2013): $\sigma_t^2 = \tau_t g_t$, o componentă lentă de termen lung τ_t determinată de date macro (frecvențe mixte)
 - ▶ Un nivel de termen lung mobil absoarbe schimbările de nivel care împing $\hat{\alpha} + \hat{\beta}$ spre 1
- Fiecare extensie se judecă la fel ca GARCH: în afara eșantionului, pierdere robustă, Model Confidence Set

Dincolo de dispersie: entropie și risc de coadă

- ▣ [Pele, Lazar & Dufour \(2017\)](#): entropia distribuției randamentelor intrazilnice și riscul de piață (EUR/JPY)
 - ▶ O entropie mai mare merge cu Value at Risk și expected shortfall intrazilnice mai mici; entropia prognozează apoi Value at Risk zilnic
- ▣ [Pele & Mazurencu-Marinescu-Pele \(2019\)](#): entropia randamentelor intrazilnice Bitcoin ca predictor al Value at Risk zilnic
 - ▶ În testarea retrospectivă, prognoza bazată pe entropie bate modelele GARCH clasice
- ▣ [Pele, Lazar & Mazurencu-Marinescu-Pele \(2019\)](#): o măsură neparametrică a cozii bazată pe entropie, comparată cu modelele standard de expected shortfall
- ▣ Volatilitatea GARCH intră direct în Value at Risk și expected shortfall: Capitolele 7–8

O întrebare deschisă

- Bat prognozele de machine learning sau cele bazate pe măsuri realizate un GARCH bine specificat pentru dispersia zilnică a acțiunilor, în afara eșantionului, după ce ținem cont de numărul de modele comparate?
- Întrebarea este deschisă
 - ▶ Christensen, Siggaard & Veliyev (2023): metodele de machine learning, cu puțină calibrare, sunt competitive cu modelele de tip HAR pentru dispersia realizată a acțiunilor din Dow Jones
 - ▶ Hansen, Lunde & Nason (2011): Model Confidence Set păstrează toate modelele care nu sunt semnificativ mai slabe decât cel mai bun, obiectul potrivit când concurează multe modele
 - ▶ Acest capitol: în familia GARCH, statistica DM variază între $-1,22$ și $-0,36$: niciun câștigător semnificativ
- Formularea formală pentru modelele A și B, pierderea QLIKE L
 - ▶ $d_t = L(r_t^2, h_t^A) - L(r_t^2, h_t^B)$; $H_0: \mathbb{E}[d_t] = 0$; $H_1: \mathbb{E}[d_t] < 0$; statistica DM cu erori HAC Diebold & Mariano (1995)
 - ▶ Infirmată dacă A iese din Model Confidence Set sau dacă semnul lui $\bar{d}$ se schimbă între subperioadele pre-înregistrate

Bucula descoperirii, pas cu pas (1/2)

- Instrumentele sunt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și motoare de literatură (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „Listează comparațiile în afara eșantionului dintre prognozele de dispersie GARCH, HAR și de machine learning publicate după 2015, cu DOI, activ, funcție de pierdere, test și orizont.”
 - Rezolvăm fiecare DOI pe Crossref; verificăm că pierderea este robustă la o aproximare zgomotoasă [Patton \(2011\)](#)
- **Ipoteze:** „Pentru afirmația că asimetria îmbunătățește prognozele pe o zi, listează mecanismele concurente (levier, feedback de volatilitate, câteva zile de criză) și ce prezice fiecare pentru d_t după semnul lui r_{t-1} și pe subperioade.”
- **Date și cod:** „Scrie cod Python cu `arch` care reestimează GARCH-t și GJR-t în fiecare ianuarie pe o fereastră în expansiune din data/market și salvează prognozele dispersiei pe o zi; niciun parametru nu folosește date de după originea prognozei.”
 - Replicăm întâi: QLIKE 0,757 (GARCH-t) și 0,732 (GJR-t), DM $t = -1,22$ (Secțiunea 7)

Bucula descoperirii, pas cu pas (2/2)

- **Robustețe:** „Scrie un plan pre-înregistrat: împărțiri după semnul lui r_{t-1} și pe subperioade, MSE pe lângă QLIKE, orizontul de 22 de zile, decalajul HAC și o corecție Bonferroni sau Model Confidence Set.”
 - ▶ Placebo: împărțiri aleatoare de aceleași mărimi; diferența dintre $\bar{d}$ pe zilele de după scăderi și cele de după creșteri trebuie să depășească banda de 95% a diferențelor aleatoare
- **Critica:** „Joacă rolul unui referent: ar putea aproximarea r_t^2 , un singur an de criză sau decalajul HAC să creeze rezultatul meu? Dă testul care l-ar expune pe fiecare.”
- **Raportul:** toate împărțirile și pierderile încercate, valorile p ajustate, codul, semințele și versiunile pachetelor
- Fixăm planul înainte de prima rulare: orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare

Ce verifică cercetătorul

- ▣ **Informație din viitor:** parametri estimați pe tot eșantionul sau h_t aliniat cu r_t în loc de $r_{t-1} \Rightarrow$ verificăm că ultima dată de estimare precede fiecare origine; decalăm prognoza o zi și comparăm
- ▣ **Pierdere nerobustă:** pierderile pe $|r_t|$ sau pe logaritmi pot ordona greșit prognozele cu o aproximare zgomotoasă [Patton \(2011\)](#) $\Rightarrow$ doar QLIKE și MSE
- ▣ **Căutarea modelelor:** 3 ecuații ale dispersiei $\times$ 4 distribuții $\times$ ferestre $\Rightarrow$ Model Confidence Set sau Bonferroni pe mulțimea pre-înregistrată
- ▣ **Perioade influente:** un an de criză poate domina $\bar{d} \Rightarrow$ raportăm subperioadele și declarăm dinainte dacă vreun an poate fi exclus
- ▣ **Scara și convergența:** randamente în % sau în zecimale, optimizări eșuate $\Rightarrow$ verificăm indicatorii optimizatorului și o actualizare a dispersiei pas cu pas
- ▣ **Referințe sau funcții inventate:** DOI care nu se rezolvă, argumente arch inexistente $\Rightarrow$ Crossref și rularea codului; notăm în `AI_ERRORS.md`

Mini-studiu de caz: îmbunătățește asimetria prognoza?

- O propunere tipică a unui asistent: „GJR-t bate GARCH-t datorită efectului de levier”; $d_t = \text{QLIKE}(\text{GJR-t}) - \text{QLIKE}(\text{GARCH-t})$
- Replicăm: 2 692 zile, 2016–2026: $\bar{d} = -0,025$, DM $t = -1,22$ ($p = 0,22$): nesemnificativ
- Implicația testabilă a levierului: câștigul apare după zilele de scădere
 - ▶ După $r_{t-1} < 0$ (1 223 zile): $\bar{d} = -0,015$, $t = -0,51$; după $r_{t-1} \geq 0$ (1 469): $\bar{d} = -0,034$, $t = -1,12$
 - ▶ Nesusținută: GJR are $\hat{\alpha} = 0,000$, deci o creștere nu îi ridică prognoza; câștigul nu este mai mic după zilele de creștere
- Subperioade: 2016–2020 $t = -0,02$; 2021–2026 $t = -4,06$ ($p < 0,001$); fără 2020 $t = -4,26$
 - ▶ Câștigul din 2021–2026 trece de corecția Bonferroni pentru cele 5 împărțiri ($0,05/5 = 0,01$); excluderea lui 2020 este legitimă doar dacă a fost pre-înregistrată
- Interpretare: asimetria ajută, dar nu prin canalul propus și nu în 2016–2020

Rândul vostru: o sămânță de proiect de echipă

- Întrebarea: intră prognozele bazate pe dispersia realizată (HAR) sau de machine learning în Model Confidence Set alături de GARCH, GJR și EGARCH pentru S&P 500 și BET, 2016–2026?
- Replicăm întâi: tabelul QLIKE din Secțiunea 7 (GARCH-t 0,757, DM EWMA $t = 3,48$) și împărțirile din mini-studiul de caz
- Livrabile
 - ▶ O preînregistrare de o pagină: modele, pierderi, împărțiri, rata de eroare și ce ar infirma afirmația
 - ▶ Cod pe data/market (zilnic și intrazilnic), Model Confidence Set la 10%, o autocritică în stilul unui referent
- Notăm fiecare prompt, instrument și rezultat acceptat în AI_USE.md; fiecare eroare prinsă (informație din viitor, scară greșită, DOI inventat) și testul care a prins-o în AI_ERRORS.md
- Codul mini-studiului de caz: [Quantlets/Ch_05/ai_discovery_case.py](#)

Idei principale

Ce reținem

- ▣ Randamentele sunt aproape imprevizibile, mărimea lor nu: GARCH transformă gruparea în prognoze
- ▣ GARCH(1,1): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$; persistența $\alpha + \beta$ aproape de 1 pe toate piețele noastre
- ▣ Volatilitatea acțiunilor este asimetrică (GJR, EGARCH); a Bitcoin nu; a aurului este inversată
- ▣ Inovațiile au cozi groase și sunt asimetrice: Student-t sau t asimetric, cu erori standard robuste
- ▣ În afara eșantionului, modelele GARCH bat EWMA și dispersia istorică; între ele, diferențele sunt mici

O listă practică de verificare

- ▣ 1. Testați efectele ARCH: Q pe r_t^2 și testul LM
- ▣ 2. Estimați GARCH, GJR și EGARCH cu inovații Normale, Student-t și t asimetrice; randamente în %
- ▣ 3. Verificați convergența, frontierele și erorile standard robuste (valide doar dacă $\mathbb{E}z_t^4 < \infty$); LR ajustat la frontieră și BIC
- ▣ 4. Diagnosticați reziduurile standardizate (nivel, pătrate, semne, cele mai mari valori)
- ▣ 5. Evaluați prognozele în afara eșantionului: QLIKE, Diebold–Mariano sau Giacomini–White, Model Confidence Set, Mincer–Zarnowitz
- ▣ 6. Raportați timpul de înjumătățire cu incertitudinea sa; nu vă bazați pe cifrele de termen lung când $\alpha + \beta \approx 1$

Resurse suplimentare

▣ Cărți

- ▶ Franke, Härdle & Hafner (2019), capitolele despre modelele ARIMA și GARCH pentru serii financiare
- ▶ Francq & Zakoïan (2019): teoria matematică a modelelor GARCH

▣ Cursuri Quantinar

- ▶  Statistics of Financial Markets
- ▶  Applied Time Series Analysis with Python

▣ Cod

- ▶ Toate graficele și tabelele: [Quantlets/Ch_05](#); pachetul Python [Sheppard, arch](#)

Ce urmează

- Capitolul 6: dependența dintre piețe, volatilitatea multivariată și corelațiile dinamice
- Capitolul 7: Value at Risk și expected shortfall, cu volatilitatea GARCH ca intrare
- Capitolul 8: testarea retrospectivă a prognozelor de risc
- Capitolul 9: volatilitatea realizată și memoria lungă
- Seminarul 5: dispersia pe mai mulți pași, derivări pentru metoda delta și eficiența QMLE, LR la frontieră, Giacomini–White și MCS, testul IGARCH prin bootstrap, transmiterea șocurilor din SUA către BET

Bibliografie (1/6)

- ▣ Andersen, T.G., Bollerslev, T. (1998). Answering the skeptics: yes, standard volatility models do provide accurate forecasts. *International Economic Review*, 39(4), 885–905.
- ▣ Andrews, D.W.K. (2000). Inconsistency of the bootstrap when a parameter is on the boundary of the parameter space. *Econometrica*, 68(2), 399–405.
- ▣ Andrews, D.W.K. (2001). Testing when a parameter is on the boundary of the maintained hypothesis. *Econometrica*, 69(3), 683–734.
- ▣ Baillie, R.T., Bollerslev, T., Mikkelsen, H.O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30.
- ▣ Berkes, I., Horváth, L., Kokoszka, P. (2003). GARCH processes: structure and estimation. *Bernoulli*, 9(2), 201–227.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *Review of Economics and Statistics*, 69(3), 542–547.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.

Bibliografie (2/6)

- ▣ Christensen, K., Siggaard, M., Veliyev, B. (2023). A machine learning approach to volatility forecasting. *Journal of Financial Econometrics*, 21(5), 1680–1727.
- ▣ Clark, T.E., McCracken, M.W. (2001). Tests of equal forecast accuracy and encompassing for nested models. *Journal of Econometrics*, 105(1), 85–110.
- ▣ Creal, D., Koopman, S.J., Lucas, A. (2013). Generalized autoregressive score models with applications. *Journal of Applied Econometrics*, 28(5), 777–795.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- ▣ Engle, R.F. (2004). Risk and volatility: econometric models and financial practice. *American Economic Review*, 94(3), 405–420.
- ▣ Engle, R.F., Ghysels, E., Sohn, B. (2013). Stock market volatility and macroeconomic fundamentals. *Review of Economics and Statistics*, 95(3), 776–797.
- ▣ Engle, R.F., Lilien, D.M., Robins, R.P. (1987). Estimating time varying risk premia in the term structure: the ARCH-M model. *Econometrica*, 55(2), 391–407.

Bibliografie (3/6)

- ▣ Engle, R.F., Ng, V.K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778.
- ▣ Fan, J., Qi, L., Xiu, D. (2014). Quasi-maximum likelihood estimation of GARCH models with heavy-tailed likelihoods. *Journal of Business & Economic Statistics*, 32(2), 178–191.
- ▣ Francq, C., Zakoïan, J.-M. (2004). Maximum likelihood estimation of pure GARCH and ARMA-GARCH processes. *Bernoulli*, 10(4), 605–637.
- ▣ Francq, C., Zakoïan, J.-M. (2019). *GARCH Models: Structure, Statistical Inference and Financial Applications*, 2nd ed. Wiley.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- ▣ Hall, P., Yao, Q. (2003). Inference in ARCH and GARCH models with heavy-tailed errors. *Econometrica*, 71(1), 285–317.

Bibliografie (4/6)

- ▣ Hamilton, J.D., Susmel, R. (1994). Autoregressive conditional heteroskedasticity and changes in regime. *Journal of Econometrics*, 64(1–2), 307–333.
- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- ▣ Hansen, P.R., Huang, Z., Shek, H.H. (2012). Realized GARCH: a joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6), 877–906.
- ▣ Hansen, P.R., Lunde, A. (2005). A forecast comparison of volatility models: does anything beat a GARCH(1,1)? *Journal of Applied Econometrics*, 20(7), 873–889.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics — Technical Document*, 4th ed. New York.
- ▣ Jensen, S.T., Rahbek, A. (2004). Asymptotic inference for nonstationary GARCH. *Econometric Theory*, 20(6), 1203–1226.
- ▣ Lamoureux, C.G., Lastrapes, W.D. (1990). Persistence in variance, structural change, and the GARCH model. *Journal of Business & Economic Statistics*, 8(2), 225–234.

Bibliografie (5/6)

- ▣ Lee, J.H.H., King, M.L. (1993). A locally most mean powerful based score test for ARCH and GARCH regression disturbances. *Journal of Business & Economic Statistics*, 11(1), 17–27.
- ▣ Li, W.K., Mak, T.K. (1994). On the squared residual autocorrelations in non-linear time series with conditional heteroskedasticity. *Journal of Time Series Analysis*, 15(6), 627–636.
- ▣ Lumsdaine, R.L. (1996). Consistency and asymptotic normality of the quasi-maximum likelihood estimator in IGARCH(1,1) and covariance stationary GARCH(1,1) models. *Econometrica*, 64(3), 575–596.
- ▣ Mandelbrot, B. (1963). The variation of certain speculative prices. *Journal of Business*, 36(4), 394–419.
- ▣ McLeod, A.I., Li, W.K. (1983). Diagnostic checking ARMA time series models using squared-residual autocorrelations. *Journal of Time Series Analysis*, 4(4), 269–273.
- ▣ Mincer, J., Zarnowitz, V. (1969). The evaluation of economic forecasts. In J. Mincer (ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*, NBER.
- ▣ Nelson, D.B. (1990). Stationarity and persistence in the GARCH(1,1) model. *Econometric Theory*, 6(3), 318–334.
- ▣ Nelson, D.B. (1991). Conditional heteroskedasticity in asset returns: a new approach. *Econometrica*, 59(2), 347–370.

Bibliografie (6/6)

- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). Modeling expected shortfall using tail entropy. *Entropy*, 21(12), 1204.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). Using high-frequency entropy to forecast Bitcoin's daily Value at Risk. *Entropy*, 21(2), 102.
- ▣ Self, S.G., Liang, K.-Y. (1987). Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, 82(398), 605–610.
- ▣ Sheppard, K. arch: ARCH models and other tools for financial econometrics in Python (software documentation).
- ▣ West, K.D. (1996). Asymptotic inference about predictive ability. *Econometrica*, 64(5), 1067–1084.