



Modelarea piețelor financiare

Capitolul 5: Volatilitate condiționată — modele GARCH



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ACF: AutoCorrelation Function (funcția de autocorelație)
- AI: Artificial Intelligence (inteligență artificială)
- AIC: Akaike Information Criterion (criteriul informațional Akaike)
- AR: AutoRegressive (model) (model autoregresiv)
- ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ARIMA: AutoRegressive Integrated Moving Average (model) (model autoregresiv integrat cu medie mobilă)
- ARMA: AutoRegressive Moving Average (model) (model autoregresiv cu medie mobilă)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BNR: Banca Națională a României
- COVID-19: COroNaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- EGARCH: Exponential GARCH (GARCH exponențial)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- FIGARCH: Fractionally Integrated GARCH (GARCH integrat fracționar)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-M: GARCH-in-Mean (GARCH cu volatilitatea în ecuația mediei)
- GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- GED: Generalised Error Distribution (distribuția generalizată a erorilor)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- IGARCH: Integrated GARCH (GARCH integrat)

Acronime folosite în acest material (2/2)

- ▣ LM: Lagrange Multiplier (multiplicatorul Lagrange)
- ▣ LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ QQ: Quantile–Quantile (plot) (graficul cuantilă–cuantilă)
- ▣ SUA: Statele Unite ale Americii
- ▣ VIX: CBOE Volatility Index (indicele de volatilitate CBOE)
- ▣ XAU: gold, ISO 4217 code (one troy ounce) (aur, codul ISO 4217 (o uncie troy))

Cuprins

Motivație

De la ARCH la GARCH

Estimare și alegerea modelului

Exemplu lucrat și rezultate pe piețe

Volatilitate asimetrică

Inovații și diagnostic

Prognoza și evaluarea prognozelor

Extensii și limite

AI pentru descoperire științifică

Concluzii

Bibliografie

De ce modelăm volatilitatea?

Volatilitatea este prețul riscului

- ▣ **Volatilitatea:** abaterea standard a randamentelor, de obicei anualizată
- ▣ Intră în orice cifră de risc: Value at Risk (Capitolul 7), ponderile portofoliului (Capitolul 4), prețul opțiunilor
- ▣ Capitolul 1 a arătat că **nu este constantă**: perioadele calme alternează cu cele agitate

Ce facem în acest capitol

- ▣ Scriem volatilitatea ca funcție de trecut: ARCH și GARCH
- ▣ Adăugăm asimetrie (GJR-GARCH, EGARCH) și inovații cu cozi groase
- ▣ Estimăm, diagnosticăm și comparăm modele pe șase piețe
- ▣ Prognozăm volatilitatea și evaluăm prognozele în afara eșantionului

Volatilitatea vine în rafale



Bursa din Amsterdam, 21 octombrie 1987, după prăbușirea din 19 octombrie

Foto: Bart Molendijk / Anefo (1987); CC0; Wikimedia Commons


- Prăbușirile nu sunt zile izolate: mișcările mari sunt urmate de mișcări mari
 - ▶ „Schimbările mari tind să fie urmate de schimbări mari, de orice semn” [Mandelbrot \(1963\)](#)
- Această **grupare a volatilității** este faptul stilizat 6 din Capitolul 1
- Întrebarea: putem transforma gruparea într-o **prognoză** a riscului de mâine?

Datele folosite în acest capitol

Serie	Proprietar / sursă	Început	Obs.	Obs. pe an
S&P 500	S&P Dow Jones Indices	2000	6 714	251,4
BET	Bursa de Valori București	2000	6 670	249,8
BET-TR	Bursa de Valori București	2014	2 992	249,7
Bitcoin (BTC/USD)	burse cripto (compozit)	2014	4 384	365,3
EUR/RON, curs de referință	BNR	2005	5 352	252,4
Aur (XAU/USD)	piața spot	2000	6 922	259,2

- Închideri zilnice până la 18 septembrie 2026; randamente $r_t = 100 (\ln P_t - \ln P_{t-1})$, în %
- Indici bursieri și aur: doar zilele lucrătoare; aurul este anualizat cu frecvența sa reală
- Bitcoin se tranzacționează 7 zile din 7; indicele VIX al Chicago Board Options Exchange este folosit ca reper

Randamente: perioade calme și agitate




- Randamentele log zilnice ale S&P 500, BET și Bitcoin; rafalele de randamente mari alternează cu perioade lungi de calm

Interpretare: grupare peste tot

- ▣ 2008–2009 (criza financiară globală) și martie 2020 (COVID-19) ies în evidență la ambii indici bursieri
- ▣ Bitcoin este mult mai volatil: 66,6% pe an, față de 19,2% (S&P 500) și 22,1% (BET)
- ▣ Excesul de aplatizare este mare pentru toate seriile
 - ▶ S&P 500: 10,7; BET: 11,1; Bitcoin: 12,0; distribuția Normală are 0
- ▣ Un model cu dispersie constantă nu poate produce aceste imagini; unul cu dispersie variabilă în timp poate

Randamentele sunt slab corelate, pătratele lor nu



□ S&P 500, 2000–2026: funcția de autocorelație a lui r_t și a lui r_t^2 , decalaje 1–50

Interpretare: dispersie predictibilă

- ▣ Autocorelația de ordin 1 a randamentelor: $-0,099$; a pătratelor: $0,313$
- ▣ Toate cele 50 autocorelații ale lui r_t^2 până la decalajul 50 ies din banda $\pm 0,024$; încă $0,053$ la decalajul 50
- ▣ Direcția mișcării de mâine este aproape imprevizibilă (Capitolul 2); mărimea ei nu este
 - ▶ Exact asta trebuie să surprindă un model pentru dispersia condiționată

Testarea efectelor ARCH

- ▣ **Ljung-Box pe pătrate:** $Q(10) = n(n+2) \sum_{k=1}^{10} \hat{\rho}_k^2(r^2)/(n-k)$, χ_{10}^2 în absența grupării
 - ▶ $\hat{\rho}_k(r^2)$: autocorelația de selecție a lui r_t^2 la decalajul k
- ▣ **Testul LM al lui Engle Engle (1982):** regresăm $\hat{\varepsilon}_t^2$ pe $\hat{\varepsilon}_{t-1}^2, \dots, \hat{\varepsilon}_{t-5}^2$
 - ▶ $\hat{\varepsilon}_t = r_t - \bar{r}$ (randamente centrate); statistica $nR^2 \sim \chi_5^2$ în absența efectelor ARCH
- ▣ Ambele teste pun aceeași întrebare: mărimea șocurilor trecute prezice mărimea celor prezente?

Efecte ARCH pe șase piețe

Serie	Vol. (% anual)	Exces aplatare	$\hat{\rho}_1(r^2)$	$Q(10)$ pe r^2	LM(5)
S&P 500	19,2	10,7	0,313	6133	1679
BET	22,1	11,1	0,330	2440	983
BET-TR	15,4	17,8	0,171	714	372
Bitcoin	66,6	12,0	0,137	213	115
EUR/RON	4,4	15,1	0,342	2420	872
Aur	17,6	7,7	0,110	744	330

- Valori critice la 5%: χ_{10}^2 : 18,3; χ_5^2 : 11,1; toate statisticile sunt mult peste ele (toate valorile $p < 0,001$)
- Gruparea este universală: acțiuni, crypto, un curs de schimb administrat și aur
- Cea mai slabă (dar tot decisivă) pentru Bitcoin și aur, cea mai puternică pentru S&P 500

Dispersia condiționată și dispersia necondiționată

- Descompunerea randamentului: $r_t = \mu + \varepsilon_t$, cu $\varepsilon_t = \sigma_t z_t$ și z_t i.i.d., $\mathbb{E}(z_t) = 0$, $\text{Var}(z_t) = 1$
- **Mulțimea de informații** $\mathcal{F}_{t-1}$: tot ce se știe la închiderea zilei $t - 1$
 - ▶ **Dispersia condiționată**: $\sigma_t^2 = \text{Var}(r_t | \mathcal{F}_{t-1})$, se schimbă în fiecare zi
 - ▶ **Dispersia necondiționată**: $\sigma^2 = \text{Var}(r_t) = \mathbb{E}[\sigma_t^2]$, un singur număr, de termen lung
- z_t : **inovația** (șocul standardizat); ε_t : șocul în puncte procentuale
- Un model pentru σ_t^2 este o regulă care actualizează dispersia la fiecare observație nouă

Modelul ARCH al lui Engle (1982)

- ▣ **ARCH(q)**: $\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \cdots + \alpha_q \varepsilon_{t-q}^2$ Engle (1982)
 - ▶ $\omega > 0, \alpha_i \geq 0$: dispersia este mereu pozitivă
- ▣ Un șoc mare ieri (ε_{t-1}^2 mare) crește dispersia de azi: grupare prin construcție
- ▣ ARCH(1): dispersia necondiționată $\sigma^2 = \omega/(1 - \alpha_1)$, finită dacă $\alpha_1 < 1$
 - ▶ Aplatizarea $3(1 - \alpha_1^2)/(1 - 3\alpha_1^2) > 3$ pentru z_t Normal: cozile groase apar chiar cu inovații Normale
- ▣ Aplicația originală: dispersia inflației din Marea Britanie

Robert Engle și Premiul Nobel din 2003



Robert F. Engle (2022)

Foto: Jon Demske (2022); CC

BY-SA 4.0; Wikimedia Commons



Clive W.J. Granger (2008)

Foto: Olaf Storbeck (2008); CC

BY-SA 2.0; Wikimedia Commons

- **Premiul Nobel 2003:** Engle „pentru metode de analiză a seriilor de timp economice cu volatilitate variabilă în timp (ARCH)”
 - ▶ Împărțit cu Clive Granger (cointegrare)
- **Prelegerea Nobel:** [Engle \(2004\)](#), despre risc și volatilitate în practica financiară
- Tim Bollerslev, doctorandul lui Engle, a generalizat ARCH la GARCH în 1986

De la ARCH la GARCH (Bollerslev, 1986)

- Problema ARCH: gruparea în datele reale durează luni de zile, deci q trebuie să fie mare (mulți parametri)
- **GARCH(1,1)** [Bollerslev \(1986\)](#): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$
 - ▶ $\omega > 0, \alpha \geq 0, \beta \geq 0$; α : reacția la știri; β : memoria dispersiei trecute
- Prin substituție înapoi: $\sigma_t^2 = \frac{\omega}{1-\beta} + \alpha \sum_{j \geq 1} \beta^{j-1} \varepsilon_{t-j}^2$
 - ▶ Un ARCH(∞) cu ponderi descrescătoare geometric, cu doar trei parametri
- GARCH(p, q) adaugă decalaje; în practică GARCH(1,1) este modelul de bază [Hansen & Lunde \(2005\)](#)

GARCH(1,1) ca model ARMA pentru pătratele șocurilor

- Definim $\nu_t = \varepsilon_t^2 - \sigma_t^2$, surpriza din pătratul șocului ($\mathbb{E}[\nu_t | \mathcal{F}_{t-1}] = 0$)
- Atunci $\varepsilon_t^2 = \omega + (\alpha + \beta) \varepsilon_{t-1}^2 + \nu_t - \beta \nu_{t-1}$
 - Un ARMA(1,1) în ε_t^2 cu coeficientul autoregresiv $\alpha + \beta$
- Consecință: autocorelațiile lui ε_t^2 scad geometric, $\rho_k = \rho_1(\alpha + \beta)^{k-1}$
- De aceea $\alpha + \beta$ se numește **persistența** volatilității

Staționaritatea și dispersia necondiționată

- **Staționaritate în covarianță:** $\alpha + \beta < 1$; atunci

- ▶ $\sigma^2 = \mathbb{E}[\sigma_t^2] = \frac{\omega}{1 - \alpha - \beta}$

- Derivare: aplicăm media în recursie, $\mathbb{E}\sigma_t^2 = \omega + (\alpha + \beta) \mathbb{E}\sigma_{t-1}^2$, și impunem $\mathbb{E}\sigma_t^2 = \mathbb{E}\sigma_{t-1}^2$

- **IGARCH** (GARCH integrat): $\alpha + \beta = 1$; dispersia necondiționată este infinită

- ▶ Totuși procesul rămâne **strict** staționar: condiția este $\mathbb{E} \ln(\alpha z_t^2 + \beta) < 0$ [Nelson \(1990\)](#)

- Țintirea dispersiei: fixăm $\omega = \hat{\sigma}^2(1 - \alpha - \beta)$ cu dispersia de selecție $\hat{\sigma}^2$


Persistența și timpul de înjumătățire

- Prognoza pe mai mulți pași: $\mathbb{E}[\sigma_{t+h}^2 \mid \mathcal{F}_t] = \sigma^2 + (\alpha + \beta)^{h-1}(\sigma_{t+1}^2 - \sigma^2)$
 - Distanța față de dispersia de termen lung scade cu factorul $\alpha + \beta$ în fiecare zi
- **Timpul de înjumătățire:** numărul de zile după care jumătate dintr-un șoc de dispersie a dispărut
 - $(\alpha + \beta)^h = 0,5 \Rightarrow h_{1/2} = \frac{\ln 0,5}{\ln(\alpha + \beta)}$
- Exemple: $\alpha + \beta = 0,95$: 13,5 zile; 0,99: 69 de zile; 0,995: 138 de zile
- Schimbări mici ale lui $\alpha + \beta$ lângă 1 dau timpi de înjumătățire foarte diferiți: incertitudinea estimării contează (Seminarul 5)

Momentul de ordin patru și aplatizarea

- Cu z_t Normal, aplatizarea lui ε_t este $K = \frac{3[1 - (\alpha + \beta)^2]}{1 - (\alpha + \beta)^2 - 2\alpha^2}$
 - ▶ Finită doar dacă $(\alpha + \beta)^2 + 2\alpha^2 < 1$ (Seminarul 1, Exercițiul A9)
- S&P 500, GARCH(1,1) cu inovații Normale: $\hat{\alpha} = 0,121$, $\hat{\beta} = 0,860$
 - ▶ $(\hat{\alpha} + \hat{\beta})^2 + 2\hat{\alpha}^2 = 0,9904$: puțin sub 1, deci $K = 12,1$
 - ▶ Aplatizarea de selecție a randamentelor: 13,7
- Gruparea singură generează o mare parte din cozile groase; restul vine din z_t cu cozi groase (Secțiunea 6)

Simulare: GARCH produce gruparea volatilității



- Sus: randamente Normale i.i.d.; jos: GARCH(1,1) cu aceeași dispersie necondiționată (1) și benzile $\pm 2\sigma_t$

Interpretare: grupare dintr-o regulă cu trei parametri

- Aceeași dispersie necondiționată, traiectorii foarte diferite: perioadele liniștite și rafalele apar doar în traiectoria GARCH
- Pe o traiectorie simulată lungă (un milion de zile)
 - ▶ Exces de aplatizare 2,47 (teoretic 3,06); autocorelația de ordin 1 a lui ε_t^2 : 0,26
 - ▶ Aplatizarea de selecție converge încet: precizia ei depinde de momentul de ordin opt, infinit pentru acești parametri
- Inovații Normale, dar randamente cu cozi groase: amestecul de dispersii creează cozile

EWMA: un caz particular de GARCH

- ▣ **EWMA** J.P. Morgan/Reuters (1996): $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, cu $\lambda = 0,94$ pentru date zilnice
 - ▶ Ponderi $(1 - \lambda)\lambda^{j-1}$ pe pătratele randamentelor trecute: zilele recente contează cel mai mult
- ▣ EWMA este un IGARCH(1,1) cu $\omega = 0$, $\alpha = 1 - \lambda$, $\beta = \lambda$: niciun parametru de estimat
- ▣ Prețul simplității: fără revenire la medie
 - ▶ Prognoza pentru orice orizont este egală cu dispersia de azi; GARCH o trage spre σ^2
- ▣ Folosim EWMA ca reper în comparația prognozelor din Secțiunea 7

Recapitulare: ARCH și GARCH

Idei-cheie

- ▣ σ_t^2 este dispersia dată fiind informația de ieri; se mișcă odată cu mărimea șocurilor recente
- ▣ $\text{GARCH}(1,1) = \text{ARCH}(\infty)$ cu trei parametri; $\alpha + \beta$ este persistența
- ▣ $\alpha + \beta < 1$: dispersie de termen lung finită $\omega/(1 - \alpha - \beta)$ și timp de înjumătățire $\ln 0,5 / \ln(\alpha + \beta)$
- ▣ Gruparea creează cozi groase, chiar cu inovații Normale
- ▣ EWMA este cazul particular IGARCH cu $\omega = 0$

Verosimilitatea maximă

- ▣ Parametrii $\theta = (\mu, \omega, \alpha, \beta)$; dat fiind θ , recursia produce $\sigma_1^2(\theta), \dots, \sigma_n^2(\theta)$
- ▣ Log-verosimilitatea Normală: $\ell(\theta) = -\frac{1}{2} \sum_{t=1}^n [\ln 2\pi + \ln \sigma_t^2 + \varepsilon_t^2 / \sigma_t^2]$
 - Fiecare zi contribuie cu densitatea lui ε_t condiționată de trecut: verosimilitatea se factorizează în timp
- ▣ Fără formulă explicită: optimizare numerică sub restricțiile $\omega > 0, \alpha, \beta \geq 0, \alpha + \beta < 1$
- ▣ Pornirea: σ_1^2 se fixează la dispersia de selecție (efectul său dispare cu rata β)

Cvasi-verosimilitate maximă și erori standard robuste

- ▣ Dacă z_t **nu** este Normal, maximizarea verosimilității Normale rămâne consistentă [Bollerslev & Wooldridge \(1992\)](#)
 - ▶ Condiția: ecuațiile mediei și dispersiei sunt corect specificate
- ▣ Dar erorile standard obișnuite sunt greșite; folosim forma „sandviș”
 - ▶ $\widehat{\text{Var}}(\hat{\theta}) = \hat{A}^{-1} \hat{B} \hat{A}^{-1}$, cu A = minus hessiana, B = produsul exterior al scorurilor
- ▣ Sub normalitate corectă $A = B$ și formula devine $\hat{A}^{-1}$ (cea clasică)
- ▣ Aceste erori Bollerslev–Wooldridge sunt implicate în pachetul `arch` [Sheppard](#), `arch`

Inovații cu cozi groase

- **Student-t Bollerslev (1987)**: $z_t = \sqrt{(\nu - 2)/\nu} t_\nu$, dispersie unitară pentru $\nu > 2$
 - ▶ ν (grade de libertate): cu cât ν este mai mic, cu atât cozile sunt mai groase; momentul de ordin patru există doar pentru $\nu > 4$
- **t asimetric Hansen (1994)**: adaugă un parametru de asimetrie $\lambda \in (-1, 1)$
 - ▶ $\lambda < 0$: coada stângă este mai lungă (pierderile mari mai probabile decât câștigurile mari)
- **GED Nelson (1991)**: densitate $\propto \exp(-\frac{1}{2}|z/\lambda_\nu|^\nu)$
 - ▶ $\nu = 2$: distribuția Normală; $\nu = 1$: Laplace; $\nu < 2$: cozi mai groase (λ_ν asigură dispersia unitară)

Compararea modelelor: LR, AIC, BIC

- ▣ **Testul raportului de verosimilitate (LR)**, modele imbricate: $LR = 2(\ell_1 - \ell_0) \sim \chi_m^2$
 - ▶ m : numărul de restricții (de ex. GJR față de GARCH: $\gamma = 0$, $m = 1$)
 - ▶ Nu este valid la frontieră (de ex. $\nu = \infty$ pentru inovații Student-t față de inovații Normale): folosim criterii informaționale
- ▣ **AIC** = $-2\ell + 2k$ și **BIC** = $-2\ell + k \ln n$ (k parametri, n observații): mai mic înseamnă mai bun
- ▣ BIC penalizează mai tare parametrii suplimentari ($\ln n \approx 8,8$ pentru $n = 6714$)
- ▣ Potrivirea în eșantion nu este capacitate de prognoză: Secțiunea 7 compară modelele în afara eșantionului

Estimarea în practică

- Python: `arch_model(r, vol='GARCH', p=1, o=0, q=1, dist='t').fit()` Sheppard, arch
 - ▶ `o=1`: termenul GJR; `vol='EGARCH'`; `dist` în normal, `t`, `skewt`, `ged`
- Scara: randamente în %, nu în zecimale; optimizatoarele funcționează cel mai bine când dispersia este de ordinul 1
 - ▶ EUR/RON are o abatere standard zilnică de circa 0,28%: estimăm pe 10 r_t și rescalăm parametrii
 - ▶ Pe seria nescalată optimizatorul s-a oprit într-un optim local cu verosimilitate mult mai mică
- Verificați mereu convergența, parametrii aflați la frontieră ($\alpha = 0$, $\alpha + \beta = 1$) și diagnosticele

S&P 500: estimările GARCH(1,1)-t

Parametru	Estimare	E.s. robustă	E.s. clasică	Raport
ω	0,0157			
α	0,123	0,011	0,010	1,06
β	0,872	0,010	0,010	1,08
ν	6,26	0,48		
$\alpha + \beta$	0,9947			

- Randamente zilnice în %, 2000–2026; media $\hat{\mu} = 0,079\%$ pe zi
- Timp de înjumătățire 131 zile; volatilitatea de termen lung $\sqrt{252 \hat{\omega} / (1 - \hat{\alpha} - \hat{\beta})} = 27,3\%$ anual

Interpretare: estimările pentru S&P 500

- ▣ $\hat{\beta} = 0,872$: cea mai mare parte a dispersiei de azi este dispersia de ieri; $\hat{\alpha} = 0,123$: știrile adaugă o actualizare moderată
- ▣ Persistența 0,9947: șocurile de volatilitate durează luni, nu zile
- ▣ Volatilitatea de termen lung (27,3%) depășește volatilitatea de selecție (19,2%)
 - ▶ Lângă $\alpha + \beta = 1$, $\omega/(1 - \alpha - \beta)$ împarte la un număr foarte mic și este imprecisă
- ▣ $\hat{\nu} = 6,26$: inovațiile au cozi clar mai groase decât distribuția Normală
- ▣ Erorile standard robuste sunt cu circa 5–7% mai mari decât cele clasice pentru α și β

S&P 500: douăsprezece modele comparate prin BIC

ΔBIC	$N(0, 1)$	Student-t	t asimetric	GED
GARCH(1,1)	648,9	346,7	307,4	339,8
GJR-GARCH(1,1)	394,7	119,9	49,6	141,6
EGARCH(1,1)	372,9	74,8	0,0	111,4

- ▣ ΔBIC : BIC minus cel mai mic BIC dintre cele 12 modele (0 = modelul preferat)
- ▣ Contează două alegeri: o ecuație a dispersiei asimetrică și o inovație cu cozi groase și asimetrică
- ▣ Trecerea de la inovații Normale la inovații Student-t scade BIC cu circa 300; adăugarea asimetriei îl mai scade cu 230–270
- ▣ Câștigător: EGARCH cu inovații t asimetrice; Secțiunile 5–6 explică de ce

Recapitulare: Estimare

Idei-cheie

- ▣ GARCH se estimează prin verosimilitate maximă; verosimilitatea se construiește zi cu zi din recursie
- ▣ Cu inovații non-Normale, folosim cvasi-verosimilitatea maximă cu erori standard robuste („sandviș”)
- ▣ Student-t, t asimetric și GED surprind cozile pe care GARCH singur le lasă
- ▣ Comparăm modelele imbricate cu teste LR, pe cele neimbricate cu AIC/BIC
- ▣ Rescalăm seriile cu volatilitate mică și verificăm parametrii aflați la frontieră

Exemplu lucrat: dispersia de mâine, pas cu pas


- S&P 500, GARCH(1,1)-t: $\hat{\omega} = 0,0157$, $\hat{\alpha} = 0,123$, $\hat{\beta} = 0,872$, $\hat{\mu} = 0,079$
- Ultima zi $T = 18.09.2026$: $r_T = 0,167\%$, deci $\hat{\varepsilon}_T = r_T - \hat{\mu} = 0,088$; dispersia filtrată $\hat{\sigma}_T^2 = 0,565$
 - ▶ Pasul 1: termenul de știri $\hat{\alpha} \hat{\varepsilon}_T^2 = 0,0009$
 - ▶ Pasul 2: termenul de memorie $\hat{\beta} \hat{\sigma}_T^2 = 0,493$
 - ▶ Pasul 3: $\hat{\sigma}_{T+1}^2 = \hat{\omega} + 0,0009 + 0,493 = 0,509$
- Volatilitatea: $\hat{\sigma}_{T+1} = 0,714\%$ pe zi, adică $0,714\sqrt{252} = 11,3\%$ anual
- O zi calmă ($\hat{\varepsilon}_T$ mic): dispersia scade cu factorul $\hat{\beta}$, plus $\hat{\omega}$

Exemplu lucrat: prognoza pe zece zile

- Dispersia de termen lung $\hat{\sigma}^2 = \hat{\omega} / (1 - \hat{\alpha} - \hat{\beta}) = 2,97$ (%² pe zi)
- Ziua 10: $\hat{\sigma}_{T+10}^2 = \hat{\sigma}^2 + (\hat{\alpha} + \hat{\beta})^9 (\hat{\sigma}_{T+1}^2 - \hat{\sigma}^2)$
 - ▶ $= 2,97 + 0,953 \times (0,509 - 2,97) = 0,624$
- Dispersia randamentului pe 10 zile: suma prognozelor zilnice, $\sum_{h=1}^{10} \hat{\sigma}_{T+h}^2 = 5,67$
 - ▶ Volatilitatea pe 10 zile $\sqrt{5,67} = 2,38\%$; regula rădăcinii pătrate a timpului ar da $\sqrt{10} \times 0,714 = 2,26\%$, adică mai puțin
- Dispersia de azi este sub cea de termen lung, deci GARCH prognozează o volatilitate în creștere

 MFM_ch5_garch_estimation

Structura la termen a volatilității



□ Prognoza, din 18.09.2026, a volatilității medii pe următoarele h zile (GARCH(1,1)-t); punctat: nivelul de termen lung

Interpretare: revenire la medie sau nu

- ▣ S&P 500: de la 11,3% (ziua următoare) la 20,1% (un an), urcând încet spre nivelul de termen lung
- ▣ Aur: azi peste nivelul de termen lung, deci curba scade, de la 23,9% la 22,4%
- ▣ Bitcoin și EUR/RON: $\hat{\alpha} + \hat{\beta} = 1$ (IGARCH), fără nivel de termen lung
 - ▶ Prognoza dispersiei crește cu $\hat{\omega}$ pe zi: Bitcoin de la 54,1% la 108,3% într-un an
 - ▶ Un artefact al estimării cu rădăcină unitară, nu o predicție pe care să tranzacționăm
- ▣ Prognozele GARCH pe orizonturi lungi moștenesc toată incertitudinea despre $\alpha + \beta$

GARCH(1,1)-t pe șase piețe


Serie	$\hat{\omega}$	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\alpha} + \hat{\beta}$	$h_{1/2}$ (zile)	$\hat{\nu}$	Vol. termen lung
S&P 500	0,0157	0,123	0,872	0,9947	131	6,26	27,3
BET	0,0448	0,192	0,799	0,9907	74	5,01	34,7
BET-TR	0,0755	0,206	0,713	0,9188	8	5,02	15,2
Bitcoin	0,1937	0,109	0,891	1,0000	∞	3,18	–
EUR/RON	0,0000	0,123	0,877	1,0000	∞	4,20	–
Aur	0,0107	0,049	0,944	0,9935	106	4,58	20,7

- ▣ Volatilitatea de termen lung în % anual (anualizată cu frecvența proprie a fiecărei serii); – când $\hat{\alpha} + \hat{\beta} \geq 0,999$
- ▣ EUR/RON: $\hat{\omega}$ este 0,0000 la patru zecimale (cursul se mișcă cu fracțiuni de ban în cele mai multe zile)

Interpretare: șase „personalități” ale volatilității

- Acțiuni (S&P 500, BET) și aur: persistență 0,99–0,995, timpi de înjumătățire de 3–6 luni de tranzacționare
- BET reacționează mai puternic la știri ($\hat{\alpha} = 0,192$) și uită mai repede decât S&P 500
 - ▶ BET-TR (doar 2014–2026): timp de înjumătățire 8 zile; un eșantion mai scurt și mai calm dă o persistență mai mică
- Bitcoin: cele mai groase cozi ($\hat{\nu} = 3,18$, momentul de ordin patru infinit) și rădăcină unitară în dispersie
- EUR/RON: un curs de schimb administrat; perioade lungi liniștite, apoi salturi
 - ▶ 6 mai 2025: +1,20% după zile de $\pm 0,004\%$: reziduu standardizat de 154

Persistența: cât de repede se sting șocurile?




□ Partea dintr-un șoc de dispersie încă prezentă după h zile, $(\hat{\alpha} + \hat{\beta})^h$; linia întreruptă: o jumătate

Interpretare: persistența

- ▣ Timpi de înjumătățire: S&P 500 131 zile, aur 106, BET 74, BET-TR 8
- ▣ Bitcoin și EUR/RON sunt pe linia orizontală: un $\alpha + \beta$ estimat de 1 înseamnă că șocurile nu se sting niciodată în model
- ▣ O persistență foarte mare poate fi falsă: schimbările de nivel ale volatilității imită o rădăcină unitară [Lamoureux & Lastrapes \(1990\)](#)
 - ▶ Alternative cu schimbare de regim: [Hamilton & Susmel \(1994\)](#)
- ▣ Regulă practică: raportați timpii de înjumătățire cu un interval de încredere (bootstrap parametric, Seminarul 5)

S&P 500: volatilitatea GARCH și VIX




□ Volatilitatea condiționată GARCH(1,1)-t anualizată $\hat{\sigma}_t \sqrt{252}$ și VIX, volatilitatea implicită pe 30 de zile, 2000–2026

Interpretare: volatilitate statistică și volatilitate implicită

- ▣ Corelația celor două serii: 0,89; GARCH folosește doar randamentele trecute, VIX folosește prețurile opțiunilor
- ▣ VIX mediu 19,8% față de volatilitatea GARCH medie 17,0%; VIX este mai mare în 84% din zile
 - ▶ Diferența este **prima de risc a dispersiei**: cumpărătorii de opțiuni plătesc pentru asigurarea împotriva volatilității
- ▣ Intervalul GARCH: de la 6,2% (octombrie 2017) la 111% (martie 2020)
- ▣ GARCH reacționează cu o zi întârziere prin construcție: are nevoie de șoc înainte să se miște

Detaliu: prăbușirea COVID-19, 2020




■ Ianuarie–iulie 2020: randamente absolute (anualizate), volatilitatea GARCH-t și GJR-GARCH-t, VIX

MFM_ch5_sp500_vix

Interpretare: COVID-19

- ▣ 16 martie 2020: $r_t = -12,8\%$, cea mai mare scădere zilnică din eșantion; VIX a închis la 82,7%
- ▣ Volatilitatea maximă a modelelor pe 17 martie: GARCH-t 111%, GJR-GARCH-t 127%
 - ▶ GJR urcă mai sus deoarece șocurile au fost negative (Secțiunea 5)
- ▣ 24 februarie 2020 ($r_t = -3,41\%$): VIX a sărit în aceeași zi, de la 17,1% la 25,0%
 - ▶ GARCH-t s-a mișcat abia a doua zi, de la 12,2% la 22,5%: piețele evaluează știrile imediat, GARCH doar reacționează
- ▣ După vârf, volatilitatea scade cu rata $\alpha + \beta$ pe zi, cum prezice modelul

BET, Bitcoin, EUR/RON și aur



- Volatilitatea condiționată GJR-GARCH-t, anualizată cu frecvența fiecărei serii (Bitcoin: 365 de zile)

Interpretare: patru piețe

- ▣ BET: criza din 2008 domină; apoi vârfuri scurte și abrupte; nivelul actual 26,4%
- ▣ Bitcoin: volatilitatea de 50–100% este normală; martie 2020 este vârful cel mai înalt
- ▣ EUR/RON: volatilitate mare până în 2012, apoi o perioadă lungă de calm administrat, cu rafale în 2022 și 2025
 - ▶ Volatilitate aproape de zero în multe zile: un GARCH zilnic descrie slab un curs administrat
- ▣ Aur: vârfuri de 52% (2008), 31% (2013), 41% (2020) și un nou maxim de 53% în 2026

Recapitulare: Rezultate pe piețe

Idei-cheie

- ▣ Prognozele pe un pas și pe mai mulți pași rezultă din recursie; dispersia pe 10 zile este suma dispersiilor zilnice
- ▣ Persistența este mare peste tot; timpii de înjumătățire variază de la circa o săptămână (BET-TR) la câteva luni
- ▣ Rădăcinile unitare estimate (Bitcoin, EUR/RON) fac prognozele de termen lung lipsite de sens
- ▣ GARCH urmărește îndeaproape VIX, dar cu întârziere; VIX este mai mare în medie (prima de risc a dispersiei)

Știrile proaste mișcă volatilitatea mai mult

- ▣ Faptul stilizat 9 (Capitolul 1): randamentele negative cresc volatilitatea viitoare mai mult decât cele pozitive de aceeași mărime
- ▣ **Efectul de levier:** un preț în scădere crește raportul datorii/capital propriu, deci acțiunea devine mai riscantă
 - ▶ **Feedback-ul volatilității:** volatilitatea așteptată mai mare crește randamentul cerut, deci prețurile scad acum
- ▣ GARCH(1,1) nu vede semnul: ε_{t-1}^2 este același pentru -3 și $+3$
- ▣ Două soluții: GJR adaugă un termen pentru șocurile negative, EGARCH modelează logaritmul dispersiei

GJR-GARCH (Glosten, Jagannathan și Runkle, 1993)

- $\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, cu $I_{t-1} = 1$ dacă $\varepsilon_{t-1} < 0$ Glosten, Jagannathan & Runkle (1993)
 - ▶ Știri bune: panta α ; știri proaste: panta $\alpha + \gamma$; $\gamma > 0$ înseamnă asimetrie
- Persistența cu z_t simetric: $\alpha + \gamma/2 + \beta$ (jumătate din șocuri sunt negative)
 - ▶ Dispersia de termen lung $\omega/(1 - \alpha - \gamma/2 - \beta)$
- Testul simetriei: $H_0: \gamma = 0$ printr-un test t sau prin LR față de GARCH(1,1)
- S&P 500: $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t = 10,0$), $\hat{\beta} = 0,881$


EGARCH (Nelson, 1991)

- $\ln \sigma_t^2 = \omega + \alpha (|z_{t-1}| - \mathbb{E}|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$ Nelson (1991)
 - ▶ Efectul de mărime α , efectul de semn γ ; $\gamma < 0$: șocurile negative cresc volatilitatea mai mult
- Forma logaritmică păstrează $\sigma_t^2 > 0$ fără restricții de semn asupra parametrilor
- Persistența: β (staționar dacă $|\beta| < 1$)
- S&P 500: $\hat{\alpha} = 0,138$, $\hat{\gamma} = -0,165$ ($t = -15,2$), $\hat{\beta} = 0,979$
- În arch, $\mathbb{E}|z|$ este fixat la $\sqrt{2/\pi}$, valoarea sa sub distribuția Normală

Curba de impact a știrilor

- **Curba de impact a știrilor Engle & Ng (1993):** σ_t^2 ca funcție de ε_{t-1} , cu σ_{t-1}^2 fixat la dispersia de selecție
 - ▶ GARCH: o parabolă simetrică în jurul lui 0
 - ▶ GJR: două semi-parabole cu pante diferite
 - ▶ EGARCH: exponențială în $|\varepsilon|$, înclinată de γ
- Ea izolează modul în care fiecare model transformă o zi de știri în dispersia de mâine
- Engle și Ng propun și teste de asimetrie folosite la diagnostic (Secțiunea 6)

Curbe de impact al știrilor pentru S&P 500



□ Dispersia de a doua zi după un șoc ε_{t-1} (în %), pentru cele trei modele estimate cu inovații Student-t

Interpretare: impactul știrilor

- Dispersia de pornire 1,47 (dispersia de selecție, %²)
- Un șoc de -3% : GJR dă 3,16, EGARCH 2,76; un șoc de $+3\%$: GJR 1,31, EGARCH 1,22
 - ▶ Știrile proaste cresc dispersia de 2,4 ori mai mult decât știrile bune în GJR, de 2,3 ori în EGARCH
- GARCH simetric dă 2,40 pentru ambele semne: prea mult după știrile bune, prea puțin după cele proaste
- Pentru S&P 500, $\hat{\alpha} = 0$ în GJR: șocurile pozitive nu cresc deloc volatilitatea

Asimetria pe șase piețe

Serie	$\hat{\gamma}_{GJR}$	t	LR vs GARCH	valoare p	$\hat{\gamma}_{EGARCH}$	t
S&P 500	0,205	10,0	235,7	< 0,001	-0,165	-15,2
BET	0,043	2,1	4,9	0,026	-0,028	-2,6
BET-TR	0,111	2,9	10,3	0,001	-0,063	-3,5
Bitcoin	-0,013	-0,7	0,7	0,416	0,015	1,2
EUR/RON	0,039	3,0	9,3	0,002	-0,040	-2,5
Aur	-0,043	-4,7	27,6	< 0,001	0,038	5,7

- ▣ Toate modelele cu inovații Student-t; statistici t cu erori standard robuste; $LR \sim \chi_1^2$ (valoarea critică 3,84)
- ▣ Asimetria: $\hat{\gamma} > 0$ în GJR și $\hat{\gamma} < 0$ în EGARCH pentru aceeași direcție (știrile proaste contează mai mult)

Interpretare: unde este efectul de levier?

- S&P 500: foarte puternic ($LR = 235,7$); efectul de levier clasic al unui indice bursier dezvoltat
 - ▶ BET și BET-TR: prezent, dar slab ($LR = 4,9$ și $10,3$)
- Bitcoin: fără asimetrie ($LR = 0,7$); creșterile crypto sunt la fel de volatile ca prăbușirile
- Aur: asimetrie **inversă** ($\hat{\gamma}_{GJR} = -0,043$): creșterile de preț cresc volatilitatea mai mult
 - ▶ Consistent cu aurul ca activ de refugiu: crește în perioadele agitate
- EUR/RON: GJR $\hat{\gamma} > 0$, EGARCH $\hat{\gamma} < 0$: scăderile cursului (aprecierea leului) cresc volatilitatea ceva mai mult

Recapitulare: Asimetrie

Idei-cheie

- GARCH simetric ignoră semnul știrilor; datele bursiere resping puternic această ipoteză
- GJR adaugă o pantă γ pentru șocurile negative; EGARCH modelează $\ln \sigma_t^2$ cu un termen de semn
- Curba de impact a știrilor arată direct asimetria
- Asimetria este un fenomen al acțiunilor: absentă la Bitcoin, inversată la aur



Reziduurile standardizate: ce trebuie să fie adevărat

- ▣ **Reziduul standardizat:** $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$; dacă modelul este corect, $\hat{z}_t$ este aproape i.i.d. cu dispersia 1
- ▣ Verificări
 - ▶ Fără autocorelație în $\hat{z}_t$: Ljung–Box $Q(10)$ pe $\hat{z}_t$ (ecuația mediei)
 - ▶ Fără grupare rămasă: $Q(10)$ pe $\hat{z}_t^2$ și testul LM(5) (ecuația dispersiei)
 - ▶ Fără asimetrie rămasă: testele de asimetrie [Engle & Ng \(1993\)](#)
 - ▶ Distribuția: comparăm $\hat{z}_t$ cu densitatea presupusă (grafic QQ)

Testele de asimetrie (Engle și Ng, 1993)

- ▣ Regresăm $\hat{z}_t^2 = b_0 + b_1 S_{t-1}^- + b_2 S_{t-1}^- \hat{z}_{t-1} + b_3 S_{t-1}^+ \hat{z}_{t-1} + u_t$
 - ▶ $S_{t-1}^- = 1$ dacă $\hat{z}_{t-1} < 0$, altfel 0; $S_{t-1}^+ = 1 - S_{t-1}^-$
- ▣ **Asimetria de semn** (b_1): doar șocurile negative cresc pătratul reziduului următor?
- ▣ **Asimetria de mărime negativă / pozitivă** (b_2, b_3): contează mărimea șocurilor negative / pozitive dincolo de model?
- ▣ Testul comun: $nR^2 \sim \chi_3^2$ (valoarea critică la 5%: 7,81)

S&P 500: sunt inovațiile Normale?



- Reziduurile standardizate ale GARCH(1,1) cu inovații Normale: log-densitatea și graficul QQ față de Normală și Student-t

Interpretare: cozile după GARCH

- ▣ Excesul de aplatizare scade de la 10,7 (randamente) la 1,73 (reziduuri standardizate): GARCH explică cea mai mare parte
- ▣ Dar nu tot: Jarque–Bera 1153; asimetria -0,53
 - ▶ 15 reziduuri sub -4 ; distribuția Normală se așteaptă la 0,21, o Student-t cu $\nu = 6,3$ la 8,5
 - ▶ Cel mai mare: $\hat{z} = -6,6$ pe 27 februarie 2007, o scădere mare într-o perioadă calmă
- ▣ Coadă stângă este mai lungă decât cea dreaptă: t asimetric cu $\hat{\lambda} = -0,150$ (GJR, $\hat{\eta} = 7,7$)
- ▣ De aceea BIC preferă inovațiile t asimetrice pentru S&P 500

S&P 500: diagnosticul a cinci modele


Model	$Q(10)$ pe $\hat{z}$	$Q(10)$ pe $\hat{z}^2$	LM(5)	Asim. semn t	Comun χ^2_3
GARCH-N	21,2	16,4	8,0	2,59	44,5
GARCH-t	21,9	13,6	5,8	2,47	39,3
GJR-t	22,3	10,2	4,5	3,96	23,5
EGARCH-t	27,6	10,5	8,2	2,95	8,8
GJR-t asimetric	19,7	10,7	5,0	4,22	27,1

- Valori critice la 5%: χ^2_{10} : 18,3; χ^2_5 : 11,1; χ^2_3 : 7,81; $|t| > 1,96$
- Înainte de modelare, $Q(10)$ pe r_t^2 era 6133

Interpretare: ce spun diagnosticele

- ▣ Gruparea a dispărut pentru toate modelele: $Q(10)$ pe $\hat{z}^2$ scade de la 6133 la 10–16, LM(5) nu este semnificativ
- ▣ GARCH simetric pică testul de asimetrie (comun 39,3): asimetrie rămasă
 - ▶ GJR tot pică (23,5); EGARCH se apropie cel mai mult (8,8, $p = 0,032$)
- ▣ $Q(10)$ pe $\hat{z}$ în jur de 20–28: o autocorelație în medie, pe care media constantă o ignoră
- ▣ Cu $n = 6\,714$, efectele mici sunt semnificative: judecați mărimea economică, nu doar valorile p

Diagnostic: pătratele randamentelor și pătratele reziduurilor



- S&P 500: autocorelațiile lui r_t^2 și ale lui $\hat{z}_t^2$ din GJR-GARCH-t, decalaje 1–30
- După model, autocorelațiile sunt în interiorul benzii i.i.d.: dinamica dispersiei este surprinsă

Diagnostic pe alte piețe

- BET: $Q(10)$ pe $\hat{z} = 116,6$: autocorelație puternică în medie (tranzacționare redusă, Capitolul 2)
 - ▶ Remediul: o ecuație a mediei AR(1), $r_t = \mu + \phi r_{t-1} + \varepsilon_t$
- Bitcoin: ecuația dispersiei trece ($Q(10)$ pe $\hat{z}^2 = 4,7$), fără asimetrie (comun 2,3)
- EUR/RON: exces de aplatizare reziduală 3190, provocat de un singur reziduu de 154 (mai 2025)
 - ▶ O singură observație poate domina diagnosticele: priviți mereu cele mai mari reziduuri
- Aur: EGARCH lasă grupare ($Q(10)$ pe $\hat{z}^2 = 48,8$) deși BIC-ul său este printre cele mai bune

Recapitulare: Inovații și diagnostic

Idei-cheie

- ▣ Reziduurile standardizate trebuie să arate i.i.d.: le testăm nivelul, pătratele și semnele
- ▣ GARCH elimină gruparea și cea mai mare parte a aplatizării, nu și asimetria
- ▣ Pentru S&P 500 sunt necesare atât inovațiile cu cozi groase și asimetrice, cât și dispersia asimetrică
- ▣ Diagnosticile pot contrazice criteriile informaționale; un singur reziduu extrem le poate determina

Problema variabilei aproximative

- Volatilitatea nu este observată niciodată: comparăm prognozele cu o **aproximare** zgomotoasă, de ex. r_t^2
- $r_t^2 = \sigma_t^2 z_t^2$ este nedeplasat ($\mathbb{E}[r_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2$ pentru $\mu = 0$), dar foarte zgomotos
 - ▶ R^2 -ul său față de dispersia reală este mic chiar pentru o prognoză perfectă [Andersen & Bollerslev \(1998\)](#)
- [Patton \(2011\)](#): doar unele funcții de pierdere ordonează corect prognozele cu o aproximare zgomotoasă
 - ▶ Robuste: $\text{MSE } (r_t^2 - h_t)^2$ și **QLIKE** $r_t^2/h_t + \ln h_t$, cu h_t prognoza dispersiei
 - ▶ Nerobuste: pierderile pe volatilitate $|r_t| - \sqrt{h_t}$ sau pe logaritmi
- QLIKE este (până la constante) minus log-verosimilitatea Normală; penalizează mai mult subestimarea


Mincer–Zarnowitz și Diebold–Mariano

- **Regresia Mincer–Zarnowitz** Mincer & Zarnowitz (1969): $r_t^2 = a + b h_t + u_t$
 - ▶ Prognoză nedeplasată: $a = 0$, $b = 1$ (test Wald comun cu erori HAC); R^2 măsoară conținutul informațional
 - ▶ $b < 1$: prognoze prea dispersate (prea mari când sunt mari, prea mici când sunt mici)
- **Testul Diebold–Mariano** Diebold & Mariano (1995): diferența de pierderi $d_t = L(r_t^2, h_t^A) - L(r_t^2, h_t^B)$
 - ▶ $DM = \bar{d} / \widehat{s.e.}(\bar{d})$ cu eroare standard HAC; $\approx N(0, 1)$ sub acuratețe egală
 - ▶ $DM < -1,96$: modelul A semnificativ mai bun

Designul în afara eșantionului

- ▣ S&P 500; perioada de prognoză 2016–2026: 2 692 prognoze pentru ziua următoare
- ▣ Parametrii reestimați la începutul fiecărui an pe toate datele din 2000 (fereastră în expansiune)
 - ▶ În cursul anului, dispersia este actualizată zilnic cu parametri ficși: fără informație din viitor
- ▣ Modele: GARCH cu inovații Normale și Student-t, GJR-t, EGARCH-t
- ▣ Repere: EWMA ($\lambda = 0,94$) și dispersia istorică pe 20 de zile (Hist-20)
- ▣ De asemenea, prognoze ale dispersiei cumulate pe 22 de zile (o lună) pe 122 ferestre nesuprapuse

Proгноze și mișcări realizate, 2016–2026




□ Prognozele volatilității pentru ziua următoare (anualizate) din GJR-GARCH-t și EWMA; puncte turcoaz: $|r_t|\sqrt{252}$

S&P 500: evaluarea prognozelor, 2016–2026

Model	QLIKE	MSE	DM t vs GARCH-t	MZ b	MZ R^2	Wald p
GARCH-N	0,751	22,3	-1,47	0,97	0,250	1,00
GARCH-t	0,757	22,8	—	0,88	0,238	0,80
GJR-t	0,732	21,8	-1,22	0,84	0,276	0,68
EGARCH-t	0,745	21,3	-0,36	1,24	0,293	0,71
EWMA	0,815	24,7	3,48	0,89	0,172	0,69
Hist-20	0,889	26,1	4,10	0,68	0,152	0,03

- Pierderi medii pe 2692 zile; DM pe QLIKE, HAC cu 5 decalaje; t negativ: mai bun decât GARCH-t
- MZ: $r_t^2 = a + b h_t$; Wald p: testul $a = 0$, $b = 1$

QLIKE relativ la GARCH-t




- QLIKE mediu al fiecărui model minus cel al GARCH-t, cu statistica t Diebold–Mariano

Interpretare: bate ceva GARCH(1,1)?

- Cel mai bun QLIKE: GJR-t (0,732); dar diferențele din familia GARCH nu sunt semnificative (DM t de la -1,22 la -0,36)
- EWMA și Hist-20 sunt semnificativ mai slabe (DM t = 3,48 și 4,10)
 - ▶ Revenirea la medie și parametrii estimați aduc un câștig
- MZ: prognozele de tip GARCH sunt nedeplasate (b aproape de 1, Wald $p > 0,6$); Hist-20 nu este ($p = 0,03$)
- R^2 de doar 0,15–0,29: zgomotul lui r_t^2 , nu un model prost
- Același mesaj ca Hansen & Lunde (2005): GARCH(1,1) este greu de bătut; asimetria ajută puțin la acțiuni

Proгноze pe o lună: Mincer-Zarnowitz în logaritmi



- Prognoza GJR-GARCH-t a dispersiei pe 22 de zile față de suma realizată a 22 de pătrate ale randamentelor, 122 ferestre nesuprapuse

Interpretare: orizontul lunar

- ▣ Agregarea a 22 de zile reduce zgomotul aproximării: R^2 în logaritmi 0,38 (GJR-t), față de 0,28 pentru o zi, în niveluri
- ▣ Panta $b = 0,75$ (e.s. 0,07): prognozele lunare sunt prea dispersate
 - ▶ Prognozele mari sunt urmate de mai puțină dispersie decât s-a prezis: consistent cu o revenire la medie mai rapidă decât implică $\alpha + \beta$
- ▣ În niveluri panta este doar 0,27: două ferestre COVID-19 (februarie și martie 2020) domină regresia
- ▣ Evaluați în logaritmi sau cu QLIKE când câteva luni de criză au dispersii uriașe

Recapitulare: Prognoză

Idei-cheie


- ▣ Evaluăm prognozele în afara eșantionului, cu parametri estimați doar pe datele trecute
- ▣ Cu o aproximare zgomotoasă folosim pierderi robuste (QLIKE, MSE) și testul Diebold–Mariano
- ▣ Mincer–Zarnowitz verifică nedeplasarea; un R^2 mic la o zi este de așteptat
- ▣ GARCH bate EWMA și dispersia istorică; membrii familiei GARCH sunt greu de departajat

GARCH-in-mean: este riscul recompensat?

- ▣ **GARCH-M** Engle, Lilien & Robins (1987): $r_t = c + \kappa \sigma_t + \varepsilon_t$ (sau $\kappa \sigma_t^2$)
 - ▶ $\kappa > 0$: investitorii cer un randament așteptat mai mare când riscul este mai mare (compromisul risc–randament)
- ▣ S&P 500, GARCH(1,1)-t în medie: $\hat{\kappa} = 0,096$ (t = 3,02) cu σ_t ; 0,028 (t = 2,35) cu σ_t^2
 - ▶ Pozitiv și semnificativ în acest eșantion, dar literatura este împărțită: GJR (1993) au găsit o relație negativă
- ▣ Atenție: un efect zilnic în medie este mic și fragil; depinde de eșantion și de asimetria dispersiei

 MFM_ch5_long_memory

Memoria lungă: unde GARCH nu ajunge



- S&P 500: autocorelația lui $|r_t|$ (decalaje 1–250, scară log) în date și în traiectorii lungi simulate din GARCH(1,1)-t și FIGARCH(1,d,1)-t estimate

Interpretare: memoria lungă

- Date: 0,289 la decalajul 1, 0,082 la 100, 0,009 la 250: o scădere lentă, aproximativ log-liniară
 - ▶ GARCH: prea mare la decalaje mici (0,416), apoi o prăbușire exponențială: ACF-ul său are un timp caracteristic
- **FIGARCH** Baillie, Bollerslev & Mikkelsen (1996): integrarea fracționară $(1 - L)^d$ dă o scădere hiperbolică
 - ▶ $\hat{d} = 0,60$ (e.s. 0,06); BIC mai mic cu 34,2 decât GARCH, dar memoria simulată este acum prea lungă (0,144 la decalajul 250)
- Niciun model cu o singură scară nu se potrivește tuturor orizonturilor: Capitolul 9 folosește volatilitatea realizată și modelul HAR

Alte limite ale GARCH

- ▣ **Rupturi structurale:** schimbările nivelului volatilității umflă $\alpha + \beta$ spre 1 [Lamoureux & Lastrapes \(1990\)](#)
 - ▶ Persistența noastră BET-TR (2014–2026) 0,9188 față de BET (2000–2026) 0,9907: eșantionul contează
- ▣ **Întârzierea reacției:** GARCH răspunde după șoc; volatilitatea implicită, de ex. VIX, se mișcă înainte
- ▣ **Doar date zilnice:** informația intrazilnică se pierde; măsurile realizate o folosesc (Capitolul 9)
- ▣ **Un singur activ:** portofoliile au nevoie de covarianțe; GARCH multivariat și DCC în Capitolul 6
- ▣ **Prețuri administrate (EUR/RON):** un GARCH zilnic descrie slab intervențiile

Dincolo de dispersie: entropie și risc de coadă

- ▣ [Pele, Lazar & Dufour \(2017\)](#): entropia distribuției randamentelor intrazilnice și riscul de piață (EUR/JPY)
 - ▶ O entropie mai mare merge cu Value at Risk și expected shortfall intrazilnice mai mici; entropia prognozează apoi Value at Risk zilnic
- ▣ [Pele & Mazurencu-Marinescu-Pele \(2019\)](#): entropia randamentelor intrazilnice Bitcoin ca predictor al Value at Risk zilnic
 - ▶ În testarea retrospectivă, prognoza bazată pe entropie bate modelele GARCH clasice
- ▣ [Pele, Lazar & Mazurencu-Marinescu-Pele \(2019\)](#): o măsură neparametrică a cozii bazată pe entropie, comparată cu modelele standard de expected shortfall
- ▣ Volatilitatea GARCH intră direct în Value at Risk și expected shortfall: Capitolele 7–8

O întrebare deschisă

- Bat prognozele de machine learning sau cele bazate pe măsuri realizate un GARCH bine specificat pentru dispersia zilnică a acțiunilor, în afara eșantionului, după ce ținem cont de numărul de modele comparate?
- Întrebarea este deschisă
 - ▶ Christensen, Siggaard & Veliyev (2023): metodele de machine learning, cu puțină calibrare, sunt competitive cu modelele de tip HAR pentru dispersia realizată a acțiunilor din Dow Jones
 - ▶ Hansen, Lunde & Nason (2011): Model Confidence Set păstrează toate modelele care nu sunt semnificativ mai slabe decât cel mai bun, obiectul potrivit când concurează multe modele
 - ▶ Acest capitol: în familia GARCH, statistica DM variază între $-1,22$ și $-0,36$: niciun câștigător semnificativ
- Formularea formală pentru modelele A și B, pierderea QLIKE L
 - ▶ $d_t = L(r_t^2, h_t^A) - L(r_t^2, h_t^B)$; $H_0: \mathbb{E}[d_t] = 0$; $H_1: \mathbb{E}[d_t] < 0$; statistica DM cu erori HAC Diebold & Mariano (1995)
 - ▶ Infirmată dacă A iese din Model Confidence Set sau dacă semnul lui $\bar{d}$ se schimbă între subperioadele pre-înregistrate

Bucula descoperirii, pas cu pas (1/2)

- Instrumentele sunt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și motoare de literatură (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „Listează comparațiile în afara eșantionului dintre prognozele de dispersie GARCH, HAR și de machine learning publicate după 2015, cu DOI, activ, funcție de pierdere, test și orizont.”
 - ▶ Rezolvăm fiecare DOI pe Crossref; verificăm că pierderea este robustă la o aproximare zgomotoasă [Patton \(2011\)](#)
- **Ipoteze:** „Pentru afirmația că asimetria îmbunătățește prognozele pe o zi, listează mecanismele concurente (levier, feedback de volatilitate, câteva zile de criză) și ce prezice fiecare pentru d_t după semnul lui r_{t-1} și pe subperioade.”
- **Date și cod:** „Scrie cod Python cu `arch` care reestimează GARCH-t și GJR-t în fiecare ianuarie pe o fereastră în expansiune din data/market și salvează prognozele dispersiei pe o zi; niciun parametru nu folosește date de după originea prognozei.”
 - ▶ Replicăm întâi: QLIKE 0,757 (GARCH-t) și 0,732 (GJR-t), DM $t = -1,22$ (Secțiunea 7)

Bucula descoperirii, pas cu pas (2/2)

- **Robustețe:** „Scrie un plan pre-înregistrat: împărțiri după semnul lui r_{t-1} și pe subperioade, MSE pe lângă QLIKE, orizontul de 22 de zile, decalajul HAC și o corecție Bonferroni sau Model Confidence Set.”
 - ▶ Placebo: împărțiri aleatoare de aceleași mărimi; diferența dintre $\bar{d}$ pe zilele de după scăderi și cele de după creșteri trebuie să depășească banda de 95% a diferențelor aleatoare
- **Critica:** „Joacă rolul unui referent: ar putea aproximarea r_t^2 , un singur an de criză sau decalajul HAC să creeze rezultatul meu? Dă testul care l-ar expune pe fiecare.”
- **Raportul:** toate împărțirile și pierderile încercate, valorile p ajustate, codul, semințele și versiunile pachetelor
- Fixăm planul înainte de prima rulare: orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare

Ce trebuie să verifice omul

- ▣ **Informație din viitor:** parametri estimați pe tot eșantionul sau h_t aliniat cu r_t în loc de r_{t-1} $\Rightarrow$ verificăm că ultima dată de estimare precede fiecare origine; decalăm prognoza o zi și comparăm
- ▣ **Pierdere nerobustă:** pierderile pe $|r_t|$ sau pe logaritmi pot ordona greșit prognozele cu o aproximare zgomotoasă [Patton \(2011\)](#) $\Rightarrow$ doar QLIKE și MSE
- ▣ **Căutarea modelelor:** 3 ecuații ale dispersiei $\times$ 4 distribuții $\times$ ferestre $\Rightarrow$ Model Confidence Set sau Bonferroni pe mulțimea pre-înregistrată
- ▣ **Perioade influente:** un an de criză poate domina $\bar{d}$ $\Rightarrow$ raportăm subperioadele și declarăm dinainte dacă vreun an poate fi exclus
- ▣ **Scara și convergența:** randamente în % sau în zecimale, optimizări eșuate $\Rightarrow$ verificăm indicatorii optimizatorului și o actualizare a dispersiei pas cu pas
- ▣ **Referințe sau funcții inventate:** DOI care nu se rezolvă, argumente arch inexistente $\Rightarrow$ Crossref și rularea codului; notăm în `AI_ERRORS.md`

Mini-studiu de caz: îmbunătățește asimetria prognoza?

- O propunere tipică a unui asistent: „GJR-t bate GARCH-t datorită efectului de levier”; $d_t = \text{QLIKE}(\text{GJR-t}) - \text{QLIKE}(\text{GARCH-t})$
- Replicăm: 2 692 zile, 2016–2026: $\bar{d} = -0,025$, DM $t = -1,22$ ($p = 0,22$): nesemnificativ
- Implicația testabilă a levierului: câștigul apare după zilele de scădere
 - ▶ După $r_{t-1} < 0$ (1 223 zile): $\bar{d} = -0,015$, $t = -0,51$; după $r_{t-1} \geq 0$ (1 469): $\bar{d} = -0,034$, $t = -1,12$
 - ▶ Nesusținută: GJR are $\hat{\alpha} = 0,000$, deci o creștere nu îi ridică prognoza; câștigul nu este mai mic după zilele de creștere
- Subperioade: 2016–2020 $t = -0,02$; 2021–2026 $t = -4,06$ ($p < 0,001$); fără 2020 $t = -4,26$
 - ▶ Câștigul din 2021–2026 trece de corecția Bonferroni pentru cele 5 împărțiri ($0,05/5 = 0,01$); excluderea lui 2020 este legitimă doar dacă a fost pre-înregistrată
- Interpretare: asimetria ajută, dar nu prin canalul propus și nu în 2016–2020

Rândul vostru: o sămânță de proiect de echipă

- Întrebarea: intră prognozele bazate pe dispersia realizată (HAR) sau de machine learning în Model Confidence Set alături de GARCH, GJR și EGARCH pentru S&P 500 și BET, 2016–2026?
- Replicăm întâi: tabelul QLIKE din Secțiunea 7 (GARCH-t 0,757, DM EWMA $t = 3,48$) și împărțirile din mini-studiul de caz
- Livrabile
 - ▶ O preînregistrare de o pagină: modele, pierderi, împărțiri, rata de eroare și ce ar infirma afirmația
 - ▶ Cod pe data/market (zilnic și intrazilnic), Model Confidence Set la 10%, o autocritică în stilul unui referent
- Notăm fiecare prompt, instrument și rezultat acceptat în AI_USE.md; fiecare eroare prinsă (informație din viitor, scară greșită, DOI inventat) și testul care a prins-o în AI_ERRORS.md
- Codul mini-studiului de caz: [Quantlets/Ch_05/ai_discovery_case.py](#)

Idei principale

Ce reținem

- ▣ Randamentele sunt aproape imprevizibile, mărimea lor nu: GARCH transformă gruparea în prognoze
- ▣ GARCH(1,1): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$; persistența $\alpha + \beta$ aproape de 1 pe toate piețele noastre
- ▣ Volatilitatea acțiunilor este asimetrică (GJR, EGARCH); a Bitcoin nu; a aurului este inversată
- ▣ Inovațiile au cozi groase și sunt asimetrice: Student-t sau t asimetric, cu erori standard robuste
- ▣ În afara eșantionului, modelele GARCH bat EWMA și dispersia istorică; între ele, diferențele sunt mici

O listă practică de verificare

- ▣ 1. Testați efectele ARCH: Q pe r_t^2 și testul LM
- ▣ 2. Estimați GARCH, GJR și EGARCH cu inovații Normale, Student-t și t asimetrice; randamente în %
- ▣ 3. Verificați convergența, frontierele și erorile standard robuste; comparați cu LR și BIC
- ▣ 4. Diagnosticați reziduurile standardizate (nivel, pătrate, semne, cele mai mari valori)
- ▣ 5. Evaluați prognozele în afara eșantionului cu QLIKE, Diebold–Mariano și Mincer–Zarnowitz
- ▣ 6. Raportați timpul de înjumătățire cu incertitudinea sa; nu vă bazați pe cifrele de termen lung când $\alpha + \beta \approx 1$

Resurse suplimentare

▣ Cărți

- ▶ Franke, Härdle & Hafner (2019), capitolele despre modelele ARIMA și GARCH pentru serii financiare
- ▶ Francq & Zakoïan (2019): teoria matematică a modelelor GARCH

▣ Cursuri Quantinar

- ▶  Statistics of Financial Markets
- ▶  Applied Time Series Analysis with Python

▣ Cod

- ▶ Toate graficele și tabelele: [Quantlets/Ch_05](#); pachetul Python [Sheppard, arch](#)

Ce urmează

- Capitolul 6: dependența dintre piețe, volatilitatea multivariată și corelațiile dinamice
- Capitolul 7: Value at Risk și expected shortfall, cu volatilitatea GARCH ca intrare
- Capitolul 8: testarea retrospectivă a prognozelor de risc
- Capitolul 9: volatilitatea realizată și memoria lungă
- Seminarul 5: recursia dispersiei pas cu pas, diagnosticul GARCH-t, GJR vs GARCH pe BET, compararea prognozelor, bootstrap, transmiterea șocurilor din SUA către BET

Bibliografie (1/4)

- Andersen, T.G., Bollerslev, T. (1998). Answering the skeptics: yes, standard volatility models do provide accurate forecasts. *International Economic Review*, 39(4), 885–905.
- Baillie, R.T., Bollerslev, T., Mikkelsen, H.O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30.
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *Review of Economics and Statistics*, 69(3), 542–547.
- Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- Christensen, K., Siggaard, M., Veliyev, B. (2023). A machine learning approach to volatility forecasting. *Journal of Financial Econometrics*, 21(5), 1680–1727.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.

Bibliografie (2/4)

- ▣ Engle, R.F. (2004). Risk and volatility: econometric models and financial practice. *American Economic Review*, 94(3), 405–420.
- ▣ Engle, R.F., Lilien, D.M., Robins, R.P. (1987). Estimating time varying risk premia in the term structure: the ARCH-M model. *Econometrica*, 55(2), 391–407.
- ▣ Engle, R.F., Ng, V.K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778.
- ▣ Francq, C., Zakoïan, J.-M. (2019). *GARCH Models: Structure, Statistical Inference and Financial Applications*, 2nd ed. Wiley.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- ▣ Hamilton, J.D., Susmel, R. (1994). Autoregressive conditional heteroskedasticity and changes in regime. *Journal of Econometrics*, 64(1–2), 307–333.
- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.

Bibliografie (3/4)

- Hansen, P.R., Lunde, A. (2005). A forecast comparison of volatility models: does anything beat a GARCH(1,1)? *Journal of Applied Econometrics*, 20(7), 873–889.
- Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- J.P. Morgan/Reuters (1996). *RiskMetrics — Technical Document*, 4th ed. New York.
- Lamoureux, C.G., Lastrapes, W.D. (1990). Persistence in variance, structural change, and the GARCH model. *Journal of Business & Economic Statistics*, 8(2), 225–234.
- Mandelbrot, B. (1963). The variation of certain speculative prices. *Journal of Business*, 36(4), 394–419.
- Mincer, J., Zarnowitz, V. (1969). The evaluation of economic forecasts. In J. Mincer (ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*, NBER.
- Nelson, D.B. (1990). Stationarity and persistence in the GARCH(1,1) model. *Econometric Theory*, 6(3), 318–334.
- Nelson, D.B. (1991). Conditional heteroskedasticity in asset returns: a new approach. *Econometrica*, 59(2), 347–370.

Bibliografie (4/4)

- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). Modeling expected shortfall using tail entropy. *Entropy*, 21(12), 1204.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). Using high-frequency entropy to forecast Bitcoin's daily Value at Risk. *Entropy*, 21(2), 102.
- ▣ Sheppard, K. [arch: ARCH models and other tools for financial econometrics in Python](#) (software documentation).