



Modelarea piețelor financiare

Capitolul 5: Volatilitate condiționată — modele GARCH



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ACF: AutoCorrelation Function (funcția de autocorelație)
- AI: Artificial Intelligence (inteligență artificială)
- AIC: Akaike Information Criterion (criteriul informațional Akaike)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ARIMA: AutoRegressive Integrated Moving Average (model) (model autoregresiv integrat cu medie mobilă)
- ARMA: AutoRegressive Moving Average (model) (model autoregresiv cu medie mobilă)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BNR: Banca Națională a României
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- EGARCH: Exponential GARCH (GARCH exponențial)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- FIGARCH: Fractionally Integrated GARCH (GARCH integrat fracționar)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-M: GARCH-in-Mean (GARCH cu volatilitatea în ecuația mediei)
- GARCH-MIDAS: GARCH with Mixed Data Sampling (long-run component) (GARCH cu eșantionare mixtă a datelor (componentă de termen lung))
- GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- GAS: Generalised Autoregressive Score (model) (model cu scor autoregresiv generalizat)
- GED: Generalised Error Distribution (distribuția generalizată a erorilor)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- GW: Giacomini–White (test) (testul Giacomini–White)

Acronime folosite în acest material (2/2)

- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- IGARCH: Integrated GARCH (GARCH integrat)
- LM: Lagrange Multiplier (multiplicatorul Lagrange)
- LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- MLE: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- MSE: Mean Squared Error (eroarea pătratică medie)
- MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- PIT: Probability Integral Transform (transformarea integrală de probabilitate)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)
- QQ: Quantile–Quantile (plot) (graficul cuantilă–cuantilă)
- QSD: Quasi Score-Driven (model) (model bazat pe un cvasi-scor)
- VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)
- XAU: gold, ISO 4217 code (one troy ounce) (aur, codul ISO 4217 (o uncie troy))

Structura capitolului și rezultatele învățării

Trei întrebări

- Cum evoluează dispersia? ARCH, GARCH, persistență, prognoze (partea I)
- Cum se estimează și se verifică modelele? Verosimilitate, inferență QMLE, teste la frontieră, asimetrie, diagnostic (partea I)
- Îmbunătățesc modelele prognozele? Pierderi în afara eșantionului, teste pentru mai multe modele, limite și extensii, un studiu de caz (partea a II-a)
- Detaliile tehnice sînt în [▶ Anexa](#) de la final

La sfîrșitul capitolului veți putea

- estima GARCH, GJR și EGARCH cu inovații cu cozi groase și interpreta fiecare parametru
- cuantifica corect incertitudinea persistenței și a timpului de înjumătățire și testa ipoteze aflate la frontiera spațiului parametrilor
- diagnostica reziduurile standardizate și compara prognozele dispersiei cu pierderi robuste la aproximarea volatilității

Episoade de volatilitate ridicată




Bursa din Amsterdam, 21 octombrie 1987, după crahul din 19 octombrie

Foto: Bart Molendijk / Anefo (1987); CC0; Wikimedia Commons


- Crahurile nu se limitează la zile izolate: variațiile mari sînt urmate de variații mari
 - ▶ „Schimbările mari tind să fie urmate de schimbări mari, de orice semn” [Mandelbrot \(1963\)](#)
- Acest **volatility clustering** este faptul stilizat 6 din [Capitolul 1](#)
- Volatilitatea intervine în calculul Value at Risk ([Capitolul 7](#)), al ponderilor portofoliului ([Capitolul 4](#)) și al prețurilor opțiunilor
- Întrebări
 - ▶ putem folosi volatility clustering pentru a **prognoza** riscul de mîine?
 - ▶ putem evalua corect incertitudinea prognozei?

Volatility clustering pe orice piață



- Randamente log zilnice
 $r_t = 100 (\ln P_t - \ln P_{t-1})$ în %, închideri pînă la 18 septembrie 2026; S&P 500 și BET din 2000, Bitcoin din 17 septembrie 2014
- Indici bursieri: zilele lucrătoare; zilele cu închiderea egală cu cea precedentă (sărbători completate cu ultimul preț) se elimină: 3 la S&P 500, 0 la BET; Bitcoin: 7 zile din 7
- În toate cele trei serii, anii liniștiți alternează cu luni agitate: 2008, martie 2020, aprilie 2025

Semnul este imprevizibil, mărimea nu



- S&P 500, decalajul 1: -0,099 pentru r_t , 0,313 pentru r_t^2 ; toate cele 50 de autocorelații ale lui r_t^2 pînă la decalajul 50 ies din $\pm 0,024$
- Și cozi groase: exces de aplatizare 10,7 (S&P 500), 11,1 (BET), 12,0 (Bitcoin); 0 pentru distribuția Normală
- Obiectul de modelat: $\sigma_t^2 = \text{Var}(r_t | \mathcal{F}_{t-1})$, cu $\mathcal{F}_{t-1}$ informația de la închiderea zilei $t - 1$

Testarea efectelor ARCH

- H_0 : fără volatility clustering, $\text{Var}(r_t | \mathcal{F}_{t-1})$ constantă
- **McLeod–Li** [McLeod & Li \(1983\)](#): Ljung–Box $Q(10)$ pe r_t^2 ; respingem dacă $Q(10) > 18,3$ (χ_{10}^2 , 5%)
- **Testul LM al lui Engle** [Engle \(1982\)](#): regresăm $\hat{\varepsilon}_t^2$ pe o constantă și pe $\hat{\varepsilon}_{t-1}^2, \dots, \hat{\varepsilon}_{t-5}^2$, $\hat{\varepsilon}_t = r_t - \bar{r}$
 - ▶ $LM = nR^2$; H_0 : toate cele cinci pante sînt 0; respingem dacă $LM > 11,1$ (χ_5^2 , 5%)
- Toate statisticile sînt mult peste valorile critice (toate $p < 0,001$): volatility clustering la acțiuni, cripto, un curs administrat și aur; cea mai slabă la Bitcoin și aur
- Testele scorului unilaterale și tabelul complet: [▶ Anexă](#)

Serie	$Q(10)$ pe r^2	LM(5)	$\hat{\rho}_1(r^2)$
S&P 500	6133	1684	0,313
BET	2440	982	0,330
BET-TR	714	371	0,171
Bitcoin	213	115	0,137
EUR/RON	2420	871	0,342
Aur	744	329	0,110

Modelul ARCH al lui Engle (1982)

- ▣ Cadrul: $r_t = \mu + \varepsilon_t$, $\varepsilon_t = \sigma_t z_t$, inovațiile z_t i.i.d. cu media 0 și dispersia 1
 - ▶ Dispersia condiționată $\sigma_t^2 = \text{Var}(r_t | \mathcal{F}_{t-1})$; dispersia necondiționată $\sigma^2 = \mathbb{E}\sigma_t^2$
- ▣ **ARCH(q)**: $\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2$ [Engle \(1982\)](#)
 - ▶ $\omega > 0$, $\alpha_i \geq 0$: dispersia este mereu pozitivă
- ▣ Un șoc mare ieri (ε_{t-1}^2 mare) crește dispersia de azi: volatility clustering rezultă direct din specificația modelului
- ▣ ARCH(1): dispersia necondiționată $\sigma^2 = \omega/(1 - \alpha_1)$, finită dacă $\alpha_1 < 1$; momentul său de ordin patru este cazul $\beta = 0$ al rezultatului GARCH de mai jos
- ▣ Engle a primit Premiul Nobel în 2003 pentru ARCH (istoric: [▶ Anexă](#))

De la ARCH la GARCH (Bollerslev, 1986)

- ▣ Problema ARCH: volatility clustering în datele reale durează luni de zile, deci q trebuie să fie mare (mulți parametri)
- ▣ **GARCH(1,1)** [Bollerslev \(1986\)](#): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$
 - ▶ $\omega > 0$, $\alpha \geq 0$, $\beta \geq 0$; α : reacția la știri; β : memoria dispersiei trecute
- ▣ Prin substituții succesive în recursie: $\sigma_t^2 = \frac{\omega}{1-\beta} + \alpha \sum_{j \geq 1} \beta^{j-1} \varepsilon_{t-j}^2$
 - ▶ Un ARCH(∞) cu ponderi descrescătoare geometric, cu doar trei parametri
- ▣ GARCH(p, q) adaugă decalaje; în practică GARCH(1,1) este modelul de bază [Hansen & Lunde \(2005\)](#)

GARCH(1,1) ca model ARMA pentru pătratele șocurilor

- ▣ Definim $\nu_t = \varepsilon_t^2 - \sigma_t^2$, surpriza din pătratul șocului ($\mathbb{E}[\nu_t | \mathcal{F}_{t-1}] = 0$)
- ▣ Atunci $\varepsilon_t^2 = \omega + (\alpha + \beta) \varepsilon_{t-1}^2 + \nu_t - \beta \nu_{t-1}$
 - ▶ Un ARMA(1,1) în ε_t^2 cu coeficientul autoregresiv $\alpha + \beta$
- ▣ Consecință: autocorelațiile lui ε_t^2 scad geometric, $\rho_k = \rho_1(\alpha + \beta)^{k-1}$
 - ▶ $\rho_1 = \alpha(1 - \beta^2 - \alpha\beta)/(1 - \beta^2 - 2\alpha\beta)$ dacă $\mathbb{E}\varepsilon_t^4 < \infty$ (Seminarul 5, A6)
 - ▶ S&P 500, GARCH(1,1) cu inovații Normale: $\rho_1 = 0,356$, $\rho_{10} = 0,298$; în eșantion 0,313 și 0,248
- ▣ De aceea $\alpha + \beta$ se numește **persistența** volatilității

Staționaritatea și dispersia necondiționată

- ▣ **Staționaritate în covarianță:** $\alpha + \beta < 1$; atunci

- ▶ $\sigma^2 = \mathbb{E}[\sigma_t^2] = \frac{\omega}{1 - \alpha - \beta}$

- ▣ Derivare: luăm valoarea așteptată în recursie, $\mathbb{E}\sigma_t^2 = \omega + (\alpha + \beta)\mathbb{E}\sigma_{t-1}^2$, și impunem $\mathbb{E}\sigma_t^2 = \mathbb{E}\sigma_{t-1}^2$

- ▣ **IGARCH** (GARCH integrat): $\alpha + \beta = 1$; dispersia necondiționată este infinită


- ▶ Totuși, dacă $\alpha > 0$ și z_t^2 este nedegenerat, procesul rămîne **strict** staționar: condiția $\mathbb{E} \ln(\alpha z_t^2 + \beta) < 0$ **Nelson (1990)** este îndeplinită din inegalitatea lui Jensen, deoarece $\mathbb{E} \ln(\alpha z_t^2 + \beta) < \ln(\alpha + \beta) = 0$

- ▣ Țintirea dispersiei: fixăm $\omega = \hat{\sigma}^2(1 - \alpha - \beta)$ cu dispersia de selecție $\hat{\sigma}^2$

Momentul de ordin patru și applatizarea

- Cu z_t Normal, applatizarea lui ε_t este $K = \frac{3[1 - (\alpha + \beta)^2]}{1 - (\alpha + \beta)^2 - 2\alpha^2}$
 - ▶ Finită doar dacă $(\alpha + \beta)^2 + 2\alpha^2 < 1$ (Seminarul 1, Exercițiul A9)
 - ▶ ARCH(1) este cazul $\beta = 0$: $K = 3(1 - \alpha^2)/(1 - 3\alpha^2)$, finită doar dacă $\alpha < 1/\sqrt{3}$: cozi groase chiar cu inovații Normale
- S&P 500, GARCH(1,1) cu inovații Normale: $\hat{\alpha} = 0,120604$, $\hat{\beta} = 0,859878$
 - ▶ $(\hat{\alpha} + \hat{\beta})^2 + 2\hat{\alpha}^2 = 0,990435$: puțin sub 1, deci $K = 12,1$; applatizarea de selecție a randamentelor: 13,7
- K este prost condiționat lângă frontiera momentelor: îl raportăm din estimări nerotunjite (un exemplu de rotunjire: 
▶ Anexă ; Seminarul 5, A4)
- Volatility clustering singur generează o mare parte din cozile groase; restul vine din z_t cu cozi groase

Simulare: GARCH produce volatility clustering



- Sus: randamente Normale i.i.d.; jos: GARCH(1,1) cu $\omega = 0,02$, $\alpha = 0,10$, $\beta = 0,88$, aceeași dispersie necondiționată (1) și benzile $\pm 2\sigma_t$
- Perioadele liniștite și rafalele apar doar în traiectoria GARCH
- Inovații Normale, dar randamente cu cozi groase: un amestec de distribuții Normale cu dispersii diferite are cozi groase (aplatizarea pe o traiectorie lungă: [▶ Anexă](#))

Persistența și timpul de înjumătățire

- ▣ Prognoza pe mai mulți pași: $\mathbb{E}[\sigma_{t+h}^2 \mid \mathcal{F}_t] = \sigma^2 + (\alpha + \beta)^{h-1}(\sigma_{t+1}^2 - \sigma^2)$
 - ▶ Distanța față de dispersia de termen lung scade cu factorul $\alpha + \beta$ în fiecare zi
- ▣ **Timpul de înjumătățire:** numărul de zile după care jumătate dintr-un șoc de dispersie a dispărut
 - ▶ $(\alpha + \beta)^h = 0,5 \Rightarrow h_{1/2} = \frac{\ln 0,5}{\ln(\alpha + \beta)}$
- ▣ Exemple: $\alpha + \beta = 0,95$: 13,5 zile; 0,99: 69 de zile; 0,995: 138 de zile
- ▣ Schimbări mici ale lui $\alpha + \beta$ lângă 1 dau timpi de înjumătățire foarte diferiți: incertitudinea estimării contează (secțiunea următoare; Seminarul 5, A3 și B7)

EWMA și IGARCH: fără revenire la medie

- ▣ **EWMA J.P. Morgan/Reuters (1996):** $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, cu $\lambda = 0,94$ pentru date zilnice și randamente de medie zero
 - ▶ Ponderi $(1 - \lambda)\lambda^{j-1}$ pe pătratele randamentelor trecute: zilele recente contează cel mai mult
 - ▶ EWMA este un IGARCH(1,1) cu $\omega = 0$, $\alpha = 1 - \lambda$, $\beta = \lambda$: niciun parametru de estimat
- ▣ Prognozele pe mai mulți pași, la închiderea zilei t , diferă
 - ▶ EWMA: constantă, $\mathbb{E}_t \sigma_{t+h}^2 = \sigma_{t+1}^2$ pentru orice h
 - ▶ IGARCH cu $\omega > 0$: crescătoare, $\mathbb{E}_t \sigma_{t+h}^2 = \sigma_{t+1}^2 + (h - 1)\omega$
 - ▶ GARCH staționar: atrasă spre σ^2 cu rata $\alpha + \beta$
- ▣ EWMA servește drept reper în comparația prognozelor

Verosimilitatea maximă

- Parametrii $\theta = (\mu, \omega, \alpha, \beta)$; dat fiind θ , recursia produce $\sigma_1^2(\theta), \dots, \sigma_n^2(\theta)$
- Log-verosimilitatea Normală: $\ell(\theta) = -\frac{1}{2} \sum_{t=1}^n [\ln 2\pi + \ln \sigma_t^2 + \varepsilon_t^2 / \sigma_t^2]$
 - Fiecare zi contribuie cu densitatea lui ε_t condiționată de trecut: verosimilitatea se factorizează în timp
- Fără formulă explicită: optimizare numerică sub restricțiile $\omega > 0, \alpha, \beta \geq 0, \alpha + \beta < 1$
- Pornirea: σ_1^2 se fixează la dispersia de selecție (efectul său dispăre cu rata β)
- Scara: randamente în %, astfel încât dispersia să fie de ordinul 1
 - EUR/RON (abatere standard zilnică de circa 0,28%) se estimează pe 10 r_t : nescalat, optimizatorul s-a oprit într-un optim local

QMLE Gaussian: rezultatul și ipotezele sale

- **QMLE Gaussian:** maximizăm verosimilitatea Normală chiar dacă z_t nu este Normal [Bollerslev & Wooldridge \(1992\)](#)
- **Consistența** (GARCH(1,1)) [Berkas, Horváth & Kokoszka \(2003\)](#), [Francq & Zakoïan \(2004\)](#)
 - ▶ Staționaritate strictă $\mathbb{E} \ln(\alpha z_t^2 + \beta) < 0$; θ_0 într-o mulțime compactă; z_t^2 nedegenerat; nicio condiție de moment asupra lui ε_t
- **Normalitatea asimptotică** a lui $\vartheta = (\omega, \alpha, \beta)$ (GARCH pur, media cunoscută): adăugăm ϑ_0 interior și $\kappa_z = \mathbb{E} z_t^4 < \infty$
 - ▶ $\sqrt{n}(\hat{\vartheta} - \vartheta_0) \rightarrow N(0, (\kappa_z - 1)J^{-1})$, $J = \mathbb{E}[g_t g_t']$, $g_t = \partial \ln \sigma_t^2 / \partial \vartheta$
- Estimatorul sandwich $\hat{A}^{-1} \hat{B} \hat{A}^{-1}$ estimează $(\kappa_z - 1)J^{-1}$; inversa hessianei $\hat{A}^{-1}$ estimează $2J^{-1}$
 - ▶ A: minus hessiana medie; B: dispersia scorului; e.s. robustă / clasică = $\sqrt{(\kappa_z - 1)/2}$, 1 sub normalitate
- Variante (medie estimată, IGARCH, cazul exploziv): [▶ Anexă](#)

QMLE: validitatea inferenței în aplicații

- S&P 500, GARCH(1,1) cu verosimilitate Normală: aplatizarea reziduurilor $\hat{\kappa}_z = 4,73$
 - ▶ Teoria: e.s. robustă / clasică = $\sqrt{(4,73 - 1)/2} = 1,37$; observat: 1,37 pentru $\hat{\alpha}$, 1,37 pentru $\hat{\beta}$
- Bitcoin: GARCH-t (sufixul -t: inovații Student-t) dă $\hat{\nu} = 3,18 < 4$: sub această lege $\mathbb{E}z_t^4 = \infty$, iar condiția pentru normalitatea asimptotică a QMLE Gaussian nu este îndeplinită
 - ▶ Aplatizarea reziduurilor nu se stabilizează: 19,8 pe prima jumătate, 14,6 pe tot eșantionul; rapoartele e.s. 2,51 și 2,01
- Hall & Yao (2003): atunci QMLE Gaussian converge mai lent decât $\sqrt{n}$, spre o limită non-Gaussiană: statisticile t robuste ale QMLE Gaussian nu sînt valide
- Remedii: o cvasi-verosimilitate cu cozi groase, cu ajustarea scalei Fan, Qi & Xiu (2014), sau MLE Student-t (scor mărginit: nu cere momentul de ordin patru dacă legea este corectă), cu inferență bootstrap lîngă frontiere

Inovații cu cozi groase


- **Student-t Bollerslev (1987)**: $z_t = \sqrt{(\nu - 2)/\nu} t_\nu$, dispersie unitară pentru $\nu > 2$
 - ▶ ν (grade de libertate): cu cât ν este mai mic, cu atât cozile sînt mai groase; momentul de ordin patru există doar pentru $\nu > 4$
- **t asimetric Hansen (1994)**: adaugă un parametru de asimetrie $\lambda \in (-1, 1)$
 - ▶ $\lambda < 0$: coada stîngă este mai lungă (pierderile mari mai probabile decît câștigurile mari)
- **GED Nelson (1991)**: densitate $\propto \exp(-\frac{1}{2}|z/\lambda_\nu|^\nu)$
 - ▶ $\nu = 2$: distribuția Normală; $\nu = 1$: Laplace; $\nu < 2$: cozi mai groase (λ_ν asigură dispersia unitară)

S&P 500: estimările GARCH(1,1)-t

Parametru	Estimare	E.s. robustă	E.s. clasică	Raport
ω	0,0157			
α	0,123	0,011	0,010	1,06
β	0,872	0,010	0,010	1,08
ν	6,26	0,48		
$\alpha + \beta$	0,9947			

- Randamente zilnice în %, 2000–2026; media $\hat{\mu} = 0,079\%$ pe zi; tabelul complet, cu toate erorile standard: Seminarul 5, B1
- $\hat{\beta}$: cea mai mare parte a dispersiei de azi este dispersia de ieri; $\hat{\alpha}$: știrile modifică dispersia doar moderat; $\hat{\nu} = 6,26$: cozi clar mai groase decât cele ale distribuției Normale
- Timp de înjumătățire 131 de zile; volatilitatea de termen lung $\sqrt{251,4 \hat{\omega} / (1 - \hat{\alpha} - \hat{\beta})} = 27,3\%$ anual ($q = 251,4$ randamente pe an), peste valoarea din eșantion 19,2%: împărțirea la $1 - \hat{\alpha} - \hat{\beta}$ o face imprecisă (slide-ul următor)

Persistență aproape de 1: ce poate și ce nu poate metoda delta



- Metoda delta: $\widehat{e.s.} g(\hat{\theta}) \approx \sqrt{\nabla g' \hat{V} \nabla g}$, $\hat{V}$ covarianța robustă a lui $(\hat{\omega}, \hat{\alpha}, \hat{\beta})$; volatilitatea de termen lung 27,3% anual, e.s. 10,8 puncte
- Timpul de înjumătățire: $\partial h / \partial p = 24\,789$ la $\hat{p} = 0,994712$, $\widehat{e.s.}(\hat{p}) = 0,0047$, deci $\widehat{e.s.}(\hat{h}) \approx 116$ zile, iar $\hat{h} \pm 1,96 \widehat{e.s.}$ conține timpi de înjumătățire negativi: liniarizarea eșuează
- Transformăm în schimb intervalul pentru p : [0,9855; 1,0039] dă $h \in [48; \infty)$; plauzibilitatea lui $p = 1$ cere un test la frontieră (slide-urile următoare)

Testarea la frontieră: un tabel de decizie

Situația sub H_0	Exemplu	Legea lui $LR = 2(\ell_1 - \ell_0)$	Valoare critică 5%
Restricție interioară	GJR (GARCH asimetric) vs GARCH, $\gamma = 0$ (cu $\alpha > 0$)	χ_1^2	3,84
Un parametru pe frontieră, ceilalți identificați și interiori	Normală vs Student-t ($1/\nu = 0$); IGARCH ($\alpha + \beta = 1$)	$\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ Self & Liang (1987), Andrews (2001)	2,71
Un parametru perturbator (nuisance) neidentificat	Fără ARCH: $\alpha = 0$ lasă β neidentificat	nestandard Andrews (2001)	simulare
Mai multe restricții active simultan	GJR cu $\hat{\alpha} = 0$, testul $\gamma = 0$	nestandard	simulare

- ▣ Modele neimbricate: **AIC** = $-2\ell + 2k$, **BIC** = $-2\ell + k \ln n$ (k parametri); se preferă valoarea mai mică
- ▣ Testul Wald t pentru o estimare la limită (de ex. $\hat{\alpha} = 0$) nu este $N(0, 1)$; bootstrap-ul parametric din $\hat{\theta}$ este inconsistent când θ_0 este pe frontieră Andrews (2000): simulăm în schimb sub H_0

Teste la frontieră pe datele noastre


- Inovații Normale vs Student-t, GARCH(1,1): $LR = 311,0$ (S&P 500), 1082,0 (Bitcoin)
 - ▶ Mult peste 2,71: cozile groase sînt decisive; amestecul contează doar în cazurile la limită
- GJR-t (GJR: un GARCH asimetric, secțiunea următoare), S&P 500: $\hat{\alpha} = 0,000$; testul său t nu este standard, iar legea χ_1^2 a LR pentru $\gamma = 0$ presupune $\alpha_0 > 0$
- IGARCH, $H_0: \alpha + \beta = 1$ (GARCH-t): $LR = 1,11$ (S&P 500), 1,14 (BET)
 - ▶ S&P 500: $p = 0,29$ (χ_1^2), 0,15 (amestec), 0,17 (bootstrap parametric sub H_0 , $B = 999$)
 - ▶ BET: $p = 0,28$, 0,14 și 0,17
- Sub H_0 , 52% din reestimări au $\hat{\alpha} + \hat{\beta} \geq 0,999$ (la frontiera $\alpha + \beta = 1$), cum prezice amestecul: rădăcina unitară în dispersie nu poate fi respinsă pentru niciunul dintre indici

Exemplu lucrat: prognozele pe o zi și pe zece zile

- S&P 500, GARCH(1,1)-t: $\hat{\omega} = 0,0157$, $\hat{\alpha} = 0,123$, $\hat{\beta} = 0,872$, $\hat{\mu} = 0,079$
- Ultima zi $T = 18.09.2026$: $\hat{\varepsilon}_T = r_T - \hat{\mu} = 0,088$, dispersia filtrată $\hat{\sigma}_T^2 = 0,565$
 - $\hat{\sigma}_{T+1}^2 = \hat{\omega} + \hat{\alpha}\hat{\varepsilon}_T^2 + \hat{\beta}\hat{\sigma}_T^2 = \hat{\omega} + 0,0009 + 0,493 = 0,509$, adică 11,3% anual
- Dispersia de termen lung $\hat{\sigma}^2 = \hat{\omega}/(1 - \hat{\alpha} - \hat{\beta}) = 2,97$; ziua 10: $\hat{\sigma}^2 + (\hat{\alpha} + \hat{\beta})^9(\hat{\sigma}_{T+1}^2 - \hat{\sigma}^2)$
 - $= 2,97 + 0,953 \times (0,509 - 2,97) = 0,624$
- Dispersia pe 10 zile $\sum_{h=1}^{10} \hat{\sigma}_{T+h}^2 = 5,67$, volatilitatea 2,38%
 - Regula rădăcinii pătrate a timpului dă $\sqrt{10} \times 0,714 = 2,26\%$: prea puțin, deoarece $\hat{\sigma}_{T+1}^2 < \hat{\sigma}^2$ și volatilitatea este prognozată în creștere

 MFM_ch5_garch_estimation

Structura la termen a volatilității




- Volatilitatea medie pe următoarele h zile, prognozată din 18.09.2026 (GARCH(1,1)-t); punctat: nivelul de termen lung
- S&P 500 urcă de la 11,3% la 20,1% într-un an (azi sub nivelul de termen lung); aurul scade de la 23,9% la 22,4%
- Bitcoin, EUR/RON: IGARCH cu $\hat{\omega} > 0$, prognoza dispersiei crește cu $\hat{\omega}$ pe zi (Bitcoin: 108,3% într-un an): o consecință a rădăcinii unitare estimate

GARCH(1,1)-t pe șase piețe

Serie	$\hat{\omega}$	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\alpha} + \hat{\beta}$	$h_{1/2}$ (zile)	$\hat{\nu}$	Vol. termen lung
S&P 500	0,0157	0,123	0,872	0,9947	131	6,26	27,3
BET	0,0448	0,192	0,799	0,9907	74	5,01	34,7
BET-TR	0,0755	0,206	0,713	0,9188	8	5,02	15,2
Bitcoin	0,1937	0,109	0,891	1,0000	∞	3,18	–
EUR/RON	0,0000	0,123	0,877	1,0000	∞	4,20	–
Aur	0,0107	0,049	0,944	0,9935	106	4,58	20,7


- Volatilitatea de termen lung în % anual, fiecare serie anualizată cu frecvența ei; – când $\hat{\alpha} + \hat{\beta} \geq 0,999$; la EUR/RON $\hat{\omega}$ este 0,0000 la patru zecimale
- Acțiuni și aur: persistență 0,99–0,995; BET reacționează mai puternic la știri ($\hat{\alpha} = 0,192$) și uită mai repede decât S&P 500
- Eșantioane diferite: BET-TR începe în 2014, deci persistența sa mai mică nu este comparabilă cu cea a BET 2000–2026; Bitcoin: $\hat{\nu} < 4$, moment de ordin patru infinit sub legea estimată
- EUR/RON, un curs administrat: pe 6 mai 2025, o variație de +1,20% după zile de $\pm 0,004\%$ dă un reziduu standardizat de 154

Persistența: cât de repede se sting șocurile?







- $(\hat{\alpha} + \hat{\beta})^h$: partea dintr-un șoc de dispersie rămasă după h zile; linia întreruptă: o jumătate
- Timpi de înjumătățire: S&P 500 131 de zile, aur 106, BET 74, BET-TR 8; la Bitcoin și EUR/RON șocurile nu se sting niciodată în model
- Schimbările nivelului volatilității pot imita o persistență mare [Lamoureux & Lastrapes \(1990\)](#) (schimbare de regim: [Hamilton & Susmel \(1994\)](#)): raportați timpii de înjumătățire ca intervale (Seminarul 5, B7)

S&P 500: volatilitatea GARCH și VIX



- $\hat{\sigma}_t \sqrt{q}$ ($q = 251,4$) din GARCH(1,1)-t și VIX (volatilitatea implicită pe 30 de zile), 2000–2026: corelația 0,89
- VIX este mai mare în medie: 19,8% față de 17,0%, peste GARCH în 84% din zile
- Diferența nu măsoară variance risk premium (prima de risc a dispersiei): prima compară VIX^2 cu o prognoză a dispersiei pe 30 de zile sub probabilitatea reală; $\hat{\sigma}_t$ este o volatilitate pe o zi

BET, Bitcoin, EUR/RON și aur



- Volatilitatea GJR-GARCH-t, fiecare serie anualizată cu frecvența ei (Bitcoin: 365 de zile)
- BET: 2008 domină, acum 26,4%; Bitcoin: 50–100% este obișnuit, cel mai înalt vîrf este în martie 2020
- EUR/RON: o liniște administrată, întreruptă de rafale în 2022 și 2025, pe care un GARCH zilnic o descrie slab; aur: un nou maxim de 53% în 2026


GJR-GARCH (Glosten, Jagannathan și Runkle, 1993)

- Știrile proaste cresc volatilitatea viitoare mai mult decât știrile bune de aceeași mărime (faptul stilizat 9, Capitolul 1); GARCH(1,1) nu vede semnul: ε_{t-1}^2 este același pentru -3 și $+3$
- $\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, cu $I_{t-1} = 1$ dacă $\varepsilon_{t-1} < 0$ Glosten, Jagannathan & Runkle (1993)
 - ▶ Știri bune: panta α ; știri proaste: panta $\alpha + \gamma$; pozitivitatea: $\omega > 0, \alpha \geq 0, \alpha + \gamma \geq 0, \beta \geq 0$ (γ poate fi negativ)
 - ▶ Persistența $\alpha + \gamma/2 + \beta$ pentru z_t simetric; pentru z_t asimetric, $1/2$ se înlocuiește cu $\mathbb{E}[z_t^2 1(z_t < 0)]$ (Seminarul 5, A2)
- S&P 500: $\hat{\alpha} = 0,000, \hat{\gamma} = 0,205$ ($t = 10,0$), $\hat{\beta} = 0,881$; testul simetriei: $H_0: \gamma = 0$ prin t sau prin LR față de GARCH(1,1)
- Mecanisme posibile, netestate aici: levierul (un preț în scădere crește raportul datorii/capital propriu) și feedback-ul volatilității (volatilitatea așteptată mai mare crește randamentul cerut, deci prețurile scad acum)

EGARCH (Nelson, 1991)


- $\ln \sigma_t^2 = \omega + \alpha (|z_{t-1}| - \mathbb{E}|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$ Nelson (1991)
 - Efectul de mărime α , efectul de semn γ ; $\gamma < 0$: șocurile negative cresc volatilitatea mai mult
- Forma logaritmică garantează $\sigma_t^2 > 0$ fără restricții de semn asupra parametrilor
- Persistența: β (staționar dacă $|\beta| < 1$)
- S&P 500: $\hat{\alpha} = 0,138$, $\hat{\gamma} = -0,165$ ($t = -15,2$), $\hat{\beta} = 0,979$
- În arch, $\mathbb{E}|z|$ este fixat la $\sqrt{2/\pi}$, valoarea sa sub distribuția Normală

Curba de impact a știrilor pentru S&P 500



- Curba de impact a știrilor Engle & Ng (1993): σ_t^2 ca funcție de ε_{t-1} , cu σ_{t-1}^2 fixată la dispersia de selecție 1,47 ($\%^2$)
- Șoc de -3%: GJR 3,16, EGARCH 2,76; +3%: GJR 1,31, EGARCH 1,22; GARCH: 2,40 pentru ambele
- După știri proaste prognoza este de 2,4 ori (GJR) și de 2,3 ori (EGARCH) cea după știri bune: rapoarte de niveluri, nu de creșteri

Detaliu: crahul COVID-19, 2020



- Ianuarie–iulie 2020: $|r_t|$ anualizat, volatilitatea GARCH-t și GJR-GARCH-t, VIX
- 24 februarie ($r_t = -3,41\%$): VIX a trecut de la 17,1% la 25,0% în aceeași zi; GARCH-t de la 12,2% la 22,5% abia a doua zi: GARCH reacționează cu o zi întârziere, piața include informația în preț imediat
- După $r_t = -12,8\%$ pe 16 martie, vîrfuri pe 17 martie: GARCH-t 111%, GJR-t 127%, mai sus deoarece șocurile au fost negative

Asimetria pe șase piețe

Serie	$\hat{\gamma}_{GJR}$	t	LR vs GARCH	valoare p	$\hat{\gamma}_{EGARCH}$	t
S&P 500	0,205	10,0	235,7	< 0,001	-0,165	-15,2
BET	0,043	2,1	4,9	0,026	-0,028	-2,6
BET-TR	0,111	2,9	10,3	0,001	-0,063	-3,5
Bitcoin	-0,013	-0,7	0,7	0,416	0,015	1,2
EUR/RON	0,039	3,0	9,3	0,002	-0,040	-2,5
Aur	-0,043	-4,7	27,6	< 0,001	0,038	5,7

- Inovații Student-t; t robust; $LR \sim \chi^2_1(3,84)$ dacă densitatea Student-t este corectă; t robust este $N(0, 1)$ doar dacă ceilalți parametri sînt interiori (nu pentru $\hat{\alpha} = 0$)
- Știrile proaste contează mai mult (GJR $\hat{\gamma} > 0$, EGARCH $\hat{\gamma} < 0$): S&P 500 puternic ($LR = 235,7$), BET și BET-TR slab (4,9, 10,3), EUR/RON ușor; Bitcoin: nedetectată ($LR = 0,7$); aur: inversă ($\hat{\gamma}_{GJR} = -0,043$)
- Levierul pentru acțiuni și rolul de refugiu al aurului sînt interpretări compatibile cu aceste semne, nu mecanisme testate

S&P 500: douăsprezece modele comparate prin BIC


ΔBIC	$N(0, 1)$	Student-t	t asimetric	GED
GARCH(1,1)	648,9	346,7	307,4	339,8
GJR-GARCH(1,1)	394,7	119,9	49,6	141,6
EGARCH(1,1)	372,9	74,8	0,0	111,4

- ΔBIC : $BIC = -2\ell + k \ln n$ minus cel mai mic BIC dintre cele 12 modele (0 = modelul preferat)
- Contează două alegeri: inovațiile Student-t în locul celor Normale scad BIC cu circa 300; asimetria îl mai scade cu 230–270; câștigător: EGARCH cu inovații t asimetrice
- BIC ordonează adecvarea în eșantion, nu acuratețea prognozelor: secțiunea despre prognoze testează dacă aceste câștiguri se păstrează în afara eșantionului

Reziduurile standardizate și testele de asimetrie

- **Reziduul standardizat:** $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$; dacă modelul este corect, $\hat{z}_t$ este aproape i.i.d. cu dispersia 1
- Verificări, fiecare cu H_0 : modelul surprinde acea proprietate
 - ▶ Ecuația mediei: Ljung–Box $Q(10)$ pe $\hat{z}_t$; ecuația dispersiei: $Q(10)$ pe $\hat{z}_t^2$ și LM(5); distribuția: grafic QQ față de densitatea presupusă
- Regresia de asimetrie Engle & Ng (1993): $\hat{z}_t^2 = b_0 + b_1 S_{t-1}^- + b_2 S_{t-1}^- \hat{\varepsilon}_{t-1} + b_3 S_{t-1}^+ \hat{\varepsilon}_{t-1} + u_t$
 - ▶ $S_{t-1}^- = 1$ dacă $\hat{\varepsilon}_{t-1} < 0$, altfel 0; $S_{t-1}^+ = 1 - S_{t-1}^-$; termenii de mărime folosesc reziduul nestandardizat $\hat{\varepsilon}_{t-1}$ (ec. 18 din Engle și Ng, 1993)
 - ▶ b_1 : asimetria de semn; b_2 , b_3 : asimetria de mărime negativă și pozitivă; testul comun $nR^2 \sim \chi_3^2$ (7,81 la 5%), conservator deoarece omite gradientul dispersiei estimate

S&P 500: sînt inovațiile Normale?



- Reziduurile standardizate ale GARCH(1,1) cu inovații Normale: excesul de aplatizare scade de la 10,7 (randamente) la 1,73; asimetria -0,53, Jarque-Bera 1153
- 15 reziduuri sub -4: 0,21 așteptate sub distribuția Normală, 8,5 sub Student-t cu $\nu = 6,3$; cel mai mare: $\hat{z} = -6,6$ (27 februarie 2007)
- O coadă stîngă mai lungă: t asimetric cu $\hat{\lambda} = -0,150$ (GJR, $\hat{\nu} = 7,7$ grade de libertate), de aceea BIC preferă inovațiile t asimetrice

S&P 500: diagnosticul a cinci modele


Model	$Q(10)$ pe $\hat{z}$	$Q(10)$ pe $\hat{z}^2$	LM(5)	Asim. semn t	Comun χ^2_3
GARCH-N	21,2	16,4	8,0	3,64	41,8
GARCH-t	21,9	13,6	5,8	3,56	40,7
GJR-t	22,3	10,2	4,5	3,61	28,1
EGARCH-t	27,6	10,5	8,2	2,04	9,9
GJR cu t asimetric	19,7	10,7	5,0	3,91	31,8

- Valori critice la 5%: 18,3 (χ^2_{10}), 11,1 (χ^2_5), 7,81 (χ^2_3), $|t| > 1,96$; legi naive, conservatoare cu parametri estimați (slide-ul următor)
- Media: $Q(10)$ pe $\hat{z}$ între 20 și 28 în toate modelele: o mică autocorelație pe care media constantă o ignoră
- Dispersia: $Q(10)$ pe $\hat{z}^2$ scade de la 6133 (pe r_t^2) la 10–16, iar LM(5) nu este semnificativ: aceste teste naive nu detectează volatility clustering rămas
- Asimetria: GARCH simetric este respins de testul comun (40,7), GJR la fel (28,1), EGARCH se apropie cel mai mult (9,9, $p = 0,020$); cu $n = 6\,714$, judecați mărimea economică, nu doar valorile p

Diagnosticul reziduurilor depinde de parametrii estimați

- ▣ $\hat{z}_t$ depinde de $\hat{\theta}$: statistica Ljung–Box pe $\hat{z}_t^2$ nu este exact χ_m^2 Li & Mak (1994); dispersia estimată a preluat deja o parte din dependența de la decalajele mici
- ▣ S&P 500, QMLE Gaussian pentru GARCH(1,1), $Q(10)$ pe $\hat{z}_t^2$
 - ▶ Ljung–Box naiv: 16,4, $p = 0,089$: nerespins la 5%
 - ▶ Corectat pentru parametrii estimați: 19,1, $p = 0,038$: respins la 5%, verdictul se inversează
- ▣ Testul naiv este conservator: respinge prea rar o ecuație a dispersiei greșit specificată; testul comun de asimetrie are aceeași limită
- ▣ Matricea de corecție și elementele ei: [▶ Anexă](#)

Diagnostic: pătratele randamentelor și pătratele reziduurilor



- S&P 500, decalajele 1–30: autocorelațiile lui r_t^2 (înainte de model) și ale lui $\hat{z}_t^2$ din GJR-GARCH-t
- După model ele sînt în banda i.i.d.: la aceste decalaje nu se mai detectează dinamică a dispersiei
- Banda este cea naivă: cu parametri estimați este prea largă la decalaje mici (slide-ul anterior)

Diagnostic pe alte piețe: un tabel de decizie

Piața	Tiparul reziduurilor	Problema posibilă	Verificarea următoare
BET	$Q(10)$ pe $\hat{z} = 116,6$	autocorelație în medie (tranzacționare redusă, Capitolul 2)	ecuația mediei AR(1)
Bitcoin	$Q(10)$ pe $\hat{z}^2 = 4,7$, testul comun de asimetrie 1,3: nerespins	$\hat{\nu} = 3,18 < 4$: $\text{Var}(z_t^2) = \infty$, deci calibrarea χ^2 nu este justificată	teste pe $ \hat{z}_t $
EUR/RON	exces de aplatizare 3190	un singur reziduu de 154 (mai 2025) domină	inspectarea celor mai mari reziduuri; un model cu scor mărginit
Aur	EGARCH: $Q(10)$ pe $\hat{z}^2 = 48,8$	volatility clustering rămas, deși BIC este bun	alegere prin diagnostic, nu doar prin BIC

☐ Priviți mereu cele mai mari reziduuri: o singură observație poate domina toate diagnosticele


Problema aproximării și pierderile robuste

- Volatilitatea nu este observată niciodată: comparăm prognozele cu o **aproximare** zgomotoasă, de ex. r_t^2
- $r_t^2 = \sigma_t^2 z_t^2$ este nedeplasat ($\mathbb{E}[r_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2$ pentru $\mu = 0$), dar foarte zgomotos
 - ▶ R^2 -ul său față de dispersia reală este mic chiar pentru o prognoză perfectă [Andersen & Bollerslev \(1998\)](#)
 - ▶ S&P 500: ignorăm media, deoarece $\hat{\mu}^2 = 0,0062$ față de o dispersie zilnică medie de 1,47 (%²), o deplasare sub 1%
- [Patton \(2011\)](#): doar unele funcții de pierdere ordonează corect prognozele cu o aproximare zgomotoasă
 - ▶ Robuste: MSE $(r_t^2 - h_t)^2$ și **QLIKE** $r_t^2/h_t + \ln h_t$, cu h_t prognoza dispersiei
 - ▶ Nerobuste: pierderile pe volatilitate $|r_t| - \sqrt{h_t}$ sau pe logaritmi
- QLIKE este (pînă la constante) minus log-verosimilitatea Normală; penalizează mai mult subestimarea

Mincer–Zarnowitz și Diebold–Mariano


- **Regresia Mincer–Zarnowitz** Mincer & Zarnowitz (1969): $r_t^2 = a + b h_t + u_t$
 - ▶ Prognoză nedeplasată: $a = 0$, $b = 1$ (test Wald comun cu erori HAC); R^2 măsoară conținutul informațional
 - ▶ $b < 1$: prognoze prea dispersate (prea mari când sînt mari, prea mici când sînt mici)
- **Testul Diebold–Mariano** Diebold & Mariano (1995): diferența de pierderi $d_t = L(r_t^2, h_t^A) - L(r_t^2, h_t^B)$
 - ▶ $DM = \bar{d} / \widehat{e.s.}(\bar{d})$ cu eroare standard HAC; $\approx N(0, 1)$ sub acuratețe egală; $DM < -1,96$: A semnificativ mai bun
 - ▶ Legea $N(0, 1)$ presupune prognoze date; pentru modele estimate și imbricate (GARCH-t în GJR-t) poate să nu fie valabilă, deci acolo citim t DM descriptiv (slide-ul GW de mai jos)

Schema în afara eșantionului și traiectoriile prognozelor, 2016–2026



- S&P 500: 2 692 de prognoze pe o zi; reestimare în fiecare ianuarie pe toate datele din 2000 (fereastră în expansiune), actualizare zilnică cu parametri ficși
- Alinierea în timp: h_t folosește datele pînă la închiderea zilei $t - 1$ și se compară cu r_t^2 ; modificarea lui r_t nu trebuie să schimbe h_t
- Modele: GARCH-N, GARCH-t, GJR-t, EGARCH-t; repere: EWMA și Hist-20 (dispersia istorică pe 20 de zile); în grafic: GJR-t, EWMA, $|r_t|\sqrt{q}$ ($q = 251,4$)

S&P 500: există un model mai bun decât GARCH(1,1)?



- QLIKE mediu minus cel al GARCH-t, cu t DM (HAC, 5 decalaje); cel mai mic QLIKE: GJR-t (0,732)
- Familia GARCH: t DM între -1,47 și -0,36, descriptiv pentru aceste perechi imbricate
- EWMA și Hist-20 sînt clar mai slabe ($t = 3,48, 4,10$): revenirea la medie și parametrii estimați aduc un câștig [Hansen & Lunde \(2005\)](#)
- MZ: nedeplasarea nu este respinsă pentru prognozele de tip GARCH, este respinsă pentru Hist-20 (toate statisticile: [Anexă](#))

 [MFM_ch5_forecast_evaluation](#)


Compararea metodelor de prognoză: Giacomini–White și Model Confidence Set

- Cu parametri estimați, modele imbricate și fereastră în expansiune, diferența DM degenerază sub H_0 : DM nu este $N(0, 1)$ West (1996), Clark & McCracken (2001)
- Giacomini & White (2006): testăm metoda de prognoză (model + fereastră mobilă de $W = 1000$ de zile), validă pentru modele imbricate, deoarece zgomotul estimării nu dispare
- Șase modele, cinci teste pe perechi: o problemă de comparații multiple; **Model Confidence Set** Hansen, Lunde & Nason (2011) elimină cel mai slab model pînă cînd acuratețea egală nu mai este respinsă; mulțimea conține cel mai bun model cu probabilitatea $\geq 1 - \alpha$
- Rezultat: GW respinge doar EWMA și Hist-20; MCS 90% păstrează cele patru modele GARCH: verdictul DM, acum calibrat (formule și tabelul complet: [▶ Anexă](#))

Model	GW p	MCS p
GARCH-N	0,054	0,586
GARCH-t	–	0,353
GJR-t	0,288	1,000
EGARCH-t	0,201	0,586
EWMA	0,003	0,008
Hist-20	< 0,001	0,001

- GW: fereastră mobilă, 2 692 de prognoze, față de GARCH-t; MCS: fereastră în expansiune, QLIKE, bootstrap staționar

Proгноze pe o lună: Mincer–Zarnowitz în logaritmi




- Prognoza GJR-t a dispersiei pe 22 de zile față de suma realizată a 22 de pătrate ale randamentelor, 122 de ferestre nesuprapuse; R^2 în logaritmi 0,38
- Panta în logaritmi $b = 0,75$ (e.s. 0,07): doar descriptivă, deoarece $\mathbb{E}[\ln Y \mid \mathcal{F}] \neq \ln \mathbb{E}[Y \mid \mathcal{F}]$; $b < 1$ nu dovedește prognoze prea dispersate
- În niveluri b este doar 0,27: două ferestre COVID-19 domină; comparăm prognozele cu QLIKE [Patton \(2011\)](#)

GARCH-in-mean: este riscul recompensat?

- ▣ **GARCH-M** Engle, Lilien & Robins (1987): $r_t = c + \kappa \sigma_t + \varepsilon_t$ (sau $\kappa \sigma_t^2$)
 - ▶ $\kappa > 0$: investitorii cer un randament așteptat mai mare când riscul este mai mare (compromisul risc–randament)
- ▣ S&P 500, GARCH(1,1)-t în medie: $\hat{\kappa} = 0,096$ (t = 3,02) cu σ_t ; 0,028 (t = 2,35) cu σ_t^2
 - ▶ Pozitiv și semnificativ în acest eșantion, dar literatura este împărțită: GJR (1993) au găsit o relație negativă
- ▣ Atenție: un efect zilnic în medie este mic și fragil; depinde de eșantion și de asimetria dispersiei

 MFM_ch5_long_memory

Memoria lungă: unde GARCH nu ajunge



- S&P 500, ACF a lui $|r_t|$ (scară log): datele 0,289, 0,082, 0,009 la decalajele 1, 100, 250; GARCH(1,1)-t prea mare la decalajul 1 (0,416), apoi o scădere exponențială
- **FIGARCH** Baillie, Bollerslev & Mikkelsen (1996), $(1 - L)^d$: scădere hiperbolică; $\hat{d} = 0,60$ (e.s. 0,06), BIC mai mic cu 34,2, dar memoria este acum prea lungă (0,144 la decalajul 250)
- Niciun model cu o singură scară nu se potrivește tuturor orizonturilor: volatilitatea realizată și HAR în [Capitolul 9](#)

 MFM_ch5_long_memory

Limitele GARCH și extensiile pe care le motivează

Limita	Dovada din acest capitol	Extensia
Schimbările de nivel exagerează $\alpha + \beta$ Lamoureux & Lastrapes (1990)	BET-TR (2014–2026) 0,9188 vs BET (2000–2026) 0,9907	GARCH-MIDAS, o componentă lentă de termen lung Engle, Ghysels & Sohn (2013) ; schimbare de regim Hamilton & Susmel (1994)
Reacție întârziată cu o zi	COVID-19: VIX s-a mișcat în aceeași zi, GARCH a doua zi	Realized GARCH, cu o ecuație de măsurare pentru dispersia realizată Hansen, Huang & Shek (2012) (Capitolul 9)
O valoare extremă domină actualizarea	reziduul EUR/RON de 154 (mai 2025)	Modele bazate pe scor (GAS), cu scor mărginit Creal, Koopman & Lucas (2013) ; studiul de caz de mai jos
Memorie scurtă	ACF a lui $ r_t $ la decalajele 100–250	FIGARCH; HAR pe dispersia realizată (Capitolul 9)
Un singur activ Prețuri administrate	portofoliile au nevoie de covarianțe EUR/RON: calm lung, apoi salturi	GARCH multivariat și DCC (Capitolul 6) Intervențiile modelate ca salturi sau regimuri

- Fiecare extensie se judecă la fel ca GARCH: în afara eșantionului, pierdere robustă, Model Confidence Set (ecuațiile modelelor: [▶ Anexă](#))

Studiu de caz: întrebarea și modelul


- **Întrebarea** Blasques, Francq & Laurent (2023): trebuie ca un model de volatilitate bazat pe scor să actualizeze σ_t^2 cu scorul aceleiași densități care descrie randamentele?
- Actualizarea bazată pe scor (GAS) Creal, Koopman & Lucas (2013): $f_{t+1} = \omega + \alpha S(f_t) \partial \log p(y_t | f_t) / \partial f_t + \beta f_t$; cu o densitate Student-t, un singur ν determină atât cozile lui z_t , cât și cât de puternic este atenuat un șoc mare
- **QSD GARCH(1,1)-t**, ec. (30) din lucrare: $y_t = \sqrt{f_t} \epsilon_t$, ϵ_t Student-t standardizat cu $1/\xi$ grade de libertate (f_t este σ_t^2 , ϵ_t este z_t)
 - ▶ $f_{t+1} = \omega + \varpi X_t + \alpha \frac{1 + \zeta}{1 - 2\zeta + \zeta \epsilon_t^2} \epsilon_t^2 f_t + \beta f_t$
 - ▶ Doi parametri: ξ , grosimea cozilor lui ϵ_t , și ζ , atenuarea valorilor mari ale lui ϵ_t^2 în actualizare; $\zeta = 0$: GARCH(1,1)-t; $\zeta = \xi$: Beta-t-GARCH (bazat pe scor)
- Date: 400 de acțiuni din S&P 500, 3 ianuarie 1995 (sau mai târziu) – 28 februarie 2019; X_t : pătratul VIX la orizont zilnic; verosimilitate maximă cu medie AR(1); teste LR pentru $\zeta = 0$ și $\xi = \zeta$, față de χ_1^2 (metoda completă: [▶ Anexă](#))

Studiu de caz: rezultatele principale (lucrarea, Tabelele 4–6)

Respinse la 5%, % din cele 400 de acțiuni	Student-t (Tabelul 4)	t asimetric (Tabelul 6)
LR, $H_0: \zeta = 0$ (actualizare GARCH)	89,5	98,8
LR, $H_0: \xi = \zeta$ (bazat pe scor; asimetric: și $\kappa = \tau$)	53,5	100,0
Testul PIT: GARCH(1,1)	40,0	33,1
Testul PIT: Beta-t-GARCH	46,0	72,2
Testul PIT: QSD GARCH(1,1)	45,7	11,3


- Atenuarea șocurilor mari contează: $\zeta = 0$ este respinsă pentru 89,5% din acțiuni și toate valorile $\hat{\zeta}$ sînt pozitive (Tabelul 4)
- Dar Beta-t-GARCH atenuează prea mult: acolo unde $\hat{\xi} - \hat{\zeta}$ este semnificativă, $\hat{\xi} > \hat{\zeta}$ pentru toate acțiunile, cu o excepție; mediana lui $1/\hat{\zeta}$ este 9,48, față de 5,07 la Beta-t-GARCH ($\zeta = \xi$) (lucrarea, Fig. 2–3): grosimea cozilor și atenuarea șocurilor sînt parametri diferiți
- t asimetric: $\hat{\tau}$ mult sub 0,5 (mediana 0,333), iar $\hat{\kappa}$ rămîne aproape de 0,5 (Fig. 5–6): efectul de levier intră prin actualizare, nu prin densitate; testul PIT respinge apoi modelul QSD pentru doar 11,3% din acțiuni

Studiu de caz: replicare pe 11 acțiuni (cf. lucrarea, Fig. 2)



- Eșantionul cursului: 11 acțiuni mari, încă listate (lucrarea: 400), 1995 (sau mai târziu) – februarie 2019, 4986–6081 randamente fiecare; $X_t = \text{VIX}_t^2 / 252$
- $\zeta = 0$ respinsă pentru 9 din 11 (lucrarea: 89,5%); $\xi = \zeta$ respinsă pentru 8 (lucrarea: 53,5%); $\hat{\xi} > \hat{\zeta}$ pentru 10 din 11
- Mediana lui $1/\hat{\zeta}$: 21,4 (QSD) față de 6,32 (Beta-t-GARCH); lucrarea: 9,48 față de 5,07; 11 companii selectate, încă listate: rezultate imprecise și nerepresentative

Studiu de caz: impactul știrilor (cf. lucrarea, Fig. 3)



- GARCH(1,1)-t ($\zeta = 0$)
- Beta-t-GARCH, $\zeta = \hat{\zeta}$, median over stocks (0.158)
- Beta-t-GARCH, $\zeta = \hat{\zeta}$, 5% and 95% quantiles (0.139, 0.231)
- QSD GARCH(1,1)-t, $\hat{\zeta}$, median over stocks (0.047)
- QSD GARCH(1,1)-t, $\hat{\zeta}$, 5% and 95% quantiles (0.018, 0.188)

- Contribuția lui ϵ_t la f_{t+1} (în unități de αf_t) la cuantile ale celor 11 estimări: funcții de actualizare la același αf_t , nu traiectorii estimate
- Un șoc de 5 abateri standard adaugă 25 (GARCH-t), 12,6 (QSD median), 6,2 (Beta-t-GARCH median); la 10 abateri standard: 100, 18,8, 7,0 (limita $(1 + \zeta)/\zeta = 7,3$)
- QSD se află între cele două: șocurile mari sînt atenuate, dar mult mai puțin decît impune Beta-t-GARCH

Întrebări deschise și bucla descoperirii

□ Întrebări

- ▶ depășesc prognozele bazate pe învățare automată sau pe măsuri realizate un GARCH bine specificat pentru dispersia zilnică a acțiunilor, în afara eșantionului?
- ▶ rămîne răspunsul valabil după ce ținem cont de numărul de modele comparate?

- Christensen, Siggaard & Veliyev (2023): metodele de învățare automată, cu puțină calibrare, sînt competitive cu modelele de tip HAR; Hansen, Lunde & Nason (2011): Model Confidence Set este obiectul potrivit cînd concurează multe modele

- Formal: $d_t = L(r_t^2, h_t^A) - L(r_t^2, h_t^B)$, $H_0: \mathbb{E}d_t = 0$; infirmată dacă A iese din Model Confidence Set sau dacă semnul lui $\bar{d}$ se schimbă între subperioadele pre-înregistrate

- Bucla: un asistent AI propune harta literaturii, ipoteze concurente, codul, un plan de robustețe și o critică în stilul unui referent; cercetătorul verifică fiecare DOI, reproduce fiecare cifră și fixează planul înainte de prima rulare

- Verificări specifice prognozelor de volatilitate

- ▶ Look-ahead bias (h_t nu trebuie să se schimbe cînd se modifică r_t); pierdere robustă la aproximare (QLIKE, MSE); căutarea modelelor (Model Confidence Set sau Bonferroni); scara și convergența optimizatorului; DOI sau argumente arch inventate
- ▶ Prompturi reutilizabile și lista completă de verificare: [▶ Anexă](#)

Mini-studiu de caz și un punct de plecare pentru proiect

- O afirmație tipică a unui asistent: „GJR-t bate GARCH-t datorită efectului de levier”; $d_t = \text{QLIKE}(\text{GJR-t}) - \text{QLIKE}(\text{GARCH-t})$, 2 692 de zile, 2016–2026: $\bar{d} = -0,025$, DM $t = -1,22$
- Implicația testabilă a levierului: câștigul apare după zilele de scădere
 - ▶ După $r_{t-1} < 0$ (1 223 de zile): $\bar{d} = -0,015$, $t = -0,51$; după $r_{t-1} \geq 0$ (1 469): $\bar{d} = -0,034$, $t = -1,12$: nesuținută; 2016–2020 $t = -0,02$, 2021–2026 $t = -4,06$
 - ▶ Doar descriptiv (modele imbricate, fereastră în expansiune): continuarea calibrată este un test GW cu fereastră fixă pentru diferența dintre semne, cu regresia lui d_t pe $1(r_{t-1} < 0)$
- **Punct de plecare pentru proiect:** intră prognozele bazate pe învățare automată în Model Confidence Set alături de GARCH, GJR și EGARCH pentru S&P 500 și BET, 2016–2026?
 - ▶ Replicați întâi tabelul QLIKE; preînregistrați modelele, pierderile, împărțirile și rata de eroare; notați utilizarea AI în AI_USE.md și fiecare eroare prinsă în AI_ERRORS.md (descrierea completă: [▶ Anexă](#))

Sinteză: un flux de decizie

- ▣ 1. **Detectăm:** $Q(10)$ pe r_t^2 și testul LM; volatility clustering este universal, persistența $\alpha + \beta$ este aproape de 1 pe toate piețele noastre
- ▣ 2. **Estimăm:** GARCH, GJR, EGARCH cu inovații Normale, Student-t, t asimetrice; randamente în %; verificăm convergența și parametrii la limită
- ▣ 3. **Diagnosticăm:** nivelul, pătratele și semnele lui $\hat{z}_t$ și cele mai mari valori; testele naive sînt conservatoare
- ▣ 4. **Prognostăm:** recursia dă dispersiile pe mai mulți pași; regula rădăcinii pătrate a timpului ignoră revenirea la medie
- ▣ 5. **Comparăm:** în afara eșantionului, QLIKE, GW cu fereastră mobilă și Model Confidence Set: GARCH bate EWMA și Hist-20, modelele din familia GARCH sînt greu de departajat
- ▣ 6. **Raportăm incertitudinea:** e.s. robuste (valide dacă $\mathbb{E}z_t^4 < \infty$), teste care țin cont de frontieră, timpi de înjumătățire ca intervale $[h_{10}; \infty)$ cînd $\alpha + \beta \approx 1$

Autoevaluare și ce urmează: Capitolul 6

Întrebări de verificare

- De ce supraestimează regula rădăcinii pătrate a timpului riscul pe 10 zile după o zi agitată?
- De ce se compară testul LR al inovațiilor Normale față de Student-t cu 2,71 și nu cu 3,84?
- De ce poate un interval simetric pentru timpul de înjumătățire să conțină valori negative?
- De ce diferența dintre VIX și volatilitatea GARCH nu măsoară variance risk premium?

Capitolele următoare

- **Capitolul 6:** volatilitate multivariată și corelații dinamice (DCC)
- **Capitolele 7–8:** Value at Risk și expected shortfall cu volatilitate GARCH și backtesting-ul lor
- **Capitolul 9:** volatilitatea realizată și memoria lungă
- **Seminarul 5:** recursia dispersiei pas cu pas, GARCH-t și GJR pe date reale, un răspuns AI de verificat, teste bootstrap și comparații de prognoze

Anexă: Datele folosite în acest capitol

Serie	Proprietar / sursă	Început	Obs.	Obs. pe an
S&P 500	S&P Dow Jones Indices	2000	6 714	251,4
BET	Bursa de Valori București	2000	6 670	249,8
BET-TR	Bursa de Valori București	2014	2 992	249,7
Bitcoin (BTC/USD)	burse crypto (compozit)	2014	4 384	365,3
EUR/RON, curs de referință	BNR	2005	5 352	252,4
Aur (XAU/USD)	piața spot	2000	6 922	259,2

- Prețuri zilnice de închidere până la 18 septembrie 2026; randamente $r_t = 100 (\ln P_t - \ln P_{t-1})$, în %
- Indici bursieri și aur: doar zilele lucrătoare; volatilitatea aurului este anualizată cu frecvența reală a observațiilor
- Bitcoin se tranzacționează 7 zile din 7; indicele VIX al Chicago Board Options Exchange este folosit ca reper

 MFM_ch5_arch_effects

Anexă: Efecte ARCH, toate statisticile

Serie	Vol. (% anual)	Exces aplatizare	$\hat{\rho}_1(r^2)$	$Q(10)$ pe r^2	LM(5)
S&P 500	19,2	10,7	0,313	6133	1684
BET	22,1	11,1	0,330	2440	982
BET-TR	15,4	17,8	0,171	714	371
Bitcoin	66,6	12,0	0,137	213	115
EUR/RON	4,4	15,1	0,342	2420	871
Aur	17,6	7,7	0,110	744	329

▣ Valori critice la 5%: χ_{10}^2 : 18,3; χ_5^2 : 11,1; toate valorile $p < 0,001$

 MFM_ch5_arch_effects

Anexă: Teste ale scorului unilaterale și problema Davies

- Alternativa este unilaterală ($\alpha_i \geq 0$): testul χ^2 bilateral pierde putere
 - ▶ [Lee & King \(1993\)](#): test al scorului unilateral, construit pe suma componentelor scorului, $N(0, 1)$ sub H_0 , respinge doar în coada superioară
- Față de GARCH(1,1), ipoteza nulă $\alpha = 0$ lasă β neidentificat (problema Davies)
 - ▶ Statistica LM ARCH(q) este și testul scorului față de GARCH(p, q) [Lee & King \(1993\)](#): aceeași statistică servește ambele alternative

Anexă: Robert Engle și Premiul Nobel din 2003



Robert F. Engle (2022)

Foto: Jon Demske (2022); CC

BY-SA 4.0; Wikimedia Commons



Clive W.J. Granger (2008)

Foto: Olaf Storbeck (2008); CC

BY-SA 2.0; Wikimedia Commons

- **Premiul Nobel 2003:** Engle „pentru metode de analiză a seriilor de timp economice cu volatilitate variabilă în timp (ARCH)”
 - ▶ Împărțit cu Clive Granger (cointegrare)
- **Prelegerea Nobel:** [Engle \(2004\)](#), despre risc și volatilitate în practica financiară
- Tim Bollerslev, doctorandul lui Engle, a generalizat ARCH la GARCH în 1986

Anexă: Aplatizarea: rotunjirea și o traiectorie simulată lungă

- S&P 500, GARCH-N: condiția de moment este 0,990435, deci $K = 12,1$ are numitorul $1 - 0,990435$
 - ▶ Rotunjirea la $\hat{\alpha} = 0,121$, $\hat{\beta} = 0,860$ dă 0,9916 și $K = 13,5$: raportați astfel de funcții din estimări nerotunjite
- GARCH(1,1) simulat de pe slide-ul de simulare, un milion de zile
 - ▶ Exces de aplatizare 2,47 (teoretic 3,06); autocorelația de ordin 1 a lui ε_t^2 : 0,26
 - ▶ Aplatizarea de selecție converge încet: precizia ei depinde de momentul de ordin opt, infinit pentru acești parametri

Anexă: QMLE: variante ale teoremei

- Media estimată: scorul capătă termenul $\varepsilon_t / \sigma_t^2$, iar covarianța $(\kappa_z - 1)J^{-1}$ își schimbă forma
- IGARCH ($\alpha + \beta = 1$): staționaritatea strictă rămîne valabilă, iar QMLE rămîne consistent și asimptotic Normal [Lumsdaine \(1996\)](#)
- Cazul exploziv, $\mathbb{E} \ln(\alpha z_t^2 + \beta) \geq 0$: [Jensen & Rahbek \(2004\)](#) tratează (α, β) cu ω fixat, deoarece ω nu este identificat
- Cozi groase, $\kappa_z = \infty$: convergență mai lentă decît $\sqrt{n}$, limite non-Gaussiene [Hall & Yao \(2003\)](#); cvasi-verosimilități cu cozi groase, cu ajustarea scalei [Fan, Qi & Xiu \(2014\)](#)

Anexă: Corecția Li-Mak pentru autocorelațiile pătratelor reziduurilor

- Autocorelațiile pătratelor reziduurilor $\hat{r}_k$: $\sqrt{n} \hat{r} \rightarrow N(0, C)$, $C = I - H' J^{-1} H / (\kappa_z - 1)$ Li & Mak (1994)
 - ▶ $H_k = \mathbb{E}[g_t(z_{t-k}^2 - 1)]$: cît din dependența de ordin k absoarbe dispersia estimată; regula ARMA χ_{m-p-q}^2 nu se aplică
- S&P 500, QMLE Gaussian pentru GARCH(1,1): $C_{1,1} = 0,78$, $C_{5,5} = 0,93$, $C_{10,10} = 0,97$
 - ▶ Corecția este cea mai mare la decalaje mici, unde $\hat{\alpha}$ a preluat deja dependența; statistica corectată $n \hat{r}' C^{-1} \hat{r} = 19,1$

 MFM_ch5_inference

Anexă: S&P 500: evaluarea prognozelor, toate statisticile

Model	QLIKE	MSE	DM t vs GARCH-t	MZ b	MZ R^2	Wald p
GARCH-N	0,751	22,3	-1,47	0,97	0,250	1,00
GARCH-t	0,757	22,8	—	0,88	0,238	0,80
GJR-t	0,732	21,8	-1,22	0,84	0,276	0,68
EGARCH-t	0,745	21,3	-0,36	1,24	0,293	0,71
EWMA	0,815	24,7	3,48	0,89	0,172	0,69
Hist-20	0,889	26,1	4,10	0,68	0,152	0,03

- Pierderi medii pe 2 692 de zile; DM pe QLIKE, HAC cu 5 decalaje; t negativ: mai bun decât GARCH-t
- MZ: $r_t^2 = a + b h_t$; Wald p: testul $a = 0$, $b = 1$

 MFM_ch5_forecast_evaluation

Anexă: Giacomini–White și MCS: formule și tabelul complet

Model	QLIKE (W)	t necond.	GW	p	MCS p
GARCH-N	0,751	1,87	5,85	0,054	0,586
GARCH-t	0,743	–	–	–	0,353
GJR-t	0,738	-0,18	2,49	0,288	1,000
EGARCH-t	0,746	0,07	3,21	0,201	0,586
EWMA	0,815	3,20	11,40	0,003	0,008
Hist-20	0,889	3,87	16,41	< 0,001	0,001

- Testul condițional $\mathbb{E}[d_{t+1} \mid \mathcal{F}_t] = 0$ cu instrumentele $x_t = (1, d_t)$: $GW = n \bar{Z}' \hat{\Omega}^{-1} \bar{Z} \rightarrow \chi_2^2$, $Z_{t+1} = x_t d_{t+1}$ (valoarea critică 5,99)
- Fereastră mobilă $W = 1\,000$ de zile, reestimată în fiecare ianuarie, 2 692 de prognoze; teste față de GARCH-t, HAC cu 5 decalaje
- MCS pe prognozele cu fereastră în expansiune: QLIKE, statistica T_R , bootstrap staționar (bloc mediu 10, 10 000 de extrageri); MCS 90%: GARCH-N, GARCH-t, GJR-t, EGARCH-t

Anexă: Modele bazate pe scor, Realized GARCH și modele cu componente

- **Bazate pe scor (GAS)** Creal, Koopman & Lucas (2013): $\sigma_{t+1}^2 = \omega + A s_t + B \sigma_t^2$, s_t scorul scalat al densității Student-t
 - ▶ Scorul este mărginit în z_t : o valoare extremă ca reziduul EUR/RON de 154 mișcă dispersia mult mai puțin decât în GARCH
- **Realized GARCH** Hansen, Huang & Shek (2012): adaugă o ecuație de măsurare care leagă σ_t^2 de o dispersie realizată
 - ▶ Folosește informația intrazilnică și reacționează mai repede; puntea spre [Capitolul 9](#)
- **GARCH-MIDAS** Engle, Ghysels & Sohn (2013): $\sigma_t^2 = \tau_t g_t$, o componentă lentă de termen lung τ_t determinată de date macro (frecvențe mixte)
 - ▶ Un nivel de termen lung mobil absoarbe schimbările de nivel care împing $\hat{\alpha} + \hat{\beta}$ spre 1

Anexă: Dincolo de dispersie: entropie și tail risk

- [Pele, Lazar & Dufour \(2017\)](#): entropia distribuției randamentelor intrazilnice și riscul de piață (EUR/JPY)
 - ▶ O entropie mai mare se asociază cu Value at Risk și expected shortfall intrazilnice mai mici; entropia prognozează apoi Value at Risk zilnic
- [Pele & Mazurencu-Marinescu-Pele \(2019\)](#): entropia randamentelor intrazilnice Bitcoin propusă ca semnal suplimentar pentru Value at Risk zilnic
- [Pele, Lazar & Mazurencu-Marinescu-Pele \(2019\)](#): o măsură neparametrică a cozii bazată pe entropie, comparată cu modelele standard de expected shortfall
- Volatilitatea GARCH intră direct în Value at Risk și expected shortfall: [Capitolele 7–8](#)

Anexă: Studiu de caz, metoda completă

- **De ce contează:** GARCH este determinat de ε_t^2 oricare ar fi densitatea, deci un șoc extrem izolat poate produce o reacție excesivă a volatilității, care durează zile sau săptămâni (Secțiunea 1 din lucrare)
 - ▶ Cu o densitate asimetrică la stînga, un model pur bazat pe scor crește volatilitatea mai mult după randamente pozitive: opusul efectului de levier (Exemplul 2)
 - ▶ Modelele QSD, ec. (3): $f_{t+1} = \omega + \alpha \psi(y_t, X_t, f_t, \theta) + \beta f_t$, ψ scorul scalat al unei funcții de actualizare ρ care nu coincide neapărat cu $\log p$; teoria: consistență, normalitate asimptotică, testele LR și LM cu limite χ^2 (Secțiunea 3)
- **Estimarea:** $\zeta = 0$ rămîne în interiorul spațiului parametrilor prin ec. (31)–(32): $\zeta \in (-1, 1/2)$ și $\Psi(x) = x(1 - e^{-cx})/(1 + e^{-cx})$ aplicată ponderii, $c = 1000$
 - ▶ Testul PIT Diebold, Gunther & Tay (1998): $u_t = F(\varepsilon_t)$ i.i.d. $U(0, 1)$ dacă modelul este corect; cu estimatorul de verosimilitate maximă și Pierce (1982), se respinge dacă $|\sum_t \hat{u}_t - T/2|/\sqrt{T(1/12 - B\mathcal{I}(\hat{\theta})^{-1}B^\top)} > 1,96$, $B = \lim_{T \rightarrow \infty} \mathbb{E}[\partial \sum_t (u_t - T/2)/\partial \theta^\top]$, $\mathcal{I}$ informația Fisher; detectează o medie PIT deplasată, nu orice abatere de la uniformitate
- **Date:** se elimină acțiunile cu mai puțin de 4000 de observații sau cu probleme de convergență: 400 de acțiuni (Secțiunea 5)
 - ▶ Varianta asimetrică, ec. (47): o distribuție Student-t asimetrică pentru ε_t , cu parametrul de asimetrie κ , și parametri separați (ζ, τ) pentru actualizare; $\tau < 0,5$ produce efect de levier oricare ar fi κ (Secțiunea 5.2)

Anexă: Studiu de caz, un exemplu și limitele indicate de autori

- Centene, 4330 de zile: $\hat{\xi} \approx 0,26$ (circa 4 grade de libertate) în toate cele trei modele, dar $\hat{\zeta} = 0,048$ (e.s. 0,027); LR 8,81 ($p = 0,003$) pentru $\xi = \zeta$ și 8,42 ($p = 0,004$) pentru $\zeta = 0$ (Tabelul 5); după o zi de crah din martie–aprilie 2008, volatilitatea GARCH-t rămîne mult peste cea Beta-t-GARCH, iar QSD se află între ele (Fig. 4)
- **Limitele indicate de autori**
 - ▶ Rezultatele mai bune decît cele ale GARCH-t și Beta-t-GARCH nu garantează adecvarea modelului QSD Student-t: testul PIT respinge cele trei modele pentru 40,0–46,0% din acțiuni (Tabelul 4)
 - ▶ În recursia nemodificată (30), $\zeta < 0$ sau $\zeta > 1/2$ nu definesc un model de volatilitate propriu-zis, iar $\zeta = 1/2$ cu $\varpi = 0$ este degenerat (Secțiunea 4.1)
 - ▶ Legea $N(T/2, T/12)$ pentru $\sum_t u_t$ este valabilă doar pentru parametri cunoscuți; cu parametri estimați testul PIT are nevoie de corecția de mai sus (Secțiunea 5.1)
- **Extinderi deschise** (Seminarul 5, C3)
 - ▶ Depășește actualizarea mărginită QSD modelul GJR-GARCH-t în QLIKE, în afara eșantionului, mai ales după martie 2020?
 - ▶ Reduce influența reziduuului EUR/RON de 154?

Anexă: Bucla descoperirii: prompturi reutilizabile (1/2)

- Instrumentele sînt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și instrumente de căutare a literaturii științifice (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „Listează comparațiile în afara eșantionului dintre prognozele dispersiei bazate pe GARCH, HAR și învățare automată publicate după 2015, cu DOI, activ, funcție de pierdere, test și orizont.”
 - ▶ Verificăm fiecare DOI în Crossref; verificăm că pierderea este robustă la o aproximare zgomotoasă [Patton \(2011\)](#)
- **Ipoteze:** „Pentru afirmația că asimetria îmbunătățește prognozele pe o zi, listează mecanismele concurente (levier, feedback de volatilitate, câteva zile de criză) și ce prezice fiecare pentru d_t după semnul lui r_{t-1} și pe subperioade.”
- **Date și cod:** „Scrie cod Python cu `arch` care reestimează GARCH-t și GJR-t în fiecare ianuarie pe o fereastră în expansiune, din fișierele de prețuri zilnice ale cursului, și salvează prognozele dispersiei pe o zi; niciun parametru nu folosește date de după originea prognozei.”
 - ▶ Replicăm întâi: QLIKE 0,757 (GARCH-t) și 0,732 (GJR-t), DM $t = -1,22$

Anexă: Bucla descoperirii: prompturi reutilizabile (2/2)

- **Robustețe:** „Scrie un plan pre-înregistrat: împărțiri după semnul lui r_{t-1} și pe subperioade, MSE pe lângă QLIKE, orizontul de 22 de zile, decalajul HAC și o corecție Bonferroni sau Model Confidence Set.”
 - Un placebo cu împărțiri aleatoare este calibrat doar dacă realocă blocuri de zile, păstrînd volatility clustering
- **Critica:** „Joacă rolul unui referent: ar putea aproximarea r_t^2 , un singur an de criză sau decalajul HAC să creeze rezultatul meu? Propune cîte un test pentru a verifica fiecare explicație.”
- **Raportul:** toate împărțirile și pierderile încercate, valorile p ajustate, codul, valorile de inițializare ale generatoarelor de numere aleatoare și versiunile pachetelor; o specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare
- **Perioade influente:** un an de criză poate domina $\bar{d}$; raportăm subperioadele și declarăm dinainte dacă vreun an poate fi exclus

Anexă: Punctul de plecare pentru proiect, complet

- Întrebarea: intră prognozele bazate pe învățare automată, pe date zilnice, în Model Confidence Set alături de GARCH, GJR și EGARCH pentru S&P 500 și BET, 2016–2026?
- Ramura cu dispersie realizată (HAR): setul de date al cursului cu dispersii realizate la 5 minute conține 40 de acțiuni americane mari, ianuarie 2015 – ianuarie 2026; pentru indicele S&P 500 și pentru BET nu există date intrazilnice, deci această ramură se aplică acțiune cu acțiune
- Replicăm întâi: tabelul QLIKE (GARCH- t 0,757, DM EWMA $t = 3,48$) și împărțirile din mini-studiul de caz
- Livrabile
 - ▶ O pre-înregistrare de o pagină: modele, pierderi, împărțiri, rata de eroare și ce ar infirma afirmația
 - ▶ Cod pe datele de piață ale cursului, Model Confidence Set la 10%, o autocritică în stilul unui referent; `AI_USE.md` și `AI_ERRORS.md`
- Codul mini-studiului de caz: [Quantlets/Ch_05/ai_discovery_case.py](#)

Anexă: Resurse suplimentare

▣ Cărți

- ▶ Franke, Härdle & Hafner (2019), capitolele despre modelele ARIMA și GARCH pentru serii financiare
- ▶ Francq & Zakoïan (2019): teoria matematică a modelelor GARCH

▣ Cursuri Quantinar

- ▶  Statistics of Financial Markets
- ▶  Applied Time Series Analysis with Python

▣ Cod

- ▶ Toate graficele și tabelele: [Quantlets/Ch_05](#); pachetul Python [Sheppard](#), [arch](#)

Bibliografie (1/6)

- ▣ Andersen, T.G., Bollerslev, T. (1998). Answering the skeptics: yes, standard volatility models do provide accurate forecasts. *International Economic Review*, 39(4), 885–905.
- ▣ Andrews, D.W.K. (2000). Inconsistency of the bootstrap when a parameter is on the boundary of the parameter space. *Econometrica*, 68(2), 399–405.
- ▣ Andrews, D.W.K. (2001). Testing when a parameter is on the boundary of the maintained hypothesis. *Econometrica*, 69(3), 683–734.
- ▣ Baillie, R.T., Bollerslev, T., Mikkelsen, H.O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30.
- ▣ Berkes, I., Horváth, L., Kokoszka, P. (2003). GARCH processes: structure and estimation. *Bernoulli*, 9(2), 201–227.
- ▣ Blasques, F., Francq, C., Laurent, S. (2023). Quasi score-driven models. *Journal of Econometrics*, 234(1), 251–275.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *Review of Economics and Statistics*, 69(3), 542–547.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.

Bibliografie (2/6)

- ▣ Christensen, K., Siggaard, M., Veliyev, B. (2023). A machine learning approach to volatility forecasting. *Journal of Financial Econometrics*, 21(5), 1680–1727.
- ▣ Clark, T.E., McCracken, M.W. (2001). Tests of equal forecast accuracy and encompassing for nested models. *Journal of Econometrics*, 105(1), 85–110.
- ▣ Creal, D., Koopman, S.J., Lucas, A. (2013). Generalized autoregressive score models with applications. *Journal of Applied Econometrics*, 28(5), 777–795.
- ▣ Diebold, F.X., Gunther, T.A., Tay, A.S. (1998). Evaluating density forecasts with applications to financial risk management. *International Economic Review*, 39(4), 863–883.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- ▣ Engle, R.F. (2004). Risk and volatility: econometric models and financial practice. *American Economic Review*, 94(3), 405–420.
- ▣ Engle, R.F., Ghysels, E., Sohn, B. (2013). Stock market volatility and macroeconomic fundamentals. *Review of Economics and Statistics*, 95(3), 776–797.
- ▣ Engle, R.F., Lilien, D.M., Robins, R.P. (1987). Estimating time varying risk premia in the term structure: the ARCH-M model. *Econometrica*, 55(2), 391–407.

Bibliografie (3/6)

- ▣ Engle, R.F., Ng, V.K. (1993). [Measuring and testing the impact of news on volatility](#). *Journal of Finance*, 48(5), 1749–1778.
- ▣ Fan, J., Qi, L., Xiu, D. (2014). [Quasi-maximum likelihood estimation of GARCH models with heavy-tailed likelihoods](#). *Journal of Business & Economic Statistics*, 32(2), 178–191.
- ▣ Francq, C., Zakoïan, J.-M. (2004). [Maximum likelihood estimation of pure GARCH and ARMA-GARCH processes](#). *Bernoulli*, 10(4), 605–637.
- ▣ Francq, C., Zakoïan, J.-M. (2019). [GARCH Models: Structure, Statistical Inference and Financial Applications](#), 2nd ed. Wiley.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Giacomini, R., White, H. (2006). [Tests of conditional predictive ability](#). *Econometrica*, 74(6), 1545–1578.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). [On the relation between the expected value and the volatility of the nominal excess return on stocks](#). *Journal of Finance*, 48(5), 1779–1801.
- ▣ Hall, P., Yao, Q. (2003). [Inference in ARCH and GARCH models with heavy-tailed errors](#). *Econometrica*, 71(1), 285–317.
- ▣ Hamilton, J.D., Susmel, R. (1994). [Autoregressive conditional heteroskedasticity and changes in regime](#). *Journal of Econometrics*, 64(1–2), 307–333.

Bibliografie (4/6)

- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- ▣ Hansen, P.R., Huang, Z., Shek, H.H. (2012). Realized GARCH: a joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6), 877–906.
- ▣ Hansen, P.R., Lunde, A. (2005). A forecast comparison of volatility models: does anything beat a GARCH(1,1)? *Journal of Applied Econometrics*, 20(7), 873–889.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ J.P. Morgan/Reuters (1996). RiskMetrics — Technical Document, 4th ed. New York.
- ▣ Jensen, S.T., Rahbek, A. (2004). Asymptotic inference for nonstationary GARCH. *Econometric Theory*, 20(6), 1203–1226.
- ▣ Lamoureux, C.G., Lastrapes, W.D. (1990). Persistence in variance, structural change, and the GARCH model. *Journal of Business & Economic Statistics*, 8(2), 225–234.
- ▣ Lee, J.H.H., King, M.L. (1993). A locally most mean powerful based score test for ARCH and GARCH regression disturbances. *Journal of Business & Economic Statistics*, 11(1), 17–27.
- ▣ Li, W.K., Mak, T.K. (1994). On the squared residual autocorrelations in non-linear time series with conditional heteroskedasticity. *Journal of Time Series Analysis*, 15(6), 627–636.

Bibliografie (5/6)

- ▣ Lumsdaine, R.L. (1996). Consistency and asymptotic normality of the quasi-maximum likelihood estimator in IGARCH(1,1) and covariance stationary GARCH(1,1) models. *Econometrica*, 64(3), 575–596.
- ▣ Mandelbrot, B. (1963). The variation of certain speculative prices. *Journal of Business*, 36(4), 394–419.
- ▣ McLeod, A.I., Li, W.K. (1983). Diagnostic checking ARMA time series models using squared-residual autocorrelations. *Journal of Time Series Analysis*, 4(4), 269–273.
- ▣ Mincer, J., Zarnowitz, V. (1969). The evaluation of economic forecasts. In J. Mincer (ed.), *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*, NBER.
- ▣ Nelson, D.B. (1990). Stationarity and persistence in the GARCH(1,1) model. *Econometric Theory*, 6(3), 318–334.
- ▣ Nelson, D.B. (1991). Conditional heteroskedasticity in asset returns: a new approach. *Econometrica*, 59(2), 347–370.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). Modeling expected shortfall using tail entropy. *Entropy*, 21(12), 1204.

Bibliografie (6/6)

- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). Using high-frequency entropy to forecast Bitcoin's daily Value at Risk. *Entropy*, 21(2), 102.
- ▣ Pierce, D.A. (1982). The asymptotic effect of substituting estimators for parameters in certain types of statistics. *The Annals of Statistics*, 10(2), 475–478.
- ▣ Self, S.G., Liang, K.-Y. (1987). Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, 82(398), 605–610.
- ▣ Sheppard, K. arch: ARCH models and other tools for financial econometrics in Python (software documentation).
- ▣ West, K.D. (1996). Asymptotic inference about predictive ability. *Econometrica*, 64(5), 1067–1084.