








Modelarea piețelor financiare

Capitolul 6: Volatilitate multivariată și dependență



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Cînd se mișcă piețele împreună și cît de sigure sînt estimările?

Ce vom explica

- Partea I: de ce contează dependența, incertitudinea covarianței, GARCH multivariat (generalised autoregressive conditional heteroskedasticity) și DCC (dynamic conditional correlation, corelație condiționată dinamică) și distorsiunea Forbes–Rigobon
- Partea a II-a: copule și dependență în cozi, piețe europene și românești, bănci, volatilitate comună și cercetare cu inteligența artificială (AI)
- Se bazează pe Capitolul 1 (cozi groase, volatility clustering), Capitolul 4 (Σ în alegerea portofoliului) și Capitolul 5 (GARCH univariat)
- Pregătește Capitolul 7 (Value at Risk, VaR, și Expected Shortfall, ES, de portofoliu), Capitolul 8 (backtesting) și Capitolul 18 (risc sistemic)

Ce trebuie să poți face

- să estimezi o covariață variabilă în timp (fereastră mobilă, EWMA: exponentially weighted moving average, DCC) și să calculezi o eroare standard validă pentru o corelație
- să separi contagion de distorsiunea de volatilitate a corelațiilor din criză
- să alegi, să estimezi și să testezi o copulă și să interpretezi dependența ei în cozi la un prag finit și la limită

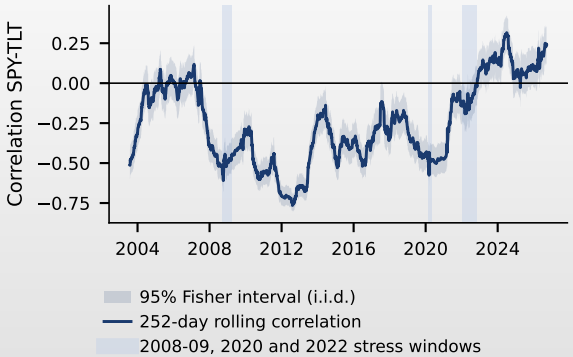
Rolul dependenței (1/2): diversificarea portofoliului

- **Diversificarea** (Markowitz (1952))
  - Varianța portofoliului depinde de corelație printr-un singur termen încrucișat
  - $\sigma_p^2 = w^\top \Sigma w = w^2\sigma_1^2 + (1-w)^2\sigma_2^2 + 2w(1-w)\rho\,\sigma_1\sigma_2$
  - w: ponderea activului 1 ($1-w$: ponderea activului 2)
  - Σ: matricea de covarianță
  - σ_1, σ_2: volatilitățile celor două active
  - ρ: corelația dintre ele
  - Portofoliu 60/40 din SPY (fondul tranzacționat la bursă pe S&P 500) și TLT (fondul de obligațiuni de stat americane cu scadențe de peste 20 de ani)
  - Aceleași volatilități ale activelor, $\sigma_1 = 18{,}8\%$ (SPY) și $\sigma_2 = 14{,}3\%$ (TLT): abaterile standard zilnice din iulie 2002 (începutul istoricului TLT) pînă în septembrie 2026, înmulțite cu $\sqrt{252}$, ponderi readuse la 60/40 în fiecare zi
  - Separăm la ianuarie 2022, începutul șocului de inflație; testul de ruptură din secțiunea DCC datează schimbarea mai devreme, în august 2020
  - Volatilitatea portofoliului este 10,4% cu corelația din 2002–2021 ($-0{,}40$) și 13,2% cu cea din 2022–2026 (0,11)
  - Verificare: $0{,}6^2 \cdot 0{,}188^2 + 0{,}4^2 \cdot 0{,}143^2 + 2 \cdot 0{,}6 \cdot 0{,}4 \cdot (-0{,}40) \cdot 0{,}188 \cdot 0{,}143 = 0{,}0108$, iar radicalul este 10,4%

Rolul dependenței (2/2): hedging, contagion și covariațe variabile

- **Hedging-ul riscului**
  - Ce valoare din instrumentul de hedging F vindem pentru fiecare unitate de valoare deținută în poziția S, pentru a minimiza varianța
  - Raportul de hedging de varianță minimă $h^* = \rho\,\sigma_S/\sigma_F$: panta regresiei lui r_S pe r_F
  - Estimat pe randamente, h^* este un raport de valori: numărul de unități din F pe unitatea din S este $h^* P_S/P_F$ (P_S, P_F: prețurile, inclusiv mărimea contractului)
  - r_S, r_F: randamentele poziției și ale instrumentului de hedging
  - σ_S, σ_F: volatilitățile lor
  - Eficiența hedging-ului, ρ^2: proporția din varianță eliminată
  - Dacă se schimbă corelația, hedge-ul de ieri devine inadecvat astăzi: un hedge dinamic cere un ρ_t dinamic
- **Contagion și interdependență** (Forbes & Rigobon (2002))
  - Contagion: o *creștere semnificativă* a legăturilor dintre piețe după un șoc
  - Interdependența: legături prezente în toate stările (comerț, investitori comuni, factori macroeconomici comuni)
  - Corelațiile tind să crească exact cînd diversificarea este cea mai necesară
- Nou în acest capitol: matricea de covarianță la data t, Σ_t, variază în timp
- Întrebările capitolului: cum o estimăm și cum măsurăm incertitudinea de selecție a fiecărei estimări a dependenței

Acțiuni și obligațiuni: o corelație care și-a schimbat semnul



- Corelația randamentelor zilnice SPY și TLT, pe o fereastră mobilă de 252 de zile
- Banda: intervalul Fisher de 95%, valid pentru date i.i.d. (independente și identic distribuite)
- Zonele umbrite: toamna 2008 – martie 2009, februarie–aprilie 2020, ianuarie–octombrie 2022
- Corelația minimă este $-0{,}77$ (8 august 2012), cea maximă 0,32 (1 iulie 2024), iar ultima valoare 0,24 (18 septembrie 2026)
- Corelația a fost pozitivă în 6% din zile înainte de 2022 și în 81% din zile începînd din ianuarie 2022
- Șocurile de creștere economică deplasează prețurile acțiunilor și ale obligațiunilor în direcții opuse (corelație negativă)
- Șocurile de inflație le afectează în aceeași direcție (corelație pozitivă, ca în 2022)
- Banda Fisher este prea îngustă aici: ignoră cozile groase și volatility clustering (secțiunea următoare)

MFM_ch6_spy_tlt_rolling

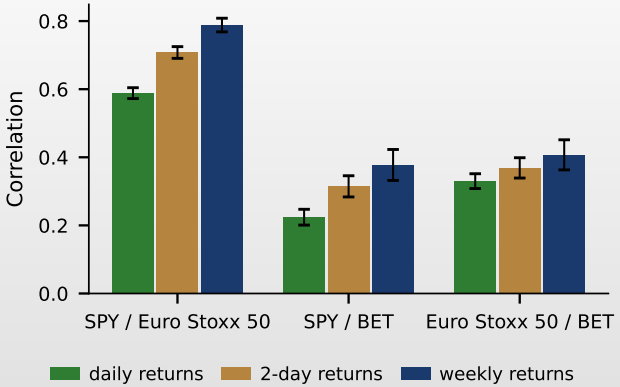
Cît de precisă este o corelație estimată?

- Întrebarea secțiunii: cum estimăm Σ și cît de incertă este fiecare corelație estimată?
- Prima capcană: orele de închidere diferă, deci frecvența datelor schimbă corelația
- A doua capcană: cozile groase și volatility clustering fac intervalul Fisher prea îngust
- A treia capcană: lungimea ferestrei decide cît de repede vedem o schimbare de regim

Tranzacționarea asincronă: o capcană pentru corelațiile zilnice

- Orele de închidere diferă: Bursa de Valori București și bursele din zona euro se închid cu cîteva ore înaintea bursei din New York
  - Știrile din SUA de după închiderea europeană intră în prețurile europene abia a doua zi
- Consecință (la dependență pozitivă, ca între piețele de acțiuni): corelația din aceeași zi este deplasată spre zero, iar corelația decalată este pozitivă
- Soluții
  - Frecvență mai mică: randamente pe 2 zile sau săptămînale, în zilele comune de tranzacționare
  - Adăugarea termenului decalat: $\rho_0 + \rho_{+1}$ (ρ_0: corelația din aceeași zi, ρ_{+1}: SUA ieri cu Europa azi)
  - O aproximare grosieră a corelației sincrone, valabilă doar pentru un lag de o zi, fără autocorelație și cu variațe egale
- Regula folosită peste tot: întîi aliniem *prețurile* pe zilele comune de tranzacționare, apoi calculăm randamentele

Corelații zilnice, pe 2 zile și săptămînale, 2000–2026 (1/2)



MFM_ch6_async

Corelații zilnice, pe 2 zile și săptămînale, 2000–2026 (2/2)

- SPY, Euro Stoxx 50 și BET (indicele de referință al Bursei de Valori București) în zilele comune de tranzacționare
- Liniile verticale de pe bare: intervale Fisher de 95%
- Corelația SPY–Euro Stoxx 50 este 0,59 pe randamente zilnice, 0,71 pe randamente pe 2 zile și 0,79 pe randamente săptămînale
- Corelația dintre SPY de ieri și Euro Stoxx 50 de azi este 0,20
- Corelația SPY–BET este 0,22 pe randamente zilnice, față de 0,38 pe randamente săptămînale
- Corelația decalată (SPY ieri, BET azi) este 0,17
- Euro Stoxx 50 și BET au închideri aproape sincrone: corelația lor este 0,33 zilnic și 0,41 săptămînal
- Valoarea redusă a corelației zilnice SUA–Europa este în parte un artefact de măsurare: orele de închidere diferă (slide-ul următor)
- Datele săptămînale sînt mai puțin afectate de asincronism, dar dau 1 367 în loc de 6 446 observații: intervale mai largi

MFM_ch6_async

Trei frecvențe, fiecare aleasă cu un motiv

- Randamentele sînt logaritmice, $r_t = \ln P_t - \ln P_{t-1}$, calculate după alinierea prețurilor pe zilele comune de tranzacționare
- Volatilitățile anualizate înmulțesc abaterea standard zilnică cu $\sqrt{252}$
- Zilnic: DCC, intervalele HAC (eroare standard robustă la heteroscedasticitate și autocorelație, definită mai jos) și hedging-ul, unde contează viteza de reacție
- Pe 2 zile: testele Forbes–Rigobon, pentru a absorbi diferențele dintre orele de închidere
- În testele Forbes–Rigobon randamentele pe 2 zile se suprapun: două randamente consecutive au o zi comună
- În graficul cu trei frecvențe randamentele pe 2 zile nu se suprapun (3 223 de observații)
- Săptămînal (închiderile de vineri): corelațiile de depășire, integrarea piețelor și rețelele de bănci, care combină fusuri orare diferite

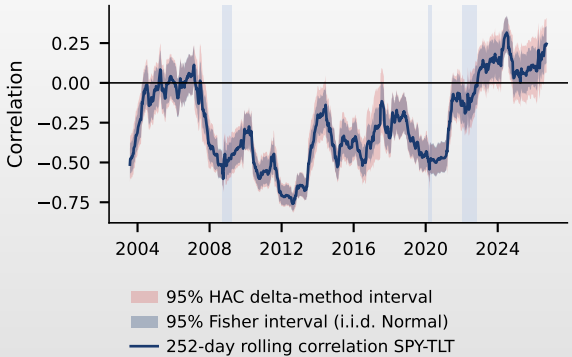
Covarianța de selecție și inferența pentru o corelație (1/2): estimatorul și intervalul Fisher

- Matricea de covarianță de selecție și corelația Pearson pentru N active pe T zile
  - $\hat{\Sigma} = \frac{1}{T-1} \sum_t (r_t - \bar{r})(r_t - \bar{r})^\top, \quad \hat{\rho}_{ij} = \hat{\Sigma}_{ij} / \sqrt{\hat{\Sigma}_{ii}\hat{\Sigma}_{jj}}$
  - $r_t \in \mathbb{R}^N$: vectorul celor N randamente din ziua t, $t = 1, \ldots, T$
  - $\bar{r}$: vectorul mediilor de selecție
  - $\hat{\Sigma}_{ij}$: elementul (i, j) al matricei
  - $N(N+1)/2$ elemente distincte de estimat: 125 250 pentru $N = 500$
- **Transformarea Fisher**: $z = \operatorname{artanh} \hat{\rho} = \frac{1}{2} \ln \frac{1+\hat{\rho}}{1-\hat{\rho}}$ este aproximativ Normală, cu o variață care nu depinde de ρ
  - $z \approx N\big(\operatorname{artanh} \rho,\ 1/(T-3)\big)$ pentru perechi i.i.d. cu distribuția Normală bivariată
  - Interval de 95% $\tanh(z \pm 1{,}96/\sqrt{T-3})$, readus pe scara corelației prin tanh
  - Exemplu: pentru $T = 252$ și $\rho = 0{,}5$, semilărgimea intervalului este de aproximativ 0,09

Covarianța de selecție și inferența pentru o corelație (2/2): metoda delta și HAC

- Metoda delta scrie eroarea de estimare $\hat{\rho} - \rho$ ca o medie de selecție a contribuțiilor zilnice ψ_t
- Volatility clustering nu schimbă această formă, ci doar varianța lui ψ_t
  - $\hat{\rho} - \rho \approx \frac{1}{T} \sum_t \psi_t, \quad \psi_t = \tilde{x}_t \tilde{y}_t - \frac{\rho}{2}(\tilde{x}_t^2 + \tilde{y}_t^2)$
  - $\tilde{x}_t$, $\tilde{y}_t$: cele două randamente standardizate la media 0 și varianța 1
  - ψ_t: contribuția zilei t la eroarea de estimare
- Eroarea standard (SE, standard error) din varianța pe termen lung a lui ψ_t
  - Estimatorul HAC (heteroskedasticity and autocorrelation consistent, consistent la heteroscedasticitate și autocorelație) folosește nucleul Bartlett cu L laguri (Newey & West (1987))
  - Condiții: staționaritate, momente de ordinul patru finite și dependență slabă
  - Numărul de laguri după regula practică uzuală $L = \lfloor 4(T/100)^{2/9} \rfloor$: $L = 9$ pentru $T = 4\,891$, $L = 6$ pentru $T = 1\,182$, $L = 4$ pentru o fereastră de 252 de zile
  - Pentru perechi i.i.d. cu distribuția Normală, $\mathrm{Var}(\psi_t) = (1 - \rho^2)^2$, adică varianța Fisher
  - Cozile groase și GARCH cresc această varianță (derivarea în ▸ Anexă)
- Exemplu: SPY–TLT zilnic, 2002–2021 ($T = 4\,891$, $\hat{\rho} = -0{,}403$). Eroarea standard a lui $\hat{\rho}$ este:
  - 0,0120 după formula Fisher
  - 0,0217 cu momentele de ordinul patru, fără autocorelație ($L = 0$)
  - 0,0227 cu HAC ($L = 9$)

Intervale Fisher față de HAC: SPY și TLT



- Corelația mobilă pe 252 de zile, din 5 în 5 zile, cu intervalul Fisher de 95% și intervalul HAC de 95% prin metoda delta (Bartlett, $L = 4$)
- Intervalul HAC este mai larg decît cel Fisher în aproape orice fereastră
- Raportul dintre lățimea HAC și lățimea Fisher are mediana 1,24 și cuantila de 90% egală cu 1,54
- Corelația este semnificativ diferită de zero în 73% din ferestre după Fisher și în 65% după HAC
- Concluzia testului se schimbă în 8,2% din ferestre
- Pe perioadele întregi, SE HAC este de 1,9 ori SE Fisher în 2002–2021 și de 1,4 ori din 2022
- Numai corecția pentru momentele de ordinul patru dă deja un raport de 1,8 în 2002–2021 (1,28 din 2022): cozile groase contează mai mult decît autocorelația
- Regula pentru randamente zilnice: raportăm intervale HAC prin metoda delta

MFM_ch6_corr_inference

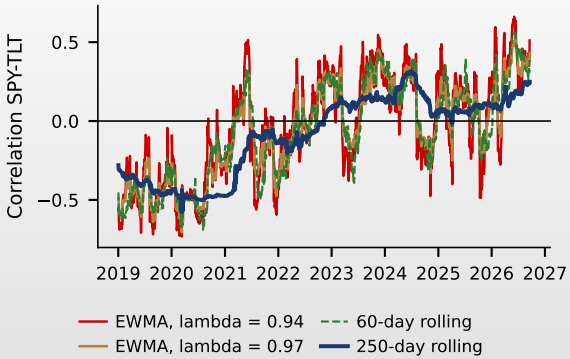
Ferestre mobile

- **Fereastra mobilă** de lungime m: $\hat{\Sigma}_t = \frac{1}{m} \sum_{s=t-m}^{t-1} r_s r_s^\top$ (media fixată la zero pentru date zilnice)
- r_s: vectorul randamentelor din ziua s; m: numărul de zile trecute folosite
- Pozitiv semidefinită: pentru orice vector de ponderi v, $v^\top \hat{\Sigma}_t v = \frac{1}{m} \sum_s (v^\top r_s)^2 \geq 0$, deci orice variantă de portofoliu este ≥ 0
- Singulară dacă $m < N$; pozitiv definită doar dacă cei m vectori de randamente generează $\mathbb{R}^N$
- **Ghost effect**: o zi extremă intră cu ponderea $1/m$ și iese brusc după m zile
- O fereastră scurtă reacționează repede, dar estimările sînt zgomotoase
- O fereastră lungă dă estimări stabile, dar detectează tîrziu o schimbare de regim

EWMA (RiskMetrics)

- **EWMA** (exponentially weighted moving average, media mobilă ponderată exponențial, J.P. Morgan/Reuters (1996)): $\mathbf{\Sigma}_t = \lambda \mathbf{\Sigma}_{t-\mathbf{1}} + (1-\lambda)\, r_{t-\mathbf{1}} r_{t-\mathbf{1}}^\top = (1-\lambda) \sum_{k \geq \mathbf{1}} \lambda^{k-\mathbf{1}} r_{t-k} r_{t-k}^\top$
- $\lambda \in (0,1)$: factorul de descreștere; k: vechimea observației în perioade, cu ponderea $(1-\lambda)\lambda^{k-\mathbf{1}}$
- Valori uzuale: $\lambda = 0{,}94$ pentru date zilnice și $\lambda = 0{,}97$ pentru date lunare
- Timpul de înjumătățire $\ln 0{,}5 / \ln \lambda$: 11,2 perioade pentru $\lambda = 0{,}94$ și 22,8 pentru $\lambda = 0{,}97$; eșantionul efectiv $(1+\lambda)/(1-\lambda)$ este de circa 32 de zile pentru $\lambda = 0{,}94$
- Pozitiv semidefinită și fără ghost effect
- Limita: un singur λ pentru toate elementele și fără revenire la medie, adică un GARCH(1,1) integrat fără constantă (Capitolul 5)
- Un λ mic reacționează repede, dar este zgomotos; un λ mare este stabil, dar detectează târziu o schimbare de regim

EWMA față de ferestre mobile, SPY–TLT din 2019



- Doi estimatori EWMA ($\lambda = 0{,}94$ și $0{,}97$) și două ferestre mobile (60 și 250 de zile) pe aceleași date
- Abaterea standard a variației zilnice a corelației estimate este 0,060 pentru EWMA cu $\lambda = 0{,}94$, 0,032 pentru EWMA cu $\lambda = 0{,}97$ și 0,0088 pentru fereastra de 250 de zile
- Din 10 mai 2022, corelația EWMA cu $\lambda = 0{,}94$ rămîne pozitivă 20 de zile consecutive
- Fereastra de 250 de zile ajunge la același semnal abia pe 8 decembrie 2022
- La EWMA și la ferestrele mobile, λ și m sînt aleși de analist, nu estimați
- DCC (secțiunea următoare) estimează din date viteza de reacție și memoria corelației

MFM_ch6_ewma_rolling

De la volatilitate univariată la volatilitate multivariată (1/2): modelul

- Întrebarea secțiunii: cum modelăm o matrice de covarianță care se schimbă zilnic, rămîne pozitiv definită și are puțini parametri?
- În Capitolul 5 am modelat un singur activ: $r_t = \sigma_t z_t$, $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$
- Acum avem N active și o întreagă matrice de covarianță
  - $r_t = H_t^{1/2} z_t, \quad \mathbb{E}(z_t \mid \mathcal{F}_{t-1}) = 0, \quad \text{Var}(z_t \mid \mathcal{F}_{t-1}) = I_N, \quad \text{deci Var}(r_t \mid \mathcal{F}_{t-1}) = H_t$
  - r_t, z_t: vectorii celor N randamente și ai celor N inovații
  - H_t: matricea $N \times N$ de covarianță condiționată, cunoscută la $t-1$ (notată Σ_t în secțiunea anterioară)
  - $H_t^{1/2}$: o rădăcină pătrată matriceală, $H_t^{1/2}(H_t^{1/2})^\top = H_t$
  - I_N: matricea identitate
  - $\mathcal{F}_{t-1}$: informația disponibilă pînă la $t-1$
- Orice model pentru H_t trebuie să asigure
  - caracterul pozitiv definit la orice t (orice portofoliu are varianță pozitivă)
  - un număr mic de parametri
  - o dinamică interpretabilă
- Log-cvasi-verosimilitatea Gaussiană, maximizată după parametrii lui H_t
  - $\ell = -\frac{1}{2} \sum_t \left(N \ln 2\pi + \ln |H_t| + r_t^\top H_t^{-1} r_t \right)$
  - $|H_t|$: determinantul lui H_t
  - „Cvasi": estimările rămîn consistente și dacă z_t nu are distribuția Normală, cu condiția ca H_t să fie corect specificată

De la volatilitate univariată la volatilitate multivariată (2/2): problema dimensiunii

- **VEC** (Bollerslev, Engle & Wooldridge (1988)):
  $\operatorname{vech}(H_t) = c + A \operatorname{vech}(r_{t-\mathbf{1}} r_{t-\mathbf{1}}^\top) + B \operatorname{vech}(H_{t-\mathbf{1}})$
  - vech: vectorul celor $N(N+1)/2$ elemente distincte ale unei matrice simetrice; A, B: matrice pătrate de această dimensiune
  - Fără garanția caracterului pozitiv definit
- **BEKK** (Baba–Engle–Kraft–Kroner, Engle & Kroner (1995)):
  $H_t = CC^\top + A^\top r_{t-\mathbf{1}} r_{t-\mathbf{1}}^\top A + B^\top H_{t-\mathbf{1}} B$
  - C: triunghiulară inferior; A, B: matrice $N \times N$
  - Pozitiv definită prin construcție (sumă de forme pătratice), dar elementele lui A, B nu au o interpretare directă (▸ Anexă)
- **DCC**: $3N$ parametri GARCH univariați plus a, b; ținta $\bar{Q}$ se estimează separat (slide-ul următor)
- Numărul de parametri crește ca N^4 (VEC) și ca N^2 (BEKK): pentru portofolii mari, modelele devin imposibil de estimat

Numărul de parametri

N	VEC	BEKK complet	DCC
2	21	11	$6+2$
5	465	65	$15+2$
10	6 105	255	$30+2$
50	3 252 525	6 275	$150+2$

Corelația condiționată constantă și dinamică

- Descompunerea: covarianța = volatilități × corelații × volatilități
  - $H_t = D_t R_t D_t, \quad D_t = \text{diag}(\sigma_{\mathbf{1}t}, \ldots, \sigma_{Nt})$
  - σ_{it}: volatilitatea GARCH a activului i; R_t: matricea corelațiilor condiționate; $\varepsilon_{it} = r_{it}/\sigma_{it}$: reziduurile standardizate
- **CCC** (constant conditional correlation, corelație condiționată constantă, Bollerslev (1990)): $R_t = R$ constantă
- **DCC** (Engle (2002)): o recursie de tip GARCH pentru o matrice auxiliară Q_t
  - $Q_t = (1 - a - b)\,\bar{Q} + a\,\varepsilon_{t-\mathbf{1}}\varepsilon_{t-\mathbf{1}}^\top + b\,Q_{t-\mathbf{1}}, \quad a, b \geq 0,\ a + b < 1$
  - $R_t = \text{diag}(Q_t)^{-\mathbf{1}/\mathbf{2}}\, Q_t\, \text{diag}(Q_t)^{-\mathbf{1}/\mathbf{2}}$
  - $\bar{Q}$: matricea constantă (interceptul) a recursiei, cu $N(N-1)/2$ elemente libere
  - Correlation targeting o înlocuiește cu covarianța de selecție $\hat{\bar{Q}} = \frac{\mathbf{1}}{T}\sum_t \varepsilon_t\varepsilon_t^\top$ (consistența acestei alegeri: slide-ul „Estimarea în doi pași (2/2)")
  - a: reacția la produsul șocurilor de ieri; b: memoria; $a + b$: persistența
  - A doua relație rescalează Q_t astfel încît diagonala să fie 1: R_t este o matrice de corelație validă
- Doi parametri guvernează toate cele $N(N-1)/2$ corelații: parcimonios, dar toate perechile au aceeași persistență
- Q_t este o pseudo-covarianță, nu o corelație: $\mathbb{E}_{t-\mathbf{1}}[\varepsilon_t\varepsilon_t^\top] = R_t \neq Q_t$

Estimarea în doi pași (1/2): împărțirea verosimilității

- Log-verosimilitatea Gaussiană se împarte într-o parte de volatilitate și o parte de corelație
  - $\ell = \underbrace{-\frac{1}{2}\sum_t \left(N \ln 2\pi + 2\ln|D_t| + r_t^\top D_t^{-2} r_t\right)}_{\ell_V} \underbrace{-\frac{1}{2}\sum_t \left(\ln|R_t| + \varepsilon_t^\top R_t^{-1}\varepsilon_t - \varepsilon_t^\top \varepsilon_t\right)}_{\ell_C}$
  - ℓ_V: partea de volatilitate, depinde doar de parametrii GARCH
  - ℓ_C: partea de corelație, depinde de (a, b), date fiind volatilitățile
  - $|D_t|$, $|R_t|$: determinanții lui D_t și R_t
- De unde vine împărțirea: înlocuim $H_t = D_t R_t D_t$ și $\varepsilon_t = D_t^{-1} r_t$ în log-cvasi-verosimilitatea din secțiunea anterioară
  - Determinantul: $|H_t| = |D_t|^2 |R_t|$, deci $\ln|H_t| = 2\ln|D_t| + \ln|R_t|$
  - Forma pătratică: $r_t^\top H_t^{-1} r_t = r_t^\top D_t^{-1} R_t^{-1} D_t^{-1} r_t = \varepsilon_t^\top R_t^{-1} \varepsilon_t$
  - Adunăm și scădem $\varepsilon_t^\top \varepsilon_t = r_t^\top D_t^{-2} r_t = \sum_i r_{it}^2/\sigma_{it}^2$: atunci $\ell_V = \sum_i \left[-\frac{1}{2}\sum_t (\ln 2\pi + \ln\sigma_{it}^2 + r_{it}^2/\sigma_{it}^2)\right]$, suma celor N log-verosimilități GARCH Gaussiene univariate
- Pasul 1: estimăm N modele GARCH(1,1) univariate, păstrăm σ_{it} și ε_{it}
- Pasul 2: fixăm $\bar{Q}$ la covarianța de selecție a lui ε_t și maximizăm ℓ_C după (a, b)

Estimarea în doi pași (2/2): ținta și inferența

- Correlation targeting cu covarianța de selecție face estimatorul DCC standard inconsistent în general. De ce: luăm media recursiei, folosind $\mathbb{E}[\varepsilon_{t-\mathbf{1}}\varepsilon_{t-\mathbf{1}}^\top] = \mathbb{E}[R_{t-\mathbf{1}}]$
  - Staționaritatea dă $(1-b)\,\mathbb{E}[Q_t] = (1-a-b)\,\bar{Q} + a\,\mathbb{E}[R_t]$
  - $\hat{\bar{Q}} = \frac{\mathbf{1}}{T}\sum_t \varepsilon_t\varepsilon_t^\top$ estimează $\mathbb{E}[R_t]$, care este egală cu interceptul $\bar{Q}$ doar dacă $\mathbb{E}[Q_t] = \mathbb{E}[R_t]$
  - Egalitatea nu are loc în general: R_t rescalează Q_t cu propria diagonală, aleatoare
  - DCC-ul corectat al lui Aielli (2013) folosește $\mathrm{diag}(Q_{t-\mathbf{1}})^{\mathbf{1}/\mathbf{2}}\varepsilon_{t-\mathbf{1}}$ în locul lui $\varepsilon_{t-\mathbf{1}}$, astfel încît $\mathbb{E}[Q_t] = \bar{Q}$, iar correlation targeting rămîne consistent
- Erorile standard din pasul 2 tratează estimările GARCH și $\bar{Q}$ drept cunoscute: propagăm eroarea lor cu sandwich-ul comun al lui Newey & McFadden (1994) sau prin bootstrap pe ambii pași (▸ Anexă)
- Testul CCC față de DCC: $H_0 : a = 0$
- Sub H_0, b nu este identificat, deci distribuția χ^2 este doar orientativă, iar p-value-ul se obține prin bootstrap sub CCC

Estimările DCC pentru SPY și TLT

Pasul 1: GARCH(1,1), randamente în %

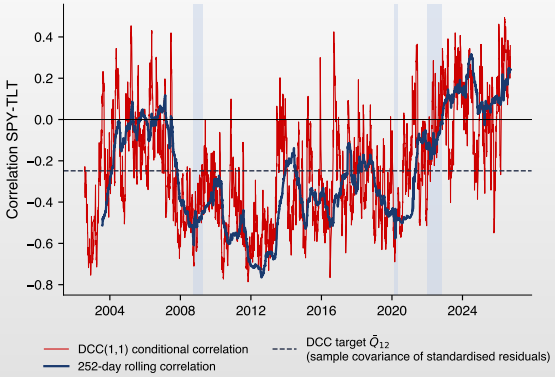
	ω	α	β	$\alpha+\beta$
SPY	0,0283	0,127	0,848	0,975
TLT	0,0057	0,049	0,943	0,993

Pasul 2: DCC(1,1) și trei erori standard

	estimare	hessiană	boot. pasul 2	boot. ambii
a	0,0522	0,0059	0,0051	0,0052
b	0,9335	0,0084	0,0077	0,0077
$a+b$	0,9857	–	0,0038	0,0040

- Date zilnice între 31 iulie 2002 și 18 septembrie 2026, $T = 6\,073$; ținta $\hat{\bar{Q}}_{\mathbf{12}} = -0{,}248$
- Persistența $a+b = 0{,}986$: un șoc asupra lui Q_t se înjumătățește în $\ln 0{,}5 / \ln 0{,}986 \approx 48$ de zile (pentru R_t doar aproximativ, recursia fiind liniară în Q_t)
- Testul LR față de CCC: $LR = 2(\hat{\ell}^{DCC} - \hat{\ell}^{CCC}) = 2(460{,}26 - 193{,}54) = 533{,}4$
- Bootstrap pe ambii pași sub CCC ($B = 199$): maximul simulat sub H_0 este 15,7, deci $p = 1/(B+1) = 0{,}005$, cea mai mică valoare posibilă: CCC este respins
- Incertitudinea din pasul 1 crește SE cu doar 2% pentru a și cu 1% pentru b, deoarece T este mare
- SE din hessiană (0,0059 pentru a, 0,0084 pentru b) sînt mai mari decît cele bootstrap: sînt conservatoare
- Volatilitatea TLT este mai persistentă ($\alpha+\beta = 0{,}993$ față de 0,975), dar reacționează mai puțin la știri ($\alpha = 0{,}049$ față de 0,127)

Corelația DCC dintre SPY și TLT, 2002–2026



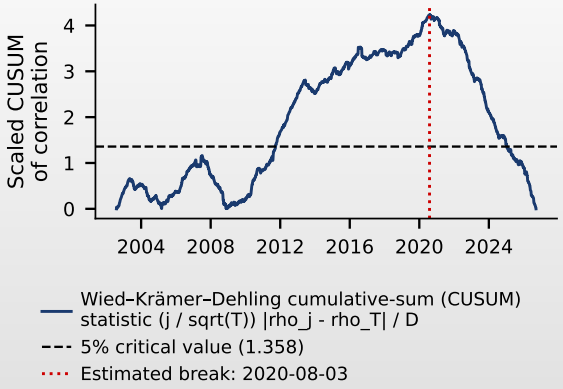
- Corelația condiționată DCC(1,1), corelația mobilă pe 252 de zile și ținta $\bar{\hat{Q}}_{12} = -0{,}248$, media produselor $\varepsilon_{1t}\varepsilon_{2t}$ ale reziduurilor standardizate (slide-urile anterioare)
- Corelația DCC variază între $-0{,}79$ (2 noiembrie 2011) și 0,49 (21 mai 2026)
- Ultima valoare: 0,36
- Corelația DCC medie: $-0{,}54$ între 15 septembrie și 31 decembrie 2008, $-0{,}56$ în 2012, 0,00 în 2022
- DCC reacționează în cîteva zile, ca EWMA, dar viteza a și memoria b sînt estimate
- Din ianuarie 2022 corelația DCC este deasupra țintei în 92% din zile, față de 36% înainte
- Ipoteza unei singure corelații pe termen lung este deci discutabilă

MFM_ch6_dcc_spy_tlt

Testarea corelației constante la o dată necunoscută

- Tse (2000): test de tip multiplicator Lagrange pentru H_0: corelație constantă, contra $\rho_{ij,t} = \rho_{ij} + \delta_{ij}\,\varepsilon_{i,t-1}\varepsilon_{j,t-1}$; se calculează doar din modelul CCC estimat
- Alegerea datei rupturii de pe un grafic și testarea ei ulterioară cu un test Fisher z la dată fixă duc la un nivel efectiv prea mare: data este ea însăși aleasă pe baza datelor
- Wied, Krämer & Dehling (2012): $Q_T = \max_{2 \le j \le T} \frac{j}{\sqrt{T}\,\hat{D}} \left|\hat{\rho}_j - \hat{\rho}_T\right|$, $\hat{\rho}_j$ corelația primelor j observații; data estimată a rupturii: $\hat{j} = \arg\max$
  - Compară corelația primelor j zile cu $\hat{\rho}_T$ din tot eșantionul
  - O diferență mare la un anumit j semnalează o ruptură
  - $\hat{D}^2$: varianța pe termen lung a lui $\hat{\rho}$ prin metoda delta, nucleu Bartlett cu lățimea $\lfloor T^{1/4} \rfloor$ ($\lfloor\cdot\rfloor$: partea întreagă)
  - Sub H_0 (corelație, medii și variațe constante): $Q_T \to \sup_{0 \le s \le 1} |B(s)|$, cu $s = j/T$
  - B: o punte browniană, adică o mișcare browniană (random walk în timp continuu) fixată la 0 în $s = 0$ și în $s = 1$
  - Valoarea critică la 5%: 1,358
  - Variațele trebuie să fie constante, deci îl aplicăm reziduurilor standardizate GARCH

Datarea rupturii corelației SPY–TLT (1/2)



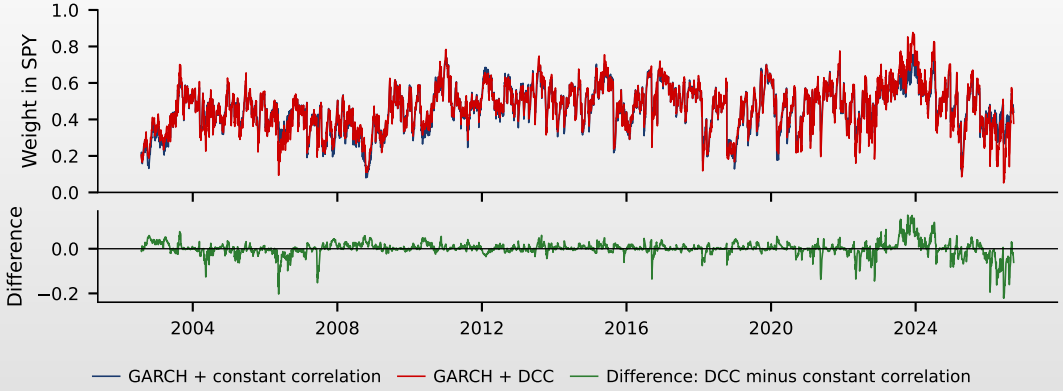
MFM_ch6_corr_inference

Datarea rupturii corelației SPY–TLT (2/2)

- Procesul Wied–Krämer–Dehling pe reziduurile standardizate GARCH(1,1), $T = 6\,073$, lățimea nucleului 8
- Linia întreruptă: valoarea critică la 5%
- $Q_T = 4{,}25$ față de 1,358: corelația constantă este respinsă ($p < 0{,}001$)
- Ruptura estimată are loc pe 3 august 2020, nu în ianuarie 2022
- Corelația reziduurilor este $-0{,}36$ înainte de ruptură și 0,07 după
- Segmentarea binară (testul repetat pe fiecare subperioadă): înainte de ruptura principală, $Q = 3{,}01$ și o a doua ruptură pe 9 iulie 2007
- După ruptura principală (din august 2020): $Q = 1{,}56 > 1{,}358$, $p = 0{,}015$, deci nici aici corelația nu este constantă
- Legea limită este demonstrată pentru serii observate: pe reziduuri estimate p-value-urile sînt aproximative
- O singură țintă DCC pe 2002–2026 este o medie a cel puțin trei regimuri (rupturi în iulie 2007 și în august 2020)

MFM_ch6_corr_inference

Aplicație: ponderi de variantă minimă cu DCC (1/2)



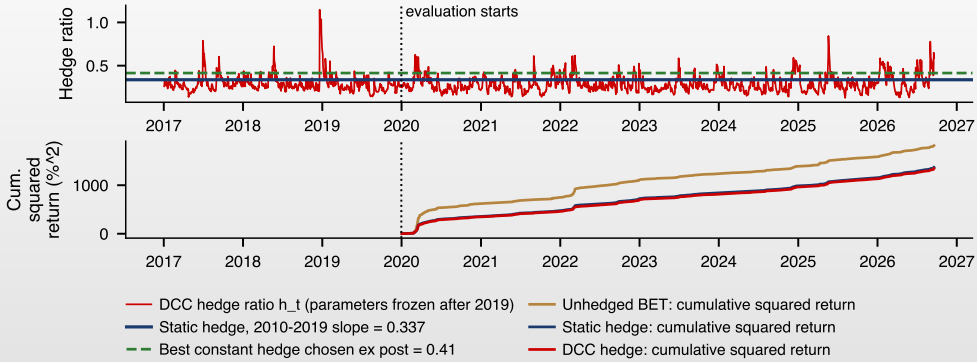
MFM_ch6_dcc_minvar

Aplicație: ponderi de variață minimă cu DCC (2/2)

- Ponderea SPY în portofoliul zilnic SPY–TLT de variață minimă: $w_t = (\sigma^2_{2t} - \sigma_{12,t})/(\sigma^2_{1t} + \sigma^2_{2t} - 2\sigma_{12,t})$, trunchiată la $[0, 1]$
- $\sigma_{12,t} = \rho_t \sigma_{1t} \sigma_{2t}$: covariația condiționată
- Volatilitățile GARCH sînt aceleași, iar corelația provine din DCC sau este constantă, egală cu corelația randamentelor pe tot eșantionul 2002–2026 ($-0{,}30$)
- Volatilitatea anualizată a portofoliului: 10,99% pentru 60/40 fix, 9,10% pentru GARCH cu corelație constantă și 9,06% pentru GARCH cu DCC
- Cea mai mare parte a cîștigului vine din volatilitățile GARCH, iar DCC adaugă puțin
- Diferența absolută dintre ponderea DCC și ponderea cu corelație constantă este în medie 0,019 și cel mult 0,22 (8 iunie 2026)
- Ilustrare in-sample: un test corect reestimează pe ferestre cu lungime crescătoare și adaugă costurile de tranzacționare (costurile de tranzacționare: Capitolul 4; evaluarea out-of-sample: Capitolul 8)

MFM_ch6_dcc_minvar

Hedging dinamic out-of-sample: BET cu Euro Stoxx 50 (1/2)



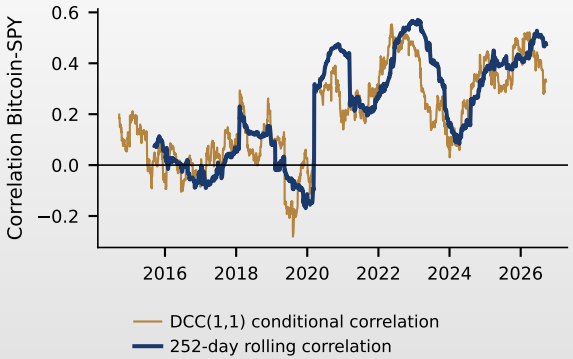
MFM_ch6_corr_inference

Hedging dinamic out-of-sample: BET cu Euro Stoxx 50 (2/2)

- Investitorul în BET acoperă riscul cu Euro Stoxx 50: pe BET nu există futures lichide, iar cele două piețe se închid aproape sincron
- Estimare zilnică din 5 ianuarie 2010 pînă la sfîrșitul lui 2019 ($n = 2\,491$)
- Evaluare out-of-sample în 2020–2026 ($n = 1\,663$), cu parametrii ținuți fixi; panoul de sus arată din 2017
- Hedge static: panta regresiei din fereastra de estimare, $h = 0{,}337$
- Hedge DCC: $h_t = \rho_t \sigma_{S,t}/\sigma_{F,t}$ (S: BET, F: Euro Stoxx 50, $\hat{a} = 0{,}009$, $\hat{b} = 0{,}964$), cu media 0,29 și valori între 0,13 și 0,84 în 2020–2026
- Varianța eliminată în 2020–2026: 24,7% cu hedge-ul static, 26,2% cu hedge-ul DCC și 25,6% cu cel mai bun hedge constant ales ex post ($h = 0{,}41$)
- Testul Diebold & Mariano (1995) (test t pentru media diferenței de pierdere d_t = pătratul randamentului acoperit static minus DCC, cu SE HAC): $t = 1{,}29$, p unilateral $= 0{,}098$, deci cîștigul DCC este mic și nesemnificativ la 5%

MFM_ch6_corr_inference

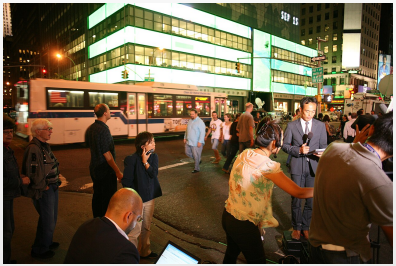
Bitcoin și acțiunile americane: corelația DCC



- Bitcoin și SPY în zilele comune de tranzacționare din 18 septembrie 2014 ($T = 3\,018$)
- Mișcările Bitcoin din weekend intră în randamentul de luni
- Corelația DCC medie este 0,04 înainte de 2020 și 0,31 din ianuarie 2020
- Vîrful, 0,55, este atins pe 19 mai 2022
- Corelația este foarte persistentă: $a = 0{,}015$, $b = 0{,}982$, $a + b = 0{,}9968$
- Testul LR față de CCC: 105,6; bootstrap sub CCC ($B = 199$): $p = 1/(B + 1) = 0{,}005$, minimul posibil: CCC este respins
- De la activ de diversificare la activ de risc: corelația din tot eșantionul (0,24) ascunde două regimuri
- Liu & Tsyvinski (2021): pînă în 2018, criptoactivele au avut expuneri mici la factorii pieței de acțiuni; după 2020 DCC arată contrariul

MFM_ch6_dcc_btc_spy

Contagion sau interdependență?



Sediul Lehman Brothers, New York, 15 septembrie 2008, ziua cererii de faliment

Foto: Robert Scoble (2008); CC BY 2.0; Wikimedia Commons

- Constatare frecventă: corelațiile măsurate în criză sînt mai mari decît în perioadele calme
- O corelație mare în criză nu este încă contagion: trebuie să o depășească semnificativ pe cea din perioada calmă
- Două explicații foarte diferite
  - **Contagion**: se schimbă însuși mecanismul de transmitere
  - **Distorsiune de volatilitate**: mecanismul rămîne neschimbat, dar o piață-sursă mai volatilă crește mecanic corelația
- Forbes & Rigobon (2002): după corecție, cea mai mare parte din „contagion"-ul din 1987, 1994 și 1997 s-a dovedit interdependență
- Longin & Solnik (2001), Ang & Chen (2002): corelațiile cresc pe piețele în scădere, nu pe cele în creștere, o asimetrie pe care distribuția Normală nu o poate produce

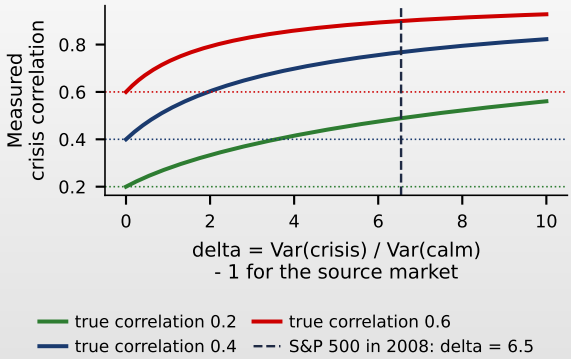
Distorsiunea de heteroscedasticitate (1/2): corelația în perioada calmă

- Modelul: $y_t = \alpha + \beta x_t + \varepsilon_t$, $\text{Cov}(x_t, \varepsilon_t) = 0$, β și σ_ε^2 constante
  - x_t: randamentul pieței-sursă
  - y_t: randamentul celeilalte piețe
  - β: coeficientul de transmitere
  - ε_t: șocul propriu al lui y, cu varianța σ_ε^2
  - σ_x^2: varianța lui x
- Două momente ale modelului
  - $\text{Cov}(x_t, y_t) = \beta\sigma_x^2$ și $\text{Var}(y_t) = \beta^2\sigma_x^2 + \sigma_\varepsilon^2$, deoarece ε_t este necorelat cu x_t
- Corelația: $\rho^2 = \dfrac{\beta^2\sigma_x^2}{\beta^2\sigma_x^2 + \sigma_\varepsilon^2} = \left(1 + \dfrac{\sigma_\varepsilon^2}{\beta^2\sigma_x^2}\right)^{-1}$
- Același lucru printr-un singur număr: raportul semnal–zgomot $k = \beta^2\sigma_x^2/\sigma_\varepsilon^2$
  - $\rho^2 = \dfrac{k}{1+k}$, echivalent $k = \dfrac{\rho^2}{1-\rho^2}$: corelația depinde de σ_x^2 doar prin k

Distorsiunea de heteroscedasticitate (2/2): de la calm la criză

- În criză (indicele c): $\sigma^2_{x,c} = (1+\delta)\,\sigma^2_x$, unde $\delta > 0$ este creșterea relativă a variației prețului-sursă
- Nimic altceva nu se schimbă
- Crește doar σ^2_x, deci $k_c = (1+\delta)\,k$ și
  - $\rho^2_c = \dfrac{k_c}{1+k_c} = \dfrac{(1+\delta)\rho^2/(1-\rho^2)}{1+(1+\delta)\rho^2/(1-\rho^2)} = \dfrac{(1+\delta)\rho^2}{1+\delta\rho^2}$
- Atunci $\rho_c = \rho\sqrt{\dfrac{1+\delta}{1+\delta\rho^2}}$, deci $|\rho_c| > |\rho|$ pentru $0 < |\rho| < 1$: corelația măsurată crește în valoare absolută deși β este același
- Inversînd: $\rho^* = \dfrac{\rho_c}{\sqrt{1+\delta(1-\rho^2_c)}}$ este corelația din criză corectată pentru creșterea volatilității
- Verificare rapidă: varianța prețului-sursă se dublează ($\delta = 1$), iar $\rho = 0{,}5$
  - $k = 0{,}25/0{,}75 = 1/3$, $k_c = 2/3$, $\rho^2_c = (2/3)/(5/3) = 0{,}4$, deci $\rho_c = 0{,}632$: o creștere de 0,13 fără nicio schimbare a lui β
  - Corecția: $\rho^* = 0{,}632/\sqrt{1+1\cdot(1-0{,}4)} = 0{,}632/1{,}265 = 0{,}5$, deci regăsim valoarea din perioada calmă

Creșterea corelației cauzată numai de volatilitate



- Corelația măsurată în criză ρ_c în funcție de δ, pentru trei corelații adevărate care nu se schimbă
- Linia verticală: în fereastra de criză din 2008, varianța randamentelor S&P 500 pe 2 zile a fost de 7,5 ori nivelul din anul calm ($\delta = 6{,}54$)
- La acest δ, o corelație adevărată neschimbată de 0,4 se măsoară ca 0,77, iar una de 0,2 ca 0,49

MFM_ch6_fr_bias

Testul Forbes–Rigobon și inferența lui

- Procedura
  - Alegem piața-sursă x, o fereastră calmă și una de criză
  - Folosim randamente pe 2 zile ca să neutralizăm diferența dintre orele de închidere ale piețelor
  - Calculăm $\delta = \hat{\sigma}^2_{x,c}/\hat{\sigma}^2_{x,calm} - 1$ și ρ^*
  - Testăm $H_0 : \rho^* \leq \rho_{calm}$ cu statistici Fisher z, convenția din Forbes & Rigobon (2002)
- Inferența
  - Cu δ fixat, $\mathrm{Var}(\operatorname{artanh}\rho^*) \approx 1/[n_c(1+\delta(1-\rho_c^2))] < 1/n_c$ (n_c: observațiile din criză): testul Fisher este conservator
  - δ este estimat, iar randamentele pe 2 zile se suprapun
  - Soluția: reeșantionăm împreună ferestrele calmă și de criză (bootstrap staționar, bloc mediu de 10 zile, $B = 1\,999$ extrageri) și testăm $D = \rho^* - \rho_{calm}$
  - Bootstrap staționar: reeșantionează blocuri de zile consecutive, cu începuturi aleatoare și lungimi aleatoare geometrice, care păstrează dependența serială din interiorul fiecărui bloc

Ipoteze de reținut

- Niciun șoc comun omis: un factor global care afectează ambele piețe crește atît σ_x, cît și σ_ε, iar corecția este excesivă (Corsetti, Pericoli & Sbracia (2005); ▸ Anexă)
- Nicio legătură inversă de la y la x (fără endogenitate)
- Alegerea ferestrelor contează: o deplasare a ferestrelor cu cîteva săptămîni poate inversa rezultatele
- Corecția este excesivă dacă mecanismul de transmitere s-a schimbat efectiv

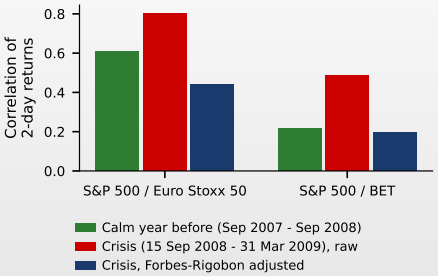
Exemplu lucrat: criza din 2008 pas cu pas (1/2): corecția

- Piața-sursă: S&P 500
- Anul calm: 14 septembrie 2007 – 12 septembrie 2008 ($n = 242$ randamente pe 2 zile)
- Criza: 15 septembrie 2008 – 31 martie 2009 ($n = 130$)
- Raportul varianțelor: $1 + \delta = 7{,}54$, deci $\delta = 6{,}54$
- Euro Stoxx 50: $\rho_{calm} = 0{,}610$, $\rho_c = 0{,}804$
  - $\rho^* = 0{,}804/\sqrt{1 + 6{,}54\,(1 - 0{,}804^2)} = 0{,}442$
- BET: $\rho_{calm} = 0{,}216$, $\rho_c = 0{,}485$
  - $\rho^* = 0{,}485/\sqrt{1 + 6{,}54\,(1 - 0{,}485^2)} = 0{,}198$
- Ambele corelații brute din criză le depășesc mult pe cele din perioada calmă
- După corecție, ambele scad sub ele

Exemplu lucrat: criza din 2008 pas cu pas (2/2): testarea

- Test Fisher unilateral pentru $H_0 : \rho_1 \le \rho_{calm}$, cu $\rho_1 = \rho_c$ (brut) sau $\rho_1 = \rho^*$ (corectat)
  - $z = \dfrac{\operatorname{artanh}\rho_1 - \operatorname{artanh}\rho_{calm}}{\sqrt{1/(n_c-3) + 1/(n_{calm}-3)}}, \quad p = 1 - \Phi(z)$
- Volumele ședințioanelor: randamentele pe 2 zile consecutive au o zi comună, deci nu sînt independente
  - Folosim volumele efective $n_{calm} = 121$ și $n_c = 65$, jumătate din 242 și 130
  - Pentru perechi zilnice i.i.d. Normale, aproximația Bartlett dă un volum efectiv apropiat de $2n/3$, deci înjumătățirea este prudentă în acest reper, nu o limită generală
- Euro Stoxx 50, brut: $z = \dfrac{\operatorname{artanh} 0{,}804 - \operatorname{artanh} 0{,}610}{\sqrt{1/62 + 1/118}} = 2{,}56$
  - p-value-ul unilateral: 0,005 cu ρ_c ($z = 2{,}56$), 0,932 cu ρ^* ($z = -1{,}49$)
- BET
  - $z = 1{,}97$ brut ($p = 0{,}024$), $z = -0{,}12$ corectat ($p = 0{,}548$)
- Verificare: cu toate cele 130 și 242 randamente suprapuse, statistica brută pentru Euro Stoxx 50, din corelațiile nerotunjite, ar fi $z = 3{,}66$, cu $p \approx 0{,}0001$: tratarea randamentelor suprapuse ca independente supraevaluează dovezile

2008: corelații de criză brute față de cele corectate



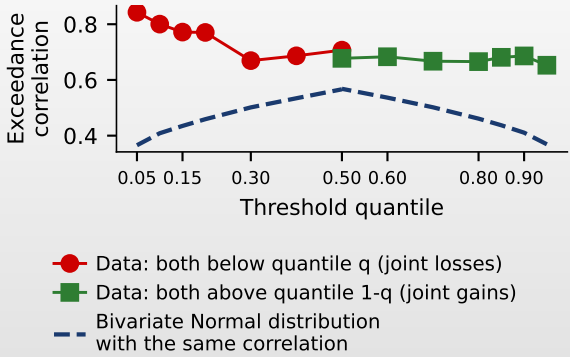
- Corelația randamentelor pe 2 zile cu S&P 500: anul calm, criza (brută) și criza după corecția Forbes–Rigobon
- Ambele creșteri brute sînt semnificative la 5%, niciuna nu rămîne semnificativă după corecție
- Bootstrap staționar: $\hat{\delta} = 6{,}54$, cu intervalul de 90% [3,9; 9,6]
- Euro Stoxx 50: intervalul de 90% pentru ρ^* este [0,38; 0,52], iar $p = 0{,}98$
- BET: intervalul de 90% pentru ρ^* este [0,16; 0,24], iar $p = 0{,}62$; SE bootstrap a lui ρ^* este 0,025, față de 0,047 cu formula Normală
- Concluzie: nicio dovadă de contagion după corecția pentru volatilitate, în ipotezele modelului
- Rezerve: în 2008 un șoc global comun a lovit toate piețele, deci corecția poate fi excesivă (Corsetti, Pericoli & Sbracia (2005)); testul are și putere mică (aplicația pentru 2020: Seminarul B3)

MFM_ch6_forbes_rigobon

Corelațiile de depășire

- Întrebarea secțiunii: cît de probabile sînt pierderile extreme simultane și ce model al dependenței le poate reproduce, cînd corelația nu o poate face?
- Longin & Solnik (2001): corelația condiționată de faptul că ambele randamente depășesc un prag
- Lower tail la cuantila q: $\rho^{-}(q) = \mathrm{Corr}(x, y \mid x \leq F_x^{-1}(q),\, y \leq F_y^{-1}(q))$
- $F_x^{-1}(q)$: cuantila de ordin q a lui x (de ex. $q = 0{,}10$: cele mai proaste 10% dintre săptămîni)
- Upper tail: la fel, cu $x \geq F_x^{-1}(1-q)$, $y \geq F_y^{-1}(1-q)$
- Referința: pentru distribuția Normală bivariată, $\rho^{\pm}(q) \to 0$ cînd $q \to 0$
  - Condiționarea pe valori extreme reduce corelația chiar dacă structura dependenței rămîne neschimbată: comparăm cu curba Normală, nu cu ρ

Corelații de depășire: S&P 500 și Euro Stoxx 50



- Randamente săptămînale 2000–2026, în zilele comune de tranzacționare S&P 500 și Euro Stoxx 50 ($n = 1\,393$), cu corelația pe tot eșantionul $\hat{\rho} = 0{,}78$
- Linia întreruptă: distribuția Normală bivariată cu aceeași corelație (2 milioane de perechi simulate)
- La $q = 0{,}10$, corelația pe pierderile comune este $\rho^{-} = 0{,}80$ (86 săptămîni), iar cea pe cîștigurile comune $\rho^{+} = 0{,}69$ (70 săptămîni)
- Referința Normală la același q: 0,41
- Ambele cozi sînt mult peste referința Normală, iar scăderile puternice apar simultan mai des decît creșterile puternice
- Un singur coeficient nu poate descrie acest lucru: este necesar un model al întregii structuri de dependență, o copulă

MFM_ch6_exceedance

Limitele corelației liniare

- Embrechts, McNeil & Straumann (2002): trei erori frecvente despre corelația liniară
- Corelația măsoară doar dependența *liniară* și nu este invariantă la transformări monotone: $\text{Corr}(x, y) \neq \text{Corr}(e^x, e^y)$
- Marginalele și corelația nu determină distribuția comună
  - Două portofolii cu aceleași marginale și același ρ pot avea Value at Risk foarte diferite (Capitolul 7)
- Corelațiile posibile: pentru marginale date, $\rho \in [\rho_{\min}, \rho_{\max}]$, atinse de perechi contramonotone și comonotone
  - Exemplu cu distribuții lognormale: $X = e^{\sigma_1 Z}$, $Y = e^{\pm\sigma_2 Z}$, cu Z din distribuția Normală standard (cu $+$ variabilele sînt comonotone, cu $-$ contramonotone)
  - $\rho_{\max} = \dfrac{e^{\sigma_1\sigma_2} - 1}{\sqrt{(e^{\sigma_1^2} - 1)(e^{\sigma_2^2} - 1)}}$, iar $\rho_{\min}$ se obține cu $e^{-\sigma_1\sigma_2}$ la numărător
  - Pentru $\sigma_1 = 1$ și $\sigma_2 = 3$: $\rho_{\max} = 0{,}162$ și $\rho_{\min} = -0{,}008$, deci variabile perfect dependente pot fi aproape necorelate

Teorema lui Sklar: marginale plus copulă

- O **copulă** este o funcție de repartiție comună pe $[0,1]^d$ cu marginale uniforme
- Sklar (1959): pentru orice repartiție comună F cu marginalele $F_1, \ldots, F_d$ există o copulă C astfel încît $F(x_1, \ldots, x_d) = C(F_1(x_1), \ldots, F_d(x_d))$
  - d: numărul de variabile
  - F_i: funcția de repartiție marginală a lui x_i
  - $u_i = F_i(x_i) \in [0,1]$: nivelul ei de probabilitate
  - C este unică dacă marginalele sînt continue
  - Invers, orice copulă și orice marginale dau o repartiție comună validă
  - Cu densități: $f(x) = c(F_1(x_1), \ldots, F_d(x_d)) \prod_i f_i(x_i)$, c densitatea copulei, f_i densitățile marginale (copula comonotonă nu are densitate)
- Marginalele conțin volatilitatea, asimetria și cozile groase ale fiecărui activ (Capitolele 1 și 5)
- Copula conține toată dependența și este invariantă la transformări crescătoare ale fiecărei variabile
- Trei copule de referință și marginile Fréchet–Hoeffding $W \leq C \leq M$ (Nelsen (2006))
  - Independența: $\Pi(u,v) = uv$
  - Comonotonia: $M(u,v) = \min(u,v)$
  - Contramonotonia: $W(u,v) = \max(u+v-1, 0)$

Corelații de rang: Kendall și Spearman

- **Tau al lui Kendall** (Kendall (1938)): perechi concordante minus perechi discordante
  - $\tau = P\big[(X_1 - X_2)(Y_1 - Y_2) > 0\big] - P\big[(X_1 - X_2)(Y_1 - Y_2) < 0\big]$
  - (X_1, Y_1), (X_2, Y_2): două extrageri independente ale perechii
  - Perechi concordante: ambele coordonate variază în același sens
  - Forma în copule: $\tau = 4 \iint C \, dC - 1 = 4\,\mathbb{E}[C(U, V)] - 1$
- **Rho al lui Spearman** (Spearman (1904)): corelația Pearson a rangurilor
  - Forma în copule: $\rho_S = 12 \iint (C(u, v) - uv)\, du\, dv$
- Ambele iau valori în $[-1, 1]$ și depind doar de copulă: 1 pentru M, 0 pentru Π, -1 pentru W
- θ: parametrul copulei

Legătura cu parametrii copulelor

Copula	τ
Gaussiană, t	$\frac{2}{\pi} \arcsin \rho$
Clayton	$\theta/(\theta + 2)$
Gumbel	$1 - 1/\theta$
Frank	$1 - \frac{4}{\theta}\left[1 - D_1(\theta)\right]$

- $D_1(\theta) = \frac{1}{\theta} \int_0^\theta \frac{t}{e^t - 1} dt$ (funcția Debye)
- Gaussiană: $\rho_S = \frac{6}{\pi} \arcsin(\rho/2)$
- Exemplu, copula Gaussiană cu $\rho = 0{,}5$: $\tau = \frac{2}{\pi} \cdot \frac{\pi}{6} = 1/3$ și $\rho_S = \frac{6}{\pi} \arcsin 0{,}25 = 0{,}483$

Cinci familii de copule

Familia	$C(u,v)$	Parametru
Gaussiană	$\Phi_{\mathbf{2},\rho}\left(\Phi^{-\mathbf{1}}(u), \Phi^{-\mathbf{1}}(v)\right)$	$-1 < \rho < 1$
Student t (Demarta & McNeil (2005))	$t_{\mathbf{2},\rho,\nu}\left(t_\nu^{-\mathbf{1}}(u), t_\nu^{-\mathbf{1}}(v)\right)$	$-1 < \rho < 1$, $\nu > 0$
Clayton (Clayton (1978))	$(u^{-\theta} + v^{-\theta} - 1)^{-\mathbf{1}/\theta}$	$\theta > 0$
Gumbel (Gumbel (1960))	$\exp\left(-[(-\ln u)^\theta + (-\ln v)^\theta]^{\mathbf{1}/\theta}\right)$	$\theta \geq 1$
Frank (Frank (1979))	$-\frac{\mathbf{1}}{\theta}\ln\left(1 + \frac{(e^{-\theta u}-\mathbf{1})(e^{-\theta v}-\mathbf{1})}{e^{-\theta}-\mathbf{1}}\right)$	$\theta \neq 0$

- $\Phi, \Phi^{-\mathbf{1}}$, $\Phi_{\mathbf{2},\rho}$: funcția de repartiție, cuantila și funcția de repartiție bivariată (corelația ρ) ale distribuției Normale; t_ν, $t_{\mathbf{2},\rho,\nu}$: analoagele Student t cu ν grade de libertate; θ: parametrul de dependență
- De ce aceste cinci: acoperă cele patru tipare de cozi: niciuna (Gaussiană, Frank), ambele simetric (t), doar lower tail (Clayton), doar upper tail (Gumbel)
- Eliptice (Gaussiană, t): se extind la d dimensiuni cu o matrice de corelație, alegerea standard în sistemele de risc
- Pentru $\nu \to \infty$, copula t devine copula Gaussiană
- Arhimediene (Clayton, Gumbel, Frank): $C(u,v) = \varphi^{-\mathbf{1}}\left(\varphi(u) + \varphi(v)\right)$, φ: generator (descrescător, $\varphi(1) = 0$)
  - Au un singur parametru, formă închisă și se simulează ușor
  - Dar sînt simetrice la permutarea variabilelor și puțin flexibile în dimensiuni mari
- Rotirea cu 180° (copula de supraviețuire a lui $(1-U, 1-V)$) transferă dependența în cozi în coada opusă (densitățile și generatorii în Anexă)

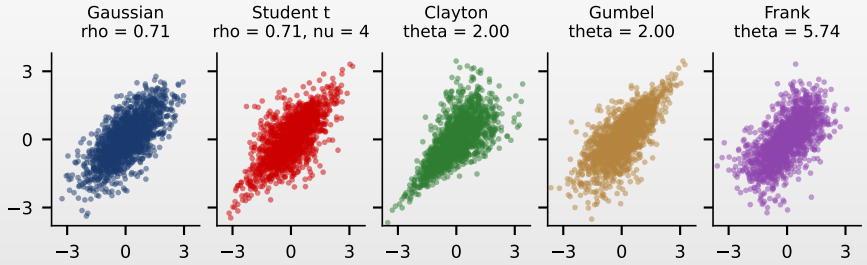
Dependența în cozi

- Lower tail:
  $\lambda_L = \lim_{q \downarrow \mathbf{0}} P(V \leq q \mid U \leq q) = \lim_{q \downarrow \mathbf{0}} C(q,q)/q$, cu
  $U = F_{\mathbf{1}}(X_{\mathbf{1}})$, $V = F_{\mathbf{2}}(X_{\mathbf{2}})$ și q probabilitatea din coadă
- Upper tail: $\lambda_U = \lim_{q \downarrow \mathbf{0}} P(V > 1 - q \mid U > 1 - q)$
- $\lambda > 0$: probabilitatea unei extreme comune rămîne pozitivă oricît de extrem ar fi pragul; $\lambda = 0$: independență asimptotică
- Dependența în cozi este o proprietate a copulei, invizibilă în ρ
- La un q finit, $C(q,q)/q$ este o probabilitate, nu încă limita
- $t_{\nu+\mathbf{1}}$ în tabel: funcția de repartiție Student t cu $\nu + 1$ grade de libertate

Forme închise

	λ_L	λ_U
Gaussiană	0	0
Student t	$2\, t_{\nu+\mathbf{1}}\Big(-\sqrt{\frac{(\nu+\mathbf{1})(\mathbf{1}-\rho)}{\mathbf{1}+\rho}} \Big)$	la fel
Clayton	$2^{-\mathbf{1}/\theta}$	0
Gumbel	0	$2 - 2^{\mathbf{1}/\theta}$
Frank	0	0

Cinci copule cu același tau al lui Kendall



All with Kendall's tau = 0.5, shown on Normal-score margins

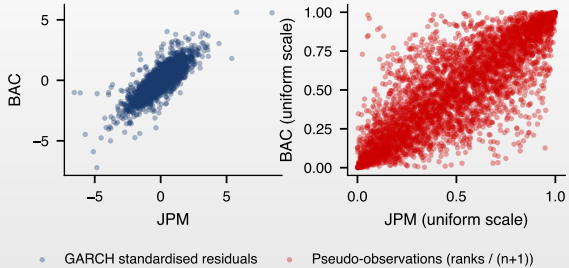
- 1 500 de perechi simulate din fiecare copulă cu $\tau = 0{,}5$, pe marginale Normale $(\Phi^{-1}(u), \Phi^{-1}(v))$
- Parametrii care dau $\tau = 0{,}5$: $\rho = 0{,}707$ pentru Gaussiană și t (copula t cu $\nu = 4$), $\theta = 2{,}0$ pentru Clayton și Gumbel, $\theta = 5{,}74$ pentru Frank
- În cozi: copulele Gaussiană și Frank devin rarefiate, copula t rămîne densă în ambele, Clayton se concentrează în lower tail (crahuri comune), Gumbel în upper tail
- Același tau al lui Kendall nu determină riscul extremelor simultane

MFM_ch6_copula_zoo

Estimarea copulelor

- **Verosimilitate maximă completă**: marginalele și copula estimate simultan
  - Eficientă, dar costisitoare computațional și sensibilă la erorile de specificare
- **IFM** (funcții de inferență pentru marginale, Joe (2005)): doi pași
  - Pasul 1: estimăm marginale parametrice (de exemplu GARCH cu Student t)
  - Calculăm $\hat{u}_{it} = \hat{F}_i(x_{it})$, unde $\hat{F}_i$ este funcția de repartiție marginală estimată
  - Pasul 2: maximizăm $\sum_t \ln c(\hat{u}_{\mathbf{1}t}, \hat{u}_{\mathbf{2}t}; \theta)$, unde c este densitatea copulei
- **CML** (verosimilitate maximă canonică, Genest, Ghoudi & Rivest (1995)): fără marginale parametrice
  - Pseudo-observații $\hat{u}_{it} = \text{rang}(x_{it})/(T+1)$
  - Apoi maximizăm verosimilitatea copulei
  - Robustă la marginale specificate greșit
  - Numitorul $T+1$ menține $\hat{u}$ la distanță de 0 și 1
- Pentru randamente: filtrăm întîi fiecare serie cu GARCH, deoarece copula presupune observații i.i.d., iar volatility clustering ar amesteca dependența cu variația volatilității; apoi folosim rangurile reziduurilor standardizate (CML, metoda folosită în continuare)
- Alegerea modelului: familiile nu sînt imbricate, deci testul LR nu se aplică; folosim AIC $= 2k - 2\ell$ (criteriul Akaike) și BIC $= k \ln T - 2\ell$ (criteriul bayesian)
- k: numărul de parametri, iar ℓ: log-verosimilitatea maximă
- Valoarea mai mică a criteriului indică modelul preferat

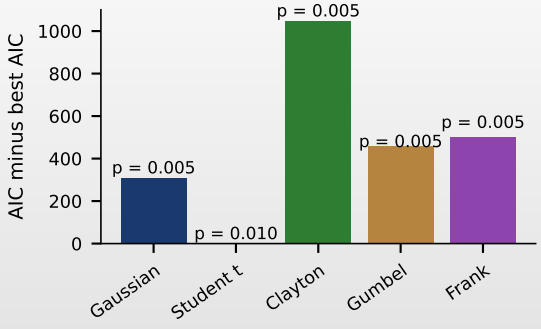
De la reziduuri la pseudo-observații: JPM și BAC



- JPMorgan Chase (JPM) și Bank of America (BAC), zilnic 2010–2026 ($T = 4\,202$), filtrate GARCH(1,1)
- Tau al lui Kendall: $\hat{\tau} = 0{,}641$
- Rho al lui Spearman: $\hat{\rho}_S = 0{,}822$
- Norul de puncte cu marginale uniforme este dens în ambele cozi: crahuri comune și creșteri comune

MFM_ch6_copula_banks

Estimările copulelor și adecvarea lor: JPM și BAC



Numbers above bars: goodness-of-fit p-value
(Rosenblatt Cramer-von Mises, parametric bootstrap)

	$\hat{\theta}$ sau $\hat{\rho}$	$\hat{\nu}$	λ_L	λ_U
Gaussiană	0,833	–	0,000	0,000
Student t	0,842	4,24	0,531	0,531
Clayton	2,384	–	0,748	0,000
Gumbel	2,587	–	0,000	0,693
Frank	9,152	–	0,000	0,000

- Barele arată distanța AIC, iar numerele de deasupra lor p-value-urile bootstrap ale testului de adecvare (tabelul complet în ▸ Anexă)
- Copula Student t este net superioară: $\hat{\nu} = 4{,}2$, $\hat{\lambda} = 0{,}53$ în ambele cozi
- Testul Rosenblatt (mai jos) respinge toate familiile: fiecare p-value este minimul posibil, $1/(B+1)$
- Statistica: t 0,082, Frank 0,365, Gaussiană 0,968, Clayton 1,24, Gumbel 1,42; Frank este a doua după adecvare, dar a patra după AIC

MFM_ch6_copula_banks

Inferența pentru parametrii copulelor (1/2): inversarea lui tau al lui Kendall

- **Inversarea lui** $\hat{\tau}$: $\hat{\tau}$ este o U-statistică, cu eroarea standard din proiecția Hoeffding
- Pentru $\hat{\theta} = g(\hat{\tau})$, eroarea standard se obține prin metoda delta (Genest & Rivest (1993))
  - g: inversa legăturii $\tau(\theta)$ din tabelul anterior
  - U-statistică: o medie pe toate perechile de observații
  - Copule eliptice: $\tau = \frac{2}{\pi} \arcsin \rho$ pentru *orice* ν, deci τ identifică ρ, niciodată ν
  - JPM–BAC: $\hat{\tau} = 0{,}641$ (SE 0,0065), deci $\hat{\rho}_\tau = \sin(\pi\hat{\tau}/2) = 0{,}845$ (SE 0,0055)
  - Estimarea CML: $\hat{\rho} = 0{,}842$ (SE 0,0053)

Aprofundare

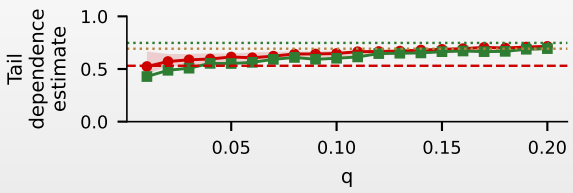
Inferența pentru parametrii copulelor (2/2): ranguri, adecvare și filtrare GARCH

- **CML: rangurile sînt estimate**, deci inversa hessianei este prea mică
- Sandwich-ul Genest, Ghoudi & Rivest (1995) adaugă termenii datorați rangurilor
  - Cu sandwich-ul, SE crește cu 60% pentru ρ al copulei Gaussiene (S&P 500–Euro Stoxx 50, săptămînal, de la 0,00863 la 0,01380)
  - Pentru JPM–BAC, SE crește cu 17% pentru ρ al copulei t (de la 0,004576 la 0,005334) și cu 1% pentru ν
- Nu tot plusul de 60% este prețul rangurilor
  - Dacă copula Gaussiană ar fi corectă, estimarea marginalelor prin ranguri ar înmulți SE cu $\sqrt{1+\rho^2}$ (Anexă)
  - La corelația săptămînală 0,78 factorul ar fi 1,27; simularea Monte Carlo la $\rho = 0{,}8$ dă 1,28
  - Factorul observat, 1,60, indică o copulă Gaussiană specificată greșit
  - Sandwich-ul rămîne valid și în acest caz (adecvarea: Seminarul B2)
- **După filtrarea GARCH** (Chen & Fan (2006)): CML pe rangurile reziduurilor estimate are aceeași limită ca pe inovațiile adevărate
  - Condiții: inovații i.i.d. cu copula C_θ și un GARCH corect specificat
  - Atunci sandwich-ul rămîne valid și, spre deosebire de DCC, nu este nevoie de corecția pasului 1 (Monte Carlo în Anexă)

Adecvarea: testul Rosenblatt

- Dacă $(U, V) \sim C_\theta$, atunci $E_1 = U$ și $E_2 = h(V \mid U) = \partial C_\theta(U, V)/\partial u$ (funcția de repartiție condiționată a lui V dat fiind U) sînt uniforme independente
- Statistica (Genest, Rémillard & Beaudoin (2009)): $S_n = n \int_{[0,1]^2} \left(D_n(e) - e_1 e_2\right)^2 de$
  - $e = (e_1, e_2) \in [0, 1]^2$
  - $D_n(e)$: proporția celor n perechi cu $E_1 \leq e_1$ și $E_2 \leq e_2$
  - $e_1 e_2$: aceeași proporție sub independență
  - $S_n \geq 0$, iar valorile mari înseamnă adecvare slabă
- p-value-ul prin bootstrap parametric, deoarece θ este estimat
  - Simulăm n perechi din $C_{\hat{\theta}}$, le transformăm din nou în pseudo-observații prin ranguri, reestimăm, recalculăm $S_n^{(b)}$
  - $p = (1 + \#\{S_n^{(b)} \geq S_n\})/(B + 1)$
  - Pentru JPM–BAC $B = 200$ (100 pentru Student t)
  - Cel mai mic p-value posibil este deci $1/201 \approx 0{,}005$ ($1/101 \approx 0{,}010$ pentru t)
- Pe reziduuri GARCH, Rémillard (2017) arată că testele bazate pe ranguri își păstrează limita și bootstrap-ul parametric se aplică
- Cu $T = 4\,202$ testul are putere mare împotriva abaterilor mici: o respingere nu indică ce caracteristică a dependenței lipsește din model

Dependența empirică în cozi: JPM și BAC



- $\hat{\lambda}_L(q) = \hat{C}(q,q)/q$ și $\hat{\lambda}_U(q)$ pentru q între 1% și 20%
- Banda: intervalul de 90% al aceluiași estimator pe date simulate din copula t estimată
- La $q = 5\%$: $\hat{\lambda}_L = 0{,}61$ și $\hat{\lambda}_U = 0{,}55$
- La $q = 1\%$: $\hat{\lambda}_L = 0{,}52$ și $\hat{\lambda}_U = 0{,}43$
- Cînd JPM are una dintre cele mai proaste 5% zile, BAC se află în propriile 5% cele mai proaste zile în aproximativ 61% din cazuri
- Lower tail-ul este în banda copulei t (0,57–0,65 la 5%): copula t descrie bine crahurile
- Upper tail-ul (0,55 la 5%) este sub banda copulei t: cîștigurile comune sînt mai slabe decît prezice modelul
- La $q = 1\%$ rămîn doar 42 de zile în coadă, deci estimarea este imprecisă

MFM_ch6_copula_banks

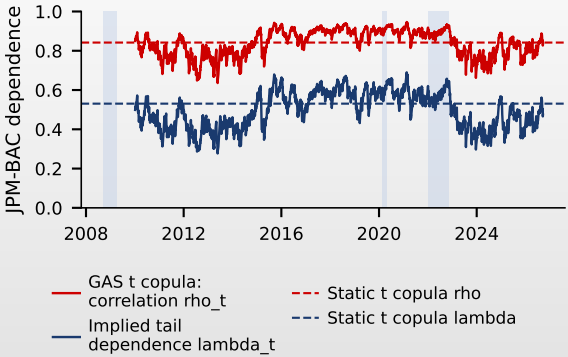
Semnificația asimetriei cozilor

- Schmidt & Stadtmüller (2006): $\hat{\lambda}_L = \frac{n}{k}\,\hat{C}_n\left(\frac{k}{n}, \frac{k}{n}\right)$, estimatorul din grafic cu $q = k/n$
  - n: volumul eșantionului
  - k: numărul de observații din coadă
  - $\hat{C}_n$: copula empirică
  - Un k mai mare scade varianța, dar crește deplasarea (condițiile în Anexă)
- $H_0 : \lambda_L(q) = \lambda_U(q)$ la un q fixat (probabilități la prag, nu limitele)
- Bootstrap pe perechile de reziduuri, cu rangurile recalculate, $B = 999$

q	k	$\hat{\lambda}_L - \hat{\lambda}_U$	interval de 95%, i.i.d.	interval de 95%, blocuri
5%	210	0,062	$[-0{,}014;\ 0{,}148]$	$[-0{,}014;\ 0{,}138]$
1%	42	0,095	$[-0{,}095;\ 0{,}286]$	$[-0{,}119;\ 0{,}286]$

- Varianta pe blocuri (bootstrap staționar, bloc mediu de 1,6 și 1,0 zile, regula Politis & White (2004)) permite dependența serială a tail indicator-ilor
- Intervalul la 1% este mai larg, conform compromisului deplasare–varianță
- Toate intervalele conțin zero: asimetria nu este semnificativă, deci copula t simetrică nu este contrazisă în cozi

O copulă t dinamică pentru JPM și BAC (1/2)



MFM_ch6_copula_inference

O copulă t dinamică pentru JPM și BAC (2/2)

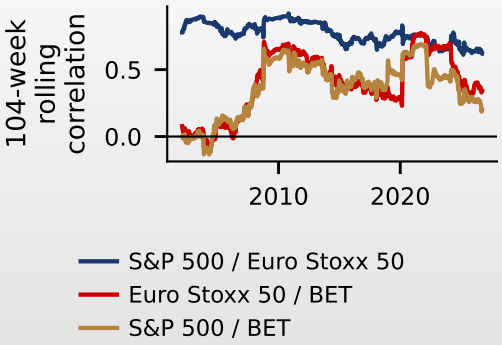
- Copula t GAS (generalised autoregressive score, Creal, Koopman & Lucas (2013)): $\rho_t = \tanh f_t$, $f_{t+1} = \omega + A\, s_t + B f_t$, pe aceleași pseudo-observații
- f_t: corelația transformată, pe toată axa reală; ω: constanta; $s_t = \partial \ln c(\hat{u}_t, \hat{v}_t; \rho_t, \nu)/\partial f_t$: scorul (scalare unitară); A: reacția la scor; B: persistența
- Estimări: $A = 0{,}025$, $B = 0{,}9926$, $\nu = 5{,}35$ (în copula statică $\nu = 4{,}24$)
- ρ_t variază între 0,64 (23 mai 2013) și 0,95 (18 februarie 2021); λ_t între 0,28 și 0,69, față de valoarea statică 0,53; benzile umbrite: toamna 2008 – martie 2009, februarie–aprilie 2020, ianuarie–octombrie 2022
- Cînd ρ variază în timp, $\hat{\nu}$ crește: o parte din dependența în cozi a copulei statice reflecta variația în timp a dependenței
- Statistica LR față de copula t statică: 245,5; sub $A = 0$, B nu este identificat, deci χ^2 nu se aplică și p-value-ul se obține prin bootstrap (Seminarul B6)
- Variația în timp este o explicație compatibilă cu respingerea tuturor familiilor statice

MFM_ch6_copula_inference

O lecție de prudență: copula Gaussiană și 2008

- Li (2000) a modelat momentele simultane ale falimentelor cu o copulă Gaussiană
  - Un singur parametru de corelație, calibrat pe spread-urile de piață
  - Evalua portofolii întregi de credite și a devenit standardul pentru tranșele de obligațiuni garantate cu datorii (CDO)
- Dependență asimptotică zero în cozi: pentru falimentele comune cele mai extreme dă probabilități mai mici decît modelele cu dependență în cozi calibrate pe aceleași date
- O corelație statică, calibrată în anii calmi: aceleași probleme evidențiate în acest capitol de Forbes–Rigobon și de DCC

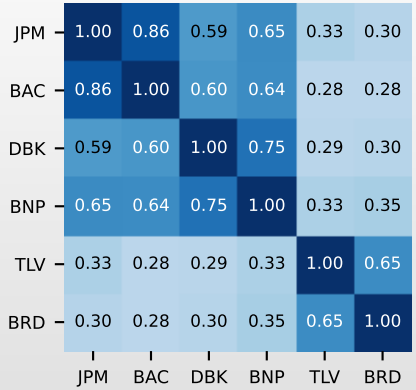
Acțiuni din SUA, zona euro și România, 2000–2026



- Întrebarea secțiunii: este piața românească tot mai integrată cu cele mari și se mai poate diversifica între sistemele bancare în crize?
- Corelații pe o fereastră mobilă de 104 săptămîni, din randamente săptămînale calculate cu închiderile de vineri, în zilele comune de tranzacționare
- Corelația Euro Stoxx 50–BET: 0,33 în 2000–2009, 0,45 în 2010–2019 și 0,61 din 2020
- Corelația S&P 500–Euro Stoxx 50 în aceleași perioade: 0,84, 0,78 și 0,70
- Corelația Euro Stoxx 50–BET pe fereastra mobilă: 0,31 la sfîrșitul lui 2007, 0,65 la sfîrșitul lui 2009, 0,29 la sfîrșitul lui 2019, 0,76 la sfîrșitul lui 2021, 0,35 în septembrie 2026
- Salturi în crize și revenire parțială după aceea: integrare sau distorsiunea de volatilitate Forbes–Rigobon? (Seminarul C2)

MFM_ch6_integration

Bănci: corelațiile randamentelor săptămînale, 2010–2026 (1/2)



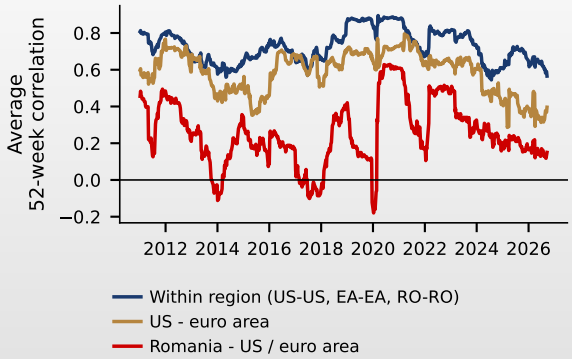
MFM_ch6_banks

Bănci: corelațiile randamentelor săptămînale, 2010–2026 (2/2)

- SUA: JPM și BAC
- Zona euro: DBK (Deutsche Bank) și BNP (BNP Paribas)
- România: TLV (Banca Transilvania) și BRD (BRD-Groupe Société Générale)
- 871 săptămîni, din 15 ianuarie 2010
- Alegerea: două dintre cele mai mari bănci listate din fiecare sistem, cu date continue din 2010
- Corelația din interiorul fiecărui bloc regional: 0,86 în SUA, 0,75 în zona euro și 0,65 în România
- Legăturile dintre regiuni sînt cele mai slabe pentru România: BNP–TLV 0,33, JPM–BRD 0,30
- Randamentele băncilor au factori comuni la nivel de țară: riscul suveran, dobînzile interne, reglementarea

MFM_ch6_banks

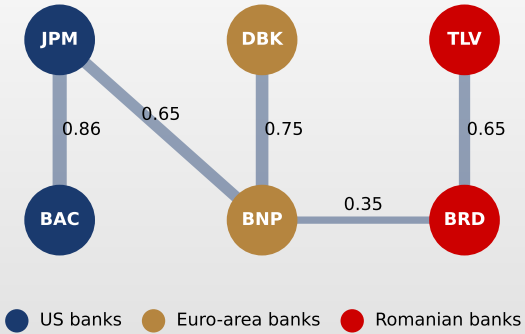
Corelațiile dintre bănci în timp



- Media corelațiilor pe perechi, pe 52 de săptămîni, ale randamentelor săptămînale: în interiorul regiunilor (în legendă: US: SUA, EA: zona euro, RO: România), între SUA și zona euro, între România și celelalte
- Media pe toată perioada: 0,73 în interiorul regiunilor, 0,59 între SUA și zona euro, 0,25 între România și celelalte
- În martie–iunie 2020, aceleași medii au fost 0,87, 0,69 și 0,56: într-un șoc global, legătura României a crescut de peste două ori
- Ultimele valori, în aceeași ordine: 0,57, 0,40 și 0,15
- Diversificarea între sisteme bancare funcționează în perioade normale și slăbește exact în evenimentele sistemice

MFM_ch6_banks

O rețea de corelații între bănci



- Arborele de acoperire minimă (Mantegna (1999)) pe $d_{ij} = \sqrt{2(1-\rho_{ij})}$: cele 5 legături cele mai puternice care conectează toate cele 6 bănci fără cicluri
- Muchiile: JPM–BAC (0,86); JPM–BNP (0,65); DBK–BNP (0,75); BNP–BRD (0,35); TLV–BRD (0,65)
- România este legată de restul rețelei prin BNP–BRD
- Capitolul 4 folosește $\sqrt{(1-\rho)/2}$, care diferă printr-un factor 2
- Ambele distanțe cresc cu $1-\rho$, deci arborele este același
- Arborele este neorientat și contemporan: nu identifică canalele de transmitere, ci sugerează doar ipoteze pentru măsurile de rețea din Capitolul 18 (literatura în ▸ Anexă)

MFM_ch6_banks

Studiu de caz (1/2): ce evenimente zguduie simultan toate piețele?

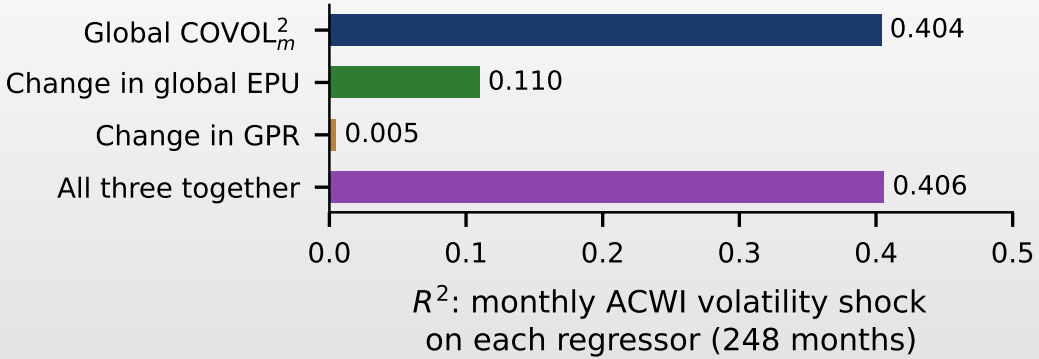
- Întrebările din Engle & Campos-Martins (2023)
  - ce evenimente modifică simultan volatilitățile aproape tuturor țărilor și claselor de active?
  - cît de mare este acest șoc comun?
- Mărimea zilnică a șocului comun este COVOL global (common volatility, volatilitatea comună)
- Ideea nouă: un DCC corect dă reziduuri e_t cu $E_{t-\mathbf{1}}(e_t e_t^\top) = I$, dar necorelat nu înseamnă independent: pătratele pot varia împreună
  - $\Psi_t = E_{t-\mathbf{1}}\left[(e_t^{\mathbf{2}} - \iota)(e_t^{\mathbf{2}} - \iota)^\top\right]$
  - e_t: vectorul celor N reziduuri DCC din ziua t
  - $e_t^{\mathbf{2}}$: pătratul lui, element cu element
  - ι: vectorul de unu
  - $E_{t-\mathbf{1}}$: media condiționată, dată fiind informația pînă la $t-1$
  - Elemente nenule în afara diagonalei, $\Psi_{ij,t} \neq 0$: pătratele șocurilor activelor i și j sînt mari în aceleași zile
  - Analogul transversal al modelului ARCH (autoregressive conditional heteroskedasticity, Capitolul 5: varianța de azi depinde de șocul de ieri la pătrat): pătrate corelate între active în aceeași zi, nu în timp
  - Herskovic, Kelly, Lustig & Van Nieuwerburgh (2016) documentează un asemenea factor în volatilitatea idiosincratică a acțiunilor americane

Aprofundare

Studiu de caz (2/2): un factor comun scalează toate variațiile

- Modelul: un singur factor comun x_t scalează varianța fiecărui reziduu
  - $e_{it} = \sqrt{s_i x_t + 1 - s_i}\,\varepsilon_{it}$, ε_{it} i.i.d. $\mathcal{N}(0,1)$, $x_t > 0$, $E_{t-\mathbf{1}}(x_t) = 1$
  - x_t: pătratul COVOL global din ziua t ($x_t > 1$: o zi cu șoc comun)
  - $s_i \in [0,1]$: încărcarea activului i, ponderea lui x_t în varianța sa condiționată $g_{it} = s_i x_t + 1 - s_i = 1 + s_i(x_t - 1)$
- Estimarea: sînt identificate doar produsele $s_i(x_t - 1)$, deci scara trebuie fixată printr-o normalizare
  - Încărcări egale $s_i = 1$: $\hat{x}_t = \frac{1}{N}\sum_i e_{it}^{\mathbf{2}}$, media transversală a pătratelor reziduurilor, pe scara variației reziduurilor
  - Exemplu: pătratele reziduurilor 4, 9, 1 și 4 într-o zi dau $\hat{x}_t = 4{,}5$
  - Încărcări diferite: estimare alternantă prin verosimilitate maximă, pe rînd pentru x_t (o secțiune transversală pe zi) și s_i (o serie temporală pe activ), cu $s^\top s = 1$ și media $x_t = 1$
  - Cu $s^\top s = 1$, încărcările sînt mărimi relative, nu proporții din variață (încărcări egale ar însemna $s_i = 1/\sqrt{N}$)
- Testul ξ: media pe zile și pe perechi a produselor $(e_{it}^{\mathbf{2}} - 1)(e_{jt}^{\mathbf{2}} - 1)$, standardizată; sub H_0: $\Psi_{ij} = 0$, $i \neq j$, are distribuția Normală standard
- Date: 47 de ETF-uri de țară (exchange-traded funds, fonduri tranzacționate la bursă) listate la NYSE (New York Stock Exchange), 2000–2021, și 23 de serii pe clase de active din SUA (detalii în Anexă)

Șocurile realizate față de indicii de știri (1/2)



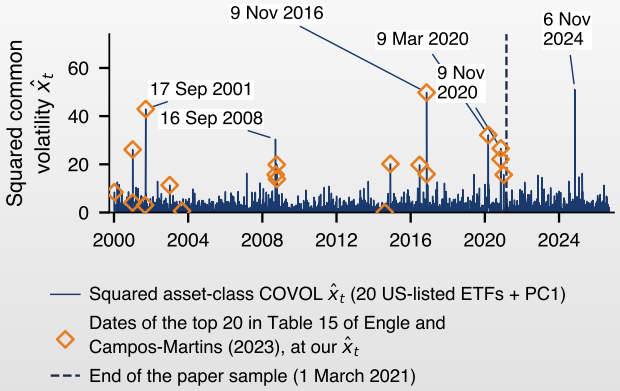
MFM_ch6_covol

Șocurile realizate față de indicii de știri (2/2)

- Date lunare, 248 de luni (tabelul 8 din Engle & Campos-Martins (2023)): regresăm șocul de volatilitate ACWI (MSCI All Country World Index) pe fiecare indice
  - Regresia pe COVOL_m^2, media lunară a lui $\hat{x}_t$ minus 1: $R^2 = 0{,}404$ (R^2: proporția de variață explicată)
  - Regresia pe variația EPU (economic policy uncertainty, incertitudinea politicii economice, Baker, Bloom & Davis (2016)): $R^2 = 0{,}110$
  - Regresia pe GPR (geopolitical risk, riscul geopolitic, Caldara & Iacoviello (2022)): $R^2 = 0{,}005$
  - Adăugînd ambii indici de știri la COVOL_m^2, R^2 crește doar la 0,406
- Zilele de vîrf din articol: 9 martie 2020 ($\hat{x}_t = 51{,}4$) și 24 iunie 2016 (Brexit)
- 28 aprilie 2020 este tot o zi de vîrf, dar cu randament mediu pozitiv (+2,33%)
  - COVOL măsoară mărimea șocului comun, nu semnul lui
  - Indicii de știri măsoară percepția riscului, iar COVOL șocurile reflectate efectiv în prețuri (tabelul evenimentelor în Anexă)

MFM_ch6_covol

COVOL pe clase de active cu ETF-urile cursului, 2000–2026 (1/2)



MFM_ch6_covol

COVOL pe clase de active cu ETF-urile cursului, 2000–2026 (2/2)

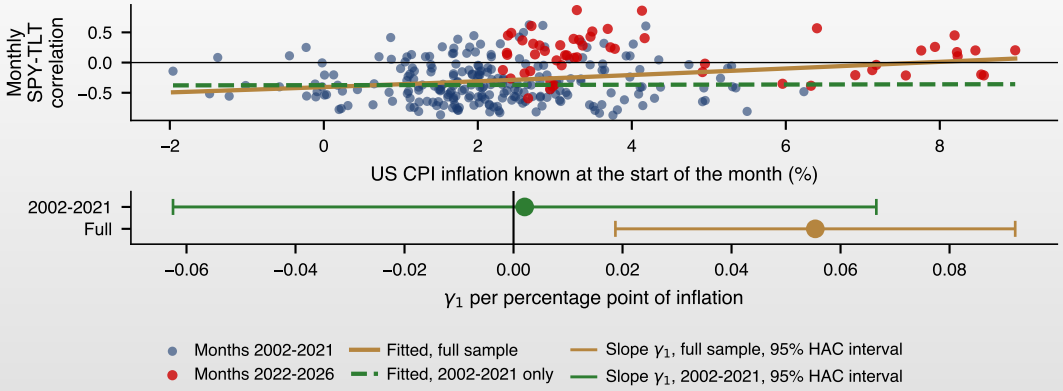
- 20 de ETF-uri listate în SUA și PC1 (prima componentă principală), 4 ianuarie 2000 – 18 septembrie 2026, 6 717 zile
- Modelul: media AR(1) (autoregresivă de ordinul 1) cu PC1, varianța GARCH(1,1), apoi estimarea alternantă (13 iterații)
- Romburile: cele 20 de date din tabelul 15 din Engle & Campos-Martins (2023), plasate la valoarea replicării noastre din acea zi (pentru 11 și 14 septembrie 2001, piața fiind închisă, prima zi de tranzacționare, 17 septembrie)
- Zilele de vîrf pînă la 1 martie 2021:
  - 9 noiembrie 2016 ($\hat{x}_t = 49{,}8$): alegerile din SUA din 2016
  - 17 septembrie 2001 ($\hat{x}_t = 42{,}9$): redeschiderea după 11 septembrie
  - 9 martie 2020 ($\hat{x}_t = 32{,}2$): crahul din pandemia COVID-19
- 13 dintre cele mai mari 20 de zile ale replicării noastre dinainte de martie 2021 apar printre cele 20 de date din tabelul 15
- Cu $s^\top s = 1$ și media $\hat{x}_t = 1$, scara depinde de panel
- Valorile replicării nu se compară cu cele din articol: comparăm clasamente, nu niveluri
- Cea mai mare valoare din tot eșantionul: 6 noiembrie 2024 ($\hat{x}_t = 51{,}1$), ziua de după alegerile din SUA din 2024
- Randamentul mediu al ETF-urilor în acea zi a fost 0,95%: un șoc comun mare într-o zi de creștere

MFM_ch6_covol

O întrebare deschisă: va rămîne pozitivă corelația acțiuni–obligațiuni?

- Întrebarea: este corelația pozitivă acțiuni–obligațiuni de după 2022 un regim durabil, guvernat de inflație, și poate fi prognozată?
- Campbell, Pflueger & Viceira (2020): semnul corelației urmează relația inflație–producție și regimul politicii monetare; Molenaar, Sénéchal, Swinkels & Wang (2024) extind analiza la mai multe țări și la o istorie lungă
- Faptele: corelația SPY–TLT este pozitivă în 81% din zile din ianuarie 2022, iar testul Wied–Krämer–Dehling datează ruptura pe 3 august 2020
- Ipoteza: $z_m = \operatorname{artanh} \rho_m = \gamma_{\mathbf{0}} + \gamma_{\mathbf{1}} \pi_{m-\mathbf{2}} + u_m$, cu ρ_m corelația realizată lunară, π inflația anuală CPI (consumer price index) din SUA și u_m eroarea
- $H_{\mathbf{0}}$: $\gamma_{\mathbf{1}} = 0$, față de $H_{\mathbf{1}}$: $\gamma_{\mathbf{1}} > 0$, cu statistica t HAC
- Ipoteza este infirmată dacă $\gamma_{\mathbf{1}} \approx 0$ în perioade în care inflația a variat, dar regimul nu
- Bucla: un asistent AI schițează harta literaturii, ipotezele concurente, codul, un plan de robustețe și o critică de referent; cercetătorul verifică fiecare DOI, replică întîi cifrele capitolului și fixează planul înainte de prima rulare (prompturile în ▸ Anexă)

Mini-studiu de caz: inflația și corelația acțiuni–obligațiuni (1/2)



MFM_ch6_ai_inflation

Mini-studiu de caz: inflația și corelația acțiuni–obligațiuni (2/2)

- Corelația lunară SPY–TLT din randamente zilnice față de inflația cunoscută la începutul lunii m: CPI pentru luna $m-1$ apare abia la mijlocul lunii m, deci ultima valoare cunoscută este $\pi_{m-\mathbf{2}}$
- Folosim versiunea curentă a CPI, deci un test retrospectiv, nu în timp real
- Pe tot eșantionul (287 de luni): $\hat{\gamma}_{\mathbf{1}} = 0{,}055$ pe punct procentual de inflație, SE HAC 0,019, $t = 2{,}96$, $R^{\mathbf{2}} = 0{,}047$
- Corelația medie ρ este $-0{,}12$ în lunile cu inflația peste 3% (89 de luni) și $-0{,}30$ în celelalte luni
- Numai pe 2002–2021 (232 de luni, dintre care 53 cu inflația peste 3%): $\hat{\gamma}_{\mathbf{1}} = 0{,}002$, $t = 0{,}06$
- Deci panta estimată pe tot eșantionul este determinată de episodul de după 2022
- Pe 2002–2021 criteriul de infirmare de pe slide-ul cu întrebarea deschisă este îndeplinit: inflația a variat (53 de luni peste 3%), iar $\hat{\gamma}_{\mathbf{1}} \approx 0$
- Relația apare numai împreună cu schimbarea de regim din 2022, iar o singură schimbare nu separă nivelul inflației de regimul politicii (Campbell, Pflueger & Viceira (2020))

MFM_ch6_ai_inflation

Verificările cercetătorului și un punct de plecare pentru proiect

Verificări înaintea oricărei afirmații

- Look-ahead bias: calendarul publicărilor și versiunile datelor (decalajul tratează întîrzierea publicării, nu revizuirile)
- Calendare: aliniem prețurile pe zilele comune de tranzacționare înainte de a calcula randamentele
- Regresor persistent și puține regimuri: folosim subeșantioane, laguri HAC lungi și placebo cu serii persistente simulate
- Distorsiunea de volatilitate: control pentru volatilitatea realizată
- Testare multiplă: fixăm dinainte măsurile și ferestrele
- Referințe inventate: un DOI care nu duce la nicio lucrare este eliminat și notat în `AI_ERRORS.md`

Punct de plecare pentru proiect

- Prognozează mai bine out-of-sample corelația SPY–TLT un DCC a cărui țintă depinde de inflație și de dobînda de politică monetară decît DCC-ul simplu?
- Replicăm întîi: $a + b = 0{,}986$, $\bar{Q}_{12} = -0{,}25$ și panta $\hat{\gamma}_1 = 0{,}055$
- Livrabile: o pre-înregistrare de o pagină, codul pe datele de piață ale cursului plus CPI, o comparație Diebold–Mariano și o autocritică de referent
- Declarația folosirii AI, în `AI_USE.md`

Lista de decizie: întrebare, estimator, incertitudine, eșec

Întrebarea	Estimatorul	Incertitudinea	Eșuează cînd
S-a schimbat o corelație?	Pearson pe prețuri aliniate	HAC prin metoda delta, bootstrap pe blocuri	Fisher cu volatility clustering; date zilnice între fusuri orare
Covarianța pentru riscul de azi?	EWMA, DCC	bootstrap pe ambii pași	ținta $\bar{Q}$ se modifică odată cu regimul
Cînd a avut loc ruptura?	Wied–Krämer–Dehling pe reziduuri GARCH	limita punții browniene	reziduuri GARCH estimate (p-value aproximativ); variațe nemodelate
Contagion?	Forbes–Rigobon ρ^*	bootstrap staționar, δ estimat	un șoc comun sau legătură inversă
Extreme comune?	copulă pe pseudo-observații GARCH	sandwich de rang, bootstrap parametric	copula Gaussiană ($\lambda = 0$), copulă statică cînd dependența variază în timp

- Urmează: Capitolul 7 transformă covariațele DCC și copulele simulate în VaR și ES de portofoliu

Verificarea înțelegerii

- De ce este prea îngust intervalul Fisher pentru corelația SPY–TLT pe date zilnice și ce două caracteristici ia în calcul intervalul HAC?
- De ce este corelația din aceeași zi dintre SPY și Euro Stoxx 50 deplasată spre zero și cum reduc randamentele pe 2 zile sau săptămînale această deplasare?
- Ce sursă de incertitudine ignoră erorile standard din pasul 2 al DCC și cum o readuce bootstrap-ul pe ambii pași?
- O corelație din criză este mai mare decît cea din perioada calmă: ce trebuie să calculați înainte de a numi creșterea contagion și ce ipoteză poate face corecția excesivă?
- Cinci copule au același tau al lui Kendall, $\tau = 0{,}5$: de ce pot avea totuși probabilități diferite ale crahurilor comune?

Pentru aprofundare — cursuri, cod și date

Cursuri avansate pe quantinar.com

- Measuring Statistical Risk
- Multivariate Statistical Analysis
- Minimum Spanning Tree
- FRM: Financial Risk Meter

Cod, date și manuale

- Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_06
- Manuale: Franke, Härdle & Hafner (2019); Härdle & Simar (2019); Nelsen (2006)

Înapoi

Inferența pentru o corelație, metoda delta

- $\hat{\rho} = g(\hat{m})$, unde $\hat{m}$ este media empirică a lui $m_t = (x_t,\ y_t,\ x_t^2,\ y_t^2,\ x_t y_t)$, iar g funcția care transformă aceste cinci momente în corelație; ∇g: gradientul lui g
- Metoda delta: $\sqrt{T}(\hat{\rho} - \rho) \to N\big(0,\ \nabla g^\top \Omega\, \nabla g\big)$, unde Ω este covarianța pe termen lung a lui m_t, estimată HAC cu nucleu Bartlett și L laguri (Newey & West (1987))
- Forma echivalentă cu funcția de influență, $\hat{\rho} - \rho \approx \frac{1}{T}\sum_t \psi_t$, este cea din textul principal
- Condiții: staționaritate, momente finite de ordin $4+\delta$ pentru (x_t, y_t) și dependență slabă (mixing); cu momente de ordinul patru infinite limita Normală nu mai este valabilă
- Intervalul HAC, calculat pe scara Fisher: $\tanh\big(\operatorname{artanh}\hat{\rho} \pm 1{,}96\,\widehat{\mathrm{SE}}_{\mathrm{HAC}}/(1-\hat{\rho}^2)\big)$, unde $\widehat{\mathrm{SE}}_{\mathrm{HAC}} = \sqrt{\nabla\hat{g}^\top \hat{\Omega}\, \nabla\hat{g}/T}$
- Intervalul Fisher clasic înlocuiește $\widehat{\mathrm{SE}}_{\mathrm{HAC}}/(1-\hat{\rho}^2)$ cu $1/\sqrt{T-3}$
- Ultima fereastră de 252 de zile (seria din 5 în 5 zile) se încheie pe 17 septembrie 2026: $\hat{\rho} = 0{,}245$, intervalul Fisher [0,13; 0,36], intervalul HAC [0,07; 0,41]; cel mai mare raport dintre lățimea HAC și cea Fisher: 2,02

înapoi

Modelele VEC și BEKK

- **VEC** (Bollerslev, Engle & Wooldridge (1988)): $\text{vech}(H_t) = c + A\,\text{vech}(r_{t-1}r_{t-1}^\top) + B\,\text{vech}(H_{t-1})$; c: vector constant; A, B: matrice pătrate de parametri
- VEC: caracterul pozitiv definit nu este garantat
- VEC: numărul de parametri este $N(N+1)/2 \cdot [1 + N(N+1)]$
- **BEKK** (Engle & Kroner (1995)): $H_t = CC^\top + A^\top r_{t-1}r_{t-1}^\top A + B^\top H_{t-1}B$; C: matrice inferior triunghiulară $N \times N$; A, B: matrice $N \times N$ complete
- BEKK: pozitiv definită prin construcție dacă $CC^\top$ este pozitiv definită
- BEKK: $N(N+1)/2 + 2N^2$ parametri, greu de interpretat, iar verosimilitatea este plată în dimensiuni mari
- DCC păstrează GARCH univariat pentru fiecare variantă și adaugă doi parametri de corelație: $3N + 2$ în total

Înapoi

Estimatori în doi pași, covariança corectă

- Sistemul ecuațiilor de estimare: $\sum_t s_{1t}(\theta_1) = 0$ (pasul 1: GARCH și, cu correlation targeting, vech $\bar{Q}$) și $\sum_t s_{2t}(\theta_1, \theta_2) = 0$ (pasul 2, $\theta_2 = (a, b)$)
- s_{jt}: scorul pasului j în ziua t; $A_{jk} = \mathbb{E}\left[\partial s_{jt}/\partial \theta_k^\top\right]$, iar A_{21} măsoară cît reacționează scorul corelației la parametrii GARCH
- Newey & McFadden (1994), Secțiunea 6: $\sqrt{T}(\hat{\theta}_2 - \theta_2) \to N(0, V_2)$,
  $V_2 = A_{22}^{-1} \mathbb{E}\left[(s_{2t} - A_{21}A_{11}^{-1}s_{1t})(s_{2t} - A_{21}A_{11}^{-1}s_{1t})^\top\right] A_{22}^{-1\top}$
- Erorile standard din pasul 2 păstrează doar s_{2t}: omit $A_{21}A_{11}^{-1}s_{1t}$, eroarea de estimare GARCH transmisă în pasul 2
- Cu momente condiționate corecte, scorurile sînt diferențe de martingal și termenul din mijloc este variança lor; altfel folosim versiunea pe termen lung (HAC)
- Engle & Sheppard (2001) derivă V_2 pentru DCC
- O alternativă simplă este bootstrap-ul întregii proceduri în doi pași (slide-ul următor)

Înapoi

Bootstrap pe ambii pași DCC

- Bootstrap parametric pe reziduuri, $B = 199$: decorelăm reziduurile cu factorul Cholesky al lui R_t, le reeșantionăm și simulăm inovații DCC cu $(\hat{a}, \hat{b}, \bar{Q})$
- Doar pasul 2: reestimăm (a, b) pe inovațiile simulate
- Ambii pași: reconstruim randamentele cu GARCH-ul estimat, reestimăm GARCH, $\bar{Q}$ și (a, b) pe aceleași inovații
- SPY–TLT: SE($\hat{b}$) din hessiana pasului 2 este 0,0084, față de 0,0077 din bootstrap-ul pe ambii pași (+8%); bootstrap-ul doar pe pasul 2 dă 0,0077
- Bootstrap-ul sub CCC pentru testul LR folosește același mecanism cu $a = b = 0$: inovații cu corelație constantă, randamente GARCH simulate, ambii pași reestimați

Înapoi

Robert Engle și modelul DCC



Robert F. Engle la conferința Western Economic Association International, Santiago, 2017

Foto: Econterms (2017); CC BY-SA 4.0; Wikimedia Commons

- Premiul Nobel pentru științe economice 2003 pentru modelele ARCH (Capitolul 5)
- Engle (2002): „Dynamic Conditional Correlation"
  - Păstrează flexibilitatea GARCH univariat pentru fiecare variantă
  - Descrie evoluția corelațiilor printr-o ecuație simplă, ai cărei parametri pot fi estimați
- Rafinare: DCC-ul corectat al lui Aielli (2013), care face din $\bar{Q}$ o țintă consistentă

Înapoi

Teste de contagion dincolo de Forbes–Rigobon

- Corsetti, Pericoli & Sbracia (2005): cu un factor comun, corecția Forbes–Rigobon este excesivă și deplasează testul spre „niciun contagion"
- Autorii propun o versiune bazată pe un model factorial
- Rigobon (2003): identificare prin heteroscedasticitate
- Schimbarea variației între regimuri identifică coeficientul structural β, o idee de tip variabile instrumentale
- Cu δ reestimat în fiecare extragere bootstrap, concluzia pentru 2008 se menține: niciun contagion ($p = 0{,}62$ pentru BET, $p = 0{,}98$ pentru Euro Stoxx 50)
- Critica factorului comun rămîne valabilă (Seminarul A1, B3)

înapoi

Densitățile și construcția copulelor

- Densitatea Gaussiană: $c = \frac{1}{\sqrt{1-\rho^2}} \exp\Big(- \frac{\rho^2(x^2+y^2)-2\rho xy}{2(1-\rho^2)} \Big)$, $x = \Phi^{-1}(u)$, $y = \Phi^{-1}(v)$
- Este simetrică, fără dependență în cozi pentru $|\rho| < 1$
- Student t: $\lambda_L = \lambda_U = 2\, t_{\nu+1}\big(- \sqrt{(\nu+1)(1-\rho)/(1+\rho)}\big)$, mare pentru ν mic
- Copula t extinde copula Gaussiană cu un singur parametru, ν, păstrînd matricea de corelație
- Generatorii arhimedieni φ din $C(u,v) = \varphi^{-1}(\varphi(u) + \varphi(v))$
  - Clayton: $\varphi(t) = (t^{-\theta} - 1)/\theta$
  - Gumbel: $\varphi(t) = (-\ln t)^{\theta}$
  - Frank: $\varphi(t) = -\ln \frac{e^{-\theta t}-1}{e^{-\theta}-1}$
- Cozi asimetrice: Clayton pentru crahurile comune ale randamentelor, Gumbel pentru extremele comune ale pierderilor
- Rotirea cu 180° $\bar{C}(u,v) = u + v - 1 + C(1-u, 1-v)$ transferă dependența în coada opusă

Înapoi

Estimările copulelor pentru JPM și BAC, tabelul complet

Copula	$\hat{\theta}$ sau $\hat{\rho}$	$\hat{\nu}$	ℓ	ΔAIC	λ_L	λ_U	p adecvare
Gaussiană	0,833	–	2 486,0	309,3	0,000	0,000	0,005
Student t	0,842	4,24	2 641,7	0,0	0,531	0,531	0,010
Clayton	2,384	–	2 116,7	1 048,0	0,748	0,000	0,005
Gumbel	2,587	–	2 412,2	456,9	0,000	0,693	0,005
Frank	9,152	–	2 390,8	499,8	0,000	0,000	0,005

- CML pe pseudo-observațiile reziduurilor GARCH
- ΔAIC: distanța față de cel mai bun model
- p de adecvare din testul Rosenblatt cu bootstrap parametric: $0{,}005 = 1/(B+1)$ cu $B = 200$ (copula t: $B = 100$, minimul 0,010), deci toate familiile sînt respinse la limita bootstrap-ului

înapoi

Estimatorii de rang și precizia lor (1/2)

- $\hat{\tau}$ este o U-statistică; proiecția Hoeffding dă $\sqrt{n}(\hat{\tau} - \tau) \to N\big(0,\ 16\mathrm{Var}[2C(U,V) - U - V]\big)$
- Estimare: $\widehat{\mathrm{SE}}(\hat{\tau}) = 4\,\mathrm{sd}\big(2\hat{C}_n(\hat{U}_i, \hat{V}_i) - \hat{U}_i - \hat{V}_i\big)/\sqrt{n}$
- Pentru estimatorii prin inversare $\hat{\theta} = g(\hat{\tau})$, SE se obține prin metoda delta (Genest & Rivest (1993))
- Estimatorul prin inversarea lui $\hat{\tau}$ este aproape la fel de precis ca CML pentru ρ (JPM–BAC: SE 0,0055 față de 0,0053) și oferă o valoare inițială robustă pentru maximizarea verosimilității

Înapoi

Estimatorii de rang și precizia lor (2/2)

- Sandwich-ul CML (Genest, Ghoudi & Rivest (1995)): $\sqrt{n}(\hat{\theta} - \theta) \to N(0,\, A^{-1}\Sigma A^{-1})$; A: informația Fisher a copulei
- $\Sigma = \mathrm{Var}\big[\dot{\ell}_\theta(U,V) + W_1(U) + W_2(V)\big]$, unde $\dot{\ell}_\theta$ este scorul lui $\ln c$
- $W_1(u) = \int\!\!\int 1\{u \le u'\}\, \partial_u \dot{\ell}_\theta(u',v')\, dC(u',v')$: corecția pentru estimarea marginalelor prin ranguri; W_2: analog pentru v
- Copula Gaussiană: varianța $(1-\rho^2)^2$ pentru CML, față de $(1-\rho^2)^2/(1+\rho^2)$ cu marginale cunoscute
- S&P 500–Euro Stoxx 50 săptămînal, copula Gaussiană: SE 0,0086 din inversa hessianei, față de 0,0138 din sandwich
- Raportul 1,60 depășește $\sqrt{1+\rho^2} \le \sqrt{2}$: restul vine din specificarea greșită a copulei Gaussiene, pe care sandwich-ul o captează
- JPM–BAC, copula t (inversa hessianei față de sandwich): pentru ρ, 0,0046 față de 0,0053; pentru ν, 0,359 față de 0,364

Chen și Fan (2006), filtrarea GARCH și limita

- Modelul: $r_{it} = \mu_i + \sigma_{it}\varepsilon_{it}$ cu σ_{it} GARCH
- Inovațiile $(\varepsilon_{1t}, \varepsilon_{2t})$ i.i.d. cu copula C_θ
- Chen & Fan (2006): CML pe rangurile reziduurilor *estimate* $\hat{\varepsilon}_{it}$ are aceeași distribuție limită ca CML pe rangurile inovațiilor adevărate ε_{it}
- Monte Carlo: 500 eșantioane, $T = 2\,000$, copulă Gaussiană $\rho = 0{,}8$, inovații Student t(5), GARCH ca cel estimat pentru JPM și BAC
  - Abaterea standard a lui $\hat{\rho}$ în simulări: 0,0081 cu inovațiile adevărate și 0,0082 cu reziduurile GARCH
  - Media erorilor standard estimate: 0,0081 pentru sandwich și 0,0063 pentru inversa hessianei

Înapoi

Dependența neparametrică în cozi, condiții

- Schmidt & Stadtmüller (2006): estimatorul $\hat{\lambda}_L$ din textul principal este consistent și asimptotic Normal dacă $k \to \infty$, $k/n \to 0$, copula de coadă există și este îndeplinită o condiție de ordinul doi pentru deplasare ($\sqrt{k}\, A(n/k) \to 0$, $A(\cdot)$ viteza cu care $C(q,q)/q$ se apropie de λ_L)
- Bootstrap-ul i.i.d. al perechilor de reziduuri presupune o copulă statică a inovațiilor
- Bootstrap-ul staționar pe blocuri păstrează dependența serială a diferenței $1\{U \le q,\, V \le q\} - 1\{U > 1-q,\, V > 1-q\}$, a cărei medie împărțită la q estimează $\lambda_L - \lambda_U$
- Lungimea medie a blocului după regula automată a lui Politis & White (2004), aplicată tail indicator-ului
- $B = 999$ extrageri, rangurile recalculate la fiecare extragere

Înapoi

Dependența în dimensiuni mari și în timp

- DCC pentru N mare: verosimilitatea completă este lentă și deplasată
- Remedii: verosimilitate compusă pe perechi de active (Pakel, Shephard, Sheppard & Engle (2021)) și DCC-NL, shrinkage neliniar al țintei $\bar{Q}$ (Engle, Ledoit & Wolf (2019); shrinkage-ul din Capitolul 4)
- Construcțiile de tip vine (vine copulas, Aas, Czado, Frigessi & Bakken (2009)): $d(d-1)/2$ copule bivariate, unele condiționate, în arbori imbricați, fiecare cu propria familie și propriile cozi
- Copule arhimediene ierarhice (Okhrin, Okhrin & Schmid (2013)): grupuri imbricate după tăria dependenței, de exemplu bănci într-o țară și țări într-o regiune
- Copule dinamice: parametrii ghidați de scor (Creal, Koopman & Lucas (2013)) se extind la multe active prin copule factoriale
- Oh & Patton (2018) măsoară riscul sistemic variabil în timp în spread-urile CDS (credit default swap)
- Copule condiționate: Patton (2006)

Înapoi

De la corelații la riscul sistemic

- Rețelele de corelații sînt primul pas spre măsurile de risc sistemic din Capitolul 18
  - Conectivitate din cauzalitate Granger: Billio, Getmansky, Lo & Pelizzon (2012)
  - Indici de spillover din descompunerea variației: Diebold & Yilmaz (2009)
  - Conectivitate prin regresii cuantilice: CoVaR, Adrian & Brunnermeier (2016)
- Șocurile petroliere și piața de acțiuni din SUA: Kilian & Park (2009)
- Rețelele de corelații moștenesc toate problemele corelațiilor: neliniaritate, variație în timp, cozi

Înapoi

COVOL: date și estimare

- **Modelul** (ec. 8–11 din Engle & Campos-Martins (2023)): pentru $i \neq j$, $\Psi_{ij,t} = s_i s_j v_t$, $v_t = \mathrm{Var}_{t-\mathbf{1}}(x_t)$, deci Ψ are un singur factor, iar prima lui componentă principală dă valorile inițiale (ec. 12–13)
  - e_{it}: reziduul standardizat al activului i; $\Psi_{ij,t} = \mathrm{Cov}_{t-\mathbf{1}}(e_{it}^{\mathbf{2}}, e_{jt}^{\mathbf{2}})$
  - Încărcări egale (înainte de normalizarea $s^\top s = 1$): $g_{it} = x_t$, iar media transversală $\hat{x}_t = \frac{\mathbf{1}}{N} \sum_i e_{it}^{\mathbf{2}}$ din textul principal este estimatorul de verosimilitate maximă (ec. 17)
- **Estimarea** (Secțiunea 5.3): maximizăm $-\frac{\mathbf{1}}{\mathbf{2}} \sum_{i,t} \left[\ln g_{it} + e_{it}^{\mathbf{2}} / g_{it} \right]$, $g_{it} = s_i x_t + 1 - s_i$, alternînd x_t și s_i pînă la convergență
  - După fiecare pas: $s^\top s = 1$, media lui x_t egală cu 1 (Observația 2)
  - Testul ξ (ec. 27): media standardizată a produselor $(e_{it}^{\mathbf{2}} - 1)(e_{jt}^{\mathbf{2}} - 1)$ pe cele $N(N-1)/2$ perechi, $\mathcal{N}(0,1)$ sub $H_{\mathbf{0}}$
- **Date** (Secțiunea 7.1, tabelul B.1): randamente logaritmice zilnice în USD ale celor 47 de ETF-uri de țară listate la NYSE, 2 iunie 2000 – 1 martie 2021
- Aceeași oră de închidere, deci fără asincronism
- Panel neechilibrat
  - Media: AR(1) plus doi factori, ACWI și PC1 a randamentelor ETF-urilor
  - Variațele: GARCH(1,1)
  - COVOL estimat pe cele 47 de serii de reziduuri și pe cei doi factori
  - În plus: 23 de serii pe clase de active din SUA (Secțiunea 9) și simulări Monte Carlo pentru estimator și pentru test (Secțiunile 5.4, 6.1)

Înapoi

COVOL: rezultatele principale

Ziua	$\hat{x}_t$	$\bar{r}_t$ (%)	Evenimentul (eticheta din articol)
9 martie 2020	51,416	−9,650	COVID-19: Italia în carantină; războiul prețului petrolului
24 iunie 2016	49,190	−7,270	Brexit
5 august 2019	39,457	−2,574	Războiul comercial: China își devalorizează moneda
28 aprilie 2020	38,883	2,334	COVID-19: vînzări masive de acțiuni tehnologice
17 septembrie 2001	30,077	−8,630	NYSE se redeschide după 11 septembrie

$\bar{r}_t$: randamentul mediu al ETF-urilor de țară. Tabelul arată primele cinci dintre cele mai mari douăzeci de valori din tabelul 6 din Engle & Campos-Martins (2023)

- Încărcări (tabelul 7, normalize prin $s^\top s = 1$, deci mărimi relative, nu proporții din varianță): cele mai mari le au PC1 (0,261) și ACWI (0,250)
- Printre țări: Franța 0,217 și Spania 0,200, față de Noua Zeelandă 0,065 și Polonia 0,080
- Factorii au încărcări mai mari decît componentele idiosincratice, deci corelațiile cresc odată cu COVOL (ec. 41)
- Regresia pătratului reziduului ACWI pe $\text{COVOL}_m^{\mathbf{2}}$ (media lunară a lui $\hat{x}_t$ minus 1): coeficientul 0,326 (SE 0,025), $R^{\mathbf{2}} = 0{,}404$ (tabelul 8)
- Corelația medie pe perechi de ETF-uri crește cu 0,053 pentru fiecare unitate de $\text{COVOL}_m^{\mathbf{2}}$ (SE 0,009, tabelul 10, coloana 4)
- Regresia variației VIX (indicele Cboe al volatilității implicite a S&P 500) pe $\text{COVOL}_m^{\mathbf{2}}$: coeficientul 4,034 (SE 0,249), $R^{\mathbf{2}} = 0{,}517$ (tabelul 12)

Înapoi

COVOL: protocolul replicării

- **Replicare**: versiunea pe clase de active (Secțiunea 9) cu ETF-urile listate în SUA din datele de piață ale cursului, care se închid toate la aceeași oră
- ETF-urile: 11 sectoriale, Russell 1000 Growth și Value, Russell 2000, piețele dezvoltate și emergente din afara SUA, aur, obligațiuni de stat pe termen lung, obligațiuni corporative, petrol
- Un singur factor, PC1, pe un panel neechilibrat
- $\hat{x}_t$ prin ec. 17, apoi iterația din Secțiunea 5.3
- Testul ξ înainte și după împărțirea lui e_{it}^2 la $\hat{g}_{it}$ (Secțiunea 7.2)
- Tabelul 15 din articol plasează 9 noiembrie 2016 (43,04) și 9 martie 2020 (40,47) între primele patru zile
- Dolarul și împărțirea Russell 2000 pe creștere/valoare nu sînt în datele cursului

Înapoi

COVOL: limitele și datele de după 2021

- Limite menționate de autori: după împărțirea la $\hat{g}_{it}$ pătratele sînt încă corelate, posibil un al doilea factor (Secțiunea 7.2); COVOL multifactorial rămîne deschis (Secțiunea 9)
- Cu $s^\top s = 1$ încărcările scad cînd N crește: R_s^2 (potrivirea dintre încărcările estimate și cele adevărate) este 0,640 pentru $N = 50$, $T = 1000$, față de 0,924 pentru $N = 10$ (tabelul 2)
- Testul pierde putere cînd încărcările diferă, deci autorii recomandă $T \geq 1000$
- După eșantionul articolului: 6 noiembrie 2024 ($\hat{x}_t = 51{,}1$), cea mai mare valoare din tot eșantionul
- 3 aprilie 2025 ($\hat{x}_t = 16{,}2$, randamentul mediu $-3{,}67\%$), după anunțarea taxelor vamale ale SUA; 10 noiembrie 2022 ($\hat{x}_t = 15{,}4$, $+4{,}56\%$), cînd inflația din SUA a ieșit sub așteptări
- Întrebare deschisă (Seminarul C3): au alegerile, taxele vamale și știrile despre inflație un singur factor comun?
- Întrebare deschisă: explică COVOL_m^2 corelațiile DCC lunare și după includerea variației VIX?

Bucla descoperirii, prompturi reutilizabile (1/2)

- Instrumentele sînt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și motoare de căutare a literaturii științifice (Semantic Scholar, Elicit, Google Scholar)
- **Literatura**: *„Listează studiile publicate după 2015 despre determinanții corelației acțiuni–obligațiuni, cu DOI, eșantion, măsura corelației, strategia de identificare și estimarea principală."*
  - Verificăm în Crossref fiecare DOI și verificăm estimarea în articol, nu în rezumat
- **Ipoteze**: *„Dă explicații concurente pentru schimbarea de semn din 2022 (nivelul inflației, regimul politicii monetare, un șoc al primei de termen, un episod izolat de înăsprire a politicii monetare) și ce implică fiecare pentru ρ înainte de 2022 și out-of-sample."*
- **Date și cod**: *„Scrie cod Python care aliniază prețurile ajustate SPY și TLT din datele de piață ale cursului pe zilele comune de tranzacționare, calculează corelațiile realizate lunare și adaugă inflația CPI din SUA publicată înainte de începutul fiecărei luni."*
  - Replicăm întîi corelația SPY–TLT medie: $-0{,}40$ în 2002–2021 și $0{,}11$ în 2022–2026

Înapoi

Bucla descoperirii, prompturi reutilizabile (2/2)

- **Robustețe**: *„Scrie un plan pre-înregistrat: subeșantionul de dinainte de 2022, inflația de bază în loc de cea totală, randamente săptămînale în loc de zilnice, DCC în loc de corelația realizată, control pentru volatilitatea realizată, lag HAC 12."*
  - Placebo: înlocuim π cu serii random walk simulate, de aceeași persistență
  - Un regresor persistent poate da statistici t mari din întîmplare
- **Critica**: *„Joacă rolul unui referent: este γ_1 identificat de un singur episod și l-ar explica distorsiunea de volatilitate Forbes–Rigobon? Indică testele care ar evidenția fiecare dintre aceste probleme."*
- **Raportul**: fiecare măsură a inflației, fereastră și frecvență încercată
- Estimările pe subeșantioane, alături de cele pe tot eșantionul
- Orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare
- Codul mini-studiului de caz: Quantlets/Ch_06/ai_discovery_case.py
- Inflația: indicele prețurilor de consum pentru toți consumatorii urbani din SUA, U.S. Bureau of Labor Statistics

Înapoi

Acronime folosite în acest material (1/4)

- **ACWI**: All Country World Index — *indicele global al acțiunilor din toate țările (MSCI)*
- **AI**: Artificial Intelligence — *inteligență artificială*
- **AIC**: Akaike Information Criterion — *criteriul informațional Akaike*
- **AR**: AutoRegressive (model) — *model autoregresiv*
- **ARCH**: AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă*
- **BAC**: Bank of America Corporation (NYSE ticker) — *Bank of America Corporation (simbolul bursier NYSE)*
- **BEKK**: Baba–Engle–Kraft–Kroner (multivariate GARCH model) — *modelul GARCH multivariat Baba–Engle–Kraft–Kroner*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BIC**: Bayesian Information Criterion — *criteriul informațional bayesian*
- **BNP**: BNP Paribas SA (Euronext Paris ticker; Banque Nationale de Paris) — *BNP Paribas SA (simbolul bursier Euronext Paris)*
- **BRD**: BRD–Groupe Société Générale (BVB ticker) — *BRD–Groupe Société Générale (simbolul bursier BVB)*
- **CCC**: Constant Conditional Correlation (model) — *modelul cu corelație condiționată constantă*

Acronime folosite în acest material (2/4)

- **CDO**: Collateralised Debt Obligation — *obligațiune garantată cu un portofoliu de datorii*
- **CDS**: Credit Default Swap — *swap pe riscul de credit (contract de asigurare împotriva neplății)*
- **CML**: Canonical Maximum Likelihood — *verosimilitate maximă canonică (pe pseudo-observații)*
- **COVID-19**: COronaVIrus Disease 2019 — *boala provocată de coronavirus, 2019*
- **COVOL**: COmmon VOLatility (global COVOL: the size of the volatility shock common to all assets) — *volatilitatea comună (COVOL global: mărimea șocului de volatilitate comun tuturor activelor)*
- **CPI**: Consumer Price Index — *indicele prețurilor de consum*
- **DBK**: Deutsche Bank AG (Xetra ticker) — *Deutsche Bank AG (simbolul bursier Xetra)*
- **DCC**: Dynamic Conditional Correlation — *corelație condiționată dinamică*
- **DCC-NL**: Dynamic Conditional Correlation with NonLinear shrinkage — *corelație condiționată dinamică cu shrinkage neliniar al țintei*
- **DOI**: Digital Object Identifier — *identificatorul digital al unei publicații*
- **EPU**: Economic Policy Uncertainty (index) — *indicele incertitudinii politicii economice*
- **ES**: Expected Shortfall — *pierderea așteptată în coadă*

Acronime folosite în acest material (3/4)

- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- **EWMA**: Exponentially Weighted Moving Average — *medie mobilă ponderată exponențial*
- **FRM**: Financial Risk Meter — *indicatorul de risc financiar sistemic Financial Risk Meter*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GAS**: Generalised Autoregressive Score (model) — *model cu scor autoregresiv generalizat*
- **GPR**: GeoPolitical Risk (index) — *indicele riscului geopolitic*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **i.i.d.**: independent and identically distributed — *independente și identic distribuite*
- **IFM**: Inference Functions for Margins — *funcții de inferență pentru marginale (estimare în doi pași)*
- **JPM**: JPMorgan Chase & Co. (NYSE ticker) — *JPMorgan Chase & Co. (simbolul bursier NYSE)*
- **LR**: Likelihood Ratio (test) — *testul raportului de verosimilitate*
- **MSCI**: Morgan Stanley Capital International (index provider) — *furnizorul de indici Morgan Stanley Capital International*

Acronime folosite în acest material (4/4)

- **NYSE**: New York Stock Exchange — *Bursa din New York*
- **PC1**: first Principal Component — *prima componentă principală*
- **SE**: Standard Error — *eroarea standard*
- **SPY**: SPDR S&P 500 ETF Trust — *fondul tranzacționat la bursă pe S&P 500*
- **SUA**: Statele Unite ale Americii
- **TLT**: iShares 20+ Year Treasury Bond ETF — *fondul de obligațiuni de stat americane cu scadențe de peste 20 de ani*
- **TLV**: Banca Transilvania (BVB ticker) — *Banca Transilvania (simbolul bursier BVB)*
- **UE**: Uniunea Europeană
- **US**: United States — *Statele Unite ale Americii*
- **USD**: United States Dollar — *dolarul american*
- **VEC**: VECtorised multivariate GARCH model (vech of the covariance matrix) — *modelul GARCH multivariat vectorizat (vech al matricei de covarianță)*
- **VIX**: Cboe Volatility Index — *indicele de volatilitate implicită al Cboe pentru S&P 500*

Bibliografie (1/5)

- Aas, K., Czado, C., Frigessi, A., Bakken, H. (2009). Pair-copula constructions of multiple dependence. *Insurance: Mathematics and Economics*, 44(2), 182–198.
- Adrian, T., Brunnermeier, M.K. (2016). CoVaR. *American Economic Review*, 106(7), 1705–1741.
- Aielli, G.P. (2013). Dynamic conditional correlation: on properties and estimation. *Journal of Business & Economic Statistics*, 31(3), 282–299.
- Ang, A., Chen, J. (2002). Asymmetric correlations of equity portfolios. *Journal of Financial Economics*, 63(3), 443–494.
- Baker, S.R., Bloom, N., Davis, S.J. (2016). Measuring economic policy uncertainty. *Quarterly Journal of Economics*, 131(4), 1593–1636.
- Billio, M., Getmansky, M., Lo, A.W., Pelizzon, L. (2012). Econometric measures of connectedness and systemic risk in the finance and insurance sectors. *Journal of Financial Economics*, 104(3), 535–559.
- Bollerslev, T. (1990). Modelling the coherence in short-run nominal exchange rates: a multivariate generalized ARCH model. *Review of Economics and Statistics*, 72(3), 498–505.
- Bollerslev, T., Engle, R.F., Wooldridge, J.M. (1988). A capital asset pricing model with time-varying covariances. *Journal of Political Economy*, 96(1), 116–131.
- Caldara, D., Iacoviello, M. (2022). Measuring geopolitical risk. *American Economic Review*, 112(4), 1194–1225.
- Campbell, J.Y., Pflueger, C., Viceira, L.M. (2020). Macroeconomic drivers of bond and equity risks. *Journal of Political Economy*, 128(8), 3148–3185.
- Chen, X., Fan, Y. (2006). Estimation and model selection of semiparametric copula-based multivariate dynamic models under copula misspecification. *Journal of Econometrics*, 135(1–2), 125–154.
- Clayton, D.G. (1978). A model for association in bivariate life tables and its application in epidemiological studies of familial tendency in chronic disease incidence. *Biometrika*, 65(1), 141–151.
- Corsetti, G., Pericoli, M., Sbracia, M. (2005). 'Some contagion, some interdependence': more pitfalls in tests of financial contagion. *Journal of International Money and Finance*, 24(8), 1177–1199.

Bibliografie (2/5)

- Creal, D., Koopman, S.J., Lucas, A. (2013). Generalized autoregressive score models with applications. *Journal of Applied Econometrics*, 28(5), 777–795.
- Demarta, S., McNeil, A.J. (2005). The t copula and related copulas. *International Statistical Review*, 73(1), 111–129.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Diebold, F.X., Yilmaz, K. (2009). Measuring financial asset return and volatility spillovers, with application to global equity markets. *Economic Journal*, 119(534), 158–171.
- Embrechts, P., McNeil, A.J., Straumann, D. (2002). Correlation and dependence in risk management: properties and pitfalls. În M.A.H. Dempster (ed.), *Risk Management: Value at Risk and Beyond*, 176–223. Cambridge University Press.
- Engle, R.F. (2002). Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- Engle, R.F., Campos-Martins, S. (2023). What are the events that shake our world? Measuring and hedging global COVOL. *Journal of Financial Economics*, 147(1), 221–242.
- Engle, R.F., Kroner, K.F. (1995). Multivariate simultaneous generalized ARCH. *Econometric Theory*, 11(1), 122–150.
- Engle, R.F., Ledoit, O., Wolf, M. (2019). Large dynamic covariance matrices. *Journal of Business & Economic Statistics*, 37(2), 363–375.
- Engle, R.F., Sheppard, K. (2001). Theoretical and empirical properties of dynamic conditional correlation multivariate GARCH. NBER Working Paper 8554.
- Forbes, K.J., Rigobon, R. (2002). No contagion, only interdependence: measuring stock market comovements. *Journal of Finance*, 57(5), 2223–2261.
- Frank, M.J. (1979). On the simultaneous associativity of F(x, y) and x + y − F(x, y). *Aequationes Mathematicae*, 19, 194–226.

Bibliografie (3/5)

- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, ed. a 5-a. Springer.
- Genest, C., Ghoudi, K., Rivest, L.-P. (1995). A semiparametric estimation procedure of dependence parameters in multivariate families of distributions. *Biometrika*, 82(3), 543–552.
- Genest, C., Rémillard, B., Beaudoin, D. (2009). Goodness-of-fit tests for copulas: a review and a power study. *Insurance: Mathematics and Economics*, 44(2), 199–213.
- Genest, C., Rivest, L.-P. (1993). Statistical inference procedures for bivariate Archimedean copulas. *Journal of the American Statistical Association*, 88(423), 1034–1043.
- Gumbel, E.J. (1960). Bivariate exponential distributions. *Journal of the American Statistical Association*, 55(292), 698–707.
- Härdle, W.K., Simar, L. (2019). Applied Multivariate Statistical Analysis, ed. a 5-a. Springer.
- Herskovic, B., Kelly, B., Lustig, H., Van Nieuwerburgh, S. (2016). The common factor in idiosyncratic volatility: quantitative asset pricing implications. *Journal of Financial Economics*, 119(2), 249–283.
- Joe, H. (2005). Asymptotic efficiency of the two-stage estimation method for copula-based models. *Journal of Multivariate Analysis*, 94(2), 401–419.
- J.P. Morgan/Reuters (1996). RiskMetrics – Technical Document, ed. a 4-a. New York.
- Kendall, M.G. (1938). A new measure of rank correlation. *Biometrika*, 30(1–2), 81–93.
- Kilian, L., Park, C. (2009). The impact of oil price shocks on the U.S. stock market. *International Economic Review*, 50(4), 1267–1287.
- Li, D.X. (2000). On default correlation: a copula function approach. *Journal of Fixed Income*, 9(4), 43–54.
- Liu, Y., Tsyvinski, A. (2021). Risks and returns of cryptocurrency. *Review of Financial Studies*, 34(6), 2689–2727.

Bibliografie (4/5)

- Longin, F., Solnik, B. (2001). Extreme correlation of international equity markets. *Journal of Finance*, 56(2), 649–676.
- Mantegna, R.N. (1999). Hierarchical structure in financial markets. *European Physical Journal B*, 11(1), 193–197.
- Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- Molenaar, R., Sénéchal, E., Swinkels, L., Wang, Z. (2024). Empirical evidence on the stock–bond correlation. *Financial Analysts Journal*, 80(3), 17–36.
- Nelsen, R.B. (2006). An Introduction to Copulas, ed. a 2-a. Springer.
- Newey, W.K., McFadden, D. (1994). Large sample estimation and hypothesis testing. În R.F. Engle, D.L. McFadden (ed.), *Handbook of Econometrics*, Vol. 4, 2111–2245. Elsevier.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Oh, D.H., Patton, A.J. (2018). Time-varying systemic risk: evidence from a dynamic copula model of CDS spreads. *Journal of Business & Economic Statistics*, 36(2), 181–195.
- Okhrin, O., Okhrin, Y., Schmid, W. (2013). On the structure and estimation of hierarchical Archimedean copulas. *Journal of Econometrics*, 173(2), 189–204.
- Pakel, C., Shephard, N., Sheppard, K., Engle, R.F. (2021). Fitting vast dimensional time-varying covariance models. *Journal of Business & Economic Statistics*, 39(3), 652–668.
- Patton, A.J. (2006). Modelling asymmetric exchange rate dependence. *International Economic Review*, 47(2), 527–556.

Bibliografie (5/5)

- Politis, D.N., White, H. (2004). Automatic block-length selection for the dependent bootstrap. *Econometric Reviews*, 23(1), 53–70.
- Rémillard, B. (2017). Goodness-of-fit tests for copulas of multivariate time series. *Econometrics*, 5(1), 13.
- Rigobon, R. (2003). Identification through heteroskedasticity. *Review of Economics and Statistics*, 85(4), 777–792.
- Schmidt, R., Stadtmüller, U. (2006). Non-parametric estimation of tail dependence. *Scandinavian Journal of Statistics*, 33(2), 307–335.
- Sklar, A. (1959). Fonctions de répartition à n dimensions et leurs marges. *Publications de l'Institut de Statistique de l'Université de Paris*, 8, 229–231.
- Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15(1), 72–101.
- Tse, Y.K. (2000). A test for constant correlations in a multivariate GARCH model. *Journal of Econometrics*, 98(1), 107–127.
- Wied, D., Krämer, W., Dehling, H. (2012). Testing for a change in correlation at an unknown point in time using an extended functional delta method. *Econometric Theory*, 28(3), 570–589.