



Modelarea piețelor financiare

Capitolul 6: Volatilitate multivariată și dependență



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- AI: Artificial Intelligence (inteligență artificială)
- AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- BAC: Bank of America Corporation (NYSE ticker) (Bank of America Corporation (simbolul bursier NYSE))
- BEKK: Baba–Engle–Kraft–Kroner (multivariate GARCH model) (modelul GARCH multivariat Baba–Engle–Kraft–Kroner)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BNP: BNP Paribas SA (Euronext Paris ticker; Banque Nationale de Paris) (BNP Paribas SA (simbolul bursier Euronext Paris))
- CCC: Constant Conditional Correlation (model) (modelul cu corelație condiționată constantă)
- CDO: Collateralised Debt Obligation (obligațiune garantată cu un portofoliu de datorii)
- CML: Canonical Maximum Likelihood (verosimilitate maximă canonică (pe pseudo-observații))
- CPI: Consumer Price Index (indicele prețurilor de consum)
- DBK: Deutsche Bank AG (Xetra ticker) (Deutsche Bank AG (simbolul bursier Xetra))
- DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- ES: Expected Shortfall (pierderea așteptată în coadă)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- FRM: Financial Risk Meter (indicatorul de risc financiar sistemic Financial Risk Meter)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- IFM: Inference Functions for Margins (funcții de inferență pentru marginale (estimare în doi pași))
- IIT: Illinois Institute of Technology (Institutul de Tehnologie din Illinois)
- JPM: JPMorgan Chase & Co. (NYSE ticker) (JPMorgan Chase & Co. (simbolul bursier NYSE))
- SUA: Statele Unite ale Americii
- UE: Uniunea Europeană
- VEC: VECtorised multivariate GARCH model (vech of the covariance matrix) (modelul GARCH multivariat vectorizat (vech al matricei de covarianță))

Cuprins

De ce contează corelațiile

Covarianțe pe ferestre mobile și EWMA

GARCH multivariat și DCC

Corelații în criză și distorsiunea Forbes–Rigobon

Copule și dependență în cozi

Aplicații: Europa, România și bănci

AI pentru descoperire științifică

Sinteză

Bibliografie

De ce contează dependența

Trei motive

- **Diversificarea:** riscul portofoliului depinde de modul în care activele se mișcă împreună
 - ▶ **Markowitz (1952):** varianța unui portofoliu este o formă pătratică în matricea de covarianță
- **Acoperirea riscului:** raportul de acoperire este o pantă de regresie condiționată
 - ▶ Dacă se schimbă corelația, acoperirea de ieri este greșită astăzi
- **Contagiunea:** șocurile se propagă între piețe și instituții
 - ▶ Corelațiile tind să crească exact când diversificarea este cea mai necesară

Ce facem în acest capitol

- Estimăm covarianțe variabile în timp: ferestre mobile, EWMA, GARCH multivariat, DCC
- Separăm contagiunea reală de distorsiunea produsă de volatilitate (Forbes–Rigobon)
- Trecem dincolo de corelație: copule și dependență în cozi
- Aplicăm totul pe acțiuni și obligațiuni, Europa și România, Bitcoin și bănci

Diversificarea: algebra

- ▣ Ponderile portofoliului $w \in \mathbb{R}^N$, matricea de covarianță Σ a randamentelor
- ▣ Varianța portofoliului:


$$\sigma_p^2 = w^\top \Sigma w = \sum_i \sum_j w_i w_j \rho_{ij} \sigma_i \sigma_j$$
- ▣ Două active:
 - ▶ $\sigma_p^2 = w^2 \sigma_1^2 + (1-w)^2 \sigma_2^2 + 2w(1-w)\rho \sigma_1 \sigma_2$
- ▣ Doar $\rho = 1$ nu reduce deloc riscul:

$$\sigma_p = w\sigma_1 + (1-w)\sigma_2$$

SPY și TLT, 31 iulie 2002 – 2026

- ▣ SPY: fondul tranzacționat la bursă pe S&P 500; TLT: fondul de obligațiuni de stat americane cu scadența peste 20 de ani
- ▣ Volatilitate anualizată: SPY 18,9%, TLT 14,3%
- ▣ Portofoliu 60/40 cu $\rho = 1$: 17,0%; cu $\rho = 0$: 12,7%
- ▣ Cu corelația din 2002–2021 ($-0,40$): 10,4%
- ▣ Cu corelația din 2022–2026 ($0,11$): 13,2%

Valoarea unei corelații negative



- Volatilitatea unui portofoliu 60/40 SPY-TLT în funcție de corelație, cu volatilitățile din tot eșantionul
- Punctele: corelația măsurată înainte și după ianuarie 2022

Interpretarea graficului de diversificare

- ▣ Trecerea de la $\rho = -0,40$ la $\rho = 0,11$ crește volatilitatea portofoliului 60/40 de la 10,4% la 13,2%
- ▣ Volatilitățile celor două active nu trebuie să se schimbe: corelația singură produce efectul
 - ▶ Componenta de obligațiuni a încetat să fie o acoperire și a devenit o a doua sursă de risc
- ▣ Graficul presupune o singură corelație constantă pe perioadă; restul capitolului arată cum se măsoară una care se mișcă
- ▣ Lecția: un model de risc cu corelație fixă poate subestima riscul după o schimbare de regim

Acoperirea riscului: raportul de acoperire de varianță minimă

- Deținem o unitate din activul S și vindem h unități din instrumentul de acoperire F : $r_H = r_S - h r_F$
- Minimizăm $\text{Var}(r_H) = \sigma_S^2 - 2h\sigma_{SF} + h^2\sigma_F^2$ după h
- Soluția: $h^* = \sigma_{SF}/\sigma_F^2 = \rho\sigma_S/\sigma_F$, panta regresiei lui r_S pe r_F
- Eficiența acoperirii: proporția de varianță eliminată $= \rho^2$

Exemplu lucrat: BET acoperit cu Euro Stoxx 50

- Randamente săptămânale, 10 ianuarie 2020 – 2026 ($n = 350$)
- $\hat{\sigma}_{BET} = 2,53\%$, $\hat{\sigma}_{SX5E} = 2,88\%$, $\hat{\rho} = 0,615$
- $h^* = 0,615 \times 2,53/2,88 = 0,540$
- Varianța eliminată: $\hat{\rho}^2 = 0,378$; volatilitatea scade cu $1 - \sqrt{1 - \hat{\rho}^2} = 21,2\%$
- Dacă ρ se schimbă, se schimbă și h^* : o acoperire dinamică cere o corelație dinamică

Contagiunea: când corelațiile sar




Sediul Lehman Brothers, New York, 15 septembrie
2008, ziua cererii de faliment

Foto: Robert Scoble (2008); CC BY 2.0; Wikimedia
Commons

- ▣ **Interdependența:** piețele sunt legate în orice stare a lumii
 - ▶ Comerț, investitori comuni, factori macroeconomici comuni
- ▣ **Contagiune (Forbes & Rigobon (2002)):** o creștere semnificativă a legăturilor dintre piețe după un șoc
 - ▶ O corelație mare în criză nu este suficientă; trebuie să fie mai mare decât în perioadele calme
- ▣ Secțiunea 4 arată de ce o comparație naivă a corelațiilor supraestimează contagiunea

Acțiuni și obligațiuni: o corelație care și-a schimbat semnul



- Corelația randamentelor zilnice SPY și TLT pe o fereastră de 252 de zile, cu un interval Fisher de 95% care presupune date i.i.d.
- Benzile gri: toamna 2008 – martie 2009, februarie–aprilie 2020 și ianuarie–octombrie 2022

Interpretarea corelației acțiuni–obligațiuni

- ▣ Minim $-0,76$ (9 august 2012), maxim $0,32$ (3 iulie 2024), ultima valoare $0,24$
- ▣ Proporția zilelor cu corelație mobilă pozitivă: 6% înainte de 2022, 81% din ianuarie 2022
- ▣ Semnul depinde de ceea ce mișcă randamentele obligațiunilor
 - ▶ Șocuri de creștere economică: acțiunile scad, randamentele scad, obligațiunile cresc (corelație negativă)
 - ▶ Șocuri de inflație: acțiunile și obligațiunile scad împreună (corelație pozitivă), ca în 2022
- ▣ Banda Fisher este prea îngustă aici: ignoră gruparea volatilității și suprapunerea ferestrelor

Recapitulare

- ▣ Riscul portofoliului este $w^\top \Sigma w$: termenii din afara diagonalei domină adesea în portofoliile mari
- ▣ Raportul de acoperire de varianță minimă este $\rho \sigma_S / \sigma_F$; eficiența sa este ρ^2
- ▣ Contagiunea înseamnă o *creștere* semnificativă a legăturilor, nu doar o mișcare comună puternică
- ▣ Corelația SPY–TLT a trecut în 2022 de la valori predominant negative la valori predominant pozitive: corelațiile nu sunt constante

Covarianța de selecție și precizia ei

- ▣ Randamente $r_t \in \mathbb{R}^N$, $t = 1, \dots, T$; covarianța de selecție $\hat{\Sigma} = \frac{1}{T-1} \sum_t (r_t - \bar{r})(r_t - \bar{r})^\top$
- ▣ Corelația Pearson: $\hat{\rho}_{ij} = \hat{\Sigma}_{ij} / \sqrt{\hat{\Sigma}_{ii} \hat{\Sigma}_{jj}} \in [-1, 1]$
- ▣ Transformarea Fisher: $z = \text{artanh } \hat{\rho} \approx N(\text{artanh } \rho, 1/(T-3))$ pentru date i.i.d. cu distribuția Normală
 - ▶ Interval de 95%: $\tanh(z \pm 1,96/\sqrt{T-3})$
 - ▶ Cu $T = 252$ și $\rho = 0,5$ semilărgimea este de aproximativ 0,09: o corelație pe un an este zgomotoasă
- ▣ N active: $N(N+1)/2$ elemente distincte; pentru $N = 500$ sunt 125 250 de numere

Estimatori pe fereastră mobilă

- ▣ Estimăm pe ultimele m observații: $\hat{\Sigma}_t = \frac{1}{m} \sum_{s=t-m}^{t-1} r_s r_s^\top$ (media fixată la zero pentru date zilnice)
- ▣ Compromisul în alegerea lui m
 - ▶ Fereastră scurtă: reacționează repede, dar este zgomotoasă
 - ▶ Fereastră lungă: stabilă, dar detectează târziu o schimbare de regim
- ▣ **Efectul fantomă**: o zi extremă intră cu ponderea $1/m$ și iese brusc după m zile
- ▣ Pozitiv semidefinită prin construcție dacă $m \geq N$; singulară dacă $m < N$

EWMA: recursia RiskMetrics

- ▣ Ponderi care scad exponențial:
 $\Sigma_t = \lambda \Sigma_{t-1} + (1 - \lambda) r_{t-1} r_{t-1}^\top$
- ▣ Echivalent: $\Sigma_t = (1 - \lambda) \sum_{k \geq 1} \lambda^{k-1} r_{t-k} r_{t-k}^\top$
- ▣ J.P. Morgan/Reuters (1996): $\lambda = 0,94$ pentru date zilnice și $\lambda = 0,97$ pentru date lunare
- ▣ Timpul de înjumătățire al unui șoc: $\ln 0,5 / \ln \lambda = 11,2$ zile ($\lambda = 0,94$), 22,8 zile ($\lambda = 0,97$)

Proprietăți

- ▣ Pozitiv semidefinită: o sumă ponderată de produse exterioare
- ▣ Fără efect fantomă: ponderile scad lin
- ▣ Același λ pentru toate varianțele și covarianțele: foarte restrictiv
- ▣ Este un GARCH(1,1) integrat fără constantă: nu revine la medie (Capitolul 5)


Exemplu lucrat: o actualizare EWMA, pas cu pas

- SPY și TLT, randamente în %; $\lambda = 0,94$
- Estimarea pentru 17 septembrie 2026: $\sigma_{11} = 0,395$, $\sigma_{22} = 0,307$, $\sigma_{12} = 0,139$
- Randamentele observate în acea zi: $r_1 = 1,128$, $r_2 = 1,107$
- Corelația înainte de actualizare:
 $0,139 / \sqrt{0,395 \times 0,307} = 0,400$

Actualizarea pentru 18 septembrie 2026

- $\sigma_{11} = 0,94 \times 0,395 + 0,06 \times 1,128^2 = 0,448$
- $\sigma_{22} = 0,94 \times 0,307 + 0,06 \times 1,107^2 = 0,362$
- $\sigma_{12} = 0,94 \times 0,139 + 0,06 \times 1,128 \times 1,107 = 0,206$
- Corelația nouă: 0,511
- O singură zi cu SPY +1,13% și TLT +1,11% a mutat-o de la 0,40 la 0,51

EWMA versus ferestre mobile, SPY-TLT din 2019



- Doi estimatori EWMA ($\lambda = 0,94$ și $0,97$) și două ferestre mobile (60 și 250 de zile) pe aceleași date


Interpretarea comparației EWMA

- ▣ Abaterea standard a variației zilnice a estimării: 0,060 (EWMA 0,94), 0,032 (EWMA 0,97), 0,0089 (fereastră de 250 de zile)
- ▣ EWMA cu $\lambda = 0,94$ folosește un eșantion efectiv de aproximativ $(1 + \lambda)/(1 - \lambda) \approx 32$ de zile: rapid, dar zgomotos
- ▣ Pozitivă persistent (20 de zile la rând) din 10 mai 2022 cu EWMA 0,94, dar abia din 8 decembrie 2022 cu fereastra de 250 de zile
- ▣ Niciuna dintre metode nu estimează λ sau m din date: DCC (Secțiunea 3) o face

Tranzacționarea asincronă: o capcană pentru corelațiile zilnice

- ▣ Orele de închidere diferă: Bucureștiul și Frankfurtul se închid cu ore înaintea New York-ului
 - ▶ Știrile din SUA de după închiderea europeană intră în prețurile europene abia a doua zi
- ▣ Consecință: corelația din aceeași zi este deplasată spre zero, iar corelația decalată este pozitivă
- ▣ Soluții
 - ▶ Frecvență mai mică: randamente pe 2 zile sau săptămânale, în zilele comune de tranzacționare
 - ▶ Adăugarea termenului decalat: $\rho_0 + \rho_{+1}$ aproximează corelația sincronă
- ▣ Regula folosită peste tot: întâi unim *prețurile* în zilele comune, apoi calculăm randamentele

Corelații zilnice, pe 2 zile și săptămânale, 2000–2026



□ SPY, Euro Stoxx 50 și BET în zilele comune de tranzacționare; barele de eroare: intervale Fisher de 95%

Interpretarea efectului de frecvență

- SPY–Euro Stoxx 50: 0,59 zilnic, 0,71 pe 2 zile, 0,79 săptămânal
- Corelația zilnică decalată (SPY ieri, Euro Stoxx 50 azi): 0,20; pentru BET: 0,17
- SPY–BET: 0,23 zilnic față de 0,38 săptămânal; Euro Stoxx 50–BET (închideri aproape sincrone): 0,33 față de 0,41
- Diferența este maximă între fusuri orare: o parte din corelația zilnică „mică” SUA–Europa este un artefact de măsurare
- Datele săptămânale sunt mai curate, dar dau 1 367 în loc de 6 428 observații: intervale mai largi

Recapitulare

- ▣ Ferestrele mobile: simple, dar lungimea ferestrei este arbitrară, iar zilele extreme creează efecte fantomă
- ▣ EWMA: $\Sigma_t = \lambda \Sigma_{t-1} + (1 - \lambda) r_{t-1} r_{t-1}^\top$, pozitiv semidefinită, o singură rată de descreștere pentru toate elementele, fără revenire la medie
- ▣ Eroarea de selecție a unei corelații este mare; intervalele Fisher o subestimează când volatilitatea se grupează
- ▣ Între fusuri orare folosim randamente pe 2 zile sau săptămânale ori adăugăm termeni decalați

De la volatilitate univariată la volatilitate multivariată

- ▣ Capitolul 5: $r_t = \sigma_t z_t$ cu $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$
- ▣ Acum: $r_t = H_t^{1/2} z_t$, $\mathbb{E}(z_t) = 0$, $\text{Var}(z_t) = I_N$, deci $\text{Var}(r_t | \mathcal{F}_{t-1}) = H_t$
- ▣ Orice model pentru H_t trebuie să asigure
 - ▶ Pozitiv definirea la fiecare t
 - ▶ Puțini parametri, astfel încât estimarea să fie posibilă pentru multe active
 - ▶ Dinamică interpretabilă: transmiterea volatilității, corelație variabilă în timp
- ▣ Log-cvasi-verosimilitatea Gaussiană: $\ell = -\frac{1}{2} \sum_t (N \ln 2\pi + \ln |H_t| + r_t^\top H_t^{-1} r_t)$

Modelele VEC și BEKK

- **VEC** (Bollerslev, Engle & Wooldridge (1988)): fiecare element al lui H_t depinde de toate pătratele și produsele încrucișate
 - ▶ $\text{vech}(H_t) = c + A \text{vech}(r_{t-1} r_{t-1}^\top) + B \text{vech}(H_{t-1})$
 - ▶ Pozitiv definirea nu este garantată
- **BEKK** (Engle & Kroner (1995)): pozitiv definită prin construcție
 - ▶ $H_t = CC^\top + A^\top r_{t-1} r_{t-1}^\top A + B^\top H_{t-1} B$
 - ▶ Parametrii sunt greu de interpretat; verosimilitatea este plată în dimensiuni mari

Numărul de parametri

N	VEC	BEKK complet	DCC
2	21	11	$6 + 2$
5	465	65	$15 + 2$
10	6 105	255	$30 + 2$
50	3 252 525	6 275	$150 + 2$

- VEC: $N(N+1)/2 \cdot [1 + N(N+1)]$; BEKK: $N(N+1)/2 + 2N^2$
- DCC: $3N$ parametri GARCH univariați plus 2 (cu țintirea corelației)

Corelația condiționată constantă și dinamică

- ▣ Descompunerea: $H_t = D_t R_t D_t$, $D_t = \text{diag}(\sigma_{1t}, \dots, \sigma_{Nt})$ din modele GARCH univariate
- ▣ **CCC** (Bollerslev (1990)): $R_t = R$ constantă; reziduuri standardizate $\varepsilon_{it} = r_{it}/\sigma_{it}$
- ▣ **DCC** (Engle (2002)): o recursie de tip GARCH pentru o matrice auxiliară Q_t
 - ▶ $Q_t = (1 - a - b) \bar{Q} + a \varepsilon_{t-1} \varepsilon_{t-1}^\top + b Q_{t-1}$, $a, b \geq 0$, $a + b < 1$
 - ▶ $R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2}$
 - ▶ $\bar{Q}$: covarianța de selecție a lui ε_t (țintirea corelației)
- ▣ Doi parametri guvernează toate cele $N(N-1)/2$ corelații: parcimonios, dar toate perechile au aceeași persistență

Robert Engle și modelul DCC



Robert F. Engle la conferința Western Economic Association International, Santiago, 2017

Foto: [Econterms \(2017\)](#); CC BY-SA 4.0; [Wikimedia Commons](#)

- Premiul Nobel pentru științe economice 2003 pentru modelele ARCH (Capitolul 5)
- [Engle \(2002\)](#): „Dynamic Conditional Correlation”
 - ▶ Păstrează flexibilitatea GARCH univariat pentru fiecare varianță
 - ▶ Adaugă o lege de mișcare simplă și estimabilă pentru corelații
- Rafinare: DCC corectat al lui [Aielli \(2013\)](#), care face din $\bar{Q}$ o țintă consistentă

Estimarea în doi pași

- Log-verosimilitatea Gaussiană se împarte într-o parte de volatilitate și o parte de corelație

$$\ell = \underbrace{-\frac{1}{2} \sum_t (N \ln 2\pi + 2 \ln |D_t| + r_t^\top D_t^{-2} r_t)}_{\ell_V} - \underbrace{\frac{1}{2} \sum_t (\ln |R_t| + \varepsilon_t^\top R_t^{-1} \varepsilon_t - \varepsilon_t^\top \varepsilon_t)}_{\ell_C}$$

- Pasul 1: estimăm N modele GARCH(1,1) univariate; păstrăm σ_{it} și ε_{it}
- Pasul 2: fixăm $\bar{Q}$ la covarianța de selecție a lui ε_t și maximizăm ℓ_C după (a, b)
- Inferență
 - Consistent (cvasi-verosimilitate maximă) chiar dacă z_t nu are distribuția Normală
 - Erorile standard doar din pasul 2 ignoră eroarea de estimare din pasul 1: sunt prea mici
 - Testăm CCC contra DCC: $H_0 : a = 0$; b nu este identificat sub H_0 , deci referința χ^2 este doar orientativă

Estimările DCC pentru SPY și TLT

Pasul 1: GARCH(1,1), randamente în %


	ω	α	β	$\alpha + \beta$
SPY	0,0289	0,129	0,846	0,975
TLT	0,0057	0,049	0,944	0,993

Pasul 2: DCC(1,1)

	estimare	eroare std.
a	0,0529	0,0060
b	0,9326	0,0084
$a + b$	0,9856	
$\bar{Q}_{12}$	-0,248	

- Date zilnice 31 iulie 2002 – 18 septembrie 2026, $T = 6\,023$
- Persistența corelației $a + b = 0,986$: timpul de înjumătățire al unui șoc de corelație ≈ 48 de zile
- Raportul de verosimilitate DCC contra CCC:
 $2(\ell_C^{DCC} - \ell_C^{CCC}) = 526,4$
- Corelația constantă este respinsă categoric, oricare ar fi distribuția de referință exactă
- Volatilitatea TLT este mai persistentă (β mai mare), dar reacționează mai puțin la știri (α mai mic) decât cea a SPY

Corelația DCC dintre SPY și TLT, 2002–2026




- Corelația condiționată $\rho_{12,t}$ din modelul DCC(1,1), corelația mobilă pe 252 de zile și ținta $\bar{Q}_{12}$

Interpretarea traiectoriei DCC

- ▣ Intervalul: de la $-0,79$ (2 noiembrie 2011) la $0,50$ (21 mai 2026); ultima valoare $0,36$
- ▣ Corelația DCC medie: $-0,54$ între 15 septembrie și 31 decembrie 2008, $-0,55$ în 2012, $-0,01$ în 2022
- ▣ DCC reacționează în câteva zile, ca EWMA, dar viteza (a) și memoria (b) sunt estimate, nu impuse
- ▣ Revenirea la $\bar{Q}_{12} = -0,25$ este o slăbiciune când se schimbă regimul
 - ▶ Din ianuarie 2022 traiectoria este deasupra țintei în 91% din zile (36% înainte): o singură corelație pe termen lung este îndoielnică

Aplicație: ponderi de varianță minimă cu DCC




- Ponderea SPY în portofoliul zilnic de varianță minimă SPY-TLT: $w_t = (\sigma_{2t}^2 - \sigma_{12,t}) / (\sigma_{1t}^2 + \sigma_{2t}^2 - 2\sigma_{12,t})$, trunchiată la $[0, 1]$
- Aceleași volatilități GARCH; corelația din DCC sau constantă $(-0,30)$

Interpretarea aplicației de portofoliu

- ▣ Volatilitatea anualizată (%): 60/40 fix 11,05; GARCH + corelație constantă 9,15; GARCH + DCC 9,10
- ▣ Cea mai mare parte a câștigului vine din volatilitățile GARCH și din ponderile de varianță minimă; corelația DCC adaugă doar o reducere suplimentară mică
- ▣ Diferența absolută medie de pondere DCC minus constant: 0,019; cea mai mare: 0,22 (8 iunie 2026)
- ▣ Atenție: parametrii sunt estimați pe tot eșantionul, deci aceasta este o ilustrare în eșantion
 - ▶ O comparație corectă reestimează modelele pe ferestre extinse și adaugă costurile de tranzacționare (Capitolul 8)

Bitcoin și acțiunile americane: corelația DCC



- Bitcoin și SPY în zilele comune de tranzacționare din 18 septembrie 2014 ($T = 3012$); mișcările Bitcoin din weekend intră în randamentul de luni

Interpretarea corelației Bitcoin–acțiuni

- ▣ Corelația DCC medie: 0,04 înainte de 2020, 0,31 din ianuarie 2020; vârf 0,55 pe 19 mai 2022
- ▣ Dinamică foarte persistentă: $a = 0,015$, $b = 0,982$, $a + b = 0,9968$; CCC este respins (raportul de verosimilitate 105,4)
- ▣ De la diversificator la activ de risc: din 2020 Bitcoin se mișcă împreună cu acțiunile mult mai mult decât înainte
 - ▶ [Pele et al. \(2023\)](#) se întreabă dacă criptoactivele au devenit o clasă de active distinctă; corelația în creștere face parte din răspuns
- ▣ Corelația din tot eșantionul (0,24) ascunde două regimuri diferite

GARCH multivariat în practică

- ▣ N mare: DCC cu țintirea corelației rămâne fezabil; VEC și BEKK nu
 - ▶ Pentru sute de active, se combină cu modele factoriale sau cu contracția lui $\bar{Q}$ (Capitolele 3 și 4)
- ▣ Aceiași a , b pentru toate perechile: persistența eterogenă cere modele mai bogate (și mai dificile)
- ▣ Asimetria: corelațiile cresc mai mult după scăderi comune; variantele asimetrice de DCC adaugă un termen pentru șocurile negative
- ▣ Diagnostic: reziduurile standardizate $\hat{H}_t^{-1/2} r_t$ ar trebui să fie necorelate serial, cu matricea de covarianță identitate
- ▣ Tratare în manual: [Franke, Härdle & Hafner \(2019\)](#), capitolele despre volatilitate multivariată și copule

Recapitulare

- ▣ $H_t = D_t R_t D_t$ separă volatilitățile (GARCH univariat) de corelații
- ▣ VEC și BEKK sunt generale, dar numărul de parametri explodează; DCC cere $3N + 2$
- ▣ Estimarea în doi pași este consistentă; erorile standard din pasul 2 sunt prea mici
- ▣ SPY–TLT: $a + b = 0,986$, CCC respins, schimbare de semn după 2022; Bitcoin–SPY: corelația crește de la 0,04 la 0,31


Cresc corelațiile în criză?

- ▣ Constatare frecventă: corelațiile măsurate în criză sunt mai mari decât în perioadele calme
- ▣ Două explicații foarte diferite
 - ▶ **Contagiune**: se schimbă însuși mecanismul de transmitere
 - ▶ **Distorsiune de volatilitate**: mecanismul rămâne neschimbat, dar o piață-sursă mai volatilă crește mecanic corelația
- ▣ **Forbes & Rigobon (2002)**: după corecție, cea mai mare parte a „contagiunii” din 1987, 1994 și 1997 s-a dovedit interdependentă
- ▣ **Longin & Solnik (2001), Ang & Chen (2002)**: corelațiile cresc pe piețele în scădere, nu pe cele în creștere: o asimetrie pe care distribuția Normală nu o poate produce

Distorsiunea de heteroscedasticitate: derivare

- ▣ Modelul: $y_t = \alpha + \beta x_t + \varepsilon_t$, $\text{Cov}(x_t, \varepsilon_t) = 0$, β și σ_ε^2 constante
- ▣ Corelația: $\rho^2 = \frac{\beta^2 \sigma_x^2}{\beta^2 \sigma_x^2 + \sigma_\varepsilon^2} = \left(1 + \frac{\sigma_\varepsilon^2}{\beta^2 \sigma_x^2}\right)^{-1}$
- ▣ Criză: $\sigma_{x,c}^2 = (1 + \delta) \sigma_x^2$ cu $\delta > 0$; nimic altceva nu se schimbă
- ▣ Atunci $\rho_c = \rho \sqrt{\frac{1 + \delta}{1 + \delta \rho^2}} > \rho$: corelația măsurată crește deși β este același
- ▣ Inversând: $\rho^* = \frac{\rho_c}{\sqrt{1 + \delta(1 - \rho_c^2)}}$ este corelația din criză corectată pentru creșterea volatilității

Cât poate crește o corelație doar din cauza volatilității?



- Corelația măsurată în criză ρ_c în funcție de δ , pentru trei corelații adevărate care nu se schimbă
- Linia verticală: varianța randamentelor S&P 500 pe 2 zile a fost de 7,5 ori nivelul din anul calm în fereastra de criză din 2008 ($\delta = 6,48$)

Testul Forbes–Rigobon

- Procedura
 - ▶ Alegem piața-sursă x , o fereastră calmă și o fereastră de criză
 - ▶ Calculăm $\delta = \hat{\sigma}_{x,c}^2 / \hat{\sigma}_{x,calm}^2 - 1$ și corelația corectată ρ^*
 - ▶ Testăm $H_0 : \rho^* \leq \rho_{calm}$ cu statistici Fisher z
- Folosim randamente pe 2 zile pentru a reduce problema fusurilor orare (ca în [Forbes & Rigobon \(2002\)](#))


Ipoteze de reținut

- Niciun șoc comun omis: un factor global care lovește ambele piețe crește și σ_x
- Nicio legătură inversă de la y la x (fără endogenitate)
- Alegerea ferestrelor contează: rezultatele se pot inversa cu câteva săptămâni
- Corecția poate merge prea departe dacă mecanismul real chiar s-a schimbat

Exemplu lucrat: criza din 2008 pas cu pas

- Piața-sursă: S&P 500; anul calm: 14 septembrie 2007 – 12 septembrie 2008 ($n = 241$ randamente pe 2 zile); criza: 15 septembrie 2008 – 31 martie 2009 ($n = 130$)
- Raportul varianțelor: $1 + \delta = 7,48$, deci $\delta = 6,48$
- Euro Stoxx 50: $\rho_{calm} = 0,608$, $\rho_c = 0,804$
 - ▶ $\rho^* = 0,804 / \sqrt{1 + 6,48(1 - 0,804^2)} = 0,444$
 - ▶ p -valoarea unilaterală: 0,005 cu ρ_c , 0,928 cu ρ^*
- BET: $\rho_{calm} = 0,217$, $\rho_c = 0,485$, $\rho^* = 0,199$
 - ▶ p -valoarea unilaterală: 0,025 cu ρ_c , 0,550 cu ρ^*

2008: corelații de criză brute versus corectate



- Corelația randamentelor pe 2 zile cu S&P 500 în anul calm, în criză (brută) și după corecția Forbes–Rigobon


Interpretarea testului pentru 2008

- ▣ Corelațiile brute sar: Euro Stoxx 50 de la 0,61 la 0,80, BET de la 0,22 la 0,48; ambele creșteri sunt semnificative la 5%
- ▣ După corecție nicio creștere nu rezistă: mișcarea comună din 2008 este compatibilă cu „nicio contagiune, doar interdependență”
- ▣ De ce cu prudență?
 - ▶ 2008 a fost un șoc global care a lovit toate piețele simultan: ipoteza „niciun șoc comun” este îndoielnică
 - ▶ Cu $\delta \approx 6,5$ corecția este mare, iar testul are putere mică
- ▣ Seminarul repetă testul pentru 2020 și verifică sensibilitatea la alegerea ferestrelor

Corelațiile de depășire

- ▣ Longin & Solnik (2001): corelația condiționată de faptul că ambele randamente depășesc un prag
- ▣ Coda inferioară la cuantila q : $\rho^-(q) = \text{Corr}(x, y \mid x \leq F_x^{-1}(q), y \leq F_y^{-1}(q))$
- ▣ Coda superioară: la fel, cu $x \geq F_x^{-1}(1 - q), y \geq F_y^{-1}(1 - q)$
- ▣ Referința: pentru distribuția Normală bivariată, $\rho^\pm(q) \rightarrow 0$ când $q \rightarrow 0$
 - Condiționarea pe extreme scade corelația chiar dacă nu se schimbă nimic: comparăm cu curba Normală, nu cu ρ

Corelații de depășire: S&P 500 și Euro Stoxx 50



- Randamente săptămânale 2000–2026 ($n = 1\,393$, $\hat{\rho} = 0,78$ total); gri: Normala bivariată cu aceeași corelație (2 milioane de perechi simulate)

Interpretarea graficului de depășire

- ▣ La $q = 0,10$: pierderi comune $\rho^- = 0,80$ (86 săptămâni), câștiguri comune $\rho^+ = 0,69$ (70 săptămâni); referința Normală 0,41
- ▣ Ambele cozi sunt mult peste referința Normală: extremele sunt mai dependente decât permite un model Gaussian
- ▣ Coda inferioară este mai sus decât cea superioară: prăbușirile sunt comune mai des decât creșterile
- ▣ Un coeficient de corelație nu poate descrie acest lucru: avem nevoie de un model pentru întreaga structură de dependență $\Rightarrow$ copule

Recapitulare

- ▣ Volatilitatea mai mare a pieței-sursă crește corelația măsurată chiar dacă mecanismul nu se schimbă
- ▣ Corelația corectată: $\rho^* = \rho_c / \sqrt{1 + \delta(1 - \rho_c^2)}$
- ▣ 2008: creșterile brute sunt semnificative, cele corectate nu; rezultatul se sprijină pe ipoteze puternice
- ▣ Corelațiile de depășire sunt asimetrice și mult peste referința Normală

De ce corelația nu este suficientă

- ▣ Embrechts, McNeil & Straumann (2002): trei erori frecvente despre corelația liniară
- ▣ Corelația măsoară doar dependența *liniară*
 - ▶ $x \sim N(0, 1)$ și $y = x^2$: $\rho = 0$, deși y este o funcție de x
- ▣ Corelația nu este invariantă la transformări monotone
 - ▶ $\text{Corr}(x, y) \neq \text{Corr}(e^x, e^y)$: prețurile și randamentele pot avea corelații diferite
- ▣ Marginalele și corelația nu determină distribuția comună
 - ▶ Două portofolii cu aceleași marginale și același ρ pot avea valori la risc foarte diferite (Capitolul 7)
- ▣ Nu orice $\rho \in [-1, 1]$ este posibil pentru marginale date: de exemplu, două variabile lognormale

Teorema lui Sklar



Clădirea principală, Illinois Institute of Technology, Chicago: Abe Sklar (1925–2020) a fost profesor de matematică aplicată la IIT; nu există un portret al său cu licență liberă

Foto: Joe Ravi (2010); CC BY-SA 3.0; Wikimedia

[Commons](#)

- O **copulă** este o funcție de repartiție comună pe $[0, 1]^d$ cu marginale uniforme
- Sklar (1959): pentru orice repartiție comună F cu marginalele $F_1, \dots, F_d$ există o copulă C astfel încât
 - ▶ $F(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d))$
 - ▶ C este unică dacă marginalele sunt continue
- Invers, orice copulă și orice marginale dau o repartiție comună validă
- Densitatea: $f(x) = c(F_1(x_1), \dots, F_d(x_d)) \prod_i f_i(x_i)$

Ce separă copula

- ▣ Marginalele: volatilitatea, asimetria, cozile groase ale fiecărui activ (Capitolele 1 și 5)
- ▣ Copula: toată dependența și nimic altceva; invariantă la transformări crescătoare ale fiecărei variabile
- ▣ Trei copule de referință în două dimensiuni
 - ▶ Independența: $\Pi(u, v) = uv$
 - ▶ Comonotonia (dependență pozitivă perfectă): $M(u, v) = \min(u, v)$
 - ▶ Contramonotonia: $W(u, v) = \max(u + v - 1, 0)$
- ▣ Marginile Fréchet–Hoeffding: $W \leq C \leq M$ pentru orice copulă
- ▣ Text de referință: [Nelsen \(2006\)](#)

Corelații de rang: Kendall și Spearman

- **Tau al lui Kendall (Kendall (1938))**: perechi concordante minus perechi discordante
 - ▶ $\tau = P[(X_1 - X_2)(Y_1 - Y_2) > 0] - P[(X_1 - X_2)(Y_1 - Y_2) < 0]$
 - ▶ Forma în copule: $\tau = 4 \iint C \, dC - 1$
- **Rho al lui Spearman (Spearman (1904))**: corelația Pearson a rangurilor
 - ▶ Forma în copule: $\rho_S = 12 \iint (C(u, v) - uv) \, du \, dv$
- Ambele depind doar de copulă; ambele sunt 1 pentru M , 0 pentru Π , -1 pentru W

Legătura cu parametrii copulelor

Copula	τ
Gaussiană, t	$\frac{2}{\pi} \arcsin \rho$
Clayton	$\theta/(\theta + 2)$
Gumbel	$1 - 1/\theta$
Frank	$1 - \frac{4}{\theta} [1 - D_1(\theta)]$

- $D_1(\theta) = \frac{1}{\theta} \int_0^\theta \frac{t}{e^t - 1} dt$ (funcția Debye)
- Gaussiană: $\rho_S = \frac{6}{\pi} \arcsin(\rho/2)$

Copule eliptice: Gaussiană și Student t

- ▣ **Gaussiană:** $C_{\rho}^{Ga}(u, v) = \Phi_{2,\rho}(\Phi^{-1}(u), \Phi^{-1}(v))$
 - ▶ Densitatea: $c = \frac{1}{\sqrt{1-\rho^2}} \exp\left(-\frac{\rho^2(x^2+y^2)-2\rho xy}{2(1-\rho^2)}\right)$, $x = \Phi^{-1}(u)$, $y = \Phi^{-1}(v)$
 - ▶ Simetrică, fără dependență în cozi pentru $|\rho| < 1$
- ▣ **Student t** (Demarta & McNeil (2005)): $C_{\rho,\nu}^t(u, v) = t_{2,\rho,\nu}(t_{\nu}^{-1}(u), t_{\nu}^{-1}(v))$
 - ▶ ν grade de libertate: ν mic = extreme comune puternice; $\nu \rightarrow \infty$ dă copula Gaussiană
 - ▶ Dependență în cozi simetrică, egală în ambele cozi
- ▣ Ușor de extins la d dimensiuni cu o matrice de corelație: alegerea standard în sistemele de risc


Copule arhimedienne: Clayton, Gumbel, Frank

- ▣ Construite dintr-un generator φ : $C(u, v) = \varphi^{-1}(\varphi(u) + \varphi(v))$
- ▣ **Clayton** ([Clayton \(1978\)](#)), $\theta > 0$
 - ▶ $C = (u^{-\theta} + v^{-\theta} - 1)^{-1/\theta}$
 - ▶ dependență doar în coada inferioară
- ▣ **Gumbel** ([Gumbel \(1960\)](#)), $\theta \geq 1$
 - ▶ $C = \exp(-[(-\ln u)^\theta + (-\ln v)^\theta]^{1/\theta})$
 - ▶ dependență doar în coada superioară
- ▣ **Frank** ([Frank \(1979\)](#)), $\theta \neq 0$
 - ▶ $C = -\frac{1}{\theta} \ln\left(1 + \frac{(e^{-\theta u} - 1)(e^{-\theta v} - 1)}{e^{-\theta} - 1}\right)$
 - ▶ simetrică, fără dependență în cozi

De ce le folosim

- ▣ Un singur parametru, C în formă închisă, simulare ușoară
- ▣ Cozi asimetrice: Clayton pentru prăbușirile comune ale randamentelor, Gumbel pentru extremele comune ale pierderilor
- ▣ Rotirea unei copule (folosind $1 - u, 1 - v$) mută dependența în cozi în colțul opus
- ▣ Limită: interschimbabile, slabe în dimensiuni mari (un parametru pentru toate perechile)

Cinci copule cu același tau al lui Kendall



- 1500 de perechi simulate din fiecare copulă cu $\tau = 0,5$, reprezentate pe marginale Normale ($\Phi^{-1}(u), \Phi^{-1}(v)$)
- Parametrii din tabelul lui τ : Gaussiană și t $\rho = 0,707$, Clayton și Gumbel $\theta = 2,0$, Frank $\theta = 5,74$

Interpretarea galeriei de copule

- ▣ Același tau al lui Kendall, aceleași marginale: norii diferă doar în colțuri
- ▣ Gaussiană și Frank: colțurile se răresc, deci extremele comune sunt rare
- ▣ Student t: ambele colțuri rămân dense
- ▣ Clayton: un colț stânga-jos ascuțit (prăbușiri comune); Gumbel: un colț dreapta-sus ascuțit
- ▣ Un manager de risc care calibrează doar τ sau ρ poate alege oricare dintre cele cinci și obține riscuri în coadă foarte diferite

Dependența în cozi

- Coadă inferioară:
 $\lambda_L = \lim_{q \downarrow 0} P(V \leq q \mid U \leq q) = \lim_{q \downarrow 0} C(q, q)/q$
- Coadă superioară: $\lambda_U = \lim_{q \downarrow 0} P(V > 1 - q \mid U > 1 - q)$
- $\lambda > 0$: extremele vin împreună oricât de extreme ar fi;
 $\lambda = 0$: independență asimptotică
- Dependența în cozi este o proprietate a copulei, invizibilă în ρ

Forme închise

	λ_L	λ_U
Gaussiană	0	0
Student t	$2 t_{\nu+1} \left(- \sqrt{\frac{(\nu+1)(1-\rho)}{1+\rho}} \right)$	la fel
Clayton	$2^{-1/\theta}$	0
Gumbel	0	$2 - 2^{1/\theta}$
Frank	0	0


Exemplu lucrat: dependența în cozi pas cu pas

- ▣ Student t cu $\rho = 0,707$ și $\nu = 4$ (parametrii din galerie)
 - ▶ Argumentul: $\sqrt{(\nu + 1)(1 - \rho)/(1 + \rho)} = \sqrt{5 \times 0,293/1,707} = 0,926$
 - ▶ Funcția de repartiție Student t cu $\nu + 1 = 5$ grade de libertate: $t_5(-0,926) = 0,1984$
 - ▶ $\lambda_L = \lambda_U = 2 \times 0,1984 = 0,397$
- ▣ Clayton cu $\theta = 2$: $\lambda_L = 2^{-1/2} = 0,707$; Gumbel cu $\theta = 2$: $\lambda_U = 2 - \sqrt{2} = 0,586$
 - ▶ Același $\tau = 0,5$, dar probabilitatea unui extrem comun variază de la 0 la aproximativ 0,7
- ▣ Semnificația lui $\lambda = 0,40$: dat fiind un crash extrem într-un activ, celălalt se prăbușește și el în aproximativ 40% din cazuri

Estimarea copulelor

- ▣ **Verosimilitate maximă completă:** marginale și copulă împreună; eficientă, dar grea și fragilă
- ▣ **IFM** (funcții de inferență pentru marginale, [Joe \(2005\)](#)): doi pași
 - ▶ Estimăm marginale parametrice (de exemplu GARCH cu Student t); $\hat{u}_{it} = \hat{F}_i(x_{it})$; maximizăm $\sum_t \ln c(\hat{u}_{1t}, \hat{u}_{2t}; \theta)$
- ▣ **CML** (verosimilitate maximă canonică, [Genest, Ghoudi & Rivest \(1995\)](#)): fără marginale parametrice
 - ▶ Pseudo-observații $\hat{u}_{it} = \text{rang}(x_{it}) / (T + 1)$; apoi maximizăm verosimilitatea copulei
 - ▶ Robustă la marginale specificate greșit; $T + 1$ ține $\hat{u}$ departe de 0 și 1
- ▣ Pentru randamente: filtrăm întâi fiecare serie cu GARCH, apoi folosim rangurile reziduurilor standardizate
- ▣ Alegerea modelului: $AIC = 2k - 2\ell$, $BIC = k \ln T - 2\ell$

De la reziduuri la pseudo-observații: JPM și BAC




- JPMorgan Chase (JPM) și Bank of America (BAC), zilnic 2010–2026 ($T = 4122$), filtrate GARCH(1,1)
- $\hat{\tau}$ Kendall = 0,644, $\hat{\rho}_S$ Spearman = 0,825; ambele colțuri ale norului uniform sunt dense

Estimările copulelor pentru JPM și BAC

Copula	$\hat{\theta}$ sau $\hat{\rho}$	$\hat{\nu}$	ℓ	ΔAIC	λ_L	λ_U	p adecvare
Gaussiană	0,834	–	2449,3	308,3	0,000	0,000	0,005
Student t	0,844	4,28	2604,5	0,0	0,531	0,531	0,020
Clayton	2,394	–	2083,5	1039,9	0,749	0,000	0,005
Gumbel	2,596	–	2375,8	455,4	0,000	0,694	0,005
Frank	9,266	–	2375,8	455,4	0,000	0,000	0,005

- CML pe pseudo-observațiile reziduurilor GARCH; ΔAIC față de cel mai bun model
- Student t câștigă detașat: $\hat{\nu} = 4,3$ înseamnă extreme comune puternice, $\hat{\lambda} = 0,53$ în ambele cozi
- Gaussiană bate Clayton, Gumbel și Frank: dependența este puternică și aproximativ simetrică
- Ultima coloană: p -valorile testului de adecvare (slide-urile următoare)

Compararea modelelor și adecvarea




Numbers above bars: goodness-of-fit p-value (Rosenblatt Cramer-von Mises, parametric bootstrap)

- Barele: distanța AIC față de cea mai bună copulă; numerele: p -valorile bootstrap ale testului de adecvare

Adecvarea: testul Rosenblatt

- Dacă $(U, V) \sim C_\theta$, atunci $E_1 = U$ și $E_2 = h(V | U) = \partial C_\theta(U, V) / \partial u$ sunt uniforme independente
- Statistica (Genest, Rémillard & Beaudoin (2009)): $S_n = n \int_{[0,1]^2} (D_n(e) - e_1 e_2)^2 de$, D_n repartiția empirică a lui (E_1, E_2)
- p -valoarea prin bootstrap parametric, deoarece θ este estimat
 - ▶ Simulăm n perechi din $C_{\hat{\theta}}$, le transformăm în pseudo-observații, reestimăm, recalculăm $S_n^{(b)}$
 - ▶ $p = (1 + \#\{S_n^{(b)} \geq S_n\}) / (B + 1)$; aici $B = 200$ (100 pentru Student t)
- Rezultat: toate familiile sunt respinse la 5%; Student t are de departe cea mai mică statistică (0,099 față de 1,035 pentru Gaussiană)
- De ce sunt toate respinse?
 - ▶ $T = 4122$ dă putere mare; o copulă statică pe 16 ani ignoră faptul că dependența se mișcă (Secțiunea 3)
 - ▶ Remediu: copule variabile în timp (condiționate), Patton (2006)

Dependența empirică în cozi: JPM și BAC



- Estimările $\hat{\lambda}_L(q) = \hat{C}(q, q)/q$ și $\hat{\lambda}_U(q)$ pentru q de la 1% la 20%, cu banda de 90% a aceluiași estimator pe date simulate din copula t estimată

Interpretarea graficului de dependență în cozi

- ▣ La $q = 5\%$: $\hat{\lambda}_L = 0,59$, $\hat{\lambda}_U = 0,54$; la $q = 1\%$: 0,51 și 0,44
- ▣ Când JPM are una dintre cele mai proaste 5% zile, BAC se află în propriile 5% cele mai proaste zile în aproximativ 59% din cazuri
- ▣ Estimările din coada inferioară sunt în banda copulei t (0,57–0,65 la 5%): copula t descrie bine prăbușirile
- ▣ Coada superioară este mai slabă: creșterile comune sunt mai puțin strânse decât prăbușirile comune, o asimetrie pe care copula t nu o poate produce
- ▣ Estimările la q finit sunt deplasate și zgomotoase: λ este o limită, iar foarte puține puncte se află în colțul extrem


O poveste de avertizare: copula Gaussiană și 2008

- ▣ Li (2000) a modelat momentele de faliment comune cu o copulă Gaussiană
 - ▶ Un singur parametru de corelație, calibrat pe marjele de piață, evalua portofolii întregi de credite
- ▣ A devenit standardul pieței pentru evaluarea tranșelor de obligațiuni garantate cu datorii (CDO)
- ▣ Ce a mers prost
 - ▶ Dependență zero în cozi: falimentele comune din criză erau tratate ca aproape imposibile
 - ▶ O corelație statică, calibrată în anii calmi: exact lecțiile Forbes–Rigobon și DCC
- ▣ Copula este un instrument; pericolul a fost o singură alegere comodă, cu cozi subțiri

Recapitulare

- ▣ Sklar: repartiția comună = marginale + copulă; copula conține toată dependența
- ▣ Tau Kendall și rho Spearman depind doar de copulă și corespund unu-la-unu parametrilor familiilor cu un parametru
- ▣ Dependența în cozi: 0 pentru Gaussiană și Frank, simetrică pentru t, inferioară pentru Clayton, superioară pentru Gumbel
- ▣ Estimăm pe pseudo-observațiile reziduurilor GARCH; testăm adecvarea cu statistica Rosenblatt și bootstrap parametric
- ▣ JPM–BAC: copula t este cea mai bună, $\hat{\lambda} \approx 0,53$, dar o copulă statică este totuși respinsă

Acțiuni din SUA, zona euro și România, 2000–2026




- Corelațiile randamentelor săptămânale pe o fereastră de 104 săptămâni (zile comune de tranzacționare, închiderile de vineri)

Interpretarea integrării piețelor

- ▣ Euro Stoxx 50–BET: 0,33 în 2000–2009, 0,45 în 2010–2019, 0,61 din 2020
- ▣ S&P 500–Euro Stoxx 50: 0,84, 0,78, 0,70 în aceleași perioade
- ▣ Corelația mobilă Euro Stoxx 50–BET: 0,31 la sfârșitul lui 2007, 0,65 la sfârșitul lui 2009, 0,29 la sfârșitul lui 2019, 0,76 la sfârșitul lui 2021, 0,35 acum
 - ▶ Salturi în crize, revenire parțială după aceea: integrare sau distorsiunea de volatilitate Forbes–Rigobon?
Seminarul testează acest lucru
- ▣ O corelație mai mică înseamnă o diversificare mai bună pentru investitorii din zona euro care dețin acțiuni românești

Bănci: corelațiile randamentelor săptămânale, 2010–2026




- SUA: JPM și BAC; zona euro: DBK (Deutsche Bank) și BNP (BNP Paribas); România: TLV (Banca Transilvania) și BRD (BRD-Groupe Société Générale)
- 869 săptămâni din 15 ianuarie 2010

Interpretarea corelațiilor dintre bănci

- ▣ Trei blocuri: SUA (0,86), zona euro (0,75), România (0,65)
- ▣ Legăturile dintre regiuni sunt mai slabe pentru România: de exemplu BNP–TLV 0,35, JPM–BRD 0,30
- ▣ BRD este controlată de Société Générale, dar acțiunea ei se mișcă mai mult împreună cu TLV decât cu orice bancă din zona euro
- ▣ Randamentele băncilor au factori comuni la nivel de țară: riscul suveran, dobânzile interne, reglementarea

Corelațiile dintre bănci în timp




- Media corelațiilor pe perechi, pe 52 de săptămâni, ale randamentelor săptămânale: în interiorul regiunilor, între SUA și zona euro și între România și celelalte

Interpretarea corelațiilor dintre bănci în timp

- ▣ Mediile pe toată perioada: în interiorul regiunilor 0,73, SUA–zona euro 0,58, România–celelalte 0,26
- ▣ Martie–iunie 2020: 0,87, 0,68 și 0,56: legătura României s-a dublat într-un șoc global
- ▣ Ultimele valori: 0,56, 0,37, 0,15
- ▣ Diversificarea între sisteme bancare funcționează în vremuri normale și slăbește exact în evenimentele sistemice

O rețea de corelații între bănci



- Arborele de acoperire minimă ([Mantegna \(1999\)](#)) pe distanțele $d_{ij} = \sqrt{2(1 - \rho_{ij})}$: cele 5 legături cele mai puternice care conectează toate cele 6 bănci fără cicluri
- Muchiile: JPM-BAC (0.86); JPM-BNP (0.64); DBK-BNP (0.75); BNP-TLV (0.35); TLV-BRD (0.65); România este legată prin BNP-TLV

De la corelații la riscul sistemic

- ▣ Arborele arată drumul pe care un șoc se propagă cel mai probabil: SUA ↔ zona euro ↔ România
- ▣ Rețelele de corelații sunt primul pas spre măsurile de risc sistemic (Capitolul 18)
 - ▶ Conectivitate din cauzalitate Granger: [Billio, Getmansky, Lo & Pelizzon \(2012\)](#)
 - ▶ Indici de transmitere din descompunerea varianței: [Diebold & Yilmaz \(2009\)](#)
 - ▶ Rețele de evenimente extreme: Financial Risk Meter aplicat firmelor energetice din UE, [Toma, Dima, Grecu, Pele & Lessmann \(2026\)](#)
- ▣ Prețurile energiei și piețele de acțiuni europene: dependență între sectoare, [Grecu, Cramer, Pele & Lessmann \(2024\)](#)
- ▣ Rețelele de corelații moștenesc toate problemele corelațiilor: neliniaritate, variație în timp, cozi

Recapitulare

- ▣ Corelația săptămânală BET–Euro Stoxx 50 a crescut de la 0,33 (anii 2000) la 0,61 (din 2020)
- ▣ Randamentele băncilor se grupează pe regiuni; băncile românești sunt cele mai puțin conectate, cu excepția șocurilor globale
- ▣ Arborii de acoperire minimă rezumă o matrice de corelație sub formă de rețea, puntea spre Capitolul 18

O întrebare deschisă

- Este corelația pozitivă acțiuni–obligațiuni de după 2022 un regim durabil, guvernat de inflație, și poate fi prognozată?
- Întrebarea este deschisă
 - ▶ Campbell, Pflueger & Viceira (2020): semnul co-mișcării obligațiuni–acțiuni urmează relația inflație–producție și regimul politicii monetare
 - ▶ Molenaar, Sénéchal, Swinkels & Wang (2024): corelația pe mai multe țări și pe o istorie lungă și legăturile ei cu condițiile macroeconomice, precum inflația
 - ▶ Acest capitol: corelația zilnică SPY–TLT $-0,40$ în 2002–2021 și $0,11$ în 2022–2026; DCC deasupra țintei în 91% din zile după 2022
- Formularea formală cu corelațiile realizate lunare ρ_m
 - ▶ $z_m = \operatorname{artanh} \rho_m = a + b \pi_{m-2} + u_m$, π inflația anuală CPI din SUA cunoscută la începutul lunii m
 - ▶ $H_0: b = 0$; $H_1: b > 0$; statistica t HAC; infirmată dacă $b \approx 0$ în perioade în care inflația a variat, dar regimul nu

Bucula descoperirii, pas cu pas (1/2)

- Instrumentele sunt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și motoare de literatură (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „*Listează studiile publicate după 2015 despre determinanții corelației acțiuni–obligațiuni, cu DOI, eșantion, măsura corelației, strategia de identificare și estimarea principală.*”
 - ▶ Rezolvăm fiecare DOI pe Crossref și verificăm estimarea în articol, nu în rezumat
- **Ipoteze:** „*Dă explicații concurente pentru schimbarea de semn din 2022 (nivelul inflației, regimul politicii monetare, un șoc al primei de termen, o înăsprire unică) și ce prezice fiecare pentru ρ înainte de 2022 și în afara eșantionului.*”
- **Date și cod:** „*Scrie cod Python care unește prețurile ajustate SPY și TLT din data/market pe zilele comune, calculează corelațiile realizate lunare și adaugă inflația CPI din SUA publicată înainte de începutul fiecărei luni.*”
 - ▶ Replicăm întâi: $-0,40$ (2002–2021) și $0,11$ (2022–2026), cifrele din Secțiunea 1

Bucula descoperirii, pas cu pas (2/2)

- **Robustețe:** „Scrie un plan pre-înregistrat: subeșantionul de dinainte de 2022, inflația de bază în loc de cea totală, randamente săptămânale în loc de zilnice, DCC în loc de corelația realizată, control pentru volatilitatea realizată, decalaj HAC 12.”
 - ▶ Placebo: înlocuim π cu mersuri aleatoare simulate de aceeași persistență; un regresor persistent poate da statistici t mari din întâmplare
- **Critica:** „Joacă rolul unui referent: este b identificat de un singur episod și l-ar explica distorsiunea de volatilitate Forbes–Rigobon? Dă testul care l-ar expune pe fiecare.”
- **Raportul:** fiecare măsură a inflației, fereastră și frecvență încercată; estimările pe subeșantioane lângă cele pe tot eșantionul
- Fixăm planul înainte de prima rulare: orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare

Ce trebuie să verifice omul

- ▣ **Informație din viitor:** CPI pentru luna m se publică în luna $m + 1 \Rightarrow$ folosim π_{m-2} și verificăm calendarul publicărilor
- ▣ **Calendare:** randamentele calculate înainte de unire creează perechi false $\Rightarrow$ unim întâi prețurile pe zilele comune (Secțiunea 2)
- ▣ **Regresor persistent, puține regimuri:** inflația este aproape de o rădăcină unitară și și-a schimbat regimul o singură dată $\Rightarrow$ estimări pe subeșantioane, decalaje HAC lungi, placebo cu serii persistente simulate
- ▣ **Distorsiunea de volatilitate:** corelația măsurată se mișcă odată cu volatilitatea (Secțiunea 4) $\Rightarrow$ adăugăm volatilitatea realizată drept control
- ▣ **Testare multiplă:** mai multe măsuri ale inflației, ferestre și frecvențe $\Rightarrow$ le fixăm în pre-înregistrare
- ▣ **Referințe inventate:** un DOI care nu se rezolvă sau o estimare citată greșit $\Rightarrow$ renunțăm la afirmație și o notăm în `AI_ERRORS.md`

Mini-studiu de caz: determină inflația corelația acțiuni–obligațiuni?

- O propunere tipică a unui asistent: „inflația ridicată face pozitivă corelația acțiuni–obligațiuni”; $H_0: b = 0$
- Replicăm: corelația zilnică SPY–TLT $-0,40$ (2002–2021) și $0,11$ (2022–2026)
- Tot eșantionul, 287 luni (septembrie 2002 – august 2026): $\hat{b} = 0,055$ pe punct procentual de inflație, e.s. HAC $0,019$, $t = 2,94$, $R^2 = 0,046$
 - ▶ ρ lunar mediu: $-0,12$ când inflația depășește 3% (89 luni), $-0,30$ în rest (198)
- Verificarea identificării, doar 2002–2021 (232 luni, dintre care 53 cu inflația peste 3%): $\hat{b} = 0,003$, $t = 0,08$
- Interpretare: panta pe tot eșantionul vine din episodul de după 2022; inflația peste 3% de dinainte nu a mișcat corelația
- O singură schimbare de regim nu poate separa „nivelul inflației” de „regimul politicii” (Campbell, Pflueger & Viceira (2020)): afirmația nu este încă stabilită

Rândul vostru: o sămânță de proiect de echipă

- Întrebarea: prognozează mai bine în afara eșantionului corelația SPY–TLT un model DCC a cărei țintă de corelație depinde de inflație și de dobânda de politică monetară decât DCC-ul simplu?
- Replicăm întâi: estimările DCC din Secțiunea 3 ($a + b = 0,986$, $\bar{Q}_{12} = -0,25$) și panta din mini-studiul de caz $\hat{b} = 0,055$
- Livrabile
 - ▶ O pre-înregistrare de o pagină: ipoteze, funcția de pierdere a prognozei, subeșantioane, placebo și ce ar infirma afirmația
 - ▶ Cod pe data/market plus seria oficială a inflației, o comparație Diebold–Mariano, o autocritică în stilul unui referent
- Notăm fiecare prompt, instrument și rezultat acceptat în AI_USE.md; fiecare eroare prinsă (informație din viitor în CPI, randamente înainte de unire, DOI inventat) și testul care a prins-o în AI_ERRORS.md
- Codul mini-studiului de caz: [Quantlets/Ch_06/ai_discovery_case.py](#); inflația: indicele prețurilor de consum pentru toți consumatorii urbani din SUA, U.S. Bureau of Labor Statistics

Greșeli frecvente

- ▣ Calculul randamentelor înainte de unirea seriilor cu calendare diferite (randamente false de luni, zile pierdute)
- ▣ Compararea corelațiilor zilnice între fusuri orare fără randamente pe 2 zile sau săptămânale
- ▣ Numirea unei creșteri din criză „contagiune” fără corecția Forbes–Rigobon
- ▣ Judecarea adecvării unei copule doar după AIC: cea mai bună dintre cinci poate fi totuși respinsă
- ▣ Presupunerea unei copule Gaussiene pentru risc: dependență zero în cozi prin construcție
- ▣ Încrederea în erorile standard din pasul 2 sau în intervalele Fisher când volatilitatea se grupează

Locul acestui capitol

Se bazează pe

- Capitolul 1: cozi groase și gruparea volatilității pentru serii individuale
- Capitolul 4: optimizarea portofoliului are nevoie de Σ
- Capitolul 5: GARCH univariat este pasul 1 al DCC și filtrul dinaintea copulelor

Conduce la

- Capitolul 7: VaR și ES de portofoliu cu covarianțe DCC și copule simulate
- Capitolul 8: backtesting pentru prognozele de risc multivariate
- Capitolul 18: risc sistemic și rețele financiare

Concluzii

- Corelațiile se mișcă: SPY–TLT și-a schimbat semnul, Bitcoin–SPY a crescut de la aproape zero la 0,31, BET s-a alăturat ciclului european
- EWMA este simplu, DCC estimează dinamica cu $3N + 2$ parametri și respinge corelația constantă
- Corelațiile din criză trebuie corectate pentru volatilitate înainte de a vorbi de contagiune
- Copulele separă marginalele de dependență; dependența în cozi contează pentru pierderile comune
- Modelele statice de dependență sunt respinse pe eșantioane lungi: dependența însăși este dinamică

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ▣  Measuring Statistical Risk
- ▣  Multivariate Statistical Analysis
- ▣  Minimum Spanning Tree
- ▣  FRM: Financial Risk Meter

Cod, date și manuale

- ▣ Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_06
- ▣ Manuale: Franke, Härdle & Hafner (2019); Härdle & Simar (2019); Nelsen (2006)

Bibliografie (1/4)

- ▣ Aielli, G.P. (2013). [Dynamic conditional correlation: on properties and estimation](#). *Journal of Business & Economic Statistics*, 31(3), 282–299.
- ▣ Ang, A., Chen, J. (2002). [Asymmetric correlations of equity portfolios](#). *Journal of Financial Economics*, 63(3), 443–494.
- ▣ Billio, M., Getmansky, M., Lo, A.W., Pelizzon, L. (2012). [Econometric measures of connectedness and systemic risk in the finance and insurance sectors](#). *Journal of Financial Economics*, 104(3), 535–559.
- ▣ Bollerslev, T. (1990). [Modelling the coherence in short-run nominal exchange rates: a multivariate generalized ARCH model](#). *Review of Economics and Statistics*, 72(3), 498–505.
- ▣ Bollerslev, T., Engle, R.F., Wooldridge, J.M. (1988). [A capital asset pricing model with time-varying covariances](#). *Journal of Political Economy*, 96(1), 116–131.
- ▣ Campbell, J.Y., Pflueger, C., Viceira, L.M. (2020). [Macroeconomic drivers of bond and equity risks](#). *Journal of Political Economy*, 128(8), 3148–3185.
- ▣ Clayton, D.G. (1978). [A model for association in bivariate life tables and its application in epidemiological studies of familial tendency in chronic disease incidence](#). *Biometrika*, 65(1), 141–151.
- ▣ Demarta, S., McNeil, A.J. (2005). [The t copula and related copulas](#). *International Statistical Review*, 73(1), 111–129.
- ▣ Diebold, F.X., Yilmaz, K. (2009). [Measuring financial asset return and volatility spillovers, with application to global equity markets](#). *Economic Journal*, 119(534), 158–171.

Bibliografie (2/4)

- ▣ Embrechts, P., McNeil, A.J., Straumann, D. (2002). [Correlation and dependence in risk management: properties and pitfalls](#). In M.A.H. Dempster (ed.), *Risk Management: Value at Risk and Beyond*, 176–223. Cambridge University Press.
- ▣ Engle, R.F. (2002). [Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models](#). *Journal of Business & Economic Statistics*, 20(3), 339–350.
- ▣ Engle, R.F., Kroner, K.F. (1995). [Multivariate simultaneous generalized ARCH](#). *Econometric Theory*, 11(1), 122–150.
- ▣ Forbes, K.J., Rigobon, R. (2002). [No contagion, only interdependence: measuring stock market comovements](#). *Journal of Finance*, 57(5), 2223–2261.
- ▣ Frank, M.J. (1979). [On the simultaneous associativity of \$F\(x, y\)\$ and \$x + y - F\(x, y\)\$](#) . *Aequationes Mathematicae*, 19, 194–226.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Genest, C., Ghoudi, K., Rivest, L.-P. (1995). [A semiparametric estimation procedure of dependence parameters in multivariate families of distributions](#). *Biometrika*, 82(3), 543–552.
- ▣ Genest, C., Rémillard, B., Beaudoin, D. (2009). [Goodness-of-fit tests for copulas: a review and a power study](#). *Insurance: Mathematics and Economics*, 44(2), 199–213.
- ▣ Grecu, R., Cramer, A., Pele, D.T., Lessmann, S. (2024). [The link between energy prices and stock markets in European Union countries](#). SSRN Working Paper.

Bibliografie (3/4)

- ▣ Gumbel, E.J. (1960). *Bivariate exponential distributions*. *Journal of the American Statistical Association*, 55(292), 698–707.
- ▣ Härdle, W.K., Simar, L. (2019). *Applied Multivariate Statistical Analysis*, 5th ed. Springer.
- ▣ Joe, H. (2005). *Asymptotic efficiency of the two-stage estimation method for copula-based models*. *Journal of Multivariate Analysis*, 94(2), 401–419.
- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics – Technical Document*, 4th ed. New York.
- ▣ Kendall, M.G. (1938). *A new measure of rank correlation*. *Biometrika*, 30(1–2), 81–93.
- ▣ Li, D.X. (2000). *On default correlation: a copula function approach*. *Journal of Fixed Income*, 9(4), 43–54.
- ▣ Longin, F., Solnik, B. (2001). *Extreme correlation of international equity markets*. *Journal of Finance*, 56(2), 649–676.
- ▣ Mantegna, R.N. (1999). *Hierarchical structure in financial markets*. *European Physical Journal B*, 11(1), 193–197.
- ▣ Markowitz, H. (1952). *Portfolio selection*. *Journal of Finance*, 7(1), 77–91.

Bibliografie (4/4)

- ▣ Molenaar, R., Sénéchal, E., Swinkels, L., Wang, Z. (2024). [Empirical evidence on the stock–bond correlation](#). *Financial Analysts Journal*, 80(3), 17–36.
- ▣ Nelsen, R.B. (2006). [An Introduction to Copulas](#), 2nd ed. Springer.
- ▣ Patton, A.J. (2006). [Modelling asymmetric exchange rate dependence](#). *International Economic Review*, 47(2), 527–556.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). [Are cryptos becoming alternative assets?](#). *European Journal of Finance*, 29(10), 1064–1105.
- ▣ Sklar, A. (1959). [Fonctions de répartition à n dimensions et leurs marges](#). *Publications de l'Institut de Statistique de l'Université de Paris*, 8, 229–231.
- ▣ Spearman, C. (1904). [The proof and measurement of association between two things](#). *American Journal of Psychology*, 15(1), 72–101.
- ▣ Toma, F.-M., Dima, D.M., Grecu, R., Pele, D.T., Lessmann, S. (2026). [Energy Financial Risk Meter: systemic risk in the EU energy sector](#). SSRN Working Paper.