



Modelarea piețelor financiare

Capitolul 6: Volatilitate multivariată și dependență



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ACWI: All Country World Index (MSCI) (indicele global al acțiunilor din toate țările (MSCI))
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ BAC: Bank of America Corporation (NYSE ticker) (Bank of America Corporation (simbolul bursier NYSE))
- ▣ BEKK: Baba–Engle–Kraft–Kroner (multivariate GARCH model) (modelul GARCH multivariat Baba–Engle–Kraft–Kroner)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- ▣ BNP: BNP Paribas SA (Euronext Paris ticker; Banque Nationale de Paris) (BNP Paribas SA (simbolul bursier Euronext Paris))
- ▣ CCC: Constant Conditional Correlation (model) (modelul cu corelație condiționată constantă)
- ▣ CDO: Collateralised Debt Obligation (obligațiune garantată cu un portofoliu de datorii)
- ▣ CDS: Credit Default Swap (swap pe riscul de credit (contract de asigurare împotriva neplății))
- ▣ CML: Canonical Maximum Likelihood (verosimilitate maximă canonică (pe pseudo-observații))
- ▣ COVID-19: CORonaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- ▣ COVOL: COMmon VOLatility (global COVOL: the size of the volatility shock common to all assets) (volatilitatea comună (COVOL global: mărimea șocului de volatilitate comun tuturor activelor))
- ▣ CPI: Consumer Price Index (indicele prețurilor de consum)
- ▣ DBK: Deutsche Bank AG (Xetra ticker) (Deutsche Bank AG (simbolul bursier Xetra))
- ▣ DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- ▣ DCC-NL: Dynamic Conditional Correlation with NonLinear shrinkage (corelație condiționată dinamică cu shrinkage neliniar al țintei)
- ▣ EPU: Economic Policy Uncertainty (index) (indicele incertitudinii politicii economice)
- ▣ ES: Expected Shortfall (pierdere așteptată în coadă)
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ FRM: Financial Risk Meter (indicatorul de risc financiar sistemic Financial Risk Meter)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)

Acronime folosite în acest material (2/2)

- GAS: Generalised Autoregressive Score (model) (model cu scor autoregresiv generalizat)
- GPR: GeoPolitical Risk (index) (indicele riscului geopolitic)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- IFM: Inference Functions for Margins (funcții de inferență pentru marginale (estimare în doi pași))
- JPM: JPMorgan Chase & Co. (NYSE ticker) (JPMorgan Chase & Co. (simbolul bursier NYSE))
- LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- MSCI: Morgan Stanley Capital International (index provider) (furnizorul de indici Morgan Stanley Capital International)
- NYSE: New York Stock Exchange (Bursa din New York)
- PC1: first Principal Component (prima componentă principală)
- SUA: Statele Unite ale Americii
- UE: Uniunea Europeană
- VEC: VECtorised multivariate GARCH model (vech of the covariance matrix) (modelul GARCH multivariat vectorizat (vech al matricei de covarianță))
- VIX: CBOE Volatility Index (indicele de volatilitate CBOE)

Structura capitolului și rezultatele învățării

Structura capitolului

- ▣ Partea I: de ce contează dependența, estimarea covarianței și incertitudinea ei, GARCH multivariat și DCC, corelațiile în criză și distorsiunea Forbes–Rigobon
- ▣ Partea a II-a: copule și dependență în cozi, aplicații pentru Europa, România și bănci, un studiu de caz despre volatilitatea comună globală, un exemplu de buclă de cercetare asistată de AI
- ▣ Se bazează pe [Capitolul 1](#) (cozi groase, volatility clustering), [Capitolul 4](#) (Σ în alegerea portofoliului) și [Capitolul 5](#) (GARCH univariat); pregătește [Capitolul 7](#) (VaR și ES de portofoliu), [Capitolul 8](#) (backtesting) și [Capitolul 18](#) (risc sistemic)
- ▣ Detaliile tehnice se află în [▶ Anexă](#), la final

La sfârșitul capitolului veți putea

- ▣ estima o covarianță variabilă în timp (fereastră mobilă, EWMA, DCC) și calcula o eroare standard validă pentru o corelație
- ▣ separa contagiunea de distorsiunea de volatilitate a corelațiilor din criză
- ▣ alege, estima și testa o copulă și interpreta dependența ei în cozi la un prag finit și la limită

Rolul dependenței (1/2): diversificarea portofoliului

□ Diversificarea (Markowitz (1952))

- ▶ Varianța portofoliului depinde de corelație printr-un singur termen încrucișat
- ▶ $\sigma_p^2 = w^\top \Sigma w = w^2 \sigma_1^2 + (1 - w)^2 \sigma_2^2 + 2w(1 - w)\rho \sigma_1 \sigma_2$
- ▶ w : ponderea activului 1 ($1 - w$ în activul 2); Σ : matricea de covarianță; σ_1, σ_2 : volatilitățile; ρ : corelația
- ▶ Portofoliu 60/40 din SPY (fondul tranzacționat la bursă pe S&P 500) și TLT (fondul de obligațiuni de stat americane cu scadențe de peste 20 de ani)
- ▶ La aceleași volatilități ale activelor: volatilitatea portofoliului este 10,4% cu corelația din 2002–2021 ($-0,40$) și 13,2% cu cea din 2022–2026 ($0,11$)

Rolul dependenței (2/2): hedging, contagiune și covarianțe variabile

□ Hedging-ul riscului


- ▶ Câte unități din instrumentul de hedging F vindem pentru fiecare unitate din poziția S , pentru a minimiza varianța
- ▶ Raportul de hedging de varianță minimă $h^* = \rho \sigma_S / \sigma_F$: panta regresiei lui r_S pe r_F
- ▶ r_S, r_F : randamentele poziției și ale instrumentului de hedging; σ_S, σ_F : volatilitățile lor; eficiența ρ^2 : proporția din varianță eliminată
- ▶ Dacă se schimbă corelația, hedge-ul de ieri devine inadecvat astăzi: un hedge dinamic cere un ρ_t dinamic

□ Contagiunea și interdependența (Forbes & Rigobon (2002))

- ▶ Contagiunea: o *creștere semnificativă* a legăturilor dintre piețe după un șoc
- ▶ Interdependența: legături prezente în toate stările (comerț, investitori comuni, factori macroeconomici comuni)
- ▶ Corelațiile tind să crească exact când diversificarea este cea mai necesară

- Nou în acest capitol: Σ_t , matricea de covarianță la data t , variază în timp; cum o estimăm și cum măsurăm incertitudinea de selecție a fiecărei estimări a dependenței

Acțiuni și obligațiuni: o corelație care și-a schimbat semnul



- Randamente zilnice SPY și TLT, fereastră de 252 de zile; banda: interval Fisher de 95% pentru date i.i.d.; zonele umbrite: toamna 2008 – martie 2009, februarie–aprilie 2020, ianuarie–octombrie 2022
- Minim $-0,77$ (8 august 2012), maxim $0,32$ (1 iulie 2024), ultima valoare $0,24$
- Pozitivă în 6% din zile înainte de 2022, în 81% din ianuarie 2022
- Șocurile de creștere economică deplasează prețurile acțiunilor și ale obligațiunilor în direcții opuse (corelație negativă); șocurile de inflație le afectează în aceeași direcție (corelație pozitivă, ca în 2022)
- Banda Fisher este prea îngustă aici: ignoră cozile groase și volatility clustering (secțiunea următoare)

MFM_ch6_spy_tlt_rolling

Covarianța de selecție și inferența pentru o corelație (1/2): estimatorul și intervalul Fisher

□ Matricea de covarianță de selecție și corelația Pearson pentru N active pe T zile

- ▶ $\hat{\Sigma} = \frac{1}{T-1} \sum_t (r_t - \bar{r})(r_t - \bar{r})^\top$, $\hat{\rho}_{ij} = \hat{\Sigma}_{ij} / \sqrt{\hat{\Sigma}_{ii} \hat{\Sigma}_{jj}}$
- ▶ $r_t \in \mathbb{R}^N$: vectorul celor N randamente din ziua t , $t = 1, \dots, T$; $\bar{r}$: vectorul mediilor de selecție; $\hat{\Sigma}_{ij}$: elementul (i, j)
- ▶ $N(N+1)/2$ elemente distincte de estimat: 125 250 pentru $N = 500$


□ **Transformarea Fisher:** $z = \operatorname{artanh} \hat{\rho} = \frac{1}{2} \ln \frac{1+\hat{\rho}}{1-\hat{\rho}}$ este aproximativ Normală, cu o varianță care nu depinde de ρ

- ▶ $z \approx N(\operatorname{artanh} \rho, 1/(T-3))$ pentru perechi i.i.d. cu distribuția Normală bivariată
- ▶ Interval de 95% $\tanh(z \pm 1,96/\sqrt{T-3})$, readus pe scara corelației prin $\tanh$; $T = 252$, $\rho = 0,5$: semilărgime de aproximativ 0,09

Covarianța de selecție și inferența pentru o corelație (2/2): metoda delta și HAC

- Când există volatility clustering, metoda delta scrie eroarea de estimare ca o medie de selecție
 - ▶ $\hat{\rho} - \rho \approx \frac{1}{T} \sum_t \psi_t$, $\psi_t = \tilde{x}_t \tilde{y}_t - \frac{\rho}{2}(\tilde{x}_t^2 + \tilde{y}_t^2)$
 - ▶ $\tilde{x}_t, \tilde{y}_t$: cele două randamente standardizate la media 0 și varianța 1; ψ_t : contribuția zilei t la eroare
- Eroarea standard (e.s.) din varianța pe termen lung a lui ψ_t
 - ▶ HAC (consistentă la heteroscedasticitate și autocorelație): nucleu Bartlett, L laguri (Newey & West (1987)); cere staționaritate, momente de ordinul patru finite și dependență slabă
 - ▶ Perechile i.i.d. Normale dau $\text{Var}(\psi_t) = (1 - \rho^2)^2$, varianța Fisher; cozile groase și GARCH o cresc (derivarea în [▶ Anexă](#))
- SPY–TLT zilnic, 2002–2021 ($T = 4891$, $\hat{\rho} = -0,403$): e.s. 0,0120 (Fisher), 0,0217 (momente de ordinul patru, $L = 0$), 0,0227 (HAC, $L = 9$)

Intervale Fisher față de HAC: SPY și TLT




- Corelația mobilă pe 252 de zile, din 5 în 5 zile, cu intervalul Fisher de 95% și intervalul HAC de 95% prin metoda delta (Bartlett, $L = 4$)
- HAC este mai larg în aproape orice fereastră: raportul median al lățimilor 1,24, cuantila de 90% 1,54
- Corelație semnificativ diferită de zero: 73% din ferestre după Fisher, 65% după HAC; concluzia se schimbă în 8,2%
- Pe perioade întregi: e.s. $HAC = 1,9 \times$ Fisher în 2002–2021, $1,4 \times$ din 2022; doar momentele de ordinul patru dau $1,8 \times$: cozile groase contează mai mult decât autocorelația
- Regula pentru randamente zilnice: raportăm intervale HAC prin metoda delta

Ferestre mobile și EWMA

- ▣ **Fereastra mobilă** de lungime m : $\hat{\Sigma}_t = \frac{1}{m} \sum_{s=t-m}^{t-1} r_s r_s^\top$ (media fixată la zero pentru date zilnice)
 - ▶ r_s : vectorul randamentelor din ziua s ; m : numărul de zile trecute folosite
 - ▶ Pozitiv semidefinită (orice varianță de portofoliu ≥ 0): pentru orice vector de ponderi v ,

$$v^\top \hat{\Sigma}_t v = \frac{1}{m} \sum_s (v^\top r_s)^2 \geq 0$$
 - ▶ Singulară dacă $m < N$; pozitiv definită doar dacă cei m vectori de randamente generează $\mathbb{R}^N$
 - ▶ **Efectul ghost** (ghost effect): o zi extremă intră cu ponderea $1/m$ și iese brusc după m zile
- ▣ **EWMA** (exponentially weighted moving average, media mobilă ponderată exponențial, J.P. Morgan/Reuters (1996)): $\Sigma_t = \lambda \Sigma_{t-1} + (1 - \lambda) r_{t-1} r_{t-1}^\top = (1 - \lambda) \sum_{k \geq 1} \lambda^{k-1} r_{t-k} r_{t-k}^\top$
 - ▶ $\lambda \in (0, 1)$: factorul de descreștere; k : vechimea observației în perioade, cu ponderea $(1 - \lambda) \lambda^{k-1}$
 - ▶ $\lambda = 0,94$ pentru date zilnice și $0,97$ pentru date lunare; timpul de înjumătățire $\ln 0,5 / \ln \lambda$: $11,2$ și $22,8$ perioade; eşantion efectiv $(1 + \lambda)/(1 - \lambda) \approx 32$ de zile pentru $\lambda = 0,94$
 - ▶ Pozitiv semidefinită, fără ghost effect; dar un singur λ pentru toate elementele și fără revenire la medie: un GARCH(1,1) integrat fără constantă (Capitolul 5)
- ▣ Același compromis pentru ambele: o fereastră scurtă sau un λ mic reacționează repede, dar sînt zgomotoase; o fereastră lungă sau un λ mare sînt stabile, dar detectează tîrziu o schimbare de regim

EWMA față de ferestre mobile, SPY-TLT din 2019




- Doi estimatori EWMA ($\lambda = 0,94$ și $0,97$) și două ferestre mobile (60 și 250 de zile) pe aceleași date
- Abaterea standard a variației zilnice a estimării: 0,060 (EWMA 0,94), 0,032 (EWMA 0,97), 0,0088 (fereastra de 250 de zile)
- Pozitivă 20 de zile la rând din 10 mai 2022 cu EWMA 0,94, dar abia din 8 decembrie 2022 cu fereastra de 250 de zile
- λ și m sînt fixați dinainte; DCC (secțiunea următoare) își estimează singur viteza și memoria (a, b)

Tranzacționarea asincronă: o capcană pentru corelațiile zilnice

- ▣ Orele de închidere diferă: bursele din București și Frankfurt se închid cu câteva ore înaintea bursei din New York
 - ▶ Știrile din SUA de după închiderea europeană intră în prețurile europene abia a doua zi
- ▣ Consecință (la dependență pozitivă, ca între piețele de acțiuni): corelația din aceeași zi este deplasată spre zero, iar corelația decalată este pozitivă
- ▣ Soluții
 - ▶ Frecvență mai mică: randamente pe 2 zile sau săptămânale, în zilele comune de tranzacționare
 - ▶ Adăugarea termenului decalat: $\rho_0 + \rho_{+1}$ (ρ_0 : corelația din aceeași zi, ρ_{+1} : SUA ieri cu Europa azi)
 - ▶ O aproximare grosieră a corelației sincrone, valabilă doar pentru un lag de o zi, fără autocorelație și cu varianțe egale
- ▣ Regula folosită peste tot: întâi aliniem *prețurile* pe zilele comune de tranzacționare, apoi calculăm randamentele

Corelații zilnice, pe 2 zile și săptămânale, 2000–2026



- SPY, Euro Stoxx 50 și BET în zilele comune de tranzacționare; bare: intervale Fisher de 95%
- SPY–Euro Stoxx 50: 0,59 zilnic, 0,71 pe 2 zile, 0,79 săptămânal; SPY ieri cu Euro Stoxx 50 azi: 0,20
- SPY–BET: 0,22 zilnic față de 0,38 săptămânal (decalat 0,17); Euro Stoxx 50–BET, închideri aproape sincrone: 0,33 față de 0,41
- Valoarea redusă a corelației zilnice SUA–Europa este în parte un artefact de măsurare
- Datele săptămânale sînt mai puțin afectate de asincronism, dar dau 1 367 în loc de 6 446 observații: intervale mai largi

De la volatilitate univariată la volatilitate multivariată (1/2): modelul

- **Capitolul 5:** un activ, $r_t = \sigma_t z_t$, $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$; acum N active și o întreagă matrice de covarianță
 - ▶ $r_t = H_t^{1/2} z_t$, $\mathbb{E}(z_t | \mathcal{F}_{t-1}) = 0$, $\text{Var}(z_t | \mathcal{F}_{t-1}) = I_N$, deci $\text{Var}(r_t | \mathcal{F}_{t-1}) = H_t$
 - ▶ r_t, z_t : vectorii celor N randamente și inovații; H_t : matricea $N \times N$ de covarianță condiționată, cunoscută la $t - 1$
 - ▶ $H_t^{1/2}$: o rădăcină pătrată matriceală, $H_t^{1/2} (H_t^{1/2})^\top = H_t$; I_N : matricea identitate; $\mathcal{F}_{t-1}$: informația pînă la $t - 1$
- Orice model pentru H_t trebuie să asigure
 - ▶ caracterul pozitiv definit la orice t (orice portofoliu are varianță pozitivă); puțini parametri; o dinamică interpretabilă
- Log-cvasi-verosimilitatea Gaussiană, maximizată după parametrii lui H_t
 - ▶ $\ell = -\frac{1}{2} \sum_t (N \ln 2\pi + \ln |H_t| + r_t^\top H_t^{-1} r_t)$
 - ▶ $|H_t|$: determinantul lui H_t ; cvasi: estimările rămîn consistente dacă z_t nu este Normal, dar H_t este corect specificată

De la volatilitate univariată la volatilitate multivariată (2/2): problema dimensiunii

- ▣ **VEC** (Bollerslev, Engle & Wooldridge (1988))
 - ▶ Fiecare element al lui H_t depinde de toate pătratele și produsele încrucișate
 - ▶ Fără garanția caracterului pozitiv definit
- ▣ **BEKK** (Engle & Kroner (1995))
 - ▶ Pozitiv definită prin construcție, greu de interpretat (recursiile în [▶ Anexă](#))
- ▣ **DCC**: $3N$ parametri GARCH univariați plus 2
 - ▶ Ținta corelației (correlation target) se estimează separat (slide-ul următor)
- ▣ Numărul de parametri VEC și BEKK crește ca N^4 și N^2 : imposibil de estimat pentru portofolii mari

Numărul de parametri

N	VEC	BEKK complet	DCC
2	21	11	$6 + 2$
5	465	65	$15 + 2$
10	6 105	255	$30 + 2$
50	3 252 525	6 275	$150 + 2$

Corelația condiționată constantă și dinamică

- Descompunerea: covarianța = volatilități $\times$ corelații $\times$ volatilități
 - ▶ $H_t = D_t R_t D_t$, $D_t = \text{diag}(\sigma_{1t}, \dots, \sigma_{Nt})$
 - ▶ σ_{it} : volatilitatea GARCH a activului i ; R_t : matricea corelațiilor condiționate; $\varepsilon_{it} = r_{it}/\sigma_{it}$: reziduurile standardizate
- CCC (Bollerslev (1990)): $R_t = R$ constantă
- DCC (Engle (2002)): o recursie de tip GARCH pentru o matrice auxiliară Q_t
 - ▶ $Q_t = (1 - a - b) \bar{Q} + a \varepsilon_{t-1} \varepsilon_{t-1}^\top + b Q_{t-1}$, $a, b \geq 0$, $a + b < 1$
 - ▶ $R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2}$
 - ▶ $\bar{Q}$: covarianța de selecție a lui ε_t (correlation targeting); a : reacția la produsul șocurilor de ieri; b : memoria; $a + b$: persistența
 - ▶ A doua relație rescalează Q_t astfel încât diagonala să fie 1: R_t este o matrice de corelație validă
- Doi parametri guvernează toate cele $N(N-1)/2$ corelații: parcimonios, dar toate perechile au aceeași persistență
- Q_t este o pseudo-covarianță, nu o corelație: $\mathbb{E}_{t-1}[\varepsilon_t \varepsilon_t^\top] = R_t \neq Q_t$

Estimarea în doi pași și inferența

- Log-verosimilitatea Gaussiană se împarte într-o parte de volatilitate și o parte de corelație

$$\ell = \underbrace{-\frac{1}{2} \sum_t (N \ln 2\pi + 2 \ln |D_t| + r_t^\top D_t^{-2} r_t)}_{\ell_V} - \underbrace{\frac{1}{2} \sum_t (\ln |R_t| + \varepsilon_t^\top R_t^{-1} \varepsilon_t - \varepsilon_t^\top \varepsilon_t)}_{\ell_C}$$

- ℓ_V : depinde doar de parametrii GARCH (partea de volatilitate); ℓ_C : depinde de (a, b) , date fiind volatilitățile (partea de corelație); $|D_t|$, $|R_t|$: determinanți

- Pasul 1: estimăm N modele GARCH(1,1) univariate, păstrăm σ_{it} și ε_{it} ; pasul 2: fixăm $\tilde{Q}$ la covarianța de selecție a lui ε_t și maximizăm ℓ_C după (a, b)
- Cvasi-verosimilitate: distribuția Normală a lui z_t nu este necesară dacă mediile și covarianțele condiționate sînt corecte
 - Dar correlation targeting cu covarianța de selecție face estimatorul DCC standard inconsistent în general; DCC-ul corectat nu (Aielli (2013))
- Erorile standard din pasul 2 tratează estimările GARCH și $\tilde{Q}$ drept cunoscute: propagăm eroarea lor cu sandwich-ul comun al lui Newey & McFadden (1994) sau prin bootstrap pe ambii pași (▶ Anexă)
- CCC față de DCC: $H_0 : a = 0$; b nu este identificat sub H_0 , deci referința χ^2 este doar orientativă: bootstrap sub CCC

Estimările DCC pentru SPY și TLT

Pasul 1: GARCH(1,1), randamente în %


	ω	α	β	$\alpha + \beta$
SPY	0,0283	0,127	0,848	0,975
TLT	0,0057	0,049	0,943	0,993

Pasul 2: DCC(1,1) și trei erori standard

	estimare	hessiană	boot. pasul 2	boot. ambii
a	0,0522	0,0059	0,0051	0,0052
b	0,9335	0,0084	0,0077	0,0077
$a + b$	0,9857	–	0,0038	0,0040

- Date zilnice 31 iulie 2002 – 18 septembrie 2026, $T = 6\,073$; ținta $\tilde{Q}_{12} = -0,248$
- Persistența $a + b = 0,986$: un șoc asupra lui Q_t se înjumătățește în ≈ 48 de zile, aproximativ, deoarece $\mathbb{E}_{t-1}[\varepsilon_t \varepsilon_t^\top] = R_t \neq Q_t$
- LR față de CCC 533,4; bootstrap al ambilor pași sub CCC ($B = 199$): cea mai mare valoare sub H_0 15,7, $p = 0,005$: CCC respins
- Pasul 1 crește e.s. doar cu 2% (a) și 1% (b): T este mare; e.s.($\hat{b}$) din hessiană este aici conservatoare
- Volatilitatea TLT este mai persistentă (β mai mare), dar reacționează mai puțin la știri (α mai mic) decât cea a SPY

Corelația DCC dintre SPY și TLT, 2002–2026




- Corelația condiționată DCC(1,1), corelația mobilă pe 252 de zile și ținta $\bar{Q}_{12}$
- Între $-0,79$ (2 noiembrie 2011) și $0,49$ (21 mai 2026); ultima valoare $0,36$
- Media: $-0,54$ între 15 septembrie și 31 decembrie 2008, $-0,56$ în 2012, $0,00$ în 2022
- DCC reacționează în câteva zile, ca EWMA, dar viteza a și memoria b sînt estimate
- Din ianuarie 2022 traiectoria este deasupra țintei în 92% din zile (36% înainte): ipoteza unei singure corelații pe termen lung este discutabilă

Testarea corelației constante la o dată necunoscută


- ▣ Tse (2000): un test de tip multiplicator Lagrange pentru corelația condiționată constantă, calculat doar din modelul CCC
- ▣ Alegerea datei rupturii de pe un grafic și testarea ei ulterioară cu un test Fisher z la dată fixă duc la un nivel efectiv prea mare: data este ea însăși aleasă pe baza datelor
- ▣ Wied, Krämer & Dehling (2012): $Q_T = \max_{2 \leq j \leq T} \frac{j}{\sqrt{T} \hat{D}} |\hat{\rho}_j - \hat{\rho}_T|$, $\hat{\rho}_j$ corelația primelor j observații
 - ▶ Compară corelația primelor j zile cu $\hat{\rho}_T$ din tot eșantionul; o diferență mare la un anumit j semnalează o ruptură
 - ▶ $\hat{D}^2$: varianța pe termen lung a lui $\hat{\rho}$ prin metoda delta, nucleu Bartlett cu lățimea $\lfloor T^{1/4} \rfloor$ ($\lfloor \cdot \rfloor$: partea întreagă)
 - ▶ Sub H_0 (corelație, medii și varianțe constante): $Q_T \rightarrow \sup_{0 \leq s \leq 1} |B(s)|$, B o punte browniană (un mers aleator în timp continuu fixat la 0 în $s = 0$ și $s = 1$), $s = j/T$; valoarea critică la 5%: 1,358
 - ▶ Varianțele trebuie să fie constante, deci îl aplicăm reziduurilor standardizate GARCH; data estimată a rupturii $\hat{j} = \arg \max$

Datarea rupturii corelației SPY–TLT




- Procesul Wied-Krämer-Dehling pe reziduurile standardizate $GARCH(1,1)$, $T = 6073$, lățimea 8; linia întreruptă: valoarea critică la 5%
- $Q_T = 4,25$ față de 1,358: corelația constantă este respinsă ($p < 0,001$)
- Ruptura estimată 3 august 2020, nu ianuarie 2022: corelația reziduurilor $-0,36$ înainte, $0,07$ după
- Segmentare binară: o a doua ruptură pe 9 iulie 2007 ($Q = 3,01$); după ruptura principală $Q = 1,56$, $p = 0,015$
- Legea limită este demonstrată pentru serii observate: pe reziduuri estimate p-value-urile sînt aproximative; o singură țintă DCC pe 2002–2026 este o medie a cel puțin două regimuri

Aplicație: ponderi de varianță minimă cu DCC




- Ponderea SPY în portofoliul zilnic de varianță minimă SPY-TLT,
 $w_t = (\sigma_{2t}^2 - \sigma_{12,t}) / (\sigma_{1t}^2 + \sigma_{2t}^2 - 2\sigma_{12,t})$,
 trunchiată la $[0, 1]$, $\sigma_{12,t} = \rho_t \sigma_{1t} \sigma_{2t}$ covarianța condiționată; aceleași volatilități GARCH, corelația din DCC sau constantă $(-0,30)$
- Volatilitatea anualizată: 60/40 fix 10,99%, GARCH cu corelație constantă 9,10%, GARCH cu DCC 9,06%
- Cea mai mare parte a câștigului vine din volatilitățile GARCH; DCC adaugă puțin. Diferența absolută medie de pondere DCC minus constant 0,019, cea mai mare 0,22 (8 iunie 2026)
- Ilustrare în eșantion: un test corect reestimează pe ferestre cu lungime crescătoare și adaugă costurile de tranzacționare (costurile de tranzacționare: [Capitolul 4](#); evaluarea în afara eșantionului: [Capitolul 8](#))

Hedging dinamic în afara eșantionului: BET cu Euro Stoxx 50




- BET și Euro Stoxx 50 zilnic (închideri aproape sincrone) din 5 ianuarie 2010; estimare pînă la sfîrșitul lui 2019 ($n = 2\,491$), evaluare 2020–2026 ($n = 1\,663$) cu parametrii ținuți fixi
- Hedge static: panta din fereastra de estimare, $h = 0,337$; hedge DCC $h_t = \rho_t \sigma_{S,t} / \sigma_{F,t}$ (S : BET, F : Euro Stoxx 50; $\hat{a} = 0,009$, $\hat{b} = 0,964$): medie 0,29, între 0,13 și 0,84
- Varianța eliminată în 2020–2026: static 24,7%, DCC 26,2%; cel mai bun hedge constant ales ex post ($h = 0,41$): 25,6%
- Testul [Diebold & Mariano \(1995\)](#) pe pătratele randamentelor cu hedging (static minus DCC), HAC: $t = 1,29$, p unilateral = 0,098: un câștig mic, nesemnificativ la 5%

Bitcoin și acțiunile americane: corelația DCC



- Bitcoin și SPY în zilele comune de tranzacționare din 18 septembrie 2014 ($T = 3018$); mișcările Bitcoin din weekend intră în randamentul de luni
- Corelația DCC medie 0,04 înainte de 2020, 0,31 din ianuarie 2020; vîrf 0,55 pe 19 mai 2022
- Foarte persistentă: $a = 0,015$, $b = 0,982$, $a + b = 0,9968$; LR 105,6, p bootstrap sub CCC = 0,005: CCC respins
- De la activ de diversificare la activ de risc: corelația din tot eșantionul (0,24) ascunde două regimuri; [Pele et al. \(2023\)](#) analizează dacă criptoactivele au devenit o clasă de active distinctă

Contagiune sau interdependență?



Sediul Lehman Brothers, New York, 15 septembrie
2008, ziua cererii de faliment

Foto: Robert Scoble (2008); CC BY 2.0; Wikimedia


[Commons](#)

- Constatare frecventă: corelațiile măsurate în criză sînt mai mari decît în perioadele calme; o corelație mare în criză nu este încă contagiune, trebuie să o depășească semnificativ pe cea din perioada calmă
- Două explicații foarte diferite
 - ▶ **Contagiune**: se schimbă însuși mecanismul de transmitere
 - ▶ **Distorsiune de volatilitate**: mecanismul rămîne neschimbat, dar o piață-sursă mai volatilă crește mecanic corelația
- **Forbes & Rigobon (2002)**: după corecție, cea mai mare parte a „contagiunii” din 1987, 1994 și 1997 s-a dovedit interdependență
- **Longin & Solnik (2001), Ang & Chen (2002)**: corelațiile cresc pe piețele în scădere, nu pe cele în creștere, o asimetrie pe care distribuția Normală nu o poate produce

Distorsiunea de heteroscedasticitate: derivare

- Modelul: $y_t = \alpha + \beta x_t + \varepsilon_t$, $\text{Cov}(x_t, \varepsilon_t) = 0$, β și σ_ε^2 constante
 - ▶ x_t : randamentul pieței-sursă; y_t : randamentul celeilalte piețe; β : coeficientul de transmitere; ε_t : șocul propriu al lui y , cu varianța σ_ε^2 ; σ_x^2 : varianța lui x
- Corelația: $\rho^2 = \frac{\beta^2 \sigma_x^2}{\beta^2 \sigma_x^2 + \sigma_\varepsilon^2} = \left(1 + \frac{\sigma_\varepsilon^2}{\beta^2 \sigma_x^2}\right)^{-1}$
- Criză (indicele c): $\sigma_{x,c}^2 = (1 + \delta) \sigma_x^2$, $\delta > 0$ creșterea relativă a varianței pieței-sursă; nimic altceva nu se schimbă
- Atunci $\rho_c = \rho \sqrt{\frac{1 + \delta}{1 + \delta \rho^2}}$, deci $|\rho_c| > |\rho|$ pentru $0 < |\rho| < 1$: corelația măsurată crește în valoare absolută deși β este același
- Inversînd: $\rho^* = \frac{\rho_c}{\sqrt{1 + \delta(1 - \rho_c^2)}}$ este corelația din criză corectată pentru creșterea volatilității

Creșterea corelației cauzată numai de volatilitate



- Corelația măsurată în criză ρ_c în funcție de δ , pentru trei corelații adevărate care nu se schimbă
- Linia verticală: în fereastra de criză din 2008, varianța randamentelor S&P 500 pe 2 zile a fost de 7,5 ori nivelul din anul calm ($\delta = 6,54$)
- La acest δ , o corelație adevărată neschimbată de 0,4 se măsoară ca 0,77, iar una de 0,2 ca 0,49

Testul Forbes–Rigobon și inferența lui

□ Procedura

- ▶ Alegem piața-sursă x , o fereastră calmă și una de criză; folosim randamente pe 2 zile ca să neutralizăm diferența dintre orele de închidere ale piețelor
- ▶ Calculăm $\delta = \hat{\sigma}_{x,c}^2 / \hat{\sigma}_{x,calm}^2 - 1$ și ρ^* ; testăm $H_0 : \rho^* \leq \rho_{calm}$ cu statistici Fisher z , convenția din Forbes & Rigobon (2002)

□ Inferența

- ▶ Cu δ fixat, $\text{Var}(\text{artanh } \rho^*) \approx 1/[n_c(1 + \delta(1 - \rho_c^2))] < 1/n_c$ (n_c : observațiile din criză): testul Fisher este conservator
- ▶ δ este estimat, iar randamentele pe 2 zile se suprapun: reeșantionăm împreună ferestrele calmă și de criză (bootstrap staționar, bloc mediu de 10 zile, $B = 1999$ extrageri) și testăm $D = \rho^* - \rho_{calm}$


Ipoteze de reținut

- Niciun șoc comun omis: un factor global care afectează ambele piețe crește atât σ_x , cât și σ_ε , iar corecția este excesivă (Corsetti, Pericoli & Sbracia (2005); ▶ Anexă)
- Nicio legătură inversă de la y la x (fără endogenitate)
- Alegerea ferestrelor contează: o deplasare a ferestrelor cu câteva săptămîni poate inversa rezultatele
- Corecția este excesivă dacă mecanismul de transmitere s-a schimbat efectiv

Exemplu lucrat: criza din 2008 pas cu pas

- ▣ Piața-sursă: S&P 500; anul calm: 14 septembrie 2007 – 12 septembrie 2008 ($n = 242$ randamente pe 2 zile); criza: 15 septembrie 2008 – 31 martie 2009 ($n = 130$)
- ▣ Raportul varianțelor: $1 + \delta = 7,54$, deci $\delta = 6,54$
- ▣ Euro Stoxx 50: $\rho_{calm} = 0,610$, $\rho_c = 0,804$
 - ▶ $\rho^* = 0,804 / \sqrt{1 + 6,54(1 - 0,804^2)} = 0,442$
 - ▶ p-value-ul unilateral: 0,005 cu ρ_c , 0,932 cu ρ^*
- ▣ BET: $\rho_{calm} = 0,216$, $\rho_c = 0,485$, $\rho^* = 0,198$
 - ▶ p-value-ul unilateral: 0,024 cu ρ_c , 0,548 cu ρ^*

2008: corelații de criză brute față de cele corectate




- Corelația randamentelor pe 2 zile cu S&P 500: anul calm, criza (brută) și după corecția Forbes–Rigobon
- Corelațiile brute cresc puternic, Euro Stoxx 50 de la 0,61 la 0,80, BET de la 0,22 la 0,48; ambele creșteri sînt semnificative la 5%, niciuna nu rămîne semnificativă după corecție
- Cu δ estimat: $\hat{\delta} = 6,54$, interval de 90% [3,9; 9,6]; BET ρ^* în [0,16; 0,24], $p = 0,62$; Euro Stoxx 50 în [0,38; 0,52], $p = 0,98$
- Concluzie: nicio dovadă de creștere după corecția pentru volatilitate, în ipotezele modelului; 2008 a fost un șoc comun global, deci ipoteza este îndoielnică, iar testul are putere mică (Seminarul B4 îl repetă pentru 2020)

Corelațiile de depășire

- ▣ Longin & Solnik (2001): corelația condiționată de faptul că ambele randamente depășesc un prag
- ▣ Lower tail la cuantila q : $\rho^-(q) = \text{Corr}(x, y \mid x \leq F_x^{-1}(q), y \leq F_y^{-1}(q))$
- ▣ $F_x^{-1}(q)$: cuantila de ordin q a lui x (de ex. $q = 0,10$: cele mai proaste 10% dintre săptămîni)
- ▣ Upper tail: la fel, cu $x \geq F_x^{-1}(1 - q), y \geq F_y^{-1}(1 - q)$
- ▣ Referința: pentru distribuția Normală bivariată, $\rho^\pm(q) \rightarrow 0$ cînd $q \rightarrow 0$
 - Condiționarea pe valori extreme reduce corelația chiar dacă structura dependenței rămîne neschimbată: comparăm cu curba Normală, nu cu ρ

Corelații de depășire: S&P 500 și Euro Stoxx 50



- Randamente săptămânale 2000–2026 ($n = 1\,393$, $\hat{\rho} = 0,78$ total); linia întreruptă: distribuția Normală bivariată cu aceeași corelație (2 milioane de perechi simulate)
- La $q = 0,10$: pierderi comune $\rho^- = 0,80$ (86 săptămâni), câștiguri comune $\rho^+ = 0,69$ (70 săptămâni); referința Normală 0,41
- Ambele cozi sînt mult peste referința Normală, iar scăderile puternice apar simultan mai des decît creșterile puternice
- Un singur coeficient nu poate descrie acest lucru: este necesar un model al întregii structuri de dependență, o copulă

Limitele corelației liniare

- ▣ Embrechts, McNeil & Straumann (2002): trei erori frecvente despre corelația liniară
- ▣ Corelația măsoară doar dependența *liniară* și nu este invariantă la transformări monotone:
 $\text{Corr}(x, y) \neq \text{Corr}(e^x, e^y)$
- ▣ Marginalele și corelația nu determină distribuția comună
 - ▶ Două portofolii cu aceleași marginale și același ρ pot avea Value at Risk foarte diferite (Capitolul 7)
- ▣ Corelațiile posibile: pentru marginale date, $\rho \in [\rho_{\min}, \rho_{\max}]$, atinse de perechi contramonotone și comonotone
 - ▶ Variabile cu distribuții lognormale $X = e^{\sigma_1 Z}$, $Y = e^{\pm \sigma_2 Z}$, Z Normală standard (+: comonotone, -: contramonotone): $\rho_{\max} = \frac{e^{\sigma_1 \sigma_2} - 1}{\sqrt{(e^{\sigma_1^2} - 1)(e^{\sigma_2^2} - 1)}}$, $\rho_{\min}$ cu $e^{-\sigma_1 \sigma_2}$ la numărător
 - ▶ $\sigma_1 = 1$, $\sigma_2 = 3$: $\rho_{\max} = 0,162$ și $\rho_{\min} = -0,008$: perfect dependente, dar aproape necorelate

Teorema lui Sklar: marginale plus copulă

- ▣ O **copulă** este o funcție de repartiție comună pe $[0, 1]^d$ cu marginale uniforme
- ▣ **Sklar (1959)**: pentru orice repartiție comună F cu marginalele $F_1, \dots, F_d$ există o copulă C astfel încât $F(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d))$
 - ▶ d : numărul de variabile; F_i : funcția de repartiție marginală a lui x_i ; $u_i = F_i(x_i) \in [0, 1]$: nivelul ei de probabilitate
 - ▶ C este unică dacă marginalele sînt continue; invers, orice copulă și orice marginale dau o repartiție comună validă
 - ▶ Cu densități: $f(x) = c(F_1(x_1), \dots, F_d(x_d)) \prod_i f_i(x_i)$, c densitatea copulei, f_i densitățile marginale (copula comonotonă nu are densitate)
- ▣ Marginalele conțin volatilitatea, asimetria și cozile groase ale fiecărui activ (**Capitolele 1 și 5**); copula conține toată dependența și este invariantă la transformări crescătoare ale fiecărei variabile
- ▣ Trei copule de referință și marginile Fréchet–Hoeffding $W \leq C \leq M$ (**Nelsen (2006)**)
 - ▶ Independența $\Pi(u, v) = uv$; comonotonia $M(u, v) = \min(u, v)$; contramonotonia $W(u, v) = \max(u + v - 1, 0)$

Corelații de rang: Kendall și Spearman

- **Tau al lui Kendall (Kendall (1938))**: perechi concordante minus perechi discordante
 - ▶ $\tau = P[(X_1 - X_2)(Y_1 - Y_2) > 0] - P[(X_1 - X_2)(Y_1 - Y_2) < 0]$
 - ▶ $(X_1, Y_1), (X_2, Y_2)$: două extrageri independente ale perechii; concordante: ambele coordonate variază în același sens
 - ▶ Forma în copule: $\tau = 4 \iint C \, dC - 1 = 4 \mathbb{E}[C(U, V)] - 1$
- **Rho al lui Spearman (Spearman (1904))**: corelația Pearson a rangurilor
 - ▶ Forma în copule: $\rho_S = 12 \iint (C(u, v) - uv) \, du \, dv$
- Ambele iau valori în $[-1, 1]$ și depind doar de copulă: 1 pentru M , 0 pentru Π , -1 pentru W ; θ : parametrul copulei

Legătura cu parametrii copulelor

Copula	τ
Gaussiană, t	$\frac{2}{\pi} \arcsin \rho$
Clayton	$\theta/(\theta + 2)$
Gumbel	$1 - 1/\theta$
Frank	$1 - \frac{4}{\theta} [1 - D_1(\theta)]$

- $D_1(\theta) = \frac{1}{\theta} \int_0^\theta \frac{t}{e^t - 1} dt$ (funcția Debye)
- Gaussiană: $\rho_S = \frac{6}{\pi} \arcsin(\rho/2)$

Cinci familii de copule

Familia	$C(u, v)$	Parametru
Gaussiană	$\Phi_{2,\rho}(\Phi^{-1}(u), \Phi^{-1}(v))$	$-1 < \rho < 1$
Student t (Demarta & McNeil (2005))	$t_{2,\rho,\nu}(t_\nu^{-1}(u), t_\nu^{-1}(v))$	$-1 < \rho < 1, \nu > 0$
Clayton (Clayton (1978))	$(u^{-\theta} + v^{-\theta} - 1)^{-1/\theta}$	$\theta > 0$
Gumbel (Gumbel (1960))	$\exp(-[(-\ln u)^\theta + (-\ln v)^\theta]^{1/\theta})$	$\theta \geq 1$
Frank (Frank (1979))	$-\frac{1}{\theta} \ln\left(1 + \frac{(e^{-\theta u} - 1)(e^{-\theta v} - 1)}{e^{-\theta} - 1}\right)$	$\theta \neq 0$

- Φ, Φ^{-1} : funcția de repartiție și funcția cuantilă Normale standard; $\Phi_{2,\rho}$: funcția de repartiție Normală bivariată cu corelația ρ ; $t_\nu, t_{2,\rho,\nu}$: analoagele Student t, cu ν grade de libertate; θ : parametrul de dependență
- Eliptice (Gaussiană, t): se extind la d dimensiuni cu o matrice de corelație, alegerea standard în sistemele de risc; $\nu \rightarrow \infty$ transformă copula t în cea Gaussiană
- Arhimedene (Clayton, Gumbel, Frank): $C(u, v) = \varphi^{-1}(\varphi(u) + \varphi(v))$, φ : generator (descrescător, $\varphi(1) = 0$)
 - Un parametru, formă închisă, simulare ușoară, dar simetrice la permutarea variabilelor și puțin flexibile în dimensiuni mari
- Rotirea cu 180° (copula de supraviețuire a lui $(1 - U, 1 - V)$) transferă dependența în cozi în coada opusă (densitățile și generatorii în [► Anexă](#))


Dependența în cozi

- Lower tail:
 $\lambda_L = \lim_{q \downarrow 0} P(V \leq q \mid U \leq q) = \lim_{q \downarrow 0} C(q, q)/q$, cu
 $U = F_1(X_1)$, $V = F_2(X_2)$
- Upper tail: $\lambda_U = \lim_{q \downarrow 0} P(V > 1 - q \mid U > 1 - q)$
- q : probabilitatea din coadă (nivelul pragului);
 $\lambda_L, \lambda_U \in [0, 1]$; $t_{\nu+1}$ în tabel: funcția de repartiție Student t
 cu $\nu + 1$ grade de libertate
- $\lambda > 0$: valorile extreme apar simultan indiferent de nivelul
 pragului; $\lambda = 0$: independență asimptotică
- Dependența în cozi este o proprietate a copulei, invizibilă în
 ρ ; la un q finit, $C(q, q)/q$ este o probabilitate, nu încă limita

Forme închise

	λ_L	λ_U
Gaussiană	0	0
Student t	$2 t_{\nu+1} \left(- \sqrt{\frac{(\nu+1)(1-\rho)}{1+\rho}} \right)$	la fel
Clayton	$2^{-1/\theta}$	0
Gumbel	0	$2 - 2^{1/\theta}$
Frank	0	0

Cinci copule cu același tau al lui Kendall




- 1500 de perechi simulate din fiecare copulă cu $\tau = 0,5$, pe marginale Normale ($\Phi^{-1}(u)$, $\Phi^{-1}(v)$); Gaussiană și t $\rho = 0,707$, Clayton și Gumbel $\theta = 2,0$, Frank $\theta = 5,74$
- În cozi: copulele Gaussiană și Frank devin rarefiate, copula t rămîne densă în ambele, Clayton se concentrează în lower tail (crahuri comune), Gumbel în upper tail
- Același tau al lui Kendall nu determină riscul extremelor simultane

Estimarea copulelor


- **Verosimilitate maximă completă:** marginalele și copula estimate simultan
 - ▶ Eficientă, dar costisitoare computațional și sensibilă la erorile de specificare
- **IFM** (funcții de inferență pentru marginale, [Joe \(2005\)](#)): doi pași
 - ▶ Estimăm marginale parametrice (de exemplu GARCH cu Student t); $\hat{u}_{it} = \hat{F}_i(x_{it})$ ($\hat{F}_i$: funcția de repartiție marginală estimată); maximizăm $\sum_t \ln c(\hat{u}_{1t}, \hat{u}_{2t}; \theta)$, c densitatea copulei
- **CML** (verosimilitate maximă canonică, [Genest, Ghoudi & Rivest \(1995\)](#)): fără marginale parametrice
 - ▶ Pseudo-observații $\hat{u}_{it} = \text{rang}(x_{it}) / (T + 1)$; apoi maximizăm verosimilitatea copulei
 - ▶ Robustă la marginale specificate greșit; numitorul $T + 1$ menține $\hat{u}$ la distanță de 0 și 1
- Pentru randamente: filtrăm întâi fiecare serie cu GARCH, apoi folosim rangurile reziduurilor standardizate
- Alegerea modelului: $AIC = 2k - 2\ell$, $BIC = k \ln T - 2\ell$ (k : numărul de parametri, ℓ : log-verosimilitatea maximă); valoarea mai mică este mai bună

De la reziduuri la pseudo-observații: JPM și BAC



- JPMorgan Chase (JPM) și Bank of America (BAC), zilnic 2010–2026 ($T = 4\,202$), filtrate GARCH(1,1)
- $\hat{\tau}$ Kendall = 0,641, $\hat{\rho}_S$ Spearman = 0,822
- Norul de puncte cu marginale uniforme este dens în ambele cozi: crahuri comune și creșteri comune

Estimările copulelor și adecvarea lor: JPM și BAC



	$\hat{\theta}$ sau $\hat{\rho}$	$\hat{\nu}$	λ_L	λ_U
Gaussiană	0,833	–	0,000	0,000
Student t	0,842	4,24	0,531	0,531
Clayton	2,384	–	0,748	0,000
Gumbel	2,587	–	0,000	0,693
Frank	9,152	–	0,000	0,000

- Barele: distanța AIC față de cea mai bună copulă; numerele: p-value-urile bootstrap ale testului de adecvare (tabelul complet în [Anexă](#))
- Copula Student t este net superioară: $\hat{\nu} = 4,2$, $\hat{\lambda} = 0,53$ în ambele cozi; copula Gaussiană le depășește pe cele arhimediene: dependență puternică, aproximativ simetrică
- Toate familiile sînt respinse la 5%; copula t are de departe cea mai mică statistică (0,082 față de 0,968 pentru Gaussiană)


Inferența pentru parametrii copulelor

- ▣ **Inversarea lui $\hat{\tau}$:** o U-statistică, cu eroarea standard din proiecția Hoeffding; $\hat{\theta} = g(\hat{\tau})$ prin metoda delta (Genest & Rivest (1993))
 - ▶ g : inversa legăturii $\tau(\theta)$ din tabelul anterior; U-statistică: o medie pe toate perechile de observații
 - ▶ Copule eliptice: $\tau = \frac{2}{\pi} \arcsin \rho$ pentru orice ν , deci τ identifică ρ , niciodată ν
 - ▶ JPM–BAC: $\hat{\tau} = 0,641$ (e.s. 0,0065), $\hat{\rho}_{\tau} = \sin(\pi\hat{\tau}/2) = 0,845$ (e.s. 0,0055); CML $\hat{\rho} = 0,842$ (e.s. 0,0053)
- ▣ **CML: rangurile sînt estimate**, deci inversa hessianei este prea mică; sandwich-ul Genest, Ghoudi & Rivest (1995) adaugă termenii de rang
 - ▶ Creșterea e.s.: +60% pentru ρ Gaussian (S&P 500–Euro Stoxx 50 săptămînal), +17% pentru ρ al copulei t și +1% pentru ν (JPM–BAC)
- ▣ **După filtrarea GARCH (Chen & Fan (2006)):** CML pe rangurile reziduurilor estimate are aceeași limită ca pe inovațiile adevărate
 - ▶ Condiții: inovații i.i.d. cu copula C_{θ} și un GARCH corect specificat; atunci sandwich-ul rămîne valid și, spre deosebire de DCC, nu este nevoie de corecția pasului 1 (Monte Carlo în [Anexă](#))

Adecvarea: testul Rosenblatt

- Dacă $(U, V) \sim C_\theta$, atunci $E_1 = U$ și $E_2 = h(V | U) = \partial C_\theta(U, V) / \partial u$ (funcția de repartiție condiționată a lui V dat fiind U) sînt uniforme independente
- Statistica (Genest, Rémillard & Beaudoin (2009)): $S_n = n \int_{[0,1]^2} (D_n(e) - e_1 e_2)^2 de$
 - ▶ $e = (e_1, e_2) \in [0, 1]^2$; $D_n(e)$: proporția celor n perechi cu $E_1 \leq e_1$ și $E_2 \leq e_2$; $e_1 e_2$: aceeași proporție sub independență; $S_n \geq 0$, valori mari înseamnă adecvare slabă
- p-value-ul prin bootstrap parametric, deoarece θ este estimat
 - ▶ Simulăm n perechi din $C_{\hat{\theta}}$, le transformăm din nou în pseudo-observații prin ranguri, reestimăm, recalculăm $S_n^{(b)}$
 - ▶ $p = (1 + \#\{S_n^{(b)} \geq S_n\}) / (B + 1)$; pentru JPM-BAC $B = 200$ (100 pentru Student t)
- Pe reziduuri GARCH, Rémillard (2017) arată că testele bazate pe ranguri își păstrează limita și bootstrap-ul parametric se aplică
- Cu $T = 4\,202$ testul are putere mare împotriva abaterilor mici: o respingere nu indică ce caracteristică a dependenței lipsește din model

Dependența empirică în cozi: JPM și BAC



- $\hat{\lambda}_L(q) = \hat{C}(q, q)/q$ și $\hat{\lambda}_U(q)$ pentru q între 1% și 20%; banda: intervalul de 90% al aceluiași estimator pe date simulate din copula t estimată
- $q = 5\%$: $\hat{\lambda}_L = 0,61$, $\hat{\lambda}_U = 0,55$; $q = 1\%$: 0,52 și 0,43
- Când JPM are una dintre cele mai proaste 5% zile, BAC se află în propriile 5% cele mai proaste zile în aproximativ 61% din cazuri
- Lower tail-ul este în banda copulei t (0,57–0,65 la 5%): copula t descrie bine craturile
- Valorile la q finit sînt probabilități la prag, nu limita λ ; puține puncte se află în zona extremă


Semnificația asimetriei cozilor

- ▣ Schmidt & Stadtmüller (2006): $\hat{\lambda}_L = \frac{n}{k} \hat{C}_n\left(\frac{k}{n}, \frac{k}{n}\right)$, estimatorul din grafic cu $q = k/n$
 - n : volumul eșantionului; k : numărul de observații din coadă; $\hat{C}_n$: copula empirică
 - Un k mai mare scade varianța, dar crește deplasarea (condițiile în [Anexă](#))
- ▣ $H_0 : \lambda_L(q) = \lambda_U(q)$ la un q fixat (probabilități la prag, nu limitele); bootstrap pe perechile de reziduuri, cu rangurile recalculate, $B = 999$

q	k	$\hat{\lambda}_L - \hat{\lambda}_U$	interval de 95%, i.i.d.	interval de 95%, blocuri
5%	210	0,062	$[-0,014; 0,148]$	$[-0,014; 0,138]$
1%	42	0,095	$[-0,095; 0,286]$	$[-0,119; 0,286]$

- ▣ Varianta pe blocuri (bootstrap staționar, bloc mediu de 1,6 și 1,0 zile, regula Politis & White (2004)) permite dependența serială a tail indicator-ilor; intervalul la 1% este mai larg, conform compromisului deplasare–varianță
- ▣ Toate intervalele conțin zero: asimetria nu este semnificativă, deci copula t simetrică nu este contrazisă în cozi

O copulă t dinamică pentru JPM și BAC




- Copula t GAS (generalised autoregressive score, scor autoregresiv generalizat), [Creal, Koopman & Lucas \(2013\)](#): $\rho_t = \tanh f_t$, $f_{t+1} = \omega + A s_t + B f_t$, $s_t = \partial \ln c(\hat{u}_t, \hat{v}_t; \rho_t, \nu) / \partial f_t$ (scalare unitară), aceleași pseudo-observații; A : reacția la scorul s_t , B : persistența
- $A = 0,025$, $B = 0,9926$, $\nu = 5,35$ (static 4,24); raportul de verosimilitate față de copula t statică 245,5
- ρ_t între 0,64 (23 mai 2013) și 0,95 (18 februarie 2021); λ_t între 0,28 și 0,69, în jurul valorii statice 0,53
- Când ρ variază în timp, estimarea lui ν crește: o parte din dependența în cozi a copulei statice reflecta de fapt variația în timp a dependenței
- Sub $A = 0$, B nu este identificat: LR se evaluează prin bootstrap, nu prin χ^2 ; variația în timp este o explicație compatibilă cu respingerea tuturor familiilor statice (Seminarul B6)

O lecție de prudență: copula Gaussiană și 2008


- ▣ Li (2000) a modelat momentele simultane ale falimentelor cu o copulă Gaussiană
 - ▶ Un singur parametru de corelație, calibrat pe spread-urile de piață
 - ▶ Evalua portofolii întregi de credite și a devenit standardul pentru tranșele de obligațiuni garantate cu datorii (CDO)
- ▣ Dependență asimptotică zero în cozi: pentru falimentele comune cele mai extreme da probabilități mai mici decât modelele cu dependență în cozi calibrate pe aceleași date
- ▣ O corelație statică, calibrată în anii calmi: aceleași probleme evidențiate în acest capitol de Forbes–Rigobon și de DCC

Acțiuni din SUA, zona euro și România, 2000–2026




- Randamente săptămânale, fereastră de 104 săptămâni, zile comune de tranzacționare, închiderile de vineri
- Euro Stoxx 50–BET: 0,33 în 2000–2009, 0,45 în 2010–2019, 0,61 din 2020; S&P 500–Euro Stoxx 50: 0,84, 0,78, 0,70
- Euro Stoxx 50–BET pe fereastră mobilă: 0,31 la sfârșitul lui 2007, 0,65 la sfârșitul lui 2009, 0,29 la sfârșitul lui 2019, 0,76 la sfârșitul lui 2021, 0,35 acum
- Salturi în crize și revenire parțială după aceea: integrare sau distorsiunea de volatilitate Forbes–Rigobon? (Seminarul C1)

Bănci: corelațiile randamentelor săptămânale, 2010–2026




- SUA: JPM și BAC; zona euro: DBK (Deutsche Bank) și BNP (BNP Paribas); România: TLV (Banca Transilvania) și BRD (BRD-Groupe Société Générale); 871 săptămîni din 15 ianuarie 2010
- Trei blocuri regionale: SUA 0,86, zona euro 0,75, România 0,65
- Legăturile dintre regiuni sînt cele mai slabe pentru România: BNP–TLV 0,33, JPM–BRD 0,30
- Randamentele băncilor au factori comuni la nivel de țară: riscul suveran, dobînzile interne, reglementarea

Corelațiile dintre bănci în timp



- Media corelațiilor pe perechi, pe 52 de săptămâni, ale randamentelor săptămânale: în interiorul regiunilor, între SUA și zona euro, între România și celelalte
- Toată perioada: în interiorul regiunilor 0,73, SUA–zona euro 0,59, România–celelalte 0,25
- Martie–iunie 2020: 0,87, 0,69 și 0,56: legătura României s-a intensificat de peste două ori într-un șoc global; ultimele valori 0,57, 0,40, 0,15
- Diversificarea între sisteme bancare funcționează în perioade normale și slăbește exact în evenimentele sistemice

O rețea de corelații între bănci



- Arborele de acoperire minimă (Mantegna (1999)) pe $d_{ij} = \sqrt{2(1 - \rho_{ij})}$: cele 5 legături cele mai puternice care conectează toate cele 6 bănci fără cicluri
- Muchiile: JPM-BAC (0,86); JPM-BNP (0,65); DBK-BNP (0,75); BNP-BRD (0,35); TLV-BRD (0,65); România este legată prin BNP-BRD
- Capitolul 4 folosește $\sqrt{(1 - \rho)/2}$: diferă printr-un factor 2, ambele cresc cu $1 - \rho$, deci arborele este același
- Arborele este neorientat și contemporan: nu identifică canalele de transmitere, ci sugerează doar ipoteze pentru măsurile de rețea din Capitolul 18 (literatura în [▶ Anexă](#))

Studiu de caz (1/2): întrebările și ideea

□ Întrebările din Engle & Campos-Martins (2023)

- ▶ ce evenimente modifică simultan volatilitățile aproape tuturor țărilor și claselor de active?
- ▶ cât de mare este acest șoc comun?

□ Mărimea zilnică a șocului comun este COVOL global (common volatility, volatilitatea comună)

□ Ideea nouă: un DCC corect dă reziduuri e_t cu $E_{t-1}(e_t e_t^\top) = I$, dar necorelat nu înseamnă independent: pătratele pot varia împreună

- ▶ $\Psi_t = E_{t-1}[(e_t^2 - \iota)(e_t^2 - \iota)^\top]$
- ▶ e_t : vectorul celor N reziduuri DCC din ziua t ; e_t^2 : pătratul lui element cu element; ι : vectorul de unu; E_{t-1} : valoarea așteptată dată fiind informația de la $t - 1$
- ▶ Elemente nenule în afara diagonalei, $\Psi_{ij,t} \neq 0$: pătratele șocurilor activelor i și j sînt mari în aceleași zile
- ▶ Analogul transversal al modelului ARCH: pătrate corelate între active în aceeași zi, nu în timp; [Herskovic, Kelly, Lustig & Van Nieuwerburgh \(2016\)](#) documentează un asemenea factor în volatilitatea idiosincronică a acțiunilor americane

Studiu de caz (2/2): modelul, estimarea și datele

□ Modelul: un singur factor comun x_t scalează varianța fiecărui reziduu


- ▶ $e_{it} = \sqrt{s_i x_t + 1 - s_i} \varepsilon_{it}$, ε_{it} i.i.d. $\mathcal{N}(0, 1)$, $x_t > 0$, $E_{t-1}(x_t) = 1$
- ▶ x_t : pătratul COVOL global din ziua t ($x_t > 1$: o zi cu șoc comun); $s_i \in [0, 1]$: încărcarea activului i , partea din varianța sa care variază cu x_t

□ Estimarea

- ▶ Încărcări egale $s_i = 1$: $\hat{x}_t = \frac{1}{N} \sum_i e_{it}^2$, media transversală a pătratelor reziduurilor
- ▶ Încărcări diferite: estimare alternantă prin verosimilitate maximă, pe rând pentru x_t (o secțiune transversală pe zi) și s_i (o serie temporală pe activ), cu $s^\top s = 1$ și media $x_t = 1$


□ Testul ξ pentru $H_0: \Psi_{ij} = 0, i \neq j$ ($\mathcal{N}(0, 1)$ sub H_0); date: 47 de ETF-uri de țară listate la NYSE, 2000–2021, și 23 de serii pe clase de active din SUA (detalii în [Anexă](#))

Studiu de caz: șocurile realizate față de indicii de știri



- Lunar, 248 de luni (tabelul 8 din [Engle & Campos-Martins \(2023\)](#)): regresia șocului de volatilitate ACWI (MSCI All Country World Index) pe fiecare indice
 - ▶ Pe COVOL_m^2 , media lunară a lui $\hat{x}_t$ minus 1: $R^2 = 0,404$ (R^2 : proporția de varianță explicată)
 - ▶ Pe variația EPU (economic policy uncertainty, incertitudinea politicii economice, [Baker, Bloom & Davis \(2016\)](#)): 0,110; pe GPR (geopolitical risk, riscul geopolitic, [Caldara & Iacoviello \(2022\)](#)): 0,005; cu ambii indici de știri: doar 0,406
- Printre zilele de vîrf: 9 martie 2020 ($\hat{x}_t = 51,4$), Brexit și o zi cu randament mediu pozitiv
 - ▶ COVOL măsoară mărimea șocului comun, nu semnul lui; indicii de știri măsoară percepția riscului, iar COVOL șocurile reflectate efectiv în prețuri (tabelul evenimentelor în [▶ Anexă](#))

Studiu de caz: COVOL pe clase de active cu ETF-urile cursului, 2000–2026



- 20 de ETF-uri listate în SUA și PC1 (prima componentă principală), 4 ianuarie 2000 – 18 septembrie 2026, 6 717 zile; medie AR(1) cu PC1, GARCH(1,1), apoi estimarea alternantă (13 iterații); romburile: cele mai mari 20 de valori din tabelul 15 din [Engle & Campos-Martins \(2023\)](#)
- Zilele de vîrf pînă la 1 martie 2021: 9 noiembrie 2016 ($\hat{x}_t = 50,5$), 17 septembrie 2001 (43,5), 9 martie 2020 (32,6): alegerile din SUA din 2016, redeschiderea după 11 septembrie și crahul din pandemia COVID-19
- 12 dintre cele mai mari 20 de zile ale replicării noastre dinainte de martie 2021 apar printre cele 20 de date din tabelul 15; cu $s^T s = 1$ și media $\hat{x}_t = 1$ scara depinde de panel, deci comparăm clasamente, nu niveluri
- Cea mai mare în tot eșantionul: 6 noiembrie 2024 (51,8, randamentul mediu al ETF-urilor 0,95%), ziua de după alegerile din SUA din 2024: un șoc comun mare într-o zi de creștere

Întrebări deschise și bucla descoperirii

□ Întrebări

- ▶ este corelația pozitivă acțiuni–obligațiuni de după 2022 un regim durabil, guvernat de inflație?
- ▶ poate fi prognozată?

□ Campbell, Pflueger & Viceira (2020): semnul corelației obligațiuni–acțiuni urmează relația inflație–producție și regimul politicii monetare; Molenaar, Sénéchal, Swinkels & Wang (2024) extinde analiza la mai multe țări și la o istorie lungă

□ Acest capitol: corelația zilnică SPY–TLT $-0,40$ în 2002–2021 și $0,11$ în 2022–2026; DCC deasupra țintei în 92% din zile după 2022


□ Ipoteza cu corelațiile realizate lunare ρ_m : $z_m = \text{artanh } \rho_m = a + b \pi_{m-2} + u_m$, π inflația anuală CPI (consumer price index, indicele prețurilor de consum) din SUA cunoscută la începutul lunii m , u_m eroarea

- ▶ H_0 : $b = 0$; H_1 : $b > 0$; statistica t HAC; infirmată dacă $b \approx 0$ în perioade în care inflația a variat, dar regimul nu

□ Bucla: un asistent AI schițează harta literaturii, ipotezele concurente, codul, un plan de robustețe și o critică de referent (prompturile în [▶ Anexă](#))

- ▶ Cercetătorul verifică fiecare DOI, replică întîi cifrele capitolului și fixează planul înainte de prima rulare

Mini-studiu de caz: inflația și corelația acțiuni-obligațiuni



- Corelația lunară SPY-TLT din randamente zilnice față de inflația cunoscută la începutul lunii (π_{m-2} : CPI pentru luna m se publică în luna $m+1$); versiunea curentă a CPI, deci un test retrospectiv, nu în timp real
- Tot eșantionul, 287 de luni: $\hat{b} = 0,055$ pe punct procentual, e.s. HAC 0,019, $t = 2,96$, $R^2 = 0,047$; ρ mediu $-0,12$ când inflația depășește 3% (89 de luni), $-0,30$ în rest
- Doar 2002–2021 (232 de luni, 53 cu inflația peste 3%): $\hat{b} = 0,002$, $t = 0,06$: panta estimată pe tot eșantionul este determinată de episodul de după 2022
- Asociere, nu cauzalitate, iar o singură schimbare de regim nu poate separa nivelul inflației de regimul politicii (Campbell, Pflueger & Viceira (2020)): afirmația nu este încă demonstrată

Verificările cercetătorului și un punct de plecare pentru proiect

Verificări înaintea oricărei afirmații

- Look-ahead bias: calendarul publicărilor și versiunile datelor (decalajul tratează întârzierea publicării, nu revizuirile)
- Calendare: aliniem prețurile pe zilele comune de tranzacționare înainte de a calcula randamentele
- Regresor persistent, puține regimuri: subeșantioane, laguri HAC lungi, placebo cu serii persistente simulate
- Distorsiunea de volatilitate: control pentru volatilitatea realizată
- Testare multiplă: fixăm dinainte măsurile și ferestrele
- Referințe inventate: un DOI care nu duce la nicio lucrare este eliminat și notat în `AI_ERRORS.md`

Punct de plecare pentru proiect

- Prognozează mai bine în afara eșantionului corelația SPY–TLT un DCC a cărui țintă depinde de inflație și de dobânda de politică monetară decât DCC-ul simplu?
- Replicăm întâi: $a + b = 0,986$, $\bar{Q}_{12} = -0,25$ și panta $\hat{b} = 0,055$
- Predați o pre-înregistrare de o pagină, cod pe datele de piață ale cursului plus CPI, o comparație Diebold–Mariano și o autocritică de referent; notați folosirea AI în `AI_USE.md`

Lista de decizie: întrebare, estimator, incertitudine, eșec

Întrebarea	Estimatorul	Incetitudinea	Eșuează când
S-a schimbat o corelație?	Pearson pe prețuri aliniate	HAC prin metoda delta, bootstrap pe blocuri	Fisher cu volatility clustering; date zilnice între fusuri orare
Covarianța pentru riscul de azi?	EWMA, DCC	bootstrap pe ambii pași	ținta $\tilde{Q}$ se modifică odată cu regimul
Cînd a avut loc ruptura?	Wied–Krämer–Dehling pe reziduuri GARCH	limita punții browniene	data este aleasă după grafic
Contagiune?	Forbes–Rigobon ρ^*	bootstrap staționar, δ estimat	un șoc comun sau legătură inversă
Extreme comune?	copulă pe pseudo-observații GARCH	sandwich de rang, bootstrap parametric	copula Gaussiană ($\lambda = 0$), copulă statică cînd dependența variază în timp

▣ Urmează: [Capitolul 7](#) transformă covarianțele DCC și copulele simulate în VaR și ES de portofolii

Anexă: Studiu suplimentar, cod și date

Cursuri avansate pe quantinar.com

- ▣  Measuring Statistical Risk
- ▣  Multivariate Statistical Analysis
- ▣  Minimum Spanning Tree
- ▣  FRM: Financial Risk Meter

Cod, date și manuale

- ▣ Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_06
- ▣ Manuale: Franke, Härdle & Hafner (2019); Härdle & Simar (2019); Nelsen (2006)

Anexă: Inferența pentru o corelație, metoda delta

- ▣ $\hat{\rho} = g(\hat{m})$, unde $\hat{m}$ este media de selecție a lui $m_t = (x_t, y_t, x_t^2, y_t^2, x_t y_t)$, iar g funcția care transformă aceste cinci momente în corelație; ∇g : gradientul ei
- ▣ Metoda delta: $\sqrt{T}(\hat{\rho} - \rho) \rightarrow N(0, \nabla g^\top \Omega \nabla g)$, Ω covarianța pe termen lung a lui m_t ; cere staționaritate, momente de ordinul patru finite pentru (x_t, y_t) și dependență slabă (mixing)
 - ▶ $\hat{\Omega}$: estimator HAC cu nucleu Bartlett și L laguri (Newey & West (1987))
 - ▶ Forma echivalentă cu funcția de influență: $\hat{\rho} - \rho \approx \frac{1}{T} \sum_t \psi_t$, $\psi_t = \tilde{x}_t \tilde{y}_t - \frac{\rho}{2}(\tilde{x}_t^2 + \tilde{y}_t^2)$
- ▣ Perechi i.i.d. Normale: $\text{Var}(\psi_t) = (1 - \rho^2)^2$, varianța Fisher; cozile groase cresc de regulă $\text{Var}(\psi_t)$, iar GARCH poate face ψ_t autocorelat; cu momente de ordinul patru infinite limita Normală nu mai este valabilă
- ▣ Interval pe scara Fisher: $\tanh(\text{artanh} \hat{\rho} \pm 1,96 \hat{\text{sê}} / (1 - \hat{\rho}^2))$
- ▣ Ultima fereastră SPY–TLT (17 septembrie 2026): $\hat{\rho} = 0,25$, Fisher $[0,13; 0,36]$, HAC $[0,07; 0,41]$; cel mai mare raport al lățimilor 2,02

Anexă: Modelele VEC și BEKK

- ▣ **VEC** (Bollerslev, Engle & Wooldridge (1988)): fiecare element al lui H_t depinde de toate pătratele și produsele încrucișate
 - ▶ $\text{vech}(H_t) = c + A \text{vech}(r_{t-1} r_{t-1}^\top) + B \text{vech}(H_{t-1})$
 - ▶ vech : așază triunghiul inferior al unei matrice simetrice într-un vector; c : vector constant; A, B : matrice pătrate de parametri
 - ▶ Caracterul pozitiv definit nu este garantat; parametri: $N(N+1)/2 \cdot [1 + N(N+1)]$
- ▣ **BEKK** (Engle & Kroner (1995)): pozitiv definită prin construcție dacă $CC^\top$ este pozitiv definită
 - ▶ $H_t = CC^\top + A^\top r_{t-1} r_{t-1}^\top A + B^\top H_{t-1} B$
 - ▶ C : matrice inferior triunghiulară $N \times N$; A, B : matrice $N \times N$ complete; parametri: $N(N+1)/2 + 2N^2$; greu de interpretat, iar verosimilitatea este plată în dimensiuni mari
- ▣ DCC păstrează GARCH univariat pentru fiecare varianță și adaugă doi parametri de corelație: $3N + 2$ în total

Anexă: Estimatori în doi pași, covarianța corectă

- Reunim ecuațiile de estimare într-un sistem: $\sum_t s_{1t}(\theta_1) = 0$ (pasul 1, GARCH) și $\sum_t s_{2t}(\theta_1, \theta_2) = 0$ (pasul 2, corelația); θ_1 : parametrii GARCH, $\theta_2 = (a, b)$, s_{jt} : scorul pasului j în ziua t
- $A_{jk} = \mathbb{E}[\partial s_{jt} / \partial \theta_k^\top]$: A_{21} măsoară cât reacționează scorul corelației la parametrii GARCH
- Newey & McFadden (1994), Secțiunea 6: $\sqrt{T}(\hat{\theta}_2 - \theta_2) \rightarrow N(0, V_2)$ cu
 - ▶ $V_2 = A_{22}^{-1} \mathbb{E}[(s_{2t} - A_{21} A_{11}^{-1} s_{1t})(s_{2t} - A_{21} A_{11}^{-1} s_{1t})^\top] A_{22}^{-1\top}$
- Erorile standard din pasul 2 păstrează doar s_{2t} : omit $A_{21} A_{11}^{-1} s_{1t}$, eroarea de estimare GARCH transmisă în pasul 2
- Cu momente condiționate corecte, scorurile sînt diferențe de martingală, deci termenul din mijloc este varianța lor; altfel folosim versiunea pe termen lung (HAC)
 - ▶ Cu correlation targeting, și $\bar{Q}$ este estimat: ecuațiile lui de momente fac parte din pasul 1 (θ_1 include vech $\bar{Q}$)
- Engle & Sheppard (2001) derivă V_2 pentru DCC; o alternativă simplă este bootstrap-ul întregii proceduri în doi pași (slide-ul următor)

Anexă: Bootstrap pe ambii pași DCC

- Bootstrap parametric pe reziduuri, $B = 199$: decorelăm reziduurile cu factorul Cholesky al lui R_t , le reeșantionăm și simulăm inovații DCC cu $(\hat{a}, \hat{b}, \bar{Q})$
- Doar pasul 2: reestimăm (a, b) pe inovațiile simulate; ambii pași: reconstruim randamentele cu GARCH-ul estimat, reestimăm GARCH, $\bar{Q}$ și (a, b) pe aceleași inovații
- SPY-TLT: pasul 1 crește e.s. cu 2% (a) și 1% (b); e.s. ($\hat{b}$) din hessiana pasului 2 este cu 8% mai mare decât cea bootstrap pentru ambii pași
- Bootstrap-ul sub CCC pentru testul LR folosește același mecanism cu $a = b = 0$: inovații cu corelație constantă, randamente GARCH simulate, ambii pași reestimați

Anexă: Robert Engle și modelul DCC



Robert F. Engle la conferința Western Economic Association International, Santiago, 2017

Foto: Econterms (2017); CC BY-SA 4.0; Wikimedia Commons

- Premiul Nobel pentru științe economice 2003 pentru modelele ARCH ([Capitolul 5](#))
- [Engle \(2002\)](#): „Dynamic Conditional Correlation”
 - ▶ Păstrează flexibilitatea GARCH univariat pentru fiecare varianță
 - ▶ Descrie evoluția corelațiilor printr-o ecuație simplă, ai cărei parametri pot fi estimați
- Rafinare: DCC-ul corectat al lui [Aielli \(2013\)](#), care face din $\bar{Q}$ o țintă consistentă

Anexă: Teste de contagiune dincolo de Forbes–Rigobon

- Corsetti, Pericoli & Sbracia (2005): cu un factor comun, corecția Forbes–Rigobon este excesivă și deplasează testul spre „nicio contagiune”; autorii propun o versiune bazată pe un model factorial
- Rigobon (2003): identificare prin heteroscedasticitate; schimbarea varianței între regimuri identifică coeficientul structural β , o idee de tip variabile instrumentale
- Bootstrap pentru un δ estimat: reeșantionăm ferestrele calmă și de criză cu un bootstrap staționar, recalculăm $\hat{\delta}$, ρ^* și ρ_{calm} la fiecare extragere; p este proporția extragerilor cu $\rho^* - \rho_{calm} \leq 0$
- Concluzia pentru 2008 se menține și după includerea incertitudinii lui δ ; critica factorului comun rămîne valabilă (Seminarul A3, B4)

Anexă: Densitățile și construcția copulelor

- Densitatea Gaussiană: $c = \frac{1}{\sqrt{1-\rho^2}} \exp\left(-\frac{\rho^2(x^2+y^2)-2\rho xy}{2(1-\rho^2)}\right)$, $x = \Phi^{-1}(u)$, $y = \Phi^{-1}(v)$; simetrică, fără dependență în cozi pentru $|\rho| < 1$
- Student t: ν mic înseamnă extreme comune puternice, egale în ambele cozi; copula t este elementul de bază al sistemelor de risc cu o matrice de corelație
- Generatorii arhimedieni φ din $C(u, v) = \varphi^{-1}(\varphi(u) + \varphi(v))$
 - Clayton $\varphi(t) = (t^{-\theta} - 1)/\theta$; Gumbel $\varphi(t) = (-\ln t)^\theta$; Frank $\varphi(t) = -\ln \frac{e^{-\theta t} - 1}{e^{-\theta} - 1}$
- Cozi asimetrice: Clayton pentru crahurile comune ale randamentelor, Gumbel pentru extremele comune ale pierderilor; rotirea cu 180° $\bar{C}(u, v) = u + v - 1 + C(1 - u, 1 - v)$ transferă dependența în coada opusă

Anexă: Estimările copulelor pentru JPM și BAC, tabelul complet

Copula	$\hat{\theta}$ sau $\hat{\rho}$	$\hat{\nu}$	ℓ	ΔAIC	λ_L	λ_U	p adecvare
Gaussiană	0,833	–	2486,0	309,3	0,000	0,000	0,005
Student t	0,842	4,24	2641,7	0,0	0,531	0,531	0,010
Clayton	2,384	–	2116,7	1048,0	0,748	0,000	0,005
Gumbel	2,587	–	2412,2	456,9	0,000	0,693	0,005
Frank	9,152	–	2390,8	499,8	0,000	0,000	0,005

- CML pe pseudo-observațiile reziduurilor GARCH; ΔAIC față de cel mai bun model; p de adecvare din testul Rosenblatt cu bootstrap parametric

Anexă: Estimatorii de rang și precizia lor

- $\hat{\tau}$ este o U-statistică; proiecția Hoeffding dă $\sqrt{n}(\hat{\tau} - \tau) \rightarrow N(0, 16\text{Var}[2C(U, V) - U - V])$
- Estimare: $\widehat{\text{se}}(\hat{\tau}) = 4 \text{sd}(2\hat{C}_n(\hat{U}_i, \hat{V}_i) - \hat{U}_i - \hat{V}_i) / \sqrt{n}$; estimatorii prin inversare $\hat{\theta} = g(\hat{\tau})$ prin metoda delta (Genest & Rivest (1993))
- Estimatorul de momente este aproape la fel de precis ca CML pentru ρ și oferă o valoare inițială robustă pentru maximizarea verosimilității
- Sandwich-ul CML (Genest, Ghoudi & Rivest (1995)): $\sqrt{n}(\hat{\theta} - \theta) \rightarrow N(0, A^{-1}\Sigma A^{-1})$, A informația Fisher a copulei, $\Sigma = \text{Var}[\dot{\ell}_{\theta}(U, V) + W_1(U) + W_2(V)]$, $\dot{\ell}_{\theta}$ scorul lui $\ln c$
 - ▶ $W_1(u) = \iint 1\{u \leq u'\} \partial_u \dot{\ell}_{\theta}(u', v') dC(u', v')$: corecția pentru estimarea marginalelor prin ranguri; W_2 analog pentru v
 - ▶ Copula Gaussiană: varianța $(1 - \rho^2)^2$ pentru CML, față de $(1 - \rho^2)^2 / (1 + \rho^2)$ cu marginale cunoscute
- S&P 500–Euro Stoxx 50 săptămînal, Gaussiană: e.s. 0,0086 (inversa hessianei) față de 0,0138 (sandwich); JPM–BAC, t: ρ 0,0046 față de 0,0053, ν 0,359 față de 0,364

Anexă: Chen și Fan (2006), filtrarea GARCH și limita

- Modelul: $r_{it} = \mu_i + \sigma_{it}\varepsilon_{it}$ cu σ_{it} GARCH; inovațiile $(\varepsilon_{1t}, \varepsilon_{2t})$ i.i.d. cu copula C_θ
- **Chen & Fan (2006)**: CML pe rangurile reziduurilor *estimate* $\hat{\varepsilon}_{it}$ are aceeași distribuție limită ca CML pe rangurile inovațiilor adevărate ε_{it}
- Monte Carlo: 500 eșantioane, $T = 2\,000$, copulă Gaussiană $\rho = 0,8$, inovații Student $t(5)$, GARCH ca cel estimat pentru JPM și BAC
 - ▶ Abaterea standard a lui $\hat{\rho}$: 0,0081 (inovații adevărate) și 0,0082 (reziduuri GARCH); e.s. sandwich medie 0,0081, e.s. din inversa hessiane medii 0,0063
- Adecvarea pe reziduuri: **Rémillard (2017)** arată că testele bazate pe ranguri își păstrează limita și bootstrap-ul parametric se aplică

Anexă: Dependența neparametrică în cozi, condiții

- Schmidt & Stadtmüller (2006): $\hat{\lambda}_L = \frac{n}{k} \hat{C}_n(\frac{k}{n}, \frac{k}{n})$ este consistent și asimptotic Normal dacă $k \rightarrow \infty$, $k/n \rightarrow 0$, copula de coadă există și este îndeplinită o condiție de ordinul doi pentru deplasare ($\sqrt{k} A(n/k) \rightarrow 0$, $A(\cdot)$ viteza cu care $C(q, q)/q$ se apropie de λ_L)
- Bootstrap-ul i.i.d. al perechilor de reziduuri presupune o copulă statică a inovațiilor; bootstrap-ul staționar pe blocuri permite dependența serială a tail indicator-ilor $1\{U \leq q, V \leq q\} - 1\{U > 1 - q, V > 1 - q\}$
- Lungimea medie a blocului după regula automată a lui Politis & White (2004), aplicată tail indicator-ului; $B = 999$ extrageri, rangurile recalculate la fiecare extragere

Anexă: Dependența în dimensiuni mari și în timp

- DCC pentru N mare: verosimilitatea completă este lentă și deplasată
 - ▶ Verosimilitate compusă pe perechi de active, [Pakel, Shephard, Sheppard & Engle \(2021\)](#); DCC-NL, shrinkage neliniar al țintei $\bar{Q}$ (shrinkage-ul din [Capitolul 4](#)), [Engle, Ledoit & Wolf \(2019\)](#)
- Construcțiile de tip vine (vine copulas, copule construite din perechi), [Aas, Czado, Frigessi & Bakken \(2009\)](#)
 - ▶ $d(d-1)/2$ copule bivariate, unele condiționate, în arbori imbricați; fiecare pereche are propria familie și propriile cozi
- Copule arhimedene ierarhice, [Okhrin, Okhrin & Schmid \(2013\)](#)
 - ▶ Grupuri imbricate după tăria dependenței: bănci într-o țară, țări într-o regiune
- Copule dinamice
 - ▶ Parametrii ghidați de scor ([Creal, Koopman & Lucas \(2013\)](#)) se extind la multe active prin copule factoriale; [Oh & Patton \(2018\)](#) măsoară riscul sistemic variabil în timp în spread-urile CDS (credit default swap); copule condiționate: [Patton \(2006\)](#)

Anexă: De la corelații la riscul sistemic

- Rețelele de corelații sînt primul pas spre măsurile de risc sistemic din Capitolul 18
 - ▶ Conectivitate din cauzalitate Granger: [Billio, Getmansky, Lo & Pelizzon \(2012\)](#)
 - ▶ Indici de spillover din descompunerea varianței: [Diebold & Yilmaz \(2009\)](#)
 - ▶ Rețele de evenimente extreme: Financial Risk Meter aplicat firmelor energetice din UE, [Toma, Dima, Grecu, Pele & Lessmann \(2026\)](#)
- Prețurile energiei și piețele de acțiuni din UE: dependența pe regiuni și grupe industriale, [Grecu, Cramer, Pele & Lessmann \(2025\)](#)
- Rețelele de corelații moștenesc toate problemele corelațiilor: neliniaritate, variație în timp, cozi

Anexă: Studiu de caz, date și estimare

- **Modelul** (ec. 8–11 din Engle & Campos-Martins (2023)): pentru $i \neq j$, $\Psi_{ij,t} = s_i s_j v_t$, $v_t = \text{Var}_{t-1}(x_t)$, deci Ψ are un singur factor, iar prima lui componentă principală dă valorile inițiale (ec. 12–13)
 - ▶ Încărcări egale $s_i = 1$: estimatorul de verosimilitate maximă este $\hat{x}_t = \frac{1}{N} \sum_i e_{it}^2$ (ec. 17)
- **Estimarea** (Secțiunea 5.3): maximizăm $-\frac{1}{2} \sum_{i,t} [\ln g_{it} + e_{it}^2/g_{it}]$, $g_{it} = s_i x_t + 1 - s_i$, alternînd x_t și s_i pînă la convergență
 - ▶ După fiecare pas: $s^\top s = 1$, media lui x_t egală cu 1 (Observația 2); testul ξ (ec. 27): media standardizată a produselor $(e_{it}^2 - 1)(e_{jt}^2 - 1)$ pe cele $N(N-1)/2$ perechi, $\mathcal{N}(0, 1)$ sub H_0
- **Date** (Secțiunea 7.1, tabelul B.1): randamente logaritmice zilnice în USD ale celor 47 de ETF-uri de țară listate la NYSE, 2 iunie 2000 – 1 martie 2021; aceeași oră de închidere, deci fără asincronism; panel neechilibrat
 - ▶ Media: AR(1) plus doi factori, ACWI și PC1 a randamentelor ETF-urilor; varianțe GARCH(1,1); COVOL estimat pe cele 47 de serii de reziduuri și pe cei doi factori
 - ▶ În plus: 23 de serii pe clase de active din SUA (Secțiunea 9) și simulări Monte Carlo pentru estimator și pentru test (Secțiunile 5.4, 6.1)

Anexă: Studiu de caz, rezultatele principale

Ziua	$\hat{x}_t$	$\bar{r}_t$ (%)	Evenimentul (eticheta din articol)
9 martie 2020	51,416	-9,650	COVID-19: Italia în carantină; războiul prețului petrolului
24 iunie 2016	49,190	-7,270	Brexit
5 august 2019	39,457	-2,574	Războiul comercial: China își devalorizează moneda
28 aprilie 2020	38,883	2,334	COVID-19: vânzări masive de acțiuni tehnologice
17 septembrie 2001	30,077	-8,630	NYSE se redeschide după 11 septembrie

$\bar{r}_t$: randamentul mediu al ETF-urilor de țară; primele cinci dintre cele mai mari douăzeci de valori din tabelul 6 din [Engle & Campos-Martins \(2023\)](#)

- Încărcări (tabelul 7): cele mai mari încărcări le au PC1 (0,261) și ACWI (0,250); Franța 0,217, Spania 0,200 față de Noua Zeelandă 0,065, Polonia 0,080: factorii au încărcări mai mari decât componentele idiosincratice, deci corelațiile cresc odată cu COVOL (ec. 41)
- Pătratul reziduului ACWI pe COVOL_m^2 (media lunară a lui $\hat{x}_t$ minus 1): 0,326 (e.s. 0,025), $R^2 = 0,404$ (tabelul 8); corelația medie pe perechi de ETF-uri +0,053 pe unitate (e.s. 0,009, tabelul 10, coloana 4); variația VIX 4,034 (e.s. 0,249), $R^2 = 0,517$ (tabelul 12)

Anexă: Studiu de caz, protocolul replicării și limitele

- **Replicare:** versiunea pe clase de active (Secțiunea 9) cu ETF-urile listate în SUA din datele de piață ale cursului, care se închid toate la aceeași oră: 11 ETF-uri sectoriale, Russell 1000 Growth și Value, Russell 2000, piețele dezvoltate și emergente din afara SUA, aur, obligațiuni de stat pe termen lung, obligațiuni corporative, petrol
 - ▶ Un singur factor, PC1; panel neechilibrat; $\hat{x}_t$ prin ec. 17, apoi iterația din Secțiunea 5.3; ξ înainte și după împărțirea lui e_{it}^2 la $\hat{g}_{it}$ (Secțiunea 7.2)
 - ▶ Reperul: tabelul 15 plasează 9 noiembrie 2016 (43,04) și 9 martie 2020 (40,47) între primele patru; dolarul și împărțirea Russell 2000 pe creștere/valoare nu sînt în datele cursului
- **Limite menționate de autori**
 - ▶ După împărțirea la $\hat{g}_{it}$ pătratele sînt încă corelate: posibil un al doilea factor (Secțiunea 7.2); COVOL multifactorial rămîne deschis (Secțiunea 9)
 - ▶ Cu $s^\top s = 1$ încărcările scad cînd N crește: $R_s^2 = 0,640$ pentru $N = 50$, $T = 1000$ față de 0,924 pentru $N = 10$ (tabelul 2); testul pierde putere cînd încărcările diferă, deci se recomandă $T \geq 1000$
- După eșantionul articolului: 3 aprilie 2025 (16,5, -3,67%), după anunțarea taxelor vamale ale SUA, și 10 noiembrie 2022 (15,6, 4,56%), o rată a inflației din SUA sub așteptări
 - ▶ Întrebare deschisă (Seminarul C3): au alegerile, taxele vamale și știrile despre inflație un singur factor comun?
 - ▶ Întrebare deschisă: explică COVOL_m^2 corelațiile DCC lunare și după includerea variației VIX?

Anexă: Bucla descoperirii, prompturi reutilizabile (1/2)

- Instrumentele sînt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și motoare de căutare a literaturii științifice (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „*Listează studiile publicate după 2015 despre determinanții corelației acțiuni–obligțiuni, cu DOI, eșantion, măsura corelației, strategia de identificare și estimarea principală.*”
 - ▶ Verificăm în Crossref fiecare DOI și verificăm estimarea în articol, nu în rezumat
- **Ipoteze:** „*Dă explicații concurente pentru schimbarea de semn din 2022 (nivelul inflației, regimul politicii monetare, un șoc al primei de termen, un episod izolat de înăsprire a politicii monetare) și ce prezice fiecare pentru ρ înainte de 2022 și în afara eșantionului.*”
- **Date și cod:** „*Scrie cod Python care aliniază prețurile ajustate SPY și TLT din datele de piață ale cursului pe zilele comune de tranzacționare, calculează corelațiile realizate lunare și adaugă inflația CPI din SUA publicată înainte de începutul fiecărei luni.*”
 - ▶ Replicăm întîi: $-0,40$ (2002–2021) și $0,11$ (2022–2026)

Anexă: Bucla descoperirii, prompturi reutilizabile (2/2)

- **Robustețe:** „*Scrie un plan pre-înregistrat: subeșantionul de dinainte de 2022, inflația de bază în loc de cea totală, randamente săptămânale în loc de zilnice, DCC în loc de corelația realizată, control pentru volatilitatea realizată, lag HAC 12.*”
 - ▶ Placebo: înlocuim π cu mersuri aleatoare simulate de aceeași persistență; un regresor persistent poate da statistici t mari din întâmplare
- **Critica:** „*Joacă rolul unui referent: este b identificat de un singur episod și l-ar explica distorsiunea de volatilitate Forbes–Rigobon? Indică testele care ar evidenția fiecare dintre aceste probleme.*”
- **Raportul:** fiecare măsură a inflației, fereastră și frecvență încercată; estimările pe subeșantioane lângă cele pe tot eșantionul; orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare
- Codul mini-studiului de caz: [Quantlets/Ch_06/ai_discovery_case.py](#); inflația: indicele prețurilor de consum pentru toți consumatorii urbani din SUA, U.S. Bureau of Labor Statistics

Bibliografie (1/5)

- ▣ Aas, K., Czado, C., Frigessi, A., Bakken, H. (2009). Pair-copula constructions of multiple dependence. *Insurance: Mathematics and Economics*, 44(2), 182–198.
- ▣ Aielli, G.P. (2013). Dynamic conditional correlation: on properties and estimation. *Journal of Business & Economic Statistics*, 31(3), 282–299.
- ▣ Ang, A., Chen, J. (2002). Asymmetric correlations of equity portfolios. *Journal of Financial Economics*, 63(3), 443–494.
- ▣ Baker, S.R., Bloom, N., Davis, S.J. (2016). Measuring economic policy uncertainty. *Quarterly Journal of Economics*, 131(4), 1593–1636.
- ▣ Billio, M., Getmansky, M., Lo, A.W., Pelizzon, L. (2012). Econometric measures of connectedness and systemic risk in the finance and insurance sectors. *Journal of Financial Economics*, 104(3), 535–559.
- ▣ Bollerslev, T. (1990). Modelling the coherence in short-run nominal exchange rates: a multivariate generalized ARCH model. *Review of Economics and Statistics*, 72(3), 498–505.
- ▣ Bollerslev, T., Engle, R.F., Wooldridge, J.M. (1988). A capital asset pricing model with time-varying covariances. *Journal of Political Economy*, 96(1), 116–131.
- ▣ Caldara, D., Iacoviello, M. (2022). Measuring geopolitical risk. *American Economic Review*, 112(4), 1194–1225.
- ▣ Campbell, J.Y., Pflueger, C., Viceira, L.M. (2020). Macroeconomic drivers of bond and equity risks. *Journal of Political Economy*, 128(8), 3148–3185.
- ▣ Chen, X., Fan, Y. (2006). Estimation and model selection of semiparametric copula-based multivariate dynamic models under copula misspecification. *Journal of Econometrics*, 135(1–2), 125–154.
- ▣ Clayton, D.G. (1978). A model for association in bivariate life tables and its application in epidemiological studies of familial tendency in chronic disease incidence. *Biometrika*, 65(1), 141–151.
- ▣ Corsetti, G., Pericoli, M., Sbracia, M. (2005). 'Some contagion, some interdependence': more pitfalls in tests of financial contagion. *Journal of International Money and Finance*, 24(8), 1177–1199.

Bibliografie (2/5)

- ▣ Creal, D., Koopman, S.J., Lucas, A. (2013). Generalized autoregressive score models with applications. *Journal of Applied Econometrics*, 28(5), 777–795.
- ▣ Demarta, S., McNeil, A.J. (2005). The t copula and related copulas. *International Statistical Review*, 73(1), 111–129.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Diebold, F.X., Yilmaz, K. (2009). Measuring financial asset return and volatility spillovers, with application to global equity markets. *Economic Journal*, 119(534), 158–171.
- ▣ Embrechts, P., McNeil, A.J., Straumann, D. (2002). Correlation and dependence in risk management: properties and pitfalls. În M.A.H. Dempster (ed.), *Risk Management: Value at Risk and Beyond*, 176–223. Cambridge University Press.
- ▣ Engle, R.F. (2002). Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- ▣ Engle, R.F., Campos-Martins, S. (2023). What are the events that shake our world? Measuring and hedging global COVOL. *Journal of Financial Economics*, 147(1), 221–242.
- ▣ Engle, R.F., Kroner, K.F. (1995). Multivariate simultaneous generalized ARCH. *Econometric Theory*, 11(1), 122–150.
- ▣ Engle, R.F., Ledoit, O., Wolf, M. (2019). Large dynamic covariance matrices. *Journal of Business & Economic Statistics*, 37(2), 363–375.
- ▣ Engle, R.F., Sheppard, K. (2001). Theoretical and empirical properties of dynamic conditional correlation multivariate GARCH. NBER Working Paper 8554.
- ▣ Forbes, K.J., Rigobon, R. (2002). No contagion, only interdependence: measuring stock market comovements. *Journal of Finance*, 57(5), 2223–2261.
- ▣ Frank, M.J. (1979). On the simultaneous associativity of $F(x, y)$ and $x + y - F(x, y)$. *Aequationes Mathematicae*, 19, 194–226.

Bibliografie (3/5)

- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, ed. a 5-a. Springer.
- ▣ Genest, C., Ghoudi, K., Rivest, L.-P. (1995). *A semiparametric estimation procedure of dependence parameters in multivariate families of distributions*. *Biometrika*, 82(3), 543–552.
- ▣ Genest, C., Rémillard, B., Beaudoin, D. (2009). *Goodness-of-fit tests for copulas: a review and a power study*. *Insurance: Mathematics and Economics*, 44(2), 199–213.
- ▣ Genest, C., Rivest, L.-P. (1993). *Statistical inference procedures for bivariate Archimedean copulas*. *Journal of the American Statistical Association*, 88(423), 1034–1043.
- ▣ Grecu, R.A., Cramer, A.A., Pele, D.T., Lessmann, S. (2025). *The link between energy prices and stock markets in European Union countries*. *The North American Journal of Economics and Finance*, 78, 102420.
- ▣ Gumbel, E.J. (1960). *Bivariate exponential distributions*. *Journal of the American Statistical Association*, 55(292), 698–707.
- ▣ Härdle, W.K., Simar, L. (2019). *Applied Multivariate Statistical Analysis*, ed. a 5-a. Springer.
- ▣ Herskovic, B., Kelly, B., Lustig, H., Van Nieuwerburgh, S. (2016). *The common factor in idiosyncratic volatility: quantitative asset pricing implications*. *Journal of Financial Economics*, 119(2), 249–283.
- ▣ Joe, H. (2005). *Asymptotic efficiency of the two-stage estimation method for copula-based models*. *Journal of Multivariate Analysis*, 94(2), 401–419.
- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics – Technical Document*, ed. a 4-a. New York.
- ▣ Kendall, M.G. (1938). *A new measure of rank correlation*. *Biometrika*, 30(1–2), 81–93.
- ▣ Li, D.X. (2000). *On default correlation: a copula function approach*. *Journal of Fixed Income*, 9(4), 43–54.

Bibliografie (4/5)

- ▣ Longin, F., Solnik, B. (2001). [Extreme correlation of international equity markets](#). *Journal of Finance*, 56(2), 649–676.
- ▣ Mantegna, R.N. (1999). [Hierarchical structure in financial markets](#). *European Physical Journal B*, 11(1), 193–197.
- ▣ Markowitz, H. (1952). [Portfolio selection](#). *Journal of Finance*, 7(1), 77–91.
- ▣ Molenaar, R., Sénéchal, E., Swinkels, L., Wang, Z. (2024). [Empirical evidence on the stock–bond correlation](#). *Financial Analysts Journal*, 80(3), 17–36.
- ▣ Nelsen, R.B. (2006). [An Introduction to Copulas](#), ed. a 2-a. Springer.
- ▣ Newey, W.K., McFadden, D. (1994). [Large sample estimation and hypothesis testing](#). În R.F. Engle, D.L. McFadden (ed.), *Handbook of Econometrics*, Vol. 4, 2111–2245. Elsevier.
- ▣ Newey, W.K., West, K.D. (1987). [A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix](#). *Econometrica*, 55(3), 703–708.
- ▣ Oh, D.H., Patton, A.J. (2018). [Time-varying systemic risk: evidence from a dynamic copula model of CDS spreads](#). *Journal of Business & Economic Statistics*, 36(2), 181–195.
- ▣ Okhrin, O., Okhrin, Y., Schmid, W. (2013). [On the structure and estimation of hierarchical Archimedean copulas](#). *Journal of Econometrics*, 173(2), 189–204.
- ▣ Pakel, C., Shephard, N., Sheppard, K., Engle, R.F. (2021). [Fitting vast dimensional time-varying covariance models](#). *Journal of Business & Economic Statistics*, 39(3), 652–668.
- ▣ Patton, A.J. (2006). [Modelling asymmetric exchange rate dependence](#). *International Economic Review*, 47(2), 527–556.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). [Are cryptos becoming alternative assets?](#). *European Journal of Finance*, 29(10), 1064–1105.

Bibliografie (5/5)

- ▣ Politis, D.N., White, H. (2004). Automatic block-length selection for the dependent bootstrap. *Econometric Reviews*, 23(1), 53–70.
- ▣ Rémillard, B. (2017). Goodness-of-fit tests for copulas of multivariate time series. *Econometrics*, 5(1), 13.
- ▣ Rigobon, R. (2003). Identification through heteroskedasticity. *Review of Economics and Statistics*, 85(4), 777–792.
- ▣ Schmidt, R., Stadtmüller, U. (2006). Non-parametric estimation of tail dependence. *Scandinavian Journal of Statistics*, 33(2), 307–335.
- ▣ Sklar, A. (1959). Fonctions de répartition à n dimensions et leurs marges. *Publications de l'Institut de Statistique de l'Université de Paris*, 8, 229–231.
- ▣ Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15(1), 72–101.
- ▣ Toma, F.-M., Dima, D.M., Grecu, R., Pele, D.T., Lessmann, S. (2026). Energy Financial Risk Meter: systemic risk in the EU energy sector. SSRN Working Paper.
- ▣ Tse, Y.K. (2000). A test for constant correlations in a multivariate GARCH model. *Journal of Econometrics*, 98(1), 107–127.
- ▣ Wied, D., Krämer, W., Dehling, H. (2012). Testing for a change in correlation at an unknown point in time using an extended functional delta method. *Econometric Theory*, 28(3), 570–589.