



Modelarea piețelor financiare

Capitolul 6: Volatilitate multivariată și dependență



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ACWI: All Country World Index (MSCI) (indicele global al acțiunilor din toate țările (MSCI))
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ AR: AutoRegressive (model) (model autoregresiv)
- ▣ ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ BAC: Bank of America Corporation (NYSE ticker) (Bank of America Corporation (simbolul bursier NYSE))
- ▣ BEKK: Baba–Engle–Kraft–Kroner (multivariate GARCH model) (modelul GARCH multivariat Baba–Engle–Kraft–Kroner)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- ▣ BNP: BNP Paribas SA (Euronext Paris ticker; Banque Nationale de Paris) (BNP Paribas SA (simbolul bursier Euronext Paris))
- ▣ CCC: Constant Conditional Correlation (model) (modelul cu corelație condiționată constantă)
- ▣ CDO: Collateralised Debt Obligation (obligațiune garantată cu un portofoliu de datorii)
- ▣ CML: Canonical Maximum Likelihood (verosimilitate maximă canonică (pe pseudo-observații))
- ▣ COVID-19: COroNaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- ▣ COVOL: COmmon VOLatility (global COVOL: the size of the volatility shock common to all assets) (volatilitatea comună (COVOL global: mărimea șocului de volatilitate comun tuturor activelor))
- ▣ CPI: Consumer Price Index (indicele prețurilor de consum)
- ▣ DBK: Deutsche Bank AG (Xetra ticker) (Deutsche Bank AG (simbolul bursier Xetra))
- ▣ DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- ▣ DCC-NL: Dynamic Conditional Correlation with NonLinear shrinkage (corelație condiționată dinamică cu contracție neliniară a țintei)
- ▣ EPU: Economic Policy Uncertainty (index) (indicele incertitudinii politicii economice)
- ▣ ES: Expected Shortfall (pierderea așteptată în coadă)
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ FRM: Financial Risk Meter (indicatorul de risc financiar sistemic Financial Risk Meter)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GAS: Generalised Autoregressive Score (model) (model cu scor autoregresiv generalizat)

Acronime folosite în acest material (2/2)

- ▣ GPR: GeoPolitical Risk (index) (indicele riscului geopolitic)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ IFM: Inference Functions for Margins (funcții de inferență pentru marginale (estimare în doi pași))
- ▣ IIT: Illinois Institute of Technology (Institutul de Tehnologie din Illinois)
- ▣ JPM: JPMorgan Chase & Co. (NYSE ticker) (JPMorgan Chase & Co. (simbolul bursier NYSE))
- ▣ MSCI: Morgan Stanley Capital International (index provider) (furnizorul de indici Morgan Stanley Capital International)
- ▣ NYSE: New York Stock Exchange (Bursa din New York)
- ▣ PC1: first Principal Component (prima componentă principală)
- ▣ SE: Standard Error (eroare standard)
- ▣ SUA: Statele Unite ale Americii
- ▣ UE: Uniunea Europeană
- ▣ VEC: VECTORised multivariate GARCH model (vech of the covariance matrix) (modelul GARCH multivariat vectorizat (vech al matricei de covarianță))
- ▣ VIX: CBOE Volatility Index (indicele de volatilitate CBOE)

Cuprins

De ce contează corelațiile

Covarianțe pe ferestre mobile și EWMA

GARCH multivariat și DCC

Corelații în criză și distorsiunea Forbes–Rigobon

Copule și dependență în cozi

Aplicații: Europa, România și bănci

Studiu de caz: volatilitatea comună globală

AI pentru descoperire științifică

Sinteză

Bibliografie

De ce contează dependența

Trei motive

- **Diversificarea:** riscul portofoliului depinde de modul în care activele se mișcă împreună
 - ▶ **Markowitz (1952):** varianța unui portofoliu este o formă pătratică în matricea de covarianță
- **Acoperirea riscului:** raportul de acoperire este o pantă de regresie condiționată
 - ▶ Dacă se schimbă corelația, acoperirea de ieri este greșită astăzi
- **Contagiunea:** șocurile se propagă între piețe și instituții
 - ▶ Corelațiile tind să crească exact când diversificarea este cea mai necesară

Ce facem în acest capitol

- Estimăm covarianțe variabile în timp: ferestre mobile, EWMA, GARCH multivariat, DCC
- Separăm contagiunea reală de distorsiunea produsă de volatilitate (Forbes–Rigobon)
- Trecem dincolo de corelație: copule și dependență în cozi
- Aplicăm metodele la acțiuni și obligațiuni, la piețele europene și românești, la Bitcoin și la bănci

Recapitulare din Capitolul 4: corelația în riscul portofoliului

- ▣ Varianța portofoliului $\sigma_p^2 = w^\top \Sigma w$; cu două active, corelația apare doar în termenul încrucișat $2w(1-w)\rho\sigma_1\sigma_2$
- ▣ SPY (fondul tranzacționat la bursă pe S&P 500) și TLT (fondul de obligațiuni de stat americane cu scadențe de peste 20 de ani), portofoliu 60/40
 - ▶ Volatilitatea 10,4% cu corelația din 2002–2021 ($-0,40$), 13,2% cu cea din 2022–2026 ($0,11$), la aceleași volatilități ale activelor
- ▣ Raportul de acoperire de varianță minimă $h^* = \rho\sigma_S/\sigma_F$ (panta regresiei lui r_S pe r_F), eficiența ρ^2 : o acoperire dinamică cere un ρ_t dinamic (Secțiunea 3)
- ▣ Ce este nou în acest capitol
 - ▶ Σ_t variază în timp: cum o estimăm și cum măsurăm incertitudinea de selecție a fiecărei estimări a dependenței

Contagiunea: când corelațiile sar




Sediul Lehman Brothers, New York, 15 septembrie
2008, ziua cererii de faliment

Foto: Robert Scoble (2008); CC BY 2.0; Wikimedia
Commons

- **Interdependența:** piețele sunt interconectate în toate condițiile economice
 - ▶ Comerț, investitori comuni, factori macroeconomici comuni
- **Contagiune (Forbes & Rigobon (2002)):** o *creștere semnificativă* a legăturilor dintre piețe după un șoc
 - ▶ O corelație mare în criză nu este suficientă; trebuie să fie mai mare decât în perioadele calme
- Secțiunea 4 arată de ce o comparație naivă a corelațiilor supraestimează contagiunea

Acțiuni și obligațiuni: o corelație care și-a schimbat semnul



- Corelația randamentelor zilnice SPY și TLT pe o fereastră de 252 de zile, cu un interval Fisher de 95% care presupune date i.i.d.
- Benzile gri: toamna 2008 – martie 2009, februarie–aprilie 2020 și ianuarie–octombrie 2022

Interpretarea corelației acțiuni-obligațiuni

- ▣ Minim $-0,77$ (8 august 2012), maxim $0,32$ (1 iulie 2024), ultima valoare $0,24$
- ▣ Proporția zilelor cu corelație mobilă pozitivă: 6% înainte de 2022, 81% din ianuarie 2022
- ▣ Semnul depinde de factorii care determină randamentele la maturitate ale obligațiunilor
 - ▶ Șocuri de creștere economică: prețurile acțiunilor scad, randamentele la maturitate scad, iar prețurile obligațiunilor cresc (corelație negativă)
 - ▶ Șocuri de inflație: acțiunile și obligațiunile scad împreună (corelație pozitivă), ca în 2022
- ▣ Banda Fisher este prea îngustă aici: ignoră cozile groase și gruparea volatilității (Secțiunea 2 dă banda corectată)

Recapitulare

- ▣ Riscul portofoliului este $w^\top \Sigma w$: termenii din afara diagonalei domină adesea în portofoliile mari
- ▣ Raportul de acoperire de varianță minimă este $\rho \sigma_S / \sigma_F$; eficiența sa este ρ^2
- ▣ Contagiunea înseamnă o *creștere* semnificativă a legăturilor, nu doar o mișcare comună puternică
- ▣ Corelația SPY–TLT a trecut în 2022 de la valori predominant negative la valori predominant pozitive: corelațiile nu sunt constante


Covarianța de selecție și precizia ei

- ▣ Randamente $r_t \in \mathbb{R}^N$, $t = 1, \dots, T$; covarianța de selecție $\hat{\Sigma} = \frac{1}{T-1} \sum_t (r_t - \bar{r})(r_t - \bar{r})^\top$
- ▣ Corelația Pearson: $\hat{\rho}_{ij} = \hat{\Sigma}_{ij} / \sqrt{\hat{\Sigma}_{ii} \hat{\Sigma}_{jj}} \in [-1, 1]$
- ▣ Transformarea Fisher: $z = \text{artanh } \hat{\rho} \approx N(\text{artanh } \rho, 1/(T-3))$ pentru date i.i.d. cu distribuția Normală
 - ▶ Interval de 95%: $\tanh(z \pm 1,96/\sqrt{T-3})$
 - ▶ Cu $T = 252$ și $\rho = 0,5$ semilărgimea este de aproximativ 0,09: corelația estimată pe un an are o incertitudine ridicată
- ▣ N active: $N(N+1)/2$ elemente distincte; pentru $N = 500$ sunt 125 250 de numere

Inferența pentru o corelație când volatilitatea se grupează

- ▣ $\hat{\rho} = g(\hat{m})$, unde $\hat{m}$ este media de selecție a lui $m_t = (x_t, y_t, x_t^2, y_t^2, x_t y_t)$
- ▣ Metoda delta: $\sqrt{T}(\hat{\rho} - \rho) \rightarrow N(0, \nabla g^\top \Omega \nabla g)$, Ω covarianța pe termen lung a lui m_t ; cere staționaritate, momente de ordinul patru finite pentru (x_t, y_t) și dependență slabă (mixing)
 - ▶ $\hat{\Omega}$: estimator HAC cu nucleu Bartlett și L decalaje (Newey & West (1987))
 - ▶ Formă echivalentă: $\hat{\rho} - \rho \approx \frac{1}{T} \sum_t \psi_t$, $\psi_t = \tilde{x}_t \tilde{y}_t - \frac{\rho}{2}(\tilde{x}_t^2 + \tilde{y}_t^2)$, $\tilde{x}, \tilde{y}$ standardizate
- ▣ Perechi i.i.d. cu distribuția Normală: $\text{Var}(\psi_t) = (1 - \rho^2)^2$, varianța Fisher; cozile groase cresc de regulă $\text{Var}(\psi_t)$, iar GARCH poate face ψ_t autocorelat; cu momente de ordinul patru infinite limita Normală nu mai este valabilă
- ▣ Interval pe scara Fisher: $\tanh(\text{artanh } \hat{\rho} \pm 1,96 \hat{\text{se}} / (1 - \hat{\rho}^2))$
- ▣ SPY–TLT zilnic, 2002–2021 ($T = 4\,891$, $\hat{\rho} = -0,403$): e.s. 0,0120 (Fisher), 0,0217 (momente de ordinul patru, $L = 0$), 0,0227 (HAC, $L = 9$)

Intervale Fisher versus HAC: SPY și TLT



- Corelația mobilă pe 252 de zile a randamentelor zilnice, din 5 în 5 zile, cu intervalul Fisher de 95% și intervalul HAC de 95% prin metoda delta (Bartlett, $L = 4$)

Interpretarea intervalelor HAC

- Intervalul HAC este mai larg în aproape orice fereastră: raportul median al lățimilor 1,24, cuantila de 90% 1,54, maxim 2,02
- Ferestre cu o corelație semnificativ diferită de zero: 73% după Fisher, 65% după HAC; verdictul se schimbă în 8,2% din ferestre
- Ultima fereastră (17 septembrie 2026): $\hat{\rho} = 0,25$, Fisher $[0,13, 0,36]$, HAC $[0,07, 0,41]$
- Pe perioade întregi: eroarea standard HAC este de 1,9 ori cea Fisher în 2002–2021 și de 1,4 ori din 2022; doar momentele de ordinul patru dau 1,8 înainte de 2022, deci cozile groase contează mai mult decât autocorelarea
- Regula pentru randamente zilnice: raportăm pentru corelații intervale HAC prin metoda delta

Estimatori pe fereastră mobilă

- ▣ Estimăm pe ultimele m observații: $\hat{\Sigma}_t = \frac{1}{m} \sum_{s=t-m}^{t-1} r_s r_s^\top$ (media fixată la zero pentru date zilnice)
- ▣ Compromisul în alegerea lui m
 - ▶ Fereastră scurtă: reacționează repede, dar este zgomotoasă
 - ▶ Fereastră lungă: stabilă, dar detectează târziu o schimbare de regim
- ▣ **Efectul fantomă**: o zi extremă intră cu ponderea $1/m$ și iese brusc după m zile
- ▣ Întotdeauna pozitiv semidefinită ($v^\top \hat{\Sigma}_t v = \frac{1}{m} \sum_s (v^\top r_s)^2 \geq 0$); singulară dacă $m < N$; pozitiv definită doar dacă cei m vectori de randamente generează $\mathbb{R}^N$


EWMA: recursia RiskMetrics

- ▣ Ponderi care scad exponențial:
 $\Sigma_t = \lambda \Sigma_{t-1} + (1 - \lambda) r_{t-1} r_{t-1}^\top$
- ▣ Echivalent: $\Sigma_t = (1 - \lambda) \sum_{k \geq 1} \lambda^{k-1} r_{t-k} r_{t-k}^\top$
- ▣ J.P. Morgan/Reuters (1996): $\lambda = 0,94$ pentru date zilnice și $\lambda = 0,97$ pentru date lunare
- ▣ Timpul de înjumătățire al unui șoc: $\ln 0,5 / \ln \lambda = 11,2$ perioade ($\lambda = 0,94$), 22,8 perioade ($\lambda = 0,97$); perioada este o zi pentru date zilnice și o lună pentru date lunare

Proprietăți

- ▣ Pozitiv semidefinită: o sumă ponderată de produse exterioare
- ▣ Fără efect fantomă: ponderile scad lin
- ▣ Același λ pentru toate varianțele și covarianțele: foarte restrictiv
- ▣ Este un GARCH(1,1) integrat fără constantă: nu revine la medie (Capitolul 5)

EWMA versus ferestre mobile, SPY-TLT din 2019



- Doi estimatori EWMA ($\lambda = 0,94$ și $0,97$) și două ferestre mobile (60 și 250 de zile) pe aceleași date


Interpretarea comparației EWMA

- ▣ Abaterea standard a variației zilnice a estimării: 0,060 (EWMA 0,94), 0,032 (EWMA 0,97), 0,0088 (fereastră de 250 de zile)
- ▣ EWMA cu $\lambda = 0,94$ folosește un eșantion efectiv de aproximativ $(1 + \lambda)/(1 - \lambda) \approx 32$ de zile: rapid, dar zgomotos
- ▣ Corelația rămâne pozitivă 20 de zile la rând începând cu 10 mai 2022 pentru EWMA 0,94, dar abia din 8 decembrie 2022 pentru fereastra de 250 de zile
- ▣ Aici λ și m sunt fixați dinainte; DCC (Secțiunea 3) își estimează din date proprii parametri dinamici (a, b)

Tranzacționarea asincronă: o capcană pentru corelațiile zilnice

- ▣ Orele de închidere diferă: bursele din București și Frankfurt se închid cu câteva ore înaintea bursei din New York
 - ▶ Știrile din SUA de după închiderea europeană intră în prețurile europene abia a doua zi
- ▣ Consecință (la dependență pozitivă, ca între piețele de acțiuni): corelația din aceeași zi este deplasată spre zero, iar corelația decalată este pozitivă
- ▣ Soluții
 - ▶ Frecvență mai mică: randamente pe 2 zile sau săptămânale, în zilele comune de tranzacționare
 - ▶ Adăugarea termenului decalat: $\rho_0 + \rho_{+1}$, o aproximare grosieră a corelației sincrone, valabilă doar pentru un decalaj de o zi, fără autocorelație și cu varianțe egale
- ▣ Regula folosită peste tot: întâi unim *prețurile* în zilele comune, apoi calculăm randamentele

Corelații zilnice, pe 2 zile și săptămânale, 2000–2026



□ SPY, Euro Stoxx 50 și BET în zilele comune de tranzacționare; barele de eroare: intervale Fisher de 95%

Interpretarea efectului de frecvență

- SPY–Euro Stoxx 50: 0,59 zilnic, 0,71 pe 2 zile, 0,79 săptămânal
- Corelația zilnică decalată (SPY ieri, Euro Stoxx 50 azi): 0,20; pentru BET: 0,17
- SPY–BET: 0,22 zilnic față de 0,38 săptămânal; Euro Stoxx 50–BET (închideri aproape sincrone): 0,33 față de 0,41
- Diferența este maximă între fusuri orare: o parte din corelația zilnică „mică” SUA–Europa este un artefact de măsurare
- Datele săptămânale sunt mai curate, dar dau 1 367 în loc de 6 446 observații: intervale mai largi

Recapitulare

- ▣ Ferestrele mobile: simple, dar lungimea ferestrei este arbitrară, iar zilele extreme creează efecte fantomă
- ▣ EWMA: $\Sigma_t = \lambda \Sigma_{t-1} + (1 - \lambda) r_{t-1} r_{t-1}^\top$, pozitiv semidefinită, o singură rată de descreștere pentru toate elementele, fără revenire la medie
- ▣ Eroarea de selecție a unei corelații este mare; pentru SPY–TLT intervalele Fisher o subestimează; intervalele HAC prin metoda delta sunt valide asimptotic dacă momentele de ordinul patru sunt finite și dependența este slabă
- ▣ Între fusuri orare folosim randamente pe 2 zile sau săptămânale ori adăugăm termeni decalați

De la volatilitate univariată la volatilitate multivariată

- ▣ Capitolul 5: $r_t = \sigma_t z_t$ cu $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$
- ▣ Acum: $r_t = H_t^{1/2} z_t$, H_t cunoscută la $t - 1$ (măsurabilă în raport cu $\mathcal{F}_{t-1}$), $\mathbb{E}(z_t | \mathcal{F}_{t-1}) = 0$, $\text{Var}(z_t | \mathcal{F}_{t-1}) = I_N$, deci $\text{Var}(r_t | \mathcal{F}_{t-1}) = H_t$
- ▣ Orice model pentru H_t trebuie să asigure
 - ▶ Caracterul pozitiv definit la fiecare t
 - ▶ Puțini parametri, astfel încât estimarea să fie posibilă pentru multe active
 - ▶ Dinamică interpretabilă: transmiterea volatilității, corelație variabilă în timp
- ▣ Log-cvasi-verosimilitatea Gaussiană: $\ell = -\frac{1}{2} \sum_t (N \ln 2\pi + \ln |H_t| + r_t^\top H_t^{-1} r_t)$

Modelele VEC și BEKK

- **VEC** (Bollerslev, Engle & Wooldridge (1988)): fiecare element al lui H_t depinde de toate pătratele și produsele încrucișate
 - ▶ $\text{vech}(H_t) = c + A \text{vech}(r_{t-1} r_{t-1}^\top) + B \text{vech}(H_{t-1})$
 - ▶ Caracterul pozitiv definit nu este garantat
- **BEKK** (Engle & Kroner (1995)): pozitiv definită prin construcție dacă $CC^\top$ este pozitiv definită
 - ▶ $H_t = CC^\top + A^\top r_{t-1} r_{t-1}^\top A + B^\top H_{t-1} B$
 - ▶ Parametrii sunt greu de interpretat; verosimilitatea este plată în dimensiuni mari

Numărul de parametri

N	VEC	BEKK complet	DCC
2	21	11	$6 + 2$
5	465	65	$15 + 2$
10	6 105	255	$30 + 2$
50	3 252 525	6 275	$150 + 2$

- VEC: $N(N+1)/2 \cdot [1 + N(N+1)]$; BEKK: $N(N+1)/2 + 2N^2$
- DCC: $3N$ parametri GARCH univariați plus 2 (cu țintirea corelației)

Corelația condiționată constantă și dinamică

- ▣ Descompunerea: $H_t = D_t R_t D_t$, $D_t = \text{diag}(\sigma_{1t}, \dots, \sigma_{Nt})$ din modele GARCH univariate
- ▣ **CCC** (Bollerslev (1990)): $R_t = R$ constantă; reziduuri standardizate $\varepsilon_{it} = r_{it}/\sigma_{it}$
- ▣ **DCC** (Engle (2002)): o recursie de tip GARCH pentru o matrice auxiliară Q_t
 - ▶ $Q_t = (1 - a - b) \bar{Q} + a \varepsilon_{t-1} \varepsilon_{t-1}^\top + b Q_{t-1}$, $a, b \geq 0$, $a + b < 1$
 - ▶ $R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2}$
 - ▶ $\bar{Q}$: covarianța de selecție a lui ε_t (țintirea corelației)
- ▣ Doi parametri guvernează toate cele $N(N-1)/2$ corelații: parcimonios, dar toate perechile au aceeași persistență

Robert Engle și modelul DCC



Robert F. Engle la conferința Western Economic Association International, Santiago, 2017

Foto: [Econterms \(2017\)](#); CC BY-SA 4.0; [Wikimedia Commons](#)

- Premiul Nobel pentru științe economice 2003 pentru modelele ARCH (Capitolul 5)
- [Engle \(2002\)](#): „Dynamic Conditional Correlation”
 - ▶ Păstrează flexibilitatea GARCH univariat pentru fiecare varianță
 - ▶ Descrie evoluția corelațiilor printr-o ecuație simplă, ai cărei parametri pot fi estimați
- Rafinare: DCC corectat al lui [Aielli \(2013\)](#), care face din $\bar{Q}$ o țintă consistentă

Estimarea în doi pași

- Log-verosimilitatea Gaussiană se împarte într-o parte de volatilitate și o parte de corelație

$$\ell = \underbrace{-\frac{1}{2} \sum_t (N \ln 2\pi + 2 \ln |D_t| + r_t^\top D_t^{-2} r_t)}_{\ell_V} \underbrace{-\frac{1}{2} \sum_t (\ln |R_t| + \varepsilon_t^\top R_t^{-1} \varepsilon_t - \varepsilon_t^\top \varepsilon_t)}_{\ell_C}$$

- Pasul 1: estimăm N modele GARCH(1,1) univariate; păstrăm σ_{it} și ε_{it}
- Pasul 2: fixăm $\bar{Q}$ la covarianța de selecție a lui ε_t și maximizăm ℓ_C după (a, b)
- Inferență
 - ▶ Cvasi-verosimilitate: distribuția Normală a lui z_t nu este necesară dacă mediile și covarianțele condiționate sunt corect specificate; dar țintirea cu covarianța de selecție face estimatorul DCC standard inconsistent în general, DCC-ul corectat nu ([Aielli \(2013\)](#))
 - ▶ Erorile standard doar din pasul 2 tratează estimările GARCH drept cunoscute: slide-ul următor dă corecția
 - ▶ Testăm CCC contra DCC: $H_0 : a = 0$; b nu este identificat sub H_0 , deci referința χ^2 este doar orientativă

Estimatori în doi pași: covarianța corectă

- Reunim ecuațiile de estimare într-un sistem: $\sum_t s_{1t}(\theta_1) = 0$ (pasul 1, GARCH) și $\sum_t s_{2t}(\theta_1, \theta_2) = 0$ (pasul 2, corelația)
- $A_{jk} = \mathbb{E}[\partial s_{jt} / \partial \theta_k^\top]$: A_{21} măsoară cât reacționează scorul corelației la parametrii GARCH
- Newey & McFadden (1994), Secțiunea 6: $\sqrt{T}(\hat{\theta}_2 - \theta_2) \rightarrow N(0, V_2)$ cu
 - ▶ $V_2 = A_{22}^{-1} \mathbb{E}[(s_{2t} - A_{21}A_{11}^{-1}s_{1t})(s_{2t} - A_{21}A_{11}^{-1}s_{1t})^\top] A_{22}^{-1\top}$
- Erorile standard din pasul 2 păstrează doar s_{2t} : omit $A_{21}A_{11}^{-1}s_{1t}$, eroarea de estimare GARCH transmisă în pasul 2
- Condiții: cu momente condiționate corecte, scorurile sunt diferențe de martingală, deci termenul din mijloc este varianța lor; altfel folosim versiunea pe termen lung (HAC)
 - ▶ Cu țintire, și $\bar{Q}$ este estimat: ecuațiile lui de momente fac parte din pasul 1 (θ_1 include vech $\bar{Q}$)
- Engle & Sheppard (2001) derivă V_2 pentru DCC; o alternativă simplă este bootstrapul întregii proceduri în doi pași, cu GARCH, $\bar{Q}$ și (a, b) reestimate pe fiecare traiectorie

Estimările DCC pentru SPY și TLT

Pasul 1: GARCH(1,1), randamente în %

	ω	α	β	$\alpha + \beta$
SPY	0,0283	0,127	0,848	0,975
TLT	0,0057	0,049	0,943	0,993

Pasul 2: DCC(1,1)

	estimare	eroare std.
a	0,0522	0,0059
b	0,9335	0,0084
$a + b$	0,9857	
$\bar{Q}_{12}$	-0,248	


- Date zilnice 31 iulie 2002 – 18 septembrie 2026, $T = 6073$
- Persistența corelației $a + b = 0,986$: timpul de înjumătățire al unui șoc asupra lui $Q_t \approx 48$ de zile, aproximativ, deoarece $\mathbb{E}_{t-1}[\varepsilon_t \varepsilon_t^\top] = R_t \neq Q_t$
- Raportul de verosimilitate DCC contra CCC:
 $2(\ell_C^{DCC} - \ell_C^{CCC}) = 533,4$
- Sub H_0 : CCC, b nu este identificat: bootstrap parametric al ambilor pași sub CCC ($B = 199$), cea mai mare statistică sub H_0 15,7, $p = 0,005$: CCC este respins
- Volatilitatea TLT este mai persistentă (β mai mare), dar reacționează mai puțin la știri (α mai mic) decât cea a SPY

Erori standard în doi pași pentru SPY și TLT

	$\hat{a}$	$\hat{b}$	$\hat{a} + \hat{b}$
estimare	0,0522	0,9335	0,9857
e.s., hessiana pasului 2	0,0059	0,0084	–
e.s., bootstrap doar pentru pasul 2	0,0051	0,0077	0,0038
e.s., bootstrap pentru ambii pași	0,0052	0,0077	0,0040

- Bootstrap parametric pe reziduuri, $B = 199$: inovații DCC simulate cu $(\hat{a}, \hat{b}, \bar{Q})$ din reziduuri decorelate reșantionate
- Doar pasul 2: reestimăm (a, b) pe inovațiile simulate; ambii pași: reconstruim randamentele cu GARCH-ul estimat, reestimăm GARCH, apoi DCC (aceleași inovații)
- Pasul 1 crește e.s. doar cu 2% (a) și 1% (b): $T = 6\,073$ dă estimări GARCH precise; e.s. ($\hat{b}$) din hessiana pasului 2 este cu 8% mai mare decât cea bootstrap pentru ambii pași, deci aici este conservatoare

Corelația DCC dintre SPY și TLT, 2002–2026



- Corelația condiționată $\rho_{12,t}$ din modelul DCC(1,1), corelația mobilă pe 252 de zile și ținta $\bar{Q}_{12}$


Interpretarea traiectoriei DCC

- ▣ Intervalul: de la $-0,79$ (2 noiembrie 2011) la $0,49$ (21 mai 2026); ultima valoare $0,36$
- ▣ Corelația DCC medie: $-0,54$ între 15 septembrie și 31 decembrie 2008, $-0,56$ în 2012, $0,00$ în 2022
- ▣ DCC reacționează în câteva zile, ca EWMA, dar viteza (a) și memoria (b) sunt estimate, nu impuse
- ▣ Revenirea la $\bar{Q}_{12} = -0,25$ este o slăbiciune când se schimbă regimul
 - ▶ Din ianuarie 2022 traiectoria este deasupra țintei în 92% din zile (36% înainte): o singură corelație pe termen lung este îndoielnică

Testarea corelației constante la o dată necunoscută

- Tse (2000): un test de tip multiplicator Lagrange pentru corelația condiționată constantă, calculat doar din modelul CCC
- Alegerea datei rupturii de pe un grafic și aplicarea ulterioară a unui test Fisher z pentru o dată fixată în prealabil duc la un nivel efectiv al testului prea mare: data este ea însăși aleasă pe baza datelor
- Wied, Krämer & Dehling (2012): $Q_T = \max_{2 \leq j \leq T} \frac{j}{\sqrt{T} \hat{D}} |\hat{\rho}_j - \hat{\rho}_T|$, $\hat{\rho}_j$ corelația primelor j observații
 - ▶ $\hat{D}^2$: varianța pe termen lung a lui $\hat{\rho}$ prin metoda delta (Secțiunea 2), nucleu Bartlett cu lățimea $\lfloor T^{1/4} \rfloor$
 - ▶ Sub H_0 (corelație, medii și varianțe constante): $Q_T \rightarrow \sup_{0 \leq s \leq 1} |B(s)|$, B o punte browniană; valoarea critică la 5%: 1,358
 - ▶ Varianțele trebuie să fie constante, deci îl aplicăm reziduurilor standardizate GARCH; data estimată a rupturii $\hat{j} = \arg \max$

Datarea rupturii corelației SPY–TLT



- Procesul Wied–Krämer–Dehling pe reziduurile standardizate GARCH(1,1) ale SPY și TLT, $T = 6\,073$, lățimea 8; linia întreruptă: valoarea critică la 5%

Interpretarea testului de ruptură

- ▣ $Q_T = 4,25$ față de valoarea critică la 5% de 1,358: corelația constantă a reziduurilor este respinsă ($p < 0,001$)
- ▣ Ruptura estimată: 3 august 2020, nu ianuarie 2022; corelația reziduurilor $-0,36$ înainte și $0,07$ după
- ▣ Segmentare binară: înainte de ruptură $Q = 3,01$ (a doua ruptură 9 iulie 2007); după ea $Q = 1,56$, $p = 0,015$: mai mult de o ruptură
- ▣ Atenție: legea limită este demonstrată pentru serii observate; pe reziduuri GARCH estimate, p -valorile sunt aproximative
- ▣ Pentru DCC: o singură țintă $\bar{Q}$ pe 2002–2026 face media a cel puțin două regimuri

Aplicație: ponderi de varianță minimă cu DCC



- Ponderea SPY în portofoliul zilnic de varianță minimă SPY-TLT: $w_t = (\sigma_{2t}^2 - \sigma_{12,t}) / (\sigma_{1t}^2 + \sigma_{2t}^2 - 2\sigma_{12,t})$, trunchiată la $[0, 1]$
- Aceleași volatilități GARCH; corelația din DCC sau constantă $(-0,30)$


Interpretarea aplicației de portofoliu

- ▣ Volatilitatea anualizată (%): 60/40 fix 10,99; GARCH + corelație constantă 9,10; GARCH + DCC 9,06
- ▣ Cea mai mare parte a câștigului vine din volatilitățile GARCH și din ponderile de varianță minimă; corelația DCC adaugă doar o reducere suplimentară mică
- ▣ Diferența absolută medie de pondere DCC minus constant: 0,019; cea mai mare: 0,22 (8 iunie 2026)
- ▣ Atenție: parametrii sunt estimați pe tot eșantionul, deci aceasta este o ilustrare în eșantion
 - ▶ O comparație corectă reestimează modelele pe ferestre cu lungime crescătoare și adaugă costurile de tranzacționare (Capitolul 8)

Acoperire dinamică în afara eșantionului: BET cu Euro Stoxx 50

- BET și Euro Stoxx 50 zilnic (închideri aproape sincrone) din 5 ianuarie 2010; estimare până la sfârșitul lui 2019 ($n = 2\,491$), evaluare 2020–2026 ($n = 1\,663$) cu parametri menținuți fixați
- Acoperire statică: panta regresiei randamentelor BET pe randamentele Euro Stoxx 50 în fereastra de estimare, $h = 0,337$
- Acoperire dinamică: $h_t = \rho_t \sigma_{S,t} / \sigma_{F,t}$ din GARCH(1,1) și DCC(1,1) ($\hat{a} = 0,009$, $\hat{b} = 0,964$): medie 0,29, între 0,13 și 0,84
- Varianța eliminată în 2020–2026: static 24,7%, DCC 26,2%; cea mai bună acoperire constantă aleasă ex post ($h = 0,41$): 25,6%
- Testul Diebold & Mariano (1995) pe pătratele randamentelor acoperite (static minus DCC), HAC: $t = 1,29$, p unilateral = 0,098: un câștig mic, nesemnificativ la 5%

Bitcoin și acțiunile americane: corelația DCC



- Bitcoin și SPY în zilele comune de tranzacționare din 18 septembrie 2014 ($T = 3018$); mișcările Bitcoin din weekend intră în randamentul de luni

Interpretarea corelației Bitcoin–acțiuni

- ▣ Corelația DCC medie: 0,04 înainte de 2020, 0,31 din ianuarie 2020; vârf 0,55 pe 19 mai 2022
- ▣ Dinamică foarte persistentă: $a = 0,015$, $b = 0,982$, $a + b = 0,9968$; raportul de verosimilitate 105,6, p bootstrap sub $CCC = 0,005$: CCC este respins
- ▣ De la activ de diversificare la activ de risc: din 2020 Bitcoin se mișcă împreună cu acțiunile mult mai mult decât înainte
 - ▶ [Pele et al. \(2023\)](#) se întreabă dacă criptoactivele au devenit o clasă de active distinctă; corelația în creștere face parte din răspuns
- ▣ Corelația din tot eșantionul (0,24) ascunde două regimuri diferite

Recapitulare

- ▣ $H_t = D_t R_t D_t$ separă volatilitățile (GARCH univariat) de corelații
- ▣ VEC și BEKK sunt generale, dar numărul de parametri explodează; DCC cere $3N + 2$
- ▣ Cvasi-verosimilitatea în doi pași cere momente condiționate corect specificate, nu distribuția Normală; țintirea DCC standard este în general inconsistentă (DCC-ul corectat o repară); erorile standard din pasul 2 omit eroarea GARCH: folosim Newey–McFadden sau bootstrap pe ambii pași
- ▣ Un test cu dată necunoscută datează ruptura reziduurilor SPY–TLT la 3 august 2020; o acoperire statică pierde puțin față de DCC în afara eșantionului (BET)
- ▣ SPY–TLT: $a + b = 0,986$, CCC respins printr-un bootstrap sub H_0 , schimbare de semn după 2022; Bitcoin–SPY: corelația crește de la 0,04 la 0,31


Cresc corelațiile în criză?

- ▣ Constatare frecventă: corelațiile măsurate în criză sunt mai mari decât în perioadele calme
- ▣ Două explicații foarte diferite
 - ▶ **Contagiune**: se schimbă însuși mecanismul de transmitere
 - ▶ **Distorsiune de volatilitate**: mecanismul rămâne neschimbat, dar o piață-sursă mai volatilă crește mecanic corelația
- ▣ **Forbes & Rigobon (2002)**: după corecție, cea mai mare parte a „contagiunii” din 1987, 1994 și 1997 s-a dovedit interdependentă
- ▣ **Longin & Solnik (2001), Ang & Chen (2002)**: corelațiile cresc pe piețele în scădere, nu pe cele în creștere: o asimetrie pe care distribuția Normală nu o poate produce

Distorsiunea de heteroscedasticitate: derivare

- Modelul: $y_t = \alpha + \beta x_t + \varepsilon_t$, $\text{Cov}(x_t, \varepsilon_t) = 0$, β și σ_ε^2 constante
- Corelația: $\rho^2 = \frac{\beta^2 \sigma_x^2}{\beta^2 \sigma_x^2 + \sigma_\varepsilon^2} = \left(1 + \frac{\sigma_\varepsilon^2}{\beta^2 \sigma_x^2}\right)^{-1}$
- Criză: $\sigma_{x,c}^2 = (1 + \delta) \sigma_x^2$ cu $\delta > 0$; nimic altceva nu se schimbă
- Atunci $\rho_c = \rho \sqrt{\frac{1 + \delta}{1 + \delta \rho^2}}$, deci $|\rho_c| > |\rho|$ pentru $0 < |\rho| < 1$ ($\rho_c > \rho$ când $\rho > 0$): corelația măsurată crește în valoare absolută deși β este același
- Inversând: $\rho^* = \frac{\rho_c}{\sqrt{1 + \delta(1 - \rho_c^2)}}$ este corelația din criză corectată pentru creșterea volatilității

Cât poate crește o corelație doar din cauza volatilității?



- Corelația măsurată în criză ρ_c în funcție de δ , pentru trei corelații adevărate care nu se schimbă
- Linia verticală: varianța randamentelor S&P 500 pe 2 zile a fost de 7,5 ori nivelul din anul calm în fereastra de criză din 2008 ($\delta = 6,54$)

Testul Forbes–Rigobon

□ Procedura

- ▶ Alegem piața-sursă x , o fereastră calmă și o fereastră de criză
 - ▶ Calculăm $\delta = \hat{\sigma}_{x,c}^2 / \hat{\sigma}_{x,calm}^2 - 1$ și corelația corectată ρ^*
 - ▶ Testăm $H_0 : \rho^* \leq \rho_{calm}$ cu statistici Fisher z (convenția publicată)
 - ▶ Atenție: cu δ fixat, $\text{Var}(\text{artanh } \rho^*) \approx 1/[n_c(1 + \delta(1 - \rho_c^2))] < 1/n_c$, deci testul este conservator; un δ estimat și randamentele pe 2 zile suprapuse (n înjumătățit, o aproximare) cer metoda delta comună sau un bootstrap pe blocuri
- Folosim randamente pe 2 zile pentru a reduce problema fusurilor orare (ca în [Forbes & Rigobon \(2002\)](#))


Ipoteze de reținut

- Niciun șoc comun omis: un factor global care lovește ambele piețe crește și σ_x
- Nicio legătură inversă de la y la x (fără endogenitate)
- Alegerea ferestrelor contează: rezultatele se pot inversa cu câteva săptămâni
- Corecția poate merge prea departe dacă mecanismul real chiar s-a schimbat

Exemplu lucrat: criza din 2008 pas cu pas

- Piața-sursă: S&P 500; anul calm: 14 septembrie 2007 – 12 septembrie 2008 ($n = 242$ randamente pe 2 zile); criza: 15 septembrie 2008 – 31 martie 2009 ($n = 130$)
- Raportul varianțelor: $1 + \delta = 7,54$, deci $\delta = 6,54$
- Euro Stoxx 50: $\rho_{calm} = 0,610$, $\rho_c = 0,804$
 - ▶ $\rho^* = 0,804 / \sqrt{1 + 6,54 (1 - 0,804^2)} = 0,442$
 - ▶ p -valoarea unilaterală: 0,005 cu ρ_c , 0,932 cu ρ^*
- BET: $\rho_{calm} = 0,216$, $\rho_c = 0,485$, $\rho^* = 0,198$
 - ▶ p -valoarea unilaterală: 0,024 cu ρ_c , 0,548 cu ρ^*

2008: corelații de criză brute versus corectate



- Corelația randamentelor pe 2 zile cu S&P 500 în anul calm, în criză (brută) și după corecția Forbes–Rigobon

Interpretarea testului pentru 2008

- ▣ Corelațiile brute sar: Euro Stoxx 50 de la 0,61 la 0,80, BET de la 0,22 la 0,48; ambele creșteri sunt semnificative la 5%
- ▣ După corecție nicio creștere nu rezistă: mișcarea comună din 2008 este compatibilă cu „nicio contagiune, doar interdependență”
- ▣ De ce cu prudență?
 - ▶ 2008 a fost un șoc global care a lovit toate piețele simultan: ipoteza „niciun șoc comun” este îndoielnică
 - ▶ Cu $\delta \approx 6,5$ corecția este mare, iar testul are putere mică
- ▣ Seminarul repetă testul pentru 2020 și verifică sensibilitatea la alegerea ferestrelor


Teste de contagiune dincolo de Forbes–Rigobon

- Corsetti, Pericoli & Sbracia (2005): cu un factor comun, corecția Forbes–Rigobon este excesivă și deplasează testul spre „nicio contagiune”; ei dau o versiune cu model factorial
- Rigobon (2003): identificare prin heteroscedasticitate; schimbarea varianței între regimuri identifică coeficientul structural β , o idee de tip variabile instrumentale
- δ este estimat, deci ρ^* moștenește eroarea raportului varianțelor: reeșantionăm ferestrele calmă și de criză (bootstrap staționar, bloc mediu de 10 zile, $B = 1999$)
 - ▶ 2008: $\hat{\delta} = 6,54$, interval de 90% $[3,9, 9,6]$
 - ▶ BET: $\rho^* = 0,20$, interval de 90% $[0,16, 0,24]$, p bootstrap pentru $H_0 : \rho^* \leq \rho_{calm}$: 0,62
 - ▶ Euro Stoxx 50: $\rho^* = 0,44$ $[0,38, 0,52]$, $p = 0,98$
- Verdictul pentru 2008 rămâne și după includerea incertitudinii lui δ ; critica factorului comun rămâne (Seminarul A3, B4)

Corelațiile de depășire

- ▣ Longin & Solnik (2001): corelația condiționată de faptul că ambele randamente depășesc un prag
- ▣ Coda inferioară la cuantila q : $\rho^-(q) = \text{Corr}(x, y \mid x \leq F_x^{-1}(q), y \leq F_y^{-1}(q))$
- ▣ Coda superioară: la fel, cu $x \geq F_x^{-1}(1 - q), y \geq F_y^{-1}(1 - q)$
- ▣ Referința: pentru distribuția Normală bivariată, $\rho^\pm(q) \rightarrow 0$ când $q \rightarrow 0$
 - Condiționarea pe extreme scade corelația chiar dacă nu se schimbă nimic: comparăm cu curba Normală, nu cu ρ

Corelații de depășire: S&P 500 și Euro Stoxx 50



- Randamente săptămânale 2000–2026 ($n = 1\,393$, $\hat{\rho} = 0,78$ total); linia întreruptă: distribuția Normală bivariată cu aceeași corelație (2 milioane de perechi simulate)

Interpretarea graficului de depășire

- ▣ La $q = 0,10$: pierderi comune $\rho^- = 0,80$ (86 săptămâni), câștiguri comune $\rho^+ = 0,69$ (70 săptămâni); referința Normală 0,41
- ▣ Ambele cozi sunt mult peste referința Normală: extremele sunt mai dependente decât permite un model Gaussian
- ▣ Coda inferioară este mai sus decât cea superioară: prăbușirile sunt comune mai des decât creșterile
- ▣ Un coeficient de corelație nu poate descrie acest lucru: avem nevoie de un model pentru întreaga structură de dependență $\Rightarrow$ copule

Recapitulare

- ▣ Volatilitatea mai mare a pieței-sursă crește corelația măsurată chiar dacă mecanismul nu se schimbă
- ▣ Corelația corectată: $\rho^* = \rho_c / \sqrt{1 + \delta(1 - \rho_c^2)}$
- ▣ 2008: creșterile brute sunt semnificative, cele corectate nu; rezultatul se sprijină pe ipoteze puternice
- ▣ Corelațiile de depășire sunt asimetrice și mult peste referința Normală

De ce corelația nu este suficientă

- ▣ Embrechts, McNeil & Straumann (2002): trei erori frecvente despre corelația liniară
- ▣ Corelația măsoară doar dependența *liniară* și nu este invariantă la transformări monotone:
 $\text{Corr}(x, y) \neq \text{Corr}(e^x, e^y)$
- ▣ Marginalele și corelația nu determină distribuția comună
 - ▶ Două portofolii cu aceleași marginale și același ρ pot avea valori la risc foarte diferite (Capitolul 7)
- ▣ Corelațiile posibile: pentru marginale date, $\rho \in [\rho_{\min}, \rho_{\max}]$, atinse de perechi contramonotone și comonotone (marginile Fréchet–Hoeffding, slide-urile următoare)
 - ▶ Variabile cu distribuții lognormale $X = e^{\sigma_1 Z}$, $Y = e^{\pm \sigma_2 Z}$: $\rho_{\max} = \frac{e^{\sigma_1 \sigma_2} - 1}{\sqrt{(e^{\sigma_1^2} - 1)(e^{\sigma_2^2} - 1)}}$, $\rho_{\min}$ cu $e^{-\sigma_1 \sigma_2}$ la numărător
 - ▶ $\sigma_1 = 1$, $\sigma_2 = 3$: $\rho_{\max} = 0,162$ și $\rho_{\min} = -0,008$: perfect dependente, dar aproape necorelate

Teorema lui Sklar



Clădirea principală, Illinois Institute of Technology, Chicago: Abe Sklar (1925–2020) a fost profesor de matematică aplicată la IIT; nu există un portret al său cu licență liberă

Foto: Joe Ravi (2010); CC BY-SA 3.0; Wikimedia

[Commons](#)

- O **copulă** este o funcție de repartiție comună pe $[0, 1]^d$ cu marginale uniforme
- **Sklar (1959)**: pentru orice repartiție comună F cu marginalele $F_1, \dots, F_d$ există o copulă C astfel încât
 - ▶ $F(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d))$
 - ▶ C este unică dacă marginalele sunt continue
- Invers, orice copulă și orice marginale dau o repartiție comună validă
- Dacă marginalele și copula au densități:
 $f(x) = c(F_1(x_1), \dots, F_d(x_d)) \prod_i f_i(x_i)$ (copula comonotonă nu are)

Ce separă copula

- ▣ Marginalele: volatilitatea, asimetria, cozile groase ale fiecărui activ (Capitolele 1 și 5)
- ▣ Copula: toată dependența și nimic altceva; invariantă la transformări crescătoare ale fiecărei variabile
- ▣ Trei copule de referință în două dimensiuni
 - ▶ Independența: $\Pi(u, v) = uv$
 - ▶ Comonotonia (dependență pozitivă perfectă): $M(u, v) = \min(u, v)$
 - ▶ Contramonotonia: $W(u, v) = \max(u + v - 1, 0)$
- ▣ Marginile Fréchet–Hoeffding: $W \leq C \leq M$ pentru orice copulă
- ▣ Text de referință: [Nelsen \(2006\)](#)

Corelații de rang: Kendall și Spearman

- **Tau al lui Kendall (Kendall (1938))**: perechi concordante minus perechi discordante
 - ▶ $\tau = P[(X_1 - X_2)(Y_1 - Y_2) > 0] - P[(X_1 - X_2)(Y_1 - Y_2) < 0]$
 - ▶ Forma în copule: $\tau = 4 \iint C \, dC - 1$
- **Rho al lui Spearman (Spearman (1904))**: corelația Pearson a rangurilor
 - ▶ Forma în copule: $\rho_S = 12 \iint (C(u, v) - uv) \, du \, dv$
- Ambele depind doar de copulă; ambele sunt 1 pentru M , 0 pentru Π , -1 pentru W

Legătura cu parametrii copulelor

Copula	τ
Gaussiană, t	$\frac{2}{\pi} \arcsin \rho$
Clayton	$\theta/(\theta + 2)$
Gumbel	$1 - 1/\theta$
Frank	$1 - \frac{4}{\theta} [1 - D_1(\theta)]$

- $D_1(\theta) = \frac{1}{\theta} \int_0^\theta \frac{t}{e^t - 1} dt$ (funcția Debye)
- Gaussiană: $\rho_S = \frac{6}{\pi} \arcsin(\rho/2)$

Copule eliptice: Gaussiană și Student t

- ▣ **Gaussiană:** $C_{\rho}^{Ga}(u, v) = \Phi_{2,\rho}(\Phi^{-1}(u), \Phi^{-1}(v))$
 - ▶ Densitatea: $c = \frac{1}{\sqrt{1-\rho^2}} \exp\left(-\frac{\rho^2(x^2+y^2)-2\rho xy}{2(1-\rho^2)}\right)$, $x = \Phi^{-1}(u)$, $y = \Phi^{-1}(v)$
 - ▶ Simetrică, fără dependență în cozi pentru $|\rho| < 1$
- ▣ **Student t** (Demarta & McNeil (2005)): $C_{\rho,\nu}^t(u, v) = t_{2,\rho,\nu}(t_{\nu}^{-1}(u), t_{\nu}^{-1}(v))$
 - ▶ ν grade de libertate: ν mic = extreme comune puternice; $\nu \rightarrow \infty$ dă copula Gaussiană
 - ▶ Dependență în cozi simetrică, egală în ambele cozi
- ▣ Ușor de extins la d dimensiuni cu o matrice de corelație: alegerea standard în sistemele de risc


Copule arhimedienne: Clayton, Gumbel, Frank

- Construite dintr-un generator φ : $C(u, v) = \varphi^{-1}(\varphi(u) + \varphi(v))$
- **Clayton** (Clayton (1978)), $\theta > 0$
 - ▶ $C = (u^{-\theta} + v^{-\theta} - 1)^{-1/\theta}$
 - ▶ dependență doar în coada inferioară
- **Gumbel** (Gumbel (1960)), $\theta \geq 1$
 - ▶ $C = \exp(-[(-\ln u)^\theta + (-\ln v)^\theta]^{1/\theta})$
 - ▶ dependență doar în coada superioară
- **Frank** (Frank (1979)), $\theta \neq 0$
 - ▶ $C = -\frac{1}{\theta} \ln\left(1 + \frac{(e^{-\theta u} - 1)(e^{-\theta v} - 1)}{e^{-\theta} - 1}\right)$
 - ▶ simetrică, fără dependență în cozi

De ce le folosim

- Un singur parametru, C în formă închisă, simulare ușoară
- Cozi asimetrice: Clayton pentru prăbușirile comune ale randamentelor, Gumbel pentru extremele comune ale pierderilor
- Rotirea unei copule (folosind $1 - u, 1 - v$) mută dependența în cozi în colțul opus
- Limitare: simetria la permutarea variabilelor și un singur parametru pentru toate perechile reduc flexibilitatea în dimensiuni mari

Cinci copule cu același tau al lui Kendall



- 1500 de perechi simulate din fiecare copulă cu $\tau = 0.5$, reprezentate pe marginale Normale $(\Phi^{-1}(u), \Phi^{-1}(v))$
- Parametrii din tabelul lui τ : Gaussiană și t $\rho = 0.707$, Clayton și Gumbel $\theta = 2.0$, Frank $\theta = 5.74$

Interpretarea galeriei de copule

- ▣ Același tau al lui Kendall, aceleași marginale: norii diferă totuși, mai ales în colțuri
- ▣ Gaussiană și Frank: colțurile se răresc, deci extremele comune sunt rare
- ▣ Student t: ambele colțuri rămân dense
- ▣ Clayton: un colț stânga-jos ascuțit (prăbușiri comune); Gumbel: un colț dreapta-sus ascuțit
- ▣ Un manager de risc care calibrează doar τ sau ρ poate alege oricare dintre cele cinci și obține riscuri în coadă foarte diferite

Dependența în cozi

- Coadă inferioară:
 $\lambda_L = \lim_{q \downarrow 0} P(V \leq q \mid U \leq q) = \lim_{q \downarrow 0} C(q, q)/q$
- Coadă superioară: $\lambda_U = \lim_{q \downarrow 0} P(V > 1 - q \mid U > 1 - q)$
- $\lambda > 0$: extremele vin împreună oricât de extreme ar fi;
 $\lambda = 0$: independență asimptotică
- Dependența în cozi este o proprietate a copulei, invizibilă în ρ


Forme închise

	λ_L	λ_U
Gaussiană	0	0
Student t	$2 t_{\nu+1} \left(- \sqrt{\frac{(\nu+1)(1-\rho)}{1+\rho}} \right)$	la fel
Clayton	$2^{-1/\theta}$	0
Gumbel	0	$2 - 2^{1/\theta}$
Frank	0	0

Estimarea copulelor

- ▣ **Verosimilitate maximă completă:** marginalele și copula estimate simultan; eficientă, dar costisitoare computațional și sensibilă la erorile de specificare
- ▣ **IFM** (funcții de inferență pentru marginale, [Joe \(2005\)](#)): doi pași
 - ▶ Estimăm marginale parametrice (de exemplu GARCH cu Student t); $\hat{u}_{it} = \hat{F}_i(x_{it})$; maximizăm $\sum_t \ln c(\hat{u}_{1t}, \hat{u}_{2t}; \theta)$
- ▣ **CML** (verosimilitate maximă canonică, [Genest, Ghoudi & Rivest \(1995\)](#)): fără marginale parametrice
 - ▶ Pseudo-observații $\hat{u}_{it} = \text{rang}(x_{it}) / (T + 1)$; apoi maximizăm verosimilitatea copulei
 - ▶ Robustă la marginale specificate greșit; $T + 1$ ține $\hat{u}$ departe de 0 și 1
- ▣ Pentru randamente: filtrăm întâi fiecare serie cu GARCH, apoi folosim rangurile reziduurilor standardizate
- ▣ Alegerea modelului: $AIC = 2k - 2\ell$, $BIC = k \ln T - 2\ell$

De la reziduuri la pseudo-observații: JPM și BAC



- JPMorgan Chase (JPM) și Bank of America (BAC), zilnic 2010–2026 ($T = 4\,202$), filtrate GARCH(1,1)
- $\hat{\tau}$ Kendall = 0,641, $\hat{\rho}_S$ Spearman = 0,822; ambele colțuri ale norului de puncte cu marginale uniforme sunt dense

Estimările copulelor pentru JPM și BAC

Copula	$\hat{\theta}$ sau $\hat{\rho}$	$\hat{\nu}$	ℓ	ΔAIC	λ_L	λ_U	p adecvare
Gaussiană	0,833	–	2486,0	309,3	0,000	0,000	0,005
Student t	0,842	4,24	2641,7	0,0	0,531	0,531	0,010
Clayton	2,384	–	2116,7	1048,0	0,748	0,000	0,005
Gumbel	2,587	–	2412,2	456,9	0,000	0,693	0,005
Frank	9,152	–	2390,8	499,8	0,000	0,000	0,005

- CML pe pseudo-observațiile reziduurilor GARCH; ΔAIC față de cel mai bun model
- Student t câștigă detașat: $\hat{\nu} = 4,2$ înseamnă extreme comune puternice, $\hat{\lambda} = 0,53$ în ambele cozi
- Copula Gaussiană se potrivește datelor mai bine decât copulele Clayton, Gumbel și Frank: dependența este puternică și aproximativ simetrică
- Ultima coloană: p -valorile testului de adecvare (slide-urile următoare)

Estimatorii de rang și precizia lor

- ▣ $\hat{\tau}$ este o U-statistică; proiecția Hoeffding dă $\sqrt{n}(\hat{\tau} - \tau) \rightarrow N(0, 16\text{Var}[2C(U, V) - U - V])$
- ▣ Estimare: $\widehat{\text{se}}(\hat{\tau}) = 4 \text{sd}(2\hat{C}_n(\hat{U}_i, \hat{V}_i) - \hat{U}_i - \hat{V}_i) / \sqrt{n}$; estimatorii prin inversare $\hat{\theta} = g(\hat{\tau})$ prin metoda delta (Genest & Rivest (1993))
- ▣ Copule eliptice: $\tau = \frac{2}{\pi} \arcsin \rho$ pentru orice ν , deci τ identifică ρ , niciodată ν ; ν vine din verosimilitate sau din cozi
- ▣ JPM–BAC: $\hat{\tau} = 0,641$ (e.s. 0,0065), deci $\hat{\rho}_{\tau} = \sin(\pi\hat{\tau}/2) = 0,845$ (e.s. 0,0055); CML: $\hat{\rho} = 0,842$ (e.s. 0,0053, slide-ul următor)
- ▣ Estimatorul de momente este aproape la fel de precis ca CML pentru ρ și oferă o valoare inițială robustă pentru maximizarea verosimilității


Erorile standard CML: rangurile sunt estimate

- CML maximizează $\sum_i \ln c(\hat{U}_i, \hat{V}_i; \theta)$ cu marginale *estimate*; inversa hessienei presupune marginale cunoscute și este prea mică
- Genest, Ghoudi & Rivest (1995): $\sqrt{n}(\hat{\theta} - \theta) \rightarrow N(0, A^{-1}\Sigma A^{-1})$, A informația Fisher a copulei, $\Sigma = \text{Var}[\dot{\ell}_\theta(U, V) + W_1(U) + W_2(V)]$
 - ▶ $W_1(u) = \iint 1\{u \leq u'\} \partial_u \dot{\ell}_\theta(u', v') dC(u', v')$: corecția pentru estimarea marginalelor prin ranguri; W_2 se definește analog pentru v
 - ▶ Copula Gaussiană: varianța $(1 - \rho^2)^2$ pentru CML, față de $(1 - \rho^2)^2 / (1 + \rho^2)$ cu marginale cunoscute
- S&P 500–Euro Stoxx 50 săptămânal, copula Gaussiană: e.s. 0,0086 (inversa hessienei) față de 0,0138 (sandwich), +60%
- JPM–BAC, copula t: ρ : 0,0046 față de 0,0053 (+17%); ν : 0,359 față de 0,364 (+1%): ν este determinat de cozi, unde rangurile adaugă puțină eroare

Chen și Fan (2006): filtrarea GARCH nu schimbă limita

- Modelul: $r_{it} = \mu_i + \sigma_{it}\varepsilon_{it}$ cu σ_{it} GARCH; inovațiile $(\varepsilon_{1t}, \varepsilon_{2t})$ i.i.d. cu copula C_θ
- **Chen & Fan (2006)**: CML pe rangurile reziduurilor *estimate* $\hat{\varepsilon}_{it}$ are aceeași distribuție limită ca CML pe rangurile inovațiilor adevărate ε_{it}
- Consecință: sandwich-ul **Genest, Ghoudi & Rivest (1995)** rămâne valid după filtrarea GARCH; spre deosebire de DCC, nu este nevoie de corecția pasului 1
- Monte Carlo: 500 eșantioane, $T = 2\,000$, copulă Gaussiană $\rho = 0,8$, inovații Student $t(5)$, GARCH ca cel estimat pentru JPM și BAC
 - ▶ a.s. a lui $\hat{\rho}$: 0,0081 (inovații adevărate) și 0,0082 (reziduuri GARCH); e.s. sandwich medie 0,0081, e.s. din inversa hessienei medie 0,0063
- Adecvarea pe reziduuri: **Rémillard (2017)** arată că testele bazate pe ranguri își păstrează limita și bootstrapul parametric se aplică, ceea ce justifică testul Rosenblatt prezentat mai jos

Compararea modelelor și adecvarea




Numbers above bars: goodness-of-fit p-value (Rosenblatt Cramer-von Mises, parametric bootstrap)

- Barele: distanța AIC față de cea mai bună copulă; numerele: p -valorile bootstrap ale testului de adecvare

Adecvarea: testul Rosenblatt

- Dacă $(U, V) \sim C_\theta$, atunci $E_1 = U$ și $E_2 = h(V | U) = \partial C_\theta(U, V) / \partial u$ sunt uniforme independente
- Statistica (Genest, Rémillard & Beaudoin (2009)): $S_n = n \int_{[0,1]^2} (D_n(e) - e_1 e_2)^2 de$, D_n repartiția empirică a lui (E_1, E_2)
- p -valoarea prin bootstrap parametric, deoarece θ este estimat
 - ▶ Simulăm n perechi din $C_{\hat{\theta}}$, le transformăm în pseudo-observații, reestimăm, recalculăm $S_n^{(b)}$
 - ▶ $p = (1 + \#\{S_n^{(b)} \geq S_n\}) / (B + 1)$; aici $B = 200$ (100 pentru Student t)
- Rezultat: toate familiile sunt respinse la 5%; Student t are de departe cea mai mică statistică (0,082 față de 0,968 pentru Gaussiană)
- De ce sunt toate respinse?
 - ▶ $T = 4\,202$ dă putere mare împotriva abaterilor mici; o abatere posibilă: o copulă statică pe 16 ani ignoră faptul că dependența se poate mișca (Secțiunea 3)
 - ▶ Remediu: copule variabile în timp (condiționate), Patton (2006); o copulă t dinamică urmează la finalul secțiunii

Dependența empirică în cozi: JPM și BAC



- Estimările $\hat{\lambda}_L(q) = \hat{C}(q, q)/q$ și $\hat{\lambda}_U(q)$ pentru q de la 1% la 20%, cu banda de 90% a aceluiași estimator pe date simulate din copula t estimată


Interpretarea graficului de dependență în cozi

- ▣ La $q = 5\%$: $\hat{\lambda}_L = 0,61$, $\hat{\lambda}_U = 0,55$; la $q = 1\%$: 0,52 și 0,43
- ▣ Când JPM are una dintre cele mai proaste 5% zile, BAC se află în propriile 5% cele mai proaste zile în aproximativ 61% din cazuri
- ▣ Estimările din coada inferioară sunt în banda copulei t (0,57–0,65 la 5%): copula t descrie bine prăbușirile
- ▣ Coada superioară pare mai slabă (creșterile sunt mai slab asociate decât prăbușirile); slide-ul următor testează dacă asimetria este mai mult decât zgomot
- ▣ Estimările la q finit sunt deplasate și zgomotoase: λ este o limită, iar foarte puține puncte se află în colțul extrem

Estimarea neparametrică a dependenței în cozi

- ▣ Schmidt & Stadtmüller (2006): $\hat{\lambda}_L = \frac{n}{k} \hat{C}_n(\frac{k}{n}, \frac{k}{n})$, estimatorul din grafic cu $q = k/n$; $\hat{\lambda}_U$ la fel, în colțul superior
- ▣ Consistent și asimptotic Normal dacă $k \rightarrow \infty$, $k/n \rightarrow 0$, copula de coadă există și este îndeplinită o condiție de ordinul doi pentru deplasare ($\sqrt{k} A(n/k) \rightarrow 0$): un k mai mare scade varianța, dar crește deplasarea
- ▣ Este reală asimetria JPM–BAC la q fixat? $H_0 : \lambda_L(q) = \lambda_U(q)$ (probabilități la prag finit, nu limitele); bootstrap pe perechile de reziduuri, cu rangurile recalulate, $B = 999$
 - ▶ $q = 5\%$ ($k = 210$): $\hat{\lambda}_L - \hat{\lambda}_U = 0,062$, interval de 95% i.i.d. $[-0,014, 0,148]$, bootstrap staționar pe blocuri $[-0,014, 0,138]$
 - ▶ $q = 1\%$ ($k = 42$): $0,095$, i.i.d. $[-0,095, 0,286]$, pe blocuri $[-0,119, 0,286]$: mai larg, cum prezice compromisul deplasare–varianță
 - ▶ Bootstrapul i.i.d. presupune o copulă statică a inovațiilor; varianta pe blocuri (blocul mediu după regula Politis & White (2004): 1,6 și 1,0 zile) permite dependența serială a indicatorilor de coadă
- ▣ Toate intervalele conțin zero: la aceste praguri asimetria cozilor nu este semnificativă, deci copula t simetrică nu este contrazisă în cozi

O copulă t dinamică pentru JPM și BAC



- Copula t GAS (generalised autoregressive score, scor autoregresiv generalizat), [Creal, Koopman & Lucas \(2013\)](#):

$$\rho_t = \tanh f_t, \quad f_{t+1} = \omega + A s_t + B f_t, \quad s_t = \partial \ln c(\hat{u}_t, \hat{v}_t; \rho_t, \nu) / \partial f_t \text{ (scalare unitară)}$$

- Aceleași pseudo-observații ca la estimarea statică; $\lambda_t = 2t_{\nu+1} \left(-\sqrt{(\nu+1)(1-\rho_t)/(1+\rho_t)} \right)$ implicat

Interpretarea copulei dinamice

- ▣ Estimări: $A = 0,025$, $B = 0,9926$, $\nu = 5,35$ (static 4,24); raportul de verosimilitate față de copula t statică 245,5
- ▣ ρ_t variază între 0,64 (23 mai 2013) și 0,95 (18 februarie 2021); λ_t între 0,28 și 0,69, în jurul valorii statice 0,53
- ▣ Când ρ se mișcă, ajunge un ν mai mare: o parte din cozile groase statice era variația în timp a dependenței
- ▣ Sub $A = 0$, B nu este identificat (din nou problema Davies): judecăm raportul de verosimilitate prin bootstrap, nu prin χ^2 ; aici diferența este foarte mare
- ▣ Dependența variabilă în timp este o explicație compatibilă cu respingerea tuturor familiilor statice; respingerea singură nu o identifică (Seminarul B6)

Dependența în dimensiuni mari și în timp

- DCC pentru N mare: verosimilitatea completă este lentă și deplasată
 - ▶ Verosimilitate compusă pe perechi de active, [Pakel, Shephard, Sheppard & Engle \(2021\)](#); DCC-NL, contracția neliniară a țintei $\bar{Q}$ (contracția din Capitolul 4), [Engle, Ledoit & Wolf \(2019\)](#)
- Construcțiile vine (copule pe perechi), [Aas, Czado, Frigessi & Bakken \(2009\)](#)
 - ▶ $d(d - 1)/2$ copule bivariate, unele condiționate, în arbori imbricați; fiecare pereche are propria familie și propriile cozi
- Copule arhimedene ierarhice, [Okhrin, Okhrin & Schmid \(2013\)](#)
 - ▶ Grupuri imbricate după tăria dependenței: bănci într-o țară, țări într-o regiune
- Copule dinamice
 - ▶ Parametrii ghidați de scor ([Creal, Koopman & Lucas \(2013\)](#)) se extind la multe active prin copule factoriale; [Oh & Patton \(2018\)](#) măsoară riscul sistemic variabil în timp în marjele swap-urilor pe riscul de credit


Copula Gaussiană: lecțiile crizei din 2008

- ▣ Li (2000) a modelat momentele de faliment comune cu o copulă Gaussiană
 - ▶ Un singur parametru de corelație, calibrat pe marjele de piață, evalua portofolii întregi de credite
- ▣ A devenit standardul pieței pentru evaluarea tranșelor de obligațiuni garantate cu datorii (CDO)
- ▣ Ce a mers prost
 - ▶ Dependență asimptotică zero în cozi: pentru falimentele comune cele mai extreme da probabilități mai mici decât modelele cu dependență în cozi calibrate pe aceleași date
 - ▶ O corelație statică, calibrată în anii calmi: exact lecțiile Forbes–Rigobon și DCC
- ▣ Copula este un instrument; pericolul a fost o singură alegere comodă, cu cozi subțiri

Recapitulare

- ▣ Sklar: repartiția comună = marginale + copulă; copula conține toată dependența
- ▣ Tau Kendall și rho Spearman depind doar de copulă și corespund unu-la-unu parametrilor familiilor cu un parametru
- ▣ Dependența în cozi: 0 pentru Gaussiană și Frank, simetrică pentru t, inferioară pentru Clayton, superioară pentru Gumbel
- ▣ Estimăm pe pseudo-observațiile reziduurilor GARCH; testăm adecvarea cu statistica Rosenblatt și bootstrap parametric
- ▣ Erorile standard CML au nevoie de termenul de rang Genest–Ghoudi–Rivest; după filtrarea GARCH nu se mai schimbă nimic (Chen–Fan)
- ▣ JPM–BAC: copula t este cea mai bună dintre cele statice, dar este respinsă; o copulă t GAS cu ρ_t variabil în timp se potrivește mult mai bine

Acțiuni din SUA, zona euro și România, 2000–2026




- Corelațiile randamentelor săptămânale pe o fereastră de 104 săptămâni (zile comune de tranzacționare, închiderile de vineri)

Interpretarea integrării piețelor

- ▣ Euro Stoxx 50–BET: 0,33 în 2000–2009, 0,45 în 2010–2019, 0,61 din 2020
- ▣ S&P 500–Euro Stoxx 50: 0,84, 0,78, 0,70 în aceleași perioade
- ▣ Corelația mobilă Euro Stoxx 50–BET: 0,31 la sfârșitul lui 2007, 0,65 la sfârșitul lui 2009, 0,29 la sfârșitul lui 2019, 0,76 la sfârșitul lui 2021, 0,35 acum
 - ▶ Salturi în crize, revenire parțială după aceea: integrare sau distorsiunea de volatilitate Forbes–Rigobon?
Seminarul testează acest lucru
- ▣ O corelație mai mică înseamnă o diversificare mai bună pentru investitorii din zona euro care dețin acțiuni românești

Bănci: corelațiile randamentelor săptămânale, 2010–2026




- SUA: JPM și BAC; zona euro: DBK (Deutsche Bank) și BNP (BNP Paribas); România: TLV (Banca Transilvania) și BRD (BRD-Groupe Société Générale)
- 871 săptămâni din 15 ianuarie 2010

Interpretarea corelațiilor dintre bănci

- ▣ Trei blocuri: SUA (0,86), zona euro (0,75), România (0,65)
- ▣ Legăturile dintre regiuni sunt mai slabe pentru România: de exemplu BNP–TLV 0,33, JPM–BRD 0,30
- ▣ BRD este controlată de Société Générale, dar acțiunea ei se mișcă mai mult împreună cu TLV decât cu orice bancă din zona euro
- ▣ Randamentele băncilor au factori comuni la nivel de țară: riscul suveran, dobânzile interne, reglementarea

Corelațiile dintre bănci în timp




- Media corelațiilor pe perechi, pe 52 de săptămâni, ale randamentelor săptămânale: în interiorul regiunilor, între SUA și zona euro și între România și celelalte

Interpretarea corelațiilor dintre bănci în timp

- ▣ Mediile pe toată perioada: în interiorul regiunilor 0,73, SUA–zona euro 0,59, România–celelalte 0,25
- ▣ Martie–iunie 2020: 0,87, 0,69 și 0,56: legătura României s-a intensificat de peste două ori în timpul unui șoc global
- ▣ Ultimele valori: 0,57, 0,40, 0,15
- ▣ Diversificarea între sisteme bancare funcționează în vremuri normale și slăbește exact în evenimentele sistemice

O rețea de corelații între bănci



- Arborele de acoperire minimă (Mantegna (1999)) pe distanțele $d_{ij} = \sqrt{2(1 - \rho_{ij})}$: cele 5 legături cele mai puternice care conectează toate cele 6 bănci fără cicluri
- Muchiile: JPM-BAC (0,86); JPM-BNP (0,65); DBK-BNP (0,75); BNP-BRD (0,35); TLV-BRD (0,65); România este legată prin BNP-BRD

De la corelații la riscul sistemic

- ▣ Arborele rezumă cele mai puternice legături de mișcare comună SUA ↔ zona euro ↔ România; este neorientat și contemporan, deci nu identifică drumurile de transmitere a șocurilor, ci doar ipoteze de testat
- ▣ Rețelele de corelații sunt primul pas spre măsurile de risc sistemic (Capitolul 18)
 - ▶ Conectivitate din cauzalitate Granger: Billio, Getmansky, Lo & Pelizzon (2012)
 - ▶ Indici de transmitere din descompunerea varianței: Diebold & Yilmaz (2009)
 - ▶ Rețele de evenimente extreme: Financial Risk Meter aplicat firmelor energetice din UE, Toma, Dima, Grecu, Pele & Lessmann (2026)
- ▣ Prețurile energiei și piețele de acțiuni din UE: dependența pe regiuni și grupe industriale, Grecu, Cramer, Pele & Lessmann (2025)
- ▣ Rețelele de corelații moștenesc toate problemele corelațiilor: neliniaritate, variație în timp, cozi
- ▣ Distanțele: aici $\sqrt{2(1-\rho)}$, în Capitolul 4 (paritatea ierarhică a riscului) $\sqrt{(1-\rho)/2}$; diferă printr-un factor 2, ambele cresc cu $1-\rho$ și dau același arbore

Recapitulare

- ▣ Corelația săptămânală BET–Euro Stoxx 50 a crescut de la 0,33 (anii 2000) la 0,61 (din 2020)
- ▣ Randamentele băncilor se grupează pe regiuni; băncile românești sunt cele mai puțin conectate, cu excepția șocurilor globale
- ▣ Arborii de acoperire minimă rezumă o matrice de corelație sub formă de rețea, puntea spre Capitolul 18

Studiu de caz: întrebarea de cercetare

- Engle & Campos-Martins (2023): ce evenimente afectează simultan volatilitatea piețelor din aproape toate țările și clasele de active și cât de mare este acest șoc comun? COVOL global (common volatility, volatilitatea comună) măsoară zilnic amploarea lui
- De ce contează: un model DCC corect specificat, inclusiv DCC-ul pentru N mare al lui Engle, Ledoit & Wolf (2019), produce reziduuri standardizate multivariat e_t cu $E_{t-1}(e_t e_t^\top) = I$ (ec. 1–2)
 - ▶ Reziduurile necorelate pot fi dependente: pătratele lor pot varia împreună, $\Psi_t = E_{t-1}[(e_t^2 - \iota)(e_t^2 - \iota)^\top]$ cu elemente nenule în afara diagonalei (ec. 3)
 - ▶ Volatilitățile pot crește simultan, fără ca un activ să reacționeze primul; estimatorul de cvasi-verosimilitate pentru distribuția Normală rămâne consistent, deci estimarea standard nu evidențiază această dependență a pătratelor (Secțiunea 3)
 - ▶ În asemenea episoade, atât șocurile factorilor, cât și cele idiosincratice sunt ample; volatilitatea portofoliului poate rămâne surprinzător de ridicată chiar și după diversificarea riscului idiosincritic (Secțiunea 4)
- Ideea: analogul transversal al modelului ARCH (Capitolul 5)
 - ▶ ARCH folosește corelația pătratelor reziduurilor în timp; COVOL o folosește între active, în aceeași zi (Secțiunea 5.1)
 - ▶ Herskovic, Kelly, Lustig & Van Nieuwerburgh (2016) documentează un factor comun în volatilitatea idiosincritică a acțiunilor americane; studiul de caz propune un model, un estimator și un test pentru un asemenea factor
- Legătura cu acest capitol: standardizarea GARCH–DCC, corelațiile în criză (Forbes–Rigobon) și extremele comune (copulele)

Studiu de caz: date și metodă

- **Modelul (ec. 8–11):** $e_{it} = \sqrt{s_i x_t + 1 - s_i} \varepsilon_{it}$, ε_{it} i.i.d. $\mathcal{N}(0, 1)$, $x_t > 0$, $E_{t-1}(x_t) = 1$, încărcarea $s_i \in [0, 1]$; x_t este pătratul COVOL global
 - ▶ Pentru $i \neq j$: $\Psi_{ij,t} = s_i s_j v_t$, $v_t = \text{Var}_{t-1}(x_t)$, deci Ψ are o structură cu un singur factor, iar prima sa componentă principală furnizează valorile inițiale (ec. 12–13)
 - ▶ Încărcări egale $s_i = 1$: estimatorul de verosimilitate maximă este $\hat{x}_t = \frac{1}{N} \sum_i e_{it}^2$, media transversală a pătratelor reziduurilor standardizate (ec. 17)
- **Estimarea (Secțiunea 5.3):** se maximizează $-\frac{1}{2} \sum_{i,t} [\ln g_{it} + e_{it}^2/g_{it}]$, $g_{it} = s_i x_t + 1 - s_i$, alternând estimarea lui x_t pe secțiuni transversale zilnice cu estimarea lui s_i pe seria temporală a fiecărui activ, până la convergență
 - ▶ După fiecare pas: $s^\top s = 1$, media lui x_t egală cu 1 (Observația 2); testul ξ (ec. 27): media standardizată a produselor $(e_{it}^2 - 1)(e_{jt}^2 - 1)$ pe cele $N(N - 1)/2$ perechi, $\mathcal{N}(0, 1)$ sub $H_0: \Psi_{ij} = 0$, $i \neq j$
- **Date (Secțiunea 7.1, tabelul B.1):** randamente logaritmice zilnice în USD ale celor 47 de ETF-uri de țară listate la NYSE, 2 iunie 2000 – 1 martie 2021; aceeași oră de închidere, deci fără asincronism; panel neechilibrat; în fiecare zi se folosesc seriile disponibile la acea dată
 - ▶ Media: AR(1) plus doi factori, MSCI ACWI (All Country World Index, indicele global al tuturor țărilor) și PC1 a randamentelor ETF-urilor; varianțe GARCH(1,1); COVOL estimat pe cele 47 de serii de reziduuri și pe cei doi factori
 - ▶ În plus: 23 de serii pe clase de active din SUA (Secțiunea 9) și simulări Monte Carlo pentru estimator și pentru test (Secțiunile 5.4, 6.1)


Studiu de caz: rezultatele principale

Ziua	$\hat{x}_t$	$\bar{r}_t$ (%)	Evenimentul (eticheta din articol)
9 martie 2020	51,416	-9,650	COVID-19: Italia în carantină; războiul prețului petrolului
24 iunie 2016	49,190	-7,270	Brexit
5 august 2019	39,457	-2,574	Războiul comercial: China își devalorizează moneda
28 aprilie 2020	38,883	2,334	COVID-19: vânzări masive de acțiuni tehnologice
17 septembrie 2001	30,077	-8,630	NYSE se redeschide după 11 septembrie

$\bar{r}_t$: randamentul mediu al ETF-urilor de țară; primele cinci dintre cele mai mari douăzeci de valori din tabelul 6 din [Engle & Campos-Martins \(2023\)](#)

- Clasamentul include evenimente sanitare, politice, comerciale și teroriste; valori mari ale lui $\hat{x}_t$ apar și în zile de creștere ($\bar{r}_t = 2,334\%$ pe 28 aprilie 2020) $\Rightarrow$ COVOL măsoară amploarea șocului comun, nu semnul lui
- Cele mai mari încărcări (tabelul 7): PC1 0,261 și ACWI 0,250; Franța 0,217, Spania 0,200 față de Noua Zeelandă 0,065, Polonia 0,080 $\Rightarrow$ factorii au încărcări mai mari decât componentele idiosincratice, deci corelațiile cresc odată cu COVOL (ec. 41)
- Lunar, 248 de luni (tabelul 8): pătratul reziduului standardizat al ACWI pe COVOL_m^2 (media lunară a lui $\hat{x}_t$ minus 1): 0,326 (SE 0,025), $R^2 = 0,404$, față de $R^2 = 0,110$ pentru variația indicelui EPU ([Baker, Bloom & Davis \(2016\)](#)) și 0,005 pentru indicele GPR ([Caldara & Iacoviello \(2022\)](#)) $\Rightarrow$ șocurile comune realizate, nu numărul de articole, explică volatilitatea globală
- Corelația medie pe perechi de ETF-uri: +0,053 pentru o unitate de COVOL_m^2 (SE 0,009), condiționat de valoarea ei întârziată (tabelul 10); variația VIX: 4,034 (SE 0,249), $R^2 = 0,517$ (tabelul 12) $\Rightarrow$ COVOL este asociat cu corelațiile în criză din acest capitol și cu creșterile VIX

Studiu de caz: șocurile realizate față de indicii de știri




- Sursa: [Engle & Campos-Martins \(2023\)](#), tabelul 8: R^2 al regresiilor șocului lunar de volatilitate al ACWI pe fiecare indicator, 248 de luni
- Numai COVOL_m^2 explică 40,4% din variație; adăugarea variațiilor indicilor EPU și GPR crește R^2 doar la 0,406, iar coeficienții celor doi indici sunt ne semnificativi în regresia comună (coloana 4)
- Indicii bazați pe știri măsoară ce îi îngrijorează pe oameni; COVOL măsoară șocurile care au lovit efectiv prețurile

Studiu de caz: replicare, limite și o extensie propusă

- ▣ **Replicare:** versiunea pe clase de active (Secțiunea 9) cu ETF-urile listate în SUA din data/market, care au toate aceeași oră de închidere: cele 11 ETF-uri sectoriale și ETF-urile pe indicii Russell 1000 Growth și Value, Russell 2000, piețele dezvoltate și emergente din afara SUA, aur, obligațiuni de stat pe termen lung, obligațiuni corporative și petrol; codul GARCH(1,1) din acest capitol ([Quantlet](#))
 - ▶ Un singur factor, PC1 (Secțiunea 9); panel neechilibrat (Secțiunea 7.1); $\hat{x}_t$ prin ec. 17, apoi iterația din Secțiunea 5.3; ξ înainte și după împărțirea lui e_{it}^2 la $\hat{g}_{it}$ (Secțiunea 7.2)
 - ▶ Reperul: tabelul 15 plasează 9 noiembrie 2016 (43,04) și 9 martie 2020 (40,47) între primele patru; dolarul și împărțirea Russell 2000 pe creștere/valoare nu sunt în datele cursului, deci comparăm clasamente, nu niveluri
 - ▶ Valorile de închidere ale indicilor de țară din data/market sunt înregistrate la ore diferite; autorii corectează acest asincronism cu o ajustare pe care nu o specifică (Secțiunea 4), deci versiunea pe țări nu poate fi replicată exact
- ▣ **Limite menționate de autori**
 - ▶ După împărțirea la $\hat{g}_{it}$ pătratele sunt încă semnificativ corelate: posibil un al doilea factor (Secțiunea 7.2); alte seturi de date dau alte evenimente, deci COVOL multifactorial rămâne o problemă deschisă (Secțiunea 9)
 - ▶ Cu $s^\top s = 1$ încărcările scad când N crește: $R_s^2 = 0,640$ pentru $N = 50$, $T = 1000$ față de 0,924 pentru $N = 10$ (tabelul 2); testul pierde putere când încărcările diferă, deci se recomandă $T \geq 1000$ (tabelul 5, Secțiunea 6.1)
- ▣ **Extensie propusă:** după martie 2021, predomină în clasament aceleași tipuri de evenimente? Explică COVOL_m^2 corelațiile DCC lunare din acest capitol și după includerea variației VIX în regresie?
 - ▶ Punct de plecare pentru proiect: Seminarul 6, C3

Studiu de caz: COVOL pe clase de active cu ETF-urile cursului, 2000–2026



- Aplicație pe datele cursului: 20 de ETF-uri listate în SUA și PC1 al acestora, 4 ianuarie 2000 – 18 septembrie 2026, 6 717 zile; ecuația mediei AR(1) cu PC1, GARCH(1,1), apoi algoritmul din Secțiunea 5.3 (13 iterații)
- Romburile: cele mai mari 20 de valori din tabelul 15 din [Engle & Campos-Martins \(2023\)](#) (23 de active, până la 1 martie 2021)

Studiu de caz: interpretarea replicării

- În aplicație, cele mai mari trei valori până la 1 martie 2021 apar la 9 noiembrie 2016 ($\hat{x}_t = 50,5$), 17 septembrie 2001 (43,5) și 9 martie 2020 (32,6)
 - ▶ Alegerile din SUA din 2016, redeschiderea după 11 septembrie (articolul tratează 11, 14 și 17 septembrie 2001 drept același eveniment, nota 4) și prăbușirea din pandemia COVID-19: trei dintre primele patru zile din articol
 - ▶ 12 dintre zilele cu cele mai mari 20 de valori din aplicație, înainte de martie 2021, apar și printre cele 20 de date din tabelul 15, fără seria dolarului și fără împărțirea Russell 2000 pe creștere/valoare
- Nivelurile diferă (73,16 pentru 11 septembrie în articol): cu $s^T s = 1$ și media $\hat{x}_t = 1$, scara depinde de panel, deci doar clasamentele se pot compara
- După încheierea eșantionului din articol: cea mai mare valoare din întregul eșantion este 6 noiembrie 2024 (51,8, randamentul mediu al ETF-urilor 0,95%), ziua de după alegerile din SUA din 2024
 - ▶ Urmează 3 aprilie 2025 (16,5, $-3,67\%$), după anunțarea taxelor vamale ale SUA, și 10 noiembrie 2022 (15,6, 4,56%), ziua publicării unei rate a inflației din SUA sub așteptări
- Randamente medii pozitive în zilele de vârf: COVOL măsoară mărimea șocului comun, nu semnul lui; întrebare deschisă pentru Seminarul 6, C3: au alegerile, taxele vamale și știrile despre inflație un singur factor comun?

O întrebare deschisă

- Este corelația pozitivă acțiuni–obligațiuni de după 2022 un regim durabil, guvernat de inflație, și poate fi prognozată?
- Întrebarea este deschisă
 - ▶ Campbell, Pflueger & Viceira (2020): semnul corelației dintre obligațiuni și acțiuni urmează relația inflație–producție și regimul politicii monetare
 - ▶ Molenaar, Sénéchal, Swinkels & Wang (2024): corelația în mai multe țări, pe o perioadă istorică îndelungată și legăturile ei cu condițiile macroeconomice, precum inflația
 - ▶ Acest capitol: corelația zilnică SPY–TLT $-0,40$ în 2002–2021 și $0,11$ în 2022–2026; DCC deasupra țintei în 92% din zile după 2022
- Specificarea modelului pentru corelațiile realizate lunare ρ_m
 - ▶ $z_m = \operatorname{artanh} \rho_m = a + b \pi_{m-2} + u_m$, π inflația anuală CPI din SUA cunoscută la începutul lunii m
 - ▶ $H_0: b = 0$; $H_1: b > 0$; statistica t HAC; infirmată dacă $b \approx 0$ în perioade în care inflația a variat, dar regimul nu

Bucula descoperirii, pas cu pas (1/2)

- Instrumentele sunt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și motoare de căutare a literaturii științifice (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „*Listează studiile publicate după 2015 despre determinanții corelației acțiuni-obligațiuni, cu DOI, eșantion, măsura corelației, strategia de identificare și estimarea principală.*”
 - ▶ Verificăm în Crossref înregistrarea asociată fiecărui DOI și verificăm estimarea în articol, nu în rezumat
- **Ipoteze:** „*Dă explicații concurente pentru schimbarea de semn din 2022 (nivelul inflației, regimul politicii monetare, un șoc al primei de termen, un episod izolat de înăsprire a politicii monetare) și ce prezice fiecare pentru ρ înainte de 2022 și în afara eșantionului.*”
- **Date și cod:** „*Scrie cod Python care unește prețurile ajustate SPY și TLT din data/market pe zilele comune, calculează corelațiile realizate lunare și adaugă inflația CPI din SUA publicată înainte de începutul fiecărei luni.*”
 - ▶ Replicăm întâi: $-0,40$ (2002–2021) și $0,11$ (2022–2026), cifrele din Secțiunea 1

Bucula descoperirii, pas cu pas (2/2)

- **Robustețe:** „Scrie un plan pre-înregistrat: subeșantionul de dinainte de 2022, inflația de bază în loc de cea totală, randamente săptămânale în loc de zilnice, DCC în loc de corelația realizată, control pentru volatilitatea realizată, decalaj HAC 12.”
 - ▶ Placebo: înlocuim π cu mersuri aleatoare simulate de aceeași persistență; un regresor persistent poate da statistici t mari din întâmplare
- **Critica:** „Joacă rolul unui referent: este b identificat de un singur episod și l-ar explica distorsiunea de volatilitate Forbes–Rigobon? Indică testele care ar evidenția fiecare dintre aceste probleme.”
- **Raportul:** fiecare măsură a inflației, fereastră și frecvență încercată; estimările pe subeșantioane lângă cele pe tot eșantionul
- Fixăm planul înainte de prima rulare: orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare

Ce verifică cercetătorul

- **Informație din viitor:** CPI pentru luna m se publică în luna $m + 1 \Rightarrow$ folosim π_{m-2} și verificăm calendarul publicărilor
 - ▶ Decalajul tratează întârzierea publicării, nu revizuirile: mini-studiul folosește versiunea curentă a CPI ajustat sezonier, revizuit anual; afirmațiile în timp real cer versiuni istorice sau CPI neajustat sezonier, care nu se revizuieste
- **Calendare:** randamentele calculate înainte de unire creează perechi false $\Rightarrow$ unim întâi prețurile pe zilele comune (Secțiunea 2)
- **Regresor persistent, puține regimuri:** inflația poate fi foarte persistentă, iar relația pe tot eșantionul poate fi dominată de episodul de după 2022 $\Rightarrow$ estimări pe subeșantioane, decalaje HAC lungi, placebo cu serii persistente simulate
- **Distorsiunea de volatilitate:** corelația măsurată se mișcă odată cu volatilitatea (Secțiunea 4) $\Rightarrow$ adăugăm volatilitatea realizată drept control
- **Testare multiplă:** mai multe măsuri ale inflației, ferestre și frecvențe $\Rightarrow$ le fixăm în pre-înregistrare
- **Referințe inventate:** un DOI care nu se rezolvă sau o estimare citată greșit $\Rightarrow$ renunțăm la afirmație și o notăm în `AI_ERRORS.md`

Mini-studiu de caz: determină inflația corelația acțiuni–obligațiuni?

- O propunere tipică a unui asistent: „inflația ridicată face pozitivă corelația acțiuni–obligațiuni”; $H_0: b = 0$
- Replicăm: corelația zilnică SPY–TLT $-0,40$ (2002–2021) și $0,11$ (2022–2026)
- Tot eșantionul, 287 luni (septembrie 2002 – august 2026): $\hat{b} = 0,055$ pe punct procentual de inflație, e.s. HAC $0,019$, $t = 2,96$, $R^2 = 0,047$
 - ▶ ρ lunar mediu: $-0,12$ când inflația depășește 3% (89 luni), $-0,30$ în rest (198)
- Verificarea identificării, doar 2002–2021 (232 luni, dintre care 53 cu inflația peste 3%): $\hat{b} = 0,002$, $t = 0,06$
- Interpretare (asociere, nu cauzalitate): panta pe tot eșantionul depinde de episodul de după 2022; panta de dinainte de 2022 nu se distinge de zero, ceea ce nu dovedește absența efectului; o diferență între regimuri cere un test cu interacțiune
- O singură schimbare de regim nu poate separa „nivelul inflației” de „regimul politicii” (Campbell, Pflueger & Viceira (2020)): afirmația nu este încă stabilită

Rândul vostru: un punct de plecare pentru proiectul de echipă

- Întrebarea: prognozează mai bine în afara eșantionului corelația SPY–TLT un model DCC a cărei țintă de corelație depinde de inflație și de dobânda de politică monetară decât DCC-ul simplu?
- Replicăm întâi: estimările DCC din Secțiunea 3 ($a + b = 0,986$, $\bar{Q}_{12} = -0,25$) și panta din mini-studiul de caz $\hat{b} = 0,055$
- Livrabile
 - ▶ O pre-înregistrare de o pagină: ipoteze, funcția de pierdere a prognozei, subeșantioane, placebo și ce ar infirma afirmația
 - ▶ Cod pe data/market plus seria oficială a inflației, o comparație Diebold–Mariano, o autocritică în stilul unui referent
- Notăm fiecare prompt, instrument și rezultat acceptat în AI_USE.md; fiecare eroare prinsă (informație din viitor în CPI, randamente înainte de unire, DOI inventat) și testul care a prins-o în AI_ERRORS.md
- Codul mini-studiului de caz: [Quantlets/Ch_06/ai_discovery_case.py](#); inflația: indicele prețurilor de consum pentru toți consumatorii urbani din SUA, U.S. Bureau of Labor Statistics

Greșeli frecvente

- ▣ Calculul randamentelor înainte de unirea calendarelor sau compararea corelațiilor zilnice între fusuri orare
- ▣ Testarea unei rupturi la o dată aleasă privind graficul: folosim un test cu dată necunoscută
- ▣ Numirea unei creșteri din criză „contagiune” fără corecția Forbes–Rigobon
- ▣ Judecarea adecvării unei copule doar după AIC: cea mai bună dintre cinci poate fi totuși respinsă
- ▣ Presupunerea unei copule Gaussiene pentru risc: dependență zero în cozi prin construcție
- ▣ Încrederea în erorile standard din pasul 2, în erorile standard ale copulei din inversa hessienei sau în intervalele Fisher când volatilitatea se grupează

Locul acestui capitol

Se bazează pe

- Capitolul 1: cozi groase și gruparea volatilității pentru serii individuale
- Capitolul 4: optimizarea portofoliului are nevoie de Σ
- Capitolul 5: GARCH univariat este pasul 1 al DCC și filtrul dinaintea copulelor

Conduce la

- Capitolul 7: VaR și ES de portofoliu cu covarianțe DCC și copule simulate
- Capitolul 8: backtesting pentru prognozele de risc multivariate
- Capitolul 18: risc sistemic și rețele financiare

Concluzii

- Corelațiile se mișcă: SPY–TLT și-a schimbat semnul, Bitcoin–SPY a crescut de la aproape zero la 0,31, BET s-a alăturat ciclului european
- EWMA este simplu, DCC estimează dinamica cu $3N + 2$ parametri și respinge corelația constantă
- Corelațiile din criză trebuie corectate pentru volatilitate înainte de a vorbi de contagiune
- Copulele separă marginalele de dependență; dependența în cozi contează pentru pierderile comune
- Pentru JPM–BAC toate copulele statice sunt respinse, iar o copulă t dinamică se potrivește mult mai bine: dovezi că dependența se mișcă în timp

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ▣  Measuring Statistical Risk
- ▣  Multivariate Statistical Analysis
- ▣  Minimum Spanning Tree
- ▣  FRM: Financial Risk Meter

Cod, date și manuale

- ▣ Toate graficele și tabelele: github.com/danpele/MFM/tree/main/Quantlets/Ch_06
- ▣ Manuale: Franke, Härdle & Hafner (2019); Härdle & Simar (2019); Nelsen (2006)

Bibliografie (1/6)

- ▣ Aas, K., Czado, C., Frigessi, A., Bakken, H. (2009). Pair-copula constructions of multiple dependence. *Insurance: Mathematics and Economics*, 44(2), 182–198.
- ▣ Aielli, G.P. (2013). Dynamic conditional correlation: on properties and estimation. *Journal of Business & Economic Statistics*, 31(3), 282–299.
- ▣ Ang, A., Chen, J. (2002). Asymmetric correlations of equity portfolios. *Journal of Financial Economics*, 63(3), 443–494.
- ▣ Baker, S.R., Bloom, N., Davis, S.J. (2016). Measuring economic policy uncertainty. *Quarterly Journal of Economics*, 131(4), 1593–1636.
- ▣ Billio, M., Getmansky, M., Lo, A.W., Pelizzon, L. (2012). Econometric measures of connectedness and systemic risk in the finance and insurance sectors. *Journal of Financial Economics*, 104(3), 535–559.
- ▣ Bollerslev, T. (1990). Modelling the coherence in short-run nominal exchange rates: a multivariate generalized ARCH model. *Review of Economics and Statistics*, 72(3), 498–505.
- ▣ Bollerslev, T., Engle, R.F., Wooldridge, J.M. (1988). A capital asset pricing model with time-varying covariances. *Journal of Political Economy*, 96(1), 116–131.
- ▣ Caldara, D., Iacoviello, M. (2022). Measuring geopolitical risk. *American Economic Review*, 112(4), 1194–1225.
- ▣ Campbell, J.Y., Pflueger, C., Viceira, L.M. (2020). Macroeconomic drivers of bond and equity risks. *Journal of Political Economy*, 128(8), 3148–3185.
- ▣ Chen, X., Fan, Y. (2006). Estimation and model selection of semiparametric copula-based multivariate dynamic models under copula misspecification. *Journal of Econometrics*, 135(1–2), 125–154.
- ▣ Clayton, D.G. (1978). A model for association in bivariate life tables and its application in epidemiological studies of familial tendency in chronic disease incidence. *Biometrika*, 65(1), 141–151.

Bibliografie (2/6)

- ▣ Corsetti, G., Pericoli, M., Sbracia, M. (2005). 'Some contagion, some interdependence': more pitfalls in tests of financial contagion. *Journal of International Money and Finance*, 24(8), 1177–1199.
- ▣ Creal, D., Koopman, S.J., Lucas, A. (2013). Generalized autoregressive score models with applications. *Journal of Applied Econometrics*, 28(5), 777–795.
- ▣ Demarta, S., McNeil, A.J. (2005). The t copula and related copulas. *International Statistical Review*, 73(1), 111–129.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Diebold, F.X., Yilmaz, K. (2009). Measuring financial asset return and volatility spillovers, with application to global equity markets. *Economic Journal*, 119(534), 158–171.
- ▣ Embrechts, P., McNeil, A.J., Straumann, D. (2002). Correlation and dependence in risk management: properties and pitfalls. In M.A.H. Dempster (ed.), *Risk Management: Value at Risk and Beyond*, 176–223. Cambridge University Press.
- ▣ Engle, R.F. (2002). Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- ▣ Engle, R.F., Campos-Martins, S. (2023). What are the events that shake our world? Measuring and hedging global COVOL. *Journal of Financial Economics*, 147(1), 221–242.
- ▣ Engle, R.F., Kroner, K.F. (1995). Multivariate simultaneous generalized ARCH. *Econometric Theory*, 11(1), 122–150.
- ▣ Engle, R.F., Ledoit, O., Wolf, M. (2019). Large dynamic covariance matrices. *Journal of Business & Economic Statistics*, 37(2), 363–375.
- ▣ Engle, R.F., Sheppard, K. (2001). Theoretical and empirical properties of dynamic conditional correlation multivariate GARCH. NBER Working Paper 8554.

Bibliografie (3/6)

- ▣ Forbes, K.J., Rigobon, R. (2002). No contagion, only interdependence: measuring stock market comovements. *Journal of Finance*, 57(5), 2223–2261.
- ▣ Frank, M.J. (1979). On the simultaneous associativity of $F(x, y)$ and $x + y - F(x, y)$. *Aequationes Mathematicae*, 19, 194–226.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Genest, C., Ghoudi, K., Rivest, L.-P. (1995). A semiparametric estimation procedure of dependence parameters in multivariate families of distributions. *Biometrika*, 82(3), 543–552.
- ▣ Genest, C., Rémillard, B., Beaudoin, D. (2009). Goodness-of-fit tests for copulas: a review and a power study. *Insurance: Mathematics and Economics*, 44(2), 199–213.
- ▣ Genest, C., Rivest, L.-P. (1993). Statistical inference procedures for bivariate Archimedean copulas. *Journal of the American Statistical Association*, 88(423), 1034–1043.
- ▣ Grecu, R.A., Cramer, A.A., Pele, D.T., Lessmann, S. (2025). The link between energy prices and stock markets in European Union countries. *The North American Journal of Economics and Finance*, 78, 102420.
- ▣ Gumbel, E.J. (1960). Bivariate exponential distributions. *Journal of the American Statistical Association*, 55(292), 698–707.
- ▣ Härdle, W.K., Simar, L. (2019). *Applied Multivariate Statistical Analysis*, 5th ed. Springer.
- ▣ Herskovic, B., Kelly, B., Lustig, H., Van Nieuwerburgh, S. (2016). The common factor in idiosyncratic volatility: quantitative asset pricing implications. *Journal of Financial Economics*, 119(2), 249–283.
- ▣ Joe, H. (2005). Asymptotic efficiency of the two-stage estimation method for copula-based models. *Journal of Multivariate Analysis*, 94(2), 401–419.

Bibliografie (4/6)

- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics – Technical Document*, 4th ed. New York.
- ▣ Kendall, M.G. (1938). *A new measure of rank correlation*. *Biometrika*, 30(1–2), 81–93.
- ▣ Li, D.X. (2000). *On default correlation: a copula function approach*. *Journal of Fixed Income*, 9(4), 43–54.
- ▣ Longin, F., Solnik, B. (2001). *Extreme correlation of international equity markets*. *Journal of Finance*, 56(2), 649–676.
- ▣ Mantegna, R.N. (1999). *Hierarchical structure in financial markets*. *European Physical Journal B*, 11(1), 193–197.
- ▣ Markowitz, H. (1952). *Portfolio selection*. *Journal of Finance*, 7(1), 77–91.
- ▣ Molenaar, R., Sénéchal, E., Swinkels, L., Wang, Z. (2024). *Empirical evidence on the stock–bond correlation*. *Financial Analysts Journal*, 80(3), 17–36.
- ▣ Nelsen, R.B. (2006). *An Introduction to Copulas*, 2nd ed. Springer.
- ▣ Newey, W.K., McFadden, D. (1994). *Large sample estimation and hypothesis testing*. In R.F. Engle, D.L. McFadden (eds.), *Handbook of Econometrics*, Vol. 4, 2111–2245. Elsevier.
- ▣ Newey, W.K., West, K.D. (1987). *A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix*. *Econometrica*, 55(3), 703–708.
- ▣ Oh, D.H., Patton, A.J. (2018). *Time-varying systemic risk: evidence from a dynamic copula model of CDS spreads*. *Journal of Business & Economic Statistics*, 36(2), 181–195.

Bibliografie (5/6)

- ▣ Okhrin, O., Okhrin, Y., Schmid, W. (2013). On the structure and estimation of hierarchical Archimedean copulas. *Journal of Econometrics*, 173(2), 189–204.
- ▣ Pakel, C., Shephard, N., Sheppard, K., Engle, R.F. (2021). Fitting vast dimensional time-varying covariance models. *Journal of Business & Economic Statistics*, 39(3), 652–668.
- ▣ Patton, A.J. (2006). Modelling asymmetric exchange rate dependence. *International Economic Review*, 47(2), 527–556.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *European Journal of Finance*, 29(10), 1064–1105.
- ▣ Politis, D.N., White, H. (2004). Automatic block-length selection for the dependent bootstrap. *Econometric Reviews*, 23(1), 53–70.
- ▣ Rémillard, B. (2017). Goodness-of-fit tests for copulas of multivariate time series. *Econometrics*, 5(1), 13.
- ▣ Rigobon, R. (2003). Identification through heteroskedasticity. *Review of Economics and Statistics*, 85(4), 777–792.
- ▣ Schmidt, R., Stadtmüller, U. (2006). Non-parametric estimation of tail dependence. *Scandinavian Journal of Statistics*, 33(2), 307–335.
- ▣ Sklar, A. (1959). Fonctions de répartition à n dimensions et leurs marges. *Publications de l'Institut de Statistique de l'Université de Paris*, 8, 229–231.
- ▣ Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, 15(1), 72–101.
- ▣ Toma, F.-M., Dima, D.M., Grecu, R., Pele, D.T., Lessmann, S. (2026). Energy Financial Risk Meter: systemic risk in the EU energy sector. SSRN Working Paper.

Bibliografie (6/6)

- ▣ Tse, Y.K. (2000). A test for constant correlations in a multivariate GARCH model. *Journal of Econometrics*, 98(1), 107–127.
- ▣ Wied, D., Krämer, W., Dehling, H. (2012). Testing for a change in correlation at an unknown point in time using an extended functional delta method. *Econometric Theory*, 28(3), 570–589.