



Modelarea piețelor financiare

Capitolul 7: VaR și Expected Shortfall



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **AI:** Artificial Intelligence — *inteligență artificială*
- ▣ **AR:** AutoRegressive (model); in event studies: Abnormal Return — *model autoregresiv; în studiile de eveniment: randament anormal*
- ▣ **ARMA:** AutoRegressive Moving Average (model) — *model autoregresiv cu medie mobilă*
- ▣ **BET:** Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- ▣ **BIS:** Bank for International Settlements — *Banca Reglementelor Internaționale*
- ▣ **BNR:** Banca Națională a României
- ▣ **BVB:** Bursa de Valori București
- ▣ **CF:** Cornish–Fisher (expansion) — *dezvoltarea Cornish–Fisher*
- ▣ **COVID-19:** COronaVirus Disease 2019 — *boala provocată de coronavirus, 2019*
- ▣ **CQFE:** Conditional Quantile Forecast Encompassing (test) — *testul de includere a prognozelor cuantilelor condiționate*
- ▣ **CV:** Cross-Validation — *validare încrucișată*
- ▣ **DM:** Diebold–Mariano (test) — *testul Diebold–Mariano de comparare a prognozelor*
- ▣ **ES:** Expected Shortfall — *pierdere așteptată în coadă*
- ▣ **ETF:** Exchange-Traded Fund — *fond tranzacționat la bursă*
- ▣ **EU:** European Union — *Uniunea Europeană*
- ▣ **EVT:** Extreme Value Theory — *teoria valorilor extreme*
- ▣ **FHS:** Filtered Historical Simulation — *simulare istorică filtrată*
- ▣ **FRTB:** Fundamental Review of the Trading Book — *revizuirea fundamentală a portofoliului de tranzacționare*
- ▣ **FZ0:** Fissler–Ziegel loss, zero-homogeneous version — *funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero*

Acronime folosite în acest material (2/2)

- **GARCH:** Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GAS:** Generalised Autoregressive Score (model) — *model cu scor autoregresiv generalizat*
- **GEV:** Generalised Extreme Value (distribution) — *distribuția generalizată a valorilor extreme*
- **GPD:** Generalised Pareto Distribution — *distribuția Pareto generalizată*
- **HAC:** Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **LASSO:** Least Absolute Shrinkage and Selection Operator — *regresie penalizată L1 cu selecția variabilelor*
- **MIDAS:** MlXed DAta Sampling (regression) — *regresie cu date de frecvențe mixte*
- **MSE:** Mean Squared Error — *eroarea pătratică medie*
- **QML:** Quasi-Maximum Likelihood — *cvasi-verosimilitate maximă*
- **RMSFE:** Root Mean Squared Forecast Error — *rădăcina erorii pătratice medii de prognoză*
- **SAV:** Symmetric Absolute Value (CAViaR specification) — *specificația CAViaR cu valoare absolută simetrică*
- **SE:** Standard Error — *eroare standard*
- **SHAP:** SHapley Additive exPlanations — *explicații aditive Shapley*
- **SUA:** Statele Unite ale Americii
- **UE:** Uniunea Europeană
- **XFG:** Quantlet prefix of Applied Quantitative Finance (Härdle, Chen & Overbeck) — *prefixul Quantlet-urilor din Applied Quantitative Finance (Härdle, Chen & Overbeck)*

Structura capitolului și rezultatele învățării

Structura capitolului

- ▣ Partea I: definiții, coerență, metode de estimare necondiționate și precizia lor
- ▣ Partea a II-a: prognoze condiționate (FHS, CAViaR), teoria valorilor extreme, orizontul, portofoliul, reglementarea, un studiu de caz și un exemplu de buclă de cercetare asistată de AI
- ▣ Exemplul principal: pierderile zilnice ale S&P 500, 2000–2026; comparații pe BET, Bitcoin, EUR/RON (cursul de referință BNR) și aur; date până la 18 septembrie 2026 (inventarul complet în [▶ Anexă](#))
- ▣ Unități: randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$, cu P_t prețul de închidere din ziua t ; detaliile tehnice se află în [▶ Anexă](#)

La sfârșitul capitolului veți putea

- ▣ defini VaR și ES și explica de ce ES este coerent, iar VaR nu
- ▣ estima ambele măsuri istoric, parametric, prin simulare filtrată și prin teoria valorilor extreme, fiecare cu o eroare standard sau un interval
- ▣ le scala la 10 zile, le descompune pe active și interpreta regulile Basel și FRTB

Pierdere potențială: RiskMetrics și VaR



Clădirea J.P. Morgan & Co., 23 Wall Street, New York

Foto: Beyond My Ken (2012); CC BY-SA 4.0; Wikimedia

[Commons](#)

- Valoarea de mâine a portofoliului este aleatoare; conducerea și autoritățile au nevoie de **un singur număr**: un prag de pierdere depășit rar, folosit la stabilirea limitelor și a cerințelor de **capital**
- J.P. Morgan a publicat **RiskMetrics** în octombrie 1994, o metodologie și un set de date gratuite pentru riscul de piață; documentul tehnic (ed. a 4-a, 1996) a devenit referința pentru VaR [J.P. Morgan/Reuters \(1996\)](#)
- Manuale: [Franke, Härdle & Hafner \(2019\)](#), [McNeil, Frey & Embrechts \(2015\)](#), [Dánielsson \(2011\)](#)

Pierderi, orizonturi și probabilități ale cozii

- ▣ Randamentul pe o zi: $X_{t+1} = r_{t+1}$, randamentul log în %; **pierdere** $L_{t+1} = -X_{t+1}$, o **pierdere log**
 - ▶ L pozitiv = poziția a pierdut bani; L negativ = un câștig
 - ▶ În bani, cu V_t valoarea poziției: pierdere = $V_t (1 - e^{-L_{t+1}/100}) \approx V_t L_{t+1}/100$ pentru L mic; cu randamente simple R , $V_t (-R_{t+1})/100$ este exactă
 - ▶ VaR se convertește exact prin această transformare monotonă; pentru ES, convertim pierderea din fiecare scenariu, apoi calculăm media
- ▣ **Orizontul h** : numărul de zile pe care se măsoară pierderea (1 zi, 10 zile)
- ▣ **Nivelul α** : **probabilitatea cozii**, de regulă $\alpha = 1\%$ sau $2,5\%$: „VaR 1%”, „ES 2,5%”
- ▣ **Convenția de semn în acest curs**: VaR și ES sînt numere **pozitive** atunci cînd sînt pierderi


Definiții (1/2): valoarea la risc (VaR)

- ▣ **VaR** la nivelul α : pierderea depășită cu probabilitatea α (exact pentru L continuă, cel mult α în general)
 - ▶ $\text{VaR}_\alpha(X) = -\inf\{x \in \mathbb{R} : P(X \leq x) > \alpha\} = -q_\alpha(X)$
 - ▶ În cuvinte: VaR este cuantila de ordin α a randamentului, cu semn schimbat, adică pragul sub care cade doar o fracțiune α din zile
- ▣ Notățiile
 - ▶ X : randamentul poziției pe orizontul ales; $P(X \leq x)$: probabilitatea ca acesta să fie cel mult x , adică funcția de repartiție în x
 - ▶ $\inf\{\cdot\}$: infimumul (cel mai mare minorant) al mulțimii, aici cel mai mic x în care funcția de repartiție depășește α
 - ▶ $q_\alpha(X)$: cuantila de ordin α a lui X , negativă pentru α mic; pentru o pierdere continuă $L = -X$: $\text{VaR}_\alpha = q_{1-\alpha}(L)$, cuantila superioară a pierderii
- ▣ Interpretarea VaR 1%
 - ▶ „Cu probabilitatea de 1%, pierderea de mâine va depăși $\text{VaR}_{1\%}$ ”
 - ▶ VaR **nu** spune cât de mare este pierderea dincolo de acest prag

Definiții (2/2): Expected Shortfall

- ▣ **Expected Shortfall** (pierdere așteptată în coadă): media tuturor cuantilelor din coada de probabilitate α
 - ▶ $ES_\alpha(X) = -\frac{1}{\alpha} \int_0^\alpha q_u(X) du = \frac{1}{\alpha} \int_0^\alpha VaR_u(X) du$
 - ▶ u : variabila de integrare, o probabilitate a cozii care parcurge intervalul de la 0 la α ; integrala împărțită la α este media lui VaR_u pe toate nivelurile $u \leq \alpha$
- ▣ Pentru o distribuție continuă: pierdere medie în zilele de dincolo de VaR
 - ▶ $ES_\alpha(X) = -\mathbb{E}[X \mid X \leq q_\alpha(X)]$; $\mathbb{E}[\cdot \mid \cdot]$: media condiționată, aici media lui X pe cea mai rea fracțiune α a rezultatelor
 - ▶ Întotdeauna $ES_\alpha \geq VaR_\alpha$: ES descrie **întreaga** coadă, VaR doar pragul ei; două portofolii cu același VaR pot avea ES foarte diferite
- ▣ Alte denumiri: Conditional VaR (CVaR), Tail VaR, Average VaR [Rockafellar & Uryasev \(2002\)](#), [Acerbi & Tasche \(2002\)](#)
- ▣ Estimarea istorică a ES: media pierderilor observate mai mari sau egale cu VaR empiric
 - ▶ O aproximare a integralei pe baza distribuției empirice, exactă când $n\alpha$ este întreg; n : numărul de observații

VaR și ES pentru S&P 500 (1/2)



VaR și ES pentru S&P 500 (2/2)

- ▣ Pierderile zilnice 2000–2026 față de distribuția Normală cu aceeași medie și abatere standard (stînga); coada (dreapta)
- ▣ $\text{VaR}_{1\%}$ istoric = 3,45%: în 68 din 6 717 zile (1,01%) pierderea a fost mai mare; în acele zile, pierderea medie, $\text{ES}_{1\%}$, a fost 5,01%
- ▣ $\text{VaR}_{2,5\%} = 2,51\%$, $\text{ES}_{2,5\%} = 3,76\%$; cea mai mare pierdere, 12,77%, pe 2020-03-16 (crahul din pandemia COVID-19), circa zece abateri standard
- ▣ Distribuția Normală se potrivește în centru, dar are cozi mult prea subțiri ([Capitolul 1](#))

 MFM_ch7_loss_distribution

Distribuția Normală: ES într-o singură formulă (1/2)

- ▣ Cadrul: $X \sim N(\mu, \sigma^2)$, un randament cu distribuția Normală, de medie μ și abatere standard σ
 - ▶ Φ, φ : funcția de repartiție și densitatea distribuției Normale standard $N(0, 1)$
 - ▶ $z_\alpha = \Phi^{-1}(\alpha) < 0$: cuantila de ordin α a distribuției Normale standard, de exemplu $z_{1\%} = -2,326$
- ▣ VaR: media minus $|z_\alpha|$ abateri standard, cu semn schimbat
 - ▶ $\text{VaR}_\alpha = -(\mu + \sigma z_\alpha)$
- ▣ ES: aceeași formă, cu factorul mai mare $\varphi(z_\alpha)/\alpha$ în locul lui $-z_\alpha$
 - ▶ $\text{ES}_\alpha = -\mu - \frac{\sigma}{\alpha} \int_{-\infty}^{z_\alpha} u \varphi(u) du = -\mu + \sigma \frac{\varphi(z_\alpha)}{\alpha}$
 - ▶ Integrala este media șocului standardizat u pe coada $u \leq z_\alpha$; ea este egală cu $-\varphi(z_\alpha)$ deoarece $\varphi'(u) = -u\varphi(u)$

Distribuția Normală: ES într-o singură formulă (2/2)

▣ Constante utile

- ▶ $-z_{1\%} = 2,326$, $\varphi(z_{1\%})/0,01 = 2,665$
- ▶ $-z_{2,5\%} = 1,960$, $\varphi(z_{2,5\%})/0,025 = 2,338$
- ▶ Deci, sub distribuția Normală, ES 2,5% este aproape egal cu VaR 1% (2,338 față de 2,326 abateri standard)

▣ S&P 500 ($\hat{\mu} = 0,025\%$, $\hat{\sigma} = 1,21\%$; notația $\hat{\cdot}$ indică o valoare estimată din date): $\text{VaR}_{1\%}^{\text{Normal}} = 2,80\%$ față de 3,45% istoric

- ▶ De 1,24 ori mai mic decât valoarea istorică
- ▶ Sub distribuția Normală, pentru μ dat, VaR și ES nu aduc informație dincolo de σ

Exemplu numeric: distribuția Student- t

- ▣ Modelul: randamentul este o variabilă Student- t deplasată și rescalată, $X = m + s T$ cu $T \sim t_\nu$
 - ▶ m : parametrul de poziție; $s > 0$: scala; ν : gradele de libertate, ν mai mic = cozi mai grele
 - ▶ $t_\alpha = t_\nu^{-1}(\alpha) < 0$: cuantila de ordin α a lui t_ν ; g_ν : densitatea lui t_ν
- ▣ VaR ca la distribuția Normală, cu t_α în locul lui z_α ; ES primește un factor suplimentar $(\nu + t_\alpha^2)/(\nu - 1) > 1$, datorat cozii grele
 - ▶ $\text{VaR}_\alpha = -(m + s t_\alpha)$, $\text{ES}_\alpha = -m + s \frac{g_\nu(t_\alpha)}{\alpha} \frac{\nu + t_\alpha^2}{\nu - 1}$ (pentru $\nu > 1$)
 - ▶ Dispersia $s^2 \nu / (\nu - 2)$ există doar pentru $\nu > 2$, deci s nu este abaterea standard
- ▣ Estimare de verosimilitate maximă pe randamentele S&P 500: $\hat{\nu} = 2,67$
 - ▶ $\text{VaR}_{1\%} = 3,46\%$ (istoric 3,45%), $\text{ES}_{1\%} = 5,71\%$ (istoric 5,01%)
- ▣ Distribuția t corectează VaR, dar cu $\hat{\nu} < 3$ supraestimează ES: un singur parametru trebuie să descrie și centrul, și coada

Măsuri de risc coerente (1/2): cele patru axiome

- O **măsură de risc** ρ asociază unei pierderi L (o variabilă aleatoare) un număr, capitalul necesar; este **coerentă** dacă satisface patru axiome Artzner, Delbaen, Eber & Heath (1999)
 - ▶ L_1, L_2 : două pierderi; c : o sumă sigură (constantă); $\lambda \geq 0$: un factor de scală (mărimea poziției)
- **Monotonă**: $L_1 \leq L_2 \Rightarrow \rho(L_1) \leq \rho(L_2)$
 - ▶ o poziție care pierde mereu mai mult cere mai mult capital
- **Invariantă la translație**: $\rho(L + c) = \rho(L) + c$
 - ▶ adăugarea unei pierderi sigure c crește capitalul exact cu c
- **Pozitiv omogenă**: $\rho(\lambda L) = \lambda \rho(L)$
 - ▶ dublarea poziției dublează capitalul
- **Subaditivă**: $\rho(L_1 + L_2) \leq \rho(L_1) + \rho(L_2)$
 - ▶ reunirea a două poziții nu cere niciodată mai mult capital decât păstrarea lor separată: diversificarea nu adaugă risc

Măsuri de risc coerente (2/2): implicațiile axiomelor

▣ Limitele de risc

- ▶ Prin subaditivitate, riscul întregii bănci nu depășește suma limitelor de risc ale birourilor de tranzacționare, $\sum_i \rho_i$
- ▶ **Fără arbitraj de reglementare** prin divizarea firmei

▣ Optimizare: omogenitate + subaditivitate $\Rightarrow$ convexitate în ponderile portofoliului

- ▶ Orice minim local este global; unicitatea ar cere convexitate **strictă**, pe care ES pe scenarii nu o are (este liniar pe porțiuni)


▣ VaR satisface primele trei axiome, dar **nu** și subaditivitatea în general

- ▶ Excepție: pierderi cu distribuție eliptică comună (Normală sau Student- t multivariată) și $\alpha < 50\%$, când VaR și ES sînt ambele $\mu_p + \sigma_p \times \text{constantă}$ [McNeil, Frey & Embrechts \(2015\)](#)
- ▶ μ_p, σ_p : media și abaterea standard a pierderii portofoliului; rafinările pentru cozi grele sînt în [▶ Anexă](#)

Contraexemplu: două obligațiuni, pas cu pas

- Obligațiunile A și B, independente; fiecare pierde 100 cu probabilitatea $p = 0,9\%$ (neplată) și 0 altfel; X : variația valorii, $X = -L$
- **O obligațiune:** $P(X \leq -100) = p = 0,9\%$, nu peste 1%, deci $q_{1\%} = 0$ și $\text{VaR}_{1\%}(A) = \text{VaR}_{1\%}(B) = 0$
 - ▶ $\text{ES}_{1\%}(A) = (100 \cdot 0,009 + 0 \cdot 0,001)/0,01 = 90$
- **Portofoliul A + B:** $P(X \leq -100) = 1 - (1 - p)^2 = 1,79\% > 1\%$, $P(X \leq -200) = p^2 = 0,0081\%$, deci $q_{1\%} = -100$
 - ▶ $\text{VaR}_{1\%}(A + B) = 100 > 0 + 0 = \text{VaR}_{1\%}(A) + \text{VaR}_{1\%}(B)$
 - ▶ Formula generală pentru o pierdere discretă $L = -X$: $\text{ES}_\alpha = \frac{1}{\alpha} (\mathbb{E}[L \mathbf{1}\{L > \text{VaR}_\alpha\}] + \text{VaR}_\alpha (\alpha - P(L > \text{VaR}_\alpha)))$
 - ▶ $\mathbf{1}\{\cdot\}$: indicatorul, 1 dacă are loc condiția și 0 altfel; primul termen: pierderile strict dincolo de VaR; al doilea: restul probabilității cozii α , plasat chiar în VaR
- $\text{ES}_{1\%}(A + B) = 100,81 \leq 180 = \text{ES}_{1\%}(A) + \text{ES}_{1\%}(B)$

Subaditivitatea: încălcată de VaR, respectată de ES



- Albastru: suma celor două măsuri individuale; roșu: măsura portofoliului combinat
- Pentru fiecare obligațiune luată separat, probabilitatea de neplată rămîne sub 1%, deci nu influențează VaR; împreună, cel puțin o neplată are probabilitatea $1,79\% > 1\%$, iar VaR crește brusc la 100
- O limită VaR ar recompensa **concentrarea**: deținerea doar a obligațiunii A pare fără risc; ES ține cont de mărimea pierderilor din coadă și este coerent [Acerbi & Tasche \(2002\)](#)
- Portofoliile de credit, opțiunile și alte câștiguri asimetrice sînt situațiile tipice în care VaR încălcă subaditivitatea în practică

ES ca problemă de optimizare: Rockafellar–Uryasev

- **Teoremă Rockafellar & Uryasev (2000):** pentru orice pierdere integrabilă L
 - ▶ $ES_\alpha(L) = \min_{v \in \mathbb{R}} F(v)$, $F(v) = v + \frac{1}{\alpha} \mathbb{E}[(L - v)_+]$, $(x)_+ = \max(x, 0)$
 - ▶ v : un prag candidat; $F(v)$: pragul plus depășirea medie a pierderii peste prag, mărită cu factorul $1/\alpha$
 - ▶ Punctul de minim este $VaR_\alpha(L)$, valoarea minimă este $ES_\alpha(L)$; $F(VaR_\alpha)$ este formula ES discretă de pe slide-ul celor două obligațiuni
- F este convexă în v și, pentru pierderea unui portofoliu $-w^\top R$, convexă simultan în (w, v)
 - ▶ w : vectorul ponderilor; R : vectorul randamentelor activelor
 - ▶ ES este convex în ponderi, ceea ce **demonstrează** subaditivitatea (demonstrația în [Anexă](#))
 - ▶ Cu scenarii istorice, minimizarea ES devine o problemă de programare liniară (secțiunea „VaR de portofoliu și contribuțiile la risc”)
- Pierderile S&P 500, $\alpha = 2,5\%$: $\arg \min F = 2,51\%$ (valoarea v care minimizează), $\min F = 3,76\%$
 - ▶ VaR și ES istorice (cuantilă interpolată, medie în coadă): $2,51\%$ și $3,76\%$
 - ▶ Egale doar după rotunjire: punctul de minim empiric este o statistică de ordine

Coerență și robustețe

- ▣ **Robustețe calitativă:** o mică schimbare a distribuției datelor modifică doar puțin distribuția estimatorului [Cont, Deguest & Scandolo \(2010\)](#)
 - ▶ VaR istoric este calitativ robust în distribuțiile cu α -cuantilă unică; ES istoric **nu**: o singură pierdere extremă îl poate modifica oricât de mult (secțiunea „Precizia estimărilor VaR și ES”)
- ▣ S&P 500, ultimele 500 de zile: eliminăm cea mai mare pierdere (6,16%, 2025-04-04)
 - ▶ $ES_{2,5\%}$: 2,94% $\rightarrow$ 2,60%; $VaR_{1\%}$: 2,73% $\rightarrow$ 2,68%
- ▣ Există un compromis: subaditivitatea cere informație din coada de dincolo de cuantilă, exact ceea ce face ES sensibil la observații izolate
- ▣ FRTB a ales coerența pentru capital (ES 2,5%) și a păstrat VaR, robust și elicitabil, pentru backtesting

Elicitabilitatea: dificultatea evaluării ES (Capitolul 8)

- O măsură de risc este **elicitabilă** dacă minimizează valoarea așteptată a unei funcții de scor
 - ▶ VaR: cuantila $q_\alpha(X)$ minimizează funcția de pierdere pinball $\mathbb{E}[(1\{X \leq v\} - \alpha)(v - X)]$
 - ▶ Funcția de scor: o penalizare calculată din prognoza v și din rezultatul X , mai mică înseamnă mai bine; pierderea pinball penalizează cu $1 - \alpha$ pe unitate când X cade sub v și cu α pe unitate când rămîne deasupra
- ES, considerat separat, **nu** este elicitabil [Gneiting \(2011\)](#): nu există o funcție de scor strict consistentă pentru prognozele ES evaluate separat
- Perechea (VaR, ES) este elicitabilă împreună [Fissler & Ziegel \(2016\)](#): scoruri comune precum FZ0 ordonează prognozele (VaR, ES) ([▶ Anexă](#); Capitolul 8)
- Consecință: compararea prognozelor de ES este mai dificilă decît a celor de VaR
 - ▶ Precizia ES este dată de numărul de observații din coadă $n\alpha$, nu de n [Pele & Mazurencu-Marinescu-Pele \(2026\)](#); S&P 500, 26 de ani: doar 168 zile în coada lui ES 2,5%

Simularea istorică

- Luăm ultimele n pierderi zilnice $L_{t-n+1}, \dots, L_t$ și le ordonăm: $L_{(1)} \leq \dots \leq L_{(n)}$; $L_{(i)}$: a i -a cea mai mică pierdere (statistica de ordine i)
 - ▶ $\widehat{\text{VaR}}_\alpha =$ cuantila empirică de ordin $(1 - \alpha)$, interpolată liniar în poziția $1 + (n - 1)(1 - \alpha)$ a pierderilor ordonate (convenția folosită peste tot)
 - ▶ $\widehat{\text{ES}}_\alpha =$ media celor k_α pierderi $\geq \widehat{\text{VaR}}_\alpha$, $k_\alpha \approx n\alpha$; înlocuirea exactă în integrală dă pierderii de la frontieră ponderea $n\alpha - \lfloor n\alpha \rfloor$ ($\lfloor x \rfloor$: partea întreagă a lui x), deci cele două coincid doar când $n\alpha$ este întreg (pierderi distincte)
- Alegerea ferestrei n : estimarea pe 250 de zile reacționează mai repede, iar cea pe 1 000 de zile este mai precisă
 - ▶ Cu $n = 500$: 5 pierderi se află dincolo de VaR 1%; ES 2,5% este media a $k = 13$ pierderi ($n\alpha = 12,5$)
- Nicio pierdere mai mare decât cea mai rea din fereastră nu poate apărea în estimare
- **Efectul fantomă**: o zi de criză intră în fereastră, rămîne n zile, apoi iese și VaR scade brusc

Dezvoltarea Cornish–Fisher (1/2)



- ▣ Ajustăm cuantila Normală pentru **asimetrie** $S = \mathbb{E}[(X - \mu)^3]/\sigma^3$ și **excesul de kurtosis** $K = \mathbb{E}[(X - \mu)^4]/\sigma^4 - 3$ **Cornish & Fisher (1938)**

- $\tilde{z}_\alpha = z_\alpha + \frac{(z_\alpha^2 - 1)S}{6} + \frac{(z_\alpha^3 - 3z_\alpha)K}{24} - \frac{(2z_\alpha^3 - 5z_\alpha)S^2}{36}, \quad \text{VaR}_\alpha = -(\mu + \sigma\tilde{z}_\alpha)$
- $\tilde{z}_\alpha$: cuantila corectată, cuantila Normală $z_\alpha < 0$ plus un termen pentru asimetrie, unul pentru excesul de kurtosis și unul pentru pătratul asimetriei; $S = K = 0$ redă VaR Normal
- $S < 0$ (coada stângă a randamentelor mai lungă) sau $K > 0$ (cozi grele) împing $\tilde{z}_\alpha$ sub z_α și cresc VaR

Dezvoltarea Cornish–Fisher (2/2)

- ES: media lui $-(\mu + \sigma \tilde{z}_u)$ pe $u \in (0, \alpha)$, calculată numeric
- O dezvoltare în jurul distribuției Normale: precisă doar pentru S și K **mici**; pentru K mare, transformarea $z \mapsto \tilde{z}$ nici măcar nu este monotonă (Seminarul 7, A6)
- Randamentele S&P 500: $S = -0,35$, $K = 10,7$: mult în afara acestui domeniu
 - ▶ $\text{VaR}_{1\%}^{CF} = 6,08\%$ față de valoarea istorică 3,45%: termenul de kurtosis supraestimează puternic VaR

Cinci metode la diferite niveluri de risc (1/2)




Cinci metode la diferite niveluri de risc (2/2)

- Pierderile zilnice S&P 500 2000–2026, α de la 5% pînă la 0,1%; EVT = coada Pareto generalizată, o anticipare a secțiunii „Teoria valorilor extreme”
- VaR 0,1% (o zi în patru ani): istoric 7,22%, EVT 7,04%, Student- t 8,58%, Cornish–Fisher 15,06%, distribuția Normală 3,72%, aproximativ jumătate
- Diferența dintre metode **crește** cînd α scade, mai mult pentru ES decît pentru VaR; EVT și estimarea istorică coincid pînă la 0,5%, mai jos EVT extrapolează o coadă estimată

 MFM_ch7_var_levels

Metodele comparate pe cinci active (1/2)



Metodele comparate pe cinci active (2/2)

- Bare pline: $\text{VaR}_{1\%}$; bare hașurate: $\text{ES}_{2,5\%}$; pierderi zilnice în %, selecțiile complete (toate cifrele în [Anexă](#))
- Distribuția Normală: VaR prea mic peste tot (Bitcoin $\text{VaR}_{1\%}$ 7,99% față de 10,51% istoric)
- Cornish–Fisher: supraestimează VaR, deoarece excesul de kurtosis depășește 7 în toate seriile (BET 7,25% față de 4,13%)
- **Excepție:** Student- t pentru EUR/RON
 - ▶ $\hat{\nu} = 1,25$ (dispersie infinită) și un ES nerealist de 3,27%
 - ▶ Numeroasele variații aproape nule ale cursului de referință împing $\hat{\nu}$ în jos
- EVT rămîne apropiată de simularea istorică pentru VaR 1% în toate cele cinci serii


Erori standard pentru VaR și ES (1/2): VaR

- ▣ Eroarea standard (SE): abaterea standard a unui estimator de la o selecție la alta; un interval de 95% este aproximativ estimarea $\pm 1,96$ SE
- ▣ **VaR**: pierderi i.i.d. (independente și identic distribuite) cu densitatea f continuă și pozitivă în VaR_α
 - ▶ $\text{SE}(\widehat{\text{VaR}}_\alpha) \approx \frac{1}{f(\text{VaR}_\alpha)} \sqrt{\frac{\alpha(1-\alpha)}{n}}$
 - ▶ $\sqrt{\alpha(1-\alpha)}/n$: SE a proporției de zile dincolo de VaR; împărțirea la densitatea $f(\text{VaR}_\alpha)$ o transformă într-o eroare pe scala pierderii
 - ▶ Densitatea în coadă este mică, deci SE este mare
 - ▶ $\sigma = 1,2\%$, $n = 500$: SE pentru $\text{VaR}_{1\%} = 0,20$ puncte procentuale (pp) sub distribuția Normală, 0,43 pp sub o t_4 cu același σ
- ▣ t_4 : distribuția Student- t cu 4 grade de libertate

Erori standard pentru VaR și ES (2/2): ES

- ▣ **ES Chen (2008)**: funcția de influență $IF(x) = VaR_\alpha + (x - VaR_\alpha)_+/\alpha - ES_\alpha$, nemărginită în x ; dacă $\mathbb{E}[L^2] < \infty$
 - ▶ $IF(x)$: efectul unei observații suplimentare x asupra estimării; crește nelimitat cu x , deci o singură pierdere extremă poate deplasa ES oricât de mult
 - ▶ $SE(\widehat{ES}_\alpha) \approx \frac{1}{\alpha} \sqrt{\frac{\text{Var}((L - VaR_\alpha)_+)}{n}}$; estimarea VaR nu adaugă niciun termen de ordinul întâi (Rockafellar–Uryasev); Var: dispersia
 - ▶ Pentru cozi de tip Pareto, eroarea **relativă** scade ca $1/\sqrt{n\alpha}$: numărul de observații din coadă determină precizia [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)
- ▣ Volatility clustering [Newey & West \(1987\)](#)
 - ▶ Înlocuim dispersiile cu dispersiile de termen lung (HAC: consistente la heteroscedasticitate și autocorelare) ale lui $1\{L_t > VaR_\alpha\}$ și $(L_t - VaR_\alpha)_+$
 - ▶ Sau folosim un bootstrap pe blocuri; derivările sînt în [▶ Anexă](#)

Precizia pentru S&P 500 (1/2)



Precizia pentru S&P 500 (2/2)

- Intervale de 95%, lățimea în pp lângă fiecare bară; bootstrap: 2 000 de reeșantionări (Seminarul 7, B6); tabelul complet în [▶ Anexă](#)
- Selecția completă: volatility clustering lărgeste intervalul ES de la 0,60 (i.i.d.) la 1,00 (HAC), la fel ca bootstrap-ul (0,62 i.i.d., 1,16 pe blocuri); ultimele 500 de zile: ES 2,5% este media a 13 pierderi, lățimea intervalului HAC 2,55 pp
- Aceste intervale privesc VaR și ES **necondiționate**; riscul de mâine este o întrebare condiționată (secțiunea următoare)

 MFM_ch7_precision

Simularea istorică filtrată (1/2): modelul

- Ideea Barone-Adesi, Giannopoulos & Vosper (1999), Hull & White (1998): distribuția empirică furnizează **forma** șocurilor, iar modelul GARCH **scala** curentă
 - ▶ $r_t = \mu_t + \sigma_t z_t$, $\mu_t = c + \phi r_{t-1}$, $\sigma_t^2 = \omega + \alpha_1 (r_{t-1} - \mu_{t-1})^2 + \beta_1 \sigma_{t-1}^2$ (Capitolul 5, Bollerslev (1986); α_1 este un coeficient GARCH, nu nivelul α)
- Notățiile
 - ▶ μ_t : media condiționată, un AR(1) în randamentul anterior, cu constanta c și coeficientul ϕ
 - ▶ σ_t : volatilitatea condiționată; z_t : șoc i.i.d. cu media 0 și dispersia 1, cu distribuție nespecificată
 - ▶ $\omega > 0$: constanta; $\alpha_1 \geq 0$: reacția la pătratul surprizei de ieri; $\beta_1 \geq 0$: ponderea dispersiei de ieri; $\alpha_1 + \beta_1 < 1$: persistența, aproape de 1 = șocurile se sting lent

Simularea istorică filtrată (2/2): trei pași

- ▣ Pasul 1: estimăm modelul AR(1)-GARCH(1,1) prin cvasi-verosimilitate maximă (verosimilitate Normală, robustă la alte distribuții ale șocurilor)
- ▣ Pasul 2: reziduuri standardizate $\hat{z}_t = (r_t - \hat{\mu}_t) / \hat{\sigma}_t$: aproximativ i.i.d., dar tot cu cozi grele
- ▣ Pasul 3: rescalăm cu volatilitatea de mîine
 - ▶ $\text{VaR}_{\alpha,t+1} = -\hat{\mu}_{t+1} + \hat{\sigma}_{t+1} \hat{\xi}_{\alpha}$, $\hat{\xi}_{\alpha} = -q_{\alpha}(\hat{z})$; $\text{ES}_{\alpha,t+1} = -\hat{\mu}_{t+1} - \hat{\sigma}_{t+1} \overline{(\hat{z} \mid \hat{z} \leq q_{\alpha}(\hat{z}))}$
 - ▶ $\hat{\mu}_{t+1}$, $\hat{\sigma}_{t+1}$: prognozele modelului pentru mîine; $\hat{\xi}_{\alpha}$: cuantila empirică de ordin α a reziduurilor, cu semn schimbat
 - ▶ $\overline{(\hat{z} \mid \hat{z} \leq q_{\alpha}(\hat{z}))}$: media reziduurilor mai mici sau egale cu acea cuantilă


Exemplu numeric: prognoza pentru S&P 500 în următoarea zi de tranzacționare

- ▣ AR(1)-GARCH(1,1) pe 2000–2026: $\hat{\phi} = -0,053$, $\hat{\alpha}_1 = 0,120$, $\hat{\beta}_1 = 0,860$; persistența $\hat{\alpha}_1 + \hat{\beta}_1 = 0,981$
 - ▶ Prognozele pentru prima zi de tranzacționare de după 18 septembrie 2026: $\hat{\mu}_{t+1} = 0,056\%$, $\hat{\sigma}_{t+1} = 0,725\%$ (abaterea standard de selecție 1,21%: o piață calmă)
- ▣ Cuantila reziduurilor $\hat{\xi}_{1\%} = -q_{1\%}(\hat{z}) = 2,79$, peste $-z_{1\%} = 2,326$: șocurile filtrate păstrează cozi grele
 - ▶ $\text{VaR}_{1\%,t+1} = -0,056 + 0,725 \times 2,791 = 1,97\%$; $\text{ES}_{1\%,t+1} = 2,55\%$
- ▣ VaR 1% istoric necondiționat: 3,45%; estimările condiționate urmăresc evoluția pieței, cea necondiționată nu
- ▣ Alternative pentru aceeași zi: EVT condiționată 2,03%, GARCH cu șocuri Normale 1,63%; toate cele cinci active în [▶ Anexă](#)

Incertitudinea prognozei VaR pentru ziua următoare


- Două intrări estimate: parametrii GARCH θ (prin $\hat{\sigma}_{t+1}$) și cuantila reziduurilor $\hat{\xi}_\alpha$ [Francq & Zakoïan \(2015\)](#)
 - ▶ Bootstrap pe reziduuri [Christoffersen & Gonçalves \(2005\)](#): simulăm traiectorii AR(1)-GARCH(1,1) cu $\hat{\sigma}$ reeșantionate, re-estimăm pe fiecare traiectorie și prognozăm din istoria **originală** (algoritmul în [▶ Anexă](#))
- S&P 500, 999 de traiectorii: $\text{VaR}_{1\%} \text{ FHS} = 1,97\%$, interval de 90% [1,90; 2,09]%
- Cele două surse: $\hat{\sigma}_{t+1} = 0,725$ [0,708; 0,743]; $\hat{\xi}_{1\%} = 2,79$ [2,68; 2,88]
 - ▶ Dacă variază doar cuantila: [1,89; 2,03]; dacă variază doar σ_{t+1} : [1,92; 2,02]; cuantila reziduurilor (circa 67 de reziduuri în coadă) este sursa principală de incertitudine
- EVT condiționată (2,03%) se află în interval, GARCH cu șocuri Normale (1,63%) mult sub el: alegerea modelului pentru coadă contează mai mult decât eroarea de estimare a unui model dat

Simularea istorică și simularea istorică filtrată: S&P 500



- VaR_{1%} prognozat pentru ziua următoare; GARCH re-estimat în fiecare ianuarie pe toate datele anterioare, deci fiecare prognoză folosește doar informația disponibilă la momentul ei
- Zile cu pierdere peste VaR 1%, 2006–2026 (5 210 zile; ținta 1%): istoric pe 500 de zile 1,67%, filtrat 1,54%, GARCH cu șocuri Normale 2,34%
- Depășirile VaR istoric apar în **grupuri** (2008, 2020): fereastra reacționează cu luni de întârziere; VaR filtrat a atins 18,01% pe 2020-03-18 și distribuie depășirile mai uniform în timp (teste în [Capitolul 8](#))

Simularea istorică și simularea istorică filtrată: Bitcoin




- Aceași construcție, prognoze din ianuarie 2017, 7 zile pe săptămână; zile cu pierderi peste VaR (3 548 de zile): istoric 1,16%, filtrat 0,76%, GARCH cu șocuri Normale 1,58%
- Volatilitatea a scăzut după 2022, iar estimarea pe fereastra de 500 de zile se ajustează cu mare întârziere; criptoactivele ca o clasă distinctă de active: [Pele et al. \(2023\)](#)
- VaR filtrat a atins 54,83% în martie 2020, după crahul din 2020-03-12: o pierdere log de 46,47%, adică o scădere a prețului de 37,17% (pierderile log și simple diferă la mișcări mari)

Modelarea directă a cuantilei: CAViaR

- ▣ CAViaR (Conditional Autoregressive Value at Risk, valoarea la risc condițională autoregresivă) Engle & Manganelli (2004): cuantila urmează propria recursie; specificația SAV
 - ▶ $\text{VaR}_t = \beta_0 + \beta_1 \text{VaR}_{t-1} + \beta_2 |r_{t-1}|$, $q_t = -\text{VaR}_t$
 - ▶ SAV (symmetric absolute value, valoarea absolută simetrică): VaR de azi = o constantă β_0 + o fracțiune $\beta_1 \in (0, 1)$ din VaR de ieri (persistența) + $\beta_2 > 0$ ori randamentul absolut de ieri
 - ▶ O mișcare mare, în orice sens, crește VaR; q_t : cuantila randamentului
- ▣ Regresie cuantilă Koenker & Bassett (1978): minimizăm pierderea pinball, fără ipoteze asupra distribuției șocurilor
 - ▶ $\hat{\beta} = \arg \min_{\beta} \sum_t (\alpha - 1\{r_t < q_t(\beta)\})(r_t - q_t(\beta))$
 - ▶ $\arg \min_{\beta}$: valoarea lui $\beta = (\beta_0, \beta_1, \beta_2)$ care minimizează suma; $q_t(\beta)$: traiectoria cuantilei dată de β ; elicibilitatea este folosită direct în estimare (setările optimizării în [Anexă](#))
- ▣ S&P 500, $\alpha = 1\%$, estimat pe 2000–2015 (4 024 de zile): $\hat{\beta}_0 = 0,090$, $\hat{\beta}_1 = 0,897$, $\hat{\beta}_2 = 0,246$
 - ▶ Timpul de înjumătățire al unui șoc asupra VaR: $\ln 0,5 / \ln \hat{\beta}_1 = 6,4$ zile
- ▣ CAViaR reacționează liniar la $|r_{t-1}|$, GARCH la r_{t-1}^2

CAViaR față de simularea istorică filtrată în afara eșantionului



- S&P 500, 2016–2026 (2 693 de zile): CAViaR cu parametrii fixați pe 2000–2015; FHS re-estimat în fiecare ianuarie (o schemă diferită de re-estimare)
- Depășiri ale VaR 1%: CAViaR 1,30% (35), FHS 1,30% (35), istoric pe 500 de zile 1,41% (38); pierderea pinball medie (mai mică e preferabilă): 0,039, 0,037, 0,052
- COVID-19, 20 februarie – 30 aprilie 2020 (50 de zile): depășiri 6 / 3 / 9, VaR maxim 13,5% / 18,0% / 4,5%: după un crah, VaR FHS crește cel mai mult
- Numărul de depășiri nu este suficient pentru a ierarhiza modelele: semnificația se testează în [Capitolul 8](#)


Maxime pe blocuri și distribuția GEV (1/2)

- Împărțim selecția în blocuri de n zile; păstrăm maximul fiecărui bloc $M_n = \max(L_1, \dots, L_n)$
 - ▶ Teorema Fisher–Tippett–Gnedenko [Fisher & Tippett \(1928\)](#), [Gnedenko \(1943\)](#): dacă $(M_n - b_n)/a_n$ are o limită nedegenerată pentru pierderi i.i.d., aceasta este GEV
 - ▶ $a_n > 0$, b_n : constante de normalizare, care rescalează și recentrează maximul; GEV: distribuția generalizată a valorilor extreme
- Funcția de repartiție GEV: probabilitatea ca maximul unui bloc să fie cel mult x
 - ▶ $H_\xi(x) = \exp \left\{ - \left(1 + \xi \frac{x-\mu}{\sigma} \right)^{-1/\xi} \right\}$, $1 + \xi(x - \mu)/\sigma > 0$ ($\xi = 0$: $\exp\{-e^{-(x-\mu)/\sigma}\}$)
 - ▶ μ : poziția (unde se află maximele); $\sigma > 0$: scala (dispersia lor); ξ : forma (tipul cozii, slide-ul următor)

Maxime pe blocuri și distribuția GEV (2/2)

- **Forma** ξ determină tipul cozii
 - ▶ $\xi > 0$: Fréchet, coadă de tip putere cu tail index-ul $1/\xi$ (randamentele financiare)
 - ▶ $\xi = 0$: domeniul Gumbel, cozi de tip exponențial (de ex. distribuția Normală, distribuția lognormală); $\xi < 0$: Weibull, coadă mărginită
- **Nivelul de revenire** pentru k blocuri: nivelul depășit în medie o dată la k blocuri, $H_\xi^{-1}(1 - 1/k)$, cu H_ξ^{-1} funcția cuantilă a GEV
- În finanțe modelăm **doar coada** Embrechts, Klüppelberg & Mikosch (1997), Longin (2000)

Maximele lunare ale pierderilor S&P 500



- 321 de luni calendaristice, 2000–2026; GEV prin verosimilitate maximă
- $\hat{\xi} = 0,22$ (Fréchet), $\hat{\mu} = 1,37$, $\hat{\sigma} = 0,79$: o coadă de tip putere
- Niveluri de revenire: 10 ani 8,09%, 30 de ani 10,95%; cel mai mare maxim lunar 12,77%
- Maximele lunare nu dau direct un VaR zilnic: conversia presupune zile independente, ipoteză încălcată de volatility clustering (▶ Anexă)
- Reținerea unei singure valori pe lună irosește informație: metoda următoare folosește toate pierderile mari

Depășiri de prag și distribuția GPD (1/2)

- Fixăm un prag ridicat u ; modelăm **excesele** $Y = L - u$, condiționat de $L > u$
 - ▶ Teorema Pickands–Balkema–de Haan [Pickands \(1975\)](#), [Balkema & de Haan \(1974\)](#): pentru o clasă largă de distribuții, când u se apropie de capătul drept al distribuției, excesele urmează o distribuție Pareto generalizată
- Funcția de repartiție GPD: probabilitatea ca un exces să fie cel mult y
 - ▶ $G_{\xi, \beta}(y) = 1 - (1 + \xi y / \beta)^{-1/\xi}$ ($\xi \neq 0$), $1 - e^{-y/\beta}$ ($\xi = 0$)
 - ▶ $y \geq 0$ și $y < -\beta/\xi$ dacă $\xi < 0$; scala $\beta > 0$: mărimea tipică a unui exces; forma ξ : aceeași ca la GEV, $\xi > 0$ = coadă grea

Depășiri de prag și distribuția GPD (2/2)

- Estimatorul cozii cu N_u depășiri din n observații [McNeil, Frey & Embrechts \(2015\)](#)

$$\blacktriangleright \widehat{\text{VaR}}_\alpha = u + \frac{\hat{\beta}}{\hat{\xi}} \left[\left(\frac{n}{N_u} \alpha \right)^{-\hat{\xi}} - 1 \right], \quad \widehat{\text{ES}}_\alpha = \frac{\widehat{\text{VaR}}_\alpha}{1 - \hat{\xi}} + \frac{\hat{\beta} - \hat{\xi}u}{1 - \hat{\xi}} \quad (\alpha < N_u/n, \hat{\xi} \neq 0; \text{ES cere } \hat{\xi} < 1)$$


- În cuvinte: VaR este pragul u plus cuantila GPD a excesului care lasă probabilitatea α în coadă; N_u/n este proporția zilelor peste u
- ES adaugă la VaR excesul mediu de dincolo de VaR, care crește cu $\hat{\xi}$; $\hat{\xi} \geq 1$ înseamnă medie infinită

- Compromis deplasare–dispersie: un u mic încalcă teorema limită, un u mare lasă puține depășiri

Alegerea pragului: funcția de exces mediu

- **Funcția de exces mediu:** $e(u) = \mathbb{E}[L - u \mid L > u]$; empiric, media exceselor peste u , reprezentată în funcție de u
- Pentru o coadă GPD, $e(u)$ este **liniară** în u
 - ▶ $e(u) = \frac{\beta + \xi(u - u_0)}{1 - \xi}$ pentru $u \geq u_0$, finită doar dacă $\xi < 1$; panta $\xi/(1 - \xi)$ este pozitivă pentru cozi grele și nulă pentru cozi exponențiale
 - ▶ u_0 : cel mai mic prag peste care este valabilă GPD; β : scala GPD în u_0
- Regula practică: alegem u acolo unde graficul devine aproximativ liniar; verificăm stabilitatea lui $\hat{\xi}$ pentru mai multe praguri
- Estimatorul Hill din [Capitolul 1 Hill \(1975\)](#) estimează același tail index $1/\xi$



Graficul excesului mediu: S&P 500



- Empirical mean excess $e(u)$
- GPD implied: $(\beta + \xi(u - u_0)) / (1 - \xi)$
- Threshold $u_0 = 1.85\%$ (top 5% of losses above it)

- Praguri depășite de 20% pînă la 0,5% dintre pierderile zilnice; linia roșie: GPD estimată pe cele mai mari 5%
- Excesul mediu crește cu u : o coadă grea (de tip Fréchet), nu linia orizontală a unei cozi exponențiale
- Pragul ales $u_0 = 1,85\%$ lasă $N_u = 336$ depășiri; excesul mediu 1,09%, panta GPD $\hat{\xi}/(1 - \hat{\xi}) = 0,23$
- Dincolo de VaR 1% punctele au o dispersie mare: fiecare este media a foarte puține pierderi

Cozi GPD: S&P 500 și Bitcoin (1/2)



Cozi GPD: S&P 500 și Bitcoin (2/2)

- ▣ Scală log-log: probabilitatea unei pierderi zilnice peste x , cele mai mari 5% dintre pierderi; coada Normală cade mult sub date, coada Student- t este apropiată de GPD
- ▣ S&P 500: $\hat{\xi} = 0,19$ (SE 0,065), tail index-ul 5,3, $\text{VaR}_{1\%} = 3,54\%$; Bitcoin: $\hat{\xi} = 0,16$ (SE 0,078), $\text{VaR}_{1\%} = 10,23\%$; toate cele cinci serii în [▶ Anexă](#)
- ▣ $\text{SE}(\hat{\xi}) = (1 + \hat{\xi})/\sqrt{N_u}$ presupune depășiri independente; gruparea depășirilor în timp o subestimează (slide-ul următor)

 MFM_ch7_gpd_tail


Extreme grupate: indicele extremal

- Pierderi staționare cu extreme grupate: dacă $nP(L > u_n) \rightarrow \tau$, atunci $P(M_n \leq u_n) \rightarrow e^{-\theta\tau}$, $\theta \in (0, 1]$
[Embrechts, Klüppelberg & Mikosch \(1997\)](#)
 - ▶ u_n : un prag care crește cu n ; τ : numărul așteptat de depășiri ale lui u_n în n zile; M_n : maximul celor n pierderi
 - ▶ θ = indicele extremal, $1/\theta$ = mărimea medie a unui grup; date i.i.d.: $\theta = 1$; n zile dependente se comportă ca $n\theta$ zile independente
- S&P 500, pragul GPD $u = 1,85\%$ ($N = 336$ depășiri): estimatorul pe intervale [Ferro & Segers \(2003\)](#) dă $\hat{\theta} = 0,19$, adică 62 de grupuri de câte 5,4 depășiri în medie
 - ▶ GPD pe maximele grupurilor: $\hat{\xi} = 0,152$ (SE 0,146) față de 0,188 (SE 0,065) pe toate depășirile: tot pozitiv, dar intervalul lui de 95% include acum 0
- Reziduurile GARCH standardizate: $\hat{\theta} = 0,99$: filtrarea GARCH elimină gruparea; de aceea, EVT condiționată estimează GPD pe reziduurile filtrate
- Estimatorul, regula de separare a grupurilor (declustering) și corecția pentru maximele pe blocuri: [▶ Anexă](#)

EVT condiționată (McNeil și Frey)

- ▣ McNeil & Frey (2000): aceiași pași ca la FHS, cu un singur pas schimbat
- ▣ Filtrul: AR(1)-GARCH(1,1) prin cvasi-verosimilitate maximă, reziduuri $\hat{z}_t$, prognoze $\hat{\mu}_{t+1}$, $\hat{\sigma}_{t+1}$ (ca la FHS)
- ▣ **Pasul cozii:** în locul cuantilei empirice a lui $-\hat{z}$, estimăm o GPD pe cele mai mari 10% valori și luăm VaR-ul ei $\hat{z}_\alpha^{GPD}$ și $ES \hat{e}_\alpha^{GPD}$
 - ▶ $VaR_{\alpha,t+1} = -\hat{\mu}_{t+1} + \hat{\sigma}_{t+1}\hat{z}_\alpha^{GPD}$, $ES_{\alpha,t+1} = -\hat{\mu}_{t+1} + \hat{\sigma}_{t+1}\hat{e}_\alpha^{GPD}$
- ▣ O coadă parametrică netedă, extrapolată dincolo de date: avantajul apare mai ales în extremitatea cozii (VaR 0,5%, VaR 0,1%), unde există doar câteva reziduuri

EVT condiționată pentru S&P 500



- $\text{VaR}_{1\%}$ prognozat pentru ziua următoare, 2018–2026, parametri re-estimați în fiecare ianuarie; depășiri (2 190 de zile; ținta 1%): EVT condiționată 1,23%, GARCH cu șocuri Normale 2,42%, istoric pe 500 de zile 1,60%

- GARCH–Normal surprinde corect **momentul**, dar are un **nivel** greșit; EVT condiționată păstrează momentul și corectează nivelul: contează coada șocurilor, nu doar scala lor



Regula rădăcinii pătrate a timpului: ipoteze și limite

- Pierderi zilnice i.i.d. $N(0, \sigma^2)$: $\text{VaR}_\alpha^{(h)} = \sqrt{h} \text{VaR}_\alpha^{(1)}$, $\text{ES}_\alpha^{(h)} = \sqrt{h} \text{ES}_\alpha^{(1)}$; Basel 1996 a permis $\sqrt{10} = 3,162$ [Basel Committee \(1996\)](#)
 - ▶ $\text{VaR}_\alpha^{(h)}$, $\text{ES}_\alpha^{(h)}$: măsurile pentru pierderea însumată pe h zile; abaterea standard a unei sume de h termeni i.i.d. crește ca $\sqrt{h}$
 - ▶ Cere medie zero, fără autocorelație, volatilitate constantă și șocuri Normale; fiecare ipoteză este încălcată de date ([Capitolele 1, 2, 5](#))
- **Autocorelația** (raportul dispersiilor, [Capitolul 2](#))
 - ▶ $\text{Var}(r_{t+1} + \dots + r_{t+h}) = h\sigma^2 \text{VR}(h)$, cu $\text{VR}(h)$ dispersia sumei pe h zile împărțită la h ori dispersia zilnică
 - ▶ $\text{VR} = 1$ fără autocorelație; $\text{VR} > 1$ cu autocorelație pozitivă, iar atunci $\sqrt{h}$ **subestimează** riscul pe h zile
- **Volatility clustering**: volatilitatea revine la medie pe h zile
 - ▶ Volatilitate scăzută azi $\Rightarrow \sqrt{h}$ prea mic; volatilitate ridicată azi $\Rightarrow$ prea mare
- **Cozi grele**: pentru șocuri i.i.d. cu tail index $a > 2$, cuantila extremă a unei sume crește ca $h^{1/a} < \sqrt{h}$ [Dánielsson \(2011\)](#)
 - ▶ a : tail index, $P(L > x)$ scade ca x^{-a} ; a mai mic = coadă mai grea
 - ▶ Cu salturi, regula poate evalua foarte greșit riscul pe mai multe zile [Dánielsson & Zigrand \(2006\)](#)

Monte Carlo filtrat pe h zile

- ▣ Simulăm multe traiectorii viitoare din modelul estimat și citim VaR și ES din pierderile simulate: tratează deodată toate cele trei probleme, precum și câștigurile neliniare (opțiuni)
- ▣ Pentru fiecare traiectorie $j = 1, \dots, M$ (M : numărul de traiectorii simulate)
 - ▶ extragem $z_{t+1}^{(j)}, \dots, z_{t+h}^{(j)}$ cu revenire din reziduurile standardizate $\hat{z}$
 - ▶ actualizăm $\sigma^{(j)}$ și $r^{(j)}$ zi de zi cu recursia AR(1)-GARCH(1,1), pornind de la starea de azi
 - ▶ agregăm: $L^{(j)} = -\sum_{i=1}^h r_{t+i}^{(j)}$, pierderea pe h zile a traiectoriei j (i : ziua din traiectorie)
- ▣ $\widehat{\text{VaR}}_\alpha, \widehat{\text{ES}}_\alpha$ = estimările istorice pe cele M pierderi simulate; eroarea de simulare scade ca $1/\sqrt{M}$

Regula rădăcinii pătrate în date (1/2)



Regula rădăcinii pătrate în date (2/2)

- Stînga: $\text{VaR}_{1\%}$ empiric al pierderilor suprapuse pe h zile, împărțit la $\sqrt{h}$ ori valoarea pe o zi (sume suprapuse: mult mai puține observații independente); dreapta: Monte Carlo filtrat, 200 000 de traiectorii
- Raportul la $h = 10$: BET 1,22 (autocorelația de ordin 1 0,109) și EUR/RON 1,05: $\sqrt{h}$ prea mic; S&P 500 0,95, aur 0,92, Bitcoin 0,89: regula este conservatoare
- $\text{VaR}_{1\%}$ pe 10 zile pentru S&P 500: Monte Carlo filtrat 6,29%, $\sqrt{10} \times \text{VaR}$ filtrat pe o zi 6,22%, $\sqrt{10} \times \text{VaR}$ istoric pe o zi 10,92%: diferența mare vine din trecerea de la necondiționat la condiționat


VaR de portofoliu și alocarea Euler (1/2)

- ▣ Cadrul: pierderea portofoliului $L_p = -w^\top R$
 - ▶ w : vectorul ponderilor; R : vectorul randamentelor simple (randamentele simple se adună între active), cu matricea de covarianță Σ ; σ_i : abaterea standard a activului i
- ▣ Randamente cu distribuție Normală, neglijînd media: VaR este un multiplu al abaterii standard a portofoliului
 - ▶ $\text{VaR}_\alpha(L_p) = z_{1-\alpha}\sigma_p$, $\sigma_p = \sqrt{w^\top \Sigma w}$; $z_{1-\alpha} = -z_\alpha > 0$
 - ▶ Pentru ponderi nenegative $w \geq 0$, VaR nediversificat $\sum_i z_{1-\alpha} w_i \sigma_i$ (suma VaR-urilor individuale) este mai mare, cu excepția corelațiilor egale cu 1

VaR de portofoliu și alocarea Euler (2/2)

- ▣ **VaR marginal:** variația VaR al portofoliului la o creștere cu o unitate a ponderii w_i
 - ▶ $\partial \text{VaR}_\alpha / \partial w_i = z_{1-\alpha}(\Sigma w)_i / \sigma_p$; $(\Sigma w)_i$: covarianța activului i cu portofoliul
- ▣ **VaR pe componente** $C_i = w_i \partial \text{VaR}_\alpha / \partial w_i$: partea din VaR atribuită activului i
 - ▶ Teorema lui Euler pentru o funcție omogenă de grad 1: $\sum_i w_i \partial \rho / \partial w_i = \rho$, deci componentele se adună, $\sum_i C_i = \text{VaR}_\alpha$ Tasche (2008)
- ▣ ES, fără ipoteză de distribuție (pierderi continue): pierderea medie a activului i în zilele din coada portofoliului
 - ▶ $C_i^{ES} = \mathbb{E}[-w_i R_i \mid L_p \geq \text{VaR}_\alpha(L_p)]$, $\sum_i C_i^{ES} = \text{ES}_\alpha(L_p)$
 - ▶ Estimarea istorică: media pe zilele din coadă; un C_i negativ înseamnă că activul **acoperă** riscul portofoliului

Contribuțiile activelor la risc



□ SPY (ETF pe S&P 500) 40%, TLT (ETF pe obligațiuni de stat americane pe termen lung) 30%, GLD (ETF pe aur) 20%, Bitcoin 10%, rebalansare zilnică; randamente simple în 3 017 zile comune, 2014–2026; turcoaz: ponderi, albastru: cote din $VaR_{1\%}$ Normal, roșu: cote din $ES_{2,5\%}$ istoric

□ $VaR_{1\%} = 1,77\%$ față de $3,11\%$ nediversificat (-43%); $ES_{2,5\%} = 2,15\%$ față de $3,87\%$ (-44%)

□ Bitcoin: 10% din capitalul investit, 37,8% din VaR și 36,6% din ES; TLT: 30% din capital, doar 6,5% din ES (a pierdut 0,47% în zilele cele mai rele ale portofoliului)

Portofoliul cu ES minim: o problemă de programare liniară

- Cu N scenarii istorice R_s , funcția Rockafellar–Uryasev devine o problemă de **programare liniară** Rockafellar & Uryasev (2000)
 - ▶ $\min_{w,v,u} v + \frac{1}{\alpha N} \sum_s u_s$ cu restricțiile $u_s \geq -w^\top R_s - v$, $u_s \geq 0$, $\sum_i w_i = 1$, $w \geq 0$
 - ▶ $s = 1, \dots, N$: scenariile; u_s : o variabilă auxiliară egală, la optim, cu excesul $(-w^\top R_s - v)_+$ al scenariului s peste pragul v ; v optim este VaR al portofoliului
 - ▶ Restricții: capital investit integral ($\sum_i w_i = 1$), fără vânzări în lipsă ($w \geq 0$)
- Aceleași patru active, 3017 zile comune, $\alpha = 2,5\%$: ponderi 31% / 44% / 25% / 0%
 - ▶ $ES_{2,5\%} = 1,67\%$, față de 2,15% pentru portofoliul 40/30/20/10
- Dispersie minimă fără vânzări în lipsă: 35% / 43% / 22% / 0%, $ES_{2,5\%} = 1,67\%$: pentru aceste active cele două criterii aproape coincid; ele diverg pentru opțiuni și credit
- Mai multe portofolii pot atinge același minim: raportăm soluția împreună cu scenariile ei din coadă

VaR ajustat la lichiditate


- VaR presupune că pozițiile pot fi vândute la prețul mediu; în realitate, lichidarea costă jumătate din diferența dintre prețul cerut și cel oferit (spread)
 - ▶ **Spread relativ** $S = (\text{ask} - \text{bid}) / \text{mid}$; se lărgeste tocmai în perioadele de scădere a pieței
- Bangia, Diebold, Schuermann & Stroughair (2001): $\text{LVaR}_\alpha = \text{VaR}_\alpha + \frac{1}{2}(\mu_S + a \sigma_S)$
 - ▶ μ_S, σ_S : media și abaterea standard a spread-ului; a : un multiplicator (aici S este spread-ul, nu asimetria)
 - ▶ VaR plus costul traversării unei jumătăți din spread-ul în condiții de stres, cu a abateri standard peste media lui
- Banca Transilvania, 1 milion RON, ultimii doi ani: $\text{VaR}_{1\%} = 3,16\%$; cu $\mu_S = 0,5\%$, $\sigma_S = 0,3\%$, $a = 3$ presupuse: $\text{LVaR} = 3,86\%$ (+22%)
- Pozițiile mari influențează și prețul (lichiditate endogenă): reglementarea tratează acest lucru prin orizonturi mai lungi

De la Basel 1996 la FRTB (2019)

	Basel 1996 Basel Committee (1996)	FRTB 2019 Basel Committee (2019)
Măsura de risc	VaR 1%, calculat zilnic	ES 2,5%, calculat zilnic pentru fiecare birou de tranzacționare
Orizontul	10 zile; scalarea cu $\sqrt{10}$ permisă	bază de 10 zile, scalată prin orizonturi de lichiditate (acțiuni cu capitalizare mare 10, mică 20, spread-uri de credit pînă la 120 de zile)
Datele	cel puțin un an de istorie	calibrat pe cea mai severă perioadă de stres de 12 luni
Capitalul	$\max(\text{VaR de ieri, multiplicator} \geq 3 \times \text{media VaR pe 60 de zile})$; multiplicatorul crește cu 0–1 după rezultate slabe la backtesting (zonele semafor, Capitolul 8)	multiplicator $m_c = 1,5$, crescut după rezultate slabe la backtesting
Backtesting	excepțiile VaR 1% (Capitolul 8)	VaR 1% și VaR 2,5% pe o zi: VaR se testează, ES stabilește capitalul

- Critica de după 2008: VaR ignoră mărimea pierderilor din coadă, iar ferestrele de un an exclud crizele mai vechi; în UE, cerințele de fonduri proprii FRTB se aplică de la 1 ianuarie 2027 [Delegated Regulation \(EU\) 2025/1496](#)

VaR 1% față de ES 2,5% pe cinci active



- Simulare istorică, pierderi zilnice, selecțiile complete; numărul de deasupra fiecărei perechi: $ES_{2,5\%}/VaR_{1\%}$
- Reperul Normal: $2,338/2,326 \approx 1,005$, același capital pentru cozi subțiri; Student- t : 1,01 la $\nu = 30$, 1,07 la $\nu = 4$
- Date: S&P 500 1,09, BET 1,11, Bitcoin 1,03, EUR/RON 1,10, aur 1,06: trecerea de la VaR 1% la ES 2,5% crește măsura pe o zi cu 3–11%
- Atenție: $ES_{\alpha} \geq VaR_{\alpha}$ este valabilă la **același** α ; între niveluri diferite, cozile grele nu o garantează prin ele însele
- Calibrarea pe perioada de stres și orizonturile de lichiditate au un efect mai mare: Seminarul 7, C1


Studiu de caz (1/4): întrebarea și datele

- ▣ **Întrebarea** Chronopoulos, Raftapostolos & Kapetanios (2024) (*Journal of Financial Econometrics*)
 - ▶ Poate o rețea neuronală adâncă să îmbunătățească prognoza VaR învățând o relație **neliniară, cu formă necunoscută**, între cuantila condiționată și predictorii?
- ▣ Date (Secțiunea 3 a articolului): randamentele log zilnice ale S&P 500, septembrie 1985 – august 2020; $\alpha = 1\%, 5\%, 10\%$
 - ▶ Predictorii x_t : volatilitatea GARCH sau RiskMetrics, variabilele de stare CAViaR
 - ▶ Ultimele 2 000 de zile în afara eșantionului, o singură fereastră fixă de calibrare; detaliile în [▶ Anexă](#)
- ▣ Reperul: regresia cuantilă liniară Koenker & Bassett (1978) pe aceiași predictorii
 - ▶ adică liniaritatea de tip CAViaR (secțiunea „VaR și ES condiționate”)

Studiu de caz (2/4): modelul

- ▣ Modelul (Ec. 5–10): cuantila condiționată a randamentului este o rețea neuronală a predictorilor
 - ▶ $Q_{r_t}(\alpha \mid x_t) \approx G_\alpha(x_t, w)$
 - ▶ $Q_{r_t}(\alpha \mid x_t)$: cuantila de ordin α a lui r_t , dat fiind x_t ; G_α : o rețea cu propagare înainte (feed-forward), cu straturi ascunse ReLU ($\max(\cdot, 0)$); w : ponderile ei
- ▣ Estimarea: minimizăm pierderea pinball plus o penalizare a lui w (niciuna, LASSO, ridge sau elastic net); w^* : ponderile estimate
- ▣ Ținta: cuantila randamentului zilnic peste 10 zile (Ec. 23)
 - ▶ $\widehat{\text{VaR}}_{t+10|\mathcal{F}_t} = -G_\alpha(x_t, w^*)$; $\mathcal{F}_t$: informația disponibilă în ziua t
- ▣ Evaluarea: RMSFE (rădăcina erorii pătratice medii de prognoză) relativă la reper; sub 1 = eroare mai mică decât regresia cuantilă liniară
 - ▶ Semnificația: testul Diebold–Mariano (DM) al preciziei egale a prognozelor

Studiu de caz (3/4): erorile relative, $\alpha = 1\%$



Studiu de caz (4/4): erorile relative, $\alpha = 1\%$

- Chronopoulos, Raftapostolos & Kapetanios (2024), Tabelul 6: RMSFE relativ la regresia cuantilă liniară (linia întreruptă = 1), scară logaritmică; S&P 500, ultimele 2 000 de zile pînă în august 2020
- Modelele flexibile fără rețele: 7 din 12 bare la 1 sau peste; toate cele 16 bare ale rețelelor adînci și cele 4 ale MIDAS adînc sub 1 (0,014–0,850), toate semnificative în testul DM, cu excepția MIDAS adînc pentru SAV
- Atenție: RMSFE este minimizată de **media** condiționată, nu de cuantilă; precizia cuantilelor cere pierderea pinball
- O singură fereastră fixă de calibrare: rămîne de văzut dacă o reducere de 98% se păstrează la reestimarea pe fereastră mobilă (Seminarul 7, C3)

 MFM_ch7_crk_table6

O întrebare deschisă și verificările necesare (1/2)


- Pot datele zilnice ordona modelele concurente (VaR 1%, ES 1%)? [Nolde & Ziegel \(2017\)](#), [Patton, Ziegel & Chen \(2019\)](#), [Bayer & Dimitriadis \(2022\)](#), [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)
 - Dificultăți: ES singur nu este elicitable, iar doar circa 1% din zile sînt informative
- Scorul FZ0: o penalizare comună pentru o prognoză (VaR, ES), dat fiind randamentul realizat; o valoare mai mică este mai bună [Patton, Ziegel & Chen \(2019\)](#)
 - $S(v, e; Y) = -\frac{1}{\alpha e} 1\{Y \leq v\}(v - Y) + \frac{v}{e} + \ln(-e) - 1$
 - Y : randamentul realizat; $v_t = -\text{VaR}_{\alpha,t}$ și $e_t = -\text{ES}_{\alpha,t}$: cuantila și media cozii prognozate, ambele negative; primul termen penalizează randamentele sub v
- Testul: $d_t = S_t^A - S_t^B$, diferența zilnică dintre scorurile modelelor A și B
 - $H_0: \mathbb{E}[d_t] = 0$ (precizie egală) față de $H_1: \mathbb{E}[d_t] \neq 0$; statistica t Diebold–Mariano cu erori HAC, aproximativ $N(0, 1)$ sub H_0 ; $t < -1,96$: A semnificativ mai bun la 5%
 - Cîte un interval pentru fiecare subperioadă pre-înregistrată

O întrebare deschisă și verificările necesare (2/2)

- ▣ Un asistent AI poate schița harta literaturii, codul și un raport de referent; cercetătorul verifică
 - ▶ semnul și nivelul: $\text{VaR } 1\% = -q_{1\%}$, pozitiv pentru o pierdere (recalculăm FZ0 pentru o zi, pas cu pas)
 - ▶ look-ahead bias: fiecare prognoză folosește doar date de dinaintea zilei ei
 - ▶ scorul: doar scoruri comune (VaR, ES), niciodată MSE (eroarea pătratică medie) pentru ES singur [Gneiting \(2011\)](#)
 - ▶ puterea: numărăm zilele din coadă
 - ▶ fiecare DOI (Digital Object Identifier, identificatorul digital al articolului) verificat; prompturile reutilizabile în

▶ Anexă

Mini-studiu de caz: ordonarea modelelor ES (1/2)



Mini-studiu de caz: ordonarea modelelor ES (2/2)

- Afirmația testată: „EVT condiționată este cel mai bun model (VaR 1%, ES 1%) pentru S&P 500”; replicăm întâi: rata de depășire FHS 1,54% (80 din 5 210 zile, 2006–2026)
- FZ0 mediu (o valoare mai mică indică un model mai bun): EVT condiționată 1,267, FHS 1,283, GARCH–Normal 1,453; bare: intervale HAC de 95% pentru $\mathbb{E}[d_t]$
- Forma șocurilor contează, iar rezultatul este robust: șocurile Normale pierd în ambele jumătăți ($t = -3,24, -3,38$)
- Câștigul EVT față de FHS este de zece ori mai mic și nesemnificativ în 2016–2026 ($[-0,018; 0,004]$): câștigul nu este demonstrat, dar nici echivalența celor două modele nu este dovedită

 MFM_ch7_ai_discovery_case

Punct de plecare pentru proiectul de echipă

- ▣ Întrebarea: oferă un model semiparametric dinamic (VaR, ES) [Patton, Ziegel & Chen \(2019\)](#) prognoze mai bune decât FHS și EVT condiționată la ES 2,5%, în afara eșantionului?
 - ▶ Piețe: S&P 500, BET și Bitcoin
- ▣ Replicăm întâi: VaR 1% FHS pentru S&P 500 de 1,97% și ordonarea FZ0 din mini-studiul de caz
- ▣ Livrabile
 - ▶ O pre-înregistrare de o pagină: modele, niveluri, scoruri, subperioade, putere (zile din coadă) și ce ar infirma afirmația
 - ▶ Cod pe datele zilnice de piață ale cursului, un tabel cu toate comparațiile și p-value-urile ajustate, o autocritică în stilul unui referent
- ▣ Notăm prompturile și rezultatele acceptate în `AI_USE.md`, fiecare eroare prinsă (semn inversat, etichetă greșită a nivelului, look-ahead bias, DOI inventat) în `AI_ERRORS.md`; codul: [Quantlet](#)

Alegerea metodei

Situația	Metoda	Eșuează când
Verificare rapidă, istorie lungă și stabilă	Simulare istorică, 500–1 000 de zile	volatilitatea se schimbă; estimarea nu poate depăși cea mai mare pierdere observată
Riscul zilnic după un șoc de volatilitate	FHS sau EVT condiționată, cu interval bootstrap	modelul GARCH este greșit specificat
VaR 0,5% și mai adânc, teste de stres	Depășiri de prag (GPD), condiționate sau nu	prag ales greșit; depășiri grupate
Orizont de mai multe zile, opțiuni	Monte Carlo filtrat	domină riscul de model
Bugetarea riscului pe birouri sau active	Contribuții Euler la ES	fiecare contribuție se bazează pe puține zile din coadă
Capitalul reglementat	ES 2,5%, 10 zile, perioadă de stres, backtesting pe VaR	fereastra de stres este scurtă și zgomotoasă

- Orice VaR sau ES este o estimare: îl raportăm cu numărul de observații din coadă și un interval

Autoevaluare și capitolul următor: Capitolul 8

Întrebări de verificare

- De ce poate VaR recompensa concentrarea?
- De ce nu o poate recompensa ES?
- De ce depinde precizia ES de $n\alpha$ și nu de n ?
- Când este scalarea cu $\sqrt{10}$ prea mică?
- Când este prea mare?

Capitolul 8: backtesting

- Cît de des au depășit pierderile VaR?
- Au fost depășirile independente?
- Testele de acoperire și zonele de tip semafor din Basel
- Compararea prognozelor (VaR, ES) cu scoruri comune Fissler & Ziegel (2016)
- Lecturi suplimentare: Franke, Härdle & Hafner (2019), Härdle, Chen & Overbeck (2017), Čížek, Härdle & Weron (2011), McNeil, Frey & Embrechts (2015)

Anexă: datele folosite în acest capitol

Seria	Tip	Perioada	Zile
S&P 500	indice bursier SUA	2000–2026	6 717
BET	indice bursier BVB	2000–2026	6 670
Bitcoin	cripto-activ, 7 zile din 7	2014–2026	4 384
EUR/RON	cursul de referință BNR	2005–2026	5 352
Aur	USD pe uncie troy, zile lucrătoare	2000–2026	6 956
Portofoliu	SPY, TLT, GLD (ETF-uri) și Bitcoin	2014–2026	3 017
Banca Transilvania	acțiune BVB (exemplul de lichiditate)	2024–2026	496

- ▣ Valori zilnice de închidere pînă la 18 septembrie 2026; randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$
- ▣ Fiecare serie pe propriul calendar; portofoliul folosește zilele în care există toate cele patru prețuri
- ▣ ETF-uri: prețuri ajustate pentru dividende; SPY replică S&P 500, TLT obligațiunile de stat americane pe termen lung, GLD aurul

Anexă: demonstrația reprezentării Rockafellar–Uryasev

- **Demonstrație:** $F(v) = v + \mathbb{E}[(L - v)_+]/\alpha$ este convexă, cu derivata la dreapta (panta imediat la dreapta lui v) $1 - P(L > v)/\alpha$
 - ▶ Este ≥ 0 exact când $P(L > v) \leq \alpha$, adică $v \geq \text{VaR}_\alpha$; $F(\text{VaR}_\alpha)$ este formula ES discretă de pe slide-ul celor două obligațiuni
- **Corolar:** $(w, v) \mapsto v + \mathbb{E}[(-w^\top R - v)_+]/\alpha$ este convexă simultan în ambele argumente; minimizarea în raport cu v păstrează convexitatea
 - ▶ ES este convex în w ; împreună cu omogenitatea pozitivă, aceasta demonstrează subaditivitatea
- Argumentul înfășurătoarei: $\partial F/\partial v = 0$ în $v = \text{VaR}_\alpha$, deci o mică eroare în VaR schimbă minimul doar la ordinul al doilea: de aici eroarea standard a ES fără termen din VaR

Anexă: condiții de subaditivitate pentru VaR

- Pierderi cu distribuție **eliptică comună** (distribuția Normală multivariată, distribuția Student- t multivariată) și $\alpha < 0,5$: VaR este subaditiv [McNeil, Frey & Embrechts \(2015\)](#)
 - ▶ Acolo VaR și ES sînt ambele $\mu_p + \sigma_p \times$ constantă, cu $\sigma_p \leq \sum_i \sigma_i$; marginale Normale sau t nu sînt suficiente prin ele însele
- **Cozi grele, dar nu prea grele**: pentru pierderi cu variație regulată multivariată și tail index peste 1, VaR este subaditiv suficient de departe în coadă (asimptotic, cînd $\alpha \rightarrow 0$) [Daniélsson et al. \(2013\)](#)
 - ▶ Tail index-urile estimate pentru acțiuni și cursuri de schimb sînt în acest domeniu (între 4,8 și 6,5 în secțiunea „Teoria valorilor extreme”), dar rezultatul este asimptotic, nu o garanție la un α dat
- Subaditivitatea nu se mai menține în prezența salturilor discrete (neplăți), cozi extrem de grele și unele cîștiguri din opțiuni
- VaR față de ES în practică: ES are nevoie de mai multe date pentru aceeași precizie [Yamai & Yoshida \(2005\)](#)

Anexă: agregarea VaR în condiții de incertitudine privind dependența

- Marginale $F_1, \dots, F_d$ cunoscute, copula necunoscută (Capitolul 6): $\text{VaR}_\alpha(\sum_i L_i)$ se află într-un interval Embrechts, Puccetti & Rüschendorf (2013)
 - ▶ F_i : funcția de repartiție a pierderii L_i a activului i , d : numărul de active; copula: structura de dependență care leagă marginalele
 - ▶ Valoarea comonotonă $\sum_i \text{VaR}_\alpha(L_i)$ (toate pierderile variază perfect împreună) **nu** este capătul superior: VaR nu este subaditiv
- **Algoritmul de rearanjare**: discretizăm coada de dincolo de fiecare $\text{VaR}_\alpha(L_i)$ în N puncte (o coloană pe activ)
 - ▶ Ordonăm fiecare coloană invers față de suma celorlalte pînă cînd sumele pe rînduri devin uniforme; VaR maxim $\approx$ cea mai mică sumă pe rînd
- Portofoliul 40/30/20/10 din secțiunea „VaR de portofoliu și contribuțiile la risc”, $\text{VaR}_{1\%}$ zilnic, marginale empirice, $N = 2000$
 - ▶ Dependența istorică 1,95%; comonotonă 3,63%; cazul cel mai rău 4,76% ($1,31 \times$ valoarea comonotonă)
- Incertitudinea privind modelul dependenței afectează capitalul bazat pe VaR cu un ordin de mărime comparabil cu beneficiul diversificării

Anexă: entropia și riscul de piață

- **Entropia diferențială** a unei densități f : $H(L) = - \int f(x) \ln f(x) dx$, o măsură a dispersiei fără momente
 - ▶ H mai mare = densitate mai dispersată; $\ln$: logaritmul natural
 - ▶ Pentru o familie locație-scală $L = \mu + \sigma Z$ (Z : pierderea standardizată): $H(L) = \ln \sigma + H(Z)$, deci $\text{VaR}_\alpha = \mu + e^{H(L)-H(Z)} q_{1-\alpha}(Z)$: entropia joacă rolul scalei
- **Pele, Lazar & Dufour (2017)**: entropia randamentelor intrazilnice este legată de VaR și ES intrazilnice și ajută la prognoza VaR zilnic (EUR/JPY)
- **Pele & Mazurencu-Marinescu-Pele (2019)**: entropia din date de înaltă frecvență dă cele mai bune prognoze VaR zilnice pentru Bitcoin dintre modelele comparate
- **Pele, Lazar & Mazurencu-Marinescu-Pele (2019)**: o măsură neparametrică bazată pe entropia cozii, ca estimator alternativ pentru ES

Anexă: VaR și ES pe metode și active

	VaR _{1%} (%)					ES _{2,5%} (%)				
	Ist.	Distr. Normală	t	CF	EVT	Ist.	Distr. Normală	t	CF	EVT
S&P 500	3,45	2,80	3,46	6,08	3,54	3,76	2,81	3,95	6,65	3,78
BET	4,13	3,19	4,06	7,25	4,22	4,57	3,21	4,76	7,93	4,58
Bitcoin	10,51	7,99	11,06	18,89	10,23	10,84	8,03	13,37	20,69	10,84
EUR/RON	0,76	0,64	1,36	1,43	0,78	0,84	0,65	3,27	1,60	0,84
Aur	3,04	2,50	3,00	4,64	3,07	3,23	2,51	3,27	5,02	3,23

- Pierderi zilnice, selecțiile complete; CF = Cornish–Fisher, EVT = coada Pareto generalizată estimată pe cele mai mari 5% dintre pierderi (secțiunea „Teoria valorilor extreme”)
- Excesul de kurtosis: S&P 500 10,7, BET 11,1, Bitcoin 12,0, EUR/RON 15,1, aur 7,7; Bitcoin necesită o rezervă de aproximativ trei ori mai mare decât S&P 500, EUR/RON de aproximativ o cincime

Anexă: teoria asimptotică pentru VaR și ES istorice

- **VaR:** pentru pierderi i.i.d. cu densitatea f continuă și pozitivă în VaR_α ,

$$\sqrt{n}(\widehat{\text{VaR}}_\alpha - \text{VaR}_\alpha) \rightarrow N\left(0, \frac{\alpha(1-\alpha)}{f(\text{VaR}_\alpha)^2}\right)$$
 - ▶ $\rightarrow$: convergență în distribuție când $n \rightarrow \infty$; dispersia limitei este dispersia asimptotică (avar), iar $\text{SE} = \sqrt{\text{avar}/n}$
- **ES Chen (2008):** funcția de influență $\text{IF}(x) = \text{VaR}_\alpha + (x - \text{VaR}_\alpha)_+/\alpha - \text{ES}_\alpha$
 - ▶ Niciun termen din estimarea VaR: $\partial F/\partial v = 0$ în $v = \text{VaR}_\alpha$; dacă $\mathbb{E}[(L - \text{VaR}_\alpha)_+^2] < \infty$, dispersia limitei lui $\sqrt{n}(\widehat{\text{ES}}_\alpha - \text{ES}_\alpha)$ este $\text{avar} = \text{Var}((L - \text{VaR}_\alpha)_+)/\alpha^2$
 - ▶ Coadă de tip Pareto cu indicele $a > 2$, $\alpha \rightarrow 0$: $\text{Var}((L - \text{VaR}_\alpha)_+) \approx \frac{2\alpha \text{VaR}_\alpha^2}{(a-1)(a-2)}$, deci $\text{SE} \propto \text{VaR}_\alpha/\sqrt{n\alpha}$ ($\propto$: proporțional cu) [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)
- Pierderi staționare, slab dependente: înlocuim dispersiile cu dispersiile de termen lung (HAC) ale lui $1\{L_t > \text{VaR}_\alpha\}$ și $(L_t - \text{VaR}_\alpha)_+$ [Newey & West \(1987\)](#) sau folosim un bootstrap pe blocuri

Anexă: precizia pentru S&P 500, tabelul complet

	n	$\widehat{\text{VaR}}_{1\%}$	SE i.i.d.	SE HAC	$\widehat{\text{ES}}_{2,5\%}$	SE i.i.d.	SE HAC
2000–2026	6 717	3,45	0,13	0,19	3,76	0,15	0,26
Ultimele 500 de zile	500	2,73	0,36	0,44	2,94	0,48	0,65

- Densitatea $f(\text{VaR})$ prin nucleu Gaussian (lățimea de bandă Silverman); HAC: nucleu Bartlett, lag $\lfloor 4(n/100)^{2/9} \rfloor$ (10 și 5) Newey & West (1994)
- Selecția completă, $n = 6\,717$: SE a $\text{VaR}_{1\%}$ sub distribuția Normală cu $\sigma = 1,2\%$ ar fi 0,055, sub t_4 0,12; volatility clustering crește SE cu 50–70%

Anexă: filtre GARCH și volatilitatea de mîne

	$\hat{\phi}$	$\hat{\alpha}_1$	$\hat{\beta}_1$	$\hat{\alpha}_1 + \hat{\beta}_1$	$\hat{\sigma}$ (selecție)	$\hat{\sigma}_{t+1}$	$-q_1\%(\hat{z})$
S&P 500	-0,053	0,120	0,860	0,981	1,21	0,73	2,79
BET	0,104	0,207	0,787	0,994	1,40	1,76	2,74
Bitcoin	-0,009	0,127	0,843	0,970	3,49	3,00	2,88
EUR/RON	0,169	0,200	0,780	0,980	0,28	0,11	2,74
Aur	-0,022	0,046	0,943	0,989	1,09	1,43	2,68

- $\hat{\sigma}_{t+1}$: prognoza pentru prima zi de tranzacționare de după 18 septembrie 2026 (19 septembrie pentru Bitcoin), în %
- Persistența aproape de 1: șocurile de volatilitate se sting încet ([Capitolul 5](#)); S&P 500 și EUR/RON sînt calme azi, BET și aurul agitate
- $-q_1\%(\hat{z})$ între 2,68 și 2,88, peste $-z_1\% = 2,326$: șocurile filtrate păstrează cozi grele

Anexă: VaR și ES condiționate pentru următoarea zi de tranzacționare

	VaR _{1%} (%)				ES _{1%} (%)			
	GARCH	FHS	c-EVT	Ist.	GARCH	FHS	c-EVT	Ist.
S&P 500	1,63	1,97	2,03	3,45	1,88	2,55	2,56	5,01
BET	3,80	4,53	4,63	4,13	4,39	6,16	6,20	6,28
Bitcoin	6,89	8,56	8,68	10,51	7,90	12,22	12,19	14,29
EUR/RON	0,23	0,27	0,26	0,76	0,27	0,34	0,35	1,12
Aur	3,32	3,82	3,86	3,04	3,80	4,94	4,93	4,21

- GARCH: GARCH cu șocuri Normale; c-EVT: teoria valorilor extreme condiționată (secțiunea „Teoria valorilor extreme”); Ist.: necondiționat, întreaga selecție
- GARCH cu șocuri Normale dă cea mai mică valoare dintre cele trei metode condiționate pe fiecare rând: volatilitatea singură nu descrie coada


Anexă: riscul de estimare în VaR condiționat

- $\text{VaR}_{\alpha,t+1} = -\mu_{t+1}(\theta) + \sigma_{t+1}(\theta) \xi_{\alpha}$, $\xi_{\alpha} = -q_{\alpha}(z)$: **atît** θ (GARCH, prin QML), cît și ξ_{α} (o cuantilă a reziduurilor) sînt estimați
 - ▶ θ : parametrii AR(1)-GARCH(1,1); QML: cvasi-verosimilitate maximă; $\mu_{t+1}(\theta)$, $\sigma_{t+1}(\theta)$: prognozele implicate de ei
- **Francq & Zakoïan (2015)**: estimăm împreună **parametrul de risc** (θ, ξ_{α}) ; sub staționaritate strictă, $\mathbb{E}[z_t^4] < \infty$ și o densitate pozitivă a lui z în $q_{\alpha}(z)$, VaR condiționat este asimptotic Normal, cu o dispersie provenind din $\hat{\theta}$, din $\hat{\xi}_{\alpha}$ și din covarianța lor
- **Bootstrap pe reziduuri Christoffersen & Gonçalves (2005)**, pentru $b = 1, \dots, B$ (B : numărul de eșantioane bootstrap; steluța marchează o valoare calculată pe un eșantion bootstrap)
 - ▶ simulăm o traiectorie AR(1)-GARCH(1,1) de lungimea selecției cu $\hat{z}$ reeșantionate și re-estimăm θ^* pe ea
 - ▶ σ_{t+1}^* din randamentele **originale** cu θ^* ; ξ_{α}^* din reziduurile traiectoriei; $\text{VaR}_{t+1}^* = -\mu_{t+1}^* + \sigma_{t+1}^* \xi_{\alpha}^*$; interval percentil: cuantilele de 5% și 95% ale celor B valori VaR_{t+1}^*
- Cozile grele și asimetria lui z încetinesc convergența; **Spierdijk (2016)** compară metodele de construire a intervalelor de încredere pentru VaR ARMA-GARCH în acest caz

Anexă: setările estimării CAViaR și modelele comune (VaR, ES)

- Setările de estimare din [Engle & Manganelli \(2004\)](#): 10^4 puncte de start aleatoare în $(0, 1)^3$, cele mai bune 10 rafinate prin pași simplex și quasi-Newton; valoarea de pornire a recursiei, $\text{VaR}_1 = -\hat{q}_\alpha$, este cuantila empirică de ordin α a primelor 300 de randamente, cu semn schimbat; aceste zile rămân în eșantionul de estimare
- Perechea (VaR, ES) poate fi **estimată** prin minimizarea unui scor comun strict consistent [Fissler & Ziegel \(2016\)](#); [Capitolul 8](#) folosește aceleași scoruri pentru a **evalua** prognozele
 - ▶ [Patton, Ziegel & Chen \(2019\)](#): modele semiparametrice dinamice pentru (VaR, ES), de ex. cu dinamică GAS, estimate prin minimizarea pierderii FZ0; consistență și normalitate asimptotică
 - ▶ [Taylor \(2019\)](#): recursii de tip CAViaR pentru VaR și ES, estimate printr-o verosimilitate Laplace asimetrică
 - ▶ [Dimitriadis & Bayer \(2019\)](#): regresie liniară a cuantilei și a ES pe covariate (volatilitate realizată și implicită), cu erori standard
- Firul comun: funcția de scor care ordonează prognozele este și funcția obiectiv care estimează modelul

Anexă: Emil Gumbel și statistica extremelor



Emil Julius Gumbel (1891–1966)

Foto: autor necunoscut (c. 1931); domeniu public;

[Wikimedia Commons](#)

- Fisher & Tippett (1928): maximul multor variabile i.i.d., rescalat corespunzător, poate avea doar trei forme limită
- Gnedenko (1943) a demonstrat riguros rezultatul
- Gumbel (1958) a scris primul manual și a aplicat teoria la inundații, secete și durate de viață
 - ▶ Distribuția Gumbel este una dintre cele trei forme limită

Anexă: de la maxime lunare la un VaR zilnic

- Zile independente: $P(M_n \leq x) \approx P(L \leq x)^n$, deci $\text{VaR}_\alpha \approx H^{-1}((1 - \alpha)^n)$ cu $n = 20,9$ zile de tranzacționare pe lună și H^{-1} funcția cuantilă a GEV estimate
 - ▶ $\text{VaR}_{1\%} \approx H^{-1}(0,810) = 2,83\%$ față de valoarea istorică 3,45%; $\text{VaR}_{0,1\%} \approx 6,19\%$
- Volatility clustering încalcă ipoteza de independență, iar aproximarea subestimează aici VaR
- Cu indicele extremal: $P(M_n \leq x) \approx F(x)^{n\theta}$, F : funcția de repartiție a pierderii zilnice
 - ▶ $\hat{\theta} = 0,35$ (prag la VaR 1%): $\text{VaR}_{1\%} \approx H^{-1}(0,929) = 4,14\%$ în loc de 2,83%; cu $\hat{\theta} = 0,19$: 5,09%
 - ▶ Corecția modifică rezultatul mai mult decât eroarea pe care o corectează: trecerea de la maximele pe blocuri la VaR zilnic este fragilă

Anexă: estimările GPD pentru cinci serii

	u (%)	N_u	$\hat{\xi}$	$SE(\hat{\xi})$	$1/\hat{\xi}$	$VaR_{1\%}$	$ES_{1\%}$
S&P 500	1,85	336	0,19	0,065	5,3	3,54	5,04
BET	1,93	334	0,21	0,066	4,8	4,22	6,34
Bitcoin	5,33	220	0,16	0,078	6,1	10,23	14,36
EUR/RON	0,38	268	0,18	0,072	5,5	0,78	1,14
Aur	1,68	348	0,15	0,062	6,5	3,07	4,22

- $\hat{\xi}$ între 0,15 și 0,21 pentru toate cele cinci serii, fiecare la peste două erori standard i.i.d. deasupra lui 0: cozi grele peste tot (gruparea depășirilor face ca aceste SE să fie subestimate)
- Tail index-ul $1/\hat{\xi}$ între 4,8 și 6,5: cozile drepte estimate ale pierderilor au momente de ordinul patru finite, dar fiecare interval de 95% pentru ξ trece de 0,25, deci existența momentelor de ordinul patru nu este confirmată statistic (comparați cu Capitolul 1)

Anexă: indicele extremal: estimatorul și separarea grupurilor

- ▣ **Estimatorul pe intervale** Ferro & Segers (2003) din cele N momente de depășire a lui u și intervalele T_i dintre ele
 - ▶ $\hat{\theta} = \min \left\{ 1, \frac{2(\sum_i (T_i - 1))^2}{(N - 1) \sum_i (T_i - 1)(T_i - 2)} \right\}$ dacă $\max T_i > 2$ (altfel cu T_i, T_i^2); compară pătratul intervalului mediu cu media pătratelor intervalelor: intervalele scurte din interiorul grupurilor împing $\hat{\theta}$ sub 1
- ▣ **Separarea grupurilor (declustering)** Ferro & Segers (2003): ținta este $C = \lfloor \hat{\theta} N \rfloor + 1$ grupuri, separate de cele mai mari $C - 1$ intervale; estimăm GPD pe maximele grupurilor
 - ▶ Egalități: dacă al $(C - 1)$ -lea și al C -lea cel mai mare interval sînt egale, C se reduce pînă cînd diferă, deci numărul realizat de grupuri poate fi sub țintă
- ▣ S&P 500: ținta $C = 63$, 62 de grupuri după regula egalităților; la VaR 1% istoric ($u = 3,45\%$, $N = 68$):
 $\hat{\theta} = 0,35$
 - ▶ SE i.i.d. a lui $\hat{\xi}$ era mai puțin de jumătate din SE obținută din maximele grupurilor

Anexă: portofoliul: volatilități, corelații și contribuții

	Pondere	σ_i (%)	corel. SPY	corel. TLT	corel. GLD
SPY	40%	1,10	1,00		
TLT	30%	0,93	-0,17	1,00	
GLD	20%	1,03	0,07	0,25	1,00
Bitcoin	10%	4,14	0,23	-0,02	0,09

	σ_i (%)	VaR marginal	C_i	cotă	C_i^{ES}	cotă
SPY	1,10	1,68	0,67	38,1%	0,98	45,4%
TLT	0,93	0,70	0,21	11,8%	0,14	6,5%
GLD	1,03	1,08	0,22	12,3%	0,25	11,4%
Bitcoin	4,14	6,68	0,67	37,8%	0,79	36,6%
Total	$\sigma_p = 0,76$		1,77	100%	2,15	100%

- SPY are o cotă mai mare din ES decât din VaR Normal (45,4% față de 38,1%): pierderile lui se concentrează în zilele cele mai rele ale portofoliului mai mult decât indică covarianțele; pentru a o interpreta drept dependență în coadă este necesară o analiză separată ([Capitolul 6](#))

Anexă: Comitetul de la Basel și calendarul UE



Turnul BIS din Basel, sediul Comitetului de la Basel pentru Supraveghere Bancară

Foto: Michal Pleskowicz (2018); CC BY-SA 4.0;
Wikimedia Commons

- Comitetul de la Basel pentru Supraveghere Bancară stabilește standardele globale de capital; autoritățile naționale (în UE, prin Regulamentul privind cerințele de capital) le transformă în lege
- **1996:** riscul de piață intră în regulile de capital; băncile pot folosi modele VaR interne [Basel Committee \(1996\)](#)
- **2019:** standardul revizuirii fundamentale a portofoliului de tranzacționare (Fundamental Review of the Trading Book) înlocuiește VaR cu ES în abordarea bazată pe modele interne [Basel Committee \(2019\)](#); fiecare jurisdicție își stabilește data de aplicare
- UE: [Delegated Regulation \(EU\) 2025/1496](#) a amânat cerințele de fonduri proprii FRTB la 1 ianuarie 2027; pînă atunci băncile aplică cadrul anterior, bazat pe VaR

Anexă: studiu de caz: date și metodă în detaliu (1/2)

- **Date** (Secțiunea 3.1 a articolului): randamentele log zilnice ale S&P 500, $r_t = \ln(P_t/P_{t-1})$, septembrie 1985 – august 2020, $T = 9\,053$; $\alpha = 1\%, 5\%$ și 10%
 - ▶ Patru seturi de predictor x_t (Ec. 14–17, după [Giacomini & Komunjer \(2005\)](#)): σ_t din GARCH(1,1); σ_t RiskMetrics cu factorul de atenuare $\lambda = 0,94$; CAViaR SAV ($\text{VaR}_{t-1}, |r_{t-1}|$); CAViaR cu pantă asimetrică ($\text{VaR}_{t-1}, r_{t-1}^+, r_{t-1}^-$), $r^+ = \max(r, 0)$, $r^- = \max(-r, 0)$
 - ▶ În articol, τ corespunde nivelului α din curs; $\text{VaR}_{\alpha,t} = -Q_{r_t}(\alpha \mid x_t)$, ca în secțiunea „VaR și Expected Shortfall”
- **Schema de evaluare** (Secțiunea 3.2 a articolului): ultimele 2 000 de zile formează eșantionul de evaluare; primele 7 053 sînt folosite pentru calibrarea unică a modelului (fereastră fixă)
 - ▶ CV (validare încrucișată) pentru serii de timp (Ec. 12): se exclud $\delta = 5$ zile de fiecare parte a observației evaluate; se alege aleatoriu $\kappa = 20$ de observații pentru testare; grile: adîncimea și lățimea din $\{1, 5, 10\}$, cîte cinci valori pentru rata de învățare și ponderea penalizării λ (alta decît λ RiskMetrics) în $[0,001; 0,01]$, dimensiunea lotului din $\{10, 20\}$; antrenare: dropout de cel mult 20%, Adam (algoritm de optimizare stocastică cu pas adaptiv), oprire timpurie (Secțiunea 1.4 a articolului)

Anexă: studiu de caz: date și metodă în detaliu (2/2)

- **Modele comparate:** regresia cuantilă liniară (modelul de referință), regresiile cuantile polinomială și cu funcții B-spline, modelul MIDAS liniar (Ec. 18) și o rețea MIDAS adâncă
 - ▶ **Evaluare** (Secțiunea 3.3 a articolului): RMSFE relativ la reperul liniar; testul DM [Diebold & Mariano \(1995\)](#) aplicat pierderilor pinball, cu corecția [Harvey, Leybourne & Newbold \(1997\)](#); testul CQFE (conditional quantile forecast encompassing) [Giacomini & Komunjer \(2005\)](#): verifică dacă o prognoză conține deja informația celeilalte; parametrul de netezire $\eta = 0,005$
 - ▶ Motivația: [Patton, Ziegel & Chen \(2019\)](#) au extins CAViaR la (VaR, ES) cu dinamică parametrică; acest articol păstrează doar VaR, dar renunță la liniaritate

Anexă: studiu de caz: rezultatele complete (Tabelele 6 și 7)

$\alpha = 1\%$	Polin.	Spline	MIDAS	Adînc	LASSO	Ridge	Elnet	MIDAS adînc
GARCH	0,909	0,791	1,083	0,346	0,236	0,177	0,146	0,346
RiskMetrics	0,780	0,570	1,066	0,289	0,141	0,207	0,239	0,246
SAV	1,000	1,511	0,838	0,198	0,024	0,225	0,498	0,850
Pantă asim.	1,000	1,040	4,918	0,235	0,096	0,014	0,037	0,601

- RMSFE relativ la regresia cuantilă liniară, $\alpha = 1\%$ (Tabelul 6; LASSO, Ridge, Elnet = rețele adînci penalizate): toate cele 16 valori ale rețelor adînci sînt sub 1 și semnificative la 1% în testul DM
 - Pe toate nivelurile, rețelele adînci reduc eroarea cu 50%–98%, MIDAS adînc cu 11%–84%; penalizarea cea mai bună se schimbă cu setul de predictor (elastic net pentru GARCH, LASSO pentru RiskMetrics și SAV, ridge pentru panta asimetrică)
- În majoritatea cazurilor, reperul liniar are erori mai mici decît regresiiile polinomială și cu spline (raport de pînă la 1,716 la alte niveluri α din Tabelul 6); MIDAS liniar ajunge la 4,918; rezultatele nu separă contribuțiile arhitecturii, penalizării și CV
- CQFE la $\alpha = 1\%$ (Tabelul 7): prognozele blocului neliniar înglobează informația din prognozele concurente în 757 de comparații (42 de rezultate nefavorabile, 751 neconcludente); pentru blocul liniar, 173 (15, 170); numeroasele perechi neconcludente arată că o combinație de prognoze ar putea aduce încă informație

Anexă: studiu de caz: replicare și limite

- **Replicare** pe datele zilnice de piață ale cursului: seria S&P 500 începe în ianuarie 1990, deci lipsește perioada 1985–1989 (o limită a datelor)
 - ▶ Păstrăm fereastra de evaluare din articol (ultimele 2 000 de randamente pînă la 31 august 2020, de la 19 septembrie 2012): 5 726 de zile de calibrare în loc de 7 053
 - ▶ Construim predictorii GARCH și SAV, estimăm regresia cuantilă liniară și regresia cuantilă cu o rețea neuronală adîncă la $\alpha = 1\%$ și recalculăm aceste două rînduri din Tabelul 6 (Seminarul 7, C3)
- **Limite menționate de autori**
 - ▶ O singură fereastră de estimare: recalibrarea recursivă sau pe fereastră mobilă, repetată pentru 2 000 de zile, necesită un volum mare de calcul (Secțiunea 3.2 a articolului)
 - ▶ Rețelele sînt predispuse la overfitting, de aici penalizările, dropout, CV și oprirea timpurie (Secțiunea 1.4 a articolului); rezultatul se interpretează doar prin valori SHAP și derivate parțiale (Secțiunea 4 a articolului)
- **Extinderi deschise** (Seminarul 7, C3)
 - ▶ Se păstrează cîștigul la reestimarea pe fereastră mobilă în 2020–2026 și pe BET?
 - ▶ Poate o rețea antrenată pe pierderea FZ0 a lui [Patton, Ziegel & Chen \(2019\)](#) să prognozeze împreună (VaR, ES), cum cere FRTB?

Anexă: bucla descoperirii, prompturi reutilizabile (1/2)

- Instrumentele sînt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și instrumente de căutare în literatura științifică (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „*Listează articolele publicate după 2015 despre backtesting-ul comparativ al perechii (VaR, ES) cu funcții de scor strict consistente: DOI, funcția de scor, testul, mărimea eșantionului și rezultatele privind puterea.*”
 - ▶ Verificăm fiecare DOI în Crossref; verificăm în articol convenția de semn a scorului
- **Ipoteze:** „*Pentru FHS, EVT condiționată și GARCH cu șocuri Normale, spune ce trăsături ale cozii surprinde fiecare și ce implică fiecare pentru diferențele FZ0 în anii calmi și în cei agitați.*”
- **Date și cod:** „*Scrie cod Python care calculează pierderea FZ0 pentru prognozele zilnice VaR 1% și ES 1% pe S&P 500 din datele zilnice de piață ale cursului, cu convenția de semn $VaR = -q_\alpha$, și un test Diebold–Mariano cu erori HAC.*”
 - ▶ Replicăm întâi: rata de depășire FHS de 1,54% pe 5 210 zile (secțiunea „VaR și ES condiționate”)

Anexă: bucla descoperirii, prompturi reutilizabile (2/2)

- **Robustețe:** „Scrie un plan pre-înregistrat: subperioadele 2006–2015 și 2016–2026, nivelurile 1% și 2,5%, FZ0 și un al doilea scor consistent, laguri HAC 5 și 20, un al doilea indice.”
 - Verificarea mărimii testului: simulăm dintr-un GARCH-t estimat și evaluăm două prognoze cu același FZ0 așteptat; testul trebuie să respingă în circa 5% din simulări
- **Critica:** „Joacă rolul unui referent: este ordonarea mea determinată de 2008 și 2020, de convenția de semn a scorului sau de ferestrele de estimare suprapuse? Indică un test care ar identifica fiecare dintre aceste probleme.”
- **Raportul:** fiecare pereche de modele, nivel și perioadă; numărul de zile din coadă pe care se bazează fiecare comparație
- **Testare multiplă:** modele $\times$ niveluri $\times$ perioade $\times$ active: fixăm familia dinainte și ajustăm p-value-urile; un DOI care nu duce la nicio lucrare sau un scor atribuit greșit: renunțăm la afirmație și o notăm în `AI_ERRORS.md`
- Fixăm planul înainte de prima rulare: orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare

Anexă: studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ▣  Measuring Statistical Risk
- ▣  XFG Advanced Methods in Quantitative Finance

Cod și date

- ▣ Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_07

Bibliografie (1/6)

- ▣ Acerbi, C., Tasche, D. (2002). *On the coherence of expected shortfall*. *Journal of Banking & Finance*, 26(7), 1487–1503.
- ▣ Artzner, P., Delbaen, F., Eber, J.-M., Heath, D. (1999). *Coherent measures of risk*. *Mathematical Finance*, 9(3), 203–228.
- ▣ Balkema, A.A., de Haan, L. (1974). *Residual life time at great age*. *Annals of Probability*, 2(5), 792–804.
- ▣ Bangia, A., Diebold, F.X., Schuermann, T., Strouhair, J.D. (2001). *Modeling liquidity risk, with implications for traditional market risk measurement and management*. In *Risk Management: The State of the Art*, Springer, 3–13.
- ▣ Barone-Adesi, G., Giannopoulos, K., Vosper, L. (1999). *VaR without correlations for portfolios of derivative securities*. *Journal of Futures Markets*, 19(5), 583–602.
- ▣ Basel Committee on Banking Supervision (1996). *Amendment to the capital accord to incorporate market risks*. Bank for International Settlements.
- ▣ Basel Committee on Banking Supervision (2019). *Minimum capital requirements for market risk*. Bank for International Settlements.
- ▣ Bayer, S., Dimitriadis, T. (2022). *Regression-based expected shortfall backtesting*. *Journal of Financial Econometrics*, 20(3), 437–471.
- ▣ Bollerslev, T. (1986). *Generalized autoregressive conditional heteroskedasticity*. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Chen, S.X. (2008). *Nonparametric estimation of expected shortfall*. *Journal of Financial Econometrics*, 6(1), 87–107.

Bibliografie (2/6)

- ▣ Christoffersen, P., Gonçalves, S. (2005). Estimation risk in financial risk management. *Journal of Risk*, 7(3), 1–28.
- ▣ Chronopoulos, I., Raftapostolos, A., Kapetanios, G. (2024). Forecasting Value-at-Risk using deep neural network quantile regression. *Journal of Financial Econometrics*, 22(3), 636–669.
- ▣ Čížek, P., Härdle, W.K., Weron, R. (Eds.) (2011). *Statistical Tools for Finance and Insurance*, 2nd ed. Springer.
- ▣ Cont, R., Deguest, R., Scandolo, G. (2010). Robustness and sensitivity analysis of risk measurement procedures. *Quantitative Finance*, 10(6), 593–606.
- ▣ Cornish, E.A., Fisher, R.A. (1938). Moments and cumulants in the specification of distributions. *Revue de l'Institut International de Statistique*, 5(4), 307–320.
- ▣ Daníelsson, J. (2011). *Financial Risk Forecasting*. Wiley.
- ▣ Daníelsson, J., Jorgensen, B.N., Samorodnitsky, G., Sarma, M., de Vries, C.G. (2013). Fat tails, VaR and subadditivity. *Journal of Econometrics*, 172(2), 283–291.
- ▣ Daníelsson, J., Zigrand, J.-P. (2006). On time-scaling of risk and the square-root-of-time rule. *Journal of Banking & Finance*, 30(10), 2701–2713.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Dimitriadis, T., Bayer, S. (2019). A joint quantile and expected shortfall regression framework. *Electronic Journal of Statistics*, 13(1), 1823–1871.

Bibliografie (3/6)

- ▣ Embrechts, P., Klüppelberg, C., Mikosch, T. (1997). *Modelling Extremal Events for Insurance and Finance*. Springer.
- ▣ Embrechts, P., Puccetti, G., Rüschendorf, L. (2013). *Model uncertainty and VaR aggregation*. *Journal of Banking & Finance*, 37(8), 2750–2764.
- ▣ Engle, R.F., Manganelli, S. (2004). *CAViaR: conditional autoregressive value at risk by regression quantiles*. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- ▣ Ferro, C.A.T., Segers, J. (2003). *Inference for clusters of extreme values*. *Journal of the Royal Statistical Society: Series B*, 65(2), 545–556.
- ▣ Fisher, R.A., Tippett, L.H.C. (1928). *Limiting forms of the frequency distribution of the largest or smallest member of a sample*. *Mathematical Proceedings of the Cambridge Philosophical Society*, 24(2), 180–190.
- ▣ Fissler, T., Ziegel, J.F. (2016). *Higher order elicibility and Osband's principle*. *Annals of Statistics*, 44(4), 1680–1707.
- ▣ Francq, C., Zakoïan, J.-M. (2015). *Risk-parameter estimation in volatility models*. *Journal of Econometrics*, 184(1), 158–173.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Giacomini, R., Komunjer, I. (2005). *Evaluation and combination of conditional quantile forecasts*. *Journal of Business & Economic Statistics*, 23(4), 416–431.
- ▣ Gnedenko, B. (1943). *Sur la distribution limite du terme maximum d'une série aléatoire*. *Annals of Mathematics*, 44(3), 423–453.

Bibliografie (4/6)

- ▣ Gneiting, T. (2011). [Making and evaluating point forecasts](#). *Journal of the American Statistical Association*, 106(494), 746–762.
- ▣ Gumbel, E.J. (1958). [Statistics of Extremes](#). Columbia University Press.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). [Applied Quantitative Finance](#), 3rd ed. Springer.
- ▣ Harvey, D., Leybourne, S., Newbold, P. (1997). [Testing the equality of prediction mean squared errors](#). *International Journal of Forecasting*, 13(2), 281–291.
- ▣ Hill, B.M. (1975). [A simple general approach to inference about the tail of a distribution](#). *Annals of Statistics*, 3(5), 1163–1174.
- ▣ Hull, J., White, A. (1998). [Incorporating volatility updating into the historical simulation method for value-at-risk](#). *Journal of Risk*, 1(1), 5–19.
- ▣ J.P. Morgan/Reuters (1996). [RiskMetrics – Technical Document](#), 4th ed. New York.
- ▣ Koenker, R., Bassett, G. (1978). [Regression quantiles](#). *Econometrica*, 46(1), 33–50.
- ▣ Longin, F.M. (2000). [From value at risk to stress testing: the extreme value approach](#). *Journal of Banking & Finance*, 24(7), 1097–1130.
- ▣ McNeil, A.J., Frey, R. (2000). [Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach](#). *Journal of Empirical Finance*, 7(3–4), 271–300.

Bibliografie (5/6)

- ▣ McNeil, A.J., Frey, R., Embrechts, P. (2015). *Quantitative Risk Management: Concepts, Techniques and Tools*, revised ed. Princeton University Press.
- ▣ Newey, W.K., West, K.D. (1987). *A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix*. *Econometrica*, 55(3), 703–708.
- ▣ Newey, W.K., West, K.D. (1994). *Automatic lag selection in covariance matrix estimation*. *Review of Economic Studies*, 61(4), 631–653.
- ▣ Nolde, N., Ziegel, J.F. (2017). *Elicitability and backtesting: perspectives for banking regulation*. *Annals of Applied Statistics*, 11(4), 1833–1874.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). *Dynamic semiparametric models for expected shortfall (and Value-at-Risk)*. *Journal of Econometrics*, 211(2), 388–413.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). *Information entropy and measures of market risk*. *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). *Modeling expected shortfall using tail entropy*. *Entropy*, 21(12), 1204.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). *Using high-frequency entropy to forecast Bitcoin's daily value at risk*. *Entropy*, 21(2), 102.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). *Finite-sample precision limits for expected shortfall forecast comparisons*. *Mathematics*, 14(13), 2316.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). *Are cryptos becoming alternative assets?*. *European Journal of Finance*, 29(10), 1064–1105.

Bibliografie (6/6)

- ▣ Pickands, J. (1975). [Statistical inference using extreme order statistics](#). *Annals of Statistics*, 3(1), 119–131.
- ▣ Rockafellar, R.T., Uryasev, S. (2000). [Optimization of conditional value-at-risk](#). *Journal of Risk*, 2(3), 21–41.
- ▣ Rockafellar, R.T., Uryasev, S. (2002). [Conditional value-at-risk for general loss distributions](#). *Journal of Banking & Finance*, 26(7), 1443–1471.
- ▣ Spierdijk, L. (2016). [Confidence intervals for ARMA–GARCH value-at-risk: the case of heavy tails and skewness](#). *Computational Statistics & Data Analysis*, 100, 545–559.
- ▣ Tasche, D. (2008). [Capital allocation to business units and sub-portfolios: the Euler principle](#). arXiv:0708.2542.
- ▣ Taylor, J.W. (2019). [Forecasting value at risk and expected shortfall using a semiparametric approach based on the asymmetric Laplace distribution](#). *Journal of Business & Economic Statistics*, 37(1), 121–133.
- ▣ Yamai, Y., Yoshida, T. (2005). [Value-at-risk versus expected shortfall: a practical perspective](#). *Journal of Banking & Finance*, 29(4), 997–1015.