

Modelarea piețelor financiare

Capitolul 7: VaR și Expected Shortfall



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Cît de mari sînt pierderile extreme de mîine și cu ce precizie le putem estima?

Ce vom explica

- Două măsuri ale cozii: VaR (Value-at-Risk, valoarea la risc), un prag de pierdere, și ES (Expected Shortfall), pierderea medie dincolo de prag
- Partea I: definiții, coerență, metode de estimare necondiționate și precizia lor
- Partea a II-a: prognoze condiționate (simularea istorică filtrată, FHS, și modelarea directă a cuantilei, CAViaR), teoria valorilor extreme, orizontul, portofoliul, reglementarea, un studiu de caz și un exemplu de buclă de cercetare asistată de AI (inteligență artificială)
- Exerciții rezolvate, Seminarul 7: A1, A2, A3, A5, B1, B4

Ce trebuie să poți face

- să definești VaR și ES și să explici de ce ES este coerent, iar VaR nu
- să estimezi ambele măsuri istoric, parametric, prin simulare filtrată și prin teoria valorilor extreme, fiecare cu o eroare standard sau un interval
- să le scalezi la 10 zile și să le descompui pe active
- să interpretezi regulile Basel, inclusiv FRTB (Fundamental Review of the Trading Book, standardul din 2019 pentru riscul de piață)

Ce pierderi măsurăm și în ce unități?

- Exemplul principal: pierderile zilnice ale S&P 500, 2000–2026
- Comparații pe BET (indicele principal al Bursei de Valori București, BVB), Bitcoin, EUR/RON (cursul de referință al Băncii Naționale a României, BNR) și aur
- Date pînă la 18 septembrie 2026 (inventarul complet în Anexă)
- Unități: randamente log zilnice în %, $r_t = 100\,(\ln P_t - \ln P_{t-1})$, cu P_t prețul de închidere din ziua t

Pierderea potențială: RiskMetrics și VaR



Clădirea J.P. Morgan & Co., 23 Wall Street, New York

Foto: Beyond My Ken (2012); CC BY-SA 4.0; Wikimedia Commons

- Valoarea de mîine a portofoliului este aleatoare
- Conducerea și autoritățile au nevoie de **un singur număr**: un prag de pierdere depășit rar, folosit la stabilirea limitelor și a cerințelor de **capital**
- J.P. Morgan a publicat **RiskMetrics** în octombrie 1994, o metodologie și un set de date gratuite pentru riscul de piață
- Documentul tehnic (ed. a 4-a, 1996) a devenit referința pentru VaR J.P. Morgan/Reuters (1996)
- Manuale: Franke, Härdle & Hafner (2019), McNeil, Frey & Embrechts (2015), Daníelsson (2011)

Pierderi, orizonturi și probabilități ale cozii

- Randamentul pe o zi: $X_{t+1} = r_{t+1}$, randamentul log în %
- **Pierderea**: $L_{t+1} = -X_{t+1}$, o **pierdere log**
  - Un L pozitiv înseamnă că poziția a pierdut bani
  - Un L negativ înseamnă un cîștig
  - În bani, cu V_t valoarea poziției: pierderea $= V_t\,(1 - e^{-L_{t+1}/100}) \approx V_t L_{t+1}/100$ pentru L mic
  - Cu randamente simple R, $V_t\,(-R_{t+1})/100$ este exactă
  - Exemplu: un preț care scade de la 100 la 90 are un randament simplu de -10%, dar un randament log de $100\ln(0{,}9) = -10{,}54\%$
  - Randamentele log se adună în timp, cele simple se adună între active
  - VaR se convertește exact prin această transformare monotonă
  - Pentru ES, convertim pierderea din fiecare scenariu, apoi calculăm media
- **Orizontul** h: numărul de zile pe care se măsoară pierderea (1 zi, 10 zile)
- **Nivelul** α: **probabilitatea cozii**, de regulă $\alpha = 1\%$ sau 2,5%: „VaR 1%", „ES 2,5%"
- **Convenția de semn în acest curs**: VaR și ES sînt numere **pozitive** atunci cînd sînt pierderi

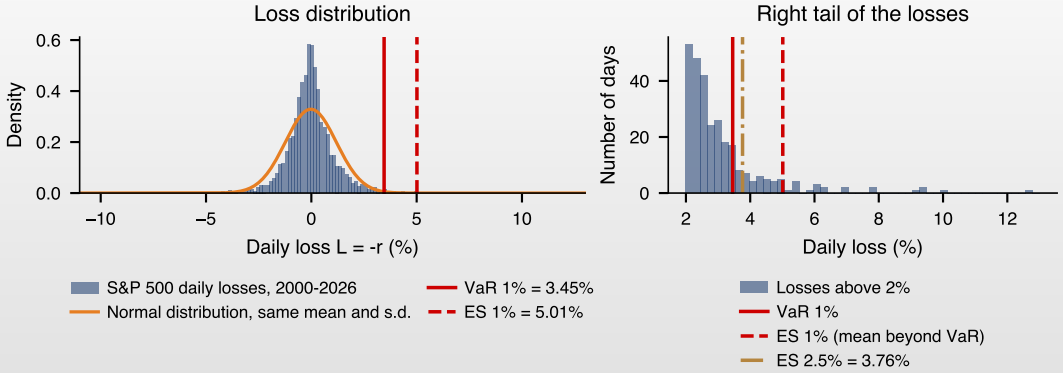
Definiții (1/2): valoarea la risc (VaR)

- **VaR** la nivelul α: pierderea depășită cu probabilitatea α (exact pentru L continuă, cel mult α în general)
  - $\mathrm{VaR}_\alpha(X) = -\inf\{x \in \mathbb{R} : P(X \leq x) > \alpha\} = -q_\alpha(X)$
  - În cuvinte: $\mathrm{VaR}_\alpha = -q_\alpha(X)$, unde $q_\alpha(X)$ este pragul randamentului sub care cade doar o fracțiune α din zile
  - VaR este acest prag luat cu semn schimbat, deci un număr pozitiv (o pierdere)
- Notațiile
  - X: randamentul poziției pe orizontul ales
  - $P(X \leq x)$: probabilitatea ca acesta să fie cel mult x, adică funcția de repartiție în x
  - $\inf\{\cdot\}$: infimumul (cel mai mare minorant) al mulțimii, aici cel mai mic x în care funcția de repartiție depășește α
  - $q_\alpha(X)$: cuantila de ordin α a lui X, negativă pentru α mic
  - Pentru o pierdere continuă $L = -X$: $\mathrm{VaR}_\alpha = q_{1-\alpha}(L)$, cuantila superioară a pierderii
- Interpretarea VaR 1%
  - „Cu probabilitatea de 1%, pierderea de mîine va depăși $\mathrm{VaR}_{1\%}$"
  - VaR **nu** spune cît de mare este pierderea dincolo de acest prag

Definiții (2/2): Expected Shortfall

- **Expected Shortfall** (pierderea așteptată în coadă): media tuturor cuantilelor din coada de probabilitate α
  - $\mathrm{ES}_\alpha(X) = -\frac{1}{\alpha}\int_0^\alpha q_u(X)\,du = \frac{1}{\alpha}\int_0^\alpha \mathrm{VaR}_u(X)\,du$
  - u: variabila de integrare, o probabilitate a cozii care parcurge intervalul de la 0 la α
  - Integrala împărțită la α este media lui VaR_u pe toate nivelurile $u \leq \alpha$
- Pentru o distribuție continuă: pierderea medie în zilele de dincolo de VaR
  - $\mathrm{ES}_\alpha(X) = -\mathbb{E}[X \mid X \leq q_\alpha(X)]$; $\mathbb{E}[\cdot \mid \cdot]$: media condiționată, aici media lui X pe cea mai rea fracțiune α a rezultatelor
  - Întotdeauna $\mathrm{ES}_\alpha \geq \mathrm{VaR}_\alpha$: ES descrie **întreaga** coadă, VaR doar pragul ei
  - Două portofolii cu același VaR pot avea ES foarte diferite
- Alte denumiri: Conditional VaR (CVaR), Tail VaR, Average VaR Rockafellar & Uryasev (2002), Acerbi & Tasche (2002)

VaR și ES pentru S&P 500 (1/2)



MFM_ch7_loss_distribution

VaR și ES pentru S&P 500 (2/2)

- Stînga: pierderile zilnice 2000–2026 față de distribuția Normală cu aceeași medie și abatere standard
- Dreapta: coada distribuției
- $\mathrm{VaR}_{1\%}$ istoric $= 3{,}45\%$: pierderea l-a depășit în 68 din 6 717 zile (1,01%)
- În acele zile, pierderea medie, adică $\mathrm{ES}_{1\%}$, a fost 5,01%
- La nivelul 2,5%: VaR istoric este 2,51%, iar ES este 3,76%
- Cea mai mare pierdere: 12,77%, pe 2020-03-16 (crahul din pandemia COVID-19), adică circa zece abateri standard
- Distribuția Normală se potrivește în centru, dar are cozi mult prea subțiri (Capitolul 1)

MFM_ch7_loss_distribution

Distribuția Normală: ES într-o singură formulă (1/2)

- Cadrul: $X \sim N(\mu, \sigma^2)$, un randament cu distribuția Normală, de medie μ și abatere standard σ
  - Φ, φ: funcția de repartiție și densitatea distribuției Normale standard $N(0,1)$
  - $z_\alpha = \Phi^{-1}(\alpha) < 0$: cuantila de ordin α a distribuției Normale standard, de exemplu $z_{1\%} = -2{,}326$
- VaR: media minus $|z_\alpha|$ abateri standard, cu semn schimbat
  - $\mathrm{VaR}_\alpha = -(\mu + \sigma z_\alpha)$
- ES: aceeași formă, cu factorul mai mare $\varphi(z_\alpha)/\alpha$ în locul lui $-z_\alpha$
  - $\mathrm{ES}_\alpha = -\mu - \dfrac{\sigma}{\alpha} \displaystyle\int_{-\infty}^{z_\alpha} u\varphi(u)\, du = -\mu + \sigma\, \dfrac{\varphi(z_\alpha)}{\alpha}$
  - Integrala împărțită la α este media șocului standardizat u pe coada $u \le z_\alpha$
  - Integrala neîmpărțită este egală cu $-\varphi(z_\alpha)$ deoarece $\varphi'(u) = -u\varphi(u)$

Distribuția Normală: ES într-o singură formulă (2/2)

- Constante utile
  - $-z_{1\%} = 2{,}326$, $\varphi(z_{1\%})/0{,}01 = 2{,}665$
  - $-z_{2{,}5\%} = 1{,}960$, $\varphi(z_{2{,}5\%})/0{,}025 = 2{,}338$
  - Deci, sub distribuția Normală, ES 2,5% este aproape egal cu VaR 1% (2,338 față de 2,326 abateri standard)
- S&P 500: $\hat{\mu} = 0{,}025\%$, $\hat{\sigma} = 1{,}213\%$ (notația $\hat{}$ indică o valoare estimată din date)
- $\mathrm{VaR}_{1\%}$ Normal $= 2{,}80\%$ față de $3{,}45\%$ istoric
  - Calculul: $\mathrm{VaR}_{1\%} = -\hat{\mu} + \hat{\sigma}\,(-z_{1\%}) = -0{,}025 + 1{,}213 \times 2{,}326 \approx 2{,}80\%$
  - VaR istoric este de 1,24 ori mai mare decît VaR Normal
- Sub distribuția Normală, pentru μ dat, VaR și ES nu aduc informație dincolo de σ

Distribuția Student-t: VaR și ES

- Modelul: randamentul este o variabilă Student-t deplasată și rescalată, $X = m + s\,T$ cu $T \sim t_\nu$
  - m: parametrul de poziție
  - $s > 0$: scala
  - ν: gradele de libertate, iar un ν mai mic înseamnă cozi mai grele
  - $t_\alpha = t_\nu^{-1}(\alpha) < 0$: cuantila de ordin α a lui t_ν
  - g_ν: densitatea lui t_ν
- VaR ca la distribuția Normală, cu t_α în locul lui z_α
- ES primește un factor suplimentar $(\nu + t_\alpha^2)/(\nu - 1) > 1$, datorat cozii grele
  - $\mathrm{VaR}_\alpha = -(m + s\,t_\alpha), \qquad \mathrm{ES}_\alpha = -m + s\,\dfrac{g_\nu(t_\alpha)}{\alpha}\,\dfrac{\nu + t_\alpha^2}{\nu - 1}$ (pentru $\nu > 1$)
  - Dispersia $s^2\nu/(\nu - 2)$ există doar pentru $\nu > 2$, deci s nu este abaterea standard

Distribuția Student-t estimată pe S&P 500, pas cu pas

- Estimările de verosimilitate maximă pe randamentele zilnice în %: $\hat{m} = 0{,}068$, $\hat{s} = 0{,}702$, $\hat{\nu} = 2{,}666$
  - Abaterea standard implicată $\hat{s}\sqrt{\hat{\nu}/(\hat{\nu}-2)} = 1{,}40\%$, nu $\hat{\sigma} = 1{,}21\%$ din selecție
  - În formule intră scala $\hat{s}$, nu $\hat{\sigma}$
- **VaR**: cuantila $t_{1\%} = t_{\hat{\nu}}^{-1}(0{,}01) = -5{,}028$
  - $\mathrm{VaR}_{1\%} = -(\hat{m} + \hat{s}\, t_{1\%}) = -0{,}068 + 0{,}702 \times 5{,}028 \approx 3{,}46\%$
- **ES**: densitatea $g_{\hat{\nu}}(t_{1\%}) = 0{,}00490$, deci $g_{\hat{\nu}}(t_{1\%})/\alpha = 0{,}490$
- Factorul cozii: $(\hat{\nu} + t_{1\%}^2)/(\hat{\nu} - 1) = 16{,}77$
  - $\mathrm{ES}_{1\%} = -\hat{m} + \hat{s}\,\dfrac{g_{\hat{\nu}}(t_{1\%})}{\alpha}\,\dfrac{\hat{\nu} + t_{1\%}^2}{\hat{\nu} - 1} = -0{,}068 + 0{,}702 \times 0{,}490 \times 16{,}77 \approx 5{,}71\%$
- De ce ES este prea mare: cu $\hat{\nu}$ aproape de 2, factorul cozii este mare, deci ES este 5,71% față de 5,01% istoric, deși VaR se potrivește

MFM_ch7_methods_assets

Cum comparăm corect formele cozilor?

- Pentru a izola forma cozii, păstrăm aceeași medie și aceeași abatere standard
- Modelele Normal și Student-t estimate pe aceleași date nu au obligatoriu același parametru de scală
- Exemplu: medie zero, abatere standard 2% și $\nu = 4$; scala Student-t este $s = 2\sqrt{(4-2)/4} = 1{,}414\%$, iar scala Normală este 2%
- Cu $s = 2\%$ în ambele modele, abaterea standard Student-t ar fi mai mare: diferența ar amesteca efectul scalei cu cel al formei cozii
- Comparația controlată (aceeași medie și aceeași abatere standard) arată efectul formei cozii (Seminarul 7, A2)
- Estimarea separată a celor două modele pe aceleași date schimbă și scala: diferențele din secțiunea „Metode de estimare" amestecă cele două efecte

Măsuri de risc coerente (1/2): cele patru axiome

- O **măsură de risc** ρ asociază unei pierderi L (o variabilă aleatoare) un număr, capitalul necesar
- Măsura este **coerentă** dacă satisface patru axiome Artzner, Delbaen, Eber & Heath (1999)
  - L_1, L_2: două pierderi
  - c: o sumă sigură (constantă)
  - $\lambda \geq 0$: un factor de scală (mărimea poziției)
- **Monotonă**: $L_1 \leq L_2 \Rightarrow \rho(L_1) \leq \rho(L_2)$
  - O poziție care pierde mereu mai mult cere mai mult capital
- **Invariantă la translație**: $\rho(L + c) = \rho(L) + c$
  - Adăugarea unei pierderi sigure c crește capitalul exact cu c
- **Pozitiv omogenă**: $\rho(\lambda L) = \lambda \rho(L)$
  - Dublarea poziției dublează capitalul
- **Subadditivă**: $\rho(L_1 + L_2) \leq \rho(L_1) + \rho(L_2)$
  - Reunirea a două poziții nu cere niciodată mai mult capital decît păstrarea lor separată: diversificarea nu adaugă risc

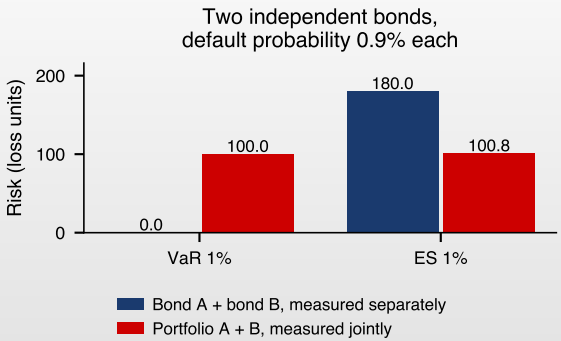
Măsuri de risc coerente (2/2): implicațiile axiomelor

- **Limitele de risc**
  - Prin subaditivitate, riscul întregii bănci nu depășește suma limitelor de risc ale birourilor de tranzacționare, $\sum_i \rho_i$
  - **Fără arbitraj de reglementare** prin divizarea firmei
- **Optimizare**: omogenitate + subaditivitate $\Rightarrow$ convexitate în ponderile portofoliului
  - Orice minim local este global
  - Unicitatea ar cere convexitate **strictă**, pe care ES pe scenarii nu o are (este liniar pe porțiuni)
- VaR satisface primele trei axiome, dar **nu** și subaditivitatea în general
  - Excepție: pierderi cu distribuție eliptică comună (Normală sau Student-t multivariată) și $\alpha < 50\%$, cînd VaR și ES sînt ambele $\mu_p + \sigma_p \times$ constantă McNeil, Frey & Embrechts (2015)
  - μ_p, σ_p: media și abaterea standard a pierderii portofoliului (rafinările pentru cozi grele: Anexă)

Contraexemplu: două obligațiuni, pas cu pas

- Obligațiunile A și B sînt independente
- Fiecare pierde 100 cu probabilitatea $p = 0{,}9\%$ (neplată) și 0 altfel
- X: variația valorii, $X = -L$
- Formula generală pentru o pierdere discretă $L = -X$: $\mathrm{ES}_\alpha = \frac{1}{\alpha}\left(\mathbb{E}[L\,1\{L > \mathrm{VaR}_\alpha\}] + \mathrm{VaR}_\alpha\left(\alpha - P(L > \mathrm{VaR}_\alpha)\right)\right)$
  - $1\{\cdot\}$: indicatorul, 1 dacă are loc condiția și 0 altfel
  - Primul termen: pierderile strict dincolo de VaR
  - Al doilea termen: restul probabilității cozii α, plasat chiar în VaR
- **O obligațiune**: $P(X \le -100) = p = 0{,}9\%$, nu peste 1%, deci $q_{\mathbf{1\%}} = 0$ și $\mathrm{VaR}_{\mathbf{1\%}}(A) = \mathrm{VaR}_{\mathbf{1\%}}(B) = 0$
  - $\mathrm{ES}_{\mathbf{1\%}}(A) = (100 \cdot 0{,}009 + 0 \cdot 0{,}001)/0{,}01 = 90$
- **Portofoliul A + B**: $P(X \le -100) = 1 - (1-p)^{\mathbf{2}} = 1{,}79\% > 1\%$, $P(X \le -200) = p^{\mathbf{2}} = 0{,}0081\%$, deci $q_{\mathbf{1\%}} = -100$
  - $\mathrm{VaR}_{\mathbf{1\%}}(A+B) = 100 > 0 + 0 = \mathrm{VaR}_{\mathbf{1\%}}(A) + \mathrm{VaR}_{\mathbf{1\%}}(B)$
- $\mathrm{ES}_{\mathbf{1\%}}(A+B) = 100{,}81 \le 180 = \mathrm{ES}_{\mathbf{1\%}}(A) + \mathrm{ES}_{\mathbf{1\%}}(B)$

Subadditivitatea: încălcată de VaR, respectată de ES



- Albastru: suma celor două măsuri individuale
- Roșu: măsura portofoliului combinat
- Pentru fiecare obligațiune luată separat, probabilitatea de neplată rămîne sub 1%, deci nu influențează VaR
- Împreună, cel puțin o neplată are probabilitatea 1,79% $>$ 1%, iar VaR crește brusc la 100
- O limită VaR ar recompensa **concentrarea**: deținerea doar a obligațiunii A pare fără risc
- ES ține cont de mărimea pierderilor din coadă și este coerent Acerbi & Tasche (2002)
- Portofoliile de credit, opțiunile și alte cîștiguri asimetrice sînt situațiile tipice în care VaR încalcă subaditivitatea în practică

MFM_ch7_subadditivity

Verificare rapidă: care poziție este mai riscantă?

- Două poziții, pierderi în %, nivelul $\alpha = 10\%$
- **A**: pierderea L_A uniformă pe $[0, 10]$, toate valorile la fel de probabile
  - Calculează $\mathrm{VaR}_{10\%}(A)$ și $\mathrm{ES}_{10\%}(A)$ din definiții
- **B**: pierdere 0 cu probabilitatea 0,95, pierdere 20 cu probabilitatea 0,05
  - Calculează $\mathrm{VaR}_{10\%}(B)$ și $\mathrm{ES}_{10\%}(B)$ cu formula ES discretă de pe slide-ul celor două obligațiuni
- Ce poziție consideră mai riscantă fiecare măsură și ce nu vede VaR?
- Răspunsurile sînt în ▸ Anexă

ES ca problemă de optimizare: Rockafellar–Uryasev

- **Teoremă** Rockafellar & Uryasev (2000): pentru orice pierdere integrabilă L
  - $\mathrm{ES}_\alpha(L) = \min_{v \in \mathbb{R}} F(v), \quad F(v) = v + \frac{1}{\alpha}\mathbb{E}[(L-v)_+], \quad (x)_+ = \max(x, 0)$
  - v: un prag candidat
  - $F(v)$: pragul plus depășirea medie a pierderii peste prag, mărită cu factorul $1/\alpha$
  - Punctul de minim este $\mathrm{VaR}_\alpha(L)$, iar valoarea minimă este $\mathrm{ES}_\alpha(L)$
  - $F(\mathrm{VaR}_\alpha)$ este formula ES discretă de pe slide-ul celor două obligațiuni
- F este convexă în v și, pentru pierderea unui portofoliu $-w^\top R$, convexă simultan în (w, v)
  - w: vectorul ponderilor
  - R: vectorul randamentelor activelor
  - ES este convex în ponderi, ceea ce **demonstrează** subadditivitatea (demonstrația în Anexă)
  - Cu scenarii istorice, minimizarea ES devine o problemă de programare liniară (secțiunea „VaR de portofoliu și contribuțiile la risc")
- Pierderile S&P 500, $\alpha = 2{,}5\%$: punctul de minim este $\arg\min F = 2{,}51\%$, iar valoarea minimă $\min F = 3{,}76\%$
  - VaR și ES istorice (cuantilă interpolată, medie în coadă): 2,51% și 3,76%
  - Egale doar după rotunjire: punctul de minim empiric este o statistică de ordine

Coerență și robustețe

- **Robustețe calitativă**: o mică schimbare a distribuției datelor modifică doar puțin distribuția estimatorului Cont, Deguest & Scandolo (2010)
  - VaR istoric este calitativ robust în distribuțiile cu α-cuantilă unică
  - ES istoric **nu** este: o singură pierdere extremă îl poate modifica oricît de mult (secțiunea „Precizia estimărilor VaR și ES")
- S&P 500, ultimele 500 de zile: eliminăm cea mai mare pierdere (6,16%, 2025-04-04)
  - $\mathrm{ES}_{2,5\%}$ trece de la 2,94% la 2,60%
  - $\mathrm{VaR}_{1\%}$ trece de la 2,73% la 2,68%
- Există un compromis: subaditivitatea cere informație din coada de dincolo de cuantilă, exact ceea ce face ES sensibil la observații izolate
- FRTB a ales coerența pentru capital (ES 2,5%) și a păstrat VaR, robust și elicitabil, pentru backtesting

Elicitabilitatea: dificultatea evaluării ES (Capitolul 8)

- O măsură de risc este **elicitabilă** dacă minimizează media unei funcții de scor
  - VaR: cuantila $q_\alpha(X)$ minimizează funcția de pierdere pinball $\mathbb{E}[(1\{X \leq v\} - \alpha)(v - X)]$
  - Funcția de scor: o penalizare calculată din prognoza v și din rezultatul X, o valoare mai mică înseamnă o prognoză mai bună
  - Pierderea pinball penalizează cu $1 - \alpha$ pe unitate cînd X cade sub v și cu α pe unitate cînd rămîne deasupra
- ES, considerat separat, **nu** este elicitabil Gneiting (2011): nu există o funcție de scor strict consistentă pentru prognozele ES evaluate separat
- Perechea (VaR, ES) este elicitabilă împreună Fissler & Ziegel (2016): scoruri comune precum FZ0 (scorul Fissler–Ziegel omogen de grad zero din Patton, Ziegel & Chen (2019)) ordonează prognozele (VaR, ES) (▸ Anexă; Capitolul 8)
- Consecință: compararea prognozelor de ES este mai dificilă decît a celor de VaR

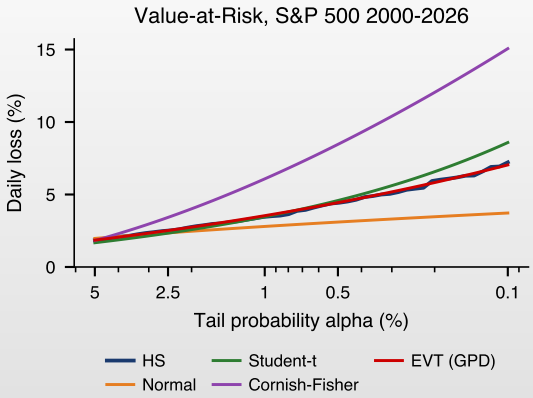
Simularea istorică

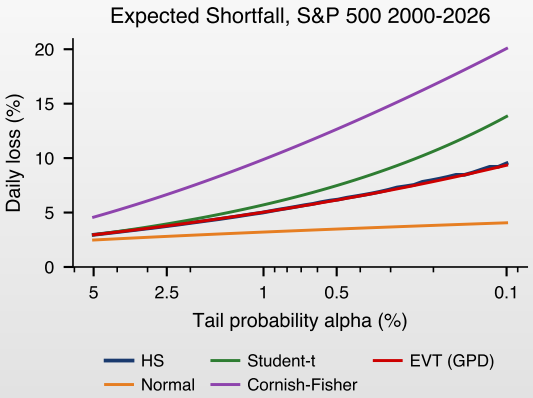
- Luăm ultimele n pierderi zilnice $L_{t-n+1}, \ldots, L_t$ și le ordonăm: $L_{(1)} \leq \cdots \leq L_{(n)}$
- $L_{(i)}$: a i-a cea mai mică pierdere (statistica de ordine i)
  - $\widehat{\mathrm{VaR}}_\alpha$ = cuantila empirică de ordin $(1-\alpha)$, interpolată liniar în poziția $1+(n-1)(1-\alpha)$ a pierderilor ordonate (convenția folosită peste tot)
  - $\widehat{\mathrm{ES}}_\alpha$ = media celor k_α pierderi $\geq \widehat{\mathrm{VaR}}_\alpha$, cu $k_\alpha \approx n\alpha$
  - Definiția prin integrală dă ultimei pierderi incluse ponderea $n\alpha - \lfloor n\alpha \rfloor$ ($\lfloor x \rfloor$: partea întreagă a lui x); media simplă a celor k_α pierderi coincide cu ea doar cînd $n\alpha$ este întreg
- Alegerea ferestrei n: estimarea pe 250 de zile reacționează mai repede, iar cea pe 1 000 de zile este mai precisă
  - Cu $n = 500$: 5 pierderi se află dincolo de VaR 1%
  - ES 2,5% este media a $k = 13$ pierderi ($n\alpha = 12{,}5$)
- Nicio pierdere mai mare decît cea mai rea din fereastră nu poate apărea în estimare
- **Efectul fantomă**: o zi de criză intră în fereastră, rămîne n zile, apoi iese și VaR scade brusc

Cornish–Fisher: corecția cuantilei Normale și limitele ei

- Ajustăm cuantila Normală pentru **asimetrie** $S = \mathbb{E}[(X-\mu)^3]/\sigma^3$ și **excesul de kurtosis** $K = \mathbb{E}[(X-\mu)^4]/\sigma^4 - 3$ Cornish & Fisher (1938)
  - $\tilde{z}_\alpha = z_\alpha + \frac{(z_\alpha^2-1)S}{6} + \frac{(z_\alpha^3-3z_\alpha)K}{24} - \frac{(2z_\alpha^3-5z_\alpha)S^2}{36}, \quad \mathrm{VaR}_\alpha = -(\mu+\sigma\tilde{z}_\alpha)$
  - $\tilde{z}_\alpha$: cuantila corectată, cuantila Normală $z_\alpha < 0$ plus un termen pentru asimetrie, unul pentru excesul de kurtosis și unul pentru pătratul asimetriei
  - Pentru $S = K = 0$ se obține VaR Normal
  - Pentru α sub circa 4% ($|z_\alpha| > \sqrt{3}$): $S < 0$ (coada stîngă a randamentelor mai lungă) sau $K > 0$ (cozi grele) împing $\tilde{z}_\alpha$ sub z_α și cresc VaR, iar termenul în S^2 acționează în sens opus
  - La $\alpha = 5\%$, termenul în K are semnul opus
- ES: media lui $-(\mu+\sigma\tilde{z}_u)$ pe $u \in (0,\alpha)$, calculată numeric
- O dezvoltare în jurul distribuției Normale: precisă doar pentru S și K **mici**
- Pentru K mare, transformarea $z \mapsto \tilde{z}$ nici măcar nu este monotonă (Seminarul 7, A6)
- Randamentele S&P 500: $S = -0{,}35$, $K = 10{,}7$: mult în afara acestui domeniu
  - $\mathrm{VaR}_{1\%}^{CF} = 6{,}08\%$ față de valoarea istorică 3,45%: termenul de kurtosis supraestimează puternic VaR

Cinci metode la diferite niveluri de risc (1/2)





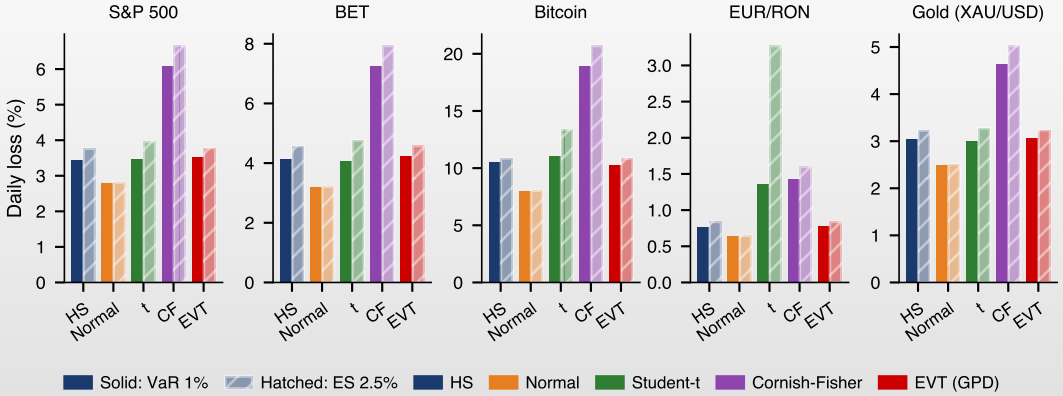
MFM_ch7_var_levels

Cinci metode la diferite niveluri de risc (2/2)

- Pierderile zilnice S&P 500 2000–2026, α de la 5% pînă la 0,1%
- În legendă, HS (historical simulation) este simularea istorică
- EVT (extreme value theory, teoria valorilor extreme): coada GPD (generalised Pareto distribution, distribuția Pareto generalizată), prezentată în secțiunea „Teoria valorilor extreme"
- VaR 0,1% (depășit în medie o zi la patru ani) este 7,22% istoric, 7,04% cu EVT, 8,58% cu Student-t și 15,06% cu Cornish–Fisher
- Distribuția Normală dă doar 3,72%, aproximativ jumătate din valoarea istorică
- Diferența dintre metode **crește** cînd α scade, mai mult pentru ES decît pentru VaR
- EVT și estimarea istorică coincid pînă la 0,5%, iar mai jos EVT extrapolează o coadă estimată

MFM_ch7_var_levels

Metodele comparate pe cinci active (1/2)



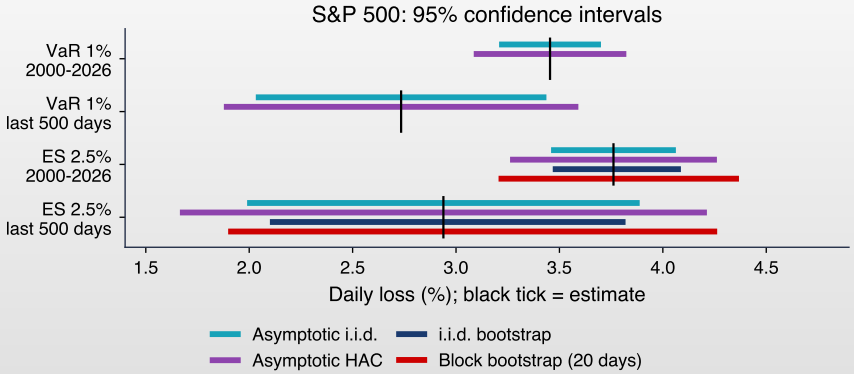
MFM_ch7_methods_assets

Metodele comparate pe cinci active (2/2)

- Barele pline arată $\mathrm{VaR}_{1\%}$, iar cele hașurate $\mathrm{ES}_{2{,}5\%}$
- Pierderi zilnice în %, pe selecțiile complete (toate cifrele în Anexă)
- Etichetele barelor: CF = Cornish–Fisher, t = Student-t; XAU/USD: prețul aurului în dolari americani pe uncie troy
- Distribuția Normală dă un VaR prea mic peste tot: pentru Bitcoin, $\mathrm{VaR}_{1\%}$ este 7,99%, față de 10,51% istoric
- Cornish–Fisher: supraestimează VaR, deoarece excesul de kurtosis depășește 7 în toate seriile (pentru BET, 7,25% față de 4,13% istoric)
- Student-t eșuează pentru EUR/RON: $\hat{\nu} = 1{,}25$ (dispersie infinită) dă un ES 2,5% nerealist de 3,27%, față de 0,84% istoric
  - Numeroasele variații aproape nule ale cursului de referință împing $\hat{\nu}$ în jos
- EVT rămîne apropiată de simularea istorică pentru VaR 1% în toate cele cinci serii

MFM_ch7_methods_assets

Precizia pentru S&P 500 (1/2)



MFM_ch7_precision

Precizia pentru S&P 500 (2/2)

- Intervale de 95% (bare), cu estimările marcate prin liniuțe negre
- Bootstrap: 2 000 de reeșantionări (Seminarul 7, B2)
- Tabelul complet este în ▸ Anexă
- Pe selecția completă, volatility clustering lărgește intervalul ES de la 0,60 pp (i.i.d.) la 1,00 pp (HAC)
- Bootstrap-ul arată același efect: 0,62 pp i.i.d., față de 1,16 pp pe blocuri
- Pe ultimele 500 de zile, ES 2,5% este media a doar 13 pierderi, iar intervalul HAC are lățimea de 2,55 pp

- Aceste intervale privesc VaR și ES **necondiționate**
- Riscul de mîine este o întrebare condiționată (secțiunea următoare)

MFM_ch7_precision

Erori standard pentru VaR și ES (1/2): VaR

- Eroarea standard (SE): abaterea standard a unui estimator de la o selecție la alta
- Un interval de 95% este aproximativ estimarea $\pm 1{,}96$ SE
- **VaR**: pierderi i.i.d. (independente și identic distribuite) cu densitatea f continuă și pozitivă în VaR_α
  - $\mathrm{SE}(\widehat{\mathrm{VaR}}_\alpha) \approx \frac{1}{f(\mathrm{VaR}_\alpha)} \sqrt{\frac{\alpha(1-\alpha)}{n}}$
  - $\sqrt{\alpha(1-\alpha)/n}$: SE a proporției de zile dincolo de VaR
  - Împărțirea la densitatea $f(\mathrm{VaR}_\alpha)$ o transformă într-o eroare pe scala pierderii
  - Densitatea în coadă este mică, deci SE este mare
  - Exemplu cu $\sigma = 1{,}2\%$ și $n = 500$: SE pentru $\mathrm{VaR}_{1\%}$ este de 0,20 puncte procentuale (pp) sub distribuția Normală
  - Sub o t_4 cu același σ, SE este de 0,43 pp
- t_4: distribuția Student-t cu 4 grade de libertate

Erori standard pentru VaR și ES (2/2): ES

- **ES** Chen (2008): funcția de influență $\mathrm{IF}(x) = \mathrm{VaR}_\alpha + (x - \mathrm{VaR}_\alpha)_+/\alpha - \mathrm{ES}_\alpha$, nemărginită în x
  - $\mathrm{IF}(x)$: efectul unei observații suplimentare x asupra estimării
  - IF crește nelimitat cu x, deci o singură pierdere extremă poate deplasa ES oricît de mult
- Eroarea standard
  - Dacă $\mathbb{E}[L^2] < \infty$: $\mathrm{SE}(\widehat{\mathrm{ES}}_\alpha) \approx \frac{1}{\alpha}\sqrt{\frac{\mathrm{Var}((L - \mathrm{VaR}_\alpha)_+)}{n}}$, unde Var este dispersia
  - Estimarea VaR nu adaugă niciun termen de ordinul întîi (Rockafellar–Uryasev)
  - Pentru cozi de tip Pareto, eroarea **relativă** scade ca $1/\sqrt{n\alpha}$: numărul de observații din coadă determină precizia Pele & Mazurencu-Marinescu-Pele (2026)
- Volatility clustering: zilele agitate tind să urmeze zilelor agitate, iar cele calme zilelor calme
  - Înlocuim dispersiile cu dispersiile de termen lung HAC (consistente la heteroscedasticitate și autocorelare) Newey & West (1987) ale lui $1\{L_t > \mathrm{VaR}_\alpha\}$ și $(L_t - \mathrm{VaR}_\alpha)_+$
  - Sau folosim un bootstrap pe blocuri (derivările: Anexă)

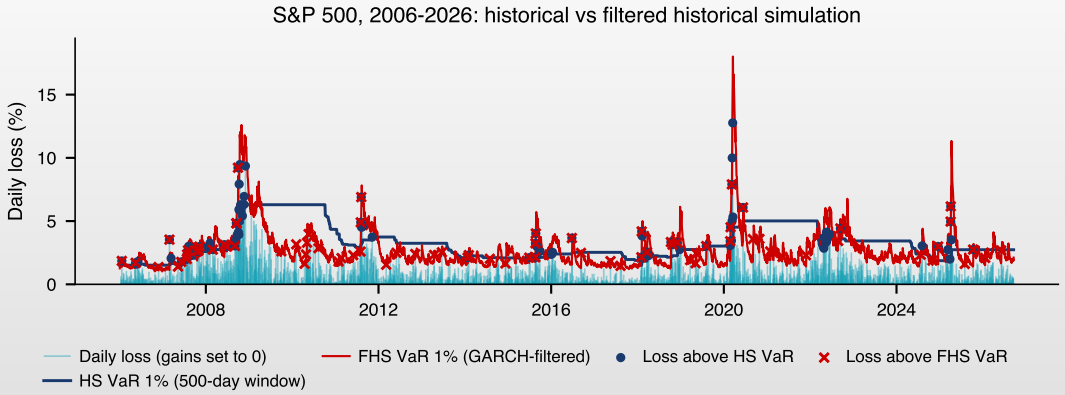
Bootstrap și HAC: cum se construiesc intervalele

- **Bootstrap** (i.i.d.): extragem cu revenire n pierderi din selecție și recalculăm $\widehat{\mathrm{VaR}}$ sau $\widehat{\mathrm{ES}}$
  - Repetăm de $B = 2\,000$ de ori
  - Intervalul de 95% merge de la cuantila de 2,5% la cea de 97,5% a celor B valori recalculate
- **Bootstrap pe blocuri mobile**: extragem blocuri de 20 de zile consecutive în locul zilelor izolate și alăturăm $n/20$ astfel de blocuri
  - Perioadele calme și cele agitate rămîn întregi în interiorul fiecărui bloc, deci fiecare reeșantionare păstrează volatility clustering
- **Dispersia de termen lung HAC** a unei serii y_t (aici $1\{L_t > \mathrm{VaR}_\alpha\}$ sau $(L_t - \mathrm{VaR}_\alpha)_+$):
  $\hat\gamma_0 + 2\sum_{j=1}^{m}\left(1 - \frac{j}{m+1}\right)\hat\gamma_j$
  - $\hat\gamma_j$: autocovarianța de selecție a lui y_t la lagul j, iar $\hat\gamma_0$ dispersia ei
  - Ponderile Bartlett $1 - j/(m+1)$ micșorează lagurile îndepărtate
  - Lagul $m = \lfloor 4(n/100)^{2/9} \rfloor$ ($m = 10$ pe selecția completă S&P 500)
  - Ea înlocuiește dispersia i.i.d. $\hat\gamma_0$ în formulele SE
  - Exemplu: $\hat\gamma_0 = 1$, $\hat\gamma_1 = 0{,}3$, celelalte $\hat\gamma_j = 0$, $m = 1$: dispersia de termen lung este $1 + 2 \times 0{,}5 \times 0{,}3 = 1{,}3$, deci SE crește de $\sqrt{1{,}3} \approx 1{,}14$ ori
- Calcul complet pentru BET: Seminarul 7, B1 (intervale i.i.d., HAC și bootstrap pe blocuri pentru VaR 1%)

Verificare rapidă: cîte zile sînt necesare pentru un VaR precis?

- Pierderi zilnice i.i.d. Normale, cu media 0 și $\sigma = 1\%$; nivelul $\alpha = 5\%$, deci $\mathrm{VaR}_{5\%} = 1{,}645\%$, iar densitatea în acest punct este $f(\mathrm{VaR}_{5\%}) = \varphi(1{,}645)/\sigma = 0{,}1031$
  - (a) Cu $n = 1\,000$ de zile, care este SE a $\mathrm{VaR}_{5\%}$ istoric și jumătatea lățimii intervalului de 95%?
  - (b) Cîte zile înjumătățesc această SE?
  - (c) Cu $n = 1\,000$, din cîte pierderi este media $\mathrm{ES}_{1\%}$ istoric și de ce este acesta un semnal de alarmă?
- Răspunsurile sînt în Anexă

Simularea istorică și simularea istorică filtrată: S&P 500 (1/2)



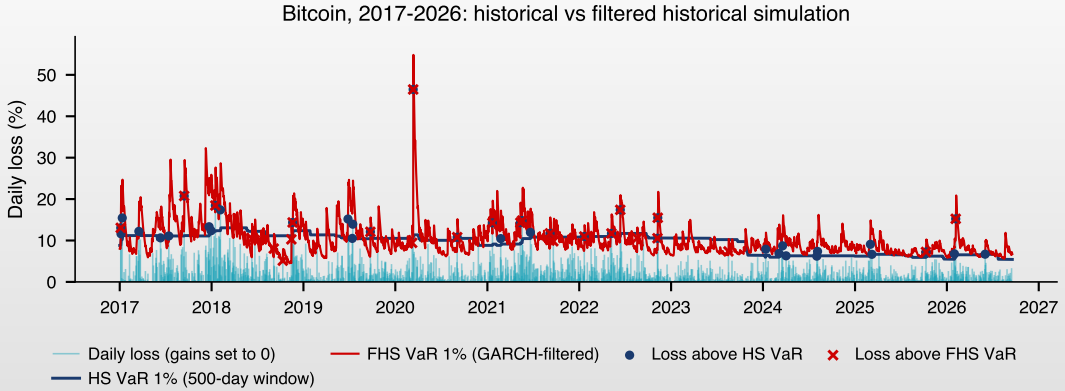
MFM_ch7_hs_fhs_sp500

Simularea istorică și simularea istorică filtrată: S&P 500 (2/2)

- $\mathrm{VaR}_{1\%}$ prognozat pentru ziua următoare
- GARCH re-estimat în fiecare ianuarie pe toate datele anterioare, deci fiecare prognoză folosește doar informația disponibilă la momentul ei
- Proporția zilelor cu pierdere peste VaR 1% în 2006–2026 (5 210 zile, cu ținta de 1%): 1,67% pentru simularea istorică pe 500 de zile, 1,54% pentru FHS și 2,34% pentru GARCH cu șocuri Normale
- Depășirile VaR istoric apar în **grupuri** (2008, 2020): fereastra reacționează cu luni de întîrziere
- VaR filtrat a atins 18,01% pe 2020-03-18 și distribuie depășirile mai uniform în timp (teste în Capitolul 8)

MFM_ch7_hs_fhs_sp500

Simularea istorică și simularea istorică filtrată: Bitcoin (1/2)



MFM_ch7_hs_fhs_btc

Simularea istorică și simularea istorică filtrată: Bitcoin (2/2)

- Aceeași construcție, cu prognoze din ianuarie 2017, 7 zile pe săptămînă
- Proporția zilelor cu pierderi peste VaR (3 548 de zile): 1,16% pentru simularea istorică, 0,76% pentru FHS și 1,58% pentru GARCH cu șocuri Normale
- VaR filtrat a atins 54,83% în martie 2020, după crahul din 2020-03-12: o pierdere log de 46,47%, adică o scădere a prețului de 37,17% (pierderile log și simple diferă la mișcări mari)
- Volatilitatea a scăzut după 2022, iar estimarea pe fereastra de 500 de zile se ajustează cu mare întîrziere

MFM_ch7_hs_fhs_btc

Simularea istorică filtrată (1/2): modelul

- Ideea Barone-Adesi, Giannopoulos & Vosper (1999), Hull & White (1998): distribuția empirică furnizează **forma** șocurilor, iar modelul GARCH (generalised autoregressive conditional heteroskedasticity, heteroscedasticitate condiționată autoregresivă generalizată) **scala** curentă
  - $r_t = \mu_t + \sigma_t z_t$, $\mu_t = c + \phi r_{t-1}$, $\sigma_t^2 = \omega + \alpha_1 (r_{t-1} - \mu_{t-1})^2 + \beta_1 \sigma_{t-1}^2$ (Capitolul 5, Bollerslev (1986); α_1 este un coeficient GARCH, nu nivelul α)
- Notațiile
  - μ_t: media condiționată, un AR(1) (model autoregresiv de ordinul 1) în randamentul anterior, cu constanta c și coeficientul ϕ
  - σ_t: volatilitatea condiționată
  - z_t: șoc i.i.d. cu media 0 și dispersia 1, cu distribuție nespecificată
  - $\omega > 0$: constanta
  - $\alpha_1 \geq 0$: reacția la pătratul surprizei de ieri
  - $\beta_1 \geq 0$: ponderea dispersiei de ieri
  - $\alpha_1 + \beta_1$: persistența
  - $\alpha_1 + \beta_1 < 1$ asigură o dispersie necondiționată finită (aproape de 1: șocurile se sting lent)

Simularea istorică filtrată (2/2): trei pași

- Pasul 1: estimăm modelul AR(1)-GARCH(1,1) prin cvasi-verosimilitate maximă (verosimilitate Normală, robustă la alte distribuții ale șocurilor)
- Pasul 2: reziduuri standardizate $\hat{z}_t = (r_t - \hat{\mu}_t)/\hat{\sigma}_t$: aproximativ i.i.d., dar tot cu cozi grele
- Pasul 3: rescalăm cu volatilitatea de mîine
  - $\mathrm{VaR}_{\alpha,t+1} = -\hat{\mu}_{t+1} + \hat{\sigma}_{t+1}\hat{\xi}_\alpha$, $\hat{\xi}_\alpha = -q_\alpha(\hat{z})$; $\quad \mathrm{ES}_{\alpha,t+1} = -\hat{\mu}_{t+1} - \hat{\sigma}_{t+1}\bar{z}_\alpha$
  - $\hat{\mu}_{t+1}$, $\hat{\sigma}_{t+1}$: prognozele modelului pentru mîine
  - $\hat{\xi}_\alpha$: cuantila empirică de ordin α a reziduurilor, cu semn schimbat
  - $\bar{z}_\alpha$: media reziduurilor $\hat{z}_t \leq q_\alpha(\hat{z})$

Exemplu numeric: prognoza pentru S&P 500 în următoarea zi de tranzacționare

- AR(1)-GARCH(1,1) pe 2000–2026: $\hat{\phi} = -0{,}053$, $\hat{\alpha}_1 = 0{,}1204$, $\hat{\beta}_1 = 0{,}8604$
- Persistența $\hat{\alpha}_1 + \hat{\beta}_1 = 0{,}981$
  - Prognozele pentru prima zi de tranzacționare de după 18 septembrie 2026: $\hat{\mu}_{t+1} = 0{,}056\%$, $\hat{\sigma}_{t+1} = 0{,}725\%$
  - Abaterea standard de selecție este 1,21%, deci $\hat{\sigma}_{t+1}$ indică o piață calmă
- Cuantila reziduurilor $\hat{\xi}_{1\%} = -q_{1\%}(\hat{z}) = 2{,}79$, peste $-z_{1\%} = 2{,}326$: șocurile filtrate păstrează cozi grele
  - $\mathrm{VaR}_{1\%,t+1} = -0{,}056 + 0{,}725 \times 2{,}791 = 1{,}97\%$; $\mathrm{ES}_{1\%,t+1} = 2{,}55\%$
  - Pasul ES: media reziduurilor mai mici sau egale cu $q_{1\%}(\hat{z})$, cu semn schimbat, este 3,594 (Normală: 2,665), deci $\mathrm{ES}_{1\%,t+1} = -0{,}056 + 0{,}725 \times 3{,}594 \approx 2{,}55\%$
- VaR 1% istoric necondiționat: 3,45%
- Estimările condiționate urmăresc evoluția pieței, cea necondiționată nu
- Cu GARCH cu șocuri Normale, VaR 1% pentru aceeași zi este 1,63% (toate cele cinci active: Anexă)

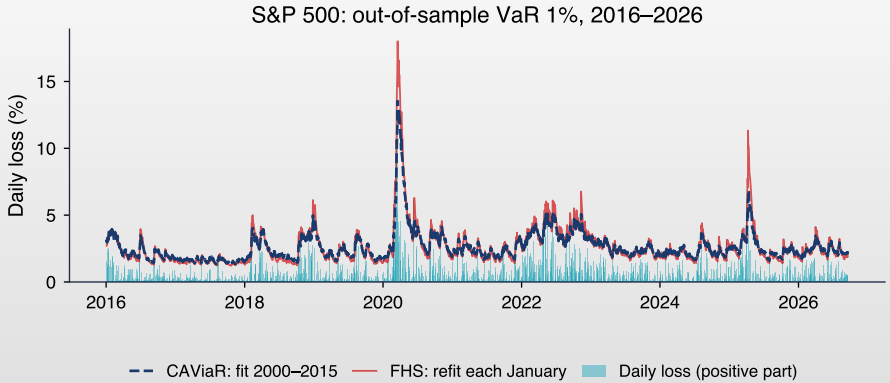
Incertitudinea prognozei VaR pentru ziua următoare

- Două intrări estimate: parametrii GARCH θ (prin $\hat{\sigma}_{t+1}$) și cuantila reziduurilor $\hat{\xi}_\alpha$ Francq & Zakoïan (2015)
  - Bootstrap pe reziduuri Christoffersen & Gonçalves (2005): simulăm traiectorii AR(1)-GARCH(1,1) cu $\hat{x}$ reeșantionate, re-estimăm pe fiecare traiectorie și prognozăm din istoria **originală** (algoritmul în Anexă)
- S&P 500, 999 de traiectorii bootstrap: $\mathrm{VaR}_{1\%}$ FHS $= 1{,}97\%$, cu intervalul de 90% $[1{,}90; 2{,}09]\%$
- Prima sursă de incertitudine: $\hat{\sigma}_{t+1} = 0{,}725$, cu intervalul $[0{,}708; 0{,}743]$
- A doua sursă: $\hat{\xi}_{1\%} = 2{,}79$, cu intervalul $[2{,}68; 2{,}88]$
  - Intervalul VaR dacă variază doar cuantila: $[1{,}89; 2{,}03]$
  - Intervalul VaR dacă variază doar σ_{t+1}: $[1{,}92; 2{,}02]$
  - Cuantila reziduurilor (circa 67 de reziduuri în coadă) este deci sursa principală de incertitudine
- GARCH cu șocuri Normale (1,63%) este mult sub interval: alegerea modelului pentru coadă contează mai mult decît eroarea de estimare a unui model dat

Modelarea directă a cuantilei: CAViaR

- CAViaR (Conditional Autoregressive Value at Risk, valoarea la risc condițională autoregresivă) Engle & Manganelli (2004): cuantila urmează propria recursie
- Specificația SAV:
  - $\mathrm{VaR}_t = \beta_0 + \beta_1 \mathrm{VaR}_{t-1} + \beta_2 |r_{t-1}|, \quad q_t = -\mathrm{VaR}_t$
  - SAV (symmetric absolute value, valoarea absolută simetrică): VaR de azi este suma dintre o constantă β_0, o fracțiune $\beta_1 \in (0,1)$ din VaR de ieri (persistența) și $\beta_2 > 0$ ori randamentul absolut de ieri
  - O mișcare mare, în orice sens, crește VaR
  - q_t: cuantila randamentului
- **Regresie cuantilă** Koenker & Bassett (1978): minimizăm pierderea pinball, fără ipoteze asupra distribuției șocurilor
  - $\hat{\beta} = \arg\min_\beta \sum_t (\alpha - 1\{r_t < q_t(\beta)\})(r_t - q_t(\beta))$
  - $\arg\min_\beta$: valoarea lui $\beta = (\beta_0, \beta_1, \beta_2)$ care minimizează suma
  - $q_t(\beta)$: traiectoria cuantilei dată de β
  - Elicitabilitatea este folosită direct în estimare (setările optimizării în Anexă)
- S&P 500, $\alpha = 1\%$, estimat pe 2000–2015 (4 024 de zile): $\hat{\beta}_0 = 0{,}090$, $\hat{\beta}_1 = 0{,}897$, $\hat{\beta}_2 = 0{,}246$
  - Timpul de înjumătățire al unui șoc asupra VaR: $\ln 0{,}5 / \ln \hat{\beta}_1 = 6{,}4$ zile
- CAViaR reacționează liniar la $|r_{t-1}|$, GARCH la r_{t-1}^2

CAViaR față de simularea istorică filtrată în afara eșantionului (1/2)



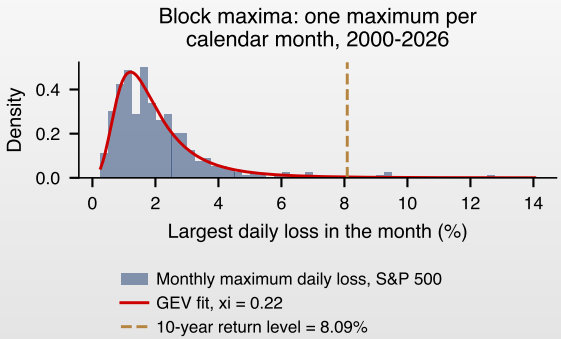
MFM_ch7_caviar

CAViaR față de simularea istorică filtrată în afara eșantionului (2/2)

- S&P 500, 2016–2026 (2 693 de zile): CAViaR cu parametrii fixați pe 2000–2015
- FHS re-estimat în fiecare ianuarie (o schemă diferită de re-estimare)
- Rata depășirilor VaR 1%: 1,30% (35 zile) pentru CAViaR, 1,30% (35) pentru FHS și 1,41% (38) pentru simularea istorică pe 500 de zile
- Pierderea pinball medie (o valoare mai mică este preferabilă), în aceeași ordine: 0,039, 0,037 și 0,052
- Criza COVID-19, 20 februarie – 30 aprilie 2020 (50 de zile), pentru CAViaR, FHS și simularea istorică:
  - numărul de depășiri: 6, 3 și 9
  - VaR maxim: 13,5%, 18,0% și 4,5%
- După un crah, VaR FHS crește cel mai mult
- Numărul de depășiri nu este suficient pentru a ierarhiza modelele: semnificația se testează în Capitolul 8

MFM_ch7_caviar

Maximele lunare ale pierderilor S&P 500



- 321 de luni calendaristice, 2000–2026
- GEV estimată prin verosimilitate maximă
- Estimări: $\hat{\xi} = 0{,}22$ (tip Fréchet, deci o coadă de tip putere), $\hat{\mu} = 1{,}37$, $\hat{\sigma} = 0{,}79$
- Nivelul de revenire la 10 ani este 8,09%, iar la 30 de ani 10,95%
- Cel mai mare maxim lunar observat: 12,77%
- Maximele lunare nu dau direct un VaR zilnic: conversia presupune zile independente, ipoteză încălcată de volatility clustering (▸ Anexă)
- Reținerea unei singure valori pe lună irosește informație: metoda următoare folosește toate pierderile mari

MFM_ch7_gev

Maxime pe blocuri și distribuția GEV (1/2)

- Împărțim selecția în blocuri de n zile
- Păstrăm maximul fiecărui bloc $M_n = \max(L_1, \ldots, L_n)$
  - Teorema Fisher–Tippett–Gnedenko Fisher & Tippett (1928), Gnedenko (1943): dacă $(M_n - b_n)/a_n$ are o limită nedegenerată pentru pierderi i.i.d., aceasta este distribuția generalizată a valorilor extreme (GEV, generalised extreme value)
  - $a_n > 0$, b_n: constante de normalizare, care rescalează și recentrează maximul
- Funcția de repartiție GEV: probabilitatea ca maximul unui bloc să fie cel mult x
  - $H_\xi(x) = \exp\left\{-\left(1 + \xi \frac{x-\mu}{\sigma}\right)^{-1/\xi}\right\}$, $1 + \xi(x-\mu)/\sigma > 0$ ($\xi = 0$: $\exp\{-e^{-(x-\mu)/\sigma}\}$)
  - μ: poziția (unde se află maximele)
  - $\sigma > 0$: scala (dispersia lor)
  - ξ: forma (tipul cozii, pe slide-ul GEV (2/2); simbolurile refolosite: Anexă)

Maxime pe blocuri și distribuția GEV (2/2)

- **Forma** ξ determină tipul cozii
  - $\xi > 0$: Fréchet, coadă de tip putere cu tail index-ul $1/\xi$ (randamentele financiare)
  - $\xi = 0$: domeniul Gumbel, cozi de tip exponențial (de ex. distribuția Normală, distribuția lognormală)
  - $\xi < 0$: Weibull, coadă mărginită
- **Nivelul de revenire** pentru k blocuri: nivelul depășit în medie o dată la k blocuri, $H_\xi^{-1}(1 - 1/k)$, cu H_ξ^{-1} funcția cuantilă a GEV
- În finanțe modelăm **doar coada** Embrechts, Klüppelberg & Mikosch (1997), Longin (2000)

Depășiri de prag și distribuția GPD (1/2)

- Fixăm un prag ridicat u
- Modelăm **excesele** $Y = L - u$, condiționat de $L > u$
  - Teorema Pickands–Balkema–de Haan Pickands (1975), Balkema & de Haan (1974): pentru o clasă largă de distribuții, cînd u se apropie de capătul drept al distribuției, excesele urmează o distribuție Pareto generalizată
- Funcția de repartiție GPD: probabilitatea ca un exces să fie cel mult y
  - $G_{\xi,\beta}(y) = 1 - (1 + \xi y/\beta)^{-1/\xi}$ ($\xi \neq 0$), $1 - e^{-y/\beta}$ ($\xi = 0$)
  - Domeniul: $y \geq 0$ și, dacă $\xi < 0$, $y < -\beta/\xi$
  - Scala $\beta > 0$: mărimea tipică a unui exces
  - Forma ξ: aceeași ca la GEV, iar $\xi > 0$ înseamnă coadă grea

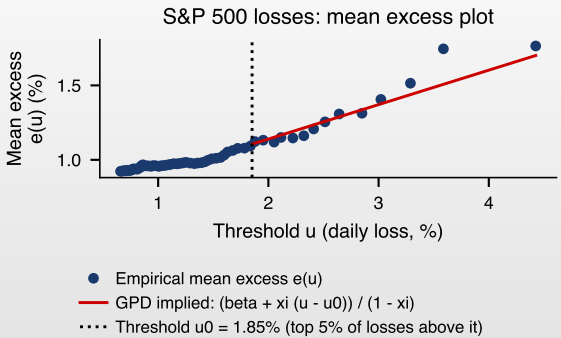
Depășiri de prag și distribuția GPD (2/2)

- Estimatorul cozii cu N_u depășiri din n observații McNeil, Frey & Embrechts (2015)
  - $\widehat{\mathrm{VaR}}_\alpha = u + \frac{\hat\beta}{\hat\xi}\left[\left(\frac{n}{N_u}\,\alpha\right)^{-\hat\xi} - 1\right]$, $\quad \widehat{\mathrm{ES}}_\alpha = \frac{\widehat{\mathrm{VaR}}_\alpha}{1-\hat\xi} + \frac{\hat\beta - \hat\xi u}{1-\hat\xi}$ ($\alpha < N_u/n$, $\hat\xi \neq 0$, iar ES cere $\hat\xi < 1$)
  - În cuvinte: VaR este pragul u plus cuantila GPD a excesului care lasă probabilitatea α în coadă
  - N_u/n este proporția zilelor peste u
  - ES adaugă la VaR excesul mediu de dincolo de VaR, care crește cu $\hat\xi$
  - $\hat\xi \geq 1$ înseamnă medie infinită
- Compromis deplasare–dispersie: un u mic încalcă teorema limită, un u mare lasă puține depășiri

Alegerea pragului: funcția de exces mediu

- **Funcția de exces mediu**: $e(u) = \mathbb{E}[L - u \mid L > u]$
- Empiric: media excesele peste u, reprezentată în funcție de u
- Pentru o coadă GPD, $e(u)$ este **liniară** în u
  - $e(u) = \dfrac{\beta + \xi(u - u_0)}{1 - \xi}$ pentru $u \geq u_0$, finită doar dacă $\xi < 1$
  - Panta $\xi/(1-\xi)$ este pozitivă pentru cozi grele și nulă pentru cozi exponențiale
  - u_0: cel mai mic prag peste care este valabilă GPD
  - β: scala GPD în u_0
- Regula practică: alegem u acolo unde graficul devine aproximativ liniar
- Verificăm stabilitatea lui $\hat{\xi}$ pentru mai multe praguri
- Estimatorul Hill din Capitolul 1 Hill (1975) estimează același tail index $1/\xi$

Graficul excesului mediu: S&P 500



- Pragurile sînt depășite de 20% pînă la 0,5% dintre pierderile zilnice
- Linia roșie: GPD estimată pe cele mai mari 5%
- Excesul mediu crește cu u: o coadă grea (de tip Fréchet), nu linia orizontală a unei cozi exponențiale
- Pragul ales $u_0 = 1{,}85\%$ lasă $N_u = 336$ depășiri
- Excesul mediu empiric în jurul lui u_0 este 1,09% (valoarea implicată de GPD: $\hat{\beta}/(1-\hat{\xi}) = 1{,}11\%$, deoarece GPD este estimată prin verosimilitate maximă, nu prin potrivirea acestei medii)
- Panta GPD: $\hat{\xi}/(1-\hat{\xi}) = 0{,}23$
- Dincolo de VaR 1% punctele au o dispersie mare: fiecare este media a foarte puține pierderi

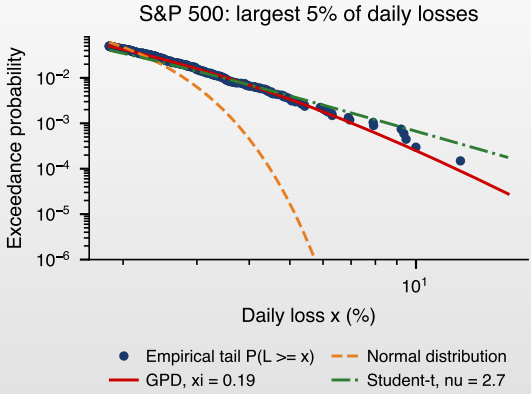
MFM_ch7_mean_excess

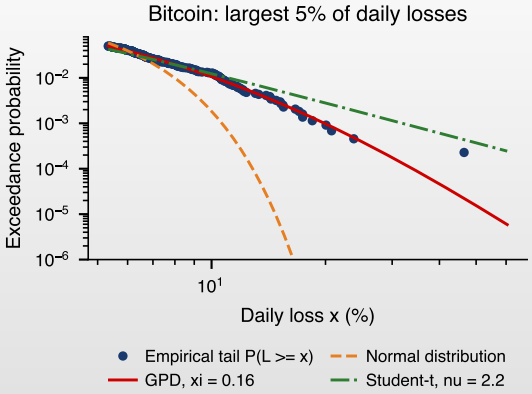
Estimatorul GPD al cozii pe S&P 500, pas cu pas

- Intrări: $n = 6\,717$ pierderi zilnice, pragul $u = 1{,}852\%$, $N_u = 336$ depășiri; estimări de verosimilitate maximă $\hat{\xi} = 0{,}188$, $\hat{\beta} = 0{,}898$
- Pasul 1: $\dfrac{n}{N_u}\,\alpha = \dfrac{67{,}17}{336} = 0{,}200$, proporția depășirilor aflate dincolo de VaR 1%
- $0{,}200^{-\hat{\xi}} = 1{,}353$
- Pasul 2: $\widehat{\mathrm{VaR}}_{1\%} = u + \dfrac{\hat{\beta}}{\hat{\xi}}\,(1{,}353 - 1) = 1{,}852 + 4{,}779 \times 0{,}353 \approx 3{,}54\%$
- Pasul 3: $\widehat{\mathrm{ES}}_{1\%} = \dfrac{3{,}540}{0{,}812} + \dfrac{0{,}898 - 0{,}188 \times 1{,}852}{0{,}812} = \dfrac{3{,}540 + 0{,}550}{0{,}812} \approx 5{,}04\%$
- Valorile istorice, pentru comparație: 3,45% și 5,01% (estimările pentru toate cele cinci serii: Anexă)

MFM_ch7_gpd_tail

Cozi GPD: S&P 500 și Bitcoin (1/2)





MFM_ch7_gpd_tail

Cozi GPD: S&P 500 și Bitcoin (2/2)

- Scală log–log: probabilitatea unei pierderi zilnice peste x, pentru cele mai mari 5% dintre pierderi
- Coada Normală cade mult sub date, iar coada Student-t este apropiată de GPD
- S&P 500: $\hat{\xi} = 0{,}19$ (SE 0,065), deci tail index-ul este 5,3, iar $\mathrm{VaR}_{\mathbf{1\%}} = 3{,}54\%$
- Bitcoin: $\hat{\xi} = 0{,}16$ (SE 0,078) și $\mathrm{VaR}_{\mathbf{1\%}} = 10{,}23\%$ (toate cele cinci serii: Anexă)
- SE$(\hat{\xi}) = (1 + \hat{\xi})/\sqrt{N_u}$ presupune depășiri independente
- Gruparea depășirilor în timp o subestimează (slide-ul următor)

MFM_ch7_gpd_tail

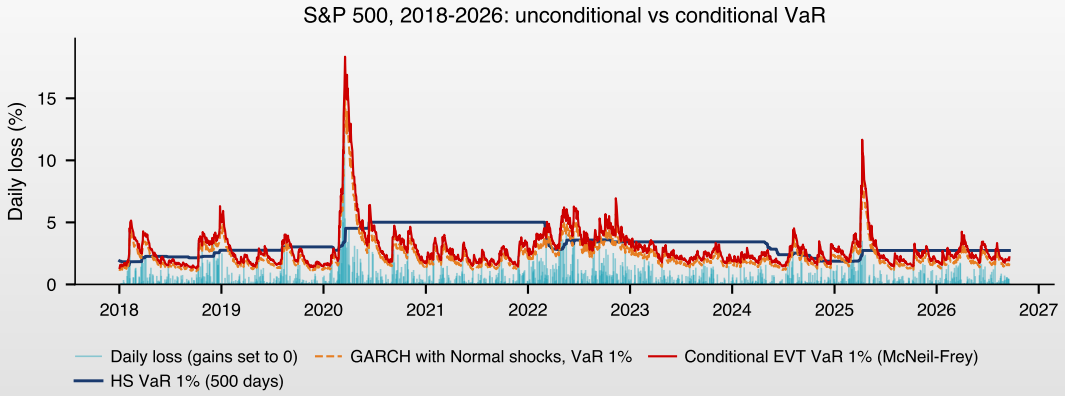
Extreme grupate: indicele extremal

- Pierderi staționare cu extreme grupate: dacă $nP(L > u_n) \to \tau$, atunci $P(M_n \leq u_n) \to e^{-\theta\tau}$, $\theta \in (0, 1]$ Embrechts, Klüppelberg & Mikosch (1997)
  - u_n: un prag care crește cu n
  - τ: numărul mediu de depășiri ale lui u_n în n zile
  - M_n: maximul celor n pierderi
  - θ: indicele extremal
  - $1/\theta$: mărimea medie a unui grup de extreme
  - Pentru date i.i.d., $\theta = 1$
  - n zile dependente se comportă ca $n\theta$ zile independente
- S&P 500, pragul GPD $u = 1{,}85\%$ ($N = 336$ depășiri): estimatorul pe intervale Ferro & Segers (2003) dă $\hat{\theta} = 0{,}19$, adică 62 de grupuri de cîte 5,4 depășiri în medie
  - GPD estimată pe maximele grupurilor: $\hat{\xi} = 0{,}152$ (SE 0,146), față de 0,188 (SE 0,065) pe toate depășirile
  - $\hat{\xi}$ rămîne pozitiv, dar intervalul lui de 95% include acum 0
- Pe reziduurile GARCH standardizate, $\hat{\theta} = 0{,}99$: filtrarea GARCH elimină gruparea extremelor (estimatorul și separarea grupurilor: ▸ Anexă)
- De aceea, EVT condiționată estimează GPD pe reziduurile filtrate

EVT condiționată (McNeil și Frey)

- McNeil & Frey (2000): aceiași pași ca la FHS, cu un singur pas schimbat
- Filtrul: AR(1)-GARCH(1,1) prin cvasi-verosimilitate maximă, reziduuri $\hat{z}_t$, prognoze $\hat{\mu}_{t+1}$, $\hat{\sigma}_{t+1}$ (ca la FHS)
- **Pasul cozii**: în locul cuantilei empirice a lui $-\hat{z}$, estimăm o GPD pe cele mai mari 10% valori și luăm VaR-ul ei $\hat{z}_\alpha^{GPD}$ și ES $\hat{e}_\alpha^{GPD}$
  - $\mathrm{VaR}_{\alpha,t+1} = -\hat{\mu}_{t+1} + \hat{\sigma}_{t+1}\hat{z}_\alpha^{GPD}, \qquad \mathrm{ES}_{\alpha,t+1} = -\hat{\mu}_{t+1} + \hat{\sigma}_{t+1}\hat{e}_\alpha^{GPD}$
  - $\hat{z}_\alpha^{GPD}$ ia locul lui $\hat{\xi}_\alpha$ din formula FHS: aceeași cuantilă a pierderilor reziduale, citită acum din coada GPD estimată pentru $-\hat{z}$
- O coadă parametrică netedă, extrapolată dincolo de date: avantajul apare mai ales în extremitatea cozii (VaR 0,5%, VaR 0,1%), unde există doar cîteva reziduuri
- S&P 500, prima zi de tranzacționare de după 18 septembrie 2026: VaR 1% = 2,03% cu EVT condiționată, în intervalul bootstrap FHS [1,90; 2,09]%

EVT condiționată pentru S&P 500 (1/2)



MFM_ch7_cond_evt

EVT condiționată pentru S&P 500 (2/2)

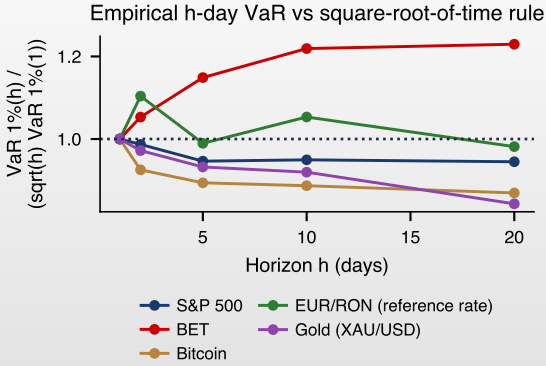
- $\mathrm{VaR}_{1\%}$ prognozat pentru ziua următoare, 2018–2026, cu parametrii re-estimați în fiecare ianuarie
- Rata depășirilor (2 190 de zile, cu ținta de 1%): 1,23% pentru EVT condiționată, 2,42% pentru GARCH cu șocuri Normale și 1,60% pentru simularea istorică pe 500 de zile
- GARCH cu șocuri Normale urmărește corect creșterile și scăderile riscului, dar VaR-ul lui este prea mic (2,42% depășiri față de 1%)
- EVT condiționată păstrează dinamica și corectează nivelul: contează coada șocurilor, nu doar scala lor

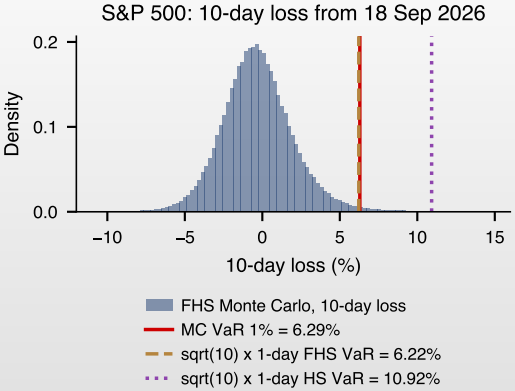
MFM_ch7_cond_evt

Regula rădăcinii pătrate a timpului: ipoteze și limite

- Pierderi zilnice i.i.d. $N(0, \sigma^2)$: $\mathrm{VaR}_\alpha^{(h)} = \sqrt{h}\,\mathrm{VaR}_\alpha^{(1)}$, $\mathrm{ES}_\alpha^{(h)} = \sqrt{h}\,\mathrm{ES}_\alpha^{(1)}$
- Basel 1996 a permis $\sqrt{10} = 3{,}162$ Basel Committee (1996)
  - $\mathrm{VaR}_\alpha^{(h)}$, $\mathrm{ES}_\alpha^{(h)}$: măsurile pentru pierderea însumată pe h zile
  - Abaterea standard a unei sume de h termeni i.i.d. crește ca $\sqrt{h}$
  - Cere medie zero, fără autocorelație, volatilitate constantă și șocuri Normale
  - Fiecare ipoteză este încălcată de date (Capitolele 1, 2, 5)
- **Autocorelația** (variance ratio $\mathrm{VR}(h)$, Capitolul 2)
  - $\mathrm{Var}(r_{t+1} + \cdots + r_{t+h}) = h\sigma^2\,\mathrm{VR}(h)$, cu $\mathrm{VR}(h)$ dispersia sumei pe h zile împărțită la h ori dispersia zilnică
  - $\mathrm{VR} = 1$ fără autocorelație
  - $\mathrm{VR} > 1$ cu autocorelație pozitivă, iar atunci $\sqrt{h}$ **subestimează** riscul pe h zile
- **Volatility clustering**: volatilitatea revine la medie pe h zile
  - Dacă volatilitatea de azi este scăzută, regula $\sqrt{h}$ dă un risc prea mic
  - Dacă volatilitatea de azi este ridicată, regula dă un risc prea mare
- **Cozi grele**: pentru șocuri i.i.d. cu tail index $a > 2$, cuantila extremă a unei sume crește ca $h^{1/a} < \sqrt{h}$ Daníelsson (2011)
  - a: tail index-ul, adică $P(L > x)$ scade ca x^{-a}
  - Un a mai mic înseamnă o coadă mai grea
  - Cu salturi, regula poate evalua foarte greșit riscul pe mai multe zile Daníelsson & Zigrand (2006)

Regula rădăcinii pătrate în date (1/2)





MFM_ch7_horizon

Regula rădăcinii pătrate în date (2/2)

- Stînga: $\mathrm{VaR}_{\mathbf{1\%}}$ empiric al pierderilor suprapuse pe h zile, împărțit la $\sqrt{h}$ ori valoarea pe o zi (sume suprapuse: mult mai puține observații independente)
- Dreapta: Monte Carlo filtrat (MC în legendă), 200 000 de traiectorii
- La $h = 10$, raportul este 1,22 pentru BET (autocorelația de ordin 1: 0,109) și 1,05 pentru EUR/RON: aici $\sqrt{h}$ este prea mic
- Raportul este 0,95 pentru S&P 500, 0,92 pentru aur și 0,89 pentru Bitcoin: aici regula este conservatoare
- $\mathrm{VaR}_{\mathbf{1\%}}$ pe 10 zile pentru S&P 500 este 6,29% prin Monte Carlo filtrat, 6,22% ca $\sqrt{10}\times$ VaR filtrat pe o zi și 10,92% ca $\sqrt{10}\times$ VaR istoric pe o zi
- Diferența mare vine din trecerea de la VaR necondiționat la VaR condiționat

MFM_ch7_horizon

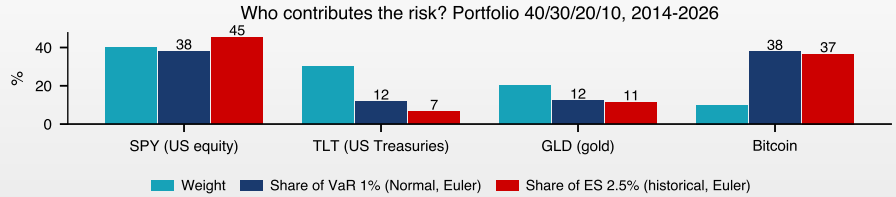
Monte Carlo filtrat pe h zile

- Simulăm multe traiectorii viitoare din modelul estimat și citim VaR și ES din pierderile simulate: tratează deodată autocorelația, volatility clustering și cozile grele, precum și cîștigurile neliniare (opțiuni)
- Pentru fiecare traiectorie $j = 1, \ldots, M$ (M: numărul de traiectorii simulate)
  - extragem $z_{t+1}^{(j)}, \ldots, z_{t+h}^{(j)}$ cu revenire din reziduurile standardizate $\hat{z}$
  - actualizăm $\sigma^{(j)}$ și $r^{(j)}$ zi de zi cu recursia AR(1)-GARCH(1,1), pornind de la starea de azi
  - agregăm: $L^{(j)} = -\sum_{i=1}^{h} r_{t+i}^{(j)}$, pierderea pe h zile a traiectoriei j (i: ziua din traiectorie)
- $\widehat{\mathrm{VaR}}_\alpha$, $\widehat{\mathrm{ES}}_\alpha$ = estimările istorice pe cele M pierderi simulate
- Eroarea de simulare scade ca $1/\sqrt{M}$

Verificare rapidă: de la o zi la zece zile

- Un birou de tranzacționare raportează $\mathrm{VaR}_{1\%} = 2\%$ pe o zi, din pierderi i.i.d. Normale cu media 0
  - (a) Cît este $\mathrm{VaR}_{1\%}$ pe 10 zile după regula rădăcinii pătrate a timpului?
  - (b) Randamentele se dovedesc pozitiv autocorelate, cu $\mathrm{VR}(10) = 1{,}21$, și rămîn Normale. Cît este acum $\mathrm{VaR}_{1\%}$ pe 10 zile?
  - (c) Fără autocorelație, dar volatilitatea GARCH de azi este mult sub nivelul ei de termen lung. Este $\sqrt{10}\times$ VaR condiționat pe o zi prea mic sau prea mare și de ce?
- Răspunsurile sînt în Anexă

Contribuțiile activelor la risc



- SPY (ETF pe S&P 500; ETF: exchange-traded fund, fond tranzacționat la bursă) 40%, TLT (ETF pe obligațiuni de stat americane pe termen lung) 30%, GLD (ETF pe aur) 20%, Bitcoin 10%, cu rebalansare zilnică
- Randamente simple în 3 017 zile comune, 2014–2026
- Culorile: turcoaz pentru ponderi, albastru pentru cotele din $\mathrm{VaR}_{1\%}$ Normal, roșu pentru cotele din $\mathrm{ES}_{2,5\%}$ istoric
- $\mathrm{VaR}_{1\%}$ al portofoliului: 1,77%, față de 3,11% nediversificat (-43%)
- $\mathrm{ES}_{2,5\%}$ al portofoliului: 2,15%, față de 3,87% nediversificat (-44%)
- Bitcoin: 10% din capitalul investit, 37,8% din VaR și 36,6% din ES
- TLT: 30% din capital, doar 6,5% din ES (a pierdut 0,47% în zilele cele mai rele ale portofoliului)

MFM_ch7_components

VaR de portofoliu și alocarea Euler (1/2)

- Cadrul: pierderea portofoliului $L_p = -w^\top R$
  - w: vectorul ponderilor
  - R: vectorul randamentelor simple (randamentele simple se adună între active), cu matricea de covarianță Σ
  - σ_i: abaterea standard a activului i
- Randamente cu distribuție Normală, neglijînd media: VaR este un multiplu al abaterii standard a portofoliului
  - $\mathrm{VaR}_\alpha(L_p) = z_{1-\alpha}\sigma_p, \quad \sigma_p = \sqrt{w^\top \Sigma w}$; $z_{1-\alpha} = -z_\alpha > 0$
  - Pentru ponderi nenegative $w \geq 0$, VaR nediversificat $\sum_i z_{1-\alpha} w_i \sigma_i$ (suma VaR-urilor individuale) este mai mare, cu excepția corelațiilor egale cu 1

VaR de portofoliu și alocarea Euler (2/2)

- **VaR marginal**: variația VaR al portofoliului la o creștere cu o unitate a ponderii w_i
  - $\partial \mathrm{VaR}_\alpha / \partial w_i = z_{1-\alpha}(\Sigma w)_i / \sigma_p$; $(\Sigma w)_i$: covarianța activului i cu portofoliul
- **VaR pe componente** $C_i = w_i \, \partial \mathrm{VaR}_\alpha / \partial w_i$: partea din VaR atribuită activului i
  - Teorema lui Euler pentru o funcție omogenă de grad 1: $\sum_i w_i \, \partial \rho / \partial w_i = \rho$, deci componentele se adună, $\sum_i C_i = \mathrm{VaR}_\alpha$ Tasche (2008)
- ES, fără ipoteză de distribuție (pierderi continue): pierderea medie a activului i în zilele din coada portofoliului
  - $C_i^{ES} = \mathbb{E}[-w_i R_i \mid L_p \geq \mathrm{VaR}_\alpha(L_p)]$, $\quad \sum_i C_i^{ES} = \mathrm{ES}_\alpha(L_p)$
  - Estimarea istorică: media pe zilele din coadă
  - Un C_i negativ înseamnă că activul **acoperă** riscul portofoliului

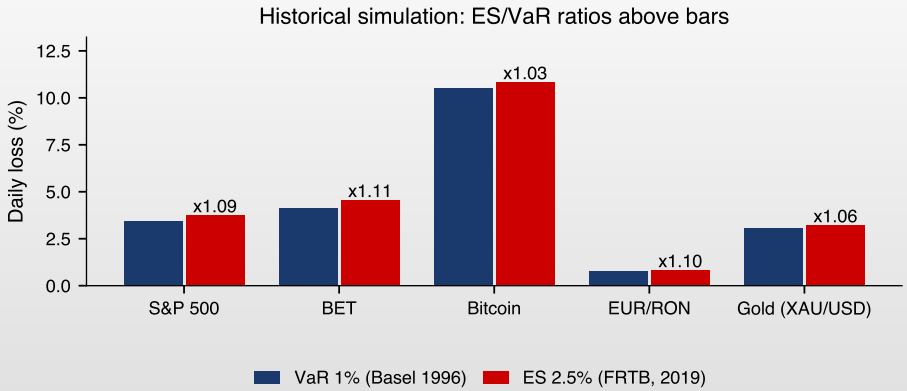
Portofoliul cu ES minim: o problemă de programare liniară

- Cu N scenarii istorice R_s, funcția Rockafellar–Uryasev devine o problemă de **programare liniară** Rockafellar & Uryasev (2000)
  - $\min_{w,v,u}\ v + \frac{1}{\alpha N}\sum_s u_s$ cu restricțiile $u_s \geq -w^\top R_s - v$, $u_s \geq 0$, $\sum_i w_i = 1$, $w \geq 0$
  - $s = 1, \ldots, N$: scenariile
  - u_s: o variabilă auxiliară egală, la optim, cu excesul $(-w^\top R_s - v)_+$ al scenariului s peste pragul v
  - v optim este VaR al portofoliului
  - Restricții: capital investit integral ($\sum_i w_i = 1$), fără vînzări în lipsă ($w \geq 0$)
- Aceleași patru active, 3 017 zile comune, $\alpha = 2{,}5\%$: ponderile optime sînt 31% SPY, 44% TLT, 25% GLD și 0% Bitcoin
  - $\mathrm{ES}_{2{,}5\%} = 1{,}67\%$, față de 2,15% pentru portofoliul 40/30/20/10
- Portofoliul de dispersie minimă fără vînzări în lipsă: 35% SPY, 43% TLT, 22% GLD, 0% Bitcoin, cu $\mathrm{ES}_{2{,}5\%} = 1{,}67\%$
- Pentru aceste active cele două criterii aproape coincid, dar ele diverg pentru opțiuni și credit
- Mai multe portofolii pot atinge același minim: raportăm soluția împreună cu scenariile ei din coadă

VaR ajustat la lichiditate

- VaR presupune că pozițiile pot fi vîndute la prețul mediu
- În realitate, lichidarea costă jumătate din diferența dintre prețul cerut și cel oferit (spread)
- Bid: cel mai bun preț oferit de cumpărători; ask: cel mai bun preț cerut de vînzători; mid $= (\text{bid} + \text{ask})/2$
  - **Spread relativ** $S = (\text{ask} - \text{bid})/\text{mid}$
  - Se lărgește tocmai în perioadele de scădere a pieței
- Bangia, Diebold, Schuermann & Stroughair (2001): $\mathrm{LVaR}_\alpha = \mathrm{VaR}_\alpha + \frac{1}{2}(\mu_S + k\,\sigma_S)$
  - μ_S, σ_S: media și abaterea standard a spread-ului
  - k: un multiplicator (aici S este spread-ul, nu asimetria)
  - VaR plus costul traversării unei jumătăți din spread-ul în condiții de stres, cu k abateri standard peste media lui
- Banca Transilvania, poziție de 1 milion RON: VaR 1% istoric pe o zi, pe ultimele 496 de zile, este 3,16%
- Cu valorile presupuse $\mu_S = 0{,}5\%$, $\sigma_S = 0{,}3\%$ și $k = 3$: $\mathrm{LVaR} = 3{,}86\%$ (+22%)
  - În bani: VaR $\approx$ 31 581 RON, costul spread-ului $\frac{1}{2}(0{,}5 + 3 \times 0{,}3)\% = 0{,}70\% \to$ 7 000 RON, LVaR $\approx$ 38 581 RON
- Pozițiile mari influențează și prețul (lichiditate endogenă): reglementarea tratează acest lucru prin orizonturi mai lungi

VaR 1% față de ES 2,5% pe cinci active (1/2)



MFM_ch7_basel

VaR 1% față de ES 2,5% pe cinci active (2/2)

- Simulare istorică, pierderi zilnice, selecțiile complete
- Numărul de deasupra fiecărei perechi: $\mathrm{ES}_{\mathbf{2,5\%}}/\mathrm{VaR}_{\mathbf{1\%}}$
- Reperul Normal: raportul 2,338/2,326 $\approx$ 1,005, deci același capital pentru cozi subțiri
- Student-t: raportul este 1,01 la $\nu = 30$ și 1,07 la $\nu = 4$
- Raportul în date: 1,09 pentru S&P 500, 1,11 pentru BET, 1,03 pentru Bitcoin, 1,10 pentru EUR/RON și 1,06 pentru aur
- Trecerea de la VaR 1% la ES 2,5% crește măsura pe o zi cu 3–11%
- ES 2,5% nu depășește neapărat VaR 1%: inegalitatea $\mathrm{ES}_\alpha \geq \mathrm{VaR}_\alpha$ este garantată doar la același nivel α
- Calibrarea pe perioada de stres și orizonturile de lichiditate au un efect mai mare: Seminarul 7, C2

MFM_ch7_basel

Termenii FRTB: birouri, orizonturi și perioada de stres

- **MAR**: capitolul despre riscul de piață din cadrul Basel consolidat; MAR12, MAR33.12 etc. sînt paragrafele lui
- **Trading desk** (birou de tranzacționare): un grup bine delimitat de traderi și conturi de tranzacționare, cu o singură strategie de afaceri
- În FRTB, modelele interne se aprobă separat pentru fiecare birou (MAR12)
- **Abordarea bazată pe modele interne**: banca își calculează capitalul pentru riscul de piață cu propriul model ES, aprobat de autoritatea de supraveghere, în locul formulelor standardizate
- **Cerințele de fonduri proprii**: termenul juridic din UE pentru capitalul pe care banca trebuie să îl dețină
- **Orizontul de lichiditate** (LH): timpul necesar pentru a închide sau acoperi o poziție pe o piață în criză fără a-i mișca prețul
- Fiecare factor de risc primește 10, 20, 40, 60 sau 120 de zile (MAR33.12)
- **Perioada de stres**: fereastra de 12 luni, căutată cel puțin pînă în 2007, care dă portofoliului curent cel mai mare ES
- ES se calibrează pe această fereastră (MAR33.6–33.7)
- **Multiplicatorul**: capitalul este maximul dintre ultima valoare și $m_c\times$ media pe 60 de zile, cu $m_c = 1{,}5$ plus 0–0,5 după rezultate slabe la backtesting (MAR33.41–33.42)
- **Simplificarea didactică** folosită în Seminarul 7, C2: capitalul $\approx m_c \times \mathrm{ES}^{(\mathbf{10})}_{\mathbf{2,5\%}}\sqrt{\mathrm{LH}/10}$
  - Nu este regula MAR33 completă: formula de reglementare parcurge succesiv grupele de orizonturi LH și adaugă alți termeni
  - Cele două coincid pentru ES doar cînd toți factorii de risc au același LH

De la Basel 1996 la FRTB (2019)

	Basel 1996 Basel Committee (1996)	FRTB 2019 Basel Committee (2019)
Măsura de risc	VaR 1%, calculat zilnic	ES 2,5%, calculat zilnic pentru fiecare birou de tranzacționare
Orizontul	10 zile, cu scalarea prin $\sqrt{10}$ permisă	bază de 10 zile, scalată prin orizonturi de lichiditate (acțiuni cu capitalizare mare 10, mică 20, spread-uri de credit pînă la 120 de zile)
Datele	cel puțin un an de istorie	calibrat pe cea mai severă perioadă de stres de 12 luni
Capitalul	max(VaR de ieri, multiplicator $\geq 3 \times$ media VaR pe 60 de zile), iar multiplicatorul crește cu 0–1 după rezultate slabe la backtesting (zonele semafor, Capitolul 8)	multiplicator $m_c = 1{,}5$, crescut după rezultate slabe la backtesting
Backtesting	excepțiile VaR 1% (Capitolul 8)	VaR 1% și VaR 2,5% pe o zi: VaR se testează, ES stabilește capitalul

- Critica de după 2008: VaR ignoră mărimea pierderilor din coadă, iar ferestrele de un an exclud crizele mai vechi

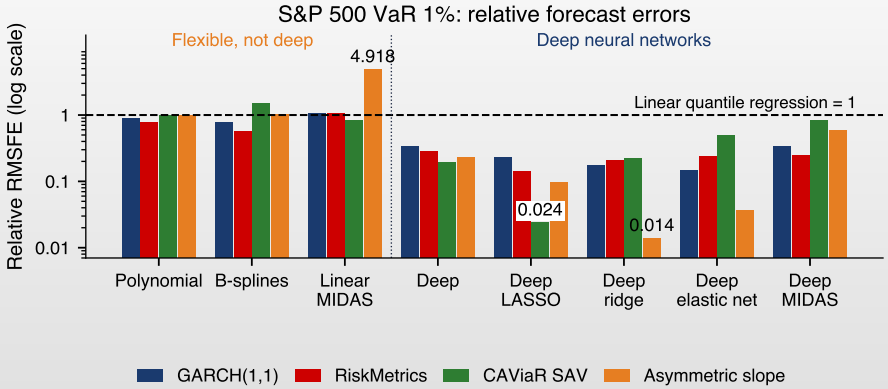
Studiu de caz (1/4): poate o rețea neuronală adîncă îmbunătăți prognoza VaR?

- **Întrebarea** Chronopoulos, Raftapostolos & Kapetanios (2024) (*Journal of Financial Econometrics*)
  - Poate o rețea neuronală adîncă să îmbunătățească prognoza VaR învățînd o relație **neliniară, cu formă necunoscută**, între cuantila condiționată și predictori?
- Date (Secțiunea 3 a articolului): randamentele log zilnice ale S&P 500, septembrie 1985 – august 2020
- Niveluri: $\alpha = 1\%, 5\%, 10\%$
- Predictorii x_t: volatilitatea GARCH sau RiskMetrics, variabilele de stare CAViaR
- Ultimele 2 000 de zile în afara eșantionului, o singură fereastră fixă de calibrare (detaliile: Anexă)
- Reperul: regresia cuantilă liniară Koenker & Bassett (1978) pe aceiași predictori, adică o specificație liniară de tip CAViaR

Studiu de caz (2/4): cuantila condiționată ca rețea neuronală

- Modelul (Ec. 5–10): cuantila condiționată a randamentului este o rețea neuronală a predictorilor
  - $Q_{r_t}(\alpha \mid x_t) \approx G_\alpha(x_t, w)$
  - $Q_{r_t}(\alpha \mid x_t)$: cuantila de ordin α a lui r_t, dat fiind x_t
  - G_α: o rețea cu propagare înainte (feed-forward), cu straturi ascunse ReLU (rectified linear unit, $\max(\cdot, 0)$)
  - w: ponderile rețelei
- Estimarea: minimizăm pierderea pinball plus o penalizare a lui w: niciuna, LASSO (penalizare L_1), ridge (penalizare L_2) sau elastic net (ambele)
- w^*: ponderile estimate
- Ținta: cuantila randamentului zilnic peste 10 zile (Ec. 23)
  - $\widehat{\mathrm{VaR}}_{t+10|\mathcal{F}_t} = -G_\alpha(x_t, w^*)$; $\mathcal{F}_t$: informația disponibilă în ziua t
- Evaluarea: RMSFE (rădăcina erorii pătratice medii de prognoză) relativă la reper
- O valoare sub 1 înseamnă o eroare mai mică decît a regresiei cuantile liniare
  - Semnificația: testul Diebold–Mariano (DM) al preciziei egale a prognozelor

Studiu de caz (3/4): erorile relative, $\alpha = 1\%$



MFM_ch7_crk_table6

Studiu de caz (4/4): ce arată și ce nu arată rezultatele

- Chronopoulos, Raftapostolos & Kapetanios (2024), Tabelul 6: RMSFE relativ la regresia cuantilă liniară (linia întreruptă marchează 1), pe scară logaritmică
- S&P 500, ultimele 2 000 de zile pînă în august 2020
- Modelele flexibile fără rețele (polinomial, B-spline, MIDAS liniar; MIDAS: mixed data sampling, regresie cu date de frecvențe diferite): 7 din 12 bare sînt la 1 sau peste
- Toate cele 16 bare ale rețelelor adînci și cele 4 ale MIDAS adînc sînt sub 1 (între 0,014 și 0,850)
- Toate sînt semnificative în testul DM, cu excepția MIDAS adînc pentru SAV
- Atenție: RMSFE este minimizată de **media** condiționată, nu de cuantilă
- Precizia cuantilelor cere pierderea pinball
- O singură fereastră fixă de calibrare: rămîne de văzut dacă o reducere de 98% se păstrează la reestimarea pe fereastră mobilă (Seminarul 7, C3)

MFM_ch7_crk_table6

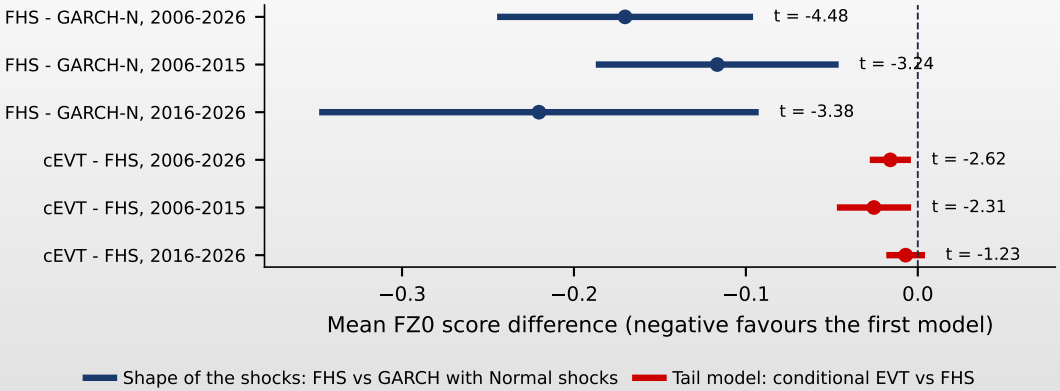
Pot datele zilnice ordona modelele (VaR, ES)? (1/2): scorul și testul

- Pot datele zilnice ordona modelele concurente (VaR 1%, ES 1%)? Nolde & Ziegel (2017), Patton, Ziegel & Chen (2019), Bayer & Dimitriadis (2022), Pele & Mazurencu-Marinescu-Pele (2026)
  - Dificultăți: ES singur nu este elicitabil, iar doar circa 1% din zile sînt informative
- Scorul FZ0: o penalizare comună pentru o prognoză (VaR, ES), dat fiind randamentul realizat
- O valoare mai mică este mai bună Patton, Ziegel & Chen (2019)
  - $S(v, e; Y) = -\frac{1}{\alpha e} 1\{Y \le v\}(v - Y) + \frac{v}{e} + \ln(-e) - 1$
  - Y: randamentul realizat
  - $v_t = -\mathrm{VaR}_{\alpha,t}$ și $e_t = -\mathrm{ES}_{\alpha,t}$: cuantila și media cozii prognozate, ambele negative
  - Primul termen penalizează randamentele sub v
- Testul: $d_t = S_t^A - S_t^B$, diferența zilnică dintre scorurile modelelor A și B
  - H_0: $\mathbb{E}[d_t] = 0$ (precizie egală) față de H_1: $\mathbb{E}[d_t] \neq 0$
  - Statistica t Diebold–Mariano, cu erori HAC, este aproximativ $N(0,1)$ sub H_0
  - Dacă $t < -1{,}96$, modelul A este semnificativ mai bun la 5%
  - Raportăm intervalul pentru $\mathbb{E}[d_t]$ separat pe subperioadele fixate înainte de analiză (2006–2015, 2016–2026)

Pot datele zilnice ordona modelele (VaR, ES)? (2/2): ce verifică cercetătorul

- Un asistent AI poate schița harta literaturii, codul și un raport de referent
- Cercetătorul verifică
  - Semnul și nivelul: VaR 1% $= -q_{1\%}$, pozitiv pentru o pierdere (recalculăm FZ0 pentru o zi, pas cu pas)
  - Look-ahead bias: fiecare prognoză folosește doar date de dinaintea zilei ei
  - Scorul: doar scoruri comune (VaR, ES), niciodată MSE (eroarea pătratică medie) pentru ES singur Gneiting (2011)
  - Puterea testului: numărăm zilele din coadă pe care se bazează comparația
  - Fiecare DOI (Digital Object Identifier, identificatorul digital al articolului) este verificat (prompturile reutilizabile: ▸ Anexă)

Mini-studiu de caz: ordonarea modelelor ES (1/2)



MFM_ch7_ai_discovery_case

Mini-studiu de caz: ordonarea modelelor ES (2/2)

- Afirmația testată: „EVT condiționată este cel mai bun model (VaR 1%, ES 1%) pentru S&P 500”
- Replicăm întîi rata de depășire FHS: 1,54% (80 din 5 210 zile, 2006–2026)
- Scorul FZ0 mediu (o valoare mai mică indică un model mai bun): 1,267 pentru EVT condiționată, 1,283 pentru FHS și 1,453 pentru GARCH–Normal
- Barele: intervale HAC de 95% pentru $\mathbb{E}[d_t]$; în grafic, cEVT = EVT condiționată, iar GARCH-N = GARCH cu șocuri Normale
- Toate cele șase statistici t Diebold–Mariano (negativă: primul model are scor mai bun; valoarea critică la 5% este $-1{,}96$)
  - FHS față de GARCH–Normal: 2006–2026 $t = -4{,}48$; 2006–2015 $t = -3{,}24$; 2016–2026 $t = -3{,}38$
  - EVT condiționată față de FHS: 2006–2026 $t = -2{,}62$; 2006–2015 $t = -2{,}31$; 2016–2026 $t = -1{,}23$
- Regula de decizie aplicată aici: un cîștig este considerat demonstrat doar dacă este semnificativ la 5% în **ambele** jumătăți pre-înregistrate
- Statistica t pe întreaga perioadă este raportată, dar nu este decisivă
- Forma șocurilor contează, iar rezultatul este robust: șocurile Normale pierd în ambele jumătăți ale perioadei
- Cîștigul EVT față de FHS este de zece ori mai mic, semnificativ în 2006–2015, dar nu și în 2016–2026 ($[-0{,}018; 0{,}004]$): după regula de mai sus, cîștigul nu este demonstrat, dar nici echivalența celor două modele nu este dovedită

MFM_ch7_ai_discovery_case

Punct de plecare pentru proiectul de echipă

- Întrebarea: oferă un model semiparametric dinamic (VaR, ES) Patton, Ziegel & Chen (2019) prognoze mai bune decît FHS și EVT condiționată la ES 2,5%, în afara eșantionului?
  - Piețe: S&P 500, BET și Bitcoin
  - Modelul testat: modelul GAS (generalised autoregressive score) cu un factor din Patton, Ziegel & Chen (2019) (Secțiunea 2.3 a articolului), estimat prin minimizarea pierderii FZ0
  - Statut: o extindere opțională, pentru aprofundare
  - Lista proiectelor de echipă din seminar: Seminarul 7, C2 și C3
- Replicăm întîi: VaR 1% FHS pentru S&P 500 de 1,97% și ordonarea FZ0 din mini-studiul de caz
- Livrabile
  - O pre-înregistrare de o pagină: modele, niveluri, scoruri, subperioade, putere (zile din coadă) și ce ar infirma afirmația
  - Codul, pe datele zilnice de piață ale cursului (punct de plecare: Quantlet)
  - Un tabel cu toate comparațiile și p-value-urile ajustate
  - O autocritică în stilul unui referent
- Notăm prompturile și rezultatele acceptate în `AI_USE.md`
- Notăm fiecare eroare prinsă (semn inversat, etichetă greșită a nivelului, look-ahead bias, DOI inventat) în `AI_ERRORS.md`

Alegerea metodei

Situația	Metoda	Eșuează cînd
Verificare rapidă, istorie lungă și stabilă	Simulare istorică, 500–1 000 de zile	volatilitatea se schimbă, iar estimarea nu poate depăși cea mai mare pierdere observată
Riscul zilnic după un șoc de volatilitate	FHS sau EVT condiționată, cu interval bootstrap	modelul GARCH este greșit specificat
VaR 0,5% și mai adînc, teste de stres	Depășiri de prag (GPD), condiționate sau nu	prag ales greșit sau depășiri grupate
Orizont de mai multe zile, opțiuni	Monte Carlo filtrat	domină riscul de model
Bugetarea riscului pe birouri sau active	Contribuții Euler la ES	fiecare contribuție se bazează pe puține zile din coadă
Capitalul reglementat	ES 2,5%, 10 zile, perioadă de stres, backtesting pe VaR	fereastra de stres este scurtă și zgomotoasă

- Orice VaR sau ES este o estimare: îl raportăm cu numărul de observații din coadă și un interval

Întrebări recapitulative și legătura cu Capitolul 8

Întrebări de verificare

- De ce poate VaR recompensa concentrarea?
- De ce nu o poate recompensa ES?
- De ce depinde precizia ES de $n\alpha$ și nu de n?
- Cînd este scalarea cu $\sqrt{10}$ prea mică?
- Cînd este prea mare?

Capitolul 8: backtesting

- Cît de des au depășit pierderile VaR?
- Au fost depășirile independente?
- Testele de acoperire și zonele de tip semafor din Basel
- Compararea prognozelor (VaR, ES) cu scoruri comune Fissler & Ziegel (2016)

Lecturi suplimentare: Franke, Härdle & Hafner (2019), Härdle, Chen & Overbeck (2017), Čížek, Härdle & Weron (2011), McNeil, Frey & Embrechts (2015)

Datele folosite în acest capitol

Seria	Tip	Perioada	Zile
S&P 500	indice bursier SUA	2000–2026	6 717
BET	indice bursier BVB	2000–2026	6 670
Bitcoin	cripto-activ, 7 zile din 7	2014–2026	4 384
EUR/RON	cursul de referință BNR	2005–2026	5 352
Aur	USD pe uncie troy, zile lucrătoare	2000–2026	6 956
Portofoliu	SPY, TLT, GLD (ETF-uri) și Bitcoin	2014–2026	3 017
Banca Transilvania	acțiune BVB (exemplul de lichiditate)	2024–2026	496

- Valori zilnice de închidere pînă la 18 septembrie 2026
- Randamente log zilnice în %, $r_t = 100\,(\ln P_t - \ln P_{t-\mathbf{1}})$
- Fiecare serie are propriul calendar
- Portofoliul folosește zilele în care există toate cele patru prețuri
- ETF-uri: prețuri ajustate pentru dividende
- SPY replică S&P 500, TLT obligațiunile de stat americane pe termen lung, GLD aurul

Înapoi

Răspunsurile la verificările rapide

Care poziție este mai riscantă?

- A: $\mathrm{VaR}_{\mathbf{10\%}} = q_{\mathbf{0,9}}(L_A) = 9\%$
- $\mathrm{ES}_{\mathbf{10\%}}$ = media lui L_A pe $[9, 10] = 9{,}5\%$
- B: $P(L_B > 0) = 5\% \leq 10\%$, deci $\mathrm{VaR}_{\mathbf{10\%}} = 0$
- $\mathrm{ES}_{\mathbf{10\%}} = (20 \times 0{,}05 + 0 \times 0{,}05)/0{,}10 = 10\%$
- VaR consideră A mai riscantă (9 față de 0), ES consideră B mai riscantă (10 față de 9,5): VaR nu vede șansa de 5% de a pierde 20

Cîte zile sînt necesare pentru un VaR precis?

- (a) SE $\approx \sqrt{0{,}05 \times 0{,}95/1\,000}\,/\,0{,}1031 = 0{,}0069/0{,}1031 \approx 0{,}067$ pp
- Jumătatea intervalului de 95%: $1{,}96 \times 0{,}067 \approx 0{,}13$ pp
- (b) SE scade ca $1/\sqrt{n}$: $4 \times 1\,000 = 4\,000$ de zile, circa 16 ani de zile de tranzacționare
- (c) $n\alpha = 10$ pierderi: o singură zi extremă modifică mult media
- Precizia depinde de $n\alpha$, nu de n

De la o zi la zece zile

- (a) $2 \times \sqrt{10} = 6{,}32\%$
- (b) $6{,}32 \times \sqrt{1{,}21} = 6{,}32 \times 1{,}1 \approx 6{,}96\%$
- (c) Prea mic: volatilitatea este de așteptat să crească spre nivelul ei de termen lung în cele zece zile
- S&P 500: Monte Carlo filtrat 6,29%, față de $\sqrt{10}\times$ VaR filtrat pe o zi 6,22%

Înapoi

Demonstrația reprezentării Rockafellar–Uryasev

- **Demonstrație**: $F(v) = v + \mathbb{E}[(L - v)_+]/\alpha$ este convexă, cu derivata la dreapta (panta imediat la dreapta lui v) $1 - P(L > v)/\alpha$
  - Este ≥ 0 exact cînd $P(L > v) \leq \alpha$, adică $v \geq \mathrm{VaR}_\alpha$
- **Corolar**: $(w, v) \mapsto v + \mathbb{E}[(-w^\top R - v)_+]/\alpha$ este convexă simultan în ambele argumente
- Minimizarea în raport cu v păstrează convexitatea
  - ES este convex în w
  - Împreună cu omogenitatea pozitivă, aceasta demonstrează subaditivitatea
- Argumentul înfășurătoarei: $\partial F/\partial v = 0$ în $v = \mathrm{VaR}_\alpha$, deci o mică eroare în VaR schimbă minimul doar la ordinul al doilea: de aici eroarea standard a ES fără termen din VaR

Înapoi

Condiții de subaditivitate pentru VaR

- Pierderi cu distribuție **eliptică comună**, $\alpha < 0{,}5$: VaR este subaditiv (slide-ul „Măsuri de risc coerente (2/2)") McNeil, Frey & Embrechts (2015)
  - Marginalele Normale sau t nu sînt suficiente prin ele însele: distribuția comună trebuie să fie eliptică
- **Cozi grele, dar nu prea grele**: pentru pierderi cu variație regulată multivariată și tail index peste 1, VaR este subaditiv suficient de departe în coadă (asimptotic, cînd $\alpha \to 0$) Daníelsson et al. (2013)
  - Tail index-urile estimate pentru acțiuni și cursuri de schimb sînt în acest domeniu (între 4,8 și 6,5 în secțiunea „Teoria valorilor extreme"), dar rezultatul este asimptotic, nu o garanție la un α dat
- Subaditivitatea nu se mai menține în prezența salturilor discrete (neplăți), a cozilor extrem de grele și a unor cîștiguri din opțiuni
- VaR față de ES în practică: ES are nevoie de mai multe date pentru aceeași precizie Yamai & Yoshiba (2005)

Înapoi

Agregarea VaR în condiții de incertitudine privind dependența

- Marginale $F_1, \ldots, F_d$ cunoscute, copula necunoscută (Capitolul 6): $\mathrm{VaR}_\alpha(\sum_i L_i)$ se află într-un interval Embrechts, Puccetti & Rüschendorf (2013)
  - F_i: funcția de repartiție a pierderii L_i a activului i
  - d: numărul de active
  - Copula: structura de dependență care leagă marginalele
  - Valoarea comonotonă $\sum_i \mathrm{VaR}_\alpha(L_i)$ (toate pierderile variază perfect împreună) **nu** este capătul superior: VaR nu este subaditiv

înapoi

Algoritmul de rearanjare și riscul modelului

- **Algoritmul de rearanjare**: discretizăm coada de dincolo de fiecare $\mathrm{VaR}_\alpha(L_i)$ în N puncte (o coloană pe activ)
  - Ordonăm fiecare coloană invers față de suma celorlalte pînă cînd sumele pe rînduri devin uniforme
  - VaR maxim este aproximativ cea mai mică sumă pe rînd
- Portofoliul 40/30/20/10 din secțiunea „VaR de portofoliu și contribuțiile la risc", $\mathrm{VaR}_{1\%}$ zilnic, marginale empirice, $N = 2\,000$
  - $\mathrm{VaR}_{1\%}$ cu dependența istorică (cuantila empirică a pierderii portofoliului): 1,95%
  - Cu dependență comonotonă (suma VaR-urilor empirice individuale): 3,63%
  - În cazul cel mai rău: 4,76%, adică de 1,31 ori valoarea comonotonă
  - Acestea sînt valori empirice
  - Secțiunea „VaR de portofoliu și contribuțiile la risc" folosește formula Normală, de aceea dă 1,77% și 3,11% nediversificat pentru același portofoliu
- Incertitudinea privind modelul dependenței afectează capitalul bazat pe VaR cu un ordin de mărime comparabil cu beneficiul diversificării

VaR și ES pe metode și active

	$\mathrm{VaR}_{1\%}$ (%)					$\mathrm{ES}_{2,5\%}$ (%)				
	Ist.	Distr. Normală	t	CF	EVT	Ist.	Distr. Normală	t	CF	EVT
S&P 500	3,45	2,80	3,46	6,08	3,54	3,76	2,81	3,95	6,65	3,78
BET	4,13	3,19	4,06	7,25	4,22	4,57	3,21	4,76	7,93	4,58
Bitcoin	10,51	7,99	11,06	18,89	10,23	10,84	8,03	13,37	20,69	10,84
EUR/RON	0,76	0,64	1,36	1,43	0,78	0,84	0,65	3,27	1,60	0,84
Aur	3,04	2,50	3,00	4,64	3,07	3,23	2,51	3,27	5,02	3,23

- Pierderi zilnice, selecțiile complete
- CF: Cornish–Fisher
- EVT: coada Pareto generalizată estimată pe cele mai mari 5% dintre pierderi (secțiunea „Teoria valorilor extreme")
- Excesul de kurtosis: 10,7 pentru S&P 500, 11,1 pentru BET, 12,0 pentru Bitcoin, 15,1 pentru EUR/RON și 7,7 pentru aur
- Bitcoin necesită o rezervă de aproximativ trei ori mai mare decît S&P 500, EUR/RON de aproximativ o cincime

Înapoi

Teoria asimptotică pentru VaR și ES istorice

- **VaR**: pentru pierderi i.i.d. cu densitatea f continuă și pozitivă în VaR_α,
  $\sqrt{n}\,(\widehat{\mathrm{VaR}}_\alpha - \mathrm{VaR}_\alpha) \to N\left(0, \frac{\alpha(1-\alpha)}{f(\mathrm{VaR}_\alpha)^2}\right)$
  - $\to$: convergență în distribuție cînd $n \to \infty$
  - Dispersia limitei este dispersia asimptotică (avar), iar SE $= \sqrt{\mathrm{avar}/n}$
- **ES** Chen (2008), cu funcția de influență IF de pe slide-ul „Erori standard pentru VaR și ES (2/2)"
  - Niciun termen din estimarea VaR: $\partial F/\partial v = 0$ în $v = \mathrm{VaR}_\alpha$
  - Dacă $\mathbb{E}[(L - \mathrm{VaR}_\alpha)_+^2] < \infty$, dispersia limitei lui $\sqrt{n}(\widehat{\mathrm{ES}}_\alpha - \mathrm{ES}_\alpha)$ este $\mathrm{avar} = \mathrm{Var}((L - \mathrm{VaR}_\alpha)_+)/\alpha^2$
  - Coadă de tip Pareto cu indicele $a > 2$, $\alpha \to 0$: $\mathrm{Var}((L - \mathrm{VaR}_\alpha)_+) \approx \frac{2\alpha \mathrm{VaR}_\alpha^2}{(a-1)(a-2)}$, deci SE $\propto \mathrm{VaR}_\alpha/\sqrt{n\alpha}$ ($\propto$: proporțional cu) Pele & Mazurencu-Marinescu-Pele (2026)

înapoi

Precizia pentru S&P 500, tabelul complet

	n	$\widehat{\mathrm{VaR}}_{1\%}$	SE i.i.d.	SE HAC	$\widehat{\mathrm{ES}}_{2{,}5\%}$	SE i.i.d.	SE HAC
2000–2026	6 717	3,45	0,13	0,19	3,76	0,15	0,26
Ultimele 500 de zile	500	2,73	0,36	0,44	2,94	0,48	0,65

- Densitatea $f(\mathrm{VaR})$ prin nucleu Gaussian (lățimea de bandă Silverman)
- HAC: nucleu Bartlett, lag $\lfloor 4(n/100)^{2/9} \rfloor$ (10 pentru selecția completă și 5 pentru ultimele 500 de zile) Newey & West (1994)
- Selecția completă, $n = 6\,717$: SE a $\mathrm{VaR}_{1\%}$ ar fi 0,055 sub distribuția Normală cu $\sigma = 1{,}2\%$ și 0,12 sub t_4
- Volatility clustering crește SE cu 46–73% pe selecția completă și cu 22–35% pe ultimele 500 de zile

înapoi

Filtrele GARCH și volatilitatea de mîine

	$\hat{\phi}$	$\hat{\alpha}_1$	$\hat{\beta}_1$	$\hat{\alpha}_1 + \hat{\beta}_1$	$\hat{\sigma}$ (selecție)	$\hat{\sigma}_{t+1}$	$-q_{1\%}(\hat{z})$
S&P 500	−0,053	0,1204	0,8604	0,981	1,21	0,73	2,79
BET	0,104	0,207	0,787	0,994	1,40	1,76	2,74
Bitcoin	−0,009	0,127	0,843	0,970	3,49	3,00	2,88
EUR/RON	0,089	0,148	0,852	1,000	0,28	0,08	2,80
Aur	−0,022	0,046	0,943	0,989	1,09	1,43	2,68

- $\hat{\sigma}_{t+1}$: prognoza pentru prima zi de tranzacționare de după 18 septembrie 2026 (19 septembrie pentru Bitcoin), în %
- Sub 1, persistența implică revenirea prognozei varianței la un nivel finit pe termen lung. Pentru EUR/RON, estimarea ajunge la frontiera integrată GARCH ($\hat{\alpha}_1 + \hat{\beta}_1 = 1$, în limita preciziei numerice): varianța necondiționată nu este finită, iar prognoza varianței nu revine la un nivel finit pe termen lung
- $\hat{\sigma}$ (selecție) este abaterea standard empirică a randamentelor; nu reprezintă volatilitatea pe termen lung implicată de model
- Cuantila $-q_{1\%}(\hat{z})$ este între 2,68 și 2,88, peste $-z_{1\%} = 2{,}326$: șocurile filtrate păstrează cozi grele

Înapoi

VaR și ES condiționate pentru următoarea zi de tranzacționare

	$\mathrm{VaR}_{1\%}$ (%)				$\mathrm{ES}_{1\%}$ (%)			
	GARCH	FHS	c-EVT	Ist.	GARCH	FHS	c-EVT	Ist.
S&P 500	1,63	1,97	2,03	3,45	1,88	2,55	2,56	5,01
BET	3,80	4,53	4,63	4,13	4,39	6,16	6,20	6,28
Bitcoin	6,89	8,56	8,68	10,51	7,90	12,22	12,19	14,29
EUR/RON	0,18	0,22	0,21	0,76	0,21	0,28	0,28	1,12
Aur	3,32	3,82	3,86	3,04	3,80	4,94	4,93	4,21

- GARCH: GARCH cu șocuri Normale
- c-EVT: teoria valorilor extreme condiționată (secțiunea „Teoria valorilor extreme")
- Ist.: necondiționat, întreaga selecție
- GARCH cu șocuri Normale dă cea mai mică valoare dintre cele trei metode condiționate pe fiecare rînd: volatilitatea singură nu descrie coada

înapoi

Riscul de estimare în VaR condiționat

- $\mathrm{VaR}_{\alpha,t+1} = -\mu_{t+1}(\theta) + \sigma_{t+1}(\theta)\,\xi_\alpha$, $\xi_\alpha = -q_\alpha(z)$: **atît** θ (GARCH, prin QML), cît și ξ_α (o cuantilă a reziduurilor) sînt estimați
  - θ: parametrii AR(1)-GARCH(1,1)
  - QML: cvasi-verosimilitate maximă
  - $\mu_{t+1}(\theta)$, $\sigma_{t+1}(\theta)$: prognozele implicate de ei
- Francq & Zakoïan (2015): estimăm împreună **parametrul de risc** (θ, ξ_α)
- Sub staționaritate strictă, $\mathbb{E}[z_t^4] < \infty$ și o densitate pozitivă a lui z în $q_\alpha(z)$, VaR condiționat este asimptotic Normal, cu o dispersie provenind din $\hat{\theta}$, din $\hat{\xi}_\alpha$ și din covarianța lor
- **Bootstrap pe reziduuri** Christoffersen & Gonçalves (2005), pentru $b = 1, \ldots, B$ (B: numărul de eșantioane bootstrap; steluța marchează o valoare calculată pe un eșantion bootstrap)
  - simulăm o traiectorie AR(1)-GARCH(1,1) de lungimea selecției cu $\hat{z}$ reeșantionate și re-estimăm θ^* pe ea
  - calculăm σ^*_{t+1} din randamentele **originale** cu θ^*
  - calculăm ξ^*_α din reziduurile traiectoriei
  - $\mathrm{VaR}^*_{t+1} = -\mu^*_{t+1} + \sigma^*_{t+1}\xi^*_\alpha$
  - intervalul percentil: cuantilele de 5% și 95% ale celor B valori VaR^*_{t+1}
- Cozile grele și asimetria lui z încetinesc convergența
- Spierdijk (2016): intervale VaR pentru ARMA (autoregressive moving average)–GARCH

înapoi

Setările estimării CAViaR și modelele comune (VaR, ES)

- Setările de estimare din Engle & Manganelli (2004): 10^4 puncte de start aleatoare în $(0,1)^3$, cele mai bune 10 rafinate prin pași simplex și quasi-Newton
- Valoarea de pornire a recursiei, $\mathrm{VaR}_1 = -\hat{q}_\alpha$, este cuantila empirică de ordin α a primelor 300 de randamente, cu semn schimbat
- Aceste zile rămîn în eșantionul de estimare
- Perechea (VaR, ES) poate fi **estimată** prin minimizarea unui scor comun strict consistent Fissler & Ziegel (2016)
- Capitolul 8 folosește aceleași scoruri pentru a **evalua** prognozele
  - Patton, Ziegel & Chen (2019): modele semiparametrice dinamice pentru (VaR, ES), de ex. cu dinamică GAS (generalised autoregressive score, scor autoregresiv generalizat), estimate prin minimizarea pierderii FZ0, pentru care sînt demonstrate consistența și normalitatea asimptotică
  - Taylor (2019): recursii de tip CAViaR pentru VaR și ES, estimate printr-o verosimilitate Laplace asimetrică
  - Dimitriadis & Bayer (2019): regresie liniară a cuantilei și a ES pe covariate (volatilitate realizată și implicită), cu erori standard
- Firul comun: funcția de scor care ordonează prognozele este și funcția obiectiv care estimează modelul

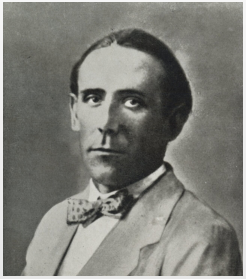
înapoi

Același simbol, sensuri diferite: notațiile din teoria valorilor extreme

- ξ: forma GEV/GPD
- $\hat{\xi}_\alpha$ (cu nivel): cuantila reziduurilor FHS, $-q_\alpha(\hat{z})$; EVT condiționată o estimează dintr-o GPD și o notează $\hat{z}_\alpha^{GPD}$
- β: scala GPD
- β_1: coeficient GARCH
- $\beta_0, \beta_1, \beta_2$: coeficienți CAViaR
- μ, σ: poziția și scala GEV în secțiunea despre maxime; în rest, media și volatilitatea condiționate
- u: pragul GPD; în definiția ES, u este variabila de integrare
- u_s: variabila auxiliară din programul liniar pentru ES minim
- α: probabilitatea cozii
- α_1: coeficient GARCH
- $a = 1/\xi$: tail index-ul

Înapoi

Emil Gumbel și statistica extremelor



Emil Julius Gumbel (1891–1966)

Foto: autor necunoscut (c. 1931); domeniu public; Wikimedia Commons

- Fisher & Tippett (1928): maximul multor variabile i.i.d., rescalat corespunzător, poate avea doar trei forme limită
- Gnedenko (1943) a demonstrat riguros rezultatul
- Gumbel (1958) a scris primul manual și a aplicat teoria la inundații, secete și durate de viață
  - Distribuția Gumbel este una dintre cele trei forme limită

Înapoi

De la maxime lunare la un VaR zilnic

- Zile independente: $P(M_n \leq x) \approx P(L \leq x)^n$, deci $\mathrm{VaR}_\alpha \approx H^{-1}((1-\alpha)^n)$ cu $n = 20{,}9$ zile de tranzacționare pe lună și H^{-1} funcția cuantilă a GEV estimate
  - $\mathrm{VaR}_{1\%} \approx H^{-1}(0{,}810) = 2{,}83\%$ față de valoarea istorică 3,45%; $\mathrm{VaR}_{0{,}1\%} \approx 6{,}19\%$
- Volatility clustering încalcă ipoteza de independență, iar aproximarea subestimează aici VaR
- Cu indicele extremal: $P(M_n \leq x) \approx F(x)^{n\theta}$, F: funcția de repartiție a pierderii zilnice
  - Cu $\hat{\theta} = 0{,}35$ (pragul la VaR 1%): $\mathrm{VaR}_{1\%} \approx H^{-1}(0{,}929) = 4{,}14\%$, în loc de 2,83%
  - Cu $\hat{\theta} = 0{,}19$ (pragul GPD): 5,09%
  - Corecția modifică rezultatul mai mult decît eroarea pe care o corectează: trecerea de la maximele pe blocuri la VaR zilnic este fragilă

înapoi

Estimările GPD pentru cinci serii

	u (%)	N_u	$\hat{\xi}$	SE($\hat{\xi}$)	$\hat{\beta}$	$1/\hat{\xi}$	$\mathrm{VaR}_{\mathbf{1\%}}$	$\mathrm{ES}_{\mathbf{1\%}}$
S&P 500	1,85	336	0,19	0,065	0,898	5,3	3,54	5,04
BET	1,93	334	0,21	0,066	1,196	4,8	4,22	6,34
Bitcoin	5,33	220	0,16	0,078	2,651	6,1	10,23	14,36
EUR/RON	0,38	268	0,18	0,072	0,217	5,5	0,78	1,14
Aur	1,68	348	0,15	0,062	0,759	6,5	3,07	4,22

- $\hat{\xi}$ între 0,15 și 0,21 pentru toate cele cinci serii, fiecare la peste două erori standard i.i.d. deasupra lui 0: cozi grele peste tot
- Gruparea depășirilor face ca aceste SE să fie subestimate
- Tail index-ul $1/\hat{\xi}$ între 4,8 și 6,5: cozile drepte estimate ale pierderilor au momente de ordinul patru finite
- Dar fiecare interval de 95% pentru ξ trece de 0,25, deci existența momentelor de ordinul patru nu este confirmată statistic (comparați cu Capitolul 1)

Înapoi

Indicele extremal: estimatorul și separarea grupurilor

- **Estimatorul pe intervale** Ferro & Segers (2003) din cele N momente de depășire a lui u și intervalele T_i dintre ele
  - $\hat{\theta} = \min\left\{1, \dfrac{2\left(\sum_i (T_i - 1)\right)^2}{(N-1)\sum_i (T_i - 1)(T_i - 2)}\right\}$ dacă $\max T_i > 2$ (altfel cu T_i, T_i^2)
  - Estimatorul compară pătratul intervalului mediu cu media pătratelor intervalelor: intervalele scurte din interiorul grupurilor împing $\hat{\theta}$ sub 1
- **Separarea grupurilor (declustering)** Ferro & Segers (2003): ținta este $C = \lfloor \hat{\theta} N \rfloor + 1$ grupuri, separate de cele mai mari $C - 1$ intervale
- Estimăm GPD pe maximele grupurilor
  - Egalități: dacă al $(C-1)$-lea și al C-lea cel mai mare interval sînt egale, C se reduce pînă cînd diferă, deci numărul realizat de grupuri poate fi sub țintă
  - SE i.i.d. a lui $\hat{\xi}$ era mai puțin de jumătate din SE obținută din maximele grupurilor
- S&P 500: $\hat{\theta} N = 0{,}18738 \times 336 = 62{,}96$, deci ținta este $C = \lfloor 62{,}96 \rfloor + 1 = 63$ (folosim $\hat{\theta}$ nerotunjit; valoarea 0,19 de pe slide-ul principal este rotunjită)
- După regula egalităților rămîn 62 de grupuri
- Cu pragul la VaR 1% istoric ($u = 3{,}45\%$, $N = 68$): $\hat{\theta} = 0{,}35$

înapoi

Portofoliul: volatilități, corelații și contribuții

	Pondere	σ_i (%)	corel. SPY	corel. TLT	corel. GLD
SPY	40%	1,10	1,00		
TLT	30%	0,93	−0,17	1,00	
GLD	20%	1,03	0,07	0,25	1,00
Bitcoin	10%	4,14	0,23	−0,02	0,09

	σ_i (%)	VaR marginal	C_i	cotă	C_i^{ES}	cotă
SPY	1,10	1,68	0,67	38,1%	0,98	45,4%
TLT	0,93	0,70	0,21	11,8%	0,14	6,5%
GLD	1,03	1,08	0,22	12,3%	0,25	11,4%
Bitcoin	4,14	6,68	0,67	37,8%	0,79	36,6%
Total	$\sigma_p = 0{,}76$		1,77	100%	2,15	100%

- SPY are o cotă mai mare din ES decît din VaR Normal (45,4% față de 38,1%): pierderile lui se concentrează în zilele cele mai rele ale portofoliului mai mult decît indică covariațele
- Pentru a o interpreta drept dependență în coadă este necesară o analiză separată (Capitolul 6)

Înapoi

Comitetul de la Basel și calendarul UE



Turnul Băncii Reglementelor Internaționale (BIS) din Basel, sediul Comitetului de la Basel pentru Supraveghere Bancară

Foto: Michal Pleskowicz (2018); CC BY-SA 4.0; Wikimedia Commons

- Comitetul de la Basel pentru Supraveghere Bancară stabilește standardele globale de capital
- Autoritățile naționale (în UE, prin Regulamentul privind cerințele de capital) le transformă în lege
- **1996**: riscul de piață intră în regulile de capital, iar băncile pot folosi modele VaR interne Basel Committee (1996)
- **2019**: standardul revizuirii fundamentale a portofoliului de tranzacționare (Fundamental Review of the Trading Book) înlocuiește VaR cu ES în abordarea bazată pe modele interne Basel Committee (2019)
- Fiecare jurisdicție își stabilește data de aplicare
- UE: Delegated Regulation (EU) 2025/1496 a amînat cerințele de fonduri proprii FRTB la 1 ianuarie 2027
- Pînă atunci băncile aplică cadrul anterior, bazat pe VaR

Înapoi

Studiu de caz: predictori, eșantion și calibrare (1/2)

- **Date** (Secțiunea 3.1 a articolului): randamentele log zilnice ale S&P 500, $r_t = \ln(P_t/P_{t-\mathbf{1}})$, septembrie 1985 – august 2020, $T = 9\,053$
- Niveluri: $\alpha = 1\%$, 5% și 10%
  - Patru seturi de predictori x_t (Ec. 14–17, după Giacomini & Komunjer (2005)):
    - σ_t din GARCH(1,1)
    - σ_t RiskMetrics cu factorul de atenuare $\lambda = 0{,}94$
    - CAViaR SAV $(\mathrm{VaR}_{t-\mathbf{1}}, |r_{t-\mathbf{1}}|)$
    - CAViaR cu pantă asimetrică $(\mathrm{VaR}_{t-\mathbf{1}}, r^+_{t-\mathbf{1}}, r^-_{t-\mathbf{1}})$, $r^+ = \max(r, 0)$, $r^- = \max(-r, 0)$
  - În articol, τ corespunde nivelului α din curs
  - $\mathrm{VaR}_{\alpha,t} = -Q_{r_t}(\alpha \mid x_t)$, ca în secțiunea „VaR și Expected Shortfall"
- **Schema de evaluare** (Secțiunea 3.2 a articolului): ultimele 2 000 de zile formează eșantionul de evaluare
- Primele 7 053 sînt folosite pentru calibrarea unică a modelului (fereastră fixă)
  - CV (validare încrucișată) pentru serii de timp (Ec. 12): se exclud $\delta = 5$ zile de fiecare parte a observației evaluate
  - Se aleg aleatoriu $\kappa = 20$ de observații pentru testare
  - Grile: adîncimea și lățimea din $\{1, 5, 10\}$, cîte cinci valori pentru rata de învățare și ponderea penalizării λ (alta decît λ RiskMetrics) în $[0{,}001; 0{,}01]$, dimensiunea lotului din $\{10, 20\}$
  - Antrenare: dropout de cel mult 20%, Adam (algoritm de optimizare stocastică cu pas adaptiv), oprire timpurie (Secțiunea 1.4 a articolului)

Înapoi

Studiu de caz: modele concurente și teste de evaluare (2/2)

- **Modele comparate**: regresia cuantilă liniară (modelul de referință), regresiile cuantile polinomială și cu funcții B-spline, modelul MIDAS liniar (Ec. 18) și o rețea MIDAS adîncă
  - **Evaluare** (Secțiunea 3.3 a articolului): RMSFE relativ la reperul liniar
  - Testul DM Diebold & Mariano (1995) aplicat pierderilor pinball, cu corecția Harvey, Leybourne & Newbold (1997)
  - Testul CQFE (conditional quantile forecast encompassing) Giacomini & Komunjer (2005): verifică dacă o prognoză conține deja informația celeilalte, cu parametrul de netezire $\eta = 0{,}005$
  - Motivația: Patton, Ziegel & Chen (2019) au extins CAViaR la (VaR, ES) cu dinamică parametrică
  - Acest articol păstrează doar VaR, dar renunță la liniaritate

Înapoi

Studiu de caz: rezultatele complete (Tabelele 6 și 7)

$\alpha = 1\%$	Polin.	Spline	MIDAS	Adînc	LASSO	Ridge	Elnet	MIDAS adînc
GARCH	0,909	0,791	1,083	0,346	0,236	0,177	0,146	0,346
RiskMetrics	0,780	0,570	1,066	0,289	0,141	0,207	0,239	0,246
SAV	1,000	1,511	0,838	0,198	0,024	0,225	0,498	0,850
Pantă asim.	1,000	1,040	4,918	0,235	0,096	0,014	0,037	0,601

- RMSFE relativ la regresia cuantilă liniară, $\alpha = 1\%$ (Tabelul 6, unde LASSO, Ridge și Elnet sînt rețele adînci penalizate): toate cele 16 valori ale rețelelor adînci sînt sub 1 și semnificative la 1% în testul DM
  - Pe toate nivelurile, rețelele adînci reduc eroarea cu 50%–98%, MIDAS adînc cu 11%–84%
  - Penalizarea cea mai bună se schimbă cu setul de predictori (elastic net pentru GARCH, LASSO pentru RiskMetrics și SAV, ridge pentru panta asimetrică)
- În majoritatea cazurilor, reperul liniar are erori mai mici decît regresiile polinomială și cu spline (raport de pînă la 1,716 la alte niveluri α din Tabelul 6)
- MIDAS liniar ajunge la 4,918
- Rezultatele nu separă contribuțiile arhitecturii, penalizării și CV
- CQFE la $\alpha = 1\%$ (Tabelul 7): prognozele blocului neliniar înglobează informația din prognozele concurente în 757 de comparații, cu 42 de rezultate nefavorabile și 751 neconcludente
- Pentru blocul liniar: 173 de comparații favorabile, 15 nefavorabile și 170 neconcludente
- Numeroasele perechi neconcludente arată că o combinație de prognoze ar putea aduce încă informație

înapoi

Studiu de caz: replicare și limite

- **Replicare** pe datele zilnice de piață ale cursului: seria S&P 500 începe în ianuarie 1990, deci lipsește perioada 1985–1989 (o limită a datelor)
  - Păstrăm fereastra de evaluare din articol (ultimele 2 000 de randamente pînă la 31 august 2020, de la 19 septembrie 2012): 5 726 de zile de calibrare în loc de 7 053
  - Construim predictorii GARCH și SAV, estimăm regresia cuantilă liniară și regresia cuantilă cu o rețea neuronală adîncă la $\alpha = 1\%$ și recalculăm rîndul GARCH din Tabelul 6 (Seminarul 7, C3: versiunea minimă; rîndurile complete în extinderea de replicare)
- **Limite menționate de autori**
  - O singură fereastră de estimare: recalibrarea recursivă sau pe fereastră mobilă, repetată pentru 2 000 de zile, necesită un volum mare de calcul (Secțiunea 3.2 a articolului)
  - Rețelele sînt predispuse la overfitting, de aici penalizările, dropout, CV și oprirea timpurie (Secțiunea 1.4 a articolului)
  - Rezultatul se interpretează doar prin valori SHAP (Shapley additive explanations, explicații aditive Shapley) și derivate parțiale (Secțiunea 4 a articolului)
- **Extinderi deschise** (Seminarul 7, C3)
  - Se păstrează cîștigul la reestimarea pe fereastră mobilă în 2020–2026 și pe BET?
  - Poate o rețea antrenată pe pierderea FZ0 a lui Patton, Ziegel & Chen (2019) să prognozeze împreună (VaR, ES), cum cere FRTB?

Înapoi

Bucla descoperirii, prompturi reutilizabile (1/2)

- Instrumentele sînt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și instrumente de căutare în literatura științifică (Semantic Scholar, Elicit, Google Scholar)
- **Literatura**: *„Listează articolele publicate după 2015 despre backtesting-ul comparativ al perechii (VaR, ES) cu funcții de scor strict consistente: DOI, funcția de scor, testul, mărimea eșantionului și rezultatele privind puterea."*
  - Verificăm fiecare DOI în Crossref
  - Verificăm în articol convenția de semn a scorului
- **Ipoteze**: *„Pentru FHS, EVT condiționată și GARCH cu șocuri Normale, spune ce trăsături ale cozii surprinde fiecare și ce implică fiecare pentru diferențele FZ0 în anii calmi și în cei agitați."*
- **Date și cod**: *„Scrie cod Python care calculează pierderea FZ0 pentru prognozele zilnice VaR 1% și ES 1% pe S&P 500 din datele zilnice de piață ale cursului, cu convenția de semn VaR $= -q_\alpha$, și un test Diebold–Mariano cu erori HAC."*
  - Replicăm întîi: rata de depășire FHS de 1,54% pe 5 210 zile (secțiunea „VaR și ES condiționate")

Înapoi

Bucla descoperirii, prompturi reutilizabile (2/2)

- **Robustețe**: *„Scrie un plan pre-înregistrat: subperioadele 2006–2015 și 2016–2026, nivelurile 1% și 2,5%, FZ0 și un al doilea scor consistent, laguri HAC 5 și 20, un al doilea indice."*
  - Verificarea mărimii testului: simulăm dintr-un GARCH-t estimat și evaluăm două prognoze cu aceeași medie a scorului FZ0
  - Testul trebuie să respingă în circa 5% din simulări
- **Critica**: *„Joacă rolul unui referent: este ordonarea mea determinată de 2008 și 2020, de convenția de semn a scorului sau de ferestrele de estimare suprapuse? Indică un test care ar identifica fiecare dintre aceste probleme."*
- **Raportul**: fiecare pereche de modele, nivel și perioadă
- Numărul de zile din coadă pe care se bazează fiecare comparație
- **Testare multiplă**: modele × niveluri × perioade × active: fixăm familia dinainte și ajustăm p-value-urile
- Un DOI care nu duce la nicio lucrare sau un scor atribuit greșit: renunțăm la afirmație și o notăm în `AI_ERRORS.md`
- Fixăm planul înainte de prima rulare: orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare

Înapoi

Cursuri Quantinar și codul capitolului

Cursuri avansate pe quantinar.com

- Measuring Statistical Risk
- XFG Advanced Methods in Quantitative Finance

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_07

Înapoi

Acronime folosite în acest material (1/3)

- **AI**: Artificial Intelligence — *inteligență artificială*
- **AR**: AutoRegressive (model) — *model autoregresiv*
- **ARMA**: AutoRegressive Moving Average (model) — *model autoregresiv cu medie mobilă*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BIS**: Bank for International Settlements — *Banca Reglementelor Internaționale*
- **BNR**: Banca Națională a României
- **BVB**: Bursa de Valori București
- **CF**: Cornish–Fisher (expansion) — *dezvoltarea Cornish–Fisher*
- **COVID-19**: COronaVIrus Disease 2019 — *boala provocată de coronavirus, 2019*
- **CQFE**: Conditional Quantile Forecast Encompassing (test) — *testul de includere a prognozelor cuantilelor condiționate*
- **CV**: Cross-Validation — *validare încrucișată*
- **DM**: Diebold–Mariano (test) — *testul Diebold–Mariano de comparare a prognozelor*
- **ES**: Expected Shortfall — *pierderea așteptată în coadă*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*

Acronime folosite în acest material (2/3)

- **EU**: European Union — *Uniunea Europeană*
- **EVT**: Extreme Value Theory — *teoria valorilor extreme*
- **FHS**: Filtered Historical Simulation — *simulare istorică filtrată*
- **FRTB**: Fundamental Review of the Trading Book — *revizuirea fundamentală a portofoliului de tranzacționare*
- **FZ0**: Fissler–Ziegel loss, zero-homogeneous version — *funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GARCH-N**: GARCH with Normal innovations — *GARCH cu inovații Normale*
- **GAS**: Generalised Autoregressive Score (model) — *model cu scor autoregresiv generalizat*
- **GEV**: Generalised Extreme Value (distribution) — *distribuția generalizată a valorilor extreme*
- **GPD**: Generalised Pareto Distribution — *distribuția Pareto generalizată*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*

Acronime folosite în acest material (3/3)

- **HS**: Historical Simulation — *simulare istorică*
- **IF**: Influence Function — *funcția de influență*
- **LASSO**: Least Absolute Shrinkage and Selection Operator — *regresie penalizată L1 cu selecția variabilelor*
- **MC**: Monte Carlo (simulation) — *simulare Monte Carlo*
- **MIDAS**: MIxed DAta Sampling (regression) — *regresie cu date de frecvențe mixte*
- **MSE**: Mean Squared Error — *eroarea pătratică medie*
- **QML**: Quasi-Maximum Likelihood — *cvasi-verosimilitate maximă*
- **RMSFE**: Root Mean Squared Forecast Error — *rădăcina erorii pătratice medii de prognoză*
- **SAV**: Symmetric Absolute Value (CAViaR specification) — *specificația CAViaR cu valoare absolută simetrică*
- **SE**: Standard Error — *eroare standard*
- **SHAP**: SHapley Additive exPlanations — *explicații aditive Shapley*
- **SUA**: Statele Unite ale Americii
- **UE**: Uniunea Europeană
- **XAU**: gold, ISO 4217 code (one troy ounce) — *aur, codul ISO 4217 (o uncie troy)*
- **XFG**: Quantlet prefix of Applied Quantitative Finance (Härdle, Chen & Overbeck) — *prefixul Quantlet-urilor din Applied Quantitative Finance (Härdle, Chen & Overbeck)*

Bibliografie (1/4)

- Acerbi, C., Tasche, D. (2002). On the coherence of expected shortfall. *Journal of Banking & Finance*, 26(7), 1487–1503.
- Artzner, P., Delbaen, F., Eber, J.-M., Heath, D. (1999). Coherent measures of risk. *Mathematical Finance*, 9(3), 203–228.
- Balkema, A.A., de Haan, L. (1974). Residual life time at great age. *Annals of Probability*, 2(5), 792–804.
- Bangia, A., Diebold, F.X., Schuermann, T., Stroughair, J.D. (2001). Modeling liquidity risk, with implications for traditional market risk measurement and management. In *Risk Management: The State of the Art*, Springer, 3–13.
- Barone-Adesi, G., Giannopoulos, K., Vosper, L. (1999). VaR without correlations for portfolios of derivative securities. *Journal of Futures Markets*, 19(5), 583–602.
- Basel Committee on Banking Supervision (1996). Amendment to the capital accord to incorporate market risks. Bank for International Settlements.
- Basel Committee on Banking Supervision (2019). Minimum capital requirements for market risk. Bank for International Settlements.
- Bayer, S., Dimitriadis, T. (2022). Regression-based expected shortfall backtesting. *Journal of Financial Econometrics*, 20(3), 437–471.
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Chen, S.X. (2008). Nonparametric estimation of expected shortfall. *Journal of Financial Econometrics*, 6(1), 87–107.
- Christoffersen, P., Gonçalves, S. (2005). Estimation risk in financial risk management. *Journal of Risk*, 7(3), 1–28.
- Chronopoulos, I., Raftapostolos, A., Kapetanios, G. (2024). Forecasting Value-at-Risk using deep neural network quantile regression. *Journal of Financial Econometrics*, 22(3), 636–669.
- Čížek, P., Härdle, W.K., Weron, R. (Eds.) (2011). Statistical Tools for Finance and Insurance, 2nd ed. Springer.
- Cont, R., Deguest, R., Scandolo, G. (2010). Robustness and sensitivity analysis of risk measurement procedures. *Quantitative Finance*, 10(6), 593–606.
- Cornish, E.A., Fisher, R.A. (1938). Moments and cumulants in the specification of distributions. *Revue de l'Institut International de Statistique*, 5(4), 307–320.

Bibliografie (2/4)

- Daníelsson, J. (2011). Financial Risk Forecasting. Wiley.
- Daníelsson, J., Jorgensen, B.N., Samorodnitsky, G., Sarma, M., de Vries, C.G. (2013). Fat tails, VaR and subadditivity. *Journal of Econometrics*, 172(2), 283–291.
- Daníelsson, J., Zigrand, J.-P. (2006). On time-scaling of risk and the square-root-of-time rule. *Journal of Banking & Finance*, 30(10), 2701–2713.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Dimitriadis, T., Bayer, S. (2019). A joint quantile and expected shortfall regression framework. *Electronic Journal of Statistics*, 13(1), 1823–1871.
- Embrechts, P., Klüppelberg, C., Mikosch, T. (1997). Modelling Extremal Events for Insurance and Finance. Springer.
- Embrechts, P., Puccetti, G., Rüschendorf, L. (2013). Model uncertainty and VaR aggregation. *Journal of Banking & Finance*, 37(8), 2750–2764.
- Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- Ferro, C.A.T., Segers, J. (2003). Inference for clusters of extreme values. *Journal of the Royal Statistical Society: Series B*, 65(2), 545–556.
- Fisher, R.A., Tippett, L.H.C. (1928). Limiting forms of the frequency distribution of the largest or smallest member of a sample. *Mathematical Proceedings of the Cambridge Philosophical Society*, 24(2), 180–190.
- Fissler, T., Ziegel, J.F. (2016). Higher order elicitability and Osband's principle. *Annals of Statistics*, 44(4), 1680–1707.
- Francq, C., Zakoïan, J.-M. (2015). Risk-parameter estimation in volatility models. *Journal of Econometrics*, 184(1), 158–173.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, 5th ed. Springer.
- Giacomini, R., Komunjer, I. (2005). Evaluation and combination of conditional quantile forecasts. *Journal of Business & Economic Statistics*, 23(4), 416–431.
- Gnedenko, B. (1943). Sur la distribution limite du terme maximum d'une série aléatoire. *Annals of Mathematics*, 44(3), 423–453.

Bibliografie (3/4)

- Gneiting, T. (2011). Making and evaluating point forecasts. *Journal of the American Statistical Association*, 106(494), 746–762.
- Gumbel, E.J. (1958). Statistics of Extremes. Columbia University Press.
- Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). Applied Quantitative Finance, 3rd ed. Springer.
- Harvey, D., Leybourne, S., Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291.
- Hill, B.M. (1975). A simple general approach to inference about the tail of a distribution. *Annals of Statistics*, 3(5), 1163–1174.
- Hull, J., White, A. (1998). Incorporating volatility updating into the historical simulation method for value-at-risk. *Journal of Risk*, 1(1), 5–19.
- J.P. Morgan/Reuters (1996). RiskMetrics – Technical Document, 4th ed. New York.
- Koenker, R., Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50.
- Longin, F.M. (2000). From value at risk to stress testing: the extreme value approach. *Journal of Banking & Finance*, 24(7), 1097–1130.
- McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- McNeil, A.J., Frey, R., Embrechts, P. (2015). Quantitative Risk Management: Concepts, Techniques and Tools, revised ed. Princeton University Press.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Newey, W.K., West, K.D. (1994). Automatic lag selection in covariance matrix estimation. *Review of Economic Studies*, 61(4), 631–653.
- Nolde, N., Ziegel, J.F. (2017). Elicitability and backtesting: perspectives for banking regulation. *Annals of Applied Statistics*, 11(4), 1833–1874.
- Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and Value-at-Risk). *Journal of Econometrics*, 211(2), 388–413.

Bibliografie (4/4)

- Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). Modeling expected shortfall using tail entropy. *Entropy*, 21(12), 1204.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). Using high-frequency entropy to forecast Bitcoin's daily value at risk. *Entropy*, 21(2), 102.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *European Journal of Finance*, 29(10), 1064–1105.
- Pickands, J. (1975). Statistical inference using extreme order statistics. *Annals of Statistics*, 3(1), 119–131.
- Rockafellar, R.T., Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41.
- Rockafellar, R.T., Uryasev, S. (2002). Conditional value-at-risk for general loss distributions. *Journal of Banking & Finance*, 26(7), 1443–1471.
- Spierdijk, L. (2016). Confidence intervals for ARMA–GARCH value-at-risk: the case of heavy tails and skewness. *Computational Statistics & Data Analysis*, 100, 545–559.
- Tasche, D. (2008). Capital allocation to business units and sub-portfolios: the Euler principle. arXiv:0708.2542.
- Taylor, J.W. (2019). Forecasting value at risk and expected shortfall using a semiparametric approach based on the asymmetric Laplace distribution. *Journal of Business & Economic Statistics*, 37(1), 121–133.
- Yamai, Y., Yoshiba, T. (2005). Value-at-risk versus expected shortfall: a practical perspective. *Journal of Banking & Finance*, 29(4), 997–1015.