



Modelarea piețelor financiare

Capitolul 7: VaR și Expected Shortfall



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model) (model autoregresiv)
- ARMA: AutoRegressive Moving Average (model) (model autoregresiv cu medie mobilă)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BIS: Bank for International Settlements (Banca Reglementelor Internaționale)
- BNR: Banca Națională a României
- BVB: Bursa de Valori București
- CF: Cornish–Fisher (expansion) (dezvoltarea Cornish–Fisher)
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- CQFE: Conditional Quantile Forecast Encompassing (test) (testul de includere a prognozelor cuantilelor condiționate)
- CV: Cross-Validation (validare încrucișată)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ES: Expected Shortfall (pierderea așteptată în coadă)
- ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- EVT: Extreme Value Theory (teoria valorilor extreme)
- FHS: Filtered Historical Simulation (simulare istorică filtrată)
- FRTB: Fundamental Review of the Trading Book (revizuirea fundamentală a portofoliului de tranzacționare)
- FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GAS: Generalised Autoregressive Score (model) (model cu scor autoregresiv generalizat)
- GEV: Generalised Extreme Value (distribution) (distribuția generalizată a valorilor extreme)
- GPD: Generalised Pareto Distribution (distribuția Pareto generalizată)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- MIDAS: MIXed DATA Sampling (regression) (regresie cu date de frecvențe mixte)
- QML: Quasi-Maximum Likelihood (cvasi-verosimilitate maximă)

Acronime folosite în acest material (2/2)

- RMSFE: Root Mean Squared Forecast Error (rădăcina erorii pătratice medii de prognoză)
- SAV: Symmetric Absolute Value (CAViaR specification) (specificația CAViaR cu valoare absolută simetrică)
- SE: Standard Error (eroare standard)
- SHAP: SHapley Additive exPlanations (explicații aditive Shapley)
- SUA: Statele Unite ale Americii
- UE: Uniunea Europeană
- XFG: Quantlet prefix of Applied Quantitative Finance (Härdle, Chen & Overbeck) (prefixul Quantlet-urilor din Applied Quantitative Finance (Härdle, Chen & Overbeck))

Cuprins

Motivație

VaR și Expected Shortfall

Măsuri de risc coerente

Metode de estimare

Orizontul: regula rădăcinii pătrate

VaR de portofoliu și contribuțiile la risc

Teoria valorilor extreme

Lichiditate și reglementare

Studiu de caz: prognoza VaR cu rețele neuronale

AI pentru descoperire științifică

Sinteză

Bibliografie

Cât putem pierde? RiskMetrics și VaR



Clădirea J.P. Morgan & Co., 23 Wall Street, New York

Foto: [Beyond My Ken \(2012\)](#); CC BY-SA 4.0; [Wikimedia Commons](#)

- Valoarea de mâine a portofoliului este aleatoare; conducerea și autoritățile au nevoie de **un singur număr**: un prag de pierdere depășit rar, folosit la stabilirea limitelor și a cerințelor de **capital**
- J.P. Morgan a lansat **RiskMetrics** în octombrie 1994: o metodologie și un set de date gratuite pentru măsurarea riscului de piață [J.P. Morgan/Reuters \(1996\)](#)
 - ▶ Volatilități și corelații pentru multe piețe, actualizate zilnic
- Documentul tehnic (ed. a 4-a, 1996) a devenit referința pentru VaR; în același an, Comitetul de la Basel a permis băncilor să folosească modele interne VaR pentru capital [Basel Committee \(1996\)](#)
- Manuale: [Franke, Härdle & Hafner \(2019\)](#), [McNeil, Frey & Embrechts \(2015\)](#), [Dánielsson \(2011\)](#)

Datele folosite în acest capitol

Seria	Tip	Perioada	Zile
S&P 500	indice bursier SUA	2000–2026	6 717
BET	indice bursier BVB	2000–2026	6 670
Bitcoin	cripto-activ, 7 zile din 7	2014–2026	4 384
EUR/RON	cursul de referință BNR	2005–2026	5 352
Aur	USD pe uncie troy, zile lucrătoare	2000–2026	6 956
Portofoliu	SPY, TLT, GLD (ETF-uri) și Bitcoin	2014–2026	3 017

- Valori zilnice de închidere până la 18 septembrie 2026; randamente log zilnice în %, $r_t = 100 (\ln P_t - \ln P_{t-1})$
- Fiecare serie pe propriul calendar; portofoliul folosește zilele în care există toate cele patru prețuri
- ETF-uri: prețuri ajustate pentru dividende; SPY replică S&P 500, TLT obligațiunile de stat americane pe termen lung, GLD aurul

Pierderi, orizonturi și probabilități ale cozii

- Randamentul pe o zi: $X_{t+1} = r_{t+1}$, randamentul log în %; **pierdere** $L_{t+1} = -X_{t+1}$, o **pierdere log**
 - ▶ L pozitiv = poziția a pierdut bani; L negativ = un câștig
 - ▶ În bani, cu V_t valoarea poziției: pierdere = $V_t (1 - e^{-L_{t+1}/100}) \approx V_t L_{t+1}/100$ pentru L mic; cu randamente simple R , $V_t (-R_{t+1})/100$ este exactă
 - ▶ VaR se convertește exact prin această transformare monotonă; pentru ES, convertim pierdere din fiecare scenariu, apoi calculăm media
- **Orizontul h** : numărul de zile pe care se măsoară pierdere (1 zi, 10 zile)
- **Nivelul α** : **probabilitatea cozii**, de regulă $\alpha = 1\%$ sau $2,5\%$: „VaR 1%”, „ES 2,5%”
 - ▶ Pentru pierderi continue, α este probabilitatea de a depăși VaR; ES este media pierderilor din această coadă
- **Convenția de semn în acest curs**: VaR și ES sunt numere **pozitive** atunci când sunt pierderi


Definiție: valoarea la risc

- ▣ **VaR** la nivelul α : pierderea depășită cu probabilitatea α (exact pentru L continuă, cel mult α în general)
 - ▶ $\text{VaR}_\alpha(X) = -\inf\{x \in \mathbb{R} : P(X \leq x) > \alpha\} = -q_\alpha(X)$, minus cuantila de ordin α a randamentului
 - ▶ Echivalent, pentru pierderea $L = -X$ cu distribuție continuă: $\text{VaR}_\alpha = q_{1-\alpha}(L)$
- ▣ Citirea VaR 1%: „cu probabilitatea de 1%, pierderea de mâine va depăși $\text{VaR}_{1\%}$ ”
- ▣ Ce **nu** spune VaR: cât de mare este pierderea atunci când depășește VaR
 - ▶ Două portofolii cu același VaR pot avea cozi foarte diferite

Definiție: Expected Shortfall

- ▣ **Expected Shortfall** (pierdere așteptată în coadă): media tuturor cuantilelor din coada de probabilitate α
 - $$ES_{\alpha}(X) = -\frac{1}{\alpha} \int_0^{\alpha} q_u(X) du = \frac{1}{\alpha} \int_0^{\alpha} VaR_u(X) du$$
- ▣ Pentru o distribuție continuă: $ES_{\alpha}(X) = -\mathbb{E}[X \mid X \leq q_{\alpha}(X)]$, pierdere medie în fracțiunea α a zilelor cu cele mai mari pierderi
- ▣ Întotdeauna $ES_{\alpha} \geq VaR_{\alpha}$: ES privește **în interiorul** cozii, VaR doar la intrarea în ea
- ▣ Alte denumiri: Conditional VaR (CVaR), Tail VaR, Average VaR [Rockafellar & Uryasev \(2002\)](#), [Acerbi & Tasche \(2002\)](#)
- ▣ Estimarea istorică: media pierderilor observate mai mari sau egale cu VaR empiric, o aproximare a integralei pe baza distribuției empirice (exactă când $n\alpha$ este întreg)

VaR și ES pentru S&P 500



□ Stânga: pierderile zilnice 2000–2026 și distribuția Normală cu aceeași medie și abatere standard; dreapta: coada

Interpretarea distribuției pierderilor

- ▣ $\text{VaR}_{1\%} \text{ istoric} = 3,45\%$: 68 din 6 717 zile (1,01%) au avut o pierdere mai mare
 - ▶ $\text{ES}_{1\%} = 5,01\%$: în acele zile, pierderea medie a fost de 5,01%
- ▣ $\text{VaR}_{2,5\%} = 2,51\%$ și $\text{ES}_{2,5\%} = 3,76\%$: ES 2,5% depășește VaR 1%
- ▣ Distribuția Normală se potrivește în centru, dar este mult prea subțire în coadă (Capitolul 1): cozi grele
- ▣ Cea mai mare pierdere: 12,77% pe 2020-03-16 (prăbușirea din pandemia COVID-19), aproximativ zece abateri standard

Distribuția Normală: ES într-un rând

- $X \sim N(\mu, \sigma^2)$, $z_\alpha = \Phi^{-1}(\alpha) < 0$, cu Φ , φ funcția de repartiție și densitatea distribuției Normale standard
 - $\text{VaR}_\alpha = -(\mu + \sigma z_\alpha)$; deoarece $\varphi'(u) = -u\varphi(u)$, $\int_{-\infty}^z u\varphi(u) du = -\varphi(z)$
 - $\text{ES}_\alpha = -\mu - \frac{\sigma}{\alpha} \int_{-\infty}^{z_\alpha} u\varphi(u) du = -\mu + \sigma \frac{\varphi(z_\alpha)}{\alpha}$
- Constante: $-z_{1\%} = 2,326$, $\varphi(z_{1\%})/0,01 = 2,665$; $-z_{2,5\%} = 1,960$, $\varphi(z_{2,5\%})/0,025 = 2,338$
- S&P 500 ($\hat{\mu} = 0,025\%$, $\hat{\sigma} = 1,21\%$): $\text{VaR}_{1\%} \text{ Normal} = 2,80\%$ față de $3,45\%$ istoric
 - Prea mic de 1,24 ori; sub distribuția Normală, pentru μ dat, VaR și ES nu aduc informație dincolo de σ

Exemplu lucrat: distribuția Student- t

- $X = m + s T$ cu $T \sim t_\nu$ (locăție m , scală s , grade de libertate ν); $t_\alpha = t_\nu^{-1}(\alpha) < 0$, g_ν densitatea
 - ▶ $\text{VaR}_\alpha = -(m + s t_\alpha)$, $\text{ES}_\alpha = -m + s \frac{g_\nu(t_\alpha)}{\alpha} \frac{\nu + t_\alpha^2}{\nu - 1}$ (pentru $\nu > 1$)
- Dispersia $s^2 \nu / (\nu - 2)$ există doar pentru $\nu > 2$; ν mai mic = cozi mai grele
- Estimare de verosimilitate maximă pe randamentele S&P 500: $\hat{\nu} = 2,67$
 - ▶ $\text{VaR}_{1\%} = 3,46\%$ (istoric 3,45%), $\text{ES}_{1\%} = 5,71\%$ (istoric 5,01%)
- Distribuția t corectează VaR, dar cu $\hat{\nu} < 3$ supraestimează ES: un singur parametru trebuie să potrivească și centrul, și coada


Măsuri de risc coerente: axiome și de ce contează

- O **măsură de risc** ρ asociază unei pierderi L un capital; este **coerentă** dacă Artzner, Delbaen, Eber & Heath (1999)
 - ▶ monotonă: $L_1 \leq L_2 \Rightarrow \rho(L_1) \leq \rho(L_2)$; invariantă la translație: $\rho(L + c) = \rho(L) + c$
 - ▶ pozitiv omogenă: $\rho(\lambda L) = \lambda \rho(L)$, $\lambda \geq 0$; subaditivă: $\rho(L_1 + L_2) \leq \rho(L_1) + \rho(L_2)$
- **Limite**: prin subaditivitate, riscul întregii bănci nu depășește suma limitelor de risc ale birourilor de tranzacționare, $\sum_i \rho_i$; **fără arbitraj de reglementare** prin divizarea firmei
- **Optimizare**: omogenitate + subaditivitate $\Rightarrow$ convexitate în ponderile portofoliului
 - ▶ Orice minim local este global; unicitatea ar cere convexitate **strictă**, pe care ES pe scenarii nu o are (este liniar pe porțiuni)
- VaR satisface primele trei axiome, dar **nu** și subaditivitatea în general

Contraexemplu: două obligațiuni, pas cu pas

- ▣ Obligațiunile A și B, independente; fiecare pierde 100 cu probabilitatea $p = 0,9\%$ (neplată) și 0 altfel
- ▣ **O obligațiune:** $P(X \leq -100) = p = 0,9\%$, nu peste 1%, deci $q_{1\%} = 0$ și $\text{VaR}_{1\%}(A) = \text{VaR}_{1\%}(B) = 0$
 - ▶ $\text{ES}_{1\%}(A) = (100 \cdot 0,009 + 0 \cdot 0,001)/0,01 = 90$
- ▣ **Portofoliul A + B:** $P(X \leq -100) = 1 - (1 - p)^2 = 1,79\% > 1\%$, $P(X \leq -200) = p^2 = 0,0081\%$, deci $q_{1\%} = -100$
 - ▶ $\text{VaR}_{1\%}(A + B) = 100 > 0 + 0 = \text{VaR}_{1\%}(A) + \text{VaR}_{1\%}(B)$
 - ▶ Formula generală pentru o pierdere discretă $L = -X$: $\text{ES}_\alpha = \frac{1}{\alpha} (\mathbb{E}[L \mathbf{1}\{L > \text{VaR}_\alpha\}] + \text{VaR}_\alpha (\alpha - P(L > \text{VaR}_\alpha)))$
- ▣ $\text{ES}_{1\%}(A + B) = 100,81 \leq 180 = \text{ES}_{1\%}(A) + \text{ES}_{1\%}(B)$

Subaditivitatea: VaR eșuează, ES o respectă



□ Albastru: suma celor două măsuri individuale; roșu: măsura portofoliului combinat

Ce ne învață contraexemplul

- VaR ignoră tot ce este dincolo de cuantilă: fiecare obligațiune singură își „ascunde” neplata în ultimul 1%
 - ▶ Împreună, șansa a cel puțin unei neplăți este $1,79\% > 1\%$, iar VaR sare la 100
- O limită bazată pe VaR ar recompensa **concentrarea**: deținerea exclusivă a obligațiunii A pare lipsită de risc
- ES vede mărimea cozii și este coerent [Acerbi & Tasche \(2002\)](#)
 - ▶ Este și convex; cu un număr finit de scenarii, pierderi liniare în ponderi și restricții liniare, minimizarea lui este o problemă de programare liniară [Rockafellar & Uryasev \(2002\)](#)
- Portofoliile de credit, opțiunile și alte câștiguri asimetrice sunt cazurile în care VaR eșuează în practică

ES ca problemă de optimizare: Rockafellar–Uryasev

- **Teoremă Rockafellar & Uryasev (2000):** pentru orice pierdere integrabilă L
 - ▶ $ES_\alpha(L) = \min_{v \in \mathbb{R}} \left\{ v + \frac{1}{\alpha} \mathbb{E}[(L - v)_+] \right\}$, cu $VaR_\alpha(L)$ un punct de minim
- **Demonstrație:** $F(v) = v + \mathbb{E}[(L - v)_+]/\alpha$ este convexă, cu derivata la dreapta $1 - P(L > v)/\alpha$
 - ▶ Este ≥ 0 exact când $P(L > v) \leq \alpha$, adică $v \geq VaR_\alpha$; $F(VaR_\alpha)$ este formula ES discretă de pe slide-ul celor două obligațiuni
- **Corolar:** $(w, v) \mapsto v + \mathbb{E}[(-w^\top R - v)_+]/\alpha$ este convexă simultan în ambele argumente; minimizarea în raport cu v păstrează convexitatea
 - ▶ ES este convex în w ; împreună cu omogenitatea pozitivă, aceasta **demonstrează** subaditivitatea
- Pierderile S&P 500, $\alpha = 2,5\%$: $\arg \min F = 2,51\%$, $\min F = 3,76\%$; VaR și ES istorice (cuantilă interpolată, medie în coadă): $2,51\%$ și $3,76\%$, egale doar după rotunjire (punctul de minim empiric este o statistică de ordine)

Portofoliul cu ES minim: o problemă de programare liniară

- Cu N scenarii istorice R_s , funcția Rockafellar–Uryasev devine o problemă de **programare liniară** Rockafellar & Uryasev (2000)
 - ▶ $\min_{w,v,u} v + \frac{1}{\alpha N} \sum_s u_s$ cu restricțiile $u_s \geq -w^\top R_s - v$, $u_s \geq 0$, $\sum_i w_i = 1$, $w \geq 0$
- SPY, TLT, GLD, Bitcoin, 3 017 zile comune, $\alpha = 2,5\%$: ponderi 31% / 44% / 25% / 0%
 - ▶ $ES_{2,5\%} = 1,67\%$, față de 2,15% pentru portofoliul 40/30/20/10 din Secțiunea 6
- Dispersie minimă fără vânzări în lipsă: 35% / 43% / 22% / 0%, $ES_{2,5\%} = 1,67\%$: pentru aceste active cele două criterii aproape coincid
- Ele diverg pentru opțiuni și credit, unde coada nu este o funcție de dispersie
- Funcția obiectiv este liniară pe porțiuni: mai multe portofolii pot atinge același minim, deci raportăm soluția împreună cu scenariile ei din coadă

Când este totuși VaR subaditiv?

- Pierderi cu distribuție **eliptică comună** (distribuția Normală multivariată, distribuția Student- t multivariată) și $\alpha < 0,5$: VaR este subaditiv [McNeil, Frey & Embrechts \(2015\)](#)
 - ▶ Acolo VaR și ES sunt ambele $\mu_p + \sigma_p \times$ constantă, cu $\sigma_p \leq \sum_i \sigma_i$; marginale Normale sau t nu sunt suficiente singure
- **Cozi grele, dar nu prea grele**: pentru pierderi cu variație regulată multivariată și indice de coadă peste 1, VaR este subaditiv suficient de departe în coadă (asimptotic, când $\alpha \rightarrow 0$) [Danielsson et al. \(2013\)](#)
 - ▶ Indicii de coadă estimați pentru acțiuni și cursuri de schimb sunt în acest domeniu (între 4,8 și 6,5 în Secțiunea 7), dar rezultatul este asimptotic, nu o garanție la un α dat
- Eșuează pentru salturi discrete (neplăți), cozi extrem de grele și unele câștiguri din opțiuni
- VaR vs ES în practică: ES are nevoie de mai multe date pentru aceeași precizie [Yamai & Yoshida \(2005\)](#)

Coerență versus robustețe

- **Robustețe calitativă:** o mică schimbare a distribuției datelor modifică doar puțin distribuția estimatorului [Cont, Deguest & Scandolo \(2010\)](#)
 - ▶ În distribuțiile cu α -cuantilă unică, VaR istoric este calitativ robust; ES istoric **nu**: funcția sa de influență $VaR_\alpha + (x - VaR_\alpha)_+ / \alpha - ES_\alpha$ este nemărginită în x
- S&P 500, ultimele 500 de zile: eliminăm cea mai mare pierdere (6,16%, 2025-04-04)
 - ▶ $ES_{2,5\%}: 2,94\% \rightarrow 2,60\%$; $VaR_{1\%}: 2,73\% \rightarrow 2,68\%$
- Există un compromis: subaditivitatea cere coada de dincolo de cuantilă, exact ce face ES sensibil la observații izolate
- FRTB a ales coerența pentru capital ($ES_{2,5\%}$) și a păstrat VaR, robust și elicibil, pentru testarea retrospectivă

Agregarea VaR sub incertitudinea dependenței

- Marginale $F_1, \dots, F_d$ cunoscute, copula necunoscută (Capitolul 6): $\text{VaR}_\alpha(\sum_i L_i)$ se află într-un interval Embrechts, Puccetti & Rüschendorf (2013)
 - ▶ Valoarea comonotonă $\sum_i \text{VaR}_\alpha(L_i)$ **nu** este capătul superior: VaR nu este subaditiv
- **Algoritmul de rearanjare**: discretizăm coada de dincolo de fiecare $\text{VaR}_\alpha(L_i)$ în N puncte (o coloană pe activ)
 - ▶ Ordonăm fiecare coloană invers față de suma celorlalte până când sumele pe rânduri devin uniforme; VaR maxim $\approx$ cea mai mică sumă pe rând
- Portofoliul 40/30/20/10 din Secțiunea 6, $\text{VaR}_{1\%}$ zilnic, marginale empirice, $N = 2\,000$
 - ▶ Dependența istorică 1,95%; comonotonă 3,63%; cazul cel mai rău 4,76% ($1,31 \times$ valoarea comonotonă)
- Incertitudinea privind modelul dependenței afectează capitalul bazat pe VaR cu un ordin de mărime comparabil cu beneficiul diversificării

Anticipare: elicitabilitatea (Capitolul 8)

- O măsură de risc este **elicitabilă** dacă minimizează valoarea așteptată a unei funcții de scor
 - ▶ VaR: cuantila $q_\alpha(X)$ minimizează funcția de pierdere pinball $\mathbb{E}[(1\{X \leq v\} - \alpha)(v - X)]$
- ES, considerat separat, **nu** este elicitabil [Gneiting \(2011\)](#): nu există o funcție de scor strict consistentă pentru prognozele ES evaluate separat
- Dar perechea (VaR, ES) este elicitabilă împreună [Fissler & Ziegel \(2016\)](#)
- Consecință: compararea prognozelor de ES este mai dificilă decât a celor de VaR
 - ▶ Precizia ES este dată de numărul de observații din coadă $n\alpha$, nu de n [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)
 - ▶ S&P 500, 26 de ani: doar 168 zile în coada lui ES 2,5%

Entropia și riscul de piață

- **Entropia diferențială** a unei densități f : $H(L) = - \int f(x) \ln f(x) dx$, o măsură a dispersiei fără momente
 - ▶ Pentru o familie locație-scală $L = \mu + \sigma Z$: $H(L) = \ln \sigma + H(Z)$, deci $\text{VaR}_\alpha = \mu + e^{H(L)-H(Z)} q_{1-\alpha}(Z)$
- **Pele, Lazar & Dufour (2017)**: entropia randamentelor intrazilnice este legată de VaR și ES intrazilnice și ajută la prognoza VaR zilnic (EUR/JPY)
- **Pele & Mazurencu-Marinescu-Pele (2019)**: entropia din date de înaltă frecvență dă cele mai bune prognoze VaR zilnice pentru Bitcoin dintre modelele comparate
- **Pele, Lazar & Mazurencu-Marinescu-Pele (2019)**: o măsură neparametrică bazată pe entropia cozii, ca estimator alternativ pentru ES

Recapitulare: coerența

- Coerență = monotonie, invarianță la translație, omogenitate pozitivă și subaditivitate
- VaR poate încălca subaditivitatea (exemplul cu două obligațiuni); ES niciodată: Rockafellar–Uryasev îl scrie ca minim convex
- Coerența costă robustețe, iar agregarea VaR depinde de copula necunoscută
- VaR este subaditiv pentru randamente cu distribuție eliptică comună; pentru cozi cu variație regulată și indice peste 1, doar asimptotic, departe în coadă
- VaR este elicitable, iar ES, considerat separat, nu este elicitable: această proprietate determină metodele de testare retrospectivă din Capitolul 8

Cinci familii de metode

Metoda	Ipoteza	Punctul slab
Simulare istorică	Ultimele n zile sunt o selecție din distribuția de mâine	Reacție lentă; nicio pierdere peste cea mai mare observată
Parametrică (distribuția Normală, t , Cornish–Fisher)	O familie de distribuții cu parametri estimați	Familie greșită = coadă greșită
Simulare istorică filtrată	Volatilitate GARCH $\times$ reziduuri standardizate empirice	Depinde de modelul de volatilitate
Monte Carlo	Traietorii simulate dintr-un model estimat	Riscul de model; timpul de calcul
Teoria valorilor extreme	Doar coada urmează o lege limită	Alegerea pragului; puține date

- Fiecare metodă dă VaR și ES din aceeași distribuție estimată: ES_α este media lui VaR_u , $u < \alpha$

Simularea istorică

- Luăm ultimele n pierderi zilnice $L_{t-n+1}, \dots, L_t$ și le ordonăm: $L_{(1)} \leq \dots \leq L_{(n)}$
 - ▶ $\widehat{\text{VaR}}_\alpha =$ cuantila empirică de ordin $(1 - \alpha)$, interpolată liniar în poziția $1 + (n - 1)(1 - \alpha)$ a pierderilor ordonate (convenția folosită peste tot)
 - ▶ $\widehat{\text{ES}}_\alpha =$ media celor k_α pierderi $\geq \widehat{\text{VaR}}_\alpha$, $k_\alpha \approx n\alpha$; înlocuirea exactă în integrală dă pierderii de la frontieră ponderea $n\alpha - \lfloor n\alpha \rfloor$, deci cele două coincid doar când $n\alpha$ este întreg (pierderi distincte)
- Nicio ipoteză de distribuție: cozile grele și asimetria sunt păstrate automat
- Alegerea ferestrei n : estimarea pe 250 de zile reacționează mai repede, iar cea pe 1000 de zile este mai precisă
 - ▶ Cu $n = 500$: 5 pierderi se află dincolo de VaR 1%; ES 2,5% este media a $k = 13$ pierderi ($n\alpha = 12,5$)
- **Efectul fantomă**: o zi de criză intră în fereastră, rămâne n zile, apoi iese și VaR scade brusc

Cât de precise sunt VaR și ES istorice? Teoria asimptotică

- **VaR**: pentru pierderi i.i.d. cu densitatea f continuă și pozitivă în VaR_α ,

$$\sqrt{n}(\widehat{\text{VaR}}_\alpha - \text{VaR}_\alpha) \rightarrow N\left(0, \frac{\alpha(1-\alpha)}{f(\text{VaR}_\alpha)^2}\right)$$
 - Densitatea este mică în coadă: $\sigma = 1,2\%$, $n = 500$, $\text{VaR}_{1\%}$ are SE 0,20 puncte procentuale sub distribuția Normală și 0,43 sub o t_4 cu același σ
- **ES Chen (2008)**: funcția de influență $\text{IF}(x) = \text{VaR}_\alpha + (x - \text{VaR}_\alpha)_+/\alpha - \text{ES}_\alpha$
 - Niciun termen din estimarea VaR: $\partial F/\partial v = 0$ în $v = \text{VaR}_\alpha$ (Rockafellar–Uryasev); dacă $\mathbb{E}[(L - \text{VaR}_\alpha)_+^2] < \infty$, dispersia limitei lui $\sqrt{n}(\widehat{\text{ES}}_\alpha - \text{ES}_\alpha)$ este avar $= \text{Var}((L - \text{VaR}_\alpha)_+)/\alpha^2$
 - Coadă de tip Pareto cu indicele $a > 2$, $\alpha \rightarrow 0$: $\text{Var}((L - \text{VaR}_\alpha)_+) \approx \frac{2\alpha \text{VaR}_\alpha^2}{(a-1)(a-2)}$, deci $\text{SE} \propto \text{VaR}_\alpha/\sqrt{n\alpha}$: eroarea **relativă** scade ca $1/\sqrt{n\alpha}$, iar numărul de observații din coadă $n\alpha$ guvernează precizia [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)
- Gruparea volatilității (pierderi staționare, slab dependente): înlocuim dispersiile cu dispersiile de termen lung (HAC) ale lui $1\{L_t > \text{VaR}_\alpha\}$ și $(L_t - \text{VaR}_\alpha)_+$ [Newey & West \(1987\)](#), sau folosim un bootstrap pe blocuri

Precizia pentru S&P 500


	n	$\widehat{\text{VaR}}_{1\%}$	SE i.i.d.	SE HAC	$\widehat{\text{ES}}_{2,5\%}$	SE i.i.d.	SE HAC
2000–2026	6 717	3,45	0,13	0,19	3,76	0,15	0,26
Ultimele 500 de zile	500	2,73	0,36	0,44	2,94	0,48	0,65

- Densitatea $f(\text{VaR})$ prin nucleu Gaussian (lățimea de bandă Silverman); HAC: nucleu Bartlett, decalaj $\lfloor 4(n/100)^{2/9} \rfloor$ (10 și 5) Newey & West (1994)
- Eșantionul complet, lățimea intervalului de încredere de 95% pentru ES: 0,60 (i.i.d.) și 1,00 (HAC)
 - Seminarul 7, B6: bootstrap i.i.d. 0,62, bootstrap pe blocuri 1,16: lățimile asimptotice sunt apropiate de amândouă
- Gruparea crește SE cu 50–70% pe selecția completă; cu 500 de zile, ES 2,5% este media a 13 pierderi ($n\alpha = 12,5$), iar intervalul HAC de 95% este $\pm 1,27$ puncte procentuale

Dezvoltarea Cornish–Fisher

- ▣ Ajustăm cuantila Normală pentru **asimetrie** $S = \mathbb{E}[(X - \mu)^3]/\sigma^3$ și **excesul de aplatizare** $K = \mathbb{E}[(X - \mu)^4]/\sigma^4 - 3$ **Cornish & Fisher (1938)**
 - ▶ $\tilde{z}_\alpha = z_\alpha + \frac{(z_\alpha^2 - 1)S}{6} + \frac{(z_\alpha^3 - 3z_\alpha)K}{24} - \frac{(2z_\alpha^3 - 5z_\alpha)S^2}{36}, \quad \text{VaR}_\alpha = -(\mu + \sigma\tilde{z}_\alpha), \text{ cu } z_\alpha < 0$
- ▣ ES: media lui $-(\mu + \sigma\tilde{z}_u)$ pe $u \in (0, \alpha)$, calculată numeric
- ▣ O dezvoltare în jurul distribuției Normale: precisă doar pentru S și K **mici**
- ▣ Randamentele S&P 500: $S = -0,35$, $K = 10,7$: mult în afara acestui domeniu
 - ▶ $\text{VaR}_{1\%}^{CF} = 6,08\%$ față de valoarea istorică $3,45\%$: termenul de aplatizare depășește ținta

Cinci metode la diferite niveluri de risc



□ Pierderile zilnice S&P 500 2000–2026; probabilități ale cozii α de la 5% până la 0,1%

Interpretarea curbelor pe niveluri


- VaR 0,1% (o zi în patru ani): istoric 7,22%, din valori extreme 7,04%
 - ▶ Distribuția Normală: 3,72%, aproximativ jumătate; Student- t : 8,58%; Cornish–Fisher: 15,06%
- Diferența dintre metode **crește** când α scade: cu cât intrăm mai adânc în coadă, cu atât modelul contează mai mult
- Curbele ES se depărtează mai mult decât cele VaR: ES depinde de întreaga formă a cozii
- Estimările din valori extreme și cele istorice coincid până la $\alpha = 0,5\%$; mai departe în coadă, simularea istorică se bazează pe tot mai puține observații, iar EVT extrapolează cu un model estimat al cozii (și distribuțiile Normală și t extrapolează, dar pornind de la întreaga distribuție)

VaR și ES pe metode și active

	VaR _{1%} (%)					ES _{2,5%} (%)				
	Ist.	Distr. Normală	<i>t</i>	CF	EVT	Ist.	Distr. Normală	<i>t</i>	CF	EVT
S&P 500	3,45	2,80	3,46	6,08	3,54	3,76	2,81	3,95	6,65	3,78
BET	4,13	3,19	4,06	7,25	4,22	4,57	3,21	4,76	7,93	4,58
Bitcoin	10,51	7,99	11,06	18,89	10,23	10,84	8,03	13,37	20,69	10,84
EUR/RON	0,76	0,64	1,36	1,43	0,78	0,84	0,65	3,27	1,60	0,84
Aur	3,04	2,50	3,00	4,64	3,07	3,23	2,51	3,27	5,02	3,23

- Pierderi zilnice, selecțiile complete; CF = Cornish–Fisher, EVT = coada Pareto generalizată estimată pe cele mai mari 5% dintre pierderi (Secțiunea 7)
- Bitcoin necesită o rezervă de aproximativ trei ori mai mare decât cea pentru S&P 500; EUR/RON de aproximativ o cincime

Metodele comparate pe cinci active



□ Bare pline: $\text{VaR}_{1\%}$; bare hașurate: $\text{ES}_{2.5\%}$; pierderi zilnice în %

Ce nu funcționează și unde

- **Distribuția Normală:** produce estimări prea mici pentru toate seriile, de ex. Bitcoin $\text{VaR}_{1\%}$ 7,99% vs 10,51%
 - ▶ ES 2,5% este aproape egal cu VaR 1%: coada Normală este subțire
- **Cornish–Fisher:** excesul de aplatizare peste 7 în toate seriile o face să depășească ținta, de ex. BET 7,25% vs 4,13%
 - ▶ Aplatizare: S&P 500 10,7, BET 11,1, Bitcoin 12,0, EUR/RON 15,1, aur 7,7
- **Student- t :** VaR bun, dar EUR/RON dă $\hat{\nu} = 1,25$ (dispersie infinită) și un ES absurd de 3,27%
 - ▶ Vârful format de numeroasele variații aproape nule ale cursului de referință împinge $\hat{\nu}$ în jos
- **Teoria valorilor extreme:** apropiată de simularea istorică pentru VaR 1% în toate cele cinci serii, cu o coadă netedă dincolo de ea

Simularea istorică filtrată

- Ideea Barone-Adesi, Giannopoulos & Vosper (1999), Hull & White (1998): istoria dă **forma** șocurilor, un model GARCH dă **scala** de azi
 - ▶ $r_t = \mu_t + \sigma_t z_t$, $\mu_t = c + \phi r_{t-1}$, $\sigma_t^2 = \omega + \alpha_1 (r_{t-1} - \mu_{t-1})^2 + \beta_1 \sigma_{t-1}^2$ (Capitolul 5, Bollerslev (1986))
- Pasul 1: estimăm modelul AR(1)-GARCH(1,1) prin cvasi-verosimilitate maximă (verosimilitate Normală, robustă la alte distribuții ale șocurilor)
- Pasul 2: reziduuri standardizate $\hat{z}_t = (r_t - \hat{\mu}_t) / \hat{\sigma}_t$: aproximativ i.i.d., tot cu cozi grele
- Pasul 3: rescalăm cu volatilitatea de mâine
 - ▶ $\text{VaR}_{\alpha, t+1} = -(\hat{\mu}_{t+1} + \hat{\sigma}_{t+1} q_\alpha(\hat{z}))$, $\text{ES}_{\alpha, t+1} = -\hat{\mu}_{t+1} - \hat{\sigma}_{t+1} \overline{(\hat{z} \mid \hat{z} \leq q_\alpha(\hat{z}))}$

Filtrele GARCH și volatilitatea de mâine

	$\hat{\phi}$	$\hat{\alpha}_1$	$\hat{\beta}_1$	$\hat{\alpha}_1 + \hat{\beta}_1$	$\hat{\sigma}$ (selecție)	$\hat{\sigma}_{t+1}$	$-q_1\%(\hat{z})$
S&P 500	-0,053	0,120	0,860	0,981	1,21	0,73	2,79
BET	0,104	0,207	0,787	0,994	1,40	1,76	2,74
Bitcoin	-0,009	0,127	0,843	0,970	3,49	3,00	2,88
EUR/RON	0,169	0,200	0,780	0,980	0,28	0,11	2,74
Aur	-0,022	0,046	0,943	0,989	1,09	1,43	2,68

- $\hat{\sigma}_{t+1}$: prognoza pentru prima zi de tranzacționare de după 18 septembrie 2026 (19 septembrie pentru Bitcoin), în %
- Persistența $\hat{\alpha}_1 + \hat{\beta}_1$ aproape de 1: șocurile de volatilitate se sting încet (Capitolul 5)
- S&P 500 și EUR/RON sunt calme azi ($\hat{\sigma}_{t+1}$ sub valoarea din selecție); BET și aurul sunt agitate
- $-q_1\%(\hat{z})$ este între 2,68 și 2,88, peste $-z_{1\%} = 2,326$: șocurile filtrate au tot cozi grele

VaR și ES condiționate pentru următoarea zi de tranzacționare

	VaR _{1%} (%)				ES _{1%} (%)			
	GARCH	FHS	c-EVT	Ist.	GARCH	FHS	c-EVT	Ist.
S&P 500	1,63	1,97	2,03	3,45	1,88	2,55	2,56	5,01
BET	3,80	4,53	4,63	4,13	4,39	6,16	6,20	6,28
Bitcoin	6,89	8,56	8,68	10,51	7,90	12,22	12,19	14,29
EUR/RON	0,23	0,27	0,26	0,76	0,27	0,34	0,35	1,12
Aur	3,32	3,82	3,86	3,04	3,80	4,94	4,93	4,21

- GARCH: GARCH cu șocuri Normale; c-EVT: teoria valorilor extreme condiționată (Secțiunea 7); Ist.: necondiționat, întreaga selecție
- Estimările condiționate variază odată cu condițiile de piață: VaR FHS pentru S&P 500 este azi 1,97% față de 3,45% necondiționat
- GARCH cu șocuri Normale dă cea mai mică valoare dintre cele trei metode condiționate pe fiecare rând: volatilitatea singură nu creează coada


Riscul de estimare în VaR condiționat

- $\text{VaR}_{\alpha, t+1} = -\mu_{t+1}(\theta) + \sigma_{t+1}(\theta) \xi_{\alpha}$, $\xi_{\alpha} = -q_{\alpha}(z)$: **atât** θ (GARCH, prin QML), cât și ξ_{α} (o cuantilă a reziduurilor) sunt estimați
 - ▶ Tabelul de mai sus dă prognoze punctuale; un comitet de risc are nevoie și de o evaluare a erorii lor de eșantionare
- **Francq & Zakoïan (2015)**: estimăm împreună **parametrul de risc** (θ, ξ_{α}) ; sub staționaritate strictă, $\mathbb{E}[z_t^4] < \infty$ și o densitate pozitivă a lui z în $q_{\alpha}(z)$, VaR condiționat este asimptotic Normal (consistența QML singură cere mai puțin), cu o dispersie provenind din $\hat{\theta}$, din $\hat{\xi}_{\alpha}$ și din covarianța lor
- **Bootstrap pe reziduuri Christoffersen & Gonçalves (2005)**: simulăm traiectorii AR(1)-GARCH(1,1) cu $\hat{z}$ reeșantionate și re-estimăm θ^* pe fiecare
 - ▶ σ_{t+1}^* din randamentele **originale** cu θ^* ; ξ_{α}^* din reziduurile traiectoriei; interval percentil al lui VaR_{t+1}^*
- Cozile grele și asimetria lui z încetinesc convergența; **Spierdijk (2016)** compară metodele de construire a intervalelor de încredere pentru VaR ARMA-GARCH în acest caz

Un interval de încredere pentru VaR FHS de azi

- ▣ S&P 500, 999 traiectorii bootstrap: $\text{VaR}_{1\%} \text{ FHS} = 1,97\%$, interval de 90% $[1,90; 2,09]\%$
- ▣ Cele două surse: $\hat{\sigma}_{t+1} = 0,725 [0,708; 0,743]$; $\hat{\xi}_{1\%} = 2,79 [2,68; 2,88]$
 - Variaza doar cuantila: $[1,89; 2,03]$; variaza doar σ_{t+1} : $[1,92; 2,02]$: cuantila reziduurilor (circa 67 de reziduuri în coadă) este sursa mai mare
- ▣ EVT condiționată (2,03%) se află în interval, GARCH cu șocuri Normale (1,63%) mult sub el
- ▣ Azi alegerea modelului pentru coadă contează mai mult decât eroarea de estimare a unui model dat

Simulare istorică vs simulare istorică filtrată: S&P 500




- $\text{VaR}_{1\%}$ prognozat zilnic pentru ziua următoare; parametrii GARCH re-estimați în fiecare ianuarie pe toate datele anterioare, deci fără informație din viitor

Interpretarea comparației pentru S&P 500

- ▣ Proporția zilelor cu pierdere peste VaR 1%, 2006–2026 (5 210 zile; ținta $\alpha = 1\%$)
 - ▶ Istorică, 500 de zile: 1,67%; filtrată: 1,54%; GARCH cu șocuri Normale: 2,34%
- ▣ VaR istoric variază între 1,49% și 6,32%; VaR filtrat între 1,09% și 18,01% (maxim pe 2020-03-18)
- ▣ Depășirile VaR istoric apar în **grupuri** (2008, 2020): fereastra reacționează cu luni de întârziere
- ▣ VaR filtrat împrăștie depășirile în timp: exact ce trebuie să facă o prognoză bună (teste formale în Capitolul 8)

Simulare istorică vs simulare istorică filtrată: Bitcoin



□ Aceeași construcție ca pentru S&P 500; prognoze din ianuarie 2017, 7 zile din 7

 MFM_ch7_hs_fhs_btc

Interpretarea comparației pentru Bitcoin

- ▣ Proporția zilelor cu pierderi peste VaR (3 548 zile): istorică 1,16%, filtrată 0,76%, GARCH cu șocuri Normale 1,58%
- ▣ VaR filtrat a atins 54,83% în martie 2020, imediat după prăbușirea din 2020-03-12 (pierdere log de 46,47% într-o zi, o scădere a prețului de 37,17%)
- ▣ Volatilitatea Bitcoin a scăzut după 2022; VaR istoric pe 500 de zile urmează cu o întârziere mare
- ▣ Criptoactivele ca o clasă distinctă de active, cu propriul profil de risc: [Pele et al. \(2023\)](#)


Simularea Monte Carlo

- ▣ Simulăm multe scenarii viitoare dintr-un model estimat; citim VaR și ES din pierderile simulate
 - ▶ Necesară când pierderea este o funcție neliniară de factorii de risc (opțiuni) sau orizontul are mai multe zile
- ▣ **Monte Carlo filtrat** pe h zile: repetăm pentru $j = 1, \dots, M$
 - ▶ extragem $z_{t+1}^{(j)}, \dots, z_{t+h}^{(j)}$ cu revenire din reziduurile standardizate $\hat{z}$
 - ▶ actualizăm $\sigma^{(j)}$ și $r^{(j)}$ zi de zi cu recursia GARCH; $L^{(j)} = -\sum_{i=1}^h r_{t+i}^{(j)}$
- ▣ $\widehat{\text{VaR}}_\alpha, \widehat{\text{ES}}_\alpha$ = estimările istorice pe cele M pierderi simulate; eroarea de simulare scade ca $1/\sqrt{M}$
- ▣ Păstrează gruparea volatilității, cozile grele și revenirea volatilității la medie pe parcursul orizontului

Modelarea directă a cuantilei: CAViaR

- CAViaR (Conditional Autoregressive Value at Risk, valoarea la risc condițională autoregresivă) [Engle & Manganelli \(2004\)](#): cuantila urmează propria recursie; specificația SAV
 - ▶ $\text{VaR}_t = \beta_0 + \beta_1 \text{VaR}_{t-1} + \beta_2 |r_{t-1}|, \quad q_t = -\text{VaR}_t$
- **Regresie cuantilă** [Koenker & Bassett \(1978\)](#): minimizăm pierderea pinball, fără ipoteze asupra distribuției șocurilor
 - ▶ $\hat{\beta} = \arg \min_{\beta} \sum_t (\alpha - 1\{r_t < q_t(\beta)\})(r_t - q_t(\beta))$: elicitabilitatea devenită estimator
- Strategia de estimare publicată: 10^4 puncte de start aleatoare în $(0, 1)^3$, cele mai bune 10 rafinate prin pași simplex și quasi-Newton; $\text{VaR}_1 = -\hat{q}_\alpha$ al primelor 300 de randamente (cuantila superioară a pierderilor), zile păstrate în eșantionul de estimare
- S&P 500, $\alpha = 1\%$, estimat pe 2000–2015 (4 024 zile): $\hat{\beta}_0 = 0,090$, $\hat{\beta}_1 = 0,897$, $\hat{\beta}_2 = 0,246$
 - ▶ Timpul de înjumătățire al unui șoc asupra VaR: $\ln 0,5 / \ln \hat{\beta}_1 = 6,4$ zile

CAViaR vs simulare istorică filtrată, în afara eşantionului



- S&P 500, 2016–2026: CAViaR cu parametrii fixați pe 2000–2015; FHS re-estimat în fiecare ianuarie pe toate datele anterioare

Interpretarea comparației CAViaR

- 2016–2026 (2 693 zile), proporția zilelor cu pierderi peste VaR 1%: CAViaR 1,30% (35), FHS 1,30% (35), istorică pe 500 de zile 1,41% (38)
 - ▶ Pierderea pinball medie (o valoare mai mică este preferabilă): CAViaR 0,039, FHS 0,037, istorică 0,052
- Fereastra COVID-19, 20 februarie – 30 aprilie 2020 (50 de zile): depășiri CAViaR 6, FHS 3, istorică 9
 - ▶ VaR maxim: CAViaR 13,5%, FHS 18,0%, istoric 4,5%
- CAViaR reacționează liniar la $|r_{t-1}|$, GARCH la r_{t-1}^2 : după o prăbușire VaR estimat prin FHS crește mai mult și înregistrează mai puține depășiri
- Pe întregul deceniu, cele două modele condiționate sunt apropiate; dacă diferența este semnificativă este o întrebare pentru Capitolul 8

Modele comune pentru VaR și ES

- ES singur nu este elicibil, dar perechea (VaR, ES) este [Fissler & Ziegel \(2016\)](#): poate fi **estimată** prin minimizarea unui scor comun strict consistent
 - ▶ Capitolul 8 folosește aceleași scoruri pentru a **evalua** prognozele
- [Patton, Ziegel & Chen \(2019\)](#): modele semiparametrice dinamice pentru (VaR, ES), de ex. cu dinamică GAS, estimate prin minimizarea pierderii FZ0; consistență și normalitate asimptotică
- [Taylor \(2019\)](#): recursii de tip CAViaR pentru VaR și ES, estimate printr-o verosimilitate Laplace asimetrică
- [Dimitriadis & Bayer \(2019\)](#): regresie liniară a cuantilei și a ES pe covariate (volatilitate realizată, volatilitate implicită), cu erori standard
- Firul comun: funcția de scor care ordonează prognozele este și funcția obiectiv care estimează modelul



Recapitulare: metode

- ▣ Simularea istorică: simplă și fără model, dar lentă și oarbă dincolo de cea mai mare pierdere observată; precizia ES este dată de $n\alpha$
- ▣ Distribuția Normală: subestimează coada; Cornish–Fisher: nesigură cu aplatizarea randamentelor zilnice
- ▣ Student- t : o coadă bună cu un singur parametru, fragilă când $\hat{\nu}$ se apropie de 2
- ▣ Simularea istorică filtrată și Monte Carlo: volatilitatea de azi + forma empirică a șocurilor; alegerea noastră implicită pentru riscul zilnic, raportată cu interval bootstrap
- ▣ CAViaR și modelele comune (VaR, ES) estimează măsura de risc direct prin funcția ei de scor

Regula rădăcinii pătrate a timpului: ipoteze și eșecuri

- ▣ Pierderi zilnice i.i.d. $N(0, \sigma^2)$: $\text{VaR}_\alpha^{(h)} = \sqrt{h} \text{VaR}_\alpha^{(1)}$, $\text{ES}_\alpha^{(h)} = \sqrt{h} \text{ES}_\alpha^{(1)}$; Basel 1996 a permis $\sqrt{10} = 3,162$ [Basel Committee \(1996\)](#)
 - ▶ Cere medie zero, fără autocorelație, volatilitate constantă și șocuri Normale; fiecare este încălcată de date (Capitolele 1, 2, 5)
- ▣ **Autocorelație**: $\text{Var}(r_{t+1} + \dots + r_{t+h}) = h\sigma^2 \text{VR}(h)$ (raportul dispersiilor, Capitolul 2)
 - ▶ $\text{VR} > 1$: $\sqrt{h}$ **subestimează** riscul pe h zile
- ▣ **Gruparea volatilității**: volatilitatea revine la medie pe h zile; calm azi $\Rightarrow \sqrt{h}$ prea mic, agitație azi $\Rightarrow$ prea mare
- ▣ **Cozi grele**: pentru șocuri i.i.d. cu indice de coadă $a > 2$, cuantila extremă a unei sume crește ca $h^{1/a} < \sqrt{h}$ [Dánielsson \(2011\)](#)
 - ▶ Cu salturi, regula poate greși mult riscul pe mai multe zile [Dánielsson & Zigrand \(2006\)](#)

Regula rădăcinii pătrate în date



- Stânga: $\text{VaR}_{1\%}$ empiric al pierderilor suprapuse pe h zile, împărțit la $\sqrt{h}$ ori valoarea pe o zi; dreapta: Monte Carlo filtrat, 200 000 de traiectorii

Interpretarea graficului orizontului

- Raportul la $h = 10$: BET 1,22 (autocorelația de ordin 1 0,109), EUR/RON 1,05 (0,170)
 - ▶ S&P 500 0,95 (−0,099), aur 0,92, Bitcoin 0,89: cozile grele și inversarea fac regula $\sqrt{h}$ conservatoare
- S&P 500 azi: $\hat{\sigma}_{t+1} = 0,73\%$ față de 1,21% în selecție
 - ▶ $\text{VaR}_{1\%}$ pe 10 zile: Monte Carlo filtrat 6,29%; $\sqrt{10} \times \text{VaR}$ filtrat pe o zi 6,22%; $\sqrt{10} \times \text{VaR}$ istoric pe o zi 10,92%
- Revenirea volatilității la medie și cozile grele ale șocurilor aproape se compensează aici
- Diferența mare este condiționat vs necondiționat, nu $\sqrt{h}$ vs simulare

Recapitulare: orizontul

- ▣ $\sqrt{h}$ este exactă doar pentru pierderi i.i.d. Normale cu medie zero
- ▣ Autocorelația pozitivă (BET) o face prea mică; cozile grele și inversarea (S&P 500, Bitcoin), prea mare
- ▣ Simularea dintr-un model filtrat tratează toate efectele deodată
- ▣ Estimările istorice directe pe h zile folosesc sume suprapuse: mai puține observații independente

VaR de portofoliu și alocarea Euler


- Ponderi w , randamente simple R cu covarianța Σ (randamentele simple se adună între active); $L_p = -w^\top R$
 - ▶ Sub distribuția Normală, neglijând media: $\text{VaR}_\alpha(L_p) = z_{1-\alpha}\sigma_p$, $\sigma_p = \sqrt{w^\top \Sigma w}$; pentru ponderi nenegative $w \geq 0$, VaR nediversificat $\sum_i z_{1-\alpha} w_i \sigma_i$ este mai mare, cu excepția corelațiilor egale cu 1
- **VaR marginal** $\partial \text{VaR}_\alpha / \partial w_i = z_{1-\alpha}(\Sigma w)_i / \sigma_p$; **VaR pe componente** $C_i = w_i \partial \text{VaR}_\alpha / \partial w_i$
 - ▶ Teorema lui Euler pentru o funcție omogenă de grad 1: $\sum_i w_i \partial \rho / \partial w_i = \rho$, deci $\sum_i C_i = \text{VaR}_\alpha$ Tasche (2008)
- ES, fără ipoteză de distribuție (pierderi continue): $C_i^{ES} = \mathbb{E}[-w_i R_i \mid L_p \geq \text{VaR}_\alpha(L_p)]$, $\sum_i C_i^{ES} = \text{ES}_\alpha(L_p)$
 - ▶ Estimarea istorică: media pe zilele din coadă; un C_i negativ înseamnă că activul **acoperă** riscul portofoliului

Portofoliul: SPY, TLT, GLD și Bitcoin

	Pondere	σ_i (%)	corel. SPY	corel. TLT	corel. GLD
SPY	40%	1,10	1,00		
TLT	30%	0,93	-0,17	1,00	
GLD	20%	1,03	0,07	0,25	1,00
Bitcoin	10%	4,14	0,23	-0,02	0,09

- Randamente simple zilnice în 3 017 zile comune de tranzacționare, septembrie 2014 – septembrie 2026; rebalansare zilnică
- Portofoliul $\sigma_p = 0,76\%$; $\text{VaR}_{1\%}$ Normal = 1,77%, nediversificat 3,11%: diversificarea elimină 43%
- $\text{ES}_{2,5\%}$ istoric = 2,15% față de 3,87% nediversificat (44% mai puțin)

Cine contribuie la risc?



□ Turcoaz: ponderi; albastru: cotele din $\text{VaR}_{1\%}$ Normal; roșu: cotele din $\text{ES}_{2,5\%}$ istoric (alocare Euler)

Interpretarea contribuțiilor la risc


	VaR marginal	C_i	cotă	C_i^{ES}	cotă
SPY	1,68	0,67	38,1%	0,98	45,4%
TLT	0,70	0,21	11,8%	0,14	6,5%
GLD	1,08	0,22	12,3%	0,25	11,4%
Bitcoin	6,68	0,67	37,8%	0,79	36,6%
Total		1,77	100%	2,15	100%

- Bitcoin: 10% din bani, 37,8% din VaR și 36,6% din ES: volatilitatea lui este de aproape patru ori cea a SPY
- TLT: 30% din bani, doar 6,5% din ES: în cele mai rele zile ale portofoliului, TLT a pierdut în medie doar 0,47%
- SPY poartă mai mult din ES decât din VaR Normal (45,4% vs 38,1%): pierderile lui se concentrează în zilele cele mai rele ale portofoliului mai mult decât indică covarianțele; a numi aceasta dependență în coadă cere o analiză separată (Capitolul 6)

Recapitulare: riscul portofoliului

- ▣ Sub normalitate comună și cu ponderi nenegative, VaR-ul portofoliului este sub suma VaR-urilor individuale ori de câte ori corelațiile sunt sub 1; în afara modelelor eliptice o poate depăși (exemplul celor două obligațiuni)
- ▣ Alocarea Euler împarte VaR sau ES în contribuții care se adună exact
- ▣ Cotele de risc, nu ponderile în bani, arată unde este riscul: poziții mici pot domina
- ▣ Contribuțiile istorice la ES reflectă mișcarea comună din zilele cele mai rele, pe care contribuțiile bazate pe covarianțe nu o surprind neapărat (dependența în coadă: Capitolul 6)

Emil Gumbel și statistica extremelor



Emil Julius Gumbel (1891–1966)

Foto: autor necunoscut (c. 1931); domeniu public;


Wikimedia Commons

- Fisher & Tippett (1928): maximul multor variabile i.i.d., rescalat corespunzător, poate avea doar trei forme limită
- Gnedenko (1943) a demonstrat riguros rezultatul
- Gumbel (1958) a scris primul manual și a aplicat teoria la inundații, secete și durate de viață
 - ▶ Distribuția Gumbel este una dintre cele trei forme limită
- În finanțe: modelăm **doar coada**, acolo unde este riscul Embrechts, Klüppelberg & Mikosch (1997), Longin (2000)

Maxime pe blocuri și distribuția GEV

- Împărțim selecția în blocuri de n zile; păstrăm maximul fiecărui bloc $M_n = \max(L_1, \dots, L_n)$
 - ▶ Teorema Fisher–Tippett–Gnedenko: dacă $(M_n - b_n)/a_n$ are o limită nedegenerată, aceasta este GEV
- $H_\xi(x) = \exp \left\{ - \left(1 + \xi \frac{x - \mu}{\sigma} \right)^{-1/\xi} \right\}$, $1 + \xi(x - \mu)/\sigma > 0$ ($\xi = 0$: $\exp\{-e^{-(x - \mu)/\sigma}\}$)
- **Forma ξ decide coada**
 - ▶ $\xi > 0$: Fréchet, coadă de tip putere cu indicele de coadă $1/\xi$ (randamentele financiare)
 - ▶ $\xi = 0$: domeniul Gumbel, cozi de tip exponențial (de ex. distribuția Normală, distribuția lognormală); $\xi < 0$: Weibull, coadă mărginită
- **Nivelul de revenire** pentru k blocuri: nivelul depășit în medie o dată la k blocuri, $H_\xi^{-1}(1 - 1/k)$

Maximele lunare ale pierderilor S&P 500



321 luni calendaristice, 2000–2026; GEV estimată prin verosimilitate maximă

Interpretarea maximelor pe blocuri

- $\hat{\xi} = 0,22$ (Fréchet), $\hat{\mu} = 1,37$, $\hat{\sigma} = 0,79$: o coadă de tip putere cu indicele aproximativ $1/\hat{\xi}$
 - Nivelul de revenire la 10 ani: 8,09%; la 30 de ani: 10,95%; cel mai mare maxim lunar a fost 12,77%
- De la maxime lunare la VaR zilnic: $P(M_n \leq x) \approx P(L \leq x)^n$, deci $\text{VaR}_\alpha \approx H^{-1}((1 - \alpha)^n)$ cu $n = 20,9$
 - $\text{VaR}_{1\%} \approx H^{-1}(0,810) = 2,83\%$ față de valoarea istorică 3,45%; $\text{VaR}_{0,1\%} \approx 6,19\%$
- Aproximarea VaR zilnic presupune pierderi independente; gruparea volatilității încalcă această ipoteză (vezi indicele extremal mai jos), iar aici estimarea este prea mică
- Metoda maximelor pe blocuri pierde informație (păstrează o valoare pe lună): metoda următoare folosește toate pierderile mari


Depășiri de prag și distribuția GPD

- Fixăm un prag ridicat u ; modelăm excesele $Y = L - u$, condiționat de $L > u$
 - Teorema Pickands–Balkema–de Haan [Pickands \(1975\)](#), [Balkema & de Haan \(1974\)](#): pentru o clasă largă de distribuții, când u se apropie de capătul drept al distribuției, excesele urmează o distribuție Pareto generalizată
- $G_{\xi, \beta}(y) = 1 - (1 + \xi y / \beta)^{-1/\xi}$ ($\xi \neq 0$), $1 - e^{-y/\beta}$ ($\xi = 0$); $y \geq 0$, și $y < -\beta/\xi$ dacă $\xi < 0$; scala $\beta > 0$; același ξ ca la GEV
- Estimatorul cozii cu N_u depășiri din n observații [McNeil, Frey & Embrechts \(2015\)](#)
 - $\widehat{\text{VaR}}_{\alpha} = u + \frac{\hat{\beta}}{\hat{\xi}} \left[\left(\frac{n}{N_u} \alpha \right)^{-\hat{\xi}} - 1 \right]$, $\widehat{\text{ES}}_{\alpha} = \frac{\widehat{\text{VaR}}_{\alpha}}{1 - \hat{\xi}} + \frac{\hat{\beta} - \hat{\xi}u}{1 - \hat{\xi}}$ ($\alpha < N_u/n$, $\hat{\xi} \neq 0$; ES cere $\hat{\xi} < 1$)
- Compromis deplasare–dispersie: un u mic încalcă teorema limită, un u mare lasă puține depășiri

Alegerea pragului: funcția de exces mediu

- **Funcția de exces mediu:** $e(u) = \mathbb{E}[L - u \mid L > u]$
 - ▶ Versiunea empirică: media exceselor peste u , reprezentată în funcție de u
- Pentru o coadă GPD, $e(u)$ este **liniară** în u
 - ▶ $e(u) = \frac{\beta + \xi(u - u_0)}{1 - \xi}$ pentru $u \geq u_0$, finită doar dacă $\xi < 1$; panta $\xi/(1 - \xi)$ este pozitivă pentru cozi grele și nulă pentru cozi exponențiale
- Regula practică: alegem u acolo unde graficul devine aproximativ liniar; verificăm stabilitatea lui $\hat{\xi}$ pentru mai multe praguri
- Estimatorul Hill din Capitolul 1 [Hill \(1975\)](#) estimează același indice de coadă $1/\xi$

Graficul excesului mediu: S&P 500





- Praguri depășite de proporții ale pierderilor zilnice cuprinse între 20% și 0,5%; linia roșie: GPD estimată pe cele mai mari 5%

Interpretarea graficului excesului mediu

- Excesul mediu empiric crește cu u : o coadă grea (de tip Fréchet), nu linia orizontală a unei cozi exponențiale
- La $u_0 = 1,85\%$ (5% dintre pierderi deasupra lui), excesul mediu este 1,09%; panta GPD $\hat{\xi}/(1 - \hat{\xi}) = 0,23$ urmează punctele
- Dincolo de VaR 1% punctele se împrăștie: fiecare este media a foarte puține pierderi
- Păstrarea celor mai mari 5% lasă $N_u = 336$ depășiri: suficient pentru o estimare stabilă

Cozi GPD: S&P 500 și Bitcoin



□ Scală log-log: probabilitatea unei pierderi zilnice peste x , pentru cele mai mari 5% dintre pierderi

 MFM_ch7_gpd_tail

Interpretarea estimărilor GPD

	u (%)	N_u	$\hat{\xi}$	$SE(\hat{\xi})$	$1/\hat{\xi}$	$VaR_{1\%}$	$ES_{1\%}$
S&P 500	1,85	336	0,19	0,065	5,3	3,54	5,04
BET	1,93	334	0,21	0,066	4,8	4,22	6,34
Bitcoin	5,33	220	0,16	0,078	6,1	10,23	14,36
EUR/RON	0,38	268	0,18	0,072	5,5	0,78	1,14
Aur	1,68	348	0,15	0,062	6,5	3,07	4,22

- $\hat{\xi}$ între 0,15 și 0,21 pentru toate cele cinci serii, fiecare la peste două erori standard i.i.d. deasupra lui 0: cozi grele peste tot (gruparea: slide-urile următoare)
- Indicele de coadă $1/\hat{\xi}$ între 4,8 și 6,5: cozile superioare estimate au momente de ordinul patru finite, dar fiecare interval de 95% pentru ξ trece de 0,25, deci acest lucru nu este stabilit (comparați cu Capitolul 1)
- Pe grafic, coada Normală cade mult sub date; coada Student- t este apropiată de GPD
- $SE(\hat{\xi}) = (1 + \hat{\xi})/\sqrt{N_u}$ presupune depășiri independente; gruparea o face prea mică (slide-urile următoare)

Extremele seriilor dependente: indicele extremal

- ▣ Pierderi staționare cu grupare: dacă $nP(L > u_n) \rightarrow \tau$, atunci $P(M_n \leq u_n) \rightarrow e^{-\theta\tau}$, $\theta \in (0, 1]$ **Embrechts, Klüppelberg & Mikosch (1997)**
 - ▶ θ = indicele extremal, $1/\theta$ = mărimea medie a unui grup; date i.i.d.: $\theta = 1$
 - ▶ Maxime pe blocuri: $P(M_n \leq x) \approx F(x)^{n\theta}$: cele n zile se comportă ca $n\theta$ zile independente
- ▣ **Estimatorul pe intervale Ferro & Segers (2003)** din cele N momente de depășire a lui u și intervalele T_i dintre ele
 - ▶ $\hat{\theta} = \min \left\{ 1, \frac{2(\sum_i (T_i - 1))^2}{(N - 1) \sum_i (T_i - 1)(T_i - 2)} \right\}$ dacă $\max T_i > 2$ (altfel cu T_i, T_i^2)
- ▣ **Declusterizare Ferro & Segers (2003)**: ținta este $C = \lfloor \hat{\theta}N \rfloor + 1$ grupuri, separate de cele mai mari $C - 1$ intervale; estimăm GPD pe maximele grupurilor
 - ▶ Egalități: dacă al $(C - 1)$ -lea și al C -lea cel mai mare interval sunt egale, C se reduce până când diferă, deci numărul realizat de grupuri poate fi sub țintă


Indicele extremal al pierderilor S&P 500

- Pragul GPD folosit mai sus ($u = 1,85\%$, $N = 336$): $\hat{\theta} = 0,19$, ținta $C = 63$, 62 grupuri după regula egalităților, cu câte 5,4 depășiri în medie
 - ▶ La VaR 1% istoric ($u = 3,45\%$, $N = 68$): $\hat{\theta} = 0,35$
- GPD pe maximele grupurilor: $\hat{\xi} = 0,152$ (SE 0,146) față de 0,188 (SE 0,065) pe toate depășirile: estimarea punctuală rămâne pozitivă, dar nu se distinge de 0 (intervalul ei de 95% include 0); SE i.i.d. era mai puțin de jumătate din cea corectă
- Maxime lunare cu $\hat{\theta} = 0,35$: $\text{VaR}_{1\%} \approx H^{-1}(0,929) = 4,14\%$ în loc de 2,83% (istoric 3,45%); cu $\hat{\theta} = 0,19$: 5,09%
- Corecția mută rezultatul mai mult decât eroarea pe care o corectează: drumul de la maxime pe blocuri la VaR zilnic este fragil
- Reziduurile GARCH standardizate: $\hat{\theta} = 0,99$: filtrarea elimină gruparea, de aceea EVT condiționată estimează GPD după filtru

EVT condiționată (McNeil și Frey)

- EVT necondiționată ignoră gruparea volatilității; [McNeil & Frey \(2000\)](#) combină filtrarea GARCH cu o coadă GPD
 - ▶ Pasul 1: estimăm AR(1)-GARCH(1,1) prin cvasi-verosimilitate maximă; reziduuri standardizate $\hat{z}_t$
 - ▶ Pasul 2: estimăm o GPD pe cele mai mari 10% dintre $-\hat{z}_t$ și calculăm VaR-ul $\hat{z}_\alpha^{GPD}$ și ES la nivelul α
 - ▶ Pasul 3: $\text{VaR}_{\alpha, t+1} = -\hat{\mu}_{t+1} + \hat{\sigma}_{t+1} \hat{z}_\alpha^{GPD}$, cu $\hat{z}_\alpha^{GPD}$ VaR-ul GPD al lui $-\hat{z}$; ES la fel
- La fel ca simularea istorică filtrată, dar cu o coadă parametrică netedă dincolo de date
- Contează mai ales adânc în coadă (VaR 0,5%, VaR 0,1%), unde există doar câteva reziduuri

EVT condiționată pentru S&P 500



□ $\text{VaR}_{1\%}$ prognozat pentru ziua următoare, 2018–2026; parametri re-estimați în fiecare ianuarie pe toate datele anterioare

Interpretarea graficului EVT condiționate

- Proporția zilelor cu pierderi peste VaR 1%, 2018–2026 (2 190 zile; ținta $\alpha = 1\%$)
 - ▶ EVT condiționată 1,23%; GARCH cu șocuri Normale 2,42%; istorică, 500 de zile 1,60%
- Curba GARCH–Normal surprinde corect **variațiile în timp**, dar are un **nivel** greșit: rata ei de depășire este de peste două ori ținta
- EVT condiționată păstrează reacția la variațiile pieței și corectează nivelul: contează coada șocurilor, nu doar scala lor
- Dacă 1,2% diferă statistic de 1% este o întrebare pentru Capitolul 8

Recapitulare: teoria valorilor extreme

- Două teoreme limită: maximele pe blocuri $\rightarrow$ GEV, excesele peste un prag ridicat $\rightarrow$ GPD; ambele guvernate de ξ
- Toate cele cinci serii: $\hat{\xi} \approx 0,15-0,22$, o coadă grea de tip Fréchet
- Depășirile de prag folosesc datele mai bine decât maximele pe blocuri; graficul excesului mediu ghidează alegerea pragului
- Gruparea ($\hat{\theta} < 1$) micșorează eșantionul efectiv: declusterizăm sau filtrăm înainte de a da o eroare standard
- EVT condiționată = scală GARCH + coadă GPD: cel mai complet model pe o zi din acest capitol

VaR ajustat la lichiditate

- VaR presupune că pozițiile pot fi vândute la prețul mediu; în realitate plătim jumătate din diferența dintre prețul de cumpărare și cel de vânzare (spread)
 - ▶ **Spread relativ** $S = (\text{ask} - \text{bid})/\text{mid}$; se lărgeste exact când piețele scad
- **Bangia, Diebold, Schuermann & Stroughair (2001)**: $\text{LVaR}_\alpha = \text{VaR}_\alpha + \frac{1}{2}(\mu_S + a\sigma_S)$, cu media μ_S și abaterea standard σ_S a spread-ului și un multiplicator a
- Banca Transilvania, 1 milion RON, ultimii doi ani: $\text{VaR}_{1\%} = 3,16\%$; cu $\mu_S = 0,5\%$, $\sigma_S = 0,3\%$, $a = 3$ presupuse: $\text{LVaR} = 3,86\%$ (+22%)
- Pozițiile mari mișcă și prețul (lichiditate endogenă): reglementarea tratează acest lucru prin orizonturi mai lungi

Comitetul de la Basel



Turnul BIS din Basel, sediul Comitetului de la Basel pentru Supraveghere Bancară

Foto: Michal Pleskowicz (2018); CC BY-SA 4.0;
Wikimedia Commons

- Comitetul de la Basel pentru Supraveghere Bancară stabilește standardele globale de capital; autoritățile naționale (în UE, prin Regulamentul privind cerințele de capital) le transformă în lege
- **1996:** riscul de piață intră în regulile de capital; băncile pot folosi modele VaR interne [Basel Committee \(1996\)](#)
- **2019:** standardul revizuirii fundamentale a portofoliului de tranzacționare (Fundamental Review of the Trading Book) înlocuiește VaR cu ES în abordarea bazată pe modele interne [Basel Committee \(2019\)](#); fiecare jurisdicție își stabilește data de aplicare
- UE: [Delegated Regulation \(EU\) 2025/1496](#) a amânat cerințele de fonduri proprii FRTB la 1 ianuarie 2027; până atunci băncile aplică cadrul anterior, bazat pe VaR

Basel 1996: VaR 1% pe 10 zile

- ▣ VaR 1% (unilateral), calculat zilnic, perioadă minimă de deținere de 10 zile de tranzacționare [Basel Committee \(1996\)](#)
- ▣ VaR pe o zi poate fi scalat la 10 zile cu rădăcina pătrată a timpului
- ▣ Cel puțin un an de date istorice
- ▣ Capitalul: maximul dintre VaR de ieri și media VaR pe 60 de zile înmulțită cu un factor de multiplicare de cel puțin 3
 - ▶ Se adaugă un „plus” între 0 și 1 când testarea retrospectivă găsește prea multe excepții (Capitolul 8)
- ▣ Critica de după 2008: VaR ignoră mărimea pierderilor din coadă, iar ferestrele de un an uită crizele


FRTB (2019): Expected Shortfall 2,5%

- ES 2,5% (unilateral), calculat zilnic pentru fiecare birou de tranzacționare care folosește modele interne [Basel Committee \(2019\)](#)
- Orizont de bază de 10 zile, scalat prin **orizonturi de lichiditate** pe factor de risc
 - ▶ Acțiuni cu capitalizare mare 10 zile, cu capitalizare mică 20 de zile, perechi valutare specificate 10 zile, spread-uri de credit până la 120 de zile
- Calibrat pe cea mai severă perioadă de stres de 12 luni disponibilă
- Multiplicatorul de capital $m_c = 1,5$, crescut de supraveghetori după rezultate slabe la testarea retrospectivă
- Birourile sunt în continuare testate retrospectiv pe VaR 2,5% și VaR 1% pe o zi: VaR rămâne, ES stabilește capitalul

De ce ES 2,5% înlocuiește VaR 1%

- ▣ Sub distribuția Normală cu medie zero, cele două sunt aproape egale
 - ▶ $ES_{2,5\%} = \sigma \times 2,338$ vs $VaR_{1\%} = \sigma \times 2,326$: același capital pentru cozi subțiri
- ▣ Student- t : $ES_{2,5\%}/VaR_{1\%}$ crește când ν scade (1,01 la $\nu = 30$, 1,07 la $\nu = 4$) și depășește 1 în toate cele cinci selecții din acest capitol
 - ▶ Cozile grele singure nu garantează acest lucru: $ES_{\alpha} \geq VaR_{\alpha}$ este valabilă la același α , nu între niveluri diferite
- ▣ ES este coerent, deci limitele ES la nivel de birou se adună în siguranță
- ▣ Prețuri: ES este mai greu de testat retrospectiv (nu este elicitable singur) și mai puțin precis decât VaR pentru aceeași selecție

VaR 1% vs ES 2,5% pe cinci active



- Simulare istorică, pierderi zilnice, selecțiile complete; numărul de deasupra fiecărei perechi este $ES_{2,5\%}/VaR_{1\%}$

Interpretarea comparației Basel

- $ES_{2,5\%}/VaR_{1\%}$: S&P 500 1,09, BET 1,11, Bitcoin 1,03, EUR/RON 1,10, aur 1,06
 - ▶ Distribuția Normală: $2,338/2,326 \approx 1,005$
- Toate cele cinci rapoarte sunt peste valoarea Normală: cu celelalte elemente fixate, înlocuirea VaR 1% pe o zi cu ES 2,5% pe o zi crește măsura de risc cu 3–11%
- Creșterea este cea mai mare pentru BET și EUR/RON, ale căror cozi dincolo de VaR 1% sunt cele mai lungi în raport cu VaR
- Capitalul reglementat adaugă și calibrarea pe perioada de stres și orizonturile de lichiditate: vezi Seminarul 7, Partea C

Recapitulare: lichiditate și reglementare

- ▣ VaR ajustat la lichiditate adaugă jumătate din spread-ul (în condiții de stres) la VaR de piață
- ▣ Basel 1996: VaR 1% pe 10 zile, scalarea cu $\sqrt{10}$ permisă, multiplicator de cel puțin 3
- ▣ FRTB 2019: ES 2,5%, orizont de bază de 10 zile, orizonturi de lichiditate, calibrare pe stres, multiplicator 1,5
- ▣ În FRTB, VaR rămâne instrumentul de testare retrospectivă și ES stabilește capitalul (UE: de la 1 ianuarie 2027)

Studiu de caz: întrebarea de cercetare

- **Chronopoulos, Raftapostolos & Kapetanios (2024)** (*Journal of Financial Econometrics*): poate o rețea neuronală adâncă să îmbunătățească prognoza VaR învățând o relație **neliniară, cu formă necunoscută**, între cuantila condiționată și predictorii?
- De ce contează: reperele comparate aici, regresia cuantilă liniară **Koenker & Bassett (1978)** și specificațiile CAViaR SAV și cu pantă asimetrică **Engle & Manganelli (2004)** (Secțiunea 4), fac VaR **liniar** în σ_t , $|r_{t-1}|$ sau VaR întârziat
 - ▶ Cozile reacționează asimetric și brusc în crize (2008, COVID-19): o relație liniară poate fi prea rigidă exact acolo unde VaR contează
 - ▶ **Patton, Ziegel & Chen (2019)** au extins ideea CAViaR la perechea (VaR, ES), cu dinamică parametrică; acest articol păstrează doar VaR, dar renunță la liniaritate
- Modelul (Ec. 5–8): $Q_{r_t}(\alpha | x_t) = h_\alpha(x_t) \approx G_\alpha(x_t, w)$, o rețea cu propagare înainte (feed-forward), cu straturi ascunse ReLU (rectified linear unit, $\max(\cdot, 0)$) și ieșire liniară
 - ▶ $\hat{w} = \arg \min_w \frac{1}{T} \sum_t \rho_\alpha(r_t - G_\alpha(x_t, w)) + \phi(w)$, pierderea pinball $\rho_\alpha(u) = u(\alpha - 1\{u < 0\})$; penalizarea ϕ : niciuna, LASSO, ridge sau elastic net (Ec. 10)
 - ▶ În articol, τ corespunde nivelului α din curs; $\text{VaR}_{\alpha,t} = -Q_{r_t}(\alpha | x_t)$, ca în Secțiunea 2

Studiu de caz: date și metodă


- **Date** (Secțiunea 3.1): randamentele log zilnice ale S&P 500, $r_t = \ln(P_t/P_{t-1})$, septembrie 1985 – august 2020, $T = 9\,053$; $\alpha = 1\%$, 5% și 10%
 - ▶ Patru seturi de predictor x_t (Ec. 14–17, după [Giacomini & Komunjer \(2005\)](#)): σ_t din GARCH(1,1); σ_t RiskMetrics cu $\lambda = 0,94$; CAViaR SAV ($\text{VaR}_{t-1}, |r_{t-1}|$); CAViaR cu pantă asimetrică ($\text{VaR}_{t-1}, r_{t-1}^+, r_{t-1}^-$)
- **Schema de evaluare** (Secțiunea 3.2): ultimele 2 000 de zile formează eșantionul de evaluare; primele 7 053 sunt folosite pentru calibrarea unică a modelului (fereastră fixă de estimare), cu prognoza la 10 zile a cuantilei randamentului zilnic, $G_\alpha(x_t, w^*)$, deci $\widehat{\text{VaR}}_{t+10|\mathcal{F}_t} = -G_\alpha(x_t, w^*)$ (Ec. 23, care raportează cuantila însăși)
 - ▶ CV pentru serii de timp (Ec. 12): se exclud $\delta = 5$ zile de fiecare parte a observației evaluate; se aleg aleatoriu $\kappa = 20$ de observații pentru testare; grile: adâncimea și lățimea din $\{1, 5, 10\}$, câte cinci valori pentru rata de învățare și λ în $[0,001; 0,01]$, dimensiunea lotului din $\{10, 20\}$; antrenare: dropout de cel mult 20%, Adam, oprire timpurie (Secțiunea 1.4)
- **Modele comparate**: regresia cuantilă liniară (modelul de referință), regresiile cuantile polinomială și cu funcții B-spline, modelul MIDAS liniar (Ec. 18) și o rețea MIDAS adâncă
 - ▶ **Evaluare** (Secțiunea 3.3): RMSFE relativ la reperul liniar; testul DM [Diebold & Mariano \(1995\)](#) aplicat pierderilor pinball, cu corecția [Harvey, Leybourne & Newbold \(1997\)](#); testul CQFE [Giacomini & Komunjer \(2005\)](#) cu parametrul de netezire $\eta = 0,005$

Studiu de caz: rezultate (Tabelele 6 și 7)

$\alpha = 1\%$	Polin.	Spline	MIDAS	Adânc	LASSO	Ridge	Elnet	MIDAS adânc
GARCH	0,909	0,791	1,083	0,346	0,236	0,177	0,146	0,346
RiskMetrics	0,780	0,570	1,066	0,289	0,141	0,207	0,239	0,246
SAV	1,000	1,511	0,838	0,198	0,024	0,225	0,498	0,850
Pantă asim.	1,000	1,040	4,918	0,235	0,096	0,014	0,037	0,601

- RMSFE relativ la regresia cuantilă liniară, $\alpha = 1\%$ (Tabelul 6; LASSO, Ridge, Elnet = rețele adânci penalizate): toate cele 16 valori ale rețelelor adânci sunt sub 1 și semnificative la 1% în testul DM
 - Interpretare: pe toate nivelurile, rețelele adânci reduc eroarea cu 50%–98%, MIDAS adânc cu 11%–84%: rezultat compatibil cu o relație liniară prea restrictivă pentru acești predictorii
- În majoritatea cazurilor, reperul liniar depășește regresiiile polinomială și cu spline (Tabelul 6, până la 1,716); MIDAS liniar ajunge la 4,918; MIDAS adânc nu este semnificativ pentru SAV (0,850)
 - Interpretare: specificațiile cu rețele neuronale au cele mai bune rezultate în această comparație; rezultatele nu separă contribuțiile arhitecturii, penalizării și CV
- CQFE la $\alpha = 1\%$ (Tabelul 7): prognozele blocului neliniar înglobează informația din prognozele concurente în 757 de comparații (42 de rezultate nefavorabile, 751 neconcludente); pentru blocul liniar, numerele corespunzătoare sunt 173 (15, 170)
 - Interpretare: numeroasele perechi neconcludente arată că o combinație de prognoze ar putea aduce încă informație

Studiu de caz: erori relative (Tabelul 6, $\alpha = 1\%$)



- Sursa: Chronopoulos, Raftapostolos & Kapetanios (2024), Tabelul 6; S&P 500, ultimele 2 000 de zile până în august 2020; RMSFE relativ la regresia cuantilă liniară (linia întreruptă = 1), scară logaritmică

Studiu de caz: interpretarea graficului

- Blocul din stânga (polinomial, B-spline, MIDAS liniar): 7 din cele 12 bare sunt la 1 sau peste
 - ▶ Modelele flexibile fără rețele neuronale nu oferă sistematic prognoze mai bune decât modelul liniar; MIDAS liniar cu panta asimetrică ajunge la 4,918
- Blocul din dreapta: toate cele 20 de bare ale rețelelor adânci sunt sub 1; raportul RMSFE este în $[0,198; 0,346]$ pentru rețeaua nepenalizată și în $[0,014; 0,498]$ pentru rețelele penalizate
 - ▶ Penalizarea cea mai bună se schimbă cu setul de predictor: elastic net pentru GARCH (0,146), LASSO pentru RiskMetrics (0,141) și SAV (0,024), ridge pentru panta asimetrică (0,014)
- MIDAS adânc are rapoarte între 0,246 și 0,850: câștigă cel mai puțin dintre modelele adânci pentru SAV și panta asimetrică, egalează rețeaua adâncă nepenalizată pentru GARCH (0,346), o depășește pentru RiskMetrics (0,246 vs 0,289) și nu este semnificativ pentru SAV
 - ▶ Precauție: un raport de 0,014 înseamnă o reducere a RMSFE cu 98% dintr-o singură fereastră fixă de calibrare; Seminarul 7, C3 întreabă dacă se păstrează la reestimarea pe fereastră mobilă

Studiu de caz: replicare, limite, extindere

- **Replicare** pe data/market: seria S&P 500 începe în ianuarie 1990, deci lipsește perioada 1985–1989 (o limită a datelor)
 - ▶ Păstrăm fereastra de evaluare publicată (ultimele 2 000 de randamente până la 31 august 2020, de la 19 septembrie 2012): 5 726 de zile de calibrare în loc de 7 053
 - ▶ Construim predictorii GARCH și SAV, estimăm regresia cuantilă liniară și regresia cuantilă cu o rețea neuronală adâncă la $\alpha = 1\%$ și recalculăm aceste două rânduri din Tabelul 6 (Seminarul 7, C3)
- **Limite menționate de autori**
 - ▶ O singură fereastră de estimare: recalibrarea recursivă sau pe fereastră mobilă, repetată pentru 2 000 de zile, necesită un volum mare de calcul (Secțiunea 3.2)
 - ▶ Rețelele sunt predispușe la supraajustare; autorii folosesc penalizări, dropout, CV și oprire timpurie (Secțiunea 1.4). Modelul este greu de interpretat direct; în articol, interpretarea se bazează pe valori SHAP și derivate parțiale (Secțiunea 4)
- **Extindere deschisă**: se păstrează câștigul la reestimarea pe fereastră mobilă în 2020–2026 și pe BET și poate o rețea antrenată pe pierderea FZ0 a lui [Patton, Ziegel & Chen \(2019\)](#) să prognozeze împreună (VaR, ES), cum cere FRTB? (Seminarul 7, C3)

O întrebare deschisă

- Pot datele zilnice ordona modelele concurente de prognoză (VaR 1%, ES 1%), știind că ES singur nu este elicitabil și că doar circa 1% din zile sunt informative?
- Întrebarea este deschisă
 - ▶ [Nolde & Ziegel \(2017\)](#): testarea retrospectivă comparativă cu scoruri strict consistente pentru (VaR, ES), în locul testelor tradiționale de acoperire
 - ▶ [Patton, Ziegel & Chen \(2019\)](#): pierderea FZ0 și modele semiparametrice dinamice pentru (VaR, ES); [Bayer & Dimitriadis \(2022\)](#): teste retrospective pentru ES bazate pe regresie
 - ▶ [Pele & Mazurencu-Marinescu-Pele \(2026\)](#): precizia ES pe eșantioane finite este guvernată de cele $n\alpha$ observații din coadă
- Formularea testului pentru modelele A și B, randamentul Y_t , $v_t = -\text{VaR}_{\alpha,t}$, $e_t = -\text{ES}_{\alpha,t}$
 - ▶ $S(v, e; Y) = -\frac{1}{\alpha e} \mathbf{1}\{Y \leq v\}(v - Y) + \frac{v}{e} + \ln(-e) - 1$ (FZ0); $d_t = S_t^A - S_t^B$
 - ▶ $H_0: \mathbb{E}[d_t] = 0$; $H_1: \mathbb{E}[d_t] \neq 0$ (bilateral; $\bar{d} < 0$ favorizează A); statistica t DM cu erori HAC; stabilitatea ordonării se evaluează separat, cu un interval de încredere pentru $\bar{d}$ în fiecare subperioadă pre-înregistrată

Bucula descoperirii, pas cu pas (1/2)

- Instrumentele sunt interschimbabile: un asistent AI (Claude, ChatGPT, Gemini, GitHub Copilot) și instrumente de căutare în literatura științifică (Semantic Scholar, Elicit, Google Scholar)
- **Literatura:** „*Listează articolele publicate după 2015 despre testarea retrospectivă comparativă a perechii (VaR, ES) cu funcții de scor strict consistente: DOI, funcția de scor, testul, mărimea eșantionului și rezultatele privind puterea.*”
 - ▶ Verificăm fiecare DOI în Crossref; verificăm în articol convenția de semn a scorului
- **Ipoteze:** „*Pentru FHS, EVT condiționată și GARCH cu șocuri Normale, spune ce trăsături ale cozii surprinde fiecare și ce prezice fiecare pentru diferențele FZ0 în anii calmi și în cei agitați.*”
- **Date și cod:** „*Scrie cod Python care calculează pierderea FZ0 pentru prognozele zilnice VaR 1% și ES 1% pe S&P 500 din data/market, cu convenția de semn $VaR = -q_\alpha$, și un test Diebold–Mariano cu erori HAC.*”
 - ▶ Replicăm întâi: rata de depășire FHS de 1,54% pe 5 210 zile (Secțiunea 4)

Bucula descoperirii, pas cu pas (2/2)

- **Robustețe:** „Scrie un plan pre-înregistrat: subperioadele 2006–2015 și 2016–2026, nivelurile 1% și 2,5%, FZ0 și un al doilea scor consistent, decalaje HAC 5 și 20, un al doilea indice.”
 - ▶ Verificarea mărimii testului: simulăm dintr-un GARCH-t estimat și evaluăm două prognoze cu același FZ0 așteptat; testul trebuie să respingă în circa 5% din simulări
- **Critica:** „Joacă rolul unui referent: este ordonarea mea determinată de 2008 și 2020, de convenția de semn a scorului sau de ferestrele de estimare suprapuse? Indică un test care ar identifica fiecare dintre aceste probleme.”
- **Raportul:** fiecare pereche de modele, nivel și perioadă; numărul de zile din coadă din spatele fiecărei comparații
- Fixăm planul înainte de prima rulare: orice specificație aleasă după ce am văzut rezultatele este exploratorie și se raportează ca atare

Ce verifică cercetătorul

- ▣ **Convenția de semn și de nivel:** $\text{VaR } 1\% = -q_{1\%}$, pozitiv pentru o pierdere; un asistent poate eticheta nivelul prin probabilitatea de încredere sau poate inversa semnele $\Rightarrow$ recalculăm FZ0 pentru o zi pas cu pas
- ▣ **Informație din viitor:** parametri GARCH sau cuantile ale reziduurilor din tot eșantionul $\Rightarrow$ verificăm că fiecare prognoză folosește doar date de dinaintea zilei ei
- ▣ **Țintă neelicitabilă:** ordonarea prognozelor ES după eroarea pătratică față de pierderi nu este consistentă [Gneiting \(2011\)](#) $\Rightarrow$ doar scoruri comune pentru (VaR, ES) [Fissler & Ziegel \(2016\)](#)
- ▣ **Puterea:** circa $n\alpha$ zile din coadă determină scorul $\Rightarrow$ le numărăm și raportăm subperioadele
- ▣ **Testare multiplă:** modele $\times$ niveluri $\times$ perioade $\times$ active $\Rightarrow$ fixăm familia dinainte și ajustăm valorile p
- ▣ **Referințe inventate:** un DOI care nu se rezolvă sau un scor atribuit greșit $\Rightarrow$ renunțăm la afirmație și o notăm în `AI_ERRORS.md`

Mini-studiu de caz: putem ordona modelele ES?

- O propunere tipică a unui asistent: „EVT condiționată este cel mai bun model (VaR 1%, ES 1%) pentru S&P 500”; $H_0: \mathbb{E}[d_t] = 0$
- Replicăm: rata de depășire FHS 1,54% (80 din 5 210 zile, 2006–2026)
- FZ0 mediu (o valoare mai mică este preferabilă): EVT condiționată 1,267, FHS 1,283, GARCH cu șocuri Normale 1,453
 - ▶ FHS vs GARCH-Normal: $\bar{d} = -0,170$, $t = -4,48$; $t = -3,24$ în 2006–2015 și $-3,38$ în 2016–2026
 - ▶ EVT condiționată vs FHS: $\bar{d} = -0,016$, $t = -2,62$ (p bilateral = 0,009, neajustat); $t = -2,31$ în 2006–2015, dar $-1,23$ în 2016–2026
- Forma distribuției șocurilor contează robust: șocurile Normale pierd în ambele jumătăți
- Câștigul EVT față de FHS este de circa zece ori mai mic: semnificativ (neajustat) pe întreaga perioadă și în 2006–2015, dar nu în 2016–2026, unde intervalul de 95% pentru $\mathbb{E}[d_t]$ este $[-0,018; 0,004]$: avantajul recent nu este stabilit, ceea ce nu dovedește echivalența

Rândul vostru: un punct de plecare pentru proiectul de echipă

- Întrebarea: oferă un model semiparametric dinamic (VaR, ES) [Patton, Ziegel & Chen \(2019\)](#) prognoze mai bune decât FHS și EVT condiționată la ES 2,5% pe S&P 500, BET și Bitcoin, în afara eșantionului?
- Replicăm întâi: cifrele condiționate din Secțiunea 4 (VaR 1% FHS pentru S&P 500 1,97%) și ordonarea FZ0 din mini-studiul de caz
- Livrabile
 - ▶ O preînregistrare de o pagină: modele, niveluri, scoruri, subperioade, putere (zile din coadă) și ce ar infirma afirmația
 - ▶ Cod pe data/market, un tabel cu toate comparațiile și valorile p ajustate, o autocritică în stilul unui referent
- Notăm fiecare prompt, instrument și rezultat acceptat în `AI_USE.md`; fiecare eroare prinsă (semn inversat, etichetă greșită a nivelului, informație din viitor, DOI inventat) și testul care a prins-o în `AI_ERRORS.md`
- Codul mini-studiului de caz: [Quantlets/Ch_07/ai_discovery_case.py](#)

Sinteză

- VaR este o cuantilă a pierderii, ES media dincolo de ea și un minim convex (Rockafellar–Uryasev); ES este coerent, VaR nu în general
- Orice VaR sau ES este o estimare: asimptotica cuantilei și a ES, intervale HAC sau bootstrap, riscul de estimare în VaR condiționat
- Cozi grele: distribuția Normală subestimează, Cornish–Fisher depășește ținta, Student- t și EVT se potrivesc bine
- Gruparea volatilității: simularea istorică filtrată și EVT condiționată reacționează în zile, nu în luni
- Scalarea cu $\sqrt{h}$ eșuează cu autocorelație, grupare și cozi grele; simulați în schimb
- Alocarea Euler arată unde se află riscul; standardul Basel din 2019 (FRTB) stabilește capitalul pentru modelele interne prin ES 2,5%, în UE de la 1 ianuarie 2027

Ce metodă și când?

Situația	Metoda sugerată
Verificare rapidă, istorie lungă și stabilă	Simulare istorică, 500–1000 de zile
Riscul zilnic după un șoc de volatilitate VaR 0,5% și mai adânc în coadă, teste de stres	Simulare istorică filtrată sau EVT condiționată Depășiri de prag (GPD), condiționate sau nu
Orizont de mai multe zile, opțiuni, câștiguri neliniare	Monte Carlo filtrat
Bugetarea riscului pe birouri sau active Comunicarea cu autoritatea de reglementare	Contribuții Euler la ES ES 2,5%, 10 zile, perioadă de stres, plus teste retrospective ale VaR 1%

Urmează: testarea retrospectivă (Capitolul 8)

- ▣ Cât de des au depășit pierderile VaR și au fost depășirile independente?
- ▣ Teste de acoperire necondiționată și condiționată; zonele de tip semafor din Basel
- ▣ Testarea retrospectivă a ES: funcții de scor comune pentru (VaR, ES) [Fissler & Ziegel \(2016\)](#)
- ▣ Lecturi suplimentare: [Franke, Härdle & Hafner \(2019\)](#), [Härdle, Chen & Overbeck \(2017\)](#), [Čížek, Härdle & Weron \(2011\)](#), [McNeil, Frey & Embrechts \(2015\)](#)

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ▣  Measuring Statistical Risk
- ▣  XFG Advanced Methods in Quantitative Finance

Cod și date

- ▣ Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_07

Bibliografie (1/6)

- ▣ Acerbi, C., Tasche, D. (2002). *On the coherence of expected shortfall*. *Journal of Banking & Finance*, 26(7), 1487–1503.
- ▣ Artzner, P., Delbaen, F., Eber, J.-M., Heath, D. (1999). *Coherent measures of risk*. *Mathematical Finance*, 9(3), 203–228.
- ▣ Balkema, A.A., de Haan, L. (1974). *Residual life time at great age*. *Annals of Probability*, 2(5), 792–804.
- ▣ Bangia, A., Diebold, F.X., Schuermann, T., Strouhair, J.D. (2001). *Modeling liquidity risk, with implications for traditional market risk measurement and management*. In *Risk Management: The State of the Art*, Springer, 3–13.
- ▣ Barone-Adesi, G., Giannopoulos, K., Vosper, L. (1999). *VaR without correlations for portfolios of derivative securities*. *Journal of Futures Markets*, 19(5), 583–602.
- ▣ Basel Committee on Banking Supervision (1996). *Amendment to the capital accord to incorporate market risks*. Bank for International Settlements.
- ▣ Basel Committee on Banking Supervision (2019). *Minimum capital requirements for market risk*. Bank for International Settlements.
- ▣ Bayer, S., Dimitriadis, T. (2022). *Regression-based expected shortfall backtesting*. *Journal of Financial Econometrics*, 20(3), 437–471.
- ▣ Bollerslev, T. (1986). *Generalized autoregressive conditional heteroskedasticity*. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Chen, S.X. (2008). *Nonparametric estimation of expected shortfall*. *Journal of Financial Econometrics*, 6(1), 87–107.

Bibliografie (2/6)

- ▣ Christoffersen, P., Gonçalves, S. (2005). Estimation risk in financial risk management. *Journal of Risk*, 7(3), 1–28.
- ▣ Chronopoulos, I., Raftapostolos, A., Kapetanios, G. (2024). Forecasting Value-at-Risk using deep neural network quantile regression. *Journal of Financial Econometrics*, 22(3), 636–669.
- ▣ Čížek, P., Härdle, W.K., Weron, R. (Eds.) (2011). *Statistical Tools for Finance and Insurance*, 2nd ed. Springer.
- ▣ Cont, R., Deguest, R., Scandolo, G. (2010). Robustness and sensitivity analysis of risk measurement procedures. *Quantitative Finance*, 10(6), 593–606.
- ▣ Cornish, E.A., Fisher, R.A. (1938). Moments and cumulants in the specification of distributions. *Revue de l'Institut International de Statistique*, 5(4), 307–320.
- ▣ Daníelsson, J. (2011). *Financial Risk Forecasting*. Wiley.
- ▣ Daníelsson, J., Jorgensen, B.N., Samorodnitsky, G., Sarma, M., de Vries, C.G. (2013). Fat tails, VaR and subadditivity. *Journal of Econometrics*, 172(2), 283–291.
- ▣ Daníelsson, J., Zigrand, J.-P. (2006). On time-scaling of risk and the square-root-of-time rule. *Journal of Banking & Finance*, 30(10), 2701–2713.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Dimitriadis, T., Bayer, S. (2019). A joint quantile and expected shortfall regression framework. *Electronic Journal of Statistics*, 13(1), 1823–1871.

Bibliografie (3/6)

- ▣ Embrechts, P., Klüppelberg, C., Mikosch, T. (1997). *Modelling Extremal Events for Insurance and Finance*. Springer.
- ▣ Embrechts, P., Puccetti, G., Rüschendorf, L. (2013). *Model uncertainty and VaR aggregation*. *Journal of Banking & Finance*, 37(8), 2750–2764.
- ▣ Engle, R.F., Manganelli, S. (2004). *CAViaR: conditional autoregressive value at risk by regression quantiles*. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- ▣ Ferro, C.A.T., Segers, J. (2003). *Inference for clusters of extreme values*. *Journal of the Royal Statistical Society: Series B*, 65(2), 545–556.
- ▣ Fisher, R.A., Tippett, L.H.C. (1928). *Limiting forms of the frequency distribution of the largest or smallest member of a sample*. *Mathematical Proceedings of the Cambridge Philosophical Society*, 24(2), 180–190.
- ▣ Fissler, T., Ziegel, J.F. (2016). *Higher order elicibility and Osband's principle*. *Annals of Statistics*, 44(4), 1680–1707.
- ▣ Francq, C., Zakoïan, J.-M. (2015). *Risk-parameter estimation in volatility models*. *Journal of Econometrics*, 184(1), 158–173.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Giacomini, R., Komunjer, I. (2005). *Evaluation and combination of conditional quantile forecasts*. *Journal of Business & Economic Statistics*, 23(4), 416–431.
- ▣ Gnedenko, B. (1943). *Sur la distribution limite du terme maximum d'une série aléatoire*. *Annals of Mathematics*, 44(3), 423–453.

Bibliografie (4/6)

- ▣ Gneiting, T. (2011). [Making and evaluating point forecasts](#). *Journal of the American Statistical Association*, 106(494), 746–762.
- ▣ Gumbel, E.J. (1958). [Statistics of Extremes](#). Columbia University Press.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). [Applied Quantitative Finance](#), 3rd ed. Springer.
- ▣ Harvey, D., Leybourne, S., Newbold, P. (1997). [Testing the equality of prediction mean squared errors](#). *International Journal of Forecasting*, 13(2), 281–291.
- ▣ Hill, B.M. (1975). [A simple general approach to inference about the tail of a distribution](#). *Annals of Statistics*, 3(5), 1163–1174.
- ▣ Hull, J., White, A. (1998). [Incorporating volatility updating into the historical simulation method for value-at-risk](#). *Journal of Risk*, 1(1), 5–19.
- ▣ J.P. Morgan/Reuters (1996). [RiskMetrics – Technical Document](#), 4th ed. New York.
- ▣ Koenker, R., Bassett, G. (1978). [Regression quantiles](#). *Econometrica*, 46(1), 33–50.
- ▣ Longin, F.M. (2000). [From value at risk to stress testing: the extreme value approach](#). *Journal of Banking & Finance*, 24(7), 1097–1130.
- ▣ McNeil, A.J., Frey, R. (2000). [Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach](#). *Journal of Empirical Finance*, 7(3–4), 271–300.

Bibliografie (5/6)

- ▣ McNeil, A.J., Frey, R., Embrechts, P. (2015). *Quantitative Risk Management: Concepts, Techniques and Tools*, revised ed. Princeton University Press.
- ▣ Newey, W.K., West, K.D. (1987). *A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix.* *Econometrica*, 55(3), 703–708.
- ▣ Newey, W.K., West, K.D. (1994). *Automatic lag selection in covariance matrix estimation.* *Review of Economic Studies*, 61(4), 631–653.
- ▣ Nolde, N., Ziegel, J.F. (2017). *Elicitability and backtesting: perspectives for banking regulation.* *Annals of Applied Statistics*, 11(4), 1833–1874.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). *Dynamic semiparametric models for expected shortfall (and Value-at-Risk).* *Journal of Econometrics*, 211(2), 388–413.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). *Information entropy and measures of market risk.* *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). *Modeling expected shortfall using tail entropy.* *Entropy*, 21(12), 1204.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). *Using high-frequency entropy to forecast Bitcoin's daily value at risk.* *Entropy*, 21(2), 102.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). *Finite-sample precision limits for expected shortfall forecast comparisons.* *Mathematics*, 14(13), 2316.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). *Are cryptos becoming alternative assets?.* *European Journal of Finance*, 29(10), 1064–1105.

Bibliografie (6/6)

- ▣ Pickands, J. (1975). [Statistical inference using extreme order statistics](#). *Annals of Statistics*, 3(1), 119–131.
- ▣ Rockafellar, R.T., Uryasev, S. (2000). [Optimization of conditional value-at-risk](#). *Journal of Risk*, 2(3), 21–41.
- ▣ Rockafellar, R.T., Uryasev, S. (2002). [Conditional value-at-risk for general loss distributions](#). *Journal of Banking & Finance*, 26(7), 1443–1471.
- ▣ Spierdijk, L. (2016). [Confidence intervals for ARMA–GARCH value-at-risk: the case of heavy tails and skewness](#). *Computational Statistics & Data Analysis*, 100, 545–559.
- ▣ Tasche, D. (2008). [Capital allocation to business units and sub-portfolios: the Euler principle](#). arXiv:0708.2542.
- ▣ Taylor, J.W. (2019). [Forecasting value at risk and expected shortfall using a semiparametric approach based on the asymmetric Laplace distribution](#). *Journal of Business & Economic Statistics*, 37(1), 121–133.
- ▣ Yamai, Y., Yoshida, T. (2005). [Value-at-risk versus expected shortfall: a practical perspective](#). *Journal of Banking & Finance*, 29(4), 997–1015.