



Modelarea piețelor financiare

Capitolul 8: Backtesting și evaluarea prognozelor de risc



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ACI: Adaptive Conformal Inference (inferență conformală adaptivă)
- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model) (model autoregresiv)
- BCBS: Basel Committee on Banking Supervision (Comitetul de la Basel pentru Supraveghere Bancară)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- BIS: Bank for International Settlements (Banca Reglementelor Internaționale)
- BNR: Banca Națională a României
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DGP: Data-Generating Process (procesul generator al datelor)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- DQ: Dynamic Quantile (test) (testul cuantilei dinamice)
- EGARCH: Exponential GARCH (GARCH exponențial)
- ES: Expected Shortfall (pierdere așteptată în coadă)
- ESR: Expected Shortfall Regression (backtest) (testul ES prin regresie)
- EVT: Extreme Value Theory (teoria valorilor extreme)
- FDR: False Discovery Rate (rata descoperirilor false)
- FHS: Filtered Historical Simulation (simulare istorică filtrată)
- FRTB: Fundamental Review of the Trading Book (revizuirea fundamentală a portofoliului de tranzacționare)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- FZ: Fissler–Ziegel (family of scoring functions for VaR and ES) (familia Fissler–Ziegel de funcții de scor pentru VaR și ES)
- FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- GARCH: Generalised Autoregressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-EVT: GARCH filter combined with Extreme Value Theory for the tail (filtru GARCH combinat cu teoria valorilor extreme pentru coadă)
- GARCH-N: GARCH with Normal innovations (GARCH cu inovații Normale)
- GAS: Generalised Autoregressive Score (model) (model cu scor autoregresiv generalizat)

Acronime folosite în acest material (2/2)

- GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- GPD: Generalised Pareto Distribution (distribuția Pareto generalizată)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HS: Historical Simulation (simulare istorică)
- IMA: Internal Models Approach (abordarea bazată pe modele interne)
- LLM: Large Language Model (model lingvistic mare)
- MCS: Model Confidence Set (mulțimea de modele de încredere)
- NVIDIA: NVIDIA Corporation (company name, US chip designer (NVIDIA Corporation (nume de companie, proiectant american de cipuri))
- PIT: Probability Integral Transform (transformarea integrală de probabilitate)
- POF: Proportion Of Failures (test) (testul proporției de depășiri)
- POT: Peaks Over Threshold (metoda depășirilor de prag)

Cuprins

De ce testăm retrospectiv prognozele de risc?

Backtesting pentru VaR: acoperire și independență

Perspectiva reglementatorului: semaforul Basel și FRTB

Backtesting pentru Expected Shortfall

Elicitabilitate și funcții de scor

Backtesting comparativ

Predicția conformală pentru riscul din coadă

Studiu de caz: testarea ES din propriile prognoze

AI pentru descoperire științifică

Ce model ați certifica?

Bibliografie

Cadrul și notațiile

- ▣ **Backtesting** (testare retrospectivă): compararea prognozelor de risc făcute cu informația $\mathcal{F}_{t-1}$ cu rezultatele care au urmat
- ▣ Randamentul logaritmic zilnic $X_t = r_t = \ln(P_t/P_{t-1})$; **pierdere** zilnică $L_t = -r_t$ (număr pozitiv = bani pierduți)
- ▣ **VaR** (Value-at-Risk, valoarea expusă la risc) și **ES** la probabilitatea de coadă α (Capitolul 7)
 - $\text{VaR}_\alpha(X) = -\inf\{x : P(X \leq x) > \alpha\} = -q_\alpha(X)$; $\text{ES}_\alpha(X) = -\frac{1}{\alpha} \int_0^\alpha q_u(X) du = E[L_t \mid L_t > \text{VaR}_\alpha]$
(cazul continuu)
- ▣ Nivelurile sunt probabilități de coadă: VaR 1% ($\alpha = 0,01$), VaR 2,5% și ES 2,5% ($\alpha = 0,025$); rata țintă de depășire este α ; Basel folosea VaR 1% pe 10 zile, FRTB folosește ES 2,5%, backtesting-ul folosește prognoze la o zi
- ▣ Planul: teste de acoperire și independență, cu mărimea și puterea lor; reglementarea; teste ES; funcții de scor și backtesting comparativ; predicția conformală


Şase modele concurente

- ▣ **HS**: cuantila empirică de ordin $1 - \alpha$ a ultimelor 1000 de pierderi
- ▣ **Normal**: distribuția Normală cu media și abaterea standard din fereastră
- ▣ **Student-t**: o distribuție Student-t estimată pe fereastră (locație, scală, grade de libertate ν)
- ▣ **GARCH-t**: $\sigma_t^2 = \omega + a\varepsilon_{t-1}^2 + b\sigma_{t-1}^2$ cu șocuri Student-t standardizate
- ▣ **FHS**: volatilitatea GARCH $\times$ cuantilele empirice ale reziduurilor standardizate $z_t = \varepsilon_t / \sigma_t$
- ▣ **GARCH-EVT (McNeil & Frey (2000))**: volatilitatea GARCH $\times$ o coadă GPD estimată prin POT pe cele mai mari 10% pierderi standardizate

Experimentul de prognoză

- ▣ Patru serii, fiecare pe propriul calendar de tranzacționare
 - ▶ S&P 500 și BET (indicele Bursei de Valori București): valori de închidere
 - ▶ Bitcoin (se tranzacționează zilnic) și EUR/RON (cursul de referință BNR)
- ▣ Fereastră mobilă de 1000 de observații; fiecare prognoză folosește doar datele până în ziua precedentă
- ▣ Parametrii GARCH, Student-t și EVT se reestimează la fiecare 20 de zile; volatilitatea se actualizează zilnic
- ▣ Zile în afara eșantionului de estimare, T (evaluare până la 18.09.2026)
 - ▶ S&P 500 4 959 și BET 4 937 (din 2007), EUR/RON 4 352 (din 2009), Bitcoin 3 384 (din 2017)

Patru piețe, un model de risc



□ Portocaliu: pierderile zilnice; roșu: VaR 1% prognozat de GARCH-EVT; puncte albastre: depășiri ($L_t > VaR_t$)

Patru piețe: ce observăm

- ▣ VaR urmează volatilitatea: se dublează sau se triplează în 2008, martie 2020 și la prăbușirea cripto din 2022
- ▣ Ratele de depășire ale VaR 1% GARCH-EVT
 - ▶ S&P 500 1,13%, BET 0,99%, Bitcoin 0,95%, EUR/RON 0,78%
- ▣ EUR/RON are o scară foarte diferită: un curs administrat, cu perioade lungi de calm și salturi rare
- ▣ Întrebarea capitolului: este suficientă o rată apropiată de 1% pentru a spune că un model este bun?


Ce poate și ce nu poate identifica un backtest

- ▣ Calibrarea condiționată ideală: $P(L_t > \text{VaR}_t \mid \mathcal{F}_{t-1}) = \alpha$ pentru orice t
 - ▶ Fiecare backtest verifică o consecință a calibrării: Kupiec verifică rata necondiționată, Christoffersen dependența de ordinul întâi, iar DQ predictibilitatea pe baza regresorilor aleși
 - ▶ Un singur rezultat pe zi, deci dovezile se acumulează doar pe multe zile
- ▣ H_0 este o ipoteză **comună** despre întreaga metodă de prognoză
 - ▶ distribuția, dinamica volatilității, parametrii estimați, lungimea ferestrei și regula de reestimare
 - ▶ O respingere nu spune care componentă a eșuat
- ▣ Limitele χ^2 din manuale tratează VaR_t ca fiind cunoscut; cu parametri estimați, depășirile nu sunt exact Bernoulli(α) nici sub un model corect (riscul de estimare, finalul Secțiunii 2)
- ▣ Nerespingerea nu înseamnă validare: este informativă doar dacă testul are putere împotriva alternativelor relevante, la T disponibil

Șirul depășirilor

- ▣ O **depășire** (excepție) are loc când pierderea depășește prognoza: $I_t = 1\{L_t > \text{VaR}_t^\alpha\}$
- ▣ Un VaR corect implică două proprietăți ([Christoffersen \(1998\)](#))
 - ▶ **Acoperire necondiționată**: $P(I_t = 1) = \alpha$, deci aproximativ αT depășiri în T zile
 - ▶ **Independență**: I_t este independent de întregul istoric al depășirilor (testul Christoffersen verifică doar memoria Markov de ordinul întâi)
- ▣ Împreună: I_t sunt variabile Bernoulli(α) i.i.d.
- ▣ Un model poate eșua în ambele feluri: prea multe depășiri sau depășiri grupate

S&P 500: două prognoze VaR, 2007–2026




□ VaR 1%: HS cu turcoaz, GARCH-t cu albastru; portocaliu: pierderile zilnice; marcate: depășirile fiecărui model

HS versus GARCH-t: interpretare

- ▣ HS reacționează lent: VaR-ul lui este o funcție în trepte, care sare doar când zile extreme intră sau ies din fereastră
- ▣ GARCH-t reacționează din ziua următoare: VaR crește imediat ce crește volatilitatea
- ▣ Aproape același număr de depășiri: HS 83, GARCH-t 88 în 4 959 de zile
 - ▶ dar depășirile HS sunt concentrate în anumite perioade (2008, 2020), iar cele GARCH-t sunt mai dispersate în timp
- ▣ Numărarea depășirilor nu este, deci, suficientă: trebuie testat și **când** apar

Martie 2020: testul de stres pe care nu l-a planificat nimeni



□ S&P 500, februarie–iunie 2020: pierderile zilnice (bare) și VaR 1% al celor șase modele

Martie 2020: interpretare

- ▣ Cea mai mare pierdere: 12,77% pe 16.03.2020; în 104 zile, pentru un VaR 1% corect, numărul așteptat de depășiri este 1,04
- ▣ Depășiri în aceste 104 zile
 - ▶ Modele necondiționate: HS 12, Normal 17, Student-t 17
 - ▶ Modele condiționate: GARCH-t 3, FHS 2, GARCH-EVT 2
- ▣ O distribuție cu cozi groase (Student-t) nu ajută dacă scala nu urmează volatilitatea
- ▣ Lecția: într-o criză, condiționarea pe volatilitatea curentă contează mai mult decât forma cozii


Kupiec (1995): testul POF

- ▣ Date: $x = \sum_t I_t$ depășiri în T zile; rata estimată de depășire $\hat{\pi} = x/T$
- ▣ H_0 : $\pi = \alpha$ (acoperire necondiționată corectă), față de H_1 : $\pi \neq \alpha$
- ▣ Statistica raportului de verosimilitate (Kupiec (1995))
 - ▶ $LR_{uc} = -2 \ln \frac{(1 - \alpha)^{T-x} \alpha^x}{(1 - \hat{\pi})^{T-x} \hat{\pi}^x} \xrightarrow{d} \chi_1^2$
- ▣ Respingem la 5% dacă $LR_{uc} > 3,84$; testul este bilateral: și prea puține depășiri înseamnă eșec
- ▣ Alternativa exactă pentru T mic: distribuția Binomială(T, α) a lui x

Testul exact și puterea locală a testului POF

- ▣ S&P 500, GARCH-t, 2008: $x = 8$ în $T = 253$ (așteptat 2,53): $LR_{uc} = 7,60$, $p = 0,0058$; p Binomial exact $= 2P(X \geq 8) = 0,009$
- ▣ Alternative locale $\pi_T = \alpha + h/\sqrt{T}$: o dezvoltare de ordinul doi a log-verosimilității Bernoulli dă
 - ▶ $LR_{uc} = \frac{T(\hat{\pi} - \alpha)^2}{\alpha(1 - \alpha)} + o_p(1) \xrightarrow{d} \chi_1^2(\lambda)$, $\lambda = \frac{h^2}{\alpha(1 - \alpha)} = \frac{T(\pi - \alpha)^2}{\alpha(1 - \alpha)}$
- ▣ $T = 250$, $\pi = 2\%$: $\lambda = 2,53$, puterea locală 36%, puterea exactă 24%: cu $\alpha T = 2,5$ domină caracterul discret al lui x
- ▣ Mărimea exactă la $T = 250$ este 9,5%, nu 5%: $P(x = 0) = 0,99^{250} = 8,1\%$ cade deja în regiunea de respingere

Câte depășiri sunt acceptabile?




□ LR_{uc} în funcție de numărul de depășiri x , pentru un an (stânga) și patru ani (dreapta) de VaR 1%

Puterea redusă a testelor de acoperire


- ▣ Cu $T = 250$, testul acceptă x între 1 și 6: un model cu rata reală de depășire de 2% (dublul țintei) trece cu probabilitatea 76%
- ▣ Chiar și $x = 0$ este respins ($LR_{uc} = -500 \ln 0,99 = 5,03$): un VaR niciodată depășit este prea conservator
- ▣ Cu $T = 1000$, regiunea de acceptare se îngustează la 5–16 depășiri
- ▣ Evenimentele din coadă sunt rare prin construcție: un an de date conține aproximativ 2,5 zile informative pentru VaR 1%
- ▣ Consecință: sunt necesare eșantioane lungi, mai multe niveluri ($\alpha = 1\%$ și $2,5\%$) și mai multe teste

Puterea testului POF



- Probabilitatea de respingere a testului Kupiec la 5% în funcție de probabilitatea reală de depășire; linie continuă: calcul Binomial exact; linie întreruptă: aproximarea locală $\chi^2_1(\lambda)$
- Puterea de 50% cere $\pi \approx 2,7\%$ la $T = 250$ și $\pi \approx 1,7\%$ la $T = 1000$; diferența dintre curba exactă și cea locală vine din regiunea de respingere discretă

Ratele de depășire pe modele și piețe



□ Ponderea zilelor cu $L_t > \text{VaR}_t$ pentru VaR 1%; linia punctată: nivelul nominal de 1%

Ratele de depășire: interpretare

- ▣ Distribuția Normală eșuează peste tot în afară de EUR/RON: S&P 500 2,70%, BET 1,90%, Bitcoin 1,74%
- ▣ GARCH-t este depășit prea des pe acțiuni (S&P 500 1,77%, BET 1,46%); FHS, cu aceeași volatilitate GARCH-t, este mult mai aproape de 1% (1,23%, 1,20%): un indiciu împotriva cozii t simetrice pe partea pierderilor
- ▣ FHS și GARCH-EVT rămân cel mai aproape de 1% pe toate cele patru piețe
- ▣ HS este prea conservator pe EUR/RON (0,51%): o criză veche din fereastră îi menține VaR ridicat
- ▣ Valori p Kupiec (S&P 500): HS <0,001, GARCH-t <0,001, FHS 0,116, GARCH-EVT 0,370


Christoffersen (1998): testarea independenței

- ▣ Modelăm I_t ca lanț Markov de ordinul întâi, cu $\pi_{ij} = P(I_t = j \mid I_{t-1} = i)$
- ▣ Numărăm tranzițiile n_{ij} (din starea i ieri în starea j azi); $\hat{\pi}_{01} = \frac{n_{01}}{n_{00} + n_{01}}$, $\hat{\pi}_{11} = \frac{n_{11}}{n_{10} + n_{11}}$
- ▣ H_0 : $\pi_{01} = \pi_{11} = \pi$ (fără memorie), cu $\hat{\pi} = (n_{01} + n_{11}) / \sum n_{ij}$
- ▣ Statistica
 - ▶ $LR_{ind} = -2 \ln \frac{(1 - \hat{\pi})^{n_{00} + n_{10}} \hat{\pi}^{n_{01} + n_{11}}}{(1 - \hat{\pi}_{01})^{n_{00}} \hat{\pi}_{01}^{n_{01}} (1 - \hat{\pi}_{11})^{n_{10}} \hat{\pi}_{11}^{n_{11}}} \xrightarrow{d} \chi_1^2$
- ▣ Acoperirea condiționată: $LR_{cc} = LR_{uc} + LR_{ind} \xrightarrow{d} \chi_2^2$ testează ambele proprietăți simultan

HS în 2007–2010: de ce ratează testul Markov

- ▣ S&P 500, VaR 1% HS: $n_{00} = 928$, $n_{01} = 38$, $n_{10} = 38$, $n_{11} = 3$; $\hat{\pi}_{01} = 0,0393$, $\hat{\pi}_{11} = 0,0732$
- ▣ Probabilitatea de depășire aproape se dublează după o depășire, totuși $LR_{ind} = 0,95$ ($p = 0,33$); acoperirea eșuează: $LR_{cc} = 55,19$
- ▣ $\hat{\pi}_{11}$ se sprijină pe 3 perechi consecutive: eroarea lui standard este de ordinul $\sqrt{\hat{\pi}_{11}(1 - \hat{\pi}_{11})/(n_{10} + n_{11})}$, mai mare decât efectul
- ▣ Grupările întinse pe mai multe zile scapă unui lanț de ordinul întâi: avem nevoie de teste cu mai multe decalaje sau cu întreaga structură a distanțelor

Când apar depășirile?



- Fiecare linie este o depășire a VaR 1% pe S&P 500


Gruparea depășirilor: interpretare

- ▣ HS, Normal și Student-t: rafale dense în 2008, 2015–2016, 2018, 2020 și 2022 și perioade lungi fără depășiri
- ▣ GARCH-t, FHS și GARCH-EVT: depășiri distribuite aproape uniform pe 20 de ani
- ▣ Grupările înseamnă că pierderile vin **exact când capitalul este cel mai necesar**
- ▣ Valori p pentru independență (S&P 500): HS $<0,001$, Normal $<0,001$, GARCH-t 0,095, FHS 0,046

Teste bazate pe durate

- ▣ Durata D_i : numărul de zile dintre depășirea $i - 1$ și depășirea i
- ▣ Pentru un VaR corect, depășirile nu au memorie: D_i urmează distribuția geometrică, cu media $1/\alpha$ (100 de zile pentru $\alpha = 1\%$)
- ▣ Christoffersen & Pelletier (2004): aproximăm duratele discrete printr-un model Weibull continuu
 - ▶ $f(D; a, b) = a^b b D^{b-1} e^{-(aD)^b}$; $b = 1$ este cazul exponențial (fără memorie)
 - ▶ $b < 1$: duratele scurte sunt prea frecvente, adică depășirile se grupează
- ▣ H_0 : $b = 1$ cu a liber, un test al raportului de verosimilitate (χ_1^2) pentru lipsa memoriei, nu pentru media $1/\alpha$ (acoperirea rămâne în seama testului Kupiec); prima și ultima durată sunt cenzurate
- ▣ Folosește întreaga structură a distanțelor, nu doar zilele consecutive: putere mai mare împotriva grupării

Cât timp trece între depășiri?



□ Ponderea duratelor mai lungi decât d (scală logaritmică); linia punctată: fără memorie, cu $\alpha = 1\%$


Duratele: interpretare

- HS: $b = 0,52$, durata mediană 7 zile, 44% dintre durate au cel mult 5 zile
- Normal: $b = 0,56$; GARCH-t: $b = 0,94$ (mediana 48 de zile); GARCH-EVT: $b = 0,88$
- Valori p ale testului de durată: HS $< 0,001$, GARCH-t 0,479, GARCH-EVT 0,240
- Pe întreg eșantionul, testul de durată respinge categoric HS, la fel ca testul Markov ($p < 0,001$); nerespingerea prin testul Markov privea doar 2007–2010
- Coadă lungă a duratelor HS: ani fără depășiri după ce o criză lasă un VaR ridicat în fereastră

Backtesting prin regresie: testul DQ

- ▣ Sub acoperirea condiționată corectă, $\text{Hit}_t = I_t - \alpha$ este o diferență de martingală: $E[\text{Hit}_t | \mathcal{F}_{t-1}] = 0$, $\text{Var}(\text{Hit}_t | \mathcal{F}_{t-1}) = \alpha(1 - \alpha)$
- ▣ Deci nicio variabilă măsurabilă în $\mathcal{F}_{t-1}$ nu îl poate prezice: regresăm $\text{Hit}_t = X_t\beta + u_t$ cu $X_t = (1, \text{Hit}_{t-1}, \dots, \text{Hit}_{t-4}, \text{VaR}_t)$ și testăm $\beta = 0$
- ▣ Statistica Dynamic Quantile (Engle & Manganelli (2004), forma Wald cu dispersia sub H_0)
 - $$\text{DQ} = \frac{\hat{\beta}' X' X \hat{\beta}}{\alpha(1 - \alpha)} = \frac{\text{Hit}' X (X' X)^{-1} X' \text{Hit}}{\alpha(1 - \alpha)} \xrightarrow{d} \chi_6^2$$
- ▣ Include testul Kupiec ($X_t = 1$ dă forma scor $T(\hat{\pi} - \alpha)^2 / (\alpha(1 - \alpha))$) și pe cel Christoffersen (un decalaj); adaugă putere împotriva memoriei dincolo de decalajul 1 și a depășirilor care depind de nivelul VaR
- ▣ Extensii: regresii logit/probit pentru depășiri

Toate testele VaR dintr-o privire



□ Valorile p ale testelor Kupiec, de acoperire condiționată, de durată și DQ, VaR 1%; roșu: respingere, verde: nerespingere

Testele VaR: interpretare

- ▣ Modelele necondiționate (HS, Normal, Student-t) eșuează la testul de durată pe fiecare piață, cu o excepție: HS pe Bitcoin ($p = 0,246$)
- ▣ GARCH-EVT nu este respins la 5% de testele de acoperire și de durată pe BET, Bitcoin și EUR/RON
- ▣ DQ respinge toate modelele pe S&P 500, inclusiv FHS ($p < 0,001$) și GARCH-EVT ($p < 0,001$): depășirile sunt previzibile din nivelul VaR și din depășirile trecute, o abatere de la acoperirea condiționată pe care simpla numărare a depășirilor nu o detectează
- ▣ Pe BET și EUR/RON modelele filtrate trec testul DQ (FHS: $p = 0,208$ și $0,800$); Bitcoin este piața cea mai ușor de trecut, fiindcă fiecare fereastră de 1000 de zile conține deja mișcări extreme
- ▣ Mai multe teste pe aceleași depășiri nu sunt independente: citiți tiparul, nu o singură valoare p

Backtesting sub riscul de estimare

- ▣ Prognozele folosesc $\hat{\theta}$ estimat pe R zile; testul folosește P zile în afara eșantionului. Depășirile $\hat{I}_t = 1\{L_t > \text{VaR}_t(\hat{\theta})\}$ nu sunt cele ale lui θ_0 adevărat
- ▣ Schema fixă, dezvoltarea (Escanciano & Olmo (2010)):

$$\frac{1}{\sqrt{P}} \sum_t (\hat{I}_t - \alpha) = \frac{1}{\sqrt{P}} \sum_t (I_t - \alpha) + \sqrt{P/R} D' \sqrt{R} (\hat{\theta} - \theta_0) + o_p(1)$$

► $D = E[\partial P(L_t > \text{VaR}_t(\theta) \mid \mathcal{F}_{t-1}) / \partial \theta]$ în θ_0 : al doilea termen dispare doar dacă $P/R \rightarrow 0$
- ▣ Capitolul folosește o schemă mobilă ($R = 1000$, reestimare la 20 de zile, $P \approx 5000$): termenul de corecție depinde de schemă, dar cu $P/R \approx 5$ nici aici valorile critice χ^2 nu sunt justificate
- ▣ Ilustrare cu schema fixă (nu regula noastră mobilă): GARCH(1,1)-t cu estimările S&P 500, $R = 1000$, 400 de traiectorii: testul Kupiec respinge un model **corect** în 27,5% din eșantioane la $P = 5000$ (4,0% cu parametrii adevărați)
- ▣ Remedii: dispersia corectată sau subeșantionarea din Escanciano & Olmo (2010), ori un bootstrap parametric care reestimează modelul pe fiecare traiectorie simulată

Mărimea și puterea testelor VaR: un Monte Carlo

- DGP: GARCH(1,1)-t estimat pe S&P 500 1990–2026 ($a = 0,102$, $b = 0,892$, $\nu = 6,1$); VaR 1%; 1000 de traiectorii; rate de respingere (%) la 5%

Proгноза	T	POF	CC	Durate	DQ
Corect (mărime)	250	9,8	1,2	14,8	8,6
	1000	6,5	3,3	7,9	11,0
	5000	4,9	3,4	4,6	8,8
Normal-GARCH (putere)	250	10,5	4,9	14,7	18,8
	1000	30,3	19,9	8,0	30,3
	5000	83,8	77,2	7,2	70,7
HS, 1000 de zile (putere)	250	51,2	17,2	12,3	32,4
	1000	46,3	47,1	68,5	73,8
	5000	57,1	86,4	100,0	99,5

- Corect: parametrii și σ_t adevărați; Normal-GARCH: σ_t adevărat, coadă Normală; p de durată nedefinit (sub 3 durate) numărat ca nerespingere; eroarea standard Monte Carlo 0,7 puncte la 5%, 1,6 la 50%


Mărime și putere: interpretare

- Mărimea la $T = 250$ este departe de 5%: POF 9,8%, CC 1,2%, durate 14,8% (nedefinit în 28% din eșantioane), DQ 8,6%
- O coadă Normală pe volatilitatea corectă este aproape nedetectabilă într-un an (POF 10,5%) și cere $T = 5000$ pentru o putere de 83,8%; duratele nu o văd niciodată (7,2%): eroarea nu are memorie
- HS pe date GARCH: duratele și DQ ajung la 100,0% și 99,5% la $T = 5000$, dar doar la 12,3% și 32,4% într-un an
- DQ are în continuare o rată de respingere sub ipoteza nulă peste nivelul nominal, chiar la $T = 5000$ (8,8%): cu depășiri rare, aproximarea χ^2_6 este slabă; simulăm valorile critice
- Lecția: raportăm mărimea și puterea bateriei de teste la mărimea eșantionului folosit, nu doar valorile p

Recapitulare: backtesting pentru VaR

- ▣ Kupiec: numărul corect de depășiri; Christoffersen: fără memorie de ordinul întâi; Christoffersen–Pelletier: fără memorie în durate
- ▣ Regresia DQ: previzibilitatea depășirilor din decalaje și din nivelul VaR; parametrii estimați cu P/R mare distorsionează orice limită χ^2
- ▣ Testele de acoperire au putere redusă și mărime greșită pe un an; duratele detectează gruparea pe care acoperirea o ratează
- ▣ Empiric: modelele condiționate (filtrul GARCH) au rezultate mai bune decât cele necondiționate; modelul cozii (FHS, EVT) corectează excesul rămas

Comitetul de la Basel și backtesting-ul



Turnul BIS, Basel: sediul secretariatului BCBS

Foto: Taxiarchos228 (2014); Free Art License; Wikimedia

[Commons](#)


- Băncile care folosesc modele interne trebuie să testeze zilnic VaR 1% față de profitul și pierderea efective
- BCBS (1996) a introdus **semaforul**: excepțiile din ultimele 250 de zile determină o majorare de capital
- BCBS (2019) (FRTB) păstrează ideea, dar capitalul se bazează acum pe ES 2,5%
- Reglementatorul vrea o regulă simplă, automată și greu de manipulat

Semaforul: de unde vin zonele?

Excepții	$P(X \leq x)$	Zona
0	8,11%	verde
2	54,32%	verde
4	89,22%	verde
5	95,88%	galben
7	99,60%	galben
9	99,97%	galben
10	99,99%	roșu

- ▣ $X \sim \text{Binomială}(250; 0,01)$: excepțiile unui VaR 1% corect în 250 de zile
- ▣ Zona galbenă începe unde $P(X \leq x) \geq 95\%$, cea roșie unde $P(X \leq x) \geq 99,99\%$ (BCBS (1996))
- ▣ Regula din 1996: multiplicatorul de capital 3 crește cu 0,40–0,85 în zona galbenă și cu 1 în zona roșie
- ▣ Contează doar **numărul** excepțiilor, nu mărimea sau momentul lor

Semaforul de-a lungul timpului



□ Excepțiile VaR 1% în ultimele 250 de zile, S&P 500; zone colorate: verde, galben și roșu

Semaforul: interpretare

- ▣ Ponderea zilelor în zona roșie: Normal 22,3%, HS 14,7%, GARCH-t 2,0%, FHS 0,8%
- ▣ Vârful: HS 27 și Normal 37 excepții în cele 250 de zile încheiate la 01.12.2008
- ▣ GARCH-t petrece 46,6% din timp în zona galbenă: prea multe excepții, dar niciodată multe deodată
- ▣ Regula penalizează modelele **după** o criză, când capitalul este deja sub presiune: backtesting-ul privește înapoi

FRTB: ce s-a schimbat în 2019

- ▣ Capitalul se calculează din ES 2,5%, care vede mărimea pierderilor din coadă (BCBS (2019))
- ▣ Backtesting-ul se face în continuare pe VaR, la două niveluri
 - ▶ La nivelul băncii: VaR 1%, 250 de zile; multiplicator 1,50 (verde, 0–4), 1,70–1,92 (galben, 5–9), 2,00 (roșu, 10 sau mai multe)
 - ▶ Biroul de tranzacționare: peste 12 excepții ale VaR 1% sau 30 ale VaR 2,5% în 12 luni impun aplicarea abordării standardizate biroului
- ▣ FRTB păstrează backtesting-ul pe VaR, deși capitalul se calculează din ES; numărarea excepțiilor VaR este simplă, iar faptul că ES nu este elicitable (Secțiunea 5) nu împiedică testarea ES (Secțiunea 4)
- ▣ Aprobarea IMA cere și un test de atribuire a profitului și pierderii (nediscutat aici)

Verificarea FRTB la nivel de birou de tranzacționare, ultimele 250 de zile

Model	S&P 500	BET	Bitcoin	EUR/RON
HS	0 / 2	4 / 7	3 / 4	1 / 5
Normal	2 / 2	6 / 9	3 / 5	1 / 4
Student-t	0 / 2	4 / 9	1 / 4	5 / 8
GARCH-t	3 / 6	4 / 9	3 / 5	4 / 5
FHS	3 / 4	4 / 6	4 / 5	1 / 4
GARCH-EVT	3 / 3	2 / 7	4 / 5	1 / 4

- Celule: excepții ale VaR 1% / ale VaR 2,5% în ultimele 250 de zile ale fiecărei serii (până la 18.09.2026)
- Limite: 12 pentru VaR 1%, 30 pentru VaR 2,5%; toate modelele trec confortabil
- Doar ilustrativ: FRTB aplică limitele profitului și pierderii birourilor (efective și ipotetice), nu randamentelor de indici
- Ultimul an a fost calm: o lumină verde azi spune puțin despre următoarea criză

Recapitulare: perspectiva reglementatorului

- Semaforul = un test Binomial cu praguri fixe, calibrat pentru 250 de zile de VaR 1%
- FRTB: capital pe ES 2,5%; backtesting pe VaR 1% la nivelul băncii și pe VaR 1% și VaR 2,5% la nivelul birourilor de tranzacționare
- Modelele necondiționate ar fi petrecut perioade lungi în zona roșie după 2008 și 2020


De ce ES este mai greu de testat

- O prognoză VaR se verifică printr-un eveniment da/nu pe zi; ES este o **medie** peste coada de dincolo de VaR
- Cea mai mare parte a informației vine din zilele cu depășire: aproximativ αT zile (124 pentru S&P 500 cu $\alpha = 2,5\%$)
- În 250 de zile există $250 \cdot 0,025 = 6,25$ observații în coadă; eroarea standard a mediei din coadă, dacă dispersia în coadă este finită, scade ca $1/\sqrt{\alpha T} \approx 0,40$
- [Pele & Mazurencu-Marinescu-Pele \(2026\)](#): aproximativ una din cinci comparații ES pe perechi, pe piețele globale, este fragilă ca precizie
- Trei familii de teste: teste pe reziduuri, statisticile Acerbi–Szekely, depășirile cumulate

McNeil și Frey (2000): reziduurile de depășire

- ▣ În fiecare zi de depășire a VaR 2,5% calculăm $e_t = (L_t - ES_t)/\sigma_t$, unde σ_t este volatilitatea prognozată
- ▣ Dacă VaR și ES sunt corecte condiționat de $\mathcal{F}_{t-1}$, iar volatilitatea $\sigma_t > 0$ este cunoscută la $t - 1$:
 $E[e_t | L_t > \text{VaR}_t, \mathcal{F}_{t-1}] = 0$; un VaR greșit schimbă evenimentul de condiționare
- ▣ H_0 : $E[e_t] = 0$ față de H_1 : $E[e_t] > 0$ (ES subestimat); statistică t unilaterală
- ▣ Reziduuri puține și cu cozi groase: [McNeil & Frey \(2000\)](#) obțin valoarea p printr-un bootstrap i.i.d. al reziduurilor centrate, care presupune reziduuri independente (altfel, bootstrap pe blocuri)
- ▣ Împărțirea la σ_t face reziduurile comparabile între zilele calme și cele agitate

Reziduurile de depășire pe S&P 500



□ Distribuția lui $(L_t - ES_t)/\sigma_t$ în zilele de depășire a VaR 2,5%; romburi: mediile

Reziduurile de depășire: interpretare


- ▣ Medii: Normal 0,875, HS 0,363, GARCH-t 0,106, FHS 0,093, GARCH-EVT 0,045
- ▣ Valori p bootstrap: Normal $<0,001$, HS $<0,001$, GARCH-t 0,023, FHS 0,096, GARCH-EVT 0,246
- ▣ Distribuția Normală subestimează media din coadă cu aproape o unitate de volatilitate
- ▣ Valorile extreme (până la 10 unități de volatilitate) sunt zilele care decid adecvarea capitalului

Acerbi și Szekely (2014): testarea directă a ES

- Indicatorul de depășire la nivelul ES: $I_t = 1\{L_t > \text{VaR}_t^\alpha\}$, $N_T = \sum_t I_t$, $\alpha = 0,025$
- $Z_1 = 1 - \frac{1}{N_T} \sum_t \frac{L_t I_t}{\text{ES}_t}$: este pierderea medie din coadă atât de mare cât s-a prognozat? (condiționat de depășiri)
- $Z_2 = 1 - \frac{1}{T_\alpha} \sum_t \frac{L_t I_t}{\text{ES}_t}$: testează frecvența și mărimea împreună
- Sub H_0 (distribuția prognozată este corectă) $E[Z_2] = 0$; riscul subestimat dacă $Z_2 < 0$ (Acerbi & Szekely (2014))
- Pentru $T = 250$ și multe distribuții, valorile critice de 5% și 0,01% sunt apropiate de $-0,70$ și $-1,8$: un semafor pentru ES

Valori p prin simulare

- ▣ Distribuția lui Z_2 sub H_0 depinde de distribuțiile prognozate F_t , pe care le furnizează modelul
- ▣ Algoritm (se repetă de $M = 2000$ ori)
 - ▶ Pentru fiecare zi extragem $U_t \sim \text{Uniform}(0,1)$ și calculăm $L_t^* = F_t^{-1}(U_t)$
 - ▶ Calculăm Z_2^* din pierderile simulate, cu aceleași prognoze VaR și ES
- ▣ Valoarea p = ponderea valorilor simulate Z_2^* mai mici sau egale cu Z_2 observat
- ▣ Contează doar extragerile din coadă: pentru HS și FHS păstrăm cele mai mari 25 de pierderi din fereastra fiecărei zile
- ▣ S&P 500, întreg eșantionul: $Z_2 = -0,618$ pentru GARCH-t ($p < 0,001$) față de $-0,091$ pentru FHS ($p = 0,172$); valoarea critică este de circa $-0,152$

Z_2 pe ferestre mobile de 250 de zile

□ Z_2 pentru prognozele ES 2,5% pe ultimele 250 de zile, S&P 500, cu pragurile fixe $-0,70$ și $-1,8$

Semaforul Z_2 : interpretare

- ▣ Minimul lui Z_2 : Normal $-11,13$ și HS $-7,30$ (fereastra încheiată la 01.12.2008); GARCH-t $-2,52$; FHS $-1,97$
- ▣ Ponderea ferestrelor sub $-1,8$ (roșu): Normal 21,9%, HS 15,8%, GARCH-t 3,0%, FHS 0,7%
- ▣ GARCH-t se află sub $-0,70$ în 39,6% dintre ferestre: subestimare frecventă, dar mică, a cozii
- ▣ Z_2 penalizează mărimea ratărilor, nu doar numărul lor: HS coboară la $-7,30$, în timp ce numărul excepțiilor a atins 27

Du și Escanciano (2017): depășirile cumulate

- ▣ PIT: $u_t = F_t(L_t)$, uniformă pe $(0, 1)$ dacă distribuția prognozată este corectă
- ▣ Depășirea cumulată: $H_t = \frac{1}{\alpha} (u_t - (1 - \alpha)) 1\{u_t > 1 - \alpha\}$: cât de adânc în coadă a ajuns pierderea
- ▣ Sub H_0 : $E[H_t] = \alpha/2$ și $\text{Var}(H_t) = \alpha(1/3 - \alpha/4)$
- ▣ Testul necondiționat: $U = \sqrt{T} (\bar{H} - \alpha/2) / \sqrt{\alpha(1/3 - \alpha/4)} \xrightarrow{d} N(0, 1)$
- ▣ Testul condiționat: statistica Box–Pierce pe primele 5 autocorelații ale lui H_t , χ_5^2 (Du & Escanciano (2017))

Toate testele ES dintr-o privire

	McNeil-Frey				Acerbi-Szekely Z2				Du-Escanciano U			
HS	<0.001	0.48	0.70	0.46	<0.001	0.13	0.86	1.00	<0.001	0.36	0.14	<0.001
Normal	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	0.001	0.97	<0.001	<0.001	<0.001	0.25
Student-t	0.17	0.01	1.00	0.47	0.002	0.003	0.62	0.92	<0.001	<0.001	0.93	0.05
GARCH-t	0.02	0.04	0.50	0.41	<0.001	<0.001	0.05	0.63	<0.001	<0.001	0.13	0.86
FHS	0.10	0.63	0.60	0.75	0.17	0.19	0.35	0.97	0.09	0.46	0.95	0.09
GARCH-EVT	0.25	0.57	0.29	0.69	0.09	0.21	0.58	0.98	0.24	0.54	0.70	0.11
	S&P 500	BET	Bitcoin	EUR/RON	S&P 500	BET	Bitcoin	EUR/RON	S&P 500	BET	Bitcoin	EUR/RON

□ Valorile p pentru ES 2,5%: McNeil–Frey (bootstrap), Z_2 (simulare), Du–Escanciano U

Testele ES: interpretare

- ▣ Distribuția Normală este respinsă de toate cele trei teste pe S&P 500, BET și Bitcoin
- ▣ FHS și GARCH-EVT trec cele trei teste ES de mai sus la 5% pe toate cele patru piețe (testul multinomial de mai jos este mai strict)
- ▣ GARCH-t eșuează la Z_2 pe acțiuni ($p < 0,001$ pe S&P 500, $< 0,001$ pe BET); FHS, cu același filtru de volatilitate, trece: eșecul indică spre coada t
- ▣ EUR/RON: majoritatea modelelor supraestimează ES ($Z_2 > 0$), consecință a cursului administrat
- ▣ Testele conduc la concluzii similare, dar diferă în cazurile limită: Student-t pe S&P 500 are McNeil–Frey $p = 0,173$, dar Z_2 $p = 0,002$

Teste VaR multinomiale: un test implicit pentru ES

- ES 2,5% este media cuantilelor de dincolo de VaR 2,5%: testăm simultan mai multe niveluri VaR (Kratz, Lok & McNeil (2018))
- $N = 4$ niveluri de coadă $\alpha_j = 2,5\% (1 - (j - 1)/4)$: 2,5%, 1,875%, 1,25%, 0,625%; fiecare zi cade într-una din 5 celule, prin PIT u_t
- Statistica Pearson $S = \sum_{j=0}^4 (O_j - Tp_j)^2 / (Tp_j) \xrightarrow{d} \chi_4^2$, probabilitățile celulelor $p_0 = 97,5\%$, $p_1 = \dots = p_4 = 0,625\%$

Valoare p	S&P 500	BET	Bitcoin	EUR/RON
HS	<0,001	0,725	0,564	0,004
Normal	<0,001	<0,001	<0,001	<0,001
Student-t	<0,001	0,024	0,015	0,172
GARCH-t	<0,001	<0,001	0,227	0,568
FHS	0,008	0,846	0,413	0,392
GARCH-EVT	0,287	0,864	0,969	0,240

- Doar GARCH-EVT trece pe toate cele patru piețe; celulele GARCH-t pe S&P 500 (4767, 36, 46, 50, 60), față de 31 așteptate în fiecare celulă din coadă: prea multe zile în fiecare celulă din coadă, cele mai multe în cea mai adâncă

Două teste ES recente: regresie și monitorizare

- ▣ Testul ES prin regresie (Bayer & Dimitriadis (2022))
 - ▶ Regresăm L_t pe $(1, ES_t)$ într-o regresie comună (cuantilă, ES); H_0 : termen liber 0, pantă 1
 - ▶ Cere doar prognozele ES, nu distribuția prognozată: avantajul față de Z_2 , ale cărei valori p cer simulare
- ▣ Monitorizarea secvențială (Hoga & Demetrescu (2023))
 - ▶ Reglementatorul verifică prognozele zilnic: testele repetate pe eșantion fix umflă mărimea totală
 - ▶ Statisticile de monitorizare cu funcții-frontieră țin sub nivelul nominal probabilitatea oricărei alarme false pe întregul orizont
- ▣ Ambele răspund slăbiciunilor de mai sus: dependența de distribuția prognozată și evaluarea la un singur moment oferită de semafor

Recapitulare: backtesting pentru ES

- ▣ Testele ES se bazează în principal pe puținele zile din coadă, deci puterea pe un an este redusă; testele prin regresie folosesc și celelalte zile
- ▣ McNeil–Frey testează reziduul mediu, Z_2 testează frecvența și mărimea, Du–Escanciano testează adâncimea depășirilor
- ▣ Simularea Z_2 și testele bazate pe PIT cer distribuția prognozată; testele cu bootstrap pe reziduuri și cele prin regresie evită specificarea ei completă
- ▣ Testele multinomiale la mai multe niveluri VaR sunt teste ES implicite, simple și puternice

A testa nu înseamnă a ierarhiza

- ▣ Un backtest întreabă: este acest model **acceptabil**? Mai multe modele pot trece sau toate pot eșua
- ▣ Backtesting-ul comparativ întreabă: care model este **mai bun**? (Nolde & Ziegel (2017))
- ▣ Ierarhizarea cere o **funcție de scor** $S(x, L)$: pierderea asociată raportării lui x când se realizează L
- ▣ Comparăm scorurile medii $\bar{S} = \frac{1}{T} \sum_t S(x_t, L_t)$: un scor mai mic indică o prognoză mai bună
- ▣ Dar care funcție de scor? Una nepotrivită poate recompensa o prognoză greșită



Elicitabilitate

- ▣ O statistică $\theta(F)$ este **elicitabilă** dacă o funcție de scor este minimizată în medie exact de valoarea adevărată (Gneiting (2011))
- ▣ $\theta(F) = \arg \min_x E_F [S(x, L)]$
- ▣ VaR: pierderea pinball $S(v, L) = (1\{L > v\} - \alpha)(L - v)$. Consistența într-un rând, pentru $E|L| < \infty$ și $f > 0$ în cuantilă
 - ▶ $\frac{\partial}{\partial v} E_F[S(v, L)] = -P(L > v) + \alpha = F(v) - (1 - \alpha) = 0 \Rightarrow v = F^{-1}(1 - \alpha) = \text{VaR}_\alpha$, iar $\frac{\partial^2}{\partial v^2} = f(v) > 0$
- ▣ Principiul lui Osband (Fissler & Ziegel (2016)): scorurile consistente se construiesc dintr-o funcție de identificare, aici $V(v, L) = 1\{L \leq v\} - (1 - \alpha)$, cu $E_F[V] = 0$ doar în valoarea adevărată
- ▣ ES **nu** este elicitabil singur: nicio funcție de scor care depinde doar de e nu este minimizată de ES adevărat (Gneiting (2011))

VaR și ES împreună: Fissler și Ziegel (2016)

- ▣ Perechea (VaR, ES) este elictabilă împreună: [Fissler & Ziegel \(2016\)](#) caracterizează întreaga familie de funcții de scor consistente
- ▣ Pierderea FZ0 ([Patton, Ziegel & Chen \(2019\)](#)), cu pierderi pozitive, $0 < v \leq e$, $E|L| < \infty$ și ES adevărat pozitiv
 - ▶
$$\text{FZ0}(v, e; L) = \frac{1\{L > v\}(L - v)}{\alpha e} + \frac{v}{e} + \ln e - 1$$
- ▣ Primul termen: penalizarea depășirilor, scalată cu ES; ultimii termeni: penalizarea raportării unui ES mare
- ▣ Diferențele de pierderi FZ0 nu depind de unitățile pierderilor, deci pot fi comparate între active
- ▣ FZ0 mediu mai mic = prognoză comună VaR și ES mai bună

Elicitabilitatea în imagini



□ Pierderi Student-t cu $\nu = 4$ și dispersie unitară, $\alpha = 2, 5\%$; pierderile așteptate sunt calculate pe 2 milioane de extrageri


Elicitabilitatea: interpretare

- ▣ Stânga: pierderea pinball așteptată este minimă în VaR 2,5% adevărat, 1,96
- ▣ Dreapta: pierderea FZ0 așteptată este minimă în (1,96; 2,82), adică în perechea adevărată (VaR, ES), în limita rezoluției grilei
- ▣ Un prognozator care cunoaște adevărul nu are motiv să raporteze altceva: scorul este **consistent**
- ▣ Consistența face ca ordonarea după scorul mediu să aibă sens

Este clasamentul robust la alegerea scorului? Scoruri elementare

- ▣ Pentru o cuantilă există o infinitate de scoruri consistente: $S(v, L) = (1\{L \leq v\} - \tau)(g(v) - g(L))$, orice g crescătoare, $\tau = 1 - \alpha$
- ▣ Fiecare este o mixtură de **scoruri elementare** (Ehm, Gneiting, Jordan & Krüger (2016))
 - ▶ $S_\theta(v, L) = (1\{L < v\} - \tau)(1\{\theta < v\} - 1\{\theta < L\})$, $\theta \in \mathbb{R}$; pierderea pinball este $\int S_\theta d\theta$
- ▣ Prognoza A o bate pe B sub **orice** scor consistent dacă și numai dacă $\bar{S}_\theta(A) \leq \bar{S}_\theta(B)$ pentru orice θ
- ▣ **Diagrama Murphy**: reprezentăm $\bar{S}_\theta$ în funcție de θ ; intersecția curbelor arată dependența clasamentului de scorul ales

Diagrama Murphy: GARCH-t versus FHS



- S&P 500, VaR 1%, 2007–2026; θ între 0,9% și 11,3% (domeniul prognozelor); dreapta: diferența, cu o bandă punctuală HAC de 95%

Diagrama Murphy: interpretare

- ▣ Pierderea pinball ($\times 10^4$): GARCH-t 3,849, FHS 3,849: egalitate sub scorul obișnuit
- ▣ Sub $\theta = 5\%$ curbele se intersectează repetat: FHS este mai bun pe 50% dintre praguri, iar banda conține zero pe 82% dintre ele
- ▣ Peste 5%, GARCH-t are scorul mai mic pe 89% dintre praguri: scorurile care ponderează pragurile de criză îl favorizează
- ▣ Nicio prognoză nu o domină pe cealaltă: clasamentul depinde de scor, deci alegem scorul înainte de a vedea rezultatele


Recapitulare: elicitabilitate

- Elicitabil = există o funcție de scor care recompensează sinceritatea
- VaR: pierderea pinball; ES singur: imposibil; (VaR, ES) împreună: familia FZ, de exemplu FZ0
- Elicitabilitatea contează pentru **ierarhizarea** modelelor; ES poate fi totuși **testat** (Secțiunea 4)
- Diagramele Murphy verifică dacă un clasament rămâne valabil pentru întreaga familie de scoruri consistente

Testul Diebold–Mariano pe pierderile FZ0

- ▣ Diferența de pierdere dintre modelele A și B : $d_t = \text{FZ0}_{A,t} - \text{FZ0}_{B,t}$
- ▣ H_0 : $E[d_t] = 0$ (acuratețe predictivă egală), Diebold & Mariano (1995)
- ▣
$$\text{DM} = \frac{\bar{d}}{\sqrt{\widehat{\text{LRV}}(d_t)/T}} \xrightarrow{d} N(0, 1)$$
- ▣ $\widehat{\text{LRV}}$: dispersia pe termen lung cu ponderi Newey–West (Newey & West (1987)), 9 decalaje; pierderile din coadă se grupează, deci d_t este autocorelat
- ▣ $\text{DM} > 0$: modelul A are pierderea medie mai mare (mai slab); $|\text{DM}| > 1,96$: semnificativ la 5%

Pierdere FZ0 medie pe modele




□ Pierdere FZ0 medie a prognozelor (VaR 2,5%, ES 2,5%) minus cea a celui mai bun model de pe fiecare piață

Clasamentul FZ0: interpretare

- ▣ Cel mai bun model: FHS pe S&P 500; GARCH-EVT pe BET, Bitcoin și EUR/RON
- ▣ Modelele necondiționate pierd 0,3–0,6 unități FZ0 pe S&P 500, BET și EUR/RON
- ▣ Pe Bitcoin toate modelele sunt apropiate (cea mai mare diferență 0,062): datele nu le pot separa
- ▣ GARCH-t este în urma FHS pe S&P 500 cu 0,039: puțin, dar este semnificativ?

Teste Diebold–Mariano pe perechi, S&P 500



Statistica DM pentru modelul A (rând) minus modelul B (coloană) pe pierderile FZ0; roșu: A mai slab, verde: A mai bun

Diebold–Mariano: interpretare

- ▣ HS față de FHS: $DM = 4,70$; GARCH-t față de FHS: $DM = 2,65$: ambele semnificativ mai slabe
- ▣ GARCH-EVT față de FHS: $DM = 1,24$: nu se pot deosebi statistic
- ▣ HS bate distribuția Normală ($DM = 2,88$ pentru Normal minus HS): o cuantilă empirică lentă este totuși mai bună decât o coadă subțire
- ▣ Multe teste pe perechi ridică o problemă de testare multiplă: care modele rămân **împreună**?

Compararea metodelor de prognoză: Giacomini–White

- DM vizează acuratețea populațională a **modelelor**; cu ferestre mobile de 1000 de zile și parametri reestimați comparăm **metode de prognoză**, iar eroarea de estimare nu dispare
- **Giacomini & White (2006)**: $H_0: E[\Delta L_t | \mathcal{F}_{t-1}] = 0$ pentru $\Delta L_t = FZ0_{A,t} - FZ0_{B,t}$; valid pentru modele imbricate și ferestre finite
- Funcția test $h_{t-1} = (1, \Delta L_{t-1})'$, $Z_t = h_{t-1} \Delta L_t$: $GW = T \bar{Z}' \hat{\Omega}^{-1} \bar{Z} \xrightarrow{d} \chi^2_2$, $\hat{\Omega} = T^{-1} \sum_t Z_t Z_t'$ (un pas înainte)
- Cu $h_{t-1} = 1$, statistica are forma DM: cifrele DM de mai sus rămân valabile, citite acum ca teste despre metode
- S&P 500 față de FHS: GARCH-EVT $GW = 7,38$ ($p = 0,025$), GARCH-t $7,59$ ($p = 0,022$), HS $53,38$ ($p < 0,001$); GARCH-EVT, la egalitate după DM, este respins condiționat: egalitatea capacității predictive condiționate este respinsă pentru aceste instrumente; ce moment o determină cere un test separat

Backtesting comparativ în trei zone (Nolde și Ziegel)

- Modelul intern A față de un model standard S (aici HS), pierderea FZ0 medie; două teste unilaterale la 5% (Nolde & Ziegel (2017))
- H_0^- : A cel puțin la fel de bun ca S ; H_0^+ : A cel mult la fel de bun. **Verde**: respingem H_0^+ ; **roșu**: respingem H_0^- ; **galben**: niciuna
- Sarcina probei se inversează: banca trebuie să arate că modelul ei este mai bun, nu supraveghetorul că este mai slab


DM (A minus HS)	S&P 500	BET	Bitcoin	EUR/RON
GARCH-t	-4,23	-5,18	0,09	-6,66
FHS	-4,70	-5,49	-0,17	-6,94
GARCH-EVT	-4,68	-5,53	-0,25	-6,92

- Culoarea = zona. Verde peste tot, cu excepția Bitcoin, unde toate modelele sunt galbene: cu o coadă atât de zgomotoasă, niciun model nu poate dovedi că bate HS

Mulțimea de modele de încredere

- ▣ Hansen, Lunde & Nason (2011): o mulțime de modele construită astfel încât să conțină modelele cele mai bune cu o probabilitate asimptotică de cel puțin $1 - \alpha_{MCS}$, în condițiile de regularitate ale metodei
- ▣ Algoritm
 - ▶ Testăm H_0 : toate modelele din mulțimea curentă au aceeași pierdere așteptată
 - ▶ Dacă o respingem, eliminăm modelul cu cea mai mare pierdere medie standardizată și repetăm
 - ▶ Valorile critice provin dintr-un bootstrap pe blocuri (blocuri de 10 zile, 1000 de replicări)
- ▣ Valoarea p MCS a unui model: cea mai mare valoare p a testelor până la eliminarea lui; păstrăm modelele cu $p \geq 0,10$
- ▣ O mulțime MCS mare este un răspuns onest: datele nu separă modelele

Ce modele rămân?



☐ Valorile p MCS pentru pierderea FZ0 a prognozelor (VaR 2,5%, ES 2,5%), pe piețe

MCS: interpretare

- ▣ S&P 500: rămân doar FHS și GARCH-EVT (MCS p 0,21); GARCH-t este exclus (p 0,01)
- ▣ EUR/RON: rămân cele trei modele condiționate; BET: rămân FHS și GARCH-EVT, GARCH-t ratează la limită (p 0,09)
- ▣ Modelele necondiționate sunt excluse peste tot, cu excepția Bitcoin
- ▣ Bitcoin: rămân toate cele șase modele: datele nu le pot separa (comparați cu [Pele & Mazurencu-Marinescu-Pele \(2026\)](#))
- ▣ Concluzia ansamblului de teste: FHS și GARCH-EVT sunt modelele de referință

Recapitulare: backtesting comparativ

- ▣ Ierarhizăm modelele cu un scor consistent (FZ0 pentru VaR și ES); le comparăm cu teste DM cu dispersii HAC
- ▣ Cu prognoze estimate pe ferestre mobile, citim testele ca teste Giacomini–White despre metode; condiționarea poate răsturna o egalitate necondiționată
- ▣ Utilizarea reglementară: testul comparativ în trei zone pune sarcina probei pe bancă
- ▣ MCS tratează multe modele deodată și arată pe care datele nu le pot separa (nerespingerea nu dovedește performanțe egale)
- ▣ Un model poate trece toate testele și totuși să fie dominat de unul mai bun

O promisiune fără ipoteze de distribuție



Emmanuel Candès, coautor al inferenței
conformale adaptive

Foto: Cmichel67 (2026); CC BY-SA 4.0;
Wikimedia Commons

- Toate modelele de până acum presupun o distribuție (Normală, t , GPD) sau un trecut stabil, ca HS
- **Predicția conformală** transformă orice prognoză într-o cuantilă cu garanție de acoperire (Lei et al. (2018), Angelopoulos & Bates (2021))
- Singura ipoteză: datele sunt **schimbabile**, adică distribuția lor comună nu se schimbă la permutare
- Randamentele financiare prezintă grupări de volatilitate, care încalcă ipoteza de schimbabilitate


Cuantile conformale split

- ▣ Scorul de neconformitate: $s_t = L_t / \hat{\sigma}_t$, cu $\hat{\sigma}_t$ abaterea standard a celor 250 de randamente anterioare zilei t
- ▣ Mulțimea de calibrare: ultimele $n = 250$ scoruri, ordonate $s_{(1)} \leq \dots \leq s_{(n)}$
- ▣ VaR conformal: $\text{VaR}_t = \hat{\sigma}_t s_{(k)}$, cu $k = \lceil (n+1)(1-\alpha) \rceil$
- ▣ Garanția, dacă cele $n+1$ scoruri sunt schimbabile: $P(L_t \leq \text{VaR}_t) \geq 1 - \alpha$ (și $\leq 1 - \alpha + \frac{1}{n+1}$ fără valori egale)
 - ▶ Fără schimbabilitate, abaterea acoperirii este mărginită de distanțe ponderate în variație totală între vectorul comun al scorurilor și același vector în care scorul de test este schimbat cu scorul de calibrare i (Barber, Candès, Ramdas & Tibshirani (2023))
 - ▶ Aici $\hat{\sigma}_t$ provine din ferestre mobile suprapuse, deci scorurile nu sunt schimbabile nici pentru randamente i.i.d.: garanția este aproximativă, spre deosebire de conformal split cu un scor estimat o singură dată pe un eșantion separat
- ▣ Exemplu: $n = 250$, $\alpha = 0,01$: $k = \lceil 251 \cdot 0,99 \rceil = 249$, al doilea cel mai mare scor; probabilitatea de depășire între 0,60% și 1%

Inferența conformală adaptivă

- ▣ **Gibbs & Candès (2021)**: nivelul de lucru se actualizează după fiecare zi, $\alpha_{t+1} = \alpha_t + \gamma (\alpha - \text{err}_t)$, $\text{err}_t = 1\{L_t > \text{VaR}_t\}$
- ▣ După o depășire α_t scade (VaR crește); după zile calme crește încet la loc; folosim $\gamma = 0,005$
 - ▶ Alegerea lui γ : **Zaffran et al. (2022)** agregă experți ACI pe o grilă de valori γ
- ▣ Garanția, fără nicio ipoteză asupra datelor: $\left| \frac{1}{T} \sum_t \text{err}_t - \alpha \right| \leq \frac{\max(\alpha_1, 1 - \alpha_1) + \gamma}{\gamma T}$
- ▣ Garanția privește **media** pe termen lung, nu fiecare zi sau fiecare criză
- ▣ Dacă $\alpha_t < 1/(n+1)$, cuantila cerută nu există: VaR devine infinit

VaR conformal în perioada COVID-19




□ S&P 500, iulie 2019–iunie 2021: VaR 1% conformal split, ACI și GARCH-t (sus) și nivelul ACI α_t (jos)

VaR conformal într-o criză: interpretare

- ▣ 20.02–30.04.2020 (50 de zile, 0,5 depășiri așteptate): conformal split 6 depășiri, ACI 4
- ▣ ACI a pus $\text{VaR} = \infty$ în 37 din aceste 50 de zile: a oprit noile depășiri, dar a ratat ținta (4 depășiri, 8% din zile); un VaR infinit nu aduce informație
- ▣ După prăbușire, mulțimea de calibrare conține martie 2020: VaR-ul conformal split rămâne în jur de 18% un an întreg
- ▣ GARCH-t se adaptează în câteva zile pentru că modelează dependența; conformal split își actualizează zilnic scala și scorurile, dar ferestrele de 250 de zile reacționează lent; nivelul ACI scade după fiecare depășire și crește doar lent ($+\gamma\alpha$) în zilele fără depășire

Acoperirea în perioade calme și de criză



- Ratele de depășire ale VaR 5%; zile de criză: volatilitatea din cele 20 de zile anterioare peste percentila 90 a valorilor ei din cele 1000 de zile anterioare (cunoscută dinainte)

Calm versus criză: interpretare

- ▣ Pe toate zilele, conformal split este aproape de 5%: S&P 500 5,34%, BET 5,63%, Bitcoin 4,58%, EUR/RON 5,06%
- ▣ După perioade agitate este depășit mai des: S&P 500 7,29%, BET 8,08%, Bitcoin 7,95%, EUR/RON 11,43%
- ▣ ACI aduce ratele din criză aproape de 5% pe acțiuni (S&P 500 4,49%, BET 5,38%) și le reduce pe Bitcoin (6,44%) și EUR/RON (6,12%)
- ▣ Pentru VaR 1%, ACI păstrează media doar printr-un VaR infinit în 13,4% dintre zilele S&P 500
- ▣ Ratele totale sunt aproape de nivelul nominal, cele din criză nu; o direcție promițătoare este aplicarea metodei conformale unui model condiționat bun (scoruri standardizate cu volatilitatea GARCH)

Recapitulare: predicția conformală

- ▣ Conformal split: acoperire în eșantion finit sub schimbabilitate, fără model de distribuție
- ▣ ACI: acoperire medie pe termen lung pentru orice șir, posibil cu VaR infinit
- ▣ Ambele eșuează condiționat în grupările de volatilitate: le testăm ca pe orice alt model

Se poate testa ES doar din prognozele ES?

- Bayer & Dimitriadis (2022): pot fi testate prognozele ES folosind doar aceste prognoze și randamentele observate?
- Relevanță: în FRTB, cerința de capital se bazează pe ES 2,5% (Secțiunea 3 a acestui curs)
 - ▶ Testele ES din Secțiunea 4 cer și prognoze VaR, volatilitatea sau întreaga distribuție prognozată (Z_2 , McNeil & Frey (2000), Du & Escanciano (2017), Kratz, Lok & McNeil (2018)); supraveghetorii nu primesc neapărat aceste date (Secțiunea 1.1 a lucrării)
 - ▶ Respingerea unui astfel de test comun nu arată care dintre date este greșită (Definiția 1.1: un backtest al unei măsuri de risc folosește doar randamentele și prognozele acelei măsuri)
- Ideea: o regresie Mincer–Zarnowitz în care randamentele sunt explicate prin prognozele ES, cu H_0 : termenul liber 0, panta 1
 - ▶ ES nu este elicitol separat (Secțiunea 5), deci nu există o funcție de pierdere pentru estimarea separată a regresiei ES; perechea (VaR, ES) este elicitolabilă în comun (Fissler & Ziegel (2016)), ceea ce permite estimarea unei regresii comune cuantilă–ES (Patton, Ziegel & Chen (2019))


Date și metodă

- Convenția randamentelor: r_t randamentul logaritmic zilnic, $\hat{e}_t = -\widehat{ES}_t < 0$ prognoza ES în unități de randament, $\tau = 2,5\%$; regresia ES (Ec. 1.4–1.6): $r_t = \gamma_1 + \gamma_2 \hat{e}_t + u_t^e$, cu $ES_\tau(u_t^e | \mathcal{F}_{t-1}) = 0$
 - ▶ **ESR auxiliar** (Ec. 1.8–1.10): ecuația cuantilei pe $(1, \hat{v}_t)$, test Wald pentru $(\gamma_1, \gamma_2) = (0, 1)$; cere și prognoze VaR
 - ▶ **ESR strict** (Ec. 1.11–1.13): și ecuația cuantilei pe $(1, \hat{e}_t)$: intră doar prognozele ES; exact când VaR și ES sunt proporționale (modele de scală pură)
 - ▶ **ESR cu termen liber** (Ec. 1.14–1.15): $r_t - \hat{e}_t = \beta_1 + \beta_2 \hat{e}_t + u_t^q$, $r_t - \hat{e}_t = \gamma_1 + u_t^e$; test t unilateral pentru $H_0: \gamma_1 \geq 0$ față de $\gamma_1 < 0$ (ES subestimat)
- Estimare (Ec. 1.16–1.18): estimator de tip M care minimizează pierderea FZ0 din Secțiunea 5; teorie asimptotică sub specificare greșită (Teorema 1.4) și o matrice de covarianță de tip sandwich robustă la specificarea greșită (Secțiunea 1.5); pachetele R [esback](#) și [esreg](#)
- Simulări (Secțiunea 2): 10 000 de replicări, T de la 250 la 5 000 de zile; EGARCH-t calibrat pe S&P 500, AR(1)-GARCH(1,1), două modele GAS Student-t; puterea împotriva prognozelor HS estimate pe o fereastră de 250 de zile
 - ▶ Teste de comparație: testul reziduurilor de depășire propus de [McNeil & Frey \(2000\)](#) și testele de calibrare condiționată propuse de [Nolde & Ziegel \(2017\)](#)
- Aplicația (Secțiunea 3): randamentele logaritmice zilnice ale celor mai mari 200 de acțiuni din S&P 500; în afara eșantionului, ianuarie 2010 – august 2019 (2 432 de zile)
 - ▶ GARCH(1,1) și GJR-GARCH(1,1), inovații Normale sau Student-t; ferestre mobile de 250, 500, 1 000, 1 500, 2 000 de zile; reestimare la fiecare 5, 21, 62, 125, 250 de zile; ESR cu termen liber, unilateral, la 5%

Rezultatele principale

Rezultat	Sursa	Interpretare
Mărima la 5% nominal, EGARCH-t: ESR strict 0,09 ($T = 250$) și 0,05 ($T = 1000$) cu covarianța robustă; 0,24 și 0,11 cu cea clasică	Tabelul 1	Covarianța robustă îmbunătățește controlul mărimii; la $T = 250$ mărimea rămâne 0,09
Mărimile ESR strict și ESR auxiliar diferă cu cel mult 0,01 pentru fiecare proces și mărime a eșantionului, inclusiv AR(1)-GARCH cu $\phi = 0,5$	Tabelul 1	În aceste simulări, renunțarea la prognozele VaR aproape nu schimbă mărimea; puterea se compară separat (Fig. 2–3)
Testul simplu de calibrare condiționată: mărime 0,29 la $T = 250$ și 0,14 la $T = 1000$ (EGARCH-t)	Tabelul 1	Un concurent cu putere brută mare o poate datora respingerilor excesive
Testele reziduurilor de depășire aproape nu reacționează la o dinamică greșită a volatilității sau la prognoze pentru un nivel greșit $\tilde{\tau} \neq \tau$; testele ESR detectează fiecare specificare greșită	Fig. 3	O bancă ar putea raporta ES pentru un nivel mai blând și ar trece testele mai vechi
Inovații Normale: respinse pentru 80%–96% dintre acțiuni în fiecare combinație fereastră–reestimare	Tabelul 3	Cozile Normale subestimează ES pentru majoritatea acțiunilor
Student-t: GARCH 0,12 cu fereastră de 250 de zile și reestimare anuală; cel mult 0,01 cu 1000 de zile sau mai mult, pentru GARCH și GJR-GARCH	Tabelul 3	Pentru aceste 200 de acțiuni și 2010–2019: cozile groase și ferestrele de cel puțin 1000 de zile dau ponderi de respingere de cel mult 0,01; termenul de levier nu le reduce

Tabelul 3: cozi și reestimare




- Ponderea acțiunilor cu prognoze ES 2,5% respinse de testul unilateral ESR cu termen liber la 5%, în eșantionul celor mai mari 200 de acțiuni din S&P 500; ianuarie 2010 – august 2019; linie continuă: reestimare la 5 zile, întreruptă: la 250 de zile. Sursa: [Bayer & Dimitriadis \(2022\)](#), Tabelul 3

Tabelul 3: interpretare

- ▣ Inovații Normale: 0,80–0,96 dintre acțiuni respinse în toate cele 50 de combinații fereastră–reestimare (GARCH și GJR-GARCH): cozile Normale subestimează ES oricare ar fi fereastra sau reestimarea
- ▣ Inovații Student-t: lungimea ferestrei contează cel mai mult
 - ▶ 250 de zile: 0,00–0,12 (GARCH-t) și 0,00–0,04 (GJR-GARCH-t); 500 de zile sau mai mult: cel mult 0,02 (GARCH-t) și 0,01 (GJR-GARCH-t)
 - ▶ Frecvența reestimării contează doar la ferestre scurte: GARCH-t pe 250 de zile, 0,00 cu reestimare săptămânală și 0,12 cu reestimare anuală; de la 1 000 de zile în sus, cel mult 0,01 pentru orice frecvență
- ▣ Termenul de levier: de la 500 de zile în sus, GJR-GARCH-t și GARCH-t diferă cu cel mult 0,01; cu inovații Normale, GJR-GARCH este respins mai des (0,92 față de 0,81, 2 000 de zile, reestimare săptămânală)
- ▣ Concluzia autorilor, pentru aceste acțiuni și această perioadă: cozile groase și o fereastră de peste 1 000 de zile (circa patru ani) dau ponderi de respingere de cel mult 0,01; frecvența reestimării nu este un factor esențial

Tabelul 3 replicat pe datele cursului



- Ponderea acțiunilor respinse de testul unilateral ESR cu termen liber la 5%, GARCH(1,1) cu inovații Normale sau Student-t; linie continuă: 11 acțiuni din datele cursului (calculul nostru), întreruptă: 200 de acțiuni (Bayer & Dimitriadis (2022), Tabelul 3)

Replicare: metodă și interpretare

- Metodă: aplicarea grilei și a testului din studiu la datele cursului
 - ▶ 11 acțiuni mari din S&P 500 din data/market, cu prețuri din 2002 (necesare pentru fereastra de 2000 de zile): Apple, Microsoft, Amazon, NVIDIA, Cisco, JPMorgan Chase, Bank of America, Citigroup, Wells Fargo, Goldman Sachs, Morgan Stanley
 - ▶ Randamente logaritmice zilnice, ianuarie 2010 – august 2019 (2 432 de zile); cele 25 de combinații fereastră–reestimare din Tabelul 3; GARCH(1,1) cu medie constantă (lucrarea nu precizează ecuația mediei); ESR cu termen liber, unilateral, la 5%, calculat cu pachetul autorilor, [esback](#)
- Inovații Normale: 0,82–1,00 dintre acțiuni respinse în toate cele 25 de combinații (Tabelul 3, GARCH-N: 0,80–0,96)
- Inovații Student-t: 0,09–0,55 cu fereastra de 250 de zile (Tabelul 3: 0,00–0,12), cel mult 0,09 cu 500 de zile (Tabelul 3: 0,02) și 0,00 cu 1000 de zile sau mai mult (Tabelul 3: 0,01)
- Rezultatul central se replică: cozile Normale eşuează, cozile Student-t trec de îndată ce fereastra este lungă; la 250 de zile, ponderile noastre pentru Student-t sunt mai mari decât în Tabelul 3; cu 11 acțiuni, o singură acțiune schimbă ponderea cu 0,09, iar ecuația mediei nu este precizată în lucrare

Replicare, limite și extinderi

- Replicarea cu datele cursului
 - ▶ Aplicați ESR strict (bilateral) și ESR cu termen liber (unilateral) prognozelor ES 2,5% ale celor șase modele din acest curs: S&P 500, BET, Bitcoin (data/market) și EUR/RON (BNR); comparați deciziile cu Z_2 și McNeil–Frey (Secțiunea 4)
 - ▶ Extindeți replicarea Tabelului 3: GJR-GARCH, mai multe acțiuni și perioada de după august 2019: se păstrează ordinea modelelor în 2020 și 2022?
- Limitele precizate de autori
 - ▶ ESR strict și ESR cu termen liber: ecuația cuantilei este corectă doar dacă VaR este o funcție afină de ES (de exemplu proporțională, ca în modelele de scală pură), altfel este greșit specificată (Secțiunea 1.2); ESR auxiliar și ESR strict sunt doar bilaterale (Secțiunea 1.3)
 - ▶ Estimarea robustă a covarianței presupune un model de locație și scală pentru distribuția condiționată (Secțiunea 1.5); cu estimatorul clasic al covarianței, testul respinge prea des în eșantioane mici (Secțiunea 2.1)
- Extensie deschisă: o fereastră de supraveghere de un an
 - ▶ La $T = 250$, ESR cu termen liber bilateral are mărimea 0,04 la 5% nominal cu covarianța robustă și 0,15 cu cea clasică (Tabelul 1, EGARCH-t); mărimea unilaterală este raportată doar pentru $T = 2500$ (0,02, Tabelul 2, GARCH(1,1)-t)
 - ▶ Întrebare: care este mărimea testului unilateral pe un an și poate bootstrap-ul statisticii t să o mențină la 5%, păstrând puterea din Fig. 4?
- Punct de plecare pentru proiect: Seminarul 8, Partea C3

O întrebare deschisă: acoperirea condiționată în crize

- Garanțiile VaR fără ipoteze de distribuție sunt **marginale**: conformal split cere schimbabilitate, ACI controlează doar media pe termen lung
 - ▶ Barber, Candès, Ramdas & Tibshirani (2023): fără schimbabilitate, pierderea de acoperire este mărginită de distanțe în variație totală între vectorul scorurilor și versiunile lui cu scorul de test schimbat; cât de mari sunt ele sub grupările de volatilitate este o întrebare empirică
 - ▶ Gibbs, Cherian & Candès (2025): acoperirea exactă condiționată pe o clasă de deplasări fixată dinainte este realizabilă; ce clasă surprinde o criză financiară rămâne deschis
- Întrebarea formală, cu un indicator de criză $C_t \in \mathcal{F}_{t-1}$ cunoscut ex ante
 - ▶ $H_0: P(L_t > \text{VaR}_t \mid C_t = 1) = \alpha$ față de $H_1: P(L_t > \text{VaR}_t \mid C_t = 1) \neq \alpha$
 - ▶ Infirmată de o rată de depășire în criză în afara regiunii de acceptare Binomiale, după corecția pentru dependența dintre depășiri și pentru testarea multiplă
- Miza: capitalul este necesar exact în zilele în care garanțiile marginale spun cel mai puțin

Etapele cercetării, pas cu pas (1/2)

- Instrumente: un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau GitHub Copilot); căutarea literaturii: [Semantic Scholar](#), [Elicit](#), [Google Scholar](#)
- 1. **Literatura**: inventarul garanțiilor, apoi verificarea fiecărui DOI pe [Crossref](#) (titlul trebuie să coincidă)
 - ▶ Enumeră lucrările evaluate de specialiști înainte de publicare, din 2019 încoace despre predicția conformală sub dependență serială; pentru fiecare dă DOI-ul, garanția exactă (marginală, condiționată sau pe termen lung) și ipotezele ei.
- 2. **Ipoteze concurente**, fiecare cu o implicație testabilă
 - ▶ Dă trei explicații rivale pentru care VaR conformal split este depășit prea des după perioade agitate (scală întârziată, formă a cozii schimbătoare, artefact al selecției regimului) și ce prezice fiecare pentru ratele de depășire pe regimuri.
- 3. **Date și cod**: replicăm o cifră cunoscută înainte de a schimba ceva
 - ▶ Scrie cod Python care citește data/market/GSPC.INDX.csv, construiește VaR 5% conformal split din acest capitol, cu intrări strict întârziate, și afișează rata de depășire în criză. Ținta: 7,29%

Etapele cercetării, pas cu pas (2/2)

- 4. **Robustețe**, scrisă înainte de a vedea rezultatele
 - ▶ Redactează un plan de robustețe pre-înregistrat: α în {1%, 5%}, mărimea calibrării în {125, 250, 500}, pragul de criză la percentilele 80, 90 și 95, două subeșantioane, corecție Holm pe piețe.
 - ▶ Placebo: etichete de criză aleatoare, cu aceeași frecvență, dau rate de depășire în criză centrate pe rata din întreg eșantionul; distribuția lor pe permutări este banda de referință
- 5. **Critica**: cerem asistentului să atace rezultatul
 - ▶ Joacă rolul unui recenzent ostil: enumeră cele mai puternice motive pentru care acest efect de criză este un artefact (depășiri grupate, regim definit din aceleași date, ferestre suprapuse) și testul care ar tranșa fiecare motiv.
- 6. **Raportul**: toate specificațiile încercate, mărimile efectelor cu intervale, codul și jurnalul utilizării AI

Ce verifică cercetătorul

- ▣ **Informație din viitor:** scala $\hat{\sigma}_t$, parametrii GARCH și indicatorul de criză pot folosi doar $\mathcal{F}_{t-1}$; test: recalculăm cu fiecare intrare întârziată încă o zi
- ▣ **Depășiri dependente:** depășirile grupate fac valorile p Binomiale prea mici; test: testele Christoffersen și de durată sau un bootstrap pe blocuri al șirului depășirilor
- ▣ **Puterea:** S&P 500 are 613 zile de criză, adică 6,1 depășiri așteptate ale VaR 1%; o rată reală de 2% este detectată cu probabilitatea 57%; calculăm puterea înainte de testare
- ▣ **Testarea multiplă:** 4 piețe $\times$ 2 niveluri $\times$ 3 metode = 24 de teste; controlăm FWER (Holm) sau FDR (BH)
- ▣ **Teoreme denaturate și referințe inventate:** de exemplu, „ACI garantează acoperirea condiționată”; verificăm teorema din [Gibbs & Candès \(2021\)](#) și fiecare DOI
- ▣ **Cuantile decalate cu o poziție:** indicele $k = \lceil (n+1)(1-\alpha) \rceil$ nu este implicit în `np.quantile`; test pe date i.i.d. simulate

Mini-caz: repară o scală GARCH acoperirea în criză?

- Replicare: VaR 5% conformal split din acest capitol este depășit în 7,29% dintre zilele de criză S&P 500 (Secțiunea 7)
- O propunere tipică a asistentului: scorul $s_t = (L_t + \mu_t)/\sigma_t$ cu prognozele GARCH-t; H_0 : rata de depășire în criză = 5%, test Binomial exact, Holm pe piețe

Piața	Zile de criză	Conformal split	p Holm	Scală GARCH	p Holm
S&P 500	613	7,01%	0,052	2,77%	0,037
BET	506	8,10%	0,009	3,95%	0,309
Bitcoin	150	8,00%	0,092	1,33%	0,111
EUR/RON	245	11,43%	<0,001	2,45%	0,153

- Rezultat: scala GARCH coboară toate ratele din criză sub 5%; Holm respinge doar pe S&P 500 (2,77%); în rest avem nerespingere, nu o dovadă de acoperire: valorile p Binomiale ignoră depășirile grupate, iar eșantioanele de criză sunt mici; ipoteza următoare: scala GARCH exagerează după șocuri
- Eșantion comun: 4 709 zile S&P 500 după 250 de zile de calibrare; cod: `Quantlets/Ch_08/ai_discovery_case.py`

Rândul vostru: un punct de plecare pentru proiect

- Întrebarea: poate o prognoză VaR 1% și ES 2,5% fără ipoteze de distribuție să atingă acoperirea condiționată de criză pe toate cele patru piețe, cu un test pre-înregistrat?
- Replicați mai întâi: ratele de depășire în criză ale VaR 5% conformal split (S&P 500 7,29%, EUR/RON 11,43%) și ponderea VaR 1% infinit la ACI (13,4%)
- Livrabile
 - ▶ O pre-înregistrare (ipoteze, teste, corecții, putere) datată înainte de prima rulare
 - ▶ O metodă candidată, de exemplu [Gibbs, Cherian & Candès \(2025\)](#) cu regimul de volatilitate drept clasă de condiționare; VaR: testele Kupiec, Christoffersen și de durată pe regimuri
 - ▶ ES: acoperirea cuantilei nu determină media din coadă; precizați cum se obține ES și testați-l cu testul ES prin regresie ([Bayer & Dimitriadis \(2022\)](#)) sau cu Z_2 , dacă metoda produce o distribuție prognozată
 - ▶ Codul, un raport de două pagini cu toate specificațiile încercate și o critică, în stil de recenzent, a propriului rezultat
- Consemnați fiecare prompt care a influențat o decizie în `AI_USE.md` și fiecare eroare a asistentului în `AI_ERRORS.md`: github.com/danpele/MFM/tree/main/project

Tabloul de bord pe patru piețe

- Fiecare celulă: rata de depășire a VaR 1% în % / valoarea p pentru Z_2 / valoarea p MCS (FZ0)

Model	S&P 500	BET	Bitcoin	EUR/RON
HS	1,67 / <0,001 / <0,001	1,17 / 0,134 / <0,001	0,77 / 0,863 / 0,87	0,51 / 1,000 / <0,001
Normal	2,70 / <0,001 / <0,001	1,90 / <0,001 / <0,001	1,74 / 0,001 / 0,63	1,06 / 0,973 / <0,001
Student-t	2,00 / 0,002 / <0,001	1,58 / 0,003 / <0,001	0,71 / 0,625 / 0,30	0,85 / 0,920 / <0,001
GARCH-t	1,77 / <0,001 / 0,01	1,46 / <0,001 / 0,09	1,12 / 0,050 / 0,84	1,17 / 0,630 / 0,90
FHS	1,23 / 0,172 / 1,00	1,20 / 0,188 / 0,90	0,92 / 0,345 / 0,87	0,85 / 0,968 / 0,99
GARCH-EVT	1,13 / 0,090 / 0,21	0,99 / 0,210 / 1,00	0,95 / 0,581 / 1,00	0,78 / 0,976 / 1,00

- Doar FHS și GARCH-EVT trec testul Z_2 la 5% și rămân în MCS de 90% pe toate cele patru piețe

Portofoliul de tranzacționare al unei bănci românești



Banca Națională a României, București

Foto: Britchi Mirela (2018); CC BY-SA 4.0; Wikimedia

[Commons](#)

- Expuneri tipice: acțiuni românești, prin indicele BET, și cursul EUR/RON
- BET: HS și distribuția Normală eșuează la testele de durată; GARCH-EVT trece toate testele VaR și ES
- EUR/RON: perioade lungi de calm și salturi rare; HS este depășit doar în 0,51% dintre zile, iar toate modelele necondiționate eșuează la testul de independență
- Seminarul 8, Partea C: ce model ați certifica pentru acest portofoliu?

Lecturi suplimentare

- ▣ Fissler & Ziegel (2016): VaR și ES sunt elicitable împreună, baza funcției de pierdere FZ0
- ▣ Nolde & Ziegel (2017): backtesturi comparative și semaforul pentru VaR și ES
- ▣ Acerbi & Szekely (2014): trei backtesturi ES fără ipoteze de model, inclusiv Z_2
- ▣ Prognoze VaR și ES bazate pe entropie: Pele, Lazar & Dufour (2017), Pele & Mazurencu-Marinescu-Pele (2019), Pele, Lazar & Mazurencu-Marinescu-Pele (2019); când pot fi deosebite două prognoze ES: Pele & Mazurencu-Marinescu-Pele (2026)
- ▣ Manuale: Franke, Härdle & Hafner (2019) (capitolele despre VaR și backtesting) și Härdle, Chen & Overbeck (2017)

Studiu suplimentar pe Quantinar

Curs avansat pe quantinar.com

- Machine learning in Financial Risk

Cod și date

- Toate graficele și testele: github.com/danpele/MFM/tree/main/Quantlets/Ch_08
- Serii: S&P 500, BET, Bitcoin (folderul data/market al repository-ului); EUR/RON: cursul de referință BNR

Idei principale

- ▣ Testați numărul și momentul depășirilor (acoperire, independență, durate, DQ) și cunoașteți mărimea și puterea testelor la T -ul vostru
- ▣ Reglementatorii folosesc numărări simple (semaforul), acum combinate cu capital bazat pe ES, conform FRTB
- ▣ ES poate fi testat (Z_2 , reziduuri, depășiri cumulate), dar prognozele ES nu pot fi ierarhizate separat: folosiți FZ0 pentru (VaR, ES)
- ▣ Ierarhizați modelele cu teste DM/Giacomini–White și MCS, verificați robustețea cu diagrame Murphy; acceptați că unele modele nu pot fi separate
- ▣ Garanțiile conformale sunt marginale: nu vă protejează în criză
- ▣ Empiric, un filtru GARCH plus o coadă flexibilă (FHS, EVT) câștigă pe toate cele patru piețe

Bibliografie (1/5)

- ▣ Acerbi, C., Szekely, B. (2014). [Backtesting expected shortfall](#). MSCI Inc., December 2014.
- ▣ Angelopoulos, A.N., Bates, S. (2021). [A gentle introduction to conformal prediction and distribution-free uncertainty quantification](#). [arXiv:2107.07511](#).
- ▣ Barber, R.F., Candès, E.J., Ramdas, A., Tibshirani, R.J. (2023). [Conformal prediction beyond exchangeability](#). *Annals of Statistics*, 51(2).
- ▣ Basel Committee on Banking Supervision (1996). [Supervisory framework for the use of "backtesting" in conjunction with the internal models approach to market risk capital requirements](#). Bank for International Settlements.
- ▣ Basel Committee on Banking Supervision (2019). [Minimum capital requirements for market risk](#) (rev. February 2019). Bank for International Settlements.
- ▣ Bayer, S., Dimitriadis, T. (2022). [Regression-based expected shortfall backtesting](#). *Journal of Financial Econometrics*, 20(3), 437–471. Earlier preprint: [arXiv:1801.04112v2](#).
- ▣ Christoffersen, P.F. (1998). [Evaluating interval forecasts](#). *International Economic Review*, 39(4), 841–862.
- ▣ Christoffersen, P., Pelletier, D. (2004). [Backtesting value-at-risk: a duration-based approach](#). *Journal of Financial Econometrics*, 2(1), 84–108.

Bibliografie (2/5)

- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Du, Z., Escanciano, J.C. (2017). Backtesting expected shortfall: accounting for tail risk. *Management Science*, 63(4), 940–958.
- ▣ Ehm, W., Gneiting, T., Jordan, A., Krüger, F. (2016). Of quantiles and expectiles: consistent scoring functions, Choquet representations and forecast rankings. *Journal of the Royal Statistical Society, Series B*, 78(3), 505–562.
- ▣ Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- ▣ Escanciano, J.C., Olmo, J. (2010). Backtesting parametric value-at-risk with estimation risk. *Journal of Business & Economic Statistics*, 28(1), 36–51.
- ▣ Fissler, T., Ziegel, J.F. (2016). Higher order elicibility and Osband's principle. *Annals of Statistics*, 44(4).
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.

Bibliografie (3/5)

- ▣ Gibbs, I., Candès, E. (2021). [Adaptive conformal inference under distribution shift](#). *Advances in Neural Information Processing Systems*, 34; arXiv:2106.00170.
- ▣ Gibbs, I., Cherian, J.J., Candès, E.J. (2025). [Conformal prediction with conditional guarantees](#). *Journal of the Royal Statistical Society, Series B*, 87(4), 1100–1126.
- ▣ Gneiting, T. (2011). [Making and evaluating point forecasts](#). *Journal of the American Statistical Association*, 106(494), 746–762.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). [The model confidence set](#). *Econometrica*, 79(2), 453–497.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (eds.) (2017). [Applied Quantitative Finance](#), 3rd ed. Springer.
- ▣ Hoga, Y., Demetrescu, M. (2023). [Monitoring value-at-risk and expected shortfall forecasts](#). *Management Science*, 69(5), 2954–2971.
- ▣ Kratz, M., Lok, Y.H., McNeil, A.J. (2018). [Multinomial VaR backtests: a simple implicit approach to backtesting expected shortfall](#). *Journal of Banking & Finance*, 88, 393–407.
- ▣ Kupiec, P.H. (1995). [Techniques for verifying the accuracy of risk measurement models](#). *Journal of Derivatives*, 3(2), 73–84.

Bibliografie (4/5)

- ▣ Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R.J., Wasserman, L. (2018). Distribution-free predictive inference for regression. *Journal of the American Statistical Association*, 113(523), 1094–1111.
- ▣ McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- ▣ Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- ▣ Nolde, N., Ziegel, J.F. (2017). Elicitability and backtesting: perspectives for banking regulation. *Annals of Applied Statistics*, 11(4).
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). Modeling expected shortfall using tail entropy. *Entropy*, 21(12), 1204.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). Using high-frequency entropy to forecast Bitcoin's daily value at risk. *Entropy*, 21(2), 102.

Bibliografie (5/5)

- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). [Finite-sample precision limits for expected shortfall forecast comparisons](#). *Mathematics*, 14(13), 2316.
- ▣ Zaffran, M., Féron, O., Goude, Y., Josse, J., Dieuleveut, A. (2022). [Adaptive conformal predictions for time series](#). *Proceedings of the 39th International Conference on Machine Learning*; arXiv:2202.07282.