



Modelarea piețelor financiare

Capitolul 8: Backtesting și evaluarea prognozelor de risc



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ACI: Adaptive Conformal Inference (inferență conformală adaptivă)
- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- BCBS: Basel Committee on Banking Supervision (Comitetul de la Basel pentru Supraveghere Bancară)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- BIS: Bank for International Settlements (Banca Reglementelor Internaționale)
- BNR: Banca Națională a României
- COVID-19: COroNaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DGP: Data-Generating Process (procesul generator al datelor)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- DQ: Dynamic Quantile (test) (testul cuantilei dinamice)
- EGARCH: Exponential GARCH (GARCH exponențial)
- ES: Expected Shortfall (pierdere așteptată în coadă)
- ESR: Expected Shortfall Regression (backtest) (testul ES prin regresie)
- EVT: Extreme Value Theory (teoria valorilor extreme)
- FDR: False Discovery Rate (rata descoperirilor false)
- FHS: Filtered Historical Simulation (simulare istorică filtrată)
- FRTB: Fundamental Review of the Trading Book (revizuirea fundamentală a portofoliului de tranzacționare)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- FZ: Fissler–Ziegel (family of scoring functions for VaR and ES) (familia Fissler–Ziegel de funcții de scor pentru VaR și ES)
- FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- GARCH: Generalised Autoregressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-EVT: GARCH filter combined with Extreme Value Theory for the tail (filtru GARCH combinat cu teoria valorilor extreme pentru coadă)
- GAS: Generalised Autoregressive Score (model) (model cu scor autoregresiv generalizat)
- GJR-GARCH: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)

Acronime folosite în acest material (2/2)

- ▣ GPD: Generalised Pareto Distribution (distribuția Pareto generalizată)
- ▣ HS: Historical Simulation (simulare istorică)
- ▣ IMA: Internal Models Approach (abordarea bazată pe modele interne)
- ▣ LLM: Large Language Model (model lingvistic mare)
- ▣ LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- ▣ MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- ▣ NVIDIA: NVIDIA Corporation (company name, US chip designer)
(NVIDIA Corporation (nume de companie, proiectant american de cipuri))
- ▣ PIT: Probability Integral Transform (transformarea integrală de probabilitate)
- ▣ POF: Proportion Of Failures (test) (testul proporției de depășiri)
- ▣ POT: Peaks Over Threshold (metoda depășirilor de prag)
- ▣ QLKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)

Structura capitolului și rezultatele învățării

Trei întrebări

- ▣ **Calibrare:** este o prognoză VaR sau ES corectă, zi de zi, și poate un backtest să o arate?
- ▣ **Comparație:** care dintre mai multe prognoze este mai bună și este diferența semnificativă?
- ▣ **Decizie:** ce putem concluziona când coada conține doar câteva zile pe an?
- ▣ Partea I: cadrul, testele VaR, mărimea și puterea lor, reglementarea, primele teste ES; Partea a II-a: dovezile ES, scorurile, backtesting-ul comparativ, VaR conformal, studiul de caz, mini studiul de caz AI
- ▣ Detaliile tehnice sînt în [▶ Anexa](#) de la final

La sfîrșitul capitolului veți putea

- ▣ testa numărul și momentul depășirilor VaR și preciza mărimea și puterea fiecărui test pentru T -ul de care dispuneți
- ▣ testa ES cu reziduuri, cu Z_2 prin simulare și cu statistici bazate pe PIT
- ▣ ierarhiza prognozele (VaR, ES) cu un scor consistent, teste DM și MCS
- ▣ aprecia ce garantează și ce nu garantează un VaR fără ipoteze de distribuție (conformal)

Cadrul și notațiile

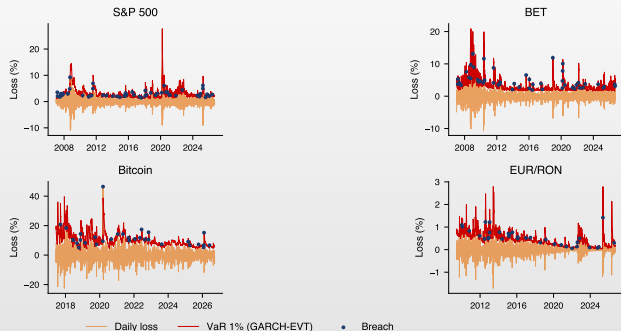
- ▣ **Backtesting**: compararea prognozelor de risc făcute cu informația $\mathcal{F}_{t-1}$ cu rezultatele care au urmat
- ▣ Randamentul logaritmic zilnic $X_t = r_t = \ln(P_t/P_{t-1})$; **pierdere** zilnică $L_t = -r_t$ (număr pozitiv = bani pierduți)
- ▣ **VaR** (Value-at-Risk, valoarea expusă la risc) și **ES** la probabilitatea de coadă α ([Capitolul 7](#))
 - ▶ $\text{VaR}_\alpha(X) = -\inf\{x : P(X \leq x) > \alpha\} = -q_\alpha(X)$; $\text{ES}_\alpha(X) = -\frac{1}{\alpha} \int_0^\alpha q_u(X) du = E[L_t \mid L_t > \text{VaR}_\alpha]$
(cazul continuu)
 - ▶ Nivelurile sînt probabilități de coadă: VaR 1% ($\alpha = 0,01$), VaR 2,5% și ES 2,5% ($\alpha = 0,025$); Basel folosea VaR 1% pe 10 zile, FRTB folosește ES 2,5%, backtesting-ul folosește prognoze la o zi
- ▣ O **depășire** (excepție) are loc cînd pierderea depășește prognoza: $I_t = 1\{L_t > \text{VaR}_t\}$, cu rata țintă α
- ▣ **Calibrarea condiționată** ideală: $P(I_t = 1 \mid \mathcal{F}_{t-1}) = \alpha$ pentru orice t , deci I_t sînt Bernoulli(α) i.i.d. ([Christoffersen \(1998\)](#))
 - ▶ **Acoperire necondiționată**: aproximativ αT depășiri în T zile; **independență**: depășirile nu se grupează

Şase modele concurente şi experimentul

Model	VaR şi ES la o zi din
HS	cuantila empirică de ordin $1 - \alpha$ a ultimelor 1000 de pierderi
Normal	distribuţia Normală cu media şi abaterea standard din fereastră
Student-t	o distribuţie Student-t estimată pe fereastră (locaţie, scală, ν)
GARCH-t	$\sigma_t^2 = \omega + a\varepsilon_{t-1}^2 + b\sigma_{t-1}^2$, şocuri Student-t standardizate
FHS	volatilitatea GARCH $\times$ cuantilele empirice ale lui $z_t = \varepsilon_t / \sigma_t$
GARCH-EVT	volatilitatea GARCH $\times$ o coadă GPD estimată prin POT pe cele mai mari 10% pierderi standardizate (McNeil & Frey (2000))

- Patru serii, fiecare pe propriul calendar
 - ▶ S&P 500 şi BET (indicele Bursei de Valori Bucureşti): închideri
 - ▶ Bitcoin (se tranzacţionează zilnic); EUR/RON: cursul de referinţă BNR
- Fereastră mobilă de 1000 de observaţii; fiecare prognoză foloseşte doar datele pînă în ziua precedentă
- Parametrii GARCH, Student-t şi EVT se reestimează la fiecare 20 de zile; volatilitatea se actualizează zilnic
- Zile de evaluare T , pînă la 18.09.2026
 - ▶ S&P 500 4 959 şi BET 4 937 (din 2007), EUR/RON 4 352 (din 2009), Bitcoin 3 384 (din 2017)

Patru piețe, un model de risc




- Portocaliu: pierderile zilnice; roșu: VaR 1% prognozat de GARCH-EVT; puncte albastre: depășiri ($L_t > VaR_t$)
- VaR urmează volatilitatea: se dublează sau se triplează în 2008, martie 2020 și la crahul crypto din 2022
- Rate de depășire: S&P 500 1,13%, BET 0,99%, Bitcoin 0,95%, EUR/RON 0,78%
- EUR/RON are o scară mult mai mică: un curs administrat, perioade lungi de calm, salturi rare
- Întrebarea capitolului: este suficientă o rată apropiată de 1% pentru a spune că un model este bun?

Ce poate și ce nu poate identifica un backtest


- Fiecare backtest verifică o consecință a calibrării condiționate: testul Kupiec verifică rata, testul Christoffersen memoria de ordinul întâi, testele de durată distanțele dintre depășiri, iar testul DQ predictibilitatea pe baza regresorilor aleși
- H_0 este o ipoteză **comună** despre întreaga procedură de prognoză
 - ▶ distribuția, dinamica volatilității, parametrii estimați, lungimea ferestrei și regula de reestimare
 - ▶ O respingere nu spune care componentă a eșuat
- Un singur rezultat pe zi: dovezile se acumulează doar pe multe zile, iar limitele χ^2 din manuale tratează VaR_t ca fiind cunoscut (riscul de estimare: ultimul slide al secțiunii „Backtesting pentru VaR: acoperire și independență”)
- Nerespingerea nu înseamnă validare: este informativă doar dacă testul are putere împotriva alternativelor relevante, la T disponibil

S&P 500: două prognoze VaR, 2007–2026



- VaR 1%: HS cu turcoaz, GARCH-t cu albastru; portocaliu: pierderile zilnice; marcate: depășirile fiecărui model
- HS este o funcție în trepte: sare doar când zile extreme intră sau ies din fereastra de 1000 de zile; GARCH-t crește din ziua următoare creșterii volatilității
- Aproape același număr: HS 83, GARCH-t 88 depășiri în 4 959 de zile
- Numere apropiate pot ascunde momente diferite: depășirile HS vin în rafale (2008, 2020), deci trebuie testat și **cînd** apar depășirile

Martie 2020: testul de stres pe care nu l-a planificat nimeni




- S&P 500, februarie–iunie 2020: pierderile zilnice (bare) și VaR 1% al celor șase modele
- Cea mai mare pierdere: 12,77% pe 16.03.2020; un VaR 1% corect are 1,04 depășiri așteptate în aceste 104 zile
- Depășiri observate
 - ▶ necondiționate: HS 12, Normal 17, Student-t 17
 - ▶ condiționate: GARCH-t 3, FHS 2, GARCH-EVT 2
- În acest episod, o coadă groasă fără scală mobilă (Student-t) nu a ajutat: condiționarea pe volatilitatea curentă a contat mai mult decât forma cozii

 MFM_ch8_var_forecasts

Kupiec (1995): testul POF


- ▣ Date: $x = \sum_t I_t$ depășiri în T zile; rata estimată de depășire $\hat{\pi} = x/T$
- ▣ H_0 : $\pi = \alpha$ (acoperire necondiționată corectă), față de H_1 : $\pi \neq \alpha$
- ▣ Statistica raportului de verosimilitate (Kupiec (1995))
 - ▶ $LR_{uc} = -2 \ln \frac{(1-\alpha)^{T-x} \alpha^x}{(1-\hat{\pi})^{T-x} \hat{\pi}^x} \xrightarrow{d} \chi_1^2$
- ▣ Respingem la 5% dacă $LR_{uc} > 3,84$; bilateral: și prea puține depășiri înseamnă eșec; pentru T mic folosim distribuția Binomială(T, α) exactă a lui x
- ▣ Exemplu lucrat, S&P 500, GARCH-t, 2008: $x = 8$ în $T = 253$ (așteptat 2,53): $LR_{uc} = 7,60$, $p = 0,0058$; p Binomial exact = $2P(X \geq 8) = 0,009$

Cîte depășiri sînt acceptabile?



- LR_{uc} în funcție de numărul de depășiri x , un an (stînga) și patru ani (dreapta) de VaR 1%
- $T = 250$: testul acceptă x între 1 și 6;
 $T = 1000$: între 5 și 16
- Chiar și $x = 0$ este respins pe un an ($LR_{uc} = -500 \ln 0,99 = 5,03$): un VaR niciodată depășit este prea conservator
- Un an conține aproximativ 2,5 zile informative pentru VaR 1%: folosim eșantioane lungi, mai multe niveluri ($\alpha = 1\%$ și $2,5\%$) și mai multe teste

Puterea testului POF




- Probabilitatea de respingere la 5% în funcție de probabilitatea reală de depășire; linia continuă: Binomial exact; linia întreruptă: $\chi^2_1(\lambda)$ local
- Alternative locale $\pi_T = \alpha + h/\sqrt{T}$:

$$LR_{uc} = \frac{T(\hat{\pi} - \alpha)^2}{\alpha(1-\alpha)} + o_p(1) \xrightarrow{d} \chi^2_1(\lambda),$$

$$\lambda = \frac{T(\pi - \alpha)^2}{\alpha(1-\alpha)}$$
- $T = 250$, $\pi = 2\%$: $\lambda = 2,53$; puterea locală 36%, puterea exactă 24%: o rată de depășire dublă trece testul în trei ani din patru
- Regula „respingem dacă $LR_{uc} > 3,84$ ” are mărimea efectivă 9,5% la $T = 250$ (doar $P(x = 0) = 8,1\%$): mărimea regulii LR calibrate pe χ^2 , nu a unui test exact de 5%
- Puterea de 50% cere $\pi \approx 2,7\%$ la $T = 250$ și $\pi \approx 1,7\%$ la $T = 1000$

Ratele de depășire pe modele și piețe




- Ponderea zilelor cu $L_t > VaR_t$ pentru VaR 1%; distribuția Normală eșuează, cu excepția EUR/RON: S&P 500 2,70%, BET 1,90%, Bitcoin 1,74%
- Aceeași volatilitate GARCH-t, altă coadă: GARCH-t 1,77% și 1,46% față de FHS 1,23% și 1,20% (S&P 500, BET): un indiciu împotriva cozii t simetrice pe partea pierderilor
- HS este prea conservator pe EUR/RON (0,51%): o criză veche din fereastră îi menține VaR ridicat

Christoffersen (1998): testarea independenței

- ▣ Modelăm I_t ca lanț Markov de ordinul întâi, cu $\pi_{ij} = P(I_t = j \mid I_{t-1} = i)$
- ▣ Numărăm tranzițiile n_{ij} (din starea i ieri în starea j azi); $\hat{\pi}_{01} = \frac{n_{01}}{n_{00} + n_{01}}$, $\hat{\pi}_{11} = \frac{n_{11}}{n_{10} + n_{11}}$
- ▣ H_0 : $\pi_{01} = \pi_{11} = \pi$ (fără memorie), cu $\hat{\pi} = (n_{01} + n_{11}) / \sum n_{ij}$
- ▣ Statistica
 - ▶ $LR_{ind} = -2 \ln \frac{(1 - \hat{\pi})^{n_{00} + n_{10}} \hat{\pi}^{n_{01} + n_{11}}}{(1 - \hat{\pi}_{01})^{n_{00}} \hat{\pi}_{01}^{n_{01}} (1 - \hat{\pi}_{11})^{n_{10}} \hat{\pi}_{11}^{n_{11}}} \xrightarrow{d} \chi_1^2$
- ▣ Acoperirea condiționată: $LR_{cc} = LR_{uc} + LR_{ind} \xrightarrow{d} \chi_2^2$ testează ambele proprietăți simultan

Cînd apar depășirile?




- Fiecare linie: o depășire a VaR 1% pe S&P 500; HS, Normal, Student-t: rafale în 2008, 2015–2016, 2018, 2020, 2022; modelele filtrate: distribuite aproape uniform
- Contraexemplu, doar HS în 2007–2010: $n_{00} = 928$, $n_{01} = 38$, $n_{10} = 38$, $n_{11} = 3$; $\hat{\pi}_{11} = 0,0732$ față de $\hat{\pi}_{01} = 0,0393$, totuși $LR_{ind} = 0,95$, $p = 0,33$: $\hat{\pi}_{11}$ se sprijină pe 3 perechi
- Întreg eșantionul: independența respinsă pentru HS ($p < 0,001$), Normal ($p < 0,001$) și, la limită, FHS ($p = 0,046$), nu și pentru GARCH-t ($p = 0,095$): o nerespingere pe un subeșantion nu este un verdict pe întreg eșantionul

Teste bazate pe durate

- ▣ Durata D_i : numărul de zile dintre depășirea $i - 1$ și depășirea i
- ▣ Pentru un VaR corect, depășirile nu au memorie: D_i urmează distribuția geometrică, cu media $1/\alpha$ (100 de zile pentru $\alpha = 1\%$)
- ▣ Christoffersen & Pelletier (2004): aproximăm duratele discrete printr-un model Weibull continuu
 - ▶ $f(D; a, b) = a^b b D^{b-1} e^{-(aD)^b}$; $b = 1$ este cazul exponențial (fără memorie)
 - ▶ $b < 1$: duratele scurte sînt prea frecvente, adică depășirile se grupează
- ▣ H_0 : $b = 1$ cu a liber, un test al raportului de verosimilitate (χ_1^2) pentru lipsa memoriei, nu pentru media $1/\alpha$ (acoperirea rămîne în seama testului Kupiec); prima și ultima durată sînt cenzurate
- ▣ Folosește întreaga structură a distanțelor, nu doar zilele consecutive: putere mai mare împotriva grupării

Cît timp trece între depășiri?



- Ponderea duratelor mai lungi decît d (scală logaritmică); linia punctată: fără memorie, cu $\alpha = 1\%$
- HS: $b = 0,52$, mediana 7 zile, 44% dintre durate au cel mult 5 zile; $p < 0,001$
- Normal: $b = 0,56$; GARCH-t: $b = 0,94$ (mediana 48 de zile, $p = 0,479$); GARCH-EVT: $b = 0,88$ ($p = 0,240$)
- Coada lungă a duratelor HS: ani fără depășiri după ce o criză lasă un VaR ridicat în fereastră

Backtesting prin regresie: testul DQ

- ▣ Sub acoperirea condiționată corectă, $\text{Hit}_t = I_t - \alpha$ este o diferență de martingală: $E[\text{Hit}_t | \mathcal{F}_{t-1}] = 0$, $\text{Var}(\text{Hit}_t | \mathcal{F}_{t-1}) = \alpha(1 - \alpha)$
- ▣ Deci nicio variabilă măsurabilă în $\mathcal{F}_{t-1}$ nu îl poate prezice: regresăm $\text{Hit}_t = X_t\beta + u_t$ cu $X_t = (1, \text{Hit}_{t-1}, \dots, \text{Hit}_{t-4}, \text{VaR}_t)$ și testăm $\beta = 0$
- ▣ Statistica Dynamic Quantile (Engle & Manganelli (2004), forma Wald cu dispersia sub H_0)
 - $$\text{DQ} = \frac{\hat{\beta}' X' X \hat{\beta}}{\alpha(1 - \alpha)} = \frac{\text{Hit}' X (X' X)^{-1} X' \text{Hit}}{\alpha(1 - \alpha)} \xrightarrow{d} \chi_6^2$$
- ▣ Are drept cazuri particulare testul Kupiec ($X_t = 1$ dă forma scor $T(\hat{\pi} - \alpha)^2 / (\alpha(1 - \alpha))$) și testul Christoffersen (un decalaj); adaugă putere împotriva memoriei dincolo de decalajul 1 și a depășirilor care depind de nivelul VaR

Toate testele VaR dintr-o privire

	Kupiec POF				Christoffersen CC				Duration (Weibull)				Dynamic Quantile			
HS	<0.001	0.23	0.16	<0.001	<0.001	0.05	0.30	<0.001	<0.001	<0.001	0.25	<0.001	<0.001	<0.001	0.87	<0.001
Normal	<0.001	<0.001	<0.001	0.71	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001
Student-t	<0.001	<0.001	0.07	0.31	<0.001	<0.001	0.08	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	0.03	<0.001
GARCH-t	<0.001	0.002	0.48	0.27	<0.001	0.01	0.58	0.48	0.48	0.25	0.96	0.95	<0.001	0.04	0.25	0.15
FHS	0.12	0.18	0.62	0.31	0.04	0.39	0.51	0.43	0.51	0.12	0.38	0.90	<0.001	0.21	0.06	0.80
GARCH-EVT	0.37	0.96	0.75	0.13	0.06	0.81	0.57	0.25	0.24	0.20	0.51	0.42	<0.001	0.32	0.09	0.07
	S&P 500	BET	Bitcoin	EUR/RON	S&P 500	BET	Bitcoin	EUR/RON	S&P 500	BET	Bitcoin	EUR/RON	S&P 500	BET	Bitcoin	EUR/RON

- Valorile p ale testelor Kupiec, de acoperire condiționată, de durată și DQ, VaR 1%; roșu: respingere, verde: nerespingere
- DQ respinge toate modelele pe S&P 500, inclusiv FHS ($p < 0,001$) și GARCH-EVT ($p < 0,001$): depășirile sînt previzibile din nivelul VaR și din depășirile trecute, o abatere pe care simpla numărare nu o detectează
- Teste diferite examinează abateri diferite: modelele necondiționate eșuează la durate aproape peste tot; GARCH-EVT trece acoperirea și duratele pe BET, Bitcoin și EUR/RON; interpretăm tabloul de ansamblu, nu o singură valoare p

Mărimea și puterea testelor VaR: un Monte Carlo

- DGP: GARCH(1,1)-t estimat pe S&P 500 1990–2026 ($a = 0,102$, $b = 0,892$, $\nu = 6,1$); VaR 1%; 1000 de traiectorii; rate de respingere (%) la 5%

Proгноза	T	POF	Acop. cond.	Durate	DQ
Corect (mărime)	250	9,8	1,2	14,8	8,6
	1000	6,5	3,3	7,9	11,0
	5000	4,9	3,4	4,6	8,8
Normal-GARCH (putere)	250	10,5	4,9	14,7	18,8
	1000	30,3	19,9	8,0	30,3
	5000	83,8	77,2	7,2	70,7
HS, 1000 de zile (putere)	250	51,2	17,2	12,3	32,4
	1000	46,3	47,1	68,5	73,8
	5000	57,1	86,4	100,0	99,5

- Corect: parametrii și σ_t adevărați; Normal-GARCH: σ_t adevărat, coadă Normală; un p de durată nedefinit (sub 3 durate, 28% din eșantioanele corecte la $T = 250$) se numără ca nerespingere; eroarea standard Monte Carlo 0,7 puncte la 5%, 1,6 la 50%
- Cu albine: într-un an, o coadă Normală pe volatilitatea corectă este aproape invizibilă, iar gruparea HS este rar detectată; DQ respinge în continuare prea des un model corect (mărime efectivă peste 5%) chiar la $T = 5000$, deci îi simulăm valorile critice

Backtesting sub riscul de estimare


- Prognozele folosesc $\hat{\theta}$ estimat pe R zile; testul folosește P zile în afara eșantionului; depășirile $\hat{I}_t = 1\{L_t > \text{VaR}_t(\hat{\theta})\}$ nu sînt Bernoulli(α) nici sub un model corect
- Corecția depinde de schema de prognoză (fixă, mobilă, recursivă) și crește cu P/R (Escanciano & Olmo (2010); dezvoltarea în [► Anexă](#))
- Ilustrare cu schema fixă: GARCH(1,1)-t cu estimările S&P 500, $R = 1000$, 400 de traiectorii: Kupiec respinge un model **corect** în 27,5% din eșantioane la $P = 5000$, față de 4,0% cu parametrii adevărați
- Capitolul reestimează pe o fereastră mobilă ($R = 1000$, la fiecare 20 de zile): cifra pentru schema fixă arată mecanismul, nu mărimea testelor noastre
- Remediul: reproducem estimarea în calibrare, de exemplu printr-un bootstrap parametric care reestimează modelul pe fiecare traiectorie simulată (Seminarul 8, B9)

Semaforul: o regulă de numărare Binomială

Excepții	$P(X \leq x)$	Zona
0	8,11%	verde
2	54,32%	verde
4	89,22%	verde
5	95,88%	galben
7	99,60%	galben
9	99,97%	galben
10	99,99%	roșu

- ▣ Băncile care folosesc modele interne compară zilnic VaR 1% cu profitul și pierderea (P&L) efective din ultimele 250 de zile (BCBS (1996))
- ▣ $X \sim \text{Binomială}(250; 0,01)$: excepțiile unui VaR 1% corect în 250 de zile
- ▣ Zona galbenă începe unde $P(X \leq x) \geq 95\%$, cea roșie unde $P(X \leq x) \geq 99,99\%$
- ▣ Contează doar **numărul** excepțiilor, nu mărimea sau momentul lor: simplu, automat, greu de manipulat

Regulile de backtesting din 1996 și 2019




Turnul BIS, Basel: sediul secretariatului BCBS

Foto: Taxiarchos228 (2014); Free Art License;

[Wikimedia Commons](#)

- **BCBS (1996):** capital pe VaR 1% pe 10 zile
 - ▶ multiplicatorul 3, plus 0,40–0,85 în zona galbenă și plus 1 în zona roșie
- **BCBS (2019) (FRTB):** capital pe ES 2,5%, backtesting tot pe VaR
 - ▶ la nivelul băncii: VaR 1%, 250 de zile; multiplicator 1,50 (verde, 0–4), 1,70–1,92 (galben, 5–9), 2,00 (roșu, 10 sau mai multe)
 - ▶ birou de tranzacționare: peste 12 excepții ale VaR 1% sau 30 ale VaR 2,5% în 12 luni mută biroul la abordarea standardizată
 - ▶ aprobarea IMA cere și un test de atribuire a P&L (nediscutat aici)
- Numărarea excepțiilor VaR rămâne pentru că este simplă; faptul că ES nu este elicibil (secțiunea „Elicitabilitate și funcții de scor”) nu împiedică testarea ES (secțiunea „Backtesting pentru Expected Shortfall”)

Semaforul de-a lungul timpului



- Excepțiile VaR 1% în ultimele 250 de zile, S&P 500; benzi: zonele verde, galbenă, roșie
- Ponderea zilelor în roșu: Normal 22,3%, HS 14,7%, GARCH-t 2,0%, FHS 0,8%
- Vîrfurile: HS 27 și Normal 37 excepții în cele 250 de zile încheiate la 01.12.2008; GARCH-t este galben 46,6% din timp
- Ferestrele suprapuse țin un model penalizat un an după o criză, cînd capitalul este deja sub presiune

Verificarea FRTB la nivel de birou, ultimele 250 de zile (limitele 12 și 30)

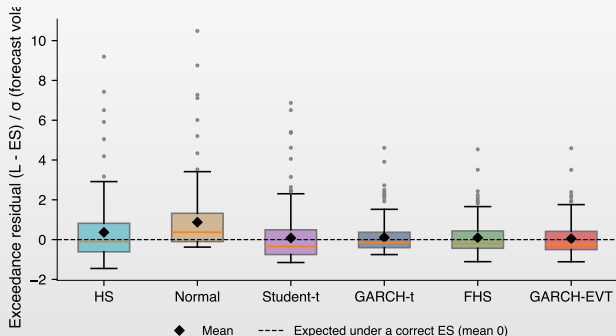
Model	S&P 500	BET	Bitcoin	EUR/RON
HS	0 / 2	4 / 7	3 / 4	1 / 5
Normal	2 / 2	6 / 9	3 / 5	1 / 4
Student-t	0 / 2	4 / 9	1 / 4	5 / 8
GARCH-t	3 / 6	4 / 9	3 / 5	4 / 5
FHS	3 / 4	4 / 6	4 / 5	1 / 4
GARCH-EVT	3 / 3	2 / 7	4 / 5	1 / 4

- Celule: excepții ale VaR 1% / VaR 2,5% în ultimele 250 de zile ale fiecărei serii (pînă la 18.09.2026); toate modelele trec confortabil
- Doar ilustrativ: FRTB aplică limitele P&L-ului birourilor (efectiv și ipotetic), nu randamentelor de indici
- Ultimul an a fost calm: o lumină verde azi spune puțin despre următoarea criză

McNeil și Frey (2000): reziduurile de depășire

- ES este o **medie** dincolo de VaR: informația stă în aproximativ αT zile din coadă (124 pentru S&P 500 la $\alpha = 2,5\%$; 6,25 într-un an, deci o eroare standard a mediei din coadă de ordinul $1/\sqrt{\alpha T} \approx 0,40$)
- În fiecare zi de depășire a VaR 2,5%: $e_t = (L_t - ES_t)/\sigma_t$, unde $\sigma_t > 0$ este volatilitatea prognozată, cunoscută la $t - 1$
- Dacă VaR și ES sînt corecte: $E[e_t \mid L_t > VaR_t, \mathcal{F}_{t-1}] = 0$; un VaR greșit schimbă evenimentul de condiționare
- H_0 : $E[e_t] = 0$ față de H_1 : $E[e_t] > 0$ (ES subestimat); statistică t unilaterală
- Reziduuri puține, cu cozi groase: valoarea p din bootstrap i.i.d. al reziduurilor centrate (McNeil & Frey (2000)), care presupune reziduuri independente; altfel, bootstrap pe blocuri

Reziduurile de depășire pe S&P 500



- Distribuția lui $(L_t - ES_t) / \sigma_t$ în zilele de depășire a VaR 2,5%; romburi: mediile
- Medii: Normal 0,875, HS 0,363, GARCH-t 0,106, FHS 0,093, GARCH-EVT 0,045
- p bootstrap: Normal $<0,001$, HS $<0,001$, GARCH-t 0,023, FHS 0,096, GARCH-EVT 0,246
- Distribuția Normală subestimează media din coadă cu aproape o unitate de volatilitate; valorile extreme (pînă la 10 unități) sînt zilele care decid adecvarea capitalului

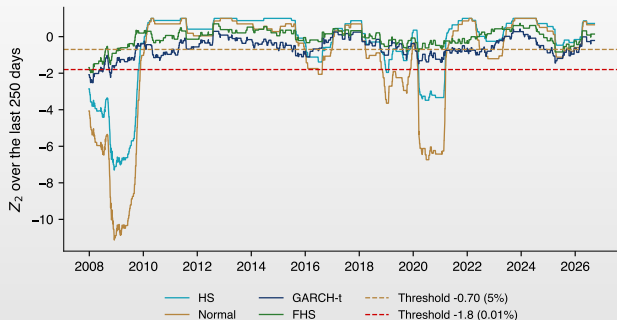
Acerbi și Szekely (2014): testarea directă a ES

- Indicatorul de depășire la nivelul ES: $I_t = 1\{L_t > \text{VaR}_t^\alpha\}$, $N_T = \sum_t I_t$, $\alpha = 0,025$
- $Z_1 = 1 - \frac{1}{N_T} \sum_t \frac{L_t I_t}{\text{ES}_t}$: este pierderea medie din coadă atît de mare cît s-a prognozat? (condiționat de depășiri)
- $Z_2 = 1 - \frac{1}{T_\alpha} \sum_t \frac{L_t I_t}{\text{ES}_t}$: testează frecvența și mărimea împreună
- Sub H_0 (distribuția prognozată este corectă) $E[Z_2] = 0$; riscul subestimat dă $Z_2 < 0$ (Acerbi & Szekely (2014))
- Pentru $T = 250$ și multe distribuții, valorile critice de 5% și 0,01% sînt apropiate de $-0,70$ și $-1,8$: praguri de referință pentru un semafor ES

Valori p prin simulare

- ▣ Distribuția lui Z_2 sub H_0 depinde de distribuțiile prognozate F_t , pe care le furnizează modelul
- ▣ Algoritm (se repetă de $M = 2000$ ori)
 - ▶ Pentru fiecare zi extragem $U_t \sim \text{Uniform}(0,1)$ și calculăm $L_t^* = F_t^{-1}(U_t)$
 - ▶ Calculăm Z_2^* din pierderile simulate, cu aceleași prognoze VaR și ES
- ▣ Valoarea p = ponderea valorilor simulate Z_2^* mai mici sau egale cu Z_2 observat
- ▣ Contează doar extragerile din coadă: pentru HS și FHS păstrăm cele mai mari 25 de pierderi din fereastra fiecărei zile
- ▣ S&P 500, întreg eșantionul: $Z_2 = -0,618$ pentru GARCH-t ($p < 0,001$) față de $-0,091$ pentru FHS ($p = 0,172$); valoarea critică este de circa $-0,152$

Z_2 pe ferestre mobile de 250 de zile



- Z_2 pentru prognozele ES 2,5% pe ultimele 250 de zile, S&P 500; pragurile de referință ilustrative $-0,70$ și $-1,8$
- Minim: Normal $-11,13$, HS $-7,30$ (fereastra încheiată la 01.12.2008), GARCH-t $-2,52$, FHS $-1,97$
- Ferestre sub $-1,8$: Normal 21,9%, HS 15,8%, GARCH-t 3,0%, FHS 0,7%; GARCH-t sub $-0,70$ în 39,6%
- Verificarea zilnică înseamnă testare repetată: alarmele false se acumulează (monitorizarea secvențială, [▶ Anexă](#))

Du și Escanciano (2017): depășirile cumulate

- ▣ PIT: $u_t = F_t(L_t)$, uniformă pe $(0, 1)$ dacă distribuția prognozată este corectă
- ▣ Depășirea cumulată: $H_t = \frac{1}{\alpha} (u_t - (1 - \alpha)) 1\{u_t > 1 - \alpha\}$: cât de adânc în coadă a ajuns pierderea
- ▣ Sub H_0 : $E[H_t] = \alpha/2$ și $\text{Var}(H_t) = \alpha(1/3 - \alpha/4)$
- ▣ Testul necondiționat: $U = \sqrt{T} (\bar{H} - \alpha/2) / \sqrt{\alpha(1/3 - \alpha/4)} \xrightarrow{d} N(0, 1)$
- ▣ Testul condiționat: statistica Box–Pierce pe primele 5 autocorelații ale lui H_t , χ_5^2 (Du & Escanciano (2017))

Toate testele ES dintr-o privire

	McNeil-Frey				Acerbi-Szekely Z2				Du-Escanciano U			
HS	<0.001	0.48	0.70	0.46	<0.001	0.13	0.86	1.00	<0.001	0.36	0.14	<0.001
Normal	<0.001	<0.001	<0.001	<0.001	<0.001	<0.001	0.001	0.97	<0.001	<0.001	<0.001	0.25
Student-t	0.17	0.01	1.00	0.47	0.002	0.003	0.62	0.92	<0.001	<0.001	0.93	0.05
GARCH-t	0.02	0.04	0.50	0.41	<0.001	<0.001	0.05	0.63	<0.001	<0.001	0.13	0.86
FHS	0.10	0.63	0.60	0.75	0.17	0.19	0.35	0.97	0.09	0.46	0.95	0.09
GARCH-EVT	0.25	0.57	0.29	0.69	0.09	0.21	0.58	0.98	0.24	0.54	0.70	0.11
	S&P 500	BET	Bitcoin	EUR/RON	S&P 500	BET	Bitcoin	EUR/RON	S&P 500	BET	Bitcoin	EUR/RON

- Valorile p pentru ES 2,5%: McNeil-Frey (bootstrap), Z_2 (simulare), Du-Escanciano U ; distribuția Normală este respinsă de toate trei pe S&P 500, BET și Bitcoin; FHS și GARCH-EVT le trec pe toate peste tot
- Ipoteze nule și date diferite, decizii diferite: Student-t pe S&P 500 are McNeil-Frey $p = 0,173$, dar Z_2 $p = 0,002$; acestea sînt teste de calibrare, nu clasamente
- GARCH-t eșuează la Z_2 pe acțiuni ($p < 0,001$, $< 0,001$), în timp ce FHS trece; EUR/RON: majoritatea modelelor supraestimează ES ($Z_2 > 0$)

Teste VaR multinomiale: un test implicit pentru ES

- ES 2,5% este media cuantilelor de dincolo de VaR 2,5%: testăm simultan mai multe niveluri VaR (Kratz, Lok & McNeil (2018))
- $N = 4$ niveluri de coadă $\alpha_j = 2,5\% (1 - (j - 1)/4)$: 2,5%, 1,875%, 1,25%, 0,625%; fiecare zi cade într-una din 5 celule, prin PIT u_t
- Statistica Pearson $S = \sum_{j=0}^4 (O_j - Tp_j)^2 / (Tp_j) \xrightarrow{d} \chi_4^2$, probabilitățile celulelor $p_0 = 97,5\%$, $p_1 = \dots = p_4 = 0,625\%$

Valoare p	S&P 500	BET	Bitcoin	EUR/RON
HS	<0,001	0,725	0,564	0,004
Normal	<0,001	<0,001	<0,001	<0,001
Student-t	<0,001	0,024	0,015	0,172
GARCH-t	<0,001	<0,001	0,227	0,568
FHS	0,008	0,846	0,413	0,392
GARCH-EVT	0,287	0,864	0,969	0,240

- Doar GARCH-EVT trece pe toate cele patru piețe; celulele GARCH-t pe S&P 500 (4767, 36, 46, 50, 60), față de 31 așteptate în fiecare celulă din coadă: prea multe zile în fiecare celulă din coadă, cele mai multe în cea mai adâncă


A testa nu înseamnă a ierarhiza: scoruri consistente

- Un backtest întreabă dacă un model este **acceptabil** (mai multe pot trece, toate pot eșua); backtesting-ul comparativ întreabă care este **mai bun** (Nolde & Ziegel (2017))
- Ierarhizarea cere o **funcție de scor** $S(x, L)$, pierderea asociată raportării lui x când se realizează L ; comparăm $\bar{S} = \frac{1}{T} \sum_t S(x_t, L_t)$, o valoare mai mică indică o prognoză mai bună
- S este **consistent** pentru $\theta(F)$, iar θ este **elicitabilă**, dacă $\theta(F) = \arg \min_x E_F[S(x, L)]$ (Gneiting (2011)): adevărul minimizează scorul așteptat
- VaR: pierderea pinball $S(v, L) = (1\{L > v\} - \alpha)(L - v)$; pentru $E|L| < \infty$ și $f > 0$ în cuantilă
 - ▶ $\frac{\partial}{\partial v} E_F[S(v, L)] = F(v) - (1 - \alpha) = 0 \Rightarrow v = F^{-1}(1 - \alpha) = \text{VaR}_\alpha$, iar $\partial^2 / \partial v^2 = f(v) > 0$
- ES **nu** este elicibil singur: nicio funcție de scor care depinde doar de prognoza ES raportată e nu este minimizată de ES adevărat (Gneiting (2011))

VaR și ES împreună: Fissler și Ziegel (2016)

- ▣ Perechea (VaR, ES) este elictabilă împreună: [Fissler & Ziegel \(2016\)](#) caracterizează întreaga familie de funcții de scor consistente
- ▣ Pierderea FZ0 ([Patton, Ziegel & Chen \(2019\)](#)), cu pierderi pozitive, $0 < v \leq e$, $E|L| < \infty$ și ES adevărat pozitiv
 - ▶
$$\text{FZ0}(v, e; L) = \frac{1\{L > v\}(L - v)}{\alpha e} + \frac{v}{e} + \ln e - 1$$
- ▣ Primul termen: penalizarea depășirilor, scalată cu ES; ultimii termeni: penalizarea raportării unui ES mare
- ▣ Diferențele de pierderi FZ0 nu depind de unitățile pierderilor, deci pot fi comparate între active
- ▣ FZ0 mediu mai mic = prognoză comună VaR și ES mai bună

Elicitabilitatea, ilustrată grafic




- Pierderi Student-t cu $\nu = 4$ și dispersie unitară, $\alpha = 2,5\%$; pierderile așteptate sînt calculate pe 2 milioane de extrageri
- Stînga: pierderea pinball așteptată este minimă în VaR 2,5% adevărat, 1,96; dreapta: pierderea FZ0 așteptată este minimă în (1,96; 2,82), perechea (VaR, ES) adevărată, în limita grilei
- Un prognozator care cunoaște adevărul nu are motiv să raporteze altceva: de aceea ordonarea după scorul mediu are sens

Este clasamentul robust la alegerea scorului? Scoruri elementare

- Pentru o cuantilă există o infinitate de scoruri consistente: $S(v, L) = (1\{L \leq v\} - \tau)(g(v) - g(L))$, orice g crescătoare, $\tau = 1 - \alpha$
- Fiecare este o mixtură de **scoruri elementare** (Ehm, Gneiting, Jordan & Krüger (2016))
 - $S_\theta(v, L) = (1\{L < v\} - \tau)(1\{\theta < v\} - 1\{\theta < L\})$, $\theta \in \mathbb{R}$; pierderea pinball este $\int S_\theta d\theta$
- Prognoza A o bate pe B sub **orice** scor consistent dacă și numai dacă $\bar{S}_\theta(A) \leq \bar{S}_\theta(B)$ pentru orice θ
- **Diagrama Murphy**: reprezentăm $\bar{S}_\theta$ în funcție de θ ; intersecția curbelor arată dependența clasamentului de scorul ales

Diagrama Murphy: GARCH-t versus FHS

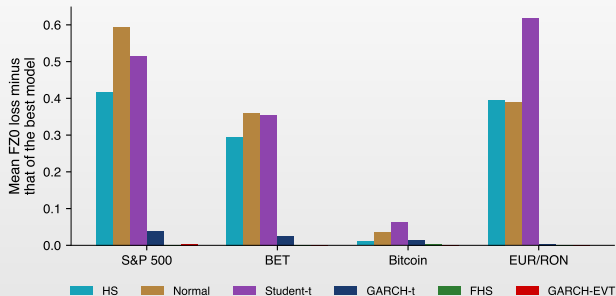


- S&P 500, VaR 1%, 2007–2026; θ între 0,9% și 11,3%; pinball ($\times 10^4$): GARCH-t 3,849, FHS 3,849, egalitate sub scorul obișnuit
- Sub $\theta = 5\%$ curbele se intersectează: FHS mai bun pe 50% dintre praguri, banda conține zero pe 82%; peste 5% GARCH-t mai mic pe 89%: nicio dominare
- Benzile sînt punctuale, nu un test simultan de dominare: alegem scorul înainte de a vedea rezultatele

Testul Diebold–Mariano pe pierderile FZ0


- ▣ Diferența de pierdere dintre modelele A și B : $d_t = \text{FZ0}_{A,t} - \text{FZ0}_{B,t}$
- ▣ H_0 : $E[d_t] = 0$ (acuratețe predictivă egală), Diebold & Mariano (1995)
- ▣
$$\text{DM} = \frac{\bar{d}}{\sqrt{\widehat{\text{LRV}}(d_t)/T}} \xrightarrow{d} N(0, 1)$$
- ▣ $\widehat{\text{LRV}}$: dispersia pe termen lung cu ponderi Newey–West (Newey & West (1987)), 9 decalaje; pierderile din coadă se grupează, deci d_t este autocorelat
- ▣ $\text{DM} > 0$: modelul A are pierderea medie mai mare (mai slab); $|\text{DM}| > 1,96$: semnificativ la 5%

Pierdere FZ0 medie pe modele



- Pierdere FZ0 medie a prognozelor (VaR 2,5%, ES 2,5%) minus cea a celui mai bun model de pe fiecare piață
- Cea mai mică: FHS pe S&P 500; GARCH-EVT pe BET, Bitcoin și EUR/RON
- Modelele necondiționate pierd 0,3–0,6 unități FZ0 pe S&P 500, BET și EUR/RON; pe Bitcoin cea mai mare diferență este 0,062
- GARCH-t este în urma FHS pe S&P 500 cu 0,039: mărimea unei diferențe nu spune singură dacă datele pot separa modelele; o testăm

Teste Diebold–Mariano pe perechi, S&P 500



- DM pentru modelul A (rînd) minus B (coloană) pe pierderile FZ0; roșu: A mai slab, verde: A mai bun
- Față de FHS: HS DM = 4,70 și GARCH-t DM = 2,65, ambele semnificativ mai slabe; GARCH-EVT DM = 1,24, nu se deosebește
- Normal minus HS: DM = 2,88: o cuantilă empirică lentă bate totuși o coadă subțire
- Cincisprezece teste pe perechi ridică o problemă de testare multiplă: care modele rămîn **împreună**? (MCS, mai jos)

Compararea metodelor de prognoză: Giacomini–White

- DM vizează acuratețea populațională a **modelelor**; cu ferestre mobile de 1000 de zile și parametri reestimați comparăm **metode de prognoză**, iar eroarea de estimare nu dispare
- **Giacomini & White (2006)**: $H_0: E[d_t | \mathcal{F}_{t-1}] = 0$ pentru diferența de scor $d_t = FZ0_{A,t} - FZ0_{B,t}$; valid pentru modele imbricate și ferestre finite
- Funcția test $h_{t-1} = (1, d_{t-1})'$, $Z_t = h_{t-1}d_t$: $GW = T \bar{Z}'\hat{\Omega}^{-1}\bar{Z} \xrightarrow{d} \chi_2^2$, $\hat{\Omega} = T^{-1} \sum_t Z_t Z_t'$ (un pas înainte); $h_{t-1} = 1$ dă forma DM
- S&P 500 față de FHS: GARCH-EVT $GW = 7,38$ ($p = 0,025$), GARCH-t $7,59$ ($p = 0,022$), HS $53,38$ ($p < 0,001$)
- GARCH-EVT, la egalitate după DM, este respins condiționat: egalitatea capacității predictive condiționate este respinsă pentru aceste instrumente; ce anume determină respingerea trebuie verificat cu un test separat

Backtesting comparativ în trei zone (Nolde și Ziegel)

- Modelul intern A față de un model standard S (aici HS), pierderea FZ0 medie; două teste unilaterale la 5% (Nolde & Ziegel (2017))
- H_0^- : A cel puțin la fel de bun ca S ; H_0^+ : A cel mult la fel de bun. **Verde**: respingem H_0^+ ; **roșu**: respingem H_0^- ; **galben**: niciuna
- Sarcina probei se inversează: banca trebuie să arate că modelul ei este mai bun, nu supraveghetorul că este mai slab

DM (A minus HS)	S&P 500	BET	Bitcoin	EUR/RON
GARCH-t	-4,23	-5,18	0,09	-6,66
FHS	-4,70	-5,49	-0,17	-6,94
GARCH-EVT	-4,68	-5,53	-0,25	-6,92

- Culoarea = zona. Verde peste tot, cu excepția Bitcoin, unde toate modelele sînt galbene: cu o coadă atît de zgomotoasă, niciun model nu poate dovedi că bate HS

Mulțimea de modele de încredere

- ▣ Hansen, Lunde & Nason (2011): o mulțime de modele construită astfel încât să conțină modelele cele mai bune cu o probabilitate asimptotică de cel puțin $1 - \alpha_{MCS}$, în condițiile de regularitate ale metodei
- ▣ Algoritm
 - ▶ Testăm H_0 : toate modelele din mulțimea curentă au aceeași pierdere așteptată
 - ▶ Dacă o respingem, eliminăm modelul cu cea mai mare pierdere medie standardizată și repetăm
 - ▶ Valorile critice provin dintr-un bootstrap pe blocuri (blocuri de 10 zile, 1000 de replicări)
- ▣ Valoarea p MCS a unui model: cea mai mare valoare p a testelor pînă la eliminarea lui; păstrăm modelele cu $p \geq 0,10$
- ▣ O mulțime MCS mare este un răspuns onest: datele nu separă modelele

Ce modele rămîn?

MCS p-values (FZ0 loss); models with $p \geq 0.10$ are in the 90% MCS

	S&P 500	BET	Bitcoin	EUR/RON
HS	<0.001	<0.001	0.87	<0.001
Normal	<0.001	<0.001	0.63	<0.001
Student-t	<0.001	<0.001	0.30	<0.001
GARCH-t	0.009	0.09	0.84	0.90
FHS	1.00	0.90	0.87	0.99
GARCH-EVT	0.21	1.00	1.00	1.00

- Valoriile p MCS pentru pierderea FZ0 a (VaR 2,5%, ES 2,5%), pe piețe; modelele cu $p \geq 0,10$ formează MCS de 90%
- S&P 500: FHS și GARCH-EVT (MCS p 0,21); GARCH-t exclus (p 0,01)
- BET: FHS și GARCH-EVT, GARCH-t exclus la limită (p 0,09); EUR/RON: cele trei modele condiționate
- Bitcoin: rămîn toate cele șase modele: datele nu le pot separa; nerespingerea nu dovedește că modelele sînt la fel de bune

Cuantile conformale split: o garanție fără ipoteze de distribuție

- ▣ Toate modelele de pînă acum presupun o distribuție (Normală, t, GPD) sau un trecut stabil (HS); **predicția conformală** transformă orice prognoză într-o cuantilă cu garanție de acoperire (Lei et al. (2018), Angelopoulos & Bates (2021))
- ▣ Scorul $s_t = L_t / \hat{\sigma}_t$, $\hat{\sigma}_t$ abaterea standard a celor 250 de randamente anterioare; mulțimea de calibrare: ultimele $n = 250$ scoruri, ordonate $s_{(1)} \leq \dots \leq s_{(n)}$
- ▣ VaR conformal: $\text{VaR}_t = \hat{\sigma}_t s_{(k)}$, cu $k = \lceil (n+1)(1-\alpha) \rceil$; $n = 250$, $\alpha = 0,01$: $k = 249$, al doilea cel mai mare scor
- ▣ Garanția, dacă cele $n+1$ scoruri sînt **schimbabile** (legea comună nu se schimbă la permutare):
 $1 - \alpha \leq P(L_t \leq \text{VaR}_t) \leq 1 - \alpha + \frac{1}{n+1}$ (fără valori egale)
- ▣ Grupările de volatilitate încalcă schimbabilitatea, iar aici $\hat{\sigma}_t$ provine din ferestre mobile suprapuse: garanția este aproximativă, spre deosebire de conformal split autentic, cu un scor estimat o singură dată pe un eșantion separat (extinderi: [▶ Anexă](#))

Inferența conformală adaptivă




Emmanuel Candès, coautor al inferenței
conformale adaptive

Foto: Cmicel67 (2026); CC BY-SA 4.0;
Wikimedia Commons


- Gibbs & Candès (2021): nivelul de lucru se actualizează după fiecare zi,
 $\alpha_{t+1} = \alpha_t + \gamma (\alpha - \text{err}_t)$, $\text{err}_t = 1\{L_t > \text{VaR}_t\}$
- După o depășire α_t scade (VaR crește); după zile calme crește încet la loc;
folosim $\gamma = 0,005$
- Garanția, pentru orice șir: $\left| \frac{1}{T} \sum_t \text{err}_t - \alpha \right| \leq \frac{\max(\alpha_1, 1 - \alpha_1) + \gamma}{\gamma T}$, o medie
pe termen lung, nu fiecare zi sau fiecare criză
- Dacă $\alpha_t < 1/(n+1)$, cuantila cerută nu există: VaR devine infinit

VaR conformal în perioada COVID-19



- S&P 500, iulie 2019–iunie 2021: VaR 1% conformal split, ACI și GARCH-t (sus), nivelul ACI α_t (jos)
- 20.02–30.04.2020, 50 de zile, 0,5 depășiri așteptate: conformal split 6, ACI 4 (8% din zile)
- ACI a stabilit $\text{VaR} = \infty$ în 37 din aceste zile: nicio depășire nouă, dar un VaR infinit nu aduce informație
- Cu martie 2020 în mulțimea de calibrare, VaR conformal split rămâne în jur de 18% timp de un an; GARCH-t se adaptează în câteva zile

Acoperirea în perioade calme și de criză



- VaR 5%; zi de criză: volatilitatea pe 20 de zile anterioare peste percentila 90 a valorilor ei din cele 1000 de zile anterioare (cunoscută dinainte)
- Conformal split, toate zilele: S&P 500 5,34%, BET 5,63%, Bitcoin 4,58%, EUR/RON 5,06%; zile de criză: 7,29%, 8,08%, 7,95%, 11,43%
- ACI aduce ratele din criză pe acțiuni aproape de 5% (4,49%, 5,38%); pentru VaR 1% păstrează media doar printr-un VaR infinit în 13,4% dintre zilele S&P 500: acoperirea marginală nu este acoperire în criză


Se poate testa ES doar din prognozele ES?

- Bayer & Dimitriadis (2022): pot fi testate prognozele ES folosind doar randamentele observate și aceste prognoze?
- De ce contează: FRTB calculează capitalul din ES 2,5% (secțiunea „Perspectiva reglementatorului”)
 - ▶ Testele ES din secțiunea „Backtesting pentru Expected Shortfall” cer și prognoze VaR, volatilitatea sau întreaga distribuție prognozată; supraveghetorii nu primesc neapărat aceste date, iar respingerea unui astfel de test comun nu arată care dintre ele este greșită (lucrarea, Sect. 1.1, Definiția 1.1)
- Ideea: o regresie Mincer–Zarnowitz a randamentelor pe prognozele ES, H_0 : termenul liber 0, panta 1
 - ▶ ES nu este elicitol separat (secțiunea „Elicitabilitate și funcții de scor”), dar perechea (VaR, ES) este elicitolabilă în comun (Fissler & Ziegel (2016)), deci se poate estima o regresie comună cuantilă–ES (Patton, Ziegel & Chen (2019))
- Convenția randamentelor: $\hat{e}_t = -\widehat{ES}_t < 0$, $\tau = 2,5\%$; ecuația ES $r_t = \gamma_1 + \gamma_2 \hat{e}_t + u_t^e$, $ES_\tau(u_t^e | \mathcal{F}_{t-1}) = 0$ (Ec. 1.4–1.6)
 - ▶ **ESR auxiliar**: ecuația cuantilei pe $(1, \hat{v}_t)$, cere prognoze VaR; **ESR strict**: ecuația cuantilei pe $(1, \hat{e}_t)$, doar prognoze ES
 - ▶ **ESR cu termen liber** (Ec. 1.14–1.15): $r_t - \hat{e}_t = \gamma_1 + u_t^e$; test t unilateral pentru $H_0: \gamma_1 \geq 0$ față de $\gamma_1 < 0$ (ES subestimat)

Estimare, covarianță și rezultate Monte Carlo

- Estimator de tip M care minimizează o pierdere de tip FZ0 (secțiunea „Elicitabilitate și funcții de scor”; lucrarea, Ec. 1.16–1.18); teorie asimptotică sub specificare greșită (lucrarea, Teorema 1.4); pachetele R [esback](#) și [esreg](#)
- Două ipoteze de reținut
 - ▶ ESR strict și ESR cu termen liber: ecuația cuantilei este corectă doar dacă VaR este o funcție afină de ES (de exemplu, modele de scală pură) (lucrarea, Secț. 1.2)
 - ▶ Covarianța sandwich robustă la specificarea greșită presupune un model de locație și scală pentru distribuția condiționată (lucrarea, Secț. 1.5)
- Design (lucrarea, Secț. 2): 10 000 de replicări, T de la 250 la 5 000; EGARCH-t calibrat pe S&P 500, AR(1)-GARCH(1,1), două modele GAS Student-t; teste de comparație [McNeil & Frey \(2000\)](#) și testele de calibrare din [Nolde & Ziegel \(2017\)](#)
- Mărimea la 5%, EGARCH-t: ESR strict 0,09 ($T = 250$) și 0,05 ($T = 1\,000$) cu covarianța robustă, 0,24 și 0,11 cu cea clasică; testul simplu de calibrare condiționată 0,29 și 0,14 (Tabelul 1)
- Puterea: testele reziduurilor de depășire aproape nu reacționează la o dinamică greșită a volatilității sau la prognoze pentru un nivel greșit $\tilde{\tau} \neq \tau$, pe care testele ESR le detectează (Fig. 3): o bancă ar putea raporta ES pentru un nivel mai blând și ar trece testele mai vechi

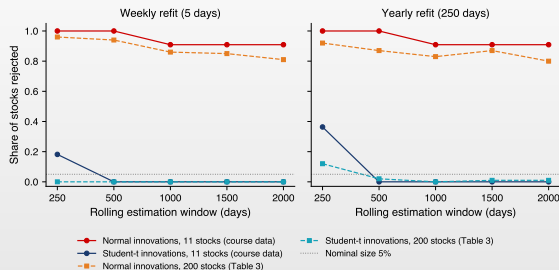
Tabelul 3 din lucrare: cozile contează mai mult decât reestimarea



- Ponderea celor mai mari 200 de acțiuni din S&P 500 cu ES 2,5% respins de ESR cu termen liber, unilateral, la 5%, 2010–2019; ferestre de 250–2000 de zile, reestimare la 5 (linia continuă) sau 250 de zile (linia întreruptă); Bayer & Dimitriadis (2022), Tabelul 3
- Inovații Normale: 0,80–0,96 respinse în toate cele 50 de combinații (fereastră × reestimare × GARCH/GJR-GARCH); Student-t: până la 0,12 cu ferestre de 250 de zile, cel mult 0,01 cu 1000 de zile sau mai mult
- Pentru aceste acțiuni și această perioadă: contează cozile groase și fereastra lungă; frecvența reestimării contează doar la ferestre scurte

 MFM_ch8_esr_case

Tabelul 3 din Bayer și Dimitriadis (2022), replicat pe datele cursului



- Linia continuă: 11 acțiuni mari din S&P 500 cu prețuri din 2002 (Apple, Microsoft, Amazon, NVIDIA, Cisco, JPMorgan Chase, Bank of America, Citigroup, Wells Fargo, Goldman Sachs, Morgan Stanley), ianuarie 2010 – august 2019 (2 432 de zile); linia întreruptă: Bayer & Dimitriadis (2022), Tabelul 3
- GARCH(1,1) cu medie constantă (lucrarea nu precizează ecuația mediei), cele 25 de combinații fereastră–reestimare (doar GARCH), ESR cu termen liber, unilateral, la 5%, cu [esback](#); cu 11 acțiuni, fiecare acțiune respinsă adaugă $1/11 \approx 0,09$ la pondere
- Normal: 0,82–1,00 respinse (lucrarea 0,80–0,96); Student-t: cel mult 0,00 de la 1 000 de zile (lucrarea 0,01), dar 0,09–0,55 la 250 de zile (lucrarea 0,00–0,12): rezultatul central se replică, ponderile la fereastra scurtă sînt mai mari

O întrebare deschisă: acoperirea condiționată în criză

- Garanțiile VaR fără ipoteze de distribuție sînt **marginale**: conformal split cere schimbabilitate, ACI controlează doar media pe termen lung (secțiunea „Predicția conformală pentru tail risk”)
- Întrebarea formală, cu un indicator de criză $C_t \in \mathcal{F}_{t-1}$ cunoscut ex ante
 - ▶ H_0 : $P(L_t > \text{VaR}_t \mid C_t = 1) = \alpha$ față de H_1 : $P(L_t > \text{VaR}_t \mid C_t = 1) \neq \alpha$
 - ▶ Infirmată de o rată de depășire în criză în afara regiunii de acceptare Binomiale, după corecția pentru depășiri dependente și pentru testarea multiplă
- Bucla de cercetare cu un asistent AI (un LLM precum Claude, ChatGPT sau Gemini)
 - ▶ literatura, cu DOI-uri verificate pe Crossref; trei explicații rivale (scală întîrziată, formă a cozii schimbătoare, artefact al selecției regimului); replicăm întîi o cifră cunoscută; pre-înregistrăm testele; cerem asistentului un raport de recenzent ostil
 - ▶ Prompturi reutilizabile și o listă de verificări: [▶ Anexă](#)
- Miza: capitalul este necesar exact în zilele în care garanțiile marginale spun cel mai puțin

Mini studiu de caz: corectează o scală GARCH acoperirea în criză?

- Propunerea asistentului: scorul $s_t = (L_t + \mu_t)/\sigma_t$ cu prognozele GARCH-t; H_0 : rata de depășire a VaR 5% în criză = 5%, test Binomial exact, corecție Holm pe cele patru piețe

Piața	Zile de criză	Conformal split	p Holm	Scală GARCH	p Holm
S&P 500	613	7,01%	0,052	2,77%	0,037
BET	506	8,10%	0,009	3,95%	0,309
Bitcoin	150	8,00%	0,092	1,33%	0,111
EUR/RON	245	11,43%	<0,001	2,45%	0,153

- Întîi schimbarea eșantionului: scorurile cu scală GARCH cer 250 de zile de calibrare, deci eșantionul comun S&P 500 are 4 709 zile și 613 zile de criză (eșantionul complet din secțiunea conformală: 713), iar rata conformal split în criză devine 7,01% (eșantionul complet: 7,29%)
- Scala GARCH coboară toate ratele din criză sub 5%; Holm respinge doar pe S&P 500 (2,77%); în rest avem nerespingere, nu dovada acoperirii: valorile p Binomiale ignoră depășirile grupate, iar eșantioanele de criză sînt mici

 ai_discovery_case.py

Ce model ați alege provizoriu?



Banca Națională a României, București

Foto: Britchi Mirela (2018); CC BY-SA 4.0;

[Wikimedia Commons](#)

- ▣ **Calibrare:** doar FHS și GARCH-EVT trec Z_2 la 5% și rămân în MCS de 90% pe toate cele patru piețe (tabloul complet în [Anexă](#))
- ▣ **Comparație:** FHS are cel mai mic FZ0 pe S&P 500, GARCH-EVT în rest; cele două nu diferă semnificativ, iar pe Bitcoin niciun model nu se distinge de HS
- ▣ **Nerezolvat:** DQ respinge toate modelele pe S&P 500, acoperirea în criză eșuează, iar un an de date are putere redusă
- ▣ **Alegere provizorie:** un filtru GARCH cu o coadă flexibilă, cu celălalt model drept alternativă, reexaminată pe măsură ce se acumulează dovezi; un portofoliu românesc (BET și EUR/RON): Seminarul 8, C1

Întrebări de verificare și capitolul următor

Întrebări de verificare

- De ce respinge regula „ $LR_{uc} > 3,84$ ” un VaR 1% corect în aproximativ un an din zece?
- De ce poate eșua un model cu numărul corect de depășiri?
- De ce poate fi testat ES, dar nu poate fi ierarhizat singur?
- Ce garantează ACI și ce nu?

: volatilitate realizată

- Măsurăm dispersia zilnică din randamente intrazilnice, în loc să o prognozăm doar din date zilnice
- Evaluăm prognozele de volatilitate cu scoruri robuste (QLIKE) și cu MCS din acest capitol

Anexă: Lecturi suplimentare și resurse

- ▣ Fissler & Ziegel (2016): VaR și ES sînt elicitable împreună, baza pierderii FZ0; Nolde & Ziegel (2017): backtesting comparativ și semaforul pentru VaR și ES; Acerbi & Szekely (2014): teste ES fără ipoteze de model, inclusiv Z_2
- ▣ Prognoze VaR și ES bazate pe entropie: Pele, Lazar & Dufour (2017), Pele & Mazurencu-Marinescu-Pele (2019), Pele, Lazar & Mazurencu-Marinescu-Pele (2019)
- ▣ Cînd pot fi deosebite două prognoze ES: Pele & Mazurencu-Marinescu-Pele (2026) arată că aproximativ una din cinci comparații ES pe perechi, pe piețele globale, are o precizie fragilă, o consecință a eșantionului efectiv mic din coadă, αT
- ▣ Manuale: Franke, Härdle & Hafner (2019) (capitolele despre VaR și backtesting) și Härdle, Chen & Overbeck (2017)
- ▣ Quantinar: Machine learning in Financial Risk
- ▣ Cod și date: github.com/danpele/MFM/tree/main/Quantlets/Ch_08; S&P 500, BET, Bitcoin: închideri zilnice din datele cursului; EUR/RON: cursul de referință BNR

Anexă: Riscul de estimare, dezvoltarea pentru schema fixă

- Prognozele folosesc $\hat{\theta}$ estimat pe R zile; testul folosește P zile în afara eșantionului
- Schema fixă (Escanciano & Olmo (2010)): $\frac{1}{\sqrt{P}} \sum_t (\hat{I}_t - \alpha) = \frac{1}{\sqrt{P}} \sum_t (I_t - \alpha) + \sqrt{P/R} D' \sqrt{R} (\hat{\theta} - \theta_0) + o_p(1)$
 - $D = E [\partial P(L_t > \text{VaR}_t(\theta) \mid \mathcal{F}_{t-1}) / \partial \theta]$ în θ_0 ; al doilea termen dispare doar dacă $P/R \rightarrow 0$
 - Termenul de estimare adaugă o dispersie de ordinul P/R la $\sqrt{P}(\hat{\pi} - \alpha)$, deci valorile critice χ^2 sînt prea mici cînd P/R este mare
- Schemele mobile și recursive schimbă forma corecției; dezvoltarea presupune $\text{VaR}_t(\theta)$ netedă, $\hat{\theta}$ consistent cu rata $\sqrt{R}$ și staționaritate
- Remedii: dispersia corectată sau subeșantionarea din Escanciano & Olmo (2010), ori un bootstrap parametric care reestimează modelul pe fiecare traiectorie simulată
- Schema fixă, 400 de traiectorii, $R = 1000$: Kupiec respinge 11,5% / 12,8% / 27,5% la $P = 250 / 1000 / 5000$ cu parametri estimați, 10,0% / 5,2% / 4,0% cu cei adevărați; eroarea standard Monte Carlo circa 1,1 puncte la 5%

Anexă: Principiul lui Osband și funcțiile de identificare

- Principiul lui Osband ([Fissler & Ziegel \(2016\)](#)): scorurile consistente se construiesc dintr-o funcție de identificare V , cu $E_F[V(x, L)] = 0$ doar în valoarea adevărată
- VaR: $V(v, L) = 1\{L \leq v\} - (1 - \alpha)$; pierderea pinball este integrala ei în v
- (VaR, ES): $V_1 = \alpha - 1\{L > v\}$ și $V_2 = e - v - \frac{1}{\alpha}1\{L > v\}(L - v)$; mediile lor se anulează doar în perechea adevărată
- Mulțimile de nivel ale ES nu sînt convexe la mixturi, deci nu există o funcție de identificare doar în e (Seminarul 8, A9)
- FZ0 este membrul familiei FZ ale cărei diferențe nu depind de scala pierderilor ([Patton, Ziegel & Chen \(2019\)](#))

Anexă: Monitorizarea secvențială a prognozelor de risc

- Reglementatorul verifică prognozele zilnic: repetarea unui test pe eșantion fix (de exemplu, Z_2 pe ferestre mobile) mărește probabilitatea a cel puțin unei alarme false
- Hoga & Demetrescu (2023): statistici de monitorizare pentru VaR și ES cu funcții-frontieră care țin sub nivelul nominal probabilitatea oricărei alarme false pe întregul orizont
- Față de semafor: dovezile se acumulează de la începutul monitorizării, nu dintr-o singură fereastră de 250 de zile
- Testul ES prin regresie (Bayer & Dimitriadis (2022)) din studiul de caz poate fi monitorizat la fel; ambele corectează limita semaforului, care evaluează un singur moment

Anexă: Predicția conformală dincolo de schimbabilitate

- Barber, Candès, Ramdas & Tibshirani (2023): fără schimbabilitate, abaterea acoperirii este mărginită de distanțe ponderate în variație totală între vectorul scorurilor și același vector în care scorul de test este schimbat cu scorul de calibrare i
- Cît de mari sînt aceste distanțe sub grupările de volatilitate este o întrebare empirică
- Gibbs, Cherian & Candès (2025): acoperirea exactă condiționată pe o clasă de deplasări fixată dinainte este realizabilă; ce clasă surprinde o criză financiară rămîne deschis
- Alegerea pasului ACI γ : Zaffran et al. (2022) agregă experți ACI pe o grilă de valori γ

Anexă: Studiul de caz, rezultatele principale complete

Rezultat	Sursa	Interpretare
Mărimea la 5% nominal, EGARCH-t: ESR strict 0,09 ($T = 250$) și 0,05 ($T = 1\,000$) cu covarianța robustă; 0,24 și 0,11 cu cea clasică	Tabelul 1	Covarianța robustă îmbunătățește controlul mărimii; la $T = 250$ mărimea rămîne 0,09
Mărimile ESR strict și ESR auxiliar diferă cu cel mult 0,01 pentru fiecare proces și mărime a eșantionului, inclusiv AR(1)-GARCH cu $\phi = 0,5$	Tabelul 1	În aceste simulări, renunțarea la prognozele VaR aproape nu schimbă mărimea; puterea se compară separat (Fig. 2–3)
Testul simplu de calibrare condiționată: mărime 0,29 la $T = 250$ și 0,14 la $T = 1\,000$ (EGARCH-t)	Tabelul 1	Puterea brută mare a unui test concurent se poate datora respingerilor excesive
Testele reziduurilor de depășire aproape nu reacționează la o dinamică greșită a volatilității sau la prognoze pentru un nivel greșit $\tilde{\tau} \neq \tau$; testele ESR detectează fiecare specificare greșită	Fig. 3	O bancă ar putea raporta ES pentru un nivel mai blînd și ar trece testele mai vechi
Inovații Normale: respinse pentru 80%–96% dintre acțiuni în fiecare combinație fereastră–reestimare	Tabelul 3	Cozile Normale subestimează ES pentru majoritatea acțiunilor
Student-t: GARCH 0,12 cu fereastră de 250 de zile și reestimare anuală; cel mult 0,01 cu 1 000 de zile sau mai mult, pentru GARCH și GJR-GARCH; levierul: de la 500 de zile, GJR-GARCH-t și GARCH-t diferă cu cel mult 0,01	Tabelul 3	Pentru aceste 200 de acțiuni și 2010–2019: cozile groase și ferestrele de cel puțin 1 000 de zile dau ponderi de respingere de cel mult 0,01

Anexă: Studiul de caz, limite și extinderi

- Limitele precizate de autori
 - ▶ ESR strict și ESR cu termen liber: ecuația cuantilei este greșit specificată dacă VaR nu este o funcție afină de ES (lucrarea, Sect. 1.2); ESR auxiliar și ESR strict sînt doar bilaterale (lucrarea, Sect. 1.3)
 - ▶ Covarianța clasică respinge prea des în eșantioane mici (lucrarea, Sect. 2.1)
- Replicarea cu datele cursului (Seminarul 8, C3)
 - ▶ Aplicați ESR strict (bilateral) și ESR cu termen liber (unilateral) prognozelor ES 2,5% ale celor șase modele pe cele patru piețe; comparați cu Z_2 și McNeil–Frey
 - ▶ Extindeți replicarea Tabelului 3: GJR-GARCH, mai multe acțiuni și perioada de după august 2019
- Întrebare deschisă: o fereastră de supraveghere de un an
 - ▶ La $T = 250$, ESR cu termen liber bilateral are mărimea 0,04 cu covarianța robustă și 0,15 cu cea clasică (Tabelul 1, EGARCH-t); mărimea unilaterală este raportată doar pentru $T = 2\,500$ (0,02, Tabelul 2)
 - ▶ Care este mărimea unilaterală pe un an și poate un bootstrap al statisticii t să o mențină la 5% fără a pierde puterea din Fig. 4?

Anexă: Tabloul de bord pe patru piețe

- Fiecare celulă: rata de depășire a VaR 1% în % / valoarea p pentru Z_2 / valoarea p MCS (FZ0)

Model	S&P 500	BET	Bitcoin	EUR/RON
HS	1,67 / <0,001 / <0,001	1,17 / 0,134 / <0,001	0,77 / 0,863 / 0,87	0,51 / 1,000 / <0,001
Normal	2,70 / <0,001 / <0,001	1,90 / <0,001 / <0,001	1,74 / 0,001 / 0,63	1,06 / 0,973 / <0,001
Student-t	2,00 / 0,002 / <0,001	1,58 / 0,003 / <0,001	0,71 / 0,625 / 0,30	0,85 / 0,920 / <0,001
GARCH-t	1,77 / <0,001 / 0,01	1,46 / <0,001 / 0,09	1,12 / 0,050 / 0,84	1,17 / 0,630 / 0,90
FHS	1,23 / 0,172 / 1,00	1,20 / 0,188 / 0,90	0,92 / 0,345 / 0,87	0,85 / 0,968 / 0,99
GARCH-EVT	1,13 / 0,090 / 0,21	0,99 / 0,210 / 1,00	0,95 / 0,581 / 1,00	0,78 / 0,976 / 1,00

- Doar FHS și GARCH-EVT trec testul Z_2 la 5% și rămân în MCS de 90% pe toate cele patru piețe; pe Bitcoin toate modelele rămân în MCS, deci comparația de acolo este neconcludentă

Anexă: Bucla de cercetare, prompturi și verificări

- Prompturi (instrumente: Semantic Scholar, Elicit, Google Scholar; verificăm fiecare DOI pe Crossref)
 - ▶ Enumeră lucrările evaluate de specialiști, din 2019 încoace, despre predicția conformală sub dependență serială, cu DOI, garanția exactă și ipotezele.
 - ▶ Dă trei explicații rivale pentru depășirile excesive în criză ale VaR conformal split și ce prezice fiecare pentru ratele pe regimuri.
 - ▶ Joacă rolul unui recenzent ostil: enumeră cele mai puternice motive pentru care acest efect de criză este un artefact și testul care ar tranșa fiecare motiv.
- Verificările cercetătorului
 - ▶ **Look-ahead bias:** modificăm observațiile de după ziua $t - 1$ și confirmăm că VaR_t , scala și indicatorul de criză nu se schimbă
 - ▶ **Depășiri dependente:** testele Christoffersen și de durată sau un bootstrap pe blocuri al șirului depășirilor; **puterea:** 613 zile de criză dau 6,1 depășiri așteptate ale VaR 1%, iar o rată reală de 2% este detectată cu probabilitatea 57%
 - ▶ **Testarea multiplă:** 4 piețe $\times$ 2 niveluri $\times$ 3 metode = 24 de teste: Holm (FWER) sau BH (FDR); **teoreme enunțate greșit:** de exemplu, „ACI garantează acoperirea condiționată”; **cuantile decalate:** $k = \lceil (n + 1)(1 - \alpha) \rceil$ nu este implicit în `np.quantile`

Anexă: Punct de plecare pentru proiect, acoperirea în criză

- Întrebarea: poate o prognoză VaR 1% și ES 2,5% fără ipoteze de distribuție să atingă acoperirea condiționată de criză pe toate cele patru piețe, cu un test preînregistrat?
- Replicați mai întâi: ratele în criză ale VaR 5% conformal split (S&P 500 7,29%, EUR/RON 11,43%) și ponderea VaR 1% infinit la ACI (13,4%)
- Livrabile
 - ▶ O preînregistrare (ipoteze, teste, corecții, putere) datată înainte de prima rulare
 - ▶ O metodă candidată, de exemplu [Gibbs, Cherian & Candès \(2025\)](#) cu regimul de volatilitate drept clasă de condiționare; teste VaR pe regimuri; ES testat cu testul ES prin regresie ([Bayer & Dimitriadis \(2022\)](#)) sau cu Z_2
 - ▶ Codul, un raport de două pagini cu toate specificațiile încercate și o critică, în stil de recenzent, a propriului rezultat
- Consemnați fiecare prompt care a influențat o decizie în AI_USE.md și fiecare eroare a asistentului în AI_ERRORS.md: github.com/danpele/MFM/tree/main/project

Bibliografie (1/5)

- Acerbi, C., Szekely, B. (2014). [Backtesting expected shortfall](#). MSCI Inc., December 2014.
- Angelopoulos, A.N., Bates, S. (2021). [A gentle introduction to conformal prediction and distribution-free uncertainty quantification](#). arXiv:2107.07511.
- Barber, R.F., Candès, E.J., Ramdas, A., Tibshirani, R.J. (2023). [Conformal prediction beyond exchangeability](#). *Annals of Statistics*, 51(2).
- Basel Committee on Banking Supervision (1996). [Supervisory framework for the use of “backtesting” in conjunction with the internal models approach to market risk capital requirements](#). Bank for International Settlements.
- Basel Committee on Banking Supervision (2019). [Minimum capital requirements for market risk](#) (rev. February 2019). Bank for International Settlements.
- Bayer, S., Dimitriadis, T. (2022). [Regression-based expected shortfall backtesting](#). *Journal of Financial Econometrics*, 20(3), 437–471.
- Christoffersen, P.F. (1998). [Evaluating interval forecasts](#). *International Economic Review*, 39(4), 841–862.
- Christoffersen, P., Pelletier, D. (2004). [Backtesting value-at-risk: a duration-based approach](#). *Journal of Financial Econometrics*, 2(1), 84–108.

Bibliografie (2/5)

- Diebold, F.X., Mariano, R.S. (1995). [Comparing predictive accuracy](#). *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Du, Z., Escanciano, J.C. (2017). [Backtesting expected shortfall: accounting for tail risk](#). *Management Science*, 63(4), 940–958.
- Ehm, W., Gneiting, T., Jordan, A., Krüger, F. (2016). [Of quantiles and expectiles: consistent scoring functions, Choquet representations and forecast rankings](#). *Journal of the Royal Statistical Society, Series B*, 78(3), 505–562.
- Engle, R.F., Manganelli, S. (2004). [CAViaR: conditional autoregressive value at risk by regression quantiles](#). *Journal of Business & Economic Statistics*, 22(4), 367–381.
- Escanciano, J.C., Olmo, J. (2010). [Backtesting parametric value-at-risk with estimation risk](#). *Journal of Business & Economic Statistics*, 28(1), 36–51.
- Fissler, T., Ziegel, J.F. (2016). [Higher order elicibility and Osband's principle](#). *Annals of Statistics*, 44(4).
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- Giacomini, R., White, H. (2006). [Tests of conditional predictive ability](#). *Econometrica*, 74(6), 1545–1578.

Bibliografie (3/5)

- Gibbs, I., Candès, E. (2021). [Adaptive conformal inference under distribution shift](#). *Advances in Neural Information Processing Systems*, 34; arXiv:2106.00170.
- Gibbs, I., Cherian, J.J., Candès, E.J. (2025). [Conformal prediction with conditional guarantees](#). *Journal of the Royal Statistical Society, Series B*, 87(4), 1100–1126.
- Gneiting, T. (2011). [Making and evaluating point forecasts](#). *Journal of the American Statistical Association*, 106(494), 746–762.
- Hansen, P.R., Lunde, A., Nason, J.M. (2011). [The model confidence set](#). *Econometrica*, 79(2), 453–497.
- Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (eds.) (2017). [Applied Quantitative Finance](#), 3rd ed. Springer.
- Hoga, Y., Demetrescu, M. (2023). [Monitoring value-at-risk and expected shortfall forecasts](#). *Management Science*, 69(5), 2954–2971.
- Kratz, M., Lok, Y.H., McNeil, A.J. (2018). [Multinomial VaR backtests: a simple implicit approach to backtesting expected shortfall](#). *Journal of Banking & Finance*, 88, 393–407.
- Kupiec, P.H. (1995). [Techniques for verifying the accuracy of risk measurement models](#). *Journal of Derivatives*, 3(2), 73–84.

Bibliografie (4/5)

- Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R.J., Wasserman, L. (2018). [Distribution-free predictive inference for regression.](#) *Journal of the American Statistical Association*, 113(523), 1094–1111.
- McNeil, A.J., Frey, R. (2000). [Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach.](#) *Journal of Empirical Finance*, 7(3–4), 271–300.
- Newey, W.K., West, K.D. (1987). [A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix.](#) *Econometrica*, 55(3), 703–708.
- Nolde, N., Ziegel, J.F. (2017). [Elicitability and backtesting: perspectives for banking regulation.](#) *Annals of Applied Statistics*, 11(4).
- Patton, A.J., Ziegel, J.F., Chen, R. (2019). [Dynamic semiparametric models for expected shortfall \(and value-at-risk\).](#) *Journal of Econometrics*, 211(2), 388–413.
- Pele, D.T., Lazar, E., Dufour, A. (2017). [Information entropy and measures of market risk.](#) *Entropy*, 19(5), 226.
- Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). [Modeling expected shortfall using tail entropy.](#) *Entropy*, 21(12), 1204.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). [Using high-frequency entropy to forecast Bitcoin's daily value at risk.](#) *Entropy*, 21(2), 102.

Bibliografie (5/5)

- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). [Finite-sample precision limits for expected shortfall forecast comparisons](#). *Mathematics*, 14(13), 2316.
- Zaffran, M., Féron, O., Goude, Y., Josse, J., Dieuleveut, A. (2022). [Adaptive conformal predictions for time series](#). *Proceedings of the 39th International Conference on Machine Learning*; arXiv:2202.07282.