









Modelarea piețelor financiare

Capitolul 8: Backtesting și evaluarea prognozelor de risc



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Cum aflăm dacă o prognoză de risc este utilă?

Trei grupuri de întrebări

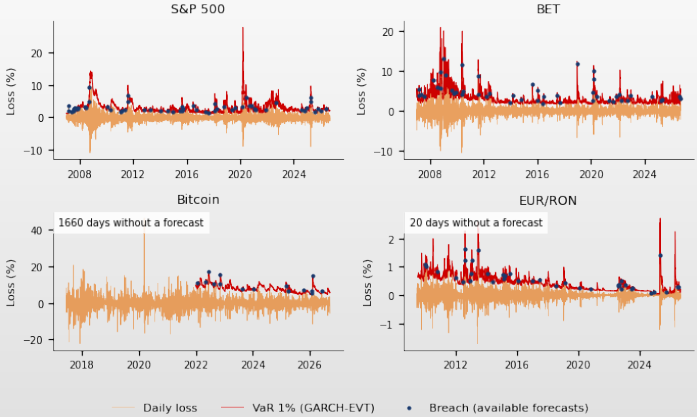
- **Calibrare**
  - este o prognoză VaR (Value-at-Risk) sau ES (Expected Shortfall) corectă, zi de zi?
  - poate un backtest să o arate?
- **Comparație**
  - care dintre mai multe prognoze este mai bună?
  - este diferența semnificativă?
- **Decizie**: ce putem concluziona cînd coada conține doar cîteva zile pe an?

Ce trebuie să poți face

- să testezi numărul și momentul depășirilor VaR și să precizezi mărimea și puterea fiecărui test pentru T-ul de care dispui
- să testezi ES cu reziduuri, cu Z_2 prin simulare și cu statistici construite pe PIT (probability integral transform, transformarea integrală a probabilității)
- să ierarhizezi prognozele (VaR, ES) cu un scor consistent, cu teste DM (Diebold–Mariano) și cu MCS (model confidence set, mulțimea de încredere a modelelor)
- să apreciezi ce garantează și ce nu garantează un VaR fără ipoteze de distribuție (conformal)

Exerciții rezolvate: Seminarul 8, A1 (Kupiec), A2 (Christoffersen), A4 (Z_2), B2 (FZ0 și DM); lecturi și demonstrații: ▸ Anexă

Patru piețe, un model de risc (1/2)



MFM_ch8_four_assets

Patru piețe, un model de risc (2/2)

- Pe grafic: pierderile zilnice (portocaliu), VaR 1% prognozat de GARCH-EVT (roșu) și depășirile, adică zilele cu $L_t > \mathrm{VaR}_t$ (puncte albastre)
- VaR urmează volatilitatea: se dublează sau se triplează în 2008, martie 2020 și la crahul cripto din 2022
- Rata de depășire a VaR 1% GARCH-EVT: 1,15% pe S&P 500 și 0,97% pe BET (țința: 1%)
- Pe Bitcoin și EUR/RON, o parte din prognozele GARCH sînt reținute (slide-ul despre prognozele reținute)
- EUR/RON are o scară mult mai mică: un curs în regim de managed float, perioade lungi de calm, salturi rare
- Întrebarea capitolului: este suficientă o rată apropiată de 1% pentru a considera un model adecvat?

MFM_ch8_four_assets

Pierderi, VaR și ES: ce testăm

- **Backtesting**: compararea prognozelor de risc făcute cu informația $\mathcal{F}_{t-1}$ cu rezultatele care au urmat
  - $\mathcal{F}_{t-1}$: tot ce se cunoaște la închiderea zilei $t-1$
- Randamentul logaritmic zilnic: $X_t = r_t = \ln(P_t/P_{t-1})$, unde P_t este prețul de închidere din ziua t; **pierderea** zilnică: $L_t = -r_t$ (o valoare pozitivă indică o pierdere)
- **VaR** (valoarea expusă la risc): pierderea depășită cu probabilitatea α, adică cuantila q_α a randamentului, cu semn schimbat (Capitolul 7)
  - $\mathrm{VaR}_\alpha(X) = -\inf\{x : P(X \le x) > \alpha\} = -q_\alpha(X)$; inf: cel mai mic x în care funcția de repartiție depășește α
  - echivalent, cuantila de ordin $1-\alpha$ a pierderii L_t
  - de exemplu, VaR 1% = 3%: pierderea ar trebui să depășească 3% în aproximativ o zi din 100
- **ES** (pierderea așteptată în coadă): media cuantilelor q_u pe toate nivelurile cozii $u \le \alpha$, adică pierderea medie dincolo de VaR
  - $\mathrm{ES}_\alpha(X) = -\frac{1}{\alpha}\int_0^\alpha q_u(X)\,du = E\left[L_t \mid L_t > \mathrm{VaR}_\alpha\right]$ (cazul continuu)
  - de exemplu, pierderi Student-t cu $\nu = 4$, abaterea standard 1% și $\alpha = 2{,}5\%$: VaR = 1,96%, ES = 2,82%
  - întotdeauna $\mathrm{ES} \ge \mathrm{VaR}$

Depășirile și ce implică un VaR corect

- Nivelurile sînt probabilități de coadă: VaR 1% ($\alpha = 0{,}01$), VaR 2,5% și ES 2,5% ($\alpha = 0{,}025$)
  - backtesting-ul folosește prognoze la o zi
- O **depășire** (excepție) are loc cînd pierderea depășește prognoza
  - $I_t = 1\{L_t > \mathrm{VaR}_t\}$, cu rata țintă α
  - $1\{\cdot\}$: indicatorul, egal cu 1 dacă are loc condiția și cu 0 altfel
  - VaR_t: prognoza făcută în ziua $t-1$ pentru ziua t
- **Calibrarea condiționată** ideală: indiferent de ce știam ieri, probabilitatea unei depășiri azi este exact α (Christoffersen (1998))
  - $P(I_t = 1 \mid \mathcal{F}_{t-1}) = \alpha$ pentru orice t, deci I_t sînt Bernoulli(α) i.i.d.: aruncări independente ale unei monede care dau 1 cu probabilitatea α
- Două consecințe testabile
  - **Acoperire necondiționată**: aproximativ αT depășiri în T zile
  - **Independență**: depășirile nu se grupează

Șase metode de prognoză a pierderilor extreme

Model	VaR și ES la o zi din
HS	simularea istorică (historical simulation): cuantila empirică de ordin $1-\alpha$ a ultimelor 1 000 de pierderi
Normal	distribuția Normală cu media și abaterea standard din fereastră
Student-t	o distribuție Student-t estimată pe fereastră (locație, scală, grade de libertate ν)
GARCH-t	GARCH (heteroscedasticitate condiționată autoregresivă generalizată, Capitolul 5): $\sigma_t^2 = \omega + a\,\varepsilon_{t-1}^2 + b\,\sigma_{t-1}^2$, cu $\varepsilon_{t-1} = r_{t-1} - \mu$; a: reacția la șocul de ieri; b: persistența; șocuri Student-t
FHS	HS filtrată (filtered historical simulation): volatilitatea GARCH $\times$ cuantilele empirice ale lui $z_t = \varepsilon_t/\sigma_t$
GARCH-EVT	coadă EVT (extreme value theory, teoria valorilor extreme): volatilitatea GARCH $\times$ o coadă GPD (Pareto generalizată) estimată pe cele mai mari 10% pierderi standardizate (McNeil & Frey (2000))

- **Necondiționate** (HS, Normal, Student-t): o singură distribuție pentru întreaga fereastră de 1 000 de zile; toate zilele din fereastră au aceeași pondere, deci prognoza reacționează lent la un salt al volatilității
- **Condiționate** sau **filtrate** (GARCH-t, FHS, GARCH-EVT): o scală σ_t actualizată zilnic prin GARCH $\times$ o coadă standardizată

Cum evaluăm prognozele?

- Patru serii, fiecare pe propriul calendar
  - S&P 500 și BET (indicele Bursei de Valori București): închideri
  - Bitcoin: închideri (se tranzacționează în fiecare zi)
  - EUR/RON: cursul de referință BNR (Banca Națională a României)
- Fereastră mobilă de 1 000 de observații
  - fiecare prognoză folosește doar datele pînă în ziua precedentă
- Reestimare la fiecare 20 de zile
  - pentru parametrii GARCH, Student-t și EVT
  - volatilitatea se actualizează zilnic
- Zile de evaluare T, pînă la 18.09.2026
  - S&P 500 și BET (din 2007): 4 959, respectiv 4 937 de zile
  - EUR/RON (din 2009): 4 352 de zile
  - Bitcoin (din 2017): 3 384 de zile

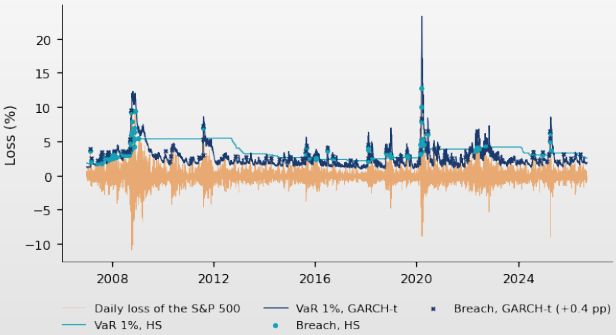
Prognozele GARCH reținute pe Bitcoin și EUR/RON

- Raportăm prognozele GARCH-t, FHS și GARCH-EVT doar în zilele în care estimarea GARCH dă un VaR finit
- Bitcoin: 1 660 din 3 384 de zile de evaluare nu au o astfel de prognoză
- EUR/RON: 20 din 4 352 de zile de evaluare nu au o astfel de prognoză
- Pe aceste două piețe, rezultatele pe eșantionul complet se raportează doar pentru HS, Normal și Student-t
- MCS nu se calculează pe Bitcoin și EUR/RON, deoarece cere toate cele șase modele
- Comparațiile care includ modelele GARCH folosesc S&P 500 și BET, unde toate prognozele există
- În tabele, „n/a" marchează un rezultat GARCH reținut; graficele îl marchează cu „—"

Capacitatea de identificare a unui backtest

- Fiecare backtest verifică o consecință a calibrării condiționate
  - testul Kupiec verifică rata depășirilor
  - testul Christoffersen verifică memoria de ordinul întîi
  - testele de durată verifică distanțele dintre depășiri
  - testul DQ (Dynamic Quantile) verifică dacă depășirile pot fi prezise din regresorii aleși
- H_0 este o ipoteză **comună** despre întreaga procedură de prognoză
  - distribuția, dinamica volatilității, parametrii estimați, lungimea ferestrei și regula de reestimare
  - O respingere nu indică ce componentă este greșit specificată
- Un singur rezultat pe zi: dovezile se acumulează doar pe multe zile
  - limitele χ^2 din manuale tratează VaR_t ca fiind cunoscut
- Nerespingerea nu înseamnă validare: este informativă doar dacă testul are putere împotriva alternativelor relevante, la T disponibil

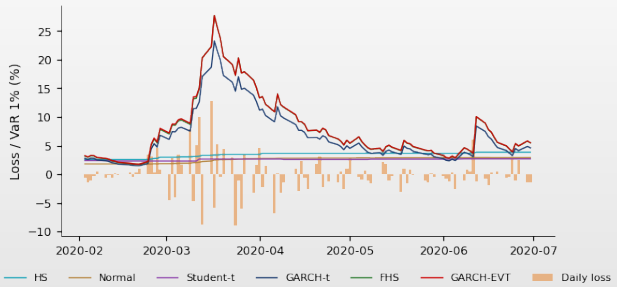
S&P 500: două prognoze VaR, 2007–2026



- Pe grafic: VaR 1% al HS (turcoaz) și al GARCH-t (albastru), pierderile zilnice (portocaliu) și depășirile fiecărui model (marcaje)
- HS este o funcție în trepte
  - se modifică brusc doar cînd zile extreme intră în fereastra de 1 000 de zile sau ies din ea
  - GARCH-t crește din ziua următoare creșterii volatilității
- Numărul depășirilor este aproape același: 83 pentru HS și 88 pentru GARCH-t, în 4 959 de zile
- Numere apropiate pot ascunde momente diferite
  - depășirile HS apar în rafale (2008, 2020)
  - deci trebuie testat și **cînd** apar depășirile

MFM_ch8_var_forecasts

Martie 2020: un test de stres neplanificat



- S&P 500, februarie–iunie 2020: pierderile zilnice (bare) și VaR 1% al celor șase modele
- Cea mai mare pierdere: 12,77%, la 16.03.2020
  - un VaR 1% corect are 1,04 depășiri așteptate în aceste 104 zile
- Numărul depășirilor observate
  - modelele necondiționate: HS 12, Normal 17, Student-t 17
  - modelele condiționate: GARCH-t 3, FHS 2, GARCH-EVT 2
- Volatilitatea curentă a contat mai mult decît forma cozii
  - o coadă groasă fără scală variabilă în timp (Student-t) nu a îmbunătățit prognoza

MFM_ch8_var_forecasts

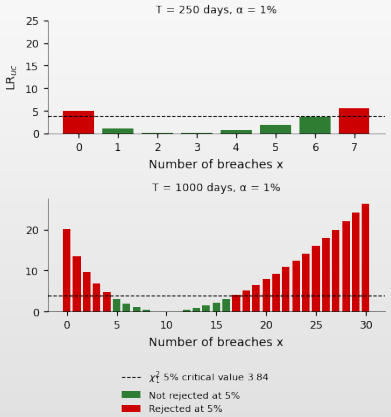
Kupiec (1995): testul POF (proportion of failures, proporția depășirilor)

- Date: $x = \sum_t I_t$ depășiri în T zile
  - rata estimată de depășire: $\hat{\pi} = x/T$
- H_0: $\pi = \alpha$ (acoperire necondiționată corectă), față de H_1: $\pi \neq \alpha$
  - π: probabilitatea reală de depășire
- Statistica raportului de verosimilitate (Kupiec (1995)): compară verosimilitatea Binomială a numărului observat sub α cu cea sub rata observată $\hat{\pi}$
  - $\mathrm{LR}_{uc} = -2 \ln \dfrac{(1-\alpha)^{T-x}\alpha^x}{(1-\hat{\pi})^{T-x}\hat{\pi}^x} \xrightarrow{d} \chi^2_1$
  - $\mathrm{LR}_{uc} \geq 0$ este egală cu 0 cînd $\hat{\pi} = \alpha$ și crește pe măsură ce $\hat{\pi}$ se îndepărtează de α
  - $\xrightarrow{d} \chi^2_1$: pentru T mare, distribuția ei sub H_0 este chi-pătrat cu 1 grad de libertate
- Respingem la 5% dacă $\mathrm{LR}_{uc} > 3{,}84$
  - testul este bilateral: și un număr prea mic de depășiri duce la respingere
  - pentru T mic folosim distribuția Binomială(T, α) exactă a lui x
- Exemplu numeric: S&P 500, GARCH-t, anul 2008
  - $x = 8$ depășiri în $T = 253$ zile, față de 2,53 așteptate
  - $\mathrm{LR}_{uc} = 7{,}60$, cu $p = 0{,}0058$
  - p-value-ul Binomial exact: $2P(X \geq 8) = 0{,}009$

Ce probabilitate însumează acest p-value?

- „Prea multe depășiri?" este o întrebare unilaterală: îi răspunde coada superioară Binomială
- Acoperirea corectă este o întrebare bilaterală: și o prognoză prea prudentă este respinsă
- p-value-ul bilateral al exemplului dublează coada superioară
- Pentru regula raportului de verosimilitate, însumăm probabilitățile Binomiale ale tuturor numerelor de depășiri care duc la respingere: obținem mărimea efectivă sub H_0 și puterea sub o alternativă
- Cu numere discrete de depășiri, nicio regulă nu are mărimea exact 5%: fixăm regula înainte de a compara p-value-uri

Numărul acceptabil de depășiri (1/2)



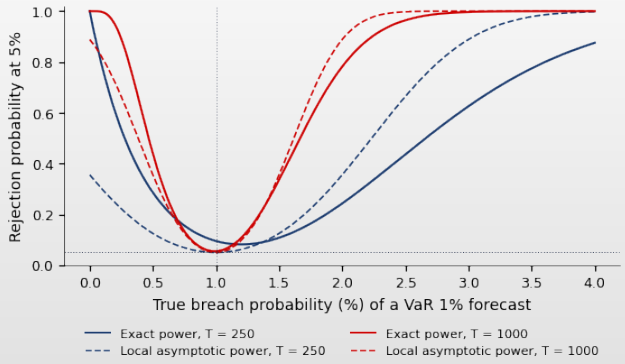
MFM_ch8_kupiec

Numărul acceptabil de depășiri (2/2)

- LR_{uc} în funcție de numărul de depășiri x, un an (sus) și patru ani (jos) de VaR 1%
- Testul acceptă între 1 și 6 depășiri într-un an ($T = 250$) și între 5 și 16 în patru ani ($T = 1000$)
- Chiar și $x = 0$ este respins pe un an
  - $\mathrm{LR}_{uc} = -500 \ln 0{,}99 = 5{,}03$: un VaR niciodată depășit este prea conservator
- Un an conține aproximativ 2,5 zile informative pentru VaR 1%
  - folosim eșantioane lungi, două niveluri ($\alpha = 1\%$ și 2,5%) și mai multe teste

MFM_ch8_kupiec

Puterea testului POF



- Probabilitatea de respingere la 5% în funcție de rata reală de depășire
  - linia continuă: calculul Binomial exact
  - linia întreruptă: aproximarea locală $\chi^2_1(\lambda)$, cu $\lambda = T(\pi - \alpha)^2/(\alpha(1-\alpha))$
- $T = 250$, rata reală $\pi = 2\%$
  - puterea după aproximarea locală este 36%, iar puterea exactă este 24%
  - o rată de depășire dublă nu este respinsă în trei ani din patru
- Regula $\mathrm{LR}_{uc} > 3{,}84$ are mărimea efectivă 9,5% la $T = 250$
  - numai evenimentul $x = 0$ are deja probabilitatea $P(x = 0) = 8{,}1\%$
  - deci regula nu este un test exact de 5%
- Pentru o putere de 50% este nevoie de
  - $\pi \approx 2{,}7\%$ la $T = 250$, respectiv $\pi \approx 1{,}7\%$ la $T = 1000$

MFM_ch8_kupiec

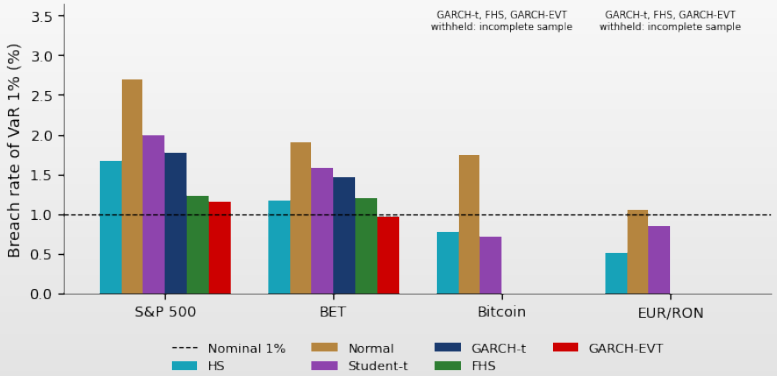
Puterea testului POF: alternative locale

- Alternative locale: rata reală se apropie de α cînd T crește
  - $\pi_T = \alpha + h/\sqrt{T}$, h: o distanță fixă pe scara $\sqrt{T}$
- Sub aceste alternative, statistica POF este aproximativ χ^2 necentrată
  - $\mathrm{LR}_{uc} = \dfrac{T(\hat{\pi}-\alpha)^2}{\alpha(1-\alpha)} + o_p(1) \xrightarrow{d} \chi^2_1(\lambda), \qquad \lambda = \dfrac{T(\pi-\alpha)^2}{\alpha(1-\alpha)}$
  - $o_p(1)$: un termen care tinde în probabilitate la 0 cînd $T \to \infty$
  - λ: parametrul de necentralitate; crește cu T și cu pătratul abaterii $(\pi-\alpha)^2$
- Interpretare
  - puterea $= P(\chi^2_1(\lambda) > 3{,}84)$: λ mai mare înseamnă putere mai mare
  - pentru $T = 250$ și $\pi = 2\%$ obținem $\lambda = 2{,}53$
  - un an cu rată dublă dă deci un λ mic

Puterea locală, calculată de mînă

- $\chi^2_1(\lambda)$ este legea lui $(Z+\sqrt{\lambda})^2$, cu $Z \sim N(0,1)$, iar $3{,}84 = 1{,}96^2$, deci
  - puterea $= P(|Z+\sqrt{\lambda}| > 1{,}96) = \Phi(\sqrt{\lambda} - 1{,}96) + \Phi(-\sqrt{\lambda} - 1{,}96)$, unde Φ este funcția de repartiție $N(0,1)$
- $T = 250$, $\pi = 2\%$: $\lambda = 2{,}525$, $\sqrt{\lambda} = 1{,}589$
  - puterea $= \Phi(-0{,}371) + \Phi(-3{,}549) = 0{,}355 + 0{,}0002 = 0{,}356$, adică cele 36% ale curbei întrerupte
- Puterea exactă este mai mică, 24%: testul acceptă între 1 și 6 depășiri, eveniment cu probabilitatea 75,7% cînd $\pi = 2\%$
  - cu 2,5 depășiri așteptate pe an, numărul este prea discret și prea asimetric pentru aproximarea Normală din spatele lui $\chi^2_1(\lambda)$

Ratele de depășire pe modele și piețe



MFM_ch8_var_forecasts

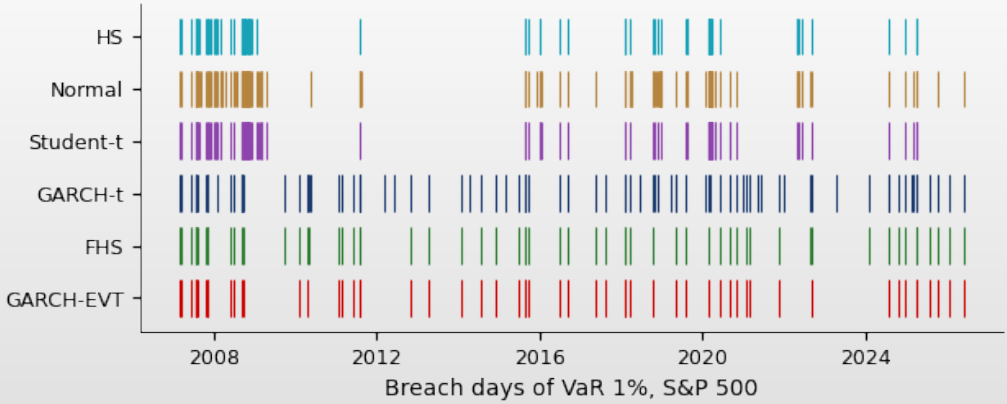
Interpretarea ratelor de depășire

- Pe grafic: ponderea zilelor cu $L_t > \mathrm{VaR}_t$, pentru VaR 1%
- Modelul Normal este respins pe S&P 500 (2,70%), BET (1,90%) și Bitcoin (1,74%), dar nu pe EUR/RON
- Aceeași volatilitate GARCH-t, altă coadă: pe S&P 500 și BET, GARCH-t are rate de 1,77%, respectiv 1,46%, iar FHS are 1,23%, respectiv 1,20%
- Datele pun sub semnul întrebării coada t simetrică
- HS este prea conservator pe EUR/RON (0,51%): o criză veche din fereastră îi menține VaR ridicat

Christoffersen (1998): testarea independenței

- Modelăm I_t ca lanț Markov de ordinul întîi, cu $\pi_{ij} = P(I_t = j \mid I_{t-1} = i)$
- Numărăm tranzițiile n_{ij} (din starea i ieri în starea j azi)
  - estimăm $\hat{\pi}_{01} = \frac{n_{01}}{n_{00}+n_{01}}$ și $\hat{\pi}_{11} = \frac{n_{11}}{n_{10}+n_{11}}$
- H_0: $\pi_{01} = \pi_{11} = \pi$ (fără memorie), cu $\hat{\pi} = (n_{01} + n_{11})/\sum n_{ij}$
- Statistica: numărătorul = verosimilitatea cu o singură probabilitate de depășire; numitorul = verosimilitatea cu o probabilitate care depinde de starea de ieri
  - $\mathrm{LR}_{ind} = -2 \ln \frac{(1-\hat{\pi})^{n_{00}+n_{10}} \hat{\pi}^{n_{01}+n_{11}}}{(1-\hat{\pi}_{01})^{n_{00}} \hat{\pi}_{01}^{n_{01}} (1-\hat{\pi}_{11})^{n_{10}} \hat{\pi}_{11}^{n_{11}}} \xrightarrow{d} \chi_1^2$
  - Statistica este mare cînd $\hat{\pi}_{11}$ (depășire după depășire) diferă de $\hat{\pi}_{01}$ (depășire după o zi fără depășire)
  - respingem la 5% dacă depășește 3,84
- Acoperirea condiționată: $\mathrm{LR}_{cc} = \mathrm{LR}_{uc} + \mathrm{LR}_{ind} \xrightarrow{d} \chi_2^2$ testează ambele proprietăți simultan (2 grade de libertate, valoarea critică la 5%: 5,99)

Momentele depășirilor (1/2)



MFM_ch8_coverage_tests

Momentele depășirilor (2/2)

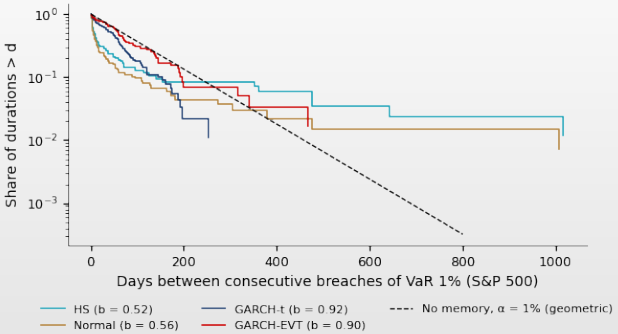
- Fiecare linie marchează o depășire a VaR 1% pe S&P 500
- HS, Normal și Student-t au depășiri în rafale: 2008, 2015–2016, 2018, 2020, 2022
- La modelele filtrate (GARCH), nu apar rafale de mai multe luni, dar rămîn cîteva depășiri în zile consecutive
- Un test pe subeșantion poate rata gruparea: HS, 2007–2010
  - tranzițiile: $n_{\mathbf{00}} = 928$, $n_{\mathbf{01}} = 38$, $n_{\mathbf{10}} = 38$, $n_{\mathbf{11}} = 3$
  - $\hat{\pi}_{\mathbf{11}} = 0{,}0732$, față de $\hat{\pi}_{\mathbf{01}} = 0{,}0393$, totuși $\mathrm{LR}_{ind} = 0{,}95$, cu $p = 0{,}33$
  - motivul: $\hat{\pi}_{\mathbf{11}}$ se sprijină doar pe 3 perechi
- Pe întreg eșantionul, p-value-urile LR_{ind}: HS $<$0,001, Normal $<$0,001, Student-t $<$0,001, GARCH-EVT 0,031, FHS 0,046, GARCH-t 0,095
  - independența este respinsă la 5% pentru toate modelele, cu excepția GARCH-t
  - la GARCH-EVT, o depășire urmează unei depășiri cu probabilitatea 0,053, față de 0,011 după o zi fără depășire
  - testul comun CC nu respinge GARCH-EVT ($p = 0{,}058$): componenta de acoperire, corectă, diluează semnalul
  - o nerespingere pe un subeșantion nu este un verdict pe întreg eșantionul

MFM_ch8_coverage_tests

Teste bazate pe durate

- Durata D_i: numărul de zile dintre depășirea $i-1$ și depășirea i
- Pentru un VaR corect, depășirile nu au memorie: D_i urmează distribuția geometrică, cu media $1/\alpha$ (100 de zile pentru $\alpha = 1\%$)
- Christoffersen & Pelletier (2004): aproximăm duratele discrete printr-un model Weibull continuu
  - $f(D; a, b) = a^b\, b\, D^{b-1} e^{-(aD)^b}$: densitatea Weibull a unei durate
  - $a > 0$: rata (inversul scalei); $b > 0$: forma
  - $b = 1$ este cazul exponențial (fără memorie)
  - $b < 1$: duratele scurte sînt prea frecvente, adică depășirile se grupează
- H_0: $b = 1$ cu a liber: un test al raportului de verosimilitate (χ^2_1) pentru lipsa memoriei
  - nu testează media $1/\alpha$: acoperirea rămîne în seama testului Kupiec
  - prima și ultima durată sînt cenzurate
- Folosește întreaga structură a distanțelor: la $T \geq 1\,000$ detectează gruparea mai bine decît testul Christoffersen; la $T = 250$ nu (tabelul Monte Carlo)

Durata dintre depășiri



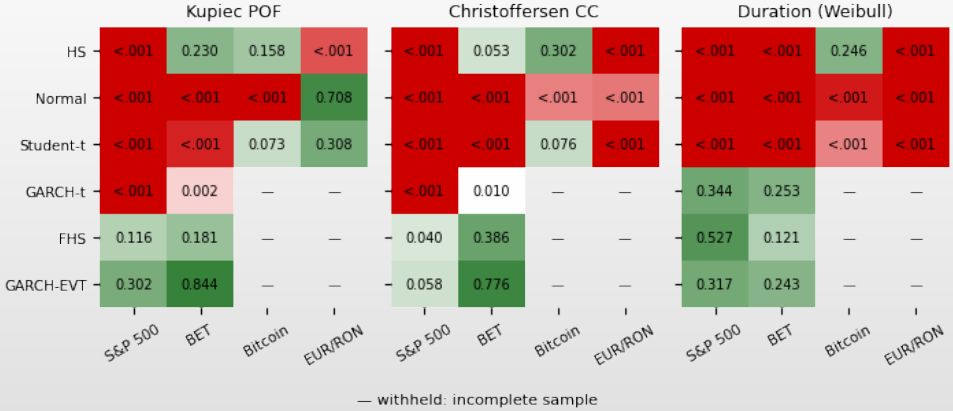
- Ponderea duratelor mai lungi decît d (scală logaritmică); linia punctată: fără memorie, cu $\alpha = 1\%$
- HS: $b = 0{,}52$, p <0,001
  - durata mediană: 7 zile
  - 44% dintre durate au cel mult 5 zile
- Normal: $b = 0{,}56$
- GARCH-t: $b = 0{,}92$, durata mediană 45 de zile, $p = 0{,}344$
- GARCH-EVT: $b = 0{,}90$, $p = 0{,}317$
- Coada lungă a duratelor HS: ani fără depășiri după ce o criză lasă un VaR ridicat în fereastră

MFM_ch8_coverage_tests

Backtesting prin regresie: testul DQ

- Sub acoperirea condiționată corectă, $\mathrm{Hit}_t = I_t - \alpha$ (indicatorul depășirii, centrat) este o diferență de martingal, adică imprevizibil din trecut: $E[\mathrm{Hit}_t \mid \mathcal{F}_{t-1}] = 0$, $\mathrm{Var}(\mathrm{Hit}_t \mid \mathcal{F}_{t-1}) = \alpha(1-\alpha)$
- Deci nicio variabilă măsurabilă în $\mathcal{F}_{t-1}$ nu îl poate prezice: regresăm $\mathrm{Hit}_t = X_t\beta + u_t$ cu $X_t = (1, \mathrm{Hit}_{t-1}, \ldots, \mathrm{Hit}_{t-4}, \mathrm{VaR}_t)$ și testăm $\beta = 0$
- Statistica Dynamic Quantile (Engle & Manganelli (2004), forma Wald cu dispersia sub H_0)
  - $\mathrm{DQ} = \dfrac{\hat\beta' X'X \hat\beta}{\alpha(1-\alpha)} = \dfrac{\mathrm{Hit}' X (X'X)^{-1} X' \mathrm{Hit}}{\alpha(1-\alpha)} \xrightarrow{d} \chi^2_6$
  - X: matricea $T \times 6$ a regresorilor, Hit: vectorul depășirilor centrate
  - $\hat\beta$: estimatorul OLS (metoda celor mai mici pătrate), u_t: eroarea regresiei
  - DQ este suma pătratelor explicată, scalată cu dispersia sub H_0, cu 6 grade de libertate (cîte unul pentru fiecare regresor)
  - un DQ mare indică depășiri previzibile
- Are drept cazuri particulare testele Kupiec și Christoffersen
  - cu $X_t = 1$ obținem forma scor $T(\hat\pi - \alpha)^2/(\alpha(1-\alpha))$
  - cu $X_t = (1, \mathrm{Hit}_{t-1})$ obținem un analog cu 2 grade de libertate al testului de acoperire condiționată Christoffersen: asimptotic echivalent cu LR_{cc}, dar nu egal numeric
  - testarea doar a coeficientului lagului corespunde lui LR_{ind}
  - adaugă putere împotriva memoriei dincolo de lagul 1 și a depășirilor care depind de nivelul VaR

Sinteza testelor VaR (1/2)



MFM_ch8_coverage_tests

Sinteza testelor VaR (2/2)

- Graficul: p-value-urile testelor Kupiec POF, de acoperire condiționată (CC, conditional coverage) și de durată (Weibull), pentru VaR 1% (roșu: respingere, verde: nerespingere; „—": prognoză GARCH reținută)
- Testul DQ (care nu apare în grafic) respinge toate modelele pe S&P 500, inclusiv FHS (p <0,001) și GARCH-EVT (p <0,001); pe BET nu respinge FHS ($p = 0{,}200$) și GARCH-EVT ($p = 0{,}279$)
  - depășirile sînt previzibile din nivelul VaR și din depășirile trecute, o abatere pe care simpla numărare nu o detectează
- Teste diferite examinează abateri diferite: interpretăm tabloul de ansamblu, nu un singur p-value
  - modelele necondiționate sînt respinse de testul duratelor aproape peste tot
  - GARCH-EVT nu este respins de testele de acoperire condiționată sau de durată pe BET

MFM_ch8_coverage_tests

Mărimea și puterea testelor VaR: un experiment Monte Carlo

- DGP (procesul generator al datelor, adevărul simulat): GARCH(1,1)-t estimat pe S&P 500 1990–2026 ($a = 0{,}102$, $b = 0{,}892$, $\nu = 6{,}1$)
- Simulăm 1 000 de traiectorii și raportăm ratele de respingere (%) ale testelor la 5%, pentru VaR 1%

Prognoza	T	POF	Acop. cond.	Durate	DQ
Corect (mărime)	250	**9,7**	1,1	15,0	8,6
	1 000	6,4	3,3	8,0	11,0
	5 000	4,9	3,4	4,6	**8,8**
Normal-GARCH (putere)	250	**10,6**	4,8	14,8	18,8
	1 000	30,2	19,9	8,2	30,2
	5 000	83,7	77,2	7,3	70,7
HS, 1 000 de zile (putere)	250	51,5	17,0	**12,0**	32,5
	1 000	46,4	46,9	68,3	73,8
	5 000	57,1	86,6	100,0	99,5

MFM_ch8_size_power

Mărimea și puterea testelor VaR: interpretarea tabelului

- Cele trei prognoze
  - Corect: parametrii și σ_t adevărați (rata de respingere = mărimea)
  - Normal-GARCH: σ_t adevărat, coadă Normală (rata de respingere = puterea)
  - HS, 1 000 de zile: fără dinamica volatilității (rata de respingere = puterea)
- Convenții
  - un p-value nedefinit al testului de durată (sub 3 durate, 28% din eșantioanele corecte la $T = 250$) se numără ca nerespingere
  - eroarea standard Monte Carlo: 0,7 puncte procentuale la 5%, 1,6 la 50% și 0,9 la valoarea observată 9,7% din celula POF cu aldine
- Celulele cu aldine
  - într-un an, o coadă Normală pe volatilitatea corectă este aproape invizibilă
  - gruparea depășirilor HS este rar detectată de testul duratelor la $T = 250$
  - DQ respinge prea des un model corect chiar la $T = 5000$: îi simulăm valorile critice

Backtesting sub riscul de estimare

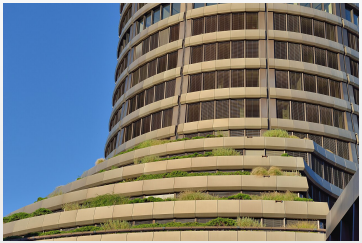
- Prognozele folosesc estimarea parametrilor $\hat{\theta}$ obținută pe R zile, iar testul folosește P zile în afara eșantionului
  - de aceea depășirile $\hat{I}_t = 1\{L_t > \mathrm{VaR}_t(\hat{\theta})\}$ nu sînt Bernoulli(α) nici sub un model corect
- Corecția depinde de schema de prognoză (fixă, mobilă, recursivă) și crește cu P/R (Escanciano & Olmo (2010); dezvoltarea în Anexă)
- Schema fixă, 400 de traiectorii GARCH(1,1)-t, $R = 1000$: estimarea este admisibilă pe 324 de traiectorii, iar pe 76 nu (rezultatele simulării)
- O rată de respingere calculată doar pe cele 324 de traiectorii admisibile este condiționată de succesul estimării: Seminarul 8, B9 o calculează și discută această selecție
- Capitolul folosește o fereastră mobilă ($R = 1000$, reestimare la fiecare 20 de zile); un experiment cu schemă fixă nu măsoară mărimea acestor teste cu fereastră mobilă
- Remediul: reproducem estimarea în calibrare, de exemplu printr-un bootstrap parametric care reestimează modelul pe fiecare traiectorie simulată (Seminarul 8, B9)

Semaforul: o regulă de numărare Binomială

Excepții	$P(X \leq x)$	Zona
0	8,11%	verde
2	54,32%	verde
4	89,22%	verde
5	95,88%	galben
7	99,60%	galben
9	99,97%	galben
10	99,99%	roșu

- Băncile cu modele interne testează zilnic VaR 1% (Comitetul de la Basel pentru Supraveghere Bancară, BCBS (1996))
  - față de profitul și pierderea (P&L) efective din ultimele 250 de zile
- $X \sim$ Binomială$(250; 0{,}01)$: excepțiile unui VaR 1% corect în 250 de zile
- Zona galbenă începe unde $P(X \leq x) \geq 95\%$, cea roșie unde $P(X \leq x) \geq 99{,}99\%$
- Contează doar **numărul** excepțiilor, nu mărimea sau momentul lor: simplu, automat, greu de manipulat

Regulile de backtesting din 1996 și 2019

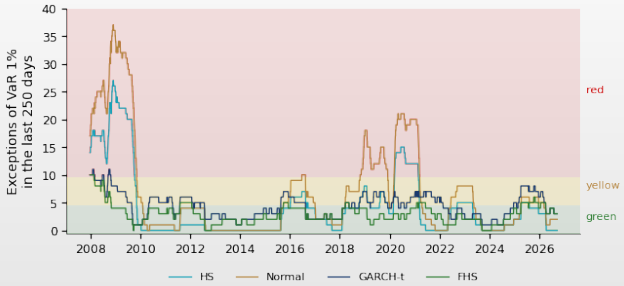


Turnul BIS (Bank for International Settlements), Basel: sediul secretariatului BCBS

Foto: Taxiarchos228 (2014); Free Art License; Wikimedia Commons

- BCBS (1996): capital pe VaR 1% pe 10 zile
  - multiplicatorul 3, plus 0,40–0,85 în zona galbenă și plus 1 în zona roșie
- BCBS (2019) (FRTB, Fundamental Review of the Trading Book): capital pe ES 2,5%, backtesting tot pe VaR
  - la nivelul băncii: VaR 1% pe ultimele 250 de zile
  - multiplicatorul este 1,50 în zona verde (0–4 excepții), 1,70–1,92 în zona galbenă (5–9 excepții) și 2,00 în zona roșie (10 sau mai multe)
  - birou de tranzacționare: peste 12 excepții ale VaR 1% sau 30 ale VaR 2,5% în 12 luni mută biroul la abordarea standardizată
  - aprobarea IMA (internal models approach, abordarea pe modele interne) cere și un test de atribuire a P&L (nediscutat aici)
- Numărarea excepțiilor VaR rămîne pentru că este simplă
  - ES nu este elicitabil (secțiunea „Elicitabilitate și funcții de scor")
  - totuși ES poate fi testat (secțiunea „Backtesting pentru Expected Shortfall")

Semaforul de-a lungul timpului



- Excepțiile VaR 1% în ultimele 250 de zile, S&P 500; benzi: zonele verde, galbenă, roșie
- Ponderea zilelor aflate în zona roșie: Normal 22,3%, HS 14,7%, GARCH-t 2,0%, FHS 0,8%
- Numărul maxim de excepții: 27 pentru HS și 37 pentru Normal
  - atins în cele 250 de zile încheiate la 01.12.2008
  - GARCH-t se află în zona galbenă 46,5% din timp
- Ferestre suprapuse: penalizarea durează un an
  - după o criză, cînd capitalul este deja sub presiune

MFM_ch8_traffic_light

Verificarea FRTB la nivel de birou, ultimele 250 de zile (limitele 12 și 30)

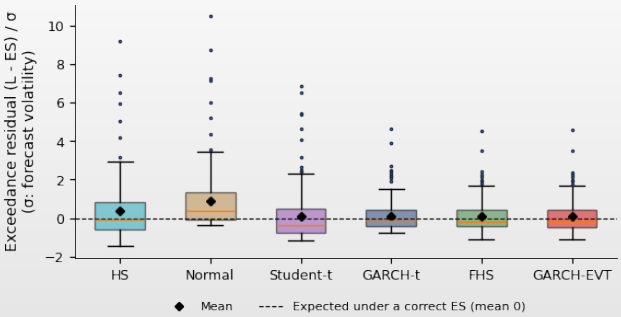
Model	S&P 500	BET	Bitcoin	EUR/RON
HS	0 / 2	4 / 7	3 / 4	1 / 5
Normal	2 / 2	6 / 9	3 / 5	1 / 4
Student-t	0 / 2	4 / 9	1 / 4	5 / 8
GARCH-t	3 / 6	4 / 9	3 / 5	4 / 5
FHS	3 / 4	4 / 6	4 / 5	3 / 4
GARCH-EVT	3 / 3	2 / 7	4 / 5	3 / 4

- Celule: excepții ale VaR 1% / VaR 2,5%
  - ultimele 250 de zile ale fiecărei serii, pînă la 18.09.2026
  - în aceste zile, prognozele GARCH există pe toate cele patru piețe
  - toate modelele se încadrează confortabil în limite
- Doar ilustrativ
  - FRTB aplică limitele P&L-ului birourilor (efectiv și ipotetic), nu randamentelor de indici
- Ultimul an a fost calm
  - o zonă verde în prezent spune puțin despre comportamentul în următoarea criză

McNeil și Frey (2000): reziduurile de depășire

- ES este o **medie** dincolo de VaR: informația provine doar din aproximativ αT zile din coadă
  - 124 zile pentru S&P 500, la $\alpha = 2{,}5\%$
  - 6,25 zile într-un an, deci o eroare standard a mediei din coadă de ordinul $1/\sqrt{\alpha T} \approx 0{,}40$ abateri standard ale pierderilor din coadă
- În fiecare zi de depășire a VaR 2,5%: $e_t = (L_t - \mathrm{ES}_t)/\sigma_t$, unde $\sigma_t > 0$ este volatilitatea prognozată, cunoscută la $t-1$
- Dacă VaR **și** ES sînt corecte: $E[e_t \mid L_t > \mathrm{VaR}_t, \mathcal{F}_{t-1}] = 0$
  - un VaR greșit schimbă evenimentul de condiționare
- H_0: $E[e_t] = 0$ față de H_1: $E[e_t] > 0$ (ES subestimat), cu o statistică t unilaterală
- Reziduurile sînt puține și au cozi groase: p-value-ul se obține printr-un bootstrap i.i.d. al reziduurilor centrate (McNeil & Frey (2000))
  - acest bootstrap presupune reziduuri independente
  - dacă reziduurile sînt dependente, se folosește un bootstrap pe blocuri

Reziduurile de depășire pe S&P 500



- Distribuția lui $(L_t - \mathrm{ES}_t)/\sigma_t$ în zilele de depășire a VaR 2,5% (romburile marchează mediile)
- Mediile reziduurilor: Normal 0,875, HS 0,363, Student-t 0,082, GARCH-t 0,100, FHS 0,104, GARCH-EVT 0,068
- p-value-urile bootstrap
  - Normal $<$0,001, HS $<$0,001, Student-t 0,173, GARCH-t 0,025
  - FHS 0,072, GARCH-EVT 0,157
- Modelul Normal subestimează media din coadă cu aproape o unitate de volatilitate
  - reziduurile extreme, de pînă la 10 volatilități, contează cel mai mult pentru capital

MFM_ch8_es_backtests

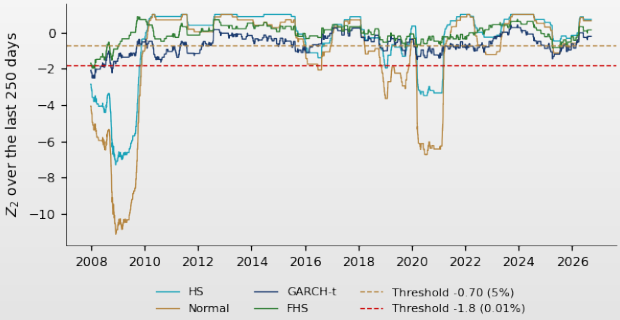
Acerbi și Szekely (2014): testarea directă a ES

- Indicatorul de depășire a VaR 2,5%: $I_t = 1\{L_t > \mathrm{VaR}_t^{\alpha}\}$, cu $\alpha = 0{,}025$
  - $N_T = \sum_t I_t$: numărul de depășiri în T zile
  - ES_t: prognoza ES pentru ziua t
- $Z_1 = 1 - \frac{1}{N_T} \sum_t \frac{L_t I_t}{\mathrm{ES}_t}$: este pierderea medie din coadă atît de mare cît s-a prognozat? (condiționat de depășiri)
- $Z_2 = 1 - \frac{1}{T\alpha} \sum_t \frac{L_t I_t}{\mathrm{ES}_t}$: testează frecvența și mărimea împreună
- Sub H_0 (distribuția prognozată este corectă) $E[Z_2] = 0$; riscul subestimat dă $Z_2 < 0$ (Acerbi & Szekely (2014))
- Pentru $T = 250$ și multe distribuții, valorile critice de 5% și 0,01% sînt apropiate de $-0{,}70$ și $-1{,}8$: praguri de referință pentru un semafor ES

Calculul p-value-ului prin simulare

- Distribuția lui Z_2 sub H_0 depinde de distribuțiile prognozate F_t (funcția de repartiție a lui L_t prognozată de model în ziua $t-1$)
- Algoritm (se repetă de $M = 2000$ ori)
  - Pentru fiecare zi extragem $U_t \sim \text{Uniform}(0,1)$ și calculăm $L_t^* = F_t^{-1}(U_t)$, o pierdere extrasă din prognoză (F_t^{-1}: funcția cuantilă)
  - Calculăm Z_2^* din pierderile simulate, cu aceleași prognoze VaR și ES
- p-value-ul = ponderea valorilor simulate Z_2^* mai mici sau egale cu Z_2 observat
- Contează doar extragerile din coadă: pentru HS și FHS păstrăm cele mai mari 25 de pierderi din fereastra fiecărei zile
- Pe întreg eșantionul S&P 500, Z_2 este $-0{,}664$ pentru GARCH-t ($p < 0{,}001$) și $-0{,}079$ pentru FHS ($p = 0{,}209$)
  - valoarea critică de 5% pentru $T = 4\,959$ este de circa $-0{,}150$, mai apropiată de 0 decît $-0{,}70$ pentru $T = 250$

Z_2 pe ferestre mobile de 250 de zile



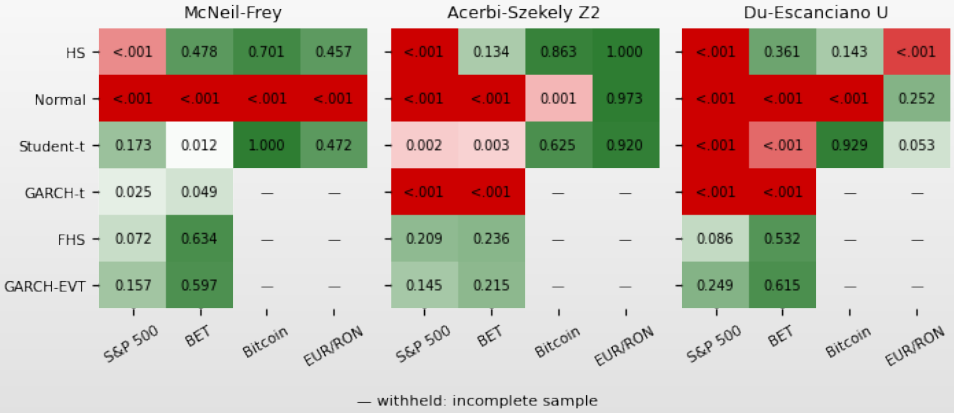
- Z_2 pentru ES 2,5% pe S&P 500, calculat de fiecare dată pe ultimele 250 de zile
  - liniile orizontale: pragurile de referință $-0{,}70$ și $-1{,}8$
- Minimul fiecărei curbe și sfîrșitul ferestrei în care apare
  - Normal $-11{,}13$ (04.12.2008), HS $-7{,}30$ (01.12.2008)
  - GARCH-t $-2{,}52$ (05.02.2008), FHS $-1{,}97$ (17.01.2008)
- Ponderea ferestrelor cu $Z_2 < -1{,}8$
  - Normal 21,9%, HS 15,8%, GARCH-t 3,0%, FHS 0,7%
  - GARCH-t sub $-0{,}70$ în 44,3% din ferestre
- Verificarea zilnică înseamnă testare repetată
  - alarmele false se acumulează (monitorizarea secvențială, Anexă)

MFM_ch8_es_backtests

Du și Escanciano (2017): depășirile cumulate

- PIT (transformarea integrală a probabilității): $u_t = F_t(L_t)$, probabilitatea prognozată a unei pierderi cel mult egale cu L_t; uniformă pe $(0,1)$ dacă distribuția prognozată F_t este corectă
- Depășirea cumulată: $H_t = \frac{1}{\alpha}(u_t - (1-\alpha))\,1\{u_t > 1-\alpha\}$: măsoară cît de departe în coadă se situează pierderea
- Sub H_0: $E[H_t] = \alpha/2$ și $\mathrm{Var}(H_t) = \alpha(1/3 - \alpha/4)$
- Testul necondiționat: $U = \sqrt{T}\,(\bar{H} - \alpha/2)/\sqrt{\alpha(1/3-\alpha/4)} \xrightarrow{d} N(0,1)$, cu $\bar{H}$ media de selecție a lui H_t
  - $U > 1{,}645$: pierderile ajung mai adînc în coadă decît s-a prognozat (test unilateral, 5%)
  - harta de pe slide-urile următoare dă p-value-ul bilateral $p = 2\Phi(-|U|)$: $U > 0$ înseamnă pierderi mai adînci decît s-a prognozat (risc subestimat), $U < 0$ pierderi mai puțin adînci (risc supraestimat)
- Testul condiționat: statistica Box–Pierce pe primele 5 autocorelații ale lui H_t, χ^2_5 (Du & Escanciano (2017))

Sinteza testelor ES (1/2)



MFM_ch8_es_backtests

Sinteza testelor ES (2/2)

- La pragul de semnificație de 5%, FHS și GARCH-EVT nu sînt respinse de McNeil–Frey, Z_2 și Du–Escanciano U, luate separat pe S&P 500 și BET
- Ipoteze nule și date diferite dau decizii diferite: pentru Student-t pe S&P 500, McNeil–Frey dă $p = 0{,}173$, dar Z_2 dă $p = 0{,}002$
- Acestea sînt teste de calibrare, nu clasamente
- GARCH-t este respins de Z_2 pe S&P 500 ($p < 0{,}001$) și BET ($p < 0{,}001$)
- Semnul lui U contează: pe EUR/RON, HS are $U = -3{,}68$ ($p < 0{,}001$), o respingere pentru că pierderile rămîn **mai puțin adînci** decît s-a prognozat, în acord cu Z_2 ($p = 1{,}000$) și cu rata de depășire a VaR 1% de 0,51%

MFM_ch8_es_backtests

Teste VaR multinomiale: un test implicit pentru ES

- ES 2,5% este media cuantilelor de dincolo de VaR 2,5%: testăm simultan mai multe niveluri VaR (Kratz, Lok & McNeil (2018))
- $N = 4$ niveluri de coadă $\alpha_j = 2{,}5\%\,(1 - (j-1)/4)$, adică 2,5%, 1,875%, 1,25% și 0,625%
  - după PIT-ul u_t, fiecare zi cade într-una din 5 celule
- Statistica Pearson: $S = \sum_{j=0}^{4} (O_j - Tp_j)^2/(Tp_j) \xrightarrow{d} \chi^2_4$
  - O_j: zilele observate în celula j; Tp_j: zilele așteptate
  - probabilitățile celulelor: $p_0 = 97{,}5\%$, $p_1 = \cdots = p_4 = 0{,}625\%$
  - un S mare arată numere departe de cele așteptate

p-value	S&P 500	BET	Bitcoin	EUR/RON
HS	<0,001	0,725	0,564	0,004
Normal	<0,001	<0,001	<0,001	<0,001
Student-t	<0,001	0,024	0,015	0,172
GARCH-t	<0,001	<0,001	n/a	n/a
FHS	0,003	0,862	n/a	n/a
GARCH-EVT	0,378	0,853	n/a	n/a

- n/a: rezultat GARCH reținut (slide-ul despre prognozele reținute)

Frecvențe pe celule: S&P 500, GARCH-t

Interval PIT	Zile observate	Zile așteptate
[0; 0,975]	4 761	4 835,02
(0,975; 0,98125]	39	30,99
(0,98125; 0,9875]	46	30,99
(0,9875; 0,99375]	52	30,99
(0,99375; 1]	61	30,99

- Prima celulă este în afara cozii superioare a pierderilor, de 2,5%
- Fiecare dintre cele patru celule din coadă conține mai multe zile decît s-ar aștepta dacă modelul ar fi calibrat

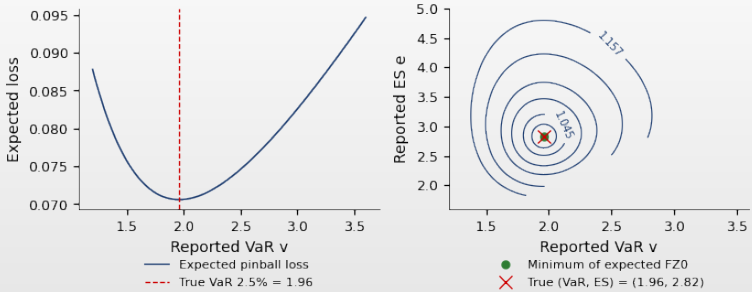
A testa nu înseamnă a ierarhiza: scoruri consistente

- Un backtest întreabă dacă un model este **acceptabil**: mai multe modele pot fi acceptate sau toate pot fi respinse
  - backtesting-ul comparativ întreabă care este **mai bun** (Nolde & Ziegel (2017))
- Ierarhizarea cere o **funcție de scor** $S(x, L)$: pierderea asociată raportării lui x cînd se realizează L
  - comparăm $\bar{S} = \frac{1}{T}\sum_t S(x_t, L_t)$: o valoare mai mică indică o prognoză mai bună
- S este **consistent** pentru $\theta(F)$, iar θ este **elicitabilă**, dacă $\theta(F) = \arg\min_x E_F[S(x, L)]$ (Gneiting (2011))
  - valoarea adevărată minimizează scorul așteptat; ierarhizarea cere ca ea să fie **unicul** punct de minim (consistență strictă)
  - $\theta(F)$: funcționala-țintă (de exemplu VaR) a distribuției pierderii F
  - E_F: media cînd $L \sim F$
- VaR: pierderea pinball $S(v, L) = (1\{L > v\} - \alpha)(L - v)$, unde v este prognoza VaR
  - dacă $E|L| < \infty$ și densitatea $f > 0$ în cuantilă:
    $$\frac{\partial}{\partial v} E_F[S(v, L)] = F(v) - (1 - \alpha) = 0 \;\Rightarrow\; v = F^{-1}(1 - \alpha) = \mathrm{VaR}_\alpha, \text{ iar } \partial^2/\partial v^2 = f(v) > 0$$
- ES **nu** este elicitabil singur: nicio funcție de scor care depinde doar de prognoza ES raportată e nu este minimizată de ES adevărat (Gneiting (2011))

VaR și ES împreună: Fissler și Ziegel (2016)

- Perechea (VaR, ES) este elicitabilă împreună: Fissler & Ziegel (2016) caracterizează întreaga familie de funcții de scor consistente (familia FZ)
- Pierderea FZ0, membrul omogen de grad zero al familiei FZ (Patton, Ziegel & Chen (2019)), cu pierderi pozitive, $0 < v \leq e$, $E|L| < \infty$ și ES adevărat pozitiv
  - $\mathrm{FZ0}(v, e; L) = \dfrac{1\{L > v\}(L - v)}{\alpha\, e} + \dfrac{v}{e} + \ln e - 1$
  - v, e: prognozele VaR și ES (pierderi pozitive); L: pierderea realizată
- Primul termen penalizează depășirile, scalat cu ES
- Ultimii termeni penalizează raportarea unui ES mare
- Exemplu pentru o zi, cu $\alpha = 2{,}5\%$ și prognozele $v = 3\%$, $e = 3{,}9\%$
  - pierderea $L = 4{,}5\%$ (depășire): $\mathrm{FZ0} = 15{,}385 + 1{,}130 = 16{,}515$
  - pierderea $L = 1\%$ (fără depășire): rămîne doar $v/e + \ln e - 1 = 0{,}769 + 1{,}361 - 1 = 1{,}130$
- Unitățile: aici v, e, L sînt în procente; doar $\ln e$ depinde de unitate
  - în zecimale ($v = 0{,}03$, $e = 0{,}039$, ca în cod) aceeași zi are scorul $-3{,}475$ (fără depășire), respectiv 11,910 (depășire): fiecare nivel se deplasează cu $\ln 100 = 4{,}605$
  - diferențele dintre modele nu depind de unitatea de măsură (procente sau zecimale)
  - de aceea pierderile FZ0 medii din cod sînt negative (S&P 500, FHS: $-3{,}551$)
- FZ0 mediu mai mic = prognoză comună VaR și ES mai bună

Elicitabilitatea, ilustrată grafic



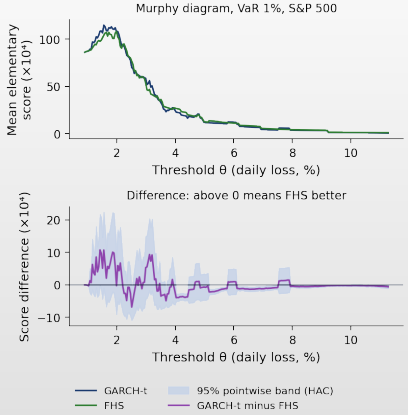
- Pierderi Student-t cu $\nu = 4$ și dispersie unitară, $\alpha = 2{,}5\%$
- Pierderile așteptate sînt calculate pe 2 milioane de extrageri
- Stînga: pierderea pinball așteptată este minimă în VaR 2,5% adevărat, 1,96
- Dreapta: pierderea FZ0 așteptată este minimă în (1,96; 2,82), adică în perechea (VaR, ES) adevărată, în limita grilei
- Un prognozator care cunoaște adevărul nu are motiv să raporteze altceva: de aceea ordonarea după scorul mediu are sens

MFM_ch8_elicitability

Robustețea clasamentului la alegerea scorului: scoruri elementare

- Pentru o cuantilă există o infinitate de scoruri consistente: $S(v, L) = (1\{L \leq v\} - \tau)(g(v) - g(L))$, orice funcție crescătoare g, $\tau = 1 - \alpha$ (nivelul cuantilei pierderii)
- Fiecare este o mixtură de **scoruri elementare** (Ehm, Gneiting, Jordan & Krüger (2016))
  - $S_\theta(v, L) = (1\{L < v\} - \tau)\,(1\{\theta < v\} - 1\{\theta < L\})$, $\theta \in \mathbb{R}$; θ: un prag pe scala pierderii
  - S_θ penalizează o prognoză doar cînd v și L cad de o parte și de alta a lui θ
  - pierderea pinball este $\int S_\theta \, d\theta$
- Prognoza A este preferată prognozei B sub **orice** scor consistent dacă și numai dacă $\bar{S}_\theta(A) \leq \bar{S}_\theta(B)$ pentru orice θ, cu $\bar{S}_\theta$ scorul elementar mediu pe cele T zile
- **Diagrama Murphy**: reprezentăm $\bar{S}_\theta$ în funcție de θ
  - dacă curbele se intersectează, clasamentul depinde de scorul ales

Diagrama Murphy: GARCH-t față de FHS (1/2)



MFM_ch8_comparative

Diagrama Murphy: GARCH-t față de FHS (2/2)

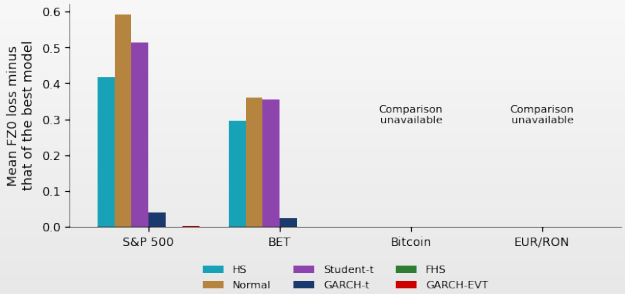
- S&P 500, VaR 1%, 2007–2026, cu pragul θ între 0,9% și 11,3%
- Pierderea pinball medie ($\times 10^4$): GARCH-t 3,852, FHS 3,861, deci egalitate sub scorul obișnuit
- Sub $\theta = 5\%$ curbele se intersectează: FHS este mai bun pe 47% dintre praguri, iar banda conține zero pe 86%
  - peste $\theta = 5\%$, GARCH-t are scorul mai mic pe 89% dintre praguri
  - niciun model nu îl domină pe celălalt
- Benzile de 95% folosesc erori standard HAC (robuste la heteroscedasticitate și autocorelație) și sînt punctuale, nu un test simultan de dominare
- Scorul se alege înainte de a vedea rezultatele

MFM_ch8_comparative

Testul Diebold–Mariano pe pierderile FZ0

- Diferența de pierdere dintre modelele A și B: $d_t = \mathrm{FZ0}_{A,t} - \mathrm{FZ0}_{B,t}$
- H_0: $E[d_t] = 0$ (acuratețe predictivă egală), Diebold & Mariano (1995)
  - statistica este diferența medie $\bar{d}$ împărțită la eroarea ei standard
- $$\mathrm{DM} = \frac{\bar{d}}{\sqrt{\widehat{\mathrm{LRV}}(d_t)/T}} \xrightarrow{d} N(0,1)$$
- $\widehat{\mathrm{LRV}}$: dispersia pe termen lung, cu ponderi Newey–West (Newey & West (1987)) și 9 laguri
  - este necesară deoarece pierderile din coadă se grupează, deci d_t este autocorelat
  - $\widehat{\mathrm{LRV}} = \hat{\gamma}_0 + 2\sum_{k=1}^{q}\left(1 - \frac{k}{q+1}\right)\hat{\gamma}_k$, unde $\hat{\gamma}_k$ este autocovarianța lui d_t la lagul k
  - regula lagurilor: $q = \lfloor 4(T/100)^{2/9} \rfloor = 9$ pentru $T = 4\,959$
- $\mathrm{DM} > 0$: modelul A are pierderea medie mai mare, deci este mai slab
  - $|\mathrm{DM}| > 1{,}96$: diferență semnificativă la 5%

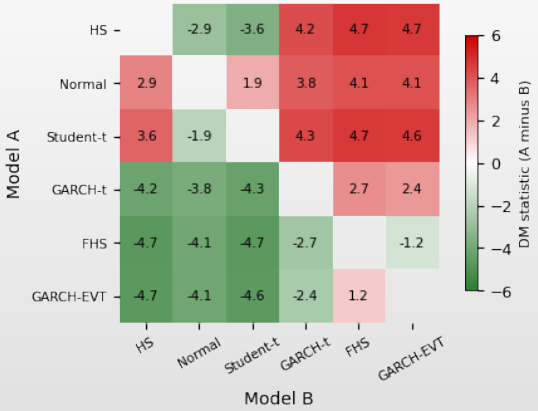
Pierderea FZ0 medie pe modele



- Pierderea FZ0 medie a prognozelor (VaR 2,5%, ES 2,5%) minus cea a celui mai bun model de pe fiecare piață
- Cea mai mică pierdere FZ0: FHS pe S&P 500 și BET
- Comparație pe eșantionul complet de evaluare
  - Pe S&P 500 și BET, comparăm toate cele șase modele pe aceleași date de evaluare
- Pierderea FZ0 medie a GARCH-t depășește pe cea a FHS cu 0,040 pe S&P 500
  - mărimea diferenței nu arată dacă datele separă modelele: o testăm

MFM_ch8_comparative

Teste Diebold–Mariano pe perechi, S&P 500 (1/2)



MFM_ch8_comparative

Teste Diebold–Mariano pe perechi, S&P 500 (2/2)

- DM pentru modelul A (rînd) minus B (coloană) pe pierderile FZ0; roșu: A mai slab, verde: A mai bun
- Față de FHS
  - HS $\mathrm{DM} = 4{,}69$, GARCH-t $\mathrm{DM} = 2{,}66$: ambele semnificativ mai slabe
  - GARCH-EVT $\mathrm{DM} = 1{,}24$: nu se deosebește
- Normal minus HS: $\mathrm{DM} = 2{,}88$: o cuantilă empirică, deși se ajustează lent, este totuși superioară unei cozi subțiri
- Cincisprezece teste pe perechi: o problemă de testare multiplă
  - care modele rămîn **împreună**? (mulțimea de încredere a modelelor, MCS)

MFM_ch8_comparative

Compararea metodelor de prognoză: Giacomini–White

- DM vizează acuratețea populațională a **modelelor**
  - cu ferestre mobile de 1 000 de zile și reestimări comparăm **metode de prognoză**
  - eroarea de estimare nu dispare
- Giacomini & White (2006): H_0: $E[d_t \mid \mathcal{F}_{t-1}] = 0$ pentru diferența de scor $d_t = \mathrm{FZ0}_{A,t} - \mathrm{FZ0}_{B,t}$
  - testul este valid pentru modele imbricate și ferestre finite
- Funcția test $h_{t-1} = (1, d_{t-1})'$: informație cunoscută la $t-1$ care ar putea prezice ce metodă cîștigă, cu $Z_t = h_{t-1} d_t$
  - $\mathrm{GW} = T\,\bar{Z}'\hat{\Omega}^{-1}\bar{Z} \xrightarrow{d} \chi^2_2$, $\hat{\Omega} = T^{-1}\sum_t Z_t Z_t'$ (un pas înainte)
  - $\bar{Z}$: media lui Z_t; $\hat{\Omega}$: covarianța ei estimată
  - 2 grade de libertate, cîte unul pentru fiecare instrument
  - cu $h_{t-1} = 1$ obținem forma DM
- S&P 500 față de FHS: GARCH-EVT $\mathrm{GW} = 6{,}71$ ($p = 0{,}035$), GARCH-t 7,60 ($p = 0{,}022$), HS 53,16 ($p < 0{,}001$)
- GARCH-EVT, la egalitate după DM, este respins condiționat
  - egalitatea capacității predictive condiționate este respinsă pentru aceste instrumente
  - ce anume determină respingerea trebuie verificat cu un test separat

Backtesting comparativ în trei zone (Nolde și Ziegel)

- Comparăm modelul intern A cu un model standard S (aici HS) după pierderea FZ0 medie
  - folosim două teste unilaterale la 5% (Nolde & Ziegel (2017))
- H_0^-: A este cel puțin la fel de bun ca S; H_0^+: A este cel mult la fel de bun
  - **verde**: respingem H_0^+
  - **roșu**: respingem H_0^-
  - **galben**: nu respingem niciuna
- Pragurile sînt unilaterale: **verde** dacă $\mathrm{DM} < -1{,}645$, **roșu** dacă $\mathrm{DM} > 1{,}645$, **galben** altfel
  - de exemplu, $\mathrm{DM} = -1{,}8$ dă zona verde, deși $|\mathrm{DM}| < 1{,}96$
- Sarcina probei se inversează: banca trebuie să arate că modelul ei este mai bun, nu supraveghetorul că este mai slab

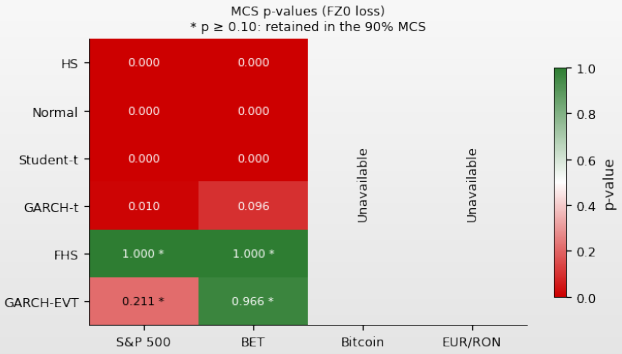
DM (A minus HS)	S&P 500	BET	Bitcoin	EUR/RON
GARCH-t	−4,21	−5,25	n/a	n/a
FHS	−4,69	−5,53	n/a	n/a
GARCH-EVT	−4,67	−5,57	n/a	n/a

- Culoarea indică zona statistică
- n/a: rezultat GARCH reținut (slide-ul despre prognozele reținute)

Mulțimea de încredere a modelelor

- Mulțimea de încredere a modelelor, MCS (Hansen, Lunde & Nason (2011))
  - conține modelele cele mai bune cu o probabilitate asimptotică de cel puțin $1 - \alpha_{MCS}$
  - garanția cere condițiile de regularitate ale metodei
  - mai jos folosim $\alpha_{MCS} = 10\%$
- Algoritm
  - Testăm H_0: toate modelele din mulțimea curentă au aceeași pierdere așteptată
  - Dacă o respingem, eliminăm modelul cu cea mai mare pierdere medie standardizată și repetăm
  - Valorile critice provin dintr-un bootstrap pe blocuri (blocuri de 10 zile, 1 000 de replicări)
- p-value-ul MCS al unui model: cel mai mare p-value al testelor pînă la eliminarea lui
  - păstrăm modelele cu $p \geq 0{,}10$
- O mulțime MCS mare este un rezultat informativ: datele nu separă modelele

Modelele reținute în MCS



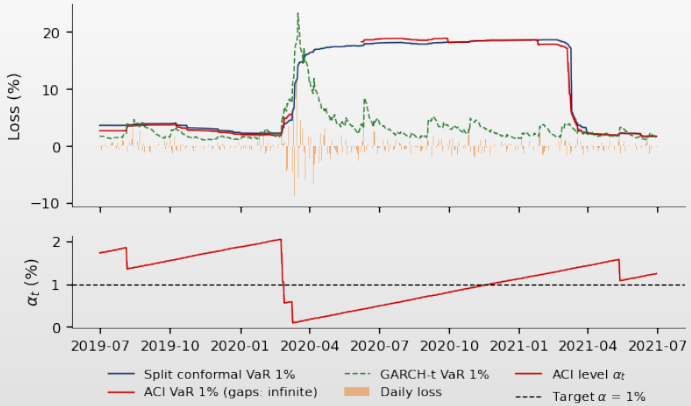
- p-value-urile MCS, calculate pe pierderea FZ0 a perechii (VaR 2,5%, ES 2,5%)
  - modelele cu $p \geq 0{,}10$ formează MCS de 90%
- S&P 500: FHS și GARCH-EVT
  - GARCH-EVT are p-value-ul MCS 0,211
  - GARCH-t este exclus (p 0,010)
- BET: FHS și GARCH-EVT
  - GARCH-t este exclus la limită (p 0,096)
- Bitcoin și EUR/RON: fără MCS, deoarece prognozele GARCH sînt reținute (slide-ul despre prognozele reținute)

MFM_ch8_comparative

Cuantile conformale split: o garanție fără ipoteze de distribuție

- **Predicția conformală** (Lei et al. (2018), Angelopoulos & Bates (2021))
  - modelele de pînă acum presupun o distribuție (Normală, t, GPD) sau un trecut stabil (HS)
  - predicția conformală transformă orice prognoză într-o cuantilă cu garanție de acoperire
- Scorul: $s_t = L_t/\hat{\sigma}_t$, unde $\hat{\sigma}_t$ este abaterea standard a celor 250 de randamente anterioare
  - mulțimea de calibrare: ultimele $n = 250$ scoruri, ordonate $s_{(1)} \leq \cdots \leq s_{(n)}$
- VaR conformal: $\mathrm{VaR}_t = \hat{\sigma}_t\, s_{(k)}$, cu $k = \lceil (n+1)(1-\alpha) \rceil$ ($\lceil x \rceil$: cel mai mic întreg $\geq x$)
  - adică volatilitatea de azi înmulțită cu al k-lea cel mai mic scor trecut
  - pentru $n = 250$ și $\alpha = 0{,}01$: $k = 249$, adică al doilea cel mai mare scor
- Garanția, dacă cele $n+1$ scoruri sînt **schimbabile** (legea comună nu se schimbă la permutare):
  $1 - \alpha \leq P(L_t \leq \mathrm{VaR}_t) \leq 1 - \alpha + \frac{1}{n+1}$ (fără valori egale)
- Aici garanția este doar aproximativă (extinderi: Anexă)
  - volatility clustering încalcă schimbabilitatea
  - $\hat{\sigma}_t$ provine din ferestre mobile suprapuse
  - conformal split autentic estimează scorul o singură dată, pe un eșantion separat

VaR conformal în perioada COVID-19 (1/2)



MFM_ch8_conformal

VaR conformal în perioada COVID-19 (2/2)

- S&P 500, iulie 2019–iunie 2021, VaR 1%
  - sus: conformal split, ACI și GARCH-t; jos: nivelul ACI α_t
  - ACI (inferența conformală adaptivă) ajustează zilnic nivelul α_t după depășiri (slide-ul următor)
- Între 20.02 și 30.04.2020: 50 de zile, cu 0,5 depășiri așteptate
  - depășiri observate: conformal split 6, ACI 4 (8% din zile)
- ACI a stabilit VaR $= \infty$ în 37 din aceste zile
  - nicio depășire nouă, dar un VaR infinit nu aduce informație
- VaR 1% conformal split rămîne în jur de 18% timp de un an
  - doi factori rămîn ridicați circa un an: $\hat{\sigma}_t$ de azi (abaterea standard pe 250 de zile, care încă include martie 2020) și $s_{(\mathbf{249})}$, al doilea cel mai mare dintre ultimele 250 de scoruri, care rămîne extrem cît timp zilele crahului se află în mulțimea de calibrare
  - cifre ilustrative: dacă $\hat{\sigma}_t$ se dublează de la 1,2% la 2,4% și $s_{(\mathbf{249})} = 7$, VaR crește de la 8,4% la 16,8%
  - GARCH-t se adaptează în cîteva zile

MFM_ch8_conformal

Inferența conformală adaptivă (ACI)

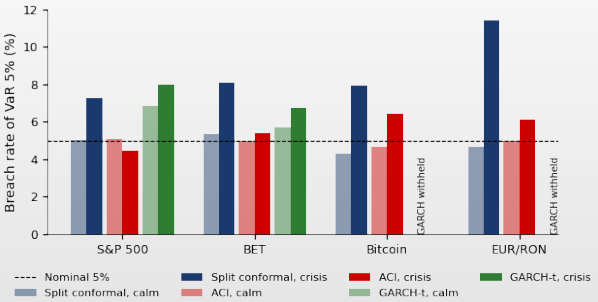


Emmanuel Candès, coautor al inferenței conformale adaptive

Foto: Cmichel67 (2026); CC BY-SA 4.0; Wikimedia Commons

- Gibbs & Candès (2021): nivelul de lucru se actualizează după fiecare zi
  - $\alpha_{t+1} = \alpha_t + \gamma\,(\alpha - \mathrm{err}_t)$, $\mathrm{err}_t = 1\{L_t > \mathrm{VaR}_t\}$
  - α_t: nivelul cuantilei conformale din ziua t
  - $\gamma > 0$: pasul
  - α_1: nivelul inițial
- După o depășire, α_t scade (VaR crește); după zile calme, α_t crește încet la loc
  - folosim $\gamma = 0{,}005$
- Garanția, pentru orice șir: $\left|\frac{1}{T}\sum_t \mathrm{err}_t - \alpha\right| \le \frac{\max(\alpha_1, 1-\alpha_1) + \gamma}{\gamma T}$, o **medie** pe termen lung, nu fiecare zi sau fiecare criză
- Dacă $\alpha_t < 1/(n+1)$, cuantila cerută nu există: VaR devine infinit

Acoperirea în perioade calme și de criză



- VaR 5%, cu zilele de criză definite dinainte
  - criză: volatilitatea din ultimele 20 de zile depășește percentila 90 a celor 1 000 de zile anterioare
- Ratele de depășire, conformal split
  - în toate zilele: S&P 500 5,34%, BET 5,63%, Bitcoin 4,58%, EUR/RON 5,06%
  - în zilele de criză: S&P 500 7,29%, BET 8,08%, Bitcoin 7,95%, EUR/RON 11,43%
- ACI: ratele în criză pe acțiuni, aproape de 5%
  - S&P 500 4,49%, BET 5,38%
  - pentru VaR 1%, acest lucru se obține doar printr-un VaR infinit în 13,4% din toate cele 4 959 de zile de evaluare S&P 500
  - acoperirea marginală nu este acoperire în criză

MFM_ch8_conformal

Studiu de caz (1/8): testarea ES doar pe baza prognozelor ES

- Bayer & Dimitriadis (2022): pot fi testate prognozele ES folosind doar randamentele observate și aceste prognoze?
- Relevanța: FRTB calculează capitalul din ES 2,5% (secțiunea „Perspectiva reglementatorului")
  - testele ES din secțiunea „Backtesting pentru Expected Shortfall" cer și prognoze VaR, volatilitatea sau întreaga distribuție prognozată
  - supraveghetorii nu primesc neapărat aceste date
  - respingerea unui astfel de test comun nu arată care dintre ele este greșită
- Ideea: o regresie Mincer–Zarnowitz a randamentelor pe prognozele ES
- H_0: termenul liber este 0 și panta este 1 (o prognoză corectă nu are nevoie de corecție)
  - ES nu este elicitabil separat (secțiunea „Elicitabilitate și funcții de scor"), dar perechea (VaR, ES) este elicitabilă în comun (Fissler & Ziegel (2016)), deci se poate estima o regresie comună cuantilă–ES (Patton, Ziegel & Chen (2019))

Studiu de caz (2/8): regresia ES

- Convenția randamentelor: $\hat{e}_t = -\widehat{\mathrm{ES}}_t < 0$ este prognoza ES pe scala randamentelor, cu $\tau = \alpha = 2{,}5\%$
  - Ecuația ES: $r_t = \gamma_{\mathbf{1}} + \gamma_{\mathbf{2}}\hat{e}_t + u_t^e$, $\mathrm{ES}_\tau(u_t^e \mid \mathcal{F}_{t-\mathbf{1}}) = 0$
  - $\gamma_{\mathbf{1}}$: termenul liber, $\gamma_{\mathbf{2}}$: panta
  - u_t^e: eroarea cu ES condiționat nul, deci $\gamma_{\mathbf{1}} + \gamma_{\mathbf{2}}\hat{e}_t$ este ES condiționat adevărat
  - prognoze corecte: $\gamma_{\mathbf{1}} = 0$, $\gamma_{\mathbf{2}} = 1$
- ESR (regresia expected shortfall) cere și o ecuație a cuantilei, deoarece ES se estimează împreună cu VaR
  - **ESR auxiliar**: ecuația cuantilei pe $(1, \hat{v}_t)$, deci cere prognoze VaR $\hat{v}_t$
  - **ESR strict**: ecuația cuantilei pe $(1, \hat{e}_t)$, deci cere doar prognoze ES
  - **ESR cu termen liber**: $r_t - \hat{e}_t = \gamma_{\mathbf{1}} + u_t^e$, cu panta fixată la 1
  - test t unilateral pentru $H_{\mathbf{0}}$: $\gamma_{\mathbf{1}} \geq 0$ față de $\gamma_{\mathbf{1}} < 0$ (ES subestimat)

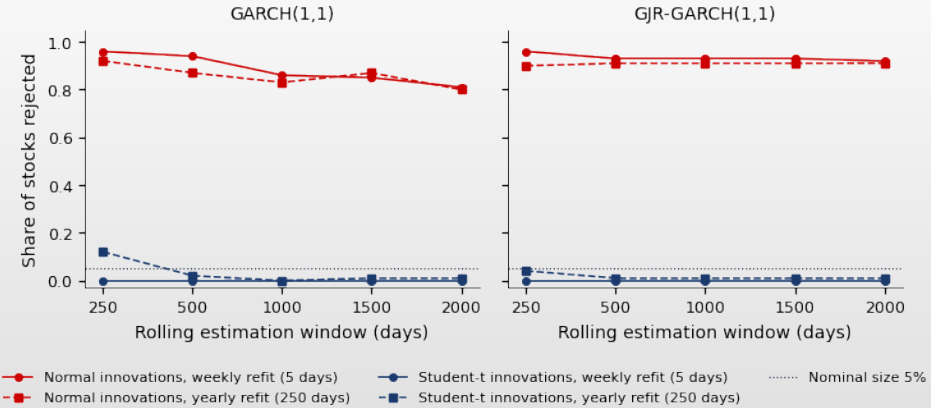
Studiu de caz (3/8): ce se estimează și sub ce ipoteze

- Estimator de tip M care minimizează o pierdere de tip FZ0
  - estimator de tip M: valoarea parametrilor care minimizează media de selecție a unei pierderi; OLS este cazul pierderii pătratice
  - teorie asimptotică sub specificare greșită (lucrarea, Teorema 1.4)
  - pachetele R esback și esreg
- Două ipoteze de reținut
  - ESR strict și ESR cu termen liber: ecuația cuantilei este corectă doar dacă VaR este o funcție afină de ES (de exemplu, modele de scală pură)
  - Covarianța sandwich robustă la specificarea greșită presupune un model de locație și scală pentru distribuția condiționată
  - covarianța sandwich: $A^{-1}BA^{-1}$, A: curbura pierderii medii, B: dispersia gradientului ei
  - model de locație și scală: $r_t = \mu_t + \sigma_t z_t$, cu șocuri standardizate z_t i.i.d.

Studiu de caz (4/8): mărimea și puterea în simulările lucrării

- Designul Monte Carlo (lucrarea, Secț. 2)
  - 10 000 de replicări, T de la 250 la 5 000
  - EGARCH-t (GARCH exponențial, șocuri Student-t) calibrat pe S&P 500
  - AR(1)-GARCH(1,1): medie autoregresivă de ordinul 1, dispersie GARCH
  - două modele GAS (generalised autoregressive score, scor autoregresiv generalizat) Student-t
  - teste de comparație: McNeil & Frey (2000) și testele de calibrare din Nolde & Ziegel (2017)
- Mărimea efectivă a testelor la nivelul nominal de 5%, pentru EGARCH-t, la $T = 250$ și $T = 1\,000$ (Tabelul 1)
  - ESR strict: 0,09, respectiv 0,05 cu covarianța robustă
  - ESR strict: 0,24, respectiv 0,11 cu covarianța clasică
  - testul simplu de calibrare condiționată: 0,29, respectiv 0,14
- Puterea (Fig. 3): ESR detectează ce ratează testele reziduurilor
  - testele reziduurilor de depășire aproape nu reacționează la o dinamică greșită a volatilității sau la un nivel greșit $\tilde{\tau} \neq \tau$
  - o bancă ar putea raporta ES pentru un nivel mai puțin extrem fără a fi respinsă de testele mai vechi

Studiu de caz (5/8): cozile contează mai mult decît reestimarea



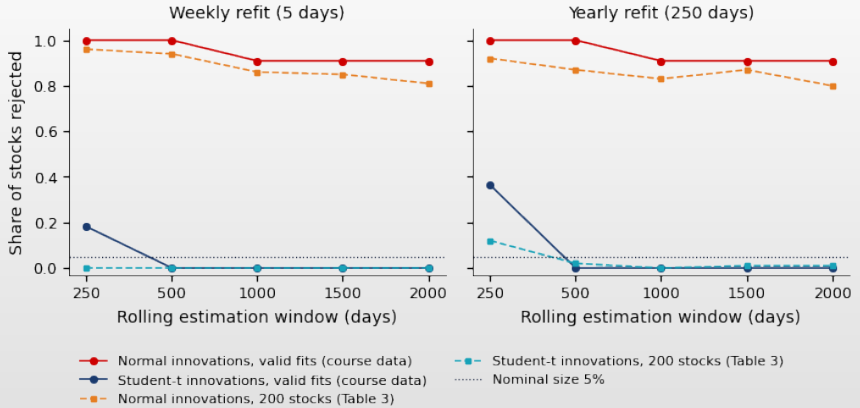
MFM_ch8_esr_case

Studiu de caz (6/8): cozile contează mai mult decît reestimarea

- Bayer & Dimitriadis (2022), Tabelul 3: cele mai mari 200 de acțiuni din S&P 500, 2010–2019
  - ponderea acțiunilor pentru care ES 2,5% este respins de ESR cu termen liber (test unilateral, la 5%)
  - ferestre de 250–2 000 de zile; reestimare la 5 (linia continuă) sau 250 de zile (linia întreruptă)
- Inovații Normale: ponderea respinsă este între 0,80 și 0,96
  - în toate cele 50 de celule ale Tabelului 3: 5 ferestre (250, 500, 1 000, 1 500, 2 000 de zile) $\times$ 5 frecvențe de reestimare (5, 21, 62, 125, 250 de zile) $\times$ GARCH/GJR-GARCH
  - graficul arată doar reestimarea la 5 și la 250 de zile
  - GJR-GARCH (Glosten–Jagannathan–Runkle): GARCH cu o reacție suplimentară la șocurile negative
- Inovații Student-t: ponderea respinsă este cel mult 0,12
  - pînă la 0,12 cu ferestre de 250 de zile
  - cel mult 0,01 cu ferestre de cel puțin 1 000 de zile
- Contează cel mai mult cozile groase și fereastra lungă
  - frecvența reestimării contează doar la ferestre scurte

MFM_ch8_esr_case

Studiu de caz (7/8): Tabelul 3, replicat pe datele cursului



MFM_ch8_esr_case

Studiu de caz (8/8): Tabelul 3, replicat pe datele cursului

- Linia continuă: 11 acțiuni mari din S&P 500, cu prețuri din 2002
  - perioada: ianuarie 2010 – august 2019 (2 432 de zile)
  - linia întreruptă: Bayer & Dimitriadis (2022), Tabelul 3
  - GARCH(1,1) cu medie constantă
  - 25 de combinații fereastră–reestimare (aceeași grilă 5×5, doar GARCH); ESR cu termen liber, cu esback
  - fiecare acțiune respinsă adaugă $1/11 \approx 0{,}09$ la pondere
- Inovații Normale: ponderea respinsă este între 0,82 și 1,00 (în lucrare: 0,80–0,96)
  - Student-t: nicio acțiune respinsă cu ferestre de cel puțin 1 000 de zile (în lucrare: cel mult 0,01)
  - dar între 0,09 și 0,55 cu ferestre de 250 de zile (în lucrare: 0,00–0,12)
- Rezultatul central se replică; la fereastra de 250 de zile, ponderile ajung la 0,55, față de cel mult 0,12 în lucrare

MFM_ch8_esr_case

O întrebare deschisă: acoperirea condiționată în criză

- Garanțiile VaR fără ipoteze de distribuție sînt **marginale**: conformal split cere schimbabilitate, ACI controlează doar media pe termen lung (secțiunea „Predicția conformală pentru tail risk (riscul pierderilor extreme)")
- Întrebarea formală, cu un indicator de criză $C_t \in \mathcal{F}_{t-\mathbf{1}}$ cunoscut ex ante ($C_t = 1$ într-o zi de criză, 0 altfel): rămîne rata de depășire în zilele de criză egală cu α?
  - $H_\mathbf{0}$: $P(L_t > \mathrm{VaR}_t \mid C_t = 1) = \alpha$ față de $H_\mathbf{1}$: $P(L_t > \mathrm{VaR}_t \mid C_t = 1) \neq \alpha$
  - Infirmată de o rată de depășire în criză în afara regiunii de acceptare Binomiale, după corecția pentru depășiri dependente și pentru testarea multiplă
- Bucla de cercetare cu un asistent AI (artificial intelligence, inteligență artificială): un LLM (large language model, model lingvistic mare) precum Claude, ChatGPT sau Gemini
  - literatura, cu DOI-uri verificate pe Crossref
  - replicăm întîi o cifră cunoscută
  - trei explicații rivale: scală întîrziată, formă a cozii schimbătoare, artefact al selecției regimului
  - pre-înregistrăm testele
  - cerem asistentului un raport critic, în stilul unui referent (prompturile: Anexă)
- Miza: capitalul este necesar exact în zilele în care garanțiile marginale spun cel mai puțin

Mini-studiu de caz: scala GARCH și acoperirea în criză

- Scorul alternativ: pierderea standardizată $s_t = (L_t + \mu_t)/\sigma_t$ ca scor
  - μ_t, σ_t: prognozele GARCH-t ale mediei și volatilității
  - H_0: rata de depășire a VaR 5% în criză = 5%
  - test Binomial exact bilateral, cu corecția Holm (ajustarea în trepte a p-value-urilor pentru teste multiple) pe cele patru piețe pentru conformal split și pe S&P 500 și BET pentru scala GARCH (n/a: prognoze GARCH reținute)

Piața	Zile de criză	Conformal split	p Holm	Scală GARCH	p Holm
S&P 500	613	7,01%	0,052	2,77%	0,018
BET	506	8,10%	0,009	3,95%	0,309
Bitcoin	150	8,00%	0,092	n/a	n/a
EUR/RON	245	11,43%	<0,001	n/a	n/a

ai_discovery_case.py

Mini-studiu de caz: interpretarea rezultatului

- Întîi schimbarea eșantionului
  - scorurile cu scală GARCH cer 250 de zile de calibrare
  - eșantionul comun pentru S&P 500 are 4 709 de zile, dintre care 613 de zile de criză (față de 713 în eșantionul complet din secțiunea conformală)
  - rata conformal split în criză: 7,01% (eșantionul complet: 7,29%)
- Ratele din criză cu scală GARCH sînt sub 5% pe S&P 500 și BET
  - Scala GARCH, Holm pe S&P 500 și BET: rata de 2,77% este semnificativ sub 5% pe S&P 500 (p 0,018), cea de 3,95% de pe BET nu (p 0,309)
  - Metoda split conformal: Holm respinge pe BET (p 0,009) și EUR/RON (p <0,001) la pragul de 5%
- Nerespingerea nu dovedește acoperirea în criză
  - p-value-urile Binomiale ignoră depășirile grupate
  - eșantioanele de criză sînt mici

Alegerea provizorie a modelului



Banca Națională a României, București

Foto: Britchi Mirela (2018); CC BY-SA 4.0; Wikimedia Commons

- **Calibrare**
  - FHS și GARCH-EVT nu sînt respinse de Z_2 la 5% și rămîn în MCS de 90% pe S&P 500 și BET (tabloul complet: Anexă)
- **Comparație**
  - cel mai mic FZ0 mediu: FHS pe S&P 500; pe BET, FHS și GARCH-EVT sînt egale la trei zecimale
- **Nerezolvat**
  - DQ respinge toate modelele pe S&P 500
  - acoperirea în criză nu este asigurată
  - un an de date are putere redusă
- **Alegere provizorie**
  - FHS ca model principal, GARCH-EVT ca alternativă, reexaminate pe măsură ce se acumulează dovezi
  - un portofoliu românesc (BET și EUR/RON): Seminarul 8, C2

Verificarea înțelegerii și capitolul 9

Întrebări de verificare

- De ce respinge regula „$\mathrm{LR}_{uc} > 3{,}84$” un VaR 1% corect în aproximativ un an din zece?
- De ce poate fi respins un model cu numărul corect de depășiri?
- De ce poate fi testat ES, dar nu poate fi ierarhizat singur?
- Ce garantează ACI?
- Ce nu garantează ACI?

Capitolul 9: volatilitate realizată

- Măsurăm dispersia zilnică din randamente intrazilnice
- Evaluăm prognozele de volatilitate cu scoruri robuste, precum QLIKE (quasi-likelihood, pierderea de tip cvasi-verosimilitate), și cu MCS

Verificări numerice

1. Kupiec: $x = 3$ depășiri ale VaR 1% în $T = 500$ de zile; calculați $\hat{\pi}$ și LR_{uc}, apoi decideți la 5%
2. FZ0: o zi, $\alpha = 5\%$, $v = 2\%$, $e = 2{,}5\%$; calculați scorul pentru $L = 3\%$ și pentru $L = 1\%$, în procente și în zecimale
3. Puterea locală: $T = 1000$, $\alpha = 1\%$, rata reală $\pi = 2\%$; calculați λ și puterea, apoi comparați cu curba întreruptă din graficul puterii
4. Z_1 și Z_2: $T = 250$, $\alpha = 2{,}5\%$, cinci depășiri cu $L_t/\mathrm{ES}_t = 1{,}1;\ 0{,}9;\ 1{,}3;\ 1{,}0;\ 1{,}2$; calculați ambele statistici și explicați semnele lor

Răspunsuri, cu pașii intermediari: Anexă. Exerciții rezolvate pe datele cursului: Seminarul 8, A1, A4, B2

Lecturi și resurse pentru aprofundare

- Lucrări de bază
  - Fissler & Ziegel (2016): VaR și ES sînt elicitabile împreună, baza pierderii FZ0
  - Nolde & Ziegel (2017): backtesting comparativ și semaforul pentru VaR și ES
  - Acerbi & Szekely (2014): teste ES fără ipoteze de model, inclusiv Z_2
- Prognoze VaR și ES bazate pe entropie: Pele, Lazar & Dufour (2017), Pele & Mazurencu-Marinescu-Pele (2019), Pele, Lazar & Mazurencu-Marinescu-Pele (2019)
- Separabilitatea a două prognoze ES: Pele & Mazurencu-Marinescu-Pele (2026)
  - aproximativ una din cinci comparații ES pe perechi, pe piețele globale, are o precizie fragilă
  - o consecință a eșantionului efectiv mic din coadă, αT
- Manuale: Franke, Härdle & Hafner (2019) (capitolele despre VaR și backtesting) și Härdle, Chen & Overbeck (2017)
- Quantinar: Machine learning in Financial Risk
- Cod și date: github.com/danpele/MFM/tree/main/Quantlets/Ch_08
  - S&P 500, BET, Bitcoin: închideri zilnice din datele cursului
  - EUR/RON: cursul de referință BNR

Înapoi

Riscul de estimare, dezvoltarea pentru schema fixă

- Schema fixă (Escanciano & Olmo (2010)): $\frac{1}{\sqrt{P}} \sum_t (\hat{I}_t - \alpha) = \frac{1}{\sqrt{P}} \sum_t (I_t - \alpha) + \sqrt{P/R}\, D' \sqrt{R}(\hat{\theta} - \theta_0) + o_p(1)$
  - Primul termen: depășirile centrate cu parametrii adevărați θ_0
  - al doilea termen: efectul erorii de estimare $\hat{\theta} - \theta_0$
  - $D = E\left[\partial P(L_t > \mathrm{VaR}_t(\theta) \mid \mathcal{F}_{t-1})/\partial\theta\right]$ în θ_0: sensibilitatea probabilității de depășire la parametri
  - al doilea termen dispare doar dacă $P/R \to 0$
  - Termenul de estimare adaugă o dispersie de ordinul P/R la $\sqrt{P}(\hat{\pi} - \alpha)$, deci valorile critice χ^2 sînt prea mici cînd P/R este mare
- Schemele mobile și recursive schimbă forma corecției
  - dezvoltarea presupune $\mathrm{VaR}_t(\theta)$ netedă, $\hat{\theta}$ consistent cu rata $\sqrt{R}$ și staționaritate
- Remedii: dispersia corectată sau subeșantionarea din Escanciano & Olmo (2010), ori un bootstrap parametric care reestimează modelul pe fiecare traiectorie simulată

Înapoi

Riscul de estimare: rezultatele simulării

- Schema fixă: 400 de traiectorii, $R = 1\,000$, testul Kupiec la 5%
- 324 de estimări admisibile
- 75 de estimări neidentificate numeric
- O estimare nu îndeplinește condiția de admisibilitate pentru dispersie finită
- Aici raportăm doar ratele cu parametrii adevărați, pe toate cele 400 de traiectorii: o rată pe cele 324 de traiectorii admisibile ar fi condiționată de succesul estimării
- Cu parametrii adevărați: 10,0% la $P = 250$, 5,2% la $P = 1\,000$, 4,0% la $P = 5\,000$
- Eroarea standard Monte Carlo la o probabilitate de respingere de 5%: circa 1,1 puncte procentuale

Înapoi

Principiul lui Osband și funcțiile de identificare

- Principiul lui Osband (Fissler & Ziegel (2016)): scorurile consistente se construiesc dintr-o funcție de identificare V, cu $E_F[V(x, L)] = 0$ doar în valoarea adevărată
- VaR: $V(v, L) = 1\{L \leq v\} - (1 - \alpha)$; pierderea pinball este integrala ei în v
- (VaR, ES): $V_1 = \alpha - 1\{L > v\}$ și $V_2 = e - v - \frac{1}{\alpha} 1\{L > v\}(L - v)$
  - mediile lor se anulează doar în perechea adevărată
- Mulțimile de nivel ale ES nu sînt convexe la mixturi, deci nu există o funcție de identificare doar în e (Seminarul 8, A8)
- FZ0 este membrul familiei FZ ale cărui diferențe nu depind de scala pierderilor (Patton, Ziegel & Chen (2019))

Înapoi

Monitorizarea secvențială a prognozelor de risc

- Reglementatorul verifică prognozele zilnic: repetarea unui test pe eșantion fix (de exemplu, Z_2 pe ferestre mobile) mărește probabilitatea a cel puțin unei alarme false
- Hoga & Demetrescu (2023): statistici de monitorizare pentru VaR și ES cu funcții-frontieră care țin sub nivelul nominal probabilitatea oricărei alarme false pe întregul orizont
- Față de semafor: dovezile se acumulează de la începutul monitorizării, nu dintr-o singură fereastră de 250 de zile
- Testul ES prin regresie (Bayer & Dimitriadis (2022)) din studiul de caz poate fi monitorizat la fel; ambele corectează limita semaforului, care evaluează un singur moment

Înapoi

Predicția conformală dincolo de schimbabilitate

- Barber, Candès, Ramdas & Tibshirani (2023): acoperirea fără schimbabilitate
  - abaterea acoperirii este mărginită de distanțe ponderate în variație totală
  - între vectorul scorurilor și același vector în care scorul de test este schimbat cu scorul de calibrare i
- Mărimea acestor distanțe în prezența volatility clustering este o întrebare empirică
- Gibbs, Cherian & Candès (2025): acoperirea exactă condiționată pe o clasă de deplasări fixată dinainte este realizabilă
  - rămîne deschisă întrebarea ce clasă descrie o criză financiară
- Alegerea pasului ACI γ: Zaffran et al. (2022) agregă experți ACI pe o grilă de valori γ

Înapoi

Studiul de caz, alte rezultate principale

Rezultat	Sursa	Interpretare
Mărimile ESR strict și ESR auxiliar diferă cu cel mult 0,01 pentru fiecare proces și mărime a eșantionului, inclusiv AR(1)-GARCH cu $\phi = 0{,}5$	Tabelul 1	În aceste simulări, renunțarea la prognozele VaR aproape nu schimbă mărimea; puterea se compară separat (Fig. 2–3)
Student-t, fereastră de 250 de zile: ponderea de 0,12 provine din GARCH cu reestimare anuală; de la 500 de zile, GJR-GARCH-t și GARCH-t diferă cu cel mult 0,01	Tabelul 3	Efectul de levier din ecuația dispersiei aproape nu schimbă ponderile de respingere cînd fereastra este lungă

Înapoi

Studiul de caz, limite și extinderi

- Limitele precizate de autori
  - ESR auxiliar și ESR strict sînt doar bilaterale (lucrarea, Secț. 1.3)
  - Covarianța clasică respinge prea des în eșantioane mici
- Replicarea cu datele cursului (Seminarul 8, C3)
  - Aplicați ESR strict (bilateral) și ESR cu termen liber (unilateral) prognozelor ES 2,5% ale celor șase modele pe cele patru piețe; comparați cu Z_2 și McNeil–Frey
  - Extindeți replicarea Tabelului 3: GJR-GARCH, mai multe acțiuni și perioada de după august 2019
- Întrebare deschisă: o fereastră de supraveghere de un an
  - La $T = 250$, ESR cu termen liber bilateral are mărimea 0,04 cu covarianța robustă și 0,15 cu cea clasică (Tabelul 1, EGARCH-t)
  - Mărimea unilaterală este raportată doar pentru $T = 2\,500$: 0,02 (Tabelul 2)
  - Care este mărimea unilaterală pe un an?
  - Poate un bootstrap al statisticii t să o mențină la 5% fără a pierde puterea din Fig. 4?

Înapoi

Tabloul de bord pe patru piețe

- Fiecare celulă: rata de depășire a VaR 1% în % / p-value-ul pentru Z_2 / p-value-ul MCS (FZ0)

Model	S&P 500	BET	Bitcoin	EUR/RON
HS	1,67 / <0,001 / <0,001	1,17 / 0,134 / <0,001	0,77 / 0,863 / n/a	0,51 / 1,000 / n/a
Normal	2,70 / <0,001 / <0,001	1,90 / <0,001 / <0,001	1,74 / 0,001 / n/a	1,06 / 0,973 / n/a
Student-t	2,00 / 0,002 / <0,001	1,58 / 0,003 / <0,001	0,71 / 0,625 / n/a	0,85 / 0,920 / n/a
GARCH-t	1,77 / <0,001 / 0,010	1,46 / <0,001 / 0,096	n/a / n/a / n/a	n/a / n/a / n/a
FHS	1,23 / 0,209 / 1,000	1,20 / 0,236 / 1,000	n/a / n/a / n/a	n/a / n/a / n/a
GARCH-EVT	1,15 / 0,145 / 0,211	0,97 / 0,215 / 0,966	n/a / n/a / n/a	n/a / n/a / n/a

- n/a: prognoză GARCH reținută; pe Bitcoin și EUR/RON, MCS nu se calculează, deoarece cere toate cele șase modele (slide-ul despre prognozele reținute)

înapoi

Răspunsuri la verificările numerice

1. $\hat{\pi} = 0{,}006$; $\ln L(\alpha) = 497 \ln 0{,}99 + 3 \ln 0{,}01 = -18{,}81$, $\ln L(\hat{\pi}) = 497 \ln 0{,}994 + 3 \ln 0{,}006 = -18{,}34$
   - $\mathrm{LR}_{uc} = 2(-18{,}34 - (-18{,}81)) = 0{,}94 < 3{,}84$, $p = 0{,}33$: nu respingem; erau așteptate 5 depășiri
2. $L = 3\%$: $\frac{\mathbf{3-2}}{\mathbf{0{,}05 \cdot 2{,}5}} + \frac{\mathbf{2}}{\mathbf{2{,}5}} + \ln 2{,}5 - 1 = 8 + 0{,}8 + 0{,}916 - 1 = 8{,}716$; $L = 1\%$: $0{,}8 + 0{,}916 - 1 = 0{,}716$
   - în zecimale se schimbă doar $\ln e$, cu $\ln 0{,}01 = -4{,}605$: 4,111, respectiv $-3{,}889$
   - diferența dintre cele două zile rămîne aceeași
3. $\lambda = 1000 \cdot 0{,}01^{\mathbf{2}}/(0{,}01 \cdot 0{,}99) = 10{,}10$, $\sqrt{\lambda} = 3{,}178$
   - puterea $= \Phi(1{,}218) + \Phi(-5{,}138) = 0{,}888$ (al doilea termen este sub $10^{-\mathbf{6}}$): cele 88,8% ale curbei întrerupte pentru $T = 1000$
   - puterea exactă: 78%
4. $\sum_t L_t I_t / \mathrm{ES}_t = 5{,}5$, $N_T = 5$, $T\alpha = 6{,}25$
   - $Z_{\mathbf{1}} = 1 - 5{,}5/5 = -0{,}10$: în zilele de depășire, pierderile sînt în medie cu 10% mai adînci decît prognoza ES
   - $Z_{\mathbf{2}} = 1 - 5{,}5/6{,}25 = 0{,}12 > 0$: numărul de depășiri, mai mic decît cele 6,25 așteptate, compensează această adîncime
   - valoarea este departe de pragul de 5%, $-0{,}70$

◂ Verificări numerice

Bucla de cercetare (1/2): prompturi

- Prompturi (instrumente: Semantic Scholar, Elicit, Google Scholar; verificăm fiecare DOI pe Crossref)
  - `Enumeră lucrările evaluate de specialiști, din 2019 încoace, despre predicția conformală sub dependență serială, cu DOI, garanția exactă și ipotezele.`
  - `Dă trei explicații rivale pentru depășirile excesive în criză ale VaR conformal split și ce implică fiecare pentru ratele pe regimuri.`
  - `Joacă rolul unui referent critic: enumeră cele mai puternice motive pentru care acest efect de criză este un artefact și testul care ar tranșa fiecare motiv.`

Înapoi

Bucla de cercetare (2/2): verificările cercetătorului

- **Look-ahead bias: informație din viitor**
  - modificăm observațiile de după ziua $t-1$ și confirmăm că VaR_t, scala și indicatorul de criză nu se schimbă
- **Depășiri dependente**
  - testele Christoffersen și de durată sau un bootstrap pe blocuri al șirului depășirilor
- **Puterea**
  - 613 de zile de criză dau 6,1 depășiri așteptate ale VaR 1%
  - o rată reală de 2% este detectată cu probabilitatea 57% de un test Binomial exact bilateral la 5% (cu depășiri presupuse i.i.d.)
- **Testarea multiplă**: 4 piețe $\times$ 2 niveluri $\times$ 3 metode $=$ 24 de teste
  - Holm controlează FWER (rata erorii pe familia de teste)
  - Benjamini–Hochberg controlează FDR (rata descoperirilor false)
- **Teoreme enunțate greșit**
  - de exemplu, „ACI garantează acoperirea condiționată”
- **Cuantile decalate**
  - $k = \lceil (n+1)(1-\alpha) \rceil$ nu este implicit în `np.quantile`

Înapoi

Punct de plecare pentru proiect, acoperirea în criză

- Întrebări
  - poate o prognoză VaR 1% și ES 2,5% fără ipoteze de distribuție să atingă acoperirea condiționată de criză?
  - se menține această acoperire pe toate cele patru piețe, cu un test pre-înregistrat?
- Replicați mai întîi: ratele în criză ale VaR 5% conformal split (S&P 500 7,29%, EUR/RON 11,43%) și ponderea VaR 1% infinit la ACI (13,4% din toate zilele de evaluare S&P 500)
- Livrabile
  - O pre-înregistrare (ipoteze, teste, corecții, putere) datată înainte de prima rulare
  - O metodă candidată, de exemplu Gibbs, Cherian & Candès (2025) cu regimul de volatilitate drept clasă de condiționare; teste VaR pe regimuri; ES testat cu testul ES prin regresie (Bayer & Dimitriadis (2022)) sau cu Z_2
  - Codul, un raport de două pagini cu toate specificațiile încercate și o critică, în stilul unui referent, a propriului rezultat
- Consemnați fiecare prompt care a influențat o decizie în `AI_USE.md` și fiecare eroare a asistentului în `AI_ERRORS.md`: github.com/danpele/MFM/tree/main/project

înapoi

Acronime folosite în acest material (1/2)

- **ACI**: Adaptive Conformal Inference — *inferență conformală adaptivă*
- **AI**: Artificial Intelligence — *inteligență artificială*
- **AR**: AutoRegressive (model) — *model autoregresiv, ca în AR(1)-GARCH*
- **BCBS**: Basel Committee on Banking Supervision — *Comitetul de la Basel pentru Supraveghere Bancară*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BIS**: Bank for International Settlements — *Banca Reglementelor Internaționale*
- **BNR**: Banca Națională a României
- **COVID-19**: COronaVIrus Disease 2019 — *boala provocată de coronavirus, 2019*
- **DGP**: Data-Generating Process — *procesul generator al datelor*
- **DM**: Diebold–Mariano (test) — *testul Diebold–Mariano de comparare a prognozelor*
- **DQ**: Dynamic Quantile (test) — *testul cuantilei dinamice*
- **EGARCH**: Exponential GARCH — *GARCH exponențial*
- **ES**: Expected Shortfall — *pierderea așteptată în coadă*
- **ESR**: Expected Shortfall Regression (backtest) — *testul ES prin regresie*
- **EVT**: Extreme Value Theory — *teoria valorilor extreme*
- **FDR**: False Discovery Rate — *rata descoperirilor false*
- **FHS**: Filtered Historical Simulation — *simulare istorică filtrată*
- **FRTB**: Fundamental Review of the Trading Book — *revizuirea fundamentală a portofoliului de tranzacționare*
- **FWER**: Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **FZ**: Fissler–Ziegel (family of scoring functions for VaR and ES) — *familia Fissler–Ziegel de funcții de scor pentru VaR și ES*

Acronime folosite în acest material (2/2)

- **FZ0**: Fissler–Ziegel loss, zero-homogeneous version — *funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GARCH-EVT**: GARCH filter combined with Extreme Value Theory for the tail — *filtru GARCH combinat cu teoria valorilor extreme pentru coadă*
- **GAS**: Generalised Autoregressive Score (model) — *model cu scor autoregresiv generalizat*
- **GJR-GARCH**: Glosten–Jagannathan–Runkle GARCH — *GARCH asimetric Glosten–Jagannathan–Runkle*
- **GPD**: Generalised Pareto Distribution — *distribuția Pareto generalizată*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HS**: Historical Simulation — *simulare istorică*
- **IMA**: Internal Models Approach — *abordarea bazată pe modele interne*
- **LLM**: Large Language Model — *model lingvistic mare*
- **MCS**: Model Confidence Set — *mulțimea de încredere a modelelor*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **PIT**: Probability Integral Transform — *transformarea integrală a probabilității*
- **POF**: Proportion Of Failures (test) — *testul proporției de depășiri*
- **QLIKE**: Quasi-LIKElihood (loss function) — *funcția de pierdere de tip cvasi-verosimilitate*

Bibliografie (1/4)

- Acerbi, C., Szekely, B. (2014). Backtesting expected shortfall. MSCI Inc., December 2014.
- Angelopoulos, A.N., Bates, S. (2021). A gentle introduction to conformal prediction and distribution-free uncertainty quantification. arXiv:2107.07511.
- Barber, R.F., Candès, E.J., Ramdas, A., Tibshirani, R.J. (2023). Conformal prediction beyond exchangeability. *Annals of Statistics*, 51(2).
- Basel Committee on Banking Supervision (1996). Supervisory framework for the use of "backtesting" in conjunction with the internal models approach to market risk capital requirements. Bank for International Settlements.
- Basel Committee on Banking Supervision (2019). Minimum capital requirements for market risk (rev. February 2019). Bank for International Settlements.
- Bayer, S., Dimitriadis, T. (2022). Regression-based expected shortfall backtesting. *Journal of Financial Econometrics*, 20(3), 437–471.
- Christoffersen, P.F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- Christoffersen, P., Pelletier, D. (2004). Backtesting value-at-risk: a duration-based approach. *Journal of Financial Econometrics*, 2(1), 84–108.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.

Bibliografie (2/4)

- Du, Z., Escanciano, J.C. (2017). Backtesting expected shortfall: accounting for tail risk. *Management Science*, 63(4), 940–958.
- Ehm, W., Gneiting, T., Jordan, A., Krüger, F. (2016). Of quantiles and expectiles: consistent scoring functions, Choquet representations and forecast rankings. *Journal of the Royal Statistical Society, Series B*, 78(3), 505–562.
- Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- Escanciano, J.C., Olmo, J. (2010). Backtesting parametric value-at-risk with estimation risk. *Journal of Business & Economic Statistics*, 28(1), 36–51.
- Fissler, T., Ziegel, J.F. (2016). Higher order elicitability and Osband's principle. *Annals of Statistics*, 44(4).
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, 5th ed. Springer.
- Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- Gibbs, I., Candès, E. (2021). Adaptive conformal inference under distribution shift. *Advances in Neural Information Processing Systems*, 34; arXiv:2106.00170.
- Gibbs, I., Cherian, J.J., Candès, E.J. (2025). Conformal prediction with conditional guarantees. *Journal of the Royal Statistical Society, Series B*, 87(4), 1100–1126.

Bibliografie (3/4)

- Gneiting, T. (2011). Making and evaluating point forecasts. *Journal of the American Statistical Association*, 106(494), 746–762.
- Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (eds.) (2017). Applied Quantitative Finance, 3rd ed. Springer.
- Hoga, Y., Demetrescu, M. (2023). Monitoring value-at-risk and expected shortfall forecasts. *Management Science*, 69(5), 2954–2971.
- Kratz, M., Lok, Y.H., McNeil, A.J. (2018). Multinomial VaR backtests: a simple implicit approach to backtesting expected shortfall. *Journal of Banking & Finance*, 88, 393–407.
- Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- Lei, J., G'Sell, M., Rinaldo, A., Tibshirani, R.J., Wasserman, L. (2018). Distribution-free predictive inference for regression. *Journal of the American Statistical Association*, 113(523), 1094–1111.
- McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.

Bibliografie (4/4)

- Nolde, N., Ziegel, J.F. (2017). Elicitability and backtesting: perspectives for banking regulation. *Annals of Applied Statistics*, 11(4).
- Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413.
- Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). Modeling expected shortfall using tail entropy. *Entropy*, 21(12), 1204.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). Using high-frequency entropy to forecast Bitcoin's daily value at risk. *Entropy*, 21(2), 102.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- Zaffran, M., Féron, O., Goude, Y., Josse, J., Dieuleveut, A. (2022). Adaptive conformal predictions for time series. *Proceedings of the 39th International Conference on Machine Learning*; arXiv:2202.07282.