



## Modelarea piețelor financiare

### Capitolul 9: Volatilitate realizată



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Acronime folosite în acest material (1/2)

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AR: AutoRegressive (model) (model autoregresiv)
- ▣ BV: Bipower Variation (variația bipower)
- ▣ BVB: Bursa de Valori București
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ CLT: Central Limit Theorem (teorema limită centrală)
- ▣ DJIA: Dow Jones Industrial Average (indicele Dow Jones al marilor companii industriale americane)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ FDR: False Discovery Rate (rata descoperirilor false)
- ▣ FOMC: Federal Open Market Committee (Comitetul Federal pentru Piața Deschisă al Rezervei Federale)
- ▣ FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- ▣ FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GMM: Generalized Method of Moments (metoda generalizată a momentelor)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- ▣ HAR-CJ: HAR model with Continuous and Jump components (model HAR cu componentă continuă și componentă de salt)
- ▣ HAR-RV: Heterogeneous AutoRegressive model of Realised Volatility (model autoregresiv heterogen al volatilității realizate)
- ▣ HARQ: HAR model with Realised Quarticity (model HAR cu cvarticitatea realizată)
- ▣ HEAVY: High-frEQUENCY-bAsed VolatilitY (models) (modele de volatilitate bazate pe date de înaltă frecvență)
- ▣ IQ: Integrated Quarticity (cvarticitatea integrată)
- ▣ LLM: Large Language Model (model lingvistic mare)
- ▣ MAE: Mean Absolute Error (eroarea absolută medie)
- ▣ MCS: Model Confidence Set (mulțimea de încredere a modelelor)

## Acronime folosite în acest material (2/2)

- ▣ ML: Machine Learning (învățare automată)
- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- ▣ NYSE: New York Stock Exchange (Bursa din New York)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ RF: Random Forest (pădure aleatoare)
- ▣ RK: Realised Kernel (nucleul realizat)
- ▣ RQ: Realised Quarticity (cvarticitatea realizată)
- ▣ RV: Realised Variance (varianța realizată)
- ▣ SE: Standard Error (eroare standard)
- ▣ SHAR: Semivariance HAR model (model HAR cu semivarianțe)
- ▣ SUA: Statele Unite ale Americii
- ▣ TRV: Truncated Realised Variance (varianța realizată trunchiată)
- ▣ TSRV: Two-Scale Realised Variance (varianța realizată pe două scări)
- ▣ UTC: Coordinated Universal Time (Temps Universel Coordonné) (timpul universal coordonat)
- ▣ VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)
- ▣ VRP: Variance Risk Premium (prima de risc a varianței)

## Cuprins

Motivație

Varianța realizată

Zgomotul de microstructură

Salturi

Fapte stilizate ale volatilității realizate

Modelul HAR-RV

Prognoze: HAR vs GARCH

Volatilitatea aspră

Studiu de caz: învățare automată vs HAR

AI pentru descoperire științifică

Sinteză

Bibliografie

## Volatilitatea este latentă: o putem măsura?

### Problema

- Volatilitatea determină riscul (Capitolele 7–8), prețurile opțiunilor (Capitolul 12) și ponderile portofoliilor (Capitolul 4)
- Dar nu este observată niciodată: un randament zilnic este o singură observație dintr-o distribuție a cărei dispersie vrem să o estimăm
- GARCH (Capitolul 5) **deduce** varianța de azi din randamentele zilnice trecute, printr-un model

### Ideea acestui capitol

- Într-o singură zi există sute de modificări de preț: le adunăm pătratele
- Suma **măsoară** varianța zilei aproape fără model: varianța realizată [Andersen & Bollerslev \(1998\)](#)
- Volatilitatea măsurată poate fi apoi modelată și prognozată ca orice serie de timp
- O contribuție timpurie: [Merton \(1980\)](#) a arătat că varianța, spre deosebire de medie, se estimează mai bine cu date mai frecvente

## Volatilitatea realizată: de la sceptici la standard



Torben G. Andersen, 2012

Foto: [Soralum \(2012\)](#); CC BY-SA 4.0; [Wikimedia Commons](#)

- Întâi măsurăm, apoi modelăm: [Andersen, Bollerslev, Diebold & Labys \(2001\)](#), [Andersen, Bollerslev, Diebold & Ebens \(2001\)](#) studiază distribuția volatilității realizate; [Andersen, Bollerslev, Diebold & Labys \(2003\)](#) o prognozează direct
- De ce scepticii au greșit (Secțiunea 7) și prezentarea din manual: [Franke, Härdle & Hafner \(2019\)](#)

## Datele folosite în acest capitol

| Seria                | Frecvența                                  | Perioada       | Zile                   |
|----------------------|--------------------------------------------|----------------|------------------------|
| SPY (ETF pe S&P 500) | bare de 5 minute, 09:30–16:00 ora New York | 2020–2026      | 1 489                  |
| Bitcoin              | bare de 5 minute, zile UTC de 24 de ore    | 2024–2026      | 659                    |
| SPY, Bitcoin         | prețuri zilnice de închidere               | 2000/2014–2026 | pentru GARCH           |
| VIX                  | valoare zilnică la închidere               | 2020–2026      | volatilitate implicită |

- Până la 18 septembrie 2026; randamente  $r_i = 100(\ln P_i - \ln P_{i-1})$  în %; o bară este etichetată cu ora de început
- SPY: 78 de randamente într-o zi completă, 42 în zilele cu program redus; barele din afara grilei de 5 minute sunt eliminate; barele lipsă dintr-o zi preiau ultimul preț
- Bitcoin: 288 de randamente pe zi; zilele cu mai puțin de 95% din bare sunt eliminate (88 din 747 zile calendaristice, mai ales un gol de date în octombrie 2025)

## Un model pentru prețurile intraday

- Notății: ziua  $t$  are  $M$  intervale de lungime  $\Delta = 1/M$ , randamente  $r_{t,i}$ , randamentul zilnic  $r_t = \sum_i r_{t,i}$ 
  - ▶ Variante în %<sup>2</sup>; volatilitatea anualizată  $\sqrt{252} \times \text{varianța (SPY)}$ ,  $\sqrt{365} \times \text{varianța (Bitcoin)}$ ; randamentul SPY peste noapte (închidere – deschiderea următoare) este în afara barelor
- Logaritmul prețului în timp continuu:  $dp(s) = \mu(s) ds + \sigma(s) dW(s)$ , cu  $W$  o mișcare browniană (Capitolul 11)
  - ▶  $\sigma(s)$  este **volatilitatea instantanee**: se schimbă în cursul zilei și de la o zi la alta
- **Varianța integrată** a zilei  $t$ : mărimea pe care vrem să o măsurăm
  - ▶  $IV_t = \int_{t-1}^t \sigma^2(s) ds$
- Dacă  $\sigma$  este independent de  $W$  (fără efect de pârghie) și deriva este nulă (sau determinată de traiectoria lui  $\sigma$ ), atunci, dată fiind această traiectorie, randamentul zilnic urmează distribuția Normală:  $r_t | \sigma \sim N(\int \mu, IV_t)$ 
  - ▶ Cu efect de pârghie (Secțiunea 6) această normalitate condiționată nu mai are loc, dar teoria limită a RV de mai jos rămâne valabilă
- $IV_t$  este varianța zilnică naturală;  $\sigma_t^2$  din GARCH este o prognoză a ei, bazată pe model și pe informația de ieri


## Definiție: varianța realizată

- **Varianța realizată:** suma pătratelor randamentelor intraday

►  $RV_t = \sum_{i=1}^M r_{t,i}^2$ , volatilitatea realizată =  $\sqrt{RV_t}$

- Când  $M \rightarrow \infty$ ,  $RV_t \rightarrow IV_t$ : deriva dispare, iar suma pătratelor converge la **variația pătratică** [Barndorff-Nielsen & Shephard \(2002\)](#)
  - Media randamentelor SPY de 5 minute este sub 1% din abaterea lor standard: poate fi ignorată
- Fără parametri de estimat:  $RV_t$  este o măsurare **fără model** a varianței unei zile
- Randamentul zilnic la pătrat  $r_t^2$  este cazul particular  $M = 1$ : nedeplasat (cu derivă nulă), dar extrem de zgomotos

## O zi, 78 de randamente: 7 aprilie 2025




□ Stânga: SPY pe bare de 5 minute în cea mai volatilă zi din eșantion; dreapta: suma cumulată a pătratelor randamentelor

## Interpretarea graficului: 7 aprilie 2025

- SPY a deschis cu  $-3,27\%$  sub închiderea anterioară, după anunțurile privind tarifele vamale; au urmat 78 randamente de 5 minute
  - ▶  $RV = 45,1\%^2$ : volatilitatea realizată anualizată  $\sqrt{252 \times 45,1} = 107\%$
- Un singur randament de 5 minute de  $+4,28\%$  (intervalul care se încheie la 10:15) a contribuit cu 41% din varianța realizată a zilei
- De la deschidere la închidere ziua s-a încheiat cu  $+3,09\%$ : randamentul zilnic singur ar numi-o o zi obișnuită, varianța realizată o numește una dintre cele mai agitate zile din 2020 încoace

## Volatilitatea realizată zilnică: SPY și Bitcoin




- Anualizată, din randamente de 5 minute; SPY: sesiunea regulată din SUA; Bitcoin: 24 de ore; golul din octombrie 2025 reprezintă date lipsă

## Interpretarea seriilor de volatilitate realizată

- SPY: volatilitatea din RV medie  $\sqrt{252 \overline{RV}} = 12,9\%$  pe an, ziua mediană 9,7%, interval de la 2,4% la 106,7%
  - ▶ Peste ziua mediană: câteva zile foarte volatile domină varianța medie (o medie pătratică, nu o medie a volatilităților zilnice)
- Bitcoin:  $\sqrt{365 \overline{RV}} = 45,1\%$  pe an, mediana 37,8%, maximul 136,1% pe 2026-02-05
- Ambele serii arată **gruparea volatilității**, ca la GARCH (Capitolul 5), dar fiecare punct este o măsurare, nu rezultatul unui model

## Unde este riscul: ziua sau noaptea?



- SPY, varianța zilnică medie pe ani, anualizată: varianța realizată intraday plus randamentul peste noapte la pătrat; 2020 și 2026 sunt ani incompleți

## Interpretarea descompunerii peste noapte

- Randamentele peste noapte aduc 38% din varianța zilnică SPY, deși piața este închisă 17,5 ore
  - ▶ Știrile (rezultate financiare, date macroeconomice, sesiunile din Asia și Europa) se acumulează și sunt încorporate în preț la deschidere
- Anualizat: închidere-închidere 16,6%; deschidere-închidere 13,6%; peste noapte 10,1%
- Cea mai mare mișcare peste noapte:  $-4,08\%$  pe 2024-08-05
- Pentru riscul zilnic folosim varianța **totală**:  $RV_t + r_{\text{noapte},t}^2$  (media anualizată 16,4%)
  - ▶ Alternative: scalarea RV intraday în sus sau ponderarea optimă a celor două părți [Hansen & Lunde \(2005\)](#)


## Cadrul: semimartingale Itô și convergența stabilă

- Semimartingală Itô:  $dp = \mu ds + \sigma dW + dJ$ , cu  $\mu$ ,  $\sigma$  adaptate și  $\sigma$  càdlàg;  $\sigma$  poate depinde de  $W$  (efect de pârghie)
  - ▶ Fără salturi:  $\sqrt{M}(RV_t - IV_t) \xrightarrow{\mathcal{L}-s} MN(0, 2IQ_t)$ , o distribuție Normală **mixtă**, a cărei varianță  $2IQ_t$ , cu cvarticitatea integrată  $IQ$ ,  $IQ_t = \int \sigma^4(s) ds$ , este ea însăși aleatoare [Barndorff-Nielsen & Shephard \(2002\)](#)
- Convergența **stabilă** ( $\mathcal{L}$ -s): limita are loc simultan cu orice variabilă din  $\sigma$ -algebra traiectoriei [Mykland & Zhang \(2009\)](#)
  - ▶ De aceea  $(RV_t - IV_t)/\sqrt{2RQ_t/M} \rightarrow N(0, 1)$ : studentizarea cu  $\sqrt{2RQ_t/M}$ , unde  $RQ_t \rightarrow IQ_t$  este aleatoare, este legitimă doar sub convergența stabilă
- În eșantioane finite: statistica  $t$  pentru  $\ln RV_t$  are acoperire mai bună decât cea pe niveluri [Barndorff-Nielsen & Shephard \(2005\)](#); o folosim pe slide-ul următor

## Cât de precisă este varianța realizată?

- Teorema limită centrală fezabilă pentru RV Barndorff-Nielsen & Shephard (2002):  
 $\sqrt{M} (RV_t - IV_t) / \sqrt{2 RQ_t} \rightarrow N(0, 1)$ 
  - ▶  $IV_t$  este estimată prin cvarticitatea realizată  $RQ_t = \frac{M}{3} \sum_i r_{t,i}^4$
- Eroarea standard:  $se(RV_t) = \sqrt{\frac{2}{3} \sum_i r_{t,i}^4}$
- CI de 95% pe scara log (întotdeauna pozitiv):  $RV_t \exp(\pm 1,96 se(RV_t) / RV_t)$ 
  - ▶ Cu volatilitate constantă,  $se/RV \approx \sqrt{2/M}$ : 16% pentru  $M = 78$
- RV este o măsurare **cu eroare**: contează atunci când RV este ținta unei prognoze (Secțiunea 6)

## Intervale de încredere pentru volatilitatea zilnică




□ SPY, martie–mai 2025; banda: intervalul de încredere de 95% pentru  $\sqrt{252 IV_t}$  din cvarticitatea realizată

## Interpretarea intervalelor de încredere

- Lățimea relativă mediană a intervalului (pentru volatilitate): 37% din nivelul ei
  - ▶ Banda presupune un preț continuu și zgomot neglijabil: într-o zi cu salt RV tinde la  $IV_t + \sum_j \kappa_j^2$ , deci acoperă variația totală, nu  $IV_t$  (Secțiunea 4)
- 9 aprilie 2025 (ziua în care a fost anunțată amânarea tarifelor): volatilitate 72%, CI [55%, 93%]
  - ▶ Intervalul se lărgeste când câteva randamente domină suma:  $\sum r^4$  crește mai repede decât  $(\sum r^2)^2$
- Totuși mult mai precisă decât  $r_t^2$ , a cărei eroare relativă este de ordinul  $\sqrt{2} \approx 141\%$  sub distribuția Normală
- Regulă practică: volatilitatea unei singure zile este cunoscută cu aproximativ  $\pm 20\%$  (bandă de 95%), iar mediile pe săptămâni mult mai precis

## Sezonalitatea intraday



□ Stânga: SPY, media  $|r_{t,i}|$  pe intervale de 5 minute ale zilei (doar zile complete); dreapta: Bitcoin pe ore UTC

## Interpretarea tiparului sezonier

- SPY: o **formă de U**: 0,106% în primele 5 minute, 0,050% la prânz, 0,089% în ultimele 5 minute [Andersen & Bollerslev \(1997\)](#)
  - ▶ Deschiderea încorporează știrile de peste noapte; închiderea concentrează reechilibrările indicilor și ale fondurilor
- Bitcoin se tranzacționează non-stop, dar este cel mai volatil la ora 14:00 UTC, în jurul deschiderii bursei din SUA (09:30 la New York: 13:30 UTC vara, 14:30 UTC iarna); cel mai calm la 10:00 UTC (raport 2,2)
- RV însumează pe toată ziua, deci sezonalitatea nu o deplasează; în schimb, deplasează BV:
 
$$\mathbb{E}|r_i| |r_{i-1}| \propto \sigma_i \sigma_{i-1} \leq (\sigma_i^2 + \sigma_{i-1}^2)/2$$
, deci schimbările rapide de scară cresc RV – BV, iar testul de salturi (Secțiunea 4) respinge prea des
  - ▶ Remediu: împărțim  $r_{t,i}$  la un factor de periodicitate  $f_i$  (estimatorul abaterii standard din [Boudt, Croux & Laurent \(2011\)](#)):  $f = 1,78$  la deschidere, 0,73 la minim; respingerile SPY la 5%: 235  $\rightarrow$  167

## Recapitulare: varianța realizată

- ▣  $RV_t = \sum_i r_{t,i}^2$  măsoară varianța integrată fără model; precizia crește cu  $M$
- ▣ Cvarticitatea realizată dă eroarea ei standard: aproximativ  $\sqrt{2/78} = 16\%$  din RV pentru o zi cu date de 5 minute, adică o bandă de 95% de aproximativ  $\pm 20\%$  pentru volatilitate
- ▣ Pentru SPY, randamentele peste noapte adaugă 38% din varianța zilnică: folosim varianța totală pentru riscul zilnic
- ▣ Volatilitatea urmează o formă de U în cursul zilei (SPY) și un tipar pe ore UTC (Bitcoin)


## De ce nu folosim fiecare tranzacție?

- Prețurile observate nu sunt prețul eficient:  $p_i^{\text{obs}} = p_i^* + \varepsilon_i$ 
  - ▶ Sursele lui  $\varepsilon$ : oscilația între bid și ask, pasul de cotare (discretizarea prețului), cotații învechite (Capitolul 10)
- Cu zgomot i.i.d. de varianță  $\omega^2$  și  $n$  randamente pe zi [Zhang, Mykland & Aït-Sahalia \(2005\)](#), [Hansen & Lunde \(2006\)](#)
  - ▶  $\mathbb{E}[\text{RV}_t^{(n)} \mid \sigma] = \text{IV}_t + 2n\omega^2$ : deplasarea **crește** cu frecvența de eșantionare
  - ▶ Randamentele observate devin autocorelate negativ:  $\text{cov}(r_i, r_{i-1}) = -\omega^2$
- Compromis: mai multe randamente reduc eroarea de eșantionare, dar adaugă deplasare din zgomot

## Derivarea deplasării din zgomot și a frecvenței optime

- Randamentul observat  $r_i = r_i^* + \varepsilon_i - \varepsilon_{i-1}$ , cu  $\varepsilon$  i.i.d.  $(0, \omega^2)$ , independent de  $p^*$ 
  - Dată fiind traiectoria lui  $\sigma$  (derivă nulă):  $\mathbb{E}[\text{RV}^{(n)} \mid \sigma] = \sum_i \mathbb{E}[r_i^{*2} \mid \sigma] + \sum_i \mathbb{E}[(\varepsilon_i - \varepsilon_{i-1})^2] = \text{IV} + 2n\omega^2$ ;  
 $\text{cov}(r_i, r_{i-1}) = -\mathbb{E}[\varepsilon_{i-1}^2] = -\omega^2$
  - Din legea numerelor mari pentru termenii de zgomot,  $\text{RV}^{(n)}/(2n) \xrightarrow{P} \omega^2$  când  $n \rightarrow \infty$ : RV din toate tranzacțiile estimează zgomotul, nu IV [Bandi & Russell \(2008\)](#)
- MSE:  $\mathbb{E}[(\text{RV}^{(n)} - \text{IV})^2] \approx \underbrace{2 \text{IQ}/n}_{\text{discretizare}} + \underbrace{4n^2\omega^4}_{\text{deplasarea la pătrat}} + O(n)$ 
  - Condiția de ordinul întâi  $-2 \text{IQ}/n^2 + 8n\omega^4 = 0$  dă  $n^* = (\text{IQ}/(4\omega^4))^{1/3}$  [Bandi & Russell \(2008\)](#)
- Cifre:  $\text{IV} = 1\%^2$ ,  $\text{IQ} = 1$ ,  $\omega = 0,01\%$ : deplasarea 0,016 la 5 minute, 4,680 la 1 secundă;  $n^* = 292$  (un randament la fiecare 80 s)

## Graficul semnăturii volatilității: simulare



100 de zile simulate, un preț pe secundă; prețul eficient cu volatilitate zilnică aleatoare plus zgomot i.i.d.,  $\omega = 0,01\%$

## Interpretarea graficului de semnătură simulat

- IV medie adevărată = 0,98; RV din prețurile observate: 5,66 la 1 secundă, 1,06 la 1 minut, 0,98 la 5 minute
  - ▶ Deplasarea corespunde lui  $2n\omega^2$  de pe slide-ul anterior
- Fără zgomot, RV este constantă în raport cu intervalul de eşantionare: creșterea la frecvențe mari este amprenta zgomotului
- Estimatori robuști la zgomot pe date de 1 secundă: RV pe două scări 0,95, nucleul realizat 0,99
  - ▶ Abaterea standard a erorii pe zile: RV pe 5 minute 0,187, pe două scări 0,150, nucleu 0,045: folosirea tuturor datelor aduce câștig doar cu o corecție de zgomot

## Remedii: eşantionare rară și subeșantionare

- **Eșantionarea rară:** folosim un randament la fiecare 5 minute în loc de fiecare tranzacție
  - ▶ Simplă și robustă; aruncă majoritatea datelor [Liu, Patton & Sheppard \(2015\)](#)
- **Subeșantionarea:** calculăm RV pe  $K$  grile decalate (decalaje  $0, 1, \dots, K - 1$ ) și facem media
  - ▶  $RV_t^{\text{avg}} = \frac{1}{K} \sum_{k=0}^{K-1} RV_t^{(k)}$ : aceeași deplasare ca o singură grilă rară, varianță mai mică
- **RV pe două scări (TSRV)** [Zhang, Mykland & Aït-Sahalia \(2005\)](#): eliminăm deplasarea rămasă cu RV din toate datele
  - ▶  $TSRV_t = RV_t^{\text{avg}} - \frac{\bar{n}}{n} RV_t^{\text{all}}$ ,  $\bar{n} = (n - K + 1)/K$ ; se împarte la  $1 - \bar{n}/n$  în eşantioane mici
  - ▶  $\bar{n}$  este numărul mediu de randamente pe o grilă rară; grilele noastre păstrează și deschiderea, și închiderea, deci  $\bar{n}$  este numărul lor mediu efectiv

## Nuclee realizate



Neil Shephard, 2004

Foto: Renate Schmid (2004); CC BY-SA 2.0  
de; Wikimedia Commons

- **Nucleul realizat** Barndorff-Nielsen, Hansen, Lunde & Shephard (2008): adăugăm autocovarianțele ponderate ale randamentelor
  - ▶  $RK_t = \gamma_0 + 2 \sum_{h=1}^H k\left(\frac{h}{H+1}\right) \gamma_h$ ,  $\gamma_h = \sum_i r_{t,i} r_{t,i-h}$
  - ▶ Funcția de ponderare Parzen  $k$ : 1 în 0, scade lin la 0 în 1; păstrează RK pozitiv
- Zgomotul face  $\gamma_1$  negativ; nucleul îl adaugă înapoi și anulează deplasarea
- Lățimea de bandă  $H$  crește cu raportul zgomot/semnal:  $H \approx 3,5 \xi^{4/5} n^{3/5}$ ,  $\xi^2 = \omega^2 / \sqrt{IQ}$
- Shephard și coautorii au dezvoltat nucleele, variația bipower și teoria asimptotică a RV

## Ratele de convergență în prezența zgomotului


| Estimator                          | Eroare de ordinul                       | Pozitiv | Sursa                                              |
|------------------------------------|-----------------------------------------|---------|----------------------------------------------------|
| RV pe toate tranzacțiile           | inconsistent (deplasare $2n\omega^2$ )  | da      | Bandi & Russell (2008)                             |
| RV rară, grilă fixă de 5 minute    | $M^{-1/2}$ , $M$ fix; deplasarea rămâne | da      | Liu, Patton & Sheppard (2015)                      |
| RV pe două scări                   | $n^{-1/6}$                              | nu      | Zhang, Mykland & Aït-Sahalia (2005)                |
| RV pe mai multe scări              | $n^{-1/4}$                              | nu      | Zhang (2006)                                       |
| Nucleu realizat, flat-top / Parzen | $n^{-1/4}$ / $n^{-1/5}$                 | nu / da | Barndorff-Nielsen, Hansen, Lunde & Shephard (2008) |
| Pre-mediarea                       | $n^{-1/4}$                              | nu      | Jacod, Li, Mykland, Podolskij & Vetter (2009)      |

- $n^{-1/4}$  este rata optimă cu zgomot i.i.d.: prețul zgomotului este jumătate din exponentul obișnuit
- Cu  $n = 23\,400$  de secunde:  $n^{1/4} \approx 12,4$ , față de  $\sqrt{78} \approx 8,8$  pentru RV pe 5 minute: cel mult un câștig modest, ceea ce explică Liu, Patton & Sheppard (2015)

## Pre-medierea

- Medii locale ale unui număr de  $k_n \approx \theta\sqrt{n}$  randamente cu o pondere  $g$  pe  $[0, 1]$ , de ex.  $g(x) = \min(x, 1 - x)$  [Jacod, Li, Mykland, Podolskij & Vetter \(2009\)](#)
  - ▶  $\bar{r}_i = \sum_{j=1}^{k_n-1} g(j/k_n) r_{i+j}$ : varianța zgomotului scade ca  $1/k_n$ , semnalul păstrează ordinul  $k_n/n$
- Estimatorul, cu  $\psi_1 = \int_0^1 g'(x)^2 dx$ ,  $\psi_2 = \int_0^1 g(x)^2 dx$  (1 și 1/12 pentru  $g$  triunghiular)
  - ▶  $\widehat{IV} = \frac{1}{\theta \psi_2 \sqrt{n}} \sum_i \bar{r}_i^2 - \frac{\psi_1}{2 \theta^2 \psi_2 n} \sum_i r_i^2$  (al doilea termen: corecția deplasării din zgomot)
- Rata  $n^{-1/4}$ ; același procedeu dă estimatori robuști la salturi (bipower pre-mediat) și estimatori de covarianță
- Construită pentru date tick cu tick: pe bare de 5 minute rămâne puțin zgomot de mediat (slide-urile următoare)

## Graficul semnăturii pe date reale



- Volatilitatea anualizată din RV medie în funcție de intervalul de eșantionare: o singură grilă vs media pe toate grilele decalate

## Interpretarea graficului de semnătură empiric

- SPY: 12,9% la 5 minute, 12,8% la 30 de minute, 13,0% la 130 de minute: constantă
  - ▶ Autocorelația de ordinul 1 a randamentelor de 5 minute:  $-0,008$  (SPY),  $0,005$  (Bitcoin): zgomot invizibil la 5 minute
- Bitcoin: 45,1% la 5 minute, 44,5% la 6 ore: tot constantă
- Pe date SPY de 5 minute:  $RV$  pe două scări /  $RV = 0,97$ , nucleu realizat /  $RV = 0,95$ ; corelații cu  $RV$  0,89 și 0,85
  - ▶ Diagnosticile arată o deplasare mică din zgomot la 5 minute: corecțiile modifică  $RV$  cu câteva procente și adaugă variabilitate de estimare
- În acord cu [Liu, Patton & Sheppard \(2015\)](#): aproape 400 de estimatori pe 31 de active întrec rareori  $RV$  pe 5 minute; estimatorii robuști la zgomot aduc câștig când zgomotul este mare față de semnal (date tick cu tick sau la nivel de secundă, active nelichide)

## Covarianța realizată și tranzacționarea asincronă

- Covarianța realizată  $\sum_i r_{t,i}^{(1)} r_{t,i}^{(2)} \rightarrow \int \sigma_{12}(s) ds$  cere prețurile ambelor active pe **aceeași** grilă
  - ▶ Efectul Epps **Epps (1979)**: corelația măsurată scade spre 0 când eșantionarea devine mai deasă, deoarece tranzacțiile sunt asincrone, iar ultimul preț este învechit
- **Hayashi & Yoshida (2005)**: însumăm produsele **tuturor** perechilor de randamente ale căror intervale de timp se suprapun
  - ▶  $\sum_{i,j} r_i^{(1)} r_j^{(2)} 1\{(t_{i-1}, t_i] \cap (s_{j-1}, s_j] \neq \emptyset\}$ : nedeplasat fără sincronizare (în absența zgomotului)
- Cu zgomot în plus: versiuni pre-mediate sau nuclee multivariate; aplicație: riscul intraday al portofoliilor (Capitolul 4)

## Recapitulare: zgomotul de microstructură

- Zgomotul adaugă  $2n\omega^2$  la RV: eşantionarea prea deasă supraestimează volatilitatea
- Graficul semnăturii este diagnosticul: RV nu ar trebui să depindă de intervalul de eşantionare
- Remedii: eşantionarea la 5 minute, subeşantionarea, RV pe două scări ( $n^{-1/6}$ ), nucleele realizate şi pre-mediarea ( $n^{-1/4}$ )
- Pentru active lichide la 5 minute (SPY, Bitcoin), RV simplă este reperul

## Prețurile sar

- Adăugăm salturi în model:  $dp = \mu ds + \sigma dW + dJ$ , cu  $J$  un proces de salturi (știri, Capitolul 11)
  - Variația pătratică are acum două părți:  $RV_t \rightarrow IV_t + \sum_j \kappa_j^2$ , cu  $\kappa_j$  mărimile salturilor din ziua  $t$
- De ce le separăm? Salturile sunt mai puțin persistente decât volatilitatea difuzivă și sunt evaluate diferit (opțiuni, Capitolul 12)
- Avem nevoie de un estimator al lui  $IV_t$  care ignoră salturile

## Variația bipower



Ole E. Barndorff-Nielsen, 2007


Foto: Thomas Steiner (2007); CC BY-SA 2.5;  
Wikimedia Commons

- **Variația bipower** Barndorff-Nielsen & Shephard (2004): produse ale valorilor absolute ale randamentelor consecutive
  - ▶  $BV_t = \mu_1^{-2} \frac{M}{M-1} \sum_{i=2}^M |r_{t,i}| |r_{t,i-1}| \rightarrow IV_t$
  - ▶  $\mu_1 = \mathbb{E}|Z| = \sqrt{2/\pi} = 0,798$  pentru  $Z \sim N(0, 1)$ , deci  $\mu_1^{-2} = \pi/2 = 1,571$
- Un salt afectează un singur randament: acesta este înmulțit cu un randament învecinat de valoare absolută mică, deci efectul lui dispare când  $M$  crește
- Partea de salt a zilei:  $\max(RV_t - BV_t, 0)$
- Barndorff-Nielsen (1935–2022) a contribuit și la dezvoltarea modelelor bazate pe procese Lévy folosite pentru salturi

## Un test pentru salturi

- ▣ Statistica raportului Huang & Tauchen (2005), Barndorff-Nielsen & Shephard (2006):  $z_t = \frac{(RV_t - BV_t)/RV_t}{\sqrt{\theta M^{-1} \max(1, TQ_t/BV_t^2)}}$ 
  - ▶  $\theta = \pi^2/4 + \pi - 5 = 0,609$ ; cvarticitatea tripower  $TQ_t = M\mu_{4/3}^{-3} \frac{M}{M-2} \sum_i |r_{t,i}|^{4/3} |r_{t,i-1}|^{4/3} |r_{t,i-2}|^{4/3}$ ,  $\mu_{4/3} = \mathbb{E}|Z|^{4/3}$
- ▣ Fără salturi  $z_t \rightarrow N(0, 1)$ ; un salt face  $RV > BV$  și  $z_t$  mare și pozitiv
- ▣ Un test pe zi: la nivelul  $\alpha$  ne așteptăm la un număr de alarme false egal cu  $\alpha \times$  numărul de zile fără salturi
  - ▶ Folosim  $\alpha = 0,1\%$  (valoarea critică 3,09): aproximativ 1,5 zile clasificate eronat ca zile cu salt pentru SPY
- ▣ Zi cu salt semnificativ: componenta de salt  $J_t = RV_t - BV_t$ , partea continuă  $C_t = RV_t - J_t$ ; altfel  $J_t = 0$

## Zile cu salt: SPY și Bitcoin



□ Punctele roșii: zile cu salt semnificativ la nivelul de 0,1%; mărimea punctului este proporțională cu partea de salt  $J_t$

## Interpretarea testului de salturi

- SPY: 35 zile cu salt din 1 489 (2,4%); salturile reprezintă 2,8% din varianța realizată totală
  - ▶ Într-o zi cu salt, saltul reprezintă în medie 35% din RV a zilei;  $BV/RV$  are media 0,95 pe toate zilele
  - ▶ Cea mai mare statistică: 2021-08-27 ( $z = 5,2$ ), salt în intervalul 10:00–10:05, când a fost publicat discursul președintelui Rezervei Federale de la Jackson Hole
- Bitcoin: 67 zile cu salt din 659 (10,2%), dar doar 1,8% din varianță
  - ▶ Multe salturi mici în zile liniștite (weekenduri): o singură mișcare izolată domină o zi calmă
- Zilele agitate din aprilie 2025 **nu** sunt în mare parte zile cu salt: multe randamente mari la rând cresc și BV

## Multe zile, multe teste: salturi false

- 1 489 teste zilnice la 5%: 235 respingeri față de 74 așteptate fără salturi; care dintre ele sunt false?
- [Benjamini & Hochberg \(1995\)](#): ordonăm valorile  $p$  și respingem cele mai mici  $k$ , cu  $k$  cel mai mare indice pentru care  $p_{(k)} \leq kq/N$ ; FDR,  $\mathbb{E}[\text{false/respingeri}]$ , rămâne  $\leq q$  (cu false/respingeri := 0 când nu se respinge nimic)
  - ▶ Garanția cere valori  $p$  valide, independente sau pozitiv dependente [Benjamini & Yekutieli \(2001\)](#); testele zilnice de salt îndeplinesc aceste condiții doar aproximativ
  - ▶ SPY: FDR la 5%: 42 zile cu salt; la 1%: 9; Bonferroni (FWER 5%): 7; FDR 5% după corecția de periodicitate: 17
- [Bajgrowicz, Scaillet & Treccani \(2016\)](#): fără controlul multiplicității majoritatea salturilor detectate sunt false; cele adevărate sunt rare și se grupează pe știri
- [Christensen, Oomen & Podolskij \(2014\)](#): la frecvența tick cu tick majoritatea „salturilor” de 5 minute sunt explozii de volatilitate abrupte, dar continue

## Localizarea salturilor în cursul zilei: Lee–Mykland

- Lee & Mykland (2008):  $L_{t,i} = r_{t,i}/\hat{\sigma}_{t,i}$ , cu  $\hat{\sigma}_{t,i}^2$  media bipower a celor  $K = 270$  randamente anterioare (valoarea lor pentru date de 5 minute)
  - ▶ Fără salturi,  $\max_i |L_i|$  pe  $n$  randamente are o limită Gumbel: respingem dacă  $(|L| - C_n)/S_n > -\ln(-\ln(1 - \alpha))$ , cu  $C_n = \sqrt{2 \ln n} - \frac{\ln \pi + \ln \ln n}{2\sqrt{2 \ln n}}$  și  $S_n = 1/\sqrt{2 \ln n}$  ( $\hat{\sigma}^2$  al nostru include factorul  $\pi/2$ , deci constanta  $c = \sqrt{2/\pi}$  din Lee & Mykland (2008) devine 1)
  - ▶ SPY, randamente împărțite la  $f_i$ ,  $\alpha = 1\%$ ,  $n = 115\,453$  (întregul eșantion): pragul  $|L| > 5,41$
- 169 salturi în 105 zile; 62 dintre ele miercurea între 14:00 și 15:00, când se publică comunicatele FOMC (14:00) și au loc conferințele de presă (14:30)
  - ▶ Cel mai mare:  $L = -22,9$  pe 2025-10-29; doar 10% din aceste zile sunt semnalate și de testul zilnic al raportului
- Cele două teste pun întrebări diferite: un randament extrem față de volatilitatea locală, respectiv un decalaj zilnic între RV și BV


## Estimatori ai varianței integrate robuste la salturi

- RV trunchiată Mancini (2009):  $TRV_t = \sum_i r_{t,i}^2 \mathbf{1}\{|r_{t,i}| \leq c \hat{\sigma}_t f_i \Delta^\varpi\}$ ,  $\varpi \in (0, 1/2)$ 
  - Incrementele difuzive sunt  $O_p(\Delta^{1/2})$  și ajung sub prag; salturile sunt  $O(1)$  și sunt eliminate
- MedRV Andersen, Dobrev & Schaumburg (2012):  $\frac{\pi}{6-4\sqrt{3}+\pi} \frac{M}{M-2} \sum_i \text{med}(|r_{i-1}|, |r_i|, |r_{i+1}|)^2$ 
  - Mediana elimină complet un salt izolat, chiar în eșantioane finite, și este mai puțin sensibilă decât BV la randamente nule izolate; două salturi alăturate trec totuși (mediana este atunci saltul mai mic)
- Ponderea salturilor în RV SPY: BV 6,3%, MedRV 7,2%, TRV 12,5% ( $c = 3$ ,  $\varpi = 0,49$ ; trunchierea acționează în 44% din zile:  $c$  este o alegere de reglaj)
- Aït-Sahalia & Jacod (2009): comparăm variațiile de putere  $\sum |r|^p$ ,  $p > 2$ , la  $\Delta$  și  $k\Delta$ ; raportul tinde la 1 cu salturi și la  $k^{p/2-1}$  fără: limite cunoscute sub ambele ipoteze

## Recapitulare: salturi

- ▣ RV măsoară variația pătratică totală: difuzia plus salturile la pătrat
- ▣ Variația bipower este robustă la salturi;  $RV - BV$  estimează partea de salt
- ▣ Testul raportului semnalează aproximativ 2,4% din zilele SPY la nivelul de 0,1%; salturile sunt o parte mică din varianța totală
- ▣ Testând multe zile, controlăm FDR: 235 zile SPY la 5% scad la 42 cu Benjamini–Hochberg; Lee–Mykland localizează salturile în timp (comunicatele FOMC)
  - ▶ Salturile sunt separate de variația continuă în modelul HAR-CJ (Secțiunea 5, Seminarul 9)

## Distribuții: log RV și randamente standardizate




- Stânga: log RV zilnică pentru SPY și densitatea Normală; dreapta: randamentele deschidere-închidere scalate cu abaterea lor standard (plin) și cu  $\sqrt{RV_t}$  (contur)

## Interpretarea distribuțiilor

- RV pentru SPY: asimetrie 20,0, aplatizare 550; log RV: asimetrie 0,29, aplatizare 3,20 (distribuția Normală: 0 și 3)
  - ▶ Log RV pentru Bitcoin: asimetrie  $-0,27$ , aplatizare 3,33: modelăm volatilitatea pe scară logaritmică
- Randamentele deschidere-închidere: aplatizare 15,73; împărțite la  $\sqrt{RV_t}$ : 2,65, abatere standard 1,05
  - ▶ Bitcoin: de la 7,57 la 2,77
- Cozile grele ale randamentelor zilnice (Capitolul 1) provin, ex post, în mare parte din volatilitatea variabilă: randamentele sunt un **amestec** de distribuții Normale cu varianțele  $IV_t$

## Memoria lungă a volatilității realizate




- Autocorelații până la 100 de zile: log RV pentru SPY (varianța totală) și Bitcoin, randamentele zilnice SPY la pătrat

## Interpretarea autocorelațiilor

- Log RV pentru SPY: 0,64 la întârzierea 1, 0,24 la o lună, încă 0,10 la 100 de zile: **memorie lungă**
  - ▶ Un AR(1) ar scădea geometric:  $0,64^{22} \approx 0,00005$
- Randamentele zilnice la pătrat arată aceeași persistență, ascunsă de zgomot: 0,20 la întârzierea 1
- Bitcoin: vârfuri la 7, 14, 21, ... zile: un **ciclu săptămânal**
  - ▶ RV de weekend este doar 0,41 din RV din zilele lucrătoare (sâmbătă 27% vs miercuri 48% pe an): fără știri bursiere sau macro, mai puțini investitori instituționali

## Volatilitate implicită vs realizată



- Stânga: VIX și volatilitatea realizată SPY în următoarele 21 de zile de tranzacționare (inclusiv randamentele peste noapte); dreapta: diferența dintre ele

## Interpretarea primei de risc a varianței

- VIX: volatilitatea pe 30 de zile implicită din opțiunile pe S&P 500 (Capitolul 12); medie 19,5% vs 15,2% realizată ulterior
  - ▶ VIX a depășit volatilitatea realizată ulterior în 88% din 1 468 zile; diferența medie 4,4 puncte procentuale
- **Prima de risc a varianței (VRP)** Carr & Wu (2009), Bollerslev, Tauchen & Zhou (2009):  
$$\text{VRP}_t = \mathbb{E}_t^Q[\text{RV}_{t,t+21}] - \mathbb{E}_t^P[\text{RV}_{t,t+21}]$$
, speranța neutră la risc minus speranța fizică a aceleiași varianțe viitoare;  $\text{VIX}^2$  aproximează primul termen
  - ▶ Investitorii plătesc pentru a se asigura împotriva salturilor de volatilitate; graficul arată o diferență **ex post** (VIX minus volatilitatea care a urmat), un indicator zgomotos al acestei prime ex ante
- Ca prognoză: regresia varianței viitoare pe  $\text{VIX}^2$  dă panta 0,56 (SE 0,05),  $R^2 = 0,23$ : VIX este informativ, dar deplasat în sus
- Diferența ex post devine negativă când volatilitatea realizată depășește volatilitatea implicită anterioară (martie–aprilie 2025): o eroare de prognoză, nu o dovadă a unei prime ex ante negative

## Recapitulare: fapte stilizate

- Distribuția log RV este apropiată de distribuția Normală Andersen, Bollerslev, Diebold & Labys (2001), Andersen, Bollerslev, Diebold & Ebens (2001): modelăm și prognozăm volatilitatea pe scară logaritmică
- Randamentele împărțite la  $\sqrt{RV}$  au, ex post, o distribuție apropiată de  $N(0, 1)$ : cozile grele provin mai ales din volatilitatea variabilă
- Memorie lungă: modelul trebuie să cântărească ultima lună, nu doar ziua de ieri
- Volatilitatea implicită conține o primă de risc: este o prognoză deplasată în sus

## Modelul HAR-RV

- Corsi (2009):  $RV_{t+1} = \beta_0 + \beta_d RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+1}$ 
  - ▶  $RV_t^{(w)} = \frac{1}{5} \sum_{j=0}^4 RV_{t-j}$  (săptămâna),  $RV_t^{(m)} = \frac{1}{22} \sum_{j=0}^{21} RV_{t-j}$  (luna)
  - ▶ Bitcoin se tranzacționează zilnic: săptămâna = 7 zile, luna = 30 de zile
- Ipoteza pieței eterogene Müller et al. (1997): investitori cu orizonturi zilnice, săptămânale și lunare; câteva componente cu persistență diferită imită memoria lungă
- Un AR(22) cu doar 3 pante libere: ponderea  $\beta_d + \beta_w/5 + \beta_m/22$  la întârzierea 1,  $\beta_w/5 + \beta_m/22$  la 2–5,  $\beta_m/22$  la 6–22
- Estimare prin OLS; erorile sunt heteroscedastice și autocorelate: folosim erori standard Newey–West (HAC)
  - ▶ log-HAR: aceeași regresie pentru  $\ln RV$ ; prognoza  $\exp(\hat{y} + \hat{s}^2/2)$ , cu  $\hat{s}^2$  varianța reziduurilor: media condiționată dacă erorile sunt  $N(0, s^2)$  (aproximare lognormală)
  - ▶ Pentru erori care nu sunt Normale folosim factorul de smearing  $\frac{1}{T} \sum_t e^{\hat{\varepsilon}_t}$  Duan (1983); cu erori heteroscedastice ambele sunt aproximări

## Extensii ale HAR

- **HAR-CJ Andersen, Bollerslev & Diebold (2007):** părțile continuă și de salt ca regresori separați
  - ▶  $\ln RV_{t+1} = \beta_0 + \beta_{Cd} \ln C_t + \beta_{Cw} \ln C_t^{(w)} + \beta_{Cm} \ln C_t^{(m)}$
  - ▶  $+ \beta_{Jd} \ln(1 + J_t) + \beta_{Jw} \ln(1 + J_t^{(w)}) + \beta_{Jm} \ln(1 + J_t^{(m)}) + \varepsilon_{t+1}$
  - ▶  $C_t^{(w)}, J_t^{(w)}$  ( $C_t^{(m)}, J_t^{(m)}$ ): medii aritmetice pe ultimele 5 (22) zile, ca  $RV_t^{(w)}$ ; logaritmul se aplică după mediere
- **HARQ Bollerslev, Patton & Quaedvlieg (2016):** pondere mai mică pentru RV de ieri când este imprecisă (cvarticitate realizată mare)
  - ▶  $\beta_d$  devine  $\beta_d + \beta_Q \sqrt{RQ}_t$  cu  $\beta_Q < 0$
- Variabile indicator pentru weekend sau sărbători, efectul de pârghie (randamentele negative cresc RV viitoare), volatilitatea implicită ca regresor suplimentar
- Pe mai mulți pași: regresăm direct  $\sum_{j=1}^h RV_{t+j}$  pe aceiași regresori

## Estimări HAR: SPY și Bitcoin


|                         | $\beta_0$         | $\beta_d$        | $\beta_w$        | $\beta_m$         | $R^2$ |
|-------------------------|-------------------|------------------|------------------|-------------------|-------|
| SPY, HAR (niveluri)     | 0,273<br>(0,064)  | 0,399<br>(0,089) | 0,222<br>(0,096) | 0,114<br>(0,053)  | 0,31  |
| SPY, log-HAR            | -0,079<br>(0,027) | 0,362<br>(0,037) | 0,337<br>(0,048) | 0,167<br>(0,044)  | 0,47  |
| Bitcoin, HAR (niveluri) | 1,496<br>(0,412)  | 0,412<br>(0,089) | 0,409<br>(0,122) | -0,065<br>(0,097) | 0,34  |
| Bitcoin, log-HAR        | 0,223<br>(0,094)  | 0,380<br>(0,041) | 0,465<br>(0,080) | -0,022<br>(0,098) | 0,36  |

- Eșantioanele complete; SPY: varianța zilnică totală (RV intraday plus randamentul peste noapte la pătrat), 1 467 zile; Bitcoin: RV pe 24 de ore, 547 zile
- Erorile standard Newey–West în paranteze

## Interpretarea estimărilor HAR

- SPY: toate cele trei componente sunt semnificative; pe log  $\hat{\beta}_d = 0,362$ ,  $\hat{\beta}_w = 0,337$ ,  $\hat{\beta}_m = 0,167$ 
  - ▶ Persistența  $\hat{\beta}_d + \hat{\beta}_w + \hat{\beta}_m = 0,87$ : șocurile se sting lent, ca la GARCH (Capitolul 5)
- $R^2 = 0,47$  pentru log-varianță vs 0,31 pentru varianța pe niveluri: nu sunt comparabile, variabilele dependente diferă; decid pierderile în afara eșantionului pe o țintă comună (Secțiunea 7)
- Bitcoin: componentele zilnică și săptămânală contează; coeficientul lunar este aproape de 0 ( $-0,022$ , SE 0,098)
  - ▶ Eșantion scurt (doi ani) și un ciclu săptămânal puternic: săptămâna preia cea mai mare parte a memoriei

## Ponderile implicite pe întârzieri și potrivirea în eșantion



- Stânga: ponderile log-HAR pe fiecare zi trecută (Bitcoin: ferestre complete de 7 și 30 de zile); dreapta: SPY, ultimele 250 de zile, volatilitatea realizată și valorile ajustate log-HAR

## Interpretarea ponderilor pe întârzieri

- SPY: ziua de ieri primește 0,437, fiecare dintre zilele 2–5 primește 0,075, fiecare dintre zilele 6–22 primește 0,008
- Scara scade lent: luna are încă ponderea  $22 \times 0,008 \approx 0,167$ 
  - ▶ Trei coeficienți reproduc memoria lungă a funcției de autocorelație
- Bitcoin: ziua de ieri 0,446, zilele 2–7 aproximativ 0,066 fiecare, aproape nimic după o săptămână
- Valorile ajustate în eșantion urmăresc nivelul volatilității, nu zgomotul de la o zi la alta

## HAR ca AR(22) restricționat: testarea restricțiilor

- Nerestricționat:  $\ln RV_{t+1} = \phi_0 + \sum_{k=1}^{22} \phi_k \ln RV_{t+1-k} + \varepsilon_{t+1}$ 
  - ▶ HAR impune  $\phi_2 = \dots = \phi_5$  (3 restricții) și  $\phi_6 = \dots = \phi_{22}$  (16):  $R\phi = 0$  cu 19 rânduri
- Wald:  $W = (R\hat{\phi})^\top (R\hat{V}_{NW}R^\top)^{-1} R\hat{\phi} \rightarrow \chi_{19}^2$  sub restricțiile HAR
- SPY, log varianța totală:  $W = 18,1$ ,  $p = 0,51$ ;  $R^2$  0,477 (AR(22)) vs 0,470 (HAR)
  - ▶ Scara nu este respinsă: HAR economisește 19 parametri aproape fără cost în eșantion, iar zgomotul de estimare mai mic ajută în afara eșantionului

## Eroarea de măsurare din regresori: de ce HARQ

- $RV_t = IV_t + u_t$  cu  $\mathbb{E}[u_t | \sigma] = 0$  și  $\text{Var}(u_t | \sigma) = 2 IQ_t/M$  (CLT din Secțiunea 2)
  - ▶ Dacă  $IV_{t+1} = \beta_0 + \beta IV_t + \eta_{t+1}$ , OLS pentru  $RV_{t+1}$  pe  $RV_t$  dă plim  $\hat{\beta} = \beta \frac{\text{Var}(IV)}{\text{Var}(IV) + \mathbb{E}[2 IQ/M]} < \beta$  pentru  $\beta > 0$ :  
atenuare
- Dacă varianța semnalului nu crește cu  $IQ_t$  (o aproximare de lucru), raportul semnal/zgomot al lui  $RV_t$  scade când  $IQ_t$  este mare; HARQ aproximează ponderea descrescătoare prin  $\beta_d + \beta_Q \sqrt{RQ_t}$ ,  $\beta_Q < 0$  [Bollerslev, Patton & Quaedvlieg \(2016\)](#)
- SPY, niveluri, SE Newey–West: RV intraday  $\hat{\beta}_Q = -0,0088$  (0,0042); varianța totală  $-0,0022$  (0,0024)
  - ▶ Panta zilnică (RV intraday) 1,13 la mediana lui  $\sqrt{RQ}$ , 1,09 la percentila 99: semnul prezis de teorie, un efect mic

## Recapitulare: HAR-RV

- HAR regresează RV de mâine pe mediile zilnică, săptămânală și lunară: OLS, trei pante
- Aproximează memoria lungă cu o scară de ponderi pe întârzieri
- Estimăm pe log; raportăm erori standard Newey–West
- HAR este un AR(22) cu 19 restricții pe care datele SPY nu le resping; eroarea de măsurare din  $RV_t$  atenuează panta zilnică, iar HARQ o corectează aproximativ
- Extensii: salturi (HAR-CJ), eroare de măsurare (HARQ), efecte de calendar, volatilitate implicită

## Designul prognozelor

- Ținta: varianța zilnică de mâine; SPY: varianța totală, 2022-01-03 – 18 septembrie 2026 (1 180 zile); Bitcoin: de la 2025-03-01 (422 zile)
  - ▶ Fiecare prognoză folosește doar datele disponibile în seara precedentă
- Cinci modele
  - ▶ log-HAR și HAR pe varianța realizată, reestimate zilnic pe o fereastră de estimare care se extinde în timp
  - ▶ GARCH(1,1) cu erori Student- $t$  pe randamente zilnice din 2000 (SPY) sau 2014 (Bitcoin), reestimat la fiecare 21 de zile [Bollerslev \(1986\)](#)
  - ▶ EWMA cu  $\lambda = 0,94$  (Capitolul 5) și „RV de ieri” (mers aleator)
- HAR vede datele intraday; GARCH și EWMA văd doar randamentele zilnice

## Evaluarea față de o țintă zgomotoasă

- Variația adevărată nu este observată; comparăm prognozele  $F_t$  cu proxy-ul  $RV_t$ 
  - ▶ O funcție de pierdere este **robustă** dacă ordinea obținută cu un proxy zgomotos nedeplasat coincide cu ordinea obținută cu variația adevărată [Patton \(2011\)](#)
- Două funcții de pierdere robuste
  - ▶  $MSE = (RV_t - F_t)^2$ : dominată de zilele cele mai volatile
  - ▶  $QLIKE = \frac{RV_t}{F_t} - \ln \frac{RV_t}{F_t} - 1 \geq 0$ : depinde doar de raport; penalizează mai mult subestimarea
- Greșeală frecventă: MAE sau MSE pe volatilitate în loc de varianță **nu** sunt robuste
  - ▶ [Andersen & Bollerslev \(1998\)](#): față de  $r_t^2$ , prognozele GARCH explicau câteva procente din variație; față de RV aceleași prognoze explică mult mai mult: proxy-ul era zgomotos, nu modelul

## Teste: Diebold–Mariano și Mincer–Zarnowitz

- Diebold & Mariano (1995): diferența de pierdere  $d_t = L(RV_t, F_t^A) - L(RV_t, F_t^B)$ ;  
 $t = \bar{d} / \text{se}_{\text{NW}}(\bar{d}) \rightarrow N(0, 1)$ 
  - $t < 0$ : modelul A are pierderea mai mică; eroare standard HAC deoarece  $d_t$  este autocorelat (Capitolul 8)
- Mincer & Zarnowitz (1969):  $RV_t = a + b F_t + u_t$ ; o prognoză nedeplasată are  $a = 0$ ,  $b = 1$ 
  - Test Wald comun cu covarianță Newey–West;  $R^2$  măsoară cât din variație explică prognoza
  - $R^2$  este limitat de zgomotul din RV: nici varianța adevărată nu ar ajunge la 1 Andersen & Bollerslev (1998)

## Rezultate: SPY, 2022–2026

| Model           | QLIKE | DM vs log-HAR ( $p$ ) | MSE  | MZ $b$ | MZ $R^2$ |
|-----------------|-------|-----------------------|------|--------|----------|
| log-HAR         | 0,310 | –                     | 4,15 | 1,16   | 0,30     |
| HAR             | 0,326 | –1,95 (0,052)         | 4,48 | 0,75   | 0,26     |
| GARCH(1,1)- $t$ | 0,343 | –2,30 (0,021)         | 4,87 | 0,70   | 0,20     |
| EWMA            | 0,393 | –4,02 ( $< 0,001$ )   | 5,14 | 0,74   | 0,14     |
| RV de ieri      | 0,502 | –5,95 ( $< 0,001$ )   | 5,41 | 0,54   | 0,29     |

- 1 180 prognoze pentru ziua următoare ale varianței zilnice totale; DM: diferențe QLIKE, Newey–West;  $t < 0$  favorizează log-HAR

## Interpretarea rezultatelor pentru SPY

- log-HAR are cele mai mici QLIKE și MSE: QLIKE cu 10% sub GARCH(1,1)- $t$  (DM  $t = -2,30$ ,  $p = 0,021$ )
  - ▶ Față de EWMA și RV de ieri câștigul este foarte semnificativ; față de HAR pe niveluri doar marginal ( $p = 0,052$ )
- Diferențele MSE nu sunt semnificative: câteva zile de criză (aprilie 2025) domină erorile la pătrat
- Mincer-Zarnowitz: log-HAR  $b = 1,16$  ( $p = 0,554$  pentru  $a = 0$ ,  $b = 1$ ), GARCH  $b = 0,70$ : fără deplasare semnificativă, dar log-HAR explică mai mult ( $R^2$  0,30 vs 0,20)
- RV de ieri are un  $R^2$  ridicat, dar  $b = 0,54$ : direcția corectă, mult prea extremă

## Rezultate: Bitcoin, 2025–2026


| Model           | QLIKE | DM vs log-HAR ( $p$ ) | MSE  | MZ $b$ | MZ $R^2$ |
|-----------------|-------|-----------------------|------|--------|----------|
| log-HAR         | 0,282 | –                     | 26,6 | 0,82   | 0,38     |
| HAR             | 0,409 | –1,22 (0,223)         | 27,6 | 0,89   | 0,34     |
| GARCH(1,1)- $t$ | 0,360 | –4,32 ( $< 0,001$ )   | 42,2 | 0,55   | 0,23     |
| EWMA            | 0,346 | –2,96 (0,003)         | 36,3 | 0,64   | 0,18     |
| RV de ieri      | 0,466 | –5,38 ( $< 0,001$ )   | 35,0 | 0,58   | 0,33     |

- 422 prognoze pentru ziua următoare ale varianței realizate pe 24 de ore; aceleași modele și teste ca pentru SPY

## Interpretarea rezultatelor pentru Bitcoin

- log-HAR câștigă din nou: QLIKE cu 22% sub GARCH(1,1)- $t$  (DM  $t = -4,32$ ,  $p < 0,001$ )
  - ▶ GARCH pe date zilnice este deplasat: MZ  $b = 0,55$  ( $p < 0,001$ ): reacționează excesiv la mișcările zilnice mari
- HAR pe niveluri este mai slab decât GARCH după QLIKE (0,409 vs 0,360): după weekenduri calme prezice o varianță prea mică, iar QLIKE penalizează subestimarea
- Informația intraday poate intra în prognozele de risc pentru Bitcoin; entropia randamentelor de înaltă frecvență a fost propusă ca un astfel de semnal ([Pele & Mazurencu-Marinescu-Pele \(2019\)](#))
- Cripto-actele se comportă ca o clasă de active distinctă, cu propria dinamică a volatilității [Pele et al. \(2023\)](#)

## Proгноzele în timp




- Sus: volatilitatea realizată SPY (inclusiv componenta de peste noapte) și cele două prognoze, anualizate; jos: pierderea QLIKE cumulată a fiecărui model minus log-HAR (linie crescătoare = log-HAR mai bun)

## Interpretarea traiectoriilor prognozelor

- După un șoc ambele prognoze cresc; GARCH rămâne ridicat mai mult (persistența lui este aproape de 1), log-HAR revine mai repede
  - ▶ Aprilie 2025: prognoza GARCH a rămas peste 40% pe an până la sfârșitul lui aprilie, în timp ce volatilitatea realizată era sub 20% de la jumătatea lunii
- Diferența cumulată de pierdere crește constant, cu salturi în episoadele agitate: câștigul nu provine dintr-o singură zi
- Dintre cele trei modele comparate în grafic cu log-HAR, EWMA pierde cel mai mult: un  $\lambda = 0,94$  fix reacționează prea mult la zile izolate

## Regresii Mincer–Zarnowitz



- ☐ SPY, 2022–2026: varianța realizată față de prognoză (scări log); linie întreruptă: dreapta de 45 de grade; negru: regresia estimată pe niveluri

## Interpretarea graficelor Mincer–Zarnowitz

- Prognozele log-HAR acoperă un interval mai larg: separă mai bine zilele calme de cele agitate
- Doar 1% dintre prognozele GARCH sunt sub  $0,26\%^2$  pe zi (log-HAR: minimum  $0,14\%^2$ ): în zilele calme varianța realizată scade mult sub GARCH
- Norul este larg pentru ambele: varianța unei zile este greu de prognozat, iar RV însăși este măsurată cu eroare
- Orizontul săptămânal și extensiile modelului: Seminarul 9 (B6, B7)

## Dincolo de HAR: semivarianțe și modele comune randament–RV

- Semivarianțele realizate  $RS_t^\pm = \sum_i r_{t,i}^2 \mathbf{1}\{r_{t,i} \gtrless 0\}$ ,  $RS^+ + RS^- = RV$ ; SHAR [Patton & Sheppard \(2015\)](#):  $\beta_d RV_t$  devine  $\beta^+ RS_t^+ + \beta^- RS_t^-$ 
  - SPY, niveluri (randamentul peste noapte socotit ca încă un randament al zilei):  $\hat{\beta}^- = 0,56$  (0,23),  $\hat{\beta}^+ = 0,21$  (0,18); Wald  $\beta^+ = \beta^-$ :  $p = 0,35$
  - Volatilitatea „rea” este mai persistentă, ca în [Patton & Sheppard \(2015\)](#), dar șase ani de date nu separă cele două pante
- Realized GARCH [Hansen, Huang & Shek \(2012\)](#): o ecuație GARCH condusă de măsura realizată  $x_t$ , plus o **ecuație de măsurare**
  - $\ln h_t = \omega + \beta \ln h_{t-1} + \gamma \ln x_{t-1}$ ,  $\ln x_t = \xi + \varphi \ln h_t + \tau(z_t) + u_t$ ,  $r_t = \sqrt{h_t} z_t$ : estimare comună prin cvasi-maximă verosimilitate
- Modelele HEAVY [Shephard & Sheppard \(2010\)](#): o ecuație de tip GARCH pentru varianța zilnică, condusă de RV întârziată, și una pentru RV însăși: prognoze coerente pe mai mulți pași

## Ce modele supraviețuiesc? Mulțimea de încredere a modelelor

| Model           | QLIKE | Valoarea $p$ MCS | În MCS (90%) |
|-----------------|-------|------------------|--------------|
| log-HAR         | 0,310 | 1,000            | ✓            |
| SHAR            | 0,320 | 0,224            | ✓            |
| HAR             | 0,326 | 0,014            |              |
| HARQ            | 0,344 | 0,095            |              |
| GARCH(1,1)- $t$ | 0,343 | 0,095            |              |
| EWMA            | 0,393 | 0,012            |              |
| RV de ieri      | 0,502 | 0,000            |              |

- Hansen, Lunde & Nason (2011): testăm egalitatea capacității predictive a tuturor modelelor (statistica amplitudinii, bootstrap pe blocuri), eliminăm cel mai slab model, repetăm; mulțimea rămasă conține cel mai bun model cu probabilitate  $\geq 90\%$
- SPY, 1 180 zile din 2022: mulțimea este {log-HAR, SHAR}; HARQ și SHAR sunt estimate pe niveluri cu filtrul din Bollerslev, Patton & Quaadvlieg (2016) (prognozele din afara intervalului din eșantion sunt înlocuite cu media)
- O procedură de comparații multiple: multe teste DM pe perechi, fără controlul probabilității erorilor de tip I, ar supraestima forța dovezilor (Capitolul 8)



## Recapitulare: prognoze

- ▣ Evaluăm prognozele de varianță cu funcții de pierdere robuste (QLIKE, MSE pe varianță) și testăm diferențele cu Diebold–Mariano
- ▣ Datele intraday ajută: log-HAR întrece GARCH(1,1)- $t$  cu 10% (SPY) și 22% (Bitcoin) după QLIKE
- ▣ Lucrăm pe log: HAR pe niveluri pierde după QLIKE când subestimează
- ▣ Clasamentele după MSE depind de câteva zile de criză și sunt rareori semnificative; MCS păstrează pentru SPY doar log-HAR și SHAR

## Este volatilitatea aspră?

- Gatheral, Jaisson & Rosenbaum (2018): log-volatilitatea se comportă ca o **mișcare browniană fracționară** cu exponentul Hurst  $H \approx 0,1$ 
  - ▶  $H = 0,5$ : mișcarea browniană obișnuită;  $H < 0,5$ : incrementele sunt corelate negativ, traiectoriile sunt mai aspre;  $H > 0,5$ : mai netede, cu tendință
- Legea de scalare:  $m(q, \Delta) = \frac{1}{T} \sum_t |\ln \sigma_{t+\Delta} - \ln \sigma_t|^q \propto \Delta^{qH}$ 
  - ▶ Regresăm  $\ln m(q, \Delta)$  pe  $\ln \Delta$ : panta  $\zeta_q = qH$ ; apoi  $H$  din pantele pentru diferite  $q$
- Modelele aspre reproduc forma zâmbetului volatilității implicite pentru scadențe scurte (Capitolul 12)

## Scalarea incrementelor log-volatilității



□ Stânga:  $\ln m(q, \Delta)$  față de  $\ln \Delta$  pentru SPY,  $\Delta = 1, \dots, 30$  de zile; dreapta: pantele  $\zeta_q$  față de  $q$

## Interpretarea estimărilor de asprime

- Linii drepte pe scara log-log: legea de scalare este respectată; pantele sunt liniare în  $q$ 
  - ▶  $\hat{H} = 0,11$  pentru SPY (CI bootstrap pe blocuri de 95% [0,09, 0,15]), 0,08 pentru Bitcoin: mult sub 0,5
- Atenție: RV măsoară volatilitatea cu eroare, iar eroarea de măsurare coboară  $\hat{H}$ 
  - ▶ O mișcare browniană simulată dă  $\hat{H} = 0,46$ ; cu zgomot de mărime relativă similară,  $\hat{H} = 0,18$  (Seminarul 9, B8)
- Estimatorul de scalare aplicat indicatorilor RV zgomotoși este **inconsistent** pentru exponentul Hurst; consistența cere asimptotica de înaltă frecvență [Fukasawa, Takabatake & Westphal \(2022\)](#)
  - ▶ Estimări aparent aspre pot proveni din eroarea de estimare într-un model neaspru [Cont & Das \(2024\)](#); asprimea pe termen scurt poate coexista cu memoria lungă [Bennedsen, Lunde & Pakkanen \(2022\)](#)

## Recapitulare: volatilitatea aspră

- Momentele incrementelor log-volatilității scalează ca  $\Delta^{qH}$  cu  $H \approx 0,1$
- Datele noastre:  $\hat{H} = 0,11$  (SPY) și  $0,08$  (Bitcoin)
- O parte din asprime poate fi eroare de măsurare în RV: eroarea i.i.d. deplasează  $\hat{H}$  în jos, alte structuri de eroare îl pot deplasa în ambele sensuri, deci  $\hat{H}$  nu este o limită pentru  $H$  latent
- Modelele de volatilitate aspră sunt un domeniu activ de cercetare în evaluarea opțiunilor

## Studiu de caz: întrebarea de cercetare

- Christensen, Siggaard & Veliyev (2023): prognozează învățarea automată (ML), folosită fără reglaje elaborate, varianța realizată zilnică mai bine decât familia HAR și, dacă da, de ce?
  - ▶ HAR Corsi (2009) este liniar în trei întârzieri ale RV, iar RV este asimetrică la dreapta și are memorie lungă (faptele stilizate de mai sus): o funcție neliniară se poate potrivi mai bine
  - ▶ Extensiile lui (log-HAR, SHAR Patton & Sheppard (2015), HARQ Bollerslev, Patton & Quaedvlieg (2016)) folosesc tot doar randamentele trecute
- De ce alți predictorii intră rar: OLS supra-ajustează când regresorii sunt mulți, corelați și zgomotoși
  - ▶ Candidați: volatilitatea implicită, VIX, volumul tranzacțiilor, indici macro și de incertitudine (Tabelul 1 al lucrării)
- De ce contează: prognozele de varianță intră în VaR (Capitolul 7) și în evaluarea opțiunilor (Capitolul 12); ML trebuie să întreacă un reper puternic, cu trei parametri
  - ▶ Alegerea de design: reglaj minim al hiperparametrilor, deci se testează metodele „ca atare”, nu efortul de reglaj

## Studiu de caz: date și metodă

- Date (Secțiunea 3): 29 dintre cele 30 de acțiuni DJIA (fără Visa), 29 ianuarie 2001 – 31 decembrie 2017,  $T = 4\,257$  zile; RV la 5 minute din prețurile curățate ale tranzacțiilor NYSE,  $n = 78$  de randamente pe zi
  - ▶ Împărțire: antrenare 70% (2 964 zile), validare 10% (424), test 20% (847); robustețe: antrenare 1 000 sau 2 000 de zile, validare 200 (Anexa A.1)
  - ▶  $\mathcal{M}_{\text{HAR}}$ : RV zilnică, săptămânală, lunară;  $\mathcal{M}_{\text{ALL}}$  adaugă 9 predictor (Tabelul 1): volatilitatea implicită, indicator de zi cu rezultate financiare, momentum pe o săptămână, variația log a volumului în dolari; VIX, randamentul Hang Seng la pătrat, indicele condițiilor de afaceri, variația ratei la 3 luni a titlurilor de stat, indicele incertitudinii politicii economice
- Modele (Secțiunea 2): HAR, log-HAR, HAR cu efect de pârgă, SHAR, HARQ prin OLS pe o fereastră mobilă; ridge (penalizare  $L_2$ ), lasso ( $L_1$ ), elastic net (o combinație), lasso adaptiv și post-lasso, cu penalizarea aleasă pe setul de validare
  - ▶ Arbori: bagging, pădure aleatoare (RF) cu valorile implicite ale lui Breiman, 500 de arbori,  $J/3$  predictor candidați la fiecare ramificare, cel puțin 5 observații într-un nod (Tabelul 15), gradient boosting
  - ▶ Rețele neuronale  $\text{NN}_k^e$ :  $k = 1, \dots, 4$  straturi ascunse (2; 4-2; 8-4-2; 16-8-4-2 neuroni), leaky ReLU, Adam, dropout, oprire timpurie;  $e = 1$ : cea mai bună din 100 de inițializări pe validare,  $e = 10$ : media celor mai bune 10
- Evaluare (Secțiunea 2.6): MSE în afara eșantionului relativ la HAR, mediat pe acțiuni; test DM unilateral pentru fiecare acțiune Diebold & Mariano (1995); MCS la 90% Hansen, Lunde & Nason (2011)

## Studiu de caz: rezultatele principale

- O zi înainte, doar întârzierile RV (Tabelul 2): MSE relativ la HAR: log-HAR 0,995, HARQ 1,059, RF 1,020, rețele neuronale 0,954–0,990
  - ▶ RV trecută lasă puțin de învățat: câștigă doar rețelele, cu aproximativ 5%
- O zi înainte, toți cei 12 predictorii (Tabelul 3): OLS cu toți predictorii 0,966, HARQ 1,289; elastic net 0,916, RF 0,901, log-HAR 0,901,  $NN_2^{10}$  0,885
  - ▶ Predictorii suplimentari aduc câștig doar cu penalizare sau neliniaritate; extensiile HAR nepenalizate supra-ajustează
- O lună înainte, toți predictorii (Tabelul 7): RF 0,604, bagging 0,621, rețele 0,786–0,964, log-HAR 0,919, OLS cu toți predictorii 1,290
  - ▶ Câștigul crește cu orizontul: ajustările ML sunt mai persistente (Figura 8) și aproximează mai bine memoria lungă a RV
- MCS la 90% (Figura 4): cu toți predictorii, rețelele rămân în mulțime pentru aproximativ 80% din acțiuni, HAR pentru aproximativ 20–40%
  - ▶ Efectele locale acumulate (Figura 7): RV zilnică, RV săptămânală și volatilitatea implicită domină în toate modelele; RF și rețelele pun volatilitatea implicită mai sus decât modelele liniare

## Studiu de caz: replicare, limite, extindere

- Replicare pe datele cursului: bare SPY de 5 minute (data/market/intraday), RV de la deschidere la închidere cu 78 de randamente pe zi, ca în Secțiunea 3; autorii raportează că SPY confirmă rezultatele pe acțiuni (nota 12)
  - ▶ Împărțirea din Anexa A.1: 1000 de zile de antrenare, 200 de zile de validare, restul până la 18 septembrie 2026 ca set de test
  - ▶ Predictorii: VIX (ține loc atât de volatilitate implicită, cât și de VIX pentru un fond indexat), randamentul Hang Seng la pătrat, momentum și volum în dolari pentru SPY, rata titlurilor de stat și incertitudinea politicii economice (FRED); fără indicator de rezultate financiare pentru un fond (Seminarul 9, C3)
- Limite precizate de autori
  - ▶ Reglaj minim: un reglaj mai amplu ar putea îmbunătăți ML (Secțiunea 7); rețelele sunt antrenate o singură dată și nu sunt reestimate în fereastra de test (Secțiunea 3)
  - ▶ Clasamentele depind de împărțire: cu 1000 de zile de antrenare criza financiară intră în setul de test, iar extensiile HAR întrec HAR (Secțiunea 4.1, Anexa A.1)
  - ▶ Modelele HAR cu o componentă de salt separată nu sunt incluse (Secțiunea 2.2); efectele locale acumulate descriu predicția medie și ratează evenimentele rare, cum sunt zilele cu rezultate financiare (Secțiunea 4.2)
- Extindere deschisă: lucrarea ordonează prognozele de varianță doar după MSE; se păstrează avantajul ML după QLIKE, robustă la indicatorul zgomotos RV [Patton \(2011\)](#), și este valabil și pentru RV Bitcoin pe 24 de ore?

## O întrebare deschisă: este volatilitatea cu adevărat aspră?

- Gatheral, Jaisson & Rosenbaum (2018) raportează  $H \approx 0,1$ , dar  $H$  este estimat din RV, un indicator zgomotos al volatilității latente  $\sigma_t$ 
  - ▶ Cont & Das (2024): estimatorul de scalare aplicat volatilității realizate găsește asprime chiar când volatilitatea instantanee este netedă: un artefact de estimare
  - ▶ Bolko, Christensen, Pakkanen & Veliyev (2023) (GMM care modelează eroarea din RV) și Fukasawa, Takabatake & Westphal (2022) (consistent sub asimptotica de înaltă frecvență) găsesc totuși  $H < 0,5$
- Întrebarea formală:  $\ln RV_t^{1/2} = \ln \sigma_t + e_t$ , cu  $\ln \sigma_t$  fracționar de indice  $H$ 
  - ▶  $H_0$ :  $H = 1/2$  (volatilitate difuzivă clasică) față de  $H_1$ :  $H < 1/2$
  - ▶ Problema de identificare: un  $H$  mic și un  $\text{Var}(e_t)$  mare aplatizează amândouă  $m(2, \Delta)$  la întârzieri mici
- Miza: panta zâmbetului la scadențe scurte și prognozele volatilității depind de  $H$  (Capitolul 12)

## Bucula descoperirii, pas cu pas (1/2)

- Instrumente: un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau GitHub Copilot); căutarea literaturii: [Semantic Scholar](#), [Elicit](#), [Google Scholar](#)
- 1. **Literatura:** tabelăm dovezile, apoi verificăm fiecare DOI pe [Crossref](#) (titlul trebuie să coincidă)
  - ▶ Tabelează estimările lui H publicate din 2018: estimatorul, frecvența de eșantionare, tratamentul erorii de măsurare din RV, estimarea punctuală și eroarea standard, DOI.
- 2. **Ipoteze concurente**, fiecare cu forma implicată a lui  $m(2, \Delta)$ 
  - ▶ Derivează  $m(2, \Delta)$  pentru trei procese care dau H în jur de 0,1 cu estimatorul de scalare: log-volatilitate fracționară cu  $H = 0,1$ ;  $H = 0,5$  plus eroare i.i.d.; un model cu doi factori, unul cu revenire rapidă la medie.
- 3. **Date și cod:** replicăm întâi cifra din capitol
  - ▶ Scrie cod Python care construiește RV la 5 minute din `data/market/intraday/SPY.US_5m.csv`, calculează  $m(q, \Delta)$  pentru  $q$  în  $\{0,5; 1; 1,5; 2; 3\}$ ,  $\Delta = 1..30$ , și panta H. Ținta:  $\hat{H} = 0,11$

## Bucula descoperirii, pas cu pas (2/2)

- 4. **Robustețe**, pre-înregistrată, cu o verificare a puterii
  - ▶ Scrie un plan pre-înregistrat: ferestre de întârzieri  $[1,30]$ ,  $[5,30]$ ,  $[10,50]$ ; RV, variația bipower și RV subeșantionată la 30 de minute; ajustajul  $m(2, \Delta) = c \Delta^{2H} + k$ ; intervale bootstrap pe blocuri; mărimea și puterea prin simulare la  $H = 0,1$  și  $0,5$ .
- 5. **Critica**: cerem cel mai puternic contraargument
  - ▶ Joacă rolul unui recenzent: ce structuri de eroare non-i.i.d. în log RV (autocorelate, dependente de nivel, provenite din randamentele peste noapte sau din salturi) ar supraviețui corecției cu  $k$  constant și cum ai detecta fiecare?
- 6. **Raportul**: toate ferestrele și măsurile, intervalele bootstrap, designul simulării, codul și jurnalul AI

## Ce verifică cercetătorul

- **Eroarea indicatorului:** RV este o estimare cu eroare standard cunoscută; test: simulăm  $H = 0,5$  plus eroare de aceeași mărime și verificăm că procedura nu întoarce  $H \approx 0,1$
- **Incrementale suprapuse:**  $m(q, \Delta)$  refolosește aceleași zile la fiecare  $\Delta$ , deci erorile standard OLS ale lui  $\zeta_q$  nu sunt valide; test: bootstrap pe blocuri
- **Zgomotul de microstructură și salturile:** verificăm graficul semnăturii, apoi repetăm cu BV și cu RV subeșantionată
- **Căutarea specificației:** ferestrele de întârzieri și grilele pentru  $q$  alese după ce vedem  $\hat{H}$  umflă semnificația; le fixăm dinainte și le raportăm pe toate
- **Estimări inventate:** asistenții citează „ $H \approx 0,1$  pentru toate activele”; verificăm fiecare cifră în tabelul lucrării citate

## Mini-caz: este $\hat{H}$ un artefact al erorii i.i.d.?

- O propunere tipică a asistentului:  $\hat{H} \approx 0,1$  provine din eroarea de măsurare i.i.d. din RV. Implicația:  $m(2, \Delta) = c \Delta^{2H} + k$  cu  $k = 2 \text{Var}(e_t) > 0$ , deci  $\hat{H}$  crește când renunțăm la întârzierile mici

|                               | $\Delta \in [1, 30]$ | $[5, 30]$ | $[10, 50]$ | Ajustaj cu $k$ , $[1, 50]$ |
|-------------------------------|----------------------|-----------|------------|----------------------------|
| $H = 0,5$ simulat plus eroare | 0,18                 | 0,24      | 0,26       | 0,39                       |
| SPY, RV totală                | 0,106                | 0,089     | 0,077      | 0,096                      |
| SPY, RV intraday              | 0,129                | 0,094     | 0,078      | 0,113                      |

- Prima coloană replică valoarea din capitol; rândul simulat (o singură traiectorie, nu un studiu de putere) arată mecanismul:  $\hat{H}$  crește, iar ajustajul recuperează mare parte din distanța până la 0,5
- SPY:  $\hat{H}$  scade cu fereastra, iar  $k$  estimat este 0;  $\hat{H} = 0,096$ , CI bootstrap pe blocuri de 95%  $[0,083, 0,203]$
- Interpretare: un diagnostic ilustrativ, incompatibil cu explicația prin eroare i.i.d.; o respingere formală cere un test calibrat prin simulare; mecanismul non-i.i.d. din [Cont & Das \(2024\)](#) nu este testat de acest design. Cod: `Quantlets/Ch_09/ai_discovery_case.py`

## Rândul vostru: un punct de plecare pentru proiect

- Întrebarea: supraviețuiește asprimea volatilității SPY și Bitcoin unui estimator care modelează eroarea de măsurare din RV?
- Replicați mai întâi:  $\hat{H} = 0,11$  (SPY) și  $0,08$  (Bitcoin) din legea de scalare și  $\hat{H} = 0,18$  pentru  $H = 0,5$  simulat plus eroare (Seminarul 9, B8)
- Livrabile
  - ▶ O pre-înregistrare (ipoteze, estimatori, ferestre de întârzieri, teste, designul simulării) datată înainte de prima rulare
  - ▶ Estimatorul GMM din [Bolko, Christensen, Pakkanen & Veliyev \(2023\)](#) pe seriile RV ale cursului, cu mărimea și puterea Monte Carlo la  $H \in \{0,1; 0,5\}$
  - ▶ Codul, un raport de două pagini cu toate specificațiile încercate și o critică, în stil de recenzent, a propriului rezultat
- Consemnați fiecare prompt care a influențat o decizie în `AI_USE.md` și fiecare eroare a asistentului în `AI_ERRORS.md`:  
[github.com/danpele/MFM/tree/main/project](https://github.com/danpele/MFM/tree/main/project)

## Sinteză

- ▣ Variația realizată transformă prețurile intraday într-o măsurare a varianței zilnice, cu o eroare standard cunoscută
- ▣ Eșantionăm la 5 minute pentru active lichide; folosim estimatori robuști la zgomot când zgomotul este important (date tick cu tick, active nelichide); adăugăm randamentul peste noapte pentru riscul zilnic
- ▣ Variația bipower, MedRV și trunchierea separă salturile de variația continuă; cu controlul FDR salturile sunt rare și o parte mică din variație
- ▣ Distribuția log RV este apropiată de distribuția Normală, iar seria are memorie lungă: modelul log-HAR surprinde această persistență cu trei coeficienți
- ▣ În afara eșantionului, log-HAR întrece GARCH pentru SPY și Bitcoin după QLIKE; comparațiile MSE nu sunt concludente

## Ce instrument și când?

| Situația                                           | Instrumentul sugerat                                                                           |
|----------------------------------------------------|------------------------------------------------------------------------------------------------|
| Activ lichid, bare de 1–5 minute                   | RV la 5 minute, subeșantionată                                                                 |
| Date tick cu tick sau o acțiune nelichidă (BVB)    | Pre-mediare sau nucleu realizat ( $n^{-1/4}$ ); verificați graficul semnăturii                 |
| Riscul zilnic al unui activ tranzacționat la bursă | Varianța totală: RV plus randamentul peste noapte la pătrat                                    |
| Separarea salturilor din știri de difuzie          | BV sau MedRV, testul raportului cu control FDR; Lee–Mykland pentru momentul saltului           |
| Proгноza varianței zilnice sau săptămânale         | log-HAR (plus salturi, weekenduri, RQ); reper GARCH                                            |
| Compararea prognozelor                             | QLIKE și MSE pe varianță, Diebold–Mariano, Mincer–Zarnowitz, mulțimea de încredere a modelelor |

## Urmează: microstructura pieței (Capitolul 10)

- ▣ De unde provine zgomotul din prețurile de înaltă frecvență? Registrul de ordine limită, spread-ul bid–ask, pasul de cotare
- ▣ Lichiditatea și impactul asupra pieței: cum reacționează prețurile la tranzacții
- ▣ Tranzacționarea de înaltă frecvență și registrele de ordine ale burselor crypto
- ▣ Lecturi suplimentare: Andersen, Bollerslev, Diebold & Labys (2003), Corsi (2009), Franke, Härdle & Hafner (2019)

## Studiu suplimentar pe Quantinar

### Cursuri avansate pe quantinar.com

- ▣  Nonparametric and Semiparametric Models
- ▣  Kalman Filter
- ▣  Applied Time Series Analysis with Python

### Cod și date

- ▣ Quantlets: [github.com/danpele/MFM/tree/main/Quantlets/Ch\\_09](https://github.com/danpele/MFM/tree/main/Quantlets/Ch_09)

## Bibliografie (1/5)

- ▣ Aït-Sahalia, Y., Jacod, J. (2009). Testing for jumps in a discretely observed process. *Annals of Statistics*, 37(1), 184–222.
- ▣ Andersen, T.G., Bollerslev, T. (1997). Intraday periodicity and volatility persistence in financial markets. *Journal of Empirical Finance*, 4(2–3), 115–158.
- ▣ Andersen, T.G., Bollerslev, T. (1998). Answering the skeptics: yes, standard volatility models do provide accurate forecasts. *International Economic Review*, 39(4), 885–905.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X. (2007). Roughing it up: including jump components in the measurement, modeling, and forecasting of return volatility. *Review of Economics and Statistics*, 89(4), 701–720.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Ebens, H. (2001). The distribution of realized stock return volatility. *Journal of Financial Economics*, 61(1), 43–76.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Labys, P. (2001). The distribution of realized exchange rate volatility. *Journal of the American Statistical Association*, 96(453), 42–55.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Labys, P. (2003). Modeling and forecasting realized volatility. *Econometrica*, 71(2), 579–625.
- ▣ Andersen, T.G., Dobrev, D., Schaumburg, E. (2012). Jump-robust volatility estimation using nearest neighbor truncation. *Journal of Econometrics*, 169(1), 75–93.
- ▣ Bajgrowicz, P., Scaillet, O., Treccani, A. (2016). Jumps in high-frequency data: spurious detections, dynamics, and news. *Management Science*, 62(8), 2198–2217.
- ▣ Bandi, F.M., Russell, J.R. (2008). Microstructure noise, realized variance, and optimal sampling. *Review of Economic Studies*, 75(2), 339–369.
- ▣ Barndorff-Nielsen, O.E., Hansen, P.R., Lunde, A., Shephard, N. (2008). Designing realized kernels to measure the ex post variation of equity prices in the presence of noise. *Econometrica*, 76(6), 1481–1536.

## Bibliografie (2/5)

- Barndorff-Nielsen, O.E., Shephard, N. (2002). [Econometric analysis of realized volatility and its use in estimating stochastic volatility models](#). *Journal of the Royal Statistical Society, Series B*, 64(2), 253–280.
- Barndorff-Nielsen, O.E., Shephard, N. (2004). [Power and bipower variation with stochastic volatility and jumps](#). *Journal of Financial Econometrics*, 2(1), 1–37.
- Barndorff-Nielsen, O.E., Shephard, N. (2005). [How accurate is the asymptotic approximation to the distribution of realised variance?](#). In D.W.K. Andrews, J.H. Stock (Eds.), *Identification and Inference for Econometric Models*, Cambridge University Press, 306–331.
- Barndorff-Nielsen, O.E., Shephard, N. (2006). [Econometrics of testing for jumps in financial economics using bipower variation](#). *Journal of Financial Econometrics*, 4(1), 1–30.
- Benjamini, Y., Hochberg, Y. (1995). [Controlling the false discovery rate: a practical and powerful approach to multiple testing](#). *Journal of the Royal Statistical Society, Series B*, 57(1), 289–300.
- Benjamini, Y., Yekutieli, D. (2001). [The control of the false discovery rate in multiple testing under dependency](#). *The Annals of Statistics*, 29(4), 1165–1188.
- Bennedsen, M., Lunde, A., Pakkanen, M.S. (2022). [Decoupling the short- and long-term behavior of stochastic volatility](#). *Journal of Financial Econometrics*, 20(5), 961–1006.
- Bolko, A.E., Christensen, K., Pakkanen, M.S., Veliyev, B. (2023). [A GMM approach to estimate the roughness of stochastic volatility](#). *Journal of Econometrics*, 235(2), 745–778.
- Bollerslev, T. (1986). [Generalized autoregressive conditional heteroskedasticity](#). *Journal of Econometrics*, 31(3), 307–327.
- Bollerslev, T., Patton, A.J., Quaedvlieg, R. (2016). [Exploiting the errors: a simple approach for improved volatility forecasting](#). *Journal of Econometrics*, 192(1), 1–18.
- Bollerslev, T., Tauchen, G., Zhou, H. (2009). [Expected stock returns and variance risk premia](#). *Review of Financial Studies*, 22(11), 4463–4492.

## Bibliografie (3/5)

- ▣ Boudt, K., Croux, C., Laurent, S. (2011). Robust estimation of intraweek periodicity in volatility and jump detection. *Journal of Empirical Finance*, 18(2), 353–367.
- ▣ Carr, P., Wu, L. (2009). Variance risk premiums. *Review of Financial Studies*, 22(3), 1311–1341.
- ▣ Christensen, K., Oomen, R.C.A., Podolskij, M. (2014). Fact or friction: jumps at ultra high frequency. *Journal of Financial Economics*, 114(3), 576–599.
- ▣ Christensen, K., Siggaard, M., Veliyev, B. (2023). A machine learning approach to volatility forecasting. *Journal of Financial Econometrics*, 21(5), 1680–1727.
- ▣ Cont, R., Das, P. (2024). Rough volatility: fact or artefact?. *Sankhya B*, 86(1), 191–223.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Duan, N. (1983). Smearing estimate: a nonparametric retransformation method. *Journal of the American Statistical Association*, 78(383), 605–610.
- ▣ Epps, T.W. (1979). Comovements in stock prices in the very short run. *Journal of the American Statistical Association*, 74(366), 291–298.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Fukasawa, M., Takabatake, T., Westphal, R. (2022). Consistent estimation for fractional stochastic volatility model under high-frequency asymptotics. *Mathematical Finance*, 32(4), 1086–1132.

## Bibliografie (4/5)

- ▣ Gatheral, J., Jaisson, T., Rosenbaum, M. (2018). *Volatility is rough*. *Quantitative Finance*, 18(6), 933–949.
- ▣ Hansen, P.R., Huang, Z., Shek, H.H. (2012). *Realized GARCH: a joint model for returns and realized measures of volatility*. *Journal of Applied Econometrics*, 27(6), 877–906.
- ▣ Hansen, P.R., Lunde, A. (2005). *A forecast comparison of volatility models: does anything beat a GARCH(1,1)?*. *Journal of Applied Econometrics*, 20(7), 873–889.
- ▣ Hansen, P.R., Lunde, A. (2006). *Realized variance and market microstructure noise*. *Journal of Business & Economic Statistics*, 24(2), 127–161.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). *The model confidence set*. *Econometrica*, 79(2), 453–497.
- ▣ Hayashi, T., Yoshida, N. (2005). *On covariance estimation of non-synchronously observed diffusion processes*. *Bernoulli*, 11(2), 359–379.
- ▣ Huang, X., Tauchen, G. (2005). *The relative contribution of jumps to total price variance*. *Journal of Financial Econometrics*, 3(4), 456–499.
- ▣ Jacod, J., Li, Y., Mykland, P.A., Podolskij, M., Vetter, M. (2009). *Microstructure noise in the continuous case: the pre-averaging approach*. *Stochastic Processes and their Applications*, 119(7), 2249–2276.
- ▣ Lee, S.S., Mykland, P.A. (2008). *Jumps in financial markets: a new nonparametric test and jump dynamics*. *Review of Financial Studies*, 21(6), 2535–2563.
- ▣ Liu, L.Y., Patton, A.J., Sheppard, K. (2015). *Does anything beat 5-minute RV? A comparison of realized measures across multiple asset classes*. *Journal of Econometrics*, 187(1), 293–311.
- ▣ Mancini, C. (2009). *Non-parametric threshold estimation for models with stochastic diffusion coefficient and jumps*. *Scandinavian Journal of Statistics*, 36(2), 270–296.

## Bibliografie (5/5)

- ▣ Merton, R.C. (1980). [On estimating the expected return on the market: an exploratory investigation](#). *Journal of Financial Economics*, 8(4), 323–361.
- ▣ Mincer, J., Zarnowitz, V. (1969). [The evaluation of economic forecasts](#). In J. Mincer (Ed.), *Economic Forecasts and Expectations*, NBER, 3–46.
- ▣ Müller, U.A., Dacorogna, M.M., Davé, R.D., Olsen, R.B., Pictet, O.V., von Weizsäcker, J.E. (1997). [Volatilities of different time resolutions: analyzing the dynamics of market components](#). *Journal of Empirical Finance*, 4(2–3), 213–239.
- ▣ Mykland, P.A., Zhang, L. (2009). [Inference for continuous semimartingales observed at high frequency](#). *Econometrica*, 77(5), 1403–1445.
- ▣ Patton, A.J. (2011). [Volatility forecast comparison using imperfect volatility proxies](#). *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Sheppard, K. (2015). [Good volatility, bad volatility: signed jumps and the persistence of volatility](#). *Review of Economics and Statistics*, 97(3), 683–697.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). [Using high-frequency entropy to forecast Bitcoin's daily value at risk](#). *Entropy*, 21(2), 102.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). [Are cryptos becoming alternative assets?](#). *European Journal of Finance*, 29(10), 1064–1105.
- ▣ Shephard, N., Sheppard, K. (2010). [Realising the future: forecasting with high-frequency-based volatility \(HEAVY\) models](#). *Journal of Applied Econometrics*, 25(2), 197–231.
- ▣ Zhang, L. (2006). [Efficient estimation of stochastic volatility using noisy observations: a multi-scale approach](#). *Bernoulli*, 12(6), 1019–1043.
- ▣ Zhang, L., Mykland, P.A., Ait-Sahalia, Y. (2005). [A tale of two time scales: determining integrated volatility with noisy high-frequency data](#). *Journal of the American Statistical Association*, 100(472), 1394–1411.