



Modelarea piețelor financiare

Capitolul 9: Volatilitate realizată



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- BV: Bipower Variation (variația bipower)
- BVB: Bursa de Valori București
- CI: Confidence Interval (interval de încredere)
- CLT: Central Limit Theorem (teorema limită centrală)
- DJIA: Dow Jones Industrial Average (indicele Dow Jones al marilor companii industriale americane)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- FDR: False Discovery Rate (rata descoperirilor false)
- FOMC: Federal Open Market Committee (Comitetul Federal pentru Piața Deschisă al Rezervei Federale)
- FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GMM: Generalized Method of Moments (metoda generalizată a momentelor)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- HAR-CJ: HAR model with Continuous and Jump components (model HAR cu componentă continuă și componentă de salt)
- HAR-RV: Heterogeneous AutoRegressive model of Realised Volatility (model autoregresiv heterogen al volatilității realizate)
- HARQ: HAR model with Realised Quarticity (model HAR cu cvarticitatea realizată)
- HEAVY: High-frEQUENCY-bAsed VolatilitY (models) (modele de volatilitate bazate pe date de înaltă frecvență)
- IQ: Integrated Quarticity (cvarticitatea integrată)
- LLM: Large Language Model (model lingvistic mare)
- MAE: Mean Absolute Error (eroarea absolută medie)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)

Acronime folosite în acest material (2/2)

- ▣ ML: Machine Learning (învățare automată)
- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ MZ: Mincer–Zarnowitz (regression) (regresia Mincer–Zarnowitz)
- ▣ NYSE: New York Stock Exchange (Bursa din New York)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ RF: Random Forest (pădure aleatoare)
- ▣ RK: Realised Kernel (nucleul realizat)
- ▣ RQ: Realised Quarticity (cvarticitatea realizată)
- ▣ RV: Realised Variance (varianța realizată)
- ▣ SE: Standard Error (eroare standard)
- ▣ SHAR: Semivariance HAR model (model HAR cu semivarianțe)
- ▣ SUA: Statele Unite ale Americii
- ▣ TRV: Truncated Realised Variance (varianța realizată trunchiată)
- ▣ TSRV: Two-Scale Realised Variance (varianța realizată pe două scări)
- ▣ UTC: Coordinated Universal Time (Temps Universel Coordonné) (timpul universal coordonat)
- ▣ VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)
- ▣ VRP: Variance Risk Premium (prima de risc a varianței)

Traseul capitolului și obiective

Traseul capitolului

- ▣ Partea I, **măsurare și diagnostic**: varianța realizată și precizia ei, zgomotul de microstructură, salturile
- ▣ Partea a II-a, **modelare și prognoză**: fapte stilizate, modelul HAR, evaluarea prognozelor față de GARCH, volatilitatea rough, un studiu de caz de învățare automată, o trecere prin bucla de cercetare asistată de AI
- ▣ Teoria asimptotică, estimatorii robuști la zgomot și la salturi și extensiile modelelor se află în [▶ Anexa](#) de la final

După acest capitol puteți

- ▣ calcula varianța realizată zilnică, eroarea ei standard și un interval de încredere din prețurile intraday
- ▣ diagnostica zgomotul de microstructură cu signature plot-ul și testa salturile cu control FDR
- ▣ estima log-HAR și compara prognoze de varianță cu QLIKE, Diebold–Mariano, Mincer–Zarnowitz și mulțimea de încredere a modelelor

Volatilitatea este latentă: o putem măsura?



Torben G. Andersen, 2012

Foto: Soralum (2012); CC BY-SA 4.0;

Wikimedia Commons

- Volatilitatea determină riscul ([Capitolele 7–8](#)), prețurile opțiunilor ([Capitolul 12](#)) și ponderile portofoliilor ([Capitolul 4](#)), dar nu este observată niciodată
 - ▶ Un randament zilnic este o singură observație dintr-o distribuție a cărei dispersie vrem să o estimăm
 - ▶ GARCH ([Capitolul 5](#)) deduce varianța de azi din randamentele zilnice trecute, printr-un model
- Ideea: într-o singură zi există sute de modificări de preț; suma pătratelor lor măsoară varianța zilei aproape fără model [Andersen & Bollerslev \(1998\)](#)
 - ▶ O contribuție timpurie: [Merton \(1980\)](#) a arătat că varianța, spre deosebire de medie, se estimează mai bine cu date mai frecvente
- Două obiecte diferite: varianța realizată este o **măsurare ex post** a zilei t , cunoscută după închidere; varianța GARCH este o **prognoză condiționată** a zilei t , făcută cu informația din ziua $t - 1$
- Întâi măsurăm, apoi modelăm: [Andersen, Bollerslev, Diebold & Labys \(2001\)](#), [Andersen, Bollerslev, Diebold & Ebens \(2001\)](#) studiază distribuția volatilității realizate; [Andersen, Bollerslev, Diebold & Labys \(2003\)](#) o prognozează direct; prezentarea din manual: [Franke, Härdle & Hafner \(2019\)](#)

Datele folosite în acest capitol

Seria	Frecvența	Perioada	Zile
SPY (ETF pe S&P 500)	bare de 5 minute, 09:30–16:00 ora New York	2020–2026	1 489
Bitcoin	bare de 5 minute, zile UTC de 24 de ore	2024–2026	659
SPY, Bitcoin	prețuri zilnice de închidere	2000/2014–2026	pentru GARCH
VIX	valoare zilnică la închidere	2020–2026	volatilitate implicită

- Până la 18 septembrie 2026; randamente $r_i = 100(\ln P_i - \ln P_{i-1})$ în %; o bară este etichetată cu ora de început
- SPY: 78 de randamente într-o zi completă, 43 în cele 12 zile cu program redus; barele din afara grilei de 5 minute sunt eliminate; barele lipsă dintr-o zi preiau ultimul preț
- Bitcoin: 288 de randamente pe zi; zilele cu mai puțin de 95% din bare sunt eliminate (88 din 747 de zile calendaristice, mai ales un gol de date în octombrie 2025)

Un model pentru prețurile intraday

- ▣ Notății: ziua t are M intervale de lungime $\Delta = 1/M$, randamente $r_{t,i}$, randamentul zilnic $r_t = \sum_i r_{t,i}$
 - ▶ Varianțe în $\%^2$; volatilitatea anualizată $\sqrt{252 \times \text{varianța}}$ (SPY), $\sqrt{365 \times \text{varianța}}$ (Bitcoin); randamentul SPY peste noapte (închidere – deschiderea următoare) este în afara barelor
- ▣ Logaritmul prețului în timp continuu: $dp(s) = \mu(s) ds + \sigma(s) dW(s)$, cu W o mișcare browniană (Capitolul 11)
 - ▶ $\sigma(s)$ este **volatilitatea instantanee**: se schimbă în cursul zilei și de la o zi la alta
- ▣ **Varianța integrată** a zilei t : mărimea pe care vrem să o măsurăm
 - ▶ $IV_t = \int_{t-1}^t \sigma^2(s) ds$
- ▣ Dacă σ este independent de W (fără efect de pârghe) și drift-ul este nul (sau determinat de traiectoria lui σ), atunci, dată fiind această traiectorie, randamentul zilnic urmează distribuția Normală: $r_t | \sigma \sim N(\int \mu, IV_t)$
 - ▶ Cu efect de pârghe (▶ Anexă: semimartingale Itô) această normalitate condiționată nu mai are loc, dar teoria limită a RV de mai jos rămâne valabilă


Definiție: varianța realizată

- **Varianța realizată:** suma pătratelor randamentelor intraday

►
$$RV_t = \sum_{i=1}^M r_{t,i}^2, \text{ volatilitatea realizată} = \sqrt{RV_t}$$


- Când $M \rightarrow \infty$, $RV_t \rightarrow IV_t$: drift-ul dispare, iar suma pătratelor converge la **variația pătratică** [Barndorff-Nielsen & Shephard \(2002\)](#)
 - Media randamentelor SPY de 5 minute este sub 1% din abaterea lor standard: poate fi ignorată
- Fără parametri de estimat: RV_t este o măsurare **fără model** a varianței unei zile
- Randamentul zilnic la pătrat r_t^2 este cazul particular $M = 1$: nedeplasat (cu drift nul), dar extrem de zgomotos

O zi, 78 de randamente: 7 aprilie 2025



- Stânga: SPY pe bare de 5 minute în cea mai volatilă zi din eșantion; dreapta: suma cumulată a pătratelor randamentelor
- SPY a deschis cu $-3,27\%$ sub închiderea anterioară, după anunțurile privind tarifele vamale; au urmat 78 de randamente de 5 minute
 - $RV = 45,1\%^2$: volatilitatea realizată anualizată $\sqrt{252 \times 45,1} = 107\%$
- Un singur randament de 5 minute de $+4,28\%$ (intervalul care se încheie la 10:15) a contribuit cu 41% din varianța realizată a zilei
- De la deschidere la închidere ziua s-a încheiat cu $+3,09\%$: randamentul zilnic ascunde oscilațiile din timpul zilei pe care RV le înregistrează; după RV, este una dintre cele mai agitate zile din 2020 încoace


Volatilitatea realizată zilnică: SPY și Bitcoin



- Anualizată, din randamente de 5 minute; SPY: sesiunea regulată din SUA; Bitcoin: 24 de ore; golul din octombrie 2025 reprezintă date lipsă
- SPY: volatilitatea din RV medie
 $\sqrt{252 \overline{RV}} = 12,9\%$ pe an, mediana volatilității zilnice 9,7%, interval de la 2,4% la 106,7%
 - ▶ Volatilitatea calculată din varianța medie depășește mediana: câteva zile foarte volatile ridică media pătratică a volatilităților zilnice
- Bitcoin: $\sqrt{365 \overline{RV}} = 45,1\%$ pe an, mediana 37,8%, maximul 136,1% pe 2026-02-05
- Ambele serii arată **gruparea volatilității**, ca la GARCH ([Capitolul 5](#)), dar fiecare punct este o măsurare, nu rezultatul unui model

 MFM_ch9_rv_series

Unde este riscul: ziua sau noaptea?




- SPY, varianța zilnică medie pe ani, anualizată: varianța realizată intraday plus randamentul peste noapte la pătrat; 2020 și 2026 sunt ani incompleți
- Randamentele peste noapte aduc 38% din varianța zilnică SPY, deși piața este închisă 17,5 ore
 - Știrile (rezultate financiare, date macroeconomice, sesiunile din Asia și Europa) se acumulează și sunt încorporate în preț la deschidere
- Anualizat: închidere-închidere 16,6%; deschidere-închidere 13,6%; peste noapte 10,1%
- Cea mai mare mișcare peste noapte: -4,08% pe 2024-08-05
- Pentru riscul zilnic folosim varianța **totală**: $RV_t + r_{\text{noapte},t}^2$ (media anualizată 16,4%)
 - Alternative: scalarea RV intraday în sus sau ponderarea optimă a celor două părți [Hansen & Lunde \(2005\)](#)

Cât de precisă este varianța realizată?


- Teorema limită centrală fezabilă pentru RV Barndorff-Nielsen & Shephard (2002):
 $\sqrt{M} (RV_t - IV_t) / \sqrt{2 RQ_t} \rightarrow N(0, 1)$
 - IQ_t este estimată prin cvarticitatea realizată $RQ_t = \frac{M}{3} \sum_i r_{t,i}^4$
- Eroarea standard: $se(RV_t) = \sqrt{\frac{2}{3} \sum_i r_{t,i}^4}$
- CI de 95% pe scara log (întotdeauna pozitiv): $RV_t \exp(\pm 1,96 se(RV_t) / RV_t)$
 - Cu volatilitate constantă, $se/RV \approx \sqrt{2/M}$: 16% pentru $M = 78$
- Varianța limită $2IQ_t$ este ea însăși aleatoare (o limită Normală mixtă); înlocuirea ei cu $2RQ_t$ este legitimă deoarece convergența este **stabilă** (enunțul formal în [► Anexă](#))

Intervale de încredere pentru volatilitatea zilnică



- ▣ SPY, martie–mai 2025; banda: intervalul de încredere de 95% pentru $\sqrt{252 IV_t}$ din cvarticitatea realizată
- ▣ Lățimea relativă mediană a intervalului (pentru volatilitate): 37% din nivelul ei
 - ▶ Banda presupune un preț continuu și zgomot neglijabil: într-o zi cu salt RV tinde la $IV_t + \sum_j \kappa_j^2$, iar $\sum r^4$ păstrează termenul κ^4 , deci banda nu mai are acoperirea nominală nici pentru variația totală, nici pentru IV_t (secțiunea Salturi)
- ▣ 9 aprilie 2025 (ziua în care a fost anunțată amânarea tarifelor): volatilitate 72%, CI [55%, 93%]
 - ▶ Intervalul se lărgiște când câteva randamente domină suma: $\sum r^4$ crește mai repede decât $(\sum r^2)^2$
- ▣ Totuși mult mai precisă decât r_t^2 , a cărei eroare relativă este de ordinul $\sqrt{2} \approx 141\%$ sub distribuția Normală
- ▣ Regulă practică: volatilitatea unei singure zile este cunoscută cu aproximativ $\pm 20\%$ (bandă de 95%), iar mediile pe săptămâni mult mai precis

Sezonalitatea intraday




- Stânga: SPY, media $|r_{t,i}|$ pe intervale de 5 minute ale zilei (doar zile complete); dreapta: Bitcoin pe ore UTC
- SPY: o **formă de U**: 0,106% în primele 5 minute, 0,050% la prânz, 0,089% în ultimele 5 minute [Andersen & Bollerslev \(1997\)](#)
 - Deschiderea încorporează știrile de peste noapte; închiderea concentrează reechilibrările indicilor și ale fondurilor
- Bitcoin se tranzacționează non-stop, dar este cel mai volatil la ora 14:00 UTC, în jurul deschiderii bursei din SUA (09:30 la New York: 13:30 UTC vara, 14:30 UTC iarna); cel mai calm la 10:00 UTC (raport 2,2)
- RV însumează pe toată ziua, deci sezonaltatea nu o deplasează; în schimb, deplasează BV și face ca testul de salturi (secțiunea Salturi) să respingă prea des; împărțirea randamentelor la un factor de periodicitate f_i [Boudt, Croux & Laurent \(2011\)](#) reduce respingerile SPY la nivelul de 5% de la 235 la 167 ([► Anexă](#))

De ce nu folosim fiecare tranzacție?

- Prețurile observate nu sunt prețul eficient: $p_i^{\text{obs}} = p_i^* + \varepsilon_i$, deci $r_i = r_i^* + \varepsilon_i - \varepsilon_{i-1}$
 - ▶ Sursele lui ε : oscilația între bid și ask, pasul de cotare (discretizarea prețului), cotații învechite (Capitolul 10)
- Cu zgomot i.i.d. de varianță ω^2 și n randamente pe zi Zhang, Mykland & Aït-Sahalia (2005), Hansen & Lunde (2006)
 - ▶ $\mathbb{E}[\text{RV}_t^{(n)} \mid \sigma] = \text{IV}_t + 2n\omega^2$ (drift nul, fără efect de pârghe): fiecare randament la pătrat conține $2\omega^2$ zgomot, deci deplasarea **crește** cu frecvența de eșantionare
 - ▶ Randamentele alăturate au în comun ε_{i-1} , cu semne opuse: $\text{cov}(r_i, r_{i-1}) = -\omega^2$
- Compromis: $\mathbb{E}[(\text{RV}^{(n)} - \text{IV})^2] \approx 2\text{IQ}/n + 4n^2\omega^4$, eroarea de discretizare plus deplasarea la pătrat
 - ▶ Numărul de randamente optim după MSE, $n^* = (\text{IQ}/(4\omega^4))^{1/3}$ Bandi & Russell (2008); derivarea în [▶ Anexă](#)
- Cifre: $\text{IV} = 1\%^2$, $\text{IQ} = 1$, $\omega = 0,01\%$: deplasarea 0,016 la 5 minute, 4,680 la 1 secundă; $n^* = 292$ (un randament la fiecare 80 s)

Signature plot-ul volatilității: simulare



- 100 de zile simulate, un preț pe secundă; prețul eficient cu volatilitate zilnică aleatoare plus zgomot i.i.d., $\omega = 0,01\%$
- IV medie adevărată = 0,98; RV din prețurile observate: 5,66 la 1 secundă, 1,06 la 1 minut, 0,98 la 5 minute
 - ▶ Deplasarea corespunde lui $2n\omega^2$ de pe slide-ul anterior
- Fără zgomot, RV este constantă în raport cu intervalul de eșantionare: creșterea la frecvențe mari este amprenta zgomotului
- Estimatori robuști la zgomot pe date de 1 secundă: RV pe două scări 0,95, nucleul realizat 0,99
 - ▶ Abaterea standard a erorii pe zile: RV pe 5 minute 0,187, pe două scări 0,150, nucleu 0,045: folosirea tuturor datelor aduce câștig doar cu o corecție de zgomot

Remedii: eşantionare rară și subeșantionare

- **Eșantionarea rară:** folosim un randament la fiecare 5 minute în loc de fiecare tranzacție
 - ▶ Simplă și robustă; aruncă majoritatea datelor [Liu, Patton & Sheppard \(2015\)](#)
- **Subeșantionarea:** calculăm RV pe K grile decalate (decalaje $0, 1, \dots, K - 1$) și facem media
 - ▶ $RV_t^{\text{avg}} = \frac{1}{K} \sum_{k=0}^{K-1} RV_t^{(k)}$: aceeași deplasare ca o singură grilă rară, varianță mai mică
- **RV pe două scări (TSRV)** [Zhang, Mykland & Aït-Sahalia \(2005\)](#): eliminăm deplasarea rămasă cu RV din toate datele
 - ▶ $TSRV_t = RV_t^{\text{avg}} - \frac{\bar{n}}{n} RV_t^{\text{all}}$, $\bar{n} = (n - K + 1)/K$; se împarte la $1 - \bar{n}/n$ în eşantioane mici
 - ▶ $\bar{n}$ este numărul mediu de randamente pe o grilă rară; grilele noastre păstrează și deschiderea, și închiderea, deci $\bar{n}$ este numărul lor mediu efectiv

Nuclee realizate




Neil Shephard, 2004

Foto: Renate Schmid (2004); CC BY-SA 2.0

de; Wikimedia Commons

- **Nucleul realizat** Barndorff-Nielsen, Hansen, Lunde & Shephard (2008): adăugăm autocovarianțele ponderate ale randamentelor
 - ▶ $RK_t = \gamma_0 + 2 \sum_{h=1}^H k\left(\frac{h}{H+1}\right) \gamma_h$, $\gamma_h = \sum_i r_{t,i} r_{t,i-h}$
 - ▶ Funcția de ponderare Parzen k : 1 în 0, scade lin la 0 în 1; păstrează RK pozitiv
- Zgomotul face γ_1 negativ; includerea acestui termen în estimatorul cu nucleu corectează deplasarea
- Lățimea de bandă H crește cu raportul zgomot/semnal: $H \approx 3,5 \xi^{4/5} n^{3/5}$, $\xi^2 = \omega^2 / \sqrt{IQ}$
- Pe date lichide de 5 minute nucleul modifică RV doar puțin (slide-ul următor); aduce câștig la date tick cu tick

Signature plot-ul pe date reale



- Volatilitatea anualizată din RV medie în funcție de intervalul de eșantionare: o singură grilă vs media pe toate grilele decalate
- Constantă: SPY 12,9% la 5 minute, 12,8% la 30, 13,0% la 130; Bitcoin 45,1% la 5 minute, 44,5% la 6 ore
 - Autocorelația de ordinul 1 a randamentelor de 5 minute: $-0,008$ (SPY), $0,005$ (Bitcoin): zgomot invizibil la 5 minute
- Limita acestor date: barele de 5 minute permit diagnosticul doar pentru eșantionarea la 5 minute și mai rară; nu spun nimic despre zgomotul sub 5 minute
- Pe date SPY de 5 minute: RV pe două scări / $RV = 0,97$, nucleu realizat / $RV = 0,95$; corelații cu RV 0,89 și 0,85
- În acord cu Liu, Patton & Sheppard (2015): aproape 400 de estimatori pe 31 de active întrec rareori RV pe 5 minute; estimatorii robuști la zgomot aduc câștig când zgomotul este mare față de semnal (date tick cu tick sau la nivel de secundă, active nelichide)

Prețurile sar: variația bipower



Ole E. Barndorff-Nielsen, 2007

Foto: Thomas Steiner (2007); CC BY-SA

2.5; Wikimedia Commons

- Adăugăm salturi în model: $dp = \mu ds + \sigma dW + dJ$, cu J un proces de salturi (știri, Capitolul 11)
 - ▶ Variația pătratică are acum două părți: $RV_t \rightarrow IV_t + \sum_j \kappa_j^2$, cu κ_j mărimile salturilor din ziua t
 - ▶ De ce le separăm? Salturile sunt mai puțin persistente decât volatilitatea difuzivă și sunt evaluate diferit (opțiuni, Capitolul 12)
- **Variația bipower** Barndorff-Nielsen & Shephard (2004): produse ale valorilor absolute ale randamentelor consecutive
 - ▶ $BV_t = \mu_1^{-2} \frac{M}{M-1} \sum_{i=2}^M |r_{t,i}| |r_{t,i-1}| \rightarrow IV_t$
 - ▶ $\mu_1 = \mathbb{E}|Z| = \sqrt{2/\pi} = 0,798$ pentru $Z \sim N(0, 1)$, deci $\mu_1^{-2} = \pi/2 = 1,571$; $\frac{M}{M-1}$: normalizarea pentru eșantion finit
- Un salt intră într-un singur randament, înmulțit cu un vecin mic: efectul lui asupra BV dispare când M crește; partea de salt a zilei este $\max(RV_t - BV_t, 0)$

Un test pentru salturi


- Statistica raportului Huang & Tauchen (2005), Barndorff-Nielsen & Shephard (2006):

$$z_t = \frac{(RV_t - BV_t)/RV_t}{\sqrt{\theta M^{-1} \max(1, TQ_t/BV_t^2)}}$$

$$\begin{aligned} \blacktriangleright \theta &= \pi^2/4 + \pi - 5 = 0,609; \text{ cvarticitatea tripower } TQ_t = M\mu_{4/3}^{-3} \frac{M}{M-2} \sum_i |r_{t,i}|^{4/3} |r_{t,i-1}|^{4/3} |r_{t,i-2}|^{4/3}, \\ \mu_{4/3} &= \mathbb{E}|Z|^{4/3} \end{aligned}$$

- Fără salturi $z_t \rightarrow N(0, 1)$; un salt face $RV > BV$ și z_t mare și pozitiv
- Un test pe zi: la nivelul α ne așteptăm la un număr de alarme false egal cu $\alpha \times$ numărul de zile fără salturi
 - Folosim $\alpha = 0,1\%$ (valoarea critică 3,09) pentru zilele cu salt din graficul următor
- Zi cu salt semnificativ: componenta de salt $J_t = RV_t - BV_t$, partea continuă $C_t = RV_t - J_t$; altfel $J_t = 0$

Zile cu salt: SPY și Bitcoin



- Punctele roșii: zile cu salt semnificativ la nivelul de 0,1%; mărimea punctului este proporțională cu partea de salt J_t
- SPY: 35 de zile cu salt din 1 489 (2,4%); salturile reprezintă 2,8% din varianța realizată totală
 - ▶ Într-o zi cu salt, saltul reprezintă în medie 35% din RV a zilei; BV/RV are media 0,95 pe toate zilele
 - ▶ Cea mai mare statistică: 2021-08-27 ($z = 5,2$), salt în intervalul 10:00–10:05, când a fost publicat discursul președintelui Rezervei Federale de la Jackson Hole
- Bitcoin: 67 de zile cu salt din 659 (10,2%), dar doar 1,8% din varianță
 - ▶ Multe salturi mici în zile liniștite (weekenduri): o singură mișcare izolată domină o zi calmă
- Zilele agitate din aprilie 2025 **nu** sunt în mare parte zile cu salt: multe randamente mari la rând cresc și BV


Multe zile, multe teste: salturi false

- 1 489 de teste zilnice la 5%: 235 de respingeri față de 74 așteptate fără salturi; care dintre ele sunt false?
- [Benjamini & Hochberg \(1995\)](#): ordonăm valorile p și respingem cele mai mici k , cu k cel mai mare indice pentru care $p_{(k)} \leq kq/N$; FDR, $\mathbb{E}[\text{false/respingeri}]$, rămâne $\leq q$ (cu false/respingeri := 0 când nu se respinge nimic)
 - ▶ Garanția cere valori p valide, independente sau pozitiv dependente [Benjamini & Yekutieli \(2001\)](#); testele zilnice de salt îndeplinesc aceste condiții doar aproximativ
 - ▶ SPY: FDR la 5%: 42 de zile cu salt; la 1%: 9; Bonferroni (FWER 5%): 7; FDR 5% după corecția de periodicitate: 17
- [Bajgrowicz, Scaillet & Treccani \(2016\)](#): fără controlul multiplicității majoritatea salturilor detectate sunt false; cele reale sunt rare și se concentrează în jurul anunțurilor
- [Christensen, Oomen & Podolskij \(2014\)](#): la frecvența tick cu tick majoritatea „salturilor” de 5 minute sunt explozii de volatilitate abrupte, dar continue
- Un test zilnic răspunde la întrebarea „a conținut ziua t un salt?”; localizarea saltului în cursul zilei cere un test intraday (Lee–Mykland, [▶ Anexă](#))

Verificați-vă: partea I


- De ce converge RV la varianța integrată când M crește și de ce eroarea ei standard folosește puterile a patra ale randamentelor?
- De ce este subestimat riscul zilnic al SPY dacă folosiți doar RV intraday?
- De ce supraestimează varianța eșantionarea fiecărei tranzacții și ce vă spune, și ce nu, un signature plot plat?
- De ce rămâne variația bipower apropiată de IV într-o zi cu salt, iar RV nu?
- Cu 1 489 de teste zilnice de salt, de ce „ $p < 0,05$ ” nu este o dovadă de salt și ce controlează FDR?

Distribuții: log RV și randamente standardizate




- Stânga: log RV zilnică pentru SPY și densitatea Normală; dreapta: randamentele deschidere-închidere scalate cu abaterea lor standard (plin) și cu $\sqrt{RV_t}$ (contur)
- RV pentru SPY: asimetrie 20,0, applatizare 550; log RV: asimetrie 0,29, applatizare 3,20 (distribuția Normală: 0 și 3)
 - Log RV pentru Bitcoin: asimetrie $-0,27$, applatizare 3,33: modelăm volatilitatea pe scară logaritmică
- Randamentele deschidere-închidere: applatizare 15,73; împărțite la $\sqrt{RV_t}$: 2,65, abatere standard 1,05
 - Bitcoin: de la 7,57 la 2,77
- Cozile grele ale randamentelor zilnice ([Capitolul 1](#)) provin, ex post, în mare parte din volatilitatea variabilă: aproximativ un amestec de distribuții Normale cu varianțele IV_t , exact doar fără efect de pârghie și fără salturi (secțiunea Varianța realizată)

Persistența volatilității realizate



- Autocorelații până la 100 de zile: log RV pentru SPY (varianța totală) și Bitcoin, randamentele zilnice SPY la pătrat
- Log RV pentru SPY: 0,64 la întârzierea 1, 0,24 la o lună, încă 0,10 la 100 de zile: dependență **foarte persistentă**
 - Un AR(1) ar scădea geometric: $0,64^{22} \approx 0,00005$; o funcție de autocorelație empirică este compatibilă cu memoria lungă, dar nu o poate dovedi
- Randamentele zilnice la pătrat arată aceeași persistență, ascunsă de zgomot: 0,20 la întârzierea 1
- Bitcoin: vârfuri la 7, 14, 21, ... zile: un **ciclu săptămânal**
 - RV de weekend este doar 0,41 din RV din zilele lucrătoare (sâmbătă 27% vs miercuri 48% pe an): fără știri bursiere sau macro, mai puțini investitori instituționali

Volatilitate implicită vs realizată



- ▣ Stânga: VIX și volatilitatea realizată SPY în următoarele 21 de zile de tranzacționare; dreapta: diferența dintre ele
- ▣ VIX: volatilitatea pe 30 de zile implicită din opțiunile pe S&P 500 ([Capitolul 12](#)); medie 19,5% vs 15,2% realizată ulterior; VIX a fost mai mare în 88% din 1 468 de zile, în medie cu 4,4 puncte procentuale
- ▣ **Prima de risc a varianței (VRP)** [Carr & Wu \(2009\)](#), [Bollerslev, Tauchen & Zhou \(2009\)](#):

$$VRP_t = \mathbb{E}^Q_t[RV_{t,t+21}] - \mathbb{E}^P_t[RV_{t,t+21}]$$
, speranța neutră la risc minus speranța fizică; VIX^2 aproximează primul termen
 - Graficul arată o diferență **ex post**, un indicator zgomotos al acestei prime ex ante; devine negativă când volatilitatea realizată depășește VIX anterior (martie–aprilie 2025): o eroare de prognoză, nu o primă negativă
- ▣ Ca prognoză: regresia varianței viitoare pe VIX^2 dă panta 0,56 (SE 0,05), $R^2 = 0,23$: VIX este informativ, dar deplasat în sus

Modelul HAR-RV


- Corsi (2009): $RV_{t+1} = \beta_0 + \beta_d RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+1}$
 - ▶ $RV_t^{(w)} = \frac{1}{5} \sum_{j=0}^4 RV_{t-j}$ (săptămâna), $RV_t^{(m)} = \frac{1}{22} \sum_{j=0}^{21} RV_{t-j}$ (luna)
 - ▶ Bitcoin se tranzacționează zilnic: săptămâna = 7 zile, luna = 30 de zile
- Ipoteza pieței eterogene Müller et al. (1997): investitori cu orizonturi zilnice, săptămânale și lunare; câteva componente cu persistență diferită imită memoria lungă
- Un AR(22) cu doar 3 pante libere: ponderea $\beta_d + \beta_w/5 + \beta_m/22$ la întârzierea 1, $\beta_w/5 + \beta_m/22$ la 2–5, $\beta_m/22$ la 6–22
- Estimare prin OLS; erorile sunt heteroscedastice și autocorelate: folosim erori standard Newey–West (HAC)
 - ▶ log-HAR: aceeași regresie pentru $\ln RV$; prognoza $\exp(\hat{y} + \hat{s}^2/2)$, cu $\hat{s}^2$ varianța reziduurilor: media condiționată dacă erorile sunt $N(0, s^2)$ (aproximare lognormală)
 - ▶ Pentru erori care nu urmează distribuția Normală folosim factorul de smearing $\frac{1}{T} \sum_t e^{\hat{\varepsilon}_t}$ Duan (1983); cu erori heteroscedastice ambele sunt aproximări

Estimări HAR: SPY și Bitcoin

	β_0	β_d	β_w	β_m	R^2
SPY, HAR (niveluri)	0,273 (0,064)	0,399 (0,089)	0,222 (0,096)	0,114 (0,053)	0,31
SPY, log-HAR	-0,079 (0,027)	0,362 (0,037)	0,337 (0,048)	0,167 (0,044)	0,47
Bitcoin, HAR (niveluri)	1,496 (0,412)	0,412 (0,089)	0,409 (0,122)	-0,065 (0,097)	0,34
Bitcoin, log-HAR	0,223 (0,094)	0,380 (0,041)	0,465 (0,080)	-0,022 (0,098)	0,36

- Eșantioanele complete; SPY: varianța zilnică totală (RV intraday plus randamentul peste noapte la pătrat), 1 467 de zile; Bitcoin: RV pe 24 de ore, 547 de zile în care sunt disponibili toți cei trei regresori HAR
- Erorile standard Newey–West în paranteze
- SPY: toate cele trei componente sunt semnificative; pe log $\hat{\beta}_d = 0,362$, $\hat{\beta}_w = 0,337$, $\hat{\beta}_m = 0,167$
 - Persistența $\hat{\beta}_d + \hat{\beta}_w + \hat{\beta}_m = 0,87$: șocurile se sting lent, ca la GARCH ([Capitolul 5](#))
- $R^2 = 0,47$ pentru log-varianță vs 0,31 pentru varianța pe niveluri: nu sunt comparabile, variabilele dependente diferă; decid pierderile în afara eșantionului pe o țintă comună (secțiunea Prognoze: HAR vs GARCH)
- Bitcoin: componentele zilnică și săptămânală contează; coeficientul lunar este aproape de 0 ($-0,022$, SE 0,098)
 - Eșantion scurt (doi ani) și un ciclu săptămânal puternic: săptămâna preia cea mai mare parte a memoriei

Ponderile implicite pe întârzieri și potrivirea în eșantion



- Stânga: ponderile log-HAR pe fiecare zi trecută (Bitcoin: ferestre complete de 7 și 30 de zile); dreapta: SPY, ultimele 250 de zile, volatilitatea realizată și valorile ajustate log-HAR
- SPY: ziua de ieri primește 0,437, fiecare dintre zilele 2–5 primește 0,075, fiecare dintre zilele 6–22 primește 0,008
- Ponderile în trepte scad lent: luna are încă ponderea $22 \times 0,008 \approx 0,167$
 - Trei coeficienți reproduc memoria lungă a funcției de autocorelație
- Bitcoin: ziua de ieri 0,446, zilele 2–7 aproximativ 0,066 fiecare, aproape nimic după o săptămână
- Valorile ajustate în eșantion urmăresc nivelul volatilității, nu zgomotul de la o zi la alta
- HAR este un AR(22) cu 19 restricții ($\phi_2 = \dots = \phi_5$, $\phi_6 = \dots = \phi_{22}$); testul Wald Newey–West pe SPY: $W = 18,1$, $p = 0,51$, nerespins (derivarea în [► Anexă](#))

Extensii ale HAR

- **HAR-CJ Andersen, Bollerslev & Diebold (2007)**: părțile continuă și de salt ca regresori separați
 - ▶ $\ln RV_{t+1} = \beta_0 + \beta_{Cd} \ln C_t + \beta_{Cw} \ln C_t^{(w)} + \beta_{Cm} \ln C_t^{(m)}$
 - ▶ $+ \beta_{Jd} \ln(1 + J_t) + \beta_{Jw} \ln(1 + J_t^{(w)}) + \beta_{Jm} \ln(1 + J_t^{(m)}) + \varepsilon_{t+1}$
 - ▶ $C_t^{(w)}, J_t^{(w)}$ ($C_t^{(m)}, J_t^{(m)}$): medii aritmetice pe ultimele 5 (22) zile, ca $RV_t^{(w)}$; logaritmul se aplică după mediere
- **HARQ Bollerslev, Patton & Quaedvlieg (2016)**: eroarea de măsurare din RV_t atenuează panta zilnică, deci punem o pondere mai mică pe RV de ieri când este imprecisă (cvarticitate realizată mare; derivarea și estimările pentru SPY în [▶ Anexă](#))
 - ▶ β_d devine $\beta_d + \beta_Q \sqrt{RQ_t}$ cu $\beta_Q < 0$
- Variabile indicator pentru weekend sau sărbători, efectul de pârghie (randamentele negative cresc RV viitoare), volatilitatea implicită ca regresor suplimentar
- Pe mai mulți pași: regresăm direct $\sum_{j=1}^h RV_{t+j}$ pe aceiași regresori

Designul prognozelor

- Ținta: varianța zilnică de mâine; SPY: varianța totală, 3 ianuarie 2022 – 18 septembrie 2026 (1 180 de zile); Bitcoin: de la 1 martie 2025 (422 de zile)
 - ▶ Fiecare prognoză folosește doar datele disponibile în seara precedentă
- Cinci modele
 - ▶ log-HAR și HAR pe varianța realizată, reestimate zilnic pe o fereastră de estimare care se extinde în timp
 - ▶ GARCH(1,1) cu erori Student- t pe randamente zilnice din 2000 (SPY) sau 2014 (Bitcoin), reestimat la fiecare 21 de zile [Bollerslev \(1986\)](#)
 - ▶ EWMA cu $\lambda = 0,94$ ([Capitolul 5](#)) și „RV de ieri” (mers aleator)
- HAR folosește date intraday; GARCH și EWMA folosesc doar randamente zilnice

Evaluarea față de o țintă zgomotoasă

- Varianța adevărată nu este observată; comparăm prognozele F_t cu proxy-ul RV_t
 - ▶ O funcție de pierdere este **robustă** dacă ordinea după pierderea *așteptată* obținută cu un proxy nedeplasat condiționat (dată fiind informația prognozelor) coincide cu ordinea obținută cu varianța adevărată [Patton \(2011\)](#)
- Două funcții de pierdere robuste
 - ▶ $MSE = (RV_t - F_t)^2$: dominată de zilele cele mai volatile
 - ▶ $QLIKE = \frac{RV_t}{F_t} - \ln \frac{RV_t}{F_t} - 1 \geq 0$: depinde doar de raport; penalizează mai mult subestimarea
- Greșeală frecventă: MAE sau MSE pe volatilitate în loc de varianță **nu** sunt robuste
 - ▶ [Andersen & Bollerslev \(1998\)](#): față de r_t^2 , prognozele GARCH explicau câteva procente din variație; față de RV aceleași prognoze explică mult mai mult: proxy-ul era zgomotos, nu modelul

Teste: Diebold–Mariano și Mincer–Zarnowitz

- Diebold & Mariano (1995): diferența de pierdere $d_t = L(RV_t, F_t^A) - L(RV_t, F_t^B)$;
 $t = \bar{d} / \text{se}_{\text{NW}}(\bar{d}) \rightarrow N(0, 1)$
 - ▶ $t < 0$: modelul A are pierderea mai mică; eroare standard HAC deoarece d_t este autocorelat (Capitolul 8)
- Mincer & Zarnowitz (1969): $RV_t = a + b F_t + u_t$; o prognoză nedeplasată are $a = 0$, $b = 1$
 - ▶ Test Wald comun cu covarianță Newey–West; R^2 măsoară cât din variație explică prognoza
 - ▶ R^2 este limitat de zgomotul din RV: nici varianța adevărată nu ar ajunge la 1 Andersen & Bollerslev (1998)

Rezultate: SPY, 2022–2026

Model	QLIKE	DM vs log-HAR (p)	MSE	MZ b	MZ R^2
log-HAR	0,310	–	4,15	1,16	0,30
HAR	0,326	–1,95 (0,052)	4,48	0,75	0,26
GARCH(1,1)- t	0,343	–2,30 (0,021)	4,87	0,70	0,20
EWMA	0,393	–4,02 ($< 0,001$)	5,14	0,74	0,14
RV de ieri	0,502	–5,95 ($< 0,001$)	5,41	0,54	0,29


- 1 180 prognoze pentru ziua următoare ale varianței zilnice totale; DM: $d_t = \text{QLIKE}(\text{log-HAR}) - \text{QLIKE}(\text{model})$, Newey–West; $t < 0$ favorizează log-HAR
- log-HAR are cele mai mici QLIKE și MSE: QLIKE cu 10% sub GARCH(1,1)- t (DM $t = -2,30$, $p = 0,021$)
 - Față de EWMA și RV de ieri câștigul este foarte semnificativ; față de HAR pe niveluri doar marginal ($p = 0,052$)
- Diferențele MSE nu sunt semnificative: câteva zile de criză (aprilie 2025) domină erorile la pătrat
- Mincer–Zarnowitz: log-HAR $b = 1,16$ ($p = 0,554$ pentru $a = 0$, $b = 1$), GARCH $b = 0,70$: fără deplasare semnificativă, dar log-HAR explică mai mult (R^2 0,30 vs 0,20)
- RV de ieri are un R^2 ridicat, dar $b = 0,54$: direcția corectă, mult prea extremă

Rezultate: Bitcoin, 2025–2026

Model	QLIKE	DM vs log-HAR (p)	MSE	MZ b	MZ R^2
log-HAR	0,282	–	26,6	0,82	0,38
HAR	0,409	–1,22 (0,223)	27,6	0,89	0,34
GARCH(1,1)- t	0,360	–4,32 ($< 0,001$)	42,2	0,55	0,23
EWMA	0,346	–2,96 (0,003)	36,3	0,64	0,18
RV de ieri	0,466	–5,38 ($< 0,001$)	35,0	0,58	0,33


- 422 prognoze pentru ziua următoare ale varianței realizate pe 24 de ore; aceleași modele și teste ca pentru SPY
- log-HAR câștigă din nou: QLIKE cu 22% sub GARCH(1,1)- t (DM $t = -4,32$, $p < 0,001$)
 - GARCH pe date zilnice este deplasat: MZ $b = 0,55$ ($p < 0,001$): reacționează excesiv la mișcările zilnice mari
- HAR pe niveluri este mai slab decât GARCH după QLIKE (0,409 vs 0,360): după weekenduri calme prezice o varianță prea mică, iar QLIKE penalizează subestimarea

Proгноzele în timp



- Sus: volatilitatea realizată SPY (inclusiv componenta de peste noapte) și cele două prognoze, anualizate; jos: pierderea QLIKE cumulată a fiecărui model minus log-HAR (linie crescătoare = log-HAR mai bun)
- După un șoc ambele prognoze cresc; GARCH rămâne ridicat mai mult (persistența lui este aproape de 1), log-HAR revine mai repede
 - ▶ Aprilie 2025: prognoza GARCH a rămas peste 40% pe an până la sfârșitul lui aprilie, în timp ce volatilitatea realizată era sub 20% de la jumătatea lunii
- Diferența cumulată de pierdere crește constant, cu salturi în episoadele agitate: câștigul nu provine dintr-o singură zi
- Dintre cele trei modele comparate în grafic cu log-HAR, EWMA pierde cel mai mult: un $\lambda = 0,94$ fix reacționează prea mult la zile izolate

Regresii Mincer–Zarnowitz



- SPY, 2022–2026: varianța realizată față de prognoză (scări log); linie întreruptă: dreapta de 45 de grade; negru: regresia estimată pe niveluri
- Prognozele log-HAR acoperă un interval mai larg: separă mai bine zilele calme de cele agitate
- Doar 1% dintre prognozele GARCH sunt sub $0,26\%^2$ pe zi (log-HAR: minimum $0,14\%^2$): în zilele calme varianța realizată scade mult sub GARCH
- Punctele sunt puternic dispersate în ambele grafice: varianța unei zile este greu de prognozat, iar RV însăși este măsurată cu eroare
- Orizontul săptămânal și extensiile modelului: Seminarul 9 (B6, B7)

Ce modele supraviețuiesc? Mulțimea de încredere a modelelor

Model	QLIKE	Valoarea p MCS	În MCS (90%)
log-HAR	0,310	1,000	✓
SHAR	0,320	0,224	✓
HAR	0,326	0,014	
HARQ	0,344	0,095	
GARCH(1,1)- t	0,343	0,095	
EWMA	0,393	0,012	
RV de ieri	0,502	0,000	

- Hansen, Lunde & Nason (2011): testăm egalitatea capacității predictive a tuturor modelelor (statistica amplitudinii, bootstrap pe blocuri), eliminăm cel mai slab model, repetăm; mulțimea rămasă conține cel mai bun model cu probabilitate asimptotică $\geq 90\%$ (în condițiile de regularitate ale metodei)
- SPY, 1 180 de zile din 2022: mulțimea de 90% este {log-HAR, SHAR}; SHAR împarte RV de ieri în semivarianțele realizate pozitivă și negativă Patton & Sheppard (2015); detaliile de estimare în [► Anexă](#)
- O procedură de comparații multiple: multe teste DM pe perechi, fără controlul probabilității erorilor de tip I, ar supraestima forța dovezilor (Capitolul 8)


Este volatilitatea rough (aspră)?

- ▣ Gatheral, Jaisson & Rosenbaum (2018): log-volatilitatea se comportă ca o **mișcare browniană fracționară** cu exponentul Hurst $H \approx 0,1$
 - ▶ $H = 0,5$: mișcarea browniană obișnuită; $H < 0,5$: incrementele sunt corelate negativ, traiectoriile sunt mai aspre; $H > 0,5$: mai netede, cu tendință
- ▣ Legea de scalare: $m(q, \Delta) = \frac{1}{T} \sum_t |\ln \sigma_{t+\Delta} - \ln \sigma_t|^q \propto \Delta^{qH}$
 - ▶ Regresăm $\ln m(q, \Delta)$ pe $\ln \Delta$: panta $\zeta_q = qH$; apoi H din pantele pentru diferite q
- ▣ Modelele de volatilitate rough reproduc forma zâmbetului volatilității implicite pentru scadențe scurte (Capitolul 12)

Rough sau zgomotoasă? Problema de identificare

- ▣ Gatheral, Jaisson & Rosenbaum (2018) raportează $H \approx 0,1$, dar H este estimat din RV, un indicator zgomotos al volatilității latente σ_t
 - ▶ Cont & Das (2024): estimatorul de scalare aplicat volatilității realizate găsește asprime chiar când volatilitatea instantanee este netedă: un artefact de estimare
 - ▶ Bolko, Christensen, Pakkanen & Veliyev (2023) (GMM care modelează eroarea din RV) și Fukasawa, Takabatake & Westphal (2022) (consistent sub asimptotica de înaltă frecvență) găsesc totuși $H < 0,5$
- ▣ Întrebarea formală: $\ln RV_t^{1/2} = \ln \sigma_t + e_t$, cu $\ln \sigma_t$ fracționar de indice H
 - ▶ $H_0: H = 1/2$ (volatilitate difuzivă clasică) față de $H_1: H < 1/2$
 - ▶ Problema de identificare: un H mic și un $\text{Var}(e_t)$ mare aplatizează amândouă $m(2, \Delta)$ la întârzieri mici
- ▣ Estimatorul de scalare aplicat indicatorilor RV zgomotoși este **inconsistent** pentru exponentul Hurst; consistența cere asimptotica de înaltă frecvență Fukasawa, Takabatake & Westphal (2022)
 - ▶ Asprimea pe termen scurt poate coexista cu memoria lungă Bennedsen, Lunde & Pakkanen (2022)
- ▣ Miza: panta zâmbetului la scadențe scurte și prognozele volatilității depind de H (Capitolul 12)

Scalarea incrementelor log-volatilității




- Stânga: $\ln m(q, \Delta)$ față de $\ln \Delta$ pentru SPY, $\Delta = 1, \dots, 30$ de zile; dreapta: pantele ζ_q față de q
- Punctele pe scala log-log sunt apropiate de linii drepte, iar pantele sunt aproape liniare în q : compatibil cu legea de scalare, pe care graficul singur nu o poate stabili
 - $\hat{H} = 0,11$ pentru SPY (CI bootstrap pe blocuri de 95% $[0,08, 0,13]$), 0,07 pentru Bitcoin (doar perechi observate la fiecare decalaj calendaristic; interpolarea zilelor lipsă dă 0,08): mult sub 0,5
- Atenție: RV măsoară volatilitatea cu eroare; eroarea i.i.d. coboară $\hat{H}$, alte structuri de eroare îl pot deplasa în ambele sensuri, deci $\hat{H}$ nu este o limită pentru H latent
 - O mișcare browniană simulată dă $\hat{H} = 0,46$; cu zgomot de mărime relativă similară, $\hat{H} = 0,18$ (Seminarul 9, B8)

Studiu de caz: întrebare, date și design


- ▣ Christensen, Siggaard & Veliyev (2023): oferă metodele de învățare automată (ML), cu reglaje minime, prognoze ale varianței realizate zilnice mai precise decât modelele HAR? Dacă da, de ce?
 - ▶ HAR Corsi (2009) este liniar în trei medii ale RV, iar RV este asimetrică la dreapta și persistentă: o funcție neliniară sau predictorii în afara RV trecute pot ajuta
- ▣ Date: 29 dintre cele 30 de acțiuni DJIA, ianuarie 2001 – decembrie 2017, $T = 4\,257$ zile, RV la 5 minute ($n = 78$)
 - ▶ Împărțire cronologică: antrenare 70%, validare 10%, test 20%
- ▣ Mulțimi de informații: $\mathcal{M}_{\text{HAR}}$ (RV zilnică, săptămânală, lunară) și $\mathcal{M}_{\text{ALL}}$, care adaugă 9 predictorii: volatilitatea implicită, VIX, volumul, momentum, indici macroeconomici și de incertitudine (Tabelul 1)
- ▣ Modele, cu reglaj minim: familia HAR prin OLS, regresii penalizate, ansambluri de arbori (bagging, random forest, boosting) și rețele neuronale; catalogul complet în [▶ Anexă](#)
- ▣ Evaluare: MSE în afara eșantionului relativă la HAR, pe fiecare acțiune și apoi mediată; test DM unilateral pe fiecare acțiune; MCS la 90%

Studiu de caz: câștigurile pe orizonturi



- Sursa: [Christensen, Siggaard & Veliyev \(2023\)](#), Tabelele 2–7: MSE în afara eșantionului relativ la HAR, mediat pe 29 de acțiuni DJIA (setul de test: ultimele 20% din 2001–2017); stânga: doar întârzierile RV, dreapta: toți cei 12 predictorii
- Doar întârzierile RV: cele șase modele din grafic rămân între 0,937 și 1,111 din MSE a HAR pe toate cele trei orizonturi: trei medii ale RV lasă puțin de învățat unui model flexibil
- Toți cei 12 predictorii: câștigul arborilor și al rețelelor crește cu orizontul, random forest $0,901 \rightarrow 0,796 \rightarrow 0,604$, rețeaua cu 2 straturi ascunse, media a 10 estimări (NN_2^{10}), $0,885 \rightarrow 0,846 \rightarrow 0,786$; autorii îl atribuie persistenței mai mari a valorilor ajustate ML (Figura 8)
- Modelele liniare cu aceiași predictorii se deteriorează (OLS $0,966 \rightarrow 1,290$, HARQ $1,289 \rightarrow 1,569$); doar log-HAR rămâne sub 1 ($0,901, 0,970, 0,919$)

Studiu de caz: 21 de modele, orizont de o lună



- Sursa: Christensen, Siggaard & Veliyev (2023), Tabelul 7: MSE relativă la HAR, orizont de o lună, toți cei 12 predictori, media pe 29 de acțiuni DJIA; NN_k^e : k straturi ascunse, media a e rețele
- Ansamblurile de arbori conduc: random forest 0,604, bagging 0,621; toate cele opt rețele întrec HAR (0,786–0,964), dar adâncimea nu ajută
- Toate regresiiile penalizate și extensiile liniare ale HAR pierd în fața HAR (1,107–1,569); log-HAR (0,919) este singurul model liniar sub 1
- Fiecare bară este media rapoartelor MSE pe acțiuni: nu este un test de semnificație al clasamentului; dacă acesta se păstrează pe SPY și după QLIKE este tema Seminarului 9, C3

Bucula descoperirii pentru întrebarea asprimii

- ▣ Întrebarea: este $\hat{H} \approx 0,1$ o proprietate a lui σ_t sau a erorii e_t din RV? $H_0: H = 1/2$ față de $H_1: H < 1/2$
- ▣ O trecere prin buclă cu un asistent AI (prompturi reutilizabile în [► Anexă](#))
 - ▶ Literatura: tabelăm estimările publicate ale lui H (estimator, frecvență, tratamentul erorii din RV); verificăm fiecare DOI pe Crossref
 - ▶ Ipoteze concurente, fiecare cu forma ei pentru $m(2, \Delta)$: fracționar cu $H = 0,1$; $H = 0,5$ plus eroare i.i.d.; doi factori, unul cu revenire rapidă la medie
 - ▶ Replicăm $\hat{H} = 0,11$ din capitol înainte de extindere; fixăm dinainte ferestrele de întârzieri, măsurile și ajustarea cu termen constant de zgomot k
- ▣ Verificări care revin cercetătorului
 - ▶ Eroarea indicatorului: simulăm $H = 0,5$ plus eroare de aceeași mărime; procedura nu trebuie să întoarcă $H \approx 0,1$
 - ▶ Incrementele suprapuse invalidează erorile standard OLS ale lui ζ_q : folosim bootstrap pe blocuri; raportăm toate ferestrele încercate
 - ▶ Asistenții citează „ $H \approx 0,1$ pentru toate activele”: verificăm fiecare cifră în tabelul lucrării citate

Mini studiu de caz: este $\hat{H}$ un artefact al erorii i.i.d.?

- O propunere tipică a asistentului: $\hat{H} \approx 0,1$ provine din eroarea de măsurare i.i.d. din RV. Implicația: $m(2, \Delta) = c \Delta^{2H} + k$ cu $k = 2 \text{Var}(e_t) > 0$, deci $\hat{H}$ **crește** când renunțăm la întârzierile mici

	$\Delta \in [1, 30]$	$[5, 30]$	$[10, 50]$	Ajustare cu k , $[1, 50]$
$H = 0,5$ simulat plus eroare	0,18	0,24	0,26	0,39
SPY, RV totală	0,106	0,089	0,077	0,096
SPY, RV intraday	0,129	0,094	0,078	0,113

- Prima coloană replică valoarea din capitol; rândul simulat (o singură traiectorie, nu un studiu de putere) arată mecanismul: $\hat{H}$ crește, iar ajustarea cu k recuperează mare parte din distanța până la 0,5
- SPY: $\hat{H}$ **scade** cu fereastra, iar k estimat este 0; $\hat{H} = 0,096$, CI bootstrap pe blocuri de 95% $[0,058, 0,268]$
- Interpretare: un diagnostic ilustrativ, incompatibil cu explicația prin eroare i.i.d.; o respingere formală cere un test calibrat prin simulare; mecanismul non-i.i.d. din [Cont & Das \(2024\)](#) nu este testat de acest design.

Rândul vostru: un punct de plecare pentru proiect

- ▣ Întrebarea: supraviețuiește asprimea volatilității SPY și Bitcoin unui estimator care modelează eroarea de măsurare din RV?
- ▣ Replicați mai întâi: $\hat{H} = 0,11$ (SPY) și $0,07$ (Bitcoin) din legea de scalare și $\hat{H} = 0,18$ pentru $H = 0,5$ simulat plus eroare (Seminarul 9, B8)
- ▣ Livrabile
 - ▶ O pre-înregistrare (ipoteze, estimatori, ferestre de întârzieri, teste, designul simulării) datată înainte de prima rulare
 - ▶ Estimatorul GMM din [Bolko, Christensen, Pakkanen & Veliyev \(2023\)](#) pe seriile RV ale cursului, cu mărimea și puterea Monte Carlo la $H \in \{0,1; 0,5\}$
 - ▶ Codul, un raport de două pagini cu toate specificațiile încercate și o critică, în stil de recenzent, a propriului rezultat
- ▣ Consemnați fiecare prompt care a influențat o decizie în `AI_USE.md` și fiecare eroare a asistentului în `AI_ERRORS.md`: github.com/danpele/MFM/tree/main/project

Ce instrument și când?

Situația	Instrumentul sugerat
Activ lichid, bare de 1–5 minute	RV la 5 minute, subeșantionată
Date tick cu tick sau o acțiune nelichidă (BVB)	Pre-averaging sau nucleu realizat flat-top ($n^{-1/4}$; Parzen $n^{-1/5}$; ▶ Anexă: ratele de convergență); verificați signature plot-ul
Riscul zilnic al unui activ tranzacționat la bursă	Varianța totală: RV plus randamentul peste noapte la pătrat
Separarea salturilor din știri de difuzie	BV sau MedRV (varianța realizată bazată pe mediane, ▶ Anexă), testul raportului cu control FDR; Lee–Mykland pentru momentul saltului
Prognoza varianței zilnice sau săptămânale	log-HAR (plus salturi, weekenduri, RQ); reper GARCH
Compararea prognozelor	QLIKE și MSE pe varianță, Diebold–Mariano, Mincer–Zarnowitz, mulțimea de încredere a modelelor

- Rezultatul cel mai solid: în afara eșantionului, log-HAR întrece GARCH(1,1)- t după QLIKE cu 10% (SPY) și 22% (Bitcoin); comparațiile după MSE nu sunt concludente
- Ipoteze: regula de 5 minute se sprijină pe un signature plot plat la 5 minute și la intervale mai mari; numărul de salturi, pe controlul FDR și corecția de periodicitate

Verificați-vă și ce urmează: Capitolul 10

Întrebări de verificare

- De ce R^2 pentru log RV nu este comparabil cu R^2 pentru RV pe niveluri?
- De ce este QLIKE robustă la un indicator RV zgomotos, iar MSE pe volatilitate nu?
- De ce MCS indică o mulțime de modele, nu un câștigător?
- Cum poate eroarea de măsurare din RV să facă volatilitatea să pară rough?

: microstructura pieței

- De unde provine zgomotul ε din acest capitol: registrul de ordine limită, spread-ul bid-ask, pasul de cotare
- Lichiditatea, impactul asupra pieței și tranzacționarea de înaltă frecvență, pe burse de acțiuni și cripto

Anexă: semimartingale Itô și convergența stabilă

- Semimartingală Itô: $dp = \mu ds + \sigma dW + dJ$, cu μ, σ adaptate și σ càdlàg; σ poate depinde de W (efect de pârghie)
 - ▶ Fără salturi: $\sqrt{M}(RV_t - IV_t) \xrightarrow{\mathcal{L}-s} MN(0, 2IQ_t)$, o distribuție Normală **mixtă**, a cărei varianță $2IQ_t$, cu cvarticitatea integrată IQ , $IQ_t = \int \sigma^4(s) ds$, este ea însăși aleatoare [Barndorff-Nielsen & Shephard \(2002\)](#)
- Convergența **stabilă** ($\mathcal{L}$ -s): convergența are loc în comun cu orice variabilă aleatoare măsurabilă în raport cu σ -algebra traiectoriei [Mykland & Zhang \(2009\)](#)
 - ▶ De aceea $(RV_t - IV_t)/\sqrt{2RQ_t/M} \rightarrow N(0, 1)$: studentizarea cu $\sqrt{2RQ_t/M}$, unde $RQ_t \rightarrow IQ_t$ este aleatoare, este legitimă doar sub convergența stabilă
- În eșantioane finite: statistica t pentru $\ln RV_t$ are acoperire mai bună decât cea pe niveluri [Barndorff-Nielsen & Shephard \(2005\)](#); intervalele de încredere din curs o folosesc

Anexă: derivarea deplasării din zgomot și a frecvenței optime

- Randamentul observat $r_i = r_i^* + \varepsilon_i - \varepsilon_{i-1}$, cu ε i.i.d. $(0, \omega^2)$, independent de p^*
 - Dată fiind traiectoria lui σ (drift nul, fără efect de pârgă: σ independent de W):
 $\mathbb{E}[\text{RV}^{(n)} \mid \sigma] = \sum_i \mathbb{E}[r_i^{*2} \mid \sigma] + \sum_i \mathbb{E}[(\varepsilon_i - \varepsilon_{i-1})^2] = \text{IV} + 2n\omega^2$; $\text{cov}(r_i, r_{i-1}) = -\mathbb{E}[\varepsilon_{i-1}^2] = -\omega^2$
 - Din legea numerelor mari pentru termenii de zgomot, $\text{RV}^{(n)}/(2n) \xrightarrow{p} \omega^2$ când $n \rightarrow \infty$: RV din toate tranzacțiile estimează zgomotul, nu IV [Bandi & Russell \(2008\)](#)
- MSE: $\mathbb{E}[(\text{RV}^{(n)} - \text{IV})^2] \approx \underbrace{2 \text{IQ}/n}_{\text{discretizare}} + \underbrace{4n^2\omega^4}_{\text{deplasarea la pătrat}} + O(n)$
 - Condiția de ordinul întâi $-2 \text{IQ}/n^2 + 8n\omega^4 = 0$ dă $n^* = (\text{IQ}/(4\omega^4))^{1/3}$ [Bandi & Russell \(2008\)](#)
- Cifre: $\text{IV} = 1\%^2$, $\text{IQ} = 1$, $\omega = 0,01\%$: deplasarea 0,016 la 5 minute, 4,680 la 1 secundă; $n^* = 292$ (un randament la fiecare 80 s)

Anexă: sezonabilitatea intraday și testul de salturi

- RV însumează pe toată ziua, deci sezonabilitatea nu o deplasează; în schimb, deplasează BV:
$$\mathbb{E}|r_i| |r_{i-1}| \propto \sigma_i \sigma_{i-1} \leq (\sigma_i^2 + \sigma_{i-1}^2)/2$$
 - ▶ Schimbările rapide de scară (deschiderea, închiderea) cresc RV – BV, deci testul raportului (secțiunea Salturi) respinge prea des
- Factorul de periodicitate f_i , estimatorul abaterii standard din [Boudt, Croux & Laurent \(2011\)](#): scalăm fiecare randament cu $\sqrt{BV_t/M_t}$, luăm rădăcina mediei pătratelor pe fiecare interval al zilei și normalizăm media lui f_i^2 la 1
 - ▶ SPY: $f = 1,78$ la deschidere, 0,73 la minim, 1,52 la închidere
- Împărțind $r_{t,i}$ la f_i înainte de test: respingerile SPY la nivelul de 5% scad de la 235 la 167; la nivelul de 0,1% rămân 20

Anexă: ratele de convergență în prezența zgomotului

Estimator	Eroare de ordinul	Pozitiv	Sursa
RV pe toate tranzacțiile	inconsistent ($2n\omega^2$) (deplasare)	da	Bandi & Russell (2008)
RV rară, grilă fixă de 5 minute	$M^{-1/2}$, M fix; deplasarea rămâne	da	Liu, Patton & Sheppard (2015)
RV pe două scări	$n^{-1/6}$	nu	Zhang, Mykland & Aït-Sahalia (2005)
RV pe mai multe scări	$n^{-1/4}$	nu	Zhang (2006)
Nucleu realizat, flat-top / Parzen	$n^{-1/4}$ / $n^{-1/5}$	nu / da	Barndorff-Nielsen, Hansen, Lunde & Shephard (2008)
Pre-averaging	$n^{-1/4}$	nu	Jacod, Li, Mykland, Podolskij & Vetter (2009)

- $n^{-1/4}$ este rata optimă cu zgomot i.i.d.: prețul zgomotului este jumătate din exponentul obișnuit
- Cu $n = 23\,400$ de secunde: $n^{1/4} \approx 12,4$, față de $\sqrt{78} \approx 8,8$ pentru RV pe 5 minute: doar o euristică (ratele ignoră constantele, mărimea zgomotului și deplasarea RV rare), compatibilă cu câștigurile modeste din Liu, Patton & Sheppard (2015)

Anexă: pre-averaging

- Medii locale ale unui număr de $k_n \approx \theta\sqrt{n}$ randamente cu o pondere g pe $[0, 1]$, de ex. $g(x) = \min(x, 1 - x)$ Jacod, Li, Mykland, Podolskij & Vetter (2009)
 - ▶ $\bar{r}_i = \sum_{j=1}^{k_n-1} g(j/k_n) r_{i+j}$: varianța zgomotului scade ca $1/k_n$, semnalul păstrează ordinul k_n/n
- Estimatorul, cu $\psi_1 = \int_0^1 g'(x)^2 dx$, $\psi_2 = \int_0^1 g(x)^2 dx$ (1 și 1/12 pentru g triunghiular)
 - ▶ $\widehat{IV} = \frac{1}{\theta \psi_2 \sqrt{n}} \sum_i \bar{r}_i^2 - \frac{\psi_1}{2\theta^2 \psi_2 n} \sum_i r_i^2$ (al doilea termen: corecția deplasării din zgomot)
- Rata $n^{-1/4}$; același procedeu dă estimatori robuști la salturi (bipower cu pre-averaging) și estimatori de covarianță
- Construită pentru date tick cu tick: pe bare de 5 minute rămâne puțin zgomot de mediat (signature plot-ul empiric, secțiunea Zgomotul de microstructură)

Anexă: covarianța realizată și tranzacționarea asincronă

- Covarianța realizată $\sum_i r_{t,i}^{(1)} r_{t,i}^{(2)} \rightarrow \int \sigma_{12}(s) ds$ cere prețurile ambelor active pe **aceeași** grilă
 - ▶ Efectul Epps [Epps \(1979\)](#): corelația măsurată scade spre 0 când eșantionarea devine mai deasă, deoarece tranzacțiile sunt asincrone, iar ultimul preț este învechit
- [Hayashi & Yoshida \(2005\)](#): însumăm produsele **tuturor** perechilor de randamente ale căror intervale de timp se suprapun
 - ▶ $\sum_{i,j} r_i^{(1)} r_j^{(2)} 1\{(t_{i-1}, t_i] \cap (s_{j-1}, s_j] \neq \emptyset\}$: nedeplasat fără sincronizare (în absența zgomotului)
- Cu zgomot în plus: versiuni cu pre-averaging sau nuclee multivariate; aplicație: riscul intraday al portofoliilor ([Capitolul 4](#))

Anexă: localizarea salturilor în cursul zilei, Lee–Mykland

- Lee & Mykland (2008): $L_{t,i} = r_{t,i} / \hat{\sigma}_{t,i}$, cu $\hat{\sigma}_{t,i}^2$ media bipower a celor $K = 270$ de randamente anterioare (valoarea lor pentru date de 5 minute)
 - ▶ Fără salturi, $\max_i |L_i|$ pe n randamente are o limită Gumbel: respingem dacă $(|L| - C_n) / S_n > -\ln(-\ln(1 - \alpha))$, cu $C_n = \sqrt{2 \ln n} - \frac{\ln \pi + \ln \ln n}{2\sqrt{2 \ln n}}$ și $S_n = 1 / \sqrt{2 \ln n}$ ($\hat{\sigma}^2$ al nostru include factorul $\pi/2$, deci constanta $c = \sqrt{2/\pi}$ din Lee & Mykland (2008) devine 1)
 - ▶ SPY, randamente împărțite la f_i , $\alpha = 1\%$, $n = 115\,453$ (întregul eșantion): pragul $|L| > 5,41$
- 169 salturi în 105 zile; 62 dintre ele miercurea între 14:00 și 15:00, când se publică comunicatele FOMC (14:00) și au loc conferințele de presă (14:30)
 - ▶ Cel mai mare: $L = -22,9$ pe 2025-10-29; doar 10% din aceste zile sunt semnalate și de testul zilnic al raportului
- Cele două teste pun întrebări diferite: un randament extrem față de volatilitatea locală, respectiv un decalaj zilnic între RV și BV

Anexă: estimatori ai varianței integrate robuste la salturi

- RV trunchiată Mancini (2009): $TRV_t = \sum_i r_{t,i}^2 \mathbf{1}\{|r_{t,i}| \leq c \hat{\sigma}_t f_i \Delta^\varpi\}$, $\varpi \in (0, 1/2)$
 - Incrementele difuzive sunt $O_p(\Delta^{1/2})$ și ajung sub prag; salturile sunt $O(1)$ și sunt eliminate
- MedRV Andersen, Dobrev & Schaumburg (2012): $\frac{\pi}{6-4\sqrt{3}+\pi} \frac{M}{M-2} \sum_i \text{med}(|r_{i-1}|, |r_i|, |r_{i+1}|)^2$
 - Un randament izolat mai mare în valoare absolută decât ambii vecini nu intră în mediană (care trece la un vecin), deci un salt izolat mare este exclus, deși efectul lui nu dispare exact în eșantioane finite; MedRV este mai puțin sensibil decât BV la randamente nule izolate; două salturi alăturate pot intra totuși în mediană
- Ponderea salturilor în RV SPY: BV 6,3%, MedRV 7,2%, TRV 12,5% ($c = 3$, $\varpi = 0,49$; trunchierea acționează în 44% din zile: c este o alegere de reglaj)
- Aït-Sahalia & Jacod (2009): comparăm variațiile de putere $\sum |r|^p$, $p > 2$, la Δ și $k\Delta$; raportul tinde la 1 cu salturi și la $k^{p/2-1}$ fără: limite cunoscute sub ambele ipoteze

Anexă: HAR ca AR(22) restricționat, testul Wald

- Nerestricționat: $\ln RV_{t+1} = \phi_0 + \sum_{k=1}^{22} \phi_k \ln RV_{t+1-k} + \varepsilon_{t+1}$
 - ▶ HAR impune $\phi_2 = \dots = \phi_5$ (3 restricții) și $\phi_6 = \dots = \phi_{22}$ (16): $R\phi = 0$ cu 19 rânduri
- Wald: $W = (R\hat{\phi})^\top (R\hat{V}_{NW}R^\top)^{-1} R\hat{\phi} \rightarrow \chi_{19}^2$ sub restricțiile HAR
- SPY, log varianța totală: $W = 18,1$, $p = 0,51$; R^2 0,477 (AR(22)) vs 0,470 (HAR)
 - ▶ Restricțiile asupra ponderilor în trepte nu sunt respinse: HAR folosește cu 19 parametri mai puțini, cu o reducere minimă a calității ajustării în eșantion, iar zgomotul de estimare mai mic ajută în afara eșantionului

Anexă: eroarea de măsurare din regresori și HARQ

- $RV_t = IV_t + u_t$ cu $\mathbb{E}[u_t | \sigma] = 0$ și $\text{Var}(u_t | \sigma) = 2 IQ_t / M$ (CLT din secțiunea Varianța realizată)
 - Dacă $IV_{t+1} = \beta_0 + \beta IV_t + \eta_{t+1}$, OLS pentru RV_{t+1} pe RV_t dă plim $\hat{\beta} = \beta \frac{\text{Var}(IV)}{\text{Var}(IV) + \mathbb{E}[2 IQ / M]} < \beta$ pentru $\beta > 0$:
atenuare
- Dacă varianța semnalului nu crește cu IQ_t (o aproximare de lucru), raportul semnal/zgomot al lui RV_t scade când IQ_t este mare; HARQ aproximează ponderea descrescătoare prin $\beta_d + \beta_Q \sqrt{RQ_t}$, $\beta_Q < 0$ [Bollerslev, Patton & Quaedvlieg \(2016\)](#)
- SPY, niveluri, SE Newey–West: RV intraday $\hat{\beta}_Q = -0,0088$ (0,0042); varianța totală $-0,0022$ (0,0024)
 - Panta zilnică (RV intraday) 1,13 la mediana lui $\sqrt{RQ}$, 1,09 la percentila 99: semnul prezis de teorie, un efect mic

Anexă: dincolo de HAR, semivarianțe și modele comune randament–RV

- Semivarianțele realizate $RS_t^\pm = \sum_i r_{t,i}^2 1\{r_{t,i} \gtrless 0\}$, $RS^+ + RS^- = RV$; SHAR Patton & Sheppard (2015): $\beta_d RV_t$ devine $\beta^+ RS_t^+ + \beta^- RS_t^-$
 - ▶ SPY, niveluri (randamentul peste noapte socotit ca încă un randament al zilei): $\hat{\beta}^- = 0,56 (0,23)$, $\hat{\beta}^+ = 0,21 (0,18)$; Wald $\beta^+ = \beta^-$: $p = 0,35$
 - ▶ Volatilitatea „rea” este mai persistentă, ca în Patton & Sheppard (2015), dar șase ani de date nu separă cele două pante
 - ▶ În comparația MCS, HARQ și SHAR sunt estimate pe niveluri cu filtrul din Bollerslev, Patton & Quaadvlieg (2016): prognozele care ies din intervalul $[\min, \max]$ al valorilor din eșantionul de estimare sunt înlocuite cu media eșantionului
- Realized GARCH Hansen, Huang & Shek (2012): o ecuație GARCH condusă de măsura realizată x_t , plus o ecuație de măsurare
 - ▶ $\ln h_t = \omega + \beta \ln h_{t-1} + \gamma \ln x_{t-1}$, $\ln x_t = \xi + \varphi \ln h_t + \tau(z_t) + u_t$, $r_t = \sqrt{h_t} z_t$: estimare comună prin cvasi-maximă verosimilitate
- Modelele HEAVY Shephard & Sheppard (2010): o ecuație de tip GARCH pentru varianța zilnică, condusă de RV întârziată, și una pentru RV însăși: prognoze coerente pe mai mulți pași

Anexă: studiul de caz, date și modele

- Date (Secțiunea 2 a lucrării): 29 dintre cele 30 de acțiuni DJIA (fără Visa), 29 ianuarie 2001 – 31 decembrie 2017, $T = 4\,257$ zile; RV calculată la 5 minute din prețurile tranzacțiilor NYSE, după filtrarea datelor, $n = 78$ de randamente pe zi
 - ▶ Împărțire: antrenare 70% (2 964 zile), validare 10% (424), test 20% (847); robustețe: antrenare 1 000 sau 2 000 de zile, validare 200 (Anexa A.1 a lucrării)
 - ▶ $\mathcal{M}_{\text{HAR}}$: RV zilnică, săptămânală, lunară; $\mathcal{M}_{\text{ALL}}$ adaugă 9 predictorii (Tabelul 1): volatilitatea implicită, indicator pentru zilele în care se anunță rezultatele financiare, momentum pe o săptămână, variația logaritmului volumului tranzacționat în dolari; VIX, randamentul Hang Seng la pătrat, indicele condițiilor de afaceri, variația ratei la 3 luni a titlurilor de stat, indicele incertitudinii politicii economice
- Modele (Secțiunea 1 a lucrării): HAR, log-HAR, HAR cu efect de pârghie, SHAR, HARQ prin OLS pe o fereastră mobilă; ridge (penalizare L_2), lasso (L_1), elastic net (o combinație), lasso adaptiv și post-lasso, cu penalizarea aleasă pe setul de validare
 - ▶ Arbori: bagging, random forest (RF) cu valorile implicite ale lui Breiman, 500 de arbori, $J/3$ predictorii candidați la fiecare ramificare (J : numărul de predictorii), cel puțin 5 observații într-un nod (Tabelul A.6 din lucrare), gradient boosting
 - ▶ Rețele neuronale NN_k^e : $k = 1, \dots, 4$ straturi ascunse (2; 4-2; 8-4-2; 16-8-4-2 neuroni), leaky ReLU, Adam, dropout, early stopping; $e = 1$: rețeaua cu cea mai mică eroare pe setul de validare dintre cele 100 de inițializări, $e = 10$: media celor mai bune 10
- Evaluare (Secțiunea 1.6 a lucrării): raportul dintre MSE în afara eșantionului și MSE a modelului HAR, calculat pentru fiecare acțiune și apoi mediat; test DM unilateral pentru fiecare acțiune [Diebold & Mariano \(1995\)](#); MCS la 90% [Hansen, Lunde & Nason \(2011\)](#)

Anexă: studiul de caz, rezultatele complete

- Prognoze pentru ziua următoare, doar cu valorile întârziate ale RV (Tabelul 2): MSE relativ la HAR: log-HAR 0,995, HARQ 1,059, RF 1,020, rețele neuronale 0,954–0,990
 - ▶ RV trecută lasă puțin de învățat: rețelele aduc cele mai clare câștiguri (1–5%), log-HAR întrece HAR la limită
- Prognoze pentru ziua următoare, cu toți cei 12 predictorii (Tabelul 3): OLS cu toți predictorii 0,966, HARQ 1,289; elastic net 0,916, RF 0,901, log-HAR 0,901, NN_2^{10} 0,885
 - ▶ Predictorii suplimentari aduc cel mai mult cu penalizare, neliniaritate sau transformarea logaritmică; OLS simplu câștigă mai puțin (0,966), iar HARQ face overfitting
- Prognoze pentru luna următoare, cu toți predictorii (Tabelul 7): RF 0,604, bagging 0,621, rețele 0,786–0,964, log-HAR 0,919, OLS cu toți predictorii 1,290
 - ▶ Câștigul crește odată cu orizontul de prognoză: valorile ajustate de modelele ML sunt mai persistente (Figura 8) și aproximează mai bine memoria lungă a RV
- MCS la 90% (Figura 4): cu toți predictorii, rețelele rămân în mulțime pentru aproximativ 80% din acțiuni, HAR pentru aproximativ 20–40%
 - ▶ Importanța variabilelor, măsurată prin efectele locale acumulate (Figura 7): RV zilnică, RV săptămânală și volatilitatea implicită domină în toate cele patru modele prezentate; RF și rețelele atribuie volatilității implicite o importanță mai mare decât OLS cu toți predictorii și elastic net

Anexă: studiul de caz, replicare, limite și extinderi

- Replicare pe datele cursului: barele SPY de 5 minute din datele cursului, RV de la deschidere la închidere cu 78 de randamente pe zi (eșantionarea din lucrare, Secțiunea 2); autorii raportează că SPY confirmă rezultatele pe acțiuni (nota 12)
 - ▶ Împărțirea din Anexa A.1 a lucrării: 1 000 de zile de antrenare, 200 de zile de validare, restul până la 18 septembrie 2026 ca set de test
 - ▶ Predictorii: VIX (calculat din opțiunile pe indicele S&P 500; aproximează volatilitatea implicită a SPY, care ar cere opțiuni pe SPY), randamentul Hang Seng la pătrat, momentum și volum în dolari pentru SPY, rata titlurilor de stat și incertitudinea politicii economice (FRED); fără indicator de rezultate financiare pentru un fond (Seminarul 9, C3)
- Limite precizate de autori
 - ▶ Reglarea mai atentă a hiperparametrilor ar putea îmbunătăți performanța ML (Secțiunea 6 a lucrării); rețelele sunt antrenate o singură dată și nu sunt reestimate în fereastra de test (Secțiunea 2 a lucrării)
 - ▶ Clasamentele depind de împărțire: cu 1 000 de zile de antrenare criza financiară intră în setul de test, iar extensiile HAR întrec HAR (Secțiunea 3.1 și Anexa A.1 ale lucrării)
 - ▶ Modelele HAR cu o componentă de salt separată nu sunt incluse (Secțiunea 1.2 a lucrării); efectele locale acumulate descriu comportamentul mediu al predicțiilor și pot omite efectele evenimentelor rare, precum anunțarea rezultatelor financiare (Secțiunea 3.2 a lucrării)
- Extindere: lucrarea compară prognozele de varianță prin MSE. Se păstrează avantajul ML la evaluarea prin QLIKE, robustă la eroarea de măsurare din RV [Patton \(2011\)](#), și pentru RV Bitcoin pe 24 de ore?

Anexă: bucla descoperirii, prompturi reutilizabile (1/2)

- Instrumente: un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau GitHub Copilot); căutarea literaturii: [Semantic Scholar](#), [Elicit](#), [Google Scholar](#)
- 1. **Literatura:** sintetizăm rezultatele într-un tabel, apoi verificăm fiecare DOI pe [Crossref](#) (titlul trebuie să coincidă)
 - ▶ Tabelează estimările lui H publicate din 2018: estimatorul, frecvența de eșantionare, tratamentul erorii de măsurare din RV, estimarea punctuală și eroarea standard, DOI.
- 2. **Ipoteze concurente**, fiecare cu forma implicată a lui $m(2, \Delta)$
 - ▶ Derivează $m(2, \Delta)$ pentru trei procese care dau H în jur de 0,1 cu estimatorul de scalare: log-volatilitate fracționară cu $H = 0,1$; $H = 0,5$ plus eroare i.i.d.; un model cu doi factori, unul cu revenire rapidă la medie.
- 3. **Date și cod:** replicăm întâi cifra din capitol
 - ▶ Scrie cod Python care construiește varianța zilnică totală din barele SPY de 5 minute ale cursului (RV la 5 minute plus pătratul randamentului peste noapte, de la închiderea precedentă la deschidere), calculează $m(q, \Delta)$ pentru q în $\{0,5; 1; 1,5; 2; 3\}$, $\Delta = 1..30$, și panta H . Ținta: $\hat{H} = 0,11$

Anexă: bucla descoperirii, prompturi reutilizabile (2/2)

- 4. **Robustețe**, pre-înregistrată, cu o verificare a puterii
 - ▶ Scrie un plan pre-înregistrat: ferestre de întârzieri [1,30], [5,30], [10,50]; RV, variația bipower și RV subeșantionată la 30 de minute; ajustarea $m(2, \Delta) = c \Delta^{(2H)} + k$; intervale bootstrap pe blocuri; mărimea și puterea prin simulare la $H = 0,1$ și $0,5$.
- 5. **Critica**: cerem cel mai puternic contraargument
 - ▶ Joacă rolul unui recenzent: ce structuri de eroare non-i.i.d. în log RV (autocorelate, dependente de nivel, provenite din randamentele peste noapte sau din salturi) ar supraviețui corecției cu k constant și cum ai detecta fiecare?
- 6. **Raportul**: toate ferestrele și măsurile, intervalele bootstrap, designul simulării, codul și jurnalul AI

Anexă: ce verifică cercetătorul

- **Eroarea indicatorului:** RV este o estimare cu eroare standard cunoscută; test: simulăm $H = 0,5$ plus eroare de aceeași mărime și verificăm că procedura nu întoarce $H \approx 0,1$
- **Incrementale suprapuse:** $m(q, \Delta)$ refolosește aceleași zile la fiecare Δ , deci erorile standard OLS ale lui ζ_q nu sunt valide; test: bootstrap pe blocuri
- **Zgomotul de microstructură și salturile:** verificăm signature plot-ul, apoi repetăm cu BV și cu RV subeșantionată
- **Căutarea specificației:** ferestrele de întârzieri și grilele pentru q alese după ce vedem $\hat{H}$ umflă semnificația; le fixăm dinainte și le raportăm pe toate
- **Estimări inventate:** asistenții citează „ $H \approx 0,1$ pentru toate activele”; verificăm fiecare cifră în tabelul lucrării citate

Anexă: lecturi suplimentare

□ Manual și sinteze

- ▶ Franke, Härdle & Hafner (2019): statistica piețelor financiare, modele de volatilitate
- ▶ Andersen, Bollerslev, Diebold & Labys (2003): modelarea și prognoza volatilității realizate; Corsi (2009): modelul HAR

□ Cripto-active

- ▶ Informația intraday poate intra în prognozele de risc pentru Bitcoin; entropia randamentelor de înaltă frecvență a fost propusă ca un astfel de semnal [Pele & Mazurencu-Marinescu-Pele \(2019\)](#)
- ▶ Cripto-actele se comportă ca o clasă de active distinctă, cu propria dinamică a volatilității [Pele et al. \(2023\)](#)

Anexă: studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ☐  Nonparametric and Semiparametric Models
- ☐  Kalman Filter
- ☐  Applied Time Series Analysis with Python

Cod și date

- ☐ Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_09

Bibliografie (1/5)

- ▣ Aït-Sahalia, Y., Jacod, J. (2009). Testing for jumps in a discretely observed process. *Annals of Statistics*, 37(1), 184–222.
- ▣ Andersen, T.G., Bollerslev, T. (1997). Intraday periodicity and volatility persistence in financial markets. *Journal of Empirical Finance*, 4(2–3), 115–158.
- ▣ Andersen, T.G., Bollerslev, T. (1998). Answering the skeptics: yes, standard volatility models do provide accurate forecasts. *International Economic Review*, 39(4), 885–905.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X. (2007). Roughing it up: including jump components in the measurement, modeling, and forecasting of return volatility. *Review of Economics and Statistics*, 89(4), 701–720.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Ebens, H. (2001). The distribution of realized stock return volatility. *Journal of Financial Economics*, 61(1), 43–76.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Labys, P. (2001). The distribution of realized exchange rate volatility. *Journal of the American Statistical Association*, 96(453), 42–55.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Labys, P. (2003). Modeling and forecasting realized volatility. *Econometrica*, 71(2), 579–625.
- ▣ Andersen, T.G., Dobrev, D., Schaumburg, E. (2012). Jump-robust volatility estimation using nearest neighbor truncation. *Journal of Econometrics*, 169(1), 75–93.
- ▣ Bajgrowicz, P., Scaillet, O., Treccani, A. (2016). Jumps in high-frequency data: spurious detections, dynamics, and news. *Management Science*, 62(8), 2198–2217.
- ▣ Bandi, F.M., Russell, J.R. (2008). Microstructure noise, realized variance, and optimal sampling. *Review of Economic Studies*, 75(2), 339–369.
- ▣ Barndorff-Nielsen, O.E., Hansen, P.R., Lunde, A., Shephard, N. (2008). Designing realized kernels to measure the ex post variation of equity prices in the presence of noise. *Econometrica*, 76(6), 1481–1536.

Bibliografie (2/5)

- Barndorff-Nielsen, O.E., Shephard, N. (2002). [Econometric analysis of realized volatility and its use in estimating stochastic volatility models](#). *Journal of the Royal Statistical Society, Series B*, 64(2), 253–280.
- Barndorff-Nielsen, O.E., Shephard, N. (2004). [Power and bipower variation with stochastic volatility and jumps](#). *Journal of Financial Econometrics*, 2(1), 1–37.
- Barndorff-Nielsen, O.E., Shephard, N. (2005). [How accurate is the asymptotic approximation to the distribution of realised variance?](#). In D.W.K. Andrews, J.H. Stock (Eds.), *Identification and Inference for Econometric Models*, Cambridge University Press, 306–331.
- Barndorff-Nielsen, O.E., Shephard, N. (2006). [Econometrics of testing for jumps in financial economics using bipower variation](#). *Journal of Financial Econometrics*, 4(1), 1–30.
- Benjamini, Y., Hochberg, Y. (1995). [Controlling the false discovery rate: a practical and powerful approach to multiple testing](#). *Journal of the Royal Statistical Society, Series B*, 57(1), 289–300.
- Benjamini, Y., Yekutieli, D. (2001). [The control of the false discovery rate in multiple testing under dependency](#). *The Annals of Statistics*, 29(4), 1165–1188.
- Bennedsen, M., Lunde, A., Pakkanen, M.S. (2022). [Decoupling the short- and long-term behavior of stochastic volatility](#). *Journal of Financial Econometrics*, 20(5), 961–1006.
- Bolko, A.E., Christensen, K., Pakkanen, M.S., Veliyev, B. (2023). [A GMM approach to estimate the roughness of stochastic volatility](#). *Journal of Econometrics*, 235(2), 745–778.
- Bollerslev, T. (1986). [Generalized autoregressive conditional heteroskedasticity](#). *Journal of Econometrics*, 31(3), 307–327.
- Bollerslev, T., Patton, A.J., Quaedvlieg, R. (2016). [Exploiting the errors: a simple approach for improved volatility forecasting](#). *Journal of Econometrics*, 192(1), 1–18.
- Bollerslev, T., Tauchen, G., Zhou, H. (2009). [Expected stock returns and variance risk premia](#). *Review of Financial Studies*, 22(11), 4463–4492.

Bibliografie (3/5)

- ▣ Boudt, K., Croux, C., Laurent, S. (2011). Robust estimation of intraweek periodicity in volatility and jump detection. *Journal of Empirical Finance*, 18(2), 353–367.
- ▣ Carr, P., Wu, L. (2009). Variance risk premiums. *Review of Financial Studies*, 22(3), 1311–1341.
- ▣ Christensen, K., Oomen, R.C.A., Podolskij, M. (2014). Fact or friction: jumps at ultra high frequency. *Journal of Financial Economics*, 114(3), 576–599.
- ▣ Christensen, K., Siggaard, M., Veliyev, B. (2023). A machine learning approach to volatility forecasting. *Journal of Financial Econometrics*, 21(5), 1680–1727.
- ▣ Cont, R., Das, P. (2024). Rough volatility: fact or artefact?. *Sankhya B*, 86(1), 191–223.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Duan, N. (1983). Smearing estimate: a nonparametric retransformation method. *Journal of the American Statistical Association*, 78(383), 605–610.
- ▣ Epps, T.W. (1979). Comovements in stock prices in the very short run. *Journal of the American Statistical Association*, 74(366), 291–298.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Fukasawa, M., Takabatake, T., Westphal, R. (2022). Consistent estimation for fractional stochastic volatility model under high-frequency asymptotics. *Mathematical Finance*, 32(4), 1086–1132.

Bibliografie (4/5)

- ▣ Gatheral, J., Jaisson, T., Rosenbaum, M. (2018). *Volatility is rough*. *Quantitative Finance*, 18(6), 933–949.
- ▣ Hansen, P.R., Huang, Z., Shek, H.H. (2012). *Realized GARCH: a joint model for returns and realized measures of volatility*. *Journal of Applied Econometrics*, 27(6), 877–906.
- ▣ Hansen, P.R., Lunde, A. (2005). *A forecast comparison of volatility models: does anything beat a GARCH(1,1)?*. *Journal of Applied Econometrics*, 20(7), 873–889.
- ▣ Hansen, P.R., Lunde, A. (2006). *Realized variance and market microstructure noise*. *Journal of Business & Economic Statistics*, 24(2), 127–161.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). *The model confidence set*. *Econometrica*, 79(2), 453–497.
- ▣ Hayashi, T., Yoshida, N. (2005). *On covariance estimation of non-synchronously observed diffusion processes*. *Bernoulli*, 11(2), 359–379.
- ▣ Huang, X., Tauchen, G. (2005). *The relative contribution of jumps to total price variance*. *Journal of Financial Econometrics*, 3(4), 456–499.
- ▣ Jacod, J., Li, Y., Mykland, P.A., Podolskij, M., Vetter, M. (2009). *Microstructure noise in the continuous case: the pre-averaging approach*. *Stochastic Processes and their Applications*, 119(7), 2249–2276.
- ▣ Lee, S.S., Mykland, P.A. (2008). *Jumps in financial markets: a new nonparametric test and jump dynamics*. *Review of Financial Studies*, 21(6), 2535–2563.
- ▣ Liu, L.Y., Patton, A.J., Sheppard, K. (2015). *Does anything beat 5-minute RV? A comparison of realized measures across multiple asset classes*. *Journal of Econometrics*, 187(1), 293–311.
- ▣ Mancini, C. (2009). *Non-parametric threshold estimation for models with stochastic diffusion coefficient and jumps*. *Scandinavian Journal of Statistics*, 36(2), 270–296.

Bibliografie (5/5)

- ▣ Merton, R.C. (1980). [On estimating the expected return on the market: an exploratory investigation](#). *Journal of Financial Economics*, 8(4), 323–361.
- ▣ Mincer, J., Zarnowitz, V. (1969). [The evaluation of economic forecasts](#). In J. Mincer (Ed.), *Economic Forecasts and Expectations*, NBER, 3–46.
- ▣ Müller, U.A., Dacorogna, M.M., Davé, R.D., Olsen, R.B., Pictet, O.V., von Weizsäcker, J.E. (1997). [Volatilities of different time resolutions: analyzing the dynamics of market components](#). *Journal of Empirical Finance*, 4(2–3), 213–239.
- ▣ Mykland, P.A., Zhang, L. (2009). [Inference for continuous semimartingales observed at high frequency](#). *Econometrica*, 77(5), 1403–1445.
- ▣ Patton, A.J. (2011). [Volatility forecast comparison using imperfect volatility proxies](#). *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Sheppard, K. (2015). [Good volatility, bad volatility: signed jumps and the persistence of volatility](#). *Review of Economics and Statistics*, 97(3), 683–697.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). [Using high-frequency entropy to forecast Bitcoin's daily value at risk](#). *Entropy*, 21(2), 102.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). [Are cryptos becoming alternative assets?](#). *European Journal of Finance*, 29(10), 1064–1105.
- ▣ Shephard, N., Sheppard, K. (2010). [Realising the future: forecasting with high-frequency-based volatility \(HEAVY\) models](#). *Journal of Applied Econometrics*, 25(2), 197–231.
- ▣ Zhang, L. (2006). [Efficient estimation of stochastic volatility using noisy observations: a multi-scale approach](#). *Bernoulli*, 12(6), 1019–1043.
- ▣ Zhang, L., Mykland, P.A., Aït-Sahalia, Y. (2005). [A tale of two time scales: determining integrated volatility with noisy high-frequency data](#). *Journal of the American Statistical Association*, 100(472), 1394–1411.