

Modelarea piețelor financiare

Capitolul 11: Modele în timp continuu



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Cum descriem prețurile în timp continuu?

Ce explică modelele

- Prețurile sînt înregistrate zilnic sau la cîteva milisecunde: le poate descrie un singur model la **orice** scară de timp?
- Partea I: mișcarea browniană, calculul Itô, simularea, mișcarea browniană geometrică (GBM), revenirea la medie
- Partea a II-a: estimarea difuziilor, schimbarea măsurii, salturile, volatilitatea stochastică, modelele confruntate cu datele, un studiu de caz, descoperirea asistată de AI (Artificial Intelligence — inteligență artificială)
- Istoria domeniului și detaliile tehnice: Anexa, înaintea bibliografiei

Ce trebuie să puteți face

- aplica lema lui Itô și simula o ecuație diferențială stochastică cu un ordin de eroare cunoscut
- estima modelele GBM, Ornstein–Uhlenbeck, Merton și Heston pe date, cu erori standard care reflectă ce parametri poate identifica eșantionul
- explica ce caracteristică a datelor reproduce fiecare model și ce caracteristică nu reproduce niciunul
- explica de ce evaluarea opțiunilor (Capitolul 12) și modelele de dobîndă folosesc acest limbaj

Parcursul de bază și aprofundarea

- **Parcursul de bază**, pentru prima lectură
  - Secțiunile 2–6: mișcarea browniană, integrala Itô și lema lui Itô, schemele Euler–Maruyama și Milstein, mișcarea browniană geometrică și estimarea ei, procesul Ornstein–Uhlenbeck și modelul Vasicek
  - Secțiunile 7–8: identificarea infill față de cea pe orizont lung; exemplul de evaluare pe o perioadă, Girsanov, prețul de piață al riscului și Feynman–Kac
  - Secțiunile 9–11: modelul Merton și momentele lui, ideea testului Lee–Mykland, modelul Heston și comparația modelelor cu datele
  - Fiecare dintre Secțiunile 5–10 se încheie cu o recapitulare: formulele de reținut, o estimare din date și o verificare scurtă, cu răspuns
- **Aprofundare**: cadrele marcate (aprofundare) în titlu, Secțiunile 12–13 și Anexa
  - Verosimilitățile pentru difuzii neliniare și testele lor, ce identifică indicele de volatilitate în modelul Heston, modelele afine, derivarea asimetriei Heston, studiul de caz despre rough volatility și descoperirea asistată de AI
- Exerciții rezolvate: Seminarul 11; slide-urile indică exercițiul corespunzător, acolo unde există

Indicii și sursele de date

- **VIX**: Cboe Volatility Index — indice al volatilității implicite a indicelui S&P 500.
- **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București.
- **BVB**: Bursa de Valori București.
- **CBOE**: Chicago Board Options Exchange — bursa de opțiuni din Chicago.
- **FRED**: Federal Reserve Economic Data — baza de date economice a Rezervei Federale (St. Louis).
- **SUA**: Statele Unite ale Americii.
- **DTB3**: 3-Month Treasury Bill: secondary market rate (FRED series code) — randamentul titlurilor de stat americane pe 3 luni pe piața secundară (codul seriei FRED).

Datele folosite în acest capitol

Seria	Tip	Perioada	Observații / frecvență
S&P 500	indice bursier SUA	1990–2026	9 245
BET	indice bursier BVB	2000–2026	6 670
Bitcoin	cripto-activ, 7 zile din 7	2014–2026	4 384
VIX	indicele de volatilitate implicită al S&P 500 (CBOE)	1990–2026	zilnic
DTB3	randamentul titlurilor de stat SUA pe 3 luni (FRED)	1954–2026	zilnic

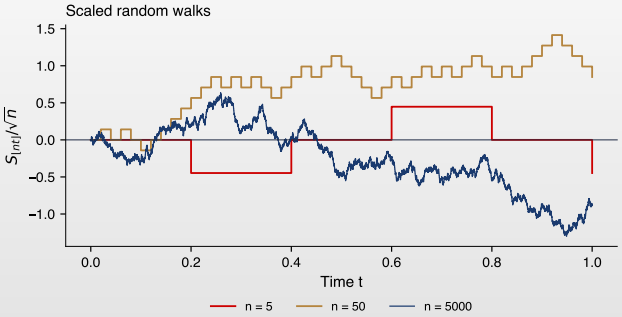
- Valori zilnice de închidere pînă la 18 septembrie 2026, fiecare serie pe propriul calendar (regulile de curățare: ▸ Anexa); randamentele logaritmice zilnice sînt $r_t = \ln P_t - \ln P_{t-1}$
- Timpul este măsurat în ani, cu pasul zilnic $\Delta t = 1/252$ (Bitcoin: $1/365$); drifturile și volatilitățile sînt anualizate
- Date intrazilnice: bare SPY (fond tranzacționat la bursă, ETF, care replică S&P 500) de 5 minute, octombrie 2020 – septembrie 2026, 1 468 de zile complete de tranzacționare (studiul de caz; Capitolul 9); datele cursului nu conțin o serie intrazilnică pentru Bitcoin
- Notații
  - W_t este mișcarea browniană standard, iar S_t este prețul
  - v_t este varianța instantanee, iar $\mathcal{F}_t$ este informația (filtrarea) disponibilă pînă la t

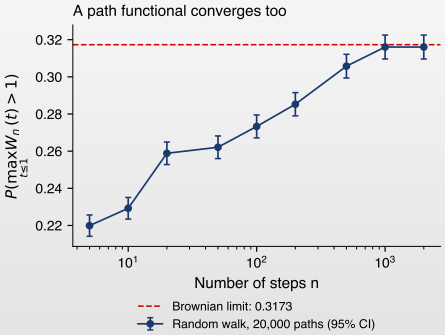
Același preț, două măsuri ale randamentului

- P_t și S_t notează același lucru: prețul activului la momentul t.
- Randamentul simplu este $(P_t - P_{t-1})/P_{t-1}$: de la 100 la 110, creșterea este de 10%.
- Randamentul logaritmic este $\ln(P_t/P_{t-1})$: în același exemplu, $\ln(1{,}1) \approx 0{,}0953$, adică 9,53%.
- Randamentele logaritmice se adună între perioade. Randamentele simple se compun prin înmulțirea factorilor de creștere.
- În timp continuu, $\mathrm{d}S/S$ este randamentul simplu instantaneu, iar $\mathrm{d}\ln S$ este variația logaritmică; lema lui Itô explică diferența dintre drifturile lor.
- Δ și Δt desemnează pasul de eșantionare, exprimat în ani.

De la mersul aleator la mișcarea browniană: teorema lui Donsker (1/2)

CI: Confidence Interval.





MFM_ch11_donsker

De la mersul aleator la mișcarea browniană: teorema lui Donsker (2/2)

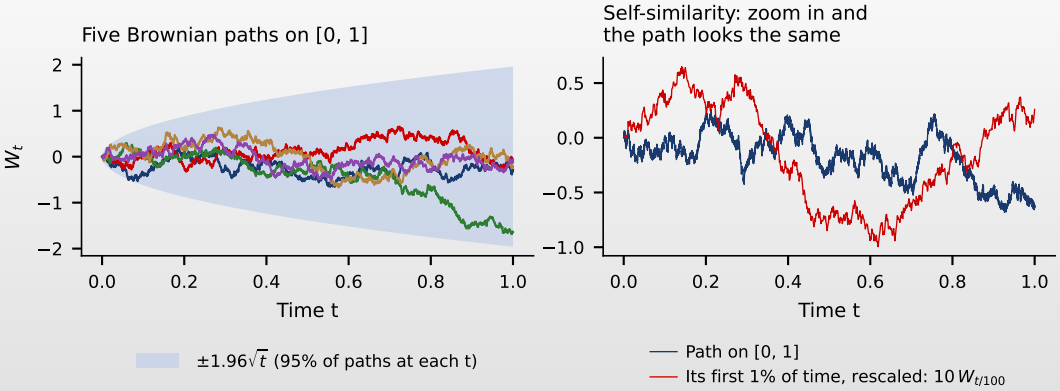
- Mersul aleator scalat $W_n(t) = S_{\lfloor nt \rfloor}/\sqrt{n}$, cu $S_k = \xi_1 + \cdots + \xi_k$
  - pașii ξ_i sînt i.i.d. (independent and identically distributed — independente și identic distribuite), cu media 0 și dispersia 1, iar $\lfloor nt \rfloor$ este partea întreagă a lui nt
  - pasul de timp este $1/n$, iar pasul de spațiu $1/\sqrt{n}$
  - Teorema limită centrală (CLT): $W_n(t) \to N(0,t)$ pentru fiecare t în parte
  - Teorema lui Donsker: $W_n \Rightarrow W$ ($\Rightarrow$: convergență în distribuție) pentru **întreaga traiectorie**, oricare ar fi legea pașilor Billingsley (1999)
- Panoul din dreapta: $P(\max_{t \le 1} W_n(t) > 1)$ crește de la 0,220 ($n = 5$) la 0,316 ($n = 2\,000$), spre valoarea din principiul reflexiei $2(1 - \Phi(1)) = 0{,}3173$ (Φ: funcția de repartiție a distribuției Normale standard)
- O grilă rară nu surprinde maximul atins între observații, iar convergența este lentă, de ordinul $1/\sqrt{n}$: închiderile zilnice subestimează amplitudinea din timpul zilei

MFM_ch11_donsker

Mișcarea browniană: definiție și proprietăți

- **Mișcarea browniană standard**: un proces care pornește din $W_0 = 0$, are incremente independente și traiectorii continue, cu $W_t - W_s \sim N(0, t-s)$ pentru $s < t$
  - Existența: Wiener (1923); simularea pe o grilă: $W_{t+\Delta t} = W_t + \sqrt{\Delta t}\, Z$, $Z \sim N(0,1)$
- Un proces gaussian cu $\mathrm{Cov}(W_s, W_t) = \min(s,t)$
- O **martingală**: $\mathbb{E}[W_t \mid \mathcal{F}_s] = W_s$, cu $\mathcal{F}_s$ informația disponibilă pînă la s (mersul aleator al pieței eficiente din Capitolul 2)
- **Autosimilaritate**: $\{c^{-1/2} W_{ct}\}$ este tot o mișcare browniană standard, pentru orice $c > 0$
- Traiectoriile sînt continue, dar **nicăieri derivabile**
  - $(W_{t+h} - W_t)/h$ are abaterea standard $1/\sqrt{h} \to \infty$: calculul diferențial clasic nu se aplică

Traiectorii browniene (1/2)



MFM_ch11_bm_paths

Traiectorii browniene (2/2)

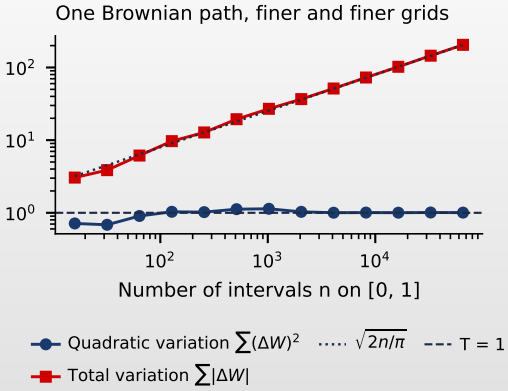
- Stînga: cinci traiectorii cu banda punctuală $\pm 1{,}96\sqrt{t}$, care acoperă 95% pentru fiecare t în parte, nu pentru întreaga traiectorie
- Dreapta: o traiectorie și primul ei 1% din timp, mărit de 100 de ori pe axa timpului și de 10 ori pe axa valorilor
- Banda se lărgește ca $\sqrt{t}$ (regula rădăcinii pătrate a timpului din Capitolul 7)
- Un segment mărit are același aspect ca întreaga traiectorie
  - Piețele reale încalcă autosimilaritatea: cozile groase și volatility clustering depind de orizont (Capitolul 1)

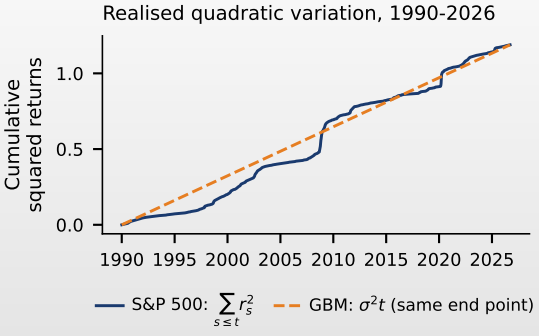
MFM_ch11_bm_paths

Variația totală și variația pătratică

- Grila $0 = t_0 < t_1 < \cdots < t_n = T$ cu pasul $\Delta t = T/n$ și incrementele $\Delta W_k = W_{t_k} - W_{t_{k-1}}$
- **Variația totală** $\sum_k |\Delta W_k|$: lungimea traiectoriei
  - Media ei este $\sqrt{2nT/\pi} \to \infty$: o traiectorie browniană are lungime infinită
- **Variația pătratică** $[W]_T = \lim \sum_k (\Delta W_k)^2 = T$
  - O sumă aleatoare cu o limită **deterministă**
  - $Q_n = \sum_{k=1}^{n} (\Delta W_k)^2$, $\mathrm{Var}(Q_n) = 2T^2/n$: un an de date zilnice dă o eroare relativă de circa 9% ($\sqrt{2/252}$), principiul care stă la baza variației realizate (Capitolul 9)
- Scrierea prescurtată folosită în calculul Itô: $(\mathrm{d}W_t)^2 = \mathrm{d}t$

Variația pătratică: simulare și date (1/2)





MFM_ch11_quadratic_variation

Variația pătratică: simulare și date (2/2)

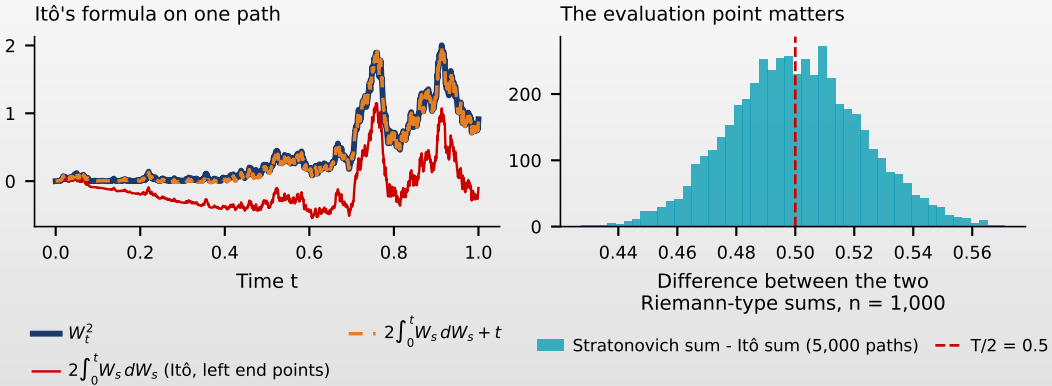
- Stînga: o traiectorie browniană pe grile cu 16 pînă la 65 536 de intervale: variația pătratică se stabilizează la 1,006 ($T = 1$), iar variația totală continuă să crească, 205 față de $\sqrt{2n/\pi} = 204$
- Dreapta: suma cumulată $\sum r_t^2$ pentru S&P 500, 1,188 în 36,7 ani (volatilitate medie 18,0%); sub mișcarea browniană geometrică ar urma dreapta $\sigma^2 t$
- Suma crește în trepte
  - septembrie 2008 – martie 2009: 1,6% din zile, dar 15,2% din variația pătratică
  - februarie – aprilie 2020: 0,5% din zile, dar 7,8% din variația pătratică
  - volatilitatea este ea însăși aleatoare (Heston, Secțiunea 10)

MFM_ch11_quadratic_variation

Integrala Itô

- Scopul: să dăm un sens integralei $\int_0^T H_t \, \mathrm{d}W_t$, cîștigul obținut deținînd H_t unități dintr-un activ al cărui preț evoluează ca W
  - Integrarea Riemann–Stieltjes nu se poate aplica, deoarece traiectoria are variație totală infinită
- **Integrala Itô**: limita în medie pătratică a sumelor cu integrandul evaluat în capătul **stîng**
  - $\int_0^T H_t \, \mathrm{d}W_t = \lim_{n\to\infty} \sum_{k=1}^n H_{t_{k-1}} \left(W_{t_k} - W_{t_{k-1}}\right)$, pentru H **adaptat**, cu $\mathbb{E}\left[\int_0^T H_t^2 \, \mathrm{d}t\right] < \infty$
  - Interpretarea financiară: H_t folosește doar informația pînă la t; poziția se alege înaintea următoarei mișcări a prețului
- Media zero, $\mathbb{E}\left[\int_0^T H_t \, \mathrm{d}W_t\right] = 0$, și **izometria Itô**, $\mathbb{E}\left[\left(\int_0^T H_t \, \mathrm{d}W_t\right)^2\right] = \mathbb{E}\left[\int_0^T H_t^2 \, \mathrm{d}t\right]$
  - $t \mapsto \int_0^t H_s \, \mathrm{d}W_s$ este o martingală: nicio strategie nu cîștigă în medie dintr-o martingală (condiții mai slabe: Anexa)
- Sumele cu integrandul mediat între cele două capete, $\frac{1}{2}(H_{t_{k-1}} + H_{t_k})$, dau integrala **Stratonovich**, o valoare diferită; în finanțe se folosește integrala Itô, deoarece o asemenea poziție ar folosi prețul de la t_k, adică informații viitoare
  - Pentru o funcție netedă $f(W)$, evaluarea în punctul de mijloc $\frac{1}{2}(t_{k-1} + t_k)$ dă aceeași limită, dar necesită o grilă de două ori mai fină

Exemplu rezolvat: $\int_0^T W_t \, \mathrm{d}W_t$ pe traiectorii simulate (1/2)



MFM_ch11_ito

Exemplu rezolvat: $\int_0^T W_t \, \mathrm{d}W_t$ pe traiectorii simulate (2/2)

- Fiecare traiectorie folosește 1 000 de pași de timp.
- Fiecare termen: $W_{t_{k-1}} \Delta W_k = \frac{1}{2}(W_{t_k}^2 - W_{t_{k-1}}^2) - \frac{1}{2}(\Delta W_k)^2$; însumate după k, primele părți dau $\frac{1}{2}(W_T^2 - W_0^2) = \frac{1}{2} W_T^2$, deoarece termenii intermediari se anulează, iar părțile a doua tind la $\frac{1}{2} T$: $\int_0^T W_t \, \mathrm{d}W_t = \frac{1}{2} W_T^2 - \frac{1}{2} T$
  - Calculul obișnuit ar da $\frac{1}{2} W_T^2$: termenul suplimentar $-\frac{1}{2} T$ este variația pătratică, iar media este $\frac{1}{2}(T - T) = 0$
- Stînga: pe o traiectorie, $2 \int_0^t W \, \mathrm{d}W + t$ se suprapune exact peste W_t^2
- Dreapta: diferența dintre sumele Stratonovich și sumele Itô pe 5 000 de traiectorii are media 0,500 și abaterea standard 0,022; teoria dă $T/2 = 0{,}5$
- Sumele Itô au media 0,007 (teoria: 0) și dispersia 0,520 (teoria, prin izometrie: $\int_0^1 t \, \mathrm{d}t = 1/2$)

MFM_ch11_ito

Procese Itô și lema lui Itô

- **Proces Itô**: $\mathrm{d}X_t = a_t\,\mathrm{d}t + b_t\,\mathrm{d}W_t$ (driftul a_t, coeficientul de difuzie b_t, ambii adaptați)
  - Prescurtare pentru $X_t = X_0 + \int_0^t a_s\,\mathrm{d}s + \int_0^t b_s\,\mathrm{d}W_s$
- **Lema lui Itô**: pentru $f(t,x)$ de două ori derivabilă Itô (1944)
  - $\mathrm{d}f(t,X_t) = \left(f_t + a_t f_x + \frac{1}{2}b_t^2 f_{xx}\right)\mathrm{d}t + b_t f_x\,\mathrm{d}W_t$
  - Derivatele parțiale evaluate în (t,X_t): $f_t = \partial f/\partial t$, $f_x = \partial f/\partial x$, $f_{xx} = \partial^2 f/\partial x^2$
- Regulă practică: dezvoltare Taylor de ordinul doi cu $\mathrm{d}t\cdot\mathrm{d}t = 0$, $\mathrm{d}t\cdot\mathrm{d}W = 0$, $\mathrm{d}W\cdot\mathrm{d}W = \mathrm{d}t$
  - Termenul de ordinul doi $\frac{1}{2}b_t^2 f_{xx}\,\mathrm{d}t$ nu dispare: aceasta este singura diferență față de calculul clasic

Covariația pătratică și formula Itô multivariată

- **Covariația pătratică** $[X, Y]_t = \lim \sum_k \Delta X_k \, \Delta Y_k$; dacă $\operatorname{Corr}(\mathrm{d}W^{(1)}, \mathrm{d}W^{(2)}) = \rho$, atunci $\mathrm{d}[W^{(1)}, W^{(2)}]_t = \rho \, \mathrm{d}t$
  - Regula produsului: $\mathrm{d}(X_t Y_t) = X_t \, \mathrm{d}Y_t + Y_t \, \mathrm{d}X_t + \mathrm{d}[X, Y]_t$
- **Formula Itô multivariată** pentru $X_t \in \mathbb{R}^d$ și $f(t, x)$ de două ori derivabilă
  - $\mathrm{d}f(t, X_t) = f_t \, \mathrm{d}t + \sum_i f_{x_i} \, \mathrm{d}X_t^i + \frac{1}{2} \sum_{i,j} f_{x_i x_j} \, \mathrm{d}[X^i, X^j]_t$
  - X_t^i este componenta i, iar f_{x_i} și $f_{x_i x_j}$ sînt derivatele parțiale de ordinul unu și doi în acele componente
- Exemplu rezolvat (Heston, Secțiunea 10): $\mathrm{d}S = \mu S \, \mathrm{d}t + \sqrt{v} \, S \, \mathrm{d}W^{(1)}$, $\mathrm{d}v = \kappa(\theta - v) \, \mathrm{d}t + \xi \sqrt{v} \, \mathrm{d}W^{(2)}$
  - S este prețul, v varianța lui, iar μ driftul
  - κ este viteza de revenire la medie, θ varianța pe termen lung, iar ξ volatilitatea variației
  - $\mathrm{d}(S_t v_t) = S_t \, \mathrm{d}v_t + v_t \, \mathrm{d}S_t + \rho \, \xi \, v_t S_t \, \mathrm{d}t$
  - ρ intră în driftul produsului: cu $\rho < 0$, prețul și varianța tind să se miște în sensuri opuse

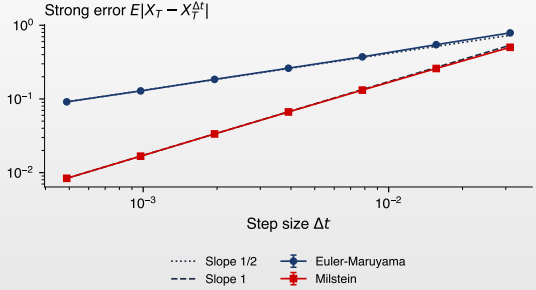
Ecuații diferențiale stochastice și două scheme

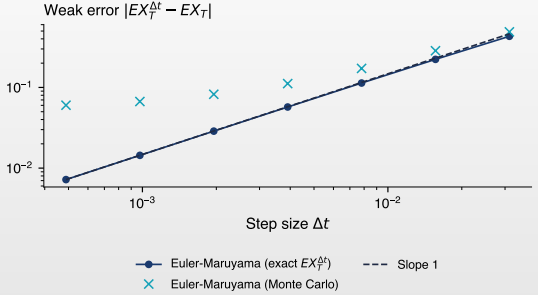
- O **ecuație diferențială stochastică** (SDE, stochastic differential equation): $\mathrm{d}X_t = a(t, X_t)\,\mathrm{d}t + b(t, X_t)\,\mathrm{d}W_t$, X_0 dat: driftul și difuzia depind de starea curentă
  - GBM, Ornstein–Uhlenbeck și Merton au tranziții cunoscute exact: le simulăm fără eroare de discretizare
  - Pentru Heston, doar funcția caracteristică are formă închisă
  - Condițiile de existență a soluției: Anexa
- **Euler–Maruyama**: a și b sînt menținuți constanți pe fiecare pas Higham (2001)
  - $X_{k+1} = X_k + a(X_k)\,\Delta t + b(X_k)\,\Delta W_k$, $\Delta W_k = \sqrt{\Delta t}\,Z_k$
  - X_k este aproximarea la $t_k = k\Delta t$, iar Z_k sînt extrageri i.i.d. din $N(0,1)$
- **Milstein**: adăugăm următorul termen Itô–Taylor Milstein (1975)
  - $X_{k+1} = X_k + a(X_k)\,\Delta t + b(X_k)\,\Delta W_k + \frac{1}{2}\,b(X_k)\,b'(X_k)\left[(\Delta W_k)^2 - \Delta t\right]$
  - $b'(x) = \mathrm{d}b/\mathrm{d}x$ este derivata coeficientului de difuzie
  - Corecția are media condiționată zero: crește ordinul tare (precizia traiectoriei), nu și ordinul slab

Convergența tare și convergența slabă

- **Eroarea tare**: $\mathbb{E}|X_T - X_T^{\Delta t}| \leq C\,\Delta t^{\gamma}$, cît de aproape este fiecare traiectorie simulată de cea adevărată
  - X_T este soluția exactă la T, $X_T^{\Delta t}$ soluția schemei cu pasul Δt, C o constantă, iar γ ordinul tare
  - Ordinul tare este $\gamma = 1/2$ pentru Euler–Maruyama și $\gamma = 1$ pentru Milstein; contează pentru mărimile dependente de traiectorie (erori de hedging, atingerea unor bariere)
- **Eroarea slabă**: $|\mathbb{E}[g(X_T^{\Delta t})] - \mathbb{E}[g(X_T)]| \leq C\,\Delta t^{\beta}$, cît de apropiată este distribuția simulată de cea adevărată
  - g este o funcție de valoarea finală (de exemplu payoff-ul unei opțiuni), iar β este ordinul slab
  - Ambele scheme au ordinul slab $\beta = 1$, suficient pentru prețurile opțiunilor europene și pentru alte valori așteptate
  - Condiții: coeficienți netezi cu derivate mărginite și g netedă Kloeden & Platen (1992)
  - Coeficienții de tip radical (CIR (Cox–Ingersoll–Ross), Heston), cuantilele precum Value-at-Risk (VaR) și atingerea barierelor pot converge mai lent
- Ecuația de test Higham (2001): $\mathrm{d}X = \lambda X\,\mathrm{d}t + \mu X\,\mathrm{d}W$, $\lambda = 2$, $\mu = 1$, $X_0 = 1$, $T = 1$ (aici λ și μ sînt doar cei doi coeficienți ai ei), cu soluția exactă ca reper
  - Pe un grafic log-log, ordinul este panta erorii în funcție de mărimea pasului (slide-ul următor)

Convergența schemelor (1/2)





MFM_ch11_convergence

Convergența schemelor (2/2)

- 20 000 de traiectorii browniene pe o grilă fină de 2^{11} pași, rărită la pași de la 2^{-11} la 2^{-5}
  - Ordinele tari (panta regresiei log-log, CI de 95% prin reeșantionarea traiectoriilor întregi): Euler–Maruyama 0,518 [0,512; 0,525], Milstein 0,986 [0,984; 0,987]
  - CI înguste măsoară doar zgomotul Monte Carlo; mica diferență față de 1/2 și 1 este curbura la pași finiți, nu un alt ordin
  - Înjumătățirea lui Δt înjumătățește eroarea Milstein, dar reduce eroarea Euler doar cu 29%
- Ordinul slab al schemei Euler–Maruyama, calculat din media ei exactă $(1+\lambda\Delta t)^{T/\Delta t}$, este 0,985: o pantă deterministă
  - Curba estimărilor Monte Carlo devine plată la pași mici: eroarea lor standard, circa 0,068, depășește deplasarea
  - Mărimea eșantionului, nu pasul, este adesea constrîngerea decisivă Glasserman (2003)

MFM_ch11_convergence

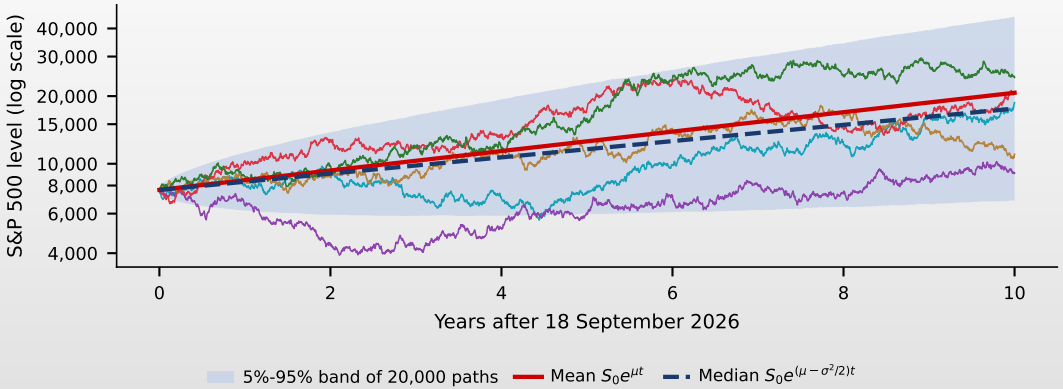
Mișcarea browniană geometrică (GBM) din lema lui Itô

- SDE: $\mathrm{d}S_t = \mu S_t\,\mathrm{d}t + \sigma S_t\,\mathrm{d}W_t$: variația **procentuală** are drift μ și volatilitate σ constante, pe an
  - Propus de Osborne (1959) și Samuelson (1965); modelul de preț din spatele Black & Scholes (1973)
- Lema lui Itô pentru $f(x) = \ln x$, cu $f_x = 1/x$, $f_{xx} = -1/x^2$, $a_t = \mu S_t$, $b_t = \sigma S_t$
  - $\mathrm{d}\ln S_t = \left(\mu - \frac{1}{2}\sigma^2\right)\mathrm{d}t + \sigma\,\mathrm{d}W_t$, deci $S_t = S_0 \exp\left(\left(\mu - \frac{1}{2}\sigma^2\right)t + \sigma W_t\right)$
  - Prețurile rămîn pozitive; simularea exactă are nevoie doar de extrageri din distribuția Normală
- Logaritmul prețului crește cu driftul logaritmic $m = \mu - \sigma^2/2$, nu cu μ: volatilitatea reduce creșterea averii investitorului median
  - Cu $\sigma = 18\%$, costul este $\sigma^2/2 = 1{,}6$ puncte procentuale pe an
  - Cu $\sigma = 67\%$ (Bitcoin), costul ajunge la 22 de puncte procentuale pe an
- Implicații testabile: $r_t = \ln(S_t/S_{t-\Delta t})$ i.i.d. $N(m\Delta t, \sigma^2\Delta t)$ la orice frecvență
  - Asimetria și excesul de kurtosis sînt zero
  - Nu există autocorelație în r_t, $|r_t|$ sau r_t^2
  - Dispersia este proporțională cu orizontul

Driftul și variația aleatoare folosesc scări de timp diferite

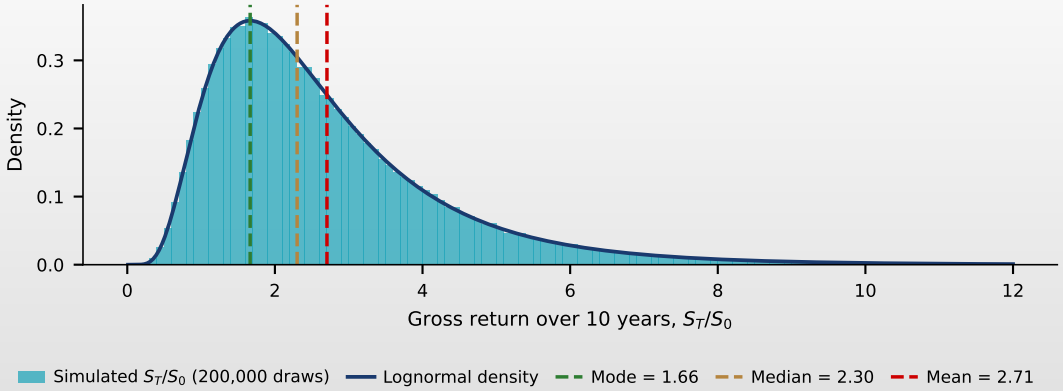
- Cînd timpul este în ani, un pas zilnic este $\Delta t = 1/252$. Incrementul log determinist este $m\Delta t$, iar abaterea standard a părții aleatoare este $\sigma\sqrt{\Delta t}$.
- La o volatilitate anuală ilustrativă de 20%, abaterea standard zilnică este $0{,}20/\sqrt{252} \approx 1{,}26\%$. Înmulțirea cu $1/252$ dă doar 0,079% și elimină cea mai mare parte a incertitudinii simulate.
- Adunarea incrementelor independente explică radicalul: variațele se adună, deci cele 252 de variațe zilnice refac σ^2. Abaterile standard nu se adună.
- Verificăm unitățile simulării înainte de a interpreta o probabilitate estimată. Mai multe traiectorii reduc eroarea Monte Carlo, dar nu repară o difuzie scalată greșit.

Rezultate lognormale: zece ani de traiectorii S&P 500 simulate (1/3)



MFM_ch11_gbm_fan

Rezultate lognormale: zece ani de traiectorii S&P 500 simulate (2/3)



MFM_ch11_gbm_fan

Rezultate lognormale: zece ani de traiectorii S&P 500 simulate (3/3)

- GBM cu $\hat{\mu} = 10{,}0\%$ și $\hat{\sigma} = 18{,}0\%$ (1990–2026), pe $T = 10$ ani: media $\mathbb{E}[S_T] = S_0 e^{\mu T}$, mediana $S_0 e^{mT}$, moda $S_0 e^{(m-\sigma^2)T}$
  - În graficul densității: raportul S_T/S_0 (randamentul brut) este 2,71 pentru medie, 2,30 pentru mediană și 1,66 pentru modă
- Fan chart: 20 000 de traiectorii exacte care pornesc de la $S_0 = 7\,650$ (18 septembrie 2026)
  - după 10 ani, media este 20 696, iar mediana 17 604
  - 90% dintre traiectorii se termină între 6 878 (cuantila de 5%) și 45 017 (cuantila de 95%)
  - probabilitatea unei pierderi pe 10 ani: $P(S_T < S_0) = \Phi(-m\sqrt{T}/\sigma) = 7{,}1\%$
- $P(S_T < \mathbb{E}[S_T]) = \Phi(\sigma\sqrt{T}/2) = 61{,}2\%$: majoritatea investitorilor ajung sub medie, deci raportați mediana și cuantilele
- Fan chart-ul este prea îngust în crize: GBM nu are cozi groase și nici volatility clustering (testat mai jos)
- Densitatea este construită din 200 000 de extrageri ale raportului S_T/S_0; fan chart-ul folosește 20 000 de traiectorii.

MFM_ch11_gbm_fan MFM_ch11_lognormal

Estimarea GBM prin verosimilitate maximă

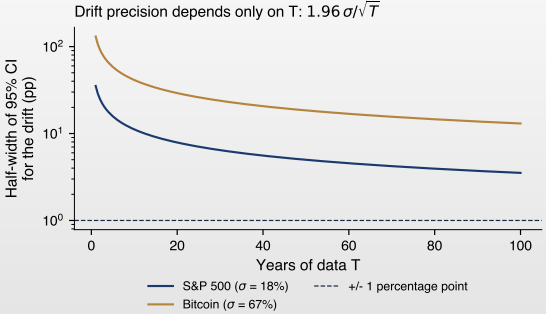
- Estimarea prin verosimilitate maximă (MLE) din n randamente logaritmice la pasul Δt, pe $T = n\Delta t$ ani ($\bar{r}$: randamentul logaritmic mediu): $\hat{\sigma}^2 = \frac{1}{n\Delta t}\sum_t (r_t - \bar{r})^2$, $\hat{m} = \bar{r}/\Delta t$, $\hat{\mu} = \hat{m} + \hat{\sigma}^2/2$
  - Sub GBM, eroarea standard (e.s.) $\mathrm{e.s.}(\hat{\sigma}) = \sigma/\sqrt{2n}$ scade cu numărul de observații
  - În schimb, $\mathrm{e.s.}(\hat{m}) = \sigma/\sqrt{T}$ depinde doar de **durata calendaristică**, deoarece $\sum_t r_t = \ln(S_T/S_0)$ folosește doar primul și ultimul preț

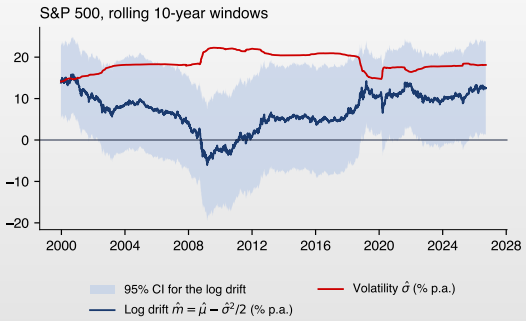
	Ani	$\hat{\sigma}$ (%)	e.s.($\hat{\sigma}$)	$\hat{m}$ (%)	e.s.($\hat{m}$)
S&P 500	36,7	18,0	0,13	8,3	3,0
BET	26,5	22,2	0,19	16,1	4,3
Bitcoin	12,0	66,6	0,71	43,1	19,2

- Volatilitatea este estimată cu o eroare standard de 0,1–0,7 puncte procentuale, driftul logaritmic doar cu una de 3–19 puncte
- Pentru S&P 500: $\hat{\mu} = 8{,}3\% + 1{,}62\% = 10{,}0\%$ pe an
- Aceste e.s. sînt condiționate de GBM: cu excesul de kurtosis k, chiar și randamentele independente cresc $\mathrm{e.s.}(\hat{\sigma})$ de $\sqrt{(k+2)/2} = 2{,}5$ ori (S&P 500). Erorile standard bootstrap pe blocuri: Seminarul 11, B1

Precizia estimării driftului (1/2)

p.p. = puncte procentuale.





MFM_ch11_drift_precision

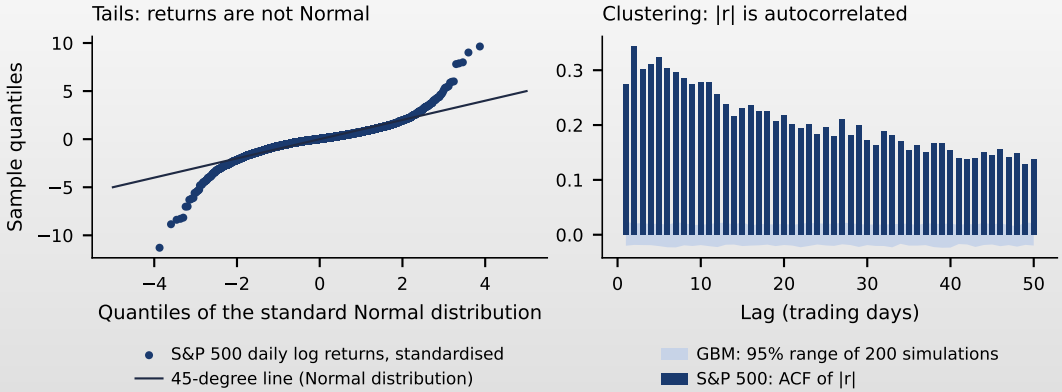
Precizia estimării driftului (2/2)

- Stînga: semilățimea CI de 95% pentru drift, în funcție de numărul de ani de date
- O precizie de ± 1 punct procentual necesită $(1{,}96\,\hat{\sigma}/0{,}01)^2 = 1\,243$ de ani de date pentru S&P 500 și 17 028 de ani pentru Bitcoin
- Dreapta: S&P 500 pe ferestre mobile de 10 ani
  - Driftul logaritmic variază între $-6{,}0\%$ (fereastra încheiată în 2009-03) și 15,8% (2000-09), fiecare cu un CI de circa ± 11 puncte, deci variația este în mare parte zgomot
  - Volatilitatea rămîne între 14,1% și 22,3%: precisă, dar nu constantă
- Evaluarea opțiunilor din Capitolul 12 evită μ: sub măsura neutră la risc intră doar σ (Girsanov, Secțiunea 8)

MFM_ch11_drift_precision

Adecvarea GBM pentru S&P 500 (1/2)

ACF: AutoCorrelation Function.



MFM_ch11_gbm_vs_data

Adecvarea GBM pentru S&P 500 (2/2)

- Stînga: graficul cuantilă–cuantilă (QQ) al randamentelor logaritmice zilnice standardizate față de distribuția Normală
  - Excesul de kurtosis este 10,9, în loc de 0, iar cea mai rea zi se află la $-11{,}3$ abateri standard
  - 62 de zile dincolo de ± 4 abateri standard, față de 0,59 așteptate sub distribuția Normală
  - Statistica Jarque–Bera (JB) de normalitate este 45 805
- Dreapta: funcția de autocorelație (ACF) a lui $|r_t|$: 0,27 la lagul 1 și încă 0,14 la lagul 50
  - 200 de eșantioane GBM de aceeași lungime nu depășesc niciodată 0,024 în valoare absolută
- GBM nu reproduce niciunul dintre cele două fapte stilizate din Capitolul 1 Cont (2001); restul capitolului adaugă revenirea la medie, salturile și volatilitatea aleatoare

MFM_ch11_gbm_vs_data

Recapitulare: creștere, lognormalitate și precizia driftului

- Formulele de reținut
  - $\ln(S_T/S_0) \sim N(mT, \sigma^2 T)$, cu $m = \mu - \frac{1}{2}\sigma^2$: mediana crește cu rata m, media $\mathbb{E}[S_T]$ cu rata μ
  - $\text{e.s.}(\hat{\sigma}) = \sigma/\sqrt{2n}$ scade cu numărul de randamente; $\text{e.s.}(\hat{m}) = \sigma/\sqrt{T}$ doar cu numărul de ani acoperiți
- Din date: pentru S&P 500, $\hat{\sigma} = 18{,}0\%$ (e.s. 0,13), dar $\hat{m} = 8{,}3\%$ (e.s. 3,0), în puncte procentuale pe an
- Verificare: cu $\sigma = 20\%$, cît este e.s. a driftului logaritmic după 10 ani de date și după 40 de ani?
  - Răspuns: $0{,}20/\sqrt{10} = 6{,}3$ și $0{,}20/\sqrt{40} = 3{,}2$ puncte procentuale; un orizont de patru ori mai lung doar înjumătățește eroarea, oricare ar fi frecvența de eșantionare

Procesul Ornstein–Uhlenbeck (OU)

- SDE: $\mathrm{d}x_t = \kappa(\theta - x_t)\,\mathrm{d}t + \sigma\,\mathrm{d}W_t$, $\kappa > 0$ Uhlenbeck & Ornstein (1930): media pe termen lung θ, viteza de revenire la medie κ, volatilitatea σ
  - Deasupra lui θ driftul este negativ, sub θ pozitiv: o forță de revenire care readuce x spre θ
  - Folosit pentru dobînzi Vasicek (1977), volatilitate, spread-uri și prețuri ale mărfurilor
- Lema lui Itô pentru $e^{\kappa t}x_t$: $x_t = \theta + (x_0 - \theta)e^{-\kappa t} + \sigma \int_0^t e^{-\kappa(t-s)}\,\mathrm{d}W_s$, o variabilă Normală cu
  - $\mathbb{E}[x_t \mid x_0] = \theta + (x_0 - \theta)e^{-\kappa t}$, $\mathrm{Var}(x_t \mid x_0) = \frac{\sigma^2}{2\kappa}\left(1 - e^{-2\kappa t}\right)$
  - Distribuția staționară ($t \to \infty$): $N\left(\theta, \sigma^2/(2\kappa)\right)$
- **Timpul de înjumătățire** $\ln 2/\kappa$: timpul în care o abatere așteptată de la θ se reduce la jumătate
  - Cu $\kappa = 0{,}5$ pe an, timpul de înjumătățire este de 1,39 ani
  - Spre deosebire de mișcarea browniană, dispersia nu mai crește odată cu orizontul

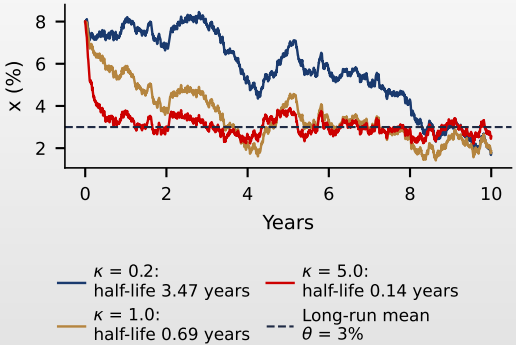
Rezolvarea ecuației OU pas cu pas

- Pasul 1: aplicăm lema lui Itô funcției $f(t,x) = e^{\kappa t}x$, cu $f_t = \kappa e^{\kappa t}x$, $f_x = e^{\kappa t}$, $f_{xx} = 0$, deci nu apare termen de ordinul doi
  - $\mathrm{d}(e^{\kappa t}x_t) = \kappa e^{\kappa t}x_t\,\mathrm{d}t + e^{\kappa t}\left[\kappa(\theta - x_t)\,\mathrm{d}t + \sigma\,\mathrm{d}W_t\right] = \kappa\theta e^{\kappa t}\,\mathrm{d}t + \sigma e^{\kappa t}\,\mathrm{d}W_t$
  - Termenii în x_t se anulează: membrul drept nu mai depinde de traiectoria necunoscută
- Pasul 2: integrăm de la 0 la t, apoi înmulțim cu $e^{-\kappa t}$
  - $e^{\kappa t}x_t - x_0 = \theta\left(e^{\kappa t} - 1\right) + \sigma\int_0^t e^{\kappa s}\,\mathrm{d}W_s$ dă soluția de pe slide-ul anterior
- Pasul 3: integrala Itô are media 0 și, prin izometrie, dispersia $\sigma^2\int_0^t e^{-2\kappa(t-s)}\,\mathrm{d}s = \frac{\sigma^2}{2\kappa}\left(1 - e^{-2\kappa t}\right)$
- Verificare: $x_0 = 8\%$, $\theta = 3\%$, $\kappa = 0{,}5$, $\sigma = 1\%$: cît sînt media și abaterea standard ale lui x_1?
  - Răspuns: $3\% + 5\% \cdot e^{-0{,}5} = 6{,}03\%$ și $1\% \cdot \sqrt{1 - e^{-1}} = 0{,}80\%$: după un an rămîne 61% din abaterea inițială

Discretizarea exactă: un AR(1)

- Eșantionat la pasul Δt, procesul OU este exact un model autoregresiv de ordinul 1 (AR(1)):
  - $x_{t+\Delta t} = a + b\,x_t + \varepsilon_t$, $b = e^{-\kappa \Delta t}$, $a = \theta(1-b)$, $\mathrm{Var}(\varepsilon_t) = \frac{\sigma^2}{2\kappa}(1-b^2)$
- Verosimilitatea maximă = metoda celor mai mici pătrate (OLS) a lui $x_{t+\Delta t}$ pe x_t, apoi inversăm relațiile
  - $\hat\kappa = -\ln \hat b / \Delta t$, $\hat\theta = \hat a/(1-\hat b)$, $\hat\sigma = \hat s_\varepsilon \sqrt{2\hat\kappa/(1-\hat b^2)}$
  - $\hat a$ și $\hat b$ sînt termenul liber și panta OLS, iar $\hat s_\varepsilon$ este abaterea standard a reziduurilor OLS
- Erori standard pentru $\hat\kappa$ și $\hat\theta$ prin metoda delta, din covarianța OLS a lui $(\hat a, \hat b)$
  - $\hat\kappa$ depinde doar de $\hat b$: $\partial\kappa/\partial b = -1/(b\Delta t)$, deci este suficientă $\mathrm{Var}(\hat b)$ (cazul rezolvat: Seminarul 11, A1)
  - $\hat\theta$ are gradientul $\big(1/(1-b),\ a/(1-b)^2\big)$ în (a,b), deci necesită și $\mathrm{Var}(\hat a)$ și $\mathrm{Cov}(\hat a, \hat b)$
- Cu date zilnice b este foarte aproape de 1: κ este estimat imprecis, ca în cazul testelor de rădăcină unitară

Trei viteze de revenire la medie



- Traiectorii OU cu aceleași șocuri, pornind de la 8%
  - $\theta = 3\%$, $\sigma = 1\%$, iar viteza de revenire este $\kappa = 0{,}2$ (lentă), $\kappa = 1$ sau $\kappa = 5$ (rapidă)
  - Simulare exactă, cu pași zilnici
- Timpii de înjumătățire: 3,47 ani pentru $\kappa = 0{,}2$, iar 0,69 ani pentru $\kappa = 1$ și 0,14 ani pentru $\kappa = 5$
  - Cu $\kappa = 5$, diferența de la 8% la 3% dispare aproape complet în cîteva luni
- Abaterile standard staționare $\sigma/\sqrt{2\kappa}$ sînt 1,58% pentru $\kappa = 0{,}2$, iar 0,71% pentru $\kappa = 1$ și 0,32% pentru $\kappa = 5$
  - O revenire lentă nu se poate distinge de un mers aleator timp de mai mulți ani
- Prognozele pe termen lung converg la θ

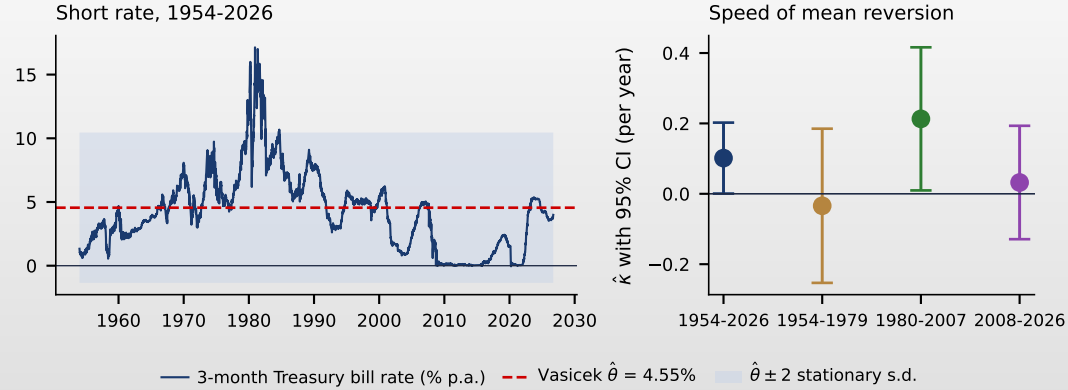
MFM_ch11_ou_paths

Modele ale ratei pe termen scurt: Vasicek și CIR

- **Vasicek**: rata pe termen scurt r_t este un proces OU Vasicek (1977)
  - Rata are distribuția Normală, deci ratele negative au probabilitate pozitivă $\Phi(-\theta\sqrt{2\kappa}/\sigma)$ pe termen lung
  - Prețurile și randamentele obligațiunilor în formă închisă (Feynman–Kac, Secțiunea 8)
- **Cox–Ingersoll–Ross** (CIR): $\mathrm{d}r_t = \kappa(\theta - r_t)\,\mathrm{d}t + \sigma\sqrt{r_t}\,\mathrm{d}W_t$ Cox, Ingersoll & Ross (1985)
  - Volatilitatea scade lîngă zero
  - Rata rămîne pozitivă dacă $2\kappa\theta \geq \sigma^2$ (condiția Feller) Feller (1951)
- Adecvarea fiecărui model la date este o întrebare empirică, testată în Secțiunea 7 Chan, Karolyi, Longstaff & Sanders (1992)

Vasicek pe randamentul titlurilor de stat pe 3 luni (1/2)

s.d. = standard deviation (abatere standard).



MFM_ch11_vasicek

Vasicek pe randamentul titlurilor de stat pe 3 luni (2/2)

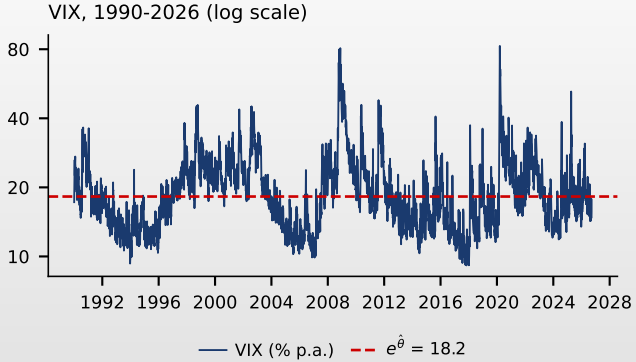
- Stînga: randamentul zilnic al titlurilor de stat SUA pe 3 luni (DTB3), 1954–2026, cu media pe termen lung Vasicek $\hat{\theta} = 4{,}55\%$
  - Viteza de revenire $\hat{\kappa} = 0{,}101$ (e.s. 0,051), adică un timp de înjumătățire de 6,8 ani; volatilitatea $\hat{\sigma} = 1{,}33\%$
  - Coeficientul AR(1) zilnic $\hat{b} = 0{,}99960$ este aproape de 1: aproape o rădăcină unitară
- Dreapta: $\hat{\kappa}$, cu CI de 95%, estimat separat pe trei perioade
  - 1954–1979: $\hat{\kappa} = -0{,}034$, negativ, deci un proces exploziv
  - 1980–2007: $\hat{\kappa} = 0{,}213$, iar 2008–2026: $\hat{\kappa} = 0{,}032$
  - Două dintre cele trei CI includ zero
- Slide-ul următor: de ce viteza estimată este deplasată în sus
- Banda din grafic: media plus/minus două abateri standard staționare (s.d., standard deviation). În simularea sub ipoteza de mers aleator, probabilitatea de a obține o estimare cel puțin la fel de mare este 0,287. Eșantionul nu demonstrează revenirea la medie (Seminarul 11, B2).

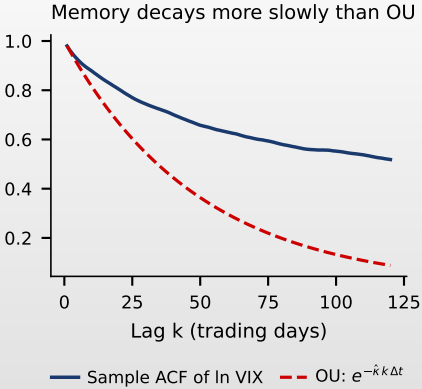
MFM_ch11_vasicek

De ce revenirea la medie estimată pare prea rapidă

- În eșantioane finite $\hat{\kappa}$ supraestimează κ cu aproximativ $4/T$ (T în ani) Tang & Chen (2009)
  - Simulare: luăm estimările pe întreaga perioadă drept valori adevărate și generăm 500 de eșantioane de 72 de ani
  - Media lui $\hat{\kappa}$ este 0,164, deci deplasarea este 0,063, apropiată de aproximarea $4/T = 0{,}055$
  - 78% dintre estimări depășesc valoarea adevărată
  - Timpii de înjumătățire estimați sînt prea scurți, iar revenirea la medie pare mai rapidă decît este (Seminarul 11, B2)
- Sursa deplasării: $\hat{b}$, panta OLS a lui $x_{t+\Delta t}$ în funcție de x_t, este deplasată spre zero într-un eșantion scurt și persistent, iar $\hat{\kappa} = -\ln \hat{b}/\Delta t$ transformă un $\hat{b}$ prea mic într-un $\hat{\kappa}$ prea mare
  - Deplasarea depinde de orizontul T, nu de numărul de observații: eșantionarea zilnică în locul celei lunare nu o elimină (Secțiunea 7)

Revenirea la medie a volatilității: VIX (1/2)





MFM_ch11_vix_ou

Revenirea la medie a volatilității: VIX (2/2)

- Stînga: VIX 1990–2026 pe scară logaritmică, cu nivelul pe termen lung OU $e^{\hat{\theta}} = 18{,}2$
  - Modelul OU estimat pentru $\ln \mathrm{VIX}$ are $\hat{\kappa} = 5{,}10$ (e.s. 0,53), adică un timp de înjumătățire de 34 zile de tranzacționare
  - Vîrfuri precum 82,7 (2020-03-16) se estompează în cîteva săptămîni
- Dreapta: ACF empirică a lui $\ln \mathrm{VIX}$, comparată cu ACF implicată de OU, $e^{-\hat{\kappa} k \Delta t}$
  - La lagul 60, autocorelația este 0,63 în date, dar doar 0,30 sub OU
  - Datele arată o scădere rapidă, urmată de o componentă lentă
- Un singur factor OU este prea simplu: alternativele sînt modelele cu doi factori sau cu memorie lungă, iar rough volatility (Secțiunea 12) este o opțiune distinctă
- Volatilitatea care revine la medie este elementul de bază al modelului Heston

MFM_ch11_vix_ou

Recapitulare: revenirea la medie în trei formule

- Formulele de reținut
  - Traiectoria așteptată: $\mathbb{E}[x_t \mid x_0] = \theta + (x_0 - \theta)e^{-\kappa t}$; timpul de înjumătățire $\ln 2/\kappa$
  - Dispersia pe termen lung: abaterea standard staționară $\sigma/\sqrt{2\kappa}$
  - Estimarea: panta AR(1) $b = e^{-\kappa \Delta t}$, deci $\hat{\kappa} = -\ln \hat{b}/\Delta t$, deplasat în sus în eșantioane scurte
- Din date: pentru DTB3, $\hat{\kappa} = 0{,}101$ (e.s. 0,051), adică un timp de înjumătățire de 6,8 ani; pentru logaritmul VIX, timpul de înjumătățire este de doar 34 zile de tranzacționare
- Verificare: datele lunare dau $\hat{b} = 0{,}95$. Cît sînt $\hat{\kappa}$ și timpul de înjumătățire?
  - Răspuns: $\hat{\kappa} = -12 \ln 0{,}95 = 0{,}616$ pe an și $\ln 2/0{,}616 = 1{,}13$ ani, circa 13,5 luni

Asimptotica infill și asimptotica pe orizont lung

Infill (umplerea intervalului): $\Delta \to 0$ pe un $[0, T]$ fix

- $\sum_k (\Delta X_k)^2 \to \int_0^T b_t^2 \, \mathrm{d}t$
- Coeficientul de difuzie: identificat fără eroare la limită
  - Variația pătratică este observabilă (proces Itô continuu, fără zgomot de măsurare)
- Eșantionarea mai deasă ajută pentru σ (Secțiunea 5) și $b(x)$ (neparametric, mai jos)

Orizont lung: $T \to \infty$

- Driftul nu se poate estima consistent pe un orizont fix: informația Fisher crește cu T, nu cu n
  - Informația Fisher $I(m) = -\mathbb{E}[\partial^2 \ell / \partial m^2]$ (ℓ: log-verosimilitatea) limitează $\mathrm{Var}(\hat{m}) \geq 1/I(m)$; pentru n randamente GBM, $I(m) = n\Delta t/\sigma^2 = T/\sigma^2$
- GBM: $\mathrm{e.s.}(\hat{m}) = \sigma/\sqrt{T}$
- OU: $\mathrm{Var}(\hat{\kappa}) \approx (e^{2\kappa\Delta} - 1)/(T\Delta) \to 2\kappa/T$ cînd $\Delta \to 0$ (Seminarul 11, A1)
- Deplasarea lui $\hat{\kappa}$ nu scade cu eșantionarea mai deasă Yu (2012)
  - $b = e^{-\kappa\Delta} \to 1$: $\hat{\kappa}$ este departe de distribuția Normală cînd κT este mic

- Un singur fenomen, nu două probleme distincte: driftul GBM imprecis și $\hat{\kappa}$ deplasat sînt ambele probleme de orizont lung

Verosimilitatea pentru difuzii neliniare (aprofundare)

- **Pseudo-verosimilitatea Euler**: o tranziție gaussiană $r_{t+\Delta} \mid r_t \sim N\left(r_t + a(r_t)\Delta,\ b^2(r_t)\Delta\right)$, cu $a(r)$, $b(r)$ funcțiile de drift și de difuzie ale ratei r și Δ pasul de eșantionare
  - Deplasare de ordinul Δ: mică cu date zilnice, mai mare cu pași lunari sau trimestriali
- **CIR exact**: $2c\, r_{t+\Delta} \mid r_t$ are distribuția χ^2 necentrală cu $4\kappa\theta/\sigma^2$ grade de libertate Cox, Ingersoll & Ross (1985)
  - $c = 2\kappa/\left(\sigma^2(1 - e^{-\kappa\Delta})\right)$, iar parametrul de necentralitate este $2c\, r_t e^{-\kappa\Delta}$
  - Condiția Feller este echivalentă cu cel puțin 2 grade de libertate (Seminarul 11, A7)
- Difuzii generale: dezvoltări Hermite în formă închisă ale densității de tranziție Aït-Sahalia (2002)
- CKLS (Chan–Karolyi–Longstaff–Sanders): $\mathrm{d}r = \kappa(\theta - r)\,\mathrm{d}t + \sigma r^{\gamma}\,\mathrm{d}W$ include Vasicek ($\gamma = 0$) și CIR ($\gamma = 1/2$) Chan, Karolyi, Longstaff & Sanders (1992)
  - Estimare prin cvasi-verosimilitate gaussiană (Euler)
  - Testele pentru γ folosesc erori standard sandwich: covariança scorurilor este estimată cu erori standard robuste la heteroscedasticitate și autocorelație (HAC) Newey & West (1987)

Vasicek, CIR și CKLS pe randamentul titlurilor de stat, 1954–2007 (aprofundare)

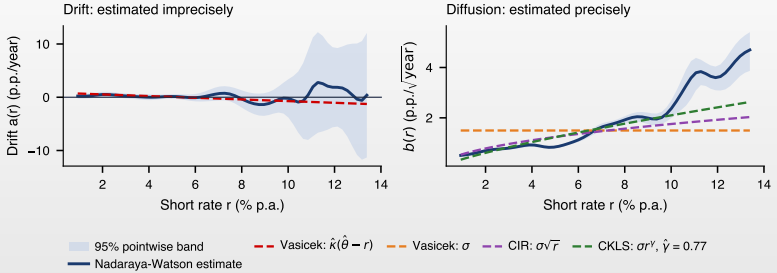
Modelul	$\hat{\kappa}$ zilnic (e.s.)	$\hat{\kappa}$ lunar (e.s.)	γ
Vasicek, exact	0,158 (0,073)	0,201 (0,083)	0
Vasicek, Euler	0,158 (0,073)	0,199 (0,082)	0
CIR, exact	0,113 (0,060)	0,153 (0,070)	1/2
CIR, Euler	0,093 (0,060)	0,144 (0,069)	1/2
CKLS, Euler	0,080 (0,057)	0,144 (0,068)	0,77 (0,033) zilnic, 0,60 (0,149) lunar

- Date: DTB3 zilnic ($n = 13\,487$) și valorile de sfîrșit de lună ($n = 647$)
- Perioada 2008–2026 este exclusă: cotațiile exact zero și cele negative sînt în afara domeniului acestor verosimilități (Anexa)
- Estimările exacte și cele Euler diferă cu mai puțin de o eroare standard: eroarea de discretizare este mică față de incertitudinea de orizont lung a lui $\hat{\kappa}$
- Volatilitatea crește cu nivelul: testele Wald HAC resping $\gamma = 0$ la ambele frecvențe și $\gamma = 1/2$ cu date zilnice, dar nu și cu date lunare (statisticile: Anexa)

Drift și difuzie neparametrice (aprofundare)

- Fără o formă funcțională impusă: medii ponderate cu un nucleu ale incrementelor în jurul fiecărui nivel x
  - $\Delta r_t = r_{t+\Delta} - r_t$ este incrementul următor, iar $w_t(x)$ este ponderea zilei t, mare cînd r_t este aproape de x
  - $\hat{a}(x) = \sum_t w_t(x)\,\Delta r_t/\Delta$, $\hat{b}^2(x) = \sum_t w_t(x)\,(\Delta r_t)^2/\Delta$, $w_t(x) = K\left((r_t - x)/h\right) / \sum_s K\left((r_s - x)/h\right)$
  - Ponderi Nadaraya–Watson cu suma 1, nucleu gaussian K, lățime de bandă h Stanton (1997)
- $\mathbb{E}[\Delta r \mid r = x]/\Delta = a(x) + O(\Delta)$ și $\mathbb{E}[(\Delta r)^2 \mid r = x]/\Delta = b^2(x) + O(\Delta)$: exacte doar cînd $\Delta \to 0$
  - Difuzia converge cu rata infill, driftul doar cu rata orizontului lung ($O(\Delta)$: o eroare de ordinul Δ)
  - Rezultatele rămîn valabile pentru procese nestaționare, dar recurente Bandi & Phillips (2003)
- Atenție: testele neparametrice de specificare resping mult prea des cu date persistente Pritsker (1998)

Driftul și difuzia neparametrice ale randamentului titlurilor de stat



- Date: DTB3 zilnic, 1954–2007, cu lățimea de bandă $h = 0{,}44$ puncte procentuale
- Benzile punctuale de 95% sînt robuste la heteroscedasticitate, dar ignoră dependența serială
- Driftul: valoarea zero se află în interiorul benzii la 97% din niveluri
- Difuzia: eroarea standard relativă mediană este 8%, iar $b(r)$ crește de la 0,5% la 4,7% (panta în logaritmi 0,90)
- Nicio formă parametrică nu este compatibilă cu datele la toate nivelurile
  - Curba CKLS se află în interiorul benzii la 35% din niveluri, CIR la 7%, iar Vasicek la 5% (ponderi descriptive)

MFM_ch11_np_diffusion

Recapitulare: ce aduce frecvența și ce nu poate aduce

- Formulele de reținut
  - Infill: $\sum_k (\Delta X_k)^2 \to \int_0^T b_t^2 \, \mathrm{d}t$, deci coeficientul de difuzie se învață din eșantionarea frecventă
  - Orizont lung: $I(m) = T/\sigma^2$ și $\mathrm{Var}(\hat{\kappa}) \approx 2\kappa/T$, deci driftul și viteza se învață doar din mai mulți ani
  - Deplasarea: $\hat{\kappa}$ depășește κ cu aproximativ $4/T$
- Din date: în eșantioane simulate de 72 de ani, media lui $\hat{\kappa}$ este 0,164, adică o deplasare de 0,063
- Verificare: aceiași 20 de ani sînt eșantionați zilnic în loc de lunar (de 21 de ori mai multe observații). Care eroare standard scade, cea a lui $\hat{\sigma}$ sau cea a lui $\hat{\kappa}$?
  - Răspuns: cea a lui $\hat{\sigma}$, de circa $\sqrt{21} \approx 4{,}6$ ori; cea a lui $\hat{\kappa}$ aproape nu se schimbă, deoarece $2\kappa/T$ nu depinde de pas

De ce prețurile folosesc altă probabilitate: un exemplu pe o perioadă

- O acțiune costă 100 astăzi, iar mîine valorează 120 (creștere) sau 90 (scădere); rata dobînzii este 0; probabilitatea reală a creșterii este $p = 0{,}6$
- Un activ derivat plătește 1 la creștere și 0 la scădere. Îl replicăm cu Δ acțiuni și suma B în numerar
  - $120\Delta + B = 1$ și $90\Delta + B = 0$ dau $\Delta = 1/30$, $B = -3$: replicarea costă $100/30 - 3 = 1/3$
  - Orice alt preț permite un arbitraj: vindem varianta mai scumpă dintre activ și replicare, o cumpărăm pe cea mai ieftină și păstrăm diferența în ambele stări
- Același preț este o valoare așteptată sub $q = (100 - 90)/(120 - 90) = 1/3$, singura pondere cu $120q + 90(1 - q) = 100$
  - Sub q, acțiunea este o martingală; p nu a intervenit: plata așteptată sub P este 0,6, iar prețul este 1/3
- În general, absența arbitrajului înseamnă că prețurile actualizate ale activelor tranzacționate sînt martingale sub o măsură echivalentă Q (teorema fundamentală a evaluării activelor, Shreve (2004), cap. 5); Girsanov construiește această măsură Q în timp continuu
- Verificare: cît costă activul derivat dacă $p = 0{,}9$? Dar dacă starea de scădere este 80 în loc de 90?
  - Răspuns: tot 1/3; cu 80, $q = 20/40 = 1/2$, deci prețul este 1/2

Teorema lui Girsanov

- Măsura reală P și o măsură echivalentă Q (aceleași evenimente de probabilitate zero), legate printr-o **densitate Radon–Nikodym**
  - $\left.\frac{\mathrm{d}Q}{\mathrm{d}P}\right|_{\mathcal{F}_T} = Z_T = \exp\left(-\int_0^T \theta_s \,\mathrm{d}W_s - \frac{1}{2}\int_0^T \theta_s^2 \,\mathrm{d}s\right)$
  - $Z_T > 0$, cu $\mathbb{E}^P[Z_T] = 1$, reponderează probabilitatea fiecărei traiectorii: $Q(A) = \mathbb{E}^P[Z_T 1_A]$
  - θ_s este un proces adaptat (mai jos: prețul de piață al riscului)
- Girsanov (1960): sub Q, $\tilde{W}_t = W_t + \int_0^t \theta_s \,\mathrm{d}s$ este o mișcare browniană dacă $\mathbb{E}\left[e^{\frac{1}{2}\int_0^T \theta_s^2 \mathrm{d}s}\right] < \infty$ (condiția Novikov)
- Pentru $\mathrm{d}X = a\,\mathrm{d}t + b\,\mathrm{d}W$: $\mathrm{d}X = (a - b\theta)\,\mathrm{d}t + b\,\mathrm{d}\tilde{W}$
  - Pentru procesele Itô continue, **se schimbă doar driftul**: coeficientul de difuzie și variația pătratică sînt aceleași sub P și Q
  - Cu salturi (Secțiunea 9), Q poate schimba și intensitatea salturilor și distribuția mărimii lor, o primă de risc a salturilor: $\hat{\lambda}$ estimat din randamente nu este intensitatea care evaluează opțiunile
  - Sub GBM (σ constant), varianța realizată (Capitolul 9) măsoară σ care evaluează opțiunile, iar μ dispare
  - Cu volatilitate stochastică, P și Q ponderează diferit traiectoriile viitoare ale variației: varianța istorică este un reper, nu o calibrare

Prețul de piață al riscului: P față de Q

- GBM: $\theta = (\mu - r)/\sigma$ este **prețul de piață al riscului**; sub Q, $\mathrm{d}S = rS\,\mathrm{d}t + \sigma S\,\mathrm{d}\tilde{W}$, iar $e^{-rt}S_t$ este o Q-martingală (Seminarul 11, A4)
  - S&P 500, 1990–2026: $\hat{\theta} = (10{,}0\% - 2{,}7\%)/18{,}0\% = 0{,}40$, cu e.s. $1/\sqrt{T} = 0{,}17$, unde r este media randamentului titlurilor de stat pe 3 luni
  - Estimarea este la fel de imprecisă ca driftul
- Vasicek cu prima de risc $\lambda\sigma$: $\kappa^Q = \kappa$, $\kappa\theta^Q = \kappa\theta - \lambda\sigma$; aici θ și θ^Q sînt niveluri pe termen lung, nu prețul de piață al riscului de mai sus
  - Nivelul pe termen lung care evaluează obligațiunile diferă de cel estimat pe date (Secțiunea 6)
  - În această convenție, o primă de termen pozitivă înseamnă $\lambda < 0$: atunci $\theta^Q = \theta - \lambda\sigma/\kappa > \theta$, iar randamentele pe termen lung sînt mai mari
- Heston cu prima de risc a volatilității λv_t (alt λ): $\kappa^Q = \kappa + \lambda$, $\kappa^Q\theta^Q = \kappa\theta$
  - $\lambda < 0$ (investitorii plătesc pentru protecția față de varianță) dă $\theta^Q > \theta$: prima de risc a variației din Capitolul 9

Feynman–Kac: de la valori așteptate la PDE de evaluare

- Dacă $\mathrm{d}X = a(X)\,\mathrm{d}t + b(X)\,\mathrm{d}\tilde{W}$ sub Q Kac (1949)
  - $u(t,x) = \mathbb{E}^Q\left[e^{-\int_t^T r_s\,\mathrm{d}s}\, g(X_T) \mid X_t = x\right]$ satisface $u_t + a\,u_x + \frac{1}{2}b^2 u_{xx} - r\,u = 0$, $u(T,x) = g(x)$
  - u este prețul la t al unui activ care plătește $g(X_T)$ la T, iar r_s este rata pe termen scurt folosită la actualizare
  - u_t, u_x, u_{xx} sînt derivatele parțiale; PDE (partial differential equation): ecuație cu derivate parțiale
- Ideea demonstrației: $e^{-\int_0^t r_s\mathrm{d}s}\,u(t,X_t)$ este o Q-martingală, deci, conform lemei lui Itô, driftul său trebuie să fie zero
- Obligațiunea Vasicek ($g = 1$, $X = r$): $p(t,r;T) = \exp\left(A(\tau) - B(\tau)\,r\right)$, $\tau = T - t$ (Seminarul 11, A6)
  - $B(\tau) = \frac{1-e^{-\kappa\tau}}{\kappa}$, $A(\tau) = \left(\theta^Q - \frac{\sigma^2}{2\kappa^2}\right)(B(\tau) - \tau) - \frac{\sigma^2 B(\tau)^2}{4\kappa}$
  - Randamentele $y(\tau) = (B(\tau)\,r - A(\tau))/\tau$ tind la $\theta^Q - \sigma^2/(2\kappa^2)$: incertitudinea ratelor reduce randamentele pe termen lung (convexitate)
  - Comparația cu randamentele titlurilor de stat: ▸ Anexa
- Capitolul 12 deduce Black–Scholes pe aceeași cale

Recapitulare: evaluarea sub Q

- Formulele de reținut
  - Girsanov: sub Q, driftul a devine $a - b\,\theta$, iar difuzia b rămîne neschimbată
  - GBM: $\theta = (\mu - r)/\sigma$ transformă driftul μ în r, deci $e^{-rt}S_t$ este o Q-martingală
  - Feynman–Kac: prețul $= \mathbb{E}^Q$[plata actualizată], soluția PDE de evaluare
- Din date: prețul de piață al riscului pentru S&P 500 este 0,40 pe $\sqrt{\text{an}}$, cu e.s. 0,17
- Verificare: $\mu = 9\%$, $\sigma = 20\%$, $r = 3\%$. Cît sînt prețul de piață al riscului și driftul lui S sub Q?
  - Răspuns: $\theta = 0{,}06/0{,}20 = 0{,}30$ și $\mu - \sigma\theta = 9\% - 6\% = 3\% = r$, cu $\sigma = 20\%$ neschimbat

Difuzia cu salturi a lui Merton

- Traiectoriile browniene sînt continue, dar prețurile prezintă salturi la publicarea știrilor: pe 19 octombrie 1987, Dow Jones a scăzut cu 22,6%, circa 20 de abateri standard sub GBM cu volatilitate de 18%
  - Un salt nu poate fi neutralizat prin hedging cu tranzacționare continuă Merton (1976)
- Logaritmul prețului = mișcare browniană cu drift + salturi **Poisson compuse**: $\mathrm{d}\ln S_t = m\,\mathrm{d}t + \sigma\,\mathrm{d}W_t + \mathrm{d}J_t$, $J_t = \sum_{i\le N_t} Y_i$
  - N_t este un proces Poisson cu intensitatea λ, iar mărimile salturilor $Y_i \sim N(\mu_J, \sigma_J^2)$ sînt i.i.d.
  - W, N și Y sînt independente, iar modelul are cinci parametri, $(m, \sigma, \lambda, \mu_J, \sigma_J)$
- Condiționat de k salturi, randamentul pe Δt are distribuția $N\left(m\Delta t + k\mu_J,\ \sigma^2\Delta t + k\sigma_J^2\right)$
- Necondiționat, randamentul este o **mixtură Poisson** de densități Normale, i.i.d. în timp
  - $f(r) = \sum_{k\ge 0} e^{-\lambda\Delta t}\frac{(\lambda\Delta t)^k}{k!}\,\varphi\left(r;\ m\Delta t + k\mu_J,\ \sigma^2\Delta t + k\sigma_J^2\right)$
  - Ponderile sînt probabilitățile Poisson ale celor k salturi, iar $\varphi(r; \text{medie}, \text{dispersie})$ este densitatea Normală
- Simulare exactă: extragem $N \sim \mathrm{Poisson}(\lambda\Delta t)$, apoi o variabilă aleatoare cu distribuția Normală și momentele condiționate

Momentele randamentului Merton

- Cumulanții c_k ai randamentului pe Δt (c, deoarece κ este viteza de revenire la medie)
  - Definiția: $K(u) = \ln \mathbb{E}[e^{ur}]$ și $c_k = K^{(k)}(0)$: c_1 media, c_2 dispersia, c_3 momentul centrat de ordinul trei; cumulanții părților independente se adună, iar o parte Normală are $c_k = 0$ pentru $k \geq 3$
  - cumulantul k al unei sume Poisson compuse este $\lambda \Delta t \, \mathbb{E}[Y^k]$
  - $c_2 = \sigma^2 \Delta t + \lambda \Delta t (\mu_J^2 + \sigma_J^2)$, $c_3 = \lambda \Delta t (\mu_J^3 + 3\mu_J \sigma_J^2)$
  - $c_4 = \lambda \Delta t (\mu_J^4 + 6\mu_J^2 \sigma_J^2 + 3\sigma_J^4)$
  - Asimetria este $c_3 / c_2^{3/2}$, iar excesul de kurtosis c_4 / c_2^2
- Un μ_J negativ dă asimetrie negativă; orice salt dă exces de kurtosis pozitiv
- Excesul de kurtosis scade ca $1/\Delta t$ cînd orizontul crește: salturile au cel mai mare efect pe orizonturi scurte
  - Exemplu: cu $\sigma = 15\%$, $\lambda = 5$, $\mu_J = -3\%$ și $\sigma_J = 4\%$, excesul de kurtosis zilnic este 17,6, iar asimetria $-2{,}07$ (Seminarul 11, A3)

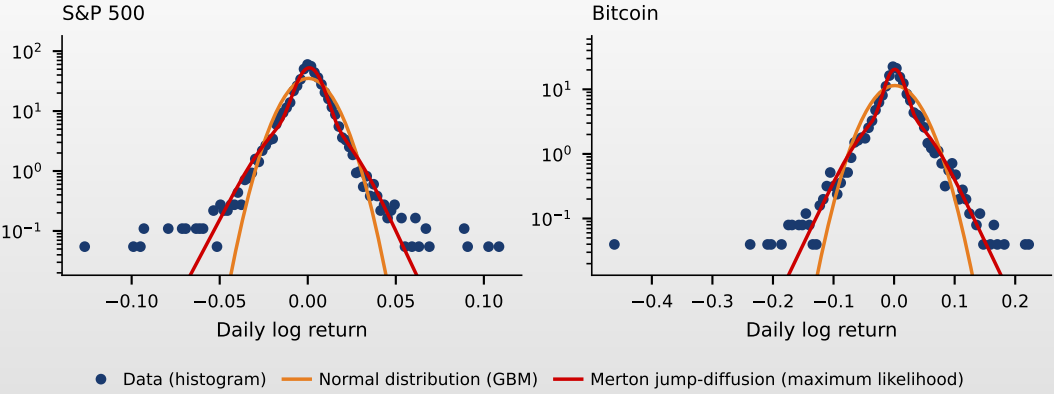
Estimările Merton pentru S&P 500, BET și Bitcoin

LR (Likelihood Ratio): statistica raportului de verosimilitate.

	$\hat{\sigma}$ (%)	$\hat{\lambda}$ (pe an)	$\hat{\mu}_J$ (%)	$\hat{\sigma}_J$ (%)	Ponderea salturilor în dispersie	LR
S&P 500	9,4	102 (11)	−0,16	1,44	71%	2 401
BET	11,3	79 (7)	−0,09	2,07	73%	2 326
Bitcoin	24,6	239 (21)	0,00	3,85	85%	1 357

- Log-verosimilitatea este maximizată numeric pe mixtura Poisson (cel mult 12 salturi pe zi), iar erorile standard calculate din hessiană apar în paranteze
- Verosimilitatea este **nemărginită**: cu $m\Delta t$ egal cu un randament observat și $\sigma \to 0$, acea densitate tinde la infinit, deci MLE este un maxim local Honoré (1998)
  - Testul LR față de GBM ($\lambda = 0$) este definit pe $\sigma \geq 5\%$ și nu are distribuția χ^2_3: $\lambda = 0$ este pe frontieră, iar μ_J, σ_J nu sînt identificați. Valorile critice bootstrap: Seminarul 11, B5
- Estimarea favorizează **multe salturi mici** (circa 80–240 pe an), nu cîteva crahuri

Estimarea Merton pentru distribuția randamentelor (1/2)



MFM_ch11_merton_density

Estimarea Merton pentru distribuția randamentelor (2/2)

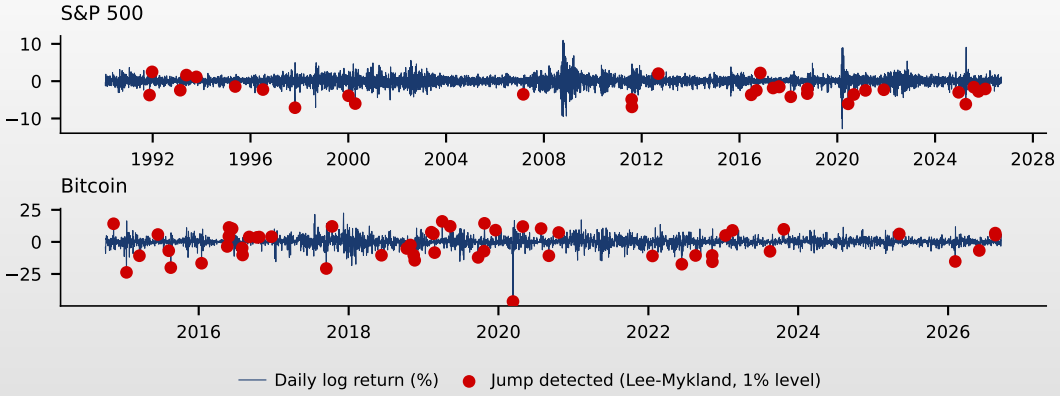
- Densitatea randamentelor logaritmice zilnice pe scară logaritmică: histograma, distribuția Normală implicată de GBM și mixtura Merton estimată
  - Merton reproduce vîrful și regiunile adiacente mult mai bine
- S&P 500: excesul de kurtosis implicat de modelul Merton este 3,7, față de 10,9 în date, iar asimetria $-0{,}31$, față de $-0{,}36$
- Zilele cele mai extreme se află dincolo de ambele curbe estimate
- Circa 102 „salturi" pe an: modelul folosește salturile pentru a imita **volatilitatea variabilă**
- Un model i.i.d. nu poate distinge un salt de o perioadă volatilă, deci este nevoie de un test direct

MFM_ch11_merton_density

Detectarea salturilor: testul Lee–Mykland

- Ideea: un salt este un randament foarte mare **raportat la volatilitatea locală** Lee & Mykland (2008)
  - $L_t = r_t/\hat{\sigma}_t$, $\hat{\sigma}_t^2 = \frac{1}{K-2}\sum_{j=t-K+2}^{t-1} |r_j|\,|r_{j-1}|$ (variația bipower, robustă la salturi)
- În absența salturilor, maximul lui $|L_t|$ pe n zile are o limită Gumbel
  - Respingem dacă $(|L_t| - C_n)/S_n > -\ln(-\ln(1-\alpha))$
  - La $\alpha = 1\%$, acest prag pentru statistica **normalizată**, nu pentru $|L_t|$, este 4,60
  - $C_n = \frac{\sqrt{2\ln n}}{c} - \frac{\ln\pi + \ln\ln n}{2c\sqrt{2\ln n}}$, $S_n = \frac{1}{c\sqrt{2\ln n}}$, $c = \sqrt{2/\pi}$ (media lui $|Z|$, care rescalează estimarea bipower), $n =$ numărul zilelor testate
- Date zilnice: fereastra $K = 16$ zile, conform recomandării autorilor
- Controlează, asimptotic, probabilitatea unui salt fals pe **întregul** eșantion, nu zi de zi

Salturi detectate în S&P 500 și Bitcoin (1/2)



MFM_ch11_jumps

Salturi detectate în S&P 500 și Bitcoin (2/2)

	S&P 500	Bitcoin
Salturi candidate	32	52
Pe an	0,87	4,35
Negative (%)	84	52
Printre primele 10 mișcări	0	5

- Randamente logaritmice zilnice, cu zilele marcate ca salturi la nivelul de semnificație de 1%
- S&P 500: cele mai mari mișcări (2008, 2020) nu sînt marcate
  - Ele au avut loc în perioade turbulente
  - În schimb, o mișcare de 1,2% într-o piață calmă este marcată (1993-10-14)
- Detecțiile diferă de intensitatea Merton estimată. Explicații posibile:
  - volatilitatea stochastică
  - drift bursts (episoade scurte de drift exploziv)
  - puterea redusă de detectare în datele zilnice

MFM_ch11_jumps

Recapitulare: ce adaugă salturile

- Formulele de reținut
  - $\mathrm{d}\ln S_t = m\,\mathrm{d}t + \sigma\,\mathrm{d}W_t + \mathrm{d}J_t$: randamentul logaritmic mediu este $m + \lambda\mu_J$ pe an, deci m singur este doar driftul părții de difuzie
  - Cumulanții de ordin superior provin doar din salturi: $c_k = \lambda\Delta t\,\mathbb{E}[Y^k]$ pentru $k \geq 3$
  - Excesul de kurtosis c_4/c_2^2 scade ca $1/\Delta t$ cu orizontul
- Din date: pentru S&P 500, $\hat{m} + \hat{\lambda}\hat{\mu}_J = 24{,}8\% + (-16{,}5\%) \approx 8{,}3\%$, apropiat de driftul logaritmic GBM de 8,3%; ponderea salturilor în dispersie este 71%
- Verificare: salturile dau un exces de kurtosis zilnic de 12. Cît este pentru randamentele pe 10 zile, dacă randamentele sînt i.i.d.?
  - Răspuns: $12/10 = 1{,}2$: pe 10 zile, atît c_4, cît și c_2 cresc de 10 ori, deci c_4/c_2^2 scade de 10 ori

Modelul Heston

- Două SDE, pentru logaritmul prețului și pentru varianța instantanee v_t Heston (1993)
  - $\mathrm{d}\ln S_t = \left(\mu - \frac{1}{2}v_t\right)\mathrm{d}t + \sqrt{v_t}\,\mathrm{d}W_t^{(1)}$
  - $\mathrm{d}v_t = \kappa(\theta - v_t)\,\mathrm{d}t + \xi\sqrt{v_t}\,\mathrm{d}W_t^{(2)}$, $\mathrm{Corr}(\mathrm{d}W^{(1)}, \mathrm{d}W^{(2)}) = \rho$
- Varianța urmează un proces CIR: revine la θ cu viteza κ, iar ξ este volatilitatea volatilității
  - Condiția Feller $2\kappa\theta \geq \xi^2$: varianța nu atinge niciodată zero Feller (1951)
- $\rho < 0$: **efectul de levier**, scăderile de preț sînt însoțite de creșterea volatilității
  - O scădere mărește varianța care scalează mișcările următoare, deci randamentele au asimetrie negativă (Secțiunea 11)
  - Simulare: schema Euler cu trunchiere completă $v^+ = \max(v, 0)$ Lord, Koekkoek & van Dijk (2010)
  - O altă discretizare: schema pătratic-exponențială Andersen (2008)

Parametrii Heston din VIX

- Folosim proxy-ul $y_t = (\mathrm{VIX}_t/100)^2$ în locul lui v_t și estimăm regresia CIR discretizată, fără termen liber suplimentar
  - $\frac{y_{t+\Delta t}-y_t}{\sqrt{y_t}} = \kappa\theta\frac{\Delta t}{\sqrt{y_t}} - \kappa\Delta t\sqrt{y_t} + \xi\sqrt{\Delta t}\,\varepsilon_t$
  - ρ este corelația dintre șocurile de randament și cele de variață
- Estimările pe S&P 500 și VIX, 1990–2026: viteza de revenire $\hat{\kappa} = 4{,}13$ (timp de înjumătățire de 42 zile), volatilitatea volatilității $\hat{\xi} = 0{,}56$ și corelația $\hat{\rho} = -0{,}69$
  - Nivelul pe termen lung din VIX este $\sqrt{\hat{\theta}} = 20{,}9\%$, dar volatilitatea realizată este 18,0%
  - Raportul Feller al proxy-ului este $2\hat{\kappa}\hat{\theta}/\hat{\xi}^2 = 1{,}16$
- Dar y_t **nu** este v_t: este valoarea așteptată a variantei viitoare sub măsura neutră la risc, afină în v_t (slide-ul următor)
  - Pentru traiectoriile reale fixăm θ la varianța realizată
  - $\hat{\xi}$ este atenuat față de ξ

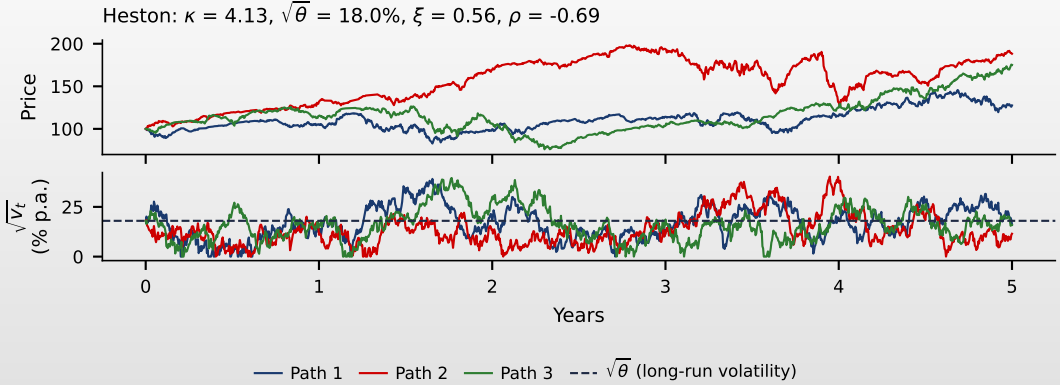
Parametrii identificați de VIX în modelul Heston (aprofundare)

- Sub Q: $y_t = \frac{1}{\tau}\mathbb{E}^Q\left[\int_t^{t+\tau} v_s\,\mathrm{d}s \mid \mathcal{F}_t\right] = a + b\,v_t$, $\tau = 30/365$ (Seminarul 11, A8)
  - $b = \frac{1-e^{-\kappa^Q\tau}}{\kappa^Q\tau} < 1$, $a = \theta^Q(1-b)$: deci y_t este **afin** în v_t, cu parametri Q
- Parametrii recuperați de regresia pe y_t
  - κ: viteza sub P, deoarece o transformare afină păstrează dinamica lui v_t
  - ρ: neschimbat (corelația nu depinde de scală), dar necesită perechi de șocuri de randament și variață, aproximate doar de variațiile zilnice ale proxy-ului
  - ξ este atenuat: difuzia lui y este $\xi\sqrt{b(y-a)}$, deci $\xi_y = b\,\xi\sqrt{v/(a+bv)}$ variază cu starea și este egal cu $b\xi$ doar la $v_t = \theta^Q$ (corecția locală $\hat{\xi}/b$: Anexa)
  - Nivelul pe termen lung $a + b\,\theta^P$ amestecă θ^Q și θ^P: recuperăm $\theta^P = (\theta_y - a)/b$, cu θ_y nivelul pe termen lung estimat al lui y, înainte de a verifica condiția Feller pentru v_t
- O estimare corectă modelează direct dinamica lui y, al cărei coeficient de difuzie este proporțional cu $\sqrt{y-a}$, sau estimează împreună v_t și ecuația de observație
- κ^Q nu se identifică doar din VIX: estimare comună P/Q cu prețuri de opțiuni Chernov & Ghysels (2000) sau momente ale variației realizate Bollerslev & Zhou (2002)

De unde provine atenuarea lui ξ (aprofundare)

- Pasul 1: $y_t = a + b\,v_t$, cu a și b constante, deci $\mathrm{d}y_t = b\,\mathrm{d}v_t$ sub P
  - $\mathrm{d}y_t = b\kappa(\theta^P - v_t)\,\mathrm{d}t + b\,\xi\sqrt{v_t}\,\mathrm{d}W_t^{(2)}$
- Pasul 2, driftul: $b\kappa(\theta^P - v_t) = \kappa(\theta_y - y_t)$, cu $\theta_y = a + b\,\theta^P$
  - Viteza κ rămîne neschimbată; prin inversare, $\theta^P = (\theta_y - a)/b$
- Pasul 3, difuzia: regresia CIR presupune $\xi_y\sqrt{y_t}$; egalînd $\xi_y\sqrt{y_t} = b\,\xi\sqrt{v_t}$ obținem
  - $\xi_y = b\,\xi\sqrt{v_t/(a + b\,v_t)}$; la $v_t = \theta^Q$, $a + b\,\theta^Q = \theta^Q$, deci $\xi_y = b\,\xi$
- Cifre: cu $\kappa^Q = 5$, $b = 0{,}82$, deci $\hat{\xi} = 0{,}56$ estimat corespunde lui $\hat{\xi}/b = 0{,}68$ în jurul lui $v_t = \theta^Q$ (alte valori κ^Q: ▸ Anexa)

Traiectorii Heston simulate (1/2)



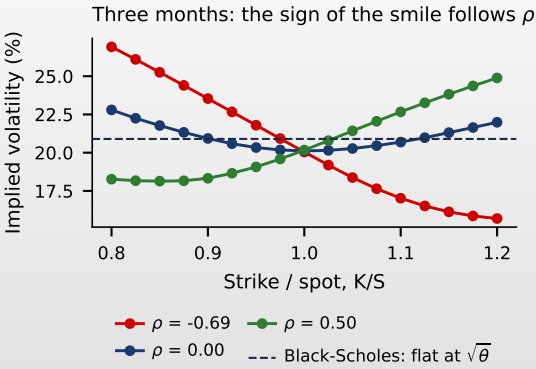
MFM_ch11_heston_paths

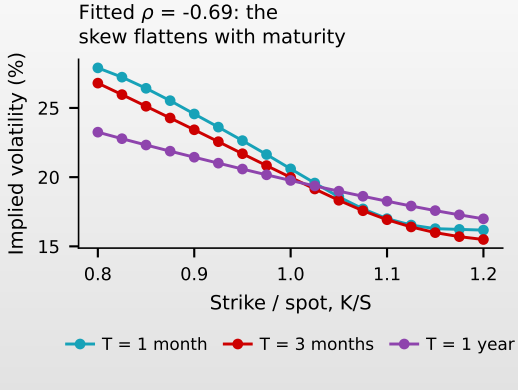
Traiectorii Heston simulate (2/2)

- Trei traiectorii simulate pe cinci ani: sus prețul, jos volatilitatea $\sqrt{v_t}$
  - Parametrii $\hat{\kappa}$, $\hat{\xi}$ (necorectat) și $\hat{\rho}$ provin din VIX, iar θ este varianța realizată a S&P 500
- Volatility clustering este acum generat de model
  - Scăderile de preț coincid cu vîrfurile de volatilitate
  - Corelația simulată randament–varianță: $-0{,}69$ (efectul de levier prin ρ)
- Raportul Feller $2\hat{\kappa}\theta/\hat{\xi}^2 = 0{,}86 < 1$: varianța poate atinge zero
  - Valorile negative apar doar în schema Euler
  - Trunchierea completă le înlocuiește cu zero (1,4% din pași)

MFM_ch11_heston_paths

Volatility smile: introducere în Capitolul 12 (1/2)





MFM_ch11_heston_smile

Volatility smile: introducere în Capitolul 12 (2/2)

- **Volatilitatea implicită**: valoarea σ pentru care prețul Black–Scholes este egal cu un preț dat al opțiunii, constantă în raport cu prețul de exercitare sub GBM
- Aici, volatilitățile implicite sînt calculate din prețurile opțiunilor call Heston (Monte Carlo, 100 000 de traiectorii antitetice)
- Stînga, scadența de trei luni
  - cu $\hat{\rho} = -0{,}69$, volatilitatea implicită este 26,9% la un preț de exercitare de 80% din spot, 20,0% la spot și 15,7% la 120% din spot: un **skew** descendent
  - cu $\rho = 0$, un **smile** simetric: 22,8% la 80% din spot, iar 20,1% la spot și 22,0% la 120% din spot
- Dreapta: skew-ul se aplatizează odată cu scadența
  - între prețurile de exercitare de 80% și 120% din spot, volatilitatea implicită scade de la 27,9% la 16,2% la o lună, dar doar de la 23,2% la 17,0% la un an
- Este doar o ilustrare: evaluarea necesită κ^Q, θ^Q calibrați pe prețurile opțiunilor (Capitolul 12)
- Corelația pozitivă din grafic ($\rho = 0{,}50$) inversează skew-ul: volatilitatea implicită crește cu prețul de exercitare.

MFM_ch11_heston_smile

Modele afine și volatilitate condiționată (aprofundare)

GARCH (Generalised Autoregressive Conditional Heteroskedasticity) descrie varianța condiționată din date discrete.

Difuzii afine cu salturi Duffie, Pan & Singleton (2000)

- Drift, variață și intensitate a salturilor afine în starea X_t
  - Vasicek, CIR, Merton, Heston și Bates
- $\mathbb{E}\left[e^{iu^\top X_T} \mid X_t\right] = \exp\left(\alpha(\tau) + \beta(\tau)^\top X_t\right)$
  - $i = \sqrt{-1}$, u: un vector real, $\tau = T - t$
  - α, β: soluții ale unor ecuații diferențiale ordinare Riccati
- Prețurile opțiunilor prin inversare Fourier
  - Cazul cel mai simplu: $A(\tau)$, $B(\tau)$ Vasicek din Secțiunea 8

De la volatilitate condiționată la difuzii Nelson (1990)

- Cînd pasul se micșorează, GARCH(1,1) converge la
  - $\mathrm{d}v_t = \kappa(\theta - v_t)\,\mathrm{d}t + \xi v_t\,\mathrm{d}W_t^{(2)}$
  - Ca Heston, cu v_t în loc de $\sqrt{v_t}$
- $\kappa \approx (1 - \alpha - \beta)/\Delta t$, cu α, β coeficienții GARCH(1,1)
  - Cu $\alpha + \beta = 0{,}99$ pe date zilnice, $\kappa \approx 2{,}5$ pe an, adică un timp de înjumătățire de circa 70 de zile (Capitolul 5)
- Experimente care nu sînt asimptotic echivalente Wang (2002)
  - Inferența poate diferi chiar cînd $\Delta t \to 0$

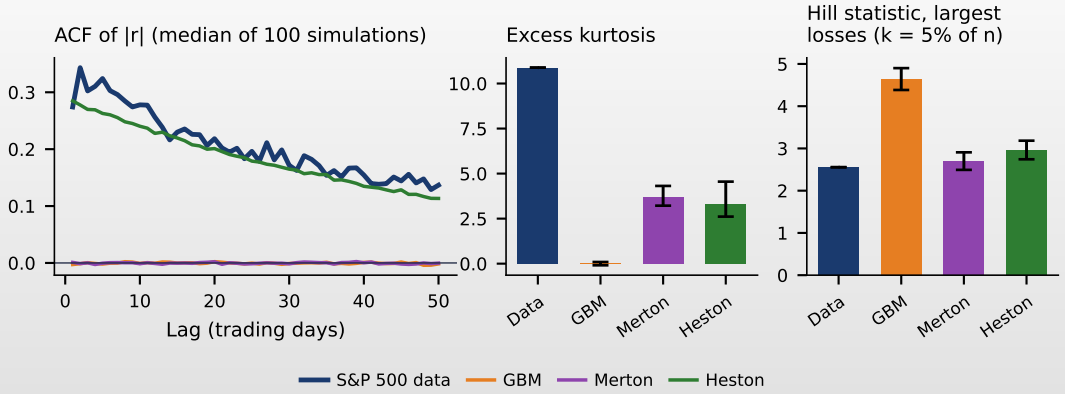
Recapitulare: volatilitatea stochastică

- Formulele de reținut
  - Varianța este un proces CIR, $\mathrm{d}v_t = \kappa(\theta - v_t)\,\mathrm{d}t + \xi\sqrt{v_t}\,\mathrm{d}W_t^{(2)}$, pozitiv dacă $2\kappa\theta \geq \xi^2$
  - $\rho = \mathrm{Corr}(\mathrm{d}W^{(1)}, \mathrm{d}W^{(2)}) < 0$ dă efectul de levier, randamente cu asimetrie negativă și un skew descendent al volatilității implicite
  - $(\mathrm{VIX}/100)^2 = a + b\,v_t$, cu parametri Q: κ și ρ se păstrează, iar ξ este atenuat de b
- Din date: $\hat{\rho} = -0{,}69$ și $\hat{\kappa} = 4{,}13$, adică un timp de înjumătățire al variației de 42 zile de tranzacționare
- Verificare: cu $\kappa = 4$ și $\theta = 0{,}04$, care este cel mai mare ξ pentru care este îndeplinită condiția Feller?
  - Răspuns: $\xi \leq \sqrt{2 \cdot 4 \cdot 0{,}04} = \sqrt{0{,}32} \approx 0{,}57$; o volatilitate a volatilității mai mare permite variației să atingă zero

Trei repere pentru randamentele simulate

- **Forma**: asimetria $c_3/c_2^{3/2}$ și excesul de kurtosis c_4/c_2^2 ale randamentelor zilnice (cumulanții: Secțiunea 9)
- **Volatility clustering**: ACF a lui $|r_t|$ la lagurile 1–20; este zero pentru orice model i.i.d., inclusiv Merton
- **Coada**: statistica Hill a celor mai mari k pierderi $L_{(1)} \geq \cdots \geq L_{(k+1)}$, $\hat{\alpha} = \left[\frac{1}{k}\sum_{i=1}^{k} \ln\left(L_{(i)}/L_{(k+1)}\right)\right]^{-1}$
  - Estimează α din $P(L > x) \approx Cx^{-\alpha}$ pentru x mare: $P(L > 2x)/P(L > x) \approx 2^{-\alpha}$
  - Cu $\alpha = 2{,}56$, dublarea mărimii pierderii păstrează $2^{-2{,}56} \approx 0{,}17$ din frecvență; o coadă Normală păstrează $P(Z > 4)/P(Z > 2) \approx 0{,}0014$: un α mai mic înseamnă o coadă mai grea
  - Estimarea depinde de k: în date, 2,97; 2,56 și 2,04 pentru $k = 2{,}5\%$; 5% și 10% din randamente
- Verificare: pierderile de două ori mai mari sînt de 8 ori mai rare. Cît este α?
  - Răspuns: $2^{-\alpha} = 1/8$, deci $\alpha = 3$

Capacitatea modelelor de a reproduce S&P 500 (1/2)



MFM_ch11_models_vs_data

Capacitatea modelelor de a reproduce S&P 500 (2/2)

- 100 de eșantioane simulate de cîte 9 245 de zile din fiecare model estimat (mediane, intervale de 90%)
  - Statisticile comparate: ACF a lui $|r_t|$, excesul de kurtosis și statistica Hill a celor mai mari pierderi, calculată pe $k = 5\%$ din randamente (o valoare mai mică înseamnă o coadă mai grea)
  - În date, excesul de kurtosis este 10,88, iar statistica Hill 2,56
- Merton reproduce statistica Hill (2,70) și asimetria ($-0{,}32$ față de $-0{,}36$), dar nu și volatility clustering
- Heston, cu parametrii din VIX, reproduce volatility clustering
- Asimetria Heston simulată (0,00) trebuie citită cu atenție: o simulare Euler cu pasul egal cu intervalul de eșantionare de o zi dă, prin construcție, asimetrie zero
  - Modelul Heston în timp continuu, cu $\rho < 0$, implică circa $-0{,}20$ la acești parametri (slide-ul următor); sînt necesari pași intrazilnici, însumați în randamente zilnice, înainte de a judeca modelul după asimetrie
- Niciun model estimat nu atinge excesul de kurtosis din date (tabelul complet: Anexa)
  - Andersen, Benzoni & Lund (2002) și Eraker, Johannes & Polson (2003) susțin salturi **și** volatilitate stochastică (SVJ, stochastic volatility with jumps, Bates (1996))

MFM_ch11_models_vs_data

De ce un ρ negativ face asimetrice randamentele zilnice (aprofundare)

- Pe o zi, $h = 1/252$, ignorînd termenii de drift de ordinul h: $R = \int_0^h \sqrt{v_s}\,\mathrm{d}W_s^{(1)}$
  - Lema lui Itô pentru $\sqrt{v}$: $\mathrm{d}\sqrt{v_s} = \frac{1}{2}\xi\,\mathrm{d}W_s^{(2)} + O(\mathrm{d}s)$, deci $\sqrt{v_s} \approx \sqrt{v_0} + \frac{1}{2}\xi W_s^{(2)}$
  - $R \approx \sqrt{v_0}\,W_h^{(1)} + \frac{1}{2}\xi \int_0^h W_s^{(2)}\,\mathrm{d}W_s^{(1)}$
- Momentul de ordinul trei: termenul încrucișat dă $\mathbb{E}[R^3] \approx \frac{3}{2}\,\xi\rho\,v_0 h^2$, iar $\mathrm{Var}(R) \approx v_0 h$
  - Asimetria $\approx \frac{3}{2}\,\rho\xi\sqrt{h}/\sqrt{v_0}$: cu $\hat{\rho} = -0{,}69$, $\hat{\xi} = 0{,}56$ și $\sqrt{v_0} = 18{,}0\%$, circa $-0{,}20$, o aproximare de ordinul principal
- Pasul Euler zilnic: $r_{t+1} = (\mu - \frac{1}{2}v_t)\Delta t + \sqrt{v_t}\,\Delta W_{t+1}^{(1)}$, cu v_t cunoscut la t
  - $\mathbb{E}[(\sqrt{v_t}\,\Delta W^{(1)})^3] = \mathbb{E}[v_t^{3/2}]\,\mathbb{E}[(\Delta W^{(1)})^3] = 0$: șocul de varianță din aceeași zi nu ajunge în randament, deci asimetria este zero prin construcție, cu excepția termenului de drift, foarte mic

Alegerea modelului: caracteristici, identificare și limite

Caracteristica din date	**Modelul**	**Parametri identificați**	**Nerezolvat**
Prețuri pozitive, scalarea cu $\sqrt{t}$	GBM	σ precis; μ doar pe orizonturi foarte lungi	cozi groase, volatility clustering
Revenirea la medie a dobînzilor și a VIX	OU, Vasicek, CIR, CKLS	$b(r)$ precis; κ deplasat în sus, necesită un orizont lung	un singur factor, prea simplu pentru VIX
Salturi, cozi groase pe orizonturi scurte	Merton	λ, σ_J doar sub randamente i.i.d.; ponderea salturilor depinde de frecvență	fără volatility clustering
Volatility clustering, efect de levier, skew-ul volatilității implicite	Heston	κ, ρ din VIX; ξ atenuat; $\theta^Q \neq \theta^P$	kurtosis-ul datelor; asimetria necesită pași de simulare intrazilnici
Toate cele de mai sus	Bates (Heston + salturi)	randamentele și suprafețele de opțiuni împreună	stări latente: este nevoie de filtrare

- Roughness-ul și memoria lungă ale volatilității, discutate în continuare, sînt caracteristici pe care niciunul dintre aceste modele cu un factor nu le reproduce

Context: mișcarea browniană fracționară și exponentul Hurst (aprofundare)

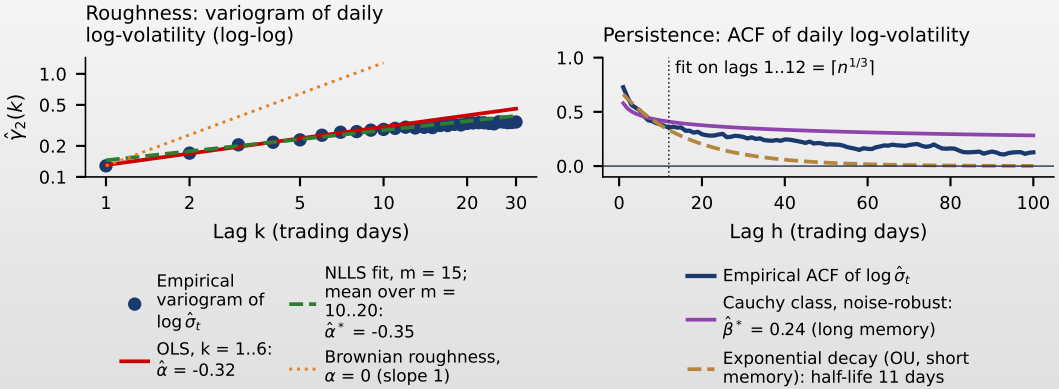
- **Mișcarea browniană fracționară** B^H, $0 < H < 1$: un proces gaussian cu $B_0^H = 0$ și $\mathrm{Cov}(B_s^H, B_t^H) = \frac{1}{2}\left(s^{2H} + t^{2H} - |t-s|^{2H}\right)$
  - $H = 1/2$ dă $\min(s,t)$, adică mișcarea browniană; incrementele au dispersia $\mathbb{E}[(B_{t+h}^H - B_t^H)^2] = h^{2H}$
  - $H < 1/2$: incrementele succesive sînt corelate negativ, iar traiectoriile sînt mai neregulate decît mișcarea browniană; $H > 1/2$: corelate pozitiv, mai netede
- **OU fracționar**: ecuația OU cu B^H în locul lui W; un singur H fixează ambele capete ale ACF
  - Laguri mici: variograma se comportă ca $h^{2H} = h^{2\alpha+1}$, deci $\alpha = H - 1/2$
  - Laguri mari: ACF scade ca $h^{2H-2} = h^{-\beta}$, deci $\beta = 2 - 2H$
- Verificare: ce H dă $\beta = 0{,}18$, estimarea memoriei raportată în lucrare? Este acel proces rough?
  - Răspuns: $H = 1 - \beta/2 = 0{,}91$, deci $\alpha = 0{,}41 > 0$: neted, nu rough; un singur H nu poate reproduce ambele trăsături, ceea ce motivează studiul de caz

Întrebarea de cercetare: poate volatilitatea să fie rough și totuși persistentă?

- Lucrarea: Bennedsen, Lunde & Pakkanen (2022), *Journal of Financial Econometrics*
  - Pornește de la Gatheral, Jaisson & Rosenbaum (2018): logaritmul volatilității ca proces OU fracționar cu exponentul Hurst $H < 1/2$ (RFSV, rough fractional stochastic volatility)
  - Modelul cu memorie lungă propus de Comte & Renault (1998) folosește $H > 1/2$ (Introducerea)
- Indicele de roughness α: $1 - \rho(h) \sim c|h|^{2\alpha+1}$ pentru $h \to 0$, cu ρ autocorelația logaritmului volatilității (ec. (1.1)). Un $\alpha < 0$ înseamnă traiectorii mai neregulate (rough) decît mișcarea browniană
  - Parametrul de memorie β: $\rho(h) \sim c|h|^{-\beta}$ pentru $h \to \infty$ (ec. (2.2)). Un $\beta < 1$ înseamnă că ACF nu este integrabilă, adică memorie lungă
- Problema: în procesul OU fracționar, un singur H determină ambii parametri, $\alpha = H - 1/2$ și $\beta = 2 - 2H$ (Secțiunea 1): cu $H < 1/2$ rezultă $\beta > 1$, deci un proces OU fracționar rough nu poate avea memorie lungă
- Întrebările de cercetare (Introducerea, Secțiunile 4 și 5)
  - sînt volatilitățile realizate în același timp rough și persistente?
  - prognozează mai bine modelele care permit valori separate pentru α și β?
- În curs replicăm partea zilnică a analizei, pe SPY; extinderea intrazilnică este în Seminarul 11, C3
- Modelul, estimatorii și rezultatele de prognoză din lucrare sînt în Anexă

Studiu de caz: replicare pe SPY, Δ = o zi (1/2)

NLLS: Non-Linear Least Squares.



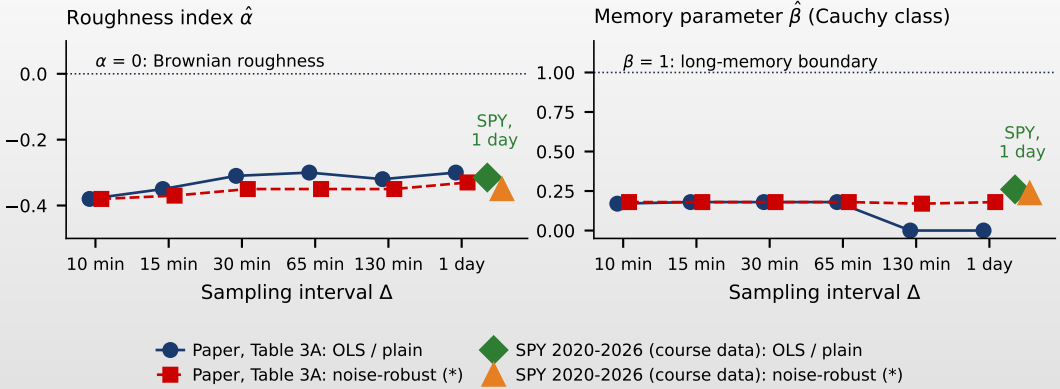
MFM_ch11_rough_vol

Studiu de caz: replicare pe SPY, Δ = o zi (2/2)

- Date: bare SPY de 5 minute, 1 468 de zile complete (octombrie 2020 – septembrie 2026)
- $x_t = \log \hat{\sigma}_t = \frac{1}{2} \log \mathrm{BV}_t$, unde BV_t este variația bipower zilnică a celor 78 de randamente la 5 minute Barndorff-Nielsen & Shephard (2004)
- Stînga, roughness: variograma $\hat{\gamma}_2(k) = \frac{1}{n-k} \sum_t (x_{t+k} - x_t)^2$
  - estimatorul OLS, pe $k = 1, \ldots, 6$, dă $\hat{\alpha}_{\mathrm{OLS}} = -0{,}32$, iar estimatorul NLLS robust la zgomot dă $\hat{\alpha}^*_{\mathrm{NLLS}} = -0{,}35$
  - în lucrare, la o zi: $-0{,}30$ (OLS) și $-0{,}33$ (NLLS) (Tabelul 3, Panoul A)
- Dreapta, persistență: autocorelația este 0,13 la lagul 100
  - modelul Cauchy, estimat pe 12 laguri, dă $\hat{\beta} = 0{,}26$ și $\hat{\beta}^* = 0{,}24$ (robust la zgomot), ambele sub 1: în acord cu memoria lungă, fără a o demonstra
  - un model OU (timp de înjumătățire de 11 zile) implică o autocorelație de 0,001 la lagul 100
- În grafic, m este numărul de laguri folosite la ajustarea NLLS: 15 pentru curba ilustrată, iar estimarea raportată este media pentru 10–20 de laguri.

MFM_ch11_rough_vol

Studiu de caz: SPY comparat cu Tabelul 3 (1/2)



MFM_ch11_rough_vol

Studiu de caz: SPY comparat cu Tabelul 3 (2/2)

- Liniile: contractul futures E-mini S&P 500, 2011–2014, Δ de la 10 minute la o zi (Bennedsen, Lunde & Pakkanen (2022), Tabelul 3, Panoul A)
- Marcajele: SPY la o zi, 2020–2026, din datele cursului; * indică estimatorii robuști la zgomot
- $\hat{\alpha}$ aproape nu depinde de Δ (între $-0{,}38$ și $-0{,}30$): roughness-ul este o proprietate a procesului, iar SPY se încadrează în aceeași bandă
- $\hat{\beta}^*$ este 0,17–0,18 la orice Δ, mult sub 1, iar $\hat{\beta}$ fără corecție este instabil
- Limite: alt contract, altă perioadă, alt estimator (bare agregate, nu fiecare tranzacție, fără pre-averaging)
- Măsurile realizate estimează varianța integrată, nu pe cea instantanee

MFM_ch11_rough_vol

O întrebare deschisă: ce parte din variația prețului provine din discontinuități?

- Modelul: $\mathrm{d}X_t = \mu_t\,\mathrm{d}t + \sigma_t\,\mathrm{d}W_t + J_t\,\mathrm{d}N_t$, cu X_t logaritmul prețului, N_t numărul de salturi (cu intensitatea λ) și J_t mărimea saltului
- Răspunsul depinde de frecvența de eșantionare și de model
  - Estimarea Merton pe date zilnice (acest capitol): salturile explică 71% din varianța S&P 500
  - Testul bipower la 5 minute (Capitolul 9): salturile explică 2,8% din varianța SPY
  - Christensen, Oomen & Podolskij (2014): la frecvența tranzacție cu tranzacție, majoritatea salturilor detectate la eșantionare mai rară dispar: sînt mișcări rapide, dar continue
  - Christensen, Oomen & Renò (2022): **drift bursts**, tendințe explozive scurte în μ_t, apar ca salturi în datele eșantionate rar
- Întrebarea formală: H_0: $\lambda = 0$ (traiectorie continuă cu volatilitate stochastică) față de H_1: $\lambda > 0$
  - Testul este nestandard: apare aceeași problemă de frontieră ca la testul LR pentru Merton (Secțiunea 9)

Bucla descoperirii și verificările cercetătorului

Bucla cu un asistent AI

- Asistentul: un LLM (Large Language Model — model lingvistic mare) precum Claude, ChatGPT sau Gemini
- **1. Literatura**: ponderile publicate ale salturilor, pe frecvențe; verificăm fiecare Digital Object Identifier (DOI) pe Crossref
- **2. Ipoteze**: salturi Merton, volatilitate Heston, drift bursts, fiecare cu o implicație testabilă distinctă
- **3. Replicăm întîi**: $\hat{\lambda} = 102$ pe an, ponderea salturilor 71%
- **4. Robustețe** pre-înregistrată
- **5. Critica**: AI ca recenzent ostil
- **6. Raportul**: toate specificațiile, codul, jurnalul AI
- Prompturi reutilizabile: Anexa

Verificări: eroare și test

- Frontieră, parametri neidentificați: bootstrap parametric sub H_0
- Look-ahead bias în filtrul de volatilitate: standardizăm doar cu $\mathcal{F}_{t-1}$
- Frecvențe diferite: ponderile salturilor la fiecare frecvență, pe un eșantion comun
- Verosimilitate multimodală: multe puncte de start și profilul în λ
- Cifre inventate: orice afirmație necesită un tabel și un DOI

Mini studiu de caz: salturi sau volatilitate stochastică deghizată?

- O propunere tipică a asistentului: „71% din varianță provine din salturi”
  - Ipoteza rivală: mixtura Poisson absoarbe volatilitatea variabilă în timp; atunci standardizarea cu volatilitatea EWMA (Exponentially Weighted Moving Average, medie mobilă ponderată exponențial; $\lambda_{\mathrm{EWMA}} = 0{,}94$, cunoscută la $t-1$) elimină salturile

	Randamente nestandardizate	Standardizate EWMA
Excesul de kurtosis	10,9	2,9
LR, Merton față de distribuția Normală	2 401	619
$\hat{\lambda}$ pe an (e.s.)	102 (11)	124 (53)
Ponderea salturilor în varianță	71%	51%

- Standardizarea elimină cea mai mare parte a excesului de kurtosis, dar modelul raportează în continuare un „salt” aproximativ o dată la două zile: $\hat{\lambda}$ măsoară cozile groase, nu discontinuitățile
- Interpretare: datele zilnice nu identifică ponderea salturilor
- Testul Lee–Mykland găsește 0,87 salturi pe an, iar testul bipower pe datele la 5 minute dă o pondere a salturilor de 2,8%, la altă frecvență și pe alt eșantion. Codul: Quantlet-ul capitolului, studiul AI

Un punct de plecare pentru proiect

- Întrebări
  - ce parte din varianța S&P 500 și Bitcoin provine din salturi?
  - cum depinde această pondere de frecvența de eșantionare?
  - sînt „salturile" detectate drift bursts?
- Replicați mai întîi
  - ponderea salturilor în varianță din modelul Merton: 71% (S&P 500, date zilnice)
  - numărul de salturi detectate de testul Lee–Mykland: 0,87 pe an
  - ponderea salturilor din testul bipower: 2,8% (SPY, 5 minute, Capitolul 9)
- Date: barele SPY de 5 minute (octombrie 2020 – septembrie 2026) pentru toate frecvențele intrazilnice; închiderile zilnice S&P 500 și Bitcoin. Datele cursului nu conțin o serie intrazilnică pentru Bitcoin: o comparație intrazilnică pentru Bitcoin necesită o sursă externă, documentată în pre-înregistrare

Proiect: livrabile și fereastra evenimentului

- O pre-înregistrare (ipoteze, frecvențe, filtre, teste, designul bootstrap) datată înainte de prima rulare
- Livrabilele de bază, realizabile cu datele cursului
  - SPY: ponderea salturilor din testul bipower și numărul de salturi Lee–Mykland la 5, 15 și 30 de minute; S&P 500 și Bitcoin: valorile zilnice din acest capitol
  - Standardizarea EWMA din mini studiul de caz, repetată pe SPY la fiecare frecvență
  - Statistica drift burst din Christensen, Oomen & Renò (2022) pe SPY în intervalul 2–11 aprilie 2025 (anunțul tarifelor SUA pe 2 aprilie, pauza de 90 de zile pe 9 aprilie), comparată cu o fereastră calmă de aceeași lungime, fixată dinainte
- Extensie opțională: un test LR bootstrap Heston (ipoteza nulă, fără salturi) față de Bates
  - Ambele verosimilități necesită filtrarea variației latente, de exemplu prin abordarea Markov Chain Monte Carlo (MCMC) din Eraker, Johannes & Polson (2003); planificați timpul de calcul înainte de a vă angaja
- Codul, un raport de două pagini cu toate specificațiile încercate și o critică, în stil de recenzent, a propriului rezultat
- Declarați folosirea AI în `AI_USE.md` și erorile identificate în `AI_ERRORS.md`: github.com/danpele/MFM/tree/main/project

Idei principale și ce urmează: Capitolul 12

- Sub ipotezele teoremei lui Donsker, mersurile aleatoare rescalate converg la mișcarea browniană; variația ei pătratică t stă la baza calculului Itô
- Lema lui Itô conduce la soluții exacte (GBM, Ornstein–Uhlenbeck, Merton); simulăm exact sau cu Euler–Maruyama și Milstein, cu un ordin de eroare cunoscut
- Identificarea: asimptotica infill identifică volatilitatea; driftul și viteza de revenire la medie necesită orizonturi lungi, iar $\hat{\kappa}$ este deplasat în sus
- Prețurile sînt valori așteptate actualizate sub Q datorită absenței arbitrajului; pentru procesele continue, Girsanov schimbă doar driftul, iar Feynman–Kac transformă o valoare așteptată sub Q într-o PDE
- $(\mathrm{VIX}/100)^2$ este o valoare așteptată sub Q, afină în v_t
- În modelele estimate, salturile explică mai bine cozile, iar volatilitatea stochastică explică volatility clustering
- Volatilitatea este rough și persistentă, ceea ce modelele cu un factor nu pot reproduce
- Urmează Capitolul 12: evaluarea opțiunilor prin replicare și citirea suprafeței de volatilitate; cod și date: github.com/danpele/MFM/tree/main/Quantlets/Ch_11

Verificarea înțelegerii

- De ce apare un termen suplimentar la schimbarea de variabilă în calculul Itô? Explicați rolul variației pătratice. Revedeți explicația.
- Observarea mai frecventă a prețurilor face estimarea driftului precisă? Separați frecvența de lungimea perioadei observate. Revedeți explicația.
- Ce caracteristică a datelor cere salturi și ce caracteristică cere volatilitate stochastică? Folosiți comparația cu randamentele observate. Revedeți explicația.
- De ce poate probabilitatea folosită la evaluare să difere de probabilitatea reală? Precizați ce schimbă trecerea la altă măsură. Revedeți explicația.

De la Brown la Bachelier, Einstein și Wiener



Louis Bachelier (1870–1946)

Foto: autor necunoscut; domeniu public; Wikimedia Commons



Albert Einstein în 1905

Foto: Lucien Chavan / ETH Zürich (1905); domeniu public; Wikimedia Commons

- 1827: botanistul Robert Brown vede la microscop particule de polen mișcîndu-se în zigzag neregulat
- Bachelier (1900): prețurile obligațiunilor de stat franceze (rente) și ale opțiunilor pe ele urmează un mers aleator în timp continuu
  - Abaterea standard a prețurilor crește cu $\sqrt{t}$; rezultatul precede cu cinci ani explicația fizică
- Einstein (1905): ciocnirile moleculare explică mișcarea lui Brown; deplasarea pătratică medie este liniară în t
- Wiener (1923): mișcarea browniană ca măsură de probabilitate pe traiectorii continue, **procesul Wiener**

Înapoi

Itô, Samuelson, Black, Scholes și Merton



Kiyosi Itô (1915–2008)

Foto: Konrad Jacobs (1970); CC BY-SA 2.0 de; Wikimedia Commons



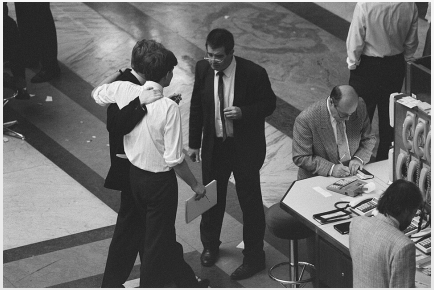
Paul A. Samuelson (1915–2009)

Foto: Bernard Gotfryd (1970–1975); domeniu public; Wikimedia Commons

- Itô (1944): integrala stochastică și regula ei de derivare, principalul instrument de lucru al capitolului
- Osborne (1959): logaritmii prețurilor, nu prețurile, se comportă ca mișcarea browniană; Samuelson (1965): mișcarea browniană geometrică
- Black & Scholes (1973) și Merton (1973): o opțiune poate fi replicată în timp continuu
- Merton (1976) adaugă salturi, Heston (1993) volatilitate aleatoare; prezentare în manual: Franke, Härdle & Hafner (2019), Partea I

Înapoi

Un crah în imagini, Amsterdam 1987



Bursa din Amsterdam, 21 octombrie 1987, după crahul din 19 octombrie

Foto: Bart Molendijk / Anefo (1987); CC0; Wikimedia Commons

- Scăderea din 19 octombrie 1987 (Secțiunea 9): 22,6% într-o zi
- Sub o distribuție Normală, o asemenea zi nu ar fi de așteptat nici măcar o dată în vîrsta universului: prețurile prezintă salturi, iar modelele continue au nevoie de salturi sau de inovații cu cozi groase

Înapoi

Curățarea datelor și condiții tehnice

- Date: indicii bursieri în zilele lucrătoare, fără cotațiile stale (închidere neschimbată și nicio variație în cursul zilei, maxim = minim), cu randamentele zero reale păstrate; Bitcoin 7 zile din 7
- Integrala Itô: sumele cu capătul stîng converg pentru integranzi regulați (de exemplu, continui și adaptați); un H general se obține prin aproximare cu procese simple
  - Dacă doar $\int_0^T H_t^2 \,\mathrm{d}t < \infty$ aproape sigur, $\int H \,\mathrm{d}W$ este doar o martingală locală, iar media ei poate fi nenulă
- SDE: existența și unicitatea unei soluții tari dacă a și b sînt lipschitziene în x, cu creștere cel mult liniară Kloeden & Platen (1992)
  - Coeficienții de tip radical (CIR, Heston) nu sînt lipschitzieni în zero, dar au soluții tari unice (condițiile Yamada–Watanabe)
- Donsker: convergență în distribuție în spațiul traiectoriilor càdlàg, cu topologia Skorokhod Billingsley (1999)

Înapoi

Rata pe termen scurt, cifre suplimentare

- DTB3, 1954–2026: rata a variat între $-0{,}05\%$ (2020-03-26) și 17,1% (1980-12-11), iar 4,3% din zile au fost sub 0,05%
  - Modelul Vasicek estimat dă o probabilitate pe termen lung de 6,1% pentru o rată negativă
  - În 2008–2026 apar 13 cotații exact zero și 8 negative, în afara domeniului verosimilităților CIR și CKLS
  - În această perioadă, 17% din zile formează un regim aproape de zero, sub 0,05%
- Testele CKLS pentru γ, 1954–2007, Wald HAC cu 11 (zilnic) și 6 (lunar) laguri
  - $\gamma = 0$ este respins: statistica Wald este 545 pe date zilnice și 16 pe date lunare
  - $\gamma = 1/2$ este respins pe date zilnice (statistica 67,0, respectiv 22,1 cu 55 de laguri), dar nu și pe date lunare (0,5, față de valoarea critică 3,84)
  - Testul LR gaussian respinge $\gamma = 1/2$ și pe date lunare (statistica 10,1), dar ignoră volatility clustering
  - Chan, Karolyi, Longstaff & Sanders (1992) au găsit $\hat{\gamma} \approx 1{,}5$ pentru 1964–1989

Înapoi

Randamentul Vasicek și rata observată

- Obligațiunea Vasicek cu estimările din Secțiunea 6, $\lambda = 0$ și $r = 3{,}99\%$ are un randament pe 10 ani de 4,05%
- Randamentul observat al titlurilor de stat pe 10 ani (seria FRED DGS10) pe 2026-09-18: 5,01%
  - Întîi convențiile: DGS10 este un randament la paritate cu cupon semestrial, $2\ln(1 + 5{,}01\%/2) = 4{,}95\%$ cu compunere continuă; DTB3 este o rată de discont pe 91 de zile, 3,99% înseamnă 4,07% cu compunere continuă și ridică randamentul modelului la 4,10%
  - Diferența scade doar de la 0,96 la 0,85 puncte procentuale (diferența dintre randamentul la paritate și cel zero-cupon nu este ajustată): nu este un efect al convenției de cotare, ci o primă de termen ($\lambda \neq 0$; pentru a o reproduce este nevoie de $\theta^Q > \hat{\theta}$, adică $\lambda < 0$) plus specificare greșită
- Estimarea neparametrică: Stanton (1997) estimează și prețul de piață al riscului de dobîndă; testul de specificare: Aït-Sahalia (1996)

Înapoi

Corecția VIX în funcție de κ^Q și comparația completă a modelelor

κ^Q	1	2,5	5	10
b	0,96	0,90	0,82	0,68
Corecție locală $\hat{\xi}/b$	0,58	0,62	0,68	0,82

	Date	GBM	Merton	Heston
Exces de kurtosis	10,88	0,00	3,66	3,30
Asimetrie	−0,36	0,00	−0,32	0,00†
Statistica Hill	2,56	4,64	2,70	2,95
ACF a lui $\lvert r\rvert$, lagul 1	0,27	0,00	0,00	0,28
ACF a lui $\lvert r\rvert$, suma lagurilor 1–20	5,32	0,00	0,00	4,78

- Corecția $\hat{\xi}/b$ este exactă doar la $v_t = \theta^Q$; coloanele modelelor sînt mediane din 100 de simulări
- Statistica Hill a datelor este 2,97 pentru $k = 2{,}5\%$ din randamente, 2,56 pentru 5% și 2,04 pentru 10%; este un tail index doar sub variație regulată (coadă de tip Pareto)
- Un model Heston cu un raport Feller mai mic ar putea atinge excesul de kurtosis: excesul pe orizont scurt $\approx 3\xi^2/(2\kappa\theta)$
- † Pas Euler zilnic: zero prin construcție; în timp continuu, Heston dă circa −0,20 (Secțiunea 11)

înapoi

Procese stocastice: lecturi suplimentare

- Cozi mai grele: procesele Lévy și distribuțiile α-stabile Pele (2014)
  - Cripto-activele formează o clasă distinctă după forma distribuțiilor randamentelor Pele et al. (2023)
  - Informația de înaltă frecvență despre volatilitatea și tail risk-ul Bitcoin Pele & Mazurencu-Marinescu-Pele (2019)
- Calcul stochastic: Shreve (2004), cap. 5–6 din carte; Franke, Härdle & Hafner (2019), capitolele despre procesul Wiener și integrarea stochastică
- Exerciții rezolvate pentru toate modelele din acest capitol: Borak, Härdle & López-Cabrera (2013); modelul Heston: Čížek, Härdle & Weron (2011); aplicații: Härdle, Chen & Overbeck (2017)
- Metode Monte Carlo: Glasserman (2003); SDE numerice: Kloeden & Platen (1992)

înapoi

Pierderile de prognoză și modelele de memorie

- **MSE**: Mean Squared Error — eroarea pătratică medie. MSE compară prognoza cu valoarea realizată prin pătratul erorii; o eroare dublă contribuie de patru ori mai mult.
- **QLIKE**: Quasi-LIKElihood (loss function) — funcția de pierdere de tip cvasi-verosimilitate. QLIKE evaluează prognozele pozitive de variantă printr-o pierdere relativă: aceeași eroare în puncte poate conta diferit la niveluri mici și mari.
- **ARMA**: AutoRegressive Moving Average (model) — model autoregresiv cu medie mobilă. ARMA combină valorile trecute ale seriei cu șocurile trecute; este reperul de memorie scurtă din comparație.
- **ARFIMA**: AutoRegressive Fractionally Integrated Moving Average (model) — model autoregresiv cu medie mobilă, integrat fracționar. ARFIMA adaugă integrarea fracționară: comparația verifică dacă persistența de durată îmbunătățește prognoza.

Înapoi

Studiul de caz, model, date și metodă (1/2)

- **Modelul**: $\sigma_t = \xi e^{X_t}$ (ec. (1.3)), $X_t = \int_{-\infty}^{t} g(t-s)\, v_s \, \mathrm{d}W_s$, un proces brownian semistaționar (BSS) cu nucleul g și procesul de volatilitate a volatilității v_s (ec. (1.5)). Prognozele iau $v_s \equiv 1$, deci un X gaussian (Secțiunea 5)
  - Nucleul gamma $g(x) = x^{\alpha} e^{-\lambda x}$ (Exemplul 1.2) dă roughness-ul α și memorie scurtă, cu scădere exponențială în ritmul λ
  - Nucleul de tip putere $g(x) = x^{\alpha}(1+x)^{-\gamma-\alpha}$ (ec. (1.8)): $\beta = \gamma$ dacă $\gamma > 1$, $\beta = 2\gamma - 1$ dacă $\gamma \in (1/2, 1)$ (Observația 1.2)
  - Procesul BSS cu acest nucleu este modelul Power-BSS
- Alternativa gaussiană: clasa Cauchy (Secțiunea 1.1.1)
  - $\rho(h) = (1 + |h|^{2\alpha+1})^{-\beta/(2\alpha+1)}$: roughness-ul α și memoria β sînt fixate separat

înapoi

Studiul de caz, model, date și metodă (2/2)

- **Pasul 1**: estimăm α din variograma $\hat{\gamma}_{\mathbf{2}}(k)$ pentru $\log \hat{\sigma}$, prin regresia OLS a lui $\log \hat{\gamma}_{\mathbf{2}}(k)$ în funcție de $\log k$, $k = 1, \ldots, 6$, $\hat{\alpha} = (\hat{a}_{\mathbf{1}} - 1)/2$ (ec. (2.1))
  - NLLS robust la zgomot: $\hat{\gamma}_{\mathbf{2}}(k) = b_{\mathbf{0}} + b_{\mathbf{1}}(k\Delta)^{\mathbf{2}\alpha+\mathbf{1}}$, unde termenul liber surprinde zgomotul de măsurare
  - Calculăm media estimărilor obținute pentru $m = 10, \ldots, 20$ laguri (Secțiunile 2.1 și 3.1)
  - **Pasul 2**: β, γ sau λ prin ajustarea ACF a modelului la cea empirică pe primele $\lceil n^{\mathbf{1}/\mathbf{3}} \rceil$ laguri (Secțiunile 2.2 și 4.1)
- **Date**: tranzacțiile cu contractul futures E-mini S&P 500, 2011–2014 (996 de zile), 09:30–16:00 ora New York
- $\hat{\sigma}_t^{\mathbf{2}}$ este variația bipower cu pre-averaging pe intervalul Δ, împărțită la Δ, pentru Δ de la 10 minute la o zi (Secțiunile 4 și 4.1)
  - Sezonalitatea intrazilnică este eliminată cu forma Fourier flexibilă propusă de Andersen & Bollerslev (1997)
  - Date zilnice pentru 1 944 de acțiuni americane lichide, 2003–2013 (Secțiunile 4.1 și 4.2)
- **Prognoze**: varianța însumată pe următorii $h = 1, 2, 5, 10, 20$ pași, estimată pe o fereastră mobilă de 200 de observații; perioada din afara eșantionului: 2 ianuarie 2013 – 31 decembrie 2014 (Secțiunea 5.1.1)
  - Modele de referință: mersul aleator, AR(5), AR(10), ARMA(1,1), log-HAR (model autoregresiv heterogen pentru logaritmul volatilității) Corsi (2009), ARFIMA(0,d,0), RFSV
  - Pierderile MSE și QLIKE și model confidence sets (MCS) de 90% și 75% Hansen, Lunde & Nason (2011), definite pe slide-ul următor

Înapoi

Studiul de caz, estimatori și pierderi de prognoză

- **Variograma** $\hat{\gamma}_{\mathbf{2}}(k)$ a lui $x_t = \log \hat{\sigma}_t$ (definită la replicarea pe SPY din textul principal). Pentru k mic, $\gamma_{\mathbf{2}}(k) \approx c\, k^{\mathbf{2}\alpha+\mathbf{1}}$ (Secțiunea 2.1)
  - **Variația bipower** a celor M randamente r_j dintr-un interval: $\mathrm{BV} = \frac{\pi}{\mathbf{2}} \sum_{j=\mathbf{2}}^{M} |r_j|\,|r_{j-\mathbf{1}}|$, robustă la salturi Barndorff-Nielsen & Shephard (2004)
  - Unele texte, și Seminarul 11, C3, înmulțesc BV cu $M/(M-1)$: aceasta deplasează x_t cu constanta $\frac{\mathbf{1}}{\mathbf{2}} \ln(78/77) \approx 0{,}006$ pentru $M = 78$, care se anulează în $\hat{\gamma}_{\mathbf{2}}(k)$ și în ACF
  - Pre-averaging: randamentele sînt întîi mediate pe ferestre scurte, pentru a atenua zgomotul de microstructură (Anexa A a lucrării)
- **Obiectul prognozei**: $\mathrm{FO}_t(\Delta, h) = \sum_{k=\mathbf{1}}^{h} \mathrm{BV}_{t+k\Delta}$ (ec. (5.3)). Pentru un model gaussian în logaritmi, $\mathbb{E}[e^{X_{t+\Delta}} \mid \mathcal{F}_t] = \exp(m + s^{\mathbf{2}}/2)$, cu m, $s^{\mathbf{2}}$ media și dispersia condiționate (ec. (5.2))
  - Pierderile pe originile din afara eșantionului: $\mathrm{MSE} = \mathrm{media}\,(\widehat{\mathrm{FO}}_t - \mathrm{FO}_t)^{\mathbf{2}}$, $\mathrm{QLIKE} = \mathrm{media}\,(\log \widehat{\mathrm{FO}}_t + \mathrm{FO}_t / \widehat{\mathrm{FO}}_t)$ (Secțiunea 5.1.1)
- **Model confidence set** (MCS) Hansen, Lunde & Nason (2011): o mulțime de modele care conține cel mai bun model cu probabilitatea 90% (sau 75%)
  - Apartenența nu este un clasament: modelele din MCS nu pot fi deosebite la acel nivel

înapoi

Studiul de caz, rezultatele din lucrare

$\log\sigma$, E-mini S&P 500 (Tabelul 3, Panoul A)	$\hat{\alpha}_{\text{OLS}}$	$\hat{\alpha}^*_{\text{NLLS}}$	$\hat{\beta}^*_{\text{Cauchy}}$	$\hat{\lambda}^*_{\text{Gamma}}$
$\Delta = 10$ minute	$-0{,}38$	$-0{,}38$	0,18	0,02
$\Delta = 65$ de minute	$-0{,}30$	$-0{,}35$	0,18	0,02
$\Delta = 1$ zi	$-0{,}30$	$-0{,}33$	0,18	0,02

- Volatilitatea este rough la orice scară ($\hat{\alpha} < 0$, mult mai rough decît mișcarea browniană, $\alpha = 0$) și persistentă ($\hat{\beta}^* < 1$): memorie lungă împreună cu roughness. * indică estimatorii robuști la zgomot; comparația cu SPY este în textul principal
  - Pe 1 944 de acțiuni americane, $\hat{\alpha}^*$ este în general între $-0{,}45$ și $-0{,}30$, iar $\hat{\beta}^*$ între 0 și 0,4, fără diferențe sistematice între sectoare (Figurile 4 și 5): ambele trăsături par universale
- Zgomotul poate imita roughness-ul: un $\alpha = 0$ simulat, observat cu raportul zgomot/semnal 0,3 la $\Delta = 0{,}1$, dă o estimare OLS medie de $-0{,}47$, dar o estimare NLLS medie de 0,01 (Tabelul 1, Panoul C)
- Prognozele: modelarea persistenței îmbunătățește prognozele intrazilnice și pe orizonturi lungi
  - La pași de 15 minute și $h = 20$, MSE ($\times 10^8$) este 0,038 pentru log-HAR, 0,020 pentru RFSV și 0,019 pentru Power-BSS (Tabelul 4, Panoul A)
  - La pași zilnici și $h = 1$, RFSV este cel mai bun: 0,493 ($\times 10^9$) (Tabelul 5, Panoul B)

Înapoi

Studiul de caz, aplicație intrazilnică, limite și întrebări deschise (1/2)

- **Aplicație intrazilnică** (ilustrativă, nu o replicare exactă) pe barele SPY de 5 minute din datele cursului
  - $\hat{\sigma}_t^2$ este variația bipower a randamentelor la 5 minute din fiecare interval $\Delta = 30$ sau 65 de minute
  - Aceasta este împărțită la Δ și la factorul sezonier Fourier flexibil Andersen & Bollerslev (1997)
  - Comparăm $\hat{\alpha}$ OLS și NLLS, $\hat{\beta}^*$ Cauchy și $\hat{\lambda}^*$ Gamma-BSS cu Tabelul 3, Panoul A
  - Comparăm prognozele log-HAR, RFSV și BSS (pierderile MSE, QLIKE și MCS) cu Tabelul 5
  - Limită a datelor: bare agregate, nu fiecare tranzacție, deci estimatorul cu pre-averaging (Anexa A a lucrării) nu poate fi calculat, iar zgomotul este mai mare
  - Un interval de 65 de minute conține doar 13 randamente

Înapoi

Studiul de caz, aplicație intrazilnică, limite și întrebări deschise (2/2)

- **Limitele menționate de autori**
  - Măsurile realizate sînt estimări cu zgomot ale variației integrate: concluziile privesc aceste măsuri, nu volatilitatea instantanee latentă (Secțiunile 4.1, 4.2 și 6)
  - Nu există o regulă pentru lățimea de bandă m a NLLS (Secțiunile 2.1 și 3.1)
  - NLLS este prea costisitor pentru prognozele pe fereastră mobilă, care folosesc $\hat{\alpha}$ OLS (Secțiunea 5.1.1)
  - Prognozele presupun un X gaussian, iar o volatilitate a volatilității negaussiană rămîne în afara lucrării (Secțiunea 5, nota 3)
- **Întrebare deschisă**: de ce îmbunătățește memoria lungă chiar și prognozele pe termen scurt? Autorii lasă întrebarea pentru cercetări viitoare (Secțiunea 5.1.2)
  - Estimările $\hat{\alpha}$ pe ferestre mobile (65 de minute, 2005–2014, mediana $-0{,}36$) indică o volatilitate mai puțin rough în 2007–2008 și 2011 (Figura 3)
  - $\hat{\alpha}$ crește cu logaritmul volumului, cu panta 0,0091 (Figura 6)
  - Se încadrează Bitcoin (barele de 5 minute), o piață care nu se închide niciodată, în acest tipar?

Înapoi

Bucla descoperirii, prompturi reutilizabile (1/2)

- Instrumente: un asistent AI (un LLM precum Claude, ChatGPT, Gemini sau GitHub Copilot); căutarea literaturii: Semantic Scholar, Elicit, Google Scholar
- **1. Literatura**: grupăm estimările într-un tabel după frecvență, apoi verificăm fiecare DOI pe Crossref (titlul trebuie să coincidă)
  - `Prezintă într-un tabel estimările publicate ale ponderii salturilor în varianța indicilor bursieri, după frecvența de eșantionare (zilnic, 5 minute, tranzacție cu tranzacție) și metodă; dă cifra exactă, tabelul din care provine și DOI-ul.`
- **2. Ipoteze concurente**, cu implicații testabile distincte
  - `Pentru trei procese care dau un exces de kurtosis zilnic în jur de 11 (salturi Merton, volatilitate Heston, drift bursts), derivează implicațiile pentru randamentele standardizate cu volatilitatea ex ante, pentru variația bipower față de varianța realizată și pentru drift chiar înaintea mișcărilor extreme.`
- **3. Date și cod**: replicăm întîi estimarea din capitol
  - `Scrie cod Python care citește închiderile zilnice S&P 500 din datele cursului și estimează modelul Merton prin verosimilitate maximă (mixtură Poisson trunchiată la 12 salturi, mai multe puncte de start).` Ținta: $\hat{\lambda} = 102$ pe an, ponderea salturilor 71%

Înapoi

Bucla descoperirii, prompturi reutilizabile (2/2)

- **4. Robustețe**, pre-înregistrată
  - `Scrie un plan pre-înregistrat: standardizăm randamentele cu volatilitatea EWMA și GARCH cunoscută la t-1; împărțim 1990-2007 și 2008-2026; testăm Heston (fără salturi, ipoteza nulă) față de Bates (SVJ); valorile critice LR prin bootstrap parametric sub ipoteza nulă Heston.`
- **5. Critica**: cerem asistentului să conteste inferența
  - `Joacă rolul unui recenzent: de ce testul LR pentru lambda = 0 este nestandard, care este distribuția de referință corectă și ar putea o mixtură Poisson cu salturi mici și frecvente să fie doar o inovație cu cozi groase?`
- **6. Raportul**: toate frecvențele și filtrele, valorile critice bootstrap, codul și jurnalul AI

Înapoi

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- Applied Computational Finance
- XFG Advanced Methods in Quantitative Finance

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_11

Înapoi

Acronime folosite în acest material (1/3)

- **ACF**: AutoCorrelation Function — *funcția de autocorelație*
- **AI**: Artificial Intelligence — *inteligență artificială*
- **AR**: AutoRegressive model — *model autoregresiv*
- **ARFIMA**: AutoRegressive Fractionally Integrated Moving Average (model) — *model autoregresiv cu medie mobilă, integrat fracționar*
- **ARMA**: AutoRegressive Moving Average (model) — *model autoregresiv cu medie mobilă*
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BSS**: Brownian SemiStationary (process) — *procesul brownian semistaționar*
- **BVB**: Bursa de Valori București
- **CBOE**: Chicago Board Options Exchange — *bursa de opțiuni din Chicago*
- **CI**: Confidence Interval — *interval de încredere*
- **CIR**: Cox–Ingersoll–Ross (model) — *modelul Cox–Ingersoll–Ross al ratei dobînzii*
- **CKLS**: Chan–Karolyi–Longstaff–Sanders (model) — *modelul Chan–Karolyi–Longstaff–Sanders al ratei dobînzii*
- **CLT**: Central Limit Theorem — *teorema limită centrală*
- **DGS10**: 10-Year Treasury Constant Maturity Rate (FRED series code) — *randamentul titlurilor de stat americane cu scadența constantă de 10 ani (codul seriei FRED)*

Acronime folosite în acest material (2/3)

- **DTB3**: 3-Month Treasury Bill: secondary market rate (FRED series code) — *randamentul titlurilor de stat americane pe 3 luni pe piața secundară (codul seriei FRED)*
- **FRED**: Federal Reserve Economic Data — *baza de date economice a Rezervei Federale (St. Louis)*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GBM**: Geometric Brownian Motion — *mișcarea browniană geometrică*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **JB**: Jarque–Bera (test) — *testul de normalitate Jarque–Bera*
- **LLM**: Large Language Model — *model lingvistic mare*
- **LR**: Likelihood Ratio (test) — *testul raportului de verosimilitate*
- **MCS**: Model Confidence Set — *mulțimea de încredere a modelelor*
- **MLE**: Maximum Likelihood Estimation — *estimarea prin metoda verosimilității maxime*

Acronime folosite în acest material (3/3)

- **MSE**: Mean Squared Error — *eroarea pătratică medie*
- **NLLS**: Non-Linear Least Squares — *metoda celor mai mici pătrate neliniare*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **OU**: Ornstein–Uhlenbeck (process) — *procesul Ornstein–Uhlenbeck*
- **PDE**: Partial Differential Equation — *ecuație cu derivate parțiale*
- **QLIKE**: Quasi-LIKElihood (loss function) — *funcția de pierdere de tip cvasi-verosimilitate*
- **QQ**: Quantile–Quantile (plot) — *graficul cuantilă–cuantilă*
- **RFSV**: Rough Fractional Stochastic Volatility (model) — *modelul de volatilitate stochastică fracționară rugoasă*
- **SDE**: Stochastic Differential Equation — *ecuație diferențială stochastică*
- **SUA**: Statele Unite ale Americii
- **SVJ**: Stochastic Volatility with Jumps (model) — *model cu volatilitate stochastică și salturi*
- **VIX**: Cboe Volatility Index — *indicele de volatilitate CBOE*
- **XFG**: Quantlet prefix of Applied Quantitative Finance (Härdle, Chen & Overbeck) — *prefixul Quantlet-urilor din Applied Quantitative Finance (Härdle, Chen & Overbeck)*

Bibliografie (1/5)

- Aït-Sahalia, Y. (1996). Testing continuous-time models of the spot interest rate. *Review of Financial Studies*, 9(2), 385–426.
- Aït-Sahalia, Y. (2002). Maximum likelihood estimation of discretely sampled diffusions: a closed-form approximation approach. *Econometrica*, 70(1), 223–262.
- Andersen, L. (2008). Simple and efficient simulation of the Heston stochastic volatility model. *Journal of Computational Finance*, 11(3), 1–42.
- Andersen, T.G., Benzoni, L., Lund, J. (2002). An empirical investigation of continuous-time equity return models. *Journal of Finance*, 57(3), 1239–1284.
- Andersen, T.G., Bollerslev, T. (1997). Intraday periodicity and volatility persistence in financial markets. *Journal of Empirical Finance*, 4(2–3), 115–158.
- Bachelier, L. (1900). Théorie de la spéculation. *Annales scientifiques de l'École Normale Supérieure*, 17, 21–86.
- Bandi, F.M., Phillips, P.C.B. (2003). Fully nonparametric estimation of scalar diffusion models. *Econometrica*, 71(1), 241–283.
- Barndorff-Nielsen, O.E., Shephard, N. (2004). Power and bipower variation with stochastic volatility and jumps. *Journal of Financial Econometrics*, 2(1), 1–37.
- Bates, D.S. (1996). Jumps and stochastic volatility: exchange rate processes implicit in Deutsche Mark options. *Review of Financial Studies*, 9(1), 69–107.
- Bennedsen, M., Lunde, A., Pakkanen, M.S. (2022). Decoupling the short- and long-term behavior of stochastic volatility. *Journal of Financial Econometrics*, 20(5), 961–1006.
- Billingsley, P. (1999). Convergence of Probability Measures, 2nd ed. Wiley.
- Black, F., Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 637–654.
- Bollerslev, T., Zhou, H. (2002). Estimating stochastic volatility diffusion using conditional moments of integrated volatility. *Journal of Econometrics*, 109(1), 33–65.

Bibliografie (2/5)

- Borak, S., Härdle, W.K., López-Cabrera, B. (2013). Statistics of Financial Markets: Exercises and Solutions, 2nd ed. Springer.
- Chan, K.C., Karolyi, G.A., Longstaff, F.A., Sanders, A.B. (1992). An empirical comparison of alternative models of the short-term interest rate. *Journal of Finance*, 47(3), 1209–1227.
- Chernov, M., Ghysels, E. (2000). A study towards a unified approach to the joint estimation of objective and risk neutral measures for the purpose of options valuation. *Journal of Financial Economics*, 56(3), 407–458.
- Christensen, K., Oomen, R.C.A., Podolskij, M. (2014). Fact or friction: jumps at ultra high frequency. *Journal of Financial Economics*, 114(3), 576–599.
- Christensen, K., Oomen, R.C.A., Renò, R. (2022). The drift burst hypothesis. *Journal of Econometrics*, 227(2), 461–497.
- Čížek, P., Härdle, W.K., Weron, R. (Eds.) (2011). Statistical Tools for Finance and Insurance, 2nd ed. Springer.
- Comte, F., Renault, E. (1998). Long memory in continuous-time stochastic volatility models. *Mathematical Finance*, 8(4), 291–323.
- Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- Cox, J.C., Ingersoll, J.E., Ross, S.A. (1985). A theory of the term structure of interest rates. *Econometrica*, 53(2), 385–407.
- Duffie, D., Pan, J., Singleton, K. (2000). Transform analysis and asset pricing for affine jump-diffusions. *Econometrica*, 68(6), 1343–1376.
- Einstein, A. (1905). Über die von der molekularkinetischen Theorie der Wärme geforderte Bewegung von in ruhenden Flüssigkeiten suspendierten Teilchen. *Annalen der Physik*, 322(8), 549–560.
- Eraker, B., Johannes, M., Polson, N. (2003). The impact of jumps in volatility and returns. *Journal of Finance*, 58(3), 1269–1300.

Bibliografie (3/5)

- Feller, W. (1951). Two singular diffusion problems. *Annals of Mathematics*, 54(1), 173–182.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, 5th ed. Springer.
- Gatheral, J., Jaisson, T., Rosenbaum, M. (2018). Volatility is rough. *Quantitative Finance*, 18(6), 933–949.
- Girsanov, I.V. (1960). On transforming a certain class of stochastic processes by absolutely continuous substitution of measures. *Theory of Probability and Its Applications*, 5(3), 285–301.
- Glasserman, P. (2003). Monte Carlo Methods in Financial Engineering. Springer.
- Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). Applied Quantitative Finance, 3rd ed. Springer.
- Heston, S.L. (1993). A closed-form solution for options with stochastic volatility with applications to bond and currency options. *Review of Financial Studies*, 6(2), 327–343.
- Higham, D.J. (2001). An algorithmic introduction to numerical simulation of stochastic differential equations. *SIAM Review*, 43(3), 525–546.
- Honoré, P. (1998). Pitfalls in estimating jump-diffusion models. Working paper, SSRN.
- Itô, K. (1944). Stochastic integral. *Proceedings of the Imperial Academy*, 20(8), 519–524.
- Kac, M. (1949). On distributions of certain Wiener functionals. *Transactions of the American Mathematical Society*, 65(1), 1–13.
- Kloeden, P.E., Platen, E. (1992). Numerical Solution of Stochastic Differential Equations. Springer.

Bibliografie (4/5)

- Lee, S.S., Mykland, P.A. (2008). Jumps in financial markets: a new nonparametric test and jump dynamics. *Review of Financial Studies*, 21(6), 2535–2563.
- Lord, R., Koekkoek, R., van Dijk, D. (2010). A comparison of biased simulation schemes for stochastic volatility models. *Quantitative Finance*, 10(2), 177–194.
- Merton, R.C. (1973). Theory of rational option pricing. *Bell Journal of Economics and Management Science*, 4(1), 141–183.
- Merton, R.C. (1976). Option pricing when underlying stock returns are discontinuous. *Journal of Financial Economics*, 3(1–2), 125–144.
- Milstein, G.N. (1975). Approximate integration of stochastic differential equations. *Theory of Probability and Its Applications*, 19(3), 557–562.
- Nelson, D.B. (1990). ARCH models as diffusion approximations. *Journal of Econometrics*, 45(1–2), 7–38.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Osborne, M.F.M. (1959). Brownian motion in the stock market. *Operations Research*, 7(2), 145–173.
- Pele, D.T. (2014). A SAS approach for estimating the parameters of an alpha-stable distribution. *Procedia Economics and Finance*, 10, 68–77.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). Using high-frequency entropy to forecast Bitcoin's daily value at risk. *Entropy*, 21(2), 102.
- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *European Journal of Finance*, 29(10), 1064–1105.
- Pritsker, M. (1998). Nonparametric density estimation and tests of continuous time interest rate models. *Review of Financial Studies*, 11(3), 449–487.
- Samuelson, P.A. (1965). Rational theory of warrant pricing. *Industrial Management Review*, 6(2), 13–39; reprinted in *Henry P. McKean Jr. Selecta* (2015), Birkhäuser.

Bibliografie (5/5)

- Shreve, S.E. (2004). Stochastic Calculus for Finance II: Continuous-Time Models. Springer.
- Stanton, R. (1997). A nonparametric model of term structure dynamics and the market price of interest rate risk. *Journal of Finance*, 52(5), 1973–2002.
- Tang, C.Y., Chen, S.X. (2009). Parameter estimation and bias correction for diffusion processes. *Journal of Econometrics*, 149(1), 65–81.
- Uhlenbeck, G.E., Ornstein, L.S. (1930). On the theory of the Brownian motion. *Physical Review*, 36(5), 823–841.
- Vasicek, O. (1977). An equilibrium characterization of the term structure. *Journal of Financial Economics*, 5(2), 177–188.
- Wang, Y. (2002). Asymptotic nonequivalence of GARCH models and diffusions. *Annals of Statistics*, 30(3), 754–783.
- Wiener, N. (1923). Differential-space. *Journal of Mathematics and Physics*, 2(1–4), 131–174.
- Yu, J. (2012). Bias in the estimation of the mean reversion parameter in continuous time models. *Journal of Econometrics*, 169(1), 114–122.