



Modelarea piețelor financiare

Capitolul 13: Machine Learning în finanțe



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/3)

- ▣ ADF: Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- ▣ CAPM: Capital Asset Pricing Model (modelul de evaluare a activelor financiare)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ CMA: Conservative Minus Aggressive (investment factor) (factorul investiții: firme conservatoare minus agresive)
- ▣ CPCV: Combinatorial Purged Cross-Validation (validare încrucișată combinatorie cu purjare)
- ▣ CRSP: Center for Research in Security Prices (Centrul de cercetare a prețurilor titlurilor (Universitatea din Chicago))
- ▣ CSCV: Combinatorially Symmetric Cross-Validation (validare încrucișată combinatorie simetrică)
- ▣ CV: Cross-Validation (validare încrucișată)
- ▣ CW: Clark–West (test for nested models) (testul Clark–West pentru modele imbricate)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ DML: Double/Debiased Machine Learning (machine learning dublu (fără distorsiune))
- ▣ DSR: Deflated Sharpe Ratio (raportul Sharpe deflatat)
- ▣ ELW: Exact Local Whittle (estimator) (estimatorul local Whittle exact)
- ▣ ES: Expected Shortfall (pierderea așteptată în coadă)
- ▣ EU: European Union (Uniunea Europeană)
- ▣ EV: Explained Variation (variația explicată)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ FDR: False Discovery Rate (rata descoperirilor false)
- ▣ FF3: Fama–French three-factor model (modelul Fama–French cu trei factori)
- ▣ FF5: Fama–French five-factor model (modelul Fama–French cu cinci factori)
- ▣ FFD: Fixed-width window Fractional Differentiation (diferențiere fracționară cu fereastră fixă)

Acronime folosite în acest material (2/3)

- FFN: FeedForward Network (rețea neuronală feedforward (fără bucle))
- FN: False Negative (fals negativ)
- FRED-MD: Federal Reserve Economic Data, Monthly Database (McCracken–Ng) (baza lunară de date macroeconomice a Rezervei Federale din St. Louis)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- GAN: Generative Adversarial Network (rețea generativă adversarială)
- GBM: Gradient Boosting Machine (model de boosting pe gradient)
- GRS: Gibbons–Ross–Shanken (test) (testul Gibbons–Ross–Shanken)
- GRU: Gated Recurrent Unit (unitate recurentă cu porți)
- GW: Giacomini–White (test) (testul Giacomini–White)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HML: High Minus Low (value factor) (factorul valoare: B/M mare minus mic)
- IBM: International Business Machines (Corporation) (compania International Business Machines)
- IS: In-Sample (în eșantion)
- LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- LIME: Local Interpretable Model-agnostic Explanations (explicații locale interpretabile, independente de model)
- LLM: Large Language Model (model lingvistic mare)
- LS: Linear SDF estimated by unregularised Least Squares (SDF liniar estimat prin cele mai mici pătrate, fără regularizare)
- LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- MA: Moving Average (medie mobilă)
- MDA: Mean Decrease Accuracy (scăderea medie a acurateței (importanța prin permutare))
- MDI: Mean Decrease Impurity (scăderea medie a impurității)
- ML: Machine Learning (învățare automată)
- MLP: MultiLayer Perceptron (perceptron multistrat)
- MSCA: Marie Skłodowska-Curie Actions (programul european Acțiunile Marie Skłodowska-Curie)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- OOB: Out-Of-Bag (error) (eroarea pe observațiile din afara eșantionului bootstrap)

Acronime folosite în acest material (3/3)

- OOS: Out-Of-Sample (în afara eșantionului)
- PAC: Probably Approximately Correct (learning) (învățare probabil aproximativ corectă)
- PBO: Probability of Backtest Overfitting (probabilitatea de supraajustare a backtest-ului)
- PCR: Principal Component Regression (regresia pe componente principale)
- PLS: Partial Least Squares (regresia prin cele mai mici pătrate parțiale)
- PSR: Probabilistic Sharpe Ratio (raportul Sharpe probabilistic)
- PT: Pesaran–Timmermann (test of directional accuracy) (testul Pesaran–Timmermann al acurateții direcționale)
- RC: Reality Check (White's test for data snooping) (testul Reality Check al lui White pentru data snooping)
- RF: Random Forest (pădure aleatoare)
- RL: Reinforcement Learning (învățare prin recompensă)
- RMW: Robust Minus Weak (profitability factor) (factorul profitabilitate: firme robuste minus slabe)
- ROC: Receiver Operating Characteristic (curve) (curba caracteristică de operare)
- RSI: Relative Strength Index (indicele puterii relative)
- SD: Standard Deviation (abatere standard)
- SDF: Stochastic Discount Factor (factorul stochastic de actualizare)
- SE: Standard Error (eroare standard)
- SHAP: SHapley Additive exPlanations (explicații aditive Shapley)
- SPA: Superior Predictive Ability (test) (testul abilității predictive superioare)
- SR: Sharpe Ratio (raportul Sharpe)
- TN: True Negative (adevărat negativ)
- TP: True Positive (adevărat pozitiv)
- VAE: Variational AutoEncoder (autoencoder variațional)
- VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)
- WF: Walk-Forward (validation) (validare progresivă în timp)
- XAI: eXplainable Artificial Intelligence (inteligență artificială explicabilă)

Cuprins

Motivație

Metode de machine learning: recapitulare

Măsurarea și testarea abilității predictive

Date financiare și caracteristici

Etichetare

Validarea încrucișată în finanțe

Studiu de caz: S&P 500

Supraajustarea backtestului

Machine learning pentru inferență

Direcții noi

Studiu de caz: deep learning în evaluarea activelor

AI pentru descoperire științifică

Bune practici și concluzii

De ce machine learning în finanțe?

Promisiunea machine learning (ML)

- ▣ Forme funcționale flexibile, neliniare
- ▣ Sute de predictorii candidați ("grădina zoologică" a factorilor, Capitolul 3)
- ▣ Interacțiuni descoperite automat
- ▣ Date alternative: text, imagini, registre de ordine, date on-chain

Problema

- ▣ **Raport semnal-zgomot** foarte mic
- ▣ **Nestaționaritate**: regimuri, rupturi structurale
- ▣ Piețele **se adaptează**: semnalele dispar odată exploatare
- ▣ Puține observații independente
- ▣ Risc uriaș de **supraajustare** (ajustarea zgomotului)

Mesajul-cheie al capitolului

- ▣ În finanțe, partea dificilă nu este estimarea unui model, ci **să nu te păcălești singur**: etichete corecte, validare corectă, backtesturi oneste


Finanțele nu sunt recunoaștere de imagini

	Domeniu ML tipic	Piețe financiare
Semnal/zgomot	ridicat (o pisică e o pisică)	extrem de scăzut
Procesul generator	stabil	se schimbă în timp, reacționează la utilizatori
Volumul eșantionului	milioane de exemple i.i.d.	o singură istorie, dependentă serial
Etichete	date de oameni	trebuie construite
Costul erorii	clasificare greșită	bani reali, efect de levier, faliment
Experimentare	se pot genera date noi	istoria nu poate fi rejucată

Ipoteza piețelor adaptive: Lo (2004)

- Predictibilitatea nu este constantă: apare, este eliminată prin arbitraj și reapare în condiții noi
- Un model care a funcționat ieri este o **ipoteză**, nu o lege (eficiența pieței: Capitolul 2)

Ce este predictibil? Direcție vs. risc



- Autocorelația de ordin k : $\rho_k = \text{Corr}(x_t, x_{t-k})$; banda gri reprezintă limitele de referință de 95% sub ipoteza de autocorelație nulă, $\pm 1.96/\sqrt{T}$
- Autocorelațiile randamentelor r_t sunt minuscule (în bandă); cele ale lui $|r_t|$ sunt mari și persistente
- ML are cele mai mari șanse acolo unde există structură: **volatilitate, risc, lichiditate, clasamente transversale**

Dovezi din evaluarea empirică a activelor

Gu, Kelly & Xiu (2020), *Review of Financial Studies*

- ▣ Prognoza **randamentelor lunare ale acțiunilor americane individuale**; comparate: modele liniare, regresii penalizate, regresia pe componente principale (PCR), regresia prin cele mai mici pătrate parțiale (PLS), păduri aleatoare, arbori antrenați prin boosting, rețele neuronale
- ▣ R^2 în afara eșantionului, $R_{OOS}^2 = 1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t r_t^2$, este mic (mult sub 1% pe lună)
- ▣ Arborii și rețelele neuronale bat modelele liniare; câștigul vine din **interacțiuni neliniare**; predictorii dominanți: momentum, lichiditate, volatilitate
- ▣ Un R_{OOS}^2 mic poate totuși ordona mii de acțiuni suficient de bine pentru câștiguri mari de portofoliu (slide-ul următor)

Avertisment

- ▣ Pentru o **singură serie de timp** (un indice), eșantionul efectiv este mult mai mic, iar dovezile mult mai slabe — după cum arată studiul de caz S&P 500


Cât de mic este mic? R_{OOS}^2 și valoarea economică

- **Campbell & Thompson (2008)**: în modelul $r_{t+1} = \mu + x_t + \varepsilon_{t+1}$, cu $R^2 = \text{Var}(x_t)/\text{Var}(r_{t+1})$ și $\text{Var}(\varepsilon_{t+1})$ constantă, un investitor fără restricții, cu un criteriu medie-varianță, care cunoaște x_t (fără costuri, fără erori de estimare) atinge

$$SR^{*2} = \frac{SR_0^2 + R^2}{1 - R^2}, \quad SR_0 = \text{raportul Sharpe al strategiei buy-and-hold}$$


- S&P 500, randamente logaritmice lunare 2001–2026: $SR_0 = 0.128$ pe lună (0.44 anualizat)
 - ilustrare idealizată: $R^2 = 0.5\%$ pe lună $\Rightarrow SR^* = 0.51$ anualizat (+15%); $R^2 = 1\% \Rightarrow 0.57$ (+27%)
- Reperul contează: **Welch & Goyal (2008)** arată că majoritatea predictorilor publicați pierd în fața **mediei istorice** în afara eșantionului
 - **Gu, Kelly & Xiu (2020)** măsoară R_{OOS}^2 față de o prognoză zero, la fel ca în Capitolul 14; media istorică este un reper mai greu
- Un R^2 lunar de 0.5% este mare economic, dar zgomotul de eșantionare are același ordin de mărime: pentru R^2 OLS în eșantion al unui predictor fără abilitate (termen liber, erori independente, $n \approx 300$ de luni), $nR^2 \approx \chi_1^2$, deci R^2 are media $1/n \approx 0.3\%$ și abaterea standard $\sqrt{2}/n \approx 0.5\%$; R_{OOS}^2 poate fi negativ, nu are această distribuție sub ipoteza nulă și cere un test propriu (Clark–West)

Fluxul de lucru ML în finanțe



- Sețiunile 4–6 urmează rândul de sus, sețiunile 7–8 rândul de jos; Sețiunea 3 dă testele folosite peste tot
- Look-ahead bias**: folosirea unor informații indisponibile la momentul deciziei; **biasul de selecție**: raportarea celei mai bune dintre multe încercări
- López de Prado (2018)**: majoritatea eșecurilor ML în finanțe țin de proces, nu de algoritm

De la perceptron la Deep Blue



Mark I Perceptron, manualul operatorului
(1960)

Figură: J.C. Hay, A.E. Murray (1960); domeniu
public; Wikimedia Commons



IBM Deep Blue, Computer
History Museum


Foto: Anton Chiang (2011); CC
BY 2.0; Wikimedia Commons

- **Perceptronul:** o regulă de învățare pentru un singur neuron artificial Rosenblatt (1958); Mark I era un dispozitiv construit pentru a recunoaște imagini simple
- 1997: Deep Blue (IBM) îl învinge pe campionul mondial de șah Garry Kasparov Campbell, Hoane & Hsu (2002)
- Deep Blue căuta cu reguli scrise de oameni; ML-ul modern (acest capitol) *învață* regulile din date

Recapitulare de cunoștințe: minimizarea riscului, bias–varianță, CV

- ▣ Învățarea supervizată: $\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_i L(y_i, f(x_i)) + \lambda \Omega(f)$; pierderea L (eroare pătratică, log-loss), penalizarea complexității Ω , parametrul $\lambda \geq 0$
- ▣ Eroarea așteptată = $\text{bias}^2 + \text{varianță} + \text{zgomot ireductibil } \sigma^2$ (Hastie, Tibshirani & Friedman (2009), cap. 7)
 - ▶ În finanțe domină σ^2 : o mică reducere a biasului rareori justifică o creștere mare a varianței
- ▣ Eroarea în eșantion (IS) este optimistă; contează eroarea în afara eșantionului (OOS)
- ▣ Validarea încrucișată (CV) în K pliuri alege λ și compară modele; un set final de test nu se atinge niciodată
 - ▶ Presupune observații interschimbabile: Secțiunea 6 arată când este valabil pentru serii de timp și când nu
- ▣ Acest capitol: clasificarea direcției pe 5 zile; regresia logistică (logit) $p = 1/(1 + e^{-x^\top \beta})$ este reperul liniar

Bias-varianță în practică: adâncimea arborelui



- S&P 500, direcția pe 5 zile; acuratețea = proporția zilelor clasificate corect
- Acuratețea pe antrenare crește la $\approx 87\%$ cu adâncimea; acuratețea CV cu purjare **scade** spre 50%
- Random forest se degradează mai lent, dar nu bate niciodată reperul “mereu în sus” (linia punctată)


Recapitulare: regresie penalizată, arbori, păduri, boosting, rețele

- Cele mai mici pătrate / logit penalizate: $\lambda [\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2]$
 - ▶ $\alpha = 0$ Ridge (Hoerl & Kennard (1970)), $\alpha = 1$ LASSO (Tibshirani (1996)), între ele Elastic Net (Zou & Hastie (2005)); caracteristicile se standardizează doar pe pliurile de antrenare
- Arbori: împărțiri binare recursive care minimizează impuritatea Gini; bias mic, varianță mare
- Random forest (RF): media a B arbori bootstrap decorelați (Breiman (2001))
 - ▶ Eroarea out-of-bag (OOB) este **optimistă** când etichetele se suprapun: bootstrap-ul extrage observații aproape identice
- Gradient boosting machine (GBM): $F_m = F_{m-1} + \eta h_m$, arbori mici ajustați pe gradientul negativ (Friedman (2001))
- Perceptronul multistrat (MLP): $h^{(\ell)} = g(W^{(\ell)}h^{(\ell-1)} + b^{(\ell)})$, g ReLU, oprire timpurie; rețelele cu puține straturi sunt suficiente pentru date despre randamente în format tabelar (Gu, Kelly & Xiu (2020)); arhitecturile în Capitolul 14
- Ce e nou pentru acest curs: **selecția LASSO nu este inferență** (Secțiunea 9), iar orice scor CV trebuie testat (Secțiunea 3)



Random Forests

Traectoria de regularizare LASSO



- ▣ Regresie logistică penalizată L_1 pentru direcția pe 5 zile a S&P 500, 14 caracteristici standardizate
- ▣ Penalizare puternică: toți coeficienții sunt zero; prima caracteristică intrată este prețul FFD, un nivel de preț scalat (Secțiunea 4)
- ▣ Penalizare slabă: caracteristicile de volatilitate (vol_20, vol_60, vol_ratio) au cei mai mari coeficienți
- ▣ Toți coeficienții sunt mici în valoare absolută: semnal slab, în acord cu piețe aproape eficiente

Exemplu rezolvat: agregarea predicțiilor arborilor

- ▣ Random forest-ul din studiul de caz (400 de arbori, dimensiune minimă a frunzei 100), antrenat pe primele patru pliuri purjate
- ▣ Predicția pentru ultima observație (11 septembrie 2026): $P(\text{creștere în 5 zile})$ dată de fiecare arbore
 - ▶ probabilitățile estimate de arborii individuali variază între 0.31 și 0.88 (abatere standard 0.11)
 - ▶ 81.5% dintre arbori votează “sus” ($p > 0.5$)
 - ▶ probabilitatea estimată de pădure = media probabilităților estimate de cei 400 de arbori = 0.608
- ▣ Predicțiile arborilor diferă mult; media lor este mult mai stabilă
- ▣ Stabilitate nu înseamnă acuratețe: pădurea tot nu bate “mereu în sus” (Secțiunea 7)

Recapitulare: trusa de unelte machine learning

- ▣ Învățare supervizată = pierdere + penalizarea complexității, ajustată prin validare încrucișată
- ▣ Finanțele sunt dominate de zgomot: controlul varianței contează mai mult decât flexibilitatea
- ▣ Trusa de unelte: logit penalizat (Ridge / LASSO / Elastic Net), arbori, random forest, gradient boosting, MLP
- ▣ Un scor CV este o **estimație**: are o distribuție de eșantionare
- ▣ Urmează: cum **testăm** dacă un clasificator bate un reper

Exemplu rezolvat: modelul care a învățat “mereu în sus”

	Prezis sus	Prezis jos
Real sus	TP = 3,572	FN = 68
Real jos	FP = 2,591	TN = 38

- Logit penalizat L2, studiul de caz S&P 500 (Secțiunea 7), predicții în afara pliului din CV cu purjare în 5 pliuri, $n = 6,269$
- TP, FN, FP, TN: rezultate adevărat pozitive, fals negative, fals pozitive, adevărat negative

- $\text{Acuratețe} = (TP + TN)/n = 57.6\%$
- $\text{Precizie} = TP/(TP + FP) = 0.580$; $\text{recall} = TP/(TP + FN) = 0.981$; $F_1 = 0.729$
- Modelul prezice “sus” în 98.3% din zile: practic a învățat “mereu în sus”
- Este 57.6% o dovadă de abilitate? Două întrebări:
 - ▶ comparat cu ce (slide-ul următor)?
 - ▶ cu ce eroare de eșantionare (testele care urmează)?

Comparați mereu cu un reper naiv

- ▣ **Reperul “mereu în sus”**: prezicem clasa majoritară în fiecare zi
- ▣ Acuratețea lui este proporția etichetelor “sus”: $\bar{y} = \frac{1}{n} \sum_i y_i$
- ▣ S&P 500, direcția pe 5 zile, 2001–2026: $\bar{y} = 58.1\%$ — un model “cu acuratețe de 57%” este *mai slab* decât a nu face nimic
- ▣ Alte repere: direcția de ieri, o regulă de medii mobile, buy-and-hold pentru tranzacționare
- ▣ Un model are valoare doar dacă bate reperul **în afara eșantionului**, după costuri, cu mai mult decât eroarea de eșantionare

Testarea acurateții direcționale: Pesaran–Timmermann

- ▣ H_0 : semnul prezis x_t este independent de semnul realizat y_t (Pesaran & Timmermann (1992))
- ▣ $\hat{P}$ = proporția semnelor corecte; sub H_0 proporția așteptată este $\hat{P}^* = \hat{p}_y \hat{p}_x + (1 - \hat{p}_y)(1 - \hat{p}_x)$

$$PT = \frac{\hat{P} - \hat{P}^*}{\sqrt{\hat{V}(\hat{P}) - \hat{V}(\hat{P}^*)}} \xrightarrow{d} N(0, 1), \quad \hat{V}(\hat{P}) = \frac{\hat{P}^*(1 - \hat{P}^*)}{n}$$

$$\blacktriangleright \hat{V}(\hat{P}^*) = [(2\hat{p}_y - 1)^2 \hat{p}_x(1 - \hat{p}_x) + (2\hat{p}_x - 1)^2 \hat{p}_y(1 - \hat{p}_y)]/n + 4\hat{p}_y \hat{p}_x(1 - \hat{p}_y)(1 - \hat{p}_x)/n^2$$

- ▣ Modelul logit de mai sus: $\hat{p}_y = 0.581$, $\hat{p}_x = 0.983 \Rightarrow \hat{P}^* = 0.578 > \hat{P} = 0.576$; $PT = -1.28$, p unilateral = 0.90
- ▣ PT ține cont automat de frecvențele marginale: nu trebuie ghicit reperul
- ▣ Etichete suprapuse pe 5 zile: PT presupune zile independente; aceeași ipoteză nulă ca testul t al pantei în $y_t = a + b x_t + u_t$ cu erori Newey–West (Newey & West (1987)): $t = -1.00$

AUC și incertitudinea ei de eșantionare

- ▣ Curba ROC (Receiver Operating Characteristic): rata rezultatelor adevărat pozitive $TP/(TP + FN)$ în funcție de rata rezultatelor fals pozitive $FP/(FP + TN)$, pentru toate pragurile
- ▣ Aria de sub curbă (AUC) = $P(\hat{p}_{\text{poz}} > \hat{p}_{\text{neg}}) + \frac{1}{2}P(\hat{p}_{\text{poz}} = \hat{p}_{\text{neg}}) = U/(n_1 n_0)$, statistica Mann–Whitney; 0.5 = nicio capacitate de ordonare
- ▣ Eroarea standard DeLong (DeLong, DeLong & Clarke-Pearson (1988)): din valorile de plasare ale fiecărei observații; presupune observații independente
- ▣ Bootstrap circular pe blocuri (Künsch (1989)): reeșantionăm blocuri de $L = 20$ zile consecutive, 1,000 de replici; păstrează dependența serială
- ▣ Logit, AUC agregat în afara pliurilor = 0.479
 - ▶ CI 95% DeLong [0.465; 0.494]: “semnificativ mai slab decât hazardul”
 - ▶ CI 95% bootstrap pe blocuri [0.455; 0.504]: zgomot în jurul lui 0.5
- ▣ Un AUC sub 0.5 înseamnă ordonare inversă doar dacă trece un test care respectă dependența

Compararea prognozelor: Diebold–Mariano și Clark–West

- ▣ Diferența pierderilor $d_t = L(y_t, \hat{p}_{1,t}) - L(y_t, \hat{p}_{0,t})$, cu log-loss sau pierderea Brier $(y_t - \hat{p}_t)^2$
- ▣ Diebold–Mariano (DM): $DM = \bar{d} / \sqrt{\hat{\Omega}_{NW}/n} \xrightarrow{d} N(0, 1)$ sub $H_0 : \mathbb{E}[d_t] = 0$ (Diebold & Mariano (1995)); $\hat{\Omega}_{NW}$ = varianța de lungă durată robustă la heteroscedasticitate și autocorelație (HAC)
- ▣ **Modele imbricate**: logit-ul cu 14 caracteristici include prognoza constantă ($\beta = 0$)
 - ▶ sub H_0 modelul mare estimează cu zgomot coeficienți nuli, deci $\mathbb{E}[d_t] > 0$ în eșantioane finite
 - ▶ DM nu mai este $N(0, 1)$ și are o rată de respingere sub nivelul nominal: rareori găsește modelul mare mai bun
- ▣ Corecția Clark–West (CW) (Clark & West (2007)): test t unilateral (HAC) pentru $\mathbb{E}[f_t] = 0$, cu

$$f_t = (y_t - \hat{p}_{0,t})^2 - [(y_t - \hat{p}_{1,t})^2 - (\hat{p}_{0,t} - \hat{p}_{1,t})^2]$$
- ▣ Ultimul termen corectează efectul zgomotului introdus prin estimarea coeficienților nuli ai modelului mai amplu, corect imbricat
- ▣ Clark și West obțin normalitatea aproximativă pentru modele imbricate *liniare* estimate prin OLS; pentru probabilitățile unui logit penalizat (pierderea Brier) aceeași corecție este o aproximare, nu o teoremă

Abilitatea predictivă condiționată: Giacomini–White

- Giacomini & White (2006): ipoteza nulă privește **metoda** de prognoză (model + fereastră de estimare + regula de reestimare), nu modelul populației

$$H_0 : \mathbb{E}[d_{t+\tau} \mid \mathcal{F}_t] = 0 \Rightarrow \mathbb{E}[h_t d_{t+\tau}] = 0, \quad GW = n \bar{Z}^\top \hat{\Omega}^{-1} \bar{Z} \xrightarrow{d} \chi_q^2$$

- ▶ $Z_t = h_t d_{t+\tau}$; funcții-test h_t (aici 1 și diferența pierderilor întârziată, $q = 2$); orizont $\tau = 5$ zile
- Teoria cere o fereastră de estimare mărginită (mobilă), astfel încât zgomotul de estimare să nu dispară; o fereastră care se extinde iese din cadrul teoremei
- CW și GW răspund la întrebări diferite
 - ▶ CW: adaugă informație modelul *populației* cu caracteristici?
 - ▶ GW: prognozează mai bine regula *mea estimată*, așa cum e folosită?
- Ambele se aplică pe walk-forward-ul S&P 500 în Secțiunea 7

De la predicții la o strategie de tranzacționare

Definiție 1 (Poziții, rulaj, costuri, expunere)

- Poziția $w_t \in \{0, 1\}$: long pe indice (1) sau în numerar (0), decisă cu informații până la t
 - Randamentul strategiei: $r_{t+1}^s = w_t r_{t+1} - c |w_t - w_{t-1}|$, cu r_{t+1} randamentul logaritmic zilnic; $r - c$ este aproximarea de ordinul întâi a lui $\log(e^r - c)$
 - Rulajul (turnover) $|w_t - w_{t-1}|$: fracțiunea portofoliului tranzacționată; costul c în puncte de bază (5 bp = 0.05% pe unitatea tranzacționată)
 - Expunerea: proporția medie a timpului investit, $\bar{w} = \frac{1}{T} \sum_t w_t$
-
- Buy-and-hold: $w_t = 1$ pentru orice t (expunere 100%, fără rulaj)

Distribuția de eșantionare a raportului Sharpe

- ▣ Raportul Sharpe (SR) pe perioadă: $\widehat{SR} = \bar{r}/\hat{\sigma}$; în acest capitol r = randamente logaritmice zilnice (creșterea logaritmică medie pe unitatea de risc), rata fără risc considerată nulă
- ▣ Randamente i.i.d. din distribuția Normală: $\text{Var}(\widehat{SR}) \approx (1 + \frac{1}{2} SR^2)/T$ (Lo (2002))
- ▣ Randamente i.i.d. nenormale, metoda delta cu asimetria γ_3 și kurtosis γ_4 (Opdyke (2007)):

$$\text{Var}(\widehat{SR}) \approx \frac{1 - \gamma_3 SR + \frac{\gamma_4 - 1}{4} SR^2}{T}$$

- ▶ acesta este numitorul raportului Sharpe probabilistic din Secțiunea 8
- ▣ Anualizarea cu $\sqrt{q}$ ($q = 252$ sau 365) cere absența autocorelației; altfel $SR_q = \eta(q) SR$,
 $\eta(q) = q / \sqrt{q + 2 \sum_{k=1}^{q-1} (q-k) \rho_k}$ (Lo (2002))
- ▣ Două strategii pe aceleași zile: testăm $SR_a - SR_b$ cu metoda delta HAC sau cu un bootstrap pe blocuri studentizat (Ledoit & Wolf (2008)); două CI separate ignoră corelația lor

Recapitulare: măsurarea și testarea abilității predictive

- ▣ Acuratețea singură induce în eroare la clase dezechilibrate; Pesaran–Timmermann ține cont de proporțiile claselor
- ▣ AUC și CI-ul ei: DeLong presupune independență; bootstrap-ul pe blocuri respectă dependența
- ▣ Compararea prognozelor: DM pentru prognoze neimbricate, Clark–West pentru modele imbricate, Giacomini–White pentru metode estimate
- ▣ Rapoartele Sharpe sunt estimații: eroarea standard $\approx \sqrt{(1 + SR^2/2)/T}$; două se compară cu Ledoit–Wolf
- ▣ Urmează: cum construim caracteristici și etichete fără scurgeri de informație

Eșantionarea datelor financiare: bare

Bare de timp și de tranzacții

- O **bară** = un rând (deschidere, maxim, minim, închidere, volum) care rezumă un interval de eșantionare
- Bare de timp: la interval fix (1 minut, 1 zi); supraeșantionează perioadele liniștite; randamente cu cozi groase
- Bare de tranzacții (tick): o bară la fiecare N tranzacții

Bare de volum, valoare și informaționale

- O bară la fiecare V acțiuni sau la fiecare D dolari tranzacționați: eșantionare după **sosirea informației**
- Randamente mai apropiate de extrageri i.i.d. din distribuția Normală: [Clark \(1973\)](#); [Ané & Geman \(2000\)](#)
- Bare de dezechilibru / de serii: eșantionăm când fluxul de ordine devine unilateral

- Capitolul folosește bare zilnice de timp; date la nivel de tranzacție (platforme de tranzacționare cripto) în Capitolele 10 și 16

Dilema staționaritate vs. memorie

- ▣ Modelele ML au nevoie de variabile de intrare a căror distribuție nu se modifică în timp: relația învățată în trecut trebuie să rămână valabilă
- ▣ Log-prețurile se comportă ca $I(1)$ (integrate de ordinul unu); randamentele $\Delta \log P_t$ sunt $I(0)$, dar **șterg memoria** nivelului prețului
- ▣ O serie este $I(\delta)$ dacă $(1 - B)^\delta X_t$ este $I(0)$; ea este staționară doar pentru $\delta < \frac{1}{2}$ ([Hosking \(1981\)](#))
- ▣ Diferențierea unui log-preț $I(1)$ cu un ordin fracționar d dă o serie $I(1 - d)$

$$0 \leq d \leq \frac{1}{2}$$

- ▣ $I(1 - d)$, $1 - d \geq \frac{1}{2}$
- ▣ nestaționară, cu revenire la medie pentru $d > 0$

$$\frac{1}{2} < d < 1$$

- ▣ staționară, memorie lungă
- ▣ autocorelații care scad lent

$$d = 1 \text{ (randamente)}$$

- ▣ $I(0)$
- ▣ memoria nivelului ștersă

- ▣ [López de Prado \(2018\)](#) propune cel mai mic d la care un test ADF respinge; această secțiune arată de ce regula eșuează

Diferențierea fracționară

Definiție 2 (Operatorul de diferențiere fracționară)

□ Cu operatorul de întârziere $BX_t = X_{t-1}$ și un ordin real d :

$$(1 - B)^d = \sum_{k=0}^{\infty} \binom{d}{k} (-B)^k, \quad \tilde{X}_t = \sum_{k=0}^{\infty} w_k X_{t-k}$$

□ Ponderi: $w_0 = 1$, $w_k = -w_{k-1} \frac{d-k+1}{k} = \frac{\Gamma(k-d)}{\Gamma(-d)\Gamma(k+1)} \sim \frac{k^{-(1+d)}}{\Gamma(-d)}$ pentru $k \rightarrow \infty$


- $d = 1$: $w = (1, -1, 0, 0, \dots)$ — randamentele obișnuite
- $0 < d < 1$: ponderile scad hiperbolic $\Rightarrow$ se păstrează memoria lungă
- Suma infinită: $\sum_{k=0}^{\infty} w_k = (1 - 1)^d = 0$, deci nivelul lui X_t se anulează doar la limită

Fereastra fixă

Definiție 3 (Diferențiere fracționară cu fereastră fixă (FFD))


- ▣ Trunchiem ponderile: păstrăm $w_0, \dots, w_K$ cu $|w_k| \geq \tau$ (de ex. $\tau = 10^{-4}$), renunțăm la rest (López de Prado (2018))
- ▣ $\tilde{X}_t = \sum_{k=0}^K w_k X_{t-k}$ pentru orice $t > K$
- ▣ Fiecare $\tilde{X}_t$ folosește același număr de întârzieri; intră doar valori trecute $\Rightarrow$ fără informație din viitor
- ▣ Cu cât d este mai mic, cu atât trebuie mai multe întârzieri: $d = 0.25, \tau = 10^{-4} \Rightarrow K = 444$ întârzieri
- ▣ Ponderile trunchiate nu mai au suma zero: $\sum_{k=0}^K w_k = 0.178$ la $d = 0.25$ (0.040 la $d = 0.5$)

Ponderile diferențierii fracționare



- Pentru $d = 1$ contează doar prima întârziere; pentru d mic ponderile întârzierilor îndepărtate rămân nenule
- Toate ponderile după w_0 sunt negative: $\tilde{X}_t$ compară nivelul de azi cu o istorie ponderată

Statistica ADF în funcție de d : S&P 500



- Testul de rădăcină unitară Dickey–Fuller augmentat (ADF) (cursul de serii de timp): H_0 rădăcină unitară, respingem sub ≈ -2.86 la 5%
- Log-prețul FFD, S&P 500 2000–2026, constantă și 1 lag: ADF respinge de la $d = 0.25$, unde $\text{Corr}(\tilde{X}_t, \log P_t) = 0.98$
- Aceeași serie, numărul de lag-uri ales prin AIC (34 de lag-uri): ADF = -0.72 , nu respinge
- O corelație de 0.98 cu un preț $I(1)$ este un semnal de alarmă, nu o calitate

FFD trunchiată a unui preț $I(1)$ rămâne $I(1)$

- Descompunem seria FFD:

$$\tilde{X}_t = \sum_{k=0}^K w_k X_{t-k} = \left(\sum_{k=0}^K w_k \right) X_t - \sum_{k=1}^K w_k (X_t - X_{t-k})$$

- Dacă X_t este $I(1)$, fiecare $X_t - X_{t-k}$ este $I(0)$; primul termen este $0.178 X_t$ la $d = 0.25$: un **mers aleator scalat**
- Componenta cu rădăcină unitară are varianță mică față de partea staționară, deci ADF cu puține lag-uri le confundă
 - Monte Carlo: mers aleator pur, $T = 6,274$, FFD cu $d = 0.25$: ADF (1 lag) respinge în **97.8%** din 500 de eșantioane, la un nivel nominal de 5%
- Local Whittle (slide-ul următor) dă $\hat{d} = 0.75$ [0.69; 0.81] pentru seria FFD: memoria aparentă în banda de frecvențe, nu ordinul ei de integrare
 - peste frecvența $1/K$ filtrul acționează ca $(1 - B)^{0.25}$; doar $n/(2\pi K) \approx 2$ din cele $m = 294$ de frecvențe sunt sub $1/K$, unde rădăcina unitară reapare
- Consecință: `ffd_price` din studiul de caz este un nivel de preț scalat, nu o caracteristică staționară


Estimarea corectă a memoriei: local Whittle

- ▣ Lângă frecvența zero, o serie $I(\delta)$ are densitatea spectrală $f(\lambda) \sim G \lambda^{-2\delta}$; periodograma $I(\lambda_j)$ la $\lambda_j = 2\pi j/n$
- ▣ Local Whittle (Robinson (1995)): folosim primele m frecvențe,

$$\hat{\delta} = \arg \min_{\delta} \log \left(\frac{1}{m} \sum_{j=1}^m \lambda_j^{2\delta} I(\lambda_j) \right) - \frac{2\delta}{m} \sum_{j=1}^m \log \lambda_j, \quad \sqrt{m}(\hat{\delta} - \delta) \xrightarrow{d} N(0, \frac{1}{4})$$


- ▣ Local Whittle exact (ELW, Shimotsu & Phillips (2005); media necunoscută: Shimotsu (2010)): periodograma lui $(1 - B)^{\delta} X_t$, valid și pentru $\delta \geq \frac{1}{2}$ (nestaționar)
- ▣ S&P 500, 2000–2026, $m = n^{0.65}$, CI 95% $\pm 1.96/(2\sqrt{m})$
 - ▶ log-preț (ELW): 0.99 [0.94; 1.05]; randamente: -0.01 [-0.07 ; 0.04]
 - ▶ randamente absolute $|r_t|$: 0.53 [0.47; 0.59]; seria FFD, $d = 0.25$ (ELW): 0.75 [0.69; 0.81]
- ▣ Memoria lungă este în **volatilitate**, nu în nivelul prețului: caracteristicile fracționare au sens pe $|r_t|$ (Franke, Härdle & Hafner (2019))

Estimările memoriei pentru diverse lățimi de bandă



- Lățimea de bandă $m = n^a$: a mic = mai puțin bias din dinamica pe termen scurt, CI mai larg; raportăm toată curba
- Log-prețul rămâne la 1; seria FFD rămâne aproape de $1 - d$ pentru că și benzile înguste folosesc puține frecvențe sub $1/K$ (ordinul ei este tot 1): niciuna nu este staționară
- Randamente: fără memorie; randamente absolute: $\hat{d} \approx 0.36-0.55$, memoria lungă a volatilității (Capitolele 5 și 9)

Prețuri, serie FFD și randamente



- ▣ **Sus:** log-prețul — $I(1)$
- ▣ **Mijloc:** FFD cu $d = 0.25$ — trendul ascendent al prețului se vede în continuare: $0.178 \log P_t$ plus o parte staționară
- ▣ **Jos:** randamentele logaritmice — se văd doar grupările de volatilitate
- ▣ Seria FFD intră în studiul de caz drept caracteristica `ffd_price`

Alegerea lui d : scurgere de informație

- ▣ “ d minim” a fost ales pe 2000–2026 și apoi folosit în CV cu purjare: pliurile de test au ajutat la alegerea unei caracteristici (Secțiunea 6)
 - ▶ aceeași regulă ADF pe datele până în 2009 dă $d = 0.15$; pe tot eșantionul $d = 0.25$
- ▣ Studiul de caz fără `ffd_price` (CV cu purjare în 5 pliuri, media pe pliuri)
 - ▶ acuratețe: logit 57,5%, RF 56,4%, GBM 55,6%, MLP 55,5%, toate sub 58,1%
 - ▶ AUC: 0,483; 0,522; 0,514; 0,514
- ▣ Concluzia negativă nu depinde de această caracteristică
- ▣ Protocolul corect
 - ▶ estimăm d (local Whittle, cu CI) doar în fiecare pliuri de antrenare
 - ▶ preferăm caracteristici cu sens economic: distanțe față de mediile mobile, filtre fracționare ale lui $|r_t|$

 `inference_tests.py`

Recapitulare: date financiare și caracteristici

- Eșantionarea după activitate (bare de volum, de valoare) produce randamente cu proprietăți statistice mai favorabile decât eșantionarea la intervale fixe
- O respingere ADF nu înseamnă staționaritate: FFD trunchiată a unui preț $I(1)$ rămâne $I(1)$ (ponderile însumează 0.178 la $d = 0.25$)
- Estimați memoria direct: local Whittle / ELW cu CI; log-prețul S&P 500 $\hat{d} = 0.99$, randamentele absolute 0.53
- Orice transformare, inclusiv alegerea lui d , folosește doar date trecute și pliurile de antrenare
- Urmează: cum transformăm prețurile în etichete

Eticheta cu orizont fix și problemele ei

Definiție 4 (Etichetă cu orizont fix)

- Randamentul logaritm pe h perioade $r_{t,t+h} = \log P_{t+h} - \log P_t$ și pragul $\tau \geq 0$: $y_t = +1$ dacă $r_{t,t+h} > \tau$, -1 dacă $r_{t,t+h} < -\tau$, 0 altfel
- **Ponderile etichetelor**: fracțiunea observațiilor din fiecare clasă, de ex. $\frac{1}{n} \sum_t 1\{y_t = +1\}$

Probleme

- Un τ constant ignoră volatilitatea variabilă: în perioade calme aproape toate etichetele sunt 0 , în crize aproape niciuna
- Ignoră **traectoria**: o poziție reală ar fi fost închisă prin stop-loss cu mult înainte de $t + h$
- Clase dezechilibrate: S&P 500, $h = 10$ zile, $\tau = 0$: 60,5% sus vs. 39,5% jos

Metoda celor trei bariere

Definiție 5 (Etichetă cu trei bariere, López de Prado (2018))


- La momentul evenimentului t_0 , cu volatilitatea zilnică σ_{t_0} și orizontul h :
 - ▶ bariera superioară (profit): $\log P_t - \log P_{t_0} \geq \pi_u \sigma_{t_0} \sqrt{h}$
 - ▶ bariera inferioară (stop-loss): $\log P_t - \log P_{t_0} \leq -\pi_l \sigma_{t_0} \sqrt{h}$
 - ▶ bariera verticală (limita de timp): $t = t_0 + h$
- Eticheta = **prima barieră atinsă** la momentul t_1 : +1 sus, -1 jos; la bariera verticală fie $\text{sign}(r_{t_0, t_1})$, fie 0
- π_u, π_l : lățimile barierelor în unități de $\sigma_{t_0} \sqrt{h}$

Estimarea volatilității și proprietățile barierelor

Definiție 6 (Volatilitate EWMA)

- Rădăcina pătrată a mediei mobile ponderate exponențial (EWMA) a abaterilor pătratice ale randamentelor logaritmice zilnice, cu span 50 (factor $\lambda = 1 - 2/51$): zilele recente cântăresc mai mult
- Barierele se scalează cu volatilitatea $\Rightarrow$ etichete comparabile în regimuri calme și turbulente
- Imită modul în care un trader își gestionează poziția: take-profit, stop-loss, perioadă maximă de deținere
- Fiecare etichetă are un **interval** $[t_0, t_1]$ — esențial pentru validarea încrucișată (Secțiunea 6)


Trei bariere: S&P 500 în 2022



- Cinci evenimente în piața descendentă din 2022, $\pi_u = \pi_l = 1$, $h = 15$ zile
- Ianuarie: stop-loss atins (-1); martie: profit ($+1$); celelalte se termină la bariera verticală




Distribuția etichetelor: orizont fix vs. trei bariere



- S&P 500, 2001–2026, $h = 10$: orizontul fix dă 60,5% sus / 39,5% jos
- Trei bariere ($\pm 1\sigma\sqrt{h}$): 19,6% sus, 21,3% jos, 59,0% expirare — etichete direcționale echilibrate
- Panoul din dreapta: barierele orizontale sunt de obicei atinse după 1–2 săptămâni

Meta-etichetarea



- Meta-eticheta: $y_t^{meta} = 1$ dacă semnalul primar a fost profitabil (barieră atinsă în direcția lui), 0 altfel
- Modelul secundar dă $\hat{p} = P(y_t^{meta} = 1 \mid x_t)$

De ce funcționează meta-etichetarea

- ▣ ML învață **când să aibă încredere** în modelul primar, nu direcția înșăși
- ▣ Modelul primar este reglat pentru recall ridicat (prinde majoritatea oportunităților)
- ▣ Modelul meta filtrează fals pozitivele $\Rightarrow$ precizie mai mare și un scor F1 mai bun când recall nu scade prea mult
- ▣ Păstrează un nucleu interpretabil, motivat economic; limitează supraajustarea direcției
- ▣ Seminarul o aplică unei încrucișări de medii mobile pe Bitcoin

Etichete suprapuse și unicitatea eșantioanelor

- Eticheta i acoperă $[t_{0,i}, t_{1,i}]$; etichetele consecutive împart randamente $\Rightarrow$ eșantioanele **nu sunt i.i.d.**
- Etichete active simultan la t : $c_t = \sum_i 1\{t_{0,i} \leq t \leq t_{1,i}\}$; unicitatea medie

$$\bar{u}_i = \frac{1}{t_{1,i} - t_{0,i} + 1} \sum_{t=t_{0,i}}^{t_{1,i}} \frac{1}{c_t}$$
- $\bar{u}_i = 1$: niciun randament comun; $\bar{u}_i = 1/5$: media armonică a lui c_t pe intervalul etichetei i este cinci

Consecințe

- Mărimea efectivă a eșantionului $\approx \sum_i \bar{u}_i \ll n$ (o euristică a suprapunerii, nu o măsură bazată pe varianță)
- Bagging-ul extrage observații aproape identice; scorurile CV sunt prea optimiste

Remedii

- Ponderare cu $\bar{u}_i$ (și cu $|r|$)
- Bootstrap secvențial; în RF $\text{max_samples} \approx \bar{u}$

Recapitulare: etichetare

- Etichetele cu orizont fix ignoră volatilitatea și traiectoria prețului și sunt dezechilibrate (60,5% sus)
- Etichetele cu trei bariere se scalează cu volatilitatea și imită gestionarea reală a pozițiilor
- Meta-etichetarea lasă ML să decidă *dacă* acționăm pe un semnal economic
- Fiecare etichetă are un interval; intervalele suprapuse micșorează eșantionul efectiv
- Urmează: o validare care respectă aceste intervale

Scurgerea de informație: de ce eșuează K-Fold standard

Definiție 7 (Scurgere de informație (leakage))


- Setul de antrenare conține informații prezente și în setul de test, așa că scorul de test nu mai măsoară performanța pe date cu adevărat noi
- Caracteristici corelate serial ($x_t \approx x_{t+1}$) și etichete suprapuse ($y_t \approx y_{t+1}$): un K -fold amestecat pune zile **aproape identice** de ambele părți
- Un model flexibil (RF, GBM) memorează vecinul $\Rightarrow$ scor “în afara eșantionului” excelent; ajustarea pe un CV cu scurgeri alege modelul **cel mai supraajustat**
- Alte surse: transformări estimate pe tot eșantionul (scalare, analiza componentelor principale, alegerea lui d pentru FFD), biasul de supraviețuire, revizuirii ale datelor, marcaje de timp greșite

Purjare și embargo

Definiție 8 (K-fold cu purjare și embargo, López de Prado (2018))

- Pliurile sunt blocuri **contigue** în timp (fără amestecare)
 - **Purjarea**: eliminăm din antrenare orice observație al cărei interval de etichetă $[t_{0,i}, t_{1,i}]$ se suprapune cu perioada de test
 - **Embargoul**: eliminăm și o mică fracțiune (de ex. 1%) de observații imediat după blocul de test, deoarece caracteristicile folosesc observații anterioare
-
- Purjarea tratează suprapunerea etichetelor; embargoul tratează memoria caracteristicilor

K-fold cu purjare: schema



- Roșu: blocul de test; gri: observațiile purjate imediat înainte; chihlimbar: embargoul imediat după
- Setul de antrenare se micșorează puțin — prețul unei estimări oneste


Exemplu rezolvat: purjare cu 10 observații

- Observații $t = 0, \dots, 9$; eticheta lui t se termină la $t + 2$ (plafonat la 9)
- 5 pliuri contigue de câte 2; embargo = 1 observație

Test	Eliminate	Antrenare
0, 1	2, 3	4–9
2, 3	0, 1, 4, 5	6–9
4, 5	2, 3, 6, 7	0, 1, 8, 9
6, 7	4, 5, 8, 9	0–3
8, 9	6, 7	0–5

- Test $\{4, 5\}$: etichetele lui 2 și 3 se termină la 4 și 5 $\Rightarrow$ purjate; 6 este embargoul; 7 începe când se termină ultima etichetă de test $\Rightarrow$ purjată
- Cu etichete suprapuse, până la 4 din 10 observații ies din antrenare

Experiment de scurgere: nimic de prezis



- Preț = mers aleator pur; eticheta = semnul randamentului pe următoarele 20 de zile
- 5 caracteristici = medii mobile ale unui zgomot independent
- Acuratețea reală este 50% prin construcție
- Clasificator random forest, 5 pliuri

 MFM_ch13_purged_cv

Experiment de scurgere: rezultate

- ▣ **K-fold amestecat: 69.4%** acuratețe — scurgere pură
- ▣ K-fold neamestecat (contiguu): 50.0%
- ▣ K-fold cu purjare + embargo: 49.7%

Lecția

- ▣ O rată de succes de 69% pe date fără niciun semnal
- ▣ Amestecarea eșuează aici pentru că etichetele se suprapun și caracteristicile sunt persistente (slide-ul următor: când nu strică)
- ▣ Un rezultat prea bun ca să fie adevărat este de obicei o scurgere

Când este valid K-fold pentru serii de timp?

- ▣ Bergmeir, Hyndman & Koo (2018): pentru un model **pur autoregresiv** $y_t = g(y_{t-1}, \dots, y_{t-p}) + \varepsilon_t$ cu erori necorelate serial, K-fold standard este valid
 - ▶ erorile din pliul de test sunt necorelate cu erorile de antrenare, deci eroarea CV este nedeplasată pentru eroarea OOS
- ▣ Eșuează când **erorile** sunt corelate serial
 - ▶ etichete suprapuse: randamentele pe h zile înainte au în comun $h - 1$ randamente zilnice
 - ▶ caracteristici persistente care nu fac parte din lag-urile modelului (medii mobile, niveluri precum `ffd_price`)
 - ▶ dinamică subspecificată (prea puține lag-uri)
- ▣ Experimentul de scurgere izolează exact acest caz: etichete pe 20 de zile și caracteristici mobile pe 20 de zile
- ▣ Verificați înainte de a alege: autocorelația reziduurilor CV; dacă este semnificativă, purjare și embargo

Walk-forward și CV combinatorică cu purjare

Walk-forward (WF)

- ▣ Antrenare pe $[0, T_k]$, test pe $(T_k, T_{k+1}]$, apoi avansăm
- ▣ Imită implementarea în timp real; fără date viitoare în antrenare
- ▣ Dar o **singură traiectorie**: varianță mare, ușor de supraajustat prin încercări repetate

CV combinatorică cu purjare (CPCV)

- ▣ N grupuri; test pe toate cele $\binom{N}{k}$ combinații de k grupuri, cu purjare și embargo
- ▣ $\varphi = \frac{k}{N} \binom{N}{k}$ traiectorii de backtest; de ex. $N = 6$, $k = 2$: 15 împărțiri, 5 traiectorii
- ▣ O **distribuție** de rapoarte Sharpe în loc de un singur număr

- ▣ Regulă practică: K-fold cu purjare / CPCV pentru selecția modelului; WF pentru evaluarea finală, realistă

Recapitulare: validarea încrucișată în finanțe

- ▣ Scurgerea provine din etichete suprapuse și caracteristici corelate serial
- ▣ K-fold amestecat raportează 69,4% pe zgomot pur; K-fold cu purjare raportează 49,7%
- ▣ K-fold este valid pentru autoregresii cu erori necorelate; etichetele suprapuse îl invalidează
- ▣ Purjarea elimină etichetele suprapuse; embargoul elimină memoria caracteristicilor după blocul de test
- ▣ Walk-forward = o traiectorie realistă; CPCV = multe traiectorii, o distribuție de rezultate
- ▣ Urmează: toate acestea aplicate pe S&P 500

Studiu de caz: date, țintă și validare

- ▣ Indicele S&P 500 și VIX, zilnic, 2001–2026: 6,269 de observații
- ▣ Ținta: $y_t = 1\{\log P_{t+5} - \log P_t > 0\}$ — direcția pe 5 zile
- ▣ Intervalul etichetei $[t, t + 5]$ este folosit la purjare
- ▣ CV cu purjare în 5 pliuri, embargo 1%
- ▣ Metrici: acuratețe și ROC AUC, comparate cu reperul “mereu în sus”



Studiu de caz: 14 caracteristici

- ▣ **Momentum:** $\log P_t - \log P_{t-h}$, $h \in \{1, 5, 20, 60, 120\}$ zile
- ▣ **Volatilitate realizată:** abaterea standard anualizată a randamentelor logaritmice zilnice pe 20 și 60 de zile și raportul lor
- ▣ **Distanța față de media mobilă:** $\log P_t$ minus media lui $\log P$ pe ultimele 50 sau 200 de zile
- ▣ **RSI(14):** $100 - 100/(1 + RS)$, RS = raportul dintre câștigurile medii și pierderile medii pe 14 zile (netezite)
- ▣ **VIX:** nivelul logaritmice și variația pe 5 zile a indicelui de volatilitate implicită
- ▣ Logaritmul prețului diferențiat fracționar (**FFD**) cu $d = 0.25$: un nivel de preț scalat (Secțiunea 4)
- ▣ Toate caracteristicile folosesc informații până în ziua t ; doar ordinul d al caracteristicii FFD a fost ales pe tot eșantionul (Secțiunea 4)

Studiu de caz: patru modele

- ▣ **Logit:** regresie logistică penalizată L2 (Ridge) pe caracteristici standardizate
- ▣ **RF:** 400 de arbori, dimensiune minimă a frunzei 100
- ▣ **GBM:** pe histograme, adâncime 3, rată de învățare 0,03, 200 de arbori
- ▣ **MLP:** două straturi ascunse (32 și 16 unități), oprire timpurie
- ▣ Setări deliberat conservatoare: frunze mari și arbori puțin adânci limitează varianța

Compararea modelelor



	Logit	RF	GBM	MLP
Acuratețe	57.6%	56.5%	54.3%	56.4%
AUC	0.478	0.503	0.493	0.515

Reperul “mereu în sus”: **58.1%**

Niciun model nu îl bate

Studiu de caz: sunt diferențele semnificative?

	Logit	RF	GBM	MLP
Acuratețe $\hat{P}$ (agregată)	0.576	0.565	0.543	0.564
Așteptată sub independență $\hat{P}^*$	0.578	0.570	0.557	0.565
Pesaran–Timmermann PT	-1.28	-1.61	-3.07	-0.36
t HAC al pantei (lag 4)	-1.00	-1.16	-2.31	-0.26
AUC agregat	0.479	0.495	0.490	0.512
CI 95% bootstrap pe blocuri	[0.455; 0.504]	[0.472; 0.520]	[0.468; 0.514]	[0.489; 0.537]

- Niciun model nu arată o abilitate direcțională pozitivă semnificativă; fiecare interval pentru AUC conține 0.5
- GBM este semnificativ *mai slab* decât independența ($PT = -3.07$, t HAC = -2.31): prezice “jos” la momente greșite
- AUC agregat diferă puțin de mediile pe pliuri din slide-ul anterior: o singură ordonare pe toate zilele vs. media a cinci

Interpretarea rezultatelor

Concluzie onestă

- ▣ **Niciun model nu bate reperul naiv “mereu în sus”**; toate intervalele pentru AUC conțin 0.5
- ▣ Acuratețea induce în eroare la clase dezechilibrate: 57.6% arată bine, dar este *sub* 58.1%
- ▣ În acord cu eficiența (în formă slabă) a unui indice foarte lichid (Capitolul 2)

Unde să căutăm în schimb

- ▣ Secțiuni transversale cu multe active (Gu, Kelly & Xiu (2020)); ținte de volatilitate și risc; riscul de delistare al criptoactivelor (Będowska-Sójka, Wójcik & Pele (2026))
- ▣ Date alternative: text (Capitolul 15); piețe mai puțin eficiente: crypto (Capitolul 16)
- ▣ Meta-etichetarea unor semnale motivate economic

Importanța caracteristicilor: MDI și MDA

Scăderea medie a impurității (MDI)

- ▣ Reducerea medie a impurității Gini din toate împărțirile pe o caracteristică, pe arborii unei păduri
- ▣ În eșantion, doar pentru arbori
- ▣ Favorizează caracteristicile continue, cu multe valori distincte

Scăderea medie a acurateței (MDA)

- ▣ Importanța prin permutare: scăderea unui scor OOS (aici AUC) când valorile unei caracteristici sunt amestecate aleator
- ▣ Orice model; în afara eșantionului
- ▣ Poate fi negativă: caracteristica dăunează

- ▣ MDI răspunde la “ce a folosit modelul?”; MDA răspunde la “ce ajută pe date noi?”

Importanța caracteristicilor: SHAP

Definiție 9 (Valoarea Shapley a caracteristicii j (SHAP, Lundberg & Lee (2017)))


- Contribuția marginală medie a lui j peste toate coalitiile $S \subseteq \{1, \dots, p\} \setminus \{j\}$:

$$\phi_j = \sum_S \frac{|S|! (p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)], \quad \hat{f}(x) = \phi_0 + \sum_j \phi_j$$

- SHAP intervențional: $v(S) = \mathbb{E}[\hat{f}(x_S, X_{\bar{S}})]$, media lui $\hat{f}$ cu caracteristicile din afara lui S extrase dintr-un eșantion de referință (ca în Quantlet); $\phi_0 = v(\emptyset) =$ predicția medie
- SHAP condiționat folosește $v(S) = \mathbb{E}[\hat{f}(X) \mid X_S = x_S]$; cele două diferă când caracteristicile sunt dependente
- Atribuire aditivă a fiecărei predicții; media lui $|\phi_j|$ pe observații = importanța globală
- Efecte de substituție:** caracteristicile corelate își împart (și diluează) importanța — grupați-le întâi



Importanța caracteristicilor în studiul de caz



- ☐ Trei panouri: MDI (în eșantion), MDA (ΔAUC în afara eșantionului), media $|SHAP|$ (în afara eșantionului)
- ☐ MDI, MDA: random forest; SHAP: gradient boosting, cu 200 de zile de antrenare ca referință; estimare pe primele 70%, evaluare pe ultimele 30% după purjare


Importanța caracteristicilor: interpretare

- **MDI** pune pe primele locuri volatilitatea; **MDA** și **SHAP** indică `mom_20` și `dist_ma200`
- `vol_20`: MDI ridicat, dar MDA **negativ** — un semn de supraajustare, nu o dovadă: zgomotul de eșantionare și caracteristicile corelate modifică și ele MDA
- Importanțele sunt minuscule ($\Delta AUC < 0.01$), în acord cu compararea modelelor
- Permutarea uneia dintre mai multe caracteristici corelate creează puncte în afara varietății datelor: MDA și SHAP **extrapolează** (Hooker, Mentch & Zhou (2021)); permutați în interiorul grupurilor sau reestimați fără caracteristică
- Importanțele sunt estimatii și cer o analiză proprie a incertitudinii; arborii “onești” dau *predicții* de pădure asimptotic normale și CI (Wager & Athey (2018)), nu CI pentru importanțe
- **Backtestul nu este un instrument de cercetare**, analiza importanței este: López de Prado (2018)

Backtest walk-forward: construcție

- ▣ Model: GBM reestimat în fiecare ianuarie pe toate datele trecute, cu purjarea etichetelor care se suprapun cu anul de test
- ▣ Regula: long pe S&P 500 dacă $\hat{p} > 0.5$, altfel numerar ($w_t \in \{0, 1\}$)
- ▣ Costuri: 5 bp pe unitatea de rulaj
- ▣ Perioada în afara eșantionului: 2010–2026, o reestimare pe an
- ▣ Reper: buy-and-hold ($w_t = 1$)

Backtest walk-forward: rezultate



- 2010–2026: Sharpe strategie **0.49** vs. buy-and-hold **0.66** (anualizat); expunere medie 77%
- Modelul a învățat în principal “fii long”, iar ieșirile au venit la momente greșite
- $d = 0.25$ pentru `ffd_price` a fost ales pe 2000–2026; cu $d = 0.15$, ales prin aceeași regulă pe datele până în 2009, SR = 0.43; fără `ffd_price`, 0.51

Walk-forward: este diferența semnificativă?

- Walk-forward 2010–2026, $n = 4,198$ zile, 60.2% “sus”; reper: prognoza constantă = proporția “sus” din antrenare
- Logit (include constanta): log-loss 0.6822 vs. 0.6757
 - ▶ DM $t = 2.39$ ($p = 0.017$): logit-ul estimat este semnificativ *mai slab*
 - ▶ Clark–West $t = -0.21$ (p unilateral = 0.58): nicio dovadă că informația caracteristicilor contează
 - ▶ Giacomini–White = 5.77 (χ^2_2 , $p = 0.056$): nicio diferență semnificativă la 5%; aproximativ, pentru că fereastra se extinde
 - ▶ fereastră mobilă de 8 ani, cum cere teoria GW: GW = 26.5 ($p < 0.001$): logit-ul prognozează mai slab decât constanta
- GBM: log-loss 0.6971; DM $t = 5.09$, GW = 25.8 ($p < 0.001$): mai slab decât o constantă; Pesaran–Timmermann -0.74
- Sharpe 0.49 vs. 0.66 (SE Lo ≈ 0.25 fiecare): diferența -0.17 , SE HAC Ledoit–Wolf 0.095, $p = 0.073$; CI bootstrap pe blocuri $[-0.36; 0.02]$
- CI conține 0: nicio dovadă de abilitate și nicio dovadă semnificativă că strategia este mai slabă decât buy-and-hold

Recapitulare: studiul de caz

- ▣ Patru modele, 14 caracteristici, 25 de ani, validare purjată; d al caracteristicii FFD a fost ales pe tot eșantionul, iar fără ea concluzia nu se schimbă
- ▣ Niciun model nu bate “mereu în sus” (58,1%); Pesaran–Timmermann nu găsește o abilitate direcțională semnificativă; fiecare CI pentru AUC conține 0,5
- ▣ Importanțele sunt minuscule și diferă între măsurile în eșantion și în afara lui
- ▣ Walk-forward: modelele pierd în fața unei constante la log-loss (DM, GW); Sharpe 0.49 vs. 0.66, $p = 0.073$
- ▣ Un rezultat negativ onest este un rezultat

Testarea multiplă și biasul de selecție

- ▣ Un **backtest**: simularea unei strategii pe date istorice
- ▣ Un cercetător încearcă N strategii sau configurații și o raportează pe cea mai bună
- ▣ Chiar dacă toate au Sharpe real zero, $\max_n \widehat{SR}_n$ crește cu N
- ▣ **Biasul de selecție**: maximul raportat supraestimează performanța reală
- ▣ [Harvey, Liu & Zhu \(2016\)](#): față de sutele de factori publicați, un factor nou are nevoie de o statistică t peste 3, nu peste 2

Teorema strategiei false


Teoremă 1 (Teorema strategiei false, Bailey & López de Prado (2014))

- ▣ Fie $\widehat{SR}_n$, $n = 1, \dots, N$, estimări independente, aproximativ $N(0, \text{Var}[\widehat{SR}])$ (fără abilitate); atunci **raportul Sharpe maxim așteptat** este

$$\mathbb{E}\left[\max_n \widehat{SR}_n\right] \approx \sqrt{\text{Var}[\widehat{SR}]} \left[(1 - \gamma) \Phi^{-1}\left(1 - \frac{1}{N}\right) + \gamma \Phi^{-1}\left(1 - \frac{1}{N_e}\right) \right]$$


- ▣ $\gamma \approx 0.5772$: constanta Euler–Mascheroni; Φ : funcția de repartiție a distribuției Normale standard
- ▣ Pentru randamente i.i.d., $\text{Var}[\widehat{SR}] \approx 1/T$ pe perioadă

Cea mai bună din N strategii fără abilitate



- Strategii cu randamente i.i.d. de medie zero, 5 ani de date zilnice ($\text{Var}[\widehat{SR}]$ anualizat $\approx 1/5$)
- Încercând $N = 1000$ variante obținem un Sharpe maxim de ≈ 1.45 — **fără nicio abilitate**
- Simularea Monte Carlo confirmă teorema

În eșantion vs. în afara eșantionului: căutare pe grilă pe Bitcoin



- Încrucișare de medii mobile (MA) pe Bitcoin: long când MA rapidă a logaritmului prețului depășește MA lentă cu mai mult decât o bandă
- 1,279 de configurații (fereastră rapidă, fereastră lentă, bandă); în eșantion 15 mai 2015 – 2020, în afara eșantionului 2021–2026
- Toate regulile încep în prima zi în care există cea mai lentă medie (240 de zile)

Căutarea pe grilă pe Bitcoin: interpretare

- ▣ Cea mai bună configurație IS (14/20 zile): $SR_{IS} = 1.89 \rightarrow SR_{OOS} = 0.02$ (anualizat cu $\sqrt{365}$)
- ▣ Corelația de rang Spearman dintre rapoartele Sharpe IS și OOS: $\rho = 0.18$
- ▣ SR OOS median: 0,55 pentru cele mai bune 10% dintre configurațiile IS vs. 0,42 pentru toate
- ▣ *Familia* de reguli de trend conține ceva informație, dar optimul *selectat* este zgomot

Raportul Sharpe probabilistic

Definiție 10 (Raportul Sharpe probabilistic (PSR), Bailey & López de Prado (2012))

- $\widehat{SR}$ observat pe perioadă din T randamente, asimetrie $\hat{\gamma}_3$, kurtosis $\hat{\gamma}_4$ (distribuția Normală: $\gamma_4 = 3$):

$$\widehat{PSR}(SR^*) = \Phi \left(\frac{(\widehat{SR} - SR^*)\sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3 \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \widehat{SR}^2}} \right)$$

- Asimetria $\gamma_3 = \mathbb{E}[(r - \mu)^3]/\sigma^3$; kurtosis $\gamma_4 = \mathbb{E}[(r - \mu)^4]/\sigma^4$ (Capitolul 1)
- PSR = probabilitatea ca SR real să depășească un reper SR^* , ținând cont de lungimea eșantionului și de non-normalitate
- Numitorul este $\sqrt{T \text{Var}(\widehat{SR})}$ din metoda delta a Secțiunii 3

Raportul Sharpe deflatat

Definiție 11 (Raportul Sharpe deflatat (DSR), Bailey & López de Prado (2014))

□ $DSR = \widehat{PSR}(SR_0)$, cu reperul egal cu maximul așteptat sub ipoteza nulă de lipsă a abilității:


$$SR_0 = \sqrt{\text{Var}[\widehat{SR}_n]} \left[(1 - \gamma) \Phi^{-1}\left(1 - \frac{1}{N}\right) + \gamma \Phi^{-1}\left(1 - \frac{1}{N_e}\right) \right]$$

- DSR corectează pentru **biasul de selecție** (N încercări), **non-normalitate** și **lungimea eșantionului**
- Respingem strategia dacă $DSR \leq 0.95$; raportăm N onest

Exemplu rezolvat: DSR pentru cea mai bună regulă pe Bitcoin

- ▣ Cea mai bună regulă IS: $T = 2,058$ randamente zilnice, $\widehat{SR} = 0.0991$ pe zi (1.89 anualizat), $\hat{\gamma}_3 = 0.12$, $\hat{\gamma}_4 = 12.33$
- ▣ Numitorul: $\sqrt{1 - 0.12 \cdot 0.0991 + \frac{12.33-1}{4} \cdot 0.0991^2} = 1.008$
- ▣ $N = 1,279$ încercări. Două alegeri pentru $\text{Var}[\widehat{SR}_n]$:
 - ▶ dispersia celor 1,279 de SR (abatere standard 0.0106): $SR_0 = 0.035/\text{zi}$, $z = 2.88$, $DSR = 0.998$
 - ▶ valoarea pentru încercări independente $1/T$ (abatere standard 0.0220): $SR_0 = 0.073/\text{zi}$, $z = 1.16$, $DSR = 0.877 < 0.95$
- ▣ Încercările sunt puternic corelate (ferestre vecine), deci dispersia lor subestimează căutarea reală: verdictul depinde de această alegere
- ▣ Raportul Sharpe de 0,02 în afara eșantionului este în acord cu valoarea conservatoare

Raportul Sharpe deflatat în practică



- 5 ani de randamente zilnice, asimetrie -0.5 , kurtosis 6
- Un SR anualizat de 1,0 este semnificativ doar dacă (aproape) nicio altă strategie nu a fost încercată: pică după 2–3 încercări
- SR = 1,5 rezistă la ≈ 10 încercări, SR = 2,0 la ≈ 200 ; doar SR = 2,5 rezistă la 1000

Teste de data snooping: Reality Check, SPA, Romano–Wolf

- ▣ K reguli, diferențe de performanță $d_{k,t} = r_{k,t} - r_{0,t}$ față de un reper r_0 ; $H_0 : \max_k \mathbb{E}[d_{k,t}] \leq 0$
- ▣ Reality Check (RC, [White \(2000\)](#)): statistica $\max_k \sqrt{n} \bar{d}_k$; distribuția sub H_0 din **bootstrap-ul staționar** ([Politis & Romano \(1994\)](#)) al întregii matrice $n \times K$
 - ▶ reeșantionarea unor zile întregi păstrează corelația dintre reguli: nu mai trebuie numărate încercările “efective”
- ▣ Superior Predictive Ability (SPA, [Hansen \(2005\)](#)): $\max_k \sqrt{n} \bar{d}_k / \hat{\omega}_k$ studentizat; regulile clar proaste nu sunt recentrate, deci adăugarea unor reguli inutile nu distruge puterea
- ▣ Romano–Wolf StepM ([Romano & Wolf \(2005\)](#)): procedură descendentă care arată *care* reguli bat reperul, cu controlul probabilității de cel puțin o eroare de tip I (FWER)
- ▣ DSR întreabă “este cel mai bun SR peste norocul a N încercări?” și are nevoie de N și de $\text{Var}[\widehat{SR}]$; aceste teste le iau pe amândouă din date

SPA vs. DSR pe grila Bitcoin

- 1,279 de reguli de medii mobile, perioada în eșantion, $n = 2,058$ zile; bootstrap staționar, bloc mediu de 20 de zile, 2,000 de replici
- Reper **numerar** ($r_0 = 0$): RC $p = 0.004$, SPA $p = 0.002$; StepM păstrează 314 reguli
 - ▶ o regulă de trend a câștigat în medie: trendul propriu al Bitcoin, comun întregii grile
- Reper **buy-and-hold**: cea mai mare statistică studentizată 0.88 (regula 14/20); RC $p = 0.74$, SPA $p = 0.70$; StepM păstrează 0 reguli
 - ▶ nicio regulă nu bate semnificativ simpla deținere de Bitcoin, nici măcar în eșantion
- DSR pentru aceeași regulă: 0.998 sau 0.877, după alegerea lui $\text{Var}[\widehat{SR}]$ (exemplul rezolvat); SPA nu cere această alegere
- În afara eșantionului câștigătoarea a obținut SR 0.02: în acord cu verdictul SPA față de buy-and-hold

Probabilitatea de supraajustare a backtestului (PBO)

Validare încrucișată combinatorică simetrică (CSCV): Bailey, Borwein, López de Prado & Zhu (2017)

1. Matricea M de randamente: T perioade $\times N$ configurații de strategie
2. Împărțim rândurile în S blocuri; pentru fiecare dintre cele $\binom{S}{S/2}$ combinații formăm IS (jumătate din blocuri) și OOS (cealaltă jumătate)
3. Alegem cea mai bună configurație n^* în eșantion; calculăm rangul ei relativ $\bar{\omega} \in (0, 1)$ în afara eșantionului
4. Logit $\lambda = \log \frac{\bar{\omega}}{1-\bar{\omega}}$
5. $PBO = \Pr[\lambda < 0]$: probabilitatea ca învingătorul IS să fie sub mediana OOS

Interpretarea PBO

- ▣ $PBO \approx 0$: învingătorul în eşantion rămâne sigur peste mediană în afara eşantionului
- ▣ $PBO \approx 0.5$ sau mai mare: procesul de selecție nu are abilitate — a alege învingătorul IS este ca și cum ai alege la întâmplare
- ▣ PBO completează DSR: evaluează **procedura de cercetare**, nu o singură strategie
- ▣ Ambele cer înregistrarea **fiecărei** încercări, inclusiv a celor eșuate

Recapitulare: supraajustarea backtestului

- Cel mai bun dintre multe backtesturi este deplasat în sus: 1000 de încercări fără abilitate dau un Sharpe de ≈ 1.45
- Grila pe Bitcoin: învingătorul IS 1.89 $\rightarrow$ OOS 0.02
- PSR corectează pentru lungimea eșantionului și non-normalitate; DSR și pentru numărul de încercări
- RC / SPA / StepM fac bootstrap pe întreaga grilă: față de buy-and-hold nicio regulă Bitcoin nu rezistă ($p = 0.70$)
- PBO măsoară fiabilitatea întregii proceduri de selecție
- Înregistrați N și corectați raportul Sharpe înainte de a interpreta rezultatele

Selecția LASSO nu este inferență

- ▣ Drumul LASSO (Secțiunea 2) răspunde la “ce caracteristică intră prima”, nu la “ce caracteristică contează”
- ▣ Statisticile t OLS după selecția LASSO ignoră pasul de selecție: sunt prea optimiste și nu sunt uniform valide
- ▣ O variabilă de control corelată cu regresorul de interes d_t , dar doar slab cu y_t , este eliminată
 - ▶ efectul ei trece în coeficientul lui d_t : bias de variabilă omisă
- ▣ Exemplul rezolvat (mai jos): LASSO pentru randamentul S&P 500 pe 5 zile, pe log VIX și 90 de controale, nu păstrează **niciun** regresor
 - ▶ “VIX nu contează”, raportat fără nicio eroare standard
- ▣ Remedii: împărțirea eșantionului, selecția dublă, machine learning dublu (DML)

Selecția dublă (post-double selection)

- ▣ Model parțial liniar: $y_t = \theta d_t + g(x_t) + \varepsilon_t$, $d_t = m(x_t) + v_t$; $\mathbb{E}[\varepsilon_t | d_t, x_t] = 0$, $\mathbb{E}[v_t | x_t] = 0$, $\text{Var}(v_t) > 0$; g , m aproximativ rare (sparse)
- ▣ Belloni, Chernozhukov & Hansen (2014):
 1. LASSO pentru y_t pe $x_t \Rightarrow$ mulțimea selectată $\hat{S}_y$
 2. LASSO pentru d_t pe $x_t \Rightarrow$ mulțimea selectată $\hat{S}_d$
 3. OLS pentru y_t pe d_t și $x_{\hat{S}_y \cup \hat{S}_d}$; eroarea standard robustă la heteroscedasticitate este validă pentru eșantionare independentă, condiții de regularitate și raritate $s^2 \log^2(p \vee n)/n \rightarrow 0$; pentru serii de timp, erorile HAC sunt o aproximare
- ▣ Funcția obiectiv LASSO $\frac{1}{n} \sum_t (y_t - x_t^\top \beta)^2 + \frac{\lambda}{n} \sum_j \hat{\psi}_j |\beta_j|$, plug-in $\lambda = 2c\sqrt{n} \Phi^{-1}(1 - \gamma/(2p))$, $c = 1.1$, $\gamma = 0.1/\log n$, ponderi $\hat{\psi}_j^2 = \frac{1}{n} \sum_t x_{tj}^2 \hat{e}_t^2$
- ▣ De ce funcționează: un control este omis doar dacă nu contează în *niciuna* dintre ecuații, deci biasul de omisiune este de ordinul doi

Machine learning dublu: scoruri ortogonale și cross-fitting

- ▣ Chernozhukov et al. (2018): rezidualizăm ambele variabile cu *orice* algoritm (LASSO, RF, boosting)

$$\tilde{y}_t = y_t - \hat{\ell}(x_t), \quad \tilde{v}_t = d_t - \hat{m}(x_t), \quad \hat{\theta} = \frac{\sum_t \tilde{v}_t \tilde{y}_t}{\sum_t \tilde{v}_t^2}$$

- ▣ Scor Neyman-ortogonal $\psi = (\tilde{y} - \theta \tilde{v}) \tilde{v}$: erorile de ordinul întâi din $\hat{\ell}$, $\hat{m}$ nu deplasează $\hat{\theta}$; cu $\ell(x) = \mathbb{E}[y | x]$, este suficient (alături de consistență și condiții de regularitate) ca $\|\hat{m} - m\| (\|\hat{\ell} - \ell\| + \|\hat{m} - m\|) = o_P(n^{-1/2})$, de exemplu ambele $o_P(n^{-1/4})$
- ▣ Cross-fitting: estimăm $\hat{\ell}$, $\hat{m}$ pe $K - 1$ pliuri, rezidualizăm pliul lăsat deoparte, repetăm; elimină biasul de supraajustare pe propriile observații
- ▣ Teoria publicată presupune eșantionare independentă
 - ▶ cu etichete suprapuse pe 5 zile folosim pliuri contigue, purjate cu 5 zile în jurul pliului de test (Secțiunea 6), și erori standard HAC
 - ▶ o limită a datelor, declarată ca atare, nu un estimator nou

Exemplu rezolvat: prezice VIX randamentele S&P 500?

- ▣ y_t : randamentul logaritmic pe următoarele 5 zile (bp); d_t : log VIX, standardizat (1 SD = 0.356)
- ▣ Controale: 12 caracteristici tehnice, pătratele lor și produsele două câte două, $p = 90$; $n = 6,269$
- ▣ Erori standard HAC (4 lag-uri); DML cu 5 pliuri contigue purjate

Metoda	$\hat{\theta}$ (bp)	SE
OLS, doar VIX	7.5	9.0
OLS, toate cele 90 de controale	-0.7	16.1
LASSO pe (VIX, controale)	eliminat	—
Selecție dublă	9.4	16.1
DML, algoritmi LASSO	4.8	19.7
DML, random forest	-11.7	16.7

- ▣ Selecția dublă păstrează $|\hat{S}_y| = 0$ și $|\hat{S}_d| = 15$ controale: cele care prezic VIX, pe care un singur LASSO le elimină
- ▣ CI 95% pentru selecția dublă: $[-22.1; 40.8]$ bp pe săptămână pentru o abatere standard a log VIX
- ▣ Interpretare: LASSO-ul simplu afirmă “niciun efect” cu o certitudine falsă; intervalele oneste conțin zero, dar și efecte predictive ale log VIX mari economic, pozitive și negative

Machine learning pentru inferență în evaluarea activelor

- [Feng, Giglio & Xiu \(2020\)](#): adaugă un factor nou informație de evaluare, date fiind sutele de factori existenți?
 - ▶ selecție dublă a factorilor de control din “grădina zoologică”, apoi un test t valid pentru prețul de risc al factorului nou
 - ▶ răspunsul inferențial la [Harvey, Liu & Zhu \(2016\)](#), care ridică pragul la $t > 3$
- Efecte eterogene: pădurile cauzale “oneste” dau CI pentru efecte care variază cu covariatele ([Wager & Athey \(2018\)](#))
- Trei reguli
 - ▶ predicția și inferența au ținte diferite: un predictor bun poate da un $\hat{\theta}$ deplasat
 - ▶ ortogonalizați înainte de a testa și faceți cross-fitting cu pliuri care respectă timpul
 - ▶ raportați CI; “selectat” sau “important” nu înseamnă “semnificativ”

Recapitulare: machine learning pentru inferență

- ▣ Selecția regularizată răspunde la o întrebare de predicție; coeficienții ei nu au erori standard valide
- ▣ Selecția dublă și DML dau inferență validă pentru un parametru, cu multe controale, în condiții de raritate sau de rată și cu eșantionare independentă
- ▣ Cross-fitting-ul trebuie să respecte timpul: pliuri contigue, purjate, și erori HAC
- ▣ VIX și randamentele S&P 500 pe 5 zile: datele nu pot decide (CI $[-22; 41]$ bp)
- ▣ Urmează: direcții noi și cum citim un rezultat ML dintr-o revistă de top

Virtutea complexității

- ▣ Kelly, Malamud & Zhou (2024): prognoza randamentului pieței prin regresii ridge pe P caracteristici Fourier aleatoare (transformări neliniare) ale câtorva predictorii
 - ▶ ferestre mobile de antrenare de doar $T = 12$ luni, cu P de ordinul miilor
- ▣ Teorie: modelele “complexe”, cu mai mulți parametri decât observații ($P > T$), domină modelele simple; R^2 în afara eșantionului poate fi negativ, în timp ce raportul Sharpe al strategiei de sincronizare **crește** cu complexitatea
 - ▶ dincolo de pragul de interpolare, soluția de normă minimă induce implicit shrinkage: “double descent”
- ▣ Empiric: modelele mai complexe dau rapoarte Sharpe mai mari în afara eșantionului pentru sincronizarea pieței
- ▣ O provocare pentru intuiția bias-varianță din Secțiunea 2: complexitatea nu înseamnă automat supraajustare
- ▣ Sinteza întregului domeniu: Kelly & Xiu (2023)

Cum citim un rezultat ML dintr-o revistă de top

- Nagel (2025): pentru $P \gg T$ prognoza este o medie a celor T randamente de antrenare, ponderată după similaritate
 - ▶ în ferestre scurte similaritatea înseamnă mai ales apropiere în timp și scade cu volatilitatea predictorilor: o strategie de **momentum ajustat la volatilitate**
 - ▶ pe date artificiale cu reversii metoda construiește aceeași strategie, care apoi pierde
- Avramov, Cheng & Metzker (2023): profiturile semnalelor deep learning vin din acțiuni greu de arbitrat; excluderea microcapitalizărilor, a firmelor în dificultate sau a episoadelor de volatilitate mare le atenuează, iar costurile de tranzacționare le erodează în continuare
- Chen, Pelger & Zhu (2024): impun structură economică; condițiile de moment fără arbitraj ale factorului stochastic de actualizare devin funcția de pierdere a unei rețele adânci
- Întrebări pentru orice rezultat
 - ▶ ce reper (zero, media istorică, buy-and-hold)? ce fereastră de antrenare?
 - ▶ tranzacționabil după costuri? la ce strategie mai simplă se reduce modelul?
 - ▶ ce test și câte încercări?

Deep learning pentru secvențe

Rețele recurente (LSTM, GRU)

- Starea ascunsă poartă memoria:
 $h_t = g(h_{t-1}, x_t)$
- Porțile controlează ce se păstrează sau se uită, atenuând dispariția gradientilor
- Folosite pentru prognoza volatilității, prognoze bazate pe registrul de ordine și prognoze intrazilnice

Transformer

- Auto-atenție: $\text{softmax}(QK^T / \sqrt{d_k})V$, cu matricele de interogare, cheie și valoare Q, K, V
- Dependență pe termen lung, antrenare paralelă
- Baza modelelor lingvistice mari (Capitolul 15)

Modele fundamentale pentru serii de timp

Modele de prognoză pre-antrenate

- Pre-antrenate pe colecții mari de serii, folosite **zero-shot** (fără reantrenare): Chronos (Ansari et al., 2024), TimesFM (Das et al., 2024), Moirai (Woo et al., 2024), Lag-Llama (Rasul et al., 2023)
 - Repere utile pentru prognoza volatilității și a volumului
 - Pentru randamente moștenesc aceleași limite de semnal/zgomot
 - Datele de pre-antrenare se pot suprapune cu perioada de test: o nouă formă de scurgere
-
- Tratatate pe larg, cu instrumentele de evaluare a prognozelor de risc din Capitolul 8, în Capitolul 14

Învățare prin recompensă, modele generative, XAI, risc

Învățare prin recompensă (RL)

- O politică $\pi(a | s)$ alege acțiuni a în stări s pentru a maximiza recompensa cumulată
- Execuție optimă, market making, deep hedging: Buehler et al. (2019)

Modele generative

- GAN, autoencodere variaționale (VAE), modele de difuzie: scenarii sintetice pentru teste de stres

AI explicabilă (XAI)

- Cerută de autorități (EU AI Act, scoring de credit, riscul de model)
- SHAP, LIME (explicații locale interpretabile, independente de model), dependență parțială

ML pentru risc

- Value-at-Risk (VaR): cuantile condiționate (păduri de regresie cuantilică, boosting cu pierdere cuantilică); Expected Shortfall (ES): media cuantilelor estimate din coadă sau o pierdere comună VaR-ES; volatilitatea: o țintă pe randamentele la pătrat (Capitolele 7-8)

- Quantinar:  Reinforcement Learning  GANs  Explainable AI  ML in Financial Risk

Deep learning în evaluarea activelor: întrebarea de cercetare

- **Chen, Pelger & Zhu (2024)**: estimează factorul stochastic de actualizare (SDF) M_{t+1} care evaluează **toate acțiunile individuale de pe piața americană**, condiționat de multe caracteristici ale firmelor și de întregul istoric al seriilor macroeconomice (Introducere)
 - ▶ Absența arbitrajului: $E_t[M_{t+1} R_{t+1,i}^e] = 0$ pentru orice randament în exces $R_{t+1,i}^e$ (Secțiunea I.A)
 - ▶ Cu $M_{t+1} = 1 - \omega_t^\top R_{t+1}^e$, ponderile ω_t sunt cele ale portofoliului tangent condiționat $F_{t+1} = \omega_t^\top R_{t+1}^e$ (ec. 1), deci $E_t[R_{t+1,i}^e] = \beta_{t,i} E_t[F_{t+1}]$
- Pornește de la **Gu, Kelly & Xiu (2020)**: rețeaua cu cele mai bune rezultate prognozează $E_t[R_{t+1,i}^e]$ prin cele mai mici pătrate și este aici reperul, rețeaua feedforward (FFN)
 - ▶ Modelul de prognoză explică variația (un moment de ordinul doi) acolo unde raportul semnal/zgomot este mic; condiția de absență a arbitrajului țintește prima de risc (un moment de ordinul întâi), iar media în timp elimină o mare parte din zgomot (Introducere)
- De ce contează: un singur estimator pentru trei întrebări deschise ale evaluării activelor
 - ▶ forma funcțională a SDF; activele de test potrivite; stările economiei
- Legături cu acest capitol
 - ▶ Rețele, dropout și ansambluri (secțiunea Metode de machine learning); o împărțire în ordine temporală în locul pliurilor amestecate
 - ▶ Lecția din “Cum citim un rezultat ML dintr-o revistă de top”: întâi structura economică, apoi flexibilitatea

Deep learning în evaluarea activelor: date și metodă

Date (Secțiunea III.A)

- Randamente lunare ale tuturor acțiunilor din CRSP, ianuarie 1967 – decembrie 2016, în exces față de dobânda la titlurile de stat pe o lună
- 46 de caracteristici ale firmelor, în șase grupe: randamente trecute, investiții, profitabilitate, active necorporale, valoare, fricțiuni de tranzacționare (Tabelul A.II)
 - ▶ Doar lunile cu toate cele 46 de caracteristici: circa 10.000 din 31.000 de acțiuni; caracteristicile devin ranguri lunare normalizate transversal
- 178 de serii macroeconomice: 124 din FRED-MD (McCracken & Ng (2016)), cele 46 de mediane lunare ale caracteristicilor, 8 predictorii din Welch & Goyal (2008); transformate în serii staționare
- Împărțire: antrenare 1967–1986, validare 1987–1991, test 1992–2016

Metodă (Secțiunile I–II, Anexa C)

- Metoda generalizată a momentelor, adversarială: $\min_{\omega} \max_g \frac{1}{N} \sum_j (E[M_{t+1} R_{t+1,j}^e g(l_t, l_{t,j})])^2$ (ec. 3); g construiește activele de test cu cele mai mari erori de evaluare, după Hansen & Jagannathan (1997)
- Rețele: o FFN pentru ω ; un LSTM care sintetizează istoricul macro în 4 stări ascunse; adversarul g , cu 8 instrumente; trei pași: SDF necondiționat, maximizare după g , din nou minimizare; modelul complet: GAN (II.D)
- Hiperparametri: 384 de configurații, ordonate după raportul Sharpe (SR) pe validare; aleasă: 2 straturi de câte 64 de unități, dropout, Adam; ansamblu de 9 estimări (Tabelul A.VIII); coeficienți beta: o a doua FFN estimează $E_t[R_{t+1,i}^e F_{t+1}] \propto \beta_{t,i}$
- Repere: FFN din Gu, Kelly & Xiu (2020); SDF liniar $\omega_{t,i} = \theta^\top l_{t,i}$ pe componentele long și short ale fiecărei caracteristici, fără regularizare (LS) sau cu elastic net (EN); portofoliile tangente FF3/FF5 (Fama & French (2015))
- Măsuri: SR al lui F ; $EV = 1 - \bar{\hat{e}}^2 / (\overline{R^e})^2$ (medii în timp ale mediilor transversale lunare); R^2 transversal: unu minus raportul dintre media pătratelor reziduurilor medii și media pătratelor randamentelor medii, ponderi T_i / T (II.F)


Deep learning în evaluarea activelor: rezultate-cheie, 1992–2016

- Sursa: Chen, Pelger & Zhu (2024), *Management Science*
- SR lunar al SDF în afara eșantionului (Tabelul I): GAN 0,75, EN 0,50, FFN 0,44, LS 0,42; FF5 0,22, FF3 0,19 (Tabelul A.VI)
 - ▶ Interpretare: anualizat, 2,6 față de 1,7 (EN) și 1,5 (FFN); modelul liniar fără arbitraj regularizat (EN) întrece deja rețeaua de prognoză; LS, fără regularizare, nu
- Acțiuni individuale (Tabelul I): EV 8% (GAN) față de 3–4%; R^2 transversal 23% față de 14–19%
 - ▶ Interpretare: criteriul bazat pe absența arbitrajului îmbunătățește ambii indicatori, deși nu îi maximizează direct
- Portofolii pe decilele coeficienților β (Tabelul II, perioada de test, anualizat): diferența dintre decila superioară și cea inferioară 0,39; alfa FF5 0,39, $t = 9,96$; testul GRS respinge CAPM, FF3 și FF5 ($p = 0,00$)
 - ▶ Interpretare: coeficienții beta au o relație liniară cu randamentele medii ($R^2 = 0,97$ al randamentului mediu pe β , Figura 8), iar modelele factoriale nu le explică randamentele
- 46 de seturi de decile sortate după caracteristici (Tabelul III): R^2 transversal GAN peste 90% pentru toate; EV inversare pe termen scurt 0,70 față de 0,43 (EN), momentum 0,54 față de 0,26
 - ▶ Interpretare: câștigurile vin din decilele extreme și din interacțiuni; toate modelele explică bine decilele de mărime și de valoare contabilă/de piață (Secțiunea III.E)
- Stări macro (Figura 6): includerea directă a celor 178 de serii reduce puternic SR în afara eșantionului; GAN pierde circa 10% fără stările macro și 20% doar cu momente necondiționate
 - ▶ Interpretare: LSTM surprinde dinamica macroeconomică pe care ultima variație observată nu o poate reda
- Acțiuni cu capitalizare mare (Tabelul IV, SR lunar, modele estimate pe toate acțiunile, evaluate pe subeșantion): circa 1.500 de acțiuni GAN 0,41, FFN 0,30, EN 0,15; circa 550 de acțiuni 0,26, 0,24, 0,23; reestimate pe cele 1.500: 0,42, 0,28, 0,42
 - ▶ Interpretare: avantajul scade puternic pentru acțiunile cu cea mai mare capitalizare; EN recuperează când este reestimat pe ele

Deep learning în evaluarea activelor: replicare, limite și extindere


- Limită de date: panelul la nivel de acțiune (randamente CRSP, 46 de caracteristici) nu e în datele cursului, deci GAN pe acțiuni individuale nu poate fi reprodus
- Cu [Kenneth French Data Library](#) și FRED-MD, pe împărțirea publicată
 - ▶ Replicabile: ponderile tangente FF3 și FF5 estimate pe 1967–1986 (nota 23), SR lunar pe 1992–2016, alături de Tabelul A.VI
 - ▶ Nereplicabile cu datele cursului: LS și EN publicate (Tabelele I și III) folosesc ramuri ponderate după rang pentru 46 de caracteristici și coeficienți beta la nivel de acțiune
 - ▶ Analog pe date de portofoliu, o extindere, nu o replicare: SDF liniar ($\hat{\theta}_{LS}$ în formă închisă, $\hat{\theta}_{EN}$ cu obiectivul din Secțiunea II.F) pe jumătățile (decilele 1–5, 6–10) celor 15 caracteristici pe care biblioteca le sortează în decile; nivelurile nu sunt comparabile cu Tabelele I și III
- Limite declarate de autori
 - ▶ Pozitivitatea SDF nu este impusă (nota 9); doar lunile cu toate caracteristicile, ceea ce elimină mai ales acțiunile foarte mici (Secțiunea III.A)
 - ▶ Fricțiuni (Secțiunea III.I, Figura 17): SR anual 1,73 fără cele mai mici 40% dintre acțiuni, 2,07 fără cele mai mari 40% dintre marjele bid–ask, 1,87 fără cele 40% cu rulajul cel mai mic; vezi și [Avramov, Cheng & Metzker \(2023\)](#)
 - ▶ Valorile indicatorilor sunt mai mari în eșantion decât în afara lui, semn de o anumită supraajustare (Secțiunea III.C); stările ascunse nu sunt comparabile între estimări, deci nu pot fi mediate (Secțiunea II.E)
- Extindere deschisă: păstrați specificația aleasă pe 1967–1991 și evaluați-l pe 2017–2026, după eșantionul lucrării; mai întrec SDF-ul liniar fără arbitraj modelul FF5 și adaugă ceva stările LSTM extrase din FRED-MD?

Deep learning în evaluarea activelor: rapoarte Sharpe, lucrare și replicare



- Albastru: lucrarea (Tabelul I, Tabelul A.VI); roșu: portofoliile tangente FF3 și FF5, $w \propto \hat{\Sigma}^{-1} \hat{\mu}$, pe factorii din [Kenneth French](#), cu ponderi fixate pe 1967–1986, SR lunar pe 1992–2016 ($T = 300$)
- Calculul nostru: FF5 0,22, CI 95% [0,11; 0,34]; FF3 0,20, CI [0,08; 0,31] (SE 0,058, [Lo \(2002\)](#)); în lucrare: 0,22 și 0,19

Deep learning în evaluarea activelor: reperele Fama–French după 2016



- Aceleași ponderi fixe, ianuarie 1992 – august 2026; fiecare serie e scalată la volatilitatea randamentului excedentar al pieței (Mkt-RF) pe 1992–2016; suma cumulată a randamentelor excedentare lunare
- SR lunar, 2017–2026 ($T = 116$, $SE \approx 0,09$): FF5 0,06, FF3 0,03, piața 0,24; pe 1992–2016: 0,22, 0,20, 0,15

Deep learning în evaluarea activelor: cum citim cele două grafice

- Reperele Fama–French din lucrare se reproduc pe date publice: ambele valori publicate se află în intervalele de încredere de 95% ale replicării
 - ▶ GAN 0,75 față de FF5 0,22: cu erorile standard Lo 0,065 și 0,058, SE a diferenței este cel mult 0,12, oricare ar fi corelația, deci diferența depășește 4 SE (randamente i.i.d. normale); un test pereche pe randamente aliniate (Ledoit & Wolf (2008)) este mai precis
- Ponderile fixe ale FF5 se concentrează pe profitabilitate și investiții: RMW 0,42, CMA 0,30 (ponderi scalate la $\sum |w| = 1$)
 - ▶ FF3 alocă 0,61 factorului HML; ambele combinații au fost alese pe 1967–1986
- După 2016, portofoliile tangente cu ponderi fixe au rapoarte Sharpe lunare mult sub cel al pieței
 - ▶ Cu $T = 116$ luni, SE e de circa 0,09: un semnal de alarmă, încă nu un test
 - ▶ Pentru GAN întrebarea e aceeași: rezistă în afara eșantionului, după lucrare, o specificație fixată în 1991?

O întrebare deschisă: descoperire sau căutare în date la scară mare?

- Chen, Lopez-Lira & Zimmermann (2022): căutarea printre 29.000 de rapoarte contabile a celor cu $t > 2$ dă o predictibilitate transversală asemănătoare cu cea a predictorilor publicați în reviste cu evaluare inter pares; pentru ambele, circa jumătate rămâne după eşantioanele originale
- Novy-Marx & Velikov (2025): un flux automat cu LLM caută peste 30.000 de semnale, păstrează 96 care trec un protocol fix și scrie sute de articole complete, cu motivații inventate și câteva citări imaginare
 - ▶ HARKing (hypothesising after the results are known, formularea ipotezelor după ce se cunosc rezultatele) la scară industrială
- Deschis: când o mașină propune variabilele, modelul și povestea, care este numărul de încercări N și ce dovezi mai separă o descoperire de cea mai bună dintre multe extrageri (DSR și PBO, Supraajustarea backtestului)?
- Formal: $H_{0,j} : \beta_j = 0, j = 1, \dots, M$; controlăm FWER (Holm) sau FDR (Benjamini & Hochberg (1995)); Harvey, Liu & Zhu (2016) cer unui factor nou $t > 3$

Bucula descoperirii, pas cu pas (1/2)

- **Literatura:** "Rezumă dovezile despre cât din predictibilitatea publicată a randamentelor rezistă în afara eșantionului și după publicare: DOI sau id arXiv, eșantion, estimarea principală a scăderii."
 - ▶ Verificați fiecare identificator; Semantic Scholar, Google Scholar, Elicit pentru căutare
- **Ipoteze:** "Pentru o variabilă care prognozează randamentele S&P 500 în 2001-2015, dă explicații concurente (primă de risc, inversare, microstructură, căutare în date) și ce prezice fiecare pentru 2016-2026 și pentru alți indici."
- **Date și cod:** "Scrie cod Python care construiește 34 de variabile tehnice din data/market/GSPC.INDX.csv și VIX.INDX.csv doar cu informația până în ziua t și raportează statisticile t Newey-West pentru randamentele la 1, 5 și 20 de zile în 2001-2015."
 - ▶ Orice asistent (Claude, ChatGPT, Gemini, GitHub Copilot); reproduceți întâi studiul de caz: "mereu în sus" 58,1%

Bucula descoperirii, pas cu pas (2/2)

- **Robustețea**, fixată dinainte: "Scrie planul de analiză: lista completă de variabile și orizonturi, perioada de verificare, corecțiile (Holm, BH, max-t) și rezultatul care ar conta drept eșec."
 - ▶ Placebo: deplasarea circulară a țintei (cu 250–3,000 de zile) rupe alinierea cu variabilele, dar păstrează dependența proprie a fiecărei serii; un nul valid pentru $\max_j |t_j|$ dacă ținta este staționară și deplasările depășesc durata dependenței ei
- **Critica**: "Joacă rolul unui recenzent: care dintre aceste variabile semnificative sunt un singur efect numărat de mai multe ori și care sunt anomalii cunoscute, nu noi?"
- **Raportul**: toate cele M teste, toate încercările, inclusiv cele abandonate, DSR și PBO pentru orice strategie construită pe ele

Ce verifică cercetătorul

- **Scurgeri de informație:** variabile standardizate sau selectate pe tot eșantionul
 - ▶ Test: estimați orice transformare în interiorul setului de antrenare; CV cu purjare și embargo (Validarea încrucișată în finanțe)
- **Încercări numărate incomplet:** asistentul renunță în tăcere la variantele eșuate
 - ▶ Test: notați fiecare propunere; M din corecție le numără pe toate
- **Teste corelate:** douăzeci de ferestre ale aceluiași efect par douăzeci de descoperiri
 - ▶ Test: $\max_j |t_j|$ sub o ipoteză nulă comună sau gruparea prealabilă a variabilelor
- **Vin vechi, etichetă nouă:** o variabilă “nouă” este o anomalie cunoscută sau referința ei nu există
 - ▶ Test: verificați fiecare DOI; comparați cu listele publicate de anomalii
- **Suprapunerea etichetelor:** etichetele de antrenare care acoperă mai multe zile se suprapun cu intervalele etichetelor de validare
 - ▶ Test: purjarea; experimentul de scurgere din acest capitol (69% pe zgomot pur)

Mini-studiu de caz: 102 teste, un singur efect vechi rezistă

- O propunere tipică a unui asistent: “adaugă mai mulți indicatori: momentum, distanțe față de mediile mobile, rapoarte de volatilitate, RSI și variații ale VIX pe mai multe ferestre”
 - ▶ Testăm 34 de variabile $\times$ 3 orizonturi (1, 5, 20 de zile) = 102 regresii predictive pe 2001–2015, t Newey–West
- $|t| > 1,96$: 21 din 102, față de 5,1 așteptate sub ipoteza nulă globală la 5%
- Holm (FWER 5%): 0; BH (FDR 10%): 13; $|t| > 3$: 4
- Nulul comun (500 de deplasări circulare ale țintei): cuantila de 95% a lui $\max_j |t_j| = 3,32$; un supraviețuitor, randamentul pe o zi pentru randamentul zilei următoare, $t = -3,37$: inversarea pe termen scurt, un efect cunoscut
- Perioada de verificare 2016–2026: 3 din cele 21 își păstrează semnul cu $|t| > 1,96$, toate variante de inversare ($t = -2,17$ pentru randamentul pe o zi); “descoperirile” bazate pe VIX eșuează
- Interpretare: Holm (FWER 5%) și BH (FDR 10%) controlează rate de eroare diferite, la niveluri diferite, deci nu trebuie să coincidă; garanția BH cere independență sau dependență pozitivă de regresie a valorilor p ale ipotezelor nule adevărate, pe care predictorii corelați nu o asigură. Singurul rezultat robust este unul vechi

 ai_discovery_case.py

Rândul vostru: un punct de plecare pentru proiect

- Întrebarea: poate o căutare de variabile asistată de AI să găsească un predictor al randamentelor indicilor (S&P 500, BET, Bitcoin) care rezistă unei corecții preînregistrate și unei perioade de verificare, dincolo de inversarea pe termen scurt?
- Replicați întâi: studiul de caz din acest capitol (“mereu în sus” 58,1%, Logit 57,6%, AUC 0,478) și acest mini-studiu (21 din 102, un supraviețuitor)
- Livrabile
 - ▶ O listă de variabile stabilită înainte de examinarea datelor; toate testele cu Holm, BH și nulul pentru $\max-|t|$; o perioadă de verificare
 - ▶ DSR și PBO pentru orice strategie construită pe supraviețuitori; o critică de tip recenzent și răspunsul vostru
- Notați fiecare prompt care a influențat o decizie în AI_USE.md; fiecare referință inventată, scurgere de informație sau încercare omisă din evidență, identificată în AI_ERRORS.md, cu testul care a identificat-o ([șabloane](#))

Listă de verificare

Date și caracteristici

- ☐ Date disponibile la momentul deciziei, fără bias de supraviețuire
- ☐ Memoria estimată cu CI (local Whittle), nu cu o regulă ADF
- ☐ Transformări estimate doar pe pliurile de antrenare

Etichete

- ☐ Etichete scalate cu volatilitatea, dependente de traiectorie
- ☐ Înregistrați intervalele etichetelor; ponderați după unicitate

Validare

- ☐ K-fold cu purjare / CPCV cu embargo
- ☐ Comparați mereu cu repere naive
- ☐ AUC și log-loss cu CI bootstrap pe blocuri
- ☐ Testați față de reper: PT, DM / CW / GW

Backtesting

- ☐ Includeți costurile de tranzacționare și slippage-ul
- ☐ Înregistrați fiecare încercare; raportați N
- ☐ DSR, SPA și PBO înainte de orice afirmație

Concluzii

- ▣ ML oferă modele flexibile, dar datele financiare oferă **puțin semnal și mult zgomot**
- ▣ Instrumentele clasice (LASSO, random forest, boosting, rețele neuronale) rămân de bază; partea specifică finanțelor este **procesul**
- ▣ O respingere ADF nu înseamnă staționaritate: FFD trunchiată a log-prețului S&P 500 rămâne $I(1)$; estimați memoria cu local Whittle
- ▣ Etichetarea cu trei bariere și meta-etichetarea produc etichete care reflectă tranzacționarea reală
- ▣ K-fold amestecat poate raporta 69% acuratețe pe zgomot pur: folosiți purjarea și embargoul
- ▣ Pe S&P 500 niciun model nu bate “mereu în sus” (PT, DM, GW); cel mai bun dintre multe backtesturi trebuie deflatat sau testat prin bootstrap (DSR, SPA)

Urmează

- ▣ Capitolul 14: deep learning și modele fundamentale pentru serii de timp; Capitolul 15: modele lingvistice mari și analiza sentimentului

Pentru aprofundare pe Quantinar

Cursuri avansate pe quantinar.com

-  Random Forests
-  Shapley Values
-  Shapley Curves: A Smoothing Perspective
-  Machine Learning in Financial Risk
-  Introduction to Reinforcement Learning
-  Generative Adversarial Networks
-  MSCA Digital: The Need for Explainable AI
-  Business Analytics and Data Science
-  Model Selection Criteria
-  PAC Learning

Bibliografie (1/9)

- ▣ Ané, T., Geman, H. (2000). Order flow, transaction clock, and normality of asset returns. *Journal of Finance*, 55(5), 2259–2284.
- ▣ Ansari, A.F. et al. (2024). Chronos: learning the language of time series. *arXiv:2403.07815*.
- ▣ Avramov, D., Cheng, S., Metzker, L. (2023). Machine learning vs. economic restrictions: evidence from stock return predictability. *Management Science*, 69(5), 2587–2619.
- ▣ Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- ▣ Bailey, D.H., López de Prado, M. (2012). The Sharpe ratio efficient frontier. *Journal of Risk*, 15(2), 3–44.
- ▣ Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Będowska-Sójka, B., Wójcik, P., Pele, D.T. (2026). Early warning systems for cryptocurrency markets: predicting 'zombie' assets using machine learning. *North American Journal of Economics and Finance*, 81, 102543.

Bibliografie (2/9)

- Belloni, A., Chernozhukov, V., Hansen, C. (2014). Inference on treatment effects after selection among high-dimensional controls. *Review of Economic Studies*, 81(2), 608–650.
- Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- Bergmeir, C., Hyndman, R.J., Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120, 70–83.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Buehler, H., Gonon, L., Teichmann, J., Wood, B. (2019). Deep hedging. *Quantitative Finance*, 19(8), 1271–1291.
- Campbell, J.Y., Thompson, S.B. (2008). Predicting excess stock returns out of sample: can anything beat the historical average? *Review of Financial Studies*, 21(4), 1509–1531.
- Campbell, M., Hoane, A.J., Hsu, F. (2002). Deep Blue. *Artificial Intelligence*, 134(1–2), 57–83.

Bibliografie (3/9)

- ▣ Chen, A.Y., Lopez-Lira, A., Zimmermann, T. (2022). Does peer-reviewed research help predict stock returns? *arXiv:2212.10317*.
- ▣ Chen, L., Pelger, M., Zhu, J. (2024). Deep learning in asset pricing. *Management Science*, 70(2), 714–750.
- ▣ Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *Econometrics Journal*, 21(1), C1–C68.
- ▣ Clark, P.K. (1973). A subordinated stochastic process model with finite variance for speculative prices. *Econometrica*, 41(1), 135–155.
- ▣ Clark, T.E., West, K.D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311.
- ▣ Das, A., Kong, W., Sen, R., Zhou, Y. (2024). A decoder-only foundation model for time-series forecasting. *Proceedings of the 41st International Conference on Machine Learning (ICML)*, PMLR 235.
- ▣ DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, 44(3), 837–845.

Bibliografie (4/9)

- Diebold, F.X., Mariano, R.S. (1995). *Comparing predictive accuracy*. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Dixon, M.F., Halperin, I., Bilokon, P. (2020). *Machine Learning in Finance: From Theory to Practice*. Springer.
- Fama, E.F., French, K.R. (2015). *A five-factor asset pricing model*. *Journal of Financial Economics*, 116(1), 1–22.
- Feng, G., Giglio, S., Xiu, D. (2020). *Taming the factor zoo: a test of new factors*. *Journal of Finance*, 75(3), 1327–1370.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- Friedman, J.H. (2001). *Greedy function approximation: a gradient boosting machine*. *Annals of Statistics*, 29(5), 1189–1232.
- Giacomini, R., White, H. (2006). *Tests of conditional predictive ability*. *Econometrica*, 74(6), 1545–1578.
- Gu, S., Kelly, B., Xiu, D. (2020). *Empirical asset pricing via machine learning*. *Review of Financial Studies*, 33(5), 2223–2273.

Bibliografie (5/9)

- Hansen, L.P., Jagannathan, R. (1997). Assessing specification errors in stochastic discount factor models. *Journal of Finance*, 52(2), 557–590.
- Hansen, P.R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). ...and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*. 2nd ed. Springer.
- Hoerl, A.E., Kennard, R.W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.
- Hooker, G., Mentch, L., Zhou, S. (2021). Unrestricted permutation forces extrapolation: variable importance requires at least one more model, or there is no free variable importance. *Statistics and Computing*, 31(6), 82.
- Hosking, J.R.M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176.
- Kelly, B., Malamud, S., Zhou, K. (2024). The virtue of complexity in return prediction. *Journal of Finance*, 79(1), 459–503.

Bibliografie (6/9)

- Kelly, B., Xiu, D. (2023). *Financial machine learning. Foundations and Trends in Finance*, 13(3–4), 205–363.
- Künsch, H.R. (1989). *The jackknife and the bootstrap for general stationary observations. Annals of Statistics*, 17(3), 1217–1241.
- Ledoit, O., Wolf, M. (2008). *Robust performance hypothesis testing with the Sharpe ratio. Journal of Empirical Finance*, 15(5), 850–859.
- Lo, A.W. (2002). *The statistics of Sharpe ratios. Financial Analysts Journal*, 58(4), 36–52.
- Lo, A.W. (2004). *The adaptive markets hypothesis. Journal of Portfolio Management*, 30(5), 15–29.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- López de Prado, M. (2020). *Machine Learning for Asset Managers*. Cambridge University Press.

Bibliografie (7/9)

- Lundberg, S.M., Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- McCracken, M.W., Ng, S. (2016). FRED-MD: a monthly database for macroeconomic research. *Journal of Business & Economic Statistics*, 34(4), 574–589.
- Nagel, S. (2025). Seemingly virtuous complexity in return prediction. NBER Working Paper 34104.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Novy-Marx, R., Velikov, M. (2025). AI-powered (finance) scholarship. NBER Working Paper 33363.
- Opdyke, J.D. (2007). Comparing Sharpe ratios: so where are the p-values? *Journal of Asset Management*, 8(5), 308–336.
- Pesaran, M.H., Timmermann, A. (1992). A simple nonparametric test of predictive performance. *Journal of Business & Economic Statistics*, 10(4), 461–465.
- Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.

Bibliografie (8/9)

- ▣ Rasul, K. et al. (2023). [Lag-Llama: towards foundation models for probabilistic time series forecasting](#). *arXiv:2310.08278*.
- ▣ Robinson, P.M. (1995). [Gaussian semiparametric estimation of long range dependence](#). *Annals of Statistics*, 23(5), 1630–1661.
- ▣ Romano, J.P., Wolf, M. (2005). [Stepwise multiple testing as formalized data snooping](#). *Econometrica*, 73(4), 1237–1282.
- ▣ Rosenblatt, F. (1958). [The perceptron: a probabilistic model for information storage and organization in the brain](#). *Psychological Review*, 65(6), 386–408.
- ▣ Shimotsu, K. (2010). [Exact local Whittle estimation of fractional integration with unknown mean and time trend](#). *Econometric Theory*, 26(2), 501–540.
- ▣ Shimotsu, K., Phillips, P.C.B. (2005). [Exact local Whittle estimation of fractional integration](#). *Annals of Statistics*, 33(4), 1890–1933.
- ▣ Tibshirani, R. (1996). [Regression shrinkage and selection via the lasso](#). *Journal of the Royal Statistical Society B*, 58(1), 267–288.

Bibliografie (9/9)

- Wager, S., Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523), 1228–1242.
- Welch, I., Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 21(4), 1455–1508.
- White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126.
- Woo, G. et al. (2024). Unified training of universal time series forecasting transformers. *arXiv:2402.02592*.
- Zou, H., Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society B*, 67(2), 301–320.
- **Cod și date:** github.com/danpele/MFM/tree/main/Quantlets/Ch_13