



Modelarea piețelor financiare

Capitolul 13: Machine Learning în finanțe



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/3)

- ▣ ADF: Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- ▣ CAPM: Capital Asset Pricing Model (modelul de evaluare a activelor financiare)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ CMA: Conservative Minus Aggressive (investment factor) (factorul investiții: firme conservatoare minus agresive)
- ▣ CPCV: Combinatorial Purged Cross-Validation (validare încrucișată combinatorie cu purjare)
- ▣ CRSP: Center for Research in Security Prices (Centrul de cercetare a prețurilor titlurilor (Universitatea din Chicago))
- ▣ CSCV: Combinatorially Symmetric Cross-Validation (validare încrucișată combinatorie simetrică)
- ▣ CV: Cross-Validation (validare încrucișată)
- ▣ CW: Clark–West (test for nested models) (testul Clark–West pentru modele imbricate)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ DML: Double/Debiased Machine Learning (machine learning dublu (fără distorsiune))
- ▣ DSR: Deflated Sharpe Ratio (raportul Sharpe deflatat)
- ▣ ELW: Exact Local Whittle (estimator) (estimatorul local Whittle exact)
- ▣ ES: Expected Shortfall (pierderea așteptată în coadă)
- ▣ EU: European Union (Uniunea Europeană)
- ▣ EV: Explained Variation (variația explicată)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ FDR: False Discovery Rate (rata descoperirilor false)
- ▣ FF3: Fama–French three-factor model (modelul Fama–French cu trei factori)
- ▣ FF5: Fama–French five-factor model (modelul Fama–French cu cinci factori)
- ▣ FFD: Fixed-width window Fractional Differentiation (diferențiere fracționară cu fereastră fixă)


Acronime folosite în acest material (2/3)

- ▣ FFN: FeedForward Network (rețea neuronală feedforward (fără bucle))
- ▣ FN: False Negative (fals negativ)
- ▣ FRED-MD: Federal Reserve Economic Data, Monthly Database (McCracken–Ng) (baza lunară de date macroeconomice a Rezervei Federale din St. Louis)
- ▣ FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- ▣ GAN: Generative Adversarial Network (rețea generativă adversarială)
- ▣ GBM: Gradient Boosting Machine (model de boosting pe gradient)
- ▣ GMM: Generalized Method of Moments (metoda generalizată a momentelor)
- ▣ GRS: Gibbons–Ross–Shanken (test) (testul Gibbons–Ross–Shanken)
- ▣ GRU: Gated Recurrent Unit (unitate recurentă cu porți)
- ▣ GW: Giacomini–White (test) (testul Giacomini–White)
- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HML: High Minus Low (value factor) (factorul valoare: B/M mare minus mic)
- ▣ IBM: International Business Machines (Corporation) (compania International Business Machines)
- ▣ IS: In-Sample (în eșantion)
- ▣ LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- ▣ LIME: Local Interpretable Model-agnostic Explanations (explicații locale interpretabile, independente de model)
- ▣ LLM: Large Language Model (model lingvistic mare)
- ▣ LS: Linear SDF estimated by unregularised Least Squares (SDF liniar estimat prin cele mai mici pătrate, fără regularizare)
- ▣ LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- ▣ LW: Local Whittle (estimator) (estimatorul local Whittle)
- ▣ MA: Moving Average (medie mobilă)
- ▣ MA20: 20-day Moving Average (medie mobilă pe 20 de zile)
- ▣ MDA: Mean Decrease Accuracy (scăderea medie a acurateții (importanța prin permutare))
- ▣ MDI: Mean Decrease Impurity (scăderea medie a impurității)
- ▣ ML: Machine Learning (învățare automată)
- ▣ MLP: MultiLayer Perceptron (perceptron multistrat)

Acronime folosite în acest material (3/3)

- MSCA: Marie Skłodowska-Curie Actions (programul european Acțiunile Marie Skłodowska-Curie)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- OOS: Out-Of-Sample (în afara eșantionului)
- PAC: Probably Approximately Correct (learning) (învățare probabil aproximativ corectă)
- PBO: Probability of Backtest Overfitting (probabilitatea de overfitting a backtest-ului)
- PCR: Principal Component Regression (regresia pe componente principale)
- PLS: Partial Least Squares (regresia prin cele mai mici pătrate parțiale)
- PSR: Probabilistic Sharpe Ratio (raportul Sharpe probabilistic)
- PT: Pesaran–Timmermann (test of directional accuracy) (testul Pesaran–Timmermann al acurateții direcționale)
- RC: Reality Check (White's test for data snooping) (testul Reality Check al lui White pentru data snooping)
- RF: Random Forest (pădure aleatoare)
- RL: Reinforcement Learning (învățare prin recompensă)
- RMW: Robust Minus Weak (profitability factor) (factorul profitabilitate: firme robuste minus slabe)
- ROC: Receiver Operating Characteristic (curve) (curba caracteristică de operare)
- RSI: Relative Strength Index (indicele puterii relative)
- SD: Standard Deviation (abatere standard)
- SDF: Stochastic Discount Factor (factorul stochastic de actualizare)
- SE: Standard Error (eroare standard)
- SHAP: SHapley Additive exPlanations (explicații aditive Shapley)
- SPA: Superior Predictive Ability (test) (testul abilității predictive superioare)
- SR: Sharpe Ratio (raportul Sharpe)
- TN: True Negative (adevărat negativ)
- TP: True Positive (adevărat pozitiv)
- VAE: Variational AutoEncoder (autoencoder variațional)
- VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)
- WF: Walk-Forward (validation) (validare progresivă în timp)

Traseul capitolului: fluxul de lucru ML în finanțe



- ▣ Partea I: problema de predicție, o trusă minimă de unelte, caracteristici și diferențiere fracționară, etichete, validare onestă
- ▣ Partea a II-a: un studiu de caz pe S&P 500 cu teste formale, selecția și overfitting-ul backtest-ului, machine learning (ML) pentru inferență, un studiu de caz de cercetare, AI pentru descoperire științifică; detaliile tehnice sînt în [► Anexă](#)
- ▣ După acest capitol puteți: construi caracteristici și etichete fără informație din viitor; valida cu purjare și embargo; testa un clasificator și un backtest față de un reper (PT, DM, DSR, SPA, PBO)
- ▣ **Look-ahead bias**: folosirea unor informații indisponibile la momentul deciziei; **biasul de selecție**: raportarea celei mai bune dintre multe încercări; [López de Prado \(2018\)](#): majoritatea eșecurilor țin de proces, nu de algoritm

Machine learning în finanțe: promisiuni și dificultăți

Promisiunea

- Forme funcționale flexibile, neliniare; interacțiuni descoperite automat
- Sute de predictorii candidați ("factor zoo", Capitolul 3)
- Date alternative: text, imagini, registre de ordine, date on-chain


Constrângerile

- **Raport semnal-zgomot** foarte mic; o singură istorie, dependentă serial, care nu poate fi repetată
- **Nestaționaritate**: regimuri, rupturi structurale; piețele se adaptează strategiilor care le exploatează
- Etichetele trebuie construite explicit; erorile au costuri financiare reale
- Risc foarte mare de **overfitting** (ajustarea zgomotului)

Ipoteza piețelor adaptive: Lo (2004)

- Predictibilitatea apare, este eliminată prin arbitraj și reapare: un model care a funcționat ieri este o **ipoteză**, nu o lege (eficiența pieței: Capitolul 2)
- Dificultatea nu constă în estimarea modelului, ci în **evitarea concluziilor false**: etichete corecte, validare corectă, backtest-uri oneste

Predictibilitatea direcției și a riscului



- Autocorelația de ordin k : $\rho_k = \text{Corr}(x_t, x_{t-k})$, corelația unei serii cu propria valoare de acum k zile
 - x_t : randamentul logaritmic zilnic r_t sau valoarea lui absolută $|r_t|$; T : numărul de observații
 - banda gri: $\pm 1,96/\sqrt{T}$, limitele de 95% sub ipoteza de autocorelație nulă; o bară în afara benzii este semnificativă la 5%
- Autocorelațiile randamentelor r_t sînt foarte mici (în interiorul benzii); cele ale lui $|r_t|$ sînt mari și persistente
- ML este cel mai util acolo unde datele au structură predictibilă: **volatilitate, risc, lichiditate, clasamente transversale**

Dovezi și valoarea economică a unui R^2_{OOS} mic (1/2)

- ▣ Gu, Kelly & Xiu (2020): randamente lunare ale acțiunilor americane individuale; modele liniare, regresii penalizate, regresia pe componente principale (PCR), regresia prin cele mai mici pătrate parțiale (PLS), păduri aleatoare, arbori antrenați prin boosting, rețele neuronale
- ▣ Măsura lor de potrivire, R^2 în afara eșantionului: cât din pătratul randamentului elimină prognoza, față de prognoza zero

$$R^2_{OOS} = 1 - \frac{\sum_t (r_t - \hat{r}_t)^2}{\sum_t r_t^2}$$

- ▶ r_t : randamentul realizat în luna t a perioadei de test; $\hat{r}_t$: prognoza făcută cu informația pînă la $t - 1$
- ▶ numitorul este eroarea prognozei zero, $\hat{r}_t = 0$
- ▶ $R^2_{OOS} > 0$: modelul depășește prognoza zero; $R^2_{OOS} < 0$: este mai slab; cel mult 1 (prognoze perfecte)
- ▣ Rezultat: R^2_{OOS} este mic (mult sub 1% pe lună); avantajul arborilor și al rețelilor provine din **interacțiuni neliniare**; predictorii dominanți sînt momentum-ul, lichiditatea și volatilitatea
- ▣ Reperul contează: Welch & Goyal (2008) arată că majoritatea predictorilor publicați nu depășesc **media istorică**; Gu, Kelly & Xiu (2020) și Capitolul 14 folosesc o prognoză zero

Dovezi și valoarea economică a unui R^2_{OOS} mic (2/2)

- ▣ Campbell & Thompson (2008): valoarea unui R^2 mic pentru un investitor; randamentul are o parte predictibilă și una impredictibilă

$$r_{t+1} = \mu + x_t + \varepsilon_{t+1}, \quad R^2 = \frac{\text{Var}(x_t)}{\text{Var}(r_{t+1})}$$

- ▶ μ : randamentul mediu; x_t : componenta predictibilă, cunoscută la t , de medie zero; ε_{t+1} : șocul impredictibil
- ▶ R^2 : proporția din varianța randamentului explicată de predictor
- ▣ Un investitor medie-varianță fără restricții, care cunoaște x_t (fără costuri, fără erori de estimare), atinge raportul Sharpe SR^*

$$SR^{*2} = \frac{SR_0^2 + R^2}{1 - R^2}$$

- ▶ raportul Sharpe (SR): randamentul mediu în exces împărțit la abaterea lui standard
- ▶ SR_0 : SR al strategiei buy-and-hold, care ignoră x_t ; pentru $R^2 = 0$ avem $SR^* = SR_0$
- ▣ S&P 500, randamente logaritmice lunare 2001–2026: $SR_0 = 0,128$ pe lună (0,44 anualizat); $R^2 = 0,5\%$ pe lună
 $\Rightarrow SR^* = 0,51$ (+15%), $R^2 = 1\% \Rightarrow 0,57$ (+27%)
- ▣ Pentru un **singur indice**, eșantionul efectiv este mult mai mic decât pentru mii de acțiuni; studiul de caz pe S&P 500 analizează tocmai această situație

Pierdere, penalizare și cinci familii de modele (1/3)

- Învățarea supervizată alege, dintr-o familie de modele, funcția care se potrivește cel mai bine datelor de antrenare, după o penalizare a complexității

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i)) + \lambda \Omega(f)$$

- Notățiile

- ▶ (y_i, x_i) , $i = 1, \dots, n$: ținta și vectorul de caracteristici ale observației de antrenare i ; $\mathcal{F}$: familia de modele (de ex. toți arborii de adâncime 3)
 - ▶ L : pierderea, eroarea pătratică $(y - f)^2$ sau, pentru o probabilitate f ca $y = 1$, log-loss-ul $-[y \log f + (1 - y) \log(1 - f)]$
 - ▶ $\Omega(f)$: penalizarea complexității; $\lambda \geq 0$: ponderea ei; $\lambda = 0$: fără penalizare, λ mare: un model mai simplu
- λ se alege prin validare încrucișată (CV) în K pliuri: împărțim datele în K pliuri, estimăm pe $K - 1$, evaluăm pe pliul lăsat deoparte și mediem cele K scoruri
- Eroarea de test așteptată = $\text{bias}^2 + \text{varianță} + \text{zgomot } \sigma^2$ (Hastie, Tibshirani & Friedman (2009), cap. 7)
 - ▶ bias: eroarea unei familii prea simple; varianța: sensibilitatea lui $\hat{f}$ la eșantionul de antrenare; σ^2 : varianța părții impredictibile a lui y
 - ▶ în finanțe domină σ^2 , deci controlul varianței contează mai mult decât flexibilitatea

Pierdere, penalizare și cinci familii de modele (2/3)

- Logit / cele mai mici pătrate penalizate: penalizarea combină valorile absolute și pătratele coeficienților

$$\lambda \Omega(\beta) = \lambda \left[\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right], \quad \|\beta\|_1 = \sum_j |\beta_j|, \quad \|\beta\|_2^2 = \sum_j \beta_j^2$$

- ▶ $\beta = (\beta_1, \dots, \beta_p)$: coeficienții celor p caracteristici; $\alpha \in [0, 1]$: ponderea penalizării în valoare absolută
- ▶ Ridge, $\alpha = 0$ (Hoerl & Kennard (1970)): micșorează toți coeficienții spre zero, fără ca vreunul să devină exact zero
- ▶ LASSO, $\alpha = 1$ (Tibshirani (1996)): face unii coeficienți exact zero, adică selectează caracteristici
- ▶ Elastic Net, $0 < \alpha < 1$ (Zou & Hastie (2005)): între cele două
- Reperul liniar este logit-ul, probabilitatea de creștere ca funcție de un scor liniar

$$p = P(y = 1 \mid x) = \frac{1}{1 + e^{-x^\top \beta}}$$


- ▶ $x^\top \beta = \sum_j \beta_j x_j$: scorul liniar; p crește de la 0 la 1 când scorul crește
- ▶ $\beta_j > 0$: o valoare mai mare a lui x_j crește probabilitatea de “sus”

Pierdere, penalizare și cinci familii de modele (3/3)

- ▣ Arbori: împărțiri recursive care minimizează impuritatea Gini $G = 1 - \sum_c \hat{\pi}_c^2$ a nodurilor rezultate
 - ▶ $\hat{\pi}_c$: proporția clasei c într-un nod; $G = 0$: nod pur; $G = 0,5$: două clase în proporție de 50/50
- ▣ Random forest (RF): media a B arbori, fiecare crescut pe un eșantion bootstrap, cu o submulțime aleatoare de caracteristici la fiecare împărțire, deci arbori decorelați (Breiman (2001)); eroarea out-of-bag este **optimistă** când etichetele se suprapun
- ▣ Gradient boosting machine (GBM, Friedman (2001)): $F_m = F_{m-1} + \eta h_m$
 - ▶ F_m : modelul după m pași; h_m : un arbore mic ajustat pe gradientul negativ al pierderii (pentru eroarea pătratică, pe reziduuri)
 - ▶ $\eta \in (0, 1]$: rata de învățare; un η mic învață lent și produce mai puțin overfitting
- ▣ Perceptronul multistrat (MLP): $h^{(\ell)} = g(W^{(\ell)}h^{(\ell-1)} + b^{(\ell)})$, $h^{(0)} = x$
 - ▶ $h^{(\ell)}$: ieșirea stratului ℓ ; $W^{(\ell)}$, $b^{(\ell)}$: matricea de ponderi și vectorul de termeni liberi ai stratului ℓ
 - ▶ g : ReLU, $g(z) = \max(0, z)$, element cu element; oprire timpurie: antrenarea se oprește când pierderea pe validare nu mai scade; arhitecturile în Capitolul 14
- ▣ Studiul de caz clasifică direcția randamentului pe 5 zile; orice scor CV este o estimare și trebuie testat față de un reper




Bias-varianță în practică: adâncimea arborelui



- S&P 500, direcția pe 5 zile; acuratețea = proporția zilelor clasificate corect
- Acuratețea pe antrenare crește la $\approx 87\%$ cu adâncimea; acuratețea CV cu purjare **scade** spre 50%
- Random forest se degradează mai lent, dar nu depășește niciodată reperul “mereu în sus” (linia punctată)

Traectoria de regularizare LASSO



- Regresie logistică penalizată L_1 pentru direcția pe 5 zile a S&P 500, 14 caracteristici standardizate
- Penalizare puternică: toți coeficienții sînt zero; prima caracteristică care intră în model este prețul FFD, un nivel de preț scalat (secțiunea următoare)
- Penalizare slabă: caracteristicile de volatilitate (volatilitatea pe 20 și pe 60 de zile și raportul lor) au cei mai mari coeficienți
- Toți coeficienții sînt mici în valoare absolută: semnal slab, în acord cu piețe aproape eficiente

Staționaritate, memorie și diferențierea fracționară (1/2)

- Modelele ML au nevoie de variabile de intrare cu o distribuție care nu se modifică
 - ▶ log-prețurile $X_t = \log P_t$ (P_t : prețul de închidere din ziua t) se comportă ca $I(1)$
 - ▶ randamentele $\Delta \log P_t = \log P_t - \log P_{t-1}$ sînt $I(0)$, dar **elimină memoria** nivelului prețului
- Ordinul de integrare: o serie X_t este $I(\delta)$ dacă $(1 - B)^\delta X_t$ este $I(0)$
 - ▶ B : operatorul lag, $BX_t = X_{t-1}$, deci $(1 - B)X_t = X_t - X_{t-1}$ este diferența obișnuită
 - ▶ $I(0)$: staționară, cu memorie scurtă; $I(1)$: o serie de tip mers aleator, staționară după o diferențiere
 - ▶ δ poate fi fracționar: seria este staționară doar pentru $\delta < \frac{1}{2}$ ([Hosking \(1981\)](#)); $0 < \delta < \frac{1}{2}$: staționară, cu memorie lungă
- Ideea diferențierii fracționare: diferențiem cu mai puțin de 1, eliminăm rădăcina unitară și păstrăm o parte din memorie

Staționaritate, memorie și diferențierea fracționară (2/2)

Definiție 1 (Diferența fracționară de ordin d)

$$\square \tilde{X}_t = (1 - B)^d X_t = \sum_{k=0}^{\infty} w_k X_{t-k}, \text{ cu } w_0 = 1 \text{ și } w_k = -w_{k-1} \frac{d-k+1}{k}$$


- d : ordinul de diferențiere ales de analist; k : lagul, în zile; w_k : ponderea valorii de acum k zile, din dezvoltarea binomială a lui $(1 - B)^d$
- $d = 1$: $w = (1, -1, 0, \dots)$, randamentele obișnuite; $0 < d < 1$: ponderile scad hiperbolic, deci memoria se păstrează
- Un log-preț $I(1)$ diferențiat cu d devine $I(1 - d)$: nestăionar pentru $d \leq \frac{1}{2}$, staționar cu memorie lungă pentru $\frac{1}{2} < d < 1$
- Ponderile infinite însumează $(1 - 1)^d = 0$: nivelul se anulează doar la limită (comportamentul asimptotic, în [▶ Anexă](#))
- [López de Prado \(2018\)](#) propune cel mai mic d la care un test ADF respinge; această secțiune arată de ce regula eșuează

Fereastra fixă (FFD)

Definiție 2 (Diferențiere fracționară cu fereastră fixă (FFD))


- ▣ Trunchiem ponderile: păstrăm $w_0, \dots, w_K$ cu $|w_k| \geq \tau$ (de ex. $\tau = 10^{-4}$), renunțăm la rest (López de Prado (2018))
- ▣ $\tilde{X}_t = \sum_{k=0}^K w_k X_{t-k}$ pentru orice $t > K$
- ▣ τ : cea mai mică pondere păstrată; K : ultimul lag păstrat, adică lungimea ferestrei; primele K zile nu au suficient istoric și sînt eliminate
- ▣ Fiecare $\tilde{X}_t$ folosește același număr de laguri; intră doar valori trecute $\Rightarrow$ fără informație din viitor
- ▣ Cu cît d este mai mic, cu atît trebuie mai multe laguri: $d = 0,25, \tau = 10^{-4} \Rightarrow K = 444$ laguri
- ▣ Ponderile trunchiate nu mai au suma zero: $\sum_{k=0}^K w_k = 0,178$ la $d = 0,25$ (0,040 la $d = 0,5$)

Ponderile diferențierii fracționare



- Pentru $d = 1$ contează doar primul lag; pentru d mic ponderile lagurilor îndepărtate rămân nenule
- Toate ponderile după w_0 sînt negative: $\tilde{X}_t$ compară nivelul de azi cu o istorie ponderată

Statistica ADF în funcție de d : S&P 500



- Testul de rădăcină unitară Dickey–Fuller augmentat (ADF) (cursul de serii de timp): statistica t a lui γ în $\Delta \tilde{X}_t = c + \gamma \tilde{X}_{t-1} + (\Delta \tilde{X} \text{ întârziat}) + e_t$
 - $H_0: \gamma = 0$, rădăcină unitară; valorile mai negative indică mai puternic staționaritatea; respingem sub $\approx -2,86$ la 5%
- Log-prețul FFD, S&P 500 2000–2026, constantă și 1 lag: ADF respinge de la $d = 0,25$, unde $\text{Corr}(\tilde{X}_t, \log P_t) = 0,98$, corelația seriei FFD cu log-prețul
- Aceeași serie, numărul de lag-uri ales prin AIC (34 de lag-uri): $\text{ADF} = -0,72$, nu respinge
- O corelație de 0,98 cu un preț $I(1)$ este un semnal de alarmă, nu o calitate

FFD trunchiată a unui preț $I(1)$ rămîne $I(1)$

- ▣ Descompunem seria FFD:

$$\tilde{X}_t = \sum_{k=0}^K w_k X_{t-k} = \left(\sum_{k=0}^K w_k \right) X_t - \sum_{k=1}^K w_k (X_t - X_{t-k})$$

- ▶ primul termen: nivelul de azi înmulțit cu suma ponderilor trunchiate; al doilea: o sumă ponderată a variațiilor pe k zile, $X_t - X_{t-k}$
- ▣ Dacă X_t este $I(1)$, fiecare $X_t - X_{t-k}$ este $I(0)$; primul termen este $0,178 X_t$ la $d = 0,25$: un **mers aleator scalat**
- ▣ Componenta cu rădăcină unitară are varianță mică față de partea staționară, deci testul ADF cu puține lag-uri nu le poate distinge
 - ▶ Monte Carlo: mers aleator pur, $T = 6.274$ de zile, FFD cu $d = 0,25$: ADF (1 lag) respinge în **97,8%** din 500 de eșantioane, la un nivel nominal de 5%
- ▣ Consecință: log-prețul FFD din studiul de caz este un nivel de preț scalat, nu o caracteristică staționară; slide-urile următoare măsoară memoria direct


Memoria estimată direct: local Whittle (1/2)

- ▣ Ideea: o serie cu memorie lungă are cea mai mare parte a varianței în ciclurile lente; panta spectrului lângă frecvența 0 arată δ

$$f(\lambda) \sim G \lambda^{-2\delta} \quad \text{pentru } \lambda \rightarrow 0$$


- ▶ $f(\lambda)$: densitatea spectrală, varianța adusă de ciclurile de frecvență λ (perioadă de $2\pi/\lambda$ zile)
- ▶ $G > 0$: o constantă de scală; $\sim$: raportul celor doi membri tinde la 1
- ▶ $\delta > 0$: f explodează lângă 0 (memorie lungă); $\delta = 0$: plat (memorie scurtă); $\delta < 0$: f tinde la 0
- ▣ Local Whittle (LW, [Robinson \(1995\)](#)): ajustează această lege doar pe primele $m = n^a$ frecvențe Fourier $\lambda_j = 2\pi j/n$, $j = 1, \dots, m$
 - ▶ n : mărimea eșantionului; $a \in (0, 1)$: exponentul lățimii de bandă; un a mai mare folosește mai multe frecvențe: varianță mai mică, bias mai mare din dinamica pe termen scurt
- ▣ Local Whittle exact (ELW, [Shimotsu & Phillips \(2005\)](#)): valid și pentru $\delta \geq \frac{1}{2}$ (nestaționar)
- ▣ Intervalul de încredere (CI) de 95%: $\hat{\delta} \pm 1,96/(2\sqrt{m})$; eroarea standard $1/(2\sqrt{m})$ depinde doar de m

Memoria estimată direct: local Whittle (2/2)



- S&P 500, 2000–2026, $m = n^{0.65}$: log-preț (ELW) 0,99 [0,94; 1,05]; seria FFD (ELW) 0,75 [0,69; 0,81]; randamente $-0,01$ [$-0,07$; $0,04$]; $|r_t|$ 0,53 [0,47; 0,59]
- Pentru seria FFD, estimarea rămîne aproape de $1 - d$ în banda de frecvențe folosită, deși ordinul de integrare este tot 1; memoria lungă este în **volatilitate** (Capitolele 5 și 9): caracteristicile fracționare sînt utile pentru $|r_t|$ (Franke, Härdle & Hafner (2019))

Prețuri, serie FFD și randamente



- ▣ **Sus:** log-prețul — $I(1)$
- ▣ **Mijloc:** FFD cu $d = 0,25$ — trendul ascendent al prețului se vede în continuare: $0,178 \log P_t$ plus o parte staționară
- ▣ **Jos:** randamentele logaritmice — se vede doar volatility clustering
- ▣ Seria FFD intră în studiul de caz drept caracteristica „log-prețul FFD”

De la etichete cu orizont fix la etichete cu trei bariere (1/2)

- **Orizont fix:** eticheta este semnul randamentului logaritmic pe h zile, cu o zonă moartă în jurul lui zero

$$r_{t,t+h} = \log P_{t+h} - \log P_t, \quad y_t = \begin{cases} +1 & \text{dacă } r_{t,t+h} > \tau \\ -1 & \text{dacă } r_{t,t+h} < -\tau \\ 0 & \text{altfel} \end{cases}$$


- P_t : prețul de închidere din ziua t ; h : orizontul, în zile; $\tau \geq 0$: pragul, variațiile mai mici decât τ primesc eticheta 0
- Trei probleme
- un τ constant ignoră variația volatilității în timp
- eticheta nu ține cont de traiectorie: un stop-loss ar fi putut fi atins înainte de $t + h$
- clasele sînt dezechilibrate: S&P 500, $h = 10$, $\tau = 0$: 60,5% sus față de 39,5% jos

De la etichete cu orizont fix la etichete cu trei bariere (2/2)

Definiție 3 (Etichetă cu trei bariere, López de Prado (2018))


- La momentul evenimentului t_0 , cu volatilitatea zilnică σ_{t_0} și orizontul h : bariera superioară $\log P_t - \log P_{t_0} \geq \pi_u \sigma_{t_0} \sqrt{h}$ (profit), bariera inferioară $\leq -\pi_l \sigma_{t_0} \sqrt{h}$ (stop-loss), bariera verticală $t = t_0 + h$
- Eticheta = **prima barieră atinsă** la t_1 : +1 sus, -1 jos; la bariera verticală $\text{sign}(r_{t_0, t_1})$ (sau 0)
- Notățiile
 - ▶ $\sigma_{t_0} \sqrt{h}$: variația tipică pe h zile; $\pi_u, \pi_l > 0$: lățimile barierelor, în unități ale acesteia
 - ▶ t_1 : ziua în care este atinsă prima barieră; $\text{sign}(x) = +1$ dacă $x > 0$, -1 dacă $x < 0$
- σ_{t_0} : rădăcina pătrată a mediei mobile ponderate exponențial (EWMA) a abaterilor pătratice ale randamentelor logaritmice zilnice, span 50
 - ▶ factorul de atenuare $\lambda = 1 - 2/51$: fiecare zi are o pondere de λ ori ponderea zilei următoare
 - ▶ barierele se scalează cu volatilitatea, ca take-profit-ul, stop-loss-ul și durata maximă de deținere ale unui trader
- Fiecare etichetă are un **interval** $[t_0, t_1]$: datele de intrare pentru purjarea din validare

Trei bariere: S&P 500 în 2022




- Cinci evenimente în piața descendentă din 2022, $\pi_u = \pi_l = 1$, $h = 15$ zile
- Ianuarie: stop-loss atins (-1); martie: profit ($+1$); celelalte se termină la bariera verticală

Distribuția etichetelor: orizont fix și trei bariere



- S&P 500, 2001–2026, $h = 10$: orizontul fix dă 60,5% sus / 39,5% jos
- Trei bariere ($\pm 1\sigma\sqrt{h}$): 19,6% sus, 21,3% jos, 59,0% expirare — etichete direcționale echilibrate
- Panoul din dreapta: barierele orizontale sînt de obicei atinse după 1–2 săptămîni

Meta-etichetarea: decizia de a acționa (1/2)



- ▣ Meta-eticheta $y_t^{meta} = 1$ dacă semnalul primar a fost profitabil (barieră atinsă în direcția lui), 0 altfel
- ▣ Modelul secundar estimează $\hat{p} = P(y_t^{meta} = 1 \mid x_t)$, probabilitatea ca semnalul din ziua t să fie corect, date fiind caracteristicile x_t
- ▣ ML învață **cînd semnalul** unei reguli primare interpretabile este de încredere, nu direcția însăși

Meta-etichetarea: decizia de a acționa (2/2)

- Trei scoruri pentru un filtru care decide pe ce semnale acționăm
 - ▶ precizia: proporția tranzacțiilor efectuate care au fost profitabile
 - ▶ recall-ul: proporția semnalelor profitabile care au fost urmate; dacă acționăm la orice semnal, recall-ul este 1
 - ▶ $F_1 = 2 \cdot \text{precizie} \cdot \text{recall} / (\text{precizie} + \text{recall})$: media lor armonică, între 0 și 1
- Meta-etichetarea poate crește precizia în detrimentul recall-ului
- Seminarul B9, încrucișarea MA20/MA50 pe Bitcoin, 1.660 de tranzacții de test: precizia 0,475 → 0,517, recall 1 → 0,541, F1 0,644 → 0,529; randamentul brut pe tranzacție -0,27% → +0,19%
- Filtrarea nu îmbunătățește neapărat F1; cu costuri pe tranzacție contează precizia și randamentul pe tranzacție

Etichete suprapuse și unicitatea eșantioanelor (1/2)

- Eticheta i acoperă $[t_{0,i}, t_{1,i}]$: de la începutul ei, $t_{0,i}$, până la sfârșitul ei, $t_{1,i}$; etichetele consecutive au randamente comune $\Rightarrow$ eșantioanele **nu sînt i.i.d.**
- Etichetele active simultan: numărul de etichete al căror interval conține ziua t

$$c_t = \sum_i 1\{t_{0,i} \leq t \leq t_{1,i}\}$$

- $1\{A\}$: funcția indicator, 1 dacă are loc condiția A și 0 altfel
- Unicitatea medie a etichetei i : partea medie din fiecare zi a intervalului ei care îi aparține doar ei

$$\bar{u}_i = \frac{1}{t_{1,i} - t_{0,i} + 1} \sum_{t=t_{0,i}}^{t_{1,i}} \frac{1}{c_t}$$

- $\bar{u}_i = 1$: niciun randament comun; $\bar{u}_i = 1/5$: media armonică a lui c_t pe intervalul etichetei i este cinci

Etichete suprapuse și unicitatea eșantioanelor (2/2)

Consecințe

- ▣ Mărimea efectivă a eșantionului $\approx \sum_i \bar{u}_i \ll n$, unde n este numărul de etichete (o euristică a suprapunerii, nu o măsură bazată pe varianță)
- ▣ Bagging-ul extrage observații aproape identice; scorurile CV sînt supraestimate

Remedii


- ▣ Ponderare cu $\bar{u}_i$ (și cu $|r|$)
- ▣ Bootstrap secvențial; în RF, fracția de observații extrase pentru fiecare arbore $\approx \bar{u}$, unicitatea medie

Leakage: informație comună între antrenare și test

Definiție 4 (Leakage (scurgere de informație))


- Setul de antrenare conține informații prezente și în setul de test, așa că scorul de test nu mai măsoară rezultatele pe date cu adevărat noi
- Caracteristici corelate serial ($x_t \approx x_{t+1}$) și etichete suprapuse ($y_t \approx y_{t+1}$): un K -fold amestecat pune zile **aproape identice** de ambele părți
- Un model flexibil (RF, GBM) memorează observația vecină $\Rightarrow$ scor "în afara eșantionului" excelent; reglarea pe un CV cu leakage selectează modelul cu **cel mai mult overfitting**
- Alte surse: transformări estimate pe tot eșantionul (scalare, analiza componentelor principale, alegerea lui d pentru FFD), survivorship bias, revizuirii ale datelor, marcaje de timp greșite

K-fold cu purjare și embargo



- Pliurile sînt blocuri **contigue** în timp (López de Prado (2018)); **purjarea** elimină din antrenare orice observație al cărei interval de etichetă $[t_{0,i}, t_{1,i}]$ se suprapune cu intervalul etichetelor de test, de la primul t_0 la ultimul t_1 din test
- **Embargoul**: eliminăm și o mică fracțiune (de ex. 1%) de observații imediat după blocul de test, deoarece caracteristicile folosesc observații anterioare
- Un exemplu: etichetele se termină la 2 zile după început, testul $\{4, 5\}$: observațiile 2 și 3 se termină în blocul de test (purjate), 6 este embargoul, 7 începe înainte de sfîrșitul ultimei etichete de test (purjată); tabelul complet în [► Anexă](#)

Experiment de leakage: o țintă fără predictibilitate



- Preț = mers aleator pur; eticheta = semnul randamentului pe următoarele 20 de zile; 5 caracteristici = medii mobile pe 20 de zile ale unui zgomot independent
- Acuratețea reală este 50% prin construcție; random forest, 5 pliuri
- **K-fold amestecat: 69,4%**; K-fold contiguu 50,0%; K-fold cu purjare + embargo 49,7%
- Amestecarea eșuează pentru că etichetele se suprapun și caracteristicile sînt persistente; un rezultat neverosimil de bun indică de obicei leakage

 MFM_ch13_purged_cv

Transformări doar pe datele de antrenare: testul fără FFD

- “ d minim” a fost ales pe 2000–2026 și apoi folosit în CV cu purjare: pliurile de test au influențat alegerea unei caracteristici
 - ▶ aceeași regulă ADF pe datele pînă în 2009 dă $d = 0,15$; pe tot eșantionul $d = 0,25$
- Studiul de caz fără log-prețul FFD (CV cu purjare în 5 pliuri, media pe pliuri)
 - ▶ acuratețe: logit 57,5%, RF 56,4%, GBM 55,6%, MLP 55,5%, toate sub 58,1%
 - ▶ AUC: 0,483; 0,522; 0,514; 0,514
- Concluzia negativă nu depinde de această caracteristică
- Protocolul corect
 - ▶ estimăm d (local Whittle, cu CI) doar în fiecare pli de antrenare
 - ▶ preferăm caracteristici cu sens economic: distanțe față de mediile mobile, filtre fracționare ale lui $|r_t|$

Selecția modelului și evaluarea lui finală

- K-fold obișnuit nu este mereu invalid: pentru un model pur autoregresiv cu erori necorelate serial este valid (Bergmeir, Hyndman & Koo (2018))
 - ▶ eșuează când erorile sînt corelate serial: etichete suprapuse, caracteristici persistente din afara lag-urilor modelului; verificați întîi autocorelația reziduurilor CV
- **Selecția modelului:** K-fold cu purjare sau CV combinatorică cu purjare (CPCV), care testează pe multe combinații de grupuri și dă o **distribuție** de rapoarte Sharpe în locul unui singur număr
- **Utilizarea:** walk-forward (WF), antrenare pe $[0, T_k]$, test pe $(T_k, T_{k+1}]$, apoi avansăm (T_k : sfîrșitul celei de-a k -a ferestre de antrenare); realist, dar o singură traiectorie, cu varianță mare
- Regulă practică: K-fold cu purjare sau CPCV pentru alegere, walk-forward pentru evaluarea finală, realistă (detalii în [▶ Anexă](#))

Studiu de caz: date, țintă și validare

- ▣ Indicele S&P 500 și VIX, închideri zilnice, 2001–2026: $n = 6.269$ de observații
- ▣ Ținta: $y_t = 1\{\log P_{t+5} - \log P_t > 0\}$, egală cu 1 dacă indicele este mai sus peste 5 zile; intervalul etichetei $[t, t + 5]$ este folosit la purjare
- ▣ Validare: CV cu purjare în 5 pliuri, embargo 1%; toate modelele primesc aceleași pliuri
- ▣ Metrici, față de reperul “mereu în sus”
 - ▶ acuratețea: proporția zilelor a căror direcție este prezisă corect
 - ▶ aria de sub curba ROC (receiver operating characteristic), AUC: probabilitatea ca o zi de creștere aleasă la întâmplare să primească o probabilitate prezisă mai mare decât o zi de scădere aleasă la întâmplare; 0,5: nicio abilitate, 1: ordonare perfectă
 - ▶ **media pe pliuri**: metrica calculată în fiecare dintre cele 5 pliuri de test, apoi mediată
 - ▶ **agregat**: metrica calculată o singură dată pe toate predicțiile în afara pliurilor; o folosesc testele
- ▣ Datele capitolului: închiderile zilnice S&P 500 și VIX din datele cursului

Studiu de caz: 14 caracteristici și patru modele

Caracteristici, informație pînă în ziua t

- ▣ **Momentum:** $\log P_t - \log P_{t-h}$, randamentul logaritmic pe ultimele h zile, $h \in \{1, 5, 20, 60, 120\}$
- ▣ **Volatilitate realizată:** abaterea standard anualizată a randamentelor logaritmice zilnice pe 20 și 60 de zile și raportul lor
- ▣ **Distanța față de media mobilă:** $\log P_t$ minus media lui $\log P$ pe 50 sau 200 de zile
- ▣ **RSI(14):** $100 - 100/(1 + RS)$, RS = câștigul mediu netezit raportat la pierderea medie, 14 zile; între 0 și 100, ridicat după creșteri
- ▣ **VIX:** nivelul logaritmic și variația pe 5 zile
- ▣ Log-prețul **FFD**, $d = 0,25$, ales pe tot eșantionul (testul fără această caracteristică, în secțiunea despre validare)

Modele, configurate deliberat conservator

- ▣ **Logit:** penalizat L2 (Ridge), caracteristici standardizate
- ▣ **RF:** 400 de arbori, frunza minimă 100
- ▣ **GBM:** pe histograme, adîncime 3, rată de învățare 0,03, 200 de arbori
- ▣ **MLP:** straturi ascunse de 32 și 16 unități, oprire timpurie
- ▣ Frunzele mari și arborii puțin adînci limitează varianța

Modelul care a învățat “mereu în sus” (1/2)

	Prezis sus	Prezis jos
Real sus	TP = 3.572	FN = 68
Real jos	FP = 2.591	TN = 38



- Logit penalizat L2, predicții agregate în afara pliurilor din CV cu purjare în 5 pliuri, $n = 6.269$
- TP, FN, FP, TN: rezultate adevărat pozitive, fals negative, fals pozitive, adevărat negative

- Acuratețe = $(TP + TN)/n = 57,6\%$: proporția zilelor clasificate corect
- Precizie = $TP/(TP + FP) = 0,580$: proporția zilelor prezise “sus” care au fost “sus”
- Recall = $TP/(TP + FN) = 0,981$: proporția zilelor reale “sus” prezise “sus”
- $F_1 = 2 \cdot \text{precizie} \cdot \text{recall}/(\text{precizie} + \text{recall}) = 0,729$: media lor armonică
- Modelul prezice “sus” în 98,3% din zile: în esență, a învățat regula “mereu în sus”

Modelul care a învățat “mereu în sus” (2/2)

- ▣ **Reperul clasei majoritare**, din același tabel: zilele reale “sus” $(3.572 + 68)/6.269 = 3.640/6.269 = 58,1\%$
 - ▶ acuratețea regulii care prezice “sus” în fiecare zi, fără niciun model
- ▣ Un model cu acuratețe de 57,6% este *mai slab* decât reperul trivial
- ▣ Alte repere: direcția de ieri, o regulă de medii mobile, buy-and-hold pentru tranzacționare
- ▣ Un model are valoare doar dacă depășește reperul **în afara eșantionului**, după costuri, cu mai mult decât eroarea de eșantionare

Compararea modelelor, medii pe pliuri



Media pe pliuri	Logit	RF	GBM	MLP
Acuratețe	57,6%	56,5%	54,3%	56,4%
AUC	0,478	0,503	0,493	0,515

- Barele: media pe cele 5 pliuri purjate; mustățile: ± 1 abatere standard între pliuri
- Reperul "mereu în sus": **58,1%**; niciun model nu îl depășește

Semnificația diferențelor: Pesaran–Timmermann și intervale pentru AUC (1/2)

- ▣ **Pesaran–Timmermann** (PT, Pesaran & Timmermann (1992)): sînt legate direcțiile prezise de cele realizate?

$$PT = \frac{\hat{P} - \hat{P}^*}{\widehat{SE}} \xrightarrow{d} N(0, 1), \quad \hat{P}^* = \hat{p}_y \hat{p}_x + (1 - \hat{p}_y)(1 - \hat{p}_x)$$

- ▶ $\hat{P}$: proporția zilelor cu semnul corect; $\hat{p}_y$, $\hat{p}_x$: proporțiile zilelor “sus” realizate și prezise
- ▶ $\hat{P}^*$: proporția corectă așteptată dacă predicțiile ar fi independente de rezultate; $\widehat{SE}$: eroarea standard a lui $\hat{P} - \hat{P}^*$ sub H_0 (▶ Anexă)
- ▶ H_0 : independență; $\xrightarrow{d} N(0, 1)$: în eșantioane mari, statistica are aproximativ distribuția Normală standard; $PT > 1,645$: abilitate la 5% (unilateral); $PT < 0$: mai puține potriviri decît la întîmplare
- ▣ Cu etichete suprapuse: statistica t a pantei în $y_t = a + b x_t + u_t$, cu x_t direcția prezisă și y_t cea realizată, erori Newey–West (Newey & West (1987)); $b > 0$: după un “sus” prezis urmează mai des “sus”
- ▣ **AUC**: eroarea standard (SE) DeLong presupune zile independente; un bootstrap circular pe blocuri reeșantionează blocuri de $L = 20$ de zile consecutive (Künsch (1989)) și păstrează dependența serială

Semnificația diferențelor: Pesaran–Timmermann și intervale pentru AUC (2/2)

Agregat în afara pliurilor	Logit	RF	GBM	MLP
$\hat{P} / \hat{P}^*$	0,576 / 0,578	0,565 / 0,570	0,543 / 0,557	0,564 / 0,565
PT / t HAC (lag 4)	-1,28 / -1,00	-1,61 / -1,16	-3,07 / -2,31	-0,36 / -0,26
AUC	0,479	0,495	0,490	0,512
CI 95% bootstrap pe blocuri	[0,455; 0,504]	[0,472; 0,520]	[0,468; 0,514]	[0,489; 0,537]

- t HAC: statistica t a pantei, cu erori robuste la heteroscedasticitate și autocorelație (HAC), 4 lag-uri
- Nicio abilitate direcțională pozitivă semnificativă; fiecare interval pentru AUC conține 0,5; GBM este semnificativ *mai slab* decât independența
- În acord cu eficiența în formă slabă (Capitolul 2); căutați semnal în secțiuni transversale (Gu, Kelly & Xiu (2020)), ținte de risc, delistarea criptoactivelor (Będowska-Sójka, Wójcik & Pele (2026)), text (Capitolul 15)

Compararea prognozelor: Diebold–Mariano, Clark–West, Giacomini–White (1/2)

- ▣ Două prognoze de probabilitate pentru $y_t \in \{0, 1\}$: modelul 1 dă $\hat{p}_{1,t}$, reperul (modelul 0, de ex. o constantă) dă $\hat{p}_{0,t}$
- ▣ Pierderea unei prognoze $\hat{p}_t$, mai mică înseamnă mai bine: log-loss $L = -[y_t \log \hat{p}_t + (1 - y_t) \log(1 - \hat{p}_t)]$ sau pierderea Brier $(y_t - \hat{p}_t)^2$
- ▣ Diferența pierderilor $d_t = L(y_t, \hat{p}_{1,t}) - L(y_t, \hat{p}_{0,t})$; $d_t > 0$: modelul 1 este mai slab în ziua t
- ▣ **Diebold–Mariano** (DM, [Diebold & Mariano \(1995\)](#)): este zero diferența medie a pierderilor?

$$DM = \frac{\bar{d}}{\sqrt{\hat{\Omega}_{NW}/n}} \xrightarrow{d} N(0, 1) \quad \text{sub } H_0 : \mathbb{E}[d_t] = 0$$

- ▶ $\bar{d}$: media lui d_t pe cele n zile de test; $\hat{\Omega}_{NW}$: varianța de lungă durată a lui d_t , robustă la heteroscedasticitate și autocorelație (HAC), estimată Newey–West
- ▶ $DM > 1,96$: modelul 1 este semnificativ mai slab la 5%; $DM < -1,96$: semnificativ mai bun

Compararea prognozelor: Diebold–Mariano, Clark–West, Giacomini–White (2/2)

- ▣ **Modele imbricate** (logit-ul cu 14 caracteristici include constanta, $\beta = 0$): sub H_0 modelul extins estimează cu zgomot coeficienți nuli, $\mathbb{E}[d_t] > 0$, iar DM rareori îl favorizează
- ▣ **Clark–West** (CW, [Clark & West \(2007\)](#)): test t HAC unilateral pentru $\mathbb{E}[f_t] = 0$ față de $\mathbb{E}[f_t] > 0$

$$f_t = (y_t - \hat{p}_{0,t})^2 - [(y_t - \hat{p}_{1,t})^2 - (\hat{p}_{0,t} - \hat{p}_{1,t})^2]$$

- ▶ câștigul de pierdere Brier al modelului 1, plus termenul $(\hat{p}_{0,t} - \hat{p}_{1,t})^2$, care elimină costul de zgomot al estimării unor coeficienți nuli
- ▶ un t mare și pozitiv: caracteristicile adaugă informație
- ▶ derivat pentru modele liniare imbricate estimate prin OLS; pentru probabilitățile unui logit penalizat este o aproximare, nu o teoremă
- ▣ **Giacomini–White** (GW, [Giacomini & White \(2006\)](#)): testează *metoda* de prognoză așa cum este folosită, cu o fereastră de estimare mărginită; CW întreabă dacă modelul populației adaugă informație (statistica în [► Anexă](#))

Importanța caracteristicilor: MDI, MDA și SHAP

Scăderea medie a impurității (MDI)

- ▣ Reducerea medie a impurității Gini din împărțirile pe o caracteristică, pe arbori
- ▣ Calculată în eșantion, doar pentru arbori; favorizează caracteristicile continue, cu multe valori distincte

Scăderea medie a acurateții (MDA)

- ▣ Scăderea unui scor în afara eșantionului (aici AUC) când o caracteristică este permutată aleator
- ▣ Aplicabilă oricărui model; o valoare negativă indică o caracteristică dăunătoare


SHAP (Lundberg & Lee (2017))

- ▣ Valoarea Shapley ϕ_j : contribuția marginală medie a caracteristicii j , mediată pe toate coalitiile
- ▣ Aditivă: $\hat{f}(x) = \phi_0 + \sum_j \phi_j$, ϕ_0 fiind predicția medie; media lui $|\phi_j|$ = importanța globală

- ▣ MDI arată pe ce caracteristici s-a sprijinit modelul; MDA și SHAP arată ce caracteristici ajută predicția pe date noi
- ▣ Caracteristicile corelate își împart și își diluează importanța (substituție): grupați-le întâi; formula coalitiilor și alegerea dintre SHAP condiționat și intervențional în [▶ Anexă](#)

 Shapley Values

Importanța caracteristicilor în studiul de caz



- Estimare pe primele 70%, evaluare pe ultimele 30% după purjare; **RF** dă MDI și MDA, **GBM** dă SHAP: diferențele țin și de model, nu doar de metodă
- MDI pune volatilitatea pe primul loc; MDA și SHAP indică momentum-ul pe 20 de zile și distanța față de media mobilă pe 200 de zile
- Volatilitatea pe 20 de zile: MDI ridicat, MDA **negativ**: un semn de overfitting, nu o dovadă
- Toate importanțele sînt foarte mici ($\Delta AUC < 0,01$)
- Caracteristici corelate: permutarea creează puncte în afara varietății datelor, deci MDA și SHAP **extrapolează** (Hooker, Mentch & Zhou (2021))

 MFM_ch13_feature_importance


Backtest walk-forward: strategie și construcție

- ▣ Poziția $w_t \in \{0, 1\}$: long pe S&P 500 dacă $\hat{p}_t > 0,5$, altfel numerar, decisă cu informații pînă la t ; $\hat{p}_t$: probabilitatea de “sus” dată de model
- ▣ Randamentul strategiei: randamentul indicelui cînd sîntem investiți, minus un cost la fiecare schimbare de poziție

$$r_{t+1}^S = w_t r_{t+1} - c |w_t - w_{t-1}|$$

- ▶ r_{t+1} : randamentul logaritmic zilnic al indicelui; $r - c$ este aproximarea de ordinul întâi a lui $\log(e^r - c)$
- ▶ turnover-ul $|w_t - w_{t-1}|$: 1 în zilele în care poziția se schimbă; costul $c = 5$ bp (0,05%) pe unitatea tranzacționată
- ▶ expunerea $\bar{w} = \frac{1}{T} \sum_t w_t$: proporția celor T zile în care sîntem investiți
- ▣ Model: GBM reestimat în fiecare ianuarie pe toate datele trecute, cu purjarea etichetelor care se suprapun cu anul de test
- ▣ Perioada în afara eșantionului 2010–2026, o reestimare pe an; reper buy-and-hold ($w_t = 1$: expunere 100%, fără turnover)
- ▣ Backtest-ul evaluează doar decizia pe care un trader ar fi putut-o lua în ziua t

Backtest walk-forward: rezultate



- 2010–2026: raportul Sharpe anualizat al strategiei **0,49**, față de **0,66** pentru buy-and-hold; expunere medie 77%
 - modelul a învățat în principal să rămână long și a ieșit din piață în momente nefavorabile
- Diferența dintre cele două rapoarte Sharpe, $-0,17$ (SE Lo $\approx 0,25$ fiecare, formula pe slide-ul despre inferența pentru raportul Sharpe): SE HAC Ledoit–Wolf $0,095$, $p = 0,073$ (Ledoit & Wolf (2008)); CI bootstrap pe blocuri $[-0,36; 0,02]$
 - nicio dovadă de abilitate și nicio dovadă semnificativă că strategia este mai slabă
- Cu $d = 0,15$, ales prin aceeași regulă pe datele pînă în 2009, SR = $0,43$; fără log-prețul FFD, $0,51$

Walk-forward: prognozele modelelor față de o prognoză constantă

- ▣ Walk-forward 2010–2026, $n = 4.198$ zile, 60,2% “sus”; reper: prognoza constantă = proporția “sus” din antrenare
- ▣ Logit (include constanta): log-loss 0,6822 față de 0,6757
 - ▶ DM $t = 2,39$ ($p = 0,017$): logit-ul estimat este semnificativ *mai slab*
 - ▶ Clark–West $t = -0,21$ (p unilateral = 0,58): nicio dovadă că informația caracteristicilor contează
 - ▶ Giacomini–White = 5,77 (χ^2_2 , $p = 0,056$): nicio diferență semnificativă la 5%; aproximativ, pentru că fereastra se extinde (rezultatul cu fereastră mobilă în [▶ Anexă](#))
- ▣ GBM: log-loss 0,6971; DM $t = 5,09$, GW = 25,8 ($p < 0,001$): mai slab decât o constantă; Pesaran–Timmermann $-0,74$
- ▣ Un rezultat negativ obținut corect este tot un rezultat: niciun model nu depășește “mereu în sus” sau o prognoză constantă

Biasul de selecție și teorema strategiei false

- Un cercetător încearcă N strategii sau configurații și o raportează pe cea mai bună; chiar dacă toate au Sharpe real zero, $\max_n \widehat{SR}_n$ crește cu N : **biasul de selecție**
- Harvey, Liu & Zhu (2016): față de sutele de factori publicați, un factor nou are nevoie de $t > 3$, nu de 2


Teoremă 1 (Teorema strategiei false, Bailey & López de Prado (2014))

- Dacă $\widehat{SR}_n$, $n = 1, \dots, N$, sînt independente și aproximativ $N(0, \text{Var}[\widehat{SR}])$ (fără abilitate), **raportul Sharpe maxim așteptat** este

$$SR_0 \equiv \mathbb{E} \left[\max_n \widehat{SR}_n \right] \approx \sqrt{\text{Var}[\widehat{SR}]} \left[(1 - \gamma) \Phi^{-1} \left(1 - \frac{1}{N} \right) + \gamma \Phi^{-1} \left(1 - \frac{1}{Ne} \right) \right]$$


- Notățiile
 - ▶ $\widehat{SR}_n$: raportul Sharpe estimat al strategiei n ; $\text{Var}[\widehat{SR}]$: varianța de eșantionare a unui SR estimat; randamente i.i.d.: $\approx 1/T$ pe perioadă, T fiind numărul de perioade
 - ▶ Φ : funcția de repartiție a distribuției Normale standard; Φ^{-1} : funcția ei cuantilă; $e \approx 2,718$; $\gamma \approx 0,5772$: constanta Euler–Mascheroni
- Interpretare: SR_0 este raportul Sharpe pe care îl așteptăm de la cea mai norocoasă dintre N strategii fără valoare; crește cu N și cu zgomotul de eșantionare $\sqrt{\text{Var}[\widehat{SR}]}$

Cea mai bună dintre N strategii fără abilitate



- Strategii cu randamente i.i.d. de medie zero, 5 ani de date zilnice ($\text{Var}[\widehat{SR}]$ anualizat $\approx 1/5$)
- Din $N = 1000$ de variante rezultă un raport Sharpe maxim de $\approx 1,45$ — **fără nicio abilitate**
- Simularea Monte Carlo confirmă teorema

În eșantion și în afara eșantionului: căutare pe grilă pe Bitcoin



- Încrucișare de medii mobile (MA) pe Bitcoin: long când MA rapidă a log-prețului depășește MA lentă cu mai mult decât o bandă; 1.279 de configurații (rapidă, lentă, bandă); în eșantion 15 mai 2015 – 2020, în afara eșantionului 2021–2026
- Regula selectată (14/20 de zile): SR_{IS} **1,89** → SR_{OOS} **0,02** (anualizat cu $\sqrt{365}$); corelația de rang Spearman IS–OOS $\rho = 0,18$
- SR OOS median 0,55 pentru cele mai bune 10% în eșantion, față de 0,42 pentru toate
 - familia de reguli de trend conține informație, dar optimul *selectat* reflectă zgomot

Inferență pentru raportul Sharpe: eroarea standard și PSR (1/2)

- ▣ Raportul Sharpe (SR) pe perioadă al randamentelor logaritmice zilnice, rata fără risc 0: $\widehat{SR} = \bar{r}/\hat{\sigma}$, randamentul mediu $\bar{r}$ împărțit la abaterea lui standard $\hat{\sigma}$
- ▣ Forma distribuției randamentelor, cu μ , σ media și abaterea standard a lui r
 - ▶ asimetria $\gamma_3 = \mathbb{E}[(r - \mu)^3]/\sigma^3$: < 0 când pierderile mari sînt mai frecvente decît câștigurile mari
 - ▶ kurtosis obișnuit (nu în exces) $\gamma_4 = \mathbb{E}[(r - \mu)^4]/\sigma^4$: 3 pentru distribuția Normală, mai mare pentru cozi groase
- ▣ Varianța de eșantionare a lui $\widehat{SR}$, randamente i.i.d., metoda delta (Lo (2002); Opdyke (2007)):

$$\text{Var}(\widehat{SR}) \approx \frac{1}{T} \left(1 - \gamma_3 SR + \frac{\gamma_4 - 1}{4} SR^2 \right)$$

- ▶ T : numărul de randamente; SR : raportul Sharpe real pe perioadă
- ▶ asimetria negativă și cozile groase măresc incertitudinea; distribuția Normală ($\gamma_3 = 0$, $\gamma_4 = 3$): $(1 + \frac{1}{2} SR^2)/T$
- ▣ Anualizarea cu $\sqrt{A}$, unde A este numărul de perioade pe an (252 de zile de tranzacționare; 365 pentru Bitcoin), cere absența autocorelației; altfel $SR_A = \eta(A) SR$ (Lo (2002))
 - ▶ $\eta(A) = A/\sqrt{A + 2 \sum_{k=1}^{A-1} (A-k)\rho_k}$, ρ_k : autocorelația randamentelor de ordin k ; $\rho_k > 0$ face ca $\eta(A) < \sqrt{A}$

Inferență pentru raportul Sharpe: eroarea standard și PSR (2/2)

Definiție 5 (Raportul Sharpe probabilistic (PSR), Bailey & López de Prado (2012))

▣ Probabilitatea ca SR real să depășească un reper SR^* , cu varianța de mai sus la numitor:

$$\widehat{PSR}(SR^*) = \Phi \left(\frac{(\widehat{SR} - SR^*)\sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3 \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \widehat{SR}^2}} \right)$$

- ▣ SR^* : reperul, de ex. 0 sau maximul așteptat SR_0 ; $\hat{\gamma}_3$, $\hat{\gamma}_4$: asimetria și kurtosis-ul de selecție
- ▣ Argumentul lui Φ este o statistică z: distanța $\widehat{SR} - SR^*$, măsurată în erori standard
- ▣ Interpretare: $\widehat{PSR} > 0,95$: SR real depășește SR^* cu o încredere de 95%
- ▣ Două strategii pe aceleași zile: testăm $SR_a - SR_b$ cu metoda delta HAC sau cu un bootstrap pe blocuri studentizat (Ledoit & Wolf (2008)), nu cu două intervale separate


Raportul Sharpe deflatat: cea mai bună regulă pe Bitcoin

- **Raportul Sharpe deflatat** (DSR, Bailey & López de Prado (2014)): $DSR = \widehat{PSR}(SR_0)$, PSR cu reperul egal cu SR_0 , maximul așteptat din teorema strategiei false, calculat cu $\text{Var}[\widehat{SR}_n]$ al încercărilor
 - ▶ corectează pentru selecție (N încercări), non-normalitate și lungimea eșantionului; respingem dacă $DSR \leq 0,95$ și raportăm N
- Exemplu rezolvat, cea mai bună regulă în eșantion: $T = 2.058$ de zile, $\widehat{SR} = 0,0991$ pe zi (1,89 anualizat), $\hat{\gamma}_3 = 0,12$, $\hat{\gamma}_4 = 12,33$
 - ▶ numitorul $\sqrt{1 - 0,12 \cdot 0,0991 + \frac{12,33-1}{4} \cdot 0,0991^2} = 1,008$; $N = 1.279$ de încercări
 - ▶ $z = (\widehat{SR} - SR_0)\sqrt{T-1}/1,008$, argumentul lui Φ ; $DSR = \Phi(z)$; $SD = \sqrt{\text{Var}[\widehat{SR}_n]}$

$\text{Var}[\widehat{SR}_n]$ din	SD	SR_0 (pe zi)	z / DSR
dispersia celor 1.279 de SR	0,0106	0,035	2,88 / 0,998
încercări independente, $1/T$	0,0220	0,073	1,16 / 0,877

- Încercările sînt puternic corelate, deci dispersia lor subestimează amploarea căutării: verdictul depinde de această alegere, iar SR de 0,02 în afara eșantionului este în acord cu valoarea conservatoare

Raportul Sharpe deflatat în practică



- 5 ani de randamente zilnice, asimetrie $-0,5$, kurtosis 6
- Un SR anualizat de 1,0 este semnificativ doar dacă (aproape) nicio altă strategie nu a fost încercată; după 2–3 încercări nu mai este
- SR = 1,5 rămâne semnificativ pînă la ≈ 10 încercări, SR = 2,0 pînă la ≈ 200 , iar SR = 2,5 și la 1.000

Teste de data snooping pe grila Bitcoin (1/2)

- ▣ K reguli; $r_{k,t}$: randamentul regulii k în ziua t ; $r_{0,t}$: randamentul reperului; diferența $d_{k,t} = r_{k,t} - r_{0,t}$; $\bar{d}_k$: media ei pe cele n zile
- ▣ $H_0 : \max_k \mathbb{E}[d_{k,t}] \leq 0$: nicio regulă nu depășește reperul
- ▣ Distribuția sub ipoteza nulă vine dintr-un **bootstrap staționar** (Politis & Romano (1994)): reeșantionăm blocuri de zile întregi, de lungime aleatoare, aceleași zile pentru toate regulile
 - ▶ păstrează corelația dintre reguli: nu mai este necesar un N “efectiv”
- ▣ Reality Check (RC, White (2000)): statistica $\max_k \sqrt{n} \bar{d}_k$, media scalată a celei mai bune reguli; p-value-ul: proporția maximelor bootstrap care o depășesc
- ▣ Superior Predictive Ability (SPA, Hansen (2005)): studentizat, $\max_k \sqrt{n} \bar{d}_k / \hat{\omega}_k$, cu $\hat{\omega}_k$ abaterea standard bootstrap a lui $\sqrt{n} \bar{d}_k$; regulile evident slabe nu sînt recentrate
- ▣ StepM Romano–Wolf (Romano & Wolf (2005)): identifică *regulile* care depășesc reperul, cu controlul probabilității de cel puțin o eroare de tip I (FWER)

Teste de data snooping pe grila Bitcoin (2/2)

▣ Configurația: 1.279 de reguli, în eșantion $n = 2.058$ zile, bloc mediu de 20 de zile, 2.000 de replici

▣ Detaliile implementării în [▶ Anexă](#)

Reper	cea mai mare medie studentizată	p RC	p SPA	reguli păstrate de StepM
numerar ($r_0 = 0$)	–	0,004	0,002	314
buy-and-hold	0,88 (regula 14/20)	0,74	0,70	0

▣ Față de numerar, regulile de trend au medii pozitive, care reflectă trendul propriu al Bitcoin; nicio regulă nu depășește deținerea Bitcoin, nici măcar în eșantion, în acord cu SR OOS de 0,02

▣ DSR întreabă “mai mult decât norocul a N încercări?” și are nevoie de N și de $\text{Var}[\widehat{SR}]$ (0,998 sau 0,877); SPA le estimează pe amîndouă din date

Probabilitatea de overfitting a backtest-ului (PBO)

Validare încrucișată combinatorică simetrică (CSCV): Bailey, Borwein, López de Prado & Zhu (2017)

1. Matricea de randamente: T perioade $\times N$ configurații; împărțim rîndurile în S blocuri contigue
 2. Pentru fiecare dintre cele $\binom{S}{S/2}$ alegeri, jumătate din blocuri sînt în eșantion (IS), restul în afara eșantionului (OOS)
 3. Alegem cea mai bună configurație IS n^* ; ordonăm crescător toate cele N configurații OOS și luăm $\bar{\omega} = \text{rang}(n^*) / (N + 1) \in (0, 1)$
 4. Logit $\lambda = \log \frac{\bar{\omega}}{1 - \bar{\omega}}$; $PBO = \Pr[\lambda \leq 0]$: proporția împărțirilor în care învingătorul IS ajunge la sau sub mediana OOS
- $\binom{S}{S/2}$: numărul de moduri de a alege $S/2$ din cele S blocuri; $\bar{\omega}$: rangul relativ OOS al învingătorului IS, aproape de 1 dacă rămîne cel mai bun; $\lambda > 0$: peste mediana OOS
 - $PBO \approx 0$: învingătorul IS rămîne sigur peste mediana OOS; $PBO \approx 0,5$ sau mai mult: a alege învingătorul IS nu este mai bun decît o alegere la întîmplare
 - PBO evaluează **procedura de cercetare**, nu o singură strategie, și nu este probabilitatea de a pierde bani; ca DSR, cere înregistrarea **fiecărei** încercări (Seminarul B11)

Selecția nu este inferență: selecția dublă (1/2)

- Traectoria coeficienților LASSO răspunde la “ce caracteristică intră prima”, nu la “ce caracteristică contează”; statisticile t OLS după LASSO ignoră pasul de selecție
- O variabilă de control corelată cu regresorul de interes d_t , dar doar slab cu y_t , este eliminată: efectul ei trece în coeficientul lui d_t (bias de variabilă omisă)
- Model parțial liniar: efectul lui d_t este liniar, controalele intră prin funcții necunoscute

$$y_t = \theta d_t + g(x_t) + \varepsilon_t, \quad d_t = m(x_t) + v_t$$

- ▶ y_t : variabila rezultat; d_t : regresorul de interes; θ : efectul lui, parametrul de estimat
- ▶ x_t : cele p controale; g : efectul lor asupra lui y_t ; m : cum prezic ele pe d_t ; ε_t , v_t : erori
- ▶ aproximativ rare (sparse): cîteva controale explică cea mai mare parte din g și m

Selecția nu este inferență: selecția dublă (2/2)

- ▣ Selecția dublă (post-double selection, Belloni, Chernozhukov & Hansen (2014)):
 1. LASSO pentru y_t pe $x_t \Rightarrow$ mulțimea selectată $\hat{S}_y$
 2. LASSO pentru d_t pe $x_t \Rightarrow$ mulțimea selectată $\hat{S}_d$
 3. OLS pentru y_t pe d_t și $x_{\hat{S}_y \cup \hat{S}_d}$, eroare standard robustă
- ▣ $\hat{S}_y, \hat{S}_d$: indicii controalelor păstrate de fiecare LASSO; $x_{\hat{S}_y \cup \hat{S}_d}$: controalele păstrate de oricare dintre ele
- ▣ Un control este omis doar dacă nu contează în *niciuna* dintre ecuații, deci biasul de omisiune este de ordinul doi
- ▣ Valid pentru eșantionare independentă și raritate; pentru serii de timp, erorile HAC sînt o aproximare (penalizarea și condițiile în [▶ Anexă](#))

Machine learning dublu: scoruri ortogonale și cross-fitting

- Chernozhukov et al. (2018): rezidualizăm ambele variabile cu *orice* algoritm (LASSO, RF, boosting), apoi regresăm reziduul pe reziduu

$$\tilde{y}_t = y_t - \hat{\ell}(x_t), \quad \tilde{v}_t = d_t - \hat{m}(x_t), \quad \hat{\theta} = \frac{\sum_t \tilde{v}_t \tilde{y}_t}{\sum_t \tilde{v}_t^2}$$

- $\hat{\ell}(x) = \hat{\mathbb{E}}[y | x]$: predicția ML a lui y_t din controale; $\hat{m}(x)$: predicția ML a lui d_t
- $\tilde{y}_t, \tilde{v}_t$: părțile lui y_t și d_t pe care controalele nu le explică; $\hat{\theta}$: panta OLS a lui $\tilde{y}_t$ pe $\tilde{v}_t$


- Scor Neyman-ortogonal $\psi = (\tilde{y} - \theta \tilde{v}) \tilde{v}$, cu media zero la valoarea reală a lui θ

- erorile de ordinul întâi din $\hat{\ell}$ și $\hat{m}$ nu deplasează $\hat{\theta}$ (condițiile de rată în [► Anexă](#))

- Cross-fitting: estimăm $\hat{\ell}, \hat{m}$ pe $K - 1$ pliuri, rezidualizăm pliul lăsat deoparte, repetăm; elimină biasul de overfitting pe propriile observații

- Teoria publicată presupune eșantionare independentă; cu etichete suprapuse pe 5 zile folosim pliuri contigue, purjate cu 5 zile în jurul pliului de test, și erori standard HAC, o limită a datelor declarată ca atare, nu un estimator nou

Exemplu rezolvat: puterea predictivă a VIX pentru randamentele S&P 500



- y_t : randamentul logaritmic pe următoarele 5 zile (bp); d_t : log VIX, standardizat (1 SD = 0,356); 90 de controale: 12 caracteristici tehnice, pătratele și produsele lor două câte două; $n = 6.269$; erori HAC, 4 lag-uri
- LASSO-ul simplu elimină VIX și toate controalele: “niciun efect”, fără nicio eroare standard
- Selecția dublă păstrează $|\hat{S}_y| = 0$ și $|\hat{S}_d| = 15$ controale ($|\cdot|$: numărul de elemente); CI 95% pentru θ $[-22,1; 40,8]$ bp pe săptămână pentru o abatere standard
- Intervalele corecte conțin zero și efecte mari de ambele semne: datele nu permit o concluzie

Virtutea complexității și o lectură critică

- **Kelly, Malamud & Zhou (2024)**: regresii ridge pe P caracteristici Fourier aleatoare ale câtorva predictor, ferestre mobile de doar $T = 12$ luni, P de ordinul miilor
 - ▶ P : numărul de caracteristici (notația lucrării); caracteristici Fourier aleatoare: sin și cos ale unor combinații liniare aleatoare de predictor; T : fereastra de antrenare, în luni
 - ▶ teorie: pentru $P > T$ soluția de normă minimă (potrivirea exactă cu cel mai mic $\|\beta\|_2$) induce implicit shrinkage ("double descent"); R_{OOS}^2 poate fi negativ, în timp ce raportul Sharpe al sincronizării pieței **crește** cu complexitatea; complexitatea nu înseamnă automat overfitting
- **Nagel (2025)**: pentru $P \gg T$ prognoza este o medie a celor T randamente de antrenare, ponderată după similaritate; în ferestre scurte similaritatea înseamnă mai ales apropiere în timp, deci metoda devine o strategie de **momentum ajustat la volatilitate**, care pierde pe date simulate cu reveniri la medie
- **Avramov, Cheng & Metzker (2023)**: profiturile semnalelor deep learning vin din acțiuni greu de arbitrat; excluderea microcapitalizărilor, a firmelor în dificultate sau a episoadelor de volatilitate mare le atenuază, iar costurile le erodează în continuare
- **Chen, Pelger & Zhu (2024)**: impun structură economică; condițiile de moment fără arbitraj devin funcția de pierdere a unei rețele adânci (slide-urile următoare)
- Sinteza domeniului: **Kelly & Xiu (2023)**

Studiu de caz: deep learning în evaluarea activelor, întrebare și metodă (1/2)

- ▣ **Chen, Pelger & Zhu (2024)**: estimează factorul stochastic de actualizare (SDF) M_{t+1} care evaluează **toate acțiunile individuale de pe piața americană**, condiționat de 46 de caracteristici ale firmelor și de istoricul a 178 de serii macroeconomice
- ▣ Absența arbitrajului: SDF evaluează orice randament în exces (Secțiunea I.A, ec. 1)

$$E_t[M_{t+1}R_{t+1,i}^e] = 0, \quad M_{t+1} = 1 - \omega_t^\top R_{t+1}^e$$

- ▶ $R_{t+1,i}^e$: randamentul în exces al acțiunii i față de titlurile de stat pe termen scurt, din luna t în $t + 1$; R_{t+1}^e : vectorul tuturor acțiunilor
- ▶ E_t : speranța condiționată de informația de la t ; ω_t : ponderile unui portofoliu, funcție de caracteristici și de stările macro
- ▣ $F_{t+1} = \omega_t^\top R_{t+1}^e$, portofoliul SDF, este portofoliul tangent condiționat (raportul Sharpe maxim), iar

$$E_t[R_{t+1,i}^e] = \beta_{t,i} E_t[F_{t+1}]$$

- ▶ $\beta_{t,i}$: expunerea acțiunii i la F ; randamentul în exces așteptat este expunerea înmulțită cu prima lui F


Studiu de caz: deep learning în evaluarea activelor, întrebare și metodă (2/2)

- ▣ Motivația: prognoza (Gu, Kelly & Xiu (2020), rețeaua feedforward de referință, FFN) ajustează un moment de ordinul doi acolo unde raportul semnal/zgomot este mic; condiția de absență a arbitrajului țintește un moment de ordinul întâi, iar media în timp elimină o mare parte din zgomot
- ▣ Metodă: metoda generalizată a momentelor (GMM), adversarială (ec. 3, după Hansen & Jagannathan (1997))

$$\min_{\omega} \max_g \frac{1}{N} \sum_{j=1}^N \left(E[M_{t+1} R_{t+1,j}^e g(I_t, I_{t,j})] \right)^2$$


- ▶ I_t : informația macroeconomică; $I_{t,j}$: caracteristicile acțiunii j ; N : numărul de acțiuni
- ▶ g : funcția-instrument aleasă de un adversar astfel încât erorile de evaluare să fie cât mai mari; ω minimizează acest caz cel mai defavorabil
- ▣ Rețele: o FFN pentru ω , o rețea LSTM (long short-term memory) care sintetizează istoricul macro în 4 stări, un adversar g care construiește cele mai dificile active de test; modelul complet se numește GAN
- ▣ Împărțire cronologică: antrenare 1967–1986, validare 1987–1991, test 1992–2016; configurațiile ordonate după raportul Sharpe pe validare (datele și reglarea în [► Anexă](#))

Deep learning în evaluarea activelor: rapoarte Sharpe, lucrare și replicare



- Albastru: lucrarea, SR lunar în afara eșantionului 1992–2016: GAN 0,75, SDF liniar cu elastic net (EN) 0,50, FFN 0,44, SDF liniar fără regularizare (LS) 0,42 (Tabelul I); FF5 0,22, FF3 0,19 (Tabelul A.VI); modelul fără arbitraj regularizat întrece deja rețeaua de prognoză
- Roșu: portofoliile tangente FF3 și FF5, $w \propto \hat{\Sigma}^{-1} \hat{\mu}$, pe factorii [Kenneth French](#), cu ponderi fixate pe 1967–1986: FF5 0,22 [0,11; 0,34], FF3 0,20 [0,08; 0,31] (SE 0,058, [Lo \(2002\)](#)); ambele valori publicate sînt în interiorul intervalelor
 - $\hat{\mu}$, $\hat{\Sigma}$: vectorul mediilor și matricea de covarianță de selecție ale randamentelor factorilor; $\propto$: proporțional cu

Deep learning în evaluarea activelor: reperele după 2016



- Aceleași ponderi fixe, ianuarie 1992 – august 2026, fiecare serie scalată la volatilitatea randamentului în exces al pieței pe 1992–2016; SR lunar 2017–2026 ($T = 116$, $SE \approx 0,09$): FF5 0,06, FF3 0,03, piața 0,24; pe 1992–2016: 0,22, 0,20, 0,15
- Replicabile cu date publice: reperele Fama–French; nereplicabile: GAN, LS și EN la nivel de acțiune (panelul CRSP nu este în datele cursului); scăderea de după 2016 este un semnal de alarmă, încă nu un test, iar aceeași întrebare se pune pentru un GAN fixat în 1991 (detalii în [Anexă](#))

O întrebare deschisă: descoperire sau data mining la scară mare?

- ▣ [Chen, Lopez-Lira & Zimmermann \(2022\)](#): căutarea printre 29.000 de rapoarte contabile a celor cu $t > 2$ dă o predictibilitate transversală asemănătoare cu cea a predictorilor publicați în reviste cu evaluare inter pares; pentru ambele, circa jumătate rămîne după eşantioanele originale
- ▣ [Novy-Marx & Velikov \(2025\)](#): un flux automat cu LLM (large language model, model lingvistic mare) caută peste 30.000 de semnale, păstrează 96 care trec un protocol fix și scrie sute de articole complete, cu motivații inventate și cîteva citări imaginare: HARKing (hypothesising after the results are known, formularea ipotezelor după ce se cunosc rezultatele) la scară mare
- ▣ Întrebarea deschisă: cînd un sistem automat propune variabilele, modelul și interpretarea
 - ▶ care este numărul de încercări?
 - ▶ ce separă o descoperire de cea mai bună dintre multe extrageri?
- ▣ Bucla descoperirii: literatura → ipoteze concurente → date și cod → robustețe fixată dinainte → critică de tip recenzent → raportarea fiecărui test (prompturi reutilizabile în [▶ Anexă](#))
- ▣ Ce verifică cercetătorul: fiecare referință există (DOI, arXiv); fiecare încercare este notată, deci M din corecție le numără pe toate; testele corelate primesc o ipoteză nulă comună; transformările rămîn în pliul de antrenare


Mini-studiu de caz: 102 teste, un singur efect cunoscut rămîne semnificativ (1/2)

- ▣ O propunere tipică a unui asistent: “adaugă mai mulți indicatori: momentum, distanțe față de mediile mobile, rapoarte de volatilitate, RSI și variații ale VIX pe mai multe ferestre”
- ▣ 34 de variabile $\times$ 3 orizonturi (1, 5, 20 de zile) = 102 regresii predictive pe 2001–2015, t Newey–West
 - ▶ regresia j : $r_{t,t+h} = \alpha_j + \beta_j x_{j,t} + e_t$, cu $x_{j,t}$ variabila j și $r_{t,t+h}$ randamentul pe următoarele h zile; $H_{0,j} : \beta_j = 0$
- ▣ Corecții pentru $M = 102$ teste, cu $p_{(1)} \leq \dots \leq p_{(M)}$ p-value-urile ordonate
 - ▶ Holm: respingem cît timp $p_{(j)} \leq 0,05/(M - j + 1)$; controlează FWER, probabilitatea oricărei respingeri false
 - ▶ Benjamini–Hochberg (BH, [Benjamini & Hochberg \(1995\)](#)): respingem cele mai mici j , pentru cel mai mare j cu $p_{(j)} \leq j q/M$; controlează rata falselor descoperiri (FDR) la nivelul q , proporția așteptată a respingerilor false printre toate respingerile
 - ▶ ipoteza nulă comună: cuantila de 95% a lui $\max_j |t_j|$ cînd ținta este deplasată circular, ceea ce păstrează corelația dintre teste

Mini-studiu de caz: 102 teste, un singur efect cunoscut rămîne semnificativ (2/2)

- ▣ $|t| > 1,96$: **21** din 102, față de 5,1 așteptate sub ipoteza nulă globală la 5%
- ▣ Holm (FWER 5%): **0**; BH (FDR 10%): **13**; $|t| > 3$ (Harvey, Liu & Zhu (2016)): **4**
- ▣ Ipoteza nulă comună pentru $\max_j |t_j|$ (500 de deplasări circulare ale țintei): cuantila de 95% a lui $\max_j |t_j| = 3,32$; rămîne semnificativ un singur predictor, randamentul de azi pentru randamentul de mâine, $t = -3,37$: short-term reversal, un efect cunoscut
- ▣ Perioada de verificare 2016–2026: 3 din cele 21 își păstrează semnul cu $|t| > 1,96$, toate variante de short-term reversal; “descoperirile” bazate pe VIX nu se confirmă
- ▣ Holm și BH controlează rate de eroare diferite, la niveluri diferite; BH cere independență sau dependență pozitivă a p-value-urilor ipotezelor nule adevărate, pe care predictorii corelați nu o asigură

Mini-studiu de caz: praguri și perioada de verificare



- Stînga: cele 102 valori $|t|$ din perioada de descoperire, în ordine descrescătoare; fiecare prag răspunde la o altă întrebare și doar ipoteza nulă comună ține cont de corelația dintre teste
- Dreapta: t din descoperire față de t din verificare; cele trei replicări (roșu) sînt toate short-term reversal; variabilele VIX semnificative cad spre zero

Un punct de plecare pentru proiect

▣ Întrebările

- ▶ poate o căutare de variabile asistată de AI să găsească un predictor al randamentelor indicilor (S&P 500, BET, Bitcoin)?
- ▶ rămîne acesta semnificativ după o corecție preînregistrată și pe o perioadă de verificare?
- ▶ adaugă el informație dincolo de short-term reversal?

▣ Replicați întâi: acest mini-studiu (21 din 102 semnificative, un singur predictor semnificativ la ipoteza nulă comună)

▣ Livrabil: o listă de variabile stabilită înainte de examinarea datelor; toate testele cu Holm, BH și ipoteza nulă comună ($\max\text{-}|t|$); o perioadă de verificare; DSR și PBO pentru orice strategie construită pe predictorii rămași

▣ Evidență: fiecare prompt care a influențat o decizie în `AI_USE.md`; fiecare referință inventată, leakage sau încercare omisă în `AI_ERRORS.md`, cu testul care a identificat-o ([șabloane](#))

Concluzii-cheie și o listă de verificare

Trei lecții empirice

- ☐ O respingere ADF nu înseamnă staționaritate: FFD trunchiată a log-prețului S&P 500 rămîne $I(1)$; estimați memoria cu local Whittle
- ☐ K-fold amestecat raportează 69% pe zgomot pur; pe S&P 500 niciun model nu depășește “mereu în sus” (PT, DM, GW)
- ☐ Cel mai bun dintre multe backtest-uri trebuie deflatat sau testat prin bootstrap: grila Bitcoin 1,89 în eșantion, 0,02 în afara lui

Urmează

- ☐ **Capitolul 14:** deep learning și modele fundamentale pentru serii de timp; **Capitolul 15:** modele lingvistice mari și analiza sentimentului

Înainte de orice afirmație


- ☐ Date disponibile la momentul deciziei; transformări estimate doar pe pliurile de antrenare
- ☐ Etichete scalate cu volatilitatea, cu intervalele înregistrate
- ☐ K-fold cu purjare sau CPCV cu embargo; walk-forward pentru testul final
- ☐ Un reper naiv; PT, DM / CW / GW și intervale bootstrap pe blocuri
- ☐ Costuri incluse; fiecare încercare înregistrată; DSR, SPA și PBO
- ☐ “Selectat” sau “important” nu înseamnă “semnificativ”: selecție dublă sau DML pentru inferență

Anexă: Pentru aprofundare pe Quantinar

Cursuri avansate pe quantinar.com

- ☐  Random Forests
- ☐  Shapley Values
- ☐  Shapley Curves: A Smoothing Perspective
- ☐  Machine Learning in Financial Risk
- ☐  Introduction to Reinforcement Learning
- ☐  Generative Adversarial Networks
- ☐  MSCA Digital: The Need for Explainable AI
- ☐  Business Analytics and Data Science
- ☐  Model Selection Criteria
- ☐  PAC Learning

Anexă: de la perceptron la Deep Blue



Mark I Perceptron, manualul operatorului
(1960)

Figură: J.C. Hay, A.E. Murray (1960); domeniu
public; Wikimedia Commons



IBM Deep Blue, Computer
History Museum

Foto: Anton Chiang (2011); CC
BY 2.0; Wikimedia Commons

- **Perceptronul:** o regulă de învățare pentru un singur neuron artificial [Rosenblatt \(1958\)](#); Mark I era un dispozitiv construit pentru a recunoaște imagini simple
- 1997: Deep Blue (IBM) îl învinge pe campionul mondial de șah Garry Kasparov [Campbell, Hoane & Hsu \(2002\)](#)
- Deep Blue căuta cu reguli scrise de oameni; ML-ul modern (acest capitol) *învață* regulile din date

Anexă: R^2 în eșantion al unui predictor fără abilitate

- Un R^2 lunar de 0,5% este mare economic, dar zgomotul de eșantionare are același ordin de mărime
- R^2 OLS în eșantion al unui predictor fără abilitate (termen liber, erori independente, $n \approx 300$ de luni):
 $nR^2 \approx \chi_1^2$
 - ▶ n : numărul de luni; χ_1^2 : distribuția hi-pătrat cu 1 grad de libertate, cu media 1 și varianța 2
 - ▶ deci R^2 are media $1/n \approx 0,3\%$ și abaterea standard $\sqrt{2}/n \approx 0,5\%$
- R_{OOS}^2 poate fi negativ, nu are această distribuție sub ipoteza nulă și cere un test propriu (Clark–West)

Anexă: exemplu rezolvat: agregarea predicțiilor arborilor

- Random forest-ul din studiul de caz (400 de arbori, dimensiune minimă a frunzei 100), antrenat pe primele patru pliuri purjate
- Predicția pentru ultima observație (11 septembrie 2026): $P(\text{creștere în 5 zile})$ dată de fiecare arbore
 - ▶ probabilitățile estimate de arborii individuali variază între 0,31 și 0,88 (abatere standard 0,11)
 - ▶ 81,5% dintre arbori votează “sus” ($p > 0,5$)
 - ▶ probabilitatea estimată de pădure = media probabilităților estimate de cei 400 de arbori = 0,608
- Predicțiile arborilor diferă mult; media lor este mult mai stabilă
- Stabilitatea nu înseamnă acuratețe: nici pădurea nu depășește “mereu în sus” (studiul de caz)

Anexă: eşantionarea datelor financiare: bare

Bare de timp şi de tranzacţii

- O **bară** = un rând (deschidere, maxim, minim, închidere, volum) care rezumă un interval de eşantionare
- Bare de timp: la interval fix (1 minut, 1 zi); supraeşantionează perioadele liniştite; randamente cu cozi groase
- Bare de tranzacţii (tick): o bară la fiecare N tranzacţii

Bare de volum, valoare şi informaţionale

- O bară la fiecare V acţiuni sau la fiecare D dolari tranzacţionaţi: eşantionare după **sosirea informaţiei**
- Randamente mai apropiate de extrageri i.i.d. din distribuţia Normală: [Clark \(1973\)](#); [Ané & Geman \(2000\)](#)
- Bare de dezechilibru / de serii: eşantionăm când order flow-ul devine unilateral

- Capitolul foloseşte bare zilnice de timp; date la nivel de tranzacţie (platforme de tranzacţionare cripto) în [Capitolele 10 şi 16](#)

Anexă: ponderile fracționare și comportamentul lor asimptotic

Definiție 6 (Operatorul de diferențiere fracționară)

□ Cu operatorul lag $BX_t = X_{t-1}$ și un ordin real d :

$$(1 - B)^d = \sum_{k=0}^{\infty} \binom{d}{k} (-B)^k, \quad \tilde{X}_t = \sum_{k=0}^{\infty} w_k X_{t-k}$$

□ Ponderi: $w_0 = 1$, $w_k = -w_{k-1} \frac{d-k+1}{k} = \frac{\Gamma(k-d)}{\Gamma(-d)\Gamma(k+1)} \sim \frac{k^{-(1+d)}}{\Gamma(-d)}$ pentru $k \rightarrow \infty$

- $\binom{d}{k} = d(d-1)\cdots(d-k+1)/k!$: coeficientul binomial, definit pentru orice d real; Γ : funcția gamma, $\Gamma(k+1) = k!$
- $\sim$: raportul celor doi membri tinde la 1; ponderile scad ca $k^{-(1+d)}$, mai lent pentru d mai mic
- $d = 1$: $w = (1, -1, 0, 0, \dots)$ — randamentele obișnuite
- $0 < d < 1$: ponderile scad hiperbolic $\Rightarrow$ se păstrează memoria lungă
- Suma infinită: $\sum_{k=0}^{\infty} w_k = (1-1)^d = 0$, deci nivelul lui X_t se anulează doar la limită

Anexă: local Whittle și local Whittle exact (1/2)

- Periodograma: estimatorul de selecție al densității spectrale la frecvența Fourier $\lambda_j = 2\pi j/n$

$$I(\lambda_j) = \frac{1}{2\pi n} \left| \sum_{t=1}^n X_t e^{-i\lambda_j t} \right|^2$$

- Local Whittle (Robinson (1995)): alegem δ astfel încât $f(\lambda) \approx G\lambda^{-2\delta}$ să se potrivească pe primele m frecvențe

$$\hat{\delta} = \arg \min_{\delta} \log \left(\frac{1}{m} \sum_{j=1}^m \lambda_j^{2\delta} I(\lambda_j) \right) - \frac{2\delta}{m} \sum_{j=1}^m \log \lambda_j, \quad \sqrt{m}(\hat{\delta} - \delta) \xrightarrow{d} N(0, \frac{1}{4})$$

- ▶ n : mărimea eșantionului; m : numărul de frecvențe folosite; i : unitatea imaginară; G a fost eliminat prin optimizare
- ▶ $\xrightarrow{d}$: convergență în distribuție; de aici eroarea standard $1/(2\sqrt{m})$

Anexă: local Whittle și local Whittle exact (2/2)

- Local Whittle exact (ELW, Shimotsu & Phillips (2005); media necunoscută: Shimotsu (2010)): periodograma lui $(1 - B)^\delta X_t$, valid și pentru $\delta \geq \frac{1}{2}$ (nestaționar)
- De ce seria FFD pare să aibă $\hat{\delta} \approx 0,75$: peste frecvența $1/K$ filtrul trunchiat acționează ca $(1 - B)^{0,25}$; doar $n/(2\pi K) \approx 2$ din cele $m = 294$ de frecvențe sînt sub $1/K$, unde rădăcina unitară reappare
 - ▶ K : lungimea ferestrei FFD (444 de laguri)
 - ▶ estimarea este memoria aparentă în banda de frecvențe, nu ordinul de integrare al seriei

 MFM_ch13_ffd

Anexă: exemplu rezolvat: purjare cu 10 observații

- Observații $t = 0, \dots, 9$; eticheta lui t se termină la $t + 2$ (plafonat la 9)
- 5 pliuri contigue de câte 2; embargo = 1 observație

Test	Eliminate	Antrenare
0, 1	2, 3	4–9
2, 3	0, 1, 4, 5	6–9
4, 5	2, 3, 6, 7	0, 1, 8, 9
6, 7	4, 5, 8, 9	0–3
8, 9	6, 7	0–5

- Test $\{4, 5\}$: etichetele lui 2 și 3 se termină la 4 și 5 $\Rightarrow$ purjate; 6 este embargoul; 7 începe când se termină ultima etichetă de test $\Rightarrow$ purjată
- Cu etichete suprapuse, pînă la 4 din 10 observații sînt eliminate din antrenare

Anexă: validitatea K-fold pentru serii de timp

- Bergmeir, Hyndman & Koo (2018): pentru un model **pur autoregresiv** $y_t = g(y_{t-1}, \dots, y_{t-p}) + \varepsilon_t$ cu erori necorelate serial, K-fold standard este valid
 - ▶ g : o funcție oarecare, posibil neliniară, de ultimele p valori; ε_t : eroarea
 - ▶ erorile din pliul de test sînt necorelate cu erorile de antrenare, deci eroarea CV este nedeplasată pentru eroarea OOS
- Eșuează cînd **erorile** sînt corelate serial
 - ▶ etichete suprapuse: randamentele pe h zile înainte au în comun $h - 1$ randamente zilnice
 - ▶ caracteristici persistente care nu fac parte din lag-urile modelului (medii mobile, niveluri precum log-prețului FFD)
 - ▶ dinamică subspecificată (prea puține lag-uri)
- Experimentul de leakage izolează exact acest caz: etichete pe 20 de zile și caracteristici mobile pe 20 de zile
- Verificați înainte de a alege: autocorelația reziduurilor CV; dacă este semnificativă, purjare și embargo

Anexă: walk-forward și CV combinatorică cu purjare

Walk-forward (WF)

- Antrenare pe $[0, T_k]$, test pe $(T_k, T_{k+1}]$, apoi avansăm; T_k : sfârșitul celei de-a k -a ferestre de antrenare
- Imită implementarea în timp real; fără date viitoare în antrenare
- Dar o **singură traiectorie**: varianță mare și risc de overfitting prin încercări repetate

CV combinatorică cu purjare (CPCV)

- N grupuri contigue; test pe toate cele $\binom{N}{k}$ combinații de k grupuri, cu purjare și embargo
- $\varphi = \frac{k}{N} \binom{N}{k}$: numărul de traiectorii complete de backtest; de ex. $N = 6, k = 2$: 15 împărțiri, 5 traiectorii
- O **distribuție** de rapoarte Sharpe în loc de un singur număr

- $\binom{N}{k}$: numărul de moduri de a alege k din N grupuri; fiecare grup este testat de φ ori, deci predicțiile de test formează φ istorii complete
- Regulă practică: K-fold cu purjare / CPCV pentru selecția modelului; WF pentru evaluarea finală, realistă

Anexă: testarea acurateții direcționale: Pesaran–Timmermann (1/2)

- H_0 : semnul prezis x_t este independent de semnul realizat y_t (Pesaran & Timmermann (1992))
- $\hat{P}$ = proporția semnelor corecte; sub H_0 proporția așteptată este $\hat{P}^* = \hat{p}_y \hat{p}_x + (1 - \hat{p}_y)(1 - \hat{p}_x)$
 - ▶ $\hat{p}_y, \hat{p}_x$: proporțiile de “sus” realizate și prezise; n : numărul de prognoze
 - ▶ $\hat{p}_y \hat{p}_x$: șansa ca ambele să fie “sus” dacă sînt independente; $(1 - \hat{p}_y)(1 - \hat{p}_x)$: ambele “jos”

$$PT = \frac{\hat{P} - \hat{P}^*}{\sqrt{\hat{V}(\hat{P}) - \hat{V}(\hat{P}^*)}} \xrightarrow{d} N(0, 1), \quad \hat{V}(\hat{P}) = \frac{\hat{P}^*(1 - \hat{P}^*)}{n}$$

- ▶ $\hat{V}(\hat{P}^*) = [(2\hat{p}_y - 1)^2 \hat{p}_x(1 - \hat{p}_x) + (2\hat{p}_x - 1)^2 \hat{p}_y(1 - \hat{p}_y)]/n + 4\hat{p}_y \hat{p}_x(1 - \hat{p}_y)(1 - \hat{p}_x)/n^2$
- ▶ $\hat{V}(\cdot)$: varianța estimată sub H_0 ; $PT > 1,645$: abilitate direcțională la 5% (unilateral)

Anexă: testarea acurateții direcționale: Pesaran–Timmermann (2/2)

- ▣ Modelul logit de mai sus: $\hat{p}_y = 0,581$, $\hat{p}_x = 0,983 \Rightarrow \hat{P}^* = 0,578 > \hat{P} = 0,576$; $PT = -1,28$, p unilateral = 0,90
- ▣ PT ține cont automat de frecvențele marginale: reperul nu trebuie specificat separat
- ▣ Etichete suprapuse pe 5 zile: PT presupune zile independente; aceeași ipoteză nulă ca testul t al pantei în $y_t = a + b x_t + u_t$ cu erori Newey–West (Newey & West (1987)): $t = -1,00$
 - a : termenul liber; b : panta, zero sub independență; u_t : eroarea

 MFM_ch13_inference

Anexă: AUC și incertitudinea ei de eșantionare

- Curba ROC (Receiver Operating Characteristic): rata rezultatelor adevărat pozitive $TP/(TP + FN)$ în funcție de rata rezultatelor fals pozitive $FP/(FP + TN)$, pentru toate pragurile
- Aria de sub curbă (AUC) = $P(\hat{p}_{\text{poz}} > \hat{p}_{\text{neg}}) + \frac{1}{2}P(\hat{p}_{\text{poz}} = \hat{p}_{\text{neg}}) = U/(n_1 n_0)$
 - ▶ $\hat{p}_{\text{poz}}, \hat{p}_{\text{neg}}$: probabilitățile prezise pentru o observație pozitivă (sus) și una negativă (jos), extrase la întâmplare
 - ▶ n_1, n_0 : numărul de observații pozitive și negative; U : statistica Mann–Whitney, numărul perechilor (pozitivă, negativă) ordonate corect, egalitățile numărate cu $\frac{1}{2}$
 - ▶ 0,5 = nicio capacitate de ordonare; 1 = orice observație pozitivă este ordonată peste orice observație negativă
- Eroarea standard DeLong (DeLong, DeLong & Clarke-Pearson (1988)): din valorile de plasare, proporția observațiilor din cealaltă clasă pe care fiecare observație le depășește; presupune observații independente
- Bootstrap circular pe blocuri (Künsch (1989)): reeșantionăm blocuri de $L = 20$ zile consecutive, 1.000 de replici; păstrează dependența serială
- Logit, AUC agregat în afara pliurilor = 0,479
 - ▶ CI 95% DeLong [0,465; 0,494]: “semnificativ mai slab decât întâmplarea”
 - ▶ CI 95% bootstrap pe blocuri [0,455; 0,504]: zgomot în jurul lui 0,5
- Un AUC sub 0,5 înseamnă ordonare inversă doar dacă trece un test care respectă dependența

Anexă: Giacomini–White, statistica și fereastra mobilă (1/2)

- Giacomini & White (2006): ipoteza nulă privește **metoda** de prognoză (model + fereastră de estimare + regula de reestimare), nu modelul populației

$$H_0 : \mathbb{E}[d_{t+\tau} \mid \mathcal{F}_t] = 0 \Rightarrow \mathbb{E}[h_t d_{t+\tau}] = 0, \quad GW = n \bar{Z}^\top \hat{\Omega}^{-1} \bar{Z} \xrightarrow{d} \chi_q^2$$

- Notățiile

- ▶ $d_{t+\tau}$: diferența pierderilor celor două prognoze făcute la t pentru orizontul $\tau = 5$ zile; $\mathcal{F}_t$: informația disponibilă la t
 - ▶ h_t : funcții-test cunoscute la t (aici 1 și diferența pierderilor întârziată, $q = 2$); $Z_t = h_t d_{t+\tau}$
 - ▶ $\bar{Z}$: media lui Z_t pe cele n prognoze; $\hat{\Omega}$: matricea de covarianță HAC a lui Z_t ; χ_q^2 : hi-pătrat cu q grade de libertate
- Interpretare: sub H_0 nicio informație de la t nu prezice care metodă va fi mai bună; un GW mare (p mic) respinge acuratețea condiționată egală

Anexă: Giacomini–White, statistica și fereastra mobilă (2/2)

- Teoria cere o fereastră de estimare mărginită (mobilă), astfel încât zgomotul de estimare să nu dispară; o fereastră care se extinde iese din cadrul teoremei
- Întrebarea pusă de fiecare test
 - ▶ CW: adaugă informație modelul *populației* cu caracteristici?
 - ▶ GW: prognozează mai bine regula *estimată*, așa cum este folosită?
- Logit-ul pe S&P 500, fereastră mobilă de 8 ani, cum cere teoria GW: $GW = 26,5$ ($p < 0,001$): logit-ul prognozează mai slab decât constanta

 MFM_ch13_inference

Anexă: importanța caracteristicilor: SHAP

Definiție 7 (Valoarea Shapley a caracteristicii j (SHAP, Lundberg & Lee (2017)))

- Contribuția marginală medie a lui j peste toate coalițiile $S \subseteq \{1, \dots, p\} \setminus \{j\}$:

$$\phi_j = \sum_S \frac{|S|! (p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)], \quad \hat{f}(x) = \phi_0 + \sum_j \phi_j$$

- SHAP intervențional: $v(S) = \mathbb{E}[\hat{f}(x_S, X_{\bar{S}})]$, media lui $\hat{f}$ cu caracteristicile din afara lui S extrase dintr-un eșantion de referință; $\phi_0 = v(\emptyset) =$ predicția medie

- Notățiile: p : numărul de caracteristici; S : o coaliție, o submulțime a celorlalte caracteristici, $|S|$ mărimea ei, $\bar{S}$ caracteristicile din afara ei; $v(S)$: predicția când sînt cunoscute doar caracteristicile din S ; $\hat{f}(x)$: predicția modelului pentru x
- Ponderea lui S este probabilitatea ca exact caracteristicile din S să apară înaintea lui j într-o ordonare aleatoare a celor p caracteristici
- SHAP condiționat folosește $v(S) = \mathbb{E}[\hat{f}(X) \mid X_S = x_S]$; cele două diferă când caracteristicile sînt dependente
- Atribuire aditivă a fiecărei predicții; media lui $|\phi_j|$ pe observații = importanța globală
- Efecte de substituție:** caracteristicile corelate își împart (și diluează) importanța — grupați-le întîi

Anexă: interpretarea importanței caracteristicilor

- **MDI** pune pe primele locuri volatilitatea; **MDA** și **SHAP** indică momentumul pe 20 de zile și distanța față de media mobilă pe 200 de zile
- Volatilitatea pe 20 de zile: MDI ridicat, dar MDA **negativ** — un semn de overfitting, nu o dovadă: zgomotul de eșantionare și caracteristicile corelate modifică și ele MDA
- Importanțele sînt foarte mici ($\Delta AUC < 0,01$), în acord cu compararea modelelor
- Permutarea uneia dintre mai multe caracteristici corelate creează puncte în afara varietății datelor: MDA și SHAP **extrapolează** (Hooker, Mentch & Zhou (2021)); permutați în interiorul grupurilor sau reestimați fără caracteristică
- Importanțele sînt estimări și cer o analiză proprie a incertitudinii; arborii “onești” dau *predicții* de pădure asimptotic normale și CI (Wager & Athey (2018)), nu CI pentru importanțe
- **Backtest-ul nu este un instrument de cercetare**; analiza importanței este (López de Prado (2018))

Anexă: teste de data snooping: Reality Check, SPA, Romano–Wolf

- K reguli, diferențe de randament $d_{k,t} = r_{k,t} - r_{0,t}$ față de un reper r_0 ; $H_0 : \max_k \mathbb{E}[d_{k,t}] \leq 0$
 - ▶ n : numărul de zile; $\bar{d}_k$: diferența medie a regulii k
- Reality Check (RC, [White \(2000\)](#)): statistica $\max_k \sqrt{n} \bar{d}_k$; distribuția sub H_0 din **bootstrap-ul staționar** ([Politis & Romano \(1994\)](#)) al întregii matrice $n \times K$
 - ▶ reeșantionarea unor zile întregi păstrează corelația dintre reguli: nu mai trebuie numărate încercările “efective”
- Superior Predictive Ability (SPA, [Hansen \(2005\)](#)): $\max_k \sqrt{n} \bar{d}_k / \hat{\omega}_k$ studentizat, cu $\hat{\omega}_k$ abaterea standard a lui $\sqrt{n} \bar{d}_k$; regulile evident slabe nu sînt recentrate, deci adăugarea unor reguli inutile nu reduce puterea testului
- Romano–Wolf StepM ([Romano & Wolf \(2005\)](#)): procedură descendentă care arată *care* reguli depășesc reperul, cu controlul probabilității de cel puțin o eroare de tip I (FWER)
- DSR întreabă “depășește cel mai bun SR norocul a N încercări?” și are nevoie de N și de $\text{Var}[\widehat{SR}]$; aceste teste le estimează pe amîndouă din date

Anexă: selecția dublă și DML, penalizarea și condițiile (1/2)

- Model parțial liniar: $\mathbb{E}[\varepsilon_t | d_t, x_t] = 0$, $\mathbb{E}[v_t | x_t] = 0$, $\text{Var}(v_t) > 0$; g , m aproximativ rare (sparse)
 - ▶ erorile nu pot fi prezise din regresori; d_t are o variație proprie, dincolo de controale
- Selecția dublă: eroarea standard robustă la heteroscedasticitate este validă pentru eșantionare independentă, condiții de regularitate și raritate $s^2 \log^2(p \vee n)/n \rightarrow 0$ (Belloni, Chernozhukov & Hansen (2014)); pentru serii de timp, erorile HAC sînt o aproximare
 - ▶ s : numărul controalelor care contează; p : numărul de controale; $p \vee n = \max(p, n)$
- Funcția obiectiv LASSO, cu ponderi de penalizare specifice fiecărei caracteristici

$$\frac{1}{n} \sum_t (y_t - x_t^\top \beta)^2 + \frac{\lambda}{n} \sum_j \hat{\psi}_j |\beta_j|, \quad \lambda = 2c\sqrt{n} \Phi^{-1}(1 - \gamma/(2p))$$

- ▶ constantele plug-in $c = 1,1$, $\gamma = 0,1/\log n$; ponderile $\hat{\psi}_j^2 = \frac{1}{n} \sum_t x_{tj}^2 \hat{e}_t^2$, $\hat{e}_t$ fiind reziduurile pasului anterior, iterate

Anexă: selecția dublă și DML, penalizarea și condițiile (2/2)

- DML (Chernozhukov et al. (2018)): cu $\ell(x) = \mathbb{E}[y | x]$, este suficient (alături de consistență și condiții de regularitate) ca

$$\|\hat{m} - m\| (\|\hat{\ell} - \ell\| + \|\hat{m} - m\|) = o_P(n^{-1/2})$$

- ▶ $\|\hat{m} - m\|$: rădăcina erorii pătratice medii de estimare a algoritmului pentru m ; la fel pentru ℓ
- ▶ $o_P(n^{-1/2})$: tinde la zero în probabilitate mai repede decât $1/\sqrt{n}$
- ▶ de exemplu, ambele erori $o_P(n^{-1/4})$: fiecare algoritm poate converge mai lent decât un model parametric, deoarece contează doar produsul erorilor

Anexă: machine learning pentru inferență în evaluarea activelor

- [Feng, Giglio & Xiu \(2020\)](#): adaugă un factor nou informație de evaluare, date fiind sutele de factori existenți?
 - ▶ selecție dublă a factorilor de control din “factor zoo”, apoi un test t valid pentru prețul de risc al factorului nou
 - ▶ răspunsul inferențial la [Harvey, Liu & Zhu \(2016\)](#), care ridică pragul la $t > 3$
- Efecte eterogene: pădurile cauzale “oneste” dau CI pentru efecte care variază cu covariatele ([Wager & Athey \(2018\)](#))
- Trei reguli
 - ▶ predicția și inferența au ținte diferite: un predictor bun poate da un $\hat{\theta}$ deplasat
 - ▶ ortogonalizați înainte de a testa și faceți cross-fitting cu pliuri care respectă timpul
 - ▶ raportați CI; “selectat” sau “important” nu înseamnă “semnificativ”

Anexă: deep learning pentru secvențe

Rețele recurente (LSTM, GRU)

- Starea ascunsă poartă memoria: $h_t = g(h_{t-1}, x_t)$; g : o funcție neliniară cu ponderi antrenate, x_t : intrarea de la t
- Porțile controlează ce se păstrează sau se uită, atenuând dispariția gradientilor
- Folosite pentru prognoza volatilității, prognoze bazate pe registrul de ordine și prognoze intrazilnice

Transformer

- Auto-atenție: $\text{softmax}(QK^\top / \sqrt{d_k})V$, cu matricele de interogare, cheie și valoare Q, K, V (transformări liniare ale intrărilor); d_k : dimensiunea cheilor; softmax transformă fiecare rând de scoruri în ponderi cu suma 1
- Dependență pe termen lung, antrenare paralelă
- Baza modelelor lingvistice mari ([Capitolul 15](#))

Anexă: modele fundamentale pentru serii de timp

Modele de prognoză pre-antrenate

- Pre-antrenate pe colecții mari de serii, folosite **zero-shot** (fără reantrenare): Chronos (Ansari et al., 2024), TimesFM (Das et al., 2024), Moirai (Woo et al., 2024), Lag-Llama (Rasul et al., 2023)
 - Repere utile pentru prognoza volatilității și a volumului
 - Pentru randamente moștenesc aceleași limite de semnal/zgomot
 - Datele de pre-antrenare se pot suprapune cu perioada de test: o nouă formă de leakage
-
- Tratatate pe larg, cu instrumentele de evaluare a prognozelor de risc din [Capitolul 8](#), în [Capitolul 14](#)

Anexă: învățare prin recompensă, modele generative, AI explicabilă, risc

Învățare prin recompensă (RL)

- O politică $\pi(a | s)$ alege acțiuni a în stări s pentru a maximiza recompensa cumulată
- Execuție optimă, market making, deep hedging: Buehler et al. (2019)

Modele generative

- GAN, autoencodere variaționale (VAE), modele de difuzie: scenarii sintetice pentru teste de stres

AI explicabilă

- Cerută de autorități (EU AI Act, scoring de credit, riscul de model)
- SHAP, LIME (explicații locale interpretabile, independente de model), dependență parțială

ML pentru risc

- Value-at-Risk (VaR): cuantile condiționate (păduri de regresie cuantică, boosting cu pierdere cuantică); Expected Shortfall (ES): media cuantilelor estimate din coadă sau o pierdere comună VaR-ES; volatilitatea: o țintă pe randamentele la pătrat (Capitolele 7–8)

□ Quantinar:  Reinforcement Learning  GANs  Explainable AI  ML in Financial Risk

◀ Înapoi

Anexă: deep learning în evaluarea activelor, datele (Secțiunea III.A)

- Randamente lunare ale tuturor acțiunilor din CRSP, ianuarie 1967 – decembrie 2016, în exces față de dobânda la titlurile de stat pe o lună
- 46 de caracteristici ale firmelor, în șase grupe: randamente trecute, investiții, profitabilitate, active necorporale, valoare, fricțiuni de tranzacționare (Tabelul A.II)
 - ▶ Doar lunile cu toate cele 46 de caracteristici: circa 10.000 din 31.000 de acțiuni; caracteristicile devin ranguri lunare normalizate transversal
- 178 de serii macroeconomice: 124 din FRED-MD ([McCracken & Ng \(2016\)](#)), cele 46 de mediane lunare ale caracteristicilor, 8 predictori din [Welch & Goyal \(2008\)](#); transformate în serii staționare
- Împărțire: antrenare 1967–1986, validare 1987–1991, test 1992–2016

Anexă: deep learning în evaluarea activelor, metoda (Secțiunile I–II, Anexa C) (1/2)

- Metoda generalizată a momentelor, adversarială: $\min_{\omega} \max_g \frac{1}{N} \sum_j (E[M_{t+1} R_{t+1,j}^e g(I_t, I_{t,j})])^2$ (ec. 3); g construiește activele de test cu cele mai mari erori de evaluare, după Hansen & Jagannathan (1997)
- Rețele: o FFN pentru ω ; un LSTM care sintetizează istoricul macro în 4 stări ascunse; adversarul g , cu 8 instrumente; trei pași: SDF necondiționat, maximizare după g , din nou minimizare; modelul complet: GAN (II.D)
- Hiperparametri: 384 de configurații, ordonate după raportul Sharpe (SR) pe validare; aleasă: 2 straturi de câte 64 de unități, dropout, Adam; ansamblu de 9 estimări (Tabelul A.VIII); coeficienți beta: o a doua FFN estimează $E_t[R_{t+1,i}^e F_{t+1}] \propto \beta_{t,i}$
- Repere: FFN din Gu, Kelly & Xiu (2020); SDF liniar $\omega_{t,i} = \theta^\top I_{t,i}$ pe componentele long și short ale fiecărei caracteristici, fără regularizare (LS) sau cu elastic net (EN); portofoliile tangente FF3/FF5 (Fama & French (2015))
 - $\omega_{t,i}$: ponderea acțiunii i ; $I_{t,i}$: caracteristicile ei; θ : câte un coeficient pentru fiecare caracteristică, același pentru toate acțiunile și lunile

Anexă: deep learning în evaluarea activelor, metoda (Secțiunile I–II, Anexa C) (2/2)

- ▣ Măsurî (II.F): SR al lui F și două măsuri de potrivire; $\hat{\epsilon}_{t+1,i}$: eroarea de evaluare, partea din $R_{t+1,i}^e$ neexplicată de $\hat{\beta}_{t,i}F_{t+1}$
- ▣ Variația explicată: unu minus raportul dintre eroarea de evaluare pătratică medie și randamentul în exces pătratic mediu

$$EV = 1 - \frac{\overline{\hat{\epsilon}^2}}{(\overline{R^e})^2}$$

- ▶ bara: media în timp a mediilor transversale lunare; $EV = 1$: factorul explică toată variația
- ▣ R^2 transversal: cât de bine explică modelul randamentele medii

$$R_{\text{transv}}^2 = 1 - \frac{\frac{1}{N} \sum_i \frac{T_i}{T} (\bar{\hat{\epsilon}}_i)^2}{\frac{1}{N} \sum_i \frac{T_i}{T} (\bar{R}_i^e)^2}$$

- ▶ $\bar{\hat{\epsilon}}_i$, $\bar{R}_i^e$: mediile în timp pentru acțiunea i ; T_i : numărul de luni cu date pentru acțiunea i , T : numărul de luni din eșantion

Anexă: deep learning în evaluarea activelor, rezultate (1/2)

- Sursa: [Chen, Pelger & Zhu \(2024\)](#), *Management Science*
- SR lunar al SDF în afara eșantionului (Tabelul I): GAN 0,75, EN 0,50, FFN 0,44, LS 0,42; FF5 0,22, FF3 0,19 (Tabelul A.VI)
 - ▶ Interpretare: anualizat, 2,6 față de 1,7 (EN) și 1,5 (FFN); modelul liniar fără arbitraj regularizat (EN) întrece deja rețeaua de prognoză; LS, fără regularizare, nu
- Acțiuni individuale (Tabelul I): EV 8% (GAN) față de 3–4%; R^2 transversal 23% față de 14–19%
 - ▶ Interpretare: criteriul bazat pe absența arbitrajului îmbunătățește ambii indicatori, deși nu îi maximizează direct
- Portofolii pe decilele coeficienților β (Tabelul II, perioada de test, anualizat): diferența dintre decila superioară și cea inferioară 0,39; alfa FF5 0,39, $t = 9,96$; testul GRS respinge CAPM, FF3 și FF5 ($p = 0,00$)
 - ▶ alfa: randamentul mediu neexplicat de modelul factorial; testul GRS (Gibbons–Ross–Shanken): H_0 toate alfa ale portofoliilor pe decile sînt zero
 - ▶ Interpretare: coeficienții beta au o relație liniară cu randamentele medii ($R^2 = 0,97$ al randamentului mediu pe β , Figura 8), iar modelele factoriale nu le explică randamentele

Anexă: deep learning în evaluarea activelor, rezultate (2/2)

- 46 de seturi de decile sortate după caracteristici (Tabelul III): R^2 transversal GAN peste 90% pentru toate; EV short-term reversal 0,70 față de 0,43 (EN), momentum 0,54 față de 0,26
 - ▶ Interpretare: câștigurile vin din decilele extreme și din interacțiuni; toate modelele explică bine decilele de mărime și de valoare contabilă/de piață (Secțiunea III.E)
- Stări macro (Figura 6): includerea directă a celor 178 de serii reduce puternic SR în afara eșantionului; GAN pierde circa 10% fără stările macro și 20% doar cu momente necondiționate
 - ▶ Interpretare: LSTM surprinde dinamica macroeconomică pe care ultima variație observată nu o poate reda
- Acțiuni cu capitalizare mare (Tabelul IV, SR lunar, modele estimate pe toate acțiunile, evaluate pe subeșantion): circa 1.500 de acțiuni GAN 0,41, FFN 0,30, EN 0,15; circa 550 de acțiuni 0,26, 0,24, 0,23; reestimate pe cele 1.500: 0,42, 0,28, 0,42
 - ▶ Interpretare: avantajul scade puternic pentru acțiunile cu cea mai mare capitalizare; EN recuperează diferența când este reestimat pe ele

Anexă: deep learning în evaluarea activelor, replicare și extindere

- Limită de date: panelul la nivel de acțiune (randamente CRSP, 46 de caracteristici) nu este în datele cursului, deci GAN pe acțiuni individuale nu poate fi reprodus
- Cu [Kenneth French Data Library](#) și FRED-MD, pe împărțirea publicată
 - ▶ Replicabile: ponderile tangente FF3 și FF5 estimate pe 1967–1986 (nota 23), SR lunar pe 1992–2016, alături de Tabelul A.VI
 - ▶ Nereplicabile cu datele cursului: LS și EN publicate (Tabelele I și III) folosesc ramuri ponderate după rang pentru 46 de caracteristici și coeficienți beta la nivel de acțiune
 - ▶ Analog pe date de portofoliu, o extindere, nu o replicare: SDF liniar ($\hat{\theta}_{LS}$ în formă închisă, $\hat{\theta}_{EN}$ cu obiectivul din Secțiunea II.F) pe jumătățile (decilele 1–5, 6–10) celor 15 caracteristici pe care biblioteca le sortează în decile; nivelurile nu sînt comparabile cu Tabelele I și III

Anexă: deep learning în evaluarea activelor, limite și o extindere deschisă

- Limite declarate de autori
 - ▶ Pozitivitatea SDF nu este impusă (nota 9); doar lunile cu toate caracteristicile, ceea ce elimină mai ales acțiunile foarte mici (Secțiunea III.A)
 - ▶ Fricțiuni (Secțiunea III.I, Figura 17): SR anual 1,73 fără cele mai mici 40% dintre acțiuni, 2,07 fără cele mai mari 40% dintre spread-urile bid–ask, 1,87 fără cele 40% cu turnover-ul cel mai mic; vezi și [Avramov, Cheng & Metzker \(2023\)](#)
 - ▶ Valorile indicatorilor sînt mai mari în eșantion decît în afara lui, semn de un anumit overfitting (Secțiunea III.C); stările ascunse nu sînt comparabile între estimări, deci nu pot fi mediate (Secțiunea II.E)
- Extindere deschisă: păstrați specificația aleasă pe 1967–1991 și evaluați-o pe 2017–2026, după eșantionul lucrării
 - ▶ mai întrece SDF-ul liniar fără arbitraj modelul FF5?
 - ▶ adaugă ceva stările LSTM extrase din FRED-MD?

Anexă: deep learning în evaluarea activelor, interpretarea celor două grafice

- GAN 0,75 față de FF5 0,22: cu erorile standard Lo 0,065 și 0,058, SE a diferenței este cel mult 0,12, oricare ar fi corelația, deci diferența depășește 4 SE (randamente i.i.d. normale); un test pe perechi, cu randamente aliniate (Ledoit & Wolf (2008)) este mai precis
- Ponderile fixe ale FF5 se concentrează pe profitabilitate și investiții: RMW 0,42, CMA 0,30 (ponderi scalate la $\sum |w| = 1$); FF3 alocă 0,61 factorului HML; ambele combinații au fost alese pe 1967–1986
- După 2016, portofoliile tangente cu ponderi fixe au rapoarte Sharpe lunare mult sub cel al pieței; cu $T = 116$ luni, SE este de circa 0,09: un semnal de alarmă, încă nu un test

 MFM_ch13_sdf_replication

Anexă: bucla descoperirii, pas cu pas (1/2)

- **Literatura:** "Rezumă dovezile despre cât din predictibilitatea publicată a randamentelor rezistă în afara eşantionului şi după publicare: DOI sau id arXiv, eşantion, estimarea principală a scăderii."
 - ▶ Verificaţi fiecare identificator; Semantic Scholar, Google Scholar, Elicit pentru căutare
- **Ipoteze:** "Pentru o variabilă care prognozează randamentele S&P 500 în 2001-2015, dă explicaţii concurente (primă de risc, reversal, microstructură, data mining) şi ce prezice fiecare pentru 2016-2026 şi pentru alţi indici."
- **Date şi cod:** "Scrie cod Python care construieşte 34 de variabile tehnice din închiderile zilnice S&P 500 şi VIX ale cursului doar cu informaţia pînă în ziua t şi raportează statisticile t Newey-West pentru randamentele la 1, 5 şi 20 de zile în 2001-2015."
 - ▶ Orice asistent (Claude, ChatGPT, Gemini, GitHub Copilot); reproduceţi întîi studiul de caz: "mereu în sus" 58,1%

Anexă: bucla descoperirii, pas cu pas (2/2)

- **Robustețea**, fixată dinainte: "Scrie planul de analiză: lista completă de variabile și orizonturi, perioada de verificare, corecțiile (Holm, BH, max-t) și rezultatul care ar conta drept eșec."
 - ▶ Placebo: deplasarea circulară a țintei (cu 250–3.000 de zile) rupe alinierea cu variabilele, dar păstrează dependența proprie a fiecărei serii; o ipoteză nulă validă pentru $\max_j |t_j|$ dacă ținta este staționară și deplasările depășesc durata dependenței ei
- **Critica**: "Joacă rolul unui recenzent: care dintre aceste variabile semnificative sînt un singur efect numărat de mai multe ori și care sînt anomalii cunoscute, nu noi?"
- **Raportul**: toate cele M teste, toate încercările, inclusiv cele abandonate, DSR și PBO pentru orice strategie construită pe ele

Bibliografie (1/9)

- Ané, T., Geman, H. (2000). Order flow, transaction clock, and normality of asset returns. *Journal of Finance*, 55(5), 2259–2284.
- Ansari, A.F. et al. (2024). Chronos: learning the language of time series. *arXiv:2403.07815*.
- Avramov, D., Cheng, S., Metzker, L. (2023). Machine learning vs. economic restrictions: evidence from stock return predictability. *Management Science*, 69(5), 2587–2619.
- Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- Bailey, D.H., López de Prado, M. (2012). The Sharpe ratio efficient frontier. *Journal of Risk*, 15(2), 3–44.
- Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- Będowska-Sójka, B., Wójcik, P., Pele, D.T. (2026). Early warning systems for cryptocurrency markets: predicting 'zombie' assets using machine learning. *North American Journal of Economics and Finance*, 81, 102543.

Bibliografie (2/9)

- Belloni, A., Chernozhukov, V., Hansen, C. (2014). Inference on treatment effects after selection among high-dimensional controls. *Review of Economic Studies*, 81(2), 608–650.
- Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- Bergmeir, C., Hyndman, R.J., Koo, B. (2018). A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120, 70–83.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Buehler, H., Gonon, L., Teichmann, J., Wood, B. (2019). Deep hedging. *Quantitative Finance*, 19(8), 1271–1291.
- Campbell, J.Y., Thompson, S.B. (2008). Predicting excess stock returns out of sample: can anything beat the historical average? *Review of Financial Studies*, 21(4), 1509–1531.
- Campbell, M., Hoane, A.J., Hsu, F. (2002). Deep Blue. *Artificial Intelligence*, 134(1–2), 57–83.

Bibliografie (3/9)

- ▣ Chen, A.Y., Lopez-Lira, A., Zimmermann, T. (2022). Does peer-reviewed research help predict stock returns? *arXiv:2212.10317*.
- ▣ Chen, L., Pelger, M., Zhu, J. (2024). Deep learning in asset pricing. *Management Science*, 70(2), 714–750.
- ▣ Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *Econometrics Journal*, 21(1), C1–C68.
- ▣ Clark, P.K. (1973). A subordinated stochastic process model with finite variance for speculative prices. *Econometrica*, 41(1), 135–155.
- ▣ Clark, T.E., West, K.D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311.
- ▣ Das, A., Kong, W., Sen, R., Zhou, Y. (2024). A decoder-only foundation model for time-series forecasting. *Proceedings of the 41st International Conference on Machine Learning (ICML)*, PMLR 235.
- ▣ DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. *Biometrics*, 44(3), 837–845.

Bibliografie (4/9)

- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Dixon, M.F., Halperin, I., Bilokon, P. (2020). *Machine Learning in Finance: From Theory to Practice*. Springer.
- Fama, E.F., French, K.R. (2015). A five-factor asset pricing model. *Journal of Financial Economics*, 116(1), 1–22.
- Feng, G., Giglio, S., Xiu, D. (2020). Taming the factor zoo: a test of new factors. *Journal of Finance*, 75(3), 1327–1370.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- Friedman, J.H. (2001). Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- Gu, S., Kelly, B., Xiu, D. (2020). Empirical asset pricing via machine learning. *Review of Financial Studies*, 33(5), 2223–2273.

Bibliografie (5/9)

- Hansen, L.P., Jagannathan, R. (1997). Assessing specification errors in stochastic discount factor models. *Journal of Finance*, 52(2), 557–590.
- Hansen, P.R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). ...and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*. 2nd ed. Springer.
- Hoerl, A.E., Kennard, R.W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.
- Hooker, G., Mentch, L., Zhou, S. (2021). Unrestricted permutation forces extrapolation: variable importance requires at least one more model, or there is no free variable importance. *Statistics and Computing*, 31(6), 82.
- Hosking, J.R.M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176.
- Kelly, B., Malamud, S., Zhou, K. (2024). The virtue of complexity in return prediction. *Journal of Finance*, 79(1), 459–503.

Bibliografie (6/9)

- Kelly, B., Xiu, D. (2023). Financial machine learning. *Foundations and Trends in Finance*, 13(3–4), 205–363.
- Künsch, H.R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.
- Lo, A.W. (2004). The adaptive markets hypothesis. *Journal of Portfolio Management*, 30(5), 15–29.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- López de Prado, M. (2020). *Machine Learning for Asset Managers*. Cambridge University Press.

Bibliografie (7/9)

- Lundberg, S.M., Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- McCracken, M.W., Ng, S. (2016). FRED-MD: a monthly database for macroeconomic research. *Journal of Business & Economic Statistics*, 34(4), 574–589.
- Nagel, S. (2025). Seemingly virtuous complexity in return prediction. NBER Working Paper 34104.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Novy-Marx, R., Velikov, M. (2025). AI-powered (finance) scholarship. NBER Working Paper 33363.
- Opdyke, J.D. (2007). Comparing Sharpe ratios: so where are the p-values? *Journal of Asset Management*, 8(5), 308–336.
- Pesaran, M.H., Timmermann, A. (1992). A simple nonparametric test of predictive performance. *Journal of Business & Economic Statistics*, 10(4), 461–465.
- Politis, D.N., Romano, J.P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, 89(428), 1303–1313.

Bibliografie (8/9)

- Rasul, K. et al. (2023). Lag-Llama: towards foundation models for probabilistic time series forecasting. *arXiv:2310.08278*.
- Robinson, P.M. (1995). Gaussian semiparametric estimation of long range dependence. *Annals of Statistics*, 23(5), 1630–1661.
- Romano, J.P., Wolf, M. (2005). Stepwise multiple testing as formalized data snooping. *Econometrica*, 73(4), 1237–1282.
- Rosenblatt, F. (1958). The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408.
- Shimotsu, K. (2010). Exact local Whittle estimation of fractional integration with unknown mean and time trend. *Econometric Theory*, 26(2), 501–540.
- Shimotsu, K., Phillips, P.C.B. (2005). Exact local Whittle estimation of fractional integration. *Annals of Statistics*, 33(4), 1890–1933.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society B*, 58(1), 267–288.

Bibliografie (9/9)

- Wager, S., Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523), 1228–1242.
- Welch, I., Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *Review of Financial Studies*, 21(4), 1455–1508.
- White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126.
- Woo, G. et al. (2024). Unified training of universal time series forecasting transformers. *arXiv:2402.02592*.
- Zou, H., Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society B*, 67(2), 301–320.
- **Cod și date:** github.com/danpele/MFM/tree/main/Quantlets/Ch_13