



Modelarea piețelor financiare

Capitolul 13: Machine Learning în finanțe



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ CV: Cross-Validation (validare încrucișată)
- ▣ DSR: Deflated Sharpe Ratio (raportul Sharpe deflatat)
- ▣ FFD: Fixed-width window Fractional Differentiation (diferențiere fracționară cu fereastră fixă)
- ▣ FN: False Negative (fals negativ)
- ▣ GBM: Gradient Boosting Machine (model de boosting pe gradient)
- ▣ IS: In-Sample (în eșantion)
- ▣ LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- ▣ ML: Machine Learning (învățare automată)
- ▣ MLP: MultiLayer Perceptron (perceptron multistrat)
- ▣ MSCA: Marie Skłodowska-Curie Actions (programul european Acțiunile Marie Skłodowska-Curie)
- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ OOB: Out-Of-Bag (error) (eroarea pe observațiile din afara eșantionului bootstrap)
- ▣ OOS: Out-Of-Sample (în afara eșantionului)
- ▣ PAC: Probably Approximately Correct (learning) (învățare probabil aproximativ corectă)
- ▣ PBO: Probability of Backtest Overfitting (probabilitatea de supraajustare a backtest-ului)
- ▣ PCR: Principal Component Regression (regresia pe componente principale)
- ▣ PLS: Partial Least Squares (regresia prin cele mai mici pătrate parțiale)
- ▣ PSR: Probabilistic Sharpe Ratio (raportul Sharpe probabilistic)
- ▣ RF: Random Forest (pădure aleatoare)
- ▣ ROC: Receiver Operating Characteristic (curve) (curba caracteristică de operare)
- ▣ SR: Sharpe Ratio (raportul Sharpe)
- ▣ TN: True Negative (adevărat negativ)
- ▣ TP: True Positive (adevărat pozitiv)
- ▣ VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)

Cuprins

Motivație

Fundamente de machine learning

Măsurarea performanței

Date financiare și caracteristici

Etichetare

Validarea încrucișată în finanțe

Studiu de caz: S&P 500

Supraajustarea backtestului

Direcții noi

Bune practici și concluzii

Bibliografie

De ce machine learning în finanțe?

Promisiunea machine learning (ML)

- ▣ Forme funcționale flexibile, neliniare
- ▣ Sute de predictorii candidați ("grădina zoologică" a factorilor, Capitolul 3)
- ▣ Interacțiuni descoperite automat
- ▣ Date alternative: text, imagini, registre de ordine, date on-chain

Problema

- ▣ **Raport semnal-zgomot** foarte mic
- ▣ **Nestaționaritate**: regimuri, rupturi structurale
- ▣ Piețele **se adaptează**: semnalele dispar odată exploatare
- ▣ Puține observații independente
- ▣ Risc uriaș de **supraajustare** (ajustarea zgomotului)

Mesajul-cheie al capitolului

- ▣ În finanțe, partea dificilă nu este estimarea unui model, ci **să nu te păcălești singur**: etichete corecte, validare corectă, backtesturi oneste


Finanțele nu sunt recunoaștere de imagini

	Domeniu ML tipic	Piețe financiare
Semnal/zgomot	ridicat (o pisică e o pisică)	extrem de scăzut
Procesul generator	stabil	se schimbă în timp, reacționează la utilizatori
Volumul eșantionului	milioane de exemple i.i.d.	o singură istorie, dependentă serial
Etichete	date de oameni	trebuie construite
Costul erorii	clasificare greșită	bani reali, efect de levier, faliment
Experimentare	se pot genera date noi	istoria nu poate fi rejucată

Ipoteza piețelor adaptive: Lo (2004)

- Predictibilitatea nu este constantă: apare, este eliminată prin arbitraj și reapare în condiții noi
- Un model care a funcționat ieri este o **ipoteză**, nu o lege (eficiența pieței: Capitolul 2)

Ce este predictibil? Direcție vs. risc



- Autocorelația de ordin k : $\rho_k = \text{Corr}(x_t, x_{t-k})$; banda gri este banda de 95% fără corelație, $\pm 1.96/\sqrt{T}$
- Autocorelațiile randamentelor r_t sunt minuscule (în bandă); cele ale lui $|r_t|$ sunt mari și persistente
- ML are cele mai mari șanse acolo unde există structură: **volatilitate, risc, lichiditate, clasamente transversale**

Dovezi din evaluarea empirică a activelor


Gu, Kelly & Xiu (2020), *Review of Financial Studies*

- ▣ Prognoza **randamentelor lunare ale acțiunilor americane individuale**; comparate: modele liniare, regresii penalizate, regresia pe componente principale (PCR), cele mai mici pătrate parțiale (PLS), random forest, arbori boosted, rețele neuronale
- ▣ R^2 în afara eșantionului, $R_{OOS}^2 = 1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t r_t^2$, este mic (mult sub 1% pe lună)
- ▣ Arborii și rețelele neuronale bat modelele liniare; câștigul vine din **interacțiuni neliniare**; predictorii dominanți: momentum, lichiditate, volatilitate
- ▣ Un R_{OOS}^2 mic poate totuși ordona mii de acțiuni suficient de bine pentru câștiguri mari de portofoliu

Avertisment


- ▣ Pentru o **singură serie de timp** (un indice), eșantionul efectiv este mult mai mic, iar dovezile mult mai slabe — după cum arată studiul de caz S&P 500

Fluxul de lucru ML în finanțe



- Secțiunile 4–6 urmează rândul de sus, secțiunile 7–8 rândul de jos
- **Look-ahead bias**: folosirea unor informații indisponibile la momentul deciziei; **biasul de selecție**: raportarea celei mai bune dintre multe încercări
- **López de Prado (2018)**: majoritatea eșecurilor ML în finanțe țin de proces, nu de algoritm

De la perceptron la Deep Blue



Mark I Perceptron, manualul operatorului
(1960)

Figură: J.C. Hay, A.E. Murray (1960); domeniu
public; Wikimedia Commons



IBM Deep Blue, Computer
History Museum

Foto: Anton Chiang (2011); CC
BY 2.0; Wikimedia Commons

- **Perceptronul:** o regulă de învățare pentru un singur neuron artificial [Rosenblatt \(1958\)](#); Mark I era un dispozitiv construit pentru a recunoaște imagini simple
- 1997: Deep Blue (IBM) îl învinge pe campionul mondial de șah Garry Kasparov [Campbell, Hoane & Hsu \(2002\)](#)
- Deep Blue căuta cu reguli scrise de oameni; ML-ul modern (acest capitol) *învață* regulile din date

Învățarea supervizată: cadrul

Definiție 1 (Învățare supervizată)

- ▣ Date $\{(x_i, y_i)\}_{i=1}^n$: caracteristici (predictori) $x_i \in \mathbb{R}^p$ și țintă (etichetă) y_i
- ▣ Căutăm funcția $\hat{f}$ care prezice bine pe date **noi**, minimizând

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n L(y_i, f(x_i)) + \lambda \Omega(f)$$

- ▣ L : funcția de pierdere; $\Omega(f)$: penalizarea complexității; $\lambda \geq 0$: parametru de ajustare
- ▣ Primul termen măsoară potrivirea, al doilea împiedică modelul să memoreze zgomotul
- ▣ λ nu se estimează din pierderea pe antrenare: se alege prin validare încrucișată

Regresie și clasificare

Regresie

- ▣ Țintă y continuă: randamentul perioadei următoare, volatilitatea
- ▣ Pierdere pătratică: $L = (y - f)^2$
- ▣ Predicție: media condiționată $\mathbb{E}[y \mid x]$

Clasificare

- ▣ Țintă $y \in \{0, 1\}$ sau $\{-1, 0, 1\}$: direcție, eveniment
- ▣ Log-loss: $L = -y \log p - (1 - y) \log(1 - p)$,
 $p = \hat{P}(y = 1 \mid x)$
- ▣ Predicție: probabilitatea clasei p , clasa
 $= 1\{p > 0.5\}$

- ▣ Capitolul folosește clasificarea: “va fi prețul mai mare peste 5 zile?”
- ▣ Regresia logistică (logit) modelează $p = 1/(1 + e^{-x^\top \beta})$ — reperul liniar

În eșantion, în afara eșantionului, validare încrucișată

- ▣ Eroarea **în eșantion (IS)**: calculată pe datele folosite la estimare — mereu optimistă
- ▣ Eroarea **în afara eșantionului (OOS)**: calculată pe date nefolosite la estimare — cea care contează
- ▣ **Validarea încrucișată (CV)** cu K pliuri: împărțim datele în K blocuri; estimăm pe $K - 1$, evaluăm pe cel rămas; repetăm de K ori și facem media
- ▣ CV servește la alegerea parametrilor de ajustare (λ , adâncimea arborelui) și la compararea modelelor
- ▣ Un **set de test** final, neatins în selecția modelului, dă estimarea onestă

Avertisment specific finanțelor

- ▣ CV standard cu K pliuri presupune observații i.i.d. — Secțiunea 6 arată de ce eșuează la serii de timp

Compromisul bias-varianță

Propoziție 1 (Descompunerea erorii de predicție așteptate)

□ Pentru $y = f(x) + \varepsilon$, $\mathbb{E}[\varepsilon] = 0$, $\text{Var}(\varepsilon) = \sigma^2$:


$$\mathbb{E}[(y - \hat{f}(x))^2] = \underbrace{(\mathbb{E}[\hat{f}(x)] - f(x))^2}_{\text{bias}^2} + \underbrace{\text{Var}(\hat{f}(x))}_{\text{varianță}} + \underbrace{\sigma^2}_{\text{ireductibil}}$$

- **Bias**: eroarea unui model prea simplu (ratează structura)
- **Varianță**: eroarea unui model care reacționează la eșantionul particular (ajustează zgomotul)
- Zgomotul **ireductibil** σ^2 : nu poate fi eliminat de niciun model

Bias–varianță în finanțe

- În finanțe, zgomotul σ^2 domină eroarea totală: cea mai mare parte a variației randamentelor este imprevizibilă
- Modelele complexe reduc biasul, dar umflă varianța $\Rightarrow$ **ajustează zgomotul**
- Cu semnal slab, o reducere mică a biasului merită rar o creștere mare a varianței
- Instrumente care controlează varianța:
 - ▶ regularizarea (penalizări $\lambda \Omega(f)$)
 - ▶ ansamblurile (media multor modele)
 - ▶ validarea corectă, fără scurgeri de informație

Bias-varianță în practică: adâncimea arborelui



- S&P 500, direcția pe 5 zile; acuratețea = proporția zilelor clasificate corect
- Acuratețea pe antrenare crește la $\approx 87\%$ cu adâncimea; acuratețea CV cu purjare **scade** spre 50%
- Random forest se degradează mai lent, dar nu bate niciodată reperul "mereu în sus" (linia punctată)

Regresie penalizată: Ridge, LASSO, Elastic Net

Definiție 2 (Cele mai mici pătrate penalizate)

- ▣ Obiectiv: $\hat{\beta} = \arg \min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda [\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2]$
 - ▣ Norme: $\|\beta\|_1 = \sum_j |\beta_j|$, $\|\beta\|_2^2 = \sum_j \beta_j^2$
 - ▣ $\alpha = 0$: **Ridge**, Hoerl & Kennard (1970) — micșorează, păstrează toți predictorii
 - ▣ $\alpha = 1$: **LASSO**, Tibshirani (1996) — micșorează și anulează exact unii coeficienți
 - ▣ $0 < \alpha < 1$: **Elastic Net**, Zou & Hastie (2005) — gestionează grupuri de predictorii corelați
-
- ▣ La clasificare, eroarea pătratică este înlocuită cu log-loss (logit penalizat)

De ce ajută micșorarea și cum se ajustează


De ce ajută în finanțe

- ▣ Mulți predictorii corelați (momentum pe mai multe orizonturi, mai multe măsuri de volatilitate)
- ▣ Cele mai mici pătrate (OLS) devin instabile: coeficienți mari, care se compensează
- ▣ Micșorarea schimbă puțin bias pentru mult mai puțină varianță

Ajustare

- ▣ λ ales prin validare încrucișată (cu purjare!)
- ▣ Standardizăm întâi caracteristicile (medie 0, abatere standard 1): penalizarea nu este invariantă la scară
- ▣ Parametrii de scalare se estimează doar pe pliurile de antrenare

Drumul de regularizare LASSO




- Regresie logistică penalizată L_1 pentru direcția pe 5 zile a S&P 500, 14 caracteristici standardizate
- Penalizare puternică: toți coeficienții sunt zero; prima caracteristică intrată este prețul FFD
- Penalizare slabă: caracteristicile de volatilitate (vol_20, vol_60, vol_ratio) au cei mai mari coeficienți
- Toți coeficienții sunt mici în valoare absolută: semnal slab, în acord cu piețe aproape eficiente

Arbori de decizie

Definiție 3 (Arbore de clasificare)

- Partiționare binară recursivă a spațiului caracteristicilor în regiuni $R_1, \dots, R_M$
- Predicție = clasa majoritară (sau media) din fiecare regiune: $\hat{f}(x) = \sum_{m=1}^M c_m 1\{x \in R_m\}$
- Împărțirile sunt alese lacom, minimizând impuritatea, de ex. Gini $G = \sum_k p_k(1 - p_k)$, p_k = ponderea clasei în nod



- Un arbore ilustrativ (neestimat)

- + Neliniarități și interacțiuni, invarianță la transformări monotone, ușor de explicat
- Varianță mare: o mică schimbare a datelor dă un arbore foarte diferit $\Rightarrow$ media multor arbori (pădure) sau arbori mici adăugați secvențial (boosting)

Random forest

Random forest (RF): Breiman (2001)

- ▣ **Bagging** (bootstrap aggregating): creștem B arbori, fiecare pe un eșantion bootstrap al datelor
- ▣ La fiecare împărțire se ia în calcul doar o submulțime aleatoare de $m \approx \sqrt{p}$ caracteristici $\Rightarrow$ arbori decorelați
- ▣ Predicția pădurii = media arborilor: $\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x)$
- ▣ Media reduce varianța; observațiile out-of-bag (OOB) dau o estimare internă a erorii

Avertisment pentru finanțe

- ▣ Bootstrapul pe etichete **suprapuse** nu este i.i.d. $\Rightarrow$ eroarea OOB este optimistă



Exemplu rezolvat: cum face pădurea media arborilor

- ▣ Random forest-ul din studiul de caz (400 de arbori, dimensiune minimă a frunzei 100), antrenat pe primele patru pliuri purjate
- ▣ Predicția pentru ultima observație (11 septembrie 2026): $P(\text{creștere în 5 zile})$ dată de fiecare arbore
 - ▶ arborii individuali variază între 0.31 și 0.88 (abatere standard 0.11)
 - ▶ 81.5% dintre arbori votează “sus” ($p > 0.5$)
 - ▶ probabilitatea pădurii = media celor 400 de arbori = 0.608
- ▣ Arborii individuali nu cad deloc de acord; media este mult mai stabilă
- ▣ Stabilitate nu înseamnă acuratețe: pădurea tot nu bate “mereu în sus” (Secțiunea 7)

Gradient boosting

Gradient boosting machine (GBM): Friedman (2001)

- ▣ Model aditiv construit secvențial:


$$F_m(x) = F_{m-1}(x) + \eta h_m(x), \quad m = 1, \dots, M$$

- ▣ h_m : un arbore mic ajustat pe gradientul negativ al pierderii (erorile curente)
 - ▣ $\eta \in (0, 1]$: rata de învățare; împreună cu adâncimea și numărul de arbori M controlează complexitatea
 - ▣ XGBoost, LightGBM, CatBoost: implementări rapide, de vârf pe date tabelare
-
- ▣ RF reduce varianța prin mediere; GBM reduce biasul corectând erorile pas cu pas

Rețele neuronale

Definiție 4 (Perceptron multistrat (MLP), L straturi)

- ▣ $h^{(0)} = x, \quad h^{(\ell)} = g(W^{(\ell)}h^{(\ell-1)} + b^{(\ell)})$
 - ▣ ieșire: $\hat{y} = \sigma(w^\top h^{(L)} + b)$
 - ▣ g : unitate liniară rectificată (ReLU), $g(z) = \max(0, z)$;
 $\sigma(z) = 1/(1 + e^{-z})$
 - ▣ Ponderile se învață prin coborâre stohastică pe gradient
-
- ▣ Regularizare: weight decay (penalizare L_2), dropout, **oprire timpurie** (ne oprim când pierderea pe validare nu mai scade)
 - ▣ Rețelele puțin adânci (1–3 straturi) merg cel mai bine pe randamente tabelare (Gu, Kelly & Xiu (2020)); adâncimea contează la text și registre de ordine (Capitolele 14–15)



Recapitulare: fundamente de machine learning

- ▣ Învățare supervizată = pierdere + penalizarea complexității, ajustată prin validare încrucișată
- ▣ Eroarea în afara eșantionului este singura relevantă
- ▣ Finanțele sunt dominate de zgomot: controlul varianței contează mai mult decât flexibilitatea
- ▣ Trusa de unelte: logit penalizat (Ridge / LASSO / Elastic Net), arbori, random forest, gradient boosting, MLP
- ▣ Urmează: cum **măsurăm** dacă un clasificator este bun

Matricea de confuzie și acuratețea

	Prezis sus	Prezis jos
Real sus	TP	FN
Real jos	FP	TN

- ▣ TP: adevărat pozitive; FN: fals negative
- ▣ FP: fals pozitive; TN: adevărat negative
- ▣ $n = TP + FN + FP + TN$

Definiție 5 (Acuratețe)

- ▣ Proporția predicțiilor corecte: $\text{Acuratețe} = \frac{TP + TN}{n}$
- ▣ Cu clase dezechilibrate, acuratețea induce în eroare: a prezice mereu clasa majoritară obține deja ponderea ei

Precizie, recall și F1

Definiție 6 (Precizie, recall, scor F1)

▣ **Precizia:** proporția zilelor prezise “sus” care chiar au fost în creștere, $\text{Prec} = \frac{TP}{TP + FP}$

▣ **Recall** (rata de detecție): proporția zilelor reale “sus” detectate, $\text{Rec} = \frac{TP}{TP + FN}$

▣ **Scorul F1:** media armonică, $F_1 = \frac{2 \text{Prec} \cdot \text{Rec}}{\text{Prec} + \text{Rec}}$

- ▣ În tranzacționare, precizia = proporția tranzacțiilor luate care aduc câștig
- ▣ Recall = proporția oportunităților bune pe care chiar le iei
- ▣ Meta-etichetarea (Secțiunea 5) schimbă recall pe precizie

Exemplu rezolvat: matricea de confuzie a modelului logit

	Prezis sus	Prezis jos
Real sus	3,572	68
Real jos	2,591	38

- Logit penalizat L2, studiul de caz S&P 500, predicții în afara pliului din CV cu purjare în 5 pliuri, $n = 6,269$

- Acuratețe = $(3,572 + 38)/6,269 = 57.6\%$
- Precizie = $3,572/(3,572 + 2,591) = 0.580$
- Recall = $3,572/(3,572 + 68) = 0.981$
- $F_1 = 0.729$
- Modelul prezice "sus" în 98.3% din zile: practic a învățat "mereu în sus"

Curba ROC și AUC

Definiție 7 (Curba ROC și AUC)

- Pentru un prag c , clasificăm “sus” dacă $\hat{p} > c$; rata adevărat pozitivelor $TPR(c) = TP / (TP + FN)$, rata fals pozitivelor $FPR(c) = FP / (FP + TN)$
- **Curba ROC** reprezintă $TPR(c)$ în funcție de $FPR(c)$ pentru toate pragurile $c \in [0, 1]$
- **AUC** = aria de sub curba ROC = $P(\hat{p}_{\text{poz}} > \hat{p}_{\text{neg}})$: probabilitatea ca o zi aleatoare “sus” să primească un scor mai mare decât o zi aleatoare “jos”
- $AUC = 0.5$: nicio capacitate de ordonare (aruncarea monedei); $AUC = 1$: ordonare perfectă
- AUC nu depinde de prag sau de echilibrul claselor — se raportează alături de acuratețe

Comparați mereu cu un reper naiv

- ▣ **Reperul “mereu în sus”**: prezicem clasa majoritară în fiecare zi
- ▣ Acuratețea lui este proporția etichetelor “sus”: $\bar{y} = \frac{1}{n} \sum_i y_i$
- ▣ S&P 500, direcția pe 5 zile, 2001–2026: $\bar{y} = 58.1\%$ — un model “cu acuratețe de 57%” este *mai slab* decât a nu face nimic
- ▣ Alte repere: direcția de ieri, o regulă de medii mobile, buy-and-hold pentru tranzacționare
- ▣ Un model are valoare doar dacă bate reperul **în afara eșantionului**, după costuri

De la predicții la o strategie de tranzacționare

Definiție 8 (Poziții, rulaj, costuri, expunere)

- Poziția $w_t \in \{0, 1\}$: long pe indice (1) sau în numerar (0), decisă cu informații până la t
- Randamentul strategiei: $r_{t+1}^s = w_t r_{t+1} - c |w_t - w_{t-1}|$
- Rulajul (turnover) $|w_t - w_{t-1}|$: fracțiunea portofoliului tranzacționată; costul c în puncte de bază (5 bp = 0.05% pe unitatea tranzacționată)
- Expunerea: proporția medie a timpului investit, $\bar{w} = \frac{1}{T} \sum_t w_t$
- Buy-and-hold: $w_t = 1$ pentru orice t (expunere 100%, fără rulaj)

Raportul Sharpe

Definiție 9 (Raportul Sharpe (SR))

- SR pe perioadă pentru randamentele $r_1, \dots, r_T$ (în exces față de rata fără risc, aici luată 0):

$$\widehat{SR} = \frac{\bar{r}}{\hat{\sigma}}, \quad \bar{r} = \frac{1}{T} \sum_t r_t, \quad \hat{\sigma}^2 = \frac{1}{T-1} \sum_t (r_t - \bar{r})^2$$

- SR **anualizat**: $\widehat{SR}_{an} = \sqrt{q} \widehat{SR}$, cu $q = 252$ zile de tranzacționare (acțiuni) sau $q = 365$ zile (cripto)
- Randament mediu pe unitatea de risc; fără unitate de măsură, deci comparabil între strategii cu levier diferit
- Regula $\sqrt{q}$ presupune randamente i.i.d.: o aproximare

Recapitulare: măsurarea performanței

- ▣ Acuratețea singură induce în eroare la clase dezechilibrate: raportați mereu reperul
- ▣ Precizia și recall separă “cât de des ai dreptate când acționezi” de “câte oportunități ieși”
- ▣ AUC măsoară capacitatea de ordonare; 0.5 = fără abilitate
- ▣ Evaluarea tranzacționării: raportul Sharpe după costuri, comparat cu buy-and-hold
- ▣ Urmează: cum construim caracteristici și etichete fără scurgeri de informație

Eșantionarea datelor financiare: bare

Bare de timp și de tranzacții

- O **bară** = un rând (deschidere, maxim, minim, închidere, volum) care rezumă un interval de eșantionare
- Bare de timp: la interval fix (1 minut, 1 zi); supraeșantionează perioadele liniștite; randamente cu cozi groase
- Bare de tranzacții (tick): o bară la fiecare N tranzacții

Bare de volum, valoare și informaționale

- O bară la fiecare V acțiuni sau $\$D$ tranzacționați: eșantionare după **sosirea informației**
- Randamente mai apropiate de extrageri i.i.d. din distribuția Normală: [Clark \(1973\)](#); [Ané & Geman \(2000\)](#)
- Bare de dezechilibru / de serii: eșantionăm când fluxul de ordine devine unilateral

- Capitolul folosește bare zilnice de timp; date tick (exchange-uri crypto) în Capitolele 10 și 16

Staționaritatea și testul ADF

Definiție 10 (Staționaritate slabă)

- $\{X_t\}$ este (slab) staționar dacă media, varianța și autocovarianțele nu se schimbă în timp

Definiție 11 (Testul Dickey–Fuller augmentat (ADF))

- Regresia: $\Delta X_t = \alpha + \rho X_{t-1} + \sum_{j=1}^k \phi_j \Delta X_{t-j} + \varepsilon_t$
- $H_0: \rho = 0$ (rădăcină unitară, nestăționar) vs. $H_1: \rho < 0$ (staționar)
- Statistica ADF = raportul t al lui $\hat{\rho}$; respingem H_0 dacă este sub valoarea critică (≈ -2.86 la 5%)
- Logaritmiile prețurilor de regulă nu resping rădăcina unitară; randamentele logaritmice o resping puternic

Dilema staționaritate vs. memorie

- ▣ Modelele ML au nevoie de intrări **staționare**: relația învățată în trecut trebuie să rămână valabilă
- ▣ Prețurile sunt nestaționare $\Rightarrow$ practicienii folosesc randamente, $\Delta \log P_t$ (diferențiere întreagă, $d = 1$)
- ▣ Dar randamentele **șterg memoria**: se pierde nivelul prețului în raport cu istoria sa

$d = 0$ (prețuri)

- ▣ memorie completă
- ▣ nestaționar

$0 < d < 1$ (fracționar)

- ▣ staționar
- ▣ **memorie păstrată**

$d = 1$ (randamente)

- ▣ staționar
- ▣ memorie ștearsă

- ▣ Ideea (Hosking (1981); López de Prado (2018)): găsim cel mai **mic** d care face seria staționară

Diferențierea fracționară

Definiție 12 (Operatorul de diferențiere fracționară)

- Cu operatorul de întârziere $BX_t = X_{t-1}$ și un ordin real d :

$$(1 - B)^d = \sum_{k=0}^{\infty} \binom{d}{k} (-B)^k, \quad \tilde{X}_t = \sum_{k=0}^{\infty} w_k X_{t-k}$$

- Ponderile se obțin recursiv:

$$w_0 = 1, \quad w_k = -w_{k-1} \frac{d - k + 1}{k}$$

- $d = 1$: $w = (1, -1, 0, 0, \dots)$ — randamentele obișnuite
- $0 < d < 1$: ponderile scad lent (hiperbolic) $\Rightarrow$ memoria lungă se păstrează


Fereastra fixă

Definiție 13 (Diferențiere fracționară cu fereastră fixă (FFD))


- ▣ Trunchiem ponderile: păstrăm $w_0, \dots, w_K$ cu $|w_k| \geq \tau$ (de ex. $\tau = 10^{-4}$), renunțăm la restul
- ▣ $\tilde{X}_t = \sum_{k=0}^K w_k X_{t-k}$ pentru orice $t > K$

- ▣ Fiecare $\tilde{X}_t$ folosește același număr de întârzieri $\Rightarrow$ fără derivă din cauza unei ferestre crescătoare
- ▣ Intră doar valori trecute $\Rightarrow$ fără look-ahead
- ▣ Cu cât d este mai mic, cu atât trebuie mai multe întârzieri până la $|w_k| < \tau$
- ▣ Primele K observații se pierd

Ponderile diferențierii fracționare




- Pentru $d = 1$ contează doar prima întârziere; pentru d mic ponderile întârzierilor îndepărtate rămân nenule
- Toate ponderile după w_0 sunt negative: $\tilde{X}_t$ compară nivelul de azi cu o istorie ponderată

Găsirea lui d minim: S&P 500

- Statistica ADF a logaritmului prețului FFD pentru $d \in [0, 1]$ (S&P 500, 2000–2026); linia roșie: valoarea critică de 5%
- Linia verde: corelația Pearson $\text{Corr}(\tilde{X}_t, \log P_t)$ dintre seria FFD și logaritmul prețului original
- Staționaritatea se atinge la $d^* = 0.25$, unde corelația este încă 0.98; randamentele ($d = 1$) păstrează o corelație ≈ 0

Prețuri, serie FFD și randamente



- **Sus:** logaritmul prețului — cu trend, nestăionar
- **Mijloc:** FFD cu $d^* = 0.25$ — staționar, dar crahurile din 2008 și 2020 rămân vizibile ca salturi de nivel
- **Jos:** randamentele logaritmice — se văd doar grupările de volatilitate
- Seria FFD intră în studiul de caz drept caracteristica `ffd_price`

Recapitulare: date financiare și caracteristici

- ▣ Eșantionarea după activitate (bare de volum, de valoare) dă randamente mai bine comportate decât timpul de ceas
- ▣ Caracteristicile trebuie să fie staționare, dar diferențierea întreagă aruncă memoria
- ▣ FFD păstrează memoria: $d^* = 0.25$ este suficient pentru S&P 500 (corelație 0.98 cu prețul)
- ▣ Orice transformare folosește doar date trecute și se estimează doar pe pliurile de antrenare
- ▣ Urmează: cum transformăm prețurile în etichete

Eticheta cu orizont fix și problemele ei

Definiție 14 (Etichetă cu orizont fix)

- Randamentul logaritm pe h perioade $r_{t,t+h} = \log P_{t+h} - \log P_t$ și pragul $\tau \geq 0$: $y_t = +1$ dacă $r_{t,t+h} > \tau$, -1 dacă $r_{t,t+h} < -\tau$, 0 altfel
- **Ponderile etichetelor**: fracțiunea observațiilor din fiecare clasă, de ex. $\frac{1}{n} \sum_t 1\{y_t = +1\}$

Probleme

- Un τ constant ignoră volatilitatea variabilă: în perioade calme aproape toate etichetele sunt 0 , în crize aproape niciuna
- Ignoră **traectoria**: o poziție reală ar fi fost închisă prin stop-loss cu mult înainte de $t + h$
- Clase dezechilibrate: S&P 500, $h = 10$ zile, $\tau = 0$: 60.5% sus vs. 39.5% jos

Metoda celor trei bariere

Definiție 15 (Etichetă cu trei bariere, López de Prado (2018))


- La momentul evenimentului t_0 , cu volatilitatea zilnică σ_{t_0} și orizontul h :
 - ▶ bariera superioară (profit): $\log P_t - \log P_{t_0} \geq \pi_u \sigma_{t_0} \sqrt{h}$
 - ▶ bariera inferioară (stop-loss): $\log P_t - \log P_{t_0} \leq -\pi_l \sigma_{t_0} \sqrt{h}$
 - ▶ bariera verticală (limita de timp): $t = t_0 + h$
- Eticheta = **prima barieră atinsă** la momentul t_1 : +1 sus, -1 jos; la bariera verticală fie $\text{sign}(r_{t_0, t_1})$, fie 0
- π_u, π_l : lățimile barierelor în unități de $\sigma_{t_0} \sqrt{h}$

Estimarea volatilității și proprietățile barierelor

Definiție 16 (Volatilitate EWMA)


- ▣ Medie mobilă ponderată exponențial (EWMA) a abaterilor pătratice ale randamentelor logaritmice zilnice, cu span 50 (factor $\lambda = 1 - 2/51$): zilele recente cântăresc mai mult
- ▣ Barierele se scalează cu volatilitatea $\Rightarrow$ etichete comparabile în regimuri calme și turbulente
- ▣ Imită modul în care un trader își gestionează poziția: take-profit, stop-loss, perioadă maximă de deținere
- ▣ Fiecare etichetă are un **interval** $[t_0, t_1]$ — esențial pentru validarea încrucișată (Secțiunea 6)

Trei bariere: S&P 500 în 2022




- Cinci evenimente în piața descendentă din 2022, $\pi_u = \pi_l = 1$, $h = 15$ zile
- Ianuarie: stop-loss atins (-1); martie: profit (+1); celelalte se termină la bariera verticală

Distribuția etichetelor: orizont fix vs. trei bariere



- S&P 500, 2001–2026, $h = 10$: orizontul fix dă 60.5% sus / 39.5% jos
- Trei bariere ($\pm 1\sigma\sqrt{h}$): 19.6% sus, 21.3% jos, 59.0% expirare — etichete direcționale echilibrate
- Panoul din dreapta: barierele orizontale sunt de obicei atinse după 1–2 săptămâni

Meta-etichetarea



- Meta-eticheta: $y_t^{meta} = 1$ dacă semnalul primar a fost profitabil (barieră atinsă în direcția lui), 0 altfel
- Modelul secundar dă $\hat{p} = P(y_t^{meta} = 1 \mid x_t)$

De ce funcționează meta-etichetarea

- ▣ ML învață **când să aibă încredere** în modelul primar, nu direcția înșăși
- ▣ Modelul primar este reglat pentru recall ridicat (prinde majoritatea oportunităților)
- ▣ Modelul meta filtrează fals pozitivele $\Rightarrow$ precizie mai mare și un scor F1 mai bun când recall nu scade prea mult
- ▣ Păstrează un nucleu interpretabil, motivat economic; limitează supraajustarea direcției
- ▣ Seminarul o aplică unei încrucișări de medii mobile pe Bitcoin

Etichete suprapuse și unicitatea eșantioanelor

- Eticheta i acoperă $[t_{0,i}, t_{1,i}]$; etichetele consecutive împart randamente $\Rightarrow$ eșantioanele **nu sunt i.i.d.**
- Etichete concurente la t : $c_t = \sum_i 1\{t_{0,i} \leq t \leq t_{1,i}\}$; unicitatea medie $\bar{u}_i = \frac{1}{t_{1,i} - t_{0,i} + 1} \sum_{t=t_{0,i}}^{t_{1,i}} \frac{1}{c_t}$
- $\bar{u}_i = 1$: niciun randament comun; $\bar{u}_i = 1/5$: în medie cinci etichete se suprapun

Consecințe

- Mărimea efectivă a eșantionului $\approx \sum_i \bar{u}_i \ll n$
- Bagging extrage aproape-duplicate; scorurile CV sunt prea optimiste

Remedii

- Ponderare cu $\bar{u}_i$ (și cu $|r|$)
- Bootstrap secvențial; în RF `max_samples` $\approx \bar{u}$

Recapitulare: etichetare

- Etichetele cu orizont fix ignoră volatilitatea și traiectoria prețului și sunt dezechilibrate (60.5% sus)
- Etichetele cu trei bariere se scalează cu volatilitatea și imită gestionarea reală a pozițiilor
- Meta-etichetarea lasă ML să decidă *dacă* acționăm pe un semnal economic
- Fiecare etichetă are un interval; intervalele suprapuse micșorează eșantionul efectiv
- Urmează: o validare care respectă aceste intervale

Scurgerea de informație: de ce eșuează K-Fold standard

Definiție 17 (Scurgere de informație (leakage))


- Setul de antrenare conține informații prezente și în setul de test, așa că scorul de test nu mai măsoară performanța pe date cu adevărat noi
- Caracteristici corelate serial ($x_t \approx x_{t+1}$) și etichete suprapuse ($y_t \approx y_{t+1}$): un K -fold amestecat pune zile **aproape identice** de ambele părți
- Un model flexibil (RF, GBM) memorează vecinul $\Rightarrow$ scor “în afara eșantionului” excelent; ajustarea pe un CV cu scurgeri alege modelul **cel mai supraajustat**
- Alte surse: transformări estimate pe tot eșantionul (scalare, analiza componentelor principale, alegerea lui d^*), biasul de supraviețuire, revizuirile ale datelor, marcaje de timp greșite

Purjare și embargo

Definiție 18 (K-fold cu purjare și embargo, López de Prado (2018))

- Pliurile sunt blocuri **contigue** în timp (fără amestecare)
 - **Purjarea**: eliminăm din antrenare orice observație al cărei interval de etichetă $[t_{0,i}, t_{1,i}]$ se suprapune cu perioada de test
 - **Embargoul**: eliminăm și o mică fracțiune (de ex. 1%) de observații imediat după blocul de test, pentru că caracteristicile privesc înapoi în timp
-
- Purjarea tratează suprapunerea etichetelor; embargoul tratează memoria caracteristicilor

K-fold cu purjare: schema



- Roșu: blocul de test; gri: observațiile purjate imediat înainte; chihlimbar: embargoul imediat după
- Setul de antrenare se micșorează puțin — prețul unei estimări oneste


Exemplu rezolvat: purjare cu 10 observații

- Observații $t = 0, \dots, 9$; eticheta lui t se termină la $t + 2$ (plafonat la 9)
- 5 pliuri contigue de câte 2; embargo = 1 observație

Test	Eliminate	Antrenare
0, 1	2, 3	4–9
2, 3	0, 1, 4, 5	6–9
4, 5	2, 3, 6, 7	0, 1, 8, 9
6, 7	4, 5, 8, 9	0–3
8, 9	6, 7	0–5

- Test $\{4, 5\}$: etichetele lui 2 și 3 se termină la 4 și 5 $\Rightarrow$ purjate; 6 este embargoul; 7 începe când se termină ultima etichetă de test $\Rightarrow$ purjată
- Cu etichete suprapuse, până la 4 din 10 observații ies din antrenare

Experiment de scurgere: nimic de prezis



- Preț = mers aleator pur; eticheta = semnul randamentului pe următoarele 20 de zile
- 5 caracteristici = medii mobile ale unui zgomot independent
- Acuratețea reală este 50% prin construcție
- Clasificator random forest, 5 pliuri

 MFM_ch13_purged_cv

Experiment de scurgere: rezultate

- ▣ **K-fold amestecat: 69.4%** acuratețe — scurgere pură
- ▣ K-fold neamestecat (contiguu): 50.0%
- ▣ K-fold cu purjare + embargo: 49.7%

Lecția

- ▣ O rată de succes de 69% pe date fără niciun semnal
- ▣ Nu amestecați niciodată seriile de timp în validarea încrucișată
- ▣ Un rezultat prea bun ca să fie adevărat este de obicei o scurgere

Walk-forward și CV combinatorică cu purjare

Walk-forward (WF)

- ▣ Antrenare pe $[0, T_k]$, test pe $(T_k, T_{k+1}]$, apoi avansăm
- ▣ Imită implementarea în timp real; fără date viitoare în antrenare
- ▣ Dar o **singură traiectorie**: varianță mare, ușor de supraajustat prin încercări repetate

CV combinatorică cu purjare (CPCV)

- ▣ N grupuri; test pe toate cele $\binom{N}{k}$ combinații de k grupuri, cu purjare și embargo
- ▣ $\varphi = \frac{k}{N} \binom{N}{k}$ traiectorii de backtest; de ex. $N = 6$, $k = 2$: 15 împărțiri, 5 traiectorii
- ▣ O **distribuție** de rapoarte Sharpe în loc de un singur număr

- ▣ Regulă practică: K-fold cu purjare / CPCV pentru selecția modelului; WF pentru evaluarea finală, realistă

Recapitulare: validarea încrucișată în finanțe

- ▣ Scurgerea provine din etichete suprapuse și caracteristici corelate serial
- ▣ K-fold amestecat raportează 69.4% pe zgomot pur; K-fold cu purjare raportează 49.7%
- ▣ Purjarea elimină etichetele suprapuse; embargoul elimină memoria caracteristicilor după blocul de test
- ▣ Walk-forward = o traiectorie realistă; CPCV = multe traiectorii, o distribuție de rezultate
- ▣ Urmează: toate acestea aplicate pe S&P 500

Studiu de caz: date, țintă și validare

- ▣ Indicele S&P 500 și VIX, zilnic, 2001–2026: 6,269 de observații
- ▣ Ținta: $y_t = 1\{\log P_{t+5} - \log P_t > 0\}$ — direcția pe 5 zile
- ▣ Intervalul etichetei $[t, t + 5]$ este folosit la purjare
- ▣ CV cu purjare în 5 pliuri, embargo 1%
- ▣ Metrici: acuratețe și ROC AUC, comparate cu reperul “mereu în sus”



Studiu de caz: 14 caracteristici

- ▣ **Momentum:** $\log P_t - \log P_{t-h}$, $h \in \{1, 5, 20, 60, 120\}$ zile
- ▣ **Volatilitate realizată:** abaterea standard anualizată a randamentelor logaritmice zilnice pe 20 și 60 de zile și raportul lor
- ▣ **Distanța față de media mobilă:** $\log P_t$ minus media lui $\log P$ pe ultimele 50 sau 200 de zile
- ▣ **RSI(14):** $100 - 100/(1 + RS)$, RS = raportul dintre câștigurile medii și pierderile medii pe 14 zile (netezite)
- ▣ **VIX:** nivelul logaritmice și variația pe 5 zile a indicelui de volatilitate implicită
- ▣ Logaritmul prețului **FFD** cu $d^* = 0.25$
- ▣ Toate caracteristicile folosesc doar informații până în ziua t

Studiu de caz: patru modele

- ▣ **Logit:** regresie logistică penalizată L2 (Ridge) pe caracteristici standardizate
- ▣ **RF:** 400 de arbori, dimensiune minimă a frunzei 100
- ▣ **GBM:** pe histograme, adâncime 3, rată de învățare 0.03, 200 de arbori
- ▣ **MLP:** două straturi ascunse (32 și 16 unități), oprire timpurie
- ▣ Setări deliberat conservatoare: frunze mari și arbori puțin adânci limitează varianța

Compararea modelelor



	Logit	RF	GBM	MLP
Acuratețe	57.6%	56.5%	54.3%	56.4%
AUC	0.478	0.503	0.493	0.515

☐ Reperul “mereu în sus”: **58.1%**

☐ Niciun model nu îl bate

Interpretarea rezultatelor

Concluzie onestă

- ▣ **Niciun model nu bate reperul naiv “mereu în sus”**; toate valorile AUC sunt apropiate de 0.5
- ▣ Acuratețea induce în eroare la clase dezechilibrate: 57.6% arată bine, dar este *sub* 58.1%
- ▣ În acord cu eficiența (în formă slabă) a unui indice foarte lichid (Capitolul 2)

Unde să căutăm în schimb

- ▣ Secțiuni transversale cu multe active (Gu, Kelly & Xiu (2020)); ținte de volatilitate și risc
- ▣ Date alternative: text (Capitolul 15); piețe mai puțin eficiente: crypto (Capitolul 16)
- ▣ Meta-etichetarea unor semnale motivate economic

Importanța caracteristicilor: MDI și MDA

Scăderea medie a impurității (MDI)

- ▣ Reducerea medie a impurității Gini din toate împărțirile pe o caracteristică, pe arborii unei păduri
- ▣ În eșantion, doar pentru arbori
- ▣ Favorizează caracteristicile continue, cu multe valori distincte

Scăderea medie a acurateței (MDA)

- ▣ Importanța prin permutare: scăderea unui scor OOS (aici AUC) când valorile unei caracteristici sunt amestecate aleator
- ▣ Orice model; în afara eșantionului
- ▣ Poate fi negativă: caracteristica dăunează

- ▣ MDI răspunde la “ce a folosit modelul?”; MDA răspunde la “ce ajută pe date noi?”

Importanța caracteristicilor: SHAP

Definiție 19 (Valoarea Shapley a caracteristicii j (SHAP, Lundberg & Lee (2017)))


- ▣ Contribuția marginală medie a lui j peste toate coalițiile $S \subseteq \{1, \dots, p\} \setminus \{j\}$:

$$\phi_j = \sum_S \frac{|S|! (p - |S| - 1)!}{p!} [v(S \cup \{j\}) - v(S)], \quad \hat{f}(x) = \phi_0 + \sum_j \phi_j$$

- ▣ $v(S)$: predicția modelului folosind doar caracteristicile din S
- ▣ Atribuire aditivă a fiecărei predicții; media lui $|\phi_j|$ pe observații = importanța globală
- ▣ **Efecte de substituție**: caracteristicile corelate își împart (și diluează) importanța — grupați-le întâi

 Shapley Values

Importanța caracteristicilor în studiul de caz



- ▣ Trei panouri: MDI (în eșantion), MDA (ΔAUC în afara eșantionului), media $|SHAP|$ (în afara eșantionului)
- ▣ Același random forest și aceleași caracteristici ca în compararea modelelor


Importanța caracteristicilor: interpretare

- ▣ **MDI** pune pe primele locuri volatilitatea: vol_60, vol_ratio, vol_20
- ▣ **MDA** și **SHAP** indică mom_20 și dist_ma200
- ▣ vol_20: MDI ridicat, dar MDA **negativ** — modelul îl folosește ca să ajusteze zgomotul
- ▣ Importanțele sunt minuscule ($\Delta AUC < 0.01$), în acord cu compararea modelelor
- ▣ **Backtestul nu este un instrument de cercetare**, analiza importanței este: [López de Prado \(2018\)](#)

Backtest walk-forward: construcție

- ▣ Model: GBM reestimat în fiecare ianuarie pe toate datele trecute, cu purjarea etichetelor care se suprapun cu anul de test
- ▣ Regula: long pe S&P 500 dacă $\hat{p} > 0.5$, altfel numerar ($w_t \in \{0, 1\}$)
- ▣ Costuri: 5 bp pe unitatea de rulaj
- ▣ Perioada în afara eșantionului: 2010–2026, o reestimare pe an
- ▣ Reper: buy-and-hold ($w_t = 1$)

Backtest walk-forward: rezultate



- 2010–2026: Sharpe strategie **0.49** vs. buy-and-hold **0.66** (anualizat); expunere medie 77%
- Modelul a învățat în principal “fii long”, iar ieșirile au venit la momente greșite

Recapitulare: studiul de caz

- ▣ Patru modele, 14 caracteristici, 25 de ani, validare fără scurgeri
- ▣ Niciun model nu bate “mereu în sus” (58.1%); AUC între 0.478 și 0.515
- ▣ Importanțele sunt minuscule și diferă între măsurile în eșantion și în afara lui
- ▣ Strategia walk-forward rămâne sub buy-and-hold după costuri (Sharpe 0.49 vs. 0.66)
- ▣ Un rezultat negativ onest este un rezultat

Testarea multiplă și biasul de selecție

- Un **backtest**: simularea unei strategii pe date istorice
- Un cercetător încearcă N strategii sau configurații și o raportează pe cea mai bună
- Chiar dacă toate au Sharpe real zero, $\max_n \widehat{SR}_n$ crește cu N
- **Biasul de selecție**: maximul raportat supraestimează performanța reală
- [Harvey, Liu & Zhu \(2016\)](#): față de sutele de factori publicați, un factor nou are nevoie de o statistică t peste 3, nu peste 2

Teorema strategiei false


Teoremă 1 (Teorema strategiei false, Bailey & López de Prado (2014))

- ▣ Fie $\widehat{SR}_n$, $n = 1, \dots, N$, estimări independente cu $\mathbb{E}[\widehat{SR}_n] = 0$ și varianța $\text{Var}[\widehat{SR}]$; atunci **raportul Sharpe maxim așteptat** este

$$\mathbb{E}\left[\max_n \widehat{SR}_n\right] \approx \sqrt{\text{Var}[\widehat{SR}]} \left[(1 - \gamma) \Phi^{-1}\left(1 - \frac{1}{N}\right) + \gamma \Phi^{-1}\left(1 - \frac{1}{N_e}\right) \right]$$


- ▣ $\gamma \approx 0.5772$: constanta Euler–Mascheroni; Φ : funcția de repartiție a distribuției Normale standard
- ▣ Pentru randamente i.i.d., $\text{Var}[\widehat{SR}] \approx 1/T$ pe perioadă

Cea mai bună din N strategii fără abilitate



- Strategii cu randamente i.i.d. de medie zero, 5 ani de date zilnice ($\text{Var}[\widehat{SR}]$ anualizat $\approx 1/5$)
- Încercând $N = 1000$ variante obținem un Sharpe maxim de ≈ 1.45 — **fără nicio abilitate**
- Simularea Monte Carlo confirmă teorema

În eșantion vs. în afara eșantionului: căutare pe grilă pe Bitcoin



- Încrucișare de medii mobile (MA) pe Bitcoin: long când MA rapidă a logaritmului prețului depășește MA lentă cu mai mult decât o bandă
- 1,279 de configurații (fereastră rapidă, fereastră lentă, bandă); în eșantion 2015–2020, în afara eșantionului 2021–2026

Căutarea pe grilă pe Bitcoin: interpretare

- ▣ Cea mai bună configurație IS (14/20 zile): $SR_{IS} = 1.65 \rightarrow SR_{OOS} = 0.02$ (anualizat cu $\sqrt{365}$)
- ▣ Corelația de rang Spearman dintre rapoartele Sharpe IS și OOS: $\rho = 0.12$
- ▣ SR OOS median: 0.53 pentru configurațiile din top-10% IS vs. 0.42 pentru toate
- ▣ *Familia* de reguli de trend conține ceva informație, dar optimul *selectat* este zgomot

Raportul Sharpe probabilistic

Definiție 20 (Raportul Sharpe probabilistic (PSR), Bailey & López de Prado (2012))

- $\widehat{SR}$ observat pe perioadă din T randamente, asimetrie $\hat{\gamma}_3$, kurtosis $\hat{\gamma}_4$ (distribuția Normală: $\gamma_4 = 3$):

$$\widehat{PSR}(SR^*) = \Phi \left(\frac{(\widehat{SR} - SR^*)\sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3 \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \widehat{SR}^2}} \right)$$

- Asimetria $\gamma_3 = \mathbb{E}[(r - \mu)^3]/\sigma^3$; kurtosis $\gamma_4 = \mathbb{E}[(r - \mu)^4]/\sigma^4$ (Capitolul 1)
- PSR = probabilitatea ca SR real să depășească un reper SR^* , ținând cont de lungimea eșantionului și de non-normalitate

Raportul Sharpe deflatat

Definiție 21 (Raportul Sharpe deflatat (DSR), Bailey & López de Prado (2014))

□ $DSR = \widehat{PSR}(SR_0)$, cu reperul egal cu maximul așteptat sub ipoteza nulă de lipsă a abilității:


$$SR_0 = \sqrt{\text{Var}[\widehat{SR}_n]} \left[(1 - \gamma) \Phi^{-1}\left(1 - \frac{1}{N}\right) + \gamma \Phi^{-1}\left(1 - \frac{1}{N_e}\right) \right]$$

- DSR corectează pentru **biasul de selecție** (N încercări), **non-normalitate** și **lungimea eșantionului**
- Respingem strategia dacă $DSR \leq 0.95$; raportăm N onest

Exemplu rezolvat: DSR pentru cea mai bună regulă pe Bitcoin

- Cea mai bună regulă IS: $T = 2,297$ randamente zilnice, $\widehat{SR} = 0.0864$ pe zi (1.65 anualizat), $\hat{\gamma}_3 = 0.10$, $\hat{\gamma}_4 = 12.71$
- Numitorul: $\sqrt{1 - 0.10 \cdot 0.0864 + \frac{12.71-1}{4} \cdot 0.0864^2} = 1.007$
- $N = 1,279$ încercări. Două alegeri pentru $\text{Var}[\widehat{SR}_n]$:
 - ▶ dispersia celor 1,279 de SR (abatere standard 0.0097): $SR_0 = 0.032/\text{zi}$, $z = 2.58$, $DSR = 0.995$
 - ▶ valoarea pentru încercări independente $1/T$ (abatere standard 0.0209): $SR_0 = 0.069/\text{zi}$, $z = 0.81$, $DSR = 0.792 < 0.95$
- Încercările sunt puternic corelate (ferestre vecine), deci dispersia lor subestimează căutarea reală: verdictul depinde de această alegere
- Sharpe-ul de 0.02 în afara eșantionului confirmă valoarea conservatoare

Raportul Sharpe deflatat în practică



- 5 ani de randamente zilnice, asimetrie -0.5, kurtosis 6
- Un SR anualizat de 1.0 este semnificativ doar dacă (aproape) nicio altă strategie nu a fost încercată: pică după 2-3 încercări
- SR = 1.5 rezistă la ≈ 10 încercări, SR = 2.0 la ≈ 200 ; doar SR = 2.5 rezistă la 1000

Probabilitatea de supraajustare a backtestului (PBO)

Validare încrucișată combinatorică simetrică (CSCV): Bailey, Borwein, López de Prado & Zhu (2017)

1. Matricea M de randamente: T perioade $\times N$ configurații de strategie
2. Împărțim rândurile în S blocuri; pentru fiecare dintre cele $\binom{S}{S/2}$ combinații formăm IS (jumătate din blocuri) și OOS (cealaltă jumătate)
3. Alegem cea mai bună configurație n^* în eșantion; calculăm rangul ei relativ $\bar{\omega} \in (0, 1)$ în afara eșantionului
4. Logit $\lambda = \log \frac{\bar{\omega}}{1-\bar{\omega}}$
5. $PBO = \Pr[\lambda < 0]$: probabilitatea ca învingătorul IS să fie sub mediana OOS


Interpretarea PBO

- ▣ $PBO \approx 0$: învingătorul în eşantion rămâne sigur peste mediană în afara eşantionului
- ▣ $PBO \approx 0.5$ sau mai mare: procesul de selecție nu are abilitate — a alege învingătorul IS este ca și cum ai alege la întâmplare
- ▣ PBO completează DSR: evaluează **procedura de cercetare**, nu o singură strategie
- ▣ Ambele cer înregistrarea **fiecărei** încercări, inclusiv a celor eșuate

Recapitulare: supraajustarea backtestului

- Cel mai bun dintre multe backtesturi este deplasat în sus: 1000 de încercări fără abilitate dau un Sharpe de ≈ 1.45
- Grila pe Bitcoin: învingătorul IS 1.65 $\rightarrow$ OOS 0.02
- PSR corectează pentru lungimea eșantionului și non-normalitate; DSR și pentru numărul de încercări
- PBO măsoară fiabilitatea întregii proceduri de selecție
- Înregistrați N ; deflatați înainte de a afirma ceva


Hardware-ul din spatele ML-ului modern



Un centru de date

Foto: BalticServers.com (2013); CC BY-SA 3.0;

Wikimedia Commons



Procesor grafic NVIDIA G80

Foto: Hyins (2011); domeniu public;

Wikimedia Commons

- Rețelele adânci și modelele fundamentale pentru serii de timp (Capitolul 14) se antrenează pe **GPU-uri** (procesoare grafice) în centre de date mari
- Un GPU rulează în paralel mii de nuclee simple: ideal pentru produse de matrice
- În finanțe constrângerea principală sunt de obicei datele (o singură istorie, raport semnal/zgomot mic), nu puterea de calcul

Deep learning pentru secvențe

Rețele recurente (LSTM, GRU)

- Starea ascunsă poartă memoria:
 $h_t = g(h_{t-1}, x_t)$
- Porțile controlează ce se păstrează sau se uită, atenuând dispariția gradientilor
- Folosite pentru prognoza volatilității, a registrului de ordine și intraday

Transformer

- Auto-atenție: $\text{softmax}(QK^T / \sqrt{d_k})V$, cu matricele de interogare, cheie și valoare Q, K, V
- Dependență pe termen lung, antrenare paralelă
- Baza modelelor lingvistice mari (Capitolul 15)

Modele fundamentale pentru serii de timp

Modele de prognoză pre-antrenate

- Pre-antrenate pe colecții mari de serii, folosite **zero-shot** (fără reantrenare): Chronos (Ansari et al., 2024), TimesFM (Das et al., 2023), Moirai (Woo et al., 2024), Lag-Llama (Rasul et al., 2023)
 - Repere utile pentru prognoza volatilității și a volumului
 - Pentru randamente moștenesc aceleași limite de semnal/zgomot
 - Datele de pre-antrenare se pot suprapune cu perioada de test: o nouă formă de scurgere
- Tratatate pe larg, cu instrumentele de evaluare a prognozelor de risc din Capitolul 8, în Capitolul 14

Învățare prin recompensă, modele generative, XAI, risc

Învățare prin recompensă (RL)

- O politică $\pi(a | s)$ alege acțiuni a în stări s pentru a maximiza recompensa cumulată
- Execuție optimă, market making, deep hedging: Buehler et al. (2019)

Modele generative

- GAN, autoencodere variaționale (VAE), modele de difuzie: scenarii sintetice pentru teste de stres

AI explicabilă (XAI)

- Cerută de autorități (EU AI Act, scoring de credit, riscul de model)
- SHAP, LIME (explicații locale interpretabile, independente de model), dependență parțială

ML pentru risc

- Volatilitate, Value-at-Risk, Expected Shortfall cu păduri cuantile sau boosting cu pierdere cuantilă (Capitolele 7–8)

- Quantinar:  Reinforcement Learning  GANs  Explainable AI  ML in Financial Risk

Listă de verificare

Date și caracteristici

- ☐ Date la momentul respectiv, fără bias de supraviețuire
- ☐ Caracteristici staționare care păstrează memoria: FFD
- ☐ Transformări estimate doar pe pliurile de antrenare

Etichete

- ☐ Etichete scalate cu volatilitatea, dependente de traiectorie
- ☐ Înregistrați intervalele etichetelor; ponderați după unicitate

Validare

- ☐ K-fold cu purjare / CPCV cu embargo
- ☐ Comparați mereu cu repere naive
- ☐ Raportați AUC și log-loss, nu doar acuratețea

Backtesting

- ☐ Includeți costurile de tranzacționare și slippage-ul
- ☐ Înregistrați fiecare încercare; raportați N
- ☐ Sharpe deflatat și PBO înainte de orice afirmație

Concluzii

- ▣ ML oferă modele flexibile, dar datele financiare oferă **puțin semnal și mult zgomot**
- ▣ Instrumentele clasice (LASSO, random forest, boosting, rețele neuronale) rămân de bază; partea specifică finanțelor este **procesul**
- ▣ Diferențierea fracționară împacă staționaritatea cu memoria ($d^* = 0.25$ pentru S&P 500)
- ▣ Etichetarea cu trei bariere și meta-etichetarea produc etichete care reflectă tranzacționarea reală
- ▣ K-fold amestecat poate raporta 69% acuratețe pe zgomot pur: folosiți purjarea și embargoul
- ▣ Pe S&P 500 niciun model nu bate “mereu în sus”; cel mai bun dintre multe backtesturi trebuie deflatat

Urmează

- ▣ Capitolul 14: deep learning și modele fundamentale pentru serii de timp; Capitolul 15: modele lingvistice mari și analiza sentimentului

Pentru aprofundare pe Quantinar

Cursuri avansate pe quantinar.com

-  Random Forests
-  Shapley Values
-  Shapley Curves: A Smoothing Perspective
-  Machine Learning in Financial Risk
-  Introduction to Reinforcement Learning
-  Generative Adversarial Networks
-  MSCA Digital: The Need for Explainable AI
-  Business Analytics and Data Science
-  Model Selection Criteria
-  PAC Learning

Bibliografie (1/3)

- ▣ Ané, T., Geman, H. (2000). Order flow, transaction clock, and normality of asset returns. *Journal of Finance*, 55(5), 2259–2284.
- ▣ Ansari, A.F. et al. (2024). Chronos: learning the language of time series. *arXiv:2403.07815*.
- ▣ Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- ▣ Bailey, D.H., López de Prado, M. (2012). The Sharpe ratio efficient frontier. *Journal of Risk*, 15(2), 3–44.
- ▣ Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- ▣ Buehler, H., Gonon, L., Teichmann, J., Wood, B. (2019). Deep hedging. *Quantitative Finance*, 19(8), 1271–1291.
- ▣ Clark, P.K. (1973). A subordinated stochastic process model with finite variance for speculative prices. *Econometrica*, 41(1), 135–155.
- ▣ Das, A., Kong, W., Sen, R., Zhou, Y. (2023). A decoder-only foundation model for time-series forecasting. *arXiv:2310.10688*.

Bibliografie (2/3)

- Dixon, M.F., Halperin, I., Bilokon, P. (2020). *Machine Learning in Finance: From Theory to Practice*. Springer.
- Friedman, J.H. (2001). Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- Gu, S., Kelly, B., Xiu, D. (2020). Empirical asset pricing via machine learning. *Review of Financial Studies*, 33(5), 2223–2273.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). ...and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*. 2nd ed. Springer.
- Hoerl, A.E., Kennard, R.W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.
- Hosking, J.R.M. (1981). Fractional differencing. *Biometrika*, 68(1), 165–176.
- Kelly, B., Xiu, D. (2023). Financial machine learning. *Foundations and Trends in Finance*, 13(3–4), 205–363.

Bibliografie (3/3)

- ▣ Lo, A.W. (2004). *The adaptive markets hypothesis*. *Journal of Portfolio Management*, 30(5), 15–29.
- ▣ López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- ▣ López de Prado, M. (2020). *Machine Learning for Asset Managers*. Cambridge University Press.
- ▣ Lundberg, S.M., Lee, S.-I. (2017). *A unified approach to interpreting model predictions*. *Advances in Neural Information Processing Systems*, 30.
- ▣ Rasul, K. et al. (2023). *Lag-Llama: towards foundation models for probabilistic time series forecasting*. *arXiv:2310.08278*.
- ▣ Tibshirani, R. (1996). *Regression shrinkage and selection via the lasso*. *Journal of the Royal Statistical Society B*, 58(1), 267–288.
- ▣ Woo, G. et al. (2024). *Unified training of universal time series forecasting transformers*. *arXiv:2402.02592*.
- ▣ Zou, H., Hastie, T. (2005). *Regularization and variable selection via the elastic net*. *Journal of the Royal Statistical Society B*, 67(2), 301–320.
- ▣ **Cod și date:** github.com/danpele/MFM/tree/main/Quantlets/Ch_13
- ▣ Campbell, M., Hoane, A.J., Hsu, F. (2002). *Deep Blue*. *Artificial Intelligence*, 134(1–2), 57–83.
- ▣ Rosenblatt, F. (1958). *The perceptron: a probabilistic model for information storage and organization in the brain*. *Psychological Review*, 65(6), 386–408.