



Modelarea piețelor financiare

Capitolul 14: Deep learning și modele fundamentale pentru serii de timp



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ACF: AutoCorrelation Function (funcția de autocorelație)
- ACI: Adaptive Conformal Inference (inferență conformală adaptivă)
- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ARFIMA: AutoRegressive Fractionally Integrated Moving Average (model) (model autoregresiv cu medie mobilă, integrat fracționar)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- CI: Confidence Interval (interval de încredere)
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- CPU: Central Processing Unit (procesorul central al calculatorului)
- CRPS: Continuous Ranked Probability Score (scorul de probabilitate ordonat continuu)
- CRSP: Center for Research in Security Prices (Centrul de cercetare a prețurilor titlurilor (Universitatea din Chicago))
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- DQ: Dynamic Quantile (test) (testul cuantilei dinamice)
- ES: Expected Shortfall (pierderea așteptată în coadă)
- ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- FHS: Filtered Historical Simulation (simulare istorică filtrată)
- FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GIFT: General Time Series Forecasting Model Evaluation (benchmark GIFT-Eval) (bancul de testare GIFT-Eval pentru evaluarea modelelor generale de prognoză a seriilor de timp)
- GPD: Generalised Pareto Distribution (distribuția Pareto generalizată)
- GRU: Gated Recurrent Unit (unitate recurentă cu porți)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- HS: Historical Simulation (simulare istorică)
- LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)

Acronime folosite în acest material (2/2)


- ▣ LLM: Large Language Model (model lingvistic mare)
- ▣ LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- ▣ LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- ▣ MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- ▣ MDE: Minimum Detectable Effect (efectul minim detectabil)
- ▣ MLP: MultiLayer Perceptron (perceptron multistrat)
- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ NBER: National Bureau of Economic Research (Biroul Național de Cercetări Economice (SUA))
- ▣ PIT: Probability Integral Transform (transformarea integrală de probabilitate)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ QS: Quantile Score (scorul cuantic)
- ▣ RFF: Random Fourier Features (trăsături Fourier aleatoare)
- ▣ RNN: Recurrent Neural Network (rețea neuronală recurentă)
- ▣ RV: Realised Variance (varianța realizată)
- ▣ SPA: Superior Predictive Ability (test) (testul abilității predictive superioare)
- ▣ SUA: Statele Unite ale Americii
- ▣ TS: Time Series (in the name TS-Arena) (serii de timp (în numele platformei TS-Arena))
- ▣ VAR: Vector AutoRegression (model vector autoregresiv)

Traseul capitolului și rezultatele învățării

- Întrebarea: prognozează rețelele profunde și **modelele fundamentale** pentru serii de timp **randamentele**, **volatilitatea** și **tail risk** mai bine decât modelele clasice din [capitolele 5–9](#)?
 - ▶ **Deep learning** (învățare profundă): modele construite din multe straturi de unități neliniare simple, antrenate pe date; din 2024, modele fundamentale pre-antrenate pe miliarde de observații
 - ▶ Răspundem cu instrumentele de evaluare din [Capitolul 8](#): repere puternice, diferențe de pierdere, backtesting
- Traseul capitolului
 - ▶ Partea I: rețele pentru secvențe, atenție, modele fundamentale, Testul 1 (randamente)
 - ▶ Partea a II-a: Testul 2 (volatilitate realizată), Testul 3 (VaR 1% și ES 2,5%), studiu de caz, AI pentru descoperire științifică
- La final veți putea
 - ▶ explica dispariția gradientului prin răspunsurile la impuls ale unui VAR și starea celulei LSTM ca AR(1)
 - ▶ transforma o grilă de cuantile zero-shot în prognoze punctuale, de volatilitate și VaR/ES
 - ▶ testa corect un model nou: imbricare, teste multiple, calibrare, contaminare și putere

Trei ținte de prognoză


- ▣ **Randamentele** r_t (media condiționată)
 - ▶ Raport semnal-zgomot foarte mic; tiparele previzibile dispar prin tranzacționare ([Capitolul 2](#))
 - ▶ Reperul: prognoza zero
- ▣ **Volatilitatea** (varianța condiționată)
 - ▶ Persistentă, cu episoade de volatilitate ridicată sau scăzută ([capitolele 1 și 5](#)): există un semnal de învățat
 - ▶ Reperul: log-HAR
- ▣ **Măsurile de tail risk**: VaR 1% și ES 2,5%
 - ▶ Cer forma cozii stîngi, nu doar centrul distribuției ([Capitolul 7](#))
 - ▶ Reperul: FHS



Un centru de date: rețelele profunde sînt antrenate pe
astfel de servere

Foto: [BalticServers.com](#) (2013); CC BY-SA 3.0; [Wikimedia Commons](#)

Unde este semnalul?



- Randamentele zilnice ale S&P 500 din 2000 (6 718 zile), decalajele 1–50; banda gri: $\pm 1,96/\sqrt{T} = \pm 0,024$ sub independență
- Randamentele: autocorelația de ordinul 1 este -0,099; 15 din 50 de decalaje ies din bandă, mici și cu semne diferite: puțin de învățat despre medie
- Randamentele absolute: 0,29 la decalajul 1, încă 0,13 la decalajul 50; toate cele 50 de decalaje ies din bandă: grupare persistentă a volatilității
- Ce așteptăm în acest capitol: modelele flexibile pot găsi semnalul din volatilitate, dar aproape nimic în medie

De la perceptronul multistrat la deep learning

- MLP (perceptronul multistrat, [Capitolul 13](#)):

$$h^{(\ell)} = \varphi \left(W^{(\ell)} h^{(\ell-1)} + b^{(\ell)} \right), h^{(0)} = x; \varphi: \text{ReLU, tanh sau sigmoida}$$

$$\sigma(z) = 1/(1 + e^{-z})$$
 - Propagare înapoi ([Rumelhart, Hinton & Williams \(1986\)](#)) și Adam ([Kingma & Ba \(2015\)](#)); pierderea MSE pentru puncte, pinball $(u - 1\{y < q\})(y - q)$ pentru o cuantilă de nivel u
- Aproximarea universală ([Hornik, Stinchcombe & White \(1989\)](#)): nu spune nimic despre mărimea eșantionului necesar, constrângerea decisivă pentru o singură serie financiară
 - Regularizare: oprire timpurie, weight decay, ansambluri pe seed-uri; blocul de validare trebuie să urmeze blocului de antrenare
- Premiul Nobel pentru Fizică 2024 acordat lui Hopfield și Hinton ([LeCun, Bengio & Hinton \(2015\)](#) pentru metode); în finanțe, [Gu, Kelly & Xiu \(2020\)](#) câștigă pe o secțiune transversală de mii de acțiuni, nu pe un singur indice




Geoffrey Hinton, laureat Nobel 2024

Foto: [Arthur Petron \(2024\)](#); CC BY-SA 4.0;

[Wikimedia Commons](#)

RNN și LSTM pe scurt

- ▣ **Rețea neuronală recurentă (RNN):** $h_t = \tanh(W h_{t-1} + U x_t + b)$, $\hat{y}_{t+1} = v^\top h_t + c$
 - ▶ Aceleași ponderi la fiecare pas: desfășurată în timp, o rețea foarte adâncă, cu ponderi comune
- ▣ **Long short-term memory (LSTM, Hochreiter & Schmidhuber (1997)):** porți $f_t, i_t, o_t = \sigma(W_\bullet x_t + U_\bullet h_{t-1} + b_\bullet)$, candidatul $g_t = \tanh(W_g x_t + U_g h_{t-1} + b_g)$
 - ▶ Starea celulei $c_t = f_t \odot c_{t-1} + i_t \odot g_t$, ieșirea $h_t = o_t \odot \tanh(c_t)$; $\odot$: produs element cu element
 - ▶ f_t : poarta de uitare, i_t : poarta de intrare, o_t : poarta de ieșire; GRU (unitate recurentă cu porți): o variantă mai ușoară, cu două porți



Dispariția gradientului: o majorare și un VAR(1)

- Propagarea înapoi în timp înmulțește câte o matrice jacobiană la fiecare pas

► $\frac{\partial h_T}{\partial h_{T-k}} = \prod_{j=0}^{k-1} D_{T-j} W, \quad D_t = \text{diag}(\varphi'(Wh_{t-1} + Ux_t + b))$

- Submultiplicativitatea: $\|\partial h_T / \partial h_{T-k}\|_2 \leq (\gamma_\varphi \|W\|_2)^k$, $\gamma_\varphi = \sup_z |\varphi'(z)|$ ($= 1$ pentru tanh): $\gamma_\varphi \|W\|_2 < 1$ este suficient pentru dispariție (Pascanu, Mikolov & Bengio (2013))

- Liniarizăm într-un punct fix h^* : $h_t - h^* \approx A(h_{t-1} - h^*) + DUx_t$, $A = DW$: un VAR(1) (autoregresie vectorială) în starea ascunsă

- $\partial h_T / \partial h_{T-k} = A^k$ este răspunsul lui la impuls la orizontul k : VAR stabil, $\rho(A) < 1$, gradientii scad ca $\rho(A)^k$; $\rho(A) > 1$, explodează

- O RNN stabilă în jurul punctului fix este un model cu memorie scurtă, ca orice VAR staționar (Seminarul, A1; detalii în [Anexă](#))

- Cazul scalar $|w|^k$: $0,9^{20} = 0,12$, $0,9^{50} = 0,005$ (Bengio, Simard & Frasconi (1994))

- Remedii: limitarea normei gradientului (explozie); porțile, ca în LSTM (dispariție)

De ce își amintește LSTM

- Pe calea directă prin starea celulei, singurul factor multiplicativ este poarta de uitare
 - ▶ $\frac{\partial c_T}{\partial c_{T-k}} = \prod_{j=0}^{k-1} f_{T-j}$ (drumul direct); $c_t = f_t \odot c_{t-1} + i_t \odot g_t$: un AR(1) cu coeficient aleator
- Poartă de uitare constantă $f = \sigma(b_f)$: un AR(1) cu coeficientul f
 - ▶ $b_f = 0$: $f = 0,5$, $0,5^{50} \approx 9 \times 10^{-16}$
 - ▶ $b_f = 3$: $f = 0,953$, $0,953^{50} \approx 0,09$; timp de înjumătățire 14 pași
- Memorie scurtă prin construcție: $\text{Corr}(c_t, c_{t-k}) = f^k$ scade geometric; memoria lungă scade hiperbolic, $\rho_k \sim Ck^{2d-1}$
 - ▶ Ajustat pe randamentele absolute ale S&P 500, $f = 0,984$ prezice 0,027 la decalajul 150, față de 0,059 observat ([▶ Anexă](#))




Sepp Hochreiter, co-inventator al LSTM

Foto: Eulenreich (2015); CC BY-SA 4.0;

[Wikimedia Commons](#)

Dispariția gradientului, măsurată numeric



- $|\partial h_T / \partial x_{T-k}|$ prin diferențiere automată; 16 unități ascunse, 50 de inițializări aleatoare, aceleași intrări Normale
- RNN simplă: $8,3 \times 10^{-5}$ la decalajul 20, $7,4 \times 10^{-9}$ la decalajul 50: nu se învață nimic din intrări mai vechi de câteva săptămîni
- LSTM, termenul liber al porții de uitare 0: $1,2 \times 10^{-10}$ la decalajul 50, nu mai bine decît RNN ($f \approx 0,5$ înjumătățește memoria la fiecare pas)
- LSTM, termenul liber 3: 8,4% la decalajul 50, cum prezice $0,953^{50} \approx 0,09$; inițializați termenul liber al porții de uitare cu o valoare pozitivă

Atenția, pozițiile și patch-urile

- Fiecare pas de timp pune o întrebare (query) și o compară cu fiecare pas trecut (key):

$$\text{Attention}(Q, K, V) = \text{softmax}\left(QK^T / \sqrt{d_k}\right) V \text{ (Vaswani et al. (2017))}$$


- ▶ $Q = XW_Q$, $K = XW_K$, $V = XW_V$: proiecții liniare ale intrărilor X ; softmax transformă scorurile în ponderi cu suma 1; $\sqrt{d_k}$ împiedică saturarea
- ▶ Niciun produs de jacobiene în timp: orice pas trecut este legat direct de pasul curent; costul $O(n^2)$ în numărul de intrări n

- **Codificarea poziției:** atenția tratează intrările ca pe o mulțime, deci ordinea trebuie adăugată (sinusoide în Transformerul original; codificări rotative în Chronos-2)

- **Împărțirea în patch-uri (Nie et al. (2023)):** un token este un bloc de observații consecutive

- ▶ 512 randamente zilnice în patch-uri de 16 zile: 32 de tokeni, de circa 256 de ori mai puține scoruri de atenție; fiecare token rezumă câteva săptămîni de piață

Împărțirea unui context de 512 zile în patch-uri



- Ultimele 512 randamente zilnice ale S&P 500, împărțite așa cum le citesc Chronos-2 (16 zile) și TimesFM-2.5 (32 de zile)
- Fiecare bloc colorat devine un vector de reprezentare pentru Transformer
- DeepAR (Salinas et al. (2020)), N-BEATS (Oreshkin et al. (2020)) și PatchTST (Nie et al. (2023)) învață pe multe serii; modelele fundamentale duc ideea pînă la capăt


Ce este un model fundamental?

- ▣ O rețea mare, pre-antrenată o singură dată pe un corpus foarte larg, apoi folosită pentru sarcini noi
 - ▶ Idee preluată de la modelele mari de limbaj (LLM): pre-antrenare pe text, apoi utilizare pentru orice întrebare
- ▣ Prognoza **zero-shot**: fără antrenare pe seria-țintă; doar istoricul ei recent (**contextul**) este transmis la momentul prognozei
 - ▶ Rezultatul: o mulțime de cuantile ale valorilor viitoare, nu doar un punct
 - ▶ Fine-tuning-ul (antrenare suplimentară pe seria-țintă) este posibil, dar nu o folosim aici
- ▣ Avantajul pentru finanțe: un singur model pentru mii de serii, fără estimare separată pentru fiecare serie

Chronos: seriile de timp ca limbaj

- ▣ [Ansari et al. \(2024\)](#): valorile devin tokeni, iar un model de limbaj (T5) este antrenat cu entropia încrucișată
 - ▶ Scalarea prin medie: contextul se împarte la $s = \frac{1}{C} \sum_t |x_t|$
 - ▶ Cuantizarea: 4.093 de centre echidistante în $[-15, 15]$ (lățimea 0,0073), plus tokeni speciali
 - ▶ Prognoza: se eșantionează tokeni viitori, se transformă înapoi în valori, se citesc cuantilele din eșantioane
- ▣ Corpusul de pre-antrenare: seturi publice de date (energie, transport, comerț, vreme, web, finanțe și economie) plus serii sintetice (TSMixup, KernelSynth)
 - ▶ Dimensiuni de 20 pînă la 710 milioane de parametri; versiunea mică are 46 de milioane

Ce vede Chronos: randamente scalate și tokeni



- Contextul: ultimele 512 randamente zilnice ale S&P 500; scala $s = 0,672\%$; randamentele scalate între -9,2 și 13,5, 96% în intervalul ± 3
- Cele 512 randamente folosesc 336 de tokeni distincți din 4.093: scalarea face modelul independent de unități, deci nivelul volatilității trebuie citit din context
- O zi de crah M mărește s cu circa $|M|/C$: puternic într-un context scurt, puțin într-unul de 512 zile (Seminarul, A3)

Cele trei modele pe care le testăm


Model	Parametri	Patch	Niveluri de cuantile	Data publicării ponderilor
Chronos-Bolt (small)	48 M	16	10%–90%	25.11.2024
TimesFM-2.5	231 M	32	medie, 10%–90%	01.10.2025
Chronos-2	119 M	16	1%, 5%, ..., 99%	30.10.2025

- ▣ **Chronos-Bolt**: patch-uri și estimarea directă a cuantilelor, în locul eșantionării de tokeni
- ▣ **Chronos-2** ([Ansari et al. \(2025\)](#)): scalare robustă, atenție în timp și între grupuri de serii înrudite
- ▣ **TimesFM** ([Das et al. \(2024\)](#)): Transformer doar cu decodor, pre-antrenat pe circa 10^{11} puncte
- ▣ Toate rulează pe un CPU, cu un context de 512 zile; datele de publicare a ponderilor limitează ce au putut vedea modelele; doar Chronos-2 ajunge la nivelul de 1%

De la o grilă de cuantile la VaR și ES

- Modelul întoarce cuantile q_u la nivelurile $u_1 < \dots < u_K$
 - ▶ Prognoza punctuală: mediana $q_{0,5}$ sau media $\int_0^1 q_u du$; pentru g crescătoare, $E[g(Y)] = \int_0^1 g(q_u) du$ (de exemplu $g = \exp$ pentru logaritmul varianței)
 - ▶ Tail risk (Capitolul 7): $\text{VaR}_\alpha = -q_\alpha$, $\text{ES}_\alpha = -\frac{1}{\alpha} \int_0^\alpha q_u du$
- Exemplu lucrat, S&P 500, ziua de după 18.09.2026: $q_{0,01} = -2,70\%$, $q_{0,05} = -1,40\%$
 - ▶ VaR 1% = 2,70%; interpolare liniară $q_{0,025} = q_{0,01} + \frac{0,015}{0,04}(q_{0,05} - q_{0,01}) = -2,21\%$, VaR 2,5% = 2,21%
 - ▶ $\text{ES } 2,5\% = -\frac{1}{0,025} \left[0,01 q_{0,01} + 0,015 \frac{q_{0,01} + q_{0,025}}{2} \right] = 2,56\%$
- Sub cel mai mic nivel, grila nu spune nimic: păstrarea lui q_u la $q_{0,01}$ subestimează ES, interpolarea poate greși în ambele sensuri (Seminarul, A5–A6)
 - ▶ Chronos-Bolt și TimesFM se opresc la 10%: o cerere de „VaR 1%” întoarce cuantila de 10%

Un fan chart zero-shot pentru volatilitate



- Chronos-2 pe logaritmul varianței realizate a SPY (context de 512 zile), 22 de zile de tranzacționare de la 18.09.2026; benzi: cuantilele 5–95% și 25–75%
- Ultima volatilitate 4,8% pe an, media pe 20 de zile 6,6%; prognoza mediană la 22 de zile 6,6%, banda de 90% 3,8–15,4%
- Banda se lărgeste și este asimetrică în sus: revenire la medie, ca la GARCH și HAR ([capitolele 5, 9](#)), fără nicio estimare pe SPY
- Testele 1–3 verifică dacă aceste prognoze sînt mai bune


Leakage prin pre-antrenare și contaminarea

- Un test este în afara eșantionului doar dacă perioada de test nu a fost văzută la antrenare; patru moduri în care poate fi „văzută”
 - ▶ (i) aceeași serie este în corpusul de pre-antrenare; (ii) serii corelate poartă aceleași șocuri; (iii) dezvoltatorii aleg versiunile după benchmark-uri publice care se suprapun cu datele de test
 - ▶ (iv) propriul nostru look-ahead: scalări, ferestre, seed-uri sau contexte alese cu date de test
 - Corpusul Chronos include serii financiare (de exemplu cursuri de schimb zilnice 1990–2016); nu putem exclude că seriile noastre au fost văzute
 - Remediul pentru (i)–(iii): o **ferastră de după publicare**, de la 3 noiembrie 2025, o dată-limită comună după publicarea tuturor celor trei seturi de ponderi
 - ▶ Curată, dar scurtă (circa 220 de zile de tranzacționare; 320 de zile calendaristice pentru Bitcoin): putere mică, mai ales pentru VaR 1%
 - (iv) este sub controlul nostru: scalările, ferestrele și estimările folosesc doar date trecute; un protocol formal este în 
- ▶ Anexă


Protocolul testului pentru randamente

- ▣ Randamente log zilnice (%): S&P 500 și BET de la 04.01.2016 (2 693 și 2 675 de zile), Bitcoin de la 01.01.2019 (2 818 zile)
 - ▶ Fiecare prognoză folosește doar date pînă la închiderea precedentă
- ▣ Modele: media istorică, AR(1) pe o fereastră de 1.000 de zile, LSTM, Chronos-2, Chronos-Bolt și TimesFM-2.5 (mediana)
 - ▶ Eroarea pătratică vizează media; mediile din grilă ($\int_0^1 q_u du$) sînt și mai slabe, de exemplu pe S&P 500 R^2 -0,77% (Chronos-2), -3,42% (TimesFM-2.5)
- ▣ Reper: prognoza zero; R^2 în afara eșantionului $= 1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t r_t^2$
 - ▶ Zero în locul mediei istorice, ca la [Gu, Kelly & Xiu \(2020\)](#); comparați cu [Campbell & Thompson \(2008\)](#)
 - ▶ Inferență: CI bootstrap pe blocuri pentru R^2 (blocuri de 20 de zile), testul Diebold–Mariano (DM) pe erorile pătratice, cu varianță Newey–West ([Diebold & Mariano \(1995\)](#))

LSTM-ul pentru randamente și oprirea timpurie




- Intrarea: ultimele 20 de randamente, standardizate pe perioada de antrenare; 16 unități ascunse, ieșire liniară: $4(hd + h^2 + 2h) + h + 1 = 1\,233$ de parametri
- MSE, Adam, weight decay 10^{-4} ; antrenat o dată pe pînă la 4.000 de zile, ultimele 20% pentru oprirea timpurie; prognoza = media a 5 seed-uri
- Graficul (S&P 500, seed-ul 0): antrenarea se oprește după 26 de epoci, se păstrează ponderile din epoca 1
- Puțin de învățat: abaterea standard a prognozei 0,047%, față de 1,13% pentru randamente; MSE de validare este mai mic doar pentru că acei ani au fost mai calmi

R^2 în afara eșantionului pentru randamente


- R^2 față de prognoza zero (%), CI bootstrap pe blocuri de 95%; tabelul complet, cu valorile p DM, în [Anexă](#)
- S&P 500 și Bitcoin: niciun model nu bate semnificativ prognoza zero
- TimesFM-2.5 este semnificativ **mai slab** decât zero (S&P 500 R^2 -3,35%, DM $p = 0,001$): abaterea standard a prognozei 0,141%, de trei ori mai mare decât a LSTM
- BET: LSTM are R^2 +1,15% (DM $p = 0,014$): un semnal mic, testat mai jos pentru imbricare, teste multiple și prețuri vechi

Reducerile cumulate ale erorii pătratice pe S&P 500



- $\sum_{s \leq t} [r_s^2 - (r_s - \hat{r}_s)^2]$: crește când modelul bate prognoza zero, scade când pierde
- Toate curbele rămân lângă zero în anii calmi și sar în martie 2020: o singură lună decide clasamentul
- AR(1) câștigă în 2020 din autocorelația negativă a zilelor de crah, apoi pierde o parte; TimesFM-2.5 pierde constant
- Raportați evoluția în timp, nu doar R^2 final

Loteria seed-urilor



- R^2 în afara eșantionului pentru cinci LSTM-uri care diferă doar prin seed-ul aleator și pentru media lor
- Bitcoin: seed-urile individuale între -0,79% și +0,24%; S&P 500 între +0,37% și +1,96%: variație la fel de mare ca efectul
- BET: toate cele 5 seed-uri între +1,01% și +1,22%: robust la seed, dar încă nu la testele multiple sau la prețurile vechi
- Alegerea celui mai bun seed după ce ai văzut testul este overfitting-ul backtestului ([Capitolul 13](#))

MFM_ch14_returns

Modele imbricate și teste multiple

- Prognoza zero este imbricată în media istorică și în AR(1): sub H_0 modelul mai mare doar adaugă zgomot de estimare, deci DM respinge prea rar
 - ▶ Clark & West (2007): $\tilde{d}_t = e_{0,t}^2 - [e_{1,t}^2 - (\hat{r}_{0,t} - \hat{r}_{1,t})^2]$, test t HAC unilateral
 - ▶ p unilateral, DM vs Clark–West: media istorică 0,048 vs 0,007 (S&P 500), 0,041 vs 0,003 (BET); AR(1) 0,320 vs 0,055
- 6 modele $\times$ 3 piețe = 18 teste; cea mai mică valoare p DM unilaterală este LSTM pe BET, 0,007
 - ▶ Pragul Bonferroni 0,0028; p ajustat Holm pe cele 18 teste 0,130: nesemnificativ
 - ▶ În cele șase modele BET: Romano–Wolf (Romano & Wolf (2005)) 0,016; SPA (Hansen (2005)), H_0 : niciun model nu bate prognoza zero: BET 0,018, S&P 500 0,130, Bitcoin 0,354
- Interpretare: „un model bate prognoza zero pe BET” rezistă; „una dintre 18 comparații este reală” nu. Stabiliți familia de teste înainte de a examina rezultatele

Este reală previzibilitatea BET? Tranzacționarea nesincronă

- Prețurile neactualizate ale acțiunilor tranzacționate rar induc autocorelație pozitivă în randamentele indicelui, chiar dacă fiecare preț este eficient (Lo & MacKinlay (1990))
 - ▶ Autocorelația de ordinul 1 din 2016: BET 0,06, S&P 500 $-0,14$
 - ▶ Prognoza LSTM are corelația 0,88 cu randamentul BET din ziua precedentă: a învățat în principal această autocorelație
- Verificare pe un instrument tranzacționabil: ETF-ul Patria-TV BET ETF, care replică BET, 2 629 de zile comune, același semnal LSTM
 - ▶ Aceeași zi: R^2 2,88% (BET 1,26%), dar și ETF-ul se tranzacționează rar (autocorelația 0,07, 4,2% zile cu randament zero)
 - ▶ Executat cu o zi întârziere: R^2 0,57%, Clark–West $p = 0,003$
- Interpretare: rezultatele sînt compatibile cu efectul prețurilor neactualizate; un semnal mic rămîne și cînd execuția este întârziată cu o zi, înainte de costurile de tranzacționare (Capitolul 2)


Ținta, reperul și pierderea

- ▣ **Varianța realizată** (RV, Andersen et al. (2003)): suma pătratelor randamentelor log la 5 minute din ziua de tranzacționare
 - ▶ $RV_t = \sum_{j=1}^{78} r_{t,j}^2$ pentru SPY (sesiunea regulată, 6,5 ore); volatilitatea medie 11,9% pe an
- ▣ **HAR** (Corsi (2009)): $RV_t = \beta_0 + \beta_d RV_{t-1} + \beta_w \overline{RV}_{t-5:t-1} + \beta_m \overline{RV}_{t-22:t-1} + \varepsilon_t$
 - ▶ log-HAR: același model pe log RV, prognoza $\exp(\hat{y} + \hat{s}^2/2)$: media, dacă eroarea logaritmică este condiționat Normală
- ▣ Pierderea **QLIKE** (Patton (2011)): $L = RV_t/\hat{h}_t - \log(RV_t/\hat{h}_t) - 1$
 - ▶ Este minimizată de media condiționată; ordonează prognozele la fel ca varianța adevărată cînd RV este o aproximare condiționat nedeplasată, $E[RV_t | \mathcal{F}_{t-1}] = \sigma_t^2$ (la fel și MSE)

Protocolul testului pentru volatilitate

- ▣ Varianța realizată a SPY, prognoze la o zi de la 11.10.2022 pînă la 18.09.2026 (979 de zile)
 - ▶ HAR și log-HAR pe o fereastră mobilă de 500 de zile; random walk: $\hat{h}_t = RV_{t-1}$
 - ▶ GARCH-t pe randamentele zilnice ale SPY, rescalat în unități RV prin raportul dintre media RV și media randamentelor la pătrat pe 500 de zile
 - ▶ LSTM pe ultimele 22 de valori ale log RV, reantrenat la fiecare 125 de zile pe 500 de zile (stare ascunsă 8, trei seed-uri)
- ▣ Modelele fundamentale pe log RV (context 512): prognoza $\hat{h}_t = \int_0^1 \exp(q_u) du$ pe grila de cuantile
 - ▶ Fereastra de după publicare: 218 zile de la 3 noiembrie 2025


Prognozele în timpul șocului din aprilie 2025



- Volatilitatea realizată a SPY (anualizată) și prognozele la o zi, februarie–iulie 2025; vârful 107% pe an la 07.04.2025, după anunțurile tarifare ale SUA
- Niciun model nu anticipează saltul; toate reacționează a doua zi: prognozele la o zi extrapolează trecutul, șocurile vin din știri
- Modelele fundamentale și log-HAR revin cu viteze asemănătoare; GARCH-t reacționează la randamentele zilnice și revine mai lent

 MFM_ch14_realised_vol

Pierderile QLIKE ale celor opt modele de volatilitate




- Stînga: toată perioada de test; dreapta: după 3 noiembrie 2025 (218 zile); tabelul complet, cu valorile p DM și MCS, în [Anexă](#)
- Chronos-2 (0,231), Chronos-Bolt, TimesFM-2.5 și log-HAR (0,234): teste DM nesemnificative (Chronos-2 $p = 0,537$), toate în MCS de 90%
- Random walk și GARCH-t sînt eliminate; HAR în niveluri supraestimează (media prognozei / media RV = 1,36); după publicare, LSTM-ul mic este cel mai bun (0,233): clasamentele sînt instabile
- Nicio diferență condiționată: testul Giacomini–White ($1, d_{t-1}$) față de log-HAR, $p = 0,760$ (Chronos-2), 0,935 (TimesFM-2.5); lipsa unei diferențe detectate nu dovedește egalitatea

Mediana sau media? Un detaliu costisitor

Chronos-2 și TimesFM-2.5 pe log RV	QLIKE	Media prognozei / media RV
Chronos-2, $\int_0^1 \exp(q_u) du$	0,231	1,02
Chronos-2, $\exp(q_{0,5})$	0,259	0,79
TimesFM-2.5, $\int_0^1 \exp(q_u) du$	0,233	0,94
TimesFM-2.5, $\exp(q_{0,5})$	0,259	0,79

- O teoremă, nu o curiozitate ([Gneiting \(2011\)](#)): QLIKE este consistentă pentru medie, $\arg \min_h E[L(RV, h) | \mathcal{F}] = E[RV | \mathcal{F}]$
 - Transformările monotone păstrează cuantilele: $\exp(\text{mediana lui } \log RV)$ este mediana lui RV, elicitată de eroarea absolută, nu de QLIKE
 - RV lognormală: $\text{mediana}/\text{media} = e^{-s^2/2}$; varianta cu mediana este semnificativ mai slabă (DM +3,60 pentru Chronos-2) și mai slabă decât log-HAR (0,234)

De cât context are nevoie Chronos-2?




- QLIKE pentru Chronos-2 pe log RV cu contexte de 32 până la 512 zile, în aceleași zile de prognoză
- QLIKE scade de la 0,290 (32 de zile) la 0,231 (512 zile); sub circa 256 de zile Chronos-2 este mai slab decât log-HAR (0,234)
- Memorie lungă: mai multe luni de istorie arată nivelul care variază lent, pe care HAR îl codifică explicit prin media pe 22 de zile
- Lungimea contextului este o alegere de modelare care trebuie raportată și testată, ca lungimea unei ferestre

Protocolul testului pentru tail risk și pierderea FZ0


- $\text{VaR}_\alpha = -q_\alpha(r_{t+1} \mid \mathcal{F}_t)$, pierderea depășită cu probabilitatea α ; $\text{ES}_\alpha = -\frac{1}{\alpha} \int_0^\alpha q_u du$; nivelurile VaR 1% (teste de acoperire) și (VaR 2,5%, ES 2,5%)
- Modele clasice, fereastră de 1.000 de zile, reestimate la fiecare 20 de zile: HS, GARCH(1,1)-t, FHS (McNeil & Frey (2000))
 - ▶ **Direct**: cuantilele Chronos-2 ale randamentului de mâine (context: 512 randamente)
 - ▶ **Hibrid**: scala $\hat{\sigma}_t =$ prognoza lui $|r_t|$ (Chronos-2: media din grilă; TimesFM: mediana); FHS pe $r_t/\hat{\sigma}_t$
- ES singur nu este elicitable, perechea (VaR, ES) este (Fissler & Ziegel (2016)); FZ0 (Patton, Ziegel & Chen (2019)), pierderea $L_t = -r_t$, $v = \text{VaR}$, $e = \text{ES} > 0$:
 - ▶
$$\text{FZ0} = \frac{1\{L_t > v\}(L_t - v)}{\alpha e} + \frac{v}{e} + \log e - 1$$
 - ▶ O valoare mai mică este mai bună: penalizează depășirile (primul termen) și prognozele prea largi ($\log e$); modelele se compară prin teste DM pe diferențele FZ0 și prin MCS (Hansen, Lunde & Nason (2011))

Ratele de depășire ale VaR 1%



- Ponderea zilelor cu o pierdere peste VaR 1% (scară logaritmică); banda gri: intervalul de 95% dacă modelul ar fi corect
- Chronos-2 direct: prea multe depășiri pe S&P 500 (1,67%, p Kupiec = 0,001) și pe BET (1,50%)
- Chronos-Bolt, cea mai mică cuantilă (10%) folosită drept „VaR 1%”: 13,5%
- Hibrizii: rate de depășire apropiate de 1% pe toate cele trei piețe (doar acoperirea medie; tabelul complet în [► Anexă](#))

Crahul COVID-19: VaR 1% pentru trei modele




- S&P 500, februarie–iunie 2020 (104 zile): pierderile zilnice și prognozele VaR 1%; puncte: depășiri
- Depășiri: FHS 2, Chronos-2 direct 4, FHS cu volatilitatea Chronos-2 2, HS 12; toate modelele sînt depășite în primele zile
- Chronos-2 citește repede contextul, deci cuantilele lui se lărgesc rapid
- Hibridul exagerează: VaR 1% de 58,9% la 17.03.2020, față de 26,4% pentru FHS și o pierdere maximă de 12,8% ([▶ Anexă](#))

Backtesting dincolo de Kupiec: gruparea și testul DQ

p : indep. / DQ	HS	GARCH-t	FHS	Chronos-2 direct	FHS + Chronos-2	FHS + TimesFM
S&P 500	0,001 / <0,001	0,205 / 0,001	0,045 / 0,021	0,223 / <0,001	0,021 / 0,001	0,029 / <0,001
Bitcoin	0,611 / 0,760	0,261 / 0,463	0,220 / 0,092	0,404 / 0,034	0,026 / 0,004	0,261 / 0,182
BET	0,399 / <0,001	0,258 / 0,082	0,409 / 0,650	0,270 / 0,026	0,475 / <0,001	0,379 / <0,001


- Independența (Christoffersen (1998)): lanț Markov de ordinul 1 al depășirilor, $LR \sim \chi^2_1$; acoperirea condiționată = Kupiec + independență, χ^2_2
- Cuantila dinamică (DQ, Engle & Manganelli (2004)): regresia lui $I_t - \alpha$ pe o constantă, patru valori întârziate ale indicatorului de depășire și VaR_t ; statistica Wald $\sim \chi^2_6$
- S&P 500: hibrizii au rata corectă de depășire, dar sînt respinși de testele de independență și DQ; testul DQ respinge toate modelele la 5%
 - ▶ BET: FHS trece ambele teste, hibrizii pică DQ; corect în medie nu înseamnă corect condiționat

Cînd sînt suficiente decilele: VaR 10%



- Rata de depășire a cuantilei de 10% (ținta 10%) pentru HS, FHS și cele trei modele fundamentale
- S&P 500: HS 9,8%, FHS 9,6%; Chronos-2 11,7%, Chronos-Bolt 13,5%, TimesFM-2.5 12,0%
- Kupiec respinge modelele fundamentale în opt din nouă cazuri: coada stîngă este plasată prea sus, prin poziție, scală sau forma cozii
- Motiv plauzibil: corpusurile de pre-antrenare sînt dominate de serii mai netede; ca filtre de volatilitate în FHS, modelele preiau cozile din date

Calibrarea întregii distribuții: PIT



- PIT (transformarea integrală a probabilității) $u_t = \hat{F}_t(r_t)$: i.i.d. uniformă dacă distribuția predictivă este corectă (Diebold, Gunther & Tay (1998)); bare: frecvența observată raportată la cea așteptată în cele 22 de intervale ale grilei Chronos-2
- Testul Berkowitz (Berkowitz (2001)) pentru $\mu = 0, \sigma = 1$ al lui $\Phi^{-1}(u_t)$, censurat în afara [1%, 99%]: Chronos-2 respins pe S&P 500 ($p = 0,019, \hat{\sigma} = 1,03$) și pe BET; FHS niciodată
- Scorul cuantic QS = $\frac{2}{K} \sum_k (1\{r_t < q_{u_k}\} - u_k)(q_{u_k} - r_t)$, un analog pe grilă al CRPS (Gneiting & Raftery (2007)): Chronos-2 mai slab decât FHS în centru și în cozi (S&P 500 DM +2,51, +3,65); tabelul în [▶ Anexă](#)

Compararea prognozelor (VaR 2,5%, ES 2,5%): MCS

HS	0.140	0.343	0.015
GARCH-t	0.187	0.597	0.341
FHS	1.000	0.597	1.000
Chronos-2 quantiles	0.140	0.641	0.239
FHS + Chronos-2 volatility	0.140	1.000	0.341
FHS + TimesFM volatility	0.183	0.704	0.202
	S&P 500	Bitcoin	BET

- Valorile p ale mulțimii de modele de încredere de 90% (Hansen, Lunde & Nason (2011)) pentru pierderea FZ0; verde: păstrat, roșu: eliminat; tabelul FZ0 în [Anexă](#)
- S&P 500: FHS are cea mai mică FZ0; hibridii au rata corectă de depășire, dar depășiri grupate și un VaR mai mare (3,20% față de 2,78%)
- MCS elimină doar HS pe BET; testul DM pe perechi este mai precis: FHS bate hibridul Chronos-2 pe S&P 500 (DM +2,65, $p = 0,008$) și pe BET (DM +2,36)

După publicare: puține depășiri, putere mică

Depășiri după 3.11.2025	HS	GARCH-t	FHS	Cuantile Chronos-2	FHS + vol. Chronos-2	FHS + vol. TimesFM
S&P 500 (220 de zile)	0	2	2	2	2	2
Bitcoin (320 de zile)	3	3	4	4	3	4
BET (217 zile)	4	4	4	5	1	2


- Depășiri așteptate: 2,2 (S&P 500), 3,2 (Bitcoin), 2,2 (BET): contaminarea nu este posibilă, dar testele au putere mică
 - ▶ Testul Kupiec bilateral exact la 5% față de o rată reală de 1,67%: puterea 0,19 la $T = 220$, nivelul efectiv 0,13; 0,50 la $T = 1000$; 0,87 la $T = 2693$
 - ▶ Puterea de 80% prima dată la circa 2 130 de zile (8,4 ani), definitiv de la 2 320; față de 2%: puterea 0,29 la $T = 220$ (Seminarul, A8–A9)
- Putere mică nu înseamnă putere zero: HS are 0 depășiri pe S&P 500, iar $x = 0$ este în regiunea de respingere Kupiec la $T = 220$; o nerespingere nu dovedește calibrarea

Recalibrarea cuantilelor: inferența conformală adaptivă

- ▣ Scorul $E_t = \hat{q}_{\alpha,t} - r_t$; cuantila corectată $\hat{q}_{\alpha,t} - \hat{Q}_{1-\alpha_t}$, cu $\hat{Q}$ cuantila empirică $(1 - \alpha_t)$ a ultimelor 250 de scoruri
- ▣ Nivelul adaptiv (Gibbs & Candès (2021)): $\alpha_{t+1} = \alpha_t + \gamma(\alpha - \text{err}_t)$, $\text{err}_t = 1\{r_t < \hat{q}_{\alpha,t} - \hat{Q}_{1-\alpha_t}\}$, $\alpha_1 = \alpha$, $\gamma = 0,001$;
 $\gamma = 0$: conformal simplu
 - ▶ După o depășire α_t scade (următorul VaR este mai larg); după o zi calmă crește încet
- ▣ Garanție valabilă pentru orice secvență, fără ipoteze de model: $\left| \frac{1}{T} \sum_t \text{err}_t - \alpha \right| \leq \frac{\max(\alpha_1, 1 - \alpha_1) + \gamma}{\gamma T}$, doar o afirmație pe termen lung
- ▣ ES 2,5%: ES Chronos-2 deplasat cu corecția VaR 2,5%, o euristică fără garanție conformală; regulile și tabelul complet în

▶ Anexă

VaR 1% conformal adaptiv pe S&P 500



- Sus: nivelul adaptiv α_t (ținta 1%); jos: VaR 1% Chronos-2 direct, Chronos-2 cu ACI (inferență conformală adaptivă), FHS (scară logaritmică)
- ACI aduce depășirile aproape de 1% (S&P 500: 21 față de 24,4 așteptate); acoperirea condiționată nu este respinsă pe nicio piață
- DQ încă respinge pe S&P 500 și BET; VaR-ul este mai larg (3,36% față de 2,85% pentru FHS), iar FZ0 semnificativ mai mare
- Regulile de scor proprii recompensează concentrarea sub constrângerea calibrării ([Gneiting & Raftery \(2007\)](#)): calibrarea este necesară, nu suficientă

Studiu de caz: ajută complexitatea în prognoza randamentelor?

▣ Întrebările (Kelly, Malamud & Zhou (2024))

- ▶ trebuie ca un model de prognoză a randamentelor să aibă mult mai puțini parametri P decât observații T ?
- ▶ pot modelele cu complexitatea $c = P/T > 1$ să ofere prognoze mai bune în afara eșantionului?

▣ Cadrul (ec. 1–2): $R_{t+1} = f(G_t) + \varepsilon_{t+1}$, cu f necunoscută, aproximată printr-o rețea largă cu un strat ascuns, $\sum_{i=1}^P S_{i,t}\beta_i$ (aproximarea universală, Hornik, Stinchcombe & White (1989))

▣ Legătura cu Testul 1: pe S&P 500 și Bitcoin niciun model nu bate semnificativ prognoza zero; lucrarea întreabă dacă un R^2 negativ în afara eșantionului înseamnă lipsa valorii economice

- ▶ Valoarea economică: raportul Sharpe al randamentului strategiei de ajustare a expunerii la piață (market timing)
 $\pi_t R_{t+1}$, cu poziția $\pi_t = \hat{\beta}' S_t$ (ec. 6)

▣ Teoria (Secțiunile III–IV): în ipotezele lucrării, pentru un model greșit specificat, cu penalizarea ridge aleasă optim, R^2 așteptat în afara eșantionului și raportul Sharpe al strategiei cresc cu c

- ▶ Aproape de $c = 1$ (pragul de interpolare), metoda celor mai mici pătrate ajustează exact datele de antrenare și varianța explodează; dincolo de prag, rezultatele se îmbunătățesc din nou

▣ De ce contează: un argument teoretic pentru modelele mari din acest capitol, împotriva regulii parcimoniei din econometria clasică

Studiu de caz: date și metodă

- **Date** (Secțiunea V.A): randamentul lunar în exces al indicelui CRSP ponderat cu capitalizarea; cei 15 predictorii din [Welch & Goyal \(2008\)](#) (14 variabile și randamentul întârziat al pieței), 1926–2020
 - ▶ Randamentele sînt scalate cu volatilitatea lor din ultimele 12 luni, predictorii cu abaterea standard calculată pe o fereastră cu început fix și lungime crescătoare; după 36 de luni de inițializare, eșantionul începe în 1930
- **Trăsăturile Fourier aleatoare** (ec. 20, [Rahimi & Recht \(2007\)](#)): $S_{i,t} = (\sin(\gamma \omega_i' G_t), \cos(\gamma \omega_i' G_t))'$, $\omega_i \sim N(0, I)$, $\gamma = 2$
 - ▶ O rețea cu două straturi și multe unități ascunse; ponderile primului strat ω_i sînt generate aleator și rămîn fixe, iar ponderile de ieșire β sînt estimate
- **Ridge** (Secțiunea II.A): $\hat{\beta}(z) = (zI + T^{-1} \sum_t S_t S_t')^{-1} T^{-1} \sum_t S_t R_{t+1}$, fără termen liber; $z \rightarrow 0^+$: soluția fără penalizare (pseudo-inversa)
- **Designul** (Secțiunea V.C): ferestre mobile de $T = 12, 60, 120$ luni; P de la 2 la 12 000; $\log_{10} z = -3, \dots, 3$; rezultate mediate pe 1 000 de extrageri independente ale trăsăturilor
- **Evaluarea**: R^2 în afara eșantionului = $1 - \text{Var}(\text{eroare}) / \text{Var}(R)$ (nota 40; teoria împarte MSE la $E[R^2]$, prognoza zero din Testul 1); raportul Sharpe anualizat; alfa și raportul de informație (alfa împărțit la volatilitatea reziduală) din regresia randamentului strategiei în funcție de randamentul pieței
 - ▶ Reperul: regresia liniară „kitchen sink”, cu toți cei 15 predictorii (Secțiunea V.D)


Studiu de caz: rezultatele principale

Model ($T = 12$)	R^2 (%)	Sharpe [t]	Raport inf. [t]	Pierdere max.	Asimetrie
Liniar, $z = 0^+$	< -100	$-0,11 [-1,0]$	$-0,16 [-1,6]$	98,5	$-0,9$
Liniar, $z = 10^3$	$-3,8$	$0,46 [4,4]$	$0,33 [3,1]$	2,4	$-0,1$
RFF, $c = 1\,000$, $z = 10^3$	$0,6$	$0,47 [4,5]$	$0,31 [2,9]$	1,2	2,5

Sursa: Tabelul I, Panoul A, din lucrare; raportul de informație față de piață; pierderea lunară maximă în abateri standard


- Kitchen sink fără penalizare ($P = 15 > T = 12$): R^2 sub -100% , raportul Sharpe $-0,11$
 - Interpretare: la pragul de interpolare prognozele explodează, ceea ce reproduce verdictul negativ din [Welch & Goyal \(2008\)](#)
- Aceiași predictorii cu $z = 10^3$: $R^2 = -3,8\%$, dar raportul Sharpe $0,46$ ($t = 4,4$)
 - Interpretare: R^2 penalizează scala prognozelor; profitul sincronizării depinde de corelația lor cu randamentele (nota 5)
- RFF, $c = 1\,000$: raport de informație $0,26$ ($t = 2,5$) față de cel mai bun model liniar; cu $T = 60$ și 120 , $0,25$ și $0,24$ față de piață ($t = 2,3$ și $2,2$; Panourile B–C)
 - Interpretare: neliniaritatea extrage mai mult din aceiași predictorii, cu o pierdere maximă mai mică și asimetrie pozitivă
- Pozițiile (Figura 10) sînt aproape mereu de cumpărare; expunerea scade înainte de 14 din cele 15 recesiuni NBER, în afara eșantionului
 - Interpretare: modelul învață singur restricția de semn din [Campbell & Thompson \(2008\)](#)

Studiu de caz: complexitatea pe datele cursului



- Figurile 7–8 din Kelly, Malamud & Zhou (2024) pe datele cursului: randamentele în exces ale SPY, 7 predictor, 354 de luni de test (februarie 1997–august 2026); $T = 12$, $\gamma = 2$, 1 000 de extrageri; întreruptă: $c = 1$; punctată: liniar, $z = 10^3$
- Aproape fără penalizare ($z = 10^{-3}$): $R^2 = -1842\%$ la $c = 1$, apoi revine la $-16,6\%$ la $c = 1000$: double descent-ul din Figura 7 (panoul din stînga limitat la -60%)
- $z = 10^3$: raportul Sharpe 0,14 la $c = 1$, 0,26 la $c = 30$, 0,08 la $c = 1000$ ($t = 0,5$); liniar cu $z = 10^3$: Sharpe 0,32 ($t = 1,7$), nedepășit de RFF (raport de informație $-0,17$)
- Interpretare: complexitatea ajută pînă la $c \approx 30$, nu pînă la $c = 1000$, cu 7 din cei 15 predictor și 29,5 ani

Studiu de caz: expunerea și recesiunile



- Figura 10 din Kelly, Malamud & Zhou (2024) pe datele cursului: poziția $\hat{\beta}'S_t$ pentru RFF cu $c = 1000, z = 10^3$; umbrit: recesiunile NBER (FRED USREC); roșu: media mobilă pe 6 luni
- Poziții de cumpărare în 72% din luni, poziția medie 0,13: o primă de risc pozitivă învățată fără restricție de semn
- Poziția medie 0,07 în cele 6 luni dinaintea celor 3 recesiuni și $-0,01$ în timpul lor, față de 0,15 în rest; șocul pandemic din 2020 nu este anticipat
- Trei recesiuni permit doar o descriere, nu un test: lucrarea are 15 recesiuni și 90 de ani

Studiu de caz: limite și o întrebare deschisă

▣ Limitele indicate de autori

- ▶ Teoria acoperă modele ridge liniare pe trăsături aleatoare fixe și un singur activ; extinderea la un panel care ține cont de covarianțele dintre active rămîne deschisă (Introducerea, nota 2)
- ▶ Predictibilitatea este distribuită uniform între trăsături (Ipoteza 4); modelele cu selecție de variabile, de tip LASSO, sînt lăsate pentru cercetări viitoare (nota 22)
- ▶ Nu există un grad optim de neliniaritate γ ; randamentele medii ale strategiei sînt de circa două ori mai mici în 1975–2020 decît în 1930–1974 (Secțiunea V.F)

▣ Datele cursului (Seminarul, C3): 7 din cei 15 predictori și circa 30 de ani; puterea unui test bilateral la 5% pentru un raport de informație de 0,31 este de doar circa 39% ($t \approx 0,31\sqrt{29,5} \approx 1,7$)

▣ Întrebare deschisă: trăsături învățate în locul celor aleatoare, reprezentările interne (embeddings) ale unui model fundațional pre-antrenat, precum Chronos-2, ca S_t ; mai este complexitatea o virtute, pe un panel de piețe din datele cursului?


O întrebare deschisă: abilitate sau memorie?

- Testul 2: Chronos-2 zero-shot nu se distinge de log-HAR pe varianța realizată a SPY (QLIKE 0,231 vs 0,234, DM $p = 0,537$)
- Rahimikia, Ni & Wang (2025): pe randamentele zilnice în exces de pe piețele globale, modelele fundamentale gata antrenate sînt slabe zero-shot și după fine-tuning; modelele pre-antrenate de la zero pe date financiare cîștigă
- Lopez-Lira, Tang & Zhu (2025): odată ce un model a văzut valorile realizate, abilitatea lui de prognoză contrafactuală nu este identificată; memorarea detectată este doar o limită inferioară (demonstrat pentru LLM-uri; logica se aplică oricărui model pre-antrenat)
- Întrebări deschise
 - ▶ rezultatele comparabile reflectă învățarea structurii (memorie lungă, revenire la medie) sau memorarea perioadei de test?
 - ▶ poate o fereastră scurtă de după publicare să le distingă?
- $d_t = L(\hat{h}_t^{FM}, RV_t) - L(\hat{h}_t^{\log HAR}, RV_t)$; memorarea implică $E[d_t \mid \text{după}] > E[d_t \mid \text{înainte}]$; H_0 : egalitate; o respingere poate reflecta și o schimbare de regim

Bucula descoperirii în cinci pași

- **Literatura:** cereți unui asistent evaluări ale modelelor fundamentale pe date financiare din 2024 încoace; verificați fiecare identificator arXiv și citiți voi documentația corpusului
- **Ipoteze:** predicții care separă memorarea de abilitate: înainte vs după publicare, serii niciodată publice, serii simulate cu aceeași dinamică
- **Date și cod:** din prognozele de volatilitate ale capitolului, diferențialul QLIKE Chronos-2 minus log-HAR, un test înainte/după cu erori HAC și MDE; reproduceți întâi QLIKE log-HAR, 0,234
- **Robustețea,** fixată dinainte: o dată de publicare placebo, cu un an mai devreme, nu trebuie să arate nicio ruptură; seriile simulate nu pot fi memorate
- **Critica:** cereți asistentului să atace „nu există memorare, pentru că testul de după publicare este nesemnificativ”; de așteptat: putere mică și regimuri diferite (prompturi reutilizabile în [▶ Anexă](#))

Mini-studiu de caz: un test fără putere



- Propunere tipică a unui asistent: „paritatea Chronos-2 vine din date memorate, deci avantajul trebuie să dispară după publicare”
- d_t mediu: -0,0050 înainte de 3 nov. 2025 (761 de zile), +0,0038 după (218 zile); schimbarea +0,0088, $t_{HAC} = 1,00$, $p = 0,32$
- $MDE = (z_{0,975} + z_{0,8}) se_{HAC}(\hat{\beta}_1) = 0,0247$: de 4,9 ori diferența dinainte; cu o fereastră de după publicare infinită tot 0,0169
- Interpretare: „nu există memorare” nu este o concluzie; puterea trebuie să vină din secțiunea transversală, nu din așteptarea mai multor zile de după publicare

Capcanele pe care cercetătorul trebuie să le verifice

- **Leakage:** suprapunerea cu pre-antrenarea, scalarea pe tot eșantionul, medii HAR care includ ziua t (Seminarul, B8 reduce QLIKE cu un sfert)
 - ▶ Test: fereastra de după publicare, serii simulate sau private; recalculați prognoza pentru t din date trunchiate la $t - 1$
- **Repere slabe:** comparați cu zero (randamente), log-HAR (volatilitate), FHS (cozi), nu cu un random walk
- **Funcțională greșită:** mediane folosite ca medii (media prognozei / media RV trebuie să fie aproape de 1; mediana Chronos-2: 0,79); decile folosite drept cuantile de 1%
- **Selecția:** seed-uri, contexte și modele alese după ce ați văzut testul; notați fiecare încercare, comparați întregul set cu MCS
- **Inferența greșită:** DM pe modele imbricate, fără control al testelor multiple, acoperire fără independență, „nesemnificativ” raportat fără MDE

Rîndul vostru: un punct de plecare pentru proiect

- Întrebări (acolo unde memorarea este imposibilă)
 - ▶ rezistă abilitatea zero-shot pentru varianța zilnică după publicare?
 - ▶ rezistă ea pe serii simulate?
 - ▶ rezistă ea pe piețe mai puțin acoperite?
- Replicați întâi: QLIKE din capitol pentru log-HAR (0,234) și Chronos-2 (0,231), DM $p = 0,537$, și fereastra de 218 zile de după publicare
- Livrabile
 - ▶ Un calcul de putere preînregistrat; un panel de serii din datele cursului, cu o aproximare a varianței din amplitudinea zilnică și o pierdere robustă la aproximare (Patton (2011))
 - ▶ Teste înainte/după cu date de publicare placebo; MCS pentru toate modelele; o critică de tip recenzent și răspunsul vostru
- Notați fiecare prompt care a influențat o decizie în AI_USE.md; fiecare referință inventată, leakage sau cifră greșită identificată în AI_ERRORS.md, împreună cu testul prin care a fost identificată (șabloane)

Ce folosim și când

Ținta	Modelul de referință	Unde poate ajuta deep learning
Randamente zilnice ale indicilor Volatilitate realizată VaR 1%, ES 2,5%	Proгноza zero log-HAR FHS (filtru GARCH)	Piețe mai puțin eficiente (BET); multe active, multe variabile Proгноze zero-shot pentru mii de serii fără estimare Filtru de volatilitate în FHS sau recalibrare conformală

- ▣ Modelele fundamentale sînt ușor de încercat: fără estimare, o linie de cod, un CPU este suficient
- ▣ Valoarea lor este amploarea (multe serii, fără ajustare), nu precizia pe o singură serie bine studiată

Idei principale

- Porțile LSTM pot atenua dispariția gradientului (cu termenul liber al porții de uitare egal cu 0, gradientul tot dispare); atenția conectează direct momente îndepărtate
- Modelele fundamentale prognozează zero-shot dintr-o fereastră de context și întorc cuantile
- Randamente: nimic nu bate prognoza zero pe piețele mari; volatilitate: modelele fundamentale nu se disting de log-HAR; cozi: folosiți-le doar ca filtre de volatilitate
- Evaluați orice model nou față de un reper puternic și după publicarea ponderilor lui, cu inferența potrivită tipului de comparație: Clark–West pentru modele imbricate, SPA sau Romano–Wolf pentru multe modele, PIT, scoruri cuantile și DQ pentru distribuții

Autoevaluare și ce urmează: Capitolul 15

Întrebări de verificare

- De ce uită o RNN stabilă în ritmul în care scade răspunsul la impuls al unui VAR(1)?
- De ce este $\exp(q_{0,5})$ din log RV o prognoză deplasată sub QLIKE?
- De ce poate un VaR hibrid să treacă testul Kupiec și totuși să piardă comparația FZ0?
- De ce „nesemnificativ după publicare” nu este o dovadă împotriva memorării?

: LLM și analiza sentimentului

- Poate textul citit de un model mare de limbaj să prognozeze randamentele sau volatilitatea?
- Revin aceleași amenințări: look-ahead-ul, memorarea perioadei de test, repere slabe
- Aceleași instrumente: ferestre de după publicare, Clark–West, controlul testelor multiple

Anexă: norme, rază spectrală și explozie

- $\gamma_\varphi \|W\|_2 < 1$ este suficient pentru dispariția geometrică, deci $\gamma_\varphi \|W\|_2 \geq 1$ este necesar pentru explozie (Pascanu, Mikolov & Bengio (2013))
- Raza spectrală ρ : într-o RNN liniară, $\rho(W) > 1$ este necesar pentru explozia exponențială ($\rho(W) = 1$ cu un bloc Jordan dă totuși o creștere polinomială)
 - Cu φ contează jacobienele locale $D_t W$: se poate $\rho(W) = 0$, dar $\rho(DW) > 1$
- VAR stabil: răspunsurile la impuls și gradientii scad ca $\rho(A)^k$, pînă la un factor k^{m-1} dacă A are un bloc Jordan de dimensiune m
- DU_{x_t} este o inovație doar dacă intrările x_t sînt zgomot alb centrat; intrările cu memorie lungă s-ar transmite mai departe prin rețea

Anexă: descreșterea geometrică și cea hiperbolică, ajustate pe date

- Porți constante, valori candidate g_t i.i.d., inițializare în distribuția staționară: $\text{Corr}(c_t, c_{t-k}) = f^k$; ARFIMA cu $0 < d < 1/2$: $\rho_k \sim Ck^{2d-1}$
- Randamentele absolute ale S&P 500 din 2000: ACF 0,289 la decalajul 1, 0,132 la decalajul 50
 - ▶ Descreșterea geometrică cu amplitudine proprie, $\rho_k = \rho_1 f^{k-1}$ (un semnal AR(1) observat cu zgomot), reproduce autocorelațiile la ambele decalaje pentru $f = 0,984$: $b_f = 4,1$, timp de înjumătățire 43 de zile
 - ▶ Acest f implică 0,027 la decalajul 150; datele arată 0,059, de peste două ori mai mult (banda de 95% $\pm 0,024$)
- O poartă constantă $f < 1$ este un filtru cu memorie scurtă; un context lung sau medii lungi explicite, ca în HAR (Testul 2), doar aproximează memoria lungă pe un interval finit de decalaje

Anexă: alte modele fundamentale și corpusurile lor

- Chronos-Bolt: doar nivelurile 10%, 20%, ..., 90%; Chronos-2: corpus de seturi selectate din Chronos și [GIFT-Eval](#) plus serii multivariate sintetice; teste comparative GIFT-Eval ([Aksu et al. \(2024\)](#)) și fev-bench
- Corpusul TimesFM: Google Trends, afișări de pagini Wikipedia, serii sintetice, M4, electricitate, trafic, vreme; TimesFM-2.5 întoarce media plus decile
 - ▶ Datele de publicare a ponderilor, din depozitele Hugging Face: TimesFM-2.5, versiunea actualizată a ponderilor anunțată pe 15.09.2025, publicată pe 01.10.2025; Chronos-2 anunțat pe 20.10.2025, publicat pe 30.10.2025
- **Moirai** ([Woo et al. \(2024\)](#)): orice număr de variabile, ieșire de tip amestec de distribuții; Moirai 2.0 ([Liu et al. \(2025\)](#)); licență necomercială, nu îl folosim în teste
- **Lag-Llama** ([Rasul et al. \(2023\)](#)): model doar cu decodor, cu valori întârziate ca variabile și ieșire Student- t

Anexă: un protocol formal pentru contaminare

- Regresia înainte/după pe diferențialul de pierdere $d_t = L_t^{FM} - L_t^{reper}$: $d_t = \beta_0 + \beta_1 \mathbf{1}\{t \geq \tau\} + u_t$, e.s. HAC
 - ▶ τ : data publicării ponderilor (o dată-limită comună când se compară mai multe modele); memorarea prezice $\beta_1 > 0$; H_0 : $\beta_1 = 0$
 - ▶ Raportați efectul minim detectabil (MDE) al lui β_1 : cu 218 zile de după publicare este de 4,9 ori diferența dinainte (secțiunea AI)
- Preînregistrarea: prognozele depuse înainte ca rezultatul să existe fac contaminarea imposibilă prin construcție
 - ▶ Benchmark-uri live: TS-Arena ([Meyer et al. \(2025\)](#)), Impermanent ([Garza et al. \(2026\)](#)); fereastra noastră de după publicare este o versiune manuală
- Ablații: eliminarea componentei de model de limbaj din prognozele bazate pe LLM nu reduce precizia, adesea o îmbunătățește ([Tan et al. \(2024\)](#))
- Prețurile energiei: [Pan & Ezzat \(2026\)](#) testează pe două seturi de date pentru a limita contaminarea; modelele fundamentale sînt competitive, dar nu bat constant metodele specifice domeniului

Anexă: prognozele randamentelor, tabelul complet

R^2 (%) [DM p]	Media istorică	AR(1)	LSTM (5 seed-uri)	Chronos-2	Chronos-Bolt	TimesFM-2.5
S&P 500	+0,15 [0,095]	+0,94 [0,639]	+0,93 [0,090]	-0,26 [0,418]	-1,57 [0,078]	-3,35 [0,001]
Bitcoin	+0,07 [0,691]	-0,28 [0,326]	+0,04 [0,243]	-0,35 [0,413]	-0,61 [0,070]	-2,29 [0,001]
BET	+0,30 [0,081]	-0,00 [1,000]	+1,15 [0,014]	-0,39 [0,562]	+0,12 [0,831]	-3,27 [0,070]

- Eroarea pătratică vizează media; mediile din grilă ($\int_0^1 q_u du$) sînt și mai slabe, de exemplu pe S&P 500 R^2 -0,77% (Chronos-2), -3,42% (TimesFM-2.5)
- DM: test bilateral pe erorile pătratice față de prognoza zero, varianță Newey–West

Anexă: prognoze imbricate, AR(1) pe BET și ferestre mobile

- AR(1) pe BET, $R^2 = -0,00\%$ și DM $p = 1,000$, nu este o prognoză degenerată: abaterea standard 0,074%, panta medie 0,046
 - ▶ Reducerile erorii pătratice, de -12,7 în 2020 și +14,7 în 2026 se anulează; fără acești doi ani $R^2 = -0,11\%$
- Modele pe ferestre mobile sau reantrenate: [Giacomini & White \(2006\)](#) testează metoda de prognoză, inclusiv fereastra de estimare ([Diebold \(2015\)](#) despre folosirea și abuzul testului DM)
- SPA rafinează Reality Check al lui [White \(2000\)](#): modelele foarte slabe (TimesFM) nu mai diluează testul; ambele folosesc un bootstrap staționar cu bloc mediu de 20 de zile

Anexă: QLIKE, DM și MCS, tabelul complet

Model	QLIKE	DM vs log-HAR	p	MCS p	QLIKE după 3.11.2025
Random walk	0,326	+4,53	<0,001	0,00	0,384
HAR	0,247	+1,30	0,195	0,29	0,270
log-HAR	0,234	–	–	0,95	0,238
GARCH-t	0,283	+3,43	<0,001	0,03	0,295
LSTM	0,284	+1,68	0,094	0,29	0,233
Chronos-2	0,231	-0,62	0,537	1,00	0,242
Chronos-Bolt	0,232	-0,18	0,857	0,95	0,236
TimesFM-2.5	0,233	-0,08	0,938	0,95	0,244

- Literatura: [Brini \(2026\)](#) compară nouă modele fundamentale zero-shot cu opt modele de tip HAR pe 50 de active; pierderile agregate favorizează modelele fundamentale din cauza câtorva active atipice, iar activ cu activ doar un model mic bate log-HAR la toate orizonturile, la limită
- [Goel et al. \(2025\)](#): TimesFM zero-shot este un reper rezonabil; fine-tuning-ul incremental este necesar pentru a bate modelele econometrice

Anexă: depășirile VaR 1% și testele Kupiec, tabelul complet

Depășiri [Kupiec p]	HS	GARCH-t	FHS	Cuantile Chronos-2	FHS + vol. Chronos-2	FHS + vol. TimesFM
S&P 500 (26,9)	37 [0,065]	44 [0,002]	30 [0,559]	45 [0,001]	25 [0,705]	27 [0,989]
Bitcoin (28,2)	19 [0,065]	27 [0,822]	25 [0,539]	33 [0,374]	27 [0,822]	27 [0,822]
BET (26,8)	32 [0,322]	41 [0,010]	30 [0,536]	40 [0,016]	26 [0,884]	32 [0,322]

- În paranteză după piață: numărul așteptat de depășiri, 1% din zile
- Kupiec: test bilateral al raportului de verosimilitate pentru o rată de depășire de 1%, χ_1^2

Anexă: crahul COVID-19, scalarea și reacția excesivă

- Chronos-2 standardizează contextul prin media și abaterea standard, apoi aplică $\sinh^{-1}$ (Ansari et al. (2025)); la 16.03.2020 crahul a mărit abaterea standard a contextului de 512 zile cu 9,7% (scala prin media valorilor absolute din Chronos: 3,2%, Seminarul, A4)
 - Deci lărgirea combină schimbarea scalei cu citirea zilelor de crah; doar o ablație le-ar putea separa
- Nu este o eroare de unități: după ziua crahului Chronos-2 a prognozat o medie a lui $|r|$ de 12,5% pentru ziua următoare, apoi FHS o înmulțește cu cuantila de 1% a lui $r/\hat{\sigma}$ (4,7)
 - Filtrul extrapolează un salt de o zi ca pe un nou nivel: VaR de 4,6 ori pierderea maximă, un cost de capital ridicat pe care pierderea FZ0 îl penalizează

Anexă: testele Berkowitz și scorurile cuantile, trei piețe

Piața	p Berkowitz: Chronos-2	FHS	Sub $q_1\%$ (C2)	QS: C2 / FHS	DM [p]
S&P 500	0,019	0,599	1,67%	0,510 / 0,506	+3,06 [0,002]
Bitcoin	0,595	0,306	1,17%	1,526 / 1,529	-0,90 [0,369]
BET	0,045	0,436	1,50%	0,465 / 0,460	+3,48 [$<0,001$]

- Testul Berkowitz evaluează funcția de repartiție interpolată liniar pe grilă și doar μ, σ , nu independența în timp a PIT
- QS ponderează egal cele 21 de niveluri; CRPS ar pondera fiecare nivel cu distanța dintre niveluri; C2: Chronos-2; egalitate pe Bitcoin

Anexă: pierderile FZ0 și valorile p MCS, tabelul complet

FZ0 [MCS p]	HS	GARCH-t	FHS	Cuantile Chronos-2	FHS + vol. Chronos-2	FHS + vol. TimesFM
S&P 500	1,309 [0,14]	1,026 [0,19]	0,999 [1,00]	1,147 [0,14]	1,084 [0,14]	1,059 [0,18]
Bitcoin	2,237 [0,34]	2,192 [0,60]	2,192 [0,60]	2,181 [0,64]	2,151 [1,00]	2,160 [0,70]
BET	1,230 [0,01]	1,001 [0,34]	0,963 [1,00]	1,032 [0,24]	1,007 [0,34]	1,027 [0,20]

- Bitcoin: FHS hibrid cu volatilitatea Chronos-2 are cea mai mică pierdere FZ0, dar diferențele nu sînt semnificative
- FZ0 pentru (VaR 2,5%, ES 2,5%); MCS folosește statistica $T_{\max}$ și un bootstrap pe blocuri

Anexă: recalibrarea conformală, reguli și rezultate

După 250 de zile de calibrare:					
depășiri [<i>p</i> cc / <i>p</i> DQ]		FHS	Chronos-2 direct	FHS + vol. C2	Chronos-2 + ACI
S&P 500 (24,4)	28 [0,097 / 0,014]	42 [0,002 / <0,001]	23 [0,058 / <0,001]	21 [0,307 / 0,049]	
Bitcoin (25,7)	24 [0,449 / 0,108]	31 [0,410 / 0,026]	26 [0,087 / 0,004]	24 [0,449 / 0,191]	
BET (24,2)	26 [0,709 / 0,727]	36 [0,048 / 0,184]	23 [0,776 / 0,011]	25 [0,762 / 0,032]	
FZ0, S&P 500 [<i>p</i> DM]		1,013	1,142 [0,009]	1,087 [0,022]	1,205 [0,001]

- $\hat{Q}$: al $\lceil (1 - \alpha_t)(250 + 1) \rceil$ -lea cel mai mic scor trecut, $+\infty$ dacă rangul depășește 250 sau $\alpha_t \leq 0$, $-\infty$ dacă $\alpha_t \geq 1$; cu $\gamma = 0,005$: VaR infinit în 24 (S&P 500), 100 (Bitcoin), 270 (BET) zile
- Garanția cu $T = 2443$, $\gamma = 0,001$: limita 0,41, neinformativă pentru o rată de 1%; fără interschimbabilitate, conformalul ponderat limitează abaterea produsă de drift ([Barber et al. \(2023\)](#))
- Comparățiile ES sînt și mai dificile: limite de precizie în eșantioane finite ([Pele & Mazurencu-Marinescu-Pele \(2026\)](#)); ES se poate testa împreună cu VaR ([Nolde & Ziegel \(2017\)](#)); o coadă GPD ([McNeil & Frey \(2000\)](#)) este o alternativă pentru ES

Anexă: studiul de caz, replicarea cu datele cursului

- Randamentele totale lunare ale SPY din 1993 (datele cursului), în exces față de randamentul titlurilor de stat americane la 3 luni (FRED TB3MS)
 - ▶ Predictorii din [Welch & Goyal \(2008\)](#) disponibili: dobînda la titlurile de stat pe termen scurt ($tb1$), randamentul pe termen lung (lty), panta curbei (tms), spread-ul de credit (dfy), inflația ($infl$), toate din FRED; varianța acțiunilor ($svar$) din randamentele zilnice ale S&P 500; randamentul în exces întârziat: 7 din cei 15
 - ▶ Limitarea datelor: rapoartele de evaluare (dividend/preț dp , randamentul dividendului dy , câștig/preț ep , rata de distribuire de , valoare contabilă/de piață b/m), emisiunile nete de acțiuni ($ntis$) și randamentele obligațiunilor (pe termen lung ltr , spread-ul randamentelor corporative dfr) nu sînt în datele cursului; circa 30 de ani în loc de 90
 - ▶ Metoda rămîne aceeași: $\gamma = 2$, $T = 12$, $P \leq 12\,000$, $\log_{10} z = -3, \dots, 3$, 1 000 de extrageri
- Rezultatele pe datele cursului: kitchen sink liniar, $z = 0^+$ ($c = 7/12$): $R^2 = -1\,540\%$, Sharpe $-0,06$; liniar, $z = 10^3$: $R^2 = 0,26\%$, raport de informație $0,25$ ($t = 1,3$) față de SPY; RFF, $c = 1\,000$: $R^2 = -6,5\%$, raport de informație $-0,17$ ($t = -0,9$)

Anexă: bucla descoperirii, prompturi reutilizabile (1/2)

- **Literatura:** "Găsește evaluări ale modelelor fundamentale pentru serii de timp pe randamente sau volatilitate financiară din 2024 încoace: modele, date, pierdere, reper și dacă perioada de test se suprapune cu corpusul de pre-antrenare."
 - ▶ Semantic Scholar, Google Scholar, Elicit ajută la căutare
- **Ipoteze:** "Enumeră predicțiile care separă memorarea de abilitate pentru un model zero-shot de volatilitate: înainte vs după publicare, serii niciodată publice, serii simulate cu aceeași dinamică."
 - ▶ Diagnostiche, nu dovezi: o traiectorie log-HAR simulată testează transferul la acel proces; o diferență înainte/după poate reflecta și o schimbare de regim
- **Date și cod:** "Din prognozele zilnice ale varianței realizate SPY date de Chronos-2 și log-HAR, calculează diferențialul QLIKE Chronos-2 minus log-HAR, testează înainte vs după 3 noiembrie 2025 cu erori HAC și raportează efectul minim detectabil la o putere de 80%."
 - ▶ Orice asistent (Claude, ChatGPT, Gemini, GitHub Copilot)

Anexă: bucla descoperirii, prompturi reutilizabile (2/2)

- ▣ **Robustețea:** "Proiectează un test preînregistrat cu putere mai mare: ce secțiune transversală de serii, ce aproximare a varianței, ce test DM pe panel și câte zile de după publicare."
- ▣ **Critica:** "Atacă afirmația: nu există memorare, pentru că testul DM de după publicare este nesemnificativ. Ce este greșit în inferență?"
 - ▶ De așteptat: putere mică, absența dovezii și regimuri diferite: șocul tarifar din aprilie 2025 este în eșantionul dinaintea publicării, fereastra de după publicare este mai calmă
- ▣ **Raportul:** versiunile modelelor și datele publicării ponderilor, lungimea contextului, media sau mediana, fiecare seed și fereastră încercată

Anexă: lecturi suplimentare

- ▣ Gu, Kelly & Xiu (2020): machine learning pentru secțiunea transversală a randamentelor așteptate
- ▣ Kelly, Malamud & Zhou (2024): de ce modelele foarte mari pot prognoza mai bine randamentele
- ▣ Ansari et al. (2024): Chronos, seriile de timp citite ca un limbaj
- ▣ Aplicații pe criptoactive: prognoza lichidității Agakishiev, Härdle & Pele (2025), avertizare timpurie pentru criptoactivele „zombie” Będowska-Sójka, Wójcik & Pele (2026), clasificarea statistică a criptoactivelor Pele et al. (2023)
- ▣ Manuale: Franke, Härdle & Hafner (2019) și Härdle, Chen & Overbeck (2017) pentru statistica piețelor financiare din spatele modelelor de referință

Bibliografie (1/7)

- ▣ Agakishiev, I., Härdle, W.K., Pele, D.T. (2025). [Cryptocurrency liquidity forecasting](#). In *Springer Handbooks of Computational Statistics*, 41–60. Springer.
- ▣ Aksu, T., Woo, G., Liu, J., Liu, X., Liu, C., Savarese, S., Xiong, C., Sahoo, D. (2024). [GIFT-Eval: a benchmark for general time series forecasting model evaluation](#). [arXiv:2410.10393](#).
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Labys, P. (2003). [Modeling and forecasting realized volatility](#). *Econometrica*, 71(2), 579–625.
- ▣ Ansari, A.F., Shchur, O., Küken, J., Auer, A., et al. (2025). [Chronos-2: from univariate to universal forecasting](#). [arXiv:2510.15821](#).
- ▣ Ansari, A.F., Stella, L., Turkmen, C., Zhang, X., et al. (2024). [Chronos: learning the language of time series](#). *Transactions on Machine Learning Research*; [arXiv:2403.07815](#).
- ▣ Barber, R.F., Candès, E.J., Ramdas, A., Tibshirani, R.J. (2023). [Conformal prediction beyond exchangeability](#). *Annals of Statistics*, 51(2), 816–845.
- ▣ Będowska-Sójka, B., Wójcik, P., Pele, D.T. (2026). [Early warning systems for cryptocurrency markets: predicting ‘zombie’ assets using machine learning](#). *North American Journal of Economics and Finance*, 81, 102543.
- ▣ Bengio, Y., Simard, P., Frasconi, P. (1994). [Learning long-term dependencies with gradient descent is difficult](#). *IEEE Transactions on Neural Networks*, 5(2), 157–166.
- ▣ Berkowitz, J. (2001). [Testing density forecasts, with applications to risk management](#). *Journal of Business & Economic Statistics*, 19(4), 465–474.
- ▣ Brini, A. (2026). [Forecasting realized volatility with time series foundation models: a comparison with econometric benchmarks](#). [arXiv:2607.05291](#).

Bibliografie (2/7)

- ▣ Campbell, J.Y., Thompson, S.B. (2008). Predicting excess stock returns out of sample: can anything beat the historical average? *Review of Financial Studies*, 21(4), 1509–1531.
- ▣ Christoffersen, P.F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- ▣ Clark, T.E., West, K.D. (2007). Approximately normal tests for equal predictive accuracy in nested models. *Journal of Econometrics*, 138(1), 291–311.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Das, A., Kong, W., Sen, R., Zhou, Y. (2024). A decoder-only foundation model for time-series forecasting. *Proceedings of ICML*, PMLR 235; arXiv:2310.10688.
- ▣ Diebold, F.X. (2015). Comparing predictive accuracy, twenty years later: a personal perspective on the use and abuse of Diebold–Mariano tests. *Journal of Business & Economic Statistics*, 33(1), 1.
- ▣ Diebold, F.X., Gunther, T.A., Tay, A.S. (1998). Evaluating density forecasts with applications to financial risk management. *International Economic Review*, 39(4), 863–883.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- ▣ Fischer, T., Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), 654–669.

Bibliografie (3/7)

- ▣ Fissler, T., Ziegel, J.F. (2016). Higher order elicibility and Osband's principle. *Annals of Statistics*, 44(4), 1680–1707.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Garza, A., Rosillo, R., Mendoza-Smith, R., Salinas, D., Williams, A.R., Ashok, A. (2026). Impermanent: a live benchmark for temporal generalization in time series forecasting. [arXiv:2603.08707](https://arxiv.org/abs/2603.08707).
- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Gibbs, I., Candès, E. (2021). Adaptive conformal inference under distribution shift. *NeurIPS*; [arXiv:2106.00170](https://arxiv.org/abs/2106.00170).
- ▣ Gneiting, T. (2011). Making and evaluating point forecasts. *Journal of the American Statistical Association*, 106(494), 746–762.
- ▣ Gneiting, T., Raftery, A.E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378.
- ▣ Goel, A., Pasricha, P., Magris, M., Kannianen, J. (2025). Foundation time-series AI model for realized volatility forecasting. [arXiv:2505.11163](https://arxiv.org/abs/2505.11163).
- ▣ Gu, S., Kelly, B., Xiu, D. (2020). Empirical asset pricing via machine learning. *Review of Financial Studies*, 33(5), 2223–2273.
- ▣ Hansen, P.R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4), 365–380.

Bibliografie (4/7)

- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). [The model confidence set](#). *Econometrica*, 79(2), 453–497.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (eds.) (2017). [Applied Quantitative Finance](#), 3rd ed. Springer.
- ▣ Hochreiter, S., Schmidhuber, J. (1997). [Long short-term memory](#). *Neural Computation*, 9(8), 1735–1780.
- ▣ Hornik, K., Stinchcombe, M., White, H. (1989). [Multilayer feedforward networks are universal approximators](#). *Neural Networks*, 2(5), 359–366.
- ▣ Kelly, B., Malamud, S., Zhou, K. (2024). [The virtue of complexity in return prediction](#). *Journal of Finance*, 79(1), 459–503.
- ▣ Kingma, D.P., Ba, J. (2015). [Adam: a method for stochastic optimization](#). *ICLR*; arXiv:1412.6980.
- ▣ LeCun, Y., Bengio, Y., Hinton, G. (2015). [Deep learning](#). *Nature*, 521(7553), 436–444.
- ▣ Liu, C., Aksu, T., Liu, J., Liu, X., et al. (2025). [Moirai 2.0: when less is more for time series forecasting](#). arXiv:2511.11698.
- ▣ Lo, A.W., MacKinlay, A.C. (1990). [An econometric analysis of nonsynchronous trading](#). *Journal of Econometrics*, 45(1–2), 181–211.
- ▣ Lopez-Lira, A., Tang, Y., Zhu, M. (2025). [The memorization problem: can we trust LLMs' economic forecasts?](#) arXiv:2504.14765.

Bibliografie (5/7)

- ▣ McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- ▣ Meyer, M., Kaltenpoth, S., Albers, H., Zalipski, K., Müller, O. (2025). TS-Arena: a live forecast pre-registration platform. arXiv:2512.20761.
- ▣ Nie, Y., Nguyen, N.H., Sinthong, P., Kalagnanam, J. (2023). A time series is worth 64 words: long-term forecasting with Transformers. *ICLR*; arXiv:2211.14730.
- ▣ Nolde, N., Ziegel, J.F. (2017). Elicitability and backtesting: perspectives for banking regulation. *Annals of Applied Statistics*, 11(4), 1833–1874.
- ▣ Oreshkin, B.N., Carpov, D., Chapados, N., Bengio, Y. (2020). N-BEATS: neural basis expansion analysis for interpretable time series forecasting. *ICLR*; arXiv:1905.10437.
- ▣ Pan, Z., Ezzat, A.A. (2026). Evaluating time series foundation models for electricity price forecasting: contamination risk, distributional shifts, and covariate dependence. arXiv:2607.02623.
- ▣ Pascanu, R., Mikolov, T., Bengio, Y. (2013). On the difficulty of training recurrent neural networks. *ICML*; arXiv:1211.5063.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.

Bibliografie (6/7)

- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). *Are cryptos becoming alternative assets?* *The European Journal of Finance*, 29(10), 1064–1105.
- ▣ Rahimi, A., Recht, B. (2007). *Random features for large-scale kernel machines.* *Advances in Neural Information Processing Systems*, 20.
- ▣ Rahimikia, E., Ni, H., Wang, W. (2025). *Re(Visiting) time series foundation models in finance.* arXiv:2511.18578.
- ▣ Rasul, K., Ashok, A., Williams, A.R., Ghonia, H., et al. (2023). *Lag-Llama: towards foundation models for probabilistic time series forecasting.* arXiv:2310.08278.
- ▣ Romano, J.P., Wolf, M. (2005). *Stepwise multiple testing as formalized data snooping.* *Econometrica*, 73(4), 1237–1282.
- ▣ Rumelhart, D.E., Hinton, G.E., Williams, R.J. (1986). *Learning representations by back-propagating errors.* *Nature*, 323(6088), 533–536.
- ▣ Salinas, D., Flunkert, V., Gasthaus, J., Januschowski, T. (2020). *DeepAR: probabilistic forecasting with autoregressive recurrent networks.* *International Journal of Forecasting*, 36(3), 1181–1191.
- ▣ Tan, M., Merrill, M.A., Gupta, V., Althoff, T., Hartvigsen, T. (2024). *Are language models actually useful for time series forecasting?* *NeurIPS*; arXiv:2406.16964.
- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., et al. (2017). *Attention is all you need.* *NeurIPS*; arXiv:1706.03762.
- ▣ Welch, I., Goyal, A. (2008). *A comprehensive look at the empirical performance of equity premium prediction.* *Review of Financial Studies*, 21(4), 1455–1508.

Bibliografie (7/7)

- White, H. (2000). [A reality check for data snooping](#). *Econometrica*, 68(5), 1097–1126.
- Woo, G., Liu, C., Kumar, A., Xiong, C., Savarese, S., Sahoo, D. (2024). [Unified training of universal time series forecasting Transformers](#). *ICML*; arXiv:2402.02592.