



Modelarea piețelor financiare

Capitolul 14: Deep learning și modele fundamentale pentru serii de timp



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model) (model autoregresiv)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- CI: Confidence Interval (interval de încredere)
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- CPU: Central Processing Unit (procesorul central al calculatorului)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ES: Expected Shortfall (pierderea așteptată în coadă)
- FHS: Filtered Historical Simulation (simulare istorică filtrată)
- FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GIFT: General Time Series Forecasting Model Evaluation (benchmark GIFT-Eval) (bancul de testare GIFT-Eval pentru evaluarea modelelor generale de prognoză a seriilor de timp)
- GRU: Gated Recurrent Unit (unitate recurentă cu porți)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- HS: Historical Simulation (simulare istorică)
- LLM: Large Language Model (model lingvistic mare)
- LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- MCS: Model Confidence Set (mulțimea de modele de încredere)
- MDE: Minimum Detectable Effect (efectul minim detectabil)
- MLP: MultiLayer Perceptron (perceptron multistrat)
- MSE: Mean Squared Error (eroarea pătratică medie)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- RNN: Recurrent Neural Network (rețea neuronală recurentă)
- RV: Realised Variance (varianța realizată)
- SUA: Statele Unite ale Americii

Cuprins

De ce deep learning pentru serii financiare?

De la perceptron la rețele profunde

Rețelele recurente și LSTM

Atenția și Transformer

Modele fundamentale pentru serii de timp

Testul 1: prognoza randamentelor

Testul 2: prognoza volatilității realizate

Testul 3: VaR 1% și ES 2,5%


AI pentru descoperire științifică

Practică și concluzii

Bibliografie

Promisiunea și întrebarea

- ▣ **Deep learning** (învățare profundă): modele construite din multe straturi de unități neliniare simple, antrenate pe date
 - ▶ A transformat recunoașterea imaginilor și prelucrarea limbajului
 - ▶ Din 2024: **modele fundamentale** pentru serii de timp, pre-antrenate pe miliarde de observații
- ▣ Întrebarea acestui capitol
 - ▶ Prognozează aceste modele **randamentele, volatilitatea** și **riscul de coadă** mai bine decât modelele clasice din capitolele 5–9?
 - ▶ Răspundem cu instrumentele de evaluare din Capitolul 8




Un centru de date: rețelele profunde se antrenează pe rafturi de astfel de servere

Foto: [BalticServers.com](https://www.balticServers.com) (2013); CC BY-SA 3.0; [Wikimedia Commons](https://commons.wikimedia.org/wiki/File:Server_Rack)

Trei ținte de prognoză

- ▣ **Randamentele** r_t (media condiționată)
 - ▶ Raport semnal-zgomot foarte mic; tiparele previzibile dispar prin tranzacționare (Capitolul 2)
- ▣ **Volatilitatea** (varianța condiționată)
 - ▶ Persistentă și grupată (capitolele 1 și 5): există un semnal de învățat
- ▣ **Cuantilele cozii**: VaR 1% și ES 2,5%
 - ▶ Cer forma cozii stângi, nu doar centrul distribuției (Capitolul 7)
- ▣ Fiecare țintă are propria funcție de pierdere și propriul model de referință

Unde este semnalul?



- Randamentele zilnice ale S&P 500 din 2000 (6718 zile): autocorelația la decalajele 1–50
- Banda gri: intervalul de 95% sub independență, $\pm 1,96/\sqrt{T} = \pm 0,024$

Interpretare: media versus mărimea mișcărilor

- ▣ Randamentele: autocorelația de ordinul 1 este -0,099
 - ▶ 15 din 50 de decalaje ies din bandă, dar sunt mici și cu semn schimbător: puțin de învățat despre medie
- ▣ Randamentele absolute: autocorelația este 0,29 la decalajul 1 și încă 0,13 la decalajul 50
 - ▶ Toate cele 50 decalaje ies din bandă: grupare a volatilității cu memorie lungă
- ▣ Predicția pentru restul capitolului: orice model flexibil poate găsi semnalul de volatilitate; niciunul nu ar trebui să găsească mult în medie

Ce facem în acest capitol


- ▣ De la perceptron la rețele profunde: neuroni, straturi, antrenare
- ▣ Rețelele recurente și LSTM: de ce memoria este greu de învățat
- ▣ Atenția și Transformerile: patch-uri, poziții, ieșiri de tip cuantilă
- ▣ Modele fundamentale: Chronos, TimesFM, Moirai; utilizarea zero-shot și scurgerea de informație prin pre-antrenare
- ▣ Trei teste empirice: randamente, volatilitate realizată, VaR 1% și ES 2,5%

Recapitularea secțiunii

- ▣ Trei ținte cu rapoarte semnal-zgomot foarte diferite: media, volatilitatea, coada
- ▣ Randamentele absolute sunt puternic autocorelate, randamentele nu
- ▣ Orice model nou este judecat față de un reper simplu, cu testele din Capitolul 8

Perceptronul (1958)

- **Neuronul artificial:** suma ponderată a intrărilor plus o deplasare, trecută printr-o funcție de activare
 - ▶ $a = \varphi(w^T x + b)$
 - ▶ w : ponderi, b : deplasare (bias), φ : funcție de activare (neliniară)
- **Rosenblatt (1958):** perceptronul învață w din exemple etichetate
 - ▶ Construit ca aparat: Mark I Perceptron (fotografia)
 - ▶ Un singur strat separă clasele doar printr-o dreaptă (hiperplan)



Mark I Perceptron, Cornell Aeronautical Laboratory

Foto: J.C. Hay, A.E. Murray (1960); domeniu public; [Wikimedia](#)

[Commons](#)

Perceptronul multistrat (MLP)

- ▣ Straturi aplicate unul după altul: $h^{(\ell)} = \varphi(W^{(\ell)}h^{(\ell-1)} + b^{(\ell)})$, $h^{(0)} = x$
 - ▶ $h^{(\ell)}$: starea ascunsă a stratului ℓ ; ultimul strat este liniar pentru regresie
- ▣ Funcții de activare uzuale
 - ▶ ReLU (unitate liniară rectificată): $\max(0, z)$
 - ▶ $\tanh(z) \in (-1, 1)$; sigmoida $\sigma(z) = 1/(1 + e^{-z}) \in (0, 1)$
- ▣ **Aproximare universală** (Hornik, Stinchcombe & White (1989)): un strat ascuns cu suficiente unități aproximează orice funcție continuă
 - ▶ Nu spune nimic despre câte date sunt necesare: problema-cheie în finanțe

Antrenarea unei rețele

- ▣ Pierderea: eroarea pătratică medie (MSE) $\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2$ pentru prognoze punctuale; pierderea cuantilă (pinball) pentru cuantile
- ▣ **Propagarea înapoi** (Rumelhart, Hinton & Williams (1986)): regula lanțului dă gradientul pierderii în raport cu fiecare pondere
- ▣ **Coborârea pe gradient**: $\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$, rata de învățare η
 - ▶ Mini-loturi: gradientul pe o submulțime aleatoare de exemple; **epocă**: o trecere prin toate datele
 - ▶ Adam (Kingma & Ba (2015)): pași adaptați pentru fiecare parametru din momentele curente ale gradientului

Supraajustarea și cum o combate deep learning

- ▣ Rețelele au mulți parametri în raport cu eșantioanele financiare
 - ▶ LSTM-ul nostru mic are 1 233 parametri; Chronos-2 are circa 119 de milioane
- ▣ **Oprirea timpurie:** antrenarea se oprește când pierderea pe un set de validare nu mai scade
 - ▶ În serii de timp, setul de validare trebuie să urmeze setului de antrenare (Capitolul 13: validare încrucișată cu purjare)
- ▣ **Weight decay:** penalizarea $\lambda \|\theta\|^2$; **dropout:** dezactivarea aleatoare a unor unități în timpul antrenării
- ▣ **Ansambluri:** media mai multor rețele antrenate din semințe aleatoare diferite

Maturizarea deep learning

- ▣ **LeCun, Bengio & Hinton (2015)**: sinteza metodelor din spatele progreselor în vedere artificială și recunoașterea vorbirii
- ▣ 2024: Premiul Nobel pentru Fizică acordat lui Hopfield și Hinton pentru lucrări fundamentale despre rețelele neuronale
- ▣ În finanțe: **Gu, Kelly & Xiu (2020)** arată că rețelele neuronale îmbunătățesc prognozele lunare ale randamentelor acțiunilor prin interacțiuni neliniare (Capitolul 13)
 - ▶ Secțiune transversală de mii de acțiuni, nu un singur indice: mult mai multe date



Geoffrey Hinton, laureat Nobel 2024


Foto: **Arthur Petron (2024)**; CC BY-SA 4.0; [Wikimedia Commons](#)

Recapitularea secțiunii

- ▣ Neuronul: sumă ponderată plus activare neliniară; MLP: straturi de neuroni
- ▣ Antrenarea: propagare înapoi plus coborâre pe gradient (Adam) pe mini-loturi
- ▣ Flexibilitatea este ieftină, datele nu: oprirea timpurie, weight decay și ansamblurile sunt esențiale

Rețele neuronale recurente (RNN)

- O stare ascunsă transportă informația înainte în timp
 - ▶ $h_t = \tanh(W h_{t-1} + U x_t + b)$, $\hat{y}_{t+1} = v^\top h_t + c$
 - ▶ Aceleași ponderi W, U, b la fiecare pas: numărul de parametri nu crește cu lungimea secvenței
- Desfășurată în timp, o RNN este o rețea foarte adâncă, cu ponderi comune



De ce memoria lungă este dificilă: gradientul care dispare

- ▣ Propagarea înapoi în timp înmulțește câte o matrice jacobiană la fiecare pas

- ▶ $\frac{\partial h_T}{\partial h_{T-k}} = \prod_{j=0}^{k-1} \text{diag}(1 - h_{T-j}^2) W$

- ▶ Cazul scalar: $|w| \tanh'(\cdot) \leq |w|$, deci gradientul este cel mult $|w|^k$

- ▣ Cu $|w| = 0,9$: $0,9^{20} = 0,12$, $0,9^{50} = 0,005$

- ▶ Bengio, Simard & Frasconi (1994): învățarea dependențelor pe termen lung prin gradient este dificilă
- ▶ Gradientii care explodează (norme peste 1) sunt problema în oglindă; limitarea normei gradientului este soluția uzuală

Celula LSTM

- ▣ **Long short-term memory** (memorie lungă de scurtă durată, [Hochreiter & Schmidhuber \(1997\)](#)): o stare a celulei c_t cu porți care decid ce se păstrează, ce se scrie și ce iese
 - ▶ Poarta de uitare: $f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$
 - ▶ Poarta de intrare: $i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)$; candidatul $g_t = \tanh(W_g x_t + U_g h_{t-1} + b_g)$
 - ▶ Poarta de ieșire: $o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)$
- ▣ Actualizări: $c_t = f_t \odot c_{t-1} + i_t \odot g_t$, $h_t = o_t \odot \tanh(c_t)$
 - ▶ $\odot$: produs element cu element; porțile iau valori în $(0, 1)$

De ce își amintește LSTM

- ▣ Pe drumul stării celulei singurul multiplicator este poarta de uitare
 - ▶ $\frac{\partial c_T}{\partial c_{T-k}} = \prod_{j=0}^{k-1} f_{T-j}$ (drumul direct)
 - ▶ Cu $f \approx 1$, gradientul supraviețuiește mulți pași
- ▣ Poartă de uitare constantă $f = \sigma(b_f)$
 - ▶ $b_f = 0$: $f = 0,5$, $0,5^{50} \approx 9 \times 10^{-16}$
 - ▶ $b_f = 3$: $f = 0,953$, $0,953^{50} \approx 0,09$; timp de înjumătățire 14 pași
- ▣ GRU (unitate recurentă cu porți): o variantă mai ușoară, cu două porți




Sepp Hochreiter, co-inventator al LSTM

Foto: Eulenreich (2015); CC BY-SA 4.0; Wikimedia

[Commons](#)

Gradientul care dispare, măsurat



- ▣ $|\partial h_T / \partial x_{T-k}|$ prin diferențiere automată; 16 unități ascunse, 50 de inițializări aleatoare, scară logaritmică
- ▣ Aceleași intrări aleatoare pentru cele trei rețele; se schimbă doar arhitectura și deplasarea porții de uitare

Interpretare: arhitectura nu este suficientă

- ▣ RNN simplă: ponderea gradientului este $8,3 \times 10^{-5}$ la decalajul 20 și $7,4 \times 10^{-9}$ la decalajul 50
 - ▶ Practic nu se învață nimic din intrări mai vechi de câteva săptămâni
- ▣ LSTM cu deplasarea porții de uitare 0: $1,3 \times 10^{-9}$ la decalajul 50, nu mai bine decât RNN
 - ▶ La inițializare $f \approx 0,5$: poarta înjumătățește memoria la fiecare pas
- ▣ LSTM cu deplasarea porții de uitare 3: 8,4% la decalajul 50, 9,0% la decalajul 100
 - ▶ Corespunde calculului cu poartă constantă $0,953^{50} \approx 0,09$
 - ▶ Regulă practică: inițializați deplasarea porții de uitare cu o valoare pozitivă

Cât de mare este un LSTM mic?

- ▣ Parametrii unui strat LSTM cu dimensiunea intrării d și dimensiunea stării ascunse h
 - ▶ $4 \times (hd + h^2 + h)$ (PyTorch folosește doi vectori de deplasare: $4 \times (hd + h^2 + 2h)$)
 - ▶ Patru blocuri: trei porți și candidatul
- ▣ Modelul nostru pentru randamente: $d = 1$, $h = 16$, ieșire liniară: 1 233 parametri
 - ▶ Antrenat pe cel mult 4.000 de randamente zilnice: circa trei observații pe parametru
- ▣ Aplicație în finanțe: [Fischer & Krauss \(2018\)](#) folosesc LSTM pentru a prezice dacă acțiunile din S&P 500 bat mediana transversală în ziua următoare

Recapitularea secțiunii

- ▣ RNN: o stare ascunsă, ponderi comune; memoria lungă eșuează pentru că gradientii dispar
- ▣ LSTM: stare a celulei aditivă și porți; poarta de uitare controlează cât trăiește informația
- ▣ Chiar și LSTM-urile mici au mii de parametri: mult pentru o singură serie financiară


Atenția: privirea directă în trecut

- ▣ Fiecare pas de timp pune o întrebare (query) și o compară cu fiecare pas trecut (key)
 - ▶ $\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$ (Vaswani et al. (2017))
 - ▶ $Q = XW_Q$, $K = XW_K$, $V = XW_V$: proiecții liniare ale intrărilor X ; d_k : dimensiunea cheilor
 - ▶ softmax transformă scorurile în ponderi cu suma 1; împărțirea la $\sqrt{d_k}$ împiedică saturarea
- ▣ Niciun produs de matrice jacobiene în timp: orice pas trecut este la un singur pas distanță
 - ▶ Costul crește cu pătratul numărului de intrări n : $O(n^2)$

Poziții și patch-uri

- ▣ **Codificarea poziției:** atenția tratează intrările ca pe o mulțime, deci ordinea trebuie adăugată
 - ▶ Sinusoide de frecvențe diferite adăugate intrărilor (Transformerul original)
 - ▶ Codificări rotative: rotesc query-urile și key-urile cu un unghi proporțional cu poziția (folosite de Chronos-2)
- ▣ **Împărțirea în patch-uri (Nie et al. (2023)):** un token este un bloc de observații consecutive, nu una singură
 - ▶ 512 randamente zilnice în patch-uri de 16 zile: 32 de tokeni în loc de 512, de circa 256 de ori mai puține scoruri de atenție
 - ▶ Fiecare token rezumă dinamica locală (câteva săptămâni de piață)

Împărțirea unui context de 512 zile în patch-uri



- Ultimele 512 randamente zilnice ale S&P 500, împărțite așa cum le citesc Chronos-2 (16 zile) și TimesFM-2.5 (32 de zile)
- Fiecare bloc colorat devine un vector de reprezentare pentru Transformer

Alte arhitecturi neuronale pentru prognoză

- ▣ DeepAR (Salinas et al. (2020)): o RNN care produce parametrii unei distribuții predictive, antrenată pe multe serii înrudite
- ▣ N-BEATS (Oreshkin et al. (2020)): stive de blocuri complet conectate care prognozează și scad, fără recurență sau atenție
- ▣ PatchTST (Nie et al. (2023)): Transformer pe patch-uri, fiecare serie procesată separat
- ▣ Ideea comună: învățarea pe multe serii, pentru că o singură serie financiară este scurtă
 - ▶ Modelele fundamentale duc ideea la limită: învățarea pe toate seriile disponibile

Recapitularea secțiunii

- ▣ Atenția compară fiecare pas cu toți ceilalți: fără gradient care dispare în timp, dar cu cost pătratic
- ▣ Pozițiile trebuie codificate; patch-urile reduc numărul de tokeni și transportă context local
- ▣ Rețelele moderne de prognoză învață pe multe serii


Ce este un model fundamental?

- ▣ O rețea mare, pre-antrenată o singură dată pe un corpus foarte larg, apoi folosită pentru sarcini noi
 - ▶ Idee preluată de la modelele mari de limbaj (LLM): pre-antrenare pe text, apoi utilizare pentru orice întrebare
- ▣ Prognoza **zero-shot**: fără antrenare pe seria-țintă; doar istoria ei recentă (**contextul**) este transmisă la momentul prognozei
 - ▶ Rezultatul: o mulțime de cuantile ale valorilor viitoare, nu doar un punct
 - ▶ Ajustarea fină (antrenare suplimentară pe seria-țintă) este posibilă, dar nu o folosim aici
- ▣ Atracția pentru finanțe: un singur model pentru mii de serii, fără estimare separată pentru fiecare serie

Chronos: seriile de timp ca limbaj

- ▣ [Ansari et al. \(2024\)](#): valorile devin tokeni, iar un model de limbaj (T5) este antrenat cu entropia încrucișată
 - ▶ Scalarea prin medie: contextul se împarte la $s = \frac{1}{C} \sum_t |x_t|$
 - ▶ Cuantizarea: 4.093 de centre echidistante în $[-15, 15]$ (lățimea 0,0073), plus tokeni speciali
 - ▶ Prognoza: se eșantionează tokeni viitori, se transformă înapoi în valori, se citesc cuantilele din eșantioane
- ▣ Corpusul de pre-antrenare: seturi publice de date (energie, transport, comerț, vreme, web, finanțe și economie) plus serii sintetice (TSMixup, KernelSynth)
 - ▶ Dimensiuni de 20 până la 710 milioane de parametri; versiunea mică are 46 de milioane

Ce vede Chronos: randamente scalate și tokeni



- Contextul: ultimele 512 randamente zilnice ale S&P 500; scala $s = 0,672\%$ (media randamentelor absolute)
- Dreapta: unde cad valorile scalate în intervalul tokenilor $[-15, 15]$

Interpretare: un vocabular în mare parte nefolosit

- ▣ Randamentele scalate variază între -9,2 și 13,5; 96% se află în intervalul ± 3
 - ▶ Cele 512 randamente folosesc 336 tokeni distincți din 4.093; doar intervalul ± 3 acoperă 818 de intervale
- ▣ Scalarea face modelul independent de unități: 1% într-un an calm și 3% într-o criză pot primi același token
 - ▶ Bun pentru transferul între serii; nivelul volatilității trebuie recuperat din contextul însuși
- ▣ O zi de crah mărește s și comprimă toate celelalte zile spre zero (Seminar, A6)

Chronos-Bolt și Chronos-2

- ▣ **Chronos-Bolt:** patch-uri de 16 valori și ieșire directă de cuantile, în locul eșantionării de tokeni
 - ▶ Doar nivelurile 10%, 20%, ..., 90%; versiunea mică are 48 de milioane de parametri
- ▣ **Chronos-2** ([Ansari et al. \(2025\)](#)): scalare robustă, patch-uri de 16, atenție în timp și între grupuri de serii înrudite
 - ▶ 21 de niveluri de cuantile: 1%, 5%, 10%, ..., 95%, 99%; circa 119 de milioane de parametri
 - ▶ Corpusul de antrenare: seturi selectate din corpusurile Chronos și [GIFT-Eval](#) plus serii multivariate sintetice
 - ▶ Teste comparative: [GIFT-Eval](#) ([Aksu et al. \(2024\)](#)) și fev-bench

TimesFM, Moirai și Lag-Llama

- **TimesFM** (Das et al. (2024)): Transformer doar cu decodor, pe patch-uri de 32 de valori
 - ▶ Pre-antrenat pe circa 10^{11} puncte: Google Trends, afișări de pagini Wikipedia, serii sintetice, M4, electricitate, trafic, vreme
 - ▶ TimesFM-2.5: media plus decile; versiunea publicată are circa 231 de milioane de parametri
- **Moirai** (Woo et al. (2024)): orice număr de variabile, ieșire de tip amestec de distribuții; Moirai 2.0 (Liu et al. (2025))
 - ▶ Publicat sub o licență necomercială; nu îl folosim în teste
- **Lag-Llama** (Rasul et al. (2023)): model doar cu decodor, cu valori întârziate ca variabile și ieșire Student- t

Cele trei modele pe care le testăm

Model	Parametri	Patch	Niveluri de cuantile	Ponderi publicate
Chronos-Bolt (small)	48 M	16	10%–90%	25.11.2024
TimesFM-2.5	231 M	32	medie, 10%–90%	01.10.2025
Chronos-2	119 M	16	1%, 5%, . . . , 99%	30.10.2025

- Toate trei rulează pe un CPU obișnuit; context de 512 observații zilnice, prognoze la o zi
- Datele de publicare a ponderilor provin din repository-urile Hugging Face; ele fixează ce au putut vedea modelele
- Doar Chronos-2 ajunge la nivelul de 1% necesar pentru VaR 1%

Scurgerea de informație prin pre-antrenare

- Un test este în afara eșantionului doar dacă perioada de test nu a fost văzută la antrenare
 - ▶ Corpusul Chronos include serii financiare (de exemplu cursuri de schimb zilnice 1990–2016); corpusurile ulterioare sunt mai largi
 - ▶ Nu putem exclude că seriile noastre, sau serii influențate de aceleași șocuri, au fost în datele de pre-antrenare
- Remediul nostru: o **fereastră de după publicare**, de la 3 noiembrie 2025, după publicarea tuturor celor trei seturi de ponderi
 - ▶ Curată, dar scurtă (circa 220 de zile de tranzacționare; 320 de zile calendaristice pentru Bitcoin): putere mică, mai ales pentru VaR 1%
- Evităm și privirea în viitor în propriul proces: orice scalare, fereastră sau estimare folosește doar date trecute


De la o grilă de cuantile la ce ne trebuie

- Modelul întoarce cuantile q_u la nivelurile $u_1 < \dots < u_K$
 - ▶ Prognoza punctuală: mediana $q_{0,5}$ sau media $\int_0^1 q_u du$ aproximată pe grilă
 - ▶ Media unei variabile transformate: $E[g(Y)] = \int_0^1 g(q_u) du$ pentru g crescătoare (de exemplu $g = \exp$ pentru logaritmul varianței)
- Riscul de coadă (Capitolul 7): $\text{VaR}_\alpha = -q_\alpha$, $\text{ES}_\alpha = -\frac{1}{\alpha} \int_0^\alpha q_u du$
 - ▶ Sub cel mai mic nivel, grila nu spune nimic: păstrăm q_u la ultima valoare, ceea ce subestimează ES
 - ▶ Chronos-Bolt și TimesFM se opresc la 10%: o cerere de „VaR 1%” întoarce cuantila de 10%

Exemplu lucrat: ultima prognoză Chronos-2

- ▣ S&P 500, prognoza pentru ziua de după 18.09.2026: $q_{0,01} = -2,70\%$, $q_{0,05} = -1,40\%$
 - ▶ VaR 1% = $-q_{0,01} = 2,70\%$
 - ▶ Interpolare liniară: $q_{0,025} = q_{0,01} + \frac{0,015}{0,04}(q_{0,05} - q_{0,01}) = -2,21\%$, deci VaR 2,5% = 2,21%
- ▣ ES 2,5%: $-\frac{1}{0,025} \left[0,01 q_{0,01} + 0,015 \frac{q_{0,01} + q_{0,025}}{2} \right] = 2,56\%$
 - ▶ O limită inferioară: coada de sub 1% este tăiată la $q_{0,01}$

Un avantaj de prognoză zero-shot pentru volatilitate



- Chronos-2 pe logaritmul varianței realizate a SPY (context de 512 zile), 22 de zile de tranzacționare înainte de la 18.09.2026; volatilitate anualizată
- Benzi: cuantilele 5%–95% și 25%–75% ale distribuției predictive

Interpretare: revenirea la medie învățată fără antrenare

- ▣ Ultima volatilitate observată: 4,8% pe an; media ultimelor 20 de zile: 6,6%
 - ▶ Prognoza mediană la 22 de zile: 6,6%, cu o bandă de 90% între 3,8% și 15,4%
- ▣ Banda se lărgeste cu orizontul și este asimetrică în sus: volatilitatea poate sări, nu se poate prăbuși
 - ▶ Trăsături ale prognozelor GARCH și HAR (capitolele 5 și 9), obținute aici fără nicio estimare pe datele SPY
- ▣ Dacă aceste prognoze sunt **mai bune** este o întrebare empirică: secțiunile următoare

Recapitularea secțiunii

- ▣ Modelele fundamentale: pre-antrenate o singură dată pe corpusuri mari, folosite zero-shot cu o fereastră de context
- ▣ Citesc o serie prin scalare, tokeni sau patch-uri și întorc cuantile
- ▣ Grilele de cuantile limitează estimările de coadă; suprapunerea cu pre-antrenarea cere o fereastră de test de după publicare


Designul testului pentru randamente

- ▣ Randamente log zilnice (%): S&P 500 și BET de la 04.01.2016 (2 693 și 2 675 zile), Bitcoin de la 01.01.2019 (2 818 zile)
 - ▶ Fiecare prognoză folosește doar date până la închiderea precedentă
- ▣ Modele: media istorică, AR(1) pe o fereastră de 1.000 de zile, LSTM, Chronos-2 și Chronos-Bolt (mediana), TimesFM-2.5 (media)
- ▣ Reper: prognoza zero; R^2 în afara eșantionului $= 1 - \sum_t (r_t - \hat{r}_t)^2 / \sum_t r_t^2$
 - ▶ Zero în locul mediei istorice, ca la [Gu, Kelly & Xiu \(2020\)](#); comparați cu [Campbell & Thompson \(2008\)](#)
 - ▶ Inferență: CI bootstrap pe blocuri pentru R^2 (blocuri de 20 de zile), testul Diebold–Mariano (DM) pe erorile pătratice, cu varianță Newey–West ([Diebold & Mariano \(1995\)](#))

LSTM-ul pentru randamente

- Intrarea: ultimele 20 de randamente, standardizate cu media și abaterea standard din perioada de antrenare
 - ▶ Ieșirea: randamentul de a doua zi; pierderea MSE; Adam; weight decay 10^{-4}
- Antrenat o singură dată pe până la 4.000 de zile dinaintea perioadei de test; ultimele 20% dintre ele pentru oprirea timpurie
 - ▶ Cinci semințe aleatoare; prognoza este media celor cinci rețele
- Un strat ascuns de 16 unități: 1 233 parametri


Antrenarea LSTM: oprirea timpurie



- S&P 500, sămânța 0: MSE a randamentelor standardizate pe epoci, pe partea de antrenare și pe cea de validare
- Antrenarea se oprește după 26 epoci; se păstrează ponderile din epoca 1

Interpretare: puțin de învățat

- Ambele pierderi aproape nu se mișcă; pierderea de validare este minimă după prima epocă, deci oprirea timpurie păstrează epoca 1
 - ▶ MSE de validare este sub cea de antrenare pentru că anii de validare au fost mai calmi: nivelul reflectă volatilitatea, nu calitatea modelului
- Oprirea timpurie alege o rețea apropiată de punctul de plecare: prognoze apropiate de medie
 - ▶ Abaterea standard a prognozelor LSTM pentru S&P 500: 0,047%, față de 1,13% pentru randamente
- Un semn sănătos: o rețea care ar prognoza mișcări mari ar ajusta zgomot

R^2 în afara eșantionului pentru randamente


□ R^2 față de prognoza zero (%), cu CI bootstrap pe blocuri de 95%

Interpretare: niciun model nu bate prognoza zero, cu excepția BET

R^2 (%) [DM p]	Media istorică	AR(1)	LSTM (5 semințe)	Chronos-2	Chronos-Bolt	TimesFM-2.5
S&P 500	+0,15 [0,095]	+0,94 [0,639]	+0,82 [0,116]	-0,26 [0,418]	-1,57 [0,078]	-3,35 [0,001]
Bitcoin	+0,07 [0,691]	-0,28 [0,326]	-0,08 [0,135]	-0,35 [0,413]	-0,61 [0,070]	-2,29 [0,001]
BET	+0,30 [0,081]	-0,00 [1,000]	+1,18 [0,015]	-0,39 [0,562]	+0,12 [0,831]	-3,27 [0,070]

- S&P 500 și Bitcoin: niciun model nu bate semnificativ prognoza zero; TimesFM-2.5 este semnificativ **mai slab** decât zero
 - Modelele fundamentale prognozează prea multă mișcare: abaterea standard a prognozelor TimesFM pe S&P 500 este 0,141%, de trei ori cea a LSTM (0,047%)
- BET: LSTM are R^2 +1,18% (DM $p = 0,015$): un semnal mic, dar real, pe o piață mai puțin eficientă (Capitolul 2)

Câștigurile cumulate de eroare pătratică pe S&P 500




□ $\sum_{s \leq t} [r_s^2 - (r_s - \hat{r}_s)^2]$: crește când modelul bate prognoza zero, scade când pierde

Interpretare: câștigurile vin din câteva zile

- ▣ Toate curbele rămân lângă zero în anii calmi și sar în martie 2020
 - ▶ Erorile pătratice sunt dominate de zilele de criză: o singură lună decide clasamentul
- ▣ AR(1) câștigă în 2020 din autocorelația negativă a zilelor de crah, apoi pierde o parte
 - ▶ TimesFM-2.5 pierde constant: prognozele lui sunt prea volatile
- ▣ Lecția: raportați drumul, nu doar R^2 final; un singur episod poate crea sau distruge „previzibilitatea”

Loteria semințelor



□ R^2 în afara eșantionului pentru cinci LSTM-uri care diferă doar prin sămânța aleatoare și pentru media lor

 MFM_ch14_returns

Interpretare: raportați toate semințele

- ▣ Bitcoin: semințele individuale variază între -1,47% și +0,21%; S&P 500 între +0,35% și +1,40%
 - ▶ Variația de la o sămânță la alta este la fel de mare ca efectul însuși
- ▣ BET: toate cele 5 semințe sunt pozitive, între +1,03% și +1,25%: singurul semnal robust
- ▣ Alegerea celei mai bune semințe după ce ați văzut rezultatele de test este supraajustarea backtestului (Capitolul 13)

Recapitularea secțiunii

- Randamentele zilnice ale piețelor mari: niciun model de deep learning sau fundațional nu bate prognoza zero
- Prognozele punctuale zero-shot pot fi mai slabe decât zero: se prognozează prea multă mișcare
- Un LSTM mic găsește un semnal robust pe BET, în acord cu eficiența mai redusă a acestei piețe


Ținta, reperul și pierderea

- ▣ **Varianța realizată** (RV, Andersen et al. (2003)): suma pătratelor randamentelor log la 5 minute din ziua de tranzacționare
 - ▶ $RV_t = \sum_{j=1}^{78} r_{t,j}^2$ pentru SPY (sesiunea regulată, 6,5 ore); volatilitatea medie 11,9% pe an
- ▣ **HAR** (Corsi (2009)): $RV_t = \beta_0 + \beta_d RV_{t-1} + \beta_w \overline{RV}_{t-5:t-1} + \beta_m \overline{RV}_{t-22:t-1} + \varepsilon_t$
 - ▶ log-HAR: același model pe log RV, prognoza $\exp(\hat{y} + \hat{s}^2/2)$
- ▣ Pierderea **QLIKE** (Patton (2011)): $L = RV_t/\hat{h}_t - \log(RV_t/\hat{h}_t) - 1$
 - ▶ Clasifică prognozele corect deși RV este o aproximare zgomotoasă; este minimizată de media condiționată

Designul testului pentru volatilitate

- ▣ Varianța realizată a SPY, prognoze la o zi de la 11.10.2022 până la 18.09.2026 (979 zile)
 - ▶ HAR și log-HAR pe o fereastră mobilă de 500 de zile; random walk: $\hat{h}_t = RV_{t-1}$
 - ▶ GARCH-t pe randamentele zilnice ale SPY, rescalat în unități RV prin raportul dintre media RV și media randamentelor la pătrat pe 500 de zile
 - ▶ LSTM pe ultimele 22 de valori ale log RV, reantrenat la fiecare 125 de zile pe 500 de zile (stare ascunsă 8, trei semințe)
- ▣ Modelele fundamentale pe log RV (context 512): prognoza $\hat{h}_t = \int_0^1 \exp(q_u) du$ pe grila de cuantile
 - ▶ Fereastra de după publicare: 218 zile de la 3 noiembrie 2025

Prognozele în timpul șocului din aprilie 2025




- Volatilitatea realizată a SPY (anualizată) și prognozele la o zi, februarie–iulie 2025
- Vârful: 107% pe an la 07.04.2025, după anunțurile tarifare ale SUA

Interpretare: toată lumea întârzie o zi

- Niciun model nu anticipează saltul; toate reacționează a doua zi
 - ▶ Prognozele la o zi pot doar extrapola trecutul; șocurile vin din știri
- Modelele fundamentale și log-HAR revin cu viteze asemănătoare
 - ▶ GARCH-t reacționează la mărimea randamentelor zilnice și revine mai lent
- Clasamentul este decis de media pe circa patru ani: slide-ul următor

Pierderile QLIKE ale celor opt modele de volatilitate



□ Stânga: toată perioada de test; dreapta: fereastra de după publicarea tuturor ponderilor

MFM_ch14_realised_vol

Interpretare: modelele fundamentale egalează log-HAR, nu mai mult

Model	QLIKE	DM vs log-HAR	p	MCS p	QLIKE după 3.11.2025
Random walk	0,326	+4,53	<0,001	0,00	0,384
HAR	0,247	+1,30	0,194	0,26	0,270
log-HAR	0,234	—	—	0,95	0,238
GARCH-t	0,283	+3,43	<0,001	0,03	0,295
LSTM	0,290	+1,87	0,062	0,19	0,231
Chronos-2	0,231	-0,62	0,537	1,00	0,242
Chronos-Bolt	0,232	-0,18	0,857	0,95	0,236
TimesFM-2.5	0,233	-0,08	0,938	0,95	0,244


- Chronos-2, Chronos-Bolt, TimesFM-2.5 și log-HAR: teste DM nesemnificative, toate în MCS de 90%
- Random walk și GARCH-t sunt eliminate din MCS; HAR în niveluri supraestimează (media prognozei / media RV = 1,36)
- După 3 noiembrie 2025, LSTM-ul mic are cea mai mică QLIKE (0,231): pe 218 zile, clasamentele sunt instabile

Mediana sau media? Un detaliu costisitor

Chronos-2 și TimesFM-2.5 pe log RV	QLIKE	Media prognozei / media RV
Chronos-2, $\int_0^1 \exp(q_u) du$	0,231	1,02
Chronos-2, $\exp(q_{0,5})$	0,259	0,79
TimesFM-2.5, $\int_0^1 \exp(q_u) du$	0,233	0,94
TimesFM-2.5, $\exp(q_{0,5})$	0,259	0,79

- RV este asimetrică la dreapta: mediana ei este cu circa 20% sub medie
 - ▶ $\exp(\text{mediana lui log RV})$ este mediana lui RV, nu media: o prognoză de volatilitate deplasată
 - ▶ Varianta cu mediana este semnificativ mai slabă decât cea cu media (DM +3,60 pentru Chronos-2) și mai slabă decât log-HAR (0,234)

De cât context are nevoie Chronos-2?



- QLIKE pentru Chronos-2 pe log RV cu contexte de 32 până la 512 zile (aceleași zile de prognoză)

 MFM_ch14_realised_vol

Interpretare: memoria lungă cere context lung

- ▣ QLIKE scade de la 0,290 cu 32 de zile la 0,231 cu 512 zile
 - ▶ Cu mai puțin de circa 256 de zile, Chronos-2 este mai slab decât log-HAR (0,234)
- ▣ Volatilitatea are memorie lungă: lunile de istorie îi spun modelului nivelul care se mișcă lent
 - ▶ HAR codifică aceeași idee explicit, prin media pe 22 de zile
- ▣ Lungimea contextului este o alegere de modelare care trebuie raportată și testată, ca lungimea unei ferestre


Recapitularea secțiunii

- ▣ Modelele fundamentale zero-shot prognozează varianța realizată la fel de bine ca un log-HAR bine specificat
- ▣ Nu sunt semnificativ mai bune, nici înainte, nici după publicarea ponderilor
- ▣ Folosiți media, nu mediana, și un context lung; comparați mereu cu HAR

Designul testului pentru riscul de coadă

- $\text{VaR}_\alpha = -q_\alpha(r_{t+1} \mid \mathcal{F}_t)$, pierderea depășită cu probabilitatea α ; $\text{ES}_\alpha = -\frac{1}{\alpha} \int_0^\alpha q_u du$
 - ▶ Nivelurile: VaR 1% (teste de acoperire) și perechea (VaR 2,5%, ES 2,5%) pentru pierderea FZ0 ([Fissler & Ziegel \(2016\)](#), [Patton, Ziegel & Chen \(2019\)](#))
- Modele clasice pe o fereastră de 1.000 de zile: HS, GARCH(1,1)-t, FHS ([McNeil & Frey \(2000\)](#)), reestimate la fiecare 20 de zile
- Modelele fundamentale, în două moduri
 - ▶ **Direct**: cuantilele Chronos-2 ale randamentului de mâine (context: 512 randamente)
 - ▶ **Hibrid**: volatilitatea $\hat{\sigma}_t =$ media prognozată a lui $|r_t|$ de Chronos-2 sau TimesFM; FHS pe $r_t/\hat{\sigma}_t$

Ratele de depășire ale VaR 1%




- Ponderea zilelor cu o pierdere peste VaR 1% (scară logaritmică); banda gri: intervalul de 95% al ratei de depășire dacă modelul ar fi corect
- Chronos-Bolt: cea mai mică cuantilă a sa (10%) folosită drept „VaR 1%”

Interpretare: cuantilele directe sunt prea înguste

Depășiri [Kupiec p]	HS	GARCH-t	FHS	Cuantile Chronos-2	FHS + vol. Chronos-2	FHS + vol. TimesFM
S&P 500 (26,9)	37 [0,065]	44 [0,002]	30 [0,559]	45 [0,001]	25 [0,705]	27 [0,989]
Bitcoin (28,2)	19 [0,065]	27 [0,822]	25 [0,539]	33 [0,374]	27 [0,822]	27 [0,822]
BET (26,8)	32 [0,322]	41 [0,010]	30 [0,536]	40 [0,016]	26 [0,884]	32 [0,322]

- În paranteză după piață: numărul așteptat de depășiri, 1% din zile
- Cuantilele directe Chronos-2: prea multe depășiri pe S&P 500 (1,67%); „VaR 1%” Chronos-Bolt: 13,5%
 - ▶ FHS hibrid cu volatilitatea modelelor fundamentale: rate de depășire apropiate de 1% pe toate cele trei piețe

Crahul COVID-19: VaR 1% pentru trei modele




□ S&P 500, februarie–iunie 2020 (104 zile): pierderile zilnice și prognozele VaR 1%; puncte: depășiri

Interpretare: viteza de reacție

- ▣ Depășiri în cele 104 zile: FHS 2, Chronos-2 direct 4, FHS cu volatilitatea Chronos-2 2, HS 12
 - ▶ Toate modelele sunt depășite în primele zile ale crahului: niciunul nu îl anticipează
- ▣ Chronos-2 citește contextul din primele zile, deci cuantilele lui se lărgesc repede
 - ▶ Scalarea prin media valorilor absolute ale contextului: o zi de crah lărgeste toată distribuția
- ▣ Hibridul exagerează: VaR 1% atinge un vârf de 58,9%, față de 26,4% pentru FHS și o pierdere maximă de 12,8%
 - ▶ Puține depășiri, dar un cost de capital ridicat: exact asta va penaliza pierderea FZ0

Unde decilele sunt suficiente: VaR 10%



□ Rata de depășire a cuantilei de 10% (ținta 10%) pentru HS, FHS și cele trei modele fundamentale

Interpretare: chiar și cuantila de 10% este prea sus

- ▣ S&P 500: HS 9,8%, FHS 9,6%; Chronos-2 11,7%, Chronos-Bolt 13,5%, TimesFM-2.5 12,0%
 - ▶ Bitcoin: Chronos-2 10,6%, Chronos-Bolt 12,8%, TimesFM-2.5 11,6%; BET: 11,6%, 14,1%, 11,8%
- ▣ Toate cele trei modele fundamentale își depășesc prea des cuantila de 10%: distribuții predictive prea înguste pentru randamente
 - ▶ Un motiv plauzibil: corpusurile de pre-antrenare sunt dominate de serii mai netede (energie, trafic, web), cu cozi mai subțiri decât randamentele
- ▣ Folosite ca filtre de volatilitate, aceleași modele preiau cozile din date, prin FHS

Compararea prognozelor (VaR 2,5%, ES 2,5%): MCS

HS	0.140	0.343	0.015
GARCH-t	0.187	0.597	0.341
FHS	1.000	0.597	1.000
Chronos-2 quantiles	0.140	0.641	0.239
FHS + Chronos-2 volatility	0.140	1.000	0.341
FHS + TimesFM volatility	0.183	0.704	0.202
	S&P 500	Bitcoin	BET

- Valorile p ale mulțimii de modele de încredere de 90% (Hansen, Lunde & Nason (2011)) pentru pierderea FZ0; verde: păstrat, roșu: eliminat

Interpretare: hibrizii trec testele, FHS rămâne reperul

FZ0 [MCS p]	HS	GARCH-t	FHS	Cuantile Chronos-2	FHS + vol. Chronos-2	FHS + vol. TimesFM
S&P 500	1,309 [0,14]	1,026 [0,19]	0,999 [1,00]	1,147 [0,14]	1,084 [0,14]	1,059 [0,18]
Bitcoin	2,237 [0,34]	2,192 [0,60]	2,192 [0,60]	2,181 [0,64]	2,151 [1,00]	2,160 [0,70]
BET	1,230 [0,01]	1,001 [0,34]	0,963 [1,00]	1,032 [0,24]	1,007 [0,34]	1,027 [0,20]

- S&P 500: FHS are cea mai mică pierdere FZ0; hibrizii au acoperire corectă, dar cu VaR mai mare, mai conservator (în medie 3,20% față de 2,78%)
- Bitcoin: FHS hibrid cu volatilitatea Chronos-2 are cea mai mică pierdere FZ0, dar diferențele nu sunt semnificative
- MCS nu elimină niciun model pe S&P 500 și Bitcoin, doar HS pe BET; testele DM pe perechi sunt mai precise: FHS bate hibridul Chronos-2 pe S&P 500 (DM +2,65, $p = 0,008$) și pe BET (DM +2,36, $p = 0,018$)

După publicarea ponderilor

Depășiri după 3.11.2025	HS	GARCH-t	FHS	Cuantile Chronos-2	FHS + vol. Chronos-2	FHS + vol. TimesFM
S&P 500 (220 zile)	0	2	2	2	2	2
Bitcoin (320 zile)	3	3	4	4	3	4
BET (217 zile)	4	4	4	5	1	2

- Numărul așteptat de depășiri: 2,2 (S&P 500), 3,2 (Bitcoin), 2,2 (BET)
 - ▶ Aici nu este posibilă nicio scurgere, dar cu două sau trei depășiri așteptate niciun test nu are putere
- Pentru riscul de coadă, fereastra de după publicare nu poate încă confirma sau respinge nimic: trebuie să crească ani de zile

Recapitularea secțiunii

- ▣ Cuantilele directe ale modelelor fundamentale sunt prea înguste pentru randamente, chiar și la 10%; Chronos-Bolt și TimesFM nu pot ajunge deloc la 1%
- ▣ Ca filtre de volatilitate în FHS dau acoperire corectă, dar o pierdere FZ0 semnificativ mai mare decât FHS cu GARCH pe S&P 500 și BET
- ▣ Niciunul nu înlocuiește FHS cu GARCH, pe baza dovezilor de până acum

O întrebare deschisă: abilitate sau memorie?

- Testul 2: Chronos-2 zero-shot egalează log-HAR pe varianța realizată a SPY (QLIKE 0,231 vs 0,234, DM $p = 0,537$)
- Rahimikia, Ni & Wang (2025): pe randamentele zilnice în exces de pe piețele globale, modelele fundamentale gata antrenate sunt slabe zero-shot și după ajustarea fină; modelele pre-antrenate de la zero pe date financiare câștigă
- Lopez-Lira, Tang & Zhu (2025): odată ce un model a văzut valorile realizate, abilitatea lui de prognoză contrafactuală nu este identificată; memorarea detectată este doar o limită inferioară (arătat pentru LLM-uri; logica se aplică oricărui model pre-antrenat)
- Deschis: este paritatea o structură învățată (memorie lungă, revenire la medie) sau amintirea perioadei de test și poate o fereastră scurtă de după publicare să decidă?
 - $d_t = L(\hat{h}_t^{FM}, RV_t) - L(\hat{h}_t^{\log HAR}, RV_t)$; memorarea implică $E[d_t \mid \text{după}] > E[d_t \mid \text{înainte}]$; H_0 : egalitate

Bucula descoperirii, pas cu pas (1/2)

- **Literatura:** "Găsește evaluări ale modelelor fundamentale pentru serii de timp pe randamente sau volatilitate financiară din 2024 încoace: modele, date, pierdere, reper și dacă perioada de test se suprapune cu corpusul de pre-antrenare."
 - ▶ Verificați fiecare identificator arXiv și citiți voi documentația corpusului; Semantic Scholar, Google Scholar, Elicit ajută la căutare
- **Ipoteze:** "Enumeră predicțiile care separă memorarea de abilitate pentru un model zero-shot de volatilitate: înainte vs după publicare, serii niciodată publice, serii simulate cu aceeași dinamică."
 - ▶ Abilitatea prezice câștiguri egale pe o traiectorie log-HAR simulată; memoria prezice câștiguri doar pe serii publice dinaintea datei-limită
- **Date și cod:** "Din ch14_rv.csv, calculează diferențialul QLIKE Chronos-2 minus log-HAR, testează înainte vs după 3 noiembrie 2025 cu erori HAC și raportează efectul minim detectabil la o putere de 80%."
 - ▶ Orice asistent (Claude, ChatGPT, Gemini, GitHub Copilot); reproduceți întâi QLIKE log-HAR din capitol, 0,234

Bucula descoperirii, pas cu pas (2/2)

- **Robustețea**, fixată dinainte: "Proiectează un test preînregistrat cu putere mai mare: ce secțiune transversală de serii, ce aproximare a varianței, ce test DM pe panel și câte zile de după publicare."
 - ▶ Placebo: o dată de publicare falsă, cu un an mai devreme, nu trebuie să arate nicio ruptură; seriile simulate nu pot fi memorate
- **Critica**: "Atacă afirmația: nu există memorare, pentru că testul DM de după publicare este nesemnificativ. Ce este greșit în inferență?"
 - ▶ De așteptat: putere mică, absența dovezii și o schimbare de regim (șocul tarifar din 2025) care coincide cu publicarea
- **Raportul**: versiunile modelelor și datele publicării ponderilor, lungimea contextului, media sau mediana, fiecare sămânță și fereastră încercată

Ce trebuie să verifice omul

- **Suprapunerea cu pre-antrenarea:** o serie publică poate fi în corpus
 - ▶ Test: fereastra de după publicare, serii simulate sau private; notați data publicării ponderilor
- **Puterea mică prezentată drept rezultat nul:** „nesemnificativ” pe câteva sute de zile
 - ▶ Test: raportați efectul minim detectabil (MDE) și CI pentru $E[d_t]$, nu doar p
- **Funcționala greșită:** mediana lui log RV folosită ca prognoză a mediei
 - ▶ Test: media prognozei / media RV trebuie să fie aproape de 1 (mediana Chronos-2: 0,79)
- **Scurgeri în propriul cod:** medii HAR sau scalări care includ ziua t (Seminarul, B8)
 - ▶ Test: recalculați prognoza pentru t din date tăiate la $t - 1$; nu trebuie să se schimbe
- **Selecția:** contexte, semințe și modele alese după ce ați văzut testul
 - ▶ Test: notați fiecare încercare; comparați întregul set cu MCS ([Hansen, Lunde & Nason \(2011\)](#))

Mini-studiu de caz: un test fără putere

- O propunere tipică a unui asistent: „paritatea Chronos-2 vine din date memorate, deci avantajul trebuie să dispară după publicare”. O testăm pe prognozele salvate
- Diferențialul QLIKE mediu d_t : -0,0050 înainte de 3 noiembrie 2025 (761 zile) vs +0,0038 după (218 zile)
- Schimbarea +0,0088, $t_{HAC} = 1,00$ ($p = 0,32$): în direcția prezisă de memorare, dar H_0 nu este respinsă
- Puterea: cu 218 zile, MDE (5% bilateral, putere 80%) = $(z_{0,975} + z_{0,8}) \hat{s}_{HAC} / \sqrt{n} = 0,0180$
 - ▶ 7,7% din QLIKE log-HAR, de 3,6 ori diferența dinaintea publicării; detectarea ei cere circa 7 400 de zile, aproximativ 29 de ani
- Interpretare: fereastra nu poate separa memoria de abilitate; „nu există memorare” nu este o concluzie. Puterea trebuie să vină din secțiunea transversală, nu din așteptare

 ai_discovery_case.py

Rândul vostru: o sămânță de proiect

- Întrebarea: rezistă abilitatea zero-shot pentru varianța zilnică acolo unde memorarea este imposibilă: după publicare, pe serii simulate, pe piețe mai puțin acoperite?
- Replicați întâi: QLIKE din capitol pentru log-HAR (0,234) și Chronos-2 (0,231), DM $p = 0,537$, și fereastra de 218 zile de după publicare
- Livrabile
 - ▶ Un calcul de putere preînregistrat; un panel de serii din datele cursului, cu o aproximare a varianței din amplitudinea zilnică și o pierdere robustă la aproximare (Patton (2011))
 - ▶ Teste înainte/după cu date de publicare placebo; MCS pentru toate modelele; o critică de tip recenzent și răspunsul vostru
- Notați fiecare prompt care a influențat o decizie în AI_USE.md; fiecare referință inventată, scurgere de informație sau cifră greșită prinsă în AI_ERRORS.md, cu testul care a prins-o (șabloane)

Lista capcanelor

- ▣ **Scurgeri de informație:** suprapunerea cu pre-antrenarea, scalarea cu statistici din tot eșantionul, ferestre de validare amestecate
 - ▶ Seminarul, B8: mediile HAR care includ ziua prognozată reduc QLIKE cu un sfert, un câștig pe care niciun model corect nu îl obține
- ▣ **Repere slabe:** comparați cu zero (randamente), log-HAR (volatilitate), FHS (cozi), nu cu un random walk
- ▣ **Selecția:** semințe, lungimi de context, arhitecturi alese după ce ați văzut perioada de test
- ▣ **Funcționala greșită:** mediane folosite ca medii; decile folosite drept cuantile de 1%

Ce folosim și când

Ținta	Modelul de referință	Unde poate ajuta deep learning
Randamente zilnice ale indicilor Volatilitate realizată VaR 1%, ES 2,5%	Proгноza zero log-HAR FHS (filtru GARCH)	Piețe mai puțin eficiente (BET); multe active, multe variabile Proгноze zero-shot pentru mii de serii fără estimare Filtru de volatilitate în FHS, nu cuantile directe

- Modelele fundamentale sunt ușor de încercat: fără estimare, o linie de cod, un CPU este suficient
- Valoarea lor este amploarea (multe serii, fără ajustare), nu precizia pe o singură serie bine studiată

Cercetări înrudite

- ▣ Agakishiev, Härdle & Pele (2025): prognoza lichidității criptomonedelor, Springer Handbook of Computational Statistics
- ▣ Będowska-Sójka, Wójcik & Pele (2026): sisteme de avertizare timpurie bazate pe machine learning pentru criptoactivele „zombie”
- ▣ Pele et al. (2023): criptomonedele clasificate prin învățare statistică pe multe serii
- ▣ Manuale: Franke, Härdle & Hafner (2019) și Härdle, Chen & Overbeck (2017) pentru statistica piețelor financiare din spatele modelelor de referință

Idei principale

- ▣ LSTM rezolvă problema gradientului care dispare prin poarta de uitare; Transformererele o evită prin atenție
- ▣ Modelele fundamentale prognozează zero-shot dintr-o fereastră de context și întorc cuantile
- ▣ Randamente: nimic nu bate prognoza zero pe piețele mari; volatilitate: modelele fundamentale egalează log-HAR; cozi: folosiți-le doar ca filtre de volatilitate
- ▣ Evaluați orice model nou cu instrumentele din Capitolul 8, față de un reper puternic și după publicarea ponderilor lui

Bibliografie (1/6)

- ▣ Agakishiev, I., Härdle, W.K., Pele, D.T. (2025). [Cryptocurrency liquidity forecasting](#). In *Springer Handbooks of Computational Statistics*, 41–60. Springer.
- ▣ Aksu, T., Woo, G., Liu, J., Liu, X., Liu, C., Savarese, S., Xiong, C., Sahoo, D. (2024). [GIFT-Eval: a benchmark for general time series forecasting model evaluation](#). arXiv:2410.10393.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Labys, P. (2003). [Modeling and forecasting realized volatility](#). *Econometrica*, 71(2), 579–625.
- ▣ Ansari, A.F., Stella, L., Turkmen, C., Zhang, X., et al. (2024). [Chronos: learning the language of time series](#). *Transactions on Machine Learning Research*; arXiv:2403.07815.
- ▣ Ansari, A.F., Shchur, O., Küken, J., Auer, A., et al. (2025). [Chronos-2: from univariate to universal forecasting](#). arXiv:2510.15821.
- ▣ Będowska-Sójka, B., Wójcik, P., Pele, D.T. (2026). [Early warning systems for cryptocurrency markets: predicting 'zombie' assets using machine learning](#). *North American Journal of Economics and Finance*, 81, 102543.
- ▣ Bengio, Y., Simard, P., Frasconi, P. (1994). [Learning long-term dependencies with gradient descent is difficult](#). *IEEE Transactions on Neural Networks*, 5(2), 157–166.

Bibliografie (2/6)

- ▣ Campbell, J.Y., Thompson, S.B. (2008). Predicting excess stock returns out of sample: can anything beat the historical average? *Review of Financial Studies*, 21(4), 1509–1531.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Das, A., Kong, W., Sen, R., Zhou, Y. (2024). A decoder-only foundation model for time-series forecasting. *Proceedings of ICML*, PMLR 235; arXiv:2310.10688.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Fischer, T., Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), 654–669.
- ▣ Fissler, T., Ziegel, J.F. (2016). Higher order elicibility and Osband's principle. *Annals of Statistics*, 44(4), 1680–1707.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.

Bibliografie (3/6)

- ▣ Gu, S., Kelly, B., Xiu, D. (2020). [Empirical asset pricing via machine learning](#). *Review of Financial Studies*, 33(5), 2223–2273.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). [The model confidence set](#). *Econometrica*, 79(2), 453–497.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (eds.) (2017). [Applied Quantitative Finance](#), 3rd ed. Springer.
- ▣ Hochreiter, S., Schmidhuber, J. (1997). [Long short-term memory](#). *Neural Computation*, 9(8), 1735–1780.
- ▣ Hornik, K., Stinchcombe, M., White, H. (1989). [Multilayer feedforward networks are universal approximators](#). *Neural Networks*, 2(5), 359–366.
- ▣ Kingma, D.P., Ba, J. (2015). [Adam: a method for stochastic optimization](#). *ICLR*; arXiv:1412.6980.
- ▣ LeCun, Y., Bengio, Y., Hinton, G. (2015). [Deep learning](#). *Nature*, 521(7553), 436–444.

Bibliografie (4/6)

- ▣ Liu, C., Aksu, T., Liu, J., Liu, X., et al. (2025). *Moirai 2.0: when less is more for time series forecasting*. arXiv:2511.11698.
- ▣ Lopez-Lira, A., Tang, Y., Zhu, M. (2025). *The memorization problem: can we trust LLMs' economic forecasts?* arXiv:2504.14765.
- ▣ McNeil, A.J., Frey, R. (2000). *Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach*. *Journal of Empirical Finance*, 7(3–4), 271–300.
- ▣ Nie, Y., Nguyen, N.H., Sinthong, P., Kalagnanam, J. (2023). *A time series is worth 64 words: long-term forecasting with Transformers*. *ICLR*; arXiv:2211.14730.
- ▣ Oreshkin, B.N., Carpov, D., Chapados, N., Bengio, Y. (2020). *N-BEATS: neural basis expansion analysis for interpretable time series forecasting*. *ICLR*; arXiv:1905.10437.
- ▣ Patton, A.J. (2011). *Volatility forecast comparison using imperfect volatility proxies*. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). *Dynamic semiparametric models for expected shortfall (and value-at-risk)*. *Journal of Econometrics*, 211(2), 388–413.

Bibliografie (5/6)

- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). *Are cryptos becoming alternative assets?* *The European Journal of Finance*, 29(10), 1064–1105.
- ▣ Rahimikia, E., Ni, H., Wang, W. (2025). *Re(Visiting) time series foundation models in finance*. arXiv:2511.18578.
- ▣ Rasul, K., Ashok, A., Williams, A.R., Ghonia, H., et al. (2023). *Lag-Llama: towards foundation models for probabilistic time series forecasting*. arXiv:2310.08278.
- ▣ Rosenblatt, F. (1958). *The perceptron: a probabilistic model for information storage and organization in the brain*. *Psychological Review*, 65(6), 386–408.
- ▣ Rumelhart, D.E., Hinton, G.E., Williams, R.J. (1986). *Learning representations by back-propagating errors*. *Nature*, 323(6088), 533–536.
- ▣ Salinas, D., Flunkert, V., Gasthaus, J., Januschowski, T. (2020). *DeepAR: probabilistic forecasting with autoregressive recurrent networks*. *International Journal of Forecasting*, 36(3), 1181–1191.
- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., et al. (2017). *Attention is all you need*. *NeurIPS*; arXiv:1706.03762.

Bibliografie (6/6)

- Woo, G., Liu, C., Kumar, A., Xiong, C., Savarese, S., Sahoo, D. (2024). Unified training of universal time series forecasting Transformers. *ICML*; arXiv:2402.02592.