



Modelarea piețelor financiare

Capitolul 15: LLM-uri și analiza sentimentului



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ API: Application Programming Interface (interfață de programare a aplicațiilor)
- ▣ AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ BERT: Bidirectional Encoder Representations from Transformers (reprezentări bidirecționale produse de codificatorul unui Transformer)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ FNSPID: Financial News and Stock Price Integration Dataset (setul de date care integrează știri financiare și prețuri de acțiuni)
- ▣ GI: (Harvard) General Inquirer, dictionary IV-4 (dicționarul Harvard General Inquirer IV-4)
- ▣ GPT: Generative Pre-trained Transformer (Transformer generativ pre-antrenat)
- ▣ GPT-4: Generative Pre-trained Transformer 4 (Transformer generativ pre-antrenat, versiunea 4)
- ▣ GPU: Graphics Processing Unit (procesor grafic)
- ▣ LLM: Large Language Model (model lingvistic mare)
- ▣ LM: Loughran-McDonald (financial sentiment dictionary) (dicționarul financiar de sentiment Loughran-McDonald)
- ▣ LR: Likelihood Ratio (test) (testul raportului de verosimilitate)
- ▣ MIT: Massachusetts Institute of Technology (Institutul de Tehnologie din Massachusetts)
- ▣ PCA: Principal Component Analysis (analiza componentelor principale)
- ▣ RLHF: Reinforcement Learning from Human Feedback (învățare prin recompensă din evaluări umane)
- ▣ TF-IDF: Term Frequency - Inverse Document Frequency (frecvența termenului înmulțită cu inversul frecvenței în documente)
- ▣ US: United States (Statele Unite ale Americii)
- ▣ UTC: Coordinated Universal Time (Temps Universel Coordonné) (timpul universal coordonat)
- ▣ VADER: Valence Aware Dictionary and sEntiment Reasoner (dicționar și reguli pentru valența și sentimentul textelor)

Cuprins

De ce text?

Dicționare

Date etichetate și evaluare

Modele de limbaj ajustate fin: FinBERT

Modele mari de limbaj

Embeddings ca variabile

Privirea în viitor și memorarea

De la sentiment la un semnal de tranzacționare


Agenți AI în tranzacționare

Practică și concluzii

Bibliografie

Piețele funcționează cu cuvinte

- Prețurile se mișcă atunci când sosește informație, iar cea mai mare parte a informației sosește ca text
 - ▶ Știri, raportări ale companiilor, conferințe despre rezultate, rapoarte ale analiștilor, comunicate ale băncilor centrale, rețele sociale
- Ziarele financiare sunt la fel de vechi ca piețele organizate
 - ▶ The Wall Street Journal: primul număr pe 8 iulie 1889 (fotografia)
- Astăzi: milioane de documente pe zi, mult mai multe decât poate citi orice analist



The Wall Street Journal, primul număr, 8 iulie 1889

Foto: Dow Jones & Company (1889); domeniu public;

[Wikimedia Commons](#)

Textul ca date

- Gentzkow, Kelly & Taddy (2019): un text devine o matrice de numere, care intră într-un model statistic obișnuit
 - ▶ Pasul 1: documentul d este reprezentat prin numere x_d (frecvențe, scoruri, vectori)
 - ▶ Pasul 2: x_d este transformat într-o mărime de interes (sentiment, temă, risc)
 - ▶ Pasul 3: mărimea este folosită într-o întrebare economică (randamente, volatilitate, decizii)
- Sinteze pentru finanțe: Kearney & Liu (2014), Loughran & McDonald (2016)
- Acest capitol: pasul 2 pentru sentiment, apoi pasul 3 pentru randamentele zilnice ale acțiunilor

Ce înțelegem prin sentiment

- **Sentimentul unui text:** este o știre bună, rea sau neutră pentru activul pe care îl menționează?
 - ▶ Trei clase: pozitiv, neutru, negativ; sau un scor continuu în $[-1, 1]$
 - ▶ Scorul net din probabilitățile claselor: $s = P(\text{pozitiv}) - P(\text{negativ})$
- Nu este același lucru cu **sentimentul investitorilor**: starea de spirit a investitorilor, măsurată din date de piață (Baker & Wurgler (2006))
 - ▶ Sentimentul textelor este o componentă a sentimentului investitorilor, nu un sinonim

Primele dovezi: cuvintele mișcă prețurile

- Antweiler & Frank (2004): mesajele de pe forumurile despre acțiuni ajută la prognoza volatilității; efectul asupra randamentelor este mic
- Tetlock (2007): pesimismul ridicat dintr-o rubrică a Wall Street Journal anunță presiuni de scădere a prețurilor, urmate de o revenire
 - ▶ Pesimismul neobișnuit de mare sau de mic anunță și volume mari de tranzacționare
- Tetlock, Saar-Tsechansky & Macskassy (2008): ponderea cuvintelor negative din știrile despre o firmă anunță câștiguri mici și randamente absorbite doar treptat
- Ideea comună: textul conține informație pe care prețurile o absorb repede, dar nu întotdeauna instantaneu

Narațiuni și piețe

- **Shiller (2017)**: poveștile populare se răspândesc ca epidemiile și influențează deciziile economice
 - ▶ Narațiunile pot fi măsurate doar prin text: ziare, cărți, rețele sociale
- **Shiller**: Premiul Nobel pentru Economie 2013, împreună cu Fama și Hansen
 - ▶ Capitolul 2 (eficiența) și Capitolul 17 (bulele) se întâlnesc aici: narațiunile pot îndepărta prețurile de fundamente



Robert J. Shiller, Stockholm, decembrie 2013

Foto: **Bengt Nyman (2013)**; CC BY 2.0; [Wikimedia Commons](#)

Patru moduri de a transforma textul în sentiment

Metoda	Cum funcționează	Etichete necesare	Exemple
Dicționar	numără cuvintele din listă	niciuna	GI, LM, VADER
Model ajustat fin	rețea antrenată pe propoziții etichetate	mii	FinBERT
Model mare de limbaj	instrucțiune în limbaj natural (prompt)	niciuna (zero-shot)	Qwen2.5, GPT
Embeddings + clasificator	vectorii textelor într-o regresie	sute până la mii	MiniLM

- ▣ Le comparăm pe toate patru pe aceleași date etichetate, cu intervale de încredere
- ▣ Apoi ne întrebăm dacă vreuna produce câștiguri pe randamentele zilnice ale acțiunilor

Recapitularea secțiunii

- ▣ Cea mai mare parte a informației financiare este text; textul devine date printr-o reprezentare numerică
- ▣ Sentimentul textului: tonul unui document despre un activ, sub formă de clase sau de scor în $[-1, 1]$
- ▣ Patru familii de metode, de la liste de cuvinte la modele mari de limbaj


Mulțimea de cuvinte și tonul

- ▣ **Mulțimea de cuvinte (bag of words):** documentul este redus la frecvențele cuvintelor; ordinea este ignorată
 - ▶ Tokeni: cuvintele scrise cu majuscule, fără cifre și semne de punctuație
- ▣ Un dicționar listează cuvintele pozitive $\mathcal{P}$ și cuvintele negative $\mathcal{N}$
 - ▶ P_d, N_d : numărul de cuvinte pozitive și negative din documentul d
 - ▶ **Tonul:** $\tau_d = \frac{P_d - N_d}{P_d + N_d} \in [-1, 1]$, iar $\tau_d = 0$ dacă $P_d + N_d = 0$
 - ▶ Clasa: pozitiv dacă $\tau_d > 0$, negativ dacă $\tau_d < 0$, neutru altfel
- ▣ Transparent, rapid și fără date de antrenare; nu vede contextul și negația

Dicționare generale versus financiare

- **Harvard General Inquirer** (GI), lista IV-4: un dicționar de psihologie din anii 1960
 - ▶ 2 007 cuvinte negative și 1 637 pozitive
- **Loughran & McDonald (2011)** (LM): construit din rapoartele anuale (formularele 10-K) ale firmelor americane
 - ▶ 2 355 cuvinte negative și doar 354 pozitive; plus liste pentru incertitudine și litigii
 - ▶ Concluzia lor: aproape trei sferturi dintre cuvintele negative din GI nu sunt negative în context financiar
- În listele folosite aici: 1 552 cuvinte negative din GI (77%) nu sunt cuvinte negative în LM

Negative pentru un psiholog, neutre pentru un contabil



- Cuvinte negative în GI, dar nu în LM, ordonate după numărul de propoziții din Financial PhraseBank care le conțin
- Culoarea: eticheta de sentiment dată propoziției de adnotatorii umani

Interpretare: finanțele au propriul vocabular

- ▣ „Service” (106 de propoziții), „capital” (104) și „board” (79) sunt substantive din afaceri, nu vești proaste
 - ▶ Ponderea propozițiilor lor care nu sunt etichetate negativ: 98%, 93%, 96%
 - ▶ „Vice” apare în „vice president”: 100% dintre propozițiile lui nu sunt negative
- ▣ „Lower” este excepția: doar 26% nu sunt negative, dar „costuri mai mici” este o veste bună
 - ▶ Semnul depinde de cuvântul următor: o problemă pe care nicio listă de cuvinte nu o poate rezolva
- ▣ Din cele 964 propoziții ale căror singure cuvinte negative sunt de acest tip, 89% nu sunt etichetate negativ

Exemplu lucrat: o propoziție, două dicționare

- Propoziție din Financial PhraseBank, etichetată **pozitiv** de toți adnotatorii:
 - ▶ *Uponor improved its performance in spite of the decrease in residential construction in the US .*
- LM: cuvinte pozitive improved; cuvinte negative –
 - ▶ $\tau = (1 - 0)/(1 + 0) = +1,00$: pozitiv, corect
- GI: cuvinte pozitive –; cuvinte negative spite, decrease
 - ▶ $\tau = (0 - 2)/(0 + 2) = -1,00$: negativ, greșit
 - ▶ GI nu recunoaște „improved” și numără „spite” și „decrease”, care descriu piața, nu firma

VADER: reguli peste o listă de cuvinte

- **Hutto & Gilbert (2014)**: un lexicon cu scoruri de intensitate pentru circa 7.500 de termeni, construit pentru rețelele sociale
 - ▶ Reguli pentru negație („not good”), intensificatori („very”), majuscule, semne de exclamare și emoticoane
 - ▶ Rezultatul: un scor compus în $[-1, 1]$; pragurile uzuale $\pm 0,05$ pentru pozitiv și negativ
- Regulile rezolvă unele probleme de context, dar vocabularul rămâne general, nu financiar
 - ▶ Este al doilea reper general în testele noastre, alături de GI

Recapitularea secțiunii

- ▣ Tonul după dicționar: $(P - N)/(P + N)$ din frecvențele cuvintelor listate
- ▣ Dicționarele generale citesc greșit finanțele: majoritatea cuvintelor negative din GI sunt cuvinte obișnuite din afaceri
- ▣ LM corectează vocabularul, nu contextul: „costuri mai mici” contează în continuare ca negativ

Financial PhraseBank

- Malo et al. (2014): 4 846 propoziții din știri financiare despre firme listate
 - ▶ Fiecare propoziție este etichetată de 16 adnotatori cu pregătire în finanțe și afaceri
 - ▶ Întrebarea: este propoziția o veste bună, rea sau neutră pentru investitor?
- Niveluri de acord: cel puțin 50%, 66%, 75% sau 100% dintre adnotatori au ales eticheta
 - ▶ 2 264 de propoziții cu acord deplin; 629 la care doar jumătate au fost de acord
- Etichete: 59% neutre, 28% pozitive, 12% negative

Twitter Financial News

- Titluri de știri financiare publicate pe Twitter în 2022, etichetate bearish, bullish sau neutre
 - ▶ Set de antrenare cu 9.543 și set de validare cu 2 388 de titluri; evaluăm pe setul de validare
 - ▶ Etichete: 66% neutre, 20% pozitive, 15% negative
- Texte scurte, zgomotoase, cu simboluri bursiere și linkuri: mai aproape de fluxul real de știri decât PhraseBank
 - ▶ Publicat sub licența MIT pe Hugging Face Hub
- Două seturi de date, pentru că un rezultat obținut pe un set s-ar putea să nu se păstreze pe altul


Măsurarea unui clasificator

- ▣ **Acuratețea:** ponderea textelor cu eticheta corectă
 - ▶ Reperul: a prezice mereu „neutru” dă 66% pe Twitter și 59% pe PhraseBank
- ▣ Pentru clasa k : precizia = $\frac{TP_k}{TP_k + FP_k}$, recall-ul = $\frac{TP_k}{TP_k + FN_k}$, $F1_k = \frac{2 \text{ prec} \cdot \text{rec}}{\text{prec} + \text{rec}}$
 - ▶ TP_k : texte din clasa k etichetate k ; FP_k : alte texte etichetate k ; FN_k : texte din clasa k etichetate altfel
- ▣ **F1 macro:** media $F1_k$ pe cele trei clase; fiecare clasă contează la fel
 - ▶ „Mereu neutru” are un F1 macro de doar 26,4% pe Twitter

Inferență pentru clasificatori

- Intervalul bootstrap: reeșantionăm cele n texte cu întoarcere, recalculăm acuratețea, luăm cuantilele de 2,5% și 97,5%
 - ▶ Cu $n \approx 2,400$ de texte și acuratețe în jur de 70%, CI 95% este de circa $\pm 1,8$ puncte procentuale
- **Testul McNemar**: doi clasificatori pe aceleași texte
 - ▶ n_{01} : A greșește și B are dreptate; n_{10} : A are dreptate și B greșește; textele pe care ambii le tratează la fel nu aduc informație
 - ▶ Sub H_0 (acuratețe egală), $n_{01} \sim \text{Binomial}(n_{01} + n_{10}; 0,5)$: un test exact
- Testele pe perechi sunt mult mai puternice decât compararea a două intervale separate

Unsprezece clasificatori, două seturi de date




- TF-IDF + LR și MiniLM + LR: regresii logistice antrenate pe setul de antrenare Twitter; celelalte metode nu folosesc nicio etichetă Twitter

Interpretare: niciun câștigător unic

- ▣ Dicționarele generale pierd în fața clasei majoritare pe ambele seturi: GI 43,6%, VADER 49,6% pe Twitter
 - ▶ LM este mai bun (60,5%), dar tot sub „mereu neutru” (66%) pe Twitter
- ▣ FinBERT: 89,0% pe PhraseBank, 72,5% pe Twitter; Qwen2.5-7B zero-shot: 81,4% și 74,2%
 - ▶ Cel mai bun pe Twitter este cel mai simplu model supervizat: TF-IDF + regresie logistică, 83,2%
 - ▶ TF-IDF: frecvențele cuvintelor și ale perechilor de cuvinte, ponderate în jos când termenul apare în multe documente
- ▣ Lecția: datele etichetate din domeniul-țintă contează mai mult decât dimensiunea modelului

Când oamenii nu sunt de acord, nici modelele nu sunt



□ Financial PhraseBank împărțit după cel mai înalt nivel de acord atins de cei 16 adnotatori

Interpretare: ambiguitatea impune un plafon

- ▣ Acord deplin: FinBERT 97%, Qwen2.5-14B 94%, LM 65%
 - ▶ Doar jumătate dintre adnotatori sunt de acord: FinBERT 70%, Qwen2.5-14B 55%, LM 54%
- ▣ Multe propoziții sunt cu adevărat ambigue: chiar și experții se împart
 - ▶ Un model nu poate fi judecat pe o etichetă asupra căreia oamenii nu sunt de acord
- ▣ Pentru semnale: un ton puternic și clar este mai informativ decât unul la limită

Recapitularea secțiunii

- Două seturi de date etichetate: Financial PhraseBank (propoziții din știri) și Twitter Financial News (titluri)
- Raportați acuratețea cu CI și $F1$ macro; comparați clasificatorii cu testul McNemar pe perechi
- Dicționarele generale eșuează; modelele supervizate din domeniul-țintă sunt greu de învins


De la cuvinte la cuvinte în context

- Un dicționar dă cuvântului „lower” un semn fix; un model de limbaj citește propoziția din jurul lui
 - ▶ Fiecare token primește un vector care depinde de toți ceilalți tokeni (atenție, Capitolul 14; [Vaswani et al. \(2017\)](#))
- **BERT** ([Devlin et al. \(2019\)](#)): un codificator Transformer pre-antrenat pe cărți și Wikipedia
 - ▶ Sarcina de pre-antrenare: ghicirea cuvintelor ascunse aleator într-o propoziție (modelarea limbajului cu mascare)
 - ▶ Circa 110 milioane de parametri în versiunea de bază
- Ajustarea fină: se adaugă un strat mic de clasificare și se antrenează toată rețeaua pe propoziții etichetate

FinBERT

- ▣ [Araci \(2019\)](#): BERT pre-antrenat suplimentar pe știri financiare, apoi ajustat fin pentru sentiment
 - ▶ Modelul public folosit aici (ProsusAI/finbert) a fost ajustat fin pe Financial PhraseBank
 - ▶ Rezultatul: probabilitățile pentru pozitiv, negativ și neutru
- ▣ [Huang, Wang & Yang \(2023\)](#): un FinBERT antrenat pe rapoarte ale analiștilor, transcrieri ale conferințelor despre rezultate și formulare 10-K
 - ▶ Depășește dicționarele și alte metode de învățare automată, mai ales pe propozițiile pe care dicționarele le citeșc greșit
- ▣ Rulează pe un laptop obișnuit: câteva milisecunde pe propoziție

Unde sunt erorile



- Setul de validare Twitter: rândurile sunt etichetele adevărate, coloanele etichetele prezise; numărul de texte în celule

Interpretare: modele diferite, greșeli diferite

- ▣ LM trimite majoritatea titlurilor pozitive la neutru: lista lui pozitivă este scurtă (354 cuvinte)
- ▣ FinBERT greșește în ambele direcții în jurul clasei neutre
- ▣ Qwen2.5-7B găsește aproape toate titlurile pozitive și negative, dar consideră multe titluri neutre pozitive sau negative
 - ▶ Un LLM „vede” sentiment acolo unde adnotatorii au văzut simple fapte: recall mare, precizie mică pe clasele extreme
- ▣ Pentru tranzacționare, alarmele false costă bani: contează precizia pe clasele extreme

Capcana evaluării în eşantion

- ▣ FinBERT: 89,0% pe PhraseBank, datele pe care a fost antrenat; 72,5% pe Twitter
 - ▶ Scăderea: circa 16 puncte procentuale
- ▣ Qwen2.5-7B, neantrenat pe aceste etichete: 81,4% și 74,2%
 - ▶ O parte din avantajul FinBERT pe PhraseBank este memoria propriilor date de antrenare
- ▣ Regula: evaluați un model de limbaj doar pe texte pe care nu le-a văzut niciodată
 - ▶ Aceeași logică ca testarea în afara eşantionului din capitolele 8 și 13

Exemplu lucrat: este FinBERT mai bun decât LM?


- ▣ Setul de validare Twitter, 2 388 de titluri: LM 60,5%, FinBERT 72,5%
 - ▶ LM greșește și FinBERT are dreptate: $n_{01} = 539$; LM are dreptate și FinBERT greșește: $n_{10} = 252$
 - ▶ Testul McNemar exact: $p < 0,001$
- ▣ Diferența: +12,0 puncte procentuale, CI 95% bootstrap [+10,0; +14,2]
 - ▶ Victorie clară a modelului ajustat fin, chiar și în afara datelor lui de antrenare

Recapitularea secțiunii

- Transformerile pre-antrenate citesc cuvintele în context; ajustarea fină le adaptează cu propoziții etichetate
- FinBERT bate orice dicționar în afara eșantionului, dar scorul lui pe PhraseBank este umflat de suprapunerea cu datele de antrenare
- Priviți matricea de confuzie, nu doar acuratețea

Problema următorului cuvânt

- ▣ **Shannon (1951)**: cât de bine poate fi ghicită următoarea literă a unui text englez din literele anterioare?
 - ▶ Limbajul este foarte previzibil: entropia lui este mult sub cea a unor litere aleatoare
- ▣ Un model mare de limbaj (LLM) face același lucru cu tokeni:
 $P(w_{t+1} \mid w_1, \dots, w_t)$
 - ▶ Antrenat pe mii de miliarde de tokeni de text și cod
 - ▶ **Quantinar: The Next Word Problem** și **Quantinar: Natural Language Processing** acoperă noțiunile de bază



Claude E. Shannon, fondatorul teoriei informației

Foto: Tekniska museet, Stockholm (fără dată); CC BY

2.0; Wikimedia Commons

De la predicție la instrucțiuni

- [Brown et al. \(2020\)](#): un model suficient de mare de predicție a cuvântului următor rezolvă sarcini din câteva exemple date în prompt (few-shot)
- [Ouyang et al. \(2022\)](#): ajustarea pe instrucțiuni și RLHF învață modelul să urmeze cereri
 - ▶ Oameni ordonează răspunsurile candidate; modelul este antrenat să producă răspunsuri bine clasate
- LLM-uri specifice finanțelor: BloombergGPT ([Wu et al. \(2023\)](#)), 50 de miliarde de parametri, antrenat pe text financiar și general
 - ▶ Modelele deschise generale egalează acum multe modele specifice finanțelor la sarcinile de sentiment


Clasificarea zero-shot cu un LLM

- Prompt-ul: o instrucțiune de sistem plus textul de clasificat
 - ▶ You classify the sentiment of financial news for investors. Answer with one word: positive, negative or neutral.
 - ▶ Headline: <text> Sentiment:
- Citim probabilitățile celor trei cuvinte-răspuns la prima poziție generată
 - ▶ Logiții z_k ai tokenilor „positive”, „negative”, „neutral”: $p_k = e^{z_k} / \sum_j e^{z_j}$
 - ▶ Eticheta: $\arg \max_k p_k$; scorul: $p_{\text{poz}} - p_{\text{neg}}$; nu se generează text, deci nu trebuie interpretat nimic

Modelele: Qwen2.5-Instruct

- ▣ [Qwen Team \(2024\)](#): modele cu ponderi deschise, de la 0,5 la 72 de miliarde de parametri, ponderi publicate pe 19 septembrie 2024
 - ▶ Folosim 0.5B, 1.5B, 3B, 7B și 14B (B: miliarde de parametri), toate cu licențe deschise
- ▣ Viteza pe procesorul grafic (GPU) al unui laptop, pe titlu, inclusiv procesarea prompt-ului
 - ▶ 0.5B: 4 ms; 1.5B: 12 ms; 3B: 20 ms; 7B: 92 ms; 14B: 88 ms
 - ▶ Ponderi deschise: rezultatele pot fi reproduse, iar data publicării limitează ce putea ști modelul

Mai mare nu înseamnă întotdeauna mai bun




□ F1 macro pentru Qwen2.5 zero-shot cu același prompt; liniile punctate: FinBERT

 MFM_ch15_llm_zero_shot

Interpretare: dimensiunea ajută, dar inegal

- ▣ PhraseBank: F1 macro crește de la 63,3% (0.5B) la 82,1% (14B), tot sub FinBERT (88,3%)
 - ▶ Avantajul FinBERT de acolo vine parțial din suprapunerea cu datele de antrenare (secțiunea anterioară)
- ▣ Twitter: nu crește monoton; 1.5B este cel mai slab (55,3%), 7B cel mai bun (72,6%), peste FinBERT (66,8%)
 - ▶ 7B față de 1.5B la acuratețe: +21,5 puncte, McNemar $p < 0,001$
- ▣ Modelele mici reacționează puternic la formulare: modelul 1.5B răspunde rar „neutral” cu acest prompt

Același model, altă formulare



□ Trei prompt-uri care pun aceeași întrebare; setul de validare Twitter

 MFM_ch15_llm_zero_shot

Interpretare: prompt-ul este un parametru

- ▣ Intervalele de acuratețe: 1.5B între 52,7% și 61,7%; 7B între 73,7% și 77,8%; 14B între 69,9% și 75,6%
 - ▶ Cele trei prompt-uri dau aceeași etichetă doar pentru 67% dintre titluri (7B)
 - ▶ Ponderea răspunsurilor „neutral” pentru 7B: de la 48% (P1) la 69% (P3)
- ▣ Alegerea prompt-ului după ce ați văzut rezultatele pe test este o formă de data snooping (Capitolul 13)
 - ▶ Fixați prompt-ul dinainte sau alegeți-l pe un set de validare separat

Exemplu lucrat: LLM versus FinBERT

- ▣ Twitter, prompt-ul P1: Qwen2.5-7B 74,2%, FinBERT 72,5%
 - ▶ $n_{01} = 395$, $n_{10} = 355$; McNemar $p = 0,154$; diferența +1,7 puncte, CI 95% [-0,5; +3,8]
 - ▶ Qwen2.5-14B față de FinBERT: -0,1 puncte, $p = 0,942$
- ▣ Nicio diferență semnificativă: un model cu de 70 până la 130 de ori mai mulți parametri, de câteva ori mai lent, nu este mai precis
 - ▶ Unde ajută LLM-urile: nu cer etichete, funcționează în orice limbă, pe documente mai lungi și mai complexe

Dincolo de titluri: documente lungi

- ▣ Rapoarte anuale: [Loughran & McDonald \(2011\)](#) și-au construit listele din formulare 10-K; tonul și incertitudinea anunță randamentele și volatilitatea în jurul publicării
- ▣ Conferințe despre rezultate și rapoarte ale analiștilor: [Huang, Wang & Yang \(2023\)](#) arată că FinBERT extrage informație pe care dicționarele o ratează
- ▣ [Kim, Muhn & Nikolaev \(2023\)](#): rezumatele făcute de LLM ale raportărilor sunt mult mai scurte, dar explică mai bine reacțiile pieței decât originalele
 - ▶ Ei măsoară „umflarea” raportărilor: textul lung și puțin informativ este asociat cu o eficiență mai mică a prețurilor
- ▣ Documentele lungi cer modele cu ferestre de context lungi sau împărțire în bucăți și agregare


Recapitularea secțiunii

- Un LLM prezice tokenul următor; sentimentul zero-shot citește probabilitățile cuvintelor-răspuns
- Acuratețea crește în medie cu dimensiunea, dar nu monoton; prompt-ul schimbă rezultatul
- Pe titluri financiare scurte, un model deschis de 7B până la 14B egalează FinBERT

Embeddings de text

- **Embedding:** un vector $e_d \in \mathbb{R}^k$ astfel încât textele asemănătoare primesc vectori apropiați
 - ▶ Vectori de cuvinte: [Mikolov et al. \(2013\)](#) (word2vec) îi învață din cuvintele care apar unele lângă altele
 - ▶ Vectori de propoziții: [Reimers & Gurevych \(2019\)](#) (Sentence-BERT) antrenează un Transformer astfel încât parafrazele să fie apropiate
- Aici: MiniLM ([Wang et al. \(2020\)](#)), 22 de milioane de parametri, $k = 384$; media vectorilor tokenilor, scalată la lungimea 1
 - ▶ Similaritatea: $\cos(e_a, e_b) = e_a^\top e_b$ pentru vectori de lungime 1
- Utilizare: embeddings intră într-un clasificator sau într-o regresie obișnuită, ca orice altă variabilă

Cum arată embeddings




- Titlurile din setul de validare Twitter: primele două componente principale ale vectorilor MiniLM cu 384 de dimensiuni, colorate după etichetă

Interpretare: sentimentul nu este direcția principală

- Primele două componente separă teme (companii, știri macro, cripto), nu sentimentul
 - ▶ PCA (Capitolul 3) păstrează direcțiile de varianță maximă, care nu sunt neapărat cele care ne interesează
- Un model supervizat găsește direcția sentimentului printre cele 384 de dimensiuni
 - ▶ Regresia logistică pe toate dimensiunile: 78,6% acuratețe pe Twitter

De câte etichete aveți nevoie?



- Regresie logistică antrenată pe submulțimi aleatoare ale setului de antrenare Twitter, 10 repetări pentru fiecare dimensiune; banda: ± 2 abateri standard

Interpretare: câteva sute de etichete bat FinBERT

- ▣ Embeddings + regresie logistică: 69,0% cu 100 de etichete, peste FinBERT de la 400 de etichete
 - ▶ Vectorii pre-antrenați conțin deja cea mai mare parte din ce este necesar
- ▣ TF-IDF pornește mai jos (66,9%), dar continuă să crească: 83,1% cu toate cele 9.543 de etichete, față de 78,6% pentru embeddings
 - ▶ Cu multe etichete, cuvintele exacte („upgrade”, „cuts”, „misses”) poartă semnalul în titluri
- ▣ Regulă practică: etichetați câteva sute de documente din domeniul vostru înainte de a avea încredere într-un model preluat de-a gata

Variabile textuale în prognoza randamentelor

- ▣ [Jegadeesh & Wu \(2013\)](#): ponderile cuvintelor estimate din reacțiile pieței la formularele 10-K, în locul listelor fixe
- ▣ [Ke, Kelly & Xiu \(2019\)](#): un model supervizat care învață cuvintele de sentiment din știri și din randamentele care le urmează
 - ▶ Semnalul lor bazat pe text anunță randamentele, cel mai puternic în ziua știrii și în ziua următoare
- ▣ [Gu, Kelly & Xiu \(2020\)](#) (Capitolul 13): învățare automată pe multe caracteristici; variabilele textuale pot intra în același cadru
- ▣ Regula comună: estimați modelul textual doar pe date anterioare perioadei de prognoză

Recapitularea secțiunii

- Embeddings transformă textele în vectori care intră în regresii obișnuite
- Sentimentul este o direcție printre multe; învățarea supervizată o găsește
- Câteva sute de etichete din domeniu bat un model general ajustat fin; multe etichete favorizează variabilele simple bazate pe cuvinte


Modelul poate ști deja răspunsul

- Un LLM antrenat pe texte de până în 2024 a citit ce s-a întâmplat după fiecare titlu din 2015
 - ▶ Un backtest pe știrile din 2015 amestecă atunci prognoza cu amintirea
- Glasserman & Lin (2023): două distorsiuni în backtest-urile de sentiment
 - ▶ Privirea în viitor: modelul cunoaște randamentele care au urmat știrii
 - ▶ Distragerea: cunoștințele generale despre compania numită interferează cu citirea textului; în testele lor a contat mai mult decât privirea în viitor
- Sarkar & Vafa (2024): teste directe arată privirea în viitor în aplicații ale LLM-urilor la conferințe despre rezultate și la alegeri

Testul nostru: întrebăm despre trecut, fără context

- Lunar: „Did the S&P 500 index rise or fall during <lună an>?”, pentru 296 de luni dinainte de publicare plus 23 după
 - ▶ Zilnic: „Did Apple stock close higher or lower on <dată> than on the previous trading day?”, 500 de zile aleatoare din 2010–2023 și 493 de zile după octombrie 2024
- Scorul: $P(\text{creștere})$ din probabilitățile cuvintelor-răspuns; direcția adevărată din seria de prețuri salvată
 - ▶ AUC: probabilitatea ca o perioadă aleatoare de creștere să primească un scor mai mare decât una aleatoare de scădere; $0,5 = \text{nicio cunoaștere}$ (Capitolul 13)
- După publicarea ponderilor, modelul nu poate ști: acolo AUC trebuie să fie 0,5

Ce „își amintește” Qwen2.5-14B despre S&P 500




□ Probabilitatea răspunsului „rise” pentru fiecare lună, fără context; culoarea: ce a făcut de fapt indicele

 MFM_ch15_lookahead

Interpretare: își amintește regimuri și câteva luni celebre

- „Fall” pentru 2000–2002 și 2008–2009, „rise” pentru cea mai mare parte din 2003–2007 și 2013–2021: piețele în scădere și în creștere
 - ▶ Octombrie 2008 (-16,9%), martie 2020 (-12,5%), decembrie 2018 (-9,2%): $P(\text{creștere}) \approx 0$
 - ▶ Dar septembrie 2002 (-11,0%) și februarie 2009 (-11,0%) primesc $P(\text{creștere})$ aproape de 1
- După publicare, răspunsurile tind spre „rise”: nicio cunoaștere, doar convingerea generală că piețele cresc
- Cunoașterea este grosieră: episoade memorabile, nu fiecare lună

Memoria măsurată: AUC înainte și după publicare



- Intervale bootstrap de 95%; 0,5 înseamnă că modelul nu poate distinge creșterile de scăderi

Interpretare: lunile da, zilele nu

- ▣ Lunile dinainte de publicare: AUC 0,67 (7B, CI [0,61; 0,73]) și 0,69 (14B, CI [0,62; 0,75])
 - ▶ Valoarea p prin permutări pentru 14B: 0,000; modelul 1.5B știe mult mai puțin (0,57)
 - ▶ După publicare (23 luni): intervalele includ 0,5, dar sunt prea largi pentru a dovedi ceva
- ▣ Zile individuale pentru Apple: AUC între 0,48 și 0,52 înainte de publicare; nicio memorie zilnică
 - ▶ Privirea în viitor este un pericol pentru backtest-uri la orizontul evenimentelor bine cunoscute, mai puțin pentru zgomotul zilnic

Remedii


- ▣ Testați doar după data-limită a datelor de antrenare: [Lopez-Lira & Tang \(2026\)](#) evaluează GPT-4 pe titluri de după data-limită a cunoștințelor modelului
 - ▶ Curat, dar fereastra de test începe târziu și crește încet
- ▣ Eliminați numele companiilor și datele din text înainte de a-l evalua ([Glasserman & Lin \(2023\)](#))
- ▣ Folosiți modele ale căror date de antrenare se termină înainte de perioada de test (modele la un moment dat; [Sarkar & Vafa \(2024\)](#))
- ▣ Raportați versiunea modelului și data publicării ponderilor sale împreună cu fiecare rezultat

Recapitularea secțiunii

- LLM-urile antrenate pe texte recente au cunoștințe despre trecut pe care un backtest nu trebuie să le folosească
- Qwen2.5-7B și 14B „știu” parțial direcția lunară a S&P 500 dinainte de 2024, nu zilele individuale
- Dovezile curate cer date de după data-limită, text anonimizat sau modele la un moment dat

Date: titluri datate și prețuri


- ▣ FNSPID (Dong, Fan & Peng (2024)): 15,7 milioane de știri despre firmele din S&P 500, 1999–2023, de pe patru site-uri de știri
 - ▶ Licența CC BY-NC 4.0 (utilizare necomercială)
- ▣ Aici: 16 acțiuni americane mari cu prețuri zilnice în datele cursului (tehnologie, bănci, GameStop, Strategy)
 - ▶ 106 820 titluri distincte după eliminarea repetițiilor; 18 282 zile-acțiune cu știri, între 27.10.2009 și 18.12.2023



Bandă de știri pe clădirea Reuters, New York

Foto: [bgilliard](#) (2005); CC BY-SA 2.0; [Wikimedia Commons](#)

Câte titluri și când




- Titluri despre cele 16 acțiuni pe an, după ziua de tranzacționare la care sunt atribuite

 MFM_ch15_news_data

Interpretare: acoperirea este inegală

- ▣ 34 380 titluri doar în 2023, față de 8 445 în toți anii dinainte de 2016
 - ▶ Rezultatele sunt dominate de anii recentți; primii ani au puține zile cu știri pe acțiune
- ▣ Într-o zi cu știri, o acțiune are în medie 5,8 titluri
 - ▶ Scorul zilnic: media scorurilor titlurilor pentru acțiunea și ziua respectivă
- ▣ Supraviețuirea: cele 16 acțiuni sunt firmele mari de astăzi, alese cu beneficiul retrospectivității

Problema marcajului de timp



- Ora marcajului de timp FNSPID în timpul universal coordonat (UTC), scară logaritmică

 MFM_ch15_news_data

Interpretare: date, nu ore

- ▣ 99,8% dintre titluri au marcajul exact 00:00 UTC: sursa dă data, nu ora publicării
 - ▶ Un titlu datat d poate apărea înainte de deschidere, în timpul ședinței sau după închiderea zilei d
- ▣ Alinierea folosită aici, fără privire în viitor
 - ▶ Ziua d : prima zi de tranzacționare egală cu data titlului sau ulterioară
 - ▶ Randamentele din d și $d + 1$ pot conține încă reacția; prima prognoză sigură este randamentul din $d + 2$ (de la închiderea din $d + 1$ la închiderea din $d + 2$)
- ▣ Randamentul în exces: randamentul acțiunii minus randamentul SPY (un fond pe indicele S&P 500) în aceeași zi


Trei scoruri pentru fiecare titlu

- ▣ Tonul LM; scorul net FinBERT $P(\text{poz}) - P(\text{neg})$; scorul net Qwen2.5-7B cu prompt-ul P1
 - ▶ LM găsește un cuvânt din listă doar în 27% dintre titluri: restul primesc tonul 0
 - ▶ Etichetele FinBERT: 19% negative, 62% neutre, 18% pozitive
- ▣ Corelațiile pe titluri: FinBERT–Qwen 0,62, FinBERT–LM 0,41, Qwen–LM 0,36
 - ▶ Cele două modele de limbaj sunt mult mai de acord între ele decât cu dicționarul
- ▣ Scorurile sunt standardizate pe panel (medie 0, abatere standard 1) înainte de regresii

Designul regresiei

- ▣ Regresie pe toate zilele-acțiune cu știri: $r_{i,d+h}^e = a + b z_{i,d} + \varepsilon_{i,d+h}$, $h = 0, 1, 2$
 - ▶ r^e : randamentul în exces (%); z : scorul zilnic standardizat; b : randamentul pentru o abatere standard a scorului
- ▣ Erorile acțiunilor din aceeași zi sunt corelate (șocuri comune): grupăm erorile standard pe zile ([Petersen \(2009\)](#))
 - ▶ $\hat{V} = (X^\top X)^{-1} \left(\sum_g X_g^\top \hat{\varepsilon}_g \hat{\varepsilon}_g^\top X_g \right) (X^\top X)^{-1}$, g : zile de tranzacționare
- ▣ $h = 0$ măsoară reacția, $h = 2$ măsoară predictibilitatea

Reacție versus predicție




□ Panta b în puncte de bază (bp) pentru o abatere standard a scorului, cu CI 95% grupat pe zile

 MFM_ch15_news_signal

Interpretare: titlurile descriu prețurile

- ▣ Ziua d : FinBERT +39,2 bp ($t = +17,27$), Qwen +41,4 bp ($t = +19,07$), LM +15,5 bp ($t = +8,53$)
 - ▶ Multe titluri relatează chiar mișcarea prețului („shares jump”, „stock falls”): cauzalitatea merge în ambele sensuri
- ▣ Ziua $d + 1$: FinBERT +3,2 bp ($t = +1,60$), Qwen +3,7 bp ($t = +1,86$)
 - ▶ O parte din acest efect vine din știri publicate după închiderea zilei d , nu dintr-o prognoză
- ▣ Ziua $d + 2$: FinBERT -0,5 bp ($t = -0,25$), Qwen +2,3 bp ($t = +1,19$), LM -0,0 bp ($t = -0,01$)

Studiu de eveniment în jurul zilelor cu știri



- Randamentul în exces cumulat mediu din ziua -5 până în ziua $+5$; zilele cu știri împărțite pe tercelele scorului zilnic FinBERT; zona hașurată: zilele tranzacționabile $d + 2 - d + 5$

 MFM_ch15_news_signal


Interpretare: mișcarea are loc înainte de știre și în ziua ei

- ▣ Treimea cea mai pozitivă: +0,63% în cele 5 zile dinainte, +0,50% în ziua d , +0,11% în $d + 1$
 - ▶ Treimea cea mai negativă: +0,06%, -0,38% și +0,06%
- ▣ Zilele tranzacționabile $d + 2 - d + 5$: +0,43% (pozitiv) și +0,19% (negativ)
 - ▶ Până când un investitor poate acționa pe baza titlului, prețul s-a ajustat în mare parte: piețe eficiente (Capitolul 2)
- ▣ Mișcările dinaintea evenimentului: informația se scurge sau titlurile sunt scrise după ce prețul s-a mișcat deja

O strategie zilnică de sentiment

- La închiderea din $d + 1$: pentru fiecare acțiune cu știri în ziua d , cumpărăm dacă scorul este pozitiv și vindem în lipsă dacă este negativ
 - ▶ Fiecare poziție este acoperită cu SPY; ponderi egale; închidem după o zi și câștigăm randamentul în exces din $d + 2$
 - ▶ Zilele fără știri: nicio poziție, randament 0
- Costuri: 5 bp pe tranzacție; patru tranzacții pe zi cu poziții (acțiunea și SPY, la intrare și la ieșire)
 - ▶ Costul de echilibru: randamentul brut mediu în zilele cu poziții împărțit la 4
- Inferența: t Newey–West (Capitolul 2) și CI bootstrap pe blocuri pentru randamentul zilnic mediu

Randamentele cumulate ale strategiei




□ Suma randamentelor zilnice în exces (%), înainte de costuri și cu 5 bp pe tranzacție

 MFM_ch15_news_signal

Interpretare: un semnal mic, niciun profit net

- ▣ FinBERT: media +3,27 bp pe zi ($t = +1,27$), CI 95% [-1,51; +8,93]: nu diferă de zero
 - ▶ LM: -0,21 bp ($t = -0,07$)
- ▣ Qwen2.5-7B: +5,64 bp ($t = +2,26$), CI 95% [+0,95; +10,61]: semnificativ înainte de costuri
 - ▶ Costul de echilibru +1,5 bp pe tranzacție, mult sub 5 bp: Sharpe +0,63 înainte și -1,48 după costuri
 - ▶ Qwen2.5 a fost antrenat după 2023: o parte din avantaj poate fi memorarea prețurilor (vezi Privirea în viitor și memorarea)
- ▣ Ziua netranzacționabilă $d + 1$: FinBERT -0,22 bp ($t = -0,10$), Qwen +4,06 bp ($t = +1,36$)
 - ▶ Niciun câștig semnificativ nici aici: aproape toată reacția are loc în ziua d

Stabilitatea în timp



□ Randamentul zilnic mediu al strategiei înainte de costuri, pe subperioade

 MFM_ch15_news_signal

Interpretare: dovezi slabe, spuse cinstit

- ▣ FinBERT pe subperioade: 2010–2015 +1,4 bp, 2016–2019 -1,8 bp, 2020–2021 +24,3 bp, 2022–2023 -1,8 bp
 - ▶ Doar 2020–2021 este mare (FinBERT $t = +1,89$, Qwen +22,2 bp, $t = +1,78$): nesemnificativ la 5%, doi ani de tranzacționare a acțiunilor-meme
 - ▶ Patru tranzacții de 5 bp costă 20 bp pe zi: chiar și acea perioadă abia ar acoperi costurile
- ▣ De ce atât de puțin: 16 acțiuni foarte urmărite, marcaje de timp doar la nivel de dată, frecvență zilnică
 - ▶ Dovezile publicate de predictibilitate se bazează pe marcaje de timp precise și pe multe acțiuni mici
- ▣ Un rezultat negativ este tot un rezultat: vă arată unde nu este semnalul

Ce arată literatura

- ▣ **Lopez-Lira & Tang (2026)**: pe titluri publicate după data-limită a cunoștințelor GPT-4, modelul surprinde reacția inițială a pieței cu rate de succes de circa 90% pe zile-portofoliu
 - ▶ Reacția inițială nu este tranzacționabilă; scorurile GPT-4 anunță și deriva ulterioară, mai ales pentru acțiunile mici și știrile negative
 - ▶ Randamentele strategiilor scad pe măsură ce folosirea LLM-urilor crește: prețurile devin mai eficiente
- ▣ **Bollen, Mao & Zeng (2011)**: starea de spirit colectivă de pe Twitter a anticipat Dow Jones în 2008; rezultatul este sensibil la eșantion și metodă

Rețele sociale și mulțimi: GameStop, 2021

- ▣ Ianuarie 2021: investitori individuali s-au coordonat pe rețelele sociale și au ridicat GameStop de peste zece ori în câteva săptămâni
 - ▶ Sentimentul nu a anticipat mișcarea; mesajele au fost mișcarea
- ▣ Lecții pentru semnalele textuale
 - ▶ Volumul atenției poate conta mai mult decât tonul
 - ▶ Semnalele aglomerate se inversează și creează risc pentru vânzătorii în lipsă (Capitolul 17: bule)



Un magazin GameStop, Vallejo, California, februarie 2021

Foto: Will Buckner (2021); CC BY 2.0; Wikimedia Commons

Recapitularea secțiunii

- ▣ Aliniați știrile și prețurile cu grijă: marcajele doar la nivel de dată mută primul randament tranzacționabil în $d + 2$
- ▣ Sentimentul titlurilor este puternic legat de randamentele din aceeași zi și foarte slab de randamentele care mai pot fi tranzacționate
- ▣ Testați semnalele cu erori grupate, t Newey–West, costuri și subperioade

Ce este un agent AI?

- ▣ Un LLM într-o buclă: citește intrările, decide, apelează instrumente, observă rezultatul, repetă
 - ▶ Instrumente: interogări de date, execuția codului, căutarea știrilor, transmiterea ordinelor printr-un API
 - ▶ Memorie: note și decizii trecute păstrate între pași
- ▣ Utilizări în finanțe astăzi: rezumate de cercetare, programare și prelucrarea datelor, monitorizarea știrilor și a raportărilor
 - ▶ Tranzacționarea complet autonomă de către agenți LLM este încă rară și în mare parte experimentală

Riscurile agenților

- ▣ Riscuri de model: fapte inventate, privire în viitor în backtest-uri, sensibilitate la formulare
- ▣ Manipulare: un text citit de agent poate conține instrucțiuni (prompt injection), de exemplu un comunicat de presă fals
- ▣ Riscuri sistemice (IMF (2024)): multe firme care folosesc modele asemănătoare pot tranzacționa la fel, crescând viteza și corelația mișcărilor în perioade de stres
 - ▶ Același raport vede și beneficii: procesarea mai rapidă a informației și costuri mai mici
- ▣ Controale: limite de poziție, aprobare umană pentru ordine, jurnalizarea fiecărui pas, teste după fiecare actualizare a modelului

Lista capcanelor

- ▣ **Suprapunerea cu datele de antrenare:** FinBERT are 89,0% pe propriile date de antrenare, 72,5% pe date noi
- ▣ **Privirea în viitor:** un LLM își poate aminti piața de după știre; testați după data publicării lui
- ▣ **Momentul:** marcaje doar la nivel de dată; tranzacționați cel mai devreme la închiderea de după ce știrea este sigur publică
- ▣ **Data snooping:** prompt-uri, praguri și modele alese după ce ați văzut rezultatele pe test
- ▣ **Costuri și aglomerare:** câștigurile zilnice mici dispar după câțiva puncte de bază de costuri

Ce folosim și când

Situația	Alegerea	De ce
Reper rapid și transparent	Dicționarul LM	fără antrenare, verificabil
Texte financiare scurte în engleză	FinBERT	precis, milisecunde pe text
Fără etichete, alte limbi, documente lungi	LLM deschis (7B+)	zero-shot, flexibil
Câteva sute de etichete din domeniul vostru	embeddings + regresie logistică	ieftin și adaptat domeniului

- Oricare ar fi metoda: evaluați în afara eșantionului, cu intervale și teste pe perechi

Cercetări înrudite

- ▣ [Pele \(2024\)](#): Quantlet-ul de analiză a sentimentului din proiectul BitMood, repository-ul IDA Quantlets
- ▣ [Pele \(2025\)](#): Dogecoin și bulele speculative, studiate cu legea log-periodică de tip putere și analiza sentimentului (Quantinar)
- ▣ [Pele et al. \(2023\)](#): clasificarea statistică a cripto-activelor: când se comportă ca activele tradiționale?
- ▣ Studiu suplimentar: [Quantinar: Natural Language Processing](#), [Quantinar: DELTA](#), [Quantinar: LDA Extensions](#); manualul [Franke, Härdle & Hafner \(2019\)](#) pentru statistica din spatele testelor

Idei principale

- ▣ Dicționarele generale citesc greșit finanțele; dicționarul LM este un reper transparent
- ▣ FinBERT și LLM-urile deschise de 7B–14B sunt la egalitate statistică pe titluri financiare; câteva sute de etichete și un clasificator simplu concurează cu ambele
- ▣ LLM-urile își amintesc istoria piețelor: evaluați-le doar după data publicării lor
- ▣ Sentimentul titlurilor explică mișcările din aceeași zi; cu o aliniere realistă și costuri, nu bate piața pentru acțiunile mari

Bibliografie (1/6)

- ▣ Antweiler, W., Frank, M.Z. (2004). Is all that talk just noise? The information content of internet stock message boards. *Journal of Finance*, 59(3), 1259–1294.
- ▣ Araci, D. (2019). FinBERT: financial sentiment analysis with pre-trained language models. arXiv:1908.10063.
- ▣ Baker, M., Wurgler, J. (2006). Investor sentiment and the cross-section of stock returns. *Journal of Finance*, 61(4), 1645–1680.
- ▣ Bollen, J., Mao, H., Zeng, X. (2011). Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1), 1–8.
- ▣ Brown, T.B., Mann, B., Ryder, N., Subbiah, M., et al. (2020). Language models are few-shot learners. *NeurIPS*; arXiv:2005.14165.
- ▣ Devlin, J., Chang, M.-W., Lee, K., Toutanova, K. (2019). BERT: pre-training of deep bidirectional Transformers for language understanding. *NAACL*; arXiv:1810.04805.
- ▣ Dong, Z., Fan, X., Peng, Z. (2024). FNSPID: a comprehensive financial news dataset in time series. *Proceedings of the 30th ACM SIGKDD Conference*, 4918–4927.

Bibliografie (2/6)

- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Gentzkow, M., Kelly, B., Taddy, M. (2019). *Text as data*. *Journal of Economic Literature*, 57(3), 535–574.
- ▣ Glasserman, P., Lin, C. (2023). *Assessing look-ahead bias in stock return predictions generated by GPT sentiment analysis*. arXiv:2309.17322.
- ▣ Gu, S., Kelly, B., Xiu, D. (2020). *Empirical asset pricing via machine learning*. *Review of Financial Studies*, 33(5), 2223–2273.
- ▣ Huang, A.H., Wang, H., Yang, Y. (2023). *FinBERT: a large language model for extracting information from financial text*. *Contemporary Accounting Research*, 40(2), 806–841.
- ▣ Hutto, C., Gilbert, E. (2014). *VADER: a parsimonious rule-based model for sentiment analysis of social media text*. *Proceedings of the International AAAI Conference on Web and Social Media*, 8(1), 216–225.
- ▣ IMF (2024). *Advances in artificial intelligence: implications for capital market activities*. *Global Financial Stability Report*, October 2024, Chapter 3.

Bibliografie (3/6)

- ▣ Jegadeesh, N., Wu, D. (2013). [Word power: a new approach for content analysis](#). *Journal of Financial Economics*, 110(3), 712–729.
- ▣ Ke, Z.T., Kelly, B., Xiu, D. (2019). [Predicting returns with text data](#). NBER Working Paper 26186.
- ▣ Kearney, C., Liu, S. (2014). [Textual sentiment in finance: a survey of methods and models](#). *International Review of Financial Analysis*, 33, 171–185.
- ▣ Kim, A., Muhn, M., Nikolaev, V. (2023). [Bloated disclosures: can ChatGPT help investors process information?](#) arXiv:2306.10224.
- ▣ Lopez-Lira, A., Tang, Y. (2026). [Can ChatGPT forecast stock price movements? Return predictability and large language models](#). *Journal of Financial Economics*, 184, 104335.
- ▣ Loughran, T., McDonald, B. (2011). [When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks](#). *Journal of Finance*, 66(1), 35–65.
- ▣ Loughran, T., McDonald, B. (2016). [Textual analysis in accounting and finance: a survey](#). *Journal of Accounting Research*, 54(4), 1187–1230.

Bibliografie (4/6)

- ▣ Malo, P., Sinha, A., Korhonen, P., Wallenius, J., Takala, P. (2014). [Good debt or bad debt: detecting semantic orientations in economic texts](#). *Journal of the Association for Information Science and Technology*, 65(4), 782–796.
- ▣ Mikolov, T., Chen, K., Corrado, G., Dean, J. (2013). [Efficient estimation of word representations in vector space](#). arXiv:1301.3781.
- ▣ Ouyang, L., Wu, J., Jiang, X., Almeida, D., et al. (2022). [Training language models to follow instructions with human feedback](#). *NeurIPS*; arXiv:2203.02155.
- ▣ Pele, D.T. (2024). [Sentiment Analysis](#) (Quantlet, BitMood project). IDA Quantlets Repository, Bucharest University of Economic Studies.
- ▣ Pele, D.T. (2025). [Dogecoin and speculative bubbles: a study using LPPL and sentiment analysis](#). Quantinar course, Bucharest University of Economic Studies.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). [Are cryptos becoming alternative assets?](#) *The European Journal of Finance*, 29(10), 1064–1105.
- ▣ Petersen, M.A. (2009). [Estimating standard errors in finance panel data sets: comparing approaches](#). *Review of Financial Studies*, 22(1), 435–480.

Bibliografie (5/6)

- ▣ Qwen Team (2024). [Qwen2.5 technical report](#). arXiv:2412.15115.
- ▣ Reimers, N., Gurevych, I. (2019). [Sentence-BERT: sentence embeddings using Siamese BERT-networks](#). *EMNLP*; arXiv:1908.10084.
- ▣ Sarkar, S.K., Vafa, K. (2024). [Lookahead bias in pretrained language models](#). SSRN Working Paper 4754678.
- ▣ Shannon, C.E. (1951). [Prediction and entropy of printed English](#). *Bell System Technical Journal*, 30(1), 50–64.
- ▣ Shiller, R.J. (2017). [Narrative economics](#). *American Economic Review*, 107(4), 967–1004.
- ▣ Tetlock, P.C. (2007). [Giving content to investor sentiment: the role of media in the stock market](#). *Journal of Finance*, 62(3), 1139–1168.
- ▣ Tetlock, P.C., Saar-Tsechansky, M., Macskassy, S. (2008). [More than words: quantifying language to measure firms' fundamentals](#). *Journal of Finance*, 63(3), 1437–1467.

Bibliografie (6/6)

- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., et al. (2017). [Attention is all you need](#). *NeurIPS*; arXiv:1706.03762.
- ▣ Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., Zhou, M. (2020). [MiniLM: deep self-attention distillation for task-agnostic compression of pre-trained Transformers](#). *NeurIPS*; arXiv:2002.10957.
- ▣ Wu, S., Irsoy, O., Lu, S., Dabrovolski, V., et al. (2023). [BloombergGPT: a large language model for finance](#). arXiv:2303.17564.