



Modelarea piețelor financiare

Capitolul 15: LLM-uri și analiza sentimentului



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AMEX: American Stock Exchange (Bursa Americană de Valori)
- ▣ API: Application Programming Interface (interfață de programare a aplicațiilor)
- ▣ AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ BERT: Bidirectional Encoder Representations from Transformers (reprezentări bidirecționale produse de codificatorul unui Transformer)
- ▣ BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- ▣ BY-NC: Creative Commons Attribution-NonCommercial (licența Creative Commons: atribuire, utilizare necomercială)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ ECE: Expected Calibration Error (eroarea medie de calibrare)
- ▣ EM: Expectation-Maximisation (algorithm) (algoritmul de maximizare a așteptării)
- ▣ FDR: False Discovery Rate (rata descoperirilor false)
- ▣ FNSPID: Financial News and Stock Price Integration Dataset (setul de date care integrează știri financiare și prețuri de acțiuni)
- ▣ FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- ▣ GI: (Harvard) General Inquirer, dictionary IV-4 (dicționarul Harvard General Inquirer IV-4)
- ▣ GPT: Generative Pre-trained Transformer (Transformer generativ pre-antrenat)
- ▣ GPT-1: Generative Pre-trained Transformer 1 (Transformer generativ pre-antrenat, versiunea 1)
- ▣ GPT-2: Generative Pre-trained Transformer 2 (Transformer generativ pre-antrenat, versiunea 2)
- ▣ GPT-3: Generative Pre-trained Transformer 3 (here version 3.5) (Transformer generativ pre-antrenat, versiunea 3 (aici versiunea 3.5))
- ▣ GPT-4: Generative Pre-trained Transformer 4 (Transformer generativ pre-antrenat, versiunea 4)
- ▣ IV-4: Harvard IV-4 (version 4 of the General Inquirer word lists) (Harvard IV-4, versiunea 4 a listelor de cuvinte General Inquirer)
- ▣ LLM: Large Language Model (model lingvistic mare)
- ▣ LM: Loughran-McDonald (financial sentiment dictionary) (dicționarul financiar de sentiment Loughran-McDonald)
- ▣ LR: Logistic Regression (regresie logistică)
- ▣ MIT: Massachusetts Institute of Technology (Institutul de Tehnologie din Massachusetts)
- ▣ NASDAQ: National Association of Securities Dealers Automated Quotations (bursa americană NASDAQ (cotații automate ale Asociației Naționale a Dealerilor de Valori Mobiliare))
- ▣ NYSE: New York Stock Exchange (Bursa din New York)

Acronime folosite în acest material (2/2)

- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ PCA: Principal Component Analysis (analiza componentelor principale)
- ▣ PPI: Prediction-Powered Inference (inferență susținută de predicții)
- ▣ RLHF: Reinforcement Learning from Human Feedback (învățare prin recompensă din evaluări umane)
- ▣ SE: Standard Error (eroare standard)
- ▣ SESTM: Sentiment Extraction via Screening and Topic Modelling (extragerea sentimentului prin selecție și modelarea temelor)
- ▣ TF-IDF: Term Frequency - Inverse Document Frequency (frecvența termenului înmulțită cu inversul frecvenței în documente)
- ▣ US: United States (Statele Unite ale Americii)
- ▣ UTC: Coordinated Universal Time (Temps Universel Coordonné) (timpul universal coordonat)
- ▣ VADER: Valence Aware Dictionary and sEntiment Reasoner (dicționar și reguli pentru valența și sentimentul textelor)

Traseul capitolului și rezultatele învățării

Traseul capitolului


- ▣ Partea I: textul ca date, dicționare, evaluarea clasificatorilor, FinBERT și LLM-uri, embeddings
- ▣ Partea a II-a: look-ahead bias (folosirea informației din viitor), de la sentiment la un semnal de tranzacționare, scorurile ca estimări, un studiu de caz, o parcurgere a buclei de cercetare asistate de AI
- ▣ Detaliile tehnice sînt în [▶ Anexa](#) de la final

După acest capitol puteți

- ▣ calcula sentimentul unui text cu un dicționar, cu FinBERT și cu un LLM zero-shot și compara clasificatorii cu teste pe perechi
- ▣ detecta suprapunerea cu datele de antrenare și rezultatele memorate într-un backtest cu LLM
- ▣ testa un semnal de sentiment cu aliniere corectă în timp, inferență pentru puține grupuri, costuri și corecție pentru testarea multiplă
- ▣ trata scorul unui model ca regresor generat: atenuare și prediction-powered inference

Piețele reacționează la cuvinte

- Prețurile se modifică odată cu apariția informațiilor, iar cele mai multe informații sînt transmise sub formă de text
 - ▶ Știri, raportări ale companiilor, conferințe despre rezultate, rapoarte ale analiștilor, comunicate ale băncilor centrale, rețele sociale
- Ziarele financiare sînt la fel de vechi ca piețele organizate
 - ▶ The Wall Street Journal: primul număr pe 8 iulie 1889 (fotografia)
- Astăzi: milioane de documente pe zi, mult mai multe decît poate citi orice analist



The Wall Street Journal, primul număr, 8 iulie 1889

Foto: Dow Jones & Company (1889); domeniu public;
[Wikimedia Commons](#)

Textul ca date și definiția sentimentului

- ▣ **Gentzkow, Kelly & Taddy (2019)**: un document d este reprezentat numeric prin x_d (frecvențe, scoruri, vectori), folosit într-un model statistic obișnuit
 - ▶ x_d devine o mărime de interes (sentiment, temă, risc), folosită apoi pentru a analiza o problemă economică (randamente, volatilitate)
- ▣ **Sentimentul unui text**: o veste bună, rea sau neutră pentru activul menționat
 - ▶ Trei clase sau scorul net $s = P(\text{pozitiv}) - P(\text{negativ}) \in [-1, 1]$
 - ▶ Nu este **sentimentul investitorilor**, starea de spirit măsurată din date de piață (**Baker & Wurgler (2006)**)
- ▣ Sinteze pentru finanțe: **Kearney & Liu (2014)**, **Loughran & McDonald (2016)**
- ▣ Acest capitol: scorul este o **estimare** a tonului adevărat, cu eroare de măsurare; îl folosim apoi pentru randamentele zilnice ale acțiunilor

Primele dovezi și narațiunile

- **Antweiler & Frank (2004)**: mesaje de pe forumurile despre acțiuni ajută la prognoza volatilității; efectul asupra randamentelor este mic
- **Tetlock (2007)**: pesimismul ridicat dintr-o rubrică a Wall Street Journal anunță presiuni de scădere a prețurilor, urmate de o revenire
 - ▶ Pesimismul neobișnuit de mare sau de mic anunță și volume mari de tranzacționare
- **Tetlock, Saar-Tsechansky & Macskassy (2008)**: ponderea cuvintelor negative din știrile despre o firmă anticipează profituri și randamente scăzute; prețurile încorporează treptat această informație
- **Shiller (2017)**: narațiunile populare se răspîndesc ca epidemiile și influențează deciziile economice; ele pot fi măsurate doar prin text
 - ▶ Shiller: Premiul Nobel pentru Economie 2013, împreună cu Fama și Hansen; narațiunile pot îndepărta prețurile de fundamente ([capitolele 2 și 17](#))



Robert J. Shiller, Stockholm, decembrie 2013

Foto: [Bengt Nyman \(2013\)](#); CC BY 2.0; [Wikimedia](#)

[Commons](#)

Patru moduri de a transforma textul în sentiment

Metoda	Principiul	Etichete necesare	Exemple
Dicționar	numără cuvintele din listă	niciuna	GI, LM, VADER
Model ajustat fin	rețea antrenată pe propoziții etichetate	mii	FinBERT
Model mare de limbaj	instrucțiune în limbaj natural (prompt)	niciuna (zero-shot)	Qwen2.5, GPT
Embeddings + clasificator	vectorii textelor într-o regresie	sute până la mii	MiniLM

- Le comparăm pe toate patru pe aceleași date etichetate, cu intervale de încredere
- Apoi ne întrebăm dacă vreuna produce câștiguri pe randamentele zilnice ale acțiunilor


Frecvențele cuvintelor și tonul

- ▣ **Reprezentarea prin frecvențele cuvintelor (bag of words):** documentul este redus la frecvențele cuvintelor; ordinea este ignorată
 - ▶ Tokeni: cuvintele scrise cu majuscule, fără cifre și semne de punctuație
- ▣ Un dicționar listează cuvintele pozitive $\mathcal{P}$ și cuvintele negative $\mathcal{N}$
 - ▶ P_d, N_d : numărul de cuvinte pozitive și negative din documentul d
 - ▶ **Tonul:** $\tau_d = \frac{P_d - N_d}{P_d + N_d} \in [-1, 1]$, iar $\tau_d = 0$ dacă $P_d + N_d = 0$
 - ▶ Clasa: pozitivă dacă $\tau_d > 0$, negativă dacă $\tau_d < 0$, neutră altfel
- ▣ Transparent, rapid și fără date de antrenare; nu ține cont de context și de negație

Dicționare generale față de dicționare financiare

- **Harvard General Inquirer (GI)**, lista IV-4: un dicționar de psihologie din anii 1960
 - ▶ 2 007 cuvinte negative și 1 637 de cuvinte pozitive
- **Loughran & McDonald (2011)** (LM): construit din rapoartele anuale (formularele 10-K) ale firmelor americane
 - ▶ 2 355 de cuvinte negative și doar 354 de cuvinte pozitive; plus liste pentru incertitudine și litigii
 - ▶ Concluzia lor: aproape trei sferturi dintre cuvintele negative din GI nu sînt negative în context financiar; în listele folosite aici, 1 552 de cuvinte negative din GI (77%) nu sînt cuvinte negative în LM
- **VADER (Hutto & Gilbert (2014))**: circa 7.500 de termeni cu scoruri de intensitate, construit pentru rețelele sociale, plus reguli pentru negație („not good”), intensificatori („very”), majuscule, semne de exclamare și emoticoane
 - ▶ Scor compus în $[-1, 1]$, pragurile uzuale $\pm 0,05$; regulile rezolvă unele probleme de context, dar vocabularul este general, ca la GI

Cuvinte negative în psihologie, neutre în contabilitate



- Cuvinte negative în GI, dar nu în LM, ordonate după numărul de propoziții din Financial PhraseBank care le conțin; culoarea: eticheta dată propoziției de adnotatorii umani
- „Service” (106 propoziții), „capital” (104) și „board” (79) sînt substantive uzuale în limbajul de afaceri, nu vești negative
 - ▶ Propoziții care nu sînt etichetate negativ: 98%, 93%, 96%; „vice” („vice president”): 100%
- „Lower”: doar 26% dintre propoziții nu sînt negative, dar „costuri mai mici” este o veste bună: semnul depinde de cuvîntul următor, de care nicio listă nu ține cont
- Din cele 964 de propoziții ale căror singure cuvinte negative sînt de acest tip, 89% nu sînt etichetate negativ

Exemplu rezolvat: o propoziție, două dicționare

- Propoziție din Financial PhraseBank, etichetată **pozitiv** de toți adnotatorii:
 - ▶ *Uponor improved its performance in spite of the decrease in residential construction in the US .*
- LM: cuvinte pozitive improved; cuvinte negative –
 - ▶ $\tau = (1 - 0)/(1 + 0) = +1,00$: pozitiv, corect
- GI: cuvinte pozitive –; cuvinte negative spite, decrease
 - ▶ $\tau = (0 - 2)/(0 + 2) = -1,00$: negativ, greșit
 - ▶ GI nu recunoaște „improved” și numără „spite” și „decrease”, care descriu piața, nu firma


Două corpusuri etichetate

- Financial PhraseBank (Malo et al. (2014)): 4 846 de propoziții din știri, etichetate de un grup de 16 adnotatori cu pregătire în finanțe, câte 5–8 pentru fiecare propoziție
 - ▶ Întrebarea: veste bună, rea sau neutră pentru investitor? Niveluri de acord: cel puțin 50%, 66%, 75% sau 100% dintre adnotatorii propoziției
 - ▶ 2 264 de propoziții cu acord deplin, 629 cu acord de cel puțin 50%, dar sub 66%; etichete 59% neutre, 28% pozitive, 12% negative
- Twitter Financial News (licența MIT, Hugging Face Hub): titluri din 2022, etichetate bearish, bullish sau neutre
 - ▶ Set de antrenare cu 9.543, set de validare cu 2 388 de titluri (folosit pentru evaluare); etichete 66% neutre, 20% pozitive, 15% negative
 - ▶ Texte scurte, zgomotoase, cu simboluri bursiere și linkuri: mai aproape de fluxul real de știri
- Două seturi de date, pentru că un rezultat obținut pe un set s-ar putea să nu se confirme pe altul

Inferență pentru clasificatori


- ▣ Acuratețea, precizia, recall-ul și F1 macro ca în [Capitolul 13](#); reperul: mereu „neutru”
 - ▶ Obține 66% acuratețe pe Twitter, dar un F1 macro de doar 26,4%
- ▣ **Testul McNemar**: doi clasificatori pe aceleași texte
 - ▶ n_{01} : A greșește și B are dreptate; n_{10} : A are dreptate și B greșește; textele pe care ambii le tratează la fel nu aduc informație
 - ▶ Sub H_0 (acuratețe egală), $n_{01} \sim \text{Binomial}(n_{01} + n_{10}; 0,5)$: un test exact
- ▣ Fiecare test de aici tratează eticheta umană drept adevăr; cu 5–8 adnotatori pe propoziție, care adesea nu sînt de acord, ea este la rîndul ei zgomotoasă
 - ▶ Erorile de etichetare limitează superior acuratețea măsurată; numai cînd zgomotul este simetric și independent de clasificatori, ele atenuază spre 0 și diferențele măsurate (un zgomot dependent de clasă le poate mări sau inversa)

Unsprezece clasificatori, două seturi de date: niciun câștigător unic



- TF-IDF + LR și MiniLM + LR: regresii logistice antrenate pe setul de antrenare Twitter; celelalte metode nu folosesc nicio etichetă Twitter
- Dicționarele generale rămân sub reperul clasei majoritare: GI 43,6%, VADER 49,6% pe Twitter; LM 60,5%, tot sub „mereu neutru” (66%)
- FinBERT: 89,0% pe PhraseBank, 72,5% pe Twitter; Qwen2.5-7B zero-shot: 81,4% și 74,2%
- Cel mai bun pe Twitter: cel mai simplu model supervizat, TF-IDF + regresie logistică, 83,2% (TF-IDF: frecvențele cuvintelor și ale perechilor de cuvinte, cu ponderi mai mici pentru termenii frecvenți)
- Lecția: datele etichetate din domeniul-țintă contează mai mult decât dimensiunea modelului

Dezacordul adnotatorilor și acuratețea modelelor




- Financial PhraseBank împărțit după cel mai înalt prag de acord atins de adnotatorii fiecărei propoziții; grupul cel mai slab: de la 50% pînă sub 66%
- Acord deplin: FinBERT 97%, Qwen2.5-14B 94%, LM 65%
 - ▶ Acord de la 50% pînă sub 66%: FinBERT 70%, Qwen2.5-14B 55%, LM 54%
- Multe propoziții sînt cu adevărat ambigue: un model nu poate fi judecat pe o etichetă asupra căreia oamenii nu sînt de acord (modele cu etichete latente: [▶ Anexa](#))
- Pentru semnale: un ton puternic și clar este mai informativ decît unul la limită

De la cuvinte în context la FinBERT

- Un dicționar dă cuvîntului „lower” un semn fix; un model de limbaj citește propoziția din jurul lui
 - ▶ Fiecare token primește un vector care depinde de toți ceilalți tokeni (atenție, [Capitolul 14](#); [Vaswani et al. \(2017\)](#))
- **BERT** ([Devlin et al. \(2019\)](#)): un codificator Transformer pre-antrenat pe cărți și Wikipedia prin predicția cuvintelor mascate aleator (modelarea limbajului cu mascare), circa 110 milioane de parametri
 - ▶ Ajustarea fină: se adaugă un strat mic de clasificare și se antrenează toată rețeaua pe propoziții etichetate
- [Araci \(2019\)](#): FinBERT este BERT pre-antrenat suplimentar pe știri financiare, apoi ajustat fin pentru sentiment
 - ▶ Modelul public folosit aici (ProsusAI/finbert) a fost ajustat fin pe Financial PhraseBank; rezultatul: probabilitățile pentru pozitiv, negativ și neutru, câteva milisecunde pe propoziție pe un laptop
- [Huang, Wang & Yang \(2023\)](#): un FinBERT antrenat pe rapoarte ale analiștilor, transcrieri ale conferințelor despre rezultate și formulare 10-K depășește dicționarele, mai ales pe propozițiile pe care acestea le citesc greșit

Structura erorilor: modele diferite, greșeli diferite




- Setul de validare Twitter: rîndurile sînt etichetele adevărate, coloanele etichetele prezise; numărul de texte în celule
- LM clasifică drept neutre majoritatea titlurilor pozitive: lista sa de cuvinte pozitive este scurtă (354 de cuvinte); FinBERT greșește în ambele direcții în jurul clasei neutre
- Qwen2.5-7B găsește aproape toate titlurile pozitive și negative, dar consideră multe titluri neutre pozitive sau negative: recall mare, precizie mică pe clasele extreme
- Pentru tranzacționare, semnalele false generează pierderi: contează precizia pe clasele extreme

Capcana evaluării în eșantion

- ▣ FinBERT: 89,0% pe PhraseBank, pe care a fost antrenat în mare parte (Araci (2019): 3.101 din 4.845 de propoziții); 72,5% pe Twitter: o scădere de 16,4 puncte (diferențe calculate din acuratețile nerotunjite)
 - ▶ Qwen2.5-7B, neajustat fin pe aceste etichete, scade și el cu 7,2 puncte: titlurile Twitter sînt mai greu de clasificat
- ▣ Diferența diferențelor: $\Delta = (a_{F,P} - a_{F,T}) - (a_{Q,P} - a_{Q,T}) = 9,2$ puncte, CI 95% bootstrap [6,7; 11,9]
 - ▶ $a_{m,D}$: acuratețea modelului m (F: FinBERT, Q: Qwen) pe datele D (P: PhraseBank, T: Twitter)
 - ▶ Ipoteza de identificare: fără suprapunerea cu datele de antrenare, ambele modele ar pierde la fel de la PhraseBank la Twitter
 - ▶ Sub această ipoteză, 9,2 din cele 16,4 puncte provin din suprapunerea cu datele de antrenare; CI măsoară zgomotul de eșantionare, nu ipoteza (cele două arhitecturi pot reacționa diferit la un domeniu nou)
- ▣ Regula: evaluați un model de limbaj doar pe texte pe care nu le-a văzut niciodată, ca în testele în afara eșantionului din capitolele 8 și 13

De la predicția cuvântului următor la urmarea instrucțiunilor

- **Shannon (1951)**: engleza este foarte predictibilă din literele anterioare; un model mare de limbaj (LLM) estimează $P(w_{t+1} \mid w_1, \dots, w_t)$ pe tokeni
 - ▶ **Brown et al. (2020)**: la scară mare, sarcinile se rezolvă din câteva exemple date în prompt (few-shot)
 - ▶ **Ouyang et al. (2022)**: ajustarea pe instrucțiuni și RLHF antrenează modelul să urmeze instrucțiuni
- **BloombergGPT (Wu et al. (2023))**: 50 de miliarde de parametri, text financiar și general; modelele deschise generale îl egalează acum la clasificarea sentimentului
 - ▶ Noțiuni de bază: **Quantinar: The Next Word Problem, Quantinar: Natural Language Processing**




Claude E. Shannon, fondatorul teoriei informației

Foto: Tekniska museet, Stockholm (fără dată); CC BY 2.0; Wikimedia Commons

Clasificarea zero-shot cu Qwen2.5


- Prompt-ul: o instrucțiune de sistem plus textul de clasificat
 - ▶ You classify the sentiment of financial news for investors. Answer with one word: positive, negative or neutral.
 - ▶ Headline: <text> Sentiment:
- Citim probabilitățile celor trei cuvinte-răspuns la prima poziție generată
 - ▶ Logiții z_k ai tokenilor „positive”, „negative”, „neutral”: $p_k = e^{z_k} / \sum_j e^{z_j}$
 - ▶ Eticheta: $\arg \max_k p_k$; scorul: $p_{\text{poz}} - p_{\text{neg}}$; nu se generează text, deci nu este necesară extragerea etichetei dintr-un răspuns textual
- Qwen Team (2024): modele cu ponderi deschise, de la 0,5 la 72 de miliarde de parametri, ponderi publicate pe 19 septembrie 2024
 - ▶ Folosim 0.5B, 1.5B, 3B, 7B și 14B (B: miliarde de parametri); 3B are licența Qwen Research License, celelalte Apache 2.0; timpii de procesare: ▶ Anexa
 - ▶ Ponderi deschise: rezultatele pot fi reproduse, iar data publicării limitează ce putea ști modelul

Mai mare nu înseamnă întotdeauna mai bun




- F1 macro pentru Qwen2.5 zero-shot cu același prompt; liniile punctate: FinBERT
- PhraseBank: F1 macro crește de la 63,3% (0.5B) la 82,1% (14B), tot sub FinBERT (88,3%)
 - Avantajul FinBERT de acolo provine parțial din suprapunerea cu datele de antrenare (Capcana evaluării în eșantion)
- Twitter: nu crește monoton; 1.5B este cel mai slab (55,3%), 7B cel mai bun (72,6%), peste FinBERT (66,8%)
 - 7B față de 1.5B la acuratețe: +21,5 puncte, McNemar $p < 0,001$
- Modelele mici sînt foarte sensibile la formulare: modelul 1.5B răspunde rar „neutral” cu acest prompt

Același model, altă formulare: prompt-ul este un parametru



- Trei prompt-uri care pun aceeași întrebare; setul de validare Twitter
- Intervalele de acuratețe: 1.5B între 52,7% și 61,7%; 7B între 73,7% și 77,8%; 14B între 69,9% și 75,6%
 - ▶ Cele trei prompt-uri dau aceeași etichetă doar pentru 67% dintre titluri (7B)
 - ▶ Ponderea răspunsurilor „neutral” pentru 7B: de la 48% (P1) la 69% (P3)
- Alegerea prompt-ului după examinarea rezultatelor de test este o formă de data snooping ([Capitolul 13](#))
 - ▶ Fixați prompt-ul dinainte sau alegeți-l pe un set de validare separat

Calibrarea probabilităților: LLM-urile sînt supraîncrezătoare




- ▣ Setul de validare Twitter, o jumătate aleasă aleator; panoul din dreapta: $p_k(T) \propto p_k^{1/T}$, cu T estimat prin verosimilitate maximă pe cealaltă jumătate (Guo et al. (2017))
- ▣ ECE (expected calibration error, eroarea medie de calibrare) = $\sum_b \frac{n_b}{n} |\text{acc}_b - \text{conf}_b|$ pe 10 intervale ale probabilității maxime: FinBERT 10,4%, Qwen2.5-7B 22,6%, 14B 25,9%; 7B atribuie pentru 88% dintre titluri o probabilitate de peste 0,93 (în medie 99,7%) și are dreptate la 77% dintre ele
- ▣ Scalarea prin temperatură, $T = 8,4$ (7B) și 1,4 (FinBERT): ECE scade la 4,3% și 4,6%; pentru 7B, log loss (media lui $-\ln p_{ij_i}$) de la 2,61 la 0,63, scorul Brier (Brier (1950); distanța pătratică față de eticheta codificată one-hot, însumată pe 3 clase) de la 0,468 la 0,366; etichetele, deci acuratețea, nu se schimbă
- ▣ ECE pentru 7B depinde de prompt: 22,6%, 22,1%, 19,8% cu P1, P2, P3; cu probabilitățile brute ale LLM, scorul net dintr-o regresie este aproape o etichetă cu trei valori

Exemplu rezolvat: LLM față de FinBERT


- ▣ Twitter, prompt-ul P1: Qwen2.5-7B 74,2%, FinBERT 72,5%
 - ▶ $n_{01} = 395$, $n_{10} = 355$; McNemar $p = 0,154$; diferența +1,7 puncte, CI 95% [-0,5; +3,8]
 - ▶ Qwen2.5-14B față de FinBERT: -0,1 puncte, $p = 0,942$
- ▣ Nu s-a detectat nicio diferență semnificativă, ceea ce nu dovedește o acuratețe egală (CI admite până la +3,8 puncte): de 70 până la 130 de ori mai mulți parametri și o procesare mai lentă nu aduc un câștig demonstrat
 - ▶ Unde ajută LLM-urile: nu cer etichete, funcționează în orice limbă, pe documente mai lungi și mai complexe
(▶ Anexa)

Embeddings de text: sentimentul nu este direcția principală



- **Embedding:** un vector $e_d \in \mathbb{R}^k$, apropiat pentru texte asemănătoare: word2vec (Mikolov et al. (2013)), Sentence-BERT (Reimers & Gurevych (2019))
 - ▶ Aici MiniLM (Wang et al. (2020)), $k = 384$, vectori de normă 1: similaritatea $\cos(e_a, e_b) = e_a^\top e_b$; embeddings intră într-un clasificator sau o regresie ca orice variabilă
- Graficul: titlurile din setul de validare Twitter, primele două componente principale ale vectorilor MiniLM, colorate după etichetă
- Primele două componente separă teme (companii, știri macro, cripto), nu sentimentul: PCA (Capitolul 3) păstrează direcțiile de varianță maximă
- O regresie logistică pe toate cele 384 de dimensiuni găsește direcția sentimentului: 78,6% acuratețe pe Twitter

Numărul necesar de etichete



- Regresie logistică antrenată pe submulțimi aleatoare ale setului de antrenare Twitter, 10 repetări pentru fiecare dimensiune; banda: ± 2 abateri standard
- Embeddings + regresie logistică: 69,0% cu 100 de etichete, peste FinBERT de la 400 de etichete
 - Vectorii pre-antrenați conțin deja cea mai mare parte a informației necesare
- TF-IDF pornește mai jos (66,9%), dar continuă să crească: 83,1% cu toate cele 9.543 de etichete, față de 78,6% pentru embeddings
 - Cu multe etichete, cuvintele exacte („upgrade”, „cuts”, „misses”) conțin semnalul în titluri
- Regulă practică: etichetați câteva sute de documente din domeniul de interes înainte de a vă baza pe un model gata antrenat

 MFM_ch15_embeddings


Modelul poate ști deja răspunsul

- Un LLM antrenat pe texte de pînă în 2024 poate să fi citit ce s-a întîmplat după un titlu din 2015
 - ▶ Un backtest pe știrile din 2015 confundă atunci prognoza cu memorarea
- Glasserman & Lin (2023): două distorsiuni în backtest-urile de sentiment
 - ▶ Look-ahead bias: modelul cunoaște randamentele care au urmat știrii
 - ▶ Efectul de distragere: cunoștințele generale despre compania numită interferează cu citirea textului; în testele lor a contat mai mult decît look-ahead bias-ul
- Sarkar & Vafa (2024): teste directe arată look-ahead bias în aplicații ale LLM-urilor la conferințe despre rezultate și la alegeri

Testul memoriei: întrebări despre trecut, fără context


- Lunar: „Did the S&P 500 index rise or fall during <lună an>?”, pentru 296 de luni dinainte de publicare plus 23 după
 - ▶ Zilnic: „Did Apple stock close higher or lower on <dată> than on the previous trading day?”, 500 de zile aleatoare din 2010–2023 și 493 de zile după octombrie 2024
- Scorul: $P(\text{creștere})$ din probabilitățile cuvintelor-răspuns; direcția adevărată din închiderile lunare ale S&P 500 și din închiderile zilnice Apple
 - ▶ AUC: probabilitatea ca o perioadă aleatoare de creștere să primească un scor mai mare decât una aleatoare de scădere; 0,5 = nicio capacitate de discriminare ([Capitolul 13](#))
- Rezultatele de după publicare nu pot fi memorate în ponderi fixe: dacă data însăși nu conține informație predictivă (de exemplu sezonality), AUC în populație este 0,5 în acea perioadă, iar AUC din eșantion variază în jurul acestei valori

Memoria lui Qwen2.5-14B despre S&P 500



- Probabilitatea răspunsului „rise” pentru fiecare lună, fără context; culoarea: ce a făcut de fapt indicele
- „Fall” pentru 2000–2002 și 2008–2009, „rise” pentru cea mai mare parte din 2003–2007 și 2013–2021; octombrie 2008 (-16,9%), martie 2020 (-12,5%), decembrie 2018 (-9,2%): $P(\text{creștere}) \approx 0$
- Dar septembrie 2002 (-11,0%) și februarie 2009 (-11,0%) primesc $P(\text{creștere})$ aproape de 1: cunoașterea este aproximativă; modelul reține episoadele memorabile, nu fiecare lună
- După publicare, răspunsurile tind spre „rise”: nicio cunoaștere, doar convingerea generală că piețele cresc

Memoria măsurată: lunile da, zilele nu




- AUC cu intervale bootstrap de 95%, cu lunile reeșantionate independent; 0,5 înseamnă că modelul nu poate distinge creșterile de scăderi
- Lunile dinainte de publicare: AUC 0,67 (7B, CI [0,61; 0,73]) și 0,69 (14B, CI [0,62; 0,75]); p prin permutări pentru 14B $< 0,001$; modelul 1.5B știe mult mai puțin (0,57)
- După publicare (23 de luni) intervalele includ 0,5, dar sînt prea largi pentru o concluzie: ar fi nevoie de circa 101 luni după publicare pentru a detecta o cădere la 0,5 (testul formal: [▶ Anexa](#))
- Zile individuale pentru Apple: AUC între 0,48 și 0,52 înainte de publicare; look-ahead bias-ul este un pericol pentru evenimentele bine cunoscute, mai puțin pentru zgometul zilnic

Remedii: modele disponibile la data analizată

- ▣ Testați doar după data-limită a datelor de antrenare: [Lopez-Lira & Tang \(2026\)](#) evaluează GPT-4 pe titluri de după data-limită; fără contaminare, dar fereastra începe târziu
- ▣ Mascăți numele companiilor și datele înainte de evaluare ([Glasserman & Lin \(2023\)](#)), apoi comparați pantele cu și fără mascare: un diagnostic, pentru că produsele, evenimentele sau citatele pot identifica în continuare episodul
- ▣ Modele cu informație limitată la o dată de referință, antrenate doar pe textul disponibil pînă la data t ([Sarkar & Vafa \(2024\)](#))
 - ▶ [Drinkall et al. \(2024\)](#): o serie de LLM-uri cu date de referință succesive, fiecare fără informații despre faptele de după data lui; modelele și datele de antrenare sînt publice
 - ▶ [He et al. \(2025\)](#): ChronoBERT și ChronoGPT folosesc doar textul disponibil la fiecare dată; pe randamentele zilei următoare din știri, rapoartele lor Sharpe sînt apropiate de ale unui model mult mai mare: look-ahead bias-ul are acolo un efect modest
- ▣ Raportați versiunea modelului și data publicării ponderilor sale împreună cu fiecare rezultat

Date: titluri datate și prețuri


- ▣ FNSPID (Dong, Fan & Peng (2024)): 15,7 milioane de știri despre firmele din S&P 500, 1999–2023, de pe patru site-uri de știri
 - ▶ Licența CC BY-NC 4.0 (utilizare necomercială)
- ▣ Aici: 16 acțiuni americane mari cu prețuri zilnice în datele cursului (tehnologie, bănci, GameStop, Strategy)
 - ▶ 106 820 de titluri distincte după eliminarea repetițiilor; 18 282 de zile-acțiune cu știri, între 27.10.2009 și 18.12.2023



Bandă de știri pe clădirea Reuters, New York


Foto: [bgilliard](#) (2005); CC BY-SA 2.0; [Wikimedia Commons](#)

Numărul de titluri în timp: acoperire inegală



- Titluri despre cele 16 acțiuni pe an, după ziua de tranzacționare la care sînt atribuite
- 34 380 de titluri doar în 2023, față de 8 445 în toți anii dinainte de 2016
 - ▶ Rezultatele sînt dominate de anii recentî; primii ani au puține zile cu știri pe acțiune
- Într-o zi cu știri, o acțiune are în medie 5,8 titluri; scorul zilnic: media scorurilor titlurilor pentru acțiunea și ziua respectivă
- Survivorship bias (distorsiunea de supraviețuire): cele 16 acțiuni aparțin unor firme mari în prezent, selectate retrospectiv

Problema marcajului de timp: date, nu ore




- Ora marcajului de timp FNSPID în timpul universal coordonat (UTC), scară logaritmică
- 99,8% dintre titluri au marcajul exact 00:00 UTC: sursa dă data, nu ora publicării
 - ▶ Un titlu datat d poate apărea înainte de deschidere, în timpul ședinței sau după închiderea zilei d
- Alinierea folosită aici, fără look-ahead bias
 - ▶ Ziua d : prima zi de tranzacționare egală cu data titlului sau ulterioară
 - ▶ Randamentele din d și $d + 1$ pot conține încă reacția; prima prognoză sigură este randamentul din $d + 2$ (de la închiderea din $d + 1$ la închiderea din $d + 2$)
- Randamentul în exces: randamentul acțiunii minus randamentul SPY (un fond pe indicele S&P 500) în aceeași zi

Trei scoruri și specificația regresiei

- Tonul LM; scorul net FinBERT $P(\text{poz}) - P(\text{neg})$; scorul net Qwen2.5-7B cu prompt-ul P1
 - ▶ LM găsește un cuvânt din listă doar în 27% dintre titluri: restul primesc tonul 0; etichetele FinBERT: 19% negative, 62% neutre, 18% pozitive
 - ▶ Corelațiile pe titluri: FinBERT–Qwen 0,62, FinBERT–LM 0,41, Qwen–LM 0,36: cele două modele de limbaj sînt mult mai corelate între ele decît cu dicționarul
- Regresie pe toate zilele-acțiune cu știri: $r_{i,d+h}^e = a + b z_{i,d} + \varepsilon_{i,d+h}$, $h = 0, 1, 2$
 - ▶ r^e : randamentul în exces (%); z : scorul zilnic standardizat pe panel (medie 0, abatere standard 1); b : randamentul pentru o abatere standard a scorului
 - ▶ $h = 0$ măsoară reacția, $h = 2$ măsoară predictibilitatea
- Erorile acțiunilor din aceeași zi sînt corelate (șocuri comune): calculăm erori standard robuste la gruparea observațiilor pe zile ([Petersen \(2009\)](#))
 - ▶ $\hat{V} = (X^\top X)^{-1} \left(\sum_g X_g^\top \hat{\varepsilon}_g \hat{\varepsilon}_g^\top X_g \right) (X^\top X)^{-1}$, g : zile de tranzacționare

Reacție față de predicție: titlurile descriu prețurile



- Panta b în puncte de bază (bp) pentru o abatere standard a scorului, cu CI 95% grupat pe zile
- Ziua d : FinBERT +39,2 bp ($t = +17,27$), Qwen +41,4 bp ($t = +19,07$), LM +15,5 bp ($t = +8,53$)
 - ▶ Multe titluri relatează chiar mișcarea prețului („shares jump”, „stock falls”): cauzalitatea merge în ambele sensuri
- Ziua $d + 1$: FinBERT +3,2 bp ($t = +1,60$), Qwen +3,7 bp ($t = +1,86$)
 - ▶ O parte din acest efect provine din știri publicate după închiderea zilei d , nu dintr-o prognoză
- Ziua $d + 2$: FinBERT -0,5 bp ($t = -0,25$), Qwen +2,3 bp ($t = +1,19$), LM -0,0 bp ($t = -0,01$)


 MFM_ch15_news_signal

Inferență cu 16 acțiuni și nouă regresii

Scor, orizont	b (bp)	t pe acțiuni	t pe două dimensiuni	p wild bootstrap	p Holm
FinBERT, d	+39,2	+5,71	+5,67	<0,001	<0,001
Qwen, d	+41,4	+5,10	+5,07	<0,001	<0,001
FinBERT, $d + 2$	-0,5	-0,35	-0,30	0,739	1,00
Qwen, $d + 2$	+2,3	+2,41	+2,01	0,061	0,37
LM, $d + 2$	-0,0	-0,03	-0,02	0,979	1,00

- Efectele de firmă persistă în timp, deci erorile sînt corelate și în cadrul unei acțiuni: grupăm pe acțiuni sau pe zile și acțiuni (Cameron, Gelbach & Miller (2011)); Driscoll & Kraay (1998) adaugă corelația serială
 - Cu doar 16 grupuri, eroarea standard grupată tinde să fie subestimată: wild cluster bootstrap cu ipoteza nulă impusă, ponderi Rademacher, 9.999 de extrageri (Cameron, Gelbach & Miller (2008)); presupune acțiuni independente, deci citiți-l împreună cu t pe două dimensiuni
- Qwen în $d + 2$: $t = +2,41$ pe acțiuni pare semnificativ; p bootstrap = 0,061 și 0,37 după Holm pe cele 9 regresii (3 scoruri $\times$ 3 orizonturi)

Studiu de eveniment: mișcarea are loc înainte de știre și în ziua ei




- Randamentul în exces cumulat mediu, zilele $-5 - +5$; zilele cu știri împărțite pe terciile scorului zilnic FinBERT; zona hașurată: zilele tranzacționabile $d + 2 - d + 5$
- Treimea cea mai pozitivă: $+0,63\%$ în cele 5 zile dinainte, $+0,50\%$ în ziua d ; treimea cea mai negativă: $+0,06\%$ și $-0,38\%$: scurgeri de informații sau titluri scrise după mișcarea prețului
- Efectul sentimentului = pozitiv minus negativ pe zile-acțiune, CI grupat pe date (mediile pe grupuri de mai sus se calculează întâi pe fiecare dată): ziua $d + 1,00\%$ [$+0,88$; $+1,13$]; zilele $d + 2 - d + 5$ $+0,17\%$ [$-0,08$; $+0,42$]
- Test robust la varianța indusă de eveniment (Boehmer, Musumeci & Poulsen (1991)) pe $d + 2 - d + 5$: $z = +2,62$ (pozitiv), $+1,25$ (negativ); presupune evenimente independente, deci supraestimează z ; ambele treimi cresc, iar selecția firmelor mari de azi poate contribui

 MFM_ch15_news_signal

O strategie zilnică de sentiment

- La închiderea din $d + 1$: pentru fiecare acțiune cu știri în ziua d , cumpărăm dacă scorul este pozitiv și vindem în lipsă dacă este negativ
 - ▶ Fiecare poziție este acoperită (hedging) cu SPY; ponderi egale; închidem după o zi și obținem randamentul în exces din $d + 2$
 - ▶ Zilele fără știri: nicio poziție, randament 0
- Costuri: 5 bp pe tranzacție; patru tranzacții pe zi cu poziții (acțiunea și SPY, la intrare și la ieșire)
 - ▶ Costul de echilibru: randamentul brut mediu în zilele cu poziții împărțit la 4
- Inferența: t Newey–West ([Capitolul 2](#)) și CI bootstrap pe blocuri pentru randamentul zilnic mediu


Randamentele cumulate ale strategiei: niciun profit net



- Suma randamentelor zilnice în exces (%), înainte de costuri și cu 5 bp pe tranzacție
- FinBERT: +3,27 bp pe zi ($t = +1,27$), CI 95% [-1,51; +8,93]: nu diferă de zero; LM: -0,21 bp ($t = -0,07$)
- Qwen2.5-7B: +5,64 bp ($t = +2,26$, $p = 0,024$), CI 95% [+0,95; +10,61]; cel mai bun din trei scoruri: p Holm = 0,071, ne semnificativ
 - Costul de echilibru +1,5 bp pe tranzacție, mult sub 5 bp: Sharpe +0,63 înainte și -1,48 după costuri; o parte din avantaj poate fi memorarea prețurilor (Qwen2.5 a fost antrenat după 2023)
- Ziua netranzacționabilă $d + 1$: FinBERT -0,22 bp ($t = -0,10$), Qwen +4,06 bp ($t = +1,36$): niciun câștig semnificativ nici aici, aproape toată reacția are loc în ziua d

 MFM_ch15_news_signal

Stabilitatea în timp: dovezi slabe



- Randamentul zilnic mediu al strategiei înainte de costuri, pe subperioade
- FinBERT: 2010–2015 +1,4 bp, 2016–2019 -1,8 bp, 2020–2021 +24,3 bp, 2022–2023 -1,8 bp
 - ▶ Doar 2020–2021 este mare (FinBERT $t = +1,89$, Qwen +22,2 bp, $t = +1,78$): ne semnificativ la 5%, doi ani de tranzacționare a acțiunilor-meme; patru tranzacții de 5 bp costă 20 bp pe zi
- Explicații: 16 acțiuni foarte urmărite, marcare de timp doar la nivel de dată, frecvență zilnică; predictibilitatea publicată se bazează pe marcare de timp precise și pe multe acțiuni mici (studiul de caz)
- Un rezultat negativ este tot un rezultat: arată unde nu se află semnalul

 MFM_ch15_news_signal

Sentimentul ca regresor generat

- Modelul: $r = a + \beta s^* + \varepsilon$, cu tonul adevărat s^* ; observăm ieșirea unui model $\hat{s} = s^* + u$
 - ▶ Eroare clasică (u independentă de s^* și ε): $\text{plim } \hat{\beta} = \beta \lambda$, $\lambda = \text{Var}(s^*) / [\text{Var}(s^*) + \text{Var}(u)] < 1$
 - ▶ Testul pentru $\beta = 0$ rămîne valid; estimările sînt atenuate spre 0
- Scor standardizat z , eroare nediferențială ($E[r | s^*, \hat{s}] = E[r | s^*]$): $\text{Cov}(r, z) = \beta \text{Cov}(s^*, z)$
 - ▶ Panta pe z = (efectul unei abateri standard a lui s^*) $\times \rho(s^*, \hat{s})$: împărțim la corelația dintre adevăr și scor
 - ▶ O etichetă binară nu are eroare clasică: clasificarea greșită reduce panta unei variabile binare cu alt factor (Aigner (1973); ▶ Anexa și Seminarul 15, A1)
- Econometria variabilelor generate de AI: Battaglia et al. (2024) (corecția distorsiunii, estimare comună); Ludwig, Mullainathan & Rambachan (2024) (utilizări ale LLM-urilor pentru predicție față de estimare)

Atenuarea pantelor estimate


Scor	$\rho(s^*, \hat{s})$, Twitter	b în ziua d (bp)	b/ρ (bp)	λ , model cu un factor
LM	0,29	15	54	0,53
FinBERT	0,58	39	67	0,85
Qwen2.5-7B	0,71	41	58	0,78

- ρ : corelația scorului net cu eticheta umană $(-1, 0, 1)$; b/ρ : efectul în aceeași zi al unei abateri standard a tonului adevărat
 - După corecție cele trei metode sînt mult mai apropiate: panta mică a LM este în mare parte eroare de măsurare
 - Corecția presupune că eroarea este nediferențială și că se păstrează corelația de pe Twitter pentru titlurile FNSPID
- λ : încărcarea pe factorul comun al celor trei scoruri zilnice, un reper diferit de eticheta umană (modelul factorial și variabilele instrumentale: [► Anexa](#))

Inferență validă cu etichete de model: prediction-powered inference

- n texte etichetate de oameni (Y) și N texte neetichetate, eșantioane aleatoare independente din aceeași populație; modelul f este fix (antrenat pe alte date)
 - ▶ PPI (prediction-powered inference, [Angelopoulos et al. \(2023\)](#)): $\hat{\theta}_{\text{PPI}} = \frac{1}{N} \sum_{i \text{ neetich.}} f(\tilde{X}_i) - \frac{1}{n} \sum_{j \text{ etich.}} (f(X_j) - Y_j)$: predicția minus distorsiunea ei estimată
 - ▶ $\widehat{\text{Var}} = \widehat{\text{Var}}(f)/N + \widehat{\text{Var}}(f - Y)/n$: un CI valid asimptotic sub această schemă de eșantionare, oricare ar fi calitatea lui f
- Mai îngust decît doar cu etichete cînd $\text{Var}(f)/N + \text{Var}(f - Y)/n < \text{Var}(Y)/n$, aproximativ $\text{Var}(f - Y) < \text{Var}(Y)$ cînd $N \gg n$
 - ▶ Pentru o regresie, corecția se aplică fiecărei condiții de moment care conține variabila prezisă, și atunci cînd aceasta este regresor ([Egami et al. \(2023\)](#))
- [Egami et al. \(2023\)](#): învățare supervizată bazată pe design, o versiune dublu robustă care permite probabilități de etichetare dependente de text
- Cele cîteva sute de documente etichetate nu sînt doar date de antrenare: ele sînt eșantionul de validare care face validă inferența ulterioară

PPI pe titlurile Twitter: corecția distorsiunii este cîștigul principal



- Ținta: tonul net uman mediu $(-1, 0, 1)$; cele 2388 de titluri de validare au rolul populației; 2.000 de replicări cu n titluri etichetate și $2388 - n$ neetichetate extrase independent, cu întoarcere
- Tonul mediu adevărat $\theta = 0,054$; mediile simple ale modelelor sînt distorsionate: FinBERT $-0,014$ (semn greșit), Qwen2.5-7B $+0,101$; creșterea eșantionului nu elimină această eroare
- PPI păstrează acoperirea nominală (94,3% la $n = 100$); lățimea 0,204 față de 0,229 doar cu etichete; reducerea varianței $1 - \text{Var}(f - Y)/\text{Var}(Y)$: 24% (FinBERT), 27% (Qwen), modestă, pentru că modelele sînt zgomotoase
- La $n = 800$ PPI este mai larg (0,087 față de 0,081): cu doar $2388 - 800$ de texte neetichetate, $\text{Var}(f)/N$ nu mai este neglijabil; pentru regresiiile randamentelor, etichetați toate titlurile unui eșantion aleator de zile-acțiune și corectați ambele condiții de moment OLS (Egami et al. (2023))

Sentimentul estimat de LLM și reacția pieței

- Întrebările din [Lopez-Lira & Tang \(2026\)](#) (*Journal of Financial Economics*)
 - ▶ poate un LLM de uz general, fără o antrenare financiară explicită, să determine dacă un titlu este o veste bună sau rea pentru acțiune?
 - ▶ prognozează răspunsul lui randamentele ulterioare?
- Reacția inițială: mișcarea prețului imediat după știre; nu este tranzacționabilă, dar arată dacă LLM-ul înțelege știrea
- Drift-ul: randamentul de după reacție, în sensul știrii; este tranzacționabil și măsoară reacția insuficientă a pieței
- Legătura cu acest capitol: aceeași evaluare zero-shot a titlurilor, dar pe știri publicate după data-limită a datelor de antrenare și cu ora exactă a publicării
 - ▶ Acestea sînt exact cele două slăbiciuni ale testului nostru pe FNSPID: date fără oră și look-ahead bias-ul lui Qwen2.5
- Relevanța: LLM-ul devine un instrument de măsură pentru viteza cu care prețurile absorb știrile
 - ▶ Modelul teoretic al autorilor (secțiunea 3): doar LLM-urile care depășesc un anumit prag de acuratețe prognozează randamentele; utilizarea lor pe scară largă ar trebui să reducă predictibilitatea

Date și metodă


- 159.137 de observații firmă-titlu-dată, 4.123 de acțiuni ordinare americane (NYSE, NASDAQ, AMEX), octombrie 2021 – mai 2024 (secțiunea 4)
 - ▶ Eșantionul începe după septembrie 2021, data-limită a datelor de antrenare pentru modelul gpt-4-0314 (secțiunea 5)
 - ▶ Filtre: scorul de relevanță al furnizorului de știri egal cu 100, fără titlurile de tip „stock-gain”/„stock-loss”, doar evenimente noi, eliminarea titlurilor aproape identice din aceeași zi
 - ▶ Știrile publicate înainte de ora 9 sau după ora 16 reprezintă 82% dintre titluri; restul apar în timpul ședinței de tranzacționare
- Prompt-ul (secțiunea 5): modelul joacă rolul unui expert financiar și răspunde YES (veste bună), NO (veste rea) sau UNKNOWN despre efectul pe termen scurt asupra prețului acțiunii; temperatura 0
 - ▶ Scorul $s_{i,t}$: YES = 1, UNKNOWN = 0, NO = -1
- Portofolii zilnice cu ponderi egale (tabelul 1): poziții long pentru scoruri pozitive și short pentru scoruri negative; fiecare componentă necesită cel puțin două firme. Pentru știrile dintre ședințe, reacția inițială se măsoară de la închiderea anterioară la deschidere, iar drift-ul, de la deschidere la închidere
 - ▶ Rata de succes: ponderea zilelor cu randament pozitiv al portofoliului; raportul Sharpe $SR = \sqrt{252} \bar{r} / \hat{\sigma}$ (anualizat)
- Regresia, ec. (1): $r_{i,t} = a_i + b_t + \gamma s_{i,t} + \varepsilon_{i,t}$, efecte fixe de firmă și de dată, erori standard grupate pe date și pe firme (tabelul 2)
 - ▶ Douăsprezece modele de limbaj de mărimi crescătoare, evaluate cu aceeași metodologie, de la GPT-1 la GPT-4 (tabelul 5)

Rezultatele principale

Model	Rata de succes, reacție	Rata de succes, drift	Drift, % pe zi	SR
GPT-4	0,93	0,58	0,34	2,97
GPT-3.5	0,93	0,56	0,29	1,66
FinBERT	0,90	0,48	−0,07	−0,33
GPT-1	0,53	0,48	−0,07	−0,64


- Portofolii long-short pentru știrile dintre ședințe (tabelul 5): GPT-4 are o rată de succes de 93% pentru reacția inițială, la fel ca GPT-3.5, și cel mai mare randament ulterior
 - Componenta short: 0,26% pe zi (SR 2,01); componenta long: 0,08% (SR 0,78) (tabelul 1): piața reacționează insuficient mai ales la veștile rele
- Ec. (1), știrile de peste noapte (tabelul 2): $\hat{\gamma} = 1,326$ ($t = 26,52$) pentru reacție, 0,161 ($t = 6,59$) pentru drift; cu scorul de sentiment al furnizorului, GPT-4 rămâne la 0,158 ($t = 5,27$), iar furnizorul are 0,010 ($t = 0,15$)
 - Acțiunile mici: coeficientul interacțiunii 0,404 ($t = 4,55$): drift-ul se concentrează acolo unde arbitrajul este costisitor
- Declinul (figura 8): SR al drift-ului 6,54 în T4 2021, 3,68 în 2022, 2,33 în 2023, 1,22 în ianuarie–mai 2024, pe măsură ce LLM-urile s-au răspândit

Modelele: reacția inițială și randamentul ulterior



- Portofolii long-short pentru știrile dintre ședințe, douăsprezece modele cu aceeași construcție a portofoliilor, octombrie 2021 – mai 2024; sursa: [Lopez-Lira & Tang \(2026\)](#), tabelul 5
- Pragul: GPT-1, GPT-2, BERT și Llama2-7b ghicesc direcția reacției doar în 53–66% din zile și au rapoarte Sharpe ale drift-ului negative (între $-0,64$ și $-0,11$); șapte modele ajung la 86–93%, dar doar GPT-4 obține și un raport Sharpe al drift-ului aproape de 3 (2,97, urmat de GPT-3.5 cu 1,66)
- FinBERT: 90% pentru reacție, Sharpe al drift-ului $-0,33$, o direcție doar pentru 25% dintre titlurile dintre ședințe (nota 24): informația deja reflectată în prețul de deschidere nu aduce câștiguri ulterioare
- Examinați componența: componenta short are în medie 2 acțiuni la BERT-Large (Sharpe 1,05), 6 la GPT-3.5, 20 la GPT-4 (tabelul 5); un raport Sharpe din câteva poziții scurte este fragil

Drift-ul scade pe măsură ce LLM-urile se răspîndesc



- Strategia long-short GPT-4 pe drift-ul știrilor dintre ședințe, raportul Sharpe anualizat pe subperioade; sursa: [Lopez-Lira & Tang \(2026\)](#), figura 8 și secțiunea 8.2; valoarea pentru tot eșantionul din tabelul 1
- De la 6,54 în T4 2021 la 1,22 în ianuarie–mai 2024, o scădere de peste cinci ori; valoarea de 2,97 pe tot eșantionul combină un început puternic cu un final slab (media totală raportată la volatilitatea totală), nu este o prognoză a rezultatelor actuale
- Modelul lor (secțiunea 3): cu cât mai mulți investitori procesează știrile cu LLM-uri capabile, cu atât reacția insuficientă și drift-ul scad; momentul coincide cu răspîndirea ChatGPT
- Autorii menționează și schimbarea condițiilor de piață (secțiunea 8.2); subperioadele sînt scurte, deci intervalele de 95% din figura 8 sînt largi, iar cel pentru 2024 îl conține pe 0; știrile din timpul ședinței: drift-ul de la închidere la închidere nu mai este semnificativ în 2024 (nota 33)

Replicare, limite și direcții de cercetare

- Comparația disponibilă în acest curs: strategia Qwen2.5-7B din acest capitol pe 16 acțiuni FNSPID câștigă +5,64 bp pe zi ($t = +2,26$), față de 34 bp pentru GPT-4 (tabelul 1)
 - ▶ Replicarea (Seminarul 15, C3): prompt-ul publicat, temperatura 0, scorurile $\{-1, 0, 1\}$, regula celor două firme și ec. (1) pe titlurile FNSPID și prețurile ajustate de închidere din datele cursului
 - ▶ Limitele datelor: date fără oră, deci primul randament sigur este cel din $d + 2$, nu deschiderea următoare; 16 acțiuni mari; titluri mai vechi decât modelul
- Limite enunțate de autori: la 20 bp pe tranzacție dus-întors strategia pierde bani (figura 4), deci se potrivește celor cu costuri mici, precum formatorii de piață (secțiunea 1)
 - ▶ Declinul în timp poate reflecta și schimbarea condițiilor de piață (secțiunea 8.2); prompt-urile și modelele de reprezentare vectorială nu au fost optimizate, deci comparațiile sînt limite inferioare (secțiunea 7.4)
- Extindere deschisă: pe titluri publicate după lansarea unui model cu ponderi deschise
 - ▶ se mai păstrează drift-ul?
 - ▶ continuă să scadă raportul Sharpe, așa cum prezice propoziția 2?

O întrebare deschisă: putem avea încredere în ipotezele generate de LLM-uri?

- Ludwig & Mullainathan (2024): generarea ipotezelor ca procedură statistică: un model antrenat pe date descoperă un tipar, oamenii îl numesc, date noi îl testează
- Lopez-Lira, Tang & Zhu (2025): înainte de data-limită a cunoștințelor, un LLM își poate aminti rezultatele, deci o ipoteză propusă de el despre acea perioadă nu este independentă de datele care o vor testa
- Întrebarea deschisă: când un asistent propune semnalul, prompt-ul, pragul și perioada de deținere
 - ▶ care este familia de teste?
 - ▶ ce inferență rămâne validă?
- Agenții care rulează singuri experimentele (Lu et al. (2024)) fac familia mai mare și mai puțin vizibilă
- Formal: $H_{0,j} : E[r_t^{(j)}] = 0$ pentru strategiile candidate $j = 1, \dots, M$; controlăm FWER (Holm) sau FDR (Benjamini & Hochberg (1995))
 - ▶ M numără fiecare variantă propusă de asistent, inclusiv pe cele abandonate; dacă ipotezele au fost construite pe rezultatele de test, p -value-urile cer date de test neatinse sau inferență selectivă (secvențială)


Bucula descoperirii și verificările cercetătorului

- Literatura, ipotezele, datele și codul, robustețea fixată dinainte, critica, raportul: un asistent (Claude, ChatGPT, Gemini, GitHub Copilot) redactează fiecare pas, cercetătorul îl verifică (prompt-uri reutilizabile: [▶ Anexa](#))
- **Memorarea:** modelul știe ce a urmat după titlu
 - ▶ Test: știri de după publicarea ponderilor; text anonimizat, ca diagnostic ([Glasserman & Lin \(2023\)](#)); testul de memorie din acest capitol
- **Forking paths:** prompt, prag, orizont ajustate pe perioada de test
 - ▶ Test: o grilă preînregistrată și o rată de eroare declarată: Holm (FWER) sau BH (FDR, sub independență sau dependență pozitivă); $|t| > 3$ ([Harvey, Liu & Zhu \(2016\)](#)) este o regulă empirică, nu o garanție pentru rata de eroare
- **HARKing:** un mecanism plauzibil scris după rezultat, cu referințe care pot să nu existe
 - ▶ Test: formulați mecanismul și ce l-ar infirma înaintea testului; verificați fiecare DOI
- **Alinierea în timp și agenții care rulează cod:** marcaje de timp doar la nivel de dată; modificări neanunțate ale datelor, ferestrelor sau valorilor de inițializare
 - ▶ Test: primul randament tranzacționabil în $d + 2$; date doar pentru citire, apeluri de instrumente jurnalizate, verificarea modificărilor (diff) fiecărui script înainte de a accepta un rezultat

Mini-studiu de caz: grădina cu poteci care se bifurcă

- O propunere tipică a unui asistent: „semnalul Qwen funcționează; rafinează-l cu un prag mai strict sau cu o zi de intrare mai târzie”. Testăm toată grila pe scorurile salvate
- Grila: 3 scoruri (LM, FinBERT, Qwen) $\times$ 3 praguri $|s_{i,d}| > b$, $b \in \{0; 0,25; 0,5\}$, pe scorul brut $\times$ 4 zile de randament ($d + 2 - d + 5$, fiecare o poziție de o zi deschisă la închiderea precedentă) = 36 de strategii
 - ▶ Cazul de bază se replică: 5,6 bp pe zi, $t = 2,26$
- $|t| > 1,96$ pentru 5 din 36 de strategii, față de 1,8 așteptate sub ipoteza nulă globală la 5%; 2 dintre ele au semnul greșit
- Strategii rămase semnificative: Holm (FWER 5%) 0, BH (FDR 10%) 0, $|t| > 3$ 0; pragul Bonferroni este $|t| > 3,20$
- Interpretare: rafinările nu adaugă dovezi; cea mai bună variantă este cea de la care am pornit, aleasă ea însăși dintre trei scoruri, pe o perioadă pe care modelul și-o poate aminti

Curba specificațiilor față de zgomot



- Toate cele 36 de strategii din mini-studiu, ordonate după t (Simonsohn, Simmons & Nelson (2020)); linii punctate: $\pm 1,96$
- Ipoteza nulă comună (nicio specificație nu prognozează randamentele): schimbăm aleator semnul pozițiilor în blocuri de 10 zile de semnal consecutive (dependent wild bootstrap, Shao (2010)), de 2000 de ori, aceleași schimbări pentru toate cele 36 de specificații
 - Valid dacă, sub ipoteza nulă, randamentele cu semn sînt simetrice în jurul lui 0, iar blocurile sînt aproximativ independente
- Observat: 3 specificații cu $t > 1,96$ (2 cu $t < -1,96$), t median = 0,50; sub ipoteza nulă, 3 sau mai multe apar cu probabilitatea 0,113, un median atît de mare cu probabilitatea 0,207
- Interpretare: curba este compatibilă cu zgomotul la 5%; raportarea doar a celui mai bun punct ar ascunde asta

Temă de proiect

- Întrebarea: prognozează sentimentul titlurilor, măsurat cu un LLM, randamentele după $d + 1$ pe știri publicate după lansarea modelului, cu o grilă preînregistrată?
- Replicați întâi: strategia Qwen din acest capitol, +5,64 bp pe zi ($t = +2,26$); apoi protocolul cu știri de după data-limită din [Lopez-Lira & Tang \(2026\)](#)
- Livrabile
 - ▶ Grila și corecția preînregistrate; titluri datate de după publicarea unui model deschis; testul pe toate variantele
 - ▶ Un mecanism propus de LLM, formulat înaintea testului împreună cu ce l-ar infirma; o critică de tip recenzent și răspunsul echipei
- Notați fiecare prompt care a influențat o decizie în AI_USE.md; fiecare referință inventată, fapt memorat sau cifră greșită depistată în AI_ERRORS.md, cu testul care a depistat-o ([șabloane](#))

Alegerea metodei

Situația	Alegerea	Motivul
Reper rapid și transparent	Dicționarul LM	fără antrenare, verificabil
Texte financiare scurte în engleză	FinBERT	precis, milisecunde pe text
Fără etichete, alte limbi, documente lungi	LLM deschis (7B+)	zero-shot, flexibil
Câteva sute de etichete din domeniul de interes	embeddings + regresie logistică	ieftin și adaptat domeniului

- Oricare ar fi metoda: evaluați în afara eșantionului, cu intervale și teste pe perechi

Idei principale

- ▣ Dicționarele generale citesc greșit finanțele; dicționarul LM este un reper transparent
- ▣ Între FinBERT și LLM-urile deschise de 7B–14B nu s-a detectat o diferență semnificativă de acuratețe pe titluri financiare (ceea ce nu dovedește egalitatea); câteva sute de etichete și un clasificator simplu concurează cu ambele
- ▣ LLM-urile își amintesc istoria piețelor: evaluați-le doar după data publicării lor
- ▣ Sentimentul titlurilor explică mișcările din aceeași zi; cu o aliniere realistă și costuri, nu depășește piața pentru acțiunile mari
- ▣ Scorurile sînt măsurători cu eroare: atenuarea, erorile posibil comune ale modelelor, puținele grupuri și numeroasele încercări influențează inferența

Anexă: dezacordul adnotatorilor: acord și etichete latente

- **κ al lui Fleiss (Fleiss (1971))**: N texte, m evaluatori, n_{ij} evaluatori care dau textului i eticheta j
 - ▶ $\bar{P} = \frac{1}{N} \sum_i \sum_j \frac{n_{ij}(n_{ij}-1)}{m(m-1)}$, $\bar{P}_e = \sum_j p_j^2$, $\kappa = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$; p_j : ponderea voturilor pentru j
 - ▶ Formula presupune același m pentru fiecare text; PhraseBank are 5–8 evaluatori pe propoziție și publică doar nivelurile de acord, nu voturile: κ nu poate fi calculat din datele publicate
- **Modelul Dawid–Skene (Dawid & Skene (1979))**: evaluatorul a are o matrice de confuzie $\pi_{jl}^{(a)} = P(\text{spune } l \mid \text{adevărat } j)$; clasa adevărată este latentă
 - ▶ Algoritmul EM estimează $\pi^{(a)}$ și dă fiecărui text o etichetă probabilistă $P(\text{adevărat} = j \mid \text{voturi})$
- **Evaluati modelele cu o regulă de scor proprie (proper scoring rule)**, precum pierderea logaritmică față de etichetele probabiliste, nu prin acuratețe față de eticheta majoritară
 - ▶ Plafonul din graficul acordului este un plafon al zgomotului etichetelor, nu un eșec al modelului

Anexă: exemplu rezolvat: FinBERT față de LM

- ▣ Setul de validare Twitter, 2 388 de titluri: LM 60,5%, FinBERT 72,5%
 - ▶ LM greșește și FinBERT are dreptate: $n_{01} = 539$; LM are dreptate și FinBERT greșește: $n_{10} = 252$
 - ▶ Testul McNemar exact: $p < 0,001$
- ▣ Diferența: +12,0 puncte procentuale, CI 95% bootstrap [+10,0; +14,2]
 - ▶ Avantaj clar al modelului ajustat fin, chiar și în afara datelor lui de antrenare

Anexă: timpul de procesare al modelelor Qwen2.5

- Timpul pe titlu pe procesorul grafic al unui laptop, inclusiv prompt-ul; timpul median al unei treceri, pentru fiecare prompt
 - ▶ 0.5B: 4 ms; 1.5B: 12 ms; 3B: 20 ms; 7B: 92 ms; 14B: 105 ms
 - ▶ O singură trecere este zgomotoasă (memorie, alte sarcini): 7B a durat între 51 și 94 ms, 14B între 88 și 112 ms; o afirmație despre viteză cere rulări repetate
- FinBERT are nevoie de câteva milisecunde pe propoziție pe același laptop

Anexă: dincolo de titluri: documente lungi

- ▣ Rapoarte anuale: [Loughran & McDonald \(2011\)](#) și-au construit listele din formulare 10-K; tonul și incertitudinea anunță randamentele și volatilitatea în jurul publicării
- ▣ Conferințe despre rezultate și rapoarte ale analiștilor: [Huang, Wang & Yang \(2023\)](#) arată că FinBERT extrage informație pe care dicționarele nu o surprind
- ▣ [Kim, Muhn & Nikolaev \(2023\)](#): rezumatele făcute de LLM ale raportărilor sînt mult mai scurte, dar explică mai bine reacțiile pieței decît originalele
 - ▶ Ei măsoară lungimea excesivă a raportărilor: textul lung și puțin informativ este asociat cu o eficiență mai mică a prețurilor
- ▣ Documentele lungi cer modele cu ferestre de context mari sau segmentarea textului și agregarea rezultatelor

Anexă: regresii pe text cu fundamentare statistică

- **Taddy (2013)**: regresia inversă multinomială: modelăm frecvențele cuvintelor condiționat de rezultat, $c_d \sim \text{MN}(q(y_d), m_d)$, c_d : frecvențele, $m_d = \sum_j c_{dj}$: lungimea
 - ▶ Model log-liniar $q_j(y) \propto e^{\alpha_j + \varphi_j^\top y}$, încărcările $\Phi = (\varphi_1, \dots, \varphi_p)^\top$: dat fiind m_d și acest model, $z_d = \Phi^\top c_d / m_d$ este suficient pentru y_d
- **Ke, Kelly & Xiu (2019)** (SESTM): selectăm cuvintele corelate cu randamentele, estimăm un model cu două teme (cuvinte pozitive și negative), atribuim scoruri articolelor noi prin verosimilitate penalizată
 - ▶ Lucrarea dă garanții statistice pentru estimator; semnalul este cel mai puternic în ziua știrii și în ziua următoare
- **Bybee et al. (2024)**: atenția acordată temelor în 800.000 de articole Wall Street Journal urmărește activitatea economică și prognozează randamentele agregate ale pieței
 - ▶ De asemenea **Jegadeesh & Wu (2013)** (ponderi ale cuvintelor din reacțiile la 10-K); regula pentru toate: estimare pe date anterioare perioadei de prognoză

Anexă: dispariția memoriei: un test formal și puterea lui

- $H_0 : AUC_{\text{înainte}} = AUC_{\text{după}}$, două eșantioane independente; varianța DeLong pentru fiecare AUC (DeLong et al. (1988))
 - ▶ $z = (\widehat{AUC}_1 - \widehat{AUC}_2) / \sqrt{\widehat{V}_1 + \widehat{V}_2}$: 14B $z = 0,73$ ($p = 0,47$), 7B $z = 1,01$ ($p = 0,31$)
- Puterea: cu 23 de luni după publicare, $SE(AUC)$ sub H_0 este 0,12; cea mai mică scădere detectabilă cu puterea 80% este 0,36
 - ▶ O cădere de la 0,69 la 0,5 este mai mică: ar fi nevoie de circa 101 luni după publicare
- Nerespingerea lui H_0 aici nu este informativă: lipsa dovezilor de memorie după publicare nu este o dovadă a absenței ei înainte

Anexă: etichete discrete: clasificarea greșită nu este eroare clasică

- Variabila binară „știre negativă” $s^* \in \{0, 1\}$, eticheta prezisă $\hat{s}$; $\alpha_0 = P(\hat{s} = 1 \mid s^* = 0)$, $\alpha_1 = P(\hat{s} = 0 \mid s^* = 1)$
 - ▶ Eroarea $u = \hat{s} - s^*$ este corelată negativ cu s^* : formula clasică nu se aplică (Aigner (1973))
 - ▶ $\text{plim } \hat{b} = \beta \frac{\pi(1-\pi)(1-\alpha_0-\alpha_1)}{p(1-p)}$, $\pi = P(s^* = 1)$, $p = P(\hat{s} = 1)$
- Setul de validare Twitter, $\pi = 14,5\%$, din matricile de confuzie
 - ▶ FinBERT: $\alpha_0 = 13,3\%$, $\alpha_1 = 23,9\%$, factorul 0,45; Qwen2.5-7B: 0,59; LM ($\alpha_1 = 50,4\%$): 0,28
- Cât timp $\alpha_0 + \alpha_1 < 1$ semnul se păstrează, dar panta unei variabile binare se poate reduce la o treime sau mai puțin

Anexă: două măsuri zgomotoase: modelul factorial și variabilele instrumentale

- Un factor: $z_j = \lambda_j f + u_j$, $\text{Var}(f) = 1$, u_j necorelate cu f și între ele: $\rho_{jk} = \lambda_j \lambda_k$, deci $\lambda_j^2 = \rho_{jk} \rho_{jl} / \rho_{kl}$
 - Scorurile zilnice FNSPID: $\lambda = 0,53$ (LM), 0,85 (FinBERT), 0,78 (Qwen)
- IV (instrumental variables, variabile instrumentale): cu $r = a + \beta f + \varepsilon$, instrumentăm z_Q cu z_F :

$$\hat{b}_{IV} = \widehat{\text{Cov}}(r, z_F) / \widehat{\text{Cov}}(z_Q, z_F) \rightarrow \beta / \lambda_Q \text{ dacă } \lambda_F \neq 0, f \text{ este necorelat cu } \varepsilon, \text{ iar } u_F \text{ este necorelată cu } u_Q \text{ și cu } \varepsilon$$
 - Ziua d , Qwen: 59 bp [53; 66] cu FinBERT ca instrument, 37 bp [28; 46] cu LM (bootstrap pe zile)
- Dacă ambele instrumente ar fi valide, estimările ar coincide: diferența 22 bp, $z = 5,4$: respins
 - Testul respinge restricțiile comune, nu un instrument anume: erorile FinBERT–Qwen corelate prin texte de antrenare care se suprapun sînt o cauză plauzibilă, o eroare LM legată de randamente este alta; atunci și valorile λ ale factorului sînt îndoielnice

Anexă: rețele sociale și comportament de turmă: GameStop, 2021

- Bollen, Mao & Zeng (2011): starea de spirit colectivă de pe Twitter a anticipat Dow Jones în 2008; rezultatul este sensibil la eșantion și metodă
- Ianuarie 2021: investitori individuali s-au coordonat pe rețelele sociale și au ridicat GameStop de peste zece ori în câteva săptămâni
 - ▶ Atenția, sentimentul și tranzacțiile au crescut împreună; acest episod singur nu poate separa predicția de cauzalitate: fiecare cere propriul test
- Lecții pentru semnalele textuale
 - ▶ Volumul atenției poate conta mai mult decât tonul
 - ▶ Semnalele urmate de prea mulți investitori (crowding) se inversează și creează risc pentru vânzătorii în lipsă (Capitolul 17: bule)



Un magazin GameStop, Vallejo, California, februarie 2021

Foto: Will Buckner (2021); CC BY 2.0; Wikimedia Commons

Anexă: bucla descoperirii, prompt-uri reutilizabile (1/2)

- **Literatura:** "Găsește studii din 2023 încoace care prognozează randamentele acțiunilor cu sentimentul din LLM-uri și testează după data-limită a cunoștințelor modelului: DOI sau id arXiv, data-limită, fereastra de test, estimarea principală."
 - ▶ Verificați fiecare identificator; Semantic Scholar, Google Scholar, Elicit pentru căutare; [Lopez-Lira & Tang \(2026\)](#) este designul de referință
- **Ipoteze:** "Propune mecanisme prin care sentimentul titlurilor ar putea prognoza randamentele după $d+1$ și, pentru fiecare, tiparul transversal care l-ar infirma."
 - ▶ Reacția insuficientă prezice un drift concentrat în acțiunile mici și puțin urmărite; memorarea prezice un avantaj care dispare după data publicării
- **Date și cod:** "Din scorurile zilnice ale știrilor din acest capitol și închiderile zilnice ale cursului, reprodu strategia zilnică Qwen din acest capitol (intrare la închiderea din $d+1$, hedging pe SPY) și t -ul ei Newey-West."
 - ▶ Orice asistent (Claude, ChatGPT, Gemini, GitHub Copilot); scorurile sînt salvate, deci niciun model nu trebuie rulat din nou

Anexă: bucla descoperirii, prompt-uri reutilizabile (2/2)

- **Robustețea**, fixată dinainte: "Înainte de orice rulare nouă, scrie grila completă de variante pe care le-ai testa și corecția pentru testarea multiplă; toate vor fi raportate."
 - ▶ Placebo: scoruri amestecate între acțiuni în aceeași zi; subperioade; costuri de 5 bp pe tranzacție
- **Critica**: "Scrie un raport de recențent: toate felurile în care strategia ar putea reflecta look-ahead bias, memorarea, selecția sau marcasele de timp, cu testul pentru fiecare."
 - ▶ Apoi verificați direct fiecare test propus: și o critică poate conține rezultate inventate
- **Raportul**: toată grila, varianta aleasă înaintea rezultatelor, versiunile modelelor și datele publicării

Anexă: agenți AI în tranzacționare: utilizări și riscuri

- Un agent este un LLM într-o buclă: citește intrările, decide, apelează instrumente (date, cod, căutarea știrilor, ordine printr-un API), observă, repetă
 - ▶ Folosit azi pentru rezumate de cercetare, programare și monitorizare; tranzacționarea complet autonomă este încă rară și experimentală
- Manipulare: un text citit de agent poate conține instrucțiuni (prompt injection), de exemplu un comunicat de presă fals
- Risc sistemic (IMF (2024)): multe firme cu modele asemănătoare pot tranzacționa la fel, crescând viteza și corelația mișcărilor în perioade de stres
 - ▶ Controale: limite de poziție, aprobarea umană a ordinelor, jurnalizarea fiecărui pas, teste după fiecare actualizare a modelului

Anexă: lista capcanelor

- ▣ **Suprapunerea cu datele de antrenare:** FinBERT are 89,0% pe PhraseBank, care se suprapune în mare parte cu datele lui de antrenare, și 72,5% pe date noi de pe Twitter
- ▣ **Look-ahead bias:** un LLM își poate aminti piața de după știre; testați după data publicării lui
- ▣ **Alinierea în timp:** marcaje doar la nivel de dată; tranzacționați cel mai devreme la închiderea de după ce știrea este sigur publică
- ▣ **Data snooping:** prompt-uri, praguri și modele alese după examinarea rezultatelor de test
- ▣ **Costuri și crowding:** câștigurile zilnice mici dispar odată ce scădem costuri de câteva puncte de bază
- ▣ **Regresori generați:** scorurile sînt estimări; corecțați atenuarea, validați pe un eșantion aleator etichetat de oameni (PPI)

Anexă: lecturi suplimentare

- ▣ Tetlock (2007): pesimismul din presă prezice randamentele pieței
- ▣ Loughran & McDonald (2011): un dicționar de sentiment specific finanțelor
- ▣ Gentzkow, Kelly & Taddy (2019): textul ca date în economie
- ▣ Aplicații pe criptoactive: clasificarea criptoactivelor [Pele et al. \(2023\)](#), bulele Dogecoin și sentimentul [Pele \(2025\)](#), Quantlet de sentiment [Pele \(2024\)](#)
- ▣ Studiu suplimentar: [Quantinar: Natural Language Processing](#), [Quantinar: DELTA](#), [Quantinar: LDA Extensions](#); manualul [Franke, Härdle & Hafner \(2019\)](#) pentru statistica din spatele testelor



Bibliografie (1/7)

- ▣ Aigner, D.J. (1973). Regression with a binary independent variable subject to errors of observation. *Journal of Econometrics*, 1(1), 49–59.
- ▣ Angelopoulos, A.N., Bates, S., Fannjiang, C., Jordan, M.I., Zrnic, T. (2023). Prediction-powered inference. *Science*, 382(6671), 669–674.
- ▣ Antweiler, W., Frank, M.Z. (2004). Is all that talk just noise? The information content of internet stock message boards. *Journal of Finance*, 59(3), 1259–1294.
- ▣ Araci, D. (2019). FinBERT: financial sentiment analysis with pre-trained language models. arXiv:1908.10063.
- ▣ Baker, M., Wurgler, J. (2006). Investor sentiment and the cross-section of stock returns. *Journal of Finance*, 61(4), 1645–1680.
- ▣ Battaglia, L., Christensen, T., Hansen, S., Sacher, S. (2024). Inference for regression with variables generated by AI or machine learning. arXiv:2402.15585.
- ▣ Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- ▣ Boehmer, E., Musumeci, J., Poulsen, A.B. (1991). Event-study methodology under conditions of event-induced variance. *Journal of Financial Economics*, 30(2), 253–272.
- ▣ Bollen, J., Mao, H., Zeng, X. (2011). Twitter mood predicts the stock market. *Journal of Computational Science*, 2(1), 1–8.

Bibliografie (2/7)

- ▣ Brier, G.W. (1950). [Verification of forecasts expressed in terms of probability](#). *Monthly Weather Review*, 78(1), 1–3.
- ▣ Brown, T.B., Mann, B., Ryder, N., Subbiah, M., et al. (2020). [Language models are few-shot learners](#). *NeurIPS*; arXiv:2005.14165.
- ▣ Bybee, L., Kelly, B., Manela, A., Xiu, D. (2024). [Business news and business cycles](#). *Journal of Finance*, 79(5), 3105–3147.
- ▣ Cameron, A.C., Gelbach, J.B., Miller, D.L. (2008). [Bootstrap-based improvements for inference with clustered errors](#). *Review of Economics and Statistics*, 90(3), 414–427.
- ▣ Cameron, A.C., Gelbach, J.B., Miller, D.L. (2011). [Robust inference with multiway clustering](#). *Journal of Business & Economic Statistics*, 29(2), 238–249.
- ▣ Dawid, A.P., Skene, A.M. (1979). [Maximum likelihood estimation of observer error-rates using the EM algorithm](#). *Applied Statistics*, 28(1), 20–28.
- ▣ DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). [Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach](#). *Biometrics*, 44(3), 837–845.
- ▣ Devlin, J., Chang, M.-W., Lee, K., Toutanova, K. (2019). [BERT: pre-training of deep bidirectional Transformers for language understanding](#). *NAACL*; arXiv:1810.04805.
- ▣ Dong, Z., Fan, X., Peng, Z. (2024). [FNSPID: a comprehensive financial news dataset in time series](#). *Proceedings of the 30th ACM SIGKDD Conference*, 4918–4927.

Bibliografie (3/7)

- Drinkall, F., Rahimikia, E., Pierrehumbert, J.B., Zohren, S. (2024). [Time Machine GPT](#). arXiv:2404.18543.
- Driscoll, J.C., Kraay, A.C. (1998). [Consistent covariance matrix estimation with spatially dependent panel data](#). *Review of Economics and Statistics*, 80(4), 549–560.
- Egami, N., Hinck, M., Stewart, B.M., Wei, H. (2023). [Using imperfect surrogates for downstream inference: design-based supervised learning for social science applications of large language models](#). arXiv:2306.04746.
- Fleiss, J.L. (1971). [Measuring nominal scale agreement among many raters](#). *Psychological Bulletin*, 76(5), 378–382.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- Gentzkow, M., Kelly, B., Taddy, M. (2019). [Text as data](#). *Journal of Economic Literature*, 57(3), 535–574.
- Glasserman, P., Lin, C. (2023). [Assessing look-ahead bias in stock return predictions generated by GPT sentiment analysis](#). arXiv:2309.17322.
- Gu, S., Kelly, B., Xiu, D. (2020). [Empirical asset pricing via machine learning](#). *Review of Financial Studies*, 33(5), 2223–2273.
- Guo, C., Pleiss, G., Sun, Y., Weinberger, K.Q. (2017). [On calibration of modern neural networks](#). *ICML*; arXiv:1706.04599.

Bibliografie (4/7)

- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- ▣ He, S., Lv, L., Manela, A., Wu, J. (2025). Chronologically consistent large language models. arXiv:2502.21206.
- ▣ Huang, A.H., Wang, H., Yang, Y. (2023). FinBERT: a large language model for extracting information from financial text. *Contemporary Accounting Research*, 40(2), 806–841.
- ▣ Hutto, C., Gilbert, E. (2014). VADER: a parsimonious rule-based model for sentiment analysis of social media text. *Proceedings of the International AAAI Conference on Web and Social Media*, 8(1), 216–225.
- ▣ IMF (2024). Advances in artificial intelligence: implications for capital market activities. *Global Financial Stability Report*, October 2024, Chapter 3.
- ▣ Jegadeesh, N., Wu, D. (2013). Word power: a new approach for content analysis. *Journal of Financial Economics*, 110(3), 712–729.
- ▣ Ke, Z.T., Kelly, B., Xiu, D. (2019). Predicting returns with text data. NBER Working Paper 26186.
- ▣ Kearney, C., Liu, S. (2014). Textual sentiment in finance: a survey of methods and models. *International Review of Financial Analysis*, 33, 171–185.
- ▣ Kim, A., Muhn, M., Nikolaev, V. (2023). Bloated disclosures: can ChatGPT help investors process information? arXiv:2306.10224.

Bibliografie (5/7)

- ▣ Lopez-Lira, A., Tang, Y. (2026). [Can ChatGPT forecast stock price movements? Return predictability and large language models.](#) *Journal of Financial Economics*, 184, 104335.
- ▣ Lopez-Lira, A., Tang, Y., Zhu, M. (2025). [The memorization problem: can we trust LLMs' economic forecasts?](#) arXiv:2504.14765.
- ▣ Loughran, T., McDonald, B. (2011). [When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks.](#) *Journal of Finance*, 66(1), 35–65.
- ▣ Loughran, T., McDonald, B. (2016). [Textual analysis in accounting and finance: a survey.](#) *Journal of Accounting Research*, 54(4), 1187–1230.
- ▣ Lu, C., Lu, C., Lange, R.T., Foerster, J., Clune, J., Ha, D. (2024). [The AI Scientist: towards fully automated open-ended scientific discovery.](#) arXiv:2408.06292.
- ▣ Ludwig, J., Mullainathan, S. (2024). [Machine learning as a tool for hypothesis generation.](#) *Quarterly Journal of Economics*, 139(2), 751–827.
- ▣ Ludwig, J., Mullainathan, S., Rambachan, A. (2024). [Large language models: an applied econometric framework.](#) arXiv:2412.07031.
- ▣ Malo, P., Sinha, A., Korhonen, P., Wallenius, J., Takala, P. (2014). [Good debt or bad debt: detecting semantic orientations in economic texts.](#) *Journal of the Association for Information Science and Technology*, 65(4), 782–796.
- ▣ Mikolov, T., Chen, K., Corrado, G., Dean, J. (2013). [Efficient estimation of word representations in vector space.](#) arXiv:1301.3781.

Bibliografie (6/7)

- ▣ Ouyang, L., Wu, J., Jiang, X., Almeida, D., et al. (2022). Training language models to follow instructions with human feedback. *NeurIPS*; arXiv:2203.02155.
- ▣ Pele, D.T. (2024). [Sentiment Analysis](#) (Quantlet, BitMood project). IDA Quantlets Repository, Bucharest University of Economic Studies.
- ▣ Pele, D.T. (2025). [Dogecoin and speculative bubbles: a study using LPPL and sentiment analysis](#). Quantinar course, Bucharest University of Economic Studies.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). [Are cryptos becoming alternative assets?](#) *The European Journal of Finance*, 29(10), 1064–1105.
- ▣ Petersen, M.A. (2009). [Estimating standard errors in finance panel data sets: comparing approaches](#). *Review of Financial Studies*, 22(1), 435–480.
- ▣ Qwen Team (2024). [Qwen2.5 technical report](#). arXiv:2412.15115.
- ▣ Reimers, N., Gurevych, I. (2019). [Sentence-BERT: sentence embeddings using Siamese BERT-networks](#). *EMNLP*; arXiv:1908.10084.
- ▣ Sarkar, S.K., Vafa, K. (2024). [Lookahead bias in pretrained language models](#). SSRN Working Paper 4754678.
- ▣ Shannon, C.E. (1951). [Prediction and entropy of printed English](#). *Bell System Technical Journal*, 30(1), 50–64.

Bibliografie (7/7)

- ▣ Shao, X. (2010). [The dependent wild bootstrap](#). *Journal of the American Statistical Association*, 105(489), 218–235.
- ▣ Shiller, R.J. (2017). [Narrative economics](#). *American Economic Review*, 107(4), 967–1004.
- ▣ Simonsohn, U., Simmons, J.P., Nelson, L.D. (2020). [Specification curve analysis](#). *Nature Human Behaviour*, 4(11), 1208–1214.
- ▣ Taddy, M. (2013). [Multinomial inverse regression for text analysis](#). *Journal of the American Statistical Association*, 108(503), 755–770.
- ▣ Tetlock, P.C. (2007). [Giving content to investor sentiment: the role of media in the stock market](#). *Journal of Finance*, 62(3), 1139–1168.
- ▣ Tetlock, P.C., Saar-Tsechansky, M., Macskassy, S. (2008). [More than words: quantifying language to measure firms' fundamentals](#). *Journal of Finance*, 63(3), 1437–1467.
- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., et al. (2017). [Attention is all you need](#). *NeurIPS*; arXiv:1706.03762.
- ▣ Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., Zhou, M. (2020). [MiniLM: deep self-attention distillation for task-agnostic compression of pre-trained Transformers](#). *NeurIPS*; arXiv:2002.10957.
- ▣ Wu, S., Irsoy, O., Lu, S., Dabrovolski, V., et al. (2023). [BloombergGPT: a large language model for finance](#). arXiv:2303.17564.