



Modelarea piețelor financiare

Capitolul 15: LLM-uri și analiza sentimentului



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (inteligență artificială)
- AMEX: American Stock Exchange (Bursa Americană de Valori)
- API: Application Programming Interface (interfață de programare a aplicațiilor)
- AUC: Area Under the (ROC) Curve (aria de sub curba ROC)
- BERT: Bidirectional Encoder Representations from Transformers (reprezentări bidirecționale produse de codificatorul unui Transformer)
- BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- BY-NC: Creative Commons Attribution-NonCommercial (licența Creative Commons: atribuire, utilizare necomercială)
- CI: Confidence Interval (interval de încredere)
- ECE: Expected Calibration Error (eroarea medie de calibrare)
- EM: Expectation-Maximisation (algorithm) (algoritmul de maximizare a așteptării)
- FDR: False Discovery Rate (rata descoperirilor false)
- FNSPID: Financial News and Stock Price Integration Dataset (setul de date care integrează știri financiare și prețuri de acțiuni)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- GI: (Harvard) General Inquirer, dictionary IV-4 (dicționarul Harvard General Inquirer IV-4)
- GPT: Generative Pre-trained Transformer (Transformer generativ pre-antrenat)
- GPT-1: Generative Pre-trained Transformer 1 (Transformer generativ pre-antrenat, versiunea 1)
- GPT-2: Generative Pre-trained Transformer 2 (Transformer generativ pre-antrenat, versiunea 2)
- GPT-3: Generative Pre-trained Transformer 3 (here version 3.5) (Transformer generativ pre-antrenat, versiunea 3 (aici versiunea 3.5))
- GPT-4: Generative Pre-trained Transformer 4 (Transformer generativ pre-antrenat, versiunea 4)
- IV-4: Harvard IV-4 (version 4 of the General Inquirer word lists) (Harvard IV-4, versiunea 4 a listelor de cuvinte General Inquirer)
- LLM: Large Language Model (model lingvistic mare)
- LM: Loughran-McDonald (financial sentiment dictionary) (dicționarul financiar de sentiment Loughran-McDonald)
- LR: Logistic Regression (regresie logistică)
- MIT: Massachusetts Institute of Technology (Institutul de Tehnologie din Massachusetts)
- NASDAQ: National Association of Securities Dealers Automated Quotations (bursa americană NASDAQ (cotații automate ale Asociației Naționale a Dealerilor de Valori Mobiliare))
- NYSE: New York Stock Exchange (Bursa din New York)

Acronime folosite în acest material (2/2)

- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ PCA: Principal Component Analysis (analiza componentelor principale)
- ▣ PPI: Prediction-Powered Inference (inferență susținută de predicții)
- ▣ RLHF: Reinforcement Learning from Human Feedback (învățare prin recompensă din evaluări umane)
- ▣ SE: Standard Error (eroare standard)
- ▣ SESTM: Sentiment Extraction via Screening and Topic Modelling (extragerea sentimentului prin selecție și modelarea temelor)
- ▣ TF-IDF: Term Frequency - Inverse Document Frequency (frecvența termenului înmulțită cu inversul frecvenței în documente)
- ▣ US: United States (Statele Unite ale Americii)
- ▣ UTC: Coordinated Universal Time (Temps Universel Coordonné) (timpul universal coordonat)
- ▣ VADER: Valence Aware Dictionary and sEntiment Reasoner (dicționar și reguli pentru valența și sentimentul textelor)

Cuprins

De ce text?

Dicționare

Date etichetate și evaluare

Modele de limbaj: FinBERT și LLM-uri

Embeddings ca variabile

Privirea în viitor și memorarea

De la sentiment la un semnal de tranzacționare

Scorurile de sentiment sunt estimări

Studiu de caz: poate ChatGPT să prognozeze randamentele acțiunilor?


AI pentru descoperire științifică

Practică și concluzii

Bibliografie

Piețele funcționează cu cuvinte

- Prețurile se modifică odată cu apariția informațiilor, iar cele mai multe informații sunt transmise sub formă de text
 - ▶ Știri, raportări ale companiilor, conferințe despre rezultate, rapoarte ale analiștilor, comunicate ale băncilor centrale, rețele sociale
- Ziarele financiare sunt la fel de vechi ca piețele organizate
 - ▶ The Wall Street Journal: primul număr pe 8 iulie 1889 (fotografia)
- Astăzi: milioane de documente pe zi, mult mai multe decât poate citi orice analist



The Wall Street Journal, primul număr, 8 iulie 1889

Foto: Dow Jones & Company (1889); domeniu public;

[Wikimedia Commons](#)

Textul ca date și ce înțelegem prin sentiment

- ▣ **Gentzkow, Kelly & Taddy (2019)**: un document d este reprezentat numeric prin x_d (frecvențe, scoruri, vectori), folosit într-un model statistic obișnuit
 - ▶ x_d devine o mărime de interes (sentiment, temă, risc), folosită apoi pentru a analiza o problemă economică (randamente, volatilitate)
- ▣ **Sentimentul unui text**: o veste bună, rea sau neutră pentru activul menționat
 - ▶ Trei clase sau scorul net $s = P(\text{pozitiv}) - P(\text{negativ}) \in [-1, 1]$
 - ▶ Nu este **sentimentul investitorilor**, starea de spirit măsurată din date de piață (**Baker & Wurgler (2006)**)
- ▣ Sinteze pentru finanțe: **Kearney & Liu (2014)**, **Loughran & McDonald (2016)**
- ▣ Acest capitol: scorul este o **estimare** a tonului adevărat, cu eroare de măsurare; îl folosim apoi pentru randamentele zilnice ale acțiunilor

Primele dovezi: cuvintele mișcă prețurile

- Antweiler & Frank (2004): mesajele de pe forumurile despre acțiuni ajută la prognoza volatilității; efectul asupra randamentelor este mic
- Tetlock (2007): pesimismul ridicat dintr-o rubrică a Wall Street Journal anunță presiuni de scădere a prețurilor, urmate de o revenire
 - ▶ Pesimismul neobișnuit de mare sau de mic anunță și volume mari de tranzacționare
- Tetlock, Saar-Tsechansky & Macskassy (2008): ponderea cuvintelor negative din știrile despre o firmă anunță câștiguri mici și randamente absorbite doar treptat
- Ideea comună: textul conține informație pe care prețurile o absorb repede, dar nu întotdeauna instantaneu

Narațiuni și piețe

- **Shiller (2017)**: poveștile populare se răspândesc ca epidemiile și influențează deciziile economice
 - ▶ Narațiunile pot fi măsurate doar prin text: ziare, cărți, rețele sociale
- **Shiller**: Premiul Nobel pentru Economie 2013, împreună cu Fama și Hansen
 - ▶ Capitolul 2 (eficiența) și Capitolul 17 (bulele) se întâlnesc aici: narațiunile pot îndepărta prețurile de fundamente



Robert J. Shiller, Stockholm, decembrie 2013

Foto: Bengt Nyman (2013); CC BY 2.0; Wikimedia
Commons

Patru moduri de a transforma textul în sentiment

Metoda	Cum funcționează	Etichete necesare	Exemple
Dicționar	numără cuvintele din listă	niciuna	GI, LM, VADER
Model ajustat fin	rețea antrenată pe propoziții etichetate	mii	FinBERT
Model mare de limbaj	instrucțiune în limbaj natural (prompt)	niciuna (zero-shot)	Qwen2.5, GPT
Embeddings + clasificator	vectorii textelor într-o regresie	sute până la mii	MiniLM

- Le comparăm pe toate patru pe aceleași date etichetate, cu intervale de încredere
- Apoi ne întrebăm dacă vreuna produce câștiguri pe randamentele zilnice ale acțiunilor

Recapitularea secțiunii

- ▣ Cea mai mare parte a informației financiare este text; textul devine date printr-o reprezentare numerică
- ▣ Sentimentul textului: tonul unui document despre un activ, sub formă de clase sau de scor în $[-1, 1]$
- ▣ Patru familii de metode, de la liste de cuvinte la modele mari de limbaj


Mulțimea de cuvinte și tonul

- ▣ **Reprezentarea prin frecvențele cuvintelor (bag of words):** documentul este redus la frecvențele cuvintelor; ordinea este ignorată
 - ▶ Tokeni: cuvintele scrise cu majuscule, fără cifre și semne de punctuație
- ▣ Un dicționar listează cuvintele pozitive $\mathcal{P}$ și cuvintele negative $\mathcal{N}$
 - ▶ P_d, N_d : numărul de cuvinte pozitive și negative din documentul d
 - ▶ **Tonul:** $\tau_d = \frac{P_d - N_d}{P_d + N_d} \in [-1, 1]$, iar $\tau_d = 0$ dacă $P_d + N_d = 0$
 - ▶ Clasa: pozitiv dacă $\tau_d > 0$, negativ dacă $\tau_d < 0$, neutru altfel
- ▣ Transparent, rapid și fără date de antrenare; nu vede contextul și negația

Dicționare generale versus financiare

- **Harvard General Inquirer** (GI), lista IV-4: un dicționar de psihologie din anii 1960
 - ▶ 2 007 cuvinte negative și 1 637 pozitive
- **Loughran & McDonald (2011)** (LM): construit din rapoartele anuale (formularele 10-K) ale firmelor americane
 - ▶ 2 355 cuvinte negative și doar 354 pozitive; plus liste pentru incertitudine și litigii
 - ▶ Concluzia lor: aproape trei sferturi dintre cuvintele negative din GI nu sunt negative în context financiar
- În listele folosite aici: 1 552 cuvinte negative din GI (77%) nu sunt cuvinte negative în LM

Negative pentru un psiholog, neutre pentru un contabil



- Cuvinte negative în GI, dar nu în LM, ordonate după numărul de propoziții din Financial PhraseBank care le conțin
- Culoarea: eticheta de sentiment dată propoziției de adnotatorii umani

Interpretare: finanțele au propriul vocabular

- ▣ „Service” (106 propoziții), „capital” (104) și „board” (79) sunt substantive uzuale în limbajul de afaceri, nu indicii ale unor vești negative
 - ▶ Ponderea propozițiilor care conțin aceste cuvinte și nu sunt etichetate negativ: 98%, 93%, 96%
 - ▶ „Vice” apare în „vice president”: 100% dintre propozițiile care conțin acest cuvânt nu sunt negative
- ▣ „Lower” este excepția: doar 26% nu sunt negative, dar „costuri mai mici” este o veste bună
 - ▶ Semnul depinde de cuvântul următor: o problemă pe care nicio listă de cuvinte nu o poate rezolva
- ▣ Din cele 964 de propoziții ale căror singure cuvinte negative sunt de acest tip, 89% nu sunt etichetate negativ

Exemplu lucrat: o propoziție, două dicționare

- Propoziție din Financial PhraseBank, etichetată **pozitiv** de toți adnotatorii:
 - ▶ *Uponor improved its performance in spite of the decrease in residential construction in the US .*
- LM: cuvinte pozitive improved; cuvinte negative –
 - ▶ $\tau = (1 - 0)/(1 + 0) = +1,00$: pozitiv, corect
- GI: cuvinte pozitive –; cuvinte negative spite, decrease
 - ▶ $\tau = (0 - 2)/(0 + 2) = -1,00$: negativ, greșit
 - ▶ GI nu recunoaște „improved” și numără „spite” și „decrease”, care descriu piața, nu firma

VADER: reguli peste o listă de cuvinte

- **Hutto & Gilbert (2014)**: un lexicon cu scoruri de intensitate pentru circa 7.500 de termeni, construit pentru rețelele sociale
 - ▶ Reguli pentru negație („not good”), intensificatori („very”), majuscule, semne de exclamare și emoticoane
 - ▶ Rezultatul: un scor compus în $[-1, 1]$; pragurile uzuale $\pm 0,05$ pentru pozitiv și negativ
- Regulile rezolvă unele probleme de context, dar vocabularul rămâne general, nu financiar
 - ▶ Este al doilea reper general în testele noastre, alături de GI

Recapitularea secțiunii

- ▣ Tonul după dicționar: $(P - N)/(P + N)$ din frecvențele cuvintelor listate
- ▣ Dicționarele generale citesc greșit finanțele: majoritatea cuvintelor negative din GI sunt cuvinte obișnuite din afaceri
- ▣ LM corectează vocabularul, nu contextul: „costuri mai mici” contează în continuare ca negativ


Două corpusuri etichetate

- Financial PhraseBank (Malo et al. (2014)): 4 846 de propoziții din știri, etichetate de un grup de 16 adnotatori cu pregătire în finanțe, câte 5–8 pentru fiecare propoziție
 - ▶ Întrebarea: veste bună, rea sau neutră pentru investitor? Niveluri de acord: cel puțin 50%, 66%, 75% sau 100% dintre adnotatorii propoziției
 - ▶ 2 264 de propoziții cu acord deplin, 629 cu acord de cel puțin 50%, dar sub 66%; etichete 59% neutre, 28% pozitive, 12% negative
- Twitter Financial News (licența MIT, Hugging Face Hub): titluri din 2022, etichetate bearish, bullish sau neutre
 - ▶ Set de antrenare cu 9.543, set de validare cu 2 388 de titluri (folosit pentru evaluare); etichete 66% neutre, 20% pozitive, 15% negative
 - ▶ Texte scurte, zgomotoase, cu simboluri bursiere și linkuri: mai aproape de fluxul real de știri
- Două seturi de date, pentru că un rezultat obținut pe un set s-ar putea să nu se păstreze pe altul

Inferență pentru clasificatori

- ▣ Acuratețea, precizia, recall-ul și F1 macro ca în Capitolul 13; reperul: mereu „neutru”
 - ▶ Obține 66% acuratețe pe Twitter, dar un F1 macro de doar 26,4%
- ▣ **Testul McNemar**: doi clasificatori pe aceleași texte
 - ▶ n_{01} : A greșește și B are dreptate; n_{10} : A are dreptate și B greșește; textele pe care ambii le tratează la fel nu aduc informație
 - ▶ Sub H_0 (acuratețe egală), $n_{01} \sim \text{Binomial}(n_{01} + n_{10}; 0,5)$: un test exact
- ▣ Fiecare test de aici tratează eticheta umană drept adevăr; cu 5–8 adnotatori pe propoziție, care adesea nu sunt de acord, ea este la rândul ei zgomotoasă
 - ▶ Erorile aleatoare ale etichetelor plafonează acuratețea măsurată și apropiere de 0 diferențele măsurate dintre clasificatori

Unsprezece clasificatori, două seturi de date




- TF-IDF + LR și MiniLM + LR: regresii logistice antrenate pe setul de antrenare Twitter; celelalte metode nu folosesc nicio etichetă Twitter

Interpretare: niciun câștigător unic

- ▣ Dicționarele generale pierd în fața clasei majoritare pe ambele seturi: GI 43,6%, VADER 49,6% pe Twitter
 - ▶ LM este mai bun (60,5%), dar tot sub „mereu neutru” (66%) pe Twitter
- ▣ FinBERT: 89,0% pe PhraseBank, 72,5% pe Twitter; Qwen2.5-7B zero-shot: 81,4% și 74,2%
 - ▶ Cel mai bun pe Twitter este cel mai simplu model supervizat: TF-IDF + regresie logistică, 83,2%
 - ▶ TF-IDF: frecvențele cuvintelor și ale perechilor de cuvinte, cărora li se atribuie ponderi mai mici când termenul apare în multe documente
- ▣ Lecția: datele etichetate din domeniul-țintă contează mai mult decât dimensiunea modelului

Când oamenii nu sunt de acord, nici modelele nu sunt



- Financial PhraseBank împărțit după cel mai înalt prag de acord atins de adnotatorii fiecărei propoziții; grupul cel mai slab: de la 50% până sub 66%

Interpretare: ambiguitatea impune un plafon

- ▣ Acord deplin: FinBERT 97%, Qwen2.5-14B 94%, LM 65%
 - ▶ Acord de la 50% până sub 66%: FinBERT 70%, Qwen2.5-14B 55%, LM 54%
- ▣ Multe propoziții sunt cu adevărat ambigue: chiar și experții au opinii diferite
 - ▶ Un model nu poate fi judecat pe o etichetă asupra căreia oamenii nu sunt de acord
- ▣ Pentru semnale: un ton puternic și clar este mai informativ decât unul la limită

Când adnotatorii nu sunt de acord: acord și etichete latente

- ▣ **κ al lui Fleiss (Fleiss (1971))**: N texte, m evaluatori, n_{ij} evaluatori care dau textului i eticheta j
 - ▶ $\bar{P} = \frac{1}{N} \sum_i \sum_j \frac{n_{ij}(n_{ij}-1)}{m(m-1)}$, $\bar{P}_e = \sum_j p_j^2$, $\kappa = \frac{\bar{P} - \bar{P}_e}{1 - \bar{P}_e}$; p_j : ponderea voturilor pentru j
 - ▶ Formula presupune același m pentru fiecare text; PhraseBank are 5–8 evaluatori pe propoziție și publică doar nivelurile de acord, nu voturile: κ nu poate fi calculat din datele publicate
- ▣ **Modelul Dawid–Skene (Dawid & Skene (1979))**: evaluatorul a are o matrice de confuzie $\pi_{jl}^{(a)} = P(\text{spune } l \mid \text{adevărat } j)$; clasa adevărată este latentă
 - ▶ Algoritmul EM estimează $\pi^{(a)}$ și dă fiecărui text o etichetă probabilistă $P(\text{adevărat} = j \mid \text{voturi})$
- ▣ **Evaluati modelele cu o regulă de scor proprie (proper scoring rule)**, precum pierderea logaritmică față de etichetele probabiliste, nu prin acuratețe față de eticheta majoritară
 - ▶ Plafonul de pe slide-ul anterior este un plafon al zgomotului etichetelor, nu un eșec al modelului

Recapitularea secțiunii

- Două seturi de date etichetate: Financial PhraseBank (propoziții din știri) și Twitter Financial News (titluri)
- Raportați acuratețea cu CI și $F1$ macro; comparați clasificatorii cu testul McNemar pe perechi
- Dicționarele generale eșuează; modelele supervizate din domeniul-țintă sunt greu de învins


De la cuvinte la cuvinte în context

- Un dicționar dă cuvântului „lower” un semn fix; un model de limbaj citește propoziția din jurul lui
 - ▶ Fiecare token primește un vector care depinde de toți ceilalți tokeni (atenție, Capitolul 14; [Vaswani et al. \(2017\)](#))
- **BERT** ([Devlin et al. \(2019\)](#)): un codificator Transformer pre-antrenat pe cărți și Wikipedia
 - ▶ Sarcina de pre-antrenare: ghicirea cuvintelor ascunse aleator într-o propoziție (modelarea limbajului cu mascare)
 - ▶ Circa 110 milioane de parametri în versiunea de bază
- Ajustarea fină: se adaugă un strat mic de clasificare și se antrenează toată rețeaua pe propoziții etichetate

FinBERT

- ▣ [Araci \(2019\)](#): BERT pre-antrenat suplimentar pe știri financiare, apoi ajustat fin pentru sentiment
 - ▶ Modelul public folosit aici (ProsusAI/finbert) a fost ajustat fin pe Financial PhraseBank
 - ▶ Rezultatul: probabilitățile pentru pozitiv, negativ și neutru
- ▣ [Huang, Wang & Yang \(2023\)](#): un FinBERT antrenat pe rapoarte ale analiștilor, transcrieri ale conferințelor despre rezultate și formulare 10-K
 - ▶ Depășește dicționarele și alte metode de învățare automată, mai ales pe propozițiile pe care dicționarele le citeșc greșit
- ▣ Rulează pe un laptop obișnuit: câteva milisecunde pe propoziție

Unde sunt erorile



- Setul de validare Twitter: rândurile sunt etichetele adevărate, coloanele etichetele prezise; numărul de texte în celule

Interpretare: modele diferite, greșeli diferite

- ▣ LM trimite majoritatea titlurilor pozitive la neutru: lista sa de cuvinte pozitive este scurtă (354 de cuvinte)
- ▣ FinBERT greșește în ambele direcții în jurul clasei neutre
- ▣ Qwen2.5-7B găsește aproape toate titlurile pozitive și negative, dar consideră multe titluri neutre pozitive sau negative
 - ▶ Un LLM „vede” sentiment acolo unde adnotatorii au văzut simple fapte: recall mare, precizie mică pe clasele extreme
- ▣ Pentru tranzacționare, alarmele false costă bani: contează precizia pe clasele extreme

Capcana evaluării în eșantion


- ▣ FinBERT: 89,0% pe PhraseBank, pe care a fost antrenat în mare parte (Araci (2019): 3.101 din 4.845 de propoziții); 72,5% pe Twitter: o scădere de 16,4 puncte
 - ▶ Qwen2.5-7B, neajustat fin pe aceste etichete, scade și el cu 7,2 puncte: titlurile Twitter sunt mai grele
- ▣ Diferența diferențelor: $\Delta = (a_{F,P} - a_{F,T}) - (a_{Q,P} - a_{Q,T}) = 9,2$ puncte, CI 95% bootstrap [6,7; 11,9]
 - ▶ $a_{m,D}$: acuratețea modelului m (F: FinBERT, Q: Qwen) pe datele D (P: PhraseBank, T: Twitter)
 - ▶ Ipoteza de identificare: fără suprapunerea cu datele de antrenare, ambele modele ar pierde la fel de la PhraseBank la Twitter
 - ▶ Sub această ipoteză, 9,2 din cele 16,4 puncte provin din suprapunerea cu datele de antrenare; CI măsoară zgometul de eșantionare, nu ipoteza (cele două arhitecturi pot reacționa diferit la un domeniu nou)
- ▣ Regula: evaluați un model de limbaj doar pe texte pe care nu le-a văzut niciodată, ca în testele în afara eșantionului din capitolele 8 și 13

Exemplu lucrat: este FinBERT mai bun decât LM?

- ▣ Setul de validare Twitter, 2 388 de titluri: LM 60,5%, FinBERT 72,5%
 - ▶ LM greșește și FinBERT are dreptate: $n_{01} = 539$; LM are dreptate și FinBERT greșește: $n_{10} = 252$
 - ▶ Testul McNemar exact: $p < 0,001$
- ▣ Diferența: +12,0 puncte procentuale, CI 95% bootstrap [+10,0; +14,2]
 - ▶ Victorie clară a modelului ajustat fin, chiar și în afara datelor lui de antrenare

De la predicția cuvântului următor la instrucțiuni

- **Shannon (1951)**: engleza este foarte previzibilă din literele anterioare; un model mare de limbaj (LLM) estimează $P(w_{t+1} \mid w_1, \dots, w_t)$ pe tokeni
 - ▶ **Brown et al. (2020)**: la scară mare, sarcinile se rezolvă din câteva exemple date în prompt (few-shot)
 - ▶ **Ouyang et al. (2022)**: ajustarea pe instrucțiuni și RLHF învață modelul să urmeze cereri
- **BloombergGPT (Wu et al. (2023))**: 50 de miliarde de parametri, text financiar și general; modelele deschise generale îl egalează acum la sentiment
 - ▶ Noțiuni de bază: **Quantinar: The Next Word Problem**, **Quantinar: Natural Language Processing**



Claude E. Shannon, fondatorul teoriei informației

Foto: Tekniska museet, Stockholm (fără dată); CC BY 2.0; Wikimedia Commons


Clasificarea zero-shot cu un LLM

- Prompt-ul: o instrucțiune de sistem plus textul de clasificat
 - ▶ You classify the sentiment of financial news for investors. Answer with one word: positive, negative or neutral.
 - ▶ Headline: <text> Sentiment:
- Citim probabilitățile celor trei cuvinte-răspuns la prima poziție generată
 - ▶ Logiții z_k ai tokenilor „positive”, „negative”, „neutral”: $p_k = e^{z_k} / \sum_j e^{z_j}$
 - ▶ Eticheta: $\arg \max_k p_k$; scorul: $p_{\text{poz}} - p_{\text{neg}}$; nu se generează text, deci nu este necesară extragerea etichetei dintr-un răspuns textual

Modelele: Qwen2.5-Instruct

- ▣ [Qwen Team \(2024\)](#): modele cu ponderi deschise, de la 0,5 la 72 de miliarde de parametri, ponderi publicate pe 19 septembrie 2024
 - ▶ Folosim 0.5B, 1.5B, 3B, 7B și 14B (B: miliarde de parametri), toate cu licențe deschise
- ▣ Timpul pe titlu pe procesorul grafic al unui laptop, inclusiv prompt-ul; mediana unei treceri pentru fiecare prompt
 - ▶ 0.5B: 4 ms; 1.5B: 12 ms; 3B: 20 ms; 7B: 92 ms; 14B: 105 ms
 - ▶ O singură trecere este zgomotoasă (memorie, alte sarcini): 7B a durat între 51 și 94 ms, 14B între 88 și 112 ms; o afirmație despre viteză cere rulări repetate
 - ▶ Ponderi deschise: rezultatele pot fi reproduse, iar data publicării limitează ce putea ști modelul

Mai mare nu înseamnă întotdeauna mai bun




□ F1 macro pentru Qwen2.5 zero-shot cu același prompt; liniile punctate: FinBERT

 MFM_ch15_llm_zero_shot

Interpretare: dimensiunea ajută, dar inegal

- ▣ PhraseBank: F1 macro crește de la 63,3% (0.5B) la 82,1% (14B), tot sub FinBERT (88,3%)
 - ▶ Avantajul FinBERT de acolo vine parțial din suprapunerea cu datele de antrenare (Capcana evaluării în eșantion)
- ▣ Twitter: nu crește monoton; 1.5B este cel mai slab (55,3%), 7B cel mai bun (72,6%), peste FinBERT (66,8%)
 - ▶ 7B față de 1.5B la acuratețe: +21,5 puncte, McNemar $p < 0,001$
- ▣ Modelele mici reacționează puternic la formulare: modelul 1.5B răspunde rar „neutral” cu acest prompt

Același model, altă formulare




□ Trei prompt-uri care pun aceeași întrebare; setul de validare Twitter

 MFM_ch15_llm_zero_shot

Interpretare: prompt-ul este un parametru

- ▣ Intervalele de acuratețe: 1.5B între 52,7% și 61,7%; 7B între 73,7% și 77,8%; 14B între 69,9% și 75,6%
 - ▶ Cele trei prompt-uri dau aceeași etichetă doar pentru 67% dintre titluri (7B)
 - ▶ Ponderea răspunsurilor „neutral” pentru 7B: de la 48% (P1) la 69% (P3)
- ▣ Alegerea prompt-ului după ce ați văzut rezultatele pe test este o formă de data snooping (Capitolul 13)
 - ▶ Fixați prompt-ul dinainte sau alegeți-l pe un set de validare separat

Sunt probabilitățile calibrate?



- Setul de validare Twitter, o jumătate aleasă aleator; intervale ale probabilității etichetei alese; mărimea punctului: numărul de titluri
- Panoul din dreapta: $p_k(T) \propto p_k^{1/T}$, cu T estimat prin verosimilitate maximă pe cealaltă jumătate (Guo et al. (2017))

 MFM_ch15_valid_inference

Interpretare: probabilitățile LLM sunt prea încrezătoare

- ▣ ECE (expected calibration error, eroarea medie de calibrare): $\sum_b \frac{n_b}{n} |\text{acc}_b - \text{conf}_b|$ pe 10 intervale egale b ale probabilității maxime pe $[1/3, 1]$
 - ▶ FinBERT 10,4%, Qwen2.5-7B 22,6%, Qwen2.5-14B 25,9%: 7B atribuie etichetei alese, pentru 88% dintre titluri, o probabilitate de peste 0,93 (în medie 99,7%) și are dreptate la 77% dintre ele
- ▣ Scalarea prin temperatură: $T = 8,4$ pentru 7B, 1,4 pentru FinBERT; ECE scade la 4,3% și 4,6%
 - ▶ Log loss $-\frac{1}{n} \sum_i \ln p_{iy_i}$ (probabilități limitate inferior la 10^{-12}); Brier $\frac{1}{n} \sum_i \sum_k (p_{ik} - 1\{y_i = k\})^2$, însumat pe cele 3 clase
 - ▶ Log loss pentru 7B: de la 2,61 la 0,63; scorul Brier (Brier (1950)) de la 0,468 la 0,366; etichetele, deci acuratețea, nu se schimbă
- ▣ Calibrarea depinde de prompt: ECE pentru 7B este 22,6%, 22,1% și 19,8% cu P1, P2, P3
 - ▶ Scorul net $p_{\text{poz}} - p_{\text{neg}}$ intră în regresii: cu probabilitățile brute ale LLM el este aproape o etichetă cu trei valori

Exemplu lucrat: LLM versus FinBERT

- ▣ Twitter, prompt-ul P1: Qwen2.5-7B 74,2%, FinBERT 72,5%
 - ▶ $n_{01} = 395$, $n_{10} = 355$; McNemar $p = 0,154$; diferența +1,7 puncte, CI 95% [-0,5; +3,8]
 - ▶ Qwen2.5-14B față de FinBERT: -0,1 puncte, $p = 0,942$
- ▣ Nu s-a detectat nicio diferență semnificativă, ceea ce nu dovedește o acuratețe egală (CI admite până la +3,8 puncte): de 70 până la 130 de ori mai mulți parametri și o procesare mai lentă nu aduc un câștig demonstrat
 - ▶ Unde ajută LLM-urile: nu cer etichete, funcționează în orice limbă, pe documente mai lungi și mai complexe

Dincolo de titluri: documente lungi

- ▣ Rapoarte anuale: [Loughran & McDonald \(2011\)](#) și-au construit listele din formulare 10-K; tonul și incertitudinea anunță randamentele și volatilitatea în jurul publicării
- ▣ Conferințe despre rezultate și rapoarte ale analiștilor: [Huang, Wang & Yang \(2023\)](#) arată că FinBERT extrage informație pe care dicționarele o ratează
- ▣ [Kim, Muhn & Nikolaev \(2023\)](#): rezumatele făcute de LLM ale raportărilor sunt mult mai scurte, dar explică mai bine reacțiile pieței decât originalele
 - ▶ Ei măsoară „umflarea” raportărilor: textul lung și puțin informativ este asociat cu o eficiență mai mică a prețurilor
- ▣ Documentele lungi cer modele cu ferestre de context mari sau segmentarea textului și agregarea rezultatelor


Recapitularea secțiunii

- ▣ FinBERT bate orice dicționar în afara eșantionului; scorul lui pe PhraseBank este umflat de suprapunerea cu datele de antrenare (circa 9,2 puncte, sub ipoteza de identificare)
- ▣ Un LLM prezice tokenul următor; sentimentul zero-shot citește probabilitățile cuvintelor-răspuns
- ▣ Acuratețea crește în medie cu dimensiunea, dar nu monoton; prompt-ul schimbă rezultatul
- ▣ Pe titluri financiare scurte, între un model deschis de 7B până la 14B și FinBERT nu s-a detectat o diferență semnificativă de acuratețe; probabilitățile modelului sunt prea încrezătoare până la rescalare

Embeddings de text

- **Embedding**: un vector $e_d \in \mathbb{R}^k$, apropiat pentru texte asemănătoare: word2vec (Mikolov et al. (2013)), Sentence-BERT (Reimers & Gurevych (2019))
 - ▶ Aici MiniLM (Wang et al. (2020)), $k = 384$, lungime 1: similaritatea $\cos(e_a, e_b) = e_a^\top e_b$
- Embeddings intră într-un clasificator sau într-o regresie obișnuită, ca orice altă variabilă

Cum arată embeddings




- Titlurile din setul de validare Twitter: primele două componente principale ale vectorilor MiniLM cu 384 de dimensiuni, colorate după etichetă

Interpretare: sentimentul nu este direcția principală

- Primele două componente separă teme (companii, știri macro, cripto), nu sentimentul
 - ▶ PCA (Capitolul 3) păstrează direcțiile de varianță maximă, care nu sunt neapărat cele care ne interesează
- Un model supervizat găsește direcția sentimentului printre cele 384 de dimensiuni
 - ▶ Regresia logistică pe toate dimensiunile: 78,6% acuratețe pe Twitter

De câte etichete aveți nevoie?



- Regresie logistică antrenată pe submulțimi aleatoare ale setului de antrenare Twitter, 10 repetări pentru fiecare dimensiune; banda: ± 2 abateri standard

Interpretare: câteva sute de etichete bat FinBERT

- ▣ Embeddings + regresie logistică: 69,0% cu 100 de etichete, peste FinBERT de la 400 de etichete
 - ▶ Vectorii pre-antrenați conțin deja cea mai mare parte din ce este necesar
- ▣ TF-IDF pornește mai jos (66,9%), dar continuă să crească: 83,1% cu toate cele 9.543 de etichete, față de 78,6% pentru embeddings
 - ▶ Cu multe etichete, cuvintele exacte („upgrade”, „cuts”, „misses”) poartă semnalul în titluri
- ▣ Regulă practică: etichetați câteva sute de documente din domeniul vostru înainte de a avea încredere într-un model preluat de-a gata

Regresii pe text cu teorie statistică

- **Taddy (2013)**: regresia inversă multinomială: modelăm frecvențele cuvintelor condiționat de rezultat, $c_d \sim \text{MN}(q(y_d), m_d)$, c_d : frecvențele, $m_d = \sum_j c_{dj}$: lungimea
 - Model log-liniar $q_j(y) \propto e^{\alpha_j + \varphi_j^\top y}$, încărcările $\Phi = (\varphi_1, \dots, \varphi_p)^\top$: dat fiind m_d și acest model, $z_d = \Phi^\top c_d / m_d$ este suficient pentru y_d
- **Ke, Kelly & Xiu (2019)** (SESTM): selectăm cuvintele corelate cu randamentele, estimăm un model cu două teme (cuvinte pozitive și negative), atribuim scoruri articolelor noi prin verosimilitate penalizată
 - Lucrarea dă garanții statistice pentru estimator; semnalul este cel mai puternic în ziua știrii și în ziua următoare
- **Bybee et al. (2024)**: atenția acordată temelor în 800.000 de articole Wall Street Journal urmărește activitatea economică și prognozează randamentele agregate ale pieței
 - De asemenea **Jegadeesh & Wu (2013)** (ponderi ale cuvintelor din reacțiile la 10-K); regula pentru toate: estimare pe date anterioare perioadei de prognoză

Recapitularea secțiunii

- ▣ Embeddings transformă textele în vectori care intră în regresii obișnuite
- ▣ Sentimentul este o direcție printre multe; învățarea supervizată o găsește
- ▣ Câteva sute de etichete din domeniu bat un model general ajustat fin; multe etichete favorizează variabilele simple bazate pe cuvinte


Modelul poate ști deja răspunsul

- ▣ Un LLM antrenat pe texte de până în 2024 poate să fi citit ce s-a întâmplat după un titlu din 2015
 - ▶ Un backtest pe știrile din 2015 amestecă atunci prognoza cu amintirea
- ▣ Glasserman & Lin (2023): două distorsiuni în backtest-urile de sentiment
 - ▶ Privirea în viitor: modelul cunoaște randamentele care au urmat știrii
 - ▶ Distragerea: cunoștințele generale despre compania numită interferează cu citirea textului; în testele lor a contat mai mult decât privirea în viitor
- ▣ Sarkar & Vafa (2024): teste directe arată privirea în viitor în aplicații ale LLM-urilor la conferințe despre rezultate și la alegeri

Testul nostru: întrebăm despre trecut, fără context

- Lunar: „Did the S&P 500 index rise or fall during <lună an>?”, pentru 296 de luni dinainte de publicare plus 23 după
 - ▶ Zilnic: „Did Apple stock close higher or lower on <dată> than on the previous trading day?”, 500 de zile aleatoare din 2010–2023 și 493 de zile după octombrie 2024
- Scorul: $P(\text{creștere})$ din probabilitățile cuvintelor-răspuns; direcția adevărată din seria de prețuri salvată
 - ▶ AUC: probabilitatea ca o perioadă aleatoare de creștere să primească un scor mai mare decât una aleatoare de scădere; 0,5 = nicio capacitate de discriminare (Capitolul 13)
- Rezultatele de după publicare nu pot fi memorate în ponderi fixe: fără altă informație, AUC al populației este acolo 0,5, iar AUC din eșantion variază în jurul acestei valori

Ce „își amintește” Qwen2.5-14B despre S&P 500




□ Probabilitatea răspunsului „rise” pentru fiecare lună, fără context; culoarea: ce a făcut de fapt indicele

Interpretare: își amintește regimuri și câteva luni celebre

- ▣ „Fall” pentru 2000–2002 și 2008–2009, „rise” pentru cea mai mare parte din 2003–2007 și 2013–2021: piețele în scădere și în creștere
 - ▶ Octombrie 2008 (-16,9%), martie 2020 (-12,5%), decembrie 2018 (-9,2%): $P(\text{creștere}) \approx 0$
 - ▶ Dar septembrie 2002 (-11,0%) și februarie 2009 (-11,0%) primesc $P(\text{creștere})$ aproape de 1
- ▣ După publicare, răspunsurile tind spre „rise”: nicio cunoaștere, doar convingerea generală că piețele cresc
- ▣ Cunoașterea este grosieră: episoade memorabile, nu fiecare lună

Memoria măsurată: AUC înainte și după publicare



- Intervale bootstrap de 95%, cu lunile reeșantionate independent; 0,5 înseamnă că modelul nu poate distinge creșterile de scăderi

Interpretare: lunile da, zilele nu

- ▣ Lunile dinainte de publicare: AUC 0,67 (7B, CI [0,61; 0,73]) și 0,69 (14B, CI [0,62; 0,75])
 - ▶ Valoarea p prin permutări pentru 14B: $<0,001$; modelul 1.5B știe mult mai puțin (0,57)
 - ▶ După publicare (23 luni): intervalele includ 0,5, dar sunt prea largi pentru a dovedi ceva
- ▣ Zile individuale pentru Apple: AUC între 0,48 și 0,52 înainte de publicare: nicio discriminare detectată în acest test, ceea ce nu dovedește că nu este stocat nimic
 - ▶ Privirea în viitor este un pericol pentru backtest-uri la orizontul evenimentelor bine cunoscute, mai puțin pentru zgomotul zilnic

A dispărut memoria? Un test formal și puterea lui

- $H_0 : AUC_{\text{înainte}} = AUC_{\text{după}}$, două eșantioane independente; varianța DeLong pentru fiecare AUC (DeLong et al. (1988))
 - ▶ $z = (\widehat{AUC}_1 - \widehat{AUC}_2) / \sqrt{\widehat{V}_1 + \widehat{V}_2}$: 14B $z = 0,73$ ($p = 0,47$), 7B $z = 1,01$ ($p = 0,31$)
- Puterea: cu 23 luni după publicare, $SE(AUC)$ sub H_0 este 0,12; cea mai mică scădere detectabilă cu puterea 80% este 0,36
 - ▶ O cădere de la 0,69 la 0,5 este mai mică: ar fi nevoie de circa 101 luni după publicare
- Nerespingerea lui H_0 aici nu spune nimic: lipsa dovezilor de memorie după publicare nu este o dovadă a absenței ei înainte

Remedii, inclusiv modele la un moment dat


- ▣ Testați doar după data-limită a datelor de antrenare: [Lopez-Lira & Tang \(2026\)](#) evaluează GPT-4 pe titluri de după data-limită; curat, dar fereastra începe târziu
- ▣ Mascăți numele companiilor și datele înainte de evaluare ([Glasserman & Lin \(2023\)](#)), apoi comparați pantele cu și fără mascare: un diagnostic, pentru că produsele, evenimentele sau citatele pot identifica în continuare episodul
- ▣ Modele cu informație limitată la o dată de referință, antrenate doar pe textul disponibil până la data t ([Sarkar & Vafa \(2024\)](#))
 - ▶ [Drinkall et al. \(2024\)](#): o serie de LLM-uri cu date de referință succesive, fiecare fără informații despre faptele de după data lui; modelele și datele de antrenare sunt publice
 - ▶ [He et al. \(2025\)](#): ChronoBERT și ChronoGPT folosesc doar textul disponibil la fiecare dată; pe randamentele zilei următoare din știri, rapoartele lor Sharpe sunt apropiate de ale unui model mult mai mare: privirea în viitor este acolo modestă
- ▣ Raportați versiunea modelului și data publicării ponderilor sale împreună cu fiecare rezultat

Recapitularea secțiunii

- LLM-urile antrenate pe texte recente au cunoștințe despre trecut pe care un backtest nu trebuie să le folosească
- Qwen2.5-7B și 14B „știu” parțial direcția lunară a S&P 500 dinainte de 2024, nu zilele individuale
- Testele temporale curate folosesc date de după data-limită sau modele la un moment dat; textul anonimizat este o verificare suplimentară de sensibilitate

Date: titluri datate și prețuri


- ▣ FNSPID (Dong, Fan & Peng (2024)): 15,7 milioane de știri despre firmele din S&P 500, 1999–2023, de pe patru site-uri de știri
 - ▶ Licența CC BY-NC 4.0 (utilizare necomercială)
- ▣ Aici: 16 acțiuni americane mari cu prețuri zilnice în datele cursului (tehnologie, bănci, GameStop, Strategy)
 - ▶ 106 820 titluri distincte după eliminarea repetițiilor; 18 282 zile-acțiune cu știri, între 27.10.2009 și 18.12.2023



Bandă de știri pe clădirea Reuters, New York

Foto: [bgilliard](#) (2005); CC BY-SA 2.0; [Wikimedia Commons](#)

Câte titluri și când




- Titluri despre cele 16 acțiuni pe an, după ziua de tranzacționare la care sunt atribuite

 MFM_ch15_news_data

Interpretare: acoperirea este inegală

- ▣ 34 380 titluri doar în 2023, față de 8 445 în toți anii dinainte de 2016
 - ▶ Rezultatele sunt dominate de anii recentți; primii ani au puține zile cu știri pe acțiune
- ▣ Într-o zi cu știri, o acțiune are în medie 5,8 titluri
 - ▶ Scorul zilnic: media scorurilor titlurilor pentru acțiunea și ziua respectivă
- ▣ Distorsiunea de supraviețuire: cele 16 acțiuni aparțin unor firme mari în prezent, selectate retrospectiv

Problema marcajului de timp



- Ora marcajului de timp FNSPID în timpul universal coordonat (UTC), scară logaritmică

 MFM_ch15_news_data

Interpretare: date, nu ore

- ▣ 99,8% dintre titluri au marcajul exact 00:00 UTC: sursa dă data, nu ora publicării
 - ▶ Un titlu datat d poate apărea înainte de deschidere, în timpul ședinței sau după închiderea zilei d
- ▣ Alinierea folosită aici, fără privire în viitor
 - ▶ Ziua d : prima zi de tranzacționare egală cu data titlului sau ulterioară
 - ▶ Randamentele din d și $d + 1$ pot conține încă reacția; prima prognoză sigură este randamentul din $d + 2$ (de la închiderea din $d + 1$ la închiderea din $d + 2$)
- ▣ Randamentul în exces: randamentul acțiunii minus randamentul SPY (un fond pe indicele S&P 500) în aceeași zi


Trei scoruri pentru fiecare titlu

- ▣ Tonul LM; scorul net FinBERT $P(\text{poz}) - P(\text{neg})$; scorul net Qwen2.5-7B cu prompt-ul P1
 - ▶ LM găsește un cuvânt din listă doar în 27% dintre titluri: restul primesc tonul 0
 - ▶ Etichetele FinBERT: 19% negative, 62% neutre, 18% pozitive
- ▣ Corelațiile pe titluri: FinBERT–Qwen 0,62, FinBERT–LM 0,41, Qwen–LM 0,36
 - ▶ Scorurile celor două modele de limbaj sunt mult mai corelate între ele decât cu scorul dicționarului
- ▣ Scorurile sunt standardizate pe panel (medie 0, abatere standard 1) înainte de regresii

Designul regresiei

- Regresie pe toate zilele-acțiune cu știri: $r_{i,d+h}^e = a + b z_{i,d} + \varepsilon_{i,d+h}$, $h = 0, 1, 2$
 - ▶ r^e : randamentul în exces (%); z : scorul zilnic standardizat; b : randamentul pentru o abatere standard a scorului
- Erorile acțiunilor din aceeași zi sunt corelate (șocuri comune): calculăm erori standard robuste la gruparea observațiilor pe zile ([Petersen \(2009\)](#))
 - ▶ $\hat{V} = (X^\top X)^{-1} \left(\sum_g X_g^\top \hat{\varepsilon}_g \hat{\varepsilon}_g^\top X_g \right) (X^\top X)^{-1}$, g : zile de tranzacționare
- $h = 0$ măsoară reacția, $h = 2$ măsoară predictibilitatea

Reacție versus predicție



□ Panta b în puncte de bază (bp) pentru o abatere standard a scorului, cu CI 95% grupat pe zile

 MFM_ch15_news_signal

Interpretare: titlurile descriu prețurile


- ▣ Ziua d : FinBERT +39,2 bp ($t = +17,27$), Qwen +41,4 bp ($t = +19,07$), LM +15,5 bp ($t = +8,53$)
 - ▶ Multe titluri relatează chiar mișcarea prețului („shares jump”, „stock falls”): cauzalitatea merge în ambele sensuri
- ▣ Ziua $d + 1$: FinBERT +3,2 bp ($t = +1,60$), Qwen +3,7 bp ($t = +1,86$)
 - ▶ O parte din acest efect vine din știri publicate după închiderea zilei d , nu dintr-o prognoză
- ▣ Ziua $d + 2$: FinBERT -0,5 bp ($t = -0,25$), Qwen +2,3 bp ($t = +1,19$), LM -0,0 bp ($t = -0,01$)

Inferență cu 16 acțiuni și nouă regresii

Scor, orizont	b (bp)	t pe acțiuni	t pe două dimensiuni	p wild bootstrap	p Holm
FinBERT, d	+39,2	+5,71	+5,67	<0,001	<0,001
Qwen, d	+41,4	+5,10	+5,07	<0,001	<0,001
FinBERT, $d + 2$	-0,5	-0,35	-0,30	0,739	1,00
Qwen, $d + 2$	+2,3	+2,41	+2,01	0,061	0,37
LM, $d + 2$	-0,0	-0,03	-0,02	0,979	1,00

- Efectele de firmă persistă în timp, deci erorile sunt corelate și în cadrul unei acțiuni: grupăm pe acțiuni sau pe zile și acțiuni (Cameron, Gelbach & Miller (2011)); Driscoll & Kraay (1998) adaugă corelația serială
 - Cu 16 grupuri SE grupată tinde să fie prea mică: wild cluster bootstrap cu ipoteza nulă impusă, ponderi Rademacher, 9.999 de extrageri (Cameron, Gelbach & Miller (2008)); presupune acțiuni independente, deci citiți-l împreună cu t pe două dimensiuni
- Qwen în $d + 2$: $t = +2,41$ pe acțiuni pare semnificativ; p bootstrap = 0,061 și 0,37 după Holm pe cele 9 regresii (3 scoruri $\times$ 3 orizonturi)

Studiu de eveniment în jurul zilelor cu știri



- Randamentul în exces cumulat mediu din ziua -5 până în ziua $+5$; zilele cu știri împărțite pe tercelele scorului zilnic FinBERT; zona hașurată: zilele tranzacționabile $d + 2 - d + 5$

 MFM_ch15_news_signal


Interpretare: mișcarea are loc înainte de știre și în ziua ei

- Treimea cea mai pozitivă: +0,63% în cele 5 zile dinainte, +0,50% în ziua d ; treimea cea mai negativă: +0,06% și -0,38%
 - ▶ Mișcările dinaintea evenimentului: există scurgeri de informații sau titlurile sunt scrise după ce prețul s-a mișcat deja
- Efectul sentimentului este **diferența** pozitiv minus negativ, calculată pe toate zilele-acțiune, cu CI grupat pe date; cifrele pe grupuri de mai sus mediază întâi pe fiecare dată, deci diferența lor poate fi alta
 - ▶ Ziua d : +1,00% [+0,88; +1,13]; zilele tranzacționabile $d + 2 - d + 5$: +0,17% [-0,08; +0,42]
- Test standardizat robust la varianța indusă de eveniment (Boehmer, Musumeci & Poulsen (1991)) pe $d + 2 - d + 5$: $z = +2,62$ (pozitiv), +1,25 (negativ)
 - ▶ Ambele treimi cresc; selecția firmelor mari de azi poate contribui, dar aceste medii nu identifică sursa; testul presupune evenimente independente, deci supraestimează z

O strategie zilnică de sentiment

- La închiderea din $d + 1$: pentru fiecare acțiune cu știri în ziua d , cumpărăm dacă scorul este pozitiv și vindem în lipsă dacă este negativ
 - ▶ Fiecare poziție este acoperită cu SPY; ponderi egale; închidem după o zi și câștigăm randamentul în exces din $d + 2$
 - ▶ Zilele fără știri: nicio poziție, randament 0
- Costuri: 5 bp pe tranzacție; patru tranzacții pe zi cu poziții (acțiunea și SPY, la intrare și la ieșire)
 - ▶ Costul de echilibru: randamentul brut mediu în zilele cu poziții împărțit la 4
- Inferența: t Newey–West (Capitolul 2) și CI bootstrap pe blocuri pentru randamentul zilnic mediu

Randamentele cumulate ale strategiei




□ Suma randamentelor zilnice în exces (%), înainte de costuri și cu 5 bp pe tranzacție

 MFM_ch15_news_signal

Interpretare: un semnal mic, niciun profit net

- ▣ FinBERT: media +3,27 bp pe zi ($t = +1,27$), CI 95% [-1,51; +8,93]: nu diferă de zero
 - ▶ LM: -0,21 bp ($t = -0,07$)
- ▣ Qwen2.5-7B: +5,64 bp ($t = +2,26$, $p = 0,024$), CI 95% [+0,95; +10,61]; cel mai bun din trei scoruri: p Holm = 0,071, ne semnificativ
 - ▶ Costul de echilibru +1,5 bp pe tranzacție, mult sub 5 bp: Sharpe +0,63 înainte și -1,48 după costuri
 - ▶ Qwen2.5 a fost antrenat după 2023: o parte din avantaj poate fi memorarea prețurilor (vezi Privirea în viitor și memorarea)
- ▣ Ziua netranzacționabilă $d + 1$: FinBERT -0,22 bp ($t = -0,10$), Qwen +4,06 bp ($t = +1,36$)
 - ▶ Niciun câștig semnificativ nici aici: aproape toată reacția are loc în ziua d

Stabilitatea în timp



□ Randamentul zilnic mediu al strategiei înainte de costuri, pe subperioade

 MFM_ch15_news_signal

Interpretare: dovezi slabe, spuse cinstit

- ▣ FinBERT pe subperioade: 2010–2015 +1,4 bp, 2016–2019 -1,8 bp, 2020–2021 +24,3 bp, 2022–2023 -1,8 bp
 - ▶ Doar 2020–2021 este mare (FinBERT $t = +1,89$, Qwen +22,2 bp, $t = +1,78$): nesemnificativ la 5%, doi ani de tranzacționare a acțiunilor-meme
 - ▶ Patru tranzacții de 5 bp costă 20 bp pe zi: chiar și acea perioadă abia ar acoperi costurile
- ▣ De ce atât de puțin: 16 acțiuni foarte urmărite, marcaje de timp doar la nivel de dată, frecvență zilnică
 - ▶ Dovezile publicate de predictibilitate se bazează pe marcaje de timp precise și pe multe acțiuni mici
- ▣ Un rezultat negativ este tot un rezultat: vă arată unde nu este semnalul

Ce arată literatura

- ▣ **Lopez-Lira & Tang (2026)**: pe titluri publicate după data-limită a cunoștințelor GPT-4, modelul surprinde reacția inițială, netranzacționabilă, a pieței (rezumatul din [arXiv:2304.07619](https://arxiv.org/abs/2304.07619): rate de succes de circa 90% pe zile-portofoliu)
 - ▶ Reacția inițială nu este tranzacționabilă; scorurile GPT-4 anunță și deriva ulterioară, mai ales pentru acțiunile mici și știrile negative
 - ▶ Randamentele strategiilor scad pe măsură ce folosirea LLM-urilor crește: prețurile devin mai eficiente
- ▣ **Bollen, Mao & Zeng (2011)**: starea de spirit colectivă de pe Twitter a anticipat Dow Jones în 2008; rezultatul este sensibil la eșantion și metodă

Rețele sociale și mulțimi: GameStop, 2021

- ▣ Ianuarie 2021: investitori individuali s-au coordonat pe rețelele sociale și au ridicat GameStop de peste zece ori în câteva săptămâni
 - ▶ Atenția, sentimentul și tranzacțiile au crescut împreună; acest episod singur nu poate separa predicția de cauzalitate: fiecare cere propriul test
- ▣ Lecții pentru semnalele textuale
 - ▶ Volumul atenției poate conta mai mult decât tonul
 - ▶ Semnalele aglomerate se inversează și creează risc pentru vânzătorii în lipsă (Capitolul 17: bule)



Un magazin GameStop, Vallejo, California, februarie 2021

Foto: Will Buckner (2021); CC BY 2.0; Wikimedia Commons

Recapitularea secțiunii

- ▣ Aliniați știrile și prețurile cu grijă: marcajele doar la nivel de dată mută primul randament tranzacționabil în $d + 2$
- ▣ Sentimentul titlurilor este puternic legat de randamentele din aceeași zi și foarte slab de randamentele care mai pot fi tranzacționate
- ▣ Testați semnalele cu erori grupate (wild bootstrap când sunt puține grupuri), t Newey–West, o corecție pentru testarea multiplă, costuri și subperioade

Sentimentul ca regresor generat

- Modelul: $r = a + \beta s^* + \varepsilon$, cu tonul adevărat s^* ; observăm ieșirea unui model $\hat{s} = s^* + u$
 - ▶ Eroare clasică (u independentă de s^* și ε): $\text{plim } \hat{\beta} = \beta \lambda$, $\lambda = \text{Var}(s^*) / [\text{Var}(s^*) + \text{Var}(u)] < 1$
 - ▶ Testul pentru $\beta = 0$ rămâne valid; mărimile sunt atenuate spre 0
- Scor standardizat z , eroare nediferențială ($E[r | s^*, \hat{s}] = E[r | s^*]$): $\text{Cov}(r, z) = \beta \text{Cov}(s^*, z)$
 - ▶ Panta pe $z = (\text{efectul unei abateri standard a lui } s^*) \times \rho(s^*, \hat{s})$: împărțim la corelația dintre adevăr și scor
- Econometria variabilelor generate de AI: Battaglia et al. (2024) (corecția distorsiunii, estimare comună); Ludwig, Mullainathan & Rambachan (2024) (utilizări ale LLM-urilor pentru predicție versus estimare)

Etichete discrete: clasificarea greșită nu este eroare clasică

- Variabila binară „știre negativă” $s^* \in \{0, 1\}$, eticheta prezisă $\hat{s}$; $\alpha_0 = P(\hat{s} = 1 \mid s^* = 0)$, $\alpha_1 = P(\hat{s} = 0 \mid s^* = 1)$
 - ▶ Eroarea $u = \hat{s} - s^*$ este corelată negativ cu s^* : formula clasică nu se aplică (Aigner (1973))
 - ▶ $\text{plim } \hat{b} = \beta \frac{\pi(1 - \pi)(1 - \alpha_0 - \alpha_1)}{p(1 - p)}$, $\pi = P(s^* = 1)$, $p = P(\hat{s} = 1)$
- Setul de validare Twitter, $\pi = 14,5\%$, din matricile de confuzie
 - ▶ FinBERT: $\alpha_0 = 13,3\%$, $\alpha_1 = 23,9\%$, factorul 0,45; Qwen2.5-7B: 0,59; LM ($\alpha_1 = 50,4\%$): 0,28
- Cât timp $\alpha_0 + \alpha_1 < 1$ semnul se păstrează, dar panta unei variabile binare se poate reduce la o treime sau mai puțin

Câtă atenuare au pantele noastre?

Scor	$\rho(s^*, \hat{s})$, Twitter	b în ziua d (bp)	b/ρ (bp)	λ , un factor
LM	0,29	15	54	0,53
FinBERT	0,58	39	67	0,85
Qwen2.5-7B	0,71	41	58	0,78

- ρ : corelația scorului net cu eticheta umană $(-1, 0, 1)$; b/ρ : efectul în aceeași zi al unei abateri standard a tonului adevărat
 - ▶ După corecție cele trei metode sunt mult mai apropiate: panta mică a LM este în mare parte eroare de măsurare
 - ▶ Corecția presupune că eroarea este nediferențială și că se păstrează corelația de pe Twitter pentru titlurile FNSPID
- λ : încărcarea pe factorul comun al celor trei scoruri zilnice (slide-ul următor), un reper diferit de eticheta umană


Două măsuri zgomotoase: modelul factorial și variabilele instrumentale

- Un factor: $z_j = \lambda_j f + u_j$, $\text{Var}(f) = 1$, u_j necorelate cu f și între ele: $\rho_{jk} = \lambda_j \lambda_k$, deci $\lambda_j^2 = \rho_{jk} \rho_{jl} / \rho_{kl}$
 - Scorurile zilnice FNSPID: $\lambda = 0,53$ (LM), 0,85 (FinBERT), 0,78 (Qwen)
- IV (instrumental variables, variabile instrumentale): cu $r = a + \beta f + \varepsilon$, instrumentăm z_Q cu z_F :
 $\hat{b}_{IV} = \widehat{\text{Cov}}(r, z_F) / \widehat{\text{Cov}}(z_Q, z_F) \rightarrow \beta / \lambda_Q$ dacă $\lambda_F \neq 0$ și u_F este necorelată cu u_Q și cu ε
 - Ziua d , Qwen: 59 bp [53; 66] cu FinBERT ca instrument, 37 bp [28; 46] cu LM (bootstrap pe zile)
- Dacă ambele instrumente ar fi valide, estimările ar coincide: diferența 22 bp, $z = 5,4$: respins
 - Testul respinge restricțiile comune, nu un instrument anume: erorile FinBERT–Qwen corelate prin texte de antrenare care se suprapun sunt o cauză plauzibilă, o eroare LM legată de randamente este alta; atunci și valorile λ ale factorului sunt îndoielnice

Inferență validă cu etichete de model: prediction-powered inference

- n texte etichetate de oameni (Y) și N texte neetichetate, eșantioane aleatoare independente din aceeași populație; modelul f este fix (antrenat pe alte date)
 - ▶ PPI (prediction-powered inference, [Angelopoulos et al. \(2023\)](#)): $\hat{\theta}_{\text{PPI}} = \frac{1}{N} \sum_{i \text{ neetich.}} f(\tilde{X}_i) - \frac{1}{n} \sum_{j \text{ etich.}} (f(X_j) - Y_j)$: predicția minus distorsiunea ei estimată
 - ▶ $\widehat{\text{Var}} = \widehat{\text{Var}}(f)/N + \widehat{\text{Var}}(f - Y)/n$: un CI valid oricare ar fi calitatea lui f
- Mai îngust decât doar cu etichete când $\text{Var}(f)/N + \text{Var}(f - Y)/n < \text{Var}(Y)/n$, aproximativ $\text{Var}(f - Y) < \text{Var}(Y)$ când $N \gg n$
 - ▶ Pentru o regresie, corecția se aplică fiecărei condiții de moment care conține variabila prezisă, și atunci când aceasta este regresor ([Egami et al. \(2023\)](#))
- [Egami et al. \(2023\)](#): învățare supervizată bazată pe design, o versiune dublu robustă care permite probabilități de etichetare dependente de text
- Cele câteva sute de documente etichetate nu sunt doar date de antrenare: ele sunt eșantionul de validare care face validă inferența ulterioară

PPI pe titlurile Twitter



- Ținta: tonul net uman mediu ($-1, 0, 1$); cele 2388 de titluri de validare au rolul populației; 2.000 de replicări, n titluri etichetate și $2388 - n$ neetichetate extrase independent, cu întoarcere

 MFM_ch15_valid_inference

Interpretare: corecția distorsiunii este câștigul principal

- Tonul mediu adevărat $\theta = 0,054$; mediile simple ale modelelor sunt distorsionate: FinBERT $-0,014$ (semn greșit), Qwen2.5-7B $+0,101$
 - ▶ Nicio mărime a eșantionului nu repară asta: media modelului converge la un număr greșit
- PPI păstrează acoperirea nominală (94,3% la $n = 100$); lățimea CI 0,204 față de 0,229 doar cu etichete
 - ▶ Reducerea varianței $1 - \text{Var}(f - Y)/\text{Var}(Y)$: 24% (FinBERT), 27% (Qwen): modestă, pentru că modelele sunt zgomotoase
 - ▶ Acoperirea rămâne aproape de 95% pentru orice n ; la $n = 800$, PPI este mai larg decât doar cu etichete (0,087 față de 0,081): cu doar 2388 – 800 de texte neetichetate, $\text{Var}(f)/N$ nu mai este neglijabil
- Pentru regresiiile randamentelor: etichetați toate titlurile unui eșantion aleator de zile-acțiune, astfel încât tonul zilnic adevărat să fie cunoscut acolo, și corectați ambele condiții de moment OLS (Egami et al. (2023))

Recapitularea secțiunii

- Un scor de sentiment este o estimare: regresiile pe el sunt atenuate; împărțirea unei pante standardizate la $\rho(s^*, \hat{s})$ elimină atenuarea
- Două scoruri de model nu sunt neapărat măsurători independente: cele două instrumente nu sunt de acord, deci cel puțin o ipoteză de validitate nu este îndeplinită; erorile comune ale LLM-urilor sunt o explicație posibilă
- Un mic eșantion aleator etichetat de oameni plus PPI dă intervale valide, oricare ar fi modelul

Întrebarea de cercetare: citește un LLM știrile la fel ca piața?

- **Lopez-Lira & Tang (2026)** (*Journal of Financial Economics*): poate un LLM de uz general, fără antrenare financiară, să spună dacă un titlu este o veste bună sau rea pentru acțiune și prognozează răspunsul lui randamentele?
 - ▶ Reacția inițială: mișcarea prețului imediat după știre; nu este tranzacționabilă, dar arată dacă LLM-ul înțelege știrea
 - ▶ Deriva ulterioară: randamentul de după reacție, în sensul știrii; este tranzacționabilă și măsoară reacția insuficientă a pieței
- Legătura cu acest capitol: aceeași evaluare zero-shot a titlurilor, dar pe știri publicate după data-limită a datelor de antrenare și cu ora exactă a publicării
 - ▶ Acestea sunt exact cele două slăbiciuni ale testului nostru pe FNSPID: date fără oră și informația din viitor a lui Qwen2.5
- De ce contează: LLM-ul devine un instrument de măsură pentru viteza cu care prețurile absorb știrile
 - ▶ Modelul lor (secțiunea 3): doar LLM-urile peste un prag de calitate prognozează randamentele, iar adoptarea largă ar trebui să erodeze predictibilitatea

Date și metodă


- 159.137 de observații firmă-titlu-dată, 4.123 de acțiuni ordinare americane (NYSE, NASDAQ, AMEX), octombrie 2021 – mai 2024 (secțiunea 4)
 - ▶ Eșantionul începe după data-limită a datelor de antrenare ale modelului folosit, gpt-4-0314, septembrie 2021 (secțiunea 5)
 - ▶ Filtre: scorul de relevanță al furnizorului de știri egal cu 100, fără titlurile de tip „stock-gain”/„stock-loss”, doar evenimente noi, eliminarea titlurilor aproape identice din aceeași zi
 - ▶ Știri de peste noapte (înainte de ora 9 sau după ora 16): 82% dintre titluri; restul sunt din timpul ședinței
- Prompt-ul (secțiunea 5): modelul joacă rolul unui expert financiar și răspunde YES (veste bună), NO (veste rea) sau UNKNOWN despre efectul pe termen scurt asupra prețului acțiunii; temperatura 0
 - ▶ Scorul $s_{i,t}$: YES = 1, UNKNOWN = 0, NO = -1
- Portofolii (tabelul 1): zilnic, ponderi egale, cumpărăm acțiunile cu scor pozitiv și le vindem în lipsă pe cele cu scor negativ, un picior doar cu cel puțin două firme; pentru știrile de peste noapte, reacția inițială: de la închiderea anterioară la deschidere; deriva: de la deschidere la închidere
 - ▶ Rata de succes: ponderea zilelor cu randament pozitiv al portofoliului; raportul Sharpe $SR = \sqrt{252} \bar{r} / \hat{\sigma}$ (anualizat)
- Regresia, ec. (1): $r_{i,t} = a_i + b_t + \gamma s_{i,t} + \varepsilon_{i,t}$, efecte fixe de firmă și de dată, erori standard grupate pe date și pe firme (tabelul 2)
 - ▶ Douăsprezece modele de limbaj de mărimi crescătoare, evaluate cu același design, de la GPT-1 la GPT-4 (tabelul 5)

Rezultatele principale

Model	Rata de succes, reacție	Rata de succes, derivă	Deriva, % pe zi	SR
GPT-4	0,93	0,58	0,34	2,97
GPT-3.5	0,93	0,56	0,29	1,66
FinBERT	0,90	0,48	-0,07	-0,33
GPT-1	0,53	0,48	-0,07	-0,64

- Știrile de peste noapte, portofolii long-short (tabelul 5): GPT-4 ghicește direcția reacției în 93% din zile, ca GPT-3.5, dar obține cea mai mare derivă
 - Piciorul scurt 0,26% pe zi (SR 2,01), piciorul lung 0,08% (SR 0,78) (tabelul 1): piața reacționează insuficient mai ales la veștile rele
- Ec. (1), știrile de peste noapte (tabelul 2): $\hat{\gamma} = 1,326$ ($t = 31,10$) pentru reacție, 0,161 ($t = 6,80$) pentru derivă; cu scorul de sentiment al furnizorului, GPT-4 rămâne la 0,158 ($t = 5,35$), iar furnizorul are 0,010 ($t = 0,15$)
 - Acțiunile mici: coeficientul interacțiunii 0,404 ($t = 4,75$): deriva se concentrează unde arbitrajul este costisitor
- Declinul (figura 8): SR al derivei 6,54 în T4 2021, 3,68 în 2022, 2,33 în 2023, 1,22 în ianuarie–mai 2024, pe măsură ce LLM-urile s-au răspândit

Ce modele citesc corect știrile și care câștigă din derivă




- Portofolii long-short pe știrile de peste noapte, douăsprezece modele cu același prompt și design, octombrie 2021 – mai 2024; sursa: [Lopez-Lira & Tang \(2026\)](#), tabelul 5

Interpretare: înțelegerea știrii este necesară, dar nu suficientă

- Pragul: GPT-1, GPT-2, BERT și Llama2-7b ghicesc direcția reacției doar în 53–66% din zile, iar rapoartele Sharpe ale derivei lor sunt negative (între $-0,64$ și $-0,11$)
 - ▶ Șapte modele ajung la 86–93% pentru reacție, dar doar GPT-4 o combină cu un raport Sharpe al derivei aproape de 3 (2,97, urmat de GPT-3.5 cu 1,66)
- FinBERT: 90% pentru reacție, dar un raport Sharpe al derivei de $-0,33$; dă o direcție doar pentru 25% dintre titlurile de peste noapte (nota 24)
 - ▶ Citirea părții evidente a știrii, deja inclusă în prețul de deschidere, nu aduce câștig din derivă
- Citiți picioarele, nu doar raportul: BERT-Large (Sharpe 1,05) are în medie 2 acțiuni în piciorul scurt, GPT-3.5 are 6, GPT-4 are 20 (tabelul 5)
 - ▶ Un raport Sharpe mare obținut din câteva poziții scurte este fragil; comparați cu macro-F1 în funcție de mărimea modelului Qwen2.5 din acest capitol

Deriva scade pe măsură ce LLM-urile se răspândesc



- Strategia long-short a derivei cu GPT-4 pe știrile de peste noapte, raportul Sharpe anualizat pe subperioade; sursa: Lopez-Lira & Tang (2026), figura 8 și secțiunea 8.2; valoarea pe tot eșantionul din tabelul 1

Interpretare: adoptarea LLM-urilor sau altceva?

- Raportul Sharpe scade de la 6,54 în T4 2021 la 1,22 în ianuarie–mai 2024, de peste cinci ori; T4 2021 și 2022 sunt peste valoarea de 2,97 de pe tot eșantionul
 - ▶ Cifra pe tot eșantionul face media dintre un început puternic și un final slab: supraestimează ce ar putea aștepta azi un investitor
- Modelul lor (secțiunea 3): cu cât mai mulți investitori procesează știrile cu LLM-uri performante, cu atât reacția insuficientă și deriva scad; momentul coincide cu răspândirea ChatGPT
 - ▶ Autorii menționează și schimbarea condițiilor de piață (secțiunea 8.2); subperioadele sunt scurte (un trimestru în 2021, cinci luni în 2024), deci intervalele de 95% din figura 8 sunt largi, iar cel pentru 2024 îl conține pe 0
- Știrile din timpul ședinței, deriva de la închidere la închidere: semnificativă în 2022 și 2023, dar nu și în ianuarie–mai 2024 (nota 30)
 - ▶ Un test care să separe adoptarea de condițiile de piață rămâne deschis: extensia de pe slide-ul următor

Replicare, limite și o extensie deschisă

- Cel mai apropiat analog din curs: strategia Qwen2.5-7B din acest capitol pe 16 acțiuni FNSPID câștigă +5,64 bp pe zi ($t = +2,26$), față de 34 bp pentru GPT-4 (tabelul 1)
 - ▶ Replicarea (Seminarul 15, C3): prompt-ul publicat, temperatura 0, scorurile $\{-1, 0, 1\}$, regula celor două firme și ec. (1) pe titlurile FNSPID și închiderile ajustate din data/market
 - ▶ Limitele datelor: date fără oră, deci primul randament sigur este cel din $d + 2$, nu deschiderea următoare; 16 acțiuni mari; titluri mai vechi decât modelul
- Limite enunțate de autori: la 20 bp pe tranzacție dus-întors strategia pierde bani (figura 4), deci se potrivește celor cu costuri mici, precum formatorii de piață (secțiunea 1)
 - ▶ Declinul în timp poate reflecta și schimbarea condițiilor de piață (secțiunea 8.2); prompt-urile și modelele de vectori nu au fost optimizate, deci comparațiile sunt limite inferioare (secțiunea 7.4)
- Extensie deschisă: pe titluri publicate după lansarea unui model cu ponderi deschise, supraviețuiește deriva și continuă să scadă raportul ei Sharpe, cum prezice propoziția 2?

O întrebare deschisă: putem avea încredere în ipotezele generate de LLM-uri?

- **Ludwig & Mullainathan (2024)**: generarea ipotezelor ca procedură statistică: un model antrenat pe date descoperă un tipar, oamenii îl numesc, date noi îl testează
 - ▶ Aplicația lor: fotografiile inculpaților și deciziile judecătorilor privind arestul preventiv
- **Lopez-Lira, Tang & Zhu (2025)**: înainte de data-limită a cunoștințelor, un LLM își poate aminti rezultatele, deci o ipoteză propusă de el despre acea perioadă nu este independentă de datele care o vor testa
- Deschis: când un asistent propune semnalul, prompt-ul, pragul și perioada de deținere, care este familia de teste și ce inferență rămâne validă? Agenții care rulează singuri experimentele (**Lu et al. (2024)**) fac familia mai mare și mai puțin vizibilă
- Formal: $H_{0,j} : E[r_t^{(j)}] = 0$ pentru strategiile candidate $j = 1, \dots, M$; controlăm FWER (Holm) sau FDR (**Benjamini & Hochberg (1995)**)
 - ▶ M numără fiecare variantă propusă de asistent, inclusiv pe cele abandonate; agenții care tranzacționează sunt în Practică și concluzii, aici agentul este un asistent de cercetare

Bucula descoperirii, pas cu pas (1/2)

- **Literatura:** "Găsește studii din 2023 încoace care prognozează randamentele acțiunilor cu sentimentul din LLM-uri și testează după data-limită a cunoștințelor modelului: DOI sau id arXiv, data-limită, fereastra de test, estimarea principală."
 - ▶ Verificați fiecare identificator; Semantic Scholar, Google Scholar, Elicit pentru căutare; [Lopez-Lira & Tang \(2026\)](#) este designul de referință
- **Ipoteze:** "Propune mecanisme prin care sentimentul titlurilor ar putea prognoza randamentele după d+1 și, pentru fiecare, tiparul transversal care l-ar infirma."
 - ▶ Subreacția prezice o derivă concentrată în acțiunile mici și puțin urmărite; memorarea prezice un avantaj care dispare după data publicării
- **Date și cod:** "Din ch15_news_daily.csv și data/market, reprodu strategia zilnică Qwen din acest capitol (intrare la închiderea din d+1, acoperire cu SPY) și t-ul ei Newey-West."
 - ▶ Orice asistent (Claude, ChatGPT, Gemini, GitHub Copilot); scorurile sunt salvate, deci niciun model nu trebuie rulat din nou

Bucula descoperirii, pas cu pas (2/2)

- **Robustețea**, fixată dinainte: "Înainte de orice rulare nouă, scrie grila completă de variante pe care le-ai testa și corecția pentru testarea multiplă; toate vor fi raportate."
 - ▶ Placebo: scoruri amestecate între acțiuni în aceeași zi; subperioade; costuri de 5 bp pe tranzacție
- **Critica**: "Scrie un raport de recențent: toate felurile în care strategia ar putea reflecta privirea în viitor, memorarea, selecția sau marcajele de timp, cu testul pentru fiecare."
 - ▶ Apoi verificați voi fiecare test propus: și o critică poate conține rezultate inventate
- **Raportul**: toată grila, varianta aleasă înaintea rezultatelor, versiunile modelelor și datele publicării

Ce verifică cercetătorul


- **Memorarea:** modelul știe ce a urmat după titlu
 - ▶ Test: știri de după publicarea ponderilor; text anonimizat, ca diagnostic (Glasserman & Lin (2023)); testul de memorie din acest capitol
- **Drumurile care se bifurcă:** prompt, prag, orizont ajustate pe perioada de test
 - ▶ Test: o grilă preînregistrată și o rată de eroare declarată: Holm (FWER) sau BH (FDR, sub independență sau dependență pozitivă); $|t| > 3$ (Harvey, Liu & Zhu (2016)) este o regulă empirică, nu o garanție pentru rata de eroare
- **HARKing:** un mecanism plauzibil scris după rezultat, cu referințe care pot să nu existe
 - ▶ Test: formulați mecanismul și ce l-ar infirma înaintea testului; verificați fiecare DOI
- **Momentul:** marcate de timp doar la nivel de dată
 - ▶ Test: primul randament tranzacționabil în $d + 2$; studiul de eveniment arată ce rămâne în zilele tranzacționabile
- **Agenți care rulează cod:** modificări neanunțate ale datelor, ferestrelor sau valorilor de inițializare ale generatorului aleator
 - ▶ Test: date doar pentru citire, apeluri de instrumente jurnalizate, diferențele fiecărui script înainte de a accepta un rezultat

Mini-studiu de caz: grădina drumurilor care se bifurcă

- O propunere tipică a unui asistent: „semnalul Qwen funcționează; rafinează-l cu un prag mai strict sau cu o zi de intrare mai târzie”. Testăm toată grila pe scorurile salvate
- Grila: 3 scoruri (LM, FinBERT, Qwen) $\times$ 3 praguri $|s_{i,d}| > b$, $b \in \{0, 0,25, 0,5\}$, pe scorul brut $\times$ 4 zile de câștig $(d + 2 - d + 5$, fiecare o poziție de o zi deschisă la închiderea precedentă) = 36 strategii
 - ▶ Cazul de bază se replică: 5,6 bp pe zi, $t = 2,26$
- $|t| > 1,96$ pentru 5 din 36 strategii, față de 1,8 așteptate sub ipoteza nulă globală la 5%; 2 dintre ele au semnul greșit
- Supraviețuitori: Holm (FWER 5%) 0, BH (FDR 10%) 0, $|t| > 3$ 0; pragul Bonferroni este $|t| > 3,20$
- Interpretare: rafinările nu adaugă dovezi; cea mai bună variantă este cea de la care am pornit, aleasă ea însăși dintre trei scoruri, pe o perioadă pe care modelul și-o poate aminti

 ai_discovery_case.py

Curba specificațiilor pentru grilă



☐ Toate cele 36 de strategii din mini-studiu, ordonate după t (Simonsohn, Simmons & Nelson (2020)); linii punctate: $\pm 1,96$

 MFM_ch15_valid_inference

Interpretare: diferă întreaga curbă de zgomot?

- Ipoteza nulă comună: nicio specificație nu prognozează randamentele; o simulăm schimbând aleator semnul pozițiilor în blocuri de 10 zile de semnal consecutive (bootstrap sălbatic dependent, [Shao \(2010\)](#)), de 2 000 de ori
 - ▶ Schimbările de semn sunt comune tuturor celor 36 de specificații: păstrează dependența dintre specificații și din interiorul blocurilor
 - ▶ Valid dacă, sub ipoteza nulă, randamentele cu semn sunt simetrice în jurul lui 0, iar blocurile sunt aproximativ independente
- Observat: 3 specificații cu $t > 1,96$ (2 cu $t < -1,96$), t median = 0,50
 - ▶ Sub nul, 3 sau mai multe astfel de specificații apar cu probabilitatea 0,113; un t median atât de mare, 0,207
- Interpretare: curba este compatibilă cu zgomotul la 5%; raportarea doar a celui mai bun punct ar ascunde asta

Rândul vostru: o sămânță de proiect

- Întrebarea: prognozează sentimentul titlurilor, măsurat cu un LLM, randamentele după $d + 1$ pe știri publicate după lansarea modelului, cu o grilă preînregistrată?
- Replicați întâi: strategia Qwen din acest capitol, +5,64 bp pe zi ($t = +2,26$); apoi designul de după data-limită din [Lopez-Lira & Tang \(2026\)](#)
- Livrabile
 - ▶ Grila și corecția preînregistrate; titluri datate de după publicarea unui model deschis; testul pe toate variantele
 - ▶ Un mecanism propus de LLM, formulat înaintea testului împreună cu ce l-ar infirma; o critică de tip recenzent și răspunsul vostru
- Notați fiecare prompt care a influențat o decizie în AI_USE.md; fiecare referință inventată, fapt memorat sau cifră greșită prinsă în AI_ERRORS.md, cu testul care a prins-o ([șabloane](#))

Agenți AI în tranzacționare: utilizări și riscuri

- Un agent este un LLM într-o buclă: citește intrările, decide, apelează instrumente (date, cod, căutarea știrilor, ordine printr-un API), observă, repetă
 - ▶ Folosit azi pentru rezumate de cercetare, programare și monitorizare; tranzacționarea complet autonomă este încă rară și experimentală
- Manipulare: un text citit de agent poate conține instrucțiuni (prompt injection), de exemplu un comunicat de presă fals
- Risc sistemic (IMF (2024)): multe firme cu modele asemănătoare pot tranzacționa la fel, crescând viteza și corelația mișcărilor în perioade de stres
 - ▶ Controale: limite de poziție, aprobarea umană a ordinelor, jurnalizarea fiecărui pas, teste după fiecare actualizare a modelului

Lista capcanelor

- ▣ **Suprapunerea cu datele de antrenare:** FinBERT are 89,0% pe propriile date de antrenare, 72,5% pe date noi
- ▣ **Privirea în viitor:** un LLM își poate aminti piața de după știre; testați după data publicării lui
- ▣ **Momentul:** marcaje doar la nivel de dată; tranzacționați cel mai devreme la închiderea de după ce știrea este sigur publică
- ▣ **Data snooping:** prompt-uri, praguri și modele alese după ce ați văzut rezultatele pe test
- ▣ **Costuri și aglomerare:** câștigurile zilnice mici dispar după câteva puncte de bază reprezentând costuri
- ▣ **Regresori generați:** scorurile sunt estimări; corecții atenuarea, validați pe un eșantion aleator etichetat de oameni (PPI)

Ce folosim și când

Situația	Alegerea	De ce
Reper rapid și transparent	Dicționarul LM	fără antrenare, verificabil
Texte financiare scurte în engleză	FinBERT	precis, milisecunde pe text
Fără etichete, alte limbi, documente lungi	LLM deschis (7B+)	zero-shot, flexibil
Câteva sute de etichete din domeniul vostru	embeddings + regresie logistică	ieftin și adaptat domeniului

- Oricare ar fi metoda: evaluați în afara eșantionului, cu intervale și teste pe perechi

Lecturi suplimentare

- ▣ Tetlock (2007): pesimismul din presă prezice randamentele pieței
- ▣ Loughran & McDonald (2011): un dicționar de sentiment specific finanțelor
- ▣ Gentzkow, Kelly & Taddy (2019): textul ca date în economie
- ▣ Aplicații pe criptoactive: clasificarea criptoactivelor [Pele et al. \(2023\)](#), bulele Dogecoin și sentimentul [Pele \(2025\)](#), Quantlet de sentiment [Pele \(2024\)](#)
- ▣ Studiu suplimentar: [Quantinar: Natural Language Processing](#), [Quantinar: DELTA](#), [Quantinar: LDA Extensions](#); manualul [Franke, Härdle & Hafner \(2019\)](#) pentru statistica din spatele testelor

Idei principale

- ▣ Dicționarele generale citesc greșit finanțele; dicționarul LM este un reper transparent
- ▣ Între FinBERT și LLM-urile deschise de 7B–14B nu s-a detectat o diferență semnificativă de acuratețe pe titluri financiare (ceea ce nu dovedește egalitatea); câteva sute de etichete și un clasificator simplu concurează cu ambele
- ▣ LLM-urile își amintesc istoria piețelor: evaluați-le doar după data publicării lor
- ▣ Sentimentul titlurilor explică mișcările din aceeași zi; cu o aliniere realistă și costuri, nu bate piața pentru acțiunile mari
- ▣ Scorurile sunt măsurători cu eroare: atenuarea, erorile posibil comune ale modelelor, puținele grupuri și numeroasele încercări influențează inferența

Bibliografie (1/7)

- ▣ Aigner, D.J. (1973). [Regression with a binary independent variable subject to errors of observation](#). *Journal of Econometrics*, 1(1), 49–59.
- ▣ Angelopoulos, A.N., Bates, S., Fannjiang, C., Jordan, M.I., Zrnic, T. (2023). [Prediction-powered inference](#). *Science*, 382(6671), 669–674.
- ▣ Antweiler, W., Frank, M.Z. (2004). [Is all that talk just noise? The information content of internet stock message boards](#). *Journal of Finance*, 59(3), 1259–1294.
- ▣ Araci, D. (2019). [FinBERT: financial sentiment analysis with pre-trained language models](#). arXiv:1908.10063.
- ▣ Baker, M., Wurgler, J. (2006). [Investor sentiment and the cross-section of stock returns](#). *Journal of Finance*, 61(4), 1645–1680.
- ▣ Battaglia, L., Christensen, T., Hansen, S., Sacher, S. (2024). [Inference for regression with variables generated by AI or machine learning](#). arXiv:2402.15585.
- ▣ Benjamini, Y., Hochberg, Y. (1995). [Controlling the false discovery rate: a practical and powerful approach to multiple testing](#). *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- ▣ Boehmer, E., Musumeci, J., Poulsen, A.B. (1991). [Event-study methodology under conditions of event-induced variance](#). *Journal of Financial Economics*, 30(2), 253–272.
- ▣ Bollen, J., Mao, H., Zeng, X. (2011). [Twitter mood predicts the stock market](#). *Journal of Computational Science*, 2(1), 1–8.

Bibliografie (2/7)

- ▣ Brier, G.W. (1950). [Verification of forecasts expressed in terms of probability](#). *Monthly Weather Review*, 78(1), 1–3.
- ▣ Brown, T.B., Mann, B., Ryder, N., Subbiah, M., et al. (2020). [Language models are few-shot learners](#). *NeurIPS*; arXiv:2005.14165.
- ▣ Bybee, L., Kelly, B., Manela, A., Xiu, D. (2024). [Business news and business cycles](#). *Journal of Finance*, 79(5), 3105–3147.
- ▣ Cameron, A.C., Gelbach, J.B., Miller, D.L. (2008). [Bootstrap-based improvements for inference with clustered errors](#). *Review of Economics and Statistics*, 90(3), 414–427.
- ▣ Cameron, A.C., Gelbach, J.B., Miller, D.L. (2011). [Robust inference with multiway clustering](#). *Journal of Business & Economic Statistics*, 29(2), 238–249.
- ▣ Dawid, A.P., Skene, A.M. (1979). [Maximum likelihood estimation of observer error-rates using the EM algorithm](#). *Applied Statistics*, 28(1), 20–28.
- ▣ DeLong, E.R., DeLong, D.M., Clarke-Pearson, D.L. (1988). [Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach](#). *Biometrics*, 44(3), 837–845.
- ▣ Devlin, J., Chang, M.-W., Lee, K., Toutanova, K. (2019). [BERT: pre-training of deep bidirectional Transformers for language understanding](#). *NAACL*; arXiv:1810.04805.
- ▣ Dong, Z., Fan, X., Peng, Z. (2024). [FNSPID: a comprehensive financial news dataset in time series](#). *Proceedings of the 30th ACM SIGKDD Conference*, 4918–4927.

Bibliografie (3/7)

- ▣ Drinkall, F., Rahimikia, E., Pierrehumbert, J.B., Zohren, S. (2024). [Time Machine GPT](#). arXiv:2404.18543.
- ▣ Driscoll, J.C., Kraay, A.C. (1998). [Consistent covariance matrix estimation with spatially dependent panel data](#). *Review of Economics and Statistics*, 80(4), 549–560.
- ▣ Egami, N., Hinck, M., Stewart, B.M., Wei, H. (2023). [Using imperfect surrogates for downstream inference: design-based supervised learning for social science applications of large language models](#). arXiv:2306.04746.
- ▣ Fleiss, J.L. (1971). [Measuring nominal scale agreement among many raters](#). *Psychological Bulletin*, 76(5), 378–382.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Gentzkow, M., Kelly, B., Taddy, M. (2019). [Text as data](#). *Journal of Economic Literature*, 57(3), 535–574.
- ▣ Glasserman, P., Lin, C. (2023). [Assessing look-ahead bias in stock return predictions generated by GPT sentiment analysis](#). arXiv:2309.17322.
- ▣ Gu, S., Kelly, B., Xiu, D. (2020). [Empirical asset pricing via machine learning](#). *Review of Financial Studies*, 33(5), 2223–2273.
- ▣ Guo, C., Pleiss, G., Sun, Y., Weinberger, K.Q. (2017). [On calibration of modern neural networks](#). *ICML*; arXiv:1706.04599.

Bibliografie (4/7)

- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ...and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- ▣ He, S., Lv, L., Manela, A., Wu, J. (2025). Chronologically consistent large language models. arXiv:2502.21206.
- ▣ Huang, A.H., Wang, H., Yang, Y. (2023). FinBERT: a large language model for extracting information from financial text. *Contemporary Accounting Research*, 40(2), 806–841.
- ▣ Hutto, C., Gilbert, E. (2014). VADER: a parsimonious rule-based model for sentiment analysis of social media text. *Proceedings of the International AAAI Conference on Web and Social Media*, 8(1), 216–225.
- ▣ IMF (2024). Advances in artificial intelligence: implications for capital market activities. *Global Financial Stability Report*, October 2024, Chapter 3.
- ▣ Jegadeesh, N., Wu, D. (2013). Word power: a new approach for content analysis. *Journal of Financial Economics*, 110(3), 712–729.
- ▣ Ke, Z.T., Kelly, B., Xiu, D. (2019). Predicting returns with text data. NBER Working Paper 26186.
- ▣ Kearney, C., Liu, S. (2014). Textual sentiment in finance: a survey of methods and models. *International Review of Financial Analysis*, 33, 171–185.
- ▣ Kim, A., Muhn, M., Nikolaev, V. (2023). Bloated disclosures: can ChatGPT help investors process information? arXiv:2306.10224.

Bibliografie (5/7)

- ▣ Lopez-Lira, A., Tang, Y. (2026). [Can ChatGPT forecast stock price movements? Return predictability and large language models.](#) *Journal of Financial Economics*, 184, 104335. Earlier version: [arXiv:2304.07619](#).
- ▣ Lopez-Lira, A., Tang, Y., Zhu, M. (2025). [The memorization problem: can we trust LLMs' economic forecasts?](#) [arXiv:2504.14765](#).
- ▣ Loughran, T., McDonald, B. (2011). [When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks.](#) *Journal of Finance*, 66(1), 35–65.
- ▣ Loughran, T., McDonald, B. (2016). [Textual analysis in accounting and finance: a survey.](#) *Journal of Accounting Research*, 54(4), 1187–1230.
- ▣ Lu, C., Lu, C., Lange, R.T., Foerster, J., Clune, J., Ha, D. (2024). [The AI Scientist: towards fully automated open-ended scientific discovery.](#) [arXiv:2408.06292](#).
- ▣ Ludwig, J., Mullainathan, S. (2024). [Machine learning as a tool for hypothesis generation.](#) *Quarterly Journal of Economics*, 139(2), 751–827.
- ▣ Ludwig, J., Mullainathan, S., Rambachan, A. (2024). [Large language models: an applied econometric framework.](#) [arXiv:2412.07031](#).
- ▣ Malo, P., Sinha, A., Korhonen, P., Wallenius, J., Takala, P. (2014). [Good debt or bad debt: detecting semantic orientations in economic texts.](#) *Journal of the Association for Information Science and Technology*, 65(4), 782–796.
- ▣ Mikolov, T., Chen, K., Corrado, G., Dean, J. (2013). [Efficient estimation of word representations in vector space.](#) [arXiv:1301.3781](#).

Bibliografie (6/7)

- ▣ Ouyang, L., Wu, J., Jiang, X., Almeida, D., et al. (2022). Training language models to follow instructions with human feedback. *NeurIPS*; arXiv:2203.02155.
- ▣ Pele, D.T. (2024). [Sentiment Analysis](#) (Quantlet, BitMood project). IDA Quantlets Repository, Bucharest University of Economic Studies.
- ▣ Pele, D.T. (2025). [Dogecoin and speculative bubbles: a study using LPPL and sentiment analysis](#). Quantinar course, Bucharest University of Economic Studies.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). [Are cryptos becoming alternative assets?](#) *The European Journal of Finance*, 29(10), 1064–1105.
- ▣ Petersen, M.A. (2009). [Estimating standard errors in finance panel data sets: comparing approaches](#). *Review of Financial Studies*, 22(1), 435–480.
- ▣ Qwen Team (2024). [Qwen2.5 technical report](#). arXiv:2412.15115.
- ▣ Reimers, N., Gurevych, I. (2019). [Sentence-BERT: sentence embeddings using Siamese BERT-networks](#). *EMNLP*; arXiv:1908.10084.
- ▣ Sarkar, S.K., Vafa, K. (2024). [Lookahead bias in pretrained language models](#). SSRN Working Paper 4754678.
- ▣ Shannon, C.E. (1951). [Prediction and entropy of printed English](#). *Bell System Technical Journal*, 30(1), 50–64.

Bibliografie (7/7)

- ▣ Shao, X. (2010). [The dependent wild bootstrap](#). *Journal of the American Statistical Association*, 105(489), 218–235.
- ▣ Shiller, R.J. (2017). [Narrative economics](#). *American Economic Review*, 107(4), 967–1004.
- ▣ Simonsohn, U., Simmons, J.P., Nelson, L.D. (2020). [Specification curve analysis](#). *Nature Human Behaviour*, 4(11), 1208–1214.
- ▣ Taddy, M. (2013). [Multinomial inverse regression for text analysis](#). *Journal of the American Statistical Association*, 108(503), 755–770.
- ▣ Tetlock, P.C. (2007). [Giving content to investor sentiment: the role of media in the stock market](#). *Journal of Finance*, 62(3), 1139–1168.
- ▣ Tetlock, P.C., Saar-Tsechansky, M., Macskassy, S. (2008). [More than words: quantifying language to measure firms' fundamentals](#). *Journal of Finance*, 63(3), 1437–1467.
- ▣ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., et al. (2017). [Attention is all you need](#). *NeurIPS*; arXiv:1706.03762.
- ▣ Wang, W., Wei, F., Dong, L., Bao, H., Yang, N., Zhou, M. (2020). [MiniLM: deep self-attention distillation for task-agnostic compression of pre-trained Transformers](#). *NeurIPS*; arXiv:2002.10957.
- ▣ Wu, S., Irsoy, O., Lu, S., Dabrovolski, V., et al. (2023). [BloombergGPT: a large language model for finance](#). arXiv:2303.17564.