









Modelarea piețelor financiare

Capitolul 18: Risc sistemic și rețele



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Cînd devin dificultățile unei bănci o problemă a sistemului?

De la o bancă la sistem

- **Riscul sistemic**: riscul ca dificultățile uneia sau ale mai multor instituții să afecteze sistemul financiar în ansamblu
  - și, prin el, economia reală
- O **externalitate**: o bancă nu plătește pierderile pe care falimentul ei le impune altora
- Trei familii de măsuri (sinteză: Benoit, Colliard, Hurlin & Pérignon (2017))
  - **Expunere**: cît pierde banca atunci cînd piața se prăbușește?
  - MES: pierderea ei medie în zilele de crah; SRISK: deficitul ei de capital într-o criză
  - **Contribuție**: cu cît stă mai rău sistemul atunci cînd banca este în dificultate?
  - ΔCoVaR, cu CoVaR Value-at-Risk (VaR) al sistemului condiționat de starea băncii
  - **Conectivitate**: prin ce legături circulă șocurile?
  - Rețele de spillover și rețele în coadă

Planul capitolului: pierderi extreme și rețele financiare

Două părți

- Partea I: de la date la măsurile riscului sistemic pentru fiecare bancă
  - date și convenții
  - expunerea: MES, LRMES (adică MES într-o criză de mai multe luni), SRISK
  - contribuția: CoVaR, ΔCoVaR, și cît ne putem baza pe clasamente
- Partea a II-a: rețele, teste de stres și un caz de cercetare
  - rețele de spillover și Financial Risk Meter
  - teste de stres și riscul climatic
  - un studiu de caz despre conectivitatea cuantilă
  - o trecere prin bucla descoperirii cu AI (inteligență artificială)
- Manuale: Franke, Härdle & Hafner (2019), Härdle, Chen & Overbeck (2017)
- Exemplele detaliate și subiectele avansate sînt în Aprofundări, după Concluzii
  - butonul din subsol duce la ele, iar butonul Înapoi revine la slide-ul de plecare

Retrageri masive de depozite: Northern Rock 2007 și Silicon Valley Bank 2023



Deponenți la coadă în fața unei sucursale Northern Rock, Brighton, 14 septembrie 2007

Foto: Dominic Alves (2007); CC BY 2.0; Wikimedia Commons

- Northern Rock (2007): un creditor ipotecar britanic
  - afectat de blocarea piețelor de finanțare după pierderile din creditele subprime americane
  - Deponenții au stat la coadă pentru a-și retrage economiile
- SVB (Silicon Valley Bank, 2023): retrageri masive de depozite prin canale digitale
  - FDIC (Federal Deposit Insurance Corporation, fondul american de garantare a depozitelor) a preluat banca pe 10 martie FDIC (2023)
  - După două zile, toți deponenții SVB și Signature Bank au fost protejați, pe baza unui argument de risc **sistemic** Federal Reserve Board (2023)

Prin ce canale se transmite contagion?

- Dificultățile unei bănci devin sistemice prin trei canale
  - **Retrageri de finanțare**: deponenții și creditorii se retrag din orice bancă ce pare asemănătoare
  - **Expuneri comune** și **fire sales** (vînzări forțate): vînzările scad prețurile pentru toți deținătorii
  - **Legături între contrapărți**: datoria unei bănci este activul alteia, deci neplata ei transmite pierderi creditorilor

Treisprezece bănci, trei piețe: prețuri și randamente log

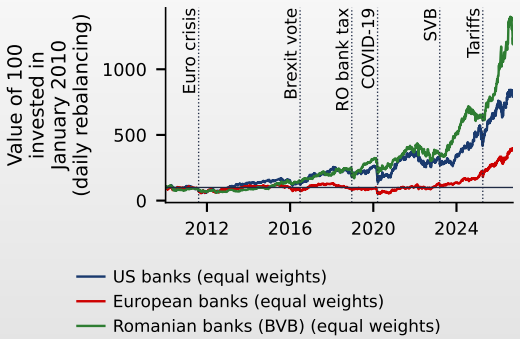
Grupul	Băncile (simbolul bursier, folosit în unele grafice)	Indicele pieței
Bănci americane	JPMorgan (JPM), Bank of America (BAC), Citigroup (C), Goldman Sachs (GS), Morgan Stanley (MS), Wells Fargo (WFC)	S&P 500
Bănci europene	Deutsche Bank (DBK), BNP Paribas (BNP), Santander (SAN), ING (INGA), HSBC (HSBA)	Euro Stoxx 50
Bănci românești	Banca Transilvania (TLV), BRD-Groupe Société Générale (BRD; „BRD-Groupe SG" în grafice)	BET
Volatilitate	indicele VIX (volatilitatea implicită a S&P 500)	

- Prețuri zilnice, ianuarie 2010–18 septembrie 2026, ajustate pentru dividende și divizări
  - Aliniate întîi pe 3 960 de zile de tranzacționare comune, apoi randamentele logaritmice zilnice $r_t = 100(\ln P_t - \ln P_{t-\mathbf{1}})$, în %
- Cazuri speciale
  - Băncile românești, tranzacționate la Bursa de Valori București (BVB, indicele BET): zilele fără tranzacții sînt eliminate
  - Scenariile istorice de stres pentru băncile internaționale încep în 2007

Pierderile ca numere pozitive și portofoliul sistemului

- Notăm randamentul cu X și pierderea cu $L = -X$
  - nivelul α este o **probabilitate a cozii** (Capitolul 7)
  - $\mathrm{VaR}_\alpha(X) = -q_\alpha(X)$, cu q_α cuantila de ordin α a lui X
  - Scriem VaR 1%, CoVaR 1%, MES 5%, toate pozitive atunci cînd sînt pierderi
- Randamentul **sistemului** X^{sys}: portofoliul cu ponderi egale al celorlalte bănci din aceeași regiune
  - $X^{sys} = \frac{1}{n}\sum_j X_j$, o aproximare de ordinul întîi a randamentului log al portofoliului reechilibrat zilnic
  - CoVaR se referă la acest agregat, iar MES condiționează pe indicele pieței din regiune

Trei sisteme bancare, 2010–2026



- Portofolii cu ponderi egale ale băncilor din fiecare regiune, reechilibrate zilnic
  - Liniile verticale marchează episoadele folosite în acest capitol
- 100 investiți în ianuarie 2010 au devenit 791 (SUA), 384 (Europa), 1 233 (România)
  - Drawdown-ul maxim: SUA 51% (2011-11-23), Europa 61% (2020-04-21), România 47% (2012-06-06)
  - Volatilitatea anualizată: 29% (SUA), 30% (Europa), 23% (România), față de 18%, 21% și 18% pentru indicii de piață
- Scăderile sînt **simultane**: criza din zona euro, COVID-19, falimentele bancare din 2023
  - Băncile românești au și un șoc propriu: anunțul taxei bancare din decembrie 2018 (eticheta „RO bank tax")

MFM_ch18_bank_indices

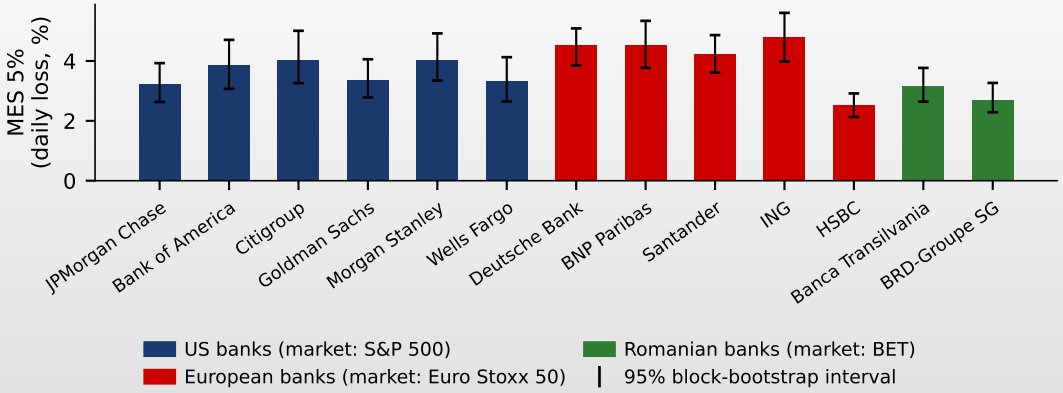
Cît pierde o bancă atunci cînd piața se prăbușește?

- **Expunerea**: pierderea băncii condiționată de o criză a pieței, nu VaR-ul ei izolat
  - Contează băncile care rămîn fără capital tocmai cînd sistemul are nevoie de el
- Trei pași, de la o zi de crah la o criză
  - MES: pierderea medie a băncii în cele mai rele 5% dintre zilele pieței, nivelul folosit de Acharya, Pedersen, Philippon & Richardson (2017)
  - LRMES: pierderea băncii într-o criză de mai multe săptămîni sau luni
  - SRISK: capitalul care i-ar lipsi băncii după această pierdere

Marginal Expected Shortfall și proprietatea Euler

- **MES** a băncii i la nivelul α Acharya, Pedersen, Philippon & Richardson (2017)
  - MES: Marginal Expected Shortfall, pierderea marginală așteptată în coadă
  - $\mathrm{MES}_{i,\alpha} = -\mathbb{E}[X_i \mid X_m \leq q_\alpha(X_m)]$: pierderea medie a băncii în fracțiunea α a celor mai rele zile ale pieței m
- Termenul „marginală": **dacă** $m = \sum_i w_i X_i$ este chiar portofoliul, atunci $\mathrm{ES}_\alpha(X_m) = \sum_i w_i \,\mathrm{MES}_{i,\alpha}$
  - aceasta este alocarea Euler (demonstrația în Anexă)
  - Indicii noștri de piață **nu** sînt portofolii ale acestor 13 bănci
  - Aici MES măsoară **expunerea**, nu o parte din ES al indicelui
- Estimarea istorică: media lui $-X_i$ în zilele cu $X_m \leq \hat{q}_\alpha(X_m)$
  - Cu $\alpha = 5\%$ și 3 960 de zile, media se calculează pe aproximativ 200 de zile

MES 5% pentru treisprezece bănci (1/2)



MFM_ch18_mes_srisk

MES 5% pentru treisprezece bănci (2/2)

- Pierderea zilnică medie a fiecărei bănci în cele mai rele 5% dintre zile ale indicelui său de piață
  - zilele cu cele mai mici randamente ale indicelui, 2010–2026
  - Intervale de 95%: bootstrap pe blocuri suprapuse de 20 de zile
- Băncile americane: de la 3,22% (JPMorgan) la 4,04% (Morgan Stanley)
  - băncile europene: pînă la 4,81% (ING)
  - În aceleași zile, pierderea medie a pieței a fost 2,72% (S&P 500) și 3,16% (Euro Stoxx 50)
  - Băncile pierd mai mult decît piața
- HSBC este excepția din Europa (2,54%, sub indice)
  - O bancă listată la Londra, cu activitate concentrată în Asia
- Băncile românești: Banca Transilvania 3,14% și BRD 2,69%
  - față de 2,70% pentru indicele BET însuși

MFM_ch18_mes_srisk

De la MES la o criză: LRMES

- **LRMES**: scăderea așteptată a capitalului de piață al băncii într-o criză
  - LRMES: Long-Run MES, MES pe termen lung
  - $\mathrm{LRMES}_{i,t} = -\mathbb{E}_t\left[R_{i,t+\mathbf{1}:t+h} \mid R_{m,t+\mathbf{1}:t+h} < C\right]$, cu R randamentele aritmetice pe h zile ale băncii și ale pieței
  - Criza: piața scade sub $C = -40\%$ în șase luni Acharya, Engle & Richardson (2012), respectiv sub $C = -10\%$ în $h = 22$ de zile Brownlees & Engle (2017)
- Aproximarea din Acharya, Engle & Richardson (2012), fără simulare: $\mathrm{LRMES}_i \approx 1 - \exp(-18 \times \mathrm{MES}_i^{\mathbf{2\%}})$
  - $\mathrm{MES}_i^{\mathbf{2\%}}$: pierderea zilnică medie a băncii în zilele în care piața scade cu peste 2%
  - Factorul 18 o duce la criza de șase luni, cu beta constant
  - Exemplu: $\mathrm{MES}^{\mathbf{2\%}} = 3\%$ dă $1 - e^{-\mathbf{0,54}} = 41{,}7\%$
- Pentru băncile noastre: de la 37% (HSBC) la 58% (ING)
  - JPMorgan 48%, Banca Transilvania 52%

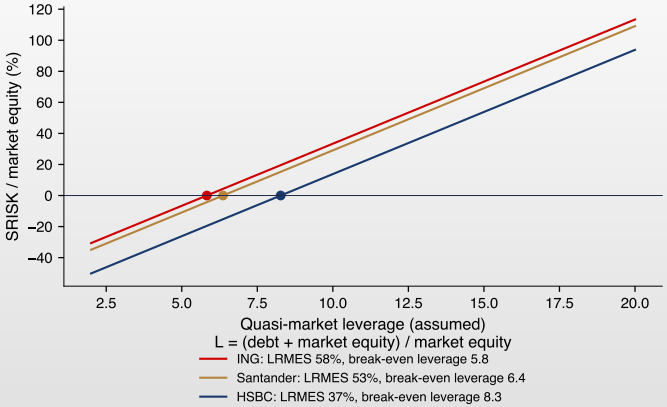
SRISK și leverage-ul de echilibru (1/2)

- **SRISK** (systemic risk): capitalul care i-ar lipsi unei bănci într-o criză severă a pieței
- Capitalul trebuie să fie cel puțin o proporție k din cvasi-active Brownlees & Engle (2017)
  - cvasi-activele: datoriile contabile D plus capitalul de piață W
  - $\mathrm{SRISK}_i = k\,D_i - (1-k)(1-\mathrm{LRMES}_i)\,W_i$, cu datoriile nerenegociate în criză
  - Echivalent, $k[D_i + (1-\mathrm{LRMES}_i)W_i] - (1-\mathrm{LRMES}_i)W_i$
  - Adică capitalul cerut după criză minus capitalul rămas
- $k = 8\%$ pentru firmele americane Brownlees & Engle (2017) și $k = 5{,}5\%$ pentru cele europene Engle, Jondeau & Rockinger (2015)
  - Bilanțurile IFRS (standardele internaționale de raportare financiară) permit mai puțin **netting** al derivatelor decît US GAAP (principiile contabile americane)
  - De aceea raportează active mai mari
- SRISK pozitiv înseamnă deficit de capital
  - SRISK al sistemului, suma valorilor pozitive, este publicat de V-Lab, New York University Stern School of Business

SRISK și leverage-ul de echilibru (2/2)

- Împărțim la W, cu leverage-ul pe bază de cvasi-active $\Lambda = (D + W)/W$
  - $\dfrac{\mathrm{SRISK}}{W} = k(\Lambda - 1) - (1 - k)(1 - \mathrm{LRMES})$
- SRISK devine pozitiv cînd Λ depășește **leverage-ul de echilibru** $\Lambda^* = 1 + \dfrac{(1 - k)(1 - \mathrm{LRMES})}{k}$
- Exemplu: $D = 900$, $W = 100$ (deci $\Lambda = 10$), $\mathrm{LRMES} = 41{,}7\%$
  - $\mathrm{SRISK} = 0{,}08 \times 900 - 0{,}92 \times (1 - 41{,}7\%) \times 100 = 72 - 53{,}6 = 18{,}4$
  - $\Lambda^* = 7{,}7 < \Lambda = 10$: deficit
- Datele noastre conțin prețuri, nu bilanțuri
  - raportăm Λ^* din LRMES estimat
  - tratăm leverage-ul ca pe o **ipoteză**

SRISK în funcție de leverage (1/2)



MFM_ch18_mes_srisk

SRISK în funcție de leverage (2/2)

- Curbele: băncile cu LRMES maxim, median și minim
  - punctele marchează Λ^*
  - Leverage-ul de pe axa orizontală este presupus, nu observat
- Curbele din grafic, cu $k = 8\%$ și LRMES aproximat: $\Lambda^* = 5{,}8$ (ING), 6,4 (Santander), 8,3 (HSBC)
  - Celelalte bănci: JPMorgan 7,0, Morgan Stanley 6,0, Banca Transilvania 6,5, BRD 7,1
- Peste Λ^*, banca are nevoie de capital nou într-un crah al pieței de 40%
  - adică la datorii de peste 4,8–7,3 ori capitalul de piață
- Cu $k = 5{,}5\%$ pragurile cresc (ING 8,2, HSBC 11,9)
  - SRISK depinde de raportul prudențial ales
- Limitele calculului
  - LRMES extrapolează date zilnice
  - capitalul de piață însuși scade într-o criză

MFM_ch18_mes_srisk

▸ Anexă: LRMES prin simulare

Cu cît crește pierderea sistemului cînd o bancă este în dificultate?

- MES privește direcția piață → bancă
  - **contribuția** privește direcția inversă, bancă → sistem
- Ne interesează o cuantilă din coada sistemului, nu media lui
  - Regresia cuantilă estimează direct cuantila condiționată Koenker & Bassett (1978)
- Nivelurile: $\alpha = 1\%$ și $\alpha = 5\%$, cele raportate de Adrian & Brunnermeier (2016)
  - comparăm clasamentele obținute la cele două niveluri
- Întrebările secțiunii
  - Cît adaugă fiecare bancă la pierderea din coadă a sistemului?
  - Sînt diferențele dintre bănci semnificative statistic?

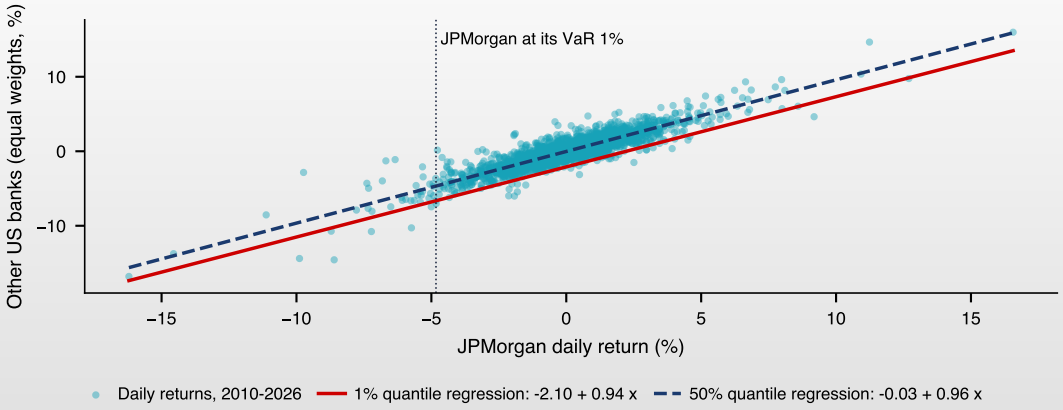
CoVaR: VaR al sistemului cînd o bancă este în dificultate

- **CoVaR** al sistemului condiționat de banca *i* aflată la nivelul VaR-ului ei Adrian & Brunnermeier (2016)
  - $P\left(X^{sys} \leq -\mathrm{CoVaR}_{\alpha}^{sys|i} \;\middle|\; X_i = -\mathrm{VaR}_{i,\alpha}\right) = \alpha$
  - Pierderea sistemului depășită cu probabilitatea α într-o zi în care banca *i* se află la propriul VaR
- **ΔCoVaR**: diferența dintre starea de dificultate a băncii și starea ei mediană, o zi obișnuită
  - $\Delta\mathrm{CoVaR}_{\alpha}^{sys|i} = \mathrm{CoVaR}_{\alpha}^{sys|X_i=q_\alpha} - \mathrm{CoVaR}_{\alpha}^{sys|X_i=q_{\mathbf{50\%}}}$, cu randamentul băncii fixat la cuantila indicată
- ΔCoVaR măsoară **contribuția** băncii *i* la riscul din coadă (tail risk) al sistemului
- Inversînd rolurile obținem **CoVaR de expunere**
  - VaR al băncii *i* atunci cînd sistemul este în dificultate

Estimarea CoVaR prin regresie cuantilă

- Regresia cuantilă Koenker & Bassett (1978): $q_\alpha(Y \mid x) = a_\alpha + b_\alpha x$
  - $(\hat{a}_\alpha, \hat{b}_\alpha) = \arg\min_{a,b} \sum_t \rho_\alpha(y_t - a - bx_t)$
  - **Funcția de pierdere cuantilă** $\rho_\alpha(u) = u\,(\alpha - 1\{u < 0\})$ ponderează reziduurile negative cu $1-\alpha$ și pe cele pozitive cu α
- 1. Regresăm sistemul pe bancă: $\hat{q}_\alpha(X^{sys} \mid X_i) = \hat{a}_\alpha + \hat{b}_\alpha X_i$
- 2. Introducem cuantila de dificultate a băncii: $\mathrm{CoVaR}_\alpha^{sys|i} = -\left(\hat{a}_\alpha + \hat{b}_\alpha \hat{q}_\alpha(X_i)\right)$
- 3. $\Delta\mathrm{CoVaR}_\alpha^{sys|i} = \hat{b}_\alpha\,(\hat{q}_{\mathbf{50\%}}(X_i) - \hat{q}_\alpha(X_i))$
  - termenul liber se simplifică
- Incertitudinea: bootstrap pe blocuri suprapuse, cu 999 de reeșantionări
  - bootstrap-ul păstrează volatility clustering
  - Lungimea blocului crește ca $n^{\mathbf{1/3}}$ Hall, Horowitz & Jing (1995): $3\,960^{\mathbf{1/3}} \approx 16$, rotunjit la 20 de zile, o lună de tranzacționare

Regresia cuantilă: JPMorgan și celelalte bănci americane (1/2)



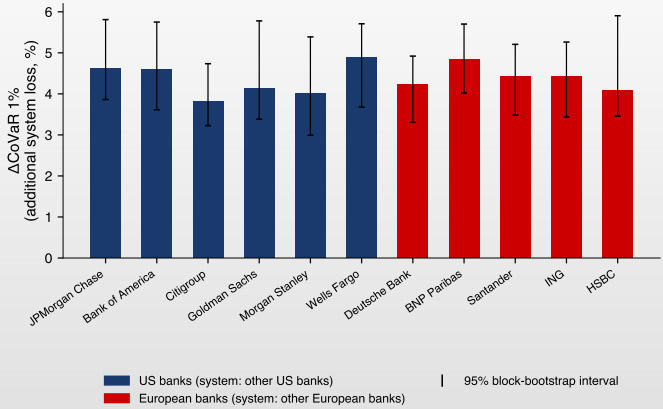
MFM_ch18_covar

Regresia cuantilă: JPMorgan și celelalte bănci americane (2/2)

- Randamente zilnice 2010–2026, dreptele de regresie cuantilă de 1% și 50%
  - linia punctată: JPMorgan la VaR 1%
- Dreapta de 1%: $\hat{q}_{\mathbf{1\%}} = -2{,}10 + 0{,}94\, X_i$
  - dreapta medianei: $-0{,}03 + 0{,}96\, X_i$
  - Pante asemănătoare: dreapta de 1% este deplasată în jos, nu mai abruptă
- Cînd JPMorgan se află la VaR 1% (4,83%), CoVaR 1% al celorlalte bănci americane este 6,64%
  - Față de VaR 1% al sistemului, 5,07%, și de CoVaR 1% cu JPMorgan la mediană, 2,03%
- $\Delta\mathrm{CoVaR}_{\mathbf{1\%}} = 4{,}62\%$
  - JPMorgan în dificultate adaugă aproximativ 4,62 puncte procentuale la pierderea din coadă a sistemului
  - Asociere, nu cauzalitate: un șoc comun afectează toate băncile în aceeași zi

MFM_ch18_covar

ΔCoVaR 1% pentru unsprezece bănci (1/2)



MFM_ch18_covar

ΔCoVaR 1% pentru unsprezece bănci (2/2)

- Barele: ΔCoVaR, pierderea **suplimentară** a sistemului cînd banca trece de la mediană la VaR
  - intervale bootstrap de 95%
  - Fără băncile românești: fiind doar două, „sistemul" celorlalte bănci ar fi o singură bancă
- Valorile merg de la 3,81% (Citigroup) la 4,89% (Wells Fargo)
  - intervalele au lățimea de 1,5–2,4 puncte procentuale
  - Intervalele marginale se suprapun, de ex. Citigroup $[3{,}23; 4{,}74]$ și Wells Fargo $[3{,}68; 5{,}71]$
- Suprapunerea **nu** este un test
  - estimările din aceleași zile sînt puternic corelate
  - deci intervalul diferenței poate fi mai îngust
- La $\alpha = 5\%$ valorile sînt mai mici (JPMorgan 2,62%), iar clasamentul se schimbă
  - Corelația Spearman dintre clasamentele de 1% și 5% este 0,10
  - O bază fragilă pentru reglementare

MFM_ch18_covar

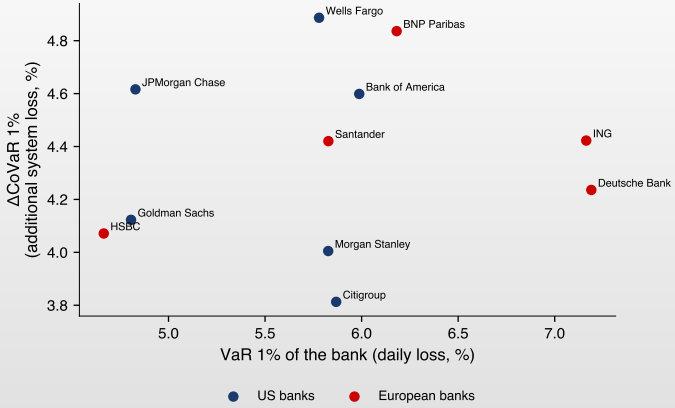
Testarea ΔCoVaR 1%

- Toate testele folosesc aceleași 999 de extrageri bootstrap pe blocuri pentru toate băncile
  - deci estimările își păstrează dependența (detalii: Anexă)
- (1) Nicio contribuție, $H_0: b_\alpha = 0$
  - test Wald cu dispersia sandviș a regresiei cuantile Koenker & Bassett (1978), estimată prin nucleu Hendricks & Koenker (1992)
  - Rapoartele t pentru $\hat{b}_{1\%}$ merg de la 4,0 (HSBC) la 6,9 (JPMorgan): fiecare bancă contribuie (Regresia cuantilă: asimptotica)
- (2) $H_0: b_\alpha = b_{50\%}$, respinsă pentru 2 din 11 bănci (Citigroup, ING, și după Holm)
  - nerespingerea la celelalte 9 nu dovedește egalitatea
- (3) Contribuții egale, $H_0: \Delta\mathrm{CoVaR}_i = \Delta\mathrm{CoVaR}_j$
  - teste de dominanță: Castro & Ferrari (2014); rezultatele pe bănci: Anexă
  - La $\alpha = 1\%$: 4 din 25 de perechi din aceeași regiune diferă la 5% (0 după Holm); testul Wald comun dă $p = 0{,}015$ (SUA) și 0,31 (Europa)
  - La $\alpha = 5\%$: 3 din 25 de perechi diferă (0 după Holm); testul Wald comun dă $p = 0{,}014$ (SUA) și 0,046 (Europa)

Cum citim testele: Holm și testul Wald comun

- **Multe perechi, o singură familie**: 25 de perechi testate la 5%
  - ne așteptăm la mai mult de o „diferență" falsă chiar cu contribuții egale
  - Holm (1979): ordonăm $p_{(1)} \le \cdots \le p_{(m)}$ și respingem cît timp $p_{(k)} \le 0{,}05/(m-k+1)$
  - Eroarea pe familie rămîne sub 5% pentru orice dependență
  - Exemplu, $p = 0{,}010;\ 0{,}030;\ 0{,}040$: $0{,}010 \le 0{,}05/3$ (respingem), $0{,}030 > 0{,}05/2$ (ne oprim): o respingere în loc de trei
- **Testul Wald comun** al egalității contribuțiilor dintr-o regiune
  - $W = \hat{d}^\top \hat{V}^{-1} \hat{d} \sim \chi^2$ cu numărul băncilor minus 1 grade de libertate
  - $\hat{d}$: diferențele față de o bancă de referință (orice alegere dă același W)
  - $\hat{V}$: covarianța lor bootstrap
- SUA: testul comun respinge ($p = 0{,}015$), deși după Holm rămîn 0 din 25 de perechi
  - Testul comun adună diferențe moderate, iar Holm cere o pereche foarte puternică singură ($p_{(1)} \le 0{,}05/25$)
  - Deci contribuțiile nu sînt toate egale, dar nu știm care pereche diferă

VaR și ΔCoVaR măsoară lucruri diferite (1/2)



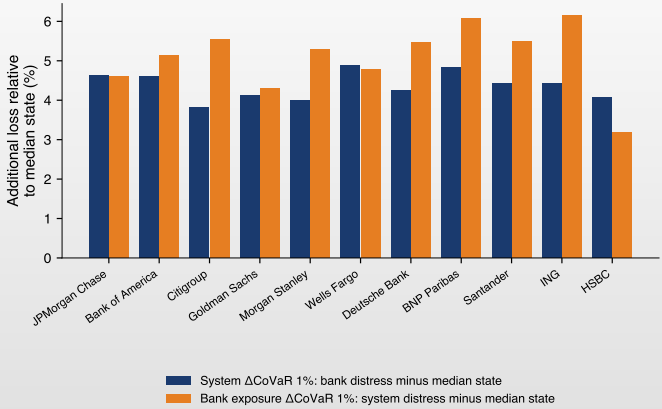
MFM_ch18_covar

VaR și ΔCoVaR măsoară lucruri diferite (2/2)

- Unsprezece bănci, 2010–2026
  - pe axa orizontală VaR 1% al băncii, pe axa verticală ΔCoVaR 1%
- Corelația de rang Spearman dintre VaR și ΔCoVaR: 0,16
  - Deutsche Bank și ING au cele mai mari VaR (7,19% și 7,16%), dar doar un ΔCoVaR mediu
  - JPMorgan are unul dintre cele mai mici VaR (4,83%), dar unul dintre cele mai mari ΔCoVaR
- Mesajul central al Adrian & Brunnermeier (2016)
  - reglementarea fiecărei bănci după propriul VaR ignoră contribuția ei la sistem
- Cu unsprezece bănci și intervale suprapuse, corelația este însă foarte incertă

MFM_ch18_covar

Contribuție față de expunere (1/2)



MFM_ch18_covar

Contribuție față de expunere (2/2)

- Albastru, contribuția: pierderea sistemului cînd banca este în dificultate
- Portocaliu, expunerea: pierderea băncii cînd sistemul este în dificultate
  - X_i regresat pe X^{sys}, apoi cuantilele lui X^{sys}
- Direcția contează: ING are contribuția 4,42% și expunerea 6,14%
  - BNP Paribas: 4,84% și 6,07%
- HSBC: contribuție 4,07%, expunere doar 3,17%
- Expunerea depășește contribuția pentru majoritatea băncilor europene
- Ambele sînt asocieri, nu efecte cauzale
- Expunerea contează pentru capitalul propriu al băncii
  - contribuția contează pentru autoritatea de reglementare

MFM_ch18_covar

Fiabilitatea clasamentelor

- Clasamentele după măsuri sistemice diferite nu coincid și au o incertitudine mare Nucera, Schwaab, Koopman & Lucas (2016)
  - combinăm măsurile și raportăm incertitudinea clasamentului
- Riscul de model Danielsson, James, Valenzuela & Zer (2016)
  - LRMES simulat față de aproximare
  - CoVaR Girardi–Ergün față de regresia cuantilă
  - $\alpha = 1\%$ față de 5%
- Eșantionul efectiv din coadă, αn: 40 de zile la 1% și 198 la 5%
  - La 1% erorile standard cu nucleu și bootstrap pe blocuri diferă (▸ Anexă)
- Backtesting-ul out-of-sample pentru $\mathrm{CoVaR}^{\leq}_{\mathbf{5\%}}$ nu respinge pentru nicio bancă
  - detalii: ▸ Anexă
  - Cu aproximativ 7,4 evenimente comune așteptate, puterea lui este mică
- Robuste sînt diferențele mari și testate
  - între regiuni și panta din coadă a unor bănci
  - nu ordinea a unsprezece estimări apropiate

Prin ce legături se transmit șocurile între bănci?

- MES și CoVaR privesc o bancă și un agregat
  - o criză se transmite însă între multe bănci deodată
- O rețea răspunde la trei întrebări
  - Cine transmite și cine primește șocuri?
  - Cît de conectat este sistemul în ansamblu?
  - Crește conectivitatea în crize?
- Abordarea: descompunerea dispersiei erorii de prognoză dintr-un VAR Diebold & Yilmaz (2014)
  - aplicată volatilităților zilnice ale băncilor

De la perechi la rețele: descompunerea dispersiei (1/2)

- O **rețea** analizează simultan toate perechile de bănci
  - nodurile sînt băncile
  - muchiile orientate arată cît din incertitudinea viitoare a băncii i vine din șocurile băncii j
- Autoregresie vectorială (VAR, vector autoregression) de ordin p pentru N serii y_t
  - $y_t = c + \sum_{l=1}^{p} A_l\, y_{t-l} + \varepsilon_t$, $\mathrm{Cov}(\varepsilon_t) = \Sigma$
  - Fiecare serie este regresată pe p laguri ale tuturor seriilor
  - Matricile de coeficienți A_l au dimensiunea $N \times N$ (ipotezele: Anexă)
- Rețele din descompunerea dispersiei Diebold & Yilmaz (2009), Diebold & Yilmaz (2012), Diebold & Yilmaz (2014): abordarea din această secțiune
- Alte rețele
  - cauzalitate Granger Billio, Getmansky, Lo & Pelizzon (2012) (Anexă)
  - rețele în coadă TENET (Tail-Event driven NETwork risk) Härdle, Wang & Yu (2016)
  - Financial Risk Meter (secțiunea următoare)

De la perechi la rețele: descompunerea dispersiei (2/2)

- Eroarea de prognoză pe H zile a lui y_i este o sumă de șocuri ale tuturor seriilor
  - deci dispersia ei se poate împărți pe surse
  - Reprezentarea de tip medie mobilă: $y_t = \mu + \sum_{h \geq \mathbf{0}} \Phi_h \, \varepsilon_{t-h}$, cu Φ_h răspunsul după h zile la un șoc de azi, $\Phi_{\mathbf{0}} = I$
- Șocurile ortogonale (Cholesky) depind de ordinea seriilor
  - descompunerea **generalizată** nu depinde de ea Koop, Pesaran & Potter (1996), Pesaran & Shin (1998)
  - $\theta_{ij}(H) = \dfrac{\sigma_{jj}^{-\mathbf{1}} \sum_{h=\mathbf{0}}^{H-\mathbf{1}} (e_i^\top \Phi_h \Sigma e_j)^{\mathbf{2}}}{\sum_{h=\mathbf{0}}^{H-\mathbf{1}} e_i^\top \Phi_h \Sigma \Phi_h^\top e_i}$, normalizat: $\tilde{\theta}_{ij} = \theta_{ij} / \sum_j \theta_{ij}$
  - Numărătorul: partea din dispersia erorii de prognoză a lui i datorată unui șoc în j
  - Numitorul: dispersia totală a acestei erori
  - e_i: al i-lea vector unitar
  - σ_{jj}: varianța șocului j

Tabelul conectivității

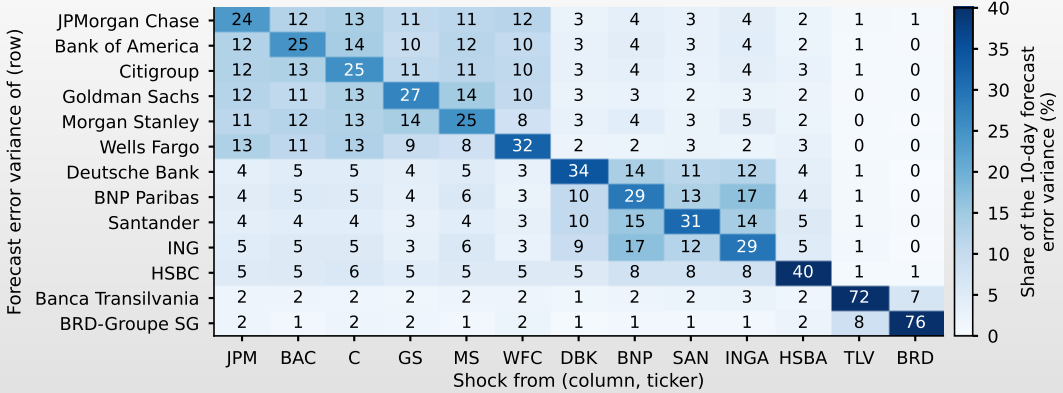
- $\tilde{\theta}_{ij}$ (în %): proporția din dispersia erorii de prognoză pe H zile a lui i datorată șocurilor lui j Diebold & Yilmaz (2014)
  - Fiecare linie însumează 100; înainte de normalizare nu, deoarece șocurile generalizate sînt corelate
- **De la** ceilalți: $F_i = \sum_{j \neq i} \tilde{\theta}_{ij}$
- **Către** ceilalți: $T_j = \sum_{i \neq j} \tilde{\theta}_{ij}$
- **Net**: $T_i - F_i$, pozitiv pentru un transmițător net
- **Net pe perechi**: $\tilde{\theta}_{ji} - \tilde{\theta}_{ij} > 0$ înseamnă că i transmite net către j
  - se desenează ca săgeată $i \to j$
- **Conectivitatea totală**: $C = \frac{1}{N} \sum_{i \neq j} \tilde{\theta}_{ij}$
  - proporția medie din dispersie care vine de la ceilalți

Anexă: exemplu cu două bănci

Volatilitatea Parkinson din range și VAR-ul celor treisprezece bănci

- **Volatilitatea Parkinson** din prețul maxim $P_t^{\max}$ și prețul minim $P_t^{\min}$ ale zilei Parkinson (1980)
  - $\hat{\sigma}_t^{\mathbf{2}} = \dfrac{(\ln P_t^{\max} - \ln P_t^{\min})^{\mathbf{2}}}{4 \ln 2}$, anualizată $100\sqrt{252\,\hat{\sigma}_t^{\mathbf{2}}}$, folosită în logaritm
  - Nedeplasată pentru o mișcare browniană fără drift și mai eficientă decît randamentul la pătrat
- Modelul nostru: VAR pe logaritmul volatilității celor 13 bănci
  - o volatilitate din range, ca în Demirer et al. (2018)
  - Volatilitatea, nu randamentul: crește brusc în crize, deci rețeaua ei arată pe unde se transmite stresul
  - Ordinul ales după criteriul informațional bayesian (BIC) este $p = 2$
  - Orizontul este $H = 10$ zile, ca în Diebold & Yilmaz (2012)
  - Băncile americane se închid după cele europene, iar lagurile VAR captează transmiterea din ziua următoare

Tabelul conectivității pentru treisprezece bănci (1/2)



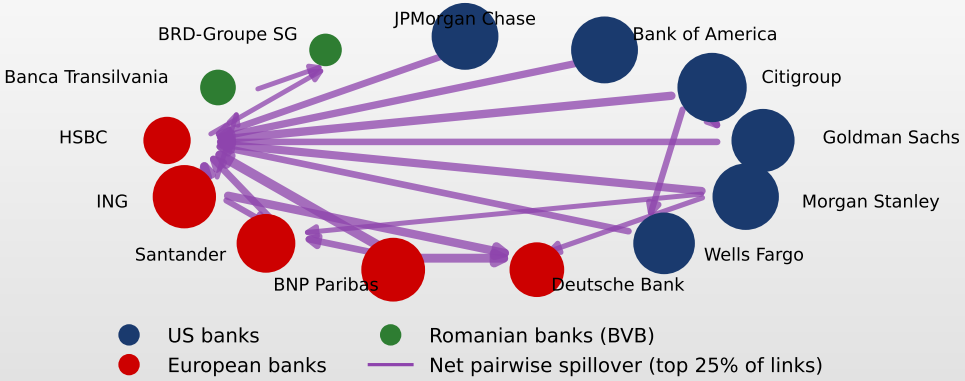
MFM_ch18_spillover

Tabelul conectivității pentru treisprezece bănci (2/2)

- Linia i, coloana j: proporția (%) din dispersia erorii de prognoză pe 10 zile a băncii i
  - datorată șocurilor băncii j, pe întreaga perioadă (simbolurile bursiere din tabelul datelor)
- Conectivitatea totală $C = 63{,}9\%$
  - în medie, două treimi din riscul de volatilitate al unei bănci provin de la celelalte
  - Pe randamente în loc de volatilitate: $C = 75{,}4\%$
- Două blocuri regionale
  - o bancă americană primește 84,0% din dispersie de la șocurile americane
  - una europeană primește 72,7% de la cele europene
  - Peste Atlantic: 26,2% de la băncile americane către o bancă europeană și 15,0% în sens invers
- Băncile românești: mai ales șocurile proprii
  - 72,3% (Banca Transilvania) și 76,1% (BRD)
  - De la băncile americane vine 10,3%, iar de la cele europene 8,0%

MFM_ch18_spillover

Rețeaua de spillover net (1/2)



Rețeaua de spillover net (2/2)

- Săgeată $j \to i$ cînd j transmite net către i (cele mai mari 25% dintre spillover-urile nete pe perechi)
- Mărimea nodului crește cu spillover-ul către ceilalți
- Transmițători neți: Citigroup (+19,0), Bank of America (+10,9)
  - Morgan Stanley (+9,9), JPMorgan (+9,8)
- Receptori neți: HSBC (−23,6), BRD (−13,0)
  - Deutsche Bank (−12,6), Banca Transilvania (−12,2)
  - HSBC primește de la aproape toate băncile: se tranzacționează la Londra, între Asia și New York
- În Europa, BNP Paribas și ING transmit către Deutsche Bank și Santander
- O rețea estimată pe întreaga perioadă face media anilor liniștiți și a celor de criză

MFM_ch18_spillover

Conectivitatea în timp (1/2)



MFM_ch18_spillover_rolling

Conectivitatea în timp (2/2)

- Sus: conectivitatea totală pe ferestre rolling de 250 de zile
  - VAR(2), $H = 10$, recalculată la fiecare 5 zile
- Jos: spillover-ul net însumat pe regiuni
- Indicele total variază între 47,4% (2024-07-24) și 79,3% (2020-08-27)
  - media: 62,0%
  - COVID-19: de la 61,8% în 2019 la 78,4% în primăvara lui 2020
  - După falimentele din 2023, 66,0%, iar în anul liniștit 2024, 53,5%
  - Indicele urcă în cîteva zile
  - Scăderea după aproximativ 250 de zile reflectă în parte ieșirea crizei din fereastră
- Băncile americane sînt transmițători neți în 89% dintre ferestre
  - suma spillover-urilor lor nete: în medie $+48{,}4$ puncte
- Băncile europene au fost transmițători neți în criza din zona euro din 2011–2012
  - după aceea, mai ales receptori neți
- Băncile românești sînt, în medie, receptori neți (în medie $-24{,}1$ puncte)

MFM_ch18_spillover_rolling

▸ Anexă: bootstrap, elastic net

Cît de strînse sînt legăturile dintre bănci în coadă?

- Rețeaua de spillover descrie un șoc mediu, iar riscul sistemic apare în coadă
- Financial Risk Meter (FRM) Mihoci, Althof, Chen & Härdle (2020): cîte o regresie cuantilă la $\tau = 5\%$ pentru fiecare firmă j
  - randamentul firmei pe **toate** celelalte firme și pe variabile macro întîrziate
  - Cu 100 de firme și 63 de zile sînt mai mulți regresori decît zile
  - Penalizarea LASSO păstrează doar legăturile puternice
  - FRM este media penalizărilor alese, un indicator al interdependenței din coadă și al stresului sistemic
- Întrebarea secțiunii: urmărește acest indicator stresul sistemic și pe cele 13 bănci ale noastre?

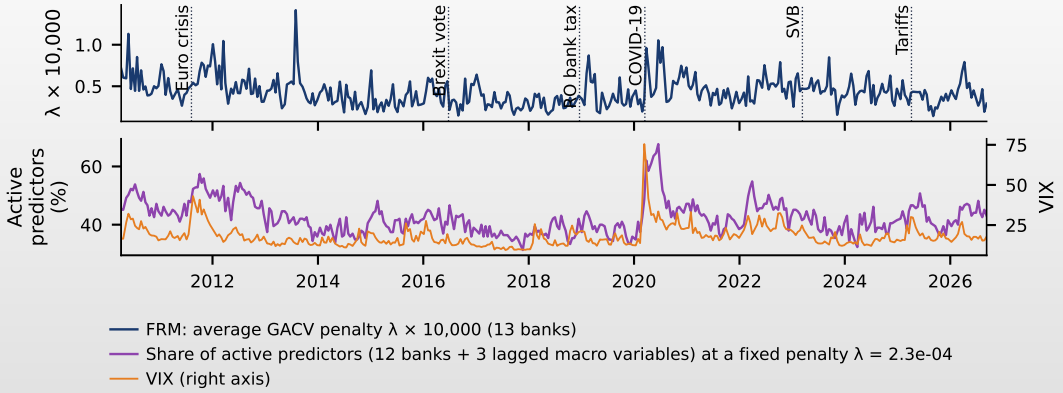
Financial Risk Meter și penalizarea GACV (1/2)

- Regresie cuantilă **LASSO** Belloni & Chernozhukov (2011)
  - LASSO: Least Absolute Shrinkage and Selection Operator, regresie penalizată L1
  - $\hat{\beta}_j(\lambda) = \arg\min_\beta \frac{1}{n} \sum_t \rho_\tau \left(X_{j,t} - \beta_{\mathbf{0}} - \beta^\top Z_{-j,t} \right) + \lambda \|\beta\|_{\mathbf{1}}$, pe cele n zile ale ferestrei
  - $X_{j,t}$: randamentul firmei j
  - $Z_{-j,t}$: randamentele celorlalte firme și variabilele macro întîrziate
  - Un λ mai mare lasă mai puțini coeficienți activi
- **GACV** echilibrează potrivirea cu numărul de coeficienți activi
  - GACV: Generalized Approximate Cross-Validation, validare încrucișată aproximativă generalizată
  - $\mathrm{GACV}(\lambda) = \frac{\sum_t \rho_\tau \left(X_{j,t} - \hat{X}_{j,t}(\lambda) \right)}{n - \mathrm{df}(\lambda)}$, cu $\hat{X}_{j,t}(\lambda)$ cuantila ajustată și df numărul coeficienților nenuli
  - λ_j ales minimizează GACV
  - FRM este media valorilor λ_j

Financial Risk Meter și penalizarea GACV (2/2)

- FRM a fost construit pentru firmele financiare americane Mihoci, Althof, Chen & Härdle (2020)
  - și pentru pieţele emergente Ben Amor, Althof & Härdle (2022) și China Wang, Althof & Härdle (2023)
  - Extensii: FRM bazat pe expectile Ren, Lu, Li & Härdle (2022), pentru criptomonede Ren, Althof & Härdle (2025) și pentru sectorul energetic din UE Toma, Dima, Grecu, Pele & Lessmann (2026)
- Versiunea noastră: 13 bănci
  - variabile macro: S&P 500, Euro Stoxx 50 și VIX la $t-1$
  - ferestre de 63 de zile, recalculate la fiecare 10 zile
  - $\tau = 5\%$ și ferestrele de 63 de zile, aproximativ un trimestru de tranzacționare, sînt cele din Mihoci, Althof, Chen & Härdle (2020)
  - 15 regresori pentru 63 de zile, mult mai puțini decît în FRM publicat

Financial Risk Meter pentru treisprezece bănci (1/2)



MFM_ch18_frm

Financial Risk Meter pentru treisprezece bănci (2/2)

- Graficul de sus: penalizarea GACV medie pe cele 13 bănci
  - 390 de ferestre de 63 de zile
  - Graficul de jos: proporția predictorilor activi la un λ fix, împreună cu VIX
- Penalizarea GACV medie este zgomotoasă: corelația cu VIX este doar 0,35
- La $\lambda = 2{,}3 \times 10^{-4}$ fix, proporția predictorilor activi urmează mai îndeaproape VIX (corelația 0,62)
  - Proporția variază de la 31% (2017-11-21) la 68% (2020-06-17), cu media 42%
- Lecția: pe acest panel mic, nicio măsură nu se dovedește un indicator fiabil al riscului sistemic
  - Numărul la penalizare fixă este doar o verificare exploratorie a sensibilității

MFM_ch18_frm

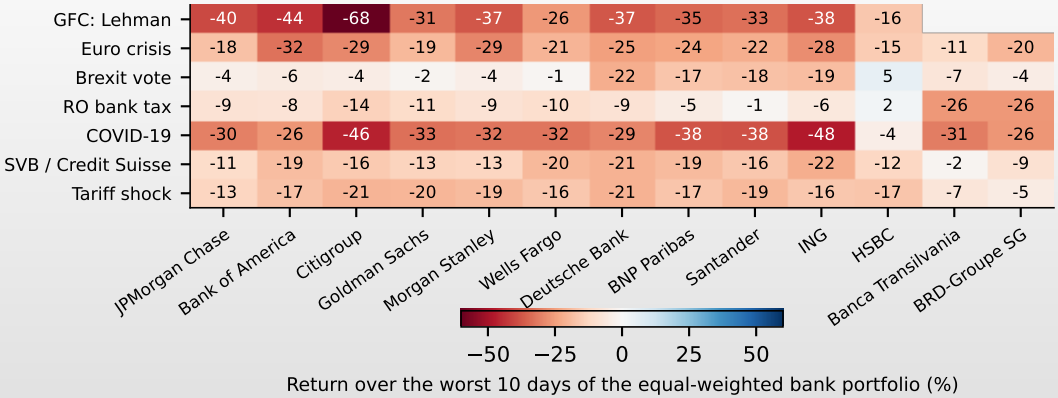
Cît s-ar pierde într-un scenariu sever, dar plauzibil? (1/2)

- Un **test de stres** aplică băncilor un scenariu sever, dar plauzibil, și măsoară pierderea
  - **Istoric**: reluăm o criză trecută
  - **Ipotetic**: aplicăm șocuri unor factori aleși
  - **Invers**: căutăm cel mai plauzibil scenariu din spatele unei pierderi date (de ex. una care ar face banca neviabilă)
  - Teste de supraveghere: Federal Reserve stress tests (SUA), European Banking Authority (UE)
  - Băncile de importanță sistemică globală: o listă de reglementare, pe baza unui scor al Comitetului de la Basel
  - Scorul: mărime, interconectare, substituibilitate, complexitate și activitate transfrontalieră
  - Ele dețin capital suplimentar Basel Committee (2018)

Cît s-ar pierde într-un scenariu sever, dar plauzibil? (2/2)

- Șapte episoade, fiecare o fereastră de cîteva săptămîni în jurul unui șoc cunoscut
  - Lehman (toamna lui 2008; în grafic „GFC": global financial crisis, criza financiară globală)
  - Criza din zona euro (vara lui 2011), votul Brexit (iunie 2016), taxa bancară din România (decembrie 2018)
  - COVID-19 (martie 2020), SVB și Credit Suisse (martie 2023), șocul tarifelor (aprilie 2025)
- În fiecare fereastră: **cele 10 zile consecutive de tranzacționare cu cel mai mic randament cumulat**
  - randamentul cumulat al portofoliului bancar cu ponderi egale
  - Raportăm randamentul fiecărei bănci în acest interval
  - Zece zile corespund orizontului riscului de piață (Capitolul 7)
  - Pentru 2008 folosim doar cele 11 bănci internaționale: seriile românești încep în 2010

Șapte scenarii istorice de stres (1/2)



MFM_ch18_stress

Șapte scenarii istorice de stres (2/2)

- Randamentul simplu (%) al fiecărei bănci în cele mai rele 10 zile consecutive ale portofoliului bancar
  - în fiecare episod: $100(e^{\sum_t r_t/\mathbf{100}} - 1)$
  - celulele goale indică lipsa datelor
- Pierderea portofoliului: Lehman 37,6% (2008-11-10 – 2008-11-21)
  - COVID-19 31,9%, criza din zona euro 22,3%
  - Șocul tarifelor 16,0%, SVB 14,8%, taxa bancară din România 10,2%, Brexit 7,9%
- Cele mai mari pierderi individuale: Citigroup −68% în 2008 (−114% ca randament log cumulat)
  - ING −48% în martie 2020
- Șocurile sînt și locale: Brexit a afectat mai ales băncile europene
- Taxa bancară a lovit cel mai puternic băncile românești (Banca Transilvania −26%, BRD −26%)
  - băncile americane au pierdut între 8% și 14%
- Un test de stres construit doar pe crize globale ar rata șocul politic intern

MFM_ch18_stress

Riscul climatic: riscul fizic și riscul de tranziție



Sediul Băncii Centrale Europene, Frankfurt, 2015

Foto: DXR (2015); CC BY-SA 4.0; Wikimedia Commons

- **Riscul fizic**: pierderi din inundații, secete, caniculă și furtuni
  - aceste evenimente afectează garanțiile și debitorii
- **Riscul de tranziție**: pierderi din trecerea la o economie cu emisii reduse
  - prețul carbonului, reglementare, tehnologie
- Riscuri de tip „lebădă verde": evenimente potențial extrem de perturbatoare
  - ar putea sta la baza următoarei crize financiare sistemice Bolton et al. (2020)
  - Modelele de risc bazate pe trecut nu le pot anticipa

Testul de stres climatic al BCE din 2022: rezultate

- La testul BCE din 2022 au participat 104 bănci semnificative
  - o proiecție bottom-up a pierderilor a acoperit 41 dintre ele ECB Banking Supervision (2022)
  - bottom-up: fiecare bancă aplică scenariile supraveghetorului pe propriile date și modele
- Aproximativ 60% dintre bănci nu aveau un cadru de testare la stres pentru riscul climatic
- Doar 20% țineau cont de riscul climatic la acordarea creditelor
- Pierderi de credit și de piață de aproximativ 70 de miliarde EUR pentru cele 41 de bănci
  - scenariile: o tranziție dezordonată pe termen scurt și două scenarii de risc fizic
  - BCE precizează că cifra subestimează semnificativ riscul
  - Cauze: lipsa datelor, modelele rudimentare și absența efectelor de ordinul al doilea

Limitele testelor de stres

- Scenariile sînt alese de oameni: criza care vine este rareori cea care a fost testată
- Efectele de ordinul al doilea sînt greu de modelat și de obicei lipsesc
  - fire sales, retrageri de finanțare, pierderi ale contrapărților
  - cum a observat BCE pentru testul său climatic
- Măsurile bazate pe piață (MES, CoVaR, conectivitate) reacționează repede, dar doar după ce prețurile se mișcă
  - testele de stres bazate pe bilanț evaluează riscurile viitoare, dar necesită mai mult timp
- Cercetarea despre semnalele de avertizare timpurie combină măsurile de piață cu datele din bilanț
  - de ex. măsurile de risc de piață bazate pe entropie Pele, Lazar & Dufour (2017)

Se schimbă rețeaua cu mărimea șocurilor?

- Ando, Greenwood-Nimmo & Shin (2022): se schimbă topologia unei rețele financiare cu **mărimea** șocurilor?
  - varianta lor a întrebării din Diebold & Yilmaz (2014): cît din incertitudinea viitoare a lui *i* vine din șocurile idiosincratice ale lui *j*, după mărimea șocului
- Conectivitatea din acest capitol se estimează la media condiționată
  - OLS, LASSO, elastic net Demirer et al. (2018)
  - descrie cum se propagă un șoc mediu
  - Șocurile sistemice sînt mai mari decît media
  - A citi creșterea conectivității rolling ca semnal de criză presupune că relațiile de la medie se mențin în cozi
- Legătura cu capitolul: regresia cuantilă folosită pentru CoVaR Adrian & Brunnermeier (2016), Koenker & Bassett (1978)
  - aplicată acum VAR-ului din care se descompune dispersia
  - Giglio, Kelly & Pruitt (2016): riscul sistemic deplasează coada stîngă a producției viitoare mai mult decît centrul ei
  - Ando, Greenwood-Nimmo & Shin (2022) pun aceeași întrebare, coadă față de centru, pentru rețeaua însăși
- Aplicația: interdependența dintre riscul de credit al statelor și cel al băncilor
  - salvările transferă riscul bancar către stat

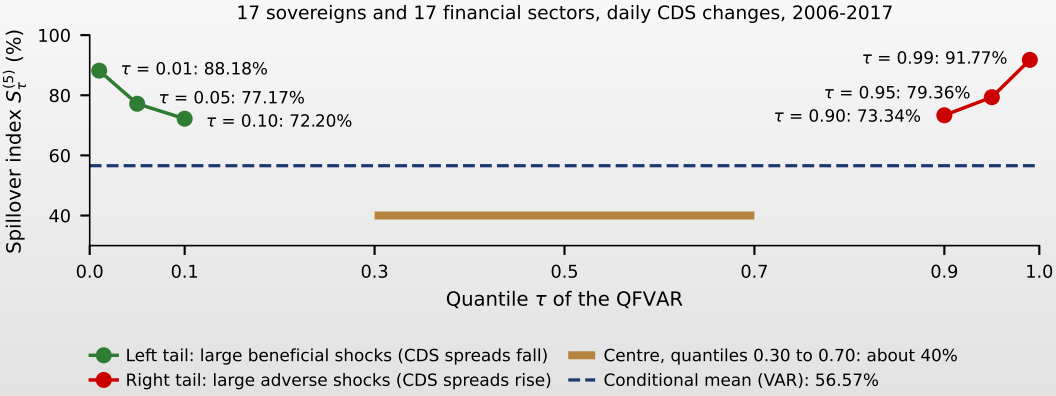
Datele CDS și VAR-ul cuantil cu factori

- Spread-ul CDS (credit default swap): prima anuală plătită pentru protecție împotriva neplății
  - neplata unui stat sau a unei bănci; prima se exprimă în puncte de bază (1 bp = 0,01%)
  - o creștere este o veste proastă
- Datele: diferențele zilnice ale spread-urilor CDS pe 5 ani
  - 17 state și 17 sectoare financiare naționale, $m = 34$ de serii
  - 3 129 de zile (3 ianuarie 2006 – 29 decembrie 2017)
- VAR cuantil cu factori (QFVAR): $y_t = \mu + \sum_{j=\mathbf{1}}^{p} \Phi_j y_{t-j} + \Gamma f_t + v_t$
  - fiecare ecuație estimată la cuantila τ prin funcția de pierdere cuantilă
  - y_t: cele m variații CDS; μ: constantele; Φ_j: matricile de coeficienți VAR; Γ: loadings pe factori
  - Factorii neobservați f_t preiau șocurile comune, deci v_t este idiosincratic
  - Numărul factorilor, după criteriul din Ando & Bai (2020): 10 la medie

Spillover și șocuri adverse de credit

- Descompunerea generalizată a dispersiei erorii de prognoză (FEVD) a șocurilor idiosincratice la cuantila τ
  - liniile sînt normalizate la 1
  - Indicele de spillover: $S_\tau^{(h)} = m^{-1} \sum_i F_{i\leftarrow\bullet,\tau}^{(h)}$
  - $F_{i\leftarrow\bullet,\tau}^{(h)}$: proporția din dispersia erorii de prognoză pe h zile a lui i care vine de la celelalte serii
  - Este măsura „de la" din tabelul conectivității
  - $S_\tau^{(h)}$ este media acestei proporții pe cele m serii
- Ferestre rolling de $w = 250$ de zile (2 880 de ferestre)
  - numărul factorilor este fixat la valoarea din întregul eșantion (specificația completă: Anexă)
  - Dependența relativă în cozi: $\mathrm{RTD} = S_{0,95}^{(5)} - S_{0,05}^{(5)}$
  - Pentru variațiile CDS, coada dreaptă ($\tau = 0{,}95$) conține șocurile adverse mari, iar coada stîngă ($\tau = 0{,}05$) pe cele favorabile mari

Spillover-ul pe cuantile (1/2)



Spillover-ul pe cuantile (2/2)

- Indicele de spillover $S_{\tau}^{(5)}$ pe întregul eșantion, la fiecare cuantilă τ
  - față de indicele la medie (sursa: Ando, Greenwood-Nimmo & Shin (2022))
- Profil în formă de U: circa 40% în centru, 88,18% la $\tau = 0{,}01$ și 91,77% la $\tau = 0{,}99$
  - Indicele la medie (56,57%) nu descrie niciun regim: prea mare pentru șocurile mici, prea mic pentru cele mari
- Pe întregul eșantion, cozi aproape simetrice: $\mathrm{RTD} = 79{,}36 - 77{,}17 = 2{,}19$ puncte
  - pe ferestre rolling asimetria este mai mare (Aprofundări)
- Pentru testele de stres: conectivitatea la medie subestimează spillover-ul dintr-o criză
  - subestimează cît din dispersia erorii de prognoză a unui sector vine, într-o criză, de la celelalte

MFM_ch18_quantile_connectedness

Anunță conectivitatea crizele sau doar urmează volatilitatea?

O întrebare de cercetare deschisă: risc sistemic sau doar volatilitate?

- Indicii de conectivitate sînt urmăriți ca instrumente de avertizare timpurie
  - dar un indice dintr-un VAR pe volatilități poate urma volatilitatea fără să adauge informație predictivă
  - Cercetare în curs: rețele din VAR-uri regularizate Demirer et al. (2018); conectivitatea în cozi diferă de cea la medie Ando, Greenwood-Nimmo & Shin (2022)
- Formularea statistică: $y_{t+h} = a + \beta_C C_t + \gamma \ln \sigma_t + e_{t+h}$, $H_0 : \beta_C = 0$, $H_1 : \beta_C > 0$
  - y_{t+h}: stresul viitor al băncilor; C_t: conectivitatea totală; σ_t: volatilitatea curentă
  - Dovezi împotriva lui H_1: intervalul de încredere (CI, confidence interval) pentru β_C exclude efectele relevante economic, nu simpla lipsă a semnificației
- Identificarea: o muchie este o proporție din dispersia erorii de prognoză, nu o expunere cauzală
  - Un șoc comun crește simultan volatilitatea și conectivitatea, fără ca vreo bancă să o contamineze pe alta

Bucla descoperirii, pas cu pas (1/2)

- **Literatura**: cartografiem ce se știe, apoi verificăm fiecare referință
  - Verificăm fiecare DOI (Digital Object Identifier) pe Crossref și ne asigurăm că articolul controlează efectiv pentru volatilitate
  - Căutăm cu Semantic Scholar, Elicit sau Google Scholar
- **Ipoteze**: interpretări concurente ale unei creșteri a conectivității, fiecare cu testul ei
  - Un șoc comun dispare odată cu volatilitatea
  - Contagion are o direcție: șocurile transmițătorilor neți le preced pe ale receptorilor
- **Date și cod**: replicăm întîi conectivitatea totală pe ferestre rolling
  - media 62,0% și maximul 79,3% (2020-08-27)

Bucla descoperirii, pas cu pas (2/2)

- **Robustețea**, fixată înainte de a rula regresiile predictive
  - Fiecare celulă a grilei este raportată
  - Familia de teste este corectată cu Holm sau controlată prin FDR (false discovery rate, rata descoperirilor false)
- **Critica**: îi cerem asistentului să atace rezultatul
  - Răspuns așteptat: adăugăm volatilitatea curentă ca variabilă de control, apoi testăm creșterea lui R^2 și a pierderii out-of-sample
- **Raportul**: efecte standardizate cu statistici t HAC, toate celulele grilei și ce a eșuat
  - HAC: heteroskedasticity and autocorrelation consistent, robuste la heteroscedasticitate și autocorelație
  - Prompturile care au influențat planul analizei sînt consemnate în `AI_USE.md` (prompturi reutilizabile și verificările cercetătorului: ▸ Anexă)

Mini studiu de caz: conectivitatea dincolo de volatilitate (1/2)

- Propunerea tipică a asistentului: „o conectivitate totală ridicată anunță stresul viitor al băncilor”
  - Testată pe 731 de observații săptămînale, între 2011 și 2026
  - y_{t+h}: logaritmul volatilității Parkinson medii a celor 13 bănci în următoarele $h = 63$ zile
  - Variabila de control: aceeași mărime în ultimele 20 de zile
  - Variabilele sînt standardizate, iar erorile standard Newey–West folosesc 13 laguri, deoarece ținta pe 63 de zile se suprapune pe aproximativ 13 săptămîni
- Conectivitatea singură: $\hat{\beta}_C = 0{,}40$ ($t = 4{,}63$), $R^2 = 0{,}16$
  - propunerea pare corectă

Mini studiu de caz: conectivitatea dincolo de volatilitate (2/2)

- Cu volatilitatea curentă: $\hat{\beta}_C = 0{,}08$ ($t = 0{,}75$), $\hat{\gamma} = 0{,}53$ ($t = 4{,}13$)
  - $R^2 = 0{,}343$, față de 0,339 doar cu volatilitatea
  - Corelația lui C_t cu volatilitatea: 0,59
  - Cu drawdown-ul maxim din următoarele 63 de zile ca variabilă dependentă: $\hat{\beta}_C = -0{,}10$ ($t = -1{,}32$), chiar cu conectivitatea ca unic regresor
- Interpretare: dată fiind volatilitatea curentă, conectivitatea nu adaugă conținut predictiv semnificativ
  - Nu dovedește că efectul este zero: în eșantionul nostru, persistența volatilității explică cea mai mare parte a conținutului predictiv
  - Informația de rețea poate conta totuși în cozi Ando, Greenwood-Nimmo & Shin (2022) sau pentru direcția transmiterii

Rîndul dumneavoastră: o idee de proiect (1/2)

- **Întrebarea**
  - prezice conectivitatea în **cozi** dificultățile băncilor dincolo de volatilitate, out-of-sample?
- **Replicați întîi**
  - Indicele nostru pe ferestre rolling: media 62,0% și maximul 79,3% (2020-08-27)
  - Tabelul de conectivitate cu șase grupuri din Demirer et al. (2018), pentru 2003–2014, cu explicația abaterilor
  - Datele de replicare sînt publicate de autori (journaldata.zbw.eu)
- **Extindeți**
  - Conectivitatea cuantilă la $\tau = 5\%$ Ando, Greenwood-Nimmo & Shin (2022), evaluată out-of-sample începînd din 2018
  - MES și SRISK ca ținte alternative

Importanța sistemică a băncilor (1/2)

Banca	VaR 1%	MES 5%	ΔCoVaR 1%	Spillover net	Λ^*
JPMorgan	4,83	3,22	4,62	9,8	7,0
Bank of America	5,99	3,85	4,60	10,9	6,2
Citigroup	5,87	4,03	3,81	19,0	6,0
Goldman Sachs	4,81	3,34	4,12	2,4	6,8
Morgan Stanley	5,83	4,04	4,00	9,9	6,0
Wells Fargo	5,78	3,32	4,89	3,6	6,8
Deutsche Bank	7,19	4,54	4,24	−12,6	6,1
BNP Paribas	6,18	4,53	4,84	6,0	6,1
Santander	5,83	4,23	4,42	−5,4	6,4
ING	7,16	4,81	4,42	5,2	5,8
HSBC	4,66	2,54	4,07	−23,6	8,3
Banca Transilvania	5,06	3,14	–	−12,2	6,5
BRD-Groupe SG	4,42	2,69	–	−13,0	7,1

- VaR și MES sînt pierderi zilnice în %
  - spillover-ul net al volatilității: „către ceilalți" minus „de la ceilalți"
  - Λ^*: leverage-ul de echilibru cu $k = 8\%$ și LRMES aproximat (criză de șase luni, piața -40%)
  - –: fără ΔCoVaR pentru cele două bănci românești, al căror „sistem" ar fi o singură bancă

Importanța sistemică a băncilor (2/2)

- Corelații de rang pe cele unsprezece bănci internaționale
  - MES și ΔCoVaR: $-0{,}01$
  - MES și spillover-ul net: $0{,}04$
  - ΔCoVaR și spillover-ul net: $-0{,}01$
  - Prin contrast, VaR și MES: $0{,}88$
- Nu există un clasament unic
  - supraveghetorii combină mai mulți indicatori cu mărimea și datele din bilanț, ca în metodologia Basel Committee (2018)
- Băncile românești au un MES moderat
  - sînt receptori neți de volatilitate
  - au un leverage de echilibru apropiat de cel al băncilor americane

Idei principale

- Riscul sistemic se manifestă în coada distribuției comune
  - expunere (MES, SRISK), contribuție (ΔCoVaR), conectivitate (rețele de spillover și rețele în coadă)
- Băncile din zona euro au cele mai mari MES din eșantionul nostru (4,2–4,8%)
- Băncile americane sînt principalii transmițători neți de volatilitate
- VaR și ΔCoVaR ordonează băncile diferit, iar clasamentele sînt incerte
  - testați diferențele, raportați intervale, precizați αn
- Măsurile bazate pe piață urcă brusc în crize
  - pentru acumularea riscului sînt necesare testele de stres și bilanțurile
- Băncile românești: mai ales șocurile proprii
  - primesc mai mult spillover de volatilitate decît transmit

Greșeli frecvente

- Interpretarea ΔCoVaR sau a unei muchii de spillover ca efect cauzal
  - un șoc comun produce același tipar
- Interpretarea intervalelor suprapuse drept „egale” și a celor separate drept „diferite”
  - Testăm diferența pe extrageri comune și corectăm pentru numărul de perechi (Holm și testul Wald comun)
- Includerea băncii în portofoliul sistemului
  - randamentul ei adaugă mecanic o autocontribuție
- Descompuneri ortogonale ale dispersiei ale căror rezultate depind de ordinea băncilor
- Raportarea SRISK fără bilanțuri sau a aproximării $1 - e^{-18\mathrm{MES}}$ ca măsură publicată
- Desenarea etichetelor nete fără intervale

LRMES prin GJR–GARCH și DCC: modelul

- Modelul Brownlees & Engle (2017): randamente log zilnice cu medie zero ale băncii și ale pieței
  - estimate în doi pași prin cvasi-verosimilitate maximă (QML, quasi-maximum likelihood)
- Volatilitatea: GJR–GARCH(1,1) Glosten, Jagannathan & Runkle (1993)
  - GARCH: heteroscedasticitate condiționată autoregresivă generalizată; GJR: Glosten, Jagannathan și Runkle
  - $\sigma_t^2 = \omega + (\alpha + \gamma\, 1\{r_{t-1} < 0\})\, r_{t-1}^2 + \beta\, \sigma_{t-1}^2$
  - $\gamma > 0$: reacția suplimentară după o scădere (leverage effect)
  - Aici α nu este nivelul cozii
- Corelația: DCC(1,1) (DCC: corelație condiționată dinamică) Engle (2002)
  - $Q_t = (1 - a - b)\, S + a\, \epsilon_{t-1} \epsilon_{t-1}^\top + b\, Q_{t-1}$, $\rho_t = Q_{12,t} / \sqrt{Q_{11,t} Q_{22,t}}$
  - $\epsilon_t = (r_{it}/\sigma_{it}, r_{mt}/\sigma_{mt})^\top$: randamentele standardizate
  - S: matricea corelațiilor lor empirice ($\bar{Q}$ în Engle (2002))
  - a măsoară reacția corelației, b persistența ei, iar ρ_t este corelația bancă–piață de azi

LRMES prin GJR–GARCH și DCC: simularea

- Simularea (detalii: Anexă)
  - Reeșantionăm **perechi** $(\xi_{it}, \epsilon_{mt})$: șocul standardizat al pieței și partea șocului băncii necorelată cu piața
  - Perechile păstrează tail dependence, pe care distribuția Normală nu o reproduce
  - Simulăm recursiile GARCH și DCC pe h zile, pornind de la σ^2 și ρ de azi
  - LRMES: minus media randamentului băncii pe traiectoriile de criză, cele cu $R_{m,t+\mathbf{1}:t+h} < C$
- Pe piață: 200 000 de traiectorii de 22 de zile ($C = -10\%$) și 400 000 de 126 de zile ($C = -40\%$)
  - date pînă la 2026-09-18
- Probabilitatea unei crize de 22 de zile: azi 1,3% (S&P 500), 4,3% (Euro Stoxx 50) și 4,0% (BET)
  - față de 12%, 19% și 8% pe 31 martie 2020

LRMES prin simulare: treisprezece bănci (1/2)

Banca	LRMES azi	interval 90%	LRMES 31.03.2020	ρ_T	Λ^* (22 de zile)
JPMorgan	10,6	$[-2, 25]$	23,7	0,53	11,3
Bank of America	14,3	$[-4, 35]$	23,2	0,44	10,9
Citigroup	13,0	$[-1, 28]$	32,8	0,54	11,0
Goldman Sachs	16,5	$[1, 34]$	25,0	0,65	10,6
Morgan Stanley	16,3	$[1, 32]$	27,2	0,65	10,6
Wells Fargo	6,7	$[-8, 24]$	22,9	0,32	11,7
Deutsche Bank	14,4	$[2, 28]$	25,7	0,66	10,8
BNP Paribas	15,6	$[2, 33]$	28,5	0,68	10,7
Santander	16,6	$[3, 34]$	26,4	0,76	10,6
ING	12,5	$[1, 27]$	32,9	0,68	11,1
HSBC	8,3	$[-2, 19]$	10,9	0,58	11,5
Banca Transilvania	12,4	$[-2, 34]$	17,2	0,74	11,1
BRD-Groupe SG	11,4	$[-2, 28]$	15,8	0,64	11,2

- LRMES (%): pierderea medie a băncii cînd piața scade sub -10% în 22 de zile Brownlees & Engle (2017)
  - intervalul de 90%: cuantilele de 5% și 95% ale pierderii băncii pe traiectoriile de criză; ρ_T: ultima corelație DCC
  - Λ^*: leverage-ul de echilibru cu $k = 8\%$, calculat din acest LRMES pe 22 de zile (necomparabil cu Λ^* din aproximare)

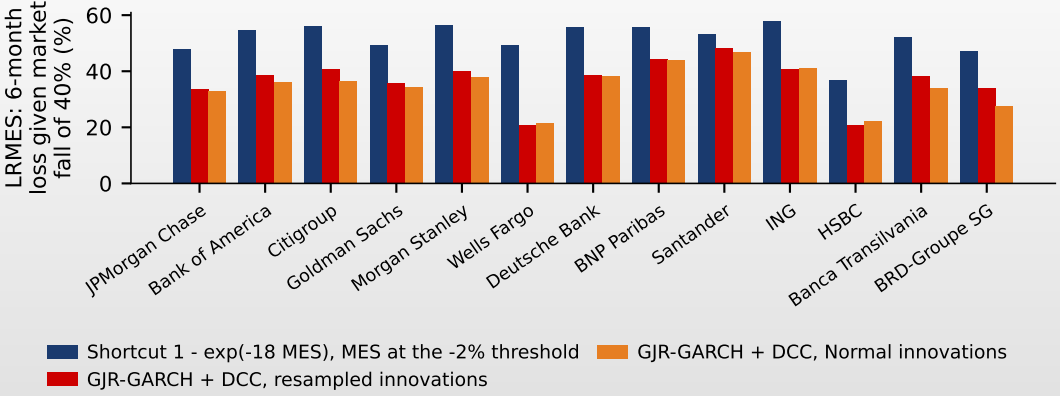
LRMES prin simulare: treisprezece bănci (2/2)

- LRMES este **condiționat**: variază odată cu volatilitatea și corelația de azi
  - JPMorgan: 10,6% azi, 23,7% cu informația din 31 martie 2020
  - Deutsche Bank: 14,4% și 25,7%
- Intervalul de 90% este larg Brownlees & Engle (2017)
  - LRMES este o medie pe traiectoriile de criză
  - Deficitul într-o criză anume poate fi mult mai mare
  - Intervalul descrie dispersia scenariilor, nu incertitudinea mediei estimate
- Scenariul, nu doar banca, stabilește nivelul
  - Pentru o criză de o lună, cu o scădere a pieței de 10%, LRMES este aproximativ o treime din valorile din Acharya, Engle & Richardson (2012)
  - Acolo valorile sînt pentru criza de șase luni, cu o scădere de 40%

Cum citim tabelul LRMES: intervale și scenarii

- Un capăt inferior negativ al intervalului de 90% nu este o eroare de semn
  - O pierdere negativă pe o traiectorie este un cîștig: pe cel puțin 5% dintre traiectoriile de criză, acțiunile băncii cresc în timp ce piața scade
  - Apare la o bancă slab corelată azi cu piața ei, de ex. Wells Fargo: $\rho_T = 0{,}32$, intervalul $[-8, 24]$
- Λ^* moștenește scenariul prin LRMES, deci îl comparăm doar în cadrul aceluiași scenariu
  - exemplu: JPMorgan, $k = 8\%$
  - Aproximarea, șase luni, piața -40%: LRMES 48%, $\Lambda^* = 7{,}0$
  - Simularea, 126 de zile, piața -40%: LRMES 33%, $\Lambda^* = 8{,}7$
  - Simularea, 22 de zile, piața -10%: LRMES 10,6%, $\Lambda^* = 11{,}3$

Riscul de model: LRMES în trei specificații (1/2)



MFM_ch18_srisk_sim

Riscul de model: LRMES în trei specificații (2/2)

- Criza de șase luni, cu piața la -40% Acharya, Engle & Richardson (2012)
  - aproximarea $1 - e^{-\mathbf{18}\mathrm{MES}^{\mathbf{2\%}}}$ față de simularea GJR–GARCH + DCC cu inovații reeșantionate sau Normale
- Raportul dintre LRMES simulat și aproximare: între 0,42 și 0,90
  - corelația de rang: 0,77
  - JPMorgan: 48% (aproximare), 33% (inovații reeșantionate), 33% (inovații Normale)
  - ING: 58%, 41%, 41%
  - Aproximarea folosește întreaga istorie, în timp ce simularea pornește de la volatilitatea de azi
- Inovații reeșantionate față de Normale: corelația de rang 0,95
  - Nivelurile diferă cel mai mult la Citigroup (40,8% față de 36,3%) și la BRD (34,1% față de 27,5%)
- Aceleași date, modele diferite și justificabile, cifre diferite: riscul de model Danielsson, James, Valenzuela & Zer (2016)

MFM_ch18_srisk_sim

CoVaR Girardi–Ergün: pierderi cel puțin egale cu VaR

- Girardi & Ergün (2013) condiționează pe o pierdere a băncii **cel puțin egală** cu VaR-ul ei
  - $P\left(X^{sys} \leq -\mathrm{CoVaR}^{\leqq}_{\alpha} \,\middle|\, X_i \leq -\mathrm{VaR}_{i,\alpha}\right) = \alpha \iff P\left(X^{sys} \leq -\mathrm{CoVaR}^{\leqq}_{\alpha}, X_i \leq -\mathrm{VaR}_{i,\alpha}\right) = \alpha^2$
  - Starea de referință din $\Delta\mathrm{CoVaR}^{\leqq}$: $|X_i - \mu_i| \leq \sigma_i$, în locul medianei
  - Mai jos comparăm doar niveluri
- Crește cu intensitatea dependenței
  - CoVaR condiționat de $X_i = -\mathrm{VaR}_{i,\alpha}$ nu face neapărat acest lucru Mainik & Schaanning (2014)
- Se poate face **backtesting**: evenimentul comun are probabilitatea α^2
- Estimarea istorică la $\alpha = 5\%$, pe cele 198 de zile cu $X_i \leq \hat{q}_{5\%}(X_i)$
  - JPMorgan 7,70%, față de 3,81% din regresia cuantilă
  - cele unsprezece bănci: 7,3–8,2%, față de 3,6–4,8%
  - Sub distribuția Normală această schimbare crește CoVaR doar moderat
  - Factorul doi indică abateri de la reperul Normal, fără să le identifice cauza

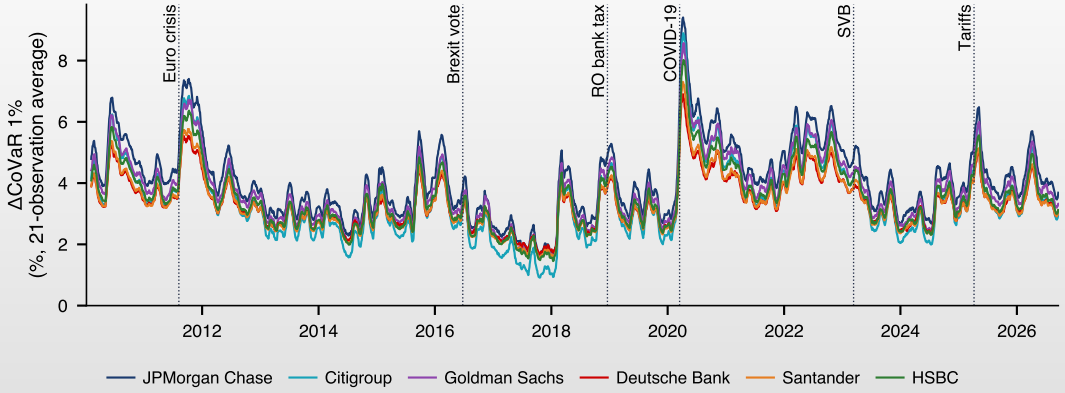
O verificare sub distribuția Normală: care CoVaR crește odată cu dependența?

- Distribuția Normală bivariată cu medii zero, $\sigma_{sys} = 1{,}5$, $\alpha = 1\%$, $z = -2{,}326$
  - banca se află la VaR, $X_i = -\mathrm{VaR}_{i,\alpha}$
  - Condiționat de bancă, sistemul are media $\rho\,\sigma_{sys} z$ și abaterea standard $\sigma_{sys}\sqrt{1-\rho^2}$
  - Deci $\mathrm{CoVaR}_\alpha = \sigma_{sys}|z|\left(\rho + \sqrt{1-\rho^2}\right)$, iar cu starea mediană $X_i = 0$, $\Delta\mathrm{CoVaR}_\alpha = \rho\,\sigma_{sys}|z|$
- De la $\rho = 0{,}6$ la $\rho = 0{,}9$: $\mathrm{CoVaR}_{1\%}$ scade de la 4,89% la 4,66%
  - pentru că $\rho + \sqrt{1-\rho^2}$ are maximul la $\rho = 0{,}71$
  - $\Delta\mathrm{CoVaR}_{1\%}$ crește de la 2,09% la 3,14%
- Lecția: nivelul CoVaR condiționat de $X_i = -\mathrm{VaR}_{i,\alpha}$ poate scădea cînd băncile devin mai interdependente
  - în timp ce ΔCoVaR și $\mathrm{CoVaR}^{\leq}$ cresc cu ρ Mainik & Schaanning (2014)

ΔCoVaR 1% în timp: variabile de stare

- Întrebarea: crește contribuția unei bănci în perioadele de stres?
- Cuantilele băncii depind de variabilele de stare M_{t-1} Adrian & Brunnermeier (2016)
  - M_{t-1}: log VIX, randamentul indicelui regional și randamentul sistemului, întîrziate cu o zi
  - $\Delta\mathrm{CoVaR}_{\alpha,t} = \hat{b}\left(\hat{q}_{50\%,t}(X_i) - \hat{q}_{\alpha,t}(X_i)\right)$, cu $\hat{q}_{\cdot,t}$ condiționat de M_{t-1} (Anexă)
- Panta $\hat{b}$ rămîne constantă: ΔCoVaR variază odată cu VaR-ul condiționat al băncii

ΔCoVaR 1% în timp (1/2)



MFM_ch18_covar_dynamic

ΔCoVaR 1% în timp (2/2)

- Șase bănci, medii rolling pe 21 de observații ale ΔCoVaR 1% zilnic
- JPMorgan: media 2,16% în 2017, media 9,06% în martie 2020
  - maximul: 10,99% pe 2020-03-18
  - Deutsche Bank: media 2,04% în 2017, media 6,65% în martie 2020
- Mic în perioadele calme, exact cînd riscul se poate acumula în bilanțuri
  - De aceea Adrian & Brunnermeier (2016) propun un ΔCoVaR anticipat, prognozat din leverage, mărime și nepotrivirea scadențelor
  - Nepotrivirea scadențelor: active pe termen lung finanțate cu datorii pe termen scurt, care trebuie refinanțate

MFM_ch18_covar_dynamic

Exemplu: tabelul conectivității pentru două bănci

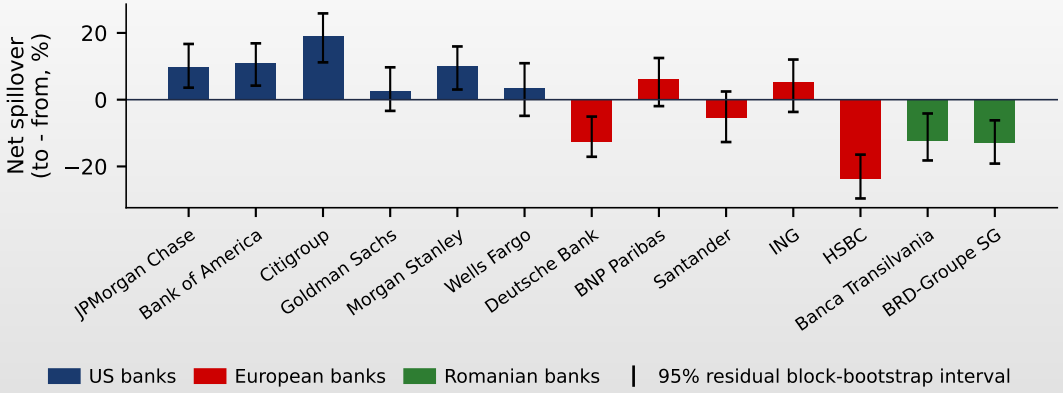
Banca i \ șocul j	1	2	F_i
1	80	20	20
2	40	60	40
T_j	40	20	

- Tabel normalizat ilustrativ $\tilde{\theta}_{ij}$ (%)
  - linia i: banca a cărei dispersie se împarte
  - coloana j: sursa șocului
  - liniile însumează 100
- Doar celulele din afara diagonalei
  - De la ceilalți: $F_1 = 20$, $F_2 = 40$ (sume pe linii)
  - Către ceilalți: $T_1 = 40$, $T_2 = 20$ (sume pe coloane)
- Net: banca 1 $40 - 20 = +20$ (transmițător), banca 2 -20
  - pozițiile nete însumează întotdeauna zero
- Total: $C = (20 + 40)/2 = 30\%$

Eroarea de estimare: cît de sigură este rețeaua?

- Întrebarea: care dintre etichetele „transmițător" și „receptor" rezistă erorii de estimare?
- Un VAR(1) pe 13 serii are 169 de coeficienți de pantă
  - VAR(2) folosit aici are $2 \times 169 = 338$
  - O fereastră de 250 de zile oferă 250 de observații pe ecuație pentru 26 de pante și o constantă
  - Tabelul conectivității este o funcție neliniară a tuturor coeficienților
- Bootstrap pe blocuri de reziduuri, 999 de extrageri
  - Reeșantionăm blocuri de 20 de zile din vectorii de reziduuri, reconstruim seriile cu VAR-ul estimat, reestimăm, recalculăm tabelul

Eroarea de estimare: intervale bootstrap pentru rețea (1/2)



MFM_ch18_spillover_uncertainty

Eroarea de estimare: intervale bootstrap pentru rețea (2/2)

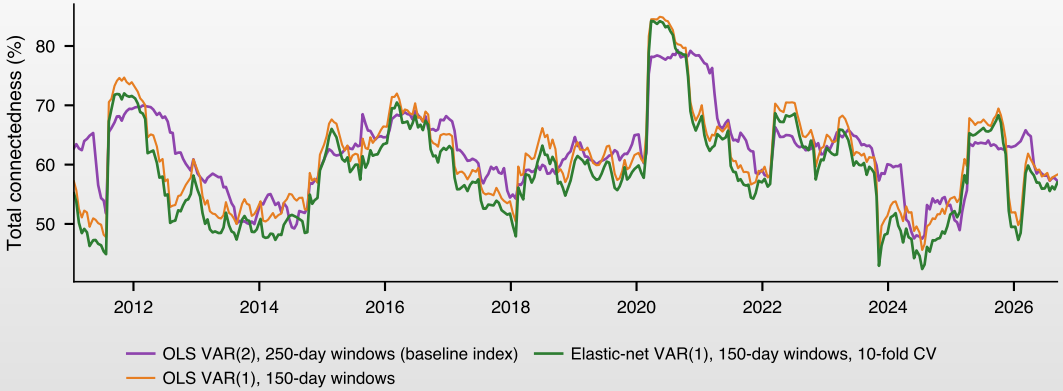
- Întreaga perioadă, $p = 2$: $C = 63{,}9\%$, interval de 95% $[59{,}9; 65{,}8]$
  - Fereastra cu valoarea maximă (pînă la 2020-08-27): $C = 79{,}3\%$, cu intervalul $[65{,}9; 83{,}0]$
  - Media bootstrap este 75,8%: în eșantioanele mici, și estimatorul lui C este deplasat
- 8 din 13 poziții nete au intervale care exclud zero
  - Pentru celelalte 5, eticheta „transmițător" sau „receptor" nu este identificată
  - Rețeaua de spillover net desenează cele mai mari 25% dintre legături, inclusiv unele nesemnificative
  - De aceea raportăm intervalele

MFM_ch18_spillover_uncertainty

Conectivitatea cu elastic net: depinde rețeaua de estimator?

- Un VAR(2) pe 13 serii are 338 de pante: pe ferestre scurte, OLS supraajustează
- Demirer et al. (2018): fiecare ecuație VAR prin elastic net adaptiv
  - pe ferestrele de 150 de zile, elastic net simplu
  - λ ales ecuație cu ecuație prin validare încrucișată cu 10 grupe, „10-fold CV" (cross-validation) în grafic (definiția în Anexă)
- Comparăm indicele de bază cu indicii pe ferestre de 150 de zile
  - pe aceleași date finale ale ferestrelor

Conectivitatea OLS și elastic net pe ferestre rolling (1/2)



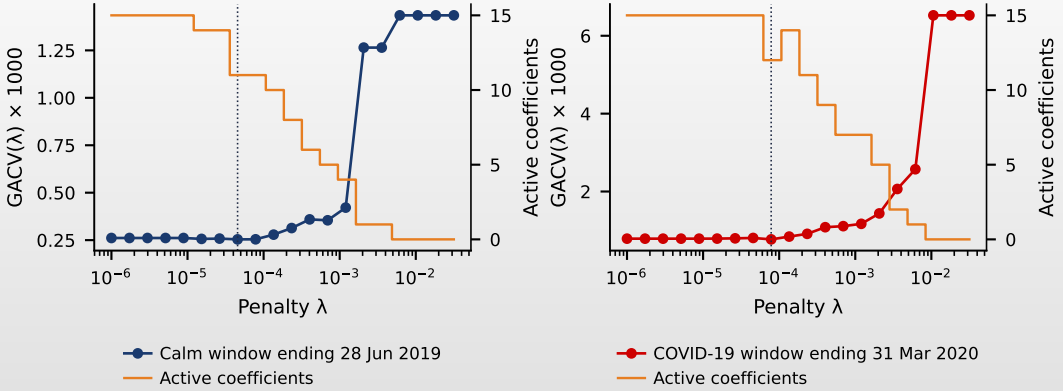
MFM_ch18_spillover_uncertainty

Conectivitatea OLS și elastic net pe ferestre rolling (2/2)

- Pe întreaga perioadă: $C = 63{,}3\%$ cu elastic net, față de 63,9% cu OLS
  - OLS: ordinary least squares, metoda celor mai mici pătrate
  - Cu elastic net, 59% dintre coeficienți sînt nenuli
- Medii pe 372 de date finale comune, cu pas de 10 zile de tranzacționare
  - indicele de bază (VAR(2) OLS, 250 de zile): 62,0%
  - VAR(1) OLS pe 150 de zile: 61,1%; VAR(1) elastic net pe 150 de zile: 58,7%
- Evoluțiile coincid: corelația dintre indicele elastic net și indicele de bază este 0,82
  - vîrfurile din crize apar în aceleași săptămîni
  - Nivelurile depind de fereastră, estimator și ordinul VAR
  - Schimbările în timp sînt robuste

MFM_ch18_spillover_uncertainty

GACV într-o fereastră calmă și într-una de criză (1/2)



MFM_ch18_frm

GACV într-o fereastră calmă și într-una de criză (2/2)

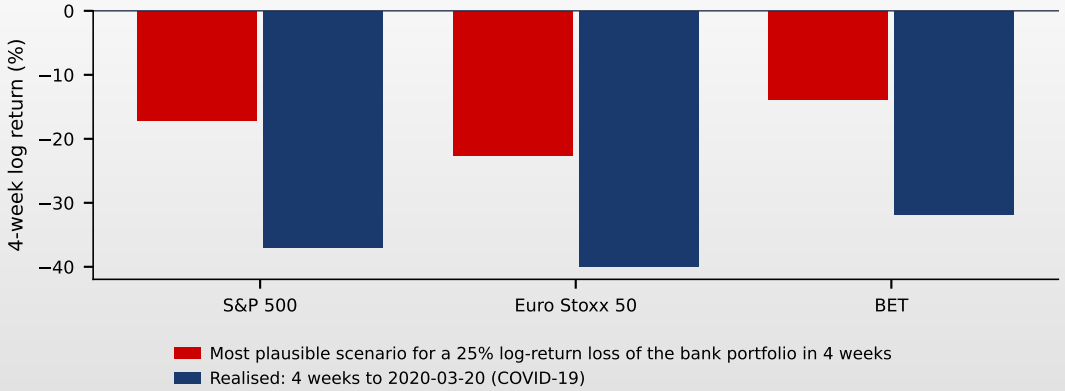
- Regresia lui JPMorgan pe celelalte 12 bănci și pe trei variabile macro întîrziate
  - fereastra are 63 de zile
  - Linia punctată marchează λ ales, iar cu portocaliu sînt coeficienții activi
- Fereastra calmă (pînă la 28 iunie 2019): $\hat{\lambda} = 4{,}5 \times 10^{-5}$, 11 din 15 coeficienți activi
- Fereastra COVID-19 (pînă la 31 martie 2020): $\hat{\lambda} = 7{,}8 \times 10^{-5}$, 12 coeficienți activi
- În criză, întreaga curbă GACV este de aproximativ trei ori mai sus
  - pierderea cuantilă este în unitățile randamentelor
- Cu puțini regresori, minimul se află aproape fără penalizare
  - alegerea este zgomotoasă

MFM_ch18_frm

Testarea inversă la stres

- Model factorial pentru randamentele log săptămînale (%): $X_i = \beta_i^\top f + e_i$
  - factorii f = (S&P 500, Euro Stoxx 50, BET)
  - Pe h săptămîni, $f \sim N(0, h\Sigma)$, cu Σ covarianța săptămînală a factorilor, fără covariațe seriale
- Pierderea portofoliului cu ponderi egale al celor 13 bănci: $L = -b^\top f$ (pierdere log, în %)
  - b: media valorilor β_i
  - reziduul $\sum_i w_i e_i$ este pus egal cu zero
- Cel mai plauzibil scenariu cu pierderea ℓ^*
  - minimizăm pătratul distanței Mahalanobis $f^\top (h\Sigma)^{-\mathbf{1}} f$ cu condiția $-b^\top f = \ell^*$
  - $f^* = -\ell^* \dfrac{h\Sigma\, b}{b^\top h\Sigma\, b}, \qquad d^* = \dfrac{\ell^*}{\sqrt{b^\top h\Sigma\, b}}$
  - d^*: pierderea țintă în abateri standard ale portofoliului
  - Un d^* mai mare înseamnă un scenariu mai puțin plauzibil (exemplu cu doi factori: Anexă)

Cel mai plauzibil scenariu pentru o pierdere log de 25% (1/2)



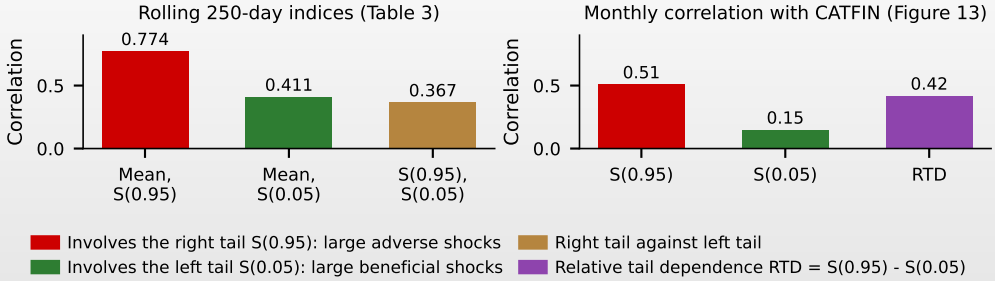
MFM_ch18_stress

Cel mai plauzibil scenariu pentru o pierdere log de 25% (2/2)

- Date săptămînale 2010–2026 (871 de săptămîni), orizont de patru săptămîni
  - patru săptămîni: durata fazei acute din martie 2020
  - Cu roșu: f^* pentru $\ell^* = 25\%$
  - Cu albastru: mișcările factorilor în cele mai rele patru săptămîni din 2020
- $b = (0{,}45;\ 0{,}65;\ 0{,}18)$
  - abaterea standard a portofoliului pe patru săptămîni este 5,79%
  - O pierdere log de 25% (aritmetică: 22,1%) cere simultan $-17{,}2\%$ (S&P 500), $-22{,}6\%$ (Euro Stoxx 50) și $-13{,}9\%$ (BET)
- $d^* = 4{,}31$
  - sub distribuția Normală, probabilitatea unei asemenea pierderi pe patru săptămîni este $8{,}0 \times 10^{-6}$
  - Totuși, în cele patru săptămîni pînă la 2020-03-20, portofoliul a pierdut 52,0% în termeni log (modelul factorial dă 48,5%)
- Forma scenariului este informativă, probabilitatea lui nu
  - cozile grele și corelațiile care cresc fac probabilitățile Normale mult prea mici

MFM_ch18_stress

Cozile evoluează diferit (1/2)



- Graficul din stînga: corelațiile dintre indicii pe ferestre rolling ($w = 250$ de zile, $h = 5$)
- Graficul din dreapta: corelațiile lunare cu CATFIN (sursa: Ando, Greenwood-Nimmo & Shin (2022))
- CATFIN: media a trei estimări VaR 1% pentru acțiunile financiare Allen, Bali & Tang (2012)

MFM_ch18_quantile_connectedness

Cozile evoluează diferit (2/2)

- Indicele la medie urmează coada adversă mult mai mult decît coada favorabilă
  - corelația 0,774 cu $S_{0,95}$, față de corelația 0,411 cu $S_{0,05}$
  - O creștere a conectivității la medie este mai ales o intensificare a transmiterii șocurilor adverse
- Cele două cozi au puțină variație comună (corelația dintre ele este 0,367)
  - Doi indicatori, nu același indice măsurat de două ori
  - De aceea RTD este informativ: circa ± 15 puncte pe ferestre rolling, față de 2,19 pe întregul eșantion
- Corelația cu CATFIN: 0,51 pentru $S_{0,95}$, 0,42 pentru RTD, doar 0,15 pentru $S_{0,05}$
  - CATFIN evoluează mai mult cu transmiterea șocurilor adverse decît cu a celor favorabile (legăturile bilaterale slabe și RTD în timp: Anexă)

Extindere pe cele 13 bănci: specificație și întrebări deschise

- Datele cursului: prețurile zilnice de închidere ale celor 13 bănci, 2010–2026
  - $y_t = -r_t$ (%), astfel încît coada dreaptă să fie cea adversă, ca la CDS
  - Limite: acțiuni în loc de CDS, niciun stat ($m = 13$ în loc de 34), ore de închidere diferite în SUA, Europa și România
- Limitele precizate de autori
  - ordinul VAR ales la medie este păstrat la fiecare cuantilă
  - cuantila rămîne fixă pe orizont (alte limite: Anexă)
- Extindere deschisă
  - Crește RTD al celor 13 bănci înainte de martie 2020 și de falimentele bancare din martie 2023?
  - Anticipează stresul bancar dincolo de volatilitatea curentă și de indicele bazat pe medie din acest capitol?
  - Pentru prognoză, ordinul VAR și numărul de factori se aleg doar pe un eșantion de antrenare

Rîndul dumneavoastră: o idee de proiect (2/2)

- **Livrabile**
  - O grilă de specificații fixată în scris înainte de regresii
  - Un notebook care regenerează fiecare cifră
  - Inferență HAC și pierderi out-of-sample pentru fiecare celulă
- **Jurnalul AI** (șabloane)
  - `AI_USE.md`: prompturile care au influențat metodologia
  - `AI_ERRORS.md`: fiecare afirmație greșită (un VAR pe nivelurile prețurilor, statistici t OLS pe ferestre suprapuse) și testul care a depistat-o

MES ca contribuție Euler: demonstrație (1/2)

- Portofoliul $X_p = \sum_i w_i X_i$ are distribuție continuă
  - expected shortfall-ul lui este $\mathrm{ES}_\alpha(X_p) = -\mathbb{E}[X_p \mid X_p \leq q_\alpha(X_p)]$
  - ES_α este pozitiv omogen de gradul 1 în w, deci din teorema lui Euler $\mathrm{ES}_\alpha(X_p) = \sum_i w_i \, \partial \mathrm{ES}_\alpha / \partial w_i$
  - Scriem $\mathrm{ES}_\alpha = -\frac{1}{\alpha}\mathbb{E}\left[X_p 1\{X_p \leq q_\alpha(w)\}\right]$, unde f_p este densitatea lui X_p
  - Derivata are un termen interior și unul de frontieră:
    $$\frac{\partial}{\partial w_i}\mathbb{E}[X_p 1\{X_p \leq q_\alpha\}] = \mathbb{E}[X_i 1\{X_p \leq q_\alpha\}] + q_\alpha f_p(q_\alpha)\left(\frac{\partial q_\alpha}{\partial w_i} - \mathbb{E}[X_i \mid X_p = q_\alpha]\right)$$
  - Derivata cuantilei este $\partial q_\alpha / \partial w_i = \mathbb{E}[X_i \mid X_p = q_\alpha]$ Gouriéroux, Laurent & Scaillet (2000), deci termenul de frontieră este zero
  - Deci $\partial \mathrm{ES}_\alpha / \partial w_i = -\mathbb{E}[X_i \mid X_p \leq q_\alpha(X_p)] = \mathrm{MES}_{i,\alpha}$ cu $m = p$ Gouriéroux, Laurent & Scaillet (2000), Scaillet (2004)

înapoi

MES ca contribuție Euler: demonstrație (2/2)

- Verificare pe datele noastre: portofoliul cu ponderi egale al celor șase bănci americane
  - $\alpha = 5\%$ (198 de zile în coadă)
  - $\mathrm{ES}_{5\%}$ al portofoliului, 4,32%, este egal cu media celor șase MES condiționate pe portofoliu, 4,32%
  - Identitatea este exactă și pentru estimatorul istoric
  - Condiționînd pe S&P 500 obținem un MES mediu de 3,63%
  - Pentru JPMorgan: 3,22% condiționînd pe S&P 500, față de 3,85% condiționînd pe portofoliu
  - Identitatea nu mai este valabilă cînd $m \neq p$
- Sub distribuția Normală bivariată cu medii zero, $\mathrm{MES}_{i,\alpha} = \beta_i \, \mathrm{ES}_\alpha(X_m)$: un beta înmulțit cu o constantă

Înapoi

Simularea LRMES: inovații și recursii

- Reziduurile standardizate $\epsilon_{it} = r_{it}/\sigma_{it}$, $\epsilon_{mt} = r_{mt}/\sigma_{mt}$
  - S, matricea corelațiilor lor empirice, este ținta pe termen lung a lui Q_t
  - Inovația băncii ortogonală față de piață: $\xi_{it} = (\epsilon_{it} - \rho_t\,\epsilon_{mt})/\sqrt{1-\rho_t^2}$ Brownlees & Engle (2017)
- În fiecare zi simulată s extragem o dată istorică τ și reconstruim șocul băncii cu corelația **simulată**
  - $\epsilon_{i,t+s} = \rho_{t+s}\,\epsilon_{m\tau} + \sqrt{1-\rho_{t+s}^2}\,\xi_{i\tau}$, apoi actualizăm σ^2 și Q cu noile randamente
- GJR–GARCH: $\omega > 0$, $\alpha \geq 0$, $\alpha + \gamma \geq 0$, $\beta \geq 0$, $\alpha + \gamma/2 + \beta < 1$
  - ultima condiție: dispersie finită pentru inovații simetrice
  - în general, condiția este $\alpha + \gamma\,\mathbb{E}[\epsilon^2 1\{\epsilon < 0\}] + \beta < 1$
- DCC: $a, b > 0$, $a + b < 1$, deci Q_t rămîne pozitiv definită
- Inițializarea: $Q_1 = S$ la estimare
  - simularea pornește de la σ^2_{T+1} și Q_{T+1} filtrate pînă la ultima dată

Înapoi

Regresia cuantilă: asimptotica

- Asimptotica pentru α fix, cu $\hat{\theta}_\alpha = (\hat{a}_\alpha, \hat{b}_\alpha)^\top$
  - n zile, $x_t = (1, X_{i,t})^\top$, iar f_t este densitatea condiționată a lui Y în cuantila de ordin α
  - $\sqrt{n}(\hat{\theta}_\alpha - \theta_\alpha) \Rightarrow N\left(0,\ \alpha(1-\alpha)\, D_{\mathbf{1}}^{-\mathbf{1}} D_{\mathbf{0}} D_{\mathbf{1}}^{-\mathbf{1}}\right)$, $D_{\mathbf{0}} = \mathbb{E}[x_t x_t^\top]$, $D_{\mathbf{1}} = \mathbb{E}[f_t\, x_t x_t^\top]$
  - Presupune observații independente (sau scoruri $x_t(\alpha - 1\{u_t < 0\})$ de tip diferență de martingal), $f_t > 0$ în jurul cuantilei și $D_{\mathbf{0}}$, $D_{\mathbf{1}}$ pozitiv definite
  - Cu scoruri dependente serial, $D_{\mathbf{0}}$ cere o estimare de termen lung (HAC) sau un bootstrap pe blocuri
  - **Inversa densității** $1/f_t$ trebuie estimată (nucleu sau lățime de bandă)
  - La $\alpha = 1\%$ puține observații sînt aproape de cuantilă, deci această estimare este zgomotoasă
- Panta b_α se poate schimba cu α
  - banca poate conta mai mult pentru sistem în coadă decît în centru

Înapoi

Cuantile extreme: dificultatea estimării la $\alpha = 1\%$

- La $\alpha = 1\%$ rămîn în coadă doar $\alpha n = 40$ de zile
  - aproximarea Normală, care presupune $\alpha n \to \infty$, poate fi imprecisă
  - Teoria cuantilelor extreme (limite de valori extreme, subeșantionare) este alternativa construită pentru acest caz Chernozhukov & Fernández-Val (2011)
- Eroarea standard bootstrap pe blocuri a ΔCoVaR 1% este de circa 0,6 ori cea bazată pe nucleu
  - în datele noastre, mediana pe bănci
  - Nucleul estimează inversa densității din puținele observații din jurul cuantilei
  - Bootstrap-ul reextrage aceleași puține zile: niciuna dintre metode nu este fiabilă
- Regulă practică: raportăm $\alpha = 5\%$ și $\alpha = 1\%$ împreună cu αn
  - clasamentul de 1% este mai zgomotos
  - Corelația Spearman mică dintre clasamentele de 1% și 5% (0,10) poate reflecta zgomotul de estimare, diferențe reale între cele două niveluri sau ambele

Înapoi

Testarea ΔCoVaR: trei ipoteze

- (1) H_0 : $b_\alpha = 0$ (nicio contribuție)
  - Testele ipotezelor liniare între cuantile folosesc asimptotica comună a lui $(\hat{b}_\alpha, \hat{b}_{50\%})$ Koenker & Bassett (1982)
- (2) H_0 : $b_\alpha = b_{50\%}$
  - dispersia lui $\hat{b}_\alpha - \hat{b}_{50\%}$ din 999 de extrageri bootstrap pe blocuri suprapuse
  - perechile de zile sînt păstrate împreună
- (3) H_0 : $\Delta\mathrm{CoVaR}_i = \Delta\mathrm{CoVaR}_j$ (contribuții egale)
  - $z_{ij} = (\Delta\widehat{\mathrm{CoVaR}}_i - \Delta\widehat{\mathrm{CoVaR}}_j)/\widehat{\mathrm{se}}^*$ pentru fiecare pereche, cu $\widehat{\mathrm{se}}^*$ eroarea standard bootstrap a diferenței
  - Corecția Holm (1979) pe familia de perechi
  - Un test Wald comun al egalității tuturor contribuțiilor

Înapoi

Testarea ΔCoVaR 1%: rezultate

Banca	ΔCoVaR	$\hat{b}_{1\%}$	t	$\hat{b}_{50\%}$	$\hat{b}_{1\%} - \hat{b}_{50\%}$	p
JPMorgan	4,62	0,94	6,9	0,96	−0,02	0,66
Bank of America	4,60	0,76	6,5	0,78	−0,02	0,73
Citigroup	3,81	0,64	4,7	0,76	−0,11	$< 0{,}001$
Goldman Sachs	4,12	0,85	5,6	0,84	0,00	0,99
Morgan Stanley	4,00	0,68	4,5	0,73	−0,05	0,28
Wells Fargo	4,89	0,84	4,3	0,78	0,06	0,17
Deutsche Bank	4,24	0,59	4,1	0,60	−0,02	0,67
BNP Paribas	4,84	0,77	6,5	0,74	0,03	0,37
Santander	4,42	0,75	4,5	0,69	0,07	0,07
ING	4,42	0,61	4,4	0,71	−0,10	0,002
HSBC	4,07	0,87	4,0	0,86	0,01	0,96

- t: $\hat{b}_{1\%}$ împărțit la eroarea sa standard sandviș estimată prin nucleu
  - valid doar pentru scoruri independente serial
- p: p-value-ul testului $b_{1\%} = b_{50\%}$
  - din $z = (\hat{b}_{1\%} - \hat{b}_{50\%})/\widehat{\text{se}}^*$ cu eroarea standard bootstrap $\widehat{\text{se}}^*$ și aproximarea Normală
- Testele pe perechi și testele Wald comune sînt pe slide-ul principal

înapoi

ΔCoVaR variabil în timp, cu variabile de stare

- Variabile de stare M_{t-1} Adrian & Brunnermeier (2016)
  - log VIX, randamentul indicelui regional și al sistemului, toate întîrziate cu o zi
  - $q_\alpha(X_{i,t} \mid M_{t-1}) = a_i + c_i^\top M_{t-1}$ la α și la 50% (a_i, c_i: termenul liber și coeficienții regresiei cuantile a băncii)
  - $q_\alpha(X_t^{sys} \mid X_{i,t}, M_{t-1}) = a + b X_{i,t} + c^\top M_{t-1}$
- Apoi $\Delta\mathrm{CoVaR}_{\alpha,t} = \hat{b}\left(\hat{q}_{50\%,t}(X_i) - \hat{q}_{\alpha,t}(X_i)\right)$
  - Variază odată cu VaR-ul condiționat al băncii, care depinde de VIX
- Panta $\hat{b}$ este constantă: variația în timp vine din stare, nu din legătură

Înapoi

Backtesting pentru CoVaR și MES (1/2)

- Măsurile sistemice sînt măsuri de risc condiționate
  - deci au nevoie de **backtesting condiționat** Banulescu-Radu, Hurlin, Leymarie & Scaillet (2021)
  - Pentru $\mathrm{CoVaR}^{\leq}$: evenimentul $I_t = 1\{X_t^{sys} \leq -\mathrm{CoVaR}_t^{\leq},\ X_{i,t} \leq -\mathrm{VaR}_{i,t}\}$
  - Sub H_0, $P(I_t = 1) = \alpha^2$ dacă atît VaR-ul băncii, cît și cuantila condiționată sînt calibrate
  - Testul Kupiec verifică dacă frecvența evenimentelor este α^2
  - Cu x evenimente în n zile și $\hat{\pi} = x/n$, $\mathrm{LR}_{\mathrm{POF}} = -2\ln \dfrac{(1-\alpha^2)^{n-x}(\alpha^2)^x}{(1-\hat{\pi})^{n-x}\hat{\pi}^x} \sim \chi^2_1$ sub H_0 (Capitolul 8)
  - Testul Christoffersen verifică în plus independența evenimentelor: un eveniment azi nu trebuie să facă mai probabil unul mîine
  - VaR-ul băncii se verifică separat, cu rata lui de depășire α
  - Pentru MES: procesul cumulat al depășirilor comune din Banulescu-Radu, Hurlin, Leymarie & Scaillet (2021)

Înapoi

Backtesting pentru CoVaR și MES (2/2)

- Verificarea noastră out-of-sample: $\mathrm{CoVaR}^{\leq}_{5\%}$ istoric pe o fereastră în expansiune
  - începînd cu ziua 1 000, cu 2 960 de zile de prognoză pentru fiecare bancă
  - Numărul așteptat de evenimente comune: 7,4
  - Numărul observat: între 5 și 9 pentru cele unsprezece bănci (JPMorgan: 9)
  - Cel mai mic p Kupiec este 0,35: nicio respingere
  - Puterea este limitată: dacă rata comună reală ar fi dublul lui α^2, testul Kupiec de 5% ar respinge în 62% din eșantioanele de această lungime cu evenimente independente
  - Deci chiar și o dublare este ratată aproximativ o dată din trei

Înapoi

Ipotezele VAR și numărul de laguri al indicelui pe ferestre rolling

- VAR(p) din De la perechi la rețele
  - Ipoteze: VAR stabil (rădăcinile lui $\det(I - \sum_l A_l z^l)$ în afara cercului unitate), ε_t necorelate serial, cu Σ finită și pozitiv definită
  - Reprezentarea de tip medie mobilă: $y_t = \mu + \sum_{h \geq \mathbf{0}} \Phi_h \varepsilon_{t-h}$, $\Phi_{\mathbf{0}} = I$, $\Phi_h = \sum_{l=\mathbf{1}}^{p} A_l \Phi_{h-l}$ ($\Phi_h = 0$ pentru $h < 0$)
  - e_i: al i-lea vector unitar
- Numărul de laguri: în toate ferestrele păstrăm $p = 2$, ordinul ales de BIC pe întreaga perioadă
  - Pe ferestre, BIC alege $p = 1$ în 100% dintre cazuri, iar cu $p = 1$ indicele are corelația 0,99 cu cel prezentat

Înapoi

VAR-uri regularizate: elastic net

- Demirer et al. (2018): fiecare ecuație VAR prin elastic net adaptiv
  - λ ales ecuație cu ecuație prin validare încrucișată cu 10 grupe
  - $\hat{\beta} = \arg\min_\beta \sum_t \left(y_t - \sum_i \beta_i x_{it}\right)^2 + \lambda \sum_i w_i \left(\frac{1}{2}|\beta_i| + \frac{1}{2}\beta_i^2\right)$, $w_i = 1/|\hat{\beta}_{i,\mathrm{OLS}}|$
  - w_i: ponderi adaptive, mai mari pentru coeficienții mici în OLS
  - Partea $|\beta_i|$ anulează coeficienți, iar partea β_i^2 îi micșorează
  - Pe ferestrele rolling de 150 de zile: elastic net simplu, $w_i = 1$, cu $p = 1$ (ordinul ales de BIC în 100% dintre ferestre) și $H = 10$
- Motivația: selecție și shrinkage pentru coeficienții VAR
  - fără a impune o **rețea** rară (legăturile vin și prin Σ)
- Pe întreaga perioadă păstrăm ordinul BIC al VAR-ului OLS, $p = 2$
- Cu aproximativ 4 000 de zile penalizarea aproape că nu contează
  - contează însă în ferestrele scurte

Înapoi

Rețele de cauzalitate Granger și testarea multiplă (1/2)

- Billio, Getmansky, Lo & Pelizzon (2012) desenează o muchie $j \to i$ cînd j cauzează în sens Granger variabila i la 5%
  - cu 13 bănci rezultă $13 \times 12 = 156$ de teste
  - j cauzează Granger pe i dacă trecutul lui j îmbunătățește prognoza lui i
  - În $X_{i,t} = c + aX_{i,t-\mathbf{1}} + gX_{j,t-\mathbf{1}} + u_t$ testăm $H_{\mathbf{0}} : g = 0$
  - Chiar fără nicio legătură, aproximativ 7,8 muchii ar apărea din întîmplare
- Testele noastre: regresii bivariate, un lag, statistici Wald robuste la heteroscedasticitate
  - Randamente zilnice: 57 de muchii semnificative la 5%, 33 după corecția Holm (1979), 55 cu rata descoperirilor false controlată la 5% Benjamini & Hochberg (1995)
  - Logaritmul volatilității, foarte persistent: adăugăm un lag suplimentar netestat Toda & Yamamoto (1995), ca în testele cu laguri suplimentare din Shi, Hurn & Phillips (2020)
  - Rezultă 153 de muchii la 5%, 150 după Holm și 153 cu rata descoperirilor false controlată la 5%

Înapoi

Rețele de cauzalitate Granger și testarea multiplă (2/2)

- Holm controlează probabilitatea oricărei muchii false pentru orice dependență
- FDR (false discovery rate) este proporția **așteptată** a muchiilor false printre cele desenate
  - procedura BH (Benjamini–Hochberg) o garantează pentru teste independente Benjamini & Hochberg (1995)
  - dar testele pe perechi de bănci suprapuse sînt dependente
- Randamente zilnice ale unor bănci din fusuri orare diferite
  - multe muchii „cauzale" arată doar că New York se închide după Frankfurt

Înapoi

Exemplu rezolvat: test invers de stres cu doi factori

- Coeficienții beta $b = (1{,}2;\ 0{,}8)$, pierderea țintă $\ell^* = 20\%$
  - covarianța pe patru săptămîni $h\Sigma = \begin{pmatrix} 16 & 6 \\ 6 & 9 \end{pmatrix}$ (%²)
  - $h\Sigma\, b = (1{,}2 \cdot 16 + 0{,}8 \cdot 6;\ 1{,}2 \cdot 6 + 0{,}8 \cdot 9) = (24;\ 14{,}4)$
  - $b^\top h\Sigma\, b = 1{,}2 \cdot 24 + 0{,}8 \cdot 14{,}4 = 40{,}32$, abaterea standard 6,35%
- Cel mai plauzibil scenariu: $f^* = -20 \cdot (24;\ 14{,}4)/40{,}32 = (-11{,}9\%;\ -7{,}1\%)$, $\quad d^* = 20/6{,}35 = 3{,}15$
  - Probabilitatea, sub distribuția Normală, a unei pierderi cel puțin atît de mari: $\Phi(-3{,}15) = 0{,}08\%$ pe patru săptămîni
- Scenariul pune mai multă greutate pe factorul cu beta și dispersie mai mari
  - ambii factori scad împreună pentru că sînt corelați

Înapoi

Sectoare, factori și ordinul VAR

- Datele (Secțiunea 3): 17 sectoare financiare
  - Un sector = media cu ponderi egale a CDS-urilor băncilor și asigurătorilor cu active de cel puțin 10 miliarde USD, 199 de instituții în total
- Factorii (Ec. (8), Figura 2)
  - 91,6% dintre perechile de reziduuri au $|\rho| < 0{,}25$ cu factori, sub jumătate fără factori
- Ordinul VAR și orizontul (Secțiunile 2.2 și 4)
  - VAR(1), ales după BIC la medie și păstrat la fiecare cuantilă
  - Orizontul $h = 5$ zile, cu cuantila fixă pe orizont

Înapoi

Rezultate suplimentare

- Din cele 1 122 de spillover-uri bilaterale, 568 sînt sub 1% la medie și 829 la mediană (Figura 7)
  - Departe de medie, rețeaua are multe legături slabe, nu cîteva legături puternice
  - În cozi, aceste legături slabe se adună în spillover-uri medii puternice
- RTD în timp (Secțiunea 4.3, Figura 11)
  - RTD crește odată cu pierderile fondurilor Bear Stearns din 2007
  - Scade după programul american de salvare a băncilor și după introducerea dobînzilor negative de către BCE
  - Un semnal de fragilitate pe care media îl ascunde

Înapoi

Specificația replicării și limitele precizate de autori

- Specificația pentru cele 13 bănci: ordinul VAR după BIC și numărul factorilor după Ec. (8)
  - Orizontul $h = 5$, cuantilele $\tau \in \{0{,}05;\ 0{,}5;\ 0{,}95\}$ și media, ferestre de $w = 250$ de zile
  - Măsura urmărită: RTD
- Numărul factorilor este fixat (Secțiunea 4.3, Anexa B a lucrării)
  - 250 de zile sînt prea puține pentru a-i alege în fiecare fereastră
  - ferestrele mai scurte lasă prea puține observații în cozi
- Se măsoară doar spillover-ul direct al șocurilor idiosincratice
  - nu și propagarea prin factorii comuni (nota 2)
- Grecia este exclusă din cauza unei întreruperi a seriei CDS (Secțiunea 3, Anexa A a lucrării)

Înapoi

Bucla descoperirii: prompturi reutilizabile (1/2)

- **Literatura**: cartografiem ce se știe, apoi verificăm fiecare referință
  - ,,Ce articole testează dacă indicii de conectivitate prezic dificultățile băncilor out-of-sample, dincolo de volatilitate? Dă DOI-ul, eșantionul, orizontul și variabilele de control.''
- **Ipoteze**: interpretări concurente ale unei creșteri a conectivității, fiecare cu testul ei
  - ,,Dă interpretări concurente ale unei creșteri a conectivității totale (șoc comun, contagion, artefact al ferestrelor rolling) și un test care le deosebește.''

Înapoi

Bucla descoperirii: prompturi reutilizabile (2/2)

- **Date și cod**: pe datele cursului, replicînd întîi o cifră cunoscută
  - „Estimează un VAR(2) pe logaritmul volatilităților Parkinson ale celor 13 bănci din datele cursului, pe ferestre de 250 de zile, și calculează conectivitatea totală generalizată cu H = 10.”
- **Robustețea**, fixată înainte de a rula regresiile predictive
  - „Preînregistrează: orizonturi de 21/63/126 de zile, controale pentru volatilitate și VIX, ferestre de 150/250/500 de zile, laguri HAC cel puțin cît suprapunerea, evaluare out-of-sample din 2018.”
- **Critica**: îi cerem asistentului să atace rezultatul
  - „Joacă rolul unui recenzent: este puterea predictivă a conectivității doar persistența volatilității? Ce regresie ar arăta asta?”

Înapoi

Verificările cercetătorului (1/2)

- **Date nestaționare**: un VAR pe nivelurile prețurilor sau pe serii cu tendință produce conectivitate spurioasă
  - Test: teste de rădăcină unitară pe fiecare serie
  - Test: toate valorile proprii ale matricei companion a VAR-ului estimat trebuie să fie strict în interiorul cercului unitate, în fiecare fereastră
- **Ordinea**: descompunerile Cholesky se schimbă cu ordinea băncilor
  - Test: permutăm coloanele, iar tabelul generalizat nu trebuie să se schimbe

Înapoi

Verificările cercetătorului (2/2)

- **Look-ahead bias**: o fereastră etichetată cu prima ei dată sau un ordin ales pe întregul eșantion
  - Test: indicele de la t nu trebuie să se modifice cînd ștergem datele de după t
- **Suprapunerea**: indicii pe ferestre rolling și rezultatele viitoare se suprapun
  - deci statisticile t OLS sînt supraestimate
  - Test: laguri Newey–West cel puțin egale cu suprapunerea sau bootstrap pe blocuri
- **Dimensiunea**: 13 bănci și $p = 2$ dau 27 de coeficienți pe ecuație din 250 de zile
  - mai multe bănci cer regularizare Demirer et al. (2018)
  - Test: comparăm cu un VAR LASSO
  - Muchiile instabile semnalează zgomot de estimare, nu structură

Înapoi

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- Financial Risk Meter for Emerging Markets
- Dynamic Crypto Networks
- Network Centrality

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_18

înapoi

Acronime folosite în acest material (1/3)

- **AI**: Artificial Intelligence — *inteligență artificială*
- **BAC**: Bank of America Corporation (NYSE ticker) — *Bank of America Corporation (simbolul bursier NYSE)*
- **BCE**: Banca Centrală Europeană
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BH**: Benjamini–Hochberg (procedure) — *procedura Benjamini–Hochberg*
- **BIC**: Bayesian Information Criterion — *criteriul informațional bayesian*
- **BNP**: BNP Paribas SA (Euronext Paris ticker; Banque Nationale de Paris) — *BNP Paribas SA (simbolul bursier Euronext Paris)*
- **BVB**: Bursa de Valori București
- **CATFIN**: CATastrophic risk in the FINancial sector — *riscul catastrofal din sectorul financiar (indicele Allen, Bali și Tang)*
- **CDS**: Credit Default Swap — *swap pe riscul de credit (contract de asigurare împotriva neplății)*
- **CI**: Confidence Interval — *interval de încredere*
- **COVID-19**: COronaVIrus Disease 2019 — *boala provocată de coronavirus, 2019*
- **CV**: Cross-Validation — *validare încrucișată*
- **DBK**: Deutsche Bank AG (Xetra ticker) — *Deutsche Bank AG (simbolul bursier Xetra)*
- **DCC**: Dynamic Conditional Correlation — *corelație condiționată dinamică*
- **EBA**: European Banking Authority — *Autoritatea Bancară Europeană*
- **ECB**: European Central Bank — *Banca Centrală Europeană*
- **ES**: Expected Shortfall — *pierderea așteptată în coadă*
- **FDIC**: Federal Deposit Insurance Corporation — *instituția federală americană de garantare a depozitelor*

Acronime folosite în acest material (2/3)

- **FDR**: False Discovery Rate — *rata descoperirilor false*
- **FEVD**: Forecast Error Variance Decomposition — *descompunerea dispersiei erorii de prognoză*
- **FRM**: Financial Risk Meter — *indicatorul de risc financiar sistemic Financial Risk Meter*
- **GAAP**: Generally Accepted Accounting Principles (US) — *principiile contabile general acceptate în SUA*
- **GACV**: Generalized Approximate Cross-Validation — *validare încrucișată aproximativă generalizată*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GFC**: Global Financial Crisis — *criza financiară globală (2007–2009)*
- **GJR**: Glosten–Jagannathan–Runkle (asymmetric GARCH) — *GARCH asimetric Glosten–Jagannathan–Runkle*
- **GS**: The Goldman Sachs Group, Inc. (NYSE ticker) — *The Goldman Sachs Group, Inc. (simbolul bursier NYSE)*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HSBA**: HSBC Holdings plc (London Stock Exchange ticker) — *HSBC Holdings plc (simbolul bursier de la Londra)*
- **HSBC**: HSBC Holdings plc (originally the Hongkong and Shanghai Banking Corporation) — *grupul bancar HSBC Holdings plc (inițial Hongkong and Shanghai Banking Corporation)*
- **IFRS**: International Financial Reporting Standards — *standardele internaționale de raportare financiară*
- **ING**: ING Groep (Internationale Nederlanden Groep) — *grupul bancar olandez ING*
- **INGA**: ING Groep N.V. (Euronext Amsterdam ticker) — *ING Groep N.V. (simbolul bursier Euronext Amsterdam)*
- **JPM**: JPMorgan Chase & Co. (NYSE ticker) — *JPMorgan Chase & Co. (simbolul bursier NYSE)*
- **LASSO**: Least Absolute Shrinkage and Selection Operator — *regresie penalizată L1 cu selecția variabilelor*

Acronime folosite în acest material (3/3)

- **LRMES**: Long-Run Marginal Expected Shortfall — *pierderea marginală așteptată în coadă pe termen lung (într-o criză)*
- **MES**: Marginal Expected Shortfall — *pierderea marginală așteptată în coadă*
- **MS**: Morgan Stanley (NYSE ticker) — *Morgan Stanley (simbolul bursier NYSE)*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **QFVAR**: Quantile Factor Vector AutoRegression — *autoregresie vectorială cuantilă cu factori comuni*
- **QML**: Quasi-Maximum Likelihood — *cvasi-verosimilitate maximă*
- **RTD**: Relative Tail Dependence — *dependența relativă în cozi (coada adversă minus coada favorabilă)*
- **SAN**: Banco Santander SA (Bolsa de Madrid ticker) — *Banco Santander SA (simbolul bursier de la Madrid)*
- **SG**: Société Générale — *grupul bancar francez Société Générale*
- **SRISK**: Systemic RISK (capital shortfall measure) — *deficitul de capital al unei bănci într-o criză sistemică*
- **SUA**: Statele Unite ale Americii
- **SVB**: Silicon Valley Bank — *banca americană Silicon Valley Bank (falimentată în martie 2023)*
- **TENET**: Tail-Event driven NETwork risk — *riscul de rețea determinat de evenimentele din coadă*
- **TLV**: Banca Transilvania (BVB ticker) — *Banca Transilvania (simbolul bursier BVB)*
- **UE**: Uniunea Europeană
- **US**: United States — *Statele Unite ale Americii*
- **VAR**: Vector AutoRegression — *model vector autoregresiv*
- **VIX**: CBOE Volatility IndeX — *indicele de volatilitate CBOE*
- **WFC**: Wells Fargo & Company (NYSE ticker) — *Wells Fargo & Company (simbolul bursier NYSE)*

Bibliografie (1/5)

- Acharya, V.V., Engle, R., Richardson, M. (2012). Capital shortfall: a new approach to ranking and regulating systemic risks. *American Economic Review*, 102(3), 59–64.
- Acharya, V.V., Pedersen, L.H., Philippon, T., Richardson, M. (2017). Measuring systemic risk. *Review of Financial Studies*, 30(1), 2–47.
- Adrian, T., Brunnermeier, M.K. (2016). CoVaR. *American Economic Review*, 106(7), 1705–1741.
- Allen, L., Bali, T.G., Tang, Y. (2012). Does systemic risk in the financial sector predict future economic downturns?. *Review of Financial Studies*, 25(10), 3000–3036.
- Ando, T., Bai, J. (2020). Quantile co-movement in financial markets: a panel quantile model with unobserved heterogeneity. *Journal of the American Statistical Association*, 115(529), 266–279.
- Ando, T., Greenwood-Nimmo, M., Shin, Y. (2022). Quantile connectedness: modeling tail behavior in the topology of financial networks. *Management Science*, 68(4), 2401–2431.
- Banulescu-Radu, D., Hurlin, C., Leymarie, J., Scaillet, O. (2021). Backtesting marginal expected shortfall and related systemic risk measures. *Management Science*, 67(9), 5730–5754.
- Basel Committee on Banking Supervision (2018). Global systemically important banks: revised assessment methodology and the higher loss absorbency requirement. Bank for International Settlements.

Bibliografie (2/5)

- Belloni, A., Chernozhukov, V. (2011). ℓ_1-penalized quantile regression in high-dimensional sparse models. *Annals of Statistics*, 39(1), 82–130.
- Ben Amor, S., Althof, M., Härdle, W.K. (2022). Financial Risk Meter for emerging markets. *Research in International Business and Finance*, 60, 101594.
- Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- Benoit, S., Colliard, J.-E., Hurlin, C., Pérignon, C. (2017). Where the risks lie: a survey on systemic risk. *Review of Finance*, 21(1), 109–152.
- Billio, M., Getmansky, M., Lo, A.W., Pelizzon, L. (2012). Econometric measures of connectedness and systemic risk in the finance and insurance sectors. *Journal of Financial Economics*, 104(3), 535–559.
- Bolton, P., Després, M., Pereira da Silva, L.A., Samama, F., Svartzman, R. (2020). The green swan: central banking and financial stability in the age of climate change. Bank for International Settlements.
- Brownlees, C., Engle, R.F. (2017). SRISK: a conditional capital shortfall measure of systemic risk. *Review of Financial Studies*, 30(1), 48–79.
- Castro, C., Ferrari, S. (2014). Measuring and testing for the systemically important financial institutions. *Journal of Empirical Finance*, 25, 1–14.
- Chernozhukov, V., Fernández-Val, I. (2011). Inference for extremal conditional quantile models, with an application to market and birthweight risks. *Review of Economic Studies*, 78(2), 559–589.
- Danielsson, J., James, K.R., Valenzuela, M., Zer, I. (2016). Model risk of risk models. *Journal of Financial Stability*, 23, 79–91.
- Demirer, M., Diebold, F.X., Liu, L., Yilmaz, K. (2018). Estimating global bank network connectedness. *Journal of Applied Econometrics*, 33(1), 1–15.

Bibliografie (3/5)

- Diebold, F.X., Yilmaz, K. (2009). Measuring financial asset return and volatility spillovers, with application to global equity markets. *Economic Journal*, 119(534), 158–171.
- Diebold, F.X., Yilmaz, K. (2012). Better to give than to receive: predictive directional measurement of volatility spillovers. *International Journal of Forecasting*, 28(1), 57–66.
- Diebold, F.X., Yilmaz, K. (2014). On the network topology of variance decompositions: measuring the connectedness of financial firms. *Journal of Econometrics*, 182(1), 119–134.
- ECB Banking Supervision (2022). Banks must sharpen their focus on climate risk, ECB supervisory stress test shows. Press release, 8 July 2022.
- Engle, R. (2002). Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- Engle, R., Jondeau, E., Rockinger, M. (2015). Systemic risk in Europe. *Review of Finance*, 19(1), 145–190.
- FDIC (2023). FDIC creates a Deposit Insurance National Bank of Santa Clara to protect insured depositors of Silicon Valley Bank, Santa Clara, California. Press release, 10 March 2023.
- Federal Reserve Board (2023). Federal Reserve Board announces it will make available additional funding to eligible depository institutions. Press release, 12 March 2023.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, 5th ed. Springer.
- Giglio, S., Kelly, B., Pruitt, S. (2016). Systemic risk and the macroeconomy: an empirical evaluation. *Journal of Financial Economics*, 119(3), 457–471.
- Girardi, G., Ergün, A.T. (2013). Systemic risk measurement: multivariate GARCH estimation of CoVaR. *Journal of Banking & Finance*, 37(8), 3169–3180.

Bibliografie (4/5)

- Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- Gouriéroux, C., Laurent, J.P., Scaillet, O. (2000). Sensitivity analysis of values at risk. *Journal of Empirical Finance*, 7(3–4), 225–245.
- Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). Applied Quantitative Finance, 3rd ed. Springer.
- Härdle, W.K., Wang, W., Yu, L. (2016). TENET: Tail-Event driven NETwork risk. *Journal of Econometrics*, 192(2), 499–513.
- Hall, P., Horowitz, J.L., Jing, B.-Y. (1995). On blocking rules for the bootstrap with dependent data. *Biometrika*, 82(3), 561–574.
- Hendricks, W., Koenker, R. (1992). Hierarchical spline models for conditional quantiles and the demand for electricity. *Journal of the American Statistical Association*, 87(417), 58–68.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- Koenker, R., Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50.
- Koenker, R., Bassett, G. (1982). Tests of linear hypotheses and ℓ_1 estimation. *Econometrica*, 50(6), 1577–1583.
- Koop, G., Pesaran, M.H., Potter, S.M. (1996). Impulse response analysis in nonlinear multivariate models. *Journal of Econometrics*, 74(1), 119–147.
- Mainik, G., Schaanning, E. (2014). On dependence consistency of CoVaR and some other systemic risk measures. *Statistics & Risk Modeling*, 31(1), 49–77.
- Mihoci, A., Althof, M., Chen, C.Y.-H., Härdle, W.K. (2020). FRM Financial Risk Meter. In *The Econometrics of Networks*, Advances in Econometrics 42, Emerald, 335–368.
- Nucera, F., Schwaab, B., Koopman, S.J., Lucas, A. (2016). The information in systemic risk rankings. *Journal of Empirical Finance*, 38, 461–475.

Bibliografie (5/5)

- Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *Journal of Business*, 53(1), 61–65.
- Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- Pesaran, H.H., Shin, Y. (1998). Generalized impulse response analysis in linear multivariate models. *Economics Letters*, 58(1), 17–29.
- Ren, R., Althof, M., Härdle, W.K. (2025). Financial Risk Meter for cryptocurrencies and tail risk network-based portfolio construction. *Singapore Economic Review*, 70(4), 901–927.
- Ren, R., Lu, M., Li, Y., Härdle, W.K. (2022). Financial Risk Meter FRM based on expectiles. *Journal of Multivariate Analysis*, 189, 104881.
- Scaillet, O. (2004). Nonparametric estimation and sensitivity analysis of expected shortfall. *Mathematical Finance*, 14(1), 115–129.
- Shi, S., Hurn, S., Phillips, P.C.B. (2020). Causal change detection in possibly integrated systems: revisiting the money–income relationship. *Journal of Financial Econometrics*, 18(1), 158–180.
- Toda, H.Y., Yamamoto, T. (1995). Statistical inference in vector autoregressions with possibly integrated processes. *Journal of Econometrics*, 66(1–2), 225–250.
- Toma, F.-M., Dima, D.M., Grecu, R., Pele, D.T., Lessmann, S. (2026). Energy Financial Risk Meter: systemic risk in the EU energy sector. SSRN working paper.
- Wang, R., Althof, M., Härdle, W.K. (2023). A financial risk meter for China. *Emerging Markets Review*, 56, 101052.