



Modelarea piețelor financiare

Capitolul 18: Risc sistemic și rețele



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (inteligență artificială)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BNP: BNP Paribas SA (Euronext Paris ticker; Banque Nationale de Paris) (BNP Paribas SA (simbolul bursier Euronext Paris))
- BVB: Bursa de Valori București
- CATFIN: CATastrophic risk in the FINancial sector (riscul catastrofal din sectorul financiar (indicele Allen, Bali și Tang))
- CDS: Credit Default Swap (swap pe riscul de credit (contract de asigurare împotriva neplății))
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- ECB: European Central Bank (Banca Centrală Europeană)
- ES: Expected Shortfall (pierderea așteptată în coadă)
- FDIC: Federal Deposit Insurance Corporation (instituția federală americană de garantare a depozitelor)
- FDR: False Discovery Rate (rata descoperirilor false)
- FEVD: Forecast Error Variance Decomposition (descompunerea dispersiei erorii de prognoză)
- FRM: Financial Risk Meter (indicatorul de risc financiar sistemic Financial Risk Meter)
- GAAP: Generally Accepted Accounting Principles (US) (principiile contabile general acceptate în SUA)
- GACV: Generalized Approximate Cross-Validation (validare încrucișată aproximativă generalizată)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HSBC: HSBC Holdings plc (originally the Hongkong and Shanghai Banking Corporation) (grupul bancar HSBC Holdings plc (inițial Hongkong and Shanghai Banking Corporation))
- IFRS: International Financial Reporting Standards (standardele internaționale de raportare financiară)
- ING: ING Groep (Internationale Nederlanden Groep) (grupul bancar olandez ING)
- LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- LRMEs: Long-Run Marginal Expected Shortfall (pierderea marginală așteptată în coadă pe termen lung (într-o criză))
- MES: Marginal Expected Shortfall (pierderea marginală așteptată în coadă)

Acronime folosite în acest material (2/2)

- ▣ OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ QFVAR: Quantile Factor Vector AutoRegression (autoregresie vectorială cuantilă cu factori comuni)
- ▣ QML: Quasi-Maximum Likelihood (cvasi-verosimilitate maximă)
- ▣ RTD: Relative Tail Dependence (dependența relativă în cozi (coada adversă minus coada favorabilă))
- ▣ SG: Société Générale (grupul bancar francez Société Générale)
- ▣ SRISK: Systemic RISK (capital shortfall measure) (deficitul de capital al unei bănci într-o criză sistemică)
- ▣ SUA: Statele Unite ale Americii
- ▣ SVB: Silicon Valley Bank (banca americană Silicon Valley Bank (falimentată în martie 2023))
- ▣ TENET: Tail-Event driven NETwork risk (riscul de rețea determinat de evenimentele din coadă)
- ▣ UE: Uniunea Europeană
- ▣ US: United States (Statele Unite ale Americii)
- ▣ VAR: Vector AutoRegression (autoregresie vectorială)
- ▣ VIX: CBOE Volatility Index (indicele de volatilitate CBOE)

Riscul sistemic și traseul capitolului

De la o bancă la sistem

- **Riscul sistemic:** riscul ca dificultățile uneia sau ale mai multor instituții să afecteze sistemul financiar în ansamblu și, prin el, economia reală
- O **externalitate:** o bancă nu plătește pierderile pe care falimentul ei le impune altora
- Trei familii de măsuri Billio, Getmansky, Lo & Pelizzon (2012); sinteză Benoit, Colliard, Hurlin & Pérignon (2017)
 - ▶ **Expunere:** cât pierde banca atunci când piața se prăbușește? MES, SRISK
 - ▶ **Contribuție:** cu cât stă mai rău sistemul atunci când banca este în dificultate? ΔCoVaR
 - ▶ **Conectivitate:** prin ce legături circulă șocurile? Rețele de spillover și rețele în coadă

Traseul capitolului (2 × 80 de minute)

- Prima întâlnire: date și convenții; expunerea (MES, LRMEs, SRISK); contribuția (CoVaR, ΔCoVaR) și cât ne putem baza pe clasamente
- A doua întâlnire: rețele de spillover, Financial Risk Meter, teste de stres și riscul climatic, un studiu de caz despre conectivitatea cuantilă, o trecere prin bucla descoperirii cu AI
- Demonstrațiile, detaliile de estimare și verificările de robustețe se află în Anexa de la final
- Manuale: Franke, Härdle & Hafner (2019), Härdle, Chen & Overbeck (2017)

Retrageri în masă: Northern Rock 2007 și Silicon Valley Bank 2023



Deponenți la coadă în fața unei sucursale Northern Rock, Brighton, 14 septembrie 2007

Foto: [Dominic Alves \(2007\)](#); CC BY 2.0; Wikimedia

[Commons](#)


- Northern Rock (2007): un creditor ipotecar britanic lovit de blocarea piețelor de finanțare după pierderile din creditele subprime americane; deponenții au stat la coadă pentru a-și retrage economiile
- SVB (2023): retrageri masive de depozite prin canale digitale; FDIC a preluat banca pe 10 martie [FDIC \(2023\)](#); după două zile toți deponenții SVB și Signature Bank au fost protejați, pe baza unui argument sistemic [Federal Reserve Board \(2023\)](#)
 - ▶ Secțiunea despre testarea la stres măsoară pierderea unui portofoliu bancar în acea fereastră
- Canale de contagiune
 - ▶ Retrageri de finanțare: deponenții și creditorii se retrag din orice bancă ce pare asemănătoare
 - ▶ Expuneri comune și vânzări forțate: vânzarea forțată scade prețurile pentru toți deținătorii
 - ▶ Legături între contrapărți: datoria unei bănci este activul alteia, deci neplata ei transmite pierderi creditorilor

Date și convenții

Grupul	Seriile	Indicele pieței
Bănci americane	JPMorgan, Bank of America, Citigroup, Goldman Sachs, Morgan Stanley, Wells Fargo	S&P 500
Bănci europene	Deutsche Bank, BNP Paribas, Santander, ING, HSBC	Euro Stoxx 50
Bănci românești	Banca Transilvania, BRD-Groupe Société Générale	BET
Volatilitate	indicele VIX (volatilitatea implicită a S&P 500)	

- ▣ Prețuri zilnice din ianuarie 2010 până la 18 septembrie 2026, ajustate pentru dividende și divizări; 3 960 zile de tranzacționare comune
- ▣ Aliniem mai întâi prețurile pe zilele comune, apoi calculăm randamentele logaritmice zilnice $r_t = 100(\ln P_t - \ln P_{t-1})$, în %
- ▣ Băncile românești: zilele fără tranzacții sunt eliminate; scenariile istorice de stres pentru băncile internaționale încep în 2007
- ▣ Randamentul X , pierderea $L = -X$; nivelul α este o probabilitate a cozii: VaR 1%, CoVaR 1%, MES 5% (Capitolul 7)
 - ▶ $\text{VaR}_\alpha(X) = -q_\alpha(X)$, cu q_α cuantila de ordin α ; VaR, CoVaR și MES sunt numere pozitive atunci când sunt pierderi
- ▣ Randamentul sistemului X^{sys} : portofoliul cu ponderi egale al celorlalte bănci din aceeași regiune
 - ▶ $X^{\text{sys}} = \frac{1}{n} \sum_j X_j$ este media randamentelor log zilnice: un agregat liniar, care aproximează la ordinul întâi randamentul log al portofoliului reechilibrat zilnic; MES, CoVaR și identitatea Euler se referă la acest agregat

Trei sisteme bancare, 2010–2026




- ▣ Portofolii cu ponderi egale ale băncilor din fiecare regiune, rebalansate zilnic; liniile verticale marchează episoadele folosite în acest capitol
- ▣ 100 investiți în ianuarie 2010 au devenit 791 în băncile americane, 384 în cele europene și 1233 în cele românești
 - Drawdown-ul maxim: SUA 51% (2011-11-23), Europa 61% (2020-04-21), România 47% (2012-06-06)
- ▣ Volatilitatea anualizată a portofoliilor: 29%, 30% și 23%, față de 18% (S&P 500), 21% (Euro Stoxx 50) și 18% (BET)
- ▣ Scăderile sunt simultane: criza din zona euro, COVID-19 și falimentele bancare din 2023 au lovit toate regiunile în aceleași săptămâni
- ▣ Băncile românești au și un șoc propriu: anunțul taxei bancare din decembrie 2018

Marginal Expected Shortfall și proprietatea Euler

- **MES** (Marginal Expected Shortfall, pierderea marginală așteptată în coadă) a băncii i la nivelul α Acharya, Pedersen, Philippon & Richardson (2017)
 - ▶ $MES_{i,\alpha} = -\mathbb{E}[X_i \mid X_m \leq q_\alpha(X_m)]$
 - ▶ Pierderea medie a băncii în fracțiunea α a zilelor cu cele mai mici randamente ale pieței m
- De ce „marginală”: **dacă** variabila de condiționare este chiar portofoliul, $m = \sum_i w_i X_i$, atunci $ES_\alpha(X_m) = \sum_i w_i MES_{i,\alpha}$ (alocarea Euler; demonstrația în Anexă)
 - ▶ Piețele noastre (S&P 500, Euro Stoxx 50, BET) **nu** sunt portofolii ale acestor 13 bănci: aici MES măsoară **expunerea**, nu o parte din ES al indicelui
- Verificare pe datele noastre (șase bănci americane, $\alpha = 5\%$, 198 zile în coadă): $ES_{5\%}$ al portofoliului = 4,32% = media MES condiționate pe portofoliu (4,32%); condiționând pe S&P 500 obținem 3,63%
- Estimarea istorică: media lui $-X_i$ în zilele cu $X_m \leq \hat{q}_\alpha(X_m)$; cu $\alpha = 5\%$ și 3 960 zile, aproximativ 200 de zile
- Piața m : S&P 500 pentru băncile americane, Euro Stoxx 50 pentru cele europene, BET pentru cele românești

MES 5% pentru treisprezece bănci



- Pierderea zilnică medie a fiecărei bănci în cele 5% dintre zile cu cele mai mici randamente ale indicelui său de piață, 2010–2026; intervale de 95% din bootstrap pe blocuri mobile (blocuri de 20 de zile)
- Băncile americane: de la 3,22% (JPMorgan) la 4,04% (Morgan Stanley); cele europene până la 4,81% (ING)
 - În aceleași zile piața a pierdut în medie 2,72% (S&P 500) și 3,16% (Euro Stoxx 50): băncile pierd mai mult decât piața
- HSBC este excepția din Europa (2,54%, sub indice): listată la Londra, cu afaceri în Asia
- Banca Transilvania 3,14% și BRD 2,69% în zilele de prăbușire a BET; BET însuși a pierdut 2,70%
- Intervalele marginale care se suprapun nu sunt un test al egalității: diferențele dintre bănci cer un test pe perechi, pe extrageri bootstrap comune (Secțiunea 3)


De la MES la o criză: LRMES

- **LRMES** (Long-Run MES, MES pe termen lung): scăderea așteptată a capitalului de piață al băncii într-o criză, o scădere a pieței sub C în h zile
 - ▶ $\text{LRMES}_{i,t} = -\mathbb{E}_t [R_{i,t+1:t+h} \mid R_{m,t+1:t+h} < C]$, randamente aritmetice pe h zile
 - ▶ Acharya, Engle & Richardson (2012) (Secțiunea I): $C = -40\%$ în șase luni; Brownlees & Engle (2017) (Secțiunea 1.1): $C = -10\%$ în $h = 22$ de zile
- Aproximarea Acharya, Engle & Richardson (2012), Secțiunea I, pentru „versiunile modelului în care simularea nu este încă implementată”: $\text{LRMES}_i \approx 1 - \exp(-18 \times \text{MES}_i^{2\%})$
 - ▶ $\text{MES}_i^{2\%}$: pierderea zilnică medie a băncii în zilele în care piața scade cu peste 2% (în fracții zecimale); exemplu $\text{MES}^{2\%} = 3\%$ dă $1 - e^{-0,54} = 41,7\%$
 - ▶ 18 este o constantă de calibrare; exercițiul A4 din Seminarul 18 explică această calibrare
- Aproximarea pe băncile noastre: de la 37% (HSBC) la 58% (ING); JPMorgan 48%, Banca Transilvania 52%
 - ▶ Piața a scăzut cu peste 2% în 138 zile în SUA, 196 în zona euro și 111 la BVB

SRISK și levierul de echilibru

- O bancă trebuie să păstreze un capital de cel puțin o proporție k din cvasi-active (datoriile contabile D plus capitalul de piață W) [Brownlees & Engle \(2017\)](#), Secțiunea 1.1, Ec. (1)
 - ▶ $SRISK_i = k D_i - (1 - k)(1 - LRMES_i) W_i$, presupunând că datoriile nu sunt renegociate în criză
 - ▶ $k = 8\%$ pentru firmele americane [Brownlees & Engle \(2017\)](#); $k = 5,5\%$ pentru firmele europene, ale căror bilanțuri IFRS raportează active mai mari decât US GAAP [Engle, Jondeau & Rockinger \(2015\)](#)
- SRISK pozitiv = deficit; SRISK al sistemului este suma valorilor pozitive; [V-Lab, New York University Stern School of Business](#) îl publică pentru băncile mari, pe baza bilanțurilor lor
- Împărțim la W și exprimăm levierul calculat pe baza cvasi-activelor $L = (D + W)/W$
 - ▶ $\frac{SRISK}{W} = k(L - 1) - (1 - k)(1 - LRMES)$
- SRISK devine pozitiv când levierul depășește levierul de echilibru
 - ▶ $L^* = 1 + \frac{(1 - k)(1 - LRMES)}{k}$
- Exemplu: $D = 900$, $W = 100$, $LRMES = 41,7\%$
 - ▶ $SRISK = 0,08 \times 900 - 0,92 \times (1 - 41,7\%) \times 100 = 72 - 53,6 = 18,4$
- Exemplul de mai sus: $L^* = 7,7$, iar banca are $L = 10$: deficit
- Datele noastre conțin prețuri, nu bilanțuri: raportăm L^* din LRMES estimat și tratăm levierul ca pe o ipoteză

SRISK în funcție de levier



- Băncile cu LRMES maxim, median și minim; levierul de pe axa orizontală este presupus, nu observat; punctele marchează L^*
- Cu $k = 8\%$: $L^* = 5,8$ pentru ING, 6,4 pentru Santander, 8,3 pentru HSBC
 - SUA: JPMorgan 7,0, Morgan Stanley 6,0; România: Banca Transilvania 6,5, BRD 7,1
- O bancă ale cărei datorii depășesc de aproximativ 5–7 ori capitalul ei de piață ar avea nevoie de capital nou într-o prăbușire a pieței cu 40%
- Cu $k = 5,5\%$ pragurile cresc (ING 8,2, HSBC 11,9): raportul prudential este o alegere de politică, iar SRISK depinde de el
- Limite: LRMES este o extrapolare din date zilnice, iar capitalul de piață însuși scade într-o criză

LRMES: GJR–GARCH, DCC și simulare


- Modelul [Brownlees & Engle \(2017\)](#), Secțiunea 1.2: randamente log cu medie zero ale băncii și pieței, volatilități GJR–GARCH(1,1) [Glosten, Jagannathan & Runkle \(1993\)](#) și o corelație DCC(1,1) [Engle \(2002\)](#), QML în doi pași
 - ▶ $\sigma_t^2 = \omega + (\alpha + \gamma \mathbf{1}\{r_{t-1} < 0\}) r_{t-1}^2 + \beta \sigma_{t-1}^2$, pentru bancă și pentru piață
 - ▶ $Q_t = (1 - a - b) S + a \epsilon_{t-1} \epsilon_{t-1}^\top + b Q_{t-1}$, $\rho_t = Q_{12,t} / \sqrt{Q_{11,t} Q_{22,t}}$
- Simularea (Anexa A): reeșantionăm **perechi** de inovații standardizate $(\xi_{it}, \epsilon_{mt})$ (Anexă), filtrăm h zile înainte, pornind de la σ^2 și ρ de azi, păstrăm traiectoriile cu $R_{m,t+1:t+h} < C$
 - ▶ LRMES = minus media randamentului băncii pe traiectoriile de criză; reeșantionarea perechilor păstrează dependența din coadă pe care distribuția Normală o ratează
- Simulare pe date până la 2026-09-18; 200 000 de traiectorii de 22 de zile pe piață ($C = -10\%$), 400 000 de traiectorii de 126 de zile ($C = -40\%$)
 - ▶ Probabilitatea crizei de 22 de zile azi: 1,3% (S&P 500), 4,3% (Euro Stoxx 50), 4,0% (BET); pe 31 martie 2020: 12%, 19%, 8%

LRMES prin simulare: treisprezece bănci

Banca	LRMES azi	interval 90%	LRMES 31.03.2020	ρ_T	L^*
JPMorgan	10,6	[-2, 25]	23,7	0,53	11,3
Bank of America	14,3	[-4, 35]	23,2	0,44	10,9
Citigroup	13,0	[-1, 28]	32,8	0,54	11,0
Goldman Sachs	16,5	[1, 34]	25,0	0,65	10,6
Morgan Stanley	16,3	[1, 32]	27,2	0,65	10,6
Wells Fargo	6,7	[-8, 24]	22,9	0,32	11,7
Deutsche Bank	14,4	[2, 28]	25,7	0,66	10,8
BNP Paribas	15,6	[2, 33]	28,5	0,68	10,7
Santander	16,6	[3, 34]	26,4	0,76	10,6
ING	12,5	[1, 27]	32,9	0,68	11,1
HSBC	8,3	[-2, 19]	10,9	0,58	11,5
Banca Transilvania	12,4	[-2, 34]	17,2	0,74	11,1
BRD-Groupe SG	11,4	[-2, 28]	15,8	0,64	11,2

- LRMES (%) pentru o scădere a pieței sub -10% în 22 de zile [Brownlees & Engle \(2017\)](#); intervalul de 90%: cuantilele de 5% și 95% ale pierderii băncii pe traiectoriile de criză; ρ_T : ultima corelație DCC; L^* cu $k = 8\%$
- LRMES este condiționat: se mișcă odată cu volatilitatea și corelația de azi
 - JPMorgan: 10,6% azi, 23,7% cu informația din 31 martie 2020; Deutsche Bank 14,4% și 25,7%
- Intervalul de 90% este larg: LRMES este o medie pe traiectoriile de criză, iar deficitul de capital într-o criză anume poate fi mult mai mare [Brownlees & Engle \(2017\)](#), Ec. (2)
- Cu o criză de o lună și -10% , LRMES este aproximativ o treime din cifrele pentru șase luni și -40% din [Acharya, Engle & Richardson \(2012\)](#): scenariul, nu doar banca, stabilește nivelul

Riscul de model: LRMES în trei specificații



- Criză de șase luni, scădere a pieței cu 40% Acharya, Engle & Richardson (2012); aproximarea $1 - e^{-18\text{MES}^2\%}$ față de simularea din GJR-GARCH + DCC cu inovații reeșantionate sau Normale, date până la 2026-09-18
- LRMES simulat împărțit la aproximare: între 0,42 și 0,90 pentru cele 13 bănci; corelația de rang 0,77
 - JPMorgan: 48% (aproximare), 33% (reeșantionate), 33% (inovații cu distribuția Normală); ING: 58%, 41%, 41%
- Aproximarea folosește întreaga istorie 2010–2026; simularea pornește de la volatilitatea și corelația de azi
- Inovații reeșantionate față de inovații cu distribuția Normală: corelația de rang 0,95; distribuția inovațiilor schimbă nivelurile mai mult decât clasamentele
- Aceleași bănci, aceleași date, modele diferite și justificabile, cifre diferite: „riscul de model al modelelor de risc” Danielsson, James, Valenzuela & Zer (2016)


CoVaR: VaR al sistemului când o bancă este în dificultate

- ▣ **CoVaR** al sistemului condiționat de banca i aflată la nivelul VaR-ului ei [Adrian & Brunnermeier \(2016\)](#)
 - ▶ $P\left(X^{sys} \leq -\text{CoVaR}_{\alpha}^{sys|i} \mid X_i = -\text{VaR}_{i,\alpha}\right) = \alpha$
 - ▶ Pierderea sistemului depășită cu probabilitatea α într-o zi în care banca i se află la propriul VaR
- ▣ **ΔCoVaR** : diferența dintre starea mediană a băncii și starea ei de dificultate
 - ▶ $\Delta\text{CoVaR}_{\alpha}^{sys|i} = \text{CoVaR}_{\alpha}^{sys|X_i=q_{\alpha}} - \text{CoVaR}_{\alpha}^{sys|X_i=q_{50\%}}$
- ▣ **ΔCoVaR** măsoară **contribuția** băncii i la riscul din coadă (tail risk) al sistemului
- ▣ Inversând rolurile obținem **CoVaR de expunere**: VaR al băncii i atunci când sistemul este în dificultate

Estimarea CoVaR prin regresie cuantilă


- Cuantila de ordin α a lui Y condiționată de x este liniară: $q_\alpha(Y | x) = a_\alpha + b_\alpha x$ Koenker & Bassett (1978)
 - ▶ $(\hat{a}_\alpha, \hat{b}_\alpha) = \arg \min_{a,b} \sum_t \rho_\alpha(y_t - a - bx_t)$, $\rho_\alpha(u) = u(\alpha - 1\{u < 0\})$
 - ▶ ρ_α este **funcția de pierdere cuantilă**: ponderează reziduurile negative cu $1 - \alpha$ și pe cele pozitive cu α ; $\alpha = 50\%$ dă regresia mediane
- 1. Regresia cuantilă a sistemului pe bancă la nivelul α
 - ▶ $\hat{q}_\alpha(X^{sys} | X_i) = \hat{a}_\alpha + \hat{b}_\alpha X_i$
- 2. Introducem cuantilele băncii: $\hat{q}_\alpha(X_i)$ (dificultate) și $\hat{q}_{50\%}(X_i)$ (mediana)
 - ▶ $\text{CoVaR}_\alpha^{sys|i} = - \left(\hat{a}_\alpha + \hat{b}_\alpha \hat{q}_\alpha(X_i) \right)$
- 3. Facem diferența
 - ▶ $\Delta \text{CoVaR}_\alpha^{sys|i} = \hat{b}_\alpha (\hat{q}_{50\%}(X_i) - \hat{q}_\alpha(X_i))$
 - ▶ Contează doar panta: termenul liber se simplifică
- Incertitudinea: bootstrap pe blocuri mobile de zile (blocurile de 20 de zile păstrează grupările de volatilitate), 999 de reesantionări

Regresia cuantilă: JPMorgan și celelalte bănci americane



- Randamente zilnice 2010–2026 cu dreptele de regresie cuantilă de 1% și 50%; linia punctată marchează JPMorgan la VaR 1%
- Dreapta de 1%: $\hat{q}_{1\%} = -2,10 + 0,94 X_i$; dreapta medianei: $-0,03 + 0,96 X_i$
 - Pante asemănătoare: dreapta de 1% este coborâtă de coada celorlalte bănci, nu este mai abruptă
- VaR 1% al JPMorgan este 4,83%; într-o astfel de zi, celelalte bănci americane au CoVaR 1% = 6,64%
 - VaR 1% necondiționat al sistemului: 5,07%; cu JPMorgan la mediană: 2,03%
- $\Delta \text{CoVaR}_{1\%} = 4,62\%$: JPMorgan în dificultate adaugă aproximativ 4,62 puncte procentuale la pierderea la nivelul de 1% a celorlalte bănci americane
- Aceasta este o asociere, nu o cauzalitate: un șoc comun lovește JPMorgan și pe celelalte bănci în aceeași zi

$\Delta\text{CoVaR 1\%}$ pentru unsprezece bănci



- Sistemul: portofoliul cu ponderi egale al celorlalte bănci din aceeași regiune; intervale bootstrap de 95% pe blocuri mobile
- Toate cele unsprezece bănci se află între 3,81% (Citigroup) și 4,89% (Wells Fargo); intervalele de 95% au o lățime de 1,5–2,4 puncte
 - De ex. Citigroup [3,23, 4,74], Wells Fargo [3,68, 5,71]: intervalele marginale se suprapun
- Suprapunerea nu este un test: două estimări calculate pe aceleași zile sunt dependente (în extragerile noastre bootstrap, puternic corelate pozitiv), deci intervalul pentru diferență poate fi mai îngust decât fiecare interval marginal
- La $\alpha = 5\%$ valorile sunt mai mici (JPMorgan 2,62%), iar clasamentul se schimbă: corelația Spearman dintre clasamentele de 1% și 5% este 0,10
 - Un clasament care se schimbă cu α nu este o bază robustă pentru reglementare


Testarea ΔCoVaR 1%

- Toate testele folosesc aceleași 999 de extrageri bootstrap pe blocuri mobile de zile pentru toate băncile, deci estimările băncilor diferite își păstrează dependența
- (1) Nicio contribuție, $H_0: b_\alpha = 0$: test Wald cu dispersia de tip sandviș a regresiei cuantile [Koenker & Bassett \(1978\)](#)
 - ▶ Rapoartele t cu nucleu (sandviș) pentru $\hat{b}_{1\%}$ între 4,0 (HSBC) și 6,9 (JPMorgan): fiecare bancă contribuie
- (2) Legătura din coadă este egală cu cea din centru, $H_0: b_\alpha = b_{50\%}$: este banca specială în crize?
 - ▶ Respinsă pentru 2 din 11 bănci la 5% (2 după Holm): pentru majoritatea băncilor legătura din coadă este egală cu cea din centru
- (3) Contribuții egale, $H_0: \Delta\text{CoVaR}_i = \Delta\text{CoVaR}_j$: aceleași zile reeșantionate pentru **toate** băncile dau distribuția comună
 - ▶ Contribuții egale în fiecare regiune: 4 din 25 perechi diferă la 5%, 0 după Holm; testul Wald comun $p = 0,01$ (SUA), 0,31 (Europa)
 - ▶ La 5%: 3 din 25 perechi diferă, 0 după Holm; testul Wald comun $p = 0,014$ (SUA), 0,046 (Europa)
- Tabelul complet cu pante și valori p : Anexă; teste de semnificație și de dominanță pentru importanța sistemică: [Castro & Ferrari \(2014\)](#)

CoVaR Girardi–Ergün: pierderi cel puțin egale cu VaR


- Girardi & Ergün (2013) condiționează pe pierderea băncii **cel puțin egală** cu VaR-ul ei, nu exact egală cu acesta
 - ▶ $P\left(X^{sys} \leq -\text{CoVaR}_{\alpha}^{\leq} \mid X_i \leq -\text{VaR}_{i,\alpha}\right) = \alpha \iff P\left(X^{sys} \leq -\text{CoVaR}_{\alpha}^{\leq}, X_i \leq -\text{VaR}_{i,\alpha}\right) = \alpha^2$
 - ▶ Starea de referință: un eveniment de o abatere standard $|X_i - \mu_i| \leq \sigma_i$ în locul medianei
- De ce contează
 - ▶ Include dificultăți mai severe decât ziua de VaR însăși și este monoton în parametrul de dependență
 - ▶ Se poate face **backtesting**: evenimentul comun $\{X^{sys} \leq -\text{CoVaR}^{\leq}, X_i \leq -\text{VaR}_i\}$ are probabilitatea α^2
- Estimarea istorică la $\alpha = 5\%$: cuantila de 5% a sistemului în cele 198 zile cu $X_i \leq \hat{q}_{5\%}(X_i)$
 - ▶ JPMorgan: $\text{CoVaR}_{5\%}^{\leq} = 7,70\%$ față de $\text{CoVaR}_{5\%} = 3,81\%$ din regresia cuantilă; unsprezece bănci: 7,3–8,2% față de 3,6–4,8%
 - ▶ Aproximativ de două ori mai mare: media pe întreaga coadă a băncii este un eveniment de condiționare mai sever (Seminarul 18, A2 derivă acest rezultat sub distribuția Normală)

VaR și ΔCoVaR măsoară lucruri diferite




- Orizontal: VaR 1% al băncii; vertical: ΔCoVaR 1% al ei, unsprezece bănci, 2010–2026
- Corelația de rang Spearman dintre VaR și ΔCoVaR : 0,16
 - ▶ Deutsche Bank și ING au cele mai mari VaR (7,19%, 7,16%), dar doar un ΔCoVaR mediu
 - ▶ JPMorgan are unul dintre cele mai mici VaR (4,83%) și unul dintre cele mai mari ΔCoVaR
- Acesta este mesajul central al lucrării [Adrian & Brunnermeier \(2016\)](#): reglementarea fiecărei bănci după propriul VaR ignoră contribuția ei la sistem
- Atenție: cu unsprezece bănci și intervale suprapuse, corelația însăși este foarte incertă (Seminarul 18, B2)

ΔCoVaR 1% în timp



- ▣ Șase bănci, medii mobile pe 21 de zile ale ΔCoVaR 1% zilnic estimat cu variabile de stare întârziate
- ▣ Variabile de stare M_{t-1} : log VIX, randamentul indicelui regional și al sistemului, toate întârziate cu o zi [Adrian & Brunnermeier \(2016\)](#)
- ▣ Apoi $\Delta\text{CoVaR}_{\alpha,t} = \hat{b} \left(\hat{q}_{50\%,t}(X_i) - \hat{q}_{\alpha,t}(X_i) \right)$
- ▣ JPMorgan: în medie 2,16% în 2017, 9,06% în martie 2020; vârf de 10,99% pe 2020-03-18
 - ▶ Deutsche Bank: 2,04% în 2017 și 6,65% în martie 2020
- ▣ ΔCoVaR bazat pe piață este mic în perioadele calme, exact atunci când riscul se poate acumula în bilanțuri, pe care datele de piață nu le văd
- ▣ De aceea [Adrian & Brunnermeier \(2016\)](#) propun un ΔCoVaR anticipat, prognozat din levier, mărime și nepotrivirea scadențelor

Contribuție față de expunere



- Albastru: ΔCoVaR 1% (pierderea sistemului când banca este în dificultate); portocaliu: ΔCoVaR de expunere 1% (pierderea băncii când sistemul este în dificultate)
- Direcția contează: cele două numere diferă pentru majoritatea băncilor
 - ING: contribuție 4,42%, expunere 6,14%; BNP Paribas: 4,84% și 6,07%
 - HSBC: contribuție 4,07%, expunere doar 3,17%
- Expunerea este mai mare decât contribuția pentru majoritatea băncilor europene: creșterea pierderii din coadă a băncii când sistemul este în dificultate depășește creșterea pierderii din coadă a sistemului când banca este în dificultate; ambele sunt asocieri, nu efecte cauzale
- Expunerea contează pentru capitalul băncii; contribuția contează pentru autoritatea care reglementează sistemul

Cât de mult ne putem baza pe un clasament?

- Clasamentele băncilor după măsuri sistemice diferite nu coincid, iar fiecare clasament are o incertitudine de eșantionare mare [Nucera, Schwaab, Koopman & Lucas \(2016\)](#)
 - ▶ Ei propun combinarea măsurilor și raportarea incertitudinii clasamentului în locul unei ordini unice
- Riscul de model: măsura de risc a aceleiași bănci variază mult de la o metodă de estimare la alta [Danielsson, James, Valenzuela & Zer \(2016\)](#)
 - ▶ În acest capitol: aproximarea LRMES față de simulare (raport 0,42–0,90), CoVaR din regresia cuantilă față de Girardi–Ergün (aproximativ $\times 2$), $\alpha = 1\%$ față de 5% (Spearman 0,10)
- Eșantionul efectiv din coadă este αn : 40 de zile la 1% și 198 la 5% din 3 960
 - ▶ În datele noastre, eroarea standard bootstrap pe blocuri a $\Delta\text{CoVaR } 1\%$ este de aproximativ 0,6 ori eroarea standard bazată pe nucleu (mediana pe bănci): cele două metode dau rezultate foarte diferite
- Backtesting-ul în afara eșantionului pentru $\text{CoVaR}_{5\%}^{\leq}$ nu respinge pentru nicio bancă, dar, cu aproximativ 7,4 evenimente comune așteptate, puterea lui este mică (Anexă)
- Ce rezistă: diferențele mari și testate (regiunile; panta din coadă a unor bănci), nu ordinea a unsprezece estimări punctuale apropiate


De la perechi la rețele: descompunerea dispersiei

- CoVaR privește o bancă și un sistem; o **rețea** privește toate perechile deodată
 - ▶ Noduri: băncile; muchii orientate: cât din incertitudinea viitoare a băncii i vine din șocurile băncii j
- Autoregresie vectorială (VAR, vector autoregression) de ordin p pentru N serii y_t : $y_t = c + \sum_{l=1}^p A_l y_{t-l} + \varepsilon_t$, $\text{Cov}(\varepsilon_t) = \Sigma$
- Eroarea de prognoză pe H zile a lui y_i este o sumă de șocuri ale tuturor seriilor: dispersia ei se poate împărți pe surse
- Șocurile ortogonale (Cholesky) depind de ordinea seriilor; descompunerea **generalizată** nu depinde Koop, Pesaran & Potter (1996), Pesaran & Shin (1998)
 - ▶ $\theta_{ij}(H) = \frac{\sigma_{jj}^{-1} \sum_{h=0}^{H-1} (e_i^\top \Phi_h \Sigma e_j)^2}{\sum_{h=0}^{H-1} e_i^\top \Phi_h \Sigma \Phi_h^\top e_i}$, normalizat: $\tilde{\theta}_{ij} = \theta_{ij} / \sum_j \theta_{ij}$
- Rețele din descompunerea dispersiei Diebold & Yilmaz (2009), Diebold & Yilmaz (2012), Diebold & Yilmaz (2014): abordarea din această secțiune
- Alte rețele: cauzalitate Granger Billio, Getmansky, Lo & Pelizzon (2012) (Anexă), rețele în coadă TENET Härdle, Wang & Yu (2016) și Financial Risk Meter (secțiunea următoare)

Tabelul conectivității și range volatility


- $\tilde{\theta}_{ij}$ (în %): proporția din dispersia erorii de prognoză pe H zile a lui i datorată șocurilor lui j ; fiecare linie însumează 100 [Diebold & Yilmaz \(2014\)](#)
 - De la ceilalți: $F_i = \sum_{j \neq i} \tilde{\theta}_{ij}$; către ceilalți: $T_j = \sum_{i \neq j} \tilde{\theta}_{ij}$
 - Net: $T_i - F_i$ (pozitiv = transmițător net); net pe perechi: $\tilde{\theta}_{ji} - \tilde{\theta}_{ij}$
- Conectivitatea totală: $C = \frac{1}{N} \sum_{i \neq j} \tilde{\theta}_{ij}$, proporția medie din dispersie care vine de la ceilalți
 - Liniile lui θ_{ij} nu însumează unu înainte de normalizare, deoarece șocurile generalizate sunt corelate (Seminarul 18, A5 derivă acest lucru)
 - O legătură netă pe perechi $\tilde{\theta}_{ji} - \tilde{\theta}_{ij} > 0$ înseamnă că i transmite net către j și este reprezentată printr-o săgeată $i \rightarrow j$: rețeaua din slide-urile următoare
- Volatilitatea Parkinson din maximul H_t și minimul L_t ale zilei [Parkinson \(1980\)](#)
 - $\hat{\sigma}_t^2 = \frac{(\ln H_t - \ln L_t)^2}{4 \ln 2}$, anualizată $100\sqrt{252} \hat{\sigma}_t^2$, în logaritm
 - Nedeplasată pentru dispersia unei mișcări browniene fără tendință; mai eficientă decât randamentul la pătrat
- Modelul nostru: VAR pe logaritmul volatilității celor 13 bănci, ordinul ales după criteriul informațional bayesian ($p = 2$), orizontul $H = 10$ zile
 - Fusurile orare: ședințele bursiere pentru acțiunile băncilor americane se încheie după cele pentru băncile europene; întârzierile VAR captează spillover-ul din ziua următoare

Tabelul conectivității pentru treisprezece bănci



- Linia i , coloana j : proporția (%) din dispersia erorii de prognoză pe 10 zile a băncii i datorată șocurilor băncii j , întreaga perioadă
- Conectivitatea totală $C = 63,9\%$: în medie, două treimi din riscul de volatilitate al unei bănci provin de la celelalte bănci
 - Pe randamente în loc de volatilitate: $C = 75,4\%$
- Două blocuri regionale: o bancă americană primește 84,0% din șocurile americane, iar una europeană 72,7% din șocurile europene, inclusiv șocul propriu
 - Peste Atlantic: o bancă europeană primește 26,2% de la băncile americane, o bancă americană 15,0% de la cele europene
- Erorile de prognoză ale volatilității băncilor românești provin mai ales din șocurile proprii: ponderea proprie 72,3% (Banca Transilvania) și 76,1% (BRD); primesc 10,3% de la băncile americane și 8,0% de la cele europene

Rețeaua de spillover net




- Săgeată de la j la i când j transmite net către i (cele mai mari 25% dintre spillover-urile nete pe perechi); mărimea nodului crește cu spillover-ul către ceilalți
- Transmițători neți: Citigroup (+19,0), Bank of America (+10,9), Morgan Stanley (+9,9), JPMorgan (+9,8)
 - Către ceilalți: Citigroup 93,8%, JPMorgan 86,2% (suma unei coloane poate depăși 100)
- Receptori neți: HSBC (−23,6), BRD (−13,0), Deutsche Bank (−12,6), Banca Transilvania (−12,2)
 - HSBC primește de la aproape toate băncile: se tranzacționează la Londra, între Asia și New York
- În Europa, BNP Paribas și ING transmit către Deutsche Bank și Santander
- O rețea pe întreaga perioadă face media anilor liniștiți și a celor de criză: graficul următor prezintă evoluția ei în timp

Conectivitatea în timp




- Sus: conectivitatea totală pe ferestre mobile de 250 de zile (VAR(2), $H = 10$, la fiecare 5 zile); jos: spillover-ul net însumat pe regiuni
- Indicele total variază între 47,4% (2024-07-24) și 79,3% (2020-08-27); media 62,0%
 - ▶ COVID-19: de la 61,8% în 2019 la 78,4% în primăvara lui 2020; urcă în câteva zile și scade pe parcursul unui an
 - ▶ După falimentele bancare din 2023, 66,0%; anul liniștit 2024, 53,5%
- Băncile americane sunt transmițători neți în 89% dintre ferestre (net mediu +48,4)
 - ▶ Băncile europene au fost transmițători neți în criza din zona euro din 2011–2012 și mai ales receptori neți după aceea
- Băncile românești sunt, în medie, receptori neți (−24,1)

Eroarea de estimare: intervale bootstrap pentru rețea



- Un VAR(1) pe 13 serii are 169 de coeficienți de pantă; o fereastră de 250 de zile dă 250 de observații pe ecuație pentru 13 pante, iar tabelul este o funcție neliniară a tuturor acestor coeficienți
- Bootstrap pe blocuri de reziduuri: reeșantionăm blocuri de 20 de zile din vectorii de reziduuri, reconstruim seriile cu VAR-ul estimat, reestimăm, recalculăm tabelul; 999 de extrageri
- Întreaga perioadă, $p = 2$: $C = 63,9\%$ cu intervalul de 95% [59,9, 65,8]
 - Fereastră vârfului (250 de zile până la 2020-08-27, $p = 2$): $C = 79,3\%$, interval [65,9, 83,0]; media bootstrap 75,8%, deci eșantioanele mici deplasează și C
- 8 din 13 poziții nete au intervale care exclud zero; pentru celelalte 5, eticheta „transmițător” sau „receptor” nu este identificată de date
- Raportăm intervalul lângă fiecare cifră netă și desenăm doar săgețile a căror legătură netă pe perechi este semnificativă

Conectivitatea OLS și elastic net pe ferestre mobile




- **Demirer et al. (2018), Ec. (9):** fiecare ecuație VAR prin elastic net adaptiv, λ ales ecuație cu ecuație prin validare încrucișată cu 10 grupe
- Întreaga perioadă, elastic net adaptiv: $C = 63,3\%$ (OLS 63,9%); 59% dintre coeficienți sunt nenuli
- Medii pe 372 ferestre: 62,0% (indicele capitolului), 61,1% (OLS, 150 de zile), 58,7% (elastic net, 150 de zile)
- Evoluțiile sunt asemănătoare: corelația 0,82 între indicele elastic net și indicele capitolului; vârfurile din crize sunt în aceleași săptămâni
- Nivelurile depind de fereastră, estimator și ordin; schimbările în timp sunt partea robustă a indicelui

Financial Risk Meter și penalizarea GACV


- Pentru fiecare firmă j , o regresie cuantilă la $\tau = 5\%$ a randamentului ei pe randamentele **tuturor** celorlalte firme și pe variabile macro întârziate Mihoci, Althof, Chen & Härdle (2020)
 - ▶ Cu 100 de firme și o fereastră de 63 de zile sunt mai mulți regresori decât zile: este nevoie de o penalizare
- Regresie cuantilă **LASSO** Belloni & Chernozhukov (2011)
 - ▶ $\hat{\beta}_j(\lambda) = \arg \min_{\beta} \frac{1}{n} \sum_t \rho_{\tau} \left(X_{j,t} - \beta_0 - \beta^{\top} Z_{-j,t} \right) + \lambda \|\beta\|_1$
 - ▶ λ elimină legăturile slabe: un λ mai mare lasă mai puțini coeficienți activi
- **GACV** (Generalized Approximate Cross-Validation, validare încrucișată aproximativă generalizată) echilibrează potrivirea cu numărul de coeficienți activi
 - ▶
$$\text{GACV}(\lambda) = \frac{\sum_t \rho_{\tau} \left(X_{j,t} - \hat{X}_{j,t}(\lambda) \right)}{n - \text{df}(\lambda)}, \text{ df} = \text{numărul coeficienților nenuli}$$
- **FRM** (Financial Risk Meter) este media valorilor λ_j alese pe toate firmele, construită ca indicator al interdependenței din coadă și al stresului sistemic
 - ▶ Construit pentru firmele financiare americane Mihoci, Althof, Chen & Härdle (2020), piețele emergente Ben Amor, Althof & Härdle (2022) și China Wang, Althof & Härdle (2023)
- Versiunea noastră: 13 bănci, variabile macro S&P 500, Euro Stoxx 50 și VIX la $t - 1$, ferestre de 63 de zile la fiecare 10 zile
 - ▶ 15 regresori pentru 63 de zile: mult mai puțini decât în FRM publicat
- Extensii: FRM bazat pe expectile Ren, Lu, Li & Härdle (2022), pentru criptomonede Ren, Althof & Härdle (2022) și pentru sectorul energetic din UE Toma, Dima, Grecu, Pele & Lessmann (2026)

GACV într-o fereastră calmă și într-una de criză



- Randamentul JPMorgan regresat pe randamentele celorlalte 12 bănci și pe trei variabile macro întârziate, 63 de zile; linia punctată: λ ales; portocaliu: coeficienți activi
- Fereastra calmă (până la 28 iunie 2019): $\hat{\lambda} = 4,5 \times 10^{-5}$, 11 din 15 coeficienți activi
 - Fereastra COVID-19 (până la 31 martie 2020): $\hat{\lambda} = 7,8 \times 10^{-5}$, 12 activi
- În criză întreaga curbă este de aproximativ trei ori mai sus: funcția de pierdere cuantilă este exprimată în unitățile randamentelor, iar randamentele sunt mai mari
- Cu puțini regresori, minimumul se află acolo unde aproape nu se aplică penalizare: alegerea este zgomotoasă

Financial Risk Meter pentru treisprezece bănci




- Sus: penalizarea GACV medie pe 13 bănci; jos: proporția predictorilor activi (12 bănci și 3 variabile macro întârziate) când λ este fix, împreună cu VIX; 390 ferestre de 63 de zile
- Penalizarea GACV medie este zgomotoasă; corelația ei cu VIX este doar 0,35
 - ▶ Cu 15 regresori și 63 de zile, estimarea aproape că nu are nevoie de penalizare; FRM publicat folosește aproximativ 100 de firme, astfel încât penalizarea să conteze cu adevărat
- La o penalizare fixă $\lambda = 2,3 \times 10^{-4}$, proporția predictorilor activi (legături cu băncile și variabile macro) urmează mai îndeaproape VIX: corelația este 0,62
 - ▶ De la 31% (2017-11-21) la 68% (2020-06-17); media 42%
- Lecția: această aplicație pe un panel mic nu arată că penalizările alese sau numărul predictorilor activi la penalizare fixă ar fi un indicator fiabil al riscului sistemic; numărul la penalizare fixă este doar o verificare exploratorie a sensibilității

Teste de stres și scenarii istorice

- ▣ Un test de stres întreabă cât am pierde într-un scenariu **sever, dar plauzibil: istoric** (reluăm o criză trecută), **ipotetic** (aplicăm șocuri unor factori aleși), **invers** (căutăm cel mai plauzibil scenariu din spatele unei pierderi fatale)
 - ▶ Teste de supraveghere pentru băncile mari: [Federal Reserve stress tests](#) în SUA, testele la nivelul UE ale [European Banking Authority](#); băncile de importanță sistemică globală dețin capital suplimentar [Basel Committee](#) (2018)
- ▣ Șapte episoade, fiecare o fereastră de câteva săptămâni în jurul unui șoc cunoscut
 - ▶ Lehman (toamna lui 2008), criza din zona euro (vara lui 2011), votul Brexit (iunie 2016), taxa bancară din România (decembrie 2018), COVID-19 (martie 2020), SVB și Credit Suisse (martie 2023), șocul tarifelor (aprilie 2025)
- ▣ În fiecare fereastră găsim **cele 10 zile consecutive de tranzacționare cu cel mai mic randament cumulat** al portofoliului bancar cu ponderi egale și raportăm randamentul fiecărei bănci în acest interval
- ▣ Episodul din 2008 folosește doar cele 11 bănci internaționale: seriile românești încep în 2010
- ▣ Zece zile corespund orizontului capitalului pentru riscul de piață (Capitolul 7)

Șapte scenarii istorice de stres




- Randamentul (%) fiecărei bănci în cele mai rele 10 zile consecutive ale portofoliului bancar cu ponderi egale din fiecare episod; gol: fără date
- Pierderea portofoliului în cele mai rele 10 zile: Lehman 37,6% (2008-11-10 – 2008-11-21), COVID-19 31,9%, criza din zona euro 22,3%
► Tarifele 16,0%, SVB 14,8%, taxa bancară din România 10,2%, Brexit 7,9%
- Cele mai mari pierderi individuale: Citigroup –68% în 2008, ING –48% în martie 2020
- Șocurile sunt și locale, nu doar globale: Brexit a lovit mai ales băncile europene; taxa bancară din România a lovit cel mai tare băncile românești (–26% și –26%), în timpul unei scăderi din decembrie 2018 care a costat și băncile americane între –8% și –14%
- Un test de stres construit doar pe crize globale ar rata șocul politic intern

Testarea inversă la stres

- Model factorial: randamentele log săptămânale (%) ale băncilor $X_i = \beta_i^\top f + e_i$, factorii $f = (\text{S\&P 500, Euro Stoxx 50, BET})$, pe h săptămâni $f \sim N(0, h\Sigma)$ (fără covarianțe seriale ale randamentelor săptămânale ale factorilor)
 - ▶ Pierderea portofoliului cu ponderi egale, în puncte de randament log: $L = -b^\top f$, cu b media valorilor β_i ; o aproximare doar pe factori, care pune reziduul $\sum_i w_i e_i$ egal cu zero
- Cel mai plauzibil scenariu cu pierderea ℓ^* minimizează distanța Mahalanobis $f^\top (h\Sigma)^{-1} f$ cu condiția $-b^\top f = \ell^*$
 - ▶ $f^* = -\ell^* \frac{h\Sigma b}{b^\top h\Sigma b}, \quad d^* = \frac{\ell^*}{\sqrt{b^\top h\Sigma b}}$
- d^* numără abaterile standard ale portofoliului: cu cât este mai mare, cu atât pierderea este mai puțin plauzibilă în model
- Un exemplu cu doi factori, rezolvat pas cu pas: Anexa și Seminarul 18, A7

Cel mai plauzibil scenariu pentru o pierdere log de 25%



- Date săptămânale 2010–2026 (871 săptămâni), orizont de patru săptămâni; roșu: f^* pentru o pierdere log $\ell^* = 25\%$; albastru: mișcările factorilor în cele mai rele patru săptămâni din 2020
- Beta ale portofoliului: $b = (0,45, 0,65, 0,18)$; abaterea standard pe patru săptămâni 5,79%
 - ▶ O pierdere log de 25% (o pierdere aritmetică de 22,1%) cere simultan randamente log S&P 500 -17,2%, Euro Stoxx 50 -22,6%, BET -13,9%
- Distanța $d^* = 4,31$: în modelul Normal probabilitatea ei este $8,0 \times 10^{-6}$ pe patru săptămâni, practic imposibilă
- Și totuși, în cele patru săptămâni până la 2020-03-20, portofoliul a pierdut 52,0% în termeni log, cu scăderi ale factorilor mai mari decât f^* (modelul implică 48,5%)
- Forma scenariului este informativă; probabilitatea lui nu este: cozile grele și corelațiile care cresc fac probabilitățile Normale mult prea mici

Riscul climatic și testul de stres climatic al ECB din 2022



Sediul Băncii Centrale Europene, Frankfurt, 2015

Foto: DXR (2015); CC BY-SA 4.0; Wikimedia

[Commons](#)

- Riscul fizic: pierderi din inundații, secete, caniculă și furtuni care afectează garanțiile și debitorii
 - ▶ Riscul de tranziție: pierderi din trecerea la o economie cu emisii reduse (prețul carbonului, reglementare, tehnologie)
- Riscuri de tip „lebedă verde”: evenimente potențial extrem de perturbatoare, care ar putea sta la baza următoarei crize financiare sistemice; modelele de risc bazate pe trecut nu le pot anticipa [Bolton et al. \(2020\)](#)
- Au participat 104 bănci semnificative; o proiecție bottom-up a pierderilor a acoperit 41 dintre ele [ECB Banking Supervision \(2022\)](#)
- Aproximativ 60% dintre bănci nu aveau un cadru de testare la stres pentru riscul climatic; doar 20% țineau cont de riscul climatic la acordarea creditelor
- Pierderi de credit și de piață de aproximativ 70 de miliarde EUR pentru cele 41 de bănci, într-un scenariu de tranziție dezordonată pe termen scurt și două scenarii de risc fizic
 - ▶ ECB precizează că cifra subestimează semnificativ riscul: lipsă de date, modele rudimentare, fără efecte de runda a doua

Limitele testelor de stres

- ▣ Scenariile sunt alese de oameni: criza care vine este rareori cea care a fost testată
- ▣ Efectele de runda a doua (vânzări forțate, retrageri de finanțare, pierderi ale contrapărților) sunt greu de modelat și de obicei lipsesc, cum a observat ECB pentru testul său climatic
- ▣ Măsurile bazate pe piață (MES, CoVaR, conectivitate) reacționează repede, dar doar după ce prețurile se mișcă; testele de stres bazate pe bilanț evaluează riscurile viitoare, dar necesită mai mult timp
- ▣ Cercetarea despre semnalele de avertizare timpurie le combină pe amândouă, de ex. măsurile de risc de piață bazate pe entropie [Pele, Lazar & Dufour \(2017\)](#)


Studiu de caz: întrebarea și motivația

- Ando, Greenwood-Nimmo & Shin (2022) se întreabă dacă topologia unei rețele financiare se schimbă cu **mărimea** șocurilor care o lovesc (Secțiunea 1)
 - Pornind de la Diebold & Yilmaz (2014), autorii întreabă cum variază, în funcție de mărimea șocurilor, contribuția șocurilor idiosincratice ale lui j la incertitudinea viitoare a lui i .
- De ce contează: conectivitatea din acest capitol se estimează la media condiționată (OLS, LASSO, elastic net Demirer et al. (2018)), adică descrie cum se propagă un șoc mediu
 - Șocurile sistemice sunt mai mari decât media; interpretarea creșterii conectivității pe ferestre mobile ca semnal de criză presupune că relațiile estimate la medie se mențin și în cozi (Secțiunea 1)
- Legătura cu acest capitol: regresia cuantilă folosită pentru CoVaR Adrian & Brunnermeier (2016), Koenker & Bassett (1978) este aplicată aici modelului VAR, pe baza căruia se descompune dispersia
 - Giglio, Kelly & Pruitt (2016) au arătat că riscul sistemic deplasează coada inferioară a producției viitoare mai mult decât centrul ei; Ando, Greenwood-Nimmo & Shin (2022) pun aceeași întrebare, coadă față de centru, pentru rețeaua însăși
- Aplicația: interdependența dintre riscul de credit al statelor și cel al băncilor, în care operațiunile de salvare transferă riscul bancar către stat (Secțiunile 1 și 3)

Studiu de caz: date și metodă

- ▣ Datele (Secțiunea 3): diferențele zilnice ale spread-urilor CDS pe 5 ani (puncte de bază) pentru 17 state și 17 sectoare financiare naționale, $m = 34$, 3 ianuarie 2006 – 29 decembrie 2017, 3 129 de zile
- ▣ VAR cuantil cu factori (QFVAR), Ec. (5)–(7): $y_t = \mu + \sum_{j=1}^p \Phi_j y_{t-j} + \Lambda f_t + v_t$, fiecare ecuație estimată la cuantila τ prin minimizarea funcției de pierdere cuantilă
 - ▶ Factorii neobservați f_t preiau șocurile comune, deci v_t este idiosincratic; numărul lor este ales după criteriul din [Ando & Bai \(2020\)](#), Ec. (8): 10 la medie (Figura 1)
- ▣ FEVD generalizată a șocurilor idiosincratice la cuantila τ , Ec. (17), cu liniile normalizate la 1; indicele de spillover $S_\tau^{(h)} = m^{-1} \sum_i F_{i \leftarrow \bullet, \tau}^{(h)}$, Ec. (20)
- ▣ Ferestre mobile de $w = 250$ de zile (2 880 de ferestre), numărul factorilor fixat la valoarea din întregul eșantion; dependența relativă în cozi RTD = $S_{0,95}^{(5)} - S_{0,05}^{(5)}$ (Secțiunea 4.3)
 - ▶ Pentru variațiile CDS, coada dreaptă ($\tau = 0,95$) conține șocurile adverse mari, iar coada stângă ($\tau = 0,05$) pe cele favorabile mari
- ▣ Specificația completă (criteriul pentru factori, ordinul VAR, orizontul) și rezultatele complete: Anexă


Studiu de caz: spillover-ul pe cuantile



- Indicele de spillover $S_\tau^{(5)}$ al QFVAR pe întregul eșantion, la fiecare cuantilă τ , față de indicele la media condiționată; sursa: Ando, Greenwood-Nimmo & Shin (2022), Figura 4
- Profilul are formă de U: circa 40% în centru, 88,18% la $\tau = 0,01$ și 91,77% la $\tau = 0,99$, de peste două ori nivelul din centru
 - Indicele la medie (56,57%) se află între cele două regimuri și nu descrie niciunul: prea mare pentru șocurile mici, prea mic pentru cele mari
- Pe întregul eșantion cele două cozi sunt aproape simetrice:
 - RTD = 79,36 – 77,17 = 2,19 puncte procentuale
 - Asimetria este mai pronunțată și variază în timp pe ferestre mobile (graficul următor)
- Consecința pentru testele de stres: un scenariu construit pe conectivitatea la medie subestimează ce proporție din dispersia erorii de prognoză pe 5 zile a unui sector provine, într-o criză, din șocurile idiosincratice ale altor sectoare

MFM_ch18_quantile_connectedness

Studiu de caz: cozile evoluează diferit



- Stânga: corelațiile dintre indicii pe ferestre mobile ($w = 250$ de zile, $h = 5$); dreapta: corelațiile lunare cu CATFIN; sursa: [Ando, Greenwood-Nimmo & Shin \(2022\)](#), Tabelul 3 și Figura 13
- Indicele la medie urmează coada adversă (0,774 cu $S_{0,95}$) mult mai îndeaproape decât coada favorabilă (0,411 cu $S_{0,05}$)
 - Variațiile indicelui estimat la medie reflectă mai ales coada adversă; creșterea lui este astfel interpretată ca o intensificare a transmiterii șocurilor adverse
- Cele două cozi au puțină variație comună (0,367): sunt doi indicatori, nu același indice măsurat de două ori
 - De aceea RTD este informativ: pe ferestre mobile ajunge la circa ± 15 puncte procentuale, față de 2,19 pe întregul eșantion
- Față de CATFIN: 0,51 pentru $S_{0,95}$, 0,42 pentru RTD, doar 0,15 pentru $S_{0,05}$
 - CATFIN este mai puternic corelat cu intensitatea transmiterii șocurilor adverse decât cu cea a șocurilor favorabile

Studiu de caz: replicare, limite, extindere

- Replicare cu datele cursului: prețurile zilnice de închidere ale celor 13 bănci din acest capitol, din data/market (SUA, zona euro și Regatul Unit, România), 2010–2026; y_t = pierderea zilnică $-r_t$ în %, astfel încât coada dreaptă să fie cea adversă, ca la CDS
 - Limite ale datelor: pierderi din acțiuni în loc de variații ale spread-urilor CDS, 13 bănci și niciun stat ($m = 13$ în loc de 34), ore de închidere diferite pe piețele din SUA, Europa și România
- Limitele precizate de autori: ordinul VAR ales pentru media condiționată este păstrat la fiecare cuantilă, iar cuantila rămâne fixă pe orizont (Secțiunile 2.1–2.2, nota 6)
- Extindere deschisă: crește RTD al celor 13 bănci înainte de martie 2020 și de falimentele bancare din martie 2023 și anticipează stresul bancar dincolo de volatilitatea curentă și de indicele bazat pe medie din acest capitol? Pentru prognoză, ordinul și factorii se aleg doar pe un eșantion de antrenare

O întrebare deschisă

Măsoară conectivitatea rețelei riscul sistemic sau doar volatilitatea?

- Indicii de conectivitate sunt urmăriți ca instrumente de avertizare timpurie, dar un indice construit dintr-un VAR pe volatilități poate evolua odată cu volatilitatea fără să adauge informație predictivă
 - ▶ Cercetare în curs: rețele bancare globale din VAR-uri regularizate [Demirer et al. \(2018\)](#); conectivitatea în cozi diferă de cea în medie [Ando, Greenwood-Nimmo & Shin \(2022\)](#)
- Formularea matematică, pentru stresul viitor al băncilor y_{t+h} , conectivitatea totală C_t și volatilitatea curentă σ_t :
$$y_{t+h} = a + \beta_C C_t + \gamma \ln \sigma_t + e_{t+h}, \quad H_0: \beta_C = 0, \quad H_1: \beta_C > 0$$
 - ▶ Argument împotriva: după controlul pentru volatilitatea curentă, intervalul de încredere pentru β_C exclude efectele relevante economic; lipsa semnificației statistice nu este suficientă
- Identificarea: o muchie a rețelei este o proporție din dispersia erorii de prognoză, nu o expunere cauzală
 - ▶ Un șoc comun crește simultan volatilitatea și conectivitatea, fără ca vreo bancă să o contamineze pe alta

Bucula descoperirii, pas cu pas

- **Literatura:** cartografiem ce se știe, apoi verificăm fiecare referință
 - ▶ Verificăm fiecare DOI pe [Crossref](#) și verificăm că articolul chiar controlează volatilitatea; căutăm cu Semantic Scholar, Elicit sau Google Scholar
- **Ipoteze:** interpretări concurente ale unei creșteri a conectivității, fiecare cu testul ei
 - ▶ De exemplu, un șoc comun dispare odată cu volatilitatea; contagiunea are o direcție: șocurile transmițătorilor neți le preced pe ale receptorilor
- **Date și cod:** pe datele cursului, replicând întâi o cifră cunoscută
 - ▶ Replicăm întâi: media 62,0% și maximumul 79,3% (2020-08-27), ca în acest capitol
- **Robustețea,** fixată înainte de a rula regresii predictive
 - ▶ Fiecare celulă a grilei este raportată; familia este corectată cu Holm sau controlată prin FDR
- **Critica:** îi cerem asistentului să atace rezultatul
 - ▶ Ne așteptăm la: adăugăm volatilitatea curentă ca variabilă de control, apoi testăm creșterea lui R^2 și a pierderii în afara eșantionului
- **Raportul:** efecte standardizate cu statistici t HAC, fiecare celulă a grilei, ce a eșuat
 - ▶ Prompturile care au influențat planul analizei sunt consemnate în `AI_USE.md`
- Prompturi reutilizabile pentru fiecare pas și lista de verificări a cercetătorului: Anexă

Mini-caz: este conectivitatea mai mult decât volatilitate?

- O propunere tipică a asistentului: „o conectivitate totală ridicată anunță stresul viitor al băncilor”; o testăm pe 731 date săptămânale, 2011–2026
 - ▶ y_{t+h} : logaritmul volatilității Parkinson medii a celor 13 bănci în următoarele $h = 63$ zile; control: aceeași mărime în ultimele 20 de zile; variabile standardizate, Newey–West cu 13 decalaje
- Conectivitatea singură: $\hat{\beta}_C = 0,40$ ($t = 4,63$), $R^2 = 0,16$: propunerea pare corectă
- Cu volatilitatea curentă: $\hat{\beta}_C = 0,08$ ($t = 0,75$), $\hat{\gamma} = 0,53$ ($t = 4,13$); $R^2 = 0,343$ față de 0,339 doar cu volatilitatea
 - ▶ Corelația lui C_t cu volatilitatea curentă: 0,59; pentru scăderea maximă a portofoliului băncilor în următoarele 63 de zile, $\hat{\beta}_C = -0,10$ ($t = -1,32$) chiar și singură
- Interpretare: odată controlată volatilitatea curentă, contribuția suplimentară a conectivității nu este semnificativă; asta nu dovedește că e zero, dar în eșantionul nostru persistența volatilității explică cea mai mare parte a conținutului predictiv; informația de rețea poate conta totuși în cozi [Ando, Greenwood-Nimmo & Shin \(2022\)](#) sau pentru direcția transiterii

Rândul vostru: o idee de proiect

- **Întrebarea:** prezice conectivitatea în **cozi** dificultățile băncilor dincolo de volatilitate, în afara eșantionului?
- **Replicați întâi:** indicele nostru pe ferestre mobile (media 62,0%, primăvara lui 2020 78,4%), apoi o cifră principală de conectivitate din [Demirer et al. \(2018\)](#) pe eșantionul lor
 - ▶ Extindeți: conectivitatea cuantilă la $\tau = 5\%$ [Ando, Greenwood-Nimmo & Shin \(2022\)](#), evaluare în afara eșantionului din 2018, MES și SRISK ca ținte alternative
- **Livrabile:** o grilă preînregistrată, salvată înaintea regresiilor, un notebook care regenerează fiecare cifră, inferență HAC și pierderi în afara eșantionului pentru fiecare celulă
- **Jurnalul AI:** prompturile care au modelat designul în AI_USE.md; fiecare afirmație greșită (un VAR pe nivelurile prețurilor, statistici t OLS pe ferestre suprapuse) și testul care a prins-o în AI_ERRORS.md ([șabloane](#))

Care bancă este cea mai sistemică?

Banca	VaR 1%	MES 5%	ΔCoVaR 1%	Spillover net	L^*
JPMorgan	4,83	3,22	4,62	9,8	7,0
Bank of America	5,99	3,85	4,60	10,9	6,2
Citigroup	5,87	4,03	3,81	19,0	6,0
Goldman Sachs	4,81	3,34	4,12	2,4	6,8
Morgan Stanley	5,83	4,04	4,00	9,9	6,0
Wells Fargo	5,78	3,32	4,89	3,6	6,8
Deutsche Bank	7,19	4,54	4,24	-12,6	6,1
BNP Paribas	6,18	4,53	4,84	6,0	6,1
Santander	5,83	4,23	4,42	-5,4	6,4
ING	7,16	4,81	4,42	5,2	5,8
HSBC	4,66	2,54	4,07	-23,6	8,3
Banca Transilvania	5,06	3,14	—	-12,2	6,5
BRD-Groupe SG	4,42	2,69	—	-13,0	7,1

- ▣ Pierderi zilnice în %; spillover-ul net a volatilității (către minus de la); L^* : levierul de echilibru cu $k = 8\%$
- ▣ Corelații de rang pe cele unsprezece bănci internaționale
 - MES și ΔCoVaR : -0,01; MES și spillover-ul net: 0,04; ΔCoVaR și spillover-ul net: -0,01
 - VaR și MES: 0,88
- ▣ Nu există un clasament unic: supraveghetorii combină mai mulți indicatori cu mărimea și datele din bilanț, ca în metodologia [Basel Committee \(2018\)](#)
- ▣ Băncile românești: MES moderat, receptori neți de volatilitate, levier de echilibru apropiat de cel al băncilor americane

Idei principale

- ▣ Riscul sistemic se manifestă în coada distribuției comune: expunere (MES, SRISK), contribuție (ΔCoVaR) și conectivitate (rețele de spillover și rețele în coadă)
- ▣ Băncile europene au cele mai mari MES din eșantionul nostru; băncile americane sunt principalii transmițători neți de volatilitate
- ▣ VaR și ΔCoVaR ordonează băncile diferit; clasamentele sunt incerte: testați diferențele, raportați intervale, precizați αn
- ▣ Măsurile bazate pe piață urcă brusc în crize; testele de stres și bilanțurile sunt necesare pentru a vedea cum se acumulează riscul
- ▣ Cea mai mare parte din dispersia erorii de prognoză a volatilității băncilor românești provine din șocurile proprii; ele primesc mai mult decât transmit

Greșeli frecvente

- Interpretarea ΔCoVaR ca efect causal: un șoc comun creează același tipar
- Interpretarea intervalelor suprapuse drept „egale” și a celor separate drept „diferite”: testăm diferența pe extrageri comune și corectăm pentru numărul de perechi
- Includerea băncii în portofoliul sistemului: propriul randament adaugă o contribuție mecanică proprie la legătură
- Descompuneri ortogonale ale dispersiei ale căror rezultate depind de ordinea băncilor
- Raportarea SRISK fără date din bilanț sau din aproximarea $1 - e^{-18\text{MES}}$ ca și cum ar fi măsura publicată
- Desenarea fiecărei muchii Granger semnificative la 5% din 156 de teste sau a fiecărei etichete nete fără intervalul ei

Anexă: MES ca contribuție Euler: demonstrație

- Portofoliul $X_p = \sum_i w_i X_i$ cu distribuție continuă; $ES_\alpha(X_p) = -\mathbb{E}[X_p \mid X_p \leq q_\alpha(X_p)]$
 - ▶ ES_α este pozitiv omogen de gradul 1 în w , deci din teorema lui Euler $ES_\alpha(X_p) = \sum_i w_i \partial ES_\alpha / \partial w_i$
 - ▶ Derivând $-\frac{1}{\alpha} \mathbb{E}[X_p \mathbf{1}\{X_p \leq q_\alpha(w)\}]$: termenul în $\partial q_\alpha / \partial w_i$ este $-\frac{1}{\alpha} q_\alpha f_p(q_\alpha) \partial q_\alpha / \partial w_i + \frac{1}{\alpha} q_\alpha f_p(q_\alpha) \partial q_\alpha / \partial w_i = 0$
 - ▶ Deci $\partial ES_\alpha / \partial w_i = -\mathbb{E}[X_i \mid X_p \leq q_\alpha(X_p)] = MES_{i,\alpha}$ cu $m = p$ [Gouriéroux, Laurent & Scaillet \(2000\)](#), [Scaillet \(2004\)](#)
- Verificare pe datele noastre: portofoliul cu ponderi egale al celor șase bănci americane, $\alpha = 5\%$ (198 zile în coadă)
 - ▶ $ES_{5\%}$ al portofoliului = 4,32% = media celor șase MES condiționate pe portofoliu (4,32%): exact, și pentru estimatorul istoric
 - ▶ Condiționând pe S&P 500 obținem un MES mediu de 3,63% (JPMorgan: 3,22% față de 3,85%): identitatea nu mai este valabilă când $m \neq p$
- Sub distribuția Normală bivariată cu medii zero, $MES_{i,\alpha} = \beta_i ES_\alpha(X_m)$: un beta înmulțit cu o constantă (Seminarul 18, A3)

Anexă: Simularea LRMES: inovații și recursii

- Reziduurile standardizate $\epsilon_{it} = r_{it}/\sigma_{it}$, $\epsilon_{mt} = r_{mt}/\sigma_{mt}$; S este matricea corelațiilor lor estimate din eșantion, ținta pe termen lung a lui Q_t
 - Inovația băncii ortogonală față de piață: $\xi_{it} = (\epsilon_{it} - \rho_t \epsilon_{mt})/\sqrt{1 - \rho_t^2}$ Brownlees & Engle (2017), Anexa A
- În fiecare zi simulată s : extragem o dată din eșantionul istoric τ , luăm perechea $(\xi_{i\tau}, \epsilon_{m\tau})$ și reconstruim șocul băncii cu corelația simulată
 - $\epsilon_{i,t+s} = \rho_{t+s} \epsilon_{m\tau} + \sqrt{1 - \rho_{t+s}^2} \xi_{i\tau}$, apoi actualizăm σ^2 și Q cu noile randamente
- Restricții: $\omega > 0$, $\alpha \geq 0$, $\alpha + \gamma \geq 0$, $\beta \geq 0$, $\alpha + \gamma/2 + \beta < 1$ (dispersie finită pentru inovații simetrice; în general $\alpha + \gamma \mathbb{E}[\epsilon^2 \mathbf{1}\{\epsilon < 0\}] + \beta < 1$); $a, b > 0$, $a + b < 1$, astfel încât $\sigma_t^2 > 0$ și Q_t să fie pozitiv definită
 - Inițializarea: $Q_1 = S$ la estimare; simularea pornește de la σ_{T+1}^2 și Q_{T+1} filtrate până la ultima dată

Anexă: Regresia cuantilă: asimptotica

- Asimptotica pentru α fix, cu $x_t = (1, X_{i,t})^\top$ și f_t densitatea condiționată a lui Y în cuantila de ordin α
 - ▶ $\sqrt{n}(\hat{\theta}_\alpha - \theta_\alpha) \Rightarrow N\left(0, \alpha(1 - \alpha) D_1^{-1} D_0 D_1^{-1}\right)$, $D_0 = \mathbb{E}[x_t x_t^\top]$, $D_1 = \mathbb{E}[f_t x_t x_t^\top]$
 - ▶ Presupune observații independente (sau scoruri $x_t(\alpha - 1\{u_t < 0\})$ de tip diferență de martingală), $f_t > 0$ în jurul cuantilei și D_0 , D_1 pozitiv definite; cu scoruri dependente serial, D_0 cere o estimare de termen lung (HAC) sau un bootstrap pe blocuri
 - ▶ **Inversa densității** $1/f_t$ trebuie estimată (nucleu sau lățime de bandă); la $\alpha = 1\%$ puține observații sunt aproape de cuantilă, deci această estimare este zgomotoasă
- Panta b_α se poate schimba cu α : banca poate conta mai mult pentru sistem în coadă decât în centru; metoda celor mai mici pătrate dă doar panta pentru medie

Anexă: Cuantile extreme: de ce $\alpha = 1\%$ este dificil

- Eșantionul efectiv din coadă este αn : 40 de zile la 1% și 198 la 5% din 3 960
 - ▶ Aproximarea Normală de mai sus presupune că $\alpha n \rightarrow \infty$ rapid; cu αn de câteva zeci poate fi slabă, iar teoria cuantilelor extreme (limite de valori extreme, subeșantionare) este alternativa construită pentru acest caz [Chernozhukov & Fernández-Val \(2011\)](#)
- În datele noastre, eroarea standard bootstrap pe blocuri a ΔCoVaR 1% este de aproximativ 0,6 ori eroarea standard bazată pe nucleu (mediana pe bănci): cele două metode dau rezultate foarte diferite
 - ▶ Eroarea standard cu nucleu se bazează pe o estimare a inversei densității din puținele observații din jurul cuantilei de 1%; bootstrap-ul reextrage aceleași puține zile din coadă: niciuna nu este fiabilă când αn este atât de mic
- Regulă practică: raportăm $\alpha = 5\%$ și $\alpha = 1\%$ împreună cu αn ; ne așteptăm ca clasamentul de 1% să fie mai zgomotos
 - ▶ Corelația Spearman mică dintre clasamentele de 1% și 5% (0,10) poate reflecta zgomotul de estimare, diferențe reale între cele două niveluri din coadă sau ambele

Anexă: Testarea ΔCoVaR : trei ipoteze

- (1) Nicio contribuție, $H_0: b_\alpha = 0$: test Wald cu dispersia de tip sandviș a regresiei cuantile Koenker & Bassett (1978)
 - ▶ Testele ipotezelor liniare între cuantile folosesc asimptotica comună a lui $(\hat{b}_\alpha, \hat{b}_{50\%})$ Koenker & Bassett (1982)
- (2) Legătura din coadă este egală cu cea din centru, $H_0: b_\alpha = b_{50\%}$: este banca specială în crize?
 - ▶ Estimăm dispersia lui $\hat{b}_\alpha - \hat{b}_{50\%}$ din 999 de extrageri bootstrap pe blocuri mobile care păstrează perechile de zile împreună
- (3) Contribuții egale, $H_0: \Delta\text{CoVaR}_i = \Delta\text{CoVaR}_j$: aceleași zile reeșantionate pentru **toate** băncile dau distribuția comună
 - ▶ $z_{ij} = (\widehat{\Delta\text{CoVaR}_i} - \widehat{\Delta\text{CoVaR}_j}) / \widehat{\text{se}}^*(\cdot)$ pentru fiecare pereche; corecția Holm pe familia de perechi Holm (1979); un test Wald comun al egalității tuturor contribuțiilor
 - ▶ Teste de semnificație și de dominanță pentru importanța sistemică: Castro & Ferrari (2014)

Anexă: Testarea ΔCoVaR 1%: rezultate

Banca	ΔCoVaR	$\hat{b}_{1\%}$	z	$\hat{b}_{50\%}$	$\hat{b}_{1\%} - \hat{b}_{50\%}$	p
JPMorgan	4,62	0,94	6,9	0,96	-0,02	0,66
Bank of America	4,60	0,76	6,5	0,78	-0,02	0,73
Citigroup	3,81	0,64	4,7	0,76	-0,11	0,00
Goldman Sachs	4,12	0,85	5,6	0,84	0,00	0,99
Morgan Stanley	4,00	0,68	4,5	0,73	-0,05	0,28
Wells Fargo	4,89	0,84	4,3	0,78	0,06	0,17
Deutsche Bank	4,24	0,59	4,1	0,60	-0,02	0,67
BNP Paribas	4,84	0,77	6,5	0,74	0,03	0,37
Santander	4,42	0,75	4,5	0,69	0,07	0,07
ING	4,42	0,61	4,4	0,71	-0,10	0,00
HSBC	4,07	0,87	4,0	0,86	0,01	0,96

- z : raportul t cu nucleu (sandviș) pentru $\hat{b}_{1\%}$, valid doar pentru scoruri independente serial: fiecare bancă contribuie; p : testul bootstrap pentru $b_{1\%} = b_{50\%}$, semnificativ pentru 2 din 11 bănci (2 după Holm)
- Contribuții egale în fiecare regiune: 4 din 25 perechi diferă la 5%, 0 după Holm; testul Wald comun $p = 0,01$ (SUA), 0,31 (Europa)
 - La 5%: 3 din 25 perechi diferă, 0 după Holm; testul Wald comun $p = 0,014$ (SUA), 0,046 (Europa)

Anexă: ΔCoVaR variabil în timp, cu variabile de stare

- Variabile de stare M_{t-1} : log VIX, randamentul indicelui regional și al sistemului, toate întârziate cu o zi [Adrian & Brunnermeier \(2016\)](#)
 - ▶ $q_\alpha(X_{i,t} | M_{t-1}) = a_i + c_i^\top M_{t-1}$ la α și la 50%
 - ▶ $q_\alpha(X_t^{\text{sys}} | X_{i,t}, M_{t-1}) = a + b X_{i,t} + c^\top M_{t-1}$
- Apoi $\Delta\text{CoVaR}_{\alpha,t} = \hat{b} (\hat{q}_{50\%,t}(X_i) - \hat{q}_{\alpha,t}(X_i))$
 - ▶ Variaza odată cu VaR-ul condiționat al băncii, care depinde de VIX
- Panta $\hat{b}$ este constantă: variația în timp vine din stare, nu din legătură

Anexă: Backtesting pentru CoVaR și MES

- Măsurile sistemice sunt măsuri de risc condiționate, deci au nevoie de **backtesting condiționat** Banulescu-Radu, Hurlin, Leymarie & Scaillet (2021)
 - ▶ Pentru $\text{CoVaR}^{\leq}$: evenimentul $I_t = 1\{X_t^{\text{sys}} \leq -\text{CoVaR}_t^{\leq}, X_{i,t} \leq -\text{VaR}_{i,t}\}$ cu $P(I_t = 1) = \alpha^2$ sub H_0 dacă atât VaR-ul băncii, cât și cuantila condiționată sunt calibrate; testele Kupiec și Christoffersen pe I_t (Capitolul 8), plus o verificare separată a ratei VaR a băncii
 - ▶ Pentru MES: procesul cumulat al depășirilor comune din Banulescu-Radu, Hurlin, Leymarie & Scaillet (2021)
- Verificarea noastră în afara eșantionului: $\text{CoVaR}_{5\%}^{\leq}$ istoric pe o fereastră extinsă de la ziua 1000, 2960 zile de prognoză pentru fiecare bancă
 - ▶ Evenimente comune așteptate 7,4; observate 5–9 pentru cele unsprezece bănci (JPMorgan 9); cel mai mic p Kupiec = 0,35: nicio respingere
 - ▶ Puterea este limitată: dacă rata comună reală ar fi dublul lui α^2 , testul Kupiec de 5% ar respinge în 62% din eșantioanele de această lungime cu evenimente independente, deci chiar și o dublare este ratată aproximativ o dată din trei

Anexă: Ipotezele VAR și ordinul indicelui pe ferestre mobile

- Autoregresie vectorială (VAR, vector autoregression) de ordin p pentru N serii y_t : $y_t = c + \sum_{l=1}^p A_l y_{t-l} + \varepsilon_t$, $\text{Cov}(\varepsilon_t) = \Sigma$
 - ▶ Ipoteze: VAR stabil (rădăcinile lui $\det(I - \sum_l A_l z^l)$ în afara cercului unitate), ε_t necorelate serial, cu Σ finită și pozitiv definită
 - ▶ Reprezentarea de tip medie mobilă: $y_t = \mu + \sum_{h \geq 0} \Phi_h \varepsilon_{t-h}$, $\Phi_0 = I$, $\Phi_h = \sum_{l=1}^p A_l \Phi_{h-l}$ ($\Phi_h = 0$ pentru $h < 0$); e_i : al i -lea vector unitar
- Ordinul: $p = 2$ este fix în toate ferestrele, pentru ca indicele să nu sară când se schimbă ordinul ales; BIC alege $p = 1$ în 100% dintre ferestre, iar cu $p = 1$ indicele are corelația 0,99 cu cel prezentat

Anexă: VAR-uri regularizate: elastic net

- Demirer et al. (2018), Ec. (9): fiecare ecuație VAR prin elastic net adaptiv, λ ales ecuație cu ecuație prin validare încrucișată cu 10 grupe
 - ▶ $\hat{\beta} = \arg \min_{\beta} \sum_t (y_t - \sum_i \beta_i x_{it})^2 + \lambda \sum_i w_i (\frac{1}{2} |\beta_i| + \frac{1}{2} \beta_i^2)$, $w_i = 1/|\hat{\beta}_{i,OLS}|$
 - ▶ Ferestre mobile de 150 de zile cu elastic net simplu, $w_i = 1$ (Secțiunea 5, nota 15); orizontul de prognoză $H = 10$
- De ce: selecție și shrinkage ale coeficienților VAR, fără a impune o rețea rară (legăturile vin și prin Σ)
 - ▶ Lucrarea nu precizează ordinul în text; păstrăm ordinul BIC al VAR-ului nostru OLS, $p = 2$
- Întreaga perioadă, elastic net adaptiv: $C = 63,3\%$ (OLS 63,9%); 59% dintre coeficienți sunt nenuli
 - ▶ Cu aproximativ 4000 de zile penalizarea aproape că nu contează; contează în ferestrele scurte (graficul pe ferestre mobile din textul principal)

Anexă: Rețele de cauzalitate Granger și testarea multiplă

- Billio, Getmansky, Lo & Pelizzon (2012) desenează o muchie $j \rightarrow i$ când j cauzează în sens Granger variabila i la 5%; cu 13 bănci sunt $13 \times 12 = 156$ de teste
 - ▶ Chiar fără nicio legătură, aproximativ 7,8 muchii ar apărea din întâmplare
- Testele noastre: regresii bivariate, o întârziere, statistici Wald robuste la heteroscedasticitate
 - ▶ Randamente zilnice: 57 muchii la 5%, 33 după Holm [Holm \(1979\)](#), 55 cu rata descoperirilor false controlată la 5% [Benjamini & Hochberg \(1995\)](#)
 - ▶ Logaritmul volatilității, foarte persistent: o întârziere suplimentară netestată [Toda & Yamamoto \(1995\)](#), ca în testele cu întârzieri suplimentare din [Shi, Hurn & Phillips \(2020\)](#): 153, 150 și 153 muchii
- Holm controlează probabilitatea oricărei muchii false pentru orice dependență; FDR este proporția **așteptată** a muchiilor false printre cele desenate, iar BH o garantează pentru teste independente [Benjamini & Hochberg \(1995\)](#), în timp ce testele pe perechi de bănci suprapuse sunt dependente
- Randamente zilnice ale unor bănci din fusuri orare diferite: multe muchii „cauzale” arată doar că New York se închide după Frankfurt

Anexă: Exemplu lucrat: test invers de stres cu doi factori

- Beta $b = (1,2, 0,8)$; covarianța pe patru săptămâni a factorilor $h\Sigma = \begin{pmatrix} 16 & 6 \\ 6 & 9 \end{pmatrix} (\%^2)$; pierderea țintă $\ell^* = 20\%$
 - ▶ $h\Sigma b = (1,2 \cdot 16 + 0,8 \cdot 6, ; 1,2 \cdot 6 + 0,8 \cdot 9) = (24, 14,4)$
 - ▶ $b^\top h\Sigma b = 1,2 \cdot 24 + 0,8 \cdot 14,4 = 40,32$, abaterea standard 6,35%
- Cel mai plauzibil scenariu și distanța lui
 - ▶ $f^* = -20 \cdot (24, 14,4)/40,32 = (-11,9\%, -7,1\%)$, $d^* = 20/6,35 = 3,15$
 - ▶ Probabilitatea Normală a unei pierderi cel puțin atât de mari: $\Phi(-3,15) = 0,08\%$ pe patru săptămâni
- Scenariul pune mai multă greutate pe factorul cu beta și dispersie mai mari, iar ambii factori scad împreună pentru că sunt corelați

Anexă: Studiu de caz: date și metodă

- Datele (Secțiunea 3): diferențele zilnice ale spread-urilor CDS pe 5 ani (puncte de bază) pentru 17 state și 17 sectoare financiare naționale, $m = 34$, 3 ianuarie 2006 – 29 decembrie 2017, 3 129 de zile
 - ▶ Un sector financiar = media cu ponderi egale a CDS-urilor băncilor și asigurătorilor cu active de cel puțin 10 miliarde USD, 199 de instituții în total
- VAR cuantil cu factori (QFVAR), Ec. (5)–(7): $y_t = \mu + \sum_{j=1}^p \Phi_j y_{t-j} + \Lambda f_t + v_t$, fiecare ecuație estimată la cuantila τ prin minimizarea funcției de pierdere cuantilă
 - ▶ Factorii neobservați f_t preiau șocurile comune, deci v_t este idiosincratic; numărul lor este ales după criteriul din [Ando & Bai \(2020\)](#), Ec. (8): 10 la medie (Figura 1)
 - ▶ Perechi de reziduuri cu $|\rho| < 0,25$: 91,6% cu factori, sub jumătate fără factori (Figura 2)
- FEVD generalizată a șocurilor idiosincratice la cuantila τ , Ec. (17), cu liniile normalizate la 1; indicele de spillover $S_{\tau}^{(h)} = m^{-1} \sum_i F_{i \leftarrow \bullet, \tau}^{(h)}$, Ec. (20)
 - ▶ VAR(1) ales după BIC la medie și păstrat la fiecare cuantilă; $h = 5$ zile; cuantila rămâne fixă pe orizontul de prognoză (Secțiunile 2.2 și 4)
- Ferestre mobile de $w = 250$ de zile (2 880 de ferestre), numărul factorilor fixat la valoarea din întregul eșantion; dependența relativă în cozi RTD = $S_{0,95}^{(5)} - S_{0,05}^{(5)}$ (Secțiunea 4.3)
 - ▶ Pentru variațiile CDS, coada dreaptă ($\tau = 0,95$) conține șocurile adverse mari, iar coada stângă ($\tau = 0,05$) pe cele favorabile mari

Anexă: Studiu de caz: rezultatele principale

- ▣ Indicele de spillover pe întregul eșantion (Figura 4): circa 40% în zona centrală de 40% a distribuției; 72,20%, 77,17%, 88,18% la $\tau = 0,10$; 0,05; 0,01; 73,34%, 79,36%, 91,77% la $\tau = 0,90$; 0,95; 0,99; 56,57% la medie
 - ▶ Șocurile mici rămân locale; șocurile mari, favorabile sau adverse, se propagă; media combină cele două regimuri într-o singură cifră
- ▣ Din cele 1 122 de spillover-uri bilaterale, 568 sunt sub 1% la medie și 829 la mediană (Figura 7)
 - ▶ Departate de medie, rețeaua are multe legături slabe, nu câteva legături puternice; în cozi, aceste legături slabe se adună în spillover-uri medii puternice
- ▣ Ferestre mobile (Tabelul 3): indicele la medie are corelația 0,774 cu $S_{0,95}$, dar 0,411 cu $S_{0,05}$; cele două cozi au corelația de doar 0,367
 - ▶ Cozile evoluează diferit: RTD este 2,19 puncte procentuale pe întregul eșantion, dar ajunge la circa ± 15 puncte procentuale pe ferestre mobile (Secțiunea 4.3, Figura 11)
- ▣ Corelația lunară cu CATFIN [Allen, Bali & Tang \(2012\)](#), media a trei estimări VaR 1% pentru acțiunile financiare (Figura 13): 0,51 pentru $S_{0,95}$, 0,15 pentru $S_{0,05}$, 0,42 pentru RTD
 - ▶ RTD crește odată cu pierderile fondurilor Bear Stearns din 2007 și scade după programul american de salvare a băncilor și după introducerea dobânzilor negative de către ECB: un semnal de fragilitate pe care media îl ascunde

Anexă: Studiu de caz: specificația replicării și limitele precizate de autori

- Replicare cu datele cursului: prețurile zilnice de închidere ale celor 13 bănci din acest capitol, din data/market (SUA, zona euro și Regatul Unit, România), 2010–2026; y_t = pierderea zilnică $-r_t$ în %, astfel încât coada dreaptă să fie cea adversă, ca la CDS
 - ▶ Specificația din lucrare: ordinul VAR după BIC, factorii după Ec. (8), $h = 5$, $\tau \in \{0,05; 0,5; 0,95\}$ și media, $w = 250$, RTD
 - ▶ Limite ale datelor: pierderi din acțiuni în loc de variații ale spread-urilor CDS, 13 bănci și niciun stat ($m = 13$ în loc de 34), ore de închidere diferite pe piețele din SUA, Europa și România
- Limitele precizate de autori: ordinul VAR ales pentru media condiționată este păstrat la fiecare cuantilă, iar cuantila rămâne fixă pe orizont (Secțiunile 2.1–2.2, nota 6)
 - ▶ 250 de zile sunt prea puține pentru a alege factorii în fiecare fereastră, deci numărul lor este fixat (Secțiunea 4.3, Anexa B); ferestrele mai scurte lasă prea puține observații efective în cozi
 - ▶ Se măsoară doar spillover-ul direct a șocurilor idiosincratice, nu și propagarea prin factorii comuni (nota 2); Grecia este exclusă din cauza unei întreruperi a seriei CDS (Secțiunea 3, Anexa A)

Anexă: Bucla descoperirii: prompturi reutilizabile

- **Literatura:** cartografiem ce se știe, apoi verificăm fiecare referință
 - ▶ „Ce articole testează dacă indicii de conectivitate prezic dificultățile băncilor în afara eșantionului, dincolo de volatilitate? Dă DOI-ul, eșantionul, orizontul și variabilele de control.”
- **Ipoteze:** interpretări concurente ale unei creșteri a conectivității, fiecare cu testul ei
 - ▶ „Dă interpretări concurente ale unei creșteri a conectivității totale (șoc comun, contagiune, artefact al ferestrelor mobile) și un test care le deosebește.”
- **Date și cod:** pe datele cursului, replicând întâi o cifră cunoscută
 - ▶ „Estimează un VAR(2) pe logaritmul volatilităților Parkinson ale celor 13 bănci din data/market, pe ferestre de 250 de zile, și calculează conectivitatea totală generalizată cu $H = 10$.”
- **Robustețea,** fixată înainte de a rula regresii predictive
 - ▶ „Preînregistrează: orizonturi de 21/63/126 de zile, controale pentru volatilitate și VIX, ferestre de 150/250/500 de zile, decalaje HAC cel puțin cât suprapunerea, evaluare în afara eșantionului din 2018.”
- **Critica:** îi cerem asistentului să atace rezultatul
 - ▶ „Joacă rolul unui recenzent: este puterea predictivă a conectivității doar persistența volatilității? Ce regresie ar arăta asta?”

Anexă: Ce verifică cercetătorul

- **Date nestaționare:** un VAR pe nivelurile prețurilor sau pe serii cu tendință produce conectivitate falsă
 - ▶ Test: teste de rădăcină unitară pe fiecare serie; toate valorile proprii ale matricei companion a VAR-ului estimat strict în interiorul cercului unitate, în fiecare fereastră
- **Ordinea:** descompunerile Cholesky se schimbă cu ordinea băncilor
 - ▶ Test: permutăm coloanele; tabelul generalizat nu trebuie să se schimbe
- **Informație din viitor:** o fereastră etichetată cu prima ei dată sau un ordin ales pe întregul eșantion
 - ▶ Test: indicele de la t nu trebuie să se miște când ștergem datele de după t
- **Suprapunerea:** indicii pe ferestre mobile și rezultatele viitoare se suprapun, deci statisticile t OLS sunt umflate
 - ▶ Test: decalaje Newey–West cel puțin egale cu suprapunerea sau bootstrap pe blocuri
- **Dimensiunea:** 13 bănci și $p = 2$ dau 27 de coeficienți pe ecuație din 250 de zile; mai multe bănci cer regularizare [Demirer et al. \(2018\)](#)
 - ▶ Test: comparăm cu un VAR LASSO; muchiile instabile semnalează zgomot de estimare, nu structură

Anexă: Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

-  Financial Risk Meter for Emerging Markets
-  Dynamic Crypto Networks
-  Network Centrality

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_18

Bibliografie (1/6)

- ▣ Acharya, V.V., Engle, R., Richardson, M. (2012). [Capital shortfall: a new approach to ranking and regulating systemic risks](#). *American Economic Review*, 102(3), 59–64.
- ▣ Acharya, V.V., Pedersen, L.H., Philippon, T., Richardson, M. (2017). [Measuring systemic risk](#). *Review of Financial Studies*, 30(1), 2–47.
- ▣ Adrian, T., Brunnermeier, M.K. (2016). [CoVaR](#). *American Economic Review*, 106(7), 1705–1741.
- ▣ Allen, L., Bali, T.G., Tang, Y. (2012). [Does systemic risk in the financial sector predict future economic downturns?](#). *Review of Financial Studies*, 25(10), 3000–3036.
- ▣ Ando, T., Bai, J. (2020). [Quantile co-movement in financial markets: a panel quantile model with unobserved heterogeneity](#). *Journal of the American Statistical Association*, 115(529), 266–279.
- ▣ Ando, T., Greenwood-Nimmo, M., Shin, Y. (2022). [Quantile connectedness: modeling tail behavior in the topology of financial networks](#). *Management Science*, 68(4), 2401–2431.
- ▣ Banulescu-Radu, D., Hurlin, C., Leymarie, J., Scaillet, O. (2021). [Backtesting marginal expected shortfall and related systemic risk measures](#). *Management Science*, 67(9), 5730–5754.
- ▣ Barigozzi, M., Brownlees, C. (2019). [NETS: network estimation for time series](#). *Journal of Applied Econometrics*, 34(3), 347–364.
- ▣ Baruník, J., Křehlík, T. (2018). [Measuring the frequency dynamics of financial connectedness and systemic risk](#). *Journal of Financial Econometrics*, 16(2), 271–296.

Bibliografie (2/6)

- ▣ Basel Committee on Banking Supervision (2018). *Global systemically important banks: revised assessment methodology and the higher loss absorbency requirement*. Bank for International Settlements.
- ▣ Battiston, S., Mandel, A., Monasterolo, I., Schütze, F., Visentin, G. (2017). *A climate stress-test of the financial system*. *Nature Climate Change*, 7(4), 283–288.
- ▣ Belloni, A., Chernozhukov, V. (2011). *ℓ_1 -penalized quantile regression in high-dimensional sparse models*. *Annals of Statistics*, 39(1), 82–130.
- ▣ Ben Amor, S., Althof, M., Härdle, W.K. (2022). *Financial Risk Meter for emerging markets*. *Research in International Business and Finance*, 60, 101594.
- ▣ Benjamini, Y., Hochberg, Y. (1995). *Controlling the false discovery rate: a practical and powerful approach to multiple testing*. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- ▣ Benoit, S., Colliard, J.-E., Hurlin, C., Pérignon, C. (2017). *Where the risks lie: a survey on systemic risk*. *Review of Finance*, 21(1), 109–152.
- ▣ Billio, M., Getmansky, M., Lo, A.W., Pelizzon, L. (2012). *Econometric measures of connectedness and systemic risk in the finance and insurance sectors*. *Journal of Financial Economics*, 104(3), 535–559.
- ▣ Bolton, P., Després, M., Pereira da Silva, L.A., Samama, F., Svartzman, R. (2020). *The green swan: central banking and financial stability in the age of climate change*. Bank for International Settlements.
- ▣ Brownlees, C., Engle, R.F. (2017). *SRISK: a conditional capital shortfall measure of systemic risk*. *Review of Financial Studies*, 30(1), 48–79.

Bibliografie (3/6)

- ▣ Castro, C., Ferrari, S. (2014). [Measuring and testing for the systemically important financial institutions](#). *Journal of Empirical Finance*, 25, 1–14.
- ▣ Chernozhukov, V., Fernández-Val, I. (2011). [Inference for extremal conditional quantile models, with an application to market and birthweight risks](#). *Review of Economic Studies*, 78(2), 559–589.
- ▣ Danielsson, J., James, K.R., Valenzuela, M., Zer, I. (2016). [Model risk of risk models](#). *Journal of Financial Stability*, 23, 79–91.
- ▣ Demirer, M., Diebold, F.X., Liu, L., Yilmaz, K. (2018). [Estimating global bank network connectedness](#). *Journal of Applied Econometrics*, 33(1), 1–15.
- ▣ Diebold, F.X., Yilmaz, K. (2009). [Measuring financial asset return and volatility spillovers, with application to global equity markets](#). *Economic Journal*, 119(534), 158–171.
- ▣ Diebold, F.X., Yilmaz, K. (2012). [Better to give than to receive: predictive directional measurement of volatility spillovers](#). *International Journal of Forecasting*, 28(1), 57–66.
- ▣ Diebold, F.X., Yilmaz, K. (2014). [On the network topology of variance decompositions: measuring the connectedness of financial firms](#). *Journal of Econometrics*, 182(1), 119–134.
- ▣ ECB Banking Supervision (2022). [Banks must sharpen their focus on climate risk, ECB supervisory stress test shows](#). Press release, 8 July 2022.
- ▣ Engle, R. (2002). [Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models](#). *Journal of Business & Economic Statistics*, 20(3), 339–350.

Bibliografie (4/6)

- ▣ Engle, R., Jondeau, E., Rockinger, M. (2015). *Systemic risk in Europe*. *Review of Finance*, 19(1), 145–190.
- ▣ FDIC (2023). *FDIC creates a Deposit Insurance National Bank of Santa Clara to protect insured depositors of Silicon Valley Bank, Santa Clara, California*. Press release, 10 March 2023.
- ▣ Federal Reserve Board (2023). *Federal Reserve Board announces it will make available additional funding to eligible depository institutions*. Press release, 12 March 2023.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Giglio, S., Kelly, B., Pruitt, S. (2016). *Systemic risk and the macroeconomy: an empirical evaluation*. *Journal of Financial Economics*, 119(3), 457–471.
- ▣ Girardi, G., Ergün, A.T. (2013). *Systemic risk measurement: multivariate GARCH estimation of CoVaR*. *Journal of Banking & Finance*, 37(8), 3169–3180.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). *On the relation between the expected value and the volatility of the nominal excess return on stocks*. *Journal of Finance*, 48(5), 1779–1801.
- ▣ Gouriéroux, C., Laurent, J.P., Scaillet, O. (2000). *Sensitivity analysis of values at risk*. *Journal of Empirical Finance*, 7(3–4), 225–245.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). *Applied Quantitative Finance*, 3rd ed. Springer.

Bibliografie (5/6)

- ▣ Härdle, W.K., Wang, W., Yu, L. (2016). **TENET: Tail-Event driven NETwork risk**. *Journal of Econometrics*, 192(2), 499–513.
- ▣ Holm, S. (1979). **A simple sequentially rejective multiple test procedure**. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- ▣ Koenker, R., Bassett, G. (1978). **Regression quantiles**. *Econometrica*, 46(1), 33–50.
- ▣ Koenker, R., Bassett, G. (1982). **Tests of linear hypotheses and ℓ_1 estimation**. *Econometrica*, 50(6), 1577–1583.
- ▣ Koop, G., Pesaran, M.H., Potter, S.M. (1996). **Impulse response analysis in nonlinear multivariate models**. *Journal of Econometrics*, 74(1), 119–147.
- ▣ Mihoci, A., Althof, M., Chen, C.Y.-H., Härdle, W.K. (2020). **FRM Financial Risk Meter**. In *The Econometrics of Networks*, Advances in Econometrics 42, Emerald, 335–368.
- ▣ Nucera, F., Schwaab, B., Koopman, S.J., Lucas, A. (2016). **The information in systemic risk rankings**. *Journal of Empirical Finance*, 38, 461–475.
- ▣ Parkinson, M. (1980). **The extreme value method for estimating the variance of the rate of return**. *Journal of Business*, 53(1), 61–65.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). **Information entropy and measures of market risk**. *Entropy*, 19(5), 226.

Bibliografie (6/6)

- ▣ Pesaran, H.H., Shin, Y. (1998). Generalized impulse response analysis in linear multivariate models. *Economics Letters*, 58(1), 17–29.
- ▣ Ren, R., Althof, M., Härdle, W.K. (2022). Financial Risk Meter for cryptocurrencies and tail risk network-based portfolio construction. *Singapore Economic Review*, 70(4), 901–927.
- ▣ Ren, R., Lu, M., Li, Y., Härdle, W.K. (2022). Financial Risk Meter FRM based on expectiles. *Journal of Multivariate Analysis*, 189, 104881.
- ▣ Scaillet, O. (2004). Nonparametric estimation and sensitivity analysis of expected shortfall. *Mathematical Finance*, 14(1), 115–129.
- ▣ Shi, S., Hurn, S., Phillips, P.C.B. (2020). Causal change detection in possibly integrated systems: revisiting the money–income relationship. *Journal of Financial Econometrics*, 18(1), 158–180.
- ▣ Toda, H.Y., Yamamoto, T. (1995). Statistical inference in vector autoregressions with possibly integrated processes. *Journal of Econometrics*, 66(1–2), 225–250.
- ▣ Toma, F.-M., Dima, D.M., Grecu, R., Pele, D.T., Lessmann, S. (2026). Energy Financial Risk Meter: systemic risk in the EU energy sector. SSRN working paper.
- ▣ Wang, R., Althof, M., Härdle, W.K. (2023). A financial risk meter for China. *Emerging Markets Review*, 56, 101052.