









Modelarea piețelor financiare

Capitolul 18: Risc sistemic și rețele



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Cînd devin dificultățile unei bănci o problemă a sistemului?

De la o bancă la sistem

- **Riscul sistemic**: riscul ca dificultățile uneia sau ale mai multor instituții să afecteze sistemul financiar în ansamblu și, prin el, economia reală
- O **externalitate**: o bancă nu plătește pierderile pe care falimentul ei le impune altora
- Trei familii de măsuri (sinteză: Benoit, Colliard, Hurlin & Pérignon (2017))
  - **Expunere**: cît pierde banca atunci cînd piața se prăbușește? MES (pierderea ei medie în zilele de crah), SRISK (deficitul ei de capital într-o criză)
  - **Contribuție**: cu cît stă mai rău sistemul atunci cînd banca este în dificultate? ΔCoVaR (CoVaR: Value-at-Risk, VaR, al sistemului condiționat de starea băncii)
  - **Conectivitate**: prin ce legături circulă șocurile? Rețele de spillover și rețele în coadă

Pierderi extreme și rețele financiare

- Partea I: date și convenții, expunerea (MES, LRMES, adică MES într-o criză de mai multe luni, SRISK), contribuția (CoVaR, ΔCoVaR) și cît ne putem baza pe clasamente
- Partea a II-a: rețele de spillover, Financial Risk Meter, teste de stres și riscul climatic, un studiu de caz despre conectivitatea cuantilă, o trecere prin bucla descoperirii cu AI (inteligență artificială)
- Manuale: Franke, Härdle & Hafner (2019), Härdle, Chen & Overbeck (2017)

Retrageri masive de depozite: Northern Rock 2007 și Silicon Valley Bank 2023



Deponenți la coadă în fața unei sucursale Northern Rock, Brighton, 14 septembrie 2007

Foto: Dominic Alves (2007); CC BY 2.0; Wikimedia Commons

- Northern Rock (2007): un creditor ipotecar britanic afectat de blocarea piețelor de finanțare după pierderile din creditele subprime americane
  - Deponenții au stat la coadă pentru a-și retrage economiile
- SVB (Silicon Valley Bank, 2023): retrageri masive de depozite prin canale digitale
  - FDIC (Federal Deposit Insurance Corporation, fondul american de garantare a depozitelor) a preluat banca pe 10 martie FDIC (2023)
  - După două zile, toți deponenții SVB și Signature Bank au fost protejați, pe baza unui argument de risc **sistemic** Federal Reserve Board (2023)
- Canale de contagion
  - **Retrageri de finanțare**: deponenții și creditorii se retrag din orice bancă ce pare asemănătoare
  - **Expuneri comune** și **fire sales** (vînzări forțate): vînzările scad prețurile pentru toți deținătorii
  - **Legături între contrapărți**: datoria unei bănci este activul alteia, deci neplata ei transmite pierderi creditorilor

Treisprezece bănci, trei piețe: prețuri și randamente log

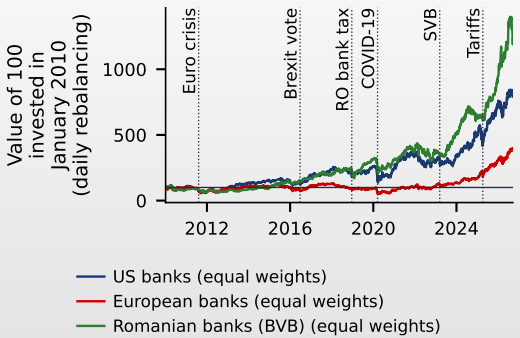
Grupul	Băncile (simbolul bursier, folosit în unele grafice)	Indicele pieței
Bănci americane	JPMorgan (JPM), Bank of America (BAC), Citigroup (C), Goldman Sachs (GS), Morgan Stanley (MS), Wells Fargo (WFC)	S&P 500
Bănci europene	Deutsche Bank (DBK), BNP Paribas (BNP), Santander (SAN), ING (INGA), HSBC (HSBA)	Euro Stoxx 50
Bănci românești	Banca Transilvania (TLV), BRD-Groupe Société Générale (BRD; „BRD-Groupe SG" în grafice)	BET
Volatilitate	indicele VIX (volatilitatea implicită a S&P 500)	

- Prețuri zilnice, ianuarie 2010–18 septembrie 2026, ajustate pentru dividende și divizări
  - Aliniate întîi pe 3 960 de zile de tranzacționare comune, apoi randamentele logaritmice zilnice $r_t = 100(\ln P_t - \ln P_{t-\mathbf{1}})$, în %
- Cazuri speciale
  - Băncile românești, tranzacționate la Bursa de Valori București (BVB, indicele BET): zilele fără tranzacții sînt eliminate
  - Scenariile istorice de stres pentru băncile internaționale încep în 2007

Pierderile ca numere pozitive și portofoliul sistemului

- Notăm randamentul cu X și pierderea cu $L = -X$, iar nivelul α este o **probabilitate a cozii** (Capitolul 7)
  - Scriem VaR 1%, CoVaR 1%, MES 5%
  - $\mathrm{VaR}_\alpha(X) = -q_\alpha(X)$, cu q_α cuantila de ordin α a lui X
  - VaR, CoVaR și MES sînt numere pozitive atunci cînd sînt pierderi
- Randamentul **sistemului** X^{sys}: portofoliul cu ponderi egale al celorlalte bănci din aceeași regiune
  - $X^{sys} = \frac{1}{n}\sum_j X_j$, media randamentelor log zilnice ale celorlalte n bănci
  - Un agregat liniar: o aproximare de ordinul întîi a randamentului log al portofoliului reechilibrat zilnic
  - CoVaR se referă la acest agregat, iar MES condiționează pe indicele pieței din regiune

Trei sisteme bancare, 2010–2026



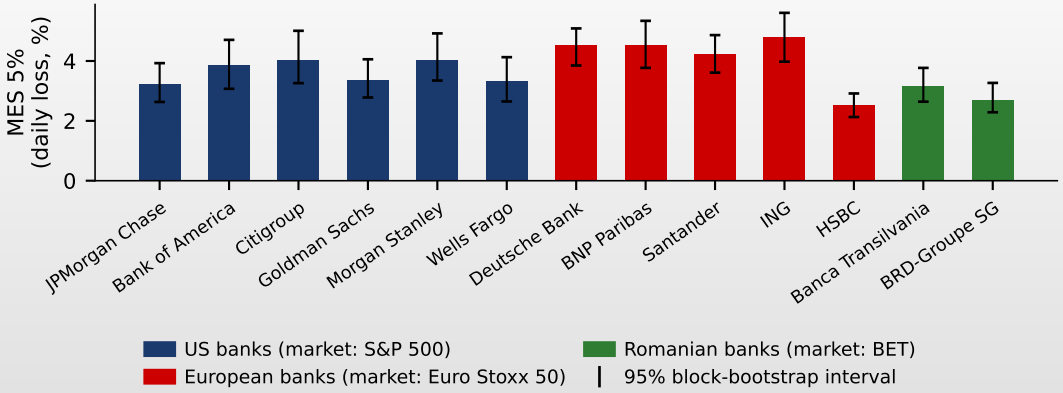
- Portofolii cu ponderi egale ale băncilor din fiecare regiune, reechilibrate zilnic
  - Liniile verticale marchează episoadele folosite în acest capitol
- 100 investiți în ianuarie 2010 au devenit 791 (SUA), 384 (Europa), 1 233 (România)
  - Drawdown-ul maxim: SUA 51% (2011-11-23), Europa 61% (2020-04-21), România 47% (2012-06-06)
  - Volatilitatea anualizată a portofoliilor bancare: 29% (SUA), 30% (Europa), 23% (România)
  - Volatilitatea anualizată a indicilor de piață: 18% (S&P 500), 21% (Euro Stoxx 50), 18% (BET)
- Scăderile sînt **simultane**: criza din zona euro, COVID-19, falimentele bancare din 2023
  - Băncile românești au și un șoc propriu: anunțul taxei bancare din decembrie 2018 (eticheta „RO bank tax")

MFM_ch18_bank_indices

Marginal Expected Shortfall și proprietatea Euler

- **MES** (Marginal Expected Shortfall, pierderea marginală așteptată în coadă) a băncii i la nivelul α Acharya, Pedersen, Philippon & Richardson (2017)
  - $\mathrm{MES}_{i,\alpha} = -\mathbb{E}[X_i \mid X_m \leq q_\alpha(X_m)]$
  - Pierderea medie a băncii în fracțiunea α a zilelor cu cele mai mici randamente ale pieței m
  - Piața m: S&P 500 pentru băncile americane, Euro Stoxx 50 pentru cele europene, BET pentru cele românești
- Termenul „marginală": **dacă** variabila de condiționare este chiar portofoliul, $m = \sum_i w_i X_i$, atunci $\mathrm{ES}_\alpha(X_m) = \sum_i w_i \, \mathrm{MES}_{i,\alpha}$ (alocarea Euler; demonstrația în Anexă)
  - w_i: ponderile din portofoliu
  - $\mathrm{ES}_\alpha(X_m) = -\mathbb{E}[X_m \mid X_m \leq q_\alpha(X_m)]$: pierderea medie a lui m în fracțiunea α a celor mai rele zile ale sale
  - Indicii noștri de piață **nu** sînt portofolii ale acestor 13 bănci: aici MES măsoară **expunerea**, nu o parte din ES al indicelui
- Estimarea istorică: media lui $-X_i$ în zilele cu $X_m \leq \hat{q}_\alpha(X_m)$
  - Cu $\alpha = 5\%$ și 3 960 de zile, media se calculează pe aproximativ 200 de zile

MES 5% pentru treisprezece bănci (1/2)



MFM_ch18_mes_srisk

MES 5% pentru treisprezece bănci (2/2)

- Pierderea zilnică medie a fiecărei bănci în cele 5% dintre zile cu cele mai mici randamente ale indicelui său de piață, 2010–2026
  - Intervale de 95%: bootstrap pe blocuri mobile de 20 de zile
- Băncile americane: de la 3,22% (JPMorgan) la 4,04% (Morgan Stanley), iar cele europene pînă la 4,81% (ING)
  - În aceleași zile, pierderea medie a pieței a fost 2,72% (S&P 500) și 3,16% (Euro Stoxx 50): băncile pierd mai mult decît piața
- HSBC este excepția din Europa (2,54%, sub indice)
  - O bancă listată la Londra, cu activitate concentrată în Asia
- Băncile românești: Banca Transilvania 3,14% și BRD 2,69%, față de 2,70% pentru indicele BET însuși

MFM_ch18_mes_srisk

De la MES la o criză: LRMES

- **LRMES** (Long-Run MES, MES pe termen lung): scăderea așteptată a capitalului de piață al băncii într-o criză
  - $\mathrm{LRMES}_{i,t} = -\mathbb{E}_t\left[R_{i,t+\mathbf{1}:t+h} \mid R_{m,t+\mathbf{1}:t+h} < C\right]$, criza: o scădere a pieței sub C în h zile
  - $R_{i,t+\mathbf{1}:t+h}$, $R_{m,t+\mathbf{1}:t+h}$: randamentele aritmetice (variații procentuale simple pe cele h zile, nu randamente log) ale băncii i și ale pieței de la $t+1$ la $t+h$
  - Pragul de criză din Acharya, Engle & Richardson (2012): $C = -40\%$ în șase luni
  - Pragul din Brownlees & Engle (2017): $C = -10\%$ în $h = 22$ de zile
- Aproximarea din Acharya, Engle & Richardson (2012), folosită cînd nu există o simulare
  - $\mathrm{LRMES}_i \approx 1 - \exp(-18 \times \mathrm{MES}_i^{\mathbf{2\%}})$
  - $\mathrm{MES}_i^{\mathbf{2\%}}$: pierderea zilnică medie a băncii în zilele în care piața scade cu peste 2% (în fracții zecimale)
  - Exemplu: $\mathrm{MES}^{\mathbf{2\%}} = 3\%$ dă $1 - e^{-\mathbf{0,54}} = 41{,}7\%$
  - Factorul 18 este o constantă de calibrare
  - Rolul factorului 18: transformă o pierdere din coadă de o zi în pierderea din criza de șase luni cu scăderea pieței de 40%, presupunînd că beta băncii față de piață rămîne constant în criză
- LRMES aproximat pentru băncile noastre: de la 37% (HSBC) la 58% (ING), cu JPMorgan la 48% și Banca Transilvania la 52%
  - Numărul zilelor în care piața a scăzut cu peste 2%: 138 în SUA, 196 în zona euro, 111 la BVB

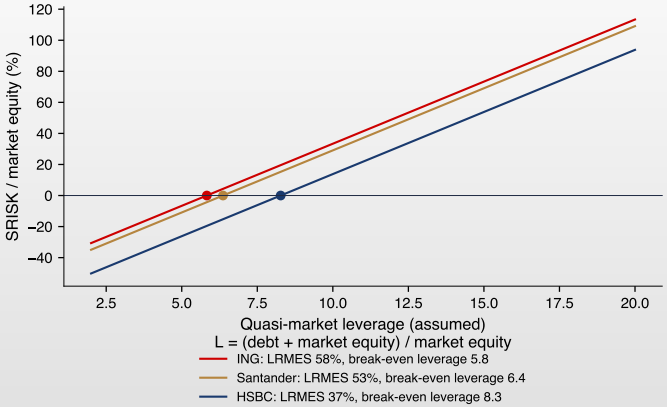
SRISK și leverage-ul de echilibru (1/2)

- **SRISK** (systemic risk): capitalul care i-ar lipsi unei bănci într-o criză severă a pieței
- O bancă trebuie să păstreze un capital de cel puțin o proporție k din cvasi-active Brownlees & Engle (2017)
  - Cvasi-activele: datoriile contabile D plus capitalul de piață W
  - $\mathrm{SRISK}_i = k\,D_i - (1-k)(1-\mathrm{LRMES}_i)\,W_i$, presupunînd că datoriile nu sînt renegociate în criză
  - Forma echivalentă: $k[D_i + (1-\mathrm{LRMES}_i)W_i] - (1-\mathrm{LRMES}_i)W_i$, capitalul cerut după criză minus capitalul rămas
  - $k = 8\%$ pentru firmele americane Brownlees & Engle (2017)
  - $k = 5{,}5\%$ pentru cele europene, deoarece bilanțurile IFRS (standardele internaționale de raportare financiară) raportează active mai mari decît cele US GAAP (principiile contabile americane) Engle, Jondeau & Rockinger (2015)
  - De ce mai mari: IFRS permite mai puțin **netting** (compensarea activelor derivate cu datoriile față de aceeași contraparte), deci aceeași bancă raportează un bilanț brut mai mare
  - Un k mai mic aplicat unor active mai mari păstrează cerința comparabilă
- SRISK pozitiv = deficit de capital
  - SRISK al sistemului: suma valorilor pozitive
  - V-Lab, New York University Stern School of Business îl publică pentru băncile mari, pe baza bilanțurilor lor

SRISK și leverage-ul de echilibru (2/2)

- Împărțim la W și definim leverage-ul pe bază de cvasi-active $\Lambda = (D + W)/W$
  - $\dfrac{\mathrm{SRISK}}{W} = k(\Lambda - 1) - (1 - k)(1 - \mathrm{LRMES})$
  - $\Lambda - 1 = D/W$ este datoria pe unitatea de capital de piață
- SRISK devine pozitiv cînd leverage-ul depășește **leverage-ul de echilibru**
  - $\Lambda^* = 1 + \dfrac{(1 - k)(1 - \mathrm{LRMES})}{k}$
- Exemplu: $D = 900$, $W = 100$ (deci $\Lambda = 10$), $\mathrm{LRMES} = 41{,}7\%$
  - $\mathrm{SRISK} = 0{,}08 \times 900 - 0{,}92 \times (1 - 41{,}7\%) \times 100 = 72 - 53{,}6 = 18{,}4$
  - $\Lambda^* = 7{,}7 < \Lambda = 10$: deficit
- Datele noastre conțin prețuri, nu bilanțuri
  - Raportăm Λ^* din LRMES estimat și tratăm leverage-ul ca pe o **ipoteză**

SRISK în funcție de leverage (1/2)



MFM_ch18_mes_srisk

SRISK în funcție de leverage (2/2)

- Curbele: băncile cu LRMES maxim, median și minim, iar punctele marchează Λ^*
  - Leverage-ul de pe axa orizontală este presupus, nu observat
- Leverage-ul de echilibru cu $k = 8\%$ și LRMES aproximat (criză de șase luni, piața -40%): $\Lambda^* = 5{,}8$ (ING), 6,4 (Santander), 8,3 (HSBC)
  - Băncile americane: JPMorgan 7,0, Morgan Stanley 6,0
  - Băncile românești: Banca Transilvania 6,5, BRD 7,1
- Cînd leverage-ul depășește $\Lambda^* = 5{,}8$–$8{,}3$, adică datoriile $D/W = \Lambda - 1$ depășesc de 4,8–7,3 ori capitalul de piață, banca are nevoie de capital nou într-un crah al pieței de 40%
- Cu $k = 5{,}5\%$ pragurile cresc (ING 8,2, HSBC 11,9)
  - Raportul prudențial este o alegere de politică, iar SRISK depinde de el
- Limite: LRMES extrapolează date zilnice, iar capitalul de piață însuși scade într-o criză

MFM_ch18_mes_srisk

LRMES: GJR–GARCH, DCC și simulare (1/2): modelul

- Modelul Brownlees & Engle (2017): randamente log zilnice cu medie zero ale băncii și ale pieței
  - Volatilități GJR–GARCH(1,1) Glosten, Jagannathan & Runkle (1993)(GARCH: heteroscedasticitate condiționată autoregresivă generalizată; GJR: Glosten, Jagannathan și Runkle)
  - O corelație DCC(1,1) (DCC: corelație condiționată dinamică) Engle (2002)
  - Estimarea: cvasi-verosimilitate maximă (QML, quasi-maximum likelihood) în doi pași
- Volatilitatea, pentru bancă și pentru piață: varianța de azi reacționează la pătratul randamentului de ieri, mai puternic după o scădere
  - $\sigma_t^2 = \omega + (\alpha + \gamma\, 1\{r_{t-1} < 0\})\, r_{t-1}^2 + \beta\, \sigma_{t-1}^2$
  - σ_t^2 este varianța condiționată a randamentului r_t, iar $\omega > 0$ este o constantă
  - α măsoară reacția la un șoc (aici nu este nivelul cozii), $\gamma > 0$ reacția suplimentară după o scădere (leverage effect), iar β persistența
  - $1\{\cdot\}$ ia valoarea 1 dacă condiția este îndeplinită și 0 altfel
- Corelația: o recursie de tip GARCH pentru matricea Q_t, rescalată la o corelație
  - $Q_t = (1 - a - b)\, S + a\, \epsilon_{t-1} \epsilon_{t-1}^\top + b\, Q_{t-1}$, $\rho_t = Q_{12,t} / \sqrt{Q_{11,t} Q_{22,t}}$
  - $\epsilon_t = (r_{it}/\sigma_{it}, r_{mt}/\sigma_{mt})^\top$ sînt randamentele standardizate, iar S este matricea corelațiilor lor din eșantion
  - a măsoară reacția corelației, b persistența ei, iar ρ_t este corelația bancă–piață de azi
  - În Engle (2002) S se notează $\bar{Q}$ și este covarianța din eșantion a lui ϵ_t
  - Randamentele standardizate au dispersia apropiată de 1, deci cele două matrici aproape coincid, iar Q_t rămîne pe scara unei corelații

LRMES: GJR–GARCH, DCC și simulare (2/2): simularea

- Simularea (detalii: Anexă)
  - Reeșantionăm **perechi** de inovații standardizate $(\xi_{it}, \epsilon_{mt})$ ale băncii și pieței
  - Simulăm recursiile GARCH și DCC pe h zile, pornind de la σ^2 și ρ de azi
  - Păstrăm doar traiectoriile de criză, cele cu $R_{m,t+\mathbf{1}:t+h} < C$
  - LRMES = minus media randamentului băncii pe aceste traiectorii de criză
  - Reeșantionarea perechilor păstrează tail dependence, pe care distribuția Normală nu o reproduce
- Date pînă la 2026-09-18, cu următorul număr de traiectorii simulate pentru fiecare piață:
  - 200 000 de traiectorii de 22 de zile, pentru pragul $C = -10\%$
  - 400 000 de traiectorii de 126 de zile, pentru pragul $C = -40\%$
- Probabilitatea unei crize de 22 de zile (o scădere a pieței cu peste 10%)
  - Azi: 1,3% (S&P 500), 4,3% (Euro Stoxx 50), 4,0% (BET)
  - Pe 31 martie 2020: 12%, 19% și 8%, pentru aceleași trei piețe

LRMES prin simulare: treisprezece bănci (1/2)

Banca	LRMES azi	interval 90%	LRMES 31.03.2020	ρ_T	Λ^* (22 de zile)
JPMorgan	10,6	$[-2, 25]$	23,7	0,53	11,3
Bank of America	14,3	$[-4, 35]$	23,2	0,44	10,9
Citigroup	13,0	$[-1, 28]$	32,8	0,54	11,0
Goldman Sachs	16,5	$[1, 34]$	25,0	0,65	10,6
Morgan Stanley	16,3	$[1, 32]$	27,2	0,65	10,6
Wells Fargo	6,7	$[-8, 24]$	22,9	0,32	11,7
Deutsche Bank	14,4	$[2, 28]$	25,7	0,66	10,8
BNP Paribas	15,6	$[2, 33]$	28,5	0,68	10,7
Santander	16,6	$[3, 34]$	26,4	0,76	10,6
ING	12,5	$[1, 27]$	32,9	0,68	11,1
HSBC	8,3	$[-2, 19]$	10,9	0,58	11,5
Banca Transilvania	12,4	$[-2, 34]$	17,2	0,74	11,1
BRD-Groupe SG	11,4	$[-2, 28]$	15,8	0,64	11,2

- LRMES (%): pierderea medie a băncii cînd piața scade sub -10% în 22 de zile Brownlees & Engle (2017)
- Intervalul de 90%: cuantilele de 5% și 95% ale pierderii băncii pe traiectoriile de criză
- ρ_T este ultima corelație DCC, iar Λ^* leverage-ul de echilibru cu $k = 8\%$, calculat din acest LRMES pe 22 de zile (necomparabil cu Λ^* din aproximare)

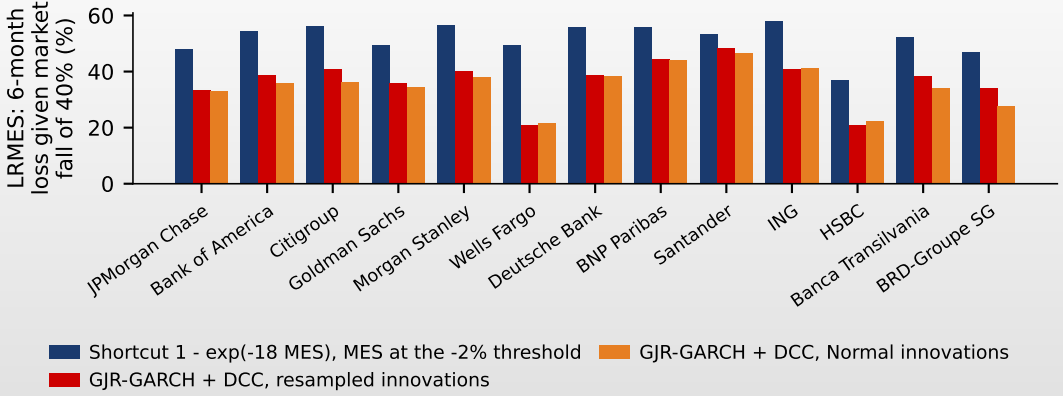
LRMES prin simulare: treisprezece bănci (2/2)

- LRMES este **condiționat**: variază odată cu volatilitatea și corelația de azi
  - JPMorgan: 10,6% azi, 23,7% cu informația din 31 martie 2020
  - Deutsche Bank: 14,4% și 25,7%
- Intervalul de 90% este larg Brownlees & Engle (2017)
  - LRMES este o medie pe traiectoriile de criză, iar deficitul într-o criză anume poate fi mult mai mare. Intervalul descrie dispersia scenariilor, nu incertitudinea mediei estimate
- Scenariul, nu doar banca, stabilește nivelul
  - Pentru o criză de o lună, cu o scădere a pieței de 10%, LRMES este aproximativ o treime din valorile pentru criza de șase luni, cu o scădere de 40%, din Acharya, Engle & Richardson (2012)

Cum citim tabelul LRMES: intervale și scenarii

- Un capăt inferior negativ al intervalului de 90% nu este o eroare de semn
  - Pierderea pe fiecare traiectorie simulată este minus randamentul băncii; LRMES este media acestor pierderi pe traiectoriile de criză. O pierdere negativă pe o traiectorie este un cîștig: pe cel puțin 5% dintre traiectoriile de criză, acțiunile băncii cresc în timp ce piața scade
  - Se întîmplă cînd banca este azi slab corelată cu piața ei, de ex. Wells Fargo: $\rho_T = 0{,}32$, intervalul $[-8, 24]$
- $\Lambda^* = 1 + (1-k)(1-\mathrm{LRMES})/k$ moștenește scenariul de criză prin LRMES: JPMorgan, $k = 8\%$
  - Aproximarea, șase luni, piața -40%: LRMES 48%, $\Lambda^* = 7{,}0$
  - Simularea, 126 de zile, piața -40%: LRMES 33%, $\Lambda^* = 8{,}7$
  - Simularea, 22 de zile, piața -10%: LRMES 10,6%, $\Lambda^* = 1 + 0{,}92(1 - 10{,}6\%)/0{,}08 = 11{,}3$
- O criză mai blîndă dă un LRMES mai mic și deci un Λ^* mai mare: comparăm Λ^* doar în cadrul aceluiași scenariu
  - În acest capitol, graficul SRISK în funcție de leverage și tabelul din concluzii folosesc aproximarea, iar tabelul LRMES al celor treisprezece bănci folosește scenariul de 22 de zile

Riscul de model: LRMES în trei specificații (1/2)



MFM_ch18_srisk_sim

Riscul de model: LRMES în trei specificații (2/2)

- Scenariul: o criză de șase luni, cu o scădere a pieței de 40% Acharya, Engle & Richardson (2012), pe date pînă la 2026-09-18
  - Aproximarea $1 - e^{-\mathbf{18}\mathrm{MES}^{\mathbf{2\%}}}$ față de simularea GJR–GARCH + DCC cu inovații reeșantionate sau Normale
- Raportul dintre LRMES simulat și aproximare variază între 0,42 și 0,90, iar corelația de rang dintre ele este 0,77
  - JPMorgan: 48% (aproximare), 33% (inovații reeșantionate), 33% (inovații Normale)
  - ING: 58%, 41% și 41%, în aceeași ordine
- Aproximarea folosește întreaga istorie, în timp ce simularea pornește de la volatilitatea de azi
- Inovații reeșantionate față de Normale: corelația de rang 0,95
  - Nivelurile diferă cel mai mult la Citigroup (40,8% față de 36,3%) și la BRD (34,1% față de 27,5%), dar clasamentele rămîn aproape aceleași
- Aceleași date, modele diferite și justificabile, cifre diferite: riscul de model Danielsson, James, Valenzuela & Zer (2016)

MFM_ch18_srisk_sim

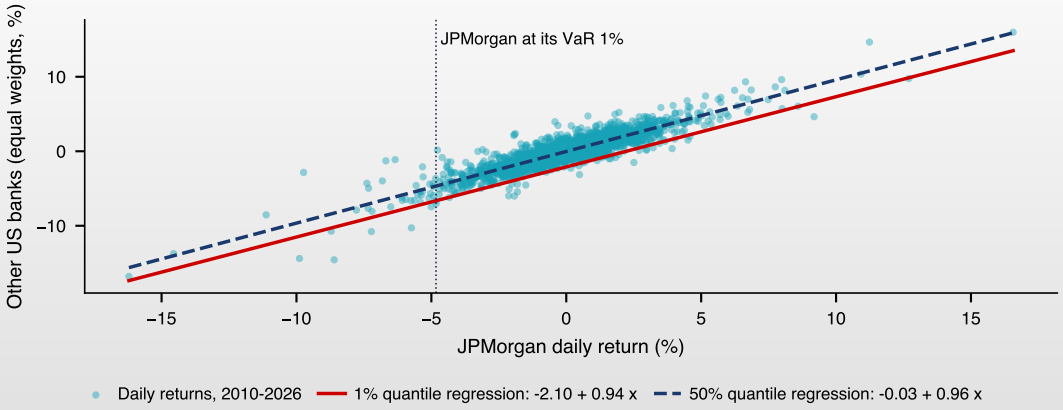
CoVaR: VaR al sistemului cînd o bancă este în dificultate

- **CoVaR** al sistemului condiționat de banca i aflată la nivelul VaR-ului ei Adrian & Brunnermeier (2016)
  - X^{sys}, X_i: randamentele sistemului și ale băncii i
  - $P\left(X^{sys} \leq -\mathrm{CoVaR}_{\alpha}^{sys|i} \;\middle|\; X_i = -\mathrm{VaR}_{i,\alpha}\right) = \alpha$
  - Pierderea sistemului depășită cu probabilitatea α într-o zi în care banca i se află la propriul VaR
- **ΔCoVaR**: diferența dintre starea mediană a băncii și starea ei de dificultate
  - $\Delta\mathrm{CoVaR}_{\alpha}^{sys|i} = \mathrm{CoVaR}_{\alpha}^{sys|X_i=q_\alpha} - \mathrm{CoVaR}_{\alpha}^{sys|X_i=q_{50\%}}$
  - $\mathrm{CoVaR}_{\alpha}^{sys|X_i=q}$: CoVaR cu randamentul băncii fixat la cuantila sa q
  - $q_{50\%}$: mediana, care corespunde unei zile obișnuite
- ΔCoVaR măsoară **contribuția** băncii i la riscul din coadă (tail risk) al sistemului
- Inversînd rolurile obținem **CoVaR de expunere**: VaR al băncii i atunci cînd sistemul este în dificultate

Estimarea CoVaR prin regresie cuantilă

- Cuantila de ordin α a lui Y condiționată de x este liniară: $q_\alpha(Y \mid x) = a_\alpha + b_\alpha x$ Koenker & Bassett (1978)
  - Aici Y este randamentul sistemului și x randamentul băncii. Pe observațiile y_t, x_t: $(\hat{a}_\alpha, \hat{b}_\alpha) = \arg\min_{a,b} \sum_t \rho_\alpha(y_t - a - bx_t), \quad \rho_\alpha(u) = u(\alpha - 1\{u < 0\})$
  - ρ_α este **funcția de pierdere cuantilă**: ponderează reziduurile negative cu $1 - \alpha$ și pe cele pozitive cu α
  - Cu $\alpha = 50\%$ obținem regresia medianei
- 1. Regresia cuantilă a sistemului pe bancă la nivelul α
  - $\hat{q}_\alpha(X^{sys} \mid X_i) = \hat{a}_\alpha + \hat{b}_\alpha X_i$
- 2. Introducem cuantilele băncii: $\hat{q}_\alpha(X_i)$ (dificultate) și $\hat{q}_{\mathbf{50\%}}(X_i)$ (mediana)
  - $\mathrm{CoVaR}_\alpha^{sys|i} = -\left(\hat{a}_\alpha + \hat{b}_\alpha \hat{q}_\alpha(X_i)\right)$
- 3. Calculăm diferența
  - $\Delta\mathrm{CoVaR}_\alpha^{sys|i} = \hat{b}_\alpha \left(\hat{q}_{\mathbf{50\%}}(X_i) - \hat{q}_\alpha(X_i)\right)$
  - Contează doar panta: termenul liber se simplifică
- Incertitudinea se estimează prin bootstrap pe blocuri mobile de 20 de zile (blocurile păstrează volatility clustering), cu 999 de reeșantionări

Regresia cuantilă: JPMorgan și celelalte bănci americane (1/2)



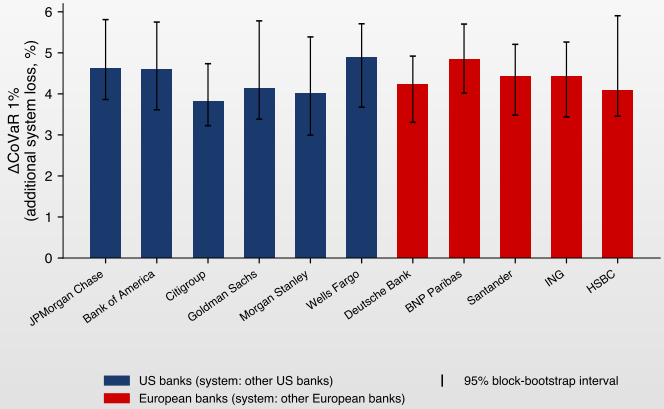
MFM_ch18_covar

Regresia cuantilă: JPMorgan și celelalte bănci americane (2/2)

- Randamente zilnice 2010–2026, dreptele de regresie cuantilă de 1% și 50%
  - Linia punctată: JPMorgan la VaR 1%
- Dreapta de 1%: $\hat{q}_{\mathbf{1\%}} = -2{,}10 + 0{,}94\, X_i$, iar dreapta medianei: $-0{,}03 + 0{,}96\, X_i$
  - Pante asemănătoare: dreapta de 1% este deplasată în jos, nu mai abruptă
- Cînd JPMorgan se află la VaR 1% (4,83%), CoVaR 1% al celorlalte bănci americane este 6,64%
  - VaR 1% al sistemului: 5,07%
  - CoVaR 1% cu JPMorgan la mediana sa: 2,03%
- $\Delta\mathrm{CoVaR}_{\mathbf{1\%}} = 4{,}62\%$: JPMorgan în dificultate adaugă aproximativ 4,62 puncte procentuale la pierderea din coadă a sistemului
  - Asociere, nu cauzalitate: un șoc comun afectează toate băncile în aceeași zi

MFM_ch18_covar

ΔCoVaR 1% pentru unsprezece bănci (1/2)



MFM_ch18_covar

ΔCoVaR 1% pentru unsprezece bănci (2/2)

- Sistemul: portofoliul cu ponderi egale al celorlalte bănci din aceeași regiune
  - Barele: ΔCoVaR, pierderea **suplimentară** a sistemului cînd banca trece de la mediană la VaR
  - Intervale bootstrap de 95% pe blocuri mobile
  - Fără băncile românești: fiind doar două, „sistemul" celorlalte bănci ar fi o singură bancă, adică o legătură bilaterală
- Valorile merg de la 3,81% (Citigroup) la 4,89% (Wells Fargo), iar intervalele au lățimea de 1,5–2,4 puncte procentuale
  - De exemplu, intervalele marginale pentru Citigroup, [3,23; 4,74], și Wells Fargo, [3,68; 5,71], se suprapun
- Suprapunerea **nu** este un test
  - Estimările calculate pe aceleași zile sînt dependente (aici puternic corelate pozitiv)
  - Intervalul pentru diferență poate fi mai îngust decît fiecare interval marginal
- La $\alpha = 5\%$ valorile sînt mai mici (JPMorgan 2,62%), iar clasamentul se schimbă
  - Corelația Spearman dintre clasamentele de 1% și 5%: 0,10
  - Un clasament atît de instabil nu este o bază robustă pentru reglementare

MFM_ch18_covar

Testarea ΔCoVaR 1%

- Toate testele folosesc aceleași 999 de extrageri bootstrap pe blocuri mobile de zile pentru toate băncile, deci estimările băncilor diferite își păstrează dependența (detalii: Anexă)
- (1) Nicio contribuție, $H_0: b_\alpha = 0$: test Wald cu dispersia de tip sandviș a regresiei cuantile Koenker & Bassett (1978), estimată prin nucleu Hendricks & Koenker (1992)
  - Rapoartele t pentru $\hat{b}_{1\%}$, cu eroarea standard sandviș estimată prin nucleu, merg de la 4,0 (HSBC) la 6,9 (JPMorgan): fiecare bancă contribuie (formula dispersiei: Regresia cuantilă: asimptotica)
- (2) Legătura din coadă este egală cu cea din centru, $H_0: b_\alpha = b_{50\%}$: se comportă banca altfel în crize?
  - Respinsă pentru 2 din 11 bănci la 5% (2 după Holm): pentru majoritatea băncilor legătura din coadă este egală cu cea din centru
- (3) Contribuții egale, $H_0: \Delta\mathrm{CoVaR}_i = \Delta\mathrm{CoVaR}_j$: aceleași zile reeșantionate pentru **toate** băncile dau distribuția comună
  - La $\alpha = 1\%$: 4 din 25 de perechi de bănci din aceeași regiune diferă la pragul de 5% (0 după corecția Holm), iar testul Wald comun dă $p = 0{,}01$ (SUA) și 0,31 (Europa)
  - La $\alpha = 5\%$: 3 din 25 de perechi diferă (0 după corecția Holm), iar testul Wald comun dă $p = 0{,}014$ (SUA) și 0,046 (Europa)
- Teste de semnificație și de dominanță pentru importanța sistemică: Castro & Ferrari (2014); pantele și p-value-urile fiecărei bănci: Anexă

Cum citim testele: Holm și testul Wald comun

- **Multe perechi, o singură familie**: cu 25 de perechi testate fiecare la 5%, ne așteptăm la mai mult de o „diferență" falsă chiar dacă toate contribuțiile ar fi egale
  - Holm (1979): ordonăm cele m p-value-uri, $p_{(1)} \leq \cdots \leq p_{(m)}$, și respingem pas cu pas cît timp $p_{(k)} \leq 0{,}05/(m-k+1)$, oprindu-ne la primul eșec
  - Procedura menține probabilitatea **oricărei** respingeri false din familie (eroarea pe familie) la cel mult 5%, pentru orice dependență între teste
  - Exemplu, $m = 3$, $p = 0{,}010;\ 0{,}030;\ 0{,}040$: $0{,}010 \leq 0{,}05/3 = 0{,}017$ (respingem), $0{,}030 > 0{,}05/2 = 0{,}025$ (ne oprim): o singură respingere în loc de trei
- **Testul Wald comun** pentru „toate contribuțiile dintr-o regiune sînt egale": o singură statistică χ^2
  - $W = \hat{d}^\top \hat{V}^{-1} \hat{d}$: $\hat{d}$ conține diferențele celorlalte bănci față de o bancă de referință (orice alegere dă același W), iar $\hat{V}$ covariația lor bootstrap
  - Gradele de libertate: numărul băncilor minus 1
- De ce testul comun respinge pentru SUA ($p = 0{,}01$), deși după Holm rămîn semnificative 0 din 25 de perechi
  - Testul comun adună mai multe diferențe moderate într-o singură statistică, în timp ce Holm cere ca o pereche să fie foarte puternică singură ($p_{(1)} \leq 0{,}05/25$ pentru familia comună de 15 perechi americane și 10 europene)
  - Interpretarea: contribuțiile băncilor americane nu sînt toate egale, dar datele nu arată care pereche diferă

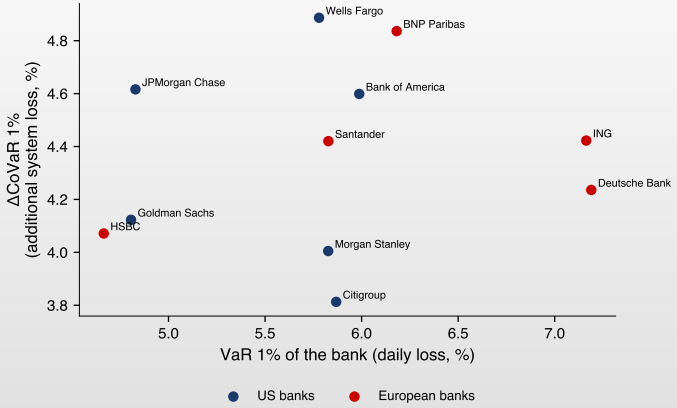
CoVaR Girardi–Ergün: pierderi cel puțin egale cu VaR

- Girardi & Ergün (2013) condiționează pe pierderea băncii **cel puțin egală** cu VaR-ul ei, nu exact egală cu acesta
  - $P\left(X^{sys} \leq -\mathrm{CoVaR}^{\leq}_{\alpha} \;\middle|\; X_i \leq -\mathrm{VaR}_{i,\alpha}\right) = \alpha \iff P\left(X^{sys} \leq -\mathrm{CoVaR}^{\leq}_{\alpha}, X_i \leq -\mathrm{VaR}_{i,\alpha}\right) = \alpha^2$
  - $\mathrm{CoVaR}^{\leq}_{\alpha}$: CoVaR condiționat de o pierdere cel puțin egală cu VaR
  - Forma cu probabilitatea comună rezultă din $P(A \mid B) = P(A,B)/P(B)$ cu $P(B) = \alpha$
  - Starea de referință: un eveniment de o abatere standard $|X_i - \mu_i| \leq \sigma_i$ (μ_i, σ_i: media și abaterea standard a lui X_i) în locul medianei
  - Starea de referință intră doar în $\Delta\mathrm{CoVaR}^{\leq}$; mai jos comparăm niveluri CoVaR
- Relevanța
  - Include dificultăți mai severe decît ziua de VaR însăși și crește cu intensitatea dependenței (de ex. cu corelația ρ a unei Normale bivariate), ceea ce CoVaR condiționat de $X_i = -\mathrm{VaR}_{i,\alpha}$ nu face neapărat Mainik & Schaanning (2014)
  - Se poate face **backtesting**: evenimentul comun $\{X^{sys} \leq -\mathrm{CoVaR}^{\leq}, X_i \leq -\mathrm{VaR}_i\}$ are probabilitatea α^2
- Estimarea istorică la $\alpha = 5\%$: cuantila de 5% a sistemului în cele 198 de zile cu $X_i \leq \hat{q}_{5\%}(X_i)$
  - JPMorgan: $\mathrm{CoVaR}^{\leq}_{5\%} = 7{,}70\%$ față de $\mathrm{CoVaR}_{5\%} = 3{,}81\%$ din regresia cuantilă
  - Pentru cele unsprezece bănci: 7,3–8,2%, față de 3,6–4,8% din regresia cuantilă
  - În datele noastre, aproximativ de două ori mai mare: întreaga coadă a băncii este un eveniment de condiționare mai sever
  - Sub distribuția Normală, această schimbare crește CoVaR doar moderat, deci factorul doi este compatibil cu abateri de la reperul Normal; raportul singur nu identifică însă cauza lor

O verificare sub distribuția Normală: care CoVaR crește odată cu dependența?

- Normală bivariată cu medii zero, $\sigma_{sys} = 1{,}5$, $\alpha = 1\%$, $z = -2{,}326$, iar banca se află la VaR, $X_i = -\mathrm{VaR}_{i,\alpha}$
  - Condiționat de bancă, sistemul are media $\rho\,\sigma_{sys} z$ și abaterea standard $\sigma_{sys}\sqrt{1-\rho^2}$
  - Deci $\mathrm{CoVaR}_\alpha = \sigma_{sys}|z|\left(\rho + \sqrt{1-\rho^2}\right)$, iar cu starea mediană $X_i = 0$, $\Delta\mathrm{CoVaR}_\alpha = \rho\,\sigma_{sys}|z|$
- Exemplu: întărim legătura de la $\rho = 0{,}6$ la $\rho = 0{,}9$
  - $\mathrm{CoVaR}_{1\%}$: 4,89% scade la 4,66%, pentru că $\rho + \sqrt{1-\rho^2}$ are maximul la $\rho = 0{,}71$
  - $\Delta\mathrm{CoVaR}_{1\%}$: 2,09% crește la 3,14%
- Lecția: nivelul CoVaR condiționat de $X_i = -\mathrm{VaR}_{i,\alpha}$ poate scădea cînd băncile devin mai interdependente
  - În acest model diferența ΔCoVaR crește odată cu ρ (formula de mai sus), la fel ca $\mathrm{CoVaR}^{\leq}$ Girardi–Ergün Mainik & Schaanning (2014)

VaR și ΔCoVaR măsoară lucruri diferite (1/2)



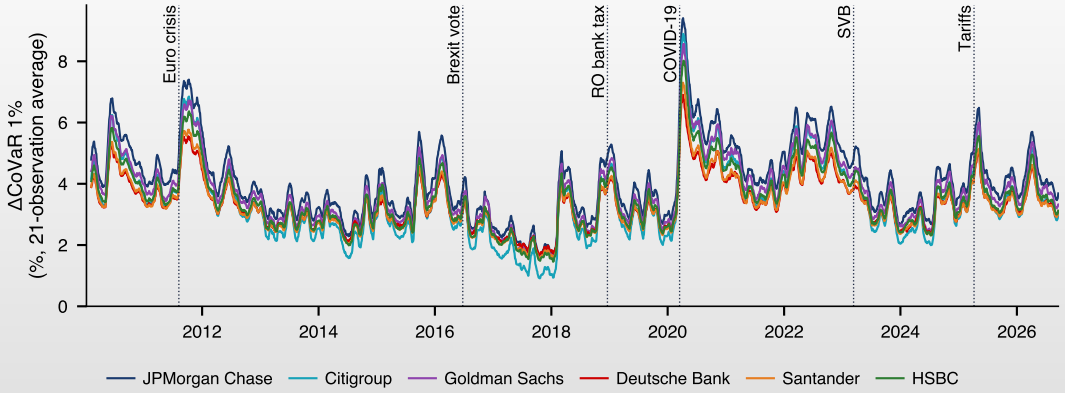
MFM_ch18_covar

VaR și ΔCoVaR măsoară lucruri diferite (2/2)

- Unsprezece bănci, 2010–2026
  - Axa orizontală: VaR 1% al băncii
  - Axa verticală: ΔCoVaR 1% al băncii
- Corelația de rang Spearman dintre VaR și ΔCoVaR: 0,16
  - Deutsche Bank și ING au cele mai mari VaR (7,19% și 7,16%), dar doar un ΔCoVaR mediu
  - JPMorgan are unul dintre cele mai mici VaR (4,83%), dar unul dintre cele mai mari ΔCoVaR
- Mesajul central al lucrării Adrian & Brunnermeier (2016)
  - Reglementarea fiecărei bănci după propriul VaR ignoră contribuția ei la sistem
- Atenție: cu unsprezece bănci și intervale suprapuse, corelația este foarte incertă

MFM_ch18_covar

ΔCoVaR 1% în timp (1/2)



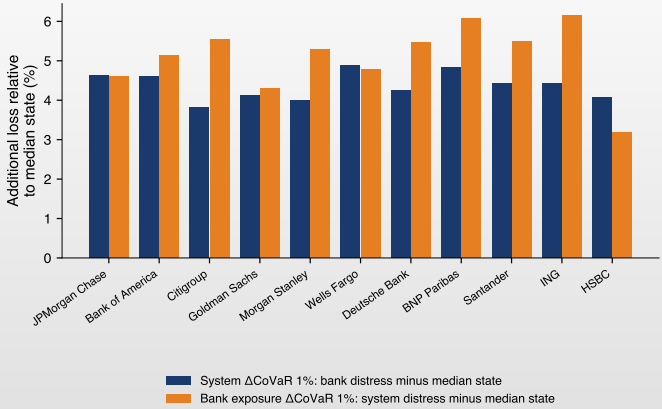
MFM_ch18_covar_dynamic

ΔCoVaR 1% în timp (2/2)

- Șase bănci, medii mobile pe 21 de observații ale ΔCoVaR 1% zilnic
  - Variabile de stare $M_{t-\mathbf{1}}$: log VIX, randamentul indicelui regional și al sistemului, întîrziate cu o zi Adrian & Brunnermeier (2016)
  - $\Delta\mathrm{CoVaR}_{\alpha,t} = \hat{b}\left(\hat{q}_{\mathbf{50\%},t}(X_i) - \hat{q}_{\alpha,t}(X_i)\right)$, cu $\hat{q}_{\cdot,t}$ condiționat de $M_{t-\mathbf{1}}$ (▸ Anexă)
- JPMorgan: media 2,16% în 2017, media 9,06% în martie 2020, maximul 10,99% pe 2020-03-18
  - Deutsche Bank: media 2,04% în 2017, media 6,65% în martie 2020
- Mic în perioadele calme, exact cînd riscul se poate acumula în bilanțuri
  - De aceea Adrian & Brunnermeier (2016) propun un ΔCoVaR anticipat, prognozat din leverage, mărime și nepotrivirea scadențelor (active pe termen lung finanțate cu datorii pe termen scurt, care trebuie refinanțate)

MFM_ch18_covar_dynamic

Contribuție față de expunere (1/2)



MFM_ch18_covar

Contribuție față de expunere (2/2)

- Două direcții ale ΔCoVaR 1%
  - Albastru, contribuția: pierderea sistemului cînd banca este în dificultate
  - Portocaliu, expunerea: pierderea băncii cînd sistemul este în dificultate
  - Același calcul cu rolurile inversate: X_i regresat pe X^{sys}, apoi se introduc cuantilele lui X^{sys}
- Direcția contează: cele două numere diferă pentru majoritatea băncilor
  - ING: contribuție 4,42%, expunere 6,14%
  - BNP Paribas: contribuție 4,84%, expunere 6,07%
  - HSBC: contribuție 4,07%, expunere doar 3,17%
- Expunerea depășește contribuția pentru majoritatea băncilor europene
  - Ambele sînt asocieri, nu efecte cauzale
- Expunerea contează pentru capitalul propriu al băncii, iar contribuția pentru autoritatea de reglementare

MFM_ch18_covar

Fiabilitatea clasamentelor

- Clasamentele după măsuri sistemice diferite nu coincid Nucera, Schwaab, Koopman & Lucas (2016)
  - Fiecare clasament are o incertitudine de eșantionare mare
  - Combinăm măsurile și raportăm incertitudinea clasamentului în locul unei ordini unice
- Riscul de model: măsura aceleiași bănci variază de la o metodă de estimare la alta Danielsson, James, Valenzuela & Zer (2016)
  - Exemple din acest capitol: LRMES simulat față de aproximare, CoVaR Girardi–Ergün față de regresia cuantilă, clasamentele la $\alpha = 1\%$ față de $\alpha = 5\%$
- Eșantionul efectiv din coadă, αn: 40 de zile la 1% și 198 la 5%, din totalul de 3 960
  - La 1% erorile standard cu nucleu și bootstrap pe blocuri diferă (Anexă)
- Backtesting-ul în afara eșantionului pentru $\mathrm{CoVaR}^{\leq}_{5\%}$ nu respinge pentru nicio bancă (Anexă)
  - Cu aproximativ 7,4 evenimente comune așteptate, puterea lor este mică
- Rezultatele robuste: diferențele mari și testate
  - Diferențele dintre regiuni și panta din coadă a unor bănci, nu ordinea a unsprezece estimări punctuale apropiate

De la perechi la rețele: descompunerea dispersiei (1/2)

- CoVaR analizează o bancă și un sistem, în timp ce o **rețea** analizează simultan toate perechile
  - Nodurile sînt băncile
  - Muchiile orientate arată cît din incertitudinea viitoare a băncii i vine din șocurile băncii j
- Autoregresie vectorială (VAR, vector autoregression) de ordin p pentru N serii y_t: $y_t = c + \sum_{l=\mathbf{1}}^{p} A_l\, y_{t-l} + \varepsilon_t$, $\mathrm{Cov}(\varepsilon_t) = \Sigma$
  - Fiecare serie este regresată pe p laguri ale tuturor seriilor (ipotezele: Anexă)
  - c este vectorul constantelor, iar A_l sînt matrici de coeficienți $N \times N$
  - ε_t: șocurile, cu matricea de covarianță Σ
- Rețele din descompunerea dispersiei Diebold & Yilmaz (2009), Diebold & Yilmaz (2012), Diebold & Yilmaz (2014): abordarea din această secțiune
- Alte rețele: cauzalitate Granger Billio, Getmansky, Lo & Pelizzon (2012) (Anexă), rețele în coadă TENET (Tail-Event driven NETwork risk) Härdle, Wang & Yu (2016) și Financial Risk Meter (secțiunea următoare)

De la perechi la rețele: descompunerea dispersiei (2/2)

- Eroarea de prognoză pe H zile a lui y_i este o sumă de șocuri ale tuturor seriilor: dispersia ei se poate împărți pe surse
  - Forma de medie mobilă $y_t = \mu + \sum_{h \geq \mathbf{0}} \Phi_h \, \varepsilon_{t-h}$: Φ_h este răspunsul lui y după h zile la un șoc de azi, $\Phi_{\mathbf{0}} = I$
- Șocurile ortogonale (Cholesky) depind de ordinea seriilor, în timp ce descompunerea **generalizată** nu depinde de ea Koop, Pesaran & Potter (1996), Pesaran & Shin (1998)
  - $\theta_{ij}(H) = \dfrac{\sigma_{jj}^{-\mathbf{1}} \sum_{h=\mathbf{0}}^{H-\mathbf{1}} (e_i^\top \Phi_h \Sigma e_j)^{\mathbf{2}}}{\sum_{h=\mathbf{0}}^{H-\mathbf{1}} e_i^\top \Phi_h \Sigma \Phi_h^\top e_i}$, normalizat: $\tilde{\theta}_{ij} = \theta_{ij} / \sum_j \theta_{ij}$
  - Numărătorul: partea din dispersia erorii de prognoză a lui i datorată unui șoc în j
  - Numitorul: dispersia totală a erorii de prognoză a lui i
  - e_i: al i-lea vector unitar (selectează seria i)
  - σ_{jj}: varianța șocului j, al j-lea element de pe diagonala lui Σ

Tabelul conectivității

- $\tilde{\theta}_{ij}$ (în %): proporția din dispersia erorii de prognoză pe H zile a lui i datorată șocurilor lui j Diebold & Yilmaz (2014)
  - Fiecare linie însumează 100
  - Înainte de normalizare, liniile lui θ_{ij} nu însumează unu: șocurile generalizate sînt corelate
- Măsurile direcționale
  - **De la** ceilalți: $F_i = \sum_{j \neq i} \tilde{\theta}_{ij}$
  - **Către** ceilalți: $T_j = \sum_{i \neq j} \tilde{\theta}_{ij}$
  - **Net**: $T_i - F_i$, pozitiv pentru un transmițător net
  - **Net pe perechi**: $\tilde{\theta}_{ji} - \tilde{\theta}_{ij} > 0$ înseamnă că i transmite net către j și se desenează ca săgeată $i \to j$
- **Conectivitatea totală**: $C = \frac{1}{N} \sum_{i \neq j} \tilde{\theta}_{ij}$
  - Proporția medie din dispersie care vine de la ceilalți, între 0 și 100%

Exemplu: tabelul conectivității pentru două bănci

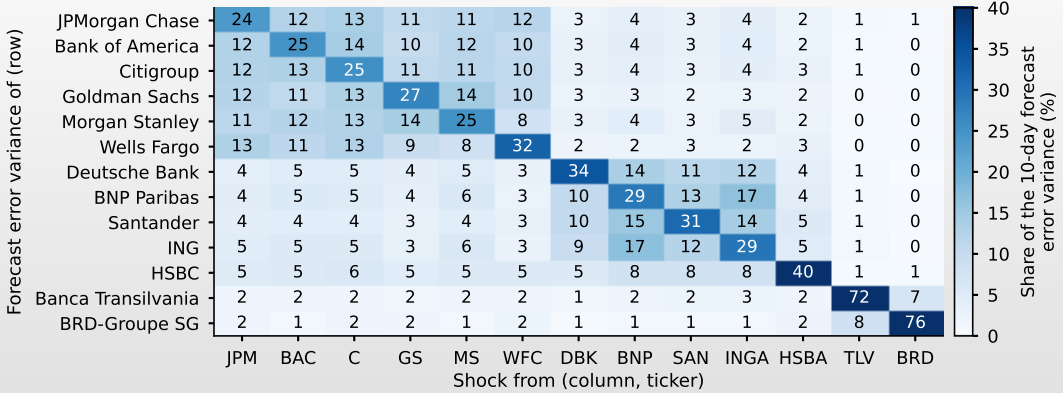
Banca i \ șocul j	1	2	F_i
1	80	20	20
2	40	60	40
T_j	40	20	

- Tabel normalizat ilustrativ $\tilde{\theta}_{ij}$ (%): linia i este banca a cărei dispersie se împarte, coloana j sursa șocului; liniile însumează 100
- Doar celulele din afara diagonalei
  - De la ceilalți: $F_1 = 20$, $F_2 = 40$ (sume pe linii)
  - Către ceilalți: $T_1 = 40$, $T_2 = 20$ (sume pe coloane)
- Net: banca 1 $40 - 20 = +20$ (transmițător), banca 2 -20; pozițiile nete însumează întotdeauna zero
- Total: $C = (20 + 40)/2 = 30\%$

Volatilitatea Parkinson din range și VAR-ul celor treisprezece bănci

- **Volatilitatea Parkinson** din prețul maxim $P_t^{\max}$ și prețul minim $P_t^{\min}$ ale zilei Parkinson (1980)
  - $\hat{\sigma}_t^2 = \dfrac{(\ln P_t^{\max} - \ln P_t^{\min})^2}{4 \ln 2}$, anualizată $100\sqrt{252\,\hat{\sigma}_t^2}$, folosită în logaritm
  - Estimatorul este nedeplasat pentru dispersia unei mișcări browniene fără drift
  - Este mai eficient decît randamentul la pătrat
- Modelul nostru: VAR pe logaritmul volatilității celor 13 bănci
  - Ordinul VAR, ales după criteriul informațional bayesian (BIC): $p = 2$
  - Orizontul de prognoză: $H = 10$ zile
  - Din cauza fusurilor orare, băncile americane se închid după cele europene, iar lagurile VAR captează transmiterea din ziua următoare

Tabelul conectivității pentru treisprezece bănci (1/2)



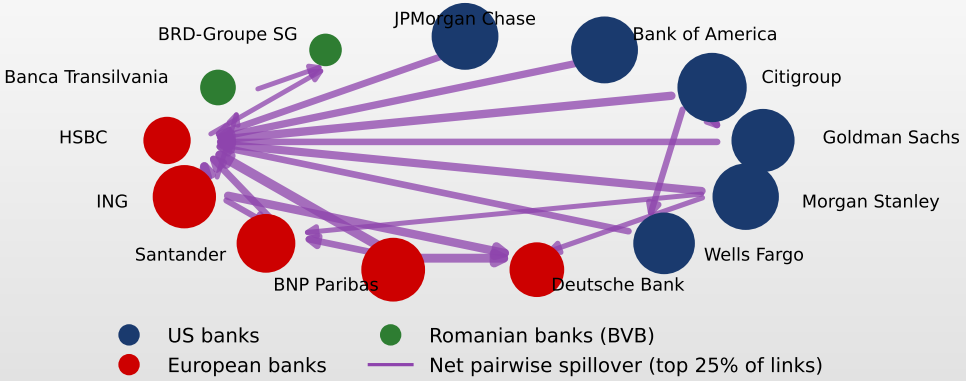
MFM_ch18_spillover

Tabelul conectivității pentru treisprezece bănci (2/2)

- Linia i, coloana j: proporția (%) din dispersia erorii de prognoză pe 10 zile a băncii i datorată șocurilor băncii j
  - Întreaga perioadă
  - Coloanele folosesc simbolurile bursiere din tabelul datelor (de ex. INGA = ING, HSBA = HSBC)
- Conectivitatea totală $C = 63{,}9\%$
  - În medie, două treimi din riscul de volatilitate al unei bănci provin de la celelalte
  - Pe randamente în loc de volatilitate: $C = 75{,}4\%$
- Două blocuri regionale, inclusiv șocul propriu
  - O bancă americană primește 84,0% din dispersie de la șocurile americane, iar una europeană 72,7% de la cele europene
  - Peste Atlantic: 26,2% de la băncile americane către o bancă europeană și 15,0% în sens invers
- Băncile românești: mai ales șocurile proprii
  - Ponderea șocurilor proprii: 72,3% (Banca Transilvania), 76,1% (BRD)
  - De la băncile americane vine 10,3%, iar de la cele europene 8,0%

MFM_ch18_spillover

Rețeaua de spillover net (1/2)



Rețeaua de spillover net (2/2)

- Săgeată $j \to i$ cînd j transmite net către i (cele mai mari 25% dintre spillover-urile nete pe perechi)
  - Mărimea nodului crește cu spillover-ul către ceilalți
- Transmițători neți: Citigroup (+19,0), Bank of America (+10,9), Morgan Stanley (+9,9), JPMorgan (+9,8)
  - Spillover-ul către ceilalți: Citigroup 93,8%, JPMorgan 86,2% (suma unei coloane poate depăși 100)
- Receptori neți: HSBC (−23,6), BRD (−13,0), Deutsche Bank (−12,6), Banca Transilvania (−12,2)
  - HSBC primește de la aproape toate băncile: se tranzacționează la Londra, între Asia și New York
- În Europa, BNP Paribas și ING transmit către Deutsche Bank și Santander
- O rețea estimată pe întreaga perioadă face media anilor liniștiți și a celor de criză

MFM_ch18_spillover

Conectivitatea în timp (1/2)



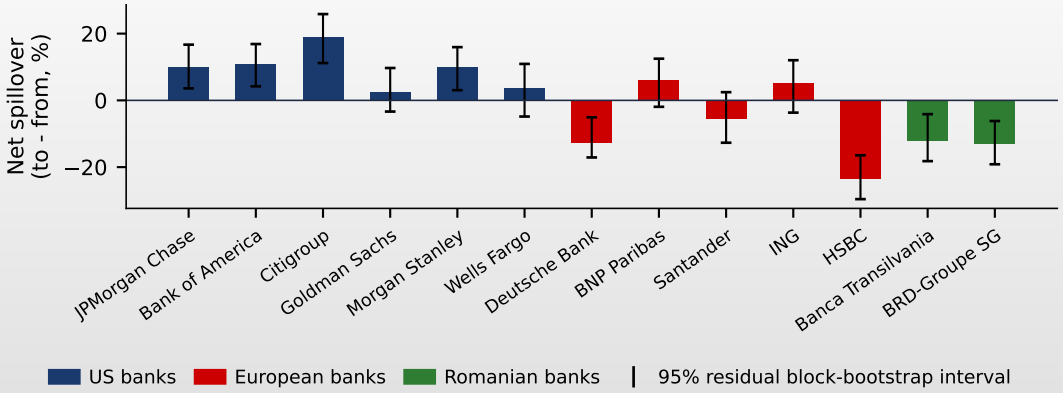
MFM_ch18_spillover_rolling

Conectivitatea în timp (2/2)

- Graficul de sus: conectivitatea totală pe ferestre mobile de 250 de zile (VAR(2), $H = 10$, recalculată la fiecare 5 zile)
- Graficul de jos: spillover-ul net însumat pe regiuni
- Indicele total variază între 47,4% (2024-07-24) și 79,3% (2020-08-27), cu media 62,0%
  - COVID-19: de la 61,8% în 2019 la 78,4% în primăvara lui 2020
  - Indicele urcă în cîteva zile; scăderea după aproximativ 250 de zile reflectă în parte ieșirea crizei din fereastră
  - După falimentele bancare din 2023, indicele este 66,0%, iar în anul liniștit 2024, 53,5%
- Băncile americane sînt transmițători neți în 89% dintre ferestre (suma spillover-urilor nete ale celor șase bănci americane, media pe ferestre: $+48{,}4$ puncte)
  - Băncile europene au fost transmițători neți în criza din zona euro din 2011–2012 și mai ales receptori neți după aceea
- Băncile românești sînt, în medie, receptori neți (suma spillover-urilor nete ale celor două bănci românești, media pe ferestre: $-24{,}1$ puncte)

MFM_ch18_spillover_rolling

Eroarea de estimare: intervale bootstrap pentru rețea (1/2)



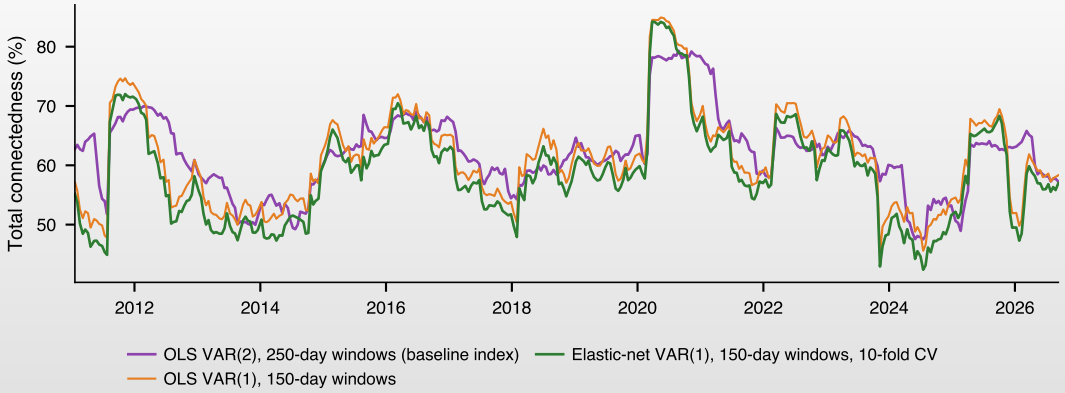
MFM_ch18_spillover_uncertainty

Eroarea de estimare: intervale bootstrap pentru rețea (2/2)

- Un VAR(1) pe 13 serii are 169 de coeficienți de pantă, iar VAR(2) folosit aici are $2 \times 169 = 338$
  - O fereastră de 250 de zile oferă 250 de observații pe ecuație pentru 26 de pante și o constantă
  - Tabelul conectivității este o funcție neliniară a tuturor coeficienților
- Bootstrap pe blocuri de reziduuri, 999 de extrageri
  - Reeșantionăm blocuri de 20 de zile din vectorii de reziduuri, reconstruim seriile cu VAR-ul estimat, reestimăm, recalculăm tabelul
- Întreaga perioadă, $p = 2$: $C = 63{,}9\%$, interval de 95% $[59{,}9; 65{,}8]$
  - Fereastra cu valoarea maximă (pînă la 2020-08-27): $C = 79{,}3\%$, cu intervalul $[65{,}9; 83{,}0]$
  - Media bootstrap este 75,8%: în eșantioanele mici, și estimatorul lui C este deplasat
- 8 din 13 poziții nete au intervale care exclud zero
  - Pentru celelalte 5, eticheta „transmițător" sau „receptor" nu este identificată
  - Rețeaua de spillover net desenează cele mai mari 25% dintre legături, inclusiv unele nesemnificative: de aceea raportăm intervalele

MFM_ch18_spillover_uncertainty

Conectivitatea OLS și elastic net pe ferestre mobile (1/2)



MFM_ch18_spillover_uncertainty

Conectivitatea OLS și elastic net pe ferestre mobile (2/2)

- Demirer et al. (2018): fiecare ecuație VAR prin elastic net adaptiv; pe ferestrele de 150 de zile, elastic net simplu
  - λ ales ecuație cu ecuație prin validare încrucișată cu 10 grupe, „10-fold CV" (cross-validation) în grafic (definiția în Anexă)
- Pe întreaga perioadă: $C = 63{,}3\%$ cu elastic net, față de 63,9% cu OLS (ordinary least squares, metoda celor mai mici pătrate)
- Cu elastic net, 59% dintre coeficienți sînt nenuli
- Medii pe 372 de date finale comune, cu pas de 10 zile de tranzacționare; indicele de bază recalculat pe aceleași date
  - Indicele de bază (VAR(2) OLS, 250 de zile): 62,0%
  - VAR(1) OLS, 150 de zile: 61,1%
  - VAR(1) elastic net, 150 de zile: 58,7%
- Evoluțiile coincid: corelația dintre indicele elastic net și indicele de bază este 0,82, iar vîrfurile din crize apar în aceleași săptămîni
  - Nivelurile depind de fereastră, estimator și ordinul VAR, dar schimbările în timp sînt robuste

MFM_ch18_spillover_uncertainty

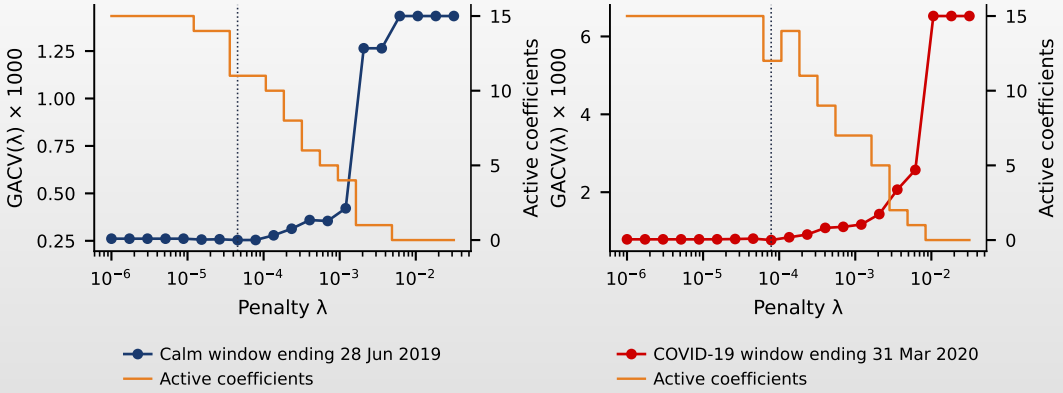
Financial Risk Meter și penalizarea GACV (1/2)

- Pentru fiecare firmă j, o regresie cuantilă la $\tau = 5\%$ a randamentului ei pe randamentele **tuturor** celorlalte firme și pe variabile macro întîrziate Mihoci, Althof, Chen & Härdle (2020)
  - Cu 100 de firme și o fereastră de 63 de zile sînt mai mulți regresori decît zile: este nevoie de o penalizare
- Regresie cuantilă **LASSO** (Least Absolute Shrinkage and Selection Operator, regresie penalizată L1) Belloni & Chernozhukov (2011)
  - $\hat{\beta}_j(\lambda) = \arg\min_\beta \frac{1}{n} \sum_t \rho_\tau \left(X_{j,t} - \beta_{\mathbf{0}} - \beta^\top Z_{-j,t} \right) + \lambda \|\beta\|_{\mathbf{1}}$
  - $X_{j,t}$ este randamentul firmei j, iar $Z_{-j,t}$ conține randamentele celorlalte firme și variabilele macro întîrziate
  - $\beta_{\mathbf{0}}$ este termenul liber, iar ρ_τ funcția de pierdere cuantilă
  - $\|\beta\|_{\mathbf{1}} = \sum_k |\beta_k|$ este norma L1, iar n numărul de zile din fereastră
  - λ elimină legăturile slabe: un λ mai mare lasă mai puțini coeficienți activi
- **GACV** (Generalized Approximate Cross-Validation, validare încrucișată aproximativă generalizată) echilibrează potrivirea cu numărul de coeficienți activi
  - $\mathrm{GACV}(\lambda) = \frac{\sum_t \rho_\tau \left(X_{j,t} - \hat{X}_{j,t}(\lambda) \right)}{n - \mathrm{df}(\lambda)}$, $\hat{X}_{j,t}(\lambda)$: cuantila ajustată
  - df: numărul coeficienților nenuli
  - Valoarea aleasă λ_j minimizează GACV

Financial Risk Meter și penalizarea GACV (2/2)

- **FRM** (Financial Risk Meter) este media valorilor λ_j alese pe toate firmele, construită ca indicator al interdependenței din coadă și al stresului sistemic
  - Construit pentru firmele financiare americane Mihoci, Althof, Chen & Härdle (2020), piețele emergente Ben Amor, Althof & Härdle (2022) și China Wang, Althof & Härdle (2023)
- Versiunea noastră: 13 bănci, cu S&P 500, Euro Stoxx 50 și VIX la $t-1$ ca variabile macro, pe ferestre de 63 de zile recalculate la fiecare 10 zile
  - Avem 15 regresori pentru 63 de zile, mult mai puțini decît în FRM publicat
- Extensii: FRM bazat pe expectile Ren, Lu, Li & Härdle (2022), pentru criptomonede Ren, Althof & Härdle (2025) și pentru sectorul energetic din UE Toma, Dima, Grecu, Pele & Lessmann (2026)

GACV într-o fereastră calmă și într-una de criză (1/2)



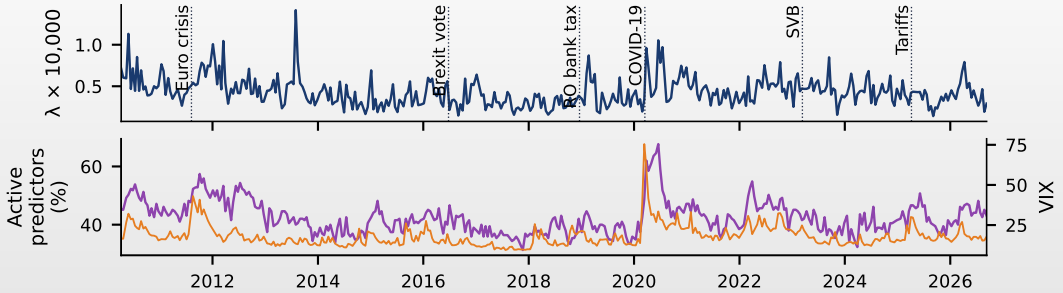
MFM_ch18_frm

GACV într-o fereastră calmă și într-una de criză (2/2)

- Regresia lui JPMorgan pe celelalte 12 bănci și pe trei variabile macro întîrziate, într-o fereastră de 63 de zile
  - Linia punctată marchează λ ales
  - Cu portocaliu: coeficienții activi
- Fereastra calmă (pînă la 28 iunie 2019): $\hat{\lambda} = 4{,}5 \times 10^{-5}$, 11 din 15 coeficienți activi
  - Fereastra COVID-19 (pînă la 31 martie 2020): $\hat{\lambda} = 7{,}8 \times 10^{-5}$, 12 coeficienți activi
- În criză, întreaga curbă GACV este de aproximativ trei ori mai sus
  - Funcția de pierdere cuantilă este în unitățile randamentelor, iar randamentele din criză sînt mai mari
- Cu puțini regresori, minimul se află aproape fără penalizare: alegerea este zgomotoasă

MFM_ch18_frm

Financial Risk Meter pentru treisprezece bănci (1/2)



MFM_ch18_frm

Financial Risk Meter pentru treisprezece bănci (2/2)

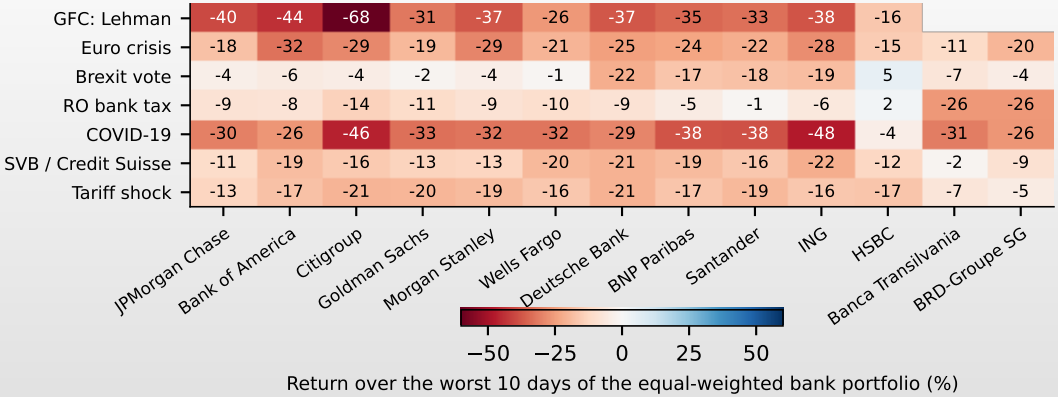
- Graficul de sus: penalizarea GACV medie pe cele 13 bănci, în 390 de ferestre de 63 de zile
  - Graficul de jos: proporția predictorilor activi la un λ fix, împreună cu VIX
- Penalizarea GACV medie este zgomotoasă: corelația cu VIX este doar 0,35
- La $\lambda = 2{,}3 \times 10^{-4}$ fix, proporția predictorilor activi urmează mai îndeaproape VIX (corelația 0,62)
  - Proporția variază de la 31% (2017-11-21) la 68% (2020-06-17), cu media 42%
- Lecția: pe acest panel mic, niciuna dintre măsuri nu se dovedește un indicator fiabil al riscului sistemic
  - Numărul la penalizare fixă este doar o verificare exploratorie a sensibilității

MFM_ch18_frm

Teste de stres și scenarii istorice

- Un test de stres: cît s-ar pierde într-un scenariu **sever, dar plauzibil**?
  - **Istoric**: reluăm o criză trecută
  - **Ipotetic**: aplicăm șocuri unor factori aleși
  - **Invers**: căutăm cel mai plauzibil scenariu din spatele unei pierderi date (de ex. una care ar face banca neviabilă)
  - Teste de supraveghere: Federal Reserve stress tests (SUA), European Banking Authority (UE)
  - Băncile de importanță sistemică globală: o listă de reglementare, pe baza unui scor al Comitetului de la Basel pentru mărime, interconectare, substituibilitate, complexitate și activitate transfrontalieră
  - Ele dețin capital suplimentar Basel Committee (2018)
- Șapte episoade, fiecare o fereastră de cîteva săptămîni în jurul unui șoc cunoscut
  - Lehman (toamna lui 2008; în grafic „GFC": global financial crisis, criza financiară globală), criza din zona euro (vara lui 2011), votul Brexit (iunie 2016), taxa bancară din România (decembrie 2018)
  - COVID-19 (martie 2020), SVB și Credit Suisse (martie 2023), șocul tarifelor (aprilie 2025)
- În fiecare fereastră: **cele 10 zile consecutive de tranzacționare cu cel mai mic randament cumulat** al portofoliului bancar cu ponderi egale
  - Raportăm randamentul fiecărei bănci în acest interval
  - Zece zile corespund orizontului riscului de piață (Capitolul 7)
  - Pentru 2008 folosim doar cele 11 bănci internaționale: seriile românești încep în 2010

Șapte scenarii istorice de stres (1/2)



MFM_ch18_stress

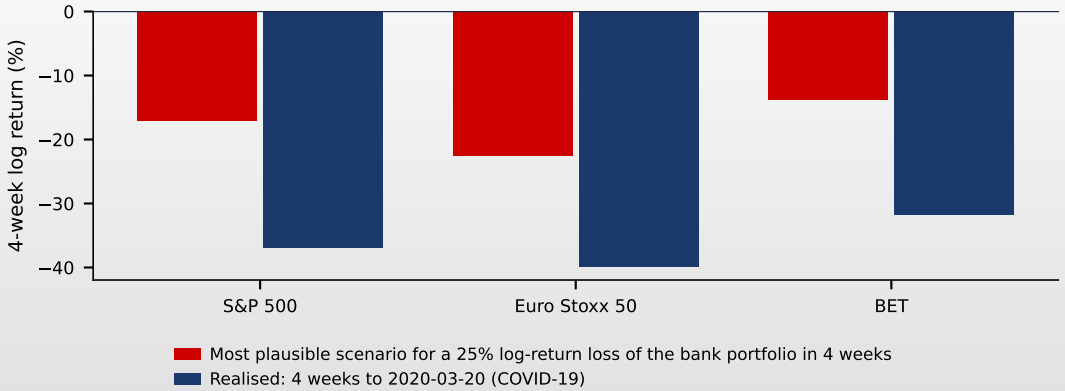
Șapte scenarii istorice de stres (2/2)

- Randamentul simplu (%) al fiecărei bănci în cele mai rele 10 zile consecutive ale portofoliului bancar din fiecare episod, $100(e^{\sum_t r_t/\mathbf{100}} - 1)$ din cele 10 randamente log zilnice r_t; celulele goale indică lipsa datelor
- Pierderea portofoliului în cele mai rele 10 zile
  - Lehman 37,6% (2008-11-10 – 2008-11-21), COVID-19 31,9%, criza din zona euro 22,3%
  - Șocul tarifelor 16,0%, SVB 14,8%, taxa bancară din România 10,2%, Brexit 7,9%
- Cele mai mari pierderi individuale: Citigroup -68% în 2008, ING -48% în martie 2020
  - Toate cifrele de aici sînt randamente simple, adică variații de preț; -68% pentru Citigroup înseamnă -114% ca randament log cumulat, care nu este mărginit de -100%
- Șocurile sînt și locale, nu doar globale
  - Brexit a afectat mai ales băncile europene
  - Taxa bancară din România a afectat cel mai puternic băncile românești (Banca Transilvania -26%, BRD -26%)
  - În aceeași fereastră din decembrie 2018, băncile americane au pierdut între 8% și 14%
- Un test de stres construit doar pe crize globale ar rata șocul politic intern

Testarea inversă la stres

- Model factorial pentru randamentele log săptămînale (%) ale băncilor: $X_i = \beta_i^\top f + e_i$
  - Factorii: $f =$ (S&P 500, Euro Stoxx 50, BET)
  - β_i: coeficienții beta ai băncii față de factori
  - e_i: randamentul idiosincratic al băncii
  - Pe h săptămîni, $f \sim N(0, h\Sigma)$, unde Σ este covarianța săptămînală a factorilor (presupunem că nu există covariațe seriale)
- Pierderea portofoliului $L = -b^\top f$, unde b este media valorilor β_i
  - Portofoliul cu ponderi egale al celor 13 bănci, $w_i = 1/13$; L este o pierdere log în %
  - O aproximare doar pe factori: reziduul $\sum_i w_i e_i$ este pus egal cu zero
- Cel mai plauzibil scenariu cu pierderea ℓ^*: minimizăm $f^\top (h\Sigma)^{-1} f$ cu condiția $-b^\top f = \ell^*$
  - $f^* = -\ell^* \dfrac{h\Sigma\, b}{b^\top h\Sigma\, b}, \qquad d^* = \dfrac{\ell^*}{\sqrt{b^\top h\Sigma\, b}}$
  - $f^\top (h\Sigma)^{-1} f$: pătratul distanței Mahalanobis
  - d^*: pierderea țintă exprimată în abateri standard ale portofoliului
  - Un d^* mai mare înseamnă un scenariu mai puțin plauzibil (exemplu cu doi factori: Anexă)

Cel mai plauzibil scenariu pentru o pierdere log de 25% (1/2)



MFM_ch18_stress

Cel mai plauzibil scenariu pentru o pierdere log de 25% (2/2)

- Date săptămînale 2010–2026 (871 de săptămîni), orizont de patru săptămîni
  - Cu roșu: f^* pentru $\ell^* = 25\%$
  - Cu albastru: mișcările factorilor în cele mai rele patru săptămîni din 2020
- Coeficienții beta ai portofoliului: $b = (0{,}45;\ 0{,}65;\ 0{,}18)$, iar abaterea standard a portofoliului pe patru săptămîni este 5,79%
  - O pierdere log de 25% (adică o pierdere aritmetică de 22,1%) cere simultan randamente de $-17{,}2\%$ (S&P 500), $-22{,}6\%$ (Euro Stoxx 50) și $-13{,}9\%$ (BET)
- $d^* = 4{,}31$ abateri standard: sub distribuția Normală, probabilitatea unei asemenea pierderi pe patru săptămîni este $8{,}0 \times 10^{-6}$
  - Totuși, în cele patru săptămîni pînă la 2020-03-20, portofoliul a avut o pierdere log de 52,0% (modelul factorial dă 48,5%)
- Forma scenariului este informativă, dar probabilitatea lui nu este
  - Cozile grele și corelațiile care cresc fac probabilitățile Normale mult prea mici

MFM_ch18_stress

Riscul climatic și testul de stres climatic al BCE din 2022



Sediul Băncii Centrale Europene, Frankfurt, 2015

Foto: DXR (2015); CC BY-SA 4.0; Wikimedia Commons

- **Riscul fizic**: pierderi din inundații, secete, caniculă și furtuni care afectează garanțiile și debitorii
- **Riscul de tranziție**: pierderi din trecerea la o economie cu emisii reduse (prețul carbonului, reglementare, tehnologie)
- Riscuri de tip „lebădă verde": evenimente potențial extrem de perturbatoare, care ar putea sta la baza următoarei crize financiare sistemice Bolton et al. (2020)
  - Modelele de risc bazate pe trecut nu le pot anticipa
- La testul BCE din 2022 au participat 104 bănci semnificative, iar o proiecție bottom-up a pierderilor (fiecare bancă aplică scenariile supraveghetorului pe propriile date și modele) a acoperit 41 dintre ele ECB Banking Supervision (2022)
- Aproximativ 60% dintre bănci nu aveau un cadru de testare la stres pentru riscul climatic
- Doar 20% țineau cont de riscul climatic la acordarea creditelor
- Pierderi de credit și de piață de aproximativ 70 de miliarde EUR pentru cele 41 de bănci, într-un scenariu de tranziție dezordonată pe termen scurt și două scenarii de risc fizic
  - BCE precizează că cifra subestimează semnificativ riscul, din cauza lipsei de date, a modelelor rudimentare și a absenței efectelor de ordinul al doilea

Limitele testelor de stres

- Scenariile sînt alese de oameni: criza care vine este rareori cea care a fost testată
- Efectele de ordinul al doilea (fire sales, retrageri de finanțare, pierderi ale contrapărților) sînt greu de modelat și de obicei lipsesc, cum a observat BCE pentru testul său climatic
- Măsurile bazate pe piață (MES, CoVaR, conectivitate) reacționează repede, dar doar după ce prețurile se mișcă
- Testele de stres bazate pe bilanț evaluează riscurile viitoare, dar necesită mai mult timp
- Cercetarea despre semnalele de avertizare timpurie combină măsurile de piață cu datele din bilanț

Se schimbă rețeaua cu mărimea șocurilor?

- Ando, Greenwood-Nimmo & Shin (2022) se întreabă dacă topologia unei rețele financiare se schimbă cu **mărimea** șocurilor care o afectează
  - Pornind de la Diebold & Yilmaz (2014), autorii întreabă cum variază, în funcție de mărimea șocurilor, contribuția șocurilor idiosincratice ale lui j la incertitudinea viitoare a lui i
- Relevanța: conectivitatea din acest capitol se estimează la media condiționată (OLS, LASSO, elastic net Demirer et al. (2018)), adică descrie cum se propagă un șoc mediu
  - Șocurile sistemice sînt mai mari decît media
  - Interpretarea creșterii conectivității pe ferestre mobile ca semnal de criză presupune că relațiile estimate la medie se mențin și în cozi
- Legătura cu acest capitol: regresia cuantilă folosită pentru CoVaR Adrian & Brunnermeier (2016), Koenker & Bassett (1978) este aplicată aici modelului VAR, pe baza căruia se descompune dispersia
  - Giglio, Kelly & Pruitt (2016) au arătat că riscul sistemic deplasează coada stîngă a distribuției producției viitoare mai mult decît centrul ei
  - Ando, Greenwood-Nimmo & Shin (2022) pun aceeași întrebare, coadă față de centru, pentru rețeaua însăși
- Aplicația: interdependența dintre riscul de credit al statelor și cel al băncilor, în care operațiunile de salvare transferă riscul bancar către stat

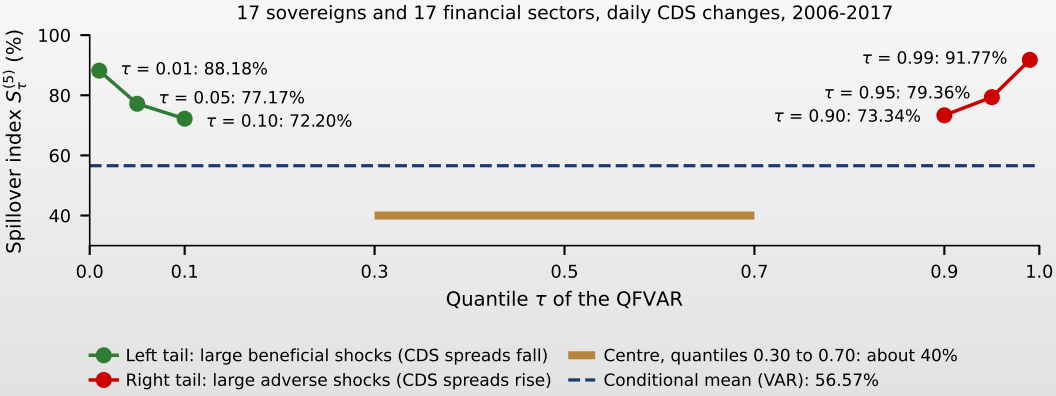
Datele CDS și VAR-ul cuantil cu factori

- Spread-ul CDS (credit default swap): prima anuală, în puncte de bază din suma asigurată (1 bp = 0,01%), plătită pentru protecție împotriva neplății unui stat sau a unei bănci; crește cînd riscul de neplată crește, deci o creștere este o veste proastă
- Datele: diferențele zilnice ale spread-urilor CDS pe 5 ani, în puncte de bază, pentru 17 state și 17 sectoare financiare naționale
  - În total $m = 34$ de serii, pe 3 129 de zile, între 3 ianuarie 2006 și 29 decembrie 2017
- VAR cuantil cu factori (QFVAR): $y_t = \mu + \sum_{j=\mathbf{1}}^{p} \Phi_j y_{t-j} + \Lambda f_t + v_t$, fiecare ecuație estimată la cuantila τ prin minimizarea funcției de pierdere cuantilă
  - y_t conține cele m variații CDS, iar μ constantele
  - Φ_j sînt matricile de coeficienți VAR, iar Λ încărcările factorilor
  - Factorii neobservați f_t preiau șocurile comune, deci v_t este idiosincratic
  - Numărul factorilor este ales după criteriul din Ando & Bai (2020): 10 factori la medie

Spillover și șocuri adverse de credit

- Descompunerea generalizată a dispersiei erorii de prognoză (FEVD) a șocurilor idiosincratice la cuantila τ, cu liniile normalizate la 1
  - Indicele de spillover: $S_\tau^{(h)} = m^{-1} \sum_i F_{i \leftarrow \bullet, \tau}^{(h)}$
  - $F_{i \leftarrow \bullet, \tau}^{(h)}$: proporția din dispersia erorii de prognoză pe h zile a lui i care vine de la celelalte serii (măsura „de la" din tabelul conectivității)
  - $S_\tau^{(h)}$ este media acestei proporții pe cele m serii
- Ferestre mobile de $w = 250$ de zile (2 880 de ferestre), cu numărul factorilor fixat la valoarea din întregul eșantion (specificația completă: ▸ Anexă)
  - Dependența relativă în cozi: $\mathrm{RTD} = S_{0,95}^{(5)} - S_{0,05}^{(5)}$
  - Pentru variațiile CDS, coada dreaptă ($\tau = 0{,}95$) conține șocurile adverse mari, iar coada stîngă ($\tau = 0{,}05$) pe cele favorabile mari

Spillover-ul pe cuantile (1/2)

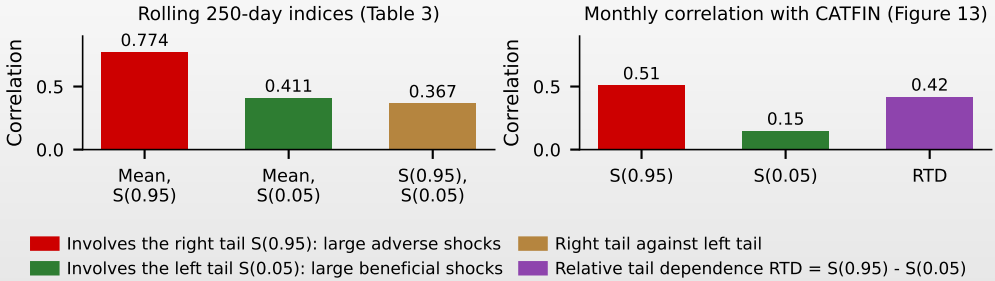


Spillover-ul pe cuantile (2/2)

- Indicele de spillover $S_{\tau}^{(5)}$ pe întregul eșantion, la fiecare cuantilă τ, față de indicele la medie
  - Sursa: Ando, Greenwood-Nimmo & Shin (2022)
- Profil în formă de U: circa 40% în centru, 88,18% la $\tau = 0{,}01$; 91,77% la $\tau = 0{,}99$
  - Indicele la medie (56,57%) nu descrie niciun regim: prea mare pentru șocurile mici, prea mic pentru cele mari
- Pe întregul eșantion, cozi aproape simetrice: $\mathrm{RTD} = 79{,}36 - 77{,}17 = 2{,}19$ puncte
  - Pe ferestre mobile asimetria este mai mare și variază (graficul următor)
- Consecința pentru testele de stres
  - Conectivitatea la medie subestimează cît din dispersia erorii de prognoză pe 5 zile a unui sector vine, într-o criză, de la celelalte sectoare

MFM_ch18_quantile_connectedness

Cozile evoluează diferit (1/2)



- Graficul din stînga: corelațiile dintre indicii pe ferestre mobile ($w = 250$ de zile, $h = 5$)
- Graficul din dreapta: corelațiile lunare cu CATFIN (sursa: Ando, Greenwood-Nimmo & Shin (2022))
- CATFIN: media a trei estimări VaR 1% pentru acțiunile financiare Allen, Bali & Tang (2012)

MFM_ch18_quantile_connectedness

Cozile evoluează diferit (2/2)

- Indicele la medie urmează coada adversă (corelația 0,774 cu $S_{0,95}$) mult mai mult decît coada favorabilă (corelația 0,411 cu $S_{0,05}$)
  - O creștere a conectivității la medie este mai ales o intensificare a transmiterii șocurilor adverse
- Cele două cozi au puțină variație comună (corelația dintre ele este 0,367)
  - Doi indicatori, nu același indice măsurat de două ori
  - De aceea RTD este informativ: circa ± 15 puncte pe ferestre mobile, față de 2,19 pe întregul eșantion
- Corelația cu CATFIN: 0,51 pentru $S_{0,95}$, 0,42 pentru RTD, doar 0,15 pentru $S_{0,05}$
  - CATFIN evoluează mai mult cu transmiterea șocurilor adverse decît cu a celor favorabile (legăturile bilaterale slabe și RTD în timp: Anexă)

Extindere pe cele 13 bănci: specificație și întrebări deschise

- Datele cursului: prețurile zilnice de închidere ale celor 13 bănci din acest capitol (SUA, zona euro și Regatul Unit, România), 2010–2026
  - y_t = pierderea zilnică $-r_t$ în %, astfel încît coada dreaptă să fie cea adversă, ca la CDS
  - Limite ale datelor: pierderi din acțiuni în loc de variații ale spread-urilor CDS, 13 bănci și niciun stat ($m = 13$ în loc de 34), ore de închidere diferite pe piețele din SUA, Europa și România
- Limitele precizate de autori: ordinul VAR ales pentru media condiționată este păstrat la fiecare cuantilă, iar cuantila rămîne fixă pe orizont (alte limite: Anexă)
- Extindere deschisă
  - Crește RTD al celor 13 bănci înainte de martie 2020 și de falimentele bancare din martie 2023?
  - Anticipează stresul bancar dincolo de volatilitatea curentă și de indicele bazat pe medie din acest capitol?
  - Pentru prognoză, ordinul VAR și numărul de factori se aleg doar pe un eșantion de antrenare

Anunță conectivitatea crizele sau doar urmează volatilitatea?

O întrebare de cercetare deschisă: risc sistemic sau doar volatilitate?

- Indicii de conectivitate sînt urmăriți ca instrumente de avertizare timpurie
  - Un indice construit dintr-un VAR pe volatilități poate evolua odată cu volatilitatea fără să adauge informație predictivă
  - Cercetare în curs: rețele din VAR-uri regularizate Demirer et al. (2018)
  - Conectivitatea în cozi diferă de cea la medie Ando, Greenwood-Nimmo & Shin (2022)
- Formularea statistică: $y_{t+h} = a + \beta_C C_t + \gamma \ln \sigma_t + e_{t+h}$, $H_0 : \beta_C = 0$, $H_1 : \beta_C > 0$
  - y_{t+h}: stresul viitor al băncilor
  - C_t: conectivitatea totală
  - σ_t: volatilitatea curentă
  - Dovezi împotriva lui H_1: intervalul de încredere (CI, confidence interval) pentru β_C exclude efectele relevante economic
  - Simpla lipsă a semnificației statistice nu este suficientă
- Identificarea: o muchie este o proporție din dispersia erorii de prognoză, nu o expunere cauzală
  - Un șoc comun crește simultan volatilitatea și conectivitatea, fără ca vreo bancă să o contamineze pe alta

Bucla descoperirii, pas cu pas

- **Literatura**: cartografiem ce se știe, apoi verificăm fiecare referință
  - Verificăm fiecare DOI (Digital Object Identifier) pe Crossref și ne asigurăm că articolul controlează efectiv pentru volatilitate
  - Căutăm cu Semantic Scholar, Elicit sau Google Scholar
- **Ipoteze**: interpretări concurente ale unei creșteri a conectivității, fiecare cu testul ei
  - De exemplu, un șoc comun dispare odată cu volatilitatea
  - Contagion, în schimb, are o direcție: șocurile transmițătorilor neți le preced pe ale receptorilor
- **Date și cod**: pe datele cursului, replicînd întîi o cifră cunoscută
  - Replicăm întîi media conectivității totale pe ferestre mobile, 62,0%, și maximul ei, 79,3% (2020-08-27), din acest capitol
- **Robustețea**, fixată înainte de a rula regresiile predictive
  - Fiecare celulă a grilei este raportată
  - Familia de teste este corectată cu Holm sau controlată prin FDR (false discovery rate, rata descoperirilor false)
- **Critica**: îi cerem asistentului să atace rezultatul
  - Răspuns așteptat: adăugăm volatilitatea curentă ca variabilă de control, apoi testăm creșterea lui R^2 și a pierderii în afara eșantionului
- **Raportul**: efecte standardizate cu statistici t HAC (heteroskedasticity and autocorrelation consistent, robuste la heteroscedasticitate și autocorelație), toate celulele grilei și ce a eșuat
  - Prompturile care au influențat planul analizei sînt consemnate în `AI_USE.md` (prompturi reutilizabile și verificările cercetătorului: ▸ Anexă)

Mini studiu de caz: conectivitatea dincolo de volatilitate

- Propunerea tipică a asistentului: „o conectivitate totală ridicată anunță stresul viitor al băncilor”
  - Testată pe 731 de observații săptămînale, între 2011 și 2026
  - y_{t+h}: logaritmul volatilității Parkinson medii a celor 13 bănci în următoarele $h = 63$ zile
  - Variabila de control: aceeași mărime în ultimele 20 de zile
  - Variabilele sînt standardizate, iar erorile standard Newey–West folosesc 13 laguri
- Conectivitatea singură: $\hat{\beta}_C = 0{,}40$ ($t = 4{,}63$), $R^2 = 0{,}16$: propunerea pare corectă
- Cu volatilitatea curentă: $\hat{\beta}_C = 0{,}08$ ($t = 0{,}75$), $\hat{\gamma} = 0{,}53$ ($t = 4{,}13$)
  - $R^2 = 0{,}343$, față de 0,339 doar cu volatilitatea
  - Corelația lui C_t cu volatilitatea: 0,59
  - Cu drawdown-ul maxim din următoarele 63 de zile ca variabilă dependentă: $\hat{\beta}_C = -0{,}10$ ($t = -1{,}32$), chiar cu conectivitatea ca unic regresor
- Interpretare: dată fiind volatilitatea curentă, conectivitatea nu adaugă conținut predictiv semnificativ
  - Nu dovedește că efectul este zero: în eșantionul nostru, persistența volatilității explică cea mai mare parte a conținutului predictiv
  - Informația de rețea poate conta totuși în cozi Ando, Greenwood-Nimmo & Shin (2022) sau pentru direcția transmiterii

Rîndul dumneavoastră: o idee de proiect

- **Întrebarea**
  - Prezice conectivitatea în **cozi** dificultățile băncilor dincolo de volatilitate, în afara eșantionului?
- **Replicați întîi**
  - Indicele nostru pe ferestre mobile: media 62,0% și maximul 79,3% (2020-08-27)
  - Tabelul de conectivitate cu șase grupuri din Demirer et al. (2018), pentru 2003–2014: intrările direcționale și totalurile pe linii/coloane, cu explicația abaterilor. Datele de replicare sînt publicate de autori (journaldata.zbw.eu)
- **Extindeți**
  - Conectivitatea cuantilă la $\tau = 5\%$ Ando, Greenwood-Nimmo & Shin (2022)
  - Evaluare în afara eșantionului începînd din 2018
  - MES și SRISK ca ținte alternative
- **Livrabile**
  - O grilă de specificații fixată în scris înainte de regresii
  - Un notebook care regenerează fiecare cifră
  - Inferență HAC și pierderi în afara eșantionului pentru fiecare celulă
- **Jurnalul AI** (șabloane)
  - `AI_USE.md`: prompturile care au influențat metodologia
  - `AI_ERRORS.md`: fiecare afirmație greșită (un VAR pe nivelurile prețurilor, statistici t OLS pe ferestre suprapuse) și testul care a depistat-o

Importanța sistemică a băncilor (1/2)

Banca	VaR 1%	MES 5%	ΔCoVaR 1%	Spillover net	Λ^*
JPMorgan	4,83	3,22	4,62	9,8	7,0
Bank of America	5,99	3,85	4,60	10,9	6,2
Citigroup	5,87	4,03	3,81	19,0	6,0
Goldman Sachs	4,81	3,34	4,12	2,4	6,8
Morgan Stanley	5,83	4,04	4,00	9,9	6,0
Wells Fargo	5,78	3,32	4,89	3,6	6,8
Deutsche Bank	7,19	4,54	4,24	−12,6	6,1
BNP Paribas	6,18	4,53	4,84	6,0	6,1
Santander	5,83	4,23	4,42	−5,4	6,4
ING	7,16	4,81	4,42	5,2	5,8
HSBC	4,66	2,54	4,07	−23,6	8,3
Banca Transilvania	5,06	3,14	–	−12,2	6,5
BRD-Groupe SG	4,42	2,69	–	−13,0	7,1

- VaR și MES sînt pierderi zilnice în %, iar spillover-ul net al volatilității este diferența „către ceilalți" minus „de la ceilalți"
- Λ^*: leverage-ul de echilibru cu $k = 8\%$ și LRMES aproximat (criză de șase luni, piața -40%)
- –: fără ΔCoVaR pentru cele două bănci românești, al căror „sistem" ar fi o singură bancă

Importanța sistemică a băncilor (2/2)

- Corelații de rang pe cele unsprezece bănci internaționale
  - MES și ΔCoVaR: $-0{,}01$
  - MES și spillover-ul net: $0{,}04$
  - ΔCoVaR și spillover-ul net: $-0{,}01$
  - VaR și MES: $0{,}88$
- Nu există un clasament unic
  - Supraveghetorii combină mai mulți indicatori cu mărimea și datele din bilanț, ca în metodologia Basel Committee (2018)
- Băncile românești
  - Au un MES moderat și sînt receptori neți de volatilitate
  - Au un leverage de echilibru apropiat de cel al băncilor americane

Idei principale

- Riscul sistemic se manifestă în coada distribuției comune
  - Expunere (MES, SRISK), contribuție (ΔCoVaR), conectivitate (rețele de spillover și rețele în coadă)
- Băncile europene: cele mai mari MES din eșantionul nostru
  - Băncile americane sînt principalii transmițători neți de volatilitate
- VaR și ΔCoVaR ordonează băncile diferit
  - Clasamentele sînt incerte: testați diferențele, raportați intervale, precizați αn
- Măsurile bazate pe piață urcă brusc în crize
  - Testele de stres și bilanțurile sînt necesare pentru a vedea acumularea riscului
- Băncile românești: mai ales șocurile proprii
  - Primesc mai mult spillover de volatilitate decît transmit

Greșeli frecvente

- Interpretarea ΔCoVaR ca efect cauzal: un șoc comun creează același tipar
- Interpretarea intervalelor suprapuse drept „egale" și a celor separate drept „diferite"
  - Testăm diferența pe extrageri comune și corectăm pentru numărul de perechi (Holm și testul Wald comun)
- Includerea băncii în portofoliul sistemului
  - Randamentul ei adaugă mecanic o autocontribuție la legătură
- Interpretarea unei muchii de spillover ca un canal cauzal: muchia este o proporție din dispersia erorii de prognoză, iar un șoc comun o produce la fel
- Descompuneri ortogonale ale dispersiei ale căror rezultate depind de ordinea băncilor
- Raportarea SRISK fără bilanțuri sau a aproximării $1 - e^{-18\mathrm{MES}}$ ca măsură publicată
- Desenarea etichetelor nete fără intervale

MES ca contribuție Euler: demonstrație

- Portofoliul $X_p = \sum_i w_i X_i$ are distribuție continuă, iar expected shortfall-ul lui este $\mathrm{ES}_\alpha(X_p) = -\mathbb{E}[X_p \mid X_p \leq q_\alpha(X_p)]$
  - ES_α este pozitiv omogen de gradul 1 în w, deci din teorema lui Euler $\mathrm{ES}_\alpha(X_p) = \sum_i w_i \, \partial \mathrm{ES}_\alpha / \partial w_i$
  - Derivînd $-\frac{1}{\alpha}\mathbb{E}[X_p 1\{X_p \leq q_\alpha(w)\}]$: folosind $\partial q_\alpha / \partial w_i = \mathbb{E}[X_i \mid X_p = q_\alpha]$, termenii de frontieră se anulează: $-\frac{1}{\alpha} q_\alpha f_p(q_\alpha) \, \partial q_\alpha / \partial w_i + \frac{1}{\alpha} q_\alpha f_p(q_\alpha) \, \partial q_\alpha / \partial w_i = 0$
  - Deci $\partial \mathrm{ES}_\alpha / \partial w_i = -\mathbb{E}[X_i \mid X_p \leq q_\alpha(X_p)] = \mathrm{MES}_{i,\alpha}$ cu $m = p$ Gouriéroux, Laurent & Scaillet (2000), Scaillet (2004)
- Verificare pe datele noastre: portofoliul cu ponderi egale al celor șase bănci americane, $\alpha = 5\%$ (198 de zile în coadă)
  - $\mathrm{ES}_{5\%}$ al portofoliului, 4,32%, este egal cu media celor șase MES condiționate pe portofoliu, 4,32%: identitatea este exactă și pentru estimatorul istoric
  - Condiționînd pe S&P 500 obținem un MES mediu de 3,63% (pentru JPMorgan: 3,22% condiționînd pe S&P 500, față de 3,85% condiționînd pe portofoliu): identitatea nu mai este valabilă cînd $m \neq p$
- Sub distribuția Normală bivariată cu medii zero, $\mathrm{MES}_{i,\alpha} = \beta_i \, \mathrm{ES}_\alpha(X_m)$: un beta înmulțit cu o constantă

înapoi

Simularea LRMES: inovații și recursii

- Reziduurile standardizate $\epsilon_{it} = r_{it}/\sigma_{it}$, $\epsilon_{mt} = r_{mt}/\sigma_{mt}$, iar S este matricea corelațiilor lor estimate din eșantion, ținta pe termen lung a lui Q_t
  - Inovația băncii ortogonală față de piață: $\xi_{it} = (\epsilon_{it} - \rho_t\,\epsilon_{mt})/\sqrt{1-\rho_t^2}$ Brownlees & Engle (2017)
- În fiecare zi simulată s: extragem aleator o dată istorică τ, luăm perechea $(\xi_{i\tau}, \epsilon_{m\tau})$ și reconstruim șocul băncii cu corelația **simulată**
  - $\epsilon_{i,t+s} = \rho_{t+s}\,\epsilon_{m\tau} + \sqrt{1-\rho_{t+s}^2}\,\xi_{i\tau}$, apoi actualizăm σ^2 și Q cu noile randamente
- Restricțiile asigură $\sigma_t^2 > 0$ și o matrice Q_t pozitiv definită
  - GJR–GARCH: $\omega > 0$, $\alpha \geq 0$, $\alpha + \gamma \geq 0$, $\beta \geq 0$, $\alpha + \gamma/2 + \beta < 1$
  - Ultima condiție dă dispersie finită pentru inovații simetrice (în general: $\alpha + \gamma\,\mathbb{E}[\epsilon^2 1\{\epsilon < 0\}] + \beta < 1$)
  - DCC: $a, b > 0$, $a + b < 1$
  - Inițializarea: $Q_1 = S$ la estimare
  - Simularea pornește de la σ^2_{T+1} și Q_{T+1} filtrate pînă la ultima dată

Înapoi

Regresia cuantilă: asimptotica

- Asimptotica pentru α fix, cu $\hat{\theta}_\alpha = (\hat{a}_\alpha, \hat{b}_\alpha)^\top$, n zile, $x_t = (1, X_{i,t})^\top$ și f_t densitatea condiționată a lui Y în cuantila de ordin α
  - $\sqrt{n}(\hat{\theta}_\alpha - \theta_\alpha) \Rightarrow N\left(0,\ \alpha(1-\alpha)\, \mathbf{D_1^{-1}} D_0 \mathbf{D_1^{-1}}\right)$, $D_0 = \mathbb{E}[x_t x_t^\top]$, $D_1 = \mathbb{E}[f_t\, x_t x_t^\top]$
  - Presupune observații independente (sau scoruri $x_t(\alpha - 1\{u_t < 0\})$ de tip diferență de martingal), $f_t > 0$ în jurul cuantilei și D_0, D_1 pozitiv definite
  - Cu scoruri dependente serial, D_0 cere o estimare de termen lung (HAC) sau un bootstrap pe blocuri
  - **Inversa densității** $1/f_t$ trebuie estimată (nucleu sau lățime de bandă)
  - La $\alpha = 1\%$ puține observații sînt aproape de cuantilă, deci această estimare este zgomotoasă
- Panta b_α se poate schimba cu α: banca poate conta mai mult pentru sistem în coadă decît în centru

Înapoi

Cuantile extreme: dificultatea estimării la $\alpha = 1\%$

- La $\alpha = 1\%$ rămîn în coadă doar $\alpha n = 40$ de zile
  - Aproximarea Normală de mai sus presupune că $\alpha n \to \infty$ rapid, iar cu αn de cîteva zeci poate fi imprecisă
  - Teoria cuantilelor extreme (limite de valori extreme, subeșantionare) este alternativa construită pentru acest caz Chernozhukov & Fernández-Val (2011)
- În datele noastre, eroarea standard bootstrap pe blocuri a ΔCoVaR 1% este de aproximativ 0,6 ori eroarea standard bazată pe nucleu (mediana pe bănci): cele două metode dau o incertitudine clar diferită
  - Eroarea standard cu nucleu se bazează pe o estimare a inversei densității din puținele observații din jurul cuantilei de 1%
  - Bootstrap-ul reextrage aceleași puține zile din coadă
  - Niciuna dintre metode nu este fiabilă cînd αn este atît de mic
- Regulă practică: raportăm $\alpha = 5\%$ și $\alpha = 1\%$ împreună cu αn
  - Ne așteptăm ca clasamentul de 1% să fie mai zgomotos
  - Corelația Spearman mică dintre clasamentele de 1% și 5% (0,10) poate reflecta zgomotul de estimare, diferențe reale între cele două niveluri din coadă sau ambele

Înapoi

Testarea ΔCoVaR: trei ipoteze

- (1) H_0 : $b_\alpha = 0$ (nicio contribuție)
  - Testele ipotezelor liniare între cuantile folosesc asimptotica comună a lui $(\hat{b}_\alpha, \hat{b}_{50\%})$ Koenker & Bassett (1982)
- (2) H_0 : $b_\alpha = b_{50\%}$ (legătura din coadă egală cu cea din centru)
  - Estimăm dispersia lui $\hat{b}_\alpha - \hat{b}_{50\%}$ din 999 de extrageri bootstrap pe blocuri mobile care păstrează perechile de zile împreună
- (3) H_0 : $\Delta\mathrm{CoVaR}_i = \Delta\mathrm{CoVaR}_j$ (contribuții egale)
  - $z_{ij} = (\widehat{\Delta\mathrm{CoVaR}}_i - \widehat{\Delta\mathrm{CoVaR}}_j)/\hat{\mathrm{se}}^*(\cdot)$ pentru fiecare pereche
  - Corecția Holm (1979) pe familia de perechi
  - Un test Wald comun al egalității tuturor contribuțiilor

Înapoi

Testarea ΔCoVaR 1%: rezultate

Banca	ΔCoVaR	$\hat{b}_{1\%}$	z	$\hat{b}_{50\%}$	$\hat{b}_{1\%} - \hat{b}_{50\%}$	p
JPMorgan	4,62	0,94	6,9	0,96	−0,02	0,66
Bank of America	4,60	0,76	6,5	0,78	−0,02	0,73
Citigroup	3,81	0,64	4,7	0,76	−0,11	0,00
Goldman Sachs	4,12	0,85	5,6	0,84	0,00	0,99
Morgan Stanley	4,00	0,68	4,5	0,73	−0,05	0,28
Wells Fargo	4,89	0,84	4,3	0,78	0,06	0,17
Deutsche Bank	4,24	0,59	4,1	0,60	−0,02	0,67
BNP Paribas	4,84	0,77	6,5	0,74	0,03	0,37
Santander	4,42	0,75	4,5	0,69	0,07	0,07
ING	4,42	0,61	4,4	0,71	−0,10	0,00
HSBC	4,07	0,87	4,0	0,86	0,01	0,96

- z: raportul t cu nucleu (sandviș) pentru $\hat{b}_{1\%}$, valid doar pentru scoruri independente serial
- p: testul bootstrap pentru $b_{1\%} = b_{50\%}$ (testele pe perechi și testele Wald comune sînt pe slide-ul principal)

înapoi

ΔCoVaR variabil în timp, cu variabile de stare

- Variabile de stare M_{t-1}: log VIX, randamentul indicelui regional și al sistemului, toate întîrziate cu o zi Adrian & Brunnermeier (2016)
  - $q_\alpha(X_{i,t} \mid M_{t-1}) = a_i + c_i^\top M_{t-1}$ la α și la 50% (a_i, c_i: termenul liber și coeficienții regresiei cuantile a băncii)
  - $q_\alpha(X_t^{sys} \mid X_{i,t}, M_{t-1}) = a + b\,X_{i,t} + c^\top M_{t-1}$
- Apoi $\Delta\mathrm{CoVaR}_{\alpha,t} = \hat{b}\left(\hat{q}_{50\%,t}(X_i) - \hat{q}_{\alpha,t}(X_i)\right)$
  - Variază odată cu VaR-ul condiționat al băncii, care depinde de VIX
- Panta $\hat{b}$ este constantă: variația în timp vine din stare, nu din legătură

Înapoi

Backtesting pentru CoVaR și MES

- Măsurile sistemice sînt măsuri de risc condiționate, deci au nevoie de **backtesting condiționat** Banulescu-Radu, Hurlin, Leymarie & Scaillet (2021)
  - Pentru $\mathrm{CoVaR}^{\leq}$: evenimentul $I_t = 1\{X_t^{sys} \leq -\mathrm{CoVaR}_t^{\leq},\ X_{i,t} \leq -\mathrm{VaR}_{i,t}\}$
  - Sub H_0, $P(I_t = 1) = \alpha^2$ dacă atît VaR-ul băncii, cît și cuantila condiționată sînt calibrate
  - Testele Kupiec și Christoffersen pe I_t (Capitolul 8), plus o verificare separată a ratei de depășire a VaR-ului băncii
  - Pentru MES: procesul cumulat al depășirilor comune din Banulescu-Radu, Hurlin, Leymarie & Scaillet (2021)
- Verificarea noastră în afara eșantionului: $\mathrm{CoVaR}^{\leq}_{5\%}$ istoric pe o fereastră în expansiune, începînd cu ziua 1 000, cu 2 960 de zile de prognoză pentru fiecare bancă
  - Numărul așteptat de evenimente comune: 7,4
  - Numărul observat: între 5 și 9 pentru cele unsprezece bănci (JPMorgan: 9)
  - Cel mai mic p Kupiec este 0,35: nicio respingere
  - Puterea este limitată: dacă rata comună reală ar fi dublul lui α^2, testul Kupiec de 5% ar respinge în 62% din eșantioanele de această lungime cu evenimente independente, deci chiar și o dublare este ratată aproximativ o dată din trei

Înapoi

Ipotezele VAR și numărul de laguri al indicelui pe ferestre mobile

- VAR(p) din De la perechi la rețele (1/2)
  - Ipoteze: VAR stabil (rădăcinile lui $\det(I - \sum_l A_l z^l)$ în afara cercului unitate), ε_t necorelate serial, cu Σ finită și pozitiv definită
  - Reprezentarea de tip medie mobilă: $y_t = \mu + \sum_{h \geq \mathbf{0}} \Phi_h \varepsilon_{t-h}$, $\Phi_{\mathbf{0}} = I$, $\Phi_h = \sum_{l=\mathbf{1}}^{p} A_l \Phi_{h-l}$ ($\Phi_h = 0$ pentru $h < 0$)
  - e_i: al i-lea vector unitar
- Numărul de laguri: în toate ferestrele păstrăm $p = 2$, ordinul ales de BIC pe întreaga perioadă
  - Pe ferestre, BIC alege $p = 1$ în 100% dintre cazuri, iar cu $p = 1$ indicele are corelația 0,99 cu cel prezentat

Înapoi

VAR-uri regularizate: elastic net

- Demirer et al. (2018): fiecare ecuație VAR prin elastic net adaptiv, λ ales ecuație cu ecuație prin validare încrucișată cu 10 grupe
  - $\hat{\beta} = \arg\min_\beta \sum_t \left(y_t - \sum_i \beta_i x_{it}\right)^2 + \lambda \sum_i w_i \left(\frac{1}{2}|\beta_i| + \frac{1}{2}\beta_i^2\right)$, $w_i = 1/|\hat{\beta}_{i,\mathrm{OLS}}|$
  - x_{it} sînt seriile întîrziate (regresorii), iar λ este intensitatea penalizării
  - w_i: ponderi adaptive, mai mari pentru coeficienții mici în OLS
  - Partea $|\beta_i|$ anulează coeficienți, iar partea β_i^2 îi micșorează
  - Ferestre mobile de 150 de zile cu elastic net simplu, $w_i = 1$
  - Orizontul de prognoză: $H = 10$
- Motivația: selecția coeficienților VAR și shrinkage, fără a impune o **rețea** rară (legăturile vin și prin Σ)
  - Pe întreaga perioadă păstrăm ordinul BIC al VAR-ului nostru OLS, $p = 2$
  - În comparația pe ferestre mobile de 150 de zile, atît OLS, cît și elastic net folosesc $p = 1$ (legenda graficului), ordinul ales de BIC în 100% dintre ferestrele mobile
- Cu aproximativ 4 000 de zile penalizarea aproape că nu contează (vezi C pe întreaga perioadă, în textul principal), dar contează în ferestrele scurte

Înapoi

Rețele de cauzalitate Granger și testarea multiplă

- Billio, Getmansky, Lo & Pelizzon (2012) desenează o muchie $j \to i$ cînd j cauzează în sens Granger variabila i la 5%, iar cu 13 bănci rezultă $13 \times 12 = 156$ de teste
  - Chiar fără nicio legătură, aproximativ 7,8 muchii ar apărea din întîmplare
- Testele noastre: regresii bivariate, un lag, statistici Wald robuste la heteroscedasticitate
  - Randamente zilnice: 57 de muchii semnificative la 5%, 33 după corecția Holm (1979), 55 cu rata descoperirilor false controlată la 5% Benjamini & Hochberg (1995)
  - Logaritmul volatilității, foarte persistent: adăugăm un lag suplimentar netestat Toda & Yamamoto (1995), ca în testele cu laguri suplimentare din Shi, Hurn & Phillips (2020)
  - Rezultă 153 de muchii la 5%, 150 după Holm și 153 cu rata descoperirilor false controlată la 5%
- Holm controlează probabilitatea oricărei muchii false pentru orice dependență
- FDR (false discovery rate) este proporția **așteptată** a muchiilor false printre cele desenate
- Procedura BH (Benjamini–Hochberg) o garantează pentru teste independente Benjamini & Hochberg (1995), dar testele pe perechi de bănci suprapuse sînt dependente
- Randamente zilnice ale unor bănci din fusuri orare diferite: multe muchii „cauzale” arată doar că New York se închide după Frankfurt

Înapoi

Exemplu rezolvat: test invers de stres cu doi factori

- Coeficienții beta: $b = (1{,}2;\ 0{,}8)$
  - Covariança pe patru săptămîni a factorilor: $h\Sigma = \begin{pmatrix} 16 & 6 \\ 6 & 9 \end{pmatrix}$ $(\%^2)$
  - Pierderea țintă: $\ell^* = 20\%$
  - $h\Sigma\, b = (1{,}2 \cdot 16 + 0{,}8 \cdot 6;\ 1{,}2 \cdot 6 + 0{,}8 \cdot 9) = (24;\ 14{,}4)$
  - $b^\top h\Sigma\, b = 1{,}2 \cdot 24 + 0{,}8 \cdot 14{,}4 = 40{,}32$, abaterea standard 6,35%
- Cel mai plauzibil scenariu și distanța lui
  - $f^* = -20 \cdot (24;\ 14{,}4)/40{,}32 = (-11{,}9\%;\ -7{,}1\%), \quad d^* = 20/6{,}35 = 3{,}15$
  - Probabilitatea, sub distribuția Normală, a unei pierderi cel puțin atît de mari: $\Phi(-3{,}15) = 0{,}08\%$ pe patru săptămîni
- Scenariul pune mai multă greutate pe factorul cu beta și dispersie mai mari, iar ambii factori scad împreună pentru că sînt corelați

Înapoi

Sectoare, factori și ordinul VAR

- Datele (Secțiunea 3): cele 17 sectoare financiare
  - Un sector financiar = media cu ponderi egale a CDS-urilor băncilor și asigurătorilor cu active de cel puțin 10 miliarde USD, 199 de instituții în total
- Factorii (Ec. (8), Figura 2)
  - Proporția perechilor de reziduuri cu $|\rho| < 0{,}25$: 91,6% cu factori, sub jumătate fără factori
- Ordinul VAR și orizontul (Secțiunile 2.2 și 4)
  - VAR(1), ales după BIC la medie și păstrat la fiecare cuantilă
  - Orizontul: $h = 5$ zile
  - Cuantila rămîne fixă pe orizontul de prognoză

Înapoi

Rezultate suplimentare

- Din cele 1 122 de spillover-uri bilaterale, 568 sînt sub 1% la medie și 829 la mediană (Figura 7)
  - Departe de medie, rețeaua are multe legături slabe, nu cîteva legături puternice
  - În cozi, aceste legături slabe se adună în spillover-uri medii puternice
- RTD în timp (Secțiunea 4.3, Figura 11)
  - RTD crește odată cu pierderile fondurilor Bear Stearns din 2007 și scade după programul american de salvare a băncilor și după introducerea dobînzilor negative de către BCE: un semnal de fragilitate pe care media îl ascunde

Înapoi

Specificația replicării și limitele precizate de autori

- Specificația pentru replicarea pe cele 13 bănci
  - Ordinul VAR după BIC și numărul factorilor după Ec. (8)
  - Orizontul $h = 5$, cuantilele $\tau \in \{0{,}05;\ 0{,}5;\ 0{,}95\}$ și media, ferestre de $w = 250$ de zile
  - Măsura urmărită: RTD
- Alte limite precizate de autori
  - 250 de zile sînt prea puține pentru a alege factorii în fiecare fereastră, deci numărul lor este fixat (Secțiunea 4.3, Anexa B a lucrării)
  - Ferestrele mai scurte lasă prea puține observații efective în cozi
  - Se măsoară doar spillover-ul direct al șocurilor idiosincratice, nu și propagarea prin factorii comuni (nota 2)
  - Grecia este exclusă din cauza unei întreruperi a seriei CDS (Secțiunea 3, Anexa A a lucrării)

Înapoi

Bucla descoperirii: prompturi reutilizabile

- **Literatura**: cartografiem ce se știe, apoi verificăm fiecare referință
  - ,,Ce articole testează dacă indicii de conectivitate prezic dificultățile băncilor în afara eșantionului, dincolo de volatilitate? Dă DOI-ul, eșantionul, orizontul și variabilele de control.''
- **Ipoteze**: interpretări concurente ale unei creșteri a conectivității, fiecare cu testul ei
  - ,,Dă interpretări concurente ale unei creșteri a conectivității totale (șoc comun, contagiune, artefact al ferestrelor mobile) și un test care le deosebește.''
- **Date și cod**: pe datele cursului, replicînd întîi o cifră cunoscută
  - ,,Estimează un VAR(2) pe logaritmul volatilităților Parkinson ale celor 13 bănci din datele cursului, pe ferestre de 250 de zile, și calculează conectivitatea totală generalizată cu H = 10.''
- **Robustețea**, fixată înainte de a rula regresiile predictive
  - ,,Preînregistrează: orizonturi de 21/63/126 de zile, controale pentru volatilitate și VIX, ferestre de 150/250/500 de zile, laguri HAC cel puțin cît suprapunerea, evaluare în afara eșantionului din 2018.''
- **Critica**: îi cerem asistentului să atace rezultatul
  - ,,Joacă rolul unui recenzent: este puterea predictivă a conectivității doar persistența volatilității? Ce regresie ar arăta asta?''

Înapoi

Verificările cercetătorului

- **Date nestaționare**: un VAR pe nivelurile prețurilor sau pe serii cu tendință produce conectivitate spurioasă
  - Test: teste de rădăcină unitară pe fiecare serie
  - Test: toate valorile proprii ale matricei companion a VAR-ului estimat trebuie să fie strict în interiorul cercului unitate, în fiecare fereastră
- **Ordinea**: descompunerile Cholesky se schimbă cu ordinea băncilor
  - Test: permutăm coloanele, iar tabelul generalizat nu trebuie să se schimbe
- **Look-ahead bias**: o fereastră etichetată cu prima ei dată sau un ordin ales pe întregul eșantion
  - Test: indicele de la t nu trebuie să se modifice cînd ștergem datele de după t
- **Suprapunerea**: indicii pe ferestre mobile și rezultatele viitoare se suprapun, deci statisticile t OLS sînt supraestimate
  - Test: laguri Newey–West cel puțin egale cu suprapunerea sau bootstrap pe blocuri
- **Dimensiunea**: 13 bănci și $p = 2$ dau 27 de coeficienți pe ecuație din 250 de zile, iar mai multe bănci cer regularizare Demirer et al. (2018)
  - Test: comparăm cu un VAR LASSO
  - Muchiile instabile semnalează zgomot de estimare, nu structură

Înapoi

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- Financial Risk Meter for Emerging Markets
- Dynamic Crypto Networks
- Network Centrality

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_18

înapoi

Acronime folosite în acest material (1/3)

- **AI**: Artificial Intelligence — *inteligență artificială*
- **BAC**: Bank of America Corporation (NYSE ticker) — *Bank of America Corporation (simbolul bursier NYSE)*
- **BCE**: Banca Centrală Europeană
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BH**: Benjamini–Hochberg (procedure) — *procedura Benjamini–Hochberg*
- **BIC**: Bayesian Information Criterion — *criteriul informațional bayesian*
- **BNP**: BNP Paribas SA (Euronext Paris ticker; Banque Nationale de Paris) — *BNP Paribas SA (simbolul bursier Euronext Paris)*
- **BVB**: Bursa de Valori București
- **CATFIN**: CATastrophic risk in the FINancial sector — *riscul catastrofal din sectorul financiar (indicele Allen, Bali și Tang)*
- **CDS**: Credit Default Swap — *swap pe riscul de credit (contract de asigurare împotriva neplății)*
- **CI**: Confidence Interval — *interval de încredere*
- **COVID-19**: COronaVIrus Disease 2019 — *boala provocată de coronavirus, 2019*
- **CV**: Cross-Validation — *validare încrucișată*
- **DBK**: Deutsche Bank AG (Xetra ticker) — *Deutsche Bank AG (simbolul bursier Xetra)*
- **DCC**: Dynamic Conditional Correlation — *corelație condiționată dinamică*
- **EBA**: European Banking Authority — *Autoritatea Bancară Europeană*
- **ECB**: European Central Bank — *Banca Centrală Europeană*
- **ES**: Expected Shortfall — *pierderea așteptată în coadă*
- **FDIC**: Federal Deposit Insurance Corporation — *instituția federală americană de garantare a depozitelor*

Acronime folosite în acest material (2/3)

- **FDR**: False Discovery Rate — *rata descoperirilor false*
- **FEVD**: Forecast Error Variance Decomposition — *descompunerea dispersiei erorii de prognoză*
- **FRM**: Financial Risk Meter — *indicatorul de risc financiar sistemic Financial Risk Meter*
- **GAAP**: Generally Accepted Accounting Principles (US) — *principiile contabile general acceptate în SUA*
- **GACV**: Generalized Approximate Cross-Validation — *validare încrucișată aproximativă generalizată*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GFC**: Global Financial Crisis — *criza financiară globală (2007–2009)*
- **GJR**: Glosten–Jagannathan–Runkle (asymmetric GARCH) — *GARCH asimetric Glosten–Jagannathan–Runkle*
- **GS**: The Goldman Sachs Group, Inc. (NYSE ticker) — *The Goldman Sachs Group, Inc. (simbolul bursier NYSE)*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HSBC**: HSBC Holdings plc (originally the Hongkong and Shanghai Banking Corporation) — *grupul bancar HSBC Holdings plc (inițial Hongkong and Shanghai Banking Corporation)*
- **IFRS**: International Financial Reporting Standards — *standardele internaționale de raportare financiară*
- **ING**: ING Groep (Internationale Nederlanden Groep) — *grupul bancar olandez ING*
- **JPM**: JPMorgan Chase & Co. (NYSE ticker) — *JPMorgan Chase & Co. (simbolul bursier NYSE)*
- **LASSO**: Least Absolute Shrinkage and Selection Operator — *regresie penalizată L1 cu selecția variabilelor*

Acronime folosite în acest material (3/3)

- **LRMES**: Long-Run Marginal Expected Shortfall — *pierderea marginală așteptată în coadă pe termen lung (într-o criză)*
- **MES**: Marginal Expected Shortfall — *pierderea marginală așteptată în coadă*
- **MS**: Morgan Stanley (NYSE ticker) — *Morgan Stanley (simbolul bursier NYSE)*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **QFVAR**: Quantile Factor Vector AutoRegression — *autoregresie vectorială cuantilă cu factori comuni*
- **QML**: Quasi-Maximum Likelihood — *cvasi-verosimilitate maximă*
- **RTD**: Relative Tail Dependence — *dependența relativă în cozi (coada adversă minus coada favorabilă)*
- **SG**: Société Générale — *grupul bancar francez Société Générale*
- **SRISK**: Systemic RISK (capital shortfall measure) — *deficitul de capital al unei bănci într-o criză sistemică*
- **SUA**: Statele Unite ale Americii
- **SVB**: Silicon Valley Bank — *banca americană Silicon Valley Bank (falimentată în martie 2023)*
- **TENET**: Tail-Event driven NETwork risk — *riscul de rețea determinat de evenimentele din coadă*
- **UE**: Uniunea Europeană
- **US**: United States — *Statele Unite ale Americii*
- **VAR**: Vector AutoRegression — *model vector autoregresiv*
- **VIX**: CBOE Volatility IndeX — *indicele de volatilitate CBOE*
- **WFC**: Wells Fargo & Company (NYSE ticker) — *Wells Fargo & Company (simbolul bursier NYSE)*

Bibliografie (1/5)

- Acharya, V.V., Engle, R., Richardson, M. (2012). Capital shortfall: a new approach to ranking and regulating systemic risks. *American Economic Review*, 102(3), 59–64.
- Acharya, V.V., Pedersen, L.H., Philippon, T., Richardson, M. (2017). Measuring systemic risk. *Review of Financial Studies*, 30(1), 2–47.
- Adrian, T., Brunnermeier, M.K. (2016). CoVaR. *American Economic Review*, 106(7), 1705–1741.
- Allen, L., Bali, T.G., Tang, Y. (2012). Does systemic risk in the financial sector predict future economic downturns?. *Review of Financial Studies*, 25(10), 3000–3036.
- Ando, T., Bai, J. (2020). Quantile co-movement in financial markets: a panel quantile model with unobserved heterogeneity. *Journal of the American Statistical Association*, 115(529), 266–279.
- Ando, T., Greenwood-Nimmo, M., Shin, Y. (2022). Quantile connectedness: modeling tail behavior in the topology of financial networks. *Management Science*, 68(4), 2401–2431.
- Banulescu-Radu, D., Hurlin, C., Leymarie, J., Scaillet, O. (2021). Backtesting marginal expected shortfall and related systemic risk measures. *Management Science*, 67(9), 5730–5754.
- Basel Committee on Banking Supervision (2018). Global systemically important banks: revised assessment methodology and the higher loss absorbency requirement. Bank for International Settlements.

Bibliografie (2/5)

- Belloni, A., Chernozhukov, V. (2011). ℓ_1-penalized quantile regression in high-dimensional sparse models. *Annals of Statistics*, 39(1), 82–130.
- Ben Amor, S., Althof, M., Härdle, W.K. (2022). Financial Risk Meter for emerging markets. *Research in International Business and Finance*, 60, 101594.
- Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- Benoit, S., Colliard, J.-E., Hurlin, C., Pérignon, C. (2017). Where the risks lie: a survey on systemic risk. *Review of Finance*, 21(1), 109–152.
- Billio, M., Getmansky, M., Lo, A.W., Pelizzon, L. (2012). Econometric measures of connectedness and systemic risk in the finance and insurance sectors. *Journal of Financial Economics*, 104(3), 535–559.
- Bolton, P., Després, M., Pereira da Silva, L.A., Samama, F., Svartzman, R. (2020). The green swan: central banking and financial stability in the age of climate change. Bank for International Settlements.
- Brownlees, C., Engle, R.F. (2017). SRISK: a conditional capital shortfall measure of systemic risk. *Review of Financial Studies*, 30(1), 48–79.
- Castro, C., Ferrari, S. (2014). Measuring and testing for the systemically important financial institutions. *Journal of Empirical Finance*, 25, 1–14.
- Chernozhukov, V., Fernández-Val, I. (2011). Inference for extremal conditional quantile models, with an application to market and birthweight risks. *Review of Economic Studies*, 78(2), 559–589.
- Danielsson, J., James, K.R., Valenzuela, M., Zer, I. (2016). Model risk of risk models. *Journal of Financial Stability*, 23, 79–91.
- Demirer, M., Diebold, F.X., Liu, L., Yilmaz, K. (2018). Estimating global bank network connectedness. *Journal of Applied Econometrics*, 33(1), 1–15.

Bibliografie (3/5)

- Diebold, F.X., Yilmaz, K. (2009). Measuring financial asset return and volatility spillovers, with application to global equity markets. *Economic Journal*, 119(534), 158–171.
- Diebold, F.X., Yilmaz, K. (2012). Better to give than to receive: predictive directional measurement of volatility spillovers. *International Journal of Forecasting*, 28(1), 57–66.
- Diebold, F.X., Yilmaz, K. (2014). On the network topology of variance decompositions: measuring the connectedness of financial firms. *Journal of Econometrics*, 182(1), 119–134.
- ECB Banking Supervision (2022). Banks must sharpen their focus on climate risk, ECB supervisory stress test shows. Press release, 8 July 2022.
- Engle, R. (2002). Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- Engle, R., Jondeau, E., Rockinger, M. (2015). Systemic risk in Europe. *Review of Finance*, 19(1), 145–190.
- FDIC (2023). FDIC creates a Deposit Insurance National Bank of Santa Clara to protect insured depositors of Silicon Valley Bank, Santa Clara, California. Press release, 10 March 2023.
- Federal Reserve Board (2023). Federal Reserve Board announces it will make available additional funding to eligible depository institutions. Press release, 12 March 2023.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, 5th ed. Springer.
- Giglio, S., Kelly, B., Pruitt, S. (2016). Systemic risk and the macroeconomy: an empirical evaluation. *Journal of Financial Economics*, 119(3), 457–471.
- Girardi, G., Ergün, A.T. (2013). Systemic risk measurement: multivariate GARCH estimation of CoVaR. *Journal of Banking & Finance*, 37(8), 3169–3180.

Bibliografie (4/5)

- Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- Gouriéroux, C., Laurent, J.P., Scaillet, O. (2000). Sensitivity analysis of values at risk. *Journal of Empirical Finance*, 7(3–4), 225–245.
- Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). Applied Quantitative Finance, 3rd ed. Springer.
- Härdle, W.K., Wang, W., Yu, L. (2016). TENET: Tail-Event driven NETwork risk. *Journal of Econometrics*, 192(2), 499–513.
- Hendricks, W., Koenker, R. (1992). Hierarchical spline models for conditional quantiles and the demand for electricity. *Journal of the American Statistical Association*, 87(417), 58–68.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- Koenker, R., Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50.
- Koenker, R., Bassett, G. (1982). Tests of linear hypotheses and ℓ_1 estimation. *Econometrica*, 50(6), 1577–1583.
- Koop, G., Pesaran, M.H., Potter, S.M. (1996). Impulse response analysis in nonlinear multivariate models. *Journal of Econometrics*, 74(1), 119–147.
- Mainik, G., Schaanning, E. (2014). On dependence consistency of CoVaR and some other systemic risk measures. *Statistics & Risk Modeling*, 31(1), 49–77.
- Mihoci, A., Althof, M., Chen, C.Y.-H., Härdle, W.K. (2020). FRM Financial Risk Meter. In *The Econometrics of Networks*, Advances in Econometrics 42, Emerald, 335–368.
- Nucera, F., Schwaab, B., Koopman, S.J., Lucas, A. (2016). The information in systemic risk rankings. *Journal of Empirical Finance*, 38, 461–475.

Bibliografie (5/5)

- Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *Journal of Business*, 53(1), 61–65.
- Pesaran, H.H., Shin, Y. (1998). Generalized impulse response analysis in linear multivariate models. *Economics Letters*, 58(1), 17–29.
- Ren, R., Althof, M., Härdle, W.K. (2025). Financial Risk Meter for cryptocurrencies and tail risk network-based portfolio construction. *Singapore Economic Review*, 70(4), 901–927.
- Ren, R., Lu, M., Li, Y., Härdle, W.K. (2022). Financial Risk Meter FRM based on expectiles. *Journal of Multivariate Analysis*, 189, 104881.
- Scaillet, O. (2004). Nonparametric estimation and sensitivity analysis of expected shortfall. *Mathematical Finance*, 14(1), 115–129.
- Shi, S., Hurn, S., Phillips, P.C.B. (2020). Causal change detection in possibly integrated systems: revisiting the money–income relationship. *Journal of Financial Econometrics*, 18(1), 158–180.
- Toda, H.Y., Yamamoto, T. (1995). Statistical inference in vector autoregressions with possibly integrated processes. *Journal of Econometrics*, 66(1–2), 225–250.
- Toma, F.-M., Dima, D.M., Grecu, R., Pele, D.T., Lessmann, S. (2026). Energy Financial Risk Meter: systemic risk in the EU energy sector. SSRN working paper.
- Wang, R., Althof, M., Härdle, W.K. (2023). A financial risk meter for China. *Emerging Markets Review*, 56, 101052.