



Modelarea piețelor financiare

Capitolul 18: Risc sistemic și rețele



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (intelență artificială)
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BNP: BNP Paribas SA (Euronext Paris ticker; Banque Nationale de Paris) (BNP Paribas SA (simbolul bursier Euronext Paris))
- BVB: Bursa de Valori București
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- ECB: European Central Bank (Banca Centrală Europeană)
- ES: Expected Shortfall (pierderea așteptată în coadă)
- FDIC: Federal Deposit Insurance Corporation (instituția federală americană de garantare a depozitelor)
- FDR: False Discovery Rate (rata descoperirilor false)
- FRM: Financial Risk Meter (indicatorul de risc financiar sistemic Financial Risk Meter)
- GAAP: Generally Accepted Accounting Principles (US) (principiile contabile general acceptate în SUA)
- GACV: Generalized Approximate Cross-Validation (validare încrucișată aproximativă generalizată)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HSBC: HSBC Holdings plc (originally the Hongkong and Shanghai Banking Corporation) (grupul bancar HSBC Holdings plc (inițial Hongkong and Shanghai Banking Corporation))
- IFRS: International Financial Reporting Standards (standardele internaționale de raportare financiară)
- ING: ING Groep (Internationale Nederlanden Groep) (grupul bancar olandez ING)
- LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- LRMEs: Long-Run Marginal Expected Shortfall (pierderea marginală așteptată în coadă pe termen lung (într-o criză))
- MES: Marginal Expected Shortfall (pierderea marginală așteptată în coadă)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- QML: Quasi-Maximum Likelihood (cvasi-verosimilitate maximă)
- SG: Société Générale (grupul bancar francez Société Générale)
- SRISK: Systemic RISK (capital shortfall measure) (deficitul de capital al unei bănci într-o criză sistemică)

Acronime folosite în acest material (2/2)

- **SUA:** Statele Unite ale Americii
- **SVB:** Silicon Valley Bank (banca americană Silicon Valley Bank (falimentată în martie 2023))
- **TENET:** Tail-Event driven NETwork risk (riscul de rețea determinat de evenimentele din coadă)
- **UE:** Uniunea Europeană
- **US:** United States (Statele Unite ale Americii)
- **VAR:** Vector AutoRegression (autoregresie vectorială)
- **VIX:** CBOE Volatility Index (indicele de volatilitate CBOE)

Cuprins

Motivație

Expunerea: MES și SRISK

Contribuția: CoVaR

Conectivitatea: rețele de transmitere

Rețele în coadă: Financial Risk Meter

Riscul climatic

Testarea la stres

AI pentru descoperire științifică

Rezumat

Bibliografie

Ce este riscul sistemic?

De la o bancă la sistem

- ▣ **Riscul sistemic:** riscul ca dificultățile uneia sau ale mai multor instituții să afecteze sistemul financiar în ansamblu și, prin el, economia reală
- ▣ Este o **externalitate**: o bancă nu plătește pierderile pe care falimentul ei le impune altora
- ▣ Capitolul 7 a măsurat riscul **unui** portofoliu; acest capitol măsoară riscul pe care o bancă îl **adaugă** sistemului sau îl **preia** de la el

Ce facem în acest capitol

- ▣ Măsurăm expunerea băncilor la prăbușirile pieței: MES și SRISK
- ▣ Măsurăm contribuția unei bănci la pierderile sistemului: CoVaR și ΔCoVaR
- ▣ Descriem rețeaua de transmitere a volatilității (Diebold–Yilmaz) și legăturile din coadă (Financial Risk Meter)
- ▣ Construim teste de stres: istorice, ipotetice și inverse; riscul climatic

Retrageri în masă: Northern Rock 2007 și Silicon Valley Bank 2023



Deponenți la coadă în fața unei sucursale Northern Rock, Brighton, 14 septembrie 2007

Foto: [Dominic Alves \(2007\)](#); CC BY 2.0; [Wikimedia](#)

[Commons](#)


- Northern Rock (2007): un creditor ipotecar britanic lovit de blocarea piețelor de finanțare după pierderile din creditele subprime americane; deponenții au stat la coadă pentru a-și retrage economiile
- SVB (2023): o retragere digitală; FDIC a preluat banca pe 10 martie [FDIC \(2023\)](#); după două zile toți deponenții SVB și Signature Bank au fost protejați, pe baza unui argument sistemic [Federal Reserve Board \(2023\)](#)
 - ▶ Secțiunea 7 măsoară pierderea unui portofoliu bancar în acea fereastră
- Canale de contagiune
 - ▶ Retrageri de finanțare: deponenții și creditorii se retrag din orice bancă ce pare asemănătoare
 - ▶ Expuneri comune și vânzări forțate: vânzarea forțată scade prețurile pentru toți deținătorii
 - ▶ Legături între contrapărți: pierderea unei bănci este activul alteia

Datele folosite în acest capitol

Grupul	Seriile	Indicele pieței
Bănci americane	JPMorgan, Bank of America, Citigroup, Goldman Sachs, Morgan Stanley, Wells Fargo	S&P 500
Bănci europene	Deutsche Bank, BNP Paribas, Santander, ING, HSBC	Euro Stoxx 50
Bănci românești	Banca Transilvania, BRD-Groupe Société Générale	BET
Volatilitate	indicele VIX (volatilitatea implicită a S&P 500)	

- Prețuri zilnice din ianuarie 2010 până la 18 septembrie 2026, ajustate pentru dividende și divizări; 3 960 zile de tranzacționare comune
- Prețurile sunt îmbinate întâi în zilele comune, apoi calculăm randamentele log zilnice $r_t = 100(\ln P_t - \ln P_{t-1})$, în %
- Băncile românești: fără zilele fără tranzacții; scenariile istorice de stres pentru băncile internaționale încep în 2007

Trei sisteme bancare, 2010–2026



- Portofolii cu ponderi egale ale băncilor din fiecare regiune, rebalansate zilnic; liniile verticale marchează episoadele folosite în acest capitol

Interpretarea celor trei sisteme bancare

- ▣ 100 investiți în ianuarie 2010 au devenit 791 în băncile americane, 384 în cele europene și 1233 în cele românești
 - ▶ Cea mai mare scădere de la vârf: SUA 51% (2011-11-23), Europa 61% (2020-04-21), România 47% (2012-06-06)
- ▣ Volatilitatea anualizată a portofoliilor: 29%, 30% și 23%, față de 18% (S&P 500), 21% (Euro Stoxx 50) și 18% (BET)
- ▣ Scăderile sunt **simultane**: criza din zona euro, COVID-19 și falimentele bancare din 2023 au lovit toate regiunile în aceleași săptămâni
- ▣ Băncile românești au și un șoc propriu: anunțul taxei bancare din decembrie 2018

Convenții și o hartă a măsurilor de risc sistemic

- Randamentul X , pierderea $L = -X$; nivelul α este o **probabilitate a cozii**: VaR 1%, CoVaR 1%, MES 5% (Capitolul 7)
 - ▶ $\text{VaR}_\alpha(X) = -q_\alpha(X)$, cu q_α cuantila de ordin α ; VaR, CoVaR și MES sunt numere pozitive atunci când sunt pierderi
- Randamentul **sistemului** X^{sys} : portofoliul cu ponderi egale al celorlalte bănci din aceeași regiune
- Trei familii de măsuri Billio, Getmansky, Lo & Pelizzon (2012)
 - ▶ **Expunere**: cât pierde banca atunci când piața sau sistemul se prăbușesc? MES, SRISK, CoVaR de expunere
 - ▶ **Contribuție**: cu cât stă mai rău sistemul atunci când banca este în dificultate? ΔCoVaR
 - ▶ **Conectivitate**: prin ce legături circulă șocurile? Rețele de transmitere, rețele în coadă
- Sinteză despre ce teorie stă în spatele fiecărei măsuri: Benoit, Colliard, Hurlin & Pérignon (2017); manuale: Franke, Härdle & Hafner (2019), Härdle, Chen & Overbeck (2017)

Recapitulare: motivație

- ▣ Riscul sistemic privește sistemul, nu banca singulară: el trăiește în coada comună a mai multor instituții
- ▣ Retragerile, expunerile comune, vânzările forțate și legăturile între contrapărți transformă un faliment în mai multe
- ▣ Portofoliile bancare scad împreună în crize și sunt mai volatile decât piața
- ▣ Avem nevoie de măsuri de expunere, contribuție și conectivitate, fiecare cu incertitudinea ei


Marginal Expected Shortfall

- **MES** (Marginal Expected Shortfall, pierderea marginală așteptată în coadă) a băncii i la nivelul α [Acharya, Pedersen, Philippon & Richardson \(2017\)](#)
 - ▶ $MES_{i,\alpha} = -\mathbb{E}[X_i \mid X_m \leq q_\alpha(X_m)]$
 - ▶ Pierdere medie a băncii în cele mai rele α din zilele pieței m
- De ce „marginală”: **dacă** variabila de condiționare este chiar portofoliul, $m = \sum_i w_i X_i$, atunci $ES_\alpha(X_m) = \sum_i w_i MES_{i,\alpha}$ (alocarea Euler, slide-ul următor)
 - ▶ Piețele noastre (S&P 500, Euro Stoxx 50, BET) **nu** sunt portofolii ale acestor 13 bănci: aici MES măsoară **expunerea**, nu o parte din ES al indicelui
- Estimarea istorică: media lui $-X_i$ în zilele cu $X_m \leq \hat{q}_\alpha(X_m)$; cu $\alpha = 5\%$ și 3 960 zile, aproximativ 200 de zile
- Piața m : S&P 500 pentru băncile americane, Euro Stoxx 50 pentru cele europene, BET pentru cele românești

MES ca contribuție Euler: demonstrație

- Portofoliul $X_p = \sum_i w_i X_i$ cu distribuție continuă; $ES_\alpha(X_p) = -\mathbb{E}[X_p \mid X_p \leq q_\alpha(X_p)]$
 - ▶ ES_α este pozitiv omogen de gradul 1 în w , deci din teorema lui Euler $ES_\alpha(X_p) = \sum_i w_i \partial ES_\alpha / \partial w_i$
 - ▶ Derivând $-\frac{1}{\alpha} \mathbb{E}[X_p \mathbf{1}\{X_p \leq q_\alpha(w)\}]$: termenul în $\partial q_\alpha / \partial w_i$ este $-\frac{1}{\alpha} q_\alpha f_p(q_\alpha) \partial q_\alpha / \partial w_i + \frac{1}{\alpha} q_\alpha f_p(q_\alpha) \partial q_\alpha / \partial w_i = 0$
 - ▶ Deci $\partial ES_\alpha / \partial w_i = -\mathbb{E}[X_i \mid X_p \leq q_\alpha(X_p)] = MES_{i,\alpha}$ cu $m = p$ [Gouriéroux, Laurent & Scaillet \(2000\)](#), [Scaillet \(2004\)](#)
- Verificare pe datele noastre: portofoliul cu ponderi egale al celor șase bănci americane, $\alpha = 5\%$ (198 zile în coadă)
 - ▶ $ES_{5\%}$ al portofoliului = 4,32% = media celor șase MES condiționate pe portofoliu (4,32%): exact, și pentru estimatorul istoric
 - ▶ Condiționând pe S&P 500 obținem un MES mediu de 3,63% (JPMorgan: 3,22% față de 3,85%): identitatea nu mai este valabilă când $m \neq p$
- Sub distribuția Normală bivariată $MES_{i,\alpha} = \beta_i ES_\alpha(X_m)$: un beta înmulțit cu o constantă (Seminarul 18, A3)

MES 5% pentru treisprezece bănci



- Pierdere zilnică medie a fiecărei bănci în cele mai rele 5% din zilele indicelui pieței ei, 2010–2026; intervale de 95% din bootstrap pe blocuri mobile (blocuri de 20 de zile)

Interpretarea MES

- ▣ Băncile americane: de la 3,22% (JPMorgan) la 4,04% (Morgan Stanley); cele europene până la 4,81% (ING)
 - ▶ În aceleași zile piața a pierdut în medie 2,72% (S&P 500) și 3,16% (Euro Stoxx 50): băncile pierd mai mult decât piața
- ▣ HSBC este excepția din Europa (2,54%, sub indice): listată la Londra, cu afaceri în Asia
- ▣ Banca Transilvania 3,14% și BRD 2,69% în zilele de prăbușire a BET; BET însuși a pierdut 2,70%
- ▣ Intervalele marginale care se suprapun nu sunt un test al egalității: diferențele dintre bănci cer un test pe perechi, pe extrageri bootstrap comune (Secțiunea 3)

De la MES la o criză: LRMES

- **LRMES** (Long-Run MES, MES pe termen lung): scăderea așteptată a capitalului de piață al băncii într-o criză, o scădere a pieței sub C în h zile
 - ▶ $\text{LRMES}_{i,t} = -\mathbb{E}_t [R_{i,t+1:t+h} \mid R_{m,t+1:t+h} < C]$, randamente aritmetice pe h zile
 - ▶ [Acharya, Engle & Richardson \(2012\)](#) (Secțiunea I): $C = -40\%$ în șase luni; [Brownlees & Engle \(2017\)](#) (Secțiunea 1.1): $C = -10\%$ în $h = 22$ de zile
- Aproximarea [Acharya, Engle & Richardson \(2012\)](#), Secțiunea I, pentru „versiunile modelului în care simularea nu este încă implementată”: $\text{LRMES}_i \approx 1 - \exp(-18 \times \text{MES}_i^{2\%})$
 - ▶ $\text{MES}_i^{2\%}$: pierderea zilnică medie a băncii în zilele în care piața scade cu peste 2% (în fracții zecimale); exemplu $\text{MES}^{2\%} = 3\%$ dă $1 - e^{-0,54} = 41,7\%$
 - ▶ 18 este o constantă de calibrare; Seminarul 18, A4 arată de unde vine
- Aproximarea pe băncile noastre: de la 37% (HSBC) la 58% (ING); JPMorgan 48%, Banca Transilvania 52%
 - ▶ Piața a scăzut cu peste 2% în 138 zile în SUA, 196 în zona euro și 111 la BVB


SRISK: deficitul de capital într-o criză

- O bancă trebuie să păstreze un capital de cel puțin o proporție k din cvasi-active (datoriile contabile D plus capitalul de piață W) [Brownlees & Engle \(2017\)](#), Secțiunea 1.1, Ec. (1)
 - ▶ $SRISK_i = k D_i - (1 - k)(1 - LRMES_i) W_i$, presupunând că datoriile nu sunt renegociate în criză
 - ▶ $k = 8\%$ pentru firmele americane [Brownlees & Engle \(2017\)](#); $k = 5,5\%$ pentru firmele europene, ale căror bilanțuri IFRS raportează active mai mari decât US GAAP [Engle, Jondeau & Rockinger \(2015\)](#)
- SRISK pozitiv = deficit; SRISK al sistemului este suma valorilor pozitive; [V-Lab, New York University Stern School of Business](#) îl publică pentru băncile mari, pe baza bilanțurilor lor
- Exemplu: $D = 900$, $W = 100$, $LRMES = 41,7\%$
 - ▶ $SRISK = 0,08 \times 900 - 0,92 \times (1 - 41,7\%) \times 100 = 72 - 53,6 = 18,4$
- SRISK combină o măsură de piață (LRMES) cu o măsură din bilanț (levierul)

SRISK pe unitatea de capital și levierul de echilibru

- ▣ Împărțim la W și scriem levierul cvasi-de piață $L = (D + W)/W$
 - ▶ $\frac{\text{SRISK}}{W} = k(L - 1) - (1 - k)(1 - \text{LRMES})$
- ▣ SRISK devine pozitiv când levierul depășește **levierul de echilibru**
 - ▶ $L^* = 1 + \frac{(1 - k)(1 - \text{LRMES})}{k}$
 - ▶ Exemplul de mai sus: $L^* = 7,7$, iar banca are $L = 10$: deficit
- ▣ Datele noastre conțin prețuri, nu bilanțuri: raportăm L^* din LRMES estimat și tratăm levierul ca pe o **ipoteză**
- ▣ Un LRMES mai mare scade L^* : banca își permite mai puține datorii înainte ca o criză să creeze un deficit

SRISK în funcție de levier



- Băncile cu LRMES maxim, median și minim; levierul de pe axa orizontală este presupus, nu observat; punctele marchează L^*

Interpretarea levierului de echilibru

- ▣ Cu $k = 8\%$: $L^* = 5,8$ pentru ING, 6,4 pentru Santander, 8,3 pentru HSBC
 - ▶ SUA: JPMorgan 7,0, Morgan Stanley 6,0; România: Banca Transilvania 6,5, BRD 7,1
- ▣ O bancă ale cărei datorii depășesc de aproximativ 5–7 ori capitalul ei de piață ar avea nevoie de capital nou într-o prăbușire a pieței cu 40%
- ▣ Cu $k = 5,5\%$ pragurile cresc (ING 8,2, HSBC 11,9): raportul prudențial este o alegere de politică, iar SRISK depinde de el
- ▣ Limite: LRMES este o extrapolare din date zilnice, iar capitalul de piață însuși scade într-o criză

LRMES ca în lucrarea publicată: GJR–GARCH, DCC și simulare

- Modelul [Brownlees & Engle \(2017\)](#), Secțiunea 1.2: randamente log cu medie zero ale băncii și pieței, volatilități GJR–GARCH(1,1) [Glosten, Jagannathan & Runkle \(1993\)](#) și o corelație DCC(1,1) [Engle \(2002\)](#), QML în doi pași
 - ▶ $\sigma_t^2 = \omega + (\alpha + \gamma 1\{r_{t-1} < 0\}) r_{t-1}^2 + \beta \sigma_{t-1}^2$, pentru bancă și pentru piață
 - ▶ $Q_t = (1 - a - b) S + a \epsilon_{t-1} \epsilon_{t-1}^\top + b Q_{t-1}$, $\rho_t = Q_{12,t} / \sqrt{Q_{11,t} Q_{22,t}}$
- Simularea (Anexa A): reeșantionăm perechi de inovații standardizate $(\xi_{it}, \epsilon_{mt})$, filtrăm h zile înainte, pornind de la σ^2 și ρ de azi, păstrăm traiectoriile cu $R_{m,t+1:t+h} < C$
 - ▶ LRMES = minus media randamentului băncii pe traiectoriile de criză; reeșantionarea perechilor păstrează dependența din coadă pe care distribuția Normală o ratează
- Rularea noastră: date până la 2026-09-18; 200 000 de traiectorii de 22 de zile pe piață ($C = -10\%$), 400 000 de traiectorii de 126 de zile ($C = -40\%$)
 - ▶ Probabilitatea crizei de 22 de zile azi: 1,3% (S&P 500), 4,3% (Euro Stoxx 50), 4,0% (BET); pe 31 martie 2020: 12%, 19%, 8%

LRMES prin simulare: treisprezece bănci


Banca	LRMES azi	interval 90%	LRMES 31.03.2020	ρ_T	L^*
JPMorgan	10,6	[-2, 25]	23,7	0,53	11,3
Bank of America	14,3	[-4, 35]	23,2	0,44	10,9
Citigroup	13,0	[-1, 28]	32,8	0,54	11,0
Goldman Sachs	16,5	[1, 34]	25,0	0,65	10,6
Morgan Stanley	16,3	[1, 32]	27,2	0,65	10,6
Wells Fargo	6,7	[-8, 24]	22,9	0,32	11,7
Deutsche Bank	14,4	[2, 28]	25,7	0,66	10,8
BNP Paribas	15,6	[2, 33]	28,5	0,68	10,7
Santander	16,6	[3, 34]	26,4	0,76	10,6
ING	12,5	[1, 27]	32,9	0,68	11,1
HSBC	8,3	[-2, 19]	10,9	0,58	11,5
Banca Transilvania	12,4	[-2, 34]	17,2	0,74	11,1
BRD-Groupe SG	11,4	[-2, 28]	15,8	0,64	11,2

- LRMES (%) pentru o scădere a pieței sub -10% în 22 de zile [Brownlees & Engle \(2017\)](#); intervalul de 90%: cuantilele de 5% și 95% ale pierderii băncii pe traiectoriile de criză; ρ_T : ultima corelație DCC; L^* cu $k = 8\%$

Interpretarea LRMES prin simulare

- LRMES este **condiționat**: se mișcă odată cu volatilitatea și corelația de azi
 - ▶ JPMorgan: 10,6% azi, 23,7% cu informația din 31 martie 2020; Deutsche Bank 14,4% și 25,7%
- Intervalul de 90% este larg: LRMES este o medie pe traiectoriile de criză, iar deficitul de capital într-o criză anume poate fi mult mai mare [Brownlees & Engle \(2017\)](#), Ec. (2)
- Intervalul reflectă doar scenariile de criză: incertitudinea parametrilor (estimările GJR și DCC) l-ar lărgi și mai mult
- Cu o criză de o lună și -10% , LRMES este aproximativ o treime din cifrele pentru șase luni și -40% din [Acharya, Engle & Richardson \(2012\)](#): scenariul, nu doar banca, stabilește nivelul

Riscul de model: LRMES în trei specificații



- Criză de șase luni, scădere a pieței cu 40% Acharya, Engle & Richardson (2012); aproximarea $1 - e^{-18\text{MES}^2\%}$ față de simularea din GJR-GARCH + DCC cu inovații reșantionate sau Normale, date până la 2026-09-18

Interpretarea riscului de model pentru LRMES

- LRMES simulat împărțit la aproximare: între 0,42 și 0,90 pentru cele 13 bănci; corelația de rang 0,77
 - ▶ JPMorgan: 48% (aproximare), 33% (reeșantionare), 33% (Normal); ING: 58%, 41%, 41%
- Aproximarea folosește întreaga istorie 2010–2026; simularea pornește de la volatilitatea și corelația de azi
 - ▶ O scădere de 40% în șase luni este rară azi: probabilitate 0,29% (S&P 500), 0,96% (Euro Stoxx 50), 0,30% (BET) în model
- Inovații reeșantionate față de Normale: corelația de rang 0,95; distribuția inovațiilor schimbă nivelurile mai mult decât clasamentele
- Aceleași bănci, aceleași date, modele diferite și apărabile, cifre diferite: „riscul de model al modelelor de risc” [Danielsson, James, Valenzuela & Zer \(2016\)](#)

Recapitulare: MES și SRISK

- ▣ MES este pierderea medie a băncii în cele mai rele zile ale pieței; însumate, dau ES al pieței
- ▣ LRMES extrapolează MES la o criză de șase luni; SRISK îl transformă în deficit de capital
- ▣ Băncile europene au cele mai mari MES din eșantionul nostru; clasamentele pe bănci și regiuni au intervale largi
- ▣ În forma publicată, LRMES se simulează din GJR–GARCH + DCC; aproximarea $1 - e^{-18\text{MES}}$ diferă de la o bancă la alta, iar scenariul (h , C) stabilește nivelul
- ▣ SRISK are nevoie de date din bilanț; fără ele putem raporta doar levierul de echilibru

CoVaR: VaR al sistemului când o bancă este în dificultate

- ▣ **CoVaR** al sistemului condiționat de banca i aflată la nivelul VaR-ului ei [Adrian & Brunnermeier \(2016\)](#)
 - ▶ $P\left(X^{sys} \leq -\text{CoVaR}_{\alpha}^{sys|i} \mid X_i = -\text{VaR}_{i,\alpha}\right) = \alpha$
 - ▶ Pierderea sistemului depășită cu probabilitatea α într-o zi în care banca i se află la propriul VaR
- ▣ **ΔCoVaR** : diferența dintre starea mediană a băncii și starea ei de dificultate
 - ▶ $\Delta\text{CoVaR}_{\alpha}^{sys|i} = \text{CoVaR}_{\alpha}^{sys|X_i=q_{\alpha}} - \text{CoVaR}_{\alpha}^{sys|X_i=q_{50\%}}$
- ▣ **ΔCoVaR** măsoară **contribuția** băncii i la riscul din coadă al sistemului
- ▣ Inversând rolurile obținem **CoVaR de expunere**: VaR al băncii i atunci când sistemul este în dificultate

Regresia cuantilă

- Cuantila de ordin α a lui Y dat x este liniară: $q_\alpha(Y | x) = a_\alpha + b_\alpha x$ Koenker & Bassett (1978)
 - ▶ $(\hat{a}_\alpha, \hat{b}_\alpha) = \arg \min_{a,b} \sum_t \rho_\alpha(y_t - a - bx_t)$, $\rho_\alpha(u) = u(\alpha - 1\{u < 0\})$
 - ▶ ρ_α este **funcția de verificare**: ponderează reziduurile negative cu $1 - \alpha$ și pe cele pozitive cu α ; $\alpha = 50\%$ dă regresia medianei
- Asimptotica pentru α fix, cu $x_t = (1, X_{i,t})^\top$ și f_t densitatea condiționată a lui Y în cuantila de ordin α
 - ▶ $\sqrt{n}(\hat{\theta}_\alpha - \theta_\alpha) \Rightarrow N\left(0, \alpha(1 - \alpha) D_1^{-1} D_0 D_1^{-1}\right)$, $D_0 = \mathbb{E}[x_t x_t^\top]$, $D_1 = \mathbb{E}[f_t x_t x_t^\top]$
 - ▶ **Rarefierea** $1/f_t$ trebuie estimată (nucleu sau lățime de bandă); la $\alpha = 1\%$ puține observații sunt aproape de cuantilă, deci această estimare este zgomotoasă
- Panta b_α se poate schimba cu α : banca poate conta mai mult pentru sistem în coadă decât în centru; metoda celor mai mici pătrate dă doar panta pentru medie


Estimarea CoVaR în trei pași

- ▣ 1. Regresia cuantilă a sistemului pe bancă la nivelul α
 - ▶ $\hat{q}_\alpha(X^{sys} | X_i) = \hat{a}_\alpha + \hat{b}_\alpha X_i$
- ▣ 2. Introducem cuantilele băncii: $\hat{q}_\alpha(X_i)$ (dificultate) și $\hat{q}_{50\%}(X_i)$ (mediana)
 - ▶ $\text{CoVaR}_\alpha^{sys|i} = - \left(\hat{a}_\alpha + \hat{b}_\alpha \hat{q}_\alpha(X_i) \right)$
- ▣ 3. Facem diferența
 - ▶ $\Delta \text{CoVaR}_\alpha^{sys|i} = \hat{b}_\alpha (\hat{q}_{50\%}(X_i) - \hat{q}_\alpha(X_i))$
 - ▶ Contează doar panta: termenul liber se simplifică
- ▣ Incertitudinea: bootstrap pe blocuri mobile de zile (blocurile de 20 de zile păstrează grupările de volatilitate), 999 de reeșantionări

Dificultate la sau sub VaR: CoVaR Girardi–Ergün

- Girardi & Ergün (2013) condiționează pe banca aflată cel mult la VaR-ul ei, nu exact la el
 - ▶ $P\left(X^{sys} \leq -\text{CoVaR}_{\alpha}^{\leq} \mid X_i \leq -\text{VaR}_{i,\alpha}\right) = \alpha \iff P\left(X^{sys} \leq -\text{CoVaR}_{\alpha}^{\leq}, X_i \leq -\text{VaR}_{i,\alpha}\right) = \alpha^2$
 - ▶ Starea de referință: un eveniment de o abatere standard $|X_i - \mu_i| \leq \sigma_i$ în locul medianei
- De ce contează
 - ▶ Include dificultăți mai severe decât ziua de VaR însăși și este monoton în parametrul de dependență
 - ▶ Poate fi verificat ex post: evenimentul comun $\{X^{sys} \leq -\text{CoVaR}^{\leq}, X_i \leq -\text{VaR}_i\}$ are probabilitatea α^2
- Estimarea istorică la $\alpha = 5\%$: cuantila de 5% a sistemului în cele 198 zile cu $X_i \leq \hat{q}_{5\%}(X_i)$
 - ▶ JPMorgan: $\text{CoVaR}_{5\%}^{\leq} = 7,70\%$ față de $\text{CoVaR}_{5\%} = 3,81\%$ din regresia cuantilă; unsprezece bănci: 7,3–8,2% față de 3,6–4,8%
 - ▶ Aproximativ de două ori mai mare: media pe întreaga coadă a băncii este un eveniment de condiționare mai sever (Seminarul 18, A2 derivă acest rezultat sub distribuția Normală)

Regresia cuantilă: JPMorgan și celelalte bănci americane




- Randamente zilnice 2010–2026 cu dreptele de regresie cuantilă de 1% și 50%; linia punctată marchează JPMorgan la VaR 1%

Interpretarea exemplului JPMorgan

- Dreapta de 1%: $\hat{q}_{1\%} = -2,10 + 0,94 X_i$; dreapta medianei: $-0,03 + 0,96 X_i$
 - ▶ Pante asemănătoare: dreapta de 1% este coborâtă de coada celorlalte bănci, nu este mai abruptă
- VaR 1% al JPMorgan este 4,83%; într-o astfel de zi, celelalte bănci americane au CoVaR 1% = 6,64%
 - ▶ VaR 1% necondiționat al sistemului: 5,07%; cu JPMorgan la mediană: 2,03%
- $\Delta\text{CoVaR}_{1\%} = 4,62\%$: JPMorgan în dificultate adaugă aproximativ 4,62 puncte procentuale la pierderea de 1% a celorlalte bănci americane
- Aceasta este o asociere, nu o cauzalitate: un șoc comun lovește JPMorgan și pe celelalte bănci în aceeași zi

$\Delta\text{CoVaR } 1\%$ pentru unsprezece bănci



- Sistemul: portofoliul cu ponderi egale al celorlalte bănci din aceeași regiune; intervale bootstrap de 95% pe blocuri mobile

Interpretarea ΔCoVaR

- Toate cele unsprezece bănci se află între 3,81% (Citigroup) și 4,89% (Wells Fargo); intervalele de 95% au o lățime de 1,5–2,4 puncte
 - ▶ De ex. Citigroup [3,23, 4,74], Wells Fargo [3,68, 5,71]: intervalele marginale se suprapun
- Suprapunerea **nu** este un test: două estimări calculate pe aceleași zile sunt corelate pozitiv, deci diferența poate fi mai precisă decât fiecare interval
 - ▶ Următoarele două slide-uri testează diferențele pe extrageri bootstrap comune
- La $\alpha = 5\%$ valorile sunt mai mici (JPMorgan 2,62%), iar clasamentul se schimbă: corelația Spearman dintre clasamentele de 1% și 5% este 0,10
 - ▶ Un clasament care se schimbă cu α nu este o bază robustă pentru reglementare

Testarea ΔCoVaR : trei ipoteze

- (1) Nicio contribuție, $H_0: b_\alpha = 0$: test Wald cu dispersia de tip sandviș de pe slide-urile anterioare [Koenker & Bassett \(1978\)](#)
 - ▶ Testele ipotezelor liniare între cuantile folosesc asimptotica comună a lui $(\hat{b}_\alpha, \hat{b}_{50\%})$ [Koenker & Bassett \(1982\)](#)
- (2) Legătura din coadă este egală cu cea din centru, $H_0: b_\alpha = b_{50\%}$: este banca specială în crize?
 - ▶ Estimăm dispersia lui $\hat{b}_\alpha - \hat{b}_{50\%}$ din 999 de extrageri bootstrap pe blocuri mobile care păstrează perechile de zile împreună
- (3) Contribuții egale, $H_0: \Delta\text{CoVaR}_i = \Delta\text{CoVaR}_j$: aceleași zile reeșantionate pentru **toate** băncile dau distribuția comună
 - ▶ $z_{ij} = (\widehat{\Delta\text{CoVaR}}_i - \widehat{\Delta\text{CoVaR}}_j) / \widehat{\text{se}}^*(\cdot)$ pentru fiecare pereche; corecția Holm pe familia de perechi [Holm \(1979\)](#); un test Wald comun că toate sunt egale
 - ▶ Teste de semnificație și de dominanță pentru importanța sistemică: [Castro & Ferrari \(2014\)](#)

Testarea ΔCoVaR 1%: rezultate


Banca	ΔCoVaR	$\hat{b}_{1\%}$	z	$\hat{b}_{50\%}$	$\hat{b}_{1\%} - \hat{b}_{50\%}$	p
JPMorgan	4,62	0,94	6,9	0,96	-0,02	0,66
Bank of America	4,60	0,76	6,5	0,78	-0,02	0,73
Citigroup	3,81	0,64	4,7	0,76	-0,11	0,00
Goldman Sachs	4,12	0,85	5,6	0,84	0,00	0,99
Morgan Stanley	4,00	0,68	4,5	0,73	-0,05	0,28
Wells Fargo	4,89	0,84	4,3	0,78	0,06	0,17
Deutsche Bank	4,24	0,59	4,1	0,60	-0,02	0,67
BNP Paribas	4,84	0,77	6,5	0,74	0,03	0,37
Santander	4,42	0,75	4,5	0,69	0,07	0,07
ING	4,42	0,61	4,4	0,71	-0,10	0,00
HSBC	4,07	0,87	4,0	0,86	0,01	0,96

- z : raportul t cu nucleu (sandviș) pentru $\hat{b}_{1\%}$: fiecare bancă contribuie; p : testul bootstrap pentru $b_{1\%} = b_{50\%}$, semnificativ pentru 2 din 11 bănci (2 după Holm)
- Contribuții egale în fiecare regiune: 4 din 25 perechi diferă la 5%, 0 după Holm; testul Wald comun $p = 0,01$ (SUA), 0,31 (Europa)
 - La 5%: 3 din 25 perechi diferă, 0 după Holm; testul Wald comun $p = 0,014$ (SUA), 0,046 (Europa)

Cuantile extreme: de ce $\alpha = 1\%$ este dificil

- Eșantionul efectiv din coadă este αn : 40 de zile la 1% și 198 la 5% din 3 960
 - ▶ Aproximarea Normală de mai sus presupune că $\alpha n \rightarrow \infty$ rapid; cu αn de câteva zeci, teoria cuantilelor extreme (limite de valori extreme, subeșantionare) este calea validă [Chernozhukov & Fernández-Val \(2011\)](#)
- În datele noastre, eroarea standard bootstrap pe blocuri a $\Delta\text{CoVaR } 1\%$ este de aproximativ 0,6 ori eroarea standard bazată pe nucleu (mediana pe bănci): cele două căi diferă mult
 - ▶ Eroarea standard cu nucleu se bazează pe o estimare a rarefierii din puținele observații din jurul cuantilei de 1%; bootstrap-ul reextrage aceleași puține zile din coadă: niciuna nu este fiabilă când αn este atât de mic
- Regulă practică: raportăm $\alpha = 5\%$ și $\alpha = 1\%$ împreună cu αn ; ne așteptăm ca clasamentul de 1% să fie zgomotos
 - ▶ Corelația Spearman mică dintre clasamentele de 1% și 5% (0,10) este exact ce produce un zgomot de estimare de această mărime

VaR și ΔCoVaR măsoară lucruri diferite



□ Orizontal: VaR 1% al băncii; vertical: ΔCoVaR 1% al ei, unsprezece bănci, 2010–2026


Interpretarea VaR față de ΔCoVaR

- Corelația de rang Spearman dintre VaR și ΔCoVaR : 0,16
 - ▶ Deutsche Bank și ING au cele mai mari VaR (7,19%, 7,16%), dar doar un ΔCoVaR mediu
 - ▶ JPMorgan are unul dintre cele mai mici VaR (4,83%) și unul dintre cele mai mari ΔCoVaR
- Acesta este mesajul central al lucrării [Adrian & Brunnermeier \(2016\)](#): reglementarea fiecărei bănci după propriul VaR ignoră contribuția ei la sistem
- Atenție: cu unsprezece bănci și intervale suprapuse, corelația însăși este foarte incertă (Seminarul 18, B2)

Δ CoVaR variabil în timp, cu variabile de stare

- Variabile de stare M_{t-1} : log VIX, randamentul indicelui regional și al sistemului, toate întârziate cu o zi [Adrian & Brunnermeier \(2016\)](#)
 - ▶ $q_{\alpha}(X_{i,t} \mid M_{t-1}) = a_i + c_i^{\top} M_{t-1}$ la α și la 50%
 - ▶ $q_{\alpha}(X_t^{sys} \mid X_{i,t}, M_{t-1}) = a + b X_{i,t} + c^{\top} M_{t-1}$
- Apoi $\Delta\text{CoVaR}_{\alpha,t} = \hat{b} (\hat{q}_{50\%,t}(X_i) - \hat{q}_{\alpha,t}(X_i))$
 - ▶ Se mișcă odată cu VaR-ul condiționat al băncii, care se mișcă odată cu VIX
- Panta $\hat{b}$ este constantă: variația în timp vine din stare, nu din legătură

$\Delta\text{CoVaR 1\%}$ în timp




- Șase bănci, medii mobile pe 21 de zile ale $\Delta\text{CoVaR 1\%}$ zilnic estimat cu variabile de stare întârziate

Interpretarea ΔCoVaR în timp

- ▣ JPMorgan: în medie 2,16% în 2017, 9,06% în martie 2020; vârf de 10,99% pe 2020-03-18
 - ▶ Deutsche Bank: 2,04% în 2017 și 6,65% în martie 2020
- ▣ Cele șase linii se mișcă împreună: variabilele de stare comune le conduc
- ▣ ΔCoVaR bazat pe piață este mic în perioadele calme, exact atunci când riscul se poate acumula în bilanțuri, pe care datele de piață nu le văd
- ▣ De aceea [Adrian & Brunnermeier \(2016\)](#) propun un ΔCoVaR anticipat, prognozat din levier, mărime și nepotrivirea scadențelor

Contribuție față de expunere



- Albastru: $\Delta\text{CoVaR 1\%}$ (pierderea sistemului când banca este în dificultate); portocaliu: ΔCoVaR de expunere 1% (pierderea băncii când sistemul este în dificultate)

Interpretarea contribuției față de expunere

- Direcția contează: cele două numere diferă pentru majoritatea băncilor
 - ▶ ING: contribuție 4,42%, expunere 6,14%; BNP Paribas: 4,84% și 6,07%
 - ▶ HSBC: contribuție 4,07%, expunere doar 3,17%
- Expunerea este mai mare decât contribuția pentru majoritatea băncilor europene: ele suferă mai mult de pe urma unei crize a sistemului decât o provoacă
- Expunerea contează pentru capitalul băncii; contribuția contează pentru autoritatea care reglementează sistemul

Verificarea ex post a CoVaR și MES

- Măsurile sistemice sunt măsuri de risc condiționate, deci au nevoie de verificări ex post **condiționate** Banulescu-Radu, Hurlin, Leymarie & Scaillet (2021)
 - ▶ Pentru $\text{CoVaR}^{\leq}$: evenimentul $I_t = 1\{X_t^{\text{sys}} \leq -\text{CoVaR}_t^{\leq}, X_{i,t} \leq -\text{VaR}_{i,t}\}$ cu $P(I_t = 1) = \alpha^2$ sub H_0 ; testele Kupiec și Christoffersen pe I_t (Capitolul 8)
 - ▶ Pentru MES: procesul cumulat al depășirilor comune din Banulescu-Radu, Hurlin, Leymarie & Scaillet (2021)
- Verificarea noastră în afara eșantionului: $\text{CoVaR}_{5\%}^{\leq}$ istoric pe o fereastră extinsă de la ziua 1 000, 2 960 zile de prognoză pentru fiecare bancă
 - ▶ Evenimente comune așteptate 7,4; observate 5–9 pentru cele unsprezece bănci (JPMorgan 9); cel mai mic p Kupiec = 0,35: nicio respingere
 - ▶ Puterea este limitată: dacă rata comună reală ar fi dublul lui α^2 , testul Kupiec de 5% ar respinge în 62% din eșantioanele de această lungime, deci chiar și o dublare este ratată aproximativ o dată din trei

Cât de mult ne putem baza pe un clasament?

- Clasamentele băncilor după măsuri sistemice diferite nu coincid, iar fiecare clasament are o incertitudine de eşantionare mare [Nucera, Schwaab, Koopman & Lucas \(2016\)](#)
 - ▶ Ei propun combinarea măsurilor și raportarea incertitudinii clasamentului în locul unei ordini unice
- Riscul de model: măsura de risc a aceleiași bănci variază mult de la o metodă de estimare la alta [Danielsson, James, Valenzuela & Zer \(2016\)](#)
 - ▶ În acest capitol: aproximarea LRMES față de simulare (raport 0,42–0,90), CoVaR din regresia cuantilă față de Girardi–Ergün (aproximativ $\times 2$), $\alpha = 1\%$ față de 5% (Spearman 0,10)
- Ce rezistă: diferențele mari și testate (regiunile; panta din coadă a unor bănci), nu ordinea a unsprezece estimări punctuale apropiate

Recapitulare: CoVaR

- ▣ CoVaR este VaR al sistemului când o bancă este în dificultate; ΔCoVaR este contribuția băncii
- ▣ Se estimează prin regresie cuantilă; contează doar panta din coadă $\hat{b}_\alpha$ și cuantilele băncii
- ▣ VaR și ΔCoVaR ordonează băncile diferit; diferențele dintre bănci se testează pe extrageri comune, cu corecție pentru testele multiple
- ▣ Cu variabile de stare, ΔCoVaR urmează volatilitatea pieței: crește în crize și scade puțin în perioadele calme

De la perechi la rețele

- ▣ CoVaR privește o bancă și un sistem; o **rețea** privește toate perechile deodată
 - ▶ Noduri: băncile; muchii orientate: cât din incertitudinea viitoare a băncii i vine din șocurile băncii j
- ▣ Rețele de cauzalitate Granger între bănci, asigurători, fonduri speculative și brokeri Billio, Getmansky, Lo & Pelizzon (2012)
- ▣ Rețele din descompunerea dispersiei Diebold & Yilmaz (2009), Diebold & Yilmaz (2012), Diebold & Yilmaz (2014): abordarea din această secțiune
- ▣ Rețele în coadă din regresii cuantile: TENET Härdle, Wang & Yu (2016)

Descompunerea dispersiei erorii de prognoză

- Autoregresie vectorială (VAR, vector autoregression) de ordin p pentru N serii y_t : $y_t = c + \sum_{l=1}^p A_l y_{t-l} + \varepsilon_t$, $\text{Cov}(\varepsilon_t) = \Sigma$
 - Forma medie mobilă: $y_t = \mu + \sum_{h \geq 0} \Phi_h \varepsilon_{t-h}$, $\Phi_0 = I$, $\Phi_h = \sum_{l=1}^p A_l \Phi_{h-l}$
- Eroarea de prognoză pe H zile a lui y_i este o sumă de șocuri ale tuturor seriilor: dispersia ei se poate împărți pe surse
- Șocurile ortogonale (Cholesky) depind de ordinea seriilor; descompunerea **generalizată** nu depinde [Koop, Pesaran & Potter \(1996\)](#), [Pesaran & Shin \(1998\)](#)
 - $\theta_{ij}(H) = \frac{\sigma_{jj}^{-1} \sum_{h=0}^{H-1} (e_i^\top \Phi_h \Sigma e_j)^2}{\sum_{h=0}^{H-1} e_i^\top \Phi_h \Sigma \Phi_h^\top e_i}$, normalizat: $\tilde{\theta}_{ij} = \theta_{ij} / \sum_j \theta_{ij}$


Tabelul conectivității

- $\tilde{\theta}_{ij}$ (în %): proporția din dispersia erorii de prognoză pe H zile a lui i datorată șocurilor lui j ; fiecare linie însumează 100 Diebold & Yilmaz (2014)
 - ▶ De la ceilalți: $F_i = \sum_{j \neq i} \tilde{\theta}_{ij}$; către ceilalți: $T_j = \sum_{i \neq j} \tilde{\theta}_{ij}$
 - ▶ Net: $T_i - F_i$ (pozitiv = transmițător net); net pe perechi: $\tilde{\theta}_{ji} - \tilde{\theta}_{ij}$
- Conectivitatea totală: $C = \frac{1}{N} \sum_{i \neq j} \tilde{\theta}_{ij}$, proporția medie din dispersie care vine de la ceilalți
 - ▶ Liniile lui θ_{ij} nu însumează unu înainte de normalizare, deoarece șocurile generalizate sunt corelate (Seminarul 18, A5 derivă acest lucru)
 - ▶ Legăturile nete pe perechi $\tilde{\theta}_{ji} - \tilde{\theta}_{ij} > 0$ desenează o săgeată $j \rightarrow i$: rețeaua din slide-urile următoare

Ce conectăm: volatilitatea zilnică din amplitudine

- **Volatilitatea Parkinson** din maximul H_t și minimul L_t ale zilei [Parkinson \(1980\)](#)
 - ▶ $\hat{\sigma}_t^2 = \frac{(\ln H_t - \ln L_t)^2}{4 \ln 2}$, anualizată $100\sqrt{252} \hat{\sigma}_t^2$, în logaritm
 - ▶ Nedepasată pentru dispersia unei mișcări browniene fără tendință; mai eficientă decât randamentul la pătrat
- Volatilitatea se transmite mai mult decât randamentele și este mai previzibilă: un obiect natural pentru un VAR
- Modelul nostru: VAR pe logaritmul volatilității celor 13 bănci, ordinul ales după criteriul informațional bayesian ($p = 1$), orizontul $H = 10$ zile
 - ▶ Fusurile orare: băncile americane se închid după cele europene; întârzierile VAR captează transmiterea din ziua următoare

Tabelul conectivității pentru treisprezece bănci




- Linia i , coloana j : proporția (%) din dispersia erorii de prognoză pe 10 zile a băncii i datorată șocurilor băncii j , întreaga perioadă

Interpretarea tabelului conectivității

- Conectivitatea totală $C = 64,8\%$: în medie, două treimi din riscul de volatilitate al unei bănci vine de la celelalte bănci
 - ▶ Pe randamente în loc de volatilitate: $C = 75,4\%$
- Două blocuri: băncile americane primesc $83,0\%$ unele de la altele, cele europene $72,2\%$ unele de la altele
 - ▶ Peste Atlantic: o bancă europeană primește $26,6\%$ de la băncile americane, o bancă americană $15,7\%$ de la cele europene
- Băncile românești sunt în mare parte independente: ponderea proprie $71,2\%$ (Banca Transilvania) și $74,6\%$ (BRD); primesc $11,1\%$ de la băncile americane și $8,7\%$ de la cele europene

Rețeaua transmiterii nete




- Săgeată de la j la i când j transmite net către i (cele mai mari 25% dintre transmiterile nete pe perechi); mărimea nodului crește cu transmiterea către ceilalți

Interpretarea rețelei

- Transmițători neți: Citigroup (+15,6), JPMorgan (+12,6), Bank of America (+12,4)
 - ▶ Către ceilalți: Citigroup 91,4%, JPMorgan 89,4% (suma unei coloane poate depăși 100)
- Receptori neți: HSBC (−25,8), BRD (−13,8), Banca Transilvania (−12,0), Deutsche Bank (−11,3)
 - ▶ HSBC primește de la aproape toate băncile: se tranzacționează la Londra, între Asia și New York
- În Europa, BNP Paribas și ING transmit către Deutsche Bank și Santander
- O rețea pe întreaga perioadă face media anilor liniștiți și a celor de criză: graficul următor o lasă să se miște

Conectivitatea în timp



- ☐ Sus: conectivitatea totală pe ferestre mobile de 250 de zile ($\text{VAR}(2)$, $H = 10$, la fiecare 5 zile); jos: transmiterea netă însumată pe regiuni


Interpretarea conectivității în timp

- ▣ Indicele total variază între 47,4% (2024-07-24) și 79,3% (2020-08-27); media 62,0%
 - ▶ COVID-19: de la 61,8% în 2019 la 78,4% în primăvara lui 2020; urcă în câteva zile și scade pe parcursul unui an
 - ▶ După falimentele bancare din 2023, 66,0%; anul liniștit 2024, 53,5%
- ▣ Băncile americane sunt transmițători neți în 90% dintre ferestre (net mediu +48,5)
 - ▶ Băncile europene au fost transmițători neți în criza din zona euro din 2011–2012 și mai ales receptori neți după aceea
- ▣ Băncile românești sunt, în medie, receptori neți (−24,1)
- ▣ Ordinul: $p = 2$ este fix în toate ferestrele, pentru ca indicele să nu sară când se schimbă ordinul ales; BIC alege $p = 1$ în 100% dintre ferestre, iar cu $p = 1$ indicele are corelația 0,99 cu cel prezentat

Eroarea de estimare în rețea

- Un VAR(1) pe 13 serii are 169 de coeficienți de pantă; o fereastră de 250 de zile dă 250 de observații pe ecuație pentru 13 pante, iar tabelul este o funcție neliniară de toți
 - ▶ Fiecare cifră din tabel și fiecare săgeată din rețea este o estimare: are nevoie de un interval
- Bootstrap pe blocuri de reziduuri: reeșantionăm blocuri de 20 de zile din vectorii de reziduuri, reconstruim seriile cu VAR-ul estimat, reestimăm, recalculăm tabelul; 999 de extrageri
 - ▶ Reeșantionarea vectorilor întregi de reziduuri păstrează corelația contemporană Σ , care determină descompunerea generalizată
- Întreaga perioadă, $p = 1$: $C = 64,8\%$ cu intervalul de 95% [60,7, 67,1]
 - ▶ Fereastra vârfului (250 de zile până la 2020-08-27, $p = 2$): $C = 79,3\%$, interval [65,9, 83,0]; media bootstrap 75,8%, deci eșantioanele mici deplasează și C

Transmiterea netă cu intervale bootstrap



- VAR(1) pe întreaga perioadă, pe logaritmul volatilității Parkinson, $H = 10$; intervale de 95% din 999 de extrageri bootstrap pe blocuri de reziduuri (blocuri de 20 de zile)


Interpretarea intervalelor transmiterii nete

- 8 din 13 poziții nete au intervale care exclud zero; pentru celelalte 5, eticheta „transmițător” sau „receptor” nu este identificată de date
- Întreaga perioadă are aproximativ 4 000 de zile; în fereastra de 250 de zile a vârfului din 2020 intervalul pentru C este de aproape trei ori mai larg ($[65,9, 83,0]$), deci etichetele nete pe ferestre mobile sunt mai ales zgomot
- Raportăm intervalul lângă fiecare cifră netă și desenăm doar săgețile a căror legătură netă pe perechi este semnificativă
- Conectivitatea pe frecvențe împarte același tabel în componente pe termen scurt și lung [Baruník & Křehlík \(2018\)](#): salturile din crize sunt mai ales pe termen scurt

VAR-uri regularizate: elastic net

- **Demirer et al. (2018)**, Ec. (9): fiecare ecuație VAR prin elastic net adaptiv, λ ales ecuație cu ecuație prin validare încrucișată cu 10 grupe
 - ▶ $\hat{\beta} = \arg \min_{\beta} \sum_t (y_t - \sum_i \beta_i x_{it})^2 + \lambda \sum_i w_i (\frac{1}{2} |\beta_i| + \frac{1}{2} \beta_i^2)$, $w_i = 1/|\hat{\beta}_{i,OLS}|$
 - ▶ Ferestre mobile de 150 de zile cu elastic net simplu, $w_i = 1$ (Secțiunea 5, nota 15); orizontul de prognoză $H = 10$
- De ce: selecție și micșorare în coeficienții VAR, fără a impune o **rețea** rară (legăturile vin și prin Σ)
 - ▶ Lucrarea nu precizează ordinul în text; păstrăm ordinul BIC al VAR-ului nostru OLS, $p = 1$
- Întreaga perioadă, elastic net adaptiv: $C = 64,2\%$ (OLS 64,8%); 70% dintre coeficienți sunt nenuli
 - ▶ Cu aproximativ 4000 de zile penalizarea aproape că nu contează; contează în ferestrele scurte (slide-ul următor)

Conectivitatea OLS și elastic net pe ferestre mobile



- Conectivitatea totală la fiecare 10 zile, $H = 10$: indicele capitolului (VAR(2) OLS, 250 de zile), VAR(1) OLS și VAR(1) elastic net pe ferestre de 150 de zile [Demirer et al. \(2018\)](#)

Interpretarea conectivității OLS față de elastic net

- Medii pe 372 ferestre: 62,0% (indicele capitolului), 61,1% (OLS, 150 de zile), 58,7% (elastic net, 150 de zile)
 - ▶ Pe aceleași ferestre de 150 de zile, OLS depășește elastic net cu 2,4 puncte în medie: zgomotul de estimare din coeficienți umflă conectivitatea măsurată
- Dinamica este aceeași: corelația 0,82 între indicele elastic net și indicele capitolului; vârfurile din crize sunt în aceleași săptămâni
- Nivelurile depind de fereastră, estimator și ordin; schimbările în timp sunt partea robustă a indicelui
- Rețele din corelații parțiale pe termen lung pentru paneluri mari: [Barigozzi & Brownlees \(2019\)](#)

Rețele de cauzalitate Granger și testarea multiplă

- Billio, Getmansky, Lo & Pelizzon (2012) desenează o muchie $j \rightarrow i$ când j cauzează Granger pe i la 5%; cu 13 bănci sunt $13 \times 12 = 156$ de teste
 - ▶ Chiar fără nicio legătură, aproximativ 7,8 muchii ar apărea din întâmplare
- Testele noastre: regresii bivariate, o întârziere, statistici Wald robuste la heteroscedasticitate
 - ▶ Randamente zilnice: 57 muchii la 5%, 33 după Holm [Holm \(1979\)](#), 55 cu rata descoperirilor false controlată la 5% [Benjamini & Hochberg \(1995\)](#)
 - ▶ Logaritmul volatilității, foarte persistent: o întârziere suplimentară netestată [Toda & Yamamoto \(1995\)](#), ca în testele cu întârzieri suplimentare din [Shi, Hurn & Phillips \(2020\)](#): 153, 150 și 153 muchii
- Holm controlează probabilitatea oricărei muchii false; FDR controlează proporția muchiilor false printre cele desenate și păstrează mai multe
- Randamente zilnice ale unor bănci din fusuri orare diferite: multe muchii „cauzale” arată doar că New York se închide după Frankfurt

Recapitulare: rețele de transmitere

- ▣ Descompunerea generalizată a dispersiei dintr-un VAR dă o rețea orientată și ponderată, care nu depinde de ordinea variabilelor
- ▣ Două treimi din riscul de volatilitate al băncilor vine de la alte bănci; băncile americane transmit, HSBC și băncile românești primesc
- ▣ Conectivitatea urcă brusc în crize și scade încet: un instrument de monitorizare pentru supraveghetori
- ▣ Alegerile contează: ordinul VAR, orizontul, lungimea ferestrei, estimatorul și volatilitate față de randamente (Seminarul 18, B5)
- ▣ Fiecare tabel și fiecare muchie are eroare de eșantionare: intervale bootstrap, micșorare și controlul testelor multiple pentru muchii

Ideea Financial Risk Meter

- Pentru fiecare firmă j , o regresie cuantilă la $\tau = 5\%$ a randamentului ei pe randamentele **tuturor** celorlalte firme și pe variabile macro întârziate Mihoci, Althof, Chen & Härdle (2020)
 - ▶ Cu 100 de firme și o fereastră de 63 de zile sunt mai mulți regresori decât zile: este nevoie de o penalizare
- Regresie cuantilă **LASSO** Belloni & Chernozhukov (2011)
 - ▶ $\hat{\beta}_j(\lambda) = \arg \min_{\beta} \frac{1}{n} \sum_t \rho_{\tau} \left(X_{j,t} - \beta_0 - \beta^T Z_{-j,t} \right) + \lambda \|\beta\|_1$
 - ▶ λ elimină legăturile slabe: un λ mai mare lasă mai puțini coeficienți activi
- **FRM** (Financial Risk Meter) este media valorilor λ_j alese pe toate firmele, construită ca indicator al interdependenței din coadă și al stresului sistemic
 - ▶ Construit pentru firmele financiare americane Mihoci, Althof, Chen & Härdle (2020), piețele emergente Ben Amor, Althof & Härdle (2022) și China Wang, Althof & Härdle (2023)



Alegerea penalizării: GACV

- **GACV** (Generalized Approximate Cross-Validation, validare încrucișată aproximativă generalizată) echilibrează potrivirea cu numărul de coeficienți activi

►
$$\text{GACV}(\lambda) = \frac{\sum_t \rho_\tau \left(X_{j,t} - \hat{X}_{j,t}(\lambda) \right)}{n - \text{df}(\lambda)}, \text{ df} = \text{numărul coeficienților nenuli}$$

- $\hat{\lambda}_j = \arg \min_{\lambda} \text{GACV}(\lambda)$ pe o grilă; $\text{FRM}_t = \frac{1}{J} \sum_j \hat{\lambda}_{j,t}$
- Versiunea noastră: 13 bănci, variabile macro S&P 500, Euro Stoxx 50 și VIX la $t - 1$, ferestre de 63 de zile la fiecare 10 zile
 - 15 regresori pentru 63 de zile: mult mai puțini decât în FRM publicat
- Extensii: FRM bazat pe expectile [Ren, Lu, Li & Härdle \(2022\)](#), pentru criptomonede [Ren, Althof & Härdle \(2022\)](#) și pentru sectorul energetic din UE [Toma, Dima, Grecu, Pele & Lessmann \(2026\)](#)

GACV într-o fereastră calmă și într-una de criză




- JPMorgan regresat pe celelalte 12 bănci și trei variabile macro întârziate, 63 de zile; linia punctată: λ ales; portocaliu: coeficienți activi

Interpretarea curbelor GACV

- ▣ Fereastra calmă (până la 28 iunie 2019): $\hat{\lambda} = 4,5 \times 10^{-5}$, 11 din 15 coeficienți activi
 - ▶ Fereastra COVID-19 (până la 31 martie 2020): $\hat{\lambda} = 7,8 \times 10^{-5}$, 12 activi
- ▣ Curba este plată pentru λ mici și crește abrupt când legăturile importante sunt eliminate
- ▣ În criză întreaga curbă este de aproximativ trei ori mai sus: pierderea de verificare este în unitățile randamentelor, iar randamentele sunt mai mari
- ▣ Cu puțini regresori, minimul se află acolo unde aproape nu se aplică penalizare: alegerea este zgomotoasă

Financial Risk Meter pentru treisprezece bănci



- ☐ Sus: penalizarea GACV medie pe 13 bănci; jos: proporția legăturilor active în coadă când λ este fix, împreună cu VIX; 390 ferestre de 63 de zile

Interpretarea Financial Risk Meter calculat de noi

- Penalizarea GACV medie este zgomotoasă; corelația ei cu VIX este doar 0,35
 - ▶ Cu 15 regresori și 63 de zile, estimarea aproape că nu are nevoie de penalizare; FRM publicat folosește aproximativ 100 de firme, astfel încât penalizarea să conteze cu adevărat
- La o penalizare fixă $\lambda = 2,3 \times 10^{-4}$, proporția legăturilor active în coadă este un semnal mai clar: corelația cu VIX este 0,62
 - ▶ De la 31% (2017-11-21) la 68% (2020-06-17); media 42%
- Lecția: o rețea în coadă are nevoie de multe noduri; cu un panel mic, numărăm legăturile în loc să facem media penalizărilor

Recapitulare: Financial Risk Meter

- ▣ Cuantila de 5% a fiecărei firme este regresată pe toate celelalte firme cu o penalizare $L1$; penalizarea λ aleasă prin GACV rezumă interdependența din coadă
- ▣ FRM este construit pentru a semnaliza stresul sistemic; se bazează pe secțiuni transversale mari de firme
- ▣ Pe 13 bănci, penalizarea este zgomotoasă, în timp ce numărul legăturilor active în coadă urmează VIX
- ▣ Material avansat: cursul Quantinar despre FRM (la finalul capitolului)

Riscul climatic ca risc sistemic

- **Riscul fizic:** pierderi din inundații, secete, caniculă și furtuni care afectează garanțiile și debitorii
 - ▶ **Riscul de tranziție:** pierderi din trecerea la o economie cu emisii reduse (prețul carbonului, reglementare, tehnologie)
- Riscuri de tip „lebedă verde”: evenimente potențial extrem de perturbatoare, care ar putea sta la baza următoarei crize financiare sistemice; modelele de risc bazate pe trecut nu le pot anticipa [Bolton et al. \(2020\)](#)
- Un test de stres climatic pe rețea descrie expunerile investitorilor față de sectoarele relevante pentru politica climatică și adaugă efectele de runda a doua prin rețeaua financiară [Battiston et al. \(2017\)](#)
- De aceea analiza de scenarii înlocuiește estimarea istorică: eșantionul trecut nu conține nicio tranziție energetică

Testul de stres climatic al ECB din 2022



Sediul Băncii Centrale Europene, Frankfurt, 2015


Foto: DXR (2015); CC BY-SA 4.0; Wikimedia Commons

- Au participat 104 bănci semnificative; o proiecție bottom-up a pierderilor a acoperit 41 dintre ele [ECB Banking Supervision \(2022\)](#)
- Aproximativ 60% dintre bănci nu aveau un cadru de testare la stres pentru riscul climatic; doar 20% țineau cont de riscul climatic la acordarea creditelor
- Aproape două treimi din veniturile băncilor de la clienții corporativi nefinanciari proveneau din industrii intensive în gaze cu efect de seră
- Pierderi de credit și de piață de aproximativ 70 de miliarde EUR pentru cele 41 de bănci, într-un scenariu de tranziție dezordonată pe termen scurt și două scenarii de risc fizic
 - ECB precizează că cifra subestimează semnificativ riscul: lipsă de date, modele rudimentare, fără efecte de runda a doua

Teste de stres și scenarii istorice

- Un test de stres întreabă cât am pierde într-un scenariu **sever, dar plauzibil: istoric** (reluăm o criză trecută), **ipotetic** (șocăm factori aleși), **invers** (căutăm cel mai plauzibil scenariu din spatele unei pierderi fatale)
 - ▶ Teste de supraveghere pentru băncile mari: [Federal Reserve stress tests](#) în SUA, testele la nivelul UE ale [European Banking Authority](#); băncile de importanță sistemică globală dețin capital suplimentar [Basel Committee](#) (2018)
- Șapte episoade, fiecare o fereastră de câteva săptămâni în jurul unui șoc cunoscut
 - ▶ Lehman (toamna lui 2008), criza din zona euro (vara lui 2011), votul Brexit (iunie 2016), taxa bancară din România (decembrie 2018), COVID-19 (martie 2020), SVB și Credit Suisse (martie 2023), șocul tarifelor (aprilie 2025)
- În fiecare fereastră găsim **cele mai rele 10 zile de tranzacționare** ale portofoliului bancar cu ponderi egale și raportăm randamentul fiecărei bănci în acele zile
- Episodul din 2008 folosește doar cele 11 bănci internaționale: seriile românești încep în 2010
- Zece zile corespund orizontului capitalului pentru riscul de piață (Capitolul 7)

Șapte scenarii istorice de stres



- Randamentul (%) fiecărei bănci în cele mai rele 10 zile ale portofoliului bancar cu ponderi egale din fiecare episod; gol: fără date

Interpretarea scenariilor istorice

- ▣ Pierderea portofoliului în cele mai rele 10 zile: Lehman 38,3% (2008-11-10 – 2008-11-21), COVID-19 32,5%, criza din zona euro 22,7%
 - ▶ Tarifele 16,1%, SVB 15,0%, taxa bancară din România 10,6%, Brexit 8,2%
- ▣ Cele mai mari pierderi individuale: Citigroup –68% în 2008, ING –48% în martie 2020
- ▣ Șocurile sunt și locale, nu doar globale: Brexit a lovit mai ales băncile europene; taxa bancară din România a lovit cel mai tare băncile românești (–26% și –26%), în timpul unei scăderi din decembrie 2018 care a costat și băncile americane între –8% și –14%
- ▣ Un test de stres construit doar pe crize globale ar rata șocul politic intern


Testarea inversă la stres

- Model factorial: randamentele săptămânale ale băncilor $X_i = \beta_i^\top f + e_i$, factorii $f = (\text{S\&P 500, Euro Stoxx 50, BET})$, pe h săptămâni $f \sim N(0, h\Sigma)$
 - Pierderea portofoliului cu ponderi egale: $L = -b^\top f$, cu b media valorilor β_i (termenii idiosincratice se diversifică)
- Cel mai plauzibil scenariu cu pierderea ℓ^* minimizează distanța Mahalanobis $f^\top (h\Sigma)^{-1} f$ cu condiția $-b^\top f = \ell^*$
 - $f^* = -\ell^* \frac{h\Sigma b}{b^\top h\Sigma b}, \quad d^* = \frac{\ell^*}{\sqrt{b^\top h\Sigma b}}$
- d^* numără abaterile standard ale portofoliului: cu cât este mai mare, cu atât pierderea este mai puțin plauzibilă în model

Exemplu lucrat: test invers de stres cu doi factori

- Beta $b = (1,2, 0,8)$; covarianța pe patru săptămâni a factorilor $h\Sigma = \begin{pmatrix} 16 & 6 \\ 6 & 9 \end{pmatrix} (\%^2)$; pierderea țintă $\ell^* = 20\%$
 - ▶ $h\Sigma b = (1,2 \cdot 16 + 0,8 \cdot 6, ; 1,2 \cdot 6 + 0,8 \cdot 9) = (24, 14,4)$
 - ▶ $b^\top h\Sigma b = 1,2 \cdot 24 + 0,8 \cdot 14,4 = 40,32$, abaterea standard 6,35%
- Cel mai plauzibil scenariu și distanța lui
 - ▶ $f^* = -20 \cdot (24, 14,4)/40,32 = (-11,9\%, -7,1\%)$, $d^* = 20/6,35 = 3,15$
 - ▶ Probabilitatea Normală a unei pierderi cel puțin atât de mari: $\Phi(-3,15) = 0,08\%$ pe patru săptămâni
- Scenariul pune mai multă greutate pe factorul cu beta și dispersie mai mari, iar ambii factori scad împreună pentru că sunt corelați

Cel mai plauzibil scenariu pentru o pierdere de 25%



- Date săptămânale 2010–2026 (871 săptămâni), orizont de patru săptămâni; roșu: f^* pentru $\ell^* = 25\%$; albastru: mișcările factorilor în cele mai rele patru săptămâni din 2020

Interpretarea testului invers de stres

- Beta ale portofoliului: $b = (0,45, 0,65, 0,18)$; abaterea standard pe patru săptămâni 5,79%
 - O pierdere de 25% cere simultan S&P 500 $-17,2\%$, Euro Stoxx 50 $-22,6\%$, BET $-13,9\%$
- Distanța $d^* = 4,31$: în modelul Normal probabilitatea ei este $8,0 \times 10^{-6}$ pe patru săptămâni, practic imposibilă
- Și totuși, în cele patru săptămâni până la 2020-03-20, portofoliul a pierdut 52,0% în termeni log, cu scăderi ale factorilor mai mari decât f^* (modelul implică 48,5%)
- Forma scenariului este informativă; probabilitatea lui nu este: cozile grele și corelațiile care cresc fac probabilitățile Normale mult prea mici

Limitele testelor de stres

- ▣ Scenariile sunt alese de oameni: criza care vine este rareori cea care a fost testată
- ▣ Efectele de runda a doua (vânzări forțate, retrageri de finanțare, pierderi ale contrapărților) sunt greu de modelat și de obicei lipsesc, cum a observat ECB pentru testul său climatic
- ▣ Măsurile bazate pe piață (MES, CoVaR, conectivitate) reacționează repede, dar doar după ce prețurile se mișcă; testele de stres pe bilanț privesc înainte, dar încet
- ▣ Cercetarea despre semnalele de avertizare timpurie le combină pe amândouă, de ex. măsurile de risc de piață bazate pe entropie [Pele, Lazar & Dufour \(2017\)](#)

Recapitulare: testarea la stres

- ▣ Testele de stres istorice, ipotetice și inverse răspund la întrebări diferite
- ▣ În cele șapte episoade, cea mai mare pierdere pe 10 zile a unui portofoliu bancar a variat între 8,2% și 38,3%
- ▣ Testele inverse de stres dau direcția cea mai plauzibilă a unui dezastru, nu probabilitatea lui
- ▣ Scenariile climatice extind testarea la stres către riscuri fără istorie

O întrebare deschisă

Măsoară conectivitatea rețelei riscul sistemic sau doar volatilitatea?

- Indicii de conectivitate sunt urmăriți ca instrumente de avertizare timpurie, dar indicele este construit dintr-un VAR pe volatilități și crește ori de câte ori crește volatilitatea
 - ▶ Cercetare în curs: rețele bancare globale din VAR-uri regularizate [Demirer et al. \(2018\)](#); conectivitatea în cozi diferă de cea în medie [Ando, Greenwood-Nimmo & Shin \(2022\)](#)
- Forma formală, pentru stresul viitor al băncilor y_{t+h} , conectivitatea totală C_t și volatilitatea curentă σ_t :
$$y_{t+h} = a + \beta_C C_t + \gamma \ln \sigma_t + e_{t+h}, \quad H_0: \beta_C = 0, \quad H_1: \beta_C > 0$$
 - ▶ Infirmată dacă C_t își pierde puterea predictivă odată ce volatilitatea curentă este controlată
- Identificarea: o muchie a rețelei este o proporție din dispersia erorii de prognoză, nu o expunere cauzală
 - ▶ Un șoc comun crește simultan volatilitatea și conectivitatea, fără ca vreo bancă să o contamineze pe alta

Bucula descoperirii, pas cu pas (1/2)

- **Literatura:** cartografiem ce se știe, apoi verificăm fiecare referință
 - ▶ „Ce articole testează dacă indicii de conectivitate prezic dificultățile băncilor în afara eșantionului, dincolo de volatilitate? Dă DOI-ul, eșantionul, orizontul și variabilele de control.”
 - ▶ Rezolvăm fiecare DOI pe [Crossref](#) și verificăm că articolul chiar controlează volatilitatea; căutăm cu Semantic Scholar, Elicit sau Google Scholar
- **Ipoteze:** interpretări concurente ale unei creșteri a conectivității, fiecare cu testul ei
 - ▶ „Dă interpretări concurente ale unei creșteri a conectivității totale (șoc comun, contagiune, artefact al ferestrelor mobile) și un test care le deosebește.”
 - ▶ De exemplu, un șoc comun dispare odată cu volatilitatea; contagiunea are o direcție: șocurile transmițătorilor neți le preced pe ale receptorilor
- **Date și cod:** pe datele cursului, replicând întâi o cifră cunoscută
 - ▶ „Estimează un VAR(2) pe logaritmul volatilităților Parkinson ale celor 13 bănci din data/market, pe ferestre de 250 de zile, și calculează conectivitatea totală generalizată cu $H = 10$.”
 - ▶ Replicăm întâi: media 62,0% și maximumul 79,3% (2020-08-27), ca în acest capitol

Bucula descoperirii, pas cu pas (2/2)

- **Robustețea**, fixată înainte de a rula regresii predictive
 - ▶ „Preînregistrează: orizonturi de 21/63/126 de zile, controale pentru volatilitate și VIX, ferestre de 150/250/500 de zile, decalaje HAC cel puțin cât suprapunerea, evaluare în afara eșantionului din 2018.”
 - ▶ Fiecare celulă a grilei este raportată; familia este corectată cu Holm sau controlată prin FDR
- **Critica**: îi cerem asistentului să atace rezultatul
 - ▶ „Joacă rolul unui recenzent: este puterea predictivă a conectivității doar persistența volatilității? Ce regresie ar arăta asta?”
 - ▶ Ne așteptăm la: adăugăm volatilitatea curentă ca variabilă de control, apoi testăm creșterea lui R^2 și a pierderii în afara eșantionului
- **Raportul**: efecte standardizate cu statistici t HAC, fiecare celulă a grilei, ce a eșuat
 - ▶ Prompturile care au modelat designul intră în AI_USE.md

Ce verifică cercetătorul

- **Date nestaționare:** un VAR pe nivelurile prețurilor sau pe serii cu tendință produce conectivitate falsă
 - ▶ Test: teste de rădăcină unitară pe fiecare serie; toate rădăcinile VAR-ului estimat în interiorul cercului unitate, în fiecare fereastră
- **Ordinea:** descompunerile Cholesky se schimbă cu ordinea băncilor
 - ▶ Test: permutăm coloanele; tabelul generalizat nu trebuie să se schimbe
- **Informație din viitor:** o fereastră etichetată cu prima ei dată sau un ordin ales pe toată selecția
 - ▶ Test: indicele de la t nu trebuie să se miște când ștergem datele de după t
- **Suprapunerea:** indicii pe ferestre mobile și rezultatele viitoare se suprapun, deci statisticile t OLS sunt umflate
 - ▶ Test: decalaje Newey–West cel puțin egale cu suprapunerea sau bootstrap pe blocuri
- **Dimensiunea:** 13 bănci și $p = 2$ dau 27 de coeficienți pe ecuație din 250 de zile; mai multe bănci cer regularizare [Demirer et al. \(2018\)](#)
 - ▶ Test: comparăm cu un VAR LASSO; muchiile instabile semnalează zgomot de estimare, nu structură

Mini-caz: este conectivitatea mai mult decât volatilitate?

- O propunere tipică a asistentului: „o conectivitate totală ridicată anunță stresul viitor al băncilor”; o testăm pe 731 date săptămânale, 2011–2026
 - ▶ y_{t+h} : logaritmul volatilității Parkinson medii a celor 13 bănci în următoarele $h = 63$ zile; control: aceeași mărime în ultimele 20 de zile; variabile standardizate, Newey–West cu 13 decalaje
- Conectivitatea singură: $\hat{\beta}_C = 0,40$ ($t = 4,58$), $R^2 = 0,16$: propunerea pare corectă
- Cu volatilitatea curentă: $\hat{\beta}_C = 0,08$ ($t = 0,72$), $\hat{\gamma} = 0,53$ ($t = 4,13$); $R^2 = 0,343$ față de 0,339 doar cu volatilitatea
 - ▶ Corelația lui C_t cu volatilitatea curentă: 0,59; pentru scăderea maximă a portofoliului băncilor în următoarele 63 de zile, $\hat{\beta}_C = -0,09$ ($t = -1,27$) chiar și singură
- Interpretare: în eșantionul nostru, conținutul predictiv al indicelui este persistența volatilității; informația de rețea poate conta totuși în cozi [Ando, Greenwood-Nimmo & Shin \(2022\)](#) sau pentru direcția transiterii

Rândul vostru: o idee de proiect

- **Întrebarea:** prezice conectivitatea în **cozi** dificultățile băncilor dincolo de volatilitate, în afara eșantionului?
- **Replicați întâi:** indicele nostru pe ferestre mobile (media 62,0%, primăvara lui 2020 78,4%), apoi o cifră principală de conectivitate din [Demirer et al. \(2018\)](#) pe eșantionul lor
 - ▶ Extindeți: conectivitatea cuantilă la $\tau = 5\%$ [Ando, Greenwood-Nimmo & Shin \(2022\)](#), evaluare în afara eșantionului din 2018, MES și SRISK ca ținte alternative
- **Livrabile:** o grilă preînregistrată, salvată înaintea regresiilor, un notebook care regenerează fiecare cifră, inferență HAC și pierderi în afara eșantionului pentru fiecare celulă
- **Jurnalul AI:** prompturile care au modelat designul în AI_USE.md; fiecare afirmație greșită (un VAR pe nivelurile prețurilor, statistici t OLS pe ferestre suprapuse) și testul care a prins-o în AI_ERRORS.md ([șabloane](#))

Care bancă este cea mai sistemică?

Banca	VaR 1%	MES 5%	$\Delta\text{CoVaR } 1\%$	Transmitere netă	L^*
JPMorgan	4,83	3,22	4,62	12,6	7,0
Bank of America	5,99	3,85	4,60	12,4	6,2
Citigroup	5,87	4,03	3,81	15,6	6,0
Goldman Sachs	4,81	3,34	4,12	2,5	6,8
Morgan Stanley	5,83	4,04	4,00	7,9	6,0
Wells Fargo	5,78	3,32	4,89	2,1	6,8
Deutsche Bank	7,19	4,54	4,24	-11,3	6,1
BNP Paribas	6,18	4,53	4,84	6,2	6,1
Santander	5,83	4,23	4,42	-4,0	6,4
ING	7,16	4,81	4,42	7,5	5,8
HSBC	4,66	2,54	4,07	-25,8	8,3
Banca Transilvania	5,06	3,14	-	-12,0	6,5
BRD-Groupe SG	4,42	2,69	-	-13,8	7,1

□ Pierderi zilnice în %; transmiterea netă a volatilității (către minus de la); L^* : levierul de echilibru cu $k = 8\%$

Interpretarea comparației

- Corelații de rang pe cele unsprezece bănci internaționale
 - ▶ MES și ΔCoVaR : $-0,01$; MES și transmiterea netă: $-0,01$; ΔCoVaR și transmiterea netă: $-0,03$
 - ▶ VaR și MES: $0,88$
- Măsurile răspund la întrebări diferite: expunerea la piață, contribuția la sistem, transmiterea volatilității
- Nu există un clasament unic: supraveghetorii combină mai mulți indicatori cu mărimea și datele din bilanț, ca în metodologia [Basel Committee \(2018\)](#)
- Băncile românești: MES moderat, receptori neți de volatilitate, levier de echilibru apropiat de cel al băncilor americane

Idei principale

- ▣ Riscul sistemic trăiește în coada comună: expunere (MES, SRISK), contribuție (ΔCoVaR) și conectivitate (rețele de transmitere și rețele în coadă)
- ▣ Băncile europene au cele mai mari MES din eșantionul nostru; băncile americane sunt principalii transmițători neți de volatilitate
- ▣ VaR și ΔCoVaR ordonează băncile diferit; clasamentele sunt incerte: testați diferențele, raportați intervale, precizați αn
- ▣ Măsurile bazate pe piață urcă brusc în crize; testele de stres și bilanțurile sunt necesare pentru a vedea cum se acumulează riscul
- ▣ Băncile românești sunt conduse mai ales de șocuri interne și primesc mai mult decât transmit

Greșeli frecvente

- Interpretarea ΔCoVaR ca efect causal: un șoc comun creează același tipar
- Interpretarea intervalelor suprapuse drept „egale” și a celor separate drept „diferite”: testăm diferența pe extrageri comune și corectăm pentru numărul de perechi
- Includerea băncii în portofoliul sistemului: propriul randament umflă legătura în mod mecanic
- Descompuneri ortogonale ale dispersiei ale căror rezultate depind de ordinea băncilor
- Raportarea SRISK fără date din bilanț sau din aproximarea $1 - e^{-18\text{MES}}$ ca și cum ar fi măsura publicată
- Desenarea fiecărei muchii Granger semnificative la 5% din 156 de teste sau a fiecărei etichete nete fără intervalul ei

Studiu suplimentar pe Quantinar

Cursuri avansate pe quantinar.com

- ▣  Financial Risk Meter for Emerging Markets
- ▣  Dynamic Crypto Networks
- ▣  Network Centrality

Cod și date

- ▣ Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_18

Bibliografie (1/6)

- ▣ Acharya, V.V., Engle, R., Richardson, M. (2012). [Capital shortfall: a new approach to ranking and regulating systemic risks](#). *American Economic Review*, 102(3), 59–64.
- ▣ Acharya, V.V., Pedersen, L.H., Philippon, T., Richardson, M. (2017). [Measuring systemic risk](#). *Review of Financial Studies*, 30(1), 2–47.
- ▣ Adrian, T., Brunnermeier, M.K. (2016). [CoVaR](#). *American Economic Review*, 106(7), 1705–1741.
- ▣ Ando, T., Greenwood-Nimmo, M., Shin, Y. (2022). [Quantile connectedness: modeling tail behavior in the topology of financial networks](#). *Management Science*, 68(4), 2401–2431.
- ▣ Banulescu-Radu, D., Hurlin, C., Leymarie, J., Scaillet, O. (2021). [Backtesting marginal expected shortfall and related systemic risk measures](#). *Management Science*, 67(9), 5730–5754.
- ▣ Barigozzi, M., Brownlees, C. (2019). [NETS: network estimation for time series](#). *Journal of Applied Econometrics*, 34(3), 347–364.
- ▣ Baruník, J., Křehlík, T. (2018). [Measuring the frequency dynamics of financial connectedness and systemic risk](#). *Journal of Financial Econometrics*, 16(2), 271–296.
- ▣ Basel Committee on Banking Supervision (2018). [Global systemically important banks: revised assessment methodology and the higher loss absorbency requirement](#). Bank for International Settlements.
- ▣ Battiston, S., Mandel, A., Monasterolo, I., Schütze, F., Visentin, G. (2017). [A climate stress-test of the financial system](#). *Nature Climate Change*, 7(4), 283–288.

Bibliografie (2/6)

- ▣ Belloni, A., Chernozhukov, V. (2011). ℓ_1 -penalized quantile regression in high-dimensional sparse models. *Annals of Statistics*, 39(1), 82–130.
- ▣ Ben Amor, S., Althof, M., Härdle, W.K. (2022). Financial Risk Meter for emerging markets. *Research in International Business and Finance*, 60, 101594.
- ▣ Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- ▣ Benoit, S., Colliard, J.-E., Hurlin, C., Pérignon, C. (2017). Where the risks lie: a survey on systemic risk. *Review of Finance*, 21(1), 109–152.
- ▣ Billio, M., Getmansky, M., Lo, A.W., Pelizzon, L. (2012). Econometric measures of connectedness and systemic risk in the finance and insurance sectors. *Journal of Financial Economics*, 104(3), 535–559.
- ▣ Bolton, P., Després, M., Pereira da Silva, L.A., Samama, F., Svartzman, R. (2020). The green swan: central banking and financial stability in the age of climate change. Bank for International Settlements.
- ▣ Brownlees, C., Engle, R.F. (2017). SRISK: a conditional capital shortfall measure of systemic risk. *Review of Financial Studies*, 30(1), 48–79.
- ▣ Castro, C., Ferrari, S. (2014). Measuring and testing for the systemically important financial institutions. *Journal of Empirical Finance*, 25, 1–14.
- ▣ Chernozhukov, V., Fernández-Val, I. (2011). Inference for extremal conditional quantile models, with an application to market and birthweight risks. *Review of Economic Studies*, 78(2), 559–589.

Bibliografie (3/6)

- ▣ Danielsson, J., James, K.R., Valenzuela, M., Zer, I. (2016). [Model risk of risk models](#). *Journal of Financial Stability*, 23, 79–91.
- ▣ Demirer, M., Diebold, F.X., Liu, L., Yilmaz, K. (2018). [Estimating global bank network connectedness](#). *Journal of Applied Econometrics*, 33(1), 1–15.
- ▣ Diebold, F.X., Yilmaz, K. (2009). [Measuring financial asset return and volatility spillovers, with application to global equity markets](#). *Economic Journal*, 119(534), 158–171.
- ▣ Diebold, F.X., Yilmaz, K. (2012). [Better to give than to receive: predictive directional measurement of volatility spillovers](#). *International Journal of Forecasting*, 28(1), 57–66.
- ▣ Diebold, F.X., Yilmaz, K. (2014). [On the network topology of variance decompositions: measuring the connectedness of financial firms](#). *Journal of Econometrics*, 182(1), 119–134.
- ▣ ECB Banking Supervision (2022). [Banks must sharpen their focus on climate risk, ECB supervisory stress test shows](#). Press release, 8 July 2022.
- ▣ Engle, R. (2002). [Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models](#). *Journal of Business & Economic Statistics*, 20(3), 339–350.
- ▣ Engle, R., Jondeau, E., Rockinger, M. (2015). [Systemic risk in Europe](#). *Review of Finance*, 19(1), 145–190.
- ▣ FDIC (2023). [FDIC creates a Deposit Insurance National Bank of Santa Clara to protect insured depositors of Silicon Valley Bank, Santa Clara, California](#). Press release, 10 March 2023.

Bibliografie (4/6)

- ▣ Federal Reserve Board (2023). [Federal Reserve Board announces it will make available additional funding to eligible depository institutions](#). Press release, 12 March 2023.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Girardi, G., Ergün, A.T. (2013). [Systemic risk measurement: multivariate GARCH estimation of CoVaR](#). *Journal of Banking & Finance*, 37(8), 3169–3180.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). [On the relation between the expected value and the volatility of the nominal excess return on stocks](#). *Journal of Finance*, 48(5), 1779–1801.
- ▣ Gouriéroux, C., Laurent, J.P., Scaillet, O. (2000). [Sensitivity analysis of values at risk](#). *Journal of Empirical Finance*, 7(3–4), 225–245.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). [Applied Quantitative Finance](#), 3rd ed. Springer.
- ▣ Härdle, W.K., Wang, W., Yu, L. (2016). [TENET: Tail-Event driven NETWORK risk](#). *Journal of Econometrics*, 192(2), 499–513.
- ▣ Holm, S. (1979). [A simple sequentially rejective multiple test procedure](#). *Scandinavian Journal of Statistics*, 6(2), 65–70.
- ▣ Koenker, R., Bassett, G. (1978). [Regression quantiles](#). *Econometrica*, 46(1), 33–50.

Bibliografie (5/6)

- ▣ Koenker, R., Bassett, G. (1982). Tests of linear hypotheses and ℓ_1 estimation. *Econometrica*, 50(6), 1577–1583.
- ▣ Koop, G., Pesaran, M.H., Potter, S.M. (1996). Impulse response analysis in nonlinear multivariate models. *Journal of Econometrics*, 74(1), 119–147.
- ▣ Mihoci, A., Althof, M., Chen, C.Y.-H., Härdle, W.K. (2020). FRM Financial Risk Meter. In *The Econometrics of Networks*, Advances in Econometrics 42, Emerald, 335–368.
- ▣ Nucera, F., Schwaab, B., Koopman, S.J., Lucas, A. (2016). The information in systemic risk rankings. *Journal of Empirical Finance*, 38, 461–475.
- ▣ Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *Journal of Business*, 53(1), 61–65.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- ▣ Pesaran, H.H., Shin, Y. (1998). Generalized impulse response analysis in linear multivariate models. *Economics Letters*, 58(1), 17–29.
- ▣ Ren, R., Althof, M., Härdle, W.K. (2022). Financial Risk Meter for cryptocurrencies and tail risk network-based portfolio construction. *Singapore Economic Review*, 70(4), 901–927.
- ▣ Ren, R., Lu, M., Li, Y., Härdle, W.K. (2022). Financial Risk Meter FRM based on expectiles. *Journal of Multivariate Analysis*, 189, 104881.

Bibliografie (6/6)

- ▣ Scaillet, O. (2004). [Nonparametric estimation and sensitivity analysis of expected shortfall](#). *Mathematical Finance*, 14(1), 115–129.
- ▣ Shi, S., Hurn, S., Phillips, P.C.B. (2020). [Causal change detection in possibly integrated systems: revisiting the money–income relationship](#). *Journal of Financial Econometrics*, 18(1), 158–180.
- ▣ Toda, H.Y., Yamamoto, T. (1995). [Statistical inference in vector autoregressions with possibly integrated processes](#). *Journal of Econometrics*, 66(1–2), 225–250.
- ▣ Toma, F.-M., Dima, D.M., Grecu, R., Pele, D.T., Lessmann, S. (2026). [Energy Financial Risk Meter: systemic risk in the EU energy sector](#). SSRN working paper.
- ▣ Wang, R., Althof, M., Härdle, W.K. (2023). [A financial risk meter for China](#). *Emerging Markets Review*, 56, 101052.