



Modelarea piețelor financiare

Capitolul 19: Recapitulare și prezentarea proiectelor



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model) (model autoregresiv)
- ASE: Academia de Studii Economice din București
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- BNR: Banca Națională a României
- BVB: Bursa de Valori București
- CAPM: Capital Asset Pricing Model (modelul de evaluare a activelor financiare)
- CI: Confidence Interval (interval de încredere)
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- CV: Cross-Validation (validare încrucișată)
- DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- DQ: Dynamic Quantile (test) (testul cuantilei dinamice)
- ES: Expected Shortfall (pierderea așteptată în coadă)
- ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- EVT: Extreme Value Theory (teoria valorilor extreme)
- FDR: False Discovery Rate (rata descoperirilor false)
- FHS: Filtered Historical Simulation (simulare istorică filtrată)
- FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- FTSE: Financial Times Stock Exchange (FTSE Russell, index provider) (furnizorul de indici FTSE Russell)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-EVT: GARCH filter combined with Extreme Value Theory for the tail (filtru GARCH combinat cu teoria valorilor extreme pentru coadă)

Acronime folosite în acest material (2/2)

- GBM: Geometric Brownian Motion (mișcarea browniană geometrică)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- GRS: Gibbons–Ross–Shanken (test) (testul Gibbons–Ross–Shanken)
- GSADF: Generalised Sup Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat suprem generalizat)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- HS: Historical Simulation (simulare istorică)
- IGARCH: Integrated GARCH (GARCH integrat)
- IQR: InterQuartile Range (intervalul intercuartilic)
- LLM: Large Language Model (model lingvistic mare)
- LRMES: Long-Run Marginal Expected Shortfall (pierderea marginală așteptată în coadă pe termen lung (într-o criză))
- LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- MCS: Model Confidence Set (mulțimea de modele de încredere)
- ML: Machine Learning (învățare automată)
- MSE: Mean Squared Error (eroarea pătratică medie)
- QLKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)
- SADF: Sup Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat suprem)
- SE: Standard Error (eroare standard)
- SML: Security Market Line (dreapta pieței titlurilor)
- SRISK: Systemic RISK (capital shortfall measure) (deficitul de capital al unei bănci într-o criză sistemică)
- SUA: Statele Unite ale Americii
- VAR: Vector AutoRegression (autoregresie vectorială)
- VIX: CBOE Volatility Index (indicele de volatilitate CBOE)
- VOLARE: VOLatility Archive for Realized Estimates (database) (arhiva de estimatori realizați ai volatilității (bază de date))

Cuprins

Introducere

Recapitulare I: piețe, randamente și evaluare

Recapitulare II: volatilitate, dependență și risc

Recapitulare III: frecvență înaltă, timp continuu și opțiuni

Recapitulare IV: învățare, text și piețe noi

Capcane frecvente

Studiu de caz integrat: BET

Proiectul de echipă

Utilizarea AI în proiect

Idei de proiect

Studiu de caz: erorile nestandard

AI pentru descoperire științifică

Concluzii

Bibliografie

Ce face acest capitol

Scop

- ▣ Recapitulăm capitolele 0–18 ca o singură poveste
- ▣ Adunăm capcanele care au revenit în fiecare capitol
- ▣ Parcurgem un studiu de caz integrat, de la prețuri brute la o valoare la risc (Value-at-Risk, VaR) de 1% testată
- ▣ Pregătim proiectul de echipă: cei patru pași, întrebarea, metodele și politica AI

Evaluare


- ▣ Proiectul de echipă (GitHub, prezentare, susținere orală): **70%**
- ▣ Quiz-uri și activitate la seminar: **20%**
- ▣ Prezență: **10%**; nu există examen final



Academia de Studii Economice din București (ASE), Piața Romană

Foto: Joe Mabel (2014); CC BY 3.0; Wikimedia Commons

Cursul într-o singură imagine



- Roșu: firul principal al cursului, de la faptele stilizate la prognoze de risc pe care le putem testa
- Săgeți albastre: unde un capitol oferă datele de intrare sau reperul pentru altul

Cum citim harta cursului

- Capitolul 1 stabilește țintele: cozi groase, grupări de volatilitate, aproape nicio predictibilitate liniară
 - ▶ Orice model ulterior este judecat după cum reproduce aceste fapte
- Capitolele 5–8 transformă faptele într-o măsură numerică a riscului și într-un test al acestei măsurii
 - ▶ GARCH dă σ_{t+1} ; VaR și ES dau pierderea; backtesting-ul spune dacă o putem crede
- Capitolele 9–12 măsoară mai bine volatilitatea (date intraday, prețuri de opțiuni) și în timp continuu
- Capitolele 13–15 aduc modele flexibile, evaluate mereu cu instrumentele din Capitolul 8
- Capitolele 16–18 aplică aceleași instrumente pentru crypto, bule și întregul sistem financiar
- Capitolul special 20: prognoza volatilității realizate cu semnături ale traiectoriilor, pe datele VOLARE

Cinci întrebări pentru orice model

Înainte de estimare

- ▣ **Date:** ce serie, ce calendar, ce ajustări (dividende, split-uri, sărbători)?
- ▣ **Model:** ce fapt stilizat surprinde și ce ignoră?
- ▣ **Estimare:** pe ce fereastră, cu ce informație la momentul t ?

După estimare

- ▣ **Evaluare:** în afara eșantionului, cu o funcție de pierdere potrivită țintei (QLIKE, FZ0) și cu testele de diagnostic potrivite (de exemplu Kupiec)?
- ▣ **Incertitudine:** erori standard robuste, bootstrap, test față de un reper simplu?
- ▣ Dacă lipsește un răspuns, rezultatul nu este încă o concluzie

Capitolul 0: Piețele financiare în 2026

Ideea principală

- Piețele combină burse, dealeri extrabursieri, fonduri tranzacționate la bursă (exchange-traded funds, ETF), algoritmi și blockchain-uri
- Calitatea datelor este o decizie de modelare: sursa, ajustarea și calendarul schimbă rezultatul

Inferența cheie

- Pentru randamente log i.i.d., anualizate cu numărul de perioade pe an: $se(\hat{\mu}_{\text{ann}}) = \sigma_{\text{ann}} / \sqrt{Y}$ pentru Y ani, indiferent de frecvență; $se(\hat{\sigma}) \approx \sigma \sqrt{(K-1)/(4T)}$ pentru T zile, K fiind kurtosis-ul populației (cere moment de ordinul patru finit); dependența în timp cere dispersii de termen lung
- SPY 2015–2026: $se(\hat{\mu}_{\text{ann}}) \approx 5,1\%$ pentru o medie de 13,7%: mediile abia pot fi estimate, volatilitățile da

Rezultat din date

- 2015–2026: SPY (ETF pe S&P 500, cu dividende reinvestite) 13,7% pe an cu volatilitate 17,6%; Bitcoin 60,6% pe an cu 66,7%
- BET, iulie 2007 – februarie 2009: o scădere de la maxim de $-82,5\%$

Duce la

- Obiectul de studiu sunt randamentele, nu prețurile (Capitolul 1)

Capitolul 1: Fapte stilizate și randamente

Ideea principală

- Randamentele sunt necorelate, dar nu independente: mărimea lor este previzibilă, semnul aproape deloc
- Cozi groase și grupări de volatilitate pe toate piețele [Cont \(2001\)](#)

Inferența cheie

- Ljung–Box $Q(m) \sim \chi_m^2$ cere randamente i.i.d.; cu grupări de volatilitate respinge prea des: folosiți Q^* robust, cu termenii $T\hat{\rho}_k^2/\hat{\tau}_k$ [Lobato, Nankervis & Savin \(2001\)](#)
- Cozile: Hill $\hat{\alpha}$ cu $se \approx \hat{\alpha}/\sqrt{k}$ [Hill \(1975\)](#); dacă $\alpha < 4$, kurtosis-ul de selecție nu este consistent, iar bootstrap-ul lui eșuează [Athreya \(1987\)](#)

Rezultat din date

- BET, indicele Hill al pierderilor (cele mai mari $k = 153$ pierderi): $\hat{\alpha} = 2,39$, CI 95% prin bootstrap pe blocuri $[2,12, 3,03]$: momentul de ordinul patru este probabil infinit
- Zilele dincolo de 5σ sunt de peste 1000 de ori mai frecvente decât prezice distribuția Normală

Duce la

- Modele de volatilitate (Capitolul 5) și măsuri ale riscului de coadă (Capitolul 7)

Capitolul 2: Eficiența pieței

Ideea principală

- Eficiență: prețurile reflectă pe deplin informația disponibilă; un test al predictibilității randamentelor anormale este un test comun al eficienței și al modelului de randament așteptat [Fama \(1970\)](#)
- Eficiența variază în timp (piețe adaptive); testele cer inferență robustă

Inferența cheie

- Raportul varianțelor robust la heteroscedasticitate $z^*(q) \Rightarrow N(0, 1)$ sub ipoteza de diferență de martingală [Lo & MacKinlay \(1988\)](#)
- Mai multe orizonturi q deodată: testul comun $\max_q |z^*(q)|$ cu valori critice de modul maxim studentizat [Chow & Denning \(1993\)](#); ferestrele mobile cer și ele o corecție pentru testele multiple

Rezultat din date

- Ponderea ferestrelor mobile care resping mersul aleator: S&P 500 6,4%, BET 22,4%, Bitcoin 0,0%
- O respingere statistică nu înseamnă profit exploatabil

Duce la

- Anomalii și factori (Capitolul 3); problema testării multiple

Capitolul 3: Modele factoriale și evaluarea activelor

Ideea principală

- Randamentele așteptate ar trebui să răsplătească doar expunerea la factori sistematici
- Sutele de factori publicați cer praguri mai înalte [Harvey, Liu & Zhu \(2016\)](#)

Inferența cheie

- $GRS = \frac{T-N-K}{N} \frac{\hat{\alpha}^\top \hat{\Sigma}^{-1} \hat{\alpha}}{1 + \hat{\mu}_f^\top \hat{\Omega}^{-1} \hat{\mu}_f} \sim F(N, T - N - K)$ doar pentru erori i.i.d. Normale [Gibbons, Ross & Shanken \(1989\)](#)
- Erorile standard Fama–MacBeth ignoră faptul că beta sunt estimate: cu $c = \hat{\gamma}^\top \hat{\Sigma}_f^{-1} \hat{\gamma}$, covarianța Shanken este $(1 + c)(\hat{V}_{FM} - \hat{\Sigma}_f / T) + \hat{\Sigma}_f / T$ pentru încărcări factoriale estimate [Shanken \(1992\)](#)

Rezultat din date

- 25 de portofolii după mărime și raportul valoare contabilă/de piață: panta SML $-4,4\%$, $GRS = 4,18$: CAPM este respins
- ETF-uri sectoriale: prima componentă principală (piața) explică 66% din varianță

Duce la

- Construcția portofoliului (Capitolul 4); modele factoriale în machine learning (Capitolul 13)

Capitolul 4: Optimizarea portofoliului

Ideea principală

- Markowitz pune întrebarea corectă, dar eroarea de estimare domină răspunsul [Markowitz \(1952\)](#)
- Shrinkage-ul, restricțiile și regulile bazate pe risc stabilizează ponderile; $1/N$ este un reper greu de bătut [DeMiguel, Garlappi & Uppal \(2009\)](#)

Inferența cheie

- $se(\widehat{SR}) \approx \sqrt{(1 + \widehat{SR}^2/2)/T}$ pentru randamente i.i.d. Normale, pe perioadă [Lo \(2002\)](#); autocorelația schimbă factorul de anualizare
- Este portofoliul A mai bun decât $1/N$? Testăm $SR_A - SR_B = 0$ cu inferență HAC sau bootstrap studentizat [Ledoit & Wolf \(2008\)](#), nu prin compararea a două estimări punctuale

Rezultat din date

- Eșantioane de 60 de luni: Sharpe median în eșantion 1,57, Sharpe adevărat median 0,30
- 96% dintre portofoliile tangente estimate sunt de fapt mai slabe decât $1/N$

Duce la

- Bugetele de risc cer prognoze de volatilitate și de dependență (Capitolele 5–6)

Recapitulare: piețe, randamente și evaluare

- ▣ Întâi date curate: prețuri ajustate pentru ETF-uri și acțiuni, calendarul propriu al fiecărei serii, join pe prețuri înainte de randamente
- ▣ Faptele stilizate sunt reperul pentru orice model care urmează
- ▣ Testele de eficiență și de factori cer erori robuste și corecții pentru testarea multiplă
- ▣ Optimizarea amplifică eroarea de estimare: evaluați în afara eșantionului, față de $1/N$

Capitolul 5: Volatilitate condiționată: GARCH

Ideea principală

- Volatilitatea se grupează, deci șocul de azi prezice varianța de mâine [Engle \(1982\)](#), [Bollerslev \(1986\)](#)
- Persistență aproape de 1; asimetrie la acțiuni; inovații cu cozi groase

Inferența cheie

- QMLE: $\sqrt{T}(\hat{\theta} - \theta) \Rightarrow N(0, A^{-1}BA^{-1})$ (sandviș); erorile standard doar din hessiană sunt greșite pentru inovații non-Normale [Bollerslev & Wooldridge \(1992\)](#)
- Aproape de $\alpha + \beta = 1$, parametrul este lângă frontiera regiunii de staționaritate în covarianță: intervalele Wald nu sunt fiabile; folosiți verosimilitatea profil sau bootstrap restrâns la spațiul parametrilor [Andrews \(1999\)](#)

Rezultat din date

- S&P 500, 2000–2026: $\alpha + \beta = 0,9947$, un timp de înjumătățire de 131 de zile
- BET: CI 95% din verosimilitatea profil pentru $\alpha + \beta$ este $[0,975, 1]$ (IGARCH nu este respins): timpul de înjumătățire este de cel puțin 27 de zile, fără o limită superioară finită

Duce la

- $\hat{\sigma}_{t+1}$ este intrarea pentru VaR și ES filtrate (Capitolul 7)

Capitolul 6: Volatilitate multivariată și dependență

Ideea principală

- Corelațiile se schimbă odată cu regimul macroeconomic; diversificarea nu este garantată
- Copulele separă distribuțiile marginale de dependență; dependența în cozi determină pierderile comune

Inferența cheie

- DCC se estimează în doi pași: erorile standard din pasul al doilea trebuie să țină cont de volatilitățile din primul pas [Engle \(2002\)](#)
- Corelația în criză față de perioada calmă: ρ crește mecanic odată cu volatilitatea; testăm pe $\rho^* = \rho / \sqrt{1 + \delta(1 - \rho^2)}$, δ creșterea relativă a varianței [Forbes & Rigobon \(2002\)](#)

Rezultat din date

- SPY-TLT (ETF pe obligațiuni americane pe termen lung): ρ de la $-0,40$ la $0,11$ după 2022, deci un portofoliu 60/40 a trecut de la $10,4\%$ la $13,2\%$ volatilitate
- Corelația DCC Bitcoin-SPY: $0,04$ înainte de 2020, $0,31$ de atunci

Duce la

- VaR de portofoliu și contribuții Euler (Capitolul 7); risc sistemic (Capitolul 18)

Capitolul 7: VaR și Expected Shortfall

Ideea principală

- VaR este o cuantilă a pierderii, ES pierderea medie dincolo de ea; ES este coerent
- Simularea istorică filtrată și EVT condiționată reacționează la volatilitate în câteva zile [McNeil & Frey \(2000\)](#)

Inferența cheie

- VaR istoric, randamente i.i.d. cu densitate continuă $f(q_\alpha) > 0$: $\sqrt{T}(\hat{q}_\alpha - q_\alpha) \Rightarrow N(0, \alpha(1 - \alpha)/f(q_\alpha)^2)$; în coadă f este mică, deci estimarea este zgomotoasă; la dependență, $\alpha(1 - \alpha)$ devine dispersia de termen lung a indicatorilor $\mathbb{1}\{r_t \leq q_\alpha\}$
- ES face media celor mai mari αT pierderi: cu αT de câteva zeci și un indice de coadă în jur de 3, dispersia lui este dominată de una sau două zile

Rezultat din date

- S&P 500, zilnic: $\text{VaR}_{1\%}$ istoric = 3,45%, $\text{ES}_{1\%} = 5,01\%$
- Distribuția Normală dă doar 2,80%: cozile groase contează

Duce la

- O prognoză de risc este utilă doar dacă trece un backtest (Capitolul 8)

Capitolul 8: Backtesting și evaluarea prognozelor de risc

Ideea principală

- Testăm numărul și momentul depășirilor: acoperirea și independența Kupiec (1995), Christoffersen (1998)
- Ierarhizăm prognozele (VaR, ES) cu un scor consistent (FZ0) și teste Diebold–Mariano Fissler & Ziegel (2016)

Inferența cheie

- Kupiec $LR_{uc} \sim \chi_1^2$, Christoffersen $LR_{ind} \sim \chi_1^2$; testul DQ regresează $I_t - \alpha$ pe indicatorii depășirilor anterioare și VaR_t , $DQ \sim \chi_k^2$ Engle & Manganelli (2004)
- Puterea este mică: la $T = 250$, testul Kupiec de 5% detectează o rată reală de 2% doar în 24% din cazuri; comparăm modelele cu teste de capacitate predictivă condiționată Giacomini & White (2006)

Rezultat din date

- S&P 500, VaR 1%, 2007–2026: depășiri Normal 2,70%, HS 1,67%, FHS 1,23%, GARCH-EVT 1,13%
- Un filtru GARCH plus o coadă flexibilă câștigă pe toate cele patru piețe

Duce la

- Testele de comparare a prognozelor (DM, MCS), cu o funcție de pierdere potrivită, judecă și prognozele volatilității realizate; testele de acoperire judecă prognozele de cuantile, inclusiv pe cele din machine learning (Capitolele 9, 13, 14)

Recapitulare: volatilitate, dependență și risc

- ▣ GARCH transformă grupările de volatilitate în prognoze pentru ziua următoare
- ▣ Dependența este dinamică și cea mai puternică în cozi; corelațiile din criză cer o ajustare pentru volatilitate
- ▣ VaR și ES trebuie să combine un filtru de volatilitate cu o distribuție cu cozi groase
- ▣ Un model de risc este acceptat doar după teste de acoperire, independență și pentru ES

Capitolul 9: Volatilitate realizată

Ideea principală

- Prețurile intraday măsoară varianța zilnică (RV , Realised Variance, varianța realizată); modelul log-HAR (Heterogeneous AutoRegressive, autoregresiv heterogen) surprinde memoria ei lungă [Corsi \(2009\)](#)
- Randamentele împărțite la volatilitatea realizată au o distribuție apropiată de distribuția Normală

Inferența cheie

- Erorile HAR sunt heteroscedastice și, pentru ținte pe mai multe zile care se suprapun, autocorelate: folosiți erori standard HAC; prognozele se compară cu teste DM pe o funcție de pierdere robustă [Patton \(2011\)](#)
- Zgomotul de microstructură deplasează în sus RV la frecvențe înalte: estimatorii pe două scale elimină deplasarea [Zhang, Mykland & Aït-Sahalia \(2005\)](#)

Rezultat din date

- SPY: kurtosis 15,73 pentru randamentele de la deschidere la închidere, 2,65 după împărțirea la $\sqrt{RV_t}$
- log-HAR bate GARCH(1,1)- t în QLIKE cu 10% pentru SPY ($p = 0,021$) și cu 22% pentru Bitcoin

Duce la

- Intrări de volatilitate mai bune pentru VaR; microstructura explică zgomotul (Capitolul 10)

Capitolul 10: Microstructura pieței

Ideea principală

- Prețurile se formează în registre de ordine limită; spread-ul compensează costurile de procesare, riscul de inventar și selecția adversă
- Lichiditatea variază în funcție de ora din zi și de VIX și dispare în perioadele de stres

Inferența cheie

- Spread-ul Roll cere $\text{Cov}(\Delta p_t, \Delta p_{t-1}) < 0$; când covarianța de selecție este pozitivă, estimatorul nu este definit, deci raportați cât de des
- O primă de ilichiditate este o afirmație privind secțiunea transversală: Fama–MacBeth cu erori Newey–West și corecția Shanken [Shanken \(1992\)](#)

Rezultat din date

- Raportul Amihud (bp la 1 milion USD): SPY 0,0016, Banca Transilvania 24,7, Transelectrica 1024,0
- SPY: primul interval de 5 minute se mișcă de 2,06 ori mai mult decât unul de la prânz

Duce la

- Riscul de lichiditate în VaR și în alegerea datelor pentru proiect

Capitolul 11: Modele în timp continuu

Ideea principală

- Mișcarea browniană este limita măsurilor aleatoare; lema lui Itô rezolvă ecuațiile prețurilor
- Salturile explică cozile, volatilitatea stochastică explică grupările

Inferența cheie

- Normalitatea randamentelor log GBM: Jarque–Bera $\sim \chi^2_2$ respinge peste tot; salturile se testează cu variația bipower, $(RV - BV)$ standardizat $\Rightarrow N(0, 1)$
Barndorff-Nielsen & Shephard (2006)
- Testul este zilnic: pe multe zile, controlați numărul zilelor cu salturi false

Rezultat din date

- S&P 500 față de mișcarea browniană geometrică: 62 de zile dincolo de ± 4 abateri standard, față de 0,59 așteptate
- Indicele Hill al pierderilor S&P 500: 2,87 [2,07, 3,67] (Capitolul 16): momentul de ordinul patru este probabil infinit, spre deosebire de randamentele log Normale ale GBM

Duce la

- Evaluarea opțiunilor cere doar σ , nu și μ (Capitolul 12)

Capitolul 12: Opțiuni și suprafața de volatilitate

Ideea principală

- Black–Scholes evaluează opțiunile prin acoperire; volatilitatea implicită este estimarea pieței pentru σ [Black & Scholes \(1973\)](#)
- Zâmbetul și asimetria volatilității reflectă teama de prăbușiri

Inferența cheie

- VRP_t folosește varianța realizată din următoarele 21 de zile: valorile consecutive se suprapun, deci media cere erori Newey–West cu cel puțin 21 de întârzieri
- Volatilitatea implicită este o prognoză neutră la risc: prima, nu eroarea de prognoză, explică cea mai mare parte a diferenței

Rezultat din date

- 1990–2026: VIX mediu 19,4, volatilitatea realizată medie în luna următoare 15,3
- Prima de risc a varianței este pozitivă în 86% din zile, dar nu și în prăbușiri

Duce la

- Volatilitatea implicită ca variabilă pentru machine learning și ca indicator de stres (Capitolele 13, 18)

Recapitulare: frecvență înaltă, timp continuu și opțiuni

- ▣ Datele intraday măsoară volatilitatea; log-HAR o prognozează mai bine decât GARCH pe date zilnice
- ▣ Lichiditatea este un risc în sine și variază cu ordine de mărime între piețe
- ▣ Modelele în timp continuu sunt tratabile analitic, dar cele realiste cer salturi și volatilitate aleatoare
- ▣ Prețurile opțiunilor conțin informație despre viitor, inclusiv o primă de risc a varianței

Capitolul 13: Machine Learning în finanțe

Ideea principală

- Modele flexibile, dar semnal slab și mult zgomot; partea specifică finanțelor este procesul [López de Prado \(2018\)](#)
- Validare încrucișată cu purjare, meta-etichetare și raportul Sharpe deflatat [Bailey & López de Prado \(2014\)](#)

Inferența cheie

- Selecția dintre N strategii: raportul Sharpe deflatat testează $SR > E[\max_N \widehat{SR}]$ sub ipoteza absenței abilității [Bailey & López de Prado \(2014\)](#)
- Validarea încrucișată pe serii de timp trebuie să purjeze etichetele suprapuse și să impună embargo, altfel acuratețea este supraestimată

Rezultat din date

- K-fold amestecat raportează o acuratețe de 69,4% pe zgomot pur: scurgere de informație
- S&P 500: seria diferențiată fracționar devine staționară la $d^* = 0,25$; niciun model nu bate regula „mereu în creștere”

Duce la

- Deep learning și modele fundamentale, judecate la fel (Capitolul 14)

Capitolul 14: Deep learning și modele fundamentale pentru serii de timp

Ideea principală

- LSTM-urile (Long Short-Term Memory, rețele cu memorie pe termen lung și scurt) și Transformer-urile învață din secvențe; modelele fundamentale prognozează zero-shot
- Le evaluăm cu instrumentele din Capitolul 8, după publicarea ponderilor

Inferența cheie

- Testul DM pe diferențele QLIKE, cu dispersie HAC: $t_{DM} \Rightarrow N(0, 1)$ pentru comparații între modele neimbricate [Diebold & Mariano \(1995\)](#)
- Cu multe modele candidate, setul de modele de încredere controlează eroarea la nivel de familie [Hansen, Lunde & Nason \(2011\)](#)

Rezultat din date

- Volatilitatea realizată SPY, QLIKE: Chronos-2 0,231, log-HAR 0,234, GARCH-t 0,283; primele două nu diferă semnificativ
- VaR 1% brut Chronos-2 pe S&P 500: 1,67% depășiri

Duce la

- Textul ca date (Capitolul 15)

Capitolul 15: LLM-uri și analiza sentimentului

Ideea principală

- De la dicționare la FinBERT și la modelele lingvistice mari (Large Language Models, LLM): textul devine un număr
- Reprezentările vectoriale ale textului intră în modele ca variabile explicative

Inferența cheie

- Regresia predictivă $r_{t+1} = a + bS_t + \varepsilon_{t+1}$: un S_t persistent, cu inovații corelate cu randamentele, introduce un bias în $\hat{b}$ și distorsionează testul t [Stambaugh \(1999\)](#)
- Rezultatele clasificatorilor pe aceleași texte sunt pereche: comparăm acuratețile cu testul McNemar exact, nu prin două intervale separate

Rezultat din date

- Qwen 7B față de 1.5B pe titluri financiare: +21,5 puncte procentuale de acuratețe, McNemar $p < 0,001$
- O strategie pe sentimentul titlurilor: Sharpe +0,63 înainte și -1,48 după costuri; costul de echilibru 1,5 bp pe tranzacție

Duce la

- Sentimentul pe piețele crypto și în bule (Capitolele 16–17)

Capitolul 16: Active digitale și DeFi

Ideea principală

- Criptomonede formează o clasă de active distinctă în spațiul caracteristicilor din [Pele et al. \(2023\)](#), unde un factor de coadă le separă; indicii lor de coadă Hill nu sunt semnificativ mai mici decât cei ai acțiunilor sau ai aurului (Capitolul 16)
- Stablecoin-urile, formatorii automați de piață și ETF-urile spot leagă crypto de finanțele tradiționale

Inferența cheie

- Modele factoriale crypto: GRS și Fama–MacBeth cu corecția Shanken [Gibbons, Ross & Shanken \(1989\)](#), [Shanken \(1992\)](#); cozile groase cer versiuni HAC sau bootstrap
- Cozile: indici Hill cu intervale, nu kurtosis de selecție (Capitolul 1); o ruptură într-o corelație se testează cu dată necunoscută [Andrews \(1993\)](#)

Rezultat din date

- Legătura Bitcoin–S&P 500: sup-Wald 20,2 (valoarea critică de 5% 11,6), ruptura estimată pe 9 mar. 2020, nu la lansarea ETF-urilor din 2024
- Indicele Hill al pierderilor: Bitcoin 2,73 [2,12, 3,33], S&P 500 2,87 [2,07, 3,67]: nu se pot distinge statistic

Duce la

- Episoade de prețuri explozive (Capitolul 17)

Capitolul 17: Bule și crahuri

Ideea principală

- O bulă este o traiectorie a prețului care crește mai repede decât o pot justifica fundamentele
- Testele de rădăcină unitară pe coada din dreapta datează începutul și sfârșitul episoadelor explozive

Inferența cheie

- Sub ipoteza rădăcinii unitare, SADF și GSADF converg către funcționale ale mișcării browniene; valorile critice depind doar de fereastra minimă r_0 Phillips, Shi & Yu (2015)
- Schimbările de volatilitate distorsionează nivelul: valori critice din bootstrap sălbatic; controlați multiplicitatea datării

Rezultat din date

- Bitcoin 2014–2026 (săptămânal): GSADF 3,85 față de valoarea critică de 95% 2,27: sunt detectate episoade explozive
- Unul față de două regimuri Markov pentru Bitcoin: $LR = 123,2$, valoarea critică de 95% din bootstrap parametric 11,8 ($p = 0,005$)

Duce la

- Contagiunea de la o piață la întregul sistem (Capitolul 18)

Capitolul 18: Risc sistemic și rețele

Ideea principală

- Riscul sistemic: pierderile unei instituții care se propagă în tot sistemul
- CoVaR (VaR-ul sistemului condiționat de dificultățile unei instituții), SRISK și rețelele de contagiune măsoară contribuția fiecărei instituții

Inferența cheie

- Diferențele de ΔCoVaR dintre bănci: teste pe perechi pe extrageri bootstrap comune pe blocuri, cu corecția Holm; la $\alpha = 1\%$ doar aproximativ 40 de zile în coadă, deci probleme de cuantile extreme
- SRISK în forma publicată: LRMES simulat din GJR-GARCH + DCC [Brownlees & Engle \(2017\)](#); tabelele de conectivitate cer intervale bootstrap și modele VAR cu shrinkage

Rezultat din date

- ΔCoVaR 1% pentru unsprezece bănci: 4 din 25 de perechi din aceeași regiune diferă la 5%, 0 după Holm; simpla suprapunere a intervalelor nu ar fi ordonat niciuna
- LRMES simulat (22 de zile, piața sub -10%): JPMorgan 10,6% azi, 23,7% cu informația din 31 martie 2020

Duce la

- Teste de stres și proiectele de echipă

Recapitulare: învățare, text și piețe noi

- ▣ Modelele flexibile cer un proces strict: purjare, embargo, măsuri de performanță deflatate
- ▣ Modelele fundamentale nu diferă semnificativ de reperele puternice pentru volatilitate și nu înlocuiesc FHS cu filtru GARCH pentru riscul de coadă
- ▣ Textul, cripto, bulele și riscul sistemic folosesc același set de instrumente statistice
- ▣ Date noi și modele noi: se aplică aceleași cinci întrebări

Șase capcane care au revenit în fiecare capitol

Capcane de concepție

- ▣ **Informație din viitor:** date de după t folosite la momentul t
- ▣ **Supraajustare:** un model calibrat pe eșantionul pe care este judecat
- ▣ **Testare multiplă:** cea mai bună dintre multe încercări raportată ca și cum ar fi singura

Capcane de date și inferență

- ▣ **Join greșit pe calendar:** randamente calculate înainte de alinierea activelor
- ▣ **Cozi groase ignorate:** erori standard care presupun distribuția Normală și independența
- ▣ **Funcție de pierdere greșită:** una care nu poate ierarhiza prognozele pentru mărimea vizată

Capcana 1: informația din viitor

- ▣ Estimarea oricărui parametru, prag sau factor de scalare pe tot eșantionul introduce informație din viitor
 - ▶ Exemple: parametri GARCH din tot eșantionul, standardizare pe tot eșantionul, etichete care se suprapun cu setul de test
- ▣ BET, VaR 1%, 2005–2026: GARCH- t cu parametri din tot eșantionul este depășit în 1,31% din zile, cu estimare pe fereastră mobilă în 1,47%
 - ▶ Varianta cu informație din viitor pare mai bună decât ar fi putut face orice prognozator în timp real
- ▣ Capitolul 13: K-fold amestecat raportează o acuratețe de 69,4% pe zgomot pur
- ▣ Remediu: ferestre mobile sau în extindere; purjare și embargo; scrieți mulțimea de informație $\mathcal{F}_{t-1}$ lângă fiecare prognoză

Capcana 2: supraajustarea

- ▣ Ajustarea în eşantion răsplăteşte zgomotul, care nu se va repeta
 - ▶ Capitolul 4: Sharpe în eşantion 1,57, Sharpe adevărat 0,30 pentru aceleaşi portofolii
- ▣ Supraajustarea backtest-ului: încercăm multe strategii şi o păstrăm pe cea mai bună [Bailey et al. \(2017\)](#)
 - ▶ Raportul Sharpe deflatat corectează pentru numărul de încercări şi pentru randamentele non-normale [Bailey & López de Prado \(2014\)](#)
- ▣ Remediul: fixaţi designul înainte de a vă uita la perioada de test; raportaţi toate modelele încercate; comparaţi cu un reper simplu ($1/N$, simulare istorică, mers aleator, log-HAR)

Capcana 3: testarea multiplă

- Capitolul 3: din 300 de factori fără valoare, în medie 15,0 trec de $|t| > 1,96$, iar cel mai bun ajunge la $|t| \approx 3,06$
 - ▶ De aceea literatura despre factori cere $|t| > 3$ [Harvey, Liu & Zhu \(2016\)](#)
- Anomalii de calendar, reguli de tranzacționare, specificații de model: fiecare test în plus adaugă o șansă de descoperire falsă
- Remediul: numărați testele și corecții
 - ▶ Bonferroni și Holm controlează probabilitatea oricărei descoperiri false; Benjamini–Hochberg controlează ponderea lor
 - ▶ Pentru prognoze: setul de modele de încredere (MCS) în locul multor teste pe perechi [Hansen, Lunde & Nason \(2011\)](#)

Capcana 4: join pe randamente în loc de prețuri

- Bitcoin se tranzacționează zilnic, SPY doar în zilele lucrătoare
 - ▶ Greșit: calculăm fiecare randament pe calendarul propriu, apoi păstrăm zilele comune: mișcările Bitcoin din weekend dispar
 - ▶ Corect: păstrăm zilele comune ale **prețurilor**, apoi calculăm randamentele: ziua de luni acoperă intervalul vineri–luni pentru ambele
- Bitcoin, 2020–2026, în zilele comune: randament cumulat 1025% (corect) față de 680% (greșit)
 - ▶ Abaterea standard a zilei de luni 5,04% (corect) față de 3,83% (greșit): join-ul greșit ascunde riscul din weekend
- Remediu: aliniați întâi prețurile pe zilele comune; o serie singură rămâne pe calendarul propriu

Capcana 5: cozile groase ignorate în inferență

- Erorile standard clasice presupun independență și momente de ordinul patru finite
 - ▶ Pierderile BET: indicele de coadă Hill $\hat{\alpha} = 2,39$, CI 95% prin bootstrap pe blocuri [2,12, 3,03] Hill (1975): cu $\alpha < 4$, kurtosis-ul populației este infinit
 - ▶ Deci kurtosis-ul de selecție (11,1) nu estimează nimic, iar un interval bootstrap pentru el nu este valid Athreya (1987): raportați indicele de coadă
- Persistența GARCH pentru BET: CI Wald [0,974, 1,007] trece de frontiera staționarității $\alpha + \beta = 1$, unde aproximarea Normală nu mai funcționează Andrews (1999)
 - ▶ CI din verosimilitatea profil, în spațiul parametrilor $p \leq 1$: [0,975, 1] (IGARCH, $p = 1$, nu este respins față de valoarea critică la frontieră 2,71 efAndrewsB), deci timpul de înjumătățire este de cel puțin 27 de zile și nu are o limită superioară finită
- Remediu: erori robuste (HAC), bootstrap pe blocuri acolo unde este valid, indici de coadă în loc de kurtosis, intervale care respectă frontiera

Capcana 6: o funcție de pierdere care nu poate clasifica ținta

- Prognozele de varianță se compară cu o aproximare zgomotoasă (r_t^2 sau RV_t)
 - ▶ Cu o aproximare condiționat nedeplasată a varianței condiționate (de exemplu r_t^2 pentru un randament de medie zero sau RV), MSE și QLIKE ierarhizează prognozele după pierderea așteptată la fel ca varianța adevărată; QLIKE depinde doar de raportul aproximare/prognoză, deci zilele volatile cântăresc mai puțin decât la MSE [Patton \(2011\)](#)
 - ▶ Capitolul 9: log-HAR bate GARCH în QLIKE; comparația în MSE nu este concludentă
- ES singur nu are o funcție de scor strict consistentă pe clasele largi obișnuite de distribuții; perechea (VaR, ES) are, în condiții slabe [Fissler & Ziegel \(2016\)](#)
 - ▶ Folosiți FZ0 cu teste Diebold–Mariano [Diebold & Mariano \(1995\)](#); precizia are limite în eșantioane finite [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)
- Remediu: alegeți funcția de pierdere înainte de comparație și precizați-o în raportul proiectului

Recapitulare: o listă de verificare împotriva capcanelor

Design

- ▣ Orice prognoză folosește doar $\mathcal{F}_{t-1}$
- ▣ Perioada de test fixată dinainte și folosită o singură dată
- ▣ Toate modelele încercate sunt raportate; testele sunt numărate

Date și inferență

- ▣ Prețurile aliniate înainte de calcularea randamentelor; ajustările și calendarele documentate
- ▣ Incertitudine robustă sau bootstrap pentru fiecare cifră principală
- ▣ Funcție de pierdere consistentă pentru țintă; comparație cu un reper simplu

O întrebare, patru capitole

Întrebarea

- Cât poate pierde mâine o poziție pe indicele BET, cu probabilitatea de 1%?
- Ce prognoză a acestei pierderi am fi putut crede în timp real, în 2005–2026?

Date

- Indicele BET, valori oficiale zilnice de închidere, 6 ian. 2000 – 18 sept. 2026: 6 670 de randamente log zilnice
- Eliminate înregistrările duplicate (rânduri identice cu cel anterior) și rândurile datate în weekend; zilele de tranzacționare cu închidere neschimbată se păstrează

Cei patru pași


- Capitolul 1: fapte stilizate, cu inferență robustă
- Capitolul 5: GARCH(1,1) cu inovații Student- t
- Capitolul 7: VaR 1% pentru o zi, din patru modele
- Capitolul 8: acoperire, independență și zonele Basel



Palatul Bursei, București (2023)

Foto: Chainwit. (2023); CC BY 4.0; Wikimedia Commons

Pasul 1: faptele stilizate ale BET




□ Stânga: cuantilele randamentelor standardizate față de distribuția Normală; dreapta: autocorelațiile r_t și $|r_t|$, decalaje 1–50

Interpretarea pasului 1

- ▣ Cozi groase: indicele Hill al pierderilor $\hat{\alpha} = 2,39$ (CI 95% prin bootstrap pe blocuri $[2,12, 3,03]$, $k = 153$); sub 4, deci kurtosis-ul nu este raportat ca estimare
 - ▶ 51 de zile dincolo de ± 4 abateri standard, față de 0,42 așteptate sub distribuția Normală
 - ▶ Cea mai proastă zi: $-13,1\%$ (log) pe 7 ian. 2009
- ▣ Grupări: autocorelația de ordinul 1 a $|r_t|$ este 0,40 și scade lent; statistica Ljung–Box $Q(10)$ pe r_t^2 este 2440
 - ▶ Randamentele au autocorelația de ordinul 1 de 0,11: BET este mai puțin lichid decât piețele mari (Capitolele 2, 10)
- ▣ Consecință: un VaR Normal cu volatilitate constantă va fi prea mic în stres și prea mare în perioadele calme

Pasul 2: volatilitatea GARCH(1,1)- t



- Randamentele log zilnice ale BET cu $\pm 2\hat{\sigma}_t$ dintr-un GARCH(1,1) cu inovații Student- t , estimat pe 2000–2026

Interpretarea pasului 2

- ▣ Estimări (erori standard robuste): $\hat{\alpha} = 0,192$ (0,025), $\hat{\beta} = 0,799$ (0,024), $\hat{\nu} = 5,01$
 - ▶ $\hat{\nu} \approx 5$: chiar după filtrare, șocurile au cozi groase
- ▣ Persistența $\hat{\alpha} + \hat{\beta} = 0,9907$: un timp de înjumătățire de aproximativ 74 de zile de tranzacționare
 - ▶ CI 95% din verosimilitatea profil $[0,975, 1]$: persistența nu poate fi separată de 1 (Capcana 5)
- ▣ Volatilitatea zilnică maximă 7,39% pe 15 oct. 2008; la finalul eșantionului 1,67%

Pasul 3: patru prognoze VaR 1%

Necondiționate (ultimele 500 de zile)

- ▣ **HS:** pierderea $L = -r$ depășită în 1% din ultimele 500 de zile (cuantila empirică)
- ▣ **Normal:** $\text{VaR} = -(\hat{\mu} + \hat{\sigma} z_{0,01})$, $z_{0,01} = -2,326$


Condiționate (GARCH- t pe ultimele 1000 de zile)

- ▣ **GARCH- t :** $\text{VaR}_t = -(\hat{\mu} + \hat{\sigma}_t t_\nu^{-1}(0,01) \sqrt{(\nu - 2)/\nu})$
- ▣ **FHS:** $\text{VaR}_t = -(\hat{\mu} + \hat{\sigma}_t \hat{q}_{0,01}(z))$, cuantila de 1% a reziduurilor standardizate [McNeil & Frey \(2000\)](#)

Design în timp real

- ▣ Prognoza pentru ziua t folosește doar datele până la $t - 1$
- ▣ GARCH reestimat la fiecare 21 de zile de tranzacționare; $\hat{\sigma}_t$ actualizat zilnic
- ▣ Evaluare: 3 ian. 2005 – 18 sept. 2026, $T = 5\,432$ zile
- ▣ Depășiri așteptate la 1%: aproximativ 54

Pasul 3: pierderi și VaR 1%, 2020–2026




□ Pierderile zilnice ale BET (câștigurile puse la 0), VaR 1% Normal și FHS; puncte negre: pierderi peste VaR FHS

Interpretarea pasului 3

- FHS reacționează în câteva zile: a atins 11,6% pe 18 mar. 2020, în timpul prăbușirii din pandemia COVID-19
 - ▶ VaR Normal pe o fereastră de 500 de zile se mișcă doar lent
- 2020–2026 (1 675 de zile, aproximativ 17 depășiri așteptate): FHS 22 de depășiri, Normal 41
 - ▶ Depășirile Normal se grupează în primele săptămâni ale fiecărui episod de stres
- Ultima prognoză din eșantion: FHS 4,48%, Normal 2,18%: modelele diferă cel mai mult când volatilitatea se schimbă

Pasul 4: ratele depășirilor




- Ponderea zilelor cu pierdere peste prognoza VaR 1%, 2005–2026; banda gri: intervalul binomial de 95% dacă rata adevărată este 1%

Interpretarea pasului 4: acoperire și independență

Model	Depășiri	Rata	p_{uc}	p_{ind}	p_{cc}	Zona roșie
HS	79	1,45%	0,002	<0,001	<0,001	5,5%
Normal	122	2,25%	<0,001	<0,001	<0,001	18,6%
GARCH-t	80	1,47%	0,001	0,864	0,005	0,0%
FHS	67	1,23%	0,095	0,267	0,134	0,0%


- p_{uc} : testul de acoperire Kupiec; p_{ind} : testul de independență Christoffersen; p_{cc} : ambele împreună [Kupiec \(1995\)](#), [Christoffersen \(1998\)](#)
- Zona roșie: ponderea ferestrelor de 250 de zile cu cel puțin 10 depășiri (semaforul Basel)
- Doar FHS nu este respins de niciunul dintre cele trei teste la 5%; HS și Normal pică și testul de independență: depășirile lor se grupează
- GARCH-t: independența nu este respinsă, dar depășirile sunt prea multe: coada Student-t nu este suficient de groasă la 1%

Pasul 4: depășirile din ultimele 250 de zile



- Numărul depășirilor pe o fereastră mobilă de 250 de zile, cu zonele Basel verde, galbenă și roșie
- Modelul Normal petrece 18,6% din ferestre în zona roșie, HS 5,5%, cele două modele cu filtru GARCH niciodată

Capcana informației din viitor în studiul de caz



- Cuanțila HS din tot eșantionul: 1,01% depășiri, prin construcție; GARCH- t din tot eșantionul: 1,31%
- Ambele par mai bune decât versiunile în timp real: diferența este valoarea unei informații pe care nimeni nu o avea

Pasul 5: compararea formală a celor patru modele


- **Testul Dynamic Quantile:** regresăm $I_t - 0,01$ pe o constantă și indicatorii depășirilor din cele patru zile anterioare și VaR_t ; $DQ \sim \chi^2_6$ Engle & Manganelli (2004)
 - ▶ Detectează depășirile previzibile din trecut sau din nivelul VaR, pe care testul Christoffersen (o întârziere) le poate rata
- **Scorul FZ0** pentru perechea (VaR 2,5%, ES 2,5%), $v = -\text{VaR}$, $e = -\text{ES}$, randamentul y :
$$S = -\frac{\mathbf{1}_{\{y \leq v\}}(v-y)}{\alpha e} + \frac{v}{e} + \ln(-e) - 1$$
 Patton, Ziegel & Chen (2019)
 - ▶ Consistent pentru (VaR, ES) Fissler & Ziegel (2016); teste Diebold–Mariano pe perechi, cu dispersie HAC Diebold & Mariano (1995); setul de modele de încredere la 10% Hansen, Lunde & Nason (2011)
- **Verificarea ES:** comparativă, față de HS ca model standard; roșu dacă modelul este semnificativ mai slab, verde dacă este semnificativ mai bun, galben altfel Nolde & Ziegel (2017)
 - ▶ Toate prognozele folosesc doar datele până la $t - 1$; 5 432 de zile, 3 ian. 2005 – 18 sept. 2026

Pasul 5: rezultate

Model	DQ	p_{DQ}	FZ0	p_{MCS}	Zona ES
HS	192,1	$<0,001$	1,424	0,00	standard
Normal	364,6	$<0,001$	1,495	0,00	roșu
GARCH-t	17,9	0,007	1,175	0,18	verde
FHS	9,9	0,129	1,157	1,00	verde

- Doar FHS trece testul DQ la 5% ($p = 0,129$); GARCH-t îl pică ($p = 0,007$) prin excesul de depășiri
- FZ0: FHS și GARCH-t nu diferă semnificativ (DM $t = 1,39$), ambele bat HS și Normal ($|t| > 4,9$); setul de modele de încredere la 10% este {GARCH-t, FHS}
- Verificarea comparativă a ES: Normal roșu, GARCH-t și FHS verzi: clasamentul din Pasul 4 rezistă inferenței formale

Cât poate detecta un backtest? Puterea testului Kupiec



- Probabilitatea binomială exactă ca testul Kupiec de 5% să respingă un model VaR 1%, în funcție de rata reală a depășirilor, pentru $T = 250$, 1000 și 5432 de zile

Interpretarea curbelor de putere

- $T = 250$ (un an Basel): o rată reală de 2% este detectată doar în 24% din cazuri; respingerea cere 0 sau cel puțin 7 depășiri
 - ▶ Rata minimă detectabilă cu putere de 80%: 3,65% la $T = 250$, 2,05% la $T = 1\,000$, 1,45% la $T = 5\,432$
- Studiul nostru de caz, $T = 5\,432$: o rată reală de 1,3% ar fi detectată doar cu probabilitatea 55%
- O nerespingere cu putere mică înseamnă „nicio dovadă”, nu „nicio problemă”: precizați puterea înaintea testului

Recapitulare: studiul de caz

- ▣ BET prezintă toate faptele stilizate: cozi groase, grupări, o anumită autocorelație liniară
- ▣ GARCH- t surprinde grupările; reziduurile filtrate au încă cozi groase
- ▣ Un filtru GARCH cu o coadă empirică (FHS) este singurul VaR 1% care trece testele de acoperire, independență și DQ; împreună cu GARCH- t formează setul de modele de încredere pentru (VaR, ES)
- ▣ Designul în timp real contează: estimările pe tot eșantionul înfrumusețează orice model
- ▣ Aceiași patru pași sunt un șablon pentru proiectul vostru

Ce este proiectul

- ▣ Un studiu empiric al unei întrebări despre piețele financiare, cu metodele acestui curs
 - ▶ Echipe; patru pași: replicare, extindere, livrare pe GitHub, prezentare și susținere (slide-ul următor)
- ▣ Reprezintă **70%** din nota finală; quiz-urile și activitatea la seminar 20%, prezența 10%
- ▣ Puncte de plecare: întrebarea din Partea C a fiecărui seminar (secțiunea următoare)
 - ▶ O întrebare proprie este binevenită dacă trece de cele cinci întrebări din acest capitol
- ▣ Un proiect bun se poate încheia cu un răspuns negativ, dacă dovezile sunt oneste și precise

Proiectul în patru pași

- 1. **Replicați:** reproduceți un tabel sau o figură întreagă dintr-un articol publicat (sau din curs), celulă cu celulă
 - ▶ Raportați diferența pentru fiecare celulă și explicați-o; un asistent AI nu poate ghici un tabel publicat
- 2. **Extindeți:** date noi, altă piață (BVB, crypto) sau un eșantion mai recent, după un **plan de analiză** salvat înainte de a deschide perioada de test
 - ▶ Planul precizează ipoteza nulă, testul, funcția de pierdere, împărțirea eșantionului, strategia de identificare, puterea testului principal și grila de specificații cu corecția ei
- 3. **Livrați pe GitHub:** cod, fișier de versiuni, seed-uri fixate, proveniența datelor; un singur notebook regenerează fiecare cifră
 - ▶ `AI_USE.md` și `AI_ERRORS.md` sunt obligatorii; raportul este un articol de 8–12 pagini
- 4. **Prezentați și susțineți:** prezentarea echipei, apoi o susținere orală de 10 minute
 - ▶ Fiecare membru explică un rezultat și răspunde la o întrebare de tipul „ce se schimbă dacă...”; notele pot diferi între membri

Standardul de replicare

- Ținta: un tabel sau o figură întreagă, cu DOI, pagină și numărul tabelului, nu un singur coeficient
 - ▶ Raportați o comparație celulă cu celulă: valoarea publicată, valoarea voastră, diferența și motivul fiecărei abateri (eșantion, filtru, sursa datelor, definiție)
- Replicările la scară mare arată de ce: multe anomalii se micșorează în afara eșantionului sau cu date mai bune [Hou, Xue & Zhang \(2020\)](#), iar majoritatea factorilor se replică atunci când designul este corect [Jensen, Kelly & Pedersen \(2023\)](#)
- Reproducibilitate: un fișier cu versiunile pachetelor, seed-uri aleatoare fixate, numele seriilor și datele lor, o singură comandă care regenerează fiecare cifră
 - ▶ Rezultatele unor echipe diferite care analizează aceleași date diferă mai mult decât sugerează erorile lor standard [Menkveld et al. \(2024\)](#): codul reproductibil reduce diferența

Identificarea: de la corelație la o afirmație

- Întrebările despre evenimente („au schimbat ETF-urile spot, reclasificarea FTSE sau o taxă bancară mărimea X ?”) cer un contrafactual
 - ▶ O piață de control neafectată de eveniment: diferența în diferențe pe măsura de risc
 - ▶ Un control sintetic construit din mai multe piețe neafectate de eveniment [Abadie, Diamond & Hainmueller \(2010\)](#); date placebo ale evenimentului (de ex. $\pm$ un an)
- Moment necunoscut: un test sup-Wald de ruptură [Andrews \(1993\)](#); raportați data estimată a rupturii, nu una impusă
- Întrebările de prognoză: doar în afara eșantionului, cu o perioadă de test declarată în plan
- Un singur eveniment înseamnă $n = 1$: spuneți ce poate și ce nu poate identifica designul

Puterea și efectul minim detectabil

- Înainte de testul principal, calculați cel mai mic efect pe care designul îl poate detecta cu putere de 80% la 5%
 - ▶ Kupiec pe 250 de zile nu poate deosebi un model VaR 1% de unul cu 2%: puterea 24%; rata minimă detectabilă 3,65% (Pasul 5)
- Livrabil: o curbă de putere simulată pentru testul principal la T -ul vostru, sub ipoteza nulă și sub alternativa care vă interesează
- Eșantioanele scurte de crypto, ETF-uri sau ferestre de după eveniment fac constrângerea reală: multe întrebări de proiect au putere mică
- O nerespingere cu putere mică înseamnă „nicio dovadă”, nu „niciun efect”

Robustețe fără p-hacking

- Planul de analiză este un commit datat în repository, făcut înainte de deschiderea perioadei de test
- Curba specificațiilor: estimați fiecare combinație justificabilă de fereastră, întârzieri, α și început al eșantionului; reprezentați toate estimările ordonate, cu intervalele lor [Simonsohn, Simmons & Nelson \(2020\)](#)
 - ▶ Raportați dispersia pe specificații, nu celula cea mai bună
- Corecții familia: Holm pentru orice descoperire falsă, Benjamini–Hochberg pentru ponderea lor sau un bootstrap de tip reality check
 - ▶ Descoperiri false și ratate în finanțe [Harvey & Liu \(2020\)](#); perspectiva științifică a domeniului [Harvey \(2017\)](#)

Evaluarea prognozelor în proiectele despre risc

- Volatilitate: comparăm prognozele cu o aproximare zgomotoasă, dar condiționat nedeplasată, doar printr-o funcție de pierdere robustă (MSE sau QLIKE) [Patton \(2011\)](#)
 - ▶ Multe modele: setul de modele de încredere [Hansen, Lunde & Nason \(2011\)](#), nu cea mai mică pierdere medie
- VaR: acoperire, independență și testul DQ [Engle & Manganelli \(2004\)](#); cu un reper, teste de capacitate predictivă condiționată [Giacomini & White \(2006\)](#)
 - ▶ Precizați puterea fiecărui backtest la T -ul vostru
- ES: evaluăm perechea (VaR, ES) cu scorul FZ0; verificări comparative cu trei zone [Nolde & Ziegel \(2017\)](#); modele dinamice pentru (VaR, ES) [Patton, Ziegel & Chen \(2019\)](#)
 - ▶ Studiul de caz integrat (Pașii 1–5) este șablonul

Alegerea întrebării

O întrebare bună este

- ▣ **Specifică:** o piață, o perioadă, o mărime
- ▣ **Testabilă:** o ipoteză nulă și un reper
- ▣ **Fezabilă:** date pe care le puteți obține și curăța în câteva săptămâni
- ▣ **Relevantă:** răspunsul contează pentru un investitor, o bancă sau o autoritate

Exemple

- ▣ Prea vagă: „Este Bitcoin riscant?”
 - ▶ Mai bună: „Au schimbat ETF-urile spot VaR 1% pe o zi al Bitcoin și ce model îl prognozează cel mai bine din 2024?”
- ▣ Prea largă: „Poate machine learning să prezică piața?”
 - ▶ Mai bună: „Bate un model de boosting modelul log-HAR pentru volatilitatea BET de a doua zi, în QLIKE, 2018–2026?”

Date

- Folosiți datele cursului unde se poate: serii zilnice pentru indici, ETF-uri, acțiuni BVB, crypto și cursuri de schimb, plus date intraday
 - ▶ Surse publice: cursurile de referință BNR, FRED, Kenneth French Data Library, DefiLlama; arhiva BVB pentru indicii românești
- Aplicați convențiile cursului
 - ▶ Prețuri ajustate pentru ETF-uri și acțiuni, valori de închidere pentru indici, cursuri de schimb și crypto
 - ▶ Eliminați zilele de sărbătoare completate și cotațiile de weekend unde piața este închisă; anualizați cu frecvența reală
 - ▶ Mai multe active: join pe prețuri, apoi calculați randamentele
- Căutați valorile eronate înainte de modelare: salturile de $\pm 50\%$ în prețurile ajustate sunt de obicei erori de date

Metode: de la întrebare la capitol

Dacă întrebarea este despre	Porniți de la
Distribuția randamentelor, cozi, predictibilitate	Capitolele 1–2: momente, teste robuste, rapoarte ale varianțelor
Randamente așteptate, factori, portofolii	Capitolele 3–4: Fama–MacBeth, shrinkage, teste Sharpe în afara eșantionului
Volatilitate și corelație	Capitolele 5, 6, 9: GARCH, DCC, copule, log-HAR
Măsurile de risc și capital	Capitolele 7–8: FHS, EVT, backtest-uri, FZ0
Lichiditate, opțiuni, timp continuu	Capitolele 10–12: Amihud, Black–Scholes, VIX, prima de risc a varianței
Prognoză cu ML, deep learning sau text	Capitolele 13–15: CV cu purjare, modele fundamentale, sentiment
Cripto, bule, risc sistemic	Capitolele 16–18: stablecoin-uri, GSADF, CoVaR, rețele

Lista de verificare pentru o evaluare onestă

Înainte să vă uitați la rezultate

- Scrieți ipoteza, reperul și funcția de pierdere
- Fixați fereastra de estimare și perioada de test
- Decideți câte modele și parametri veți încerca și corecția pentru ei
- Scrieți strategia de identificare și puterea testului principal

Când raportați

- Doar rezultate în afara eșantionului pentru afirmații despre prognoză
- Fiecare cifră principală cu eroare standard, CI sau p -valoare
- Costuri pentru strategiile de tranzacționare; subperioade și o a doua piață pentru robustețe
- Ce **nu** a funcționat și de ce

Raportul: un articol de 8–12 pagini

- **1. Introducere:** întrebarea, ipoteza și contribuția; **2. Literatură:** 10–15 referințe cu link, cel puțin 3 din ultimii cinci ani, inclusiv [Franke, Härdle & Hafner \(2019\)](#), [McNeil, Frey & Embrechts \(2015\)](#)
- **3. Date și replicare:** surse, perioadă, reguli de curățare; tabelul replicat, celulă cu celulă
- **4. Design:** planul de analiză, strategia de identificare, puterea, reperul, funcția de pierdere și testele
- **5. Rezultate:** tabele și grafice cu incertitudine; **6. Robustețe:** curba specificațiilor cu corecția pentru testele multiple; **7. Concluzie:** răspunsul într-o frază și limitele lui
- **Cod:** un repository GitHub al cărui README și notebook reproduc fiecare cifră, cu [AI_USE.md](#) și [AI_ERRORS.md](#)

Prezentarea

Structura (aproximativ 12 minute)

- ▣ Întrebarea și de ce contează (1 slide)
- ▣ Datele și un grafic care arată problema (2 slide-uri)
- ▣ Metoda și reperul (2 slide-uri)
- ▣ Rezultatul principal cu incertitudinea lui (2–3 slide-uri)
- ▣ Robustețe, limitări, răspuns (2 slide-uri)

Bune practici

- ▣ Un mesaj pe slide; grafice cu axe lizibile și legenda dedesubt
- ▣ Fiecare membru al echipei prezintă și poate răspunde la întrebări despre cod
- ▣ Apoi o susținere orală de 10 minute: fiecare membru explică un rezultat și răspunde la o întrebare „ce se schimbă dacă...”, fără AI

Evaluarea proiectului (70% din nota finală)

Componentă	Ce urmărim
Replicare (pasul 1)	Un tabel sau o figură publicată reprodusă celulă cu celulă; fiecare diferență explicată
Întrebare, date și extindere (pasul 2)	Întrebare specifică și testabilă; date documentate și calendare aliniate
Metode și inferență	Plan de analiză, strategie de identificare, putere, design în timp real, reper, curba specificațiilor cu corecție pentru testele multiple
Interpretare și raport	Semnificație economică, limitări, concluzie onestă; un articol de 8–12 pagini cu 10–15 referințe
Repository GitHub (pasul 3)	O singură comandă reproduce fiecare rezultat (fișier de versiuni, seed-uri); AI_USE.md, AI_ERRORS.md
Prezentare și susținere orală (pasul 4)	Individual: un rezultat explicat, răspunsuri la „ce se schimbă dacă...”
Total	70% din nota finală; plus quiz-uri și activitate (20%) și prezență (10%)

□ Notele pot diferi între membrii echipei, în funcție de susținerea orală

Calendar

- ▣ Săptămâna 1 după acest capitol: echipa și întrebarea
 - ▶ Trimiteți o propunere de o pagină (șablonul din Seminarul 19, Partea C); deschideți repository-ul GitHub
- ▣ Săptămânile 2–3: datele, replicarea unui tabel sau a unei figuri publicate (pasul 1) și planul de analiză salvat în repository
- ▣ Săptămânile 4–5: extindere, evaluare, robustețe (pasul 2); feedback la seminar
- ▣ Ultimele săptămâni: repository-ul cu README și cele două fișiere AI (pasul 3); prezentarea și susținerea orală (pasul 4)
- ▣ Datele exacte se anunță la curs și la seminar

Unde pierd de obicei puncte proiectele

- ▣ O întrebare care se schimbă după ce se cunosc rezultatele
- ▣ Ajustarea în eșantion prezentată drept putere de prognoză
- ▣ Niciun reper sau un reper slab, ales ca să fie bătut
- ▣ Cifre fără incertitudine; multe teste fără corecție
- ▣ Grafice fără unități, legende peste date, acronime neexplicate
- ▣ Cod care nu rulează sau cifre din raport pe care codul nu le produce
- ▣ Rezultate AI păstrate fără verificare: utilizare nedeclarată, cod neverificat, referințe care nu există

Recapitulare: proiectul de echipă

- ▣ O întrebare specifică și testabilă; un reper; o funcție de pierdere aleasă dinainte
- ▣ Date curate după convențiile cursului; design în timp real; raportare onestă
- ▣ Replicare, extindere, livrare pe GitHub, prezentare și susținere: 70% din notă

Politica AI a cursului

- ▣ **Permis:** asistenți AI pentru cod, depanare, căutarea literaturii și redactare, în proiect și la seminar
- ▣ **Declarat:** fiecare instrument, pentru ce a fost folosit și ce ați verificat voi, în [AI_USE.md](#)
 - ▶ Utilizarea nedeclarată a AI este tratată ca plagiat
- ▣ **Verificat:** răspundeți pentru fiecare rând de cod și de text
 - ▶ „L-a scris AI-ul” nu este o explicație la susținerea orală
 - ▶ Fiecare referință are nevoie de un DOI sau link funcțional; o referință care nu există este tratată ca date fabricate
- ▣ **Fără AI la susținerea orală:** răspundeți singuri, pe baza propriei înțelegeri a proiectului

Cele două fișiere obligatorii

AI_USE.md: declarația

- Instrumentele: nume, versiune, cine le-a folosit și pentru ce
- Fișierele sau secțiunile în care ați păstrat cod sau text scris de AI și ce ați schimbat
- Cum ați verificat tabelul replicat, datele, formulele și referințele
- Ce a făcut echipa fără AI

- Șabloane în engleză și română: github.com/danpele/MFM/tree/main/project

AI_ERRORS.md: jurnalul erorilor

- Cel puțin **trei** locuri în care asistentul a greșit
- Pentru fiecare: ce ați întrebat, ce a răspuns, ce era greșit, cum v-ați dat seama, varianta corectă
- Erorile prinse sunt un punct forte al proiectului, nu unul slab

Erori AI tipice în modelarea financiară (1/2)

- **Informație din viitor:** o statistică pe fereastră mobilă sau o scalare care include ziua t în prognoza pentru ziua t
 - ▶ Verificare: schimbați ultima observație; prognoza pentru acea zi nu trebuie să se miște; decalați cu o zi (`.shift(1)`)
- **Semnul VaR:** cuantila 1% a randamentelor raportată drept VaR sau cuantila 99% a randamentelor (un câștig) folosită ca pierdere
 - ▶ Verificare: $\text{VaR}_\alpha = -q_\alpha(r) > 0$ pentru o pierdere; VaR 1% pe o zi al unui indice este de câteva procente, nu negativ
- **Anualizare:** volatilitatea zilnică înmulțită cu 252 în loc de $\sqrt{252}$ sau 252 de zile folosite pentru crypto, care se tranzacționează zilnic
 - ▶ Verificare: mediile se scalează cu h , volatilitățile cu $\sqrt{h}$; folosiți numărul real de zile de tranzacționare (365 pentru crypto)

Erori AI tipice în modelarea financiară (2/2)

- ❑ **Validare încrucișată (CV) aleatoare pe serii de timp:** K-fold amestecat învață din viitor; în Capitolul 13 raportează o acuratețe de 69,4% pe zgomot pur
 - ▶ Verificare: există o dată de test anterioară unei date de antrenare? Folosiți validare walk-forward sau CV cu purjare și embargo [López de Prado \(2018\)](#)
- ❑ **Referințe inventate:** autori, titlu și revistă plauzibile, dar articolul nu există
 - ▶ Verificare: căutați fiecare DOI pe [Crossref](#); deschideți articolul și găsiți afirmația citată
- ❑ **Tot frecvente:** grade de libertate greșite într-un test, valori implicite din biblioteci pe care nu le-ați ales, cifre date fără să fi rulat vreun cod
 - ▶ Fiecare seminar are un exercițiu C2 care vă antrenează să prindeți astfel de erori

Recapitulare: utilizarea AI în proiect

- ▣ Folosiți AI liber, declarați-l în `AI_USE.md` și verificați fiecare rând pe care îl scrie
- ▣ Tabelul replicat este cel mai bun test: un AI nu îl poate ghici
- ▣ Notați cel puțin trei erori AI în `AI_ERRORS.md`; la susținerea orală răspundeți singuri

Idei de proiect: Partea C a fiecărui seminar (1/2)

Cap.	Întrebarea deschisă (link către seminar)
0	Au schimbat ETF-urile spot corelația Bitcoin cu acțiunile?
1	A scăzut autocorelația BET-TR după reclasificarea FTSE?
2	A devenit BVB mai eficientă după reclasificarea FTSE din 2020?
3	Există prime factoriale la Bursa de Valori București?
4	Un portofoliu optim de blue chips BVB în RON
5	Este volatilitatea pieței românești determinată de SUA?
6	Au devenit acțiunile din România și din zona euro mai integrate după 2020?
7	Capitalul pentru un portofoliu BVB vs un portofoliu S&P 500

- ☐ Fiecare seminar oferă datele, o metodă de pornire și o analiză de referință discutată la seminar

Idei de proiect: Partea C a fiecărui seminar (2/2)

Cap.	Întrebarea deschisă (link către seminar)
8	Ce model de risc ați certifica pentru portofoliul de tranzacționare al unei bănci românești?
9	Este volatilitatea Bitcoin mai previzibilă decât cea a S&P 500?
10	Există o primă de ilichiditate pe BVB?
11	Ce model în timp continuu se potrivește pentru BET și Bitcoin?
12	Este prima de risc a varianței un semnal tranzacționabil?
13	Bate un model fundațional boosting-ul?
14	Poate un model fundațional zero-shot să înlocuiască GARCH pentru BET?
15	Aduce sentimentul titlurilor câștig după costuri?
16	Este Bitcoin un activ alternativ, un activ de risc sau o acoperire?
17	Există o bulă AI?
18	Cât de expuse sunt băncile românești la stresul bancar din zona euro?

- ☐ Capitolul 20 (volatilitate realizată cu semnături, datele VOLARE) se potrivește și pentru un proiect de prognoză

Cum transformăm o idee într-un proiect

- ▣ Replicați mai întâi: un tabel sau o figură publicată dintr-un articol din spatele ideii (pasul 1)
- ▣ Restrângeți-o: o piață, o perioadă, un număr de prognozat sau de testat
 - ▶ Exemplu: Seminarul 8 devine „Care dintre HS, FHS și GARCH-EVT dă un VaR 1% corect pentru un portofoliu 50/50 BET–EUR în 2015–2026?”
- ▣ Extindeți-o: o a doua piață, un model nou, un eșantion mai lung sau mai recent
 - ▶ Exemplu: adăugați un model fundațional (Capitolul 14) ca filtru de volatilitate în FHS
- ▣ Păstrați analiza de referință ca reper și încercați să o îmbunătățiți în mod onest

Întrebarea de cercetare: cât dintr-un rezultat ține de cercetător?

- Menkveld et al. (2024), *Journal of Finance* 79(3): 164 de echipe de cercetare testează aceleași șase ipoteze pe aceleași date (Finance Crowd Analysis Project, #fincap; Sec. I.A)
 - ▶ **Eroarea standard**: incertitudinea din eșantionare, procesul generator de date; **eroarea nestandard**: incertitudinea din drumul de analiză ales de fiecare cercetător, procesul generator de dovezi (Introducere)
- **Modelul**: echipa j raportează $X_j = e_j + \varepsilon_j$, unde e_j este efectul fix al cercetătorului (al drumului ales), iar ε_j eroarea de eșantionare (Sec. I.C, ec. 1)
 - ▶ Eroarea nestandard $:= Q_{0,75}(x) - Q_{0,25}(x)$, intervalul intercuartilic (IQR) al estimărilor între echipe (ec. 3); IQR-ul, nu abaterea standard, pentru că e_j pot avea cozi groase
- **Patru întrebări**: cât de mare este; este mai mică pentru lucrările mai bune și mai reproductibile; o reduce feedbackul colegilor; îi cunosc cercetătorii mărimea? (Introducere)
 - ▶ Legătura cu acest capitol: fiecare proiect de echipă este un singur drum prin „grădina drumurilor care se ramifică”; preînregistrarea, grila de specificații și un repository care regenerează fiecare cifră sunt remediile

Date și metodă, așa cum au fost publicate

- **Date:** toate tranzacțiile cu contractele futures pe indicele Euro Stoxx 50, 2002–2018, 720 de milioane de înregistrări, fiecare parte marcată drept client sau cont propriu (Sec. I.A)
 - ▶ Șase ipoteze, fiecare „nicio tendință anuală” pentru: eficiența pieței, marja bid–ask realizată, ponderea clienților în volum, marja realizată pe ordinele clienților, ponderea ordinelor la piață în ordinele clienților, venitul brut din tranzacționare al clienților
 - ▶ Fiecare echipă își alege propria măsură și raportează variația anuală medie în %, cu eroarea ei standard (SE)
- **Patru etape** în 2021: analiza independentă (articol și cod); feedback de la doi evaluatori; distribuirea celor mai bune cinci lucrări; estimările finale, fără obligația codului (Sec. I.A)
 - ▶ Un plan de analiză a fost înregistrat public înainte de începerea experimentului (Sec. I.A)
- **Calitatea:** calitatea echipei (prima componentă principală a cinci indicatori), scorul de reproductibilitate 0–100 acordat de agenția de certificare Cascad, nota evaluatorilor centrată (Sec. I.B)
 - ▶ Regresii cuantile ale estimărilor la percentilele 10, 25, 50, 75 și 90; un IQR care scade înseamnă o dispersie mai mică (Sec. I.C)
- **Inferența:** fiecare estimare este testată față de estimarea mediană, cu corecție Bonferroni la un nivel al familiei de 0,5% (Sec. I.C)
 - ▶ Analiza multivers: echipele raportează alegerea făcută la fiecare bifurcație din Tabelul V; statistica Anderson–Darling cu k eşantioane ordonează bifurcațiile după cât de mult modifică estimările (Sec. II.C)

Rezultatele principale

- **Mărimea:** pentru eficiența pieței, estimarea mediană este $-1,1\%$ pe an, cu un IQR de 6,7 puncte procentuale (pp); chiar și pentru ponderea clienților în volum, un simplu raport, IQR-ul este 1,2 pp în jurul valorii $-3,3\%$ (Tabelul I, Panoul C)
 - ▶ Interpretare: SE-ul median de $2,5\%$ implică un IQR Gaussian de $1,35 \times 2,5 = 3,4\%$, jumătate din 6,7 pp; ipoteza nulă fără dispersie este respinsă pentru toate cele șase ipoteze, $p < 0,0001$ (Tabelul II)
- **Calitatea:** o creștere cu o abatere standard a reproductibilității reduce IQR-ul cu $25,0\%$, iar una a notei evaluatorilor cu $33,3\%$ (Tabelul III, Fig. 2)
 - ▶ Interpretare: codul care rulează cap-coadă este asociat cu răspunsuri mai apropiate de consens
- **Feedbackul:** de la etapa 1 la etapa 4, IQR-ul scade cu $47,2\%$, iar intervalul interdecilic cu $68,2\%$ (Tabelul IV, Fig. 3)
 - ▶ Interpretare: evaluarea colegială reduce dispersia, dar nu o elimină
- **Convingerile:** pe toate ipotezele, abaterea standard a estimărilor prezisă de echipe este cu $71,7\%$ sub cea realizată (Sec. II.B.3, Fig. 4)
 - ▶ Interpretare: cercetătorii își supraestimează certitudinea propriului drum de analiză
- **Bifurcațiile:** alegerea modelului și frecvența eșantionării modifică cel mai mult estimările; un model al variației relative dă o tendință anuală mediană de $-23\,000\%$ pe date zilnice, -200% lunar și $-4,56\%$ anual (Fig. 6, Fig. 7)
 - ▶ Interpretare: inegalitatea lui Jensen, $\prod_{t=1}^T \mathbb{E}(M_t) < \mathbb{E}(\prod_{t=1}^T M_t)$ (ec. 7); diferențele logaritmice și tendințele liniare nu sunt afectate

Replicare pe datele cursului, limite, extindere

- **Replicare:** un multivers pentru ipoteza eficienței pieței pe indicele Euro Stoxx 50 și pe BET (data/market), 2002–2018, apoi extins până la ultimul an complet (Seminarul 19, C3)
 - ▶ Bifurcațiile exact ca în Tabelul V: valorile extreme (nimic, winsorizare sau eliminare la percentilele 2,5 și 97,5), măsura (raportul varianțelor, R^2 al unui model AR), frecvențele (zi la săptămână, zi la lună), modelul (tendință liniară, diferență logaritmică, diferență relativă)
 - ▶ Limita datelor: doar închideri zilnice, deci perechile de frecvențe intrazilnice din Tabelul V nu pot fi rulate
- **Limite formulate de autori:** multiversul acoperă doar câteva bifurcații și explică slab estimările raportate (nota 32); convingerile au fost cerute ca abateri standard, nu ca IQR (nota 28)
 - ▶ Testul dispersiei presupune SE-uri raportate consistente (Sec. I.C); dinamica evaluării la reviste rămâne în afara studiului (Sec. I.A)
- **Extindere deschisă:** reduce o grilă preînregistrată eroarea nestandard a unei întrebări de risc? Măsurați IQR-ul concluziilor VaR 1% pentru BET pe drumurile de analiză justificabile
 - ▶ Pentru proiectul vostru: raportați distribuția pe grilă și bifurcațiile care o modifică cel mai mult, nu o singură celulă

O întrebare deschisă

Cât dintr-un rezultat vine din date și cât din cercetător?

- 164 de echipe au testat aceleași ipoteze pe aceleași date: dispersia răspunsurilor, **erorile nestandard**, a fost mare și subestimată de echipe [Menkveld et al. \(2024\)](#)
 - ▶ A fost mai mică pentru cercetarea mai reproductibilă și a scăzut după etapele de evaluare colegială
- Replicarea nu este fără speranță: într-un model bayesian al replicării, majoritatea factorilor de evaluare a activelor se replică și funcționează în afara eșantionului în 93 de țări [Jensen, Kelly & Pedersen \(2023\)](#)
- Asistenții AI fac aproape gratuită orice specificație în plus: drumurile care se ramifică se înmulțesc, dar și posibilitatea de a le raporta pe toate
 - ▶ Formularea formală pentru un proiect: concluzia trebuie să reziste pe o mulțime preînregistrată S de specificații justificabile, cu familia corectată (FWER sau FDR); raportăm distribuția ei pe S , nu celula cea mai bună

Bucula descoperirii, pas cu pas (1/2)

- **Săptămâna 1, întrebarea:** transformăm o idee în H_0/H_1 , cu o țintă de replicare
 - ▶ „Iată ideea noastră din Partea C a Seminarului N. Dă trei versiuni mai precise și testabile, tabelul publicat pe care l-ar replica fiecare și seriile din data/market de care are nevoie.”
- **Săptămânile 1–2, literatura și ținta:** cifra de replicat este una pe care ați văzut-o în PDF
 - ▶ „Listează cele mai citate și cele mai recente articole despre această întrebare, cu DOI; pentru fiecare, estimarea principală, tabelul și eșantionul.”
 - ▶ Verificați fiecare DOI pe [Crossref](#); căutați cu Semantic Scholar, Elicit sau Google Scholar; deschideți voi tabelul
- **Săptămâna 2, ipoteze și preînregistrare,** salvează înaintea primului rezultat
 - ▶ „Pentru H_0 și H_1 , listează ipotezele concurente și implicația care le separă; apoi scrie o preînregistrare: eșantion, filtre, ferestre, teste, corecție.”
 - ▶ Istoricul commit-urilor din repository este dovada că planul a fost primul

Bucula descoperirii, pas cu pas (2/2)

- **Săptămânile 2–3, cod și replicare:** tabelul replicat devine un test în repository
 - ▶ „Scrie o funcție care reproduce fiecare celulă a tabelului publicat din data/market și o aserțiune cu toleranța pe care o acceptăm.”
- **Săptămânile 4–5, extindere și robustețe:** rulăm toată grila preînregistrată
 - ▶ „Iată toate celulele rulate. Ce concluzii rezistă corecției Holm și pe care le-ar numi un recenzent căutare oportunistă în date (data snooping)?”
- **Înainte de susținere, critica:** asistentul întreabă, echipa răspunde
 - ▶ „Joacă rolul examinatorului la susținerea orală: pune cele mai dificile zece întrebări despre identificare, inferență și date. Nu răspunde la ele.”
 - ▶ Echipa răspunde fără AI, ca la susținerea propriu-zisă
- **Raportul:** distribuția rezultatelor pe grilă, nu celula cea mai bună; prompturile în AI_USE.md, erorile prinse în AI_ERRORS.md

Ce verifică cercetătorul

- **Ținta de replicare există:** cifra, tabelul și eșantionul luate din articol, nu din rezumatul asistentului
 - ▶ Test: raportul citează pagina și tabelul; un al doilea membru găsește acolo aceeași cifră
- **Planul a fost primul**
 - ▶ Test: în istoricul commit-urilor, preînregistrarea precede primul fișier de rezultate
- **Drumuri ramificate:** mai multe specificații încercate decât raportate
 - ▶ Test: fiecare rulare își scrie configurația și rezultatul într-un jurnal; raportul le dă numărul și corectează familia
- **Reproductibilitatea:** cifre scrise direct în raport
 - ▶ Test: o clonă nouă și o singură comandă regenerează fiecare cifră până la ultima zecimală raportată
- **Înțelegerea:** fiecare membru poate deduce formula-cheie și poate apăra fiecare alegere
 - ▶ Test: o susținere de probă în echipă, fără AI, cu o săptămână înaintea celei reale

Mini-caz: replicăm, apoi extindem

- **Replicăm:** VaR 1% FHS pentru BET; Capitolul 8 raportează 59 de depășiri în 4 937 de zile (1,20%, Kupiec $p = 0,181$)
 - ▶ Studiul de caz din acest capitol: 67 în 5 432 de zile (1,23%, $p = 0,095$); același model, alt început al evaluării (2007 față de 2005) și alte setări: documentăm orice diferență înainte de a declara o replicare eșuată
- O propunere tipică a asistentului, care citește fiecare valoare p separat la 5%: „doar GARCH-EVT este calibrat corect pe toate cele patru active”
- **Extindem:** cele 24 de teste de acoperire condiționată din Capitolul 8 (4 active $\times$ 6 modele) formează o familie
 - ▶ Respingeri la 5%: 12 fără corecție, 10 cu Holm (FWER), 11 cu BH (FDR 5%)
 - ▶ FHS eșuează doar pe S&P 500 ($p = 0,040$); în familia de 24 de teste rezistă, deci după Holm FHS și GARCH-EVT trec pe toate cele patru active
- Interpretare: „FHS eșuează pentru S&P 500” depinde de citirea testului separat sau în familia lui; preînregistrăm familia și le raportăm pe amândouă

Rândul vostru: planul final

- **Întrebarea:** ideea voastră din Partea C, scrisă ca H_0/H_1 , cu observația care ar infirma-o
- **Replicați întâi:** un tabel publicat, văzut în articol, transformat într-un test care trece în repository
 - ▶ Apoi extindeți pe o grilă preînregistrată, cu familia corectată și distribuția completă raportată
- **Livrabile** de-a lungul calendarului: propunerea și ținta de replicare, commit-ul de preînregistrare, testul de replicare care trece, grila de rezultate, susținerea de probă, raportul, susținerea orală
- **Jurnalul AI:** prompturile care au schimbat designul în AI_USE.md; fiecare eroare prinsă, cu testul care a prins-o, în AI_ERRORS.md ([șabloane](#))

Idei de reținut

- ▣ Randamentele sunt greu de prezis; riscul lor nu: volatilitatea, cozile și dependența pot fi prognozate
- ▣ Orice model este judecat în afara eșantionului, față de un reper simplu, cu o funcție de pierdere potrivită țintei
- ▣ Cozile groase schimbă inferența: folosiți erori robuste și bootstrap, raportați intervale
- ▣ Cele mai multe rezultate greșite vin din design, nu din model: informație din viitor, supraajustare, testare multiplă, calendare
- ▣ Instrumentele noi (ML, modele fundamentale, LLM-uri) ridică exigența evaluării, nu o scad

Studiu suplimentar

Manuale

- Franke, Härdle & Hafner (2019); Härdle, Chen & Overbeck (2017); McNeil, Frey & Embrechts (2015); Tsay (2010)

Cursuri avansate pe quantinar.com

-  Statistics of Financial Markets
-  Measuring Statistical Risk

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_19

Bibliografie (1/5)

- ▣ Abadie, A., Diamond, A., Hainmueller, J. (2010). Synthetic control methods for comparative case studies: estimating the effect of California's tobacco control program. *Journal of the American Statistical Association*, 105(490), 493–505.
- ▣ Andrews, D.W.K. (1993). Tests for parameter instability and structural change with unknown change point. *Econometrica*, 61(4), 821–856.
- ▣ Andrews, D.W.K. (1999). Estimation when a parameter is on a boundary. *Econometrica*, 67(6), 1341–1383.
- ▣ Athreya, K.B. (1987). Bootstrap of the mean in the infinite variance case. *Annals of Statistics*, 15(2), 724–731.
- ▣ Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- ▣ Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Barndorff-Nielsen, O.E., Shephard, N. (2006). Econometrics of testing for jumps in financial economics using bipower variation. *Journal of Financial Econometrics*, 4(1), 1–30.
- ▣ Black, F., Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 637–654.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- ▣ Brownlees, C., Engle, R.F. (2017). SRISK: a conditional capital shortfall measure of systemic risk. *Review of Financial Studies*, 30(1), 48–79.
- ▣ Chow, K.V., Denning, K.C. (1993). A simple multiple variance ratio test. *Journal of Econometrics*, 58(3), 385–401.

Bibliografie (2/5)

- ▣ Christoffersen, P.F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- ▣ Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification: how inefficient is the $1/N$ portfolio strategy?. *Review of Financial Studies*, 22(5), 1915–1953.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R. (2002). Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- ▣ Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- ▣ Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- ▣ Fama, E.F. (1970). Efficient capital markets: a review of theory and empirical work. *Journal of Finance*, 25(2), 383–417.
- ▣ Fissler, T., Ziegel, J.F. (2016). Higher order elicibility and Osband's principle. *Annals of Statistics*, 44(4), 1680–1707.
- ▣ Forbes, K.J., Rigobon, R. (2002). No contagion, only interdependence: measuring stock market comovements. *Journal of Finance*, 57(5), 2223–2261.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.

Bibliografie (3/5)

- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Gibbons, M.R., Ross, S.A., Shanken, J. (1989). A test of the efficiency of a given portfolio. *Econometrica*, 57(5), 1121–1152.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). *Applied Quantitative Finance*, 3rd ed. Springer.
- ▣ Harvey, C.R. (2017). Presidential address: the scientific outlook in financial economics. *Journal of Finance*, 72(4), 1399–1440.
- ▣ Harvey, C.R., Liu, Y. (2020). False (and missed) discoveries in financial economics. *Journal of Finance*, 75(5), 2503–2553.
- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- ▣ Hill, B.M. (1975). A simple general approach to inference about the tail of a distribution. *Annals of Statistics*, 3(5), 1163–1174.
- ▣ Hou, K., Xue, C., Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133.
- ▣ Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance?. *Journal of Finance*, 78(5), 2465–2518.
- ▣ Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- ▣ Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.

Bibliografie (4/5)

- ▣ Lo, A.W. (2002). [The statistics of Sharpe ratios](#). *Financial Analysts Journal*, 58(4), 36–52.
- ▣ Lo, A.W., MacKinlay, A.C. (1988). [Stock market prices do not follow random walks: evidence from a simple specification test](#). *Review of Financial Studies*, 1(1), 41–66.
- ▣ Lobato, I., Nankervis, J.C., Savin, N.E. (2001). [Testing for autocorrelation using a modified Box–Pierce Q test](#). *International Economic Review*, 42(1), 187–205.
- ▣ López de Prado, M. (2018). [Advances in Financial Machine Learning](#). Wiley.
- ▣ Markowitz, H. (1952). [Portfolio selection](#). *Journal of Finance*, 7(1), 77–91.
- ▣ McNeil, A.J., Frey, R. (2000). [Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach](#). *Journal of Empirical Finance*, 7(3–4), 271–300.
- ▣ McNeil, A.J., Frey, R., Embrechts, P. (2015). [Quantitative Risk Management: Concepts, Techniques and Tools](#), revised ed. Princeton University Press.
- ▣ Menkveld, A.J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). [Nonstandard errors](#). *Journal of Finance*, 79(3), 2339–2390.
- ▣ Nolde, N., Ziegel, J.F. (2017). [Elicitability and backtesting: perspectives for banking regulation](#). *Annals of Applied Statistics*, 11(4), 1833–1874.
- ▣ Patton, A.J. (2011). [Volatility forecast comparison using imperfect volatility proxies](#). *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). [Dynamic semiparametric models for expected shortfall \(and value-at-risk\)](#). *Journal of Econometrics*, 211(2), 388–413.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). [Information entropy and measures of market risk](#). *Entropy*, 19(5), 226.

Bibliografie (5/5)

- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). [Finite-sample precision limits for expected shortfall forecast comparisons](#). *Mathematics*, 14(13), 2316.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiat, M., Yatracos, Y.G. (2023). [Are cryptos becoming alternative assets?](#). *European Journal of Finance*, 29(10), 1064–1105.
- ▣ Phillips, P.C.B., Shi, S., Yu, J. (2015). [Testing for multiple bubbles: historical episodes of exuberance and collapse in the S&P 500](#). *International Economic Review*, 56(4), 1043–1078.
- ▣ Shanken, J. (1992). [On the estimation of beta-pricing models](#). *Review of Financial Studies*, 5(1), 1–33.
- ▣ Simonsohn, U., Simmons, J.P., Nelson, L.D. (2020). [Specification curve analysis](#). *Nature Human Behaviour*, 4(11), 1208–1214.
- ▣ Stambaugh, R.F. (1999). [Predictive regressions](#). *Journal of Financial Economics*, 54(3), 375–421.
- ▣ Tsay, R.S. (2010). [Analysis of Financial Time Series](#), 3rd ed. Wiley.
- ▣ Zhang, L., Mykland, P.A., Ait-Sahalia, Y. (2005). [A tale of two time scales: determining integrated volatility with noisy high-frequency data](#). *Journal of the American Statistical Association*, 100(472), 1394–1411.