



Modelarea piețelor financiare

Capitolul 19: Recapitulare și prezentarea proiectelor



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ ADF: Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ ASE: Academia de Studii Economice din București
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- ▣ BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- ▣ BNR: Banca Națională a României
- ▣ BVB: Bursa de Valori București
- ▣ CAPM: Capital Asset Pricing Model (modelul de evaluare a activelor financiare)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- ▣ CV: Cross-Validation (validare încrucișată)
- ▣ DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- ▣ ES: Expected Shortfall (pierderea așteptată în coadă)
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ EVT: Extreme Value Theory (teoria valorilor extreme)
- ▣ FDR: False Discovery Rate (rata descoperirilor false)
- ▣ FHS: Filtered Historical Simulation (simulare istorică filtrată)
- ▣ FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- ▣ FTSE: Financial Times Stock Exchange (FTSE Russell, index provider) (furnizorul de indici FTSE Russell)
- ▣ FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- ▣ FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GARCH-EVT: GARCH filter combined with Extreme Value Theory for the tail (filtru GARCH combinat cu teoria valorilor extreme pentru coadă)
- ▣ GRS: Gibbons–Ross–Shanken (test) (testul Gibbons–Ross–Shanken)
- ▣ GSADF: Generalised Sup Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat suprem generalizat)

Acronime folosite în acest material (2/2)

- ▣ HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- ▣ HS: Historical Simulation (simulare istorică)
- ▣ LLM: Large Language Model (model lingvistic mare)
- ▣ LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- ▣ MCS: Model Confidence Set (mulțimea de modele de încredere)
- ▣ ML: Machine Learning (învățare automată)
- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- ▣ SML: Security Market Line (dreapta pieței titlurilor)
- ▣ SRISK: Systemic RISK (capital shortfall measure) (deficitul de capital al unei bănci într-o criză sistemică)
- ▣ SUA: Statele Unite ale Americii
- ▣ VIX: CBOE Volatility Index (indicele de volatilitate CBOE)

Cuprins

Introducere

Recapitulare I: piețe, randamente și evaluare

Recapitulare II: volatilitate, dependență și risc

Recapitulare III: frecvență înaltă, timp continuu și opțiuni

Recapitulare IV: învățare, text și piețe noi

Capcane frecvente

Studiu de caz integrat: BET

Proiectul de echipă

Utilizarea AI în proiect

Idei de proiect

AI pentru descoperire științifică

Concluzii

Bibliografie

Ce face acest capitol

Scop

- ▣ Recapitulăm capitele 0–18 ca o singură poveste
- ▣ Adunăm capcanele care au revenit în fiecare capitol
- ▣ Parcurgem un studiu de caz integrat, de la prețuri brute la o valoare la risc (Value-at-Risk, VaR) de 1% testată
- ▣ Pregătim proiectul de echipă: cei patru pași, întrebarea, metodele și politica AI

Evaluare


- ▣ Proiectul de echipă (GitHub, prezentare, susținere orală): **70%**
- ▣ Quiz-uri și activitate la seminar: **20%**
- ▣ Prezență: **10%**; nu există examen final



Academia de Studii Economice din București (ASE), Piața Romană

Foto: Joe Mabel (2014); CC BY 3.0; Wikimedia Commons

Cursul într-o singură imagine



- Roșu: firul principal al cursului, de la faptele stilizate la prognoze de risc pe care le putem testa
- Săgeți albastre: unde un capitol oferă datele de intrare sau reperul pentru altul

Cum citim harta cursului

- ▣ Capitolul 1 stabilește țintele: cozi groase, grupări de volatilitate, aproape nicio predictibilitate liniară
 - ▶ Orice model ulterior este judecat după cum reproduce aceste fapte
- ▣ Capitolele 5–8 transformă faptele într-un număr de risc și într-un test al acestui număr
 - ▶ GARCH dă σ_{t+1} ; VaR și ES dau pierderea; backtesting-ul spune dacă o putem crede
- ▣ Capitolele 9–12 măsoară mai bine volatilitatea (date intraday, prețuri de opțiuni) și în timp continuu
- ▣ Capitolele 13–15 aduc modele flexibile, evaluate mereu cu instrumentele din Capitolul 8
- ▣ Capitolele 16–18 aplică aceleași instrumente pentru crypto, bule și întregul sistem financiar

Cinci întrebări pentru orice model

Înainte de estimare

- **Date:** ce serie, ce calendar, ce ajustări (dividende, split-uri, sărbători)?
- **Model:** ce fapt stilizat surprinde și ce ignoră?
- **Estimare:** pe ce fereastră, cu ce informație la momentul t ?

După estimare

- **Evaluare:** în afara eșantionului, cu o funcție de pierdere potrivită țintei (QLIKE, FZ0, Kupiec)?
- **Incertitudine:** erori standard robuste, bootstrap, test față de un reper simplu?
- Dacă lipsește un răspuns, rezultatul nu este încă o concluzie

Capitolul 0: Piețele financiare în 2026

Ideea principală

- Piețele combină burse, dealeri extrabursieri, fonduri tranzacționate la bursă (exchange-traded funds, ETF), algoritmi și blockchain-uri
- Calitatea datelor este o decizie de modelare: sursa, ajustarea și calendarul schimbă rezultatul

Formula cheie

- $CAGR = (P_T/P_0)^{1/Y} - 1$ (Compound Annual Growth Rate, rata anuală compusă de creștere)
- $\sigma_{\text{ann}} = \sqrt{P} \hat{\sigma}$

Rezultat din date

- 2015–2026: SPY (ETF pe S&P 500, cu dividende reinvestite) 13,7% pe an cu volatilitate 17,6%; Bitcoin 60,6% pe an cu 66,7%
- BET, iulie 2007 – februarie 2009: o scădere de la maxim de –82,5%

Duce la

- Obiectul de studiu sunt randamentele, nu prețurile (Capitolul 1)

Capitolul 1: Fapte stilizate și randamente

Ideea principală

- Randamentele sunt necorelate, dar nu independente: mărimea lor este previzibilă, semnul aproape deloc
- Cozi groase și grupări de volatilitate pe toate piețele Cont (2001)

Formula cheie

- $\hat{K} - 3 = \frac{T^{-1} \sum_t (r_t - \bar{r})^4}{\hat{\sigma}^4} - 3$
- $Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k}$

Rezultat din date

- Exces de kurtosis de la 9,3 (aur) la 17,8 (BET-TR); distribuția Normală dă 0
- Zilele dincolo de 5σ sunt de peste 1000 de ori mai frecvente decât prezice distribuția Normală

Duce la

- Modele de volatilitate (Capitolul 5) și măsuri ale riscului de coadă (Capitolul 7)

Capitolul 2: Eficiența pieței

Ideea principală

- Eficiență: randamentele în exces sunt imprevizibile, dată fiind informația disponibilă **Fama (1970)**
- Eficiența variază în timp (piețe adaptive); testele cer inferență robustă

Formula cheie

- $$VR(q) = \frac{\text{Var}(r_t + \dots + r_{t-q+1})}{q \text{Var}(r_t)} = 1$$
 (Variance Ratio, raportul varianțelor) pentru un mers aleator

Rezultat din date

- Ponderea ferestrelor mobile care resping mersul aleator: S&P 500 6,4%, BET 22,4%, Bitcoin 0,0%
- O respingere statistică nu înseamnă profit exploatabil

Duce la

- Anomalii și factori (Capitolul 3); problema testării multiple

Capitolul 3: Modele factoriale și evaluarea activelor

Ideea principală

- Randamentele așteptate ar trebui să răsplătească doar expunerea la factori sistematici
- Sutele de factori publicați cer praguri mai înalte Harvey, Liu & Zhu (2016)

Formula cheie

- $E[R_i] - r_f = \beta_i (E[R_m] - r_f)$
- $\beta_i = \text{Cov}(R_i, R_m) / \text{Var}(R_m)$

Rezultat din date

- 25 de portofolii după mărime și raportul valoare contabilă/de piață: panta SML $-4,4\%$, GRS $= 4,18$: CAPM este respins
- ETF-uri sectoriale: prima componentă principală (piața) explică 66% din varianță

Duce la

- Construcția portofoliului (Capitolul 4); modele factoriale în machine learning (Capitolul 13)

Capitolul 4: Optimizarea portofoliului

Ideea principală

- ▣ Markowitz pune întrebarea corectă, dar eroarea de estimare domină răspunsul [Markowitz \(1952\)](#)
- ▣ Shrinkage-ul, restricțiile și regulile bazate pe risc stabilizează ponderile; $1/N$ este un reper greu de bătut [DeMiguel, Garlappi & Uppal \(2009\)](#)

Formula cheie

- ▣ $w_{\text{tan}} \propto \Sigma^{-1}(\mu - r_f \mathbf{1})$
- ▣ $SR = (\mu - r_f)/\sigma$ (Sharpe Ratio, raportul Sharpe)

Rezultat din date

- ▣ Eșantioane de 60 de luni: Sharpe median în eșantion 1,57, Sharpe adevărat median 0,30
- ▣ 96% dintre portofoliile tangente estimate sunt de fapt mai slabe decât $1/N$

Duce la

- ▣ Bugetele de risc cer prognoze de volatilitate și de dependență (Capitolele 5–6)

Recapitulare: piețe, randamente și evaluare

- ▣ Întâi date curate: prețuri ajustate pentru ETF-uri și acțiuni, calendarul propriu al fiecărei serii, join pe prețuri înainte de randamente
- ▣ Faptele stilizate sunt reperul pentru orice model care urmează
- ▣ Testele de eficiență și de factori cer erori robuste și corecții pentru testarea multiplă
- ▣ Optimizarea amplifică eroarea de estimare: evaluați în afara eșantionului, față de $1/N$

Capitolul 5: Volatilitate condiționată: GARCH

Ideea principală

- ▣ Volatilitatea se grupează, deci șocul de azi prezice varianța de mâine Engle (1982), Bollerslev (1986)
- ▣ Persistență aproape de 1; asimetrie la acțiuni; inovații cu cozi groase

Formula cheie

- ▣ $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$
- ▣ $h_{1/2} = \ln 0,5 / \ln(\alpha + \beta)$

Rezultat din date

- ▣ S&P 500, 2000–2026: $\alpha + \beta = 0,9947$, un timp de înjumătățire de 131 de zile
- ▣ Volatilitatea GARCH și VIX: corelație 0,89

Duce la

- ▣ $\hat{\sigma}_{t+1}$ este intrarea pentru VaR și ES filtrate (Capitolul 7)

Capitolul 6: Volatilitate multivariată și dependență

Ideea principală

- Corelațiile se schimbă odată cu regimul macroeconomic; diversificarea nu este garantată
- Copulele separă distribuțiile marginale de dependență; dependența în cozi determină pierderile comune

Formula cheie

- $Q_t = (1 - a - b) \bar{Q} + a z_{t-1} z_{t-1}^\top + b Q_{t-1}$
- $R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2}$

Rezultat din date

- SPY-TLT (ETF pe obligațiuni americane pe termen lung): ρ de la $-0,40$ la $0,11$ după 2022, deci un portofoliu 60/40 a trecut de la $10,4\%$ la $13,2\%$ volatilitate
- Corelația DCC Bitcoin-SPY: $0,04$ înainte de 2020, $0,31$ de atunci

Duce la

- VaR de portofoliu și contribuții Euler (Capitolul 7); risc sistemic (Capitolul 18)

Capitolul 7: VaR și Expected Shortfall

Ideea principală

- VaR este o cuantilă a pierderii, ES pierderea medie dincolo de ea; ES este coerent
- Simularea istorică filtrată și EVT condiționat reacționează la volatilitate în câteva zile [McNeil & Frey \(2000\)](#)

Formula cheie

- $\text{VaR}_\alpha(X) = -q_\alpha(X)$
- $\text{ES}_\alpha(X) = -\frac{1}{\alpha} \int_0^\alpha q_u(X) du$

Rezultat din date

- S&P 500, zilnic: $\text{VaR}_{1\%}$ istoric = 3,45%, $\text{ES}_{1\%} = 5,01\%$
- Distribuția Normală dă doar 2,80%: cozile groase contează

Duce la

- O prognoză de risc este utilă doar dacă trece un backtest (Capitolul 8)

Capitolul 8: Backtesting și evaluarea prognozelor de risc

Ideea principală

- ▣ Testăm numărul și momentul depășirilor: acoperirea și independența Kupiec (1995), Christoffersen (1998)
- ▣ Clasificăm prognozele (VaR, ES) cu un scor consistent (FZ0) și teste Diebold–Mariano Fissler & Ziegel (2016)

Formula cheie

- ▣ $LR_{uc} = -2 \ln \frac{(1 - \alpha)^{T-x} \alpha^x}{(1 - \hat{\pi})^{T-x} \hat{\pi}^x} \sim \chi_1^2$
- ▣ $\hat{\pi} = x/T$

Rezultat din date

- ▣ S&P 500, VaR 1%, 2007–2026: depășiri Normal 2,70%, HS 1,67%, FHS 1,23%, GARCH-EVT 1,13%
- ▣ Un filtru GARCH plus o coadă flexibilă câștigă pe toate cele patru piețe

Duce la

- ▣ Aceleași teste judecă prognozele din volatilitatea realizată și din machine learning (Capitolele 9, 13, 14)

Recapitulare: volatilitate, dependență și risc

- ▣ GARCH transformă grupările de volatilitate în prognoze pentru ziua următoare
- ▣ Dependența este dinamică și cea mai puternică în cozi; corelațiile din criză cer o ajustare pentru volatilitate
- ▣ VaR și ES trebuie să combine un filtru de volatilitate cu o distribuție cu cozi groase
- ▣ Un model de risc este acceptat doar după teste de acoperire, independență și pentru ES

Capitolul 9: Volatilitate realizată

Ideea principală

- Prețurile intraday măsoară varianța zilnică (RV , Realised Variance, varianța realizată); modelul log-HAR (Heterogeneous AutoRegressive, autoregresiv heterogen) surprinde memoria ei lungă [Corsi \(2009\)](#)
- Randamentele împărțite la volatilitatea realizată sunt aproape de distribuția Normală

Formula cheie

- $RV_t = \sum_{i=1}^M r_{t,i}^2$
- $\ln RV_{t+1} = \beta_0 + \beta_d \ln RV_t + \beta_w \ln RV_t^{(w)} + \beta_m \ln RV_t^{(m)} + \varepsilon_{t+1}$

Rezultat din date

- SPY: kurtosis 15,73 pentru randamentele de la deschidere la închidere, 2,65 după împărțirea la $\sqrt{RV_t}$
- log-HAR bate GARCH(1,1)- t în QLIKE cu 10% pentru SPY ($p = 0,021$) și cu 22% pentru Bitcoin

Duce la

- Intrări de volatilitate mai bune pentru VaR; microstructura explică zgomotul (Capitolul 10)

Capitolul 10: Microstructura pieței

Ideea principală

- Prețurile se formează în registre de ordine limită; spread-ul plătește procesarea, stocurile și selecția adversă
- Lichiditatea urmează ora din zi și VIX, și dispare în perioadele de stres

Formula cheie

- $ILLIQ = \frac{1}{D} \sum_{d=1}^D \frac{|r_d|}{DVol_d}$ (iliciditatea Amihud; $DVol_d$: valoarea tranzacționată în ziua d)
- $s_{Roll} = 2\sqrt{-Cov(\Delta p_t, \Delta p_{t-1})}$ (spread-ul Roll)

Rezultat din date

- Raportul Amihud (bp la 1 milion USD): SPY 0,0016, Banca Transilvania 24,7, Transelectrica 1024,0
- SPY: primul interval de 5 minute se mișcă de 2,06 ori mai mult decât unul de la prânz

Duce la

- Riscul de lichiditate în VaR și în alegerea datelor pentru proiect

Capitolul 11: Modele în timp continuu

Ideea principală

- ▣ Mișcarea browniană este limita mersurilor aleatoare; lema lui Itô rezolvă ecuațiile prețurilor
- ▣ Salturile explică cozile, volatilitatea stochastică explică grupările

Formula cheie

- ▣ $dS_t = \mu S_t dt + \sigma S_t dW_t \Rightarrow S_T = S_0 \exp\left((\mu - \frac{\sigma^2}{2})T + \sigma W_T\right)$

Rezultat din date

- ▣ S&P 500 față de mișcarea browniană geometrică: exces de kurtosis 10,9 în loc de 0
- ▣ 62 de zile dincolo de ± 4 abateri standard, față de 0,59 așteptate

Duce la

- ▣ Evaluarea opțiunilor cere doar σ , nu și μ (Capitolul 12)

Capitolul 12: Opțiuni și suprafața de volatilitate

Ideea principală

- Black–Scholes evaluează opțiunile prin acoperire; volatilitatea implicită este estimarea pieței pentru σ [Black & Scholes \(1973\)](#)
- Zâmbetul și asimetria volatilității reflectă teama de prăbușiri

Formula cheie

- $C = S N(d_1) - Ke^{-rT} N(d_2)$
- $VRP_t = VIX_t^2 - RV_{t,t+21}$

Rezultat din date

- 1990–2026: VIX mediu 19,4, volatilitatea realizată medie în luna următoare 15,3
- Prima de risc a varianței este pozitivă în 86% din zile, dar nu și în prăbușiri

Duce la

- Volatilitatea implicită ca variabilă pentru machine learning și ca indicator de stres (Capitolele 13, 18)

Recapitulare: frecvență înaltă, timp continuu și opțiuni

- ▣ Datele intraday măsoară volatilitatea; log-HAR o prognozează mai bine decât GARCH pe date zilnice
- ▣ Lichiditatea este un risc în sine și variază cu ordine de mărime între piețe
- ▣ Modelele în timp continuu sunt tratabile analitic, dar cele realiste cer salturi și volatilitate aleatoare
- ▣ Prețurile opțiunilor conțin informație despre viitor, inclusiv o primă de risc a varianței

Capitolul 13: Machine Learning în finanțe

Ideea principală

- ▣ Modele flexibile, dar semnal slab și mult zgomot; partea specifică finanțelor este procesul [López de Prado \(2018\)](#)
- ▣ Validare încrucișată cu purjare, meta-etichetare și raportul Sharpe deflatat [Bailey & López de Prado \(2014\)](#)

Formula cheie

- ▣ $(1 - B)^d x_t = \sum_{k \geq 0} w_k x_{t-k}$
- ▣ $w_0 = 1, w_k = -w_{k-1} \frac{d - k + 1}{k}$

Rezultat din date

- ▣ K-fold amestecat raportează o acuratețe de 69,4% pe zgomot pur: scurgere de informație
- ▣ S&P 500: diferențierea fracționară devine staționară la $d^* = 0,25$; niciun model nu bate regula „mereu în creștere”

Duce la

- ▣ Deep learning și modele fundamentale, judecate la fel (Capitolul 14)

Capitolul 14: Deep learning și modele fundamentale pentru serii de timp

Ideea principală

- ▣ LSTM-urile (Long Short-Term Memory, rețele cu memorie pe termen scurt extinsă) și Transformerile învață din secvențe; modelele fundamentale prognozează zero-shot
- ▣ Le evaluăm cu instrumentele din Capitolul 8, după publicarea ponderilor

Formula cheie

- ▣ $L(RV, h) = \frac{RV}{h} - \ln \frac{RV}{h} - 1$ (pierderea QLIKE)

Rezultat din date

- ▣ Volatilitatea realizată SPY, QLIKE: Chronos-2 0,231, log-HAR 0,234, GARCH- t 0,283; primele două nu diferă semnificativ
- ▣ VaR 1% brut Chronos-2 pe S&P 500: 1,67% depășiri

Duce la

- ▣ Textul ca date (Capitolul 15)

Capitolul 15: LLM-uri și analiza sentimentului

Ideea principală

- De la dicționare la FinBERT și la modelele lingvistice mari (Large Language Models, LLM): textul devine un număr
- Reprezentările vectoriale ale textului intră în modele ca variabile explicative

Formula cheie

- $S_t = \frac{N_t^+ - N_t^-}{N_t^+ + N_t^-}$, cu $N_t^\pm$ numărul de texte pozitive și negative din ziua t
- $r_{t+1} = a + b S_t + \varepsilon_{t+1}$ (regresie predictivă)

Întrebările la care răspunde capitolul

- Prezice un scor de sentiment randamentele sau volatilitatea în afara eșantionului, după costuri?
- Era textul disponibil la momentul t sau aduce informație din viitor?

Duce la

- Sentimentul pe piețele crypto și în bule (Capitolele 16–17)

Capitolul 16: Active digitale și DeFi

Ideea principală

- Criptomonedele sunt o clasă de active distinctă statistic, mai ales prin cozile groase [Pele et al. \(2023\)](#)
- Stablecoin-urile, formatorii automați de piață și ETF-urile spot leagă cripto de finanțele tradiționale; finanțele descentralizate (Decentralised Finance, DeFi) funcționează prin contracte inteligente

Formula cheie

- $x \cdot y = k$ (formator de piață cu produs constant; x, y : rezervele celor două token-uri)
- Abaterea de la paritate = $|P_t - 1|$, cu P_t prețul stablecoin-ului în USD

Întrebările la care răspunde capitolul

- Cât de des și cât de mult se abat stablecoin-urile de la paritate?
- Au schimbat ETF-urile spot riscul și corelațiile Bitcoin?

Duce la

- Episoade de prețuri explozive (Capitolul 17)

Capitolul 17: Bule și crahuri

Ideea principală

- O bulă este o traiectorie a prețului care crește mai repede decât o pot justifica fundamentele
- Testele de rădăcină unitară pe coada din dreapta datează începutul și sfârșitul episoadelor explozive

Formula cheie

- $GSADF = \sup_{r_2 \in [r_0, 1]} \sup_{r_1 \in [0, r_2 - r_0]} ADF_{r_1}^{r_2}$
- $ADF_{r_1}^{r_2}$: statistica ADF pe fracțiunea de eșantion $[r_1, r_2]$; r_0 : fereastra minimă

Întrebările la care răspunde capitolul

- Ce episoade de preț din crypto sau tehnologie au fost explozive și când s-au încheiat?
- Poate un model log-periodic să prezică data prăbușirii sau doar s-o potrivească ulterior?

Duce la

- Contagiunea de la o piață la întregul sistem (Capitolul 18)

Capitolul 18: Risc sistemic și rețele

Ideea principală

- ▣ Riscul sistemic: pierderile unei instituții care se propagă în tot sistemul
- ▣ CoVaR (VaR-ul sistemului condiționat de dificultățile unei instituții), SRISK și rețelele de contagiune măsoară contribuția fiecărei instituții

Formula cheie

- ▣ $\Delta \text{CoVaR}^i = \text{CoVaR}_{\alpha}^{sys|X^i} - \text{VaR}_{\alpha}^i - \text{CoVaR}_{\alpha}^{sys|X^i=\text{median}}$
- ▣ CoVaR: VaR-ul randamentului sistemului, condiționat de starea instituției i

Întrebările la care răspunde capitolul

- ▣ Care bănci contribuie cel mai mult la riscul de coadă al sistemului și se schimbă asta în criză?
- ▣ Cât de conectate sunt piețele din România și din zona euro în perioadele de stres?

Duce la

- ▣ Teste de stres și proiectele de echipă

Recapitulare: învățare, text și piețe noi

- ▣ Modelele flexibile cer un proces strict: purjare, embargo, măsuri de performanță deflatate
- ▣ Modelele fundamentale egalează reperele puternice pentru volatilitate și nu înlocuiesc FHS cu filtru GARCH pentru riscul de coadă
- ▣ Textul, cripto, bulele și riscul sistemic folosesc același set de instrumente statistice
- ▣ Date noi și modele noi: se aplică aceleași cinci întrebări

Şase capcane care au revenit în fiecare capitol

Capcane de concepție

- ▣ **Informație din viitor:** date de după t folosite la momentul t
- ▣ **Supraajustare:** un model calibrat pe eşantionul pe care este judecat
- ▣ **Testare multiplă:** cea mai bună dintre multe încercări raportată ca şi cum ar fi singura

Capcane de date şi inferență

- ▣ **Join greşit pe calendar:** randamente calculate înainte de alinierea activelor
- ▣ **Cozi groase ignorate:** erori standard care presupun distribuția Normală şi independența
- ▣ **Funcție de pierdere greşită:** una care nu poate clasifica ținta prognozei

Capcana 1: informația din viitor

- Orice parametru, prag sau scalare estimat pe tot eșantionul aduce informație din viitor
 - ▶ Exemple: parametri GARCH din tot eșantionul, standardizare pe tot eșantionul, etichete care se suprapun cu setul de test
- BET, VaR 1%, 2005–2026: GARCH- t cu parametri din tot eșantionul este depășit în 1,31% din zile, cu estimare pe fereastră mobilă în 1,47%
 - ▶ Varianta cu informație din viitor pare mai bună decât ar fi putut face orice prognozator în timp real
- Capitolul 13: K-fold amestecat raportează o acuratețe de 69,4% pe zgomot pur
- Remediu: ferestre mobile sau în extindere; purjare și embargo; scrieți mulțimea de informație $\mathcal{F}_{t-1}$ lângă fiecare prognoză

Capcana 2: supraajustarea

- ▣ Ajustarea în eşantion răsplăteşte zgomotul, care nu se va repeta
 - ▶ Capitolul 4: Sharpe în eşantion 1,57, Sharpe adevărat 0,30 pentru aceleaşi portofolii
- ▣ Supraajustarea backtest-ului: încercăm multe strategii şi o păstrăm pe cea mai bună [Bailey et al. \(2017\)](#)
 - ▶ Raportul Sharpe deflatat corectează pentru numărul de încercări şi pentru randamentele non-normale [Bailey & López de Prado \(2014\)](#)
- ▣ Remediul: fixaţi designul înainte de a vă uita la perioada de test; raportaţi toate modelele încercate; comparaţi cu un reper simplu ($1/N$, simulare istorică, mers aleator, log-HAR)

Capcana 3: testarea multiplă

- ▣ Capitolul 3: din 300 de factori fără valoare, în medie 15,0 trec de $|t| > 1,96$, iar cel mai bun ajunge la $|t| \approx 3,06$
 - ▶ De aceea literatura despre factori cere $|t| > 3$ [Harvey, Liu & Zhu \(2016\)](#)
- ▣ Anomalii de calendar, reguli de tranzacționare, specificații de model: fiecare test în plus adaugă o șansă de descoperire falsă
- ▣ Remediul: numărați testele și corecții
 - ▶ Bonferroni și Holm controlează probabilitatea oricărei descoperiri false; Benjamini–Hochberg controlează ponderea lor
 - ▶ Pentru prognoze: setul de modele de încredere (MCS) în locul multor teste pe perechi

Capcana 4: join pe randamente în loc de prețuri

- Bitcoin se tranzacționează zilnic, SPY doar în zilele lucrătoare
 - ▶ Greșit: calculăm fiecare randament pe calendarul propriu, apoi păstrăm zilele comune: mișcările Bitcoin din weekend dispar
 - ▶ Corect: păstrăm zilele comune ale **prețurilor**, apoi calculăm randamentele: ziua de luni acoperă intervalul vineri–luni pentru ambele
- Bitcoin, 2020–2026, în zilele comune: randament cumulat 1025% (corect) față de 680% (greșit)
 - ▶ Abaterea standard a zilei de luni 5,04% (corect) față de 3,83% (greșit): join-ul greșit ascunde riscul din weekend
- Remediu: aliniați întâi prețurile pe zilele comune; o serie singură rămâne pe calendarul propriu

Capcana 5: cozile groase ignorate în inferență

- Erorile standard clasice presupun independență și momente de ordinul patru finite
 - ▶ Excesul de kurtosis al BET este 11,1, cu un CI 95% prin bootstrap pe blocuri de [8,0, 13,9]: larg chiar și cu 6 670 de zile
- Persistența GARCH pentru BET: CI 95% [0,974, 1,007], deci timpul de înjumătățire este între 26 de zile și infinit
 - ▶ O estimare punctuală a timpului de înjumătățire spune puțin singură
- Remediu: erori robuste (HAC), bootstrap pe blocuri, teste construite pentru cozi groase; raportați intervale, nu doar valori punctuale

Capcana 6: o funcție de pierdere care nu poate clasifica ținta

- Prognozele de varianță se compară cu o aproximare zgomotoasă (r_t^2 sau RV_t)
 - ▶ MSE și QLIKE le clasifică în mod consistent; QLIKE este mai robust la zilele extreme
 - ▶ Capitolul 9: log-HAR bate GARCH în QLIKE; comparația în MSE nu este concludentă
- ES singur nu poate fi clasificat de nicio funcție de scor; perechea (VaR, ES) poate [Fissler & Ziegel \(2016\)](#)
 - ▶ Folosiți FZ0 cu teste Diebold–Mariano [Diebold & Mariano \(1995\)](#); precizia are limite în eșantioane finite [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)
- Remediu: alegeți funcția de pierdere înainte de comparație și precizați-o în raportul proiectului

Recapitulare: o listă de verificare împotriva capcanelor

Design

- Orice prognoză folosește doar $\mathcal{F}_{t-1}$
- Perioada de test fixată dinainte și folosită o singură dată
- Toate modelele încercate sunt raportate; testele sunt numărate

Date și inferență

- Prețurile unite înainte de randamente; ajustările și calendarele documentate
- Incertitudine robustă sau bootstrap pentru fiecare cifră principală
- Funcție de pierdere consistentă pentru țintă; comparație cu un reper simplu

O întrebare, patru capitole

Întrebarea

- Cât poate pierde mâine o poziție pe indicele BET, cu probabilitatea de 1%?
- Ce prognoză a acestei pierderi am fi putut crede în timp real, în 2005–2026?

Date

- Indicele BET, valori oficiale zilnice de închidere, 6 ian. 2000 – 18 sept. 2026: 6 670 randamente log zilnice
- Zilele cu închidere neschimbată (sărbători completate cu valoarea anterioară) eliminate

Cei patru pași


- Capitolul 1: fapte stilizate, cu inferență robustă
- Capitolul 5: GARCH(1,1) cu inovații Student- t
- Capitolul 7: VaR 1% pentru o zi, din patru modele
- Capitolul 8: acoperire, independență și zonele Basel



Palatul Bursei, București (2023)

Foto: Chainwit. (2023); CC BY 4.0; Wikimedia Commons

Pasul 1: faptele stilizate ale BET




□ Stânga: cuantilele randamentelor standardizate față de distribuția Normală; dreapta: autocorelațiile r_t și $|r_t|$, decalaje 1–50

Interpretarea pasului 1

- ▣ Cozi groase: exces de kurtosis 11,1 (CI 95% prin bootstrap pe blocuri [8,0, 13,9]); asimetrie $-0,65$
 - ▶ 51 zile dincolo de ± 4 abateri standard, față de 0,42 așteptate sub distribuția Normală
 - ▶ Cea mai proastă zi: $-13,1\%$ (log) pe 7 ian. 2009
- ▣ Grupări: autocorelația de ordinul 1 a $|r_t|$ este 0,40 și scade lent; statistica Ljung–Box $Q(10)$ pe r_t^2 este 2440
 - ▶ Randamentele au autocorelația de ordinul 1 de 0,11: BET este mai puțin lichid decât piețele mari (Capitolele 2, 10)
- ▣ Consecință: un VaR Normal cu volatilitate constantă va fi prea mic în stres și prea mare în perioadele calme

Pasul 2: volatilitatea GARCH(1,1)-t



- Randamentele log zilnice ale BET cu $\pm 2\hat{\sigma}_t$ dintr-un GARCH(1,1) cu inovații Student- t , estimat pe 2000–2026

Interpretarea pasului 2

- ▣ Estimări (erori standard robuste): $\hat{\alpha} = 0,192$ (0,025), $\hat{\beta} = 0,799$ (0,024), $\hat{\nu} = 5,01$
 - ▶ $\hat{\nu} \approx 5$: chiar după filtrare, șocurile au cozi groase
- ▣ Persistența $\hat{\alpha} + \hat{\beta} = 0,9907$: un timp de înjumătățire de aproximativ 74 de zile de tranzacționare
 - ▶ Dar CI 95% al persistenței include valoarea 1 (Capcana 5)
- ▣ Volatilitatea zilnică maximă 7,39% pe 15 oct. 2008; la finalul eșantionului 1,67%

Pasul 3: patru prognoze VaR 1%

Necondiționate (ultimele 500 de zile)

- ▣ **HS:** pierderea $L = -r$ depășită în 1% din ultimele 500 de zile (cuantila empirică)
- ▣ **Normal:** $\text{VaR} = -(\hat{\mu} + \hat{\sigma} z_{0,01})$, $z_{0,01} = -2,326$


Condiționate (GARCH- t pe ultimele 1000 de zile)

- ▣ **GARCH- t :** $\text{VaR}_t = -(\hat{\mu} + \hat{\sigma}_t t_\nu^{-1}(0,01) \sqrt{(\nu - 2)/\nu})$
- ▣ **FHS:** $\text{VaR}_t = -(\hat{\mu} + \hat{\sigma}_t \hat{q}_{0,01}(z))$, cuantila de 1% a reziduurilor standardizate [McNeil & Frey \(2000\)](#)

Design în timp real

- ▣ Prognoza pentru ziua t folosește doar datele până la $t - 1$
- ▣ GARCH reestimat la fiecare 21 de zile de tranzacționare; $\hat{\sigma}_t$ actualizat zilnic
- ▣ Evaluare: 3 ian. 2005 – 18 sept. 2026, $T = 5\,432$ zile
- ▣ Depășiri așteptate la 1%: aproximativ 54

Pasul 3: pierderi și VaR 1%, 2020–2026




□ Pierderile zilnice ale BET (câștigurile puse la 0), VaR 1% Normal și FHS; puncte negre: pierderi peste VaR FHS

Interpretarea pasului 3

- ▣ FHS reacționează în câteva zile: a atins 11,6% pe 18 mar. 2020, în timpul prăbușirii din pandemia COVID-19
 - ▶ VaR Normal pe o fereastră de 500 de zile se mișcă doar lent
- ▣ 2020–2026 (1 675 zile, aproximativ 17 depășiri așteptate): FHS 22 depășiri, Normal 41
 - ▶ Depășirile Normal se grupează în primele săptămâni ale fiecărui episod de stres
- ▣ Ultima prognoză din eșantion: FHS 4,48%, Normal 2,18%: modelele diferă cel mai mult când volatilitatea se schimbă

Pasul 4: ratele depășirilor




- Ponderea zilelor cu pierdere peste prognoza VaR 1%, 2005–2026; banda gri: intervalul binomial de 95% dacă rata adevărată este 1%

Interpretarea pasului 4: acoperire și independență

Model	Depășiri	Rata	p_{uc}	p_{ind}	p_{cc}	Zona roșie
HS	79	1,45%	0,002	<0,001	<0,001	5,5%
Normal	122	2,25%	<0,001	<0,001	<0,001	18,6%
GARCH-t	80	1,47%	0,001	0,864	0,005	0,0%
FHS	67	1,23%	0,095	0,267	0,134	0,0%


- ▣ p_{uc} : testul de acoperire Kupiec; p_{ind} : testul de independență Christoffersen; p_{cc} : ambele împreună [Kupiec \(1995\)](#), [Christoffersen \(1998\)](#)
- ▣ Zona roșie: ponderea ferestrelor de 250 de zile cu cel puțin 10 depășiri (semaforul Basel)
- ▣ Doar FHS trece toate cele trei teste la 5%; HS și Normal pică și testul de independență: depășirile lor se grupează
- ▣ GARCH- t are depășiri independente, dar prea multe: coada Student- t nu este suficient de groasă la 1%

Pasul 4: depășirile din ultimele 250 de zile



- Numărul depășirilor pe o fereastră mobilă de 250 de zile, cu zonele Basel verde, galbenă și roșie
- Modelul Normal petrece 18,6% din ferestre în zona roșie, HS 5,5%, cele două modele cu filtru GARCH niciodată

Capcana informației din viitor în studiul de caz



- Cuanțila HS din tot eșantionul: 1,01% depășiri, prin construcție; GARCH- t din tot eșantionul: 1,31%
- Ambele par mai bune decât versiunile în timp real: diferența este valoarea unei informații pe care nimeni nu o avea

Recapitulare: studiul de caz

- ▣ BET prezintă toate faptele stilizate: cozi groase, grupări, o anumită autocorelație liniară
- ▣ GARCH- t surprinde grupările; reziduurile filtrate au încă cozi groase
- ▣ Un filtru GARCH cu o coadă empirică (FHS) este singurul VaR 1% care trece testele de acoperire și independență
- ▣ Designul în timp real contează: estimările pe tot eșantionul înfrumusețează orice model
- ▣ Aceiași patru pași sunt un șablon pentru proiectul vostru

Ce este proiectul

- ▣ Un studiu empiric al unei întrebări despre piețele financiare, cu metodele acestui curs
 - ▶ Echipe; patru pași: replicare, extindere, livrare pe GitHub, prezentare și susținere (slide-ul următor)
- ▣ Reprezintă **70%** din nota finală; quiz-urile și activitatea la seminar 20%, prezența 10%
- ▣ Puncte de plecare: întrebarea din Partea C a fiecărui seminar (secțiunea următoare)
 - ▶ O întrebare proprie este binevenită dacă trece de cele cinci întrebări din acest capitol
- ▣ Un proiect bun se poate încheia cu un răspuns negativ, dacă dovezile sunt oneste și precise

Proiectul în patru pași

- ▣ **1. Replicați:** reproduceți o cifră publicată (un tabel, un coeficient, un rezultat de backtest) dintr-un articol sau din curs
 - ▶ Un asistent AI nu poate ghici o cifră publicată exactă: dacă o obțineți, datele și codul vostru sunt corecte
- ▣ **2. Extindeți:** date noi, altă piață (BVB, crypto) sau un eșantion mai recent
 - ▶ O întrebare clară, cu răspuns dat printr-un test, nu doar printr-un grafic
- ▣ **3. Livrați pe GitHub:** cod, descrierea datelor și un README care reproduce fiecare rezultat
 - ▶ [AI_USE.md](#) și [AI_ERRORS.md](#) sunt obligatorii
- ▣ **4. Prezentați și susțineți:** prezentarea echipei, apoi o susținere orală de 10 minute
 - ▶ Fiecare membru explică un rezultat și răspunde la o întrebare de tipul „ce se schimbă dacă...”; notele pot diferi între membri

Alegerea întrebării

O întrebare bună este

- ▣ **Specifică:** o piață, o perioadă, o mărime
- ▣ **Testabilă:** o ipoteză nulă și un reper
- ▣ **Fezabilă:** date pe care le puteți obține și curăța în câteva săptămâni
- ▣ **Relevantă:** răspunsul contează pentru un investitor, o bancă sau o autoritate

Exemple

- ▣ Prea vagă: „Este Bitcoin riscant?”
 - ▶ Mai bună: „Au schimbat ETF-urile spot VaR 1% pe o zi al Bitcoin și ce model îl prognozează cel mai bine din 2024?”
- ▣ Prea largă: „Poate machine learning să prezică piața?”
 - ▶ Mai bună: „Bate un model de boosting modelul log-HAR pentru volatilitatea BET de a doua zi, în QLIKE, 2018–2026?”

Date

- Folosiți datele cursului unde se poate: serii zilnice pentru indici, ETF-uri, acțiuni BVB, cripto și cursuri de schimb, plus date intraday
 - ▶ Surse publice: cursurile de referință BNR, FRED, Kenneth French Data Library, DefiLlama; arhiva BVB pentru indicii românești
- Aplicați convențiile cursului
 - ▶ Prețuri ajustate pentru ETF-uri și acțiuni, valori de închidere pentru indici, cursuri de schimb și cripto
 - ▶ Eliminați zilele de sărbătoare completate și cotațiile de weekend unde piața este închisă; anualizați cu frecvența reală
 - ▶ Mai multe active: join pe prețuri, apoi calculați randamentele
- Căutați valorile eronate înainte de modelare: salturile de $\pm 50\%$ în prețurile ajustate sunt de obicei erori de date

Metode: de la întrebare la capitol

Dacă întrebarea este despre	Porniți de la
Distribuția randamentelor, cozi, predictibilitate	Capitolele 1–2: momente, teste robuste, rapoarte ale varianțelor
Randamente așteptate, factori, portofolii	Capitolele 3–4: Fama–MacBeth, shrinkage, teste Sharpe în afara eșantionului
Volatilitate și corelație	Capitolele 5, 6, 9: GARCH, DCC, copule, log-HAR
Măsurile de risc și capital	Capitolele 7–8: FHS, EVT, backtest-uri, FZ0
Lichiditate, opțiuni, timp continuu	Capitolele 10–12: Amihud, Black–Scholes, VIX, prima de risc a varianței
Proгноză cu ML, deep learning sau text	Capitolele 13–15: CV cu purjare, modele fundamentale, sentiment
Cripto, bule, risc sistemic	Capitolele 16–18: stablecoin-uri, GSADF, CoVaR, rețele

Lista de verificare pentru o evaluare onestă

Înainte să vă uitați la rezultate

- ▣ Scrieți ipoteza, reperul și funcția de pierdere
- ▣ Fixați fereastra de estimare și perioada de test
- ▣ Decideți câte modele și parametri veți încerca

Când raportați

- ▣ Doar rezultate în afara eșantionului pentru afirmații despre prognoză
- ▣ Fiecare cifră principală cu eroare standard, CI sau p -valoare
- ▣ Costuri pentru strategiile de tranzacționare; subperioade și o a doua piață pentru robustețe
- ▣ Ce **nu** a funcționat și de ce

Raportul

- ▣ **1. Întrebare și motivație:** un paragraf, o ipoteză
- ▣ **2. Literatură:** trei până la opt referințe cu link, inclusiv manualele cursului [Franke, Härdle & Hafner \(2019\)](#), [McNeil, Frey & Embrechts \(2015\)](#)
- ▣ **3. Date și replicare:** surse, perioadă, reguli de curățare, statistici descriptive; cifra publicată și valoarea voastră
- ▣ **4. Metode:** modele, fereastră de estimare, reper, funcție de pierdere, teste
- ▣ **5. Rezultate:** tabele și grafice, fiecare cu interpretare
- ▣ **6. Robustețe și limitări; 7. Concluzie:** răspunsul, într-o frază
- ▣ **Cod:** un repository GitHub al cărui README și notebook reproduc fiecare cifră, cu [AI_USE.md](#) și [AI_ERRORS.md](#)

Prezentarea

Structura (aproximativ 12 minute)

- ▣ Întrebarea și de ce contează (1 slide)
- ▣ Datele și un grafic care arată problema (2 slide-uri)
- ▣ Metoda și reperul (2 slide-uri)
- ▣ Rezultatul principal cu incertitudinea lui (2–3 slide-uri)
- ▣ Robustețe, limitări, răspuns (2 slide-uri)

Bune practici

- ▣ Un mesaj pe slide; grafice cu axe lizibile și legenda dedesubt
- ▣ Fiecare membru al echipei prezintă și poate răspunde la întrebări despre cod
- ▣ Apoi o susținere orală de 10 minute: fiecare membru explică un rezultat și răspunde la o întrebare „ce se schimbă dacă...”, fără AI

Evaluarea proiectului (70% din nota finală)

Componentă	Ce urmărim
Replicare (pasul 1)	O cifră publicată reprodusă; orice diferență explicată
Întrebare, date și extindere (pasul 2)	Întrebare specifică și testabilă; date documentate și calendare aliniate
Metode și inferență	Design în timp real, un reper, teste în afara eșantionului, incertitudine
Interpretare	Semnificație economică, limitări, concluzie onestă
Repository GitHub (pasul 3)	README care reproduce fiecare rezultat; AI_USE.md, AI_ERRORS.md
Prezentare și susținere orală (pasul 4)	Individual: un rezultat explicat, răspunsuri la „ce se schimbă dacă...”
Total	70% din nota finală; plus quiz-uri și activitate (20%) și prezență (10%)

- Notele pot diferi între membrii echipei, în funcție de susținerea orală

Calendar

- ▣ Săptămâna 1 după acest capitol: echipa și întrebarea
 - ▶ Trimiteți o propunere de o pagină (șablonul din Seminarul 19, Partea C); deschideți repository-ul GitHub
- ▣ Săptămânile 2–3: datele și replicarea unei cifre publicate (pasul 1)
- ▣ Săptămânile 4–5: extindere, evaluare, robustețe (pasul 2); feedback la seminar
- ▣ Ultimele săptămâni: repository-ul cu README și cele două fișiere AI (pasul 3); prezentarea și susținerea orală (pasul 4)
- ▣ Datele exacte se anunță la curs și la seminar

Unde pierd de obicei puncte proiectele

- ▣ O întrebare care se schimbă după ce se cunosc rezultatele
- ▣ Ajustarea în eșantion prezentată drept putere de prognoză
- ▣ Niciun reper sau un reper slab, ales ca să fie bătut
- ▣ Cifre fără incertitudine; multe teste fără corecție
- ▣ Grafice fără unități, legende peste date, acronime neexplicate
- ▣ Cod care nu rulează sau cifre din raport pe care codul nu le produce
- ▣ Rezultate AI păstrate fără verificare: utilizare nedeclarată, cod neverificat, referințe care nu există

Recapitulare: proiectul de echipă

- ▣ O întrebare specifică și testabilă; un reper; o funcție de pierdere aleasă dinainte
- ▣ Date curate după convențiile cursului; design în timp real; raportare onestă
- ▣ Replicare, extindere, livrare pe GitHub, prezentare și susținere: 70% din notă

Politica AI a cursului

- ▣ **Permis:** asistenți AI pentru cod, depanare, căutarea literaturii și redactare, în proiect și la seminar
- ▣ **Declarat:** fiecare instrument, pentru ce a fost folosit și ce ați verificat voi, în [AI_USE.md](#)
 - ▶ Utilizarea nedeclarată a AI este tratată ca plagiat
- ▣ **Verificat:** răspundeți pentru fiecare rând de cod și de text
 - ▶ „L-a scris AI-ul” nu este o explicație la susținerea orală
 - ▶ Fiecare referință are nevoie de un DOI sau link funcțional; o referință care nu există este tratată ca date fabricate
- ▣ **Fără AI la susținerea orală:** răspundeți singuri, pe baza propriei înțelegeri a proiectului

Cele două fișiere obligatorii

AI_USE.md: declarația

- ▣ Instrumentele: nume, versiune, cine le-a folosit și pentru ce
- ▣ Fișierele sau secțiunile în care ați păstrat cod sau text scris de AI și ce ați schimbat
- ▣ Cum ați verificat cifra replicată, datele, formulele și referințele
- ▣ Ce a făcut echipa fără AI

- ▣ Șabloane în engleză și română: github.com/danpele/MFM/tree/main/project

AI_ERRORS.md: jurnalul erorilor

- ▣ Cel puțin **trei** locuri în care asistentul a greșit
- ▣ Pentru fiecare: ce ați întrebat, ce a răspuns, ce era greșit, cum v-ați dat seama, varianta corectă
- ▣ Erorile prinse sunt un punct forte al proiectului, nu unul slab

Erori AI tipice în modelarea financiară (1/2)

- **Informație din viitor:** o statistică pe fereastră mobilă sau o scalare care include ziua t în prognoza pentru ziua t
 - ▶ Verificare: schimbați ultima observație; prognoza pentru acea zi nu trebuie să se miște; decalați cu o zi (`.shift(1)`)
- **Semnul VaR:** cuantila 1% a randamentelor raportată drept VaR sau cuantila 99% a randamentelor (un câștig) folosită ca pierdere
 - ▶ Verificare: $\text{VaR}_\alpha = -q_\alpha(r) > 0$ pentru o pierdere; VaR 1% al unui indice zilnic este de câteva procente, nu negativ
- **Anualizare:** volatilitatea zilnică înmulțită cu 252 în loc de $\sqrt{252}$ sau 252 de zile folosite pentru crypto, care se tranzacționează zilnic
 - ▶ Verificare: mediile se scalează cu h , volatilitățile cu $\sqrt{h}$; folosiți numărul real de zile de tranzacționare (365 pentru crypto)

Erori AI tipice în modelarea financiară (2/2)

- ❑ **Validare încrucișată (CV) aleatoare pe serii de timp:** K-fold amestecat învață din viitor; în Capitolul 13 raportează o acuratețe de 69,4% pe zgomot pur
 - ▶ Verificare: există o dată de test anterioară unei date de antrenare? Folosiți validare walk-forward sau CV cu purjare și embargo [López de Prado \(2018\)](#)
- ❑ **Referințe inventate:** autori, titlu și revistă plauzibile, dar articolul nu există
 - ▶ Verificare: căutați fiecare DOI pe [Crossref](#); deschideți articolul și găsiți afirmația citată
- ❑ **Tot frecvente:** grade de libertate greșite într-un test, valori implicite din biblioteci pe care nu le-ați ales, cifre date fără să fi rulat vreun cod
 - ▶ Fiecare seminar are un exercițiu C2 care vă antrenează să prindeți astfel de erori

Recapitulare: utilizarea AI în proiect

- ▣ Folosiți AI liber, declarați-l în `AI_USE.md` și verificați fiecare rând pe care îl scrie
- ▣ Cifra replicată este cel mai bun test: un AI nu o poate ghici
- ▣ Notați cel puțin trei erori AI în `AI_ERRORS.md`; la susținerea orală răspundeți singuri

Idei de proiect: Partea C a fiecărui seminar (1/2)

Cap.	Întrebarea deschisă (link către seminar)
0	Au schimbat ETF-urile spot corelația Bitcoin cu acțiunile?
1	A scăzut autocorelația BET-TR după reclasificarea FTSE?
2	A devenit BVB mai eficientă după reclasificarea FTSE din 2020?
3	Există prime factoriale la Bursa de Valori București?
4	Un portofoliu optim de blue chips BVB în RON
5	Este volatilitatea pieței românești determinată de SUA?
6	Au devenit acțiunile din România și din zona euro mai integrate după 2020?
7	Capitalul pentru un portofoliu BVB vs un portofoliu S&P 500

- ☐ Fiecare seminar oferă datele, o metodă de pornire și o analiză de referință discutată la seminar

Idei de proiect: Partea C a fiecărui seminar (2/2)

Cap.	Întrebarea deschisă (link către seminar)
8	Ce model de risc ați certifica pentru portofoliul de tranzacționare al unei bănci românești?
9	Este volatilitatea Bitcoin mai previzibilă decât cea a S&P 500?
10	Are iliciditatea o primă pe BVB?
11	Ce model în timp continuu se potrivește pentru BET și Bitcoin?
12	Este prima de risc a varianței un semnal tranzacționabil?
13	Bate un model fundațional boosting-ul?
14	Poate un model fundațional zero-shot să înlocuiască GARCH pentru BET?

- Seminarele 15–18 adaugă întrebări despre sentiment, active digitale, bule și risc sistemic

Cum transformăm o idee într-un proiect

- ▣ Replicați mai întâi: o cifră publicată dintr-un articol din spatele ideii (pasul 1)
- ▣ Restrângeți-o: o piață, o perioadă, un număr de prognozat sau de testat
 - ▶ Exemplu: Seminarul 8 devine „Care dintre HS, FHS și GARCH-EVT dă un VaR 1% corect pentru un portofoliu 50/50 BET–EUR în 2015–2026?”
- ▣ Extindeți-o: o a doua piață, un model nou, un eșantion mai lung sau mai recent
 - ▶ Exemplu: adăugați un model fundațional (Capitolul 14) ca filtru de volatilitate în FHS
- ▣ Păstrați analiza de referință ca reper și încercați să o îmbunătățiți în mod onest

O întrebare deschisă

Cât dintr-un rezultat vine din date și cât din cercetător?

- 164 de echipe au testat aceleași ipoteze pe aceleași date: dispersia răspunsurilor, **erorile nestandard**, a fost mare și subestimată de echipe [Menkveld et al. \(2024\)](#)
 - A fost mai mică pentru cercetarea mai reproductibilă și a scăzut după etapele de evaluare colegială
- Replicarea nu este fără speranță: într-un model bayesian al replicării, majoritatea factorilor de evaluare a activelor se replică și funcționează în afara eșantionului în 93 de țări [Jensen, Kelly & Pedersen \(2023\)](#)
- Asistenții AI fac aproape gratuită orice specificație în plus: drumurile care se ramifică se înmulțesc, dar și posibilitatea de a le raporta pe toate
 - Forma formală pentru un proiect: concluzia trebuie să reziste pe o mulțime preînregistrată S de specificații justificabile, cu familia corectată (FWER sau FDR); raportăm distribuția ei pe S , nu celula cea mai bună

Bucula descoperirii, pas cu pas (1/2)

- **Săptămâna 1, întrebarea:** transformăm o idee în H_0/H_1 , cu o țintă de replicare
 - ▶ „Iată ideea noastră din Partea C a Seminarului N. Dă trei versiuni mai precise și testabile, cifra publicată pe care ar replica-o fiecare și seriile din data/market de care are nevoie.”
- **Săptămânile 1–2, literatura și ținta:** cifra de replicat este una pe care ați văzut-o în PDF
 - ▶ „Listează cele mai citate și cele mai recente articole despre această întrebare, cu DOI; pentru fiecare, estimarea principală, tabelul și eșantionul.”
 - ▶ Rezolvați fiecare DOI pe [Crossref](#); căutați cu Semantic Scholar, Elicit sau Google Scholar; deschideți voi tabelul
- **Săptămâna 2, ipoteze și preînregistrare,** salvează înaintea primului rezultat
 - ▶ „Pentru H_0 și H_1 , listează ipotezele concurente și implicația care le separă; apoi scrie o preînregistrare: eșantion, filtre, ferestre, teste, corecție.”
 - ▶ Istoricul commit-urilor din repository este dovada că planul a fost primul

Bucula descoperirii, pas cu pas (2/2)

- **Săptămânile 2–3, cod și replicare:** cifra replicată devine un test în repository
 - ▶ „Scrie o funcție care reproduce cifra publicată din data/market și o aserțiune cu toleranța pe care o acceptăm.”
- **Săptămânile 4–5, extindere și robustețe:** rulăm toată grila preînregistrată
 - ▶ „Iată toate celulele rulate. Ce concluzii rezistă corecției Holm și pe care le-ar numi un recenzent căutare oportunistă în date (data snooping)?”
- **Înainte de susținere, critica:** asistentul întreabă, echipa răspunde
 - ▶ „Joacă rolul examinatorului la susținerea orală: pune cele zece cele mai grele întrebări despre identificare, inferență și date. Nu le răspunde.”
 - ▶ Echipa răspunde fără AI, ca la susținerea propriu-zisă
- **Raportul:** distribuția rezultatelor pe grilă, nu celula cea mai bună; prompturile în AI_USE.md, erorile prinse în AI_ERRORS.md

Ce trebuie să verifice omul

- **Ținta de replicare există:** cifra, tabelul și eșantionul luate din articol, nu din rezumatul asistentului
 - ▶ Test: raportul citează pagina și tabelul; un al doilea membru găsește acolo aceeași cifră
- **Planul a fost primul**
 - ▶ Test: în istoricul commit-urilor, preînregistrarea precede primul fișier de rezultate
- **Drumuri ramificate:** mai multe specificații încercate decât raportate
 - ▶ Test: fiecare rulare își scrie configurația și rezultatul într-un jurnal; raportul le dă numărul și corectează familia
- **Reproductibilitatea:** cifre scrise direct în raport
 - ▶ Test: o clonă nouă și o singură comandă regenerează fiecare cifră până la ultima zecimală raportată
- **Înțelegerea:** fiecare membru poate deduce formula-cheie și poate apăra fiecare alegere
 - ▶ Test: o susținere de probă în echipă, fără AI, cu o săptămână înaintea celei reale

Mini-caz: replicăm, apoi extindem

- **Replicăm:** VaR 1% FHS pentru BET; Capitolul 8 raportează 59 depășiri în 4 937 zile (1,20%, Kupiec $p = 0,181$)
 - ▶ Studiul de caz din acest capitol: 67 în 5 432 zile (1,23%, $p = 0,095$); același model, alt început al evaluării (2007 față de 2005) și alte setări: documentăm orice diferență înainte de a declara o replicare eșuată
- O propunere tipică a asistentului, care citește fiecare valoare p separat la 5%: „doar GARCH-EVT este calibrat corect pe toate cele patru active”
- **Extindem:** cele 24 teste de acoperire condiționată din Capitolul 8 (4 active $\times$ 6 modele) formează o familie
 - ▶ Respingeri la 5%: 12 fără corecție, 10 cu Holm (FWER), 11 cu BH (FDR 5%)
 - ▶ FHS eșuează doar pe S&P 500 ($p = 0,040$); în familia de 24 teste rezistă, deci după Holm FHS și GARCH-EVT trec pe toate cele patru active
- Interpretare: „FHS eșuează pentru S&P 500” depinde de citirea testului separat sau în familia lui; preînregistrăm familia și le raportăm pe amândouă

Rândul vostru: planul final

- **Întrebarea:** ideea voastră din Partea C, scrisă ca H_0/H_1 , cu observația care ar infirma-o
- **Replicați întâi:** o cifră publicată, văzută în articol, transformată într-un test care trece în repository
 - ▶ Apoi extindeți pe o grilă preînregistrată, cu familia corectată și distribuția completă raportată
- **Livrabile** de-a lungul calendarului: propunerea și ținta de replicare, commit-ul de preînregistrare, testul de replicare care trece, grila de rezultate, susținerea de probă, raportul, susținerea orală
- **Jurnalul AI:** prompturile care au schimbat designul în AI_USE.md; fiecare eroare prinsă, cu testul care a prins-o, în AI_ERRORS.md ([șabloane](#))

Idei de reținut

- ▣ Randamentele sunt greu de prezis; riscul lor nu: volatilitatea, cozile și dependența pot fi prognozate
- ▣ Orice model este judecat în afara eșantionului, față de un reper simplu, cu o funcție de pierdere potrivită țintei
- ▣ Cozile groase schimbă inferența: folosiți erori robuste și bootstrap, raportați intervale
- ▣ Cele mai multe rezultate greșite vin din design, nu din model: informație din viitor, supraajustare, testare multiplă, calendare
- ▣ Instrumentele noi (ML, modele fundamentale, LLM-uri) ridică exigența evaluării, nu o scad

Studiu suplimentar

Manuale

- Franke, Härdle & Hafner (2019); Härdle, Chen & Overbeck (2017); McNeil, Frey & Embrechts (2015); Tsay (2010)

Cursuri avansate pe quantinar.com

-  Statistics of Financial Markets
-  Measuring Statistical Risk

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_19

Bibliografie (1/3)

- ▣ Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- ▣ Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Black, F., Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 637–654.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Christoffersen, P.F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- ▣ Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification: how inefficient is the $1/N$ portfolio strategy?. *Review of Financial Studies*, 22(5), 1915–1953.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- ▣ Fama, E.F. (1970). Efficient capital markets: a review of theory and empirical work. *Journal of Finance*, 25(2), 383–417.
- ▣ Fissler, T., Ziegel, J.F. (2016). Higher order elicibility and Osband's principle. *Annals of Statistics*, 44(4), 1680–1707.

Bibliografie (2/3)

- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). *Applied Quantitative Finance*, 3rd ed. Springer.
- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- ▣ Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance?. *Journal of Finance*, 78(5), 2465–2518.
- ▣ Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- ▣ López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- ▣ Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- ▣ McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- ▣ McNeil, A.J., Frey, R., Embrechts, P. (2015). *Quantitative Risk Management: Concepts, Techniques and Tools*, revised ed. Princeton University Press.
- ▣ Menkveld, A.J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). Nonstandard errors. *Journal of Finance*, 79(3), 2339–2390.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.

Bibliografie (3/3)

- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). *Are cryptos becoming alternative assets?*. *European Journal of Finance*, 29(10), 1064–1105.
- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed. Wiley.