









Modelarea piețelor financiare

Capitolul 19: Recapitulare și prezentarea proiectelor



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Ce face dintr-un rezultat o concluzie?

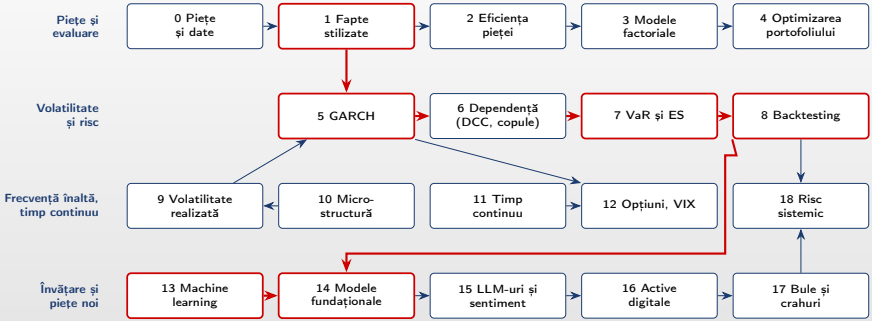
Riscul de coadă și evaluarea prognozelor

- Întrebarea: cînd merită încredere un rezultat empiric despre piețe și cînd reflectă doar datele, felul în care a fost construită analiza sau norocul?
- Partea I: cursul într-o singură imagine, recapitularea capitolelor 0–18, șase capcane și un studiu de caz integrat, de la prețurile brute ale BET (indicele de referință al Bursei de Valori București, BVB) la un Value-at-Risk (VaR) de 1% validat prin backtesting
- Firul principal: GARCH (Generalised AutoRegressive Conditional Heteroskedasticity) prognozează volatilitatea, DCC (Dynamic Conditional Correlation) corelațiile, iar VaR și ES (Expected Shortfall, pierderea medie dincolo de VaR) le transformă într-o pierdere
- Partea a II-a: proiectul de echipă, inteligența artificială (AI) în proiect, un studiu de caz de cercetare despre erorile nestandard, o parcurgere a buclei de descoperire asistate de AI
- Traseul de bază pentru propunerea de peste o săptămînă: cele șase capcane, studiul de caz BET (Pașii 1–5) și proiectul de echipă
  - Recapitularea pe capitole, studiul erorilor nestandard și Anexa servesc ca referință și aprofundare

Ce trebuie să puteți face

- Duceți o întrebare de la date la o prognoză de risc validată, cu inferență corectă
- Recunoașteți cele șase capcane în propriul cod
- Scrieți un plan de proiect cu replicare, identificare, putere și grilă de specificații

Cursul într-o singură imagine



Ce leagă etapele analizei

- Roșu: firul principal, de la faptele stilizate (Capitolul 1: cozi groase, volatility clustering, adică gruparea zilelor agitate și a celor calme, aproape nicio predictibilitate liniară) la prognoze de risc verificabile (Capitolele 5–8: GARCH dă σ_{t+1}, VaR și ES dau pierderea, backtesting-ul arată dacă prognoza este fiabilă)
- Capitolele 9–12 îmbunătățesc măsurarea volatilității (date intraday, prețuri de opțiuni, VIX, indicele volatilității implicite a S&P 500) și o modelează în timp continuu
  - Capitolele 13–15 aduc modele flexibile, inclusiv modele lingvistice mari (Large Language Models, LLM), evaluate mereu cu instrumentele din Capitolul 8
- Capitolele 16–18 aplică aceleași instrumente activelor cripto, bulelor și întregului sistem financiar
  - Capitolul special 20: volatilitatea realizată prognozată cu semnătura traiectoriei, pe datele VOLARE (VOLatility Archive for Realized Estimates, o arhivă de estimatori ai volatilității realizate)

Cinci întrebări pentru orice model

Înainte de estimare

- **Date**: ce serie, ce calendar, ce ajustări (dividende, split-uri, sărbători)?
- **Model**
  - ce fapt stilizat surprinde?
  - ce ignoră?
- **Estimare**: pe ce fereastră, cu ce informație la momentul t?

După estimare

- **Evaluare**
  - În afara eșantionului, cu o funcție de pierdere potrivită țintei (QLIKE, pierderea de cvasi-verosimilitate pentru prognoze de varianță; FZ0, scorul Fissler–Ziegel pentru perechea VaR–ES) și cu testele de diagnostic potrivite (de exemplu Kupiec)?
- **Incertitudine**: erori standard robuste, bootstrap, test față de un reper simplu?
- Fără răspuns la fiecare întrebare, rezultatul nu constituie încă o concluzie

Capitolele 0–2: piețe, randamente și eficiență

- **Capitolul 0, Piețele financiare în 2026**
  - Piețele combină burse, dealeri extrabursieri, fonduri tranzacționate la bursă (exchange-traded funds, ETF), algoritmi și blockchain-uri
  - 2015–2026: SPY (ETF pe S&P 500, cu dividende reinvestite) are un CAGR (Compound Annual Growth Rate, rata anuală compusă de creștere) de 13,7% pe an și o volatilitate anualizată de 17,6%
  - Bitcoin: un CAGR de 60,6% pe an și o volatilitate anualizată de 66,7%
  - BET, iulie 2007 – februarie 2009: un drawdown (scăderea de la vîrful anterior pînă la minim) de $-82{,}5\%$
- **Capitolul 1, Fapte stilizate și randamente**
  - Randamentele sînt necorelate, dar nu independente: mărimea lor este previzibilă, semnul aproape deloc
  - BET, indicele Hill al pierderilor (cele mai mari $k = 153$ pierderi): $\hat{\alpha} = 2{,}39$, CI (Confidence Interval, interval de încredere) 95% prin bootstrap pe blocuri $[2{,}12; 3{,}03]$ (α: tail index, probabilitatea unei pierderi peste x scade ca $x^{-\alpha}$): momentul de ordinul patru este probabil infinit
  - Zilele dincolo de 5σ sînt de peste 1 000 de ori mai frecvente decît implică distribuția Normală (Normal: $2\Phi(-5) \approx 5{,}7 \times 10^{-7}$ pe zi, o asemenea zi la aproximativ 7 000 de ani)
- **Capitolul 2, Eficiența pieței**
  - Prețurile reflectă pe deplin informația disponibilă
  - Un test al predictibilității randamentelor anormale este un test comun al eficienței și al modelului de randament așteptat Fama (1970)
  - Ponderea ferestrelor mobile în care mersul aleator este respins: S&P 500 6,4%, BET 22,4%, Bitcoin 0,0%
  - O respingere statistică nu înseamnă profit exploatabil

Capitolele 3–5: evaluarea activelor, portofolii și GARCH

- **Capitolul 3, Modele factoriale și evaluarea activelor**
  - Randamentele așteptate ar trebui să remunereze doar expunerea la factori sistematici
  - 25 de portofolii după mărime și raportul valoare contabilă/de piață: panta SML (security market line, dreapta pieței titlurilor) este $-4{,}4\%$, iar statistica GRS (testul comun că toate constantele sînt zero) este 4,18 (valoarea critică de 5% a distribuției $F(25, T-26)$: cel mult aproximativ 1,7 cînd $T-26 \geq 60$, deci $p < 0{,}01$): CAPM (Capital Asset Pricing Model, modelul de evaluare a activelor financiare) este respins
  - ETF-uri sectoriale: prima componentă principală (piața) explică 66% din varianță
- **Capitolul 4, Optimizarea portofoliului**
  - Markowitz formulează corect problema, dar eroarea de estimare domină soluția Markowitz (1952)
  - Pe eșantioane de 60 de luni, raportul Sharpe median este 1,57 în eșantion, dar raportul Sharpe adevărat median este doar 0,30
  - 96% dintre portofoliile tangente estimate au de fapt performanțe inferioare portofoliului 1/N
- **Capitolul 5, Volatilitate condiționată: GARCH**
  - Din cauza volatility clustering-ului, șocul de azi anticipează varianța de mîine Engle (1982), Bollerslev (1986)
  - S&P 500, 2000–2026: persistența $\alpha + \beta = 0{,}9947$ (α, β: ponderile GARCH(1,1) ale ultimului șoc și ale ultimei varianțe), un timp de înjumătățire $\ln 0{,}5 / \ln(\alpha + \beta)$ de 131 de zile
  - BET: CI 95% din verosimilitatea profil pentru $\alpha + \beta$ este $[0{,}975; 1]$ (IGARCH, GARCH-ul integrat cu $\alpha + \beta = 1$, nu este respins): timpul de înjumătățire este de cel puțin 27 de zile, fără o limită superioară finită

Capitolele 6–8: dependență, măsuri de risc și backtesting

- **Capitolul 6, Volatilitate multivariată și dependență**
  - Corelațiile se schimbă odată cu regimul macroeconomic; diversificarea nu este garantată
  - SPY–TLT (TLT: ETF pe obligațiuni americane pe termen lung): corelația ρ a urcat de la $-0{,}40$ la 0,11 după 2022, iar volatilitatea unui portofoliu 60/40 a crescut de la 10,4% la 13,2%
  - Corelația DCC dintre Bitcoin și SPY: 0,04 înainte de 2020 și 0,31 de atunci
- **Capitolul 7, VaR și Expected Shortfall**
  - VaR este o cuantilă a pierderii, iar ES este pierderea medie dincolo de ea și este o măsură de risc coerentă
  - S&P 500, zilnic: VaR-ul istoric $\mathrm{VaR}_{1\%} = 3{,}45\%$, iar $\mathrm{ES}_{1\%} = 5{,}01\%$
  - VaR-ul bazat pe distribuția Normală este de doar 2,80%: cozile groase contează
- **Capitolul 8, Backtesting și evaluarea prognozelor de risc**
  - Testăm numărul și momentul depășirilor: acoperirea și independența Kupiec (1995), Christoffersen (1998)
  - S&P 500, VaR 1%, 2007–2026: rata depășirilor (ținta este 1%) este 2,70% pentru modelul Normal, 1,67% pentru HS (simulare istorică), 1,23% pentru FHS (simulare istorică filtrată) și 1,13% pentru GARCH-EVT (filtru GARCH cu o coadă din teoria valorilor extreme, EVT)
  - Un filtru GARCH combinat cu o coadă flexibilă dă cele mai bune rezultate pe toate cele patru piețe

Capitolele 9–11: frecvență înaltă, lichiditate și timp continuu

- **Capitolul 9, Volatilitate realizată**
  - Prețurile intraday măsoară varianța zilnică (RV, Realised Variance, varianța realizată)
  - Modelul log-HAR (Heterogeneous AutoRegressive, autoregresiv heterogen) surprinde memoria ei lungă Corsi (2009)
  - SPY: kurtosis-ul randamentelor de la deschidere la închidere este 15,73, iar după împărțirea la $\sqrt{RV_t}$ scade la 2,65
  - log-HAR reduce QLIKE față de GARCH(1,1)-t cu 10% pentru SPY ($p = 0{,}021$) și cu 22% pentru Bitcoin
- **Capitolul 10, Microstructura pieței**
  - Prețurile se formează în registre de ordine limită; spread-ul compensează costurile de procesare, riscul de inventar și selecția adversă
  - Raportul Amihud (puncte de bază, bp, la 1 milion USD): SPY 0,0016, Banca Transilvania 24,7, Transelectrica 1 024,0
  - SPY: variația prețului în primele 5 minute este de 2,06 ori mai mare decît într-un interval de aceeași durată de la prînz
- **Capitolul 11, Modele în timp continuu**
  - Mișcarea browniană este limita mersurilor aleatoare; lema lui Itô permite rezolvarea ecuațiilor diferențiale stochastice ale prețurilor
  - S&P 500 față de mișcarea browniană geometrică (Geometric Brownian Motion, GBM): 62 de zile dincolo de ± 4 abateri standard, față de 0,59 așteptate
  - Tail index-ul Hill al pierderilor S&P 500 este sub 4 (Capitolul 16): momentul de ordinul patru este probabil infinit, spre deosebire de randamentele log ale GBM, distribuite Normal

Capitolele 12–14: opțiuni, machine learning și modele fundaționale

- **Capitolul 12, Opțiuni și suprafața de volatilitate**
  - Black–Scholes evaluează opțiunile prin hedging; volatilitatea implicită este estimarea pieței pentru σ Black & Scholes (1973)
  - 1990–2026: VIX-ul mediu este 19,4, iar volatilitatea realizată medie în luna următoare este 15,3
  - Prima de risc a variației este pozitivă în 86% din zile, dar nu și în perioadele de crah
- **Capitolul 13, Machine Learning în finanțe**
  - Modelele sînt flexibile, dar semnalul este slab și zgomotul mare; specificul finanțelor ține de procesul de validare López de Prado (2018)
  - Validarea K-fold cu amestecare raportează o acuratețe de 69,4% pe zgomot pur: leakage (informație din setul de test scursă în antrenare)
  - S&P 500: seria diferențiată fracționar devine staționară la $d^* = 0{,}25$
  - Niciun model nu depășește regula naivă „piața crește mereu"
- **Capitolul 14, Deep learning și modele fundaționale pentru serii de timp**
  - LSTM-urile (Long Short-Term Memory, rețele cu memorie pe termen lung și scurt) și Transformerele învață din secvențe, iar modelele fundaționale prognozează zero-shot, fără antrenare pe seria analizată
  - Prognoza volatilității realizate a SPY, pierderea QLIKE (mai mică este mai bine): Chronos-2 0,231, log-HAR 0,234, GARCH-t 0,283
  - Chronos-2 și log-HAR nu diferă semnificativ
  - VaR 1% din Chronos-2, fără recalibrare, pe S&P 500: rata depășirilor este 1,67%

Capitolele 15–16: text și active digitale

- **Capitolul 15, LLM-uri și analiza sentimentului**
  - De la dicționare la FinBERT și la modelele lingvistice mari (Large Language Models, LLM): textul este transformat într-o variabilă numerică
  - Qwen 7B față de Qwen 1.5B pe titluri financiare: acuratețea crește cu 21,5 puncte procentuale, testul McNemar $p < 0{,}001$
  - O strategie pe sentimentul titlurilor are un raport Sharpe de $+0{,}63$ înainte de costuri și de $-1{,}48$ după costuri
  - Costul de tranzacționare care anulează cîștigul: 1,5 bp (puncte de bază) pe tranzacție
- **Capitolul 16, Active digitale și DeFi**
  - Criptomonedele formează o clasă de active distinctă în spațiul caracteristicilor din Pele et al. (2023), unde un factor legat de cozi le separă
  - DeFi (Decentralised Finance, finanțele descentralizate) funcționează prin contracte inteligente
  - Legătura Bitcoin–S&P 500: sup-Wald 20,2 (cea mai mare statistică Wald de ruptură pe datele candidate; valoarea critică de 5% 11,6), ruptura estimată pe 9 mar. 2020, nu la lansarea ETF-urilor din 2024
  - Tail index-ul Hill al pierderilor: Bitcoin 2,73 (interval de încredere [2,12; 3,33]), S&P 500 2,87 (interval [2,07; 3,67]), pe eșantioanele din Capitolul 16; Seminarul 19 folosește Bitcoin 2014–2026 cu $k = 104$, deci valoarea Bitcoin diferă ușor: cozile cripto nu sînt semnificativ mai groase decît cele ale acțiunilor sau ale aurului

Capitolele 17–18: bule și risc sistemic

- **Capitolul 17, Bule și crahuri**
  - O bulă este o traiectorie a prețului care crește mai repede decît o pot justifica fundamentele
  - Bitcoin 2014–2026 (săptămînal): GSADF (cea mai mare statistică de rădăcină unitară pe coada din dreapta, pe toate ferestrele) 3,85 față de valoarea critică de 95% 2,27: sînt detectate episoade explozive
  - Un regim față de două regimuri Markov pentru Bitcoin: statistica raportului de verosimilitate $LR = 123{,}2$, valoarea critică de 95% din bootstrap parametric 11,8 ($p = 0{,}005$)
- **Capitolul 18, Risc sistemic și rețele**
  - Riscul sistemic: pierderile unei instituții care se propagă în tot sistemul
  - ΔCoVaR 1% (variația VaR 1% al sistemului cînd o bancă trece de la mediană la stres) pentru unsprezece bănci: 4 din 25 de perechi din aceeași regiune diferă la 5%, 0 după Holm (o corecție pentru testarea simultană a multor perechi: capcana testării multiple)
  - Comparația prin simpla suprapunere a intervalelor nu ar fi ierarhizat nicio pereche
  - LRMES simulat (pierderea așteptată a unei bănci cînd piața scade cu peste 10% în 22 de zile): JPMorgan 10,6% în prezent, față de 23,7% cu informația din 31 martie 2020

Capcane metodologice: look-ahead bias și overfitting

- **Look-ahead bias** (informația din viitor): estimarea oricărui parametru, prag sau factor de scalare pe tot eșantionul introduce informație din viitor
  - Exemple: parametri GARCH din tot eșantionul, standardizare pe tot eșantionul, etichete care se suprapun cu setul de test (studiul de caz măsoară efectul pe BET)
  - Capitolul 13: validarea K-fold cu amestecare raportează o acuratețe de 69,4% pe zgomot pur
  - Remediu: ferestre mobile sau în extindere, purging și embargo, plus mulțimea de informație $\mathcal{F}_{t-1}$ scrisă lîngă fiecare prognoză
- **Overfitting-ul**: ajustarea în eșantion recompensează zgomotul, care nu se repetă în afara eșantionului
  - Capitolul 4: pentru aceleași portofolii, raportul Sharpe este 1,57 în eșantion, dar doar 0,30 cel adevărat
  - Overfitting-ul backtest-ului: încercăm multe strategii și o păstrăm pe cea mai bună Bailey et al. (2017)
  - Raportul Sharpe deflatat corectează pentru numărul de încercări și pentru randamentele non-normale Bailey & López de Prado (2014)
  - Remediu: fixați planul analizei înainte de a vă uita la perioada de test
  - Raportați toate modelele încercate
  - Comparați cu un reper simplu (1/N, simulare istorică, mers aleator, log-HAR)

Capcană metodologică: testarea multiplă

- Capitolul 3: din 300 de factori fără putere explicativă, în medie 15,0 trec de $|t| > 1{,}96$, iar cel mai bun ajunge la $|t| \approx 3{,}06$
  - De aceea literatura despre factori cere $|t| > 3$ Harvey, Liu & Zhu (2016)
- Anomalii de calendar, reguli de tranzacționare, specificații de model: fiecare test în plus adaugă o șansă de descoperire falsă
- Remediu: numărați testele și corectați
  - Bonferroni și Holm controlează probabilitatea de a face cel puțin o descoperire falsă (FWER)
  - Benjamini–Hochberg controlează ponderea așteptată a descoperirilor false (FDR)
  - Pentru prognoze: mulțimea de încredere a modelelor (MCS) în locul multor teste pe perechi Hansen, Lunde & Nason (2011)

Capcană de date: alinierea randamentelor în locul prețurilor

- Bitcoin se tranzacționează zilnic, SPY doar în zilele lucrătoare
  - Greșit: calculăm fiecare randament pe calendarul propriu, apoi păstrăm zilele comune: mișcările Bitcoin din weekend dispar
  - Corect: păstrăm zilele comune ale **prețurilor**, apoi calculăm randamentele: ziua de luni acoperă intervalul vineri–luni pentru ambele
- Bitcoin, 2020–2026, în zilele comune: randament cumulat 1 025% (corect) față de 680% (greșit)
  - Abaterea standard a zilei de luni 5,04% (corect) față de 3,83% (greșit): alinierea greșită ascunde riscul din weekend
  - Aceste cifre pentru 2020–2026 sînt verificarea de replicare din Seminarul 19, B8; partea nouă a exercițiului este perioada 2015–2019
- Remediu: aliniați întîi prețurile pe zilele comune
- O serie analizată singură rămîne pe calendarul propriu

Capcană de inferență: ignorarea cozilor groase

- Erorile standard clasice presupun independență și momente de ordinul patru finite
  - Pierderile BET: tail index-ul Hill $\hat{\alpha} = 2{,}39$, CI 95% prin bootstrap pe blocuri [2,12; 3,03] Hill (1975)
  - Momentele de ordin $\geq \alpha$ sînt infinite: cu $\alpha < 4$, kurtosis-ul populației este infinit
  - Deci excesul de kurtosis de selecție (11,1) nu estimează nimic, iar un interval bootstrap pentru el nu este valid Athreya (1987): raportați tail index-ul
- Persistența GARCH pentru BET, $p = \alpha + \beta$ (aici α, β: parametrii GARCH(1,1)): CI Wald [0,974; 1,007] depășește $p = 1$, frontiera regiunii de parametri $p \leq 1$ pe care o impunem
  - Dacă p adevărat poate fi 1, aproximarea asimptotică Normală nu mai este validă Andrews (1999) (slide-ul următor)
  - CI din verosimilitatea profil (toate valorile p a căror statistică a raportului de verosimilitate, maximizată după ceilalți parametri, este sub valoarea critică), în spațiul parametrilor $p \leq 1$: [0,975; 1] (IGARCH, $p = 1$, nu este respins față de valoarea critică la frontieră 2,71, cuantila de 95% a unui amestec 50:50 între 0 și χ^2_1), deci timpul de înjumătățire este de cel puțin 27 de zile și nu are o limită superioară finită
- Remediu: erori HAC (Heteroskedasticity and Autocorrelation Consistent, robuste la heteroscedasticitate și autocorelație), bootstrap pe blocuri acolo unde este valid, tail index-uri în loc de kurtosis, intervale care respectă frontiera

Persistența aproape de 1: care frontieră?

- $p \leq 1$ este o restricție pe care o alegem, nu o proprietate a modelului GARCH: în interior, cu persistența strict sub unu, varianța necondiționată și timpul de înjumătățire sînt finite
  - Egalitatea reprezintă frontiera IGARCH
  - Fără ea, un p puțin peste 1 este admisibil: procesul poate fi totuși strict staționar, cînd $E \ln(\alpha z_t^2 + \beta) < 0$ Nelson (1990), dar nu are varianță finită și nici timp de înjumătățire
- Estimarea pentru BET, $\hat{p} = 0{,}9907$, este în interiorul regiunii; dificultatea vine de la p **adevărat**, care poate fi egal cu 1
  - La $p = 1$ estimatorul nu este aproximativ Normal, deci intervalul Wald [0,974; 1,007] nu este informativ sub restricția noastră, nu „greșit"
- Sub restricție, testul raportului de verosimilitate pentru $H_0 \colon p = 1$ are distribuția de frontieră $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ Andrews (1999)
  - Valoarea critică de 5% este 2,71 în loc de 3,84; BET: $LR = 1{,}01$, cu un p-value de 0,16, deci IGARCH ($p = 1$) nu este respins
  - Valorile critice de frontieră se aplică doar cînd parametrul adevărat se poate afla pe marginea spațiului impus, nu ori de cîte ori o estimare este aproape de o limită

Capcană de evaluare: o funcție de pierdere care nu poate ierarhiza ținta

- Prognozele de varianță se compară cu un proxy zgomotos (r_t^2 sau RV_t)
  - Cu un proxy condiționat nedeplasat, MSE (Mean Squared Error) și QLIKE ierarhizează prognozele la fel ca varianța adevărată
  - QLIKE depinde doar de raportul proxy/prognoză, deci zilele volatile cîntăresc mai puțin decît la MSE Patton (2011)
  - Capitolul 9: log-HAR bate GARCH în QLIKE, dar comparația în MSE nu este concludentă
- ES singur nu are o funcție de scor strict consistentă pe clasele largi obișnuite de distribuții
  - Perechea (VaR, ES) are, în condiții de regularitate slabe Fissler & Ziegel (2016)
  - Folosiți FZ0 cu teste Diebold–Mariano Diebold & Mariano (1995), ținînd cont că precizia lor este limitată în eșantioane finite Pele & Mazurencu-Marinescu-Pele (2026)
- Remediu: alegeți funcția de pierdere înainte de comparație și precizați-o în raportul proiectului

O întrebare, patru capitole

Întrebarea

- Cît poate pierde mîine o poziție pe indicele BET, cu probabilitatea de 1%?
- Pe ce prognoză a acestei pierderi ne-am fi putut baza în timp real, în 2005–2026?

Date

- Indicele BET, valori oficiale zilnice de închidere, 6 ian. 2000 – 18 sept. 2026: 6 670 de randamente log zilnice
- Randamentul log, în %: $r_t = 100 \ln(P_t / P_{t-\mathbf{1}})$, iar pierderea $L_t = -r_t$
  - Nu este variația procentuală simplă $R_t = 100(P_t/P_{t-\mathbf{1}} - 1)$: o creștere de 10% dă $r_t = 9{,}53\%$, o scădere de 10% dă $r_t = -10{,}54\%$
  - Randamentele log se adună de la o zi la alta
- Au fost eliminate înregistrările duplicate (rînduri identice cu cel anterior) și rîndurile datate în weekend
  - Zilele de tranzacționare cu închidere neschimbată se păstrează

Cei cinci pași

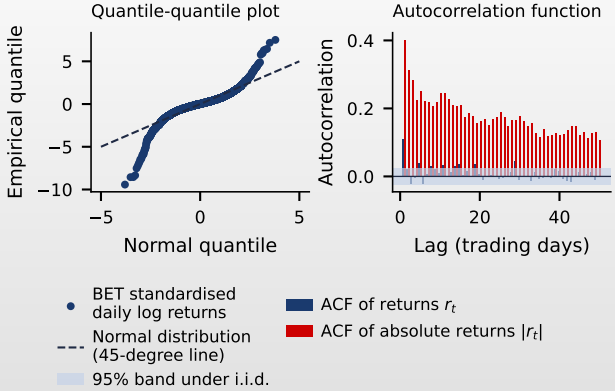
- Capitolul 1: fapte stilizate, cu inferență robustă
- Capitolul 5: GARCH(1,1) cu inovații Student-t
- Capitolul 7: VaR 1% pentru o zi, din patru modele
- Capitolul 8: acoperire, independență și zonele Basel
- Compararea formală a celor patru modele: pierderea FZ0, teste Diebold–Mariano (DM), mulțimea de încredere a modelelor

Un simbol, patru sensuri: α în studiul de caz

Unde	Sensul lui α	Valoarea	Intră în
Pasul 1, Hill	tail index-ul pierderilor	2,39	$P(L > x)$ scade ca $x^{-\alpha}$
Pasul 2, GARCH	ponderea pătratului șocului de ieri	0,192	$\sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$
Pașii 3–4, VaR și Kupiec	nivelul VaR: probabilitatea promisă a depășirii	1%	LR_{uc}, DQ
Pasul 5, FZ0 și ES	nivelul ES cu care se evaluează perechea (VaR, ES)	2,5%	$S(v, e; y)$

- Înainte de a înlocui o cifră, întrebați-vă despre ce α este vorba în formulă: testul Kupiec cere $\alpha = 0{,}01$, niciodată 2,39 sau 0,192
- Și litera p are două sensuri aici: persistența GARCH $p = \alpha + \beta$ și p-value-ul unui test

Pasul 1: faptele stilizate ale BET (1/2)



MFM_ch19_case_study

Pasul 1: faptele stilizate ale BET (2/2)

- Cozi groase (stînga, cuantilele față de cele ale distribuției Normale)
  - Tail index-ul Hill al pierderilor $\hat{\alpha} = 2{,}39$, CI 95% [2,12; 3,03] (bootstrap pe blocuri, cele mai mari $k = 153$ pierderi)
  - 51 de zile dincolo de ± 4 abateri standard, față de 0,42 cîte ar fi de așteptat sub distribuția Normală
  - Cea mai mare pierdere zilnică: $-13{,}1\%$, pe 7 ian. 2009
- Volatility clustering (dreapta)
  - ACF (funcția de autocorelație) a lui $|r_t|$ la lagul 1: 0,40, cu o scădere lentă
  - Banda presupune randamente i.i.d. (independente și identic distribuite)
  - Statistica Ljung–Box $Q(10)$ pe r_t^2 este 2 440, față de valoarea critică de 5% de 18,3
- Un VaR Normal cu volatilitate constantă: prea mic în stres, prea mare în perioadele calme

MFM_ch19_case_study

Pasul 1: interpretarea faptelor stilizate

- Tail index-ul Hill $\hat{\alpha} = 2{,}39 < 4$: kurtosis-ul nu este raportat ca estimare (capcana de inferență)
- Ljung–Box $Q(10)$: testul comun că primele 10 autocorelații sînt zero
  - Aplicat pe r_t^2, testează volatility clustering-ul
  - Sub H_0, $Q(10) \sim \chi^2_{10}$, distribuția hi-pătrat cu 10 grade de libertate
- Autocorelația de ordinul 1 a randamentelor înseși: 0,11
  - O valoare tipică pentru o piață mai puțin lichidă (Capitolele 2, 10)

Pasul 2: modelul GARCH(1,1)-t

- Varianța de azi este o sumă ponderată dintre o constantă, pătratul șocului de ieri și varianța de ieri Bollerslev (1986)

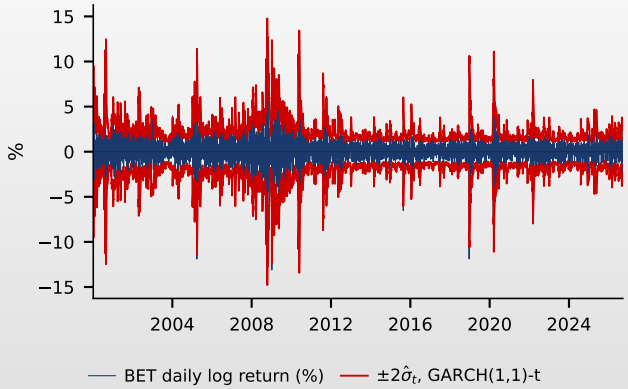
$$r_t = \mu + \varepsilon_t, \qquad \varepsilon_t = \sigma_t z_t, \qquad \sigma_t^2 = \omega + \alpha\, \varepsilon_{t-1}^2 + \beta\, \sigma_{t-1}^2$$

  - r_t: randamentul log zilnic, μ: media, ε_t: șocul
  - σ_t: volatilitatea condiționată, cunoscută în $t-1$
  - z_t: i.i.d. Student-t cu ν grade de libertate, scalat la varianța 1
  - $\omega > 0$, $\alpha, \beta \geq 0$: α măsoară reacția la știri, β memoria
  - Un ν mic înseamnă cozi groase ($\nu \to \infty$ dă distribuția Normală)
- Dacă persistența $\alpha + \beta < 1$, procesul este staționar în covarianță, iar un șoc de varianță scade cu factorul $\alpha + \beta$ în fiecare zi

$$h_{1/2} = \frac{\ln 0{,}5}{\ln(\alpha + \beta)}$$

  - $h_{1/2}$: timpul de înjumătățire, numărul de zile după care a dispărut jumătate dintr-un șoc de varianță
  - $\alpha + \beta = 1$ (IGARCH, GARCH integrat): șocurile nu se mai sting
- Modelul se estimează prin verosimilitate maximă, cu erori standard robuste (sandviș), iar slide-ul următor dă estimările pentru BET

Pasul 2: volatilitatea GARCH(1,1)-t



- Randamentele log zilnice ale BET cu $\pm 2\hat{\sigma}_t$ dintr-un GARCH(1,1) cu inovații Student-t, 2000–2026
  - Estimările, cu erorile standard robuste în paranteză: $\hat{\alpha} = 0{,}192$ (0,025), $\hat{\beta} = 0{,}799$ (0,024), $\hat{\nu} = 5{,}01$: cozi groase chiar după filtrare
- Persistența $\hat{\alpha} + \hat{\beta} = 0{,}9907$, un timp de înjumătățire de aproximativ 74 de zile de tranzacționare
  - CI 95% din verosimilitatea profil $[0{,}975; 1]$: persistența nu poate fi separată de 1 (capcana de inferență)
- Volatilitatea condiționată zilnică a atins maximul de 7,39% pe 15 oct. 2008, iar la finalul eșantionului $\hat{\sigma}_T = 1{,}67\%$ (18 sept. 2026), iar prognoza pentru ziua următoare este $\hat{\sigma}_{T+1} = 1{,}76\%$

MFM_ch19_case_study

Pasul 2: volatilitatea de azi și nivelul de termen lung

- Două cifre la finalul eșantionului: $\hat{\sigma}_T$ este cunoscut în $T-1$, iar $\hat{\sigma}_{T+1}$ folosește și ultimul randament $r_T = 2{,}17\%$ și intră în VaR-ul de mîine

$$\hat{\sigma}^2_{T+1} = \hat{\omega} + \hat{\alpha}\,(r_T - \hat{\mu})^2 + \hat{\beta}\,\hat{\sigma}^2_T = 0{,}0448 + 0{,}192\,(2{,}17 - 0{,}08)^2 + 0{,}799 \times 1{,}67^2 = 3{,}11$$

  - Deci $\hat{\sigma}_{T+1} = \sqrt{3{,}11} = 1{,}76\%$: un ultim randament mare ridică prognoza peste $\hat{\sigma}_T = 1{,}67\%$

- Varianța de termen lung implicată de model

$$\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta} = \frac{0{,}0448}{0{,}0093} = 4{,}82$$

  - Randamentele sînt în %, deci $\bar{\sigma}^2$ este în %^{2}: $\bar{\sigma} = 2{,}20\%$ pe zi, 34,7% pe an cu frecvența observată de 249,82 randamente pe an (A5 din seminar fixează 252 și parametri rotunjiți), față de o abatere standard de selecție de 1,40% pe zi (varianța 1,96) și 22,1% pe an

- De ce diferența nu este o contradicție: numitorul $1-\alpha-\beta = 0{,}0093$ este mic și imprecis
  - Cu ω fix, $p = 0{,}9867$ dă $\bar{\sigma}^2 = 3{,}37$, iar $p = 0{,}9947$ dă 8,47; CI din verosimilitatea profil ajunge la $p = 1$, unde $\bar{\sigma}^2$ este infinită
  - Folosiți $\hat{\sigma}_{T+1}$ și traiectoria prognozei pe orizonturi scurte; tratați nivelul de termen lung ca slab identificat

Pasul 3: patru prognoze VaR 1% (1/2)

- Necondiționate, pe ultimele 500 de zile: o singură cuantilă pentru toată fereastra
  - **HS** (simulare istorică): pierderea $L = -r$ depășită în 1% din ultimele 500 de zile (cuantila empirică)
  - **Normal**: $\mathrm{VaR} = -(\hat{\mu} + \hat{\sigma} z_{\mathbf{0,01}})$, cu $\hat{\mu}$, $\hat{\sigma}$ media și abaterea standard de selecție și $z_{\mathbf{0,01}} = -2{,}326$ cuantila de 1% a distribuției Normale standard
- Condiționate, GARCH-t pe ultimele 1 000 de zile: cuantila se scalează cu prognoza volatilității de azi $\hat{\sigma}_t$

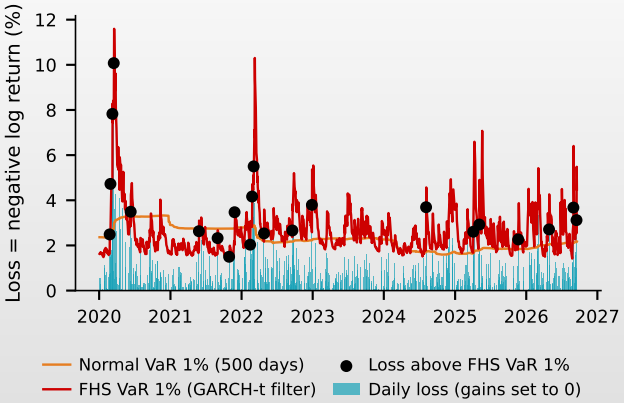
$$\textbf{GARCH-}t\textbf{:}\ \ \mathrm{VaR}_t = -\left(\hat{\mu} + \hat{\sigma}_t\, t_\nu^{-\mathbf{1}}(0{,}01)\sqrt{(\nu-2)/\nu}\right), \qquad \textbf{FHS}\colon\ \mathrm{VaR}_t = -\left(\hat{\mu} + \hat{\sigma}_t\, \hat{q}_{\mathbf{0,01}}(z)\right)$$

  - $t_\nu^{-\mathbf{1}}(0{,}01)$: cuantila de 1% a unei distribuții Student-t cu ν grade de libertate, iar factorul $\sqrt{(\nu-2)/\nu}$ o rescalează la varianța 1
  - **FHS** (simulare istorică filtrată): $\hat{q}_{\mathbf{0,01}}(z)$, cuantila empirică de 1% a reziduurilor standardizate $z_t = (r_t - \hat{\mu})/\hat{\sigma}_t$, înlocuiește cuantila Student-t McNeil & Frey (2000)

Pasul 3: patru prognoze VaR 1% (2/2)

- Procedură în timp real
  - Prognoza pentru ziua t folosește doar datele pînă la $t-1$
  - Parametrii GARCH sînt reestimați la fiecare 21 de zile de tranzacționare, iar $\hat{\sigma}_t$ este actualizat zilnic
- Evaluare: 3 ian. 2005 – 18 sept. 2026, $T = 5\,432$ zile
  - O depășire în ziua t: pierderea $-r_t$ depășește VaR_t
  - Numărul așteptat de depășiri la 1%: $0{,}01\,T \approx 54$
- Modelele necondiționate reacționează doar pe măsură ce fereastra avansează, iar cele condiționate reacționează prin $\hat{\sigma}_t$, în cîteva zile

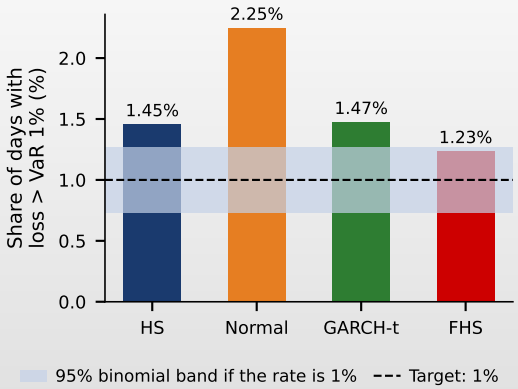
Pasul 3: pierderi și VaR 1%, 2020–2026



- Pierderile zilnice ale BET (cîștigurile sînt trunchiate la 0) și prognozele VaR 1% Normal și FHS
- Punctele negre marchează pierderile peste VaR-ul FHS
- FHS reacționează în cîteva zile: a atins 11,6% pe 18 mar. 2020, în timpul crahului din pandemia COVID-19
  - VaR Normal pe o fereastră de 500 de zile se ajustează lent
- În cele 1 675 de zile erau de așteptat aproximativ 17 depășiri, iar depășirile efective au fost 22 (FHS) și 41 (Normal)
  - Depășirile modelului Normal se grupează în primele săptămîni ale fiecărui episod de stres
- Ultima prognoză VaR: 4,48% pentru FHS și 2,18% pentru Normal: modelele diferă cel mai mult cînd volatilitatea se schimbă

MFM_ch19_case_study

Pasul 4: ratele depășirilor



- Ponderea zilelor cu pierdere peste prognoza VaR 1%, în cele $T = 5\,432$ zile de evaluare din Pasul 3
- Banda albastru deschis: intervalul binomial de 95% [0,74%; 1,27%] dacă rata adevărată este 1%
- Doar FHS (1,23%) se află în bandă, în timp ce modelul Normal (2,25%) este depășit de peste două ori mai des decît ar trebui
- Urmează
  - sînt diferențele semnificative?
  - sînt depășirile independente?

MFM_ch19_case_study

Pasul 4: cele trei backtest-uri

- Testul de acoperire Kupiec Kupiec (1995): este rata depășirilor egală cu $\alpha = 1\%$?

$$LR_{uc} = -2 \ln \frac{(1-\alpha)^{T-x}\alpha^{x}}{(1-\hat{\pi})^{T-x}\hat{\pi}^{x}} \sim \chi^2_1, \qquad \hat{\pi} = x/T$$

  - x: numărul depășirilor în T zile, $\hat{\pi}$: rata observată a depășirilor
  - $LR_{uc} = 0$ cînd $\hat{\pi} = \alpha$, iar la 5% respingem cînd $LR_{uc} > 3{,}84$

- Testul de independență Christoffersen Christoffersen (1998): este o depășire azi mai probabilă după o depășire ieri?

$$LR_{ind} = -2 \ln \frac{(1-\hat{\pi})^{n_{00}+n_{10}}\,\hat{\pi}^{\,n_{01}+n_{11}}}{(1-\hat{\pi}_{01})^{n_{00}}\,\hat{\pi}_{01}^{n_{01}}\,(1-\hat{\pi}_{11})^{n_{10}}\,\hat{\pi}_{11}^{n_{11}}} \sim \chi^2_1$$

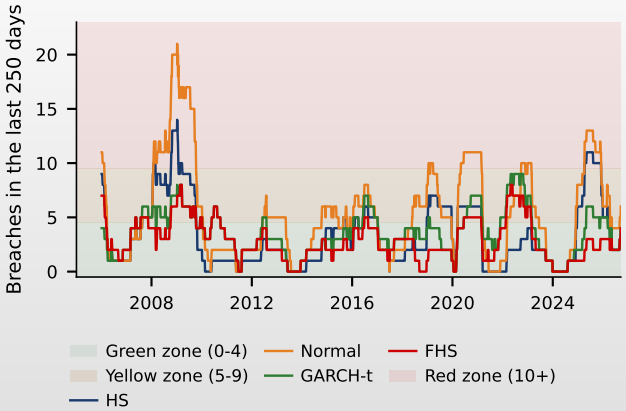
  - n_{ij}: numărul zilelor în starea j după o zi în starea i (1 = depășire, 0 = fără depășire)
  - $\hat{\pi}_{01} = n_{01}/(n_{00}+n_{01})$, $\hat{\pi}_{11} = n_{11}/(n_{10}+n_{11})$: ratele depășirilor după o zi fără depășire și după o depășire
  - În LR_{ind}, $\hat{\pi} = (n_{01}+n_{11})/(n_{00}+n_{01}+n_{10}+n_{11})$, rata depășirilor pe cele $T-1$ tranziții; diferă de x/T din testul Kupiec cu cel mult $1/(T-1)$
  - Testul comun: $LR_{cc} = LR_{uc} + LR_{ind} \sim \chi^2_2$, cu valoarea critică de 5% egală cu 5,99, iar p-value-urile p_{uc}, p_{ind}, p_{cc} se calculează din distribuțiile χ^2 corespunzătoare

Pasul 4: testele de acoperire și independență

Model	Depășiri	Rata	p_{uc}	p_{ind}	p_{cc}	Zona roșie
HS	79	1,45%	0,002	<0,001	<0,001	5,5%
Normal	122	2,25%	<0,001	<0,001	<0,001	18,6%
GARCH-t	80	1,47%	0,001	0,864	0,005	0,0%
FHS	67	1,23%	0,095	0,267	0,134	0,0%

- Zona roșie: ponderea ferestrelor de 250 de zile cu cel puțin 10 depășiri (semaforul Basel)
- Doar FHS nu este respins de niciunul dintre cele trei teste la 5%
- HS și Normal sînt respinse și de testul de independență, deoarece depășirile lor se grupează
- GARCH-t: independența nu este respinsă, dar depășirile sînt prea multe: coada Student-t nu este suficient de groasă la 1%

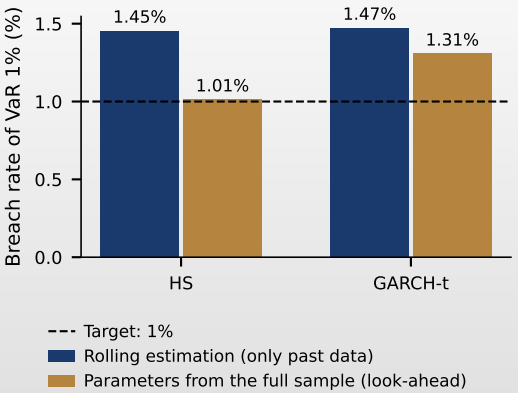
Pasul 4: depășirile din ultimele 250 de zile



- Numărul depășirilor pe o fereastră mobilă de 250 de zile, cu zonele Basel verde, galbenă și roșie
- Normal și HS intră în zona roșie în episoade, cînd depășirile lor se grupează (ponderile: ultima coloană a tabelului din Pasul 4)
- Cele două modele cu filtru GARCH nu intră niciodată în ea

MFM_ch19_case_study

Capcana look-ahead bias în studiul de caz



- Cuantila HS calculată pe tot eșantionul dă, prin construcție, 1,01% depășiri
- GARCH-t cu parametri estimați pe tot eșantionul: depășiri în 1,31% din zile, față de 1,47% cu estimare pe fereastră mobilă
- Ambele par mai bune decît versiunile în timp real: diferența măsoară valoarea unei informații indisponibile în timp real
- Doar rezultatul pe fereastră mobilă este o dovadă despre un model de prognoză

MFM_ch19_case_study

Pasul 5: trei instrumente pentru compararea formală (1/2)

- Testul **Dynamic Quantile (DQ)** Engle & Manganelli (2004): sînt depășirile previzibile?
  - Regresăm $I_t - 0{,}01$ pe o constantă, pe indicatorii depășirilor anterioare $I_{t-1}, \ldots, I_{t-4}$ și pe VaR_t
  - $I_t = 1$ dacă pierderea depășește VaR_t, altfel 0
  - DQ: statistica Wald pentru ipoteza că toți cei șase coeficienți sînt zero, $DQ \sim \chi^2_6$ pentru un model corect
  - Detectează depășirile previzibile din trecut sau din nivelul VaR, pe care testul Christoffersen (un singur lag) le poate rata
- **Scorul FZ0** Patton, Ziegel & Chen (2019): o valoare pe zi care evaluează perechea de prognoze (VaR, ES), iar un scor mai mic este mai bun

$$S(v, e; y) = -\frac{1\{y \le v\}(v - y)}{\alpha e} + \frac{v}{e} + \ln(-e) - 1$$

  - $\alpha = 2{,}5\%$, nivelul ES, nu 1% din Pasul 4 (peste două slide-uri), $v = -\mathrm{VaR}$, $e = -\mathrm{ES}$: prognozele scrise ca cuantile ale randamentelor ($e \le v < 0$)
  - y: randamentul realizat, $1\{\cdot\}$: 1 dacă condiția este îndeplinită, altfel 0
  - Strict consistent pentru (VaR, ES) Fissler & Ziegel (2016): în medie, perechea adevărată are scorul cel mai mic

Pasul 5: trei instrumente pentru compararea formală (2/2)

- Compararea scorurilor FZ0 a două modele
  - Teste Diebold–Mariano pe perechi Diebold & Mariano (1995): $t = \bar{d}/\sqrt{\hat{\Omega}/T}$, d_t fiind diferența FZ0 dintre cele două modele în ziua t, $\hat{\Omega}$ dispersia ei de termen lung HAC (Newey–West)
  - $t \approx N(0,1)$ la acuratețe egală
  - Mulțimea de încredere a modelelor la 10% Hansen, Lunde & Nason (2011): mulțimea care conține cel mai bun model cu probabilitatea 90%
  - p_{MCS}: un model rămîne în mulțime cît timp $p_{MCS} \geq 0{,}10$
- **Verificarea ES**
  - Comparativă, față de HS ca model standard
  - Roșu dacă modelul este semnificativ mai slab, verde dacă este semnificativ mai bun, galben în rest Nolde & Ziegel (2017)

Pasul 5: ce pereche de prognoze evaluează FZ0?

- O a doua pereche de prognoze, din aceleași patru modele, la nivelul ES din Basel, $\alpha = 2{,}5\%$: VaR 2,5% și ES 2,5%
  - Nu VaR 1% din Pașii 3–4: FZ0 este consistent doar cînd *v* și *e* sînt cuantila și media cozii la același nivel α
- ES 2,5% al fiecărui model este pierderea medie dincolo de propriul VaR 2,5%, din aceeași distribuție a pierderilor pe care modelul o folosește pentru VaR în Pasul 3
  - **HS**: media pierderilor din fereastră aflate dincolo de cuantila empirică de 2,5%
  - **Normal**: $\mathrm{ES} = -\hat{\mu} + \hat{\sigma}\,\varphi(z_{\mathbf{0{,}025}})/0{,}025 = -\hat{\mu} + 2{,}338\,\hat{\sigma}$, cu φ densitatea Normală standard
  - **GARCH**-*t*: $-\hat{\mu}$ plus $\hat{\sigma}_t$ înmulțit cu media cozii superioare a distribuției Student-*t* rescalate la varianța 1
  - **FHS**: opusul sumei dintre media condiționată și $\hat{\sigma}_t$ înmulțit cu media reziduurilor standardizate z_t cel mult egale cu cuantila lor de 2,5%
- Exemplu simplu (HS): într-o fereastră de 200 de zile, coada de 2,5% conține 5 zile
  - Dacă pierderile lor sînt 6,1; 5,0; 4,4; 4,0 și 3,5%, ES 2,5% HS este media lor, $23{,}0/5 = 4{,}6\%$

Pasul 5: prognozele ES 2,5% în cifre

Model	VaR 1% mediu (Pașii 3–4)	ES 2,5% mediu (Pasul 5)
HS	3,66%	3,94%
Normal	2,90%	2,92%
GARCH-t	2,95%	3,08%
FHS	3,17%	3,41%

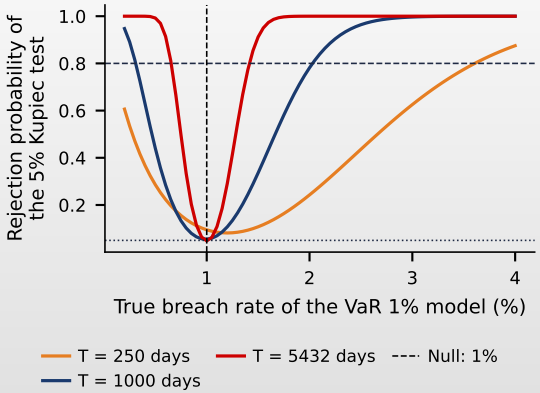
- Medii ale prognozelor zilnice pe cele $T = 5\,432$ zile de evaluare, pierderi în % din poziție
- Verificați că nivelurile diferă: pentru modelul Normal, ES 2,5% / VaR 1% $= 2{,}338/2{,}326 \approx 1{,}005$
  - Tabelul dă $2{,}92/2{,}90 = 1{,}005$: ES 2,5% este apropiat de VaR 1%, în timp ce un ES 1% ar fi cu aproximativ 15% mai mare
- Diferența dintre coloane crește cu grosimea cozii permise de model: aproximativ 7,5% pentru HS și FHS (cozi empirice), 4% pentru GARCH-t, 0,5% pentru modelul Normal

Pasul 5: rezultate

Model	DQ	p_{DQ}	FZ0	p_{MCS}	Zona ES
HS	192,1	<0,001	1,424	0,00	standard
Normal	364,6	<0,001	1,495	0,00	roșu
GARCH-t	17,9	0,007	1,175	0,18	verde
FHS	9,9	0,129	1,157	1,00	verde

- Doar FHS trece testul DQ la 5% ($p = 0{,}129$), în timp ce GARCH-t nu îl trece ($p = 0{,}007$) din cauza excesului de depășiri
- FZ0 (mai mic este mai bun): FHS și GARCH-t nu diferă semnificativ (DM $t = 1{,}39$), ambele sînt superioare modelelor HS și Normal ($|t| > 4{,}9$)
  - Mulțimea de încredere a modelelor la 10% este {GARCH-t, FHS}
- Verificarea comparativă a ES: Normal roșu, GARCH-t și FHS verzi: inferența formală confirmă clasamentul din Pasul 4

Puterea de detecție a unui backtest: testul Kupiec



- Probabilitatea binomială exactă ca testul Kupiec de 5% să respingă un model VaR 1%, după rata reală a depășirilor
- $T = 250$ (un an Basel): o rată reală a depășirilor de 2% este detectată doar în 24% din cazuri
- La $T = 250$, testul respinge doar dacă apar 0 sau cel puțin 7 depășiri
- Efectul minim detectabil (MDE), aici cea mai mică rată reală a depășirilor de pe o grilă cu pasul 0,05 pp care are putere de 80%: 3,65% la $T = 250$, 2,05% la $T = 1\,000$, 1,45% la $T = 5\,432$
  - Chiar la $T = 5\,432$, o rată reală de 1,3% este detectată doar cu probabilitatea 55%
- O nerespingere cu putere mică înseamnă „nicio dovadă", nu „nicio problemă": precizați puterea înaintea testului

MFM_ch19_case_study

Proiectul în patru pași

- Un studiu empiric al unei întrebări despre piețele financiare, cu metodele acestui curs
  - **70%** din nota finală (quiz-uri și activitate la seminar 20%, prezență 10%, fără examen final)
- **1. Replicați**: reproduceți un tabel sau o figură întreagă dintr-un articol publicat (sau din curs), celulă cu celulă
  - Un asistent AI nu poate ghici un tabel publicat (standardul: slide-ul următor)
- **2. Extindeți**
  - Date noi, altă piață (BVB, cripto) sau un eșantion mai recent, după un **plan de analiză** fixat în scris printr-un commit datat în repository înainte de a deschide perioada de test
  - Planul precizează ipoteza nulă, testul, funcția de pierdere, împărțirea eșantionului, strategia de identificare, puterea testului principal și grila de specificații cu corecția ei
- **3. Livrați pe GitHub**: un repository care regenerează fiecare cifră (standardul: slide-ul următor)
  - `AI_USE.md` și `AI_ERRORS.md` sînt obligatorii
- **4. Prezentați și susțineți**: prezentarea echipei, apoi o susținere orală de 10 minute
  - Fiecare membru explică un rezultat și răspunde la o întrebare de tipul „ce se schimbă dacă…"; notele pot diferi între membri

Standardul de replicare

- Ținta: un tabel sau o figură întreagă, cu DOI, pagină și numărul tabelului, nu un singur coeficient
  - Raportați o comparație celulă cu celulă: valoarea publicată, valoarea dumneavoastră, diferența și motivul fiecărei abateri (eșantion, filtru, sursa datelor, definiție)
- Replicările la scară mare arată necesitatea acestui standard: multe anomalii se micșorează în afara eșantionului sau cu date mai bune Hou, Xue & Zhang (2020), iar majoritatea factorilor se replică atunci cînd metodologia este corectă Jensen, Kelly & Pedersen (2023)
- Reproductibilitate: un fișier cu versiunile pachetelor, seed-uri aleatoare fixate, numele seriilor și datele lor, o singură comandă care regenerează fiecare cifră
  - Rezultatele unor echipe diferite care analizează aceleași date diferă mai mult decît sugerează erorile lor standard Menkveld et al. (2024): lucrările mai reproductibile sînt asociate cu o dispersie mai mică (studiul de caz de cercetare din acest capitol)

Alegerea întrebării

O întrebare bună este

- **Specifică**: o piață, o perioadă, o mărime
- **Testabilă**: o ipoteză nulă și un reper
- **Fezabilă**
  - Date pe care le puteți obține și curăța în cîteva săptămîni (datele cursului, în repository-ul GitHub al cursului; surse publice: Banca Națională a României, BNR, Federal Reserve Economic Data, FRED, Kenneth French Data Library, DefiLlama)
- **Relevantă**: răspunsul contează pentru un investitor, o bancă sau o autoritate

Exemple

- Prea vagă: „Este Bitcoin riscant?"
  - Mai bună: „Au schimbat ETF-urile spot VaR 1% pe o zi al Bitcoin?"
  - Apoi: „Ce model îl prognozează cel mai bine din 2024?"
- Prea largă: „Poate machine learning să prezică piața?"
  - Mai bună: „Bate un model de boosting modelul log-HAR pentru volatilitatea BET de a doua zi, în QLIKE, 2018–2026?"

Metode: de la întrebare la capitol

Dacă întrebarea este despre	Porniți de la
Distribuția randamentelor, cozi, predictibilitate	Capitolele 1–2: momente, teste robuste, rapoarte ale variațelor
Randamente așteptate, factori, portofolii	Capitolele 3–4: Fama–MacBeth, shrinkage, teste Sharpe în afara eșantionului
Volatilitate și corelație	Capitolele 5, 6, 9: GARCH, DCC, copule, log-HAR
Măsuri de risc și capital	Capitolele 7–8: FHS, EVT, backtest-uri, FZ0
Lichiditate, opțiuni, timp continuu	Capitolele 10–12: Amihud, Black–Scholes, VIX, prima de risc a variației
Prognoză cu machine learning (ML), deep learning sau text	Capitolele 13–15: purged cross-validation (CV, validare încrucișată), modele fundaționale, sentiment
Cripto, bule, risc sistemic	Capitolele 16–18: stablecoin-uri, GSADF, CoVaR, rețele

- Puncte de plecare: întrebarea din Partea C a fiecărui seminar (tabel în Anexă)
  - O întrebare proprie este binevenită dacă răspunde celor cinci întrebări din acest capitol

Identificarea: de la corelație la o afirmație

- Întrebările despre evenimente („au schimbat ETF-urile spot, reclasificarea FTSE sau o taxă bancară mărimea X?", FTSE: furnizorul de indici FTSE Russell) cer un contrafactual
  - O piață de control neafectată de eveniment: diferența în diferențe pe măsura de risc
  - Un control sintetic construit din mai multe piețe neafectate de eveniment Abadie, Diamond & Hainmueller (2010)
  - Date placebo: evenimentul mutat fictiv cu un an mai devreme sau mai tîrziu
- Dacă momentul este necunoscut: un test sup-Wald de ruptură Andrews (1993), cu data estimată a rupturii raportată, nu una impusă
- Întrebările de prognoză: doar în afara eșantionului, cu o perioadă de test declarată în plan
- Un singur eveniment înseamnă $n = 1$: precizați ce poate și ce nu poate identifica studiul

Putere și robustețe fără p-hacking

- **Putere**: înaintea testului principal, calculați cel mai mic efect pe care testul dumneavoastră îl detectează cu putere de 80% la 5% (MDE)
  - Livrabil: o curbă de putere simulată pentru testul principal la T-ul dumneavoastră
  - Eșantioanele scurte de cripto, ETF-uri sau de după eveniment fac ca multe teste să aibă putere mică (Kupiec la $T = 250$: MDE 3,65%)
- Curba specificațiilor (specification curve): estimați fiecare combinație justificabilă de fereastră, laguri, α și început al eșantionului
  - Reprezentați toate estimările ordonate, cu intervalele lor Simonsohn, Simmons & Nelson (2020)
  - Raportați dispersia pe specificații, nu celula cea mai bună
- Corectați familia: Holm pentru probabilitatea oricărei descoperiri false, Benjamini–Hochberg pentru ponderea lor așteptată sau testul bootstrap reality check al lui White pentru data snooping White (2000)
  - Descoperirile false și cele ratate în finanțe Harvey & Liu (2020)
  - Perspectiva științifică asupra domeniului Harvey (2017)

Evaluarea prognozelor în proiectele despre risc

- Volatilitate: o funcție de pierdere robustă (MSE sau QLIKE) față de un proxy condiționat nedeplasat (capcana de evaluare)
  - Pentru multe modele: mulțimea de încredere a modelelor Hansen, Lunde & Nason (2011), nu modelul cu cea mai mică pierdere medie
- VaR: acoperire, independență și testul DQ Engle & Manganelli (2004)
- Comparația VaR cu un reper: teste de capacitate predictivă condiționată Giacomini & White (2006)
  - Precizați puterea fiecărui backtest la T-ul dumneavoastră
- ES: evaluăm perechea (VaR, ES) cu scorul FZ0
- Verificări comparative ale ES, cu trei zone Nolde & Ziegel (2017)
- Modele dinamice pentru perechea (VaR, ES) Patton, Ziegel & Chen (2019)
  - Studiul de caz integrat (Pașii 1–5) servește drept model

Raportul și prezentarea

Raportul: un articol de 8–12 pagini

- **1. Introducere**: întrebarea, ipoteza, contribuția
- **2. Literatură**: 10–15 referințe cu link, cel puțin 3 din ultimii cinci ani, inclusiv Franke, Härdle & Hafner (2019), McNeil, Frey & Embrechts (2015)
- **3. Date și replicare**: surse, perioadă, reguli de curățare; tabelul replicat, celulă cu celulă
- **4. Metodologie**: plan, identificare, putere, reper, funcție de pierdere, teste
- **5. Rezultate**, cu incertitudinea lor
- **6. Robustețe**: specification curve cu corecția
- **7. Concluzie**: răspunsul într-o frază și limitele lui

Prezentarea (aproximativ 12 minute)

- Slide-urile, în ordine
  - Întrebarea (1)
  - Datele și un grafic care arată problema (2)
  - Metoda și reperul (2)
  - Rezultatul principal cu incertitudinea lui (2–3)
  - Robustețe, limitări, răspuns (2)
- Un singur mesaj pe fiecare slide, axe lizibile, legenda sub grafic
- Fiecare membru prezintă și poate răspunde la întrebări despre cod, apoi urmează susținerea orală, fără AI

Evaluarea proiectului și calendarul

Componentă	Criterii de evaluare
Replicare (pasul 1)	Un tabel sau o figură publicată reprodusă celulă cu celulă; fiecare diferență explicată
Întrebare, date, extindere (pasul 2)	Întrebare specifică și testabilă; date documentate și calendare aliniate
Metode și inferență	Plan, identificare, putere, procedură în timp real, reper, curba specificațiilor cu corecție
Interpretare și raport	Semnificație economică, limitări, concluzie onestă; 8–12 pagini, 10–15 referințe
Repository GitHub (pasul 3)	O singură comandă reproduce fiecare rezultat (fișier de versiuni, seed-uri); `AI_USE.md`, `AI_ERRORS.md`
Prezentare și susținere (pasul 4)	Individual: un rezultat explicat, răspunsuri la „ce se schimbă dacă…”

- Săptămîna 1 după acest capitol: echipa, întrebarea, propunerea de o pagină (Seminarul 19, C2), repository-ul GitHub
  - Săptămînile 2–3: datele, replicarea (pasul 1), planul fixat în scris printr-un commit datat
- Săptămînile 4–5: extindere, evaluare, robustețe (pasul 2)
  - Ultimele săptămîni: repository-ul cu README și cele două fișiere AI (pasul 3), prezentarea și susținerea orală (pasul 4)
  - Datele exacte se anunță la curs și la seminar

Politica AI și cele două fișiere obligatorii

Politica

- **Permis**: asistenți AI pentru cod, depanare, căutarea literaturii și redactare
- **Declarat**: utilizarea nedeclarată a AI este tratată ca plagiat
- **Verificat**: răspundeți pentru fiecare rînd; o referință care nu există este tratată ca date fabricate
- **Fără AI la susținerea orală**: „L-a scris AI-ul" nu este o explicație

Cele două fișiere

- `AI_USE.md`: instrumentele și versiunile, cine le-a folosit și pentru ce, unde ați păstrat cod sau text scris de AI, cum ați verificat tabelul replicat, datele, formulele și referințele
- `AI_ERRORS.md`: cel puțin **trei** locuri în care asistentul a greșit: ce ați întrebat, ce a răspuns, ce era greșit, cum v-ați dat seama, varianta corectă
- Erorile detectate sînt un punct forte al proiectului, nu unul slab

Erori AI tipice în modelarea financiară (1/2)

- **Look-ahead bias**: o statistică pe fereastră mobilă sau o scalare care include ziua t în prognoza pentru ziua t
  - Verificare: modificați ultima observație, iar prognoza pentru acea zi nu trebuie să se schimbe
  - Corectură: decalați statistica cu o zi (`.shift(1)`)
- **Semnul VaR**: cuantila 1% a randamentelor raportată drept VaR sau cuantila 99% a randamentelor (un cîștig) folosită ca pierdere
  - Verificare: $\mathrm{VaR}_\alpha = -q_\alpha(r)$, cu $q_\alpha(r)$ cuantila α a randamentelor, este pozitiv ori de cîte ori $q_\alpha(r) < 0$
  - Ordinul de mărime: VaR 1% pe o zi al unui indice bursier este de cîteva procente
- **Anualizare**: volatilitatea înmulțită cu 252 în loc de $\sqrt{252}$ sau 252 de zile folosite pentru cripto, care se tranzacționează zilnic
  - Verificare: pe h perioade, mediile se scalează cu h, volatilitățile cu $\sqrt{h}$ (randamente i.i.d.)
  - Folosiți numărul real de zile de tranzacționare (365 pentru cripto)

Erori AI tipice în modelarea financiară (2/2)

- **Validare încrucișată (CV) aleatoare pe serii de timp**
  - Validarea K-fold cu amestecare folosește informație din viitor (capcana metodologică, Capitolul 13)
  - Verificare: există o dată de test anterioară unei date de antrenare? Folosiți validare walk-forward sau purged CV cu embargo López de Prado (2018)
- **Referințe inventate**, grade de libertate greșite, valori implicite din biblioteci pe care nu le-ați ales, cifre raportate fără rularea codului
  - Verificare: căutați fiecare DOI pe Crossref și găsiți afirmația în articol, ca în exercițiul de critică a unui răspuns AI din fiecare seminar (Partea C)

Impactul alegerilor cercetătorului (1/2)

- Menkveld et al. (2024), *Journal of Finance* 79(3): 164 de echipe de cercetare testează aceleași șase ipoteze pe aceleași date (Finance Crowd Analysis Project, #fincap; Sec. I.A)
- **Eroarea standard**
  - Incertitudinea datorată eșantionării, în procesul de generare a datelor
  - **eroarea nestandard**: incertitudinea datorată alegerilor metodologice ale cercetătorului, în procesul de producere a dovezilor empirice (Introducere)
  - Modelul: echipa j raportează $X_j = e_j + \varepsilon_j$, e_j fiind efectul fix asociat alegerilor metodologice, iar ε_j eroarea de eșantionare (Sec. I.C, ec. 1)
  - Eroarea nestandard $:= Q_{0,75}(x) - Q_{0,25}(x)$, intervalul intercuartilic (IQR) al estimărilor între echipe (ec. 3), $Q_p(x)$ fiind cuantila p a estimărilor x ale echipelor
  - IQR-ul, nu abaterea standard, pentru că e_j pot avea cozi groase

Impactul alegerilor cercetătorului (2/2)

- **Date**
  - Toate tranzacțiile cu contractele futures pe indicele Euro Stoxx 50, 2002–2018, 720 de milioane de înregistrări
  - Șase ipoteze de tipul „nicio tendință anuală" (eficiența pieței, spread-ul realizat, ponderea clienților în volum, ...)
  - Fiecare echipă raportează variația anuală medie în %, cu eroarea ei standard (SE, Standard Error)
  - Patru etape în 2021: analiza independentă, feedbackul evaluatorilor, distribuirea celor mai bune cinci lucrări, estimările finale; detaliile experimentului în Anexă
- Legătura cu acest capitol: fiecare proiect de echipă este o singură specificație din „grădina potecilor care se bifurcă" (garden of forking paths)
  - Preînregistrarea, grila de specificații și un repository care regenerează fiecare cifră sînt remediile

Rezultatele principale: mărimea și calitatea

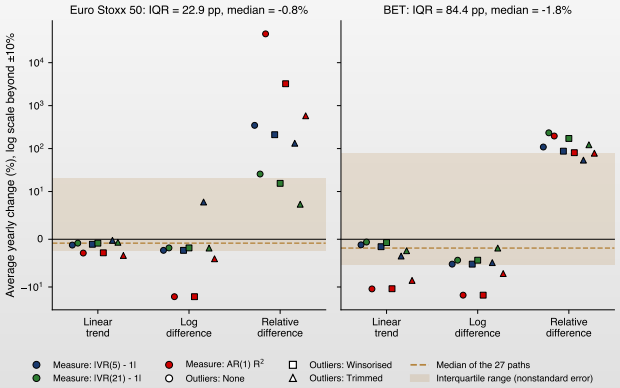
- **Mărimea**
  - Pentru eficiența pieței, estimarea mediană este $-1{,}1\%$ pe an, cu un IQR de 6,7 puncte procentuale (pp)
  - Chiar și pentru ponderea clienților în volum, un simplu raport, IQR-ul este 1,2 pp în jurul valorii $-3{,}3\%$ (Tabelul I, Panoul C)
  - SE-ul median de 2,5% implică, sub distribuția Normală, un IQR de $1{,}35 \times 2{,}5 = 3{,}4\%$ (IQR-ul distribuției Normale este de 1,35 abateri standard), jumătate din 6,7 pp
  - Ipoteza nulă fără dispersie este respinsă pentru toate cele șase ipoteze, $p < 0{,}0001$ (Tabelul II)
- **Calitatea**
  - O creștere cu o abatere standard a reproductibilității este asociată cu un IQR mai mic cu 25,0%, iar aceeași creștere a notei evaluatorilor cu un IQR mai mic cu 33,3% (Tabelul III, Fig. 2)
  - Codul care rulează integral, fără intervenție manuală, este asociat cu răspunsuri mai apropiate de consens

Rezultatele principale: feedback, convingeri și decizii metodologice

- **Feedbackul**: de la etapa 1 la etapa 4, IQR-ul scade cu 47,2%, iar intervalul interdecilic cu 68,2% (Tabelul IV, Fig. 3)
  - Evaluarea colegială reduce dispersia, dar nu o elimină
- **Convingerile**: pe toate ipotezele, abaterea standard a estimărilor anticipată de echipe este cu 71,7% sub cea observată (Sec. II.B.3, Fig. 4)
  - Cercetătorii subestimează cît de mult pot diferi echipele care analizează aceleași date
- **Deciziile metodologice (bifurcațiile)**
  - Alegerea modelului și frecvența eșantionării modifică cel mai mult estimările
  - Un model al variației relative dă o tendință anuală mediană de $-23\,000\%$ pe date zilnice, -200% lunar și $-4{,}56\%$ anual (Fig. 6, Fig. 7)
  - Inegalitatea lui Jensen pentru rapoartele $M_t = X_t/X_{t-1}$: $\mathbb{E} \ln M_t \leq \ln \mathbb{E} M_t$
  - Diferențele logaritmice se adună exact între frecvențe, iar tendința liniară este liniară în date, deci niciuna nu produce această abatere între frecvențe
  - Jensen explică de ce rezultatul depinde de frecvență
  - Pentru o măsură pozitivă, deplasează în sus variația relativă medie, deci nu poate produce singură valorile negative (exemplu simplu după mini-multivers)

Mini-multivers pe datele cursului: 27 de specificații pe indice (1/3)

Legendă: $VR(q)$, raportul variațelor pe q zile; AR(1), modelul autoregresiv de ordinul 1; IQR, intervalul intercuartilic; pp, puncte procentuale.



MFM_ch19_nonstandard_errors

Mini-multivers pe datele cursului: 27 de specificații pe indice (2/3)

- Închideri zilnice 2002–2018 din datele cursului
  - Deciziile din Tabelul V: valori extreme × măsură × model, 27 de specificații
  - Banda este IQR-ul, eroarea nestandard a multiversului
- IQR-ul estimărilor: 22,9 pp pentru Euro Stoxx 50 și 84,4 pp pentru BET
  - Medianele estimărilor sînt $-0{,}8\%$ și, respectiv, $-1{,}8\%$ pe an
- Măsurile ineficienței
  - $|VR(q) - 1|$ ($VR(q)$: raportul variațelor din Capitolul 2, $q = 5, 21$ zile) și R^2 al unui model autoregresiv AR(1): abaterea de la mersul aleator
  - O tendință pozitivă înseamnă o eficiență în scădere

MFM_ch19_nonstandard_errors

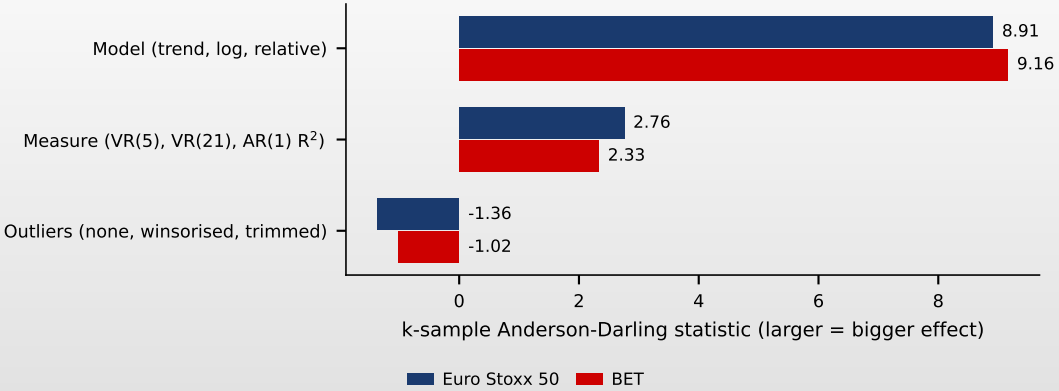
Mini-multivers pe datele cursului: 27 de specificații pe indice (3/3)

- Alegerea modelului determină dispersia
  - Pentru cele nouă specificații cu tendință liniară, IQR-ul este de doar 2,0 pp și 7,5 pp
  - Cu diferențe relative, estimările cresc exploziv: medianele sînt +210,4% (Euro Stoxx 50) și +108,7% (BET), iar maximul ajunge la 46 823%
  - Și articolul raportează explozii ale variațiilor relative (Fig. 7), dar negative
  - Măsurile noastre sînt nenegative, deci aici explodează în sus (exemplu simplu: slide-ul următor)
- Reperul datorat doar eșantionării: IQR-ul sub distribuția Normală, adică 1,35× SE-ul median, 25,9 pp (Euro Stoxx 50) și 50,8 pp (BET)
  - IQR-ul depășește acest reper pentru BET, nu și pentru Euro Stoxx 50
- Aceste cifre pentru 2002–2018 sînt verificarea de replicare din Seminarul 19, C3, care le extinde pînă la ultimul an complet

De ce explodează variațiile relative: un exemplu simplu

- O măsură care revine la valoarea de pornire: $m = (1;\ 0{,}01;\ 1)$
  - Variațiile relative $m_t/m_{t-1} - 1$: -99%, apoi $+9\,900\%$; media lor este $+4\,900{,}5\%$
  - Variațiile logaritmice: $\ln 0{,}01$, apoi $\ln 100$; media lor este exact 0, răspunsul corect pentru o măsură fără tendință
  - Pentru o măsură pozitivă, inegalitatea lui Jensen împinge în sus variația relativă medie (Anexă): multiversul cursului explodează în sus
- O măsură pozitivă nu poate scădea cu mai mult de 100%
  - O tendință anuală de $-23\,000\%$ cere deci alt mecanism: o măsură care își schimbă semnul aproape de zero ($m_{t-1} = 0{,}001$, $m_t = -0{,}2$ dă $-0{,}2/0{,}001 - 1 = -20\,100\%$) sau variații zilnice adunate, nu compuse, într-o rată anuală (250 de variații zilnice de -1% însumează -250%)
  - Mecanismul din spatele cifrelor articolului depinde de felul în care acesta construiește tendința variației relative (Sec. II.C, Fig. 7): verificați-l înainte de a compara semnele cu ale noastre
- Lecția pentru planul dumneavoastră: inspectați numitorii aproape de zero și justificați transformarea
  - Fixați dinainte diferențele logaritmice pentru măsuri pozitive sau tendința liniară

Alegerile care modifică cel mai mult estimările (1/2)



MFM_ch19_nonstandard_errors

Alegerile care modifică cel mai mult estimările (2/2)

- Statistica Anderson–Darling pentru k eșantioane a celor 27 de estimări, grupate după opțiunea de la fiecare decizie (Sec. II.C)
  - Statistica compară distribuțiile celor k grupe: o valoare mai mare înseamnă grupe mai bine separate
  - Este standardizată, deci centrată în 0 cînd grupele sînt egale: o valoare negativă (valorile extreme, mai jos) înseamnă o separare sub cea datorată hazardului
- Valoarea statisticii pentru fiecare decizie, Euro Stoxx 50 și BET
  - Modelul: 8,91 și 9,16
  - Măsura: 2,76 și 2,33
  - Tratarea valorilor extreme: $-1{,}36$ și $-1{,}02$
- Aceeași ordine ca în articol (Fig. 6): alegerea modelului modifică cel mai mult estimările
- O ierarhizare descriptivă, nu un test
  - Cele 27 de estimări folosesc aceleași date
- Rezultatul se menține atît pe un indice mare din zona euro, cît și pe BET, indicele unei piețe de frontieră în 2002–2018 (FTSE Russell: piață emergentă secundară din septembrie 2020)
- Pentru proiectul dumneavoastră
  - Fixați în plan modelul variației anuale (diferențe logaritmice sau tendințe liniare)
  - Raportați toată grila și decizia care o determină

Limite și o extindere deschisă

- **Limite formulate de autori**
  - Multiversul acoperă doar cîteva decizii metodologice și explică slab estimările raportate (nota 32)
  - Echipelor li s-a cerut să anticipeze abaterea standard, nu IQR-ul (nota 28)
  - Testul dispersiei presupune SE-uri raportate consistente (Sec. I.C); dinamica evaluării la reviste rămîne în afara studiului (Sec. I.A)
  - Multiversul acoperă doar opțiunile incluse în grilă; IQR-ul său nu estimează și nu delimitează inferior dispersia dintre echipele reale
- **Limita datelor în replicare**
  - Doar închideri zilnice, deci perechile de frecvențe intrazilnice din Tabelul V nu pot fi rulate (Seminarul 19, C3 o extinde pînă la ultimul an complet)
- **Extindere deschisă**: reduce o grilă preînregistrată eroarea nestandard a unei întrebări de risc?
  - Măsurați IQR-ul concluziilor VaR 1% pentru BET pe specificațiile justificabile

O întrebare deschisă

- **Întrebarea deschisă**: ce parte dintr-un rezultat se datorează datelor și ce parte cercetătorului?
  - Replicarea este posibilă: într-un model bayesian al replicării, majoritatea factorilor de evaluare a activelor se replică și funcționează în afara eșantionului în 93 de țări Jensen, Kelly & Pedersen (2023)
  - Asistenții AI reduc aproape la zero costul fiecărei specificații suplimentare: crește numărul specificațiilor posibile, dar și posibilitatea de a le raporta pe toate
  - Formularea formală: concluzia trebuie să rămînă valabilă pe o mulțime preînregistrată $\mathcal{S}$ de specificații justificabile, cu familia corectată (FWER sau FDR)
  - Raportăm distribuția ei pe $\mathcal{S}$, nu celula cea mai bună

Bucla descoperirii și verificările ei

- **Bucla**
  - Întrebarea și H_0/H_1 (săptămîna 1)
  - Literatura și ținta de replicare văzută în PDF (săptămînile 1–2)
  - Preînregistrarea, fixată în scris printr-un commit datat în repository înaintea primului rezultat (săptămîna 2)
  - Replicarea ca test care trece în repository (săptămînile 2–3)
  - Întreaga grilă (săptămînile 4–5)
  - Un examinator AI înainte de susținere
- **Verificările cercetătorului**
  - Cifra-țintă se află în articol
  - Planul precede primul fișier de rezultate în istoricul commit-urilor
  - Fiecare rulare este jurnalizată și numărată
  - O clonă nouă regenerează fiecare cifră
  - Fiecare membru poate deduce formula-cheie fără AI
  - Prompturile pentru fiecare pas și testul pentru fiecare verificare: ▸ Anexă

Mini studiu de caz: replicăm, apoi extindem

- **Replicăm**: VaR 1% FHS pentru BET; Capitolul 8 raportează 59 de depășiri în 4 937 de zile (1,20%, Kupiec $p = 0{,}181$)
  - Studiul de caz din acest capitol: 67 în 5 432 de zile (1,23%, $p = 0{,}095$)
  - Același model, alt început al evaluării (2007 față de 2005) și alte setări: documentăm orice diferență înainte de a declara o replicare eșuată
- O concluzie tipică propusă de asistent, care citește fiecare p-value separat la 5%: „doar GARCH-EVT este calibrat corect pe ambele piețe"
- **Extindem**
  - Cele 12 teste de acoperire condiționată din Capitolul 8 (S&P 500 și BET $\times$ 6 modele) formează o familie
  - Bitcoin și EUR/RON rămîn în afara ei, deoarece acolo prognozele lor bazate pe GARCH sînt reținute
  - Respingeri la 5%: 8 fără corecție, 6 cu Holm (FWER), 7 cu Benjamini–Hochberg, BH (FDR 5%)
  - FHS eșuează doar pe S&P 500 ($p = 0{,}040$); considerat în familia de 12 teste, nu mai este respins, deci după Holm FHS și GARCH-EVT trec pe ambele piețe
- Interpretare: „FHS eșuează pentru S&P 500" depinde de citirea testului separat sau în familia lui; preînregistrăm familia și le raportăm pe amîndouă

Planul final al echipei

- **Întrebarea**: ideea dumneavoastră din Partea C, scrisă ca H_0/H_1, cu observația care ar infirma-o
- **Replicați întîi**: un tabel publicat, văzut în articol, transformat într-un test care trece în repository
  - Apoi extindeți pe o grilă preînregistrată, cu familia corectată și distribuția completă raportată
- **Livrabile** de-a lungul calendarului: propunerea și ținta de replicare, commit-ul de preînregistrare, testul de replicare care trece, grila de rezultate, susținerea de probă, raportul, susținerea orală
- **Jurnalul AI**: prompturile care au schimbat metodologia în `AI_USE.md`; fiecare eroare detectată, cu testul care a detectat-o, în `AI_ERRORS.md` (șabloane)

Idei de reținut

- Randamentele sînt greu de prezis; riscul lor nu: volatilitatea, cozile și dependența pot fi prognozate
- Orice model este judecat în afara eșantionului, față de un reper simplu, cu o funcție de pierdere potrivită țintei
- Cozile groase schimbă inferența: folosiți erori robuste și bootstrap, raportați intervale, precizați puterea
- Cele mai multe rezultate greșite vin din felul în care este construită analiza, nu din model: look-ahead bias, overfitting, testare multiplă, calendare
- Parcursul analizei este el însuși o sursă de incertitudine: preînregistrați, replicați, raportați toată grila
- Instrumentele noi (ML, modele fundaționale, LLM-uri) ridică exigența evaluării, nu o scad

Verificarea înțelegerii

Întrebări

- De ce o scădere de 10% a BET dă un randament log de $-10{,}54\%$, nu de -10%? Revedeți explicația
- De ce excesul de kurtosis de selecție al randamentelor BET nu estimează nimic? Revedeți explicația
- De ce intervalul Wald pentru persistența GARCH nu este informativ după ce impunem $p \leq 1$? Revedeți explicația
- Ce îl înlocuiește? Revedeți explicația
- Ce vă spune o nerespingere a testului Kupiec la $T = 250$? Revedeți explicația
- De ce IQR-ul unui multivers cu 27 de specificații nu este eroarea nestandard a 164 de echipe? Revedeți explicația

Pentru aprofundare

- Seminarul 19: exercițiile A1–A12, B1–B8 și C1–C3 aplică acest capitol pe BET
- Manuale: Franke, Härdle & Hafner (2019); Härdle, Chen & Overbeck (2017); McNeil, Frey & Embrechts (2015); Tsay (2010)
- Cursuri avansate pe quantinar.com: Statistics of Financial Markets
  - Measuring Statistical Risk
- Cod și date: Quantlets/Ch_19 (GitHub)

Două calcule pe cifre noi

Încercați

- **1.** Un model VaR 1% are $x = 6$ depășiri în $T = 400$ de zile. Calculați LR_{uc} cu formula Kupiec din Pasul 4 și decideți la 5%
- **2.** Un GARCH(1,1) are $\alpha + \beta = 0{,}97$. Calculați timpul de înjumătățire $h_{1/2}$; cum se schimbă dacă $\alpha + \beta = 0{,}985$?

Verificați răspunsul

- **1.** $\hat{\pi} = 6/400 = 1{,}5\%$

$$LR_{uc} = 2\big[(394 \ln 0{,}985 + 6 \ln 0{,}015) - (394 \ln 0{,}99 + 6 \ln 0{,}01)\big] = 0{,}88$$

  - Sub 3,84: nu se respinge; la $T = 400$ testul are putere mică, deci înseamnă „nicio dovadă", nu „nicio problemă"
- **2.** $\ln 0{,}5 / \ln 0{,}97 = 22{,}8$ zile și $\ln 0{,}5 / \ln 0{,}985 = 45{,}9$ zile
  - Înjumătățirea lui $1 - \alpha - \beta$ dublează aproximativ timpul de înjumătățire

Capitolul 0: Piețele financiare în 2026

- Calitatea datelor este o decizie de modelare: sursa, ajustarea și calendarul schimbă rezultatul (Capitolul 0)
- Media și volatilitatea estimate din randamente log i.i.d., anualizate cu numărul de perioade pe an

$$\mathrm{se}(\hat{\mu}_{\mathbf{ann}}) = \frac{\sigma_{\mathbf{ann}}}{\sqrt{Y}}, \qquad \mathrm{se}(\hat{\sigma}) \approx \sigma\sqrt{\frac{K-1}{4T}}$$

  - Se: eroarea standard
  - Y: lungimea eșantionului în ani, indiferent de frecvență
  - T: numărul de randamente zilnice
  - σ, $\sigma_{\mathbf{ann}}$: volatilitatea zilnică și cea anualizată
  - K: kurtosis-ul populației (cere un moment de ordinul patru finit)
  - Dependența în timp cere dispersii de termen lung
- SPY 2015–2026: $\mathrm{se}(\hat{\mu}_{\mathbf{ann}}) \approx 5{,}1\%$ pentru un CAGR de 13,7%, adică un randament log mediu anualizat $\hat{\mu}_{\mathbf{ann}} = 100\ln(1{,}137) = 12{,}8\%$: mediile abia pot fi estimate, volatilitățile da

Înapoi

Capitolul 1: Fapte stilizate și randamente

- Cozi groase și volatility clustering pe toate piețele Cont (2001) (Capitolul 1)
- Testul Ljung–Box al absenței autocorelației pînă la lagul m

$$Q(m) = T(T+2)\sum_{k=1}^{m} \frac{\hat{\rho}_k^2}{T-k} \sim \chi_m^2$$

  - $\hat{\rho}_k$: autocorelația de selecție la lagul k
  - T: mărimea eșantionului
  - Distribuția de referință χ_m^2 cere randamente i.i.d.
  - Cu volatility clustering testul respinge prea des
  - Folosiți Q^* robust, cu termenii $T\hat{\rho}_k^2/\hat{\tau}_k$, $\hat{\tau}_k$ fiind factorul de varianță estimat al lui $\sqrt{T}\hat{\rho}_k$ (aproximativ 1 pentru randamente i.i.d.) Lobato, Nankervis & Savin (2001)
- Cozile: estimatorul Hill $\hat{\alpha}$ al tail index-ului, $\mathrm{se} \approx \hat{\alpha}/\sqrt{k}$ Hill (1975)
  - k: numărul celor mai mari pierderi folosite
  - Dacă $\alpha < 4$, kurtosis-ul de selecție nu este consistent, iar bootstrap-ul lui eșuează Athreya (1987)

Înapoi

Capitolul 2: Eficiența pieței

- Eficiența variază în timp (ipoteza piețelor adaptive), deci testele cer inferență robustă (Capitolul 2)
- Testul raportului variațelor robust la heteroscedasticitate Lo & MacKinlay (1988)

$$VR(q) = \frac{\text{Var}(r_t + \cdots + r_{t-q+1})}{q\,\text{Var}(r_t)}, \qquad z^*(q) = \frac{\widehat{VR}(q) - 1}{\widehat{\text{se}}^*} \Rightarrow N(0,1)$$

  - q: orizontul în perioade
  - $VR = 1$ pentru un mers aleator, $VR > 1$ indică autocorelație pozitivă, iar $VR < 1$ revenire la medie
  - $\widehat{\text{se}}^*$: eroarea standard robustă la heteroscedasticitate
  - $z^* \Rightarrow N(0,1)$ sub ipoteza nulă că randamentele sînt o diferență de martingal
- Mai multe orizonturi q deodată: testul comun $\max_q |z^*(q)|$ cu valori critice de modul maxim studentizat Chow & Denning (1993)
  - Ferestrele mobile cer și ele o corecție pentru testele multiple

Înapoi

Capitolul 3: Modele factoriale și evaluarea activelor

- Sutele de factori publicați cer praguri mai înalte Harvey, Liu & Zhu (2016) (Capitolul 3)
- Testul GRS că toate erorile de evaluare (constantele) sînt zero Gibbons, Ross & Shanken (1989)

$$\mathrm{GRS} = \frac{T-N-K}{N}\,\frac{\hat{\alpha}^\top \hat{\Sigma}^{-1}\hat{\alpha}}{1+\hat{\mu}_f^\top \hat{\Omega}^{-1}\hat{\mu}_f} \;\sim\; F(N, T-N-K)$$

  - T: numărul de perioade, N: numărul de active, K: numărul de factori
  - $\hat{\alpha}$: cele N constante (alpha), $\hat{\mu}_f$: mediile factorilor
  - $\hat{\Sigma}$, $\hat{\Omega}$: matricele de covariață ale reziduurilor și ale factorilor, calculate cu împărțitorul T
  - Distribuția F este exactă doar pentru erori i.i.d. Normale
  - Un GRS mare înseamnă că factorii nu explică randamentele activelor
- Erorile standard Fama–MacBeth ignoră faptul că coeficienții beta sînt estimați: covariança Shanken pentru încărcări factoriale estimate Shanken (1992)

$$\hat{V}_{\mathbf{Sh}} = (1+c)\big(\hat{V}_{FM} - \hat{\Sigma}_f/T\big) + \hat{\Sigma}_f/T, \qquad c = \hat{\gamma}^\top \hat{\Sigma}_f^{-1}\hat{\gamma}$$

  - $\hat{\gamma}$: primele de risc estimate ale factorilor
  - $\hat{\Sigma}_f$: covariança factorilor
  - $\hat{V}_{FM}$: covariança Fama–MacBeth a lui $\hat{\gamma}$
  - $c \geq 0$ o mărește, cu atît mai mult cu cît primele sînt mari față de riscul factorilor

înapoi

Capitolul 4: Optimizarea portofoliului

- Shrinkage-ul, restricțiile și regulile bazate pe risc stabilizează ponderile, iar 1/N este un reper greu de depășit DeMiguel, Garlappi & Uppal (2009) (Capitolul 4)
- Eroarea standard a raportului Sharpe $SR = (\mu - r_f)/\sigma$ pe perioadă, randamente i.i.d. Normale Lo (2002)

$$\text{se}(\widehat{SR}) \approx \sqrt{(1 + \widehat{SR}^2/2)/T}$$

  - μ, σ: media și volatilitatea pe perioadă, r_f: rata fără risc, T: numărul de perioade
  - Autocorelația randamentelor schimbă factorul de anualizare
- Este portofoliul A mai bun decît 1/N? Testăm $SR_A - SR_B = 0$ cu inferență HAC sau bootstrap studentizat Ledoit & Wolf (2008), nu prin compararea a două estimări punctuale

Înapoi

Capitolul 5: Volatilitate condiționată: GARCH

- Persistența este aproape de 1, volatilitatea acțiunilor reacționează asimetric la șocuri, iar inovațiile au cozi groase (Capitolul 5)
- QMLE (cvasi-verosimilitate maximă) pentru GARCH: covariança sandviș Bollerslev & Wooldridge (1992)

$$\sqrt{T}(\hat{\theta} - \theta) \Rightarrow N(0, A^{-1}BA^{-1})$$

  - $\theta = (\omega, \alpha, \beta)$: parametrii din $\sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$
  - A: hessiana așteptată a log-verosimilității Normale, cu semn schimbat
  - B: varianța scorului
  - $A = B$ cînd inovațiile sînt Normale
  - Pentru inovații non-Normale, erorile standard calculate doar din hessiană (A^{-1}) sînt greșite
- Aproape de $\alpha + \beta = 1$, parametrul este lîngă frontiera regiunii de staționaritate în covariança: intervalele Wald nu sînt fiabile
  - Folosiți verosimilitatea profil sau bootstrap restrîns la spațiul parametrilor Andrews (1999)

Înapoi

Capitolul 6: Volatilitate multivariată și dependență

- Copulele separă distribuțiile marginale de dependență, iar dependența în cozi determină pierderile comune (Capitolul 6)
- DCC se estimează în doi pași: erorile standard din pasul al doilea trebuie să țină cont de volatilitățile din primul pas Engle (2002)
- Corelația în criză față de perioada calmă: ρ crește mecanic odată cu volatilitatea, deci testăm pe corelația ajustată Forbes & Rigobon (2002)

$$\rho^* = \frac{\rho}{\sqrt{1 + \delta(1 - \rho^2)}}$$

  - ρ: corelația măsurată în criză
  - δ: creșterea relativă a variației prețului-sursă de la perioada calmă la criză
  - $\rho^* < \rho$ cînd $\delta > 0$

Înapoi

Capitolul 7: VaR și Expected Shortfall

- Simularea istorică filtrată și EVT condiționată reacționează la volatilitate în cîteva zile McNeil & Frey (2000) (Capitolul 7)
- VaR istoric, randamente i.i.d. cu densitate continuă $f(q_\alpha) > 0$

$$\sqrt{T}(\hat{q}_\alpha - q_\alpha) \Rightarrow N(0,\ \alpha(1-\alpha)/f(q_\alpha)^2)$$

  - q_α: cuantila α a randamentelor, $\mathrm{VaR}_\alpha = -q_\alpha$
  - $\hat{q}_\alpha$: cuantila empirică, f: densitatea randamentelor
  - În coadă f este mică, deci estimarea este zgomotoasă
  - Cînd randamentele sînt dependente, $\alpha(1-\alpha)$ devine dispersia de termen lung a indicatorilor $1\{r_t \leq q_\alpha\}$ (1 dacă condiția este îndeplinită, 0 altfel)
- ES este media celor mai mari αT pierderi: cu αT de cîteva zeci și un tail index în jur de 3, dispersia lui este dominată de una sau două zile

Înapoi

Capitolul 8: Backtesting și evaluarea prognozelor de risc

- Ierarhizăm prognozele (VaR, ES) cu un scor consistent (FZ0) și teste Diebold–Mariano Fissler & Ziegel (2016) (Capitolul 8)
- Backtesting-ul VaR: numărul și momentul depășirilor (formulele: Pasul 4 al studiului de caz)
  - Testul Kupiec, $LR_{uc} \sim \chi^2_1$: este rata depășirilor egală cu α?
  - Testul Christoffersen, $LR_{ind} \sim \chi^2_1$: este o depășire independentă de cea de ieri?
  - Testul DQ: regresăm $I_t - \alpha$ pe indicatorii depășirilor anterioare și pe VaR_t ($I_t = 1$ dacă pierderea depășește VaR_t)
  - $DQ \sim \chi^2_k$, k fiind numărul de regresori Engle & Manganelli (2004)
- Puterea este mică la $T = 250$ (puterea testului Kupiec, studiul de caz)
- Comparăm modelele cu teste de capacitate predictivă condiționată Giacomini & White (2006)

înapoi

Capitolul 9: Volatilitate realizată / Capitolul 10: Microstructura pieței

- **Capitolul 9, Volatilitate realizată**
  - Randamentele împărțite la volatilitatea realizată au o distribuție apropiată de distribuția Normală
- Erorile HAR sînt heteroscedastice și, pentru ținte pe mai multe zile care se suprapun, autocorelate: folosiți erori standard HAC
  - Prognozele se compară cu teste DM pe o funcție de pierdere robustă Patton (2011)
- Zgomotul de microstructură deplasează în sus *RV* (suma pătratelor randamentelor intraday) la frecvențe înalte: estimatorii pe două scale elimină deplasarea Zhang, Mykland & Aït-Sahalia (2005)
- **Capitolul 10, Microstructura pieței**
  - Lichiditatea variază în funcție de ora din zi și de VIX și dispare în perioadele de stres
- Spread-ul Roll: oscilația între bid și ask face ca variațiile consecutive ale prețului să fie negativ corelate

$$s_{\mathbf{Roll}} = 2\sqrt{-\mathrm{Cov}(\Delta p_t, \Delta p_{t-\mathbf{1}})}$$

  - Δp_t: variația prețului de tranzacționare
  - Cînd covarianța de selecție este pozitivă, estimatorul nu este definit, deci raportați cît de des se întîmplă
- O primă de ilichiditate este o afirmație privind secțiunea transversală: Fama–MacBeth cu erori Newey–West și corecția Shanken Shanken (1992)

înapoi

Capitolul 11: Modele în timp continuu

- Salturile explică cozile, volatilitatea stochastică explică volatility clustering (Capitolul 11)
- Normalitatea randamentelor log GBM: Jarque–Bera $JB = \frac{T}{6}\left(S^2 + (K-3)^2/4\right) \sim \chi^2_2$ respinge peste tot
  - S: asimetria de selecție, K: kurtosis-ul de selecție
  - Pentru distribuția Normală, $S = 0$ și $K = 3$
  - Salturile: $(RV - BV)$ standardizat $\Rightarrow N(0,1)$ Barndorff-Nielsen & Shephard (2006)
  - BV: variația bipower, o sumă de produse ale valorilor absolute ale randamentelor intraday vecine, robustă la salturi
- Testul este zilnic: pe multe zile, controlați numărul de salturi detectate fals

Înapoi

Capitolul 12: Opțiuni și suprafața de volatilitate

- Smile-ul și skew-ul volatilității reflectă aversiunea față de riscul de crah (Capitolul 12)
- Prima de risc a variației

$$VRP_t = VIX_t^{\mathbf{2}} - RV_{t,t+\mathbf{21}}$$

  - $VIX_t^{\mathbf{2}}$: varianța așteptată neutră la risc pentru luna următoare
  - $RV_{t,t+\mathbf{21}}$: varianța realizată în următoarele 21 de zile de tranzacționare
  - Valorile consecutive se suprapun, deci media cere erori Newey–West cu cel puțin 21 de laguri
- Volatilitatea implicită este o prognoză neutră la risc: prima, nu eroarea de prognoză, explică cea mai mare parte a diferenței

Înapoi

Capitolul 13: Machine Learning în finanțe

- Purged cross-validation, meta-labelling și raportul Sharpe deflatat Bailey & López de Prado (2014) (Capitolul 13)
- Selecția dintre N strategii: raportul Sharpe deflatat testează $SR > E[\max_N \widehat{SR}]$ sub ipoteza absenței abilității Bailey & López de Prado (2014)
  - $E[\max_N \widehat{SR}]$: media celui mai mare raport Sharpe estimat dintre N strategii al căror raport Sharpe adevărat este zero
  - Această medie crește odată cu N
- Validarea încrucișată pe serii de timp trebuie să elimine din antrenare observațiile ale căror etichete se suprapun cu setul de test (purging) și să lase o pauză după acesta (embargo), altfel acuratețea este supraestimată

Înapoi

Capitolul 14: Deep learning și modele fundaționale pentru serii de timp

- Modelele se evaluează cu instrumentele din Capitolul 8, după publicarea ponderilor lor (Capitolul 14)
- Testul DM pe diferențele QLIKE, cu dispersie HAC Diebold & Mariano (1995)

$$t_{DM} = \frac{\bar{d}}{\sqrt{\hat{\Omega}/T}} \Rightarrow N(0,1)$$

  - d_t: QLIKE a modelului 1 minus QLIKE a modelului 2 în ziua t, $\bar{d}$ media ei pe T zile
  - $\hat{\Omega}$: dispersia de termen lung HAC a lui d_t
  - Valid pentru comparații între modele neimbricate
- Cu multe modele candidate, mulțimea de încredere a modelelor (MCS) controlează eroarea la nivel de familie Hansen, Lunde & Nason (2011)

Înapoi

Capitolul 15: LLM-uri și analiza sentimentului / Capitolul 16: Active digitale și DeFi

- **Capitolul 15, LLM-uri și analiza sentimentului**
  - Reprezentările vectoriale ale textului intră în modele ca variabile explicative
- Regresia predictivă $r_{t+1} = a + bS_t + \varepsilon_{t+1}$
  - S_t: scorul de sentiment din ziua t
  - b: panta predictivă
  - Un S_t persistent, cu inovații corelate cu randamentele, introduce un bias în $\hat{b}$ și distorsionează testul t Stambaugh (1999)
- Rezultatele clasificatorilor pe aceleași texte sînt împerecheate: comparăm acuratețile cu testul McNemar exact, nu prin două intervale separate
- **Capitolul 16, Active digitale și DeFi**
  - Stablecoin-urile, automated market makers și ETF-urile spot leagă cripto de finanțele tradiționale
- Modele factoriale cripto: GRS și Fama–MacBeth cu corecția Shanken Gibbons, Ross & Shanken (1989), Shanken (1992)
- Cozile groase cer versiuni HAC sau bootstrap
- Cozile: tail index-uri Hill cu intervale de încredere, nu kurtosis de selecție (Capitolul 1)
  - O ruptură într-o corelație se testează cu dată necunoscută: statistica sup-Wald este cea mai mare statistică Wald pe toate datele candidate Andrews (1993)

Înapoi

Capitolul 17: Bule și crahuri

- Testele de rădăcină unitară pe coada din dreapta datează începutul și sfîrșitul episoadelor explozive (Capitolul 17)
- Testele de bulă: cea mai mare statistică ADF pe coada din dreapta, pe multe ferestre

$$GSADF = \sup_{r_2 \in [r_0, 1]} \sup_{r_1 \in [0, r_2 - r_0]} ADF_{r_1}^{r_2}$$

  - $ADF_{r_1}^{r_2}$: statistica ADF (Augmented Dickey–Fuller) pe fracțiunea de eșantion $[r_1, r_2]$
  - r_0: fereastra minimă
  - SADF (Sup Augmented Dickey–Fuller) fixează $r_1 = 0$
  - Sub ipoteza rădăcinii unitare, SADF și GSADF converg către funcționale ale mișcării browniene, iar valorile critice depind doar de r_0 Phillips, Shi & Yu (2015)
- Schimbările de volatilitate distorsionează nivelul testului: folosiți valori critice obținute prin wild bootstrap
- Datarea episoadelor implică multe teste: controlați multiplicitatea lor

Înapoi

Capitolul 18: Risc sistemic și rețele

- CoVaR (VaR-ul sistemului condiționat de dificultățile unei instituții), SRISK (deficitul de capital al unei bănci într-o criză sistemică) și rețelele de contagiune măsoară contribuția fiecărei instituții (Capitolul 18)
- ΔCoVaR: variația VaR-ului sistemului cînd instituția i trece de la mediană la stres

$$\Delta\text{CoVaR}^i = \text{CoVaR}_\alpha^{sys|X^i=-\text{VaR}_\alpha^i} - \text{CoVaR}_\alpha^{sys|X^i=\textbf{median}}$$

  - X^i: randamentul instituției i
  - $\text{CoVaR}_\alpha^{sys|\cdot}$: VaR α al randamentului sistemului, condiționat de starea lui i
  - Diferențele dintre bănci: teste pe perechi pe extrageri bootstrap comune pe blocuri, cu corecția Holm
  - La $\alpha = 1\%$ doar aproximativ 40 de zile în coadă, deci estimarea ridică problemele specifice cuantilelor extreme
- SRISK: LRMES (pierderea așteptată a unei bănci cînd piața scade cu peste 10% în 22 de zile) simulat din GJR–GARCH (GARCH-ul asimetric Glosten–Jagannathan–Runkle) + DCC Brownlees & Engle (2017)
  - Tabelele de conectivitate cer intervale bootstrap și modele VAR (vector autoregresive) cu shrinkage

Înapoi

Idei de proiect, Partea C a fiecărui seminar (1/2)

Cap.	Întrebarea deschisă (link către seminar)
0	Au schimbat ETF-urile spot corelația Bitcoin cu acțiunile?
1	A scăzut autocorelația BET-TR (BET cu dividendele reinvestite) după reclasificarea FTSE?
2	A devenit BVB mai eficientă după reclasificarea FTSE din 2020?
3	Există prime factoriale la Bursa de Valori București?
4	Un portofoliu optim de blue chips BVB în RON
5	Este volatilitatea pieței românești determinată de SUA?
6	Au devenit acțiunile din România și din zona euro mai integrate după 2020?
7	Capitalul pentru un portofoliu BVB față de un portofoliu S&P 500

- Fiecare seminar oferă datele, o metodă de pornire și o analiză de referință discutată la seminar

Înapoi

Idei de proiect, Partea C a fiecărui seminar (2/2)

Cap.	Întrebarea deschisă (link către seminar)
8	Ce model de risc ați certifica pentru portofoliul de tranzacționare al unei bănci românești?
9	Este volatilitatea Bitcoin mai previzibilă decît cea a S&P 500?
10	Există o primă de ilichiditate pe BVB?
11	Ce model în timp continuu se potrivește pentru BET și Bitcoin?
12	Este prima de risc a varianței un semnal tranzacționabil?
13	Este un model fundațional superior boosting-ului?
14	Poate un model fundațional zero-shot să înlocuiască GARCH pentru BET?
15	Aduce sentimentul titlurilor cîștig după costuri?
16	Este Bitcoin un activ alternativ, un activ de risc sau un hedge?
17	Există o bulă AI?
18	Cît de expuse sînt băncile românești la stresul bancar din zona euro?

- Capitolul 20 (volatilitatea realizată prognozată cu semnătura traiectoriei, pe datele VOLARE) se potrivește și pentru un proiect de prognoză

Înapoi

De la idee la proiect

- Replicați mai întîi: un tabel sau o figură publicată dintr-un articol din spatele ideii (pasul 1)
- Restrîngeți-o: o piață, o perioadă, un număr de prognozat sau de testat
  - Exemplu: Seminarul 8 devine „Care dintre HS, FHS și GARCH-EVT produce un VaR 1% corect pentru un portofoliu 50/50 format din BET și EUR (cursul EUR/RON) în 2015–2026?”
- Extindeți-o: o a doua piață, un model nou, un eșantion mai lung sau mai recent
  - Exemplu: adăugați un model fundațional (Capitolul 14) ca filtru de volatilitate în FHS
- Păstrați analiza de referință ca reper și încercați să o îmbunătățiți în mod onest

Înapoi

Convențiile de date pentru proiect

- Folosiți datele cursului unde se poate: serii zilnice pentru indici, ETF-uri, acțiuni BVB, cripto și cursuri de schimb, plus date intraday
  - Surse publice: cursurile de referință BNR, FRED, Kenneth French Data Library, DefiLlama; arhiva BVB pentru indicii românești
- Aplicați convențiile cursului
  - Prețuri ajustate pentru ETF-uri și acțiuni, valori de închidere pentru indici, cursuri de schimb și cripto
  - Eliminați zilele de sărbătoare în care furnizorul a repetat prețul anterior și cotațiile de weekend cînd piața este închisă; anualizați cu frecvența reală
  - Mai multe active: aliniați întîi prețurile pe zilele comune, apoi calculați randamentele
- Căutați valorile eronate înainte de modelare: salturile de $\pm 50\%$ în prețurile ajustate sînt de obicei erori de date

Înapoi

Lista de verificare pentru o evaluare onestă

Înainte să vă uitați la rezultate

- ⊡ Scrieți ipoteza, reperul și funcția de pierdere
- ⊡ Fixați fereastra de estimare și perioada de test
- ⊡ Decideți cîte modele și parametri veți încerca și corecția pentru ei
- ⊡ Scrieți strategia de identificare și puterea testului principal

Cînd raportați

- ⊡ Doar rezultate în afara eșantionului pentru afirmații despre prognoză
- ⊡ Fiecare rezultat principal însoțit de eroare standard, CI sau p-value
- ⊡ Costurile de tranzacționare pentru strategii
- ⊡ Subperioade și o a doua piață pentru robustețe
- ⊡ Ce **nu** a funcționat și de ce

Înapoi

Greșeli frecvente care costă puncte

- O întrebare care se schimbă după ce se cunosc rezultatele
- Ajustarea în eșantion prezentată drept putere de prognoză
- Niciun reper sau un reper slab, ales pentru a fi ușor depășit
- Cifre fără incertitudine
- Multe teste fără corecție
- Grafice fără unități, legende peste date, acronime neexplicate
- Cod care nu rulează sau cifre din raport pe care codul nu le produce
- Rezultate AI păstrate fără verificare: utilizare nedeclarată, cod neverificat, referințe care nu există

Înapoi

Erori nestandard, date și metodă (1/2)

- **Date**
  - Toate tranzacțiile cu contractele futures pe indicele Euro Stoxx 50, 2002–2018, 720 de milioane de înregistrări, pentru fiecare parte a tranzacției se indică dacă aceasta operează pentru un client sau în cont propriu (Sec. I.A)
  - Șase ipoteze, fiecare „nicio tendință anuală" pentru: eficiența pieței, spread-ul bid–ask realizat, ponderea clienților în volum, spread-ul realizat pe ordinele clienților, ponderea ordinelor la piață în ordinele clienților, venitul brut din tranzacționare al clienților
  - Fiecare echipă își alege propria măsură pentru fiecare mărime
- **Patru etape** în 2021 (Sec. I.A)
  - Analiza independentă (articol și cod)
  - Feedback de la doi evaluatori
  - Distribuirea celor mai bune cinci lucrări
  - Estimările finale, fără obligația de a furniza codul care le reproduce
  - Un plan de analiză a fost înregistrat public înainte de începerea experimentului (Sec. I.A)

Înapoi

Erori nestandard, date și metodă (2/2)

- **Calitatea**
  - Calitatea echipei (prima componentă principală a cinci indicatori), scorul de reproductibilitate 0–100 acordat de agenția de certificare Cascad, nota acordată de evaluatori, din care s-a scăzut media (Sec. I.B)
  - Regresii cuantilice ale estimărilor la percentilele 10, 25, 50, 75 și 90; un IQR care scade înseamnă o dispersie mai mică (Sec. I.C)
- **Inferența**
  - Fiecare estimare este testată față de estimarea mediană, cu corecție Bonferroni la un nivel de semnificație de 0,5% pentru familia de teste (Sec. I.C)
  - Analiza multivers: echipele raportează opțiunile metodologice din Tabelul V
  - Statistica Anderson–Darling pentru k eșantioane ierarhizează deciziile după diferențele dintre distribuțiile estimărilor (Sec. II.C)

Înapoi

Erori nestandard, detaliile replicării

- **Deciziile metodologice (bifurcațiile) din Tabelul V**
  - Valorile extreme (nimic; măsura anuală winsorizată sau cu valorile din afara percentilelor 2,5 și 97,5 eliminate), măsura (raportul variațelor zi la săptămînă, raportul variațelor zi la lună, R^2 al unui model autoregresiv AR(1)), modelul (tendință liniară, diferență logaritmică, diferență relativă)
  - Datele zilnice permit comparațiile zi–săptămînă și zi–lună ($VR(5)$, $VR(21)$), iar variantele intrazilnice ale măsurii din Tabelul V necesită date intrazilnice
- **Explozia diferențelor relative**: $m_t = |VR - 1|$ sau R^2 este aproape de zero în unii ani (articolul: Fig. 7)
  - Fără tendință, m_t staționar: panta liniară și variația logaritmică medie sînt centrate în zero, dar pentru m_t independente, $\mathbb{E}(m_t/m_{t-1}) = \mathbb{E}m \cdot \mathbb{E}(1/m) \geq 1$ (Jensen), deci variația relativă medie este pozitivă
- **Statistica Anderson–Darling**: cele 27 de estimări sînt puternic corelate, deci valorile critice tabelate și p-value-urile nu se aplică

Înapoi

Bucla descoperirii, prompturi (1/2)

- **Săptămîna 1, întrebarea**: transformăm o idee în H_0/H_1, cu o țintă de replicare
  - „Iată ideea noastră din Partea C a Seminarului N. Dă trei versiuni mai precise și testabile, tabelul publicat pe care l-ar replica fiecare și seriile din datele cursului de care are nevoie.”
- **Săptămînile 1–2, literatura și ținta**: cifra de replicat este una pe care ați văzut-o în PDF
  - „Listează cele mai citate și cele mai recente articole despre această întrebare, cu DOI; pentru fiecare, estimarea principală, tabelul și eșantionul.”
  - Verificați fiecare DOI pe Crossref; căutați cu Semantic Scholar, Elicit sau Google Scholar; deschideți personal tabelul
- **Săptămîna 2, ipoteze și preînregistrare**, fixate în scris printr-un commit datat înaintea primului rezultat
  - „Pentru H0 și H1, listează ipotezele concurente și implicația care le separă; apoi scrie o preînregistrare: eșantion, filtre, ferestre, teste, corecție.”
  - Istoricul commit-urilor documentează înregistrarea planului înaintea rezultatelor

Înapoi

Bucla descoperirii, prompturi (2/2)

- **Săptămînile 2–3, cod și replicare**: tabelul replicat devine un test în repository
  - ,,Scrie o funcție care reproduce fiecare celulă a tabelului publicat din datele cursului și o aserțiune cu toleranța pe care o acceptăm.''
- **Săptămînile 4–5, extindere și robustețe**: rulăm toată grila preînregistrată
  - ,,Iată rezultatele tuturor specificațiilor analizate. Ce concluzii rămîn valabile după corecția Holm și pe care le-ar numi un recenzent căutare oportunistă în date (data snooping)?''
- **Înainte de susținere, critica**: asistentul întreabă, echipa răspunde
  - ,,Joacă rolul examinatorului la susținerea orală: pune cele mai dificile zece întrebări despre identificare, inferență și date. Nu răspunde la ele.''
  - Echipa răspunde fără AI, ca la susținerea propriu-zisă
- **Raportul**: distribuția rezultatelor pe grilă, nu celula cea mai bună; prompturile în `AI_USE.md`, erorile detectate în `AI_ERRORS.md`

Înapoi

Verificările cercetătorului

- **Ținta de replicare există**: cifra, tabelul și eșantionul luate din articol, nu din rezumatul asistentului
  - Test: raportul citează pagina și tabelul; un al doilea membru găsește acolo aceeași cifră
- **Planul precede rezultatele**
  - Test: în istoricul commit-urilor, preînregistrarea precede primul fișier de rezultate
- **Bifurcațiile analizei**: mai multe specificații încercate decît raportate
  - Test: fiecare rulare își scrie configurația și rezultatul într-un jurnal; raportul le dă numărul și corectează familia
- **Reproductibilitatea**: cifre introduse manual în raport
  - Test: o clonă nouă și o singură comandă regenerează fiecare cifră pînă la ultima zecimală raportată
- **Înțelegerea**: fiecare membru poate deduce formula-cheie și poate apăra fiecare alegere
  - Test: o susținere de probă în echipă, fără AI, cu o săptămînă înaintea celei reale

Înapoi

Acronime folosite în acest material (1/3)

- **ACF**: AutoCorrelation Function — *funcția de autocorelație*
- **ADF**: Augmented Dickey–Fuller (test) — *testul Dickey–Fuller augmentat*
- **AI**: Artificial Intelligence — *inteligență artificială*
- **AR**: AutoRegressive model — *model autoregresiv*
- **ASE**: Academia de Studii Economice din București
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BET-TR**: BET Total Return (index) — *indicele BET cu dividendele reinvestite*
- **BH**: Benjamini–Hochberg (procedure) — *procedura Benjamini–Hochberg*
- **BNR**: Banca Națională a României
- **BVB**: Bursa de Valori București
- **CAGR**: Compound Annual Growth Rate — *rata anuală compusă de creștere*
- **CAPM**: Capital Asset Pricing Model — *modelul de evaluare a activelor financiare*
- **CI**: Confidence Interval — *interval de încredere*
- **COVID-19**: COronaVIrus Disease 2019 — *boala provocată de coronavirus, 2019*
- **CV**: Cross-Validation — *validare încrucișată*
- **DCC**: Dynamic Conditional Correlation — *corelație condiționată dinamică*
- **DM**: Diebold–Mariano (test) — *testul Diebold–Mariano de comparare a prognozelor*
- **DQ**: Dynamic Quantile (test) — *testul cuantilei dinamice*
- **ES**: Expected Shortfall — *pierderea așteptată în coadă*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*

Acronime folosite în acest material (2/3)

- **EVT**: Extreme Value Theory — *teoria valorilor extreme*
- **FDR**: False Discovery Rate — *rata descoperirilor false*
- **FHS**: Filtered Historical Simulation — *simulare istorică filtrată*
- **FRED**: Federal Reserve Economic Data — *baza de date economice a Rezervei Federale (St. Louis)*
- **FTSE**: Financial Times Stock Exchange (FTSE Russell, index provider) — *furnizorul de indici FTSE Russell*
- **FWER**: Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **FZ0**: Fissler–Ziegel loss, zero-homogeneous version — *funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GARCH-EVT**: GARCH filter combined with Extreme Value Theory for the tail — *filtru GARCH combinat cu teoria valorilor extreme pentru coadă*
- **GBM**: Geometric Brownian Motion — *mișcarea browniană geometrică*
- **GJR**: Glosten–Jagannathan–Runkle (asymmetric GARCH) — *GARCH asimetric Glosten–Jagannathan–Runkle*
- **GRS**: Gibbons–Ross–Shanken (test) — *testul Gibbons–Ross–Shanken*
- **GSADF**: Generalised Sup Augmented Dickey–Fuller (test) — *testul Dickey–Fuller augmentat suprem generalizat*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HAR**: Heterogeneous AutoRegressive (model) — *model autoregresiv heterogen*

Acronime folosite în acest material (3/3)

- **HS**: Historical Simulation — *simulare istorică*
- **IGARCH**: Integrated GARCH — *GARCH integrat*
- **IQR**: InterQuartile Range — *intervalul intercuartilic*
- **LLM**: Large Language Model — *model lingvistic mare*
- **LRMES**: Long-Run Marginal Expected Shortfall — *pierderea marginală așteptată în coadă pe termen lung (într-o criză)*
- **LSTM**: Long Short-Term Memory (network) — *rețea cu memorie pe termen lung și scurt*
- **MCS**: Model Confidence Set — *mulțimea de încredere a modelelor*
- **MDE**: Minimum Detectable Effect — *efectul minim detectabil*
- **ML**: Machine Learning — *învățare automată*
- **MSE**: Mean Squared Error — *eroarea pătratică medie*
- **QLIKE**: Quasi-LIKElihood (loss function) — *funcția de pierdere de tip cvasi-verosimilitate*
- **QMLE**: Quasi-Maximum Likelihood Estimator — *estimatorul de cvasi-verosimilitate maximă*
- **SADF**: Sup Augmented Dickey–Fuller (test) — *testul Dickey–Fuller augmentat suprem*
- **SE**: Standard Error — *eroare standard*
- **SML**: Security Market Line — *dreapta pieței titlurilor*
- **SRISK**: Systemic RISK (capital shortfall measure) — *deficitul de capital al unei bănci într-o criză sistemică*
- **SUA**: Statele Unite ale Americii
- **VAR**: Vector AutoRegression — *model vector autoregresiv*
- **VIX**: CBOE Volatility IndeX — *indicele de volatilitate CBOE*
- **VOLARE**: VOLatility Archive for Realized Estimates (database) — *arhiva de estimatori realizați ai volatilității (bază de date)*

Bibliografie (1/5)

- Abadie, A., Diamond, A., Hainmueller, J. (2010). Synthetic control methods for comparative case studies: estimating the effect of California's tobacco control program. *Journal of the American Statistical Association*, 105(490), 493–505.
- Andrews, D.W.K. (1993). Tests for parameter instability and structural change with unknown change point. *Econometrica*, 61(4), 821–856.
- Andrews, D.W.K. (1999). Estimation when a parameter is on a boundary. *Econometrica*, 67(6), 1341–1383.
- Athreya, K.B. (1987). Bootstrap of the mean in the infinite variance case. *Annals of Statistics*, 15(2), 724–731.
- Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- Barndorff-Nielsen, O.E., Shephard, N. (2006). Econometrics of testing for jumps in financial economics using bipower variation. *Journal of Financial Econometrics*, 4(1), 1–30.
- Black, F., Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 637–654.
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- Brownlees, C., Engle, R.F. (2017). SRISK: a conditional capital shortfall measure of systemic risk. *Review of Financial Studies*, 30(1), 48–79.
- Chow, K.V., Denning, K.C. (1993). A simple multiple variance ratio test. *Journal of Econometrics*, 58(3), 385–401.

Bibliografie (2/5)

- Christoffersen, P.F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy?. *Review of Financial Studies*, 22(5), 1915–1953.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Engle, R. (2002). Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- Fama, E.F. (1970). Efficient capital markets: a review of theory and empirical work. *Journal of Finance*, 25(2), 383–417.
- Fissler, T., Ziegel, J.F. (2016). Higher order elicitability and Osband's principle. *Annals of Statistics*, 44(4), 1680–1707.
- Forbes, K.J., Rigobon, R. (2002). No contagion, only interdependence: measuring stock market comovements. *Journal of Finance*, 57(5), 2223–2261.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, 5th ed. Springer.

Bibliografie (3/5)

- Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- Gibbons, M.R., Ross, S.A., Shanken, J. (1989). A test of the efficiency of a given portfolio. *Econometrica*, 57(5), 1121–1152.
- Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). Applied Quantitative Finance, 3rd ed. Springer.
- Harvey, C.R. (2017). Presidential address: the scientific outlook in financial economics. *Journal of Finance*, 72(4), 1399–1440.
- Harvey, C.R., Liu, Y. (2020). False (and missed) discoveries in financial economics. *Journal of Finance*, 75(5), 2503–2553.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). . . . and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Hill, B.M. (1975). A simple general approach to inference about the tail of a distribution. *Annals of Statistics*, 3(5), 1163–1174.
- Hou, K., Xue, C., Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133.
- Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance?. *Journal of Finance*, 78(5), 2465–2518.
- Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.

Bibliografie (4/5)

- Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.
- Lo, A.W., MacKinlay, A.C. (1988). Stock market prices do not follow random walks: evidence from a simple specification test. *Review of Financial Studies*, 1(1), 41–66.
- Lobato, I., Nankervis, J.C., Savin, N.E. (2001). Testing for autocorrelation using a modified Box–Pierce Q test. *International Economic Review*, 42(1), 187–205.
- López de Prado, M. (2018). Advances in Financial Machine Learning. Wiley.
- Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- McNeil, A.J., Frey, R., Embrechts, P. (2015). Quantitative Risk Management: Concepts, Techniques and Tools, revised ed. Princeton University Press.
- Menkveld, A.J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). Nonstandard errors. *Journal of Finance*, 79(3), 2339–2390.
- Nelson, D.B. (1990). Stationarity and persistence in the GARCH(1,1) model. *Econometric Theory*, 6(3), 318–334.
- Nolde, N., Ziegel, J.F. (2017). Elicitability and backtesting: perspectives for banking regulation. *Annals of Applied Statistics*, 11(4), 1833–1874.
- Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413.

Bibliografie (5/5)

- Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *European Journal of Finance*, 29(10), 1064–1105.
- Phillips, P.C.B., Shi, S., Yu, J. (2015). Testing for multiple bubbles: historical episodes of exuberance and collapse in the S&P 500. *International Economic Review*, 56(4), 1043–1078.
- Shanken, J. (1992). On the estimation of beta-pricing models. *Review of Financial Studies*, 5(1), 1–33.
- Simonsohn, U., Simmons, J.P., Nelson, L.D. (2020). Specification curve analysis. *Nature Human Behaviour*, 4(11), 1208–1214.
- Stambaugh, R.F. (1999). Predictive regressions. *Journal of Financial Economics*, 54(3), 375–421.
- Tsay, R.S. (2010). Analysis of Financial Time Series, 3rd ed. Wiley.
- White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126.
- Zhang, L., Mykland, P.A., Aït-Sahalia, Y. (2005). A tale of two time scales: determining integrated volatility with noisy high-frequency data. *Journal of the American Statistical Association*, 100(472), 1394–1411.