









Modelarea piețelor financiare

Capitolul 19: Recapitulare și prezentarea proiectelor



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Ce face dintr-un rezultat o concluzie?

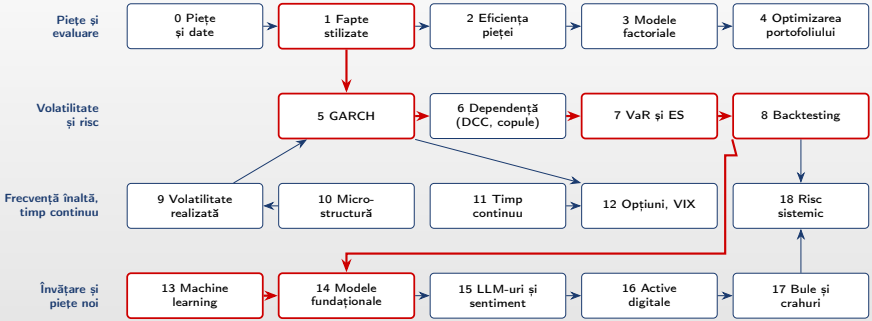
Capitolul pe scurt

- Întrebarea: cînd merită încredere un rezultat empiric despre piețe și cînd reflectă doar datele, felul în care a fost construită analiza sau norocul?
- Partea I: cursul într-o singură imagine, recapitularea capitolelor 0–18, șase capcane și un studiu de caz integrat, de la prețurile brute ale BET (indicele de referință al Bursei de Valori București, BVB) la un Value-at-Risk (VaR) de 1% validat prin backtesting
- Firul principal: GARCH (Generalised AutoRegressive Conditional Heteroskedasticity) prognozează volatilitatea, DCC (Dynamic Conditional Correlation) corelațiile, iar VaR și ES (Expected Shortfall, pierderea medie dincolo de VaR) le transformă într-o pierdere
- Partea a II-a: proiectul de echipă, AI (inteligența artificială) în proiect, un studiu de caz despre erorile nestandard și bucla de descoperire asistată de AI (ghidul proiectului pas cu pas: ▸ Anexă)

Ce trebuie să puteți face

- Duceți o întrebare de la date la o prognoză de risc validată, cu inferență corectă
- Recunoașteți cele șase capcane în propriul cod
- Scrieți un plan de proiect cu replicare, identificare, putere și grilă de specificații

Cursul într-o singură imagine



Ce leagă etapele analizei

- Roșu: firul principal, de la faptele stilizate (Capitolul 1: cozi groase, volatility clustering, aproape nicio predictibilitate liniară) la prognoze de risc verificabile (Capitolele 5–8: GARCH dă σ_{t+1}, VaR și ES dau pierderea, backtesting-ul arată dacă prognoza este fiabilă)
- Capitolele 9–12 măsoară volatilitatea mai precis (date intraday, prețuri de opțiuni, VIX, indicele volatilității implicite a S&P 500) și o modelează în timp continuu
- Capitolele 13–15 aduc modele flexibile, inclusiv modele lingvistice mari (Large Language Models, LLM), evaluate cu instrumentele din Capitolul 8
- Capitolele 16–18 aplică aceleași instrumente activelor cripto, bulelor și întregului sistem financiar
- Capitolul special 20: volatilitatea realizată prognozată cu semnătura traiectoriei, pe datele VOLARE (VOLatility Archive for Realized Estimates)
- Formule de inferență suplimentare (Shanken, QMLE, cuantila empirică): ▸ Anexă

Cinci întrebări pentru orice model

Înainte de estimare

- **Date**: ce serie, ce calendar, ce ajustări (dividende, split-uri, sărbători)?
- **Model**: ce fapt stilizat surprinde?
- **Model**: ce ignoră?
- **Estimare**: pe ce fereastră, cu ce informație la momentul t?

După estimare

- **Evaluare**: out-of-sample, cu o funcție de pierdere potrivită țintei, QLIKE (pierderea de cvasi-verosimilitate) pentru variantă sau FZ0 (scorul Fissler–Ziegel) pentru perechea (VaR, ES)?
- **Incertitudine**: erori standard robuste, bootstrap, test față de un reper simplu?
- Fără răspuns la fiecare întrebare, rezultatul nu este încă o concluzie

Capitolul 0: Piețele financiare în 2026

- Piețele combină burse, dealeri extrabursieri, fonduri tranzacționate la bursă (exchange-traded funds, ETF), algoritmi și blockchain-uri
- SPY (ETF pe S&P 500, cu dividende reinvestite), 2015–2026: CAGR (Compound Annual Growth Rate, rata anuală compusă de creștere) de 13,7%, volatilitate anualizată de 17,6%
- Bitcoin, aceeași perioadă: CAGR de 60,6%, volatilitate anualizată de 66,7%
- BET, iulie 2007 – februarie 2009: un drawdown de $-82{,}5\%$
- Erorile standard ale mediei și volatilității estimate din randamente log i.i.d. (Y: lungimea eșantionului în ani; T: numărul de randamente zilnice; K: kurtosis-ul populației)

$$\mathrm{SE}(\hat{\mu}_{\mathbf{ann}}) = \frac{\sigma_{\mathbf{ann}}}{\sqrt{Y}}, \qquad \mathrm{SE}(\hat{\sigma}) \approx \sigma\sqrt{\frac{K-1}{4T}}$$

- SPY: $\mathrm{SE}(\hat{\mu}_{\mathbf{ann}}) \approx 5{,}1\%$ pentru un randament log mediu anualizat de 12,8%: mediile abia pot fi estimate, volatilitățile da

Capitolul 1: Fapte stilizate și randamente

- Randamentele sînt necorelate, dar nu independente: mărimea lor este previzibilă, semnul aproape deloc Cont (2001)
- Tail index-ul α: probabilitatea unei pierderi peste x scade ca $x^{-\alpha}$; estimatorul Hill folosește cele mai mari k pierderi, ordonate $L_{(\mathbf{1})} \geq \cdots \geq L_{(k+\mathbf{1})}$ Hill (1975)

$$\hat{\alpha} = \Big[\frac{1}{k}\sum_{i=\mathbf{1}}^{k} \ln \frac{L_{(i)}}{L_{(k+\mathbf{1})}}\Big]^{-\mathbf{1}}, \qquad \mathrm{SE}(\hat{\alpha}) \approx \frac{\hat{\alpha}}{\sqrt{k}} \text{ pentru pierderi i.i.d.}$$

- BET, $k = 153$: $\hat{\alpha} = 2{,}39$, CI (Confidence Interval, interval de încredere) 95% prin bootstrap pe blocuri $[2{,}12; 3{,}03]$
- Intervalul i.i.d., $\hat{\alpha} \pm 1{,}96\,\hat{\alpha}/\sqrt{k} = [2{,}01; 2{,}77]$, este mai îngust: pierderile mari vin în grupuri
- $\alpha < 4$: momentul de ordinul patru este probabil infinit
- Zilele dincolo de 5σ sînt de peste 1 000 de ori mai frecvente decît sub distribuția Normală, care dă $2\Phi(-5) \approx 5{,}7 \times 10^{-\mathbf{7}}$ pe zi (o asemenea zi la aproximativ 7 000 de ani)

Capitolul 2: Eficiența pieței

- Ipoteza piețelor eficiente: prețurile reflectă pe deplin informația disponibilă
- Un test al predictibilității randamentelor anormale este un test comun al eficienței și al modelului de randament așteptat Fama (1970)
- Raportul variațelor pe q perioade și statistica lui robustă la heteroscedasticitate Lo & MacKinlay (1988)

$$VR(q) = \frac{\mathrm{Var}(r_t + \cdots + r_{t-q+\mathbf{1}})}{q\,\mathrm{Var}(r_t)}, \qquad z^*(q) = \frac{\widehat{VR}(q) - 1}{\widehat{\mathrm{SE}}^*} \Rightarrow N(0,1)$$

- Mai multe orizonturi deodată: $\max_q |z^*(q)|$, cu valorile critice Chow–Denning Chow & Denning (1993)
- Ponderea ferestrelor rolling în care ipoteza random walk este respinsă: S&P 500 6,4%, BET 22,4%, Bitcoin 0,0%
- O respingere statistică nu înseamnă profit exploatabil

Capitolul 3: Modele factoriale și evaluarea activelor

- Randamentele așteptate ar trebui să remunereze doar expunerea la factori sistematici
- Testul GRS: toate constantele (erorile de evaluare) $\hat{\alpha}$ sînt zero, cu T perioade, N active și K factori Gibbons, Ross & Shanken (1989)

$$\mathrm{GRS} = \frac{T-N-K}{N} \, \frac{\hat{\alpha}^\top \hat{\Sigma}^{-1} \hat{\alpha}}{1 + \hat{\mu}_f^\top \hat{\Omega}^{-1} \hat{\mu}_f} \;\sim\; F(N, T-N-K)$$

  - $\hat{\mu}_f$: mediile factorilor; $\hat{\Sigma}$, $\hat{\Omega}$: covariațele reziduurilor și ale factorilor; F exactă doar pentru erori i.i.d. Normale
- 25 de portofolii după mărime și raportul valoare contabilă/de piață: panta SML (security market line) este $-4{,}4\%$
- GRS $= 4{,}18$, față de o valoare critică de 5% sub 1,6: CAPM (Capital Asset Pricing Model) este respins ($p < 0{,}01$)
- ETF-uri sectoriale: prima componentă principală (piața) explică 66% din variață

Capitolul 4: Optimizarea portofoliului

- Markowitz formulează corect problema, dar eroarea de estimare domină soluția Markowitz (1952)
- Eroarea standard a raportului Sharpe pe perioadă, pentru randamente i.i.d. Normale și T perioade Lo (2002)

$$\mathrm{SE}(\widehat{SR}) \approx \sqrt{(1 + \widehat{SR}^2/2)/T}$$

- Pe eșantioane de 60 de luni, raportul Sharpe median este 1,57 in-sample, dar cel adevărat median este doar 0,30
- 96% dintre portofoliile tangente estimate sînt inferioare portofoliului 1/N, un reper greu de depășit DeMiguel, Garlappi & Uppal (2009)
- Portofoliul A față de 1/N: testăm $SR_A - SR_B = 0$ cu inferență HAC sau bootstrap studentizat Ledoit & Wolf (2008), nu comparăm două estimări punctuale

Capitolul 5: Volatilitate condiționată: GARCH

- Din cauza volatility clustering-ului, șocul de azi anticipează varianța de mîine Engle (1982), Bollerslev (1986)
- Modelul GARCH(1,1) și prognoza lui pe h zile (ε_t: șocul; α, β: ponderile ultimului șoc și ale ultimei varianțe)

$$\sigma^2_{t+1} = \omega + \alpha\,\varepsilon_t^2 + \beta\,\sigma_t^2, \qquad \bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}$$

$$\sigma^2_{T+h\mid T} = \bar{\sigma}^2 + (\alpha+\beta)^{h-1}\left(\sigma^2_{T+1\mid T} - \bar{\sigma}^2\right)$$

- Persistența $\alpha+\beta$ este rata cu care prognoza revine la nivelul de termen lung $\bar{\sigma}^2$; timpul de înjumătățire este $h_{1/2} = \ln 0{,}5 / \ln(\alpha+\beta)$
- S&P 500, 2000–2026: $\alpha+\beta = 0{,}9947$, deci $h_{1/2} = 131$ de zile
- Persistența BET nu poate fi separată de 1: capcana „Persistența aproape de 1”

Capitolul 6: Volatilitate multivariată și dependență

- Corelațiile se schimbă odată cu regimul macroeconomic; diversificarea nu este garantată
- Corelația din criză crește mecanic odată cu volatilitatea, deci testăm pe corelația ajustată Forbes & Rigobon (2002)

$$\rho^* = \frac{\rho}{\sqrt{1 + \delta(1 - \rho^2)}}$$

- ρ: corelația din criză; δ: creșterea relativă a variației prețului-sursă de la perioada calmă la criză
- SPY–TLT (TLT: ETF pe obligațiuni americane pe termen lung): ρ a urcat de la $-0{,}40$ la $0{,}11$ după 2022
- Volatilitatea unui portofoliu 60/40 a crescut în același timp de la 10,4% la 13,2%
- Corelația DCC dintre Bitcoin și SPY: 0,04 înainte de 2020 și 0,31 de atunci

Capitolul 7: VaR și Expected Shortfall

- VaR este o cuantilă a pierderii; ES, pierderea medie dincolo de ea, este o măsură de risc coerentă
- Definițiile, cu q_α cuantila α a randamentelor r (distribuție continuă)

$$\mathrm{VaR}_\alpha = -q_\alpha, \qquad \mathrm{ES}_\alpha = -\mathbb{E}\big[r \mid r \le q_\alpha\big] = \frac{1}{\alpha}\int_0^\alpha \mathrm{VaR}_u \, du$$

- S&P 500, zilnic: VaR-ul istoric $\mathrm{VaR}_{1\%} = 3{,}45\%$, iar $\mathrm{ES}_{1\%} = 5{,}01\%$
- VaR-ul bazat pe distribuția Normală este de doar 2,80%: cozile groase contează
- Simularea istorică filtrată și EVT condiționată reacționează la volatilitate în cîteva zile McNeil & Frey (2000)

Capitolul 8: Backtesting și evaluarea prognozelor de risc

- Testăm numărul și momentul depășirilor: acoperirea și independența Kupiec (1995), Christoffersen (1998)
- Kupiec, cu x depășiri în T zile și rata observată $\hat{\pi} = x/T$

$$LR_{uc} = -2 \ln \frac{(1-\alpha)^{T-x}\alpha^{x}}{(1-\hat{\pi})^{T-x}\hat{\pi}^{x}} \sim \chi^2_1$$

- Christoffersen: $LR_{ind} \sim \chi^2_1$ compară rata depășirilor după o zi fără depășire cu rata după o depășire (formula: Pasul 4 al studiului de caz)
- S&P 500, VaR 1%, 2007–2026, rata depășirilor (țința: 1%): Normal 2,70%, HS (simulare istorică) 1,67%, FHS (simulare istorică filtrată) 1,23%, GARCH-EVT (filtru GARCH cu o coadă din teoria valorilor extreme) 1,15%
- Pe S&P 500 și BET, un filtru GARCH combinat cu o coadă flexibilă (FHS, GARCH-EVT) dă cele mai bune rezultate

Capitolul 9: Volatilitate realizată

- Prețurile intraday măsoară varianța zilnică (RV, Realised Variance, varianța realizată)
- Modelul log-HAR (Heterogeneous AutoRegressive) surprinde memoria ei lungă Corsi (2009)

$$\ln RV_{t+1} = b_0 + b_d \ln RV_t + b_w \overline{\ln RV}_t^{(5)} + b_m \overline{\ln RV}_t^{(22)} + u_{t+1}$$

- $\overline{\ln RV}_t^{(5)}$, $\overline{\ln RV}_t^{(22)}$: media lui $\ln RV$ pe ultimele 5 și 22 de zile
- SPY: kurtosis-ul randamentelor de la deschidere la închidere este 15,73, iar după împărțirea la $\sqrt{RV_t}$ scade la 2,65
- log-HAR reduce QLIKE față de GARCH(1,1)-t cu 10% pentru SPY ($p = 0{,}021$) și cu 22% pentru Bitcoin

Capitolul 10: Microstructura pieței

- Prețurile se formează în registre de ordine limită; spread-ul compensează costurile de procesare, riscul de inventar și selecția adversă
- Spread-ul Roll: oscilația între bid și ask face ca variațiile consecutive ale prețului de tranzacționare, Δp_t, să fie negativ corelate

$$s_{\mathbf{Roll}} = 2\sqrt{-\mathrm{Cov}(\Delta p_t, \Delta p_{t-\mathbf{1}})}$$

- Cînd covarianța empirică este pozitivă, estimatorul nu este definit: raportați cît de des se întîmplă
- Raportul Amihud (puncte de bază, bp, la 1 milion USD): SPY 0,0016, Banca Transilvania 24,7, Transelectrica 1 024,0
- SPY: variația prețului în primele 5 minute este de 2,06 ori mai mare decît într-un interval de aceeași durată de la prînz

Capitolul 11: Modele în timp continuu

- Mișcarea browniană este limita unui random walk cu pași din ce în ce mai mici; lema lui Itô rezolvă ecuațiile diferențiale stocastice ale prețurilor
- Normalitatea randamentelor log ale mișcării browniene geometrice (Geometric Brownian Motion, GBM): testul Jarque–Bera, cu S asimetria și K kurtosis-ul empiric

$$JB = \frac{T}{6}\left(S^2 + \frac{(K-3)^2}{4}\right) \sim \chi^2_2$$

- S&P 500 față de GBM: 62 de zile dincolo de ± 4 abateri standard, față de 0,59 așteptate
- Tail index-ul Hill al pierderilor S&P 500 este sub 4 (Capitolul 16): momentul de ordinul patru este probabil infinit
- Salturile: $(RV - BV)$ standardizat $\Rightarrow N(0,1)$, cu BV variația bipower, robustă la salturi Barndorff-Nielsen & Shephard (2006)

Capitolul 12: Opțiuni și suprafața de volatilitate

- Black–Scholes evaluează opțiunile prin hedging; volatilitatea implicită este estimarea pieței pentru σ Black & Scholes (1973)
- Prima de risc a variației (VIX_t^2: varianța așteptată neutră la risc pe luna următoare; $RV_{t,t+\mathbf{21}}$: varianța realizată în următoarele 21 de zile de tranzacționare)

$$VRP_t = VIX_t^{\mathbf{2}} - RV_{t,t+\mathbf{21}}$$

- Valorile consecutive se suprapun, deci media cere erori Newey–West cu cel puțin 21 de laguri
- 1990–2026: VIX-ul mediu este 19,4, iar volatilitatea realizată medie în luna următoare este 15,3
- Prima de risc a variației este pozitivă în 86% din zile, dar nu și în perioadele de crah

Capitolul 13: Machine Learning în finanțe

- Modelele sînt flexibile, dar semnalul este slab și zgomotul mare; specificul finanțelor ține de procesul de validare López de Prado (2018)
- Validarea K-fold cu amestecare raportează o acuratețe de 69,4% pe zgomot pur: leakage (informație din setul de test scursă în antrenare)
- Remediu: purging (eliminarea din antrenare a etichetelor care se suprapun cu testul) și embargo după setul de test
- Selecția dintre N strategii: raportul Sharpe deflatat testează $SR > \mathbb{E}[\max_N \widehat{SR}]$, media celui mai mare Sharpe estimat dintre N strategii fără abilitate, care crește cu N Bailey & López de Prado (2014)
- S&P 500: seria diferențiată fracționar devine staționară la $d^* = 0{,}25$
- Niciun model nu depășește regula naivă „piața crește mereu”

Capitolul 14: Deep learning și modele fundaționale pentru serii de timp

- LSTM-urile (Long Short-Term Memory) și Transformerele învață din secvențe; modelele fundaționale prognozează zero-shot, fără antrenare pe seria analizată
- Testul Diebold–Mariano pe diferențele de pierdere d_t dintre două modele, cu $\hat{\Omega}$ dispersia de termen lung HAC a lui d_t Diebold & Mariano (1995)

$$t_{DM} = \frac{\bar{d}}{\sqrt{\hat{\Omega}/T}} \Rightarrow N(0,1)$$

- Prognoza volatilității realizate a SPY, QLIKE (mai mic este mai bine): Chronos-2 0,231, log-HAR 0,234, GARCH-t 0,283
- Chronos-2 și log-HAR nu diferă semnificativ
- VaR 1% din Chronos-2, fără recalibrare, pe S&P 500: rata depășirilor este 1,67%
- Cu multe modele candidate: mulțimea de încredere a modelelor (MCS) Hansen, Lunde & Nason (2011)

Capitolul 15: LLM-uri și analiza sentimentului

- De la dicționare la FinBERT și la LLM-uri: textul este transformat într-o variabilă numerică
- Regresia predictivă $r_{t+\mathbf{1}} = a + b\,S_t + \varepsilon_{t+\mathbf{1}}$, cu S_t scorul de sentiment: un S_t persistent, cu inovații corelate cu randamentele, deplasează $\hat{b}$ și testul t Stambaugh (1999)
- Clasificatorii evaluați pe aceleași texte se compară împerecheat, cu testul McNemar exact
- Qwen 7B față de Qwen 1.5B pe titluri financiare: acuratețea crește cu 21,5 puncte procentuale, McNemar $p < 0{,}001$
- O strategie pe sentimentul titlurilor are un raport Sharpe de $+0{,}63$ înainte de costuri și de $-1{,}48$ după costuri
- Costul de tranzacționare care anulează cîștigul: 1,5 bp pe tranzacție

Capitolul 16: Active digitale și DeFi

- Studiul de caz al capitolului (Pele et al. (2023)): criptomonedele formează o clasă de active distinctă într-un spațiu al caracteristicilor în care un factor legat de cozi le separă
- DeFi (Decentralised Finance, finanțele descentralizate) funcționează prin contracte inteligente
- Legătura Bitcoin–S&P 500: sup-Wald 20,2 (cea mai mare statistică Wald pe toate datele candidate de ruptură; valoarea critică de 5%: 11,6) Andrews (1993)
- Ruptura estimată: 9 mar. 2020, nu lansarea ETF-urilor din 2024
- Tail index-ul Hill al pierderilor: Bitcoin 2,73, CI 95% [2,12; 3,33]; S&P 500 2,87, CI 95% [2,07; 3,67]
- Intervalele se suprapun: cozile Bitcoin nu sînt semnificativ mai groase decît cele ale S&P 500

Capitolul 17: Bule și crahuri

- O bulă este o traiectorie a prețului care crește mai repede decît o pot justifica fundamentele
- GSADF: cea mai mare statistică ADF (Augmented Dickey–Fuller) pe coada din dreapta, pe toate fracțiunile de eșantion $[r_1, r_2]$ de lungime cel puțin r_0 Phillips, Shi & Yu (2015)

$$GSADF = \sup_{r_2 \in [r_0, 1]} \sup_{r_1 \in [0, r_2 - r_0]} ADF_{r_1}^{r_2}$$

- Schimbările de volatilitate distorsionează nivelul testului: valori critice prin wild bootstrap
- Bitcoin 2014–2026 (săptămînal): GSADF 3,85 față de valoarea critică de 95% 2,27: sînt detectate episoade explozive
- Un regim față de două regimuri Markov pentru Bitcoin: $LR = 123{,}2$, față de valoarea critică de 95% din bootstrap parametric 11,8 ($p = 0{,}005$)

Capitolul 18: Risc sistemic și rețele

- Riscul sistemic: pierderile unei instituții care se propagă în tot sistemul
- ΔCoVaR: variația VaR-ului sistemului cînd instituția i, cu randamentul X^i, trece de la mediană la stres

$$\Delta\text{CoVaR}^i = \text{CoVaR}_\alpha^{sys|X^i=-\text{VaR}_\alpha^i} - \text{CoVaR}_\alpha^{sys|X^i=\textbf{median}}$$

- ΔCoVaR 1% pentru unsprezece bănci: 4 din 25 de perechi din aceeași regiune diferă la 5%, 0 după corecția Holm
- Comparația prin simpla suprapunere a intervalelor nu ar fi ierarhizat nicio pereche
- LRMES (pierderea așteptată a unei bănci cînd piața scade cu peste 10% în 22 de zile), simulat din GJR–GARCH și DCC Brownlees & Engle (2017): JPMorgan 10,6% în prezent, față de 23,7% cu informația din 31 martie 2020

Capcane metodologice: look-ahead bias și overfitting

- **Look-ahead bias**: orice parametru, prag sau factor de scalare estimat pe tot eșantionul introduce informație din viitor
  - Exemple: parametri GARCH sau standardizare pe tot eșantionul, etichete care se suprapun cu setul de test (Capitolul 13; efectul pe BET: studiul de caz)
  - Remediu: ferestre rolling sau în extindere, purging și embargo, mulțimea de informație $\mathcal{F}_{t-1}$ scrisă lîngă fiecare prognoză
- **Overfitting**: ajustarea in-sample recompensează zgomotul, care nu se repetă out-of-sample (Capitolul 4)
  - Overfitting-ul backtest-ului: încercăm multe strategii și o păstrăm pe cea mai bună Bailey et al. (2017)
  - Raportul Sharpe deflatat corectează pentru numărul de încercări și pentru randamentele non-normale Bailey & López de Prado (2014)
  - Remediu: planul analizei fixat înainte de perioada de test, toate modelele încercate raportate, un reper simplu (1/N, simulare istorică, random walk, log-HAR)

Capcană metodologică: testarea multiplă

- Capitolul 3: din 300 de factori fără putere explicativă, în medie 15,0 trec de $|t| > 1{,}96$, iar cel mai bun ajunge la $|t| \approx 3{,}06$; de aceea literatura cere $|t| > 3$ Harvey, Liu & Zhu (2016)
- Anomalii de calendar, reguli de tranzacționare, specificații: fiecare test în plus adaugă o șansă de descoperire falsă
- Remediu: numărați testele și corectați; cu m teste, p-value-urile ordonate $p_{(1)} \leq \cdots \leq p_{(m)}$ și nivelul a, respingem $H_{(i)}$ dacă

Bonferroni:	$p_{(i)} \leq a/m$
Holm:	$p_{(j)} \leq a/(m-j+1)$ pentru orice $j \leq i$
Benjamini–Hochberg:	$i \leq \max\{k : p_{(k)} \leq k\, a/m\}$

  - Bonferroni și Holm Holm (1979) controlează probabilitatea oricărei descoperiri false (FWER); Holm respinge cel puțin tot ce respinge Bonferroni
  - Benjamini–Hochberg (BH) Benjamini & Hochberg (1995) controlează ponderea așteptată a descoperirilor false printre respingeri (FDR)
  - Pentru prognoze: mulțimea de încredere a modelelor (MCS) în locul multor teste pe perechi Hansen, Lunde & Nason (2011)

Capcană de date: alinierea randamentelor în locul prețurilor

- Bitcoin se tranzacționează zilnic, SPY doar în zilele lucrătoare
  - Greșit: calculăm fiecare randament pe calendarul propriu, apoi păstrăm zilele comune: mișcările Bitcoin din weekend dispar
  - Corect: păstrăm zilele comune ale **prețurilor**, apoi calculăm randamentele: ziua de luni acoperă intervalul vineri–luni pentru ambele
- Bitcoin, 2020–2026, în zilele comune: randament cumulat 1 025% (corect) față de 680% (greșit)
  - Abaterea standard a zilei de luni 5,04% (corect) față de 3,83% (greșit): alinierea greșită ascunde riscul din weekend
- Remediu: aliniați întîi prețurile pe zilele comune; o serie analizată singură rămîne pe calendarul propriu

Capcană de inferență: ignorarea cozilor groase

- Erorile standard clasice presupun independență și momente de ordinul patru finite
  - Momentele de ordin $\geq \alpha$ sînt infinite: pierderile BET au $\hat{\alpha} = 2{,}39 < 4$ (Capitolul 1), deci kurtosis-ul populației este infinit
  - Excesul de kurtosis empiric (11,1) nu estimează nimic, iar un interval bootstrap pentru el nu este valid Athreya (1987): raportați tail index-ul
- Remediu: erori HAC (Heteroskedasticity and Autocorrelation Consistent), bootstrap pe blocuri acolo unde este valid, intervale care respectă frontiera parametrilor
- Eroarea standard HAC Newey–West a unei medii $\bar{d}$ Newey & West (1987): $\mathrm{SE}(\bar{d}) = \sqrt{\hat{\Omega}/T}$, cu

$$\hat{\Omega} = \hat{\gamma}_0 + 2\sum_{j=1}^{L}\Big(1 - \frac{j}{L+1}\Big)\hat{\gamma}_j$$

  - $\hat{\gamma}_j$: autocovarianța empirică la lagul j; L: numărul de laguri; ponderile Bartlett garantează $\hat{\Omega} \geq 0$
  - Aceeași dispersie de termen lung intră în testul Diebold–Mariano (Pasul 5)

Persistența aproape de 1: care frontieră?

- $p = \alpha + \beta \leq 1$ este o restricție pe care o alegem, nu o proprietate a modelului GARCH: în interior, varianța necondiționată și timpul de înjumătățire sînt finite, iar egalitatea este frontiera IGARCH (GARCH integrat)
- Fără restricție, un p puțin peste 1 este admisibil: procesul poate fi strict staționar, cînd $E \ln(\alpha z_t^2 + \beta) < 0$ Nelson (1990), dar nu are varianță finită și nici timp de înjumătățire
- BET: $\hat{p} = 0{,}9907$ se află în interiorul regiunii; dificultatea vine de la p **adevărat**, care poate fi egal cu 1
- La $p = 1$ estimatorul nu este aproximativ Normal, deci intervalul Wald [0,974; 1,007] nu este informativ sub restricția noastră, nu „greșit" Andrews (1999)
- Testul raportului de verosimilitate pentru H_0: $p = 1$ are distribuția de frontieră $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$, cu valoarea critică de 5% 2,71 în loc de 3,84; BET: $LR = 1{,}01$, p-value 0,16, deci IGARCH nu este respins
- CI din verosimilitatea profil, în spațiul $p \leq 1$: [0,975; 1], deci timpul de înjumătățire este de cel puțin 27 de zile, fără o limită superioară finită
- Valorile critice de frontieră se aplică doar cînd parametrul adevărat se poate afla pe marginea spațiului impus, nu ori de cîte ori o estimare este aproape de o limită

Capcană de evaluare: o funcție de pierdere care nu poate ierarhiza ținta

- Prognoza de varianță f_t se compară cu un proxy zgomotos $\hat{\sigma}_t^2$ (r_t^2 sau RV_t): pierderea MSE (Mean Squared Error) $(\hat{\sigma}_t^2 - f_t)^2$ și QLIKE $\hat{\sigma}_t^2/f_t - \ln(\hat{\sigma}_t^2/f_t) - 1$
- Cu un proxy condiționat nedeplasat, MSE și QLIKE ierarhizează prognozele la fel ca varianța adevărată Patton (2011)
- QLIKE depinde doar de raportul proxy/prognoză, deci zilele volatile cîntăresc mai puțin decît la MSE
- Capitolul 9: log-HAR bate GARCH în QLIKE, dar comparația în MSE nu este concludentă
- ES singur nu are o funcție de scor strict consistentă pe clasele largi obișnuite de distribuții
- Perechea (VaR, ES) are una Fissler & Ziegel (2016): scorul FZ0 (Pasul 5), cu teste Diebold–Mariano Diebold & Mariano (1995), a căror precizie este limitată în eșantioane finite Pele & Mazurencu-Marinescu-Pele (2026)
- Remediu: alegeți funcția de pierdere înainte de comparație și precizați-o în raportul proiectului

O întrebare, patru capitole (1/2)

Întrebarea

- Cît poate pierde mîine o poziție pe indicele BET, cu probabilitatea de 1%?
- Pe ce prognoză a acestei pierderi ne-am fi putut baza în timp real, în 2005–2026?

Date

- Indicele BET, valori oficiale zilnice de închidere, 6 ian. 2000 – 18 sept. 2026: 6 670 de randamente log zilnice
- Randamentul log, în %: $r_t = 100 \ln(P_t / P_{t-\mathbf{1}})$, iar pierderea $L_t = -r_t$
- Eliminate: înregistrările duplicate și rîndurile datate în weekend; zilele cu închidere neschimbată rămîn

O întrebare, patru capitole (2/2)

Cei cinci pași

- Capitolul 1: fapte stilizate, cu inferență robustă
- Capitolul 5: GARCH(1,1) cu inovații Student-t
- Capitolul 7: VaR 1% pentru o zi, din patru modele
- Capitolul 8: acoperire, independență și zonele Basel
- Compararea formală a celor patru modele: pierderea FZ0, teste Diebold–Mariano (DM), mulțimea de încredere a modelelor

Un simbol, patru sensuri: α în studiul de caz

Unde	Sensul lui α	Valoarea	Intră în
Pasul 1, Hill	tail index-ul pierderilor	2,39	$P(L > x)$ scade ca $x^{-\alpha}$
Pasul 2, GARCH	ponderea pătratului șocului de ieri	0,192	$\sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$
Pașii 3–4, VaR și Kupiec	nivelul VaR: probabilitatea promisă a depășirii	1%	LR_{uc}, DQ
Pasul 5, FZ0 și ES	nivelul ES cu care se evaluează perechea (VaR, ES)	2,5%	$S(v, e; y)$

- Înainte de a înlocui o cifră, întrebați-vă despre ce α este vorba în formulă: testul Kupiec cere $\alpha = 0{,}01$, niciodată 2,39 sau 0,192
- Și litera p are două sensuri aici: persistența GARCH $p = \alpha + \beta$ și p-value-ul unui test

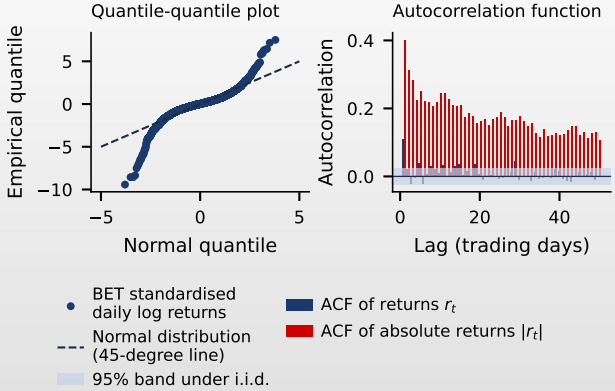
Pasul 1: ce măsurăm și cu ce test

- Cozile: tail index-ul Hill $\hat{\alpha}$ al pierderilor (formula: recapitularea Capitolului 1), cu un CI 95% prin bootstrap pe blocuri
- Volatility clustering: autocorelațiile lui $|r_t|$ și testul Ljung–Box pe r_t^2

$$Q(m) = T(T+2)\sum_{k=1}^{m} \frac{\hat{\rho}_k^2}{T-k} \;\sim\; \chi^2_m \text{ sub } H_0$$

  - H_0: primele m autocorelații sînt zero; $\hat{\rho}_k$: autocorelația empirică la lagul k; aici $m = 10$, deci valoarea critică de 5% este 18,3
- Graficul următor: în stînga, cuantilele randamentelor standardizate față de cele ale distribuției Normale; în dreapta, ACF (funcția de autocorelație) a lui r_t și a lui $|r_t|$

Pasul 1: faptele stilizate ale BET



MFM_ch19_case_study

Pasul 1: citirea graficului

- **Cozi groase** (stînga)
  - Tail index-ul Hill al pierderilor: $\hat{\alpha} = 2{,}39$, CI 95% [2,12; 3,03]; kurtosis-ul nu se raportează, pentru că $\hat{\alpha} < 4$
  - 51 de zile dincolo de ± 4 abateri standard, față de 0,42 așteptate sub distribuția Normală; cea mai mare pierdere: $-13{,}1\%$, pe 7 ian. 2009
- **Volatility clustering** (dreapta)
  - ACF a lui $|r_t|$ la lagul 1: 0,40, cu o scădere lentă (banda presupune randamente i.i.d.)
  - Ljung–Box $Q(10)$ pe r_t^2: 2 440, față de valoarea critică de 18,3
- Autocorelația de ordinul 1 a randamentelor: 0,11, tipică pentru o piață mai puțin lichidă (Capitolele 2, 10)
- Un VaR Normal cu volatilitate constantă este deci prea mic în stres și prea mare în perioadele calme

MFM_ch19_case_study

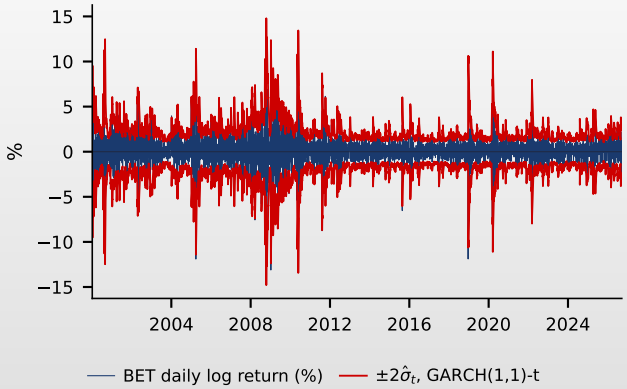
Pasul 2: modelul GARCH(1,1)-t

- GARCH(1,1) din recapitularea Capitolului 5, cu inovații Student-t Bollerslev (1986)

$$r_t = \mu + \varepsilon_t, \qquad \varepsilon_t = \sigma_t z_t, \qquad \sigma_t^2 = \omega + \alpha\, \varepsilon_{t-1}^2 + \beta\, \sigma_{t-1}^2$$

  - σ_t: volatilitatea condiționată, cunoscută în $t-1$; z_t: i.i.d. Student-t cu ν grade de libertate, scalat la varianța 1
  - $\omega > 0$, $\alpha, \beta \geq 0$: α măsoară reacția la știri, β memoria; un ν mic înseamnă cozi groase
- Persistența $\alpha + \beta$ și timpul de înjumătățire $h_{1/2}$: formulele din recapitularea Capitolului 5
- Estimare prin verosimilitate maximă, cu erori standard robuste (sandviș)

Pasul 2: volatilitatea GARCH(1,1)-t



- Randamentele log zilnice ale BET cu $\pm 2\hat{\sigma}_t$ dintr-un GARCH(1,1) cu inovații Student-t, 2000–2026
  - Estimările, cu erorile standard robuste în paranteză: $\hat{\alpha} = 0{,}192$ (0,025), $\hat{\beta} = 0{,}799$ (0,024), $\hat{\nu} = 5{,}01$: cozi groase chiar după filtrare
- Persistența $\hat{\alpha} + \hat{\beta} = 0{,}9907$, un timp de înjumătățire de aproximativ 74 de zile de tranzacționare; ea nu poate fi separată de 1 (capcana „Persistența aproape de 1")
- Volatilitatea condiționată zilnică a atins maximul de 7,39% pe 15 oct. 2008; la finalul eșantionului (18 sept. 2026), $\hat{\sigma}_T = 1{,}67\%$

MFM_ch19_case_study

Pasul 2: volatilitatea de azi și nivelul de termen lung (1/2)

- Două cifre la finalul eșantionului: $\hat{\sigma}_T$ este cunoscut în $T-1$, iar $\hat{\sigma}_{T+1}$ folosește și ultimul randament $r_T = 2{,}17\%$ și intră în VaR-ul de mîine

$$\hat{\sigma}^2_{T+1} = \hat{\omega} + \hat{\alpha}\,(r_T - \hat{\mu})^2 + \hat{\beta}\,\hat{\sigma}^2_T = 0{,}0448 + 0{,}192\,(2{,}17 - 0{,}08)^2 + 0{,}799 \times 1{,}67^2 = 3{,}11$$

  - Deci $\hat{\sigma}_{T+1} = \sqrt{3{,}11} = 1{,}76\%$: un ultim randament mare ridică prognoza peste $\hat{\sigma}_T = 1{,}67\%$

- Varianța de termen lung implicată de model

$$\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta} = \frac{0{,}0448}{0{,}0093} = 4{,}82$$

  - Randamentele sînt în %: $\bar{\sigma} = 2{,}20\%$ pe zi (34,7% pe an), față de abaterea standard empirică de 1,40% pe zi (22,1% pe an)

Pasul 2: volatilitatea de azi și nivelul de termen lung (2/2)

- De ce diferența nu este o contradicție: numitorul $1 - \alpha - \beta = 0{,}0093$ este mic și imprecis
  - Cu ω fix, $p = 0{,}9867$ dă $\bar{\sigma}^2 = 3{,}37$, iar $p = 0{,}9947$ dă 8,47; CI din verosimilitatea profil ajunge la $p = 1$, unde $\bar{\sigma}^2$ este infinită
  - Folosiți $\hat{\sigma}_{T+1}$ și traiectoria prognozei pe orizonturi scurte; tratați nivelul de termen lung ca slab identificat
- Traiectoria prognozei revine geometric spre $\bar{\sigma}^2$, cu rata $\hat{\alpha} + \hat{\beta}$

$$\hat{\sigma}^2_{T+h} = \bar{\sigma}^2 + (\hat{\alpha} + \hat{\beta})^{h-1}(\hat{\sigma}^2_{T+1} - \bar{\sigma}^2), \qquad h = 21\colon\ 4{,}82 + 0{,}9907^{20}\,(3{,}11 - 4{,}82) = 3{,}40$$

  - Deci $\hat{\sigma}_{T+21} = 1{,}84\%$: după o lună, prognoza a parcurs doar 17% din distanța pînă la nivelul de termen lung

Pasul 3: patru prognoze VaR 1% (1/2)

- Necondiționate, pe ultimele 500 de zile: o singură cuantilă pentru toată fereastra
  - **HS** (simulare istorică): pierderea $L = -r$ depășită în 1% din ultimele 500 de zile (cuantila empirică)
  - **Normal**: $\mathrm{VaR} = -(\hat{\mu} + \hat{\sigma} z_{\mathbf{0,01}})$, cu $\hat{\mu}$, $\hat{\sigma}$ media și abaterea standard empirice și $z_{\mathbf{0,01}} = -2{,}326$ cuantila de 1% a distribuției Normale standard
- Condiționate, GARCH-t pe ultimele 1 000 de zile: cuantila se scalează cu prognoza volatilității de azi $\hat{\sigma}_t$

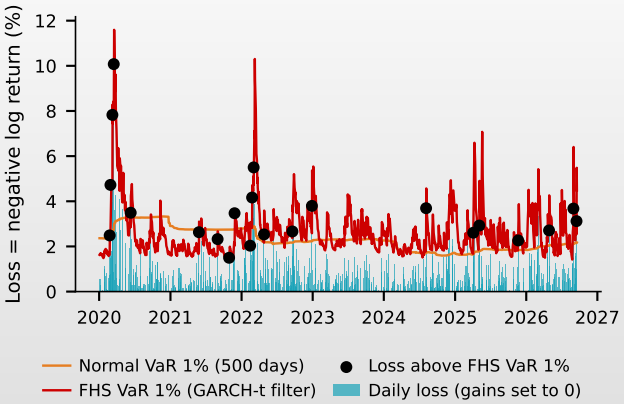
$$\textbf{GARCH-}t\textbf{:}\ \ \mathrm{VaR}_t = -\left(\hat{\mu} + \hat{\sigma}_t\, t_\nu^{-\mathbf{1}}(0{,}01)\sqrt{(\nu-2)/\nu}\right), \qquad \textbf{FHS}\colon\ \mathrm{VaR}_t = -\left(\hat{\mu} + \hat{\sigma}_t\, \hat{q}_{\mathbf{0,01}}(z)\right)$$

  - $t_\nu^{-\mathbf{1}}(0{,}01)$: cuantila de 1% a unei distribuții Student-t cu ν grade de libertate, iar factorul $\sqrt{(\nu-2)/\nu}$ o rescalează la varianța 1
  - **FHS** (simulare istorică filtrată): $\hat{q}_{\mathbf{0,01}}(z)$, cuantila empirică de 1% a reziduurilor standardizate $z_t = (r_t - \hat{\mu})/\hat{\sigma}_t$, înlocuiește cuantila Student-t McNeil & Frey (2000)

Pasul 3: patru prognoze VaR 1% (2/2)

- Procedură în timp real
  - Prognoza pentru ziua t folosește doar datele pînă la $t-1$
  - Parametrii GARCH sînt reestimați la fiecare 21 de zile de tranzacționare, iar $\hat{\sigma}_t$ este actualizat zilnic
- Evaluare: 3 ian. 2005 – 18 sept. 2026, $T = 5\,432$ zile
  - O depășire în ziua t: pierderea $-r_t$ depășește VaR_t
  - Numărul așteptat de depășiri la 1%: $0{,}01\,T \approx 54$
- Modelele necondiționate reacționează doar pe măsură ce fereastra avansează, iar cele condiționate reacționează prin $\hat{\sigma}_t$, în cîteva zile

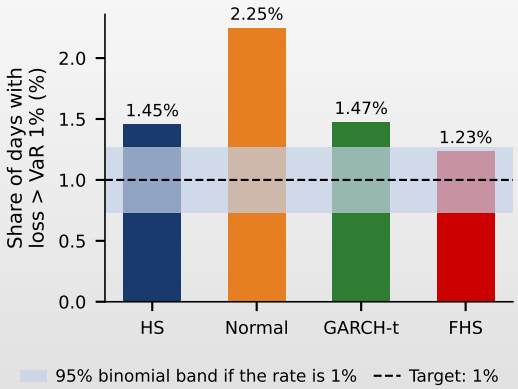
Pasul 3: pierderi și VaR 1%, 2020–2026



- Pierderile zilnice ale BET (cîștigurile sînt trunchiate la 0) și prognozele VaR 1% Normal și FHS
- Punctele negre marchează pierderile peste VaR-ul FHS
- FHS reacționează în cîteva zile: a atins 11,6% pe 18 mar. 2020, în timpul crahului din pandemia COVID-19
  - VaR Normal pe o fereastră de 500 de zile se ajustează lent
- În cele 1 675 de zile erau de așteptat aproximativ 17 depășiri, iar depășirile efective au fost 22 (FHS) și 41 (Normal)
  - Depășirile modelului Normal se grupează în primele săptămîni ale fiecărui episod de stres
- Ultima prognoză VaR: FHS 4,48%, Normal 2,18%

MFM_ch19_case_study

Pasul 4: ratele depășirilor



- Ponderea zilelor cu pierdere peste prognoza VaR 1%, în cele $T = 5\,432$ zile de evaluare din Pasul 3
- Banda albastru deschis: intervalul binomial de 95% [0,74%; 1,27%] dacă rata adevărată este 1%
- Doar FHS (1,23%) se află în bandă, în timp ce modelul Normal (2,25%) este depășit de peste două ori mai des decît ar trebui

MFM_ch19_case_study

Pasul 4: cele trei backtest-uri

- Testul de acoperire Kupiec Kupiec (1995): este rata depășirilor egală cu $\alpha = 1\%$? LR_{uc} din recapitularea Capitolului 8, respins la 5% cînd $LR_{uc} > 3{,}84$
- Testul de independență Christoffersen Christoffersen (1998): este o depășire azi mai probabilă după o depășire ieri?

$$LR_{ind} = -2 \ln \frac{(1-\hat{\pi})^{n_{00}+n_{10}}\, \hat{\pi}^{\,n_{01}+n_{11}}}{(1-\hat{\pi}_{01})^{n_{00}}\, \hat{\pi}_{01}^{n_{01}}\, (1-\hat{\pi}_{11})^{n_{10}}\, \hat{\pi}_{11}^{n_{11}}} \;\sim\; \chi^2_1$$

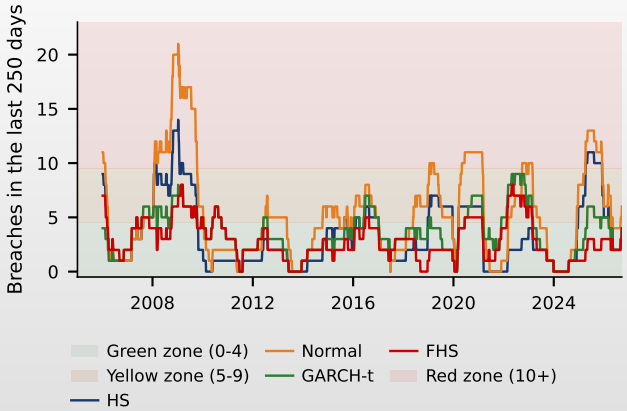
  - n_{ij}: numărul zilelor în starea j după o zi în starea i (1 = depășire, 0 = fără depășire)
  - $\hat{\pi}_{01} = n_{01}/(n_{00}+n_{01})$, $\hat{\pi}_{11} = n_{11}/(n_{10}+n_{11})$: ratele depășirilor după o zi fără depășire și după o depășire
  - $\hat{\pi} = (n_{01}+n_{11})/(n_{00}+n_{01}+n_{10}+n_{11})$: rata pe cele $T-1$ tranziții, care diferă de x/T cu cel mult $1/(T-1)$
- Testul comun: $LR_{cc} = LR_{uc} + LR_{ind} \sim \chi^2_2$, cu valoarea critică de 5% egală cu 5,99

Pasul 4: testele de acoperire și independență

Model	Depășiri	Rata	p_{uc}	p_{ind}	p_{cc}	Zona roșie
HS	79	1,45%	0,002	<0,001	<0,001	5,5%
Normal	122	2,25%	<0,001	<0,001	<0,001	18,6%
GARCH-t	80	1,47%	0,001	0,864	0,005	0,0%
FHS	67	1,23%	0,095	0,267	0,134	0,0%

- Zona roșie: ponderea ferestrelor de 250 de zile cu cel puțin 10 depășiri (semaforul Basel)
- Doar FHS nu este respins de niciunul dintre cele trei teste la 5%
- HS și Normal sînt respinse și de testul de independență, deoarece depășirile lor se grupează
- GARCH-t: independența nu este respinsă, dar depășirile sînt prea multe: coada Student-t nu este suficient de groasă la 1%

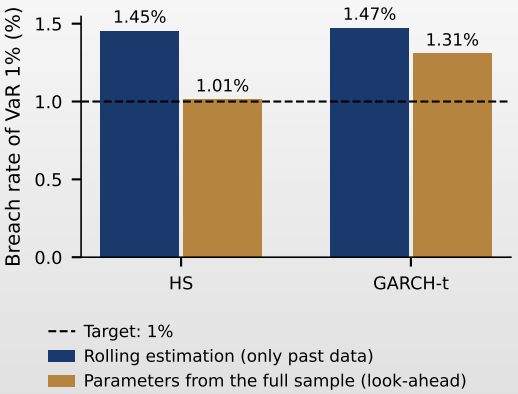
Pasul 4: depășirile din ultimele 250 de zile



- Numărul depășirilor pe o fereastră rolling de 250 de zile, cu zonele Basel verde, galbenă și roșie
- Normal și HS intră în zona roșie în episoade, cînd depășirile lor se grupează (ponderile: ultima coloană a tabelului din Pasul 4)
- Cele două modele cu filtru GARCH nu intră niciodată în ea

MFM_ch19_case_study

Capcana look-ahead bias în studiul de caz



- Cuantila HS calculată pe tot eșantionul dă, prin construcție, 1,01% depășiri
- GARCH-t cu parametri estimați pe tot eșantionul: depășiri în 1,31% din zile, față de 1,47% cu estimare pe fereastră rolling
- Ambele par mai bune decît versiunile în timp real: diferența măsoară valoarea unei informații indisponibile în timp real
- Doar rezultatul pe fereastră rolling este o dovadă despre un model de prognoză

MFM_ch19_case_study

Pasul 5: trei instrumente pentru compararea formală (1/2)

- **Testul Dynamic Quantile (DQ)** Engle & Manganelli (2004): sînt depășirile previzibile?
  - Regresăm $I_t - 0{,}01$ ($I_t = 1$ dacă pierderea depășește VaR_t, altfel 0) pe o constantă, pe $I_{t-1}, \ldots, I_{t-4}$ și pe VaR_t; DQ, statistica Wald că cei șase coeficienți sînt zero, $\sim \chi^2_6$ pentru un model corect
  - Detectează depășiri previzibile din trecut sau din nivelul VaR, pe care testul Christoffersen (un singur lag) le poate rata
- **Scorul FZ0** Patton, Ziegel & Chen (2019): o valoare pe zi pentru perechea de prognoze (VaR, ES); un scor mai mic este mai bun

$$S(v, e; y) = -\frac{1\{y \le v\}(v - y)}{\alpha e} + \frac{v}{e} + \ln(-e) - 1$$

  - $\alpha = 2{,}5\%$: nivelul ES; $v = -\mathrm{VaR}$, $e = -\mathrm{ES}$: prognozele scrise ca cuantile ale randamentelor ($e \le v < 0$); y: randamentul realizat
  - Strict consistent pentru (VaR, ES) Fissler & Ziegel (2016): în medie, perechea adevărată are scorul cel mai mic

Pasul 5: trei instrumente pentru compararea formală (2/2)

- **Teste Diebold–Mariano** pe perechi Diebold & Mariano (1995): t_{DM} din recapitularea Capitolului 14, cu d_t diferența FZ0 dintre cele două modele în ziua t; $t_{DM} \approx N(0,1)$ la acuratețe egală
- **Mulțimea de încredere a modelelor** la 10% Hansen, Lunde & Nason (2011): conține cel mai bun model cu probabilitatea 90%; un model rămîne în ea cît timp $p_{MCS} \geq 0{,}10$
- **Verificarea comparativă a ES** Nolde & Ziegel (2017), față de HS ca model standard: roșu dacă modelul este semnificativ mai slab, verde dacă este semnificativ mai bun, galben în rest

Pasul 5: ce pereche de prognoze evaluează FZ0?

- O a doua pereche de prognoze, din aceleași patru modele, la nivelul ES din Basel, $\alpha = 2{,}5\%$: VaR 2,5% și ES 2,5%
  - Nu VaR 1% din Pașii 3–4: FZ0 este consistent doar cînd *v* și *e* sînt cuantila și media cozii la același nivel α
- ES 2,5% al fiecărui model este pierderea medie dincolo de propriul VaR 2,5%, din aceeași distribuție a pierderilor pe care modelul o folosește pentru VaR în Pasul 3
  - **HS**: media pierderilor din fereastră aflate dincolo de cuantila empirică de 2,5%
  - **Normal**: $\mathrm{ES} = -\hat{\mu} + \hat{\sigma}\,\varphi(z_{\mathbf{0{,}025}})/0{,}025 = -\hat{\mu} + 2{,}338\,\hat{\sigma}$, cu φ densitatea Normală standard
  - **GARCH**-t: $-\hat{\mu}$ plus $\hat{\sigma}_t$ înmulțit cu media cozii superioare a distribuției Student-t rescalate la varianța 1
  - **FHS**: opusul sumei dintre media condiționată și $\hat{\sigma}_t$ înmulțit cu media reziduurilor standardizate z_t cel mult egale cu cuantila lor de 2,5%

Pasul 5: prognozele ES 2,5% în cifre

Model	VaR 1% mediu (Pașii 3–4)	ES 2,5% mediu (Pasul 5)
HS	3,66%	3,94%
Normal	2,90%	2,92%
GARCH-t	2,95%	3,08%
FHS	3,17%	3,41%

- Medii ale prognozelor zilnice pe cele $T = 5\,432$ zile de evaluare, pierderi în % din poziție
- Modelul Normal: ES 2,5% / VaR 1% $= 2{,}338/2{,}326 \approx 1{,}005$, raportul din tabel (2,92/2,90); un ES 1% ar fi cu aproximativ 15% mai mare
- Diferența dintre coloane crește cu grosimea cozii permise de model: aproximativ 7,5% pentru HS și FHS (cozi empirice), 4% pentru GARCH-t, 0,5% pentru modelul Normal

Pasul 5: rezultate

Model	DQ	p_{DQ}	FZ0	p_{MCS}	Zona ES
HS	192,1	$<$0,001	1,424	0,00	standard
Normal	364,6	$<$0,001	1,495	0,00	roșu
GARCH-t	17,9	0,007	1,175	0,18	verde
FHS	9,9	0,129	1,157	1,00	verde

- Doar FHS trece testul DQ la 5% ($p = 0{,}129$), în timp ce GARCH-t nu îl trece ($p = 0{,}007$) din cauza excesului de depășiri
- FZ0 (mai mic este mai bun): FHS și GARCH-t nu diferă semnificativ (DM $t = 1{,}39$), ambele sînt superioare modelelor HS și Normal ($|t| > 4{,}9$)
  - Mulțimea de încredere a modelelor la 10% este {GARCH-t, FHS}
- Verificarea comparativă a ES: Normal roșu, GARCH-t și FHS verzi
- Modelele cu filtru GARCH sînt superioare; FHS rămîne singurul model nerespins de niciun test (acoperire, independență, DQ)

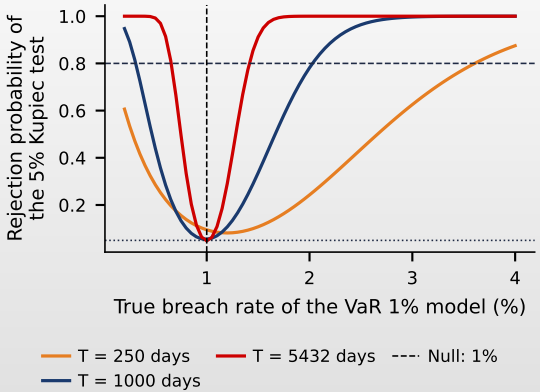
Puterea unui backtest: definiția

- Întrebarea: dacă modelul VaR 1% greșește, cît de des observă testul Kupiec acest lucru?
- Puterea la rata reală a depășirilor π: probabilitatea binomială exactă a regiunii de respingere R_T a testului de 5%

$$\text{Putere}(\pi) = \sum_{x \in R_T} \binom{T}{x} \pi^x (1-\pi)^{T-x}, \qquad R_T = \{x : LR_{uc}(x) > 3{,}84\}$$

  - La $\pi = 1\%$, aceeași sumă dă mărimea efectivă a testului
  - La $T = 250$, R_T conține 0 depășiri și orice număr de cel puțin 7
- Efectul minim detectabil (MDE): cea mai mică rată reală $\pi > 1\%$ cu $\text{Putere}(\pi) \geq 80\%$
- Puterea crește cu T: eroarea standard a ratei observate $\hat{\pi}$ este $\sqrt{\pi(1-\pi)/T}$

Puterea de detecție a unui backtest: testul Kupiec



- Probabilitatea binomială exactă ca testul Kupiec de 5% să respingă un model VaR 1%, după rata reală a depășirilor
- $T = 250$ (un an Basel): o rată reală a depășirilor de 2% este detectată doar în 24% din cazuri
- MDE, căutat pe o grilă cu pasul de 0,05 puncte procentuale: 3,65% la $T = 250$, 2,05% la $T = 1\,000$, 1,45% la $T = 5\,432$
  - Chiar la $T = 5\,432$, o rată reală de 1,3% este detectată doar cu probabilitatea 55%
- O nerespingere cu putere mică înseamnă „nicio dovadă", nu „nicio problemă": precizați puterea înaintea testului

MFM_ch19_case_study

Proiectul în patru pași

- Un studiu empiric al unei întrebări despre piețele financiare, cu metodele acestui curs: **70%** din nota finală (quiz-uri și activitate la seminar 20%, prezență 10%, fără examen final)
- **1. Replicați**: un tabel sau o figură întreagă dintr-un articol publicat (sau din curs), celulă cu celulă (standardul: slide-ul următor)
- **2. Extindeți**: date noi, altă piață (BVB, cripto) sau un eșantion mai recent, după un **plan de analiză** fixat printr-un commit datat înainte de a deschide perioada de test
  - Planul precizează ipoteza nulă, testul, funcția de pierdere, împărțirea eșantionului, strategia de identificare, puterea testului principal și grila de specificații cu corecția ei
- **3. Livrați pe GitHub**: un repository care regenerează fiecare cifră, cu `AI_USE.md` și `AI_ERRORS.md` obligatorii
- **4. Prezentați și susțineți**: prezentarea echipei, apoi o susținere orală de 10 minute
  - Fiecare membru explică un rezultat și răspunde la o întrebare de tipul „ce se schimbă dacă...”; notele pot diferi între membri

Standardul de replicare

- Ținta: un tabel sau o figură întreagă, cu DOI, pagină și numărul tabelului, nu un singur coeficient
  - Raportați o comparație celulă cu celulă: valoarea publicată, valoarea dumneavoastră, diferența și motivul fiecărei abateri (eșantion, filtru, sursa datelor, definiție)
- Replicările la scară mare arată necesitatea acestui standard: multe anomalii se micșorează out-of-sample sau cu date mai bune Hou, Xue & Zhang (2020), iar majoritatea factorilor se replică atunci cînd metodologia este corectă Jensen, Kelly & Pedersen (2023)
- Reproductibilitate: un fișier cu versiunile pachetelor, seed-uri aleatoare fixate, numele seriilor și datele lor, o singură comandă care regenerează fiecare cifră
  - Rezultatele unor echipe diferite care analizează aceleași date diferă mai mult decît sugerează erorile lor standard Menkveld et al. (2024): lucrările mai reproductibile sînt asociate cu o dispersie mai mică (studiul de caz de cercetare din acest capitol)

Alegerea întrebării

O întrebare bună este

- **Specifică**: o piață, o perioadă, o mărime
- **Testabilă**: o ipoteză nulă și un reper
- **Fezabilă**: date pe care le puteți obține și curăța în cîteva săptămîni (datele cursului, din repository-ul GitHub al cursului; Banca Națională a României, BNR; Federal Reserve Economic Data, FRED; Kenneth French Data Library; DefiLlama)
- **Relevantă**: răspunsul contează pentru un investitor, o bancă sau o autoritate

Exemple

- Prea vagă: „Este Bitcoin riscant?”
  - Mai bună: „Au schimbat ETF-urile spot VaR 1% pe o zi al Bitcoin?”
  - Apoi: „Ce model îl prognozează cel mai bine din 2024?”
- Prea largă: „Poate machine learning să prezică piața?”
  - Mai bună: „Bate un model de boosting modelul log-HAR pentru volatilitatea BET de a doua zi, în QLIKE, 2018–2026?”

Metode: de la întrebare la capitol

Dacă întrebarea este despre	Porniți de la
Distribuția randamentelor, cozi, predictibilitate	Capitolele 1–2: momente, teste robuste, rapoarte ale variațelor
Randamente așteptate, factori, portofolii	Capitolele 3–4: Fama–MacBeth, shrinkage, teste Sharpe out-of-sample
Volatilitate și corelație	Capitolele 5, 6, 9: GARCH, DCC, copule, log-HAR
Măsuri de risc și capital	Capitolele 7–8: FHS, EVT, backtest-uri, FZ0
Lichiditate, opțiuni, timp continuu	Capitolele 10–12: Amihud, Black–Scholes, VIX, prima de risc a variației
Prognoză cu machine learning (ML), deep learning sau text	Capitolele 13–15: purged cross-validation (CV, validare încrucișată), modele fundaționale, sentiment
Cripto, bule, risc sistemic	Capitolele 16–18: stablecoin-uri, GSADF, CoVaR, rețele

- Puncte de plecare: întrebarea din Partea C a fiecărui seminar (tabel în Anexă)
  - O întrebare proprie este binevenită dacă răspunde celor cinci întrebări din acest capitol

Identificarea: de la corelație la o afirmație (1/2)

- Întrebările despre evenimente („au schimbat ETF-urile spot, reclasificarea FTSE Russell sau o taxă bancară mărimea X?") cer un contrafactual
  - O piață de control neafectată de eveniment: diferența în diferențe pe măsura de risc Y (de exemplu volatilitatea sau VaR 1%)
    $$\hat{\delta} = \left(\bar{Y}^{\text{după}}_{\text{tratat}} - \bar{Y}^{\text{înainte}}_{\text{tratat}}\right) - \left(\bar{Y}^{\text{după}}_{\text{control}} - \bar{Y}^{\text{înainte}}_{\text{control}}\right)$$
  - Echivalent: δ din regresia $Y_{it} = a + b\,D_i + c\,P_t + \delta\,D_i P_t + \varepsilon_{it}$, cu $D_i = 1$ pentru piața tratată, $P_t = 1$ după eveniment și erori standard HAC
  - Ipoteza de identificare: tendințe paralele (fără eveniment, Y ar fi evoluat la fel pe ambele piețe), verificată pe perioada dinaintea evenimentului

Identificarea: de la corelație la o afirmație (2/2)

- Un control sintetic, construit din mai multe piețe neafectate de eveniment Abadie, Diamond & Hainmueller (2010)
- Date placebo: evenimentul mutat fictiv cu un an mai devreme sau mai târziu
- Dacă momentul este necunoscut: un test sup-Wald de ruptură Andrews (1993), cu data estimată a rupturii raportată, nu una impusă
- Întrebările de prognoză: doar out-of-sample, cu o perioadă de test declarată în plan
- Un singur eveniment înseamnă $n = 1$: precizați ce poate și ce nu poate identifica studiul

Putere și robustețe fără p-hacking (1/2)

- **Putere**: înaintea testului principal, calculați cel mai mic efect pe care testul dumneavoastră îl detectează cu putere de 80% la 5% (MDE)
  - Pentru o estimare aproximativ Normală cu eroarea standard SE, un test bilateral de 5% și puterea 80%

$$\mathrm{MDE} = (z_{0,975} + z_{0,80})\,\mathrm{SE} = 2{,}80\,\mathrm{SE}, \qquad T_{\min} = \left(\frac{2{,}80\,\sigma}{\delta}\right)^2 \text{ cînd } \mathrm{SE} = \sigma/\sqrt{T}$$

  - z_p: cuantila p a distribuției Normale standard; δ: efectul căutat; σ: abaterea standard a unei observații
  - Livrabil: o curbă de putere simulată pentru testul principal la T-ul dumneavoastră
  - Eșantioanele scurte de cripto, ETF-uri sau de după eveniment fac ca multe teste să aibă putere mică (Kupiec la $T = 250$: MDE 3,65%)

Putere și robustețe fără p-hacking (2/2)

- Curba specificațiilor (specification curve): estimați fiecare combinație justificabilă de fereastră, laguri, α și început al eșantionului
  - Reprezentați toate estimările ordonate, cu intervalele lor Simonsohn, Simmons & Nelson (2020)
  - Raportați dispersia pe specificații, nu celula cea mai bună
- Corectați familia: Holm pentru probabilitatea oricărei descoperiri false, Benjamini–Hochberg pentru ponderea lor așteptată sau testul bootstrap reality check al lui White pentru data snooping White (2000)
  - Pragurile de semnificație trebuie să crească odată cu numărul de teste încercate Harvey & Liu (2020), Harvey (2017)

Evaluarea prognozelor în proiectele despre risc

- Volatilitate: MSE sau QLIKE față de un proxy condiționat nedeplasat (capcana de evaluare)
  - Pentru multe modele: mulțimea de încredere a modelelor Hansen, Lunde & Nason (2011), nu modelul cu cea mai mică pierdere medie
- VaR: acoperire, independență și testul DQ Engle & Manganelli (2004); față de un reper, teste de capacitate predictivă condiționată Giacomini & White (2006)
  - Precizați puterea fiecărui backtest la T-ul dumneavoastră
- ES: perechea (VaR, ES) evaluată cu FZ0, verificări comparative cu trei zone Nolde & Ziegel (2017), modele dinamice pentru (VaR, ES) Patton, Ziegel & Chen (2019)
- Studiul de caz integrat (Pașii 1–5) servește drept model

Raportul și prezentarea (1/2)

Raportul: un articol de 8–12 pagini

- **1. Introducere**: întrebarea, ipoteza, contribuția
- **2. Literatură**: 10–15 referințe cu link, cel puțin 3 din ultimii cinci ani, inclusiv Franke, Härdle & Hafner (2019), McNeil, Frey & Embrechts (2015)
- **3. Date și replicare**: surse, perioadă, reguli de curățare; tabelul replicat, celulă cu celulă
- **4. Metodologie**: plan, identificare, putere, reper, funcție de pierdere, teste
- **5. Rezultate**, cu incertitudinea lor
- **6. Robustețe**: specification curve cu corecția
- **7. Concluzie**: răspunsul într-o frază și limitele lui

Raportul și prezentarea (2/2)

Prezentarea (aproximativ 12 minute): slide-urile, în ordine

- Întrebarea (1 slide)
- Datele și un grafic care arată problema (2)
- Metoda și reperul (2)
- Rezultatul principal cu incertitudinea lui (2–3)
- Robustețe, limitări, răspuns (2)
- Un singur mesaj pe fiecare slide, axe lizibile, legenda sub grafic
- Fiecare membru prezintă și poate răspunde la întrebări despre cod, apoi urmează susținerea orală, fără AI

Criterii de evaluare a proiectului

Componentă	Criterii de evaluare
Replicare (pasul 1)	Un tabel sau o figură publicată reprodusă celulă cu celulă; fiecare diferență explicată
Întrebare, date, extindere (pasul 2)	Întrebare specifică și testabilă; date documentate și calendare aliniate
Metode și inferență	Plan, identificare, putere, procedură în timp real, reper, curba specificațiilor cu corecție
Interpretare și raport	Semnificație economică, limitări, concluzie onestă; 8–12 pagini, 10–15 referințe
Repository GitHub (pasul 3)	O singură comandă reproduce fiecare rezultat (fișier de versiuni, seed-uri); `AI_USE.md`, `AI_ERRORS.md`
Prezentare și susținere (pasul 4)	Individual: un rezultat explicat, răspunsuri la „ce se schimbă dacă...”

Livrabile și calendar

- Săptămîna 1 după acest capitol: echipa, întrebarea, propunerea de o pagină (Seminarul 19, C2), repository-ul GitHub
- Săptămînile 2–3: datele, replicarea (pasul 1), planul extinderii fixat în scris printr-un commit datat
- Săptămînile 4–5: extindere, evaluare, robustețe (pasul 2)
- Ultimele săptămîni: raportul de 8–12 pagini, repository-ul cu README și cele două fișiere AI (pasul 3), prezentarea și susținerea orală (pasul 4)
- Datele exacte se anunță la curs și la seminar

Politica AI și cele două fișiere obligatorii

Politica

- **Permis**: asistenți AI pentru cod, depanare, căutarea literaturii și redactare
- **Declarat**: utilizarea nedeclarată a AI este tratată ca plagiat
- **Verificat**: răspundeți pentru fiecare rînd; o referință care nu există este tratată ca date fabricate
- **Fără AI la susținerea orală**: „L-a scris AI-ul" nu este o explicație

Cele două fișiere

- `AI_USE.md`: instrumentele și versiunile, cine le-a folosit și pentru ce, unde ați păstrat cod sau text scris de AI, cum ați verificat tabelul replicat, datele, formulele și referințele
- `AI_ERRORS.md`: cel puțin **trei** locuri în care asistentul a greșit: ce ați întrebat, ce a răspuns, ce era greșit, cum v-ați dat seama, varianta corectă
- Erorile detectate sînt un punct forte al proiectului, nu unul slab

Erori AI tipice în modelarea financiară (1/2)

- **Look-ahead bias**: o statistică pe fereastră rolling sau o scalare care include ziua t în prognoza pentru ziua t
  - Verificare: modificați ultima observație; prognoza pentru acea zi nu trebuie să se schimbe (corectură: `.shift(1)`)
- **Semnul VaR**: cuantila 1% a randamentelor raportată drept VaR sau cuantila 99% a randamentelor (un cîștig) folosită ca pierdere
  - Verificare: $\mathrm{VaR}_\alpha = -q_\alpha(r)$ este pozitiv ori de cîte ori $q_\alpha(r) < 0$; VaR 1% pe o zi al unui indice bursier este de cîteva procente
- **Anualizare**: volatilitatea înmulțită cu 252 în loc de $\sqrt{252}$ sau 252 de zile folosite pentru cripto, care se tranzacționează zilnic
  - Verificare: pe h perioade, mediile se scalează cu h, volatilitățile cu $\sqrt{h}$ (randamente i.i.d.); pentru cripto, 365 de zile

Erori AI tipice în modelarea financiară (2/2)

- **Validare încrucișată (CV) aleatoare pe serii de timp**
  - Validarea K-fold cu amestecare folosește informație din viitor (capcana metodologică, Capitolul 13)
  - Verificare: există o dată de test anterioară unei date de antrenare? Folosiți validare walk-forward sau purged CV cu embargo López de Prado (2018)
- **Referințe inventate**, grade de libertate greșite, valori implicite din biblioteci pe care nu le-ați ales, cifre raportate fără rularea codului
  - Verificare: căutați fiecare DOI pe Crossref și găsiți afirmația în articol, ca în exercițiul de critică a unui răspuns AI din fiecare seminar (Partea C)

Impactul alegerilor cercetătorului (1/2)

- Menkveld et al. (2024), *Journal of Finance* 79(3): 164 de echipe de cercetare testează aceleași șase ipoteze pe aceleași date (Finance Crowd Analysis Project, #fincap)
- **Eroarea standard**
  - Incertitudinea datorată eșantionării, în procesul de generare a datelor
  - **Eroarea nestandard**: incertitudinea datorată alegerilor metodologice ale cercetătorului, în procesul de producere a dovezilor empirice
  - Modelul: echipa j raportează $X_j = e_j + \varepsilon_j$, e_j fiind efectul fix asociat alegerilor metodologice, iar ε_j eroarea de eșantionare
  - Eroarea nestandard $:= Q_{0,75}(x) - Q_{0,25}(x)$, intervalul intercuartilic (IQR) al estimărilor între echipe, $Q_p(x)$ fiind cuantila p a estimărilor x ale echipelor
  - IQR-ul, nu abaterea standard, pentru că e_j pot avea cozi groase

Impactul alegerilor cercetătorului (2/2)

- **Date**
  - Toate tranzacțiile cu contractele futures pe indicele Euro Stoxx 50, 2002–2018, 720 de milioane de înregistrări
  - Șase ipoteze de tipul „nicio tendință anuală" (eficiența pieței, spread-ul realizat, ponderea clienților în volum, ...)
  - Fiecare echipă raportează variația anuală medie în %, cu eroarea ei standard (SE, Standard Error)
  - Patru etape în 2021: analiza independentă, feedbackul evaluatorilor, distribuirea celor mai bune cinci lucrări, estimările finale; detaliile experimentului în Anexă
- Legătura cu acest capitol: fiecare proiect de echipă este o singură specificație din „grădina potecilor care se bifurcă" (garden of forking paths)
  - Preînregistrarea, grila de specificații și un repository care regenerează fiecare cifră sînt remediile

Rezultatele principale: mărimea și calitatea

- **Mărimea**
  - Pentru eficiența pieței, estimarea mediană este $-1{,}1\%$ pe an, cu un IQR de 6,7 puncte procentuale (pp)
  - Chiar și pentru ponderea clienților în volum, un simplu raport, IQR-ul este 1,2 pp în jurul valorii $-3{,}3\%$ (Tabelul I, Panoul C)
  - SE-ul median de 2,5% implică, sub distribuția Normală, un IQR de $1{,}35 \times 2{,}5 = 3{,}4\%$, jumătate din 6,7 pp
  - Ipoteza nulă fără dispersie este respinsă pentru toate cele șase ipoteze, $p < 0{,}0001$ (Tabelul II)
- **Calitatea**: o creștere cu o abatere standard a reproductibilității este asociată cu un IQR mai mic cu 25,0%, iar aceeași creștere a notei evaluatorilor cu un IQR mai mic cu 33,3% (Tabelul III, Fig. 2)
  - Codul care rulează integral, fără intervenție manuală, este asociat cu răspunsuri mai apropiate de consens

Rezultatele principale: feedback, convingeri și bifurcații

- **Feedbackul**: de la etapa 1 la etapa 4, IQR-ul scade cu 47,2%, iar intervalul interdecilic cu 68,2%: evaluarea colegială reduce dispersia, dar nu o elimină
- **Convingerile**: abaterea standard a estimărilor anticipată de echipe este cu 71,7% sub cea observată
- **Bifurcațiile**: alegerea modelului și frecvența eșantionării modifică cel mai mult estimările
  - Un model al variației relative dă o tendință anuală mediană de $-23\,000\%$ pe date zilnice, -200% lunar și $-4{,}56\%$ anual
  - Diferențele logaritmice se adună exact între frecvențe, iar tendința liniară este liniară în date, deci niciuna nu produce această abatere între frecvențe
  - Pentru o măsură pozitivă, inegalitatea lui Jensen deplasează în sus variația relativă medie; valorile negative din articol cer alt mecanism (exemplul de mai jos)

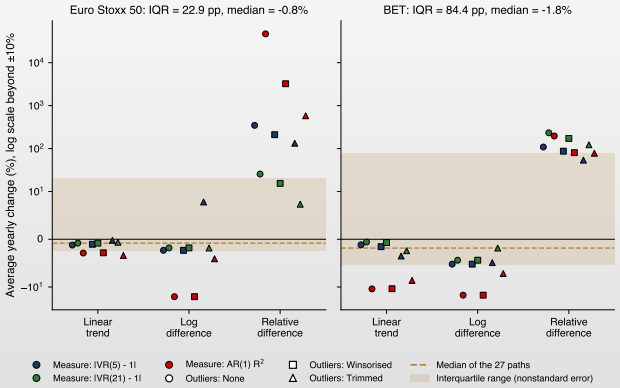
Mini-multivers pe datele cursului: designul

- Închideri zilnice 2002–2018 din datele cursului
  - Deciziile: valori extreme × măsură × model, 27 de specificații
  - Banda este IQR-ul, eroarea nestandard a multiversului
- Măsurile ineficienței
  - $|VR(q) - 1|$ ($VR(q)$: raportul variațelor din Capitolul 2, $q = 5, 21$ zile) și R^2 al unui model autoregresiv AR(1): abaterea de la random walk
  - O tendință pozitivă înseamnă o eficiență în scădere

MFM_ch19_nonstandard_errors

Mini-multivers pe datele cursului: 27 de specificații pe indice

Legendă: $VR(q)$, raportul variațelor pe q zile; AR(1), modelul autoregresiv de ordinul 1; IQR, intervalul intercuartilic; pp, puncte procentuale.



MFM_ch19_nonstandard_errors

Mini-multivers pe datele cursului: rezultatele

- IQR-ul estimărilor: 22,9 pp pentru Euro Stoxx 50 și 84,4 pp pentru BET, în jurul medianelor de $-0{,}8\%$ și $-1{,}8\%$ pe an
- Alegerea modelului determină dispersia
  - Pentru cele nouă specificații cu tendință liniară, IQR-ul este de doar 2,0 pp pentru Euro Stoxx 50 și 7,5 pp pentru BET
  - Cu diferențe relative, estimările cresc exploziv: medianele sînt $+210{,}4\%$ (Euro Stoxx 50) și $+108{,}7\%$ (BET), iar maximul ajunge la $46\,823\%$
- Reperul datorat doar eșantionării: IQR-ul sub distribuția Normală, adică $1{,}35\times$ SE-ul median, 25,9 pp (Euro Stoxx 50) și 50,8 pp (BET)
  - IQR-ul depășește acest reper pentru BET, nu și pentru Euro Stoxx 50

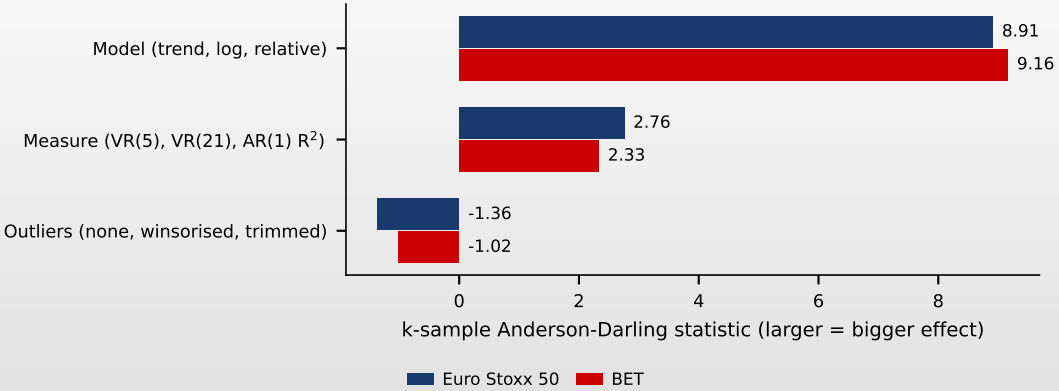
De ce explodează variațiile relative: un exemplu simplu

- O măsură care revine la valoarea de pornire: $m = (1;\ 0{,}01;\ 1)$
  - Variațiile relative $m_t/m_{t-1} - 1$: -99%, apoi $+9\,900\%$; media lor este $+4\,900{,}5\%$
  - Variațiile logaritmice: $\ln 0{,}01$, apoi $\ln 100$; media lor este exact 0, răspunsul corect pentru o măsură fără tendință
  - Pentru o măsură pozitivă, inegalitatea lui Jensen împinge în sus variația relativă medie (Anexă): multiversul cursului explodează în sus
- O măsură pozitivă nu poate scădea cu mai mult de 100%: o tendință de $-23\,000\%$ cere o măsură care își schimbă semnul aproape de zero ($m_{t-1} = 0{,}001$, $m_t = -0{,}2$ dă $-20\,100\%$) sau variații zilnice adunate, nu compuse (250 de variații de -1% însumează -250%)
- Lecția pentru planul dumneavoastră: inspectați numitorii aproape de zero și fixați dinainte transformarea (diferențe logaritmice pentru măsuri pozitive sau tendință liniară)

Alegerile care modifică cel mai mult estimările: statistica folosită

- Statistica Anderson–Darling pentru k eșantioane a celor 27 de estimări, grupate după opțiunea de la fiecare decizie
  - Statistica compară distribuțiile celor k grupe: o valoare mai mare înseamnă grupe mai bine separate
  - Este standardizată, deci centrată în 0 cînd grupele sînt egale: o valoare negativă (valorile extreme, mai jos) înseamnă o separare sub cea datorată hazardului
- O ierarhizare descriptivă, nu un test
  - Cele 27 de estimări folosesc aceleași date

Alegerile care modifică cel mai mult estimările



MFM_ch19_nonstandard_errors

Alegerile care modifică cel mai mult estimările: rezultatele

- Valoarea statisticii pentru fiecare decizie, Euro Stoxx 50 și BET
  - Modelul: 8,91 și 9,16
  - Măsura: 2,76 și 2,33
  - Tratarea valorilor extreme: $-1{,}36$ și $-1{,}02$
- Aceeași ordine ca în articol, atît pe un indice mare din zona euro, cît și pe BET, indicele unei piețe de frontieră în 2002–2018: alegerea modelului modifică cel mai mult estimările
- Pentru proiect: fixați în plan modelul variației anuale (diferențe logaritmice sau tendință liniară) și raportați toată grila, cu decizia care o determină

Limite și o extindere deschisă

- **Autorii**: multiversul acoperă doar cîteva decizii metodologice și explică slab estimările raportate
- **Autorii**: echipelor li s-a cerut să anticipeze abaterea standard, nu IQR-ul
- **Autorii**: testul dispersiei presupune SE-uri raportate consistente
- **Replicarea noastră**: multiversul acoperă doar opțiunile din grilă, deci IQR-ul său nu estimează și nu delimitează inferior dispersia dintre echipele reale
- **Replicarea noastră**: doar închideri zilnice, deci perechile de frecvențe intrazilnice ale articolului nu pot fi rulate
- **Extindere deschisă**: reduce o grilă preînregistrată eroarea nestandard a unei întrebări de risc?
  - Măsurați IQR-ul concluziilor VaR 1% pentru BET pe specificațiile justificabile

O întrebare deschisă

- **Întrebarea deschisă**: ce parte dintr-un rezultat se datorează datelor și ce parte cercetătorului?
  - Replicarea este posibilă: într-un model bayesian al replicării, majoritatea factorilor de evaluare a activelor se replică și funcționează out-of-sample în 93 de țări Jensen, Kelly & Pedersen (2023)
  - Asistenții AI reduc aproape la zero costul fiecărei specificații suplimentare: crește numărul specificațiilor posibile, dar și posibilitatea de a le raporta pe toate
  - Formularea formală: concluzia trebuie să rămînă valabilă pe o mulțime preînregistrată $\mathcal{S}$ de specificații justificabile, cu familia corectată (FWER sau FDR)
  - Raportăm distribuția ei pe $\mathcal{S}$, nu celula cea mai bună

Bucla descoperirii și verificările ei (1/2)

- **Bucla**
  - Întrebarea și H_0/H_1 (săptămîna 1)
  - Literatura și ținta de replicare văzută în PDF (săptămînile 1–2)
  - Preînregistrarea extinderii, fixată printr-un commit datat înaintea primului rezultat al extinderii (săptămîna 2)
  - Replicarea ca test care trece în repository (săptămînile 2–3)
  - Întreaga grilă (săptămînile 4–5)
  - Un examinator AI înainte de susținere

Bucla descoperirii și verificările ei (2/2)

- **Verificările cercetătorului**
  - Cifra-țintă se află în articol
  - Planul precede primul fișier de rezultate în istoricul commit-urilor
  - Fiecare rulare este jurnalizată și numărată
  - O clonă nouă regenerează fiecare cifră
  - Fiecare membru poate deduce formula-cheie fără AI (prompturi și teste: Anexă)

Mini studiu de caz: replicăm, apoi extindem (1/2)

- **Replicăm**: VaR 1% FHS pentru BET; Capitolul 8 raportează 59 de depășiri în 4 937 de zile (1,20%, Kupiec $p = 0{,}181$)
  - Studiul de caz din acest capitol: 67 în 5 432 de zile (1,23%, $p = 0{,}095$)
  - Același model, alt început al evaluării (2007 față de 2005) și alte setări: documentăm orice diferență înainte de a declara o replicare eșuată
- O concluzie tipică propusă de asistent, care citește fiecare p-value separat la 5%: „doar GARCH-EVT este calibrat corect pe ambele piețe"

Mini studiu de caz: replicăm, apoi extindem (2/2)

- **Extindem**
  - Cele 12 teste de acoperire condiționată din Capitolul 8 (S&P 500 și BET $\times$ 6 modele) formează o familie
  - Bitcoin și EUR/RON rămîn în afara familiei: pe aceste piețe, o parte din prognozele GARCH lipsesc (Capitolul 8)
  - Respingeri la 5%: 8 fără corecție, 6 cu Holm (FWER), 7 cu Benjamini–Hochberg, BH (FDR 5%)
  - FHS eșuează doar pe S&P 500 ($p = 0{,}040$); considerat în familia de 12 teste, nu mai este respins, deci după Holm FHS și GARCH-EVT trec pe ambele piețe
- Interpretare: „FHS eșuează pentru S&P 500" depinde de citirea testului separat sau în familia lui
- În proiect, fixați familia în plan înainte de rezultate și raportați ambele citiri

Planul final al echipei

- **Întrebarea**: ideea dumneavoastră din Partea C, scrisă ca H_0/H_1, cu observația care ar infirma-o
- **Replicați întîi**: un tabel publicat, văzut în articol, transformat într-un test care trece în repository
  - Apoi extindeți pe o grilă preînregistrată, cu familia corectată și distribuția completă raportată
- **Livrabile** de-a lungul calendarului: propunerea și ținta de replicare, commit-ul de preînregistrare, testul de replicare care trece, grila de rezultate, susținerea de probă, raportul, susținerea orală
- **Jurnalul AI**: prompturile care au schimbat metodologia în `AI_USE.md`; fiecare eroare detectată, cu testul care a detectat-o, în `AI_ERRORS.md` (șabloanele sînt în folderul `project` al repository-ului)

Idei de reținut

- Randamentele sînt greu de prezis; riscul lor nu: volatilitatea, cozile și dependența pot fi prognozate
- Orice model este judecat out-of-sample, față de un reper simplu, cu o funcție de pierdere potrivită țintei
- Cozile groase schimbă inferența: folosiți erori robuste și bootstrap, raportați intervale, precizați puterea
- Cele mai multe rezultate greșite vin din felul în care este construită analiza, nu din model: look-ahead bias, overfitting, testare multiplă, calendare
- Parcursul analizei este el însuși o sursă de incertitudine: preînregistrați, replicați, raportați toată grila
- Instrumentele noi (ML, modele fundaționale, LLM-uri) ridică exigența evaluării, nu o scad

Verificarea înțelegerii (1/2)

Întrebări

- De ce testul Kupiec cere $\alpha = 0{,}01$, nu 2,39 sau 0,192?
- De ce excesul de kurtosis empiric al randamentelor BET nu estimează nimic?
- De ce intervalul Wald pentru persistența GARCH nu este informativ după ce impunem $p \leq 1$, și ce îl înlocuiește?
- Ce vă spune o nerespingere a testului Kupiec la $T = 250$?
- De ce IQR-ul unui multivers cu 27 de specificații nu este eroarea nestandard a 164 de echipe?

Verificarea înțelegerii (2/2)

Pentru aprofundare

- Seminarul 19: exercițiile A1–A12, B1–B8 și C1–C3 aplică acest capitol pe BET
- Manuale: Franke, Härdle & Hafner (2019); Härdle, Chen & Overbeck (2017); McNeil, Frey & Embrechts (2015); Tsay (2010)
- Cursuri avansate pe quantinar.com: Statistics of Financial Markets
  - Measuring Statistical Risk
- Cod și date: Quantlets/Ch_19 (GitHub)

Două calcule pe cifre noi

Încercați

- **1.** Un model VaR 1% are $x = 6$ depășiri în $T = 400$ de zile. Calculați LR_{uc} cu formula Kupiec din recapitularea Capitolului 8 și decideți la 5%
- **2.** Un GARCH(1,1) are $\alpha + \beta = 0{,}97$. Calculați timpul de înjumătățire $h_{1/2}$; cum se schimbă dacă $\alpha + \beta = 0{,}985$?

Verificați răspunsul

- **1.** $\hat{\pi} = 6/400 = 1{,}5\%$

$$LR_{uc} = 2\big[(394 \ln 0{,}985 + 6 \ln 0{,}015) - (394 \ln 0{,}99 + 6 \ln 0{,}01)\big] = 0{,}88$$

  - Sub 3,84: nu se respinge; la $T = 400$ testul are putere mică, deci înseamnă „nicio dovadă", nu „nicio problemă"
- **2.** $\ln 0{,}5 / \ln 0{,}97 = 22{,}8$ zile și $\ln 0{,}5 / \ln 0{,}985 = 45{,}9$ zile
  - Înjumătățirea lui $1 - \alpha - \beta$ dublează aproximativ timpul de înjumătățire

Inferența pe capitole: formule suplimentare

- **Capitolul 3**: erorile Fama–MacBeth ignoră faptul că beta sînt estimați; covarianța Shanken, cu $\hat{\gamma}$ primele de risc și $\hat{\Sigma}_f$ covarianța factorilor Shanken (1992)

$$\hat{V}_{\mathbf{Sh}} = (1+c)\big(\hat{V}_{FM} - \hat{\Sigma}_f/T\big) + \hat{\Sigma}_f/T, \qquad c = \hat{\gamma}^\top \hat{\Sigma}_f^{-\mathbf{1}} \hat{\gamma}$$

- **Capitolul 5**: QMLE (cvasi-verosimilitate maximă) pentru GARCH, cu A hessiana așteptată (semn schimbat) și B varianța scorului Bollerslev & Wooldridge (1992)

$$\sqrt{T}(\hat{\theta} - \theta) \Rightarrow N\big(0, A^{-\mathbf{1}} B A^{-\mathbf{1}}\big)$$

  - $A = B$ doar pentru inovații Normale; altfel, erorile standard din hessiană ($A^{-\mathbf{1}}$) sînt greșite

- **Capitolul 7**: cuantila empirică, pentru randamente i.i.d. cu densitatea $f(q_\alpha) > 0$; în coadă f este mică, deci VaR-ul istoric este zgomotos

$$\sqrt{T}(\hat{q}_\alpha - q_\alpha) \Rightarrow N\big(0,\ \alpha(1-\alpha)/f(q_\alpha)^{\mathbf{2}}\big)$$

înapoi

Idei de proiect, Partea C a fiecărui seminar (1/2)

Cap.	Întrebarea deschisă (link către seminar)
0	Au schimbat ETF-urile spot corelația Bitcoin cu acțiunile?
1	A scăzut autocorelația BET-TR (BET cu dividendele reinvestite) după reclasificarea FTSE?
2	A devenit BVB mai eficientă după reclasificarea FTSE din 2020?
3	Există prime factoriale la Bursa de Valori București?
4	Bate un portofoliu optimizat de blue chips BVB, în RON, portofoliul 1/N out-of-sample?
5	Este volatilitatea pieței românești determinată de SUA?
6	Au devenit acțiunile din România și din zona euro mai integrate după 2020?
7	Cît capital cere un portofoliu BVB față de un portofoliu S&P 500?

- Fiecare seminar oferă datele, o metodă de pornire și o analiză de referință discutată la seminar

Înapoi

Idei de proiect, Partea C a fiecărui seminar (2/2)

Cap.	Întrebarea deschisă (link către seminar)
8	Ce model de risc ați certifica pentru portofoliul de tranzacționare al unei bănci românești?
9	Este volatilitatea Bitcoin mai previzibilă decît cea a S&P 500?
10	Există o primă de ilichiditate pe BVB?
11	Ce model în timp continuu se potrivește pentru BET și Bitcoin?
12	Este prima de risc a varianței un semnal tranzacționabil?
13	Este un model fundațional superior boosting-ului?
14	Poate un model fundațional zero-shot să înlocuiască GARCH pentru BET?
15	Aduce sentimentul titlurilor cîștig după costuri?
16	Este Bitcoin un activ alternativ, un activ de risc sau un hedge?
17	Există o bulă AI?
18	Cît de expuse sînt băncile românești la stresul bancar din zona euro?

- Capitolul 20 (volatilitatea realizată prognozată cu semnătura traiectoriei, pe datele VOLARE) se potrivește și pentru un proiect de prognoză

Înapoi

De la idee la proiect

- Replicați mai întîi: un tabel sau o figură publicată dintr-un articol din spatele ideii (pasul 1)
- Restrîngeți-o: o piață, o perioadă, un număr de prognozat sau de testat
  - Exemplu: Seminarul 8 devine „Care dintre HS, FHS și GARCH-EVT produce un VaR 1% corect pentru un portofoliu 50/50 format din BET și EUR (cursul EUR/RON) în 2015–2026?”
- Extindeți-o: o a doua piață, un model nou, un eșantion mai lung sau mai recent
  - Exemplu: adăugați un model fundațional (Capitolul 14) ca filtru de volatilitate în FHS
- Păstrați analiza de referință ca reper și încercați să o îmbunătățiți în mod onest

Înapoi

Convențiile de date pentru proiect

- Folosiți datele cursului unde se poate: serii zilnice pentru indici, ETF-uri, acțiuni BVB, cripto și cursuri de schimb, plus date intraday
  - Surse publice: cursurile de referință BNR, FRED, Kenneth French Data Library, DefiLlama; arhiva BVB pentru indicii românești
- Aplicați convențiile cursului
  - Prețuri ajustate pentru ETF-uri și acțiuni, valori de închidere pentru indici, cursuri de schimb și cripto
  - Eliminați zilele de sărbătoare în care furnizorul a repetat prețul anterior și cotațiile de weekend cînd piața este închisă; anualizați cu frecvența reală
  - Mai multe active: aliniați întîi prețurile pe zilele comune, apoi calculați randamentele
- Căutați valorile eronate înainte de modelare: salturile de $\pm 50\%$ în prețurile ajustate sînt de obicei erori de date

Înapoi

Lista de verificare pentru o evaluare onestă

Înainte să vă uitați la rezultate

- Fixați în plan ipoteza, reperul, funcția de pierdere, fereastra de estimare, perioada de test, numărul de modele cu corecția lor, identificarea și puterea

Cînd raportați

- Doar rezultate out-of-sample pentru afirmații despre prognoză
- Fiecare rezultat principal însoțit de eroare standard, CI sau p-value
- Costurile de tranzacționare pentru strategii
- Subperioade și o a doua piață pentru robustețe
- Ce **nu** a funcționat și de ce

Înapoi

Greșeli frecvente care costă puncte

- O întrebare care se schimbă după ce se cunosc rezultatele
- Ajustarea in-sample prezentată drept putere de prognoză
- Niciun reper sau un reper slab, ales pentru a fi ușor depășit
- Multe teste fără corecție
- Grafice fără unități, legende peste date, acronime neexplicate
- Cod care nu rulează sau cifre din raport pe care codul nu le produce
- Rezultate AI păstrate fără verificare: utilizare nedeclarată, cod neverificat, referințe care nu există

Înapoi

Erori nestandard: datele și etapele

- **Date**: toate tranzacțiile cu contractele futures pe Euro Stoxx 50, 2002–2018, 720 de milioane de înregistrări; pentru fiecare parte se indică dacă operează pentru un client sau în cont propriu (Sec. I.A)
- **Șase ipoteze** „nicio tendință anuală" pentru: eficiența pieței, spread-ul bid–ask realizat, ponderea clienților în volum, spread-ul realizat pe ordinele clienților, ponderea ordinelor la piață în ordinele clienților, venitul brut din tranzacționare al clienților
- Fiecare echipă își alege propria măsură pentru fiecare mărime
- **Patru etape** în 2021: analiza independentă (articol și cod), feedback de la doi evaluatori, distribuirea celor mai bune cinci lucrări, estimările finale, fără obligația de a furniza codul (Sec. I.A)
- Un plan de analiză a fost înregistrat public înainte de începerea experimentului

Înapoi

Erori nestandard: calitatea și inferența

- **Calitatea**
  - Calitatea echipei (prima componentă principală a cinci indicatori), scorul de reproductibilitate 0–100 acordat de agenția de certificare Cascad, nota acordată de evaluatori, din care s-a scăzut media (Sec. I.B)
  - Regresii cuantilice ale estimărilor la percentilele 10, 25, 50, 75 și 90; un IQR care scade înseamnă o dispersie mai mică (Sec. I.C)
- **Inferența**
  - Fiecare estimare este testată față de estimarea mediană, cu corecție Bonferroni la un nivel de semnificație de 0,5% pentru familia de teste (Sec. I.C)
  - Analiza multivers: echipele raportează opțiunile metodologice din Tabelul V
  - Statistica Anderson–Darling pentru k eșantioane ierarhizează deciziile după diferențele dintre distribuțiile estimărilor (Sec. II.C)

Înapoi

Erori nestandard, detaliile replicării

- **Deciziile metodologice (bifurcațiile) din Tabelul V**
  - Valorile extreme (nimic; măsura anuală winsorizată sau cu valorile din afara percentilelor 2,5 și 97,5 eliminate), măsura (raportul variațelor zi la săptămînă, raportul variațelor zi la lună, R^2 al unui model autoregresiv AR(1)), modelul (tendință liniară, diferență logaritmică, diferență relativă)
  - Datele zilnice permit comparațiile zi–săptămînă și zi–lună ($VR(5)$, $VR(21)$), iar variantele intrazilnice ale măsurii din Tabelul V necesită date intrazilnice
- **Explozia diferențelor relative**: $m_t = |VR - 1|$ sau R^2 este aproape de zero în unii ani (articolul: Fig. 7)
  - Fără tendință, m_t staționar: panta liniară și variația logaritmică medie sînt centrate în zero, dar pentru m_t independente, $\mathbb{E}(m_t/m_{t-1}) = \mathbb{E}m \cdot \mathbb{E}(1/m) \geq 1$ (Jensen), deci variația relativă medie este pozitivă
- **Statistica Anderson–Darling**: cele 27 de estimări sînt puternic corelate, deci valorile critice tabelate și p-value-urile nu se aplică

Înapoi

Bucla descoperirii, prompturi (1/2)

- **Săptămîna 1, întrebarea**: transformăm o idee în H_0/H_1, cu o țintă de replicare
  - „Iată ideea noastră din Partea C a Seminarului N. Dă trei versiuni mai precise și testabile, tabelul publicat pe care l-ar replica fiecare și seriile din datele cursului de care are nevoie.”
- **Săptămînile 1–2, literatura și ținta**: cifra de replicat este una pe care ați văzut-o în PDF
  - „Listează cele mai citate și cele mai recente articole despre această întrebare, cu DOI; pentru fiecare, estimarea principală, tabelul și eșantionul.”
  - Verificați fiecare DOI pe Crossref; căutați cu Semantic Scholar, Elicit sau Google Scholar; deschideți personal tabelul
- **Săptămîna 2, ipoteze și preînregistrare**, fixate printr-un commit datat înaintea primului rezultat
  - „Pentru H0 și H1, listează ipotezele concurente și implicația care le separă; apoi scrie o preînregistrare: eșantion, filtre, ferestre, teste, corecție.”

Înapoi

Bucla descoperirii, prompturi (2/2)

- **Săptămînile 2–3, cod și replicare**: tabelul replicat devine un test în repository
  - ,,Scrie o funcție care reproduce fiecare celulă a tabelului publicat din datele cursului și o aserțiune cu toleranța pe care o acceptăm.''
- **Săptămînile 4–5, extindere și robustețe**: rulăm toată grila preînregistrată
  - ,,Iată rezultatele tuturor specificațiilor analizate. Ce concluzii rămîn valabile după corecția Holm și pe care le-ar numi un recenzent căutare oportunistă în date (data snooping)?''
- **Înainte de susținere, critica**: asistentul întreabă, echipa răspunde fără AI, ca la susținerea propriu-zisă
  - ,,Joacă rolul examinatorului la susținerea orală: pune cele mai dificile zece întrebări despre identificare, inferență și date. Nu răspunde la ele.''
- **Raportul**: distribuția rezultatelor pe grilă, nu celula cea mai bună; prompturile în `AI_USE.md`, erorile detectate în `AI_ERRORS.md`

Înapoi

Verificările cercetătorului

- **Ținta de replicare există** (cifra, tabelul și eșantionul luate din articol, nu din rezumatul asistentului): raportul citează pagina și tabelul, iar un al doilea membru găsește acolo aceeași cifră
- **Planul precede rezultatele**: în istoricul commit-urilor, preînregistrarea extinderii precede primul fișier de rezultate al extinderii
- **Bifurcațiile analizei** (mai multe specificații încercate decît raportate): fiecare rulare își scrie configurația și rezultatul într-un jurnal, iar raportul le dă numărul și corectează familia
- **Reproductibilitatea** (fără cifre introduse manual): o clonă nouă și o singură comandă regenerează fiecare cifră pînă la ultima zecimală raportată
- **Înțelegerea**: fiecare membru poate deduce formula-cheie și poate apăra fiecare alegere; testul este o susținere de probă în echipă, fără AI, cu o săptămînă înaintea celei reale

Înapoi

Acronime folosite în acest material (1/4)

- **ACF**: AutoCorrelation Function — *funcția de autocorelație*
- **ADF**: Augmented Dickey–Fuller (test) — *testul Dickey–Fuller augmentat*
- **AI**: Artificial Intelligence — *inteligență artificială*
- **AR**: AutoRegressive model — *model autoregresiv*
- **ASE**: Academia de Studii Economice din București
- **BET**: Bucharest Exchange Trading (index) — *indicele de referință al Bursei de Valori București*
- **BET-TR**: BET Total Return (index) — *indicele BET cu dividendele reinvestite*
- **BH**: Benjamini–Hochberg (procedure) — *procedura Benjamini–Hochberg*
- **BNR**: Banca Națională a României
- **BV**: Bipower Variation — *variația bipower*
- **BVB**: Bursa de Valori București
- **CAGR**: Compound Annual Growth Rate — *rata anuală compusă de creștere*
- **CAPM**: Capital Asset Pricing Model — *modelul de evaluare a activelor financiare*
- **CI**: Confidence Interval — *interval de încredere*
- **CoVaR**: Conditional Value-at-Risk — *VaR-ul sistemului condiționat de starea unei instituții*
- **COVID-19**: COronaVIrus Disease 2019 — *boala provocată de coronavirus, 2019*
- **CV**: Cross-Validation — *validare încrucișată*

Acronime folosite în acest material (2/4)

- **DCC**: Dynamic Conditional Correlation — *corelație condiționată dinamică*
- **DeFi**: Decentralised Finance — *finanțele descentralizate*
- **DM**: Diebold–Mariano (test) — *testul Diebold–Mariano de comparare a prognozelor*
- **DOI**: Digital Object Identifier — *identificatorul digital al unei publicații*
- **DQ**: Dynamic Quantile (test) — *testul cuantilei dinamice*
- **ES**: Expected Shortfall — *pierderea așteptată în coadă*
- **ETF**: Exchange-Traded Fund — *fond tranzacționat la bursă*
- **EVT**: Extreme Value Theory — *teoria valorilor extreme*
- **FDR**: False Discovery Rate — *rata descoperirilor false*
- **FHS**: Filtered Historical Simulation — *simulare istorică filtrată*
- **FRED**: Federal Reserve Economic Data — *baza de date economice a Rezervei Federale (St. Louis)*
- **FTSE**: Financial Times Stock Exchange (FTSE Russell, index provider) — *furnizorul de indici FTSE Russell*
- **FWER**: Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **FZ0**: Fissler–Ziegel loss, zero-homogeneous version — *funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GARCH-EVT**: GARCH filter combined with Extreme Value Theory for the tail — *filtru GARCH combinat cu teoria valorilor extreme pentru coadă*
- **GBM**: Geometric Brownian Motion — *mișcarea browniană geometrică*

Acronime folosite în acest material (3/4)

- **GJR**: Glosten–Jagannathan–Runkle (asymmetric GARCH) — *GARCH asimetric Glosten–Jagannathan–Runkle*
- **GRS**: Gibbons–Ross–Shanken (test) — *testul Gibbons–Ross–Shanken*
- **GSADF**: Generalised Sup Augmented Dickey–Fuller (test) — *testul Dickey–Fuller augmentat suprem generalizat*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HAR**: Heterogeneous AutoRegressive (model) — *model autoregresiv heterogen*
- **HS**: Historical Simulation — *simulare istorică*
- **IGARCH**: Integrated GARCH — *GARCH integrat*
- **IQR**: InterQuartile Range — *intervalul intercuartilic*
- **JB**: Jarque–Bera (test) — *testul de normalitate Jarque–Bera*
- **LLM**: Large Language Model — *model lingvistic mare*
- **LR**: Likelihood Ratio — *raportul de verosimilitate*
- **LRMES**: Long-Run Marginal Expected Shortfall — *pierderea marginală așteptată în coadă pe termen lung (într-o criză)*
- **LSTM**: Long Short-Term Memory (network) — *rețea cu memorie pe termen lung și scurt*
- **MCS**: Model Confidence Set — *mulțimea de încredere a modelelor*
- **MDE**: Minimum Detectable Effect — *efectul minim detectabil*
- **ML**: Machine Learning — *învățare automată*
- **MSE**: Mean Squared Error — *eroarea pătratică medie*

Acronime folosite în acest material (4/4)

- **PDF**: Portable Document Format — *formatul de document portabil*
- **QLIKE**: Quasi-LIKElihood (loss function) — *funcția de pierdere de tip cvasi-verosimilitate*
- **QMLE**: Quasi-Maximum Likelihood Estimator — *estimatorul de cvasi-verosimilitate maximă*
- **RV**: Realised Variance — *varianța realizată*
- **SADF**: Sup Augmented Dickey–Fuller (test) — *testul Dickey–Fuller augmentat suprem*
- **SE**: Standard Error — *eroare standard*
- **SML**: Security Market Line — *dreapta pieței titlurilor*
- **SPY**: SPDR S&P 500 ETF Trust — *ETF-ul pe indicele S&P 500*
- **SR**: Sharpe Ratio — *raportul Sharpe*
- **SRISK**: Systemic RISK (capital shortfall measure) — *deficitul de capital al unei bănci într-o criză sistemică*
- **SUA**: Statele Unite ale Americii
- **TLT**: iShares 20+ Year Treasury Bond ETF — *ETF pe obligațiuni americane pe termen lung*
- **VAR**: Vector AutoRegression — *model vector autoregresiv*
- **VIX**: CBOE Volatility IndeX — *indicele de volatilitate CBOE*
- **VOLARE**: VOLatility Archive for Realized Estimates (database) — *arhiva de estimatori realizați ai volatilității (bază de date)*
- **VR**: Variance Ratio — *raportul variațelor*
- **VRP**: Variance Risk Premium — *prima de risc a variației*

Bibliografie (1/6)

- Abadie, A., Diamond, A., Hainmueller, J. (2010). Synthetic control methods for comparative case studies: estimating the effect of California's tobacco control program. *Journal of the American Statistical Association*, 105(490), 493–505.
- Andrews, D.W.K. (1993). Tests for parameter instability and structural change with unknown change point. *Econometrica*, 61(4), 821–856.
- Andrews, D.W.K. (1999). Estimation when a parameter is on a boundary. *Econometrica*, 67(6), 1341–1383.
- Athreya, K.B. (1987). Bootstrap of the mean in the infinite variance case. *Annals of Statistics*, 15(2), 724–731.
- Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- Barndorff-Nielsen, O.E., Shephard, N. (2006). Econometrics of testing for jumps in financial economics using bipower variation. *Journal of Financial Econometrics*, 4(1), 1–30.
- Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, 57(1), 289–300.
- Black, F., Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 637–654.
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.

Bibliografie (2/6)

- Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- Brownlees, C., Engle, R.F. (2017). SRISK: a conditional capital shortfall measure of systemic risk. *Review of Financial Studies*, 30(1), 48–79.
- Chow, K.V., Denning, K.C. (1993). A simple multiple variance ratio test. *Journal of Econometrics*, 58(3), 385–401.
- Christoffersen, P.F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification: how inefficient is the 1/N portfolio strategy?. *Review of Financial Studies*, 22(5), 1915–1953.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Engle, R. (2002). Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.

Bibliografie (3/6)

- Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- Fama, E.F. (1970). Efficient capital markets: a review of theory and empirical work. *Journal of Finance*, 25(2), 383–417.
- Fissler, T., Ziegel, J.F. (2016). Higher order elicitability and Osband's principle. *Annals of Statistics*, 44(4), 1680–1707.
- Forbes, K.J., Rigobon, R. (2002). No contagion, only interdependence: measuring stock market comovements. *Journal of Finance*, 57(5), 2223–2261.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, 5th ed. Springer.
- Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- Gibbons, M.R., Ross, S.A., Shanken, J. (1989). A test of the efficiency of a given portfolio. *Econometrica*, 57(5), 1121–1152.
- Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). Applied Quantitative Finance, 3rd ed. Springer.
- Harvey, C.R. (2017). Presidential address: the scientific outlook in financial economics. *Journal of Finance*, 72(4), 1399–1440.

Bibliografie (4/6)

- Harvey, C.R., Liu, Y. (2020). False (and missed) discoveries in financial economics. *Journal of Finance*, 75(5), 2503–2553.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). . . . and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- Hill, B.M. (1975). A simple general approach to inference about the tail of a distribution. *Annals of Statistics*, 3(5), 1163–1174.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- Hou, K., Xue, C., Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133.
- Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance?. *Journal of Finance*, 78(5), 2465–2518.
- Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.
- Lo, A.W., MacKinlay, A.C. (1988). Stock market prices do not follow random walks: evidence from a simple specification test. *Review of Financial Studies*, 1(1), 41–66.

Bibliografie (5/6)

- Lobato, I., Nankervis, J.C., Savin, N.E. (2001). Testing for autocorrelation using a modified Box–Pierce Q test. *International Economic Review*, 42(1), 187–205.
- López de Prado, M. (2018). Advances in Financial Machine Learning. Wiley.
- Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- McNeil, A.J., Frey, R., Embrechts, P. (2015). Quantitative Risk Management: Concepts, Techniques and Tools, revised ed. Princeton University Press.
- Menkveld, A.J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). Nonstandard errors. *Journal of Finance*, 79(3), 2339–2390.
- Nelson, D.B. (1990). Stationarity and persistence in the GARCH(1,1) model. *Econometric Theory*, 6(3), 318–334.
- Newey, W.K., West, K.D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Nolde, N., Ziegel, J.F. (2017). Elicitability and backtesting: perspectives for banking regulation. *Annals of Applied Statistics*, 11(4), 1833–1874.
- Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.

Bibliografie (6/6)

- Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413.
- Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiatis, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *European Journal of Finance*, 29(10), 1064–1105.
- Phillips, P.C.B., Shi, S., Yu, J. (2015). Testing for multiple bubbles: historical episodes of exuberance and collapse in the S&P 500. *International Economic Review*, 56(4), 1043–1078.
- Shanken, J. (1992). On the estimation of beta-pricing models. *Review of Financial Studies*, 5(1), 1–33.
- Simonsohn, U., Simmons, J.P., Nelson, L.D. (2020). Specification curve analysis. *Nature Human Behaviour*, 4(11), 1208–1214.
- Stambaugh, R.F. (1999). Predictive regressions. *Journal of Financial Economics*, 54(3), 375–421.
- Tsay, R.S. (2010). Analysis of Financial Time Series, 3rd ed. Wiley.
- White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126.
- Zhang, L., Mykland, P.A., Aït-Sahalia, Y. (2005). A tale of two time scales: determining integrated volatility with noisy high-frequency data. *Journal of the American Statistical Association*, 100(472), 1394–1411.