



Modelarea piețelor financiare

Capitolul 19: Recapitulare și prezentarea proiectelor



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ASE: Academia de Studii Economice din București
- BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- BNR: Banca Națională a României
- BVB: Bursa de Valori București
- CAPM: Capital Asset Pricing Model (modelul de evaluare a activelor financiare)
- CI: Confidence Interval (interval de încredere)
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- CV: Cross-Validation (validare încrucișată)
- DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- DQ: Dynamic Quantile (test) (testul cuantilei dinamice)
- ES: Expected Shortfall (pierderea așteptată în coadă)
- ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- EVT: Extreme Value Theory (teoria valorilor extreme)
- FDR: False Discovery Rate (rata descoperirilor false)
- FHS: Filtered Historical Simulation (simulare istorică filtrată)
- FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- FTSE: Financial Times Stock Exchange (FTSE Russell, index provider) (furnizorul de indici FTSE Russell)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GARCH-EVT: GARCH filter combined with Extreme Value Theory for the tail (filtru GARCH combinat cu teoria valorilor extreme pentru coadă)

Acronime folosite în acest material (2/2)

- GBM: Geometric Brownian Motion (mișcarea browniană geometrică)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- GRS: Gibbons–Ross–Shanken (test) (testul Gibbons–Ross–Shanken)
- GSADF: Generalised Sup Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat suprem generalizat)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- HS: Historical Simulation (simulare istorică)
- IGARCH: Integrated GARCH (GARCH integrat)
- IQR: InterQuartile Range (intervalul intercuartilic)
- LLM: Large Language Model (model lingvistic mare)
- LRMES: Long-Run Marginal Expected Shortfall (pierdere marginală așteptată în coadă pe termen lung (într-o criză))
- LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- MDE: Minimum Detectable Effect (efectul minim detectabil)
- ML: Machine Learning (învățare automată)
- MSE: Mean Squared Error (eroarea pătratică medie)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)
- SADF: Sup Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat suprem)
- SE: Standard Error (eroare standard)
- SML: Security Market Line (dreapta pieței titlurilor)
- SRISK: Systemic RISK (capital shortfall measure) (deficitul de capital al unei bănci într-o criză sistemică)
- SUA: Statele Unite ale Americii
- VAR: Vector AutoRegression (model vector autoregresiv)
- VIX: CBOE Volatility Index (indicele de volatilitate CBOE)
- VOLARE: VOLatility Archive for Realized Estimates (database) (arhiva de estimatori realizați ai volatilității (bază de date))

Traseul capitolului și rezultatele învățării

Traseul capitolului

- Partea I: cursul într-o singură imagine, recapitularea capitolelor 0–18, șase capcane și un studiu de caz integrat, de la prețurile brute ale BET la o valoare la risc (Value-at-Risk, VaR) de 1% testată
- Partea a II-a: proiectul de echipă, AI în proiect, un studiu de caz de cercetare despre erorile nestandard, o parcurgere a buclei de descoperire cu AI
- Detaliile tehnice se află în Anexa de la final

După acest capitol puteți


- parcurge o întrebare de la date la o prognoză de risc testată, cu inferență validă
- recunoaște cele șase capcane în propriul cod
- scrie un plan de proiect cu replicare, identificare, putere și grilă de specificații



Academia de Studii Economice din București (ASE),
Piața Romană

Foto: Joe Mabel (2014); CC BY 3.0; Wikimedia
[Commons](#)

Cursul într-o singură imagine



- Roșu: firul principal, de la faptele stilizate (Capitolul 1: cozi groase, grupări de volatilitate, aproape nicio predictibilitate liniară) la prognoze de risc pe care le putem testa (Capitolele 5–8: GARCH dă σ_{t+1} , VaR și ES dau pierderea, backtesting-ul spune dacă o putem crede)
- Capitolele 9–12 măsoară mai bine volatilitatea (date intraday, prețuri de opțiuni) și în timp continuu; Capitolele 13–15 aduc modele flexibile, evaluate mereu cu instrumentele din Capitolul 8
- Capitolele 16–18 aplică aceleași instrumente pentru crypto, bule și întregul sistem financiar; Capitolul special 20: volatilitatea realizată cu semnăturile traiectoriilor, pe datele VOLARE

Cinci întrebări pentru orice model

Înainte de estimare

- ▣ **Date:** ce serie, ce calendar, ce ajustări (dividende, split-uri, sărbători)?
- ▣ **Model:** ce fapt stilizat surprinde și ce ignoră?
- ▣ **Estimare:** pe ce fereastră, cu ce informație la momentul t ?

După estimare

- ▣ **Evaluare:** în afara eșantionului, cu o funcție de pierdere potrivită țintei (QLIKE, FZ0) și cu testele de diagnostic potrivite (de exemplu Kupiec)?
- ▣ **Incertitudine:** erori standard robuste, bootstrap, test față de un reper simplu?
- ▣ Dacă lipsește un răspuns, rezultatul nu este încă o concluzie

Capitolele 0–2: piețe, randamente și eficiență

- ▣ **Capitolul 0, Piețele financiare în 2026:** Piețele combină burse, dealeri extrabursieri, fonduri tranzacționate la bursă (exchange-traded funds, ETF), algoritmi și blockchain-uri
 - ▶ 2015–2026: SPY (ETF pe S&P 500, cu dividende reinvestite) 13,7% pe an cu volatilitate 17,6%; Bitcoin 60,6% pe an cu 66,7%
 - ▶ BET, iulie 2007 – februarie 2009: un drawdown de –82,5%
- ▣ **Capitolul 1, Fapte stilizate și randamente:** Randamentele sunt necorelate, dar nu independente: mărimea lor este previzibilă, semnul aproape deloc
 - ▶ BET, indicele Hill al pierderilor (cele mai mari $k = 153$ pierderi): $\hat{\alpha} = 2,39$, CI 95% prin bootstrap pe blocuri [2,12, 3,03]: momentul de ordinul patru este probabil infinit
 - ▶ Zilele dincolo de 5σ sunt de peste 1000 de ori mai frecvente decât prezice distribuția Normală
- ▣ **Capitolul 2, Eficiența pieței:** Eficiență: prețurile reflectă pe deplin informația disponibilă; un test al predictibilității randamentelor anormale este un test comun al eficienței și al modelului de randament așteptat Fama (1970)
 - ▶ Ponderea ferestrelor mobile care resping mersul aleator: S&P 500 6,4%, BET 22,4%, Bitcoin 0,0%
 - ▶ O respingere statistică nu înseamnă profit exploatabil

Capitolele 3–5: evaluarea activelor, portofolii și GARCH

- ▣ **Capitolul 3, Modele factoriale și evaluarea activelor:** Randamentele așteptate ar trebui să răsplătească doar expunerea la factori sistematici
 - ▶ 25 de portofolii după mărime și raportul valoare contabilă/de piață: panta SML $-4,4\%$, $GRS = 4,18$: CAPM este respins
 - ▶ ETF-uri sectoriale: prima componentă principală (piața) explică 66% din varianță
- ▣ **Capitolul 4, Optimizarea portofoliului:** Markowitz pune întrebarea corectă, dar eroarea de estimare domină răspunsul [Markowitz \(1952\)](#)
 - ▶ Eșantioane de 60 de luni: Sharpe median în eșantion 1,57, Sharpe adevărat median 0,30
 - ▶ 96% dintre portofoliile tangente estimate sunt de fapt mai slabe decât $1/N$
- ▣ **Capitolul 5, Volatilitate condiționată: GARCH:** Volatilitatea se grupează, deci șocul de azi prezice varianța de mâine [Engle \(1982\)](#), [Bollerslev \(1986\)](#)
 - ▶ S&P 500, 2000–2026: $\alpha + \beta = 0,9947$, un timp de înjumătățire de 131 de zile
 - ▶ BET: CI 95% din verosimilitatea profil pentru $\alpha + \beta$ este $[0,975, 1]$ (IGARCH nu este respins): timpul de înjumătățire este de cel puțin 27 de zile, fără o limită superioară finită

Capitolele 6–8: dependență, măsuri de risc și backtesting

- ▣ **Capitolul 6, Volatilitate multivariată și dependență:** Corelațiile se schimbă odată cu regimul macroeconomic; diversificarea nu este garantată
 - ▶ SPY–TLT (ETF pe obligațiuni americane pe termen lung): ρ de la $-0,40$ la $0,11$ după 2022, deci un portofoliu 60/40 a trecut de la $10,4\%$ la $13,2\%$ volatilitate
 - ▶ Corelația DCC Bitcoin–SPY: $0,04$ înainte de 2020, $0,31$ de atunci
- ▣ **Capitolul 7, VaR și Expected Shortfall:** VaR este o cuantilă a pierderii, ES pierderea medie dincolo de ea; ES este coerent
 - ▶ S&P 500, zilnic: $\text{VaR}_{1\%}$ istoric = $3,45\%$, $\text{ES}_{1\%} = 5,01\%$
 - ▶ Distribuția Normală dă doar $2,80\%$: cozile groase contează
- ▣ **Capitolul 8, Backtesting și evaluarea prognozelor de risc:** Testăm numărul și momentul depășirilor: acoperirea și independența [Kupiec \(1995\)](#), [Christoffersen \(1998\)](#)
 - ▶ S&P 500, VaR 1%, 2007–2026: depășiri Normal $2,70\%$, HS $1,67\%$, FHS $1,23\%$, GARCH-EVT $1,13\%$
 - ▶ Un filtru GARCH plus o coadă flexibilă câștigă pe toate cele patru piețe

Capitolele 9–11: frecvență înaltă, lichiditate și timp continuu

- ▣ **Capitolul 9, Volatilitate realizată:** Prețurile intraday măsoară varianța zilnică (RV , Realised Variance, varianța realizată); modelul log-HAR (Heterogeneous AutoRegressive, autoregresiv heterogen) surprinde memoria ei lungă Corsi (2009)
 - ▶ SPY: kurtosis 15,73 pentru randamentele de la deschidere la închidere, 2,65 după împărțirea la $\sqrt{RV_t}$
 - ▶ log-HAR bate GARCH(1,1)- t în QLIKE cu 10% pentru SPY ($p = 0,021$) și cu 22% pentru Bitcoin
- ▣ **Capitolul 10, Microstructura pieței:** Prețurile se formează în registre de ordine limită; spread-ul compensează costurile de procesare, riscul de inventar și selecția adversă
 - ▶ Raportul Amihud (puncte de bază, bp, la 1 milion USD): SPY 0,0016, Banca Transilvania 24,7, Transelectrica 1024,0
 - ▶ SPY: variația prețului în primele 5 minute este de 2,06 ori mai mare decât într-un interval de aceeași durată de la prânz
- ▣ **Capitolul 11, Modele în timp continuu:** Mișcarea browniană este limita măsurilor aleatoare; lema lui Itô rezolvă ecuațiile prețurilor
 - ▶ S&P 500 față de mișcarea browniană geometrică: 62 de zile dincolo de ± 4 abateri standard, față de 0,59 așteptate
 - ▶ Indicele Hill al pierderilor S&P 500: 2,87 [2,07, 3,67] (Capitolul 16): momentul de ordinul patru este probabil infinit, spre deosebire de randamentele log Normale ale GBM

Capitolele 12–14: opțiuni, machine learning și modele fundamentale

- ▣ **Capitolul 12, Opțiuni și suprafața de volatilitate:** Black–Scholes evaluează opțiunile prin hedging; volatilitatea implicită este estimarea pieței pentru σ [Black & Scholes \(1973\)](#)
 - ▶ 1990–2026: VIX mediu 19,4, volatilitatea realizată medie în luna următoare 15,3
 - ▶ Prima de risc a varianței este pozitivă în 86% din zile, dar nu și în prăbușiri
- ▣ **Capitolul 13, Machine Learning în finanțe:** Modele flexibile, dar semnal slab și mult zgomot; partea specifică finanțelor este procesul [López de Prado \(2018\)](#)
 - ▶ K-fold amestecat raportează o acuratețe de 69,4% pe zgomot pur: leakage
 - ▶ S&P 500: seria diferențiată fracționar devine staționară la $d^* = 0,25$; niciun model nu bate regula „mereu în creștere”
- ▣ **Capitolul 14, Deep learning și modele fundamentale pentru serii de timp:** LSTM-urile (Long Short-Term Memory, rețele cu memorie pe termen lung și scurt) și Transformerile învață din secvențe; modelele fundamentale prognozează zero-shot
 - ▶ Volatilitatea realizată SPY, QLIKE: Chronos-2 0,231, log-HAR 0,234, GARCH- t 0,283; primele două nu diferă semnificativ
 - ▶ VaR 1% Chronos-2 fără recalibrare pe S&P 500: 1,67% depășiri

Capitolele 15–16: text și active digitale

- **Capitolul 15, LLM-uri și analiza sentimentului:** De la dicționare la FinBERT și la modelele lingvistice mari (Large Language Models, LLM): textul devine un număr
 - ▶ Qwen 7B față de 1.5B pe titluri financiare: +21,5 puncte procentuale de acuratețe, McNemar $p < 0,001$
 - ▶ O strategie pe sentimentul titlurilor: Sharpe +0,63 înainte și -1,48 după costuri; costul de echilibru 1,5 bp pe tranzacție
- **Capitolul 16, Active digitale și DeFi:** Criptomonedele formează o clasă de active distinctă în spațiul caracteristicilor din [Pele et al. \(2023\)](#), unde un factor de coadă le separă; indicii lor de coadă Hill nu sunt semnificativ mai mici decât cei ai acțiunilor sau ai aurului (Capitolul 16)
 - ▶ Legătura Bitcoin–S&P 500: sup-Wald 20,2 (valoarea critică de 5% 11,6), ruptura estimată pe 9 mar. 2020, nu la lansarea ETF-urilor din 2024
 - ▶ Indicele Hill al pierderilor: Bitcoin 2,73 [2,12, 3,33], S&P 500 2,87 [2,07, 3,67]: nu se pot distinge statistic

Capitolele 17–18: bule și risc sistemic

- ▣ **Capitolul 17, Bule și crahuri:** O bulă este o traiectorie a prețului care crește mai repede decât o pot justifica fundamentele
 - ▶ Bitcoin 2014–2026 (săptămânal): GSADF 3,85 față de valoarea critică de 95% 2,27: sunt detectate episoade explozive
 - ▶ Unul față de două regimuri Markov pentru Bitcoin: statistica raportului de verosimilitate $LR = 123,2$, valoarea critică de 95% din bootstrap parametric 11,8 ($p = 0,005$)
- ▣ **Capitolul 18, Risc sistemic și rețele:** Riscul sistemic: pierderile unei instituții care se propagă în tot sistemul
 - ▶ $\Delta\text{CoVaR } 1\%$ (variația VaR 1% al sistemului când o bancă trece de la mediană la stres) pentru unsprezece bănci: 4 din 25 de perechi din aceeași regiune diferă la 5%, 0 după Holm; simpla suprapunere a intervalelor nu ar fi ordonat niciuna
 - ▶ LRMES simulat (22 de zile, piața sub -10%): JPMorgan 10,6% azi, 23,7% cu informația din 31 martie 2020

Capcane de design: look-ahead bias şi overfitting

- ▣ **Look-ahead bias** (informaţia din viitor): estimarea oricărui parametru, prag sau factor de scalare pe tot eşantionul introduce informaţie din viitor
 - ▶ Exemple: parametri GARCH din tot eşantionul, standardizare pe tot eşantionul, etichete care se suprapun cu setul de test; studiul de caz măsoară efectul pe BET
 - ▶ Capitolul 13: K-fold amestecat raportează o acurateţe de 69,4% pe zgomot pur
 - ▶ Remediu: ferestre mobile sau în extindere; purging şi embargo; scrieţi mulţimea de informaţie $\mathcal{F}_{t-1}$ lângă fiecare prognoză
- ▣ **Overfitting-ul**: ajustarea în eşantion răsplăteşte zgomotul, care nu se va repeta
 - ▶ Capitolul 4: Sharpe în eşantion 1,57, Sharpe adevărat 0,30 pentru aceleaşi portofolii
 - ▶ Overfitting-ul backtest-ului: încercăm multe strategii şi o păstrăm pe cea mai bună [Bailey et al. \(2017\)](#); raportul Sharpe deflatat corectează pentru numărul de încercări şi pentru randamentele non-normale [Bailey & López de Prado \(2014\)](#)
 - ▶ Remediu: fixaţi designul înainte de a vă uita la perioada de test; raportaţi toate modelele încercate; comparaţi cu un reper simplu (1/N, simulare istorică, mers aleator, log-HAR)

Capcană de design: testarea multiplă

- ▣ Capitolul 3: din 300 de factori fără valoare, în medie 15,0 trec de $|t| > 1,96$, iar cel mai bun ajunge la $|t| \approx 3,06$
 - ▶ De aceea literatura despre factori cere $|t| > 3$ [Harvey, Liu & Zhu \(2016\)](#)
- ▣ Anomalii de calendar, reguli de tranzacționare, specificații de model: fiecare test în plus adaugă o șansă de descoperire falsă
- ▣ Remediul: numărați testele și corecții
 - ▶ Bonferroni și Holm controlează probabilitatea oricărei descoperiri false (FWER); Benjamini–Hochberg controlează ponderea lor așteptată (FDR)
 - ▶ Pentru prognoze: mulțimea de încredere a modelelor (MCS) în locul multor teste pe perechi [Hansen, Lunde & Nason \(2011\)](#)

Capcană de date: alinierea randamentelor în loc de a preţurilor

- Bitcoin se tranzacţionează zilnic, SPY doar în zilele lucrătoare
 - ▶ Greşit: calculăm fiecare randament pe calendarul propriu, apoi păstrăm zilele comune: mişcările Bitcoin din weekend dispar
 - ▶ Corect: păstrăm zilele comune ale **preţurilor**, apoi calculăm randamentele: ziua de luni acoperă intervalul vineri–luni pentru ambele
- Bitcoin, 2020–2026, în zilele comune: randament cumulat 1025% (corect) faţă de 680% (greşit)
 - ▶ Abaterea standard a zilei de luni 5,04% (corect) faţă de 3,83% (greşit): alinierea greşită ascunde riscul din weekend
- Remediu: aliniaţi întâi preţurile pe zilele comune; o serie singură rămâne pe calendarul propriu

Capcană de inferenţă: cozile groase ignorate

- Erorile standard clasice presupun independenţă şi momente de ordinul patru finite
 - ▶ Pierderile BET: indicele de coadă Hill $\hat{\alpha} = 2,39$, CI 95% prin bootstrap pe blocuri [2,12, 3,03] [Hill \(1975\)](#): cu $\alpha < 4$, kurtosis-ul populaţiei este infinit
 - ▶ Deci kurtosis-ul de selecţie (11,1) nu estimează nimic, iar un interval bootstrap pentru el nu este valid [Athreya \(1987\)](#): raportaţi indicele de coadă
- Persistenţa GARCH pentru BET: CI Wald [0,974, 1,007] trece de frontiera staţionarităţii $\alpha + \beta = 1$, unde aproximarea Normală nu mai funcţionează [Andrews \(1999\)](#)
 - ▶ CI din verosimilitatea profil, în spaţiul parametrilor $p \leq 1$: [0,975, 1] (IGARCH, $p = 1$, nu este respins faţă de valoarea critică la frontieră 2,71), deci timpul de înjumătăţire este de cel puţin 27 de zile şi nu are o limită superioară finită
- Remediu: erori robuste (HAC), bootstrap pe blocuri acolo unde este valid, indici de coadă în loc de kurtosis, intervale care respectă frontiera

Capcană de evaluare: o funcţie de pierdere care nu poate ierarhiza ţinta

- Prognozele de varianţă se compară cu o aproximare zgomotoasă (r_t^2 sau RV_t)
 - ▶ Cu o aproximare condiţionat nedeplasată, MSE şi QLIKE ierarhizează prognozele la fel ca varianţa adevărată; QLIKE depinde doar de raportul aproximare/prognoză, deci zilele volatile cântăresc mai puţin decât la MSE [Patton \(2011\)](#)
 - ▶ Capitolul 9: log-HAR bate GARCH în QLIKE; comparaţia în MSE nu este concludentă
- ES singur nu are o funcţie de scor strict consistentă pe clasele largi obişnuite de distribuţii; perechea (VaR, ES) are, în condiţii slabe [Fissler & Ziegel \(2016\)](#)
 - ▶ Folosiţi FZ0 cu teste Diebold–Mariano [Diebold & Mariano \(1995\)](#); precizia are limite în eşantioane finite [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)
- Remediu: alegeţi funcţia de pierdere înainte de comparaţie şi precizaţi-o în raportul proiectului

O întrebare, patru capitole

Întrebarea

- Cât poate pierde mâine o poziție pe indicele BET, cu probabilitatea de 1%?
- Ce prognoză a acestei pierderi am fi putut crede în timp real, în 2005–2026?

Date

- Indicele BET, valori oficiale zilnice de închidere, 6 ian. 2000 – 18 sept. 2026: 6 670 de randamente log zilnice
- Eliminate înregistrările duplicate (rânduri identice cu cel anterior) și rândurile datate în weekend; zilele de tranzacționare cu închidere neschimbată se păstrează

Cei cinci pași


- Capitolul 1: fapte stilizate, cu inferență robustă
- Capitolul 5: GARCH(1,1) cu inovații Student- t
- Capitolul 7: VaR 1% pentru o zi, din patru modele
- Capitolul 8: acoperire, independență și zonele Basel
- Compararea formală a celor patru modele: pierderea FZ0, teste DM, setul de modele de încredere



Palatul Bursei, București (2023)


Foto: Chainwit. (2023); CC BY 4.0; Wikimedia Commons

Pasul 1: faptele stilizate ale BET



- Cozi groase (stânga, cuantile față de distribuția Normală): indicele Hill al pierderilor $\hat{\alpha} = 2,39$, CI 95% prin bootstrap pe blocuri $[2,12, 3,03]$, $k = 153$; sub 4, deci kurtosis-ul nu este raportat ca estimare
- 51 de zile dincolo de ± 4 abateri standard, față de 0,42 așteptate sub distribuția Normală; cea mai proastă zi: $-13,1\%$ (log) pe 7 ian. 2009
- Grupări (dreapta): autocorelația de ordinul 1 a $|r_t|$ 0,40, cu scădere lentă; Ljung-Box $Q(10)$ pe r_t^2 2440; randamentele înseși 0,11: o piață mai puțin lichidă (Capitolele 2, 10)
- Consecință: un VaR Normal cu volatilitate constantă va fi prea mic în stres și prea mare în perioadele calme

Pasul 2: volatilitatea GARCH(1,1)- t



- Randamentele log zilnice ale BET cu $\pm 2\hat{\sigma}_t$ dintr-un GARCH(1,1) cu inovații Student- t , 2000–2026; erori standard robuste: $\hat{\alpha} = 0,192$ (0,025), $\hat{\beta} = 0,799$ (0,024), $\hat{\nu} = 5,01$: cozi groase chiar după filtrare
- Persistența $\hat{\alpha} + \hat{\beta} = 0,9907$, un timp de înjumătățire de aproximativ 74 de zile de tranzacționare; CI 95% din verosimilitatea profil [0,975, 1]: persistența nu poate fi separată de 1 (capcana de inferență)
- Volatilitatea zilnică maximă 7,39% pe 15 oct. 2008; la finalul eșantionului 1,67%

Pasul 3: patru prognoze VaR 1%

Necondiționate (ultimele 500 de zile)

- ▣ **HS** (simulare istorică): pierderea $L = -r$ depășită în 1% din ultimele 500 de zile (cuantila empirică)
- ▣ **Normal**: $\text{VaR} = -(\hat{\mu} + \hat{\sigma} z_{0,01})$, $z_{0,01} = -2,326$

Condiționate (GARCH- t pe ultimele 1000 de zile)

- ▣ **GARCH- t** :


$$\text{VaR}_t = -(\hat{\mu} + \hat{\sigma}_t t_\nu^{-1}(0,01) \sqrt{(\nu - 2)/\nu})$$
- ▣ **FHS** (simulare istorică filtrată):

$$\text{VaR}_t = -(\hat{\mu} + \hat{\sigma}_t \hat{q}_{0,01}(z))$$
, cuantila de 1% a reziduurilor standardizate [McNeil & Frey \(2000\)](#)

Design în timp real


- ▣ Prognoza pentru ziua t folosește doar datele până la $t - 1$
- ▣ GARCH reestimat la fiecare 21 de zile de tranzacționare; $\hat{\sigma}_t$ actualizat zilnic
- ▣ Evaluare: 3 ian. 2005 – 18 sept. 2026, $T = 5\,432$ zile
- ▣ Depășiri așteptate la 1%: aproximativ 54

Pasul 3: pierderi și VaR 1%, 2020–2026



- Pierderile zilnice ale BET (câștigurile puse la 0), VaR 1% Normal și FHS; puncte negre: pierderi peste VaR FHS
- FHS reacționează în câteva zile: a atins 11,6% pe 18 mar. 2020, în timpul prăbușirii din pandemia COVID-19; VaR Normal pe o fereastră de 500 de zile se mișcă doar lent
- 1 675 de zile, aproximativ 17 depășiri așteptate: FHS 22, Normal 41; depășirile Normal se grupează în primele săptămâni ale fiecărui episod de stres
- Ultima prognoză: FHS 4,48%, Normal 2,18%: modelele diferă cel mai mult când volatilitatea se schimbă

Pasul 4: ratele depășirilor




- Ponderea zilelor cu pierdere peste prognoza VaR 1%, 3 ian. 2005 – 18 sept. 2026, $T = 5\,432$
- Banda gri: intervalul binomial de 95% [0,74%, 1,27%] dacă rata adevărată este 1%
- Doar FHS (1,23%) se află în bandă; modelul Normal (2,25%) este depășit de peste două ori mai des decât ar trebui
- Urmează: sunt diferențele semnificative și sunt depășirile independente?

Pasul 4: testele de acoperire și independență

Model	Depășiri	Rata	p_{uc}	p_{ind}	p_{cc}	Zona roșie
HS	79	1,45%	0,002	<0,001	<0,001	5,5%
Normal	122	2,25%	<0,001	<0,001	<0,001	18,6%
GARCH-t	80	1,47%	0,001	0,864	0,005	0,0%
FHS	67	1,23%	0,095	0,267	0,134	0,0%


- ▣ p_{uc} : testul de acoperire Kupiec; p_{ind} : testul de independență Christoffersen; p_{cc} : ambele împreună [Kupiec \(1995\)](#), [Christoffersen \(1998\)](#)
- ▣ Zona roșie: ponderea ferestrelor de 250 de zile cu cel puțin 10 depășiri (semaforul Basel)
- ▣ Doar FHS nu este respins de niciunul dintre cele trei teste la 5%; HS și Normal pică și testul de independență: depășirile lor se grupează
- ▣ GARCH-t: independența nu este respinsă, dar depășirile sunt prea multe: coada Student-t nu este suficient de groasă la 1%

Pasul 4: depășirile din ultimele 250 de zile



- Numărul depășirilor pe o fereastră mobilă de 250 de zile, cu zonele Basel verde, galbenă și roșie
- Modelul Normal petrece 18,6% din ferestre în zona roșie, HS 5,5%, cele două modele cu filtru GARCH niciodată

Capcana look-ahead bias în studiul de caz



- Cuantila HS din tot eșantionul: 1,01% depășiri, prin construcție
- GARCH-t cu parametri din tot eșantionul: 1,31% din zile, cu estimare pe fereastră mobilă 1,47%
- Ambele par mai bune decât versiunile în timp real: diferența este valoarea unei informații pe care nimeni nu o avea
- Doar rezultatul pe fereastră mobilă este o dovadă despre un model de prognoză

Pasul 5: trei instrumente pentru compararea formală


- Testul **Dynamic Quantile (DQ)**: regresăm $I_t - 0,01$ pe o constantă, indicatorii depășirilor din cele patru zile anterioare și VaR_t ; $DQ \sim \chi^2_6$ Engle & Manganelli (2004)
 - ▶ Detectează depășirile previzibile din trecut sau din nivelul VaR, pe care testul Christoffersen (o întârziere) le poate rata
- **Scorul FZ0** pentru perechea (VaR 2,5%, ES 2,5%), $v = -\text{VaR}$, $e = -\text{ES}$, randamentul y :
$$S = -\frac{1\{y \leq v\}(v-y)}{\alpha e} + \frac{v}{e} + \ln(-e) - 1$$
 Patton, Ziegel & Chen (2019)
 - ▶ Consistent pentru (VaR, ES) Fissler & Ziegel (2016); teste Diebold–Mariano pe perechi, cu dispersie HAC Diebold & Mariano (1995); setul de modele de încredere la 10% Hansen, Lunde & Nason (2011)
- **Verificarea ES**: comparativă, față de HS ca model standard; roșu dacă modelul este semnificativ mai slab, verde dacă este semnificativ mai bun, galben altfel Nolde & Ziegel (2017)
 - ▶ Toate prognozele folosesc doar datele până la $t - 1$; 5 432 de zile, 3 ian. 2005 – 18 sept. 2026

Pasul 5: rezultate

Model	DQ	p_{DQ}	FZ0	p_{MCS}	Zona ES
HS	192,1	<0,001	1,424	0,00	standard
Normal	364,6	<0,001	1,495	0,00	roșu
GARCH-t	17,9	0,007	1,175	0,18	verde
FHS	9,9	0,129	1,157	1,00	verde

- Doar FHS trece testul DQ la 5% ($p = 0,129$); GARCH- t îl pică ($p = 0,007$) prin excesul de depășiri
- FZ0 (mai mic este mai bun): FHS și GARCH- t nu diferă semnificativ (DM $t = 1,39$), ambele bat HS și Normal ($|t| > 4,9$); setul de modele de încredere la 10% este {GARCH- t , FHS}
- Verificarea comparativă a ES: Normal roșu, GARCH- t și FHS verzi: clasamentul din Pasul 4 rezistă inferenței formale

Cât poate detecta un backtest? Puterea testului Kupiec



- Probabilitatea binomială exactă ca testul Kupiec de 5% să respingă un model VaR 1%, după rata reală a depășirilor
- $T = 250$ (un an Basel): o rată reală de 2% este detectată doar în 24% din cazuri; respingerea cere 0 sau cel puțin 7 depășiri
- Efectul minim detectabil (MDE), aici o rată reală a depășirilor, cu putere de 80%: 3,65% la $T = 250$, 2,05% la $T = 1000$, 1,45% la $T = 5432$; o rată reală de 1,3% este detectată doar cu probabilitatea 55%
- O nerespingere cu putere mică înseamnă „nicio dovadă”, nu „nicio problemă”: precizați puterea înaintea testului

Proiectul în patru pași

- ▣ Un studiu empiric al unei întrebări despre piețele financiare, cu metodele acestui curs; **70%** din nota finală (quiz-uri și activitate la seminar 20%, prezență 10%, fără examen final)
- ▣ **1. Replicați:** reproduceți un tabel sau o figură întreagă dintr-un articol publicat (sau din curs), celulă cu celulă
 - ▶ Raportați diferența pentru fiecare celulă și explicați-o; un asistent AI nu poate ghici un tabel publicat
- ▣ **2. Extindeți:** date noi, altă piață (BVB, crypto) sau un eșantion mai recent, după un **plan de analiză** înregistrat printr-un commit datat în repository înainte de a deschide perioada de test
 - ▶ Planul precizează ipoteza nulă, testul, funcția de pierdere, împărțirea eșantionului, strategia de identificare, puterea testului principal și grila de specificații cu corecția ei
- ▣ **3. Livrați pe GitHub:** cod, un fișier cu versiunile pachetelor, seed-uri aleatoare fixate, proveniența datelor; un singur notebook regenerează fiecare cifră
 - ▶ `AI_USE.md` și `AI_ERRORS.md` sunt obligatorii; raportul este un articol de 8–12 pagini
- ▣ **4. Prezentați și susțineți:** prezentarea echipei, apoi o susținere orală de 10 minute
 - ▶ Fiecare membru explică un rezultat și răspunde la o întrebare de tipul „ce se schimbă dacă...”; notele pot diferi între membri

Standardul de replicare

- Ținta: un tabel sau o figură întreagă, cu DOI, pagină și numărul tabelului, nu un singur coeficient
 - ▶ Raportați o comparație celulă cu celulă: valoarea publicată, valoarea voastră, diferența și motivul fiecărei abateri (eșantion, filtru, sursa datelor, definiție)
- Replicările la scară mare arată de ce: multe anomalii se micșorează în afara eșantionului sau cu date mai bune [Hou, Xue & Zhang \(2020\)](#), iar majoritatea factorilor se replică atunci când designul este corect [Jensen, Kelly & Pedersen \(2023\)](#)
- Reproductibilitate: un fișier cu versiunile pachetelor, seed-uri aleatoare fixate, numele seriilor și datele lor, o singură comandă care regenerează fiecare cifră
 - ▶ Rezultatele unor echipe diferite care analizează aceleași date diferă mai mult decât sugerează erorile lor standard [Menkveld et al. \(2024\)](#): lucrările mai reproductibile sunt asociate cu o diferență mai mică (studiul de caz de cercetare din acest capitol)

Alegerea întrebării

O întrebare bună este

- ▣ **Specifică:** o piață, o perioadă, o mărime
- ▣ **Testabilă:** o ipoteză nulă și un reper
- ▣ **Fezabilă:** date pe care le puteți obține și curăța în câteva săptămâni (datele cursului, în repository-ul GitHub al cursului; surse publice: BNR, FRED, Kenneth French Data Library, DefiLlama)
- ▣ **Relevantă:** răspunsul contează pentru un investitor, o bancă sau o autoritate

Exemple

- ▣ Prea vagă: „Este Bitcoin riscant?”
 - ▶ Mai bună: „Au schimbat ETF-urile spot VaR 1% pe o zi al Bitcoin și ce model îl prognozează cel mai bine din 2024?”
- ▣ Prea largă: „Poate machine learning să prezică piața?”
 - ▶ Mai bună: „Bate un model de boosting modelul log-HAR pentru volatilitatea BET de a doua zi, în QLIKE, 2018–2026?”

Metode: de la întrebare la capitol

Dacă întrebarea este despre	Porniți de la
Distribuția randamentelor, cozi, predictibilitate	Capitolele 1–2: momente, teste robuste, rapoarte ale varianțelor
Randamente așteptate, factori, portofolii	Capitolele 3–4: Fama–MacBeth, shrinkage, teste Sharpe în afara eșantionului
Volatilitate și corelație	Capitolele 5, 6, 9: GARCH, DCC, copule, log-HAR
Măsuri de risc și capital	Capitolele 7–8: FHS, EVT, backtest-uri, FZ0
Lichiditate, opțiuni, timp continuu	Capitolele 10–12: Amihud, Black–Scholes, VIX, prima de risc a varianței
Proгноză cu ML, deep learning sau text	Capitolele 13–15: purged CV, modele fundamentale, sentiment
Cripto, bule, risc sistemic	Capitolele 16–18: stablecoin-uri, GSADF, CoVaR, rețele

- Puncte de plecare: întrebarea din Partea C a fiecărui seminar (tabel în Anexă); o întrebare proprie este binevenită dacă trece de cele cinci întrebări din acest capitol

Identificarea: de la corelație la o afirmație

- ▣ Întrebările despre evenimente („au schimbat ETF-urile spot, reclasificarea FTSE sau o taxă bancară mărimea X ?”) cer un contrafactual
 - ▶ O piață de control neafectată de eveniment: diferența în diferențe pe măsura de risc
 - ▶ Un control sintetic construit din mai multe piețe neafectate de eveniment [Abadie, Diamond & Hainmueller \(2010\)](#); date placebo ale evenimentului (de ex. $\pm$ un an)
- ▣ Moment necunoscut: un test sup-Wald de ruptură [Andrews \(1993\)](#); raportați data estimată a rupturii, nu una impusă
- ▣ Întrebările de prognoză: doar în afara eșantionului, cu o perioadă de test declarată în plan
- ▣ Un singur eveniment înseamnă $n = 1$: spuneți ce poate și ce nu poate identifica designul

Putere și robustețe fără p-hacking

- ▣ **Putere:** înainte de testul principal, calculați cel mai mic efect pe care designul îl detectează cu putere de 80% la 5% (MDE)
 - ▶ Livrabil: o curbă de putere simulată pentru testul principal la T -ul vostru; eșantioanele scurte de crypto, ETF-uri sau de după eveniment fac multe întrebări să aibă putere mică (Kupiec la $T = 250$: MDE 3,65%)
- ▣ Planul de analiză este un commit datat în repository, făcut înainte de deschiderea perioadei de test
- ▣ Curba specificațiilor (specification curve): estimați fiecare combinație justificabilă de fereastră, întârzieri, α și început al eșantionului; reprezentați toate estimările ordonate, cu intervalele lor [Simonsohn, Simmons & Nelson \(2020\)](#)
 - ▶ Raportați dispersia pe specificații, nu celula cea mai bună
- ▣ Corecți familia: Holm pentru orice descoperire falsă, Benjamini–Hochberg pentru ponderea lor sau testul bootstrap reality check al lui White pentru data snooping [White \(2000\)](#)
 - ▶ Descoperiri false și ratate în finanțe [Harvey & Liu \(2020\)](#); perspectiva științifică a domeniului [Harvey \(2017\)](#)

Evaluarea prognozelor în proiectele despre risc

- ▣ Volatilitate: comparăm prognozele cu o aproximare zgomotoasă, dar condiționat nedeplasată, doar printr-o funcție de pierdere robustă (MSE sau QLIKE) [Patton \(2011\)](#)
 - ▶ Multe modele: setul de modele de încredere [Hansen, Lunde & Nason \(2011\)](#), nu cea mai mică pierdere medie
- ▣ VaR: acoperire, independență și testul DQ [Engle & Manganelli \(2004\)](#); cu un reper, teste de capacitate predictivă condiționată [Giacomini & White \(2006\)](#)
 - ▶ Precizați puterea fiecărui backtest la T -ul vostru
- ▣ ES: evaluăm perechea (VaR, ES) cu scorul FZ0; verificări comparative cu trei zone [Nolde & Ziegel \(2017\)](#); modele dinamice pentru (VaR, ES) [Patton, Ziegel & Chen \(2019\)](#)
 - ▶ Studiul de caz integrat (Pașii 1–5) este șablonul

Raportul și prezentarea

Raportul: un articol de 8–12 pagini

- **1. Introducere:** întrebarea, ipoteza, contribuția; **2. Literatură:** 10–15 referințe cu link, cel puțin 3 din ultimii cinci ani, inclusiv [Franke, Härdle & Hafner \(2019\)](#), [McNeil, Frey & Embrechts \(2015\)](#)
- **3. Date și replicare:** surse, perioadă, reguli de curățare; tabelul replicat, celula cu celula
- **4. Design:** plan, identificare, putere, reper, funcție de pierdere, teste
- **5. Rezultate** cu incertitudine; **6. Robustețe:** specification curve cu corecția; **7. Concluzie:** răspunsul într-o frază și limitele lui

Prezentarea (aproximativ 12 minute)

- Întrebarea (1 slide); datele și un grafic care arată problema (2); metoda și reperul (2); rezultatul principal cu incertitudinea lui (2–3); robustețe, limitări, răspuns (2)
- Un mesaj pe slide; axe lizibile, legenda sub grafic
- Fiecare membru prezintă și poate răspunde la întrebări despre cod; apoi susținerea orală de 10 minute, fără AI

Evaluarea proiectului și calendarul

Componentă	Ce urmărim
Replicare (pasul 1)	Un tabel sau o figură publicată reprodusă celulă cu celulă; fiecare diferență explicată
Întrebare, date, extindere (pasul 2) Metode și inferență	Întrebare specifică și testabilă; date documentate și calendare aliniate Plan, identificare, putere, design în timp real, reper, curba specificațiilor cu corecție
Interpretare și raport	Semnificație economică, limitări, concluzie onestă; 8–12 pagini, 10–15 referințe
Repository GitHub (pasul 3)	O singură comandă reproduce fiecare rezultat (fișier de versiuni, seed-uri); AI_USE.md, AI_ERRORS.md
Prezentare și susținere (pasul 4)	Individual: un rezultat explicat, răspunsuri la „ce se schimbă dacă...”

- Săptămâna 1 după acest capitol: echipa, întrebarea, propunerea de o pagină (Seminarul 19, C1), repository-ul GitHub; săptămânile 2–3: datele, replicarea (pasul 1), planul înregistrat printr-un commit datat
- Săptămânile 4–5: extindere, evaluare, robustețe (pasul 2); ultimele săptămâni: repository-ul cu README și cele două fișiere AI (pasul 3), prezentarea și susținerea orală (pasul 4); datele exacte se anunță la curs și la seminar

Politica AI și cele două fișiere obligatorii

Politica

- ▣ **Permis:** asistenți AI pentru cod, depanare, căutarea literaturii și redactare
- ▣ **Declarat:** utilizarea nedeclarată a AI este tratată ca plagiat
- ▣ **Verificat:** răspundeți pentru fiecare rând; o referință care nu există este tratată ca date fabricate
- ▣ **Fără AI la susținerea orală:** „L-a scris AI-ul” nu este o explicație

Cele două fișiere

- ▣ **AI_USE.md:** instrumentele și versiunile, cine le-a folosit și pentru ce, unde ați păstrat cod sau text scris de AI, cum ați verificat tabelul replicat, datele, formulele și referințele
- ▣ **AI_ERRORS.md:** cel puțin **trei** locuri în care asistentul a greșit: ce ați întrebat, ce a răspuns, ce era greșit, cum v-ați dat seama, varianta corectă
- ▣ Erorile prinse sunt un punct forte al proiectului, nu unul slab

Erori AI tipice în modelarea financiară

- **Look-ahead bias:** o statistică pe fereastră mobilă sau o scalare care include ziua t în prognoza pentru ziua t
 - ▶ Verificare: schimbați ultima observație; prognoza pentru acea zi nu trebuie să se miște; decalați cu o zi (`.shift(1)`)
- **Semnul VaR:** cuantila 1% a randamentelor raportată drept VaR sau cuantila 99% a randamentelor (un câștig) folosită ca pierdere
 - ▶ Verificare: $\text{VaR}_\alpha = -q_\alpha(r)$ este pozitiv ori de câte ori $q_\alpha(r) < 0$; VaR 1% pe o zi al unui indice este de câteva procente
- **Anualizare:** volatilitatea înmulțită cu 252 în loc de $\sqrt{252}$ sau 252 de zile folosite pentru crypto, care se tranzacționează zilnic
 - ▶ Verificare: mediile se scalează cu h , volatilitățile cu $\sqrt{h}$; folosiți numărul real de zile de tranzacționare (365 pentru crypto)
- **Validare încrucișată (CV) aleatoare pe serii de timp:** K-fold amestecat învață din viitor (acuratețe de 69,4% pe zgomot pur, Capitolul 13)
 - ▶ Verificare: există o dată de test anterioară unei date de antrenare? Folosiți validare walk-forward sau purged CV cu embargo [López de Prado \(2018\)](#)
- **Referințe inventate,** grade de libertate greșite, valori implicite din biblioteci pe care nu le-ați ales, cifre date fără să fi rulat cod
 - ▶ Verificare: căutați fiecare DOI pe [Crossref](#) și găsiți afirmația în articol; fiecare seminar are un exercițiu C2 care exersează acest lucru

Cât contează alegerile cercetătorului?

- Menkveld et al. (2024), *Journal of Finance* 79(3): 164 de echipe de cercetare testează aceleași șase ipoteze pe aceleași date (Finance Crowd Analysis Project, #fincap; Sec. I.A)
- **Eroarea standard:** incertitudinea datorată eșantionării, în procesul de generare a datelor; **eroarea nestandard:** incertitudinea datorată alegerilor metodologice ale cercetătorului, în procesul de producere a dovezilor empirice (Introducere)
 - ▶ Modelul: echipa j raportează $X_j = e_j + \varepsilon_j$, e_j fiind efectul fix asociat alegerilor metodologice, iar ε_j eroarea de eșantionare (Sec. I.C, ec. 1)
 - ▶ Eroarea nestandard $:= Q_{0,75}(x) - Q_{0,25}(x)$, intervalul intercuartilic (IQR) al estimărilor între echipe (ec. 3); IQR-ul, nu abaterea standard, pentru că e_j pot avea cozi groase
- **Date:** toate tranzacțiile cu contractele futures pe indicele Euro Stoxx 50, 2002–2018, 720 de milioane de înregistrări; șase ipoteze de tipul „nicio tendință anuală” (eficiența pieței, spread-ul realizat, ponderea clienților în volum, ...); fiecare echipă raportează variația anuală medie în %, cu eroarea ei standard (SE)
 - ▶ Patru etape în 2021: analiza independentă, feedbackul evaluatorilor, distribuirea celor mai bune cinci lucrări, estimările finale; detaliile designului în Anexă
- Legătura cu acest capitol: fiecare proiect de echipă este o singură specificație din „grădina potecilor care se bifurcă” (garden of forking paths); preînregistrarea, grila de specificații și un repository care regenerează fiecare cifră sunt remediile


Rezultatele principale: mărimea și calitatea

- ▣ **Mărimea:** pentru eficiența pieței, estimarea mediană este $-1,1\%$ pe an, cu un IQR de 6,7 puncte procentuale (pp); chiar și pentru ponderea clienților în volum, un simplu raport, IQR-ul este 1,2 pp în jurul valorii $-3,3\%$ (Tabelul I, Panoul C)
 - ▶ SE-ul median de $2,5\%$ implică un IQR Gaussian de $1,35 \times 2,5 = 3,4\%$, jumătate din 6,7 pp; ipoteza nulă fără dispersie este respinsă pentru toate cele șase ipoteze, $p < 0,0001$ (Tabelul II)
- ▣ **Calitatea:** o creștere cu o abatere standard a reproductibilității este asociată cu un IQR mai mic cu $25,0\%$, iar aceeași creștere a notei evaluatorilor cu un IQR mai mic cu $33,3\%$ (Tabelul III, Fig. 2)
 - ▶ Codul care rulează cap-coadă este asociat cu răspunsuri mai apropiate de consens

Rezultatele principale: feedback, convingeri și decizii metodologice


- ▣ **Feedbackul:** de la etapa 1 la etapa 4, IQR-ul scade cu 47,2%, iar intervalul interdecilic cu 68,2% (Tabelul IV, Fig. 3)
 - ▶ Evaluarea colegială reduce dispersia, dar nu o elimină
- ▣ **Convingerile:** pe toate ipotezele, abaterea standard a estimărilor prezisă de echipe este cu 71,7% sub cea realizată (Sec. II.B.3, Fig. 4)
 - ▶ Cercetătorii subestimează cât de mult pot diferi echipele care analizează aceleași date
- ▣ **Deciziile metodologice (bifurcațiile):** alegerea modelului și frecvența eșantionării modifică cel mai mult estimările; un model al variației relative dă o tendință anuală mediană de $-23\,000\%$ pe date zilnice, -200% lunar și $-4,56\%$ anual (Fig. 6, Fig. 7)
 - ▶ Inegalitatea lui Jensen pentru rapoartele $M_t = X_t/X_{t-1}$: $\mathbb{E} \ln M_t \leq \ln \mathbb{E} M_t$; diferențele logaritmice se adună exact între frecvențe, iar tendința liniară este liniară în date, deci niciuna nu produce această abatere între frecvențe

Mini-multivers pe datele cursului: 27 de specificații pe indice



- Închideri zilnice 2002–2018 din datele cursului; deciziile metodologice (bifurcațiile) valori extreme $\times$ măsură $\times$ model din Tabelul V; banda este IQR-ul, eroarea nestandard a multiversului
- IQR: 22,9 pp (Euro Stoxx 50) și 84,4 pp (BET), în jurul unor mediane de $-0,8\%$ și $-1,8\%$ pe an; $|VR(q) - 1|$, cu $VR(q)$ raportul varianțelor din Capitolul 2, și R^2 măsoară abaterea de la mersul aleator, deci o tendință pozitivă înseamnă o eficiență în scădere
- Alegerea modelului determină dispersia: pentru cele nouă specificații cu tendință liniară, IQR-ul este de doar 2,0 pp și 7,5 pp; diferențele relative explodează (mediane $+210,4\%$ și $+108,7\%$, până la $46\,823\%$); articolul raportează aceeași explozie (Fig. 7)
- Față de $1,35 \times$ SE-ul median ($25,9$ și $50,8$ pp), IQR-ul depășește reperul de eșantionare pentru BET, nu și pentru Euro Stoxx 50

Ce alegeri modifică estimările?



- Statistica Anderson–Darling pentru k eşantioane a celor 27 de estimări grupate după opțiunea de la fiecare decizie (Sec. II.C): modelul 8,91 (Euro Stoxx 50) și 9,16 (BET); măsura 2,76 și 2,33; valorile extreme $-1,36$ și $-1,02$
- Aceeași ordine ca în articol (Fig. 6): alegerea modelului modifică cel mai mult estimările, atât pe un indice mare din zona euro, cât și pe un indice de frontieră
- Cele 27 de estimări folosesc aceleași date, deci statistica este o ierarhizare descriptivă, nu un test; statistica standardizată este centrată în zero pentru distribuții egale: o valoare negativă indică o separare sub cea datorată hazardului, nu absența unui efect
- Pentru proiectul vostru: fixați în plan modelul variației anuale (diferențe logaritmice sau tendințe liniare), apoi raportați toată grila și decizia care o determină

 MFM_ch19_nonstandard_errors

Limite și o extindere deschisă

- **Limite formulate de autori:** multiversul acoperă doar câteva decizii metodologice și explică slab estimările raportate (nota 32); echipelor li s-a cerut să anticipeze abaterea standard, nu IQR-ul (nota 28)
 - ▶ Testul dispersiei presupune SE-uri raportate consistente (Sec. I.C); dinamica evaluării la reviste rămâne în afara studiului (Sec. I.A)
 - ▶ Multiversul acoperă doar opțiunile incluse în grilă; IQR-ul său nu estimează și nu delimitează inferior dispersia dintre echipele reale
- **Limita datelor în replicare:** doar închideri zilnice, deci perechile de frecvențe intrazilnice din Tabelul V nu pot fi rulate (Seminarul 19, C3 o extinde până la ultimul an complet)
- **Extindere deschisă:** reduce o grilă preînregistrată eroarea nestandard a unei întrebări de risc? Măsurați IQR-ul concluziilor VaR 1% pentru BET pe specificațiile justificabile
 - ▶ Pentru proiectul vostru: raportați distribuția pe grilă și deciziile metodologice care o modifică cel mai mult, nu o singură celulă

O întrebare deschisă și bucla descoperirii

- ▣ **Întrebarea deschisă:** cât dintr-un rezultat vine din date și cât din cercetător? Replicarea nu este fără speranță: într-un model bayesian al replicării, majoritatea factorilor de evaluare a activelor se replică și funcționează în afara eșantionului în 93 de țări [Jensen, Kelly & Pedersen \(2023\)](#)
 - ▶ Asistenții AI fac aproape gratuită orice specificație în plus: specificațiile posibile se înmulțesc, dar și posibilitatea de a le raporta pe toate
 - ▶ Formularea formală: concluzia trebuie să reziste pe o mulțime preînregistrată S de specificații justificabile, cu familia corectată (FWER sau FDR); raportăm distribuția ei pe S , nu celula cea mai bună
- ▣ **Bucla:** întrebarea și H_0/H_1 (săptămâna 1); literatura și ținta de replicare văzută în PDF (săptămânile 1–2); preînregistrarea înregistrată printr-un commit datat în repository înaintea primului rezultat (săptămâna 2); replicarea ca test care trece în repository (săptămânile 2–3); întreaga grilă (săptămânile 4–5); un examinator AI înainte de susținere
 - ▶ „Iată rezultatele tuturor specificațiilor analizate. Ce concluzii rezistă corecției Holm și pe care le-ar numi un recenzent căutare oportunistă în date (data snooping)?”
- ▣ **Verificările cercetătorului:** cifra-țintă se află în articol; planul precede primul fișier de rezultate în istoricul commit-urilor; fiecare rulare este jurnalizată și numărată; o clonă nouă regenerează fiecare cifră; fiecare membru poate deduce formula-cheie fără AI
 - ▶ Prompturile pentru fiecare pas și testul pentru fiecare verificare: Anexă

Mini-caz: replicăm, apoi extindem

- ▣ **Replicăm:** VaR 1% FHS pentru BET; Capitolul 8 raportează 59 de depășiri în 4 937 de zile (1,20%, Kupiec $p = 0,181$)
 - ▶ Studiul de caz din acest capitol: 67 în 5 432 de zile (1,23%, $p = 0,095$); același model, alt început al evaluării (2007 față de 2005) și alte setări: documentăm orice diferență înainte de a declara o replicare eșuată
- ▣ O propunere tipică a asistentului, care citește fiecare valoare p separat la 5%: „doar GARCH-EVT este calibrat corect pe toate cele patru active”
- ▣ **Extindem:** cele 24 de teste de acoperire condiționată din Capitolul 8 (4 active $\times$ 6 modele) formează o familie
 - ▶ Respingeri la 5%: 12 fără corecție, 10 cu Holm (FWER), 11 cu BH (FDR 5%)
 - ▶ FHS eșuează doar pe S&P 500 ($p = 0,040$); în familia de 24 de teste rezistă, deci după Holm FHS și GARCH-EVT trec pe toate cele patru active
- ▣ Interpretare: „FHS eșuează pentru S&P 500” depinde de citirea testului separat sau în familia lui; preînregistrăm familia și le raportăm pe amândouă

Rândul vostru: planul final

- ▣ **Întrebarea:** ideea voastră din Partea C, scrisă ca H_0/H_1 , cu observația care ar infirma-o
- ▣ **Replicați întâi:** un tabel publicat, văzut în articol, transformat într-un test care trece în repository
 - ▶ Apoi extindeți pe o grilă preînregistrată, cu familia corectată și distribuția completă raportată
- ▣ **Livrabile** de-a lungul calendarului: propunerea și ținta de replicare, commit-ul de preînregistrare, testul de replicare care trece, grila de rezultate, susținerea de probă, raportul, susținerea orală
- ▣ **Jurnalul AI:** prompturile care au schimbat designul în `AI_USE.md`; fiecare eroare prinsă, cu testul care a prins-o, în `AI_ERRORS.md` ([șabloane](#))

Idei de reținut

- ▣ Randamentele sunt greu de prezis; riscul lor nu: volatilitatea, cozile și dependența pot fi prognozate
- ▣ Orice model este judecat în afara eșantionului, față de un reper simplu, cu o funcție de pierdere potrivită țintei
- ▣ Cozile groase schimbă inferența: folosiți erori robuste și bootstrap, raportați intervale, precizați puterea
- ▣ Cele mai multe rezultate greșite vin din design, nu din model: look-ahead bias, overfitting, testare multiplă, calendare
- ▣ Drumul de analiză este el însuși o sursă de incertitudine: preînregistrați, replicați, raportați toată grila
- ▣ Instrumentele noi (ML, modele fundamentale, LLM-uri) ridică exigența evaluării, nu o scad

Verificați-vă și studiu suplimentar

Întrebări de verificare

- De ce kurtosis-ul de selecție al randamentelor BET nu estimează nimic?
- De ce nu poate fi raportat intervalul Wald pentru persistența GARCH și ce îl înlocuiește?
- Ce vă spune o nerespingere a testului Kupiec la $T = 250$?
- De ce IQR-ul unui multivers cu 27 de specificații nu este eroarea nestandard a 164 de echipe?

Studiu suplimentar

- Manuale: Franke, Härdle & Hafner (2019); Härdle, Chen & Overbeck (2017); McNeil, Frey & Embrechts (2015); Tsay (2010)
- Cursuri avansate pe quantinar.com:  Statistics of Financial Markets;  Measuring Statistical Risk
- Cod și date:
github.com/danpele/MFM/tree/main/Quantlets/Ch_19

Anexă: Inferența cheie pe capitole (1/7)

- **Capitolul 0:** Calitatea datelor este o decizie de modelare: sursa, ajustarea și calendarul schimbă rezultatul
 - ▶ Pentru randamente log i.i.d., anualizate cu numărul de perioade pe an: $se(\hat{\mu}_{\text{ann}}) = \sigma_{\text{ann}}/\sqrt{Y}$ pentru Y ani, indiferent de frecvență; $se(\hat{\sigma}) \approx \sigma\sqrt{(K-1)/(4T)}$ pentru T zile, K fiind kurtosis-ul populației (cere moment de ordinul patru finit); dependența în timp cere dispersii de termen lung
 - ▶ SPY 2015–2026: $se(\hat{\mu}_{\text{ann}}) \approx 5,1\%$ pentru o medie de 13,7%: mediile abia pot fi estimate, volatilitățile da
- **Capitolul 1:** Cozi groase și grupări de volatilitate pe toate piețele [Cont \(2001\)](#)
 - ▶ Ljung–Box $Q(m) \sim \chi_m^2$ cere randamente i.i.d.; cu grupări de volatilitate respinge prea des: folosiți Q^* robust, cu termenii $T\hat{\rho}_k^2/\hat{\tau}_k$ [Lobato, Nankervis & Savin \(2001\)](#)
 - ▶ Cozile: Hill $\hat{\alpha}$ cu $se \approx \hat{\alpha}/\sqrt{k}$ [Hill \(1975\)](#); dacă $\alpha < 4$, kurtosis-ul de selecție nu este consistent, iar bootstrap-ul lui eșuează [Athreya \(1987\)](#)
- **Capitolul 2:** Eficiența variază în timp (piețe adaptive); testele cer inferență robustă
 - ▶ Raportul varianțelor robust la heteroscedasticitate $z^*(q) \Rightarrow N(0, 1)$ sub ipoteza de diferență de martingală [Lo & MacKinlay \(1988\)](#)
 - ▶ Mai multe orizonturi q deodată: testul comun $\max_q |z^*(q)|$ cu valori critice de modul maxim studentizat [Chow & Denning \(1993\)](#); ferestrele mobile cer și ele o corecție pentru testele multiple

Anexă: Inferența cheie pe capitole (2/7)

Capitolul 3: Sutele de factori publicați cer praguri mai înalte [Harvey, Liu & Zhu \(2016\)](#)

- $GRS = \frac{T-N-K}{N} \frac{\hat{\alpha}^\top \hat{\Sigma}^{-1} \hat{\alpha}}{\mathbf{1} + \hat{\mu}_f^\top \hat{\Omega}^{-1} \hat{\mu}_f} \sim F(N, T - N - K)$ doar pentru erori i.i.d. Normale [Gibbons, Ross & Shanken \(1989\)](#); N active, K factori; $\hat{\Sigma}$, $\hat{\Omega}$: covarianțele reziduurilor și factorilor, împărțitor T
- Erorile standard Fama–MacBeth ignoră faptul că beta sunt estimate: cu $c = \hat{\gamma}^\top \hat{\Sigma}_f^{-1} \hat{\gamma}$, covarianța Shanken este $(1 + c)(\hat{V}_{FM} - \hat{\Sigma}_f/T) + \hat{\Sigma}_f/T$ pentru încărcări factoriale estimate [Shanken \(1992\)](#)

Capitolul 4: Shrinkage-ul, restricțiile și regulile bazate pe risc stabilizează ponderile; $1/N$ este un reper greu de bătut [DeMiguel, Garlappi & Uppal \(2009\)](#)

- $se(\widehat{SR}) \approx \sqrt{(1 + \widehat{SR}^2/2)/T}$ pentru randamente i.i.d. Normale, pe perioadă [Lo \(2002\)](#); autocorelația schimbă factorul de anualizare
- Este portofoliul A mai bun decât $1/N$? Testăm $SR_A - SR_B = 0$ cu inferență HAC sau bootstrap studentizat [Ledoit & Wolf \(2008\)](#), nu prin compararea a două estimări punctuale

Capitolul 5: Persistență aproape de 1; asimetrie la acțiuni; inovații cu cozi groase

- QMLE: $\sqrt{T}(\hat{\theta} - \theta) \Rightarrow N(0, A^{-1}BA^{-1})$ (sandviș); erorile standard doar din hessiană sunt greșite pentru inovații non-Normale [Bollerslev & Wooldridge \(1992\)](#)
- Aproape de $\alpha + \beta = 1$, parametrul este lângă frontiera regiunii de staționaritate în covarianță: intervalele Wald nu sunt fiabile; folosiți verosimilitatea profil sau bootstrap restrâns la spațiul parametrilor [Andrews \(1999\)](#)

Anexă: Inferența cheie pe capitole (3/7)

- **Capitolul 6:** Copulele separă distribuțiile marginale de dependență; dependența în cozi determină pierderile comune
 - ▶ DCC se estimează în doi pași: erorile standard din pasul al doilea trebuie să țină cont de volatilitățile din primul pas [Engle \(2002\)](#)
 - ▶ Corelația în criză față de perioada calmă: ρ crește mecanic odată cu volatilitatea; testăm pe $\rho^* = \rho / \sqrt{1 + \delta(1 - \rho^2)}$, δ creșterea relativă a varianței [Forbes & Rigobon \(2002\)](#)
- **Capitolul 7:** Simularea istorică filtrată și EVT condiționată reacționează la volatilitate în câteva zile [McNeil & Frey \(2000\)](#)
 - ▶ VaR istoric, randamente i.i.d. cu densitate continuă $f(q_\alpha) > 0$: $\sqrt{T}(\hat{q}_\alpha - q_\alpha) \Rightarrow N(0, \alpha(1 - \alpha)/f(q_\alpha)^2)$; în coadă f este mică, deci estimarea este zgomotoasă; la dependență, $\alpha(1 - \alpha)$ devine dispersia de termen lung a indicatorilor $\mathbb{1}_{\{r_t \leq q_\alpha\}}$
 - ▶ ES face media celor mai mari αT pierderi: cu αT de câteva zeci și un indice de coadă în jur de 3, dispersia lui este dominată de una sau două zile
- **Capitolul 8:** Ierarhizăm prognozele (VaR, ES) cu un scor consistent (FZ0) și teste Diebold–Mariano [Fissler & Ziegel \(2016\)](#)
 - ▶ Kupiec $LR_{uc} \sim \chi_1^2$, Christoffersen $LR_{ind} \sim \chi_1^2$; testul DQ regresează $I_t - \alpha$ pe indicatorii depășirilor anterioare și VaR_t , $DQ \sim \chi_k^2$ [Engle & Manganelli \(2004\)](#)
 - ▶ Puterea este mică: la $T = 250$, testul Kupiec de 5% detectează o rată reală de 2% doar în 24% din cazuri; comparăm modelele cu teste de capacitate predictivă condiționată [Giacomini & White \(2006\)](#)

Anexă: Inferența cheie pe capitole (4/7)

- **Capitolul 9:** Randamentele împărțite la volatilitatea realizată au o distribuție apropiată de distribuția Normală
 - ▶ Erorile HAR sunt heteroscedastice și, pentru ținte pe mai multe zile care se suprapun, autocorelate: folosiți erori standard HAC; prognozele se compară cu teste DM pe o funcție de pierdere robustă [Patton \(2011\)](#)
 - ▶ Zgomotul de microstructură deplasează în sus RV la frecvențe înalte: estimatorii pe două scale elimină deplasarea [Zhang, Mykland & Aït-Sahalia \(2005\)](#)
- **Capitolul 10:** Lichiditatea variază în funcție de ora din zi și de VIX și dispare în perioadele de stres
 - ▶ Spread-ul Roll cere $\text{Cov}(\Delta p_t, \Delta p_{t-1}) < 0$; când covarianța de selecție este pozitivă, estimatorul nu este definit, deci raportați cât de des
 - ▶ O primă de ilichiditate este o afirmație privind secțiunea transversală: Fama–MacBeth cu erori Newey–West și corecția Shanken [Shanken \(1992\)](#)
- **Capitolul 11:** Salturile explică cozile, volatilitatea stochastică explică grupările
 - ▶ Normalitatea randamentelor log GBM: Jarque–Bera $\sim \chi^2_2$ respinge peste tot; salturile se testează cu variația bipower, $(RV - BV)$ standardizat $\Rightarrow N(0, 1)$ [Barndorff-Nielsen & Shephard \(2006\)](#)
 - ▶ Testul este zilnic: pe multe zile, controlați numărul zilelor cu salturi false

Anexă: Inferența cheie pe capitole (5/7)

- **Capitolul 12:** Smile-ul și skew-ul volatilității reflectă teama de prăbușiri
 - ▶ VRP_t folosește varianța realizată din următoarele 21 de zile: valorile consecutive se suprapun, deci media cere erori Newey–West cu cel puțin 21 de întârzieri
 - ▶ Volatilitatea implicită este o prognoză neutră la risc: prima, nu eroarea de prognoză, explică cea mai mare parte a diferenței
- **Capitolul 13:** Purged cross-validation, meta-labelling și raportul Sharpe deflatat [Bailey & López de Prado \(2014\)](#)
 - ▶ Selecția dintre N strategii: raportul Sharpe deflatat testează $SR > E[\max_N \widehat{SR}]$ sub ipoteza absenței abilității [Bailey & López de Prado \(2014\)](#)
 - ▶ Validarea încrucișată pe serii de timp trebuie să elimine din antrenare observațiile ale căror etichete se suprapun cu setul de test (purging) și să lase o pauză după acesta (embargo), altfel acuratețea este supraestimată
- **Capitolul 14:** Le evaluăm cu instrumentele din Capitolul 8, după publicarea ponderilor
 - ▶ Testul DM pe diferențele QLIKE, cu dispersie HAC: $t_{DM} \Rightarrow N(0, 1)$ pentru comparații între modele neimbricate [Diebold & Mariano \(1995\)](#)
 - ▶ Cu multe modele candidate, mulțimea de încredere a modelelor (MCS) controlează eroarea la nivel de familie [Hansen, Lunde & Nason \(2011\)](#)

Anexă: Inferența cheie pe capitole (6/7)

- **Capitolul 15:** Reprezentările vectoriale ale textului intră în modele ca variabile explicative
 - ▶ Regresia predictivă $r_{t+1} = a + bS_t + \varepsilon_{t+1}$: un S_t persistent, cu inovații corelate cu randamentele, introduce un bias în $\hat{b}$ și distorsionează testul t [Stambaugh \(1999\)](#)
 - ▶ Rezultatele clasificatorilor pe aceleași texte sunt pereche: comparăm acuratețile cu testul McNemar exact, nu prin două intervale separate
- **Capitolul 16:** Stablecoin-urile, automated market makers și ETF-urile spot leagă crypto de finanțele tradiționale
 - ▶ Modele factoriale crypto: GRS și Fama–MacBeth cu corecția Shanken [Gibbons, Ross & Shanken \(1989\)](#), [Shanken \(1992\)](#); cozile groase cer versiuni HAC sau bootstrap
 - ▶ Cozile: indici Hill cu intervale, nu kurtosis de selecție (Capitolul 1); o ruptură într-o corelație se testează cu dată necunoscută [Andrews \(1993\)](#)

Anexă: Inferența cheie pe capitole (7/7)

- **Capitolul 17:** Testele de rădăcină unitară pe coada din dreapta datează începutul și sfârșitul episoadelor explozive
 - ▶ Sub ipoteza rădăcinii unitare, SADF și GSADF converg către funcționale ale mișcării browniene; valorile critice depind doar de fereastra minimă r_0 [Phillips, Shi & Yu \(2015\)](#)
 - ▶ Schimbările de volatilitate distorsionează nivelul testului: folosiți valori critice obținute prin wild bootstrap; controlați multiplicitatea datării
- **Capitolul 18:** CoVaR (VaR-ul sistemului condiționat de dificultățile unei instituții), SRISK și rețelele de contagiune măsoară contribuția fiecărei instituții
 - ▶ Diferențele de ΔCoVaR dintre bănci: teste pe perechi pe extrageri bootstrap comune pe blocuri, cu corecția Holm; la $\alpha = 1\%$ doar aproximativ 40 de zile în coadă, deci probleme de cuantile extreme
 - ▶ SRISK: LRMES simulat din GJR–GARCH + DCC [Brownlees & Engle \(2017\)](#); tabelele de conectivitate cer intervale bootstrap și modele VAR (vector autoregresive) cu shrinkage

Anexă: idei de proiect, Partea C a fiecărui seminar (1/2)

Cap.	Întrebarea deschisă (link către seminar)
0	Au schimbat ETF-urile spot corelația Bitcoin cu acțiunile?
1	A scăzut autocorelația BET-TR după reclasificarea FTSE?
2	A devenit BVB mai eficientă după reclasificarea FTSE din 2020?
3	Există prime factoriale la Bursa de Valori București?
4	Un portofoliu optim de blue chips BVB în RON
5	Este volatilitatea pieței românești determinată de SUA?
6	Au devenit acțiunile din România și din zona euro mai integrate după 2020?
7	Capitalul pentru un portofoliu BVB vs un portofoliu S&P 500

- ☐ Fiecare seminar oferă datele, o metodă de pornire și o analiză de referință discutată la seminar

Anexă: idei de proiect, Partea C a fiecărui seminar (2/2)

Cap.	Întrebarea deschisă (link către seminar)
8	Ce model de risc ați certifica pentru portofoliul de tranzacționare al unei bănci românești?
9	Este volatilitatea Bitcoin mai previzibilă decât cea a S&P 500?
10	Există o primă de ilichiditate pe BVB?
11	Ce model în timp continuu se potrivește pentru BET și Bitcoin?
12	Este prima de risc a varianței un semnal tranzacționabil?
13	Bate un model fundațional boosting-ul?
14	Poate un model fundațional zero-shot să înlocuiască GARCH pentru BET?
15	Aduce sentimentul titlurilor câștig după costuri?
16	Este Bitcoin un activ alternativ, un activ de risc sau un hedge?
17	Există o bulă AI?
18	Cât de expuse sunt băncile românești la stresul bancar din zona euro?

- Capitolul 20 (volatilitate realizată cu semnături, datele VOLARE) se potrivește și pentru un proiect de prognoză

Anexă: cum transformăm o idee într-un proiect

- Replicați mai întâi: un tabel sau o figură publicată dintr-un articol din spatele ideii (pasul 1)
- Restrângeți-o: o piață, o perioadă, un număr de prognozat sau de testat
 - ▶ Exemplu: Seminarul 8 devine „Care dintre HS, FHS și GARCH-EVT dă un VaR 1% corect pentru un portofoliu 50/50 format din BET și EUR (cursul EUR/RON) în 2015–2026?”
- Extindeți-o: o a doua piață, un model nou, un eșantion mai lung sau mai recent
 - ▶ Exemplu: adăugați un model fundațional (Capitolul 14) ca filtru de volatilitate în FHS
- Păstrați analiza de referință ca reper și încercați să o îmbunătățiți în mod onest

Anexă: convențiile de date pentru proiect

- Folosiți datele cursului unde se poate: serii zilnice pentru indici, ETF-uri, acțiuni BVB, crypto și cursuri de schimb, plus date intraday
 - ▶ Surse publice: cursurile de referință BNR, FRED, Kenneth French Data Library, DefiLlama; arhiva BVB pentru indicii românești
- Aplicați convențiile cursului
 - ▶ Prețuri ajustate pentru ETF-uri și acțiuni, valori de închidere pentru indici, cursuri de schimb și crypto
 - ▶ Eliminați zilele de sărbătoare în care furnizorul a repetat prețul anterior și cotațiile de weekend când piața este închisă; anualizați cu frecvența reală
 - ▶ Mai multe active: aliniați întâi prețurile pe zilele comune, apoi calculați randamentele
- Căutați valorile eronate înainte de modelare: salturile de $\pm 50\%$ în prețurile ajustate sunt de obicei erori de date

Anexă: lista de verificare pentru o evaluare onestă

Înainte să vă uitați la rezultate

- ☐ Scrieți ipoteza, reperul și funcția de pierdere
- ☐ Fixați fereastra de estimare și perioada de test
- ☐ Decideți câte modele și parametri veți încerca și corecția pentru ei
- ☐ Scrieți strategia de identificare și puterea testului principal

Când raportați

- ☐ Doar rezultate în afara eșantionului pentru afirmații despre prognoză
- ☐ Fiecare rezultat principal însoțit de eroare standard, CI sau valoare p
- ☐ Costuri pentru strategiile de tranzacționare; subperioade și o a doua piață pentru robustețe
- ☐ Ce **nu** a funcționat și de ce

Anexă: unde pierd de obicei puncte proiectele

- ▣ O întrebare care se schimbă după ce se cunosc rezultatele
- ▣ Ajustarea în eșantion prezentată drept putere de prognoză
- ▣ Niciun reper sau un reper slab, ales ca să fie bătut
- ▣ Cifre fără incertitudine; multe teste fără corecție
- ▣ Grafice fără unități, legende peste date, acronime neexplicate
- ▣ Cod care nu rulează sau cifre din raport pe care codul nu le produce
- ▣ Rezultate AI păstrate fără verificare: utilizare nedeclarată, cod neverificat, referințe care nu există

Anexă: erori nestandard, date și metodă

- **Date:** toate tranzacțiile cu contractele futures pe indicele Euro Stoxx 50, 2002–2018, 720 de milioane de înregistrări, pentru fiecare parte a tranzacției se indică dacă aceasta operează pentru un client sau în cont propriu (Sec. I.A)
 - ▶ Șase ipoteze, fiecare „nicio tendință anuală” pentru: eficiența pieței, spread-ul bid–ask realizat, ponderea clienților în volum, spread-ul realizat pe ordinele clienților, ponderea ordinelor la piață în ordinele clienților, venitul brut din tranzacționare al clienților
 - ▶ Fiecare echipă își alege propria măsură și raportează variația anuală medie în %, cu eroarea ei standard (SE)
- **Patru etape** în 2021: analiza independentă (articol și cod); feedback de la doi evaluatori; distribuirea celor mai bune cinci lucrări; estimările finale, fără obligația de a furniza codul care le reproduce (Sec. I.A)
 - ▶ Un plan de analiză a fost înregistrat public înainte de începerea experimentului (Sec. I.A)
- **Calitatea:** calitatea echipei (prima componentă principală a cinci indicatori), scorul de reproductibilitate 0–100 acordat de agenția de certificare Cascad, nota acordată de evaluatori, din care s-a scăzut media (Sec. I.B)
 - ▶ Regresii cuantile ale estimărilor la percentilele 10, 25, 50, 75 și 90; un IQR care scade înseamnă o dispersie mai mică (Sec. I.C)
- **Inferența:** fiecare estimare este testată față de estimarea mediană, cu corecție Bonferroni la un nivel de semnificație de 0,5% pentru familia de teste (Sec. I.C)
 - ▶ Analiza multivers: echipele raportează opțiunile metodologice din Tabelul V; statistica Anderson–Darling pentru k eșantioane ierarhizează deciziile după diferențele dintre distribuțiile estimărilor (Sec. II.C)

Anexă: Erori nestandard, detaliile replicării

- **Deciziile metodologice (bifurcațiile) din Tabelul V:** valorile extreme (nimic; măsura anuală winsorizată sau cu valorile din afara centilelor 2,5 și 97,5 eliminate), măsura (raportul varianțelor zi la săptămână, raportul varianțelor zi la lună, R^2 al unui model AR), modelul (tendință liniară, diferență logaritmică, diferență relativă)
 - ▶ Datele zilnice permit comparațiile zi-săptămână și zi-lună ($VR(5)$, $VR(21)$); frecvențele intrazilnice ale măsurii din Tabelul V necesită date intrazilnice
- **De ce explodează diferențele relative:** $m_t = |VR - 1|$ sau R^2 este aproape de zero în unii ani; articolul găsește aceeași explozie, o mediană de $-23\,000\%$ pe date zilnice (Fig. 7)
 - ▶ Fără tendință, m_t staționar: panta liniară și variația logaritmică medie sunt centrate în zero, dar pentru m_t independente, $\mathbb{E}(m_t/m_{t-1}) = \mathbb{E}m \cdot \mathbb{E}(1/m) \geq 1$ (Jensen), deci variația relativă medie este pozitivă
- **Statistica Anderson-Darling:** statistica standardizată este centrată în zero pentru distribuții egale ale unor eșantioane independente; cele 27 de estimări sunt puternic corelate, deci valorile critice tabelate și valorile p nu se aplică
 - ▶ Articolul, 164 de echipe: 6,7 pp față de 3,4 pp (Tabelul I, Panoul C); în mini-multivers, IQR-ul depășește acest reper pentru BET, nu și pentru Euro Stoxx 50

Anexă: bucla descoperirii, prompturi (1/2)

- **Săptămâna 1, întrebarea:** transformăm o idee în H_0/H_1 , cu o țintă de replicare
 - ▶ „Iată ideea noastră din Partea C a Seminarului N. Dă trei versiuni mai precise și testabile, tabelul publicat pe care l-ar replica fiecare și seriile din datele cursului de care are nevoie.”
- **Săptămânile 1–2, literatura și ținta:** cifra de replicat este una pe care ați văzut-o în PDF
 - ▶ „Listează cele mai citate și cele mai recente articole despre această întrebare, cu DOI; pentru fiecare, estimarea principală, tabelul și eșantionul.”
 - ▶ Verificați fiecare DOI pe [Crossref](#); căutați cu Semantic Scholar, Elicit sau Google Scholar; deschideți voi tabelul
- **Săptămâna 2, ipoteze și preînregistrare,** înregistrate printr-un commit datat înaintea primului rezultat
 - ▶ „Pentru H_0 și H_1 , listează ipotezele concurente și implicația care le separă; apoi scrie o preînregistrare: eșantion, filtre, ferestre, teste, corecție.”
 - ▶ Istoricul commit-urilor documentează înregistrarea planului înaintea rezultatelor

Anexă: bucla descoperirii, prompturi (2/2)

- **Săptămânile 2–3, cod și replicare:** tabelul replicat devine un test în repository
 - ▶ „Scrie o funcție care reproduce fiecare celulă a tabelului publicat din datele cursului și o aserțiune cu toleranța pe care o acceptăm.”
- **Săptămânile 4–5, extindere și robustețe:** rulăm toată grila preînregistrată
 - ▶ „Iată rezultatele tuturor specificațiilor analizate. Ce concluzii rezistă corecției Holm și pe care le-ar numi un recenzent căutare oportunistă în date (data snooping)?”
- **Înainte de susținere, critica:** asistentul întreabă, echipa răspunde
 - ▶ „Joacă rolul examinatorului la susținerea orală: pune cele mai dificile zece întrebări despre identificare, inferență și date. Nu răspunde la ele.”
 - ▶ Echipa răspunde fără AI, ca la susținerea propriu-zisă
- **Raportul:** distribuția rezultatelor pe grilă, nu celula cea mai bună; prompturile în AI_USE.md, erorile prinse în AI_ERRORS.md

Anexă: ce verifică cercetătorul

- **Ținta de replicare există:** cifra, tabelul și eșantionul luate din articol, nu din rezumatul asistentului
 - ▶ Test: raportul citează pagina și tabelul; un al doilea membru găsește acolo aceeași cifră
- **Planul a fost primul**
 - ▶ Test: în istoricul commit-urilor, preînregistrarea precede primul fișier de rezultate
- **Drumuri ramificate:** mai multe specificații încercate decât raportate
 - ▶ Test: fiecare rulare își scrie configurația și rezultatul într-un jurnal; raportul le dă numărul și corectează familia
- **Reproductibilitatea:** cifre scrise direct în raport
 - ▶ Test: o clonă nouă și o singură comandă regenerează fiecare cifră până la ultima zecimală raportată
- **Înțelegerea:** fiecare membru poate deduce formula-cheie și poate apăra fiecare alegere
 - ▶ Test: o susținere de probă în echipă, fără AI, cu o săptămână înaintea celei reale

Bibliografie (1/5)

- ▣ Abadie, A., Diamond, A., Hainmueller, J. (2010). Synthetic control methods for comparative case studies: estimating the effect of California's tobacco control program. *Journal of the American Statistical Association*, 105(490), 493–505.
- ▣ Andrews, D.W.K. (1993). Tests for parameter instability and structural change with unknown change point. *Econometrica*, 61(4), 821–856.
- ▣ Andrews, D.W.K. (1999). Estimation when a parameter is on a boundary. *Econometrica*, 67(6), 1341–1383.
- ▣ Athreya, K.B. (1987). Bootstrap of the mean in the infinite variance case. *Annals of Statistics*, 15(2), 724–731.
- ▣ Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- ▣ Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Barndorff-Nielsen, O.E., Shephard, N. (2006). Econometrics of testing for jumps in financial economics using bipower variation. *Journal of Financial Econometrics*, 4(1), 1–30.
- ▣ Black, F., Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 637–654.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- ▣ Brownlees, C., Engle, R.F. (2017). SRISK: a conditional capital shortfall measure of systemic risk. *Review of Financial Studies*, 30(1), 48–79.
- ▣ Chow, K.V., Denning, K.C. (1993). A simple multiple variance ratio test. *Journal of Econometrics*, 58(3), 385–401.

Bibliografie (2/5)

- ▣ Christoffersen, P.F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- ▣ Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification: how inefficient is the $1/N$ portfolio strategy?. *Review of Financial Studies*, 22(5), 1915–1953.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R. (2002). Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- ▣ Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- ▣ Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- ▣ Fama, E.F. (1970). Efficient capital markets: a review of theory and empirical work. *Journal of Finance*, 25(2), 383–417.
- ▣ Fissler, T., Ziegel, J.F. (2016). Higher order elicibility and Osband's principle. *Annals of Statistics*, 44(4), 1680–1707.
- ▣ Forbes, K.J., Rigobon, R. (2002). No contagion, only interdependence: measuring stock market comovements. *Journal of Finance*, 57(5), 2223–2261.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.

Bibliografie (3/5)

- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Gibbons, M.R., Ross, S.A., Shanken, J. (1989). A test of the efficiency of a given portfolio. *Econometrica*, 57(5), 1121–1152.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). *Applied Quantitative Finance*, 3rd ed. Springer.
- ▣ Harvey, C.R. (2017). Presidential address: the scientific outlook in financial economics. *Journal of Finance*, 72(4), 1399–1440.
- ▣ Harvey, C.R., Liu, Y. (2020). False (and missed) discoveries in financial economics. *Journal of Finance*, 75(5), 2503–2553.
- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- ▣ Hill, B.M. (1975). A simple general approach to inference about the tail of a distribution. *Annals of Statistics*, 3(5), 1163–1174.
- ▣ Hou, K., Xue, C., Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133.
- ▣ Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance?. *Journal of Finance*, 78(5), 2465–2518.
- ▣ Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- ▣ Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.

Bibliografie (4/5)

- ▣ Lo, A.W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.
- ▣ Lo, A.W., MacKinlay, A.C. (1988). Stock market prices do not follow random walks: evidence from a simple specification test. *Review of Financial Studies*, 1(1), 41–66.
- ▣ Lobato, I., Nankervis, J.C., Savin, N.E. (2001). Testing for autocorrelation using a modified Box–Pierce Q test. *International Economic Review*, 42(1), 187–205.
- ▣ López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- ▣ Markowitz, H. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- ▣ McNeil, A.J., Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- ▣ McNeil, A.J., Frey, R., Embrechts, P. (2015). *Quantitative Risk Management: Concepts, Techniques and Tools*, revised ed. Princeton University Press.
- ▣ Menkveld, A.J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). Nonstandard errors. *Journal of Finance*, 79(3), 2339–2390.
- ▣ Nolde, N., Ziegel, J.F. (2017). Elicitability and backtesting: perspectives for banking regulation. *Annals of Applied Statistics*, 11(4), 1833–1874.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.

Bibliografie (5/5)

- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiaty, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *European Journal of Finance*, 29(10), 1064–1105.
- ▣ Phillips, P.C.B., Shi, S., Yu, J. (2015). Testing for multiple bubbles: historical episodes of exuberance and collapse in the S&P 500. *International Economic Review*, 56(4), 1043–1078.
- ▣ Shanken, J. (1992). On the estimation of beta-pricing models. *Review of Financial Studies*, 5(1), 1–33.
- ▣ Simonsohn, U., Simmons, J.P., Nelson, L.D. (2020). Specification curve analysis. *Nature Human Behaviour*, 4(11), 1208–1214.
- ▣ Stambaugh, R.F. (1999). Predictive regressions. *Journal of Financial Economics*, 54(3), 375–421.
- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed. Wiley.
- ▣ White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126.
- ▣ Zhang, L., Mykland, P.A., Aït-Sahalia, Y. (2005). A tale of two time scales: determining integrated volatility with noisy high-frequency data. *Journal of the American Statistical Association*, 100(472), 1394–1411.