



## Modelarea piețelor financiare

### Capitolul 19: Recapitulare și prezentarea proiectelor



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

## Acronime folosite în acest material (1/3)

- ▣ ADF: Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ ASE: Academia de Studii Economice din București
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BET-TR: BET Total Return (index) (indicele BET cu dividendele reinvestite)
- ▣ BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- ▣ BNR: Banca Națională a României
- ▣ BVB: Bursa de Valori București
- ▣ CAPM: Capital Asset Pricing Model (modelul de evaluare a activelor financiare)
- ▣ CI: Confidence Interval (interval de încredere)
- ▣ COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- ▣ CV: Cross-Validation (validare încrucișată)
- ▣ DCC: Dynamic Conditional Correlation (corelație condiționată dinamică)
- ▣ DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ▣ DQ: Dynamic Quantile (test) (testul cuantilei dinamice)
- ▣ ES: Expected Shortfall (pierderea așteptată în coadă)
- ▣ ETF: Exchange-Traded Fund (fond tranzacționat la bursă)
- ▣ EVT: Extreme Value Theory (teoria valorilor extreme)
- ▣ FDR: False Discovery Rate (rata descoperirilor false)
- ▣ FHS: Filtered Historical Simulation (simulare istorică filtrată)
- ▣ FRED: Federal Reserve Economic Data (baza de date economice a Rezervei Federale (St. Louis))
- ▣ FTSE: Financial Times Stock Exchange (FTSE Russell, index provider) (furnizorul de indici FTSE Russell)
- ▣ FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- ▣ FZ0: Fissler–Ziegel loss, zero-homogeneous version (funcția de pierdere Fissler–Ziegel, varianta omogenă de grad zero)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)

## Acronime folosite în acest material (2/3)

- GARCH-EVT: GARCH filter combined with Extreme Value Theory for the tail (filtru GARCH combinat cu teoria valorilor extreme pentru coadă)
- GBM: Geometric Brownian Motion (mișcarea browniană geometrică)
- GJR: Glosten–Jagannathan–Runkle (asymmetric GARCH) (GARCH asimetric Glosten–Jagannathan–Runkle)
- GRS: Gibbons–Ross–Shanken (test) (testul Gibbons–Ross–Shanken)
- GSADF: Generalised Sup Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat suprem generalizat)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- HS: Historical Simulation (simulare istorică)
- IGARCH: Integrated GARCH (GARCH integrat)
- IQR: InterQuartile Range (intervalul intercuartilic)
- LLM: Large Language Model (model lingvistic mare)
- LRMEs: Long-Run Marginal Expected Shortfall (pierdere marginală așteptată în coadă pe termen lung (într-o criză))
- LSTM: Long Short-Term Memory (network) (rețea cu memorie pe termen lung și scurt)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- MDE: Minimum Detectable Effect (efectul minim detectabil)
- ML: Machine Learning (învățare automată)
- MSE: Mean Squared Error (eroarea pătratică medie)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- QMLE: Quasi-Maximum Likelihood Estimator (estimatorul de cvasi-verosimilitate maximă)
- SADF: Sup Augmented Dickey–Fuller (test) (testul Dickey–Fuller augmentat suprem)
- SE: Standard Error (eroare standard)
- SML: Security Market Line (dreapta pieței titlurilor)
- SRISK: Systemic RISK (capital shortfall measure) (deficitul de capital al unei bănci într-o criză sistemică)
- SUA: Statele Unite ale Americii
- VAR: Vector AutoRegression (model vector autoregresiv)
- VIX: CBOE Volatility IndeX (indicele de volatilitate CBOE)

## Acronime folosite în acest material (3/3)

- **VOLARE: VOLatility Archive for Realized Estimates (database)** (arhiva de estimatori realizați ai volatilității (bază de date))

## Traseul capitolului și rezultatele învățării

### Traseul capitolului

- Partea I: cursul într-o singură imagine, recapitularea **capitolelor 0–18**, șase capcane și un studiu de caz integrat, de la prețurile brute ale BET la un Value-at-Risk (VaR) de 1% validat prin backtesting
- Partea a II-a: proiectul de echipă, AI în proiect, un studiu de caz de cercetare despre erorile nestandard, o parcurgere a buclei de descoperire asistate de AI
- Detaliile tehnice se află în [▶ Anexa](#) de la final

### După acest capitol puteți


- duce o întrebare de la date la o prognoză de risc validată, cu inferență corectă
- recunoaște cele șase capcane în propriul cod
- scrie un plan de proiect cu replicare, identificare, putere și grilă de specificații



Academia de Studii Economice din București (ASE),  
Piața Romană

Foto: Joe Mabel (2014); CC BY 3.0; Wikimedia  
[Commons](#)

## Cursul într-o singură imagine



- Roșu: firul principal, de la faptele stilizate ([Capitolul 1](#): cozi groase, volatility clustering, aproape nicio predictibilitate liniară) la prognoze de risc verificabile ([Capitolele 5–8](#): GARCH dă  $\sigma_{t+1}$ , VaR și ES dau pierderea, backtesting-ul arată dacă prognoza este fiabilă)
- [Capitolele 9–12](#) îmbunătățesc măsurarea volatilității (date intraday, prețuri de opțiuni) și o modelează în timp continuu; [Capitolele 13–15](#) aduc modele flexibile, evaluate mereu cu instrumentele din [Capitolul 8](#)
- [Capitolele 16–18](#) aplică aceleași instrumente activelor crypto, bulelor și întregului sistem financiar; [Capitolul special 20](#): volatilitatea realizată cu semnăturile traiectoriilor, pe datele VOLARE

## Cinci întrebări pentru orice model

### Înainte de estimare

- **Date:** ce serie, ce calendar, ce ajustări (dividende, split-uri, sărbători)?
- **Model**
  - ▶ ce fapt stilizat surprinde?
  - ▶ ce ignoră?
- **Estimare:** pe ce fereastră, cu ce informație la momentul  $t$ ?

### După estimare

- **Evaluare:** în afara eșantionului, cu o funcție de pierdere potrivită țintei (QLIKE, FZ0) și cu testele de diagnostic potrivite (de exemplu Kupiec)?
- **Incertitudine:** erori standard robuste, bootstrap, test față de un reper simplu?
- Fără răspuns la fiecare întrebare, rezultatul nu constituie încă o concluzie

## Capitolele 0–2: piețe, randamente și eficiență

- ▣ **Capitolul 0, Piețele financiare în 2026:** Piețele combină burse, dealeri extrabursieri, fonduri tranzacționate la bursă (exchange-traded funds, ETF), algoritmi și blockchain-uri
  - ▶ 2015–2026: SPY (ETF pe S&P 500, cu dividende reinvestite) 13,7% pe an cu volatilitate 17,6%; Bitcoin 60,6% pe an cu 66,7%
  - ▶ BET, iulie 2007 – februarie 2009: un drawdown de –82,5%
- ▣ **Capitolul 1, Fapte stilizate și randamente:** Randamentele sînt necorelate, dar nu independente: mărimea lor este previzibilă, semnul aproape deloc
  - ▶ BET, indicele Hill al pierderilor (cele mai mari  $k = 153$  pierderi):  $\hat{\alpha} = 2,39$ , CI 95% prin bootstrap pe blocuri [2,12, 3,03] ( $\alpha$ : tail index, probabilitatea unei pierderi peste  $x$  scade ca  $x^{-\alpha}$ ): momentul de ordinul patru este probabil infinit
  - ▶ Zilele dincolo de  $5\sigma$  sînt de peste 1000 de ori mai frecvente decît implică distribuția Normală
- ▣ **Capitolul 2, Eficiența pieței:** Prețurile reflectă pe deplin informația disponibilă; un test al predictibilității randamentelor anormale este un test comun al eficienței și al modelului de randament așteptat [Fama \(1970\)](#)
  - ▶ Ponderea ferestrelor mobile în care mersul aleator este respins: S&P 500 6,4%, BET 22,4%, Bitcoin 0,0%
  - ▶ O respingere statistică nu înseamnă profit exploatabil



## Capitolele 3–5: evaluarea activelor, portofolii și GARCH

- ▣ **Capitolul 3, Modele factoriale și evaluarea activelor:** Randamentele așteptate ar trebui să remunereze doar expunerea la factori sistematici
  - ▶ 25 de portofolii după mărime și raportul valoare contabilă/de piață: panta SML (dreapta pieței de capital)  $-4,4\%$ , GRS (testul comun că toate constantele sînt zero)  $= 4,18$ : CAPM este respins
  - ▶ ETF-uri sectoriale: prima componentă principală (piața) explică  $66\%$  din varianță
- ▣ **Capitolul 4, Optimizarea portofoliului:** Markowitz formulează corect problema, dar eroarea de estimare domină soluția [Markowitz \(1952\)](#)
  - ▶ Eșantioane de 60 de luni: Sharpe median în eșantion  $1,57$ , Sharpe adevărat median  $0,30$
  - ▶  $96\%$  dintre portofoliile tangente estimate au de fapt performanțe inferioare portofoliului  $1/N$
- ▣ **Capitolul 5, Volatilitate condiționată: GARCH:** Din cauza volatility clustering-ului, șocul de azi anticipează varianța de mâine [Engle \(1982\)](#), [Bollerslev \(1986\)](#)
  - ▶ S&P 500, 2000–2026: persistența  $\alpha + \beta = 0,9947$  ( $\alpha, \beta$ : ponderile GARCH(1,1) ale ultimului șoc și ale ultimei varianțe), un timp de înjumătățire  $\ln 0,5 / \ln(\alpha + \beta)$  de  $131$  de zile
  - ▶ BET: CI  $95\%$  din verosimilitatea profil pentru  $\alpha + \beta$  este  $[0,975, 1]$  (IGARCH nu este respins): timpul de înjumătățire este de cel puțin  $27$  de zile, fără o limită superioară finită

## Capitolele 6–8: dependență, măsuri de risc și backtesting

- ▣ **Capitolul 6, Volatilitate multivariată și dependență:** Corelațiile se schimbă odată cu regimul macroeconomic; diversificarea nu este garantată
  - ▶ SPY–TLT (ETF pe obligațiuni americane pe termen lung):  $\rho$  de la  $-0,40$  la  $0,11$  după 2022, iar volatilitatea unui portofoliu 60/40 a crescut de la  $10,4\%$  la  $13,2\%$  volatilitate
  - ▶ Corelația DCC Bitcoin–SPY:  $0,04$  înainte de 2020,  $0,31$  de atunci
- ▣ **Capitolul 7, VaR și Expected Shortfall:** VaR este o cuantilă a pierderii, ES pierderea medie dincolo de ea; ES este coerent
  - ▶ S&P 500, zilnic:  $\text{VaR}_{1\%}$  istoric =  $3,45\%$ ,  $\text{ES}_{1\%} = 5,01\%$
  - ▶ VaR-ul bazat pe distribuția Normală este de doar  $2,80\%$ : cozile groase contează
- ▣ **Capitolul 8, Backtesting și evaluarea prognozelor de risc:** Testăm numărul și momentul depășirilor: acoperirea și independența [Kupiec \(1995\)](#), [Christoffersen \(1998\)](#)
  - ▶ S&P 500, VaR 1%, 2007–2026: depășiri Normal  $2,70\%$ , HS  $1,67\%$ , FHS  $1,23\%$ , GARCH-EVT  $1,13\%$
  - ▶ Un filtru GARCH combinat cu o coadă flexibilă dă cele mai bune rezultate pe toate cele patru piețe

## Capitolele 9–11: frecvență înaltă, lichiditate și timp continuu

- ▣ **Capitolul 9, Volatilitate realizată:** Prețurile intraday măsoară varianța zilnică ( $RV$ , Realised Variance, varianța realizată); modelul log-HAR (Heterogeneous AutoRegressive, autoregresiv heterogen) surprinde memoria ei lungă Corsi (2009)
  - ▶ SPY: kurtosis 15,73 pentru randamentele de la deschidere la închidere, 2,65 după împărțirea la  $\sqrt{RV_t}$
  - ▶ log-HAR reduce QLIKE față de GARCH(1,1)- $t$  cu 10% pentru SPY ( $p = 0,021$ ) și cu 22% pentru Bitcoin
- ▣ **Capitolul 10, Microstructura pieței:** Prețurile se formează în registre de ordine limită; spread-ul compensează costurile de procesare, riscul de inventar și selecția adversă
  - ▶ Raportul Amihud (puncte de bază, bp, la 1 milion USD): SPY 0,0016, Banca Transilvania 24,7, Transelectrica 1024,0
  - ▶ SPY: variația prețului în primele 5 minute este de 2,06 ori mai mare decât într-un interval de aceeași durată de la prînz
- ▣ **Capitolul 11, Modele în timp continuu:** Mișcarea browniană este limita măsurilor aleatoare; lema lui Itô permite rezolvarea ecuațiilor diferențiale stochastice ale prețurilor
  - ▶ S&P 500 față de mișcarea browniană geometrică: 62 de zile dincolo de  $\pm 4$  abateri standard, față de 0,59 așteptate
  - ▶ Tail index-ul Hill al pierderilor S&P 500: 2,87 [2,07, 3,67] (**Capitolul 16**): momentul de ordinul patru este probabil infinit, spre deosebire de randamentele log ale GBM, distribuite Normal

## Capitolele 12–14: opțiuni, machine learning și modele fundamentale

- ▣ **Capitolul 12, Opțiuni și suprafața de volatilitate:** Black–Scholes evaluează opțiunile prin hedging; volatilitatea implicită este estimarea pieței pentru  $\sigma$  [Black & Scholes \(1973\)](#)
  - ▶ 1990–2026: VIX mediu 19,4, volatilitatea realizată medie în luna următoare 15,3
  - ▶ Prima de risc a varianței este pozitivă în 86% din zile, dar nu și în perioadele de crah
- ▣ **Capitolul 13, Machine Learning în finanțe:** Modelele sînt flexibile, dar semnalul este slab și zgomotul mare; specificul finanțelor ține de procesul de validare [López de Prado \(2018\)](#)
  - ▶ Validarea K-fold cu amestecare raportează o acuratețe de 69,4% pe zgomot pur: leakage
  - ▶ S&P 500: seria diferențiată fracționar devine staționară la  $d^* = 0,25$ ; niciun model nu depășește regula naivă „piața crește mereu”
- ▣ **Capitolul 14, Deep learning și modele fundamentale pentru serii de timp:** LSTM-urile (Long Short-Term Memory, rețele cu memorie pe termen lung și scurt) și Transformerile învață din secvențe; modelele fundamentale prognozează zero-shot
  - ▶ Volatilitatea realizată SPY, QLIKE: Chronos-2 0,231, log-HAR 0,234, GARCH- $t$  0,283; primele două nu diferă semnificativ
  - ▶ VaR 1% Chronos-2 fără recalibrare pe S&P 500: 1,67% depășiri

## Capitolele 15–16: text și active digitale

- **Capitolul 15, LLM-uri și analiza sentimentului:** De la dicționare la FinBERT și la modelele lingvistice mari (Large Language Models, LLM): textul este transformat într-o variabilă numerică
  - ▶ Qwen 7B față de 1.5B pe titluri financiare: +21,5 puncte procentuale de acuratețe, McNemar  $p < 0,001$
  - ▶ O strategie pe sentimentul titlurilor: Sharpe +0,63 înainte și -1,48 după costuri; costul de tranzacționare care anulează câștigul: 1,5 bp pe tranzacție
- **Capitolul 16, Active digitale și DeFi:** Criptomonede formează o clasă de active distinctă în spațiul caracteristicilor din [Pele et al. \(2023\)](#), unde un factor legat de cozi le separă; tail index-urile lor Hill nu sînt semnificativ mai mici decît cei ai acțiunilor sau ai aurului ([Capitolul 16](#))
  - ▶ Legătura Bitcoin–S&P 500: sup-Wald 20,2 (cea mai mare statistică Wald de ruptură pe datele candidate; valoarea critică de 5% 11,6), ruptura estimată pe 9 mar. 2020, nu la lansarea ETF-urilor din 2024
  - ▶ Tail index-ul Hill al pierderilor: Bitcoin 2,73 [2,12, 3,33], S&P 500 2,87 [2,07, 3,67]: nu se pot distinge statistic

## Capitolele 17–18: bule și risc sistemic

- **Capitolul 17, Bule și crahuri:** O bulă este o traiectorie a prețului care crește mai repede decât o pot justifica fundamentele
  - ▶ Bitcoin 2014–2026 (săptămînal): GSADF (cea mai mare statistică de rădăcină unitară pe coada din dreapta, pe toate ferestrele) 3,85 față de valoarea critică de 95% 2,27: sînt detectate episoade explozive
  - ▶ Un regim față de două regimuri Markov pentru Bitcoin: statistica raportului de verosimilitate  $LR = 123,2$ , valoarea critică de 95% din bootstrap parametric 11,8 ( $p = 0,005$ )
- **Capitolul 18, Risc sistemic și rețele:** Riscul sistemic: pierderile unei instituții care se propagă în tot sistemul
  - ▶  $\Delta\text{CoVaR } 1\%$  (variația VaR 1% al sistemului cînd o bancă trece de la mediană la stres) pentru unsprezece bănci: 4 din 25 de perechi din aceeași regiune diferă la 5%, 0 după Holm; comparația prin simpla suprapunere a intervalelor nu ar fi ierarhizat nicio pereche
  - ▶ LRMES simulat (22 de zile, piața sub  $-10\%$ ): JPMorgan 10,6% în prezent, 23,7% cu informația din 31 martie 2020

## Capcane metodologice: look-ahead bias şi overfitting

- ▣ **Look-ahead bias** (informaţia din viitor): estimarea oricărui parametru, prag sau factor de scalare pe tot eşantionul introduce informaţie din viitor
  - ▶ Exemple: parametri GARCH din tot eşantionul, standardizare pe tot eşantionul, etichete care se suprapun cu setul de test; studiul de caz măsoară efectul pe BET
  - ▶ **Capitolul 13**: Validarea K-fold cu amestecare raportează o acurateţe de 69,4% pe zgomot pur
  - ▶ Remediu: ferestre mobile sau în extindere; purging şi embargo; scrieţi mulţimea de informaţie  $\mathcal{F}_{t-1}$  lângă fiecare prognoză
- ▣ **Overfitting-ul**: ajustarea în eşantion recompensează zgomotul, care nu se repetă în afara eşantionului
  - ▶ **Capitolul 4**: Sharpe în eşantion 1,57, Sharpe adevărat 0,30 pentru aceleaşi portofolii
  - ▶ Overfitting-ul backtest-ului: încercăm multe strategii şi o păstrăm pe cea mai bună [Bailey et al. \(2017\)](#); raportul Sharpe deflatat corectează pentru numărul de încercări şi pentru randamentele non-normale [Bailey & López de Prado \(2014\)](#)
  - ▶ Remediu: fixaţi planul analizei înainte de a vă uita la perioada de test; raportaţi toate modelele încercate; comparaţi cu un reper simplu (1/N, simulare istorică, mers aleator, log-HAR)

## Capcană metodologică: testarea multiplă

- ▣ **Capitolul 3:** din 300 de factori fără putere explicativă, în medie 15,0 trec de  $|t| > 1,96$ , iar cel mai bun ajunge la  $|t| \approx 3,06$ 
  - ▶ De aceea literatura despre factori cere  $|t| > 3$  [Harvey, Liu & Zhu \(2016\)](#)
- ▣ Anomalii de calendar, reguli de tranzacționare, specificații de model: fiecare test în plus adaugă o șansă de descoperire falsă
- ▣ Remediu: numărați testele și corecții
  - ▶ Bonferroni și Holm controlează probabilitatea oricărei descoperiri false (FWER); Benjamini–Hochberg controlează ponderea lor așteptată (FDR)
  - ▶ Pentru prognoze: mulțimea de încredere a modelelor (MCS) în locul multor teste pe perechi [Hansen, Lunde & Nason \(2011\)](#)



## Capcană de date: alinierea randamentelor în locul prețurilor

- Bitcoin se tranzacționează zilnic, SPY doar în zilele lucrătoare
  - ▶ Greșit: calculăm fiecare randament pe calendarul propriu, apoi păstrăm zilele comune: mișcările Bitcoin din weekend dispar
  - ▶ Corect: păstrăm zilele comune ale **prețurilor**, apoi calculăm randamentele: ziua de luni acoperă intervalul vineri–luni pentru ambele
- Bitcoin, 2020–2026, în zilele comune: randament cumulat 1025% (corect) față de 680% (greșit)
  - ▶ Abaterea standard a zilei de luni 5,04% (corect) față de 3,83% (greșit): alinierea greșită ascunde riscul din weekend
- Remediu: aliniați întîi prețurile pe zilele comune; o serie singură rămîne pe calendarul propriu

## Capcană de inferenţă: ignorarea cozilor groase

- ▣ Erorile standard clasice presupun independenţă şi momente de ordinul patru finite
  - ▶ Pierderile BET: tail index-ul Hill  $\hat{\alpha} = 2,39$ , CI 95% prin bootstrap pe blocuri [2,12, 3,03] Hill (1975);  $\alpha$ : probabilitatea unei pierderi peste  $x$  scade ca  $x^{-\alpha}$ , deci momentele de ordin  $\geq \alpha$  sînt infinite: cu  $\alpha < 4$ , kurtosis-ul populaţiei este infinit
  - ▶ Deci kurtosis-ul de selecţie (11,1) nu estimează nimic, iar un interval bootstrap pentru el nu este valid Athreya (1987): raportaţi tail index-ul
- ▣ Persistenţa GARCH pentru BET,  $p = \alpha + \beta$  (aici  $\alpha, \beta$ : parametrii GARCH(1,1)): CI Wald [0,974, 1,007] depăşeşte frontiera staţionarităţii  $p = 1$ , unde aproximarea asimptotică Normală nu mai este validă Andrews (1999)
  - ▶ CI din verosimilitatea profil (toate p-value-urile a căror statistică a raportului de verosimilitate, maximizată după ceilalţi parametri, este sub valoarea critică), în spaţiul parametrilor  $p \leq 1$ : [0,975, 1] (IGARCH,  $p = 1$ , nu este respins faţă de valoarea critică la frontieră 2,71, cuantila de 5% a unui amestec 50:50 între 0 şi  $\chi_1^2$ ), deci timpul de înjumătăţire este de cel puţin 27 de zile şi nu are o limită superioară finită
- ▣ Remediul: erori robuste (HAC), bootstrap pe blocuri acolo unde este valid, tail index-uri în loc de kurtosis, intervale care respectă frontiera

## Capcană de evaluare: o funcție de pierdere care nu poate ierarhiza ținta

- Prognosele de varianță se compară cu un proxy zgomotos ( $r_t^2$  sau  $RV_t$ )
  - ▶ Cu un proxy condiționat nedeplasat, MSE și QLIKE ierarhizează prognozele la fel ca varianța adevărată; QLIKE depinde doar de raportul proxy/prognost, deci zilele volatile cîntăresc mai puțin decît la MSE [Patton \(2011\)](#)
  - ▶ [Capitolul 9](#): log-HAR bate GARCH în QLIKE; comparația în MSE nu este concludentă
- ES singur nu are o funcție de scor strict consistentă pe clasele largi obișnuite de distribuții; perechea (VaR, ES) are, în condiții de regularitate slabe [Fissler & Ziegel \(2016\)](#)
  - ▶ Folosiți FZ0 cu teste Diebold–Mariano [Diebold & Mariano \(1995\)](#); precizia are limite în eşantioane finite [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)
- Remediu: alegeți funcția de pierdere înainte de comparație și precizați-o în raportul proiectului

## O întrebare, patru capitole

### Întrebarea

- Cît poate pierde mîine o poziție pe indicele BET, cu probabilitatea de 1%?
- Pe ce prognoză a acestei pierderi ne-am fi putut baza în timp real, în 2005–2026?

### Date

- Indicele BET, valori oficiale zilnice de închidere, 6 ian. 2000 – 18 sept. 2026: 6 670 de randamente log zilnice
- Au fost eliminate înregistrările duplicate (rînduri identice cu cel anterior) și rîndurile datate în weekend; zilele de tranzacționare cu închidere neschimbată se păstrează

### Cei cinci pași


- **Capitolul 1:** fapte stilizate, cu inferență robustă
- **Capitolul 5:** GARCH(1,1) cu inovații Student- $t$
- **Capitolul 7:** VaR 1% pentru o zi, din patru modele
- **Capitolul 8:** acoperire, independență și zonele Basel
- Compararea formală a celor patru modele: pierderea FZ0, teste DM, mulțimea de încredere a modelelor



Palatul Bursei, București (2023)

Foto: Chainwit. (2023); CC BY 4.0; Wikimedia Commons

## Pasul 1: faptele stilizate ale BET



- Cozi groase (stînga, cuantilele față de cele ale distribuției Normale): tail index-ul Hill al pierderilor  $\hat{\alpha} = 2,39$ , CI 95% prin bootstrap pe blocuri  $[2,12, 3,03]$ , din cele mai mari  $k = 153$  pierderi; sub 4, deci kurtosis-ul nu este raportat ca estimare
- 51 de zile dincolo de  $\pm 4$  abateri standard, față de 0,42 așteptate sub distribuția Normală; cea mai mare pierdere zilnică:  $-13,1\%$  (log) pe 7 ian. 2009
- Volatility clustering (dreapta): autocorelația de ordinul 1 a  $|r_t|$  0,40, cu scădere lentă; Ljung-Box  $Q(10)$  (testul comun al primelor 10 autocorelații, valoarea critică de 5% 18,3) pe  $r_t^2$  2440; autocorelația randamentelor înseși: 0,11, specifică unei piețe mai puțin lichide ([Capitolele 2, 10](#))
- Consecință: un VaR Normal cu volatilitate constantă va fi prea mic în stres și prea mare în perioadele calme

## Pasul 2: modelul GARCH(1,1)-t

- Variația de azi este o sumă ponderată dintre o constantă, pătratul șocului de ieri și variația de ieri [Bollerslev \(1986\)](#)


$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad \sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

- ▶  $r_t$ : randamentul log zilnic;  $\mu$ : media;  $\varepsilon_t$ : șocul;  $\sigma_t$ : volatilitatea condiționată, cunoscută în  $t - 1$ ;  $z_t$ : i.i.d. Student-t cu  $\nu$  grade de libertate, scalat la varianța 1
- ▶  $\omega > 0, \alpha, \beta \geq 0$ :  $\alpha$  măsoară reacția la știri,  $\beta$  memoria;  $\nu$  mic: cozi groase ( $\nu \rightarrow \infty$  dă distribuția Normală)
- Persistența  $\alpha + \beta < 1$ : staționaritate în covarianță; un șoc de varianță scade cu factorul  $\alpha + \beta$  în fiecare zi

$$h_{1/2} = \frac{\ln 0,5}{\ln(\alpha + \beta)}$$

- ▶  $h_{1/2}$ : timpul de înjumătățire, numărul de zile după care a dispărut jumătate dintr-un șoc de varianță;  $\alpha + \beta = 1$  (IGARCH): șocurile nu se mai sting
- Estimat prin verosimilitate maximă, cu erori standard robuste (sandviș); slide-ul următor dă estimările pentru BET

## Pasul 2: volatilitatea GARCH(1,1)- $t$



- Randamentele log zilnice ale BET cu  $\pm 2\hat{\sigma}_t$  dintr-un GARCH(1,1) cu inovații Student- $t$ , 2000–2026; erori standard robuste:  $\hat{\alpha} = 0,192$  (0,025),  $\hat{\beta} = 0,799$  (0,024),  $\hat{\nu} = 5,01$ : cozi groase chiar după filtrare
- Persistența  $\hat{\alpha} + \hat{\beta} = 0,9907$ , un timp de înjumătățire de aproximativ 74 de zile de tranzacționare; CI 95% din verosimilitatea profil [0,975, 1]: persistența nu poate fi separată de 1 (capcana de inferență)
- Volatilitatea zilnică maximă 7,39% pe 15 oct. 2008; la finalul eșantionului 1,67%

## Pasul 3: patru prognoze VaR 1% (1/2)

- Necondiționate, pe ultimele 500 de zile: o singură cuantilă pentru toată fereastra
  - ▶ **HS** (simulare istorică): pierderea  $L = -r$  depășită în 1% din ultimele 500 de zile (cuantila empirică)
  - ▶ **Normal**:  $\text{VaR} = -(\hat{\mu} + \hat{\sigma} z_{0,01})$ ;  $\hat{\mu}$ ,  $\hat{\sigma}$ : media și abaterea standard de selecție;  $z_{0,01} = -2,326$ : cuantila de 1% a distribuției Normale standard
- Condiționate, GARCH- $t$  pe ultimele 1000 de zile: cuantila se scalează cu prognoza volatilității de azi  $\hat{\sigma}_t$

$$\text{GARCH-}t: \text{VaR}_t = -\left(\hat{\mu} + \hat{\sigma}_t t_{\nu}^{-1}(0,01) \sqrt{(\nu - 2)/\nu}\right), \quad \text{FHS: } \text{VaR}_t = -(\hat{\mu} + \hat{\sigma}_t \hat{q}_{0,01}(z))$$


- ▶  $t_{\nu}^{-1}(0,01)$ : cuantila de 1% a unei distribuții Student- $t$  cu  $\nu$  grade de libertate;  $\sqrt{(\nu - 2)/\nu}$  o rescalează la varianța 1
- ▶ **FHS** (simulare istorică filtrată):  $\hat{q}_{0,01}(z)$ , cuantila empirică de 1% a reziduurilor standardizate  $z_t = (r_t - \hat{\mu})/\hat{\sigma}_t$ , înlocuiește cuantila Student- $t$  [McNeil & Frey \(2000\)](#)



## Pasul 3: patru prognoze VaR 1% (2/2)


- Procedură în timp real
  - ▶ Prognoza pentru ziua  $t$  folosește doar datele pînă la  $t - 1$
  - ▶ GARCH reestimat la fiecare 21 de zile de tranzacționare;  $\hat{\sigma}_t$  actualizat zilnic
- Evaluare: 3 ian. 2005 – 18 sept. 2026,  $T = 5432$  zile
  - ▶ O depășire în ziua  $t$ : pierderea  $-r_t$  depășește  $\text{VaR}_t$ ; depășiri așteptate la 1%:  $0,01 T \approx 54$
- Modelele necondiționate reacționează doar pe măsură ce fereastra avansează; cele condiționate reacționează prin  $\hat{\sigma}_t$ , în cîteva zile

### Pasul 3: pierderi și VaR 1%, 2020–2026



- Pierderile zilnice ale BET (cîștigurile sînt trunchiate la 0), VaR 1% Normal și FHS; puncte negre: pierderi peste VaR FHS
- FHS reacționează în cîteva zile: a atins 11,6% pe 18 mar. 2020, în timpul crahului din pandemia COVID-19; VaR Normal pe o fereastră de 500 de zile se ajustează lent
- 1 675 de zile, aproximativ 17 depășiri așteptate: FHS 22, Normal 41; depășirile Normal se grupează în primele săptămîni ale fiecărui episod de stres
- Ultima prognoză: FHS 4,48%, Normal 2,18%: modelele diferă cel mai mult cînd volatilitatea se schimbă

## Pasul 4: ratele depășirilor



- Ponderea zilelor cu pierdere peste prognoza VaR 1%, 3 ian. 2005 – 18 sept. 2026,  $T = 5\,432$
- Banda gri: intervalul binomial de 95% [0,74%, 1,27%] dacă rata adevărată este 1%
- Doar FHS (1,23%) se află în bandă; modelul Normal (2,25%) este depășit de peste două ori mai des decât ar trebui
- Urmează
  - ▶ sînt diferențele semnificative?
  - ▶ sînt depășirile independente?

## Pasul 4: cele trei backtest-uri

- Testul de acoperire Kupiec [Kupiec \(1995\)](#): este rata depășirilor egală cu  $\alpha = 1\%$ ?

$$LR_{uc} = -2 \ln \frac{(1 - \alpha)^{T-x} \alpha^x}{(1 - \hat{\pi})^{T-x} \hat{\pi}^x} \sim \chi_1^2, \quad \hat{\pi} = x/T$$

►  $x$ : numărul depășirilor în  $T$  zile;  $\hat{\pi}$ : rata observată a depășirilor;  $LR_{uc} = 0$  când  $\hat{\pi} = \alpha$ ; respingem la 5% când  $LR_{uc} > 3,84$

- Testul de independență Christoffersen [Christoffersen \(1998\)](#): este o depășire azi mai probabilă după o depășire ieri?

$$LR_{ind} = -2 \ln \frac{(1 - \hat{\pi})^{n_{00}+n_{10}} \hat{\pi}^{n_{01}+n_{11}}}{(1 - \hat{\pi}_{01})^{n_{00}} \hat{\pi}_{01}^{n_{01}} (1 - \hat{\pi}_{11})^{n_{10}} \hat{\pi}_{11}^{n_{11}}} \sim \chi_1^2$$


- $n_{ij}$ : numărul zilelor în starea  $j$  după o zi în starea  $i$  ( $1 = \text{depășire}$ ,  $0 = \text{fără depășire}$ );  $\hat{\pi}_{01} = n_{01}/(n_{00} + n_{01})$ ,  $\hat{\pi}_{11} = n_{11}/(n_{10} + n_{11})$ : ratele depășirilor după o zi fără depășire și după o depășire
- Testul comun:  $LR_{cc} = LR_{uc} + LR_{ind} \sim \chi_2^2$  (valoarea critică de 5% 5.99); p-value-urile:  $p_{uc}$ ,  $p_{ind}$ ,  $p_{cc}$  provin din aceste distribuții  $\chi^2$

## Pasul 4: testele de acoperire și independență

| Model   | Depășiri | Rata  | $p_{uc}$ | $p_{ind}$ | $p_{cc}$ | Zona roșie |
|---------|----------|-------|----------|-----------|----------|------------|
| HS      | 79       | 1,45% | 0,002    | <0,001    | <0,001   | 5,5%       |
| Normal  | 122      | 2,25% | <0,001   | <0,001    | <0,001   | 18,6%      |
| GARCH-t | 80       | 1,47% | 0,001    | 0,864     | 0,005    | 0,0%       |
| FHS     | 67       | 1,23% | 0,095    | 0,267     | 0,134    | 0,0%       |


- $p_{uc}$ : testul de acoperire Kupiec;  $p_{ind}$ : testul de independență Christoffersen;  $p_{cc}$ : ambele împreună [Kupiec \(1995\)](#), [Christoffersen \(1998\)](#)
- Zona roșie: ponderea ferestrelor de 250 de zile cu cel puțin 10 depășiri (semaforul Basel)
- Doar FHS nu este respins de niciunul dintre cele trei teste la 5%; HS și Normal sînt respinse și de testul de independență: depășirile lor se grupează
- GARCH-t: independența nu este respinsă, dar depășirile sînt prea multe: coada Student-t nu este suficient de groasă la 1%

## Pasul 4: depășirile din ultimele 250 de zile



- Numărul depășirilor pe o fereastră mobilă de 250 de zile, cu zonele Basel verde, galbenă și roșie
- Modelul Normal petrece 18,6% din ferestre în zona roșie, HS 5,5%, cele două modele cu filtru GARCH niciodată

## Capcana look-ahead bias în studiul de caz



- Cuantila HS din tot eșantionul: 1,01% depășiri, prin construcție
- GARCH-t cu parametri din tot eșantionul: 1,31% din zile, cu estimare pe fereastră mobilă 1,47%
- Ambele par mai bune decât versiunile în timp real: diferența măsoară valoarea unei informații indisponibile în timp real
- Doar rezultatul pe fereastră mobilă este o dovadă despre un model de prognoză

## Pasul 5: trei instrumente pentru compararea formală (1/2)

- **Testul Dynamic Quantile (DQ) Engle & Manganelli (2004):** sînt depășirile previzibile?
  - ▶ Regresăm  $I_t - 0,01$  pe o constantă, indicatorii depășirilor  $I_{t-1}, \dots, I_{t-4}$  și  $\text{VaR}_t$ ;  $I_t = 1$  dacă pierderea depășește  $\text{VaR}_t$ , altfel 0
  - ▶  $DQ$ : statistica Wald că toți cei șase coeficienți sînt zero,  $DQ \sim \chi^2_6$  pentru un model corect; detectează depășirile previzibile din trecut sau din nivelul  $\text{VaR}$ , pe care testul Christoffersen (un singur lag) le poate rata
- **Scorul FZ0 Patton, Ziegel & Chen (2019):** o valoare pe zi care evaluează perechea de prognoze ( $\text{VaR}$ ,  $\text{ES}$ ); mai mic este mai bine

$$S(v, e; y) = -\frac{1\{y \leq v\}(v - y)}{\alpha e} + \frac{v}{e} + \ln(-e) - 1$$

- ▶  $\alpha = 2,5\%$ ;  $v = -\text{VaR}$ ,  $e = -\text{ES}$ : prognozele scrise ca cuantile ale randamentelor ( $e \leq v < 0$ );  $y$ : randamentul realizat;  $1\{\cdot\}$ : 1 dacă condiția este îndeplinită, altfel 0
- ▶ Strict consistent pentru ( $\text{VaR}$ ,  $\text{ES}$ ) Fissler & Ziegel (2016): în medie, perechea adevărată are scorul cel mai mic



## Pasul 5: trei instrumente pentru compararea formală (2/2)

### ▣ Compararea scorurilor FZ0 a două modele

- ▶ Teste Diebold–Mariano pe perechi [Diebold & Mariano \(1995\)](#):  $t = \bar{d} / \sqrt{\hat{\Omega} / T}$ ,  $d_t$  fiind diferența FZ0 dintre cele două modele în ziua  $t$ ,  $\hat{\Omega}$  dispersia ei de termen lung HAC;  $t \approx N(0, 1)$  la acuratețe egală
- ▶ Mulțimea de încredere a modelelor la 10% [Hansen, Lunde & Nason \(2011\)](#): mulțimea care conține cel mai bun model cu probabilitatea 90%;  $p_{MCS}$ : un model rămîne în mulțime cît timp  $p_{MCS} \geq 0,10$

### ▣ **Verificarea ES**: comparativă, față de HS ca model standard; roșu dacă modelul este semnificativ mai slab, verde dacă este semnificativ mai bun, galben în rest [Nolde & Ziegel \(2017\)](#)


- ▶ Toate prognozele folosesc doar datele pînă la  $t - 1$ ; 5 432 de zile, 3 ian. 2005 – 18 sept. 2026

## Pasul 5: rezultate

| Model   | $DQ$  | $p_{DQ}$ | FZ0   | $p_{MCS}$ | Zona ES  |
|---------|-------|----------|-------|-----------|----------|
| HS      | 192,1 | <0,001   | 1,424 | 0,00      | standard |
| Normal  | 364,6 | <0,001   | 1,495 | 0,00      | roșu     |
| GARCH-t | 17,9  | 0,007    | 1,175 | 0,18      | verde    |
| FHS     | 9,9   | 0,129    | 1,157 | 1,00      | verde    |

- Doar FHS trece testul DQ la 5% ( $p = 0,129$ ); GARCH- $t$  nu îl trece ( $p = 0,007$ ) din cauza excesului de depășiri
- FZ0 (mai mic este mai bun): FHS și GARCH- $t$  nu diferă semnificativ (DM  $t = 1,39$ ), ambele sînt superioare modelelor HS și Normal ( $|t| > 4,9$ ); mulțimea de încredere a modelelor la 10% este {GARCH- $t$ , FHS}
- Verificarea comparativă a ES: Normal roșu, GARCH- $t$  și FHS verzi: inferența formală confirmă clasamentul din Pasul 4

## Puterea de detecție a unui backtest: testul Kupiec



- Probabilitatea binomială exactă ca testul Kupiec de 5% să respingă un model VaR 1%, după rata reală a depășirilor
- $T = 250$  (un an Basel): o rată reală de 2% este detectată doar în 24% din cazuri; respingerea cere 0 sau cel puțin 7 depășiri
- Efectul minim detectabil (MDE), aici o rată reală a depășirilor, cu putere de 80%: 3,65% la  $T = 250$ , 2,05% la  $T = 1000$ , 1,45% la  $T = 5432$ ; o rată reală de 1,3% este detectată doar cu probabilitatea 55%
- O nerespingere cu putere mică înseamnă „nicio dovadă”, nu „nicio problemă”: precizați puterea înaintea testului

## Proiectul în patru pași

- ▣ Un studiu empiric al unei întrebări despre piețele financiare, cu metodele acestui curs; **70%** din nota finală (quiz-uri și activitate la seminar 20%, prezență 10%, fără examen final)
- ▣ **1. Replicați:** reproduceți un tabel sau o figură întreagă dintr-un articol publicat (sau din curs), celulă cu celulă
  - ▶ Raportați diferența pentru fiecare celulă și explicați-o; un asistent AI nu poate ghici un tabel publicat
- ▣ **2. Extindeți:** date noi, altă piață (BVB, crypto) sau un eșantion mai recent, după un **plan de analiză** fixat în scris printr-un commit datat în repository înainte de a deschide perioada de test
  - ▶ Planul precizează ipoteza nulă, testul, funcția de pierdere, împărțirea eșantionului, strategia de identificare, puterea testului principal și grila de specificații cu corecția ei
- ▣ **3. Livrați pe GitHub:** cod, un fișier cu versiunile pachetelor, seed-uri aleatoare fixate, proveniența datelor; un singur notebook regenerează fiecare cifră
  - ▶ `AI_USE.md` și `AI_ERRORS.md` sînt obligatorii; raportul este un articol de 8–12 pagini
- ▣ **4. Prezentați și susțineți:** prezentarea echipei, apoi o susținere orală de 10 minute
  - ▶ Fiecare membru explică un rezultat și răspunde la o întrebare de tipul „ce se schimbă dacă...”; notele pot diferi între membri

## Standardul de replicare

- ▣ Ținta: un tabel sau o figură întreagă, cu DOI, pagină și numărul tabelului, nu un singur coeficient
  - ▶ Raportați o comparație celulă cu celulă: valoarea publicată, valoarea dumneavoastră, diferența și motivul fiecărei abateri (eșantion, filtru, sursa datelor, definiție)
- ▣ Replicările la scară mare arată necesitatea acestui standard: multe anomalii se micșorează în afara eșantionului sau cu date mai bune [Hou, Xue & Zhang \(2020\)](#), iar majoritatea factorilor se replică atunci când metodologia este corectă [Jensen, Kelly & Pedersen \(2023\)](#)
- ▣ Reproductibilitate: un fișier cu versiunile pachetelor, seed-uri aleatoare fixate, numele seriilor și datele lor, o singură comandă care regenerează fiecare cifră
  - ▶ Rezultatele unor echipe diferite care analizează aceleași date diferă mai mult decât sugerează erorile lor standard [Menkveld et al. \(2024\)](#): lucrările mai reproductibile sînt asociate cu o dispersie mai mică (studiul de caz de cercetare din acest capitol)

## Alegerea întrebării

### O întrebare bună este

- ▣ **Specifică:** o piață, o perioadă, o mărime
- ▣ **Testabilă:** o ipoteză nulă și un reper
- ▣ **Fezabilă:** date pe care le puteți obține și curăța în câteva săptămîni (datele cursului, în repository-ul GitHub al cursului; surse publice: BNR, FRED, Kenneth French Data Library, DefiLlama)
- ▣ **Relevantă:** răspunsul contează pentru un investitor, o bancă sau o autoritate

### Exemple

- ▣ Prea vagă: „Este Bitcoin riscant?”
  - ▶ Mai bună: „Au schimbat ETF-urile spot VaR 1% pe o zi al Bitcoin?”
  - ▶ Apoi: „Ce model îl prognozează cel mai bine din 2024?”
- ▣ Prea largă: „Poate machine learning să prezică piața?”
  - ▶ Mai bună: „Bate un model de boosting modelul log-HAR pentru volatilitatea BET de a doua zi, în QLIKE, 2018–2026?”

## Metode: de la întrebare la capitol

| Dacă întrebarea este despre                       | Porniți de la                                                               |
|---------------------------------------------------|-----------------------------------------------------------------------------|
| Distribuția randamentelor, cozi, predictibilitate | Capitolele 1–2: momente, teste robuste, rapoarte ale varianțelor            |
| Randamente așteptate, factori, portofolii         | Capitolele 3–4: Fama–MacBeth, shrinkage, teste Sharpe în afara eșantionului |
| Volatilitate și corelație                         | Capitolele 5, 6, 9: GARCH, DCC, copule, log-HAR                             |
| Măsuri de risc și capital                         | Capitolele 7–8: FHS, EVT, backtest-uri, FZ0                                 |
| Lichiditate, opțiuni, timp continuu               | Capitolele 10–12: Amihud, Black–Scholes, VIX, prima de risc a varianței     |
| Prognoză cu ML, deep learning sau text            | Capitolele 13–15: purged CV, modele fundamentale, sentiment                 |
| Cripto, bule, risc sistemic                       | Capitolele 16–18: stablecoin-uri, GSADF, CoVaR, rețele                      |

- Puncte de plecare: întrebarea din Partea C a fiecărui seminar (tabel în [Anexă](#)); o întrebare proprie este binevenită dacă răspunde celor cinci întrebări din acest capitol

## Identificarea: de la corelație la o afirmație

- ▣ Întrebările despre evenimente („au schimbat ETF-urile spot, reclasificarea FTSE sau o taxă bancară mărimea  $X$ ?”) cer un contrafactual
  - ▶ O piață de control neafectată de eveniment: diferența în diferențe pe măsura de risc
  - ▶ Un control sintetic construit din mai multe piețe neafectate de eveniment [Abadie, Diamond & Hainmueller \(2010\)](#); date placebo ale evenimentului (de ex.  $\pm$  un an)
- ▣ Moment necunoscut: un test sup-Wald de ruptură [Andrews \(1993\)](#); raportați data estimată a rupturii, nu una impusă
- ▣ Întrebările de prognoză: doar în afara eșantionului, cu o perioadă de test declarată în plan
- ▣ Un singur eveniment înseamnă  $n = 1$ : precizați ce poate și ce nu poate identifica studiul



## Putere și robustețe fără p-hacking

- ▣ **Putere:** înainte de testul principal, calculați cel mai mic efect pe care testul dumneavoastră îl detectează cu putere de 80% la 5% (MDE)
  - ▶ Livrabil: o curbă de putere simulată pentru testul principal la  $T$ -ul dumneavoastră; eșantioanele scurte de crypto, ETF-uri sau de după eveniment fac ca multe teste să aibă putere mică (Kupiec la  $T = 250$ : MDE 3,65%)
- ▣ Planul de analiză este fixat în scris printr-un commit datat în repository, înainte de deschiderea perioadei de test
- ▣ Curba specificațiilor (specification curve): estimați fiecare combinație justificabilă de fereastră, laguri,  $\alpha$  și început al eșantionului; reprezentați toate estimările ordonate, cu intervalele lor [Simonsohn, Simmons & Nelson \(2020\)](#)
  - ▶ Raportați dispersia pe specificații, nu celula cea mai bună
- ▣ Corecții familia: Holm pentru probabilitatea oricărei descoperiri false, Benjamini–Hochberg pentru ponderea lor așteptată sau testul bootstrap reality check al lui White pentru data snooping [White \(2000\)](#)
  - ▶ Descoperiri false și ratate în finanțe [Harvey & Liu \(2020\)](#); perspectiva științifică a domeniului [Harvey \(2017\)](#)

## Evaluarea prognozelor în proiectele despre risc

- Volatilitate: comparăm prognozele cu o aproximare zgomotoasă, dar condiționat nedeplasată, doar printr-o funcție de pierdere robustă (MSE sau QLIKE) [Patton \(2011\)](#)
  - Pentru multe modele: mulțimea de încredere a modelelor [Hansen, Lunde & Nason \(2011\)](#), nu modelul cu cea mai mică pierdere medie
- VaR: acoperire, independență și testul DQ [Engle & Manganelli \(2004\)](#); cu un reper, teste de capacitate predictivă condiționată [Giacomini & White \(2006\)](#)
  - Precizați puterea fiecărui backtest la  $T$ -ul dumneavoastră
- ES: evaluăm perechea (VaR, ES) cu scorul FZ0; verificări comparative cu trei zone [Nolde & Ziegel \(2017\)](#); modele dinamice pentru (VaR, ES) [Patton, Ziegel & Chen \(2019\)](#)
  - Studiul de caz integrat (Pașii 1–5) servește drept model

## Raportul și prezentarea

### Raportul: un articol de 8–12 pagini

- ▣ **1. Introducere:** întrebarea, ipoteza, contribuția; **2. Literatură:** 10–15 referințe cu link, cel puțin 3 din ultimii cinci ani, inclusiv [Franke, Härdle & Hafner \(2019\)](#), [McNeil, Frey & Embrechts \(2015\)](#)
- ▣ **3. Date și replicare:** surse, perioadă, reguli de curățare; tabelul replicat, celulă cu celulă
- ▣ **4. Metodologie:** plan, identificare, putere, reper, funcție de pierdere, teste
- ▣ **5. Rezultate** cu incertitudine; **6. Robustețe:** specification curve cu corecția; **7. Concluzie:** răspunsul într-o frază și limitele lui

### Prezentarea (aproximativ 12 minute)

- ▣ Întrebarea (1 slide); datele și un grafic care arată problema (2); metoda și reperul (2); rezultatul principal cu incertitudinea lui (2–3); robustețe, limitări, răspuns (2)
- ▣ Un mesaj pe slide; axe lizibile, legenda sub grafic
- ▣ Fiecare membru prezintă și poate răspunde la întrebări despre cod; apoi susținerea orală de 10 minute, fără AI

## Evaluarea proiectului și calendarul

| Componentă                           | Criterii de evaluare                                                                                 |
|--------------------------------------|------------------------------------------------------------------------------------------------------|
| Replicare (pasul 1)                  | Un tabel sau o figură publicată reprodusă celulă cu celulă; fiecare diferență explicată              |
| Întrebare, date, extindere (pasul 2) | Întrebare specifică și testabilă; date documentate și calendare aliniate                             |
| Metode și inferență                  | Plan, identificare, putere, procedură în timp real, reper, curba specificațiilor cu corecție         |
| Interpretare și raport               | Semnificație economică, limitări, concluzie onestă; 8–12 pagini, 10–15 referințe                     |
| Repository GitHub (pasul 3)          | O singură comandă reproduce fiecare rezultat (fișier de versiuni, seed-uri); AI_USE.md, AI_ERRORS.md |
| Prezentare și susținere (pasul 4)    | Individual: un rezultat explicat, răspunsuri la „ce se schimbă dacă...”                              |

- Săptămîna 1 după acest capitol: echipa, întrebarea, propunerea de o pagină (Seminarul 19, C1), repository-ul GitHub; săptămînile 2–3: datele, replicarea (pasul 1), planul fixat în scris printr-un commit datat
- Săptămînile 4–5: extindere, evaluare, robustețe (pasul 2); ultimele săptămîni: repository-ul cu README și cele două fișiere AI (pasul 3), prezentarea și susținerea orală (pasul 4); datele exacte se anunță la curs și la seminar

## Politica AI și cele două fișiere obligatorii

### Politica

- ▣ **Permis:** asistenți AI pentru cod, depanare, căutarea literaturii și redactare
- ▣ **Declarat:** utilizarea nedeclarată a AI este tratată ca plagiat
- ▣ **Verificat:** răspundeți pentru fiecare rînd; o referință care nu există este tratată ca date fabricate
- ▣ **Fără AI la susținerea orală:** „L-a scris AI-ul” nu este o explicație

### Cele două fișiere

- ▣ **AI\_USE.md:** instrumentele și versiunile, cine le-a folosit și pentru ce, unde ați păstrat cod sau text scris de AI, cum ați verificat tabelul replicat, datele, formulele și referințele
- ▣ **AI\_ERRORS.md:** cel puțin **trei** locuri în care asistentul a greșit: ce ați întrebat, ce a răspuns, ce era greșit, cum v-ați dat seama, varianta corectă
- ▣ Erorile detectate sînt un punct forte al proiectului, nu unul slab

## Erori AI tipice în modelarea financiară

- **Look-ahead bias:** o statistică pe fereastră mobilă sau o scalare care include ziua  $t$  în prognoza pentru ziua  $t$ 
  - ▶ Verificare: schimbați ultima observație; prognoza pentru acea zi nu trebuie să se modifice; decalați cu o zi (`.shift(1)`)
- **Semnul VaR:** cuantila 1% a randamentelor raportată drept VaR sau cuantila 99% a randamentelor (un câștig) folosită ca pierdere
  - ▶ Verificare:  $\text{VaR}_\alpha = -q_\alpha(r)$ , cu  $q_\alpha(r)$  cuantila  $\alpha$  a randamentelor, este pozitiv ori de câte ori  $q_\alpha(r) < 0$ ; VaR 1% pe o zi al unui indice este de câteva procente
- **Anualizare:** volatilitatea înmulțită cu 252 în loc de  $\sqrt{252}$  sau 252 de zile folosite pentru cripto, care se tranzacționează zilnic
  - ▶ Verificare: pe  $h$  perioade, mediile se scalează cu  $h$ , volatilitățile cu  $\sqrt{h}$  (randamente i.i.d.); folosiți numărul real de zile de tranzacționare (365 pentru cripto)
- **Validare încrucișată (CV) aleatoare pe serii de timp:** validarea K-fold cu amestecare folosește informație din viitor (acuratețe de 69,4% pe zgomot pur, [Capitolul 13](#))
  - ▶ Verificare: există o dată de test anterioară unei date de antrenare? Folosiți validare walk-forward sau purged CV cu embargo [López de Prado \(2018\)](#)
- **Referințe inventate,** grade de libertate greșite, valori implicite din biblioteci pe care nu le-ați ales, cifre raportate fără rularea codului
  - ▶ Verificare: căutați fiecare DOI pe [Crossref](#) și găsiți afirmația în articol; fiecare seminar are un exercițiu C2 care exersează acest lucru

## Impactul alegerilor cercetătorului

- Menkveld et al. (2024), *Journal of Finance* 79(3): 164 de echipe de cercetare testează aceleași șase ipoteze pe aceleași date (Finance Crowd Analysis Project, #fincap; Sec. I.A)
- **Eroarea standard:** incertitudinea datorată eșantionării, în procesul de generare a datelor; **eroarea nestandard:** incertitudinea datorată alegerilor metodologice ale cercetătorului, în procesul de producere a dovezilor empirice (Introducere)
  - ▶ Modelul: echipa  $j$  raportează  $X_j = e_j + \varepsilon_j$ ,  $e_j$  fiind efectul fix asociat alegerilor metodologice, iar  $\varepsilon_j$  eroarea de eșantionare (Sec. I.C, ec. 1)
  - ▶ Eroarea nestandard  $:= Q_{0,75}(x) - Q_{0,25}(x)$ , intervalul intercuartilic (IQR) al estimărilor între echipe (ec. 3),  $Q_p(x)$  fiind cuantila  $p$  a estimărilor  $x$  ale echipelor; IQR-ul, nu abaterea standard, pentru că  $e_j$  pot avea cozi groase
- **Date:** toate tranzacțiile cu contractele futures pe indicele Euro Stoxx 50, 2002–2018, 720 de milioane de înregistrări; șase ipoteze de tipul „nicio tendință anuală” (eficiența pieței, spread-ul realizat, ponderea clienților în volum, ...); fiecare echipă raportează variația anuală medie în %, cu eroarea ei standard (SE)
  - ▶ Patru etape în 2021: analiza independentă, feedbackul evaluatorilor, distribuirea celor mai bune cinci lucrări, estimările finale; detaliile experimentului în [▶ Anexă](#)
- Legătura cu acest capitol: fiecare proiect de echipă este o singură specificație din „grădina potecilor care se bifurcă” (garden of forking paths); preînregistrarea, grila de specificații și un repository care regenerează fiecare cifră sînt remediile

## Rezultatele principale: mărimea și calitatea


- ▣ **Mărimea:** pentru eficiența pieței, estimarea mediană este  $-1,1\%$  pe an, cu un IQR de 6,7 puncte procentuale (pp); chiar și pentru ponderea clienților în volum, un simplu raport, IQR-ul este 1,2 pp în jurul valorii  $-3,3\%$  (Tabelul I, Panoul C)
  - ▶ SE-ul median de  $2,5\%$  implică, sub distribuția Normală, un IQR de  $1,35 \times 2,5 = 3,4\%$  (IQR-ul distribuției Normale este de 1,35 abateri standard), jumătate din 6,7 pp; ipoteza nulă fără dispersie este respinsă pentru toate cele șase ipoteze,  $p < 0,0001$  (Tabelul II)
- ▣ **Calitatea:** o creștere cu o abatere standard a reproductibilității este asociată cu un IQR mai mic cu  $25,0\%$ , iar aceeași creștere a notei evaluatorilor cu un IQR mai mic cu  $33,3\%$  (Tabelul III, Fig. 2)
  - ▶ Codul care rulează integral, fără intervenție manuală, este asociat cu răspunsuri mai apropiate de consens



## Rezultatele principale: feedback, convingeri și decizii metodologice


- ▣ **Feedbackul:** de la etapa 1 la etapa 4, IQR-ul scade cu 47,2%, iar intervalul interdecilic cu 68,2% (Tabelul IV, Fig. 3)
  - ▶ Evaluarea colegială reduce dispersia, dar nu o elimină
- ▣ **Convingerile:** pe toate ipotezele, abaterea standard a estimărilor anticipată de echipe este cu 71,7% sub cea observată (Sec. II.B.3, Fig. 4)
  - ▶ Cercetătorii subestimează cât de mult pot diferi echipele care analizează aceleași date
- ▣ **Deciziile metodologice (bifurcațiile):** alegerea modelului și frecvența eșantionării modifică cel mai mult estimările; un model al variației relative dă o tendință anuală mediană de  $-23\,000\%$  pe date zilnice,  $-200\%$  lunar și  $-4,56\%$  anual (Fig. 6, Fig. 7)
  - ▶ Inegalitatea lui Jensen pentru rapoartele  $M_t = X_t/X_{t-1}$ :  $\mathbb{E} \ln M_t \leq \ln \mathbb{E} M_t$ ; diferențele logaritmice se adună exact între frecvențe, iar tendința liniară este liniară în date, deci niciuna nu produce această abatere între frecvențe

## Mini-multivers pe datele cursului: 27 de specificații pe indice



- Închideri zilnice 2002–2018 din datele cursului; deciziile metodologice (bifurcațiile) valori extreme  $\times$  măsură  $\times$  model din Tabelul V; banda este IQR-ul, eroarea nestandard a multiversului
- IQR: 22,9 pp (Euro Stoxx 50) și 84,4 pp (BET), în jurul unor mediane de  $-0,8\%$  și  $-1,8\%$  pe an;  $|VR(q) - 1|$ , cu  $VR(q)$  raportul varianțelor din Capitolul 2, și  $R^2$  măsoară abaterea de la mersul aleator, deci o tendință pozitivă înseamnă o eficiență în scădere
- Alegerea modelului determină dispersia: pentru cele nouă specificații cu tendință liniară, IQR-ul este de doar 2,0 pp și 7,5 pp; diferențele relative cresc exploziv (mediane  $+210,4\%$  și  $+108,7\%$ , până la  $46\,823\%$ ); articolul raportează același fenomen (Fig. 7)
- Față de  $1,35 \times$  SE-ul median ( $25,9$  și  $50,8$  pp), IQR-ul depășește reperul de eșantionare pentru BET, nu și pentru Euro Stoxx 50

## Alegerile care modifică cel mai mult estimările



- Statistica Anderson–Darling pentru  $k$  eşantioane (compară distribuțiile celor  $k$  grupe; o valoare mai mare înseamnă grupe mai separate) a celor 27 de estimări grupate după opțiunea de la fiecare decizie (Sec. II.C): modelul 8,91 (Euro Stoxx 50) și 9,16 (BET); măsura 2,76 și 2,33; valorile extreme  $-1,36$  și  $-1,02$
- Aceeași ordine ca în articol (Fig. 6): alegerea modelului modifică cel mai mult estimările, atât pe un indice mare din zona euro, cât și pe indicele unei piețe de frontieră
- Cele 27 de estimări folosesc aceleași date, deci statistica este o ierarhizare descriptivă, nu un test; statistica standardizată este centrată în zero pentru distribuții egale: o valoare negativă indică o separare sub cea datorată hazardului, nu absența unui efect
- Pentru proiectul dumneavoastră: fixați în plan modelul variației anuale (diferențe logaritmice sau tendințe liniare), apoi raportați toată grila și decizia care o determină

 MFM\_ch19\_nonstandard\_errors

## Limite și o extindere deschisă

- **Limite formulate de autori:** multiversul acoperă doar câteva decizii metodologice și explică slab estimările raportate (nota 32); echipelor li s-a cerut să anticipeze abaterea standard, nu IQR-ul (nota 28)
  - ▶ Testul dispersiei presupune SE-uri raportate consistente (Sec. I.C); dinamica evaluării la reviste rămîne în afara studiului (Sec. I.A)
  - ▶ Multiversul acoperă doar opțiunile incluse în grilă; IQR-ul său nu estimează și nu delimitează inferior dispersia dintre echipele reale
- **Limita datelor în replicare:** doar închideri zilnice, deci perechile de frecvențe intrazilnice din Tabelul V nu pot fi rulate (Seminarul 19, C3 o extinde pînă la ultimul an complet)
- **Extindere deschisă:** reduce o grilă preînregistrată eroarea nestandard a unei întrebări de risc?
  - ▶ Măsurăți IQR-ul concluziilor VaR 1% pentru BET pe specificațiile justificabile
  - ▶ Pentru proiectul dumneavoastră: raportați distribuția pe grilă și deciziile metodologice care o modifică cel mai mult, nu o singură celulă

## O întrebare deschisă și bucla descoperirii

- ▣ **Întrebarea deschisă:** ce parte dintr-un rezultat se datorează datelor și ce parte cercetătorului?
  - ▶ Replicarea este posibilă: într-un model bayesian al replicării, majoritatea factorilor de evaluare a activelor se replică și funcționează în afara eșantionului în 93 de țări [Jensen, Kelly & Pedersen \(2023\)](#)
  - ▶ Asistenții AI reduc aproape la zero costul fiecărei specificații suplimentare: crește numărul specificațiilor posibile, dar și posibilitatea de a le raporta pe toate
  - ▶ Formularea formală: concluzia trebuie să rămână valabilă pe o mulțime preînregistrată  $S$  de specificații justificabile, cu familia corectată (FWER sau FDR); raportăm distribuția ei pe  $S$ , nu celula cea mai bună
- ▣ **Bucla:** întrebarea și  $H_0/H_1$  (săptămîna 1); literatura și ținta de replicare văzută în PDF (săptămînile 1–2); preînregistrarea, fixată în scris printr-un commit datat în repository înaintea primului rezultat (săptămîna 2); replicarea ca test care trece în repository (săptămînile 2–3); întreaga grilă (săptămînile 4–5); un examinator AI înainte de susținere
  - ▶ „Iată rezultatele tuturor specificațiilor analizate. Ce concluzii rămîn valabile după corecția Holm și pe care le-ar numi un recenzent căutare oportunistă în date (data snooping)?”
- ▣ **Verificările cercetătorului:** cifra-țintă se află în articol; planul precede primul fișier de rezultate în istoricul commit-urilor; fiecare rulare este jurnalizată și numărată; o clonă nouă regenerează fiecare cifră; fiecare membru poate deduce formula-cheie fără AI
  - ▶ Prompturile pentru fiecare pas și testul pentru fiecare verificare: [▶ Anexă](#)

## Mini studiu de caz: replicăm, apoi extindem

- ▣ **Replicăm:** VaR 1% FHS pentru BET; **Capitolul 8** raportează 59 de depășiri în 4 937 de zile (1,20%, Kupiec  $p = 0,181$ )
  - ▶ Studiul de caz din acest capitol: 67 în 5 432 de zile (1,23%,  $p = 0,095$ ); același model, alt început al evaluării (2007 față de 2005) și alte setări: documentăm orice diferență înainte de a declara o replicare eșuată
- ▣ O concluzie tipică propusă de asistent, care citește fiecare p-value separat la 5%: „doar GARCH-EVT este calibrat corect pe toate cele patru active”
- ▣ **Extindem:** cele 24 de teste de acoperire condiționată din **Capitolul 8** (4 active  $\times$  6 modele) formează o familie
  - ▶ Respingeri la 5%: 12 fără corecție, 10 cu Holm (FWER), 11 cu BH (FDR 5%)
  - ▶ FHS eșuează doar pe S&P 500 ( $p = 0,040$ ); considerat în familia de 24 de teste, nu mai este respins, deci după Holm FHS și GARCH-EVT trec pe toate cele patru active
- ▣ Interpretare: „FHS eșuează pentru S&P 500” depinde de citirea testului separat sau în familia lui; preînregistrăm familia și le raportăm pe amândouă

## Planul final al echipei

- ▣ **Întrebarea:** ideea dumneavoastră din Partea C, scrisă ca  $H_0/H_1$ , cu observația care ar infirma-o
- ▣ **Replicați întâi:** un tabel publicat, văzut în articol, transformat într-un test care trece în repository
  - ▶ Apoi extindeți pe o grilă preînregistrată, cu familia corectată și distribuția completă raportată
- ▣ **Livrabile** de-a lungul calendarului: propunerea și ținta de replicare, commit-ul de preînregistrare, testul de replicare care trece, grila de rezultate, susținerea de probă, raportul, susținerea orală
- ▣ **Jurnalul AI:** prompturile care au schimbat metodologia în AI\_USE.md; fiecare eroare detectată, cu testul care a detectat-o, în AI\_ERRORS.md ([șabloane](#))

## Idei de reținut

- ▣ Randamentele sînt greu de prezis; riscul lor nu: volatilitatea, cozile și dependența pot fi prognozate
- ▣ Orice model este judecat în afara eșantionului, față de un reper simplu, cu o funcție de pierdere potrivită țintei
- ▣ Cozile groase schimbă inferența: folosiți erori robuste și bootstrap, raportați intervale, precizați puterea
- ▣ Cele mai multe rezultate greșite vin din felul în care este construită analiza, nu din model: look-ahead bias, overfitting, testare multiplă, calendare
- ▣ Parcursul analizei este el însuși o sursă de incertitudine: preînregistrați, replicați, raportați toată grila
- ▣ Instrumentele noi (ML, modele fundamentale, LLM-uri) ridică exigența evaluării, nu o scad



## Autoverificare și studiu suplimentar

### Întrebări de verificare

- De ce kurtosis-ul de selecție al randamentelor BET nu estimează nimic?
- De ce nu poate fi raportat intervalul Wald pentru persistența GARCH?
- Ce îl înlocuiește?
- Ce vă spune o nerespingere a testului Kupiec la  $T = 250$ ?
- De ce IQR-ul unui multivers cu 27 de specificații nu este eroarea nestandard a 164 de echipe?

### Studiu suplimentar

- Manuale: Franke, Härdle & Hafner (2019); Härdle, Chen & Overbeck (2017); McNeil, Frey & Embrechts (2015); Tsay (2010)
- Cursuri avansate pe quantinar.com:  Statistics of Financial Markets;  Measuring Statistical Risk
- Cod și date:  
[github.com/danpele/MFM/tree/main/Quantlets/Ch\\_19](https://github.com/danpele/MFM/tree/main/Quantlets/Ch_19)

## Anexă: Inferența cheie pe capitole (1/17)

- ▣ **Capitolul 0, Piețele financiare în 2026:** Calitatea datelor este o decizie de modelare: sursa, ajustarea și calendarul schimbă rezultatul
- ▣ Media și volatilitatea estimate din randamente log i.i.d., anualizate cu numărul de perioade pe an

$$\text{se}(\hat{\mu}_{\text{ann}}) = \frac{\sigma_{\text{ann}}}{\sqrt{Y}}, \quad \text{se}(\hat{\sigma}) \approx \sigma \sqrt{\frac{K-1}{4T}}$$

- ▶ se: eroarea standard;  $Y$ : lungimea eșantionului în ani, indiferent de frecvență;  $T$ : numărul de randamente zilnice;  $\sigma$ ,  $\sigma_{\text{ann}}$ : volatilitatea zilnică și cea anualizată;  $K$ : kurtosis-ul populației (cere un moment de ordinul patru finit)
  - ▶ Dependența în timp cere dispersii de termen lung
- ▣ SPY 2015–2026:  $\text{se}(\hat{\mu}_{\text{ann}}) \approx 5,1\%$  pentru o medie de 13,7%: mediile abia pot fi estimate, volatilitățile da

## Anexă: Inferența cheie pe capitole (2/17)

- ▣ **Capitolul 1, Fapte stilizate și randamente:** Cozi groase și volatility clustering pe toate piețele [Cont \(2001\)](#)
- ▣ Testul Ljung–Box al absenței autocorelației pînă la lagul  $m$

$$Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k} \sim \chi_m^2$$

- ▶  $\hat{\rho}_k$ : autocorelația de selecție la lagul  $k$ ;  $T$ : mărimea eșantionului; distribuția de referință  $\chi_m^2$  cere randamente i.i.d.; cu volatility clustering testul respinge prea des
- ▶ Folosiți  $Q^*$  robust, cu termenii  $T\hat{\rho}_k^2/\hat{\tau}_k$ ,  $\hat{\tau}_k$  fiind factorul de varianță estimat al lui  $\sqrt{T}\hat{\rho}_k$  (aproximativ 1 pentru randamente i.i.d.) [Lobato, Nankervis & Savin \(2001\)](#)
- ▣ Cozile: estimatorul Hill  $\hat{\alpha}$  al tail index-ului, se  $\approx \hat{\alpha}/\sqrt{k}$  [Hill \(1975\)](#)
  - ▶  $\alpha$ : probabilitatea unei pierderi peste  $x$  scade ca  $x^{-\alpha}$ ;  $k$ : numărul celor mai mari pierderi folosite
  - ▶ Dacă  $\alpha < 4$ , kurtosis-ul de selecție nu este consistent, iar bootstrap-ul lui eșuează [Athreya \(1987\)](#)

## Anexă: Inferența cheie pe capitole (3/17)

▣ **Capitolul 2, Eficiența pieței:** Eficiența variază în timp (piețe adaptive); testele cer inferență robustă

▣ Testul raportului varianțelor robust la heteroscedasticitate [Lo & MacKinlay \(1988\)](#)

$$VR(q) = \frac{\text{Var}(r_t + \dots + r_{t-q+1})}{q \text{Var}(r_t)}, \quad z^*(q) = \frac{\widehat{VR}(q) - 1}{\widehat{se}^*} \Rightarrow N(0, 1)$$

►  $q$ : orizontul în perioade;  $VR = 1$  pentru un mers aleator,  $VR > 1$ : autocorelație pozitivă,  $VR < 1$ : revenire la medie

►  $\widehat{se}^*$ : eroarea standard robustă la heteroscedasticitate;  $z^* \Rightarrow N(0, 1)$  sub ipoteza de diferență de martingală

▣ Mai multe orizonturi  $q$  deodată: testul comun  $\max_q |z^*(q)|$  cu valori critice de modul maxim studentizat [Chow & Denning \(1993\)](#); ferestrele mobile cer și ele o corecție pentru testele multiple

## Anexă: Inferența cheie pe capitole (4/17)

- ▣ **Capitolul 3, Modele factoriale și evaluarea activelor:** Sutele de factori publicați cer praguri mai înalte [Harvey, Liu & Zhu \(2016\)](#)
- ▣ Testul GRS că toate erorile de evaluare (constantele) sînt zero [Gibbons, Ross & Shanken \(1989\)](#)

$$\text{GRS} = \frac{T - N - K}{N} \frac{\hat{\alpha}^\top \hat{\Sigma}^{-1} \hat{\alpha}}{1 + \hat{\mu}_f^\top \hat{\Omega}^{-1} \hat{\mu}_f} \sim F(N, T - N - K)$$

- ▶  $T$  perioade,  $N$  active,  $K$  factori;  $\hat{\alpha}$ : cele  $N$  constante (alpha);  $\hat{\mu}_f$ : mediile factorilor;  $\hat{\Sigma}$ ,  $\hat{\Omega}$ : covarianțele reziduurilor și factorilor, împărțitor  $T$
- ▶  $F$  exact doar pentru erori i.i.d. Normale; un GRS mare înseamnă că factorii nu explică randamentele activelor
- ▣ Erorile standard Fama–MacBeth ignoră faptul că coeficienții beta sînt estimați: covarianța Shanken pentru încărcări factoriale estimate [Shanken \(1992\)](#)

$$\hat{V}_{\text{sh}} = (1 + c)(\hat{V}_{FM} - \hat{\Sigma}_f/T) + \hat{\Sigma}_f/T, \quad c = \hat{\gamma}^\top \hat{\Sigma}_f^{-1} \hat{\gamma}$$

- ▶  $\hat{\gamma}$ : primele de risc estimate ale factorilor;  $\hat{\Sigma}_f$ : covarianța factorilor;  $\hat{V}_{FM}$ : covarianța Fama–MacBeth a lui  $\hat{\gamma}$ ;  $c \geq 0$  o mărește, cu atît mai mult cu cît primele sînt mari față de riscul factorilor

## Anexă: Inferența cheie pe capitole (5/17)

- **Capitolul 4, Optimizarea portofoliului:** Shrinkage-ul, restricțiile și regulile bazate pe risc stabilizează ponderile;  $1/N$  este un reper greu de depășit [DeMiguel, Garlappi & Uppal \(2009\)](#)
- Eroarea standard a raportului Sharpe  $SR = (\mu - r_f)/\sigma$  pe perioadă, randamente i.i.d. Normale [Lo \(2002\)](#)

$$se(\widehat{SR}) \approx \sqrt{(1 + \widehat{SR}^2/2)/T}$$

- ▶  $\mu$ ,  $\sigma$ : media și volatilitatea pe perioadă;  $r_f$ : rata fără risc;  $T$ : numărul de perioade; autocorelația schimbă factorul de anualizare
- Este portofoliul A mai bun decât  $1/N$ ? Testăm  $SR_A - SR_B = 0$  cu inferență HAC sau bootstrap studentizat [Ledoit & Wolf \(2008\)](#), nu prin compararea a două estimări punctuale

## Anexă: Inferența cheie pe capitole (6/17)

- **Capitolul 5, Volatilitate condiționată: GARCH:** Persistență aproape de 1; asimetrie la acțiuni; inovații cu cozi groase
- QMLE (cvasi-verosimilitate maximă) pentru GARCH: covarianța sandviș [Bollerslev & Wooldridge \(1992\)](#)

$$\sqrt{T}(\hat{\theta} - \theta) \Rightarrow N(0, A^{-1}BA^{-1})$$

- ▶  $\theta = (\omega, \alpha, \beta)$ : parametrii din  $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$ ;  $A$ : hessiana așteptată a log-verosimilității Normale (cu semn schimbat);  $B$ : varianța scorului
- ▶  $A = B$  când inovațiile sînt Normale; erorile standard doar din hessiană ( $A^{-1}$ ) sînt greșite pentru inovații non-Normale
- Aproape de  $\alpha + \beta = 1$ , parametrul este lîngă frontiera regiunii de staționaritate în covarianță: intervalele Wald nu sînt fiabile; folosiți verosimilitatea profil sau bootstrap restrîns la spațiul parametrilor [Andrews \(1999\)](#)

## Anexă: Inferența cheie pe capitole (7/17)

- **Capitolul 6, Volatilitate multivariată și dependență:** Copulele separă distribuțiile marginale de dependență; dependența în cozi determină pierderile comune
- DCC se estimează în doi pași: erorile standard din pasul al doilea trebuie să țină cont de volatilitățile din primul pas [Engle \(2002\)](#)
- Corelația în criză față de perioada calmă:  $\rho$  crește mecanic odată cu volatilitatea; testăm pe corelația ajustată [Forbes & Rigobon \(2002\)](#)

$$\rho^* = \frac{\rho}{\sqrt{1 + \delta(1 - \rho^2)}}$$

- $\rho$ : corelația măsurată în criză;  $\delta$ : creșterea relativă a varianței pieței-sursă de la perioada calmă la criză;  $\rho^* < \rho$  când  $\delta > 0$



## Anexă: Inferența cheie pe capitole (8/17)

- **Capitolul 7, VaR și Expected Shortfall:** Simularea istorică filtrată și EVT condiționată reacționează la volatilitate în câteva zile McNeil & Frey (2000)
- VaR istoric, randamente i.i.d. cu densitate continuă  $f(q_\alpha) > 0$

$$\sqrt{T}(\hat{q}_\alpha - q_\alpha) \Rightarrow N(0, ; \alpha(1 - \alpha)/f(q_\alpha)^2)$$

- ▶  $q_\alpha$ : cuantila  $\alpha$  a randamentelor,  $\text{VaR}_\alpha = -q_\alpha$ ;  $\hat{q}_\alpha$ : cuantila empirică;  $f$ : densitatea randamentelor; în coadă  $f$  este mică, deci estimarea este zgomotoasă
- ▶ La dependență,  $\alpha(1 - \alpha)$  devine dispersia de termen lung a indicatorilor  $\mathbb{1}\{r_t \leq q_\alpha\}$  (1 dacă condiția este îndeplinită, 0 altfel)
- ES este media celor mai mari  $\alpha T$  pierderi: cu  $\alpha T$  de câteva zeci și un tail index în jur de 3, dispersia lui este dominată de una sau două zile

## Anexă: Inferența cheie pe capitole (9/17)

- **Capitolul 8, Backtesting și evaluarea prognozelor de risc:** Ierarhizăm prognozele (VaR, ES) cu un scor consistent (FZ0) și teste Diebold–Mariano [Fissler & Ziegel \(2016\)](#)
- Backtesting-ul VaR: numărul și momentul depășirilor (formulele: Pasul 4 al studiului de caz)
  - ▶ Kupiec  $LR_{uc} \sim \chi_1^2$  (este rata depășirilor egală cu  $\alpha$ ?); Christoffersen  $LR_{ind} \sim \chi_1^2$  (este o depășire independentă de cea de ieri?)
  - ▶ Testul DQ: regresăm  $I_t - \alpha$  pe indicatorii depășirilor anterioare și  $Var_t$ ,  $I_t = 1$  dacă pierderea depășește  $Var_t$ ;  $DQ \sim \chi_k^2$ ,  $k$  fiind numărul de regresori [Engle & Manganelli \(2004\)](#)
- Puterea este mică: la  $T = 250$ , testul Kupiec de 5% detectează o rată reală de 2% doar în 24% din cazuri; comparăm modelele cu teste de capacitate predictivă condiționată [Giacomini & White \(2006\)](#)

## Anexă: Inferența cheie pe capitole (10/17)

- ▣ **Capitolul 9, Volatilitate realizată:** Randamentele împărțite la volatilitatea realizată au o distribuție apropiată de distribuția Normală
- ▣ Erorile HAR sînt heteroscedastice și, pentru ținte pe mai multe zile care se suprapun, autocorelate: folosiți erori standard HAC; prognozele se compară cu teste DM pe o funcție de pierdere robustă [Patton \(2011\)](#)
- ▣ Zgomotul de microstructură deplasează în sus  $RV$  (suma pătratelor randamentelor intraday) la frecvențe înalte: estimatorii pe două scale elimină deplasarea [Zhang, Mykland & Aït-Sahalia \(2005\)](#)
- ▣ **Capitolul 10, Microstructura pieței:** Lichiditatea variază în funcție de ora din zi și de VIX și dispare în perioadele de stres
- ▣ Spread-ul Roll: oscilația între bid și ask face ca variațiile consecutive ale prețului să fie negativ corelate

$$s_{\text{Roll}} = 2\sqrt{-\text{Cov}(\Delta p_t, \Delta p_{t-1})}$$

- ▶  $\Delta p_t$ : variația prețului de tranzacționare; cînd covarianța de selecție este pozitivă, estimatorul nu este definit, deci raportați cît de des se întîmplă
- ▣ O primă de ilichiditate este o afirmație privind secțiunea transversală: Fama–MacBeth cu erori Newey–West și corecția Shanken [Shanken \(1992\)](#)

## Anexă: Inferența cheie pe capitole (11/17)

- ▣ **Capitolul 11, Modele în timp continuu:** Salturile explică cozile, volatilitatea stohastică explică volatility clustering
- ▣ Normalitatea randamentelor log GBM: Jarque–Bera  $JB = \frac{T}{6} (S^2 + (K - 3)^2/4) \sim \chi^2_2$  respinge peste tot
  - ▶  $S$ : asimetria de selecție;  $K$ : kurtosis-ul de selecție; 0 și 3 sub distribuția Normală
  - ▶ Salturile:  $(RV - BV)$  standardizat  $\Rightarrow N(0, 1)$  [Barndorff-Nielsen & Shephard \(2006\)](#);  $BV$ : variația bipower, o sumă de produse ale valorilor absolute ale randamentelor intraday vecine, robustă la salturi
- ▣ Testul este zilnic: pe multe zile, controlați numărul de salturi detectate fals

## Anexă: Inferența cheie pe capitole (12/17)

▣ **Capitolul 12, Opțiuni și suprafața de volatilitate:** Smile-ul și skew-ul volatilității reflectă aversiunea față de riscul de crah

▣ Prima de risc a varianței

$$VRP_t = VIX_t^2 - RV_{t,t+21}$$

▶  $VIX_t^2$ : varianța așteptată neutră la risc pentru luna următoare;  $RV_{t,t+21}$ : varianța realizată în următoarele 21 de zile de tranzacționare

▶ Valorile consecutive se suprapun, deci media cere erori Newey–West cu cel puțin 21 de laguri

▣ Volatilitatea implicită este o prognoză neutră la risc: prima, nu eroarea de prognoză, explică cea mai mare parte a diferenței

## Anexă: Inferența cheie pe capitole (13/17)

- **Capitolul 13, Machine Learning în finanțe:** Purged cross-validation, meta-labelling și raportul Sharpe deflatat [Bailey & López de Prado \(2014\)](#)
- Selecția dintre  $N$  strategii: raportul Sharpe deflatat testează  $SR > E[\max_N \widehat{SR}]$  sub ipoteza absenței abilității [Bailey & López de Prado \(2014\)](#)
  - ▶  $E[\max_N \widehat{SR}]$ : cel mai mare raport Sharpe estimat așteptat dintre  $N$  strategii cu raport Sharpe adevărat zero; crește odată cu  $N$
- Validarea încrucișată pe serii de timp trebuie să elimine din antrenare observațiile ale căror etichete se suprapun cu setul de test (purging) și să lase o pauză după acesta (embargo), altfel acuratețea este supraestimată

## Anexă: Inferența cheie pe capitole (14/17)

- **Capitolul 14, Deep learning și modele fundamentale pentru serii de timp:** Modelele se evaluează cu instrumentele din Capitolul 8, după publicarea ponderilor lor
- Testul DM pe diferențele QLIKE, cu dispersie HAC [Diebold & Mariano \(1995\)](#)

$$t_{DM} = \frac{\bar{d}}{\sqrt{\hat{\Omega}/T}} \Rightarrow N(0, 1)$$

- ▶  $d_t$ : QLIKE a modelului 1 minus QLIKE a modelului 2 în ziua  $t$ ,  $\bar{d}$  media ei pe  $T$  zile;  $\hat{\Omega}$ : dispersia de termen lung HAC a lui  $d_t$ ; valid pentru comparații între modele neimbricate
- Cu multe modele candidate, mulțimea de încredere a modelelor (MCS) controlează eroarea la nivel de familie [Hansen, Lunde & Nason \(2011\)](#)

## Anexă: Inferența cheie pe capitole (15/17)

- **Capitolul 15, LLM-uri și analiza sentimentului:** Reprezentările vectoriale ale textului intră în modele ca variabile explicative
- Regresia predictivă  $r_{t+1} = a + bS_t + \varepsilon_{t+1}$ 
  - ▶  $S_t$ : scorul de sentiment din ziua  $t$ ;  $b$ : panta predictivă; un  $S_t$  persistent, cu inovații corelate cu randamentele, introduce un bias în  $\hat{b}$  și distorsionează testul  $t$  [Stambaugh \(1999\)](#)
- Rezultatele clasificatorilor pe aceleași texte sînt împerecheate: comparăm acuratețile cu testul McNemar exact, nu prin două intervale separate
- **Capitolul 16, Active digitale și DeFi:** Stablecoin-urile, automated market makers și ETF-urile spot leagă crypto de finanțele tradiționale
- Modele factoriale crypto: GRS și Fama–MacBeth cu corecția Shanken [Gibbons, Ross & Shanken \(1989\)](#), [Shanken \(1992\)](#); cozile groase cer versiuni HAC sau bootstrap
- Cozile: tail index-uri Hill cu intervale de încredere, nu kurtosis de selecție ([Capitolul 1](#)); o ruptură într-o corelație se testează cu dată necunoscută: statistica sup-Wald este cea mai mare statistică Wald pe toate datele candidate [Andrews \(1993\)](#)



## Anexă: Inferența cheie pe capitole (16/17)

- **Capitolul 17, Bule și crahuri:** Testele de rădăcină unitară pe coada din dreapta datează începutul și sfârșitul episoadelor explozive
- Testele de bulă: cea mai mare statistică ADF pe coada din dreapta, pe multe ferestre

$$GSADF = \sup_{r_2 \in [r_0, 1]} \sup_{r_1 \in [0, r_2 - r_0]} ADF_{r_1}^{\prime 2}$$

- ▶  $ADF_{r_1}^{\prime 2}$ : statistica ADF (Augmented Dickey–Fuller) pe fracțiunea de eșantion  $[r_1, r_2]$ ;  $r_0$ : fereastra minimă; SADF fixează  $r_1 = 0$
- ▶ Sub ipoteza rădăcinii unitare, SADF și GSADF converg către funcționale ale mișcării browniene; valorile critice depind doar de  $r_0$  Phillips, Shi & Yu (2015)
- Schimbările de volatilitate distorsionează nivelul testului: folosiți valori critice obținute prin wild bootstrap; controlați multiplicitatea datării

## Anexă: Inferența cheie pe capitole (17/17)

- **Capitolul 18, Risc sistemic și rețele:** CoVaR (VaR-ul sistemului condiționat de dificultățile unei instituții), SRISK și rețelele de contagiune măsoară contribuția fiecărei instituții
- $\Delta\text{CoVaR}$ : variația VaR-ului sistemului când instituția  $i$  trece de la mediană la stres

$$\Delta\text{CoVaR}^i = \text{CoVaR}_{\alpha}^{\text{sys}|X^i=-} - \text{CoVaR}_{\alpha}^{\text{sys}|X^i=\text{median}}$$

- ▶  $X^i$ : randamentul instituției  $i$ ;  $\text{CoVaR}_{\alpha}^{\text{sys}|}$ : VaR  $\alpha$  al randamentului sistemului, condiționat de starea lui  $i$ ; diferențele dintre bănci: teste pe perechi pe extrageri bootstrap comune pe blocuri, cu corecția Holm
- ▶ La  $\alpha = 1\%$  doar aproximativ 40 de zile în coadă, deci estimarea ridică problemele specifice cuantilelor extreme
- SRISK: LRMES (pierderea așteptată a unei bănci când piața scade cu peste 10% în 22 de zile) simulat din GJR–GARCH + DCC [Brownlees & Engle \(2017\)](#); tabelele de conectivitate cer intervale bootstrap și modele VAR (vector autoregresive) cu shrinkage

## Anexă: idei de proiect, Partea C a fiecărui seminar (1/2)

| Cap. | Întrebarea deschisă (link către seminar)                                                   |
|------|--------------------------------------------------------------------------------------------|
| 0    | <a href="#">Au schimbat ETF-urile spot corelația Bitcoin cu acțiunile?</a>                 |
| 1    | <a href="#">A scăzut autocorelația BET-TR după reclasificarea FTSE?</a>                    |
| 2    | <a href="#">A devenit BVB mai eficientă după reclasificarea FTSE din 2020?</a>             |
| 3    | <a href="#">Există prime factoriale la Bursa de Valori București?</a>                      |
| 4    | <a href="#">Un portofoliu optim de blue chips BVB în RON</a>                               |
| 5    | <a href="#">Este volatilitatea pieței românești determinată de SUA?</a>                    |
| 6    | <a href="#">Au devenit acțiunile din România și din zona euro mai integrate după 2020?</a> |
| 7    | <a href="#">Capitalul pentru un portofoliu BVB față de un portofoliu S&amp;P 500</a>       |

- ☐ Fiecare seminar oferă datele, o metodă de pornire și o analiză de referință discutată la seminar

## Anexă: idei de proiect, Partea C a fiecărui seminar (2/2)

| Cap. | Întrebarea deschisă (link către seminar)                                                     |
|------|----------------------------------------------------------------------------------------------|
| 8    | Ce model de risc ați certifica pentru portofoliul de tranzacționare al unei bănci românești? |
| 9    | Este volatilitatea Bitcoin mai previzibilă decât cea a S&P 500?                              |
| 10   | Există o primă de ilichiditate pe BVB?                                                       |
| 11   | Ce model în timp continuu se potrivește pentru BET și Bitcoin?                               |
| 12   | Este prima de risc a varianței un semnal tranzacționabil?                                    |
| 13   | Este un model fundațional superior boosting-ului?                                            |
| 14   | Poate un model fundațional zero-shot să înlocuiască GARCH pentru BET?                        |
| 15   | Aduce sentimentul titlurilor câștig după costuri?                                            |
| 16   | Este Bitcoin un activ alternativ, un activ de risc sau un hedge?                             |
| 17   | Există o bulă AI?                                                                            |
| 18   | Cît de expuse sînt băncile românești la stresul bancar din zona euro?                        |

- Capitolul 20 (volatilitate realizată cu semnături, datele VOLARE) se potrivește și pentru un proiect de prognoză

## Anexă: de la idee la proiect

- ▣ Replicați mai întâi: un tabel sau o figură publicată dintr-un articol din spatele ideii (pasul 1)
- ▣ Restrângeți-o: o piață, o perioadă, un număr de prognozat sau de testat
  - ▶ Exemplu: Seminarul 8 devine „Care dintre HS, FHS și GARCH-EVT produce un VaR 1% corect pentru un portofoliu 50/50 format din BET și EUR (cursul EUR/RON) în 2015–2026?”
- ▣ Extindeți-o: o a doua piață, un model nou, un eșantion mai lung sau mai recent
  - ▶ Exemplu: adăugați un model fundațional ([Capitolul 14](#)) ca filtru de volatilitate în FHS
- ▣ Păstrați analiza de referință ca reper și încercați să o îmbunătățiți în mod onest

## Anexă: convențiile de date pentru proiect

- Folosiți datele cursului unde se poate: serii zilnice pentru indici, ETF-uri, acțiuni BVB, crypto și cursuri de schimb, plus date intraday
  - ▶ Surse publice: cursurile de referință BNR, FRED, Kenneth French Data Library, DefiLlama; arhiva BVB pentru indicii românești
- Aplicați convențiile cursului
  - ▶ Prețuri ajustate pentru ETF-uri și acțiuni, valori de închidere pentru indici, cursuri de schimb și crypto
  - ▶ Eliminați zilele de sărbătoare în care furnizorul a repetat prețul anterior și cotațiile de weekend când piața este închisă; anualizați cu frecvența reală
  - ▶ Mai multe active: aliniați întâi prețurile pe zilele comune, apoi calculați randamentele
- Căutați valorile eronate înainte de modelare: salturile de  $\pm 50\%$  în prețurile ajustate sînt de obicei erori de date

## Anexă: lista de verificare pentru o evaluare onestă

### Înainte să vă uitați la rezultate

- Scrieți ipoteza, reperul și funcția de pierdere
- Fixați fereastra de estimare și perioada de test
- Decideți câte modele și parametri veți încerca și corecția pentru ei
- Scrieți strategia de identificare și puterea testului principal

### Cînd raportați

- Doar rezultate în afara eșantionului pentru afirmații despre prognoză
- Fiecare rezultat principal însoțit de eroare standard, CI sau p-value
- Costuri pentru strategiile de tranzacționare; subperioade și o a doua piață pentru robustețe
- Ce **nu** a funcționat și de ce

## Anexă: greșeli frecvente care costă puncte

- ▣ O întrebare care se schimbă după ce se cunosc rezultatele
- ▣ Ajustarea în eșantion prezentată drept putere de prognoză
- ▣ Niciun reper sau un reper slab, ales pentru a fi ușor depășit
- ▣ Cifre fără incertitudine; multe teste fără corecție
- ▣ Grafice fără unități, legende peste date, acronime neexplicate
- ▣ Cod care nu rulează sau cifre din raport pe care codul nu le produce
- ▣ Rezultate AI păstrate fără verificare: utilizare nedeclarată, cod neverificat, referințe care nu există



## Anexă: erori nestandard, date și metodă

- **Date:** toate tranzacțiile cu contractele futures pe indicele Euro Stoxx 50, 2002–2018, 720 de milioane de înregistrări, pentru fiecare parte a tranzacției se indică dacă aceasta operează pentru un client sau în cont propriu (Sec. I.A)
  - ▶ Șase ipoteze, fiecare „nicio tendință anuală” pentru: eficiența pieței, spread-ul bid–ask realizat, ponderea clienților în volum, spread-ul realizat pe ordinele clienților, ponderea ordinelor la piață în ordinele clienților, venitul brut din tranzacționare al clienților
  - ▶ Fiecare echipă își alege propria măsură și raportează variația anuală medie în %, cu eroarea ei standard (SE)
- **Patru etape** în 2021: analiza independentă (articol și cod); feedback de la doi evaluatori; distribuirea celor mai bune cinci lucrări; estimările finale, fără obligația de a furniza codul care le reproduce (Sec. I.A)
  - ▶ Un plan de analiză a fost înregistrat public înainte de începerea experimentului (Sec. I.A)
- **Calitatea:** calitatea echipei (prima componentă principală a cinci indicatori), scorul de reproductibilitate 0–100 acordat de agenția de certificare Cascad, nota acordată de evaluatori, din care s-a scăzut media (Sec. I.B)
  - ▶ Regresii cuantile ale estimărilor la percentilele 10, 25, 50, 75 și 90; un IQR care scade înseamnă o dispersie mai mică (Sec. I.C)
- **Inferența:** fiecare estimare este testată față de estimarea mediană, cu corecție Bonferroni la un nivel de semnificație de 0,5% pentru familia de teste (Sec. I.C)
  - ▶ Analiza multivers: echipele raportează opțiunile metodologice din Tabelul V; statistica Anderson–Darling pentru  $k$  eșantioane ierarhizează deciziile după diferențele dintre distribuțiile estimărilor (Sec. II.C)

## Anexă: Erori nestandard, detaliile replicării

- **Deciziile metodologice (bifurcațiile) din Tabelul V:** valorile extreme (nimic; măsura anuală winsorizată sau cu valorile din afara centilelor 2,5 și 97,5 eliminate), măsura (raportul varianțelor zi la săptămână, raportul varianțelor zi la lună,  $R^2$  al unui model AR), modelul (tendință liniară, diferență logaritmică, diferență relativă)
  - ▶ Datele zilnice permit comparațiile zi-săptămână și zi-lună ( $VR(5)$ ,  $VR(21)$ ); frecvențele intrazilnice ale măsurii din Tabelul V necesită date intrazilnice
- **Explozia diferențelor relative:**  $m_t = |VR - 1|$  sau  $R^2$  este aproape de zero în unii ani; articolul găsește aceeași explozie, o mediană de  $-23\,000\%$  pe date zilnice (Fig. 7)
  - ▶ Fără tendință,  $m_t$  staționar: panta liniară și variația logaritmică medie sînt centrate în zero, dar pentru  $m_t$  independente,  $\mathbb{E}(m_t/m_{t-1}) = \mathbb{E}m \cdot \mathbb{E}(1/m) \geq 1$  (Jensen), deci variația relativă medie este pozitivă
- **Statistica Anderson-Darling:** statistica standardizată este centrată în zero pentru distribuții egale ale unor eșantioane independente; cele 27 de estimări sînt puternic corelate, deci valorile critice tabelate și p-value-urile nu se aplică
  - ▶ Articolul, 164 de echipe: 6,7 pp față de 3,4 pp (Tabelul I, Panoul C); în mini-multivers, IQR-ul depășește acest reper pentru BET, nu și pentru Euro Stoxx 50

## Anexă: bucla descoperirii, prompturi (1/2)

- **Săptămîna 1, întrebarea:** transformăm o idee în  $H_0/H_1$ , cu o țintă de replicare
  - ▶ „Iată ideea noastră din Partea C a Seminarului N. Dă trei versiuni mai precise și testabile, tabelul publicat pe care l-ar replica fiecare și seriile din datele cursului de care are nevoie.”
- **Săptămînilor 1–2, literatura și ținta:** cifra de replicat este una pe care ați văzut-o în PDF
  - ▶ „Listează cele mai citate și cele mai recente articole despre această întrebare, cu DOI; pentru fiecare, estimarea principală, tabelul și eșantionul.”
  - ▶ Verificați fiecare DOI pe Crossref; căutați cu Semantic Scholar, Elicit sau Google Scholar; deschideți personal tabelul
- **Săptămîna 2, ipoteze și preînregistrare,** fixate în scris printr-un commit datat înaintea primului rezultat
  - ▶ „Pentru  $H_0$  și  $H_1$ , listează ipotezele concurente și implicația care le separă; apoi scrie o preînregistrare: eșantion, filtre, ferestre, teste, corecție.”
  - ▶ Istoricul commit-urilor documentează înregistrarea planului înaintea rezultatelor

## Anexă: bucla descoperirii, prompturi (2/2)

- **Săptămânile 2–3, cod și replicare:** tabelul replicat devine un test în repository
  - ▶ „Scrie o funcție care reproduce fiecare celulă a tabelului publicat din datele cursului și o aserțiune cu toleranța pe care o acceptăm.”
- **Săptămânile 4–5, extindere și robustețe:** rulăm toată grila preînregistrată
  - ▶ „Iată rezultatele tuturor specificațiilor analizate. Ce concluzii rămân valabile după corecția Holm și pe care le-ar numi un recenzent căutare oportunistă în date (data snooping)?”
- **Înainte de susținere, critica:** asistentul întreabă, echipa răspunde
  - ▶ „Joacă rolul examinatorului la susținerea orală: pune cele mai dificile zece întrebări despre identificare, inferență și date. Nu răspunde la ele.”
  - ▶ Echipa răspunde fără AI, ca la susținerea propriu-zisă
- **Raportul:** distribuția rezultatelor pe grilă, nu celula cea mai bună; prompturile în AI\_USE.md, erorile detectate în AI\_ERRORS.md

## Anexă: verificările cercetătorului

- **Ținta de replicare există:** cifra, tabelul și eșantionul luate din articol, nu din rezumatul asistentului
  - ▶ Test: raportul citează pagina și tabelul; un al doilea membru găsește acolo aceeași cifră
- **Planul precede rezultatele**
  - ▶ Test: în istoricul commit-urilor, preînregistrarea precede primul fișier de rezultate
- **Bifurcațiile analizei:** mai multe specificații încercate decât raportate
  - ▶ Test: fiecare rulare își scrie configurația și rezultatul într-un jurnal; raportul le dă numărul și corectează familia
- **Reproductibilitatea:** cifre introduse manual în raport
  - ▶ Test: o clonă nouă și o singură comandă regenerează fiecare cifră pînă la ultima zecimală raportată
- **Înțelegerea:** fiecare membru poate deduce formula-cheie și poate apăra fiecare alegere
  - ▶ Test: o susținere de probă în echipă, fără AI, cu o săptămînă înaintea celei reale

## Bibliografie (1/5)

- ▣ Abadie, A., Diamond, A., Hainmueller, J. (2010). Synthetic control methods for comparative case studies: estimating the effect of California's tobacco control program. *Journal of the American Statistical Association*, 105(490), 493–505.
- ▣ Andrews, D.W.K. (1993). Tests for parameter instability and structural change with unknown change point. *Econometrica*, 61(4), 821–856.
- ▣ Andrews, D.W.K. (1999). Estimation when a parameter is on a boundary. *Econometrica*, 67(6), 1341–1383.
- ▣ Athreya, K.B. (1987). Bootstrap of the mean in the infinite variance case. *Annals of Statistics*, 15(2), 724–731.
- ▣ Bailey, D.H., Borwein, J., López de Prado, M., Zhu, Q.J. (2017). The probability of backtest overfitting. *Journal of Computational Finance*, 20(4), 39–69.
- ▣ Bailey, D.H., López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- ▣ Barndorff-Nielsen, O.E., Shephard, N. (2006). Econometrics of testing for jumps in financial economics using bipower variation. *Journal of Financial Econometrics*, 4(1), 1–30.
- ▣ Black, F., Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 637–654.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- ▣ Brownlees, C., Engle, R.F. (2017). SRISK: a conditional capital shortfall measure of systemic risk. *Review of Financial Studies*, 30(1), 48–79.
- ▣ Chow, K.V., Denning, K.C. (1993). A simple multiple variance ratio test. *Journal of Econometrics*, 58(3), 385–401.

## Bibliografie (2/5)

- ▣ Christoffersen, P.F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- ▣ Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification: how inefficient is the  $1/N$  portfolio strategy?. *Review of Financial Studies*, 22(5), 1915–1953.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R. (2002). Dynamic conditional correlation: a simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3), 339–350.
- ▣ Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- ▣ Engle, R.F., Manganelli, S. (2004). CAViaR: conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.
- ▣ Fama, E.F. (1970). Efficient capital markets: a review of theory and empirical work. *Journal of Finance*, 25(2), 383–417.
- ▣ Fissler, T., Ziegel, J.F. (2016). Higher order elicibility and Osband's principle. *Annals of Statistics*, 44(4), 1680–1707.
- ▣ Forbes, K.J., Rigobon, R. (2002). No contagion, only interdependence: measuring stock market comovements. *Journal of Finance*, 57(5), 2223–2261.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.

## Bibliografie (3/5)

- ▣ Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- ▣ Gibbons, M.R., Ross, S.A., Shanken, J. (1989). A test of the efficiency of a given portfolio. *Econometrica*, 57(5), 1121–1152.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ Härdle, W.K., Chen, C.Y.-H., Overbeck, L. (Eds.) (2017). *Applied Quantitative Finance*, 3rd ed. Springer.
- ▣ Harvey, C.R. (2017). Presidential address: the scientific outlook in financial economics. *Journal of Finance*, 72(4), 1399–1440.
- ▣ Harvey, C.R., Liu, Y. (2020). False (and missed) discoveries in financial economics. *Journal of Finance*, 75(5), 2503–2553.
- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the cross-section of expected returns. *Review of Financial Studies*, 29(1), 5–68.
- ▣ Hill, B.M. (1975). A simple general approach to inference about the tail of a distribution. *Annals of Statistics*, 3(5), 1163–1174.
- ▣ Hou, K., Xue, C., Zhang, L. (2020). Replicating anomalies. *Review of Financial Studies*, 33(5), 2019–2133.
- ▣ Jensen, T.I., Kelly, B., Pedersen, L.H. (2023). Is there a replication crisis in finance?. *Journal of Finance*, 78(5), 2465–2518.
- ▣ Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- ▣ Ledoit, O., Wolf, M. (2008). Robust performance hypothesis testing with the Sharpe ratio. *Journal of Empirical Finance*, 15(5), 850–859.



## Bibliografie (4/5)

- ▣ Lo, A.W. (2002). [The statistics of Sharpe ratios](#). *Financial Analysts Journal*, 58(4), 36–52.
- ▣ Lo, A.W., MacKinlay, A.C. (1988). [Stock market prices do not follow random walks: evidence from a simple specification test](#). *Review of Financial Studies*, 1(1), 41–66.
- ▣ Lobato, I., Nankervis, J.C., Savin, N.E. (2001). [Testing for autocorrelation using a modified Box–Pierce Q test](#). *International Economic Review*, 42(1), 187–205.
- ▣ López de Prado, M. (2018). [Advances in Financial Machine Learning](#). Wiley.
- ▣ Markowitz, H. (1952). [Portfolio selection](#). *Journal of Finance*, 7(1), 77–91.
- ▣ McNeil, A.J., Frey, R. (2000). [Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach](#). *Journal of Empirical Finance*, 7(3–4), 271–300.
- ▣ McNeil, A.J., Frey, R., Embrechts, P. (2015). [Quantitative Risk Management: Concepts, Techniques and Tools](#), revised ed. Princeton University Press.
- ▣ Menkveld, A.J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). [Nonstandard errors](#). *Journal of Finance*, 79(3), 2339–2390.
- ▣ Nolde, N., Ziegel, J.F. (2017). [Elicitability and backtesting: perspectives for banking regulation](#). *Annals of Applied Statistics*, 11(4), 1833–1874.
- ▣ Patton, A.J. (2011). [Volatility forecast comparison using imperfect volatility proxies](#). *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Ziegel, J.F., Chen, R. (2019). [Dynamic semiparametric models for expected shortfall \(and value-at-risk\)](#). *Journal of Econometrics*, 211(2), 388–413.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). [Information entropy and measures of market risk](#). *Entropy*, 19(5), 226.

## Bibliografie (5/5)

- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- ▣ Pele, D.T., Wesselhöfft, N., Härdle, W.K., Kolossiaty, M., Yatracos, Y.G. (2023). Are cryptos becoming alternative assets?. *European Journal of Finance*, 29(10), 1064–1105.
- ▣ Phillips, P.C.B., Shi, S., Yu, J. (2015). Testing for multiple bubbles: historical episodes of exuberance and collapse in the S&P 500. *International Economic Review*, 56(4), 1043–1078.
- ▣ Shanken, J. (1992). On the estimation of beta-pricing models. *Review of Financial Studies*, 5(1), 1–33.
- ▣ Simonsohn, U., Simmons, J.P., Nelson, L.D. (2020). Specification curve analysis. *Nature Human Behaviour*, 4(11), 1208–1214.
- ▣ Stambaugh, R.F. (1999). Predictive regressions. *Journal of Financial Economics*, 54(3), 375–421.
- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed. Wiley.
- ▣ White, H. (2000). A reality check for data snooping. *Econometrica*, 68(5), 1097–1126.
- ▣ Zhang, L., Mykland, P.A., Aït-Sahalia, Y. (2005). A tale of two time scales: determining integrated volatility with noisy high-frequency data. *Journal of the American Statistical Association*, 100(472), 1394–1411.