



Modelarea piețelor financiare

Capitolul 20 (capitol special): Signaturi de căi și volatilitate realizată — un studiu de cercetare



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AAPL: Apple Inc. (Nasdaq ticker) (Apple Inc. (simbolul bursier Nasdaq))
- ACM: Association for Computing Machinery (Asociația pentru Mașini de Calcul)
- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model) (model autoregresiv)
- ARIMA: AutoRegressive Integrated Moving Average (model) (model autoregresiv integrat cu medie mobilă)
- AUD: Australian Dollar (ISO 4217 code) (dolarul australian (cod ISO 4217))
- BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BPQ: Bollerslev–Patton–Quaedvlieg (insanity filter of the HARQ paper) (Bollerslev–Patton–Quaedvlieg (filtrul din articolul HARQ))
- CAD: Canadian Dollar (ISO 4217 code) (dolarul canadian (cod ISO 4217))
- CL: Crude oil (WTI light sweet) futures, NYMEX ticker (contractul futures pe petrol (WTI), simbolul NYMEX)
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DE: Deutschland (jurisdiction of the CC licence) (Germania (jurisdicția licenței CC))
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ES: E-mini S&P 500 futures (CME ticker) (contractul futures E-mini S&P 500 (simbolul CME))
- FDR: False Discovery Rate (rata descoperirilor false)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- FX: Foreign eXchange (piața valutară)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GC: Gold futures, COMEX ticker (contractul futures pe aur, simbolul COMEX)
- GW: Giacomini–White (test) (testul Giacomini–White)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- HARQ: HAR model with Realised Quarticity (model HAR cu cvarticitatea realizată)
- JPM: JPMorgan Chase & Co. (NYSE ticker) (JPMorgan Chase & Co. (simbolul bursier NYSE))
- KDD: Knowledge Discovery and Data Mining (ACM SIGKDD conference) (descoperirea cunoașterii și mineritul datelor (conferința ACM SIGKDD))

Acronime folosite în acest material (2/2)

- LARS: Least-Angle RegreSsion (algorithm) (algoritmul regresiei unghiului minim)
- LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- MCS: Model Confidence Set (mulțimea de modele de încredere)
- MSE: Mean Squared Error (eroarea pătratică medie)
- NG: Natural Gas futures, NYMEX ticker (contractul futures pe gaze naturale, simbolul NYMEX)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- PDE: Partial Differential Equation (ecuație cu derivate parțiale)
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- RQ: Realised Quarticity (cvarticitatea realizată)
- RV: Realised Variance (varianța realizată)
- SHAR: Semivariance HAR model (model HAR cu semivarianțe)
- TSLA: Tesla, Inc. (Nasdaq ticker) (Tesla, Inc. (simbolul bursier Nasdaq))
- VOLARE: VOLatility Archive for Realized Estimates (database) (arhiva de estimatori realizați ai volatilității (bază de date))
- XOM: Exxon Mobil Corporation (NYSE ticker) (Exxon Mobil Corporation (simbolul bursier NYSE))

Cuprins

Motivație

Măsurile realizate: ce prognoză

Baza de date VOLARE

Reperete: familia HAR

Signaturi de căi

Articolul: Gu et al. (2024)

Designul transferului (preînregistrat)

Rezultate

Ablații și robustețe

Limite și discuție

AI pentru descoperire științifică


Concluzii

Bibliografie

Ce face acest capitol special

Un studiu de cercetare, de la început la sfârșit

- ▣ Luăm o metodă publicată pentru o altă problemă: prognoza tarifelor de transport la Amazon [Gu et al. \(2024\)](#)
- ▣ O transferăm la o problemă centrală a cursului: prognoza varianței realizate zilnice
- ▣ Fixăm designul înainte de a vedea rezultatele în afara eșantionului, apoi raportăm orice rezultă
- ▣ Date: 50 de active din baza VOLARE (VOLatility Archive for Realized Estimates, arhiva de estimatori realizați) [Cipollini et al. \(2026\)](#)



Wall Street și Bursa din New York, 25 martie 2020

Foto: [Billie Grace Ward \(2020\)](#); CC BY 2.0; [Wikimedia Commons](#)

De ce prognozăm varianța realizată?

- ▣ Volatilitatea este intrarea aproape a oricărui număr de risc din acest curs
 - ▶ Măsurile ale riscului de coadă (Capitolul 7), prețuri de opțiuni (Capitolul 12), ponderi de portofoliu (Capitolul 4)
- ▣ Datele intraday fac varianța zilnică aproape observabilă: varianța realizată (Realised Variance, RV, Capitolul 9)
 - ▶ Astfel, prognoza volatilității devine o problemă de regresie cu o țintă zgomotoasă, dar fără model
- ▣ Reperul este greu de bătut: modelul HAR [Corsi \(2009\)](#) (Capitolul 9)
 - ▶ Trei medii ale RV trecute; liniar; estimat prin OLS într-o secundă
- ▣ Orice metodă nouă trebuie să bată HAR în afara eșantionului, pe multe active, cu un test corect

Întrebarea de cercetare

- ▣ Gu et al. descriu o fereastră recentă a unei serii ca o **cale** și o rezumă prin **signatura** ei
 - ▶ Trăsăturile din semnătură intră într-o regresie liniară rară (LASSO în doi pași)
 - ▶ Perioadele trecute a căror cale seamănă cu cea de azi primesc o pondere mai mare (un nucleu al semnăturii)
- ▣ Ei raportează o creștere de peste cinci ori a acurateții față de o prognoză din industrie pentru tarifele de transport
 - ▶ Întrebare: îmbunătățește aceeași rețetă modelele de tip HAR pentru varianța realizată?
- ▣ Două ingrediente separate de testat: trăsăturile din semnătură și ponderile date de nucleu

Varianța realizată și variația pătratică

- ▣ Prețul logaritmic p_t cu $dp_t = \mu_t dt + \sigma_t dW_t + dJ_t$; ziua t împărțită în M randamente intraday $r_{t,i}$
 - ▶ $RV_t = \sum_{i=1}^M r_{t,i}^2 \xrightarrow{M \rightarrow \infty} \int_{t-1}^t \sigma_s^2 ds + \sum_{t-1 < s \leq t} (\Delta J_s)^2$ Barndorff-Nielsen & Shephard (2002)
- ▣ Fără salturi, limita este varianța integrată IV_t ; eroarea este mixt Normală
 - ▶ $\sqrt{M}(RV_t - IV_t) \Rightarrow MN(0, 2IQ_t)$, $IQ_t = \int_{t-1}^t \sigma_s^4 ds$ (cvarticitatea integrată)
- ▣ Zgomotul de microstructură deplasează eșantionarea foarte fină; randamentele la cinci minute sunt compromisul standard (Capitolul 9)
- ▣ Capitolul 9 deduce aceste rezultate; aici le folosim ca atare

Măsurile realizate din VOLARE

- ▣ Semivarianțele [Barndorff-Nielsen, Kinnebrock & Shephard \(2010\)](#): $RV_t^+ = \sum_i r_{t,i}^2 1\{r_{t,i} > 0\}$,
 $RV_t^- = \sum_i r_{t,i}^2 1\{r_{t,i} < 0\}$
 - ▶ Se adună: $RV_t = RV_t^+ + RV_t^-$ (în VOLARE, până la precizia mașinii)
- ▣ Cvarticitatea realizată: $RQ_t = \frac{M}{3} \sum_i r_{t,i}^4 \rightarrow IQ_t$, scala erorii de măsurare a RV
- ▣ Variația bipower (robustă la salturi), nucleul realizat (robust la zgomot) [Barndorff-Nielsen et al. \(2008\)](#), estimatori bazați pe amplitudine
- ▣ Ținta acestui capitol: RV la cinci minute (rv5)
 - ▶ Pe 400 de active, puțini estimatori bat RV la cinci minute ca aproximare a varianței zilnice [Liu, Patton & Sheppard \(2015\)](#)
 - ▶ Semivarianțele și cvarticitatea ei sunt pe aceeași grilă, deci SHAR și HARQ folosesc intrări consistente

Ținte și funcții de pierdere

- Orizontul h : $RV_{t+1:t+h} = \frac{1}{h} \sum_{j=1}^h RV_{t+j}$, $h \in \{1, 5, 22\}$; modelele logaritmice prognozează $\ln RV_{t+1:t+h}$
 - ▶ Înapoi la nivel cu corecția log-Normală $F_t = \exp(\hat{y}_t + \hat{s}^2/2)$, $\hat{s}^2 = \text{varianța reziduurilor}$
 - ▶ Pentru $h > 1$ țintele se suprapun: erorile sunt autocorelate până la lagul $h - 1$, deci fiecare test cere o varianță HAC
- O funcție de pierdere este **robustă** dacă ordinea prognozelor cu aproximarea RV_t coincide cu ordinea cu varianța adevărată [Patton \(2011\)](#)
 - ▶ $MSE_t = (RV_t - F_t)^2$, $QLIKE_t = RV_t/F_t - \ln(RV_t/F_t) - 1 \geq 0$ (zero doar dacă $F_t = RV_t$)
- QLIKE depinde de raportul RV_t/F_t : o eroare într-o zi calmă contează cât una într-o zi agitată
- MSE este dominată de câteva zile de criză; QLIKE este pierderea principală, MSE cea secundară

Recapitulare: Măsuri realizate

- ▣ RV estimează variația pătratică zilnică; eroarea ei crește cu cvarticitatea
- ▣ Semivarianțele împart RV după semnul randamentului intraday; RQ măsoară cât de zgomotoasă este RV
- ▣ Ținta: RV la cinci minute, mediată pe $h = 1, 5, 22$ zile; pierderea principală QLIKE, secundară MSE

VOLARE: o arhivă deschisă de măsuri realizate

- Construită la universitățile din Messina și Florența din date tick cu tick [Cipollini et al. \(2026\)](#)
 - ▶ Curățare specifică fiecărui activ, calendare de tranzacționare și precizia marcajelor de timp; aceiași estimatori pentru toate clasele de active
- Gratuită pentru cercetare la volare.unime.it; nu este redistribuită împreună cu acest curs
 - ▶ Descărcați fișierele de varianță realizată și indicați notebook-urilor folderul vostru local
- Citarea cerută de autori: Cipollini, Cruciani, Gallo, Insana, Otranto și Spagnolo (2026), arXiv:2602.19732



Universitatea din Messina, gazda VOLARE


Foto: [Superchilum \(2013\)](#); CC BY-SA 3.0; [Wikimedia Commons](#)

Panelul: 50 de active în trei clase

Clasa	Active	Eșantion	Observații	Volatilitate mediană
Acțiuni americane mari	40	2 ian. 2015 – 30 ian. 2026	111 440	17,1%
Futures (C, CL, ES, GC, NG)	5	28 sept. 2009 – 30 ian. 2026	21 059	19,7%
FX (AUD, EUR, GBP, CAD, JPY față de USD)	5	25 sept. 2009 – 30 ian. 2026	21 203	7,3%

- Acțiuni: 40 de componente ale Dow Jones 30 și S&P 100 (de la AAPL la XOM); futures: porumb, petrol, E-mini S&P 500, aur, gaze naturale
- Volatilitatea mediană: $\sqrt{252 \text{ mediana}(RV_t)}$ pentru fiecare activ, apoi mediana clasei; weekendurile lipsesc în toate cele trei fișiere
- Variabile folosite: rv5, rsp5, rsn5, rq5 și prețurile zilnice de deschidere și de închidere

Volatilitatea realizată în clasele de active



□ Volatilitatea anualizată $\sqrt{252 RV_t}$, medie pe cinci zile, scală logaritmică; două active pe clasă

Cum citim graficul volatilității

- Toate clasele au în comun martie 2020; petrolul (CL) atinge maximul în aprilie 2020, când contractul apropiat s-a tranzacționat sub zero
 - ▶ Un prognozator bun trebuie să se adapteze în câteva zile, nu în luni
- Nivelurile diferă cu un ordin de mărime: FX în jur de 7,3%, acțiunile în jur de 17,1% pe an
- Pe scală logaritmică, volatilitatea pare staționară și persistentă: memoria lungă pe care o aproximează HAR
- Vârfurile se sting în câteva săptămâni: forma căii recente, nu doar nivelul ei, poartă informație

Recapitulare: Baza de date VOLARE

- ▣ 50 de active, trei clase, 2009–2026 (acțiunile din 2015), măsuri realizate standardizate
- ▣ Licență pentru cercetare: codul și rezultatele se publică, datele le descarcă fiecare utilizator
- ▣ Episoadele comune de stres (martie 2020, aprilie 2025) sunt perioade naturale de test

HAR: trei medii ale trecutului

- Modelul HAR (Heterogeneous AutoRegressive, autoregresiv heterogen) [Corsi \(2009\)](#)

- $\text{RV}_{t+1:t+h} = \beta_0 + \beta_d \text{RV}_t + \beta_w \text{RV}_t^{(w)} + \beta_m \text{RV}_t^{(m)} + \varepsilon_{t+h}$

- $\text{RV}_t^{(w)} = \frac{1}{5} \sum_{j=0}^4 \text{RV}_{t-j}, \quad \text{RV}_t^{(m)} = \frac{1}{22} \sum_{j=0}^{21} \text{RV}_{t-j}$

- HAR este un AR(22) restricționat: cei 22 de coeficienți ai lagurilor iau doar trei valori distincte

- $\phi_1 = \beta_d + \beta_w/5 + \beta_m/22, \phi_{2..5} = \beta_w/5 + \beta_m/22, \phi_{6..22} = \beta_m/22$

- Traderi la frecvență zilnică, săptămânală și lunară: o cascadă care imită memoria lungă cu trei parametri

- log-HAR: aceeași regresie pentru $\ln \text{RV}$; nu poate da prognoze negative și este mai puțin dominat de vârfuri

Două rafinări: HARQ și SHAR

- RV este un regresor generat: $RV_t = IV_t + \eta_t$, $\text{Var}(\eta_t) \approx 2IQ_t/M$; erorile în variabile atenuează β_d în zilele zgomotoase
 - ▶ HARQ [Bollerslev, Patton & Quaedvlieg \(2016\)](#):
 $RV_{t+1:t+h} = \beta_0 + (\beta_d + \beta_Q(RQ_t^{1/2} - \overline{RQ^{1/2}}))RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+h}$, se așteaptă $\beta_Q < 0$
 - ▶ Filtrul BPQ: o prognoză în afara intervalului din eșantion al țintei este înlocuită cu media din eșantion („insanity filter”)
- SHAR [Patton & Sheppard \(2015\)](#): împărțim termenul zilnic după semnul randamentelor intraday
 - ▶ $RV_{t+1:t+h} = \beta_0 + \beta^+ RV_t^+ + \beta^- RV_t^- + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+h}$
 - ▶ Patton și Sheppard găsesc $\beta^- > \beta^+$: o versiune intraday a efectului de levier (Capitolul 5)
- Signatura poate surprinde un efect înrudit din date zilnice: aria Lévy dintre randamente și log RV (secțiunea următoare)

Șapte modele într-un tabel

Model	Țintă	Ponderi	Regresori
HAR	RV	egale	$RV_t, RV_t^{(w)}, RV_t^{(m)}$
log-HAR	$\ln RV$	egale	aceiași, în logaritmi
HARQ	RV	egale	$HAR + RV_t (RQ_t^{1/2} - \overline{RQ^{1/2}})$
SHAR	RV	egale	$RV_t^+, RV_t^-, RV_t^{(w)}, RV_t^{(m)}$
log-HAR-K	$\ln RV$	nucleul semnăturii	regresorii log-HAR
Sig-L	$\ln RV$	egale	log-HAR + 39 de termeni ai semnăturii, LASSO în doi pași
Sig-LK	$\ln RV$	nucleul semnăturii	ca Sig-L: metoda lui Gu et al.


- Ultimele patru formează o ablație 2×2 : trăsături din semnătură (da/nu) $\times$ ponderi de nucleu (da/nu)
- Log-HAR este reperul natural pentru modelele cu semnături: aceeași țintă, regresori imbricați

Recapitulare: Repere

- HAR este un $AR(22)$ restricționat cu trei parametri; log-HAR este versiunea lui logaritmică
- HARQ corectează eroarea de măsurare a RV; SHAR separă volatilitatea bună de cea rea
- Modelele cu semnături îl conțin pe log-HAR: pot câștiga doar adăugând informație despre forma căii

De unde vin signaturile

- **Chen (1957)**: integralele iterate ale unei căi formează o algebră și o determină până la reparametrizare
 - ▶ Kuo-Tsai Chen, geometria spațiilor de bucle
- **Lyons (1998)**: teoria căilor aspre (rough paths); signatura este mulțimea naturală de trăsături pentru ecuațiile diferențiale controlate
 - ▶ Un răspuns la o cale depinde de ea (în prima aproximare) doar prin signatura ei
- Machine learning: [Levin, Lyons & Ni \(2013\)](#), [Chevyrev & Kormilitzin \(2016\)](#), [Lyons & McLeod \(2022\)](#); finanțe: modele de prețuri bazate pe signaturi [Cuchiero, Gazzani & Svaluto-Ferro \(2023\)](#)



Terry Lyons (stânga), Oberwolfach, 2024

Foto: [Katrin Schmid \(2024\)](#); CC BY-SA 2.0 DE; [Wikimedia Commons](#)

O fereastră de date este o cale

- ▣ Luăm ultimele L zile din $d - 1$ serii și unim punctele liniar
 - ▶ $X : [0, 1] \rightarrow \mathbb{R}^d$, $X_{u_i} = (u_i, \ln RV_{t-L+1+i}, \sum_{j \leq t-L+1+i} r_j)$, $u_i = i/(L - 1)$
- ▣ **Augmentarea cu timpul:** primul canal este chiar timpul
 - ▶ Fără el, signatura nu distinge o mișcare rapidă de una lentă (invarianța la reparametrizare)
- ▣ O regresie pe fereastră vede 22 de laguri; un rezumat al căii vede ordinea, viteza și co-mișcarea lor
 - ▶ Exemplu: RV a crescut în timp ce prețurile scădeau, sau RV a crescut întâi și prețurile au scăzut mai târziu

Signatura: definiție

- Pentru o cale $X : [a, b] \rightarrow \mathbb{R}^d$ cu variație mărginită și un cuvânt $(i_1, \dots, i_k)$ cu litere din $\{1, \dots, d\}$
 - ▶ $S(X)_{a,b}^{i_1 \dots i_k} = \int_{a < u_1 < \dots < u_k < b} dX_{u_1}^{i_1} \dots dX_{u_k}^{i_k}$ (integrală iterată)
- Signatura este întregul șir de niveluri
 - ▶ $\text{Sig}(X) = (1, S^{(1)}, S^{(2)}, S^{(3)}, \dots)$, $S^{(k)} \in (\mathbb{R}^d)^{\otimes k}$ are d^k termeni
- Nivelul 1: $S^i = X_b^i - X_a^i$, creșterile totale
 - ▶ Nivelul 2: $S^{ij} = \int_a^b (X_u^i - X_a^i) dX_u^j$; nivelul 3 adaugă încă o integrală

Segmente liniare și identitatea lui Chen

- Un segment liniar cu creșterea $\Delta \in \mathbb{R}^d$ are ca signatură exponențială tensorială
 - ▶ $\text{Sig}(\text{segment}) = \exp_{\otimes}(\Delta) = (1, \Delta, \frac{1}{2!}\Delta^{\otimes 2}, \frac{1}{3!}\Delta^{\otimes 3}, \dots)$
- **Identitatea lui Chen** [Chen \(1957\)](#): signatura unei concatenări este produsul tensorial
 - ▶ $\text{Sig}(X * Y) = \text{Sig}(X) \otimes \text{Sig}(Y), \quad (A \otimes B)^{(k)} = \sum_{p=0}^k A^{(k-p)} \otimes B^{(p)}$
- O cale liniară pe porțiuni cu m segmente: $\text{Sig} = \exp_{\otimes}(\Delta_1) \otimes \dots \otimes \exp_{\otimes}(\Delta_m)$
 - ▶ Acesta este tot algoritmul: m actualizări, fiecare de cost $O(d^N)$ la adâncimea N (câteva rânduri de numpy)
 - ▶ Ferestre mobile: Chen dă și $\text{Sig}(X_{[s,t]}) = \text{Sig}(X_{[a,s]})^{-1} \otimes \text{Sig}(X_{[a,t]})$

Exemplu lucrat: o cale cu două segmente

Calea

- ▣ $X : (0, 0) \rightarrow (1, 0) \rightarrow (1, 2); \Delta_1 = (1, 0), \Delta_2 = (0, 2)$
- ▣ Nivelul 1: $S^{(1)} = \Delta_1 + \Delta_2 = (1, 2)$
- ▣ Nivelul 2 prin Chen:


$$S^{ij} = \frac{1}{2}\Delta_1^i\Delta_1^j + \Delta_1^i\Delta_2^j + \frac{1}{2}\Delta_2^i\Delta_2^j$$

Rezultat

- ▣ $S^{11} = \frac{1}{2}, S^{12} = 0 + 1 \cdot 2 + 0 = 2$
- ▣ $S^{21} = 0, S^{22} = \frac{1}{2} \cdot 2^2 = 2$
- ▣ Verificare: $S^{11} = (\Delta X^1)^2/2$ și $S^{22} = (\Delta X^2)^2/2$ (identitatea shuffle)
- ▣ $S^{12} \neq S^{21}$: ordinea contează (întâi la dreapta, apoi în sus)

Aria Lévy: ordinea ca număr

- Partea antisimetrică a nivelului 2
 - ▶ $A^{ij} = \frac{1}{2} (S^{ij} - S^{ji}) =$ aria cu semn dintre cale și coarda ei
- Partea simetrică: $\frac{1}{2} (S^{ij} + S^{ji}) = \frac{1}{2} \Delta X^i \Delta X^j$, nicio informație nouă
 - ▶ Exemplul de mai sus: $A^{12} = (2 - 0)/2 = 1$, aria triunghiului de sub cale
- Canalele (randament, log RV): $A < 0$ când volatilitatea a crescut *după* ce prețurile au scăzut
 - ▶ O statistică de avans-întârziere: efectul de levier din Capitolul 5, citit dintr-o singură fereastră




Paul Lévy (1886–1971)

Foto: Konrad Jacobs; CC BY-SA 2.0 DE;

[Wikimedia Commons](#)

Două ferestre JPM ca niște căi



- Călea (randament cumulat de la deschidere la închidere, log RV) pe 22 de zile; coarda punctată unește începutul și sfârșitul; zona hașurată dă aria Lévy

Cum citim cele două căi

- Fereastra calmă (până la 15 nov. 2019): log RV se schimbă cu $-0,58$, calea rătăcește, aria Lévy $-0,011$
 - ▶ Creșterile și scăderile RV nu sunt legate de direcția prețurilor
- Fereastra de stres (până la 16 mar. 2020): log RV crește cu $+4,32$ (RV multiplicată cu aproximativ 75)
 - ▶ Randamentele intraday scad întâi cu aproximativ 10% și RV urcă pe măsură ce ele scad: aria Lévy $-0,247$
 - ▶ Randamentul intraday net pe fereastră este doar $+0,5\%$: nivelul 1 singur ar rata prăbușirea, care s-a produs în mare parte peste noapte
- Același început, același sfârșit, povești diferite: exact ce înregistrează nivelurile superioare ale semnăturii


De ce funcționează signaturile: trei teoreme

- ▣ **Unicitate Hambly & Lyons (2010):** $\text{Sig}(X)$ determină X până la o echivalență de tip arbore; cu un canal de timp strict crescător, în mod unic
 - ▶ Augmentarea cu timpul face ca aplicația de trăsături să fie injectivă
- ▣ **Universalitate (liniarizare):** pentru o mulțime compactă K de căi augmentate cu timpul și $f : K \rightarrow \mathbb{R}$ continuă, pentru orice $\varepsilon > 0$ există o funcțională liniară ℓ cu
 - ▶ $\sup_{X \in K} |f(X) - \langle \ell, \text{Sig}(X) \rangle| < \varepsilon$ (Stone–Weierstrass, prin identitatea shuffle)
- ▣ **Descreștere factorială:** $\|S^{(k)}\| \leq \|X\|_{1\text{-var}}^k / k!$
 - ▶ Trunchierea la o adâncime mică N pierde puțin pentru căi de lungime moderată

Identitatea shuffle: neliniaritate gratuită

- ▣ Produsele termenilor semnaturii sunt combinații liniare de termeni superiori
 - ▶ $S^i S^j = S^{ij} + S^{ji}$, $S^{ij} S^k = S^{ijk} + S^{ikj} + S^{kij}$
- ▣ Deci un model liniar în $\text{Sig}^N(X)$ conține deja polinoame în creșteri
 - ▶ De aceea un LASSO pe semnaturi poate aproxima funcții neliniare ale căii
- ▣ Prețul: numărul de trăsături crește ca d^N
 - ▶ Este nevoie de raritate (LASSO), ca la Gu et al.

Câte trăsături? Dimensiunea trunchierii



□ Nivelurile 1..N ale unei căi d -dimensionale: $M(d, N) = \sum_{k=1}^N d^k = \frac{d^{N+1}-d}{d-1}$ termeni

Alegerea lui d și N

- ▣ Calea noastră: $d = 3$ canale (timp, log RV, randament cumulat), adâncimea $N = 3$: $3 + 9 + 27 = 39$ de termeni
 - ▶ Trei dintre ei sunt constanți (cuvintele doar cu litera timpului), deci 36 variază
- ▣ Cu $d = 5$ și $N = 4$ am avea deja 780 de termeni pentru 1000 de observații: LASSO ar alege din zgomot
- ▣ Gu et al. folosesc tot calea țintei singure (cu timpul), plus factori externi în afara semnăturii
 - ▶ Articolul nu publică valorile N și L ; fixăm $N = 3$, $L = 22$ dinainte și verificăm $N = 2$ ca robustețe

Două invarianțe de reținut

- ▣ **Invarianța la translație:** $\text{Sig}(X + c) = \text{Sig}(X)$ — intră doar creșterile
 - ▶ Signatura nu vede **nivelul** volatilității, doar forma căii recente
 - ▶ Deci nivelul trebuie să intre separat: termenii log-HAR joacă rolul factorilor externi x_τ ai lui Gu et al.
- ▣ **Invarianța la reparametrizare:** parcurgerea căii mai repede sau mai încet lasă Sig neschimbată
 - ▶ Eliminată de canalul de timp; un punct de bază (calea pornește din 0) ar elimina prima invarianță [Morrill et al. \(2020\)](#)

Nucleul semnăturii

- Nucleu = produsul scalar al aplicațiilor de trăsături [Király & Oberhauser \(2019\)](#)
 - ▶ $k_N(X, Y) = \langle \text{Sig}^N(X), \text{Sig}^N(Y) \rangle = 1 + \sum_{k=1}^N \sum_{|w|=k} S(X)^w S(Y)^w$
- Distanța indusă de nucleu (Gu et al., ec. 9)
 - ▶ $d_{\text{Sig}}(X, Y) = k(X, X) - 2k(X, Y) + k(Y, Y) = \|\text{Sig}^N(X) - \text{Sig}^N(Y)\|^2$
- Gu et al. și acest capitol folosesc acest nucleu **trunchiat**, cu același N ca pentru trăsături
 - ▶ Nucleul netrunchiat rezolvă o ecuație cu derivate parțiale de tip Goursat (Partial Differential Equation, PDE) [Salvi et al. \(2021\)](#); articolul îl citează, dar nu îl folosește
- Canalele se rescalează înaintea nucleului (secțiunea următoare): altfel domină canalul cu unitățile cele mai mari

Recapitulare: Signaturi de căi

- ▣ Signatura = toate integralele iterate ale unei căi; calculată exact pentru căi liniare pe porțiuni cu identitatea lui Chen
- ▣ Nivelul 2 conține ariile Lévy: cine s-a mișcat primul; identitatea shuffle transformă produsele în termeni liniari
- ▣ Universalitate: modelele liniare pe signaturi aproximează orice funcție continuă a căii
- ▣ Invarianța la translație: nivelul volatilității trebuie furnizat de alți regresori

Problema de la Amazon

- Tarife săptămânale pe piața nord-americană de transport rutier, la nivel național și în cinci regiuni, 2018–2022 [Gu et al. \(2024\)](#)
 - Prognose pe până la 12 săptămâni, pentru decizii de achiziție și de preț
- Peste 100 de factori candidați (prețuri, locuințe, foraj, indici logistici, ocupare, vreme), reduși la aproximativ 40
 - Folosit în operațiunile de transport rutier ale Amazon din noiembrie 2022
- KDD 2024 (ACM Conference on Knowledge Discovery and Data Mining); preprint [arXiv:2401.04857](#)



Un camion cu container pe o autostradă americană, 2025

Foto: [DanTD \(2025\)](#); CC BY 4.0; [Wikimedia Commons](#)

Metoda, pasul 1: trăsăturile

- În săptămâna τ : factorii externi x_τ și signatura căii țintei, augmentată cu timpul
 - ▶ $z_\tau = [x_\tau, \text{Sig}^N(\hat{y}_{\tau-l:\tau})]$, $\hat{y}_{\tau-l:\tau} = \{(t_i, y_{t_i})\}$ (Secțiunea 4.1)
- Hiperparametri: fereastra de istoric l , adâncimea N , orizontul Δt , temperatura γ
 - ▶ Valorile lor nu sunt publicate (confidențialitate)
- O regresie directă pe orizont: $y_{\tau+\Delta t}$ pe z_τ (fără iterarea prognozelor la un pas)

Metoda, pasul 2: LASSO în doi pași

- ▣ Selecție printr-un LASSO ponderat (Least Absolute Shrinkage and Selection Operator) [Tibshirani \(1996\)](#) (ec. 14)
 - ▶ $\hat{\theta}_L = \arg \min_{\theta} \sum_{\tau} w_{\tau} (y_{\tau+\Delta t} - z_{\tau}^{\top} \theta)^2 + \lambda \|\theta\|_1$
- ▣ Reestimare prin OLS ponderat pe suportul selectat (ec. 15)
 - ▶ $\hat{\theta} = \arg \min_{\text{supp}(\theta)=\text{supp}(\hat{\theta}_L)} \sum_{\tau} w_{\tau} (y_{\tau+\Delta t} - z_{\tau}^{\top} \theta)^2$
- ▣ De ce reestimăm: LASSO micșorează spre zero coeficienții păstrați; OLS după selecție elimină această deplasare [Belloni & Chernozhukov \(2013\)](#)
 - ▶ Articolul îl numește „adaptiv” din cauza ponderilor w_{τ} , nu în sensul LASSO-ului adaptiv al lui [Zou \(2006\)](#)
- ▣ Modul de alegere a lui λ nu este raportat

Metoda, pasul 3: ponderi date de nucleu

- ▣ Distanța fiecărei ferestre trecute față de cea curentă (Algoritmul 1, ec. 12)
 - ▶ $\delta_\tau = d_{\text{Sig}, N}(z_{\tau-l:\tau}, z_{t-\Delta t-l:t-\Delta t})$
- ▣ Ponderi softmax cu temperatura $\gamma \geq 0$
 - ▶ $w_\tau = \frac{\exp(-\gamma \delta_\tau)}{\sum_s \exp(-\gamma \delta_s)}$
 - ▶ $\gamma = 0$: regresie obișnuită (ponderi egale); $\gamma \rightarrow \infty$: doar cea mai asemănătoare fereastră trecută
- ▣ O idee de tip cel mai apropiat vecin într-o regresie: învățăm din perioadele trecute care arătau ca azi
 - ▶ Costul ideii: mai puține observații efective, $n_{\text{eff}} = 1 / \sum_\tau w_\tau^2$ (Kish)

Ce raportează articolul

- ▣ Tarife naționale, 12 săptămâni înainte, aprilie–noiembrie 2021 (Tabelul 1): eroare relativă de aproximativ 1–2% față de 13–27% pentru prognoza din industrie
 - ▶ Eroarea relativă = $|y - \hat{y}|/|y|$; „acuratețea prognozei crește de peste cinci ori”
- ▣ Erori la 12 săptămâni (Tabelul 2): 1,06–2,38% la nivel național, 1,05–5,65% pe regiuni
- ▣ Ablația nucleului (Tabelul 3, octombrie–decembrie 2021): erori de până la 9,85% fără nucleu, față de până la 5,15% cu el
 - ▶ O economie anuală estimată de aproximativ 50 de milioane de dolari pentru Amazon

O lectură critică a articolului

- ▣ **Un singur reper:** o prognoză comercială nenumită; fără ARIMA, fără LASSO fără semnături, fără mers aleator
 - ▶ Un câștig de cinci ori față de un reper slab spune puțin despre metoda însăși
- ▣ **Evaluare scurtă:** câteva luni din 2021–2022, câteva serii; fără erori standard, fără un test de acuratețe egală
- ▣ **Calibrare nepublicată:** I , N , γ , λ și modul lor de alegere; ablația nucleului acoperă zece săptămâni
- ▣ Nimic din acestea nu face metoda greșită; face dovezile subțiri, de aceea o testăm în alt context
 - ▶ Replicarea înaintea extinderii este regula proiectului de curs (Capitolul 19)

Ce se transferă la volatilitate și ce nu

Se transferă

- ▣ Signatura căii recente a țintei, augmentată cu timpul
- ▣ LASSO în doi pași cu ponderi, regresie directă pe orizont
- ▣ Ponderi de nucleu $\exp(-\gamma d_{\text{Sig}})$ cu nucleul semnăturii trunchiat

Trebuie adaptat

- ▣ Țintă zilnică și zgomotoasă în loc de tarife săptămânale: logaritmi, inferență HAC, pierderi robuste
- ▣ Factorii externi x_τ înlocuiți de termenii log-HAR (ei aduc nivelul)
- ▣ Alegerile nepublicate (I, N, γ, λ) fixate de noi, dinainte
- ▣ Repere puternice și teste formale în locul unei singure prognoze comerciale

Recapitulare: Articolul

- ▣ Trăsături: factori externi plus semnatura căii țintei; estimare: LASSO ponderat, apoi OLS pe suport
- ▣ Ponderi: softmax din minus distanța semnaturii față de fereastra curentă
- ▣ Câștigurile raportate sunt mari, dar măsurate față de un singur reper, pe o perioadă scurtă, fără inferență

Ipoteze

- ▣ **H1 (trăsături):** termenii semnăturii aduc informație dincolo de log-HAR
 - ▶ Test: Sig-L față de log-HAR, aceeași țintă, aceleași ponderi egale
- ▣ **H2 (ponderi):** ponderile de nucleu îmbunătățesc o regresie dată
 - ▶ Teste: Sig-LK față de Sig-L și log-HAR-K față de log-HAR
- ▣ **H3 (metoda):** metoda completă a lui Gu et al. bate familia HAR
 - ▶ Teste: Sig-LK față de HAR și de log-HAR; mulțimea de încredere a celor șapte modele
- ▣ **H4 (stres):** orice câștig este mai mare în perioadele de stres (prăbușirea din pandemia COVID-19, aprilie 2025), unde ferestrele trecute asemănătoare ar trebui să conteze cel mai mult

Trăsături și scalare

- ▣ Regresorii în ziua τ pentru modelele cu semnături: 3 termeni log-HAR + 39 de termeni ai semnăturii
 - ▶ $z_\tau = [\ln RV_\tau, \ln RV_\tau^{(w)}, \ln RV_\tau^{(m)}, \text{Sig}^3(X_{\tau-21:\tau})]$, calea $X = (\text{timp}, \ln RV, r \text{ cumulat})$, 22 de puncte
- ▣ Scala canalelor fixată în fiecare fereastră de estimare: canalul c împărțit la $s_c \sqrt{L-1}$, $s_c =$ abaterea standard a creșterilor lui zilnice
 - ▶ Timpul merge de la 0 la 1; un cuvânt $(i_1..i_k)$ se rescalează cu $\prod_j c_{i_j}$, deci semnăturile se calculează o singură dată
- ▣ Înaintea LASSO fiecare coloană este standardizată cu momentele ponderate ale ferestrei de antrenare
- ▣ Nicio informație de după ziua τ nu intră în z_τ ; scalele folosesc doar fereastra de antrenare


Estimare: alegerea lui λ fără informație din viitor

- În fiecare fereastră de antrenare: tot drumul LASSO ponderat, prin LARS (Least-Angle Regression, regresia unghiului minim)
 - ▶ Pentru fiecare suport de pe drum: reestimare OLS ponderată (pasul 2 din Gu et al.)
- Alegem suportul care minimizează BIC (Bayesian Information Criterion, criteriul informațional bayesian) cu mărimea efectivă a eșantionului Kish
 - ▶ $\text{BIC}(S) = n_{\text{eff}} \ln \hat{\sigma}_S^2 + (|S| + 1) \ln n_{\text{eff}}, \quad n_{\text{eff}} = 1 / \sum_{\tau} w_{\tau}^2$
- De ce nu validare încrucișată: 50 de active $\times$ 3 orizonturi $\times$ sute de reestimări; BIC folosește doar fereastra
 - ▶ Slăbiciune cunoscută: țintele suprapuse ($h > 1$) fac n_{eff} prea mare, deci BIC păstrează puțin prea mulți termeni

Temperatura nucleului: o singură alegere, pe un bloc de validare

- Temperatură fără unități: $\gamma = c/\text{mediana}_{\tau}(\delta_{\tau})$ în fiecare fereastră
 - ▶ $c = 1$: o fereastră la distanța mediană primește ponderea e^{-1} față de una identică
- Grila $c \in \{0,5; 1; 2; 4\}$, aleasă o singură dată pe orizont, pe primele 250 de zile de prognoză ale fiecărui activ, cumulativ
 - ▶ Criteriu: media pe active a $\text{QLIKE}(c)$ împărțită la media activului pe grilă
 - ▶ Evaluarea începe la h zile după sfârșitul blocului de validare, deci nicio țintă evaluată nu a fost folosită la calibrare
- Ales: $c = 0,5; 0,5; 0,5$ pentru Sig-LK și $c = 0,5; 0,5; 2,0$ pentru log-HAR-K ($h = 1, 5, 22$)
- Cea mai mică valoare (cea mai plată) câștigă în cinci din șase cazuri: un prim semn că ponderarea mai ascuțită nu ajută

Estimarea pe fereastră mobilă, pas cu pas



- Reestimăm la fiecare 5 zile de tranzacționare pe ultimele 1000 de perechi complete; între reestimări coeficienții sunt fiți, dar regresorii se actualizează zilnic
- Distanțele nucleului se recalculează la fiecare reestimare, față de fereastra care se termină la originea t

Protocolul de evaluare

- Pe activ și orizont: QLIKE și MSE medii; testul DM (Diebold–Mariano) cu varianță Newey–West, lățime de bandă $\max(h, \lceil T^{1/3} \rceil)$ [Diebold & Mariano \(1995\)](#)
 - ▶ Estimare pe fereastră mobilă, deci testul se citește ca testul GW (Giacomini–White) necondiționat; testul GW condiționat folosește instrumentele $(1, d_{t-h})$ [Giacomini & White \(2006\)](#)
- MCS (Model Confidence Set, mulțimea de încredere a modelelor) la 90%, statistica $T_{\max}$, bootstrap staționar, 1000 de replicări [Hansen, Lunde & Nason \(2011\)](#)
 - ▶ Lungimea blocului $\max(h, 10)$ zile
- Panel: testul DM pe diferența medie de pierdere pe secțiune transversală (o serie pe dată)
 - ▶ Numărarea victoriilor pe 50 de active: corecțiile Holm (FWER) și BH (FDR) [Benjamini & Hochberg \(1995\)](#)
- Subperioade: 20 feb.–30 apr. 2020, 2–30 apr. 2025, toate celelalte zile; eroarea relativă din articol ca statistică descriptivă

O abatere declarată

- ▣ Preînregistrat: filtrul BPQ („insanity filter”) pe toate modelele
 - ▶ Un test al codului pe JPM (un singur activ, înaintea oricărui rezultat pe panel) a arătat că înlocuiește prognoze corecte din prăbușire cu media calmă din eșantion
 - ▶ Pe 12 martie 2020, RV realizată a zilei următoare pentru JPM a fost de aproximativ 40 de ori prognoza HAR filtrată
- ▣ Schimbat înainte de rularea pe panel: rezultatele principale doar cu pozitivitate (o prognoză ≤ 0 devine media din eșantion)
 - ▶ Filtrul BPQ rămâne ca verificare de robustețe și este raportat complet
- ▣ Regula: o abatere este permisă, o abatere ascunsă nu; spuneți ce ați văzut când ați schimbat

Recapitulare: Design


- ▣ Șapte modele, trei orizonturi, 50 de active, fereastră mobilă de 1000 de zile, reestimare la fiecare 5 zile
- ▣ Toate alegerile nepublicate ale articolului fixate dinainte; o singură temperatură aleasă pe un bloc de validare
- ▣ Pierderea principală QLIKE; DM/GW pe activ, DM pe panel, MCS, Holm și BH pentru numărarea victoriilor

Ce s-a evaluat

Clasa	Evaluarea începe	Se termină	Zile pe activ (mediana)
Acțiuni	27 ian. 2020	29 ian. 2026	1 499
Futures	2 sept. 2014	29 ian. 2026	2 919
FX	22 aug. 2014	29 ian. 2026	2 954

- 266 106 de prognoze în afara eșantionului pentru fiecare model (50 de active $\times$ 3 orizonturi)
- Acțiunile încep în 2015, deci evaluarea lor începe în ianuarie 2020: prăbușirea din pandemia COVID-19 este în eșantionul fiecărei acțiuni
 - Futures și FX încep în 2009 și sunt evaluate din 2014
- Calcul: 3,0 ore-procesor; 17 minute pe 14 procese paralele; semnături și LASSO în numpy și scikit-learn

QLIKE relativ la HAR, activ cu activ



□ Cutii: intervalul intercuartilic pe cele 50 de active; linia: mediana; romb: media; mustățile: 1,5 intervale intercuartilice

Cum citim rezultatele principale

- $h = 1$: log-HAR, log-HAR-K, Sig-L și Sig-LK sunt la egalitate (0,885; 0,886; 0,889; 0,889)
 - ▶ Față de log-HAR, Sig-LK este la +0,5% în medie: niciun câștig din 36 de trăsături în plus
- $h = 5$ și $h = 22$: modelele cu semnături rămân în urma log-HAR (+26,6% și +92,6% pentru Sig-LK)
 - ▶ Medianele (0,989; 0,967) sunt mult mai bune decât mediile: câteva active și zile determină pierderea
- HARQ și SHAR pierd aici în fața HAR în nivel; fără filtrul BPQ, HARQ produce prognoze instabile (un slide de robustețe revine asupra acestui aspect)
- Primul verdict: H3 respinsă în sensul relevant: metoda lui Gu et al. nu bate cel mai simplu model logaritmic

Activ cu activ: victorii și înfrângeri, corectate


Comparația (QLIKE)	$h = 1$		$h = 5$		$h = 22$	
Sig-LK vs log-HAR	2/1/1	5/0/0	0/0/0	15/0/0	0/0/0	27/1/15
Sig-L vs log-HAR	4/1/1	5/0/0	0/0/0	11/0/0	1/0/0	21/0/0
log-HAR-K vs log-HAR	3/0/0	1/0/0	3/0/0	1/0/0	2/0/0	6/0/0
Sig-LK vs Sig-L	2/0/0	4/0/0	0/0/0	4/0/0	2/0/0	9/0/0
Sig-LK vs HAR	16/7/10	0/0/0	8/2/2	0/0/0	9/2/4	1/0/0
log-HAR vs HAR	21/6/17	0/0/0	23/14/20	0/0/0	42/25/42	0/0/0

- Celula: semnificativ mai bun pe active raw/Holm/BH | semnificativ mai slab pe active raw/Holm/BH; DM unilateral la 5%, familie de 50 de active
- Holm controlează probabilitatea oricărei victorii false (FWER); BH controlează proporția așteptată de victorii false (FDR)

Cum citim numărul de victorii

- Signaturile (H1): Sig-L bate log-HAR pe 4 din 50 de active la $h = 1$ fără corecție, 1 după Holm
 - ▶ Sub ipoteza nulă fără câștig ne așteptăm la aproximativ 2,5 victorii necorectate din întâmplare: exact ce vedem
- Ponderile (H2): log-HAR-K față de log-HAR, 3/3/2 victorii necorectate, niciuna după Holm
 - ▶ Sig-LK față de Sig-L: nicio diferență semnificativă după Holm, la niciun orizont
- Față de HAR la $h = 1$, Sig-LK câștigă pe 16 active (7 după Holm); log-HAR singur câștigă pe 21 (6 după Holm, 17 după BH)
 - ▶ Lecție: alegeți reperul care izolează ideea; „bate HAR” ar fi atribuit signaturilor câștigul transformării logaritmice

Statisticile DM pentru fiecare activ și orizont




- Statisticile t Diebold–Mariano ale diferenței QLIKE; albastru: Sig-LK mai precis, roșu: mai puțin precis

Cum citim harta DM

- Panoul din stânga (față de log-HAR): în mare parte pal la $h = 1$, roșu la $h = 5$ și $h = 22$
 - ▶ Excepțiile albastre la $h = 1$: ES și TSLA ($|t| > 1,645$) și GC; cinci active sunt semnificativ roșii, înaintea oricărei corecții
- Panoul din dreapta (față de HAR): albastru la $h = 1$ pentru majoritatea activelor, pentru că Sig-LK moștenește ținta logaritmică
 - ▶ La $h = 22$ culoarea depinde de activ: câștigul țintei logaritmice este anulat de prognozele instabile
- O singură hartă arată de ce un studiu pe un singur activ poate induce în eroare: alegeți ES la $h = 1$ și signaturile par un succes clar

Mulțimi de încredere a modelelor



□ Ponderea celor 50 de active în care fiecare model aparține MCS de 90% sub QLIKE

Cum citim mulțimile de încredere


- log-HAR este în MCS pentru 100%, 98% și 100% dintre active; Sig-LK pentru 100%, 96%, 90%
 - ▶ MCS separă rar cele patru modele logaritmice: datele nu le pot distinge activ cu activ
- HAR, HARQ și SHAR sunt excluse pentru între o cincime și o treime dintre active: ținta în nivel este cel mai clar învins
- Sub MSE aproape fiecare model rămâne în mulțime: MSE este dominată de câteva zile de criză și are putere mică [Patton \(2011\)](#)
- Puterea mică este ea însăși un rezultat: diferențele mici de pierdere medie cer eșantioane foarte lungi [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)

Teste pe panel: cumularea dovezilor

Comparația: DM t (p unilateral)	$h = 1$	$h = 5$	$h = 22$
Sig-LK vs log-HAR	-1,10 (0,135)	+1,57 (0,942)	+1,80 (0,964)
Sig-L vs log-HAR	-1,88 (0,030)	+1,51 (0,935)	+1,51 (0,935)
log-HAR-K vs log-HAR	+1,04 (0,852)	+0,31 (0,620)	+1,51 (0,935)
Sig-LK vs Sig-L	+0,93 (0,824)	-0,96 (0,168)	-0,80 (0,211)
log-HAR vs HAR	-3,15 (<0,001)	-4,22 (<0,001)	-4,50 (<0,001)

- ▣ Seria: diferența medie QLIKE pe toate activele tranzacționate în acea zi; t negativ = primul model mai bun
- ▣ Cumulat, doar transformarea logaritmică este clar semnificativă; Sig-L față de log-HAR la $h = 1$ este la limită ($p = 0,030$), datorită futures
 - ▶ Doar pentru cele 40 de acțiuni semnul se inversează: $t = +1,72$ împotriva Sig-L
- ▣ Testul GW condiționat, Sig-LK față de log-HAR: 1, 0 și 0 respingeri Holm din 50

În prăbușirea din pandemia COVID-19: JPM, ziua următoare




□ Volatilitatea anualizată $\sqrt{252F_t}$ a prognozelor și $\sqrt{252RV_{t+1}}$ a țintei realizate, februarie–mai 2020

Cum citim prognozele din prăbușire

- Toate modelele întârzie față de primul salt (sfârșitul lui februarie): niciun model nu vede un șoc înainte să se producă
 - ▶ Sig-LK reacționează puțin mai repede decât log-HAR la mijlocul lui martie, când calea s-a întors deja
- HAR în nivel depășește ținta și apoi devine negativ la sfârșitul lui martie: regula de pozitivitate îl înlocuiește cu media din eșantion (segmentul plat)
 - ▶ Un model în nivel cu termeni săptămânali și lunari mari reacționează prost după un vârf
- După vârf, log-HAR și Sig-LK scad cu viteze asemănătoare; termenii suplimentari ai semnăturii schimbă puțin la $h = 1$

Perioade de stres vs perioade normale



Media pe active a QLIKE relativ la HAR în fiecare subperioadă (fixată înaintea evaluării)

Cum citim subperioadele (H4)


- $h = 1$, prăbușirea COVID-19: log-HAR 0,71, Sig-LK 0,72, HARQ 1,93 (relativ la HAR)
 - ▶ Aprilie 2025: log-HAR 0,88, Sig-LK 0,91; toate celelalte zile: 0,94 și 0,94
- $h = 22$, prăbușirea COVID-19: Sig-LK de 6,34 ori și Sig-L de 8,29 ori pierderea HAR
 - ▶ Exact acolo unde ferestrele trecute asemănătoare trebuiau să ajute, modelele cu semnături eșuează cel mai mult
- H4 respinsă: niciun avantaj în perioadele de stres la $h = 1$, un dezavantaj mare la orizonturi mai lungi

Metrica articolului pe datele noastre

Eroarea relativă mediană $ RV - F /RV$ (%)	$h = 1$	$h = 5$	$h = 22$
HAR	57,2	48,9	51,7
log-HAR	50,4	41,9	38,7
HARQ	55,0	49,0	50,7
SHAR	57,9	49,2	51,8
log-HAR-K	49,7	41,0	38,7
Sig-L	50,1	42,6	42,6
Sig-LK	50,5	43,2	43,7

- Mediana pe active a erorii relative medii: aproximativ 40–60%, față de 1–2% pentru tarifele de transport la Gu et al.
- RV zilnică este o țintă zgomotoasă, cu cozi groase: niciun model nu poate atinge erori de câteva procente, deci câștiguri „de cinci ori” sunt imposibile aici
 - Prognoze Sig-LK peste de zece ori maximul din eșantion: 8, 33, 38 ($h = 1, 5, 22$), pe 11 active la $h = 5$; log-HAR: niciuna

Ponderile nucleului pe 16 martie 2020




- Ponderile Sig-LK ($h = 1$) pe zilele de antrenare (18 mar. 2016 – 9 mar. 2020), înmulțite cu lungimea ferestrei: 1 = ponderare egală

Ce alege nucleul într-o prăbușire

- Ponderile rămân aproape egale: între 0,47 și 1,55 ori $1/n$; mărimea efectivă a eșantionului 944 din 1000
 - ▶ Temperatura aleasă la validare ($c = 0,5$) este cea mai plată din grilă
- Cele mai mari ponderi merg la ultimele zile dinaintea originii, când volatilitatea creștea deja
 - ▶ Fereastra de stres a scăderilor de la sfârșitul lui 2018 (octombrie 2018 – ianuarie 2019) primește o pondere *mai mică*; corelația ponderilor cu log-volatilitatea -0,27
- De ce: semnatura este invariantă la translație; o fereastră cu vârf și scădere are altă formă decât una în creștere, indiferent de nivel

Favorizează vreodată nucleul stresul?




- Ponderea pe care Sig-LK ($h = 1$) o pune pe cele mai volatile 10% zile din fereastra de antrenare, medie pe clasă și pe trei luni

Cum citim ponderea zilelor volatile

- Pentru acțiuni ponderea are media 6,7%, între 4,4% și 9,9% (maximul pe 17 mar. 2020)
 - ▶ Mereu sub cele 10% ale ponderării egale: nucleul *reduce* sistematic ponderea zilelor de stres
- Futures și FX arată același tipar, cu vârfuri în turbulențele din martie 2020
- Acesta este mecanismul din spatele rezultatului nul pentru H2: ponderile nu implementează „învățăm din crizele trecute”

Ce selectează LASSO




- Ponderea reestimărilor în care un regresor este în suportul ales prin BIC pentru Sig-LK (toate activele și orizonturile); t = timp, lr = $\ln RV$, ret = randament cumulat

Cum citim frecvențele de selecție

- Cei trei termeni log-HAR sunt păstrați în 99%, 94% și 93% dintre reestimări
 - ▶ LASSO redescoperă HAR: nivelul și cele trei medii ale lui poartă cea mai mare parte a semnalului
- Cel mai frecvent termen al semnăturii este (t,r,r) , în 29%; toți termenii frecvenți sunt de nivelul 3
 - ▶ Mărimea medie a suportului: 8,7 regresori pentru Sig-L, 6,8 pentru Sig-LK
- Termenii de nivelul 3 sunt cubici în creșteri: într-o fereastră de prăbușire iau valori mult în afara intervalului de antrenare, iar $\exp(\cdot)$ amplifică eroarea

Recapitulare: Rezultate

- H1 (signaturile aduc informație): nesusținută; egalitate la o zi, pierdere la o săptămână și la o lună
- H2 (ponderile nucleului ajută): nesusținută; ponderile sunt aproape plate și reduc ponderea stresului trecut
- H3 (metoda bate familia HAR): doar HAR în nivel și doar prin ținta logaritmică
- H4 (câștiguri în stres): respinsă; modelele cu semnături eșuează cel mai mult în prăbușirea COVID-19 la orizonturi lungi


Ablația 2×2 

- Media pe cele 50 de active a QLIKE relativ la log-HAR: trăsături (signatură sau nu) încrucișate cu ponderi (nucleu sau egale)

Cum citim ablația

- Doar ponderile (log-HAR-K): 1,001; 1,001; 1,010: niciun efect la niciun orizont
 - ▶ Consecvent cu ponderile aproape plate (mărimea efectivă medie a eșantionului 841 din 1000)
- Doar trăsăturile (Sig-L): 1,004; 1,285; 2,236
 - ▶ Adăugarea ponderilor (Sig-LK: 1,266; 1,926) atenuează puțin eșecurile la orizont lung, dar nu le elimină
- Contrast cu Gu et al. (Tabelul 3): nucleul lor a redus eroarea în zece săptămâni din 2021; pe 50 de active și șase până la doisprezece ani nu o face

Robustețea Sig-LK



- Sig-LK relativ la HAR (media pe 50 de active) în designul principal și în trei variante preînregistrate; linia marchează log-HAR

Cum citim verificările de robustețe

- Adâncimea 2: 0,922 și 0,819 la $h = 5,22$ (principal: 1,094; 1,332); calea fără randamente: 0,878 și 0,770
 - ▶ Eșecurile la orizont lung vin din termenii de nivelul 3 care implică canalul randamentelor
- Chiar și variantele stabile doar egalează log-HAR (0,873; 0,765): nu îl bat
 - ▶ Deci rezultatul nul pentru H1 nu depinde de adâncime sau de canale; instabilitatea depinde
- O specificație mai simplă este mai robustă, dar aici mai simplu înseamnă „mai aproape de log-HAR”

Filtrul „insanity”, revăzut

QLIKE relativ la HAR, filtrul BPQ pe toate modelele	$h = 1$	$h = 5$	$h = 22$
HAR	1,000	1,000	1,000
log-HAR	0,762	0,654	0,776
HARQ	0,997	0,913	1,011
SHAR	1,016	1,002	1,001
log-HAR-K	0,770	0,659	0,783
Sig-L	0,869	0,820	0,900
Sig-LK	0,886	0,867	0,930

- Filtrul salvează HARQ față de HAR (0,997 la $h = 1$ în loc de 1,145), cum au intenționat BPQ
- Lovește modelele cu semnături mult mai des decât log-HAR, deci distanța lor față de log-HAR crește la fiecare orizont
- Prognoze filtrate, $h = 1$: HAR 178, HARQ 142, Sig-LK 136, log-HAR 25 (din 266 106)

Pe clase de active

Sig-L relativ la log-HAR (QLIKE)	$h = 1$	$h = 5$	$h = 22$
Acțiuni (40)	1,009	1,332	2,505
Futures (5)	0,971	1,106	1,163
FX (5)	0,998	1,087	1,163

- Singurul câștig: futures la $h = 1$ (-2,9%) și, marginal, FX
 - Cinci futures și un orizont: un candidat pentru un nou studiu preînregistrat, nu o concluzie a acestuia
- Acțiunile, 80% din panel, nu arată niciun câștig: rezultatul cumulat este în principal un rezultat pentru acțiuni

Limitele acestui studiu

- Un design din multe: $L = 22$, $N = 3$, trei canale, BIC, o grilă de patru puncte pentru c
 - ▶ Un rezultat nul pentru acest design nu este un rezultat nul pentru semnături în general
- Doar nucleul trunchiat (ca în articol); nucleul PDE [Salvi et al. \(2021\)](#), log-semnăturile sau un punct de bază (Seminarul 20, Partea C) nu au fost rulate în designul principal
- Fără factori externi (volatilitate implicită, știri macro), care erau centrali la Gu et al.
- Realized GARCH [Hansen, Huang & Shek \(2012\)](#) și reperele de machine learning (Capitolul 13) sunt în afara comparației
- Acțiunile sunt evaluate doar pe șase ani, cu prăbușirea COVID-19 la începutul fiecărui eșantion

Direcții deschise

- Un nucleu care vede nivelul: augmentarea cu punct de bază sau adăugarea nivelului în RV în distanță (analiza de referință în Seminarul 20, Partea C)
- Signaturi ale căii intraday (randamente la 5 minute în cursul zilei) în locul căii zilnice
- Log-signaturi (fără termeni simetrici redundanți) și canale mărginite (tanh) pentru a evita termenii explozivi de nivelul 3 [Morrill et al. \(2020\)](#)
- Căi între active (de exemplu, futures pe S&P 500 și o acțiune), unde ariile Lévy măsoară avansul-întârzierea între piețe
- Futures la $h = 1$: replicare pe un panel mai lung de futures, cu acest design fixat dinainte

O întrebare deschisă

Când se transferă o metodă între domenii?

- Metodele circulă mai repede decât dovezile: un articol KDD despre tarife de transport devine candidat pentru volatilitate, credit, energie
 - ▶ Ce proprietăți ale problemei-sursă au făcut metoda să funcționeze și le are și problema-țintă?
- Finanțele adaugă un filtru sever: 164 de echipe pe aceleași date diferă mai mult decât sugerează erorile lor standard Menkveld et al. (2024)
- Forma formală: un transfer reușește dacă câștigul față de cel mai puternic reper simplu rezistă pe o mulțime preînregistrată S de designuri, active și orizonturi, cu familia corectată
 - ▶ În acest capitol: $S = 50$ de active $\times$ 3 orizonturi $\times$ 4 variante; câștigul nu a rezistat

Bucloa descoperirii, pas cu pas (1/2)

- **Citim:** extragem exact ce a făcut articolul
 - ▶ „Din arXiv:2401.04857, listează fiecare ecuație a estimatorului, fiecare hiperparametru și valoarea raportată și reperul fiecărui tabel. Marchează ce nu este publicat.”
 - ▶ Verificați fiecare element în PDF: numerele ecuațiilor, ale tabelelor, nucleul folosit efectiv
- **Mapăm:** ce se transferă, ce trebuie adaptat
 - ▶ „Ținta noastră este varianța realizată zilnică. Pentru fiecare componentă a metodei, spune dacă se transferă, ce trebuie schimbat și ce reper o izolează.”
- **Preînregistrăm:** ipoteze, grilă, teste, corecție, saluate înainte a primului rezultat
 - ▶ Asistentul face ciorna; echipa decide fiecare cifră și semnează commit-ul

Bucula descoperirii, pas cu pas (2/2)

- **Construim și testăm piesele:** signaturile față de identități, nu față de altă bibliotecă
 - ▶ „Scrie teste unitare pentru o semnătură de adâncime 3: nivelul 1 egal cu creșterea, partea simetrică a nivelului 2 egală cu jumătate din produsul exterior, identitatea lui Chen pe o cale împărțită.”
- **Rulăm grila, apoi o atacăm**
 - ▶ „Iată toate cele 450 de rulări. Ce concluzii rezistă corecției Holm pe 50 de active? Ce activ sau ce subperioadă ar da un titlu înșelător?”
- **Explicăm rezultatul nul:** găsim mecanismul, nu o scuză
 - ▶ Aici: ponderi plate (invarianța la translație) și termeni explozivi de nivelul 3 (legătura exponențială), ambele verificate cu date

Ce verifică cercetătorul

- **Metoda este cea din articol:** nucleul, ponderile, reestimarea, ca în ecuațiile citate
 - ▶ Test: fiecare slide de design citează o ecuație, un tabel sau o secțiune a articolului; alegerile nepublicate sunt marcate ca ale noastre
- **Fără informație din viitor:** λ , scalele, c și trăsăturile folosesc doar date disponibile la origine
 - ▶ Test: schimbați fiecare valoare de după origine (de exemplu, înmulțiți RV viitoare cu 10); prognoza făcută la origine nu trebuie să se schimbe
- **Reperul izolează ideea**
 - ▶ Test: ablația 2×2 este raportată, nu doar modelul complet față de HAR
- **Funcțiile de pierdere și testele sunt aplicate corect**
 - ▶ Test: $QLIKE(RV, RV) = 0$ și $QLIKE(RV, F) > 0$ în rest; varianța DM este HAC cu lățimea de bandă cel puțin h

Mini-caz: trei titluri din aceleași rulări

- „Signaturile bat HAR pe 16 din 50 de active” (orizont de o zi, DM necorectat)
 - ▶ Adevărat, dar log-HAR singur bate HAR pe 21: câștigul aparține transformării logaritmice
- „Signaturile îmbunătățesc prognozele de volatilitate pentru E-mini S&P 500” (ES, $h = 1$, DM $t = -3,84$ față de log-HAR)
 - ▶ O celulă din 150 de celule activ-orizont: după Holm, 1 din 50 la $h = 1$ și niciuna la $h = 5, 22$
- Titlul preînregistrat: „niciun câștig față de log-HAR; mai slab la orizonturi mai lungi; ponderile nucleului inerte”
 - ▶ Un asistent AI rugat să „găsească unde funcționează metoda” le va produce pe primele două; planul îl protejează pe al treilea

Rândul vostru

- Alegeți o direcție deschisă din acest capitol (nucleu care vede nivelul, semnături intraday, log-semnături, doar futures)
 - ▶ Scrieți H_0/H_1 , reperul care o izolează și rezultatul care v-ar face să renunțați la ea
- Folosiți un asistent pentru a lista ce poate merge prost în designul vostru, apoi scrieți un test unitar pentru fiecare element
- Salvați preînregistrarea înaintea primei cifre în afara eșantionului; rulați grila; raportați distribuția pe $\mathcal{S}$
- Notați fiecare eroare AI prinsă în `AI_ERRORS.md` (Seminarul 20, C2 dă trei erori tipice)

Idei de reținut

- ▣ Signaturile transformă o fereastră într-un vector de trăsături cu o teorie în spate: identitatea lui Chen, unicitate, universalitate
- ▣ Transferată la varianța realizată, metoda lui Gu et al. nu bate log-HAR: egalitate la o zi, pierdere la o săptămână și la o lună
- ▣ Ponderile nucleului rămân aproape plate și reduc ponderea stresului trecut: nucleul invariant la translație vede forma, nu nivelul
- ▣ Cel mai puternic efect din studiu este cel mai vechi: modelați logaritmul RV
- ▣ Un rezultat nul preînregistrat, cu ablații și cu un mecanism, este o concluzie

Studiu suplimentar

Lecturi

- Signaturi: Chevyrev & Kormilitzin (2016); Lyons & McLeod (2022); măsuri realizate: Franke, Härdle & Hafner (2019) și Capitolul 9

Cursuri avansate pe quantinar.com

-  Statistics of Financial Markets
-  Applied Time Series Analysis with Python
-  Machine Learning in Financial Risk

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_20; date: VOLARE, gratuit pentru cercetare la volare.unime.it

Bibliografie (1/2)

- ▣ Barndorff-Nielsen, O.E., Hansen, P.R., Lunde, A., Shephard, N. (2008). [Designing realized kernels to measure the ex post variation of equity prices in the presence of noise](#). *Econometrica*, 76(6), 1481–1536.
- ▣ Barndorff-Nielsen, O.E., Kinnebrock, S., Shephard, N. (2010). [Measuring downside risk: realised semivariance](#). In *Volatility and Time Series Econometrics*, Oxford University Press, 117–136.
- ▣ Barndorff-Nielsen, O.E., Shephard, N. (2002). [Econometric analysis of realized volatility and its use in estimating stochastic volatility models](#). *Journal of the Royal Statistical Society B*, 64(2), 253–280.
- ▣ Belloni, A., Chernozhukov, V. (2013). [Least squares after model selection in high-dimensional sparse models](#). *Bernoulli*, 19(2), 521–547.
- ▣ Benjamini, Y., Hochberg, Y. (1995). [Controlling the false discovery rate: a practical and powerful approach to multiple testing](#). *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- ▣ Bollerslev, T., Patton, A.J., Quaedvlieg, R. (2016). [Exploiting the errors: a simple approach for improved volatility forecasting](#). *Journal of Econometrics*, 192(1), 1–18.
- ▣ Chen, K.-T. (1957). [Integration of paths, geometric invariants and a generalized Baker–Hausdorff formula](#). *Annals of Mathematics*, 65(1), 163–178.
- ▣ Chevyrev, I., Kormilitzin, A. (2016). [A primer on the signature method in machine learning](#). arXiv:1603.03788.
- ▣ Cipollini, F., Cruciani, G., Gallo, G.M., Insana, A., Otranto, E., Spagnolo, F. (2026). [VOLatility Archive for Realized Estimates \(VOLARE\)](#). arXiv:2602.19732.
- ▣ Corsi, F. (2009). [A simple approximate long-memory model of realized volatility](#). *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Cuchiero, C., Gazzani, G., Svaluto-Ferro, S. (2023). [Signature-based models: theory and calibration](#). *SIAM Journal on Financial Mathematics*, 14(3), 910–957.
- ▣ Diebold, F.X., Mariano, R.S. (1995). [Comparing predictive accuracy](#). *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Giacomini, R., White, H. (2006). [Tests of conditional predictive ability](#). *Econometrica*, 74(6), 1545–1578.
- ▣ Gu, H., Guo, X., Jacobs, T.L., Kaminsky, P., Li, X. (2024). [Transportation marketplace rate forecast using signature transform](#). *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 4997–5005; arXiv:2401.04857.
- ▣ Hambly, B., Lyons, T. (2010). [Uniqueness for the signature of a path of bounded variation and the reduced path group](#). *Annals of Mathematics*, 171(1), 109–167.

Bibliografie (2/2)

- ▣ Hansen, P.R., Huang, Z., Shek, H.H. (2012). Realized GARCH: a joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6), 877–906.
- ▣ Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- ▣ Király, F.J., Oberhauser, H. (2019). Kernels for sequentially ordered data. *Journal of Machine Learning Research*, 20(31), 1–45.
- ▣ Levin, D., Lyons, T., Ni, H. (2013). Learning from the past, predicting the statistics for the future, learning an evolving system. arXiv:1309.0260.
- ▣ Liu, L.Y., Patton, A.J., Sheppard, K. (2015). Does anything beat 5-minute RV? A comparison of realized measures across multiple asset classes. *Journal of Econometrics*, 187(1), 293–311.
- ▣ Lyons, T. (1998). Differential equations driven by rough signals. *Revista Matemática Iberoamericana*, 14(2), 215–310.
- ▣ Lyons, T., McLeod, A.D. (2022). Signature methods in machine learning. arXiv:2206.14674.
- ▣ Menkveld, A.J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). Nonstandard errors. *Journal of Finance*, 79(3), 2339–2390.
- ▣ Morrill, J., Fermanian, A., Kidger, P., Lyons, T. (2020). A generalised signature method for multivariate time series feature extraction. arXiv:2006.00873.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Patton, A.J., Sheppard, K. (2015). Good volatility, bad volatility: signed jumps and the persistence of volatility. *Review of Economics and Statistics*, 97(3), 683–697.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- ▣ Salvi, C., Cass, T., Foster, J., Lyons, T., Yang, W. (2021). The signature kernel is the solution of a Goursat PDE. *SIAM Journal on Mathematics of Data Science*, 3(3), 873–899.
- ▣ Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society B*, 58(1), 267–288.
- ▣ Zou, H. (2006). The adaptive lasso and its oracle properties. *Journal of the American Statistical Association*, 101(476), 1418–1429.