

Modelarea piețelor financiare

Capitolul 20 (capitol special): Semnătura traiectoriilor și volatilitatea realizată — un studiu de cercetare

Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Îmbunătățește o metodă construită pentru tarife de transport prognoza volatilității?

Forma traiectoriilor și prognoza volatilității

- Un studiu de cercetare: metoda lui Gu et al. (2024), publicată pentru tarifele de transport de la Amazon, aplicată variantei realizate zilnice a 50 de active din VOLARE (VOLatility Archive for Realized Estimates, o arhivă de măsuri realizate) Cipollini et al. (2026)
- Parcurs principal: ținte și pierderi, HAR, traiectoria și exemplul de semnătură, ponderile nucleului, apoi comparația empirică. Teoria rough paths, universalitatea și discuția ecuațiilor cu derivate parțiale sînt pentru aprofundare
- Partea a II-a: articolul lui Gu et al., un plan de analiză fixat înaintea rezultatelor, rezultate, robustețe, o parcurgere a buclei de descoperire științifică asistate de AI (Artificial Intelligence, inteligență artificială)
- Detaliile de implementare sînt în Anexa de la final

Ce trebuie să poți face

- calcula semnătura unei traiectorii liniare pe porțiuni și interpreta aria ei Lévy
- construi trăsături (variabile) de semnătură și ponderi de nucleu pentru o prognoză a volatilității
- compara prognoze pe multe active cu teste Diebold–Mariano (DM), mulțimi de încredere pentru modele și corecții Holm și Benjamini–Hochberg (BH)
- preînregistra aplicarea unei metode într-un domeniu nou și raporta un rezultat nul împreună cu mecanismul lui

De ce prognozăm varianța realizată?

- Volatilitatea intră în calculul aproape tuturor indicatorilor de risc din acest curs
  - Măsuri de tail risk (Capitolul 7), prețuri de opțiuni (Capitolul 12), ponderi de portofoliu (Capitolul 4)
- Datele intraday fac varianța zilnică aproape observabilă: varianța realizată (Realised Variance, RV, Capitolul 9)
  - Astfel, prognoza volatilității devine o problemă de regresie cu o țintă zgomotoasă, dar calculată fără a specifica un model parametric
- Reperul este greu de depășit: modelul HAR (Heterogeneous AutoRegressive, autoregresiv heterogen) Corsi (2009) (Capitolul 9)
  - Folosește trei medii ale valorilor trecute ale RV: zilnică, săptămînală și lunară
  - Este un model liniar, estimat prin OLS (Ordinary Least Squares, metoda celor mai mici pătrate) aproape instantaneu
- Orice metodă nouă trebuie să depășească HAR în afara eșantionului, pe multe active, cu un test corect

Două componente de testat: trăsăturile de semnătură și ponderile de nucleu

- Gu et al. descriu o fereastră recentă a unei serii ca o **traiectorie** și o rezumă prin **semnătura traiectoriei** (engl. *path signature*)
  - Trăsăturile de semnătură intră într-o regresie liniară cu puțini coeficienți nenuli (LASSO, Least Absolute Shrinkage and Selection Operator, aplicat în doi pași)
  - Perioadele trecute a căror traiectorie seamănă cu cea curentă primesc o pondere mai mare (un nucleu de semnătură)
- Ei raportează o creștere de peste cinci ori a acurateței față de o prognoză din industrie pentru tarifele de transport
  - Întrebare: îmbunătățește aceeași metodă modelele de tip HAR pentru varianța realizată?
- Fiecare componentă este testată separat, astfel încît un eventual cîștig poate fi atribuit trăsăturilor sau ponderilor



Wall Street și Bursa din New York, 25 martie 2020

Foto: Billie Grace Ward (2020); CC BY 2.0; Wikimedia Commons

Varianța realizată și variația pătratică (1/2)

- Modelul prețului: prețul logaritmic se modifică printr-un drift, un termen de difuzie și salturi

$$dp_t = \mu_t\, dt + \sigma_t\, dW_t + dJ_t$$

  - p_t: prețul logaritmic la momentul t (timpul este măsurat în zile)
  - μ_t: drift-ul, σ_t: volatilitatea instantanee, W_t: o mișcare browniană
  - J_t: un proces de salturi, cu ΔJ_s mărimea saltului la momentul s

- Varianța realizată: suma pătratelor randamentelor intraday din ziua t Barndorff-Nielsen & Shephard (2002)

$$\mathrm{RV}_t = \sum_{i=1}^{M} r_{t,i}^2 \xrightarrow{M\to\infty} \int_{t-1}^{t} \sigma_s^2\, ds + \sum_{t-1<s\le t} (\Delta J_s)^2$$

  - M: numărul de randamente intraday din ziua t (pentru o acțiune americană, 78 de randamente la cinci minute într-o zi de tranzacționare de 6,5 ore)
  - $r_{t,i}$: al i-lea randament logaritmic intraday din ziua t
  - Limita este variația pătratică a zilei t: varianța integrată plus suma pătratelor salturilor

Varianța realizată și variația pătratică (2/2)

- Fără salturi și fără zgomot, pe o grilă echidistantă, limita este varianța integrată, iar eroarea are o distribuție Normală mixtă

$$\sqrt{M}\,(\mathrm{RV}_t - \mathrm{IV}_t) \Rightarrow \mathrm{MN}(0,\ 2\,\mathrm{IQ}_t)\,, \qquad \mathrm{IV}_t = \int_{t-1}^{t} \sigma_s^2\, ds, \quad \mathrm{IQ}_t = \int_{t-1}^{t} \sigma_s^4\, ds$$

  - IV_t: varianța integrată, adică varianța adevărată a zilei t
  - IQ_t: cvarticitatea integrată
  - $\Rightarrow$: convergență în distribuție
  - $\mathrm{MN}(0, V)$: distribuția Normală mixtă, adică o distribuție Normală cu varianță aleatoare V
  - Condiționat de traiectoria volatilității, eroarea are distribuția Normală cu varianța $2\,\mathrm{IQ}_t/M$
- Interpretare: RV este o măsurare zgomotoasă a lui IV_t, iar zgomotul este cel mai mare în zilele volatile (unde IQ_t este mare)
  - Aceasta este eroarea de măsurare pe care o corectează HARQ, modelul HAR cu cvarticitatea realizată (secțiunea următoare)
- Zgomotul de microstructură introduce o deplasare în estimare la frecvențe foarte mari de eșantionare
- Randamentele la cinci minute sînt compromisul standard (Capitolul 9)
- Capitolul 9 deduce aceste rezultate; aici sînt folosite ca atare

Semivariațele și cvarticitatea din VOLARE

- Semivariațele Barndorff-Nielsen, Kinnebrock & Shephard (2010): RV descompusă după semnul randamentelor intraday

$$\mathrm{RV}_t^+ = \sum_{i=1}^{M} r_{t,i}^2 \, 1\{r_{t,i} > 0\}, \qquad \mathrm{RV}_t^- = \sum_{i=1}^{M} r_{t,i}^2 \, 1\{r_{t,i} < 0\}$$

  - $1\{\cdot\}$: funcția indicator, egală cu 1 dacă condiția este îndeplinită și cu 0 altfel
  - RV_t^+: varianța din creșteri, RV_t^-: varianța din scăderi
  - Suma lor este RV: $\mathrm{RV}_t = \mathrm{RV}_t^+ + \mathrm{RV}_t^-$ (în VOLARE, pînă la precizia mașinii)
- Cvarticitatea realizată: o estimare a lui IQ_t, scala erorii de măsurare a RV

$$\mathrm{RQ}_t = \frac{M}{3} \sum_{i=1}^{M} r_{t,i}^4 \;\to\; \mathrm{IQ}_t$$

  - Factorul $M/3$: un randament Normal cu varianța s^2 are momentul de ordinul patru $3s^4$, iar fiecare varianță la cinci minute este aproximativ IV_t/M
  - Limita cere un preț continuu, fără zgomot, și o grilă echidistantă
  - Un salt ΔJ adaugă aproximativ $M(\Delta J)^4/3$, deci RQ brută este sensibilă la salturi

De ce RV la cinci minute și de unde provin datele?

- Variația bipower (robustă la salturi), nucleul realizat (robust la zgomot) Barndorff-Nielsen et al. (2008), estimatori bazați pe amplitudinea zilnică a prețului (range)
- Ținta acestui capitol: RV la cinci minute
  - Pe 400 de active, puțini estimatori depășesc RV la cinci minute ca proxy al variației zilnice Liu, Patton & Sheppard (2015)
  - Semivariațele și cvarticitatea sînt calculate pe aceeași grilă temporală, deci SHAR (modelul HAR cu semivariațe) și HARQ folosesc date de intrare coerente
- Construită la universitățile din Messina și Florența din date tick cu tick Cipollini et al. (2026)
  - Curățarea datelor, calendarele de tranzacționare și precizia marcajelor de timp sînt specifice fiecărui activ
  - Aceiași estimatori sînt aplicați tuturor claselor de active
- Arhiva este gratuită pentru cercetare la volare.unime.it, dar nu este redistribuită împreună cu acest curs
  - Descărcați fișierele de variață realizată și setați în notebook-uri calea către folderul local
- Citarea cerută de autori
  - Cipollini, Cruciani, Gallo, Insana, Otranto și Spagnolo (2026), arXiv:2602.19732

Ținte și funcții de pierdere (1/2): ținta

- Ținta la orizontul h este media RV pe următoarele h zile

$$\mathrm{RV}_{t+\mathbf{1}:t+h} = \frac{1}{h}\sum_{j=\mathbf{1}}^{h} \mathrm{RV}_{t+j}, \qquad h \in \{1, 5, 22\}$$

  - t: originea prognozei (ultima zi observată)
  - $h = 1, 5, 22$: o zi, o săptămînă și o lună, măsurate în zile de tranzacționare
- Modelele logaritmice prognozează $y = \ln \mathrm{RV}_{t+\mathbf{1}:t+h}$ și revin la nivel cu o corecție de varianță

$$F_t = \exp(\hat{y}_t + \hat{s}^{\mathbf{2}}/2)$$

  - F_t: prognoza lui $\mathrm{RV}_{t+\mathbf{1}:t+h}$ făcută în t
  - $\hat{y}_t$: prognoza logaritmică estimată, $\hat{s}^{\mathbf{2}}$: varianța reziduurilor regresiei
  - $+\hat{s}^{\mathbf{2}}/2$: deoarece $\mathbb{E}[e^Z] = e^{\mu+s^{\mathbf{2}}/\mathbf{2}}$ pentru $Z \sim N(\mu, s^{\mathbf{2}})$
  - Corecția este exactă dacă eroarea logaritmică are condiționat distribuția Normală, cu varianță constantă, și aproximativă în rest
- Pentru $h > 1$ țintele se suprapun, ceea ce creează dependență serială (pînă la lagul $h-1$ prin construcție, posibil și mai departe)
- De aceea fiecare test folosește o varianță HAC (Heteroskedasticity and Autocorrelation Consistent, robustă la heteroscedasticitate și autocorelare)

Cum asociem prognoza cu ținta

- În definiția țintei, indicele desemnează originea prognozei. În formulele pierderilor și testelor, el identifică o pereche de evaluare: ținta realizată și prognoza făcută înainte ca ținta să fie observabilă.
- La închiderea de luni, pentru orizontul de o zi: informația pînă luni produce prognoza RV de marți. Alături se stochează realizarea de marți. Nu folosim o prognoză estimată după închiderea de marți.
- La orizontul de cinci zile, aceeași origine prognozează media de marți pînă lunea următoare (cinci zile de tranzacționare). Originea următoare produce altă țintă, suprapusă.
- DM și GW compară două prognoze cu aceeași țintă realizată pe fiecare rînd. Eticheta rîndului nu permite folosirea țintei la estimare.

Ținte și funcții de pierdere (2/2): pierderi robuste

- O funcție de pierdere este **robustă** dacă, pentru un proxy condiționat nedeplasat, ordinea pierderilor *așteptate* cu RV_t coincide cu cea cu varianța adevărată Patton (2011)
  - Condiționat nedeplasat: $\mathbb{E}_{t-1}[\mathrm{RV}_t] = \sigma_t^2$, unde $\mathbb{E}_{t-1}$ este media condiționată de informația pînă la $t-1$, iar σ_t^2 este varianța adevărată a zilei t
- Cele două pierderi robuste folosite aici (scrise pentru $h = 1$; pentru $h > 1$, RV_t se înlocuiește cu ținta)

$$\mathrm{MSE}_t = (\mathrm{RV}_t - F_t)^2, \qquad \mathrm{QLIKE}_t = \frac{\mathrm{RV}_t}{F_t} - \ln \frac{\mathrm{RV}_t}{F_t} - 1 \;\geq\; 0$$

  - F_t: prognoza lui RV_t
  - MSE (Mean Squared Error): eroarea pătratică
  - QLIKE (quasi-likelihood, pierderea de tip cvasi-verosimilitate) este zero doar dacă $F_t = \mathrm{RV}_t$ și crește mai repede cînd prognoza este prea mică decît cînd este prea mare
  - Exemplu cu $\mathrm{RV}_t = 1$: $F_t = 0{,}5$ dă $\mathrm{QLIKE}_t = 2 - \ln 2 - 1 = 0{,}307$, iar $F_t = 2$ dă $0{,}5 - \ln 0{,}5 - 1 = 0{,}193$
- QLIKE depinde de raportul RV_t / F_t: aceeași eroare proporțională produce aceeași pierdere într-o zi calmă ca într-o zi volatilă
- MSE este dominată de cîteva zile de criză
- QLIKE este pierderea principală, iar MSE cea secundară
- Modelele se compară prin pierderea medie pe zilele de evaluare

Petrol: ce prețuri intră în traiectorie?

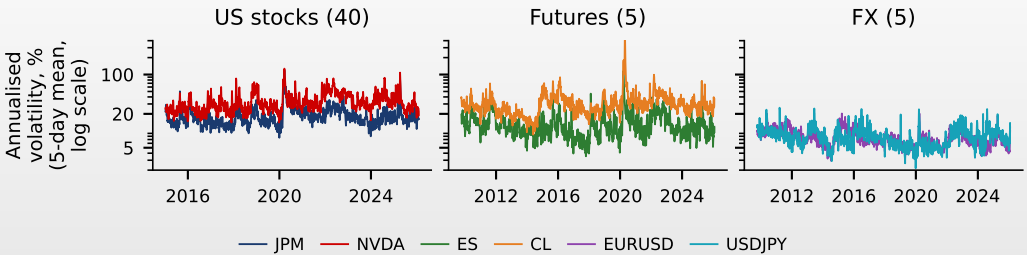
- CL desemnează futures pe petrol West Texas Intermediate (WTI). Prețul negativ din aprilie 2020 privea un anumit contract aproape de expirare. Nu înseamnă că orice serie continuă de petrol avea prețuri zilnice negative la deschidere și închidere.
- Seria CL folosită aici este cea furnizată de VOLARE. Prețurile zilnice de deschidere și închidere sînt pozitive în tot eșantionul; la 20 aprilie 2020 sînt 23,725 și 21,405.
- O serie continuă unește contracte succesive pe măsură ce se apropie de expirare. Regula de roll stabilește aceste legături. Calculăm randamentele logaritmice din prețurile pozitive furnizate; cotația negativă a unui singur contract nu le poate înlocui.

Panelul: 50 de active în trei clase

Clasa	Active	Eșantion	Observații	Volatilitate mediană
Acțiuni americane cu capitalizare mare	40	2 ian. 2015 – 30 ian. 2026	111 440	17,1%
Futures (C, CL, ES, GC, NG)	5	28 sept. 2009 – 30 ian. 2026	21 059	19,7%
FX (AUD, EUR, GBP, CAD, JPY față de USD)	5	25 sept. 2009 – 30 ian. 2026	21 203	7,3%

- Activele
  - Acțiuni: 40 de componente ale Dow Jones 30 și S&P 100, notate prin simbolul bursier, de la AAPL (Apple) la XOM (Exxon Mobil)
  - Futures: C = porumb, CL = petrol, ES = E-mini S&P 500, GC = aur, NG = gaze naturale
  - FX (foreign exchange, piața valutară): dolarul australian, euro, lira sterlină, dolarul canadian și yenul japonez față de dolarul american
- Volatilitatea mediană: $\sqrt{252\,\mathrm{mediana}(\mathrm{RV}_t)}$ pentru fiecare activ, apoi mediana clasei
  - Înmulțirea cu 252, numărul de zile de tranzacționare dintr-un an, transformă varianța zilnică în varianță anuală
  - Datele conțin doar zilele de tranzacționare
- Variabile: RV la cinci minute, semivarianțele RV^+, RV^-, cvarticitatea realizată (RQ), prețurile zilnice de deschidere și de închidere

Volatilitatea realizată în clasele de active



- Volatilitatea anualizată $\sqrt{252\,\mathrm{RV}_t}$ în %, medie pe cinci zile, scală logaritmică, două active pe clasă (acțiuni: JPM = JPMorgan Chase, NVDA = Nvidia; futures: ES = E-mini S&P 500, CL = petrol; FX: EURUSD = dolari SUA pentru un euro, USDJPY = yeni pentru un dolar SUA)
- Toate clasele au un vîrf în martie 2020, iar petrolul (CL) atinge maximul în aprilie 2020, cînd contractul futures cu scadența cea mai apropiată s-a tranzacționat la un preț negativ: un model de prognoză trebuie să se adapteze în cîteva zile
- Pe scală logaritmică volatilitatea este staționară și persistentă (memoria lungă pe care o aproximează HAR), iar vîrfurile se disipă în cîteva săptămîni, deci forma traiectoriei recente conține informație

MFM_ch20_case_study

HAR: trei medii ale trecutului (1/2)

- Modelul HAR Corsi (2009): RV viitoare este o funcție liniară de mediile zilnică, săptămînală și lunară ale RV trecute

$$\mathrm{RV}_{t+\mathbf{1}:t+h} = \beta_{\mathbf{0}} + \beta_d \,\mathrm{RV}_t + \beta_w \,\mathrm{RV}_t^{(w)} + \beta_m \,\mathrm{RV}_t^{(m)} + \varepsilon_{t+h}$$

$$\mathrm{RV}_t^{(w)} = \frac{1}{5}\sum_{j=\mathbf{0}}^{\mathbf{4}} \mathrm{RV}_{t-j}, \qquad \mathrm{RV}_t^{(m)} = \frac{1}{22}\sum_{j=\mathbf{0}}^{\mathbf{21}} \mathrm{RV}_{t-j}$$

- Notațiile
  - $\mathrm{RV}_t^{(w)}$, $\mathrm{RV}_t^{(m)}$: mediile săptămînală (5 zile) și lunară (22 de zile) ale RV pînă în ziua t
  - ε_{t+h}: eroarea de prognoză
  - $\beta_{\mathbf{0}}$: constanta
  - $\beta_d, \beta_w, \beta_m$ (în practică ≥ 0): cît contează ziua de ieri, ultima săptămînă și ultima lună, estimați prin OLS separat pentru fiecare orizont h
  - $\beta_d + \beta_w + \beta_m$ apropiat de 1: persistență ridicată a volatilității
- Intuiția: participanții la piață tranzacționează la orizonturi zilnice, săptămînale și lunare, iar această cascadă aproximează memoria lungă cu doar trei parametri

HAR: trei medii ale trecutului (2/2)

- HAR este un AR(22) restricționat: cei 22 de coeficienți ai lagurilor iau doar trei valori distincte

$$\phi_{\mathbf{1}} = \beta_d + \frac{\beta_w}{5} + \frac{\beta_m}{22}, \qquad \phi_{\mathbf{2..5}} = \frac{\beta_w}{5} + \frac{\beta_m}{22}, \qquad \phi_{\mathbf{6..22}} = \frac{\beta_m}{22}$$

  - ϕ_j: coeficientul lui $\mathrm{RV}_{t+\mathbf{1}-j}$ într-un AR(22) (autoregresie cu 22 de laguri)
  - Aceste valori rezultă prin explicitarea celor două medii

- log-HAR: aceeași regresie în logaritmi

$$\ln \mathrm{RV}_{t+\mathbf{1}:t+h} = \beta_{\mathbf{0}} + \beta_d \ln \mathrm{RV}_t + \beta_w \ln \mathrm{RV}_t^{(w)} + \beta_m \ln \mathrm{RV}_t^{(m)} + \varepsilon_{t+h}$$

  - Nu produce prognoze negative și este mai puțin dominat de vîrfuri
  - Revenirea la nivel se face cu $F_t = \exp(\hat{y}_t + \hat{s}^2/2)$
  - Logaritmul mediei nu este media logaritmilor, deci acest log-HAR nu este exact un AR(22) restricționat în $\ln \mathrm{RV}$ (Seminarul 20, A7)

Două rafinări (1/2): HARQ

- RV este un regresor generat: măsoară varianța adevărată cu o eroare

$$\mathrm{RV}_t = \mathrm{IV}_t + \eta_t, \qquad \mathrm{Var}(\eta_t) \approx 2\,\mathrm{IQ}_t/M$$

  - η_t: eroarea de măsurare
  - Erorile în variabile atenuează β_d (îl trag spre zero), mai ales în zilele zgomotoase

- HARQ Bollerslev, Patton & Quaedvlieg (2016): ponderea RV de ieri scade cînd RV este măsurată mai puțin precis

$$\mathrm{RV}_{t+\mathbf{1}:t+h} = \beta_{\mathbf{0}} + \left(\beta_d + \beta_Q(\mathrm{RQ}_t^{\mathbf{1/2}} - \overline{\mathrm{RQ}^{\mathbf{1/2}}})\right)\mathrm{RV}_t + \beta_w \mathrm{RV}_t^{(w)} + \beta_m \mathrm{RV}_t^{(m)} + \varepsilon_{t+h}$$

  - $\mathrm{RQ}_t^{\mathbf{1/2}}$: rădăcina pătrată a cvarticității realizate, o măsură a erorii lui RV_t
  - $\overline{\mathrm{RQ}^{\mathbf{1/2}}}$: media ei în eșantion, deci β_d este ponderea într-o zi obișnuită
  - Se așteaptă $\beta_Q < 0$: într-o zi zgomotoasă (RQ_t peste medie) RV de ieri primește o pondere mai mică

- Filtrul BPQ (Bollerslev, Patton și Quaedvlieg): o prognoză în afara intervalului din eșantion al țintei este înlocuită cu media din eșantion („insanity filter")

Două rafinări (2/2): SHAR

- SHAR Patton & Sheppard (2015): descompunem termenul zilnic după semnul randamentelor intraday

$$\mathrm{RV}_{t+\mathbf{1}:t+h} = \beta_0 + \beta^+ \mathrm{RV}_t^+ + \beta^- \mathrm{RV}_t^- + \beta_w \mathrm{RV}_t^{(w)} + \beta_m \mathrm{RV}_t^{(m)} + \varepsilon_{t+h}$$

  - RV_t^+, RV_t^-: semivariațele pozitivă și negativă ale zilei t
  - β^+, β^-: ponderile lor în prognoză
  - $\beta^+ = \beta^-$ readuce HAR, deoarece $\mathrm{RV}_t^+ + \mathrm{RV}_t^- = \mathrm{RV}_t$
- Patton și Sheppard găsesc $\beta^- > \beta^+$
  - Varianța din scăderi prezice mai multă variață viitoare decît varianța din creșteri: o versiune intraday a fenomenului leverage effect (Capitolul 5)
- Semnătura poate surprinde un efect înrudit din date zilnice: aria Lévy dintre randamente și log RV (secțiunea despre semnături)

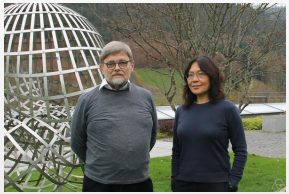
Șapte modele într-un tabel

Model	Țintă	Ponderi	Regresori
HAR	RV	egale	$\mathrm{RV}_t, \mathrm{RV}_t^{(w)}, \mathrm{RV}_t^{(m)}$
log-HAR	$\ln \mathrm{RV}$	egale	aceiași, în logaritmi
HARQ	RV	egale	HAR + $\mathrm{RV}_t \left(\mathrm{RQ}_t^{\mathbf{1/2}} - \overline{\mathrm{RQ}^{\mathbf{1/2}}}\right)$
SHAR	RV	egale	$\mathrm{RV}_t^+, \mathrm{RV}_t^-, \mathrm{RV}_t^{(w)}, \mathrm{RV}_t^{(m)}$
log-HAR-K	$\ln \mathrm{RV}$	nucleul de semnătură	regresorii log-HAR
Sig-L	$\ln \mathrm{RV}$	egale	log-HAR + 36 de termeni neconstanți ai semnăturii (39 înaintea eliminării constantelor), LASSO în doi pași
Sig-LK	$\ln \mathrm{RV}$	nucleul de semnătură	ca Sig-L: metoda lui Gu et al.

- Denumiri: L = LASSO, K = ponderi de nucleu
- În grafice, Sig-L apare ca „Signature LASSO", Sig-LK ca „Signature LASSO + kernel weights", iar log-HAR-K ca „log-HAR + kernel weights"
- Ultimele patru formează o analiză 2×2 pe componente (ablație: fiecare componentă inclusă sau exclusă pe rînd): trăsături de semnătură (da/nu) $\times$ ponderi de nucleu (da/nu)
- Log-HAR este reperul natural pentru modelele cu semnături: are aceeași țintă, iar regresorii lui se află printre candidați
- Totuși, LASSO poate elimina și termeni log-HAR, deci Sig-L față de log-HAR compară două proceduri, nu doar două mulțimi de variabile

Originile semnăturilor

- Chen (1957): integralele iterate ale unei traiectorii formează o algebră și o determină pînă la reparametrizare pentru traiectoriile cu canal de timp folosite aici, cu punctul inițial fixat
  - Kuo-Tsai Chen, geometria spațiilor de bucle
- Lyons (1998): teoria traiectoriilor aspre (rough paths), în care semnătura este mulțimea naturală de trăsături pentru ecuațiile diferențiale controlate
  - Soluția unei ecuații controlate de o traiectorie depinde de aceasta (în primă aproximare) doar prin semnătura ei
- Aplicații în învățarea automată: Levin, Lyons & Ni (2013), Chevyrev & Kormilitzin (2016), Lyons & McLeod (2022)
- Aplicații în finanțe: modele de prețuri bazate pe semnături Cuchiero, Gazzani & Svaluto-Ferro (2023)



Terry Lyons (stînga), Oberwolfach, 2024

Foto: Katrin Schmid (2024); CC BY-SA 2.0 DE; Wikimedia Commons

O fereastră de date este o traiectorie

- Considerăm ultimele L zile ale celor $d-1$ serii, adăugăm timpul ca un canal și unim punctele prin segmente

$$X : [0,1] \to \mathbb{R}^d, \qquad X_{u_i} = \Big(u_i,\ \ln \mathrm{RV}_{t-L+1+i},\ \textstyle\sum_{j \le t-L+1+i} r_j\Big), \qquad u_i = \tfrac{i}{L-1},\ i = 0, \ldots, L-1$$

  - L: lungimea ferestrei în zile (aici 22)
  - d: numărul de canale (aici $d = 3$: timp, log RV, randament cumulat)
  - $u_i \in [0,1]$: timpul rescalat al punctului i
  - $r_j = \ln(C_j/O_j)$: randamentul logaritmic de la deschidere la închidere al zilei j, cu O_j, C_j prețurile de deschidere și de închidere
  - Randamentele logaritmice se adună de la o zi la alta, deci suma lor cumulează randamentele intraday din fereastră, fără componenta overnight, pe cînd variațiile procentuale simple $C_j/O_j - 1$ se compun multiplicativ
  - Exemplu: de la 100 la 97, variația simplă este -3%, iar randamentul logaritmic $\ln 0{,}97 = -3{,}05\%$; de la 100 la 103: $+3\%$, respectiv $+2{,}96\%$
- **Augmentarea cu timpul**: primul canal este chiar timpul
  - Fără el, semnătura nu distinge o mișcare rapidă de una lentă (invarianța la reparametrizare)
- O regresie pe fereastră folosește 22 de laguri; un rezumat al traiectoriei surprinde și ordinea, viteza și co-mișcarea lor
  - Exemplu: RV a crescut în timp ce prețurile scădeau, sau RV a crescut întîi și prețurile au scăzut mai tîrziu

Semnătura: definiție (1/2)

- Un termen al semnăturii este o integrală iterată a traiectoriei de-a lungul unui cuvînt de canale

$$S(X)_{a,b}^{i_1 \cdots i_k} = \int_{a<u_1<\cdots<u_k<b} dX_{u_1}^{i_1} \cdots dX_{u_k}^{i_k}$$

- Notațiile
  - $X : [a, b] \to \mathbb{R}^d$: o traiectorie cu variație mărginită (lungime totală finită), de exemplu liniară pe porțiuni
  - X_u^i: canalul i al traiectoriei la momentul u
  - Cuvîntul $(i_1, \ldots, i_k)$: o listă ordonată de k canale, cu litere din $\{1, \ldots, d\}$
  - k este **nivelul** termenului
  - $u_1 < \cdots < u_k$: integrala se calculează pe momente ordonate
  - dX_u^i: incrementul canalului i la momentul u (pe un segment liniar, panta înmulțită cu du)

Semnătura: definiție (2/2)

- Semnătura este întregul șir de niveluri

$$\mathrm{Sig}(X) = (1,\ S^{(1)},\ S^{(2)},\ S^{(3)}, \dots), \qquad S^{(k)} \in (\mathbb{R}^d)^{\otimes k}$$

  - $S^{(k)}$: cei d^k termeni de nivelul k, unul pentru fiecare cuvînt de lungime k, aranjați ca un tablou k-dimensional (un tensor, iar $\otimes$ este produsul tensorial)
  - $\mathrm{Sig}^N(X)$: semnătura trunchiată, formată din nivelurile de la 0 la N, unde N este adîncimea
- Nivelul 1: incrementele totale ale canalelor

$$S^i = X_b^i - X_a^i$$

- Nivelul 2: incrementele canalului j ponderate cu cît s-a deplasat deja canalul i

$$S^{ij} = \int_a^b (X_u^i - X_a^i)\, dX_u^j$$

  - Nivelul 3 adaugă încă o integrală
  - Nivelurile superioare rețin detalii tot mai fine ale ordinii mișcărilor

Segmente liniare și identitatea lui Chen (1/2)

- Un segment liniar cu incrementul $\Delta \in \mathbb{R}^d$ are ca semnătură exponențiala tensorială

$$\mathrm{Sig}(\text{segment}) = \exp_{\otimes}(\Delta) = \left(1,\ \Delta,\ \tfrac{1}{2!}\Delta^{\otimes \mathbf{2}},\ \tfrac{1}{3!}\Delta^{\otimes \mathbf{3}}, \dots\right)$$

  - $\Delta = X_b - X_a$: incrementul segmentului
  - $\Delta^{\otimes k}$: tabloul tuturor produselor $\Delta^{i_\mathbf{1}} \cdots \Delta^{i_k}$, deci un termen de nivelul k este $\Delta^{i_\mathbf{1}} \cdots \Delta^{i_k}/k!$

- **Identitatea lui Chen** Chen (1957): semnătura a două traiectorii parcurse una după alta este produsul tensorial al semnăturilor lor

$$\mathrm{Sig}(X * Y) = \mathrm{Sig}(X) \otimes \mathrm{Sig}(Y), \qquad \left(A \otimes B\right)^{(k)} = \sum_{p=\mathbf{0}}^{k} A^{(k-p)} \otimes B^{(p)}$$

  - $X * Y$: concatenarea, în care Y începe unde se termină X
  - $A^{(k)}$, $B^{(k)}$: nivelul k al semnăturilor A, B, cu $A^{(\mathbf{0})} = B^{(\mathbf{0})} = 1$
  - Nivelul k al traiectoriei întregi adună toate modurile de a împărți un cuvînt de lungime k între prima și a doua bucată

Segmente liniare și identitatea lui Chen (2/2)

- O traiectorie liniară pe porțiuni cu m segmente, cu incrementele $\Delta_1, \ldots, \Delta_m$

$$\mathrm{Sig} = \exp_{\otimes}(\Delta_1) \otimes \cdots \otimes \exp_{\otimes}(\Delta_m)$$

  - Întregul algoritm: m actualizări, fiecare cu un cost de ordinul $O(d^N)$ operații la adîncimea N (cîteva rînduri de cod numpy)

- Ferestre mobile: identitatea lui Chen permite și eliminarea unei porțiuni inițiale

$$\mathrm{Sig}(X_{[s,t]}) = \mathrm{Sig}(X_{[a,s]})^{-1} \otimes \mathrm{Sig}(X_{[a,t]})$$

  - $X_{[s,t]}$: traiectoria restrînsă la $[s,t]$, cu $a \leq s \leq t$
  - $(\cdot)^{-1}$: inversul față de $\otimes$, adică semnătura porțiunii parcurse în sens invers

Exemplu rezolvat: o traiectorie cu două segmente

Traiectoria

- $X : (0,0) \to (1,0) \to (1,2)$; $\Delta_1 = (1,0)$, $\Delta_2 = (0,2)$
- Nivelul 1: $S^{(1)} = \Delta_1 + \Delta_2 = (1,2)$
- Nivelul 2 prin Chen: $S^{ij} = \frac{1}{2}\Delta_1^i\Delta_1^j + \Delta_1^i\Delta_2^j + \frac{1}{2}\Delta_2^i\Delta_2^j$
- Δ_m^i: componenta i a incrementului segmentului m
- Termenul din mijloc: canalul i se mișcă în segmentul 1 înainte ca j să se miște în segmentul 2

Rezultat

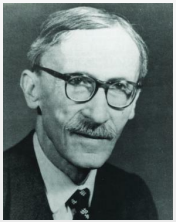
- $S^{11} = \frac{1}{2}$, $S^{12} = 0 + 1 \cdot 2 + 0 = 2$
- $S^{21} = 0$, $S^{22} = \frac{1}{2} \cdot 2^2 = 2$
- Verificare: $S^{11} = (\Delta X^1)^2/2$ și $S^{22} = (\Delta X^2)^2/2$ (identitatea shuffle: produsul a două coordonate de nivel 1 este suma celor două ordonări de nivel 2)
- $S^{12} \neq S^{21}$: ordinea contează (întîi la dreapta, apoi în sus)

Aria Lévy: ordinea exprimată numeric

- Aria Lévy A^{ij}: partea antisimetrică a nivelului 2

$$A^{ij} = \tfrac{1}{2}\left(S^{ij} - S^{ji}\right)$$

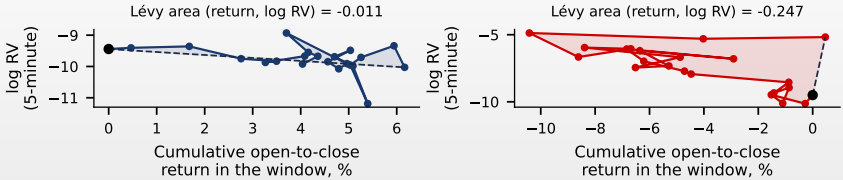
  - Este aria cu semn dintre traiectorie, proiectată pe canalele (i, j), și coarda ei (dreapta de la început la sfîrșit)
  - $A^{ij} > 0$: canalul i tinde să se miște înaintea canalului j
  - Aria este antisimetrică: $A^{ij} = -A^{ji}$
- Partea simetrică: $\frac{1}{2}(S^{ij} + S^{ji}) = \frac{1}{2}\,\Delta X^i\,\Delta X^j$, care nu aduce nicio informație nouă
  - Exemplul de mai sus: $A^{\mathbf{12}} = (2-0)/2 = 1$, aria triunghiului de sub traiectorie
- Canalele (randament, log RV): o scădere a prețului urmată de o creștere a volatilității dă $A < 0$, dar la fel și o creștere urmată de o scădere a volatilității
  - Aria Lévy este o statistică de tip lead-lag: secvențele de tip leverage effect (Capitolul 5) sînt doar una dintre sursele unei arii negative
  - Semnul singur nu permite identificarea lor



Paul Lévy (1886–1971)

Foto: Konrad Jacobs; CC BY-SA 2.0 DE; Wikimedia Commons

Două ferestre JPM reprezentate ca traiectorii



- Traiectoria pe 22 de zile are două canale, randamentul cumulat de la deschidere la închidere și log RV; coarda punctată unește începutul și sfîrșitul, iar zona hașurată dă aria Lévy
- Fereastra calmă (pînă la 15 nov. 2019): log RV se schimbă cu -0,58, traiectoria fluctuează fără direcție, iar aria Lévy este -0,011
- Fereastra de stres (pînă la 16 mar. 2020): log RV crește cu +4,32 (RV se înmulțește cu 75) în timp ce traiectoria randamentelor intraday scade și apoi recuperează, iar aria Lévy este -0,247 (randamente zecimale la calculul ariei, procente pe axă)
- Randamentul intraday net este doar +0,5%: crahul s-a produs în mare parte peste noapte, în afara acestui canal, iar nicio adîncime a semnăturii nu poate recupera informația absentă din date

MFM_ch20_signatures

Fundamentele teoretice ale semnăturilor (1/2): unicitate și shuffle

- **Unicitate** Hambly & Lyons (2010): semnătura completă identifică traiectoria
  - $\mathrm{Sig}(X)$ determină X pînă la o echivalență de tip arbore (adăugarea unor porțiuni parcurse apoi înapoi) și o translație
  - Cu un canal de timp strict crescător nimic nu poate fi parcurs înapoi, deci rămîne doar translația
  - O trunchiere finită Sig^N nu este injectivă: două traiectorii diferite pot avea aceleași niveluri $1..N$
- **Identitatea shuffle**: un produs de termeni ai semnăturii este o sumă de termeni superiori

$$S^i S^j = S^{ij} + S^{ji}, \qquad S^{ij} S^k = S^{ijk} + S^{ikj} + S^{kij}$$

  - Suma se face pe toate intercalările (shuffle) ale celor două cuvinte care păstrează ordinea din fiecare cuvînt
  - Deci un model liniar în $\mathrm{Sig}^N(X)$ conține deja polinoame în incremente

Fundamentele teoretice ale semnăturilor (2/2): universalitate și descreștere

- **Universalitate**: orice funcție continuă de traiectorie este aproximativ liniară în semnătură (Stone–Weierstrass, prin identitatea shuffle)

$$\forall \varepsilon > 0 \;\; \exists\, \ell \text{ liniară} : \quad \sup_{X \in K} \left| f(X) - \langle \ell, \mathrm{Sig}(X) \rangle \right| < \varepsilon$$

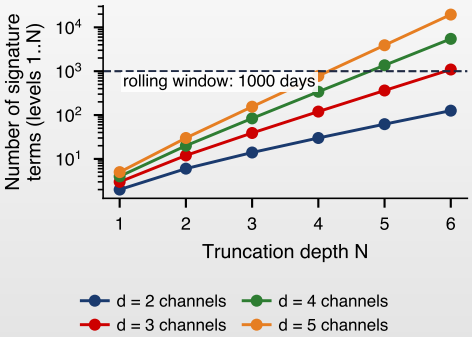
  - K: o mulțime compactă de traiectorii augmentate cu timpul, cu start comun (în topologia 1-variației)
  - $f : K \to \mathbb{R}$: o funcție continuă de traiectorie
  - $\langle \ell, \mathrm{Sig}(X) \rangle$: o sumă ponderată a unui număr finit de termeni ai semnăturii, adică o regresie liniară pe aceștia
  - O adîncime suficientă permite aproximarea neliniară; aceasta nu garantează precizia la adîncimea 3 sau în afara eșantionului
  - Costul este de d^N trăsături, deci este necesară o soluție cu puțini coeficienți nenuli

- **Descreștere factorială**: nivelurile înalte sînt mici

$$\|S^{(k)}\| \leq \frac{\|X\|_{\text{1-var}}^{k}}{k!}$$

  - $\|X\|_{\text{1-var}}$: lungimea totală a traiectoriei (suma lungimilor segmentelor)
  - $\|S^{(k)}\|$: mărimea (norma euclidiană) nivelului k
  - Trunchierea la o adîncime mică N pierde puțin pentru traiectorii de lungime moderată, motiv pentru care canalele se rescalează (Anexă)

Numărul de trăsături: dimensiunea trunchierii



- Numărul de termeni din nivelurile $1..N$ ale unei traiectorii d-dimensionale (o sumă geometrică, deoarece nivelul k are d^k cuvinte)
  - $\dim(d, N) = \sum_{k=\mathbf{1}}^{N} d^k = \frac{d^{N+\mathbf{1}} - d}{d - \mathbf{1}}$
- În acest capitol: $d = 3$ canale (timp, log RV, randament cumulat), adîncimea $N = 3$: $3 + 9 + 27 = 39$ de termeni
  - Trei sînt constanți (cuvintele doar cu litera timpului), deci 36 variază
- $d = 5$, $N = 4$ ar da 780 de termeni pentru 1 000 de observații: LASSO ar selecta zgomot
- Gu et al. nu publică N și L
- Aici $N = 3$ și $L = 22$ sînt fixate dinainte, iar $N = 2$ servește ca verificare de robustețe

MFM_ch20_signatures

Două invarianțe de reținut

- **Invarianța la translație**: $\mathrm{Sig}(X + c) = \mathrm{Sig}(X)$ pentru orice vector constant $c \in \mathbb{R}^d$: contează doar incrementele
  - Semnătura nu reflectă **nivelul** volatilității, doar forma traiectoriei recente
  - Deci nivelul trebuie să intre separat: termenii log-HAR joacă rolul factorilor externi x_τ ai lui Gu et al.
- **Invarianța la reparametrizare**: parcurgerea traiectoriei mai repede sau mai încet, $X_{\psi(u)}$ cu ψ crescătoare, lasă Sig neschimbată
  - Această invarianță este eliminată de canalul de timp
  - Augmentarea cu punct de bază (adăugarea la început a unui segment de la 0 la punctul de start inițial) ar elimina prima invarianță Morrill et al. (2020)
  - Translatarea traiectoriei ca să pornească din 0 nu o elimină: este ea însăși o translație (Seminarul 20, C2 folosește segmentul adăugat la început)

Nucleul de semnătură

- Nucleu = produsul scalar al aplicațiilor de trăsături Király & Oberhauser (2019): un scor de asemănare între două traiectorii

$$k_N(X, Y) = \langle \mathrm{Sig}^N(X), \mathrm{Sig}^N(Y) \rangle = 1 + \sum_{k=1}^{N} \sum_{|w|=k} S(X)^w S(Y)^w$$

  - X, Y: două traiectorii cu aceleași canale
  - w: un cuvînt de lungime $|w|$ (nivelul), iar $S(X)^w$ este termenul semnăturii corespunzător lui w
  - Termenul 1 din față corespunde nivelului 0
- Distanța indusă de nucleu (Gu et al., ec. 9): pătratul distanței euclidiene dintre semnăturile trunchiate

$$d_{\mathrm{Sig}}(X, Y) = k_N(X, X) - 2\, k_N(X, Y) + k_N(Y, Y) = \|\mathrm{Sig}^N(X) - \mathrm{Sig}^N(Y)\|^2$$

  - $d_{\mathrm{Sig}} = 0$: cele două ferestre au aceeași semnătură pînă la adîncimea N
  - d_{Sig} mare: forme diferite
- Gu et al. și acest capitol folosesc acest nucleu **trunchiat**, cu același N ca pentru trăsături
  - Nucleul netrunchiat rezolvă o ecuație cu derivate parțiale de tip Goursat (Partial Differential Equation, PDE) Salvi et al. (2021)
  - Articolul lui Gu et al. îl citează, dar nu îl folosește
- Canalele se rescalează înaintea nucleului (Anexă): altfel domină canalul cu unitățile cele mai mari

Problema de la Amazon și trăsăturile

- Tarife săptămînale pe piața nord-americană de transport rutier, la nivel național și în cinci regiuni, 2018–2022, prognozate pe pînă la 12 săptămîni Gu et al. (2024)
  - Peste 100 de factori candidați, reduși la aproximativ 40
  - Metoda este folosită în operațiunile Amazon din noiembrie 2022 și a fost publicată la KDD 2024 (Knowledge Discovery and Data Mining, conferința ACM, Association for Computing Machinery)
- Trăsăturile în săptămîna τ (Secțiunea 4.1, ec. 14): factorii externi x_τ și semnătura traiectoriei țintei, augmentată cu timpul
  - $\xi_\tau = \left[x_\tau,\ \mathrm{Sig}^N(\hat{y}_{\tau-l:\tau})\right], \quad \hat{y}_{\tau-l:\tau} = \{(t_i, y_{t_i})\}$
  - y_{t_i}: tariful din săptămîna t_i, cu $\tau - l \le t_i \le \tau$
  - l: lungimea ferestrei în săptămîni
  - $\hat{y}_{\tau-l:\tau}$: traiectoria augmentată cu timpul a ultimelor l săptămîni
- Pentru fiecare orizont Δt (în săptămîni) se estimează o regresie directă a lui $y_{\tau+\Delta t}$ pe ξ_τ
- Fereastra l, adîncimea N și temperatura γ (slide-urile următoare) nu sînt publicate, din motive de confidențialitate



Un camion cu container pe o autostradă americană, 2025

Foto: DanTD (2025); CC BY 4.0; Wikimedia Commons

Metoda: LASSO în doi pași

- Pasul 1, selecție printr-un LASSO ponderat Tibshirani (1996) (ec. 14)

$$\hat{\theta}_{\mathrm{L}} = \arg\min_{\theta} \sum_{\tau} w_{\tau} \left(y_{\tau+\Delta t} - \xi_{\tau}^{\top} \theta \right)^2 + \lambda \|\theta\|_1$$

  - θ: vectorul coeficienților, cu norma $\|\theta\|_1 = \sum_j |\theta_j|$
  - $w_\tau \geq 0$: ponderea săptămînii τ (egală sau dată de nucleu, slide-ul următor)
  - $\lambda \geq 0$: penalizarea, un λ mai mare anulează exact mai mulți coeficienți, iar $\lambda = 0$ înseamnă OLS ponderat
- Pasul 2, reestimare prin OLS ponderat pe suportul selectat (ec. 15)

$$\hat{\theta} = \arg \min_{\mathrm{supp}(\theta) = \mathrm{supp}(\hat{\theta}_{\mathrm{L}})} \sum_{\tau} w_{\tau} \left(y_{\tau+\Delta t} - \xi_{\tau}^{\top} \theta \right)^2$$

  - $\mathrm{supp}(\theta)$: suportul, adică mulțimea coeficienților nenuli, deci se reestimează doar regresorii păstrați la pasul 1
- Motivul reestimării: LASSO micșorează spre zero coeficienții păstrați, iar OLS după selecție elimină această deplasare Belloni & Chernozhukov (2013)
  - Articolul îl numește „adaptiv" din cauza ponderilor w_τ, nu în sensul LASSO-ului adaptiv al lui Zou (2006)
- Modul de alegere a lui λ nu este raportat

Alegerea penalizării LASSO în fiecare fereastră

- Articolul nu precizează selecția penalizării. Aici selecția se repetă în fiecare fereastră de antrenare, fără ținte din evaluare.
- LARS (Least Angle Regression) generează suporturi candidate de-a lungul traiectoriei de regularizare LASSO: soluțiile pe măsură ce penalizarea scade. Fiecare suport este reestimat prin OLS ponderat.
- BIC (Bayesian Information Criterion) echilibrează potrivirea cu numărul coeficienților selectați; cînd ponderile diferă, termenul de mărime a eșantionului folosește mărimea efectivă Kish $n_{\text{eff}} = 1/\sum_\tau w_\tau^2$, cu ponderi normalizate. Alegem suportul cu BIC minim.
- Selecția penalizării și formula BIC

Metoda: ponderi date de nucleu

- Distanța fiecărei ferestre trecute față de ultima fereastră cu țintă observată (ec. 11)

$$\delta_\tau = d_{\mathrm{Sig},N}\left(z_{\tau-l:\tau},\ z_{t-\Delta t-l:t-\Delta t}\right)$$

  - $z_\tau = (x_\tau, y_{\tau+\Delta t})$: *perechile* de predictori și țintă ulterioară, nu trăsăturile ξ_τ (Algoritmul 1)
  - $z_{\tau-l:\tau}$: traiectoria lor pe l săptămîni
  - t: săptămîna curentă, iar $t - \Delta t$ este ultima săptămînă a cărei țintă y_t este deja observată
  - $d_{\mathrm{Sig},N}$: distanța de semnătură la adîncimea N

- Ponderi softmax cu temperatura $\gamma \geq 0$ (ec. 12): ferestrele asemănătoare (δ_τ mic) primesc o pondere mai mare

$$w_\tau = \frac{\exp(-\gamma\,\delta_\tau)}{\sum_s \exp(-\gamma\,\delta_s)}$$

  - s: parcurge toate săptămînile de antrenare, deci ponderile însumează 1
  - Cazuri-limită: $\gamma = 0$ dă regresia obișnuită (ponderi egale), iar $\gamma \to \infty$ păstrează doar cea mai asemănătoare fereastră trecută

- O idee de tip cel mai apropiat vecin într-o regresie: învățăm din perioadele trecute care semănau cu prezentul
  - Costul ideii: mai puține observații efective, $n_{\mathrm{eff}} = 1/\sum_\tau w_\tau^2$ (Kish), cu $n_{\mathrm{eff}} = n$ pentru ponderi egale $1/n$, $n_{\mathrm{eff}} = 1$ dacă o singură săptămînă ia toată ponderea

Trei ferestre: ponderi și informație

- Considerăm distanțele $\delta = (0{,}1, 0{,}4, 0{,}9)$ și $\gamma = 2$. Ponderile nenormalizate sînt $(0{,}819, 0{,}449, 0{,}165)$, cu suma 1,433.
- Împărțim la sumă: $w = (0{,}571, 0{,}313, 0{,}115)$. Rezultă $n_{\text{eff}} = 1/\sum w_i^2 \approx 2{,}28$, față de 3 pentru ponderi egale.
- Parametrul numit temperatură în articol acționează ca o temperatură inversă: un γ mai mare concentrează ponderile. Cîștigăm asemănare, dar pierdem informație.
- Dublați γ: înaintea calculului, anticipați ce pondere crește și dacă mărimea efectivă urcă sau scade. Comparați cu limitele: ponderi egale și o singură fereastră selectată.

Rezultatele articolului: o lectură critică

- Tarife naționale, cu trei luni înainte, aprilie–noiembrie 2021 (Tabelul 1): eroarea relativă $|y - \hat{y}|/|y|$ (y: tariful realizat, $\hat{y}$: prognoza lui) de aproximativ 1–2% față de 13–27% pentru prognoza din industrie, „de peste cinci ori”
  - Orizonturi de 1–12 săptămîni (Tabelul 2): eroarea relativă este de 1,06–2,60% la nivel național și de 1,05–5,69% pe regiuni
  - Economia anuală estimată: aproximativ 50 de milioane de dolari
  - Ablația nucleului (Tabelul 3, șase valori săptămînale, 31 octombrie–5 decembrie 2021, o regiune): erori de pînă la 9,85% fără nucleu, față de pînă la 5,15% cu el
- Limitele dovezilor
  - **Un singur reper**: o prognoză comercială al cărei furnizor nu este precizat
  - Lipsesc comparațiile cu un model ARIMA (AutoRegressive Integrated Moving Average), cu un LASSO fără semnături și cu mersul aleator
  - **Evaluare scurtă**: cîteva luni, cîteva serii, fără erori standard, fără un test de acuratețe egală
  - **Calibrare nepublicată**: l, N, γ, λ și modul lor de alegere
- Aceste limite nu invalidează metoda, dar slăbesc dovezile
- De aceea o testăm în alt context: replicarea înaintea extinderii (Capitolul 19)

Transferul la volatilitate: componente preluate și adaptate

Se transferă

- Semnătura traiectoriei recente a țintei, augmentată cu timpul
- LASSO în doi pași cu ponderi, regresie directă pe orizont
- Ponderi softmax $\exp(-\gamma\,\delta_\tau)$ cu nucleul de semnătură trunchiat

Trebuie adaptat

- Țintă zilnică și zgomotoasă în loc de tarife săptămînale: de aici logaritmii, inferența HAC și pierderile robuste
- Factorii externi x_τ înlocuiți de termenii log-HAR (aceștia aduc informația despre nivel)
- Alegerile nepublicate (l, N, γ, λ) fixate dinainte în acest capitol
- Nucleul compară traiectoria din acest capitol (timp, $\ln \mathrm{RV}$, randament) care se termină în τ cu fereastra care se termină în t și este actualizat la fiecare 5 zile
- Gu et al. compară în schimb perechile $(x_\tau, y_{\tau+\Delta t})$ care se termină în $t - \Delta t$: aici este deci o adaptare
- Repere puternice și teste formale în locul unei singure prognoze comerciale

Patru ipoteze fixate înaintea rezultatelor

- **H1 (trăsături)**: termenii semnăturii aduc informație dincolo de log-HAR
  - Test: Sig-L față de log-HAR, aceeași țintă, aceleași ponderi egale
- **H2 (ponderi)**: ponderile de nucleu îmbunătățesc o regresie dată
  - Teste: Sig-LK față de Sig-L și log-HAR-K față de log-HAR
- **H3 (metoda)**: metoda completă a lui Gu et al. depășește familia HAR
  - Teste: Sig-LK față de HAR și față de log-HAR
  - Mulțimea de încredere pentru modele (Model Confidence Set, MCS), construită pentru toate cele șapte modele
- **H4 (stres)**: orice cîștig este mai mare în perioadele de stres (crahul din pandemia COVID-19 și șocul tarifelor americane din 2–30 aprilie 2025), unde ferestrele trecute asemănătoare ar trebui să conteze cel mai mult

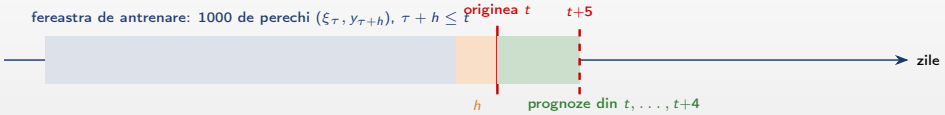
Temperatura nucleului: o alegere pe clasă, pe un bloc de validare

- Temperatură fără unități, fixată în fiecare fereastră de antrenare

$$\gamma = \frac{c}{\text{median}_\tau(\delta_\tau)}$$

  - δ_τ: distanțele nucleului dintre zilele de antrenare și fereastra curentă
  - $c > 0$: o constantă fără unități, singurul parametru de calibrare
  - Împărțirea la mediană elimină unitățile lui δ_τ
  - Cu $c = 1$, o fereastră aflată la distanța mediană primește ponderea e^{-1} față de una identică, iar un c mai mare concentrează ponderile
- Valoarea lui c din grila $\{0{,}5; 1; 2; 4\}$ se alege separat pentru fiecare orizont și clasă de active, pe primele 250 de zile de prognoză ale fiecărui activ, cumulate la nivelul clasei
  - Criteriul: QLIKE(c) al fiecărui activ, împărțit la media QLIKE a activului pe toată grila, apoi mediat pe clasă
  - Evaluarea începe după ultima țintă de validare a clasei, deci nicio țintă folosită la calibrare nu este ulterioară unei origini evaluate
- Pentru cele 40 de acțiuni, cea mai mică temperatură, $c = 0{,}5$ (ponderile cele mai apropiate de cele egale), este aleasă la fiecare orizont pentru Sig-LK
- Pentru futures și FX alegerea se schimbă cu orizontul, semn că criteriul este plat și zgomotos (toate valorile sînt în Anexă)

Estimarea pe fereastră mobilă, pas cu pas



- Reestimăm la fiecare 5 zile de tranzacționare pe ultimele 1 000 de perechi complete
- Între reestimări coeficienții sînt ficși, dar regresorii se actualizează zilnic
- Distanțele nucleului se recalculează la fiecare reestimare, față de fereastra care se termină la originea t

Protocolul de evaluare (1/2): testul DM

- Pe activ și orizont: QLIKE și MSE medii, comparate prin testul DM (Diebold–Mariano) de acuratețe predictivă egală Diebold & Mariano (1995)

$$d_t = L(\mathrm{RV}_t, F_t^A) - L(\mathrm{RV}_t, F_t^B), \qquad \mathrm{DM} = \frac{\bar{d}}{\sqrt{\hat{\Omega}/T}}$$

  - L: funcția de pierdere (QLIKE sau MSE)
  - F_t^A, F_t^B: prognozele modelelor A și B, iar d_t este diferența dintre pierderile lor
  - $\bar{d}$: media lui d_t pe cele T zile de evaluare
  - $\hat{\Omega}$: varianța de termen lung Newey–West (HAC) a lui d_t, cu lățimea de bandă de $\max(h, \lceil T^{1/3} \rceil)$ laguri, unde $\lceil \cdot \rceil$ înseamnă rotunjire în sus

- Interpretare: sub $H_0 : \mathbb{E}[d_t] = 0$, DM are aproximativ distribuția $N(0,1)$
  - $\mathrm{DM} < -1{,}645$: modelul A este semnificativ mai precis la 5% (test unilateral)
  - $\mathrm{DM} > 1{,}645$: modelul A este semnificativ mai puțin precis
  - Estimarea se face pe fereastră mobilă, deci testul se interpretează ca testul GW (Giacomini–White) necondiționat
  - Testul GW condiționat verifică în plus dacă d_{t-h} prezice d_t (cu instrumentele $(1, d_{t-h})$) Giacomini & White (2006)

De la diferența de pierdere la mai multe teste

- Să presupunem că diferența medie de pierdere (candidat minus reper) este $-0{,}02$, cu eroarea standard HAC 0,01. Statistica DM este -2: o p-value Normală unilaterală de circa 0,023 susține candidatul într-un singur test.
- Pentru trei p-value-uri ordonate $(0{,}004, 0{,}023, 0{,}08)$, Holm compară succesiv cu $(0{,}05/3, 0{,}05/2, 0{,}05)$. Primele două trec, a treia nu. Ne oprim la primul eșec.
- BH le compară cu $(0{,}05/3, 2 \cdot 0{,}05/3, 0{,}05)$ și alege cel mai mare rang care trece: tot două aici. Holm controlează la 5% probabilitatea de a face cel puțin o respingere falsă; BH controlează proporția medie a respingerilor false, sub ipotezele sale de dependență.
- Măriți acum familia la 50 de teste: aceleași p-value-uri pot să nu mai treacă. Familia este aleasă înaintea rezultatelor; Seminarul 20 B4 parcurge familia efectivă de active.

Protocolul de evaluare (2/2): multe modele, multe active

- MCS (Model Confidence Set, mulțimea de încredere a modelelor) la 90% Hansen, Lunde & Nason (2011): mulțimea de modele care conține cel mai bun model cu probabilitate de cel puțin 90%
  - Construită prin eliminare: cît timp statistica $T_{\max}$ (cea mai mare diferență standardizată dintre pierderea medie a unui model și media modelelor aflate încă în mulțime) respinge acuratețea egală, se elimină cel mai slab model
  - Valorile p se obțin prin bootstrap staționar, cu 1 000 de replicări și lungimea medie a blocului de $\max(h, 10)$ zile
- Testul pe panel: testul DM aplicat diferenței medii de pierdere pe secțiune transversală (o singură serie, cu o valoare pe dată)
  - Numărăm activele (din 50) cu rezultate semnificativ mai bune
  - Corecția Holm controlează FWER (Family-Wise Error Rate, probabilitatea a cel puțin unei respingeri false)
  - Corecția BH Benjamini & Hochberg (1995) controlează FDR (False Discovery Rate, proporția așteptată de respingeri false printre respingeri)
- Trei subperioade: 20 feb.–30 apr. 2020 (crahul COVID-19), 2–30 apr. 2025 (șocul tarifelor americane) și toate celelalte zile
- Eroarea relativă folosită în articol este raportată doar ca statistică descriptivă: definiție și rezultate
- Perioadele de evaluare pe clase și numărul prognozelor: Anexă

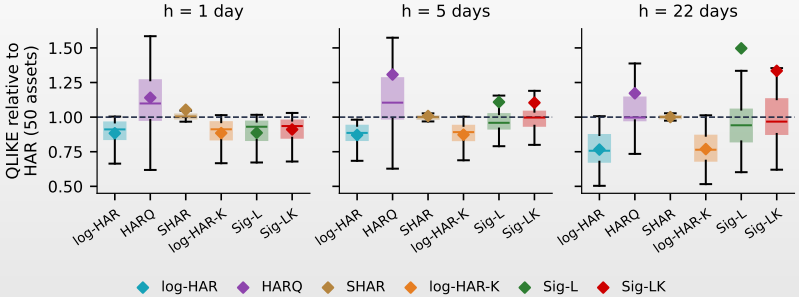
Cum se restrînge mulțimea de modele

- Pornim cu trei modele A, B și C. Să presupunem că diferențele standardizate de pierdere sînt 2,4; -0,5; -0,7, iar p-value bootstrap pentru acuratețe egală este 0,04. La 10%, respingem și eliminăm A, modelul cu cea mai mare diferență standardizată.
- Recalculăm mediile, erorile standard și testul bootstrap doar cu B și C. Dacă noua p-value este 0,30, ne oprim: rămîn B și C. Faptul că testul nu le separă nu dovedește că pierderile lor în populație sînt egale.
- Acoperirea nominală de 90% este o garanție pe eșantioane repetate, sub ipotezele procedurii, nu o probabilitate a posteriori pentru mulțimea obținută. Reeșantionăm seriile de pierdere împreună, pentru a păstra dependența dintre modele.
- Verificare: dacă prima p-value bootstrap ar fi 0,14, ce modele ar rămîne? Explicați de ce alegerea exclusivă a celei mai mici medii din eșantion este o altă regulă.

O abatere declarată

- Preînregistrat: filtrul BPQ („insanity filter") pe toate modelele
  - Un test al codului pe JPM (un singur activ, înaintea oricărui rezultat pe panel) a arătat că înlocuiește prognoze corecte din perioada crahului cu media din perioada calmă a eșantionului
  - Pe 12 martie 2020, RV observată în ziua următoare pentru JPM a fost de aproximativ 40 de ori mai mare decît prognoza HAR filtrată
- Modificare făcută înainte de estimarea pe panelul de 50 de active: rezultatele principale folosesc doar regula de pozitivitate (o prognoză ≤ 0 devine media din eșantion)
  - Filtrul BPQ rămîne ca verificare de robustețe și este raportat complet
- Regula: o abatere este permisă, o abatere ascunsă nu
- Precizați ce ați observat înainte de modificare

QLIKE relativ la HAR, activ cu activ



- Raportul pentru fiecare activ: QLIKE medie a modelului împărțită la QLIKE medie a HAR, iar un raport sub 1 înseamnă un model mai precis decît HAR
  - Fiecare cutie acoperă intervalul intercuartilic pe cele 50 de active, linia din cutie este mediana, rombul este media, iar mustățile se întind pe 1,5 intervale intercuartilice

MFM_ch20_case_study

Media pierderilor relative pe active

- Calculăm întîi QLIKE mediu în timp pentru un activ. Îl împărțim la media reperului pentru același activ. Apoi facem media rapoartelor pe active, cu ponderi egale.
- Exemplu: pierderile modelului $(0{,}5, 2)$ și ale reperului $(1, 0{,}5)$ dau raportul mediu $(0{,}5 + 4)/2 = 2{,}25$. Raportul mediilor agregate este însă $2{,}5/1{,}5 = 1{,}67$.
- Schimbarea reperului cere recalcularea rapoartelor pe fiecare activ. Împărțirea a două medii raportate față de HAR nu dă raportul mediu față de log-HAR.
- Aceeași convenție se aplică ablației și rezultatelor filtrate. Medianele descriu un activ tipic; mediile rămîn sensibile la cîteva pierderi mari.

Interpretarea comparației QLIKE

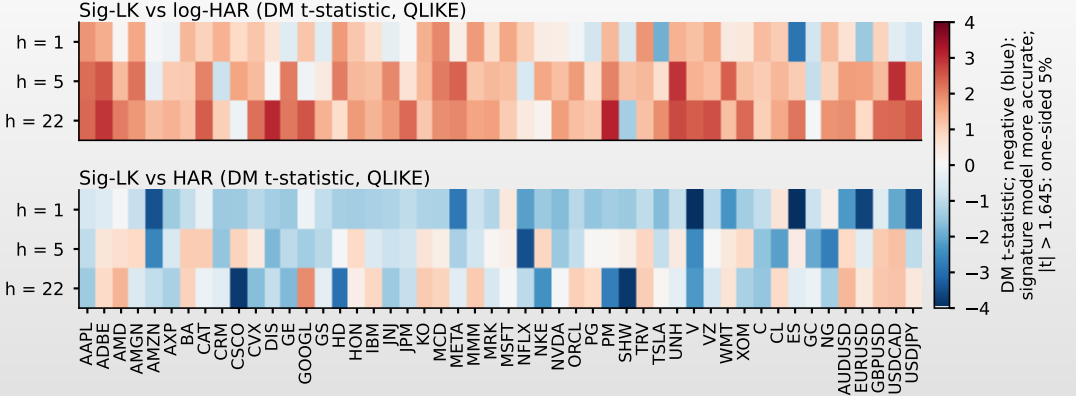
- La orizontul de o zi ($h = 1$), log-HAR, log-HAR-K și Sig-L au rapoarte apropiate: 0,883 pentru log-HAR, 0,885 pentru log-HAR-K și 0,886 pentru Sig-L
  - Diferența relativă de QLIKE a Sig-LK față de log-HAR este de +4,5%: cele 36 de trăsături în plus nu aduc niciun cîștig
- La o săptămînă și la o lună, Sig-LK rămîne în urma log-HAR: diferența relativă de QLIKE este de +28,0% la $h = 5$ și de +92,9% la $h = 22$
  - Medianele rapoartelor față de HAR (0,997 la $h = 5$ și 0,968 la $h = 22$) sînt mult mai bune decît mediile: pierderea provine de la cîteva active și zile
- HARQ și SHAR sînt aici inferioare modelului HAR în nivel
  - Specificația principală nu aplică filtrul BPQ (Anexa arată că filtrul ameliorează HARQ)
- Primul verdict: metoda nu depășește cel mai simplu model logaritmic
  - O egalitate aproximativă nu dovedește acuratețe egală

Comparații activ cu activ, cu corecție pentru testare multiplă

Comparația (QLIKE)	$h = 1$	$h = 5$	$h = 22$
Sig-LK față de log-HAR	2/0/0 | 5/0/0	0/0/0 | 15/0/2	0/0/0 | 27/1/16
Sig-L față de log-HAR	3/1/1 | 5/0/0	0/0/0 | 9/0/0	1/0/0 | 21/0/0
log-HAR-K față de log-HAR	3/0/0 | 3/0/0	3/0/0 | 1/0/0	5/0/0 | 6/0/0
Sig-LK față de Sig-L	2/0/0 | 5/0/0	0/0/0 | 5/0/0	2/0/0 | 10/0/0
Sig-LK față de HAR	12/5/6 | 0/0/0	7/1/1 | 0/0/0	8/2/4 | 1/0/0
log-HAR față de HAR	21/5/17 | 0/0/0	23/13/20 | 0/0/0	42/25/42 | 0/0/0

- Fiecare celulă: numărul de active semnificativ mai bune (fără corecție/Holm/BH) | numărul de active semnificativ mai slabe (fără corecție/Holm/BH)
- Test DM unilateral la 5%, pe o familie de 50 de active
- Holm controlează FWER sub orice dependență, iar BH controlează FDR sub independență sau PRDS (Positive Regression Dependence on a Subset, dependență pozitivă de regresie pe o submulțime) Benjamini & Yekutieli (2001)
- H1 (semnături): la $h = 1$, Sig-L este superior lui log-HAR pe 3 din 50 de active fără corecție și pe 1 după corecția Holm
  - Doar din întîmplare ne-am aștepta la aproximativ 2,5 respingeri necorectate
- H2 (ponderi): log-HAR-K față de log-HAR și Sig-LK față de Sig-L: nicio diferență semnificativă după Holm, la niciun orizont
- Față de HAR la $h = 1$, Sig-LK este superior pe 12 active, dar log-HAR singur este superior pe 21: alegeți reperul care izolează ideea

Statisticile DM pentru fiecare activ și orizont (1/2)



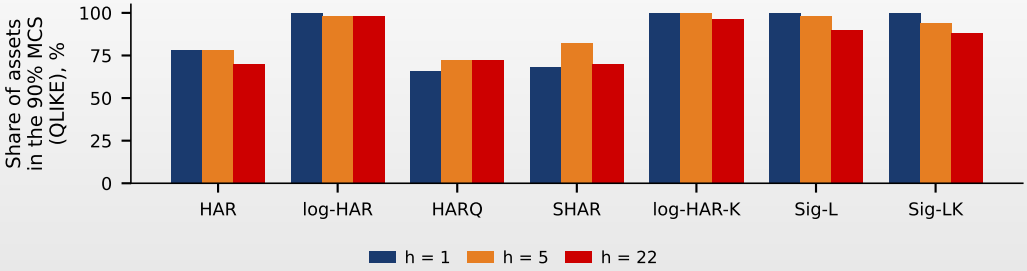
MFM_ch20_case_study

Statisticile DM pentru fiecare activ și orizont (2/2)

- Statisticile t Diebold–Mariano ale diferenței de QLIKE, cîte un rînd pentru simbolul fiecărui activ (40 de acțiuni, 5 futures, 5 perechi FX): albastru înseamnă că Sig-LK este mai precis, roșu că este mai puțin precis
- Față de log-HAR (stînga): culori palide la $h = 1$, cu excepțiile albastre ES, TSLA (Tesla) și EURUSD și cu cinci active semnificativ roșii înaintea corecției, iar la $h = 5, 22$ predomină roșul
- Față de HAR (dreapta): albastru la $h = 1$ pentru că Sig-LK moștenește ținta logaritmică

MFM_ch20_case_study

Mulțimi de încredere pentru modele



- Proporția activelor (din 50) pentru care fiecare model aparține MCS de 90% sub QLIKE, la $h = 1$, 5 și 22: pentru log-HAR 100%, 98% și 98%, iar pentru Sig-LK 100%, 94% și 88%
- MCS separă rar cele patru modele logaritmice, în schimb HAR, HARQ și SHAR sînt excluse pentru o cincime pînă la o treime dintre active: ținta în nivel este clar cea mai slabă alegere
- Sub MSE aproape fiecare model rămîne în mulțime Patton (2011): diferențele mici de pierdere medie cer eșantioane foarte lungi Pele & Mazurencu-Marinescu-Pele (2026)

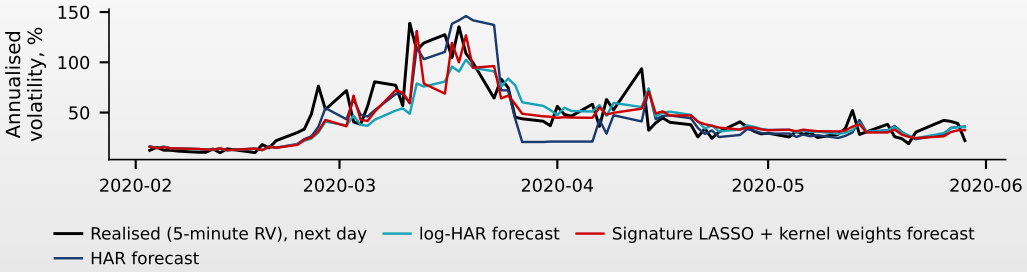
MFM_ch20_case_study

Teste pe panel: cumularea dovezilor

Comparația: DM t (p unilateral)	$h = 1$	$h = 5$	$h = 22$
Sig-LK față de log-HAR	+1,45 (0,927)	+1,68 (0,953)	+1,80 (0,964)
Sig-L față de log-HAR	-1,91 (0,028)	+1,48 (0,931)	+1,51 (0,935)
log-HAR-K față de log-HAR	+1,89 (0,971)	+0,40 (0,654)	+1,92 (0,973)
Sig-LK față de Sig-L	+1,74 (0,959)	+0,98 (0,837)	-0,77 (0,221)
log-HAR față de HAR	-3,09 (<0,001)	-3,95 (<0,001)	-4,50 (<0,001)

- Seria testată: diferența medie de QLIKE pe toate activele tranzacționate în acea zi
- Un t negativ înseamnă că primul model este mai bun
- La nivel agregat, doar transformarea logaritmică este clar semnificativă
- Sig-L față de log-HAR la $h = 1$ este la limita semnificației ($p = 0{,}028$), datorită contractelor futures
  - Doar pentru cele 40 de acțiuni semnul se inversează: $t = +1{,}72$ împotriva Sig-L
- Testul GW condiționat pentru Sig-LK față de log-HAR, după corecția Holm: respingeri pentru 0 din 50 de active la $h = 1$, 0 la $h = 5$ și 0 la $h = 22$

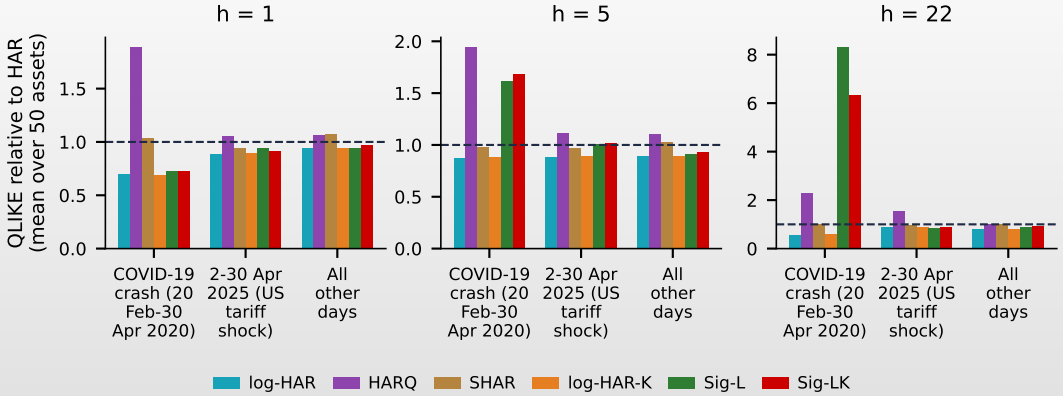
În crahul din pandemia COVID-19: JPM, ziua următoare



- Volatilitatea anualizată în % a prognozelor, $\sqrt{252 F_t}$, și a țintei, $\sqrt{252\,\mathrm{RV}_{t+\mathbf{1}}}$, în februarie–mai 2020: toate modelele reacționează cu întîrziere la primul salt
- Sig-LK reacționează puțin mai repede decît log-HAR la mijlocul lui martie, cînd traiectoria și-a schimbat deja direcția, iar după vîrf ambele scad cu viteze asemănătoare
- HAR în nivel depășește ținta, apoi devine negativ la sfîrșitul lui martie: regula de pozitivitate îl înlocuiește cu media din eșantion (segmentul plat)

MFM_ch20_case_study

Perioade de stres față de perioade normale (H4) (1/2)



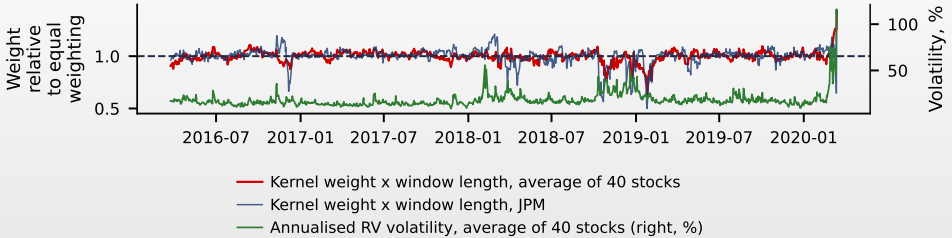
MFM_ch20_case_study

Perioade de stres față de perioade normale (H4) (2/2)

- Media pe active a QLIKE relativ la HAR în fiecare subperioadă fixată înaintea evaluării
- La $h = 1$, în crahul COVID-19: log-HAR 0,70, Sig-LK 0,73, HARQ 1,89
- În 2–30 aprilie 2025 (șocul tarifelor americane): log-HAR 0,88, Sig-LK 0,92
- În celelalte zile: log-HAR 0,94, Sig-LK 0,97
- La $h = 22$, în crahul COVID-19, pierderea Sig-LK este de 6,35 ori, iar a Sig-L de 8,30 ori pierderea HAR: tocmai acolo unde ferestrele trecute asemănătoare ar trebui să ajute, modelele cu semnături au cele mai slabe rezultate
- H4 nu este susținută (comparație descriptivă, fără un test formal de interacțiune)

MFM_ch20_case_study

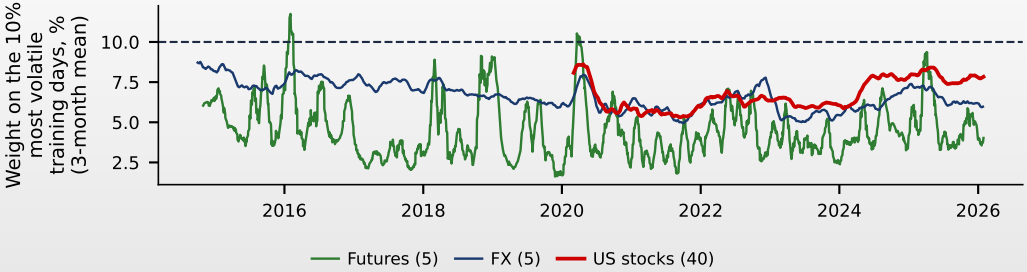
Ponderile nucleului la originea din 16 martie 2020



- Ponderile Sig-LK ($h = 1$) la originea din 16 martie 2020 pe zilele de antrenare (24 mar. 2016 – 13 mar. 2020), înmulțite cu lungimea ferestrei, astfel încît valoarea 1 corespunde ponderării egale
- Ponderile sînt aproape egale, între 0,61 și 1,43 ori $1/n$, iar mărimea efectivă a eșantionului este 975 din 1 000 (media celor 40 de acțiuni)
- Cele mai mari ponderi revin ultimelor zile dinaintea originii. Ferestrele recente de 22 de puncte se suprapun cu cea curentă; asemănarea poate reflecta parțial suprapunerea, nu un regim economic distinct
- Scăderile de la sfîrșitul lui 2018 primesc o pondere *mai mică*, iar ponderile sînt aproape necorelate cu log-volatilitatea (corelația este +0,04): semnătura invariantă la translație reflectă forma, nu nivelul

MFM_ch20_case_study

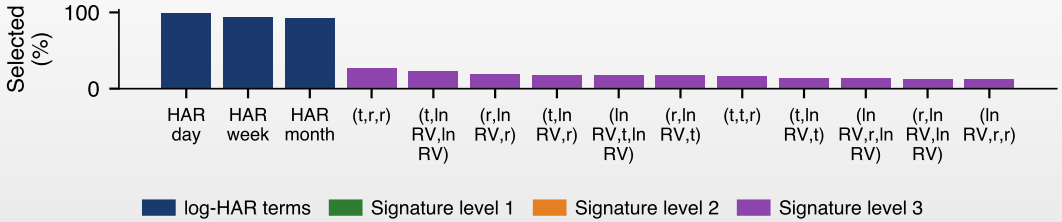
Ponderea perioadelor de stres în nucleu



- Ponderea pe care Sig-LK ($h = 1$) o atribuie celor mai volatile 10% dintre zile din fereastra de antrenare, mediată pe clasă și pe intervale de trei luni
- Pentru acțiuni, această pondere are media 6,7% și variază între 4,4% și 9,9% (maximul pe 17 mar. 2020), deci rămîne mereu sub cele 10% date de ponderarea egală
- Futures și FX arată același tipar
- Mecanismul din spatele rezultatului nul pentru H2: ponderile nu implementează „învățăm din crizele trecute"

MFM_ch20_case_study

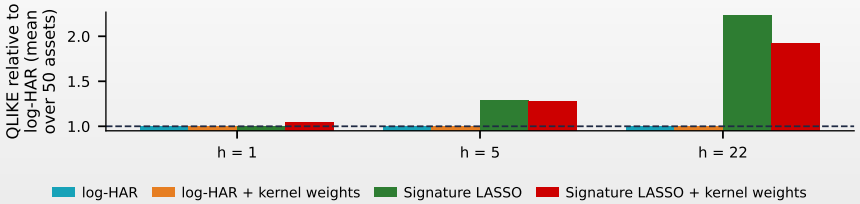
Variabilele selectate de LASSO



- Pe toate activele și orizonturile: proporția reestimărilor în care un regresor face parte din suportul ales prin BIC (Bayesian Information Criterion) pentru Sig-LK (etichete: HAR day/week/month = cei trei termeni log-HAR, t = timp, ln RV = $\ln \mathrm{RV}$, r = randament cumulat)
- Termenii log-HAR zilnic, săptămînal și lunar sînt păstrați în 99%, 94% și, respectiv, 93% dintre reestimări: LASSO redescoperă HAR
- Suportul mediu are 8,7 regresori pentru Sig-L și 6,7 pentru Sig-LK
- Cel mai frecvent termen al semnăturii este (t,r,r) (în 27% dintre reestimări), iar toți termenii frecvenți sînt de nivelul 3
- Fiind cubici în incremente, într-un crah ajung mult în afara intervalului de antrenare și sînt amplificați de exp(·)

MFM_ch20_case_study

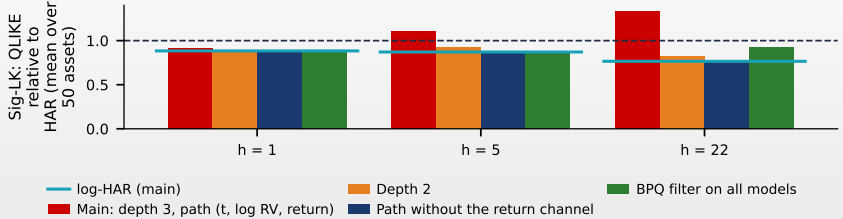
Ablația 2×2



- Media pe cele 50 de active a QLIKE relativ la log-HAR: trăsături (semnătură sau nu) încrucișate cu ponderi (nucleu sau egale)
- Doar ponderile (log-HAR-K): 1,002 la $h = 1$, 1,002 la $h = 5$ și 1,004 la $h = 22$, deci niciun efect
  - Mărimea efectivă medie a eșantionului: 816 din 1 000
  - Doar trăsăturile (Sig-L): 1,004 la $h = 1$, 1,285 la $h = 5$ și 2,238 la $h = 22$
- Ambele componente (Sig-LK: 1,045 la $h = 1$, 1,280 la $h = 5$ și 1,929 la $h = 22$) reduc pierderea de acuratețe la o lună, fără a o elimina
  - În schimb, înrăutățesc rezultatul la $h = 1$ din cauza petrolului (raportul pentru CL este 2,71), spre deosebire de cîștigul adus de nucleu în Tabelul 3 al lui Gu et al.

MFM_ch20_case_study

Robustețea Sig-LK



- Sig-LK relativ la HAR (media pe 50 de active) în specificația principală, în două variante preînregistrate și cu filtrul BPQ (abaterea declarată), iar linia de referință marchează log-HAR
- Cu adîncimea 2, rapoartele sînt 0,922 la $h = 5$ și 0,820 la $h = 22$, față de 1,104 și 1,334 în specificația principală
- Fără canalul randamentelor: 0,878 la $h = 5$ și 0,770 la $h = 22$, deci eșecurile la orizont lung provin din termenii de nivelul 3 care conțin acest canal
- La $h = 5$ și $h = 22$, varianta fără randamente se apropie de log-HAR (0,871, 0,765); adîncimea 2 rămîne inferioară. Ambele reduc instabilitatea, fără a confirma H1

MFM_ch20_case_study

Pe clase de active

Sig-L relativ la log-HAR (QLIKE)	$h = 1$	$h = 5$	$h = 22$
Acțiuni (40)	1,009	1,332	2,505
Futures (5)	0,965	1,084	1,206
FX (5)	0,996	1,111	1,134

- Singurul cîștig: futures la $h = 1$ (-3,5%) și, marginal, FX
  - Rezultatul privește doar cinci contracte futures și un orizont: este un candidat pentru un nou studiu preînregistrat, nu o concluzie a acestuia
- Acțiunile, 80% din panel, nu arată niciun cîștig: rezultatul agregat este în principal un rezultat pentru acțiuni

Limite și direcții deschise

Limitele acestui studiu

- O specificație din multe ($L = 22$, $N = 3$, trei canale, BIC, o grilă de patru puncte pentru c): un rezultat nul pentru această specificație nu este unul pentru semnături în general
- Este folosit doar nucleul trunchiat
- Lipsesc factorii externi (volatilitatea implicită, știrile macro), esențiali în Gu et al.
- Realized GARCH Hansen, Huang & Shek (2012) (GARCH: Generalised AutoRegressive Conditional Heteroskedasticity, Capitolul 5) și modelele de referință din învățarea automată (Capitolul 13) sînt în afara comparației
- Acțiunile sînt evaluate doar pe șase ani

Direcții deschise

- Un nucleu sensibil la nivel: augmentarea cu punct de bază sau nivelul $\ln \mathrm{RV}$ în distanță (Seminarul 20, C2)
- Semnături ale traiectoriei intraday (randamente la 5 minute)
- Nucleul PDE Salvi et al. (2021)
- Log-semnături și canale mărginite (tanh) împotriva termenilor explozivi de nivelul 3 Morrill et al. (2020)
- Traiectorii între active, unde ariile Lévy măsoară relațiile lead-lag între piețe
- Futures la $h = 1$ pe un panel mai lung, cu această specificație fixată dinainte

Cînd se transferă o metodă dintr-un domeniu în altul?

- Metodele circulă mai repede decît dovezile: un articol KDD despre tarife de transport devine candidat pentru aplicații în volatilitate, credit sau energie
  - Ce proprietăți ale problemei-sursă au făcut metoda să funcționeze?
  - Le are și problema-țintă?
- Finanțele adaugă un filtru sever: 164 de echipe care analizează aceleași date obțin estimări care diferă mai mult decît sugerează erorile lor standard Menkveld et al. (2024)
- Formulare formală: un transfer reușește dacă cîștigul față de cel mai puternic reper simplu rămîne valabil pe o mulțime preînregistrată $\mathcal{S}$ de specificații, active și orizonturi, cu o corecție pentru testarea multiplă aplicată familiei de teste
  - În acest capitol: $\mathcal{S} = 50$ de active $\times$ 3 orizonturi $\times$ 4 variante
  - Holm și BH s-au aplicat pe fiecare comparație și orizont (familii de 50 de active), iar variantele sînt raportate descriptiv, fără o corecție comună pe toate cele 600 de celule
  - Cîștigul nu s-a confirmat

Bucla descoperirii aplicată acestui capitol

- Cererile pentru extragere și cererile pentru falsificare oferă exemple reutilizabile pentru pașii de mai jos.
- **Citim**: un asistent listează fiecare ecuație, hiperparametru și reper din articol și marchează ce nu este publicat, iar fiecare element se verifică în PDF
- **Stabilim corespondența**: se stabilește, pentru fiecare componentă, dacă se transferă, ce trebuie schimbat și ce reper o izolează
- **Preînregistrăm**: ipotezele, grila, testele și corecția sînt fixate într-un document datat înaintea primului rezultat: asistentul face ciorna, iar echipa decide fiecare cifră
- **Construim și testăm piesele**: semnăturile față de identități (nivelul 1 = incrementul, Chen pe o traiectorie împărțită), nu față de altă bibliotecă
- **Rulăm grila, apoi o supunem unor teste de rezistență**
  - ce concluzii rămîn valabile după corecția Holm pe 50 de active?
  - ce activ ar da un titlu înșelător?
- **Explicăm rezultatul nul**: aici ponderi plate (invarianța la translație) și termeni explozivi de nivelul 3 (legătura exponențială), ambele verificate cu date
- Lista de verificări a cercetătorului și cererile complete sînt în ▸ Anexă

Mini studiu de caz: trei titluri din aceleași rulări

- „Semnăturile depășesc HAR pe 12 din 50 de active" (orizont de o zi, DM necorectat)
  - Adevărat, dar log-HAR singur este superior lui HAR pe 21: cîștigul aparține transformării logaritmice
- „Semnăturile îmbunătățesc prognozele de volatilitate pentru E-mini S&P 500" (ES, $h = 1$, DM $t = -2{,}91$ față de log-HAR)
  - O celulă din 150 de celule activ-orizont: după Holm, 0 din 50 la $h = 1$ și niciuna la $h = 5, 22$
- Titlul rezultat din evaluarea preînregistrată: „niciun cîștig față de log-HAR; mai slab la orizonturi mai lungi; ponderile nucleului inerte"
  - Un asistent AI rugat să „găsească unde funcționează metoda" le va produce pe primele două; planul îl protejează pe al treilea

Aplicație pentru proiect: planificați un transfer

- Alegeți o direcție deschisă din acest capitol (nucleu sensibil la nivel, semnături intraday, log-semnături, doar futures)
  - Scrieți H_0/H_1, reperul care o izolează și rezultatul care v-ar face să renunțați la ea
- Folosiți un asistent pentru a lista ce poate merge prost în studiul dumneavoastră, apoi scrieți un test unitar pentru fiecare element
- Fixați preînregistrarea într-un document datat înaintea primului rezultat în afara eșantionului
- Rulați grila și raportați distribuția rezultatelor pe $\mathcal{S}$
- Documentați fiecare eroare AI detectată în `AI_ERRORS.md` (Seminarul 20, C1 dă erori tipice)

Idei de reținut

- Semnăturile transformă o fereastră într-un vector de trăsături cu fundament teoretic: identitatea lui Chen, unicitate, universalitate
- Aplicată variantei realizate, metoda lui Gu et al. nu depășește log-HAR
  - H1 (semnăturile aduc informație) nu este susținută: niciun cîștig la o zi, iar la o săptămînă și la o lună apare o pierdere
  - H2 (ponderile nucleului ajută) nu este susținută: ponderile sînt aproape plate și reduc ponderea stresului trecut
  - H3 (metoda depășește familia HAR): doar HAR în nivel este depășit, datorită țintei logaritmice
  - H4 (cîștiguri mai mari în perioadele de stres) nu este susținută
- Nucleul invariant la translație reflectă forma, nu nivelul
- Termenii de nivelul 3 iau valori explozive în crahuri
- Cel mai puternic efect din studiu este cel mai vechi: modelați logaritmul RV
- Un rezultat nul preînregistrat, cu ablații și cu un mecanism, este o concluzie

Lecturi despre semnături și măsuri realizate

Lecturi

- Semnături: Chevyrev & Kormilitzin (2016); Lyons & McLeod (2022); măsuri realizate: Franke, Härdle & Hafner (2019) și Capitolul 9

Cursuri avansate pe quantinar.com

- Statistics of Financial Markets
- Applied Time Series Analysis with Python
- Machine Learning in Financial Risk

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_20; date: VOLARE, gratuit pentru cercetare la volare.unime.it

Verificarea înțelegerii

- Ce informație despre ordine păstrează semnătura unei traiectorii și pierde o medie simplă? Folosiți exemplul cu două segmente. Revedeți explicația.
- De ce comparăm atît cu o țintă în nivel, cît și cu una în logaritmi? Explicați ce ablație izolează contribuția semnăturilor. Revedeți explicația.
- Un singur avantaj semnificativ între multe active dovedește superioritatea metodei? Explicați rolul corecției pentru comparații multiple. Revedeți explicația.
- Cum poate fi informativ un rezultat nul? Legați reperul de comparație, mecanismul și limitele transferului într-un domeniu nou. Revedeți explicația.

Trăsături și scalare

◂ Parcurs ◂ Descreștere ◂ Nucleu

- Regresorii în ziua τ pentru modelele cu semnături: 3 termeni log-HAR + 39 de termeni ai semnăturii
  - $\xi_\tau = \left[\ln \mathrm{RV}_\tau,\ \ln \mathrm{RV}_\tau^{(w)},\ \ln \mathrm{RV}_\tau^{(m)},\ \mathrm{Sig}^3(X_{\tau-21:\tau})\right]$, traiectoria X = (timp, $\ln \mathrm{RV}$, r cumulat), 22 de puncte
- Fiecare canal q (altul decît timpul) se înmulțește cu $\kappa_q = 1/(s_q\sqrt{L-1})$, astfel încît deplasarea lui totală tipică pe fereastră este aproximativ 1
  - s_q: abaterea standard a incrementelor zilnice ale canalului q în fereastra de antrenare, pînă la originea t
  - Fiecare fereastră are $L - 1 = 21$ de incremente
  - Timpul nu se rescalează (incremente constante, $s = 0$) și ia valori de la 0 la 1
  - Un cuvînt $(i_1..i_k)$ se rescalează cu $\prod_j \kappa_{i_j}$, deci semnăturile se calculează o singură dată
- Înaintea LASSO fiecare coloană este standardizată cu momentele ponderate ale ferestrei de antrenare, iar coloanele constante (cuvintele formate doar din litera timpului) se elimină
- Variabilele brute din τ folosesc date pînă la τ, iar scalele și standardizarea folosesc date pînă la originea t
- Deci nicio informație de după originea t nu intră în prognoză

Estimare: alegerea lui λ fără look-ahead bias

- În fiecare fereastră de antrenare: întreaga traiectorie de regularizare LASSO ponderată, prin LARS (Least-Angle Regression, regresia unghiului minim)
  - Pentru fiecare suport de pe traiectoria de regularizare: reestimare OLS ponderată (pasul 2 din Gu et al.)
- Alegem suportul care minimizează un criteriu de tip BIC (Bayesian Information Criterion, criteriul informațional bayesian) cu mărimea efectivă a eșantionului Kish, o euristică a acestui studiu
  - $\mathrm{BIC}(S) = n_{\mathrm{eff}} \ln \hat{s}_S^2 + (|S|+1) \ln n_{\mathrm{eff}}, \quad n_{\mathrm{eff}} = 1/\sum_\tau w_\tau^2$
  - S: un suport (mulțimea regresorilor păstrați), iar $|S|$ este mărimea lui ($+1$ pentru constantă)
  - $\hat{s}_S^2$: varianța reziduală ponderată a reestimării pe S
  - Primul termen măsoară potrivirea, al doilea penalizează fiecare parametru
- Motivul pentru care nu folosim validarea încrucișată: ar cere 50 de active $\times$ 3 orizonturi $\times$ sute de reestimări, în timp ce BIC folosește doar fereastra
  - Mărimea Kish corectează ponderile inegale, nu dependența serială (ținte suprapuse, $h > 1$), deci criteriul nu este un BIC bazat pe verosimilitate pentru aceste date

Înapoi

Perioadele de evaluare și parametrii nucleului

Clasa	Evaluarea începe	Se termină	Zile pe activ (mediana)
Acțiuni	27 ian. 2020	29 ian. 2026	1 499
Futures	25 sept. 2014	29 ian. 2026	2 919
FX	27 aug. 2014	29 ian. 2026	2 952

- 265 929 de prognoze în afara eșantionului pentru fiecare model (50 de active $\times$ 3 orizonturi)
- Acțiunile încep în 2015, deci evaluarea lor începe în ianuarie 2020: crahul din pandemia COVID-19 este în eșantionul fiecărei acțiuni
  - Futures și FX încep în 2009 și sînt evaluate din 2014

- Valoarea lui c aleasă pentru Sig-LK, pe clase și orizonturi
  - Acțiuni: 0,5 la $h = 1$, 0,5 la $h = 5$ și 0,5 la $h = 22$
  - Futures: 2,0 la $h = 1$, 1,0 la $h = 5$ și 0,5 la $h = 22$
  - FX: 0,5 la $h = 1$, 2,0 la $h = 5$ și 0,5 la $h = 22$
- Valoarea lui c aleasă pentru log-HAR-K, pe clase și orizonturi
  - Acțiuni: 0,5 la $h = 1$, 0,5 la $h = 5$ și 1,0 la $h = 22$
  - Futures: 2,0 la $h = 1$, 1,0 la $h = 5$ și 4,0 la $h = 22$
  - FX: 4,0 la $h = 1$, 2,0 la $h = 5$ și 4,0 la $h = 22$

înapoi

Metrica articolului pe datele VOLARE

Mediana erorilor medii pe active $\lvert \mathrm{RV} - F \rvert / \mathrm{RV}$ (%)	$h = 1$	$h = 5$	$h = 22$
HAR	57,2	48,9	51,7
log-HAR	50,4	41,9	38,7
HARQ	55,0	49,0	50,7
SHAR	57,9	49,2	51,8
log-HAR-K	49,7	41,0	38,7
Sig-L	50,1	42,6	42,6
Sig-LK	50,6	43,6	43,7

- Mediana pe active a erorii relative medii: aproximativ 40–60%, față de 1–2% pentru tarifele de transport la Gu et al.
- RV zilnică este o țintă zgomotoasă, cu cozi groase: modelele evaluate au erori relative mult mai mari decît cele raportate pentru tarifele de transport, fără ca aceasta să stabilească o limită inferioară a erorii posibile
  - Numărul prognozelor Sig-LK care depășesc de zece ori maximul din eșantion: 8 la $h = 1$, 29 la $h = 5$ (pe 10 active) și 36 la $h = 22$
  - Log-HAR nu are nicio astfel de prognoză

Înapoi

Filtrul „insanity", revăzut

QLIKE relativ la HAR, filtrul BPQ pe toate modelele	$h = 1$	$h = 5$	$h = 22$
HAR	1,000	1,000	1,000
log-HAR	0,763	0,654	0,778
HARQ	0,995	0,912	1,014
SHAR	1,014	1,003	1,000
log-HAR-K	0,772	0,659	0,779
Sig-L	0,871	0,819	0,904
Sig-LK	0,890	0,867	0,930

- Filtrul îmbunătățește HARQ față de HAR (0,995 la $h = 1$ în loc de 1,140), așa cum au urmărit Bollerslev, Patton și Quaedvlieg
- Sig-LK relativ la log-HAR, ambele filtrate: 1,238 la $h = 1$, 1,424 la $h = 5$ și 1,209 la $h = 22$ (fără filtru: 1,045, 1,280 și, respectiv, 1,929)
- Cu filtru, distanța crește la $h = 1, 5$ și scade la $h = 22$
- Numărul prognozelor înlocuite de filtru la $h = 1$ (din 89 893): HAR 180, HARQ 140, Sig-LK 143, log-HAR 29: filtrul se aplică modelelor cu semnături mult mai des decît lui log-HAR

Înapoi

Verificările cercetătorului

- **Metoda este cea din articol**: nucleul, ponderile, reestimarea, ca în ecuațiile citate
  - Test: fiecare slide despre metodologie citează o ecuație, un tabel sau o secțiune a articolului; alegerile nepublicate sînt marcate ca alegeri ale studiului
- **Fără look-ahead bias**: λ, scalele, c și trăsăturile folosesc doar date disponibile la origine
  - Test: dacă modificați orice valoare de după origine (de exemplu, înmulțiți RV viitoare cu 10), prognoza făcută la origine nu trebuie să se schimbe
- **Reperul izolează ideea**
  - Test: ablația 2×2 este raportată, nu doar modelul complet față de HAR
- **Funcțiile de pierdere și testele sînt aplicate corect**
  - Test: $\mathrm{QLIKE}(\mathrm{RV}, \mathrm{RV}) = 0$ și $\mathrm{QLIKE}(\mathrm{RV}, F) > 0$ în rest
  - Test: varianța DM este HAC, cu lățimea de bandă de cel puțin h

Înapoi

Bucla descoperirii, cererile (1/2)

- **Citim**: extragem exact ce a făcut articolul
  - „Din Gu et al. (2024, KDD), listează fiecare ecuație a estimatorului, fiecare hiperparametru și valoarea raportată și reperul fiecărui tabel. Marchează ce nu este publicat.”
  - Verificați fiecare element în PDF: numerele ecuațiilor, ale tabelelor, nucleul folosit efectiv
- **Stabilim corespondența**: ce se transferă, ce trebuie adaptat
  - „Ținta noastră este varianța realizată zilnică. Pentru fiecare componentă a metodei, spune dacă se transferă, ce trebuie schimbat și ce reper o izolează.”
- **Preînregistrăm**: ipoteze, grilă, teste, corecție, fixate într-un document datat înaintea primului rezultat
  - Asistentul face ciorna, iar echipa decide fiecare cifră și semnează preînregistrarea datată

Înapoi

Bucla descoperirii, cererile (2/2)

- **Construim și testăm piesele**: semnăturile față de identități, nu față de altă bibliotecă
  - „Scrie teste unitare pentru o semnătură de adîncime 3: nivelul 1 egal cu incrementul, partea simetrică a nivelului 2 egală cu jumătate din produsul exterior, identitatea lui Chen pe o traiectorie împărțită.”
- **Rulăm grila, apoi o supunem unor teste de rezistență**
  - „Iată toate cele 600 de rulări (50 de active × 3 orizonturi × 4 specificații: principală, adîncimea 2, fără canalul randamentelor, filtrul BPQ). Ce concluzii rămîn valabile după corecția Holm pe 50 de active? Ce activ sau ce subperioadă ar da un titlu înșelător?”
- **Explicăm rezultatul nul**: identificăm mecanismul, nu o justificare

Înapoi

Acronime folosite în acest material (1/3)

- **AAPL**: Apple Inc. (Nasdaq ticker) — *Apple Inc., simbolul bursier Nasdaq*
- **ACM**: Association for Computing Machinery — *Asociația pentru Mașini de Calcul*
- **AI**: Artificial Intelligence — *inteligență artificială*
- **AR**: AutoRegressive model — *model autoregresiv*
- **ARIMA**: AutoRegressive Integrated Moving Average (model) — *model autoregresiv integrat cu medie mobilă*
- **AUD**: Australian Dollar (ISO 4217 code) — *dolarul australian (cod ISO 4217)*
- **BH**: Benjamini–Hochberg (procedure) — *procedura Benjamini–Hochberg*
- **BIC**: Bayesian Information Criterion — *criteriul informațional bayesian*
- **BPQ**: Bollerslev–Patton–Quaedvlieg (insanity filter of the HARQ paper) — *Bollerslev–Patton–Quaedvlieg (filtrul din articolul HARQ)*
- **CAD**: Canadian Dollar (ISO 4217 code) — *dolarul canadian (cod ISO 4217)*
- **CL**: Crude oil (WTI light sweet) futures, NYMEX ticker — *contractul futures pe petrol (WTI), simbolul NYMEX*
- **COVID-19**: COronaVIrus Disease 2019 — *boala provocată de coronavirus, 2019*
- **DM**: Diebold–Mariano (test) — *testul Diebold–Mariano de comparare a prognozelor*
- **ES**: E-mini S&P 500 futures (CME ticker) — *contractul futures E-mini S&P 500 (simbolul CME)*
- **EURUSD**: Euro / US dollar exchange rate (FX pair code) — *cursul euro / dolar american (codul perechii FX)*

Acronime folosite în acest material (2/3)

- **FDR**: False Discovery Rate — *rata descoperirilor false*
- **FWER**: Family-Wise Error Rate — *probabilitatea de cel puțin o eroare de tip I în familia de teste*
- **FX**: Foreign eXchange — *piața valutară*
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity — *heteroscedasticitate condiționată autoregresivă generalizată*
- **GC**: Gold futures, COMEX ticker — *contractul futures pe aur, simbolul COMEX*
- **GW**: Giacomini–White (test) — *testul Giacomini–White*
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — *erori standard robuste la heteroscedasticitate și autocorelație*
- **HAR**: Heterogeneous AutoRegressive (model) — *model autoregresiv heterogen*
- **HARQ**: HAR model with Realised Quarticity — *model HAR cu cvarticitatea realizată*
- **JPM**: JPMorgan Chase & Co. (NYSE ticker) — *JPMorgan Chase & Co. (simbolul bursier NYSE)*
- **KDD**: Knowledge Discovery and Data Mining (ACM SIGKDD conference) — *descoperirea cunoașterii și data mining (conferința ACM SIGKDD)*
- **LARS**: Least-Angle RegreSsion (algorithm) — *algoritmul regresiei unghiului minim*
- **LASSO**: Least Absolute Shrinkage and Selection Operator — *regresie penalizată L1 cu selecția variabilelor*
- **MCS**: Model Confidence Set — *mulțimea de încredere a modelelor*
- **MSE**: Mean Squared Error — *eroarea pătratică medie*

Acronime folosite în acest material (3/3)

- **NG**: Natural Gas futures, NYMEX ticker — *contractul futures pe gaze naturale, simbolul NYMEX*
- **NVDA**: NVIDIA Corporation (Nasdaq ticker) — *NVIDIA Corporation, simbolul bursier Nasdaq*
- **OLS**: Ordinary Least Squares — *metoda celor mai mici pătrate*
- **PDE**: Partial Differential Equation — *ecuație cu derivate parțiale*
- **PRDS**: Positive Regression Dependence on a Subset (of p-values) — *dependența pozitivă de regresie pe o submulțime (a p-value-urilor)*
- **QLIKE**: Quasi-LIKElihood (loss function) — *funcția de pierdere de tip cvasi-verosimilitate*
- **RQ**: Realised Quarticity — *cvarticitatea realizată*
- **RV**: Realised Variance — *varianța realizată*
- **SHAR**: Semivariance HAR model — *model HAR cu semivarianțe*
- **SUA**: Statele Unite ale Americii
- **TSLA**: Tesla, Inc. (Nasdaq ticker) — *Tesla, Inc., simbolul bursier Nasdaq*
- **USDJPY**: US dollar / Japanese yen exchange rate (FX pair code) — *cursul dolar american / yen japonez (codul perechii FX)*
- **VOLARE**: VOLatility Archive for Realized Estimates (database) — *arhiva de estimatori realizați ai volatilității (bază de date)*
- **WTI**: West Texas Intermediate (crude oil benchmark) — *țițeiul de referință West Texas Intermediate*
- **XOM**: Exxon Mobil Corporation (NYSE ticker) — *Exxon Mobil Corporation, simbolul bursier NYSE*

Bibliografie (1/3)

- Barndorff-Nielsen, O.E., Hansen, P.R., Lunde, A., Shephard, N. (2008). Designing realized kernels to measure the ex post variation of equity prices in the presence of noise. *Econometrica*, 76(6), 1481–1536.
- Barndorff-Nielsen, O.E., Kinnebrock, S., Shephard, N. (2010). Measuring downside risk: realised semivariance. In *Volatility and Time Series Econometrics*, Oxford University Press, 117–136.
- Barndorff-Nielsen, O.E., Shephard, N. (2002). Econometric analysis of realized volatility and its use in estimating stochastic volatility models. *Journal of the Royal Statistical Society B*, 64(2), 253–280.
- Belloni, A., Chernozhukov, V. (2013). Least squares after model selection in high-dimensional sparse models. *Bernoulli*, 19(2), 521–547.
- Benjamini, Y., Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- Benjamini, Y., Yekutieli, D. (2001). The control of the false discovery rate in multiple testing under dependency. *The Annals of Statistics*, 29(4), 1165–1188.
- Bollerslev, T., Patton, A.J., Quaedvlieg, R. (2016). Exploiting the errors: a simple approach for improved volatility forecasting. *Journal of Econometrics*, 192(1), 1–18.
- Chen, K.-T. (1957). Integration of paths, geometric invariants and a generalized Baker–Hausdorff formula. *Annals of Mathematics*, 65(1), 163–178.
- Chevyrev, I., Kormilitzin, A. (2016). A primer on the signature method in machine learning. arXiv:1603.03788.
- Cipollini, F., Cruciani, G., Gallo, G.M., Insana, A., Otranto, E., Spagnolo, F. (2026). VOLatility Archive for Realized Estimates (VOLARE). arXiv:2602.19732.
- Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.

Bibliografie (2/3)

- Cuchiero, C., Gazzani, G., Svaluto-Ferro, S. (2023). Signature-based models: theory and calibration. *SIAM Journal on Financial Mathematics*, 14(3), 910–957.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). Statistics of Financial Markets: An Introduction, 5th ed. Springer.
- Giacomini, R., White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- Gu, H., Guo, X., Jacobs, T.L., Kaminsky, P., Li, X. (2024). Transportation marketplace rate forecast using signature transform. *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 4997–5005; arXiv:2401.04857.
- Hambly, B., Lyons, T. (2010). Uniqueness for the signature of a path of bounded variation and the reduced path group. *Annals of Mathematics*, 171(1), 109–167.
- Hansen, P.R., Huang, Z., Shek, H.H. (2012). Realized GARCH: a joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6), 877–906.
- Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- Király, F.J., Oberhauser, H. (2019). Kernels for sequentially ordered data. *Journal of Machine Learning Research*, 20(31), 1–45.
- Levin, D., Lyons, T., Ni, H. (2013). Learning from the past, predicting the statistics for the future, learning an evolving system. arXiv:1309.0260.
- Liu, L.Y., Patton, A.J., Sheppard, K. (2015). Does anything beat 5-minute RV? A comparison of realized measures across multiple asset classes. *Journal of Econometrics*, 187(1), 293–311.

Bibliografie (3/3)

- Lyons, T. (1998). Differential equations driven by rough signals. *Revista Matemática Iberoamericana*, 14(2), 215–310.
- Lyons, T., McLeod, A.D. (2022). Signature methods in machine learning. arXiv:2206.14674.
- Menkveld, A.J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). Nonstandard errors. *Journal of Finance*, 79(3), 2339–2390.
- Morrill, J., Fermanian, A., Kidger, P., Lyons, T. (2020). A generalised signature method for multivariate time series feature extraction. arXiv:2006.00873.
- Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- Patton, A.J., Sheppard, K. (2015). Good volatility, bad volatility: signed jumps and the persistence of volatility. *Review of Economics and Statistics*, 97(3), 683–697.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- Salvi, C., Cass, T., Foster, J., Lyons, T., Yang, W. (2021). The signature kernel is the solution of a Goursat PDE. *SIAM Journal on Mathematics of Data Science*, 3(3), 873–899.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society B*, 58(1), 267–288.
- Zou, H. (2006). The adaptive lasso and its oracle properties. *Journal of the American Statistical Association*, 101(476), 1418–1429.