



Modelarea piețelor financiare

Capitolul 20 (capitol special): Semnătura traiectoriilor și volatilitatea realizată —
un studiu de cercetare



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- AAPL: Apple Inc. (Nasdaq ticker) (Apple Inc., simbolul bursier Nasdaq)
- ACM: Association for Computing Machinery (Asociația pentru Mașini de Calcul)
- AI: Artificial Intelligence (inteligență artificială)
- AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ARIMA: AutoRegressive Integrated Moving Average (model) (model autoregresiv integrat cu medie mobilă)
- AUD: Australian Dollar (ISO 4217 code) (dolarul australian (cod ISO 4217))
- BH: Benjamini–Hochberg (procedure) (procedura Benjamini–Hochberg)
- BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- BPQ: Bollerslev–Patton–Quaedvlieg (insanity filter of the HARQ paper) (Bollerslev–Patton–Quaedvlieg (filtrul din articolul HARQ))
- CAD: Canadian Dollar (ISO 4217 code) (dolarul canadian (cod ISO 4217))
- CL: Crude oil (WTI light sweet) futures, NYMEX ticker (contractul futures pe petrol (WTI), simbolul NYMEX)
- COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- DM: Diebold–Mariano (test) (testul Diebold–Mariano de comparare a prognozelor)
- ES: E-mini S&P 500 futures (CME ticker) (contractul futures E-mini S&P 500 (simbolul CME))
- EURUSD: Euro / US dollar exchange rate (FX pair code) (cursul euro / dolar american (codul perechii FX))
- FDR: False Discovery Rate (rata descoperirilor false)
- FWER: Family-Wise Error Rate (probabilitatea de cel puțin o eroare de tip I în familia de teste)
- FX: Foreign eXchange (piața valutară)
- GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- GC: Gold futures, COMEX ticker (contractul futures pe aur, simbolul COMEX)
- GW: Giacomini–White (test) (testul Giacomini–White)
- HAC: Heteroskedasticity and Autocorrelation Consistent (standard errors) (erori standard robuste la heteroscedasticitate și autocorelație)
- HAR: Heterogeneous AutoRegressive (model) (model autoregresiv heterogen)
- HARQ: HAR model with Realised Quarticity (model HAR cu cvarticitatea realizată)
- JPM: JPMorgan Chase & Co. (NYSE ticker) (JPMorgan Chase & Co. (simbolul bursier NYSE))
- KDD: Knowledge Discovery and Data Mining (ACM SIGKDD conference) (descoperirea cunoașterii și data mining (conferința ACM SIGKDD))

Acronime folosite în acest material (2/2)

- LARS: Least-Angle RegreSsion (algorithm) (algoritmul regresiei unghiului minim)
- LASSO: Least Absolute Shrinkage and Selection Operator (regresie penalizată L1 cu selecția variabilelor)
- MCS: Model Confidence Set (mulțimea de încredere a modelelor)
- MSE: Mean Squared Error (eroarea pătratică medie)
- NG: Natural Gas futures, NYMEX ticker (contractul futures pe gaze naturale, simbolul NYMEX)
- NVDA: NVIDIA Corporation (Nasdaq ticker) (NVIDIA Corporation, simbolul bursier Nasdaq)
- OLS: Ordinary Least Squares (metoda celor mai mici pătrate)
- PDE: Partial Differential Equation (ecuație cu derivate parțiale)
- PRDS: Positive Regression Dependence on a Subset (of p-values) (dependența pozitivă de regresie pe o submulțime (a valorilor p))
- QLIKE: Quasi-LIKelihood (loss function) (funcția de pierdere de tip cvasi-verosimilitate)
- RQ: Realised Quarticity (cvarticitatea realizată)
- RV: Realised Variance (varianța realizată)
- SHAR: Semivariance HAR model (model HAR cu semivarianțe)
- TSLA: Tesla, Inc. (Nasdaq ticker) (Tesla, Inc., simbolul bursier Nasdaq)
- USDJPY: US dollar / Japanese yen exchange rate (FX pair code) (cursul dolar american / yen japonez (codul perechii FX))
- VOLARE: VOLatility Archive for Realized Estimates (database) (arhiva de estimatori realizați ai volatilității (bază de date))
- XOM: Exxon Mobil Corporation (NYSE ticker) (Exxon Mobil Corporation, simbolul bursier NYSE)

Parcursul capitolului și rezultatele învățării

Parcursul capitolului

- Un studiu de cercetare: metoda lui Gu et al. (2024), publicată pentru tarifele de transport de la Amazon, aplicată varianței realizate zilnice a 50 de active VOLARE Cipollini et al. (2026)
- Partea I: măsuri realizate, datele, reperele HAR, semnăturile traiectoriilor
- Partea a II-a: articolul lui Gu et al., un plan de analiză fixat înaintea rezultatelor, rezultate, robustețe, o parcurgere a buclei de descoperire științifică asistate de AI
- Detaliile de implementare sînt în [▶ Anexa](#) de la final

După acest capitol puteți


- calcula semnătura unei traiectorii liniare pe porțiuni și interpreta aria ei Lévy
- construi trăsături (variabile) de semnătură și ponderi de nucleu pentru o prognoză a volatilității
- compara prognoze pe multe active cu teste DM, mulțimi de încredere pentru modele și corecții Holm/BH
- preînregistra aplicarea unei metode într-un domeniu nou și raporta un rezultat nul împreună cu mecanismul lui

Motivația: prognoza varianței realizate

- ▣ Volatilitatea intră în calculul aproape tuturor indicatorilor de risc din acest curs
 - ▶ Măsuri de tail risk ([Capitolul 7](#)), prețuri de opțiuni ([Capitolul 12](#)), ponderi de portofoliu ([Capitolul 4](#))
- ▣ Datele intraday fac varianța zilnică aproape observabilă: varianța realizată (Realised Variance, RV, [Capitolul 9](#))
 - ▶ Astfel, prognoza volatilității devine o problemă de regresie cu o țintă zgomotoasă, dar calculată fără a specifica un model parametric
- ▣ Reperul este greu de depășit: modelul HAR [Corsi \(2009\)](#) ([Capitolul 9](#))
 - ▶ Trei medii ale valorilor trecute ale RV; model liniar, estimat prin OLS aproape instantaneu
- ▣ Orice metodă nouă trebuie să depășească HAR în afara eșantionului, pe multe active, cu un test corect

Întrebarea de cercetare

- Gu et al. descriu o fereastră recentă a unei serii ca o **traietorie** și o rezumă prin **semnătura traietoriei** (engl. *path signature*)
 - ▶ Trăsăturile de semnătură intră într-o regresie liniară cu puțini coeficienți nenuli (LASSO în doi pași)
 - ▶ Perioadele trecute a căror traietorie seamănă cu cea curentă primesc o pondere mai mare (un nucleu de semnătură)
- Ei raportează o creștere de peste cinci ori a acurateței față de o prognoză din industrie pentru tarifele de transport
 - ▶ Întrebare: îmbunătățește aceeași metodă modelele de tip HAR pentru varianța realizată?
- Două componente de testat separat: trăsăturile de semnătură și ponderile date de nucleu



Wall Street și Bursa din New York, 25 martie 2020

Foto: Billie Grace Ward (2020); CC BY 2.0; Wikimedia

[Commons](#)

Varianța realizată și variația pătratică (1/2)

- Modelul prețului: prețul logaritmic se modifică printr-un drift, un termen de difuzie și salturi

$$dp_t = \mu_t dt + \sigma_t dW_t + dJ_t$$

- p_t : prețul logaritmic la momentul t (timpul în zile); μ_t : drift; σ_t : volatilitatea instantanee; W_t : mișcare browniană; J_t : proces de salturi, $\Delta J_s =$ mărimea saltului la momentul s

- Varianța realizată: suma pătratelor randamentelor intraday din ziua t [Barndorff-Nielsen & Shephard \(2002\)](#)

$$RV_t = \sum_{i=1}^M r_{t,i}^2 \xrightarrow{M \rightarrow \infty} \int_{t-1}^t \sigma_s^2 ds + \sum_{t-1 < s \leq t} (\Delta J_s)^2$$

- M : numărul de randamente intraday din ziua t (pentru o acțiune americană, 78 de randamente la cinci minute în ședința de 6,5 ore); $r_{t,i}$: al i -lea randament logaritmic intraday din ziua t
- Limita este variația pătratică a zilei t : varianța integrată plus suma pătratelor salturilor

Varianța realizată și variația pătratică (2/2)

- Fără salturi și fără zgomot, pe o grilă echidistantă, limita este varianța integrată; eroarea are o distribuție Normală mixtă

$$\sqrt{M}(RV_t - IV_t) \Rightarrow MN(0, 2IQ_t), \quad IV_t = \int_{t-1}^t \sigma_s^2 ds, \quad IQ_t = \int_{t-1}^t \sigma_s^4 ds$$

- ▶ IV_t : varianța integrată, varianța adevărată a zilei t ; IQ_t : cvarticitatea integrată; $\Rightarrow$: convergență în distribuție
- ▶ $MN(0, V)$: distribuția Normală mixtă, adică Normală cu o varianță aleatoare V ; condiționat de traiectoria volatilității, eroarea este Normală cu varianța $2IQ_t/M$
- Interpretare: RV este o măsurare zgomotoasă a lui IV_t , iar zgomotul este cel mai mare în zilele volatile (unde IQ_t este mare)
 - ▶ Aceasta este eroarea de măsurare pe care o corectează HARQ (secțiunea următoare)
- Zgomotul de microstructură introduce o deplasare în estimare la frecvențe foarte mari de eșantionare; randamentele la cinci minute sînt compromisul standard ([Capitolul 9](#))
- [Capitolul 9](#) deduce aceste rezultate; aici sînt folosite ca atare

Măsurile realizate din VOLARE (1/2)

- Semivarianțele [Barndorff-Nielsen, Kinnebrock & Shephard \(2010\)](#): RV descompusă după semnul randamentelor intraday

$$RV_t^+ = \sum_{i=1}^M r_{t,i}^2 1\{r_{t,i} > 0\}, \quad RV_t^- = \sum_{i=1}^M r_{t,i}^2 1\{r_{t,i} < 0\}$$

- ▶ $1\{\cdot\}$: funcția indicator, 1 dacă condiția este îndeplinită și 0 altfel; RV_t^+ : varianța din creșteri, RV_t^- : varianța din scăderi
- ▶ Suma lor este RV: $RV_t = RV_t^+ + RV_t^-$ (în VOLARE, pînă la precizia mașinii)

- Cvarțicitatea realizată: o estimare a lui IQ_t , scala erorii de măsurare a RV

$$RQ_t = \frac{M}{3} \sum_{i=1}^M r_{t,i}^4 \rightarrow IQ_t$$

- ▶ Factorul $M/3$: un randament Normal cu varianța s^2 are momentul de ordinul patru $3s^4$, iar fiecare varianță la cinci minute este aproximativ IV_t/M
- ▶ Limita cere un preț continuu, fără zgomot, și o grilă echidistantă; un salt ΔJ adaugă aproximativ $M(\Delta J)^4/3$, deci RQ brută este sensibilă la salturi

Măsurile realizate din VOLARE (2/2)

- ▣ Variația bipower (robustă la salturi), nucleul realizat (robust la zgomot) [Barndorff-Nielsen et al. \(2008\)](#), estimatori bazați pe amplitudinea zilnică a prețului (range)
- ▣ Ținta acestui capitol: RV la cinci minute
 - ▶ Pe 400 de active, puțini estimatori depășesc RV la cinci minute ca proxy al varianței zilnice [Liu, Patton & Sheppard \(2015\)](#)
 - ▶ Semivarianțele și cvarticitatea sînt calculate pe aceeași grilă temporală, deci SHAR și HARQ folosesc date de intrare coerente

Ținte și funcții de pierdere (1/2): ținta

- Ținta la orizontul h este media RV pe următoarele h zile

$$RV_{t+1:t+h} = \frac{1}{h} \sum_{j=1}^h RV_{t+j}, \quad h \in \{1, 5, 22\}$$

- ▶ t : originea prognozei (ultima zi observată); $h = 1, 5, 22$: o zi, o săptămână, o lună de zile de tranzacționare

- Modelele logaritmice prognozează $y = \ln RV_{t+1:t+h}$ și revin la nivel cu o corecție de varianță

$$F_t = \exp(\hat{y}_t + \hat{s}^2/2)$$

- ▶ F_t : prognoza lui $RV_{t+1:t+h}$ făcută în t ; $\hat{y}_t$: prognoza logaritmică estimată; $\hat{s}^2$: varianța reziduurilor regresiei
- ▶ $+\hat{s}^2/2$: deoarece $\mathbb{E}[e^Z] = e^{\mu+s^2/2}$ pentru $Z \sim N(\mu, s^2)$; exactă dacă eroarea logaritmică este condiționat Normală cu varianță constantă, altfel o aproximare
- Pentru $h > 1$ țintele se suprapun: apare dependență serială (pînă la lagul $h - 1$ prin construcție, posibil mai departe), deci fiecare test folosește o varianță HAC (Heteroskedasticity and Autocorrelation Consistent, robustă la heteroscedasticitate și autocorelare)

Ținte și funcții de pierdere (2/2): pierderi robuste

- O funcție de pierdere este **robustă** dacă, pentru un proxy condiționat nedeplasat, ordinea pierderilor *așteptate* cu RV_t coincide cu cea cu varianța adevărată [Patton \(2011\)](#)
 - ▶ Condiționat nedeplasat: $\mathbb{E}_{t-1}[RV_t] = \sigma_t^2$, unde $\mathbb{E}_{t-1}$ este media condiționată de informația pînă la $t - 1$, iar σ_t^2 este varianța adevărată a zilei t
- Cele două pierderi robuste folosite aici (scrise pentru $h = 1$; pentru $h > 1$, RV_t se înlocuiește cu ținta)

$$MSE_t = (RV_t - F_t)^2, \quad QLIKE_t = \frac{RV_t}{F_t} - \ln \frac{RV_t}{F_t} - 1 \geq 0$$

- ▶ F_t : prognoza lui RV_t ; QLIKE este zero doar dacă $F_t = RV_t$ și crește mai repede cînd prognoza este prea mică decît cînd este prea mare
- QLIKE depinde de raportul RV_t/F_t : aceeași eroare proporțională produce aceeași pierdere într-o zi calmă ca într-o zi volatilă
- MSE este dominată de cîteva zile de criză; QLIKE este pierderea principală, MSE cea secundară; modelele se compară prin pierderea medie pe zilele de evaluare

VOLARE: o arhivă deschisă de măsuri realizate

- Construită la universitățile din Messina și Florența din date tick cu tick [Cipollini et al. \(2026\)](#)
 - ▶ Curățare specifică fiecărui activ, calendare de tranzacționare și precizia marcajelor de timp; aceiași estimatori pentru toate clasele de active
- Gratuită pentru cercetare la volare.unime.it; nu este redistribuită împreună cu acest curs
 - ▶ Descărcați fișierele de varianță realizată și setați în notebook-uri calea către folderul local
- Citarea cerută de autori: Cipollini, Cruciani, Gallo, Insana, Otranto și Spagnolo (2026), arXiv:2602.19732



Universitatea din Messina, gazda VOLARE


Foto: [Superchilum \(2013\)](#); CC BY-SA 3.0; [Wikimedia Commons](#)

Panelul: 50 de active în trei clase

Clasa	Active	Eșantion	Observații	Volatilitate mediană
Acțiuni americane cu capitalizare mare	40	2 ian. 2015 – 30 ian. 2026	111 440	17,1%
Futures (C, CL, ES, GC, NG)	5	28 sept. 2009 – 30 ian. 2026	21 059	19,7%
FX (AUD, EUR, GBP, CAD, JPY față de USD)	5	25 sept. 2009 – 30 ian. 2026	21 203	7,3%

- Acțiuni: 40 de componente ale Dow Jones 30 și S&P 100 (de la AAPL la XOM); futures: porumb, petrol, E-mini S&P 500, aur, gaze naturale
- Volatilitatea mediană: $\sqrt{252 \text{ mediana}(RV_t)}$ pentru fiecare activ (cele 252 de zile de tranzacționare dintr-un an transformă varianța zilnică în varianță anuală), apoi mediana clasei; datele conțin doar zilele de tranzacționare
- Variabile folosite: RV la cinci minute, semivarianțele pozitivă și negativă (RV^+ , RV^-), cvarticitatea realizată (RQ) și prețurile zilnice de deschidere și de închidere

Volatilitatea realizată în clasele de active



- Volatilitatea anualizată $\sqrt{252} RV_t$, medie pe cinci zile, scală logaritmică, două active pe clasă (acțiuni: JPM = JPMorgan Chase, NVDA = Nvidia; futures: ES = E-mini S&P 500, CL = petrol; FX: EURUSD, USDJPY = dolarul american în yen); niveluri tipice: FX în jur de 7,3%, acțiunile în jur de 17,1% pe an
- Toate clasele prezintă un vîrf în martie 2020; petrolul (CL) atinge maximum în aprilie 2020, cînd contractul cu scadența cea mai apropiată s-a tranzacționat la un preț negativ: un model de prognoză trebuie să se adapteze în cîteva zile
- Pe scală logaritmică volatilitatea este staționară și persistentă (memoria lungă pe care o aproximează HAR); vîrfurile se disipă în cîteva săptămîni, deci forma traiectoriei recente conține informație

HAR: trei medii ale trecutului (1/2)

- Modelul HAR (Heterogeneous AutoRegressive, autoregresiv heterogen) [Corsi \(2009\)](#): RV viitoare este o funcție liniară de mediile zilnică, săptămînală și lunară ale RV trecute

$$RV_{t+1:t+h} = \beta_0 + \beta_d RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+h}$$

$$RV_t^{(w)} = \frac{1}{5} \sum_{j=0}^4 RV_{t-j}, \quad RV_t^{(m)} = \frac{1}{22} \sum_{j=0}^{21} RV_{t-j}$$

Notățiile

- ▶ $RV_t^{(w)}, RV_t^{(m)}$: mediile săptămînală (5 zile) și lunară (22 de zile) ale RV pînă în ziua t ; ε_{t+h} : eroarea de prognoză
 - ▶ β_0 : constanta; $\beta_d, \beta_w, \beta_m \geq 0$ în practică: cît contează ziua de ieri, ultima săptămîină și ultima lună; estimați prin OLS pentru fiecare orizont h
 - ▶ $\beta_d + \beta_w + \beta_m$ apropiat de 1: persistență ridicată a volatilității
- Participanți care tranzacționează la orizonturi zilnice, săptămînale și lunare: o cascadă care aproximează memoria lungă cu trei parametri

HAR: trei medii ale trecutului (2/2)

- HAR este un AR(22) restricționat: cei 22 de coeficienți ai lagurilor iau doar trei valori distincte

$$\phi_1 = \beta_d + \frac{\beta_w}{5} + \frac{\beta_m}{22}, \quad \phi_{2..5} = \frac{\beta_w}{5} + \frac{\beta_m}{22}, \quad \phi_{6..22} = \frac{\beta_m}{22}$$

- ▶ ϕ_j : coeficientul lui RV_{t+1-j} într-un AR(22) (autoregresie cu 22 de laguri); explicitarea celor două medii dă aceste valori
- log-HAR: aceeași regresie în logaritmi

$$\ln RV_{t+1:t+h} = \beta_0 + \beta_d \ln RV_t + \beta_w \ln RV_t^{(w)} + \beta_m \ln RV_t^{(m)} + \varepsilon_{t+h}$$

- ▶ Fără prognoze negative, mai puțin dominat de vîrfuri; revenirea la nivel cu $F_t = \exp(\hat{y}_t + \hat{s}^2/2)$
- ▶ Logaritmul mediei nu este media logaritmilor, deci acest log-HAR nu este exact un AR(22) restricționat în $\ln RV$ (Seminarul 20, A5)

Două rafinări (1/2): HARQ

- RV este un regresor generat: măsoară varianța adevărată cu o eroare

$$RV_t = IV_t + \eta_t, \quad \text{Var}(\eta_t) \approx 2 IQ_t / M$$

- η_t : eroarea de măsurare; erorile în variabile atenuază β_d (îl trag spre zero), mai ales în zilele zgomotoase

- HARQ [Bollerslev, Patton & Quaedvlieg \(2016\)](#): ponderea RV de ieri scade când RV este măsurată mai puțin precis

$$RV_{t+1:t+h} = \beta_0 + (\beta_d + \beta_Q(RQ_t^{1/2} - \overline{RQ^{1/2}}))RV_t + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+h}$$

- $RQ_t^{1/2}$: rădăcina pătrată a cvarticității realizate, o măsură a erorii lui RV_t ; $\overline{RQ^{1/2}}$: media ei în eșantion, deci β_d este ponderea într-o zi obișnuită
- Se așteaptă $\beta_Q < 0$: într-o zi zgomotoasă (RQ_t peste medie) RV de ieri primește o pondere mai mică

- Filtrul BPQ: o prognoză în afara intervalului din eșantion al țintei este înlocuită cu media din eșantion („insanity filter”)

Două rafinări (2/2): SHAR

- SHAR Patton & Sheppard (2015): descompunem termenul zilnic după semnul randamentelor intraday

$$RV_{t+1:t+h} = \beta_0 + \beta^+ RV_t^+ + \beta^- RV_t^- + \beta_w RV_t^{(w)} + \beta_m RV_t^{(m)} + \varepsilon_{t+h}$$

- ▶ RV_t^+, RV_t^- : semivarianțele pozitivă și negativă ale zilei t ; β^+, β^- : ponderile lor în prognoză
- ▶ $\beta^+ = \beta^-$ readuce HAR, deoarece $RV_t^+ + RV_t^- = RV_t$
- Patton și Sheppard găsesc $\beta^- > \beta^+$
 - ▶ Variația din scăderi prezice mai multă varianță viitoare decât variația din creșteri: o versiune intraday a efectului de levier (Capitolul 5)
- Semnătura poate surprinde un efect înrudit din date zilnice: aria Lévy dintre randamente și log RV (secțiunea despre semnături)


Șapte modele într-un tabel

Model	Țintă	Ponderi	Regresori
HAR	RV	egale	$RV_t, RV_t^{(w)}, RV_t^{(m)}$
log-HAR	$\ln RV$	egale	aceiași, în logaritmi
HARQ	RV	egale	$HAR + RV_t (RQ_t^{1/2} - \overline{RQ^{1/2}})$
SHAR	RV	egale	$RV_t^+, RV_t^-, RV_t^{(w)}, RV_t^{(m)}$
log-HAR-K	$\ln RV$	nucleul de semnătură	regresorii log-HAR
Sig-L	$\ln RV$	egale	log-HAR + 39 de termeni ai semnăturii, LASSO în doi pași
Sig-LK	$\ln RV$	nucleul de semnătură	ca Sig-L: metoda lui Gu et al.

- Ultimele patru formează o analiză 2×2 pe componente (ablație: fiecare componentă inclusă sau exclusă pe rând): trăsături de semnătură (da/nu) $\times$ ponderi de nucleu (da/nu)
- Log-HAR este reperul natural pentru modelele cu semnături: aceeași țintă, iar regresorii lui sînt printre candidați; dar LASSO poate elimina și termeni log-HAR, deci Sig-L față de log-HAR compară două proceduri, nu doar două mulțimi de variabile

Originile semnăturilor

- **Chen (1957)**: integralele iterate ale unei traiectorii formează o algebră și o determină pînă la reparametrizare
 - ▶ Kuo-Tsai Chen, geometria spațiilor de bucle
- **Lyons (1998)**: teoria traiectoriilor aspre (rough paths); semnătura este mulțimea naturală de trăsături pentru ecuațiile diferențiale controlate
 - ▶ Soluția unei ecuații controlate de o traiectorie depinde de aceasta (în primă aproximare) doar prin semnătura ei
- Învățare automată: **Levin, Lyons & Ni (2013)**, **Chevyrev & Kormilitzin (2016)**, **Lyons & McLeod (2022)**; finanțe: modele de prețuri bazate pe semnături **Cuchiero, Gazzani & Svaluto-Ferro (2023)**



Terry Lyons (stînga), Oberwolfach, 2024

Foto: **Katrin Schmid (2024)**; CC BY-SA 2.0 DE; **Wikimedia**

Commons

O fereastră de date este o traiectorie

- Considerăm ultimele L zile ale celor $d - 1$ serii, adăugăm timpul ca un canal și unim punctele prin segmente

$$X : [0, 1] \rightarrow \mathbb{R}^d, \quad X_{u_i} = \left(u_i, \ln RV_{t-L+1+i}, \sum_{j \leq t-L+1+i} r_j \right), \quad u_i = \frac{i}{L-1}, \quad i = 0, \dots, L-1$$

- L : lungimea ferestrei în zile (aici 22); d : numărul de canale (aici $d = 3$: timp, log RV, randament cumulat); $u_i \in [0, 1]$: timpul rescalat al punctului i ; r_j : randamentul de la deschidere la închidere al zilei j
- Augmentarea cu timpul: primul canal este chiar timpul
 - Fără el, semnătura nu distinge o mișcare rapidă de una lentă (invarianța la reparametrizare)
- O regresie pe fereastră folosește 22 de laguri; un rezumat al traiectoriei surprinde și ordinea, viteza și co-mișcarea lor
 - Exemplu: RV a crescut în timp ce prețurile scădeau, sau RV a crescut întâi și prețurile au scăzut mai târziu

Semnătura: definiție (1/2)

- Un termen al semnăturii este o integrală iterată a traiectoriei de-a lungul unui cuvânt de canale

$$S(X)_{a,b}^{i_1 \dots i_k} = \int_{a < u_1 < \dots < u_k < b} dX_{u_1}^{i_1} \dots dX_{u_k}^{i_k}$$

- Notățiile

- ▶ $X : [a, b] \rightarrow \mathbb{R}^d$: o traiectorie cu variație mărginită (lungime totală finită), de exemplu liniară pe porțiuni; X_u^i : canalul ei i la momentul u
- ▶ Cuvântul $(i_1, \dots, i_k)$: o listă ordonată de k canale, cu litere din $\{1, \dots, d\}$; k este **nivelul** termenului
- ▶ $u_1 < \dots < u_k$: integrala se calculează pe momente ordonate; dX_u^i : incrementul canalului i la momentul u (pe un segment liniar, panta înmulțită cu du)

Semnătura: definiție (2/2)

- Semnătura este întregul șir de niveluri

$$\text{Sig}(X) = (1, S^{(1)}, S^{(2)}, S^{(3)}, \dots), \quad S^{(k)} \in (\mathbb{R}^d)^{\otimes k}$$

- ▶ $S^{(k)}$: cei d^k termeni de nivelul k , unul pentru fiecare cuvînt de lungime k , aranjați ca un tablou k -dimensional (un tensor; $\otimes$: produsul tensorial)
- ▶ $\text{Sig}^N(X)$: semnătura trunchiată, nivelurile de la 0 la N ; N este adîncimea

- Nivelul 1: incrementele totale ale canalelor

$$S^i = X_b^i - X_a^i$$

- Nivelul 2: incrementele canalului j ponderate cu cît s-a deplasat deja canalul i

$$S^{ij} = \int_a^b (X_u^i - X_a^i) dX_u^j$$

- ▶ Nivelul 3 adaugă încă o integrală; nivelurile superioare rețin detalii tot mai fine ale ordinii mișcărilor

Segmente liniare și identitatea lui Chen (1/2)

- Un segment liniar cu incrementul $\Delta \in \mathbb{R}^d$ are ca semnătură exponențială tensorială

$$\text{Sig}(\text{segment}) = \exp_{\otimes}(\Delta) = \left(1, \Delta, \frac{1}{2!}\Delta^{\otimes 2}, \frac{1}{3!}\Delta^{\otimes 3}, \dots\right)$$

- $\Delta = X_b - X_a$: incrementul segmentului; $\Delta^{\otimes k}$: tabloul tuturor produselor $\Delta^{i_1} \dots \Delta^{i_k}$, deci un termen de nivelul k este $\Delta^{i_1} \dots \Delta^{i_k} / k!$

- **Identitatea lui Chen** [Chen \(1957\)](#): semnătura a două traiectorii parcurse una după alta este produsul tensorial al semnăturilor lor

$$\text{Sig}(X * Y) = \text{Sig}(X) \otimes \text{Sig}(Y), \quad (A \otimes B)^{(k)} = \sum_{p=0}^k A^{(k-p)} \otimes B^{(p)}$$

- $X * Y$: concatenarea, Y începe unde se termină X ; $A^{(k)}, B^{(k)}$: nivelul k al semnăturilor A, B , cu $A^{(0)} = B^{(0)} = 1$
- Nivelul k al traiectoriei întregi adună toate modurile de a împărți un cuvânt de lungime k între prima și a doua bucată

Segmente liniare și identitatea lui Chen (2/2)

- O traiectorie liniară pe porțiuni cu m segmente, cu incrementele $\Delta_1, \dots, \Delta_m$

$$\text{Sig} = \exp_{\otimes}(\Delta_1) \otimes \dots \otimes \exp_{\otimes}(\Delta_m)$$

- ▶ Algoritmul se reduce la atît: m actualizări, fiecare de cost $O(d^N)$ la adîncimea N (cîteva rînduri de numpy); $O(\cdot)$: ordinul numărului de operații

- Ferestre mobile: identitatea lui Chen permite și eliminarea unei porțiuni inițiale

$$\text{Sig}(X_{[s,t]}) = \text{Sig}(X_{[a,s]})^{-1} \otimes \text{Sig}(X_{[a,t]})$$

- ▶ $X_{[s,t]}$: traiectoria restrînsă la $[s, t]$, cu $a \leq s \leq t$; $(\cdot)^{-1}$: inversul față de $\otimes$, semnătura porțiunii parcurse în sens invers

Exemplu rezolvat: o traiectorie cu două segmente

Traectoria

- ▣ $X : (0, 0) \rightarrow (1, 0) \rightarrow (1, 2); \Delta_1 = (1, 0), \Delta_2 = (0, 2)$
- ▣ Nivelul 1: $S^{(1)} = \Delta_1 + \Delta_2 = (1, 2)$
- ▣ Nivelul 2 prin Chen:

$$S^{ij} = \frac{1}{2} \Delta_1^i \Delta_1^j + \Delta_1^i \Delta_2^j + \frac{1}{2} \Delta_2^i \Delta_2^j$$
- ▣ Δ_m^i : componenta i a incrementului segmentului m ; termenul din mijloc: canalul i se mișcă în segmentul 1 înainte ca j să se miște în segmentul 2

Rezultat


- ▣ $S^{11} = \frac{1}{2}, S^{12} = 0 + 1 \cdot 2 + 0 = 2$
- ▣ $S^{21} = 0, S^{22} = \frac{1}{2} \cdot 2^2 = 2$
- ▣ Verificare: $S^{11} = (\Delta X^1)^2/2$ și $S^{22} = (\Delta X^2)^2/2$ (identitatea shuffle)
- ▣ $S^{12} \neq S^{21}$: ordinea contează (întâi la dreapta, apoi în sus)

Aria Lévy: ordinea exprimată numeric

- Aria Lévy A^{ij} : partea antisimetrică a nivelului 2

$$A^{ij} = \frac{1}{2}(S^{ij} - S^{ji})$$

- ▶ Este aria cu semn dintre traiectorie, proiectată pe canalele (i, j) , și coarda ei (dreapta de la început la sfârșit)
- ▶ $A^{ij} > 0$: canalul i tinde să se miște înaintea canalului j ; $A^{ij} = -A^{ji}$
- Partea simetrică: $\frac{1}{2}(S^{ij} + S^{ji}) = \frac{1}{2} \Delta X^i \Delta X^j$, nicio informație nouă
 - ▶ Exemplul de mai sus: $A^{12} = (2 - 0)/2 = 1$, aria triunghiului de sub traiectorie
- Canalele (randament, log RV): o scădere a prețului urmată de o creștere a volatilității dă $A < 0$, dar la fel și o creștere urmată de o scădere a volatilității
 - ▶ O statistică de tip lead-lag: secvențele de tip levier ([Capitolul 5](#)) sînt una dintre sursele unei arii negative; semnul singur nu le identifică




Paul Lévy (1886–1971)

Foto: Konrad Jacobs; CC BY-SA 2.0 DE;

[Wikimedia Commons](#)

Două ferestre JPM reprezentate ca traiectorii



- Traectoria (randament cumulat de la deschidere la închidere, log RV) pe 22 de zile; coarda punctată unește începutul și sfârșitul; zona hașurată dă aria Lévy
- Fereastra calmă (pînă la 15 nov. 2019): log RV se schimbă cu -0,58, traiectoria fluctuează fără direcție, aria Lévy -0,011; fereastra de stres (pînă la 16 mar. 2020): log RV crește cu +4,32 ($RV \times 75$) în timp ce randamentele scad, aria Lévy -0,247
- Randamentul intraday net este doar +0,5%: crahul s-a produs în mare parte peste noapte, în afara acestui canal; nicio adîncime a semnăturii nu poate recupera informația absentă din date

Fundamentele teoretice ale semnăturilor (1/2): unicitate și shuffle

- **Unicitate Hambly & Lyons (2010):** semnătura completă identifică traiectoria
 - ▶ $\text{Sig}(X)$ determină X până la o echivalență de tip arbore (adăugarea unor porțiuni parcurse apoi înapoi) și o translație
 - ▶ Cu un canal de timp strict crescător nimic nu poate fi parcurs înapoi, deci rămîne doar translația
 - ▶ O trunchiere finită Sig^N nu este injectivă: două traiectorii diferite pot avea aceleași niveluri $1..N$
- **Identitatea shuffle:** un produs de termeni ai semnăturii este o sumă de termeni superiori

$$S^i S^j = S^{ij} + S^{ji}, \quad S^{ij} S^k = S^{ijk} + S^{ikj} + S^{kij}$$

- ▶ Suma se face pe toate intercalările (shuffle) ale celor două cuvinte care păstrează ordinea din fiecare cuvînt
- ▶ Deci un model liniar în $\text{Sig}^N(X)$ conține deja polinoame în incremente

Fundamentele teoretice ale semnăturilor (2/2): universalitate și descreștere

- **Universalitate:** orice funcție continuă de traiectorie este aproximativ liniară în semnătură (Stone–Weierstrass, prin identitatea shuffle)

$$\forall \varepsilon > 0 \quad \exists \ell \text{ liniară} : \quad \sup_{X \in K} |f(X) - \langle \ell, \text{Sig}(X) \rangle| < \varepsilon$$


- ▶ K : o mulțime compactă de traiectorii augmentate cu timpul, cu start comun (în topologia 1-variației); $f : K \rightarrow \mathbb{R}$: o funcție continuă de traiectorie
- ▶ $\langle \ell, \text{Sig}(X) \rangle$: o sumă ponderată a unui număr finit de termeni ai semnăturii, adică o regresie liniară pe aceștia
- ▶ De aceea un LASSO pe semnături poate aproxima funcții neliniare ale traiectoriei; costul este de d^N trăsături, deci este necesară o soluție cu puțini coeficienți nenuli

- **Descreștere factorială:** nivelurile înalte sînt mici

$$\|S^{(k)}\| \leq \frac{\|X\|_{\mathbf{1-var}}^k}{k!}$$

- ▶ $\|X\|_{\mathbf{1-var}}$: lungimea totală a traiectoriei (suma lungimilor segmentelor); $\|S^{(k)}\|$: mărimea (norma euclidiană) nivelului k
 - ▶ Trunchierea la o adîncime mică N pierde puțin pentru traiectorii de lungime moderată; de aceea canalele se rescalează
- (▶ Anexă)

Numărul de trăsături: dimensiunea trunchierii



- Numărul de termeni din nivelurile 1..N ale unei traiectorii d -dimensionale (o sumă geometrică, deoarece nivelul k are d^k cuvinte)

$$\dim(d, N) = \sum_{k=1}^N d^k = \frac{d^{N+1} - d}{d - 1}$$

- În acest capitol: $d = 3$ canale (timp, log RV, randament cumulat), adâncimea $N = 3$: $3 + 9 + 27 = 39$ de termeni
 - Trei sînt constanți (cuvintele doar cu litera timpului), deci 36 variază
- $d = 5$, $N = 4$ ar da 780 de termeni pentru 1000 de observații: LASSO ar selecta zgomot
- Gu et al. nu publică N și L ; aici $N = 3$, $L = 22$ sînt fixate dinainte, cu $N = 2$ ca verificare de robustețe

 MFM_ch20_signatures

Două invarianțe de reținut

- **Invarianța la translație:** $\text{Sig}(X + c) = \text{Sig}(X)$ pentru orice vector constant $c \in \mathbb{R}^d$: contează doar incrementele
 - ▶ Semnătura nu reflectă **nivelul** volatilității, doar forma traiectoriei recente
 - ▶ Deci nivelul trebuie să intre separat: termenii log-HAR joacă rolul factorilor externi x_τ ai lui Gu et al.
- **Invarianța la reparametrizare:** parcurgerea traiectoriei mai repede sau mai încet, $X_{\psi(u)}$ cu ψ crescătoare, lasă Sig neschimbată
 - ▶ Eliminată de canalul de timp; augmentarea cu punct de bază (adăugarea la început a unui segment de la 0 la punctul de start inițial) ar elimina prima invarianță [Morrill et al. \(2020\)](#)
 - ▶ Translatarea traiectoriei ca să pornească din 0 nu o elimină: este ea însăși o translație (Seminarul 20, C1 folosește segmentul adăugat la început)

Nucleul de semnătură

- Nucleu = produsul scalar al aplicațiilor de trăsături Király & Oberhauser (2019): un scor de asemănare între două traiectorii

$$k_N(X, Y) = \langle \text{Sig}^N(X), \text{Sig}^N(Y) \rangle = 1 + \sum_{k=1}^N \sum_{|w|=k} S(X)^w S(Y)^w$$


- ▶ X, Y : două traiectorii cu aceleași canale; w : un cuvânt, $|w|$: lungimea lui (nivelul); $S(X)^w$: termenul cuvântului w ; 1 din față este nivelul 0
- Distanța indusă de nucleu (Gu et al., ec. 9): pătratul distanței euclidiene dintre semnăturile trunchiate

$$d_{\text{Sig}}(X, Y) = k_N(X, X) - 2k_N(X, Y) + k_N(Y, Y) = \|\text{Sig}^N(X) - \text{Sig}^N(Y)\|^2$$

- ▶ $d_{\text{Sig}} = 0$: cele două ferestre au aceeași semnătură pînă la adîncimea N ; d_{Sig} mare: forme diferite
- Gu et al. și acest capitol folosesc acest nucleu **trunchiat**, cu același N ca pentru trăsături
 - ▶ Nucleul netrunchiat rezolvă o ecuație cu derivate parțiale de tip Goursat (Partial Differential Equation, PDE) Salvi et al. (2021); articolul îl citează, dar nu îl folosește
- Canalele se rescalează înaintea nucleului (▶ Anexă): altfel domină canalul cu unitățile cele mai mari

Problema de la Amazon și trăsăturile

- Tarife săptămânale pe piața nord-americană de transport rutier, la nivel național și în cinci regiuni, 2018–2022, prognozate pe pînă la 12 săptămîni [Gu et al. \(2024\)](#)
 - ▶ Peste 100 de factori candidați, reduși la aproximativ 40; folosită folosită în operațiunile Amazon din noiembrie 2022; KDD 2024 (ACM Conference on Knowledge Discovery and Data Mining)
- Trăsăturile în săptămîna τ (Secțiunea 4.1, ec. 14): factorii externi x_τ și semnătura traiectoriei ținte, augmentată cu timpul
 - ▶ $\xi_\tau = [x_\tau, \text{Sig}^N(\hat{y}_{\tau-l:\tau})]$, $\hat{y}_{\tau-l:\tau} = \{(t_i, y_{t_i})\}$
 - ▶ y_{t_i} : tariful din săptămîna t_i , $\tau - l \leq t_i \leq \tau$; l : fereastra în săptămîni; $\hat{y}_{\tau-l:\tau}$: traiectoria augmentată cu timpul a ultimelor l săptămîni
- O regresie directă pe orizont Δt (în săptămîni), $y_{\tau+\Delta t}$ pe ξ_τ ; fereastra l , adîncimea N , temperatura γ (slide-urile următoare) nu sînt publicate (confidențialitate)



Un camion cu container pe o autostradă americană,
2025

Foto: DanTD (2025); CC BY 4.0; Wikimedia Commons

Metoda: LASSO în doi pași

- ▣ Pasul 1, selecție printr-un LASSO ponderat (Least Absolute Shrinkage and Selection Operator) [Tibshirani \(1996\)](#) (ec. 14)

$$\hat{\theta}_L = \arg \min_{\theta} \sum_{\tau} w_{\tau} (y_{\tau+\Delta t} - \xi_{\tau}^{\top} \theta)^2 + \lambda \|\theta\|_1$$

- ▶ θ : vectorul coeficienților; $w_{\tau} \geq 0$: ponderea săptămânii τ (egală sau dată de nucleu, slide-ul următor); $\|\theta\|_1 = \sum_j |\theta_j|$
- ▶ $\lambda \geq 0$: penalizarea; un λ mai mare anulează exact mai mulți coeficienți; $\lambda = 0$ înseamnă OLS ponderat

- ▣ Pasul 2, reestimare prin OLS ponderat pe suportul selectat (ec. 15)

$$\hat{\theta} = \arg \min_{\text{supp}(\theta)=\text{supp}(\hat{\theta}_L)} \sum_{\tau} w_{\tau} (y_{\tau+\Delta t} - \xi_{\tau}^{\top} \theta)^2$$

- ▶ $\text{supp}(\theta)$: suportul, mulțimea coeficienților nenuli; se reestimează doar regresorii păstrați la pasul 1
- ▣ Motivul reestimării: LASSO micșorează spre zero coeficienții păstrați; OLS după selecție elimină această deplasare [Belloni & Chernozhukov \(2013\)](#)
 - ▶ Articolul îl numește „adaptiv” din cauza ponderilor w_{τ} , nu în sensul LASSO-ului adaptiv al lui [Zou \(2006\)](#)
- ▣ Modul de alegere a lui λ nu este raportat

Metoda: ponderi date de nucleu

- Distanța fiecărei ferestre trecute față de ultima fereastră cu țintă observată (ec. 11)

$$\delta_{\tau} = d_{\text{Sig},N}(z_{\tau-l:\tau}, z_{t-\Delta t-l:t-\Delta t})$$

- ▶ $z_{\tau} = (x_{\tau}, y_{\tau+\Delta t})$: *perechile* de predictor și țintă ulterioară, nu trăsăturile ξ_{τ} (Algoritmul 1); $z_{\tau-l:\tau}$: traiectoria lor pe l săptămâni
- ▶ t : săptămîna curentă; $t - \Delta t$: ultima săptămîna a cărei țintă y_t este deja observată; $d_{\text{Sig},N}$: distanța de semnătură la adîncimea N

- Ponderi softmax cu temperatura $\gamma \geq 0$ (ec. 12): ferestrele asemănătoare (δ_{τ} mic) primesc o pondere mai mare

$$w_{\tau} = \frac{\exp(-\gamma \delta_{\tau})}{\sum_s \exp(-\gamma \delta_s)}$$

- ▶ s : parcurge toate săptămînile de antrenare, deci ponderile însumează 1; $\gamma = 0$: regresie obișnuită (ponderi egale); $\gamma \rightarrow \infty$: doar cea mai asemănătoare fereastră trecută
- O idee de tip cel mai apropiat vecin într-o regresie: învățăm din perioadele trecute care semănau cu prezentul
- ▶ Costul ideii: mai puține observații efective, $n_{\text{eff}} = 1 / \sum_{\tau} w_{\tau}^2$ (Kish); $n_{\text{eff}} = n$ pentru ponderi egale $1/n$, $n_{\text{eff}} = 1$ dacă o singură săptămîna ia toată ponderea

Rezultatele articolului: o lectură critică

- Tarife naționale, cu trei luni înainte, aprilie–noiembrie 2021 (Tabelul 1): eroarea relativă $|y - \hat{y}|/|y|$ (y : tariful realizat, $\hat{y}$: prognoza lui) de aproximativ 1–2% față de 13–27% pentru prognoza din industrie, „de peste cinci ori”
 - ▶ Orizonturi de 1–12 săptămîni (Tabelul 2): 1,06–2,60% la nivel național, 1,05–5,69% pe regiuni; economie anuală estimată de aproximativ 50 de milioane de dolari
 - ▶ Ablația nucleului (Tabelul 3, șase valori săptămînale, 31 octombrie–5 decembrie 2021, o regiune): erori de pînă la 9,85% fără nucleu, față de pînă la 5,15% cu el
- Limitele dovezilor
 - ▶ **Un singur reper:** o prognoză comercială al cărei furnizor nu este precizat; fără ARIMA, fără LASSO fără semnături, fără mers aleator
 - ▶ **Evaluare scurtă:** cîteva luni, cîteva serii, fără erori standard, fără un test de acuratețe egală
 - ▶ **Calibrare nepublicată:** I , N , γ , λ și modul lor de alegere
- Aceste limite nu invalidează metoda, dar slăbesc dovezile; de aceea o testăm în alt context, replicarea înaintea extinderii (Capitolul 19)

Transferul la volatilitate: componente preluate și adaptate

Se transferă

- ▣ Semnătura traiectoriei recente a țintei, augmentată cu timpul
- ▣ LASSO în doi pași cu ponderi, regresie directă pe orizont
- ▣ Ponderi softmax $\exp(-\gamma \delta_\tau)$ cu nucleul de semnătură trunchiat

Trebuie adaptat

- ▣ Țintă zilnică și zgomotoasă în loc de tarife săptămânale: logaritmi, inferență HAC, pierderi robuste
- ▣ Factorii externi x_τ înlocuiți de termenii log-HAR (aceștia aduc informația despre nivel)
- ▣ Alegerile nepublicate (I, N, γ, λ) fixate dinainte în acest capitol
- ▣ Nucleul: traiectoria din acest capitol (timp, ln RV, randament) care se termină în τ față de fereastra care se termină în t , actualizat la 5 zile, în locul perechilor $(x_\tau, y_{\tau+\Delta t})$ care se termină în $t - \Delta t$: o adaptare
- ▣ Repere puternice și teste formale în locul unei singure prognoze comerciale

Ipoteze

- ▣ **H1 (trăsături):** termenii semnăturii aduc informație dincolo de log-HAR
 - ▶ Test: Sig-L față de log-HAR, aceeași țintă, aceleași ponderi egale
- ▣ **H2 (ponderi):** ponderile de nucleu îmbunătățesc o regresie dată
 - ▶ Teste: Sig-LK față de Sig-L și log-HAR-K față de log-HAR
- ▣ **H3 (metoda):** metoda completă a lui Gu et al. depășește familia HAR
 - ▶ Teste: Sig-LK față de HAR și de log-HAR; mulțimea de încredere a celor șapte modele
- ▣ **H4 (stres):** orice câștig este mai mare în perioadele de stres (crahul din pandemia COVID-19, 2–30 aprilie 2020, șocul tarifelor americane), unde ferestrele trecute asemănătoare ar trebui să conteze cel mai mult


Temperatura nucleului: o alegere pe clasă, pe un bloc de validare

- Temperatură fără unități, fixată în fiecare fereastră de antrenare

$$\gamma = \frac{c}{\text{median}_{\tau}(\delta_{\tau})}$$

- ▶ δ_{τ} : distanțele nucleului dintre zilele de antrenare și fereastra curentă; $c > 0$: o constantă fără unități, singurul parametru de calibrare
- ▶ Împărțirea la mediană elimină unitățile lui δ_{τ} ; $c = 1$: o fereastră la distanța mediană primește ponderea e^{-1} față de una identică; c mai mare: ponderi mai concentrate
- Grila $c \in \{0,5; 1; 2; 4\}$, aleasă pe orizont și pe clasă de active, pe primele 250 de zile de prognoză ale fiecărui activ, agregat la nivelul clasei de active
 - ▶ Criteriu: media pe clasă a QLIKE(c) împărțită la media activului pe grilă
 - ▶ Evaluarea începe după ultima țintă de validare a clasei, deci nicio țintă folosită la calibrare nu este ulterioară unei origini evaluate
- Pentru cele 40 de acțiuni, cea mai mică temperatură, $c = 0,5$ (ponderile cele mai apropiate de cele egale), este aleasă la fiecare orizont pentru Sig-LK; pentru futures și FX alegerea se schimbă cu orizontul: un criteriu plat și zgomotos (toate valorile în [Anexă](#))

Estimarea pe fereastră mobilă, pas cu pas



primele 250 de zile de prognoză ale fiecărui activ: doar validarea lui c , agregat la nivelul clasei de active

apoi evaluarea tuturor modelelor, de la prima origine de după ultima țintă de validare a clasei până la ultima țintă

- Reestimăm la fiecare 5 zile de tranzacționare pe ultimele 1000 de perechi complete; între reestimări coeficienții sînt ficși, dar regresorii se actualizează zilnic
- Distanțele nucleului se recalculează la fiecare reestimare, față de fereastra care se termină la originea t

Protocolul de evaluare (1/2): testul DM

- Pe activ și orizont: QLIKE și MSE medii, comparate prin testul DM (Diebold–Mariano) de acuratețe predictivă egală [Diebold & Mariano \(1995\)](#)

$$d_t = L(RV_t, F_t^A) - L(RV_t, F_t^B), \quad DM = \frac{\bar{d}}{\sqrt{\hat{\Omega}/T}}$$

- ▶ L : funcția de pierdere (QLIKE sau MSE); F_t^A, F_t^B : prognozele modelelor A și B ; d_t : diferența de pierdere; $\bar{d}$: media ei pe cele T zile de evaluare
- ▶ $\hat{\Omega}$: varianța de termen lung Newey–West (HAC) a lui d_t , lățimea de bandă $\max(h, \lceil T^{1/3} \rceil)$ laguri; $\lceil \cdot \rceil$: rotunjire în sus
- Interpretare: sub H_0 : $\mathbb{E}[d_t] = 0$, DM are aproximativ distribuția $N(0, 1)$
 - ▶ $DM < -1,645$: modelul A este semnificativ mai precis la 5% (unilateral); $DM > 1,645$: semnificativ mai puțin precis
 - ▶ Estimare pe fereastră mobilă, deci testul se citește ca testul GW (Giacomini–White) necondiționat; testul GW condiționat verifică în plus dacă d_{t-h} prezice d_t (instrumentele $(1, d_{t-h})$) [Giacomini & White \(2006\)](#)


Protocolul de evaluare (2/2): multe modele, multe active

- MCS (Model Confidence Set, mulțimea de încredere a modelelor) la 90% [Hansen, Lunde & Nason \(2011\)](#): mulțimea de modele care conține cel mai bun model cu probabilitate de cel puțin 90%
 - ▶ Construită prin eliminare: cât timp statistica $T_{\max}$ (cea mai mare diferență standardizată dintre pierderea medie a unui model și media modelelor aflate încă în mulțime) respinge acuratețea egală, se elimină cel mai slab model
 - ▶ Valorile p prin bootstrap staționar, 1000 de replicări, lungimea medie a blocului $\max(h, 10)$ zile
- Panel: testul DM pe diferența medie de pierdere pe secțiune transversală (o serie pe dată)
 - ▶ Numărul activelor cu rezultate semnificativ mai bune (din 50): corecția Holm controlează FWER (Family-Wise Error Rate, probabilitatea a cel puțin unei respingeri false), BH [Benjamini & Hochberg \(1995\)](#) controlează FDR (False Discovery Rate, proporția așteptată de respingeri false printre respingeri)
- Subperioade: 20 feb.–30 apr. 2020, 2–30 apr. 2025, toate celelalte zile; eroarea relativă din articol ca statistică descriptivă
- 265 929 de prognoze în afara eșantionului pentru fiecare model; acțiunile sînt evaluate din ianuarie 2020 (crahul COVID-19 este în eșantionul fiecărei acțiuni), futures și FX din 2014 (datele în [▶ Anexă](#))

O abatere declarată

- ▣ Preînregistrat: filtrul BPQ („insanity filter”) pe toate modelele
 - ▶ Un test al codului pe JPM (un singur activ, înaintea oricărui rezultat pe panel) a arătat că înlocuiește prognoze corecte din perioada crahului cu media din perioada calmă a eșantionului
 - ▶ Pe 12 martie 2020, RV observată în ziua următoare pentru JPM a fost de aproximativ 40 de ori mai mare decât prognoza HAR filtrată
- ▣ Modificare făcută înainte de estimarea pe panelul de 50 de active: rezultatele principale doar cu pozitivitate (o prognoză ≤ 0 devine media din eșantion)
 - ▶ Filtrul BPQ rămîne ca verificare de robustețe și este raportat complet
- ▣ Regula: o abatere este permisă, o abatere ascunsă nu; precizați ce ați observat înainte de modificare

QLIKE relativ la HAR, activ cu activ




- Raportul pentru fiecare activ: QLIKE medie a modelului împărțită la QLIKE medie a HAR; sub 1: mai precis decât HAR; cutii: intervalul intercuartilic pe cele 50 de active; linia: mediana; romb: media; mustățile: 1,5 intervale intercuartile
- $h = 1$: log-HAR, log-HAR-K și Sig-L sînt apropiate (0,883; 0,885; 0,886); Sig-LK este la +4,5% față de log-HAR: niciun câștig din 36 de trăsături în plus
- $h = 5, 22$: Sig-LK rămîne în urma log-HAR (+28,0%; +92,9%); medianele (0,997; 0,968) sînt mult mai bune decât mediile: cîteva active și zile determină pierderea
- HARQ și SHAR sînt aici inferioare modelului HAR în nivel, pentru că specificația principală nu aplică filtrul BPQ (vezi [Anexa](#)): filtrul ameliorează HARQ); primul verdict: metoda nu depășește cel mai simplu model logaritmic (o egalitate aproximativă nu dovedește acuratețe egală)

Comparații activ cu activ, cu corecție pentru testare multiplă

Comparația (QLIKE)	$h = 1$		$h = 5$		$h = 22$	
Sig-LK față de log-HAR	2/0/0	5/0/0	0/0/0	15/0/2	0/0/0	27/1/16
Sig-L față de log-HAR	3/1/1	5/0/0	0/0/0	9/0/0	1/0/0	21/0/0
log-HAR-K față de log-HAR	3/0/0	3/0/0	3/0/0	1/0/0	5/0/0	6/0/0
Sig-LK față de Sig-L	2/0/0	5/0/0	0/0/0	5/0/0	2/0/0	10/0/0
Sig-LK față de HAR	12/5/6	0/0/0	7/1/1	0/0/0	8/2/4	1/0/0
log-HAR față de HAR	21/5/17	0/0/0	23/13/20	0/0/0	42/25/42	0/0/0


- Celula: numărul de active semnificativ mai bune, fără corecție/Holm/BH | semnificativ mai slabe, fără corecție/Holm/BH; DM unilateral la 5%, familie de 50 de active; Holm controlează FWER sub orice dependență, BH controlează FDR sub independență sau PRDS (Positive Regression Dependence on a Subset, dependență pozitivă de regresie pe o submulțime) [Benjamini & Yekutieli \(2001\)](#)
- H1 (semnături): Sig-L este superior log-HAR pe 3 din 50 de active la $h = 1$ fără corecție, 1 după Holm; doar prin hazard se așteaptă aproximativ 2,5 respingeri necorectate
- H2 (ponderi): log-HAR-K față de log-HAR și Sig-LK față de Sig-L: nicio diferență semnificativă după Holm, la niciun orizont
- Față de HAR la $h = 1$, Sig-LK este superior pe 12 active, dar log-HAR singur pe 21: alegeți reperul care izolează ideea

Statisticile DM pentru fiecare activ și orizont



- Statisticile t Diebold–Mariano ale diferenței QLIKE; albastru: Sig-LK mai precis, roșu: mai puțin precis
- Față de log-HAR (stînga): culori palide la $h = 1$ (excepții albastre ES, TSLA, EURUSD; cinci active semnificativ roșii înaintea corecției), roșu la $h = 5, 22$
- Față de HAR (dreapta): albastru la $h = 1$ pentru că Sig-LK moștenește ținta logaritmică; o singură celulă, ca ES la $h = 1$, ar face semnăturile să pară un succes clar

Mulțimi de încredere pentru modele




- Propoția din cele 50 de active pentru care fiecare model aparține MCS de 90% sub QLIKE: log-HAR 100%, 98%, 98%; Sig-LK 100%, 94%, 88% ($h = 1, 5, 22$)
- MCS discriminează rar între cele patru modele logaritmice; HAR, HARQ și SHAR sînt excluse pentru o cincime pînă la o treime dintre active: ținta în nivel este clar cea mai slabă alegere
- Sub MSE aproape fiecare model rămîne în mulțime [Patton \(2011\)](#): diferențele mici de pierdere medie cer eșantioane foarte lungi [Pele & Mazurencu-Marinescu-Pele \(2026\)](#)

Teste pe panel: cumularea dovezilor

Comparația: DM t (p unilateral)	$h = 1$	$h = 5$	$h = 22$
Sig-LK față de log-HAR	+1,45 (0,927)	+1,68 (0,953)	+1,80 (0,964)
Sig-L față de log-HAR	-1,91 (0,028)	+1,48 (0,931)	+1,51 (0,935)
log-HAR-K față de log-HAR	+1,89 (0,971)	+0,40 (0,654)	+1,92 (0,973)
Sig-LK față de Sig-L	+1,74 (0,959)	+0,98 (0,837)	-0,77 (0,221)
log-HAR față de HAR	-3,09 (<0,001)	-3,95 (<0,001)	-4,50 (<0,001)


- ▣ Seria: diferența medie QLIKE pe toate activele tranzacționate în acea zi; t negativ = primul model mai bun
- ▣ Agregat, doar transformarea logaritmică este clar semnificativă; Sig-L față de log-HAR la $h = 1$ este la limită ($p = 0,028$), datorită contractelor futures
 - ▶ Doar pentru cele 40 de acțiuni semnul se inversează: $t = +1,72$ împotriva Sig-L
- ▣ Testul GW condiționat, Sig-LK față de log-HAR: 0, 0 și 0 respingeri Holm din 50

În crahul din pandemia COVID-19: JPM, ziua următoare




- ▣ Volatilitatea anualizată $\sqrt{252F_t}$ a prognozelor și $\sqrt{252RV_{t+1}}$ a țintei, februarie–mai 2020; toate modelele reacționează cu întârziere la primul salt
- ▣ Sig-LK reacționează puțin mai repede decât log-HAR la mijlocul lui martie, când traiectoria și-a schimbat deja direcția; după vîrf ambele scad cu viteze asemănătoare
- ▣ HAR în nivel depășește ținta, apoi devine negativ la sfîrșitul lui martie: regula de pozitivitate îl înlocuiește cu media din eșantion (segmentul plat)

Perioade de stres față de perioade normale (H4)




- Media pe active a QLIKE relativ la HAR în fiecare subperioadă fixată înaintea evaluării
- $h = 1$, crahul COVID-19: log-HAR 0,70, Sig-LK 0,73, HARQ 1,89; 2–30 aprilie 2025 (șocul tarifelor americane): 0,88 și 0,92; celelalte zile: 0,94 și 0,97
- $h = 22$, crahul COVID-19: Sig-LK de 6,35 ori și Sig-L de 8,30 ori pierderea HAR: tocmai acolo unde ferestrele trecute asemănătoare ar trebui să ajute, modelele cu semnături au cele mai slabe rezultate; H4 nesușinută (descriptiv, fără test formal de interacțiune)

Ponderile nucleului la originea din 16 martie 2020




- Ponderile Sig-LK ($h = 1$) la originea din 16 martie 2020 pe zilele de antrenare (24 mar. 2016 – 13 mar. 2020), înmulțite cu lungimea ferestrei: 1 = ponderare egală
- Aproape egale: între 0,61 și 1,43 ori $1/n$, mărimea efectivă a eșantionului 975 din 1000 (media celor 40 de acțiuni); cele mai mari ponderi revin ultimelor zile dinaintea originii
- Scăderile de la sfârșitul lui 2018 primesc o pondere *mai mică*; ponderile sînt aproape necorelate cu log-volatilitatea (+0,04): semnătura invariantă la translație reflectă forma, nu nivelul

Ponderea perioadelor de stres în nucleu




- ▣ Ponderea pe care Sig-LK ($h = 1$) o atribuie celor mai volatile 10% dintre zile din fereastra de antrenare, medie pe clasă și pe trei luni
- ▣ Acțiuni: media 6,7%, între 4,4% și 9,9% (maximul pe 17 mar. 2020): mereu sub cele 10% ale ponderării egale; futures și FX arată același tipar
- ▣ Mecanismul din spatele rezultatului nul pentru H2: ponderile nu implementează „învățăm din crizele trecute”

Variabilele selectate de LASSO




- Ponderea reestimărilor în care un regresor este în suportul ales prin BIC pentru Sig-LK; t = timp, $\ln RV = \ln RV$, r = randament cumulat
- Termenii log-HAR sînt păstrați în 99%, 94% și 93% dintre reestimări: LASSO redescoperă HAR; suport mediu 8,7 regresori (Sig-L), 6,7 (Sig-LK)
- Cel mai frecvent termen al semnăturii, (t,r,r) (27%), iar toți termenii frecvenți sînt de nivelul 3: cubici în incremente, ajung într-un crah mult în afara intervalului de antrenare și sînt amplificați de $\exp(\cdot)$

Ablația 2×2 

- Media pe cele 50 de active a QLIKE relativ la log-HAR: trăsături (semnătură sau nu) încrucișate cu ponderi (nucleu sau egale)
- Doar ponderile (log-HAR-K): 1,002; 1,002; 1,004, niciun efect (mărima efectivă medie 816 din 1000); doar trăsăturile (Sig-L): 1,004; 1,285; 2,238
- Ambele (Sig-LK: 1,045; 1,280; 1,929) reduc pierderea de acuratețe la o lună fără a o elimina și înrăutățesc rezultatul la $h = 1$ din cauza petrolului (CL: 2,71); Gu et al. (Tabelul 3) au raportat un câștig al nucleului în șase valori săptămânale dintr-o regiune

Robustețea Sig-LK



- Sig-LK relativ la HAR (media pe 50 de active) în specificația principală, în două variante preînregistrate și cu filtrul BPQ (abaterea declarată); linia marchează log-HAR
- Adâncimea 2: 0,922 și 0,820 la $h = 5, 22$ (principal: 1,104; 1,334); traiectoria fără randamente: 0,878 și 0,770: eșecurile la orizont lung provin din termenii de nivelul 3 cu canalul randamentelor
- Variantele stabile doar ating nivelul log-HAR (0,871; 0,765): rezultatul nul pentru H1 nu depinde de adâncime sau de canale; instabilitatea, da

Pe clase de active

Sig-L relativ la log-HAR (QLIKE)	$h = 1$	$h = 5$	$h = 22$
Acțiuni (40)	1,009	1,332	2,505
Futures (5)	0,965	1,084	1,206
FX (5)	0,996	1,111	1,134

- Singurul câștig: futures la $h = 1$ (-3,5%) și, marginal, FX
 - Cinci futures și un orizont: un candidat pentru un nou studiu preînregistrat, nu o concluzie a acestuia
- Acțiunile, 80% din panel, nu arată niciun câștig: rezultatul agregat este în principal un rezultat pentru acțiuni

Limite și direcții deschise

Limitele acestui studiu

- O specificație din multe ($L = 22$, $N = 3$, trei canale, BIC, o grilă de patru puncte pentru c): un rezultat nul pentru această specificație nu este unul pentru semnături în general
- Doar nucleul trunchiat; fără factori externi (volatilitate implicită, știri macro), esențiali în Gu et al.
- Realized GARCH Hansen, Huang & Shek (2012) și modelele de referință din învățarea automată (Capitolul 13) sînt în afara comparației; acțiunile sînt evaluate doar pe șase ani

Direcții deschise

- Un nucleu sensibil la nivel: augmentarea cu punct de bază sau nivelul $\ln RV$ în distanță (Seminarul 20, C1)
- Semnături ale traiectoriei intraday (randamente la 5 minute); nucleul PDE Salvi et al. (2021); log-semnături și canale mărginite (tanh) împotriva termenilor explozivi de nivelul 3 Morrill et al. (2020)
- Traiectorii între active, unde ariile Lévy măsoară relațiile lead-lag între piețe; futures la $h = 1$ pe un panel mai lung, cu această specificație fixată dinainte

O întrebare deschisă

Transferul unei metode între domenii

- Metodele circulă mai repede decât dovezile: un articol KDD despre tarife de transport devine candidat pentru volatilitate, credit, energie
 - ▶ Ce proprietăți ale problemei-sursă au făcut metoda să funcționeze?
 - ▶ Le are și problema-țintă?
- Finanțele adaugă un filtru sever: 164 de echipe care analizează aceleași date obțin estimări care diferă mai mult decât sugerează erorile lor standard [Menkveld et al. \(2024\)](#)
- Formulare formală: un transfer reușește dacă câștigul față de cel mai puternic reper simplu rămîne valabil pe o mulțime preînregistrată $\mathcal{S}$ de specificații, active și orizonturi, cu o corecție pentru testarea multiplă aplicată familiei de teste
 - ▶ În acest capitol: $\mathcal{S} = 50$ de active $\times$ 3 orizonturi $\times$ 4 variante; Holm/BH s-au aplicat pe comparație și orizont (familii de 50 de active), variantele sînt raportate descriptiv; nicio corecție comună pe toate cele 600 de celule; câștigul nu s-a confirmat

Bucula descoperirii aplicată acestui capitol

- **Citim:** un asistent listează fiecare ecuație, hiperparametru și reper din articol și marchează ce nu este publicat; fiecare element se verifică în PDF
 - ▶ **Stabilim corespondența:** se stabilește, pentru fiecare componentă, dacă se transferă, ce trebuie schimbat și ce reper o izolează
- **Preînregistrăm:** ipotezele, grila, testele și corecția fixate într-un document datat înaintea primului rezultat; asistentul face ciorna, echipa decide fiecare cifră
- **Construim și testăm piesele:** semnăturile față de identități (nivelul 1 = incrementul, Chen pe o traiectorie împărțită), nu față de altă bibliotecă
- **Rulăm grila, apoi o supunem unor teste de rezistență**
 - ▶ ce concluzii rămân valabile după corecția Holm pe 50 de active?
 - ▶ ce activ ar da un titlu înșelător?
- **Explicăm rezultatul nul:** aici ponderi plate (invarianța la translație) și termeni explozivi de nivelul 3 (legătura exponențială), ambele verificate cu date; cererile complete și lista de verificări a cercetătorului sînt în [▶ Anexă](#)

Mini studiu de caz: trei titluri din aceleași rulări

- „Semnăturile depășesc HAR pe 12 din 50 de active” (orizont de o zi, DM necorectat)
 - ▶ Adevărat, dar log-HAR singur este superior lui HAR pe 21: câștigul aparține transformării logaritmice
- „Semnăturile îmbunătățesc prognozele de volatilitate pentru E-mini S&P 500” (ES, $h = 1$, DM $t = -2,91$ față de log-HAR)
 - ▶ O celulă din 150 de celule activ-orizont: după Holm, 0 din 50 la $h = 1$ și niciuna la $h = 5, 22$
- Titlul rezultat din evaluarea preînregistrată: „niciun câștig față de log-HAR; mai slab la orizonturi mai lungi; ponderile nucleului inerte”
 - ▶ Un asistent AI rugat să „găsească unde funcționează metoda” le va produce pe primele două; planul îl protejează pe al treilea

Aplicație pentru proiect

- Alegeți o direcție deschisă din acest capitol (nucleu sensibil la nivel, semnături intraday, log-semnături, doar futures)
 - ▶ Scrieți H_0/H_1 , reperul care o izolează și rezultatul care v-ar face să renunțați la ea
- Folosiți un asistent pentru a lista ce poate merge prost în studiul dumneavoastră, apoi scrieți un test unitar pentru fiecare element
- Fixați preînregistrarea într-un document datat înaintea primei cifre în afara eșantionului; rulați grila; raportați distribuția pe S
- Documentați fiecare eroare AI detectată în `AI_ERRORS.md` (Seminarul 20, C2 dă erori tipice)

Idei de reținut

- Semnăturile transformă o fereastră într-un vector de trăsături cu fundament teoretic: identitatea lui Chen, unicitate, universalitate
- Aplicată varianței realizate, metoda lui Gu et al. nu depășește log-HAR
 - ▶ H1 (semnăturile aduc informație): nesuținută, niciun câștig la o zi, pierdere la o săptămână și la o lună
 - ▶ H2 (ponderile nucleului ajută): nesuținută, ponderile sînt aproape plate și reduc ponderea stresului trecut;
 - H3: metoda depășește doar HAR în nivel, datorită țintei logaritmice; H4 (câștiguri în stres): nesuținută
- Nucleul invariant la translație reflectă forma, nu nivelul; termenii de nivelul 3 iau valori explozive în crahuri
- Cel mai puternic efect din studiu este cel mai vechi: modelați logaritmul RV
- Un rezultat nul preînregistrat, cu ablații și cu un mecanism, este o concluzie

Studiu suplimentar

Lecturi

- Semnături: Chevyrev & Kormilitzin (2016); Lyons & McLeod (2022); măsuri realizate: Franke, Härdle & Hafner (2019) și Capitolul 9

Cursuri avansate pe quantinar.com

-  Statistics of Financial Markets
-  Applied Time Series Analysis with Python
-  Machine Learning in Financial Risk

Cod și date

- Quantlets: github.com/danpele/MFM/tree/main/Quantlets/Ch_20; date: VOLARE, gratuit pentru cercetare la volare.unime.it

Anexă: Trăsături și scalare

- Regresorii în ziua τ pentru modelele cu semnături: 3 termeni log-HAR + 39 de termeni ai semnăturii
 - ▶ $\xi_\tau = [\ln RV_\tau, \ln RV_\tau^{(w)}, \ln RV_\tau^{(m)}, \text{Sig}^3(X_{\tau-21:\tau})]$, traiectoria $X = (\text{timp}, \ln RV, r \text{ cumulat})$, 22 de puncte
- Fiecare canal q (altul decât timpul) se înmulțește cu $\kappa_q = 1/(s_q\sqrt{L-1})$, astfel încât deplasarea lui totală tipică pe fereastră este aproximativ 1
 - ▶ s_q : abaterea standard a incrementelor zilnice ale canalului q în fereastra de antrenare, pînă la originea t ; $L-1 = 21$ de incremente pe fereastră
 - ▶ Timpul nu se rescalează (incrementele constante, $s = 0$): ia valori de la 0 la 1; un cuvînt $(i_1..i_k)$ se rescalează cu $\prod_j \kappa_{i_j}$, deci semnăturile se calculează o singură dată
- Înaintea LASSO fiecare coloană este standardizată cu momentele ponderate ale ferestrei de antrenare; coloanele constante (cuvintele doar cu timp) se elimină
- Variabilele brute din τ folosesc date pînă la τ ; scalele și standardizarea folosesc date pînă la originea t : limita fără informație din viitor este t

Anexă: Estimare: alegerea lui λ fără look-ahead bias

- În fiecare fereastră de antrenare: întreaga traiectorie de regularizare LASSO ponderată, prin LARS (Least-Angle Regression, regresia unghiului minim)
 - ▶ Pentru fiecare suport de pe traiectoria de regularizare: reestimare OLS ponderată (pasul 2 din Gu et al.)
- Alegem suportul care minimizează un criteriu de tip BIC (Bayesian Information Criterion, criteriul informațional bayesian) cu mărimea efectivă a eșantionului Kish, o euristică a acestui studiu
 - ▶ $\text{BIC}(S) = n_{\text{eff}} \ln \hat{s}_S^2 + (|S| + 1) \ln n_{\text{eff}}$, $n_{\text{eff}} = 1 / \sum_{\tau} w_{\tau}^2$
 - ▶ S : un suport (mulțimea regresorilor păstrați), $|S|$: mărimea lui, +1 pentru constantă; $\hat{s}_S^2$: varianța reziduală ponderată a reestimării pe S ; primul termen: potrivirea, al doilea: penalizarea pe parametru
- Motivul pentru care nu folosim validarea încrucișată: 50 de active $\times$ 3 orizonturi $\times$ sute de reestimări; BIC folosește doar fereastra
 - ▶ Mărimea Kish corectează ponderile inegale, nu dependența serială (ținte suprapuse, $h > 1$): nu este un BIC bazat pe verosimilitate pentru aceste date

Anexă: Temperaturile nucleului alese pe blocul de validare

- c ales pentru Sig-LK ($h = 1, 5, 22$)
 - ▶ acțiuni 0,5; 0,5; 0,5; futures 2,0; 1,0; 0,5; FX 0,5; 2,0; 0,5
- c ales pentru log-HAR-K ($h = 1, 5, 22$)
 - ▶ acțiuni 0,5; 0,5; 1,0; futures 2,0; 1,0; 4,0; FX 4,0; 2,0; 4,0
- Grila $c \in \{0,5; 1; 2; 4\}$; cea mai mică temperatură (ponderile cele mai apropiate de cele egale) este aleasă pentru acțiuni la fiecare orizont; pentru futures și FX alegerea se schimbă cu orizontul

Anexă: Perioadele de evaluare

Clasa	Evaluarea începe	Se termină	Zile pe activ (mediana)
Acțiuni	27 ian. 2020	29 ian. 2026	1 499
Futures	25 sept. 2014	29 ian. 2026	2 919
FX	27 aug. 2014	29 ian. 2026	2 952

- 265 929 de prognoze în afara eșantionului pentru fiecare model (50 de active $\times$ 3 orizonturi)
- Acțiunile încep în 2015, deci evaluarea lor începe în ianuarie 2020: crahul din pandemia COVID-19 este în eșantionul fiecărei acțiuni
 - Futures și FX încep în 2009 și sînt evaluate din 2014

Anexă: Metrica articolului pe datele VOLARE

Eroarea relativă mediană $ RV - F /RV$ (%)	$h = 1$	$h = 5$	$h = 22$
HAR	57,2	48,9	51,7
log-HAR	50,4	41,9	38,7
HARQ	55,0	49,0	50,7
SHAR	57,9	49,2	51,8
log-HAR-K	49,7	41,0	38,7
Sig-L	50,1	42,6	42,6
Sig-LK	50,6	43,6	43,7

- Mediana pe active a erorii relative medii: aproximativ 40–60%, față de 1–2% pentru tarifele de transport la Gu et al.
- RV zilnică este o țintă zgomotoasă, cu cozi groase: modelele evaluate au erori relative mult mai mari decât cele raportate pentru tarifele de transport, fără ca aceasta să stabilească o limită inferioară a erorii posibile
 - Prognoze Sig-LK care depășesc pragul de zece ori maximumul din eșantion: 8, 29, 36 ($h = 1, 5, 22$), pe 10 active la $h = 5$; log-HAR: niciuna

Anexă: Filtrul „insanity”, revăzut

QLIKE relativ la HAR, filtrul BPQ pe toate modelele	$h = 1$	$h = 5$	$h = 22$
HAR	1,000	1,000	1,000
log-HAR	0,763	0,654	0,778
HARQ	0,995	0,912	1,014
SHAR	1,014	1,003	1,000
log-HAR-K	0,772	0,659	0,779
Sig-L	0,871	0,819	0,904
Sig-LK	0,890	0,867	0,930

- Filtrul îmbunătățește HARQ față de HAR (0,995 la $h = 1$ în loc de 1,140), cum au intenționat BPQ
- Sig-LK relativ la log-HAR, ambele filtrate: 1,238; 1,424; 1,209 (nefiltrat 1,045; 1,280; 1,929): distanța crește la $h = 1, 5$ și scade la $h = 22$
- Prognoze filtrate, $h = 1$: HAR 180, HARQ 140, Sig-LK 143, log-HAR 29 (din 89 893): filtrul se aplică modelelor cu semnături mult mai des decât lui log-HAR

Anexă: Verificările cercetătorului

- **Metoda este cea din articol:** nucleul, ponderile, reestimarea, ca în ecuațiile citate
 - ▶ Test: fiecare slide despre metodologie citează o ecuație, un tabel sau o secțiune a articolului; alegerile nepublicate sînt marcate ca alegeri ale studiului
- **Fără look-ahead bias:** λ , scalele, c și trăsăturile folosesc doar date disponibile la origine
 - ▶ Test: schimbați fiecare valoare de după origine (de exemplu, înmulțiți RV viitoare cu 10); prognoza făcută la origine nu trebuie să se schimbe
- **Reperul izolează ideea**
 - ▶ Test: ablația 2×2 este raportată, nu doar modelul complet față de HAR
- **Funcțiile de pierdere și testele sînt aplicate corect**
 - ▶ Test: $QLIKE(RV, RV) = 0$ și $QLIKE(RV, F) > 0$ în rest; varianța DM este HAC cu lățimea de bandă cel puțin h

Anexă: Bucla descoperirii, cererile (1/2)

- **Citim:** extragem exact ce a făcut articolul
 - ▶ „Din Gu et al. (2024, KDD), listează fiecare ecuație a estimatorului, fiecare hiperparametru și valoarea raportată și reperul fiecărui tabel. Marchează ce nu este publicat.”
 - ▶ Verificați fiecare element în PDF: numerele ecuațiilor, ale tabelelor, nucleul folosit efectiv
- **Stabilim corespondența:** ce se transferă, ce trebuie adaptat
 - ▶ „Ținta noastră este varianța realizată zilnică. Pentru fiecare componentă a metodei, spune dacă se transferă, ce trebuie schimbat și ce reper o izolează.”
- **Preînregistrăm:** ipoteze, grilă, teste, corecție, fixate într-un document datat înaintea primului rezultat
 - ▶ Asistentul face ciorna; echipa decide fiecare cifră și semnează preînregistrarea datată

Anexă: Bucla descoperirii, cererile (2/2)

- **Construim și testăm piesele:** semnăturile față de identități, nu față de altă bibliotecă
 - ▶ „Scrie teste unitare pentru o semnătură de adâncime 3: nivelul 1 egal cu incrementul, partea simetrică a nivelului 2 egală cu jumătate din produsul exterior, identitatea lui Chen pe o traiectorie împărțită.”
- **Rulăm grila, apoi o supunem unor teste de rezistență**
 - ▶ „Iată toate cele 600 de rulări (50 de active $\times$ 3 orizonturi $\times$ 4 specificații: principală, adâncimea 2, fără canalul randamentelor, filtrul BPQ). Ce concluzii rămân valabile după corecția Holm pe 50 de active? Ce activ sau ce subperioadă ar da un titlu înșelător?”
- **Explicăm rezultatul nul:** identificăm mecanismul, nu o justificare
 - ▶ Aici: ponderi plate (invarianța la translație) și termeni explozivi de nivelul 3 (legătura exponențială), ambele verificate cu date

Bibliografie (1/2)

- ▣ Barndorff-Nielsen, O.E., Hansen, P.R., Lunde, A., Shephard, N. (2008). [Designing realized kernels to measure the ex post variation of equity prices in the presence of noise](#). *Econometrica*, 76(6), 1481–1536.
- ▣ Barndorff-Nielsen, O.E., Kinnebrock, S., Shephard, N. (2010). [Measuring downside risk: realised semivariance](#). In *Volatility and Time Series Econometrics*, Oxford University Press, 117–136.
- ▣ Barndorff-Nielsen, O.E., Shephard, N. (2002). [Econometric analysis of realized volatility and its use in estimating stochastic volatility models](#). *Journal of the Royal Statistical Society B*, 64(2), 253–280.
- ▣ Belloni, A., Chernozhukov, V. (2013). [Least squares after model selection in high-dimensional sparse models](#). *Bernoulli*, 19(2), 521–547.
- ▣ Benjamini, Y., Hochberg, Y. (1995). [Controlling the false discovery rate: a practical and powerful approach to multiple testing](#). *Journal of the Royal Statistical Society B*, 57(1), 289–300.
- ▣ Benjamini, Y., Yekutieli, D. (2001). [The control of the false discovery rate in multiple testing under dependency](#). *The Annals of Statistics*, 29(4), 1165–1188.
- ▣ Bollerslev, T., Patton, A.J., Quaedvlieg, R. (2016). [Exploiting the errors: a simple approach for improved volatility forecasting](#). *Journal of Econometrics*, 192(1), 1–18.
- ▣ Chen, K.-T. (1957). [Integration of paths, geometric invariants and a generalized Baker–Hausdorff formula](#). *Annals of Mathematics*, 65(1), 163–178.
- ▣ Chevyrev, I., Kormilitzin, A. (2016). [A primer on the signature method in machine learning](#). arXiv:1603.03788.
- ▣ Cipollini, F., Cruciani, G., Gallo, G.M., Insana, A., Otranto, E., Spagnolo, F. (2026). [VOLatility Archive for Realized Estimates \(VOLARE\)](#). arXiv:2602.19732.
- ▣ Corsi, F. (2009). [A simple approximate long-memory model of realized volatility](#). *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Cuchiero, C., Gazzani, G., Svaluto-Ferro, S. (2023). [Signature-based models: theory and calibration](#). *SIAM Journal on Financial Mathematics*, 14(3), 910–957.
- ▣ Diebold, F.X., Mariano, R.S. (1995). [Comparing predictive accuracy](#). *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). [Statistics of Financial Markets: An Introduction](#), 5th ed. Springer.
- ▣ Giacomini, R., White, H. (2006). [Tests of conditional predictive ability](#). *Econometrica*, 74(6), 1545–1578.
- ▣ Gu, H., Guo, X., Jacobs, T.L., Kaminsky, P., Li, X. (2024). [Transportation marketplace rate forecast using signature transform](#). *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 4997–5005; arXiv:2401.04857.

Bibliografie (2/2)

- Hambly, B., Lyons, T. (2010). Uniqueness for the signature of a path of bounded variation and the reduced path group. *Annals of Mathematics*, 171(1), 109–167.
- Hansen, P.R., Huang, Z., Shek, H.H. (2012). Realized GARCH: a joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6), 877–906.
- Hansen, P.R., Lunde, A., Nason, J.M. (2011). The model confidence set. *Econometrica*, 79(2), 453–497.
- Király, F.J., Oberhauser, H. (2019). Kernels for sequentially ordered data. *Journal of Machine Learning Research*, 20(31), 1–45.
- Levin, D., Lyons, T., Ni, H. (2013). Learning from the past, predicting the statistics for the future, learning an evolving system. arXiv:1309.0260.
- Liu, L.Y., Patton, A.J., Sheppard, K. (2015). Does anything beat 5-minute RV? A comparison of realized measures across multiple asset classes. *Journal of Econometrics*, 187(1), 293–311.
- Lyons, T. (1998). Differential equations driven by rough signals. *Revista Matemática Iberoamericana*, 14(2), 215–310.
- Lyons, T., McLeod, A.D. (2022). Signature methods in machine learning. arXiv:2206.14674.
- Menkveld, A.J., Dreber, A., Holzmeister, F., Huber, J., Johannesson, M., Kirchler, M., et al. (2024). Nonstandard errors. *Journal of Finance*, 79(3), 2339–2390.
- Morrill, J., Fermanian, A., Kidger, P., Lyons, T. (2020). A generalised signature method for multivariate time series feature extraction. arXiv:2006.00873.
- Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- Patton, A.J., Sheppard, K. (2015). Good volatility, bad volatility: signed jumps and the persistence of volatility. *Review of Economics and Statistics*, 97(3), 683–697.
- Pele, D.T., Mazurencu-Marinescu-Pele, M. (2026). Finite-sample precision limits for expected shortfall forecast comparisons. *Mathematics*, 14(13), 2316.
- Salvi, C., Cass, T., Foster, J., Lyons, T., Yang, W. (2021). The signature kernel is the solution of a Goursat PDE. *SIAM Journal on Mathematics of Data Science*, 3(3), 873–899.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society B*, 58(1), 267–288.
- Zou, H. (2006). The adaptive lasso and its oracle properties. *Journal of the American Statistical Association*, 101(476), 1418–1429.